

- (b) Con un ensayo unilateral al nivel de significación del 0.05, se rechazará la hipótesis H_0 si T fuese mayor que $t_{.95}$, lo cual para 22 grados de libertad es 1.72.

Así, pues, se rechaza H_0 al nivel de significación del 0.05.

Se deduce que el incremento en la producción de trigo al utilizar el fertilizante es *probablemente significativo*. Sin embargo antes de sacar conclusiones definitivas referentes a la conveniencia del fertilizante, sería deseable tener alguna prueba más.

ENSAYOS RELACIONADOS CON LA DISTRIBUCION CHI-CUADRADO

- 7.20. En el pasado la desviación típica de los pesos de ciertos paquetes de 40.0 onzas, llenados por una máquina era de 0.25 onzas. Una muestra aleatoria de 20 paquetes dio una desviación típica de 0.32 onzas. ¿Es el aparente incremento de variabilidad significativa al nivel de significación del (a) 0.05 y (b) 0.01?

Hay que decidir entre las dos hipótesis:

$H_0: \sigma = 0.25$ onzas, y los resultados observados se deben al azar

$H_1: \sigma > 0.25$ onzas, y la variabilidad se ha incrementado

El valor de χ^2 para la muestra es $\chi^2 = ns^2/\sigma^2 = 20(0.32)^2/(0.25)^2 = 32.8$.

- (a) Mediante un ensayo unilateral, se rechaza H_0 al nivel de significación del 0.05 si el valor de χ^2 muestral fuese mayor que $\chi_{.95}^2$, que es igual a 30.1 para $\nu = 20 - 1 = 19$ grados de libertad. Así pues, se rechaza H_0 al nivel de significación del 0.05.
- (b) Mediante un ensayo unilateral, se rechazará H_0 al nivel de significación del 0.01 si el valor muestral de χ^2 fuese mayor que $\chi_{.99}^2$, que es igual a 36.2 para 19 grados de libertad. Así pues, no se rechaza H_0 al nivel de significación del 0.01.

Se deduce que la variabilidad se ha, probablemente incrementado. Y deberá efectuarse una revisión en la máquina.

ENSAYOS RELACIONADOS CON LA DISTRIBUCION F

- 7.21. Un instructor tiene dos clases, A y B, en una asignatura específica. La clase A tiene 16 estudiantes en tanto que la clase B tiene 25 estudiantes. En el mismo examen, aunque no hubo diferencia significativa en medias de las calificaciones, la clase A tuvo una desviación típica de 9 en tanto que la clase B tuvo una desviación típica de 12. ¿Podemos concluir al nivel de significación del (a) 0.01, (b) 0.05 que la variabilidad de la clase B es mayor que la de la clase A?

- (a) Tenemos, empleando subíndices 1 y 2 para las clases A y B respectivamente, $s_1 = 9$, $s_2 = 12$ de modo que

$$\hat{s}_1^2 = \frac{n_1}{n_1 - 1} s_1^2 = \frac{16}{15} (9)^2 = 86.4, \quad \hat{s}_2^2 = \frac{n_2}{n_2 - 1} s_2^2 = \frac{25}{24} (12)^2 = 150$$

Hay que decidir entre las dos hipótesis

$H_0: \sigma_1 = \sigma_2$, y cualquier variabilidad observada se debe al azar

$H_1: \sigma_1 > \sigma_2$, y la variabilidad de la clase A es mayor que la de la B

La decisión debe por tanto basarse en un ensayo unilateral de la distribución F. El número de grados de libertad para las clases son respectivamente $\nu_1 = 16 - 1 = 15$, $\nu_2 = 25 - 1 = 24$. Al nivel 0.01 para $\nu_1 = 15$, $\nu_2 = 24$ tenemos del Apéndice F, $F_{.99} = 2.89$. Entonces, para las muestras en cuestión,

$$F = \frac{\hat{s}_1^2}{\hat{s}_2^2} = \frac{150}{86.4} = 1.74$$

Entonces, ya que $F < F_{.99}$ no podemos rechazar H_0 al nivel 0.01.

- (b) Ya que $F_{.95} = 2.11$ para 15, 24 grados de libertad (véase Apéndice F), vemos que $F < F_{.95}$. Por tanto tampoco podemos rechazar H_0 al nivel 0.05.

7.22. ¿Cambiarían sus conclusiones en el Problema 7.21 si existe una diferencia significativa en la media de las calificaciones de las clases? Justificar su solución.

Puesto que la media real de las calificaciones no se usó para nada en el Problema 7.21 no interesa sus valores. Esto es de esperarse ya que no estamos tratando de decidir si hay una diferencia en las medias de las calificaciones, sino solamente si hay una variabilidad en las calificaciones.

CURVAS CARACTERISTICAS DE OPERACION

7.23. Con referencia al Problema 7.2 ¿cuál es la probabilidad de aceptar la hipótesis de que la moneda está bien hecha cuando la probabilidad real de cara es $p = 0.7$?

La hipótesis H_0 de que la moneda está bien hecha, es decir, $p = 0.5$ se acepta cuando el número de caras en 100 lanzamientos se encuentra entre 39.5 y 60.5. La probabilidad de rechazar H_0 cuando debería aceptarse (es decir, probabilidad de error del Tipo I) viene dada por el área total α de la región sombreada bajo la curva normal de la izquierda en la Fig. 7-6. Calculada en el Problema 7.2(a), esta área α , que representa el nivel de significación del ensayo de H_0 , es igual a 0.0358.




Fig. 7-6

Si la probabilidad de cara es $p = 0.7$, entonces la distribución de caras en 100 lanzamientos está representada por la curva normal de la derecha en la Fig. 7-6. En el diagrama se ve claramente que la probabilidad de aceptar H_0 cuando realmente $p = 0.7$ (es decir, probabilidad de error del Tipo II), está dada por el área rayada β de la figura. Para calcular esta área se observa que la distribución bajo la hipótesis $p = 0.7$ tiene una media y una desviación típica que son dadas por

$$\mu = np = (100)(0.7) = 70 \quad \sigma = \sqrt{npq} = \sqrt{(100)(0.7)(0.3)} = 4.58$$

$$60.5 \text{ en unidades tipificadas} = \frac{60.5 - 70}{4.58} = -2.07$$

$$39.5 \text{ en unidades tipificadas} = \frac{39.5 - 70}{4.58} = -6.66$$

Entonces

$$\beta = \text{área bajo la curva normal entre } z = -6.66 \text{ y } z = -2.07 = 0.0192$$

Así, pues, con la regla de decisión dada hay muy poco riesgo de aceptar la hipótesis de que la moneda está bien hecha, cuando realmente $p = 0.7$.

Adviértase que en este problema se tenía la regla de decisión de la que se obtenía α y β . En la práctica se pueden presentar otras dos posibilidades:

(1) Se decide sobre α (tal como 0.05 ó 0.01), llegando a una regla de decisión y después se calcula β .

(2) Se decide sobre α y β y después se llega a una regla de decisión.

7.24. Solucionar el Problema 7.23 si (a) $p = 0.6$, (b) $p = 0.8$, (c) $p = 0.9$, (d) $p = 0.4$.

(a) Si $p = 0.6$, la media y la desviación típica de la distribución de caras vienen dadas por

$$\mu = np = (100)(0.6) = 60 \quad \sigma = \sqrt{npq} = \sqrt{(100)(0.6)(0.4)} = 4.90$$

$$60.5 \text{ en unidades tipificadas} = \frac{60.5 - 60}{4.90} = 0.102$$

$$39.5 \text{ en unidades tipificadas} = \frac{39.5 - 60}{4.90} = -4.18$$

Entonces $\beta = \text{área bajo la curva normal entre } z = -4.18 \text{ y } z = 0.102 = 0.5405$

Así, pues, con la regla de decisión dada hay un gran riesgo de aceptar la hipótesis de que la moneda está bien hecha cuando realmente $p = 0.6$.

(b) Si $p = 0.8$, entonces $\mu = np = (100)(0.8) = 80$ y $\sigma = \sqrt{npq} = \sqrt{(100)(0.8)(0.2)} = 4$.

$$60.5 \text{ en unidades tipificadas} = \frac{60.5 - 80}{4} = -4.88$$

$$39.5 \text{ en unidades tipificadas} = \frac{39.5 - 80}{4} = -10.12$$

Entonces $\beta = \text{área bajo la curva normal entre } z = -10.12 \text{ y } z = -4.88 = 0.0000 \text{ muy aproximadamente.}$

(c) Comparando con (b) o por cálculo, se ve que si $p = 0.9$, $\beta = 0$ para todos los propósitos prácticos.

(d) Por simetría $p = 0.4$ da el mismo valor de β que $p = 0.6$; es decir, $\beta = 0.5405$.

7.25. Representar gráficamente los resultados de los Problemas 7.23 y 7.24 construyendo un gráfico cuyos ejes sean (a) β y p , (b) $(1 - \beta)$ y p . Interpretar los gráficos obtenidos.

La Tabla 7-3 muestra los valores de β correspondientes a valores dados de p , como los obtenidos en los Problemas 7.23 y 7.24.

Tabla 7-3

p	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9
β	0.0000	0.0000	0.0192	0.5405	0.9642	0.5405	0.0192	0.0000	0.0000

Nótese que β representa la probabilidad de aceptar la hipótesis $p = 0.5$ cuando realmente p tiene un valor distinto a 0.5. Sin embargo, si realmente $p = 0.5$ se puede interpretar β como la probabilidad de aceptar $p = 0.5$ cuando debiera ser aceptado. Esta probabilidad es igual a $1 - 0.0358 = 0.9642$ y ha sido introducida en la Tabla 7-3.




Fig. 7-7

(a) El gráfico β, p se muestra en la Fig. 7-7.(a), se llama *curva característica de operación* o *curva OC* de la regla de la decisión o ensayo de hipótesis.

La distancia del punto máximo de la curva OC a la línea $\beta = 1$ es igual a $\alpha = 0.0358$ al nivel de significación del ensayo.

En general, el apuntamiento mayor de la curva OC es la mejor regla de decisión para rechazar hipótesis que no son válidas.

- (b) El gráfico $(1 - \beta)$, p se muestra en la Fig. 7-7(b), se llama *curva de potencia* de la regla de decisión o ensayo de hipótesis. Esta curva se obtiene sencillamente invirtiendo la curva OC, de modo que realmente ambos gráficos son equivalentes.

La cantidad $(1 - \beta)$ se llama a menudo *función de potencia*, puesto que indica la aptitud o *potencia* de un ensayo para rechazar hipótesis que son falsas, es decir, que deberían ser rechazadas. La cantidad β se llama también *función característica de operación* de un ensayo.

- 7.26. Una compañía fabrica cuerdas cuyas resistencias a la rotura tienen un valor medio de 300 libras y una desviación típica de 24 libras. Se cree que mediante un nuevo proceso de fabricación puede incrementarse la resistencia media. (a) Diseñar una regla de decisión para rechazar el proceso primitivo al nivel de significación del 0.01 si se pone de manifiesto que debe rechazarse al ensayar 64 cuerdas. (b) Bajo la regla de decisión adoptada en (a), ¿cuál es la probabilidad de aceptar el proceso primitivo cuando en efecto el nuevo proceso incrementa la resistencia media a 310 libras? Supóngase que la desviación típica se mantiene en 24 libras.

- (a) Si μ es la resistencia media, se quiere decidir entre las hipótesis:

$H_0: \mu = 300$ libras, y el nuevo proceso es igual que el primitivo

$H_1: \mu > 300$ libras, y el nuevo proceso es mejor que el primitivo

Para un ensayo unilateral al nivel de significación del 0.01, se tiene la siguiente regla de decisión (referente con la Fig. 7-8):

- (1) Se rechaza H_0 si la z de la media de resistencia muestral es mayor que 2.33.
- (2) Se acepta H_0 en caso contrario.

Puesto que $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{\bar{X} - 300}{24/\sqrt{64}}$, $\bar{X} = 300 + 3Z$. Entonces si $Z > 2.33$, $\bar{X} > 300 + 3(2.33) = 307.0$ lb.

Así, la regla de decisión anterior se convierte en:

- (1) Se rechaza H_0 si la resistencia media de 64 cuerdas excede a 307.0 libras.
- (2) Se acepta H_0 en caso contrario.

- (b) Considérense las dos hipótesis ($H_0: \mu = 300$ libras) y ($H_1: \mu = 310$ libras). Las distribuciones de las resistencias medias correspondientes a estas dos hipótesis se representan, respectivamente con las distribuciones normales de la izquierda y de la derecha de la Fig. 7-9.

La probabilidad de aceptar el proceso primitivo cuando la nueva resistencia media sea realmente 310 libras se representa por el área β de la Fig. 7-9. Para hallar su valor nótese que 307.0 libras en unidades tipificadas $= (307.0 - 310)/3 = -1.00$; de aquí que

$\beta = \text{área bajo la curva normal de la derecha a la izquierda de } z = -1.00 = 0.1587$.

Esta es la probabilidad de aceptar $H_0: \mu = 300$ libras cuando realmente $H_1: \mu = 310$ libras es cierta, es decir, es la probabilidad de cometer error del Tipo II.




Fig. 7-8




Fig. 7-9

- 7.27. Construir (a) una curva OC y (b) una curva de potencia para el Problema 7.26, suponiendo que la desviación típica de las resistencias se mantiene en 24 libras.

Razonando análogamente a como se hizo en el Problema 7.26(b), se puede hallar β para los casos en que el

nuevo proceso da una resistencia media μ igual a 305 libras, 315 libras, etc. Por ejemplo, si $\mu = 305$ libras, entonces 307.0 libras en unidades tipificadas $= (307.0 - 305)/3 = 0.67$, y de aquí

$$\beta = \text{área bajo la curva normal de la derecha a la izquierda de } z = 0.67 = 0.7486$$

De esta forma se obtiene la Tabla 7-4.

Tabla 7-4

μ	290	295	300	305	310	315	320
β	1.0000	1.0000	0.9900	0.7486	0.1587	0.0038	0.0000




Fig. 7-10

- (a) La curva OC se muestra en la Fig. 7-10(a). En esta curva se ve que la probabilidad de seguir con el proceso primitivo, si el nuevo da una resistencia menor de 300 libras, es prácticamente 1 (excepto para el nivel de significación del 0.01 cuando el nuevo proceso da una media de 300 libras). Después, la curva baja rápidamente hacia cero, de modo que no hay probabilidad de seguir con el proceso primitivo cuando la media de resistencia es mayor de 315 libras.
- (b) La curva de potencia se ve en la Fig. 7-10(b); se pueden obtener de ella las mismas interpretaciones que de la curva OC, ya que las dos curvas son esencialmente equivalentes.

7.28. Para ensayar la hipótesis de que una moneda está bien hecha (es decir, $p = 0.5$) mediante un número de lanzamientos de la moneda, se desea imponer las siguientes restricciones: (A) la probabilidad de rechazar la hipótesis cuando sea realmente correcta debe ser a lo sumo 0.05; (B) la probabilidad de aceptar la hipótesis cuando realmente p difiera de 0.5 en 0.1 o más (es decir, $p \geq 0.6$ ó $p \leq 0.4$) debe ser a lo sumo 0.05. Determinar el tamaño mínimo de muestra necesario y enunciar la regla de decisión resultante.

Aquí se ha puesto límite al riesgo de error del Tipo I y Tipo II. Por ejemplo, la restricción (A) impuesta requiere que la probabilidad de error del Tipo I sea a lo sumo $\alpha = 0.05$, mientras que la restricción (B) requiere que la probabilidad de error del Tipo II sea a lo sumo $\beta = 0.05$. La situación planteada se ve gráficamente en la Fig. 7-11.

Denótese por n el tamaño de muestra pedido y por x el número de caras en los n lanzamientos, por encima del cual se rechaza la hipótesis de que $p = 0.5$. De la Fig. 7-11 se tiene:




Fig. 7-11

(1) El área bajo la curva normal $p = 0.5$ a la derecha de $\frac{x - np}{\sqrt{npq}} = \frac{x - 0.5n}{0.5\sqrt{n}}$ es 0.025.

(2) El área bajo la curva normal $p = 0.6$ a la izquierda de $\frac{x - np}{\sqrt{npq}} = \frac{x - 0.6n}{0.49\sqrt{n}}$ es 0.05.

Realmente el área entre

$$\frac{(n - x) - 0.6n}{0.49\sqrt{n}} \quad \text{y} \quad \frac{x - 0.6n}{0.49\sqrt{n}}$$

es 0.05; (2) es una cantidad muy aproximada. Obsérvese que tomando la probabilidad de aceptación como 0.05 en el "peor de los casos", $p = 0.6$, automáticamente tomaríamos como 0.05 o menos cuando p tiene cualquier otro valor por fuera del recorrido 0.4 a 0.6. Por tanto un promedio ponderado de todas estas probabilidades, que representan la probabilidad de error del tipo II, también será 0.05 o menos.

De (1) $\frac{x - 0.5n}{0.5\sqrt{n}} = 1.96$ ó (3) $x = 0.5n + 0.980\sqrt{n}$.

De (2) $\frac{x - 0.6n}{0.49\sqrt{n}} = -1.645$ ó (4) $x = 0.6n - 0.806\sqrt{n}$.

De (3) y (4), $n = 318.98$. Se sigue que el tamaño de la muestra debe ser al menos 319, es decir, se debe lanzar la moneda al menos 319 veces. Haciendo $n = 319$ en (3) o (4), $x = 177$.

Para $p = 0.5$, $x - np = 177 - 159.5 = 17.5$. Así pues, se adopta la siguiente regla de decisión:

(a) Se acepta la hipótesis $p = 0.5$, si el número de caras en 319 lanzamientos está dentro del recorrido 159.5 ± 17.5 , es decir, entre 142 y 177.

(b) Se rechaza la hipótesis en caso contrario.

GRAFICOS DE CONTROL DE CALIDAD

7.29. Se construye una máquina que producirá cojinetes de bolas teniendo un diámetro medio de 0.574 pulgadas y una desviación típica de 0.008 pulgadas. Para determinar si la máquina está adecuadamente construida para el fin que se destina, se toma una muestra de 6 cojinetes cada 2 horas, por ejemplo, y se observa el diámetro medio de la muestra. (a) Diseñar una regla de decisión mediante la cual se puede estar razonablemente cierto de que la calidad del producto está de acuerdo con las normas requeridas. (b) Mostrar cómo se representaría gráficamente la regla de decisión de (a).

(a) Con confianza del 99.73% se puede decir que la media muestral $\bar{X}$ debe estar dentro del intervalo $(\mu_{\bar{X}} - 3\sigma_{\bar{X}})$ a $(\mu_{\bar{X}} + 3\sigma_{\bar{X}})$ ó $(\mu - 3\sigma/\sqrt{n})$ a $(\mu + 3\sigma/\sqrt{n})$. Puesto que $\mu = 0.574$, $\sigma = 0.008$ y $n = 6$, se sigue que con el 99.73% de confianza la media muestral se encontrará entre $(0.574 - 0.024/\sqrt{6})$ y $(0.574 + 0.024/\sqrt{6})$ o entre 0.564 y 0.584 pulgadas.

De aquí que la regla de decisión sea como sigue:

(1) Si la media muestral cae dentro del intervalo 0.564 a 0.584 pulgadas, se supone que la máquina es adecuada para el trabajo pedido.

(2) De otro modo, la máquina no será adecuada y habrá que buscar la razón de su ineptitud.

(b) Un registro de las medias muestrales puede llevarse por medio de un gráfico tal como se muestra en la Fig. 7-12, llamado *gráfico de control de calidad*. Cada vez que se observa una media muestral se representa por un punto en el gráfico. En tanto que los puntos se encuentran entre los límites 0.564 y 0.584 pulgadas, el proceso está bajo control. Cuando un punto se sale de estos límites control (tal como en la tercera muestra tomada el jueves), hay la posibilidad de que falle algo y se precisa una investigación del posible fallo.

Los límites de control determinados anteriormente se llaman límites de confianza del 99.73% o brevemente límites 3σ . Sin embargo, pueden igualmente determinarse otros límites de confianza, tales como los límites del 99% o del 95%. La elección en cada caso depende de las circunstancias particulares del mismo.




Fig. 7-12

AJUSTE DE DATOS A DISTRIBUCIONES TEORICAS

7.30. Ajustar una distribución binomial a los datos del Problema 5.30, página 178.

Se tiene $P(x \text{ caras en una serie de 5 lanzamientos}) = f(x) = {}_5C_x p^x q^{5-x}$, donde p y q son las probabilidades respectivas de cara y sello en un solo lanzamiento de la moneda. La media del número de caras es $\mu = np = 5p$.

Para la distribución de frecuencias observada, la media del número de caras es

$$\frac{\sum fx}{\sum f} = \frac{(38)(0) + (144)(1) + (342)(2) + (287)(3) + (164)(4) + (25)(5)}{1000} = \frac{2470}{1000} = 2.47$$

Igualando las medias teóricas y real se tiene $5p = 2.47$ ó $p = 0.494$. Así pues, la distribución binomial ajustada viene dada por $f(x) = {}_5C_x (0.494)^x (0.506)^{5-x}$.

En la Tabla 7-5 se han obtenido estas probabilidades así como las frecuencias esperadas (teóricas) y las observadas. El ajuste se observa que es bueno. La bondad del ajuste se estudia en el Problema 7.43.

Tabla 7-5

Número de caras x	$P(x \text{ caras})$	Frecuencia esperada	Frecuencia observada
0	0.0332	33.2 ó 33	38
1	0.1619	161.9 ó 162	144
2	0.3162	316.2 ó 316	342
3	0.3087	308.7 ó 309	287
4	0.1507	150.7 ó 151	164
5	0.0294	29.4 ó 29	25

7.31. Utilizar papel gráfico de probabilidad para determinar si la distribución de frecuencias de la Tabla 5-2, página 163 puede ajustarse a una distribución normal.

Tabla 7-6

Estatura (pulgadas)	Frecuencias Relativas Acumuladas (%)
menor que 61.5	5.0
menor que 64.5	23.0
menor que 67.5	65.0
menor que 70.5	92.0
menor que 73.5	100.0

Primero, la distribución de frecuencias dada se convierte en una distribución de frecuencias relativas acumuladas, como se muestra en la Tabla 7-6. Después, las frecuencias relativas acumuladas expresadas en porcentajes, son pasadas sobre los límites reales superiores de clase, en un papel gráfico de probabilidad especial, como se ve en la Fig. 7-13. El grado en que los puntos así dibujados se encuentran sobre una línea recta, determina la bondad de ajuste de la distribución dada a la distribución normal. Por lo anterior, se observa que hay una distribución normal que se ajusta estrechamente a los datos. Véase Problema 7.32.




Fig. 7-13

7.32. Ajustar una curva normal a los datos de la Tabla 5-2, página 163.

Tabla 7-7

Estatura (pulgadas)	Límites reales de clase x	z para los límites reales de clase	Area bajo la curva normal desde 0 hasta z	Area para cada clase	Frecuencia esperada	Frecuencia observada
60-62	59.5	-2.72	0.4967	0.0413 0.2068 0.3892 0.2771 0.0743	4.13 ó 4	5
63-65	62.5	-1.70	0.4554		20.68 ó 21	18
66-68	65.5	-0.67	0.2486		38.92 ó 39	42
69-71	68.5	0.36	0.1406		27.71 ó 28	27
72-74	71.5	1.39	0.4177		7.43 ó 7	8
	74.5	2.41	0.4920			

$$\bar{x} = 61.45 \text{ pulgadas}, \quad s = 2.92 \text{ pulgadas}$$

El trabajo puede organizarse como en la Tabla 7-7. Para calcular z de los límites reales de clase, se utiliza $z = (x - \bar{x})/s$, donde la media $\bar{x}$ y la desviación típica s se han obtenido en los Problemas 5.35 y 5.40 respectivamente.

La cuarta columna, que da las áreas bajo la curva normal de 0 a z se obtiene con la tabla del Apéndice C. De aquí se sacan las áreas bajo la curva normal entre los valores sucesivos de z , dadas en la quinta columna. Estas se obtienen restando las áreas sucesivas de la cuarta columna cuando las correspondientes z tienen igual signo y sumándolas cuando tienen signo contrario (lo cual solo ocurre una vez en la tabla). La razón de esto se ve claramente con un diagrama.

Multiplicando los valores de la quinta columna (que representan las frecuencias relativas) por la frecuencia total n (en este caso $n = 100$), se obtienen las frecuencias esperadas de la sexta columna. Y se pone de manifiesto que se ajustan bastante bien con las frecuencias observadas realmente, anotadas en la última columna.

La "bondad del ajuste" de la distribución se considera en el Problema 7.44.

7.33. La Tabla 7-8 muestra el número de días f durante un período de 50 días, durante los cuales x autos tuvieron accidentes en una ciudad. Ajustar los datos a una distribución de Poisson.

El número medio de accidentes es

$$\lambda = \frac{\sum fx}{\sum f} = \frac{(21)(0) + (18)(1) + (7)(2) + (3)(3) + (1)(4)}{50} = \frac{45}{50} = 0.90$$

Entonces, de acuerdo con la distribución de Poisson,

$$P(x \text{ accidentes}) = \frac{(0.90)^x e^{-0.90}}{x!}$$

Tabla 7-8

Número de accidentes, x	Número de días, f
0	21
1	18
2	7
3	3
4	1
TOTAL	50

En la Tabla 7-9 aparecen las probabilidades para 0, 1, 2, 3 y 4 accidentes de esta distribución de Poisson, así como los números teóricos de días en los que se presentarán x accidentes (obtenidos multiplicando las correspondientes probabilidades por 50). Para conveniencia de la comparación, la cuarta columna que da los números de días observados se ha repetido.

Tabla 7-9

Número de accidentes, x	$P(x \text{ accidentes})$	Número de días esperado	Número de días observado
0	0.4066	20.33 ó 20	21
1	0.3659	18.30 ó 18	18
2	0.1647	8.24 ó 8	7
3	0.0494	2.47 ó 2	3
4	0.0111	0.56 ó 1	1

Nótese que el ajuste de los datos dados a una distribución de Poisson es bueno.

Para una verdadera distribución de Poisson, la varianza $\sigma^2 = \lambda$. El cálculo de la varianza de la distribución dada, da 0.97. Comparando con el valor de $\lambda = 0.90$ hallado, puede ser esto un indicio de la adaptabilidad de la distribución de Poisson a la muestra de datos.

LA PRUEBA CHI-CUADRADO

7.34. En 200 lanzamientos de una moneda se observaron 115 caras y 85 sellos. Ensayar la hipótesis de que la moneda está bien hecha con un nivel de significación del (a) 0.05, (b) 0.01.

Las frecuencias de caras y sellos observadas son, respectivamente $x_1 = 115$, $x_2 = 85$.

Las frecuencias de caras y sellos esperadas si la moneda está bien hecha son $np_1 = 100$, $np_2 = 100$, respectivamente. Entonces

$$\chi^2 = \frac{(x_1 - np_1)^2}{np_1} + \frac{(x_2 - np_2)^2}{np_2} = \frac{(115 - 100)^2}{100} + \frac{(85 - 100)^2}{100} = 4.50$$

Puesto que el número de categorías o clases (caras, sellos) es $k = 2$, $\nu = k - 1 = 2 - 1 = 1$.

(a) El valor crítico $\chi_{.95}^2$ para 1 grado de libertad es 3.84. Entonces, puesto que $4.50 > 3.84$, se rechaza la hipótesis de que la moneda está bien hecha al nivel de significación del 0.05.

(b) El valor crítico $\chi_{.99}^2$ para 1 grado de libertad es 6.63. Entonces, puesto que $4.50 < 6.63$, no se rechaza la hipótesis de que la moneda está bien hecha al nivel de significación del 0.01.

Se deduce de los resultados observados que son *probablemente significativos* y la moneda *no está probablemente bien hecha*.

Para una comparación de este método con los métodos utilizados anteriormente, véase método 1 del Problema 7.36.

7.35. Solucionar el Problema 7.34 utilizando la corrección de Yates.

$$\begin{aligned}\chi^2 \text{ (corregida)} &= \frac{(|x_1 - np_1| - 0.5)^2}{np_1} + \frac{(|x_2 - np_2| - 0.5)^2}{np_2} \\ &= \frac{(|115 - 100| - 0.5)^2}{100} + \frac{(|85 - 100| - 0.5)^2}{100} = \frac{(14.5)^2}{100} + \frac{(14.5)^2}{100} = 4.205\end{aligned}$$

Puesto que $4.205 > 3.84$ y $4.205 < 6.63$ se deducen las mismas conclusiones que en el Problema 7.34.

Para una comparación con los métodos anteriores, véase método 2 del Problema 7.36.

7.36. Solucionar el Problema 7.34 mediante la aproximación normal a la distribución binomial.

Bajo la hipótesis de que la moneda está bien hecha, la media y la desviación típica del número de caras esperadas en 200 lanzamientos de la moneda son $\mu = np = (200)(0.5) = 100$ y $\sigma = \sqrt{npq} = \sqrt{(200)(0.5)(0.5)} = 7.07$, respectivamente.

Método 1.

$$115 \text{ caras en unidades tipificadas} = (115 - 100)/7.07 = 2.12.$$

Con un nivel de significación del 0.05 y un ensayo bilateral, se rechaza la hipótesis de que la moneda está bien hecha, si el valor de z está fuera del intervalo -1.96 a 1.96 . Con un nivel de 0.01 el intervalo sería -2.58 a 2.58 . Se sigue como en el Problema 7.34 que la hipótesis se rechaza al nivel de 0.05 pero no al de 0.01.

Nótese que el cuadrado del valor anterior, $(2.12)^2 = 4.50$, es el mismo valor de χ^2 obtenido en el Problema 7.34. Esto se cumple siempre que la prueba de chi-cuadrado comprende dos categorías. Véase Problema 4.36.

Método 2.

Con la corrección para la continuidad, 115 o más caras equivale a 114.5 o más caras. Entonces 114.5 en unidades tipificadas $= (114.5 - 100)/7.07 = 2.05$. Esto conduce a las mismas conclusiones que por el primer método.

Nótese que el cuadrado de este valor, $(2.05)^2 = 4.20$, es igual al valor de χ^2 corregido con la corrección de Yates para la continuidad del Problema 7.35. Esto se cumple siempre que la prueba de chi-cuadrado comprende dos categorías y se aplica la corrección de Yates, de nuevo en consecuencia del Problema 4.36.

7.37. La Tabla 7-10 muestra las frecuencias observadas y esperadas al lanzar un dado 120 veces. Ensayar la hipótesis de que el dado esté bien hecho al nivel de significación del 0.05.

Tabla 7-10

Cara	1	2	3	4	5	6
Frecuencia observada	25	17	15	23	24	16
Frecuencia esperada	20	20	20	20	20	20

$$\begin{aligned}\chi^2 &= \frac{(x_1 - np_1)^2}{np_1} + \frac{(x_2 - np_2)^2}{np_2} + \frac{(x_3 - np_3)^2}{np_3} + \frac{(x_4 - np_4)^2}{np_4} + \frac{(x_5 - np_5)^2}{np_5} + \frac{(x_6 - np_6)^2}{np_6} \\ &= \frac{(25 - 20)^2}{20} + \frac{(17 - 20)^2}{20} + \frac{(15 - 20)^2}{20} + \frac{(23 - 20)^2}{20} + \frac{(24 - 20)^2}{20} + \frac{(16 - 20)^2}{20} = 5.00\end{aligned}$$

Puesto que el número de categorías o clases (caras 1, 2, 3, 4, 5, 6) es $k = 6$, $\nu = k - 1 = 6 - 1 = 5$.

El valor crítico $\chi^2_{.95}$ para 5 grados de libertad es 11.1. Entonces, puesto que $5.00 < 11.1$, no se puede rechazar la hipótesis de que el dado está bien hecho.

Para 5 grados de libertad $\chi^2_{.05} = 11.15$, de modo que $\chi^2 = 5.00 > 1.15$. De ello se sigue que la concordancia entre ambas frecuencias no es tan buena como para no dudar de lo deducido.

- 7.38. Una tabla de números aleatorios de 250 dígitos mostró la distribución de los dígitos 0, 1, 2, ..., 9 que se da en la Tabla 7-11. ¿Difiere significativamente la distribución observada de la distribución esperada?

Tabla 7-11

Dígito	0	1	2	3	4	5	6	7	8	9
Frecuencia observada	17	31	29	18	14	20	35	30	20	36
Frecuencia esperada	25	25	25	25	25	25	25	25	25	25

$$\chi^2 = \frac{(17-25)^2}{25} + \frac{(31-25)^2}{25} + \frac{(29-25)^2}{25} + \frac{(18-25)^2}{25} + \dots + \frac{(36-25)^2}{25} = 23.3$$

El valor crítico de $\chi^2_{.99}$ para $\nu = k - 1 = 9$ grados de libertad es 21.7; como $23.3 > 21.7$ se deduce que la distribución observada difiere significativamente de la esperada al nivel de significación del 0.01. Se deduce que cabe sospechar alguna tendencia no aleatoria en dicha tabla de números.

- 7.39. En los experimentos de Mendel con guisantes, observó 315 lisos y amarillos, 108 lisos y verdes, 101 rugosos y amarillos y 32 rugosos y verdes. De acuerdo con su teoría, estos números deberían presentarse en la proporción 9:3:3:1. ¿Hay alguna evidencia que permita dudar de su teoría al nivel de significación del (a) 0.01; (b) 0.05?

El número total de guisantes es $315 + 108 + 101 + 32 = 556$. Puesto que los números esperados están en la proporción 9:3:3:1 (y $9 + 3 + 3 + 1 = 16$), se esperarían

$$\frac{9}{16}(556) = 312.75 \text{ lisos y amarillos} \quad \frac{3}{16}(556) = 104.25 \text{ rugosos y amarillos}$$

$$\frac{3}{16}(556) = 104.25 \text{ lisos y verdes} \quad \frac{1}{16}(556) = 34.75 \text{ rugosos y verdes}$$

Entonces

$$\chi^2 = \frac{(315-312.75)^2}{312.75} + \frac{(108-104.25)^2}{104.25} + \frac{(101-104.25)^2}{104.25} + \frac{(32-34.75)^2}{34.75} = 0.470$$

Puesto que hay cuatro categorías, $k = 4$ y el número de grados de libertad es $\nu = 4 - 1 = 3$.

(a) Para $\nu = 3$, $\chi^2_{.99} = 11.3$, de modo que no se puede rechazar la teoría al nivel de 0.01.

(b) Para $\nu = 3$, $\chi^2_{.95} = 7.81$, de modo que no se puede rechazar la teoría al nivel de 0.05.

Se deduce pues, que la teoría y los resultados del experimento están de acuerdo.

Nótese que para 3 grados de libertad, $\chi^2_{.05} = 0.352$ y $\chi^2 = 0.470 > 0.352$. De modo que aunque el acuerdo es bueno, los resultados obtenidos están sujetos a una razonable influencia de error muestral.

- 7.40. Una urna contiene un gran número de bolas de cuatro colores diferentes: rojo, naranja, amarillo y verde. Una muestra de 12 bolas extraída aleatoriamente de la urna dio 2 rojas, 5 naranjas, 4 amarillas y 1 verde. Ensayar la hipótesis de que la urna contenga proporciones iguales de los diferentes colores.

Bajo la hipótesis de que la urna contiene proporciones iguales de los cuatro colores, cabría esperar 3 bolas de cada clase en la muestra de 12 bolas.

Puesto que estos números esperados son menores de 5, la aproximación de chi-cuadrado será errónea. Para evitar esto se agrupan las categorías de modo que los números esperados en cada categoría sea al menos 5.

Si se desea rechazar la hipótesis, se agrupan las categorías de forma que la evidencia en contra de la hipótesis se muestre claramente. Esto se consigue en nuestro caso considerando las categorías "roja o verde" y "naranja o amarilla", para las que la muestra dio 3 y 9 bolas, respectivamente. Puesto que el número esperado en cada categoría bajo la hipótesis de iguales proporciones es 6, se tiene

$$\chi^2 = \frac{(3-6)^2}{6} + \frac{(9-6)^2}{6} = 3$$

Para $\nu = 2 - 1 = 1$, $\chi_{.95}^2 = 3.84$. Así no se puede rechazar la hipótesis al nivel de significación del 0.05 (aunque sí se puede al nivel de 0.10). Los resultados observados pueden imaginablemente deberse al azar, aun cuando las proporciones de los colores sean iguales.

Otro método: Utilizando la corrección de Yates, se tiene

$$\chi^2 = \frac{(|3-6|-0.5)^2}{6} + \frac{(|9-6|-0.5)^2}{6} = \frac{(2.5)^2}{6} + \frac{(2.5)^2}{6} = 2.1$$

que conduce a las mismas conclusiones anteriores. Esto cabía esperarse puesto que la corrección de Yates siempre reduce el valor de χ^2 .

Debe ponerse de manifiesto que si se emplea la aproximación de χ^2 a pesar de que las frecuencias sean demasiado pequeñas, se obtendría

$$\chi^2 = \frac{(2-3)^2}{3} + \frac{(5-3)^2}{3} + \frac{(4-3)^2}{3} + \frac{(1-3)^2}{3} = 3.33$$

Puesto que para $\nu = 4 - 1 = 3$, $\chi_{.95}^2 = 7.81$ se llegaría a las mismas conclusiones que antes. Desgraciadamente, la aproximación χ^2 para frecuencias pequeñas es pobre, de aquí que cuando no sea aconsejable agrupar frecuencias se debe recurrir a los métodos exactos de probabilidad incluyendo la distribución multinomial.

- 7.41. En 360 lanzamientos de un par de dados, se observaron 74 veces "siete" y 24 veces "once". Ensayar la hipótesis de que el dado esté bien hecho al nivel de significación de 0.05.

Un par de dados puede caer de 36 formas. "Siete" se puede presentar de 6 formas y "once" de 2 formas.

Entonces $P(\text{"siete"}) = 6/36 = 1/6$ y $P(\text{"once"}) = 2/36 = 1/18$. Así pues, en 360 lanzamientos cabría esperar $1/6(360) = 60$ veces "siete" y $1/18(360) = 20$ veces "once", de modo que

$$\chi^2 = \frac{(74-60)^2}{60} + \frac{(24-20)^2}{20} = 4.07$$

Para $\nu = 2 - 1 = 1$, $\chi_{.95}^2 = 3.84$. Entonces, puesto que $4.07 > 3.84$ se estaría inclinando a rechazar la hipótesis de que los dados estén bien. Sin embargo, empleando la corrección de Yates, se tiene

$$\chi^2 (\text{corregida}) = \frac{(|74-60|-0.5)^2}{60} + \frac{(|24-20|-0.5)^2}{20} = \frac{(13.5)^2}{60} + \frac{(3.5)^2}{20} = 3.65$$

De acuerdo, pues con la χ^2 corregida, no se rechazaría la hipótesis al nivel de 0.05.

En general, para grandes muestras tales como las de aquí, los resultados que se obtienen utilizando la corrección de Yates son más dignos de confianza que los resultados no corregidos. Sin embargo, puesto que incluso el valor corregido de χ^2 se encuentra cerca del valor crítico, se duda acerca de la decisión que se debe tomar. En tales casos, lo mejor quizá sea incrementar el tamaño muestral haciendo más observaciones si se está interesado de una manera especial por alguna razón en el nivel de 0.05. De otro modo, se rechazaría la hipótesis a algún otro nivel (tal como 0.10).

- 7.42. Una encuesta sobre 320 familias con 5 niños dio la distribución que aparece en la Tabla 7-12. ¿Es el resultado consistente con la hipótesis de que el nacimiento de varón y hembra son igualmente probables?

Tabla 7-12

Número de niños y niñas	5 niños 0 niñas	4 niños 1 niña	3 niños 2 niñas	2 niños 3 niñas	1 niño 4 niñas	0 niños 5 niñas	TOTAL
Número de familias	18	56	110	88	40	8	320

Sea p = probabilidad de nacimiento de varón, y $q = 1 - p$ = probabilidad de nacimiento de hembra. Entonces, las probabilidades de (5 niños), (4 niños y 1 niña), ..., (5 niñas) son dadas por los términos del desarrollo binomial

$$(p + q)^5 = p^5 + 5p^4q + 10p^3q^2 + 10p^2q^3 + 5pq^4 + q^5$$

Si $p = q = 1/2$, se tiene

$$P(5 \text{ niños y } 0 \text{ niñas}) = \left(\frac{1}{2}\right)^5 = \frac{1}{32}$$

$$P(2 \text{ niños y } 3 \text{ niñas}) = 10\left(\frac{1}{2}\right)^2\left(\frac{1}{2}\right)^3 = \frac{10}{32}$$

$$P(4 \text{ niños y } 1 \text{ niña}) = 5\left(\frac{1}{2}\right)^4\left(\frac{1}{2}\right) = \frac{5}{32}$$

$$P(1 \text{ niño y } 4 \text{ niñas}) = 5\left(\frac{1}{2}\right)\left(\frac{1}{2}\right)^4 = \frac{5}{32}$$

$$P(3 \text{ niños y } 2 \text{ niñas}) = 10\left(\frac{1}{2}\right)^3\left(\frac{1}{2}\right)^2 = \frac{10}{32}$$

$$P(0 \text{ niños y } 5 \text{ niñas}) = \left(\frac{1}{2}\right)^5 = \frac{1}{32}$$

Entonces el número de familias que se espera tengan 5, 4, 3, 2, 1 y 0 niños se obtiene multiplicando las respectivas probabilidades anteriores por 320, y los resultados son 10, 50, 100, 100, 50, 10. De aquí

$$\chi^2 = \frac{(18-10)^2}{10} + \frac{(56-50)^2}{50} + \frac{(110-100)^2}{100} + \frac{(88-100)^2}{100} + \frac{(40-50)^2}{50} + \frac{(8-10)^2}{10} = 12.0$$

Puesto que $\chi_{.95}^2 = 11.1$ y $\chi_{.99}^2 = 15.1$ para $\nu = 6 - 1 = 5$ grados de libertad, se rechazará la hipótesis al nivel de significación del 0.05, pero no al 0.01. Así se deduce que los resultados son probablemente significativos y el nacimiento de varón y hembra no son probablemente iguales.

BONDAD DE AJUSTE

7.43. Utilizar la prueba chi-cuadrado para determinar la bondad de ajuste de los datos del Problema 7.30.

$$\chi^2 = \frac{(38-33.2)^2}{33.2} + \frac{(144-161.9)^2}{161.9} + \frac{(342-316.2)^2}{316.2} + \frac{(287-308.7)^2}{308.7} + \frac{(164-150.7)^2}{150.7} + \frac{(25-29.4)^2}{29.4} = 7.45$$

Puesto que el número de parámetros utilizados para estimar las frecuencias esperadas es $m = 1$ (que es el parámetro p de la distribución binomial), $\nu = k - 1 - m = 6 - 1 - 1 = 4$.

Para $\nu = 4$, $\chi_{.95}^2 = 9.49$. De aquí que el ajuste de los datos es muy bueno.

Para $\nu = 4$, $\chi_{.05}^2 = 0.711$. Así puesto que $\chi^2 = 7.54 > 0.711$, el ajuste no es tan bueno como pudiera creerse.

7.44. Determinar la bondad de ajuste de los datos del Problema 7.32.

$$\chi^2 = \frac{(5-4.13)^2}{4.13} + \frac{(18-20.68)^2}{20.68} + \frac{(42-38.92)^2}{38.92} + \frac{(27-27.71)^2}{27.71} + \frac{(8-7.43)^2}{7.43} = 0.959$$

Puesto que el número de parámetros empleados en estimar las frecuencias esperadas es $m = 2$ (que son la media μ y la desviación típica σ de la distribución normal), $\nu = k - 1 - m = 5 - 1 - 2 = 2$.

Para $\nu = 2$, $\chi_{.95}^2 = 5.99$. Se deduce que el ajuste de los datos es muy bueno.

Para $\nu = 2$, $\chi_{.05}^2 = 0.103$. Entonces, puesto que $\chi^2 = 0.959 > 0.103$, el ajuste no es "demasiado bueno".

TABLAS DE CONTINGENCIA

7.45. Solucionar el Problema 7.13 utilizando la prueba chi-cuadrado.

Las condiciones del problema se presentan en la Tabla 7-13. Bajo la hipótesis nula H_0 de que el suero no tiene efecto, cabría esperar que 70 individuos de cada uno de los grupos se recuperase y 30 en cada grupo no se recuperase, como se indica en la Tabla 7-14. Adviértase que H_0 es equivalente a afirmar que la recuperación es independiente del empleo del suero, es decir, las clasificaciones son independientes.

Tabla 7-13
FRECUENCIAS OBSERVADAS

	Se recuperan	No se recuperan	TOTAL
Grupo A (utilizando suero)	75	25	100
Grupo B (no utilizando suero)	65	35	100
TOTAL	140	60	200

Tabla 7-14
FRECUENCIAS ESPERADAS BAJO H_0

	Se recuperan	No se recuperan	TOTAL
Grupo A (utilizando suero)	70	30	100
Grupo B (no utilizando suero)	70	30	100
TOTAL	140	60	200

$$\chi^2 = \frac{(75 - 70)^2}{70} + \frac{(65 - 70)^2}{70} + \frac{(25 - 30)^2}{30} + \frac{(35 - 30)^2}{30} = 2.38$$

Para determinar el número de grados de libertad, considérese la Tabla 7-15, que es igual a las dos dadas anteriormente, pero en la que solamente se han puesto los totales. Está claro que solamente se tiene libertad para colocar un número en una de las cuatro casillas vacías, puesto que una vez hecho esto los números de las restantes casillas vienen obligados por los totales ya indicados. De modo que hay un grado de libertad.

Tabla 7-15

	Se recuperan	No se recuperan	TOTAL
Grupo A			100
Grupo B			100
TOTAL	140	60	200

Puesto que $\chi_{.95} = 3.84$ para 1 grado de libertad y puesto que $\chi^2 = 2.38 < 3.84$, se deduce que los resultados *no son significativos* al nivel de 0.05. No se está así en condiciones de rechazar H_0 a este nivel y se deduce o que el suero no es efectivo o se deja sin tomar decisión en espera de posteriores ensayos.

Nótese que $\chi^2 = 2.38$ es el cuadrado del valor de $z = 1.54$, obtenido en el Problema 7.13. En general, la prueba chi-cuadrado en relación con proporciones muestrales de una tabla de contingencia 2×2 equivale a un ensayo de significación de diferencias de proporciones mediante la aproximación normal, como en la página 215 (véase Problema 7.51).

Nótese también que un ensayo unilateral utilizando χ^2 equivale a un ensayo bilateral utilizando χ , ya que, por ejemplo, $\chi^2 > \chi_{.95}^2$ corresponde a $\chi > \chi_{.95}$ ó $\chi < -\chi_{.95}$. Puesto que para las tablas 2×2 , χ^2 es el cuadrado del valor de z , se sigue que χ es lo mismo que z en este caso. Así pues, al rechazar una hipótesis al nivel de 0.05 utilizando χ^2 equivale a rechazar esta hipótesis con un ensayo unilateral al nivel de 0.10 utilizando z .

7.46. Solucionar el Problema 7.45 aplicando la corrección de Yates.

$$\chi^2 (\text{corregida}) = \frac{(|75 - 70| - 0.5)^2}{70} + \frac{(|65 - 70| - 0.5)^2}{70} + \frac{(|25 - 30| - 0.5)^2}{30} + \frac{(|35 - 30| - 0.5)^2}{30} = 1.93$$

Obteniéndose que las conclusiones del Problema 7.45 son también válidas aquí. Esto podría haberse visto rápidamente, ya que la corrección de Yates siempre disminuye el valor de χ^2 .

7.47. En la Tabla 7-16 se indican los estudiantes aprobados y suspendidos por 3 profesores: Sr. X, Sr. Y y Sr. Z. Ensayar la hipótesis de que las proporciones de estudiantes suspendidos por los tres profesores son iguales.

Bajo la hipótesis H_0 de que las proporciones de estudiantes suspendidos por los tres profesores son las mismas, habrían suspendido $27/180 = 15\%$ de los estudiantes y

Tabla 7-16
FRECUENCIAS OBSERVADAS

	Sr. X	Sr. Y	Sr. Z	TOTAL
Aprobados	50	47	56	153
Suspendidos	5	14	8	27
TOTAL	55	61	64	180

habrían aprobado el 85% de los estudiantes. Las frecuencias esperadas bajo H_0 se muestran en la Tabla 7-17.

Tabla 7-17
FRECUENCIAS ESPERADAS BAJO H_0

	Sr. X	Sr. Y	Sr. Z	TOTAL
Apro- bados	85% de 55 = 46.75	85% de 61 = 51.85	85% de 64 = 54.40	153
Suspen- didos	15% de 55 = 8.25	15% de 61 = 9.15	15% de 64 = 9.60	27
TOTAL	55	61	64	180

Tabla 7-18

	Sr. X	Sr. Y	Sr. Z	TOTAL
Apro- bados				153
Suspen- didos				27
TOTAL	55	61	64	180

Entonces

$$\chi^2 = \frac{(50 - 46.75)^2}{46.75} + \frac{(47 - 51.85)^2}{51.85} + \frac{(56 - 54.40)^2}{54.40} + \frac{(5 - 8.25)^2}{8.25} + \frac{(14 - 9.15)^2}{9.15} + \frac{(8 - 9.60)^2}{9.60} = 4.84$$

Para determinar el número de grados de libertad, considérese la Tabla 7-18, que es igual que la Tabla 7-17 pero en la que solamente se han puesto los totales. Está claro que como cada fila y cada columna han de cumplir con los totales, solamente se está en libertad de poner al azar un número en una de las casillas de la primera columna y otro en una de las casillas de la segunda o tercera columna, después de lo cual, todos los números restantes vienen obligados por los totales. Así pues, hay en este caso dos grados de libertad.

Puesto que $\chi^2_{.95} = 5.99$, no se puede rechazar H_0 al nivel de 0.05. Nótese, sin embargo, que puesto que $\chi^2_{.90} = 4.61$, se puede rechazar H_0 al nivel de 0.10 si se está dispuesto a correr el riesgo de estar equivocado 1 vez de cada 10.

7.48. Mostrar que para una tabla de contingencia $h \times k$ ($h > 1, k > 1$) el número de grados de libertad es $(h-1)(k-1)$.

Hay $h + k - 1$ totales independientes de un total hk . Se deduce que el número de grados de libertad es

$$hk - (h + k - 1) = (h-1)(k-1)$$

como se requería. Nótese que este resultado es válido si se conocen los parámetros poblacionales necesarios para obtener las frecuencias teóricas; de otra forma se necesitan ajustes como los descritos en (b), página 220.

7.49. Demostrar que para la tabla de contingencia 2×2 que se muestra en la Tabla 7-19

$$\chi^2 = \frac{n(a_1b_2 - a_2b_1)^2}{n_1n_2n_An_B}$$

Tabla 7-19
RESULTADOS OBSERVADOS

	I	II	TOTAL
A	a_1	a_2	n_A
B	b_1	b_2	n_B
TOTAL	n_1	n_2	n

Tabla 7-20
RESULTADOS ESPERADOS

	I	II	TOTAL
A	n_1n_A/n	n_2n_A/n	n_A
B	n_1n_B/n	n_2n_B/n	n_B
TOTAL	n_1	n_2	n

Como en el Problema 7-45, los resultados esperados bajo la hipótesis nula aparecen en la Tabla 7-20. Entonces

$$\chi^2 = \frac{(a_1 - n_1n_A/n)^2}{n_1n_A/n} + \frac{(a_2 - n_2n_A/n)^2}{n_2n_A/n} + \frac{(b_1 - n_1n_B/n)^2}{n_1n_B/n} + \frac{(b_2 - n_2n_B/n)^2}{n_2n_B/n}$$

Pero

$$a_1 - \frac{n_1n_A}{n} = a_1 - \frac{(a_1 + b_1)(a_1 + a_2)}{a_1 + b_1 + a_2 + b_2} = \frac{a_1b_2 - a_2b_1}{n}$$

Análogamente
$$a_2 - \frac{n_2 n_A}{n} = b_1 - \frac{n_1 n_B}{n} = b_2 - \frac{n_2 n_B}{n} = \frac{a_1 b_2 - a_2 b_1}{n}$$

Así, se puede escribir

$$\chi^2 = \frac{n}{n_1 n_A} \left(\frac{a_1 b_2 - a_2 b_1}{n} \right)^2 + \frac{n}{n_2 n_A} \left(\frac{a_1 b_2 - a_2 b_1}{n} \right)^2 + \frac{n}{n_1 n_B} \left(\frac{a_1 b_2 - a_2 b_1}{n} \right)^2 + \frac{n}{n_2 n_B} \left(\frac{a_1 b_2 - a_2 b_1}{n} \right)^2$$

que al simplificar, da

$$(1) \quad \chi^2 = \frac{n(a_1 b_2 - a_2 b_1)^2}{n_1 n_2 n_A n_B} = \frac{n \Delta^2}{n_1 n_2 n_A n_B}$$

donde $\Delta = a_1 b_2 - a_2 b_1$, $n = a_1 + a_2 + b_1 + b_2$, $n_1 = a_1 + b_1$, $n_2 = a_2 + b_2$, $n_A = a_1 + a_2$, $n_B = b_1 + b_2$. Si se aplica la corrección de Yates, (1) se reemplaza por

$$(2) \quad \chi^2 \text{ (corregida)} = \frac{n(|\Delta| - \frac{1}{2}n)^2}{n_1 n_2 n_A n_B}$$

7.50. Ilustrar el resultado del Problema 7.49 para los datos del Problema 7.45.

En el Problema 7.45, $a_1 = 75$, $a_2 = 25$, $b_1 = 65$, $b_2 = 35$, $n_1 = 140$, $n_2 = 60$, $n_A = 100$, $n_B = 100$, y $n = 200$; entonces (1) del Problema 7.49 da

$$\chi^2 = \frac{200[(75)(35) - (25)(65)]^2}{(140)(60)(100)(100)} = 2.38$$

Empleando la corrección de Yates, el resultado es el mismo que en el Problema 7.46:

$$\chi^2 \text{ (corregida)} = \frac{n(|a_1 b_2 - a_2 b_1| - \frac{1}{2}n)^2}{n_1 n_2 n_A n_B} = \frac{200[|(75)(35) - (25)(65)| - 100]^2}{(140)(60)(100)(100)} = 1.93$$

7.51. Demostrar que una prueba chi-cuadrado que se refiera a dos proporciones muestrales es equivalente a un ensayo de significación de diferencia de proporciones utilizando la aproximación normal (véase página 215).

Denótese por P_1 y P_2 las dos proporciones muestrales y p la proporción poblacional. Con referencia al Problema 7.49, se tiene

$$(1) \quad P_1 = \frac{a_1}{n_1}, \quad P_2 = \frac{a_2}{n_2}, \quad 1 - P_1 = \frac{b_1}{n_1}, \quad 1 - P_2 = \frac{b_2}{n_2}$$

$$(2) \quad p = \frac{n_A}{n}, \quad 1 - p = q = \frac{n_B}{n}$$

de modo que

$$(3) \quad a_1 = n_1 P_1, \quad a_2 = n_2 P_2, \quad b_1 = n_1(1 - P_1), \quad b_2 = n_2(1 - P_2)$$

$$(4) \quad n_A = np, \quad n_B = nq$$

Utilizando (3) y (4), se tiene del Problema 7.49

$$\begin{aligned} \chi^2 &= \frac{n(a_1 b_2 - a_2 b_1)^2}{n_1 n_2 n_A n_B} = \frac{n[n_1 P_1 n_2 (1 - P_2) - n_2 P_2 n_1 (1 - P_1)]^2}{n_1 n_2 npnq} \\ &= \frac{n_1 n_2 (P_1 - P_2)^2}{npq} = \frac{(P_1 - P_2)^2}{pq(1/n_1 + 1/n_2)} \quad (\text{ya que } n = n_1 + n_2) \end{aligned}$$

que es el cuadrado del estadístico Z , dado en (10) en la página 215.

COEFICIENTE DE CONTINGENCIA

7.52. Hallar el coeficiente de contingencia para los datos de la tabla de contingencia del Problema 7.45.

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}} = \sqrt{\frac{2.38}{2.38 + 200}} = \sqrt{0.01176} = 0.1084$$

7.53. Hallar el valor máximo de C para la tabla 2×2 del Problema 7.13.

El valor máximo de C se presenta cuando las dos clasificaciones son perfectamente dependientes o asociadas. En tal caso, todos los que tomen el suero se recuperarán y todos los que no se lo tomen no se recuperarán. Esta tabla de contingencia aparece en la Tabla 7-21.

Puesto que las frecuencias esperadas, suponiendo independencia total, son todas iguales a 50.

Tabla 7-21

	Se recuperan	No se recuperan	TOTAL
Grupo A (utilizando suero)	100	0	100
Grupo B (no utilizando suero)	0	100	100
TOTAL	100	100	200

$$\chi^2 = \frac{(100-50)^2}{50} + \frac{(0-50)^2}{50} + \frac{(0-50)^2}{50} + \frac{(100-50)^2}{50} = 200$$

Entonces el valor máximo de C es $\sqrt{\chi^2/(\chi^2 + n)} = \sqrt{200/(200 + 200)} = 0.7071$.

En general, para la dependencia total en una tabla de contingencia, en la que el número de filas y columnas son ambas iguales a k , las únicas frecuencias de casillas que no son cero aparecen en la diagonal que baja de izquierda a derecha de la tabla. Para tales casos, $C_{\max} = \sqrt{(k-1)/k}$. (Véase Problema 7.127).

PROBLEMAS DIVERSOS

7.54. Un instructor hace un cuestionario formado por 10 preguntas falso-verdadero. Para ensayar la hipótesis de que el estudiante acierte por casualidad, adopta la siguiente regla de decisión: (i) si 7 o más respuestas son acertadas el estudiante no las acierta por casualidad; (ii) en caso contrario, el estudiante está adivinando. Hallar la probabilidad de rechazar la hipótesis cuando es correcta.

Sea p la probabilidad de que una pregunta sea contestada correctamente.

La probabilidad de contestar correctamente x preguntas de las 10 será ${}_{10}C_x p^x q^{10-x}$, donde $q = 1 - p$.

Bajo la hipótesis $p = 0.5$ (es decir, el estudiante acierta al azar).

$$\begin{aligned} P(7 \text{ o más correctas}) &= P(7 \text{ correctas}) + P(8 \text{ correctas}) + P(9 \text{ correctas}) + P(10 \text{ correctas}) \\ &= {}_{10}C_7 \left(\frac{1}{2}\right)^7 \left(\frac{1}{2}\right)^3 + {}_{10}C_8 \left(\frac{1}{2}\right)^8 \left(\frac{1}{2}\right)^2 + {}_{10}C_9 \left(\frac{1}{2}\right)^9 \left(\frac{1}{2}\right) + {}_{10}C_{10} \left(\frac{1}{2}\right)^{10} = 0.1719 \end{aligned}$$

Así, pues, la probabilidad de decidir que el estudiante no responde al azar cuando es que sí, es 0.1719. Nótese que ésta es la probabilidad de error del Tipo I.

7.55. En el problema 7.54, hallar la probabilidad de aceptar la hipótesis $p = 0.5$ cuando realmente $p = 0.7$.

Bajo la hipótesis $p = 0.7$

$$\begin{aligned} P(\text{menos de 7 correctas}) &= 1 - P(7 \text{ o más correctas}) \\ &= 1 - [{}_{10}C_7(0.7)^7(0.3)^3 + {}_{10}C_8(0.7)^8(0.3)^2 + {}_{10}C_9(0.7)^9(0.3) + {}_{10}C_{10}(0.3)^{10}] = 0.3504 \end{aligned}$$

7.56. En el Problema 7.54, hallar la probabilidad de aceptar la hipótesis $p = 0.5$ cuando realmente (a) $p = 0.6$, (b) $p = 0.8$, (c) $p = 0.9$, (d) $p = 0.4$, (e) $p = 0.3$, (f) $p = 0.2$, (g) $p = 0.1$.

(a) Si $p = 0.6$ la probabilidad pedida será

$$\begin{aligned} &1 - [P(7 \text{ correctas}) + P(8 \text{ correctas}) + P(9 \text{ correctas}) + P(10 \text{ correctas})] \\ &= 1 - [{}_{10}C_7(0.6)^7(0.4)^3 + {}_{10}C_8(0.6)^8(0.4)^2 + {}_{10}C_9(0.6)^9(0.4) + {}_{10}C_{10}(0.6)^{10}] = 0.618 \end{aligned}$$

Los resultados de (b), (c), . . . , (g) pueden hallarse análogamente y se indican en la Tabla 7-22 junto con el valor correspondiente a $p = 0.7$ hallado en el Problema 7.55. Nótese que la probabilidad se denota por β (probabilidad de error del Tipo II). Se ha incluido también el valor para $p = 0.5$ dado por $\beta = 1 - 0.1719 = 0.828$ del Problema 7.54.

Tabla 7-22


p	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9
β	1.000	0.999	0.989	0.945	0.828	0.618	0.350	0.121	0.013

- 7.57. Utilizar el Problema 7.56 para construir el gráfico de β y p obteniendo así la curva característica de operación de la regla de decisión del Problema 7.54.

El gráfico pedido es el de la Fig. 7-14. Adviértase la semejanza con la curva OC del Problema 7-27.

Si se hubiese dibujado $(1 - \beta)$ y p , se habría obtenido la curva de potencia de la regla de decisión.

El gráfico indica que la regla de decisión dada es muy adecuada para rechazar $p = 0.5$ cuando realmente $p \cong 0.8$.



- 7.58. Una moneda que se lanza 6 veces da 6 veces cara. ¿Puede deducirse que al nivel de significación (a) 0.05 y (b) 0.01 la moneda no está bien hecha? Considerar ensayos de una y dos colas.

Sea p la probabilidad de cara en un solo lanzamiento de la moneda.

Bajo la hipótesis ($H_0: p = 0.5$) (es decir, la moneda está bien hecha),

$$f(x) = P(x \text{ caras en 6 lanzamientos}) = {}_6C_x \left(\frac{1}{2}\right)^x \left(\frac{1}{2}\right)^{6-x} = \frac{{}_6C_x}{64}$$


Entonces las probabilidades de 0, 1, 2, 3, 4, 5 y 6 caras son dadas, respectivamente, por $\frac{1}{64}$, $\frac{6}{64}$, $\frac{15}{64}$, $\frac{20}{64}$, $\frac{15}{64}$, $\frac{6}{64}$ y $\frac{1}{64}$, como se muestra gráficamente en la distribución de probabilidad de la Fig. 7-15.

Ensayo unilateral:

Aquí se desea decidir entre las hipótesis ($H_0: p = 0.5$) y ($H_1: p > 0.5$). Puesto que $P(6 \text{ caras}) = \frac{1}{64} = 0.01562$ y $P(5 \text{ ó } 6 \text{ caras}) = \frac{6}{64} + \frac{1}{64} = 0.1094$, se puede rechazar H_0 al nivel 0.05, pero no al 0.01 (es decir, el resultado observado es significativo al nivel 0.05, pero no al 0.01).

Ensayo bilateral:

Aquí se desea decidir entre las hipótesis ($H_0: p = 0.5$) y ($H_1: p \neq 0.5$). Puesto que $P(0 \text{ ó } 6 \text{ caras}) = \frac{1}{64} + \frac{1}{64} = 0.03125$, se puede rechazar H_0 al nivel 0.05, pero no al 0.01.



- 7.59. Solucionar el Problema 7.58, si en la moneda sale 5 veces cara.

Ensayo unilateral. Puesto que $P(5 \text{ ó } 6 \text{ caras}) = \frac{6}{64} + \frac{1}{64} = \frac{7}{64} = 0.1094$, no se puede rechazar H_0 al nivel de 0.05 ó 0.01.

Ensayo bilateral. Puesto que $P(0 \text{ ó } 1 \text{ ó } 5 \text{ ó } 6 \text{ caras}) = 2\left(\frac{7}{64}\right) = 0.2188$, no se puede rechazar H_0 al nivel de 0.05 ó 0.01.

7.60. Mostrar que una prueba en chi-cuadrado que comprende dos categorías es equivalente al ensayo especial de significación para proporciones (página 214).

Tabla 7-23

	I	II	TOTAL
Frecuencia observada	nP	$n(1 - P)$	n
Frecuencia esperada	np	$n(1 - p) = nq$	n

Si P es la proporción muestral para la categoría I, p es la proporción poblacional y n es la frecuencia total, se pueden describir las situaciones por medio de la Tabla 7-23. Entonces, por definición,

$$\begin{aligned}\chi^2 &= \frac{(nP - np)^2}{np} + \frac{[n(1 - P) - n(1 - p)]^2}{nq} \\ &= \frac{n^2(P - p)^2}{np} + \frac{n^2(P - p)^2}{nq} = n(P - p)^2 \left(\frac{1}{p} + \frac{1}{q} \right) = \frac{n(P - p)^2}{pq} = \frac{(P - p)^2}{pq/n}\end{aligned}$$

que es el cuadrado del estadístico Z , (5) de la página 214.

7.61. Suponga que $X_1, X_2, \dots, X_k$ tienen una distribución multinomial, con frecuencias esperadas $np_1, np_2, \dots, np_k$ respectivamente. Sean $Y_1, Y_2, \dots, Y_k$ variables mutuamente independientes con distribución de Poisson y parámetros $\lambda_1 = np_1, \lambda_2 = np_2, \dots, \lambda_k = np_k$ respectivamente. Demostrar que la distribución condicional de las Y dado que

$$Y_1 + Y_2 + \dots + Y_k = n$$

es precisamente la distribución multinomial de las X .

Para la función de probabilidad conjunta de las Y tenemos

$$\begin{aligned}(1) \quad P(Y_1 = y_1, Y_2 = y_2, \dots, Y_k = y_k) &= \left[\frac{(np_1)^{y_1} e^{-np_1}}{y_1!} \right] \left[\frac{(np_2)^{y_2} e^{-np_2}}{y_2!} \right] \dots \left[\frac{(np_k)^{y_k} e^{-np_k}}{y_k!} \right] \\ &= \frac{n^{y_1 + y_2 + \dots + y_k} p_1^{y_1} p_2^{y_2} \dots p_k^{y_k}}{y_1! y_2! \dots y_k!} e^{-n}\end{aligned}$$

donde hemos utilizado el hecho de que $p_1 + p_2 + \dots + p_k = 1$. La distribución condicional que estamos buscando está dada por

$$\begin{aligned}(2) \quad P(Y_1 = y_1, Y_2 = y_2, \dots, Y_k = y_k \mid Y_1 + Y_2 + \dots + Y_k = n) \\ = \frac{P(Y_1 = y_1, Y_2 = y_2, \dots, Y_k = y_k \text{ y } Y_1 + Y_2 + \dots + Y_k = n)}{P(Y_1 + Y_2 + \dots + Y_k = n)}\end{aligned}$$

Entonces, el numerador en (2) tiene, de (1), el valor

$$\frac{n^{y_1 + y_2 + \dots + y_k} p_1^{y_1} p_2^{y_2} \dots p_k^{y_k}}{y_1! y_2! \dots y_k!} e^{-n}$$

En cuanto al denominador, sabemos del Problema 4.95, página 147, que $Y_1 + Y_2 + \dots + Y_k$ es en sí misma una variable de Poisson con parámetro $np_1 + np_2 + \dots + np_k = n$. Así el denominador tiene el valor

$$\frac{n^n e^{-n}}{n!}$$

Por tanto (2) se convierte en

$$P(Y_1 = y_1, Y_2 = y_2, \dots, Y_k = y_k \mid Y_1 + Y_2 + \dots + Y_k = n) = \frac{n!}{y_1! y_2! \dots y_k!} p_1^{y_1} p_2^{y_2} \dots p_k^{y_k}$$

que es la distribución multinomial de las X [compárese (16), página 113].

7.62. Emplear el resultado del Problema 7.61 para demostrar que χ^2 , como se define por (21), página 218, tiene aproximadamente una distribución chi-cuadrado.

Tal como se establece, (21) es difícil de manipular ya que las X distribuidas multinomialmente son dependientes, de acuerdo con la restricción (22). Sin embargo, el Problema 7.61 demuestra que podemos reemplazar las X por las Y independientes con distribución de Poisson si se cumple que $Y_1 + Y_2 + \dots + Y_k = n$. Por tanto reescribimos (21) como

$$(1) \quad \chi^2 = \left(\frac{Y_1 - \lambda_1}{\sqrt{\lambda_1}} \right)^2 + \left(\frac{Y_2 - \lambda_2}{\sqrt{\lambda_2}} \right)^2 + \dots + \left(\frac{Y_k - \lambda_k}{\sqrt{\lambda_k}} \right)^2$$

Cuando $n \rightarrow \infty$, todos los λ tienden a ∞ , y el teorema del límite central para las distribuciones de Poisson [(14), página 112] resulta

$$(2) \quad \chi^2 \approx Z_1^2 + Z_2^2 + \cdots + Z_k^2$$

donde las Z son variables normales independientes con media 0 y varianza 1 cuya distribución es condicional dependiendo del suceso.

$$(3) \quad \sqrt{\lambda_1} Z_1 + \sqrt{\lambda_2} Z_2 + \cdots + \sqrt{\lambda_k} Z_k = 0 \quad \text{ó} \quad \sqrt{p_1} Z_1 + \sqrt{p_2} Z_2 + \cdots + \sqrt{p_k} Z_k = 0$$

o, ya que las variables son continuas,

$$(4) \quad |\sqrt{p_1} Z_1 + \sqrt{p_2} Z_2 + \cdots + \sqrt{p_k} Z_k| < \epsilon$$

Denótese por $F_\nu(x)$ la función de distribución acumulada para una variable chi-cuadrado con ν grados de libertad. Entonces lo que deseamos demostrar es:

$$(5) \quad P(Z_1^2 + Z_2^2 + \cdots + Z_k^2 \leq x \mid |\sqrt{p_1} Z_1 + \sqrt{p_2} Z_2 + \cdots + \sqrt{p_k} Z_k| < \epsilon) \\ = \frac{P(Z_1^2 + Z_2^2 + \cdots + Z_k^2 \leq x \text{ y } |\sqrt{p_1} Z_1 + \sqrt{p_2} Z_2 + \cdots + \sqrt{p_k} Z_k| < \epsilon)}{P(|\sqrt{p_1} Z_1 + \sqrt{p_2} Z_2 + \cdots + \sqrt{p_k} Z_k| < \epsilon)} = F_\nu(x)$$

para un valor apropiado de ν .

Es fácil establecer (5) si utilizamos nuestra intuición geométrica. Primero que todo, el Teorema 4-3 demuestra que la distribución incondicional de $Z_1^2 + Z_2^2 + \cdots + Z_k^2$ es chi-cuadrado con k grados de libertad. Por tanto, ya que la función de densidad para cada Z_j es $(2\pi)^{-1/2} e^{-z^2/2}$,

$$(6) \quad F_k(x) = (2\pi)^{-k/2} \int \cdots \int_{z_1^2 + z_2^2 + \cdots + z_k^2 \leq x} e^{-(z_1^2 + z_2^2 + \cdots + z_k^2)/2} dz_1 dz_2 \cdots dz_k$$

Además, tenemos para el numerador de (5):

$$(7) \quad \text{Numerador} = (2\pi)^{-k/2} \int \cdots \int_{\substack{z_1^2 + z_2^2 + \cdots + z_k^2 \leq x, \\ |\sqrt{p_1} z_1 + \sqrt{p_2} z_2 + \cdots + \sqrt{p_k} z_k| < \epsilon}} e^{-(z_1^2 + z_2^2 + \cdots + z_k^2)/2} dz_1 dz_2 \cdots dz_k$$

Recordamos de la geometría analítica que en el espacio tridimensional $x_1^2 + x_2^2 + x_3^2 \leq a^2$ representa un sólido esférico de radio a con centro en el origen, en tanto que $\alpha_1 x_1 + \alpha_2 x_2 + \alpha_3 x_3 = 0$ es un plano a través del origen cuya normal es el vector unitario $(\alpha_1, \alpha_2, \alpha_3)$. La Fig. 7-16 indica la intersección de los dos cuerpos. Es lógico que cuando una función que depende solamente de la distancia desde el origen, es decir

$$f(r) \quad \text{donde} \quad r = \sqrt{x_1^2 + x_2^2 + x_3^2}$$

se integra sobre el área circular —o a través de una tira delgada en esa área— el valor de la integral es completamente independiente de los cosenos direccionales $\alpha_1, \alpha_2, \alpha_3$. En otras palabras, todos los planos cortantes a través del origen dan la misma integral.

Por analogía concluimos que en (7), donde $e^{-r^2/2}$ se integra sobre la intersección de una hipersfera alrededor del origen, se pueden dar los valores convenientes arbitrarios a las p . Escogemos

$$p_1 = p_2 = \cdots = p_{k-1} = 0, \quad p_k = 1$$

y obtenemos

$$(8) \quad \text{Numerador} = (2\pi)^{-k/2} \int \cdots \int_{z_1^2 + z_2^2 + \cdots + z_{k-1}^2 \leq x} e^{-(z_1^2 + z_2^2 + \cdots + z_{k-1}^2)/2} dz_1 dz_2 \cdots dz_{k-1} (2\epsilon) \\ = (2\pi)^{-1/2} F_{k-1}(x) (2\epsilon)$$

utilizando (6). El factor 2ϵ es el espesor de la tira.




Fig. 7-16

Para evaluar el denominador de (5) notamos que la variable aleatoria

$$W = \sqrt{p_1} Z_1 + \sqrt{p_2} Z_2 + \cdots + \sqrt{p_k} Z_k$$

es normal (puesto que es una combinación lineal de las variables Z normales e independientes), y que

$$E(W) = \sqrt{p_1}(0) + \sqrt{p_2}(0) + \cdots + \sqrt{p_k}(0) = 0$$

$$\text{Var}(W) = p_1(1) + p_2(1) + \cdots + p_k(1) = 1$$

Por tanto la función de densidad para W es $\phi(w) = (2\pi)^{-1/2} e^{-w^2/2}$, y

$$(9) \quad \text{Denominador} = P(|W| < \epsilon) = \phi(0)(2\epsilon) = (2\pi)^{-1/2}(2\epsilon)$$

Al dividir (8) por (9) obtenemos el resultado deseado, donde $\nu = k - 1$.

La "demostración" anterior (que puede hacerse rigurosa) muestra incidentalmente que cada restricción lineal colocada a las Z , y por tanto a las Y o a las X , reduce el número de grados de libertad en χ^2 en 1. Esto provee las bases para las reglas dadas en la página 219.

Problemas suplementarios

ENSAYOS DE MEDIAS Y PROPORCIONES UTILIZANDO DISTRIBUCIONES NORMALES

- 7.63. Una urna contiene bolas rojas y azules. Para ensayar la hipótesis de proporciones iguales de estos colores, se acuerda en tomar una muestra de 64 bolas con **remplazamiento**, anotando los colores extraídos y adoptando la siguiente regla de decisión: (1) se acepta la hipótesis si se extraen entre 28 y 36 bolas rojas; (2) se rechaza en caso contrario. (a) Hallar la probabilidad de rechazar la hipótesis cuando en realidad sea correcta. (b) Interpretar gráficamente la regla de decisión y el resultado obtenido en (a).
- 7.64. (a) ¿Qué regla de decisión se adoptaría en el Problema 7.63 si se quisiera que la probabilidad de rechazar la hipótesis siendo realmente correcta sea a lo sumo 0.01, es decir, se quiere un nivel de significación del 0.01? (b) ¿A qué nivel de confianza se aceptaría la hipótesis? (c) ¿Cuál sería la regla de decisión si se adoptara un nivel de significación del 0.05?
- 7.65. Supóngase que en el Problema 7.63 se desea ensayar la hipótesis de que hay *mayor proporción* de bolas rojas que de azules. (a) ¿Cuál sería la hipótesis nula y cuál la alternativa? (b) ¿Se utilizaría un ensayo de una o dos colas? ¿Por qué? (c) ¿Qué regla de decisión se adoptaría si el nivel de significación fuera del 0.05? (d) ¿Cuál sería la regla de decisión si el nivel de significación fuera del 0.01?
- 7.66. Se lanza un par de dados 100 veces y se observa que un total de "siete" aparece 23 veces. Ensayar la hipótesis de que los dados estén bien hechos, es decir, no cargados, mediante (a) un ensayo bilateral y (b) un ensayo unilateral y un nivel de significación del 0.05. Discutir las razones de las posibles preferencias de uno de estos ensayos sobre el otro.
- 7.67. Solucionar el Problema 7.66 si el nivel de significación es del 0.01.
- 7.68. Un fabricante sostiene que al menos el 95% de los equipos que suministra a una fábrica está de acuerdo con las especificaciones requeridas. Un examen sobre una muestra de 200 de tales equipos reveló que 18 eran defectuosos. Ensayar la afirmación del fabricante al nivel de significación del (a) 0.01, (b) 0.05.
- 7.69. La experiencia ha demostrado que la media de resistencia a la rotura de una determinada clase de hilo es de 9.72 onzas con una desviación típica de 1.40 onzas. Recientemente, una muestra de 36 piezas de hilo dieron una resistencia media de 8.93 onzas. ¿Se puede deducir al nivel de significación del (a) 0.05 y (b) 0.01 que el hilo es ahora peor?
- 7.70. En un examen dado a un gran número de estudiantes de muchas escuelas distintas, la puntuación media fue de 74.5 y la desviación típica fue 8.0. En una escuela determinada con 200 estudiantes el mismo examen dio una puntuación media de 75.9. Comentar la significación de este resultado al nivel de 0.05 desde el punto de vista de (a) un ensayo unilateral y (b) un ensayo bilateral, explicando las conclusiones sacadas con estos ensayos.

- 7.71. Solucionar el Problema 7.70 si el nivel de significación es del 0.01.

ENSAYOS REFERENTES A DIFERENCIAS DE MEDIAS Y PROPORCIONES

- 7.72. Una muestra de 100 bombillas de un fabricante *A* dio una duración media de 1190 horas y una desviación típica de 90 horas. Una muestra de 75 bombillas de otro fabricante *B* dio una duración media de 1230 horas con una desviación típica de 120 horas. ¿Hay diferencias entre las duraciones medias de las bombillas de los dos fabricantes al nivel de significación del (a) 0.05 y (b) 0.01?
- 7.73. En el Problema 7.72 ensayar la hipótesis de que las bombillas del fabricante *B* sean mejores a las del fabricante *A* utilizando un nivel de significación del (a) 0.05, (b) 0.01. Explicar las diferencias entre esto y lo que se pedía en el problema anterior. ¿Se contradicen los resultados con los del problema anterior?
- 7.74. En un examen de ortografía en una escuela elemental, la puntuación media de 32 niños fue de 72 con una desviación típica de 8, mientras que la puntuación media de 36 niñas fue de 75 con una desviación típica de 6. Ensayar la hipótesis de que a los niveles de significación (a) del 0.05 y (b) del 0.01 las niñas tengan mejor ortografía que los niños.
- 7.75. Para ensayar los efectos de un nuevo fertilizante sobre la producción de trigo, una parcela de terreno se dividió en 60 cuadrados de áreas iguales, todos ellos tenían idénticas características de suelo, exposición a la luz del sol, etc. El nuevo fertilizante se aplicó a 30 de estos cuadrados y el antiguo fertilizante a los restantes. El número medio de fanegadas de trigo cosechadas por cuadrado en los que se utilizó el fertilizante nuevo fue de 18.2 con una desviación típica de 0.63 fanegadas. La media y desviación típica correspondientes a los otros cuadrados fueron 17.8 y 0.54 fanegadas, respectivamente. Con un nivel de significación del (a) 0.05 y (b) 0.01, ensayar la hipótesis de que el nuevo fertilizante sea mejor que el antiguo.
- 7.76. Muestras al azar de 200 tuercas fabricadas por la máquina *A* y de 100 tuercas fabricadas por la máquina *B* dieron 19 y 5 tuercas defectuosas, respectivamente. Ensayar la hipótesis de que (a) las dos máquinas tengan diferente calidad de fabricación y (b) la máquina *B* sea mejor que *A*. Utilizar el nivel de significación del 0.05.

ENSAYOS EN RELACION CON LA DISTRIBUCIÓN *t* DE STUDENT

- 7.77. La duración media de las bombillas producidas por una compañía ha sido en el pasado de 1120 horas con una desviación típica de 125 horas. Una muestra de 8 bombillas de la producción actual dio una duración media de 1070 horas. Ensayar la hipótesis de que la duración media de las bombillas no ha cambiado, con los niveles de significación de (a) 0.05 y (b) 0.01.
- 7.78. En el Problema 7.77 ensayar la hipótesis $\mu = 1120$ horas contra la hipótesis alternativa $\mu < 1120$ horas, mediante un nivel de significación del (a) 0.05 y (b) 0.01.
- 7.79. Las especificaciones para la producción de una cierta aleación piden el 23.2% de cobre. Una muestra de 10 análisis dio una media de contenido en cobre de 23.5% y una desviación típica de 0.24%. ¿Puede deducirse al nivel de significación del (a) 0.01 y (b) 0.05 que el producto presenta las especificaciones requeridas?
- 7.80. En el Problema 7.79 ensayar la hipótesis de que el contenido medio de cobre sea más alto que el que marcan las especificaciones, mediante un nivel de significación del (a) 0.01 y (b) 0.05.
- 7.81. Un experto eficiente mantiene que introduciendo un nuevo tipo de maquinaria en un proceso de producción se puede disminuir sustancialmente el tiempo de producción. A causa de lo costoso del mantenimiento de estas máquinas resulta que a menos que el tiempo de producción se disminuya en un 8.0% la introducción de tales máquinas en el proceso resulta antieconómico. En seis pruebas de este tipo se obtuvo un decrecimiento en el tiempo de producción de 8.4% con una desviación típica de 0.32%. Utilizando un nivel de significación del (a) 0.01 y (b) 0.05 ensayar la hipótesis de que las máquinas deben ser introducidas.
- 7.82. Dos tipos de soluciones químicas, *A* y *B* fueron ensayadas para ver su pH (grado de acidez de la solución). Análisis de 6 muestras de *A* dieron un pH medio de 7.52 con una desviación típica de 0.024. Análisis de 5 muestras de *B* dieron un pH medio de 7.49 con una desviación típica de 0.032. Mediante un nivel de significación del 0.05, determinar si los dos tipos de soluciones tienen diferentes valores de pH.
- 7.83. En un examen de psicología de 12 estudiantes de una clase hubo una puntuación media de 78 con una desviación típica de 6, mientras que 15 estudiantes de otra clase tuvieron una puntuación media de 74 con una des-

viación típica de 8. Con un nivel de significación del 0.05 determinar si el primer grupo es superior al segundo.

ENSAYOS EN RELACION CON LA DISTRIBUCION CHI-CUADRADO

- 7.84. La desviación típica de resistencia a la rotura de ciertos cables producidos por una compañía viene dada por 240 libras. Después de introducir un cambio en el proceso de producción de estos cables, la resistencia a la rotura de una muestra de 8 cables dio una desviación típica de 300 libras. Investigar la significación del aparente incremento en la variabilidad, mediante un nivel de significación del (a) 0.05 y (b) 0.01.
- 7.85. La desviación típica de las temperaturas anuales de una ciudad en un período de 100 años fue de 16° Fahrenheit. Con la temperatura media del día 15 de cada mes, durante los 15 últimos años, la desviación típica de las temperaturas anuales fue calculada como de 10° Fahrenheit. Ensayar la hipótesis de que las temperaturas en esta ciudad presentan ahora menos variabilidad que en el pasado, al nivel de significación del (a) 0.05, (b) 0.01.
- 7.86. En el Problema 7.77 una muestra de 20 bombillas reveló una desviación típica en la duración de 150 horas. ¿Concluiría que esto no es común? Explicar.

ENSAYOS EN RELACION CON LA DISTRIBUCION F

- 7.87. Dos muestras consisten de 21 y 9 observaciones, tienen varianzas dadas por $s_1^2 = 16$ y $s_2^2 = 8$ respectivamente. Ensayar la hipótesis de que la primera varianza poblacional es mayor que la de la segunda a un nivel de significación del (a) 0.05, (b) 0.01.
- 7.88. Solucionar el Problema 7.87 si las dos muestras consisten de 60 y 120 observaciones respectivamente.
- 7.89. En el Problema 7.82, ¿podemos concluir que hay una diferencia significativa en la variabilidad de los valores del pH para las dos soluciones al nivel de significación del 0.01?

CURVAS CARACTERISTICAS DE OPERACION

- 7.90. En relación con el Problema 7.63, determinar la probabilidad de aceptar la hipótesis de que haya igual proporción de bolas rojas y azules, cuando la proporción real p de bolas rojas sea (a) 0.6, (b) 0.7, (c) 0.8, (d) 0.9, (e) 0.3.
- 7.91. Representar gráficamente los resultados del Problema 7.90 construyendo un gráfico de (a) β y p , (b) $(1 - \beta)$ y p . Comparar estos gráficos con los del Problema 7.25 considerando la analogía de bolas rojas y azules con caras y sellos respectivamente.
- 7.92. (a) Solucionar los Problemas 7.26 y 7.27 si se ensayan 400 cuerdas. (b) ¿Qué conclusiones pueden sacarse de acuerdo con los riesgos de error del Tipo II cuando se incrementan los tamaños muestrales?
- 7.93. Construir (a) una curva OC y (b) una curva de potencia correspondientes al Problema 7.65. Comparar estas curvas con las del Problema 7.27.

GRAFICOS DE CONTROL DE CALIDAD

- 7.94. En el pasado, un cierto tipo de hilo producido por un fabricante tenía una resistencia media de rotura de 8.64 onzas y una desviación típica de 1.28 onzas. Para determinar si el producto está de acuerdo a estas normas, se toma cada 3 horas una muestra de 16 piezas de hilo y se determina la resistencia media. Hallar los límites de control del (a) 99.73% ó 3σ , (b) 99% sobre un gráfico de control de calidad y explicar sus aplicaciones.
- 7.95. Alrededor del 3% de las tuercas producidas por una compañía son defectuosas. Para mantener esta calidad de producción, se toma una muestra cada 4 horas de 200 de las tuercas producidas. Determinar los límites de control del (a) 99% y (b) 95% para el número de tuercas defectuosas de cada muestra. Adviértase que en este caso solo son necesarios los límites de control superiores.

AJUSTE DE DATOS A DISTRIBUCIONES TEORICAS

- 7.96. Ajustar una distribución binomial a los datos de la Tabla 7-24.
- 7.97. Utilizar papel gráfico de probabilidad para determinar si los datos del Problema 5.98 pueden ser aproximados estrechamente a una distribución normal.
- 7.98. Ajustar una distribución normal a los datos del Problema 5.98.
- 7.99. Ajustar una distribución normal a los datos del Problema 5.100.
- 7.100. Ajustar una distribución de Poisson a los datos del Problema 7.96 y comparar con el ajuste obtenido utilizando la distribución binomial.
- 7.101. En 10 unidades del ejército prusiano y en un período de 20 años 1875-1894, el número de muertos por unidad y año debido a coz de caballo se dan en la Tabla 7-25. Ajustar una distribución de Poisson a los datos.

Tabla 7-24

x	0	1	2	3	4
f	30	62	46	10	2

Tabla 7-25

x	0	1	2	3	4
f	109	65	22	3	1

LA PRUEBA CHI-CUADRADO

- 7.102. En 60 lanzamientos de una moneda se observaron 37 caras y 23 sellos. Ensayar la hipótesis de que la moneda está bien hecha utilizando un nivel de significación del (a) 0.05, (b) 0.01.
- 7.103. Solucionar el Problema 7.102 utilizando la corrección de Yates.
- 7.104. Durante un largo período de tiempo, las puntuaciones dadas por un grupo de profesores en un determinado curso dieron un promedio de 12% A, 18% B, 40% C, 18% D y 12% F. Un profesor nuevo da durante dos semestres 22 A, 34 B, 66 C, 16 D y 12 F. Determinar al nivel de significación de 0.05 si el profesor nuevo sigue las mismas normas de puntuación que los otros.
- 7.105. Se lanzaron tres monedas un total de 240 veces y se observó cada vez el número de caras obtenido. Los resultados aparecen en la Tabla 7-26 junto con las frecuencias esperadas bajo la hipótesis de que las monedas están bien hechas. Ensayar esta hipótesis al nivel de significación del 0.05.
- 7.106. El número de libros sacados de una biblioteca pública durante una semana determinada viene dado en la Tabla 7-27. Ensayar la hipótesis de que el número de libros sacados no dependa del día de la semana, con un nivel de significación del (a) 0.05, (b) 0.01.

Tabla 7-26

	0 caras	1 cara	2 caras	3 caras
Frecuencia observada	24	108	95	23
Frecuencia esperada	30	90	90	30

Tabla 7-27

	Lun.	Mar.	Mierc.	Juev.	Vier.
Número de libros sacados	135	108	120	114	146

Tabla 7-28

	0 rojo 2 blanco	1 rojo 1 blanco	2 rojo 0 blanco
Número de extracciones	6	53	61

- 7.107. Una urna contiene 6 bolas rojas y 3 blancas. Se extraen aleatoriamente dos bolas de la urna, se anota su color y se vuelven a la urna. Este proceso se repite un total de 120 veces y los resultados obtenidos se muestran en la Tabla 7-28. (a) Determinar las frecuencias esperadas, (b) Determinar al nivel de significación del 0.05 si los resultados obtenidos son consistentes con los esperados.
- 7.108. Se eligieron aleatoriamente tuercas de la producción de cada una de 4 máquinas. El número de defectuosas fueron 2, 9, 10, 3. Determinar si existe entre las máquinas una diferencia significativa al nivel de significación del 0.05.

BONDAD DE AJUSTE

- 7.109. (a) Utilizar la prueba chi-cuadrado para determinar la bondad de ajuste de los datos del Problema 7.96. (b) ¿Es el ajuste "bastante bueno"? Emplear el nivel de significación del 0.05.
- 7.110. Mediante la prueba chi-cuadrado determinar la bondad de ajuste de los datos de (a) Problema 7.98. (b) Problema 7.99. Utilizar el nivel de significación del 0.05 y en cada caso determinar si el ajuste es "bastante bueno".
- 7.111. Mediante la prueba chi-cuadrado determinar la bondad de ajuste de los datos de (a) Problema 7.100, (b) Problema 7.101. ¿Es consistente el resultado de (a) con el del Problema 7.109?

TABLAS DE CONTINGENCIA

- 7.112. La Tabla 7-29 muestra el resultado de un experimento para investigar el efecto de vacunación de animales de laboratorio contra una determinada enfermedad. Mediante un nivel de significación del (a) 0.01 y (b) 0.05, ensayar la hipótesis de que no haya diferencia entre los grupos vacunados y no vacunados, es decir, la vacunación y esta enfermedad son independientes.

Tabla 7-29

	Se enfermaron	No se enfermaron
Vacunados	9	42
No Vacunados	17	28

- 7.113. Solucionar el Problema 7.112 introduciendo la corrección de Yates.

Tabla 7-30

	Aprobados	Suspendidos
Clase A	72	17
Clase B	64	23

- 7.114. La Tabla 7-30 muestra el número de estudiantes de cada una de dos clases A y B que aprobó y suspendió un examen dado a ambos grupos. Mediante un nivel de significación del (a) 0.05 y (b) 0.01, ensayar la hipótesis de que no haya diferencia entre las dos clases. Hacer el problema con y sin la corrección de Yates.

- 7.115. De un grupo de enfermos que se quejaban de que no dormían bien, a unos se les dio píldoras para dormir, mientras que a otros se les dio píldoras de azúcar (aunque todos ellos creían que sus píldoras eran para dormir). Posteriormente, se les preguntó si las pastillas habían surtido efecto o no. El resultado de sus respuestas se muestra en la Tabla 7-31. Suponiendo que todos los pacientes dijeron la verdad, ensayar la hipótesis de que no hay diferencia entre las píldoras de dormir y las de azúcar al nivel de significación del 0.05.

Tabla 7-31

	Durmieron bien	No durmieron bien
Tomaron píldoras para dormir	44	10
Tomaron píldoras de azúcar	81	35

Tabla 7-32

	A favor	En contra	Abstencionistas
Demócratas	85	78	37
Republicanos	118	61	25

- 7.116. Sobre una decisión de importancia nacional, los votos de los demócratas y republicanos registraron los resultados que se observan en la Tabla 7-32. Al nivel de significación del (a) 0.01 y (b) 0.05, ensayar la hipótesis de que no hay diferencia entre ambos partidos en lo que a esta decisión se refiere.

- 7.117. La Tabla 7-33 da la relación entre las notas de los estudiantes en matemáticas y física. Ensayar la hipótesis de que las notas de física sean independientes de las obtenidas en matemáticas, mediante un nivel de significación del (a) 0.05 y (b) 0.01.

- 7.118. Los resultados de una encuesta hecha para determinar si la edad de los conductores a partir de los 21 años, tiene su efecto en el número de accidentes de automóvil (incluyendo todo tipo de accidentes) se indican en la Tabla 7-34. A un nivel de significación de (a) 0.05 y (b) 0.01 ensayar la hipótesis de que el número de accidentes es independiente de la edad del conductor. ¿Qué posibles dificultades en las técnicas de muestreo como en otras consideraciones pueden afectar las conclusiones?

Tabla 7-33

		MATEMATICAS		
		Notas altas	Notas medias	Notas bajas
FISICA	Notas altas	56	71	12
	Notas medias	47	163	38
	Notas bajas	14	42	85

Tabla 7-34

		EDAD DEL CONDUCTOR				
		21-30	31-40	41-50	51-60	61-70
NUMERO DE ACCIDENTES	0	748	821	786	720	672
	1	74	60	51	66	50
	2	31	25	22	16	15
	1 Más de 2	9	10	6	5	7

- 7.119. (a) Demostrar que $\chi^2 = \sum (x_{ij}^2/n_{p_j}) - n$ para toda tabla de contingencia, donde n es la frecuencia total de todas las casillas. (b) Con el resultado de (a) hacer el Problema 7.117.
- 7.120. Si n_i y n_j denotan, respectivamente, la suma de frecuencias en la fila i y en la columna j de una tabla de contingencia (*frecuencias marginales*), mostrar que la frecuencia esperada para la casilla perteneciente a la fila i y a la columna j es $n_i n_j / n$, donde n es la frecuencia total de todas las casillas.
- 7.121. Demostrar el resultado (2) del Problema 7.49.
- 7.122. Por similitud con las ideas desarrolladas para tablas de contingencia $h \times k$, discutir las tablas de contingencia $h \times k \times l$, señalando las posibles aplicaciones que pueden tener.

COEFICIENTE DE CONTINGENCIA

- 7.123. La Tabla 7-35 muestra la relación entre el color del pelo y los ojos de una muestra de 200 estudiantes. (a) Hallar el coeficiente de contingencia sin y con la corrección de Yates. (b) Comparar el resultado de (a) con el coeficiente máximo de contingencia.
- 7.124. Hallar el coeficiente de contingencia sin y con la corrección de Yates para los datos de (a) Problema 7.112 y (b) Problema 7.114.

Tabla 7-35

		COLOR DE PELO	
		Rubio	No rubio
COLOR DE OJOS	Azules	49	25
	No azules	30	96

- 7.125. Hallar el coeficiente de contingencia para los datos del Problema 7.117.
- 7.126. Demostrar que el coeficiente de contingencia máximo para una tabla 3×3 es $\sqrt{2/3} = 0.8165$ aproximadamente.
- 7.127. Demostrar que el coeficiente de contingencia máximo para una tabla $k \times k$ es $\sqrt{(k-1)/k}$.

PROBLEMAS DIVERSOS

- 7.128. Dos urnas A y B contienen igual número de bolas, pero se desconocen las proporciones de bolas rojas y blancas en cada una de las urnas; se toma una muestra de 50 bolas con remplazamiento de cada una de las urnas,

dando la de A 32 bolas rojas y la de B 23 bolas rojas. Mediante un nivel de significación del 0.05 ensayar la hipótesis de que (a) las dos urnas tengan igual proporción de bolas rojas y (b) A tenga una proporción de bolas rojas superior a B.

- 7.129. Con referencia al Problema 7.54, hallar el menor número de preguntas que un estudiante debe contestar correctamente para que el instructor esté seguro al nivel de significación del (a) 0.05, (b) 0.01, (c) 0.001, (d) 0.06 de que el estudiante no está contestando al azar. Comentar los resultados.
- 7.130. Construir gráficos análogos a los del Problema 7.23 para el Problema 7.55.
- 7.131. Solucionar los Problemas 7.54-7.56 si el 7 en la regla de decisión del Problema 7.54 es ahora 8.
- 7.132. Una moneda se lanza 8 veces y se obtienen 7 caras. ¿Se puede rechazar la hipótesis de que la moneda está bien hecha al nivel de significación del (a) 0.05, (b) 0.10, (c) 0.01? Utilizar un ensayo bilateral.
- 7.133. Solucionar el Problema 7.132 empleando un ensayo unilateral.
- 7.134. Solucionar el Problema 7.132 si salen 6 caras.
- 7.135. Comentar cómo puede utilizarse la teoría del muestreo para investigar las proporciones de diferentes tipos de pescado presentes en un lago.
- 7.136. Explicar cómo podría definir *intervalos de confianza unilaterales* y dar una posible aplicación.
- 7.137. El porcentaje de calificaciones A dadas en un curso de física en una universidad determinada durante mucho tiempo fue 10%. Durante un período particular hubo 40 calificaciones A en un grupo de 300 estudiantes. Ensayar la significación de este resultado a un nivel de (a) 0.05, (b) 0.01.
- 7.138. Con una determinada marca A de gasolina, el número medio de millas por galón consumido en 5 automóviles análogos bajo idénticas condiciones fue de 22.6 con una desviación típica de 0.48. Con otra marca B, el número medio fue de 21.4 con una desviación típica de 0.54. Al nivel de significación del 0.05 investigar si la marca A realmente es mejor que B proporcionando mayor recorrido por galón.
- 7.139. En el Problema 7.138 ¿hay mayor variabilidad en millas por galón utilizando la marca B que utilizando la marca A? Explicar.
- 7.140. Demostrar que para la Tabla 7-36

$$\chi^2 = \frac{n}{n_A} \left(\frac{a_1^2}{n_1} + \frac{a_2^2}{n_2} + \frac{a_3^2}{n_3} \right) + \frac{n}{n_B} \left(\frac{b_1^2}{n_1} + \frac{b_2^2}{n_2} + \frac{b_3^2}{n_3} \right) - n$$

- 7.141. Generalizar el resultado del Problema 7.140.
- 7.142. Utilizar el resultado del Problema 7.140 para obtener el valor de χ^2 para el Problema 7.47.

Tabla 7-36

	I	II	III	TOTALES
A	a_1	a_2	a_3	n_A
B	b_1	b_2	b_3	n_B
TOTALES	n_1	n_2	n_3	n

Capítulo 8

Curva de ajuste, regresión y correlación

CURVA DE AJUSTE

Muy a menudo en la práctica se encuentra que existe una relación entre dos (o más) variables, y se desea expresar esta relación en forma matemática determinando una ecuación que conecte las variables.

Un primer paso es la colección de datos indicando los valores correspondientes de las variables. Por ejemplo, si x y y denotan la estatura y peso de un adulto; entonces una muestra de n individuos resultaría en las estaturas $x_1, x_2, \dots, x_n$ y los pesos correspondientes $y_1, y_2, \dots, y_n$.

El paso siguiente es dibujar los puntos $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ en un sistema de coordenadas rectangulares. El conjunto resultante de puntos se llama a veces *diagrama de dispersión*.

Del diagrama de dispersión es posible frecuentemente visualizar una curva que se aproxime a los datos. Dicha curva se llama *curva de aproximación*. En la Fig. 8-1, por ejemplo, se observa que los datos se aproximan bien por una recta y decimos que existe una *relación lineal* entre las variables. Sin embargo, en la Fig. 8-2 aunque existe una relación entre las variables ésta no es una relación lineal y por esto la llamamos *relación no lineal*. En la Fig. 8-3 parece que no hay ninguna relación entre las variables.




Fig. 8-1




Fig. 8-2




Fig. 8-3

El problema general de hallar ecuaciones de curvas de aproximación que se ajusten a conjuntos de datos dados se denomina *curva de ajuste*. En la práctica el tipo de ecuación se sugiere frecuentemente del diagrama de dispersión. Así para la Fig. 8-1 podríamos utilizar una recta

$$y = a + bx \quad (1)$$

mientras que para la Fig. 8-2 ensayaríamos una *curva cuadrática* o *parabólica*

$$y = a + bx + cx^2 \quad (2)$$

Algunas veces conviene dibujar los diagramas de dispersión en términos de *variables transformadas*. Así por ejemplo, si $\log y$ vs. x conduce a una recta trataríamos $\log y = a + bx$ como ecuación para la curva de aproximación.

REGRESION

Uno de los propósitos principales de la curva de ajuste es estimar una de las variables (la *variable dependiente*) de la otra (la *variable independiente*). El proceso de estimación se conoce como *regresión*. Si y se va a estimar a partir de x por medio de alguna ecuación la llamamos *ecuación de regresión de y sobre x* y a la curva correspondiente *curva de regresión de y sobre x* .

METODO DE MINIMOS CUADRADOS

Generalmente, más de una curva de un tipo dado parece ajustar un conjunto de datos. Para evitar el juicio individual en la construcción de rectas, parábolas, u otras curvas de aproximación, es necesario obtener una definición de la “mejor recta de ajuste”, “mejor parábola de ajuste”, etc.

Para motivar una posible definición considérese la Fig. 8-4 en la cual los puntos de datos son $(x_1, y_1), \dots, (x_n, y_n)$. Para un valor dado de x , por ejemplo x_1 , habrá una diferencia entre el valor de y_1 y el valor correspondiente determinado de la curva C . Denotamos esta diferencia por d_1 , que algunas veces se conoce como *desviación*, *error*, o *residuo* y puede ser positivo, negativo o cero. Análogamente, correspondiendo a los valores $x_2, \dots, x_n$ obtenemos las desviaciones $d_2, \dots, d_n$.

Una medida de la “bondad del ajuste” de la curva C al conjunto de datos la suministra la cantidad $d_1^2 + d_2^2 + \dots + d_n^2$. Si la suma es pequeña el ajuste es bueno si es grande el ajuste es malo. Por tanto tomamos la siguiente




Fig. 8-4

Definición. De todas las curvas de aproximación de un conjunto de puntos de datos dados, la curva que tenga la propiedad de que

$$d_1^2 + d_2^2 + \dots + d_n^2 = \text{un mínimo}$$

es la *mejor curva de ajuste*.

Una curva con esta propiedad se dice que ajusta los datos en el *sentido de mínimos cuadrados* y se llama *curva de regresión de mínimos cuadrados* o simplemente *curva de mínimos cuadrados*. Por tanto una recta con esta propiedad se llama *recta de mínimos cuadrados*, una parábola con esta propiedad se llama *parábola de mínimos cuadrados*, etc.

Se acostumbra a emplear la definición anterior cuando x es la variable independiente y y es la variable dependiente. Si x es la variable dependiente, la definición se modifica al considerar las desviaciones horizontales en cambio de las verticales, que se reduce a intercambiar los ejes x, y . Estas dos definiciones conducen en general a dos curvas de mínimos cuadrados diferentes. Al menos se especifique lo contrario consideraremos a y como la variable dependiente y a x como la independiente.

Es posible definir otra curva de mínimos cuadrados considerando distancias perpendiculares desde los puntos de datos a la curva en cambio de sus distancias verticales u horizontales. Sin embargo, esto no se emplea con frecuencia.

RECTA DE MINIMOS CUADRADOS

Empleando la definición anterior podemos demostrar (véase Problema 8.3) que la recta de mínimos cuadrados de aproximación al conjunto de datos $(x_1, y_1), \dots, (x_n, y_n)$ tiene la ecuación

$$y = a + bx \quad (3)$$

donde las constantes a y b se determinan solucionando simultáneamente las ecuaciones

$$\begin{aligned}\sum y &= an + b \sum x \\ \sum xy &= a \sum x + b \sum x^2\end{aligned}\quad (4)$$

que se conocen como las *ecuaciones normales* para la recta de mínimos cuadrados. Obsérvese que por brevedad hemos utilizado $\sum y$, $\sum xy$ en cambio de $\sum_{j=1}^n y_j$, $\sum_{j=1}^n x_j y_j$. Las ecuaciones normales, (4), se pueden recordar fácilmente si se observa que la primera ecuación se obtiene formalmente sumando ambos lados de (3), mientras que la segunda ecuación se obtiene primero multiplicando por x ambos lados de (3) y luego sumando. Lógicamente esta no es una derivación de las ecuaciones normales sino solamente un medio para recordarlas.

Los valores de a y b obtenidos de (4) están dados por

$$a = \frac{(\sum y)(\sum x^2) - (\sum x)(\sum xy)}{n \sum x^2 - (\sum x)^2} \quad b = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2} \quad (5)$$

El resultado para b en (5) también puede escribirse como

$$b = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2} \quad (6)$$

Aquí, como es común, una barra indica *media*, es decir, $\bar{x} = (\sum x)/n$. Al dividir ambos lados de la primera ecuación normal en (4) por n resulta

$$\bar{y} = a + b\bar{x} \quad (7)$$

Por tanto, si se desea podemos hallar primero b de (5) o (6) y luego emplear (7) para hallar $a = \bar{y} - b\bar{x}$. Esto es equivalente a escribir la recta de mínimos cuadrados como

$$y - \bar{y} = b(x - \bar{x}) \quad \text{ó} \quad y - \bar{y} = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2} (x - \bar{x}) \quad (8)$$

El resultado (8) indica que la constante b , que es la pendiente de la recta (3), es la constante fundamental para determinar la recta. De (8) también se ve que la recta de mínimos cuadrados pasa a través del punto $(\bar{x}, \bar{y})$, denominado el *centroide* o *centro de gravedad* de los datos.

La pendiente b de la recta de regresión es independiente del origen de coordenadas. Esto quiere decir que si hacemos la transformación (comúnmente llamada *traslación de ejes*) dada por

$$x = x' + h \quad y = y' + k \quad (9)$$

donde h y k son constantes arbitrarias, entonces b también está dada por

$$b = \frac{n \sum x'y' - (\sum x')(\sum y')}{n \sum x'^2 - (\sum x')^2} = \frac{\sum (x' - \bar{x}')(y' - \bar{y}')}{\sum (x' - \bar{x}')^2} \quad (10)$$

donde x , y han sido simplemente remplazadas por x' , y' [por esta razón decimos que b es *invariante bajo la transformación* (9)]. Sin embargo, debe notarse que a , que determina el intercepto sobre el eje x , depende del origen (y por tanto no es invariante).

En el caso particular cuando $h = \bar{x}$, $k = \bar{y}$, (10) se simplifica a

$$b = \frac{\sum x'y'}{\sum x'^2} \quad (11)$$

Los resultados (10) u (11) son útiles frecuentemente en simplificar el trabajo involucrado en obtener la recta de mínimos cuadrados.

Las anotaciones anteriores también son válidas para la recta de regresión de x sobre y . Los resultados se obtienen simplemente intercambiando x y y . Así, por ejemplo, la recta de regresión de mínimos cuadrados de x sobre y es

$$x - \bar{x} = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (y - \bar{y})^2} (y - \bar{y}) \quad (12)$$

Debe notarse que en general (12) no es la misma recta que (8).

RECTA DE MINIMOS CUADRADOS EN TERMINOS DE VARIANZAS Y COVARIANZAS MUESTRALES

Las varianzas y covarianzas muestrales de x , y están dadas por

$$s_x^2 = \frac{\sum (x - \bar{x})^2}{n}, \quad s_y^2 = \frac{\sum (y - \bar{y})^2}{n}, \quad s_{xy} = \frac{\sum (x - \bar{x})(y - \bar{y})}{n} \quad (13)$$

En términos de éstas, las rectas de regresión de mínimos cuadrados de y sobre x y de x sobre y pueden escribirse respectivamente como

$$y - \bar{y} = \frac{s_{xy}}{s_x^2} (x - \bar{x}) \quad x - \bar{x} = \frac{s_{xy}}{s_y^2} (y - \bar{y}) \quad (14)$$

Si formalmente definimos el *coeficiente de correlación muestral* por [comparar (54), página 82]

$$r = \frac{s_{xy}}{s_x s_y} \quad (15)$$

entonces (14) puede escribirse como

$$\frac{y - \bar{y}}{s_y} = r \left(\frac{x - \bar{x}}{s_x} \right) \quad \frac{x - \bar{x}}{s_x} = r \left(\frac{y - \bar{y}}{s_y} \right) \quad (16)$$

En vista de que $(x - \bar{x})/s_x$ y $(y - \bar{y})/s_y$ son valores muestrales tipificados, los resultados en (16) proveen una forma muy simple de recordar las rectas de regresión. Es lógico que las dos rectas en (16) son diferentes al menos que $r = \pm 1$, en cuyo caso todos los puntos muestrales están sobre una recta [esto se demostrará en (26)] y hay una *correlación y regresión lineal perfecta*.

También es de interés notar que si las dos rectas de regresión (16) se escriben como $y = a + bx$, $x = c + dy$ respectivamente, entonces

$$bd = r^2 \quad (17)$$

Hasta ahora no hemos considerado la significación precisa del coeficiente de correlación sino solamente lo hemos definido en términos de las varianzas y covarianza. En la página 263 se dará la significación.

PARABOLA DE MINIMOS CUADRADOS

Las ideas anteriores se amplían fácilmente. Por ejemplo, la *parábola de mínimos cuadrados* que ajusta un conjunto de puntos muestrales viene dada por

$$y = a + bx + cx^2 \quad (18)$$

donde a , b , c se determinan de las *ecuaciones normales*

$$\begin{aligned} \sum y &= na + b \sum x + c \sum x^2 \\ \sum xy &= a \sum x + b \sum x^2 + c \sum x^3 \\ \sum x^2 y &= a \sum x^2 + b \sum x^3 + c \sum x^4 \end{aligned} \quad (19)$$

Estas ecuaciones se obtienen formalmente sumando ambos lados de (18) después de multiplicar sucesivamente por 1, x y x^2 respectivamente.

REGRESION MULTIPLE

Las ideas anteriores también pueden generalizarse a más variables. Por ejemplo, si creemos que hay una relación lineal entre una variable dependiente z y dos variables independientes x , y , entonces buscaríamos una ecuación conectando las variables que tenga la forma

$$z = a + bx + cy \quad (20)$$

Esta se denomina *ecuación de regresión de z sobre x , y* . Si x es la variable dependiente una ecuación semejante se llamaría *ecuación de regresión de x sobre y , z* .

Puesto que (20) representa un plano en un sistema de coordenadas rectangulares tridimensional se llama con frecuencia *plano de regresión*. Para hallar el plano de regresión de mínimos cuadrados determinamos a , b , c en (20) de modo que

$$\begin{aligned} \sum z &= na + b \sum x + c \sum y \\ \sum xz &= a \sum x + b \sum x^2 + c \sum xy \\ \sum yz &= a \sum y + b \sum xy + c \sum y^2 \end{aligned} \quad (21)$$

Estas ecuaciones, llamadas las *ecuaciones normales* correspondientes a (20), se obtienen como resultado de aplicar una definición análoga a la de la página 259. Adviértase que pueden obtenerse formalmente de (20) multiplicando por 1, x , y respectivamente y sumando.

Generalizaciones a más variables, incluyendo ecuaciones lineales y no lineales conducentes a *superficies de regresión* en espacios tridimensionales y superiores, se hacen fácilmente.

ERROR TIPICO DE LA ESTIMA

Si denotamos por y_{est} el valor estimado de y para un valor dado de x , obtenido de la curva de regresión de y sobre x , entonces una medida de la dispersión con respecto a la curva de regresión está suministrada por la cantidad

$$s_{y.x} = \sqrt{\frac{\sum (y - y_{\text{est}})^2}{n}} \quad (22)$$

que se llama el *error típico de la estima de y sobre x* . Puesto que $\sum (y - y_{\text{est}})^2 = \sum d^2$, como se empleó en la definición de la página 259, vemos que de todas las curvas de regresión posible, la curva de mínimos cuadrados tiene el más pequeño error típico de la estima.

En el caso de una recta de regresión $y_{\text{est}} = a + bx$, con a y b dados por (4), tenemos

$$s_{y.x}^2 = \frac{\sum y^2 - a \sum y - b \sum xy}{n} \quad (23)$$

$$\text{ó} \quad s_{y.x}^2 = \frac{\sum (y - \bar{y})^2 - b \sum (x - \bar{x})(y - \bar{y})}{n} \quad (24)$$

También podemos expresar $s_{y.x}^2$ por la recta de mínimos cuadrados en términos de la varianza y del coeficiente de correlación como

$$s_{y.x}^2 = s_y^2(1 - r^2) \quad (25)$$

de donde incidentalmente se deduce como corolario que $r^2 \leq 1$, esto es $-1 \leq r \leq 1$.

El error típico de la estima tiene propiedades análogas a esas de la desviación típica. Por ejemplo, si construimos pares de rectas paralelas a la recta de regresión de y sobre x a distancias verticales $s_{y.x}$, $2s_{y.x}$ y $3s_{y.x}$ respectivamente, debemos hallar si n es lo suficientemente grande para que estén incluidos entre estas parejas de rectas alrededor del 68%, 95% y 97% de los puntos muestrales respectivamente. Véase Problema 8.23.

Así como hay una estima insesgada de la varianza muestral dada por $\hat{s}^2 = ns^2/(n-1)$ igualmente hay una estima insesgada del cuadrado del error típico de la estima. Este está dado por $\hat{s}_{y,x}^2 = ns_{y,x}^2/(n-2)$. Por esta razón algunos estadísticos prefieren expresar (22) con $n-2$ en cambio de n en el denominador.

Las anotaciones anteriores se modifican fácilmente para la recta de regresión de x sobre y (en cuyo caso el error típico de la estima se denota por $s_{x,y}$) o para regresión no lineal o múltiple.

COEFICIENTE DE CORRELACION LINEAL

Hasta el momento hemos definido el coeficiente de correlación formalmente por (15) pero no hemos examinado su significado. Al tratar de hacerlo notemos que de (25) y las definiciones de $s_{y,x}$ y s_y tenemos

$$r^2 = 1 - \frac{\sum (y - y_{\text{est}})^2}{\sum (y - \bar{y})^2} \quad (26)$$

Entonces podemos demostrar que (véase Problema 8.24)

$$\sum (y - \bar{y})^2 = \sum (y - y_{\text{est}})^2 + \sum (y_{\text{est}} - \bar{y})^2 \quad (27)$$

La cantidad a la izquierda de (27) se llama la *variación total*. La primera suma a la derecha de (27) se conoce como la *variación no explicada*, mientras que la segunda suma se llama *variación explicada*. Esta terminología surge debido a que las desviaciones $y - y_{\text{est}}$ se comportan en una manera aleatoria o impredecible en tanto que las desviaciones $y_{\text{est}} - \bar{y}$ se explican por la recta de regresión de mínimos cuadrados y así tienden a seguir un patrón definido. Se deduce de (26) y (27) que

$$r^2 = \frac{\sum (y_{\text{est}} - \bar{y})^2}{\sum (y - \bar{y})^2} = \frac{\text{variación explicada}}{\text{variación total}} \quad (28)$$

Por tanto r^2 puede interpretarse como la fracción de la variación total que se explica por la recta de regresión de mínimos cuadrados. En otras palabras, r mide *qué tan bien* la recta de regresión de mínimos cuadrados se ajusta a los datos muestrales. Si la variación total se explica *totalmente* por la recta de regresión, es decir, si $r^2 = 1$ ó $r = \pm 1$, decimos que hay una *correlación lineal perfecta* (y en tal caso también *regresión lineal perfecta*). De otra parte si la variación total no se puede explicar, entonces la variación explicada es cero y así $r = 0$. En la práctica la cantidad r^2 , algunas veces llamada *coeficiente de determinación*, se encuentra entre 0 y 1.

El coeficiente de correlación puede calcularse de cualquiera de los resultados

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2} \sqrt{\sum (y - \bar{y})^2}} \quad (29)$$

$$\text{ó} \quad r^2 = \frac{\text{variación explicada}}{\text{variación total}} = \frac{\sum (y_{\text{est}} - \bar{y})^2}{\sum (y - \bar{y})^2} \quad (30)$$

que para regresión lineal son equivalentes. La fórmula (29) se conoce como la *fórmula producto-momento* para correlación lineal.

Fórmulas equivalentes a las anteriores, que se utilizan en la práctica son

$$r = \frac{n \sum xy - (\sum x)(\sum y)}{\sqrt{[n \sum x^2 - (\sum x)^2][n \sum y^2 - (\sum y)^2]}} \quad (31)$$

y

$$r = \frac{\bar{xy} - \bar{x}\bar{y}}{\sqrt{(\bar{x}^2 - \bar{x}^2)(\bar{y}^2 - \bar{y}^2)}} \quad (32)$$

Si utilizamos la transformación (9), página 260, hallamos

$$r = \frac{n \sum x'y' - (\sum x')(\sum y')}{\sqrt{[n \sum x'^2 - (\sum x')^2][n \sum y'^2 - (\sum y')^2]}} \quad (33)$$

que indica que r es invariante bajo una traslación de ejes. En particular, si $h = \bar{x}$, $k = \bar{y}$, (33) se convierte en

$$r = \frac{\sum x'y'}{\sqrt{(\sum x'^2)(\sum y'^2)}} \quad (34)$$

que comúnmente se emplea en computación.

El coeficiente de correlación lineal puede ser positivo o negativo. Si r es positivo y tiende a *aumentar* con x (la pendiente de la recta de mínimos cuadrados es positiva) en tanto que si r es negativo y tiende a *disminuir* con x (la pendiente es negativa). El signo se toma en cuenta *automáticamente* si empleamos el resultado (29), (31), (32), (33) o (34). Sin embargo, si utilizamos (30) para obtener r debemos aplicar el signo apropiado.

COEFICIENTE DE CORRELACION GENERALIZADO

La definición (29) [o cualquiera de las formas equivalentes (31) a (34)] para el coeficiente de correlación incluye solamente valores muestrales x , y . En consecuencia da el mismo número para todas las formas de curvas de regresión y no es útil como medida de ajuste, excepto en el caso de regresión lineal, donde coincide con (30). Sin embargo, la última definición, esto es

$$r^2 = \frac{\text{variación explicada}}{\text{variación total}} = \frac{\sum (y_{\text{est}} - \bar{y})^2}{\sum (y - \bar{y})^2} \quad (35)$$

refleja la forma de la curva de regresión (vía y_{est}) y de este modo es apropiada como la definición de un *coeficiente de correlación generalizado* r . Utilizamos (35) para obtener coeficientes de correlación no lineales (que mide qué tan bien se ajusta una *curva de regresión no lineal* a los datos) o, por generalización apropiada, *coeficientes de correlación múltiple*. La conexión (25) entre el coeficiente de correlación y el error típico de la estima es válida para correlación no lineal.

Puesto que un coeficiente de correlación simplemente mide qué tan bien se ajusta una curva de regresión (o superficie) a los datos muestrales, es ilógico utilizar un coeficiente de correlación lineal donde los datos no son lineales. Sin embargo, suponga que se aplica (29) a datos no lineales y se obtiene un valor que es considerablemente menor que 1. Entonces la conclusión a extraerse no es que hay *poca correlación* (conclusión algunas veces alcanzada por aquellos laicos con los fundamentos de la teoría de correlación) sino que hay *poca correlación lineal*. En efecto, puede existir una *gran* correlación no lineal.

CORRELACION GRADUAL

En cambio de utilizar valores muestrales precisos, o cuando la precisión no puede obtenerse, los datos pueden clasificarse en orden de tamaño, importancia, etc., empleando los números 1, 2, . . . n . Si dos conjuntos correspondientes de valores x , y se clasifican de tal forma, el *coeficiente de correlación gradual*, denotado por r_{grad} o sencillamente r , está dado por

$$r_{\text{grad}} = 1 - \frac{6 \sum d^2}{n(n^2 - 1)} \quad (36)$$

donde d = diferencias entre las clasificaciones de los correspondientes x , y

n = número de pares de valores (x , y) en los datos

La fórmula (36), es derivada en el Problema 8.36, se denomina *fórmula de Spearman para la correlación gradual*.

INTERPRETACION PROBABILISTICA DE LA REGRESION

Un diagrama de dispersión, como el de la Fig. 8-1, es una representación gráfica de los puntos de datos para una muestra particular. Al escoger una muestra diferente, o aumentar la original, un diagrama de dispersión algo diferente se obtendría generalmente. Cada diagrama de dispersión resultaría en una recta o curva de regresión diferente, aunque esperamos que las diferencias no sean significantes si las muestras se extraen de la misma población.

Del concepto de curva de ajuste en muestras pasamos al de curva de ajuste para la población de donde se tomaron las muestras. La dispersión de puntos alrededor de una recta o curva de regresión indican que para un valor particular de x hay realmente varios valores de y distribuidos alrededor de la recta o curva. Esta idea de distribución nos conduce naturalmente a la realización de que hay una conexión entre curva de ajuste y probabilidad.

La conexión se implementa introduciendo las variables aleatorias X, Y que toman los diferentes valores muestrales x, y respectivamente. Por ejemplo X, Y pueden representar las estaturas y pesos de adultos en una población de la cual se extraen las muestras. Entonces se supone que X, Y tienen una función de probabilidad conjunta o función de densidad, $f(x, y)$, según si se consideran discretas o continuas.

Dada la función de densidad conjunta o función de probabilidad, $f(x, y)$, de dos variables aleatorias X, Y , es lógico de las anotaciones anteriores preguntar si hay una función $g(X)$ tal que

$$E\{[Y - g(X)]^2\} = \text{un mínimo} \quad (37)$$

Una curva con ecuación $y = g(x)$ con la propiedad (37) se llama *curva de regresión de mínimos cuadrados de Y sobre X*. Tenemos el teorema siguiente:

Teorema 8-1: Si X, Y son variables aleatorias con función de densidad conjunta o función de probabilidad $f(x, y)$, entonces existe una curva de regresión de mínimos cuadrados de Y sobre X , con la propiedad (37), dada por

$$y = g(x) = E(Y | X = x) \quad (38)$$

siempre y cuando X, Y tengan una varianza finita.

Nótese que $E(Y | X = x)$ es la esperanza condicional de Y dada $X = x$, como se define en la página 83.

Anotaciones análogas pueden hacerse para una *curva de regresión de mínimos cuadrados de X sobre Y*. En tal caso (37) se reemplaza por

$$E\{[X - h(Y)]^2\} = \text{un mínimo}$$

y (38) se reemplaza por $x = h(y) = E(X | Y = y)$. Las dos curvas de regresión $y = g(x), x = h(y)$ son diferentes en general.

Un caso interesante se presenta cuando la distribución conjunta es la distribución normal bidimensional dada por (49), página 118. Entonces tenemos el teorema siguiente:

Teorema 8-2: Si X, Y son variables aleatorias con la distribución normal bidimensional, entonces la curva de regresión de mínimos cuadrados de Y sobre X es una *recta de regresión* dada por

$$\frac{y - \mu_Y}{\sigma_Y} = \rho \left(\frac{x - \mu_X}{\sigma_X} \right) \quad (39)$$

donde

$$\rho = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} \quad (40)$$

representa el coeficiente de correlación poblacional.

También podemos escribir (39) como

$$y - \mu_Y = \beta(x - \mu_X) \quad (41)$$

donde

$$\beta = \frac{\sigma_{XY}}{\sigma_X^2} \quad (42)$$

Anotaciones semejantes pueden hacerse para la curva de regresión de mínimos cuadrados de X sobre Y , que también resulta ser una recta [dada por (39) con X , Y ; x , y intercambiadas]. Estos resultados deben compararse con los correspondientes en la página 261.

En caso de que no se conozca $f(x, y)$ podemos aún emplear el criterio (37) para obtener curvas de regresión de aproximación para la población. Por ejemplo, si suponemos que $g(x) = \alpha + \beta x$ obtenemos la recta de regresión de mínimos cuadrados (39), donde α y β vienen dadas en términos de los parámetros (desconocidos) μ_X , μ_Y , σ_X , σ_Y , ρ . Análogamente si $g(x) = \alpha + \beta x + \gamma x^2$ podemos obtener una parábola de regresión de mínimos cuadrados, etc. Véase Problema 8.39.

En general todas las anotaciones de las páginas 259 a 264 para muestras se amplían fácilmente a la población. Por ejemplo, el error típico de la estima en el caso de la población viene dado en términos de la varianza y el coeficiente de correlación por

$$\sigma_{Y.X}^2 = \sigma_Y^2(1 - \rho^2) \quad (43)$$

que debe compararse con (25), página 262.

INTERPRETACION PROBABILISTICA DE LA CORRELACION

De las anotaciones anteriores es lógico que un coeficiente de correlación poblacional debe dar una medida de qué tan bien una curva de regresión poblacional dada se ajusta a los datos poblacionales. Todas las anotaciones previamente enunciadas para la correlación en una muestra se aplican a la población. Por ejemplo, si $g(x)$ se determina por (37), entonces

$$E[(Y - \bar{Y})^2] = E[(Y - Y_{\text{est}})^2] + E[(Y_{\text{est}} - \bar{Y})^2] \quad (44)$$

donde $Y_{\text{est}} = g(X)$ y $\bar{Y} = E(Y)$. Las tres cantidades en (44) se llaman las *variaciones total, no explicada y explicada* respectivamente. Esto conduce a la definición del *coeficiente de correlación poblacional* ρ , donde

$$\rho^2 = \frac{\text{variación explicada}}{\text{variación total}} = \frac{E[(Y_{\text{est}} - \bar{Y})^2]}{E[(Y - \bar{Y})^2]} \quad (45)$$

Para el caso lineal, (45) se reduce a (40). Resultados análogos a (31)–(34) pueden escribirse para el caso de una población y regresión lineal. El resultado (45) también se emplea para definir ρ en el caso no lineal.

TEORIA MUESTRAL DE LA REGRESION

La ecuación de regresión $y = a + bx$ se obtiene basados en los datos muestrales. Con frecuencia estamos interesados en la correspondiente ecuación de regresión $y = \alpha + \beta x$ para la población de la cual se extrajo la muestra. Los siguientes son algunos ensayos relacionados con una población normal. Para conservar una notación sencilla seguimos la convención común de indicar valores de las variables aleatorias muestrales en cambio de las variables aleatorias en sí mismas.

1. Ensayo de la hipótesis $\beta = b$.

Para ensayar la hipótesis de que el coeficiente de regresión β es igual a algún valor específico b utilizamos el hecho de que el estadístico

$$t = \frac{\beta - b}{s_{y.x}/s_x} \sqrt{n-2} \quad (46)$$

tiene una distribución de Student con $n - 2$ grados de libertad. Esto también puede utilizarse para hallar intervalos de confianza para coeficientes de regresión poblacionales de los valores muestrales. Véanse Problemas 8.43 y 8.44.

2. Ensayo de hipótesis para valores predichos.

Denótese por y_0 el valor predicho de y correspondiente a $x = x_0$ estimado de la ecuación de regresión muestral, es decir, $y_0 = a + bx_0$. Denótese por y_p el valor predicho de y correspondiente a $x = x_0$ para la población. Entonces el estadístico

$$t = \frac{(y_0 - y_p)\sqrt{n-2}}{s_{y,x}\sqrt{n+1 + [n(x_0 - \bar{x})^2/s_x^2]}} \quad (47)$$

tiene una distribución de Student con $n - 2$ grados de libertad. De esta ecuación se pueden hallar límites de confianza para valores de población predichos. Véase Problema 8.45.

3. Ensayo de hipótesis para valores medios predichos.

Denótese por y_0 el valor predicho de y correspondiente a $x = x_0$ estimado de la ecuación de regresión muestral, es decir, $y_0 = a + bx_0$. Denótese por $\bar{y}_p$ el *valor medio* predicho de y correspondiente a $x = x_0$ para la población [esto es, $\bar{y}_p = E(Y|X = x_0)$]. Entonces el estadístico

$$t = \frac{(y_0 - \bar{y}_p)\sqrt{n-2}}{s_{y,x}\sqrt{1 + [(x_0 - \bar{x})^2/s_x^2]}} \quad (48)$$

tiene una distribución de Student con $n - 2$ grados de libertad. De aquí pueden hallarse los límites de confianza para valores medios poblacionales predichos. Véase Problema 8.46.

TEORIA MUESTRAL DE CORRELACION

Con frecuencia tenemos que estimar el coeficiente de correlación poblacional ρ a partir del coeficiente de correlación muestral r o ensayar la hipótesis relacionando a ρ . Para este propósito debemos conocer la distribución muestral de r . En el caso de que $\rho = 0$ esta distribución es simétrica y se puede utilizar un estadístico con distribución de Student. Para $\rho \neq 0$ la distribución es sesgada. En ese caso una transformación debida a Fisher produce un estadístico que aproximadamente tiene una distribución normal. Los ensayos siguientes resumen los procedimientos involucrados.

1. Ensayo de la hipótesis $\rho = 0$.

Aquí utilizamos el hecho de que el estadístico

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \quad (49)$$

tiene distribución de Student con $n - 2$ grados de libertad. Véanse Problemas 8.47 y 8.48.

2. Ensayo de la hipótesis $\rho \neq 0$.

Aquí utilizamos el hecho de que el estadístico

$$Z = \frac{1}{2} \ln \left(\frac{1+r}{1-r} \right) = 1.1513 \log_{10} \left(\frac{1+r}{1-r} \right) \quad (50)$$

aproximadamente tiene una distribución normal con media y desviación típica dadas por

$$\mu_z = \frac{1}{2} \ln \left(\frac{1+\rho}{1-\rho} \right) = 1.1513 \log_{10} \left(\frac{1+\rho}{1-\rho} \right), \quad \sigma_z = \frac{1}{\sqrt{n-3}} \quad (51)$$

Estos hechos pueden también utilizarse para hallar los límites de confianza para los coeficientes de correlación. Véanse Problemas 8.49 y 8.50. La transformación (50) se llama *transformación Z de Fisher*.

3. Significado de una diferencia entre coeficientes de correlación.

Para determinar si dos coeficientes de correlación r_1 y r_2 extraídos de muestras de tamaños n_1 y n_2 respectivamente difieren apreciablemente entre sí, calculamos Z_1 y Z_2 correspondientes a r_1 y r_2 utilizando (50). Luego utilizamos el hecho de que el estadístico

$$z = \frac{Z_1 - Z_2 - \mu_{Z_1 - Z_2}}{\sigma_{Z_1 - Z_2}} \quad (52)$$

$$\text{donde } \mu_{Z_1 - Z_2} = \mu_{Z_1} - \mu_{Z_2}, \quad \sigma_{Z_1 - Z_2} = \sqrt{\sigma_{Z_1}^2 + \sigma_{Z_2}^2} = \sqrt{\frac{1}{n_1 - 3} + \frac{1}{n_2 - 3}} \quad (53)$$

se distribuye normalmente. Véase Problema 8.51.

CORRELACION Y DEPENDENCIA

Si dos variables aleatorias X , Y tienen un coeficiente de correlación diferente a cero, sabemos (Teorema 3-15, página 82) que son *dependientes* en el sentido de probabilidad (esto es, su distribución conjunta no se factoriza en sus distribuciones marginales). Además, cuando $\rho \neq 0$, podemos utilizar una ecuación de la forma de (39) para *predecir* el valor de Y a partir del valor de X .

Es importante aclarar que “correlación” y “dependencia” en el sentido anterior no necesariamente implica una independencia causal directa de X y Y . Esto se demuestra en los ejemplos siguientes.

EJEMPLO 8.1. Sean X , Y variables aleatorias que representan estaturas y pesos de individuos. Aquí hay una independencia directa entre X , Y .

EJEMPLO 8.2. Si X representa los salarios anuales de los profesores en tanto que Y representa la cantidad de crímenes, el coeficiente de correlación puede ser diferente de cero y podríamos hallar una ecuación de regresión prediciendo una variable de la otra. Pero difícilmente diríamos que hay interdependencia directa entre X y Y .

Problemas resueltos

RECTA DE MINIMOS CUADROS

8.1. Una recta pasa por los puntos (x_1, y_1) y (x_2, y_2) . Demostrar que la ecuación de la recta es

$$y - y_1 = \left(\frac{y_2 - y_1}{x_2 - x_1} \right) (x - x_1)$$

La ecuación de una recta es $y = a + bx$. Entonces ya que (x_1, y_1) y (x_2, y_2) son puntos sobre la recta tenemos

$$y_1 = a + bx_1, \quad y_2 = a + bx_2$$

Por tanto

(1)

$$y - y_1 = (a + bx) - (a + bx_1) = b(x - x_1)$$

(2)

$$y_2 - y_1 = (a + bx_2) - (a + bx_1) = b(x_2 - x_1)$$

Obteniendo que $b = (y_2 - y_1)/(x_2 - x_1)$ de (2) y sustituyendo en (1), el resultado pedido se deduce.

La gráfica de la recta PQ se muestra en la Fig. 8-5. La constante $b = (y_2 - y_1)/(x_2 - x_1)$ es la pendiente de la recta.




Fig. 8-5

8.2. (a) Construir una recta que se aproxime a los datos de la Tabla 8-1. (b) Hallar una ecuación para esta recta.

(a) Dibujar los puntos (1, 1), (3, 2), (4, 4), (6, 4), (8, 5), (9, 7), (11, 8) y (14, 9) sobre un sistema de coordenadas rectangulares como se muestra en la Fig. 8-6.

Una recta que se aproxime a los datos se dibuja a *mano alzada* en la figura. Para un método que elimine la necesidad de juicio individual, véase Problema 8.4 que emplea el método de mínimos cuadrados.

(b) Para obtener la ecuación de la recta construida en (a), escójanse dos puntos cualesquiera sobre la recta, tales como P y Q, por ejemplo. Las coordenadas de estos puntos tomados de la gráfica son aproximadamente (0,1) y (12, 7.5). Entonces el Problema 8.1

$$y - 1 = \frac{7.5 - 1}{12 - 0}(x - 0)$$

$$\text{ó } y - 1 = 0.542x \quad \text{ó } y = 1 + 0.542x.$$

Tabla 8-1								
x	1	3	4	6	8	9	11	14
y	1	2	4	4	5	7	8	9




Fig. 8-6

8.3. Derivar las ecuaciones normales (4), página 260, para la recta de mínimos cuadrados.

Refiriéndonos a la Fig. 8-7. Los valores de y sobre la recta de mínimos cuadrados correspondientes a $x_1, x_2, \dots, x_n$ son

$$a + bx_1, a + bx_2, \dots, a + bx_n$$

Las desviaciones verticales correspondientes son

$$d_1 = a + bx_1 - y_1, \quad d_2 = a + bx_2 - y_2, \quad \dots,$$

$$d_n = a + bx_n - y_n$$

Entonces la suma de los cuadrados de las desviaciones es

$$d_1^2 + d_2^2 + \dots + d_n^2 = (a + bx_1 - y_1)^2 + (a + bx_2 - y_2)^2 + \dots + (a + bx_n - y_n)^2$$

$$\text{ó } \sum d^2 = \sum (a + bx - y)^2$$

Esto es una función de a y b, es decir, $F(a, b) = \sum (a + bx - y)^2$. Una condición necesaria para que esto sea un mínimo (o un máximo) es que $\partial F / \partial a = 0$, $\partial F / \partial b = 0$. Ya que

$$\frac{\partial F}{\partial a} = \sum \frac{\partial}{\partial a} (a + bx - y)^2 = \sum 2(a + bx - y)$$

$$\frac{\partial F}{\partial b} = \sum \frac{\partial}{\partial b} (a + bx - y)^2 = \sum 2x(a + bx - y)$$

obtenemos

$$\sum (a + bx - y) = 0 \quad \sum x(a + bx - y) = 0$$

es decir,

$$\sum y = an + b \sum x \quad \sum xy = a \sum x + b \sum x^2$$

como se pedía. Puede demostrarse que estas realmente resultan en un mínimo.




Fig. 8-7

8.4. Ajustar una recta de mínimos cuadrados a los datos del Problema 8.2 utilizando a (a) x como variable independiente, (b) x como variable dependiente.

(a) La ecuación de la recta es $y = a + bx$. Las ecuaciones normales son

$$\sum y = an + b \sum x$$

$$\sum xy = a \sum x + b \sum x^2$$

El trabajo involucrado en el cálculo de las sumas puede ordenarse como se indica en la Tabla 8-2. Aunque la última columna no se necesita para esta parte del problema, se ha agregado a la tabla para emplearla en la parte (b).

Tabla 8-2

x	y	x^2	xy	y^2
1	1	1	1	1
3	2	9	6	4
4	4	16	16	16
6	4	36	24	16
8	5	64	40	25
9	7	81	63	49
11	8	121	88	64
14	9	196	126	81
$\Sigma x = 56$	$\Sigma y = 40$	$\Sigma x^2 = 524$	$\Sigma xy = 364$	$\Sigma y^2 = 256$

Puesto que hay 8 pares de valores de x , y , $n = 8$ y las ecuaciones normales se convierten a

$$8a + 56b = 40$$

$$56a + 524b = 364$$

Resolviendo simultáneamente $a = \frac{6}{11}$ ó 0.545, $b = \frac{7}{11}$ ó 0.636; y la recta de mínimos cuadrados pedida es $y = \frac{6}{11} + \frac{7}{11}x$ ó $y = 0.545 + 0.636x$. Nótese que esta no es la recta obtenida en el Problema 8.2 utilizando el método a mano alzada.

Otro método.

$$a = \frac{(\Sigma y)(\Sigma x^2) - (\Sigma x)(\Sigma xy)}{n \Sigma x^2 - (\Sigma x)^2} = \frac{(40)(524) - (56)(364)}{(8)(524) - (56)^2} = \frac{6}{11} \text{ ó } 0.545$$

$$b = \frac{n \Sigma xy - (\Sigma x)(\Sigma y)}{n \Sigma x^2 - (\Sigma x)^2} = \frac{(8)(364) - (56)(40)}{(8)(524) - (56)^2} = \frac{7}{11} \text{ ó } 0.636$$

(b) Si se considera a x como la variable dependiente y a y como la variable independiente, la ecuación de la recta de mínimos cuadrados es $x = c + dy$, las ecuaciones normales son

$$\sum x = cn + d \sum y$$

$$\sum xy = c \sum y + d \sum y^2$$

Entonces utilizando la Tabla 8-2, las ecuaciones normales se convierten en

$$8c + 40d = 56$$

$$40c + 256d = 364$$

de donde $c = -\frac{1}{2}$ ó -0.50, $d = \frac{3}{2}$ ó 1.50.

Estos valores también pueden obtenerse de

$$c = \frac{(\Sigma x)(\Sigma y^2) - (\Sigma y)(\Sigma xy)}{n \Sigma y^2 - (\Sigma y)^2} = \frac{(56)(256) - (40)(364)}{(8)(256) - (40)^2} = -0.50$$

$$d = \frac{n \Sigma xy - (\Sigma x)(\Sigma y)}{n \Sigma y^2 - (\Sigma y)^2} = \frac{(8)(364) - (56)(40)}{(8)(256) - (40)^2} = 1.50$$