

Por tanto la ecuación pedida de la recta de mínimos cuadrados es $x = 0.50 + 1.50 y$.

Nótese que al solucionar esta ecuación para y obtenemos $y = 0.333 + 0.667 x$, que no es la misma recta obtenida en la parte (a).

8.5. Representar gráficamente las dos rectas obtenidas en el Problema 8.4.

Las gráficas de las dos rectas, $y = 0.545 + 0.636x$, $x = -0.50 + 1.50y$, se indican en la Fig. 8.8. Nótese que las dos rectas en este caso prácticamente coinciden, lo cual es una indicación de que los datos están muy bien descritos por una relación lineal.

La recta obtenida en la parte (a) se llama la *recta de regresión de y sobre x* y se utiliza para estimar y para valores dados de x . La recta obtenida en la parte (b) se llama la *recta de regresión de x sobre y* , se utiliza para estimar x para valores dados de y .




Fig. 8-8

- 8.6. (a) Demostrar que las dos rectas de mínimos cuadrados obtenidas en el Problema 8.4 intersecan en el punto $(\bar{x}, \bar{y})$. (b) Estimar el valor de y cuando $x = 12$. (c) Estimar el valor de x cuando $y = 3$.

$$\bar{x} = \frac{\Sigma x}{n} = \frac{56}{8} = 7, \quad \bar{y} = \frac{\Sigma y}{n} = \frac{40}{8} = 5$$

Luego el punto $(\bar{x}, \bar{y})$, llamado el *centroide*, es $(7, 5)$.

- (a) El punto $(7, 5)$ se encuentra en la recta $y = 0.545 + 0.636x$ o, más exactamente, $y = \frac{6}{11} + \frac{7}{11}x$, puesto que $5 = \frac{6}{11} + \frac{7}{11}(7)$. El punto $(7, 5)$ se encuentra sobre la recta $x = -\frac{1}{2} + \frac{3}{2}y$, puesto que $7 = -\frac{1}{2} + \frac{3}{2}(5)$.

Otro método.

Las ecuaciones de las dos rectas son $y = \frac{6}{11} + \frac{7}{11}x$ y $x = -\frac{1}{2} + \frac{3}{2}y$. Resolviendo simultáneamente, hallamos $x = 7$, $y = 5$. Por tanto las rectas se intersecan en el punto $(7, 5)$.

- (b) Al remplazar $x = 12$ en la recta de regresión de y sobre x , $y = 0.545 + 0.636(12) = 8.2$.
(c) Al remplazar $y = 3$ en la recta de regresión de x sobre y , $x = -0.50 + 1.50(3) = 4.0$.

8.7. Demostrar que una recta de mínimos cuadrados siempre pasa por el punto $(\bar{x}, \bar{y})$.

Caso 1. x es la variable independiente.

La ecuación de la recta de mínimos cuadrados es

$$(1) \quad y = a + bx$$

Una ecuación normal para la recta de mínimos cuadrados es

$$(2) \quad \Sigma y = an + b \Sigma x$$

Al dividir ambos lados de (2) por n da

$$(3) \quad \bar{y} = a + b\bar{x}$$

Restando (3) de (1), la recta de mínimos cuadrados puede escribirse como

$$(4) \quad y - \bar{y} = b(x - \bar{x})$$

que muestra que la recta pasa por el punto $(\bar{x}, \bar{y})$.

Caso 2. y es la variable independiente.

Procediendo como en el caso 1 intercambiando x , y ; reemplazando las constantes a , b por c , d respectivamente, hallamos que la recta de mínimos cuadrados puede escribirse como

$$(5) \quad x - \bar{x} = d(y - \bar{y})$$

que indica que la recta pasa por el punto $(\bar{x}, \bar{y})$.

Nótese que en general, las rectas (4) y (5) no coinciden, pero se intersectan en $(\bar{x}, \bar{y})$.

- 8.8. Demostrar que la recta de regresión de mínimos cuadrados de y sobre x puede escribirse en la forma (8), página 260.

Tenemos de (4), Problema 8.7, $y - \bar{y} = b(x - \bar{x})$. De la segunda ecuación en (5), página 260, tenemos

$$(1) \quad b = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2}$$

Entonces

$$\begin{aligned} \sum (x - \bar{x})^2 &= \sum (x^2 - 2\bar{x}x + \bar{x}^2) \\ &= \sum x^2 - 2\bar{x}\sum x + \sum \bar{x}^2 \\ &= \sum x^2 - 2n\bar{x}^2 + n\bar{x}^2 \\ &= \sum x^2 - n\bar{x}^2 \\ &= \sum x^2 - \frac{1}{n}(\sum x)^2 \\ &= \frac{1}{n}[n\sum x^2 - (\sum x)^2] \end{aligned}$$

También

$$\begin{aligned} \sum (x - \bar{x})(y - \bar{y}) &= \sum (xy - \bar{x}y - \bar{y}x + \bar{x}\bar{y}) \\ &= \sum xy - \bar{x}\sum y - \bar{y}\sum x + \sum \bar{x}\bar{y} \\ &= \sum xy - n\bar{x}\bar{y} - n\bar{y}\bar{x} + n\bar{x}\bar{y} \\ &= \sum xy - n\bar{x}\bar{y} \\ &= \sum xy - \frac{(\sum x)(\sum y)}{n} \\ &= \frac{1}{n}[n\sum xy - (\sum x)(\sum y)] \end{aligned}$$

Por tanto (1) se convierte en

$$b = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2}$$

de donde se obtiene el resultado (8). La demostración de (12), página 261, se sigue intercambiando x , y .

- 8.9. Sean $x = x' + h$, $y = y' + k$, donde h y k son constantes. Demostrar que

$$b = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2} = \frac{n \sum x'y' - (\sum x')(\sum y')}{n \sum x'^2 - (\sum x')^2}$$

Del Problema 8.8 tenemos

$$b = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2} = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2}$$

Entonces si $x = x' + h$, $y = y' + k$, tenemos

$$\bar{x} = \bar{x}' + h, \quad \bar{y} = \bar{y}' + k$$

$$\begin{aligned} \text{Por tanto} \quad \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2} &= \frac{\sum (x' - \bar{x}')(y' - \bar{y}')}{\sum (x' - \bar{x}')^2} \\ &= \frac{n \sum x'y' - (\sum x')(\sum y')}{n \sum x'^2 - (\sum x')^2} \end{aligned}$$

El resultado es útil para desarrollar un camino corto para obtener rectas de mínimos cuadrados al restar constantes apropiadas de los valores dados de x , y (véase Problema 8.12).

- 8.10 Si en el Problema 8.9, $h = \bar{x}$, $k = \bar{y}$, demostrar que

$$b = \frac{\sum x'y'}{\sum x'^2}$$

Se deduce inmediatamente del Problema 8.9 ya que

$$\Sigma x' = \Sigma(x - \bar{x}) = \Sigma x - n\bar{x} = 0$$

y análogamente $\Sigma y' = 0$.

- 8-11 La Tabla 8-3 muestra las respectivas estaturas x, y de una muestra de 12 padres y sus hijos mayores. (a) Construir un diagrama de dispersión. (b) Hallar la recta de regresión de mínimos cuadrados de y sobre x . (c) Hallar la recta de regresión de mínimos cuadrados de x sobre y .

Tabla 8-3

Estatura x del padre (pulgadas)	65	63	67	64	68	62	70	66	68	67	69	71
Estatura y del hijo (pulgadas)	68	66	68	65	69	66	68	65	71	67	68	70

- (a) El diagrama de dispersión se obtiene dibujando los puntos (x, y) sobre un sistema de coordenadas rectangulares como se muestra en la Fig. 8-9.

- (b) La recta de regresión de y sobre x está dada por $y = a + bx$, donde a y b se obtienen resolviendo las ecuaciones normales.

$$\Sigma y = an + b\Sigma x$$

$$\Sigma xy = a\Sigma x + b\Sigma x^2$$

Las sumas se muestran en la Tabla 8-4, de modo que las ecuaciones normales se convierten en

$$12a + 800b = 811$$

$$800a + 53,418b = 54,107$$

de donde hallamos $a = 35.82$ y $b = 0.476$, de modo que $y = 35.82 + 0.476x$. La gráfica de esta ecuación se muestra en la Fig. 8-9.




Fig. 8-9

Tabla 8-4

x	y	x^2	xy	y^2
65	68	4225	4420	4624
63	66	3969	4158	4356
67	68	4489	4556	4624
64	65	4096	4160	4225
68	69	4624	4692	4761
62	66	3844	4092	4356
70	68	4900	4760	4624
66	65	4356	4290	4225
68	71	4624	4828	5041
67	67	4489	4489	4489
69	68	4761	4692	4624
71	70	5041	4970	4900
$\Sigma x = 800$	$\Sigma y = 811$	$\Sigma x^2 = 53,418$	$\Sigma xy = 54,107$	$\Sigma y^2 = 54,849$

Otro método.

$$a = \frac{(\Sigma y)(\Sigma x^2) - (\Sigma x)(\Sigma xy)}{n\Sigma x^2 - (\Sigma x)^2} = 35.82, \quad b = \frac{n\Sigma xy - (\Sigma x)(\Sigma y)}{n\Sigma x^2 - (\Sigma x)^2} = 0.476$$

- (c) La recta de regresión de x sobre y viene dada por $x = c + dy$, donde c y d se obtienen solucionando las ecuaciones normales

$$\Sigma x = cn + d\Sigma y$$

$$\Sigma xy = c\Sigma y + d\Sigma y^2$$

Utilizando las sumas en la Tabla 8-4, se convierten en

$$12c + 811d = 800$$

$$811c + 54,849d = 54,107$$

de las cuales hallamos $c = -3.38$, $d = 1.036$, así que $x = -3.38 + 1.036y$. La gráfica de esta ecuación se muestra en la Fig. 8-9.

Otro método.

$$c = \frac{(\Sigma x)(\Sigma y^2) - (\Sigma y)(\Sigma xy)}{n\Sigma y^2 - (\Sigma y)^2} = -3.38, \quad d = \frac{n\Sigma xy - (\Sigma y)(\Sigma x)}{n\Sigma y^2 - (\Sigma y)^2} = 1.036$$

8.12. Solucionar el Problema 8.11 utilizando el método del Problema 8.9.

Rétese un valor apropiado, por ejemplo 68, de x , y (los números restados de x y de y podrían ser diferentes). Esto nos conduce a la Tabla 8-5.

Tabla 8-5

x'	y'	x'^2	$x'y'$	y'^2
-3	0	9	0	0
-5	-2	25	10	4
-1	0	1	0	0
-4	-3	16	12	9
0	1	0	0	1
-6	-2	36	12	4
2	0	4	0	0
-2	-3	4	6	9
0	3	0	0	9
-1	-1	1	1	1
1	0	1	0	0
3	2	9	6	4
$\Sigma x' = -16$	$\Sigma y' = -5$	$\Sigma x'^2 = 106$	$\Sigma x'y' = 47$	$\Sigma y'^2 = 41$

De la tabla hallamos

$$b = \frac{n\Sigma x'y' - (\Sigma x')(\Sigma y')}{n\Sigma x'^2 - (\Sigma x')^2} = \frac{(12)(47) - (-16)(-5)}{(12)(106) - (16)^2} = 0.476$$

También ya que $x' = x - 68$, $y' = y - 68$ tenemos $\bar{x}' = \bar{x} - 68$, $\bar{y}' = \bar{y} - 68$. Por tanto

$$\bar{x} = \bar{x}' + 68 = -\frac{16}{12} + 68 = 66.67, \quad \bar{y} = \bar{y}' + 68 = -\frac{5}{12} + 68 = 67.58$$

La ecuación de regresión pedida de y sobre x es $y - \bar{y} = b(x - \bar{x})$, esto es

$$y - 67.58 = 0.476(x - 66.07) \quad \text{ó} \quad y = 35.85 + 0.476x$$

de acuerdo con el Problema 8.11, aparte de los errores de redondeo. De una manera análoga podemos obtener la ecuación de regresión de x sobre y .

ECUACIONES NO LINEALES REDUCIBLES A FORMA LINEAL

- 8.13. La tabla 8-6 da valores experimentales de la presión P de una masa de gas dada correspondiente a varios valores del volumen V . De acuerdo con los principios de la termodinámica una relación de la forma $PV^\gamma = C$, donde γ y C son constantes, debe existir entre las variables. (a) Hallar el valor de γ y C . (b) Escribir las ecuaciones que relacionan a P y V . (c) Estimar P cuando $V = 100.0$ pulgadas cúbicas.

Tabla 8-6

Volumen V (pul ³)	54.3	61.8	72.4	88.7	118.6	194.0
Presión P (lb/pul ²)	61.2	49.5	37.6	28.4	19.2	10.1

Ya que $PV^\gamma = C$, tenemos tomando logaritmos de base 10

$$\log P + \gamma \log V = \log C \quad \text{ó} \quad \log P = \log C - \gamma \log V$$

Tomando $\log V = x$, $\log P = y$, la última ecuación puede escribirse

$$(1) \quad y = a + bx$$

donde $a = \log C$, $b = -\gamma$.

La Tabla 8-7 da los valores x , y correspondientes a los valores de V , P de la Tabla 8-6 y también indica los cálculos involucrados en el cómputo de la recta de mínimos cuadrados (1).

Las ecuaciones normales correspondientes a la recta de mínimos cuadrados (1) son

$$\Sigma y = an + b\Sigma x \quad \Sigma xy = a\Sigma x + b\Sigma x^2$$

de las cuales

$$a = \frac{(\Sigma y)(\Sigma x^2) - (\Sigma x)(\Sigma xy)}{n\Sigma x^2 - (\Sigma x)^2} = 4.20, \quad b = \frac{n\Sigma xy - (\Sigma x)(\Sigma y)}{n\Sigma x^2 - (\Sigma x)^2} = -1.40$$

Luego $y = 4.20 - 1.40x$.

Tabla 8-7

$x = \log V$	$y = \log P$	x^2	xy
1.7348	1.7868	3.0095	3.0997
1.7910	1.6946	3.2077	3.0350
1.8597	1.5752	3.4585	2.9294
1.9479	1.4533	3.7943	2.8309
2.0741	1.2833	4.3019	2.6617
2.2878	1.0043	5.2340	2.2976
$\Sigma x = 11.6953$	$\Sigma y = 8.7975$	$\Sigma x^2 = 23.0059$	$\Sigma xy = 16.8543$

(a) Puesto que $a = 4.20 = \log C$ y $b = -1.40 = -\gamma$, $C = 1.60 \times 10^4$ y $\gamma = 1.40$.

(b) $PV^{1.40} = 16,000$.

(c) Cuando $V = 100$, $x = \log V = 2$ y $y = \log P = 4.20 - 1.40(2) = 1.40$. Entonces $P = \text{antilog } 1.40 = 25.1 \text{ lb/pulg}^2$.

8.14. Solucionar el Problema 8.13 dibujando los datos en un papel log-log.

Para cada pareja de valores de la presión P y el volumen V en la Tabla 8-6, obtenemos un punto que se dibuja en el *papel log-log* construido especialmente como se muestra en la Fig. 8-10.




Fig. 8-10

También se indica una recta (dibujada a mano alzada) que se aproxima a estos puntos. La gráfica resultante muestra que hay una relación lineal entre $\log P$ y $\log V$ que puede representarse por la ecuación

$$\log P = a + b \log V \quad \text{ó} \quad y = a + bx$$

La pendiente b , que es negativa en este caso, se da numéricamente por la relación de la longitud AB a la longitud AC . La medida en este caso indica que $b = -1.4$.

Para obtener a se necesita un punto sobre la recta. Por ejemplo cuando $V = 100$, $P = 25$ de la gráfica. Entonces

$$a = \log P - b \log V = \log 25 + 1.4 \log 100 = 1.4 + (1.4)(2) = 4.2$$

de modo que

$$\log P + 1.4 \log V = 4.2, \quad \log PV^{1.4} = 4.2, \quad \text{y} \quad PV^{1.4} = 16,000$$

PARABOLA DE MINIMOS CUADRADOS

8.15. Derivar las ecuaciones normales (19), página 261, para la parábola de mínimos cuadrados.

$$y = a + bx + cx^2$$

Sean los puntos muestrales $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$. Entonces los valores de y sobre la parábola de mínimos cuadrados correspondientes a $x_1, x_2, \dots, x_n$ son

$$a + bx_1 + cx_1^2, \quad a + bx_2 + cx_2^2, \quad \dots, \quad a + bx_n + cx_n^2$$

Por tanto las desviaciones de $y_1, y_2, \dots, y_n$ están dadas por

$$d_1 = a + bx_1 + cx_1^2 - y_1, \quad d_2 = a + bx_2 + cx_2^2 - y_2, \quad \dots, \quad d_n = a + bx_n + cx_n^2 - y_n$$

y la suma de los cuadrados de las desviaciones está dada por

$$\sum d^2 = \sum (a + bx + cx^2 - y)^2$$

Esta es función de a , b , c , es decir

$$F(a, b, c) = \sum (a + bx + cx^2 - y)^2$$

Para minimizar esta función debemos tener

$$\frac{\partial F}{\partial a} = 0, \quad \frac{\partial F}{\partial b} = 0, \quad \frac{\partial F}{\partial c} = 0$$

$$\begin{aligned} \text{Entonces} \quad \frac{\partial F}{\partial a} &= \sum \frac{\partial}{\partial a} (a + bx + cx^2 - y)^2 = \sum 2(a + bx + cx^2 - y) \\ \frac{\partial F}{\partial b} &= \sum \frac{\partial}{\partial b} (a + bx + cx^2 - y)^2 = \sum 2x(a + bx + cx^2 - y) \\ \frac{\partial F}{\partial c} &= \sum \frac{\partial}{\partial c} (a + bx + cx^2 - y)^2 = \sum 2x^2(a + bx + cx^2 - y) \end{aligned}$$

Al simplificar cada una de estas sumas e igualándola a cero se obtienen las ecuaciones (19), página 261.

8.16. Ajustar una parábola de mínimos cuadrados de la forma $y = a + bx + cx^2$ a los datos de la Tabla 8-8.

Tabla 8-8

x	1.2	1.8	3.1	4.9	5.7	7.1	8.6	9.8
y	4.5	5.9	7.0	7.8	7.2	6.8	4.5	2.7

Las ecuaciones normales son

$$\begin{aligned} \Sigma y &= an + b\Sigma x + c\Sigma x^2 \\ \Sigma xy &= a\Sigma x + b\Sigma x^2 + c\Sigma x^3 \\ \Sigma x^2y &= a\Sigma x^2 + b\Sigma x^3 + c\Sigma x^4 \end{aligned} \quad (1)$$

El trabajo involucrado en computar las sumas puede ordenarse como se muestra en la Tabla 8-9.

Tabla 8-9

x	y	x^2	x^3	x^4	xy	x^2y
1.2	4.5	1.44	1.73	2.08	5.40	6.48
1.8	5.9	3.24	5.83	10.49	10.62	19.12
3.1	7.0	9.61	29.79	92.35	21.70	67.27
4.9	7.8	24.01	117.65	576.48	38.22	187.28
5.7	7.2	32.49	185.19	1055.58	41.04	233.93
7.1	6.8	50.41	357.91	2541.16	48.28	342.79
8.6	4.5	73.96	636.06	5470.12	38.70	332.82
9.8	2.7	96.04	941.19	9223.66	26.46	259.31
$\Sigma x =$ 42.2	$\Sigma y =$ 46.4	$\Sigma x^2 =$ 291.20	$\Sigma x^3 =$ 2275.35	$\Sigma x^4 =$ 18,971.92	$\Sigma xy =$ 230.42	$\Sigma x^2y =$ 1449.00

Puesto que $n = 8$, las ecuaciones normales (1) se convierten en

$$\begin{aligned} 8a + 42.2b + 291.20c &= 46.4 \\ 42.2a + 291.20b + 2275.35c &= 230.42 \\ 291.20a + 2275.35b + 18971.92c &= 1449.00 \end{aligned} \quad (2)$$

Resolviendo, $a = 2.588$, $b = 2.065$, $c = -0.2110$; así la parábola de mínimos cuadrados pedida tiene la ecuación

$$y = 2.588 + 2.065x - 0.2110x^2$$

- 8.17. Utilizar la parábola de mínimos cuadrados del Problema 8.16 para estimar los valores de y de los valores dados de x .

Para $x = 1.2$, $y_{\text{est}} = 2.588 + 2.065(1.2) - 0.2110(1.2)^2 = 4.762$. Análogamente se obtienen otros valores estimados. Los resultados se muestran en la Tabla 8-10 junto con los valores reales de y .

Tabla 8-10

y_{est}	4.762	5.621	6.962	7.640	7.503	6.613	4.741	2.561
y	4.5	5.9	7.0	7.8	7.2	6.8	4.5	2.7

REGRESION MULTIPLE

- 8.18 Se desea estimar una variable z de las variables x, y por medio de una ecuación de regresión de la forma $z = a + bx + cy$. Demostrar que la ecuación de regresión de mínimos cuadrados se obtiene al determinar a, b, c de modo que satisfaga (21), página 262.

Sean los puntos muestrales $(x_1, y_1, z_1), \dots, (x_n, y_n, z_n)$. Entonces los valores de z sobre el plano de regresión de mínimos cuadrados correspondientes a $(x_1, y_1), \dots, (x_n, y_n)$ son respectivamente

$$a + bx_1 + cy_1, \dots, a + bx_n + cy_n$$

Por tanto las desviaciones de $z_1, \dots, z_n$ vienen dadas por

$$d_1 = a + bx_1 + cy_1 - z_1, \dots, d_n = a + bx_n + cy_n - z_n$$

y la suma de los cuadrados de las desviaciones está dada por

$$\sum d^2 = \sum (a + bx + cy - z)^2$$

Considerando esto como función de a, b, c e igualando las derivadas parciales con respecto a a, b y c a cero, las ecuaciones normales pedidas (21) en la página 262 se obtienen.

- 8.19. La Tabla 8-11 muestra los pesos z a la libra más cercana, las estaturas x a la pulgada más cercana y las edades y al año más cercano de 12 muchachos. (a) Hallar la ecuación de regresión de mínimos cuadrados de z sobre x, y . (b) Determinar los valores estimados de z de los valores dados de x, y . (c) Estimar el peso de un muchacho de 9 años y 54 pulgadas de estatura.

Tabla 8-11

Peso (z)	64	71	53	67	55	58	77	57	56	51	76	68
Estatura (x)	57	59	49	62	51	50	55	48	52	42	61	57
Edad (y)	8	10	6	11	8	7	10	9	10	6	12	9

- (a) La ecuación de regresión lineal de z sobre x, y puede escribirse

$$z = a + bx + cy$$

Las ecuaciones normales (21), página 262, vienen dadas por

$$\sum z = na + b\sum x + c\sum y$$

$$(1) \quad \sum xz = a\sum x + b\sum x^2 + c\sum xy$$

$$\sum yz = a\sum y + b\sum xy + c\sum y^2$$

El trabajo involucrado en computar las sumas puede ordenarse como se indica en la Tabla 8-12.

Tabla 8-12

z	x	y	z^2	x^2	y^2	xz	yz	xy
64	57	8	4096	3249	64	3648	512	456
71	59	10	5041	3481	100	4189	710	590
53	49	6	2809	2401	36	2597	318	294
67	62	11	4489	3844	121	4154	737	682
55	51	8	3025	2601	64	2805	440	408
58	50	7	3364	2500	49	2900	406	350
77	55	10	5929	3025	100	4235	770	550
57	48	9	3249	2304	81	2736	513	432
56	52	10	3136	2704	100	2912	560	520
51	42	6	2601	1764	36	2142	306	252
76	61	12	5776	3721	144	4636	912	732
68	57	9	4624	3249	81	3876	612	513
$\Sigma z =$ 753	$\Sigma x =$ 643	$\Sigma y =$ 106	$\Sigma z^2 =$ 48,139	$\Sigma x^2 =$ 34,843	$\Sigma y^2 =$ 976	$\Sigma xz =$ 40,830	$\Sigma yz =$ 6796	$\Sigma xy =$ 5779

Utilizando esta tabla, las ecuaciones normales (1) se convierten en

$$12a + 643b + 106c = 753$$

(2)

$$643a + 34,843b + 5779c = 40,830$$

$$106a + 5779b + 976c = 6796$$

Resolviendo, $a = 3.6512$, $b = 0.8546$, $c = 1.5063$, la ecuación de regresión pedida es

(3)

$$z = 3.65 + 0.855x + 1.506y$$

- (b) Utilizando la ecuación de regresión (3) obtenemos los valores estimados de z , denotados por z_{est} , al sustituir los valores correspondientes de x , y . Los resultados se dan en la Tabla 8-13 junto con los valores muestrales de z .

Tabla 8-13

z_{est}	64.414	69.136	54.564	73.206	59.286	56.925	65.717	58.229	63.153	48.582	73.857	65.920
z	64	71	53	67	55	58	77	57	56	51	76	68

- (c) Remplazando $x = 54$, $y = 9$ en (3), el peso estimado es $z_{\text{est}} = 63.356$, o aproximadamente 63 lb.

ERROR TIPICO DE LA ESTIMA

8.20. Si la recta de regresión de mínimos cuadrados de y sobre x viene dada por $y = a + bx$, demostrar que el error típico de la estima $s_{y,x}$ está dado por

$$s_{y,x}^2 = \frac{\Sigma y^2 - a \Sigma y - b \Sigma xy}{n}$$

Los valores de y estimados a partir de la recta de regresión vienen dados por $y_{\text{est}} = a + bx$. Entonces

$$\begin{aligned}
 s_{y,x}^2 &= \frac{\Sigma (y - y_{\text{est}})^2}{n} = \frac{\Sigma (y - a - bx)^2}{n} \\
 &= \frac{\Sigma y(y - a - bx) - a \Sigma (y - a - bx) - b \Sigma x(y - a - bx)}{n}
 \end{aligned}$$

Pero

$$\Sigma(y - a - bx) = \Sigma y - an - b\Sigma x = 0$$

$$\Sigma x(y - a - bx) = \Sigma xy - a\Sigma x - b\Sigma x^2 = 0$$

puesto que de las ecuaciones normales

$$\Sigma y = an + b\Sigma x \quad \Sigma xy = a\Sigma x + b\Sigma x^2$$

Entonces

$$s_{y,x}^2 = \frac{\Sigma y(y - a - bx)}{n} = \frac{\Sigma y^2 - a\Sigma y - b\Sigma xy}{n}$$

Este resultado puede extenderse a ecuaciones de regresión no lineal.

8.21. Demostrar que el resultado del Problema 8.20 puede escribirse como

$$s_{y,x}^2 = \frac{\Sigma(y - \bar{y})^2 - b\Sigma(x - \bar{x})(y - \bar{y})}{n}$$

Método 1.

Si $x = x' + \bar{x}$, $y = y' + \bar{y}$. Entonces del Problema 8.20

$$\begin{aligned} ns_{y,x}^2 &= \Sigma y^2 - a\Sigma y - b\Sigma xy \\ &= \Sigma(y' + \bar{y})^2 - a\Sigma(y' + \bar{y}) - b\Sigma(x' + \bar{x})(y' + \bar{y}) \\ &= \Sigma(y'^2 + 2y'\bar{y} + \bar{y}^2) - a(\Sigma y' + n\bar{y}) - b\Sigma(x'y' + \bar{x}y' + x'\bar{y} + \bar{x}\bar{y}) \\ &= \Sigma y'^2 + 2\bar{y}\Sigma y' + n\bar{y}^2 - an\bar{y} - b\Sigma x'y' - b\bar{x}\Sigma y' - b\bar{y}\Sigma x' - bn\bar{x}\bar{y} \\ &= \Sigma y'^2 + n\bar{y}^2 - an\bar{y} - b\Sigma x'y' - bn\bar{x}\bar{y} \\ &= \Sigma y'^2 - b\Sigma x'y' + n\bar{y}(\bar{y} - a - b\bar{x}) \\ &= \Sigma y'^2 - b\Sigma x'y' \\ &= \Sigma(y - \bar{y})^2 - b\Sigma(x - \bar{x})(y - \bar{y}) \end{aligned}$$

donde hemos utilizado los resultados $\Sigma x' = 0$, $\Sigma y' = 0$ y $\bar{y} = a + b\bar{x}$ (que se deducen al dividir ambos lados de la ecuación normal $\Sigma y = an + b\Sigma x$ por n). Esto demuestra el resultado pedido.

Método 2.

Sabemos que la recta de regresión puede escribirse como $y - \bar{y} = b(x - \bar{x})$, que corresponde a empezar con $y = a + bx$ y remplazando: a por cero, y por $y - \bar{y}$, x por $x - \bar{x}$. Cuando se hacen estos remplazos en el Problema 8.20 se obtiene el resultado pedido.

8.22. Calcular el error típico de la estima, $s_{y,x}$, para los datos del Problema 8.11.

Del Problema 8.11(b) la recta de regresión de y sobre x es $y = 35.82 + 0.476x$. En la Tabla 8-14 se listan los valores reales de y (de la Tabla 8-3) y los valores estimados de y , denotados por y_{est} , como se obtienen de la recta de regresión. Por ejemplo, correspondiendo a $x = 65$ tenemos $y_{\text{est}} = 35.82 + 0.476(65) = 66.76$.

También se indican los valores $y - y_{\text{est}}$, que se necesitan para el cálculo de $s_{y,x}$.

Tabla 8-14

x	65	63	67	64	68	62	70	66	68	67	69	71
y	68	66	68	65	69	66	68	65	71	67	68	70
y_{est}	66.76	65.81	67.71	66.28	68.19	65.33	69.14	67.24	68.19	67.71	68.66	69.62
$y - y_{\text{est}}$	1.24	0.19	0.29	-1.28	0.81	0.67	-1.14	-2.24	2.81	-0.71	-0.66	0.38

$$s_{y,x}^2 = \frac{\Sigma(y - y_{\text{est}})^2}{n} = \frac{(1.24)^2 + (0.19)^2 + \cdots + (0.38)^2}{12} = 1.642$$

y $s_{y,x} = \sqrt{1.642} = 1.28$ pulgadas.

8.23. (a) Construir dos rectas paralelas a la recta de regresión del Problema 8.11 a una distancia vertical $s_{y,x}$. (b) Determinar el porcentaje de puntos de datos que se encuentren entre estas dos rectas.

(a) La recta de regresión $y = 35.82 + 0.476x$ obtenida en el Problema 8.11 se muestra sólida en la Fig. 8-11. Las dos rectas paralelas, cada una a una distancia vertical $s_{y,x} = 1.28$ (véase Problema 8.22), se muestran a trazos en la Fig. 8-11.

(b) De la figura se ve que de los 12 puntos de datos, 7 se encuentran entre las rectas en tanto que 3 parecen estar sobre las rectas. Un examen posterior utilizando el último renglón en la Tabla 8-14 revela que 2 de estos 3 puntos se encuentran entre las rectas. Entonces el porcentaje pedido es $9/12 = 75\%$.

Otro método.

Del último renglón de la Tabla 8-14, $y - y_{est}$ se encuentra entre -1.28 y 1.28 (es decir, $\pm s_{y,x}$) para 9 puntos (x, y). Entonces el porcentaje pedido es $9/12 = 75\%$.




Fig. 8-11

Si los puntos están distribuidos normalmente respecto a la recta de regresión, la teoría predice que alrededor del 68% de los puntos se encuentra entre las rectas. Este hubiera sido el caso aproximado si el tamaño fuera más grande.

NOTA: Una mejor estima del error típico de la estima de la población de la cual se tomaron las estaturas viene dada por $\hat{s}_{y,x} = \sqrt{n/(n-2)} s_{y,x} = \sqrt{12/10} (1.28) = 1.40$ pulgadas.

COEFICIENTE DE CORRELACION LINEAL

8.24. Demostrar que $\Sigma(y - \bar{y})^2 = \Sigma(y - y_{est})^2 + \Sigma(y_{est} - \bar{y})^2$.

Elevando al cuadrado $y - \bar{y} = (y - y_{est}) + (y_{est} - \bar{y})$ sumando, tenemos

$$\Sigma(y - \bar{y})^2 = \Sigma(y - y_{est})^2 + \Sigma(y_{est} - \bar{y})^2 + 2\Sigma(y - y_{est})(y_{est} - \bar{y})$$

El resultado pedido se deduce si podemos mostrar que la última suma es cero. En el caso de regresión lineal este es el caso, ya que

$$\begin{aligned} \Sigma(y - y_{est})(y_{est} - \bar{y}) &= \Sigma(y - a - bx)(a + bx - \bar{y}) \\ &= a\Sigma(y - a - bx) + b\Sigma x(y - a - bx) - \bar{y}\Sigma(y - a - bx) \\ &= 0 \end{aligned}$$

puesto que de las ecuaciones normales $\Sigma(y - a - bx) = 0$, $\Sigma x(y - a - bx) = 0$.

Análogamente puede demostrarse que el resultado es válido para regresión no lineal utilizando una curva de mínimos cuadrados dada por $y_{est} = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$.

8.25. Calcular (a) la variación explicada, (b) la variación no explicada y (c) la variación total para los datos del Problema 8.11.

Tenemos $\bar{y} = 67.58$ del Problema 8.12 (o de la Tabla 8-4, ya que $\bar{y} = 811/12 = 67.58$). Utilizando los valores y_{est} de la Tabla 8-14 podemos construir la Tabla 8-15.

Tabla 8-15

$y_{est} - \bar{y}$	-0.82	-1.77	0.13	-1.30	0.61	-2.25	1.56	-0.34	0.61	0.13	1.08	2.04
---------------------	-------	-------	------	-------	------	-------	------	-------	------	------	------	------

(a) Variación explicada = $\Sigma(y_{est} - \bar{y})^2 = (-0.82)^2 + \dots + (2.04)^2 = 19.22$.

(b) Variación no explicada = $\Sigma(y - y_{est})^2 = ns_{y,x}^2 = 19.70$, del Problema 8.22.

(c) Variación total = $\Sigma(y - \bar{y})^2 = 19.22 + 19.70 = 38.92$, del Problema 8.24.

Los resultados (b) y (c) pueden obtenerse por cálculo directo de la suma de los cuadrados.

8.26. Hallar (a) el coeficiente de determinación y (b) el coeficiente de correlación para los datos del Problema 8.11. Utilizar los resultados del Problema 8.25.

$$(a) \text{ coeficiente de determinación } = r^2 = \frac{\text{variación explicada}}{\text{variación total}} = \frac{19.22}{38.92} = 0.4938.$$

$$(b) \text{ coeficiente de correlación } = r = \pm\sqrt{0.4938} = \pm 0.7027.$$

Puesto que la variable y_{est} aumenta a medida que x aumenta, la correlación es positiva y por tanto escribimos $r = 0.7027$ o con dos cifras significativas $r = 0.70$.

8.27. A partir del resultado general (30), página 263, para el coeficiente de correlación, derivar el resultado (34), página 264, (la fórmula producto momento), en el caso de regresión lineal.

La recta de regresión de mínimos cuadrados de y sobre x puede escribirse $y_{\text{est}} = a + bx$ ó $y'_{\text{est}} = bx'$, donde $b = \Sigma x'y' / \Sigma x'^2$, $x' = x - \bar{x}$, y $y'_{\text{est}} = y_{\text{est}} - \bar{y}$. Entonces, utilizando $y' = y - \bar{y}$, tenemos

$$\begin{aligned} r^2 &= \frac{\text{variación explicada}}{\text{variación no explicada}} = \frac{\Sigma(y_{\text{est}} - \bar{y})^2}{\Sigma(y - \bar{y})^2} = \frac{\Sigma y'^2_{\text{est}}}{\Sigma y'^2} \\ &= \frac{\Sigma b^2 x'^2}{\Sigma y'^2} = \frac{b^2 \Sigma x'^2}{\Sigma y'^2} = \left(\frac{\Sigma x'y'}{\Sigma x'^2} \right)^2 \left(\frac{\Sigma x'^2}{\Sigma y'^2} \right) = \frac{(\Sigma x'y')^2}{\Sigma x'^2 \Sigma y'^2} \end{aligned}$$

así

$$r = \pm \frac{\Sigma x'y'}{\sqrt{\Sigma x'^2 \Sigma y'^2}}$$

Sin embargo, puesto que $\Sigma x'y'$ es positiva cuando y_{est} aumenta a medida que x aumenta, pero negativa cuando y_{est} disminuye a medida que x aumenta, la expresión para r tiene automáticamente el signo correcto asociado. Por tanto se sigue el resultado pedido.

8.28. Utilizando la fórmula producto-momento, obtener el coeficiente de correlación lineal para los datos del Problema 8.11.

El trabajo involucrado en la computación puede organizarse como se indica en la Tabla 8-16. Entonces

$$r = \frac{\Sigma x'y'}{\sqrt{(\Sigma x'^2)(\Sigma y'^2)}} = \frac{40.34}{\sqrt{(84.68)(38.92)}} = 0.7027$$

de acuerdo con el Problema 8.26(b).

Tabla 8-16

x	y	$x' = x - \bar{x}$	$y' = y - \bar{y}$	x'^2	$x'y'$	y'^2
65	68	-1.7	0.4	2.89	-0.68	0.16
63	66	-3.7	-1.6	13.69	5.92	2.56
67	68	0.3	0.4	0.09	0.12	0.16
64	65	-2.7	-2.6	7.29	7.02	6.76
68	69	1.3	1.4	1.69	1.82	1.96
62	66	-4.7	-1.6	22.09	7.52	2.56
70	68	3.3	0.4	10.89	1.32	0.16
66	65	-0.7	-2.6	0.49	1.82	6.76
68	71	1.3	3.4	1.69	4.42	11.56
67	67	0.3	-0.6	0.09	-0.18	0.36
69	68	2.3	0.4	5.29	0.92	0.16
71	70	4.3	2.4	18.49	10.32	5.76
$\Sigma x = 800$ $\bar{x} = 800/12$ $= 66.7$	$\Sigma y = 811$ $\bar{y} = 811/12$ $= 67.6$			$\Sigma x'^2 = 84.68$	$\Sigma x'y' = 40.34$	$\Sigma y'^2 = 38.92$

$\Sigma x = 800$
 $\Sigma y = 811$
 $R = 0.7027$
 $ST = 19.2135$

8.29. Demostrar el resultado (17), página 261.

La recta de regresión de y sobre x es

$$y = a + bx \quad \text{donde} \quad b = \frac{rs_y}{s_x}$$

Análogamente, la recta de regresión de x sobre y es

$$x = c + dy \quad \text{donde} \quad d = \frac{rs_x}{s_y}$$

Entonces

$$bd = \left(\frac{rs_y}{s_x}\right)\left(\frac{rs_x}{s_y}\right) = r^2$$

8.30. Utilizar el resultado del Problema 8.29 para hallar el coeficiente de correlación lineal para los datos del Problema 8.11.

Del Problema 8.11 (b) y 8.11(c) respectivamente

$$b = \frac{484}{1016} = 0.476 \quad d = \frac{484}{467} = 1.036$$

Entonces

$$r^2 = bd = \left(\frac{484}{1016}\right)\left(\frac{484}{467}\right) \quad \text{ó} \quad r = 0.7027$$

que está de acuerdo con los Problemas 8.26(b) y 8.28.

8.31. Demostrar que el coeficiente de correlación lineal viene dado por

$$r = \frac{n\sum xy - (\sum x)(\sum y)}{\sqrt{[n\sum x^2 - (\sum x)^2][n\sum y^2 - (\sum y)^2]}}$$

En el Problema 8.27 se demostró que

$$(1) \quad r = \frac{\sum x'y'}{\sqrt{(\sum x'^2)(\sum y'^2)}} = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{[\sum (x - \bar{x})^2][\sum (y - \bar{y})^2]}}$$

Pero

$$\begin{aligned} \sum (x - \bar{x})(y - \bar{y}) &= \sum (xy - \bar{x}y - x\bar{y} + \bar{x}\bar{y}) = \sum xy - \bar{x}\sum y - \bar{y}\sum x + n\bar{x}\bar{y} \\ &= \sum xy - n\bar{x}\bar{y} - n\bar{y}\bar{x} + n\bar{x}\bar{y} = \sum xy - n\bar{x}\bar{y} \\ &= \sum xy - \frac{(\sum x)(\sum y)}{n} \end{aligned}$$

Puesto que $\bar{x} = (\sum x)/n$ y $\bar{y} = (\sum y)/n$.

Análogamente,

$$\begin{aligned} \sum (x - \bar{x})^2 &= \sum (x^2 - 2x\bar{x} + \bar{x}^2) = \sum x^2 - 2\bar{x}\sum x + n\bar{x}^2 \\ &= \sum x^2 - \frac{2(\sum x)^2}{n} + \frac{(\sum x)^2}{n} = \sum x^2 - \frac{(\sum x)^2}{n} \end{aligned}$$

y

$$\sum (y - \bar{y})^2 = \sum y^2 - \frac{(\sum y)^2}{n}$$

Entonces (1) se convierte en

$$r = \frac{\sum xy - (\sum x)(\sum y)/n}{\sqrt{[\sum x^2 - (\sum x)^2/n][\sum y^2 - (\sum y)^2/n]}} = \frac{n\sum xy - (\sum x)(\sum y)}{\sqrt{[n\sum x^2 - (\sum x)^2][n\sum y^2 - (\sum y)^2]}}$$

- 8.32. Utilizar la fórmula del Problema 8.31 para obtener el coeficiente de correlación lineal para los datos del Problema 8.11.

De la Tabla 8-4

$$\begin{aligned}
 r &= \frac{n\sum xy - (\sum x)(\sum y)}{\sqrt{[n\sum x^2 - (\sum x)^2][n\sum y^2 - (\sum y)^2]}} \\
 &= \frac{(12)(54,107) - (800)(811)}{\sqrt{[(12)(53,418) - (800)^2][(12)(54,849) - (811)^2]}} = 0.7027
 \end{aligned}$$

como en los Problemas 8.26(b), 8.28 y 8.30.

COEFICIENTE DE CORRELACION GENERALIZADO

- 8.33. (a) Hallar el coeficiente de correlación lineal entre las variables x , y del Problema 8.16. (b) Hallar el coeficiente de correlación no lineal entre estas variables, suponiendo la relación parabólica obtenida en el Problema 8.16. (c) Explicar la diferencia entre los coeficientes de correlación obtenidos en (a) y (b). (d) ¿Qué porcentaje de la variación total permanece como no explicada por la suposición de la relación parabólica entre x , y ?

(a) Utilizando los cálculos de la Tabla 8-9 y agregando que $\sum y^2 = 290.52$, hallamos

$$\begin{aligned}
 r &= \frac{n\sum xy - (\sum x)(\sum y)}{\sqrt{[n\sum x^2 - (\sum x)^2][n\sum y^2 - (\sum y)^2]}} \\
 &= \frac{(8)(230.42) - (42.2)(46.4)}{\sqrt{[(8)(291.20) - (42.2)^2][(8)(290.52) - (46.4)^2]}} = -0.3743
 \end{aligned}$$

(b) De la Tabla 8-9, $\bar{y} = (\sum y)/n = (46.4)/8 = 5.80$. Entonces

$$\text{variación total} = \sum (y - \bar{y})^2 = 21.40$$

De la Tabla 8-10

$$\text{variación explicada} = \sum (y_{\text{est}} - \bar{y})^2 = 21.02$$

$$\text{Por tanto} \quad r^2 = \frac{\text{variación explicada}}{\text{variación total}} = \frac{21.02}{21.40} = 0.9822 \quad \text{y} \quad r = 0.9911$$

- (c) El hecho de que la parte (a) muestra un coeficiente de correlación de solo -0.3743 indica prácticamente ninguna *relación lineal* entre x , y . Sin embargo, hay una muy buena *relación no lineal* dada por la parábola del Problema 8.16, como lo indica el hecho de que el coeficiente de correlación en (b) está muy cercano a 1.

$$(d) \quad \frac{\text{variación no explicada}}{\text{variación total}} = 1 - r^2 = 1 - 0.9822 = 0.0178$$

Por tanto 1.78% de la variación total permanece no explicada. Esto puede deberse a fluctuaciones aleatorias o a una variable adicional que no se ha considerado.

- 8.34. Hallar (a) s_y y (b) $s_{y,x}$ para los datos del Problema 8.16.

(a) Del Problema 8.33 (b), $\sum (y - \bar{y})^2 = 21.40$. Entonces la desviación típica de y es

$$s_y = \sqrt{\frac{\sum (y - \bar{y})^2}{n}} = \sqrt{\frac{21.40}{8}} = 1.636 \text{ ó } 1.64$$

(b) Primer método.

Utilizando (a) y el Problema 8.33 (b), el error típico de la estima de y sobre x es

$$s_{y,x} = s_y \sqrt{1 - r^2} = 1.636 \sqrt{1 - (0.9911)^2} = 0.218 \text{ ó } 0.22$$

Segundo método.

Utilizando el Problema 8.33,

$$s_{y,x} = \sqrt{\frac{\sum (y - y_{est})^2}{n}} = \sqrt{\frac{\text{variación no explicada}}{n}} = \sqrt{\frac{21.40 - 21.02}{8}} = 0.218 \text{ ó } 0.22$$

Tercer método.

Utilizando el Problema 8.16 y el cálculo adicional $\sum y^2 = 290.52$, tenemos

$$s_{y,x} = \sqrt{\frac{\sum y^2 - a\sum y - b\sum xy - c\sum x^2 y}{n}} = 0.218 \text{ ó } 0.22$$

8.35. Explicar cómo determinaría un coeficiente de correlación múltiple para las variables en el Problema 8.19.

Ya que z se determina de x , y estamos interesados en el *coeficiente de correlación múltiple de z sobre x , y* . Para obtenerlo, vemos del Problema 8.19 que

$$\begin{aligned}\text{Variación no explicada} &= \sum (z - z_{est})^2 \\ &= (64 - 64.414)^2 + \cdots + (68 - 65.920)^2 = 258.88\end{aligned}$$

$$\begin{aligned}\text{Variación total} &= \sum (z - \bar{z})^2 = \sum z^2 - n\bar{z}^2 \\ &= 48,139 - 12(62.75)^2 = 888.25\end{aligned}$$

$$\text{Variación explicada} = 888.25 - 258.88 = 629.37$$

Entonces

Coeficiente de correlación múltiple de z sobre x , y

$$= \sqrt{\frac{\text{variación explicada}}{\text{variación no explicada}}} = \sqrt{\frac{629.37}{888.25}} = 0.8418$$

Debe mencionarse que si fuéramos a considerar la regresión de x sobre y , z , el coeficiente de correlación de x sobre y , z sería en general diferente del valor anterior.

CORRELACION GRADUAL

8.36. Derivar la fórmula de correlación gradual de Spearman (36), página 264.

Aquí estamos considerando n valores de x (por ejemplo pesos) y n valores correspondientes de y (por ejemplo estaturas). Sea x_j el grado dado al j -ésimo valor de x , y_j el grado dado al j -ésimo valor de y . Los grados son enteros de 1 a n . La media de x_j es

$$\bar{x} = \frac{1 + 2 + \cdots + n}{n} = \frac{n(n+1)/2}{n} = \frac{n+1}{2}$$

mientras que la varianza es

$$\begin{aligned}s_x^2 &= \overline{x^2} - \bar{x}^2 = \frac{1^2 + 2^2 + \cdots + n^2}{n} - \left(\frac{n+1}{2}\right)^2 \\ &= \frac{n(n+1)(2n+1)/6}{2} - \left(\frac{n+1}{2}\right)^2 \\ &= \frac{n^2 - 1}{12}\end{aligned}$$

utilizando los resultados 1 y 2 del Apéndice A. Análogamente, la media $\bar{y}$ y la varianza s_y^2 son iguales a $(n+1)/2$ y $(n^2 - 1)/12$ respectivamente.

Entonces si $d_j = x_j - y_j$ son las desviaciones entre las graduaciones, la varianza de las desviaciones, s_d^2 , viene dada en términos de s_x^2 , s_y^2 y el coeficiente de correlación entre grados por

$$s_d^2 = s_x^2 + s_y^2 - 2r_{\text{grad}} s_x s_y$$

Entonces

$$(1) \quad r_{\text{grad}} = \frac{s_x^2 + s_y^2 - s_d^2}{2s_x s_y}$$

Puesto que $\bar{d} = 0$, $s_d^2 = (\sum d^2)/n$ y (1) se convierte en

$$(2) \quad r_{\text{grad}} = \frac{(n^2 - 1)/12 + (n^2 - 1)/12 - (\sum d^2)/n}{(n^2 - 1)/6} = 1 - \frac{6\sum d^2}{n(n^2 - 1)}$$

8.37. La Tabla 8-17 muestra cómo 10 estudiantes fueron clasificados según su rendimiento en el laboratorio y en teoría de un curso de biología. Hallar el coeficiente de correlación gradual.

Tabla 8-17

Laboratorio	8	3	9	2	7	10	4	6	1	5
Teoría	9	5	10	1	8	7	3	4	2	6

La diferencia de puntuaciones d en laboratorio y teoría para cada estudiante se da en la tabla siguiente. También se incluyen d^2 y $\sum d^2$.

Tabla 8-18

Diferencias de puntuaciones, d	-1	-2	-1	1	-1	3	1	2	-1	-1	
d^2	1	4	1	1	1	9	1	4	1	1	$\sum d^2 = 24$

Entonces

$$r_{\text{grad}} = 1 - \frac{6\sum d^2}{n(n^2 - 1)} = 1 - \frac{6(24)}{10(10^2 - 1)} = 0.8545$$

indicando que hay una relación entre el rendimiento en laboratorio y teoría.

8.38. Calcular el coeficiente de correlación gradual para los datos del Problema 8.11 y comparar los resultados con el coeficiente de correlación obtenido por otros métodos.

Ordenadas en forma ascendente de magnitud, las estaturas de los padres son

$$(1) \quad 62, 63, 64, 65, 66, 67, 67, 68, 68, 69, 70, 71$$

Puesto que en esta ordenación los lugares sexto y séptimo representan la misma estatura (67 pulgadas), les asignamos a estos dos lugares un *orden medio* de 6.5. Análogamente, a los lugares 8 y 9 se les asigna el orden 8.5. Así, a las estaturas de los padres se les asigna los órdenes

$$(2) \quad 1, 2, 3, 4, 5, 6.5, 6.5, 8.5, 8.5, 10, 11, 12$$

De igual forma, las estaturas de los hijos ordenadas en sentido creciente son

$$(3) \quad 65, 65, 66, 66, 67, 68, 68, 68, 68, 69, 70, 71$$

y puesto que los lugares 6, 7, 8 y 9 representan la misma estatura (68 pulgadas), les asignamos un *orden medio* de 7.5 $[(6 + 7 + 8 + 9)/4]$. Por tanto las estaturas de los hijos quedan ordenadas

$$(4) \quad 1.5, 1.5, 3.5, 3.5, 5, 7.5, 7.5, 7.5, 7.5, 10, 11, 12$$

Con las correspondencias (1) y (2), (3) y (4), la Tabla 8-3 se convierte en

Tabla 8-19

Graduación del padre	4	2	6.5	3	8.5	1	11	5	8.5	6.5	10	12
Graduación del hijo	7.5	3.5	7.5	1.5	10	3.5	7.5	1.5	12	5	7.5	11

La diferencia en graduaciones d , los cálculos de d^2 y Σd^2 se muestran en la Tabla 8-20. 20.

Tabla 8-20

d	-3.5	-1.5	-1.0	1.5	-1.5	-2.5	3.5	3.5	-3.5	1.5	2.5	1.0	
d^2	12.25	2.25	1.00	2.25	2.25	6.25	12.25	12.25	12.25	2.25	6.25	1.00	$\Sigma d^2 = 72.50$

Entonces
$$r_{\text{grad}} = 1 - \frac{6\Sigma d^2}{n(n^2-1)} = 1 - \frac{6(72.50)}{12(12^2-1)} = 0.7465$$

que concuerda muy bien con el valor $r = 0.7027$ obtenido en el Problema 8.26(b).

INTERPRETACION PROBABILISTICA DE REGRESION Y CORRELACION

8.39. Derivar (39) a partir de (37).

Suponga que la ecuación de regresión es

$$y = E(Y | X = x) = \alpha + \beta x$$

Para la recta de regresión de mínimos cuadrados debemos considerar

$$\begin{aligned} E\{[Y - (\alpha + \beta X)]^2\} &= E\{(Y - \mu_Y) - \beta(X - \mu_X) + (\mu_Y - \beta\mu_X - \alpha)\}^2 \\ &= E[(Y - \mu_Y)^2] + \beta^2 E[(X - \mu_X)^2] - 2\beta E[(X - \mu_X)(Y - \mu_Y)] + (\mu_Y - \beta\mu_X - \alpha)^2 \\ &= \sigma_Y^2 + \beta^2 \sigma_X^2 - 2\beta \sigma_{XY} + (\mu_Y - \beta\mu_X - \alpha)^2 \end{aligned}$$

donde hemos utilizado $E(X - \mu_X) = 0$, $E(Y - \mu_Y) = 0$.

Denotando la última expresión por $F(\alpha, \beta)$ tenemos

$$\frac{\partial F}{\partial \alpha} = -2(\mu_Y - \beta\mu_X - \alpha), \quad \frac{\partial F}{\partial \beta} = 2\beta\sigma_X^2 - 2\sigma_{XY} - 2\mu_X(\mu_Y - \beta\mu_X - \alpha)$$

Igualando estas ecuaciones a cero, lo cual es una condición necesaria para que $F(\alpha, \beta)$ sea un mínimo, hallamos

$$\mu_Y = \alpha + \beta\mu_X \quad \beta\sigma_X^2 = \sigma_{XY}$$

Por tanto si $y = \alpha + \beta x$ entonces $y - \mu_Y = \beta(x - \mu_X)$ ó

$$y - \mu_Y = \frac{\sigma_{XY}}{\sigma_X^2}(x - \mu_X)$$

ó

$$\frac{y - \mu_Y}{\sigma_Y} = \rho \left(\frac{x - \mu_X}{\sigma_X} \right)$$

Debe notarse la semejanza de la demostración anterior para poblaciones, utilizando esperanzas, con la correspondiente para muestras, utilizando sumas. En general, los resultados para muestras tienen resultados análogos para poblaciones e inversamente.

8.40. La función de densidad conjunta de las variables aleatorias X , Y es

$$f(x, y) = \begin{cases} \frac{2}{3}(x + 2y) & 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{de otra forma} \end{cases}$$

Hallar la curva de regresión de (a) Y sobre X , (b) X sobre Y .

(a) La función de densidad marginal de X es

$$f_1(x) = \int_0^1 \frac{2}{3}(x + 2y) dy = \frac{2}{3}(x + 1)$$

para $0 \leq x \leq 1$, y $f_1(x) = 0$ de otra forma. Por tanto, para $0 \leq x \leq 1$, la densidad condicional de Y dada X es

$$f_2(y|x) = \frac{f(x,y)}{f_1(x)} = \begin{cases} \frac{x+2y}{x+1} & 0 \leq y \leq 1 \\ 0 & y < 0 \text{ ó } y > 1 \end{cases}$$

y la curva de regresión de Y sobre X está dada por

$$\begin{aligned} y &= E(Y|X=x) = \int_{-\infty}^{\infty} y f_2(y|x) dy \\ &= \int_0^1 y \left(\frac{x+2y}{x+1} \right) dy = \frac{3x+4}{6x+6} \end{aligned}$$

Ni $f_2(y|x)$, ni la curva de regresión están definidas para $x < 0$ ó $x > 1$.

(b) Para $0 \leq y \leq 1$ la función de densidad marginal de Y es

$$f_2(y) = \int_0^1 \frac{2}{3} (x+2y) dx = \frac{1}{3} (1+4y)$$

Por tanto, para $0 \leq y \leq 1$, la densidad condicional de X dada Y es

$$f_1(x|y) = \frac{f(x,y)}{f_2(y)} = \begin{cases} \frac{2x+4y}{1+4y} & 0 \leq x \leq 1 \\ 0 & x < 0 \text{ ó } x > 1 \end{cases}$$

y la curva de regresión de X sobre Y viene dada por

$$\begin{aligned} x &= E(X|Y=y) = \int_{-\infty}^{\infty} x f_1(x|y) dx \\ &= \int_0^1 x \left(\frac{2x+4y}{1+4y} \right) dx = \frac{2+6y}{3+12y} \end{aligned}$$

Ni $f_1(x|y)$, ni la curva de regresión se definen para $y < 0$ ó $y > 1$.

Nótese que las dos curvas de regresión $y = (3x+4)/(6x+6)$, $x = (2+6y)/(3+12y)$ son diferentes.

8.41. Hallar (a) $\bar{X}$, (b) $\bar{Y}$, (c) σ_X^2 , (d) σ_Y^2 , (e) σ_{XY} , (f) ρ para la distribución del Problema 8.40.

$$(a) \quad \bar{X} = \int_{x=0}^1 \int_{y=0}^1 x \left[\frac{2}{3} (x+2y) \right] dx dy = \frac{5}{9}$$

$$(b) \quad \bar{Y} = \int_{x=0}^1 \int_{y=0}^1 y \left[\frac{2}{3} (x+2y) \right] dx dy = \frac{11}{18}$$

$$(c) \quad \overline{X^2} = \int_{x=0}^1 \int_{y=0}^1 x^2 \left[\frac{2}{3} (x+2y) \right] dx dy = \frac{7}{18}$$

Entonces $\sigma_X^2 = \overline{X^2} - \bar{X}^2 = \frac{7}{18} - \left(\frac{5}{9} \right)^2 = \frac{13}{162}$

$$(d) \quad \overline{Y^2} = \int_{x=0}^1 \int_{y=0}^1 y^2 \left[\frac{2}{3} (x+2y) \right] dx dy = \frac{4}{9}$$

Entonces $\sigma_Y^2 = \overline{Y^2} - \bar{Y}^2 = \frac{4}{9} - \left(\frac{11}{18} \right)^2 = \frac{23}{324}$

$$(e) \quad \overline{XY} = \int_{x=0}^1 \int_{y=0}^1 xy \left[\frac{2}{3}(x+2y) \right] dx dy = \frac{1}{3}$$

Entonces
$$\sigma_{XY} = \overline{XY} - \bar{X}\bar{Y} = \frac{1}{3} - \left(\frac{5}{9}\right)\left(\frac{11}{18}\right) = -\frac{1}{162}$$

$$(f) \quad \rho = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} = \frac{-1/162}{\sqrt{13/162} \sqrt{23/324}} = -0.0818$$

Nótese que el coeficiente de correlación lineal es pequeño. Esto es de esperarse al observar las rectas de regresión de mínimos cuadrados obtenidos en el Problema 8.42.

8.42. Escribir las rectas de regresión de mínimos cuadrados de (a) Y sobre X, (b) X sobre Y para el Problema 8.40.

(a) La recta de regresión de Y sobre X es
$$\frac{y - \bar{Y}}{\sigma_Y} = \rho \left(\frac{x - \bar{X}}{\sigma_X} \right) \quad \text{ó}$$

$$y - \bar{Y} = \frac{\sigma_{XY}}{\sigma_X^2} (x - \bar{X}) \quad \text{ó} \quad y - \frac{11}{18} = \frac{-1/162}{13/162} \left(x - \frac{5}{9} \right)$$

(b) La recta de regresión de X sobre Y es
$$\frac{x - \bar{X}}{\sigma_X} = \rho \left(\frac{y - \bar{Y}}{\sigma_Y} \right) \quad \text{ó}$$

$$x - \bar{X} = \frac{\sigma_{XY}}{\sigma_Y^2} (y - \bar{Y}) \quad \text{ó} \quad x - \frac{5}{9} = \frac{-1/162}{23/324} \left(y - \frac{11}{18} \right)$$

TEORIA MUESTRAL DE LA REGRESION N

8.43. En el Problema 8.11 se halló que la ecuación de regresión de y sobre x era $y = 35.82 + 0.476x$. Ensayar la hipótesis al nivel de significación del 0.05 de que el coeficiente de regresión de la ecuación de regresión poblacional es tan bajo como 0.180.

$$t = \frac{\beta - b}{s_{y,x}/s_x} \sqrt{n-2} = \frac{0.476 - 0.180}{1.28/2.66} \sqrt{12-2} = 1.95$$

ya que $s_{y,x} = 1.28$ (calculada en el Problema 8.22) y $s_x = \sqrt{x^2 - \bar{x}^2} = 2.66$ del Problema 8.11.

Con un ensayo unilateral de la distribución de Student a un nivel 0.05 rechazaríamos la hipótesis de que el coeficiente es tan bajo como 0.180 si $t > t_{.95} = 1.81$ para $12 - 2 = 10$ grados de libertad. Por tanto no podemos rechazar la hipótesis.

8.44. Hallar los límites de confianza del 95% para el coeficiente de regresión del Problema 8.43.

$$\beta = b + \frac{t}{\sqrt{n-2}} \left(\frac{s_{y,x}}{s_x} \right).$$
 Los límites de confianza del 95% para β (obtenidos al colocar $t = \pm t_{.975} = \pm 2.23$ para $12 - 2 = 10$ grados de libertad) vienen dados por

$$b \pm \frac{2.23}{\sqrt{12-2}} \left(\frac{s_{y,x}}{s_x} \right) = 0.476 \pm \frac{2.23}{\sqrt{10}} \left(\frac{1.28}{2.66} \right) = 0.476 \pm 0.340$$

es decir, se está en la confianza del 95% de que β se encuentra entre 0.136 y 0.816.

8.45. En el Problema 8.11, hallar los límites de confianza del 95% para las estaturas de los hijos cuyos padres tienen unas estaturas de (a) 65.0 y (b) 70.0 pulgadas.

Puesto que $t_{.975} = 2.23$ para $12 - 2 = 10$ grados de libertad, los límites de confianza del 95% para y_p son

$$y_0 \pm \frac{2.23}{\sqrt{n-2}} s_{y,x} \sqrt{1 + \frac{n(x_0 - \bar{x})^2}{s_x^2}}$$

donde $y_0 = 35.82 + 0.476 x_0$ (Problema 8.11), $s_{y,x} = 1.28$, $s_x = 2.66$ (Problema 8.43), y $n = 12$.

- (a) Si $x_0 = 65.0$, $y_0 = 66.76$ pulgadas. También, $(x_0 - \bar{x})^2 = (65 - 800/12)^2 = 2.78$. Entonces los límites de confianza del 95% son

$$66.76 \pm \frac{2.23}{\sqrt{10}} (1.28) \sqrt{12 + 1 + \frac{12(2.78)}{(2.66)^2}} = 66.76 \pm 3.80 \text{ pulgadas}$$

es decir, se puede estar en la confianza del 95% de que las estaturas de los hijos están entre 63.0 y 70.6 pulgadas

- (b) Si $x_0 = 70.0$, $y_0 = 69.14$ pulgadas. También $(x_0 - \bar{x})^2 = (70.0 - 800/12)^2 = 11.11$. Entonces los límites de confianza del 95% son 69.14 ± 5.09 pulgadas, es decir, se puede estar en la confianza del 95% de que las estaturas de los hijos están entre 64.1 y 74.2 pulgadas.

Nótese que para grandes valores de n , los límites de confianza del 95% están dados aproximadamente por $y_0 \pm 1.96 s_{y.x}$ ó $y_0 \pm 2s_{y.x}$ con tal que $x_0 - \bar{x}$ no sea demasiado grande. Esto concuerda con los resultados aproximados mencionados en la página 262. Los métodos de este problema son válidos independiente del tamaño de n ó $x_0 - \bar{x}$, es decir, los métodos muestrales son exactos para una población normal.

- 8.46. En el problema 8.11, hallar los límites de confianza del 95% para las estaturas medias de los hijos cuyas estaturas de los padres son (a) 65.0 y (b) 70.0 pulgadas.

Ya que $t_{.975} = 2.23$ para 10 grados de libertad, los límites de confianza del 95% para $\bar{y}_p$ son

$$y_0 \pm \frac{2.23}{\sqrt{10}} s_{y.x} \sqrt{1 + \frac{(x_0 - \bar{x})^2}{s_x^2}}$$

donde $y_0 = 35.82 + 0.476 x_0$ (Problema 8.11), $s_{y.x} = 2.66$ (Problema 8.43).

- (a) Si $x_0 = 65.0$, hallamos [comparar con el Problema 8.45(a)] los límites de confianza del 95%; 66.76 ± 1.07 pulgadas, es decir, se puede tener confianza de 95% que la estatura media de todos los hijos cuyas estaturas de los padres son 65.0 pulgadas se encontrarán entre 65.7 y 67.8 pulgadas.
- (b) Si $x_0 = 70.0$, hallamos [comparar con el Problema 8.45(b)] los límites de confianza del 95%; 69.14 ± 1.45 pulgadas, es decir, se puede estar en la confianza del 95% de que la estatura media de todos los hijos cuyas estaturas de los padres son 70.0 pulgadas se encontrarán entre 67.7 y 70.6 pulgadas.

TEORIA MUESTRAL DE LA CORRELACION

- 8.47. Un coeficiente de correlación basado en una muestra de tamaño 18 resultó ser 0.32. ¿Puede concluirse a un nivel de significación del (a) 0.05 y (b) 0.01 que el coeficiente de correlación poblacional es apreciablemente mayor que cero?

Deseamos decidir entre las hipótesis ($H_0: \rho = 0$) y ($H_1: \rho > 0$).

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{0.32\sqrt{18-2}}{\sqrt{1-(0.32)^2}} = 1.35$$

- (a) Sobre la base de un ensayo unilateral de la distribución de Student a un nivel 0.05, rechazaríamos H_0 si $t > t_{.95} = 1.75$ para $18 - 2 = 16$ grados de libertad. Por tanto no podemos rechazar H_0 al nivel 0.05.
- (b) Puesto que no podemos rechazar H_0 al nivel 0.05, ciertamente no podemos rechazarla al nivel 0.01

- 8.48. ¿Cuál es el tamaño mínimo de una muestra para que podamos concluir que un coeficiente de correlación de 0.32 sea considerablemente mayor que cero al nivel 0.05?

A un nivel 0.05 utilizando un ensayo unilateral de la distribución de Student, el valor mínimo de n debe ser tal que

$$\frac{0.32\sqrt{n-2}}{\sqrt{1-(0.32)^2}} = t_{.95} \quad \text{para } n - 2 \text{ grados de libertad}$$

Para un número infinito de grados de libertad, $t_{.95} = 1.64$ y por tanto $n = 25.6$.

Para $n = 26$, $\nu = 24$, $t_{.95} = 1.71$, $t = 0.32\sqrt{24/\sqrt{1-(0.32)^2}} = 1.65$.

Para $n = 27$, $\nu = 25$, $t_{.95} = 1.71$, $t = 0.32\sqrt{25/\sqrt{1-(0.32)^2}} = 1.69$.

Para $n = 28$, $\nu = 26$, $t_{.95} = 1.71$, $t = 0.32\sqrt{26/\sqrt{1-(0.32)^2}} = 1.72$.

Entonces el tamaño mínimo de la muestra es $n = 28$.

- 8.49. Un coeficiente de correlación basado en una muestra de tamaño 24 se calculó era $r = 0.75$. ¿Podemos rechazar la hipótesis de que el coeficiente de correlación poblacional sea tan pequeño como (a) $\rho = 0.60$, (b) $\rho = 0.50$, a un nivel de significación del 0.05?

$$(a) \quad Z = 1.1513 \log\left(\frac{1+0.75}{1-0.75}\right) = 0.9730, \quad \mu_Z = 1.1513 \log\left(\frac{1+0.60}{1-0.60}\right) = 0.6932,$$

$$\sigma_Z = \frac{1}{\sqrt{n-3}} = \frac{1}{\sqrt{21}} = 0.2182$$

La variable tipificada es

$$z = \frac{Z - \mu_Z}{\sigma_Z} = \frac{0.9730 - 0.6932}{0.2182} = 1.28$$

A un nivel de significación del 0.05 utilizando un ensayo unilateral de la distribución normal rechazaríamos la hipótesis solamente si z fuera mayor a 1.64. Por tanto no podemos rechazar la hipótesis de que el coeficiente de correlación sea tan pequeño como 0.60.

- (b) Si $\rho = 0.50$, $\mu_Z = 1.1513 \log 3 = 0.5493$ y $z = (0.9730 - 0.5493)/0.2182 = 1.94$. Por tanto podemos rechazar la hipótesis de que el coeficiente de correlación poblacional sea tan pequeño como $\rho = 0.50$ a un nivel de significación del 0.05.

- 8.50. El coeficiente de correlación entre las calificaciones finales de física y matemáticas para un grupo de 21 estudiantes se calculó era 0.80. Hallar los límites de confianza del 95% para este coeficiente.

Puesto que $r = 0.80$ y $n = 21$, los límites de confianza del 95% para μ_Z vienen dados por

$$Z \pm 1.96 \sigma_Z = 1.1513 \log\left(\frac{1+r}{1-r}\right) \pm 1.96 \left(\frac{1}{\sqrt{n-3}}\right) = 1.0986 \pm 0.4620$$

Entonces μ_Z tiene el intervalo de confianza del 95%; 0.5366 a 1.5606.

$$\text{Si } \mu_Z = 1.1513 \log\left(\frac{1+\rho}{1-\rho}\right) = 0.5366, \quad \rho = 0.4904.$$

$$\text{Si } \mu_Z = 1.1513 \log\left(\frac{1+\rho}{1-\rho}\right) = 1.5606, \quad \rho = 0.9155.$$

Por tanto los límites de confianza del 95% para ρ son 0.49 y 0.92.

- 8.51. Dos coeficientes de correlación obtenidos de muestras de tamaños $n_1 = 28$ y $n_2 = 35$ se calcularon como $r_1 = 0.50$ y $r_2 = 0.30$ respectivamente. ¿Hay una diferencia considerable entre los dos coeficientes a un nivel de 0.05?

$$Z_1 = 1.1513 \log\left(\frac{1+r_1}{1-r_1}\right) = 0.5493, \quad Z_2 = 1.1513 \log\left(\frac{1+r_2}{1-r_2}\right) = 0.3095$$

y

$$\sigma_{Z_1-Z_2} = \sqrt{\frac{1}{n_1-3} + \frac{1}{n_2-3}} = 0.2669$$

Deseamos decidir entre las hipótesis ($H_0: \mu_{Z_1} = \mu_{Z_2}$) y ($H_1: \mu_{Z_1} \neq \mu_{Z_2}$).

Bajo la hipótesis H_0 ,

$$z = \frac{Z_1 - Z_2 - (\mu_{Z_1} - \mu_{Z_2})}{\sigma_{Z_1 - Z_2}} = \frac{0.5493 - 0.3095 - 0}{0.2669} = 0.8985$$

Utilizando un ensayo bilateral de la distribución normal, rechazaríamos H_0 solamente si $z > 1.96$ ó $z < -1.96$. Por tanto no podemos rechazar H_0 , y concluimos que los resultados no son considerablemente diferentes al nivel de 0.05.

PROBLEMAS DIVERSOS

8.52. Demostrar la fórmula (25), página 262.

Para la recta de mínimos cuadrados tenemos, de los Problemas 8.20 y 8.21,

$$s_{y.x}^2 = \frac{\sum (y - \bar{y})^2}{n} - b \frac{\sum (x - \bar{x})(y - \bar{y})}{n}$$

Pero por definición,

$$\frac{\sum (y - \bar{y})^2}{n} = s_y^2 \quad \frac{\sum (x - \bar{x})(y - \bar{y})}{n} = s_{xy}$$

y, por (6) en la página 260,

$$b = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2} = \frac{s_{xy}}{s_x^2}$$

Por tanto

$$s_{y.x}^2 = s_y^2 - \frac{s_{xy}^2}{s_x^2} = s_y^2 \left[1 - \left(\frac{s_{xy}}{s_x s_y} \right)^2 \right] = s_y^2 (1 - r^2)$$

Una fórmula análoga es válida para la población (véase Problema 8.54).

8.53. Demostrar que $E[(Y - \hat{Y})^2] = E[(Y - Y_{\text{est}})^2] + E[(Y_{\text{est}} - \hat{Y})^2]$ para el caso de (a) una recta de mínimos cuadrados, (b) una parábola de mínimos cuadrados.

Tenemos

$$Y - \hat{Y} = (Y - Y_{\text{est}}) + (Y_{\text{est}} - \hat{Y})$$

Entonces

$$(Y - \hat{Y})^2 = (Y - Y_{\text{est}})^2 + (Y_{\text{est}} - \hat{Y})^2 + 2(Y - Y_{\text{est}})(Y_{\text{est}} - \hat{Y})$$

y así

$$E[(Y - \hat{Y})^2] = E[(Y - Y_{\text{est}})^2] + E[(Y_{\text{est}} - \hat{Y})^2] + 2E[(Y - Y_{\text{est}})(Y_{\text{est}} - \hat{Y})]$$

El resultado pedido se deduce si podemos demostrar que el último término es cero.

(a) Para regresión lineal, $Y_{\text{est}} = \alpha + \beta X$. Entonces

$$\begin{aligned} E[(Y - Y_{\text{est}})(Y_{\text{est}} - \hat{Y})] &= E[(Y - \alpha - \beta X)(\alpha + \beta X - \hat{Y})] \\ &= (\alpha - \bar{Y})E(Y - \alpha - \beta X) + \beta E(XY - \alpha X - \beta X^2) \\ &= 0 \end{aligned}$$

porque las ecuaciones normales

$$E(Y - \alpha - \beta X) = 0, \quad E(XY - \alpha X - \beta X^2) = 0$$

(comparar con el Problema 8.3).

(b) Para regresión parabólica, $Y_{\text{est}} = \alpha + \beta X + \gamma X^2$. Entonces

$$\begin{aligned} E[(Y - Y_{\text{est}})(Y_{\text{est}} - \hat{Y})] &= E[(Y - \alpha - \beta X - \gamma X^2)(\alpha + \beta X + \gamma X^2 - \hat{Y})] \\ &= (\alpha - \bar{Y})E(Y - \alpha - \beta X - \gamma X^2) + \beta E[X(Y - \alpha - \beta X - \gamma X^2)] \\ &\quad + \gamma E[X^2(Y - \alpha - \beta X - \gamma X^2)] \\ &= 0 \end{aligned}$$

debido a las ecuaciones normales

$$E(Y - \alpha - \beta X - \gamma X^2) = 0, \quad E[X(Y - \alpha - \beta X - \gamma X^2)] = 0, \quad E[X^2(Y - \alpha - \beta X - \gamma X^2)] = 0$$

Comparar las ecuaciones (19), página 261.

El resultado puede ampliarse a curvas de orden superior de mínimos cuadrados.

8.54. Demostrar que $\sigma_{Y.X}^2 = \sigma_Y^2(1 - \rho^2)$ para regresión de mínimos cuadrados.

Por definición del coeficiente de correlación generalizado ρ , junto con el Problema 8.53, tenemos para el caso lineal o parabólico

$$\rho^2 = \frac{E[(Y_{\text{est}} - \bar{Y})^2]}{E[(Y - \bar{Y})^2]} = 1 - \frac{E[(Y - Y_{\text{est}})^2]}{E[(Y - \bar{Y})^2]} = 1 - \frac{\sigma_{Y.X}^2}{\sigma_Y^2}$$

y el resultado se deduce inmediatamente.

También para órdenes superiores la relación sigue la curva de los mínimos cuadrados.

8.55. Demostrar que para el caso de regresión lineal el coeficiente de correlación definido por (45) se reduce al definido por (40).

El cuadrado del coeficiente de correlación, es decir, el *coeficiente de determinación*, dado por (45) en el caso de regresión lineal viene dado por

$$(1) \quad \rho^2 = \frac{E[(Y_{\text{est}} - \bar{Y})^2]}{E[(Y - \bar{Y})^2]} = \frac{E[(\alpha + \beta X - \bar{Y})^2]}{\sigma_Y^2}$$

Pero dado que $\bar{Y} = \alpha + \beta \bar{X}$,

$$(2) \quad \begin{aligned} E[(\alpha + \beta X - \bar{Y})^2] &= E[\beta^2(X - \bar{X})^2] = \beta^2 E[(X - \bar{X})^2] \\ &= \frac{\sigma_{XY}^2}{\sigma_X^4} \sigma_X^2 = \frac{\sigma_{XY}^2}{\sigma_X^2} \end{aligned}$$

Entonces (1) se convierte en

$$(3) \quad \rho^2 = \frac{\sigma_{XY}^2}{\sigma_X^2 \sigma_Y^2} \quad \text{ó} \quad \rho = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

que era lo que se pedía demostrar. (El signo correcto para ρ se incluye en σ_{XY}).

- 8.56.** Referirse a la Tabla 8.21. (a) Hallar una parábola de regresión de mínimos cuadrados que se ajuste a los datos. (b) Calcular los valores de regresión (comúnmente llamados *valores de tendencia*) para los años dados y compararlos con los valores reales. (c) Estimar la población en 1945. (d) Estimar la población en 1960 y compararla con el valor real, 179.3. (e) Estimar la población en 1840 y compararla con el valor real, 17.1.

Tabla 8-21

Año	1850	1860	1870	1880	1890	1900	1910	1920	1930	1940	1950
Población en EE. UU. (millones)	23.2	31.4	39.8	50.2	62.9	76.0	92.0	105.7	122.8	131.7	151.1

Fuente: Bureau of the Census

- (a) Denótese por las variables x , y el año y la población durante ese año respectivamente. La ecuación de la parábola de mínimos cuadrados que se ajusta a los datos es

$$(1) \quad y = a + bx + cx^2$$

donde a , b , c se hallan de las ecuaciones normales

$$\begin{aligned}
 \Sigma y &= an + b\Sigma x + c\Sigma x^2 \\
 \Sigma xy &= a\Sigma x + b\Sigma x^2 + c\Sigma x^3 \\
 \Sigma x^2y &= a\Sigma x^2 + b\Sigma x^3 + c\Sigma x^4
 \end{aligned}
 \tag{2}$$

Conviene localizar el origen de modo que el año central, 1900, corresponda con $x = 0$, y los años 1910, 1920, 1930, 1940, 1950 y 1890, 1880, 1870, 1860, 1850 correspondan con 1, 2, 3, 4, 5 y $-1, -2, -3, -4, -5$ respectivamente. Con esta selección Σx y Σx^3 son cero y las ecuaciones (2) se simplifican.

El trabajo a realizarse para el cálculo puede ordenarse como en la Tabla 8-22. Las ecuaciones normales (2) se convierten en

$$\begin{aligned}
 11a + 110c &= 886.8 \\
 110b &= 1429.8 \\
 110a + 1958c &= 9209.0
 \end{aligned}
 \tag{3}$$

De la segunda ecuación en (3), $b = 13.00$; de la primera y tercera ecuaciones, $a = 76.64$, $c = 0.3974$. Entonces la ecuación pedida es

$$y = 76.64 + 13.00x + 0.3974x^2 \tag{4}$$

donde el origen, $x = 0$, es 1.o. de julio de 1900 y la unidad de x es diez años.

Tabla 8-22

Año	x	y	x^2	x^3	x^4	xy	x^2y
1850	-5	23.2	25	-125	625	-116.0	580.0
1860	-4	31.4	16	-64	256	-125.6	502.4
1870	-3	39.8	9	-27	81	-119.4	358.2
1880	-2	50.2	4	-8	16	-100.4	200.8
1890	-1	62.9	1	-1	1	-62.9	62.9
1900	0	76.0	0	0	0	0	0
1910	1	92.0	1	1	1	92.0	92.0
1920	2	105.7	4	8	16	211.4	422.8
1930	3	122.8	9	27	81	368.4	1105.2
1940	4	131.7	16	64	256	526.8	2107.2
1950	5	151.1	25	125	625	755.5	3777.5
	$\Sigma x = 0$	$\Sigma y = 886.8$	$\Sigma x^2 = 110$	$\Sigma x^3 = 0$	$\Sigma x^4 = 1958$	$\Sigma xy = 1429.8$	$\Sigma x^2y = 9209.0$

- (b) Los valores de tendencia, obtenidos al sustituir $x = -5, -4, -3, -2, -1, 0, 1, 2, 3, 4, 5$ en (4) se muestran en la Tabla 8-23 junto con los valores reales. Se observa que el ajuste es bueno.

Tabla 8-23

Año	$x = -5$ 1850	$x = -4$ 1860	$x = -3$ 1870	$x = -2$ 1880	$x = -1$ 1890	$x = 0$ 1900	$x = 1$ 1910	$x = 2$ 1920	$x = 3$ 1930	$x = 4$ 1940	$x = 5$ 1950
Valor de tendencia	21.6	31.0	41.2	52.2	64.0	76.6	90.0	104.2	119.2	135.0	151.6
Valor real	23.2	31.4	39.8	50.2	62.9	76.0	92.0	105.7	122.8	131.7	151.1

- (c) 1945 corresponde a $x = 4.5$, para lo cual $y = 76.64 + 13.00(4.5) + 0.3974(4.5)^2 = 143.2$.
- (d) 1960 corresponde a $x = 6$, para lo cual $y = 76.64 + 13.00(6) + 0.3974(6)^2 = 168.9$. Esto no se ajusta mucho al valor real, 179.3.

- (e) 1840 corresponde a $x = -6$, para lo cual $y = 76.64 + 13.00(-6) + 0.3974(-6)^2 = 12.9$. Esto no se ajusta mucho al valor real 17.1.

Este ejemplo ilustra el hecho de que si se encuentra una relación satisfactoria para un intervalo de valores no implica necesariamente que lo sea para una prolongación del intervalo de valores.

- 8.57. Los precios promedios de acciones y obligaciones anotadas en el New York Stock Exchange durante los años 1950—1959 se dan en la Tabla 8-24. (a) Hallar el coeficiente de correlación, (b) interpretar los resultados.

Tabla 8-24

Año	1950	1951	1952	1953	1954	1955	1956	1957	1958	1959
Precio promedio de acciones (dólares)	35.22	39.87	41.85	43.23	40.06	53.29	54.14	49.12	40.71	55.15
Precio promedio de obligaciones (dólares)	102.43	100.93	97.43	97.81	98.32	100.07	97.08	91.59	94.85	94.65

Fuente: New York Stock Exchange

- (a) Denotando por x , y los precios promedio de acciones y obligaciones, el cálculo del coeficiente de correlación puede organizarse como en la Tabla 8-25. Nótese que el año se utiliza solamente para especificar los valores correspondientes de x , y .

Tabla 8-25

x	y	$x' = x - \bar{x}$	$y' = y - \bar{y}$	x'^2	$x'y'$	y'^2
35.22	102.43	-10.04	4.91	100.80	-49.30	24.11
39.87	100.93	-5.39	3.41	29.05	-18.38	11.63
41.85	97.43	-3.41	-0.09	11.63	0.31	0.01
43.23	97.81	-2.03	0.29	4.12	-0.59	0.08
40.06	98.32	-5.20	0.80	27.04	-4.16	0.64
53.29	100.07	8.03	2.55	64.48	20.48	6.50
54.14	97.08	8.88	-0.44	78.85	-3.91	0.19
49.12	91.59	3.86	-5.93	14.90	-22.89	35.16
40.71	94.85	-4.55	-2.67	20.70	12.15	7.13
55.15	94.65	9.89	-2.87	97.81	-28.38	8.24
$\Sigma x = 452.64$ $\bar{x} = 45.26$	$\Sigma y = 975.16$ $\bar{y} = 97.52$			$\Sigma x'^2 = 449.38$	$\Sigma x'y' = -94.67$	$\Sigma y'^2 = 93.69$

Entonces por la fórmula producto-momento,

$$r = \frac{\Sigma x'y'}{\sqrt{(\Sigma x'^2)(\Sigma y'^2)}} = \frac{-94.67}{\sqrt{(449.38)(93.69)}} = -0.4614$$

- (b) Se deduce que hay cierta correlación negativa entre los precios de acciones y obligaciones (es decir, una tendencia a disminuir los precios de las acciones cuando aumentan los de las obligaciones y viceversa), aunque esta relación no es muy marcada.

Otro método.

La Tabla 8-26 muestra las graduaciones de los precios promedios de acciones y obligaciones para los años 1950—1959 en orden de precios ascendentes. También se indican las diferencias en graduaciones d y Σd^2 .

Tabla 8-26

Año	1950	1951	1952	1953	1954	1955	1956	1957	1958	1959	
Precios de acciones en orden de grad.	1	2	5	6	3	8	9	7	4	10	
Precios de obligaciones en orden de grad.	10	9	5	6	7	8	4	1	3	2	
Diferencia de graduación d	-9	-7	0	0	-4	0	5	6	1	8	
d^2	81	49	0	0	16	0	25	36	1	64	$\Sigma d^2 = 272$

Entonces
$$r_{\text{grad}} = 1 - \frac{6\Sigma d^2}{n(n^2-1)} = 1 - \frac{6(272)}{10(10^2-1)} = -0.6485$$

Esto se compara favorablemente con el resultado del primer método.

- 8.58. La Tabla 8.27 muestra las distribuciones de frecuencia de las calificaciones finales de 100 estudiantes en matemáticas y física. Refiriéndose a esta tabla determinar (a) el número de estudiantes que obtuvieron calificaciones 70–79 en matemáticas y 80–89 en física, (b) el porcentaje de estudiantes con calificaciones de matemáticas inferiores a 70, (c) el número de estudiantes que obtuvieron una calificación de 70 o más en física y menos de 80 en matemáticas, (d) el porcentaje de estudiantes que aprobaron al menos una de las asignaturas suponiendo que 60 es la calificación mínima de aprobación.

Tabla 8-27

		CALIFICACIONES DE MATEMATICAS						TOTALES
		40–49	50–59	60–69	70–79	80–89	90–99	
CALIFICACIONES DE FISICA	90–99				2	4	4	10
	80–89			1	4	6	5	16
	70–79			5	10	8	1	24
	60–69	1	4	9	5	2		21
	50–59	3	6	6	2			17
	40–49	3	5	4				12
TOTALES		7	15	25	23	20	10	100

- (a) Bajando por la columna rotulada 70–79 (calificaciones de matemáticas) hasta la fila rotulada 80–89 (calificaciones de física). El resultado 4 da el número pedido de estudiantes.

- (b) Número total de estudiantes con calificaciones inferiores a 70

$$= (\text{No. con calif. 40–49}) + (\text{No. con calif. 50–59}) + (\text{No. con calif. 60–69})$$

$$= 7 + 15 + 25 = 47$$

Porcentaje de estudiantes con calificaciones menores a 70 = $47/100 = 47\%$.

- (c) El número pedido de estudiantes es el total de las entradas en la Tabla 8-28, que representa parte de la Tabla 8-27.

$$\text{Número de estudiantes pedidos} = 1 + 5 + 2 + 4 + 10 = 22.$$

Tabla 8-28

CALIFICACIONES DE FISICA	CALIFICACIONES DE MATEMATICAS	
	60-69	70-79
90-99		2
80-89	1	4
70-79	5	10

Tabla 8-29

CALIFICACIONES DE FISICA	CALIFICACIONES, DE MATEMATICAS	
	40-49	50-59
50-59	3	6
40-49	3	5

- (d) Con referencia a la Tabla 8-29, que está sacada de la Tabla 8-27, se observa que el número de estudiantes con calificaciones menores a 60 en matemáticas y física es $3 + 3 + 6 + 5 = 17$. Entonces el número de estudiantes con calificaciones de 60 o más en física o matemáticas o en ambas es $100 - 17 = 83$, y el porcentaje pedido es $83/100 = 83\%$.

La Tabla 8-27 algunas veces se llama *tabla de frecuencias de doble variación* o *distribución de frecuencias de doble variación*. Cada cuadrado de la tabla se llama *casilla* y corresponde a un par de clases o intervalo de clase. El número indicado en la casilla se llama *frecuencia de casilla*. Por ejemplo, en la parte (a) el número 4 es la frecuencia de la casilla correspondiente al par de intervalos de clase 70-79 en matemáticas y 80-89 en física.

Los totales indicados en la última fila y en la última columna se llaman *totales marginales* o *frecuencias marginales*. Corresponden respectivamente a las frecuencias de clase de las distribuciones de frecuencia de las calificaciones de matemáticas y física por separado.

8.59. Mostrar cómo modificar la fórmula del Problema 8.31 para el caso de datos agrupados como en la Tabla 8-27.

Para datos agrupados, podemos considerar los diferentes valores de las variables x, y coincidiendo con las marcas de clase, en tanto que f_x y f_y son las correspondientes frecuencias de clase o frecuencias marginales indicadas en la última fila y columna de la tabla de frecuencias de doble variación. Si se representa por f las diferentes frecuencias de casilla correspondientes a los pares de marcas de clase (x, y) , entonces podemos reemplazar la fórmula del Problema 8.31 por

$$(1) \quad r = \frac{n \sum fxy - (\sum f_x x)(\sum f_y y)}{\sqrt{[n \sum f_x x^2 - (\sum f_x x)^2][n \sum f_y y^2 - (\sum f_y y)^2]}}$$

Si hacemos $x = x_0 + c_x u_x$ y $y = y_0 + c_y u_y$, donde c_x, c_y son las amplitudes de los intervalos de clase (supuestos constantes) y x_0, y_0 son marcas de clase arbitrarias correspondientes a las variables, la fórmula anterior se convierte a

$$(2) \quad r = \frac{n \sum f u_x u_y - (\sum f_x u_x)(\sum f_y u_y)}{\sqrt{[n \sum f_x u_x^2 - (\sum f_x u_x)^2][n \sum f_y u_y^2 - (\sum f_y u_y)^2]}}$$

Este es el *método clave* utilizado en el Capítulo 5 como un método breve para calcular medias, desviaciones típicas y momentos superiores.

8.60. Hallar el coeficiente de correlación lineal de las calificaciones de matemáticas y física del Problema 8.58.

Utilizamos la fórmula (2) del Problema 8.59. El trabajo puede ordenarse como en la Tabla 8-30, que se llama *tabla de correlación*.

Tabla 8-30

		Calificaciones de matemáticas, x						f_y	$f_y u_y$	$f_y u_y^2$	Suma de los números esquinados en cada fila	
		x	44.5	54.5	64.5	74.5	84.5					94.5
Calificaciones de Física, y	y	u_x u_y	-2	-1	0	1	2	3				
	94.5	2				2	4	4	10	20	40	44
	84.5	1			1	4	6	5	16	16	16	31
	74.5	0			5	10	8	1	24	0	0	0
	64.5	-1	1	4	9	5	2		21	-21	21	-3
	54.5	-2	3	6	6	2			17	-34	68	20
	44.5	-3	3	5	4				12	-36	108	33
f_x			7	15	25	23	20	10	$\Sigma f_x = \Sigma f_y = n = 100$	$\Sigma f_y u_y = -55$	$\Sigma f_y u_y^2 = 253$	$\Sigma f u_x u_y = 125$
$f_x u_x$			-14	-15	0	23	40	30	$\Sigma f_x u_x = 64$	Verificación		
$f_x u_x^2$			28	15	0	23	80	90	$\Sigma f_x u_x^2 = 236$			
Suma de los números esquinados en cada columna			32	31	0	-1	24	39	$\Sigma f u_x u_y = 125$			

El número en la esquina de cada casilla representa el producto $f u_x u_y$, donde f es la frecuencia de casilla. La suma de esos números esquinados en cada fila se indica en la fila correspondiente en la última columna. La suma de esos números esquinados en cada columna se indica en la columna correspondiente en la última fila. Los totales finales de la última fila y columna son iguales y representan $\Sigma f u_x u_y$.

De la Tabla 8-30 tenemos

$$r = \frac{n \Sigma f u_x u_y - (\Sigma f_x u_x)(\Sigma f_y u_y)}{\sqrt{[n \Sigma f_x u_x^2 - (\Sigma f_x u_x)^2][n \Sigma f_y u_y^2 - (\Sigma f_y u_y)^2]}}$$

$$= \frac{(100)(125) - (64)(-55)}{\sqrt{[(100)(236) - (64)^2][(100)(253) - (-55)^2]}} = \frac{16,020}{\sqrt{(19,504)(22,275)}} = 0.7686$$

8.61. Utilizar la tabla de correlación del Problema 8.60 para calcular (a) s_x , (b) s_y , (c) s_{xy} y verificar la fórmula

$$(a) \quad s_x = c_x \sqrt{\frac{\Sigma f_x u_x^2}{n} - \left(\frac{\Sigma f_x u_x}{n}\right)^2} = 10 \sqrt{\frac{236}{100} - \left(\frac{64}{100}\right)^2} = 13.966$$

$$(b) \quad s_y = c_y \sqrt{\frac{\Sigma f_y u_y^2}{n} - \left(\frac{\Sigma f_y u_y}{n}\right)^2} = 10 \sqrt{\frac{253}{100} - \left(\frac{-55}{100}\right)^2} = 14.925$$

$$(c) \quad s_{xy} = c_x c_y \left[\frac{\Sigma f u_x u_y}{n} - \left(\frac{\Sigma f_x u_x}{n}\right) \left(\frac{\Sigma f_y u_y}{n}\right) \right] = (10)(10) \left[\frac{125}{100} - \left(\frac{64}{100}\right) \left(\frac{-55}{100}\right) \right] = 160.20$$

Por tanto las desviaciones típicas de las calificaciones de matemáticas y física son 14.0 y 14.9 respectivamente, en tanto que su covarianza es 160.2. Tenemos

$$\frac{s_{xy}}{s_x s_y} = \frac{160.20}{(13.966)(14.925)} = 0.7686$$

que concuerda con r hallado en el Problema 8.60.

8.62. Escribir las ecuaciones de las rectas de regresión de (a) y sobre x , (b) x sobre y para los datos del Problema 8.60.

De la Tabla 8-30 tenemos,

$$\bar{x} = x_0 + c_x \frac{\sum f_x u_x}{n} = 64.5 + \frac{(10)(64)}{100} = 70.9$$

$$\bar{y} = y_0 + c_y \frac{\sum f_y u_y}{n} = 74.5 + \frac{(10)(-55)}{100} = 69.0$$

De los resultados del Problema 8.61 $s_x = 13.966$, $s_y = 14.925$ y $r = 0.7686$.

Entonces utilizamos (16), página 261, para obtener las ecuaciones de las rectas de regresión

$$(a) \quad y - \bar{y} = \frac{r s_y}{s_x} (x - \bar{x}), \quad y - 69.0 = \frac{(0.7686)(14.925)}{13.966} (x - 70.9),$$

$$\text{ó} \quad y - 69.0 = 0.821(x - 70.9)$$

$$(b) \quad x - \bar{x} = \frac{r s_x}{s_y} (y - \bar{y}), \quad x - 70.0 = \frac{(0.7686)(13.966)}{14.925} (y - 69.0),$$

$$\text{ó} \quad x - 70.9 = 0.719(y - 69.0)$$

8.63. Calcular los errores típicos de la estima (a) $s_{y,x}$, (b) $s_{x,y}$ para los datos del Problema 8.60. Utilizar los resultados del Problema 8.61.

$$(a) \quad s_{y,x} = s_y \sqrt{1 - r^2} = 14.925 \sqrt{1 - (0.7686)^2} = 9.548$$

$$(b) \quad s_{x,y} = s_x \sqrt{1 - r^2} = 13.966 \sqrt{1 - (0.7686)^2} = 8.934$$

Problemas suplementarios

RECTA DE MINIMOS CUADRADOS

8.64. Ajustar una recta de mínimos cuadrados a los datos de la Tabla 8-31 utilizando a (a) x como la variable independiente, (b) y como la variable dependiente. Representar gráficamente los datos y las rectas de mínimos cuadrados utilizando el mismo conjunto de ejes coordenados.

Tabla 8-31

x	3	5	6	8	9	11
y	2	3	4	6	5	8

8.65. Para los datos del Problema 8.64, hallar (a) los valores de y cuando $x = 5$, $x = 12$. (b) el valor de x para $y = 7$.

8.66. (a) Utilizar el método a mano alzada para obtener la ecuación para una recta de ajuste de los datos del Problema 8.64. (b) Solucionar el Problema 8.65 utilizando el resultado de la parte (a).

- 8.67. La Tabla 8-32 muestra las calificaciones finales en álgebra y física obtenidas por diez estudiantes seleccionados aleatoriamente de un gran grupo de estudiantes. (a) Representar gráficamente los datos. (b) Hallar la recta de mínimos cuadrados que se ajuste a los datos, utilizando a x como la variable independiente. (c) Hallar la recta de mínimos cuadrados que se ajuste a los datos, utilizando a y como la variable independiente. (d) Si un estudiante obtiene una calificación de 75 en álgebra, ¿cuál es su puntuación esperada en física? (e) Si un estudiante obtiene una puntuación de 95 en física, ¿cuál es su puntuación esperada en álgebra?

Tabla 8-32

Álgebra (x)	75	80	93	65	87	71	98	68	84	77
Física (y)	82	78	86	72	91	80	95	72	89	74

- 8.68. Con referencia a la Tabla 8-33. (a) Construir un diagrama de dispersión. (b) Hallar la recta de regresión de mínimos cuadrados de y sobre x . (c) Hallar la recta de regresión de mínimos cuadrados de x sobre y . (d) Representar gráficamente las dos rectas de regresión de (b) y (c) sobre el diagrama de dispersión de (a).

Tabla 8-33

Calificación en el primer examen	6	5	8	8	7	6	10	4	9	7
Calificación en el segundo examen	8	7	7	10	5	8	10	6	8	6

CURVAS DE REGRESION DE MINIMOS CUADRADOS

- 8.69. Ajustar una parábola de mínimos cuadrados, $y = a + bx + cx^2$, a los datos de la Tabla 8-34.

Tabla 8-34

x	0	1	2	3	4	5	6
y	2.4	2.1	3.2	5.6	9.3	14.6	21.9

- 8.70. La Tabla 8-35 da las distancias de parada d (pies) de un automóvil que viaja a una velocidad v (millas por hora) en el instante que se observa el peligro. (a) Representar gráficamente d , v . (b) Ajustar una parábola de mínimos cuadrados de la forma $d = a + bv + cv^2$ a los datos. (c) Estimar d cuando $v = 45$ mi/h y 80 mi/h.

Tabla 8-35

Velocidad, v (mi/h)	20	30	40	50	60	70
Distancia de parada $d(p)$	54	90	138	206	292	396

- 8.71. El número y de bacterias por unidad de volumen presentes en un cultivo después de x horas viene dado en la Tabla 8-36. (a) Representar los datos en papel semi-logaritmo, con la escala logarítmica para y , la escala aritmética para x . (b) Ajustar una curva de mínimos cuadrados de la forma $y = ab^x$ a los datos y explicar por qué esta ecuación específica da buenos resultados. (c) Comparar los valores de y obtenidos de esta ecuación con los valores reales. (d) Estimar el valor de y cuando $x = 7$.

Tabla 8-36

Números de horas (x)	0	1	2	3	4	5	6
Número de bacterias por unidad de volumen (y)	32	47	65	92	132	190	275

- 8.72. En el Problema 8.71 mostrar cómo una gráfica en papel semilogarítmico puede utilizarse para obtener la ecuación pedida sin emplear el método de los mínimos cuadrados.
- 8.73. Escribir las ecuaciones normales para la curva cúbica de mínimos cuadrados dada por $y = a + bx + cx^2 + dx^3$.

REGRESION MULTIPLE

- 8.74. La Tabla 8-37 muestra los valores correspondientes de tres variables x , y , z . (a) Hallar la ecuación de regresión lineal de mínimos cuadrados de z sobre x , y . (b) Estimar z cuando $x = 10$, $y = 6$.

Tabla 8-37

x	3	5	6	8	12	14
y	16	10	7	4	3	2
z	90	72	54	42	30	12

- 8.75. Demostrar que la ecuación para regresión lineal de z sobre x , y puede escribirse como

$$z - \bar{z} = a(x - \bar{x}) + b(y - \bar{y})$$

y obtener expresiones para los coeficientes de regresión de mínimos cuadrados a , b .

- 8.76. Utilizar el resultado del Problema 8.75 para solucionar el Problema 8.74.

- 8.77. Obtener las ecuaciones normales para la regresión lineal de mínimos cuadrados de w sobre x , y , z . ¿Hay alguna interpretación geométrica para esto? Explicar.

- 8.78. Una superficie de regresión de z sobre x , y tiene la forma

$$z = A + Bx + Cy + Dx^2 + Exy + Fy^2$$

Obtener las ecuaciones normales para los coeficientes de regresión de mínimos cuadrados.

ERROR TIPICO DE LA ESTIMA Y COEFICIENTE DE CORRELACION LINEAL

- 8.79. Hallar (a) $s_{y,x}$, (b) $s_{x,y}$ para los datos en el Problema 8.68.

- 8.80. Calcular (a) la variación total en y , (b) la variación no explicada en y , (c) la variación explicada en y para los datos del Problema 8.68.

- 8.81. Utilizar los resultados del Problema 8.80 para hallar el coeficiente de correlación entre los dos conjuntos de calificaciones de los exámenes del Problema 8.68.

- 8.82. (a) Hallar el coeficiente de correlación entre los dos conjuntos de calificaciones de los exámenes del Problema 8.68 utilizando la fórmula producto-momento y comparar con el resultado del Problema 8.81. (b) Obtener el coeficiente de correlación directamente de las pendientes de las rectas de regresión del Problema 8.68(b) y (c).

- 8.83. Hallar la covarianza para los datos del Problema 8.68 (a) directamente, (b) utilizando la fórmula $s_{xy} = rs_x s_y$ y el resultado del Problema 8.81 u 8.82.

- 8.84. La Tabla 8.38 muestra las edades x y la presión sanguínea y de 12 mujeres. (a) Hallar el coeficiente de correlación entre x , y . (b) Determinar la recta de regresión de mínimos cuadrados de y sobre x . (c) Estimar la presión sanguínea de una mujer de 45 años.

Tabla 8-38

Edad (x)	56	42	72	36	63	47	55	49	38	42	68	60
Presión Sanguínea (y)	147	125	160	118	149	128	150	145	115	140	152	155

- 8.85. Hallar los coeficientes de correlación para los datos del (a) Problema 8.64, (b) Problema 8.67.

- 8.86. El coeficiente de correlación entre dos variables x , y es $r = 0.60$. Si $s_x = 1.50$, $s_y = 2.00$, $\bar{x} = 10$, $\bar{y} = 20$, hallar las ecuaciones de la recta de regresión de (a) y sobre x , (b) x sobre y .

- 8.87. Calcular (a) $s_{y,x}$, (b) $s_{x,y}$ para los datos del Problema 8.86.

- 8.88. Si $s_{y,x} = 3$ y $s_y = 5$, hallar r .

- 8.89. Si el coeficiente de correlación entre x , y es 0.50, ¿qué porcentaje de la variación total permanece no explicada por la ecuación de regresión?

- 8.90. (a) Calcular el coeficiente de correlación entre los valores correspondientes de x , y dados en la Tabla 8-39. (b) Multiplicar todos los valores de x por 2 y sumarle 6. Multiplicar todos los valores de y por 3 y restarle 15. Hallar el coeficiente de correlación entre los dos nuevos conjuntos de valores, explicar por qué se obtiene o no el mismo resultado que en la parte (a).

Tabla 8-39

x	2	4	5	6	8	11
y	18	12	10	8	7	5

COEFICIENTE DE CORRELACION GENERALIZADO

- 8.91. Hallar el coeficiente de correlación para las variables en el Problema 8.68 utilizando el resultado (35), página 264.
- 8.92. Hallar el error típico de la estima de z sobre x , y para los datos del Problema 8.74.
- 8.93. (a) Calcular el coeficiente de correlación múltiple para los datos del Problema 8.74. (b) ¿Qué porcentaje de la variación total es explicada por la superficie de regresión?
- 8.94. Demostrar el resultado (27), página 263, para el caso de una superficie de regresión lineal para z sobre x , y .

CORRELACION GRADUAL

- 8.95. Dos jueces en una competencia debían clasificar a 8 candidatos A, B, C, D, E, F, G, H de acuerdo con sus preferencias, los resultados se muestran en la Tabla 8-40. Hallar el coeficiente de correlación gradual y decidir sobre el acuerdo de los jueces en sus elecciones.

Tabla 8-40

Candidato	A	B	C	D	E	F	G	H
Primer Juez	5	2	8	1	4	6	3	7
Segundo Juez	4	5	7	3	2	8	1	6

- 8.96. Hallar el coeficiente de correlación gradual para los datos del (a) Problema 8.68 y (b) Problema 8.84.
- 8.97. (a) Hallar el coeficiente de correlación gradual para los datos del Problema 8.90. (b) De sus observaciones en (a), estudiar una posible desventaja del método de correlación gradual.
- 8.98. Mostrar cómo se puede diseñar un coeficiente de correlación múltiple.

INTERPRETACION PROBABILISTICA DE LA REGRESION Y LA CORRELACION

- 8.99. La función de densidad conjunta de las variables aleatorias X, Y viene dada por

$$f(x, y) = \begin{cases} 2x + 3y & 0 < x < 1, 0 < y < 2 \\ 0 & \text{de otra forma} \end{cases}$$

Hallar la curva de regresión de (a) Y sobre X , (b) X sobre Y .

- 8.100. Hallar la recta de regresión de mínimos cuadrados de (a) Y sobre X , (b) X sobre Y para el Problema 8.99.
- 8.101. Obtener el coeficiente de correlación lineal para el Problema 8.99.
- 8.102. Hallar la curva de regresión de (a) Y sobre X , (b) X sobre Y para los datos del Problema 2.8, página 52.
- 8.103. Hallar la recta de regresión de mínimos cuadrados de (a) Y sobre X , (b) X sobre Y para los datos del Problema 2.8, página 52.
- 8.104. Hallar el coeficiente de correlación lineal para las variables aleatorias del Problema 2.8, página 52.
- 8.105. Dar un ejemplo para demostrar cómo hallaría (a) el error típico de la estima, (b) las variaciones explicada y no explicada, (c) el coeficiente de correlación generalizado, en el caso de dos variables aleatorias X, Y con función de densidad conjunta (o función de probabilidad conjunta) $f(x, y)$.
- 8.106. ¿Ocurren algunas simplificaciones en las curvas de regresión de Y sobre X ó X sobre Y para el caso de variables aleatorias independientes? Explicar.

TEORIA MUESTRAL DE LA REGRESION

- 8.107. Sobre la base de una muestra de tamaño 27 se encontró que la ecuación de regresión de y sobre x era $y = 25.0 + 2.00x$. Si $s_{y,x} = 1.50$, $s_x = 3.00$ y $\bar{x} = 7.50$, hallar los límites de confianza del (a) 95%, (b) 99% para el coeficiente de regresión.
- 8.108. En el Problema 8.107 ensayar la hipótesis de que el coeficiente de regresión poblacional es (a) tan bajo como 1.70, (b) tan alto como 2.20, a un nivel de significación del 0.01.
- 8.109. En el Problema 8.107 hallar los límites de confianza del (a) 95%, (b) 99% para y cuando $x = 6.00$.
- 8.110. En el Problema 8.107 hallar los límites de confianza del (a) 95%, (b) 99% para la media de todos los valores de y correspondientes a $x = 6.00$.
- 8.111. Con referencia al Problema 8.84, hallar los límites de confianza del 95% para (a) el coeficiente de regresión de y sobre x , (b) la presión sanguínea de las mujeres de 45 años, (c) la media de las presiones sanguíneas de las mujeres de 45 años.

TEORIA MUESTRAL DE LA CORRELACION

- 8.112. Un coeficiente de correlación basado sobre una muestra de tamaño 27 se calculó como 0.40. ¿Podemos concluir a un nivel de significación del (a) 0.05, (b) 0.01, que el correspondiente coeficiente de correlación poblacional es considerablemente mayor que cero?
- 8.113. Un coeficiente de correlación basado sobre una muestra de tamaño 35 se calculó como 0.50. ¿Podemos rechazar la hipótesis de que el coeficiente de correlación poblacional es (a) tan pequeño como $\rho = 0.30$, (b) tan grande como $\rho = 0.70$, utilizando un nivel de significación del 0.05?
- 8.114. Hallar los límites de confianza del (a) 95%, (b) 99% para un coeficiente de correlación que se calculó como 0.60 de una muestra de tamaño 28.
- 8.115. Solucionar el Problema 8.114 si el tamaño de la muestra es 52.
- 8.116. Hallar los límites de confianza del 95% para el coeficiente de correlación calculado en el Problema 8.84.
- 8.117. Dos coeficientes de correlación obtenidos de muestras de tamaños 23 y 28 se calcularon como 0.80 y 0.95 respectivamente. ¿Podemos concluir a un nivel del (a) 0.05, (b) 0.01, que hay una diferencia significativa entre los dos coeficientes?

RESULTADOS DIVERSOS

- 8.118. Verificar los coeficientes (5), página 260, para la recta de mínimos cuadrados.
- 8.119. Demostrar que para el caso de regresión lineal el valor mínimo de $E\{[Y - (a + \beta X)]^2\}$ es

$$\sigma_{Y.X}^2 = \sigma_Y^2(1 - \rho^2)$$

- 8.120. Las rectas de regresión muestrales de mínimos cuadrados para un conjunto de datos involucrando X , Y vienen dadas por $2x - 5y = 3$, $5x - 8y = 2$. Hallar el coeficiente de correlación lineal.
- 8.121. Demostrar que el ángulo entre dos rectas de regresión muestrales de mínimos cuadrados viene dado por

$$\tan^{-1} \left[\frac{(1 - r^2)s_x s_y}{r(s_x^2 + s_y^2)} \right]$$

- 8.122. Demostrar que el coeficiente de correlación entre x , y puede expresarse como

$$r = \frac{\overline{xy} - \bar{x}\bar{y}}{\sqrt{(\overline{x^2} - \bar{x}^2)(\overline{y^2} - \bar{y}^2)}}$$

- 8.123. Demostrar que el coeficiente de correlación es independiente de la elección del origen de las variables o de las unidades en que se expresan. (Sugerencia: Suponga que $x' = x_0 + c_1x$, $y' = y_0 + c_2y$, donde x_0 , y_0 , c_1 , c_2 son constantes arbitrarias, demuestre que el coeficiente de correlación entre x' , y' es el mismo que el entre x , y).

8.124. Demostrar que para regresión lineal $\frac{s_{y,x}^2}{s_y^2} = \frac{s_{x,y}^2}{s_x^2}$. ¿Es el resultado válido para regresión no lineal?

8.125. Hallar el coeficiente de correlación entre las estaturas y pesos de 300 adultos dados en la tabla de frecuencias siguiente.

Tabla 8-41

ESTATURAS x (pulgadas)

	59-62	63-66	67-70	71-74	75-78
90-109	2	1			
110-129	7	8	4	2	
130-149	5	15	22	7	1
150-169	2	12	63	19	5
170-189		7	28	32	12
190-209		2	10	20	7
210-229			1	4	2

PESOS y (libras)

8.126. (a) Hallar la recta de regresión de mínimos cuadrados de y sobre x para los datos del Problema 8.125. (b) Estimar los pesos de dos hombres cuyas estaturas son 64 y 72 pulgadas respectivamente.

8.127. Hallar (a) $s_{y,x}$, (b) $s_{x,y}$ para los datos del Problema 8.125.

8.128. Hallar los límites de confianza del 95% para el coeficiente de correlación calculado en el Problema 8.125.

8.129. Hallar el coeficiente de correlación entre los índices de precios al consumidor y los índices de precios al por mayor para todos los artículos indicados en la Tabla 8-42. El período base es de 1947 - 1949 = 100.

Tabla 8-42

Año	1949	1950	1951	1952	1953	1954	1955	1956	1957	1958
Indice de precios al consumidor	101.8	102.8	111.0	113.5	114.4	114.8	114.5	116.2	120.2	123.5
Indice de precios al por mayor	99.2	103.1	114.8	111.6	110.1	110.3	110.7	114.3	117.6	119.2

Fuente: Bureau of Labor Statistics

8.130. Con referencia a la Tabla 8-43. (a) Representar gráficamente los datos. (b) Hallar la recta de mínimos cuadrados que se ajusta a los datos y construir su gráfica. (c) Calcular los valores de tendencia y compararlos con los valores reales. (d) Predecir el índice de precio para la asistencia médica durante 1958 y compararlo con el valor verdadero (144.4). (e) ¿En qué año podemos esperar que el índice de costos médicos doble el del 1947-1949, suponiendo que las tendencias presentes continúen?

Tabla 8-43

Año	1950	1951	1952	1953	1954	1955	1956	1957
Indice de precios al consumidor por asistencia médica (1947 - 1949 = 100)	106.0	111.1	117.2	121.3	125.2	128.0	132.6	138.0

Fuente: Bureau of Labor Statistics

- 8.131. Con referencia a la Tabla 8-44. (a) Representar gráficamente los datos. (b) Hallar la parábola de mínimos cuadrados que se ajuste a los datos. (c) Calcular los valores de tendencia y compararlos con los valores reales. (d) Explicar por qué la ecuación en (b) no es útil para propósitos de extrapolación.

Tabla 8-44

Año	1915	1920	1925	1930	1935	1940	1945	1950	1955
Natalidad por cada 1000 habitantes	25.0	23.7	21.3	18.9	16.9	17.9	19.5	23.6	24.6

Fuente: Department of Health, Education and Welfare

- 8.132. Sean X , Y variables aleatorias con función de densidad conjunta (o función de probabilidad) $f(x, y)$. Demostrar que si $g(x) = E(Y | X = x)$ entonces

$$E\{|Y - \phi(X)|^2\} = E\{|Y - g(X)|^2\} + E\{|g(X) - \phi(X)|^2\}$$

donde $\phi(x)$ es cualquier función de x para el cual estas esperanzas existen.

- 8.133. Estudiar la relación, si la hay, del Problema 8.132 para variaciones explicadas y no explicadas.

- 8.134. Demostrar el Teorema 8-1, página 265. (Sugerencia: Utilizar el Problema 8.132).

- 8.135. En el Teorema 8-1, ¿es $g(x)$ única? Explicar.

- 8.136. Demostrar el Teorema 8-2, página 265.

Capítulo 9

Análisis de varianza

PROPOSITO DEL ANALISIS DE VARIANZA

En el Capítulo 7 utilizamos la teoría de muestreo para ensayar la significación de diferencias entre dos medias muestrales. Supusimos que las dos poblaciones, de las cuales se extrajeron las muestras, tenían la misma varianza. En muchas situaciones existe la necesidad de ensayar la significación de diferencias entre tres o más medias muestrales, o lo que es equivalente a ensayar la hipótesis nula de que las medias muestrales son iguales.

EJEMPLO 9.1. Supóngase que en un experimento agrícola cuatro tratamientos químicos diferentes del suelo producen rendimientos medios de trigo de 28, 22, 18 y 24 hl/ha respectivamente. ¿Hay una diferencia apreciable en estas medias o la dispersión observada simplemente se debe al azar?

Problemas como estos pueden resolverse utilizando una técnica importante conocida como *análisis de varianza*, desarrollada por Fisher. Utiliza la distribución F considerada anteriormente en los capítulos previos.

CLASIFICACION SIMPLE O EXPERIMENTOS DE UN FACTOR

En un *experimento de un factor* se obtienen medidas u observaciones para a grupos independientes de muestras, donde el número de medidas en cada grupo es b . Hablamos de a *tratamientos*, cada uno de los cuales tiene b *repeticiones* o *réplicas*. En el Ejemplo 9.1, $a = 4$.

Los resultados de un experimento de un factor pueden representarse en una tabla con a filas y b columnas (Tabla 9-1). Aquí x_{jk} denota la medida en la fila j y la columna k , donde $j = 1, 2, \dots, a$; $k = 1, 2, \dots, b$. Por ejemplo, x_{35} se refiere a la quinta medida para el tercer tratamiento.

Tabla 9-1

Tratamiento 1	x_{11}	x_{12}	$\dots$	x_{1b}	$\bar{x}_1$
Tratamiento 2	x_{21}	x_{22}	$\dots$	x_{2b}	$\bar{x}_2$
$\vdots$			$\vdots$		
Tratamiento a	x_{a1}	x_{a2}	$\dots$	x_{ab}	$\bar{x}_a$

Denotaremos por $\bar{x}_j$ la media de las medidas en la fila j . Tenemos

$$\bar{x}_j = \frac{1}{b} \sum_{k=1}^b x_{jk} \quad j = 1, 2, \dots, a \quad (1)$$

El punto en $\bar{x}_j$ se utiliza para indicar que el índice k se ha sumado. Los valores $\bar{x}_j$ se denominan *medias de grupo*, *medias de tratamiento* o *medias de fila*. La *gran media* o *media total* es la media de todas las medidas en todos los grupos y se denota por $\bar{x}$, esto es

$$\bar{x} = \frac{1}{ab} \sum_{j,k} x_{jk} = \frac{1}{ab} \sum_{j=1}^a \sum_{k=1}^b x_{jk} \quad (2)$$

VARIACION TOTAL. VARIACION DENTRO DE TRATAMIENTOS. VARIACION ENTRE TRATAMIENTOS

Definimos la *variación total*, denotada por v , como la suma de los cuadrados de las desviaciones de cada medida de la gran media $\bar{x}$, es decir

$$\text{Variación total} = v = \sum_{j,k} (x_{jk} - \bar{x})^2 \quad (3)$$

Al escribir la identidad

$$x_{jk} - \bar{x} = (x_{jk} - \bar{x}_j) + (\bar{x}_j - \bar{x}) \quad (4)$$

y luego elevando al cuadrado y sumando sobre j y k podemos demostrar (véase Problema 9.1) que

$$\sum_{j,k} (x_{jk} - \bar{x})^2 = \sum_{j,k} (x_{jk} - \bar{x}_j)^2 + \sum_{j,k} (\bar{x}_j - \bar{x})^2 \quad (5)$$

$$\text{ó} \quad \sum_{j,k} (x_{jk} - \bar{x})^2 = \sum_{j,k} (x_{jk} - \bar{x}_j)^2 + b \sum_j (\bar{x}_j - \bar{x})^2 \quad (6)$$

A la primera suma a la derecha de (5) o (6) las llamamos *variación dentro de tratamientos* (puesto que incluye los cuadrados de las desviaciones de x_{jk} con respecto a las medias de tratamiento $\bar{x}_j$) y la denotamos por v_w . Por tanto

$$v_w = \sum_{j,k} (x_{jk} - \bar{x}_j)^2 \quad (7)$$

La segunda suma a la derecha de (5) o (6) se llama la *variación entre tratamientos* (ya que involucra los cuadrados de las desviaciones de las diferentes medias de tratamiento $\bar{x}_j$ de la gran media $\bar{x}$) y se denota por v_b . Por tanto

$$v_b = \sum_{j,k} (\bar{x}_j - \bar{x})^2 = b \sum_j (\bar{x}_j - \bar{x})^2 \quad (8)$$

Así las ecuaciones (5) o (6) pueden escribirse como

$$v = v_w + v_b \quad (9)$$

MÉTODOS CORTOS PARA OBTENER VARIACIONES

Para minimizar el trabajo en calcular las variaciones anteriores son convenientes las formas siguientes:

$$v = \sum_{j,k} x_{jk}^2 - \frac{\tau^2}{ab} \quad (10)$$

$$v_b = \frac{1}{b} \sum_j \tau_j^2 - \frac{\tau^2}{ab} \quad (11)$$

$$v_w = v - v_b \quad (12)$$

donde τ es el total de todos los valores x_{jk} y τ_j es el total de todos los valores en el tratamiento j , esto es

$$\tau = \sum_{j,k} x_{jk} \quad \tau_j = \sum_k x_{jk} \quad (13)$$

En la práctica es conveniente restar algún valor fijo de todos los datos en la tabla; esto no tiene efecto en los resultados finales.

MODELO MATEMÁTICO LINEAL PARA ANÁLISIS DE VARIANZA

Podemos considerar que cada fila de la Tabla 9-1 representa una muestra aleatoria de tamaño b de la población para ese tratamiento particular. Así, para el tratamiento j tenemos las variables aleatorias $X_{j1}, X_{j2}, \dots, X_{jb}$ independientes y distribuidas idénticamente, las cuales toman los valores

$x_{j1}, x_{j2}, \dots, x_{jb}$ respectivamente. Cada una de las X_{jk} ($k = 1, 2, \dots, b$) puede expresarse como la suma de su valor esperado y un término de "error":

$$X_{jk} = \mu_j + \Delta_{jk} \quad (14)$$

Los Δ_{jk} pueden tomarse como variables aleatorias independientes (relativas a j y k), distribuidas normalmente con media cero y varianza σ^2 . Esto equivale a suponer que las X_{jk} ($j = 1, 2, \dots, a; k = 1, 2, \dots, b$) son variables normales, mutuamente independientes con medias μ_j y varianza común σ^2 .

Definamos la constante μ por

$$\mu = \frac{1}{a} \sum_j \mu_j$$

Podemos interpretar a μ como la media para una clase de gran población que comprende todas las poblaciones de tratamiento. Entonces (14) puede escribirse como (véase Problema 9.18).

$$X_{jk} = \mu + \alpha_j + \Delta_{jk} \quad \text{donde} \quad \sum_j \alpha_j = 0 \quad (15)$$

La constante α_j puede considerarse como el efecto especial del tratamiento j .

La hipótesis nula de que todas las medias de tratamiento son iguales viene dada por ($H_0: \alpha_j = 0; j = 1, 2, \dots, a$) o en forma equivalente por ($H_0: \mu_j = \mu; j = 1, 2, \dots, a$). Si H_0 es cierta, las poblaciones de tratamiento, que por suposición son normales, tienen una media común como también una varianza común. Por tanto solamente hay una población de tratamiento y todos los tratamientos son estadísticamente idénticos.

VALORES ESPERADOS DE LAS VARIACIONES

La variación entre tratamientos V_b , la variación dentro de tratamientos V_w y la variación total V son variables aleatorias que respectivamente toman los valores v_b, v_w y v de acuerdo con las definiciones (8), (7) y (3). Podemos demostrar que (véase Problema 9.19)

$$E(V_b) = (a-1)\sigma^2 + b \sum_j \alpha_j^2 \quad (16)$$

$$E(V_w) = a(b-1)\sigma^2 \quad (17)$$

$$E(V) = (ab-1)\sigma^2 + b \sum_j \alpha_j^2 \quad (18)$$

De (17) se deduce que

$$E\left[\frac{V_w}{a(b-1)}\right] = \sigma^2 \quad (19)$$

de modo que

$$\hat{S}_w^2 = \frac{V_w}{a(b-1)} \quad (20)$$

es siempre la mejor estima (insesgada) de σ^2 independiente de si H_0 es cierta o no. De otra parte, de (16) y (18) vemos que sólo si H_0 es cierta tendremos

$$E\left(\frac{V_b}{a-1}\right) = \sigma^2 \quad E\left(\frac{V}{ab-1}\right) = \sigma^2 \quad (21)$$

de modo que solamente en ese caso

$$\hat{S}_b^2 = \frac{V_b}{a-1} \quad \hat{S}^2 = \frac{V}{ab-1} \quad (22)$$

proveerá estimas insesgadas de σ^2 . Sin embargo, si H_0 no es cierta, entonces tenemos de (16)

$$E(\hat{S}_b^2) = \sigma^2 + \frac{b}{a-1} \sum_j \alpha_j^2 \quad (23)$$

DISTRIBUCIONES DE LAS VARIACIONES

Utilizando el Teorema 4-4, página 116, podemos demostrar los siguientes teoremas fundamentales relativos a las distribuciones de las variaciones V_w , V_b y V .

Teorema 9-1: V_w/σ^2 tiene la distribución chi-cuadrado con $a(b-1)$ grados de libertad.

Teorema 9-2: Bajo la hipótesis nula H_0 , V_b/σ^2 y V/σ^2 tienen la distribución chi-cuadrado con $a-1$ y $ab-1$ grados de libertad respectivamente.

Es importante recalcar que el Teorema 9-1 es válido si se supone o no H_0 , en tanto que el Teorema 9-2 sólo es válido si se supone H_0 .

ENSAYO F PARA LA HIPOTESIS NULA DE MEDIAS IGUALES

Si la hipótesis nula H_0 no es cierta, es decir, si las medias de tratamiento no son iguales, vemos de (23) que $\hat{S}_b^2$ puede ser mayor que σ^2 , siendo el efecto más pronunciado a medida que la discrepancia entre medias aumenta. Por otra parte, de (19) y (20) cabe esperarse que $\hat{S}_w^2$ sea igual a σ^2 independientemente de si las medias son iguales o no. Se deduce que un buen estadístico para ensayar la hipótesis H_0 viene dado por $\hat{S}_b^2/\hat{S}_w^2$. Si este estadístico es considerablemente grande podemos concluir que hay una diferencia significativa entre las medias de tratamiento y así rechazamos H_0 . De otra forma podemos o aceptar H_0 o reservarnos el juicio dependiendo de análisis posterior.

Para utilizar este estadístico debemos conocer su distribución. Esto viene dado en el teorema siguiente, el cual es una consecuencia del Teorema 5-8, página 161.

Teorema 9-3: El estadístico $F = \hat{S}_b^2/\hat{S}_w^2$ tiene la distribución F con $a-1$ y $a(b-1)$ grados de libertad.

El Teorema 9-3 nos permite ensayar la hipótesis nula a un nivel de significación determinado empleando un ensayo unilateral de la distribución F .

TABLAS DE ANÁLISIS DE VARIANZA

Los cálculos pedidos para el ensayo anterior se resumen en la Tabla 9-2, que se denomina *tabla de análisis de varianza*. En la práctica calcularíamos v y v_b empleando el método largo, (3) y (8), o el método corto, (10) y (11), y luego calcular $v_w = v - v_b$. Debe advertirse que los grados de libertad para la variación total, esto es, $ab-1$, es igual a la suma de los grados de libertad para las variaciones entre tratamientos y las variaciones dentro de tratamientos.

Tabla 9-2

Variación	Grados de libertad	Media de cuadrados	F
Entre tratamientos, $v_b = b \sum_j (\bar{x}_j - \bar{x})^2$	$a-1$	$\hat{s}_b^2 = \frac{v_b}{a-1}$	$\frac{\hat{s}_b^2}{\hat{s}_w^2}$ con $a-1, a(b-1)$ grados de libertad
Dentro de tratamientos, $v_w = v - v_b$	$a(b-1)$	$\hat{s}_w^2 = \frac{v_w}{a(b-1)}$	
Total, $v = v_b + v_w$ $= \sum_{j,k} (x_{jk} - \bar{x})^2$	$ab-1$		

MODIFICACIONES PARA NUMEROS DESIGUALES DE OBSERVACIONES

En el caso de que los tratamientos 1, . . . , a tengan números diferentes de observaciones iguales a $n_1, \dots, n_a$ respectivamente, los resultados anteriores se modifican fácilmente. Por tanto obtenemos

$$v = \sum_{j,k} (x_{jk} - \bar{x})^2 = \sum_{j,k} x_{jk}^2 - \frac{\tau^2}{n} \quad (24)$$

$$v_b = \sum_{j,k} (\bar{x}_j - \bar{x})^2 = \sum_j n_j (\bar{x}_j - \bar{x})^2 = \sum_j \frac{\tau_j^2}{n_j} - \frac{\tau^2}{n} \quad (25)$$

$$v_w = v - v_b \quad (26)$$

donde $\sum_{j,k}$ denota la suma sobre k desde 1 hasta n_j y luego sobre j desde 1 hasta a , $n = \sum_j n_j$ es el número total de observaciones en todos los tratamientos, τ es la suma de todas las observaciones, τ_j es la suma de todos los valores en el tratamiento j y $\sum_j$ es la suma desde $j = 1$ hasta a .

La tabla de análisis de varianza para este caso viene dada en la Tabla 9-3.

Tabla 9-3

Variación	Grados de libertad	Media de cuadrados	F
Entre tratamientos, $v_b = \sum_j n_j (\bar{x}_j - \bar{x})^2$	$a - 1$	$\hat{s}_b^2 = \frac{v_b}{a - 1}$	$\frac{\hat{s}_b^2}{\hat{s}_w^2}$ con $a - 1$, $n - a$ grados de libertad
Dentro de tratamientos, $v_w = v - v_b$	$n - a$	$\hat{s}_w^2 = \frac{v_w}{n - a}$	
Total, $v = v_b + v_w$ $= \sum_{j,k} (x_{jk} - \bar{x})^2$	$n - 1$		

CLASIFICACION DOBLE O EXPERIMENTOS DE DOS FACTORES

Las ideas de análisis de varianza para clasificación simple o experimentos de un factor pueden generalizarse. Ilustramos el procedimiento para *clasificación doble o experimentos de dos factores*.

EJEMPLO 9-2. Supóngase que un experimento agrícola consiste en examinar los rendimientos por acre de 4 variedades diferentes de trigo, donde cada variedad se cultiva en 5 parcelas diferentes. Luego se necesita un total de $(4)(5) = 20$ parcelas. Es conveniente en tal caso combinar las parcelas en *bloques*, por ejemplo 4 parcelas en un bloque, con una variedad diferente de trigo cultivado en cada parcela dentro de un bloque. Por tanto se necesitarán 5 bloques.

En este caso hay dos clasificaciones o factores, puesto que pueden existir diferencias en el rendimiento por acre debido a (i) el tipo particular de trigo cultivado o (ii) el bloque particular utilizado (que puede tener diferente fertilidad del suelo, etc.).

Por analogía con el experimento agrícola del Ejemplo 9.2 con frecuencia nos referimos a las dos clasificaciones o factores en un experimento como *tratamientos y bloques*, pero lógicamente podríamos simplemente referirnos a ellos como factor 1, factor 2, etc.