

Cuadro 4-13. Datos de lactantes con apnea durante el sueño¹

	Número de lactantes	Índice de mortalidad (%)
Todos los lactantes	76	13.2
Lactantes con episodios repetidos de apnea durante el sueño Que requieren estimulación vigorosa	12	25
Que requieren resucitación	13	30
Hermanos de víctimas de SMSI	8	25
Lactantes con convulsiones y episodios repetidos de apnea que requieren estimulación vigorosa y resucitación	7	57.1

¹ Reproducido, con permiso, de Cuadro 2 en Oren J, Kelly D y Shannon DC: Identification of a high-risk group for sudden infant death syndrome among infants who were resuscitated for sleep apnea. *Pediatrics* 1986;77:495. SMSI = síndrome de muerte infantil súbita.

8. Úsen las observaciones sobre porcentaje de sobresaturación de bilis en varones y mujeres del cuadro 3-7 (basado en el Planteamiento del problema 3 del capítulo 3) para determinar los percentiles 2.5 y 97.5; es decir, los "límites normales" de sobresaturación biliar.
9. Utilícese la figura 4-2 para contestar las preguntas siguientes:
 - a. ¿Cuál es el peso promedio en niñas de 24 meses de edad?
 - b. ¿Cuál es el percentil 90o en estatura para niñas de 12 meses de edad?
 - c. ¿Cuál es el 5o percentil en el peso de niñas de doce meses de edad?
 - d. ¿Qué conclusiones pueden extraerse acerca de una niña de 15 meses de edad cuya estatura es de 29 pulgadas con peso de 26 libras?
10. Encuéntrese el coeficiente de variación del cambio en la media del diámetro vascular.

Probabilidad, muestreo y distribuciones de probabilidad

PLANTEAMIENTO DE PROBLEMAS

Planteamiento del problema 1

El síndrome de inmunodeficiencia adquirida (SIDA) lo causa el virus de inmunodeficiencia humana (HIV). Estudios recientes sugieren que hasta 20% de personas con anticuerpos a HIV (seropositivos a HIV) en su suero desarrollarán SIDA en el transcurso de cinco años y los investigadores están interesados en saber si este porcentaje subestima el riesgo. Los efectos a largo plazo de la infección sobre el sistema inmunitario y la salud general de personas asintomáticas portadoras del virus no se conocen del todo.

Un artículo reciente en *Annals of Internal Medicine* informó de un estudio longitudinal de cinco años de duración con una cohorte de 250 homosexuales en un principio sanos para determinar antecedentes de la infección con HIV (Melbye y otros, 1986). A estos homosexuales los agruparon en cuatro: (seronegativos, seropositivos con menos de 19 meses de este resultado, seropositivos por 19 a 29 meses y seropositivos por un tiempo mayor de 29 meses) y los estudiaron respecto a las razones de subconjuntos de linfocitos T y de sus síntomas clínicos. Hubo una declinación sorprendente relacionada con el tiempo en la razón linfocitos T colaboradores/linfocitos T supresores (T4/T8). Se presentó inversión de la razón T4/T8 en 92% de sujetos positivos desde 29 meses o más atrás, pero sólo en 13% de aquéllos que se con-

servaron seronegativos. Se observó correlación elevada entre linfadenopatía y seropositividad entre personas seropositivas por corto y por largo tiempo. Diarrea, candidiasis oral y herpes zoster fueron comunes con seropositividad por más de 29 meses pero no en seropositividad por menos de 19 meses. En el cuadro 5-1 se muestran los resultados de un subgrupo de homosexuales estudiados durante 34 meses y clasificados en tres conjuntos (seronegativos, seropositivos por 29 meses o menos y seropositivos por más de 29 meses) y se usan aquí para ilustrar conceptos básicos de probabilidad y para demostrar la relación entre tiempo y razón T4/T8.

Planteamiento del problema 2

A un banco de sangre local se le pidió información acerca de la distribución de tipos sanguíneos en varones y mujeres. Esta información es útil para describir algunos principios básicos de teoría de la probabilidad. Los resultados se muestran en el cuadro 5-2.

Planteamiento del problema 3

El término *anemia aplásica* se refiere a una pancitopenia grave (anemia, neutropenia, trombocitopenia) causada por una médula ósea acelular o notablemente hipocelular. Se piensa que se debe a lesión de la célula tronco pluripotencial común básica para la formación de todas las poblaciones consecuentes de células precursoras. Aunque se han identificado varias causas

Cuadro 5-1. Cambios de subconjuntos de linfocitos T y seronegatividad o seropositividad en 550 homosexuales estudiados en forma longitudinal por 34 meses¹

Estado seronegativo o seropositivo	Número de homosexuales		
	Proporción T4/T8 baja	Proporción T4/T8 normal	Total
Seronegativos	4	27	31
Seropositivos ≤ 29 meses	5	2	7
Seropositivos > 29 meses	11	1	12
Total	20	30	50

¹ Adaptado y reproducido, con permiso, de Cuadro 1 en Maye M. et al: Long-term seropositivity for human T-lymphotropic virus type III in homosexual men without the acquired immunodeficiency syndrome: Development of immunologic and clinical abnormalities. A longitudinal study. *Ann Intern Med* 1986;104:495.

(medicamentos, tóxicas, infecciones), en más de la mitad de los casos en E.U.A., la causa se desconoce. Los pacientes con cuadro grave tienen un riesgo alto de morir por hemorragia o infecciones. El trasplante de médula ósea alógena es quizá el tratamiento de elección para pacientes menores de 40 años si se dispone de un donador compatible en antígeno leucocitario humano (HLA). Los datos experimentales sugieren que en estos pacientes, la transfusión de productos sanguíneos previa al trasplante de médula ósea puede sensibilizarlos, ocasionando el rechazo del injerto.

Los investigadores del *Fred Hutchinson Cancer Research Center* en Seattle, Washington, informaron los resultados de su estudio de trasplante de médula ósea en 50 pacientes con anemia aplásica grave que no habían recibido transfusión de productos sanguí-

neos sino justo antes del trasplante (Anasetti y otros, 1986). La probabilidad de diez años de supervivencia en este grupo de enfermos no transfundidos fue 82%; la tasa de supervivencia era de 43 a 50% para pacientes de estudios previos quienes habían recibido transfusiones múltiples. Los resultados de este trabajo se usan como ejemplo de la distribución binomial de probabilidad.

Planteamiento del problema 4

El "Coronary Artery Surgery Study" (CASS, 1983) fue una investigación prospectiva, aleatoria, multi-hospitalaria de terapéutica médica y quirúrgica en subconjuntos de pacientes con cardiopatía isquémica estable. En este grupo de pacientes, la supervivencia a los cinco años fue igual y adecuada en los grupos tratados con medicamentos y con cirugía (revascularización coronaria). Una segunda parte del estudio comparó los efectos de tratamiento médico y quirúrgico sobre la calidad de la vida.

Durante un periodo de cinco años, 780 pacientes con cardiopatía isquémica estable se subdividieron en tres subentidades clínicas. La asignación de pacientes fue al azar para tratamiento médico o quirúrgico. Todos los pacientes enrolados tenían una estenosis de 50% o mayor de la arteria coronaria principal izquierda o 70% o más de estenosis de los otros vasos operables. El Grupo A tenía angina leve y una fracción de expulsión de 50% por lo menos; el grupo B tenía angina leve y una fracción de expulsión menor de 50%; el Grupo C no tenía angina después de infarto del miocardio. Se tomó historia clínica y se hicieron examen físico y pruebas en banda sin fin a 6, 18 y 60 meses; además, a intervalos de seis meses se llenó un cuestionario de seguimiento. La calidad de vida se valoró por estado del dolor de pecho, insuficiencia cardíaca, limitación de actividades, empleo, recreación, terapéutica farmacológica, número de hospitalizaciones y alteración de factores de riesgo, como fumar, control de la presión sanguínea y colesterol. Los datos sobre el número de hospitalizaciones se usaron para ilustrar la distribución de probabilidad de Poisson.

Planteamiento del problema 5

La presión sanguínea de una persona tiene implicaciones importantes sobre su salud; la hipertensión está entre los problemas médicos crónicos tratados más comunes. ¿Cuáles factores influyen en la presión sanguínea y qué constituye un valor anormal? La *Society of Actuaries* (1980) presentó datos de un estudio de presiones sanguíneas sistólica y diastólica en varones y mujeres de 15 a 69 años. Los resultados se resumen abajo.

Presiones sanguíneas medias

Edades	Varones		Mujeres	
	Sistólica	Diastólica	Sistólica	Diastólica
16	115	70	112	69
19	119	71	114	70
24	122	73	115	71
29	122	75	116	72
39	123	76	118	74
49	125	78	123	76
59	128	79	128	79
69	132	79	134	80

Para varones y mujeres entre 20 y 39 años de edad, la presión sistólica media es alrededor de 120 mm Hg. Las desviaciones estándar eran cerca de 10 mm Hg para presión sistólica y de 8 para presión diastólica. ¿Cómo puede usarse esta información para calcular probabilidades de que los pacientes tengan presiones sanguíneas a distintos niveles?

5.1 PROPÓSITO DEL CAPÍTULO

Los dos capítulos anteriores presentaron métodos para resumir información de investigaciones: gráficas, diagramas y parámetros estadísticos para compendiar. Sin embargo, una razón importante para llevar a cabo investigación clínica es generalizar los hallazgos del conjunto de observaciones en un grupo de sujetos con otro semejante a él. Por ejemplo, en el Planteamiento del problema 3, los autores concluyeron que "pacientes con anemia aplásica grave sometidos a trasplante antes de sensibilización inducida por transfusiones, tienen una probabilidad excelente de supervivencia prolongada y de una vida normal". Esta conclusión se basó en su estudio y en el seguimiento longitudinal de 50 pacientes. Estudiar a todos los pacientes con anemia aplásica grave no es posible ni deseable; por tanto, los investigadores hicieron inferencias para una población mayor de pacientes con bases en su investigación de una muestra de enfermos. El uso del término probabilidad en su conclusión indica que no pueden asegurar que todos los pacientes con anemia aplásica grave responderán al tratamiento que recomiendan, pero de su experiencia con los 50 pacientes planean que las probabilidades son buenas. ¿Cómo pudieron llegar los investigadores a esta conclusión y qué métodos usaron para determinar que la probabilidad de supervivencia es excelente?

En este capítulo se describen conceptos para hacer enunciados acerca de la probabilidad de resultados posibles, como supervivencia prolongada. Primero, se define y estudia qué es probabilidad y se dan reglas elementales para calcularla. Luego se describen métodos para seleccionar una muestra de sujetos que se pueden incluir en un estudio. Por último, se introducen las distribuciones de probabilidad, junto con ejemplos de la forma en que se usan en medicina.

5.2 SIGNIFICADO DEL TÉRMINO PROBABILIDAD

Las personas usan con frecuencia el concepto y el término probabilidad, si bien gran parte de ellas no podrían definir su significado, a menos que sean investigadores científicos. Para el propósito de este texto, de modo que pueda usarse el concepto de probabilidad de una manera significativa para interpretar resultados de estudios médicos, bastará con la definición de frecuencia que proporciona un sentido intuitivo. Supóngase que un experimento puede repetirse numerosas veces, llamando a cada repetición (réplica) una prueba y que de cada prueba pueden obtenerse uno o más resultados. Luego, la probabilidad de un resultado dado es el número de veces que el resultado ocurre dividido entre el número total de pruebas. Si es seguro que el resultado ocurra, tiene una probabilidad de uno; si no es posible que el resultado ocurra, su probabilidad es cero.

Un cálculo de probabilidad puede determinarse en forma empírica o basarse en un modelo teórico. Para usar un ejemplo familiar, todos saben que la probabilidad de lanzar una moneda al aire y conseguir un "águila" es de 0.5 o 50 por ciento. Por supuesto, si la moneda se lanza al aire diez veces, no se garantiza que se observarían exactamente cinco "águilas"; la proporción de éstas puede variar de 0 a 1, aunque en la mayor parte de los casos cabe esperar que se aproxime más de 0.5 que a 0 o 1. Si la moneda se lanza 100 veces, la probabilidad de que la proporción se aproxime a 0.5 es aún mejor y con 1 000 lanzamientos, las probabilidades aumentan más. Conforme aumenta el número de lanzamientos la proporción de águilas se aproxima a 0.5; por tanto, la probabilidad de águila en un lanzamiento cualquiera es 0.5.

La definición anterior de probabilidad se designa en ocasiones como probabilidad objetiva, en oposición a la probabilidad subjetiva, que es una estimación que refleja la opinión, presentimiento o mejor conjetura de una persona acerca de si un resultado ocurrirá. Las probabilidades subjetivas son impor-

Cuadro 5-2. Distribución del tipo sanguíneo por sexo

Tipo sanguíneo	Probabilidades		
	Varones	Mujeres	Total
O	0.21	0.21	0.42
A	0.215	0.215	0.43
B	0.055	0.055	0.11
AB	0.02	0.02	0.04
Total	0.50	0.50	1.00

tantes en medicina debido a que forman la base de la opinión de un médico acerca de si el paciente tiene una enfermedad específica. En el capítulo 13 se estudiará la forma en que esta estimación, basada en información obtenida de la historia clínica y del examen físico, cambia de acuerdo al resultado de pruebas de laboratorio o de otros procedimientos de diagnóstico. Aunque algunas personas desprecian las estimaciones de probabilidad subjetiva debido a que no se apoyan en datos "rígidos", son necesarias en medicina debido a que a menudo representan la única información disponible y debe tomarse una decisión a pesar de lo incierto de la situación. Las probabilidades que se estudian en este capítulo son objetivas y se apoyan en la definición de frecuencia; las probabilidades subjetivas se describen en capítulos ulteriores.

5.3 DEFINICIONES Y REGLAS BÁSICAS DE PROBABILIDAD

Los conceptos de probabilidad son útiles para comprender e interpretar datos presentados en cuadros y gráficas de informes publicados; además, permiten hacer enunciados acerca de cuánta es la confianza que se tiene en estimaciones como medias, proporciones o riesgos relativos (explicados en el capítulo anterior). Entender que es probabilidad es esencial para descubrir el significado de los valores P dados en las publicaciones.

Aquí se usarán dos ejemplos para ilustrar algunas definiciones y reglas para determinar probabilidades: Planteamiento del problema 1 de seropositividad en homosexuales (cuadro 5-1) y la información dada en el cuadro 5-2 sobre sexo y tipo sanguíneo.

5.3.1 DEFINICIONES BÁSICAS EN PROBABILIDAD

En probabilidad, un experimento se define como cualquier proceso planeado de recolección de datos. Para el Planteamiento del problema 1, el experimento es el proceso de determinar estado de seronegatividad o seropositividad en un grupo de 50 homosexuales. Un experimento consiste de un número de pruebas (réplicas) independientes bajo las mismas condiciones; en este ejemplo, una prueba consiste en determinar el estado del suero en una persona. Cada prueba puede tener uno de tres resultados: seronegativo, seropositivo por 29 meses o menos o seropositivo por más de 29 meses.

La probabilidad de un resultado particular, sea resultado A , se simboliza $P(A)$. Por ejemplo, el cuadro 5-1, si el resultado A es "seronegativo", la probabilidad de que un homosexual en un estudio sea seronegativo es:

$$P(\text{seronegativo}) = 31/50 = 0.62$$

En el Planteamiento del problema 2, las probabilidades de resultados diferentes ya se calcularon. Los resultados de cada prueba para determinar tipo sanguíneo son O, A, B y AB. Del cuadro 5-2, la probabilidad de que una persona tenga tipo sanguíneo A es:

$$P(\text{tipo A}) = 0.43$$

Los datos de tipo sanguíneo ilustran dos características importantes de lo que se esté estudiando:

1. La probabilidad de cada resultado (tipo sanguíneo) es mayor o igual a 0.
2. La suma de las probabilidades de los diversos resultados es 1.

Los eventos pueden definirse como resultados sencillos o como conjuntos de resultados. Por ejemplo, los resultados del estado del suero son seronegativo, seropositivo por 29 meses o menos y seropositivo por más de 29 meses; pero deseamos definir un evento como homosexual seronegativo o seropositivo. El evento "seropositivo" comprende dos resultados: ≤ 29 meses y > 29 meses.

En ocasiones, se desea conocer la probabilidad de que un evento no ocurra; un evento opuesto al que interesa se designa como un evento complementario. Por ejemplo, evento complementario a "seronegativo" es "no ser seronegativo". La probabilidad del complemento es:

$$\begin{aligned} P(\text{Complemento de seronegativo}) &= P(\text{no ser seronegativo}) \\ &= P(\text{seropositivo}) \\ &= \frac{7 + 12}{50} = \frac{19}{50} = .38 \end{aligned}$$

Observe que la probabilidad de un evento complementario también puede encontrarse restando de 1 la probabilidad del evento que interesa y en algunas situaciones su cálculo puede ser más sencillo. Así, se obtiene:

$$\begin{aligned} P(\text{complemento de seronegativo}) &= 1 - P(\text{seronegativo}) \\ &= 1 - \frac{31}{50} = 1 - .62 = .38 \end{aligned}$$

5.3.2 EVENTOS MUTUAMENTE EXCLUYENTES Y REGLAS DE ADICIÓN

Dos eventos o más eventos se excluyen de manera mutua si la ocurrencia de un evento impide la de los demás. Por definición, los resultados son mutuamente excluyentes; es decir, un homosexual en el Planteamiento del problema 1 no puede ser a la vez seropositivo ≤ 29 meses y seropositivo > 29 meses. Además, todos los eventos complementarios se excluyen también en forma mutua; sin embargo, los eventos pueden ser mutuamente excluyentes sin ser complementarios si hay tres o más eventos posibles.

Como se indicó antes, qué constituye un evento es tema de definición. Ahora, se definirá de nuevo el experimento en Planteamiento del problema 2 de modo que cada resultado (tipo sanguíneo O, A, B o AB) sea un evento separado. La probabilidad de que ocurran eventos mutuamente excluyentes es la probabilidad de que ocurra uno u otro evento. Esta probabilidad se encuentra sumando las probabilidades de los dos eventos, lo cual se conoce como regla de adición para probabilidades. Por ejemplo, la probabilidad de tener tipo sanguíneo O o tipo sanguíneo A es:

$$\begin{aligned} P(O \text{ o } A) &= P(O) + P(A) \\ &= .42 + .43 \\ &= .85 \end{aligned}$$

¿Funciona la regla de adición para más de dos eventos? La respuesta es sí, siempre que sean mutuamente excluyentes. En la sección 5.3.5 se estudiará este enfoque para eventos que no se excluyen en forma mutua.

5.3.3 EVENTOS INDEPENDIENTES Y LA REGLA DE MULTIPLICACIÓN

Dos eventos distintos son eventos independientes si el resultado de uno no tiene efecto en el del otro. Usando el ejemplo del tipo sanguíneo, se definirá también un segundo evento, como el sexo de la persona que consiste de los dos resultados "varón" y "mujer". En este caso, sexo y tipo sanguíneo son dos eventos independientes; el sexo de una persona no afecta en modo alguno a su tipo sanguíneo y viceversa. La probabilidad de dos eventos independientes es la de que ambos se presenten y se encuentra multiplicando las probabilidades de los dos eventos, lo cual se conoce como regla de multiplicación para probabilidades. Por ejemplo, la probabilidad de ser varón y tener tipo sanguíneo O es:

$$\begin{aligned} P(\text{varón y tipo sanguíneo O}) &= P(\text{varón}) \times P(\text{tipo sanguíneo O}) \\ &= .50 \times .42 = .21 \end{aligned}$$

La probabilidad de ser varón, 0.50 y la probabilidad de tener tipo O, 0.42, se designan probabilidades marginales; es decir, se presentan en los "bordes" de una tabla de probabilidad. La probabilidad de ser varón y tener tipo sanguíneo O, 0.21, se llaman probabilidad de unión o unida; es la probabilidad de que "varón" y "tipo sanguíneo O" ocurran en forma conjunta.

¿Tener una razón T4/T8 es independiente del estado sérico en los sujetos del Planteamiento del problema 1? El cuadro 5-1 muestra que estos dos eventos no son independientes; es decir, pacientes seronegativos tienden a tener una razón T4/T8 menor. Si los dos eventos fueron independientes, el producto de las probabilidades marginales sería igual a la probabilidad unida en todos los casos. Para demostrar que dos eventos no son independientes, necesita mostrarse un solo caso en que el producto de las probabilidades marginales no es igual a la probabilidad unida. Por ejemplo, para demostrar que estado del suero y razón T4/T8 no son independientes, considérese la probabilidad unida de tener T4/T8 bajo y ser seropositivo. En el cuadro 5-1 se observa que:

$$P(\text{T4/T8 baja y seropositivo}) = \frac{5 + 11}{50} = .32$$

Sin embargo, el producto de las probabilidades marginales no produce el mismo resultado; es decir:

$$P(\text{T4/T8 baja}) \times P(\text{seropositivo}) = \frac{20}{50} \times \frac{7 + 12}{50} = .152$$

Puede demostrarse que el producto de las probabilidades marginales no es igual a la probabilidad unida para cualquiera de las combinaciones de este ejemplo, pero requiere solo un caso para comprobar que dos eventos no son independientes.

5.3.4 EVENTOS NO INDEPENDIENTES O CONDICIONALES Y MODIFICACIÓN DE LA REGLA DE MULTIPLICAR

Hallar la probabilidad unida de dos eventos cuando no son independientes es un poco más complejo que la simple multiplicación de dos probabilidades marginales. Cuando dos eventos no son independientes, la ocurrencia de un evento depende de si el otro ha ocurrido. Sea A el evento "razón T4/T8 baja" y B el evento "seropositivo". Se desea conocer la probabilidad del evento A dado el evento B , que se escribe $P(A|B)$, donde la línea vertical, se lee "dado". De los datos del cuadro 5-1, la probabilidad de

una razón T4/T8 baja, dado que el paciente es seropositivo, es:

$$P(T4/T8 \text{ baja} \mid \text{seropositivo}) = \frac{5 + 11}{7 + 12} = .842$$

Esta probabilidad que se designa probabilidad condicional es la de un evento, dado que se ha presentado otro evento. Puesto de otra manera, probabilidad de una razón T4/T8 baja es condicional en el evento de seropositividad; ahora puede sustituir a $P(T4/T8 \text{ baja})$ en la regla de multiplicación. Si se reúnen las expresiones, es posible encontrar la probabilidad unidad de tener una razón T4/T8 baja y ser seropositivo:

$$\begin{aligned} P(T4/T8 \text{ baja y seropositivo}) &= \\ &= P(T4/T8 \text{ baja} \mid \text{seropositivo}) \times P(\text{seropositivo}) \\ &= \frac{16}{19} \times \frac{19}{50} \\ &= .842 \times .38 = .32 \end{aligned}$$

La probabilidad de tener una razón T4/T8 baja y ser positivo puede determinarse también hallando la probabilidad condicional de ser seropositivo, dada una razón T4/T8 baja y sustituyendo esa expresión en la regla de multiplicación para $P(\text{seropositivo})$. Por consiguiente, se obtiene:

$$\begin{aligned} P(T4/T8 \text{ baja y seropositivo}) &= \\ &= P(\text{seropositivo} \mid \text{T4/T8 baja}) \times P(T4/T8) \\ &= \frac{16}{20} \times \frac{20}{50} \\ &= .80 \times .40 = .32 \end{aligned}$$

5.3.5 EVENTOS QUE NO SE EXCLUYEN EN FORMA MUTUA Y REGLA DE ADICIÓN MODIFICADA

Recuérdese que dos o más eventos mutuamente excluyentes no pueden ocurrir al mismo tiempo y la regla de adición se aplica para calcular la probabilidad de que ocurra uno u otro de los eventos. Ahora, se analizará la situación para hallar la probabilidad de que ocurra uno u otro evento cuando no son mutuamente excluyentes. Por ejemplo, sexo y grupo sanguíneo O no son eventos mutuamente excluyentes debido a que la ocurrencia de uno no impide la del otro. La regla de adición debe modificarse en esta situación; de otro modo, la probabilidad de que los dos eventos ocurran se agregará dos veces en el cálculo.

En el cuadro 5-2, la probabilidad de ser varón es 0.5 y la probabilidad de tipo sanguíneo O es 0.42. Sin

embargo, la probabilidad de ser varón o tener tipo sanguíneo O no es $0.50 + 0.42$, debido a que en esta suma, los varones con tipo sanguíneo O se han contado dos veces. Por tanto, debe sustraerse la probabilidad de ser varón y tener tipo sanguíneo O, 0.21. El cálculo es:

$$\begin{aligned} P(\text{varón o tipo O}) &= \\ &= P(\text{varón}) + P(\text{tipo O}) - P(\text{varón y tipo O}) \\ &= .50 + .42 - .21 \\ &= .71 \end{aligned}$$

Por supuesto, si no se sabe que $P(\text{varón y tipo O}) = 0.21$, debe usarse la regla de la multiplicación (en este caso, para eventos independientes) para determinar esta probabilidad.

5.3.6 RESUMEN DE REGLAS Y UNA EXTENSIÓN

En esta sección, se hace un resumen de las reglas presentadas hasta ahora y se describe una extensión de éstas. Recuérdese que cuestiones acerca de exclusión mutua usan la palabra *o* y la regla de adición; las de independencia usan la palabra *y* y la regla de multiplicar. Para el resumen, se usarán letras para representar eventos; es decir, A , B , C y D son cuatro eventos diferentes con probabilidad $P(A)$, $P(B)$, $P(C)$ y $P(D)$.

5.3.6.a Regla de adición

La regla de adición para la ocurrencia de dos o más eventos es la siguiente: Si A , B y C son mutuamente excluyentes, luego

$$P(A \text{ o } B \text{ o } C) = P(A) + P(B) + P(C)$$

Si dos eventos como A y D no son mutuamente excluyentes, luego

$$P(A \text{ o } D) = P(A) + P(D) - P(A \text{ y } D)^*$$

5.3.6.b Regla de multiplicación

La regla de multiplicación para la ocurrencia simultánea de dos o más eventos es la siguiente: Si A , B y C son independientes, luego

* La probabilidad de tres o más eventos que no son mutuamente excluyentes o no son independientes requiere cálculos complejos que están más allá del campo de este libro. Los lectores interesados pueden consultar libros elementales sobre probabilidad, como Miller y Freund (1985).

$$P(A \text{ y } B \text{ y } C) = P(A) \times P(B) \times P(C)$$

Si dos eventos, como B y D no son independientes, luego

$$P(B \text{ y } D) = P(B \mid D) \times P(D)$$

$$P(B \text{ y } D) = P(B) \times P(D \mid B)^*$$

5.3.6.c Una extensión-Teorema de Bayes

La regla de multiplicación para probabilidades cuando los eventos no son independientes puede usarse para derivar una forma de una importante fórmula llamada *teorema de Bayes*. Debido a que $P(B \text{ y } D)$ es igual a $P(B \mid D) \times P(D)$ y a $P(B) \times P(D \mid B)$, estas dos últimas expresiones son iguales entre sí. Suponiendo que $P(B)$ y $P(D)$ no son iguales a cero, puede resolverse una en términos de la otra. Por consiguiente, si

$$P(B \mid D) \times P(D) = P(B) \times P(D \mid B)$$

luego

$$P(B \mid D) = \frac{P(D \mid B) \times P(B)}{P(D)}$$

que se encuentra dividiendo los dos lados de la ecuación entre $P(D)$. De igual modo,

$$P(D \mid B) = \frac{P(B \mid D) \times P(D)}{P(B)}$$

En la ecuación para $P(B \mid D)$, $P(B)$, que está en el lado derecho, se designa en ocasiones como probabilidad *a priori*, debido a que su valor se conoce antes del cálculo; $P(B \mid D)$ se llama probabilidad *a posteriori*, ya que su valor se conoce sólo después del cálculo.

Las dos fórmulas del teorema de Bayes son importantes debido a que con frecuencia los clínicos conocen sólo una de las probabilidades pertinentes y deben determinar la otra. Ejemplos son los estudios de genética y análisis de laboratorio, tópicos que se estudian en forma amplia en el capítulo 13.

5.3.7 COMENTARIO SOBRE TERMINOLOGÍA

Aunque en el uso diario los términos probabilidad, casualidad y verosimilitud se usan como sinónimos, los matemáticos no los emplean de esa manera. Casualidad (*odds*, en inglés) puede considerarse mejor como

la probabilidad de que el evento ocurra dividido entre la probabilidad de que no ocurra —o como la probabilidad de un evento dividida entre la probabilidad de su complemento. Por ejemplo, la casualidad de que una persona tenga tipo sanguíneo O es $0.42/(1 - 0.42) = 0.72$ a 1; pero, en general "a 1" no se representa en forma explícita. Esta interpretación va de acuerdo con el significado de razón de la casualidad, descrito en el capítulo 4, sección 4.5.4.b.

La verosimilitud (*likelihood*, en inglés) puede relacionarse con el teorema de Bayes para probabilidades condicionales. Supóngase que un médico está tratando de determinar cuál de tres enfermedades posibles tiene el paciente —infarto del miocardio, neumonía o esofagitis por reflujo. Cualquiera de las tres puede causar dolor en el pecho y el médico necesita conocer la probabilidad de que éste se deba a infarto del miocardio, o neumonía o a esofagitis por reflujo. Las probabilidades de un resultado dado (dolor de pecho) cuando se valoran bajo hipótesis diferentes (infarto del miocardio, neumonía y esofagitis por reflujo) se denominan verosimilitudes de las hipótesis (o enfermedades).

5.4 POBLACIONES Y MUESTRAS

Como se estableció en la introducción, un propósito importante para hacer investigación es inferir o generalizar, de una muestra a una población más grande. Este proceso de inferencia se efectúa por medio de métodos estadísticos basados en la probabilidad. Población es el término usado por estadígrafos para describir un conjunto o colección grande de artículos que tienen algo en común. En medicina, población en general se refiere a pacientes u otros organismos vivos, pero el término puede usarse también para denotar conjuntos de objetos inanimados, como colecciones de informes de autopsias, cargos de hospital o certificados de nacimiento. Una muestra es un subconjunto de la población, seleccionado de manera tal que represente a la población mayor.

Son demasiadas las razones para estudiar una muestra en lugar de una población entera y en esta sección se estudiarán cuatro métodos comunes para seleccionar una muestra. No obstante, antes de iniciar este tópico, observe que en medicina el término población se usa con frecuencia en forma errónea para describir lo que de hecho es una muestra. Por ejemplo, a veces los médicos se refieren a la "población de pacientes en estudio". Después de leer este texto, la persona interesada será capaz de reconocer tales errores cuando los vea en la bibliografía médica.

5.4.1 RAZONES PARA MUESTREAR

Existen por lo menos seis razones para estudiar muestras en lugar de poblaciones.

1. Las muestras pueden estudiarse con más rapidez que las poblaciones. La prontitud puede ser un factor importante si un médico necesita una respuesta rápida a una cuestión importante, como en la búsqueda de una vacuna o tratamiento para una enfermedad nueva.
2. El estudio de una muestra es menos costoso que el de una población entera, debido a que se analiza un número menor de sujetos u objetos. Esta consideración tiene importancia especial al planear estudios grandes que requieren seguimiento por tiempo prolongado.
3. En la mayor parte de situaciones el estudio de una población entera es imposible. En ocasiones, el proceso del estudio destruye o agota el objeto que se está estudiando. Por ejemplo, en un estudio de curación de cartilago en las extremidades de perros después de seis semanas de inmovilización, los animales deben sacrificarse para llevar a cabo estudios histológicos. Otras veces, el deseo es inferir eventos futuros como en el estudio de pacientes con anemia aplásica grave del Planteamiento del problema 3. En todos estos casos, el estudio de una población es imposible.
4. Con frecuencia, los resultados de una muestra son más precisos que los basados en una población. En las muestras es más accesible emplear tiempo y recursos en capacitar personas que se ocupen de efectuar observaciones y recoger datos. Además, es posible usar procedimientos más costosos que mejoren la exactitud si sólo se van a utilizar en una muestra puesto que se llevarán a cabo un número menor de veces.
5. Si las muestras se seleccionan con propiedad, es posible utilizar métodos de probabilidad para estimar el error en los parámetros estadísticos resultantes. Es este aspecto del muestreo el que permite a los investigadores hacer enunciados de probabilidad acerca de las observaciones de un estudio.
6. Las muestras pueden seleccionarse para reducir la heterogeneidad. Por ejemplo, el lupus eritematoso disseminado (LED) tiene numerosas manifestaciones clínicas, lo que resulta en una población heterogénea. Una muestra de la población con características específicas es más apropiada que la población entera para el estudio de ciertos aspectos de la enfermedad.

Para condensar, más grande no siempre significa mejor. Por esta razón, los investigadores deben planear el tamaño apropiado de muestra para su estudio antes de iniciar. Este proceso se conoce como determinación de la fuerza del estudio y se explica con mayor profundidad en capítulos ulteriores.

5.4.2 MÉTODOS DE MUESTREO

Ahora, se estudiarán los métodos para obtener muestras. La mejor forma de asegurar que una muestra conducirá a inferencias confiables y válidas es usar muestras de probabilidad en donde se conoce la probabilidad de cada sujeto de la población de ser incluido en la muestra. Los cuatro métodos usados para muestreo de probabilidad en medicina son: aleatorio simple, sistemático, estratificado y en conglomerado.

Aquí se usará el ejemplo siguiente para ilustrar cada método: considérese un médico que intenta obtener una concesión para un estudio que comprende la medición del diámetro traqueal por rayos X. Desea convencer a la fundación patrocinadora de que estas mediciones son confiables. Para estimar la confiabilidad intracalificador, seleccionará una muestra de placas de tórax entre las tomadas durante el año anterior, medirá de nuevo el diámetro traqueal y comparará la medición nueva con la original anotada en la historia del paciente. Tiene una población de 3 400 radiografías y supóngase que ha decidido que una muestra de 200 placas es suficiente para proporcionar una estimación exacta de la confiabilidad intratasador. Ahora, debe seleccionar la muestra para el estudio de confiabilidad.

5.4.2.a Muestreo aleatorio simple

En éste, cada sujeto (cada placa en el ejemplo de las radiografías) tiene una probabilidad igual de ser seleccionado para el estudio. La forma recomendada para seleccionar una muestra aleatoria simple es usar una tabla de números aleatorios o una lista de números aleatorios generada por una computadora. En este método, cada radiografía debe tener un número de identificación (ID) y disponerse de una lista de números ID, llamada **marco de muestreo**. Por simplicidad, supóngase que las radiografías están numeradas del 1 al 3 400. Usando una tabla de números aleatorios, el médico puede, después de identificar un lugar de inicio en la tabla, seleccionar los primeros 200 dígitos entre 1 y 3 400. Las placas con número ID, que corresponden a 200 números aleatorios, constituyen la muestra aleatoria simple. Si se dispone de un programa de computadora para generar números aleatorios, el

médico puede solicitar 200 números entre 1 y 3 400. Para ilustrar el proceso con una tabla de números aleatorios, se reproduce aquí una parte de la tabla A-1 del Apéndice A como cuadro 5-3. Una forma de seleccionar un punto de inicio es lanzar un dado al aire para seleccionar un renglón y una columna al azar. Lanzar el dado dos veces determina, primero, un grupo grande de renglones y segundo, un renglón particular en el bloque. Por ejemplo, si sale un 2 y un 3, se inicia en el segundo grupo, tercer renglón, iniciando con el número 83 (si se ha obtenido un 6, deberá lanzarse el dado otra vez, ya que sólo hay cinco renglones). Ahora, debe seleccionarse al azar una columna para empezar, lanzando de nuevo el dado dos veces para seleccionar un bloque y una columna en el bloque. Por ejemplo, si en el lanzamiento se obtuvo 3 y 1, se usa el tercer bloque de columnas y la primera columna, encabezada por el número 1. Por tanto, el lugar de inicio en este ejemplo, se localiza donde el renglón inicia con 83 y la columna, con 1, en su intersección está un 6 (subrayado en el cuadro 5-3).

Debido a que son 3 400 radiografías es necesario leer números de cuatro dígitos; así los primeros diez números son 6 221, 7 678, 9 781, 2 624, 8 060, 7 562, 5 288, 1 071, 3 988 y 8 549. Números menores de 3 401 son los ID de las radiografías a usarse en la muestra. En los primeros diez números seleccionados, sólo dos son menores de 3 401; de manera que se usarán las placas con los números ID 2 624 y 1 071. Este procedimiento continua hasta que se han seleccionado

200 radiografías. Cuando se alcanza el número del último renglón (7 819), la persona que está seleccionando consulta el primer renglón y se mueve un dígito a la derecha para los números 6 811, 1 465, 3 226, etcétera.

Si se localiza dos veces un mismo número menor de 3 401, la placa con ese número ID puede seleccionarse para la muestra y usarse en el estudio una segunda vez. En este caso, la muestra final será de 200 mediciones en lugar de 200 radiografías. No obstante, con frecuencia cuando un número ocurre dos veces, se ignora la segunda vez y se usa el siguiente número elegible. Las diferencias entre estos dos procedimientos son despreciables cuando se extrae la muestra de una población grande.

5.4.2.b Muestreo sistemático

Una muestra aleatoria sistemática es aquella donde cada k (tercero, quinto, décimo, etcétera) el objeto se selecciona; k se determina dividiendo el número de objetos o personas en el marco de muestreo entre el tamaño de la muestra deseada. Por ejemplo, 3 400 radiografías divididas entre 200 es 17, de modo que se selecciona la placa que está cada decimoséptimo lugar. No obstante, con este método debe seleccionarse primero un número aleatorio entre uno y 17 y de éste iniciar a contar cada decimoséptimo ID. Supóngase que de una tabla de números aleatorios se seleccionó al azar el número 12. Luego, la muestra sistemática se constituye con placas cuyos números ID son 12, 29,

Cuadro 5-3. Números aleatorios de la tabla A-1

927415	956121	168117	169280	326569	266541
926937	515107	014658	159944	821115	317592
867169	388342	832261	993050	639410	698969
867169	542747	032683	131188	926198	371071
512500	843384	085361	398488	774767	383837
062454	423050	670884	840940	845839	979662
806702	881309	772977	367506	729850	457758
837815	163631	622143	938278	231305	219737
926839	453853	767825	284716	916182	467113
854813	731620	978100	589512	147694	389180
851595	452454	262448	688990	461777	647487
449353	556695	806050	123754	722070	935916
169116	586865	756231	469281	258737	989450
139470	358095	528858	660128	342072	681203
433775	761861	107191	515960	759056	150336
221922	232624	398839	495004	881970	792001
740207	078048	854928	875559	246288	000144
525873	755998	866034	444933	785944	018016
734185	499711	254256	616625	243045	251938
773112	463857	781983	078184	380752	492215

46, 63, 80, etcétera; cada número siguiente se determina por adición de 17 al último número ID.

El muestreo sistemático no deberá usarse cuando existe una repetición cíclica inherente en el marco de muestreo. Por ejemplo, no es apropiado para seleccionar meses del año en un estudio de las frecuencias de clases diferentes de accidentes, debido a que algunos de éstos suceden con más frecuencia en ciertas épocas del año. Por ejemplo, lesiones por esquiar y accidentes automovilísticos son más comunes en los meses de invierno, en tanto que lesiones por nadar y accidentes agrícolas se presentan más a menudo en los meses de verano.

5.4.2.c Muestreo estratificado

Una muestra aleatoria estratificada es aquella que divide a la población primero en estratos pertinentes (subgrupos) y luego, de cada estrato se selecciona una muestra aleatoria. En el ejemplo de las radiografías, es posible que el médico desee estratificar la edad de los pacientes, debido a que la tráquea varía en tamaño con la edad y puede ser difícil medir con precisión el diámetro de la tráquea en pacientes jóvenes. La población de radiografías podría dividirse en lactantes menores de un año; niños de un año o menos de seis; niños de seis años a menos de 16 y todos los demás pacientes de 16 o mayores; luego, se selecciona una muestra aleatoria de cada estrato por edad. Aparte de la edad existen en medicina otros estratos de uso común como el sexo del paciente, la gravedad o etapa de la enfermedad y la duración de ésta. Las medidas escogidas como estratos deben relacionarse con los valores que interesan, en cuyo caso, el muestreo aleatorio estratificado es el más eficaz es decir, requiere una muestra más pequeña.

5.4.2.d Muestreo en conglomerado

Una muestra aleatoria en conglomerado se obtiene en un proceso de dos etapas en donde la población se divide en conglomerados y de éstos se selecciona un subconjunto. En general, los conglomerados se basan en áreas geográficas o distritos, de modo que éste planteamiento se usa con más frecuencia en investigación epidemiológica que en estudios clínicos. Por ejemplo, la muestra de una encuesta en una ciudad pueden ser manzanas de casas como conglomerados; de este modo, se escogen manzanas de casas al azar y en las elegidas se hace encuesta (o se toma una muestra aleatoria de casas). En pruebas multihospitalarias, las instituciones seleccionadas para participar en el estudio son los conglomerados; los pacientes de cada institución se pueden escoger usando cualquier

otro procedimiento de muestreo aleatorio. El muestreo de conglomerado es un poco menos preciso que los demás métodos y requiere una muestra de mayor tamaño, pero en algunas situaciones es el método de elección, como en los estudios clínicos de múltiples centros, para obtener un número adecuado de pacientes.

5.4.2.e Muestreo que no utiliza la probabilidad

Los métodos de muestreo estudiados antes se basan en la probabilidad, pero hay también otros que no la utilizan, como la muestra conveniente o muestra contingente. Las muestras no escogidas por probabilidad son aquellas en donde se desconoce la probabilidad de un sujeto de ser seleccionado. Estas muestras con frecuencia adolecen de desviaciones o sesgos de selección por la persona que está haciendo el estudio y no cubren los requerimientos de aleatoriedad necesarios para calcular errores de muestreo. Cuando se usa el término muestra en el contexto de estudios de observación, se supondrá aquí que la muestra se ha elegido en una forma aleatoria apropiada. No obstante, en el capítulo 15, se tratarán de nuevo los problemas que se presentan cuando se emplean muestras de conveniencia o convenientes y se describirá la forma en que afectan la interpretación de resultados.

5.4.2.f Asignación (designación) aleatoria

Los métodos de muestreo aleatorio se usan cuando se selecciona una muestra de una población de sujetos posibles en estudios de observación, como cohorte de caso-control o de sección cruzada. En estudios experimentales como series clínicas aleatorias, primero se seleccionan los sujetos a incluir en el estudio en base a criterios apropiados; luego se asignan a las diferentes modalidades de tratamiento. Si la asignación (designación) de los sujetos a los tratamientos se hace empleando métodos aleatorios, el proceso se conoce como asignación aleatoria. Esta puede definirse también como tratamientos asignados al azar. En cualquier caso, la asignación aleatoria ayuda a asegurar que los grupos que están recibiendo las diferentes modalidades de tratamiento son lo más semejantes posible. Así, al terminar el estudio, cualquier diferencia que se aprecie en el resultado tiene mayor probabilidad de deberse a los distintos tratamientos y no a variabilidad en la composición de los grupos.

La mejor forma de lograr una asignación aleatoria es mediante el uso de números aleatorios. Como ejemplo, considérese el estudio CASS (1983), en donde pacientes que cubrían los criterios para participar

se dividieron en subconjuntos clínicos y luego se asignaron de manera aleatoria a tratamiento médico o quirúrgico. En este estudio la asignación aleatoria puede efectuarse usando una lista de números aleatorios (obtenida de una computadora o de una tabla de números aleatorios) y asignando los números aleatorios conforme entran a la prueba. Quizá pacientes a los que se asignó un número aleatorio par reciban tratamiento médico y a los que se asignó un número impar reciban tratamiento quirúrgico o viceversa. Si el estudio comprende varias investigaciones en sitios distintos, como en un estudio multihospitalario, el investigador que prepara la entrada de un paciente elegible puede llamar a la oficina central para saber a cuál tratamiento le corresponde ser asignado. Como alternativa, en cada sitio pueden generarse por separado listas de asignación aleatoria. Desde luego, en estudios doble ciego, otra persona distinta del investigador debe conservar la lista de asignaciones aleatorias.

Supóngase que los investigadores en el estudio CASS desean un número igual de pacientes en cada sitio que participa. Para este protocolo, la asignación de números aleatorios puede equilibrarse en bloques de pacientes de un tamaño predeterminado. Por ejemplo, equilibrar los pacientes en bloques de 12 garantiza que cada vez que entren 12 pacientes al estudio en un sitio dado, seis pacientes recibirán tratamiento médico y seis tratamiento quirúrgico. No obstante, en el bloque de 12 pacientes, la asignación es aleatoria hasta que se designen seis pacientes para cada uno de los tratamientos.

También al planear una investigación se deben igualar características importantes como sexo, edad, gravedad de la enfermedad, y después hacer la selección aleatoria. Esta asignación estratificada elimina los posibles efectos por confusión de las características: equivale a la muestra aleatoria estratificada de los estudios de observación.

En estudios donde los pacientes no se designan de manera aleatoria a las distintas modalidades de tratamiento pueden producirse muchos tipos de desviaciones o sesgos. Por ejemplo, se criticó a los primeros estudios que compararon tratamiento médico con quirúrgico para coronariopatía porque no hicieron asignación aleatoria de pacientes. Algunos críticos clamaban que a los pacientes más graves no se les consideró aptos para cirugía y por tanto, el grupo sometido a cirugía estaba sesgado por formarse con los sujetos más sanos. Otros críticos establecieron que los pacientes en mejores condiciones recibieron tratamiento médico debido a que su enfermedad no se consideraba tan seria como la de pacientes graves. El problema principal es que en estudios no aleatorios, es difícil determinar cuáles desviaciones

están operando y qué conclusiones son apropiadas; de hecho, el estudio CASS se emprendió en parte para responder a estas críticas. En el capítulo 15 se da una descripción detallada de clases diferentes de desviaciones o sesgos que amenazan la validez de los estudios.

5.4.2.g Uso e interpretación de muestras aleatorias

En estudios clínicos reales, los pacientes no siempre se seleccionan en forma aleatoria de la población para la cual el investigador desea hacer inferencias. En su lugar, el investigador clínico con frecuencia utiliza a todos los pacientes que tiene a mano y cubren los criterios para integrar el estudio. Este procedimiento práctico se usa en especial cuando los estudios comprenden situaciones poco comunes. Colton (1974) hizo una distinción útil entre población objetivo y población muestreada. Población objetivo es aquella en que el investigador desea generalizar; población muestreada es de la que en realidad se extrajo la muestra. La figura 5-1 muestra un esquema de estos conceptos.

Por ejemplo, los investigadores en el Planteamiento del problema 3 querían en forma clara generalizar sus hallazgos sobre supervivencia a todos los pacientes con anemia aplásica grave; quizá muchos de ellos viviendo en otras ciudades o países e inclusive personas que aún no manifiestan la enfermedad. La población muestreada fue el conjunto de pacientes que recibieron trasplantes de médula ósea en Seattle, E.U.A., entre septiembre de 1972 y septiembre de 1984. Por tanto, la muestra en este estudio podría de hecho ser un censo completo de todos los pacientes que recibieron trasplantes de médula ósea durante ese periodo o podrían ser un subconjunto de estos pacien-




Figura 5-1. Poblaciones objetivo y muestreadas.

tes; los autores no lo especifican. La función de la inferencia estadística permite la generalización de la muestra a la población muestreada. Para hacer inferencias de la población muestreada a la población objetivo se debe indagar si la población muestreada es representativa de la población objetivo. Una población (o una muestra) es representativa de la población objetivo si la distribución de la característica importante es la misma en las dos. Este juicio es clínico, no estadístico. Señala la importancia de leer siempre la sección "Método" de informes de revistas para aprender cuál población se muestreó en realidad de modo que la persona o el médico interesados en la publicación pueden determinar la representatividad de esa población.

5.4.3 PARÁMETROS DE POBLACIÓN Y ESTADÍSTICAS DE LAS MUESTRAS

Los estadígrafos emplean un lenguaje preciso para describir las características de poblaciones y muestras. Medidas de tendencia central y de variación, como media y desviación estándar, son características fijas e invariables en las poblaciones y las designan parámetros. Sin embargo, en las muestras, la media o desviación estándar observadas, que se calculan con base en la información de la muestra son en realidad una estimación de la media o la desviación estándar de la población; estas estimaciones se llaman estadísticas. Los estadígrafos acostumbran emplear letras griegas para parámetros de población y letras latinas para estadísticas simples. En el cuadro 5-4 se resumen algunos de los símbolos usados y que a menudo se encuentran en este texto.

Cuadro 5-4. Símbolos de uso común para parámetros y estadísticas

Características	Símbolo del parámetro	Símbolo de la estadística
Media	μ	$\bar{X}$
Desviación estándar	σ	s
Varianza	σ^2	s^2
Corrección	p	r
Proporción	π	ρ

* La palabra **parámetro** tiene un significado mucho más específico y algo diferente en estadística que en su uso diario. En general, cuando las personas hablan de los parámetros que comprende el caso, se refieren en realidad a características que varían, no a características fijas en la población.

5.5 VARIABLES ALEATORIAS Y DISTRIBUCIONES DE PROBABILIDAD

En un estudio, la característica que interesa se designa **variable**. En el Planteamiento del problema 1: estado del suero de un sujeto respecto a HIV y razón T4/T8. El término **variable** tiene sentido ya que el valor de la característica difiere de un sujeto a otro. Esta variabilidad se debe a la variación biológica inherente entre personas y a errores cometidos en la medición y registro del valor de la característica de un sujeto, llamada **error de medición**. Una **variable aleatoria** es la de un estudio donde los sujetos se seleccionaron al azar. Si se piensa en los sujetos en el Planteamiento del problema 1 como seleccionados como muestra aleatoria de una población mayor de homosexuales; luego, estado del suero y razón T4/T8 son ejemplos de variables aleatorias.

Del mismo modo que los valores de características como la edad de los pacientes con cáncer colorrectal o el porcentaje de sobresaturación de bilis (capítulo 3), pueden resumirse en distribuciones de frecuencia, los valores de una variable aleatoria pueden condensarse en una distribución de frecuencias llamada **distribución de probabilidad**. Por ejemplo, si X es una variable aleatoria definida como la longitud de tiempo que un homosexual es seropositivo a HIV, luego del estudio descrito en Planteamiento del problema 1, X puede tomar los valores 0, 1, 2, ..., 34 meses y es posible determinar la probabilidad de que la variable aleatoria X tenga cualquier valor dado. Por ejemplo, del cuadro 5-1, la probabilidad $X = 0$ meses es $31/50 = 0.62$. En algunas aplicaciones, una fórmula o una regla describirán de manera adecuada una distribución; luego, la fórmula puede usarse para calcular la probabilidad que interesa. En otras situaciones, una distribución de probabilidad teórica se ajusta de manera apropiada a la distribución de la variable de interés.

En estadística importan varias distribuciones de probabilidad teóricas y aquí se analizarán tres que son útiles en medicina. Las distribuciones de probabilidad **binomial** y de **Poisson** son **discretas**; es decir, la variable aleatoria toma sólo valores enteros: 0, 1, 2, ..., n . La **distribución normal** (de Gauss o gaussiana) es una distribución de probabilidad **continua**; esto es, la variable aleatoria tiene valores medidos en una escala continua. Se analizarán las distribuciones binomial y de Poisson en forma breve, usando los Planteamientos de problemas para ilustrar cada una; luego se estudiará con profundidad la distribución normal.

5.5.1 DISTRIBUCIÓN BINOMIAL

Supóngase que un evento sólo puede tener resultados dicotómicos (por ejemplo, si y no o positivo y nega-

tivo), simbolizados con A y B . La probabilidad de A se designa π , es decir, $P(A) = \pi$ y esta probabilidad se conserva igual cada vez que el evento ocurre. Por tanto, la probabilidad de B deber ser $1 - \pi$, debido a que B se presenta cuando A no. Si un experimento que incluye a este evento se repite n veces y el resultado es independiente de una prueba a otra, ¿cuál es la probabilidad de que el resultado A ocurra exactamente X veces? O, de manera equivalente, ¿qué proporción de los n resultados serán A ? Estos interrogantes interesan a menudo, en especial en la investigación de laboratorio y pueden contestarse mediante una distribución binomial.

Los principios básicos de la distribución binomial los desarrolló el matemático suizo Jacobo Bernoulli en el siglo XVIII y constituyen una gran contribución a la teoría de la probabilidad. Fue autor del que se reconoce en general como el primer libro consagrado a la probabilidad; lo publicó en 1713. De hecho, cada prueba que utiliza la probabilidad binomial se designa en ocasiones como prueba Bernoulli y una secuencia de pruebas, como un proceso Bernoulli. La distribución binomial da la probabilidad de que un resultado específico ocurra dentro de un número dado de pruebas independientes. La distribución binomial puede usarse en genética para el modelo de herencia de un rasgo particular, para estimar la ocurrencia de una reacción determinada como una descarga (liberación cuántica) de acetilcolina en la unión neuromuscular o estimar la muerte de una célula cancerosa en una prueba *in vitro* de un agente quimioterapéutico nuevo.

Para ilustrar la distribución binomial se empleará el Planteamiento del problema 3. Supóngase, por un momento, que se ha estudiado la población entera de personas con anemia aplásica grave y que la probabilidad de supervivencia al año es de 0.8 (se emplea 0.8 por conveniencia de cálculo, en lugar de 0.82 como se observó en el estudio). Como símbolos, S represente el evento de diez años de supervivencia y D represente deceso antes de los diez años; luego, $\pi = P(S) = 0.8$ y $1 - \pi = P(D) = 0.2$. Considérese un grupo de $n = 2$ pacientes con anemia aplásica grave. ¿Cuál es la probabilidad exacta de que los dos pacientes vivan diez años? ¿Cuál, que en forma exacta uno viva a los diez años? ¿Cuál, que ninguno viva a los diez años? Estas probabilidades se encuentran aplicando las reglas de multiplicación y adición delineadas al principio del capítulo.

La probabilidad exacta de que los dos pacientes vivan a los diez años se encuentra usando la regla de multiplicación para eventos independientes. Se sabe que para el paciente 1 $P(S) = 0.8$ y para el paciente 2 lo mismo, $P(S) = 0.8$. Debido a que la supervivencia de un paciente es independiente (no tiene influencia) en la supervivencia del otro, la probabilidad de que **ambos** sobrevivan es:

$$P(S \text{ para paciente 1 y } S \text{ para paciente 2}) \\ P(S)P(S) = (0.8)(0.8) = .64$$

El evento de que un paciente sobreviva exactamente diez años puede producirse de dos maneras; el paciente 1 sobrevive diez años, el 2 no, o el 2 sobrevive diez años y el 1, no. Estos dos eventos son mutuamente excluyentes; por tanto, después de usar la regla de multiplicación para obtener la probabilidad de cada evento, puede aplicarse la regla de adición de eventos mutuamente excluyentes para combinar las probabilidades.

$$P(S \text{ para paciente 1 y } D \text{ para paciente 2})$$

$$= P(S)P(D) = (.8)(.2) = .16,$$

$$\text{y } P(D \text{ para paciente 1 y } S \text{ para paciente 2})$$

$$= P(D)P(S) = (.2)(.8) = .16$$

$$\text{Por tanto, } P(\text{evento 1 o evento 2}) = 0.16 + 0.16 = 0.32$$

Por último, la probabilidad de que ninguno de ellos viva diez años es:

$$P(D \text{ para el paciente 1 y } D \text{ para el paciente 2})$$

$$= P(D)P(D) = (.2)(.2) = .04$$

Los cálculos anteriores se resumen en el cuadro 5-5, observe que la probabilidad total es:

$$P(X) = \frac{n!}{X!(n-X)!} \pi^X (1-\pi)^{n-X}$$

que algunos lectores pueden reconocer como la fórmula del binomio cuadrado perfecto, $a^2 + 2ab + b^2$.

El mismo proceso puede aplicarse para cualquier tamaño de grupo de pacientes o para cualquier número de pruebas, pero se vuelve bastante tedioso. Una técnica más sencilla es usar la fórmula para la distribución binomial, que se expresa a continuación. La probabilidad de resultados X en un grupo de tamaño n , si cada resultado tiene probabilidad π y es independiente de los demás resultados, está dado por:

Cuadro 5-5. Resumen de probabilidades para dos pacientes

Resultado		Número de formas a ocurrir	Probabilidad
Primer paciente	Segundo paciente		
S	S	1	$0.8 \times 0.8 = 0.64$
D	S	2	$2 \times 0.8 \times 0.2 = 0.32$
S	D	2	
D	D	1	$0.2 \times 0.2 = 0.04$

$$P(X) = \frac{n!}{X!(n-X)!} \pi^X (1-\pi)^{n-X}$$

donde ! es el símbolo para factorial; $n!$ se llama factorial de n y es igual al producto de $n(n-1)(n-2) \dots (3)(2)(1)$. Por ejemplo, $4! = (4)(3)(2)(1) = 24$. El número 0! se define como 1. El símbolo π^X indica que π se eleva a la potencia X y $(1-\pi)^{n-X}$ significa que $1-\pi$ se eleva a la potencia $n-X$. La expresión $n!/[X!(n-X)!]$ en ocasiones se designa como la fórmula para las combinaciones debido a que da el número de combinaciones posibles para objetos X entre los n objetos en el grupo. El uso de esta fórmula simplifica los cálculos.

Para verificar que la probabilidad exacta de que $X = 1$ en $n = 2$ pacientes sobreviva diez años es 0.32, se emplea la fórmula siguiente:

$$\begin{aligned} P(1) &= \frac{2!}{1!(2-1)!} (.8)^1 (1-.8)^{2-1} \\ &= \frac{(2)(1)}{(1)(1)} (.8)(.2) = (2)(.8)(.2) = .32 \end{aligned}$$

Para resumir, la distribución binomial es útil para resolver interrogantes acerca de la probabilidad de X número de ocurrencias en n pruebas independientes cuando hay una probabilidad constante π de éxito en cada prueba. Por ejemplo, supóngase que se inicia una serie nueva de trasplantes de médula ósea con diez pacientes. Puede usarse la distribución binomial para calcular la probabilidad de que un número particular de ellos sobrevivirá diez años. Por ejemplo, la probabilidad de que sobrevivan los diez pacientes por diez años es:

$$\begin{aligned} P(10) &= \frac{10!}{10!(10-10)!} (.8)^{10} (1-.8)^{10-10} \\ &= \frac{10!}{(10!)(0!)} (.8)^{10} (.2)^0 = (1)(.8)^{10}(1) = .107, \end{aligned}$$

De igual modo, la probabilidad de que sobrevivan exactamente ocho pacientes los diez años es:

$$\begin{aligned} P(8) &= \frac{10!}{8!(10-8)!} (.8)^8 (1-.8)^{10-8} \\ &= \frac{(10)(9)(8!)}{(8!)(2!)} (.8)^8 (.2)^2 \\ &= \frac{(10)(9)}{(2)(1)} (.168)(.04) = (45)(.168)(.04) = .302 \end{aligned}$$

El cuadro 5-6 enumera las probabilidades para $X = 0, 1, 2, 3, \dots, 10$; la figura 5-2 es una gráfica de la

Cuadro 5-6. Probabilidades para distribución binomial con $n = 10$ y $\pi = 0.8$

Número de pacientes que sobreviven	$\frac{n!}{X!(n-X)!}$	π^X	$(1-\pi)^{n-X}$	$P(X)^1$
0	1	1	0.0000001	0
1	10	0.8	0.0000005	0
2	45	0.64	0.0000026	0.0001
3	120	0.512	0.0000128	0.0008
4	210	0.410	0.000064	0.0055
5	252	0.328	0.00032	0.0264
6	210	0.262	0.0016	0.0881
7	120	0.210	0.008	0.2013
8	45	0.168	0.04	0.3020
9	10	0.134	0.2	0.2684
10	1	0.107	1	0.1074

¹ Redondeada a cuatro cifras decimales.

distribución binomial cuando $n = 10$ y $\pi = 0.8$. La media de la distribución binomial es $n\pi$; por tanto, $(10)(0.8) = 8$ es el número medio de supervivencia de pacientes a diez años en este ejemplo. La desviación estándar es $\sqrt{n\pi(1-\pi)}$, que para este ejemplo es $\sqrt{(10)(0.8)(0.2)} = 1.265$. Así, los dos únicos datos que se requieren para definir una distribución binomial son n y π , que se denominan parámetros de esa distribución. Los estudios en donde hay variables dicotómicas (capítulo 9) a menudo utilizan proporción en lugar de número; por ejemplo, la proporción de pacientes que sobreviven un tiempo dado en lugar del número de pacientes. Cuando se emplea proporción en lugar del número de éxitos, se requieren los mismos dos datos (n y π). No obstante, debido a que la proporción se encuentra dividiendo X entre n , π se convierte en la media de la distribución de la proporción y la desviación estándar es $\sqrt{\pi(1-\pi)/n}$.

Aun con el uso de la fórmula, el cálculo de la distribución binomial consume tiempo, en especial si




Figura 5-2. Distribución binomial para $n = 10$ y $\pi = 0.8$.

las cifras son grandes. Además, la fórmula da la probabilidad de observar con precisión X éxitos y con frecuencia el interés real consiste en conocer la probabilidad de X o más éxitos o de X o menos éxitos. Por ejemplo, para encontrar la probabilidad de que ocho o más pacientes sobrevivirán diez o más años, debe usarse la fórmula para encontrar por separado las probabilidades de que sobrevivirán ocho, nueve y diez y luego sumar estos resultados; del cuadro 5-6 se tiene que $P(X \geq 8) = P(X=8) + P(X=9) + P(X=10) = 0.3020 + 0.2684 + 0.1074 = 0.6778$. En numerosos textos elementales se presentan tablas que dan probabilidades para la distribución binomial; si el lector está interesado en analizar resultados dicotómicos de muestras pequeñas, puede consultar estos textos (Daniel, 1974; Mendenhall, 1987; Sokal y Rohlf, 1981). En este libro no se incluyen tablas binomiales debido a que la mayor parte de la investigación en medicina se lleva a cabo con muestras bastante grandes que pueden usar una aproximación de la distribución binomial; esta aproximación se estudiará en el capítulo 9.

5.5.2 DISTRIBUCIÓN DE POISSON

Esta medida estadística se debe al matemático francés Simeon D. Poisson. Igual que la binomial, la distribución de Poisson es una distribución discreta aplicable cuando el resultado es el número de veces que un evento ocurre. Puede usarse para determinar la probabilidad de eventos poco frecuentes; es decir, da la probabilidad de que un resultado ocurra un número específico de veces cuando la cantidad de pruebas es grande y la probabilidad de cualquier ocurrencia es pequeña. Por ejemplo, sirve para planear el número de camas que un hospital necesita en su unidad de cuidados intensivos, el número de ambulancias para acudir a llamadas o el número de operadores que se requieren para atender el conmutador. También puede usarse para definir el número de células en un volumen dado de líquido, el número de colonias bacterianas que está proliferando en cierta cantidad de medio o la emisión de partículas que emite una cantidad específica de material radiactivo.

Considérese una variable aleatoria que representa el número de veces que un evento ocurre en un tiempo dado o en un intervalo. Luego la probabilidad de ocurrencias exactas de X está dada por la fórmula siguiente:

$$P(X) = \frac{\lambda^X e^{-\lambda}}{X!}$$

en donde λ (letra griega lambda) es el valor de la media y de la varianza de la distribución de Poisson y

e es la base de los logaritmos naturales (igual a 2.718). El término λ se conoce como parámetro de la distribución de Poisson, del mismo modo n y π son parámetros de la distribución binomial. Por tanto se requiere sólo un dato, λ , para caracterizar cualquier distribución de Poisson dada.

En el *Coronary Artery Surgery Study* (CASS, 1983) se usó una variable aleatoria que tiene una distribución de Poisson, como se resume en el Punteamiento del problema 4. Los investigadores describieron el número de hospitalizaciones para cada grupo de pacientes (médicos o quirúrgicos) siguiendo distribuciones de Poisson. Este modelo es apropiado debido a que la casualidad de que un paciente se hospitalice durante cualquier intervalo de tiempo es pequeña y puede suponerse que es independiente entre pacientes. Los resultados indicaron que los 390 pacientes escogidos al azar para el grupo médico se hospitalizaron 660 veces en el transcurso de los cinco años del estudio; los 390 pacientes asignados de manera aleatoria al grupo quirúrgico se hospitalizaron un total de 950 veces. La media del número de hospitalizaciones, del modelo de Poisson para pacientes con tratamiento médico es $660/390 = 1.69$ y la media para los pacientes quirúrgicos es $950/390 = 2.44$. Con esta información y la fórmula del modelo de Poisson se calculan las probabilidades del número de hospitalizaciones. Por ejemplo, la probabilidad de que un paciente del grupo médico no se hospitalice (cero) es:

$$P(X=0) = \frac{(1.69)^0 (e^{-1.69})}{0!} = \frac{(1)(.184)}{1} = .184$$

La probabilidad de que el paciente se hospitalice una vez es:

$$P(X=1) = \frac{(1.69)^1 (e^{-1.69})}{1!} = \frac{(1.69)(.184)}{1} = .312$$

En el cuadro 5-7, se dan los cálculos para la distribución de Poisson completa cuando $\lambda = 1.69$.

La figura 5-3 es una gráfica de la distribución de Poisson para $\lambda = 1.69$. Observe que la media de la distribución está entre 1 y 2 (el valor exacto es 1.69). También, obsérvese su sesgo positivo. Para lectores que deseen más información acerca de la distribución de Poisson consúltese la lista de referencias para la distribución binomial.

5.5.3 DISTRIBUCIÓN NORMAL (DE GAUSS)

Ahora se explicará la distribución de probabilidad más famosa en estadística, llamada normal o gaussiana.

Cuadro 5-7. Probabilidades para la distribución de Poisson con $\lambda = 1.69$


Número de hospitalizaciones	1.69*	$e^{-1.69}$	$X!$	$P(X)^1$
0	1	0.184	0	0.184
1	1.69	0.184	1	0.312
2	2.856	0.184	2	0.265
3	4.827	0.184	6	0.148
4	8.157	0.184	24	0.063
5	13.786	0.184	120	0.021
6	23.298	0.184	720	0.006

* Redondeada a tres cifras decimales.

na (o campana de Gauss). La curva normal fue descubierta por primera vez por el matemático francés Abraham Demoivre, quien publicó sus trabajos en 1733. Sin embargo, dos astrónomos matemáticos, Pierre-Simon Laplace de Francia y Carl Friedrich Gauss de Alemania, se ocuparon de establecer los principios científicos de la distribución normal. Muchos consideran que Laplace contribuyó más a la teoría de la probabilidad, pero se le dio el nombre de Gauss después que éste aplicó la teoría a los movimientos de cuerpos pesados. Algunos estadígrafos prefieren usar el término *gaussiano* en lugar de normal debido a que este último tiene la infortunada (e incorrecta) connotación de que la curva normal describe la forma en que las características se distribuyen en poblaciones compuestas por personas "normales" —en oposición a enfermas. Aquí se emplea el término **normal** debido a que en la bibliografía médica su uso es más común.

5.5.3.a Descripción de la distribución normal

La distribución normal es continua, de modo que puede tomar un valor cualquiera (no sólo enteros,

Figura 5-3. Distribución de Poisson para $\lambda = 1.69$

como en las distribuciones binomial y de Poisson). Es una curva lisa en forma de campana, simétrica alrededor de la media de la distribución que en este caso se simboliza μ (letra griega mu) y no $\bar{X}$. La campana gaussiana se muestra en la figura 5-4.

La desviación estándar de la distribución se simboliza con σ (letra griega sigma) y es la distancia horizontal entre la media y el punto de inflexión de la curva —es decir, el punto donde la curva cambia de convexa a cóncava. La media y la desviación estándar (o varianza) son los dos parámetros de la distribución normal; esto es, μ y σ determinan completamente la ubicación en las cantidades y la forma de una curva normal. Por tanto, hay numerosas curvas normales diferentes, una para cada valor de μ y σ . Debido a que la campana gaussiana es una distribución de probabilidad, el área bajo la curva es igual a uno y como es una distribución simétrica, la mitad del área está a la izquierda de la media y la mitad a la derecha.

Dada una variable aleatoria X que puede tomar cualquier valor entre $-\infty$ y $+\infty$ (∞ representa infinito), la fórmula del área bajo la curva normal en la siguiente:

$$\int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right] dx = 1$$

donde $\exp$ es para la base e de los logaritmos naturales y $\pi = 3.1416$. Observe que la función sólo depende de μ y σ para una X dada, debido a que son los únicos componentes que varían.

Que el área bajo la curva sea igual a uno conduce al uso de la distribución normal para calcular probabilidades. Por ejemplo, supóngase que se quiere conocer la probabilidad de que una observación caiga entre a y b en la curva de la figura 5-5; esta probabilidad puede encontrarse por integración de la ecuación anterior entre a y b ; es decir, en la integración, a a se le da el valor $-\infty$ y a b el valor $+\infty$ (Integración es una técnica matemática en cálculo, que se emplea para calcular el área bajo una curva).






Figura 5-4. Distribución normal y porcentaje del área bajo la curva.

Figura 5-5. Área bajo una curva normal entre a y b .Figura 5-6. Distribución normal estándar (z)

5.5.3.b Distribución normal estándar (z)

Por fortuna, no hay necesidad de integrar esta función ya que se dispone de tablas. No obstante, dado que no se necesita usar una tabla diferente para cada valor de μ y σ ; se emplea una curva (distribución) normal estándar, que tiene una media = 0 y desviación estándar = 1, como se muestra en la figura 5-6. Esta curva se designa también **distribución z** . La tabla A-2 (Apéndice A) da el área bajo la curva que está entre $-z$ y $+z$, la suma de las áreas a la izquierda de $-z$ y a la derecha de $+z$ y el área a la izquierda de $-z$ o la derecha de $+z$.

Antes de usar la tabla A-2, obsérvese la distribución normal estándar de la figura 5-6 y estimése la proporción (o porcentaje) de las áreas siguientes:

1. Arriba de 1
2. Abajo de -1
3. Arriba de 2
4. Abajo de -2
5. Entre -1 y 1
6. Entre -2 y 2.

Ahora utilícese la tabla A-2 y encuéntrense las áreas designadas. Las respuestas se dan adelante.

1. 0.159 del área está a la derecha de 1 (de la cuarta columna en la tabla A-2).
2. La tabla A-2 no enlista valores para z menores de 0; no obstante debido a que la distribución es simétrica alrededor de 0, el área bajo -1 es igual que el área a la derecha de 1, que es 0.159.
3. 0.023 del área está a la derecha de 2 (de la cuarta columna en la tabla A-2).
4. El mismo razonamiento se aplica en el 2 de modo que 0.023 del área está a la izquierda de -2.
5. 0.683 del área está entre -1 y 1 (de la segunda columna de la tabla A-2).
6. 0.954 del área entre -2 y 2 (de la segunda columna de la tabla A-2).

Cuando la media de una distribución gaussiana no es 0 y la desviación no es 1, se debe hacer una transformación llamada z de modo que pueda usarse la tabla normal estándar. La transformación z expre-

sa la desviación desde la media en unidades de desviación estándar. Esto es, cualquier distribución normal puede transformarse a distribución normal estándar mediante los dos pasos siguientes:

1. Muevase la distribución hacia arriba o hacia abajo del eje de modo que la media sea 0. Este paso se efectúa sustrayendo la media μ de la variable X dada.
2. La distribución se hace más angosta o ancha para que la desviación estándar sea igual a 1. Este paso se ejecuta dividiendo entre σ .

Para resumir, el valor transformado es:

$$z = \frac{X - \mu}{\sigma}$$

y por lo general se designa **razón z** , **desviación normal**, **razón estandarizada** o **razón crítica**.

5.5.3.c Ejemplos que usan la distribución normal estándar

Considérese el Planteamiento del problema 5, donde la presión sanguínea (PS) sistólica de personas normales se distribuye en forma normal con $\mu = 120$ y $\sigma = 10$ mm Hg. Háganse las transformaciones apropiadas para contestar las preguntas siguientes (*sugerencia*: Dibújense esquemas de la distribución para tener seguridad de hallar el área correcta).

1. ¿Qué área de la curva está por arriba de 130 mm Hg?
2. ¿Qué área de la curva está arriba de 140 mm Hg?
3. ¿Qué área de la curva está entre 100 y 140 mm Hg?
4. ¿Qué área de la curva está por arriba de 150 mm Hg?
5. ¿Qué área de la curva está por abajo de 90 mm Hg o por arriba de 150 mm Hg?
6. ¿Qué valor de la presión sanguínea sistólica divide el área bajo la curva en el 95% inferior y el 5% superior?
7. ¿Qué valor de presión sanguínea sistólica divide el área bajo la curva en el 97.5% inferior y el 2.5% superior?

Para responder, el lector puede referirse a los esquemas de la figura 5-7, de acuerdo a:

1. $z = (130 - 120)/10 = 1.00$ y el área por arriba de 1.00 es 0.159. Así, 15.9% de personas sanas tienen una presión sanguínea sistólica superior a una desviación estándar (>130 mm Hg).
2. $z = (140 - 120)/10 = 2.00$ y el área superior a 2.00 es 0.023. Así, 2.3% tienen una presión sanguínea sistólica superior a dos desviaciones estándar (>140 mm Hg).
3. $z_1 = (100 - 120)/10 = -2.00$ y $z_2 = (140 - 120)/10 = 2.00$; el área entre -2 y +2 es 0.954. Así, 95.4% tienen una presión sanguínea sistólica entre -2 y +2 desviaciones estándar (entre 100 y 140 mm Hg).
4. $z = (150 - 120)/10 = 3.00$ y el área por arriba de 3.00 es 0.001. Por tanto, sólo 0.1% tienen una presión sanguínea sistólica por arriba de tres desviaciones estándar (>150 mm Hg).
5. $z_1 = (90 - 120)/10 = -3.00$ y $z_2 = 3.00$; el área por arriba de 3.00 es 0.003. Por tanto, sólo 0.3% tienen una presión sanguínea sistólica por abajo o por arriba de tres desviaciones estándar (<90 o >150 mm Hg).
6. Este problema es algo más difícil y debe resolverse retrocediendo en la información. El valor de z , obtenido de la tabla A-2, que divide al 0.95 inferior del área del 0.05 superior es 1.645. Sustituyendo este valor para z en la fórmula y resolviendo para los productos X :

$$z = \frac{X - \mu}{\sigma}$$

$$1.645 = \frac{X - 120}{10}$$

$$(10)(1.645) = X - 120$$

$$136.45 = X$$

Por tanto, en el percentil 95o se encuentra la presión sanguínea sistólica de 136.45 mm Hg (deberá reconocerse que esto es más específico que las mediciones de presión sanguínea que en general se hacen). De modo que 95% de personas sanas normales tienen una presión sanguínea sistólica de 136.45 mm Hg o menor.

7. Retrocediendo de nuevo en la información, se obtiene el valor 1.96 para z . Sustituyendo y resolviendo para los productos X :

$$1.96 = \frac{X - 120}{10}$$

$$19.6 = X - 120$$

$$139.6 = X$$

Por consiguiente, una presión sanguínea sistólica de 139.6 mm Hg divide la distribución de personas sanas normales en el 97.5% inferior y el 2.5% superior.

De los resultados de los ejercicios anteriores, pueden establecerse algunos enunciados importantes para usar la distribución gaussiana. Como se mencionó en el capítulo 4 esta distribución tiene tres características distintivas:

1. La media $\pm$ una desviación estándar abarca alrededor de 66.7% del área bajo la curva normal.
2. La media $\pm$ dos desviaciones estándar incluye alrededor de 95% del área bajo la curva normal.
3. La media $\pm$ tres desviaciones estándar incluye alrededor de 99.7% del área bajo la curva normal.

Aunque estas características indican que la distribución normal es una herramienta valiosa en estadística, su valor va más allá del hecho simple de describir distribuciones. En realidad, pocas características tienen distribución gaussiana. Es seguro que los datos de presión sanguínea sistólica del Planteamiento del problema 5 no están distribuidos en forma normal exacta en todas las poblaciones. En algunas de éstas, los datos muestran sesgo positivo: un número mayor de personas tienen presión sistólica por arriba de 120 mm Hg que por abajo y Elveback, Guillier y Keating (1970) demostraron que algunos valores de laboratorio muy comunes no tienen distribuciones normales; en consecuencia, el uso del planteamiento de $\pm$ dos desviaciones estándar puede causar que más o menos 5% de la población quede fuera de estos límites. Sin embargo, usados en forma sensata, estos tres enunciados son reglas adecuadas para características que tienen distribuciones aproximadamente normales.

No obstante, la importancia principal de la distribución normal radica en la función que tiene en la inferencia estadística. En el capítulo siguiente se muestra que la distribución normal constituye la base para hacer inferencias estadísticas, inclusive cuando la población no tiene distribución normal. Sin embargo, hay un punto muy importante y se mencionará varias veces: En general, la inferencia estadística emplea valores medios de una población, no valores relacionados con las personas. En este capítulo las aplicaciones se ocupan de personas y, si se hacen enunciados de probabilidad acerca de personas utilizando las reglas de media y desviación estándar, la distribución de la característica que interesa debe tener una distribución normal aproximada.

5.6 RESUMEN

Este capítulo se enfoca a tres conceptos que explican por qué los resultados de un estudio que emplea cierto




Figura 5-7. Cálculo de áreas bajo la curva que siguen la distribución normal.

conjunto de sujetos pueden usarse para extraer conclusiones acerca de otros sujetos semejantes. Los tres conceptos son probabilidad, muestreo y distribuciones de probabilidad. Después de definir la probabilidad, se usaron dos ejemplos para ilustrar la forma en que las reglas para calcular probabilidades ayudan a determinar la distribución de características en muestras de personas (por ejemplo, distribución de tipos sanguíneos en varones y mujeres; distribución del tiempo que los homosexuales son seronegativos o seropositivos para HIV y su relación con la razón T4/T8).

También se ilustraron las reglas de adición y de multiplicación para eventos no mutuamente exclusivos y eventos no independientes. La regla de adición se emplea para agregar las probabilidades de dos o más eventos mutuamente exclusivos. Si los eventos no son mutuamente exclusivos, la probabilidad de su ocurrencia simultánea debe sustraerse de la suma. La regla de multiplicación se emplea con probabilidades de dos o más eventos independientes. Si los eventos no son independientes, se dice que son condicionales, y para obtener su probabilidad deberá usarse el teorema de Bayes. La aplicación de la regla de multiplicación permite llegar a la conclusión de que sexo y tipo sanguíneo tienen distribución independiente en las personas. Por el contrario, el estado del suero y la razón T4/T8 en homosexuales sanos no son características independientes.

Empleando como ejemplo un estudio sobre medición de diámetros traqueales, se ilustraron las

ventajas y desventajas de los diferentes métodos de muestreo aleatorio. Se obtuvo una muestra aleatoria simple por selección al azar de radiografías que correspondían a cifras tomadas de una tabla de números aleatorios. El muestreo sistemático se ilustró por selección de cada radiografía decimoséptima y se mencionó que el muestreo sistemático es fácil de usar y apropiado en tanto no haya un componente cíclico para los datos. Para ilustrar el muestreo aleatorio estratificado se usaron los datos de radiografías separados por grupos de edades. El muestreo estratificado es el método más eficiente y por tanto se emplea en numerosos estudios grandes. En estudios clínicos, los investigadores deben asignar pacientes de manera aleatoria a las condiciones experimental y control (en lugar de seleccionar pacientes al azar) para evitar las desviaciones o sesgos que amenazarían la validez de las conclusiones del estudio.

Por último, se presentaron tres distribuciones de probabilidad: binomial, Poisson y normal (gaussiana). La distribución binomial se emplea para modelar eventos que tienen resultado dicotómico (es decir, el resultado puede ocurrir o no) y para determinar los resultados que interesan. La distribución binomial es útil para obtener la probabilidad de que un número específico de pacientes con anemia aplásica grave sobreviva diez años. Se indicó que la distribución binomial se emplea a menudo para determinar probabilidades acumuladas.

La distribución de Poisson se utiliza para determinar probabilidades de eventos poco comunes. En el estudio CASS de coronariopatía, la hospitalización de los pacientes durante los cinco años de seguimiento fue poco común; de este modo se calculó su probabilidad para pacientes asignados de manera aleatoria a tratamiento médico. El ejercicio 4 emplea cálculos para probabilidades semejantes en el grupo quirúrgico.

La distribución normal se emplea para determinar la probabilidad de características medidas en una escala numérica continua. Cuando la serie de datos dan una forma aproximada de campana, la distribución normal puede usarse para mostrar cuan representativa o extrema es una observación. Aquí la distribución normal se empleó para determinar los porcentajes de población que se espera tengan presiones sanguíneas sistólicas superiores o inferiores a ciertos valores. También se encontró el valor de presión sanguínea sistólica que divide la población de adultos normales sanos en 95% menor y 5% mayor. Por último, se hizo notar que la distribución normal tiene un papel crítico en hacer inferencias acerca de otras muestras semejantes, como se estudiará en el próximo capítulo.

EJERCICIOS

- 1. a. Demuéstrese que sexo y tipo sanguíneo son independientes; es decir, que la probabilidad conjunta es el producto de las dos probabilidades marginales para cada casilla del cuadro 5-2.
b. ¿Qué pasa si se usa la regla de multiplicación con probabilidad condicional cuando dos eventos son independientes? Usense los datos de sexo y tipo sanguíneo para ilustrar este punto.
- 2. El cuadro 5-8 da la incidencia de enfermedad injerto-contrahuésped aguda, enfermedad injerto-contrahuésped crónica y muerte en subgrupos de pacientes definidos de acuerdo a los títulos séricos de anticuerpos a citomegalovirus del Planteamiento del problema 3. Usese este cuadro para contestar las preguntas siguientes:
a. ¿Cuál es la probabilidad de enfermedad injerto-contrahuésped crónica?
b. ¿Cuál es la probabilidad de enfermedad injerto-contrahuésped aguda?
c. Si un paciente experimenta seroconversión, ¿cuál es la probabilidad de que el paciente

Cuadro 5-8. Incidencia de la enfermedad injerto-contrahuésped

Condición	Sero-negativo	Sero-conversión	Sero-positivo
Enfermedad injerto-contrahuésped aguda	6	2	2
Enfermedad injerto-contrahuésped crónica	7	8	2
Muerte	3	3	2
Total de pacientes	17	18	12

- tenga enfermedad injerto-contrahuésped aguda?
- d. ¿Qué tan probable es que un paciente que falleció haya sido seropositivo?
 - e. ¿Qué proporción de pacientes eran seronegativos? Si este valor fuera la proporción real en la población, ¿qué tan probable sería que cuatro de cada ocho pacientes nuevos sean seronegativos?
3. Un cirujano plástico desea comparar el número de injertos cutáneos con éxito en su serie de pacientes quemados con los éxitos en otros pacientes quemados. Una encuesta de la bibliografía indica que alrededor de 30% de injertos se infectan, pero que 80% sobrevive. En su serie, el cirujano ha observado una supervivencia de injertos de siete de cada ocho pacientes y sólo uno se infectó.
a. ¿Qué tan verosímil es la ocurrencia de sólo una infección en ocho pacientes?
b. ¿Qué tan verosímil es la supervivencia de siete de cada ocho injertos?
4. Calcúlese la distribución de Poisson para el número de hospitalizaciones en el grupo quirúrgico de pacientes del estudio CASS (Planteamiento del problema 4) y dibújese una gráfica de la distribución (de la sección 5.5.2, recuérdese que hubo 950 hospitalizaciones entre los 390 pacientes quirúrgicos). ¿Cómo cambia la forma de la distribución de Poisson cuando λ se vuelve más grande? ¿Qué tan verosímil es que un paciente quirúrgico se haya hospitalizado exactamente dos veces en los cinco años de seguimiento?
5. Los valores de sodio sérico en adultos sanos siguen aproximadamente una distribución nor-

- mal con media de 141 mEq/L y desviación estándar de 3 mEq/L.
- a. ¿Cuál es la probabilidad de que un adulto sano normal tendrá un sodio sérico mayor de 147 mEq/L?
 - b. ¿Cuál es la probabilidad de que un adulto sano normal tendrá un sodio sérico menor de 130 mEq/L?
 - c. ¿Cuál es la probabilidad de que un adulto sano normal tendrá un sodio sérico entre 132 y 150 mEq/L?

- d. ¿Qué concentración sérica de sodio deberá tener una persona para quedar en el 1% superior de la distribución?
 - e. ¿Qué concentración sérica de sodio es necesaria para que una persona esté en el 10% inferior de la distribución?
6. Calcúlese la distribución binomial para cada conjunto de parámetros: $n = 6, \pi = 0.1$; $n = 6, \pi = 0.3$; $n = 6, \pi = 0.5$. Dibújese una gráfica y establezcanse conclusiones acerca de las formas.