

Estadística



Martes, Viernes y Sábados de 9-11hs

Consideraciones generales y operativas



 **EconCampus** SharePoint

 **Novedades de la cursada**
 
No hay novedades
•

 **Ingresar en**
ESTADISTICA -
BURDISO

 **Materiales**
Última actualización: 15/07/2020 17:32:05

 **Actividades**
No hay consignas subidas

 **Anuncio de la cátedra**
Fin de cuatrimestre
Estimados alu... [Ver más...](#)

 **Comunicaciones**

 No se encuentran eventos
ingresados para las
proximas fechas

Consideraciones generales y operativas



EconCampus SharePoint

Novedades de la cursada

No hay novedades

Ingresar en ESTADISTICA - BURDISO

Materiales

Última actualización: 15/07/2020 17:32:05

Actividades

No hay consignas subidas

Anuncio de la cátedra

Fin de cuatrimestre

Estimados alu... Ver más...

Comunicaciones

No se encuentran eventos ingresados para las proximas fechas

La titular de cátedra es la
Profesora Silvia Vietri

Consideraciones generales y operativas



EconCampus SharePoint

Novedades de la cursada

No hay novedades

Ingresar en ESTADISTICA - BURDISO

Materiales

Última actualización: 15/07/2020 17:32:05

Actividades

No hay consignas subidas

Anuncio de la cátedra

Fin de cuatrimestre

Estimados alu... Ver más...

Comunicaciones

No se encuentran eventos ingresados para las proximas fechas

- Los mails de los alumnos
- Foro (ojo vamos a usar otro)

Consideraciones generales y operativas



The screenshot shows the EconCampus SharePoint interface. The top navigation bar includes the EconCampus logo and the text 'SharePoint'. The main content area is divided into several colored tiles:

- Novedades de la cursada** (Orange): A large tile with a central dot and arrows, indicating no updates.
- Ingresar en ESTADISTICA - BURDISO** (Blue): A tile with a user icon and the course name.
- Materiales** (Purple): A tile with a book icon, the title 'Materiales', and the text 'Última actualización: 15/07/2020 17:32:05'.
- Actividades** (Dark Purple): A tile with a document icon, the title 'Actividades', and the text 'No hay consignas subidas'.
- Anuncio de la cátedra** (Orange): A tile with a building icon, the title 'Anuncio de la cátedra', and the text 'Fin de cuatrimestre' and 'Estimados alu... Ver más...'.
- Comunicaciones** (Teal): A tile with an envelope icon and the title 'Comunicaciones'.
- Calendar** (Orange): A small tile with a calendar icon and the text 'No se encuentran eventos ingresados para las proximas fechas'.

A green arrow points from the 'Comunicaciones' tile to the list of video resources below.

- Videos de las clases teóricas
- Videos de las clases prácticas
- Videos de la resolución de los trabajos prácticos

Consideraciones generales y operativas



EconCampus SharePoint

Novedades de la cursada

No hay novedades

Ingresar en
ESTADISTICA - BURDISO

Materiales
Última actualización: 15/07/2020 17:32:05

Actividades
No hay consignas subidas

Anuncio de la cátedra
Fin de cuatrimestre
Estimados alu... Ver más...

Comunicaciones

No se encuentran eventos ingresados para las proximas fechas

EconCampus SharePoint

Inicio **El curso** La cursada Comunicaciones La cátedra

ESTADISTICA - BURDISO

Prof. Vietri


Novedades

Título
Modificado

No hay elementos para mostrar en esta vista de la lista "Novedades". Para agregar un nuevo elemento, haga clic en "Nuevo".

+ Agregar nuevo anuncio

ESTADISTICA BURDISO



[bienvenid@s](#) / [programa y calendario](#) / [docentes](#) / [material del curso](#)

BIENVENID@S

PROGRAMA Y CALENDARIO

DOCENTES

MATERIAL DEL CURSO

BIENVENID@S

A la página de Estadística (248) de Tamara Burdisso (curso 39) – Sede Paternal FCE | UBA

Aquí encontrarán información útil sobre el curso (2do cuatrimestre de 2020)

consultas y/o sugerencias:

- estadistica.burdisso@gmail.com
- [Foro estudiantil](#)

Horarios:

- Clases Teóricas : Martes – Viernes 9 a 11 hs

SITIOS DE INTERÉS

- FCE UBA
- Foro estudiantil
- Gapminder
- Infostat – Programa estadístico
- Libro – Open Intro Statistics
- Libro ¿Qué es (y qué no es) la estadística?
- R – Programa Estadístico

SOBRE NUESTRA IMAGEN DE CABECERA



Dudas o Consultas:
estadistica.burdisso@gmail.com

- Clases en Power Point
- Enunciados TP

Programa: 1er parcial



- **Unidad 1.** La naturaleza de la estadística: Muestreo aleatorio. Experimentos aleatorizados. El experimento ideal. Fuentes y tipos de datos. Datos observacionales vs. datos experimentales. Estructura de los datos: corte transversal, series de tiempo y datos de panel. Análisis exploratorio de datos. Estadística descriptiva. Histogramas, box-plots, diagrama de puntos, series de tiempo. Práctica en planilla de cálculo Excel.
- **Unidad 2.** Métodos de conteo. Probabilidades. Eventos disjuntos. Eventos independientes. Probabilidad condicional. Teorema de Bayes. Distribución de probabilidades. Media y varianza. Variables aleatorias discretas. Bernoulli y la distribución binomial. Desigualdad de Chebyshev. La distribución de Poisson. Distribuciones bivariadas. Covarianza. Correlación. Combinación lineal de variables aleatorias. Variables aleatorias continuas. La distribución uniforme. La distribución normal.

Programa: 2do parcial



- **Unidad 3.** Introducción a la inferencia. Muestreo aleatorio. Parámetro y estimador. La distribución muestral. La forma de las distribuciones muestrales. Ley de los grandes números. Teorema Central del Límite. Muestras pequeñas. Bootstrapping. Introducción a la inferencia vía simulación.
- **Unidad 4.** Inferencia basada en una muestra. Estimación puntual para la media, proporción y varianza. Intervalo de confianza. Test de hipótesis.
- **Unidad 5:** Inferencia basada en dos muestra. Test de hipótesis para dos muestras.
- **Unidad 6:** El modelo de regresión lineal. Método de estimación. Cuadrados mínimos ordinarios. Variabilidad muestral. Intervalo de confianza y test para β . Predicción de Y dado X.
- **Unidad 7:** Números índices de precios y cantidades.

Bibliografía



- Newbold, Paul (2008) . Sexta Edición. Estadística para los negocios y la economía. Pearson. Prentice Hall
- Anderson, D., Sweeney D., y Williams T. (1999). Séptima edición. Estadística para administración y economía. Thomson Editors.
- Wackerly, D., Mendenhall, W. y Scheaffer, R., (2002). Sexta Edición. Estadística Matemática con Aplicaciones. Thomson Editors.
- Harnett y Murphy (1987), Addison- Wesley, Iberoamericana. Introducción al análisis estadístico
- Ross, Sheldon Ross (2007), Introducción a la estadística. Editorial Reverte.
- Levine, David, Krehbiel Timothy y Berenson Mark (2006). Cuarta edición. Estadística para Administración

Bibliografía



- Walpole, R. y Myers, R. (1998). Sexta Edición. Probabilidad y Estadística para Ingenieros. Pearson Educación
- Wonnacott T. y Wonnacott R. (1990). Introductory Statistics for Business and Economics. John Wiley and Sons.
- Diez, D., Barr, C., y Cetinkaya-Rundel, M. (2013). OpenIntro Statistics.
- Canavos, (1988). Probabilidad y estadística. McGraw-Hill
- Rice, J. A. (2007), Third edition. Mathematical Statistics and Data Analysis. Thomson
- Knight, K. (2000), Mathematical Statistics. Chapman & Hall
- DeGroot, M. (4th Edition) Probability and Statistics (Classic Version), Pearson Modern Classics for Advanced Statistics Series
- Apuntes armados en base a diferentes libros en COPY.AR (+54 9 11 6398-8775)

Fechas de parciales, recuperatorios y examen final



- En principio todas las evaluaciones serán **no presenciales/virtuales**.
 - Primer Parcial: sábado 17-10-2020
 - Segundo parcial: sábado 28-11-2020
 - Recuperatorios: viernes 4-12-2020
 - Examen final: viernes 11-12-2020
- Asimismo tendrán 2 (dos) trabajos prácticos en R, TP1 y TP2.

Consignas para la entrega y corrección de los de los TPs en R Studio



- La corrección de los TPs en R Studio estará a cargo de los alumnos. Esta forma de corrección se conoce como “peer review” (corrección entre pares).
- La entrega de los TPs en R son:
 - TP1 hora 0:00 del **lunes 19-10-2020**
 - TP2 hora 0:00 del **lunes 30-11-2020**
- Inmediatamente la cátedra le asigna a cada alumno, 4 (cuatro) TPs anónimos que deberá corregir de acuerdo con la tabla que se muestra a continuación.
- Las fechas de entrega de los “peer reviews” son:
 - TP1 hora 0:00 de **lunes 26-10-2020**
 - TP2 hora 0:00 del **miércoles 9-12-2020**

Consignas para la entrega y corrección de los de los TPs en R Studio



Calificación trabajo práctico R Studio

Nota		Explicación
4/5	Regular	Hizo el esfuerzo de realizar el TP, pero no logra demostrar que comprende los temas enseñados.
6/7	Bien	El trabajo está incompleto. Evidencia conocer algunos temas, pero ha dado respuestas poco precisas.
8/9	Muy Bien	Demuestra dominar los conocimientos de la materia, pero no consigue articular correctamente todas las respuestas.
10	Excelente	Articula de forma precisa las respuestas a todas las consignas, mostrando una clara comprensión de los conocimientos de la materia enseñados

Consignas para la entrega y corrección de los de los TPs en R Studio



- Los TPs deben enviarse a los mails de los docentes que figuran en el campus, antes de la fecha/hora indicada en el punto anterior. El nombre del archivo deberá ser el siguiente:
 - nombre_apellido_TP1
 - nombre_apellido_TP2
- La nota final del **TP surgirá como un promedio de las cuatro (4) calificaciones que cada alumno tendrá de sus pares** . En caso de disconformidad con su calificación, el alumno puede solicitarle a la cátedra que revise su nota.

Reglamento interno de la cátedra para aprobar la materia



- La nota final de la materia se obtiene como un **promedio ponderado de las notas de ambos parciales y de la entrega de los TPs en R Studio.**
- Cada **parcial pondera 40%** de la nota mientras que cada **TP en R Studio pondera 10%.**
- **Para regularizar la materia, es imprescindible tener aprobados ambos parciales** (calificación 4 o más en cada parcial).
- **Para promocionar la materia debe obtener una calificación de 7 o más en cada parcial.**
- En caso de tener algún parcial desaprobado, **la entrega de ambos TP en R no alcanza para regularizar la materia.**

Reglamento interno de la cátedra para aprobar la materia



- Si el **TP no se entrega** (o se entrega sin completar) su **calificación es cero** y pondera en la nota final.
- Si la nota final **es menor a 7 y mayor a 4**, se regularizó la materia y deber rendir **examen final**.
- Hay derecho a un **único recuperatorio**, se haya o no desaprobado un parcial.
- Quienes habiendo aprobado ambos parciales (más de 4 en cada parcial) no les alcanza para promocionar la materia, pueden optar por recuperar el parcial que les permita acceder a la promoción. Está última calificación del recuperatorio es la que cuenta.

Estadística???



- Es un término que suena familiar (medios de comunicación que citan cierto estudio estadístico, encuestas electorales, partidos de fútbol, etc.) Curiosidad: aunque la disciplina es la **estadística**, en estos casos hablamos de **estadísticas** en plural (simplemente recopilación de datos).
- Etimología: proviene del latín *statisticum collegium* (“Consejo de Estado”) y de su derivado italiano ***statista*** (“hombre de Estado o político”). En 1749, el alemán Gottfried Achenwall comenzó a utilizar la palabra alemana ***statistik*** para designar el análisis de datos que recopilaba el estado. Por lo tanto, los orígenes de la estadística están relacionados con el gobierno y sus cuerpos administrativos (v.gr. La gran epidemia de cólera de 1854; la enfermera Florence Nightingale en la guerra de Crimea de 1853)

¿Cuándo las estadísticas pasan a la esfera de la disciplina estadística?



- ¿Qué es la estadística? Muchas definiciones y muy variadas
<http://www.mat.uc.cl/archivos/File/SOBRE.DOCENCIA/A02%20La%20Coexistencia%20de%20Diferentes%20Definiciones%20de%20Estadistica.pdf>
- Posible definición de estadística?: Es una disciplina que trabaja con datos cuyo objetivo consiste en hacer inferencia, mediante técnicas matemáticas y teoría de probabilidades.
bibliotecadigital.ilce.edu.mx/sites/ciencia/volumen2/ciencia3/099/htm/sec_17.htm
- La **estadística es una disciplina imperialista** que puede ser aplicada a casi cualquier ciencia. Se valen de la estadística para entender e interpretar cuestiones que hacen a sus objetos de estudio.

Estadística: ¿una disciplina controversial?




- Tiene mala prensa, a veces se la considera poco seria (Huff, 2011, "Cómo mentir con estadísticas"). Y lo peor es que hay motivos...
- "El 25 % de la población argentina accede a transacciones para tenencia en moneda extranjera. Esta [es una] burda mentira instalada respecto a restricciones al acceso". En particular, el funcionario detalló que 4.798.952 personas accedieron a la compra del dólar ahorro por un monto de 3061 millones de dólares.
- Sin embargo, un ex director del Indec señaló que las declaraciones del funcionario representan "una nueva prueba de la ligereza con que el Gobierno maneja las estadísticas". Respecto del 25% de la población, el ex-director aclaró que **"aquel es el número de operaciones registradas, no de personas"**. Además, "dado que una persona autorizada a comprar por la AFIP pudo haber realizado 12 compras en el año, el total de personas sería de unas 400.000, o sea el 1% de la población total o el 2% de la PEA, que supongo es a lo que se refirió el funcionario".

<http://www.lanacion.com.ar/1758015-para-capitanich-el-cepo-no-existe>

Estadística: ¿una disciplina controversial?



12 de abril 2020



Estadística: ¿una disciplina controversial?



<https://twitter.com/fernandezpablo/status/1249493191944032256?s=09>



Estadística: ¿una disciplina controversial?



- ¿Es una rama de la matemática?
- Fuerte contraste de la estadística vs. la solidez y certidumbre de la matemática.
- La estadística estudia como recoger datos(¿cuántos?, ¿de qué forma?) y cómo analizarlos para obtener información que permita responder las preguntas que uno se plantea.
- Se trata de avanzar en el conocimiento a partir de la observación y el análisis de la realidad, de manera objetiva. Es la **esencia del método científico**.

Primera aproximación a un problema estadístico



- Experimento: **Evaluar la efectividad de los stents en el tratamiento de pacientes con riesgo cerebrovascular.** Los stents son dispositivos que se colocan dentro de los vasos sanguíneos y que ayudan en la recuperación del paciente después de eventos cardíacos. Además reducen el riesgo de un ataque cardíaco adicional o muerte. Muchos médicos tienen la esperanza de que habría beneficios similares para los pacientes de riesgo de accidente cerebrovascular.
- La pregunta clave que los investigadores se hacen es **¿puede el uso de los stents reducir el riesgo de un accidente cerebrovascular?**
- Los investigadores que hicieron esta pregunta recopilaron datos de 451 pacientes en situación de riesgo. Cada paciente voluntario fue asignado al azar a uno de dos grupos:
 - **Grupo de tratamiento.** Los pacientes en el grupo de tratamiento recibieron un stent y atención médica. La atención médica incluye medicamentos, manejo de los factores de riesgo y ayuda en la adquisición de nuevos hábitos saludables.
 - **Grupo de control.** Los pacientes en el grupo de control recibieron el mismo manejo médico que el grupo de tratado, sin recibir los stents.

Primera aproximación a un problema estadístico



- Resultados del estudio

Resultados de los pacientes del estudio del stent

Paciente	grupo	0-30 días	0-365 días
1	tratamiento	no ataque	no ataque
2	tratamiento	ataque	ataque
3	tratamiento	no ataque	no ataque
.	.	.	.
.	.	.	.
.	.	.	.
450	control	no ataque	no ataque
451	control	no ataque	no ataque

Información resumida del estudio del stent

	0 - 30 días		0 - 365 días	
	ataque	no ataque	ataque	no ataque
tratamiento	33	191	45	179
control	13	214	28	199
Total	46	405	73	378

- De los 224 pacientes del grupo de tratamiento, 45 tuvieron un accidente cerebrovascular durante el primer año. Con estos números, calcular la proporción de pacientes en el grupo de tratamiento que tuvo un derrame cerebral durante el primer año. ¿Y en el grupo control?
- Estas proporciones muestran en forma clara y contundente la información de las tablas anteriores.

Primera aproximación a un problema estadístico



- Sorpresa: un 8 p.p.(puntos porcentuales) más de pacientes en el grupo de tratamiento tuvieron un accidente cerebrovascular (grupo control:12%; grupo de tratamiento: 20%)
 - Es contrario a lo que los médicos esperaban
 - Esta diferencia que muestran los datos entre grupos es “real” o “estadísticamente significativa”?
- Esta última pregunta es donde la estadística como ciencia hace su aporte.

Primera aproximación a un problema estadístico



- Supongamos que tenemos una moneda, y la arrojamos 100 veces. La probabilidad de obtener una cara en un lanzamiento cualquiera es de 50%. Pero eso no quiere decir que vamos a observar exactamente 50 caras. Este tipo de fluctuación es parte de casi cualquier proceso generador de datos.
- ¿es posible que los 8 p.p. de diferencia en el estudio del stent sea atribuible a la variación natural de casi cualquier proceso?
- Claramente cuanto mayor sea la diferencia que se observa (para un tamaño de muestra dado) menos creíble resulta que la diferencia se deba al azar.
- Luego la pregunta es: ¿es la diferencia lo suficientemente grande como para rechazar la idea de que fue el azar el culpable de esa diferencia?
- Aún no contamos con las herramientas estadísticas para abordar esta pregunta pero la conclusión del estudio fue: “la evidencia fue convincente del daño de los stents en este estudio de pacientes con riesgo de accidente cerebrovascular.”

Primera aproximación a los datos



- La descripción de los datos es el primer paso en cualquier análisis.
- Hay tres conceptos básicos en un conjunto de datos.
 - Observaciones
 - Variables
 - Matriz de datos

Elecciones a presidente en el estado de Florida - Año 2000


STFIPS	CTYFIPS	CTYNAME	BUSH	GORE	NADER	BUCHANAN
12	1	Alachua	28879	42207	2927	222
12	3	Baker	4872	2035	45	69
12	5	Bay	29668	15523	695	211
12	7	Bradford	4745	2639	73	61
12	9	Brevard	94982	86446	3973	487
12	11	Broward	156847	359233	6511	706
12	13	Calhoun	2490	1885	34	84
12	15	Charlotte	29374	26291	1293	159
12	17	Citrus	23923	21478	1178	230

Matriz de
datos

observación


variables

Primera aproximación a los datos




- **Variables numéricas** (o cuantitativas). Son sensibles a la suma, resta, etc, i.e se pueden realizar operaciones matemáticas con este tipo de variables. Por ej. En la tabla anterior, el número de votos a presidente de alguno de los candidatos
- **Variables categóricas** (o cualitativas). Variables que toman un número limitado de categorías. Las categorías pueden estar identificadas con números pero carece de sentido realizar operaciones matemáticas con este tipo de variables. Por ej. En la tabla anterior CTYFIPS

Primera aproximación a los datos



- **Continua:** Sólo pueden tomar valores numéricos. Por ej. PIB de Argentina
- **Discreta:** Se utilizan para contar. Sólo toman valores **no negativos**. Por ej. La cantidad de votos a presidente de algún candidato de la tabla anterior.

Primera aproximación a los datos



- **Ordinal:** el orden de la categorías es relevante. Por ej. encuestas de satisfacción.
- **Sólo categórica:** No hay orden en las categorías. Por ej. estado civil

Primera aproximación a los datos



Elecciones a presidente en el estado de Florida - Año 2000

Cantidad de votos						
STFIPS	CTYFIPS	CTYNAME	BUSH	GORE	NADER	BUCHANAN
12	1	Alachua	28879	42207	2927	222
12	3	Baker	4872	2035	45	69
12	5	Bay	29668	15523	695	211
12	7	Bradford	4745	2639	73	61
12	9	Brevard	94982	86446	3973	487
12	11	Broward	156847	359233	6511	706
12	13	Calhoun	2490	1885	34	84
12	15	Charlotte	29374	26291	1293	159
12	17	Citrus	23923	21478	1178	230

country	life_exp	inf_mort
Afghanistan	49.72	121.63
Albania	77.59	14.12
Algeria	74.73	24.9
American San	74.44	9.42
Andorra	82.5	3.76
Angola	54.59	83.53
Anguilla	80.98	3.44
Antigua and B	75.69	14.17
Argentina	77.14	10.52
Armenia	73.49	18.21
Aruba	75.93	12.51

- CTYFIPS: **categórica**
- CTYNAME: **texto**
- BUSH, GORE,...: **numérica discreta**

- Life_exp, inf_mort: **numérica continua**

gender	age	maritalStatus	highestQuali	nationality	ethnicity
Male	38	Divorced	No Qualificati	British	White
Female	42	Single	No Qualificati	British	White
Male	40	Married	Degree	English	White
Female	40	Married	Degree	English	White
Female	39	Married	GCSE/O Leve	British	White
Female	37	Married	GCSE/O Leve	British	White
Male	53	Married	Degree	British	White

- Gender, marital status, nationality, ethnicity: **categórica**
- Highest qualification: **categórica ordinal**
- Age: **numérica discreta**

Primera aproximación a los datos



- ¿Qué tipo de variable es un número telefónico?
 - a. numérica continua
 - b. numérica discreta
 - c. categórica
 - d. categórica ordinal

Datos. Fuente y estructura de los datos



- La estadística cuenta con dos tipos de fuente de datos:
 - ***datos observacionales o no experimentales*** : Se recogen los datos sin intervención alguna, i.e. se observan y se colectan.
 - ***datos experimentales***: Asignación aleatoria de los individuos a varios tratamientos.
- Por otro lado, la forma en que estos datos se estructuran son básicamente de dos tipos:
 - ***datos de corte transversal (cross-section)***
 - ***datos temporales*** o de series de tiempo.



Fuente de los datos

- Datos observacionales o **no** experimentales
 - Se recogen los datos sin intervención alguna, i.e. simplemente se observan y se colectan.
 - Los datos observacionales se obtienen de las encuestas, de registros administrativos, de registros históricos, de solicitudes de préstamos, de encuestas telefónicas, etc.
 - Por esa razón, un ejercicio estadístico con datos observacionales es limitado, ya que por lo general, sólo podrá establecer ***asociaciones*** entre las variables y ***no relaciones causales***.



- Datos experimentales
 - Asignación aleatoria de los individuos a los diferentes tratamientos.
 - Por esa razón, un ejercicio estadístico con datos experimentales, podría establecer ***relaciones causales*** entre las variables bajo análisis.
 - Ejemplo 1: Evaluar la efectividad de los stents en el tratamiento de pacientes con riesgo cerebrovascular.

Estructura de los datos



- Si bien los datos pueden ser observacionales o experimentales, la forma en que estos datos se estructuran son básicamente de dos tipos: datos de corte transversal (*cross-section*) y datos temporales o de series de tiempo .
- Hoy en día también están los **datos en panel** que es una combinación de los datos transversales con los datos temporales.

Datos de corte transversal



- Un conjunto de datos transversales consiste en una muestra de individuos, familias, empresas, ciudades, unidades gubernamentales, países, etc. en un punto del tiempo.
- Los datos transversales son ampliamente usados en economía, en marketing y otras ciencias sociales.
- Particularmente en microeconomía: economía laboral, organización industrial, finanzas públicas, economía de la salud, estudios de mercado, etc.
- Los datos transversales nos permiten estudiar relaciones entre variables analizando diferencias a través de los individuos, firmas, u otras unidades económicas.

Datos de corte transversal



- Una característica importante de los datos de corte transversal es que a menudo asumimos que fueron muestreados de manera aleatoria de la población subyacente. Sin embargo a veces el **supuesto de muestreo aleatorio es violado** y aparece lo que se denomina problemas de sesgo por selección (*sample selection problem*).
- Otra violación que suele ocurrir cuando las unidades muestreadas son muy grandes relativas a la población subyacente (i.e. unidades geográficas) **es la ausencia de independencia** de las mismas.

Datos de corte transversal



- Ejemplo: ¿Reducir el número de alumnos mejora la educación primaria? Se examina la relación entre el tamaño de la clase y el aprendizaje de los alumnos, utilizando datos de 420 distritos escolares en California durante 1998.

Algunas variables de los distritos escolares de California

Número de observación	Calificación promedio del distrito	Gastos promedio por estudiante	Ratio alumnos-maestro	Porcentaje de alumnos que aprenden inglés
1	690.8	\$6,385	17.9	0.0
2	661.2	\$5,099	21.5	4.6
3	643.6	\$5,502	18.7	30.0
4	647.7	\$7,102	17.4	0.0
5	640.8	\$5,236	18.7	13.9
6	605.6	\$5,580	21.4	12.4
7	606.8	\$5,253	19.5	68.7
.	.	.	.	.
.	.	.	.	.
417	706.8	\$5,741	17.9	4.7
418	645.0	\$4,403	21.9	24.3
419	672.2	\$4,776	20.2	3.0
420	655.8	\$5,993	19.0	5.0

Datos de series de tiempo



- Los datos de series de tiempo son datos correspondientes a una sola unidad (firma, país, etc.) observados para múltiples períodos de tiempo.
- Ejemplo 1: la tasa de inflación anual de la economía X desde 1980 hasta el 2015
- Ejemplo 2: la tasa de desempleo anual de la economía X desde 1980 hasta 2015

Datos de series de tiempo



- Particularmente, en el caso de la tasa de inflación se utiliza una relación empírica importante que se verifica por lo general, entre la tasa de desempleo y la tasa de inflación. Esta relación macroeconómica, llamada “curva de Phillips”, encuentra que valores bajos de la tasa de desempleo están asociados con un incremento en la tasa de inflación del año próximo.
- Ejemplo: Datos de la tasa de inflación y la tasa de desempleo para los EE.UU. para 167 observaciones en el tiempo. En este caso cada período de tiempo corresponde a datos trimestrales comenzando 1959:II y finaliza en 2000:IV. El número de observaciones se indica con T , que en este caso es $T=167$.

Datos de series de tiempo



Algunas observaciones de las tasa de inflación y desempleo en EE.UU. Datos trimestrales

Nro de observación	Fecha	Tasa de inflación en	Tasa de desempleo
		% - variación interanual (CPI EE.UU.)	en %
1	Jun-59	0.7	5.1
2	Sep-59	2.1	5.3
3	Dic-59	2.4	5.6
4	Mar-60	0.4	5.1
5	Jun-60	2.4	5.2
.	.	.	.
.	.	.	.
181	Jun-04	4.3	5.6
182	Sep-04	1.6	5.4
183	Dic-04	3.5	5.4

A diferencia de los datos de corte transversal, **el orden cronológico** de las observaciones contiene información potencialmente importante

Datos de panel



- ***Datos de panel*** (también llamados **datos longitudinales**) son datos donde cada unidad (individuo, firma, ciudad, etc.) se observa más de un período de tiempo. El número de unidades se denota por **N** y el nro de períodos de tiempo se denota con **T**. El número de observaciones totales está dado por **NxT**.
- Algunos distinguen también los *pooled cross-section*. Se trata de un mix de datos de corte transversal para más de un período de tiempo, donde no necesariamente deben contarse con exactamente los mismos individuos en todos los períodos de tiempo que se observan.

Resumiendo



- Los datos de corte transversal consisten en múltiples unidades observadas en un único período de tiempo.
- Los datos de series de tiempo consisten en una única unidad observada múltiple períodos de tiempo.
- Los datos de panel consisten en múltiples unidades, donde cada uno de ellas es observada dos o más períodos de tiempo.

Efectos causales y el experimento ideal



- Muchas veces el objetivo del analista es tratar de inferir el efecto causal que una variable tiene sobre otra. Encontrar una asociación entre dos o más variables **no necesariamente** permite establecer causalidad entre las variables.
- La relación causa-efecto es bastante más compleja.
- La forma ideal de medir **el efecto causal de una variable sobre otra es mediante la realización de un experimento.**
- Supongamos que se está probando un nuevo fertilizante para la soja. ¿Como se procede?
- Este ejercicio se denomina **experimento aleatorizado controlado**. Se dice **controlado** porque existe un grupo de control (el que no recibe tratamiento) y es **aleatorizada** en el sentido que el tratamiento fue asignado de manera aleatoria.

Efectos causales y el experimento ideal



- Esta asignación aleatoria es la que elimina cualquier posibilidad de una relación sistemática entre, por ej. la cantidad de sol de la subparcela y el fertilizante, de manera que **la única diferencia** entre las subparcelas tratadas y las subparcelas de control **es el tratamiento**.
- Si este experimento se lo implementa en una escala significativa, entonces se podrá obtener cual es el efecto causal de x cantidad de fertilizante sobre el rinde de la soja.
- Este es el experimento ideal (muy común en disciplinas como la biología, la medicina, etc). Sin embargo, en las ciencias sociales rara vez este tipo de experimentos es practicable, ya sea por cuestiones éticas/morales/ legales y/o económicas (pensar por ejemplo el efecto de un año más de educación sobre el salario del individuo).

Efectos causales y el experimento ideal



- Sin embargo, la estadística dispone hoy en día de una herramienta poderosa (el análisis de regresión) para tratar de medir efectos causales sin recurrir al diseño experimental.
- El **análisis de regresión** es una herramienta estadística que utilizada correctamente intenta “simular” el contexto del experimento ideal. De ahí su amplia difusión en la ciencias sociales.

Censo vs. muestra



- Una de las actividades de la estadística es la de extraer conclusiones (inferir) sobre el **todo** mirando sólo una **parte**.
- Pero, no sería mejor disponer del “todo” (llamado población), que sólo de una parte (muestra), i.e. realizar un censo?
 - Mucho más oneroso que un muestreo
 - La logística es muchísimo más compleja
 - La población de interés puede estar cambiando permanentemente.
 - En algunos casos hasta puede resultar impracticable censar.
- El muestreo es la solución natural: **conocer el todo mirando sólo una parte**.

Muestreo



Cuando uno degusta y decimos que le falta sal, lo que estamos haciendo es un **análisis exploratorio**



Cuando luego de degustar concluimos que le falta sal a toda la preparación estamos haciendo **inferencia**

Para que al degustar podamos concluir que el plato puede ser servido, la muestra que tomamos en nuestra cuchara debe ser representativa, i.e. previamente deberíamos haber revuelto bien para que todos los ingredientes y condimentos se mezclen de manera que lo que se degusta sea una **muestra representativa** de toda la comida.

Algunas causas que sesgan una muestra



- **Conveniencia muestral:** individuos/ unidades que son más accesibles y por ende más fácil de ser incluidos en la muestra.
- **No respuesta:** cuando sólo una fracción (no aleatoria) de la muestra responde a la encuesta, invalidando la representatividad de la muestra.
- **Respuestas voluntarias:** ocurre cuando la muestra consiste en un grupo de personas con una posición tomada que accede voluntariamente a responder la encuesta (las típicas encuestas de la web).
- ¿Cuál es la diferencia muestral entre **no respuesta** y **respuesta voluntaria**?

Fuerza bruta nunca más: Landon vs. Roosevelt, EE.UU. (1936)



- Elección presidencial en EE.UU. 1936, Landon vs. Roosevelt. La encuesta fue publicada por Literary Digest. Mostraba que Landon ganaba 57% a 43%. Pero Roosevelt ganó con el 61% de los votos.
- Muestra sesgada: la encuesta se realizó sobre aquellos que poseían teléfonos y/o autos, i.e. en base a estos registros realizaron la encuesta. No se trataba de una muestra representativa de la población americana.

- Fue el mayor sondeo electoral.
- Enviaron 10 millones de cuestionarios
- Recibieron 2.3 millones de respuestas
- El esfuerzo fue enorme y el fracaso aún mayor



- En contraste, una empresa que había sido creada recientemente por George Gallup, acertó el resultado consultando menos de 5000 personas, pero se aseguró de que se tratase de una muestra representativa.

Tabla para determinar la muestra en poblaciones finitas para márgenes de error del 1 al 10% (Fisher, Arkin y Colton)

AMPLITUD DE LA POBLACION	TAMAÑO DE LA MUESTRA SEGÚN MARGEN DE ERROR					
	+ - 1 0,01	+ - 2 0,02	+ - 3 0,03	+ - 4 0,04	+ - 5 0,05	+ - 10 0,10
N	n1	n2	n3	n4	n5	n10
500	--	--	--	--	222	83
1 000	--	--	--	385	386	91
1 500	--	--	638	441	316	94
2 000	--	--	714	476	333	95
2 500	--	1 250	769	500	345	96
3 000	--	1 364	811	520	353	97
3 500	--	1 468	843	530	359	98
4 000	--	1 538	870	541	364	98
4 500	--	1 607	891	546	367	98
5 000	--	1 667	909	556	370	98
6 000	--	1 765	938	566	375	99
7 000	--	1 842	959	574	378	99
8 000	--	1 905	976	580	381	99
9 000	--	1 957	989	584	383	99
10 000	5 000	2 000	1 000	588	385	99
15 000	6 000	2 143	1 034	600	390	100
20 000	6 667	2 222	1 053	606	392	100
25 000	7 143	2 273	1 064	610	394	100
50 000	8 333	2 381	1 087	617	397	100
100 000	9 091	2 439	1 099	621	398	100
+ de 100 000	10 000	2 500	1 111	625	400	100

El poder lo da la aleatoriedad



- A veces los informes sobre los resultados de una encuesta resaltan los cálculos de los niveles de confianza, el margen de error, el tamaño de muestra pero no dicen nada sobre la forma en que se obtuvo la muestra.
- Si **la muestra no es aleatoria** todos los cálculos matemáticos/estadísticos en base a la encuesta carecen de valor.
- Además si la muestra no es representativa, aumentar el tamaño no resuelve el problema.
- Bibliografía utilizada:
 - La certeza absoluta y otras ficciones. Pere Grima (2011)
 - Que és y que no es la estadística. Walter Sosa Escudero (2014)
 - Cómo mentir con estadística. Darrel Huff (2011)

El poder lo da la aleatoriedad



- “Dos semanas después de la elección, la mayoría de las compañías frenaron la difusión de sondeos, entablaron conversaciones con los clientes -que pagan por los informes- y contemplan la **posibilidad de modificar la metodología de trabajo de campo** para intentar obtener resultados que se acerquen más a la realidad.”
- “Una de esas hipótesis, coinciden los consultores, es que hubo una falla importante en una de las metodologías comúnmente utilizadas para hacer encuestas: los llamados a teléfonos fijos. Calificada por algunos como "obsoleta", esa herramienta de investigación otrora representativa hoy tiene un sesgo marcado pues el teléfono fijo fue reemplazado masivamente por el celular y quienes aún lo usan suelen ser adultos mayores pertenecientes a sectores medios y altos. Por eso, las consultoras evalúan hacer ajustes en el uso de esa herramienta, combinarla con otra más confiable o reemplazarla.”
- <https://www.lanacion.com.ar/politica/los-encuestadores-evaluan-cambios-superar-papelon-paso-nid2280291>

El poder lo da la aleatoriedad



La metodología, bajo la lupa

- "El diagnóstico refleja el desafío de hacer relevamientos telefónicos. **La dificultad que tenés es que no llegás a los segmentos de menor edad, de menores recursos económicos y de menor instrucción.** Ahí, te das cuenta de que coincide mucho con el perfil de votantes de Alberto Fernández. Es una tecnología imprecisa en términos de capacidad predictiva", dijo a **LA NACION** un consultor que pasó los días posteriores a las elecciones primarias en comunicación permanente con sus clientes para determinar los pasos a seguir. "Hay una cantidad de cosas que se pueden hacer para calibrar mejor la recolección de los datos, como reforzar las muestras o pedir cuotas más altas. Queda claro que no vamos a usar el mismo sistema con las mismas características porque el resultado te obliga, necesariamente, a revisar eso"
- <https://www.lanacion.com.ar/politica/los-encuestadores-evaluan-cambios-superar-papelon-paso-nid2280291>