

MERCK investiga

BIOESTADÍSTICA **Handbook**

Fundamentos Básicos

Diego H. Giunta

Contenido

1 LA PREGUNTA DE INVESTIGACIÓN

¿Por qué empezar por la pregunta de investigación?	9
¿Cuáles son las características de una buena pregunta de investigación?	9
¿Cómo se utilizan los aspectos de la pregunta?	13
¿Cómo se clasifican las preguntas de investigación?	14
¿Qué estructura tiene una pregunta de investigación?	15
¿Cómo expresar la hipótesis de investigación?	16
¿Cuál es la relación entre pregunta, hipótesis y objetivos?	16
¿Cuántas preguntas tiene un estudio?	17

2 POBLACIÓN

¿Qué es la población del estudio?	19
¿Qué tipos de poblaciones hay?	19
¿En que parte se define la población blanco de un estudio?	21
¿En que parte se describe la muestra?	23
¿Cómo se toma una muestra?	25
¿Cuáles son las diferencias entre los tipos de muestreo probabilístico?	25

3 DISEÑOS DE ESTUDIOS DE INVESTIGACIÓN

¿Qué es un diseño?	29
¿Cómo se clasifican?	29
Con respecto a las unidades de observación	30
Con respecto a la temporalidad	30
Con respecto a la naturaleza de la exposición	31
¿Cuáles son los tipos de diseños más frecuentes?	32
¿Cómo se define un ensayo clínico?	32
¿Qué es el ciego o enmascaramiento?	33
¿Para qué sirve la asignación al azar de tratamiento?	34

¿Cómo se clasifican los ensayos clínicos?	35
¿En qué se diferencian los ensayos clínicos pragmáticos de los clásicos?	37
¿Cómo se define un estudio de cohorte?	38
¿Cómo se define un estudio de casos y controles?	39
¿Qué es el matcheo? ¿Para qué sirve?	40
¿Cómo se define un estudio de corte transversal?	40
¿Cómo se define un estudio ecológico?	41
¿Cuál es el mejor diseño?	42

4 VARIABLES, MEDIDAS DE RESUMEN Y MEDIDAS DE ASOCIACIÓN

¿Qué son las variables?	43
¿Cómo se clasifican las variables?	44
¿Cuánta información contiene cada tipo de variable?	45
¿Cómo se clasifican las variables de acuerdo a su función en el estudio?	46
¿Qué utilidad tiene clasificar las variables?	47
¿Cómo elijo las variables a medir?	47
¿Qué son los parámetros poblacionales y los estimadores muestrales?	48
¿Qué son las medidas de resumen?	49
¿Cuáles son las medidas de resumen para variables cuantitativas?	50
¿Qué son las medidas de frecuencia?	51
¿Qué son las medidas de asociación?	52
¿Cómo se clasifican las medidas de asociación?	52
Otras medidas de asociación	53
¿Cómo se interpretan las medidas de asociación?	54
¿Cómo se interpretan las medidas de asociación relativas?	54
¿Cómo se interpretan las medidas de asociación absolutas?	55

5 AMENAZAS A LA VALIDEZ

¿Qué es la validez de un estudio?	57
¿Qué es la validez interna?	57
¿Qué es la validez externa?	57
¿Cuáles son las amenazas a la validez?	58
¿Qué son los sesgos?	58
¿Qué son los sesgos de selección?	59
¿Cómo minimizo los sesgos de selección?	60
¿Qué son los sesgos de información?	60
¿Cómo minimizo los sesgos de información?	62
¿Qué es el error aleatorio?	62
¿Qué hago con los sesgos?	62
¿Qué son los confundidores?	62
¿Qué hago con los confundidores?	63
¿Qué es el azar de muestreo?	64
Teorema del Límite Central	65
¿Qué es una distribución normal?	67
¿Cuál es el efecto del azar de muestreo?	67
¿Cómo minimizo el efecto del azar de muestreo?	68

6 TEST DE HIPÓTESIS E INTERVALOS DE CONFIANZA

¿Qué es una hipótesis?	69
¿Cuál es la relación entre pregunta e hipótesis?	70
¿Cómo se clasifican las hipótesis?	70
¿Cuáles son los componentes de la hipótesis?	70
¿Qué es la hipótesis nula? ¿Y la hipótesis alterna?	70
¿Qué es una asociación causal?	71
¿Qué es el error Alfa y Beta?	72
¿Qué es un test de hipótesis?	74
¿Cuáles son los componentes de un test de hipótesis?	74
¿Cuántas colas puede tener un test de hipótesis?	76

¿Qué es el p valor?	77
¿Qué son los intervalos de confianza?	77
¿Cómo se interpretan los intervalos de confianza?	79

7 ANÁLISIS ESTADÍSTICO

¿Cuál es el objetivo de la planificación del análisis estadístico?	81
Antes de analizar..	81
¿Qué partes tiene el plan de análisis estadístico?	82
¿Qué es el análisis descriptivo?	83
¿Qué es el análisis bivariado?	84
¿Qué test uso para variables continuas?	85
¿Qué hago si las muestras no son independientes?	87
¿Cómo seleccionar las medidas de asociación?	87
¿Cómo calcular las medidas de asociación?	88
¿Cómo detectar los potenciales confundidores?	89
¿Qué es la modificación de efecto?	90

8 MODELOS DE REGRESIÓN

¿Qué es el análisis de regresión?	91
¿Cuál es el uso de un modelo de regresión?	91
¿Cómo uso los modelos de regresión para predecir?	92
¿Cómo valido los modelos de regresión predictivos?	92
¿Cómo uso los modelos de regresión para ajustar por potenciales confundidores?	93
¿Cuáles son los componentes del análisis de regresión?	94
¿Qué parámetros estima un modelo de regresión?	95
¿Cómo se clasifican los modelos de regresión?	96
¿Cuáles son los supuestos de los modelos de regresión?	98
¿Cómo evalúo los supuestos de un modelo de regresión lineal?	98
¿Qué tipos de variables explicativas se pueden incluir en un modelo de regresión?	100

¿Cómo selecciono las variables para incorporar en el modelo?	101
¿Cómo elijo el mejor modelo predictivo?	101

9 MÉTODOS PARA DATOS CENSURADOS

¿Qué son los datos censurados?	103
¿Cómo registrar datos censurados?	105
¿Qué son los eventos competitivos?	105
¿Cómo describo los datos censurados?	106
¿Cómo comparo dos curvas de supervivencia?	107
¿Cuál es el modelo de regresión para datos censurados?	107

10 ESTUDIOS DE TEST DIAGNÓSTICOS

¿Qué es un test diagnóstico?	109
¿Qué es un estudio de test diagnóstico?	109
¿Qué preguntas responden los estudios de test diagnósticos?	110
¿Qué componentes tienen los estudios de test diagnóstico clásicos?	111
¿Cuáles son las situaciones clínicas específicas de un test diagnóstico?	112
¿Cuáles son las medidas de performance diagnóstica?	113
¿Qué es la curva ROC y para qué sirve?	115
¿Cuáles son los diseños de los estudios de test diagnóstico?	115
¿Cuál es el mejor test diagnóstico?	117

11 ESTIMACIÓN DE TAMAÑO MUESTRAL

¿Necesito estimar el tamaño muestral?	119
¿Cuándo hacer la estimación de tamaño muestral?	120
¿Tamaño muestral en las preguntas descriptivas?	120
¿Qué necesito para realizar una estimación de tamaño muestral para precisión?	121
¿Cómo se modifica el tamaño muestral por precisión?	121

¿Cómo se hace una estimación de tamaño muestral por precisión?	122
¿Tamaño muestral en las preguntas analíticas?	122
¿Qué necesito para realizar una estimación de tamaño muestral para poder?	123
¿Cómo se modifica el tamaño muestral para testear hipótesis?	125
¿Cómo se hace una estimación de tamaño muestral para testear una hipótesis?	125
¿Qué pasa si tengo más de una pregunta de investigación?	126
¿Qué hago si me faltan datos para la estimación del tamaño muestral?	126
¿Qué hago si requiero un tamaño muestral muy grande?	127
REFERENCIAS	129

1

LA PREGUNTA DE INVESTIGACIÓN

¿Por qué empezar por la pregunta de investigación?

La pregunta de investigación es el eje central de un proyecto de investigación. Representa lo que el investigador intenta contestar con un estudio de investigación, el conocimiento nuevo que se pretende generar. Respondiendo a las preguntas de investigación, la comunidad científica conoce y construye la realidad. En la investigación en salud, las preguntas de investigación tienen el fin de conocer para mejorar el cuidado de la salud de las poblaciones e individuos. Desde este rol clave y central, la pregunta de investigación es el primer paso de una investigación. Es el componente principal e inicial de cualquier proyecto de investigación, tanto en la construcción de proyectos o reportes de estudios de investigación. Una adecuada estructura y apropiado proceso de generación de la pregunta asegurará la construcción de un proyecto sólido fundamentado en los conocimientos disponibles. Asimismo, es el componente principal a identificar en el primer paso de la lectura crítica de un artículo científico.

Algunas preguntas de investigación podrían ser ¿Cuál es la sobrevida de los pacientes con fibrosis quística? ¿El tratamiento con antihipertensivos disminuye la sobrevida de los pacientes hipertensos adultos? ¿Cuáles son las barreras y facilitadores para dejar de fumar en los fumadores de áreas rurales? ¿Los agroquímicos causan cáncer? A estas preguntas les faltaría madurar y refinarse.

La pregunta puede surgir de la experiencia del investigador, nuevas ideas o nuevas aproximaciones a nuevos problemas, estudios previos, creatividad propia para asociar distintas observaciones, evaluación crítica de la literatura, entre otros. Cualquiera sea el origen de la pregunta, deberá cumplir con ciertos requisitos y propiedades para convertirse en el centro de un proyecto de investigación.


¿Cuáles son las características de una buena pregunta de investigación?

La pregunta de investigación debe poseer ciertas características para ser adecuada como eje de un proyecto de investigación. Las principales características de la pregunta de investigación se pueden recordar por las siglas FINER-P, modificado de la propuesta de Hulley.^[1] Representan las principales caracterís-

ticas que debería tener una pregunta de investigación para ser el mejor eje de un estudio: Factible, Interesante, Novedoso, Ético, Relevante, y Biológicamente Plausible.

Es interesante notar que la evaluación de estos aspectos se realiza en un contexto sociocultural en un determinado lugar y tiempo. En diferentes momentos de la historia, estas características varían para una misma pregunta. Por ejemplo, una pregunta novedosa en un determinado momento de la historia de la ciencia como ¿Fumar causa cáncer?, no sería novedosa ni ética en el día de hoy.

Figura 1: Características de una buena pregunta de investigación.



A continuación, presentaremos una breve descripción de cada una de las características cambiando el orden en sentido uno de los muchos órdenes de relevancia propuestos para los mismos aspectos:

ÉTICA

El primer aspecto a considerar es la ética de la pregunta de investigación. Desde el punto de vista del contenido de la pregunta, una pregunta es ética cuando respeta todos los principios éticos: no maleficencia (no causar daño), justicia (igualdad de oportunidades para todos), benevolencia (intención de hacer el bien) y autonomía (respetar la decisión de participar en el estudio de los individuos).

Todas las preguntas y proyectos de investigación biomédica deben estar en total concordancia con el Código de Nüremberg de principios éticos sobre la experimentación en seres humanos publicado en 1947 luego de los juicios de Nüremberg de 1945 - 1946^[2], la Declaración de Principios éticos para las investigaciones médicas en seres humanos de Helsinki de la Asociación Médica Mundial y enmiendas posteriores,^[3] las guías de Buenas Prácticas Clínicas de la de Conferencia Internacional de Armonización ICH,^[4] la normativa y legislación regulatoria local.

FACTIBLE

Es importante evaluar de manera precoz si podemos llevar a cabo el proyecto. Por ejemplo, muchas veces las preguntas de investigación para ser contestadas requieren un número elevados de participantes y si no tenemos manera de incluir dicho número, la factibilidad del estudio se verá amenazada. Los componentes de la factibilidad son la ética, la complejidad y los recursos.

Los recursos implican cantidad de pacientes, tiempo disponible, recursos económicos, humanos, materiales, entre otros. La complejidad del estudio es un componente fundamental. Los estudios más simples tienen menos componentes que pudieran fallar y son más fáciles de diseñar, implementar y maximizar su calidad.

INTERESANTE

La pregunta debería ser interesante para el investigador, su equipo de trabajo, la comunidad científica, los pacientes y la salud pública. La motivación probablemente sea uno de los recursos más importante por lo cual es fundamental que la pregunta, eje de la investigación, resulte interesante para el investigador y su equipo también. El desarrollo de una pregunta madura, el diseño, la implementación y el reporte de los resultados lleva mucho tiempo y esfuerzo, por lo cual es fundamental mantener el interés del investigador y su equipo. Si bien toda pregunta que apunte hacia un área de desconocimiento es fundamental para el crecimiento del conocimiento universal, si existe poco interés de la comunidad científica es probable que sea más dificultoso el financiamiento y su difusión. Dado que el objetivo de la investigación clínica y epidemiológica es conocer la realidad para mejorar la salud de la población, esto no debiera ser un inconveniente sino una consideración.

NOVEDOSA

¡La pregunta debe contribuir nuevo conocimiento!

Sea cual sea la pregunta de investigación es fundamental que no esté respondida en la literatura. No tiene sentido desperdiciar recursos en contestar una pregunta cuya respuesta se encuentra al alcance de cualquier búsqueda bibliográfica. La gran mayoría de las preguntas que podríamos formularnos en realidad son falta de lectura o de búsqueda bibliográfica adecuada. Existe mucho más conocimiento generado del que aplicamos en la práctica diaria.

Por supuesto se podría contestar una pregunta que ya fue contestada sólo si tenemos razones para creer que la respuesta no es definitiva o concluyente. Por ejemplo si los resultados de otros estudios son contradictorios y ninguno es concluyente definitivamente, si podemos identificar errores o amenazas a la validez de los resultados, o si tenemos suficientes razones para pensar que nuestra población se comporta de manera diferente que la población donde se estudió la pregunta. Otra razón es confirmar resultados de estudios ya que todo resultado está sujeto a errores por el fenómeno de azar de muestreo (error alfa y error beta).

Además de la ineficiencia de montar un estudio de investigación con todo el costo en recursos que implica, no sería ético implementar un proyecto de investigación para contestar un interrogante cuya respuesta se conoce con certeza. No es ético si se quiere interrogar pacientes en el marco de una investigación, que probablemente no reciban beneficios directos de participar, ni tampoco generará beneficios indirectos en otros pacientes con similares características ya que no se generará ningún conocimiento nuevo. Sólo se repetirán los hallazgos ya conocidos.

Un problema adicional lo constituyen las preguntas ya contestadas y no publicadas. Si nuestra pregunta ya se evaluó pero por algún motivo no se difundió el resultado (en EEUU 20% de los estudios realizados nunca se difunden y más del 50% de las presentaciones en congresos)^[5], irremediablemente repetiremos un mismo estudio para obtener la misma respuesta. ¡Asegurémonos en este caso de difundir nuestros resultados!^[6]

RELEVANTE

El esfuerzo requerido para responder una pregunta de investigación hace que sea fundamental que la pregunta sea relevante para el conocimiento científico, para políticas de salud o para futuras investigaciones.

Una buena manera de evaluar si una pregunta es relevante es considerar cuánto aportará nuestra pregunta al avance científico, si aporta a las políticas actuales de salud o guiar a futuras investigaciones.

¡El solo hecho de que la pregunta carezca de respuesta hace que sea relevante! Si bien no debiera ser un impedimento que la pregunta no tuviera una relevancia obvia de gran impacto, se puede modificar las preguntas para que se encuentren dirigidas al aspecto más relevante del área de desconocimiento.

Obviamente si el conocimiento se basara sólo en los visionarios que contestaron preguntas de máxima relevancia en un determinado paradigma de conocimiento, ¡el conocimiento no habría llegado tan lejos! Las preguntas más irrelevantes pueden tener implicaciones inesperadas que pueden tener un alto impacto en el futuro o en otros contextos.

PLAUSIBILIDAD BIOLÓGICA

¿Es posible construir un mecanismo biológico o de otra naturaleza que una la exposición con el evento? Una pregunta que permita identificar el concatenado de eventos biológicos que relacionan la exposición con un evento será mejor.

Esta característica es un agregado a los criterios FINER originales. Es una de los postulados de Bradford Hill para identificar asociaciones causales.^[7,8] En nuestra opinión, es un aspecto valioso a considerar durante la construcción de una pregunta de investigación. La revisión y reflexión sobre el mecanismo biológico tiene un impacto directo en la maduración y construcción de preguntas de investigación.

En algunos casos se conocerá perfecto en un determinado momento todos los mecanismos implicados. En otros casos no se conoce completamente los mecanismo, pero puede ser vital revisar la biología relacionada con la pregunta para al menos estar seguro que lo que se conoce al respecto no contradice nuestra pregunta de investigación. Por ejemplo, se conocen perfectamente los eventos que deben ocurrir en el desarrollo de un cáncer de colon. En otros casos puede no conocerse tan acabadamente los mecanismos por los cuales se desarrolla un determinado síntoma del espectro autista en ciertas ocasiones. La cantidad de conocimiento relacionado que permite armar un mecanismo biológico, cambia con el momento histórico. La plausibilidad es un concepto que es extensible a cualquier otro tipo de pregunta que implique otro mecanismo que podría ser descrito como plausibilidad como por ejemplo psicológica, social, antropológica o física que sea necesario para relacionar una exposición con un resultado.

¿Cómo se utilizan los aspectos de la pregunta?

Es esperable que los aspectos enunciados se superpongan y en ocasiones sea difícil distinguir cual de los aspectos se está discutiendo. No es nuestra intención revisar las características de la pregunta como si fueran estancas, exhaustivas y excluyentes. Estos aspectos son una guía que sirve para reflexionar sobre las preguntas de investigación, refinar y madurarlas. Durante la etapa de construcción de una pregunta de investigación, suelen coexistir varias preguntas similares relacionadas. En esta situación, estos atributos de la pregunta sirven para se-



leccionar cuál es la mejor pregunta para ser eje de un trabajo de investigación. A su vez, es posible modificar la pregunta para que sea dirigida hacia un área de desconocimiento o de mayor relevancia, mayor interés o mayor factibilidad. Es ideal que en la selección de la pregunta eje del proyecto se intente maximizar todos los aspectos mencionados en la tabla anterior. Aunque es claro que no es posible maximizar todos estos aspectos a la vez. La pregunta más relevante puede no ser factible. La que más me interesa puede no ser la más novedosa. Por ejemplo, podría ser que la pregunta que me resultara más interesante ¿la observación de ciertas imágenes, genera cambios en la activación de ciertas áreas corticales del cerebro?, no sea factible por falta de disponibilidad de recursos para hacer resonancias magnéticas funcionales en tiempo real. Podría reformular para ver el impacto sobre el ánimo a través de un cuestionario de autocompletado. Este cambio de la pregunta, podría hacer más factible un estudio de investigación cambiando la variable de resultado.

Si mi pregunta específica fuera ¿Cuál es la frecuencia de enfermedades oncohematológicas en los pacientes con Lupus Eritematoso Sistémico? Pero, si la frecuencia fuera muy baja de nuevos casos de enfermedad oncohematológicas, podríamos modificar por enfermedades oncológicas. ¿O tal vez por todas las enfermedades autoinmunes como población? Este cambio de evento o de población modifica la pregunta dramáticamente, pero acerca la factibilidad.

¿Cómo se clasifican las preguntas de investigación?

Existen formas diferentes de clasificar las preguntas de investigación. Por ejemplo, las preguntas de investigación pueden ser clasificadas en descriptivas o analíticas. En las preguntas descriptivas, el investigador se pregunta cómo es algo en particular. ¿Cómo es la frecuencia? ¿Cuál es la prevalencia? ¿Cuál es la incidencia? ¿Cómo es el tiempo al desarrollo de un determinado evento? ¿Cuáles son los factores de riesgo para el desarrollo de una condición? ¿Y los factores protectores?

Las preguntas descriptivas en sí no puede transformarse en una hipótesis directamente. Siempre se responden estimando un parámetro poblacional. Como la frecuencia de una determinada característica; en estos casos, se espera que en los resultados de una pregunta descriptiva se presente la estimación del parámetro que se pretendía conocer, acompañado de intervalos de confianza.

Por el contrario, las preguntas analíticas son preguntas de asociación entre dos variables. Naturalmente tienen la estructura de una hipótesis evaluable (o testeable), por lo cual es fácil expresarlas como hipótesis. En este caso existe asimetría entre las variables de la pregunta, una funciona como una variable de exposición y otra como una variable de respuesta. ¿Los pacientes tratados con la droga 1 tienen mejor calidad de vida que los pacientes tratados con la droga 2? En este caso, las drogas 1 o 2 son la exposición, y la calidad de vida es la respuesta.

Las preguntas causales son analíticas. Por ejemplo ¿La exposición a plastificantes en la comida causa síndrome metabólico? ¿La exposición solar controlada y breve causa fotoenvejecimiento? ¿Es un determinado tratamiento más eficaz y seguro para controlar la hipertensión arterial? No toda pregunta analítica es causal ¿La eritrosedimentación extremadamente elevada es un factor pronóstico de mortalidad?

En la respuesta a una pregunta analítica debería haber una medida de asociación. La medida de asociación brinda mucha información: direccionalidad, y magnitud de la asociación entre la variable de exposición y la variable de respuesta. A su vez, nos interesara saber el p valor como resultado de un test de hipótesis para evaluar la pregunta analítica o los intervalos de confianza de la medida de asociación. Ambos métodos brindan información similar sobre los resultados de una pregunta analítica.

¿Qué estructura tiene un pregunta de investigación?

Las preguntas descriptivas responden a la estructura simplificada ¿Cómo es A en C? donde A es lo que interesa conocer y C la población blanco a la que se pretende generalizar los resultados. ¿Cómo es la sobrevida libre de enfermedad de los pacientes con estadio 4 de cáncer de pulmón en Latinoamérica?

Las preguntas analíticas responden a la estructura general simplificada ¿A se asocia a B en C? donde A es la variable de exposición, B la variable de resultado y C la población blanco. ¿La estrategia educativa centrada en aprendizaje basado en problemas genera conocimiento más significativo en estudiantes de secundario en Argentina?

Para las preguntas analíticas se puede utilizar el acrónimo PICOTS para enunciar todos los componentes necesarios: Población, Intervención/exposición, Comparador, Outcome/resultado, Temporalidad y Escenario (setting).^[9] Por supuesto el orden de los componentes no es lo importante, sino su presencia o ausencia. Este acrónimo fue propuesto en el marco de la lectura crítica de las prácticas basadas en la evidencia, con foco en estudios experimentales.^[10] De ahí su estructura y su máxima utilidad para estudios con preguntas analíticas y experimentales. Es una herramienta útil para la presentación transparente y completa de preguntas analíticas.

Es fundamental remarcar que toda pregunta tiene una población de referencia C. La población blanco a la que se pretende generalizar los resultados. A los fines de la claridad, se omitió la población en la gran mayoría de las preguntas de juguete presentadas en este apartado. Intente identificar los componentes de las preguntas de ejemplo.

¿Cómo expresar la hipótesis de investigación?

La hipótesis es una afirmación que hace el investigador antes de conducir la investigación, como respuesta a la pregunta central del estudio. Siempre es una afirmación y tiene el mismo contenido que la pregunta analítica: A se asocia a B en C, donde A es la exposición, B es la variable de resultado y C la población blanco. Por ejemplo la pregunta de mi estudio puede ser ¿A mayor índice de masa corporal es mayor la mortalidad de origen cardiovascular? Y la hipótesis de mi estudio sería la afirmación “A mayor índice de masa corporal la mortalidad de origen cardiovascular es mayor”. Las hipótesis simples son las que tienen sólo una exposición y sólo una variable de respuesta. Las que tienen más de uno de estos componentes se llaman hipótesis complejas.

Esta estructura específica, permitirá aplicar métodos estadísticos específicos. Por esta razón, muchas veces se las llama hipótesis en sentido estadístico. Aplicando esta definición, las preguntas descriptivas no tienen hipótesis en este sentido.

Una hipótesis específica puede ser verdadera o falsa, pero no las dos cosas a la vez. Es posible utilizar métodos estadísticos para testear cuál es la probabilidad de que una hipótesis sea verdadera utilizando un estudio de investigación. Se llama inferencia a este método de obtener información en una muestra para sacar conclusiones sobre el comportamiento de una población blanco. En este caso utilizaremos la información de los individuos incluidos en la muestra de un estudio, para evaluar si la hipótesis es verdadera o falsa en la población blanco de la cual proviene la muestra. Esto se realiza a través de un procedimiento que se llama testeo de hipótesis que describiremos más adelante.

En muchos casos se utiliza el término hipótesis del estudio en un sentido más amplio que el estrictamente formal que acabamos de enunciar. En estos casos, se utiliza hipótesis como sinónimo de lo que el investigador espera encontrar *a priori*. En estos casos, no es exclusiva de las preguntas analíticas. El investigador podría decir “Nuestra hipótesis es que el índice de masa corporal incrementa la mortalidad debido a ...” Lo que el investigador cree que va a pasar con los resultados no requiere métodos estadísticos específicos.

¿Cuál es la relación entre pregunta, hipótesis y objetivos?

En general pregunta, hipótesis y objetivos expresiones de lo mismo. Deben estar 100% alineados en un determinado estudio. No es esperable que los componentes sean totalmente diferentes entre los tres. Los objetivos son acciones concretas alineadas con las preguntas del estudio.

Para la pregunta descriptiva ¿Cuál es la prevalencia de obesidad entre los estudiantes de medicina en Ciudad Autónoma de Buenos Aires?, es esperable un objetivo “Estimar la prevalencia de obesidad entre los estudiantes de medicina en Ciudad Autónoma de Buenos Aires”. En este caso no hay una hipótesis predefinida.

La pregunta analítica ¿Es mayor la prevalencia de obesidad en los estudiantes de medicina que en los estudiantes de abogacía de Ciudad Autónoma de Buenos Aires? En este caso una hipótesis apropiada podría ser “La prevalencia de obesidad en los estudiantes de medicina es mayor que en los estudiantes de abogacía de Ciudad Autónoma de Buenos Aires”. El objetivo podría ser “Evaluar la asociación entre obesidad y estudiar medicina o abogacía en estudiantes universitarios de Ciudad Autónoma de Buenos Aires”. ¿Qué componentes de PICOTS faltan en este caso?

¿Cuántas preguntas tiene un estudio?

Un estudio tiene idealmente una pregunta central, la cual es la pregunta principal eje del estudio. El protocolo de una propuesta de investigación se construirá sobre una pregunta central. En sentido estricto el protocolo es el método que se utilizara para contestar una pregunta de investigación. En este sentido contendrá todas las decisiones que se toman para contestar la pregunta. Se seleccionará el diseño más apropiado a la pregunta central; la población más adecuada a la pregunta central; los métodos estadísticos más apropiados a la pregunta, y todo el resto de las decisiones en función de contestar la pregunta central del estudio. Esta es la razón por la cual la pregunta es el eje del protocolo y del estudio de investigación.

Preguntas adicionales pueden requerir diseños diferentes, muestreos diferentes, poblaciones diferentes, tamaños muestrales diferentes. En este caso puede que los componentes del protocolo queden desalineados con las preguntas y objetivos. Si el protocolo tiene múltiples preguntas, es fundamental que al menos requieran el mismo diseño, la misma población y el resto de materiales y métodos definidos para contestar las preguntas adicionales.

Es un error muy común intentar responder más de una pregunta con un estudio de investigación. La mejor opción es definir una pregunta central única. Es una práctica ineficiente intentar contestar más de una pregunta de investigación con un mismo estudio. En general genera desprolijidades y es difícil alinear todos los componentes del estudio a varias preguntas de investigación a la vez, como es esperable.

Por ejemplo un estudio cuya pregunta central es ¿La exposición a concentraciones altas de partículas ambientales genera mayor cantidad de exacerbaciones de enfermedad pulmonar obstructiva crónica (EPOC) en pacientes con EPOC? Tiene implícito los siguientes objetivos que corresponden a preguntas accesorias necesarias para responder de manera apropiada la pregunta central del estudio:

- Evaluar la asociación entre la exposición a concentraciones altas de partículas ambientales y cantidad de exacerbaciones de EPOC en pacientes con EPOC.

- Estimar la exposición a concentraciones altas de partículas ambientales.
- Estimar la frecuencia de exacerbaciones de EPOC en pacientes con EPOC.
- Describir las principales características de los pacientes con EPOC/las exacerbaciones.
- Es claro que algunas son objetivos principales y otros secundarios.
¿Cuáles y por qué?

¿Qué es la población del estudio?

Según Leon Gordis, la epidemiología es el estudio de la distribución y determinantes de los estados relacionados con la salud o eventos en poblaciones específicas y su aplicación al control de los problemas de salud, con el fin de maximizar la salud de las poblaciones.^[11,12] Podríamos definir la población como un conjunto de individuos con características específicas, referidas a un espacio y tiempo.^[11] Las características específicas podrían referirse a una condición clínica, una exposición, una enfermedad, un subgrupo de individuos o cualquier otro segmento sobre el que interese conocer su comportamiento. En sentido más amplio se puede llamar población al conjunto de unidades de observación. En esta última definición, se incluyen unidades de observación que podrían corresponder a conjuntos de individuos o el mismo individuo en diferentes momentos o incluso situaciones diferentes.

El método epidemiológico que utilizamos para contestar preguntas de investigación, requiere que seamos específicos con la población bajo estudio. Las preguntas de investigación están siempre referidas a una población. Las preguntas descriptivas quieren conocer cómo se comporta un determinado parámetro en una población. Las preguntas analíticas se preguntan si una asociación es verdadera en una determinada población.

No existe pregunta que no esté referida a una determinada población. De la misma manera los resultados de un estudio en particular se extrapolan a una determinada población. Esta es la razón por la cual debe quedar definida con claridad tanto en el protocolo como en un artículo de investigación.

¿Qué tipos de poblaciones hay?

Considerando una pregunta específica, en general se describen 3 tipos de población: la población blanco, la población accesible y la muestra. Describiremos la población para la pregunta ¿La broncoaspiración se asocia con mayor severidad de las exacerbaciones de los pacientes con EPOC?

La población blanco es la población sobre la que se quieren generalizar los re-



sultados y por lo tanto, las preguntas se plantean siempre sobre esta población. La población blanco se describe por características clínicas y demográficas y está formada por todos los individuos con una determinada característica, incluyendo los que la tuvieron, los que la tienen y los que la van a tener. Con esta definición operativa, ni siquiera los censos representan la totalidad de una población blanco.


Desde este punto de vista, la población blanco es teórica e inabarcable. No es posible siquiera conocer qué tamaño tiene, ni conocer nada sobre su comportamiento. En nuestro ejemplo, la población blanco serían todos los pacientes con EPOC, incluyendo los que van a tener desde el momento que lo desarrollen, los que tienen y conocen su diagnóstico en la actualidad, los que no y los que tuvieron EPOC en el pasado. Esta forma de definirla, implica que si conozco algo sobre esta población blanco, podré generalizar lo que conozca al próximo paciente con esa condición que diagnostique. En esto nos basamos en la toma de decisiones clínicas en el consultorio o en cualquier ámbito permanentemente.

La población accesible es una parte de la población blanco que está disponible y potencialmente podría incluirse en el estudio. Se define por características geográficas, temporales y de accesibilidad. Por ejemplo: todos los EPOC de la Ciudad Autónoma de Buenos Aires en 2017 podría ser una población accesible. Probablemente todos los EPOC asistidos en un determinado centro de salud de la Ciudad Autónoma de Buenos Aires en 2017 sea una población accesible mejor definida.

La muestra corresponde a la fracción de la población accesible que efectivamente se incluye en un determinado estudio. La muestra es lo opuesto a la población blanco en el sentido de que puedo conocer todo: su tamaño, la distribución de los diferentes factores, su comportamiento y sus características. En general, tiene un tamaño definido previamente de acuerdo a la estimación de tamaño muestral. Si tomo 100 pacientes de la población accesible y los invito a participar de mi estudio, ellos constituirán mi muestra.

La muestra tiene la ventaja de ser tangible y es posible obtener mediciones concretas de las variables que le interesan al investigador a los fines de responder su pregunta. A través de las mediciones que se realizan en la muestra, utilizando métodos estadísticos, podremos hacer inferencia sobre lo que ocurre en la población blanco. Esta es la razón por la cual es fundamental que la población accesible represente lo que ocurre en la población blanco y de igual manera, que la muestra represente lo que ocurre en la población blanco.

Figura 2. En A se muestra la relación entre la población blanco, población accesible y muestras. Se espera que la muestra del estudio represente el mismo fenómeno que ocurre en la población blanco. Para que eso ocurra debe haber una correspondencia perfecta entre lo que ocurre en la población blanco y lo que observo en mi muestra. En la figura B se muestra un esquema que representa una tabla de doble entrada en la población blanco y la misma proporción exacta de cada cuadrante en la población accesible y la muestra.



¿En que parte se define la población blanco de un estudio?

La pregunta de investigación define la población blanco del estudio. A su vez, se repite en la hipótesis y los objetivos. Al responder esta pregunta, esta será la población a la cual se extrapolan los resultados de un estudio.

La población blanco se define con precisión en los criterios de inclusión. Los criterios de inclusión son las condiciones que debe cumplir una unidad de observación para ser elegible para participar de un estudio de investigación. Los criterios de inclusión deben definir sin ambigüedades las características que se debe tener para pertenecer a la población blanco sobre la que se intenta constatar una pregunta de investigación. La población accesible a su vez se describe principalmente en los criterios de inclusión también.

Los criterios de exclusión en general responden al respeto por los principios éticos de autonomía, y no maleficencia, restricción como método para controlar potenciales confundidores y decisiones prácticas (problemas con accesibilidad, comprensión, adherencia, entre otros). Los dos primeros son necesarios y fundamentales. Los dos segundos pueden potencialmente generar sesgos y es muy importante considerarlos con cuidado antes de utilizarlos o al leer un artículo de investigación.

Se respeta la autonomía cuando se deja explícito en los criterios de exclusión que no se va a incluir participantes que no decidan libre e informadamente su participación en el estudio. Se respeta el principio ético de no maleficencia cuando se excluyen los participantes que pudieran tener algún perjuicio por la participación en el estudio o pudiera comprometer su seguridad. En los estudios experimentales es fundamental que un comité de ética evalúe y apruebe la relación entre los beneficios y los riesgos de la participación en el estudio.

Para la pregunta ¿la droga A previene las exacerbaciones de EPOC en pacientes adultos con EPOC?, los criterios de inclusión deben tomar una definición validada de EPOC de acuerdo a la mejor evidencia conocida, características demográficas acordes (como podría ser mayores a 60 años), que se atiendan en el Centro de Salud D de la Ciudad Autónoma de Buenos Aires durante 2017. Los criterios de exclusión podrían ser la negativa a participar o al proceso de consentimiento informado, hipersensibilidad conocida o sospechosa a la droga A o sus componentes, contraindicaciones para recibir A. A su vez podría restringir mi estudio a no fumadores que vivan en la ciudad, cerca del centro de salud donde se realizará el estudio.

Ser adherente habitual en la toma de medicación o estar cerca del centro donde se realiza el estudio son criterios que se suelen agregar a los criterios de exclusión del estudio con el fin de mejorar la eficiencia y disminuir la pérdida de los participantes. Este tipo de criterios de exclusión comprometen la forma en que la muestra representa la población blanco ¿Por qué?

A su vez en ocasiones se restringe el grupo etario del estudio a una población poco mórbida donde los eventos graves como la muerte son extremadamente improbables, por ejemplo, Pacientes entre 60 y 75 años. Este tipo de restricción en la edad o las comorbilidades hace que luego los resultados no sean extrapolables a los pacientes muy ancianos o con comorbilidades. Ambos grupos son muy frecuentes en la práctica clínica cotidiana.

Nunca los criterios de exclusión son la negativa de los criterios de inclusión. Los criterios de exclusión son las excepciones. Si un participante coincide con los criterios de inclusión, si presenta al menos un criterio de exclusión está excluido del estudio.

Figura 3. En este ejemplo se muestra una descripción de criterios de inclusión y de exclusión: *Spontaneous bacteremia and spontaneous bacterial peritonitis share similar prognosis in patients with cirrhosis: a cohort study.** Este es un resumen de los criterios detallados ampliados que se detallan en el protocolo del estudio.

Inclusion criteria were patients older than 17 years with cirrhosis (based on liver biopsy, or a combination of clinical signs and findings provided by laboratory tests, endoscopy, and radiological imaging) and diagnosis of a first episode of either spontaneous bacteremia or spontaneous bacterial peritonitis. Spontaneous bacteremia was defined as growth of a noncommon skin contaminant in ≥ 1 blood cultures, without evidence of infection located at another body site. All patients with spontaneous bacteremia and ascites underwent ascitic fluid analysis and culture to rule out spontaneous bacterial peritonitis or bacterascites. Patients in whom analysis of ascitic fluid was not possible for the catheter-related bloodstream infection were also excluded. Spontaneous bacterial peritonitis was defined as absolute polymorphonuclear count ≥ 250 cells/mm³ in ascitic fluid without an evident intraabdominal, surgically treatable source of infection. Exclusion criteria included at least one prior episode of spontaneous infection (spontaneous bacterial peritonitis, spontaneous empyema, or spontaneous bacteremia), concomitant bacterial infection at time of inclusion, history of liver or other organ transplantation, advanced hepatocellular carcinoma according to Barcelona Clinic Liver Cancer classification, and infection with human immunodeficiency virus. Patients were

* Marciano S, Dirchwolf M, Bermudez CS, Sobenko N, Haddad L, Genre Bert F, et al. *Spontaneous bacteremia and spontaneous bacterial peritonitis share similar prognosis in patients with cirrhosis: a cohort study.* *Hepatol Int.* 2017; doi:10.1007/s12072-017-9837-7. Con permiso de los autores

¿En que parte se describe la muestra?

Los individuos que forman parte de la muestra deben cumplir todos los criterios de inclusión y no tener ningún criterio de exclusión. Sólo se tiene una muestra cuando el estudio finaliza. La sección de resultados de un artículo científico empieza con un diagrama de flujo que presenta la población accesible y la muestra del estudio.^[13,14] Asimismo también suele brindar información de la permanencia en el estudio. Tanto el ingreso como la permanencia en el estudio son fundamentales para asegurar que la muestra representa la población blanco y evaluar la potencial presencia de sesgos de selección.

La descripción de la muestra se realiza en el análisis descriptivo de la misma sección resultados. Describir la muestra del estudio permite al lector conocer cuál es la verdadera población que se terminó incluyendo en el estudio. Esta información nos permite rápidamente saber si los resultados del estudio son extrapolables a la población sobre la cual quisiera aplicar los resultados. Si el estudio incluyó sólo pacientes EPOC entre 55 y 70 años sin comorbilidades, y en la primer tabla del artículo todos tienen cerca de 60 años ¿a qué población blanco son generalizables los resultados? ¿Puedo aplicar los resultados a mis pacientes de consultorio? ¿A cuáles?

*Figura 4. Este es un ejemplo de descripción en una tabla de los resultados del mismo artículo que presentamos anteriormente: Spontaneous bacteremia and spontaneous bacterial peritonitis share similar prognosis in patients with cirrhosis: a cohort study.**

Table 1. Baseline characteristics of entire study population, and according to type of infection (spontaneous bacteremia or spontaneous peritonitis), at Hospital Italiano from 2008 to 2016 (n=126)

Variable	All (n=126)	Spontaneous bacteremia (n=71)	Spontaneous bacterial peritonitis (n=55)	p
Age (years)	63 (53-69)	62 (53-69)	65 (51-69)	0.83
Male gender	73 (58%)	42 (59%)	31 (56%)	0.75
Cirrhosis etiology				
Viral hepatitis	39 (31%)	27 (38%)	12 (22%)	0.17
Alcohol	28 (22%)	15 (21%)	13 (24%)	
Autoimmune hepatitis	16 (13%)	9 (13%)	7 (13%)	
Primary biliary cholangitis	13 (10%)	5 (7%)	8 (15%)	
Other	30 (24%)	15 (21%)	15 (26%)	
HCC	23 (18%)	12 (17%)	11 (20%)	0.65
Ascites	106 (84%)	51 (72%)	55 (100%)	<0.001
Creatinine (mg/dL)	1.1 (0.8-1.6)	1 (0.8-1.4)	1.3 (0.8-1.9)	0.041
Leukocyte count (x 10 ³ /mm ³)	7.6 (5.0-10.1)	7.3 (4.7-9.4)	7.8 (5.6-12.1)	0.24
Total bilirubin (mg/dL)	4.4 (2.1-7.6)	3.8 (1.9-6.1)	6.4 (3.1-9.0)	0.003
Serum albumin (g/dL)	2.6 (2.2-2.9)	2.6 (2-3)	2.6 (2-3)	0.74
INR	1.8 (1.5-2.2)	1.8 (1.4-2.1)	1.95 (1.6-2.8)	0.03
Serum sodium (mEq/L)	133 (129-137)	134 (129-137)	132 (127-136)	0.10
SIRS*	70 (56%)	38 (54%)	32 (58%)	0.66
MELD score	20 (16-26)	19 (14-25)	24 (18-31)	0.001
Child-Pugh score	10 (9-12)	10 (9-12)	11 (9-12)	0.34

All variables collected at time of diagnosis of infection. All qualitative variables expressed an absolute numbers and percentages.
All quantitative variables expressed as median and interquartile range (IQR)
HCC hepatocellular carcinoma, INR international normalized ratio, SIRS systemic inflammatory response syndrome, MELD Model for End-Stage Liver Disease
* Available in 125 patients.

** Marciano S, Dirchwolf M, Bermudez CS, Sobenko N, Haddad L, Genre Bert F, et al. Spontaneous bacteremia and spontaneous bacterial peritonitis share similar prognosis in patients with cirrhosis: a cohort study. Hepatol Int. 2017; doi:10.1007/s12072-017-9837-7. Con permiso de los autores*

¿Cómo se toma una muestra?

Se llama técnica de muestreo al método para seleccionar unidades de observación a los fines de un estudio de investigación. En la investigación cualitativa, las técnicas de muestreo permiten seleccionar los participantes del estudio para representar la población blanco. Se dividen en técnicas probabilísticas y no probabilísticas.

En un muestreo probabilístico, los individuos de la población accesible tienen una probabilidad conocida de estar en la muestra. Ejemplos de este tipo de muestreo son el muestreo probabilístico simple, el muestreo sistemático, el muestreo consecutivo, el muestreo por estratos y el muestreo por clusters. Algunos tipos de muestreo no probabilístico son el muestreo por conveniencia y el muestreo en bola de nieve.

En la investigación cualitativa las muestras se toman de manera diferente. En este caso el objetivo de la muestra no es utilizar técnicas estadísticas para hacer inferencia sobre una población blanco, sino comprender un fenómeno. Por lo tanto, las unidades de observación se eligen específicamente por ser la mejor fuente del fenómeno bajo estudio, representando un punto de vista valioso y representativo a los ojos del investigador.

La técnica de muestreo se define en base a las necesidades de la pregunta de investigación y aspectos técnicos como capacidad de evaluación de pacientes en el tiempo. Se describe en el protocolo y se sostiene a lo largo del estudio. Muchas de las técnicas más complejas requieren ajustes de la estimación de tamaño muestral o de los métodos estadísticos que se utilizarán en el estudio.

¿Cuáles son las diferencias entre los tipos de muestreo probabilístico?

El muestreo aleatorio simple consiste en tomar al azar una muestra de una lista. Para este tipo de muestreo es necesario tener una lista de la población accesible previamente para seleccionar los individuos. Es muy fácil de realizar, ya que se puede utilizar cualquier software que sea capaz de generar números aleatorios como planillas de cálculos o paquetes de análisis estadísticos. Se dice que la probabilidad es conocida de pertenecer a la muestra aleatoria simple porque si debo tomar 50 pacientes de una población accesible de 500, la probabilidad de estar incluido en la muestra es 0,1 para cualquier individuo de la población accesible.

Por el contrario si carezco de la lista completa, es necesario utilizar otras técnicas que permiten tomar muestras aleatorias, aun en ausencia de la lista completa de la población accesible, como el muestreo sistemático. El inicio debe ser aleatorio para que sea considerado como muestreo probabilístico. Este tipo de muestreo es particularmente útil si los individuos que forman parte de la población accesible van a incluirse en la población accesible en el tiempo. Los pacientes que van a requerir una colecistectomía o los pacientes que consultan a una central de emergencias de adultos son ejemplos de estas situaciones.

Si mi pregunta requiere tomar una muestra prospectiva de los pacientes que llegan a la guardia en un determinado período, puedo utilizar el muestreo sistemático. Si mi probabilidad de inclusión es 0,1, quiere decir que incluiré 1 de cada 10 pacientes que consulten a la guardia. El muestreo sistemático requiere que en los pacientes ordenados por orden de llegada, incluiría el paciente número 10, el número 20, el número 30, etc. Es importante asegurarse que no exista periodicidad asociada a la frecuencia de muestreo. Si existiera alguna variable asociada a la periodicidad de la frecuencia de muestreo, podríamos cometer un sesgo al utilizar este tipo de muestreo.

¿Cómo elijo la frecuencia de muestreo? depende principalmente de la capacidad y recurso disponible para las evaluaciones. Si tengo recurso disponible para evaluar 1 de cada 5 pacientes que consultan, entonces es posible plantear una probabilidad de estar en la muestra de 0,2. ¿Qué pasa si tengo capacidad de incorporar 1 de cada 3? ¿o 1 de cada 2? Puedo tomar una frecuencia de muestreo de 0,33 o de 0,5. En el mismo sentido, el muestreo consecutivo es un caso particular de muestreo probabilístico sistemático con relación 1 de 1. La frecuencia de muestreo sistemático se define previamente y no se cambia durante la implementación de un estudio.

Se llama cluster o conglomerado a grupos naturales de individuos como pueden ser los alumnos de una escuela. Por definición los individuos de un mismo cluster se parecen más entre sí, que con los individuos de otros clusters. Son ejemplos de cluster, los pacientes de un hospital, los pacientes de un médico de cabecera, entre otros. En el muestreo por clusters, se seleccionan al azar los clusters de unidades de observación y no los individuos en particular. Este tipo de muestreo, requiere utilizar tipos de análisis estadísticos que consideren el natural agrupamiento de las unidades de observación en esos clusters. Asimismo, requiere considerar esta estructura en clusters en el cálculo del tamaño muestral.

En el muestreo estratificado, la probabilidad de estar en la muestra es fija por estratos. Por ejemplo: si me interesa tener 50% de hombres y 50% de mujeres en una muestra de una población accesible que tiene 500 hombres y 1000 mujeres, la probabilidad de ingresar al estudio en los hombres será 0,1 y en las mujeres 0,05. En algunos casos me interesa representar un determinado estrato que es de particular importancia para mi pregunta de investigación, pero que hay pocos individuos. Puedo utilizar un muestreo por estratos para asegurarme de incluir suficientes pacientes del estrato que me interesa en el estudio. En este tipo de muestreo, es necesario utilizar métodos estadísticos específicos para ponderar los estimadores muestrales por los tamaños de los estratos. Muchas encuestas, como La Encuesta Nacional de Examen de Salud y Nutrición (NHANES),^[15] utilizan probabilidades de muestreo por estratos de zonas por ejemplo. Luego ponderan los resultados obtenidos en cada zona para estimar cómo se comporta un parámetro en toda la población.

Se llama muestreo multietápico a todas las técnicas que combinan estos tipos de muestreo en diferentes etapas. Requieren ajustes del tamaño muestral y de los métodos estadísticos. En líneas generales, la técnica más simple será la más apropiada y la más fácil de diseñar, implementar y controlar su calidad. Para las técnicas más complejas, es una buena idea buscar ayuda de alguien con experiencia en el campo de muestreos complejos.

3

DISEÑOS DE ESTUDIOS DE INVESTIGACIÓN

¿Qué es un diseño?


El diseño de un estudio es una estructura estándar con características predefinidas que se selecciona para responder una pregunta de investigación específica. Es un componente principal de un estudio de investigación que determina aspectos fundamentales como el grado de evidencia a generar, fortalezas, debilidades, complejidad, factibilidad, calidad, costos, temporalidad, entre otros. Existe una gran variedad de diseños y clasificaciones. Nos enfocaremos sólo en los más importantes y sus aspectos principales.

¿Cómo se clasifican?

Los diferentes diseños pueden clasificarse de diferentes maneras de acuerdo a distintos atributos. La importancia de la clasificación radica en conocer qué quiere decir que un determinado diseño caiga en una determinada categoría. Conocer las ventajas y desventajas de una categoría, permite que clasificar un diseño tenga sentido. Clasificar solo es útil si nos dice algo del comportamiento o las características del estudio.

De acuerdo a sus características se pueden clasificar con respecto a la pregunta de investigación (descriptivos o analíticos), de acuerdo a las unidades de observación (individuales o poblacionales), de acuerdo a la temporalidad (retrospectivos o prospectivos), de acuerdo a la naturaleza de la exposición (observacionales o experimentales).

Figura 5. En este esquema se muestra una simplificación de la clasificación de diseños más comunes.



Con respecto a las unidades de observación

Los diseños pueden clasificarse de acuerdo con las unidades de observación en individuales o poblacionales.

Los estudios individuales son muchísimo más frecuentes. Se trata de cualquier estudio que realiza mediciones a nivel del individuo. En estos casos es posible conocer el valor de las mediciones de cada variable a nivel individual. Por ende va a ser posible clasificar a los individuos participantes de acuerdo al nivel de exposición y al nivel de variable de respuesta. La gran fortaleza es que para estimar asociaciones causales es necesario obtener mediciones individuales.

En los estudios poblacionales, las unidades de observación son poblaciones. Típicamente las mediciones son frecuencias o tasas de exposición o de eventos. En este tipo de diseños no es posible saber si quien tuvo una determinada exposición es el mismo individuo que tiene un determinado evento. Este fenómeno se llama falacia ecológica. Se clasifica habitualmente como un sesgo de información. Se presenta porque intentamos sacar conclusiones a nivel individual, utilizando mediciones agregadas en poblaciones en un nivel superior.^[16]

Si mi pregunta fuera ¿Cuál es la asociación entre el consumo de carne por persona y la tasa de cáncer colorrectal?, es posible obtener las tasas de consumo de carne por persona de todos los países de latinoamérica y la tasa de cáncer colorrectal de la misma manera. En ambos casos son datos disponibles, de fácil y rápido acceso y de bajo costo. Debido a que las mediciones se encuentran agregadas al nivel de la población, no es posible identificar si los individuos que más carne consumen son los que más probabilidad de desarrollar cáncer tienen. A su vez sólo podré sacar conclusiones a nivel de las poblaciones, con baja evidencia en sentido causal. Otro ejemplo de estudio con mediciones poblacionales es *Cancer incidence in adults living in the vicinity of nuclear power plants in France, based on data from the French Network of Cancer Registries*.^[17]

Con respecto a la temporalidad

Los diseños pueden clasificarse de acuerdo con la temporalidad en retrospectivos y prospectivos. La diferencia entre los estudios retrospectivos y prospectivos es el momento en el que ocurre la variable de resultado. Agregamos a esta clasificación los estudios de series temporales y los ambispectivos o retro prospectivos.

En los estudios retrospectivos, la variable de resultado ya ocurrió en el momento que decidimos incluir a un individuo en el estudio. Es decir, al momento de incluir los individuos en el estudio, el evento de interés ya ocurrió o no. Los diseños más frecuentes que entran dentro de esta categoría son los cortes transversales y los casos y controles. Por ejemplo, en este estudio *Geographic region: Does it matter in cutaneous melanoma of the head and neck?* los autores utilizaron información retrospectiva para identificar y evaluar las características de los melanomas de manera retrospectiva.^[18]

Por ejemplo si mi pregunta es ¿existe asociación entre la exposición a asbestos y el desarrollo de cáncer de laringe? y decido estudiarlo incluyendo a pacientes con cáncer de laringe y controles sin cáncer de laringe, la naturaleza del estudio es retrospectiva. En estos casos las variables independientes se recuperan de la información disponible sobre exposiciones previas al desarrollo o no del evento. Esto puede generar que recordar las exposiciones o recuperar información de exposiciones previas sea potencialmente un problema.

En los estudios prospectivos por definición, la inclusión de los participantes es previa a que ocurra el evento de interés. En este caso es posible medir las exposiciones previamente al desarrollo de los eventos. Esta condición aporta fortaleza causal ya que la preexistencia de la exposición al evento de interés es una de los requisitos para evaluar asociaciones causales. Son típicamente prospectivos los estudios de cohorte prospectiva y los ensayos clínicos.

En los estudios ambispectivos se incluyen pacientes retrospectivamente y prospectivamente a la vez. Este tipo de diseño se utiliza muchas veces, por ejemplo, para registros de enfermedades raras. En estos casos se consensúa un set de datos posible para los pacientes retrospectivos y los prospectivos. La principal dificultad es la heterogeneidad de la calidad y disponibilidad de la información. Un ejemplo de este tipo de estudios es *Quality of Life in Patients with Osteoporotic Vertebral Compression Fractures*.^[19]

Los estudios que utilizan bases de datos secundarias son por definición retrospectivos. En este caso se utilizan bases de datos recolectadas con otro objetivo diferente de la investigación. Estas bases pueden ser administrativas, registros, datos rutinarios, etc. En este caso la información ya está recolectada y fue medida de acuerdo a otros objetivos. No es posible controlar o definir una forma estándar de medición dado que ya se realizaron. La información que no fue medida no estará disponible. A su vez, es común que presenten gran cantidad de datos perdidos y heterogeneidad en las mediciones. Estos problemas se solucionan con captura de información primaria, es decir un sistema de recolección de datos diseñado a los fines de la pregunta de investigación. Un ejemplo de estudio utilizando bases de datos secundarias es *Do influenza and pneumococcal vaccines prevent community-acquired respiratory infections among older people with diabetes and does this vary by chronic kidney disease? A cohort study using electronic health records*,^[20] Otro ejemplo es *Comparative effectiveness research using electronic health records: impacts of oral antidiabetic drugs on the development of chronic kidney disease*.^[21]

Con respecto a la naturaleza de la exposición

Con respecto a la naturaleza de la exposición, se puede clasificar los estudios en observacionales o experimentales.

Adicionalmente, existen estudios quasi experimentales que son aquellos donde falta alguno de los componentes de los estudios experimentales como pueden

ser los diseños antes - después de una determinada intervención. Un ejemplo de este tipo de estudios es *Evaluating influenza vaccination campaigns beyond coverage: a before-after study among health care workers*.^[22] En este estudio los autores evaluaron el efecto de una campaña educativa sobre los profesionales de salud, comparando antes y después de la implementación de la campaña. Los estudios observacionales son aquellos en que el investigador para contestar su pregunta de investigación sólo observa. Observar no es una actividad pasiva en este sentido, ya que implica observar lo que ocurre de manera activa y recuperar la información de manera estandarizada. El investigador no indica procedimientos adicionales sino que se limita a obtener información del cuidado habitual de los pacientes. Pueden existir variaciones en el cuidado, pero típicamente no se le indican procedimientos o exposiciones adicionales.

Está ampliamente documentado que los participantes de un estudio, modifican su comportamiento por el solo hecho de ser observados. Este cambio en el comportamiento en los participantes que se saben observados, se llama efecto Hawthorne.^[23] Este efecto está presente en todos los estudios que involucren sujetos de investigación de manera prospectiva.

En los estudios experimentales el investigador administra una exposición. Los estudios experimentales más comunes son los ensayos clínicos en los cuales el investigador administra la exposición bajo estudio. Esta administración de la exposición, sólo es posible con las exposiciones administrables. Es decir que no se podrá hacer estudios experimentales con exposiciones potencialmente dañinas (fumar, radiación o exposición a agroquímicos) o con exposiciones no administrables (como polimorfismos genéticos o historia de interacciones sociales de un individuo). Algunos ejemplos de exposiciones administrables son tratamientos (farmacológicos o no), vacunas, métodos de diagnóstico, educación, entre otras.

¿Cuáles son los tipos de diseños más frecuentes?

Los tipos más frecuentes de diseño son los ensayos clínicos, las cohortes, los estudios de casos y controles, los cortes transversales y los estudios ecológicos. A continuación presentaremos las características principales de cada uno de los diseños clásicos.

¿Cómo se define un ensayo clínico?

En los ensayos clínicos el investigador evalúa el efecto sobre un evento, de una exposición administrada por el investigador. En sentido estricto son cohortes experimentales, donde el investigador administra una exposición y sigue a los participantes en el tiempo en busca de los que desarrollan un evento de interés. Son siempre experimentales y prospectivos. A su vez los ensayos clínicos pueden ser aleatorios, controlados, y ciegos entre otros.

Pueden tener una o más ramas de exposición. Se llama ramas de exposición a los diferentes niveles de exposición, como por ejemplo dieta A o dieta B. Los ensayos clínicos con más de una rama son los más comunes y permiten obtener información de eficacia y seguridad de las intervenciones. La eficacia de una exposición es el efecto deseado o buscado. Por ejemplo: una medicación para el tratamiento de hipertensión es eficaz cuando controla adecuadamente la presión de una población específica de pacientes hipertensos. La medicación es segura si el perfil de efectos adversos es apropiado para una determinada situación clínica de una población específica. La relación entre eficacia y seguridad es un aspecto fundamental de cualquier ensayo clínico. Se llaman controlados a los ensayos clínicos que tienen más de una rama de exposición. Generalmente en estos casos, una de las ramas actúa como control.

Las ventajas principales de los ensayos clínicos son la posibilidad de obtener información causal sobre la asociación entre la exposición bajo estudio y el evento de interés cuando es posible aleatorizar la exposición. Las principales desventajas son el costo y el tiempo de la implementación y la complejidad del diseño, implementación y control de calidad.

Por ejemplo si mi pregunta es ¿El uso de una aplicación para *smartphones* (teléfonos celulares móviles inteligentes) con estrategias de gamificación para el control del peso corporal, es más eficaz que el consejo médico habitual en adultos con obesidad? En este caso puedo plantear un ensayo clínico con dos ramas: una rama expuesta a la aplicación de *smartphones* y otra rama expuesta a consejo habitual de descenso de peso. Los participantes serán asignados al azar a una rama u otra del estudio. Los seguiremos en el tiempo por un período de 6 meses y compararemos el descenso de peso en ambos grupos.

Si bien no son las publicaciones más frecuentes, existen muchos ejemplos en la literatura de ensayos clínicos. Como *Assessment of the effectiveness of physical activity interventions in the Brazilian Unified Health System* donde se asignaron adultos a diferentes intervenciones y se evaluó su efecto en el descenso de peso.^[24] Se trata de un estudio experimental no aleatorizado.

¿Qué es el ciego o enmascaramiento?

Los participantes que se saben tomando un placebo reportan menos efectos adversos aunque los sientan. Los participantes que se saben tomando un principio activo presentan más efectos adversos. Los participantes que se saben tomando un principio activo, que creen que es mejor, reportan mucha más eficacia y bienestar que los participantes que toman una medicación que creen que es inferior. Esto representa un sesgo de información ya que los participantes reportan sistemáticamente diferente de acuerdo a en qué rama del estudio se encuentran. A su vez los médicos podrían preguntar diferente o seguir diferente o solicitar diferentes estudios o indicar medicación adicional a sus pacientes si saben la rama del estudio en la cual está un determinado participante.

El ciego o enmascaramiento es el ocultamiento de la rama de exposición a uno o más actores del estudio. Se puede ocultar al paciente, al médico, al evaluador, a quien realiza el análisis estadístico. Todos los actores podrían potencialmente estar afectados por su subjetividad, por lo cual se recomienda cegar siempre que sea técnica y éticamente posible. Es posible utilizar el ciego incluso en estudios observacionales donde pudieran existir sesgos de información relacionados con la subjetividad.

Los estudios no ciegos o abiertos se parecen más a la práctica clínica real, pero son mucho más susceptibles de sesgos de información por reporte diferencial de los pacientes o por recuperación de la información diferencial. A su vez son problemas frecuentes el uso diferencial de estudios de test diagnósticos o las cointervenciones de acuerdo a conocer en qué rama del estudio está un paciente. En muchos casos como los estudios incluidos en este metanálisis *Efficacy and safety of insulin glargine compared to other interventions in younger and older adults: a pooled analysis of nine open-label, randomized controlled trials in patients with type 2 diabetes*, no es posible enmascarar las intervenciones.^[25] ¿Qué efecto podría tener sobre los resultados que los pacientes conozcan su rama de intervención?

Una desventaja del ciego es que aumenta la complejidad del estudio. Requiere el desarrollo de mecanismos para asegurar el ciego y mantenerlo durante todo el estudio. Así también requiere mecanismos de ruptura de ciego ante eventuales necesidades clínicas. Por ejemplo si un paciente en un estudio consulta a la guardia con un dolor precordial, puede ser fundamental tener disponible un mecanismo para que los médicos que lo asistan tengan la posibilidad de conocer en qué rama del estudio está, para tomar acciones en el cuidado de emergencia del paciente.

¿Para qué sirve la asignación al azar de tratamiento?

En los ensayos clínicos la exposición bajo estudio es administrada por el investigador. Esta única posibilidad exclusiva de este diseño permite usar la aleatorización como herramienta para decidir quien recibe la exposición. Es decir, si mi pregunta fuera ¿es la droga A más eficaz que la droga B en el tratamiento de la hipertensión crónica en adultos? Al asignar al azar los participantes del estudio a recibir la droga A o la droga B, se eliminan las diferencias entre los grupos.

Sólo es posible aleatorizar exposiciones administrables y cuando existe *Equipoise*. *Equipoise* quiere decir que no se conoce que ninguna de las ramas del estudio sea más eficaz o más segura antes de iniciar el estudio.^[26] Es decir, no hay evidencia a priori de eficacia y seguridad entre las ramas del estudio.

En la práctica clínica múltiples factores intervienen en la decisión de iniciar un tratamiento y con qué principio activo. Se trata de una decisión activa en la cual participa el médico y el paciente decidiendo cual es el mejor tratamiento para la situación clínica particular. Esto hace que en la práctica clínica, los pacientes

que tomaron la droga A podrían ser diferentes a los que toman la droga B. Imaginemos que la droga B pudiera causar enfermedad coronaria, entonces existe la posibilidad que los médicos decidan dar la droga A a los pacientes con factores de riesgo coronario y no la droga B. Por esta razón, probablemente, ambos grupos no serían comparables por las diferencias en sus factores de riesgo conocidos y desconocidos. Este problema es una constante de los estudios observacionales. Este fenómeno se llama confusión por indicación. La asignación aleatoria a droga A o droga B elimina el sesgo de confusión por indicación, ya que nadie elige quien recibe droga A o droga B, sino que se asigna a un grupo u otro aleatoriamente.

Que ambos grupos sean similares en todas sus características con excepción de la exposición a A o B, podría enunciarse como que son intercambiables. La intercambiabilidad promedio es una propiedad de la causalidad que dice que los individuos que reciben la droga A, se hubieran comportado igual que los que reciben la droga B, si hubieran recibido droga B. Es decir, con respecto a su probabilidad de tener el evento condicional al tratamiento que recibieron, son intercambiables. La intercambiabilidad es la propiedad más importante de la causalidad y es exclusiva de los ensayos clínicos aleatorizados.^[27]

Si la aleatorización funciona, los dos grupos resultantes serán idénticos en todas sus características con excepción de que unos fueron expuestos a la droga A y otros a la droga B. La aleatorización es una estrategia para tratar confundidores que tiene el potencial de eliminar el efecto de los confundidores conocidos, los desconocidos e incluso los no medibles. Sólo funciona cuando el tamaño muestral es lo suficientemente grande.

Algunos ejemplos de estudios aleatorizados son: *A Bivalent Meningococcal B Vaccine in Adolescents and Young Adults*,^[28] *Limited screening with versus without*,^[18] *F-fluorodeoxyglucose PET/CT for occult malignancy in unprovoked venous thromboembolism: an open-label randomised controlled trial*,^[29] *Primary isoniazid prophylaxis against tuberculosis in HIV-exposed children*,^[30] y *Outcomes of a Coaching-Based WHO Safe Childbirth Checklist Program in India*.^[31] En estos estudios se aleatorizaron diferentes exposiciones: una vacuna, diferentes estrategias diagnósticas, un preparado farmacéutico o una estrategia educativa, respectivamente.

¿Cómo se clasifican los ensayos clínicos?

Los ensayos clínicos pueden clasificarse acuerdo a diferentes criterios. Por ejemplo, durante el desarrollo y evaluación de los fármacos nuevos se desarrollan diferentes fases con diferentes objetivos, diseños y particularidades que se resumen en la siguiente tabla.

Fase	Objetivo	Individuos de estudio
Fase preclínica	Estudio de farmacocinética, diferentes tipos y niveles de toxicidad.	Animales
Fase I	Datos incipientes de toxicidad, dosis máxima tolerada, vía de administración.	Individuos sanos
Fase II	Actividad clínica y respuesta, dosis y frecuencia.	Pacientes <100
Fase III	Comparación de seguridad y eficacia; comparación con tratamiento conocido o placebo.	>1000 pacientes
Fase IV	Farmacovigilancia, eficacia a largo plazo, efectividad, detección de efectos adversos raros.	Población general una vez comercializado

Los ensayos clínicos farmacológicos son los estudios experimentales clásicos que utilizan exposiciones farmacológicas. En estos estudios es común la comparación con otro principio activo o con un placebo. Dentro de los ensayos clínicos no farmacológicos se agrupan una gran cantidad de exposiciones diferentes no farmacológicas, como: quirúrgicas, tecnología, educativas, diagnósticas, conductuales, entre otros.

Con respecto a las ramas del ensayo clínico, se puede dividir en estudios de ramas paralelas o cruzadas. En los primeros, la asignación a rama de intervención se mantiene constante durante todo el estudio. Por el contrario en los ensayos clínicos con ramas cruzadas, los participantes son asignados a una exposición y luego de un período de wash out, reciben la otra exposición del estudio. Este diseño sólo puede aplicarse a eventos de interés reversibles. Por ejemplo en este estudio se evaluó el efecto de 3 dietas diferentes sobre la presión arterial y el perfil lipídico en pacientes ambulatorios sanos *Comparison of the DASH (Dietary Approaches to Stop Hypertension) diet and a higher-fat DASH diet on blood pressure and lipids and lipoproteins: a randomized controlled trial*.^[32] En este estudio de ramas cruzadas, todos los participantes recibieron las 3 dietas por 3 semanas, separadas por 2 semanas cada una. El orden en el que recibieron cada dieta fue al azar.

Existe un subtipo de ensayo clínico denominado factorial. En este tipo de diseño, se estudia simultáneamente el efecto de 2 intervenciones diferentes y su combinación. Los diseños factoriales son muy eficientes para estudiar el efecto

de dos intervenciones en simultáneo. Por ejemplo en este estudio se evaluó el efecto de la dieta, el ejercicio o la combinación sobre el peso y su repercusión metabólica en mujeres obesas lactantes a través de un diseño factorial *Diet and exercise interventions among overweight and obese lactating women: randomized trial of effects on cardiovascular risk factors*.^[33]

En los estudios de superioridad, el investigador cree que una de las dos ramas del ensayo clínico es superior a la otra. Por ejemplo, si interesa evaluar la eficacia de un nuevo tratamiento para el control de la ansiedad versus placebo. Por el contrario es común que no sea ético dejar sin tratamiento a los participantes de un estudio de investigación ya que existen tratamientos disponibles de conocida eficacia. En ese contexto, cualquier nuevo tratamiento interesa demostrar que al menos no es inferior que los tratamientos de mejor cuidado recomendado disponible. Estos estudios se llaman estudios de no inferioridad y tienen particularidades en su diseño, tamaño muestral, análisis estadístico y métodos. Por ejemplo en este estudio se evaluó el uso de antibióticos profilácticos en la colecistectomía laparoscópica de bajo riesgo *Antibiotic Prophylaxis in Laparoscopic Cholecystectomy: A Randomized Controlled Trial*.^[34] Si bien está planteado como un estudio de superioridad, impresiona que la pregunta del estudio es una pregunta de no inferioridad.

¿En qué se diferencian los ensayos clínicos pragmáticos de los clásicos?

De acuerdo a su diseño específico se los puede clasificar en ensayos clínicos clásicos y pragmáticos. Los ensayos clínicos clásicos, de eficacia o tradicionales son situaciones muy artificiales donde se estudia la eficacia de una intervención sobre un determinado resultado. Los pacientes incluidos en el estudio se seleccionan para ser similares, adherentes y tener baja probabilidad de abandonar el estudio. A su vez se incluye un determinado grupo etario que tenga baja frecuencia de eventos adversos y dentro de lo posible pocas comorbilidades adicionales. Los métodos de seguimiento de los participantes son intensivos, invasivos y muy diferentes de la práctica habitual. Los pacientes incluidos son muy parecidos entre sí. Esta situación maximiza la validez interna y la eficiencia del estudio, pero compromete la validez externa.

Es fácil imaginarse lo difícil que es extrapolar los resultados de los estudios clínicos clásicos a la población de la práctica clínica habitual: en el consultorio los pacientes son cada vez más ancianos, son frecuentes las múltiples comorbilidades y tratamientos farmacológicos. Los pacientes reales no cumplen con las visitas ni son completamente adherentes. Las decisiones sobre tratamientos, estudios diagnósticos o conductas se discuten y consensúan entre el paciente, su equipo médico tratante y la familia. No siempre toman la medicación, cuando la toman, no siempre la toman bien ni de la misma manera. Son muy variables y diferentes entre sí y su seguimiento puede ser errático y personal.

La efectividad es la medida de cómo funciona una determinada intervención en

un escenario más real y no tan artificial como son los ensayos clínicos clásicos. Estos estudios se llaman pragmáticos y son más parecidos a la práctica clínica habitual. Los pacientes son diferentes, con comorbilidades, similares a la práctica clínica habitual. El seguimiento es más parecido al seguimiento habitual de los pacientes en el mundo real. Si bien aportan información más parecida a lo que pasa en la realidad con las indicaciones de tratamiento, requieren tamaños muestrales mucho más grandes.

Una herramienta apropiada para clasificar a los estudios en pragmáticos o clásicos es el PRECIS-2 que permite asignar puntajes a la características del diseño para definir si se trata de un estudio pragmático o clásico.^[35] La herramienta mide diferentes aspectos como elegibilidad, reclutamiento, seguimiento, flexibilidad, organización, seguimiento, eventos primarios y análisis. Con esta herramienta es posible clasificar los estudios en ensayos de eficacia o efectividad.

¿Cómo se define un estudio de cohorte?

En los estudios de cohorte el investigador incluye los pacientes de acuerdo a su exposición y los sigue en el tiempo en busca de los participantes que desarrollan eventos. Las cohortes implican un período de seguimiento para los participantes. Pueden ser retrospectivas o prospectivas. Pueden tener una única rama o varias ramas de exposición diferente y permiten estimar riesgos. La medida natural de asociación es el riesgo relativo o la razón de tasas de incidencia.

En las cohortes retrospectivas se incluyen los individuos en un momento hacia atrás en el tiempo y se los sigue retrospectivamente para identificar quienes desarrollaron el evento durante el tiempo de seguimiento. Las cohortes retrospectivas requieren recuperación de información retrospectiva que puede provenir de historias clínicas, historias clínicas electrónicas, otras bases de datos secundarias. En las cohortes prospectivas se incluyen respectivamente los participantes y se los sigue en el tiempo hasta que desarrollan el evento.

La pregunta ¿Cuál es la asociación entre el consumo de losartán y la mortalidad en los pacientes EPOC? se podría construir una cohorte retrospectiva con pacientes que consumieron losartán en el futuro y pacientes que no consumieron losartán y seguirlos retrospectivamente para identificar los eventos de fallecimiento.^[36] En este caso requerimos un registro de fármacos y de eventos de muerte. Otro ejemplo de cohorte retrospectiva es *Do influenza and pneumococcal vaccines prevent community-acquired respiratory infections among older people with diabetes and does this vary by chronic kidney disease?* A cohort study using electronic health records, que utilizó historias clínicas electrónicas^[20]. Otro ejemplo adicional es la cohorte prospectiva más famosa: el estudio de Framingham.^[37]

Por el contrario la pregunta ¿El aprendizaje basado en problemas se asocia a conocimiento más duradero en estudiantes de medicina? podría contestarse con una cohorte retrospectiva de estudiantes de 2 universidades una que utiliza

aprendizaje tradicional y otra basado en problemas y seguirlos en el tiempo. En este caso, es posible que se requiera captura primaria de información no disponible previamente. Otro ejemplo de estudio de cohorte retrospectiva es *The incidence of venous thromboembolism in patients with overt hyperthyroidism: a retrospective multicentre cohort study*.^[38]

Las cohortes a su vez pueden ser cerradas o abiertas. Las cohortes cerradas implican el mismo tiempo de seguimiento para todos los individuos pertenecientes a la cohorte. En cambio en las cohortes abiertas o dinámicas los tiempos de seguimiento pueden ser diferentes para los distintos participantes. En este caso se deberán usar los métodos estadísticos apropiados para las cohortes dinámicas o métodos para datos censurados (ver más adelante Métodos para datos censurados).

Las cohortes son eficientes para exposiciones infrecuentes. También permiten estudiar más de un evento simultáneamente. Permiten medir las exposiciones antes que los eventos, asegurando así la preexistencia de las exposiciones a los eventos. La relación temporal es uno de los criterios de causalidad postulados por Bradford Hill para identificar asociaciones causales,^[7,8] por lo cual aportan mayor información con fortaleza causal.

Las principales desventajas de las cohortes prospectivas son la dificultad en su implementación, el costo y tiempo que requiere para completarse. La principal desventaja de las cohortes retrospectivas es la validez de la información y la calidad de las mediciones y registros retrospectivos. Por ejemplo, las historias clínicas pueden registrar información muy incompleta. A su vez es imposible estandarizar como se tomó la información o como se evaluaron los pacientes de manera retrospectiva.

¿Cómo se define un estudio de casos y controles?

En los estudios de casos y controles, los participantes se incluyen por haber tenido un evento (casos) o por no haberlo tenido (controles). En este caso se busca retrospectivamente recuperar información sobre su exposición previa a la ocurrencia del evento. En los estudios de casos y controles no se puede estimar riesgos, pero si odds. La natural medida de asociación de los estudios de casos y controles es el odds ratio (OR, ver más adelante Variables, medidas de resumen y medidas de asociación).

Debido a que en general los casos son escasos, se puede incrementar el tamaño de los controles ganando poder adicional para detectar diferencias que verdaderamente existen. En el caso más común se mantiene igual tamaño para casos y controles, pero puede incrementarse el tamaño de los controles hasta 5 veces y se sigue ganando poder adicional. Más allá de 1 caso por cada 5 controles, no se gana poder adicional. Esta misma estrategia puede aplicarse a otros diseños como ensayos clínicos o cohortes, variando el tamaño relativo de las ramas de exposición o de los grupos de exposición, respectivamente.

Los casos y controles pueden estar anidados en cohortes. El caso y control anidado en una cohorte tiene mayor calidad ya que permite recuperar información de mejor calidad con respecto a las exposiciones. Asimismo, permite determinar la preexistencia de la exposición al evento.

Por ejemplo, si mi pregunta es ¿un determinado polimorfismo de un gen específico predispone a melanoma? es posible identificar casos de melanoma y seleccionar controles de población general del mismo sexo y edad utilizando un diseño de casos y controles. Otro ejemplo de estudio de casos y controles es *Risk factors for infection following prostate biopsy - a case control study*.^[39]

Estos estudios son muy eficientes para el estudio de eventos raros (casos poco frecuentes) y permiten estudiar varias exposiciones al mismo tiempo. La gran restricción es la incapacidad para medir algunas exposiciones por falta de información. A su vez el desafío más grande de los estudios de casos y controles es asegurar que tanto casos como controles provienen de la misma población.

¿Qué es el matcheo? ¿Para qué sirve?

El matcheo o apareamiento es una técnica para controlar el efecto de confundidores. Si decido matchear por sexo y edad por ejemplo, es porque son confundidores importantes y deseamos controlar su efecto. En este caso, por cada caso de sexo femenino de 30 años, deberíamos incluir un control sexo femenino y de la misma edad. De esta manera al matchear los controles con los casos, nos aseguramos que los casos y los controles son iguales en su proporción de sexo femenino y en la edad.

El matcheo requerirá métodos estadísticos específicos para datos apareados ya que los casos y los controles matcheados dejan de ser independientes entre sí. El matcheo no va a permitir comparar el sexo ni la edad entre casos y controles ya que nos ocupamos de que sean iguales. A su vez, puede no ser suficiente y persistir confusión residual. En este caso se deberá posteriormente ajustar el efecto de la confusión residual con otro método como análisis multivariado.

Si bien no es una estrategia excluyente de los estudios de casos y controles, es frecuente su uso en este diseño. Un ejemplo de matcheo en un estudio de casos y controles es *A case-control study of the risk of cutaneous melanoma associated with three selenium exposure indicators*.^[40] Un ejemplo de una cohorte en la que matchearon por propensity score es *Concurrent Chemoradiotherapy in Curatively Resected Gallbladder Carcinoma: A Propensity Score-Matched Analysis*.^[41]

¿Cómo se define un estudio de corte transversal?

En los estudios de cohorte transversal, se seleccionaron participantes por pertenecer a una población específica. Son siempre retrospectivos, pueden ser descriptivos o analíticos. La natural medida de frecuencia en este caso es la prevalencia y la medida de asociación la razón de prevalencias.

En este tipo de estudio, se realizan las mediciones de eventos y exposiciones en el mismo momento del tiempo. Esto no quiere decir que ocurre exactamente en el mismo día, quiere decir que se trata del mismo momento conceptual para todos los participantes. Por ejemplo si me interesa responder ¿Cuál es la prevalencia de colonización por pseudomonas multirresistentes en pacientes de terapia intensiva a los 7 días de ingreso a la terapia? o ¿Cuál es la prevalencia de dolor a las 24 horas post cirugía de cadera? Son preguntas referidas a un momento conceptual específico y no a un momento calendario específico.

Los estudios de corte transversal son susceptibles a la presencia de causalidad reversa, ya que no es posible en la mayoría de las exposiciones, definir con claridad la preexistencia de una exposición en particular con respecto a un determinado evento.

La gran ventaja de este tipo de estudio es la simpleza y facilidad de su diseño e implementación. Los estudios de corte transversal generan escasa información causal, pero permiten evaluar múltiples asociaciones a la vez. Este estudio representa un ejemplo de corte trasversal analítico donde se identificaron factores asociados a calidad de vida *Factors associated with health-related quality of life among overweight or obese adults*.^[42]

¿Cómo se define un estudio ecológico?

Los estudios ecológicos son poblacionales por definición. En estos estudios las unidades de observación están medidas en niveles de poblaciones y no de individuos. Es natural presentar la asociación de las tasas como coeficientes de correlación o aplicar modelos de regresión a situaciones más complejas.

Es el diseño más apropiado cuando una determinada exposición varía naturalmente entre las poblaciones o cuando el efecto de una exposición ocurre a nivel de la población como las campañas de vacunación. En este estudio se evaluó la pregunta ¿existe asociación entre la exposición a arsénico en el agua y el desarrollo de cáncer de próstata? *Arsenic in drinking water and prostate cancer in Illinois counties: An ecologic study*.^[43]

Como todos los estudios ecológicos, está sujeto al fenómeno de falacia ecológica. La falacia ecológica se clasifica como un sesgo de información en el cual la exposición y el efecto no se miden en el mismo nivel que me interesa hacer inferencia.^[16,44] No se puede asegurar que exista una relación causal a nivel individual ya que no contamos con información individual del grado de exposición a arsénico de los individuos que desarrollaron cáncer y los que no. Es decir, no se puede saber si esta asociación se sostiene a nivel individual.

Este diseño se utiliza ampliamente en la salud pública para la toma de decisiones y para medir el impacto de las políticas en salud sobre indicadores agregados poblacionales. En este ejemplo se evaluó el efecto de la vacunación para rotavirus sobre la tasa de internaciones de niños menores a 5 años *Impact of Rotavirus Vaccination in Germany*, utilizando información agregada poblacio-

nal^[45]. En el estudio de las campañas de vacunación, parte del efecto se produce a nivel poblacional ya que una población con mayor porcentaje de individuos vacunados se resiste al contagio entre las personas (efecto manada o inmunidad de grupo).^[46]

La gran ventaja de los diseños ecológicos es su facilidad de implementación y bajo costo, ya que los datos son en general recolectados por sistemas de datos rutinarios. La desventaja más grande es que son los estudios que aportan menor fortaleza en sentido causal. Tienen un enorme valor en la generación de información para salud pública y gestión de salud.

¿Cuál es el mejor diseño?

Si bien es común ordenar los diseños por el grado de evidencia que son capaces de generar. Es interesante resaltar que la clasificación de la evidencia depende del grado de fortaleza causal que se puede generar con un determinado tipo de estudio. Los ensayos clínicos aleatorizados son los que generan mayor evidencia causal, pero no todas las preguntas pueden contestarse con ensayos clínicos. No existe un diseño único para contestar todas las preguntas. Cada pregunta tiene un mejor diseño para contestarla. El diseño más apropiado depende de la pregunta de investigación.

Por ejemplo ¿Cuál es la prevalencia de esclerosis múltiple en las poblaciones urbanas de Argentina? es una pregunta que se contesta con un estudio de corte transversal o de prevalencia.

¿Cuál es el efecto de una campaña de vacunación antigripal sobre las interacciones por neumonía en una determinada población? Es una pregunta que podría contestarse apropiadamente con un estudio de intervención poblacional antes y después de la implementación de la campaña.

Si mi interés como investigador es generar y validar un instrumento pronóstico para identificar los individuos con EPOC que tengan mayor probabilidad de morir o internarse en un año luego de una internación, probablemente el mejor diseño sea una cohorte prospectiva. Pero se podría contestar apropiadamente con una cohorte retrospectiva.

Si mi pregunta fuera ¿el consumo crónico de estatinas mejora las interacciones de los pacientes con enfermedades autoinmunes? probablemente requeriría un ensayo clínico aleatorizado para su respuesta. Sin embargo, se podría aproximar a través de una cohorte retrospectiva. También podría contestarse con un estudio de casos y controles. Cada aproximación tendrá sus ventajas y desventajas. Si pensamos en la pregunta ¿la circuncisión reduce la transmisión del HIV? ¿Cuántas formas hay de contestarla? ¿Qué ventajas y que desventajas tendría cada diseño seleccionado para contestarla?

4

VARIABLES, MEDIDAS DE RESUMEN Y MEDIDAS DE ASOCIACIÓN

¿Qué son las variables?

Se podría definir las variables como toda porción de la realidad que puede ser medida. Se llama variable a cualquier aspecto que es posible conceptualizar y potencialmente podría tomar valores diferentes entre individuos o unidades de observación. Con el instrumento apropiado se puede medir cualquier aspecto de la realidad: fisiológicas, medicación, sociales, demográficas, comportamientos, genéticas, fisiopatológicas, culturales, económicas, entre muchas otras.

Algunos ejemplos de variables son el sexo que puede tomar valores masculino y femenino. El género comprendido como identidad sexual en relación con la sociedad y la cultura, puede aproximarse con escalas diferentes y puede tomar diferentes valores en un determinado espectro, existiendo diferentes formas para medir y representarlo. La edad, la presión arterial, el consumo de una determinada medicación, su dosis, la presencia o ausencia de una enfermedad como la colitis ulcerosa, la exposición a un tóxico como la radiación ambiental, el nivel socioeconómico, el antecedente familiar de depresión, la calidad de vida, la zona de residencia, el tiempo al infarto o la muerte son algunos ejemplos de variables.

Cuando una herramienta mide apropiadamente el concepto de interés en un determinado contexto, se dice que está validada. Se llama validación de un instrumento de medición, al proceso de acumulación de evidencia sobre la capacidad de un instrumento para representar un concepto de interés. Por ejemplo, la depresión es un constructo no medible directamente. Es un concepto que sirve para tomar conductas y creemos corresponde a un estado psicológico de relevancia. Algunos instrumentos para la medición de depresión son *Beck Depression Inventory*,^[47] *Hamilton Rating Scale for Depression*^[48] y *Montgomery Asberg depression Rating Scale*.^[49] Cada una de estas escalas tiene sus propiedades particulares para la medición y representación del concepto depresión.

En un determinado estudio, al seleccionar la población blanco sobre la que se generalizarán los resultados, se utilizan variables. Los criterios de selección son variables en el mundo real, que fijo para delimitar la población blanco de mi estudio. De esta manera, en mi estudio estas variables pasan a ser constantes. Por

ejemplo, si un estudio incluirá pacientes mayores a 65 años con infarto agudo de miocardio de Argentina, las variables edad mayor de 65 (Sí) , infarto agudo de miocardio (Sí) y país de origen (Argentina) pasan a ser constantes.

¿Cómo se clasifican las variables?

Las variables se pueden clasificar de diferentes maneras. Habitualmente se las clasifica de acuerdo a la naturaleza de la información que contiene en dos grandes grupos: cuantitativas y categóricas.

Las variables cuantitativas representan números verdaderos. Que sean números implica que las operaciones matemáticas tienen sentido usando las variables cuantitativas. A su vez pueden clasificarse en variables cuantitativas continuas y las discretas.

Las cuantitativas continuas son las variables en las cuales todo valor entre dos mediciones tiene sentido. Por ejemplo, la altura, el peso, la presión arterial y cualquier medida de tiempo. Las fracciones tienen sentido y tanta importancia como los números enteros. Un individuo puede medir 1,7 y otro 1,8. Medir 1,75 es posible y tiene sentido. A su vez entre 1,7 y 1,75, está el 1,725. Todos estos números tienen una interpretación natural, son posibles y tienen sentido.

Las variables cuantitativas discretas son aquellas variables en las cuales sólo tienen sentido los números enteros. Corresponden a las cuentas de cosas, como cantidad de hijos o cantidad de eventos de infarto que tuvo un individuo durante su seguimiento. El aumento de una unidad es siempre igual y homogéneo: para pasar de 1 a 2 hijos, es necesario agregar la misma cantidad de hijos, que para pasar de 3 a 4 hijos. Nadie tiene 2 infartos y medio ni 1,333... hijos. Si bien las fracciones no tienen sentido, en muchas ocasiones se suelen tratar como variables continuas a los fines prácticos. En muchas ocasiones las variables continuas se discretizan debido a la resolución de la herramienta de medición. Por ejemplo, muchas veces en las mediciones de tiempo que es naturalmente continua, se suelen discretizar por ejemplo, en días u horas de acuerdo al problema bajo estudio.

Las variables categóricas son aquellas que corresponden a categorías exhaustivas y mutuamente excluyentes. Los individuos se clasifican en categorías. Estas categorías pueden codificarse utilizando números. Esto facilita el análisis de muchos de los paquetes estadísticos. Estos números equivalentes a los códigos de las categorías no son números en realidad sino códigos numéricos que identifican las categorías. Las operaciones matemáticas con estos códigos no tienen sentido. Se dividen en ordinales y nominales.

Las variables categóricas ordinales son las que las categorías tienen un orden natural. Suelen representar una variable continua atrás no observable. Los scores y escalas corresponden a esta categoría. Como el score de Charlson que representa el grado de comorbilidad de un paciente. Un charlson de 2 tiene más comorbilidad que un score de 1. A su vez un score de 5 es mayor que un score

de 4. Una característica de las variables ordinales es que si bien las categorías contiene un orden natural, la cantidad de comorbilidad que se le agrega a un individuo para pasar de 1 a 2 no es la misma que para pasar de 4 a 5. Otras variables ordinales son el Mini-Mental test o test de Folstein,^[50] la escala de nivel socioeconómico^[51,52] y la escala de coma de Glasgow.^[53]

Las variables categóricas nominales son categorías no ordenadas. El orden de las categorías no transmite información. Algunos ejemplos pueden ser país de origen (Italia, España, Alemania, Egipto), profesión (enfermero, kinesiólogo, ingeniero, bioquímico), tipo de diabetes (tipo 1, tipo 2, MODY). Se codifican habitualmente con números. Pueden ordenarse por frecuencia, por importancia, por orden alfabético, o utilizando cualquier otro criterio que tenga sentido para cada situación.

Dentro del grupo de las variables categóricas nominales, hay un subgrupo de particular interés que son las categóricas nominales dicotómicas que contienen sólo dos categorías. Las variables dicotómicas son más fáciles de conceptualizar, registrar, estudiar, analizar, reportar y comunicar. Ejemplos de variables dicotómicas son diabetes, hipertensión arterial, sexo. En general se codifican como 0 (No) y 1 (Sí).

¿Cuánta información contiene cada tipo de variable?

Las diferentes tipos de variables contienen diferente cantidad de información. La cantidad de información está relacionada con el poder para detectar diferencias. A mayor información, más poder para detectar diferencias. A su vez, suele ser más dificultoso recolectar las variables con la mayor cantidad de información. La dificultad puede estar relacionada con el tiempo que lleva la medición, el costo o los recursos que se necesitan. Si las distintas alternativas tienen el mismo grado de dificultad y costo, siempre se debe recolectar la información más granular.

Para un mismo fenómeno, una variable continua contiene la máxima información y una variable dicotómica contiene la mínima cantidad de información. Las variables dicotómicas son más fáciles de recolectar, medir, comprender y comunicar. Esto es lo que las hace extremadamente populares.


Si me interesara representar la masa grasa de un individuo, puedo tomar diferentes estrategias para medir el fenómeno. Puedo medir peso y talla. Con estas dos mediciones continuas, puedo calcular el índice de masa corporal (BMI) que es una medida continua que se calcula con peso/talla². Puedo poner al BMI puntos de corte y dividir en 4 categorías: bajo peso (<18,5 kg/m²), normopeso (>=18,5 kg/m² y <25), sobrepeso (>=25 kg/m² y <30) y obesidad (>=30 kg/m²). A su vez puedo solo querer representar sólo Obesidad (>=30 kg/m²) No/Sí. De esta manera, pasamos de dos variables continuas a una variable continua, luego a una categórica ordinal, por último categórica nominal dicotómica. Pasamos de información muy granular a mínima información.

Es fundamental destacar que si recolecto la variable como peso y talla puedo

realizar el resto de las transformaciones. Si la recolecto como obesidad No/Sí, no podré reconstruir la variable BMI. Este aspecto es muy importante, ya que por ejemplo los puntos de corte de BMI por ejemplo podrían cambiar en diferentes momentos de la ciencia. Por eso se recomienda recolectar la información lo más granular posible y posteriormente procesarla de acuerdo al plan preespecificado, para mejorar su comprensión.

¿Cuántas formas podría tener recuperar la variable edad? ¿Cuál contiene mayor información? ¿Cuál es más fácil de recuperar?

Figura 6. A mayor granularidad de la información, mayor dificultad en la medición. Este es un ejemplo de un mismo concepto representado con variables que contienen diferente tipo y cantidad de información.



¿Cómo se clasifican las variables de acuerdo a su función en el estudio?

Adicionalmente es posible clasificar las variables por su función en el estudio. Para un estudio analítico, se pueden clasificar las variables en variables de exposición o independiente y variable de respuesta o dependiente. Otras variables

del estudio cumplen el rol de ser variables descriptivas, potenciales confundidores, potenciales modificadores de efecto, variables mediadoras, variables que definen subgrupos, variables administrativas (como adherencia, seguimiento, datos de contacto).

Esta clasificación tiene importancia radical en la planificación y asignación de esfuerzos y recursos en cada uno de estos aspectos.

¿Qué utilidad tiene clasificar las variables?

Clasificar las variables tiene utilidad directa sobre la toma de decisiones en el contexto de un estudio de investigación. Si quisiera representar un concepto como BMI o la edad, ¿cuál es la mejor forma de recolectar esa información? ¿cuál es la mejor forma de testear hipótesis utilizando esa información? ¿cuál es la mejor forma de presentar los resultados?

De acuerdo con el tipo de variable, se toman un conjunto de decisiones críticas. La forma de recolección, la forma de recuperar, la forma de almacenar en una base de datos, la medida de frecuencia o tendencia central, el test de hipótesis, la medida de asociación, la forma de presentar los resultados, la forma de interpretarlos. Todas estas decisiones se toman en función del tipo de variable considerada.

¿Cómo elijo las variables a medir?

De acuerdo a la pregunta, es fundamental seleccionar qué variables es necesario medir para poder contestarla de manera apropiada y válida.

Es fundamental medir las variables que componen la pregunta de investigación, las variables que necesitemos para describir los pacientes incluidos en nuestra muestra, los potenciales confundidores, los modificadores de efecto. Para todas estas variables es fundamental conocer el tema tanto por experiencia al respecto y lectura específica. ¿Cómo eran los grupos incluidos en estudios similares? ¿Cómo se midieron las variables en otros estudios similares? ¿Cuáles son los potenciales confundidores que incluyeron y evaluaron en estudios similares? La discusión grupal con colegas y especialistas es fundamental para madurar y realizar una lista completa de las variables a medir.

Una aproximación es construir un tipo de diagrama causal que se llama diagrama acíclico dirigido (DAG). En este diagrama se conceptualiza la pregunta principal y todas las variables principales que podrían tener relaciones causales con la pregunta del estudio.^[27] Estos diagramas son representaciones poderosas y simples, que permiten comunicar el problema de manera eficiente, seleccionar qué medir, cómo analizar y detectar potenciales fuentes de amenazas a la validez específicas.

Los DAGs son simplemente nodos unidos por flechas. Las flechas implican relaciones causales. Los nodos representan variables, sean o no medibles u obser-

vables. Para la construcción del DAG es muy importante que se incluyan todas las causas comunes de al menos dos nodos. Es fundamental que en esta construcción participen todos los que conocen el problema y han profundizado en experiencia y lectura relevante al respecto.

¿Qué son los parámetros poblacionales y los estimadores muestrales?

Las preguntas de investigación se plantean siempre sobre la población blanco. Cuando nos hacemos una pregunta de investigación, nos interesa que la respuesta se extrapole a esta población blanco. Es decir, que en el campo de la generación de conocimiento, siempre queremos conocer cuál es el comportamiento de la población blanco. ¿Cuál es la mortalidad de una determinada enfermedad? ¿Cuál es la sensibilidad y la especificidad de la radiografía de tórax para la detección de nódulos pulmonares? ¿Cuáles son los factores de riesgo para infarto de miocardio? ¿Es más eficaz el tratamiento A que el tratamiento B para el tratamiento de hipertensión arterial?

Supongamos que en la última pregunta, me interesaría conocer la asociación entre el tratamiento A o B y el control de la hipertensión en la población blanco. En este caso me interesaría saber la verdadera asociación en esta población. Según la definición que presentamos anteriormente, la población blanco es inabarcable y desconocida, ya que incluye todos los hipertensos (los que existieron, los que existen, los que tienen diagnóstico y los que no, los que van a existir). Esta definición amplia de la población blanco, implica que no es posible conocer nada de su comportamiento, ya que ni siquiera es posible identificar los individuos que componen la población blanco en su totalidad. Esta es la razón por la cual no es posible observar el comportamiento de la población blanco. A su vez me interesa conocer la asociación en la población blanco, ya que se extrapola a los próximos pacientes con diagnóstico de hipertensión y por lo tanto sustenta las decisiones clínicas.

Cualquier medida que me interese conocer, si la pudiera medir en la población blanco se llama parámetro poblacional. Los parámetros poblacionales son los verdaderos valores de las medidas que me interesa conocer en una determinada población. Debido a nuestra imposibilidad técnica para observar la población blanco, los parámetros poblacionales son desconocidos. Tanto la pregunta como la hipótesis se plantean siempre en parámetros poblacionales y se representan con letras griegas. Por ejemplo el verdadero valor de la media de la presión arterial sistólica medido en la población blanco sería el parámetro poblacional. El verdadero valor de la media de asociación entre el tratamiento A o B y la respuesta de la presión arterial medido en la población blanco sería el parámetro poblacional. El verdadero valor de la sobrevida de los pacientes con cáncer de pulmón estadio 4 en la población blanco sería el parámetro poblacional.


Sólo podemos conocer el comportamiento de los parámetros poblacionales a través de muestras. La muestra es un conjunto de unidades de observación

concreta. En la muestra, es posible realizar las mediciones de las variables o medidas que nos interesan. Con la herramienta adecuada, el comportamiento en la muestra puede ser medido y será conocido. Todo lo que mido en una muestra se llama estimador muestral. Corresponde a nuestra estimación a través de una muestra del comportamiento del parámetro poblacional.

Si bien los estimadores muestrales no son el parámetro poblacional que queremos conocer, son la única aproximación posible. Los estimadores muestrales están sujetos a azar de muestreo. Esto significa que puedo conocer mucho del comportamiento de los estimadores muestrales a través del Teorema del Límite Central (ver más adelante ¿Qué es el azar de muestreo?).^[54] El comportamiento de los estimadores muestrales es conocido. Debido a que no es posible observar los parámetros poblacionales y siempre trabajamos con estimadores muestrales como nuestra aproximación a conocer la realidad, es que necesitamos la inferencia estadística. La estadística es conjunto de métodos nos permitirá conocer el comportamiento del parámetro poblacional a través de los estimadores muestrales medidos en nuestra muestra.

Cualquier cosa medida en una muestra es un estimador muestral de un parámetro poblacional. La media de edad de mi muestra. La prevalencia de un polimorfismo específico de un gen. El riesgo relativo para tener un infarto entre los tratados con la droga A o B. La sensibilidad de un test para detectar los verdaderos enfermos. La sobrevida estimada de pacientes diabéticos con daño de órgano blanco. Todo lo medido en una muestra son estimadores muestrales de parámetros poblacionales.

Figura 7. Si pudiera conocer una proporción en la población blanco sería el verdadero parámetro poblacional de esa proporción (π). Como esto no es posible, la aproximamos a través de la medición de esa proporción en una muestra ($\bar{p}$).



¿Qué son las medidas de resumen?

Cualquier variable medida en una muestra es un conjunto de datos. Cada dato es el valor que toma la variable específica en una unidad de análisis particu-

lar. Naturalmente estos valores son una lista de valores para una determinada variable. Cada variable estará representada por una lista de valores para cada unidad de análisis. Esta complejidad podría ser fácil de entender presentando e interpretando la lista cuando las unidades de observación son pocas, pero ésta no es la forma más eficiente.

Esta lista puede procesarse para generar información a través de medidas que resuman la lista a un número comprensible. Este número comprensible de resumen nos permitirá conocer el comportamiento de la variable, presentarlo y comunicarlo. Esta aproximación funciona independiente de la cantidad de unidades de observación. Las medidas de resumen son diferentes para variables cuantitativas que para las categóricas.

¿Cuáles son las medidas de resumen para variables cuantitativas?

Para las variables cuantitativas, las medidas de resumen se dividen en medidas de tendencia central y medidas de dispersión. Ambas dan información diferente. A su vez existen formas gráficas extremadamente informativas que brindan muchísima información adicional. Toda variable cuantitativa se puede presentar en un histograma de frecuencias que muestra como se distribuyen los datos de una muestra. El histograma presenta las frecuencias observadas de datos en una muestra y puede ser simétrico o asimétrico.

Las medidas de tendencia central dan idea de donde se agrupan la mayoría de los datos, cual es la tendencia central de los datos. Las más conocidas son la media, la mediana y el modo. La media es el promedio de todas las observaciones y representa el centro de la distribución cuando son distribuciones simétricas. Cuando las distribuciones son asimétricas, el promedio pierde esta propiedad de representar el centro de la distribución. La mediana es una medida más robusta a las distribuciones asimétricas o la presencia de datos atípicos (outliers). La mediana representa el valor que divide el 50% de los valores ordenados por arriba y el 50% de los valores por debajo. Es el percentil 50, y es más robusta a la presencia de asimetrías o outliers. El modo es el valor que más veces aparece en la muestra o el pico más alto. No se utiliza mucho, salvo en situaciones donde las distribuciones muestran más de un pico.

Las medidas de dispersión describen que tan alejados están los datos de la medida de tendencia central. Las más utilizadas son el rango, desvío estándar, la varianza, el intervalo intercuartil o el rango intercuartil. El rango sólo representa la distancia que existe entre el mínimo valor y el máximo. El desvío estándar representa cuánto se alejan en promedio los datos de la media. La varianza es el desvío estándar al cuadrado. El intervalo intercuartil es el percentil 25 y el 75, es decir que nos da idea de desde dónde hasta dónde van el 50% de los datos centrales. En las distribuciones simétricas, es posible usar cualquiera de estas medidas. En las dispersiones asimétricas es preferible usar rangos o intervalo intercuartil.

Para describir variables cuantitativas es fundamental presentar siempre una medida de tendencia central y una medida de dispersión. Con estos dos números es posible transmitir lo fundamental del comportamiento de la variable en la muestra. Ver la distribución a través de un histograma, por ejemplo, es muy importante para la decisión de cuál medida de tendencia central y cuál de dispersión presentar.

¿Qué son las medidas de frecuencia?

Para las variables categóricas se utilizan medidas de resumen diferentes que se llaman medidas de frecuencia. La idea es representar los tamaños de cada una de las categorías en una muestra. Algunas medidas de frecuencia son la prevalencia, la incidencia, y el odds.

La incidencia representa los casos nuevos en un determinado período de tiempo. Esta medida de frecuencia no considera los casos preexistentes, sino sólo los nuevos durante el período de observación. Habitualmente se multiplica por un tamaño poblacional para expresarla en un número que tenga sentido y sea más fácil de entender e interpretar. Por ejemplo una incidencia de 0,0003 de un determinado evento, puede multiplicarse por 10000 y ser expresada como incidencia de 3 por 10000. El multiplicador se elige según la situación y considerando la literatura publicada al respecto.

Las incidencias tiene dos formas: la incidencia acumulada y la densidad de incidencia. La incidencia acumulada es la incidencia clásica. Se calcula con los nuevos casos detectados en un determinado período de tiempo, dividido por los pacientes en riesgo durante ese mismo período. El denominador se calcula contando la totalidad de los individuos al inicio del seguimiento. Sirve para cohortes cerradas donde los tiempos de seguimiento son iguales o no existe pérdida al seguimiento (censura, ver más adelante Métodos para datos censurados).

La densidad de incidencia se utiliza para las cohortes abiertas o dinámicas en las cuales el período de seguimiento es variable. En este caso se calcula como los nuevos casos dividido por la cantidad de personas tiempo en riesgo. El denominador de personas tiempo se calcula sumando la totalidad de unidades de tiempo que aporta cada individuo durante el seguimiento. Es decir que si la unidad de tiempo es el año y un individuo fue seguido por 3 años, ese individuo aporta al denominador 3 personas año. Esta forma de presentar las incidencias es robusta al seguimiento diferente entre individuos. Por ejemplo si tengo una densidad de incidencias de 1,5 por 10.000 personas año, quiere decir que por cada 100.000 personas que sigo un año, espero detectar en promedio 15 nuevos casos.

La prevalencia representa los casos existentes en un determinado momento. Se calcula con la totalidad de casos dividido por la totalidad de la población. Puede expresarse en proporción o porcentaje. Por ejemplo si tengo 5 casos de una determinada patología en 150 individuos, puedo decir que la prevalencia es de

0,033 o de 3,3%. Esta prevalencia se interpreta como que existen 3,3 individuos por cada 10 en una determinada población.

Tanto el la incidencia como la prevalencia pueden ser interpretados como riesgos o probabilidades, con interpretación diferente.

El odds es una medida de frecuencia diferente. Se calcula con los individuos que tienen una condición dividido por los que no la tienen. De la misma manera que las medidas anteriores da información de la frecuencia, pero no existe una traducción satisfactoria al castellano: algunos autores proponen momios o chances como traducción aceptable. El odds no es una probabilidad pero puede calcularse la probabilidad a partir del odds. El odds y el riesgo se parecen cuando las frecuencias son pequeñas.

Por ejemplo si tengo 2 mujeres y 3 hombres, puedo decir que el odds de mujeres es $2/3$ o lo que es lo mismo que 0,66. Una forma alternativa de dar la misma información es el odds de hombres $3/2$ o lo que es lo mismo 1,5. En escala logarítmica, 0,66 y 1,5 están a la misma distancia del 1 pero en sentidos diferentes y representan la misma frecuencia. Un odds de 1 quiere decir que hay la misma frecuencia de mujeres y hombres en la población.

¿Qué son las medidas de asociación?

Las medidas de asociación representan asociaciones entre dos variables. De acuerdo a la naturaleza de las dos variables, se seleccionarán medidas de asociación diferentes. Como comentamos anteriormente, la asociación no implica causalidad. Simplemente es una medida de la dependencia entre dos variables. Cuánto se de la ocurrencia de una variable B si conozco el valor de otra variable A. Si dos variables no están asociadas, conocer la ocurrencia de una, no dice nada del comportamiento o frecuencia de la otra.

Las medidas de asociación dan idea de la direccionalidad de la asociación. ¿Ambas variables van el mismo sentido o en sentido contrario? Dan idea de la magnitud de la asociación ¿Cuánto es el cambio de una variable de respuesta con respecto al cambio de la variable de exposición? A su vez, a través de la estimación e interpretación de intervalos de confianza, la medida de asociación nos permite decir si existe o no asociación entre dos variables (ver más adelante Test de Hipótesis e Intervalos de confianza).

¿Cómo se clasifican las medidas de asociación?

Las medidas de asociación entre dos variables categóricas se pueden dividir en medidas de asociación relativas y absolutas.

Las medidas de asociación relativas se calculan con divisiones entre dos medidas de frecuencia. Por eso reciben el nombre de medidas multiplicativas. Algunas de las más frecuentes son el riesgo relativo y el odds ratio. Variaciones del riesgo relativo son la razón de prevalencias, razón de incidencia acumuladas, razón de densidad de incidencias, hazard ratio y tiempos relativos. Todas estas

medidas de asociación tienen interpretaciones similares. En todos los casos son números positivos y el no efecto es el 1, por encima es una asociación positiva y por debajo del 1 es asociación negativa.

El odds ratio tiene propiedades particulares que los popularizaron como medida de asociación. En particular el ser la salida natural de los modelos de regresión logística y el ser robusto al tipo de diseño. El odds ratio puede utilizarse en los casos y controles y en cualquier otro diseño. Un odds ratio de 5 se interpreta como que el odds de evento en los expuestos es 5 veces el odds del evento en los no expuestos.

Las medidas de asociación absolutas se calculan restando dos medidas de frecuencia. Son muy eficientes para comprender y comunicar diferencias de riesgo entre dos niveles de exposición. Permiten estimar cuántos casos podría curar por ejemplo si todos estuvieran expuestos o cuantos eventos podría evitar. La más utilizada es la diferencia de riesgos. Otras medidas relacionadas son, la diferencia de prevalencias, diferencias de incidencias acumuladas, diferencias de densidad de incidencias. Todas estas medidas de asociación tienen interpretaciones similares. En todos los casos el no efecto es el 0, los valores positivos implican una asociación positiva y los valores negativos asociación negativa.

Otras medidas de asociación

Los coeficientes de correlación son medidas de asociación entre dos variables continuas. El coeficiente de correlación de r de Pearson mide la asociación lineal entre dos variables continuas. Sólo es aplicable cuando la relación entre ambas variables es razonablemente lineal y la distribución de los residuos es razonablemente normal. Cuando se violan los supuestos se puede utilizar el coeficiente de correlación de Spearman que se calcula de la misma manera que el de Pearson pero utilizando los rangos.

El coeficiente de correlación de r de Pearson es un número que se mueve entre -1 y +1, siendo el 0 el no efecto. Es independiente de las unidades de las variables con las que se calcula. Cuando el coeficiente de correlación está entre -1 y 0 es negativa o inversamente proporcional. Cuando es entre 0 y 1 es asociación positiva o directamente proporcional. El grado de correlación da idea de la magnitud del efecto: una correlación de 1 representa correlación perfecta y positiva; -1 implica correlación perfecta inversamente proporcional. $\geq 0,8$ es muy alta, entre $\geq 0,6$ y $< 0,8$ alta, entre $\geq 0,4$ y $< 0,6$ moderada, entre $\geq 0,2$ y $< 0,4$ baja, $< 0,2$ muy baja. Estos puntos de corte son sólo orientativos.

Los coeficientes estimados de cada variable explicativa, por un modelo de regresión son medidas de asociación entre la variable explicativa y la variable de respuesta. Los modelos de regresión lineal estiman coeficientes, los modelos de regresión logística estiman odds ratios, los modelos de Poisson estiman razones de incidencias y los modelos de riesgos proporcionales de Cox estiman hazard ratios. Estas medidas de asociación pueden ser crudas en los modelos bivaria-

dos (regresión simple) o ajustadas en los modelos de regresión multivariados (regresión múltiple).

¿Cómo se interpretan las medidas de asociación?

El valor de las medidas de asociación tiene interpretación directa: magnitud del efecto, direccionalidad y testeo de asociación cuando se combina con intervalos de confianza (inclusión o no del no efecto en el intervalo). En todas las medidas de asociación existe un valor que representa el no efecto o la ausencia de asociación.

Existe un rango de valores que implican una asociación positiva (cuando aumenta la variable de exposición, aumenta la variable de respuesta) y un rango de valores que implica una asociación negativa (cuando aumenta la variable de exposición, disminuye la variable de respuesta).

Las asociaciones positivas para efectos negativos habitualmente se llaman factores de riesgo. Si el evento es muerte, todos las exposiciones que se asocian positivamente se pueden llamar factores de riesgo para muerte. A su vez las asociaciones negativas para eventos negativos, se comportan como factores protectores. Los factores que disminuyan el riesgo del evento muerte, son factores protectores para muerte ¿y si defino el evento como vivir en lugar de morir? Las decisiones sobre la definición de la variable específica como vivir o morir se toman considerando el problema particular y la claridad con la que se presentarán los resultados para facilitar su comprensión.

¿Cómo se interpretan las medidas de asociación relativas?

Las medidas de asociación relativas son multiplicativas y toman siempre valores positivos. En este caso, el valor de no efecto es el 1. Esto es equivalente a dividir el riesgo de un evento en un grupo de expuesto por el riesgo del mismo evento en un grupo de no expuestos. Un número dividido por el mismo número es igual a 1. Si ambos riesgos son iguales, quiere decir que el riesgo del evento no depende del grado de exposición o, lo que es lo mismo, que no existe asociación entre exposición y evento.

Con respecto a la direccionalidad, las exposiciones que se comportan como factores de riesgo tendrán medidas de asociación mayores a 1, que se moverán entre 1 y +infinito. Mientras más grande es este número, mayor es la magnitud de la asociación. Las exposiciones que se comportan como factores protectores para un determinado evento, tendrán medidas de asociación menores a 1, que se moverán entre 1 y 0. Mientras más pequeño es este número, mayor es la magnitud de la asociación. Las medidas de asociación multiplicativas no tienen unidades, y se comportan como escalas logarítmicas ya que existe la misma distancia entre 0 y 1 que entre 1 y +infinito.

Por ejemplo un OR de 2 (IC95% 1,32 - 3,01) para tos crónica de fumadores de marihuana comparados con no fumadores, ¿Cómo se interpreta? ¿Qué quiere decir

que sea mayor a 1? ¿Qué quiere decir que el intervalo de confianza no incluya al 1? ¿es un factor de riesgo o un factor protector?^[55]

¿Cómo se interpretan las medidas de asociación absolutas?

Las medidas de asociación absolutas son aditivas y toman valores que van de -infinito a +infinito. En este caso, el valor de no efecto es el 0. Esto es equivalente a restar el riesgo de un evento en un grupo de expuesto menos el riesgo del mismo evento en un grupo de no expuestos. Un número menos el mismo número es igual a 0. De la misma manera que para las medidas relativas, si ambos riesgos son iguales, quiere decir que el riesgo del evento no depende del grado de exposición o, lo que es lo mismo, que no existe asociación entre exposición y evento.

Con respecto a la direccionalidad, las exposiciones que se comportan como factores de riesgo tendrán medidas de asociación mayores a 0, que se moverán entre 0 y +infinito. Mientras más grande es este número, mayor es la magnitud de la asociación. Las exposiciones que se comportan como factores protectores para un determinado evento, tendrán medidas de asociación menores a 0, que se moverán entre 0 y -infinito. Mientras más pequeño es este número, mayor es la magnitud de la asociación. Las medidas de asociación aditivas están en la misma escala que las mediciones de la variable y en las mismas unidades.

En un estudio se asignó al azar al uso de una aplicación de teléfonos celulares y se midió el efecto sobre diferentes eventos. La rama activa tenía una reducción en el porcentaje de los fumadores de 25,6% y 15% en el grupo control. La diferencia de riesgo absoluto fue de 10,6% con un p valor 0,135.^[56] ¿Cómo se interpreta esta diferencia de riesgos? ¿Cuál es la hipótesis nula de este test de hipótesis? ¿qué quiere decir ese p valor no significativo?

5

AMENAZAS A LA VALIDEZ

¿Qué es la validez de un estudio?

Los resultados de un estudio son válidos cuando son capaces de representar la realidad del fenómeno bajo estudio. Sólo los resultados válidos permiten conocer el comportamiento de la población blanco. Esto es fundamental ya que sólo el conocimiento válido puede extrapolarse a nuestros pacientes.

¿Qué es la validez interna?

La validez interna depende de como está construido un estudio para contestar una determinada pregunta. Depende de las decisiones que se tomaron para contestar esa pregunta. ¿El diseño es el apropiado? ¿Las mediciones que se eligieron representan el fenómeno que se quería representar?

Por ejemplo, puedo representar el fenómeno calidad de vida preguntando: ¿Usted tiene o no calidad de vida? o puedo aplicar una herramienta de medición de calidad de vida validada de 36 preguntas estructuradas como el SF-36. Este cuestionario fue validado para medir diferentes aspectos de la calidad de vida con un comportamiento conocido.^[57]

Un estudio con alta validez interna se consigue con procedimientos altamente estandarizados, pacientes muy homogéneos y mediciones muy precisas como los ensayos clínicos clásicos. Si bien la validez es un aspecto fundamental de los estudios, cuando la validez interna es a expensas de la validez externa se compromete la generalizabilidad de los resultados. Este problema es típico de los ensayos clínicos de eficacia. En estos estudios se maximiza la validez interna y se compromete la validez externa o generalizabilidad de los resultados.

¿Qué es la validez externa?

La validez externa es la generalizabilidad de los resultados a una determinada población blanco. No existe validez externa sin validez interna. Si la construcción del estudio no es apropiada, no es posible generalizar. ¿Los resultados de un determinado estudio, son extrapolables a los pacientes que veo en consultorio? ¿Los resultados de un ensayo clínico clásico son extrapolables a los pacientes que vemos todos los días en consultorio ambulatorio en la práctica clínica diaria?



¿Los resultados de los estudios hechos en países desarrollados, se generalizan a los países en desarrollo?

Los ensayos clínicos pragmáticos se caracterizan por tener mucha validez externa. Esto se debe a que seleccionan pacientes más parecidos a los pacientes reales, sin usar criterios de selección restrictivos. A su vez las mediciones y seguimiento de los pacientes se parecen más a lo que ocurre con el seguimiento en la vida real de los pacientes. La contrapartida de esto es que requieren tamaños muestrales más grandes ya que la magnitud de los efectos es menor y la variabilidad mayor.

Por ejemplo en este ensayo clínico *The Hypertension in the Very Elderly Trial (HYVET)*,^[58,59] en el que se evaluó una intervención para el tratamiento de la hipertensión en pacientes mayores de 80 años. Esta población se excluye sistemáticamente de los demás estudios de investigación. Una de las críticas que se le hizo a este estudio es que excluyeron comorbilidades y que la población mayor a 80 años habitualmente tiene muchas comorbilidades ¿A qué población se extrapolan los resultados de este estudio?

¿Cuáles son las amenazas a la validez?

Las amenazas a la validez son los sesgos, los confundidores y el azar de muestreo. El nombre deriva de que cuando están presentes, comprometen la validez de los resultados de un estudio. Conocerlas permite implementar estrategias apropiadas para prevenir, detectar y en muchos casos, corregir su efecto.

¿Qué son los sesgos?

Los sesgos son errores sistemáticos direccionales no intencionales. Pueden producirse durante el diseño o la ejecución del estudio. Son sistemáticos porque afectan al estudio de manera sistemática en contraposición con los errores aleatorios. Son direccionales porque tienen el potencial de generar una direccionalidad en la estimación (para las preguntas descriptivas) o las medidas de asociación (para las preguntas analíticas). No son intencionales para los investigadores, los errores intencionales de los investigadores se llaman fraude. Se clasifican en sesgos de selección y de información (para una clasificación más completa sobre sesgos ver el artículo Bias de Delgado-Rodríguez M. y Llorca J.).^[16]

Si la pregunta central de mi estudio es descriptiva, los sesgos pueden distorsionar la estimación. Si la pregunta de mi estudio es analítica, los sesgos pueden distorsionar la medida de asociación (a través de la distorsión de las estimaciones). Pueden hacer aparecer asociaciones que no existen, hacer desaparecer asociaciones que existen o distorsionar la magnitud de las asociaciones.

Una vez que ocurrió un sesgo no se puede resolver posteriormente. Por esta razón, es fundamental pensarlos de antemano durante la fase de diseño del estudio y emplear todas las estrategias posibles para minimizar su ocurrencia.

Un subtipo diferente de sesgo es el sesgo de publicación. El sesgo de publica-

ción es diferente porque afecta el conocimiento disponible. Desde el punto de vista clásico, tienen mayor probabilidad de publicarse y difundirse los artículos con resultados positivos.^[60] Adicionalmente los artículos producidos en los países desarrollados tienen mayor probabilidad de publicarse, y por lo tanto predominan en la literatura internacional. Este sesgo afecta todo el conocimiento publicado y particularmente los metanálisis.^[61]

¿Qué son los sesgos de selección?

Técnicamente los sesgos de selección son los que afectan la continuidad desde la población blanco - población accesible - a la muestra a favor de subgrupos de individuos con características particulares. Afectan la probabilidad de un individuo o unidad de observación de formar parte de la muestra o de permanecer en el estudio.

¿Cómo se alterarían los resultados de un estudio si tienen mayor probabilidad de estar en la muestra los individuos más viejos? ¿Y los más graves? ¿O los más sanos? ¿O los de mayor nivel socioeconómico? ¿O los diagnosticados? ¿O los que presentan una complicación? ¿Cómo se alterarían los resultados si tuvieran mayor probabilidad de permanecer en el estudio los pacientes más graves? ¿O los que toleran bien la medicación? ¿O los que son capaces de adherir a los procedimientos del estudio? ¿Y si los pacientes que se pierden son los que tienen menos dolor? ¿O los que fallecen?

Asegurar que una muestra de individuos representa la población blanco es fundamental. Sería imposible sacar conclusiones sobre el comportamiento de la población blanco si la muestra no fuera verdaderamente aleatoria. Los sesgos de selección pueden existir cuando la población accesible de un estudio no representa la población blanco. Por ejemplo si mi pregunta es ¿La droga A es eficaz en el control de la presión arterial en el tratamiento de los pacientes con hipertensión? y decido realizarlo con hipertensos internados, podría estar induciendo un sesgo ¿Representan la población blanco de hipertensos los hipertensos internados? ¿Y los pacientes hipertensos en seguimiento en un hospital universitario de alta complejidad representan la población blanco de hipertensos? A su vez, la permanencia en el estudio puede generar sesgos de selección. La pérdida selectiva de pacientes con características especiales que causan que se pierdan, generan sesgo. Qué pasaría si en un estudio con seguimiento en el tiempo, ¿Se pierden sistemáticamente los más viejos? ¿O los que tienen peor nivel socioeconómico? ¿O los que el tratamiento no les es efectivo? ¿O los que no toleran la medicación? ¿Se pierden los más graves? ¿Se pierden los que fallecen?

Si mi pregunta fuera ¿Cuál es el efecto del consumo crónico de aspirina en bajas dosis sobre las infecciones? y me planteara estudiarlo en una cohorte retrospectiva de 10 años de registros. Imaginemos que puedo clasificar correctamente a los adultos de mi cohorte en tomadores de aspirina y no tomadores de aspirina.

En un estudio prospectivo y aleatorizado, la única diferencia entre ambos grupos sería que unos toman aspirina y los otros no, sin ninguna otra diferencia entre ambos grupos. Sin embargo en el estudio retrospectivo, ¿hay razones para pensar que los que toman aspirina son diferentes a los que no las tomaron? Sin duda hay razones por las cuales a un grupo le indicaron aspirina crónica y al otro no: esperaría que fueran más viejos, con mayor proporción de hombres, más diabéticos, más dislipidémicos, más hipertensos, más enfermos coronarios, más sedentarios, con mayor BMI ... entre otros. Es decir, esperaría que fueran diferentes en todas las causas que hacen que alguien tome la decisión indicar aspirina a un determinado paciente. Este fenómeno se llama confusión por indicación y es un sesgo de selección en el sentido que genera grupos diferentes no comparables en el análisis crudo.^[62] (Ver Figura 8)

¿Cómo minimizo los sesgos de selección?


Lo más importante es pensar en los sesgos precozmente para diseñar estrategias que permitan prevenirlos o minimizarlos. Algunas estrategias para minimizar los sesgos de selección de inclusión en el estudio son la asignación aleatoria de tratamientos, el muestreo aleatorio, los criterios de selección más amplios y no restrictivos. Las estrategias para minimizar los sesgos de selección de permanencia en el estudio son las que minimizan las pérdidas de los pacientes en seguimiento como aumentar la adherencia al estudio generando pertenencia, hacer sistemas de seguimiento parecidos al cuidado habitual, hacer mediciones menos intrusivas, diseñar y sostener estrategias para recuperar los pacientes perdidos.

¿Qué son los sesgos de información?

Los sesgos de información son los errores que afectan las mediciones de las distintas variables del estudio. Pueden afectar cualquier variable del estudio, exposiciones, eventos, confundidores, modificadores de efecto u otras. Pueden originarse en el paciente, en el instrumento de medición o en el observador. Las mediciones de las variables son válidas cuando son exactas y representan el fenómeno que se pretende medir.

El error sistemático induce sesgo debido a la direccionalidad. Las mediciones son exactas cuando son muy próximas al verdadero valor de la variable en la realidad. Si aplico una encuesta para medir depresión y cometo el error de sumar 5 puntos extra a todos los individuos, el puntaje obtenido para cada uno no representará el verdadero valor de depresión de cada uno. Sino que estará sobreestimado 5 puntos siempre. Imaginemos que si quisiera evaluar el efecto del tabaquismo sobre la depresión, y a todos los que el investigador le huele olor a cigarrillo les pregunta diferente, induciendo a respuestas en sentido de mayor grado de depresión.

Figura 8. Los sesgos de selección representan una distorsión en el continuo población blanco - población accesible - muestra. Tanto por alteración de la probabilidad de ingresar al estudio como por la probabilidad de permanecer en el estudio. En cualquier caso, el parámetro poblacional es diferente del estimador muestral. En A se muestra un ejemplo de sesgo de selección para una pregunta descriptiva: en este caso la proporción estimada en la muestra no representa la verdadera proporción parámetro poblacional. En B se esquematiza un caso simple de un sesgo de selección para una pregunta analítica. En este último caso, se altera el tamaño de una de las celdas de la tabla de contingencia, por ende la medida de asociación en la muestra no representa la verdadera medida de asociación parámetro poblacional.



¿Cómo minimizo los sesgos de información?

Lo principal es pensarlos de antemano durante la fase de diseño y planificación del estudio. Todas las mediciones del estudio tienen que ser planificadas para maximizar su validez. Algunas estrategias para evitar los sesgos de información son la elección de mediciones validadas, el ciego/enmascaramiento, entrenamiento y estandarización de mediciones, y el uso de mediciones objetivas poco intrusivas.

¿Qué es el error aleatorio?

El error aleatorio surge de variaciones en el método, en las condiciones, en la fisiología. No tiene direccionalidad y por lo tanto no tiene el potencial de generar sesgos, pero si aumenta la variabilidad. El aumento de la variabilidad va a afectar el poder para detectar diferencias que verdaderamente existen cuando estoy evaluando asociaciones (errores estándar más grandes, con consiguientes p valores más grandes) y la precisión de las estimaciones (mayor variabilidad, más amplios los intervalos de confianza).

La precisión de las mediciones es la propiedad por la cual un mismo procedimiento de medición aplicado al mismo individuo da el mismo resultado cada vez que se aplica. Son sinónimos la consistencia, reproducibilidad o confiabilidad. El aumento de la variabilidad se evidencia en medidas de dispersión como el desvío estándar o de consistencia como el coeficiente de correlación, el coeficiente de correlación intraclase o el kappa de acuerdo. Si peso a un individuo con la misma balanza y obtengo 5 pesos muy diferentes en el mismo momento, se trata de una medición no precisa. La precisión se relaciona con el error aleatorio.

¿Qué hago con los sesgos?

Lo mejor que puedo hacer con los sesgos es prevenir que ocurran. Para esto es fundamental la revisión de la literatura con particular foco en las debilidades de los estudios previos. En las discusiones se incluyen los sesgos de los estudios con el objetivo de transparentar lo que el investigador conoce de la validez de su estudio y prevenir la ocurrencia de los mismos errores en futuros estudios.

Si en mi estudio me doy cuenta que hay un sesgo, debo declararlo y discutirlo. Discutir un sesgo implica decir que creo que podría estar, describirlo técnicamente, dar idea de su magnitud y direccionalidad, declarar de que manera pudo afectar mis resultados, compararlo con otros estudios publicados y dar recomendaciones para que otros autores pueden prevenir o advertir este problema en futuros estudios.


¿Qué son los confundidores?

Imaginemos que quiero estudiar si la exposición a A causa que se produzca el efecto B. Si estoy evaluando la asociación entre una exposición A y un efecto

B, un confundidor es una tercer variable que es la verdadera causa de B. Clásicamente un confundidor debe estar asociado a la exposición A y a su vez al efecto B. No debe estar en el camino causal entre A y B. Las variables que se encuentran entre A y B se llaman variables intermeditarias y tienen propiedades y tratamientos diferentes al de los confundidores. Un confundidor puede hacer aparecer una asociación que no existe, hacer desaparecer una asociación que existe o distorsionar la magnitud o el sentido de una asociación bajo estudio. Si bien excede el alcance de este libro, existen definiciones diferentes de confundidores como la que se desprende de los DAGs o diagramas acíclicos dirigidos. Como vimos previamente, los DAGs son diagramas causales que permiten representar de manera sencilla las relaciones causales de las variables de un estudio. Tienen reglas de construcción simples que permiten derivar aplicaciones directas como: selección de las variables a medir, selección de las variables de ajuste, entre otras. Desde el punto de vista de estos esquemas causales, los confundidores son estructuras que abren “caminos de la puerta de atrás”. Estos caminos permiten que la asociación fluya en un sentido no causal y genere asociaciones causales espurias. Para mayor detalle sobre esto ver *Causal Inference Book*.^[27]

Por ejemplo, si yo quisiera estudiar la asociación entre llevar fósforos (A) y tener enfermedad coronaria (B) y considerara ninguna otra información de los participantes de mi estudio, probablemente encontraría que llevar fósforos aumenta el riesgo de enfermedad coronaria. La verdadera razón por la cual llevar fósforos aumenta el riesgo de enfermedad coronaria es porque existe un tercer factor que es fumar (C) que es la verdadera causa del aumento de riesgo de enfermedad coronaria. Fumar causa que alguien lleve fósforos. A su vez fumar causa el aumento de enfermedad coronaria. Se dice que la asociación entre A y B está confundida por C.

Figura 9. Los confundidores son la verdadera causa de la asociación bajo estudio. Deben estar causalmente asociados con la exposición y con el evento de interés. No deben estar en el camino causal. En el estudio de la pregunta ¿Llevar fósforos causa enfermedad coronaria?, fumar es un confundidor.



¿Qué hago con los confundidores?

Es importante notar que se puede hacer mucho con los confundidores si los pienso desde el diseño del estudio y planifico medirlos o utilizar alguna de las



estrategias para tratar confundidores. Los potenciales confundidores de una determinada asociación bajo estudio los postulo de acuerdo a lo que sé del problema, a los confundidores identificados o propuestos por otros autores o artículos para esta asociación o otras similares y de las diferencias que veo entre los grupos que me interesa comparar. No todos los confundidores son medibles o conocidos. No se va a poder evaluar, ni corregir, ni presentar el efecto de un confundidor que no se pensó ni se midió.

Algunas de las estrategias para el tratamiento de los confundidores son restricción, matcheo/apareamiento, estratificación, estandarización, ajuste/análisis multivariado (modelos de regresión) o aleatorización de la exposición. Desde las aproximaciones causales, estrategias adicionales incluyen el peso por la inversa de la probabilidad o *inverse probability weighting (IPW)*, *los scores de propensión o propensity scores*, modelos marginales estructurales, entre otras. Cada estrategia tiene ventajas y desventajas.

Por ejemplo si decido estudiar el efecto entre el tratamiento con estatinas y el desarrollo de accidentes cerebrovasculares a través de un estudio de cohorte retrospectiva. Podría comparar la frecuencia de accidente cerebrovascular en los pacientes que tomaron estatinas en los últimos 15 años y los que no las tomaron en el mismo período. Los pacientes que toman estatinas serían muy diferentes que los que no, de acuerdo al fenómeno de confusión por indicación que describimos previamente. Estas diferencias entre ambos grupos, podrían ser las verdaderas causas de cualquier diferencia de frecuencia que pudiera observar entre tomadores y no tomadores de estatinas en los últimos 15 años y se comportan como confundidores. El fenómeno de confusión por indicación es un sesgo de selección y a su vez un ejemplo claro de un grupo o vector de confundidores.


Si tuviera el recurso económico suficiente podría hacer un ensayo clínico ¿Qué estrategia podría utilizarse para tratar confundidores si estudiara esta asociación a través de un ensayo clínico?

¿Qué es el azar de muestreo?

Siempre que nos hacemos una pregunta de investigación, nos interesa conocer las poblaciones blanco y el comportamiento de sus parámetros poblacionales. La gran dificultad es que es imposible observar las poblaciones blanco. Ni tampoco los parámetros poblacionales. Como presentamos previamente, nuestra herramienta para conocerlos son las muestras y los estimadores muestrales.

El azar de muestreo es el fenómeno por el cual obtuvimos la muestra de nuestro estudio entre las infinitas muestras que podríamos haber obtenido del mismo tamaño para representar el comportamiento de la población blanco y sus parámetros poblacionales. El Teorema del Límite Central describe el comportamiento de esas muestras y nos permite conocer sus propiedades. A continuación describiremos brevemente el teorema y algunas de sus aplicaciones directas.

Figura 10. En este caso el parámetro poblacional que me interesa conocer es 0,5 en la población blanco. Si pudiera tomar infinitas muestras del mismo tamaño de la misma población blanco, las proporciones observadas en cada muestra variarían debido al azar de muestreo.



Teorema del Límite Central

El Teorema del Límite Central plantea un escenario teórico. Generalmente los estudios tienen una única muestra. ¿Pero si pudiéramos tomar infinitas muestras del mismo tamaño de la misma población blanco? El Teorema del Límite Central dice que si nos interesa estimar un parámetro poblacional A , y tomo por ejemplo 1000 muestras de igual tamaño de la misma población blanco, no obtendría exactamente el mismo valor del estimador muestral en cada muestra. Esta variación la llamamos azar de muestreo.

El siguiente link nos permite observar qué pasa cuando tomo múltiples muestras aleatorias del mismo tamaño de la misma población blanco. Es un ejercicio interesante que permite observar directamente cómo se modifica en el siguiente link http://onlinestatbook.com/stat_sim/sampling_dist/ ^[63]

Si tomo esas 1000 muestras y sus estimadores muestrales de A , puedo construir una distribución de frecuencias con un histograma. Ese histograma teórico se llama distribución de muestreo. La distribución de muestreo tiene ciertas propiedades. Cuando el tamaño de las muestras es suficientemente grande, tiene distribución normal. Su media coincide con la media de A en la población. Es decir que la media de la distribución teórica de muestreo, coincide con el parámetro poblacional A .


A su vez el desvío estándar de la distribución teórica de muestreo se llama error estándar. Y se calcula como el desvío estándar/raíz cuadrada (n). Donde n es el

tamaño de las muestras. De esta manera la forma de la distribución de muestreo depende del tamaño muestral.

- Si n es muy grande, la distribución de muestreo es muy angosta. Lo que es lo mismo, la variabilidad entre los estimadores muestrales de A va a ser chica cuando el tamaño muestral sea grande.
- Si n es muy chico, la distribución de muestreo es muy amplia. es decir, si el tamaño muestral es pequeño, la variabilidad entre muestras va a ser enorme.

Este principio aplica a cualquier parámetro que nos interese estimar: medias, proporciones, medidas de asociación. El parámetro poblacional que sea que queramos conocer y aproximemos a través de muestras y estimadores muestrales. Como la única forma que tenemos de conocer la realidad es a través de muestras, todas las mediciones realizadas en muestras están sujetas a este fenómeno.

Figura 11. La distribución de muestreo es una distribución teórica. El desvío estándar de esta distribución de muestreo se llama error estándar y depende del tamaño muestral. En B se observan 3 distribuciones de muestreo que varían entre sí en su tamaño muestral. Este es el fundamento por el cual las estimaciones de muestras más grandes son más precisas.



¿Qué es una distribución normal?

Es una distribución de frecuencias para variables continuas. Se trata de una familia de distribuciones de probabilidades que se diferencian en sus valores de media y desvío estándar. La distribución normal es simétrica y acampanada. Media, mediana y moda coinciden. Existen formas de evaluar si es razonable sostener que la distribución de una variable continua proviene de una población blanco donde la distribución es normal.

Como toda distribución de frecuencias, el área bajo la curva es = 1, es decir el 100% de los valores posibles de la variable están representados en la curva. Si consideramos que la distribución representa todos los valores posibles de una determinada variable, puede ser utilizada para estimar probabilidades calculando las áreas bajo la curva a la derecha o a la izquierda de determinados valores. Entre ± 1 desvío estándar de la media se encuentra aproximadamente un 68,26% del área o de las observaciones. Entre ± 2 desvíos estándar se encuentra 95,44%; y entre ± 3 desvíos estándar 99,74.

$\pm 1,96$ desvíos estándar de la media incluyen el 95% del área. Es decir, dejan 2,5% por fuera en cada extremo de la distribución. Este valor en desvíos estándar va a ser muy importante, ya que aplicado a la distribución de muestreo, va a permitir construir los intervalos de confianza de nivel 95%. Potencialmente podría construir un intervalo que vaya entre $\pm 1,96$ desvíos estándar de la media de una distribución normal, y quedaría comprendido en este intervalo el 95% del área bajo la curva. Esto se aplica también al área bajo la curva de la distribución de muestreo.


Uno de los componentes de esta familia se llama normal estándar o z. Se caracteriza por ser una distribución normal cuya media es 0 y su desvío estándar es 1. Cualquier distribución de variable continua puede transformarse en una distribución normal estándar restando la media a cada valor y dividiéndolo por su desvío estándar. De esta manera se pasa cualquier variable continua a expresarla en unidades de desvío estándar o de z. este procedimiento se llama estandarizar la variable.

Si bien sólo nos focalizamos en describir las más importantes, existen muchas otras propiedades de la distribución normal.^[64] (Ver Figura 12)

¿Cuál es el efecto del azar de muestreo?

El Teorema del Límite Central dice que cualquier estimador muestral estará estimado con mayor precisión si el tamaño muestral es lo suficientemente grande. A mayor tamaño muestral, la distribución de muestreo es más angosta y por ende cualquier medición en la muestra es más precisa. A menor tamaño muestral, la distribución de muestreo es más ancha y menor es la precisión en todos los estimadores muestrales.

Figura 12. En la figura A se muestran algunos ejemplos de distribuciones normales. En la figura B se presentan la diferente distribución porcentual de frecuencias alrededor de la media características de todas las distribuciones muestrales.



¿Cómo minimizo el efecto del azar de muestreo?

La estrategia natural para disminuir el efecto del azar de muestreo es el aumento del tamaño muestral. Por supuesto no siempre es posible, incide directamente sobre los costos y tiempo y recurso humano de los estudios. Por estas razones este aspecto se relaciona directamente con la factibilidad de un estudio. Una serie de estrategias se utilizan para estimar el tamaño muestral necesario para testear una hipótesis o estimar un parámetro con precisión adecuada para un problema específico.

A su vez, una estrategia adicional es disminuir las fuentes de variabilidad. Como por ejemplo, reformular la pregunta de investigación considerando una población donde los individuos son más parecidos entre sí y por ende tienen menor variabilidad entre individuos. Esta estrategia aumentará la validez interna a expensas de disminuir la validez externa y es uno de los problemas principales de los ensayos clínicos tradicionales.

6

TEST DE HIPÓTESIS E INTERVALOS DE CONFIANZA

¿Qué es una hipótesis?

La hipótesis es una afirmación que se desea constatar con la realidad. Representa lo que el investigador piensa y conoce sobre la asociación bajo estudio, y tiene el mismo contenido que la pregunta principal del estudio. Las hipótesis son afirmaciones que pueden ser verdaderas o falsas. Es decir son falsables, ya que es posible contrastarlas con la realidad utilizando algún método específico. En su forma más simple obedecen a la estructura “A se asocia a B en C”. Una hipótesis simple podría ser “el tratamiento crónico con suplemento de vitamina D, se asocia con menor incidencia eventos cardiovasculares”. A es la variable de exposición, B es la variable de respuesta. Ambos corresponden a parámetros poblacionales, es decir los verdaderos valores de A y B en la población blanco. En este ejemplo la exposición es el consumo crónico de vitamina D. Podríamos poner más precisión dando una forma específica de la vitamina D, una posología y dosis y un marco temporal. La variable de respuesta son los eventos cardiovasculares. Al igual que con la exposición, podríamos ser más precisos agregando una definición operativa y un marco temporal. C es la población. Todas las hipótesis son referidas a una población blanco y representa la población a la que se pretende generalizar los resultados del estudio.

La palabra asociación en este caso y definida en sentido amplio y natural, implica que si conozco el valor de la variable de exposición A, conozco algo del comportamiento de B. Es decir que si sabiendo el valor de A, conozco la probabilidad de ocurrencia de B. En este caso adicionalmente la asociación tiene direccionalidad, ya que la hipótesis dice “se asocia con menor incidencia eventos cardiovasculares”. Si hubiera dicho simplemente “se asocia con eventos cardiovasculares” no habría tenido esta direccionalidad. Pero naturalmente los investigadores reflejan en la hipótesis de su estudio lo que ellos piensan que corresponde a la direccionalidad de la asociación en la realidad.

No se debe confundir con el sentido natural del lenguaje de hipótesis como lo que yo creo que pasa. Si bien ambas acepciones suelen compartir sentido y contenido.



¿Cuál es la relación entre pregunta e hipótesis?

Como ya mencionamos anteriormente, es importante destacar que sólo las preguntas analíticas pueden convertirse en hipótesis, no así las preguntas descriptivas. La pregunta principal del estudio, los objetivos principales y la hipótesis deben estar totalmente alineados. Deben contener los mismos componentes y términos.

¿Cómo se clasifican las hipótesis?

Las hipótesis pueden clasificarse en simples o complejas. Las hipótesis simples son las que tienen una única exposición y un único evento. Las hipótesis complejas son las que pueden contener más de uno de alguno de estos elementos y sus combinaciones entre sí a la vez. Es mucho más sencillo intentar reducir las preguntas que nos hacemos a hipótesis simples, ya que son más fácil de planear, testear, entender y comunicar.

¿Cuáles son los componentes de la hipótesis?

Vamos a tomar la sobre simplificación de la estructura de la genérica de la hipótesis siguiendo “A se asocia a B en C” para considerar sus componentes.

A es la variable de exposición, o factor de riesgo/protector o predictor o variable explicativa o variable independiente. B corresponde a la variable de respuesta, o evento de interés o variable dependiente. Si bien se presentan varios sinónimos, el uso de cada sinónimo varía con el contexto y en general conservando el mismo significado. Tanto A como B representan los parámetros de la población. Los verdaderos valores que tomarían A y B si pudiera evaluar la totalidad de la población blanco.

C es la población como comentamos anteriormente y por lo tanto no es una variable. La población blanco para una hipótesis es fija y representa la población sobre la que se pretende generalizar los resultados de un estudio.

Para la hipótesis simple “El índice de masa corporal BMI se asocia con el riesgo de infarto agudo de miocardio en hombres mayores a 80 años”: El BMI es mi variable de exposición. El infarto agudo de miocardio es mi variable de resultado. La población blanco de mi estudio son los varones mayores a 80 años.

¿Qué es la hipótesis nula? ¿Y la hipótesis alterna?

La hipótesis alterna de un estudio es la afirmación que se pretende demostrar. En general cuando alguien enuncia la hipótesis de su estudio sin aclarar, se refiere a la hipótesis alterna. Se la llama habitualmente H1. Por ejemplo “Los polimorfismos del locus x se asocian a diferencias en la supervivencia de pacientes con leucemia mielomonocítica aguda”. Afirma lo que se pretende estudiar.

La hipótesis nula es idéntica en sus componentes a la hipótesis alterna, pero

representa el no efecto. La carencia de asociación: la independencia entre la variable explicativa y la variable de respuesta. La igualdad en la ocurrencia de la variable de respuesta en todos los estratos de la variable explicativa. Se la llama habitualmente H_0 . La hipótesis nula H_0 sería “Los polimorfismos del locus x NO se asocian a diferencias en la sobrevida de pacientes con leucemia mielomonocítica aguda” o “Los pacientes con leucemia mielomonocítica aguda con diferentes polimorfismos del locus x tienen la misma sobrevida”. Son dos formas de expresar la independencia entre la variable explicativa y la variable de respuesta.

Imaginemos que sólo estuviera interesado en un polimorfismo específico del locus x que se llama x_1 . La hipótesis nula H_0 podría ser “La presencia del polimorfismo x_1 es independiente de la sobrevida de los pacientes con leucemia mielomonocítica aguda”. Hay 3 formas de la hipótesis alterna H_1 en este caso:

Hipótesis a dos colas	1. Existen diferencias en la sobrevida de los pacientes con x_1 con respecto a los que no lo tienen.	sobrevida en x_1 es distinta de sobrevida sin x_1
Hipótesis a una cola	2. Los pacientes con x_1 tienen mayor sobrevida.	sobrevida en x_1 es mayor sobrevida sin x_1
	3. Los pacientes con x_1 tienen menor sobrevida.	sobrevida en x_1 es menor de sobrevida sin x_1

¿Qué es una asociación causal?

La causalidad es un subtipo de asociación. Las asociaciones causales son muy importantes en la investigación biomédica. Identificar la causa de una enfermedad es crucial para prevenirla. Identificar la causa de la cura de un paciente con una determinada enfermedad es fundamental para reproducirla en pacientes similares. Identificar un factor de riesgo como causa de una enfermedad es fundamental para realizar recomendaciones.

En las asociaciones causales, los componentes de la hipótesis se pueden llamar causa (independiente) y efecto (dependiente). En una hipótesis de asociación, A y B pueden ir en cualquier orden ya que no hay direccionalidad. En una hipótesis de causalidad no, ya que las asociaciones causales son direccionales.

Previo a la transición epidemiológica, las causas de enfermedades infecciosas predominaban. Por esta razón el paradigma causal produjo los postulados de Koch para identificar las causas de las enfermedades. Estos postulados sólo eran útiles para identificar causas infecciosas de las enfermedades: se puede aislar un organismo en los pacientes con la enfermedad de interés, es posible

cultivar el microorganismo, inocular ese agente reproduce la enfermedad en otros individuos.^[65]

Posteriormente a la transición epidemiológica, comienza el predominio de enfermedades crónicas no contagiosas como el cáncer o la enfermedad cardio-cerebro vascular u otras condiciones no infecciosas como los accidentes. Para identificar dichas causas se pueden utilizar los postulados de Bradford Hill: temporalidad, plausibilidad biológica, relación dosis respuesta, consistencia con el resto del conocimiento y reproducibilidad, especificidad de la asociación, fortaleza de la asociación, evidencia experimental, analogía.^[8,66]

Actualmente la causalidad ocupa un lugar fundamental en la epidemiología moderna. Se han desarrollado métodos específicos para representar y comprender las asociaciones causales y para estimar asociaciones causales desde estudios observacionales.^[27]

¿Qué es el error Alfa y Beta?

Para definir los errores utilizaremos la hipótesis nula. Si fuera posible observar la población blanco y los verdaderos valores de sus parámetros, podríamos conocer la realidad absoluta. En la realidad la hipótesis nula y la alterna no pueden ser las dos verdaderas a la vez. O es verdadera la hipótesis nula, o es verdadera la hipótesis alterna. No es posible que ambas sean verdaderas a la vez. El problema es que no es posible observar ni medir nada en la población blanco, nuestra única forma de conocer la realidad es a través de muestras.

En la muestra a su vez es posible observar y medir las variables de la hipótesis. Por lo tanto en la muestra la hipótesis nula es verdadera o falsa de acuerdo a lo que mido y observo. En mi estudio la hipótesis nula puede ser rechazada o no de acuerdo a lo que mido. En mi estudio estas dos situaciones no se dan a la vez.

Si en mi estudio rechazo la hipótesis nula, y esto es lo que ocurre en la realidad, estoy acertando en rechazarla. Si en mi estudio rechazo la hipótesis nula y en la realidad es verdadera estoy cometiendo un error. Este error se llama error de tipo 1 o error Alfa. Si en mi estudio acepto la hipótesis nula, y en la realidad es verdadera, estoy acertando en aceptarla. Por el contrario si en mi estudio acepto la hipótesis nula y en realidad es falsa estoy cometiendo un error de tipo 2 o error Beta.


Los errores Alfa y Beta pueden ocurrir porque no puedo observar la realidad del comportamiento de la hipótesis nula en la población blanco. Son consecuencia directa del fenómeno de azar de muestreo que describimos anteriormente. Entonces cuando hago un estudio y mido en mi muestra, acepto o rechazo la hipótesis nula. Puedo estimar la probabilidad de estar cometiendo un error de tipo 1, si rechace la hipótesis nula en mi estudio. Puedo estimar la probabilidad de estar cometiendo un error de tipo 2, si acepté la hipótesis nula en un mi estudio.

Si fuera verdadera la hipótesis nula en la realidad para un determinado estudio, la probabilidad de rechazarla falsamente es la probabilidad de error tipo 1 o Alfa. Se trata de una probabilidad condicional: dado que es verdadera la hipótesis nula, es la probabilidad de cometer un error de tipo 1.

Si fuera falsa la hipótesis nula en la realidad para un determinado estudio, la probabilidad de aceptarla falsamente es la probabilidad de error tipo 2 o Beta. Se trata de una probabilidad condicional: dado que es falsa la hipótesis nula, es la probabilidad de cometer un error de tipo 2. Este error es equivalente a no ver una diferencia que verdaderamente existe en la realidad. Se define como poder al complemento del error Beta: Poder = 1 - error Beta. Dado que es falsa la hipótesis nula, el poder es la probabilidad condicional de rechazarla en mi muestra. O lo que es lo mismo, la probabilidad de ver una diferencia que verdaderamente existe.

Figura 13. En la realidad la hipótesis nula es verdadera o es falsa. No puede ser las dos cosas a la vez. A su vez, con los hallazgos de un estudio, se decide aceptar o rechazar la hipótesis nula. De esta manera se pueden describir 4 situaciones donde se evidencian el error alfa y el error beta. En la figura B se presentan la misma información pero con distribuciones de frecuencias: una distribución de frecuencias centrada en la hipótesis nula, y otra distribución de frecuencias centrada en la hipótesis alterna. Esta segunda representación contiene mucha más información que la tabla de doble entrada.

		H ₀ Población Blanco	
		VERDADERA	FALSA
H ₀ Decisión basada en el Estudio	VERDADERA	Acierto	Error Tipo II o Beta
	FALSA	Error Tipo I o Alfa	Acierto Potencia (1-β)



¿Qué es un test de hipótesis?

Los test de hipótesis son un conjunto de métodos estadísticos que nos permiten utilizar la información obtenida en una muestra para hacer inferencia sobre lo que ocurre en la población blanco. Me permiten estimar la probabilidad de haber observado las diferencias que observe en mi estudio, si la muestra proviene de una población blanco donde la hipótesis nula es verdadera.^[67]

Todos los test de hipótesis funcionan de la misma manera. Se posicionan en la hipótesis nula. Si la hipótesis nula fuera cierta. ¿Cuál es la probabilidad de observar diferencias como las que observe en mi muestra? Si esa probabilidad es chica, descarto la posibilidad de que la hipótesis nula sea cierta en la población blanco. Es decir rechazo que la muestra provenga de una población blanco donde la hipótesis nula es verdadera, y por ende acepto la hipótesis alterna.

Si la probabilidad de observar lo que observe si la hipótesis nula es cierta es grande, entonces no puedo rechazar la hipótesis nula. No puedo afirmar que la muestra proviene de una población blanco en la cual la hipótesis nula es falsa. En este caso fallo en rechazar la hipótesis nula. Por ende, acepto que la hipótesis nula es verdadera.

Si bien no es perfecta, es una buena aproximación a resolver el problema de nuestra incapacidad para observar la población blanco y su comportamiento. Por convención se acepta que si la probabilidad estimada por el test de hipótesis es menor a 0,05 es razonable rechazar la hipótesis nula. Cuando la probabilidad estimada por el test de hipótesis es menor a 0,05 se dice que la diferencia es estadísticamente significativa. En general las probabilidades menores a 0,001 se consideran altamente significativas.

¿Cuáles son los componentes de un test de hipótesis?

Existen diferentes formas de clasificar los tests de hipótesis: para una muestra, para dos, para más de dos muestras, para datos independientes y dependiente, para variables continuas, variables categóricas, tiempo al evento, tasas, paramé-

tricos y no paramétricos. Cada uno aplica a un tipo de situación en particular. Los más comunes, se pueden realizar con cualquier software o paquete estadístico. El objetivo de cualquier test de hipótesis es testear si es falsa la hipótesis nula en la población blanco, considerando la información de lo observado en la muestra. Todos los test de hipótesis tienen los mismos componentes que describiremos a continuación: hipótesis nula, supuestos, calculo del estadístico y distribución de probabilidades.

- **H0 Hipótesis nula.** El test va a pararse en la hipótesis nula, por ende es muy importante conocer cuál será la hipótesis nula que testeará el test. Es imposible interpretar el significado de un p valor si no se puede identificar la hipótesis nula evaluada por el test. Algunos ejemplos de hipótesis nula son: “la media de edad en el grupo con cáncer de mama es igual a la media de edad en el grupo sin cáncer de mama” o “el porcentaje de fumadores es igual en los pacientes que sobrevivieron que en los que fallecieron”.

- **Supuestos.** Los test de hipótesis son aproximaciones a la realidad (modelos), que usan elementos matemáticos y la teoría de la probabilidad. Por este motivo, funcionan sólo bajo ciertas circunstancias. Cada test tiene sus circunstancias específicas bajo las cuales es válido y funciona adecuadamente. Estas circunstancias se llaman supuestos y son específicos de cada test. Algunos test necesitan que el tamaño de cada grupo sea lo suficientemente grande. Otros test necesitan que la comparación entre dos grupos se realice con dos grupos que sean independientes entre sí.

Cada test de hipótesis vendrá acompañado con una lista de supuestos que deben comprobarse antes de proceder. No sólo será necesario conocer los supuestos de cada test, sino también cómo evaluarlos.

Algunos sólo dependen de conocer de donde o como fueron obtenidos los datos (como la independencia entre grupos de observaciones), otros deberán evaluarse con algún método específico (como la distribución normal de las variables). Es muy importante saber que si se violan los supuestos puede no ser válido el test para una determinada situación. Cuando esto ocurre, existen alternativas al test que evalúan la misma hipótesis nula y tienen supuestos menos exigentes.

- **Estadístico.** Todos los tests implican una fórmula con la que se obtiene un valor. Esa fórmula utiliza los datos de la muestra para obtener un número que es el estadístico del test. El estadístico variará con la magnitud del efecto y con la variabilidad. Este número es una medida de que tan cerca o qué tan lejos está lo observado en la muestra con lo que se hubiera observado si en la población blanco de origen de la muestra la hipótesis nula fuera cierta.

El test de Chi cuadrado es un test de hipótesis para comparar dos proporciones en dos grupos independientes. El estadístico del test de Chi cuadrado compara lo observado en la muestra con lo que hubiera esperado observar si la hipótesis nula fuera cierta. Mientras más grande es este número, mayor es la posibilidad de rechazar la hipótesis nula (menor es el p valor). Muchos test de hipótesis siguen esa lógica directamente.

- **Distribución de probabilidades.** El valor del estadístico se buscará en una distribución de probabilidades específica. Los diferentes test de hipótesis utilizan diferentes distribuciones de probabilidades: Binomial, Chi cuadrado, Normal estándar, distribución de T, distribución F, Poisson, entre otras.

Las distribuciones de probabilidades teóricas son definidas por números que se llaman parámetros. debido a que el área bajo la curva de una distribución de probabilidades es igual a 1, es posible estimar el área bajo la curva a partir de un determinado valor del estadístico. Esta es la forma en que se obtiene la probabilidad de haber observado una diferencia como la hallada en un estudio comparada con lo que hubiera debido hallar si la hipótesis nula fuera cierta. De la búsqueda del estadístico en esta distribución de probabilidades específica del test, se obtiene el p valor del test de hipótesis. Este p valor representa el área bajo la curva correspondiente a la diferencia observada en la muestra, en una distribución de probabilidades correspondiente a la hipótesis nula.

¿Cuántas colas puede tener un test de hipótesis?

Las colas de un test dependen del tipo de hipótesis alterna planteada, ver anteriormente. Para dicha distribución de probabilidades del estadístico, si busco áreas pequeñas a ambos lados de la distribución se llama a dos colas. Corresponde a las hipótesis alternas a 2 colas. Por ejemplo cuando pienso que dos medias son diferentes pero no se cual es mayor de las dos *a priori*. Es decir, antes de la recolección de la información, no tengo un supuesto fuerte de cual de las dos es mayor.

Si busco sólo un área a uno de los lados de la distribución se llama a una cola. Corresponde a las hipótesis alternas a una cola que presuponen antes de ver los datos una direccionalidad de la asociación. Por ejemplo tengo razones *a priori* para sostener que la mortalidad con el tratamiento A es menor a la mortalidad con el tratamiento B (¡O al revés!).

Para una misma comparación, el test a una cola tiene más poder que a dos colas. Es decir, el p valor del test a una cola será menor para la misma comparación con los mismos tamaños muestrales. La decisión de si la hipótesis que se está testeando es a una cola o a dos se realiza antes de mirar los datos.

¿Qué es el p valor?

El p valor es el resultado del test de hipótesis. El p valor de un test es la probabilidad de haber observado una diferencia como la que observe en mi muestra, si esta proviene de una población blanco donde la hipótesis nula es verdadera. Es solo una herramienta para permitirnos decidir sobre la hipótesis nula en la población blanco, a través de lo observado en la muestra.

Por ejemplo, si hago un estudio para evaluar si existe asociación entre obesidad y diabetes. Mi objetivo implícito es testear la hipótesis nula de que no existe asociación entre obesidad y diabetes en la población blanco de mi estudio. Yo observo en mi estudio una diferencia en la proporción de diabetes entre los obesos y los no obesos. ¿Esta diferencia observada en mi muestra, puede deberse al azar de muestreo?

Un p valor de 0,001 de esta asociación se interpreta como estadísticamente altamente significativo; 0,001 quiere decir que si la hipótesis nula fuera cierta en la población blanco, solo 1 de cada 1.000 veces que repitiera el estudio con una muestra de ese mismo tamaño, observaría una diferencia igual o más grande en la proporción de pacientes diabéticos, entre el grupo de obesos y el grupo de no obesos. Pareciera ser una situación lo suficientemente infrecuente. Puedo asumir que no se trata de una muestra muy improbable de una población blanco donde la hipótesis nula es cierta, sino una muestra que proviene de una población blanco donde la hipótesis nula es falsa. ¿Qué pasaría si mi p valor fuera 0,04? ¿Cómo lo interpreto? ¿Y si fuera 0,4?


¿Qué son los intervalos de confianza?

Si pienso que todo lo que le mida a una muestra, corresponde a estimadores muestrales, puedo imaginarme una distribución de muestreo para cada uno. Tengo entonces la estimación correspondiente a una de las infinitas muestras de igual tamaño que hubiera podido tomar de esa misma población blanco (ver anteriormente ¿Qué es el azar de muestreo?).

Gracias al Teorema del Límite Central (ver anteriormente Teorema del Límite Central), sé mucho de esa distribución de muestreo. Algunas de las propiedades de esta distribución de muestreo teórica son la base del cálculo de los intervalos de confianza. Se que la distribución de muestreo es normal cuando n es lo suficientemente grande. Se que la media de la distribución de muestreo corresponde al parámetro poblacional. Y se que el error estándar es el desvío estándar de esta distribución de muestreo y se calcula como el desvío estándar dividido sobre la raíz del tamaño muestral.

Sé también que si me paro en la media de la distribución y le resto 1,96 errores estándar y le sumo 1,96 errores estándar, puedo construir un intervalo (ver anteriormente ¿Qué es una distribución de normal?). ¡Dentro de este intervalo estarían contenidas el 95% de las muestras posibles del mismo tamaño! Sólo 5% estarían por fuera de este intervalo (2,5% por debajo y 2,5% por arriba).

Figura 14. Para un intervalo de confianza de nivel 95%, de cada 100 muestras aleatorias del mismo tamaño, en 5 el intervalo de confianza no incluirá al parámetro que interesa estimar. Es decir, ¡En 5 de cada 100, el verdadero parámetro que me interesa conocer no estará incluido en el intervalo estimado!



Ahora, nunca sabré si me paré en la media de la distribución de muestreo, porque precisamente ese es el parámetro poblacional desconocido que me interesa estimar. Pero me puedo imaginar que si me muevo hacia la derecha o hacia la izquierda, 95% de las muestras contendrán al parámetro poblacional en este intervalo. Esto implica que el 5% de las muestras aleatorias del mismo tamaño de la misma población blanco, no incluyen el parámetro poblacional en su intervalo de confianza de 95%.

Es posible construir intervalos de confianza de otro nivel diferente a 95% utilizando el mismo procedimiento: 80% (intervalo entre $\pm 1,28$ error estándar), 90% (intervalo entre $\pm 1,64$ error estándar), 99% (intervalo entre $\pm 2,576$ error estándar). En la práctica, estos intervalos se utilizan con mucho menos frecuencia.

¿Cómo se interpretan los intervalos de confianza?

Es posible estimar un intervalo de confianza para cualquier tipo de estimador muestral: medias, medianas, proporciones, medidas de asociación, etc. Las preguntas descriptivas debieran contestarse con estimadores muestrales y sus intervalos de confianza. A su vez las preguntas analíticas pueden contestarse con una medida de asociación y su intervalo de confianza, además del test de hipótesis correspondiente.

El intervalo de confianza se utiliza como medida de precisión de una estimación. Mientras más amplio es el intervalo de confianza, más imprecisa es la medición. Si el intervalo de confianza es muy angosto, mayor es la precisión de la medición. La amplitud del intervalo de confianza está en relación directa con la forma de la distribución de muestreo, y depende directamente del error estándar.

Los intervalos de confianza pueden ser de diferente nivel. Los más usuales son el 90%, 95% y 99%, lejos 95% es el más utilizado y generalizado. Pero todos tienen la misma interpretación. Es decir, si me interesaba conocer una prevalencia de hipertensión arterial en adultos de una determinada ciudad: obtengo 15% con un intervalo de confianza de 95% entre 9% y 17%. Quiere decir que en 95% de las muestras tomadas de la misma población el parámetro poblacional prevalencia de hipertensión estaría incluido en sus intervalos de confianza. Sólo el 5% de las muestras no contendrán al parámetro en sus intervalos de confianza. Tengo un 95% de confianza que el verdadero parámetro poblacional se encuentra contenido en nuestro intervalo de confianza.

Si bien tengo una determinada confianza que el verdadero parámetro poblacional se encuentra dentro del intervalo, no puedo decir donde. No hay forma de saber exactamente qué valor tiene. Como tampoco hay forma de saber si estoy en una de esas 5 de cada 100 muestras aleatorias de la misma población blanco y del mismo tamaño, cuyo intervalo de confianza no contiene el parámetro poblacional.

Los intervalos de confianza me dan una idea de precisión de la estimación. Es decir, me dan una idea de que tan cerca del parámetro puede estar mi estimador muestral. Por ejemplo, si me interesara comparar la proporción de muertes entre dos hospitales: en hospital A 3% (IC95% 1% - 4%) y en hospital B 15% (IC95% 12% - 18%), puedo decir que son diferentes ya que los intervalos de confianza no se superponen. Un tercer hospital C tiene una mortalidad de 10% (IC95% 7% - 13%). Si quisiera comparar la mortalidad de B con el hospital C, no puedo decir que sean diferentes ya que se superponen los intervalos de confianza.

¿Cuál es el objetivo de la planificación del análisis estadístico?

La planificación del análisis estadístico consiste en una secuencia ordenada y explícita de los pasos a seguir durante el análisis estadístico de un proyecto de investigación. Es una parte fundamental del protocolo donde se explicitan las decisiones que se tomaron para analizar y presentar los resultados del estudio. Todo análisis estadístico debe ser planificado con anterioridad. Mientras más detalle tenga, más claro y más transparente será el análisis. Un buen plan de análisis estadístico debe cumplir con los objetivos de especificar los pasos para la conducción del análisis, alinear el análisis con los objetivos del estudio, permitir seleccionar, comunicar y discutir con los colegas los métodos apropiados a los objetivos.

La falta de planificación del análisis puede llevar a un análisis desorganizado, sin alineación con el propósito específico del estudio. Puede inducir a la pesca de asociaciones espurias o la tortura de datos. Estas dos últimas situaciones inflan las probabilidades de errores y potencialmente introducen sesgos a partir del análisis estadístico. Asimismo puede provocar la deriva hasta encontrar asociaciones positivas no relacionadas con el objetivo del estudio. Se recomienda fuertemente no abordar el análisis de los datos sin un plan apropiado.

Antes de analizar...

Es fundamental definir e incorporar en el equipo de análisis a las personas más apropiadas. Con cierta frecuencia el investigador está solo en esta etapa. El equipo que realizará el análisis estadístico idealmente debe incluir quienes conozcan del problema, idealmente el investigador principal, y conocimiento y experiencia en análisis estadístico y comunicación de resultados.

La base de datos debe estar en las mejores condiciones posibles antes de iniciar el análisis. El proceso de dejar la mejor base de datos posible antes de empezar se suele llamar validar la base de datos. La validación implica el tratamiento de los datos perdidos y los errores para mejorar la calidad de la base. Lo ideal es haber desarrollado la base con un diseño tal que prevenga la ocurrencia de errores y datos faltantes. Las técnicas de diseño para prevención de errores



durante la recolección e implementación de un estudio exceden nuestro objetivo, pero se recomienda asesorarse con alguien con experiencia y permitirse desarrollar experiencia propia.

Con respecto a los nombres de las variables, tenga en cuenta que es de buena práctica que empiecen con un código que las identifique de forma inequívoca en la base de datos, que las ordene. Seguido de un nombre descriptivo. Idealmente este código identifica los campos desde la operacionalización de las variables, los formularios de recolección de datos y las bases de datos y salidas de los paquetes estadísticos. Se debe evitar los espacios y los caracteres especiales (, . - + / * # ? ! (; : > < = entre otros) en los nombres ya que tanto los paquetes de manejo de bases de datos como los estadísticos no permiten su uso. Es ideal conocer los paquetes de software que se utilizarán y cuales son sus restricciones con respecto a nombres y variables.

La validación de la base de datos implica el proceso completo que se realiza para dejar la base en las mejores condiciones antes de iniciar el análisis. No necesariamente debe ser al final, es ideal realizarla durante el estudio con estrategias principalmente dirigidas a prevenir errores, detectar y corregir de la mejor forma posible. Detectar y corregir errores, datos vacíos. Es más difícil detectar los errores menos evidentes. Es más difícil corregir si detecto el error alejado en el tiempo de la recolección en lugar de hacerlo en tiempo real. Siempre que sea posible, los datos deberán completarse o corregirse con el dato fuente original. La base validada es la mejor versión de la base posible en el contexto para responder la pregunta del estudio. Es una buena idea documentar todo el proceso de validación de manera corta y concisa para asegurar que sea transparente y reproducible.

Casi todos los paquetes estadísticos permiten guardar archivos específicos que guarden los pasos del análisis. Es muy importante guardar las versiones y elegir una manera ordenada y fácil de identificar cada versión. Es fundamental tener la costumbre de documentar los pasos del análisis y elegir un sistema para nombrar y ordenar los documentos.

¿Qué partes tiene el plan de análisis estadístico?

El plan de análisis estadístico debe contener el detalle del análisis descriptivo, testeo de la hipótesis principal, ajuste por potenciales confundidores, situaciones especiales (como evaluación de modificación de efecto, análisis de subgrupos, análisis de sensibilidad), que se va a utilizar como estadísticamente significativo y el paquete estadístico y versión que se va a utilizar en el análisis.

Análisis descriptivo. Declarar qué medidas de resumen se van a utilizar en cada caso. Aclarar qué se va a hacer para decidir qué medida en cada caso. Análisis bivariado.

Testeo de la hipótesis principal y secundarios. Describir con detalle cuál va a ser el método que se va a utilizar para testear la hipótesis principal y secundarias del estudio.

Confundidores. Declarar en detalle los métodos que se va a utilizar para detectar y ajustar por el efecto de los potenciales confundidores.

Análisis de subgrupo. Los análisis de subgrupos deben ser siempre planificados, declarados y pensados de antemano. ¿Se planea hacer algún análisis de subgrupos?

Análisis de sensibilidad. Si está planificado hacer un análisis de sensibilidad y declarar los escenarios o modificaciones correspondientes. ¿Se va a testear sólo la hipótesis principal?

Límite de significancia estadística. Declarar cual va a ser el límite de significancia estadística que se va a considerar. ¿Se va a hacer algún ajuste por comparaciones múltiples?

Paquete estadístico y versión. Declare que paquete estadístico se va a utilizar y la versión.

¿Qué es el análisis descriptivo?

El análisis descriptivo tiene el objetivo de describir las variables más importantes de los individuos incluidos en el estudio. Tiene el objetivo de conocer la distribución y comportamiento de las variables medidas durante el estudio, y hacer una descripción suficiente para darle al lector la posibilidad de entender de qué tipo de población se trata. ¿Son pacientes jóvenes? ¿Son pacientes muy enfermos? ¿Son pacientes que toman mucha medicación? ¿Son pacientes muy vulnerables desde el punto de vista psicológico, físico y social? ¿Son pacientes sin comorbilidades?

Si bien los criterios de selección definen la población blanco y accesible del estudio, la descripción de las características de la población da una idea más precisa de qué características tenían los que finalmente terminaron siendo parte de la muestra del estudio. Puede ser que la descripción de las características de la muestra defina una población blanco del estudio diferente de la declarada en la hipótesis y los criterios de selección ¿Qué pasaría si un estudio que evalúa el efecto de una medicación sobre los infartos de miocardio sólo incluye pacientes menores a 65? ¿Y si en ese mismo estudio ningún paciente tiene comorbilidades? ¿Y si son todos de alto nivel socioeconómico? ¿Y si son todos japoneses? muchas de estas preguntas definen que probablemente la población blanco a la que se puede extrapolar los resultados de un estudio puede variar.

El análisis descriptivo implica seleccionar las variables relevantes y describirlas de manera detallada y sistemática. Para esto se utilizan las medidas de resumen de acuerdo al tipo de variable y a la distribución observada. Es de buena práctica mantener ordenado el análisis y seguir un orden sistemático para evitar cometer errores.

Para el análisis descriptivo es común describir la totalidad de las variables más importantes relevantes. En muchos casos es necesario separar en grupos por exposición o por evento o por subgrupos de relevancia en el contexto de la pregunta y el diseño del estudio.

Es común presentar el análisis descriptivo acompañado de una tabla. Habitualmente la división en las columnas de la tabla depende del diseño. En los ensayos clínicos, las columnas representan habitualmente las ramas del estudio. En las cohortes, las columnas suelen representar los grupos de exposición. En los estudios de casos y controles, las columnas suelen representar los casos y los controles.

¿Qué es el análisis bivariado?

Se llama análisis bivariado al testeo de hipótesis que involucra sólo dos variables. Hay dos situaciones claras que involucran análisis bivariado: la comparación de las características entre 2 o más grupos que se realiza durante el análisis descriptivo y el testeo de asociaciones en las distintas variables del estudio de manera cruda: es decir, sólo considerando la variable de exposición y la variable de resultado.

Por ejemplo si en mi estudio pretendo contestar la pregunta ¿La obesidad se asocia con la hipertensión arterial? Imaginemos que decidimos realizar un estudio de corte transversal y los participantes se clasificaron en pacientes con obesidad y pacientes con hipertensión. La hipótesis nula principal del estudio podría enunciarse como que la proporción de hipertensos en los pacientes obesos es igual a la proporción de hipertensos en los pacientes no obesos.

Pero ¿Cuántas diferencias hay entre los pacientes obesos y los pacientes no obesos? Potencialmente podría haber muchísimas. Por ejemplo ¿Será diferente la edad entre ambos grupos? ¿Será diferente la proporción de dislipemia? y ¿Será que fuman diferentes proporciones de pacientes en ambos grupos? y ¿Habrá diferencias en las proporciones de nivel socioeconómico entre ambos grupos?

Sólo tiene sentido hacerse las preguntas pertinentes con respecto al problema específico. Cada una de esas preguntas corresponde a una hipótesis nula diferente. En realidad lo que estamos pensando es ¿Qué diferencias hay entre ambos grupos? En parte esto permite conocer los grupos. Por otro lado permite identificar potenciales confundidores. Los confundidores deben estar asociados con exposición y evento, y no encontrarse en el camino causal. Las variables que se distribuyan diferente entre ambos grupos son potenciales confundidores.

Cada una de esas hipótesis puede testearse con un test de hipótesis específico. En este caso se puede considerarlas como hipótesis independientes. Tendrá sentido presentar los p valores de todas estas comparaciones.

¿Qué test uso para variables continuas?

Uno de los casos más comunes es preguntarse si dos grupos de individuos tienen diferencias entre sí con respecto a una variable de resultado específica. Por ejemplo ¿Es diferente la glucemia plasmática de los pacientes diabéticos tipo 2 en tratamiento con metformina que los pacientes sin tratamiento? ¿Es diferente la disminución de peso en los pacientes que recibieron cirugía bariátrica con respecto a los que hicieron un plan intensivo de dieta y ejercicio?

En cualquiera de los dos casos, se intenta evaluar la asociación entre dos variables: una es categórica nominal dicotómica y la otra es continua. Tomando la primer pregunta, es equivalente a plantear la hipótesis nula de la siguiente manera: La media de la glucemia plasmática en los pacientes con metformina, es igual a la media de la glucemia plasmática en los pacientes sin metformina. Se trata de un problema de comparación de dos medias ¿Es igual la media de glucemia plasmática entre ambos grupos?

El t test es un test de hipótesis paramétrico que compara medias entre dos grupos. Ya enunciamos su hipótesis nula. Los supuestos del t test son que las mediciones son independientes, ambos grupos son lo suficientemente grandes y de distribución normal. Para testear el supuesto de normalidad, es necesario ver la distribución de ambas poblaciones a través de un histograma, evaluar la normalidad utilizando alguno de los test de hipótesis para distribuciones normales (Kolmogorov Smirnov o Shapiro Wilk), y observar la media, mediana y el modo. A su vez existen dos versiones del t test de acuerdo a si la varianza en ambos grupos es igual o diferente. Para esto, sólo es necesario saber si ambos grupos tienen la misma varianza (o el mismo desvío estándar) o no.

Si los supuestos del t test no se cumplen, se puede usar test no paramétricos diferentes como el test de Mann Whitney. Este test de hipótesis compara las medianas de ambos grupos. Es decir que su hipótesis nula es que la mediana de los pacientes que toman metformina es igual a la mediana de los pacientes que no toman metformina. Tiene el mismo supuesto de independencia que el t test. (Ver Figura 15).

Figura 15. Las tablas de contingencia o tablas de doble entrada (o tablas 2 por 2 cuando ambas variables son dicotómicas) se utilizan para presentar la frecuencia observada de 2 variables categóricas. Permiten estimar las medidas de resumen y de asociación de manera simple. En general las filas representan la exposición y las columnas los eventos o variable de respuesta.

		Variable Resultado		
		SI	NO	Totales
Variable Explicativa	SI	a	b	a+b
	NO	c	d	c+d
	Totales	a+c	b+d	n

Este tipo de hipótesis se representan habitualmente con tablas. En su ejemplo más simple son tablas de 2 por 2. Si bien son simétricas, se suele colocar por convención en las filas las exposiciones y en las columnas las variables de respuesta. Debido a que ambas son variables categóricas dicotómicas, las 4 celdas representan las 4 combinaciones posibles de exposición y eventos de interés: expuestos con evento de interés, expuestos sin evento de interés, no expuestos con evento de interés y no expuestos sin evento de interés. La cantidad en cada celda representa la frecuencia observada. Los totales de filas y columnas se llaman marginales. Con esta tabla es posible calcular las medidas de frecuencias por grupos y las medidas de asociación.

Para testear la hipótesis nula de igualdad de proporciones entre dos grupos, se puede utilizar el test de Chi cuadrado. Este test testea la hipótesis nula de que ambos grupos tienen la misma proporción, ambas proporciones son iguales, o la medida de asociación multiplicativa es igual a 1, o la medida de asociación aditiva es igual a 0.

Los supuestos del test de Chi cuadrado son que las observaciones son independientes, y que el tamaño muestral sea lo suficientemente grande. Para detectar si el tamaño muestral es lo suficientemente grande, se utilizan las frecuencias esperadas en cada celda y no las frecuencias observadas. Todas las frecuencias esperadas bajo la hipótesis nula deben ser mayores a 5.

El estadístico del test de Chi cuadrado se construye sumando las diferencias entre la frecuencia observada en cada celda menos la frecuencia esperada bajo la hipótesis nula. La distribución de probabilidades es Chi cuadrado con un único

parámetro que son los grados de libertad. Los grados de libertad dependen de la cantidad de celdas de la tabla y se calculan como $gl = (\text{cantidad de columnas} - 1) * (\text{cantidad de filas} - 1)$.

Cuando no se cumple el supuesto de tamaño muestral lo suficientemente grande se puede usar el Test Exacto de Fisher. El test exacto de Fisher utiliza una lógica diferente. Calcula todas las tablas posibles manteniendo los marginales. Calcula la probabilidad exacta de haber observado una tabla como la nuestra en una distribución de probabilidades de tablas donde la hipótesis nula es cierta.

¿Qué hago si las muestras no son independientes?

Cuando ambas muestras se encuentran apareadas, no es posible utilizar test para muestras independientes. Un ejemplo podría ser la pregunta ¿Es igual la concentración plasmática de hemoglobina glicosilada antes y después de iniciado el tratamiento con insulina? En este caso, puedo contar con 2 mediciones de hemoglobina glicosilada para cada paciente. En este caso, el conjunto de mediciones antes de iniciar el tratamiento es dependiente del conjunto de mediciones después de haberlo iniciado. En este caso, cada par de mediciones correspondientes al mismo individuo serán más parecidas entre sí que con las hemoglobinas glicosiladas de otros individuos.

En este caso la hipótesis nula puede ser formulada como que la media la diferencia entre hemoglobina glicosilada antes y después del tratamiento es igual a cero. Este test de hipótesis se llama t test para muestras apareadas. Los supuestos son que la muestra es lo suficientemente grande y que la distribución de las diferencias es razonablemente normal.

Imaginemos que mi pregunta fuera si ¿Se logra el control de la presión arterial antes y después de la cirugía bariátrica? En este caso, vamos a tener mediciones de control de presión arterial antes y después de una exposición. El control de la presión arterial de un mismo individuo se parecerá más entre sí que con el control de la presión arterial de otros individuos. En este caso particular, se trata de dos variables categóricas: la primera es cirugía bariátrica No - Sí; y la segunda es control de la presión arterial No - Sí. Algunos individuos tendrán controlada la presión antes y después. Otros individuos no tendrán controlada la presión antes ni tampoco después. Pero más nos interesan los que cambian de estado: controlado antes y no controlado después o no controlado antes y controlado después. Una variación del test de Chi cuadrado utiliza las cantidades de pares discordantes antes después y se llama test de McNemar.

¿Cómo seleccionar las medidas de asociación?

Todos los estudios que tienen preguntas analíticas deben presentar una medida de asociación. Las medidas de asociación específicas dependen del problema y del diseño. Siempre deben presentarse con un intervalo de confianza de 95% para poder interpretar su precisión y significado.



Los odds ratio pueden ser utilizados en cualquier situación y con cualquier diseño. Por ejemplo, son las únicas medidas de asociación que pueden utilizarse en los estudios de casos y control. Esta restricción se debe a que si por ejemplo cambiáramos la cantidad de controles por caso en un estudio de casos y controles, el riesgo relativo va a cambiar, mientras que el odds ratio se va a mantener constante. Por ejemplo si realizamos un estudio de casos y controles con 30 casos y 30 controles (relación 1:1); y la frecuencia de la exposición en los casos es 27/30 y la frecuencia en los controles es de 10/20, el riesgo relativo será de 3,2 y el odds ratio 18. Si en cambio hubiera elegido una relación 1:2 (30 casos y 60 controles), el riesgo relativo será de 4,9 y el odds ratio de 18. Si hubiera considerado una relación 1:3 (30 casos y 90 controles) el riesgo relativo sería de 6,3 y el odds ratio de 18. ¿Cuál sería el riesgo relativo y el odds ratio si la relación fuera de 1:5? Es decir el riesgo relativo no es robusto a esta decisión de relación entre casos y controles, por lo tanto no puede utilizarse en este diseño. Los odds ratio son más difíciles de interpretar y comprender, pero no tienen restricciones por diseño. Los riesgos siempre son preferibles a los odds y todas las medidas de asociación que dependen de los riesgos son más fáciles de comprender. El riesgo puede ser interpretado como una probabilidad, en cambio los odds se parecen a los riesgos cuando las frecuencias son bajas y se parecen muy poco cuando las proporciones se acercan a 0,5.

Las medidas relativas representan la magnitud del efecto multiplicativo y son más eficaces para comunicar factores de riesgo o factores protectores. En las medidas aditivas, se extrapola directamente la proporción de la población general que puede beneficiarse o perjudicarse con una determinada exposición por lo cual pueden tener una utilidad directa en las decisiones de salud pública.

¿Cómo calcular las medidas de asociación?

Es interesante destacar que en cada situación se debe decidir cuál dividido por cuál, o a cuál le resto cuál. ¿Es mejor presentar una medida de asociación multiplicativa (como riesgo relativo, odds ratio) o aditiva (diferencia de riesgos)? Estas decisiones dependen del problema, de la concepción de la normalidad y de la facilidad de interpretación.

Para estimar el riesgo relativo se divide el riesgo en un grupo por el riesgo en el otro grupo. Es habitual dividir el riesgo en expuestos por el riesgo en no expuestos. Para estimar el odds ratio se divide el odds de un grupo por el odds en el otro grupo. Es habitual dividir el odds de un evento en los expuestos por el odds del mismo evento en los no expuestos. Expuestos sobre no expuestos es más útil cuando se trata de exposiciones que aumentan el riesgo o factores de riesgo. Cuando se trata de exposiciones que disminuyen el riesgo de un evento o factores protectores, se puede presentar no expuestos sobre expuestos. Esto se debe a que son más fáciles de entender y expresar sin ambigüedades las medidas de asociación multiplicativas mayores a 1 que las que van entre 0 y 1.

Si el riesgo de cáncer en los fumadores es 0,5 y en los no fumadores es 0,05, ¿Cómo es más apropiado presentar la medida de asociación? ¿Cuánto daña fumar o cuánto protege no fumar? ¿Cuál de las dos medidas de asociación es la más apropiada? El riesgo de cáncer en fumadores/riesgo de cáncer en no fumadores es equivalente y representa la misma magnitud que riesgo de cáncer en no fumadores/riesgo de cáncer en fumadores: es decir $0,5/0,05 = 10$ es equivalente como medida de asociación 0,1. Ambos números representan la misma magnitud exactamente. En escala logarítmica, la distancia del 1 es una medida de magnitud del efecto independiente de esta decisión; 10 y 0,1 en escala logarítmica están equidistantes del 1.

Es habitual presentar el riesgo relativo como cuanto riesgo tiene un grupo con respecto al otro. En este caso se usa el riesgo relativo como el calculado y responde a la pregunta ¿Cuántas veces el riesgo del otro grupo de exposición? El riesgo de cáncer en los pacientes fumadores es 10 veces el riesgo de cáncer de los pacientes no fumadores. El riesgo de cáncer de los pacientes no fumadores es 0,1 el riesgo de cáncer en los pacientes fumadores o el 10% del riesgo de los pacientes fumadores.

Si es más claro expresar cuanto más o cuanto menos riesgo tiene un grupo con respecto al otro, se debe restar 1 al riesgo relativo. responde a la pregunta ¿Cuánto más riesgo tiene que el otro grupo de exposición? En este caso se puede interpretar como que los pacientes fumadores tienen 9 veces más riesgo que no los que no fuman ($10 - 1$). O concordantemente los no fumadores tienen 0,9 veces menos riesgo de cáncer que los fumadores ($0,1 - 1$).

Para los odds ratios la interpretación es similar, pero no tienen una traducción homogénea al castellano: ¿Razón de momios? ¿Chance? ¿Oportunidad? Se usan diferentes traducciones en diferentes países de habla hispana.

Las medidas de asociación aditivas son más simples ya que el módulo de la magnitud es igual, sólo cambia el signo. Por ejemplo, una diferencia de riesgo de +0,45 o -0,45 es idéntica en magnitud y es fácil de identificarlo, comprenderlo y comunicarlo.

¿Cómo detectar los potenciales confundidores?

Como vimos anteriormente los confundidores son variables relacionadas con las variables de nuestra pregunta que se comportan como la verdadera causa de la asociación bajo estudio. Algunas variables sé por la literatura o por experiencia que van a comportarse como confundidores. Es fundamental el conocimiento disciplinar al respecto y de la plausibilidad biológica. La mejor aproximación probablemente sea la construcción de DAGs. Es fundamental no tratar como confundidores a variables mediadoras o modificadores de efecto.

Durante el análisis descriptivo y basal se detectan variables que pudieran comportarse como potenciales confundidores. Por ejemplo, si me interesa responder la pregunta de si ¿El consumo de enalapril se asocia con mayor desarrollo



de insuficiencia renal en pacientes mayores a 70 años? Puedo tener una cohorte retrospectiva de pacientes mayores a 70 años, que consumieron enalapril y otra de pacientes que no consumieron enalapril. Podría ser que los que toman enalapril tuvieran más enfermedad vascular... mayor edad... mayor proporción de hipertensión, entre otros. En este caso, todas las variables asociadas a la exposición podrían ser potenciales confundidores. Toda variable con diferente distribución, frecuencia o comportamiento en las características basales entre grupos potencialmente podrían comportarse como confundidores, como cualquier diferencia en un análisis descriptivo basal.

Como describimos anteriormente, existen diferentes estrategias para el tratamiento de los confundidores. Lo más importante es que quisiera eliminar su efecto. El objetivo del tratamiento de los confundidores es eliminar su efecto. Uno de los métodos para eliminar el efecto de los confundidores y ver el efecto puro del enalapril sobre el desarrollo de insuficiencia renal es el ajuste multivariado que se realiza con modelos de regresión (ver más adelante Modelos de regresión).

¿Qué es la modificación de efecto?

La modificación de efecto o interacción es un fenómeno diferente de la confusión. Existe modificación de efecto cuando el efecto de una exposición sobre un evento es diferente en los diferentes estratos de una tercera variable.

Por ejemplo, imaginemos que me interesa estudiar el efecto del consumo de un determinado biológico sobre un tipo de tumor de páncreas específico ¿Qué pasaría si no todos los pacientes tuvieran el blanco molecular para nuestro biológico? Si estratifico los pacientes en dos grupos: con el blanco biológico y sin el blanco biológico, podré observar que el fármaco sólo funciona en un grupo y no en el otro.

La modificación de efecto puede representar al menos 3 situaciones diferentes. El efecto de A sobre B es de diferente magnitud en 2 subgrupos. El efecto de A sobre B tiene una direccionalidad en un grupo y otra direccionalidad en otro: una determinada exposición es un factor de riesgo en un grupo y un factor protector en el otro grupo. El efecto de A sobre B existe en un subgrupo pero no en el otro: por ejemplo la hormonoterapia funciona en las mujeres con cáncer de mama que expresa receptores para estrógenos y no en el subgrupo que no los expresa.

Si una variable es un confundidor, quiero ajustar o eliminar su efecto. A diferencia de la confusión, la modificación de efecto debe exponerse, nunca se oculta o se elimina. Si el efecto de una exposición sobre un evento es diferente en un determinado subgrupo que en otro, quiero saberlo, exponerlo y declararlo. Es común para esto, presentar el efecto de A sobre B separado en los estratos del modificador de efecto. Muchas veces recibe el nombre de análisis de subgrupos, sobre todo en los ensayos clínicos.

¿Qué es el análisis de regresión?

El análisis de regresión utiliza un conjunto de métodos estadísticos que se utilizan para explicar el comportamiento de una variable de respuesta condicional a una o más variables explicativas. Incluimos a continuación una breve descripción de algunas de las preguntas fundamentales a modo de introducción al uso e interpretación de modelos de regresión.

Un modelo de regresión es una ecuación matemática que intenta explicar una variable de respuesta en base a una o más variables explicativas. Existen diferentes familias de modelos de regresión que se seleccionan por la naturaleza de la variable de respuesta. Los modelos de regresión derivan de la ecuación simple de la recta (ver más adelante ¿Cuáles son los componentes del análisis de regresión?).

Como en todos los métodos estadísticos, es importante conocer las hipótesis nulas que testean cada test del modelo, los supuestos del modelo y cómo se evalúan, así como también cómo se interpretan sus resultados.

¿Cuál es el uso de un modelo de regresión?

Los modelos de regresión tienen dos funciones o usos principales: predicción y ajuste por potenciales confundidores. Siempre que se decide usar un modelo de regresión, es fundamental tener en claro en cual de estas situaciones se encuentra para definir los métodos apropiados y la interpretación adecuada.

en este estudio se utilizaron los modelos de regresión para predecir mortalidad: *A new method of classifying prognostic comorbidity in longitudinal studies: development and validation.*^[68] Desarrollaron un método predictivo que utilizaron como variables explicativas las comorbilidades del paciente y como variables de respuesta la mortalidad al año. En este estudio, utilizamos diferentes variables explicativas para predecir quien faltará a un turno programado para atención médica ambulatoria de clínica médica *Factors associated with nonattendance at clinical medicine scheduled outpatient appointments in a university general hospital.*^[69]

En este estudio, los autores estudiaron la pregunta ¿El uso de estatinas se asocia a mortalidad en pacientes con cáncer de ovario? *Statin use is associated with*



improved survival in ovarian cancer: A retrospective population-based study.^[70]

Por su naturaleza retrospectiva, es necesario ajustar el efecto de las estatinas sobre la mortalidad por los potenciales confundidores.

Existen algunas diferencias importantes con respecto a las decisiones que se toman en la construcción, generación e interpretación del modelo que es importante considerar. Un error muy común es tomar decisiones no alineadas con el objetivo del estudio que podrían ser inapropiadas.

¿Cómo uso los modelos de regresión para predecir?

Los modelos de regresión son herramientas increíbles cuando mi interés es predecir la ocurrencia de una variable de respuesta. En el caso de que el objetivo del estudio sea predecir, mi pregunta podría ser: ¿Cuál es el mejor conjunto de variables explicativas para predecir la ocurrencia de un determinado evento? ¿Cuáles son las variables que en conjunto identifican los pacientes con peor pronóstico luego de un infarto agudo de miocardio? ¿Qué comorbilidades predicen mortalidad al año luego de una internación en adultos? Son preguntas que tienen que ver con el pronóstico o diagnóstico.

En el caso de los modelos de regresión predictivos, es importante que el modelo sea el mejor modelo posible para predecir la variable de respuesta. En este sentido serán muy importantes los métodos para seleccionar el mejor modelo para predecir la variable de respuesta. Esto se logra comparando los diferentes modelos entre sí.

En un modelo de regresión predictivo, va a ser muy importante presentar el modelo completo. Todas las variables incluidas en el modelo son importantes y tienen interpretación. Esto es muy importante ya que no hay una única variable que me interese más que el resto, como sería el caso de los modelos de regresión utilizados para ajustar por potenciales confundidores.

Muchos de estos modelos predictivos pueden ser simplificados en la construcción de un score predictivo. Muchas veces la construcción del score implica perder algo de la fidelidad del modelo y ganar algo de aplicación clínica directa simplificando algunos de sus componentes. En este estudio, *A new method of classifying prognostic comorbidity in longitudinal studies: development and validation*, se generó y validó un índice de comorbilidades para pronosticar muerte al año luego de una internación, el score de comorbilidades de Charlson.^[68] Se explican de qué manera simplificaron el modelo para permitir que pudiera calcularse en la cama del paciente sin necesidad de métodos sofisticados.

¿Cómo valido los modelos de regresión predictivos?

En estos casos, el diseño más apropiado incluirá la generación del modelo y la posterior validación del modelo usando muestras diferentes o diferentes individuos de una misma muestra para cada uno de estos objetivos. Es decir, puede

ser un problema utilizar los mismos casos para generar y validar un modelo. El modelo siempre va a funcionar mejor si lo valido en la misma muestra donde lo cree.

Adicionalmente, la máxima utilidad del modelo será para predecir en nuevos individuos, por lo tanto será muy importante la validez externa. La validación interna puede realizarse dividiendo la muestra de manera aleatoria en una parte de generación y una parte de validación o utilizando métodos más sofisticados como Bootstrapping.

Bootstrapping es una técnica de simulación que utiliza la misma muestra de generación. Es una técnica de validación que muestrea con reposición de la misma muestra que utilice para generar el modelo.^[71] Toma muestras del mismo tamaño, pero al ser con reposición, permite que los individuos estén más de una vez en cada muestra o directamente no estén. Debido a que el procedimiento se realiza automáticamente, es posible tomar muchas muestras con reposición y utilizar la información de estas submuestras para validar el modelo. Es una técnica válida, aunque no suficiente, cuando el tamaño muestral es pequeño. La principal dificultad es que sigo utilizando la misma muestra con la que se generó el modelo y puede tener el mismo problema de sobreajuste o sobreestimación de la performance del modelo al utilizar la información de los mismos individuos. En este estudio *Derivation and Internal Validation of the Ebola Prediction Score for Risk Stratification of Patients With Suspected Ebola Virus Disease*, se generó un modelo para identificar casos de Ébola y se validó internamente utilizando Bootstrapping.^[72]

A su vez, es fundamental realizar una validación externa con otra muestra para demostrar la validez externa del modelo. La validación externa asegura la validez externa del modelo para identificar correctamente la condición de interés.^[72] Este estudio puede ser considerado como una validación externa de varios índices de comorbilidad, incluyendo el score de comorbilidades de *Charlson: The performance of three mortality risk-adjustment comorbidity indices in a community epilepsy cohort*.^[73]

¿Cómo uso los modelos de regresión para ajustar por potenciales confundidores?

El ajuste por potenciales confundidores del efecto de una exposición sobre un evento es el uso más frecuente y difundido de los modelos de regresión. En ocasiones mi pregunta corresponde a una pregunta simple. Por ejemplo ¿Los sartanes disminuyen la mortalidad de los pacientes con EPOC? En este caso tengo una exposición que es el uso de sartanes. Y un evento que es la mortalidad. Si me propusiera contestar esta pregunta de manera retrospectiva con un estudio observacional, una de las principales dificultades sería la confusión por indicación. Si el estudio no es aleatorizado, existirán muchas diferencias entre los pacientes que tomaron estatinas y los que no. Por ejemplo, los pacientes que consumen es-

tatinas podrían ser más viejos, con mayor sobrepeso y obesidad, más hipertensos, más dislipémicos, mayor porcentaje de diabéticos, entre muchas otras diferencias. Todas estas variables adicionales son potenciales confundidores.

Cuando me interesa estudiar el efecto de una exposición sobre un determinado evento, es fundamental identificar los potenciales confundidores. Una de las estrategias para tratar confundidores es el ajuste a través de un modelo de regresión multivariado (ver anteriormente ¿Qué hago con los confundidores?). Será muy importante estimar el efecto crudo de mi exposición sobre mi evento de interés usando un modelo de regresión bivariado que considere sólo la variable de respuesta y la variable explicativa. A su vez será importante presentar una medida de asociación ajustada del efecto de la exposición sobre el evento ajustado por todos los potenciales confundidores. Esto se logra con un modelo de regresión multivariado que contenga además de las variables mencionadas en el modelo bivariado, todos los potenciales confundidores.

En la pregunta que presentamos, será fundamental presentar el efecto crudo de los sartanes sobre la mortalidad. Pero a su vez será fundamental controlar por los potenciales confundidores presentando una medida de asociación ajustada de sartanes sobre mortalidad. La medida ajustada representa el efecto independiente de la variable de exposición de interés sobre el evento independiente de los demás confundidores en el modelo. En este artículo se presentan las medidas de asociación crudas y ajustadas para mortalidad *Effect of angiotensin 2 receptor blockers on chronic obstructive lung disease mortality: A retrospective cohort study*.^[36]

¿Cuáles son los componentes del análisis de regresión?

Los modelos de regresión tienen al menos dos variables: al menos una variable de exposición (x) y una variable de respuesta (y). Las variables incluidas en el modelo no son simétricas, ya que está implícito que una es una exposición y otra es un evento que podría ser consecuencia de la exposición. Si bien el modelo no implica causalidad directamente, hay una tendencia a pensar en las asociaciones que evalúa en este mismo sentido.

De las características de la variable de respuesta del modelo, dependerá la selección del tipo de modelo de regresión (ver más adelante ¿Cómo se clasifican los modelos de regresión?). Esta es la razón por la cual es tan importante poder clasificar consistentemente nuestra variable de respuesta para poder seleccionar el modelo apropiado.

Los modelos tendrán además una o más variables explicativas. Los modelos de regresión pueden incorporar variables dicotómicas, categóricas nominales u ordinales, continuas o discretas como variables explicativas. Los modelos con sólo una variable explicativa y una variable de respuesta se llaman modelos de regresión simple. Los modelos con más de una variable explicativa se llaman modelos multivariados.

Los modelos de regresión lineal simple pueden tener una interpretación gráfica que es simple con dos variables en un plano. Los modelos de regresión multivariados responden a los mismos principios, pero tienen representaciones gráficas más complejas, con representación en un espacio multidimensional.


¿Qué parámetros estima un modelo de regresión?

El modelo de regresión utiliza la muestra y su información para estimar parámetros poblacionales de la misma manera que venimos viendo para otros estimadores muestrales. En su forma más simple, los parámetros estimados por el modelo pueden incluir un parámetro independiente (α , a veces se denomina β_0 también) y un parámetro por cada variable explicativa ($\beta_1, \beta_2, \dots \beta_p$). Estos estimadores se llaman coeficientes del modelo ($a, b_1, b_2, \dots b_p$). Como se trata de estimadores muestrales, deben presentarse con intervalos de confianza y p valores de test de hipótesis.

El estimador del parámetro independiente representa la ordenada al origen del modelo y se llama término independiente. Corresponde al valor que tomaría en promedio la variable de respuesta cuando todas las variables explicativas del modelo valen 0. Para algunos problemas biológicos puede no tener interpretación directa, ya que la variable explicativa no toma nunca valor cero. Sin embargo, es un componente necesario del modelo para su funcionamiento. Por ejemplo, pensemos en un modelo de regresión en el cual la variable de respuesta es la presión sistólica promedio en milímetros de mercurio de un paciente, y la variable explicativa es su peso en kilogramos. El término independiente representa el valor promedio de la presión arterial cuando el peso del paciente es cero. En casos como este, el término independiente podría no tener interpretación directa.

El estimador de cada variable explicativa se llama coeficiente y representa la medida de asociación entre la variable de respuesta y la variable explicativa. Cada variable explicativa tendrá un coeficiente estimado por el modelo. Este coeficiente se interpreta de acuerdo a su direccionalidad y su magnitud como una medida de asociación. Diferentes modelos de regresión estiman diferentes medidas de asociación entre las variables explicativas y las variables de respuesta. En un modelo bivariado, el coeficiente de la única variable explicativa representa la medida de asociación cruda entre explicativa y respuesta. En el caso de un modelo multivariado, el coeficiente de una variable explicativa representa la medida de asociación de la variable explicativa sobre la variable de respuesta, ajustada por todas las demás variables en el modelo. (Ver Figura 16)

Figura 16. Los modelos de regresión se basan en la ecuación de la recta. Esta recta representa un modelo de regresión simple donde y es la variable de respuesta, x es la variable explicativa, a es el estimador de a u ordenada al origen. b es el estimador de β o coeficiente de la variable x o pendiente de la recta.




¿Cómo se clasifican los modelos de regresión?

Si bien todos los modelos de regresión tienen más o menos los mismos componentes en común, presentan algunas diferencias importantes. Como mencionamos anteriormente, los modelos se clasifican por la variable de respuesta. Si la variable de respuesta es continua (o razonablemente continua), se utiliza un modelo de regresión lineal. Para las dicotómicas se utiliza el modelo de regresión logística. Para los datos censurados se utiliza el modelo de regresión de riesgos proporcionales de Cox. Para las cuentas o tasas se utiliza el modelo de regresión de Poisson.

Modelo de regresión lineal. En el modelo de regresión lineal, la variable de respuesta es continua. El término independiente representa la ordenada al origen o el valor promedio que tomaría la variable de respuesta cuando todas las variables explicativas en el modelo son iguales a cero. El coeficiente de una variable explicativa representa cuánto cambia el promedio de la variable de respuesta, con el aumento de una unidad en la variable explicativa.

Figura 17. Modelo de regresión lineal



Modelo de regresión logística. En el modelo de regresión logística la variable de respuesta es dicotómica. Se llama logística porque para utilizar un modelo lineal, es necesario transformar la probabilidad de que ocurra la variable de respuesta dicotómica utilizando una transformación que se llama logística o logit de la probabilidad. En el caso de la regresión logística, el coeficiente de cada variable explicativa puede transformarse en un odds ratio. De esta manera, se obtiene naturalmente una medida de asociación natural directamente estimada por el modelo. Este odds ratio tiene el mismo valor que si se lo calcula utilizando una tabla de doble entrada y por supuesto tiene la misma interpretación y propiedades.

Figura 18. Modelo de regresión logística

$$\bar{p}(x) = \frac{e^{(\alpha + \beta x)}}{1 + e^{(\alpha + \beta x)}}$$

$$\frac{\bar{p}(x)}{1 - \bar{p}(x)} = e^{(\alpha + \beta x)}$$

Modelo de regresión de Cox. En el modelo de regresión de riesgos proporcionales de Cox, la variable de respuesta es dicotómica con censura (ver más adelante Métodos para datos censurados). Por esta razón se trata de una variable de respuesta compuesta por una variable dicotómica del evento de interés y una variable continua que representa el tiempo. En este caso el coeficiente de cada variable explicativa puede transformarse en hazard ratio que es una medida de asociación natural entre la variable explicativa y la variable de respuesta. Otros modelos de regresión que trabajan con datos censurados permiten estimar otra medida de asociación diferente que se llama tiempo relativo.

Figura 19. Modelo de regresión de riesgos proporcionales de Cox

$$h(t) = h(t) * e^{\beta x}$$

Modelo de regresión de Poisson. En este modelo, la variable de respuesta puede ser una cuenta de algo, una tasa o el tamaño de una celda en una tabla de doble entrada.^[74,75] En su acepción más común, la medida de asociación que se obtiene del coeficiente es un riesgo relativo o una razón de tasas.

El modelo de Poisson puede utilizarse como parte de la metodología de captura recaptura para estimar el tamaño de la celda no capturada por ningún método de recuperación de casos. Esta es una aplicación muy interesante y útil cuando se intenta estimar por ejemplo una prevalencia a partir de múltiples fuentes independientes incompletas. Hay muchos ejemplos de este uso particular en la literatura, como Estimation of the Frequency of Intravenous Drug Users in Hama-dan City, Iran, Using the Capture-recapture Method^[76] o Increasing prevalence of multiple sclerosis in Buenos Aires, Argentina.^[77]

¿Cuáles son los supuestos de los modelos de regresión?

Los modelos de regresión tienen supuestos específicos que deben evaluarse siempre. El modelo no funciona si se violan sus supuestos. Una revisión detallada de los métodos estadísticos excede los objetivos de este libro. Consulte Regression Methods in Biostatistics: Linear, Logistic, Survival, and Repeated Measures Models, para una descripción más detallada sobre los modelos de regresión y sus supuestos.^[78]

Tomaremos por ejemplo el modelo de regresión lineal para explicar sus supuestos. El resto de los modelos tienen supuestos específicos que es necesario y fundamental evaluar. La evaluación de los supuestos de un modelo es una herramienta valiosa ya que existen soluciones alternativas cuando los supuestos no se sostienen.

Como ya mencionamos anteriormente, la variable de respuesta es continua en los modelos de regresión lineal. Los supuestos del modelo de regresión lineal son independencia de las observaciones (ausencia de correlación entre las distintas mediciones de la variable de respuesta), linealidad de la relación entre la variable explicativa y la variable de respuesta, homocedasticidad, normalidad de residuos, y ausencia de colinealidad entre diferentes variables explicativas del modelo.

¿Cómo evalúo los supuestos de un modelo de regresión lineal?

Independencia de las observaciones es un supuesto que se evalúa por diseño ¿Existen duplicados en los datos que violan la independencia de las variables de respuesta? Por ejemplo: 2 episodios del mismo individuo, dos hermanos gemelos o varias mediciones del mismo individuo en el tiempo. En estos casos es necesario usar modelos que permitan flexibilidad ante la presencia de correlación entre diferentes mediciones de la variable de respuesta.


Para aplicar un modelo de regresión lineal es fundamental que la relación entre

la variable explicativa y la variable de respuesta sean razonablemente lineales. Este supuesto puede evaluarse simplemente realizando gráficos para describir la relación entre la variable explicativa y la variable de respuesta. Es posible realizar transformaciones de las variables para lograr linealidad.

La homocedasticidad implica varianza constante y homogénea de los residuos del modelo. Los residuos son las diferencias para cada uno de los individuos entre el valor predicho por el modelo (estimado por el modelo o calculado con la ecuación del modelo) y el valor observado para la variable de respuesta. Mientras más pequeños son los residuos de un modelo, mejor es la bondad de ajuste del modelo. Esto es porque lo que el modelo estima como valor de la variable respuesta y lo que se observó en la realidad son muy parecidos y por ende el modelo ajusta mejor. Pero la homocedasticidad hace referencia a que los residuos tengan una variabilidad similar a lo largo de diferentes valores de la variable explicativa. Utilizando los residuos también, es necesario evaluar la normalidad de su distribución.

La colinealidad implica relación entre las variables explicativas entre sí. El modelo requiere que las variables explicativas no representen la misma información con mínimas variaciones. Si dos variables son transformaciones una de otra como podría ser el peso en kilos y el peso en libras a la vez, el modelo tendrá que eliminar una de las dos. Más frecuente es la situación en que dos variables representan el mismo concepto pero están medidas de forma diferente como podría ser dos scores que miden severidad de enfermedad hepática como el MELD (Model for End-Stage Liver Disease) y la escala de Child-Pugh.^[79] En este caso, es necesario demostrar la linealidad entre ambas variables explicativas y decidir cual de las dos se dejará en el modelo.

Figura 20. Cada residuo es la distancia entre el valor observado (dato) y el valor estimado por el modelo de regresión. Mientras más chica es esta distancia, mejor ajusta el modelo. ¿Cuál de estos 3 modelos le parece que tiene mejor ajuste?



¿Qué tipos de variables explicativas se pueden incluir en un modelo de regresión?

Los modelos de regresión son muy plásticos y permiten la incorporación de diferentes tipos de variables explicativas.

Por ejemplo en un modelo de regresión logística, la incorporación de una variable continua o discreta como variable explicativa es simple. En un modelo de regresión simple, el OR estimado por el modelo representará un OR para un aumento en una unidad de esta variable explicativa. Si se trata de la variable edad en años, un OR de 2 representa el OR entre edad y edad-1. Responde a la pregunta cuál es el OR para cada aumento de una unidad en la variable explicativa. El modelo estimará el OR para la variable de respuesta con la unidad que hayamos incorporada la edad: puede ser 1 año, 1 mes, 1 día. Va a mantener la unidad con la que hayamos incorporado la variable.

Por ejemplo, al incorporar una variable dicotómica en un modelo de regresión logística, es importante codificar como 1 y 0. En general es de buena práctica mantener una codificación homogénea para toda la base. El OR para esa variable que va a estimar el modelo corresponde al OR de la categoría 1 sobre la categoría 0. Habitualmente el 1 representa expuesto y 0 no expuesto. Si la variable que me interesa es hipertensión arterial, un OR de 3 se interpreta como que los hipertensos tienen 3 veces el odds para el evento que los no hipertensos (ver anteriormente ¿Cómo se interpretan las medidas de asociación?).

Incorporar variables categóricas con más de 2 categorías es diferente. Los modelos de regresión requieren que la variable original sea convertida en múltiples variables dicotómicas, indicadoras o dummies. Para conservar la misma información que una variable categórica con 3 categorías se requiere 2 variables indicadoras. Si mi variable original es país de origen, imaginemos que a los fines de mi estudio puede tomar sólo 4 valores: Argentina, Brasil, Chile, Perú. Puedo convertir la variable original en 3 variables dicotómicas Argentina Sí/No, Brasil Sí/No, Chile Sí/No. Si un individuo en mi variable original estaba identificado como Argentina, en las 3 variables categóricas será Argentina Si, Brasil No, Chile No. Los individuos identificados como Perú, serán los que en las 3 variables dicotómicas tendrán Argentina No, Brasil No, Chile No. Es decir, la cantidad de variables dicotómicas que necesito para conservar la misma información es la cantidad total de categorías menos 1. Es decir que la información de una variable categórica nominal con 4 categorías es equivalente a 3 variables indicadoras dicotómicas, manteniendo exactamente la misma información.

Utilizando un modelo de regresión logística para estas 3 variables indicadoras, obtendré 3 OR diferentes y todos contendrán la categoría omitida como categoría de referencia. El OR de la variable indicadora Brasil, corresponde al OR de los identificados como Brasil Sí (Argentina No, Brasil Sí, Chile No) con respecto a los identificados como Perú en la variable original (Argentina No, Brasil No, Chile No). La mayoría de los paquetes estadísticos codifican las variables categóricas con más de 2 categorías en múltiples variables indicadoras automáticamente.

¿Cómo selecciono las variables para incorporar en el modelo?

Para seleccionar las variables explicativas a incluir en el modelo, es importante tener claro el objetivo de utilizar un modelo de regresión. ¿Me interesa ajustar por potenciales confundidores? ó ¿Me interesa generar un modelo predictivo?

Si mi interés es ajustar por potenciales confundidores, es fundamental identificar las variables que podrían confundir la asociación bajo estudio. Si me interesa ¿Cuál es el efecto del ejercicio sobre el infarto? debo buscar todos los potenciales confundidores de esta asociación. Algo muy importante es considerar que debo buscarlos antes de iniciar el estudio, ya que será fundamental medir estas variables para poder ajustarlas en el análisis multivariado de regresión.

Como comentamos anteriormente, la bibliografía es fundamental. Identificar en las citas relevantes cuales fueron los confundidores identificados o postulados para esta asociación. A su vez la práctica y conocimiento profundo del campo permite identificar variables adicionales. ¿Cuáles podrían ser las verdaderas causas de esta asociación? La mejor forma de identificar confundidores es realizar un diagrama acíclico dirigido DAG como mencionamos anteriormente (ver ¿Qué son los confundidores?).^[27] Esta herramienta permite conceptualizar las relaciones causales entre las variables permitiendo elegir cuales medir y por cuales ajustar y cuales no. El análisis bivariado inicial es fundamental para identificar variables en nuestro estudio que se comportan como potenciales confundidores. Cuando me interesa estimar una asociación ajustada de una exposición sobre un evento es de buena práctica incluir todas las variables consideradas como potenciales confundidores según el DAG construido por especialistas y todas aquellas significativas en el análisis bivariado.

Si mi interés es predecir, me interesa identificar el mejor subconjunto de variables que permiten identificar quien tiene una condición o tendrá un evento particular. En este caso existe la posibilidad que no interesen tanto las asociaciones causales. También puede ser menos importante las asociaciones no estadísticamente significativas en el análisis bivariado que los investigadores consideran importantes. Por supuesto que dependerá del contexto y el problema particular.

¿Cómo elijo el mejor modelo predictivo?

Particularmente cuando nos interesa construir un modelo predictivo, es fundamental utilizar métodos válidos para seleccionar el mejor modelo con la mejor bondad de ajuste para predecir la variable de respuesta. Durante el análisis de los datos es habitual tener varios modelos alternativos entre los cuales haya que elegir cual es el mejor modelo para predecir la variable de respuesta.

Para seleccionar el mejor modelo existen diferentes estrategias. Por ejemplo en un modelo de regresión lineal, es posible comparar los diferentes modelos con el R cuadrado. El R cuadrado es un estadístico calculado para cada modelo que representa el porcentaje de variabilidad de la variable respuesta explicado por el modelo de regresión. Toma valores entre 0 y 1. Un R cuadrado de 1 es el mejor modelo posible, y representa la situación en la cual la variabilidad de la variable de respuesta está completamente explicada por el modelo. Otras formas de


comparar modelos alternativos de regresión lineal son el valor del estadístico F y su p valor.

Para modelos de regresión logística se puede utilizar el test de máxima verosimilitud. El área bajo la curva ROC (receiver operating characteristic) del modelo o los criterios de información o el test de máxima verosimilitud. Este último test sólo es útil para comparar dos modelos anidados (es decir dos modelos idénticos, en el cual uno tiene una variable más que el otro). La hipótesis nula es que la bondad de ajuste de ambos modelos es idéntica.

Aplicando un modelo de regresión logística, es posible estimar los valores predichos por el modelo. Estos valores pueden utilizarse como un test diagnóstico que va entre 0 y 1 y representan las probabilidades predichas por el modelo para cada individuo. A su vez conocemos quien tuvo el evento de interés (variable de respuesta = 1) y quien no lo tuvo (variable de respuesta = 0). Es posible entonces estimar el área bajo la curva ROC del modelo como medida aproximada de la capacidad de discriminación o precisión diagnóstica. De esta manera es posible comparar dos modelos alternativos comparando las áreas bajo las curvas ROC y sus intervalos de confianza.

Los criterios de información son estimaciones basadas en el modelo que consideran el ajuste y la parsimonia. En este sentido se entiende parsimonia como el modelo más simple, con menor cantidad de parámetros estimados. Existen varias formas de criterios de información de las cuales las más utilizadas son el criterio de información Bayesiano y el criterio de información de Akaike.^[80] El modelo de menor criterio de información es el que tiene mejor ajuste con mejor parsimonia.

Figura 21. En esta figura se muestran 3 áreas bajo la curva ROC: la primera es igual a 1 (modelo que predice perfectamente la ocurrencia de un evento); la última es igual a 0,5 (modelo que no es mejor que tirar una moneda para predecir la ocurrencia del evento). La segunda curva representa una situación más real, donde la predicción del modelo está en algún lado entre 1 y 0,5.



¿Qué son los datos censurados?

Como mencionamos anteriormente, en muchos de los estudios de cohorte el seguimiento de los diferentes participantes puede ser de diferente longitud. Típicamente las cohortes abiertas y los registros presentan este problema. Durante un período administrativo de duración del estudio, es probable que los diferentes participantes tengan diferentes tiempos de seguimiento.

Los diferentes tiempos de seguimiento pueden deberse a que los individuos entraron en la cohorte en tiempos diferentes, experimentaron el evento o se perdieron al seguimiento. Si bien estos casos son diferentes desde el punto de vista conceptual, representan las diferentes situaciones más frecuentes que podrían ocurrir durante el seguimiento de una cohorte de pacientes.

Consideramos como ejemplo un estudio donde el evento de interés es la muerte. Durante el período del estudio, algunos de los individuos en seguimiento morirán. En esos individuos el tiempo desde el ingreso a la cohorte y la muerte es observado y puedo medirlo, este tiempo se llama tiempo al evento. Corresponde a un número puntual positivo.


Por el contrario en los pacientes que no experimentaron el evento, sólo tendré un tiempo en el que seguí al individuo y sabré que al final del seguimiento el paciente estaba vivo. Pero no podemos decir nada del segundo posterior a su salida del estudio. Sólo sabemos que en un último momento que lo observe, el paciente no había experimentado el evento, es decir estaba vivo. Se podría decir que con certeza el evento muerte ocurrirá en todos nosotros. En este caso, podemos tener la certeza de que el evento muerte ocurrirá en cualquier paciente en algún tiempo. Si el paciente estaba vivo el último momento en que lo vi en mi estudio, puedo con seguridad afirmar que morirá en algún tiempo mayor al que lo observé en mi estudio. En este caso se asume que el tiempo al evento es mayor al tiempo que observé al paciente y que la ocurrencia del evento está censurada. Por esta razón se llama censurados a los eventos que no observamos durante la duración del estudio.

Es interesante notar que si el tiempo de seguimiento es diferente para cada participante, los que tengan el evento tienen también un tiempo al evento observado. Por el contrario en los pacientes que no observé que tengan el evento, el

tiempo al evento es mayor al último tiempo que lo observe vivo, pero no podría decir cuanto mayor. El tiempo al evento en este caso está censurado. Los tiempos al evento censurados son segmentos y no tiempos puntuales. Se que son mayores al último momento que lo vi vivo. De esta manera tendré dos tipos de tiempos, los observados y los censurados. No será posible realizar operaciones matemáticas con esos tiempos censurados como obtener un promedio, ya que algunos son números puntuales y otros segmentos.

A su vez, si quisiera armar una tabla de 2 por 2, sería imposible clasificar los individuos que no tuvieron el evento. Simplemente porque sólo se que no tuvieron el evento hasta el momento que los observé. Pero ese momento es diferente para cada individuo. Por esta razón no es posible armar una tabla de doble entrada con esta información. Tampoco las medidas comunes de incidencia acumulada. Sin embargo ¿Qué pasaría si el seguimiento de todos los que no tuvieron el evento fuera idéntico y completo? En este caso no habría censura y no sería una cohorte dinámica (¡y puedo usar los métodos convencionales!)

Figura 22. El primer esquema representa una cohorte cerrada, donde todos los individuos son seguidos durante el mismo período y conozco si tuvieron el evento o no al final del seguimiento. El segundo esquema representa una cohorte dinámica, donde el seguimiento no es uniforme. En este caso muchos de los individuos sin evento tienen un período de observación diferente y de menor longitud que la duración del estudio



¿Cómo registrar datos censurados?

Cuando se recolectan los datos para realizar un análisis de tiempo al evento es muy importante recolectar toda la información para que sea posible hacer el análisis apropiado. Lo más importante para esto, es reconocer la situación de censura antes de iniciar el estudio y planear los mecanismos de recolección de datos para recolectar la información de manera apropiada y completa.

En general, la mejor forma es recolectar la información de la manera más granular posible registrando las fechas y el evento. Durante el período del seguimiento se identificaron los individuos que han tenido el evento. Se debe recolectar la fecha de inicio de todos los pacientes. Para los individuos que hayan experimentado el evento, se debe recolectar la fecha del evento. Para los individuos que no hayan experimentado el evento durante el seguimiento, se recolecta la última fecha donde el paciente se observó sin el evento.

Con la fecha de inicio y la fecha fin, se calculan los tiempos de seguimiento. Así la información del evento estará contenida en dos variables: una de tiempo al evento y la otra de evento Si/No. Los pacientes que tuvieron el evento son los clasificados como Si. Los pacientes censurados son los pacientes clasificados como No.

¿Qué son los eventos competitivos?

Los eventos o riesgos competitivos son los eventos que sacan a un individuo de estar en riesgo para el evento de interés bajo estudio.^[81] Algunos ejemplos son:

- Si estoy estudiando el efecto de fumar sobre el desarrollo de cáncer de pulmón, los pacientes que fallecen de enfermedad cardiovascular dejan de estar en riesgo para desarrollar cáncer de pulmón.
- Si estoy evaluando el efecto de una infección sobre la mortalidad en pacientes cirróticos, el trasplante es un evento competitivo que no permite observar la mortalidad asociada a la infección.
- Si estoy estudiando el riesgo de metástasis luego de dos tipos de quimioterapia, la muerte cardiovascular podría ser un evento competitivo. La muerte por progresión de la enfermedad podría representar un fenómeno similar a la ocurrencia de metástasis y por ende podrían considerarse similares. En ocasiones esto último se trata como evento combinado.

Cuando existen eventos competitivos, es necesario plantear alguna estrategia alternativa. La estrategia depende completamente de la situación y de los objetivos del estudio. Algunas posibles estrategias para considerar los eventos competitivos son:

- **Excluir los individuos que tengan evento competitivo.** Esta estrategia no se recomienda porque podría potencialmente generar sesgo.

- **Ignorar la presencia de riesgos competitivos, es decir, considerarlos censurados.** Convierto los eventos competitivos en censurados, sólo válida cuando tengo razones para pensar que el comportamiento es similar. Nunca se debe combinar cuando el evento competitivo no se comporta como el censurado. Por ejemplo, no es lo mismo un paciente perdido aleatoriamente que un paciente fallecido si estoy estudiando el efecto de fumar sobre el desarrollo de cáncer.
- **Outcomes combinados con el evento de interés.** Sólo válida cuando el evento competitivo y el evento de interés se comportan similares. Por ejemplo ACV o IAM son eventos que se combinan habitualmente y que se interpretan como manifestaciones clínicas de la misma enfermedad. Si quiero estudiar progresión de cáncer, es común ver muerte o progresión debido a que se interpreta como estadios de la misma enfermedad, siendo progresión un paso necesario intermedio hasta la muerte. En ambos casos se espera que cualquier factor de riesgo o factor protector se comporte de la misma manera con respecto al outcome combinado. Es decir, si algo se comporta como un factor de riesgo, es un factor de riesgo con mismo efecto sobre los diferentes componentes del outcome combinado. Nunca se debe combinar cuando el evento competitivo no se comporta como el outcome.
- **Considerar estimaciones, tests y modelos** que consideren el evento competitivo como diferente a la censura y diferente al outcome.

¿Cómo describo los datos censurados?


Cuando existe censura, la incidencia acumulada se convierte en una función del tiempo. En este caso no hay un único número que describa la incidencia acumulada, sino que ésta cambia en función del tiempo en el que se mira.

El método descrito por Kaplan Meier es un método que permite estimar la sobrevivencia acumulada para cada tiempo. Utiliza la información de todos los participantes que se encuentran en riesgo en cada momento. De esta manera, cada paciente censurado, permanece en riesgo mientras se encuentra observado. Posteriormente deja de contar en el denominador. Se trata de un método eficiente para estimar la incidencia acumulada a un determinado tiempo.

El método es muy simple. Consiste en comenzar a tiempo cero donde la sobrevivencia es 1. Posteriormente a cada tiempo que ocurre un evento se calcula la probabilidad del evento usando la cantidad de eventos a ese tiempo y los pacientes que siguen estando en riesgo. Posteriormente se multiplica la probabilidad estimada por la probabilidad de haber llegado a ese tiempo. De esta manera se calcula la probabilidad del evento a ese tiempo. El gráfico que muestra la variación de la inversa de la incidencia acumulada se llama gráfico de Kaplan Meier de tiempo libre de evento.

La mediana de tiempo al evento representa el tiempo al cual la incidencia acumulada estimada es 0,5. Es una medida útil que interesa describir cuando existe censura. En muchos casos la mediana del tiempo al evento no está definida porque la incidencia acumulada no llega al 0,5.

Figura 23. En estas dos curvas de sobrevida estimada por el método de Kaplan Meier se ven las diferencias entre ambos grupos en función del tiempo.



¿Cómo comparo dos curvas de sobrevida?

Una pregunta frecuente es si una exposición dicotómica se asocia con el tiempo a un determinado evento. Esto es equivalente a preguntarse si el tiempo al evento es igual en los expuestos y los no expuestos.

En este caso la hipótesis nula es que la función de incidencia acumulada en el tiempo es igual en los expuestos y no expuestos. Para esto se utilizan diferentes test de hipótesis como el Log Rank test o el test de Cox Mantel.

¿Cuál es modelo de regresión para datos censurados?

Cuando la variable de respuesta tiene censura, se utiliza el modelo de regresión de riesgos proporcionales de Cox. Es un modelo a libre distribución y se dice que es semiparamétrico. Es decir que no hace supuestos sobre la distribución del tiempo al evento.

Este modelo tiene el supuesto de riesgos proporcionales que implica que el hazard ratio es un único número constante que no varía en función del tiempo. Por ejemplo para una variable explicativa dicotómica como el sexo, el hazard ratio es un único número que representa una medida multiplicativa entre ambas funciones de incidencia acumulada correspondientes a sexo = masculino y sexo = femenino, para cualquier tiempo. Cuando el supuesto se viola, es posible utilizar un conjunto de modelos de regresión de tiempo al evento paramétricos.

El modelo de regresión de riesgos proporcionales de Cox, permite estimar el hazard ratio que representa una medida de asociación entre la variable de exposición y la variable de respuesta. El hazard ratio representa por cuanto se multiplica el riesgo en función del tiempo de un grupo para dar el riesgo en función del tiempo del otro grupo.

El hazard ratio es siempre positivo, en escala logarítmica. Un hazard ratio de 1 implica que no existe asociación. Un valor mayor a 1 implica aumento de riesgo y un valor menor a 1 (entre 1 y 0) implica disminución de riesgo. Para calcular el hazard ratio de una variable de exposición dicotómica el modelo considera la categoría codificada como 1 sobre la categoría codificada como 0. De la misma manera un Hazard Ratio de una variable continua, indica por cuanto se multiplica el riesgo con cada aumento de una unidad de la variable explicativa.

¿Qué es un test diagnóstico?

Gran parte de la actividad clínica habitual consiste en categorizar pacientes. La categorización de pacientes no tiene el sentido de rotular, sino el de definir conductas diagnósticas, pronósticas o terapéuticas. Todas estas situaciones implican toma de decisiones conjunta entre médicos y pacientes. La toma de decisiones requiere información sobre las condiciones clínicas de los pacientes. Algunos de los ejemplos más comunes de tests diagnósticos son: Exámenes de laboratorio, Imágenes, Bioseñales, Tests microbiológico, Pruebas genéticas, Cuestionarios, Síntomas, Signos, Scores clínicos, Baterías de tests, entre otros. Los test diagnósticos en sentido amplio, son dispositivos o métodos que generan información. El proceso diagnóstico implica cambio de probabilidades luego del test de tener una determinada condición. El paciente tiene una probabilidad de tener la condición previa al test (probabilidad pretest) y una probabilidad posterior (probabilidad posttest). Es decir su probabilidad de tener la condición cambia luego de aplicar el test.

En este sentido el test diagnóstico implica una determinada situación clínica y una determinada condición. El cambio de probabilidades pretest y posttest es útil para la toma de decisiones clínicas. Con la probabilidad posttest se decide si el diagnóstico está confirmado o si es necesario realizar otro estudio de test diagnóstico. O si la probabilidad de tener una determinada condición es tan alta que se supera un umbral de tratamiento. La probabilidad posttest puede ser tan baja que rechaza la posibilidad de tener una determinada condición.

¿Qué es un estudio de test diagnóstico?

El propósito de un test diagnóstico es una función específica en una población específica que se puede tener una condición en particular. Los estudios de test diagnóstico son los estudios de investigación diseñados para evaluar aspectos específicos de los test diagnósticos como su performance diagnóstica o su reproducibilidad o su utilidad clínica en determinadas circunstancias.

Como veremos más adelante, existen muchas preguntas diferentes que se pueden abordar con estudios de test diagnósticos. Sin embargo, los estudios de



test diagnóstico clásico tienen los siguientes componentes: Test a evaluar, Gold Standard, Población en situación clínica específica, Performance diagnóstica. Son estudios que evalúan la capacidad de un test bajo estudio de detectar una determinada condición con respecto a un gold standard.

¿Qué preguntas responden los estudios de test diagnósticos?

Los estudios de test diagnósticos pueden contestar una gran variedad de preguntas diferentes. De manera similar que con los ensayos clínicos, se puede presentar una clasificación en fases de acuerdo a las preguntas que contestan. Esta clasificación permite organizar la evidencia que generan diferentes estudios de test diagnósticos pero no es exhaustiva. Para más detalle ver *The Evidence Base of Clinical Diagnosis: Theory and Methods of Diagnostic Research, 2nd Edition*.^[82]

- **Fase 1.** ¿Tienen los individuos con la condición buscada diferente resultado del test que los individuos sin la condición? (comparar resultados en individuos sanos e individuos enfermos).
- **Fase 2.** ¿Los pacientes con un determinado resultado del test tienen mayor chance de tener la enfermedad? Los estudios que responden estas preguntas son estudios de performance diagnóstica clásica.
- **Fase 3.** ¿En un escenario de potencial utilidad, el test distingue los enfermos de los sanos? En este caso se agrega la situación más real posible a través de estudios más pragmáticos.
- **Fase 4.** ¿Les va mejor a los pacientes evaluados con el test que a los evaluados con otros test? En este caso interesa definir si a los pacientes les va mejor si el diagnóstico se realizó con un test u otro con respecto a eventos clínicos de interés como mortalidad, calidad de vida, o funcionalidad. Como por ejemplo este estudio que comparó el centellograma ventilación perfusión con la tomografía axial computada para el diagnóstico de tromboembolismo de pulmón en un ensayo clínico aleatorizado *Computed tomographic pulmonary angiography vs ventilation-perfusion lung scanning in patients with suspected pulmonary embolism: a randomized controlled trial*.^[83]

Los test diagnósticos presentan un panorama mucho más amplio que las fases presentadas. Por ejemplo puede ser de interés contestar la pregunta ¿Cuál es la confiabilidad (o reproducibilidad o consistencia, son sinónimos) de un test? entre evaluadores o en diferentes momentos del mismo individuo. Como en este estudio, *Inter-observer reliability of computed tomographic classifications of diverticulitis*, que evaluó la concordancia entre dos observadores para la detección de diverticulitis.^[84]

O el desarrollo y validación de un instrumento de medición de variables no observables o constructos como el MiniMental Test para medir cognición o SF-36 para medir calidad de vida.^[57] O la validación transcultural de un instrumento

para su uso en otro idioma o cultura. El SF36 es un cuestionario validado a múltiples idiomas y con gran experiencia en su uso.^[85]

Como es de esperar, todas estas diferentes preguntas se responden con diseños, poblaciones y escenarios diferentes.

¿Qué componentes tienen los estudios de test diagnóstico clásicos?

En un estudio de test diagnóstico clásico, se incluyen individuos que representan una población en una determinada situación clínica. Es fundamental que en estos diseños los individuos participantes se les haga tanto el test en evaluación como el gold standard. Si uno de los dos falta, no es posible estimar la performance diagnóstica.

- **Test a evaluar.** Es el test problema del que se desea obtener información sobre su funcionamiento en una determinada situación específica con sentido clínico. Podría ser un nuevo test de Elisa para la detección de trypanosoma cruzi, el parásito responsable de la Enfermedad de Chagas Mazza. Siempre será fundamental que el nuevo test tenga alguna ventaja con respecto a los anteriores.
- **Gold Standard.** Es el test que se usa como patrón de comparación, el test que clasifica correctamente todos los casos sin equivocarse y por eso se usa como patrón de referencia. En este caso, probablemente el mejor gold standard sería la observación directa de parásitos viables en tejido del huésped.

En muchos casos no existe un buen gold standard. En estos casos se llama estándar de referencia y es necesario utilizar estrategias alternativas. Una propuesta alternativa es el uso de LEAD estándar que incluyen el seguimiento en el tiempo (Longitudinal), por un grupo de expertos (Experts) de toda la información disponible (All Data).^[86] existen otras aproximaciones similares para mejorar los estándares disponibles.

- **Población y situación clínica.** La población blanco en una determinada situación clínica específica es una parte fundamental del test, ya que depende la utilidad que se le va a dar y la situación en la que va a ser usado. ¿Se utilizará como un test de Screening? ¿De confirmación? ¿De estadificación? ¿En qué población se utilizará?
- **Performance diagnóstica o resultados.** La performance diagnóstica de un test son el conjunto de mediciones de su funcionamiento para una función específica. Todos se calculan a partir de los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos. Incluye la sensibilidad, especificidad, valor predictivo positivo, valor predictivo negativo, precisión diagnóstica, likelihood ratio positivo, likelihood ratio negativo, odds ratio diagnóstico. Cada uno tiene un valor específico en una determinada situación clínica.

¿Cuáles son las situaciones clínicas específicas de un test diagnóstico?

Los objetivos de los test diagnósticos en la práctica clínica son: Detectar o excluir enfermedades, Evaluar pronóstico, Contribuir a la toma de decisiones, Monitorizar la evolución clínica, o Medir estado físico. Las diferentes situaciones requieren características diferentes de cada test.

El screening o tamizaje es una de las situaciones clínicas más habitual para el uso de estudios de test diagnóstico. El screening se aplica a pacientes asintomáticos, en grandes poblaciones para identificar los que están en suficiente riesgo para una enfermedad para justificar más estudios. Su objetivo principal es detectar una condición de manera precoz sobre la cual es posible realizar tratamientos específicos que son más eficientes. Deben ser de bajo costo y alta disponibilidad para poder generalizar su uso de manera masiva. El objetivo principal es detectar todos los verdaderos casos, por lo cual un buen test de screening no debiera tener falsos negativos. El screening tolera la presencia razonable de falsos positivos, ya que se requeriría un nuevo test para confirmar las condiciones clínicas antes de tomar decisiones terapéuticas. Ejemplos de screening son el interrogatorio dirigido por síntomas de EPOC a los pacientes adultos que fumaron, las mamografías y la toma de presión arterial en consultorio.

Establecer un diagnóstico, específicamente para confirmar o descartar una condición o enfermedad, es una situación clínica altamente frecuente y relevante. Confirmar diagnósticos permite tomar la decisión de iniciar un determinado tratamiento, por lo cual no toleran falsos positivos. Ejemplos de estudios confirmatorios son por ejemplo una tomografía axial computada del tórax para caracterizar un nódulo pulmonar o una cinecoronariografía para establecer el diagnóstico de enfermedad coronaria o una colonoscopia para la detección de lesiones colónicas malignas o premalignas, o una biopsia con estudio anatómopatológico de una lesión nodular de tiroides.

Estadificar implica medir la naturaleza o el grado de compromiso de una determinada condición como enfermedad coronaria, demencia o cáncer de mama. Dada una determinada condición clínica, ¿Cuál será la evolución de un paciente? No es posible predecir con exactitud la sobrevida o la respuesta a un determinado tratamiento, o si un determinado paciente presentara un evento específico en el seguimiento. Sin embargo, es posible categorizar al paciente en diferentes categorías pronósticas y estimar la probabilidad dentro de cada categoría. El pronóstico es una de las situaciones clínicas más frecuentes que aporta información valiosa para la toma de decisiones terapéuticas compartidas entre médicos y pacientes. Ejemplos de categorías pronósticas son los scores TNM de estadificación tumoral, las categorías de severidad de insuficiencia cardíaca o el score de Child para estadificar pacientes con cirrosis.

Otras dos situaciones adicionales son los estudios de rutina y monitoreo. Los primeros corresponden a los estudios de rutina cuyos hallazgos no se relacionan directamente con la condición presente, como el hemograma como práctica de

rutina. Sobre estos es fundamental conocer la evidencia que avala su periodicidad para evitar su sobreuso. Por el contrario los estudios de monitoreo tienen el objetivo de controlar la evolución o control de una enfermedad en el tiempo como la hemoglobina glicosilada en los pacientes diabéticos o el recuento de CD4 en los pacientes con HIV en tratamiento con terapia antiretroviral de alta eficacia.

¿Cuáles son las medidas de performance diagnóstica?

Las medidas de performance diagnóstica son estimadores de los verdaderos parámetros poblacionales: es decir la sensibilidad estimada en una muestra es el estimador muestral de la verdadera sensibilidad parámetro poblacional si se pudiera medir en la población blanco (ver anteriormente ¿Qué son los parámetros poblacionales y los estimadores muestrales?). Se presentan con sus intervalos de confianza de 95% como medida de precisión de cada una de las estimaciones.

Si el test bajo estudio arroja un resultado positivo o negativo y a su vez la condición bajo estudio corresponde a enfermos y sanos (clasificación por gold standard), es decir ambos son dicotómicos, es posible construir una tabla de 2×2 clasificando a todos los individuos en 1 de 4 categorías mutuamente excluyentes: verdaderos positivos, falsos positivos, verdaderos negativos, falsos negativos. Para poder clasificar un individuo en alguna de estas 4 celdas, es fundamental que todos se hagan el test en evaluación y el gold standar.

La sensibilidad representa la capacidad del test para identificar los individuos con la condición bajo estudio. Se calcula como la proporción de verdaderos positivos sobre los enfermos totales (verdaderos positivos + falsos negativos). Una sensibilidad de 100% quiere decir que en todos los enfermos el test bajo estudio da positivo, es decir no existen falsos negativos. Una sensibilidad de 85% se interpreta como de 100 pacientes enfermos, sólo 85 tendrán resultados positivos (verdaderos positivos), los 15 enfermos restantes tendrán resultado negativo (falsos negativos). En los estudios de screening lo más importante es la sensibilidad, ya que me interesa detectar todos los enfermos con la menor tasa de falsos negativos posibles. Quiero tener detectados todos los enfermos, aunque tenga algún falso positivo ya que voy a confirmar los diagnósticos con un método confirmatorio.

La especificidad representa la capacidad del test para identificar los individuos sanos. Se calcula como la proporción de verdaderos negativos sobre los sanos totales (verdaderos negativos + falsos positivos). Una especificidad perfecta de 100% quiere decir que en todos los sanos el test bajo estudio da resultado negativo, es decir no existen falsos positivos. Una especificidad de 65% se interpreta como de 100 pacientes sanos, sólo 65 tendrán resultado negativo (verdaderos negativos), los 35 pacientes sanos restantes tendrán resultados positivos (falsos positivos). En los estudios confirmatorios lo más importante es la especificidad,



ya que me interesa detectar todos sanos, con la menor tasa de falsos positivos posibles. No quisiera iniciar tratamiento en un paciente sano por error (falso positivo).

Sensibilidad y especificidad son características inherentes del test y no cambia con la población ni la prevalencia. Desde el punto de vista clínico interesa mucho más los valores predictivos. Tanto el valor predictivo positivo como el negativo cambian con la prevalencia de la condición bajo estudio en la población.

El valor predictivo positivo es la probabilidad de tener una condición si tengo un resultado positivo. Se calcula con los verdaderos positivos sobre la totalidad que tiene resultado positivo (verdaderos positivos + falsos positivos). El valor predictivo negativo es la probabilidad de no tener una condición si tengo un resultado negativo. Se calcula con los verdaderos negativos sobre la totalidad de los que tienen resultado negativo (verdaderos negativos + falsos negativos). Los valores predictivos son mucho más útiles para la toma de decisiones clínicas.

La precisión diagnóstica representa cuantos individuos clasifica correctamente el test. Se calcula con los correctamente clasificados (verdaderos positivos + verdaderos negativos) sobre el total (verdaderos positivos + verdaderos negativos + falsos positivos + falsos negativos). Es una medida que combina la sensibilidad y especificidad.

Figura 24. En los estudios de test diagnóstico clásicos, todos los pacientes se realizan el test bajo estudio y el gold estándar por lo cual es posible clasificarlos en una de 4 categorías: verdaderos positivos (VP), falsos positivos (FP), falsos negativos (FN) o verdaderos negativos (VN). Con estas 4 celdas es posible calcular los estimadores de sensibilidad, especificidad, valor predictivo positivo y valor predictivo negativo.

		GOLD STANDARD		
		POSITIVO	NEGATIVO	
TEST BAJO ESTUDIO	POSITIVO	Verdadero Positivo	Falso Positivo	Sensibilidad = $\frac{VP}{VP + FN}$
	NEGATIVO	Falso Negativo	Verdadero Negativo	Especificidad = $\frac{VN}{VN + FP}$
				Valor Predictivo = $\frac{VP}{VP + FP}$
				Valor Predictivo = $\frac{VN}{VN + FN}$

¿Qué es la curva ROC y para qué sirve?

Cuando el test bajo estudio arroja un resultado continuo y la condición que se intenta detectar es dicotómica, se pueden utilizar métodos adicionales para evaluar su función en la detección de la condición. Algunos resultados de test continuos pueden ser por ejemplo el índice de masa corporal (BMI) o la reacción colorimétrica de un test de ELISA para la detección de una infección viral.

Las curvas ROC se utilizan para evaluar la precisión de un test con resultado continuo para detectar una condición. Considerando el resultado continuo del test, si pudiéramos poner puntos de corte en todos los lugares posibles de valores del test, se podría para cada punto de corte, clasificar a los individuos en positivos o negativos para el test bajo evaluación. Si para cada uno de estos puntos de corte hiciéramos una tabla de 2×2 , podríamos clasificar a los individuos en positivos o negativos para el test y a su vez en enfermos y sanos por un gold standard conocido, simultáneamente. Para cada uno de estos puntos de corte, se puede utilizar estas tablas de 2×2 y estimar una sensibilidad y especificidad para cada uno de los puntos de corte.

De esta manera se puede construir una curva graficando la sensibilidad en función de $1 - \text{especificidad}$. En esta curva, el test perfecto es el que tiene una sensibilidad de 1 y una especificidad de 1. Un test con esa curva, tendrá un área bajo la curva de 1 y su discriminación sería perfecta. Por el contrario un test con un área bajo la curva de 0,5 no es mejor que tirar la moneda ya que se equivoca tantas veces como acierta. El área bajo la curva representa la capacidad de discriminación del test entre sanos y enfermos y se presenta con intervalos de confianza.

La curva ROC se utiliza adicionalmente para elegir el mejor punto de corte para una determinada situación específica. ¿Me interesa maximizar la sensibilidad o la especificidad o ambos? En este estudio estimaron el área bajo la curva y los puntos de corte de un test autoadministrado que detecta ADN de HPV para screening de pacientes en riesgo para cáncer de cuello de útero *Optimal Positive Cutoff Points for careHPV Testing of Clinician- and Self-Collected Specimens in Primary Cervical Cancer Screening: an Analysis from Rural China*.^[87] (Ver Figura 25)


¿Cuáles son los diseños de los estudios de test diagnóstico?

Existen diferentes diseños clásicos que se utilizan para responder distintas preguntas de test diagnóstico. Como siempre, la pregunta de investigación determina cual es el diseño más apropiado.

En los estudios de corte transversal se mide el test en evaluación y el gold standard en el mismo momento conceptual. En los estudios de cohorte se puede evaluar pronóstico o valor de la estadificación por ejemplo.

Los ensayos clínicos aleatorizados se utilizan en particular para comparar diferentes eventos en el seguimiento de pacientes manejados con estrategias diagnósticas o test diagnósticos alternativos. En algunas situaciones, la implementación de una estrategia diagnóstica puede estudiarse con estudios ecológicos. Los estudios cuasi experimentales o antes después, pueden utilizarse para comparar diferentes test diagnósticos con respecto a diferentes aspectos, estos son de particular importancia por ejemplo en los cambios de tecnología como cuando las tomografías de más alta resolución reemplazaron al centellograma de ventilación perfusión en el diagnóstico de tromboembolismo de pulmón.

Figura 25. Si imaginamos que tenemos 16 individuos clasificados tanto por un test en evaluación con un resultado continuo (filas) como por un gold standar perfecto (columnas), es posible cambiar el punto de corte del test en estudio. Con un primer corte en A para los valores continuos del test bajo estudio, se construye la tabla A. Con este punto de corte, el test bajo estudio tiene una sensibilidad de 1, una especificidad de 0,5. Si continuo generando tablas como B y C con diferentes puntos de corte, puedo construir con cada punto de corte una sensibilidad y especificidad para el test bajo estudio. Con esta información se construye la curva ROC.



¿Cuál es el mejor test diagnóstico?

De acuerdo a los diferentes aspectos que venimos discutiendo, la mejor respuesta a esta pregunta será “depende”. El mejor test diagnóstico dependerá de muchas condiciones adicionales que exceden la capacidad del test para clasificar correctamente los verdaderos enfermos en una determinada situación clínica particular.

Algunas características son inherentes al test como la performance diagnóstica, la utilidad específica para la cual fue diseñado y evaluado el test, el grado de invasión y tolerancia que implica, los potenciales efectos adversos que tiene, costo, entre otras. Otras características dependen del contexto como son la disponibilidad y las demoras, los recursos que requiere, el efecto que tiene el test sobre el paciente. Todas estas características deben considerarse en el ámbito y momento, incluyendo los test diagnósticos alternativos, las posibilidades terapéuticas y el contexto.

¿Necesito estimar el tamaño muestral?

Se entiende por estimación de tamaño muestral al cálculo de un número estimado de participantes o unidades de observación que debo incluir en un estudio para contestar de manera eficiente mi pregunta de investigación. Si no realizo estimación del tamaño muestral, no sabré el costo ni el tiempo que llevará implementar un estudio. Tampoco sabré si es posible hacerlo. Imaginen que me estoy haciendo una pregunta sobre fibrosis quística y en mi centro sólo hay 5 pacientes en total afectados: el estudio no es factible y sería bueno saberlo antes de empezar.

Piense en los siguientes objetivos de estudios de investigación. ¿Le parece que es necesario realizar algún tipo de estimación de tamaño muestral?

- Estimar la Sensibilidad y Especificidad de un test para detección de deterioro cognitivo
- Evaluar la asociación entre el consumo de un fármaco y la mortalidad
- Estimar la sobrevida de los pacientes con fibrosis quística
- Generar un modelo predictivo de mortalidad al año en base a comorbilidades
- Estimar la prevalencia de HTA en Ciudad Autónoma de Buenos Aires
- Generar un registro de glaucoma
- Comparar dos test diagnósticos con su curva ROC
- Estimar el cambio en el BMI asociado a un programa de dieta hipocalórica

¡Siempre es necesario realizar una estimación de tamaño muestral! Todos estos objetivos representan situaciones diferentes donde puede requerirse algún tipo de cálculo de tamaño muestral.

Si empiezo un estudio sin conocer el tamaño muestral requerido, puedo incluir pacientes de más o de menos. Incluir pacientes de más aumentará los costos y la duración del estudio más allá de lo necesario. Por el contrario incluir pacientes de menos puede representar una pérdida de tiempo ya que los resultados del estudio no serán concluyentes. En este caso puede no haber poder suficiente para detectar diferencias que verdaderamente existan.



A su vez, cuando un paciente participa de una investigación, consienten en donar su información para realizar un estudio de investigación. En este caso dona su información para contestar una pregunta no conocida con el fin de contribuir al conocimiento científico y mejorar el cuidado de la salud. No sería ético incorporar más información personal de los pacientes que la que se necesita para contestar la pregunta.

¿Cuándo hacer la estimación de tamaño muestral?

Las técnicas de estimación de tamaño muestral son necesarias en el diseño y planificación del estudio. En todos los casos es necesario hacer una estimación de tamaño muestral o algunas de las alternativas relacionadas para situaciones especiales (estimación de poder, o mínima diferencia detectable).

Es fundamental realizar estimaciones de tamaño muestral lo más precozmente posible. La cantidad de pacientes necesarios para realizar un estudio es un componente fundamental de la factibilidad. Es muy importante evaluar esto precozmente antes de invertir tiempo en una pregunta que requiere un tamaño muestral demasiado grande.

Para realizar estimaciones de tamaño muestral es necesario dividir las preguntas de investigación en descriptivas y analíticas. A continuación detallaremos que se requiere en cada una de estas dos ocasiones.

¿Tamaño muestral en las preguntas descriptivas?

Las preguntas analíticas se contestan estimando un parámetro poblacional a través de un estimador muestral como presentamos anteriormente. Para esto es necesario acompañar con una medida de precisión como son los intervalos de confianza. Debido a que interesa la precisión de las estimaciones, los cálculos en este caso se realizarán para tener un tamaño muestral suficiente para estimar un parámetro poblacional con una amplitud de intervalo de confianza suficiente y apropiado para la pregunta de investigación.

Por ejemplo si mi pregunta es ¿Cuál es la prevalencia de pacientes EPOC colonizados por pseudomona? Imaginemos que en una determinada población pienso que es de 2%. ¿Cuántos pacientes necesito para estimar la prevalencia de colonización por pseudomona de 2% con un intervalo de confianza de 95% entre 1% y 3%? ¿Cuántos necesitaría para estimar la prevalencia de colonización por pseudomona de 2% con un intervalo de confianza de 95% que fuera entre 0% y 10%? ¿Y si tuviera 200 pacientes EPOC identificados y me planteara estudiar la misma pregunta con un estudio retrospectivo utilizando todos los pacientes disponibles?

¿Qué necesito para realizar una estimación de tamaño muestral para precisión?

Para realizar una estimación de tamaño muestral para una pregunta descriptiva necesito los siguientes componentes:

- Conocer con claridad la pregunta de investigación
- Aproximar el parámetro poblacional a estimar
- Medida de variabilidad del parámetro poblacional a estimar
- Nivel de confianza
- Magnitud de la hemiamplitud del intervalo de confianza que tendría sentido estimar

Si el parámetro que me interesa estimar es una prevalencia por ejemplo, debo tener una idea de si se trata de una prevalencia de 1/10000, 1/1000, 1/100 o 10/100 o 50/100. Para las proporciones, el desvío estándar de una proporción depende de la proporción. El desvío estándar de las proporciones es mínimo cerca de 0 y 1 y máximo cerca de 0,5. Para conocer aproximadamente donde está la proporción que deseo estimar, debo recurrir a la literatura. Leer sobre el tema y conocer aproximadamente qué proporción tendría sentido. Probablemente tenga que basarme en situaciones similares, ya que si la pregunta es original, no espero encontrar esta prevalencia en la literatura.

Si me interesara estimar una media, de la misma manera debo saber aproximadamente la posición del parámetro: ¿Es 10? ¿100? ¿10000? La medida de variabilidad más utilizada en la estimación de tamaños muestral es el desvío estándar. Para realizar el cálculo debo conocer el desvío estándar. Para esto es necesario buscarlo en la literatura en las situaciones más similares a mi estudio, la misma medición y la misma población. Si es desconocida es bueno buscar situaciones similares.

El nivel de confianza usual es 95%. Se interpreta como que en 5 de cada 100 veces que estimamos este parámetro con una muestra aleatoria de la misma población blanco y del mismo tamaño, el intervalo de confianza no contendría al verdadero parámetro poblacional. Se considera 5% aceptable por convención, sin embargo en ocasiones se puede considerar otro nivel de confianza como 90% o 99%.

Por último, ¿Qué hemiamplitud del intervalo de confianza tiene sentido? Si se tratara de una proporción ¿Más / menos 1%? o ¿Más / menos 5%? o ¿Más / menos 10%? Esta decisión equivale a la magnitud del efecto en el sentido que es una decisión clínica y no estadística. ¿Cuál es una hemiamplitud apropiada para responder mi pregunta?

¿Cómo se modifica el tamaño muestral por precisión?

La modificación de cada uno de estos valores modifica el tamaño muestral requerido. Debido a que este cálculo se realiza *a priori*, es fundamental que la

información que utilice sea lo más parecida posible a la real. Esto asegura una estimación de tamaño muestral exitosa.

Para estimación de medias, a mayor desvío estándar necesito mayor cantidad de individuos. Para la estimación de proporciones, debido a que el desvío estándar se calcula con la proporción y es máximo cerca de 0,5: requiero mayor número a medida que me alejo de 0 hasta 0,5. Como las proporciones son simétricas, ocurre lo mismo si me acerco desde 1 al 0,5. A mayor nivel de confianza requiero mayor tamaño muestral. A menor hemiamplitud requiero tamaño muestral más grande.

¿Cómo se hace una estimación de tamaño muestral por precisión?

Para realizar una estimación de tamaño muestral por precisión, asegúrese de tener todos los elementos que necesita. Invierta tiempo revisando la literatura y obteniendo toda la información necesaria para el cálculo.

Algunos software con licencia que permiten hacer este tipo de cálculos son Power and Precision^[88] y STATA.^[89] Para este cálculo sencillo no se necesita de softwares ya que se puede utilizar la siguiente fórmula o utilizar calculadores online para proporciones^[90] o medias.^[91]

Es una buena idea tomar varias estimaciones de tamaño muestral en situaciones similares para tener una idea del efecto de las diferentes decisiones en el tamaño muestral requerido. ¡Es muy importante seleccionar el escenario más real!

Figura 26. Para la estimación de tamaño muestral para estimar una proporción se puede utilizar la siguiente fórmula. Donde n es el tamaño de la muestra, $Z_{\alpha/2}$ es el valor de Z correspondiente al nivel de confianza (habitualmente 95%). p es la proporción esperada y d es la hemiamplitud del intervalo de confianza definido como de relevancia clínica.

$$n = \frac{Z_{\alpha/2}^2 * p(1-p)}{d^2}$$

García-García JA, Reding-Bernal A, López-Alvarenga JC. Cálculo del tamaño de la muestra en investigación en educación médica. *Investigación en Educación Médica*. 2013;2: 217–224.

¿Tamaño muestral en las preguntas analíticas?

En las preguntas analíticas interesa testear una hipótesis utilizando un test de hipótesis. Por ende en estos casos interesa tener poder suficiente para testear una hipótesis nula específica. Con las mismas fórmulas, según la situación específica se puede requerir estimar el tamaño muestral, el poder o la mínima diferencia detectable.

Si el diseño es prospectivo o si se planea contestar la pregunta con datos retrospectivos pero existe algún costo por unidad incluida (ética, dinero, esfuerzo o

tiempo), es necesario estimar el tamaño muestral requerido. ¿Cuántos pacientes necesitó para evaluar el efecto de un nuevo fármaco biológico sobre la mortalidad de los pacientes con estadio 3 - 4 de cáncer de pulmón?

En ocasiones se intenta responder la pregunta con un estudio retrospectivo y el tamaño muestral es fijo. En este caso podría no tener sentido estimar el tamaño muestral, ya que es fijo o al menos tiene un máximo. Si ya realicé el estudio y tengo los resultados, puedo haber detectado una diferencia estadísticamente significativa o no. Si detectamos una diferencia estadísticamente significativa, puede ser que la magnitud del efecto es de un tamaño suficiente que soy capaz de detectarla con el tamaño muestral fijo alcanzado. Pero si no detecté una diferencia estadísticamente significativa, ¿Podría ser que mi estudio no tenía poder suficiente para detectar una diferencia de la magnitud de la diferencia observada? En esta situación, tiene sentido realizar un cálculo de poder.

Los ensayos clínicos clásicos frecuentemente tienen poco poder para detectar diferencias en eventos adversos. En este estudio retrospectivo se evaluó el efecto de un tipo de catéter para drenaje ventricular externo a través de un análisis retrospectivo *Efficacy of silver-bearing external ventricular drainage catheters: a retrospective analysis*.^[92] Para el objetivo de eficacia, se pretendía evaluar la asociación entre la tasa de infecciones en los pacientes con catéter impregnado de plata versus catéteres convencionales. Para el tamaño muestral retrospectivo fijo alcanzado y la magnitud del efecto observada, el estudio no tuvo poder suficiente para detectar una asociación de la magnitud observada.

En otras ocasiones el estudio es prospectivo, pero la cantidad de pacientes disponibles es fija y limitada. También puede ocurrir que disponga de presupuesto para incluir un tamaño muestral fijo. Es más frecuente realizar el presupuesto en función del tamaño muestral, pero puede darse situaciones donde es al revés. En algunos de estos casos, puede ser de utilidad estimar la mínima diferencia que sería capaz de detectar un estudio con ese tamaño muestral. Esto permite tomar decisiones. Si la mínima diferencia que seríamos capaces de detectar con el tamaño muestral fijo es tan grande que no hay razones biológicas para pensar que se parece a la real, puede no tener sentido hacer el estudio. Por ejemplo, si quisiera estudiar una patología de baja prevalencia como el síndrome de telangiectasia hemorrágica hereditaria y en mi centro cuento con 350 pacientes como tamaño muestral fijo.

¿Qué necesito para realizar una estimación de tamaño muestral para poder?

Existen muchas situaciones diferentes con diverso grado de complejidad. A los fines de este apartado vamos a considerar la situación más simple. Para realizar una estimación de tamaño muestral para una pregunta analítica necesito los siguientes componentes:

- Conocer con claridad la pregunta de investigación/hipótesis de mi estudio
- Aproximar el parámetro poblacional a estimar de cada una de las poblaciones

- Medida de variabilidad del parámetro poblacional a estimar de cada una de las poblaciones
- Magnitud del efecto
- Nivel de error alfa aceptable
- Nivel de error beta aceptable
- ¿1 o 2 colas?

Imaginemos que mi pregunta fuera ¿Existe asociación entre recibir un tratamiento A o B y la disminución de la presión arterial bajo ambos tipos de tratamientos en pacientes hipertensos? En este caso la hipótesis nula es que la media de la disminución de la presión arterial en los tratados con la droga A es igual a la media de disminución de presión arterial en los tratados con la droga B. En este caso tendré que tener una idea aproximada de ambas medias y del desvío estándar de esas medias.

La magnitud del efecto representa siempre la relevancia clínica. En este primer caso la magnitud del efecto corresponde a que tan separadas están esas medias. Es decir si la media de la disminución de la presión arterial bajo el tratamiento A es 10 mmHg, ¿Cuánto mayor deberá ser la disminución con la droga B para que considere que esa diferencia es clínicamente relevante? Para definir una diferencia entre medias clínicamente relevante se necesita evaluar la literatura y conocer cómo se comportan tratamientos similares. Para la magnitud del efecto clínica es fundamental la mirada y experiencia de los investigadores vinculados con el ámbito del problema, que ven pacientes y se encuentran familiarizados con los efectos de diferentes tratamientos alternativos. La magnitud del efecto considerada en la estimación de tamaño muestral se debe definir por la relevancia clínica.

Ver anteriormente definiciones de errores alfa y beta en ¿Qué es el error Alfa y Beta? La comunidad biomédica le pone un límite por convención al error alfa aceptable en 5%. Es decir, es aceptable definir un tamaño muestral tal que en 5 de cada 100 veces que obtengamos un resultado estadísticamente significativo, se tratará de un falso positivo. A su vez, se tolera mucho más error beta por convención: 20%. Es decir, con el tamaño muestral propuesto 2 de cada 10 veces que obtengamos un resultado estadísticamente no significativo, se tratara de falsos negativos. El poder representa la inversa del error beta (80% en este caso), es la probabilidad o capacidad de ver una diferencia que existe.

La cantidad de colas depende de si se trata de una hipótesis a una cola o a dos colas (ver anteriormente ¿Cuántas colas puede tener un test de hipótesis?). Dependerá de la cantidad de información previa con la que cuente el investigador con respecto a ambos grupos del estudio.

Imaginemos ahora que mi pregunta es: ¿Es la proporción de efectos adversos diferente en los pacientes tratados con la droga A versus los tratados con la droga B? Mi hipótesis nula es que la proporción de efectos adversos en los pacientes tratados con la droga A es igual a la proporción de efectos adversos en

los pacientes tratados con la droga B. ¿Cómo expresaría esta misma hipótesis utilizando riesgos relativos? ¿Y diferencia de riesgos? ¿Y odds ratios? En este caso la magnitud del efecto implica definir ¿Cuánto más grande debiera ser la proporción en un grupo con respecto al otro para que yo considerara que la magnitud es clínicamente relevante?

¿Cómo se modifica el tamaño muestral para testear hipótesis?

La modificación de cada uno de estos valores modifica el tamaño muestral requerido al igual que en la preguntas descriptivas. Debido a que este cálculo se realiza *a priori*, es fundamental que la información que utilice sea lo más parecida posible a la real. Esto asegura una estimación de tamaño muestral exitosa. A mayor variabilidad, se requerirán tamaños muestrales más grandes. A menor magnitud del efecto, se requieren tamaños muestrales más grandes. A menor error alfa o menor error beta, se requieren tamaños muestrales mayores. Por último, los test a dos colas requieren tamaños muestrales mayores que los tests a una cola.

¿Cómo se hace una estimación de tamaño muestral para testear una hipótesis?

Para realizar una estimación de tamaño muestral para testear una hipótesis, asegúrese de tener todos los elementos que necesita. Invierta tiempo revisando la literatura y obteniendo toda la información necesaria para el cálculo. Los software que pueden utilizarse para la estimación son los mismos que para las preguntas descriptivas. Para comparar proporciones o medias puede usar calculadores gratuitos online como Epi Infotm del CDC.^[93] Adicionalmente puede utilizar las siguientes fórmulas.

Es una buena idea tomar varias estimaciones de tamaño muestral en situaciones similares para tener una idea del efecto de las diferentes decisiones en el tamaño muestral requerido. Se puede variar la magnitud del efecto o utilizar diferentes desvíos estándar obtenidos de diferentes estudios publicados ¡Es muy importante seleccionar el escenario más real!

Figura 27. Para estimar el tamaño muestral para una hipótesis nula de igualdad entre dos proporciones, para 2 muestras independientes, se puede utilizar la fórmula A. * Donde $2n$ es el tamaño muestral total, siendo n el tamaño muestral por cada grupo. Z_α es el valor de Z correspondiente al error alfa y Z_β es el valor de Z correspondiente al error beta. p_c y p_i a las proporciones de ocurrencia del evento en ambos grupos, mientras que $p = (p_c - p_i)/2$.

Fórmula A

$$2n = 2\{Z_\alpha\sqrt{2\bar{p}(1-\bar{p})} + Z_\beta\sqrt{p_c(1-p_c) + p_i(1-p_i)}\}^2 / (p_c - p_i)^2$$

Para estimar el tamaño muestral para una hipótesis nula de igualdad entre dos medias, para 2 muestras independientes, con varianza común, se puede utilizar la fórmula B. Donde $2n$ es el tamaño muestral total, siendo n el tamaño muestral por cada grupo. Z_α es el valor de Z correspondiente al error alfa y Z_β es el valor de Z correspondiente al error beta. σ^2 corresponde a la varianza común de las medias μ_c y μ_r , es la diferencia clínicamente significativa entre μ_c y μ_1 (μ_c y μ_1 media poblacional en ambos grupos de comparación).*

Fórmula B

$$2n = \frac{4(Z_\alpha + Z_\beta)^2 \sigma^2}{\delta^2}$$

** Friedman LM, Furberg CD, DeMets DL. Fundamentals of Clinical Trials. Fourth edition. Springer; 2010.*

¿Qué pasa si tengo más de una pregunta de investigación?

En muchas ocasiones un estudio puede tener preguntas principales y secundarias. Es necesario hacer la estimación de tamaño para cada una de las preguntas y objetivos del estudio. Posteriormente se selecciona el mayor tamaño muestral requerido para contestar todas las preguntas del estudio.

Es fundamental seleccionar cuidadosamente las preguntas y jerarquizarlas. De esta manera podemos asegurarnos que el estudio tenga un tamaño muestral suficiente para al menos responder las preguntas más importantes o que más nos interesan.

¿Qué hago si me faltan datos para la estimación del tamaño muestral?

Es máximamente importante hacer todos los esfuerzos posibles para obtener la información requerida antes de empezar. Sin embargo, es común que falte información previa para la realización de una estimación de tamaño muestral apropiada. Mientras más original es la pregunta, más información puede faltar al respecto. Es común la ausencia del desvío estándar o de los estimadores. En ocasiones por publicaciones incompletas previas. Una opción válida es la solicitud de información por email a los autores. Es muy frecuente lograr colaboración con un mail claro y educado.

En ocasiones es útil mirar resultados de situaciones similares. Si bien no es lo mismo, en ocasiones es razonable que estudios similares sobre una misma variable de resultado encontraron desvíos estándar similar y puede ser razonable utilizar el mismo.

Si carezco de información totalmente, probablemente la mejor idea sea plantear un estudio piloto. Se puede realizar la estimación del tamaño muestral con la

información disponible y plantear recalculando con datos reales incluidos un pequeño número de pacientes.

¿Qué hago si requiero un tamaño muestral muy grande?

Si la estimación de tamaño muestral es muy grande, puede ser un impedimento para la realización del estudio ya que es uno de los componentes principales de la factibilidad. Existen diferentes estrategias que pueden ser útiles en esta situación, como por ejemplo ampliar o cambiar la población, seleccionar medidas de resultado diferentes que contengan mayor cantidad de información (como las medidas continuas) o realizar un estudio multicéntrico.



Referencias

1. Hulley MD DS, Cummings SR, Browner WS, Grady MD D, Newman TB. *Designing Clinical Research*. Fourth edition. Lippincott Williams & Wilkins; 2013.
2. OHCHR | Universal Declaration of Human Rights Main [Internet]. [cited 29 Oct 2017]. Available: <http://www.ohchr.org/EN/UDHR/Pages/UDHRIndex.aspx>
3. WMA - The World Medical Association-Declaración de Helsinki de la AMM – Principios éticos para las investigaciones médicas en seres humanos [Internet]. [cited 29 Oct 2017]. Available: <https://www.wma.net/es/polices-post/declaracion-de-helsinki-de-la-amm-principios-eticos-para-las-investigaciones-medicas-en-seres-humanos/>
4. ICH Official web site : ICH [Internet]. [cited 29 Oct 2017]. Available: <http://www.ich.org/home.html>
5. Reynolds T. Eliminating publication bias: the effect of negative trial results. *J Natl Cancer Inst*. 2000;92: 682.
6. Song F, Parekh S, Hooper L, Loke YK, Ryder J, Sutton AJ, et al. Dissemination and publication of research findings: an updated review of related biases. *Health Technol Assess*. 2010;14: iii, ix–xi, 1–193.
7. Bradford Hill criteria - Wikipedia [Internet]. [cited 13 Dec 2017]. Available: https://en.wikipedia.org/wiki/Bradford_Hill_criteria
8. Hill AB. THE ENVIRONMENT AND DISEASE: ASSOCIATION OR CAUSATION? *Proc R Soc Med*. 1965;58: 295–300.
9. Akobeng AK. Principles of evidence based medicine. *Arch Dis Child*. 2005;90: 837–840.
10. Santos CM da C, Pimenta CA de M, Nobre MRC. The PICO strategy for the research question construction and evidence search. *Rev Latino-Am Enfermagem*. Escola de Enfermagem de Ribeirão Preto / Universidade de São Paulo; 2007;15: 508–511.
11. Población - Wikipedia, la enciclopedia libre [Internet]. [cited 18 Dec 2017]. Available: <https://es.wikipedia.org/wiki/Poblaci%C3%B3n>
12. Elsevier. *Epidemiology - 5th Edition* [Internet]. [cited 18 Dec 2017]. Available: <https://www.elsevier.com/books/epidemiology/gor-dis/978-1-4557-3733-8>
13. CONSORT 2010 - Flow Diagram [Internet]. [cited 18 Dec 2017]. Available: <http://www.equator-network.org/wp-content/uploads/2013/09/CONSORT-2010-Flow-Diagram-MS-Word.doc>
14. CONSORT 2010 Statement: updated guidelines for reporting parallel group randomised trials | The EQUATOR Network [Internet]. [cited 18 Dec 2017]. Available: <http://www.equator-network.org/reporting-guidelines/consort/>
15. NHANES - National Health and Nutrition Examination Survey Homepage [Internet]. 24 Oct 2017 [cited 30 Oct 2017]. Available: <https://www.cdc.gov/nchs/nhanes/index.htm>
16. Delgado-Rodríguez M, Llorca J. Bias. *J Epidemiol Community Health*. 2004;58: 635–641.
17. Desbiolles A E al. Cancer incidence in adults living in the vicinity of nuclear power plants in France, based on data from the French Network of Cancer Registries. - *PubMed - NCBI* [Internet]. [cited 30 Oct 2017]. Available: <https://www.ncbi.nlm.nih.gov/pubmed/29055029>
18. Kılıç S, Unsal AA, Chung SY, Samarrai R, Kılıç SS, Baredes S, et al. Geographic region: Does it matter in cutaneous melanoma of the head and neck? *Laryngoscope*. 2017;127: 2763–2769.
19. Jung HJ E al. Quality of Life in Patients with Osteoporotic Vertebral Compression Fractures. - *PubMed - NCBI* [Internet]. [cited 30 Oct 2017]. Available: <https://www.ncbi.nlm.nih.gov/pubmed/28955695>
20. McDonald HI, Thomas SL, Millett ERC, Quint J, Nitsch D. Do influenza and pneumococcal vaccines prevent community-acquired respiratory infections among older people with diabetes and does this vary by chronic kidney disease? A cohort study using electronic health records. *BMJ Open Diabetes Research and Care*. *BMJ Specialist Journals*; 2017;5: e000332.
21. Masica AL E al. Comparative effectiveness research using electronic health records:

- impacts of oral antidiabetic drugs on the development of chronic kidney disease. - PubMed - NCBI [Internet]. [cited 30 Oct 2017]. Available: <https://www.ncbi.nlm.nih.gov/pubmed/23436488>
22. Llupià A, Mena G, Olivé V, Quesada S, Aldea M, Sequera VG, et al. Evaluating influenza vaccination campaigns beyond coverage: a before-after study among health care workers. *Am J Infect Control*. 2013;41: 674–678.
 23. Efecto Hawthorne - Wikipedia, la enciclopedia libre [Internet]. [cited 19 Nov 2017]. Available: https://es.wikipedia.org/wiki/Efecto_Hawthorne
 24. Ribeiro EHC, Garcia LMT, Salvador EP, Costa EF, Andrade DR, Latorre M do RD de O, et al. Assessment of the effectiveness of physical activity interventions in the Brazilian Unified Health System. *Rev Saude Publica*. 2017;51: 56.
 25. Pandya N, DiGenio A, Gao L, Patel M. Efficacy and safety of insulin glargine compared to other interventions in younger and older adults: a pooled analysis of nine open-label, randomized controlled trials in patients with type 2 diabetes. *Drugs Aging*. 2013;30: 429–438.
 26. Clinical equipoise - Wikipedia [Internet]. [cited 27 Jan 2018]. Available: https://en.wikipedia.org/wiki/Clinical_equipoise
 27. Hernán M, Robins J. Causal Inference. Boca Raton: Chapman & Hall/CRC, Forthcoming; 2018.
 28. Ostergaard L, Vesikari T, Absalon J, Beeslaar J, Ward BJ, Senders S, et al. A Bivalent Meningococcal B Vaccine in Adolescents and Young Adults. *N Engl J Med*. 2017;377: 2349–2362.
 29. Robin P, Le Roux P-Y, Planquette B, Accassat S, Roy P-M, Couturaud F, et al. Limited screening with versus without 18 F-fluorodeoxyglucose PET/CT for occult malignancy in unprovoked venous thromboembolism: an open-label randomised controlled trial. *Lancet Oncol*. 2016;17: 193–199.
 30. Madhi SA, Nachman S, Violari A, Kim S, Cotton MF, Bobat R, et al. Primary isoniazid prophylaxis against tuberculosis in HIV-exposed children. *N Engl J Med*. 2011;365: 21–31.
 31. Semrau KEA, Hirschhorn LR, Marx Delaney M, Singh VP, Saurastri R, Sharma N, et al. Outcomes of a Coaching-Based WHO Safe Childbirth Checklist Program in India. *N Engl J Med*. 2017;377: 2313–2324.
 32. Chiu S, Bergeron N, Williams PT, Bray GA, Sutherland B, Krauss RM. Comparison of the DASH (Dietary Approaches to Stop Hypertension) diet and a higher-fat DASH diet on blood pressure and lipids and lipoproteins: a randomized controlled trial. *Am J Clin Nutr*. 2016;103: 341–347.
 33. Brekke HK, Bertz F, Rasmussen KM, Bosaeus I, Ellegård L, Winkvist A. Diet and exercise interventions among overweight and obese lactating women: randomized trial of effects on cardiovascular risk factors. *PLoS One*. 2014;9: e88250.
 34. Matsui Y, Satoi S, Kaibori M, Toyokawa H, Yanagimoto H, Matsui K, et al. Antibiotic prophylaxis in laparoscopic cholecystectomy: a randomized controlled trial. *PLoS One*. 2014;9: e106702.
 35. Loudon K, Treweek S, Sullivan F, Donnan P, Thorpe KE, Zwarenstein M. The PRECIS-2 tool: designing trials that are fit for purpose. *BMJ*. 2015;350: h2147.
 36. Paulin P, Maritano Furcada J, Ungaro CM, Bendelman G, Waisman GD, Castro HM, et al. Effect of angiotensin 2 receptor blockers on chronic obstructive lung disease mortality: A retrospective cohort study. *Pulm Pharmacol Ther*. 2017;44: 78–82.
 37. Mahmood SS, Levy D, Vasan RS, Wang TJ. The Framingham Heart Study and the epidemiology of cardiovascular disease: a historical perspective. *Lancet*. 2014;383: 999–1008.
 38. Kootte RS, Stuijver DJF, Dekkers OM, van Zaane B, Fliers E, Cannegieter SC, et al. The incidence of venous thromboembolism in patients with overt hyperthyroidism: a retrospective multicentre cohort study. *Thromb Haemost*. 2012;107: 417–422.
 39. Anderson E, Leahy O, Cheng AC, Grummet J. Risk factors for infection following prostate biopsy - a case control study. *BMC Infect Dis*. 2015;15: 580.

40. Vinceti M, Crespi CM, Malagoli C, Bottechi I, Ferrari A, Sieri S, et al. A case-control study of the risk of cutaneous melanoma associated with three selenium exposure indicators. *Tumori*. 2012;98: 287–295.
41. Gu B, Qian L, Yu H, Hu J, Wang Q, Shan J, et al. Concurrent Chemoradiotherapy in Curatively Resected Gallbladder Carcinoma: A Propensity Score-Matched Analysis. *Int J Radiat Oncol Biol Phys*. 2018;100: 138–145.
42. Wang J, Sereika SM, Styn MA, Burke LE. Factors associated with health-related quality of life among overweight or obese adults. *J Clin Nurs*. 2013;22: 2172–2182.
43. Bulka CM, Jones RM, Turyk ME, Stayner LT, Argos M. Arsenic in drinking water and prostate cancer in Illinois counties: An ecologic study. *Environ Res*. 2016;148: 450–456.
44. Ecological fallacy - Wikipedia [Internet]. [cited 28 Jan 2018]. Available: https://en.wikipedia.org/wiki/Ecological_fallacy
45. Uhlig U, Kostev K, Schuster V, Koletzko S, Uhlig HH. Impact of rotavirus vaccination in Germany: rotavirus surveillance, hospitalization, side effects and comparison of vaccines. *Pediatr Infect Dis J*. 2014;33: e299–304.
46. Herd immunity - Wikipedia [Internet]. [cited 28 Jan 2018]. Available: https://en.wikipedia.org/wiki/Herd_immunity
47. Beck AT, Ward CH, Mendelson M, Mock J, Erbaugh J. An inventory for measuring depression. *Arch Gen Psychiatry*. 1961;4: 561–571.
48. Hamilton M. A rating scale for depression. *J Neurol Neurosurg Psychiatry*. 1960;23: 56–62.
49. Montgomery SA, Asberg M. A new depression scale designed to be sensitive to change. *Br J Psychiatry*. 1979;134: 382–389.
50. Pangman VC, Sloan J, Guse L. An examination of psychometric properties of the mini-mental state examination and the standardized mini-mental state examination: implications for clinical practice. *Appl Nurs Res*. 2000;13: 209–213.
51. Socioeconomic status - Wikipedia [Internet]. [cited 9 Nov 2017]. Available: https://en.wikipedia.org/wiki/Socioeconomic_status
52. El nivel socioeconómico en la Argentina, 2015. Estratificación y variables. In: Observatorio Social [Internet]. [cited 9 Nov 2017]. Available: <http://www.saimo.org.ar/archivos/observatorio-social/El-NSE-en-la-Argentina-2015-Estratificacion-y-Variables.pdf>
53. Teasdale G, Jennett B. Assessment of coma and impaired consciousness. A practical scale. *Lancet*. 1974;2: 81–84.
54. Central limit theorem - Wikipedia [Internet]. [cited 28 Jan 2018]. Available: https://en.wikipedia.org/wiki/Central_limit_theorem
55. Joshi M, Joshi A, Bartter T. Marijuana and lung diseases. *Curr Opin Pulm Med*. 2014;20: 173–179.
56. Johnston N, Bodegard J, Jerström S, Åkesson J, Brorsson H, Alfredsson J, et al. Effects of interactive patient smartphone support app on drug adherence and lifestyle changes in myocardial infarction patients: A randomized study. *Am Heart J*. 2016;178: 85–94.
57. 36-Item Short Form Survey from the RAND Medical Outcomes Study [Internet]. [cited 1 Nov 2017]. Available: https://www.rand.org/health/surveys_tools/mos/36-item-short-form.html
58. Bulpitt CJ, Fletcher AE, Amery A, Coope J, Evans JG, Lightowlers S, et al. The Hypertension in the Very Elderly Trial (HYVET). *J Hum Hypertens*. 1994;8: 631–632.
59. Bulpitt C, Fletcher A, Beckett N, Coope J, Gil-Extremera B, Forette F, et al. Hypertension in the Very Elderly Trial (HYVET): protocol for the main trial. *Drugs Aging*. 2001;18: 151–164.
60. Coburn KM, Vevea JL. Publication bias as a function of study characteristics. *Psychol Methods*. 2015;20: 310–330.
61. Kicinski M, Springate DA, Kontopantelis E. Publication bias in meta-analyses from the Cochrane Database of Systematic Reviews. *Stat Med*. 2015;34: 2781–2793.
62. Danaei G, Rodríguez LAG, Cantero OF, Logan R, Hernán MA. Observational data for comparative effectiveness research: an emulation of randomised trials of statins and primary prevention of coronary heart disease. *Stat Methods Med Res*. 2013;22: 70–96.

63. Sampling Distributions [Internet]. [cited 1 May 2017]. Available: http://onlinestatbook.com/stat_sim/sampling_dist/
64. Distribución normal - Wikipedia, la enciclopedia libre [Internet]. [cited 1 May 2017]. Available: https://es.wikipedia.org/wiki/Distribuci%C3%B3n_normal
65. Robert Koch - Wikipedia, la enciclopedia libre [Internet]. [cited 7 Nov 2017]. Available: https://es.wikipedia.org/wiki/Robert_Koch
66. Bradford Hill criteria - Wikipedia [Internet]. [cited 13 Dec 2017]. Available: https://en.wikipedia.org/wiki/Bradford_Hill_criteria
67. Contraste de hipótesis - Wikipedia, la enciclopedia libre [Internet]. [cited 1 May 2017]. Available: https://es.wikipedia.org/wiki/Contraste_de_hip%C3%B3tesis
68. Charlson ME, Pompei P, Ales KL, MacKenzie CR. A new method of classifying prognostic comorbidity in longitudinal studies: development and validation. *J Chronic Dis*. 1987;40: 373–383.
69. Giunta D, Briatore A, Baum A, Luna D, Waisman G, de Quiros FGB. Factors associated with nonattendance at clinical medicine scheduled outpatient appointments in a university general hospital. *Patient Prefer Adherence*. 2013;7: 1163–1170.
70. Couttenier A, Lacroix O, Vaes E, Cardwell CR, De Schutter H, Robert A. Statin use is associated with improved survival in ovarian cancer: A retrospective population-based study. *PLoS One*. 2017;12: e0189233.
71. Bootstrapping (estadística) - Wikipedia, la enciclopedia libre [Internet]. [cited 30 Jan 2018]. Available: [https://es.wikipedia.org/wiki/Bootstrapping_\(estad%C3%ADstica\)](https://es.wikipedia.org/wiki/Bootstrapping_(estad%C3%ADstica))
72. Levine AC, Shetty PP, Burbach R, Cheemalapati S, Glavis-Bloom J, Wiskel T, et al. Derivation and Internal Validation of the Ebola Prediction Score for Risk Stratification of Patients With Suspected Ebola Virus Disease. *Ann Emerg Med*. 2015;66: 285–293.e1.
73. Collins GS, de Groot JA, Dutton S, Omar O, Shanyinde M, Tajar A, et al. External validation of multivariable prediction models: a systematic review of methodological conduct and reporting. *BMC Med Res Methodol*. 2014;14: 40.
74. Chan YH. Biostatistics 306. Log-linear models: poisson regression. *Singapore Med J*. 2005;46: 377–85; quiz 386.
75. Bellocco R, Pagano M. Poisson regression. *Nutrition*. 1998;14: 63–64.
76. Khazaei S, Poorolajal J, Mahjub H, Esmaeilnasab N, Mirzaei M. Estimation of the Frequency of Intravenous Drug Users in Hamadan City, Iran, Using the Capture-recapture Method. *Epidemiol Health*. 2012;34: e2012006.
77. Cristiano E, Patrucco L, Miguez J, Giunta D, Correale J, Fiol M, et al. Increasing prevalence of multiple sclerosis in Buenos Aires, Argentina. *Mult Scler Relat Disord*. 2016;9: 91–94.
78. Vittinghoff E, Glidden DV, Shiboski SC, McCulloch CE. *Regression Methods in Biostatistics: Linear, Logistic, Survival, and Repeated Measures Models*. Springer Science & Business Media; 2012.
79. Kamath PS, Wiesner RH, Malinchoc M, Kremers W, Therneau TM, Kosberg CL, et al. A model to predict survival in patients with end-stage liver disease. *Hepatology*. 2001;33: 464–470.
80. Criterio de información de Akaike - Wikipedia, la enciclopedia libre [Internet]. [cited 19 Nov 2017]. Available: https://es.wikipedia.org/wiki/Criterio_de_informaci%C3%B3n_de_Akaike
81. Porta M. A dictionary of epidemiology. *Revista Española de Salud Pública*. 2008;82. doi:10.1590/s1135-57272008000400008
82. Andr? Knottnerus J, Buntinx F. *The Evidence Base of Clinical Diagnosis: Theory and Methods of Diagnostic Research*. John Wiley & Sons; 2011.
83. Anderson DR, Kahn SR, Rodger MA, Kovacs MJ, Morris T, Hirsch A, et al. Computed tomographic pulmonary angiography vs ventilation-perfusion lung scanning in patients with suspected pulmonary embolism: a randomized controlled trial. *JAMA*. 2007;298: 2743–2753.
84. Unlü C, Beenen LFM, Fauquenot JMB, Jensch S, Bemelman WA, Dijkgraaf MGW, et al. Inter-observer reliability of computed tomographic classifications of diverticulitis. *Colorectal Dis*. 2014;16: O212–9.

85. Vilagut G, Ferrer M, Rajmil L, Rebollo P, Permanyer-Miralda G, Quintana JM, et al. [The Spanish version of the Short Form 36 Health Survey: a decade of experience and new developments]. *Gac Sanit*. 2005;19: 135–150.
86. Spitzer RL. Psychiatric diagnosis: are clinicians still necessary? *Compr Psychiatry*. 1983;24: 399–411.
87. Kang L-N, Jeronimo J, Qiao Y-L, Zhao F-H, Chen W, Valdez M, et al. Optimal positive cutoff points for careHPV testing of clinician- and self-collected specimens in primary cervical cancer screening: an analysis from rural China. *J Clin Microbiol*. 2014;52: 1954–1961.
88. Power Analysis Sample Size Calculation Statistical Software [Internet]. [cited 5 Nov 2017]. Available: <http://www.power-analysis.com/>
89. Data Analysis and Statistical Software | Stata [Internet]. [cited 5 Nov 2017]. Available: <https://www.stata.com/>
90. Confidence interval for a proportion - Sample Size Calculators. In: Sample Size Calculators [Internet]. 13 May 2014 [cited 5 Nov 2017]. Available: <http://www.sample-size.net/confidence-interval-proportion/>
91. Sample size - Conf interval for a mean - Sample Size Calculators. In: Sample Size Calculators [Internet]. 21 Mar 2014 [cited 5 Nov 2017]. Available: <http://www.sample-size.net/sample-size-conf-interval-mean/>
92. Fichtner J, Güresir E, Seifert V, Raabe A. Efficacy of silver-bearing external ventricular drainage catheters: a retrospective analysis. *J Neurosurg*. 2010;112: 840–846.
93. Epi Info™ | CDC [Internet]. 1 Nov 2017 [cited 5 Nov 2017]. Available: <https://www.cdc.gov/epiinfo/index.html>

Material preparado por **Diego H. Giunta** para Merck S.A. como soporte informativo de las disertaciones brindadas dentro del programa Merck Investiga. El contenido y cualquier opinión o recomendación que pudiera estar vertida en este material es de exclusiva responsabilidad del autor y no reflejan necesariamente las recomendaciones ni opiniones de Merck S.A.

Material desarrollado para entrega y uso exclusivo de los asistentes a las disertaciones brindadas dentro del programa Merck Investiga. Cualquier otro uso del mismo no se encuentra autorizado por Merck S.A.

Todos los derechos reservados

Merck S.A.

Tronador 4890 - 4to. piso
(C1430DNN) Ciudad de Buenos Aires - Argentina

