

BIOESTADÍSTICA

Base para el análisis de
las ciencias de la salud

4a
Edición

Daniel

 LIMUSA WILEY®

BIOESTADÍSTICA

Base para el análisis
de las ciencias de la salud

bioestadística

Base para el análisis de las ciencias de la salud.

Wayne W. Daniel,

Georgia State University



ESPAÑA • VENEZUELA • ARGENTINA
MÉXICO • COLOMBIA • PUERTO RICO

115401

Versión autorizada en español
de la obra publicada en inglés por
John Wiley & Sons con el título
**BIOSTATISTICS: A FOUNDATION FOR
ANALYSIS IN THE HEALTH SCIENCES 3th ed.**
© John Wiley & Sons, Inc.
ISBN 0-471-09753-5

Versión española:

MANUEL GUZMAN ORTIZ

Revisión:

ANA LIA BABINSKY EPSTEIN
Licenciada en Matemáticas de la
Universidad de Buenos Aires.

La presentación y disposición en conjunto de

BIOESTADÍSTICA

*son propiedad del editor. Ninguna parte de esta obra
puede ser reproducida o transmitida, mediante ningún sistema
o método, electrónico o mecánico (INCLUYENDO EL FOTOCOPIADO,
la grabación o cualquier sistema de recuperación y almacenamiento
de información), sin consentimiento por escrito del editor.*

Derechos reservados:

© 1991, EDITORIAL LIMUSA, S.A. de C.V.
Balderas 95, Primer piso, 06040, México, D.F.
Teléfono 521-50-98
Fax 512-29-03
Télex 1762410 ELIME

Miembro de la Cámara Nacional de la Industria
Editorial Mexicana. Registro número 121

Primera edición: 1977

Primera reimpresión: 1979
Segunda reimpresión: 1980
Tercera reimpresión: 1982
Cuarta reimpresión: 1983
Quinta reimpresión: 1984
Sexta reimpresión: 1985

Tercera edición: 1987

Primera reimpresión: 1988
Segunda reimpresión: 1989
Tercera reimpresión: 1989
Cuarta reimpresión: 1990
Quinta reimpresión: 1990

Sexta reimpresión: 1991

Impreso en México
(9941)

ISBN 968-18-0178-4

116401

*A mi esposa
Mary
y a mis hijos
Jean,
Carolyn
y John*

Prólogo

Esta versión en español de la tercera edición en inglés de *Bioestadística: base para el análisis de las ciencias de la salud*, debe ser de interés para el mismo público para el cual fueron escritas las dos primeras ediciones: el estudiante universitario avanzado, el estudiante graduado principiante y el profesional en el área de salud, que requieren un libro de referencia sobre metodología estadística.

Esta edición supera a las anteriores en tres áreas importantes: 1) se han incluido temas adicionales; 2) se han ampliado, revisado y aclarado más algunos de los temas que aparecen en las dos primeras ediciones; y 3) se han incluido ejercicios adicionales para el estudiante.

Al igual que las ediciones anteriores, esta edición necesita pocos requisitos matemáticos. Sólo se requiere una destreza razonable en álgebra para comprender los conceptos y métodos que sirven de base para los cálculos. El énfasis continúa haciéndose en el entendimiento intuitivo de los principios, más que en el entendimiento basado en la sofisticación matemática.

Desde la publicación de la primera edición, la rápida aparición de calculadoras manuales económicas ha tenido un tremendo impacto sobre la enseñanza de la estadística, por lo que es raro el estudiante que no tenga una. Ahora, más que nunca, el profesor de estadística puede centrar su enseñanza en los conceptos y principios y dedicar menos tiempo de su clase a averiguar la causa de los errores de cómputo hechos por los estudiantes. Aminorando el tedio y el trabajo asociados al tiempo que se dedica a hacer cálculos manuales, los estudiantes

de hoy en día, tienen razón en ver su curso de estadística como una experiencia mucho más agradable que sus predecesores.

Esta edición hace un mayor énfasis en las aplicaciones de cómputo. Considero que las computadoras, al igual que las calculadoras manuales, son sólo una herramienta que se utiliza para facilitar el trabajo del estudiante y de quien se dedica a la estadística. Creo que un libro de texto como éste no debería limitarse exclusivamente a un lenguaje particular o a un conjunto de programas. Por lo tanto, mis observaciones respecto a las computadoras se han expresado en términos generales, lo cual permite que cada uno de los instructores de la materia tenga mayor flexibilidad para integrar el texto con las ventajas que ofrecen las computadoras. Muchos de los ejercicios abarcan datos “en bruto”, los cuales proporcionarán datos realistas para las aplicaciones de computadora.

El instructor que utilice la computadora puede abarcar un mayor número de temas durante un período académico que en los períodos anteriores. Sin embargo, los temas de esta edición deben ser suficientes para cubrir un curso de uno o dos períodos académicos.

Las siguientes mejoras específicas se han incorporado en esta tercera edición:

1. Se han añadido varios ejercicios nuevos. Al igual que los ejercicios y ejemplos originales, los que aquí se han incorporado se tomaron de una amplia gama de disciplinas de la salud y, aun cuando todos ellos sean hipotéticos, se han hecho tan interesantes y realistas como fue posible.
2. La mayoría de los ejercicios nuevos aparecen al final de los capítulos para servir de material de repaso cuando han concluido los capítulos. Como en las dos primeras ediciones, aparecen también ejercicios al término de las secciones dentro de los capítulos para servir de refuerzo inmediato a las técnicas y conceptos que se han enseñado.
3. Se han incorporado en el texto varios esquemas nuevos para facilitar la comprensión de algunos de los conceptos más problemáticos.
4. El capítulo sobre análisis de variancia con un solo criterio de clasificación por rangos se ha ampliado para incluir el caso de las muestras de distinto tamaño. El tema del método de Tukey para comparar pares de medias individuales se ha ampliado también para incluir el caso de muestras de distinto tamaño.

5. Se ha incorporado un estudio de la prueba de Mann-Whitney en el capítulo sobre estadística no paramétrica.
6. Las tablas del apéndice se han revisado a fin de que las distribuciones binomial, de Poisson, t , F , ji-cuadrada y normal den ahora la probabilidad de obtener un valor de la estadística de prueba tan pequeño o incluso más pequeño que el calculado. Esta característica debe facilitar el uso de las tablas por el estudiante.

Quisiera aprovechar esta oportunidad para expresar mi gratitud a los muchos lectores y usuarios de mi obra como libro de texto por sus valiosas sugerencias para esta tercera edición. En particular, quisiera dar las gracias a las siguientes personas, quienes hicieron sugerencias detalladas para esta revisión:

Bruce E. Trumbo
Universidad Estatal de California en Hayward
Hayward, California

Donald A. Pierce
Universidad Estatal de Oregón
Corvallis, Oregón

A. Larry Wright
Universidad de Arizona
Tucson, Arizona

Shirley Dowdy
Universidad de Virginia Occidental
Morgantown, Virginia Occidental

John McCloskey
Universidad de Dayton
Dayton, Ohio

Alan J. Gross
Universidad de Medicina de Carolina del Sur
Charleston, Carolina del Sur

Patrick L. Brockett
Universidad de Texas en Austin
Austin, Texas

David W. Hosmer
Universidad de Massachusetts
Amherst, Massachusetts

Quisiera agradecer también a mis siguientes colegas de la Universidad Estatal de Georgia su ayuda para la preparación de esta edición. Los profesores Geoffrey Churchill y Brian Schott escribieron los programas de cómputo para obtener algunas de las tablas del apéndice; el profesor Pickett Riggs hizo muchas sugerencias valiosas para mejorar la presente edición, y el profesor James Terrell verificó las soluciones a los ejercicios y ejemplos nuevos y revisados. En lo que respecta a cualquier deficiencia del libro, sin embargo, debo aceptar la total responsabilidad.

Finalmente, agradezco la ayuda de mi esposa Mary, sin cuyas habilidades como mecanógrafa, correctora de pruebas y crítica, este libro no se hubiera publicado. *C. N. M. M. G. S. !*

Wayne W. Daniel

Contenido

1. Organización y resumen de los datos	17
1.1 Introducción	17
1.2 Algunos conceptos básicos	17
1.3 El arreglo ordenado	20
1.4 Datos agrupados: la distribución de frecuencias	23
1.5 Medidas de tendencia central	34
1.6 Medidas de dispersión	40
1.7 Medidas de tendencia central calculadas a partir de datos agrupados	45
1.8 La variancia y la desviación estándar: datos agrupados	48
1.9 Las computadoras y el análisis bioestadístico	51
1.10 Resumen	53
<i>Preguntas y ejercicios de repaso</i>	53
<i>Referencias</i>	57
 2. Algunos conceptos básicos de probabilidad	 61
2.1 Introducción	61
2.2 Dos puntos de vista de la probabilidad: objetivo y subjetivo	62
2.3 Propiedades elementales de la probabilidad	64
2.4 Teoría de conjuntos y notación de conjuntos (nocións básicas)	65
2.5 Técnicas de conteo: permutaciones y combinacio- nes	71
2.6 Cálculo de la probabilidad de un evento	82
2.7 Resumen	91

	<i>Preguntas y ejercicios de repaso</i>	91
	<i>Referencias</i>	95
3.	Distribuciones de probabilidad	97
3.1	Introducción	97
3.2	Distribuciones de probabilidad de variables discretas	97
3.3	La distribución binomial	101
3.4	La distribución de Poisson	109
3.5	Distribuciones continuas de probabilidad	114
3.6	La distribución normal	117
3.7	Resumen	131
	<i>Preguntas y ejercicios de repaso</i>	131
	<i>Referencias</i>	134
4.	Algunas distribuciones muestrales importantes	137
4.1	Introducción	137
4.2	Muestreo aleatorio simple	137
4.3	Distribuciones muestrales	142
4.4	Distribución de la media de la muestra	143
4.5	Distribución de la diferencia entre las medias de dos muestras	154
4.6	Distribución de la proporción de la muestra	160
4.7	Distribución de la diferencia entre las proporciones de dos muestras	164
4.8	Resumen	167
	<i>Preguntas y ejercicios de repaso</i>	167
	<i>Referencias</i>	170
5.	Estimación	171
5.1	Introducción	171
5.2	Intervalo de confianza para la media de una población	175
5.3	Intervalo de confianza para la diferencia entre las medias de dos poblaciones	181

5.4	Intervalo de confianza para la proporción de una población	184
5.5	Intervalo de confianza para la diferencia entre las proporciones de dos poblaciones	186
5.6	La distribución t	188
5.7	Determinación del tamaño de la muestra para estimar las medias	198
5.8	Determinación del tamaño de la muestra para estimar proporciones	202
5.9	Intervalo de confianza para la variancia de una población con distribución normal	204
5.10	Intervalo de confianza para la razón de las variancias de dos poblaciones con distribución normal	210
5.11	Resumen	214
	<i>Preguntas y ejercicios de repaso</i>	214
	<i>Referencias</i>	217
6.	Pruebas de hipótesis	221
6.1	Introducción	221
6.2	Pruebas de hipótesis: media de una sola población	226
6.3	Pruebas de hipótesis: diferencia entre las medias de dos poblaciones	242
6.4	Comparaciones en parejas	254
6.5	Prueba de la hipótesis: proporción de una sola población	261
6.6	Prueba de la hipótesis: diferencia entre las proporciones de dos poblaciones	263
6.7	Prueba de la hipótesis: variancia de una sola población	266
6.8	Prueba de la hipótesis: razón de las variancias de dos poblaciones	270
6.9	Resumen	274
	<i>Preguntas y ejercicios de repaso</i>	275
	<i>Referencias</i>	279
7.	Análisis de la variancia	283
7.1	Introducción	283

7.2	El diseño completamente aleatorizado	285
7.3	Diseño de bloques completos aleatorizados	312
7.4	El experimento factorial	322
7.5	Temas diversos	337
7.6	Resumen	341
	<i>Preguntas y ejercicios de repaso</i>	341
	<i>Referencias</i>	349
8.	Regresión y correlación lineales simples	355
8.1	Introducción	355
8.2	El modelo de regresión	356
8.3	La ecuación de regresión de la muestra	358
8.4	Evaluación de la ecuación de regresión	368
8.5	Uso de la ecuación de regresión	383
8.6	El modelo de correlación	387
8.7	El coeficiente de correlación	390
8.8	Algunas precauciones	402
8.9	Resumen	404
	<i>Preguntas y ejercicios de repaso</i>	405
	<i>Referencias</i>	412
9.	Regresión y correlación múltiples	415
9.1	Introducción	415
9.2	El modelo de regresión múltiple	416
9.3	Obtención de la ecuación de regresión múltiple	418
9.4	Evaluación de la ecuación de regresión múltiple	428
9.5	Uso de la ecuación de regresión múltiple	436
9.6	El modelo de correlación	439
9.7	Elección de variables independientes para la ecuación de regresión múltiple	448
9.8	Resumen	449
	<i>Preguntas y ejercicios de repaso</i>	450
	<i>Referencias</i>	455
10.	La distribución ji-cuadrada y el análisis de frecuencias	459
10.1	Introducción	459

10.2	Propiedades matemáticas de la distribución ji-cuadrada	459
10.3	Pruebas de bondad de ajuste	461
10.4	Pruebas de independencia	476
10.5	Pruebas de homogeneidad	487
10.6	Resumen	494
	<i>Preguntas y ejercicios de repaso</i>	495
	<i>Referencias</i>	500
11.	Estadísticas no paramétricas y de libre distribución	503
11.1	Introducción	503
11.2	Escalas de medición	505
11.3	La prueba del signo	507
11.4	La prueba de la mediana	516
11.5	La prueba de Mann-Whitney	520
11.6	La prueba de bondad de ajuste de Kolmogorov-Smirnov	525
11.7	El análisis de variancia, con un solo criterio de clasificación por rangos, de Kruskal-Wallis	533
11.8	El análisis de variancia, con dos criterios de clasificación por rangos de Friedman	539
11.9	El coeficiente de correlación de rangos de Spearman	544
11.10	Resumen	553
	<i>Preguntas y ejercicios de repaso</i>	553
	<i>Referencias</i>	557
12.	Estadística demográfica	563
12.1	Introducción	563
12.2	Tasas y razones de mortalidad	564
12.3	Medidas de fertilidad	573
12.4	Medidas de morbilidad	577
12.5	Resumen	579
	<i>Referencias</i>	579
Apéndice		581
	A. Cuadrados y raíces cuadradas	582

B. Logaritmos	584
C. Distribución binomial de probabilidad acumulada	586
D. Funciones exponenciales	615
E. Distribución acumulada de Poisson	616
F. Areas de la curva normal	622
G. Números aleatorios	624
H. Percentiles de la distribución t	625
I. Percentiles de la distribución ji-cuadrada	626
J. Percentiles de la distribución F	627
K. Puntos de porcentaje del rango Student	637
L. Transformación de r a z	639
M. Cuantiles de la estadística de prueba de Mann-Whitney	640
N. Cuantiles de la estadística de prueba de Kolmogorov	644
O. Valores críticos de la estadística de prueba de Kruskal-Wallis	645
P. Distribución exacta de χ^2_r	
a. Para tablas con 2 a 9 conjuntos de tres rangos	649
b. Para tablas con 2 a 4 conjuntos de cuatro rangos	650
Q. Valores críticos de la estadística de prueba de Spearman	651
Créditos por las tablas	652
<i>Respuestas a los ejercicios de número impar</i>	653
<i>Indice</i>	663

1

Organización y resumen de los datos

1.1 INTRODUCCIÓN

Los objetivos de este libro son dos: 1) enseñar al estudiante a organizar y resumir los datos y 2) enseñarle la manera de tomar decisiones cuando tiene una gran cantidad de datos, examinando sólo una pequeña parte de ellos. Los conceptos y métodos necesarios para lograr el primer objetivo se presentan bajo el encabezado de *estadística descriptiva* y el segundo objetivo se alcanza a través del estudio de lo que se conoce como *inferencia estadística*. En este capítulo, se estudia la estadística descriptiva. Del capítulo, 2 al 5 se estudian los temas que constituyen el fundamento de la inferencia estadística y la mayor parte del resto del libro trata de esta última.

Dado que esta obra se ha escrito para personas que están preparándose en una carrera del campo de la salud pública o que ya están ejerciéndola, el material ilustrativo y los ejercicios reflejan los problemas y actividades que estas personas probablemente encontrarán en el ejercicio de sus profesiones.

1.2 ALGUNOS CONCEPTOS BÁSICOS

Se definirán primero algunos términos básicos que se encontrarán aquí.

Estadística. El significado de *estadística* está implícito en la sección anterior. Sin embargo, más concretamente, puede decirse que *la estadística es un campo del estudio relacionado con 1) la recopilación, organización y resumen de los datos y 2) la obtención de inferencias acerca de un conjunto de datos cuando sólo se observa una parte de ellos.*

Bioestadística. Las herramientas de la estadística se emplean en muchos campos: negocios, educación, psicología, agricultura y economía para mencionar sólo unos cuantos. Cuando los datos que se están analizando se obtienen de las ciencias biológicas y de la medicina, se utiliza el término bioestadística para diferenciar a esta aplicación particular de herramientas y conceptos estadísticos. Esta área de aplicación es el propósito de este libro.

Variable. Si, conforme se observa una característica, se encuentra que toma valores distintos en diferentes personas, lugares o cosas, se dice que esta característica es una *variable*. Se hace esto por la sencilla razón de que la característica no es la misma cuando se observa en diferentes personas, lugares o cosas que la poseen. Algunos ejemplos de variables son la estatura de los adultos del sexo masculino, el peso de los niños en edad preescolar y la edad de los pacientes que se ven en una clínica dental.

Variables cuantitativas. Una *variable cuantitativa* es aquella que puede medirse en la forma habitual. Por ejemplo, se pueden hacer las mediciones de la estatura de adultos del sexo masculino, el peso de niños en edad preescolar y la edad de los pacientes que se ven en una clínica dental. Estos son ejemplos de *variables cuantitativas*.

Variables cualitativas. Algunas características pueden no ser medidas en el sentido en que se miden la estatura, el peso y la edad. Muchas características sólo pueden catalogarse, por ejemplo, cuando a una persona enferma se le hace un diagnóstico médico, cuando a una persona se clasifica dentro de un grupo socioeconómico o cuando se dice que una persona, lugar u objeto, posee o no alguna característica de interés. A las variables de este tipo se les conoce como *variables cualitativas*.

Aunque, en el caso de las variables cualitativas, no puede lograrse su medición en el sentido habitual del término, puede contarse el nú-

mero de personas, lugares o cosas que pertenecen a varias categorías. El administrador de un hospital, por ejemplo, puede contar el número de pacientes admitidos durante un día para cada uno de los diferentes diagnósticos de admisión.

Variable aleatoria. Cada vez que se determina la estatura, peso o edad de un individuo, se dice con frecuencia que el resultado es un valor de la variable correspondiente. (Cuando los valores obtenidos son el resultado de factores fortuitos, se dice que la variable es una *variable aleatoria*.) Los valores que resultan de procedimientos de medición suelen conocerse como *observaciones* o simplemente como *medidas*.

Variable aleatoria discreta. Las variables pueden caracterizarse aún más como *discretas* o *continuas*. Dado que las definiciones matemáticamente rigurosas de variables discretas y continuas están fuera del alcance de este libro, en su lugar se dan definiciones no rigurosas y un ejemplo de cada una de ellas.

(Una variable aleatoria discreta se caracteriza por saltos o interrupciones en los valores que ésta puede tener.) Estos saltos o interrupciones indican la ausencia de valores entre los valores particulares que puede tener la variable. Algunos ejemplos ilustrarán el punto. El número de admisiones diarias a un hospital general es una variable aleatoria discreta ya que, cada día, el número de admisiones debe representarse por un número entero, como 0, 1, 2, 3 y así sucesivamente. El número de admisiones por día no puede ser un número como 1.5, 2.997 ó 3.3333. El número de dientes con caries, faltantes u obturados por niño en una escuela primaria es otro ejemplo de variable discreta.

(Variable aleatoria continua. Una variable aleatoria continua no posee los saltos o interrupciones que caracterizan a una variable aleatoria discreta.) Una variable aleatoria continua puede tener cualquier valor dentro de un intervalo especificado de valores asumidos por la variable. Ejemplos de variables continuas son las diversas mediciones que pueden hacerse en individuos, como estatura, peso y circunferencia del cráneo. No importa qué tan iguales sean las estaturas observadas en dos individuos, ya que por ejemplo, puede encontrarse teóricamente otra persona que tenga una estatura intermedia entre ambas.

Sin embargo, debido a las limitaciones de los instrumentos de medición con que se cuenta, las variables que son esencialmente continuas

suelen tratarse como si fueran discretas. La estatura, por ejemplo, se registra a menudo hacia el centímetro más próximo, mientras que, con un aparato de medición exacto esa medición podría hacerse tan precisa como se deseara.

Población. La persona promedio piensa en una población como un grupo de elementos, por lo común personas. Sin embargo, una población o conjunto de elementos puede consistir de animales, máquinas, plantas o células. Para los fines de este libro, se define a una *población de elementos como el mayor grupo de elementos por los cuales se tiene un cierto interés en un momento dado*. Si se lleva a cabo una medición de alguna variable sobre cada uno de los elementos de una población, se obtiene una población de valores de esa variable. Por lo tanto, puede definirse a una *población de valores como el mayor grupo de valores de una variable aleatoria por los cuales se tiene un cierto interés en un momento dado*. Por ejemplo, si se tiene interés en el peso de todos los niños inscritos en un determinado sistema escolar municipal, la población consta de todos estos pesos. Si el interés se centra sólo en el peso de los alumnos de primer año del sistema, se tiene una población distinta: los pesos de los alumnos de primer año inscritos en el sistema escolar. En consecuencia, las poblaciones se determinan o definen de acuerdo con la esfera de interés que se tenga en ellas. Las poblaciones pueden ser *finitas* o *infinitas*. Si una población de valores consta de un número fijo de estos valores, se dice que la población es *finita*. Por otra parte, si una población consta de una sucesión sin fin de valores, dicha población es *infinita*.)

Muestra. Una muestra puede definirse simplemente como *(una parte de una población)*. Supóngase que una población consta del peso de todos los niños de nivel primaria inscritos en un determinado sistema escolar municipal. Si se reúnen para el análisis el peso de sólo una fracción de estos niños, se tiene sólo una parte de la población de pesos, es decir, se tiene una *muestra*. Hay muchos tipos de muestras que pueden seleccionarse de una población. En los capítulos siguientes se estudian estos tipos.

1.3 EL ARREGLO ORDENADO

Cuando se hacen mediciones de una variable aleatoria sobre los elementos de una población, los valores resultantes llegan por lo general al investigador o estadístico, como un conjunto de datos desordenados.

Tabla 1.3.1 Edades (en años) de los pacientes admitidos a un hospital de enfermedades crónicas durante cierto mes.

Número	Edad	Número	Edad	Número	Edad	Número	Edad
1	10	26	48	51	63	76	53
2	22	27	39	52	53	77	33
3	24	28	6	53	88	78	3
4	42	29	72	54	48	79	85
5	37	30	14	55	52	80	8
6	77	31	36	56	87	81	51
7	89	32	69	57	71	82	60
8	85	33	40	58	51	83	58
9	28	34	61	59	52	84	9
10	63	35	12	60	33	85	14
11	9	36	21	61	46	86	74
12	10	37	54	62	33	87	24
13	7	38	53	63	85	88	87
14	51	39	58	64	22	89	7
15	2	40	32	65	5	90	81
16	1	41	27	66	87	91	30
17	52	42	33	67	28	92	76
18	7	43	1	68	2	93	7
19	48	44	25	69	85	94	6
20	54	45	22	70	61	95	27
21	32	46	6	71	16	96	18
22	29	47	81	72	42	97	17
23	2	48	11	73	69	98	53
24	15	49	56	74	7	99	70
25	46	50	5	75	10	100	49

A menos que el número de observaciones sea extremadamente pequeño, es poco probable que estos datos proporcionen mucha información hasta que se hayan ordenado de alguna forma. Si el número de observaciones no es demasiado grande, un primer paso para la organización de estos datos es la preparación de un *arreglo ordenado*. (Un *arreglo ordenado* es una lista de los valores de una colección (ya sea población o muestra), en orden de magnitud, desde el valor más pequeño hasta el valor más grande.)

Ejemplo 1.3.1

La tabla 1.3.1 consta de una lista de las edades de los pacientes admitidos a un hospital de enfermedades crónicas durante cierto mes.

La tabla refleja el orden en el que fueron admitidos los pacientes. Como puede verse, se requiere un examen minucioso para averiguar una información tan elemental como la edad del paciente más joven y del más viejo que se admitió. La tabla 1.3.2 presenta los mismos datos en la forma de un arreglo ordenado. Si tienen que efectuarse a mano algunos cálculos y la organización de datos adicionales, el trabajo puede facilitarse si se lleva a cabo a partir del arreglo ordenado. Si los datos tienen que analizarse por medio de una computadora, es posible que no sea necesario preparar un arreglo ordenado.

Tabla 1.3.2 Arreglo ordenado de las edades de los pacientes admitidos a un hospital de enfermedades crónicas durante cierto mes.

Número	Edad	Número	Edad	Número	Edad	Número	Edad
1	1	26	14	51	37	76	58
2	1	27	15	52	39	77	60
3	2	28	16	53	40	78	61
4	2	29	17	54	42	79	61
5	2	30	18	55	42	80	63
6	3	31	21	56	46	81	63
7	5	32	22	57	46	82	69
8	5	33	22	58	48	83	69
9	6	34	22	59	48	84	70
10	6	35	24	60	48	85	71
11	6	36	24	61	49	86	72
12	7	37	25	62	51	87	74
13	7	38	27	63	51	88	76
14	7	39	27	64	51	89	77
15	7	40	28	65	52	90	81
16	7	41	28	66	52	91	81
17	8	42	29	67	52	92	85
18	9	43	30	68	53	93	85
19	9	44	32	69	53	94	85
20	10	45	32	70	53	95	85
21	10	46	33	71	53	96	87
22	10	47	33	72	54	97	87
23	11	48	33	73	54	98	87
24	12	49	33	74	56	99	88
25	14	50	36	75	58	100	89

1.4 DATOS AGRUPADOS: LA DISTRIBUCIÓN DE FRECUENCIAS

Aunque un conjunto de observaciones puede hacerse mas comprensible y adquirir mayor significado por medio de un arreglo ordenado, puede lograrse una mayor síntesis agrupando los datos. Para agrupar a un conjunto de observaciones, se selecciona un conjunto de intervalos contiguos que no se traslapen de modo que cada valor en el conjunto de observaciones pueda colocarse en uno, y sólo uno, de los intervalos. Estos intervalos se conocen en general como *intervalos de clase*.

Uno de los primeros puntos a considerar, cuando se van a agrupar ciertos datos, es cuántos intervalos van a incluirse. No es conveniente incluir muy pocos intervalos debido a que hay pérdida de información. Por otra parte, si se utilizan demasiados intervalos, no se logra el objetivo de la síntesis. La mejor guía en relación con lo anterior, así como para otras decisiones que deben tomarse al agrupar los datos, es el conocimiento que se tenga de ellos. Puede ser que se hayan determinado con anterioridad los intervalos de clase, como en el caso de las tabulaciones anuales, cuando se conservan los intervalos de clase de años anteriores con fines comparativos. Quienes deseen una recomendación sobre este aspecto, pueden consultar una fórmula dada por Sturges.² Esta fórmula es $k = 1 + 3.322 (\log_{10} n)$, donde k representa el número de intervalos de clase y n el número de valores en el conjunto de datos bajo consideración. La respuesta obtenida aplicando la *regla de Sturges* no debe considerarse como definitiva, sino sólo como una guía. El número de intervalos de clase, especificado por esta regla, debe aumentarse o disminuirse, según convenga en beneficio de una presentación clara.

Por ejemplo, supóngase que se tiene una muestra de 275 observaciones que se desean agrupar. En la tabla B del apéndice, se encuentra que el logaritmo de base 10 de 275 es 2.4393. Aplicando la fórmula de Sturges se obtiene un valor de $k = 1 + 3.22(2.4393) \simeq 9$. En la práctica, otras consideraciones llevarían a utilizar 8 (o menos) o quizá 10 (o más) intervalos de clase.

Otra cuestión que debe decidirse se refiere a la amplitud de los intervalos de clase. Aunque a veces es imposible, los intervalos de clase deberían, en general, tener la misma amplitud. Esta amplitud puede determinarse dividiendo el recorrido entre k , el número de intervalos de

clase. Simbólicamente, la amplitud del intervalo de clase está dada por

$$w = \frac{R}{k} \quad (1.4.1)$$

donde R (el recorrido) es la diferencia entre la observación más pequeña y más grande en el conjunto de datos. Como regla general, este procedimiento proporciona una amplitud tan grande que no es conveniente utilizarla. Una vez más, debe aplicarse el buen juicio y seleccionar una amplitud (por lo común próxima a la obtenida por la ecuación 1.4.1) que sea más conveniente.

Ejemplo 1.4.1

La tabla 1.4.1 muestra los pesos en onzas de tumores malignos extirpados del abdomen de 57 personas. Para tener una idea del número de intervalos de clase que deben utilizarse, puede aplicarse la regla de Sturges para obtener

$$\begin{aligned} k &= 1 + 3.322(\log 57) \\ &= 1 + 3.322(1.7559) \\ &\approx 7 \end{aligned}$$

Tabla 1.4.1 Pesos, en onzas, de los tumores malignos extirpados del abdomen de 57 personas.

68	65	12	22
63	43	32	43
42	25	49	27
27	74	38	49
30	51	42	28
36	36	27	23
28	42	31	19
32	28	50	46
79	31	38	30
27	28	21	43
22	25	16	49
23	45	24	12
24	12	69	
25	57	47	
44	51	23	

Divídase ahora el recorrido entre 7 para tener una idea acerca de la amplitud del intervalo de clase. Se tiene que

$$\frac{R}{k} = \frac{79 - 12}{7} = \frac{67}{7} = 9.6$$

Resulta evidente que será más conveniente utilizar una amplitud de 10 para el intervalo de clase, lo que, asimismo, tendrá más significado para el lector. Pueden construirse ahora los intervalos. Dado que el valor más pequeño en la tabla 1.4.1 es 12 y el más grande 79, pueden empezarse los intervalos con 10 y terminarse con 79. Esto da los intervalos siguientes:

10-19
20-29
30-39
40-49
50-59
60-69
70-79

Puede apreciarse que hay siete de estos intervalos, el número sugerido por la regla de Sturges.

La determinación del número de valores que caen en cada intervalo de clase consiste simplemente en observar los valores uno por uno y colocar una pequeña marca a un lado del intervalo apropiado. Cuando se hace esto, se tiene la tabla 1.4.2.

Tabla 1.4.2 Distribución de frecuencias de los pesos (en onzas) de los tumores malignos extirpados del abdomen de 57 personas.

Intervalo de clase		Frecuencia
10-19	###	5
20-29	### ### ###	19
30-39	### ###	10
40-49	### ###	13
50-59	////	4
60-69	////	4
70-79	//	2
Total		57

Una tabla de este tipo se conoce como *distribución de frecuencias*. Esta tabla muestra la forma en la que los valores de la variable se distribuyen entre los intervalos de clase especificados. Consultándola, puede determinarse la frecuencia con la que ocurren los valores dentro de cualquiera de los intervalos de clase que se muestran.

A veces puede ser útil conocer la proporción (más que el número) de valores que caen dentro de un determinado intervalo de clase. Esta información se obtiene dividiendo el número de valores del intervalo de clase entre el número total de valores. Por ejemplo, si se desea conocer la proporción de valores entre 30 y 39, inclusive, se divide 10 entre 57 y se obtiene .18. Así, se dice que 10 de 57 ó $10/57$ ó .18 de los valores están entre 30 y 39. Multiplicando .18 por 100 da el porcentaje de valores entre 30 y 39. Puede decirse entonces que el 18 por ciento de los 57 valores están entre 30 y 39. A la proporción de valores que caen dentro de un intervalo de clase se le da el nombre de *frecuencia relativa de ocurrencia* de los valores en ese intervalo.

Para determinar la frecuencia de los valores que caen dentro de dos o más intervalos de clase, se obtiene la suma del número de valores que caen dentro de los intervalos de clase de interés. Asimismo, si se desea conocer la frecuencia relativa de la ocurrencia de los valores que caen dentro de dos o más intervalos de clase, se suman las frecuencias relativas correspondientes. Pueden acumularse las frecuencias y frecuencias relativas para facilitar la obtención de información acerca de la frecuencia o frecuencia relativa de los valores dentro de dos o más intervalos de clase contiguos. La tabla 1.4.3 muestra los datos de

Tabla 1.4.3 Frecuencia, frecuencia acumulada, frecuencia relativa y frecuencia relativa acumulada para el ejemplo 1.4.1.

Intervalos de clase	Frecuencia	Frecuencia acumulada	Frecuencia relativa	Frecuencia relativa acumulada
10-19	5	5	.0877	.0877
20-29	19	24	.3333	.4210
30-39	10	34	.1754	.5964
40-49	13	47	.2281	.8245
50-59	4	51	.0702	.8947
60-69	4	55	.0702	.9649
70-79	2	57	.0351	1.0000
Total	57		1.0000	

la tabla 1.4.2 junto con las *frecuencias acumuladas*, las *frecuencias relativas* y las *frecuencias relativas acumuladas*.

Supóngase que se tiene interés en la frecuencia relativa de los valores entre 40 y 69. Se utiliza la columna de la frecuencia relativa acumulada de la tabla 1.4.3 y se resta .5964 de .9649, obteniéndose .3685.

El histograma. Puede representarse gráficamente una distribución de frecuencias (o una distribución de frecuencias relativas) en la forma de un *histograma*, como se muestra en la figura 1.4.1. Al construir un histograma, los valores de la variable en consideración constituyen el eje horizontal, mientras que el eje vertical tiene como escala a la frecuencia (o frecuencia relativa, si se desea) de ocurrencia. Por encima de cada intervalo de clase sobre el eje horizontal se levanta una barra rectangular, o celda, como a veces se conoce, de modo que su




Figura 1.4.1 Histograma de los pesos (en onzas) de los tumores malignos extirpados del abdomen de 57 personas.

altura corresponda con la frecuencia correspondiente. Las celdas de un histograma deben quedar unidas y, para lograrlo, deben tomarse en cuenta los límites verdaderos de los intervalos de clase para evitar que queden espacios entre las celdas de la gráfica.

El nivel de precisión que se observa en datos reportados que se miden sobre una escala continua indica cierto orden de redondeo. El orden del redondeo refleja las preferencias personales de quien hace el reporte o las limitaciones del instrumento de medición utilizado. Cuando se construye una distribución de frecuencias a partir de los datos, los límites del intervalo de clase reflejan por lo general el grado de precisión de los datos en bruto. Esto se ha hecho en el ejemplo que se ha utilizado. Sin embargo, se sabe que algunos de los valores que caen dentro del segundo intervalo de clase por ejemplo, si se midieran con precisión, quizá serían poco menores que 20 y que algunos serían un poco mayores que 29. Considerando la continuidad fundamental de la variable y suponiendo que los datos se redondearon hasta el número entero más próximo, es conveniente pensar que 19.5 y 29.5 son los *límites verdaderos* de este segundo intervalo. Entonces, se toman los límites verdaderos para cada uno de los intervalos de clase, como se muestra en la tabla 1.4.4.

Si se traza una gráfica utilizando estos límites de clase como la base de los rectángulos, no quedarán espacios y se tendrá el histograma que se muestra en la figura 1.4.1.

Nótese que a cada observación se le asigna una unidad del área del histograma. Dado que se tienen 57 observaciones, el histograma consta de un total de 57 unidades. Cada celda posee una cierta proporción del área total, dependiendo de la frecuencia. Por ejemplo, la segunda

Tabla 1.4.4 Datos de la tabla 1.4.2 que representan los límites de clase verdaderos.

<i>Límites de clase verdaderos</i>	<i>Frecuencia</i>
9.5–19.5	5
19.5–29.5	19
29.5–39.5	10
39.5–49.5	13
49.5–59.5	4
59.5–69.5	4
69.5–79.5	2

celda contiene diecinueve cincuentisieteavos ($19/57$) del área. Esto, como ya se vio, es la frecuencia relativa de ocurrencia de los valores entre 19.5 y 29.5. A partir de esto, se ve que las subáreas del histograma, definidas por las celdas, corresponden a las frecuencias de ocurrencia de los valores entre los límites de las áreas de la escala horizontal. La razón de una subárea particular al área total del histograma equivale a la frecuencia relativa de ocurrencia de los valores entre los puntos correspondientes sobre el eje horizontal.

El polígono de frecuencias. Una distribución de frecuencias puede representarse gráficamente aun en otra forma, es decir, por medio de un *polígono de frecuencias*. Para trazar un polígono de frecuencias, se hace una marca primero en los puntos medios de la parte superior de cada una de las barras que representan los intervalos de clase so-




Figura 1.4.2 Polígono de frecuencias. Pesos (en onzas) de los tumores malignos extirpados del abdomen de 57 personas.

bre el eje horizontal de la gráfica, como la que se muestra en la figura 1.4.1. La altura de las barras de un determinado punto corresponde a la frecuencia del intervalo de clase pertinente. Uniendo los puntos por líneas rectas se obtiene el polígono de frecuencias. La figura 1.4.2 es el polígono de frecuencias para los datos del ejemplo 1.4.1.

Nótese que el polígono se lleva hasta el eje horizontal en los extremos hasta los puntos que serían los puntos medios si hubiera una celda adicional en cada extremo del histograma correspondiente. Esto permite que el área total quede incluida. El área total bajo el polígono de frecuencias equivale al área bajo el histograma. La figura 1.4.3 muestra el polígono de frecuencias de la figura 1.4.2 sobrepuesto sobre el histograma de la figura 1.4.1. Esta figura permite ver, para el mismo conjunto de datos, la relación que existe entre las dos formas gráficas.




Figura 1.4.3 Polígono de frecuencias e histograma para el ejemplo 1.4.1.

Ejercicios

1.4.1 Los siguientes valores son los niveles de glucosa en sangre extraída a 100 niños en ayunas:

56	61	57	77	62	75	63	55	64	60
60	57	61	57	67	62	69	67	68	59
65	72	65	61	68	73	65	62	75	80
66	61	69	76	72	57	75	68	81	64
69	64	66	65	65	76	65	58	65	64
68	71	72	58	73	55	73	79	81	56
65	60	65	80	66	80	68	55	66	71
72	73	73	75	75	74	66	68	73	65
73	74	68	59	69	55	67	65	67	63
67	56	67	62	65	75	62	63	63	59

Trace:

- Una distribución de frecuencias.
- Un histograma.
- Una distribución de frecuencias relativas.
- Un polígono de frecuencias

1.4.2 Utilizando los datos de la tabla 1.3.1, trace:

- Una distribución de frecuencias.
- Una distribución de frecuencias relativas
- Un histograma.
- Un polígono de frecuencias.

1.4.3 Los siguientes valores son las calificaciones obtenidas en una prueba de inteligencia por un grupo de niños que participaron en un experimento:

Número del niño	Calificación	Número del niño	Calificación	Número del niño	Calificación	Número del niño	Calificación
1	114	16	90	31	137	46	118
2	115	17	89	32	120	47	110
3	113	18	106	33	138	48	108
4	112	19	104	34	111	49	134
5	113	20	126	35	100	50	118
6	132	21	127	36	116	51	114

Número del niño	Calificación	Número del niño	Calificación	Número del niño	Calificación	Número del niño	Calificación
7	130	22	115	37	101	52	142
8	128	23	116	38	111	53	120
9	122	24	109	39	110	54	119
10	121	25	108	40	137	55	143
11	126	26	122	41	119	56	133
12	117	27	123	42	115	57	85
13	115	28	149	43	83	58	117
14	88	29	140	44	109	59	147
15	113	30	121	45	117	60	102

Trace:

- Una distribución de frecuencias.
- Una distribución de frecuencias relativas.
- Un histograma.
- Un polígono de frecuencias.

1.4.4 A setenta y cinco empleados de un hospital general se les pidió que realizaran cierta tarea. Se registró el tiempo en minutos que requirió cada empleado para terminar su tarea. Los resultados son los que se muestran a continuación.

Número del empleado	Tiempo	Número del empleado	Tiempo	Número del empleado	Tiempo
1	1.3	26	2.2	51	3.2
2	1.5	27	2.3	52	3.0
3	1.4	28	2.6	53	3.4
4	1.5	29	2.8	54	3.4
5	1.7	30	2.1	55	3.2
6	1.0	31	2.3	56	4.5
7	1.3	32	2.4	57	4.6
8	1.7	33	2.0	58	4.9
9	1.2	34	2.8	59	4.1
10	1.8	35	2.2	60	4.6
11	1.1	36	2.5	61	4.2
12	1.0	37	2.9	62	4.0
13	1.8	38	2.0	63	4.3
14	1.6	39	2.9	64	4.8
15	2.1	40	2.5	65	4.5
16	2.1	41	3.6	66	5.1

Número del empleado	Tiempo	Número del empleado	Tiempo	Número del empleado	Tiempo
17	2.1	42	3.1	67	5.7
18	2.1	43	3.5	68	5.1
19	2.4	44	3.7	69	5.4
20	2.9	45	3.7	70	5.7
21	2.7	46	3.4	71	6.7
22	2.3	47	3.1	72	6.8
23	2.8	48	3.5	73	6.6
24	2.0	49	3.6	74	6.0
25	2.7	50	3.5	75	6.1

A partir de estos datos, trace:

- Una distribución de frecuencias.
- Una distribución de frecuencias relativas.
- Un histograma.
- Un polígono de frecuencias.

1.4.5 La siguiente tabla muestra el número de horas que durmieron 45 pacientes de un hospital después de la administración de un cierto anestésico.

7	10	12	4	8	7	3	8	5
12	11	3	8	1	1	13	10	4
4	5	5	8	7	7	3	2	3
8	13	1	7	17	3	4	5	5
3	1	17	10	4	7	7	11	8

A partir de estos datos, trace:

- Una distribución de frecuencias.
- Una distribución de frecuencias relativas.
- Un histograma.
- Un polígono de frecuencias

1.4.6 Los siguientes valores son el número de bebés nacidos durante un año en 60 hospitales de una comunidad.

30	55	27	45	56	48	45	49	32	57	47	56
37	55	52	34	54	42	32	59	35	46	24	57
32	26	40	28	53	54	29	42	42	54	53	59
39	56	59	58	49	53	30	53	21	34	28	50
52	57	43	46	54	31	22	31	24	24	57	29

A partir de estos datos, trace:

- Una distribución de frecuencias.
- Una distribución de frecuencias relativas.
- Un polígono de frecuencias.

1.5 MEDIDAS DE TENDENCIA CENTRAL

Aunque la distribución de frecuencias tiene varias aplicaciones, hay muchos casos que requieren otros tipos de resúmenes de datos. Lo que se necesita en muchos casos es la habilidad para resumir los datos por medio de sólo unas cuantas *medidas descriptivas*. Las medidas descriptivas pueden calcularse a partir de los datos de una muestra o de una población. Para diferenciarlas, se tienen las siguientes definiciones:

- Una medida descriptiva calculada a partir de los datos de una muestra se conoce como **estadística**.
- Una medida descriptiva calculada a partir de los datos de una población se conoce como **parámetro**.

Hay varios tipos de medidas descriptivas que pueden calcularse a partir de un conjunto de datos. Sin embargo, en este capítulo la atención se ha centrado en las *medidas de tendencia central* y en las *medidas de dispersión*. Las medidas de tendencia central se estudiarán en esta sección y las medidas de dispersión en la siguiente.

En cada una de las medidas de tendencia central, de las cuales se estudiarán tres, se tiene un sólo valor que se considera como típico del conjunto de datos como un todo. Las tres medidas de tendencia central que más se utilizan son la *media*, la *mediana* y la *moda*.

Media aritmética. La medida de tendencia central más conocida es la media aritmética. Es la medida descriptiva que la mayoría de las

personas tiene en mente cuando se habla del “promedio”. El adjetivo aritmética distingue a esta media de otras que pueden calcularse. Dado que en este libro no se estudian estas otras medias, no debe haber motivo alguno de confusión si se menciona simplemente como *media* a la media aritmética. La media se obtiene sumando todos los valores en una población o muestra y dividiendo el valor obtenido entre el número de valores que se sumaron. Para obtener la edad media de la población de los 100 pacientes representados en la tabla 1.3.1, se hace lo siguiente:

$$\text{edad media} = \frac{10 + 22 + \cdots + 70 + 49}{100} = \frac{3920}{100} = 39.20$$

Los tres puntos en el numerador representan los valores que no se muestran con el fin de ahorrar espacio.

Será conveniente generalizar si es posible el procedimiento para obtener la media y representar dicho procedimiento por medio de una notación más compacta. Se empezará por designar a la variable aleatoria de interés por medio de la letra mayúscula X . En el presente ejemplo, sea X la variable aleatoria, edad. Los valores específicos de una variable aleatoria se designarán por medio de la letra minúscula x . Para distinguir un valor de otro, se agrega un subíndice a la x y se considera que dicho subíndice se refiere al primer, segundo y tercer valor, y así sucesivamente. Por ejemplo, de la tabla 1.3.1 se tiene que

$$x_1 = 10, \quad x_2 = 22, \dots, \quad \text{y} \quad x_{100} = 49$$

En general, un valor típico de una variable aleatoria se designará por x_i y el valor final, en una población finita de valores, por x_N . Por último, se utilizará la letra griega μ para representar la media de la población. Puede ahora escribirse la fórmula general para la media de una población finita como sigue:

$$\mu = \frac{\sum_{i=1}^N x_i}{N} \quad (1.5.1)$$

El símbolo $\sum_{i=1}^N$ indica que deben sumarse todos los valores de la variable desde el primero hasta el último. Este símbolo, Σ , llamado *signo de sumatoria*, se utilizará ampliamente en este libro. Cuando, por

el contexto, resulta obvio cuáles valores deben sumarse, se omitirán los símbolos arriba y abajo de Σ .

Cuando se calcula la media para una muestra de valores, se sigue el procedimiento que acaba de describirse, con algunas modificaciones en la notación. Se utiliza $\bar{x}$ para designar la media de la muestra y n para indicar el número de valores de la muestra. La media de la muestra se expresa entonces como

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} \quad (1.5.2)$$

Supóngase que se tiene una muestra que consta de las siguientes cinco ($n = 5$) observaciones de la tabla 1.3.1. Sustituyendo los datos de la

<i>Observación de la población</i>	<i>Observación de la muestra</i>	
<i>Número</i>	<i>Número</i>	<i>Valor</i>
x_{12}	x_1	10
x_{20}	x_2	54
x_{36}	x_3	21
x_{62}	x_4	33
x_{98}	x_5	53

muestra en la ecuación 1.5.2, se tiene que

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{10 + 54 + 21 + 33 + 53}{5} = \frac{171}{5} = 34.2$$

La media aritmética posee ciertas propiedades, algunas deseables y otras no tan deseables. Estas propiedades incluyen las siguientes:

1. Unicidad. Para un determinado conjunto de datos, existe una y sólo una media aritmética.
2. Simplicidad. La media aritmética es fácil de comprender y fácil de calcular.

3. Dado que todos y cada uno de los valores de un conjunto de datos intervienen en el cálculo de la media, ésta es afectada por cada valor. Por lo tanto, los valores extremos influyen en la media y, en algunos casos, pueden alterarla tanto que resulta inconveniente como una medida de tendencia central.

Como ejemplo de qué tanto pueden afectar los valores extremos a la media, considérese la situación siguiente. Supóngase que se investiga a los cinco médicos que ejercen en cierta área con el fin de determinar sus honorarios para cierto trámite. Supóngase que reportan estos honorarios: \$15, \$15, \$15.50, \$15.50 y \$80. Se encuentra que los honorarios medios para los cinco médicos son de \$28.20, un valor que no es muy representativo del conjunto de datos como un todo. El único valor atípico ha tenido el efecto de inflar la media.

Mediana. La mediana de un conjunto finito de valores es aquel valor que divide al conjunto en dos partes iguales tales que el número de valores iguales a la mediana o mayores que ella es igual al número de valores iguales a ella o menores que ella. Si el número de valores es impar, la mediana será el valor que está en medio, cuando todos los valores se han arreglado en orden de magnitud. Cuando el número de observaciones es par, no se tiene una sola observación en medio, sino dos. En este caso, se toma la mediana como la media de estas dos observaciones de en medio, cuando todas las observaciones se han dispuesto en el orden de su magnitud.

Para ilustrar esto, encuéntrese la mediana de los datos de la tabla 1.3.2. Aquí, los valores ya están ordenados, de modo que sólo se necesita encontrar los dos valores de en medio. Estos son los números de observación 50 y 51. Los valores son 36 y 37 y, por lo tanto, la mediana es $(36 + 37)/2 = 36.5$.

Obténgase ahora la mediana de la muestra que consta de los valores 10, 54, 21, 33 y 53. Arreglando estos valores de acuerdo a su orden de magnitud, se tiene la secuencia 10, 21, 33, 53 y 54. Dado que éste es un número impar de valores, la mediana es el valor de en medio, o sea, 33.

Las propiedades de la mediana incluyen las siguientes:

1. Unicidad. Como ocurre con la media, sólo existe una mediana para un determinado conjunto de datos.
2. Simplicidad. La mediana es fácil de calcular.

3. No es afectada tan drásticamente por los valores extremos como lo es la media.

La moda. La moda de un conjunto de valores es aquel valor que ocurre con más frecuencia. Si todos los valores son distintos, no hay moda; por otra parte, un conjunto de valores puede tener más de una moda. Una vez más, observando los datos de la tabla 1.3.2, se encuentra que 7, el cual se presenta cinco veces, es el valor que ocurre con más frecuencia, y es por lo tanto la moda.

Como ejemplo de un conjunto de valores que tiene más de una moda, considérese un laboratorio con 10 empleados cuyas edades son 20, 21, 20, 20, 34, 22, 24, 27, 27 y 27 años. Puede decirse que estos datos tienen dos modas, 20 y 27. La muestra que tenga los valores 10, 21, 33, 53 y 54 no tiene moda, ya que todos estos valores son distintos.

La moda puede utilizarse para describir datos cualitativos. Por ejemplo, supóngase que los pacientes que se atendieron en una clínica de salud mental durante un determinado año recibieron uno de los siguientes diagnósticos: retraso mental, síndrome cerebral orgánico, psicosis, neurosis y alteración de la personalidad. El diagnóstico que ocurriera con más frecuencia en el grupo de pacientes se llamaría diagnóstico modal.

Ejercicios

- 1.5.1 Los siguientes valores son los niveles de glucosa en sangre extraída a 10 niños en ayunas.

Número	Valor	Número	Valor
1	56	6	65
2	62	7	65
3	63	8	68
4	65	9	70
5	65	10	72

Calcule:

- a) La media.
- b) La mediana.
- c) La moda.

- 1.5.2 Los siguientes valores son los pesos de una muestra de 10 animales experimentales sometidos a una operación quirúrgica.

Número	Peso(kg)	Número	Peso(kg)
1	13.2	6	14.4
2	15.4	7	13.6
3	13.0	8	15.0
4	16.6	9	14.6
5	16.9	10	13.1

- Encuentre: a) La media.
b) La mediana.

- 1.5.3 Quince pacientes que realizaron visitas iniciales a un departamento sanitario municipal recorrieron las siguientes distancias:

Paciente	Distancia (millas)	Paciente	Distancia (millas)
1	5	8	6
2	9	9	13
3	11	10	7
4	3	11	3
5	12	12	15
6	13	13	12
7	12	14	15
		15	5

- Encuentre: a) La media de la distancia recorrida por estos pacientes.
b) La mediana de la distancia recorrida.

- 1.5.4 Una muestra de once pacientes admitidos para diagnóstico y evaluación en una sala psiquiátrica recientemente abierta en un hospital general, tuvieron las duraciones siguientes de su internación:

Número	Duración del internado (días)	Número	Duración del internado (días)
1	29	6	14
2	14	7	28
3	11	8	14
4	24	9	18
5	14	10	22
		11	14

Encuentre:

- a) La duración media de la internación para estos pacientes.
- b) La mediana.
- c) La moda.

1.5.5 A veinte pacientes en el ala de convalecencia de un hospital general se les permitió que eligieran entre cuatro tipos de carne para la comida. Sus elecciones fueron las siguientes: pollo, pescado, pescado, hígado, pollo, pollo, torta de carne, pollo, pescado, torta de carne, hígado, pescado, torta de carne, pollo, pollo, pollo, hígado, pescado, torta de carne, pollo.

¿Cuál fue la elección modal?

1.6 MEDIDAS DE DISPERSIÓN

La *dispersión* de un conjunto de observaciones se refiere a la variedad que exhiben los valores de las observaciones. Si todos los valores son iguales, no hay dispersión; si no todos son iguales, hay dispersión en los datos. La magnitud de la dispersión puede ser pequeña, cuando los valores, aunque distintos, están próximos entre sí. Si los valores están ampliamente desparramados, la dispersión es mayor. Otros términos que se utilizan como sinónimos de dispersión son los de *variación* y *diseminación*.

El recorrido. Una forma de medir la variación en un conjunto de valores es calcular el *recorrido*. El recorrido es la diferencia que existe entre el valor menor y el mayor de un conjunto de observaciones. Si se denota el recorrido por R , el valor mayor por x_L y el menor por x_S , el recorrido se calcula como sigue:

$$R = x_L - x_S \quad (1.6.1)$$

Utilizando los datos de la tabla 1.3.2, se tiene que

$$R = 89 - 1 = 88$$

La utilidad del recorrido es limitada. El hecho de que sólo tome en cuenta dos valores, hace que sea una medida pobre de la dispersión. La ventaja principal de utilizar el recorrido es la sencillez de su cálculo.

La variancia. Cuando los valores de un conjunto de observaciones están muy próximos a su media, la dispersión es menor que cuando están distribuidos sobre un amplio recorrido. Dado que esto es cierto, intuitivamente sería interesante el hecho de que se pudiera medir la dispersión con respecto a la diseminación de los valores en torno a su media. Dicha medida se realiza en lo que se conoce como *variancia*. Para calcular la variancia, se resta la media de cada uno de los valores, se elevan al cuadrado las diferencias y, a continuación, se suman. Esta suma de las desviaciones de los valores de su media (elevadas al cuadrado) se divide entre el tamaño de la muestra, menos 1, para obtener la variancia. Suponiendo que s^2 es la variancia de la muestra, el procedimiento puede escribirse simbólicamente como sigue:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \quad (1.6.2)$$

Considérese lo anterior calculando la variancia de la ya conocida muestra de la tabla 1.3.1.

$$\begin{aligned} s^2 &= \frac{(10 - 34.2)^2 + (54 - 34.2)^2 + (21 - 34.2)^2 + (33 - 34.2)^2 + (53 - 34.2)^2}{4} \\ &= \frac{1506.8}{4} = 376.7 \end{aligned}$$

La razón de dividir entre $n - 1$, en lugar de n , como podría haberse esperado, es por la consideración teórica conocida como *grados de libertad*. Al calcular la variancia, se dice que tiene $n - 1$ *grados de libertad*. Se razona como sigue. La suma de las desviaciones de los valores respecto a su media es igual a cero, como puede demostrarse. Entonces, si se conocen los valores de $n - 1$ de las desviaciones respecto a la media, se conoce el n -ésimo, ya que éste queda automáticamente determinado debido a la necesidad de que los n valores tengan como suma cero. El concepto de los grados de libertad se estudiará de nuevo posteriormente. Los estudiantes que estén interesados en aprender más sobre el tema en este momento, deben consultar el artículo escrito por Walker.¹

Cuando el número de observaciones es grande, puede resultar tedioso el uso de la ecuación 1.6.2. La fórmula siguiente puede ser menos

incómoda, especialmente cuando se utiliza una calculadora de escritorio o una portátil.

$$s^2 = \frac{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2}{n(n-1)} \quad (1.6.3)$$

Cuando se calcula la variancia de una población de valores, se siguen los procedimientos esbozados en los párrafos anteriores, excepto que se divide entre N , en lugar de entre $N-1$. Si se denota por σ^2 a la variancia de una población finita, las fórmulas que la definen y que facilitan su cálculo, respectivamente, son las siguientes:

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N} \quad (1.6.4)$$

$$\sigma^2 = \frac{N \sum_{i=1}^N x_i^2 - \left(\sum_{i=1}^N x_i \right)^2}{N \cdot N} \quad (1.6.5)$$

La variancia representa unidades cuadradas y, por lo tanto, no es una medida de dispersión apropiada cuando se desea expresar este concepto en términos de las unidades originales. Para obtener una medida de dispersión en las unidades originales, simplemente se toma la raíz cuadrada de la variancia. El resultado se conoce como *desviación estándar*. En general, la desviación estándar de una muestra está dada por la expresión:

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}} \quad (1.6.6)$$

La desviación estándar de una población finita se obtiene calculando la raíz cuadrada de la cantidad resultante de la ecuación 1.6.4.

El coeficiente de variación. La desviación estándar es útil como una medida de variación dentro de un determinado conjunto de datos. Sin embargo, cuando se desea comparar la dispersión en dos conjuntos de datos, el comparar las dos desviaciones estándar puede conducir

a resultados ilógicos. Puede ser que las dos variables que intervienen se midan en unidades distintas. Por ejemplo, es posible que se desee saber, para una cierta población, si los niveles de colesterol en el suero, medidos en mg por 100 ml, son más variables que el peso del cuerpo, medido en kilogramos.

Además, aun cuando se utilice la misma unidad de medición, las dos medias pueden ser bastante distintas. Si se compara la desviación estándar de los pesos de niños de primer año de primaria con la desviación estándar de los pesos de jóvenes de primer año de secundaria, puede encontrarse que la desviación estándar de estos últimos es numéricamente mayor que la de los primeros debido a que los propios pesos son mayores y no porque la dispersión sea mayor.

Lo que se necesita en situaciones como ésta es una medida de variación relativa, más que una de variación absoluta. Dicha medida se encuentra en el *coeficiente de variación*, que expresa la desviación estándar como un porcentaje de la media. La fórmula está dada por la expresión:

$$C.V. = \frac{s}{\bar{x}} (100) \quad (1.6.7)$$

Puede apreciarse que, como la media y la desviación estándar se expresan en la misma unidad de medición esta unidad se anula al calcular el coeficiente de variación. Lo que se tiene entonces es una medida que es independiente de la unidad de medición.

Supóngase que dos muestras de personas del sexo masculino proporcionan los resultados siguientes.

	<i>Muestra 1</i>	<i>Muestra 2</i>
Edad	25 años	11 años
Peso medio	72.5 kg	40 kg
Desviación estándar	5 kg	5 kg

La comparación de las desviaciones estándar podría llevar a concluir que las dos muestras poseen igual variabilidad. Sin embargo, si se calculan los coeficientes de variación para los individuos de 25 años de edad se tiene que:

$$C.V. = \frac{5}{72.5} (100) = 6.9$$

y para los de 11 años de edad,

$$C.V. = \frac{5}{40} (100) = 12.5$$

Si se comparan estos resultados, se tiene una impresión bastante distinta.

El coeficiente de variación también es útil para comparar los resultados obtenidos por diferentes personas que estén efectuando investigaciones que comprendan la misma variable.

Ejercicios

1.6.1 Con base en el ejercicio 1.5.1, calcule:

- a) El recorrido.
- b) La variancia, s^2 .
- c) La desviación estándar, s .

1.6.2 Con base en el ejercicio 1.5.2, calcule:

- a) El recorrido.
- b) La variancia, s^2 .
- c) La desviación estándar, s .
- d) El coeficiente de variación.

1.6.3 Con base en el ejercicio 1.5.3, calcule:

- a) El recorrido.
- b) La variancia, s^2 .
- c) La desviación estándar, s .
- d) El coeficiente de variación.

1.6.4 Con base en el ejercicio 1.5.4, calcule:

- a) El recorrido.
- b) La variancia, s^2 .
- c) La desviación estándar, s .
- d) El coeficiente de variación.

1.7 MEDIDAS DE TENDENCIA CENTRAL CALCULADAS A PARTIR DE DATOS AGRUPADOS

Una vez que se han agrupado los datos, es posible que se desee calcular alguna de las medidas descriptivas, como la media y la variancia. Con frecuencia, un investigador no tiene acceso a los datos en bruto en los que está interesado, pero tiene una distribución de frecuencias. Los datos suelen publicarse en la forma de una distribución de frecuencias sin que vayan acompañados de una lista de los valores individuales o medidas descriptivas. Quienes estén interesados en una medida de tendencia central o una medida de dispersión para estos datos, deben calcularla por sí mismos.

Cuando se agrupan los datos, las observaciones individuales pierden su identidad. Observando una distribución de frecuencias puede determinarse el número de observaciones que caen dentro de los diferentes intervalos de clase, pero no pueden determinarse los valores reales. Debido a esto, deben plantearse ciertas hipótesis acerca de los valores cuando se calcule una medida descriptiva a partir de datos agrupados. Como consecuencia de estas suposiciones, los resultados obtenidos son sólo aproximaciones de los valores verdaderos.

La media calculada a partir de datos agrupados. Al calcular la media a partir de datos agrupados, se supone que todos los valores que caen dentro de un determinado intervalo de clase se localizan en el *punto medio* del intervalo. El punto medio de un intervalo de clase se obtiene calculando la media de los límites superior e inferior del intervalo. El punto medio del primer intervalo de clase de la distribución que se muestra en la tabla 1.4.3 equivale a $(10 + 19)/2 = 29/2 = 14.5$. Los puntos medios de los intervalos de clase sucesivos pueden encontrarse sumando la amplitud del intervalo de clase al punto medio anterior. El punto medio del segundo intervalo de clase de la tabla 1.4.3, por ejemplo, equivale a $14.5 + 10 = 24.5$.

Para encontrar la media, se multiplica cada punto medio por la frecuencia correspondiente, se suman estos productos y se divide entre la suma de las frecuencias. Si los datos representan una muestra de observaciones, el cálculo de la media puede mostrarse simbólicamente como:

$$\bar{x} = \frac{\sum_{i=1}^k m_i f_i}{\sum_{i=1}^k f_i} \quad (1.7.1)$$

donde k = el número de intervalos de clase, m_i = el punto medio del i -ésimo intervalo de clase y f_i = la frecuencia del i -ésimo intervalo de clase.

Cuando se calcula la media a partir de datos agrupados, resulta conveniente preparar una tabla de trabajo como la tabla 1.7.1, que se ha preparado para los datos de la tabla 1.4.3.

Ahora puede calcularse la media.

$$\bar{x} = \frac{\sum_{i=1}^k m_i f_i}{\sum_{i=1}^k f_i} = \frac{2086.5}{57} = 36.6$$

El cálculo de una media a partir de una población de valores agrupados en un número finito de clases, se lleva a cabo exactamente en la misma forma.

Figura 1.7.1 Tabla de trabajo para calcular la media a partir de los datos agrupados de la tabla 1.4.3.

<i>Intervalo de clase</i>	<i>Punto medio de la clase m_i</i>	<i>Frecuencia de la clase f_i</i>	<i>$m_i f_i$</i>
10-19	14.5	5	72.5
20-29	24.5	19	465.5
30-39	34.5	10	345.0
40-49	44.5	13	578.5
50-59	54.5	4	218.0
60-69	64.5	4	258.0
70-79	74.5	2	149.0
Total		57	2086.5

La mediana: datos agrupados. Cuando se calcula la media a partir de datos agrupados, se supone que los valores dentro de un intervalo de clase se localizan en el punto medio; sin embargo, al calcular la mediana, se supone que dichos valores están distribuidos uniformemente en todo el intervalo.

El primer paso para calcular la mediana a partir de datos agrupados es localizar el intervalo de clase en el que se encuentra. Esto se hace

encontrando el intervalo de clase que contenga el valor $n/2$. Con base una vez más en los datos del ejemplo 1.4.1 con fines ilustrativos, recuérdese que se tienen 57 observaciones. El valor de $n/2$ es 28.5. Observando la tabla 1.4.3 se ve que los dos primeros intervalos de clase comprenden 24 de las observaciones, y que 34 de ellas están comprendidas en los tres primeros intervalos de clase. El valor de la mediana, por lo tanto, está en el tercer intervalo de clase. Está en algún punto entre 29.5 y 39.5 si se consideran los límites de clase verdaderos. La pregunta ahora es: ¿Qué tanto debe avanzarse en este intervalo antes de llegar a la mediana? Bajo la premisa de que los valores están distribuidos uniformemente a lo largo de todo el intervalo, parece razonable que se debe avanzar una distancia igual a $(28.5 - 24)/10$ de la distancia total del intervalo de clase debido a que, después de alcanzar el límite inferior del intervalo de clase que contiene a la mediana, se necesitan $4\frac{1}{2}$ observaciones más, y hay un total de 10 observaciones en el intervalo. El valor de la mediana equivale entonces al valor del límite inferior del intervalo que contiene a la mediana, más $4.5/10$ de la amplitud del intervalo. Para los datos de la tabla 1.4.3, se tiene que el valor de la mediana es de $29.5 + (4.5/10)(10) = 34$.

En general, la mediana puede calcularse a partir de datos agrupados mediante la siguiente fórmula:

$$\text{mediana} = L_i + \frac{j}{f_i}(U_i - L_i) \quad (1.7.2)$$

donde L_i = el límite inferior verdadero del intervalo que contiene a la mediana, U_i = el límite superior verdadero del intervalo que contiene a la mediana, j = el número de observaciones que aún faltan por alcanzar a la mediana una vez que se ha alcanzado el límite inferior del intervalo que contiene a la mediana y f_i = la frecuencia del intervalo que contiene a la mediana.

La moda: datos agrupados. Se ha definido la moda de un conjunto de valores como el valor que ocurre con más frecuencia. Cuando se designa la moda de datos agrupados, se refiere por lo general a la *clase modal*, donde la clase modal es el intervalo de clase con la frecuencia más alta. En el ejemplo 1.4.1 la clase modal sería la segunda clase, 20-29, o bien, 19.5-29.5, utilizando los límites de clase verdaderos. Si debe especificarse un sólo valor para la moda de datos agrupados, se toma como el punto medio de la clase modal. En el presente ejemplo,

éste es 24.5. La suposición que se hace es que todos los valores del intervalo caen en el punto medio.

1.8 LA VARIANCIA Y LA DESVIACIÓN ESTÁNDAR: DATOS AGRUPADOS

Al calcular la variancia y la desviación estándar a partir de datos agrupados, se supone que todos los valores que caen dentro de un determinado intervalo de clase se localizan en el punto medio del intervalo. Se recordará que ésta es la hipótesis que se planteó al calcular la media y la moda. Entonces, la variancia de una muestra está dada por la expresión:

$$s^2 = \frac{\sum_{i=1}^k (m_i - \bar{x})^2 f_i}{\sum_{i=1}^k f_i - 1} \quad (1.8.1)$$

donde los símbolos tienen las definiciones dadas en la ecuación 1.7.1.

En ocasiones puede preferirse utilizar la siguiente fórmula de cálculo de la variancia de la muestra:

$$s^2 = \frac{n \sum_{i=1}^k m_i^2 f_i - \left(\sum_{i=1}^k m_i f_i \right)^2}{n(n-1)} \quad (1.8.2)$$

donde

$$n = \sum_{i=1}^k f_i$$

La fórmula para definir a σ^2 es la misma que para s^2 , excepto que μ sustituye a $\bar{x}$ y el denominador es $\sum_{i=1}^k f_i$. La fórmula para calcular σ^2 tiene a $N \cdot N$ en el denominador, en lugar de $n(n-1)$.

Se ejemplificará el cálculo de la variancia y de la desviación estándar, utilizando tanto la fórmula que las define como la fórmula computacional, empleando los datos de la tabla 1.4.3. Para hacerlo, resultará útil otra tabla de trabajo como la tabla 1.8.1.

Tabla 1.8.1 Tabla de trabajo para calcular la variancia y desviación estándar de los datos agrupados de la tabla 1.4.3

(1) Intervalo de clase	(2) Punto medio de la clase m_i	(3) Frecuencia de la clase f_i	(4) $(m_i - \bar{x})$	(5) $(m_i - \bar{x})^2$	(6) $(m_i - \bar{x})^2 f_i$	(7) m_i^2	(8) $m_i^2 f_i$
10-19	14.5	5	-22.1	488.41	2442.05	210.25	1051.25
20-29	24.5	19	-12.1	146.41	2781.79	600.25	11404.75
30-39	34.5	10	-2.1	4.41	44.10	1190.25	11902.50
40-49	44.5	13	7.9	62.41	811.33	1980.25	25743.25
50-59	54.5	4	17.9	320.41	1281.64	2970.25	11881.00
60-69	64.5	4	27.9	778.41	3113.64	4160.25	16641.00
70-79	74.5	2	37.9	1436.41	2872.82	5550.25	11100.50
Total		57		3236.87	13347.37		89724.25
$\bar{x} = 36.6$							

Dividiendo el total de la columna 6 entre el total de la columna 3, menos 1, se tiene que:

$$s^2 = \frac{\sum_{i=1}^k (m_i - \bar{x})^2 f_i}{\sum_{i=1}^k f_i - 1} = \frac{13347.37}{56} = 238.3459$$

La desviación estándar es

$$s = \sqrt{238.3459} = 15.44$$

Si se utiliza la fórmula de cálculo de la ecuación 1.8.2, se tiene que:

$$s^2 = \frac{57(89724.25) - (2086.5)^2}{57(56)} = 238.3459$$

Ejercicios

En los siguientes ejercicios, considere a los conjuntos de datos como muestras.

1.8.1 Véase el ejercicio 1.4.1 y encuentre:

- a) La media.
- b) La mediana.
- c) La clase modal.
- d) La variancia.
- e) La desviación estándar.

1.8.2 Véase el ejercicio 1.4.2 y encuentre:

- a) La media.
- b) La mediana.
- c) La clase modal.
- d) La variancia.
- e) La desviación estándar.

1.8.3 Véase el ejercicio 1.4.3 y encuentre:

- a) La media.
- b) La mediana.
- c) La clase modal.
- d) La variancia.
- e) La desviación estándar.

1.8.4 Véase el ejercicio 1.4.4 y encuentre:

- a) La media.
- b) La mediana.
- c) La clase modal.
- d) La variancia.
- e) La desviación estándar.

1.8.5 Véase el ejercicio 1.4.5 y encuentre:

- a) La media.
- b) La mediana.
- c) La variancia.
- d) La desviación estándar.

1.8.6 Véase el ejercicio 1.4.6 y encuentre:

- a) La media.
- b) La mediana.
- c) La variancia.
- d) La desviación estándar.

1.9 LAS COMPUTADORAS Y EL ANÁLISIS BIOESTADÍSTICO

El uso generalizado relativamente reciente de las computadoras ha tenido un tremendo impacto sobre la investigación de las ciencias de la salud en general y en el análisis bioestadístico en particular. La necesidad de llevar a cabo largos y tediosos cálculos aritméticos como parte del análisis estadístico de datos perdura sólo en la memoria de aquellos investigadores y profesionistas cuyas carreras precedieron a

la llamada “revolución de las computadoras”. Las computadoras llevan a cabo un mayor número de cálculos más rápidos y mucho más precisos que los que pueden efectuar los especialistas humanos. El uso de las computadoras ha permitido que los investigadores dediquen más tiempo al mejoramiento de la calidad de los datos en bruto y a la interpretación de los resultados.

Existen programas de computadora grabados que permiten llevar a cabo más procedimientos estadísticos descriptivos e inferenciales que los que el investigador promedio puede necesitar. Algunos “paquetes” de procedimientos estadísticos que se utilizan ampliamente son los siguientes: *BMDP: Biomedical Computer Programs*,³ *SPSS Statistical Package for the Social Sciences*,⁴ *The IMSL Library*,⁵ *Minitab*⁶ y el *SAS*.⁷ En un artículo, Dixon y Jennrich⁸ describen 38 paquetes de programas estadísticos distintos. Dan información respecto a las máquinas en las cuales pueden analizarse los programas, requerimientos del núcleo de memoria, terminología de los programas, documentación disponible y otras fuentes de información. Los cálculos de muchos de los ejercicios de este libro pueden efectuarse mediante los programas de estos y otros paquetes de programas estadísticos.

En particular, la computadora es una herramienta útil para calcular medidas descriptivas y construir varias distribuciones a partir de grandes conjuntos de datos. El uso de una computadora evita la necesidad de utilizar las fórmulas de datos agrupados de las secciones 1.7 y 1.8 cuando se dispone también de los datos en bruto.

Los programas estadísticos difieren respecto a sus requerimientos de información, sus formatos de salida y los cálculos específicos que llevarán a cabo. El lector que desee utilizar una computadora para obtener las soluciones a los ejercicios de este libro debe conocer los programas que pueden utilizarse en su centro de cómputo para determinar, ante todo, si hay un programa que efectúe los cálculos requeridos. Una vez que se ha encontrado el programa apropiado, sus requerimientos de información deben estudiarse primero cuidadosamente antes de incorporar los datos de los ejercicios a la computadora. Por último, debe estudiarse el formato de información de salida del programa a fin de que pueda hacerse la correcta interpretación de los resultados. Quienes hayan estudiado un lenguaje de computación pueden, en algunos casos, desear escribir sus propios programas de computadora para aplicarlos a los ejercicios.

La utilidad de las computadoras en las ciencias de la salud no está limitada al análisis estadístico. Quien esté interesado en saber más acer-

ca del uso de las computadoras en biología, medicina y otras ciencias de la salud, debe consultar los libros escritos por Krasnoff,⁹ Ledley,¹⁰ Lindberg,¹¹ Sterling y Pollack¹² y Taylor.¹³

Los avances generales en el uso de las computadoras en biología, medicina y otros campos relacionados se reportan en varias revistas dedicadas al tema. Algunas de estas revistas son las de *Computers in Biology and Medicine*, *Computers and Biomedical Research*, *International Journal of Bio-Medical Computing*, *Computer Programs in Biomedicine* y *Computers and Medicine*.

1.10 RESUMEN

En este capítulo se ha definido a la estadística como un área de estudio que trata de la recolección y descripción de datos y obtención de inferencias. Al principio del capítulo se incorporó un vocabulario básico de estadística. Se explican varios procedimientos estadísticos descriptivos. Estos procedimientos incluyen la organización de los datos por medio del arreglo ordenado, la distribución de frecuencias, la distribución de frecuencias relativas, el histograma y el polígono de frecuencias. Se describen los conceptos de tendencia central y variación, junto con los métodos para calcular sus medidas más comunes: media, mediana, moda, recorrido, variancia y desviación estándar. Los conceptos y métodos se presentan de manera que sea posible el manejo tanto de datos agrupados como de no agrupados.

Preguntas y ejercicios de repaso.

1. Explique qué se entiende por estadística descriptiva.
2. Explique qué se entiende por inferencia estadística.
3. Defina:
 - a) Estadística
 - b) Bioestadística
 - c) Variable
 - d) Variable cuantitativa
 - e) Variable cualitativa
 - f) Variable aleatoria
 - g) Población

- h) Población finita
- i) Población infinita
- j) Muestra
- k) Variable discreta
- l) Variable continua

4. ¿Qué es un arreglo ordenado?
5. Defina y compare las características de la media, mediana y moda.
6. ¿Cuáles son las ventajas y limitaciones del recorrido como una medida de dispersión?
7. ¿Qué es una distribución de frecuencias?
8. ¿Qué es una distribución de frecuencias relativas?
9. Explique la diferencia que existe entre una estadística y un parámetro.
10. Explique la razón de utilizar $n - 1$ para calcular la variancia de la muestra.
11. ¿Para qué se utiliza el coeficiente de variación?
12. ¿Para qué se utiliza la regla de Sturges?
13. ¿Qué es un histograma?
14. ¿Qué es un polígono de frecuencias?
15. ¿Qué suposiciones deben hacerse al calcular la media a partir de datos agrupados?; ¿cuáles respecto a la mediana?; ¿cuáles respecto a la variancia?
16. ¿Qué se entiende por el término *límites de clase verdaderos*?
17. Describa, a partir de su campo de estudio, una población de datos donde sea útil el conocimiento de la tendencia central y la dispersión. Obtenga los valores sintéticos reales o realísticos de dicha población y calcule la media, mediana, moda, variancia y desviación estándar utilizando las técnicas para datos no agrupados.
18. Reúna un conjunto de datos reales o realísticos a partir de su campo de estudio y construya una distribución de frecuencias, una distribución de frecuencias relativas, un histograma y un polígono de frecuencias.
19. Calcule la media, mediana, clase modal, variancia y desviación estándar para los datos del ejercicio 10 utilizando las técnicas para datos agrupados.
20. Encuentre un artículo de una revista de su campo de estudio en el cual se haya calculado alguna medida de tendencia central y de dispersión.
21. En un estudio diseñado para investigar la efectividad de un anestésico local potencial, varias dosis se administraron a 15 anima-

les de laboratorio. Se hizo un registro de la duración (en minutos) de la respuesta. Los resultados fueron los siguientes:

<i>Número del animal</i>	<i>Duración de la respuesta</i>	<i>Número del animal</i>	<i>Duración de la respuesta</i>
1	31	9	22
2	14	10	20
3	19	11	32
4	17	12	19
5	34	13	27
6	25	14	11
7	17	15	23
8	35		

Calcule la media, mediana, variancia y desviación estándar para estos datos de la muestra.

22. La siguiente tabla muestra el consumo diario de grasas (en gramos) de una muestra de 150 hombres adultos en un país en vías de desarrollo. Haga una distribución de frecuencias y un histograma para los siguientes datos. Calcule la media, mediana, variancia y desviación estándar.

22	62	77	84	91	102	117	129	137	141
42	56	78	73	96	105	117	125	135	143
37	69	82	93	93	100	114	124	135	142
50	77	81	94	97	102	119	125	138	142
46	89	88	99	95	100	116	121	131	152
63	85	81	94	93	106	114	127	133	155
51	80	88	98	97	106	119	122	134	151
52	70	76	95	107	105	117	128	144	150
68	79	82	96	109	108	117	120	147	153
67	75	76	92	105	104	117	129	148	164
62	85	77	96	103	105	116	132	146	168
53	72	72	91	102	101	128	136	143	164
65	73	83	92	103	118	127	132	140	167
68	75	89	95	107	111	128	139	148	168
68	79	82	96	109	108	117	130	147	153

23. Los siguientes valores son los niveles de hemoglobina (g/100 ml) de 10 niños que reciben tratamiento para anemia hemolítica:

9.1	8.3
10.0	9.9
11.4	9.1
12.4	7.5
9.8	6.7

Calcule la media, mediana, variancia y desviación estándar de esta muestra.

24. Veinte mujeres postmenopáusicas a quienes se les había practicado histerectomía durante su período de premenopausia recibieron una terapia diaria de estrógeno sintético durante cuatro meses. Después de dicho tratamiento, se registraron los siguientes valores de estrógeno:

61	58	54	54
81	56	81	75
61	80	92	59
63	83	71	58
82	92	69	94

Calcule la media, mediana, variancia y desviación estándar de esta muestra.

25. La siguiente tabla muestra la distribución de edades de casos de una cierta enfermedad reportada durante un año en un estado particular.

<i>Edad</i>	<i>Número de casos</i>
5-14	5
15-24	10
25-34	20
35-44	22
45-54	13
55-64	5
Total	75

Calcule la media, mediana, variancia y desviación estándar de esta muestra.

REFERENCIAS

Referencias citadas

1. Helen M. Walker, "Degrees of Freedom," *The Journal of Educational Psychology*, 31 (1940), 253-269.
2. H. A. Sturges, "The Choice of a Class Interval," *Journal of the American Statistical Association*, 21 (1926), 65-66.
3. W. J. Dixon y M. B. Brown, editores *BMDP: Biomedical Computer Programs P-Series*, University of California Press, Berkeley, 1979.
4. Norman H. Nie, C. Hadlai Hull, Jean G. Jenkins, Karin Steinbrenner, y Dale H. Bent, *SPSS Statistical Package for the Social Sciences*, segunda edición, McGraw-Hill, Nueva York, 1975.
5. *The IMSL Library*, Vols. 1-3, International Mathematical and Statistical Libraries, Inc., Dallas, Texas, 1979.
6. Thomas A. Ryan Jr., Brian L. Joiner y Barbara F. Ryan, *Minitab Student Handbook*, Duxbury Press, North Scituate, Mass., 1976.
7. Anthony J. Barr, James H. Goodnight, John P. Sall y June T. Helwig, *A User's Guide to SAS 79*, SAS Institute, Inc., Raleigh, N. C., 1979.
8. W. J. Dixon y R. L. Jennrich, "Scope, Impact, and Status of Packaged Statistical Programs," *Annual Review of Biophysics and Bioengineering*, 1 (1972), 505-528.
9. Sidney O. Krasnoff, *Computers in Medicine*, Charles C. Thomas, Springfield, Ill., 1967.
10. Robert Steven Ledley, *Use of Computers in Biology and Medicine*, McGraw-Hill, Nueva York, 1965.
11. Donald A. B. Lindberg, *The Computer and Medical Care*, Charles C. Thomas, Springfield, Ill., 1968.
12. Theodor D. Sterling y Seymour V. Pollack, *Computers and the Life Sciences*, Columbia University Press, Nueva York, 1965.
13. Thomas R. Taylor, *The Principles of Medical Computing*, Blackwell Scientific Publications, Oxford, 1967.

Otras referencias, libros

1. Wilfred J. Dixon y Frank J. Massey, Jr., *Introduction to Statistical Analysis*, tercera edición, McGraw-Hill, Nueva York, 1969.
2. A. Bradford Hill, *Principles of Medical Statistics*, octava edición, Oxford University Press, Nueva York, 1967.

3. George W. Snedecor y William G. Cochran, *Statistical Methods*, séptima edición. The Iowa State University Press, Ames, 1967.
4. George H. Weinberg y John A. Schumaker, *Statistics: An Intuitive Approach*, segunda edición, Wadsworth, Belmont, Cal., 1980.
5. Bernard G. Greenberg, "Biostatistics," en Hugh Rodman Leavell y E. Gurney Clark, *Preventive Medicine*, McGraw-Hill, Nueva York, 1965.

Otras referencias, artículos de revistas

1. I. Altman y A. Ciocco, "Introduction to Occupational Health Statistics I," *Journal of Occupational Medicine*, 6 (1964), 297-301.
2. A. R. Feinstein, "Clinical Biostatistics I, A New Name and Some Other Changes of the Guard," *Clinical Pharmacology and Therapeutics*, (1970), 135-138.
3. Alva R. Feinstein, "Clinical Biostatistics VI, Statistical Malpractice and the Responsibility of a Consultant," *Clinical Pharmacology and Therapeutics*, 11 (1970), 898-914.
4. Lyon Hyams, "The Practical Psychology of Biostatistical Consultation," *Biometrics*, 27 (1971), 201-211.
5. Johannes Ipsen, "Statistical Hurdles in the Medical Career," *American Statistician*, 19 (jun. 1965), 22-24.
6. Richard K. Means, "Interpreting Statistics: An Art," *Nursing Outlook* 13 (mayo 1965), 34-37.
7. E. S. Pearson, "Studies in the History of Probability and Statistics. XIV Some Incidents in the Early History of Biometry and Statistics, 1890-94," *Biometrika*, 52 (1965), 3-18.
8. Harold M. Schoolman, "Statistics in Medical Research," *The New England Journal of Medicine*, 280 (1969), 218-19.
9. Stanley Schor e Irving Karten, "Statistical Evaluation of Medical Journal Manuscripts," *Journal of the American Medical Association*, 195 (1966), 1123-1128.
10. H. C. Selvin y A. Stuart "Data—Dredging Procedures in Surgery Analysis," *American Statistician*, 20 (jun. 1966), 20-22.
11. Robert L. Stearman, "Statistical Concepts in Microbiology," *Bacteriological Reviews*, 19 (1955), 160-215.
12. Harry E. Ungerleider y Courtland C. Smith, "Use and Abuse of Statistics," *Geriatrics*, 22 (feb. 1967), 112-120.
13. James P. Zimmerman, "Statistical Data and Their Use," *Physical Therapy*, 49 (1969), 301-302.

14. Robert I. Rollwagen, "Statistical Methodology in Medicine," *Canadian Medical Association Journal*, 112 (1975), 677.
15. Editorial, "Limitations of Computers in Medicine," *Canadian Medical Association Journal*, 104 (1971), 234-235.
16. Carol M. Newton, "Biostatistical Computing," *Federation Proceedings, Federation of American Societies for Experimental Biology*, 33 (1974), 2317-2319.

2

Algunos conceptos básicos de probabilidad

2.1 INTRODUCCIÓN

La teoría de la probabilidad proporciona la base para la inferencia estadística. Sin embargo, esta teoría, que es una rama de las matemáticas, no es el tema principal de este libro y, como consecuencia, sólo se estudian aquí sus conceptos fundamentales. Los estudiantes que deseen dedicarse a este tema deben consultar los libros sobre probabilidad de Bates,¹ Dixon,² Mosteller y colaboradores,³ Earl y colaboradores,⁴ Berman,⁵ Hausner,⁶ y Mullins y Rosen.⁷ También encontrarán útiles los libros sobre estadística matemática de Freund,⁸ Hogg y Craig⁹ y Mood, Graybill y Boes.¹⁰ Para quienes estén interesados en la historia de la probabilidad, se les recomiendan los libros de Todhunter¹¹ y David.¹² Por ejemplo, en este último se encuentra que el primer matemático que calculó correctamente una probabilidad teórica fue el italiano Girolamo Cardano, quien vivió de 1501 a 1576. Los objetivos de este capítulo son ayudar al estudiante a adquirir alguna habilidad matemática en el área de la probabilidad y ayudarlo a comprender los conceptos más importantes. El progreso logrado a lo largo de estas líneas contribuirá en gran medida al éxito que tenga el estudiante en comprender los procedimientos de inferencia estadística que se presentan posteriormente en este libro.

El concepto de probabilidad no es extraño para quienes trabajan en las ciencias de la salud, y suele encontrarse en la comunicación co-

tidiana. Por ejemplo, puede escucharse decir a un médico que un paciente tiene un 50% de probabilidad de sobrevivir a una cierta operación. Otro médico puede decir que está un 95% seguro de que un paciente tiene una determinada enfermedad. Una enfermera de salud pública puede decir que nueve de diez veces un cierto cliente cancelará una cita. Así, se tiene la costumbre de medir la probabilidad de ocurrencia de algún evento por medio de un número entre cero y uno. Cuanto más probable sea el evento, más próximo estará el número a uno; y cuanto menos probable sea el mismo, más próximo estará el número a cero. Un evento que no puede ocurrir tiene una probabilidad de cero y otro que con seguridad ocurre tiene una probabilidad de uno.

2.2 DOS PUNTOS DE VISTA DE LA PROBABILIDAD: OBJETIVO Y SUBJETIVO

Hasta hace muy poco tiempo, la probabilidad era concebida por los estadísticos y matemáticos sólo como un fenómeno *objetivo* derivado de procesos objetivos.

El concepto de *probabilidad objetiva* puede caracterizarse aún más bajo los títulos de 1) *probabilidad clásica*, o *a priori* y 2) el concepto de probabilidad de *frecuencia relativa*, o *a posteriori*.

El estudio clásico de la probabilidad data del siglo XVII y del trabajo de dos matemáticos, Pascal y Fermat.^{11, 12} Gran parte de esta teoría se desarrolló a través de los intentos por resolver los problemas relacionados con los juegos de azar, como el lanzamiento de los dados. Los ejemplos de los juegos de azar ilustran muy bien los principios que intervienen en la probabilidad clásica. Por ejemplo, si se lanza un dado no cargado de seis lados, la probabilidad de que se observe un 1 es igual a $1/6$ y es la misma para las otras cinco caras. Si se elige al azar una carta de una baraja normal bien barajada, la probabilidad de elegir una de corazones es de $13/52$. Las probabilidades como éstas se calculan por el proceso de razonamiento abstracto. No es necesario lanzar un dado o tomar una carta para calcular las probabilidades anteriores. En el lanzamiento del dado se dice que es *igualmente probable* observar cada uno de los seis lados si no existe razón en favor de alguno de ellos. Asimismo, si no existe razón en favor de la elección de una carta en particular de una baraja, se dice que es igualmente probable tomar cada una de las 52 cartas. Puede definirse la probabilidad en el sentido clásico de la manera siguiente.