

Figura 3.6.8 Curva normal unitaria que muestra $P(-2.55 < z < 2.55)$.

Solución. La figura 3.6.8 muestra el área deseada. La tabla F da el área entre $-\infty$ y 2.55, la cual se encuentra localizando el 2.5 en la columna de la extrema izquierda de la tabla y, a continuación, dirigiéndose horizontalmente hasta llegar al valor que se encuentra en la columna encabezada por .05. Se encuentra que esta área es de .9946. Si se observa la figura que se trazó, se ve que ésta es más del área deseada. Se necesita restar de .9946 el área hacia la izquierda de -2.55 . Utilizando la tabla F se verifica que el área a la izquierda de -2.55 es .0054. Por lo tanto, la probabilidad deseada es

$$P(-2.55 < z < 2.55) = .9946 - .0054 = .9892$$

Supóngase que se hubiera deseado encontrar la probabilidad de que z estuviera entre -2.55 y 2.55 , inclusive. La probabilidad deseada se expresa como $P(-2.55 \leq z \leq 2.55)$. Entonces, como se señaló en la sección 3.5, $P(z = z_0) = 0$, $P(-2.55 \leq z \leq 2.55) = P(-2.55 < z < 2.55) = .9892$.

Ejemplo 3.6.3

¿Qué proporción de valores z están entre -2.74 y 1.53 ?

Solución. La figura 3.6.9 muestra el área deseada. En la tabla F se encuentra que el área entre $-\infty$ y 1.53 es .9370 y que el área entre $-\infty$ y -2.74 es .0031. Para obtener la probabilidad deseada, se resta .0031 de .9370. Es decir,

$$P(-2.74 \leq z \leq 1.53) = .9370 - .0031 = .9339$$




Figura 3.6.9 Curva normal unitaria que muestra la proporción de los valores de z entre $z = -2.74$ y $z = 1.53$.




Figura 3.6.10 Distribución normal unitaria que muestra $P(z \geq 2.71)$.

Ejemplo 3.6.4

Dada la distribución normal unitaria, encuentre $P(z \geq 2.71)$.

Solución. El área deseada se muestra en la figura 3.6.10. Se obtiene el área hacia la derecha de $z = 2.71$ restando el área entre $-\infty$ y 2.71 de 1. Así, se tiene que

$$\begin{aligned} P(z \geq 2.71) &= 1 - P(z \leq 2.71) \\ &= 1 - .9966 \\ &= .0034 \end{aligned}$$

Ejemplo 3.6.5

Dada la distribución normal unitaria, encuentre $P(.84 \leq z \leq 2.45)$.

Solución. El área deseada se muestra en la figura 3.6.11. Se obtiene primero el área entre $-\infty$ y 2.45 y, de ésta, se resta el área en-

tre $-\infty$ y .84. En otras palabras, se tiene que

$$\begin{aligned} P(.84 \leq z \leq 2.45) &= P(z \leq 2.45) - P(z \leq .84) \\ &= .9929 - .7995 \\ &= .1934 \end{aligned}$$




Figura 3.6.11 Curva normal unitaria que muestra $P(.84 \leq z \leq 2.45)$

Ejercicios

Dada la distribución normal unitaria, encuentre:

- 3.6.1 El área bajo la curva entre $z = 0$ y $z = 1.43$.
- 3.6.2 La probabilidad de que una z seleccionada al azar tenga un valor entre $z = -2.87$ y $z = 2.64$.
- 3.6.3. $P(z \geq .55)$.
- 3.6.4. $P(z \geq -.55)$.
- 3.6.5. $P(z < -2.33)$.
- 3.6.6. $P(z < 2.33)$.
- 3.6.7. $P(-1.96 \leq z \leq 1.96)$.
- 3.6.8. $P(-2.58 \leq z \leq 2.58)$.
- 3.6.9. $P(-1.65 \leq z \leq 1.65)$.
- 3.6.10. $P(z = .74)$.

Aplicaciones. Aunque su importancia en el campo de la estadística es indiscutible, debe tenerse en cuenta que la distribución normal no es una ley a la que se apeguen todas las características medibles que se presentan en la naturaleza. Sin embargo, es cierto que muchas de

esas características están distribuidas casi en forma de una distribución normal. Suelen citarse como ejemplos la estatura e inteligencia humanas. Por otra parte, Elverback y colaboradores⁴ y Nelson y colaboradores⁵ han señalado que muchas distribuciones relevantes para el campo de la salud no pueden describirse convenientemente a través de una distribución normal. Siempre que se sabe que una variable aleatoria está distribuida en forma aproximadamente normal o cuando se carece de un conocimiento completo, se considera razonable hacer esta suposición, el estadístico recibe una ayuda considerable en su esfuerzo por resolver los problemas prácticos relativos a esta variable.

Existen varias otras razones por las que la distribución normal es tan importante en la estadística, y se considerarán a su debido tiempo. Por ahora, véase cómo pueden contestarse algunas preguntas sencillas de probabilidad acerca de variables aleatorias cuando se sabe, o se tienen motivos para suponer que, al menos, están distribuidas en forma aproximadamente normal.

Ejemplo 3.6.6

Un fisioterapeuta nota que las calificaciones obtenidas en cierta prueba de destreza manual están distribuidas en forma aproximadamente normal con una media de 10 y una desviación estándar de 2.5. Si un individuo seleccionado al azar realiza la prueba, ¿cuál es la probabilidad de que obtenga una calificación de 15 o más?

Solución. Primero debe trazarse un esquema de la distribución y sombrear el área correspondiente a la probabilidad de interés. Esto se ha hecho en la figura 3.6.12.




Figura 3.6.12 Distribución normal para aproximar la distribución de las calificaciones en una prueba de destreza manual.




Figura 3.6.13 Distribución normal de las calificaciones de destreza manual (x) y la distribución normal unitaria (z).

Si la distribución en cuestión fuera la normal unitaria, con una media de 0 y una desviación estándar de 1, podría utilizarse la tabla F y encontrar la probabilidad con poco esfuerzo. Afortunadamente, cualquier distribución normal puede transformarse en la normal unitaria. Lo que tiene que hacerse es transformar todos los valores de X en los correspondientes valores de z . Esto significa que la media de X debe hacerse 0, la media de z . En la figura 3.6.13 se muestran ambas distribuciones. Debe determinarse qué valor de z , por decir z_0 , corresponde a un x de 15. Esto se lleva a cabo mediante la siguiente fórmula:

$$z = \frac{x - \mu}{\sigma} \quad (3.6.3)$$

la cual transforma cualquier valor de x en cualquier distribución normal al valor correspondiente de z en la distribución normal unitaria. Para el presente ejemplo se tiene que

$$z = \frac{15 - 10}{2.5} = \frac{5}{2.5} = 2$$

Entonces, el valor de z_0 que se busca es 2.

Examínense ahora estas relaciones con más cuidado. Se observa que la distancia desde la media, 10, hasta el valor de x de interés, 15, es de $15 - 10 = 5$, que es una distancia de dos desviaciones estándar. Cuando se transforman los valores de x en valores de z , la distancia del valor de z de interés a partir de su media, 0, es igual a la distancia del valor correspondiente de x a partir de su media, 10, en unidades de desviación estándar. Se ha visto que esta última distancia es de 2 desviaciones estándar. En la distribución z , una desviación estándar es igual a uno y, en consecuencia, el punto sobre la escala z localizado a una distancia de 2 desviaciones estándar de 0 es $z = 2$, que es el resultado que se obtuvo utilizando la fórmula. Consultando la tabla F, se encuentra que el área a la derecha de $z = 2$ es .0228. La discusión anterior puede resumirse como sigue:

$$P(x \geq 15) = P\left(z \geq \frac{15 - 10}{2.5}\right) = P(z \geq 2) = .0228$$

Para dar respuesta a la pregunta original, se dice que la probabilidad de que un individuo seleccionado al azar que realice la prueba obtenga una calificación de 15 o más es de .0228.

Ejemplo 3.6.7

Supóngase que se sabe que los pesos de cierto grupo de individuos están distribuidos en forma aproximadamente normal con una media de 70 kg y una desviación estándar de 12.5 kg. ¿Cuál es la probabilidad de que una persona seleccionada al azar de este grupo pese entre 50 y 85 kg?

Solución. En la figura 3.6.14 se muestra la distribución de los pesos y la distribución z a la cual se transforman los valores originales, con el fin de determinar las probabilidades deseadas. Se encuentra que el valor de z correspondiente a un x de 50 es

$$z = \frac{50 - 70}{12.5} = -1.6$$

Asimismo, para $x = 85$ se tiene que

$$z = \frac{85 - 70}{12.5} = 1.2$$




Figura 3.6.14 Distribución de pesos (x) y la distribución normal unitaria correspondiente (z).

En la tabla F se encuentra que el área entre $-\infty$ y -1.6 es de .0548 y que el área entre $-\infty$ y 1.2 es de .8849. El área deseada es la diferencia entre estos valores, $.8849 - .0548 = .8301$. Para resumir, se tiene que

$$\begin{aligned}
 P(100 \leq x \leq 170) &= P\left(\frac{100 - 140}{25} \leq z \leq \frac{170 - 140}{25}\right) \\
 &= P(-1.6 \leq z \leq 1.2) \\
 &= P(-\infty \leq z \leq 1.2) - P(-\infty \leq z \leq -1.6) \\
 &= .8849 - .0548 \\
 &= .8301
 \end{aligned}$$

Entonces, la probabilidad buscada en la pregunta original es de .8301.

Ejercicios

3.6.11 Supóngase que las edades en las que se adquiere cierta enfermedad están distribuidas en forma aproximadamente normal con una media de 11.5 años y una desviación estándar de 3 años. Un niño acaba de contraer dicha enfermedad. ¿Cuál es la probabilidad de que el niño tenga:

- a) Entre $8 \frac{1}{2}$ y $14 \frac{1}{2}$ años de edad?
- b) Más de 10 años de edad?
- c) Menos de 12?

3.6.12 En los estudios dactiloscópicos, una importante característica cuantitativa es el número total de surcos para los 10 dedos de un individuo. Supóngase que los números totales de surcos de los individuos de cierta población están distribuidos en forma aproximadamente normal con una media de 140 y una desviación estándar de 50. Encuentre la probabilidad de que un individuo seleccionado al azar de dicha población tenga un número de surcos:

- a) De 200 o más
- b) Menor de 100.
- c) Entre 100 y 200.
- d) Entre 200 y 250.

3.6.13 Si las capacidades de la cavidad craneana de los individuos de cierta población están distribuidas en forma aproximadamente normal con una media de 1,400 cc y una desviación estándar de 125, encuentre la probabilidad de que una persona seleccionada al azar de dicha población tenga una capacidad de cavidad craneana:

- a) Mayor de 1,450 cc.
- b) Menor de 1,350 cc.
- c) Entre 1,300 y 1,500 cc.

3.6.14 Supóngase que la duración promedio de la internación en un hospital de enfermedades crónicas para cierto tipo de paciente es de 60 días con una desviación estándar de 15. Si es lógico suponer una distribución aproximadamente normal de las duraciones de la internación, encuentre la probabilidad de que un paciente seleccionado al azar de dicho grupo tenga una duración de internación:

- a) De más de 50 días.
- b) De menos de 30 días.
- c) Entre 30 y 60 días.
- d) De más de 90 días.

3.6.15 Si las concentraciones de colesterol total para cierta población están distribuidas en forma aproximadamente normal con una media de 200 mg/100 ml y una desviación estándar de 20 mg/100 ml, encuentre la probabilidad de que un individuo seleccionado al azar de dicha población tenga una concentración de colesterol:

- a) Entre 180 y 200 mg/100 ml.
- b) Mayor de 225 mg/100 ml.
- c) Menor de 150 mg/100 ml.
- d) Entre 190 y 210 mg/100 ml.

3.6.16 Dada una población con distribución normal con una media de 75 y una variancia de 625, encuentre:

- a) $P(50 \leq x \leq 100)$.
- b) $P(x > 90)$.
- c) $P(x < 60)$.
- d) $P(x \geq 85)$.
- e) $P(30 \leq x \leq 110)$.

3.7 RESUMEN

En el presente capítulo se desarrollaron aún más los conceptos de probabilidad descritos en el capítulo anterior. Se estudiaron los conceptos de variables aleatorias discretas y continuas y sus distribuciones de probabilidad. En particular, se examinaron con bastante detalle dos distribuciones discretas de probabilidad, la binomial y la de Poisson, y una distribución continua de probabilidad, la distribución normal. Se ha visto en qué forma estas distribuciones teóricas permiten hacer ciertas afirmaciones de probabilidad acerca de ciertas variables aleatorias que son de interés para el profesional en salud pública.

Preguntas y ejercicios de repaso

1. ¿Qué es una variable aleatoria discreta? Dé tres ejemplos que sean de interés para el profesional en salud pública.
2. ¿Qué es una variable aleatoria continua? Dé tres ejemplos de interés para el profesional en salud pública.

3. Defina la distribución de probabilidad de una variable aleatoria discreta.
4. Defina la distribución de probabilidad de una variable aleatoria continua.
5. ¿Qué es una distribución de probabilidad acumulada?
6. ¿Qué es un ensayo de Bernoulli?
7. Describa la distribución binomial.
8. Dé un ejemplo de una variable aleatoria que siga una distribución binomial.
9. Describa la distribución de Poisson.
10. Dé un ejemplo de una variable aleatoria que siga una distribuida de acuerdo a la ley de Poisson.
11. Describa la distribución normal.
12. Describa la distribución normal unitaria y diga cómo se utiliza en la estadística.
13. Dé un ejemplo de una variable aleatoria que esté, al menos, distribuida en forma aproximadamente normal.
14. Utilizando los datos del ejemplo anterior, demuestre el uso de la distribución normal unitaria para contestar las preguntas de probabilidad relacionadas con la variable seleccionada.
15. El método habitual de enseñanza de una destreza particular de cuidado de sí mismo para personas con retraso mental es eficaz en el 50 por ciento de los casos. Se ensayó un nuevo método en 10 personas. Si el nuevo método no es mejor que el estándar, ¿cuál es la probabilidad de que siete o más personas aprendan dicha destreza?
16. Los registros del personal de un hospital grande muestran que el 10 por ciento de los empleados de administración y mantenimiento renuncian dentro del año posterior a su contratación. Si 10 nuevos empleados han sido contratados recientemente:
 - a) ¿cuál es la probabilidad de que exactamente la mitad de ellos continúen trabajando al cabo de un año?
 - b) ¿cuál es la probabilidad de que todos estén trabajando al cabo de un año?
 - c) ¿cuál es la probabilidad de que tres de los 10 renuncien antes de que concluya el año?
17. En cierto país en vías de desarrollo, el 30 por ciento de los niños está desnutrido. En una muestra al azar de 25 niños de esta área, ¿cuál es la probabilidad de que el número de niños desnutridos sea

- a) exactamente de 10?
 - b) menor de cinco?
 - c) de cinco o más?
 - d) entre tres y cinco, inclusive?
 - e) menor de siete, pero mayor de 4?
18. En promedio, dos estudiantes por hora acuden a la sala de primeros auxilios de una escuela primaria.
- a) ¿Cuál es la probabilidad de que durante una hora determinada tres estudiantes acudan a la sala de primeros auxilios?
 - b) ¿Cuál es la probabilidad de que durante una hora determinada dos o menos estudiantes acudan a la sala de primeros auxilios?
 - c) ¿Cuál es la probabilidad de que entre tres y cinco estudiantes, inclusive, acudan a la sala de primeros auxilios durante una hora determinada?
19. En promedio, cinco fumadores pasan por la esquina de cierta calle cada diez minutos. ¿Cuál es la probabilidad de que durante un período de diez minutos el número de fumadores que pasan por esa esquina sea de
- a) seis o menos?
 - b) siete o más?
 - c) exactamente ocho?
20. En cierta área metropolitana hay un promedio de un suicidio por mes. ¿Cuál es la probabilidad de que durante un determinado mes el número de suicidios sea
- a) mayor de uno?
 - b) menor de uno?
 - c) mayor de tres?
21. El coeficiente intelectual de individuos admitidos a una escuela estatal para retrasados mentales muestra una distribución aproximadamente normal con una media de 60 y una desviación estándar de 10.
- a) Encuentre la proporción de individuos con un coeficiente intelectual mayor de 75.
 - b) ¿Cuál es la probabilidad de que un individuo elegido al azar tenga un coeficiente intelectual entre 55 y 75?
 - c) Encuentre $P(50 \leq X \leq 70)$.

22. Una enfermera supervisora ha encontrado que las enfermeras en servicio, en promedio, tardan 10 minutos en realizar una tarea. Si los tiempos requeridos para concluir la tarea están distribuidos en forma aproximadamente normal con una desviación estándar de 3 minutos, encuentre:
- a) La proporción de enfermeras que concluyen la tarea en menos de cuatro minutos.
 - b) La proporción de enfermeras que requieren más de cinco minutos para concluir la tarea.
 - c) La probabilidad de que una enfermera, a quien recientemente se le ha asignado la tarea, la concluya al cabo de tres minutos.
23. Las calificaciones obtenidas en cierta prueba de aptitudes por estudiantes de enfermería están distribuidas en forma aproximadamente normal con una media de 500 y una variancia de 10,000.
- a) ¿Qué proporción de calificaciones están por debajo de 200?
 - b) Una persona está a punto de hacer la prueba; ¿cuál es la probabilidad de que obtenga una calificación de 650 o más?
 - c) ¿Qué proporción de calificaciones está entre 350 y 675?
24. Dada una variable binomial con una media de 20 y una variancia de 16, encuentre n y p .
25. Supóngase que una variable X muestra una distribución normal con una desviación estándar de 10. Dado que .0985 de los valores de X son mayores de 70, ¿cuál es el valor medio de X ?

REFERENCIAS

Referencias citadas

1. Norman L. Johnson y Samuel Kotz, *Discrete Distributions*, Houghton-Mifflin, Boston, 1969.
2. Frank A. Haight, *Handbook of the Poisson Distribution*, Wiley, Nueva York, 1967.
3. Helen M. Walker, *Studies in the History of Statistical Method*, The Williams and Wilkins Company, Baltimore, 1931.
4. Lila R. Elveback, Claude L. Gulliver y F. Raymond Deating, Jr., "Health, Normality and the Ghost of Gauss," *The Journal of the American Medical Association*, 211 (1970), 69-75.

5. Jerald C. Nelson, Elizabeth Haynes, Rodney Willard y Jan Kuzma, "The Distribution of Euthyroid Serum Protein-Bound Iodine Levels," *The Journal of the American Medical Association*, 216 (1971), 1639-1641.

Otras referencias

1. Sam Duker, "The Poisson Distribution in Educational Research," *Journal of Experimental Education*, 23 (1955), 265-269.
2. M. S. Lafleur, P. R. Hinrichsen, P. C. Landry y R. B. Moore, "The Poisson Distribution: An Experimental Approach to Teaching Statistics," *Physics Teacher*, 10 (1972), 314-321.

4

Algunas distribuciones muestrales importantes

4.1 INTRODUCCIÓN

Antes de examinar el tema principal del presente capítulo, se revisarán los puntos sobresalientes de lo que se ha tratado hasta aquí. En el capítulo 1 se hizo énfasis en la organización y resumen de los datos. Aquí se encuentran los conceptos de tendencia central y dispersión, y se aprende cómo calcular sus medidas descriptivas. En el capítulo 2 se estudiaron las ideas fundamentales de la probabilidad y en el capítulo 3 se consideró el concepto de una distribución de probabilidad. Estos conceptos son fundamentales para comprender la inferencia estadística, el tema que abarca la mayor parte de este libro.

El presente capítulo sirve de enlace entre el material estudiado, que es esencialmente de naturaleza descriptiva, y la mayoría de los temas restantes, que se han seleccionado del área de la inferencia estadística.

4.2 MUESTREO ALEATORIO SIMPLE

En términos generales, existen dos tipos de muestreo, el *muestreo probabilístico* y el *muestreo no probabilístico* pero, en este texto, se estudiará sólo el primero. La razón es que únicamente para el muestreo probabilístico existen procedimientos estadísticamente seguros que permiten inferir, a partir de la muestra extraída, la población de interés.

Definición

Una muestra probabilística es una muestra extraída de una población de tal manera que todo miembro de esta última tenga una probabilidad conocida de estar incluido en la muestra.

De cualquier población finita de tamaño N , puede extraerse un cierto número de muestras distintas de tamaño n . (Se hace esta afirmación bajo la hipótesis de que N es lo suficientemente grande como para garantizar el muestreo. Como regla, por razones obvias, las poblaciones pequeñas no se muestrean, sino que se estudia la población completa).

Definición

Si se extrae una muestra de tamaño n de una población de tamaño N , de tal manera que cada muestra posible de tamaño n tenga la misma probabilidad de ser seleccionada, la muestra recibe el nombre de muestra aleatoria simple.

La mecánica de extraer una muestra que satisfaga la definición de una muestra aleatoria simple se conoce como *muestreo aleatorio simple*.

Más adelante se demostrará el procedimiento del muestreo aleatorio simple, pero, primero, se considerará el problema de si se muestrea *con reemplazo* o *sin reemplazo*. Cuando se utiliza el muestreo con reemplazo, cada miembro de la población está disponible para cada extracción. Por ejemplo, supóngase que se extrae una muestra de una población de pacientes antiguos de un hospital, como parte de un estudio de duración de la internación. Supóngase que el muestreo comprende la selección de una muestra tomada de los expedientes del departamento de archivo médico de los pacientes dados de alta. En el muestreo con reemplazo se procedería como sigue: se selecciona un expediente para formar parte de la muestra, se registra la duración de la internación y se regresa el expediente al estante. El expediente está nuevamente en la “población” y puede ser tomado una vez más en alguna ocasión subsiguiente, en cuyo caso, la duración de la internación se registrará otra vez. En el muestreo sin reemplazo, el expediente extraído no se regresaría al estante después de haber registrado la duración de la internación, sino que se separaría hasta

que se extrajera la muestra completa. Siguiendo este procedimiento, un expediente dado aparecería en la muestra sólo una vez. Como regla, en la práctica, el muestreo siempre se realiza sin reemplazo. Posteriormente, se explicará el significado y las consecuencias de esto, pero primero se verá cómo se selecciona una muestra aleatoria simple. Con el fin de asegurar una verdadera aleatoriedad, se necesitará seguir algún procedimiento objetivo. Evidentemente, se deseará evitar el uso del criterio propio para decidir qué miembros de la población constituyen una muestra aleatoria.

Ejemplo 4.2.1

Una manera de seleccionar una muestra aleatoria simple es utilizar una tabla de números aleatorios como la que se muestra en la tabla G del apéndice. Supóngase que la población de interés consta de los 150 valores de concentración de azúcar en sangre que se ha extraído en ayunas y que se indican en la tabla 4.2.1.

Se desea extraer de esta población, una muestra aleatoria simple de tamaño 10, utilizando los números aleatorios de la tabla G. Como primer paso, se debe localizar un punto de partida aleatorio en la tabla. Esto puede hacerse en varias formas, una de las cuales es quitar la vista de la página, mientras se toca con la punta de un lápiz. El punto de partida aleatorio es el dígito más próximo al punto donde el lápiz tocó la página. Supóngase que, siguiendo este procedimiento, se llegó a un punto de partida aleatorio en la primera página de la tabla G, en la intersección del renglón 21 y la columna 28. El dígito en este punto es 5. Dado que se tienen 150 valores para elegir, pueden utilizarse sólo los números aleatorios del 1 al 150. Resultará conveniente seleccionar números de tres dígitos, de modo que sean elegibles sólo los números del 001 al 150. El primer número de tres dígitos, empezando en el punto de partida aleatorio, es el 532, un número que no puede utilizarse. Se recorre la tabla hacia abajo y se pasan los números 196, 372, 654 y 928 hasta llegar al 137, un número que puede utilizarse. El 137-ésimo valor de la tabla 4.2.1 es 92, el primer valor de la muestra. En la tabla 4.2.2 se han registrado el número aleatorio y la concentración de azúcar en sangre correspondiente. Se han registrado los números aleatorios para que se vea cuáles fueron los seleccionados. Dado que se desea una muestra sin reemplazo, no se desea incluir dos veces el valor de un mismo individuo. Procediendo en la forma que acaba de describirse, se llega a los nueve números aleato-

Tabla 4.2.1 Concentraciones de azúcar en la sangre que se ha extraído en ayunas a 50 individuos aparentemente normales.

Número del individuo	Concen- tración	Número del individuo	Concen- tración	Número del individuo	Concen- tración	Número del individuo	Concen- tración	Número del individuo	Concen- tración
1	91	31	107	61	87	91	91	121	90
2	94	32	94	62	104	92	104	122	105
3	115	33	101	63	109	93	109	123	100
4	85	34	95	64	93	94	92	124	89
5	89	35	80	65	95	95	85	125	90
6	107	36	104	66	107	96	108	126	106
7	94	37	94	67	88	97	99	127	94
8	105	38	102	68	107	98	103	128	100
9	94	39	89	69	113	99	81	129	92
10	103	40	98	70	95	100	96	130	91
11	104	41	106	71	102	101	105	131	87
12	105	42	85	72	94	102	91	132	105
13	88	43	93	73	99	103	115	133	102
14	107	44	103	74	87	104	108	134	101
15	90	45	119	75	102	105	102	135	111
16	95	46	90	76	105	106	101	136	91
17	104	47	82	77	80	107	94	137	92
18	93	48	90	78	90	108	93	138	98
19	109	49	113	79	108	109	102	139	81
20	87	50	104	80	105	110	119	140	117
21	92	51	97	81	90	111	96	141	103
22	117	52	101	82	115	112	104	142	96
23	98	53	90	83	82	113	85	143	101
24	89	54	88	84	90	114	108	144	88
25	105	55	108	85	102	115	103	145	100
26	101	56	95	86	91	116	90	146	100
27	81	57	100	87	103	117	105	147	95
28	108	58	103	88	107	118	99	148	103
29	94	59	108	89	107	119	88	149	101
30	104	60	85	90	97	120	103	150	90

Tabla 4.2.2 Muestra de 10 concentraciones de azúcar en la sangre que se ha extraído, obtenida de los datos de la tabla 4.2.1.

<i>Número aleatorio</i>	<i>Número del individuo en la muestra</i>	<i>Concentración</i>
137	1	92
114	2	108
028	3	108
085	4	102
018	5	93
042	6	85
053	7	90
108	8	93
144	9	88
126	10	106

rios restantes y sus correspondientes concentraciones de azúcar en sangre que se muestran en la tabla 4.2.2. Nótese que cuando se llega al fin de la columna, se avanza simplemente tres dígitos hasta el 028 y hacia arriba de la columna. También pudo haberse empezado por la parte de arriba de dicha columna con el número 369.

Así, se ha extraído una muestra aleatoria simple, de tamaño 10, de una población de tamaño 150. En todo estudio futuro, siempre que se utilice el término de muestra aleatoria simple, se entenderá que la muestra se extrajo en esta forma o en otra equivalente.

Muchas de las computadoras más comunes tienen capacidad para generar números aleatorios. Como alternativa para utilizar tablas impresas de números aleatorios, los investigadores pueden utilizar computadoras para obtener los números aleatorios que desean. En realidad, los números “aleatorios” dados por la mayoría de las computadoras son de hecho, *números pseudoaleatorios* debido a que son el resultado de una fórmula determinística. Sin embargo, como Fishman¹ lo ha señalado, parece ser que dichos números sirven satisfactoriamente para muchos de los fines prácticos.

Ejercicios

- 4.2.1 Utilizando la tabla de números aleatorios, seleccione un nuevo punto de partida aleatorio y extraiga otra muestra aleatoria simple de tamaño 10 de los datos de la tabla 4.2.1.

- 4.2.2 Obtenga una muestra aleatoria simple de tamaño 5 de los datos de la tabla 1.4.1.

4.3 DISTRIBUCIONES MUESTRALES

Se ha llegado ahora al tema principal de este capítulo, las *distribuciones muestrales*. Nunca estará de más todo lo que se haga por resaltar la importancia que tiene la comprensión clara de las distribuciones muestrales, ya que este concepto es la clave para comprender la inferencia estadística. Se empezará el estudio con la siguiente definición.

Definición

*La distribución de todos los valores posibles que puede tomar alguna estadística, calculados a partir de muestras del mismo tamaño extraídas al azar de la misma población, se conoce como **distribución muestral de esa estadística**.*

Las distribuciones muestrales pueden construirse empíricamente cuando se obtienen de una población finita, discreta. Para construir una distribución muestral, se hace lo siguiente.

1. De una población finita de tamaño N , se extraen al azar todas las muestras posibles de tamaño n .
2. Se calcula la estadística de interés para cada muestra.
3. Se enlistan en una columna los diferentes valores observados de la estadística y en otra columna, la frecuencia correspondiente de ocurrencia de cada uno de esos valores.

La construcción real de una distribución de muestreo es una tarea formidable si la población es de un tamaño apreciable, y es imposible si la población es infinita. En dichos casos, pueden obtenerse aproximaciones de las distribuciones muestrales tomando un gran número de muestras de un determinado tamaño.

En general, se tiene interés en conocer tres cosas acerca de una determinada distribución muestral: su media, su variancia y su forma funcional (cómo se ve cuando se construye su gráfica).

Es bien conocida la dificultad para construir una distribución muestral de acuerdo con los pasos dados líneas arriba, cuando la po-

blación es de un tamaño apreciable. Puede plantearse también un problema difícil cuando se considera la construcción de una distribución muestral si la población es infinita. Lo mejor que puede hacerse experimentalmente en este caso es aproximar la distribución muestral de una estadística.

Estos dos problemas pueden evitarse por medio de las matemáticas. Aunque los procedimientos que intervienen son incompatibles con el nivel matemático de este texto, las distribuciones muestrales pueden deducirse matemáticamente. El lector interesado puede consultar uno de los muchos textos de estadística matemática, como por ejemplo, el de Hoel² y de Anderson y Bancroft³.

En las secciones siguientes, se estudian algunas de las distribuciones muestrales que se encuentran con más frecuencia.

4.4 DISTRIBUCIÓN DE LA MEDIA DE LA MUESTRA

Una importante distribución muestral es la distribución de la media de la muestra. Se verá cómo podría construirse esta distribución muestral siguiendo los pasos esbozados en la sección anterior.

Ejemplo 4.4.1

Supóngase que se tiene una población de tamaño $N = 5$ que consta de las edades de cinco niños, pacientes externos de un centro de enfermedades mentales. Las edades son las siguientes: $x_1 = 6$, $x_2 = 8$, $x_3 = 10$, $x_4 = 12$ y $x_5 = 14$. La media, μ , de esta población, es igual a $\sum x_i / N = 10$ y la variancia

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{N} = \frac{40}{5} = 8$$

Se calculará otra media de dispersión como sigue:

$$S^2 = \frac{\sum (x_i - \mu)^2}{N - 1} = \frac{40}{4} = 10$$

Esta cantidad se utilizará otra vez en el capítulo siguiente. Se extraerán de esta población todas las muestras posibles de tamaño $n = 2$. Estas muestras, junto con sus medias, se muestran en la tabla 4.41.

Tabla 4.4.1 Todas las muestras posibles de tamaño $n = 2$ obtenidas de una población de tamaño $N = 5$. Las muestras por arriba o por debajo de la diagonal resultan cuando el muestreo es sin reemplazo. Las medias de las muestras están entre paréntesis.

		Segunda extracción				
		6	8	10	12	14
Primera Extracción	6	6, 6 (6)	6, 8 (7)	6, 10 (8)	6, 12 (9)	6, 14 (10)
	8	8, 6 (7)	8, 8 (8)	8, 10 (9)	8, 12 (10)	8, 14 (11)
	10	10, 6 (8)	10, 8 (9)	10, 10 (10)	10, 12 (11)	10, 14 (12)
	12	12, 6 (9)	12, 8 (10)	12, 10 (11)	12, 12 (12)	12, 14 (13)
	14	14, 6 (10)	14, 8 (11)	14, 10 (12)	14, 12 (13)	14, 14 (14)

En este ejemplo se observa que, cuando el muestreo es con reemplazo, hay 25 muestras posibles. Generalizando, cuando el muestreo es con reemplazo, el número de muestras posibles es igual a N^n .

Puede construirse la distribución de muestreo de $\bar{x}$ enumerando los diferentes valores de $\bar{x}$ en una columna y su frecuencia de ocurrencia en otra, como en la tabla 4.4.2.

Se observa que los datos de la tabla 4.4.2 satisfacen los requisitos para una distribución de probabilidad. Las probabilidades individuales son mayores que 0 y su suma es igual a 1.

Se afirmó anteriormente que, en general, se tiene interés en la forma funcional de la distribución muestral, su media y su variancia.

Obsérvese la distribución de $\bar{x}$ construida como histograma junto con la distribución de la población que se muestra en la figura 4.4.1. Sin duda, el lector debe haberse impresionado con la radical diferencia que existe en el aspecto del histograma de la población y la distribución muestral de $\bar{x}$. Mientras que la primera tiene una distribución uniforme, la última crece gradualmente hasta formar un pico y, a continuación, disminuye con una simetría perfecta. Se calcula aho-

Tabla 4.4.2 Distribución muestral de $\bar{x}$ calculada a partir de las muestras de la tabla 4.4.1.

$\bar{x}$	Frecuencia	Frecuencia relativa
6	1	1/25
7	2	2/25
8	3	3/25
9	4	4/25
10	5	5/25
11	4	4/25
12	3	3/25
13	2	2/25
14	1	1/25
Total	25	25/25





Figura 4.4.1 Distribución de la población y distribución muestral de $\bar{x}$.

ra la media, a la cual se denotará por $\mu_{\bar{x}}$, de la distribución muestral. Para hacerlo, se suman las 25 medias de las muestras y se divide entre 25. Así, se tiene que

$$\mu_{\bar{x}} = \frac{\sum \bar{x}_i}{N^n} = \frac{6 + 7 + 7 + 8 + \cdots + 14}{25} = \frac{250}{25} = 10$$

Se observa con interés que la media de la distribución muestral de $\bar{x}$ tiene el mismo valor que la media de la población original.

Finalmente, se calcula la variancia de $\bar{x}$, que se denotará por $\sigma_{\bar{x}}^2$, como sigue:

$$\begin{aligned}\sigma_{\bar{x}}^2 &= \frac{\sum (\bar{x}_i - \mu_{\bar{x}})^2}{N^n} \\ &= \frac{(6 - 10)^2 + (7 - 10)^2 + (7 - 10)^2 + \cdots + (14 - 10)^2}{25} \\ &= \frac{100}{25} = 4\end{aligned}$$

Se observa que la variancia de la distribución muestral no es igual a la variancia de la población. Sin embargo, resulta interesante observar que la variancia de la distribución muestral es igual a la variancia de la población dividida entre el tamaño de la muestra utilizada para obtener la distribución muestral. Es decir,

$$\sigma_{\bar{x}}^2 = \frac{\sigma^2}{n} = \frac{8}{2} = 4$$

La raíz cuadrada de la variancia de la distribución muestral, $\sqrt{\sigma_{\bar{x}}^2} = \sigma/\sqrt{n}$, se conoce como *error estándar de la media* o, simplemente, *error estándar*.

Estos resultados no son coincidencias, sino ejemplos de las características de las distribuciones muestrales en general, cuando el muestreo es con reemplazo o cuando se realiza a partir de una población infinita. Para generalizar, se distingue entre dos situaciones: muestreo a partir de una población con distribución normal y a partir de una población que no presenta distribución normal.

Cuando el muestreo es a partir de una población con distribución normal, la distribución de la media de la muestra tendrá las siguientes propiedades:

1. La distribución de $\bar{x}$ será normal.
2. La media, $\mu_{\bar{x}}$, de la distribución de $\bar{x}$ será igual a la media de la población de la cual se extrajeron las muestras.
3. La variancia, $\sigma_{\bar{x}}^2$, de la distribución de $\bar{x}$ será igual a la variancia de la población dividida entre el tamaño de la muestra.

Para el caso en el que el muestreo se realice a partir de una población que no tiene distribución normal, se utiliza un importante teorema matemático conocido como *teorema del límite central*. La importancia de este teorema en la inferencia estadística puede resumirse en el siguiente enunciado.

Dada una población de cualquier forma funcional no normal con una media, μ , y variancia finita, σ^2 , la distribución muestral de $\bar{x}$, calculada a partir de muestras de tamaño n de esta población, estará distribuida en forma aproximadamente normal con media μ y variancia σ^2/n , cuando el tamaño de la muestra es grande.

Nótese que el teorema del límite central permite muestrear a partir de poblaciones que no presentan distribución normal con una garantía de aproximadamente los mismos resultados que se obtendrían si la población tuviera distribución normal, siempre que se tome una muestra grande.

La importancia de esto será evidente después, cuando se aprenda que una distribución muestral con distribución normal es una herramienta muy importante en la inferencia estadística. En el caso de la media de la muestra, se tiene la seguridad de que la distribución muestral está al menos distribuida en forma aproximadamente normal bajo tres condiciones: 1) cuando se hace el muestreo a partir de una población con distribución normal; 2) cuando se hace el muestreo a partir de una población que no muestra distribución normal y la muestra es grande y 3) cuando se hace el muestreo a partir de una población cuya forma funcional se desconoce en tanto que el tamaño de la muestra es grande.

La pregunta lógica que surge en este punto es: ¿qué tan grande debe ser la muestra para que pueda aplicarse el teorema del límite central? No existe una respuesta firme y rápida, debido a que el tamaño de la muestra depende del grado de no normalidad presente en la población. Una regla empírica señala que, en la mayoría de las situaciones prácticas, resulta satisfactoria una muestra de tamaño 30.

Además, se hace mucho mejor la aproximación hacia la normalidad de la distribución muestral de $\bar{x}$, a medida que aumenta el tamaño de la muestra.

Los resultados anteriores se han dado bajo la premisa de que el muestreo es con reemplazo, o bien, que las muestras se han extraído de poblaciones infinitas. En general, no se muestrea con reemplazo y, en muchas situaciones prácticas, es posible que sea necesario muestrear a partir de una población finita; de aquí que sea necesario familiarizarse con el comportamiento de la distribución muestral de la media de la muestra bajo estas condiciones. Antes de hacer cualquier afirmación general, obsérvense de nuevo los datos de la tabla 4.4.1. Las medias de las muestras que se obtienen cuando el muestreo es sin reemplazo son aquellas que están arriba de la diagonal, que son las mismas que están debajo de la misma si se ignora el orden en que se hicieron las observaciones. Se observa que hay 10 muestras posibles. En general, cuando se extraen sin reemplazo muestras de tamaño n a partir de una población finita de tamaño N y se ignora el orden en el que fueron extraídos los valores de la muestra, el número de muestras posibles está dado por la combinación de N cosas, tomadas n a la vez. En el presente ejemplo se tiene que

$$\binom{N}{n} = \frac{N!}{n!(N-n)!} = \frac{5!}{2!3!} = \frac{5 \cdot 4 \cdot 3!}{2!3!} = 10 \text{ muestras posibles}$$

La media de las 10 medias de las muestras es

$$\mu_{\bar{x}} = \frac{\sum x_i}{\binom{N}{n}} = \frac{7 + 8 + 9 + \cdots + 13}{10} = \frac{100}{10} = 10$$

Se observa una vez más que la media de la distribución muestral es igual a la media de la población.

La variancia de esta distribución de muestreo es:

$$\sigma_{\bar{x}}^2 = \frac{\sum (\bar{x}_i - \mu_{\bar{x}})^2}{\binom{N}{n}} = \frac{30}{10} = 3$$

y se observa que, en esta ocasión, la variancia de la distribución de muestreo no es igual a la variancia de la población dividida entre el tamaño de la muestra, ya que $\sigma_{\bar{x}}^2 = 3 \neq 8/2 = 4$. Sin embargo,

existe una interesante relación que se descubre al multiplicar σ^2/n por $(N-n)/(N-1)$. Es decir,

$$\frac{\sigma^2}{n} \cdot \frac{N-n}{N-1} = \frac{8}{2} \cdot \frac{5-2}{4} = 3$$

Este resultado muestra que, si se multiplica la variancia de la distribución muestral, que se obtendría si el muestreo fuera con reemplazo, por el factor $(N-n)/(N-1)$, se obtiene el valor de la variancia de la distribución muestral que resulta cuando el muestreo es sin reemplazo. Pueden generalizarse estos resultados con el siguiente enunciado.

Cuando se muestrea sin reemplazo a partir de una población finita, la distribución de muestreo de $\bar{x}$ tendrá media μ y variancia,

$$\frac{\sigma^2}{n} \cdot \frac{N-n}{N-1}$$

Si el tamaño de la muestra es grande, se aplica el teorema del límite central, y la distribución de muestreo de $\bar{x}$ estará distribuida en forma aproximadamente normal.

El factor $(N-n)/(N-1)$ se conoce como corrección por población finita y puede ignorarse cuando el tamaño de la muestra es pequeño en comparación con el tamaño de la población. Cuando la población es mucho más grande que la muestra, la diferencia entre σ^2/n y $(\sigma^2/n)[(N-n)/(N-1)]$ será despreciable. Supóngase que una población está formada por 10,000 observaciones y que una muestra de esta población consta de 25 observaciones; la corrección por población finita sería igual a $(10,000 - 25)/(9999) = .9976$. Multiplicar σ^2/n por .9976 es casi equivalente a multiplicar por 1. La mayoría de los que hacen cálculos estadísticos no utilizan la corrección por población finita a menos que la muestra contenga más del 5 por ciento de las observaciones en la población. Es decir, la corrección por población finita se ignora por lo general cuando $n/N \leq .05$.

Aplicaciones. Como se verá en los capítulos siguientes, el conocimiento y comprensión de las distribuciones muestrales será un requisito necesario para comprender los conceptos de la inferencia estadística. La aplicación más sencilla de la distribución muestral de la media de la muestra es al calcular la probabilidad de obtener una muestra con una media de alguna magnitud especificada. Se ilustrará lo anterior con algunos ejemplos.

Ejemplo 4.4.2

Supóngase que se sabe que, en cierta gran población formada por personas, la longitud craneal está distribuida en forma casi normal con una media de 185.6 mm y una desviación estándar de 12.7 mm. ¿Cuál es la probabilidad de que una muestra aleatoria de tamaño 10 de esta población tenga una media mayor de 190?

Solución. Se sabe que la muestra bajo consideración es una de todas las muestras posibles de tamaño 10 que pueden extraerse de la población, de modo que la media a la cual conduce es una de las $\bar{x}$ que comprenden la distribución muestral de $\bar{x}$ que, teóricamente, podría derivarse de esta población.

Cuando se dice que la población está distribuida en forma casi normal, se supone que, para todos los fines prácticos, la distribución muestral de $\bar{x}$ mostrará una distribución normal. Se sabe también que la media y la desviación estándar de la distribución muestral son iguales, respectivamente, a 185.6 y $\sqrt{(12.7)^2/10} = 12.7/\sqrt{10} = 4.02$. Se supone que la población es grande respecto a la muestra, de modo que puede ignorarse la corrección por población finita.

En el capítulo anterior se aprendió que, siempre que se tiene una variable aleatoria con distribución normal, puede transformarse fácilmente en la distribución normal unitaria. La variable aleatoria es ahora $\bar{x}$, la media de su distribución es $\mu_{\bar{x}}$, y su desviación estándar es $\sigma_{\bar{x}} = \sigma/\sqrt{n}$. Modificando apropiadamente la fórmula dada con anterioridad, se llega a la fórmula siguiente para transformar la distribución normal de $\bar{x}$ en la distribución normal unitaria.

$$z = \frac{\bar{x} - \mu_{\bar{x}}}{\sigma/\sqrt{n}} \quad (4.4.1)$$

La probabilidad que da respuesta a la pregunta formulada está representada por el área a la derecha de $\bar{x} = 190$ bajo la curva de la distribución muestral. Esta área es igual al área a la derecha de

$$z = \frac{190 - 185.6}{4.02} = \frac{4.4}{4.02} = 1.09$$

Consultando la tabla normal unitaria, se encuentra que el área a la derecha de 1.09 es .1379; en consecuencia, se dice que la probabili-

dad de que una muestra de tamaño 10 tenga una media mayor de 190 es de .1379.

La figura 4.4.2 muestra la relación que existe entre la población original, la distribución muestral de $\bar{x}$ y la distribución normal unitaria.




Figura 4.4.2 Distribución de la población, distribución muestral y distribución normal unitaria, ejemplo 4.4.2. a) Distribución de la población. b) Distribución muestral de $\bar{x}$ para muestras de tamaño 10. c) Distribución normal unitaria.

Ejemplo 4.4.3

Si la media y la desviación estándar de las concentraciones de hierro en el suero de hombres sanos son, respectivamente, de 120 y 15 microgramos por 100 ml, ¿cuál es la probabilidad de que una muestra al azar de 50 hombres normales proporcione una media entre 115 y 125 microgramos por 100 ml?

Solución. No se especifica la forma funcional de la población de concentraciones de hierro en el suero, pero dado que se tiene una muestra de tamaño mayor de 30, se utiliza el teorema del límite central y se transforma la distribución muestral resultante de $\bar{x}$ con distribución casi normal (la cual tiene una media de 120 y una desviación estándar de $15/\sqrt{50} = 2.12$) en la normal unitaria. La probabilidad que se busca es:

$$\begin{aligned} P(115 \leq \bar{x} \leq 125) &= P\left(\frac{115 - 120}{2.12} \leq z \leq \frac{125 - 120}{2.12}\right) \\ &= P(-2.36 \leq z \leq 2.36) \\ &= .9909 - .0091 \\ &= .9818 \end{aligned}$$

Ejercicios

4.4.1 Supóngase que se sabe que los salarios por hora de cierto tipo de empleados de un hospital están distribuidos en forma casi normal con una media y una desviación estándar de \$4.50 y \$.50, respectivamente. Si se selecciona una muestra al azar de tamaño 16 de esta población, encuentre la probabilidad de que la media del salario por hora para la muestra sea:

- a) Mayor de \$4.25.
- b) Entre \$4.25 y \$4.75.
- c) Mayor de \$4.80.
- d) Menor de \$4.20.

4.4.2 Se ha encontrado que, después de un período de entrenamiento, el tiempo medio que requieren ciertas personas impedidas para realizar una tarea particular es de 25 segundos con una desviación estándar de 5 segundos. Suponiendo una distribu-

ción normal de los tiempos, encuentre la probabilidad de que una muestra de 25 individuos proporcione una media:

- a) De 26 segundos o más.
- b) Entre 24 y 27 segundos.
- c) De 26 segundos o menos.
- d) Mayor de 22 segundos.

4.4.3 Si las concentraciones de ácido úrico en hombres adultos y normales están distribuidas en forma casi normal con una media y una desviación estándar de 5.7 y 1 mg por ciento, respectivamente, encuentre la probabilidad de que una muestra de tamaño 9 proporcione una media:

- a) Mayor de 6.
- b) Entre 5 y 6.
- c) Menor de 5.2.

4.4.4 Para cierto sector grande de una población, en un año determinado, supóngase que el número medio de días de incapacidad es de 5.4 con una desviación estándar de 2.8 días. Encuentre la probabilidad de que una muestra al azar de tamaño 49 de dicha población tenga una media:

- a) Mayor de 6 días.
- b) Entre 4 y 6 días.
- c) Entre $4\frac{1}{2}$ y $5\frac{1}{2}$ días.

4.4.5 Dada una población con distribución normal con una media de 100 y una desviación estándar de 20, encuentre las siguientes probabilidades basadas en una muestra de tamaño 16:

- a) $P(\bar{x} \geq 100)$.
- b) $P(96 \leq \bar{x} \leq 108)$.
- c) $P(\bar{x} \leq 110)$.

4.4.6 Dados $\mu = 50$, $\sigma = 16$, $n = 64$, encuentre:

- a) $P(45 \leq \bar{x} \leq 55)$.
- b) $P(\bar{x} > 53)$.

- c) $P(\bar{x} < 47)$.
- d) $P(49 \leq \bar{x} \leq 56)$.

- 4.4.7 Supóngase que una población consta de los siguientes valores: 1, 3, 5, 7, 9. Construya la distribución muestral de $\bar{x}$ en base a muestras de tamaño 2 seleccionadas sin reemplazo. Encuentre la media y la variancia de la distribución muestral.
- 4.4.8 Utilice los datos del ejemplo 4.4.1 para construir la distribución muestral de $\bar{x}$ en base a muestras de tamaño 3 seleccionadas sin reemplazo. Encuentre la media y la variancia de la distribución muestral.

4.5 DISTRIBUCIÓN DE LA DIFERENCIA ENTRE LAS MEDIAS DE DOS MUESTRAS

Con frecuencia, el interés de una investigación está centrado en dos poblaciones. Específicamente, puede ser que un investigador desee saber algo acerca de la diferencia entre las medias de dos poblaciones. En una investigación, por ejemplo, puede ser que un investigador desee saber si es razonable concluir que las medias de dos poblaciones son distintas. En otra situación, el investigador puede desear conocer la magnitud de la diferencia entre las medias de dos poblaciones. Un grupo de médicos investigadores, por ejemplo, puede desear saber si la concentración media de colesterol en el suero es mayor en una población de oficinistas sedentarios que en una población de trabajadores. En caso de que los investigadores lleguen a la conclusión de que las medias de las poblaciones son distintas, es posible que deseen saber qué tanto difieren. El conocimiento de la distribución muestral de la diferencia entre dos medias es útil en investigaciones de este tipo.

Ejemplo 4.5.1

Supóngase que se tienen dos grupos de individuos, uno de los grupos (grupo 1) ha experimentado alguna afección que se considera está asociada al retraso mental y el otro grupo (grupo 2) no ha experimentado dicha afección. Se supone que la distribución de las calificaciones de inteligencia en cada uno de los dos grupos muestra una distribución casi normal con una desviación estándar de 20.

Supóngase además que se toma una muestra de 15 individuos de cada grupo y, para cada muestra, se calcula la calificación media de inteligencia con los siguientes resultados: $\bar{x}_1 = 92$ y $\bar{x}_2 = 105$. Si no existe diferencia entre los dos grupos con respecto a sus verdaderas calificaciones de inteligencia, ¿cuál es la probabilidad de observar esta gran diferencia entre las medias de las muestras?

Para contestar esta pregunta se necesita conocer la naturaleza de la distribución muestral de la estadística pertinente, la *diferencia entre las medias de dos muestras*, $\bar{x}_1 - \bar{x}_2$. Nótese que se busca una probabilidad asociada a la diferencia entre las medias de dos muestras, en lugar de una sola media.

Aunque en la práctica no se intentaría construir la distribución de muestreo deseada, puede formarse una idea conceptual de la manera en la que podría hacerse cuando el muestreo se hace a partir de poblaciones finitas. Se empezaría por seleccionar, del grupo 1, todas las muestras posibles de tamaño 15 y calcular la media de cada

muestra. Se sabe que habría $\binom{N_1}{n_1}$ de dichas muestras, donde N_1 es el tamaño del grupo y $n_1 = 15$. Asimismo, se seleccionarían todas las muestras posibles de tamaño 15 del grupo 2 y se calcularía la media de cada una de dichas muestras. Se tomarían entonces todas las parejas posibles de las medias de las muestras, una del grupo 1 y una del grupo 2, y se obtendría la diferencia. La tabla 4.5.1 muestra los resultados al aplicar este procedimiento. Nótese que los números fuera

Tabla 4.5.1 Tabla de trabajo para construir la distribución de la diferencia entre las medias de dos muestras.

<i>Muestras del grupo 1</i>	<i>Muestras del grupo 2</i>	<i>Medias de las muestras del grupo 1</i>	<i>Medias de las muestras del grupo 2</i>	<i>Todas las diferencias posibles entre las medias</i>
n_{11}	n_{12}	$\bar{x}_{11}$	$\bar{x}_{12}$	$\bar{x}_{11} - \bar{x}_{12}$
n_{21}	n_{22}	$\bar{x}_{21}$	$\bar{x}_{22}$	$\bar{x}_{11} - \bar{x}_{22}$
n_{31}	n_{32}	$\bar{x}_{31}$	$\bar{x}_{32}$	$\bar{x}_{11} - \bar{x}_{32}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$n \binom{N_1}{n_1}^1$	$n \binom{N_2}{n_2}^2$	$\bar{x} \binom{N_1}{n_1}^1$	$\bar{x} \binom{N_2}{n_2}^2$	$\bar{x} \binom{N_1}{n_1}^1 - \bar{x} \binom{N_2}{n_2}^2$




Figura 4.5.1 Gráfica de la distribución muestral de $\bar{x}_1 - \bar{x}_2$ cuando no existe diferencia entre las medias de las poblaciones. Ejemplo 4.5.1.

de los paréntesis de la última línea de esta tabla no son exponentes, sino indicadores del grupo 1 y del grupo 2, respectivamente.

Lo que se desea encontrar es la distribución de las diferencias entre las medias de las muestras. Si se grafican las diferencias de las muestras contra su frecuencia de ocurrencia, se obtendría una distribución normal con una media igual a $\mu_1 - \mu_2$, la diferencia entre las medias reales de los grupos o poblaciones y una variancia igual a $(\sigma_1^2/n_1) + (\sigma_2^2/n_2)$.

Para el presente ejemplo, se tendría una distribución normal con una media de 0 (si no existe diferencia entre las medias reales de las poblaciones) y una variancia de $[(20)^2/15] + [(20)^2/15] = 53.33$. La gráfica de la distribución muestral se muestra en la figura 4.5.1.

Se sabe que esta distribución normal puede transformarse en la distribución normal unitaria por medio de la modificación de una fórmula aprendida con anterioridad. La nueva fórmula es la siguiente:

$$z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \quad (4.5.1)$$

El área bajo la curva de $\bar{x}_1 - \bar{x}_2$ que corresponde a la probabilidad que se busca es el área a la izquierda de $\bar{x}_1 - \bar{x}_2 = 92 - 105 = -13$. El valor de z que corresponde a -13 , suponiendo que no existe diferencia entre las medias de las poblaciones, es

$$z = \frac{-13 - 0}{\sqrt{\frac{(20)^2}{15} + \frac{(20)^2}{15}}} = \frac{-13}{\sqrt{53.3}} = \frac{-13}{7.3} = -1.78$$

Consultando la tabla F, se encuentra que el área bajo la curva normal unitaria a la izquierda de -1.78 es igual a $.0375$. Como respuesta a la pregunta original se dice que, si no existe diferencia entre las medias de las poblaciones, la probabilidad de obtener una diferencia entre las medias de las muestras tan grande o mayor que 13 es de $.0375$.

El procedimiento que se acaba de seguir es válido incluso cuando los tamaños de las muestras, n_1 y n_2 , son distintos y cuando las variancias de las poblaciones, σ_1^2 y σ_2^2 , tienen valores distintos. Los resultados teóricos sobre los cuales se basa este procedimiento pueden resumirse como sigue.

Dadas dos poblaciones con distribución normal, con medias μ_1 y μ_2 y variancias σ_1^2 y σ_2^2 , respectivamente, la distribución muestral de la diferencia $\bar{x}_1 - \bar{x}_2$ entre las medias de muestras independientes de tamaño n_1 y n_2 , extraídas de estas poblaciones, muestra una distribución normal con media $\mu_1 - \mu_2$ y variancia $(\sigma_1^2/n_1) + (\sigma_2^2/n_2)$.

Muestreo de poblaciones no normales. Muchas veces un investigador se enfrenta a uno u otro de los problemas siguientes: la necesidad de 1) muestrear a partir de poblaciones no distribuidas normalmente, o bien, 2) muestrear a partir de poblaciones cuyas formas funcionales se desconocen. Una solución a estos problemas es tomar muestras grandes, dado que cuando los tamaños de las muestras son grandes, se aplica el teorema del límite central y la diferencia entre las dos medias de las muestras está distribuida en forma casi normal, con una media igual a $\mu_1 - \mu_2$ y una variancia de $(\sigma_1^2/n_1) + (\sigma_2^2/n_2)$. Para encontrar entonces las probabilidades asociadas a valores específicos de la estadística, el procedimiento sería el mismo que el dado anteriormente, cuando el muestreo se hace a partir de poblaciones con distribución normal.

Ejemplo 4.5.2

Supóngase que se ha establecido que, para cierto tipo de cliente, la duración media de una visita domiciliaria realizada por una enfermera es de 45 minutos, con una desviación estándar de 15 minutos y, que para un segundo tipo de cliente, la visita domiciliaria media es de 30 minutos, con una desviación estándar de 20 minutos. Si una

enfermera visita al azar a 35 clientes del primer tipo y 40 del segundo grupo, ¿cuál es la probabilidad de que la duración media de la visita difiera entre los dos grupos por 20 minutos o más?

Solución. No se menciona la forma funcional de las dos poblaciones, por lo que se supone que esta característica se desconoce, o bien, que las poblaciones no muestran distribución normal. Dado que los tamaños de las muestras son grandes (mayores de 30) en ambos casos, se hace uso de los resultados del teorema del límite central para responder a la pregunta formulada. Se sabe que la diferencia entre las medias de las muestras tiene una distribución casi normal, con las siguientes media y variancia:

$$\begin{aligned}\mu_{\bar{x}_1 - \bar{x}_2} &= \mu_1 - \mu_2 = 45 - 30 = 15 \\ \sigma_{\bar{x}_1 - \bar{x}_2}^2 &= \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} = \frac{(15)^2}{35} + \frac{(20)^2}{40} = 16.4286\end{aligned}$$

El área bajo la curva de $\bar{x}_1 - \bar{x}_2$ que se busca es aquella a la derecha de 20. El valor correspondiente de z en la distribución normal unitaria es

$$z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} = \frac{20 - 15}{\sqrt{16.4286}} = \frac{5}{4.05} = 1.23$$

En la tabla F se encuentra que el área a la derecha de $z = 1.23$ es de $1 - .8907 = .1093$. Se dice entonces que la probabilidad de que las visitas al azar de la enfermera conduzcan a una diferencia entre los dos grupos, tan grande o mayor que 20 minutos, es de .1093. La curva de $\bar{x}_1 - \bar{x}_2$ y la curva normal unitaria correspondiente se muestran en la figura 4.5.2.

Ejercicios

4.5.1 Un investigador se siente inclinado a creer que los niveles de vitamina A en el hígado de dos poblaciones de personas mues-




Figura 4.5.2 Distribución muestral de $\bar{x}_1 - \bar{x}_2$ y la distribución normal unitaria correspondiente, ejemplo de la visita domiciliaria.

tran, en cada una, una distribución normal. Se supone que las variancias para las dos poblaciones son las siguientes:

$$\text{Población 1: } \sigma_1^2 = 19,600$$

$$\text{Población 2: } \sigma_2^2 = 8100$$

¿Cuál es la probabilidad de que una muestra al azar de tamaño 15 de la primera población y de 10 de la segunda proporcionen un valor de $\bar{x}_1 - \bar{x}_2$ mayor que o igual a 50 si no existe diferencia en las medias de las poblaciones?

- 4.5.2 En un estudio de los gastos anuales por familia para el cuidado general de la salud, se investigaron dos poblaciones con los resultados siguientes:

$$\text{Población 1: } n_1 = 40, \bar{x}_1 = \$346$$

$$\text{Población 2: } n_2 = 35, \bar{x}_2 = 300$$

Si se sabe que las variancias de las dos poblaciones son $\sigma_1^2 = 2,800$ y $\sigma_2^2 = 3,250$, ¿cuál es la probabilidad de obtener re-

sultados de las muestras tan extremos como los dados anteriormente, si no existe diferencia entre las medias de ambas poblaciones?

- 4.5.3 Dadas dos poblaciones con distribución normal y con medias iguales y variancias de $\sigma_1^2 = 100$ y $\sigma_2^2 = 80$, ¿cuál es la probabilidad de que muestras de tamaños $n_1 = 25$ y $n_2 = 16$ proporcionen un valor de $\bar{X}_1 - \bar{X}_2$ mayor que o igual a 8?
- 4.5.4 Dadas dos poblaciones con distribución no normal y con medias iguales y variancias de $\sigma_1^2 = 240$ y $\sigma_2^2 = 350$, ¿cuál es la probabilidad de que muestras de tamaños $n_1 = 40$ y $n_2 = 35$ proporcionen un valor de $\bar{X}_1 - \bar{X}_2$ tan grande como 12?

4.6 DISTRIBUCIÓN DE LA PROPORCIÓN DE LA MUESTRA

En las secciones anteriores se trató de las distribuciones muestrales de estadísticas calculadas a partir de variables medidas. Sin embargo, se tiene interés con frecuencia en la distribución muestral de estadísticas, tales como una proporción de la muestra, que es un resultado de datos de conteos o frecuencias.

Ejemplo 4.6.1

Supóngase que se sabe que en cierta población de personas, .08 de sus habitantes son daltónicos. Si se designa la proporción de la población por p , puede decirse en este ejemplo que $p = .08$. Si se seleccionan al azar 150 individuos de esta población, ¿cuál es la probabilidad de que la proporción de los que son daltónicos sea tan grande como .15?

Para contestar esta pregunta, se necesita conocer las propiedades de la distribución muestral de la proporción de la muestra. Se designará a la proporción de la muestra mediante el símbolo $\tilde{p}$.

El lector reconocerá la semejanza que existe entre el presente ejemplo y los presentados en la sección 3.3, que trataron de la distribución binomial. Además, la variable daltonismo es binomial, dado que un individuo puede clasificarse en una u otra de dos categorías mutuamente excluyentes, daltónico y no daltónico. En la sección 3.3, se dio la misma información y se pidió encontrar el número con la característica de interés, mientras que aquí está pidiéndose la pro-

porción en la muestra que posee la característica de interés. Con una tabla lo suficientemente grande de probabilidades binomiales, como la tabla C, podría determinarse la probabilidad asociada con el número correspondiente a la proporción de interés. Como se verá más adelante, esto no será necesario, ya que se cuenta con otro procedimiento que, en general, es más conveniente cuando los tamaños de las muestras son grandes.

La distribución muestral de la proporción de una muestra se obtendría experimentalmente en la misma forma que se sugirió en el caso de la media aritmética y la diferencia entre dos medias. De la población, que se supone es finita, se tomarían todas las muestras posibles de un determinado tamaño y, para cada muestra, se calcularía la proporción de la muestra, $\tilde{p}$. Se prepararía entonces una distribución de frecuencias de $\tilde{p}$ enumerando los diferentes valores de $\tilde{p}$ junto con sus frecuencias de ocurrencia. Esta distribución de frecuencias (así como la distribución de frecuencias relativas correspondientes) constituirían la distribución muestral de $\tilde{p}$.

Cuando el tamaño de la muestra es grande, la distribución de las proporciones de la muestra es aproximadamente normal, en virtud del teorema del límite central. La media de la distribución, $\mu_{\tilde{p}}$, es, decir, el promedio de todas las proporciones de la muestra posibles, será igual a la proporción real de la población, p , y la variancia de la distribución, $\sigma_{\tilde{p}}^2$, será igual a $p(1 - p)/n$.

La pregunta que surge ahora es: ¿qué tan grande tiene que ser el tamaño de la muestra para que sea válido el uso de la aproximación normal? Un criterio ampliamente utilizado es que tanto np como $n(1 - p)$ deben ser mayores que 5, y se sujetará a esta regla en este texto.

Se está ahora en condiciones de contestar a la pregunta referente al daltonismo en la muestra de 150 individuos de una población en la que .08 son daltónicos. Dado que np y $n(1 - p)$ son mayores que 5 ($150 \times .08 = 12$ y $150 \times .92 = 138$), puede decirse que, en este caso, $\tilde{p}$ muestra una distribución casi normal con una media $\mu_{\tilde{p}} = p = .08$ y $\sigma_{\tilde{p}}^2 = p(1 - p)/n = (.08)(.92)/150 = .00049$. La probabilidad que se busca es el área bajo la curva de $\tilde{p}$ que está a la derecha de .15. Esta área es igual al área bajo la curva normal unitaria a la derecha de

$$z = \frac{\tilde{p} - p}{\sqrt{\frac{p(1 - p)}{n}}} = \frac{.15 - .08}{\sqrt{.00049}} = \frac{.07}{.0222} = 3.15$$

Se ha llevado a cabo la transformación hacia la distribución normal unitaria en la forma habitual: z se encuentra dividiendo la diferencia entre un valor de la estadística y la media, entre el error estándar. En la tabla F se encuentra que el área a la derecha de $z = 3.15$ es $1 - .9992 = .0008$. Puede decirse entonces que la probabilidad de observar $\tilde{p} \geq .15$ en una muestra al azar de tamaño $n = 150$ de una población en la que $p = .08$ es de .0008. De hecho, si se extrajera una muestra así, la mayoría de las personas la consideraría un evento raro.

La aproximación normal puede mejorarse mediante la *corrección por continuidad*, un artificio que hace un ajuste debido a que se está aproximando una distribución discreta mediante una distribución continua. Supóngase que $x = n\tilde{p}$, el número en la muestra con la característica de interés cuando la proporción es $\tilde{p}$. Para aplicar la corrección por continuidad, se calcula

$$z_c = \frac{\frac{x + .5}{n} - p}{\sqrt{pq/n}}, \quad \text{para } x > np \quad (4.6.1)$$

o

$$z_c = \frac{\frac{x - .5}{n} - p}{\sqrt{pq/n}}, \quad \text{para } x < np \quad (4.6.2)$$

donde $q = 1 - p$. La corrección por continuidad no produce una gran diferencia cuando n es grande. En el ejemplo anterior, $n\tilde{p} = 150(.15) = 22.5$ y

$$z_c = \frac{\frac{22.5 - .5}{150} - .08}{\sqrt{.00049}} = 3.01$$

y $P(\tilde{p} \geq .15) = 1 - .9987 = .0013$, un resultado no muy distinto del obtenido sin la corrección por continuidad.

Ejemplo 4.6.2

Supóngase que se sabe que en cierta población de mujeres, el 90 por ciento de las que entran a su tercer trimestre de embarazo ha tenido algún cuidado prenatal. Si se extrae una muestra al azar de ta-

maño 200 de esta población, ¿cuál es la probabilidad de que la proporción de la muestra que haya tenido algún cuidado prenatal sea mayor que .85?

Solución. Puede suponerse que la distribución muestral de p muestra una distribución casi normal con $\mu_{\bar{p}} = .90$ y $\sigma_{\bar{p}}^2 = (.1)(.9)/200 = .00045$. Se calcula

$$z = \frac{.85 - .90}{\sqrt{.00045}} = \frac{-.05}{.0212} = -2.36$$

El área a la izquierda de -2.36 bajo la curva normal unitaria es de .0091. Por lo tanto, $P(\bar{p} \leq .85) = P(z \leq -2.36) = .0091$.

Ejercicios

-
- 4.6.1 Si, en una población de adultos, .15 están sometidos a algún tipo de dieta, ¿cuál es la probabilidad de que una muestra al azar de tamaño 100 dé una proporción de aquellos que se encuentran a dieta:
- a) Mayor que o igual a .20?
 - b) Entre .10 y .20?
 - c) No mayor de .12?
- 4.6.2 En cierta ciudad se observa que el 20 por ciento de las familias tienen por lo menos un miembro que sufre de algún malestar debido a la contaminación atmosférica. Una muestra al azar de 150 familias dio $\bar{p} = .27$. Si el valor del 20 por ciento es correcto, ¿cuál es la probabilidad de obtener una proporción de la muestra así o mayor?
- 4.6.3 En una muestra al azar de 75 adultos, 35 dijeron que consideran que el cáncer mamario es curable. Si, en la población de la cual se extrajo la muestra, la proporción real de quienes piensan que dicho tipo de cáncer puede ser curado es de .55, ¿cuál es la probabilidad de obtener una proporción de la muestra tan pequeña o menor que la obtenida en esta muestra?
- 4.6.4 Se sabe que el medicamento estándar utilizado para tratar una cierta enfermedad ha resultado ser eficaz en un lapso de tres días en el 75 por ciento de los casos en los que se utilizó. Al

evaluar la eficacia de un nuevo medicamento para tratar la misma enfermedad, se le dio a 150 personas que la padecían. Al término de los tres días, se habían recuperado 97 personas. Si el nuevo medicamento es tan eficaz como el estándar, ¿cuál es la probabilidad de observar esta pequeña proporción de recuperación?

4.6.5 Dada una población en la que $p = .6$ y una muestra aleatoria de esta población de tamaño 100, encuentre:

- a) $P(\hat{p} \geq .65)$
- b) $P(\hat{p} \leq .58)$
- c) $P(.56 \leq \hat{p} \leq .63)$

4.7 DISTRIBUCIÓN DE LA DIFERENCIA ENTRE LAS PROPORCIONES DE DOS MUESTRAS

Con frecuencia, se tienen las proporciones de dos poblaciones en las cuales se tiene interés y se desea averiguar la probabilidad asociada a una diferencia en las proporciones calculadas a partir de muestras extraídas de cada una de dichas poblaciones. La distribución muestral pertinente es la distribución de la diferencia entre las proporciones de dos muestras. Las características de esta distribución muestral pueden resumirse como sigue:

Si se extraen muestras aleatorias independientes de tamaños n_1 y n_2 de dos poblaciones de variables binomiales donde las proporciones de las observaciones con la característica de interés en las dos poblaciones son, respectivamente, p_1 y p_2 , la distribución de la diferencia entre las proporciones de las muestras, $\hat{p}_1 - \hat{p}_2$, es casi normal con media

$$\mu_{\hat{p}_1 - \hat{p}_2} = p_1 - p_2$$

y variancia

$$\sigma_{\hat{p}_1 - \hat{p}_2}^2 = \frac{p_1(1 - p_1)}{n_1} + \frac{p_2(1 - p_2)}{n_2}$$

cuando n_1 y n_2 son grandes.

Con el fin de elaborar físicamente la distribución de muestreo de la diferencia entre las proporciones de dos muestras, se procedería

en la forma descrita en la sección 4.5 para obtener la distribución muestral de la diferencia entre dos medias.

Dadas dos poblaciones suficientemente pequeñas, se podrían extraer de la población 1, todas las muestras aleatorias posibles de tamaño n_1 y calcular, a partir de cada conjunto de datos de la muestra, la proporción de la muestra, $\tilde{p}_1$. De la población 2, se podrían extraer independientemente todas las muestras aleatorias posibles de tamaño n_2 y calcular, para cada conjunto de datos de la muestra, la proporción de la muestra, $\tilde{p}_2$. Se calcularían las diferencias entre todos los pares posibles de proporciones de las muestras, donde un miembro de cada par tenía un valor de $\tilde{p}_1$ y el otro un valor de $\tilde{p}_2$. La distribución muestral de la diferencia entre las proporciones de las muestras consistiría entonces de todas las diferencias existentes acompañadas de sus frecuencias (o frecuencias relativas) de ocurrencia. Para poblaciones grandes, finitas o infinitas, podría aproximarse la distribución muestral de la diferencia entre las proporciones de las muestras tomando un gran número de muestras aleatorias independientes y procediendo en la forma anteriormente descrita.

Ejemplo 4.7.1

Supóngase que la proporción de personas que consumen, moderada o intensamente, drogas ilegales de una población, grupo 1, es de .50, mientras que en otra población, grupo 2, la proporción es de .33. ¿Cuál es la probabilidad de que muestras de tamaño 100, extraídas de cada una de las poblaciones, tengan un valor de $\tilde{p}_1 - \tilde{p}_2$ tan grande como .30?

Se supone que la distribución muestral de $\tilde{p}_1 - \tilde{p}_2$ es casi normal con media

$$\mu_{\tilde{p}_1 - \tilde{p}_2} = .50 - .33 = .17$$

y variancia

$$\begin{aligned}\sigma_{\tilde{p}_1 - \tilde{p}_2}^2 &= \frac{(.33)(.67)}{100} + \frac{(.5)(.5)}{100} \\ &= .004711\end{aligned}$$

El área que corresponde a la probabilidad que se busca es el área bajo la curva de $\tilde{p}_1 - \tilde{p}_2$ a la derecha de .30. Pasando a la distribución normal unitaria se tiene que

$$z = \frac{(\bar{p}_1 - \bar{p}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}} = \frac{.30 - .17}{\sqrt{.004711}} = 1.89$$

Al consultar la tabla F, se encuentra que el área bajo la curva normal unitaria que está a la derecha de $z = 1.89$ es de $1 - .9706 = .0294$. Entonces, la probabilidad de observar una diferencia tan grande como .30 es .0294.

Ejemplo 4.7.2

Se sabe que en cierta población de adolescentes, el 10 por ciento de los muchachos son obesos. Si la misma proporción de muchachas de dicha población son obesas, ¿cuál es la probabilidad de que una muestra al azar de 250 muchachos y 200 muchachas dé un valor de $\bar{p}_1 - \bar{p}_2 \geq .06$?

Se supone que la distribución muestral de $\bar{p}_1 - \bar{p}_2$ es casi normal. Si la proporción de individuos obesos es la misma en los dos grupos, la media de la distribución será 0 y la variancia

$$\begin{aligned}\sigma_{\bar{p}_1 - \bar{p}_2}^2 &= \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2} = \frac{(.1)(.9)}{250} + \frac{(.1)(.9)}{200} \\ &= .00081\end{aligned}$$

El área de interés bajo la curva de $\bar{p}_1 - \bar{p}_2$ es la que se encuentra a la derecha de .06. El valor correspondiente de z es:

$$z = \frac{.06 - 0}{\sqrt{.00081}} = 2.11$$

Si se consulta la tabla F, se encuentra que el área a la derecha de $z = 2.11$ es de $1 - .9826 = .0174$.

Ejercicios

4.7.1 En cierta población de niños con retraso mental, se sabe que la proporción de los que son hiperactivos es de .40. Se extrajo una muestra al azar de tamaño 120 de esta población y otra de tamaño 100 de otra población de niños con el mismo proble-

ma. Si la proporción de niños hiperactivos es la misma en ambas poblaciones, ¿cuál es la probabilidad de que la muestra proporcione una diferencia de $\tilde{p}_1 - \tilde{p}_2$ de .16 o más?

- 4.7.2 Se tienen bases para suponer que en cierta zona de una gran ciudad, el 40 por ciento de las casas están en malas condiciones. Una muestra al azar de 75 casas de esta sección y 90 casas de otra sección dieron una diferencia de $\tilde{p}_1 - \tilde{p}_2$ de .09. Si no existe diferencia entre las dos zonas en la proporción de casas en mal estado, ¿cuál es la probabilidad de observar una diferencia como ésta o mayor?

4.8 RESUMEN

Este capítulo trata del muestreo y de las distribuciones muestrales. Se define el muestreo aleatorio simple, el tipo de muestreo básico para la inferencia estadística, y se explica un procedimiento para obtener este tipo de muestra. Se introduce el concepto de distribución muestral y se estudian las siguientes distribuciones muestrales importantes:

1. La distribución de la media de una sola muestra.
2. La distribución de la diferencia entre las medias de dos muestras.
3. La distribución de la proporción de una muestra.
4. La distribución de la diferencia entre las proporciones de dos muestras.

Se recalca la importancia de estos aspectos y se insiste en que el lector se asegure de que los ha comprendido antes de que continúe con el siguiente capítulo.

Preguntas y ejercicios de repaso

1. ¿Cuáles son los dos tipos de muestreo?
2. ¿Por qué no se estudia en este texto el muestreo no probabilístico?
3. Defina o explique los siguientes términos:
 - a) Muestra probabilística.
 - b) Muestra aleatoria simple.
 - c) Muestreo con reemplazo.

- d) Muestreo sin reemplazo.
- e) Distribución muestral.

4. Explique cómo puede conformarse una distribución muestral a partir de una población finita.
5. Describa la distribución muestral de la media de una muestra cuando el muestreo se hace con reemplazo a partir de una población con distribución normal.
6. Explique el teorema del límite central.
7. ¿En qué forma difiere la distribución muestral de la media de la muestra, cuando el muestreo es sin reemplazo, de la distribución muestral obtenida cuando el muestreo es con reemplazo?
8. Describa la distribución muestral de la diferencia entre las medias de dos muestras.
9. Describa la distribución muestral de la proporción de la muestra cuando se extraen muestras grandes.
10. Describa la distribución muestral de la diferencia entre las medias de dos muestras cuando se extraen muestras grandes.
11. Explique el procedimiento que seguiría para obtener la distribución muestral de la diferencia entre las proporciones de las muestras basada en muestras grandes obtenidas de una población finita.
12. Supóngase que se sabe que el tiempo de respuesta a un estímulo particular en individuos sanos es una variable aleatoria con distribución normal, con una media de 15 segundos y una variancia de 16. ¿Cuál es la probabilidad de que una muestra al azar de 16 individuos tenga un tiempo medio de respuesta de 12 segundos o más?
13. Cierta empresa tiene 2,000 empleados. Durante un año reciente, el monto medio por empleado debido a costos médicos personales fue de \$31.50, y la desviación estándar de \$6.00. ¿Cuál es la probabilidad de que una muestra aleatoria simple de 36 empleados proporcione una media entre \$30 y \$33?
14. Supóngase que se sabe que en cierta población de adictos a las drogas la duración media de abuso es de 5 años y la desviación estándar de 3 años. ¿Cuál es la probabilidad de que una muestra al azar de 36 individuos de dicha población proporcione una duración media de abuso entre 4 y 6 años?
15. Supóngase que el consumo medio diario de proteínas para cierta población es de 125 g, y que para otra población la media es de 100 g. Si los valores diarios de consumo de proteínas en ambas

poblaciones presentan una distribución normal con una desviación estándar de 15 g, ¿cuál es la probabilidad de que muestras al azar e independientes de tamaño 25 de cada población proporcionen una diferencia entre las medias de las muestras de 12 o menos?

16. Supóngase que dos medicamentos, que se supone sirven para reducir el tiempo de respuesta a cierto estímulo, están siendo estudiados por cierto laboratorio. El investigador está inclinado a creer que los tiempos de respuesta, después de la administración de los dos medicamentos, presentan una distribución normal con iguales variancias de .60. Como parte de la evaluación de ambos medicamentos, el A va a administrarse a 15 personas y el medicamento B a 12 personas. Al investigador le gustaría saber entre qué valores estaría el 95 por ciento central de todas las diferencias entre las medias de las muestras si dichos medicamentos son igualmente eficaces y si el experimento se repitiera un gran número de veces utilizando estos tamaños de las muestras.
17. Supóngase que se sabe que la concentración de albúmina en el suero en cierta población de individuos presenta una distribución normal con una media de 4.2 g/100 ml y una desviación estándar de .5. Una muestra al azar de nueve de esos individuos sometidos a una dosis diaria de cierto esteroide oral produjo una concentración media de albúmina en el suero de 3.8 g/100 ml. En base a estos resultados, ¿es probable que el esteroide oral disminuya la concentración de albúmina en el suero?
18. Un estudio llevado a cabo en una gran área metropolitana reveló que, entre los estudiantes de segunda enseñanza, el 35 por ciento de ellos había fumado, en una u otra ocasión, marihuana. Si, de una muestra al azar de 150 de esos estudiantes, sólo 40 admitieron haber fumado alguna vez la marihuana, ¿qué concluiría usted?
19. El sesenta por ciento de los empleados de una gran empresa faltaron a su trabajo debido a enfermedad tres o más días el último año. Si se extrae una muestra aleatoria simple de 150 de dichos empleados, ¿cuál es la probabilidad de que la proporción en la muestra de los que faltaron a su trabajo tres o más días debido a enfermedad esté entre .50 y .65?
20. Una trabajadora social especializada en problemas psiquiátricos piensa que tanto en la comunidad A como en la comunidad B la proporción de adolescentes que sufren de algún problema mental o emocional es de .20. En una muestra de 150 adolescentes de la comunidad A, 15 de ellos tuvieron algunos de estos problemas.

mientras que en una muestra de 100 de la comunidad B, el número fue de 16. Si lo que piensa la trabajadora social es acertado, ¿cuál es la probabilidad de tener una diferencia tan grande como la observada entre estas dos muestras?

21. Se supone que dos medicamentos, A y B, son igualmente eficaces para disminuir el nivel de ansiedad en cierto tipo de persona alterada emocionalmente. Se supone que la proporción de personas en las que los medicamentos son eficaces es de .80. A una muestra aleatoria de 100 personas alteradas emocionalmente se les dio el medicamento A y 85 de ellos experimentaron una disminución en su nivel de ansiedad. El medicamento B fue efectivo en 105 de una muestra aleatoria independiente de 150 individuos con trastornos emocionales. Si ambos medicamentos son, en realidad, igualmente eficaces como se pensó, ¿cuál es la probabilidad de obtener una diferencia en las proporciones de las muestras tan grande que o más grande que la observada?

REFERENCIAS

Referencias citadas

1. George S. Fishman, *Concepts and Methods in Discrete Event Digital Simulation*, John Wiley y Sons, Nueva York, 1973.
2. Paul G. Hoel, *Introduction to Mathematical Statistics*, tercera edición, Wiley, Nueva York, 1962.
3. R. L. Anderson y T. A. Bancroft, *Statistical Theory in Research*, McGraw-Hill, Nueva York, 1952.

Otras referencias, libros

1. John E. Freund y Ronald E. Walpole, *Mathematical Statistics*, tercera edición, Prentice-Hall, Englewood Cliffs, N.J., 1980.
2. Richard J. Larsen y Morris L. Marx, *An Introduction to Mathematical Statistics and Its Applications*, Prentice-Hall, Englewood Cliffs, N.J., 1981.

5

Estimación

5.1 INTRODUCCIÓN

Ahora se estudiará la *estimación*, la primera de las dos áreas generales de la inferencia estadística. La segunda área general, la *prueba de hipótesis*, se estudia en el siguiente capítulo.

En el capítulo 1 se definió la inferencia estadística como el procedimiento por medio del cual se llega a decisiones acerca de un gran volumen de datos examinando sólo una pequeña porción de ellos. Más específicamente, el gran volumen de datos, y la pequeña porción de ellos, a los que se hace referencia en dicha definición son una población y una muestra extraída de ella, respectivamente. Esto conduce al siguiente enunciado de definición de la inferencia estadística.

Definición

La inferencia estadística es el procedimiento por medio del cual se llega a inferencias acerca de una población con base en los resultados obtenidos de una muestra extraída de esa población.

El proceso de estimación implica calcular, a partir de los datos de una muestra, alguna estadística que se ofrece como una aproximación del parámetro correspondiente de la población de la cual se extrajo la muestra.

La explicación de las razones en que se funda la estimación en el campo de las ciencias de la salud se apoya en la suposición de que quie-

nes trabajan en este campo, tienen interés en los parámetros de varias poblaciones. Si este es el caso, existen dos buenas razones por las que se debe confiar en los procedimientos de estimación para obtener información respecto a dichos parámetros. Primero, muchas poblaciones de interés, aunque finitas, son tan grandes que no se podría llevar a cabo un estudio del 100 por ciento desde el punto de vista del costo. Segundo, no es posible estudiar por completo las poblaciones que son infinitas.

Supóngase que el administrador de un hospital grande está interesado en saber la edad promedio de los pacientes que fueron admitidos a su hospital durante un determinado año. Es posible que considere demasiado laborioso consultar todos los registros de todos los pacientes admitidos durante ese año y, como consecuencia, decide examinar una muestra de los registros a partir de los cuales pueda calcular una estimación de la edad promedio de los pacientes admitidos ese año.

Un médico general puede estar interesado en saber qué proporción de cierto tipo de individuos, tratados con un determinado medicamento, sufre efectos secundarios indeseables. Sin duda, su concepto de población consta de todas aquellas personas que alguna vez han sido, o serán tratadas, con este medicamento. Aplazar una conclusión hasta que haya observado la población completa podría tener un efecto adverso en el ejercicio de su profesión.

Estos dos ejemplos impulsaron cierto interés en estimar la medida y la proporción de una población, respectivamente. Otros parámetros, la estimación de los cuales se estudiará en este capítulo, son la diferencia entre dos medias, la diferencia entre dos proporciones, la variancia de la población y la razón de dos variancias.

Se encontrará que, para cada uno de estos parámetros, pueden calcularse dos tipos de estimación: una estimación puntual y una estimación por intervalos. Una *estimación puntual* es un solo valor numérico utilizado para estimar el parámetro correspondiente de la población. Una *estimación por intervalos* consta de dos valores numéricos que definen un intervalo que, con un grado especificado de confianza, se considera incluye al parámetro que se está estimando. Estos conceptos se explicarán en las siguientes secciones.

Nótese que se ha dado el nombre de *estimación* a un solo valor calculado. La regla que dice cómo calcular este valor, o estimación, se conoce como *estimador*. Los estimadores en general se presentan como fórmulas. Por ejemplo,

$$\bar{x} = \frac{\sum x_i}{n}$$

es un estimador de la media de la población, μ . El valor numérico único que resulta de evaluar esta fórmula se conoce como estimación del parámetro, μ .

En muchos casos, puede estimarse un parámetro por medio de más de un estimador. Por ejemplo, podría utilizarse la mediana de la muestra para estimar la media de la población. ¿Cómo decidir entonces qué estimador debe utilizarse para estimar un determinado parámetro? La decisión se basa en criterios que reflejan la “bondad” de los estimadores particulares. Cuando se miden contra estos criterios, algunos estimadores son mejores que otros. Uno de estos criterios es la propiedad de ser *insesgado*.

Se dice que un estimador, por decir T , del parámetro θ es un estimador insesgado de θ si $E(T) = \theta$. $E(T)$ se lee “el valor esperado de T ”. Para una población finita, $E(T)$ se obtiene tomando el valor promedio de T calculado a partir de todas las muestras posibles de un determinado tamaño que puedan extraerse de la población. Es decir, $E(T) = \mu_T$. Para una población infinita, $E(T)$ se define en términos del cálculo matemático.

En el capítulo anterior se ha visto que la media de la muestra, la proporción de la muestra, la diferencia entre las medias de dos muestras y la diferencia entre las proporciones de dos muestras son cada una estimadores insesgados de sus parámetros correspondientes. Esta propiedad estaba implícita cuando se dijo que los parámetros eran las medias de las distribuciones de muestreo correspondientes. Por ejemplo, dado que la media de la distribución de muestreo de $\bar{x}$ es igual a μ , se sabe que $\bar{x}$ es un estimador insesgado de μ . En este libro no se estudiarán los otros criterios de buenos estimadores. El lector interesado encontrará que los estudian con todo detalle Freund y Walpole¹ y Mood, Graybill y Boes² entre otros. Un estudio matemático mucho menos riguroso puede encontrarse en Yamane.³

Poblaciones muestreadas y poblaciones blanco. El investigador en el área de salud, quien utiliza los procedimientos de inferencia estadística, debe estar al tanto de las diferencias entre dos tipos de población: la *población muestreada* y la *población objetivo*. La población muestreada es la población de la cual en realidad se extrae una muestra. La población objetivo es la población de la cual se desea hacer una inferencia. Estas dos poblaciones pueden ser o no la misma. Los procedimientos de inferencia estadística permiten hacer inferencias acerca de las poblaciones muestreadas (siempre que se hayan utilizado méto-

dos de muestreo apropiados). Sólo cuando la población objetivo y la población muestreada son la misma, pueden utilizarse procedimientos de inferencia estadística para llegar a conclusiones acerca de la población objetivo. En caso de que ambas poblaciones sean distintas, el investigador puede llegar a conclusiones acerca de la población objetivo sólo en base a consideraciones no estadísticas.

Supóngase, por ejemplo, que un investigador desea estimar la efectividad de un método para tratar la artritis reumatoide. La población objetivo consta de todos los pacientes que sufren esta enfermedad. No es práctico extraer una muestra de esta población. Sin embargo, el investigador puede extraer una muestra de todos los pacientes con artritis reumatoide de alguna clínica específica. Estos pacientes constituyen la población muestreada y, si se utilizan métodos de muestreo apropiados, pueden hacerse inferencias sobre esta población muestreada en base a la información de la muestra. Si el investigador desea hacer inferencias acerca de todos los pacientes con artritis reumatoide, debe confiar en los medios no estadísticos para hacerlo. Quizá el investigador sepa que la población muestreada es similar, respecto a todas las características importantes, a la población objetivo. Es decir, es posible que el investigador sepa que la edad, sexo, severidad de la enfermedad, duración de desarrollo de ésta, etc., son similares. Y con base en este conocimiento, el investigador puede ya extrapolar sus descubrimientos a la población objetivo.

En muchos casos, la población muestreada y la población objetivo son idénticas y, cuando esto ocurre, las inferencias en torno a la población objetivo son directas. Sin embargo, el investigador debe estar consciente de que este no siempre es el caso, a fin de que no caiga en el error de hacer inferencias erróneas acerca de una población que difiere de la que ha sido muestreada.

Muestras aleatorias y no aleatorias. En los ejemplos y ejercicios de este libro, se supone que los datos que van a analizarse provienen de muestras aleatorias. La estricta validez de los procedimientos estadísticos estudiados depende de esta suposición. En muchos casos, en las aplicaciones del mundo real, es imposible o no resulta práctico utilizar muestras verdaderamente aleatorias. En experimentos con animales, por ejemplo, los investigadores suelen utilizar los animales con que cuentan o su propia raza de cría. Si los investigadores tuvieran que depender de material seleccionado al azar, se llevaría a cabo muy poca investigación de este tipo. Una vez más, las consideraciones no

estadísticas juegan un papel en el proceso de generalización. Los investigadores pueden afirmar que las muestras realmente utilizadas equivalen a muestras aleatorias simples, dado que no hay razón para pensar que el material verdaderamente utilizado no es representativo de la población de la cual se desean hacer inferencias.

En muchos proyectos de investigación en el área de la salud, se utilizan muestras de conveniencia y no muestras aleatorias. Puede ser que los investigadores tengan que confiar en el personal voluntario o en personas disponibles, como los estudiantes de su clase. Una vez más, deben hacerse generalizaciones con base en consideraciones no estadísticas. Sin embargo, las consecuencias de dichas generalizaciones pueden ser útiles o pueden ir desde erróneas hasta desastrosas.

En algunos casos puede introducirse aleatoriedad en un experimento aun cuando los individuos disponibles no sean seleccionados al azar de alguna población bien definida. Al comparar dos tratamientos, por ejemplo, a cada individuo puede asignársele al azar uno u otro de los tratamientos. Las inferencias en tales casos se aplican a los tratamientos y no a los individuos; en consecuencia, dichas inferencias son válidas.

5.2 INTERVALO DE CONFIANZA PARA LA MEDIA DE UNA POBLACIÓN

Supóngase que un investigador desea estimar la media de alguna población con distribución normal. Extrae una muestra al azar de tamaño n de la población y calcula $\bar{x}$, que utiliza como una estimación puntual de μ . Aunque esta estimación de μ posee todas la cualidades de un buen estimador, se sabe que, debido a los caprichos del muestreo, no puede esperarse que $\bar{x}$ sea igual a μ .

Por lo tanto, sería mucho más significativo estimar μ mediante un intervalo que de alguna forma muestre la magnitud probable de μ .

Para obtener dicha estimación de intervalo, debe aprovecharse lo que se sabe acerca de las distribuciones de muestreo. En el presente caso, dado que se tiene interés en la media de la muestra como estimador de la media de una población, debe recordarse lo que se sabe acerca de la distribución muestral de la media de la muestra.

En el capítulo anterior se aprendió que si el muestreo se realiza a partir de una población con distribución normal, la distribución muestral de la media de la muestra presentará una distribución normal con una media $\mu_{\bar{x}}$ igual a la media de la población, μ , y una variancia

$\sigma_{\bar{x}}^2$ igual a σ^2/n . Podría graficarse la distribución muestral si sólo se supiera dónde se localiza sobre el eje $\bar{x}$. Con base en el conocimiento que se tiene sobre las distribuciones normales, en general, se sabe aún más de la distribución de $\bar{x}$ de este caso. Por ejemplo, se sabe que sin importar dónde se localiza, aproximadamente el 95 por ciento de los valores posibles de $\bar{x}$ que constituyen la distribución están dentro de dos desviaciones estándar respecto de la media. Los dos puntos que están a dos desviaciones estándar de la media son $\mu - 2\sigma_{\bar{x}}$ y $\mu + 2\sigma_{\bar{x}}$, de modo que el intervalo $\mu \pm 2\sigma_{\bar{x}}$ contendrá aproximadamente el 95 por ciento de los valores posibles de $\bar{x}$. Se sabe que μ y, por lo tanto, $\mu_{\bar{x}}$ se desconocen, pero puede colocarse arbitrariamente la distribución muestral de $\bar{x}$ sobre el eje $\bar{x}$.

Dado que se desconoce el valor de μ , no se logra mucho por medio de la expresión $\mu \pm 2\sigma_{\bar{x}}$. Sin embargo, se tiene una estimación puntual de μ que es $\bar{x}$. ¿Resultaría útil construir un intervalo en torno a esta estimación puntual de μ ? La respuesta es sí. Supóngase que se construyeran intervalos en torno a cualquier valor posible de $\bar{x}$ calculados a partir de todas las muestras posibles de tamaño n de la población de interés. Se tendría un gran número de intervalos de la forma $\bar{x} \pm 2\sigma_{\bar{x}}$ con amplitudes todas iguales a la amplitud del intervalo en




Figura 5.2.1 Intervalo de confianza del 95 por ciento para μ .

torno a la μ desconocida. Aproximadamente el 95 por ciento de estos intervalos tendrían centros que caen dentro del intervalo $\pm 2\sigma_{\bar{x}}$ en torno a μ . Cada uno de los intervalos cuyos centros caen dentro de $2\sigma_{\bar{x}}$ de μ contendrían a μ . Estos conceptos se ilustran en la figura 5.2.1. En la figura 5.2.1 se observa que $\bar{x}_1, \bar{x}_3$ y $\bar{x}_4$ caen dentro del intervalo $2\sigma_{\bar{x}}$ en torno a μ y, en consecuencia, los intervalos $2\sigma_{\bar{x}}$ alrededor de estas medias de las muestras incluyen el valor de μ . Las medias de las muestras $\bar{x}_2$ y $\bar{x}_5$ no caen dentro del intervalo $2\sigma_{\bar{x}}$ en torno a μ , y los intervalos $2\sigma_{\bar{x}}$ en torno a ellas no incluyen a μ .

Ejemplo 5.2.1

Supóngase que un investigador, interesado en obtener una estimación del nivel promedio de alguna enzima en cierta población humana, toma una muestra de 10 individuos, determina el nivel de la enzima en cada uno y calcula la media muestral $\bar{x} = 22$. Supóngase que se sabe además que la variable de interés presenta una distribución aproximadamente normal con una variancia de 45. Un intervalo de confianza de aproximadamente el 95 por ciento para μ está dado por

$$\begin{aligned}\bar{x} \pm 2\sigma_{\bar{x}} \\ 22 \pm 2\sqrt{\frac{45}{10}} \\ 22 \pm 2(2.12) \\ 17.76, 26.24\end{aligned}$$

Examínese la composición de esta estimación de intervalo. Contiene en su centro la estimación puntual de μ . Se reconoce al 2 como un valor de la distribución normal unitaria que dice dentro de cuántos errores estándar están aproximadamente el 95 por ciento de los valores posibles de $\bar{x}$. Este valor de z se conoce como *coeficiente de confiabilidad*. El último componente, $\sigma_{\bar{x}}$, es el error estándar, o desviación estándar, de la distribución de muestreo de $\bar{x}$. En general, entonces, una estimación de intervalo puede expresarse como sigue:

$$\text{estimador} \pm (\text{coeficiente de confiabilidad}) \times (\text{error estándar}) \quad (5.2.1)$$

En particular, cuando el muestreo se realiza a partir de una distribución normal con variancia conocida, una estimación por intervalos para μ puede expresarse como

$$\bar{x} \pm z_{(1-\alpha/2)}\sigma_{\bar{x}} \quad (5.2.2)$$

¿Cómo se interpreta el intervalo dado por 5.2.2?. En el presente ejemplo, donde el coeficiente de confiabilidad es igual a 2, se dice que, al repetir el muestreo aproximadamente el 95 por ciento de los intervalos construidos mediante 5.2.2 incluirán la media de la población. Esta interpretación se basa en la probabilidad de ocurrencia de diferentes valores de $\bar{x}$. Puede generalizarse esta interpretación si se designa el área total bajo la curva de $\bar{x}$, que queda fuera del intervalo $\mu \pm 2\sigma_{\bar{x}}$ como α y el área dentro del intervalo como $1 - \alpha$ y puede darse la siguiente *interpretación probabilística* de 5.2.2.

En el muestreo repetido, a partir de una población con distribución normal, el 100 (1 - α) por ciento de todos los intervalos de la forma $\bar{x} \pm z_{(1 - \alpha/2)}\sigma_{\bar{x}}$ incluirán, a la larga, la media de la población, μ .

La cantidad $1 - \alpha$, en este caso .95, se conoce como *coeficiente de confianza* y el intervalo $\bar{x} \pm z_{(1 - \alpha/2)}\sigma_{\bar{x}}$ se conoce como *intervalo de confianza* para μ . Cuando $(1 - \alpha) = .95$, el intervalo recibe el nombre de intervalo de confianza del 95 por ciento para μ . En el presente ejemplo, se dice que se tiene el 95 por ciento de confianza de que la media de la población esté entre 17.76 y 26.24. Esto se conoce como la *interpretación práctica* de 5.2.2. En general, puede expresarse como sigue.

Se tiene el 100(1 - α) por ciento de confianza de que el intervalo único calculado, $\bar{x} \pm z_{(1 - \alpha/2)}\sigma_{\bar{x}}$, contenga la media de la población, μ .

En el ejemplo dado aquí podría preferirse, en lugar de 2, el valor más exacto de z , 1.96, que corresponde a un coeficiente de confianza de .95. El investigador puede utilizar cualquier coeficiente de confianza que desee, y los valores que se utilizan con más frecuencia son .90, .95 y .99.

Ejemplo 5.2.2

Un fisioterapeuta desea estimar, con el 99 por ciento de confianza, la media de fuerza máxima de un músculo particular en cierto grupo de individuos. Se inclina a suponer que los valores de dicha fuerza muestran una distribución aproximadamente normal con una variancia de

144. Una muestra de 15 individuos, quienes participaron en el experimento, proporcionaron una media de 84.3. En la tabla F, el valor de z que corresponde a un coeficiente de confianza de .99 es de 2.58. Este es el coeficiente de confiabilidad. El error estándar es de

$$\sigma_x = \frac{12}{\sqrt{15}} = 3.10$$

El intervalo de confianza del 99 por ciento para μ es entonces,

$$84.3 \pm 2.58(3.10)$$

$$84.3 \pm 8.0$$

$$76.3, 92.3$$

Se dice que se tiene el 99 por ciento de confianza de que la media de la población esté entre 76.3 y 92.3 ya que, al repetir el muestreo, el 99 por ciento de todos los intervalos que podrían construirse en la forma que acaba de describirse incluirían a la media de la población.

Muestreo a partir de poblaciones no normales. No siempre será posible o prudente suponer que la población de interés muestra una distribución normal. Gracias al teorema del límite central, esto no será un problema si puede seleccionarse una muestra lo suficientemente grande. Se ha aprendido que, para muestras grandes, la distribución muestral de $\bar{x}$ presenta una distribución aproximadamente normal sin importar cómo está distribuida la población original.

Ejemplo 5.2.3

En un estudio del flujo de pacientes a través de las oficinas de médicos generales, se encontró que, en promedio, una muestra de 35 pacientes llegaban 17.2 minutos tarde a las citas. Una investigación previa había demostrado que la desviación estándar era de 8 minutos aproximadamente. Se tuvo la sensación que la distribución de la población no era normal. ¿Cuál es el intervalo de confianza del 90 por ciento para μ , la cantidad de tiempo promedio verdadera de llegada tarde a las citas?

Dado que el tamaño de la muestra es bastante grande (mayor de 30) y se conoce la desviación estándar de la población, la situación se aproxima al teorema del límite central y se supone que la distribución muestral de $\bar{x}$ presenta una distribución aproximadamente normal. Utilizando la tabla F, se encuentra que el coeficiente de confiabilidad,

que corresponde a un coeficiente de confianza de .90, se aproxima a 1.645 si se interpola. El error estándar es de $\sigma_{\bar{x}} = 8\sqrt{35} = 1.35$, de modo que el intervalo de confianza del 90 por ciento para μ es

$$17.2 \pm 1.645(1.35)$$

$$17.2 \pm 2.2$$

$$15.0, 19.4$$

Ejercicios

5.2.1 En un experimento diseñado para estimar el número promedio de latidos por minuto del corazón para cierta población, en las condiciones del experimento, se encontró que el número promedio de latidos por minuto para 49 personas era de 90. Si resulta lógico suponer que esos 49 pacientes constituyen una muestra aleatoria y que la población está distribuida normalmente, con una desviación estándar de 10, encuentre:

- a) El intervalo de confianza del 90 por ciento para μ .
- b) El intervalo de confianza del 95 por ciento para μ .
- c) El intervalo de confianza del 99 por ciento para μ .

5.2.2 Se encontró que el nivel indirecto medio de bilirrubinas en el suero de 16 niños de cuatro días de nacidos era de 5.98 mg/100 cc. Suponiendo que los niveles de bilirrubinas en los niños de cuatro días de nacidos presentan una distribución aproximadamente normal con una desviación estándar de 3.5 mg/100 cc., encuentre:

- a) El intervalo de confianza del 90 por ciento para μ .
- b) El intervalo de confianza del 95 por ciento para μ .
- c) El intervalo de confianza del 99 por ciento para μ .

5.2.3 En un estudio de la duración de hospitalización realizado por varios hospitales en cooperación, se extrajo al azar una muestra de 64 pacientes con úlcera péptica de una lista de todos los pacientes con esta enfermedad admitidos alguna vez en los hospitales y se determinó, para cada uno, su duración de hospitalización por admisión. Se encontró que la duración media de hospitalización fue de 8.25 días. Si se sabe que la desviación estándar de la población es de 3 días, encuentre:

- a) El intervalo de confianza del 90 por ciento para μ .
- b) El intervalo de confianza del 95 por ciento para μ .
- c) El intervalo de confianza del 99 por ciento para μ .

5.2.4 Una muestra de 100 hombres adultos aparentemente normales, de 25 años de edad, mostró una presión sistólica sanguínea media de 125. Si se tiene la sensación de que la desviación estándar de la población es de 15, encuentre:

- a) El intervalo de confianza del 90 por ciento para μ .
- b) El intervalo de confianza del 95 por ciento para μ .

5.3 INTERVALO DE CONFIANZA PARA LA DIFERENCIA ENTRE LAS MEDIAS DE DOS POBLACIONES

A veces surgen casos en los que se tiene interés en estimar la diferencia entre la media de dos poblaciones. A partir de cada población se extrae una muestra aleatoria independiente y, de los datos de cada una, se calculan las medias de las muestras $\bar{x}_1$ y $\bar{x}_2$, respectivamente. En el capítulo anterior se aprendió que el estimador $\bar{x}_1 - \bar{x}_2$ proporciona una estimación insesgada de $\mu_1 - \mu_2$, la diferencia entre las medias de las poblaciones. De lo expuesto en el capítulo 4, se sabe también que, dependiendo de las condiciones, la distribución muestral de $\bar{x}_1 - \bar{x}_2$ puede presentar al menos una distribución aproximadamente normal, de modo que en muchos casos se utiliza la teoría pertinente a las distribuciones normales para calcular un intervalo de confianza para $\mu_1 - \mu_2$. Ilústrese ahora primero para el caso donde el muestreo se realiza a partir de una distribución normal y luego para el caso donde no puede hacerse la suposición de poblaciones con distribución normal.

Ejemplo 5.3.1

En un hospital grande para el tratamiento de retrasados mentales, una muestra de 12 individuos con síndrome de Down proporcionó una concentración media de ácido úrico en suero de $\bar{x}_1 = 4.5$ mg/100 ml. En un hospital general, se encontró que una muestra de 15 individuos normales de la misma edad y sexo tenía un valor medio de $\bar{x}_2 = 3.4$. Si resulta lógico suponer que las dos poblaciones de concentraciones

presentan una distribución normal con variancias iguales a 1, encuentre el intervalo de confianza del 95 por ciento para $\mu_1 - \mu_2$.

Para una estimación puntual de $\mu_1 - \mu_2$, utilícese

$$\bar{x}_1 - \bar{x}_2 = 4.5 - 3.4 = 1.1.$$

En la tabla F se encuentra que el coeficiente de confiabilidad que corresponde a .95 es de 1.96. El error estándar está dado por la expresión

$$\sigma_{\bar{x}_1 - \bar{x}_2} = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} = \sqrt{\frac{1}{12} + \frac{1}{15}} = .39$$

El intervalo de confianza del 95 por ciento es entonces

$$1.1 \pm 1.96(.39)$$

$$1.1 \pm .8$$

$$.3, 1.9$$

Se dice que se tiene el 95 por ciento de confianza de que la diferencia real, $\mu_1 - \mu_2$, esté entre .3 y 1.9, porque, al repetir el muestreo, el 95 por ciento de los intervalos construidos de esta manera incluirían la diferencia entre las medias reales.

Muestreo a partir de poblaciones no normales. La construcción de un intervalo de confianza para la diferencia entre la media de dos poblaciones, cuando el muestreo se realiza a partir de poblaciones no normales, se lleva a cabo en la misma forma anterior si los tamaños de las muestras, n_1 y n_2 , son grandes. Una vez más, este es un resultado del teorema del límite central.

Ejemplo 5.3.2

El ingreso medio familiar de una muestra de 75 pacientes admitidos a un hospital A fue de $\bar{x}_1 = \$6,800$, mientras que el promedio basado en una muestra de 80 pacientes de un hospital B se encontró como $\bar{x}_2 = \$4,450$. Si las desviaciones estándar de las poblaciones son

$$\sigma_1 = \$600 \text{ y } \sigma_2 = \$500,$$

encuentre el intervalo de confianza del 99 por ciento para $\mu_1 - \mu_2$, la diferencia entre las medias de ambas poblaciones.