

Tabla 8.3.2 Cálculos intermedios para las ecuaciones normales, ejemplo 8.3.1.

Calificación obtenida en la nueva prueba	Calificación obtenida en la prueba estandarizada			
x	y	x^2	y^2	xy
50	61	2500	3721	3050
55	61	3025	3721	3355
60	59	3600	3481	3540
65	71	4225	5041	4615
70	80	4900	6400	5600
75	76	5625	5776	5700
80	90	6400	8100	7200
85	106	7225	11236	9010
90	98	8100	9604	8820
95	100	9025	10000	9500
100	114	10000	12996	11400
Total 825	916	64625	80076	71790

multáneamente las dos ecuaciones siguientes, conocidas como *ecuaciones normales* para un conjunto de datos:

$$\sum y_i = na + b\sum x_i \quad (8.3.2)$$

$$\sum x_i y_i = a\sum x_i + b\sum x_i^2 \quad (8.3.3)$$

En la tabla 8.3.2 se tienen los valores necesarios para sustituirlos en las ecuaciones normales.

Sustituyendo los valores apropiados de la tabla 8.3.2 en las ecuaciones 8.3.2 y 8.3.3, se tiene que

$$916 = 11a + 825b$$

$$71790 = 825a + 64625b$$

Pueden resolverse estas ecuaciones por cualquier método conocido, para obtener

$$a = -.9973 \quad \text{y} \quad b = 1.1236$$

La ecuación lineal para la recta de mínimos cuadrados que describe la relación entre las calificaciones obtenidas en la prueba estandarizada y las obtenidas en la nueva prueba puede escribirse entonces como:

$$y_c = -.9973 + 1.1236x \quad (8.3.4)$$

Esta ecuación indica que, dado que a es negativa, la línea cruza el eje Y debajo del origen y que dado que b , la pendiente, es positiva, la recta se extiende de la parte inferior izquierda de la gráfica a la parte superior derecha de la misma. Se observa además que, para cada unidad de incremento en x , y aumenta en una cantidad igual a 1.1236. Se ha agregado el subíndice c a y para indicar que es un valor calculado a partir de la ecuación, más que un valor observado de Y .

Sustituyendo dos valores convenientes de X en la ecuación 8.3.4, pueden obtenerse las coordenadas necesarias para trazar la recta. Supóngase, primero, que $X = 50$, de lo que se obtiene

$$y_c = -.9973 + 1.1236(50) = 55.1827$$

Si se supone que $X = 100$, se tiene que

$$y_c = -.9973 + 1.1236(100) = 111.3627$$

La recta, junto con los datos originales, se muestra en la figura 8.3.2.

Los valores numéricos de a y b pueden obtenerse mediante otras fórmulas que no implican directamente las ecuaciones normales. Las fórmulas son las siguientes:

$$b = \frac{n\sum xy - (\sum x)(\sum y)}{n\sum x^2 - (\sum x)^2} \quad (8.3.5)$$

$$a = \frac{\sum y - b\sum x}{n} \quad (8.3.6)$$

Para el presente ejemplo, se tiene que

$$b = \frac{11(71790) - (825)(916)}{11(64625) - (825)^2} = 1.1236$$

$$a = \frac{916 - 1.1236(825)}{11} = -.9973$$

Así, se observa que las ecuaciones 8.3.5 y 8.3.6 dan los mismos resultados que se obtienen también al resolver las ecuaciones normales.

Ahora que se ha obtenido lo que se conoce como la “mejor” recta para describir la relación que existe entre las dos variables, se necesita determinar bajo qué criterio se considera mejor. Antes de que se enuncie el criterio, obsérvese la figura 8.3.2. Se observa que la recta de los mínimos cuadrados no pasa por punto alguno de los que se graficaron en el diagrama de dispersión. En otras palabras, los puntos observados *se desvían* de la recta en diversas cantidades.




Figura 8.3.2 Datos originales y recta de mínimos cuadrados para el ejemplo 8.3.1.

La recta que se ha trazado a través de los puntos es mejor en este sentido:

La suma de las desviaciones verticales, elevadas al cuadrado, de los puntos correspondientes a los datos observados (y_i) con respecto a la recta de los mínimos cuadrados es menor que la suma de las desviaciones verticales, elevadas al cuadrado, de los puntos de los datos que forman cualquier otra recta.

En otras palabras, si se eleva al cuadrado la distancia vertical desde cada punto observado (y_i) hasta la recta de los mínimos cuadrados y se suman los valores obtenidos para todos los puntos, el total resultante será menor que el total calculado en forma semejante para cualquier otra recta que pueda trazarse a través de los puntos. Por es-

ta razón, la recta que se ha trazado recibe el nombre de recta de mínimos cuadrados.

Ejercicios

Para cada uno de los siguientes ejercicios *a)* trace un diagrama de dispersión y *b)* obtenga la ecuación de regresión y gráfiquela en el diagrama de dispersión.

- 8.3.1 Se llevó a cabo un experimento para estudiar el efecto de cierto medicamento para disminuir la frecuencia cardíaca en adultos. La variable independiente es la dosis en miligramos del medicamento, y la variable dependiente es la diferencia entre la frecuencia cardíaca más baja después de la administración del medicamento y un control antes de administrarlo. Se reunieron los siguientes datos.

<i>Dosis (mg)</i> <i>X</i>	<i>Disminución de la frecuencia cardíaca (latidos/min)</i> <i>Y</i>
.5	10
.75	8
1.00	12
1.25	12
1.50	14
1.75	12
2.00	16
2.25	18
2.50	17
2.75	20
3.00	18
3.25	20
3.50	21

- 8.3.2 Los datos siguientes muestran la densidad óptica de cierta sustancia a diferentes niveles de concentración:

<i>Nivel de concentración (X)</i>	<i>Densidad óptica (Y)</i>
80	.08
120	.12

<i>Nivel de concentración (X)</i>	<i>Densidad óptica (Y)</i>
160	.18
200	.21
240	.28
280	.28
320	.38
360	.40
400	.42
440	.50
480	.52
520	.60

8.3.3 El administrador de un hospital reunió los siguientes datos sobre el costo por comida de una comida estándar a diferentes volúmenes de preparación.

<i>Número de comidas servidas (X)</i>	<i>Costo por comida (Y)</i>
30	\$1.15
35	1.10
40	.98
45	1.01
50	.97
55	.90
60	.89
70	.85
75	.78
80	.70
65	.80

8.3.4 Se llevó a cabo un experimento para estudiar la relación entre una medición objetiva de la ansiedad y la frecuencia cardiaca en adultos. Se obtuvieron los siguientes resultados en 12 adultos normales.

<i>Frecuencia cardiaca por minuto (X)</i>	<i>Medición objetiva de la ansiedad (Y)</i>
50	48
55	41

<i>Frecuencia cardiaca por minuto (X)</i>	<i>Medición objetiva de la ansiedad (Y)</i>
60	45
65	41
70	42
75	36
80	38
85	36
90	30
95	32
100	34
105	25

8.3.5 Se reunieron los siguientes datos en un estudio de la relación entre la inteligencia y el tamaño de la familia.

<i>Número de niños en la familia</i>	<i>Calificación promedio de la inteligencia medida para todos los niños en la familia</i>
1	105
2	102
3	104
4	100
5	97
6	101
7	95
8	93
9	97
10	88

8.4 EVALUACIÓN DE LA ECUACIÓN DE REGRESIÓN

Una vez que se ha obtenido la ecuación de regresión, debe evaluarse para determinar si describe adecuadamente la relación entre las dos variables y si puede utilizarse convenientemente con fines de predicción y estimación.

El coeficiente de determinación. Una forma de evaluar la ecuación de regresión es comparar la dispersión de los puntos en torno a la rec-




Figura 8.4.1 Diagrama de dispersión que muestra las desviaciones total, explicada e inexplorada para un valor seleccionado de Y , ejemplo 8.3.1.

ta de regresión con la dispersión alrededor de $\bar{y}$, la media de los valores de la muestra de Y . Si se toma el diagrama de dispersión para el ejemplo 8.3.1 y se traza a través de los puntos una recta que intersecte el eje Y en $\bar{y}$ y sea paralela al eje X , puede obtenerse una impresión visual de las magnitudes relativas de la dispersión de los puntos en torno a esta recta y la recta de regresión. Esto se ha hecho en la figura 8.4.1.

Parece más bien obvio, al observar la figura 8.4.1, que la dispersión de los puntos alrededor de la recta de regresión es mucho menor que la dispersión en torno a la recta $\bar{y}$. Sin embargo, no es posible que se decida que la ecuación es útil sólo en base a esto. La situación puede no ser siempre tan evidente, de modo que sería mucho más conveniente

una medida objetiva de algún tipo. El llamado *coeficiente de determinación* es dicha medida.

Antes de definir el coeficiente de determinación, debe justificarse su uso examinando la lógica en que se basa su cálculo. Empiécese por considerar el punto correspondiente a cualquier valor observado, y_i , y continúese midiendo la distancia vertical entre dicho punto y la recta $\bar{y}$. A esto se le da el nombre de *desviación total* y se designa por $(y_i - \bar{y})$.

Si se mide la distancia vertical entre la recta de regresión y la recta $\bar{y}$, se obtiene $(y_c - \bar{y})$, que se conoce como *desviación explicada*, ya que muestra en cuánto disminuye la desviación total cuando la recta de regresión se ajusta a los puntos.

Finalmente, se mide la distancia vertical entre el punto observado y la recta de regresión para obtener $(y_i - y_c)$, que se conoce como *desviación inexplicada*, ya que representa la porción de la desviación total que no está “explicada” o tomada en cuenta por la introducción de la recta de regresión. Estas tres cantidades se ilustran para un valor característico de Y en la figura 8.4.1.

Se ve entonces que la desviación total para una y_i particular es igual a la suma de las desviaciones explicada e inexplicada. Esto puede escribirse simbólicamente como

$$\begin{array}{ccccc} (y_i - \bar{y}) & = & (y_c - \bar{y}) & + & (y_i - y_c) \\ \text{desviación} & & \text{desviación} & & \text{desviación} \\ \text{total} & & \text{explicada} & & \text{inexplicada} \end{array} \quad (8.4.1)$$

Si se miden estas desviaciones para cada valor de y_i y y_c , se eleva al cuadrado cada desviación y se suman las desviaciones elevadas al cuadrado, se tiene que

$$\begin{array}{ccccc} \sum (y_i - \bar{y})^2 & = & \sum (y_c - \bar{y})^2 & + & \sum (y_i - y_c)^2 \\ \text{suma total} & & \text{suma explicada} & & \text{suma inexplicada} \\ \text{de cuadrados} & & \text{de cuadrados} & & \text{de cuadrados} \end{array} \quad (8.4.2)$$

Puede escribirse esta relación todavía en otra forma como

$$SC_T = SCE_x + SCI_n$$

Estas cantidades pueden considerarse como medidas de dispersión o de variabilidad. La *suma de cuadrados total*, por ejemplo, es una medida de la dispersión de los valores observados de Y en torno a su

media $\bar{y}$, es decir, este término es una medida de la variación total en los valores observados de Y . El lector se dará cuenta que este término es el numerador de la fórmula bien conocida de la variancia muestral.

La *suma de cuadrados explicada* mide la parte de la variabilidad total en los valores observados de Y que se toma en cuenta mediante la relación lineal entre los valores observados de X y Y . Esta cantidad se conoce también como la *suma de cuadrados debida a la regresión lineal*.

La *suma de cuadrados inexplicada* es una medida de la dispersión de los valores de Y observados en torno a la recta de regresión y, algunas veces, se conoce como *suma de error de cuadrados* o *suma residual de cuadrados*. Es la cantidad que se minimiza cuando se obtiene la recta de mínimos cuadrados.

Los cálculos necesarios para obtener la suma de cuadrados total, la explicada y la inexplicada para el ejemplo ilustrativo se muestran en la tabla 8.4.1.

Para el ejemplo ilustrativo se tiene que

$$\begin{aligned} SST &= SSE_x + SSU \\ 3798.1822 &\approx 3471.8116 + 326.1455 \\ 3798.1822 &\approx 3797.9571 \end{aligned}$$

La falla en los dos términos a la derecha de la igualdad para dar como suma el total de la izquierda se debe al redondeo.

Puede calcularse la suma de cuadrados total mediante la fórmula más adecuada

$$\sum (y_i - \bar{y})^2 = \sum y_i^2 - \frac{(\sum y_i)^2}{n} \quad (8.4.3)$$

y la suma de cuadrados explicada puede calcularse mediante la expresión

$$\sum (y_c - \bar{y})^2 = b^2 \sum (x_i - \bar{x})^2 = b^2 [\sum x_i^2 - (\sum x_i)^2/n] \quad (8.4.4)$$

La suma de cuadrados inexplicada se obtiene en forma más adecuada restando. Para el ejemplo ilustrativo se tiene que

$$\begin{aligned} SCT &= 61^2 + 61^2 + \cdots + 114^2 - \frac{(916)^2}{11} = 3798.1818 \\ SCE_x &= (1.1236)^2 \left[50^2 + 55^2 + \cdots + 100^2 - \frac{(825)^2}{11} \right] \\ &= 3471.8116 \end{aligned}$$

Tabla 8.4.1 Cálculo de las sumas de cuadrados total, explicada e inexplicada.

Número del paciente	Calificaciones obtenidas en la prueba estandarizada (y_i)	$y_c = -9973 + 1.1236x$	$(y_i - \bar{y})$	$(y_i - \bar{y})^2$	$(y_i - y_c)$	$(y_i - y_c)^2$	$(y_c - \bar{y})$	$(y_c - \bar{y})^2$
1	61	55.1827	-22.2727	496.0732	5.8173	33.8410	-28.0900	789.0481
2	61	60.8007	-22.2727	496.0732	.1993	.0397	-22.4720	504.9908
3	59	66.4187	-24.2727	589.1640	-7.4187	55.0371	-16.8540	284.0573
4	71	72.0367	-12.2727	150.6192	-1.0367	1.0747	-11.2360	126.2477
5	80	77.6547	-3.2727	10.7106	2.3453	5.5004	-5.6180	31.5619
6	76	83.2727	-7.2727	52.8922	-7.2727	52.8922	0.0000	0.0000
7	90	88.8907	6.7273	45.2566	1.1093	1.2305	5.6180	31.5619
8	106	94.5087	22.7273	516.5302	11.4913	132.0500	11.2360	126.2477
9	98	100.1267	14.7273	216.8934	-2.1267	4.5229	16.8540	284.0573
10	100	105.7447	16.7273	279.8026	-5.7447	33.0016	22.4720	504.9908
11	114	111.3627	30.7273	944.1670	2.6373	6.9554	28.0900	789.0481
Total	916			$SST = 3798.1822$		$SSE_X = 326.1455$		$SSU = 3471.8116$
$\bar{y} = 83.2727$								

y

$$\begin{aligned}
 SCIn &= SCT - SCE_x \\
 &= 3798.1818 - 3471.8116 \\
 &= 326.3702
 \end{aligned}$$

Los resultados que se obtienen utilizando las fórmulas más adecuadas para el cálculo son los mismos que se muestran en la tabla 8.4.1, excepto por el redondeo.

Intuitivamente, es razonable suponer que, si una ecuación de regresión es apropiada para describir la relación entre dos variables, la suma de cuadrados explicada debe constituir una gran proporción de la suma de cuadrados total. Sería interesante determinar entonces la magnitud de dicha proporción calculando la razón de la suma de cuadrado explicada respecto de la suma de cuadrados total. Esto es exactamente lo que se hace al evaluar una ecuación de regresión basada en los datos de la muestra y el resultado se conoce como *coeficiente de determinación*, r^2 , de la muestra. En otras palabras,

$$r^2 = \frac{\sum (y_c - \bar{y})^2}{\sum (y_i - \bar{y})^2} = \frac{b^2 [\sum x_i^2 - (\sum x_i)^2/n]}{\sum y_i^2 - \frac{(\sum y_i)^2}{n}} = SSE_x / SST$$

En el presente ejemplo, se tiene que, utilizando los valores de las sumas de cuadrados calculadas a partir de las ecuaciones 8.4.3 y 8.4.4.

$$r^2 = \frac{3471.8116}{3798.1818} = .91$$

El coeficiente de determinación de la muestra mide la proximidad del ajuste de la ecuación de regresión de la muestra a los valores observados de Y . Si se observa la tabla 8.4.1, se encuentra que cuando las cantidades $(y_i - y_c)$, las distancias verticales de los valores observados de Y a partir de la ecuación, son pequeñas, la suma de cuadrados inexplicada es pequeña. Esto conduce a una suma de cuadrados explicada grande que, a su vez, conduce a un valor grande de r^2 . Esto se ilustra en la figura 8.4.2.

En la figura 8.4.2a se observa que todas las observaciones están próximas a la recta de regresión y es de esperar que r^2 sea grande. De hecho, el r^2 calculado para estos datos es de .986, lo cual indica que aproximadamente el 99 por ciento de la variación total en los y_i es explicada por la regresión.




Figura 8.4.2 r^2 como medida de la proximidad del ajuste de la recta de regresión de la muestra a las observaciones de la muestra.

En la figura 8.4.2b se ilustra un caso donde los y_i están ampliamente dispersos en torno a la recta de regresión y, por lo tanto, se supone que r^2 es pequeño. El r^2 calculado para los datos es de .403, es decir, menos del 50 por ciento de la variación total en los y_i es explicada por la regresión.

El valor máximo que puede tomar r^2 es de 1, un resultado que se obtiene cuando toda la variación en los y_i es explicada por la regresión. Cuando $r^2 = 1$, todas las observaciones caen sobre la recta de regresión. Esta situación se muestra en la figura 8.4.2c.

El límite inferior de r^2 es 0. Este resultado se obtiene cuando coinciden la recta de regresión y la recta trazada a través de $\bar{y}$. En esta situación, ninguna de las variaciones en los y_i es explicada por la regresión. La figura 8.4.2d ilustra un caso donde r^2 se aproxima a cero.

Cuando r^2 es grande, entonces, la regresión ha explicado una gran proporción de la variabilidad total en los valores observados de Y , y se acepta la ecuación de regresión. Por otra parte, un r^2 pequeño, que indica una falla de la regresión para explicar una gran proporción de la variación total en los valores observados de Y , tiende a arrojar dudas sobre la utilidad de la ecuación de regresión. Sin embargo, la ecuación se somete a un juicio final hasta que haya sido sometida a una prueba estadística objetiva. Dicha prueba se lleva a cabo por medio del análisis de variancia, que permite probar las hipótesis nulas de no relación lineal entre X y Y .

A partir de los tres términos de la suma de cuadrados y sus grados de libertad asociados, puede construirse la tabla de análisis de variancia que se indica en la tabla 8.4.2.

En general, los grados de libertad asociados con la suma de cuadrados debida a la regresión son iguales al número de constantes de la ecuación de regresión menos 1. En el caso lineal simple, se tienen dos constantes, a y b , por lo que los grados de libertad para la regresión son $2 - 1 = 1$. Puede demostrarse que cuando la hipótesis de la no relación lineal entre X y Y es verdadera, y cuando se satisfacen las suposiciones que fundamentan la regresión, la razón que se obtiene dividiendo el cuadrado medio de regresión entre el cuadrado medio residual está distribuida como F con 1 y $n - 2$ grados de libertad. La R.V. calculada se compara entonces con el valor crítico de F , y si la primera es mayor que la última, se rechaza la hipótesis nula de que no existe relación lineal entre X y Y .

Tabla 8.4.2 Tabla ANDEVA para la regresión lineal simple.

Fuente de variación	SC	g.l.	CM	R. V.
Regresión lineal	$SC_{\text{explicada}}$	1	$SC_{\text{explicada}}/1$	$CM_{\text{explicada}}/CM_{\text{inexplicada}}$
Residual	$SC_{\text{inexplicada}}$	$n - 2$	$SC_{\text{inexplicada}}/(n - 2)$	
Total	SC_{total}	$n - 1$		

Para el ejemplo ilustrativo, supóngase que se establecen las siguientes hipótesis:

H_0 : X y Y no están relacionadas linealmente

H_A : X y Y están relacionadas linealmente

$$\alpha = .05$$

Sustituyendo los valores numéricos apropiados en la tabla 8.4.2, se obtiene la tabla 8.4.3. Dado que 95.74 es mayor que 5.12, el valor crítico de F para 1 y 9 grados de libertad, se rechaza la hipótesis nula de no relación lineal entre X y Y y se concluye que las dos variables están relacionadas linealmente. Para esta prueba, dado que $95.74 > 13.61$, se tiene que $p < .005$.

El coeficiente de determinación de la muestra proporciona una estimación puntual de ρ^2 , el *coeficiente de determinación de la población*. Este coeficiente tiene la misma función relativa a la población como la que tiene r^2 con la muestra. Indica qué proporción de la variación total de la población en Y es explicada por la regresión de Y sobre X . Cuando el número de grados de libertad es pequeño, r^2 está sesgada positivamente. Es decir, r^2 tiende a ser grande. Un estimador insesgado de ρ^2 lo proporciona

$$\tilde{r}^2 = 1 - \frac{\sum (y_i - y_c)^2 / (n - 2)}{\sum (y_i - \bar{y})^2 / (n - 1)} \quad (8.4.5)$$

Obsérvese que el numerador de la fracción en la ecuación 8.4.5 es el cuadrado medio inexplicado y que el denominador es el cuadrado medio total. Estas cantidades están incluidas en la tabla de análisis de variancia. Para el ejemplo ilustrativo se tiene que, utilizando los datos de la tabla 8.4.2,

$$\tilde{r}^2 = 1 - \frac{326.3702/9}{3798.1818/10} = 1 - \frac{36.2634}{379.81818} = .9045$$

Se observa que este valor es ligeramente menor que

$$r^2 = 1 - \frac{326.3702}{3798.1818} = 1 - .08593 = .91407$$

Se observa que la diferencia entre r^2 y $\tilde{r}^2$ se debe al factor $(\bar{n} - 1)/(n - 2)$. Cuando n es grande, este factor se aproxima a 1 y la diferencia entre r^2 y $\tilde{r}^2$ tiende a cero.

Tabla 8.4.3 Tabla ANDEVA para el ejemplo 8.3.1.

Fuente de variación	SC	g.l.	CM	R. V.
Regresión lineal	3471.8116	1	3471.8116	95.74
Residual	326.3702	9	36.2634	
Total	3798.1818	10		

Prueba de hipótesis para β . Una alternativa para probar la hipótesis nula de no relación lineal entre dos variables, está basada en b , la pendiente de la ecuación de regresión de la muestra.

Cuando se satisfacen las suposiciones establecidas en la sección 8.2, a y b son estimadores puntuales insesgados de los parámetros correspondientes α y β y; dado que bajo estas suposiciones, las subpoblaciones de los valores de Y están distribuidos normalmente, pueden formarse también intervalos de confianza para α y β y probar hipótesis acerca de ellos.

Cuando se cumplen las suposiciones de la sección 8.2, cada una de las distribuciones muestrales de a y b está distribuida normalmente con las siguientes medias y variancias:

$$\mu_a = \alpha \quad (8.4.6)$$

$$\sigma_a^2 = \frac{\sigma_{y|x}^2 \sum x_i^2}{n \sum (x_i - \bar{x})^2} \quad (8.4.7)$$

$$\mu_b = \beta \quad (8.4.8)$$

y

$$\sigma_b^2 = \frac{\sigma_{y|x}^2}{\sum (x_i - \bar{x})^2} \quad (8.4.9)$$

En las ecuaciones 8.4.7 y 8.4.9, $\sigma_{y|x}^2$ es la variancia inexplicada de las subpoblaciones de los valores de Y .

Con el conocimiento de las distribuciones muestrales de a y b , pueden formarse los intervalos de confianza y probar las hipótesis relativas a α y β en la forma acostumbrada. En general, las inferencias respecto a α no son de interés. Por otra parte, una gran parte del interés se centra en los procedimientos de inferencia respecto a β . La




Figura 8.4.3 Diagramas de dispersión en los que se muestran las relaciones directa e inversa y no relación lineal entre X y Y . a) Relación lineal directa. b) Relación lineal inversa. c) No relación lineal.

razón de esto es el hecho de que β dice mucho acerca de la forma de la relación entre X y Y . Una β positiva indica que, en general, Y aumenta a medida que X aumenta, y se dice que existe una *relación lineal directa* entre X y Y . Una β negativa indica que los valores de Y tienden a disminuir a medida que aumentan los valores de X , y se dice que hay una *relación lineal inversa* entre X y Y . Cuando no hay una relación lineal entre X y Y , β es igual a cero. Estas tres situaciones se presentan en la figura 8.4.3.

Cuando no se conoce el valor real de β , que es la situación más común pueden obtenerse sólo inferencias acerca de él a partir de los datos de la muestra. Específicamente, puede tenerse interés en determinar si los datos de la muestra proporcionan evidencia suficiente que indique que β no es igual a cero. Puede concluirse que β no es igual a cero si puede rechazarse la hipótesis nula de que $\beta = 0$. Si se rechaza esta hipótesis nula, puede concluirse, con probabilidad α (nótese que α , como aquí se utiliza, se refiere a un nivel de significación seleccionado y no a la ordenada al origen de la ecuación de regresión verdadera) de estar equivocado, que existe una relación lineal entre X y Y . Para decidir si esta relación lineal sugerida es directa o inversa, la guía será el signo de b , el estimador de β .

La estadística de prueba cuando $\sigma^2_{y|x}$ se conoce es:

$$z = \frac{b - \beta_0}{\sigma_b} \quad (8.4.10)$$

donde β_0 es el valor de β establecido en la hipótesis. El valor de β establecido en la hipótesis no tiene que ser cero, pero en la práctica,

con más frecuencia de lo que se supone, la hipótesis nula de interés es que $\beta = 0$.

Como regla, $\sigma_{y|x}^2$ se desconoce. Cuando éste es el caso, la estadística de prueba es:

$$t = \frac{b - \beta_0}{s_b} \quad (8.4.11)$$

donde s_b es una estimación de σ_b y t está distribuida como la t de Student con $n - 2$ grados de libertad. Para obtener s_b , primero debe estimarse $\sigma_{y|x}^2$. Un estimador insesgado de este parámetro lo proporciona la variancia inexplicada que se calcula a partir de los datos de la muestra. Es decir,

$$s_{y|x}^2 = \frac{\sum (y_i - y_c)^2}{n - 2} \quad (8.4.12)$$

es un estimador insesgado de $\sigma_{y|x}^2$. Este es el cuadrado medio inexplicado que aparece en la tabla de análisis de variancia.

Los términos $(y_i - y_c)$ de la ecuación 8.4.12 se conocen como *residuales*. Algunos programas por computadora para el análisis de regresión dan por lo común los residuales como parte de la información de salida. Cuando éste es el caso, puede obtenerse $s_{y|x}^2$ elevando al cuadrado los residuales, sumando los términos elevados al cuadrado y dividiendo el resultado entre $n - 2$. Otra fórmula para $s_{y|x}^2$ es:

$$s_{y|x}^2 = \frac{n - 1}{n - 2} (s_y^2 - b^2 s_x^2) \quad (8.4.13)$$

donde s_y^2 y s_x^2 son las variancias de las observaciones de y y de x , respectivamente. Para el ejemplo ilustrativo se tiene que

$$s_y^2 = 379.8182 \quad \text{y} \quad s_x^2 = 275.0000$$

de modo que

$$s_{y|x}^2 = \frac{10}{9} [379.8182 - (1.1236)^2(275.0000)] = 36.2634$$

un resultado que concuerda con el cuadrado medio residual de la tabla 8.4.3.

La raíz cuadrada de $s_{y|x}^2$, $s_{y|x}$ es la desviación estándar de las observaciones en torno a la recta de regresión ajustada y mide la dispersión de esos puntos en torno a la recta. Cuanto mayor es $s_{y|x}$ menor es el ajuste de la recta respecto de los datos observados.

Cuando $s_{y|x}^2$ se utiliza para estimar a $\sigma_{y|x}^2$, puede obtenerse el estimador deseado e insesgado de σ_b^2 mediante la expresión

$$s_b^2 = \frac{s_{y|x}^2}{\sum (x_i - \bar{x})^2} \quad (8.4.14)$$

Puede escribirse la ecuación 8.4.13 en la forma siguiente, más conveniente para el cálculo:

$$s_b^2 = \frac{s_{y|x}^2}{\sum x_i^2 - (\sum x_i)^2/n} \quad (8.4.15)$$

Si la probabilidad de observar un valor tan extremo como el valor de la estadística de prueba calculada mediante la ecuación 8.4.11, cuando la hipótesis nula es verdadera, es menor que $\alpha/2$ (dado que se tiene una prueba bilateral), se rechaza la hipótesis nula.

Se utilizará ahora el ejemplo ya conocido para ilustrar el procedimiento de prueba de la hipótesis nula de que $\beta = 0$. Primero, se enuncian las hipótesis y se decide un nivel de significación.

$$H_0: \beta = 0$$

$$H_A: \beta \neq 0$$

$$\alpha = .05$$

En seguida, se calcula s_b^2 . A partir de la tabla 8.4.3, se tiene que $s_{y|x}^2 = 36.2634$, de manera que puede calcularse.

$$s_b^2 = \frac{36.2634}{[50^2 + 55^2 + \cdots + 100^2] - \frac{(825)^2}{11}} = .013$$

Puede calcularse la estadística de prueba

$$t = \frac{1.1236 - 0}{\sqrt{.013}} = 9.85$$

La probabilidad de que se obtenga un valor de t así o más extremo cuando la hipótesis nula es verdadera, es menor que 0.01, ya que la probabilidad de obtener un valor de t tan grande como o mayor que 3.2498 es de .005, y la probabilidad de obtener un valor de t tan pequeño como o más pequeño que -3.2498 es también de 0.005. Dado que 9.85 es mayor que 3.2498, la probabilidad de observar un valor

de t tan grande como o mayor que 9.85, cuando la hipótesis nula es verdadera, es menor que 0.005.

Dicho de otra manera, puede seguirse el criterio de la regla de decisión y notar que los valores críticos de t para una prueba bilateral, cuando $\alpha = .05$ y teniéndose $(n - 2) = 9$ grados de libertad, son de ± 2.2622 . Dado que la t calculada de 9.85 es mayor que 2.2622, se dice que es significativa, se rechaza H_0 y se concluye que la pendiente de la recta de regresión verdadera no es cero. La implicación práctica es que puede concluirse que existe una relación lineal entre X y Y . El hecho de que b sea positivo conduce a pensar que β es positivo y que la relación entre X y Y es una relación lineal directa. Como ya se ha mencionado, la ecuación 8.4.11 puede utilizarse para probar la hipótesis nula de que β es igual a algún valor distinto de cero. El valor que se establece en la hipótesis para β , β_0 , se sustituye en la ecuación en lugar de 0. Todas las demás cantidades, así como los cálculos, son iguales a los del ejemplo ilustrativo. Los grados de libertad y el método para determinar el nivel de significación son también los mismos.

Intervalo de confianza para β . Una vez que se ha determinado que es improbable, a la luz de la evidencia de la muestra, que β sea cero, el investigador puede interesarse en obtener una estimación de intervalo de β . Puede utilizarse la fórmula general para un intervalo de confianza,

estimador $\pm$ (factor de confiabilidad)(error estándar de la estimación)

Cuando se obtiene un intervalo de confianza para β , el estimador es b , el factor de confiabilidad es algún valor de z o t (dependiendo de si se conoce o no $\sigma_{y|x}^2$) y el error estándar del estimador es:

$$\sigma_b = \sqrt{\frac{\sigma_{y|x}^2}{\sum (x_i - \bar{x})^2}}$$

Cuando $\sigma_{y|x}^2$ se desconoce, σ_b se estima mediante la expresión

$$s_b = \sqrt{\frac{s_{y|x}^2}{\sum (x_i - \bar{x})^2}}$$

por lo que en la mayoría de las situaciones prácticas, el intervalo de confianza del $100(1 - \alpha)$ por ciento para β es:

$$b \pm t_{(1-\alpha/2)} \sqrt{\frac{S_{y|x}^2}{\sum (x_i - \bar{x})^2}} \quad (8.4.16)$$

Para el ejemplo ilustrativo, se obtiene el siguiente intervalo de confianza del 95 por ciento para β :

$$\begin{aligned} &1.1236 \pm 2.2622 \sqrt{.013} \\ &1.1236 \pm .2579 \\ &.8657, 1.3815 \end{aligned}$$

Este intervalo se interpreta en la forma común. Desde el punto de vista probabilístico, se dice que al repetir el muestreo, el 95 por ciento de los intervalos obtenidos de esta forma incluirán a β . La interpretación práctica es que se tiene el 95 por ciento de confianza de que el único intervalo obtenido incluya a β .

Resulta útil observar que el intervalo de confianza que se construyó no incluye a cero, de manera que este valor no es un candidato para el parámetro que se está estimando. Se supone entonces que es improbable que $\beta = 0$. Esto es compatible con los resultados de la prueba de la hipótesis en la que se rechazó la hipótesis nula de que $\beta = 0$. En realidad, siempre puede probarse $H_0: \beta = 0$ en el nivel de importancia α al construir el intervalo de confianza del 100(1 - α) por ciento para β , y puede rechazarse o dejar de rechazar la hipótesis en base a si el intervalo incluye o no el cero. Si el intervalo incluye el cero, la hipótesis nula no se rechaza; y si ocurre lo contrario, dicha hipótesis se rechaza.

Debe quedar claro en este punto que el no rechazar la hipótesis nula de que $\beta = 0$ no significa que X y Y no estén relacionadas. No sólo es posible que se haya cometido un error del tipo II, sino que puede ser que X y Y estén relacionadas en alguna forma no lineal. Por otra parte, cuando se rechaza la hipótesis nula de que $\beta = 0$, no puede concluirse que la relación verdadera entre X y Y sea lineal. Una vez más, puede ser que aunque los datos se ajusten al modelo de regresión lineal bastante bien (como lo demuestra el hecho de que se rechace la hipótesis nula de que $\beta = 0$), exista algún otro método no lineal que proporcione un ajuste aún mejor. En consecuencia, cuando se rechaza la H_0 de que $\beta = 0$, lo mejor que puede decirse es que pueden obtenerse resultados más útiles (que se analizan a continuación) al tomar en cuenta la regresión de Y sobre X que ignorándola.

Ejercicios

8.4.1a 8.4.5 Utilizando como referencia los ejercicios 8.3.1 a 8.3.5 y para cada uno de ellos, lleve a cabo lo siguiente:

- Calcule el coeficiente de determinación.
- Prepare una tabla ANDEVA y pruebe la hipótesis nula de no relación lineal entre las dos variables.
- Demuestre la hipótesis nula de que $\beta = 0$ utilizando un nivel de significación de .05.
- Determine el valor p para cada prueba de hipótesis.
- Saque sus conclusiones en términos del problema.
- Obtenga el intervalo de confianza del 95 por ciento para β .

8.5 USO DE LA ECUACIÓN DE REGRESIÓN

Si los resultados al evaluar la ecuación de regresión de la muestra indican que existe una relación entre las dos variables de interés, puede darse un uso práctico a dicha ecuación. Hay dos formas en las que puede utilizarse la ecuación. Puede utilizarse para *predecir* el valor probable de Y , dado un valor particular de X . Cuando se satisfacen las suposiciones planteadas en la sección 8.2, puede obtenerse un *intervalo de predicción* para este valor pronosticado de Y .

Puede utilizarse también la ecuación de regresión para *estimar* la media de la subpoblación de los valores de Y que se supone existen para algún valor particular de X . Una vez más, si se cumplen las suposiciones establecidas anteriormente, puede construirse un intervalo de confianza para este parámetro. El valor pronosticado de Y y la estimación de punto de la media de la subpoblación de Y serán numéricamente iguales a cualquier valor particular de X , pero, como se verá, el intervalo de predicción será más amplio que el intervalo de confianza.

Predicción de Y para una X dada. Supóngase, en el ejemplo ilustrativo, que se tiene un paciente que obtiene una calificación de 70 en la nueva prueba y que se desea predecir su calificación en la prueba estandarizada. Para obtener el valor pronosticado, se sustituye x por 70 en la ecuación de regresión de la muestra para obtener

$$\begin{aligned} y_c &= -.9973 + 1.1236(70) \\ &= 78 \end{aligned}$$

redondeada hasta el entero más próximo.

Si se decide aplicar al paciente la prueba estandarizada, se pronosticaría que su calificación es de 78. Dado que no se tiene confianza en esta predicción, sería preferible un intervalo con un nivel de confianza correspondiente. Si se sabe, o se inclina a suponer, que se satisfacen las suposiciones de la sección 8.2, y cuando se desconoce $\sigma_{y|x}^2$, el intervalo de predicción del $100(1 - \alpha)$ por ciento para $\bar{Y}$ está dado por la expresión

$$y_c \pm t_{(1-\alpha/2)} s_{y|x} \sqrt{1 + \frac{1}{n} + \frac{(x_p - \bar{x})^2}{\sum (x_i - \bar{x})^2}} \quad (8.5.1)$$

donde x_p es el valor particular de x en el que se desea obtener un intervalo de predicción para Y y los grados de libertad utilizados para seleccionar t son $n - 2$. Para el ejemplo ilustrativo, puede construirse el siguiente intervalo de predicción del 95 por ciento:

$$\begin{aligned} 78 \pm 2.2622 \sqrt{36.2634} \sqrt{1 + \frac{1}{11} + \frac{(70 - 75)^2}{2750}} \\ 78 \pm 2.2622(6.02)(1.0488) \\ 78 \pm 14 \\ 64, 92 \end{aligned}$$

La interpretación de un intervalo de predicción es similar a la interpretación de un intervalo de confianza. Si se extraen muestras repetidamente, se lleva a cabo un análisis de regresión y se construyen los intervalos de predicción para los pacientes que obtienen 70 de calificación en la nueva prueba, casi el 95 por ciento de ellos incluirán la calificación de dichos pacientes en la prueba estandarizada. Esta es la interpretación probabilística. La interpretación práctica es que se tiene el 95 por ciento de confianza en que el único intervalo de predicción construido incluya la calificación de los pacientes en la prueba estandarizada.

Estimación de la media de Y para una X dada. Si, en el ejemplo ilustrativo, se tiene interés en calcular la media de la subpoblación hipotética formada por las calificaciones obtenidas en la prueba estandarizada.

darizada, constituida por los pacientes que obtienen una calificación de 70 en la nueva prueba, nuevamente se calcularía.

$$\begin{aligned}y_c &= -.9973 + 1.1236(70) \\ &= 78\end{aligned}$$

El intervalo de confianza de $100(1 - \alpha)$ por ciento para $\mu_{y|x}$, cuando se desconoce $\sigma_{y|x}^2$, está dado por la expresión

$$y_c \pm t_{(1-\alpha/2), S_{y|x}} \sqrt{\frac{1}{n} + \frac{(x_p - \bar{x})^2}{\sum (x_i - \bar{x})^2}} \quad (8.5.2)$$

Puede obtenerse el siguiente intervalo de confianza del 95 por ciento para $\mu_{y|x=70}$ del presente ejemplo haciendo las sustituciones apropiadas:

$$\begin{aligned}78 \pm 2.2622 \sqrt{36.2634} \sqrt{\frac{1}{11} + \frac{(70 - 75)^2}{2750}} \\ 78 \pm 4 \\ 74, 82\end{aligned}$$

Si se extrajeran repetidamente muestras de la población de pacientes, se lleva a cabo un análisis de regresión y se estima $\mu_{y|x} = 70$ con un intervalo de confianza construido en forma similar, casi el 95 por ciento de dichos intervalos incluiría a la media verdadera. Por esta razón, se tiene el 95 por ciento de confianza en que el único intervalo construido contenga a la media verdadera.

Si se construyen intervalos de confianza para las medias de varias subpoblaciones y se grafican los límites inferior y superior sobre el mismo diagrama de dispersión con la recta de regresión, puede obtenerse una *banda de confianza* uniendo todos los límites superiores con una curva y todos los límites inferiores con otra. La tabla 8.5.1 contiene los límites de confianza superior e inferior del 95 por ciento para $\mu_{y|x}$ para cada valor de X en el ejemplo ilustrativo, y la figura 8.5.1 muestra la banda de confianza del 95 por ciento que resulta cuando se grafican dichos valores.

Nótese que la banda de confianza es más ancha en sus extremos que en su parte media. En efecto, la banda de confianza es más angosta para $x_p = \bar{x} = 75$. La razón es que cuando se sustituye x_p por $\bar{x} = 75$ en la ecuación 8.5.2, la cantidad en el radical es un mínimo que resulta en el intervalo de confianza más angosto. A medida que

Tabla 8.5.1 Límites de confianza del 95 por ciento para $\mu_{y|x}$ para cada valor de X , Ejemplo 8.3.1.

x	y_c	Límite inferior	Límite superior
50	55.1827	47.5009	62.8645
55	60.8007	54.1798	67.4216
60	66.4187	60.7588	72.0786
65	72.0367	67.1783	76.8951
70	77.6547	73.3482	81.9612
75	83.2727	79.1666	87.3788
80	88.8907	84.5842	93.1972
85	94.5087	89.6503	99.3671
90	100.1267	94.4668	105.7866
95	105.7447	99.1238	112.3656
100	111.3627	103.6809	119.0445




Figura 8.5.1 Banda de confianza del 95 por ciento para $\mu_{y|x}$, ejemplo 8.3.1.

x_p aumenta o disminuye, la cantidad bajo el radical se hace más grande, como sucede también con los intervalos de confianza asociados.

Graybill y Bowden⁵ presentan un método para construir bandas de confianza que sean rectas. Sugieren que posiblemente sean preferibles las bandas de este tipo a las del tipo curvilíneo que se dieron anteriormente, ya que son más fáciles de calcular y de graficar, y tienen un ancho promedio menor.

Dunn,⁶ quien ha elaborado una banda de confianza que afirma es preferible a la de Graybill y Bowden, sugiere que debe preferirse la banda de confianza curvilínea común sobre cualquiera de la variedad recta. Este tema es también analizado por Hoel,⁷ Gafarian,⁸ Halperin y Gurian⁹ y Elston y Grizzle.¹⁰

En forma similar, pueden elaborarse bandas de predicción graficando los intervalos de predicción a varios valores de X .

Ejercicios

En cada uno de los ejercicios 8.5.1 a 8.5.5, utilice como referencia el ejercicio apropiado y, para el valor de X indicado, *a*) construya el intervalo de confianza del 95 por ciento para $\mu_{y|x}$ y *b*) construya el intervalo de predicción del 95 por ciento para y_p .

8.5.1 Utilice como referencia el ejercicio 8.3.1 y sea $X = 2$.

8.5.2 Utilice como referencia el ejercicio 8.3.2 y sea $X = 400$.

8.5.3 Utilice como referencia el ejercicio 8.3.3 y sea $X = 50$.

8.5.4 Utilice como referencia el ejercicio 8.3.4 y sea $X = 100$.

8.5.5 Utilice como referencia el ejercicio 8.3.5 y sea $X = 5$.

8.5.6 Construya la banda de confianza del 95 por ciento para $\mu_{y|x}$ para el ejercicio 8.3.5.

8.6 EL MODELO DE CORRELACIÓN

En el modelo clásico de regresión, que ha sido el modelo fundamental en el estudio hasta este punto, sólo Y , a la que se le ha llamado la variable dependiente, es aleatoria. La variable X se define como una variable fija (no aleatoria o matemática) y recibe el nombre de variable independiente. Recuérdese también que se han descrito las observaciones como se obtienen mediante la preselección de los valores de X y determinando los valores correspondientes de Y .

Cuando tanto Y como X son variables aleatorias, se tiene lo que se conoce como el *modelo de correlación*. Típicamente, bajo el modelo de correlación, se obtienen observaciones de la muestra seleccionando una muestra al azar de las *unidades de asociación* (que pueden ser personas, lugares, animales, puntos en el tiempo o cualquier otro elemento sobre el cual se toman las dos medidas) y tomando una medida de X y una medida de Y sobre cada una. En este procedimiento, los valores de X no se preseleccionan, sino que son al azar, dependiendo de la unidad de asociación seleccionada en la muestra.

Aunque no puede llevarse a cabo con sentido el análisis de correlación bajo el modelo clásico de regresión, el análisis de regresión puede llevarse a cabo bajo el modelo de correlación. La correlación, que comprende dos variables, implica una correlación entre las variables que pone a ambas sobre un mismo terreno y no las distingue, refiriéndose a una como la variable dependiente y a la otra como la variable independiente. En efecto, en los procedimientos básicos de cálculo, que son los mismos que para el modelo de regresión, puede ajustarse una recta a los datos, ya sea minimizando $\sum (y_i - y_c)^2$, o bien, minimizando $\sum (x_i - x_c)^2$. En otras palabras, puede hacerse una regresión de X sobre Y , así como una regresión de Y sobre X . En general, las rectas ajustadas en los dos casos serán distintas y surge una pregunta lógica: ¿cuál recta ajustar?

Si el objetivo es únicamente obtener una medida de la intensidad de la relación entre las dos variables, no importa qué recta se ajuste, ya que la medida que por lo general se calcula será la misma en cualquier caso. Sin embargo, si se desea utilizar la ecuación que describe la relación entre las dos variables para los propósitos estudiados en las secciones anteriores, sí importa qué recta se ajuste. La variable para la que se desean estimar las medias o hacer predicciones debe tratarse como la variable dependiente, es decir, debe realizarse la regresión de esta variable sobre la otra variable.

Bajo el modelo de correlación, se supone que X y Y varían juntas en lo que se conoce como *distribución conjunta*. Si la forma de esta distribución conjunta tiene una distribución normal, se conoce como *distribución normal bivariada*. Pueden hacerse inferencias sobre esta población en base a los resultados de las muestras extraídas apropiadamente de ella. Si, por otra parte, se sabe que la distribución conjunta es no normal, o si se desconoce la forma y no existe justificación para suponer que existe normalidad, se invalidan los procedimientos inferenciales, aunque bien pueden calcularse medidas descriptivas.

Deben cumplirse las siguientes suposiciones para que sean válidas las inferencias acerca de la población, cuando se muestrea a partir de una distribución bivariada.

1. Para cada valor de X , existe una subpoblación de valores de Y normalmente distribuida.
2. Para cada valor de Y , existe una subpoblación de valores de X normalmente distribuida.




Figura 8.6.1 Distribución normal bivariada. *a)* Distribución normal bivariada. *b)* Corte mostrando la subpoblación distribuida normalmente de Y para una X dada. *c)* Corte mostrando la subpoblación distribuida normalmente de X para una Y dada.

3. La distribución conjunta de X y Y es una distribución normal llamada *distribución normal bivariada*.
4. Todas las subpoblaciones de los valores de Y tienen la misma variancia.
5. Todas las subpoblaciones de los valores de X tienen la misma variancia.

La distribución normal bivariada se representa gráficamente en la figura 8.6.1. En esta ilustración, se observa que si se corta el montículo en forma paralela a Y en algún valor de X , el corte revela la distribución normal correspondiente de Y . Asimismo, un corte paralelo a X en algún valor de Y revela la subpoblación correspondiente de X con distribución normal.

8.7 EL COEFICIENTE DE CORRELACIÓN

La distribución normal bivariada analizada en la sección 8.6 tiene cinco parámetros, σ_x , σ_y , μ_x , μ_y y ρ . Los primeros cuatro son respectivamente las desviaciones estándar y las medias asociadas con las distribuciones individuales. El otro parámetro, ρ , se conoce como *coeficiente de correlación* de la población y mide la intensidad de la relación lineal entre X y Y .

El coeficiente de correlación de la población es la raíz cuadrada de ρ^2 , el coeficiente de determinación de la población que se estudió anteriormente, y dado que éste toma valores entre 0 y 1 inclusive, ρ puede tomar cualquier valor entre -1 y $+1$. Si $\rho = 1$, existe una correlación lineal directa perfecta entre las dos variables, mientras que cuando $\rho = -1$, indica una correlación lineal inversa perfecta. Si $\rho = 0$, las dos variables no están correlacionadas. El signo de ρ siempre será igual al signo de β , la pendiente de la recta de regresión para X y Y .

El coeficiente de correlación de la muestra, r , describe la relación entre las observaciones de la muestra, en dos variables, de la misma forma que ρ describe la relación en una población.

Las figuras 8.4.2d y 8.4.2c muestran respectivamente diagramas de dispersión típicos, donde $r \rightarrow 0$ ($r^2 \rightarrow 0$) y $r = +1$ ($r^2 = 1$). La figura 8.7.1 es un diagrama de dispersión típico, donde $r = -1$.

Por lo general, se tiene interés en saber si puede concluirse que $\rho \neq 0$, es decir, si X y Y están correlacionados. Dado que, por lo general,




Figura 8.7.1 Diagrama de dispersión para $r = -1$.

se desconoce ρ , se extrae una muestra aleatoria de la población de interés, se calcula r , el estimador de ρ y se prueba la hipótesis de que $H_0: \rho = 0$ contra la alternativa $\rho \neq 0$. En el siguiente ejemplo, se ilustrará el procedimiento.

Ejemplo 8.7.1

Se obtuvieron las lecturas de la presión sanguínea mediante dos métodos distintos, en 25 pacientes con hipertensión esencial. Las lecturas sistólicas obtenidas por los dos métodos se indican en la tabla 8.7.1.

El médico deseaba investigar la intensidad de la relación entre las dos mediciones. El diagrama de dispersión y la recta de regresión de los mínimos cuadrados se muestran en la figura 8.7.2.

Los cálculos previos necesarios para obtener la recta de regresión de los mínimos cuadrados se muestran en la tabla 8.7.2. Dado que el investigador desea obtener una ecuación de regresión y utilizarla para estimar y predecir propósitos, se obtendrá el coeficiente de correlación de la muestra mediante los métodos estudiados bajo el modelo de regresión.

Las lecturas del método I se tomaron como variable independiente, ya que el médico anticipó que podría desear y predecir una lectura del método II, dada una lectura del método I.

Tabla 8.7.1 Lecturas de la presión sistólica sanguínea (mm Hg) mediante dos métodos en 25 pacientes con hipertensión esencial.

<i>Número del paciente</i>	<i>Método I</i>	<i>Método II</i>
1	132	130
2	138	134
3	144	132
4	146	140
5	148	150
6	152	144
7	158	150
8	130	122
9	162	160
10	168	150
11	172	160
12	174	178
13	180	168
14	180	174
15	188	186
16	194	172
17	194	182
18	200	178
19	200	196
20	204	188
21	210	180
22	210	196
23	216	210
24	220	190
25	220	202

Sustituyendo lo obtenido en la tabla 8.7.2 en las ecuaciones 8.3.2 y 8.3.3, se obtienen las siguientes ecuaciones normales:

$$4172 = 25a + 4440b$$

$$757,276 = 4440a + 808408b$$

Cuando se resuelven estas ecuaciones, se tiene que

$$a = 20.8928$$

$$b = .8220$$




Figura 8.7.2 Lecturas de la presión sistólica sanguínea (mm Hg) en 25 pacientes con hipertensión esencial.

La ecuación de los mínimos cuadrados es

$$y_c = 20.8928 + .8220x$$

El coeficiente de determinación, que es igual a la suma de cuadrados explicada dividida entre la suma total de cuadrados, es (utilizando las ecuaciones 8.4.3 y 8.4.4)

$$r^2 = \frac{b^2[\sum x_i^2 - (\sum x_i)^2/n]}{\sum y_i^2 - (\sum y_i)^2/n} \quad (8.7.1)$$

Sustituyendo los valores de la tabla 8.7.2 y la ecuación de regresión en la ecuación 8.7.1 se tiene que

$$\begin{aligned} r^2 &= \frac{(.8220)^2[808,408 - (4440)^2/25]}{710,952 - (4172)^2/25} \\ &= .9112713 \end{aligned}$$

Tabla 8.7.2 Cálculos preliminares para obtener la recta de regresión de mínimos cuadrados, ejemplo 8.7.1.

<i>Método I (x)</i>	<i>Método II (y)</i>	x^2	y^2	xy
132	130	17424	16900	17160
138	134	19044	17956	18492
144	132	20736	17424	19008
146	140	21316	19600	20440
148	150	21904	22500	22200
152	144	23104	20736	21888
158	150	24964	22500	23700
130	122	16900	14884	15860
162	160	26244	25600	25920
168	150	28224	22500	25200
172	160	29584	25600	27520
174	178	30276	31684	30972
180	168	32400	28224	30240
180	174	32400	30276	31320
188	186	35344	34596	34968
194	172	37636	29584	33368
194	182	37636	33124	35308
200	178	40000	31684	35600
200	196	40000	38416	39200
204	188	41616	35344	38352
210	180	44100	32400	37800
210	196	44100	38416	41160
216	210	46656	44100	45360
220	190	48400	36100	41800
220	202	48400	40804	44440
Total 4440	4172	808408	710952	757276

Finalmente, el coeficiente de correlación es:

$$r = \sqrt{r^2} = \sqrt{.9112713} = .954605 \approx .95$$

Otra fórmula para calcular r es la expresión

$$r = \frac{n\sum x_i y_i - (\sum x_i)(\sum y_i)}{\sqrt{n\sum x_i^2 - (\sum x_i)^2} \sqrt{n\sum y_i^2 - (\sum y_i)^2}} \quad (8.7.2)$$

Una ventaja de esta fórmula es que puede calcularse r sin calcular primero b . Este es el procedimiento deseable cuando no se prevé que se

utilizará la ecuación de regresión. Sustituyendo los valores de la tabla 8.7.2 en la ecuación 8.7.2, se tiene que

$$r = \frac{25(757,276) - (4440)(4172)}{\sqrt{25(808,408) - (4440)^2} \sqrt{25(710,952) - (4172)^2}} \\ = .95$$

Para ver si este valor de r es de magnitud suficiente como para indicar que las dos variables de interés están correlacionadas, se prueba la hipótesis

$$H_0: \rho = 0$$

contra la alternativa

$$H_A: \rho \neq 0$$

Cuando $\rho = 0$, puede demostrarse que

$$t = r \sqrt{\frac{n-2}{1-r^2}} \quad (8.7.3)$$

está distribuida como la distribución t de Student con $n - 2$ grados de libertad.

Si se supone que $\alpha = .05$, los valores críticos de t en el presente ejemplo son ± 2.0687 . Si, a partir de los datos, se calcula un valor de t mayor que o igual a $+2.0687$ o menor que o igual a -2.0687 , se rechazará la hipótesis nula. El valor calculado de t es:

$$t = .954605 \sqrt{\frac{23}{1-.9112713}} \\ = 15.37$$

y dado que este valor es mayor que el valor crítico de t , se rechaza la hipótesis nula y se concluye que las dos variables están correlacionadas. Dado que $15.37 > 2.8073$, se tiene para esta prueba que $\rho < .01$.

El uso de la estadística t calculada en la prueba anterior es apropiado para probar sólo $H_0: \rho = 0$. Si se desea probar $H_0: \rho = \rho_0$, donde ρ_0 es algún valor distinto de cero, debe utilizarse otro procedimiento. Fisher¹¹ sugiere que r debe transformarse en z_r como sigue:

$$z_r = \frac{1}{2} \ln \frac{1+r}{1-r} \quad (8.7.4)$$

donde $\ln$ es un logaritmo natural. Puede demostrarse que z_r tiene una distribución aproximadamente normal con una media de $z_p = \frac{1}{2} \ln \{(1 + \rho)/(1 - \rho)\}$ y una desviación estándar estimada.

$$\frac{1}{\sqrt{n-3}} \quad (8.7.5)$$

Para probar la hipótesis nula de que ρ es igual a algún valor distinto de cero, la estadística de prueba es

$$Z = \frac{z_r - z_p}{1/\sqrt{n-3}} \quad (8.7.6)$$

la cual sigue aproximadamente la distribución normal unitaria.

Para determinar z_r para un r observado y z_p para un ρ establecido en la hipótesis, se consulta la tabla L, evitando así el uso directo de los logaritmos naturales.

Supóngase que en el presente ejemplo se desea probar que

$$H_0: \rho = .98$$

contra la alternativa

$$H_A: \rho \neq .98$$

al nivel de significación de .05. Consultando la tabla L, se encuentra que para

$$r = .95, \quad z_r = 1.83178$$

y para

$$\rho = .98, \quad z_p = 2.29756$$

La estadística de prueba es entonces

$$\begin{aligned} Z &= \frac{1.83178 - 2.29756}{1/\sqrt{25-3}} \\ &= -2.18 \end{aligned}$$

Dado que -2.18 es menor que el valor crítico de $z = -1.96$, debe rechazarse H_0 y concluir que el coeficiente de correlación de la población no es de .98.

Para tamaños de muestra menores que 25, debe utilizarse con precaución la transformación Z de Fisher. Puede utilizarse un procedimiento alternativo debido a Hotelling¹² para tamaños de muestra

iguales o mayores de 10. En este procedimiento, se utiliza la siguiente transformación de r

$$z^* = z_r - \frac{3z_r + r}{4n} \quad (8.7.7)$$

La desviación estándar de z^* es

$$\sigma_{z^*} = \frac{1}{\sqrt{n-1}} \quad (8.7.8)$$

La estadística de prueba es

$$Z^* = \frac{z^* - \zeta^*}{1/\sqrt{n-1}} = (z^* - \zeta^*)\sqrt{n-1} \quad (8.7.9)$$

donde

$$\zeta^* \text{ (llamada zeta)} = z_\rho - \frac{(3z_\rho + \rho)}{4n}$$

Los valores críticos para fines de comparación se obtienen a partir de la distribución normal unitaria.

En el presente ejemplo, para probar $H_0: \rho = .98$ contra la alternativa $H_A: \rho \neq .98$ ($\alpha = .05$), utilizando la transformación de Hotelling, se tiene que

$$z^* = 1.83178 - \frac{3(1.83178) + .95}{4(25)} = 1.76733$$

$$\zeta^* = 2.29756 - \frac{3(2.29756) + .98}{4(25)} = 2.21883$$

$$\begin{aligned} Z^* &= (1.76733 - 2.21883)\sqrt{25-1} \\ &= -2.21 \end{aligned}$$

Dado que -2.21 es menor que -1.96 , se rechaza la hipótesis nula y se llega a la misma conclusión que cuando se utilizó la transformación de Fisher.

Intervalo de confianza para ρ . Puede utilizarse la transformación de Fisher para construir intervalos de confianza del $100(1 - \alpha)$ por

ciento para ρ . Se utiliza la fórmula general para un intervalo de confianza,

$$\text{estimador} \pm (\text{factor de confiabilidad})(\text{error estándar})$$

Se convierte primero el estimador, r , en z_r , se construye un intervalo de confianza en torno a z_p y se reconvierten entonces los límites para obtener un intervalo de confianza del $100(1 - \alpha)$ por ciento para ρ . La fórmula general se convierte entonces en

$$z_r \pm z(1/\sqrt{n-3}) \quad (8.7.10)$$

Para el presente ejemplo, el intervalo de confianza del 95 por ciento para z_p está dado por

$$\begin{aligned} 1.83178 \pm 1.96(1/\sqrt{25-3}) \\ 1.83178 \pm .41787 \\ 1.41391, 2.24965 \end{aligned}$$

Convirtiendo estos límites, que son valores de z_r , en valores de r , se tiene que

z_r	r
1.41391	.890
2.24965	.975

Se tiene entonces el 95 por ciento de confianza de que ρ esté contenido en el intervalo de .890 a .975. Debido a los valores limitados de la tabla, estos límites deben considerarse sólo como aproximados.

Otro método para construir intervalos de confianza para ρ es utilizar las tablas especiales preparadas por David.¹³

Ejercicios

En cada uno de los siguientes ejercicios:

- Prepare un diagrama de dispersión.
- Calcule el coeficiente de correlación de la muestra.
- Pruebe que $H_0: \rho = 0$ al nivel de significación de .05 y saque sus conclusiones.
- Determine el valor p para la prueba.
- Construya el intervalo de confianza del 95 por ciento para ρ .

- 8.7.1 Una muestra aleatoria de los expedientes de cierto hospital proporcionó la siguiente información sobre la duración del internado en días y el ingreso familiar anual (redondeado hasta los \$500 más próximos) de 15 pacientes dados de alta.

<i>Ingreso familiar anual (x)</i>	<i>Duración del internado (y)</i>
\$2000	11
2500	12
3000	9
3500	8
4000	9
4500	10
5000	7
5500	8
6000	4
6500	7
7000	5
7500	6
8000	3
8500	4
9000	4
$\sum x_i =$	82,500
$\sum x_i^2 =$	523,750,000
$\sum y_i =$	107
$\sum y_i^2 =$	871
$\sum x_i y_i =$	510,500

- 8.7.2 La siguiente tabla muestra las presiones sanguíneas sistólicas en cada una de 25 parejas de gemelos idénticos.

<i>Primer gemelo (X)</i>	<i>Segundo gemelo (Y)</i>
118	115
116	119
118	116
120	119
122	118
122	138
122	124
120	128
124	126

<i>Primer gemelo(X)</i>	<i>Segundo gemelo(Y)</i>
125	130
138	130
140	125
142	164
144	160
145	158
162	145
180	184
180	190
182	188
185	180
170	174
172	170
150	160
152	155
155	160
$\sum x_i = 3,604$	$\sum x_i^2 = 532,832$
$\sum y_i = 3,676$	$\sum y_i^2 = 555,618$
$\sum x_i y_i = 543,120$	

8.7.3 Se compararon dos métodos para medir el gasto cardíaco en 10 animales de laboratorio obteniéndose los siguientes resultados.

<i>Gasto cardíaco (l./min)</i>	
<i>Método I(X)</i>	<i>Método II(Y)</i>
.8	.5
1.0	1.2
1.3	1.1
1.4	1.3
1.5	1.1
1.4	1.8
2.0	1.6
2.4	2.0
2.7	2.4
3.0	2.8

8.7.4 Los valores siguientes son 15 lecturas sobre la congestión del tráfico y la concentración de monóxido de carbono efectuadas en un sitio de muestreo para determinar la calidad del aire de cierta ciudad.

<i>Congestión del tráfico (automóviles por hora) (X)</i>	<i>CO(ppm) (Y)</i>
100	8.8
110	9.0
125	9.5
150	10.0
175	10.5
190	10.5
200	10.5
225	10.6
250	11.0
275	12.1
300	12.1
325	12.5
350	13.0
375	13.2
400	14.5
$\sum x_i = 3,550$	$\sum y_i = 167.8$
$\sum x_i^2 = 974,450$	$\sum y_i^2 = 1,915.36$
$\sum x_i y_i = 41,945$	

8.7.5 Una muestra aleatoria de 25 enfermeras seleccionadas de un registro estatal de enfermeras proporcionó la siguiente información sobre la calificación obtenida por cada una de ellas en el examen de la dirección estatal y su calificación final obtenida en la escuela. Ambas calificaciones se relacionan con el área de especialización de la enfermera.

<i>Calificación final (X)</i>	<i>Calificación obtenida en el examen de la dirección estatal (Y)</i>
87	440
87	480
87	535
88	460
88	525
89	480
89	510
89	530
89	545

<i>Calificación final (X)</i>	<i>Calificaciones obtenidas en el examen de la dirección estatal</i>
89	600
90	495
90	545
90	575
91	525
91	575
91	600
92	490
92	510
92	575
93	540
93	595
94	525
94	545
94	600
94	625

$$\begin{aligned}
 \sum x_i &= 2,263 & \sum y_i &= 13,425 \\
 \sum x_i^2 &= 204,977 & \sum y_i^2 &= 7,264,525 \\
 \sum x_i y_i &= 1,216,685
 \end{aligned}$$

8.8 ALGUNAS PRECAUCIONES

Los análisis de regresión y de correlación son herramientas estadísticas bastante útiles cuando se utilizan apropiadamente. Sin embargo, su uso inapropiado sólo puede conducir a la obtención de resultados sin sentido. Con el fin de ayudar al lector en el uso apropiado de estas técnicas, se hacen las siguientes sugerencias.

1. Antes de reunir los datos, deben revisarse cuidadosamente las suposiciones que fundamentan los análisis de regresión y de correlación. Aunque es raro encontrar que se cumplan las suposiciones a la perfección, el médico debe tener alguna idea acerca de la magnitud de la brecha que existe entre los datos que van a analizarse y las suposiciones del modelo propuesto, de modo que pueda decidir si debe elegir otro modelo; procédase con el análisis, pero tomando precauciones con la interpretación de los resultados; o bien, utilícese con confianza el modelo elegido.

2. En la regresión lineal simple y el análisis de correlación, las dos variables de interés se miden sobre la misma entidad, llamada unidad de asociación. Si se tiene interés en la relación entre la estatura y el peso, por ejemplo, estas dos medidas se hacen en el mismo individuo. En general, carece de sentido hablar de correlación, por así decirlo, entre las estaturas de un grupo de individuos y el peso de otro grupo.
3. Sin importar qué tan grande es la indicación de una relación entre dos variables, no debe interpretarse esto como un caso de causa y efecto. Si, por ejemplo, se observa un coeficiente notable de correlación de la muestra entre las dos variables X y Y , puede significar una de varias cosas:
 - a) X causa Y .
 - b) Y causa X .
 - c) Algún tercer factor, sea directa o indirectamente, causa tanto a X como a Y .




Figura 8.8.1 Ejemplo de extrapolación.

- d) Ha ocurrido un evento improbable y se ha obtenido por casualidad un gran coeficiente de correlación de la muestra a partir de una población en la que, en efecto, X y Y no están correlacionadas.
 - e) La correlación es sencillamente disparatada, una situación que puede surgir cuando las mediciones de X y Y no se hacen sobre una unidad común de asociación.
4. La ecuación de regresión de la muestra no debe utilizarse para predecir o estimar fuera del intervalo de valores de la variable independiente representado en la muestra. Esta práctica, llamada *extrapolación*, tiene sus riesgos. La verdadera relación entre dos variables, aun cuando sea lineal sobre un intervalo de la variable independiente, a veces puede describirse mejor como una curva fuera de este intervalo. Si, por casualidad, se extrae la muestra sólo del intervalo donde la relación es lineal, se tiene únicamente una representación limitada de la población, por lo que proyectar los resultados de la muestra más allá del intervalo representado por ella puede conducir a conclusiones falsas. La figura 8.8.1 ilustra una de las trampas de la extrapolación.

8.9 RESUMEN

En este capítulo se examinan dos importantes herramientas del análisis estadístico, la regresión lineal simple y la correlación. Se ha sugerido el siguiente esquema para la aplicación de dichas técnicas.

- 1 *Identificación del modelo.* El médico debe saber si el modelo de regresión o el de correlación es el apropiado para dar respuesta a sus preguntas.
- 2 *Revisión de las suposiciones.* Se ha señalado varias veces que la validez de las conclusiones depende de qué tan bien se ajusten los datos analizados al modelo elegido.
- 3 *Obtención de la ecuación de regresión.* Se ha visto cómo se obtiene la ecuación de regresión mediante el método de los mínimos cuadrados. Aunque los cálculos, cuando se hacen a mano, son un tanto largos, complicados y sujetos a error, éste no es ahora el problema como lo fue en el pasado. Las computadoras electrónicas se utilizan ahora tan ampliamente que se siente uno tentado

a decir que las personas que se dedican al estudio de la estadística o el investigador sin acceso a una de ellas es la excepción, más que la regla. No es necesario hablar en defensa del investigador que tiene que realizar largos cálculos si dispone de una computadora.

4. *Evaluación de la ecuación.* Se ha visto que la utilidad de la ecuación de regresión para fines de estimación y predicción se determina por medio del análisis de variancia, el cual prueba el significado del cuadrado medio de la regresión. Se valora la intensidad de la relación entre dos variables bajo el modelo de correlación probando la hipótesis nula de que no existe correlación en la población. Si puede rechazarse esta hipótesis, puede concluirse, al nivel de significación elegido, que las dos variables están correlacionadas.
5. *Uso de la ecuación.* Una vez que se ha determinado que es probable que la ecuación de regresión describa adecuadamente la relación entre las dos variables, X y Y , puede utilizarse para cualquiera de dos fines:

- a) predecir qué valor es probable que tenga Y , dado un valor particular de X , o bien,
- b) estimar la media de la subpoblación de los valores de Y para un valor particular de X .

Este estudio necesariamente abreviado, de la regresión y correlación lineales simples puede haber dado lugar a más preguntas que las que ha contestado. Se le puede haber ocurrido al lector, por ejemplo, que una variable dependiente puede pronosticarse con más precisión utilizando dos o más variables independientes en lugar de una sola. O, quizá, puede tener la sensación de que conocer la intensidad de la relación entre varias variables podría ser más interesante que si se sabe la relación entre sólo dos variables. La exploración de estas posibilidades es el tema del capítulo siguiente, por lo que la curiosidad del lector en este sentido debe quedar, al menos, parcialmente satisfecha.

Para quienes deseen ampliar su conocimiento sobre el tema, al final del capítulo se da cierto número de excelentes referencias, además de las ya citadas.

Preguntas y ejercicios de repaso

1. ¿Cuáles son las suposiciones que fundamentan el análisis de regresión lineal simple cuando uno de los objetivos es hacer inferencias

acerca de la población de la cual se extrajeron los datos de la muestra?

2. ¿Por qué a la ecuación de regresión se le da el nombre de ecuación de mínimos cuadrados?
3. Explique el significado de a en la ecuación de regresión de la muestra.
4. Explique el significado de b en la ecuación de regresión de la muestra.
5. Explique los siguientes términos:
 - a) Suma total de cuadrados.
 - b) Suma de cuadrados explicada.
 - c) Suma de cuadrados inexplicada.
6. Explique el significado del coeficiente de determinación y el método para calcularlo.
7. ¿Cuál es la función del análisis de variancia en el análisis de regresión?
8. Describa dos formas en las que se pueda probar la hipótesis nula de que $\beta = 0$.
9. ¿Cuáles son los dos fines para los que puede utilizarse una ecuación de regresión?
10. ¿Cuáles son las suposiciones que fundamentan al análisis de correlación simple cuando la inferencia es un objetivo?
11. ¿Qué se entiende por unidad de asociación en el análisis de regresión y de correlación?
12. ¿Cuáles son las explicaciones posibles para un coeficiente de correlación significativa de la muestra.
13. Explique por qué existen riesgos en utilizar una ecuación de regresión de la muestra para predecir o estimar fuera del intervalo de valores de la variable independiente representada en la muestra.
14. Describa una situación en su área de interés particular donde sería útil un análisis de regresión simple. Utilice datos reales o realistas y haga un análisis de regresión completo.
15. Describa una situación en su área de interés particular donde sería útil un análisis de correlación simple. Utilice datos reales o realistas y haga un análisis de correlación completo.

En cada uno de los siguientes ejercicios, lleve a cabo el análisis requerido y pruebe las hipótesis con los niveles de significación indicados. Calcule el valor p para cada prueba.

16. Los siguientes valores son los niveles de testosterona en el plasma y la edad de los prisioneros que sufrían su primera condena por crímenes violentos y agresión y que fueron tomados de una muestra de prisioneros jóvenes.

<i>Nivel de testosterona</i>	<i>Edad en la primera condena</i>	<i>Nivel de testosterona</i>	<i>Edad en la primera condena</i>
1305	11	710	17
1000	12	1150	18
1175	13	605	20
1495	14	690	21
1060	15	700	23
800	16	625	24
1005	16	610	27
		450	30

¿Proporcionan estos datos evidencia suficiente que indique que las dos variables están correlacionadas al nivel de significación de .05?

17. Algunos investigadores de la salud han reportado que existe una relación inversa entre las malformaciones del sistema nervioso central y la dureza relacionada con los suministros de agua. Supóngase que los siguientes datos se obtuvieron de una muestra de 20 zonas geográficas obteniéndose los siguientes resultados.

<i>Tasa de malformación del S.N.C. (por cada 1000 nacimientos)</i>	<i>Dureza del agua (p.p.m.)</i>	<i>Tasa de malformación del S.N.C. (por cada 1000 nacimientos)</i>	<i>Dureza del agua (p.p.m.)</i>
7.2	50	6.3	160
8.1	25	12.5	50
11.2	15	15.0	45
9.3	75	6.5	60
9.4	100	8.0	100
5.0	150	10.0	155
5.8	180	5.3	200
3.3	250	4.9	240
3.6	275	7.2	40
4.8	220	11.9	65

Construya un diagrama de dispersión y calcule r . ¿Cuáles son sus conclusiones? Sea $\alpha = .05$.

18. Se registraron la presión sistólica sanguínea media durante una intervención quirúrgica y el volumen de sangre perdido para 16 pacientes.

<i>Presión sistólica sanguínea media durante la intervención quirúrgica (mm Hg)</i>	<i>Pérdida de sangre (ml)</i>	<i>Presión sistólica sanguínea media durante la intervención quirúrgica (mm Hg)</i>	<i>Pérdida de sangre (ml)</i>
95	274	80	190
90	170	110	288
125	352	90	205
105	317	105	150
110	171	90	175
105	150	110	64
90	245	110	276
90	120	140	318

Prepare un diagrama de dispersión, calcule r y haga la prueba de significación al nivel de .05.

19. En un estudio del efecto de un componente de la dieta sobre la composición de los lípidos del plasma, se obtuvieron los siguientes datos en una muestra de 15 animales experimentales:

<i>Medida del componente de la dieta (X)</i>	<i>Medida de la concentración de lípidos en el plasma (Y)</i>
18	38
21	40
28	47
35	54
47	66
33	52
40	59
41	60
28	47
21	40
30	49
46	65
44	63
38	57
19	38

- Obtenga la ecuación de regresión para estos datos, calcule r^2 y pruebe $H_0: \beta = 0$ tanto para la prueba F como para la prueba t .
20. Los siguientes valores son el flujo sanguíneo pulmonar (FSP) y el volumen sanguíneo pulmonar (VSP) registrados para 16 bebés y niños con enfermedad congénita del corazón.

Y $VSP (ml/M^2)$	X $FSP(L/min/M^2)$
168	4.31
280	3.40
391	6.20
420	17.30
303	12.30
429	13.99
605	8.73
522	8.90
224	5.87
291	5.00
233	3.51
370	4.24
531	19.41
516	16.61
211	7.21
439	11.60

- Encuentre la ecuación de regresión que describa la relación lineal entre las dos variables, calcule r^2 y pruebe $H_0: \beta = 0$ tanto para la prueba F como para la prueba t . Sea $\alpha = .05$.
21. Se compararon mediante dos métodos quince muestras de suero de sangre con el anticuerpo tuberculina. Los logaritmos de los resultados obtenidos mediante los dos métodos fueron los siguientes:

<i>Método</i>	
$A(X)$	$B(Y)$
3.31	4.09
2.41	3.84
2.72	3.65
2.41	3.20
2.11	2.97
2.11	3.22

<i>Método.</i>	
<i>A(X)</i>	<i>B(Y)</i>
3.01	3.96
2.13	2.76
2.41	3.42
2.10	3.38
2.41	3.28
2.09	2.93
3.00	3.54
2.08	3.14
2.11	2.76

Encuentre la ecuación de regresión que describa la relación entre las dos variables, calcule r^2 y pruebe $H_0: \beta = 0$ tanto para la prueba F como para la prueba t .

22. La siguiente tabla ilustra los valores del consumo de metil mercurio y la cantidad total de mercurio en la sangre de 12 individuos expuestos a la primera sustancia por haber consumido peces contaminados.

<i>X</i> <i>Consumo de metil mercurio</i> <i>($\mu\text{g Hg/día}$)</i>	<i>Y</i> <i>Mercurio en la sangre</i> <i>(ng/g)</i>
180	90
200	120
230	125
410	290
600	310
550	290
275	170
580	375
105	70
250	105
460	205
650	480

Encuentre la ecuación de regresión que describa la relación lineal entre las dos variables, calcule r^2 y pruebe la hipótesis $H_0: \beta = 0$ tanto con la prueba F como con la prueba t . Sea $\alpha = .05$. Construya un intervalo de confianza del 95 por ciento para β .

23. Los valores siguientes son los pesos (en kg) y los niveles de glucosa en la sangre (en mg/100 ml) de 16 hombres adultos aparentemente sanos.

<i>Peso (X)</i>	<i>Glucosa (Y)</i>
64.0	108
75.3	109
73.0	104
82.1	102
76.2	105
95.7	121
59.4	79
93.4	107
82.1	101
78.9	85
76.7	99
82.1	100
83.9	108
73.0	104
64.4	102
77.6	87

Encuentre la ecuación de regresión lineal simple y pruebe la hipótesis $H_0: \beta = 0$ utilizando la tabla ANDEVA y la prueba t . Pruebe $H_0: \rho = 0$ y construya un intervalo de confianza del 95 por ciento para ρ . ¿Cuál es el nivel de glucosa pronosticado para un hombre que pesa 95 kg? Construya el intervalo de predicción del 95 por ciento para este peso. Sea $\alpha = .05$ para todas las pruebas.

24. La tabla siguiente indica las edades (en años) y las presiones sistólicas sanguíneas (PSS) de 20 adultos aparentemente sanos.

<i>Edad (X)</i>	<i>PSS(Y)</i>	<i>Edad(X)</i>	<i>PSS(Y)</i>
20	120	46	128
43	128	53	136
63	141	70	146
26	126	20	124
53	134	63	143
31	128	43	130
58	136	26	124
46	132	19	121
58	140	31	126
70	144	23	123

Encuentre la ecuación de regresión lineal simple y pruebe la hipótesis $H_0 : \beta = 0$ utilizando la tabla ANDEVA y la prueba t . Pruebe la hipótesis $H_0 : \rho = 0$ y construya un intervalo de confianza del 95 por ciento para ρ . Encuentre el intervalo de predicción del 95 por ciento para la presión sistólica sanguínea de una persona de 25 años de edad. Sea $\alpha = .05$ para todas las pruebas.

25. Se reunieron los siguientes datos durante un experimento en el cual se inoculó un animal de laboratorio con un patógeno. Las variables son el tiempo, en horas, después de la inoculación y la temperatura en grados Celsius.

<i>Tiempo</i>	<i>Temperatura</i>	<i>Tiempo</i>	<i>Temperatura</i>
24	38.8	44	41.1
28	39.5	48	41.4
32	40.3	52	41.6
36	40.7	56	41.8
40	41.0	60	41.9

Encuentre la ecuación de regresión lineal simple y pruebe la hipótesis $H_0 : \beta = 0$ utilizando la tabla ANDEVA y la prueba t . Pruebe la hipótesis $H_0 : \rho = 0$ y construya un intervalo de confianza del 95 por ciento para ρ . Construya el intervalo de predicción del 95 por ciento para la temperatura a 50 horas después de la inoculación. Sea $\alpha = .05$ para todas las pruebas.

REFERENCIAS

Referencias citadas

1. Francis Galton, *Natural Inheritance*, Macmillan, Londres, (1899).
2. Francis Galton, *Memories of My Life*, Methuen, Londres, 1908.
3. Karl Pearson, *The Life, Letters and Labours of Francis Galton*, Volumen III A, Cambridge en the University Press, 1930.
4. Francis Galton, "Co-relations and Their Measurement, Chiefly from Anthropometric Data," *Proceedings of the Royal Society*, XLV (1888), 135-145.
5. F. A. Graybill y D. C. Bowden, "Linear Segment Confidence Bands for Simple Linear Models," *Journal of the American Statistical Association*, 62 (1967), 403-408.

6. Olive Jean Dunn, "A Note on Confidence Bands for a Regression Line Over a Finite Range," *Journal of the American Statistical Association*, 63 (1968), 1028-1033.
7. P. G. Hoel, "Confidence Regions for Linear Regression," *Proceedings of the Second Berkeley Symposium on Mathematical Statistics and Probability*, University of California Press, Berkeley, 1951, pp. 75-81.
8. A. V. Gafarian, "Confidence Bands in Straight Line Regression," *Journal of the American Statistical Association*, 59 (1964), 182-213.
9. M. Halperin y J. Gurian, "Confidence Bands in Linear Regression with Constraints in the Independent Variables," *Journal of the American Statistical Association*, 63 (1968), 1020-1027.
10. R. C. Elston y J. E. Grizzle, "Estimation of Time Response Curves and their Confidence Bands," *Biometrics*, 18 (1962), 148-159.
11. R. A. Fisher, "On the Probable Error of a Coefficient of Correlation Deduced from a Small Sample," *Metron*, 1 (1921), 3-21.
12. H. Hotelling, "New Light on the Correlation Coefficient and its Transforms," *Journal of the Royal Statistical Society, Ser B*, 15 (1953), 193-232.
13. F. N. David, *Tables of the Ordinates and Probability Integral of the Distribution of the Correlation Coefficient in Small Samples*, Cambridge University Press, Cambridge, 1938.

Otras referencias, libros

1. F. S. Acton, *Analysis of Straight Line Data*, Wiley, Nueva York, 1959.
2. Andrew R. Baggaley, *Intermediate Correlational Methods*, Wiley, Nueva York, 1964.
3. Cuthbert Daniel y Fred S. Wood, *Fitting Equations to Data*, Wiley-Interscience, Nueva York, 1971.
4. N. R. Draper y H. Smith, *Applied Regression Analysis*, segunda edición, Wiley, Nueva York, 1981.
5. Mordecai Ezekiel y Karl A. Fox, *Methods of Correlation and Regression Analysis*, tercera edición, Wiley, Nueva York, 1959.
6. Arthur S. Goldberger, *Topics in Regression Analysis*, Macmillan, Toronto, 1968.
7. David G. Kleinbaum y Lawrence L. Kupper, *Applied Regression Analysis and Other Multivariable Methods*, Duxbury Press, North Scituate, Mass., 1978.

8. R. L. Plackett, *Principles of Regression Analysis*, Oxford University Press, Londres, 1960.
9. K. W. Smillie, *An Introduction to Regression and Correlation*, Academic Press, Nueva York, 1966.
10. Peter Sprent, *Models in Regression*, Methuen, Londres, 1969.
11. E. J. Williams, *Regression Analysis*, Wiley, Nueva York, 1959.
12. Stephen Wiseman, *Correlation Methods*, Manchester University Press, Manchester, 1966.
13. Mary Sue Younger, *Handbook for Linear Regression*, Duxbury Press, North Scituate, Mass., 1979.

Otras referencias, artículos de revistas

1. R. G. D. Allen, "The Assumptions of Linear Regression," *Economica*, 6 N.S. (1939), 191-204.
2. M. S. Bartlett, "The Fitting of Straight Lines if Both Variables Are Subject to Error," *Biometrics*, 5 (1949), 207-212.
3. J. Berkson, "Are There Two Regressions?" *Journal of the American Statistical Association*, 45 (1950), 164-180.
4. Dudley J. Cowden, "A Procedure for Computing Regression Coefficients," *Journal of the American Statistical Association*, 53 (1958), 144-150.
5. A. S. C. Ehrenberg, "Bivariate Regression Is Useless," *Applied Statistics*, 12 (1963), 161-179.
6. M. G. Kendall, "Regression, Structure, and Functional Relationship, Parte I," *Biometrika*, 28 (1951), 11-25.
7. M. G. Kendall, "Regression, Structure and Functional Relationship II," *Biometrika*, 39 (1952), 96-108.
8. D. V. Lindley, "Regression Lines and the Linear Functional Relationship," *Journal of the Royal Statistical Society (Supplemento)*, IX (1947), 218-244.
9. A. Madansky, "The Fitting of Straight Lines When Both Variables Are Subject to Error," *Journal of the American Statistical Association*, 54 (1959), 173-205.
10. A. Wald, "The Fitting of Straight Lines if Both Variables Are Subject to Error," *Annals of Mathematical Statistics*, 11 (1940), 284-300.
11. W. G. Warren, "Correlation or Regression: Bias or Precision," *Applied Statistics*, 20 (1971), 148-164.
12. Charles P. Winsor, "Which Regression?" *Biometrics*, 2 (1946), 101-109.

9

Regresión y correlación múltiples

9.1 INTRODUCCIÓN

En el capítulo 8 se examinaron los conceptos y técnicas para analizar y utilizar la relación entre dos variables. Se observó que este análisis puede conducir a una ecuación que puede utilizarse para predecir el valor de alguna variable dependiente dado el valor de una variable independiente asociada.

La intuición señala que, en general, debe tenerse la capacidad de mejorar la habilidad para predecir al incluir más variables independientes en dicha ecuación.

Por ejemplo, un investigador encuentra que las calificaciones de inteligencia de las personas pueden predecirse a partir de factores físicos como el orden del nacimiento, el peso al nacer y la duración de la gestación, junto con ciertos factores hereditarios y ambientales. La duración de la hospitalización de una persona en un hospital de enfermedades crónicas puede depender de la edad del paciente, estado civil, sexo e ingresos, no sin mencionar el factor obvio del diagnóstico. La respuesta de un animal de laboratorio a algún medicamento puede depender del tamaño de la dosis y de la edad y peso del animal. Una enfermera supervisora desea saber la intensidad de la relación entre la eficiencia de una enfermera en el trabajo, su calificación en el examen de la dirección estatal, sus antecedentes escolares y su calificación en alguna prueba de habilidad o aptitud. O bien, el administrador de un hospital, al estudiar las admisiones de diversas comunidades servi-

das por su hospital, desea determinar qué factores parecen ser los que influyen en las diferencias que se observan en las tasas de admisión.

Los conceptos y técnicas para analizar la asociación entre varias variables son extensiones naturales de los que se estudiaron en los capítulos anteriores. Los cálculos, como es de esperar, son más complejos y tediosos. Sin embargo, como se señaló en el capítulo 8, esto no constituye un problema real siempre que se disponga de una computadora electrónica. No es raro encontrar investigadores que estudien las relaciones existentes entre una docena de variables o más. Para quienes tienen acceso a una computadora, la decisión acerca de cuántas variables incluir en un análisis se basa no en la complejidad y lo largo de los cálculos, sino en consideraciones tales como su importancia, el costo de su inclusión y la importancia de su contribución.

En este capítulo se sigue estrictamente la secuencia del capítulo anterior. Primero se estudia el modelo de regresión, seguido por un análisis del modelo de correlación. Al considerar el modelo de regresión, se cubren los siguientes puntos: una descripción del modelo, los métodos para obtener la ecuación de regresión, la evaluación de la ecuación y los usos que pueden hacerse de ella. En ambos modelos se estudian los procedimientos inferenciales posibles y sus suposiciones fundamentales.

9.2 EL MODELO DE REGRESIÓN MÚLTIPLE_____

En el modelo de regresión múltiple, se supone que existe una relación lineal entre alguna variable Y , a la cual se da el nombre de variable dependiente, y k variables independientes, $X_1, X_2, \dots, X_k$. A veces, las variables independientes se conocen como *variables explicativas* debido a que se utilizan para explicar la variación en Y , y como *variables de predicción*, por su uso en predecir Y .

Las suposiciones acompañantes son las siguientes.

1. Las X_i son variables no aleatorias (fijas). Esta suposición distingue al modelo de regresión múltiple del modelo de correlación múltiple, el cual se estudiará en la sección 9.6. Esta condición indica que cualquier inferencia que se haga de los datos de la muestra sólo se aplica al conjunto de valores de X observados y no a algún conjunto mayor de X . Bajo el modelo de regresión, el análisis de correlación carece de significado. Bajo el modelo de correlación,

que se estudiará posteriormente, pueden aplicarse las siguientes técnicas de regresión.

2. Para cada conjunto de valores de X_i , existe una subpoblación de valores de Y . Para construir ciertos intervalos de confianza y probar hipótesis, debe saberse, o el investigador debe inclinarse a suponer, que estas subpoblaciones de valores de Y tienen distribución normal. Ya que se deseará demostrar estos procedimientos inferenciales, se hará la suposición de normalidad en los ejemplos y ejercicios de este capítulo.
 3. Todas las variancias de las subpoblaciones de Y son iguales.
 4. Los valores de Y son independientes. Es decir, Los valores de Y seleccionados para un conjunto de valores de X no dependen de los valores de Y seleccionados en otro conjunto de valores de X .
- Estas suposiciones pueden enunciarse en forma más concreta como

$$y_j = \beta_0 + \beta_1 x_{1j} + \beta_2 x_{2j} + \cdots + \beta_k x_{kj} + e_j \quad (9.2.1)$$

donde y_j es un valor típico de una de las subpoblaciones de los valores de Y , los β_i se conocen como coeficientes de regresión, x_{1j} , x_{2j} , $\dots$, x_{kj} son, respectivamente, los valores particulares de las variables independientes X_1 , X_2 , $\dots$, X_k , y e_j es una variable aleatoria con media de 0 y variancia σ^2 , que es la variancia común de las subpoblaciones de los valores de Y . Para construir intervalos de confianza para los coeficientes de regresión y probar hipótesis acerca de ellos, se supone que los e_j tienen distribución normal e independiente. Las afirmaciones referentes a los e_j son consecuencia de las suposiciones referentes a las distribuciones de los valores de Y . La ecuación 9.2.1 se conoce como el *modelo de regresión múltiple*.

Cuando la ecuación 9.2.1 consta de una variable dependiente y dos variables independientes, es decir, cuando el modelo se escribe como

$$y_j = \beta_0 + \beta_1 x_{1j} + \beta_2 x_{2j} + e_j \quad (9.2.2)$$

puede ajustarse un *plano* en el espacio tridimensional a los puntos de los datos, como se muestra en la figura 9.2.1. Cuando el modelo contiene más de dos variables independientes, se describe geométricamente como un *hiperplano*.

En la figura 9.2.1, el observador debe imaginar algunos de los puntos como si estuvieran localizados por arriba del plano y otros como




Figura 9.2.1 Plano de regresión múltiple y dispersión de los puntos.

si estuvieran por debajo. La desviación de un punto respecto del plano está representada por la expresión

$$e_j = y_j - \beta_0 - \beta_1 x_{1j} - \beta_2 x_{2j} \quad (9.2.3)$$

En la ecuación 9.2.2, β_0 representa el punto donde el plano corta al eje Y , es decir, representa la ordenada al origen del plano. β_1 mide el cambio promedio en Y para un cambio unitario en X_1 cuando X_2 permanece sin cambios, y β_2 mide el cambio promedio en Y para un cambio unitario en X_2 cuando X_1 permanece sin cambios. Por esta razón, β_1 y β_2 se conocen como *coeficientes de regresión parcial*.

9.3 OBTENCIÓN DE LA ECUACIÓN DE REGRESIÓN MÚLTIPLE

Las estimaciones insesgadas de los parámetros $\beta_0, \beta_1, \dots, \beta_k$ del modelo especificado en la ecuación 9.2.1 se obtienen mediante el método de los mínimos cuadrados. Esto significa que se minimiza la suma de

las desviaciones elevadas al cuadrado de los valores observados de Y respecto de la superficie de regresión resultante. En el caso de tres variables, como se muestra en la figura 9.2.1, la suma de las desviaciones al cuadrado de las observaciones, respecto del plano, es un mínimo cuando se estiman β_0, β_1 y β_2 por el método de los mínimos cuadrados. En otras palabras, por el método de los mínimos cuadrados, se seleccionan estimaciones de $\beta_0, \beta_1, \dots, \beta_k$ de la muestra en tal forma que se minimice la cantidad

$$\sum e_j^2 = \sum (y_j - \beta_0 x_{1j} - \beta_1 x_{2j} - \cdots - \beta_k x_{kj})$$

Esta cantidad, conocida como suma de los cuadrados de los residuales, puede escribirse también como

$$\sum (y_i - y_c)^2 \quad (9.3.1)$$

indicando el hecho de que se minimiza la suma de cuadrados de las desviaciones de los valores observados de Y respecto de los valores de esta variable calculados a partir de la ecuación estimada.

Las estimaciones $b_0, b_1, b_2, \dots, b_k$ de los coeficientes de regresión se obtienen resolviendo la siguiente serie de ecuaciones normales:

[illegible]

A continuación se hace el cálculo de la ecuación de regresión estimada y se indican sus usos para el caso donde se tiene una variable dependiente y dos variables independientes.

Cuando el modelo contiene sólo dos variables independientes, la ecuación de regresión de la muestra es

$$y_{ci} = b_0 + b_1 x_{1i} + b_2 x_{2i} \quad (9.3.3)$$

Ejemplo 9.3.1

En un estudio de la duración de la hospitalización para los pacientes que estaban en un hospital de enfermedades crónicas, un investigador

deseaba saber cómo podría predecir la duración del internado (Y), dadas las variables independientes, número de admisiones previas (X_1) y edad (X_2). Los datos de la tabla 9.3.1 se obtuvieron de una muestra de $n = 15$ pacientes.

Para obtener la ecuación de los mínimos cuadrados, deben resolverse las siguientes ecuaciones normales para los coeficientes de regresión de la muestra:

$$\left. \begin{aligned} nb_0 + b_1 \sum x_{1j} + b_2 \sum x_{2j} &= \sum y_j \\ b_0 \sum x_{1j} + b_1 \sum x_{1j}^2 + b_2 \sum x_{1j}x_{2j} &= \sum x_{1j}y_j \\ b_0 \sum x_{2j} + b_1 \sum x_{1j}x_{2j} + b_2 \sum x_{2j}^2 &= \sum x_{2j}y_j \end{aligned} \right\} \quad (9.3.4)$$

Tabla 9.3.1 Duración de la hospitalización en días, edad en años y número de admisiones previas de 15 pacientes admitidos a un hospital de enfermedades crónicas.

<i>Duración de la hospitalización (Y)</i>	<i>Número de admisiones previas (X₁)</i>	<i>Edad (X₂)</i>
15	0	21
15	0	18
21	0	22
28	1	24
30	1	25
35	1	25
40	1	26
35	2	34
30	2	25
45	2	38
50	3	44
60	3	51
45	4	39
60	4	54
50	5	55

Nótese que el número de ecuaciones es igual al número de los parámetros que van a estimarse. Pueden resolverse las tres ecuaciones como están, o bien, pueden reducirse a un conjunto de dos ecuacio-

nes transformando cada valor en una desviación respecto de su media. Si se designan estas desviaciones por y'_j , x'_{1j} y x'_{2j} , se tiene que

$$\left. \begin{aligned} y'_j &= y_j - \bar{y} \\ x'_{1j} &= x_{1j} - \bar{x}_1 \\ x'_{2j} &= x_{2j} - \bar{x}_2 \end{aligned} \right\} \quad (9.3.5)$$

Si se resta la ecuación original de regresión de la muestra (ecuación 9.3.3) en términos de estas transformaciones, se tiene que

$$y'_{cj} = b'_0 + b'_1 x'_{1j} + b'_2 x'_{2j} \quad (9.3.6)$$

donde b'_0 , b'_1 y b'_2 son los coeficientes apropiados para las variables transformadas. La relación entre los dos conjuntos de coeficientes puede determinarse sustituyendo las desviaciones de las medias de las variables originales en la ecuación 9.3.6 y simplificando entonces. Así, se tiene que

$$\begin{aligned} y_{cj} - \bar{y} &= b'_0 + b'_1(x_{1j} - \bar{x}_1) + b'_2(x_{2j} - \bar{x}_2) \\ y_{cj} &= \bar{y} + b'_0 + b'_1 x_{1j} - b'_1 \bar{x}_1 + b'_2 x_{2j} - b'_2 \bar{x}_2 \\ y_{cj} &= b'_0 + \bar{y} - b'_1 \bar{x}_1 - b'_2 \bar{x}_2 + b'_1 x_{1j} + b'_2 x_{2j} \end{aligned} \quad (9.3.7)$$

Cuando se establecen los coeficientes de términos iguales en las ecuaciones 9.3.3 y 9.3.7, iguales entre sí, se tiene que

$$\begin{aligned} b_1 &= b'_1 \\ b_2 &= b'_2 \end{aligned}$$

y, por lo tanto,

$$b_0 = b'_0 + \bar{y} - b'_1 \bar{x}_1 - b'_2 \bar{x}_2 = b'_0 + \bar{y} - b_1 \bar{x}_1 - b_2 \bar{x}_2 \quad (9.3.8)$$

Un nuevo conjunto de ecuaciones normales basado en la ecuación 9.3.6 es

$$\begin{aligned} nb'_0 + b'_1 \sum x'_{1j} + b'_2 \sum x'_{2j} &= \sum y'_j \\ b'_0 \sum x'_{1j} + b'_1 \sum x'^2_{1j} + b'_2 \sum x'_{1j} x'_{2j} &= \sum x'_{1j} y'_j \\ b'_0 \sum x'_{2j} + b'_1 \sum x'_{1j} x'_{2j} + b'_2 \sum x'^2_{2j} &= \sum x'_{2j} y'_j \end{aligned}$$

Utilizando las transformaciones de la ecuación 9.3.5 y la propiedad de que $\sum (x_i - \bar{x}) = 0$, se obtiene

$$\begin{aligned} nb'_0 + b'_1(0) + b'_2(0) &= 0 \\ b'_0(0) + b'_1 \sum (x_{1j} - \bar{x}_1)^2 + b'_2 \sum (x_{1j} - \bar{x}_1)(x_{2j} - \bar{x}_2) &= \sum (x_{1j} - \bar{x}_1)(y_j - \bar{y}) \\ b'_0(0) + b'_1 \sum (x_{1j} - \bar{x}_1)(x_{2j} - \bar{x}_2) + b'_2 \sum (x_{2j} - \bar{x}_2)^2 &= \sum (x_{2j} - \bar{x}_2)(y_j - \bar{y}) \end{aligned}$$

Nótese que $b'_0 = 0$. Así, mediante la ecuación 9.3.8, se tiene que

$$b_0 = \bar{y} - b_1 \bar{x}_1 - b_2 \bar{x}_2$$

y cuando se sustituyen b_1 y b_2 por b'_1 y b'_2 , respectivamente, las ecuaciones normales se condensan en las siguientes:

$$\left. \begin{aligned} b_1 \sum x'_{1j}{}^2 + b_2 \sum x'_{1j} x'_{2j} &= \sum x'_{1j} y'_j \\ b_1 \sum x'_{1j} x'_{2j} + b_2 \sum x'_{2j}{}^2 &= \sum x'_{2j} y'_j \end{aligned} \right\} \quad (9.3.9)$$

La tabla 9.3.2 contiene las sumas de cuadrados y los productos cruzados de los valores originales necesarios para calcular las sumas de cuadrados y productos cruzados de y'_j , x'_{1j} y x'_{2j} .

Utilizando los datos de la tabla 9.3.2, se calcula lo siguiente:

$$\begin{aligned} \sum x'_{1j}{}^2 &= \sum (x_{1j} - \bar{x}_1)^2 = \sum x_{1j}{}^2 - (\sum x_{1j})^2/n \\ &= 91 - (29)^2/15 = 34.93 \\ \sum x'_{2j}{}^2 &= \sum (x_{2j} - \bar{x}_2)^2 = \sum x_{2j}{}^2 - (\sum x_{2j})^2/n \\ &= 18,975 - (501)^2/15 = 2241.60 \\ \sum x'_{1j} x'_{2j} &= \sum (x_{1j} - \bar{x}_1)(x_{2j} - \bar{x}_2) = \sum x_{1j} x_{2j} - \sum x_{1j} \sum x_{2j}/n \\ &= 1226 - (29)(501)/15 = 257.40 \\ \sum x'_{1j} y'_j &= \sum (x_{1j} - \bar{x}_1)(y_j - \bar{y}) = \sum x_{1j} y_j - \sum x_{1j} \sum y_j/n \\ &= 1353 - (29)(559)/15 = 272.27 \\ \sum x'_{2j} y'_j &= \sum (x_{2j} - \bar{x}_2)(y_j - \bar{y}) = \sum x_{2j} y_j - \sum x_{2j} \sum y_j/n \\ &= 21,039 - (501)(559)/15 = 2368.40 \end{aligned}$$

Cuando se sustituyen estos valores en las ecuaciones 9.3.9, se tiene que

$$\left. \begin{aligned} 34.93b_1 + 257.40b_2 &= 272.27 \\ 257.40b_1 + 2241.60b_2 &= 2368.40 \end{aligned} \right\} \quad (9.3.10)$$