

Tabla 9.3.2 Sumas de cuadrados y sumas de productos cruzados para el ejemplo 9.3.1.

y_j	x_{1j}	x_{2j}	$x_{1j}x_{2j}$	$x_{1j}y_j$	$x_{2j}y_j$	x_{1j}^2	x_{2j}^2	y_j^2	
15	0	21	0	0	315	0	441	225	
15	0	18	0	0	270	0	324	225	
21	0	22	0	0	462	0	484	441	
28	1	24	24	28	672	1	576	784	
30	1	25	25	30	750	1	625	900	
35	1	25	25	35	875	1	625	1225	
40	1	26	26	40	1040	1	676	1600	
35	2	34	68	70	1190	4	1156	1225	
30	2	25	50	60	750	4	625	900	
45	2	38	76	90	1710	4	1444	2025	
50	3	44	132	150	2200	9	1936	2500	
60	3	51	153	180	3060	9	2601	3600	
45	4	39	156	180	1755	16	1521	2025	
60	4	54	216	240	3240	16	2916	3600	
50	5	55	275	250	2750	25	3025	2500	
Totales	559	29	501	1,226	1,353	21,039	91	18,975	23,775
Medias	37.27	1.93	33.40						

Estas ecuaciones pueden resolverse por cualquier método estándar para obtener

$$b_1 = .06$$

$$b_2 = 1.05$$

b_0 se obtiene a partir de la relación:

$$b_0 = \bar{y} - b_1\bar{x}_1 - b_2\bar{x}_2 \quad (9.3.11)$$

Para el presente ejemplo, se tiene que

$$\begin{aligned} b_0 &= 37.27 - (.06)(1.93) - (1.05)(33.40) \\ &= 2.08 \end{aligned}$$

La ecuación de regresión múltiple de la muestra es entonces,

$$y_c = 2.08 + .06x_{1j} + 1.05x_{2j} \quad (9.3.12)$$

Se ha utilizado un ejemplo que contiene sólo tres variables para facilitar la comprensión del tema. A medida que aumenta el número

de variables, las manipulaciones algebraicas y los cálculos aritméticos se hacen más tediosos y sujetos a error, aun cuando sean extensiones naturales de los procedimientos dados en el presente ejemplo.

Snedecor y Cochran¹ y Steel y Torrie² dan ejemplos numéricos para cuatro variables, y Anderson y Bancroft³ ilustran los cálculos que intervienen cuando se tienen cinco variables. Las técnicas utilizadas por estos autores se aplican a cualquier número de variables.

Afortunado es el investigador que, viendo necesario utilizar las técnicas del análisis de regresión múltiple, tiene acceso a una computadora electrónica y a programas ya elaborados que incluyen un gran número de variables. Puede olvidarse de las complejidades algebraicas y aritméticas de sus problemas y concentrarse en la evaluación de lo adecuado de sus modelos y en la interpretación de sus resultados.

Una vez que se ha obtenido la ecuación de regresión múltiple, el siguiente paso comprende su evaluación e interpretación. Esta es la faceta del análisis que se cubre en la siguiente sección.

Ejercicios

Obtenga la ecuación de regresión para cada uno de los siguientes conjuntos de datos.

9.3.1 En un estudio diseñado para descubrir qué factores podrían estar relacionados con el peso al nacer, se obtuvieron los siguientes datos en 10 niños recién nacidos.

Peso al nacer en gramos (Y)	Estimación del nivel socioeconómico (X_1)	Orden de nacimiento (X_2)
1361	8	4
1588	7	3
1815	4	4
2087	5	3
2268	5	2
2404	4	2
3402	3	2
3629	3	1
3765	2	1
4083	1	1
26402	42	23
$\sum x_{1j}^2 = 218$	$\sum x_{2j}^2 = 65$	$\sum y_j^2 = 78,536,258$
$\sum x_{1j}x_{2j} = 114$	$\sum x_{1j}y_j = 93,361$	$\sum x_{2j}y_j = 51,354$

9.3.2 Un investigador reunió los siguientes datos en 15 niños.

<i>Calificación de inteligencia (Y)</i>	<i>Orden de nacimiento (X₁)</i>	<i>Edad de la madre al nacimiento del niño (X₂)</i>
110	1	25
115	1	24
120	1	22
118	1	24
110	2	20
108	2	20
105	2	20
104	3	24
98	3	25
99	4	30
98	4	24
100	5	29
90	5	30
93	5	30
90	6	28
Totales 1558	45	375
$\sum x_{1j}^2 = 177$	$\sum x_{2j}^2 = 9563$	$\sum y_j^2 = 163,112$
$\sum x_{1j}x_{2j} = 1191$	$\sum x_{1j}y_j = 4458$	$\sum x_{2j}y_j = 38,620$

9.3.3 En un estudio de los factores que se pensaba estaban relacionados con los patrones de admisión a un hospital general grande, el administrador de un hospital obtuvo estos datos en 10 comunidades en el área de trabajo del hospital:

<i>Comunidad</i>	<i>Personas admitidas por cada 1,000 de la población durante el período de estudio (Y)</i>	<i>Índice de disponibilidad de otros servicios de salud (X₁)</i>	<i>Índice de inteligencia (X₂)</i>
1	61.6	6.0	6.3
2	53.2	4.4	5.5
3	65.5	9.1	3.6
4	64.9	8.1	5.8
5	72.7	9.7	6.8

<i>Comunidad</i>	<i>Personas admitidas por cada 1:000 de la población durante el período de estudio (Y)</i>	<i>Índice de disponibilidad de otros servicios de salud (X₁)</i>	<i>Índice de inteligencia (X₂)</i>
6	52.2	4.8	7.9
7	50.2	7.6	4.2
8	44.0	4.4	6.0
9	53.8	9.1	2.8
10	53.5	6.7	6.7
Total	571.6	69.9	55.6
$\sum x_{1j}^2 = 525.73$ $\sum x_{2j}^2 = 331.56$ $\sum y_j^2 = 33,349.92$ $\sum x_{1j}x_{2j} = 374.31$ $\sum x_{1j}y_j = 4104.32$ $\sum x_{2j}y_j = 3183.57$			

9.3.4 El administrador de un hospital general obtuvo los siguientes datos en 20 pacientes de cirugía durante un estudio para determinar qué factores parecen estar relacionados con la duración de la hospitalización.

<i>Duración del internado postoperatorio en días (Y)</i>	<i>Número de problemas médicos comunes (X₁)</i>	<i>Duración del internado preoperatorio en días (X₂)</i>
6	1	1
6	2	1
11	2	2
9	1	3
16	3	3
16	1	5
4	1	1
8	3	1
11	2	2
13	3	2
13	1	4
9	1	2
17	3	3
17	2	4
12	4	1
6	1	1

<i>Duración del internado postoperatorio en días (Y)</i>	<i>Número de problemas médicos comunes (X₁)</i>	<i>Duración del internado preoperatorio en días (X₂)</i>
5	1	1
12	3	2
8	1	2
9	2	2
Total 208	38	43
$\sum x_{1j}^2 = 90$	$\sum x_{2j}^2 = 119$	$\sum y_j^2 = 2478$
$\sum x_{1j}x_{2j} = 79$	$\sum x_{1j}y_j = 430$	$\sum x_{2j}y_j = 519$

9.3.5 Utilice como referencia el ejercicio 8.7.5. El investigador dispuso de información adicional sobre la calificación obtenida por cada enfermera en una prueba de aptitud realizada cuando la enfermera ingresó a la escuela. Los datos completos son los siguientes.

<i>Calificación obtenida en el examen de la dirección estatal (Y)</i>	<i>Calificación final (X₁)</i>	<i>Calificación obtenida en la prueba de aptitud (X₂)</i>
440	87	92
480	87	79
535	87	99
460	88	91
525	88	84
480	89	71
510	89	78
530	89	78
545	89	71
600	89	76
495	90	89
545	90	90
575	90	73
525	91	71
575	91	81
600	91	84
490	92	70
510	92	85

<i>Calificación obtenida en el examen de la dirección estatal (Y)</i>	<i>Calificación final (X₁)</i>	<i>Calificación obtenida en la prueba de aptitud (X₂)</i>
575	92	71
540	93	76
595	93	90
525	94	94
545	94	94
600	94	93
625	94	73
Total 13,425	2263	2053
$\sum x_{1j}^2 = 204,977$	$\sum x_{2j}^2 = 170,569$	$\sum y_j^2 = 7,264,525$
$\sum x_{1j}x_{2j} = 185,838$	$\sum x_{1j}y_j = 1,216,685$	$\sum x_{2j}y_j = 1,101,220$

9.4 EVALUACIÓN DE LA ECUACIÓN DE REGRESIÓN MÚLTIPLE

Antes de utilizar una ecuación de regresión múltiple, es conveniente determinar primero si, de hecho, vale la pena utilizarla. Al estudiar la regresión lineal simple, se ha aprendido que puede evaluarse la utilidad de una ecuación de regresión considerando el coeficiente de determinación de la muestra y la pendiente estimada. Al evaluar la ecuación de regresión múltiple, la atención se centra en el *coeficiente de determinación múltiple* y los coeficientes de regresión parciales.

El coeficiente de determinación múltiple. En el capítulo 8 se estudió con bastante detalle el coeficiente de determinación. El concepto se extiende lógicamente hacia el caso de la regresión múltiple. Puede dividirse la variación total presente en los valores de Y en dos componentes: la variación explicada, que mide la cantidad de la variación total que es explicada por la superficie de regresión ajustada, y la variación inexplorada, que es aquella parte de la variación total que no es explicada por el ajuste de la superficie de regresión. La medida de la variación en cada caso es una suma de desviaciones elevadas al cuadrado. La variación total es la suma de las desviaciones al cuadrado de cada observación de Y a partir de la media de las observaciones y se designa por $\sum (y_j - \bar{y})^2$. La variación explicada, designada por $\sum (y_c - \bar{y})^2$, es la suma de las desviaciones al cuadrado de los valores calculados a partir de la media de los valores de Y obser-

vados. Esta suma de desviaciones al cuadrado a veces se conoce como *suma de cuadrados debida a la regresión*. La variación inexplicada, escrita como $\sum (y_j - y_c)^2$, es la suma de las desviaciones al cuadrado de las observaciones originales a partir de los valores calculados. Esta cantidad se conoce a veces como la *suma de cuadrados en torno a la regresión*. Puede resumirse la relación entre las tres sumas de cuadrados mediante la siguiente ecuación:

$$\begin{aligned}\sum (y_j - \bar{y})^2 &= \sum (y_c - \bar{y})^2 + \sum (y_j - y_c)^2 \\ SC_{\text{total}} &= SC_{\text{exp.}} + SC_{\text{inexp.}}\end{aligned}\quad (9.4.1)$$

suma de cuadrados total = suma de cuadrados explicada
+ suma de cuadrados inexplicada

Las sumas de cuadrados total, explicada e inexplicada, se calculan de la manera siguiente:

$$SC_{\text{total}} = \sum (y_j - \bar{y})^2 = \sum y_j^2 - (\sum y_j)^2/n \quad (9.4.2)$$

$$\begin{aligned}SC_{\text{exp.}} &= \sum (y_c - \bar{y})^2 \\ &= b_1 \sum x'_{1j} y'_j + b_2 \sum x'_{2j} y'_j + \cdots + b_k \sum x'_{kj} y'_j\end{aligned}\quad (9.4.3)$$

$$SC_{\text{inexp.}} = SC_{\text{total}} - SC_{\text{exp.}} \quad (9.4.4)$$

Para el ejemplo ilustrativo, se tiene que (utilizando los datos de la tabla 9.3.2 y algunos cálculos anteriores)

$$SC_{\text{total}} = 23,775 - (559)^2/15 = 2942.93$$

$$SC_{\text{exp.}} = (.06)(272.27) + (1.05)(2368.40) = 2503.16$$

$$SC_{\text{inexp.}} = 2942.93 - 2503.16 = 439.77$$

El coeficiente de determinación múltiple, $R^2_{y.12\dots k}$, se obtiene dividiendo la suma de cuadrados explicada entre la suma total de cuadrados. Es decir,

$$R^2_{y.12\dots k} = \frac{\sum (y_c - \bar{y})^2}{\sum (y_j - \bar{y})^2} \quad (9.4.5)$$

El subíndice $y.12\dots k$ indica que en el análisis Y se trata como la variable dependiente y las variables X , de X_1 a X_k , se tratan como

las variables independientes. El valor de $R^2_{y.12\dots k}$ indica qué proporción de la variación total en los valores de Y observados es explicada por la regresión de Y sobre $X_1, X_2, \dots, X_k$. En otras palabras, puede decirse que $R^2_{y.12\dots k}$ es una medida de la bondad del ajuste de la superficie de regresión. Esta cantidad es análoga a r^2 , que se calculó en el capítulo 8.

Para el presente ejemplo, se tiene que

$$R^2_{y.12} = \frac{2503.16}{2942.93} = .85$$

Se dice que el 85 por ciento de la variación total en los valores de Y es explicada por el plano de regresión ajustado.

Para determinar si la regresión en conjunto es significativa, puede llevarse a cabo un análisis de variancia. Al hacerlo, se prueba la hipótesis nula de que $\beta_1 = \beta_2 = \dots = \beta_k = 0$, es decir, que ninguna variable independiente tiene valor al explicar la variación en los valores de Y . La tabla ANDEVA general se muestra en la tabla 9.4.1. En esta tabla, CMR representa el cuadrado medio debido a la regresión y CME el cuadrado medio en torno a la regresión o, como algunas veces se conoce, el cuadrado medio de error.

Para el ejemplo ilustrativo, el análisis de variancia se muestra en la tabla 9.4.2.

Cuando se consulta la tabla J con 2 y 12 grados de libertad, se encuentra que la R.V. calculada de 34.15 es significativa al nivel de .005 (es decir, $p < .005$). Por lo tanto, se concluye que la regresión explica una proporción significativa de la variación total en Y . En otras palabras, se concluye que el plano ajustado da un buen ajuste de los datos.

Tabla 9.4.1 Tabla ANDEVA para la regresión múltiple.

<i>Fuente</i>	<i>SC</i>	<i>g.l.</i>	<i>CM</i>	<i>R.V.</i>
Debida a la regresión	$SC_{\text{exp.}}$	k	$CMR = SC_{\text{exp.}}/k$	CMR/CME
En torno a la regresión	$SC_{\text{inexp.}}$	$n - k - 1$	$CME = SC_{\text{inexp.}}/n - k - 1$	
Total	SC_{total}	$n - 1$		

Tabla 9.4.2 Tabla ANDEVA para el ejemplo 9.3.1.

Fuente	SC	g.l.	CM	R.V.
Debida a la regresión	2503.16	2	1251.58	34.15
En torno a la regresión	439.77	12	36.65	
Total	2942.93	14		

Inferencias referentes a β 's individuales. Un procedimiento alternativo para evaluar la intensidad de la relación lineal entre Y y las variables independientes es probar la hipótesis nula de que $\beta_i = 0$ contra la alternativa $\beta_i \neq 0 (i = 1, 2, \dots, k)$. La validez de este procedimiento descansa en las suposiciones enunciadas al principio: que, para cada combinación de valores de X_i , existe una subpoblación de valores de Y con distribución normal y variancia σ^2 . Cuando se cumplen estas suposiciones, puede demostrarse que cada una de las estimaciones de la muestra, b_i , tiene distribución normal con media β_i y variancia $c_{ii}\sigma^2$. Dado que se desconoce σ^2 , tiene que estimarse. Una estimación la proporciona el cuadrado medio en torno a la regresión, el cual se muestra en la tabla ANDEVA. En general, puede designarse a esta cantidad como $s^2_{y.12\dots k}$. Para el ejemplo ilustrativo se tiene, que, a partir de la tabla 9.4.2, $s^2_{y.12} = 36.65$ y $s_{y.12} = 6.05$. Sin embargo, debe divagarse brevemente en este punto para explicar el cálculo de c_{ii} .

Cálculo de los c_{ii} . Los valores c_{ii} se conocen como *multiplicadores de Gauss*. Para quienes están familiarizados con el álgebra de matrices, puede ser ilustrativo señalar que pueden obtenerse invirtiendo la matriz de las sumas de los cuadrados y productos cruzados que pueden construirse utilizando los términos de la izquierda de las ecuaciones normales dadas en la ecuación 9.3.5. Las c 's pueden encontrarse sin utilizar el álgebra de matrices resolviendo las siguientes dos series de ecuaciones:

$$\left. \begin{aligned} c_{11}\sum x'^2_{1j} + c_{12}\sum x'_{1j}x'_{2j} &= 1 \\ c_{11}\sum x'_{1j}x'_{2j} + c_{12}\sum x'^2_{2j} &= 0 \end{aligned} \right\} \tag{9.4.6}$$

$$\left. \begin{aligned} c_{21}\sum x'^2_{1j} + c_{22}\sum x'_{1j}x'_{2j} &= 0 \\ c_{21}\sum x'_{1j}x'_{2j} + c_{22}\sum x'^2_{2j} &= 1 \end{aligned} \right\} \tag{9.4.7}$$

En las ecuaciones anteriores, $c_{12} = c_{21}$. Nótese también que las sumas de cuadrados y los productos cruzados son los mismos que los encontrados en las ecuaciones normales (ecuación 9.3.5).

Cuando el análisis comprende más de dos variables independientes, las c 's se obtienen desarrollando las ecuaciones 9.4.6 y 9.4.7, de modo que haya una serie de ecuaciones para cada variable independiente. Cada conjunto de ecuaciones contiene también tantas ecuaciones individuales como variables independientes se tengan. El 1 se coloca a la derecha del signo de igualdad en todas las ecuaciones que contengan un término de la forma $c_{ii}\Sigma x_i'^2$. Por ejemplo, en la ecuación 9.4.6, un 1 está a la derecha del signo de igualdad en la ecuación que contiene a $c_{11}\Sigma x_{1j}'^2$. Ezekiel y Fox⁴ han escrito las ecuaciones para el caso de tres variables independientes y, al igual que Snedecor y Cochran,¹ Steel y Torrie² y Anderson y Bancroft,³ han demostrado el uso del método abreviado de Doolittle⁵ para obtener las c 's, así como los coeficientes de regresión. Anderson y Bancroft³ dan un ejemplo numérico para cuatro variables independientes.

Cuando se sustituyen los datos del ejemplo ilustrativo en las ecuaciones 9.4.6 y 9.4.7, se tiene que

$$\left. \begin{aligned} 34.93c_{11} + 257.40c_{12} &= 1 \\ 257.40c_{11} + 2241.60c_{12} &= 0 \\ 34.93c_{21} + 257.40c_{22} &= 0 \\ 257.40c_{21} + 2241.60c_{22} &= 1 \end{aligned} \right\}$$

La solución de estas ecuaciones da

$$\begin{aligned} c_{11} &= .1861 \\ c_{12} = c_{21} &= -.0213711 \\ c_{22} &= .0029001 \end{aligned}$$

Ahora se puede regresar al problema de los procedimientos de inferencia referentes a los coeficientes individuales de regresión parcial. Para probar la hipótesis nula de que β_i es igual a algún valor particular, por ejemplo, β_{i0} , puede calcularse la siguiente estadística t :

$$t = \frac{b_i - \beta_{i0}}{s_{bi}} \quad (9.4.8)$$

donde los grados de libertad son iguales a $n - k - 1$, y

$$s_{bi} = s_{y.12\dots k} \sqrt{c_{ii}} \quad (9.4.9)$$

El error estándar de la diferencia entre dos coeficientes de regresión parciales está dado por la expresión

$$s_{(b_i - b_j)} = \sqrt{s_{y.12\dots k}^2 (c_{ii} + c_{jj} - 2c_{ij})} \quad (9.4.10)$$

de modo que puede probarse $H_0: \beta_i = \beta_j$ al calcular

$$t = \frac{b_i - b_j}{s_{(b_i - b_j)}} \quad (9.4.11)$$

el cual tiene $n - k - 1$ grados de libertad. Los intervalos de confianza para β_i y $\beta_i - \beta_j$ pueden construirse en la forma habitual utilizando un valor de la distribución t para el factor de confiabilidad y los errores estándar dados anteriormente.

Para el ejemplo de la duración de la hospitalización, se probará la hipótesis nula de que el número de admisiones previas carece de importancia para predecir la duración de la hospitalización. Se procede como sigue:

$$H_0: \beta_1 = 0$$

$$H_A: \beta_1 \neq 0$$

$$\text{Sea } \alpha = .05$$

$$t = \frac{b_1 - 0}{s_{b_1}} = \frac{.06}{6.05 \sqrt{.1861}} = \frac{.06}{2.609928} = .023$$

No se rechaza la hipótesis nula, ya que el valor calculado de t , .023, está entre -2.1788 y $+2.1788$, los valores críticos de t para una prueba bilateral cuando $\alpha = .05$ y se tienen 12 grados de libertad. Se concluye entonces que puede no haber una relación lineal significativa entre Y y X_1 cuando X_2 permanece constante. Al menos, estos datos no proporcionan evidencia de dicha relación. En otras palabras, los datos de la presente muestra no proporcionan evidencia suficiente

que indique que el número de admisiones previas, cuando se utiliza en una ecuación de regresión junto con la edad, es una variable útil para predecir la duración de la hospitalización. [Para esta prueba, $p > 2(.10) = .20$.]

Se realizará ahora una prueba similar para el segundo coeficiente de regresión parcial, β_2 .

$$H_0: \beta_2 = 0$$

$$H_A: \beta_2 \neq 0$$

$$\alpha = .05$$

$$t = \frac{b_2 - 0}{s_{b_2}} = \frac{1.05}{6.05 \sqrt{.0029001}} = \frac{1.05}{.325808} = 3.223$$

En este caso, se rechaza la hipótesis nula, ya que 3.223 es mayor que 2.1788. Se concluye que existe una relación lineal entre X_2 y Y cuando X_1 permanece constante, y que la edad, utilizada de esta manera, es una variable útil para predecir la duración de la hospitalización. [Para esta prueba, $p < 2(.005) = .01$.]

Cuando el investigador ha llegado a concluir que un coeficiente de regresión parcial no es de 0, puede ser que se interese en obtener un intervalo para este β_i . Un intervalo de confianza del 100(1 - α) por ciento para un β_i está dado por la expresión

$$b_i \pm t_{(1 - \alpha/2, n-k-1)} s_{y.12 \dots k} \sqrt{c_{ii}}$$

Para el ejemplo ilustrativo, puede calcularse el siguiente intervalo de confianza del 95 por ciento para β_2 :

$$\begin{aligned} &1.05 \pm (2.1788)(6.05) \sqrt{.0029001} \\ &1.05 \pm .71 \\ &.34, 1.76 \end{aligned}$$

Pueden darse a este intervalo las interpretaciones probabilista y práctica habituales. Se tiene el 95 por ciento de confianza de que β_2 esté contenido en el intervalo de .34 a 1.75 ya que, al repetir el muestreo, el 95 por ciento de los intervalos que pueden construirse de esta forma incluirán el parámetro verdadero.

Debe tenerse conocimiento de los problemas que se presentan al llevar a cabo pruebas de hipótesis múltiples y al construir intervalos

de confianza múltiples a partir de los mismos datos de la muestra. El efecto sobre α de llevar a cabo pruebas de hipótesis múltiples a partir de los mismos datos se estudia en la sección 7.6. Surge un problema similar cuando se desean construir intervalos de confianza para dos o más coeficientes de regresión parciales. Los intervalos no serán independientes, de modo que, en general, no se aplica el coeficiente de confianza tabulado. En otras palabras, todos estos intervalos no serían intervalos de confianza del $100(1 - \alpha)$ por ciento. Durand⁶ da un procedimiento que puede seguirse cuando se desean obtener intervalos de confianza para más de un coeficiente de regresión parcial.

Otro problema que a veces se encuentra en la aplicación de la regresión múltiple es la incompatibilidad en los resultados de las diferentes pruebas de significación que pueden llevarse a cabo. En un problema dado, para cierto nivel de significación, puede observarse una de las siguientes situaciones.

1. R^2 y todos los b_i significativos.
2. R^2 y algunos pero no todos los b_i significativos.
3. R^2 significativo pero ningún b_i significativo.
4. Todos los b_i significativos pero no R^2 .
5. Algunos de los b_i significativos, pero no todos ni R^2 .
6. Ni R^2 ni ningún b_i significativo.

Geary y Leser⁷ identifican estas seis situaciones y, después de señalar que las situaciones 1 y 6 no presentan problema alguno (ya que ambas implican resultados compatibles), explican con cierto detalle cada una de las demás situaciones.

Nótese que la situación 2 existe en el ejemplo ilustrativo, donde se tiene un R^2 significativo pero sólo uno de los dos coeficientes de regresión significativos. Geary y Leser⁷ señalan que esta situación es muy común, especialmente cuando se ha incluido un gran número de variables independientes en la ecuación de regresión, y que el único problema es decidir si se eliminan o no del análisis una o más de las variables asociadas a coeficientes no significativos.

Ejercicios

- 9.4.1 Utilice como referencia el ejercicio 9.3.1. a) Calcule el coeficiente de determinación múltiple; b) lleve a cabo un análisis de variancia; c) pruebe la significación de cada $b_i (i > 0)$. Sea $\alpha = .05$

para todas las pruebas de significación. Determine el valor p para todas las pruebas.

- 9.4.2 Utilice como referencia el ejercicio 9.3.2. Haga el análisis sugerido en 9.4.1.
- 9.4.3 Utilice como referencia el ejercicio 9.3.3. Haga el análisis sugerido en 9.4.1.
- 9.4.4 Utilice como referencia el ejercicio 9.3.4. Haga el análisis sugerido en 9.4.1.
- 9.4.5 Utilice como referencia el ejercicio 9.3.5. Haga el análisis sugerido en 9.4.1.

9.5 USO DE LA ECUACIÓN DE REGRESIÓN MÚLTIPLE

Como se aprendió en el capítulo anterior, puede utilizarse una ecuación de regresión para obtener un valor calculado de Y , y_c , cuando se da un valor particular de X . Asimismo, puede utilizarse la ecuación de regresión múltiple para obtener un valor y_c cuando se dan valores particulares de las dos o más variables X presentes en la ecuación.

Tal como fue el caso en la regresión lineal simple, en la regresión múltiple puede interpretarse un valor y_c en una de dos formas. Primero, y_c puede interpretarse como una estimación de la media de la subpoblación de valores de Y que se supone existen para combinación particulares de los valores X_i . Con esta interpretación, y_c es una estimación y , cuando se utiliza con este fin, se considera la ecuación como una *ecuación de estimación*. Con la segunda interpretación, y_c es el valor más probable que tomará Y para los valores dados de las X_i . En este caso, y_c recibe el nombre de *valor pronosticado* de Y , y la ecuación se conoce como *ecuación de predicción*. En ambos casos, pueden construirse intervalos en torno al valor de y_c cuando se cumplen las suposiciones de la sección 9.2. Cuando y_c se interpreta como una estimación de la media de una población, el intervalo se conoce como *intervalo de confianza* y, cuando se interpreta como un valor pronosticado de Y , el intervalo recibe el nombre de *intervalo de predicción*. Véase ahora cómo se construye cada uno de estos intervalos.

Intervalo de confianza para la media de una subpoblación de valores de Y dados valores particulares de las X_i . Se ha visto que puede construirse un intervalo de confianza del $100(1 - \alpha)$ por ciento

para un parámetro mediante el procedimiento general de sumar y restar del estimador una cantidad igual al factor de confiabilidad que corresponda a $1 - \alpha$ multiplicado por el error estándar del estimador. Se ha visto también que, en esta situación, el estimador es

$$y_c = b_0 + b_1x_{1j} + b_2x_{2j} + \cdots + b_kx_{kj} \quad (9.5.1)$$

El error estándar de este estimador, para el caso de dos variables independientes, está dado por la expresión

$$s_{y.12} \sqrt{\frac{1}{n} + c_{11}x'_{1j}{}^2 + c_{22}x'_{2j}{}^2 + 2c_{12}x'_{1j}x'_{2j}} \quad (9.5.2)$$

donde los valores x'_{ij} son valores particulares de las X_i expresados como desviaciones de su media. La expresión 9.5.2 se generaliza fácilmente para cualquier número de variables independientes. Véase, por ejemplo, a Anderson y Bancroft.³ El intervalo de confianza del $100(1 - \alpha)$ por ciento para el caso de tres variables es entonces el que sigue:

$$y_c \pm t_{(1-\alpha/2, n-k-1)} s_{y.12} \sqrt{\frac{1}{n} + c_{11}x'_{1j}{}^2 + c_{22}x'_{2j}{}^2 + 2c_{12}x'_{1j}x'_{2j}} \quad (9.5.3)$$

Para el ejemplo ilustrativo, supóngase que se desea estimar la duración media de la hospitalización para todos los pacientes de 25 años con dos admisiones previas. En otras palabras, dados $x_{1j} = 2$ y $x_{2j} = 25$, ¿cuál es la estimación de la media de las subpoblaciones correspondientes de los valores de Y ? Para obtener una estimación puntual, se sustituyen $x_{1j} = 2$ y $x_{2j} = 25$ en la ecuación 9.3.8:

$$\begin{aligned} y_c &= 2.08 + .06(2) + 1.05(25) \\ &= 28.45 \end{aligned}$$

Para calcular el error estándar, se obtiene primero $x'_{1j} = (x_{1j} - \bar{x}_1) = (2 - 1.93) = .07$ y $x'_{2j} = (x_{2j} - \bar{x}_2) = (25 - 33.40) = -8.40$. Sustituyendo éstos y otros valores apropiados en la expresión 9.5.3, se tiene que

$$\begin{aligned} &28.45 \pm (2.1788)(6.05) \\ &\times \sqrt{\frac{1}{15} + (.1861)(.07)^2 + (.0029001)(-8.40)^2 + 2(-.0213711)(.07)(-8.40)} \\ &28.45 \pm 7.19 \\ &21.26, 35.64 \end{aligned}$$

Este intervalo se interpreta en las formas habituales. Se tiene el 95 por ciento de confianza de que el intervalo de 21.26 a 35.64 incluya la media de la subpoblación de los valores de Y para la combinación especificada de los valores X_i , ya que este parámetro quedaría incluido en aproximadamente el 95 por ciento de los intervalos que pueden construirse en la forma mostrada.

Intervalo de predicción para un valor particular de Y dados valores particulares de las X_i . Cuando y_c se interpreta como el valor más probable que toma Y cuando se observan valores particulares de las X_i , puede construirse un intervalo de predicción de la misma forma en que se construyó el intervalo de confianza. La única diferencia en los dos es el error estándar. El error estándar de la predicción es un poco mayor que el error estándar de la estimación, lo cual hace que el intervalo de predicción sea más amplio que el intervalo de confianza.

El error estándar de la predicción para el caso de tres variables está dado por la expresión

$$s_{y_c|12} = \sqrt{1 + \frac{1}{n} + c_{11}x'_{1j}^2 + c_{22}x'_{2j}^2 + 2c_{12}x'_{1j}x'_{2j}} \quad (9.5.3)$$

de modo que el intervalo de predicción del $100(1 - \alpha)$ por ciento es

$$y_c \pm t_{(1-\alpha/2, n-k-1)} s_{y_c|12} \sqrt{1 + \frac{1}{n} + c_{11}x'_{1j}^2 + c_{22}x'_{2j}^2 + 2c_{12}x'_{1j}x'_{2j}} \quad (9.5.4)$$

Supóngase, para el ejemplo ilustrativo, que se admite un paciente de 25 años con dos admisiones previas. ¿Por cuánto tiempo es probable que quede hospitalizado? La mejor predicción puntual se encuentra al calcular y_c . Es decir,

$$\begin{aligned} y_c &= 2.08 + .06(2) + 1.95(25) \\ &= 28.45 \end{aligned}$$

el mismo valor obtenido anteriormente cuando y_c se interpretó como una estimación puntual de la media de la subpoblación.

Puede obtenerse el siguiente intervalo de predicción del 95 por ciento utilizando la expresión 9.5.4:

$$28.45 \pm (2.1788)(6.05)$$

$$\times \sqrt{1 + \frac{1}{15} + (.1861)(.07)^2 + (.0029001)(-8.40)^2 + 2(-.0213711)(.07)(-8.40)}$$

$$28.45 \pm 15.01$$

$$13.44, 43.46$$

Se tiene el 95 por ciento de confianza de que dicho paciente permanezca hospitalizado entre 13.44 y 43.46 días.

Ejercicios

Para cada uno de los siguientes ejercicios, calcule el valor de y_c y construya *a*) un intervalo de confianza del 95 por ciento y *b*) un intervalo de predicción del 95 por ciento para los valores especificados de las X_i .

9.5.1 Utilice como referencia el ejercicio 9.3.1 y sea $x_{1j} = 5$ y $x_{2j} = 3$.

9.5.2 Utilice como referencia el ejercicio 9.3.2 y sea $x_{1j} = 2$ y $x_{2j} = 20$.

9.5.3 Utilice como referencia el ejercicio 9.3.3 y sea $x_{1j} = 5$ y $x_{2j} = 6$.

9.5.4 Utilice como referencia el ejercicio 9.3.4 y sea $x_{1j} = 1$ y $x_{2j} = 2$.

9.5.5 Utilice como referencia el ejercicio 9.3.5 y sea $x_{1j} = 90$ y $x_{2j} = 80$.

9.6 EL MODELO DE CORRELACIÓN

En el capítulo anterior se señaló que, mientras que el análisis de regresión se refiere a la forma de la relación entre las variables, el objetivo del análisis de correlación es adquirir conocimientos acerca de la intensidad de la relación. Esto ocurre también en el caso de varias variables, y en esta sección se investigan los métodos para medir la intensidad de la relación entre varias variables. Sin embargo, deben definirse primero el modelo y las suposiciones sobre los cuales se basa el análisis.

Puede escribirse el modelo de correlación como

$$y_j = \beta_0 + \beta_1 x_{1j} + \beta_2 x_{2j} + \cdots + \beta_k x_{kj} + e_j \quad (9.6.1)$$

Donde y_j es un valor típico de la población de valores de la variable, Y , los β 's los coeficientes de regresión definidos en la sección 9.2 y

los x_{ij} los valores particulares (conocidos) de las variables aleatorias X_i . Este modelo es semejante al modelo de regresión múltiple, pero existe una diferencia importante entre ellos. En el modelo de regresión múltiple, dado en la ecuación 9.2.1, las X_i son variables no aleatorias, pero en el modelo de correlación múltiple, las X_i son variables aleatorias. En otras palabras, en el modelo de correlación existe una distribución conjunta de Y y las X_i conocida como *distribución multivariada*. En este modelo, las variables ya no se consideran como dependientes o independientes, ya que, lógicamente, son intercambiables y cualquiera de las X_i puede desempeñar la función de Y .

Típicamente, se extraen muestras aleatorias de unidades de asociación de una población de interés y se llevan a efecto mediciones de Y y las X_i .

Un plano o hiperplano de mínimos cuadrados se ajusta a los datos de la muestra a través de los métodos descritos en la sección 9.3 y pueden hacerse los mismos usos de la ecuación resultante. Pueden hacerse inferencias acerca de la población de la cual se extrajo la muestra si puede suponerse que la distribución fundamental es normal, es decir, si puede suponerse que la distribución conjunta de Y y las X_i es una *distribución normal multivariada*. Además, pueden calcularse medias muestrales del grado de relación entre las variables y, con la suposición de que el muestreo se realiza a partir de una distribución de este tipo, pueden estimarse los parámetros correspondientes por medio de intervalos de confianza y pueden llevarse a cabo pruebas de hipótesis. Específicamente, puede calcularse una estimación del *coeficiente de correlación múltiple* que mide la dependencia entre Y y las X_i . Esta es una extensión directa del concepto de correlación entre dos variables que se estudió en el capítulo 8. Pueden calcularse también los *coeficientes de correlación parcial*, que miden la intensidad de la relación entre dos variables cualesquiera cuando se ha eliminado el efecto de todas las demás variables.

Para ilustrar los conceptos y técnicas del análisis de correlación, considérese el siguiente ejemplo.

Ejemplo 9.6.1

Las mediciones que se presentan en la tabla 9.6.1 se hicieron en 11 hombres aparentemente normales con edades entre 14 y 24 años. El investigador que reunió los datos deseaba saber la naturaleza e intensidad de la relación entre las tres variables.

Tabla 9.6.1 Medidas tomadas en 11 hombres aparentemente normales con edades entre 14 y 24 años.

<i>Colesterol en suero</i> <i>mg/100 cc</i> <i>(Y)</i>	<i>Peso en</i> <i>kilogramos</i> <i>(X₁)</i>	<i>Presión sistólica</i> <i>sanguínea</i> <i>(X₂)</i>
162.2	51.0	108
158.0	52.9	111
157.0	56.0	115
155.0	56.5	116
156.0	58.0	117
154.1	60.1	120
169.1	58.0	124
181.0	61.0	127
174.9	59.4	122
180.2	56.1	121
174.0	61.2	125

El coeficiente de correlación múltiple. Como primer paso al analizar las relaciones entre las variables, debe observarse el coeficiente de correlación múltiple.

El coeficiente de correlación múltiple es la raíz cuadrada del coeficiente de determinación y, en consecuencia, el valor muestral puede calcularse sacando la raíz cuadrada de la ecuación 9.4.5. Es decir,

$$R_{y.12\dots k} = \sqrt{R_{y.12\dots k}^2} = \sqrt{\frac{\sum (y_c - \bar{y})^2}{\sum (y_j - \bar{y})^2}} \quad (9.6.2)$$

El numerador del término bajo el radical en la ecuación 9.6.2, que es la suma de cuadrados explicada, está dado por la ecuación 9.4.3 que, como se recordará, contiene a b_1 y b_2 , los coeficientes de regresión parcial de la muestra. Estos se calculan por los métodos de la sección 9.3.

Primero, deben calcularse las diversas sumas, sumas de cuadrados y sumas de productos cruzados. Se procede de la siguiente manera:

$$\begin{array}{lll} \sum x_{1j} = 630.20 & \sum x_{2j} = 1306.00 & \sum y_j = 1821.50 \\ \sum x_{1j}^2 = 36,209.68 & \sum x_{2j}^2 = 155,410.00 & \sum y_j^2 = 302,723.51 \\ \sum x_{1j}x_{2j} = 74,995.80 & \sum x_{1j}y_j = 104,485.19 & \sum x_{2j}y_j = 216,682.00 \end{array}$$

Cuando se calculan las sumas de cuadrados y productos cruzados de

$$y'_j = (y_j - \bar{y}) \quad y \quad x'_{1j} = (x_{1j} - \bar{x}_1) \quad x'_{2j} = (x_{2j} - \bar{x}_2)$$

se tiene que

$$\begin{aligned}\sum x_{1j}^2 &= 36,209.68 - (630.20)^2/11 = 104.95 \\ \sum x_{2j}^2 &= 155,410.00 - (1306.00)^2/11 = 352.18 \\ \sum y_j^2 &= 302,723.51 - (1821.5)^2/11 = 1099.67 \\ \sum x_{1j}x_{2j} &= 74,995.8 - (630.20)(1306.00)/11 = 173.87 \\ \sum x_{1j}y_j &= 104,485.19 - (630.20)(1821.50)/11 = 129.80 \\ \sum x_{2j}y_j &= 216,682.00 - (1306.00)(1821.50)/11 = 420.27\end{aligned}$$

Las ecuaciones normales, por las ecuaciones 9.3.9, son las siguientes

$$\begin{aligned}104.95b_1 + 173.87b_2 &= 129.80 \\ 173.87b_1 + 352.18b_2 &= 420.27\end{aligned}$$

La solución simultánea de estas ecuaciones da $b_1 = -4.06$, $b_2 = 3.20$. b_0 se obtiene sustituyendo los valores apropiados en la ecuación 9.3.11:

$$b_0 = 165.59 - (-4.06)(57.29) - (3.20)(118.73) = 18.25$$

La ecuación de mínimos cuadrados es entonces,

$$y_c = 18.25 - 4.06x_{1j} + 3.20x_{2j}$$

Esta ecuación puede utilizarse con fines de estimación y predicción y puede evaluarse por medio de los métodos descritos en la sección 9.4.

Ahora se tienen las cantidades necesarias para calcular el coeficiente de correlación múltiple. Se calcula primero la suma de cuadrados explicada mediante la ecuación 9.4.3:

$$\begin{aligned}SC_{\text{exp.}} &= (-4.06)(129.80) + (3.20)(420.27) \\ &= 817.876\end{aligned}$$

La suma de cuadrados total por la ecuación 9.4.2 es

$$\begin{aligned}SC_{\text{total}} &= 302,723.51 - (1821.5)^2/11 \\ &= 1,099.669\end{aligned}$$

El coeficiente de determinación múltiple es entonces,

$$R_{y,12}^2 = \frac{817.876}{1099.669} = .7437$$

y el coeficiente de correlación múltiple es

$$R_{y,12} = \sqrt{.7437} = .86$$

$R_{y,12}$ se interpreta como una medida de la correlación entre el nivel de colesterol en suero, el peso y la presión sistólica sanguínea en la muestra de hombres aparentemente normales con edades entre 14 y 24 años. Si los datos constituyen una muestra aleatoria de la población de dichas personas, puede utilizarse $R_{y,12}$ como una estimación de $\rho_{y,12}$, el coeficiente de correlación múltiple verdadero de la población. $R_{y,12}$ puede interpretarse también como el coeficiente de correlación simple entre y_i y y_c , respectivamente, los valores observado y calculado de la variable "dependiente". La correspondencia perfecta entre los valores observados y calculados de Y dará por resultado un coeficiente de correlación de 1, mientras que la falta completa de una relación lineal entre dichos valores da un coeficiente de correlación de 0. El coeficiente de correlación múltiple siempre tiene signo positivo.

Puede probarse la hipótesis nula $\rho_{y,12\dots k} = 0$ al calcular

$$F = \frac{R_{y,12\dots k}^2}{1 - R_{y,12\dots k}^2} \cdot \frac{n - k - 1}{k} \quad (9.6.3)$$

El valor numérico obtenido a partir de la ecuación 9.6.3 se compara con el valor tabulado de F con k y $n - 1$ grados de libertad. El lector recordará que esto es idéntico a la prueba de $H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$ descrita en la sección 9.4.

Para este ejemplo, se probará la hipótesis nula $\rho_{y,12} = 0$ contra la alternativa $\rho_{y,12} \neq 0$. Se calcula

$$F = \frac{.7437}{(1 - .7437)} \cdot \frac{(11 - 2 - 1)}{2} = 11.61$$

Dado que 11.61 es mayor que 11.04, $p < .005$, de modo que puede rechazarse la hipótesis nula al nivel de significación de .005 y concluir

que el nivel de colesterol en suero está linealmente correlacionado con el peso y la presión sistólica sanguínea en la población muestreada.

Pueden encontrarse más comentarios sobre el significado de los coeficientes de correlación múltiple observados en Ezekiel y Fox,⁴ quienes analizan un trabajo sobre el tema escrito por R. A. Fisher⁸ y presentan gráficas para construir intervalos de confianza cuando el número de variables es de ocho o menos. Kramer⁹ presenta tablas para construir límites de confianza cuando el número de variables es mayor de ocho.

Correlación parcial. Es posible que el investigador desee tener una medida de la intensidad de la relación lineal entre dos variables cuando se ha eliminado la influencia de las variables restantes. Dicha medida la proporciona el coeficiente de *correlación parcial*. Por ejemplo, el coeficiente de correlación parcial, $\rho_{y1.2}$, es una medida de la correlación entre Y y X_1 cuando X_2 permanece constante.

Los coeficientes de correlación parcial pueden calcularse a partir de los *coeficientes de correlación simple*. Estos últimos miden la correlación entre dos variables cuando no se ha hecho esfuerzo alguno por controlar otras variables. En otras palabras, son los coeficientes para cualquier par de variables que se obtendrían mediante los métodos de correlación simple tratados en el capítulo 8.

Para tres variables, pueden obtenerse estos coeficientes de correlación simple:

- r_{y1} , la correlación simple entre Y y X_1 ,
- r_{y2} , la correlación simple entre Y y X_2 ,
- r_{12} , la correlación simple entre X_1 y X_2 .

Estos pueden calcularse como sigue:

$$r_{y1} = \sum x'_{1j}y'_j / \sqrt{\sum x'^2_{1j} \sum y'^2_j} \quad (9.6.4)$$

$$r_{y2} = \sum x'_{2j}y'_j / \sqrt{\sum x'^2_{2j} \sum y'^2_j} \quad (9.6.5)$$

$$r_{12} = \sum x'_1x'_{2j} / \sqrt{\sum x'^2_{1j} \sum x'^2_{2j}} \quad (9.6.6)$$

Para el ejemplo ilustrativo, pueden utilizarse las cantidades previamente calculadas para obtener

$$r_{y1} = 129.80/\sqrt{(104.95)(1099.67)} = .382$$

$$r_{y2} = 420.27/\sqrt{(352.18)(1099.67)} = .675$$

$$r_{12} = 173.87/\sqrt{(104.95)(352.18)} = .904$$

Los coeficientes de correlación parcial de la muestra que pueden calcularse en el caso de tres variables son los siguientes

1. La correlación parcial entre Y y X_1 cuando X_2 se mantiene constante:

$$r_{y1.2} = (r_{y1} - r_{y2}r_{12})/\sqrt{(1 - r_{y2}^2)(1 - r_{12}^2)} \quad (9.6.7)$$

2. La correlación parcial entre Y y X_2 cuando X_1 se mantiene constante:

$$r_{y2.1} = (r_{y2} - r_{y1}r_{12})/\sqrt{(1 - r_{y1}^2)(1 - r_{12}^2)} \quad (9.6.8)$$

3. La correlación parcial entre X_1 y X_2 cuando Y se mantiene constante:

$$r_{12.y} = (r_{12} - r_{y1}r_{y2})/\sqrt{(1 - r_{y1}^2)(1 - r_{y2}^2)} \quad (9.6.9)$$

Si se utilizan los coeficientes de correlación simple ya calculados, se obtienen los siguientes coeficientes de correlación parcial para el ejemplo ilustrativo:

$$r_{y1.2} = [.382 - (.675)(.904)]/\sqrt{(1 - .675^2)(1 - .904^2)} = -.723$$

$$r_{y2.1} = [.675 - (.382)(.904)]/\sqrt{(1 - .382^2)(1 - .904^2)} = .834$$

$$r_{12.y} = [.904 - (.382)(.675)]/\sqrt{(1 - .382^2)(1 - .675^2)} = .948$$

Puede probarse la hipótesis nula de que el coeficiente de correlación parcial de la población que corresponde a cualquiera de los anteriores coeficientes es 0 por medio de la prueba t . Por ejemplo, para probar $H_0: \rho_{y1.2 \dots k} = 0$, se calcula

$$t = r_{y1.2 \dots k} \sqrt{\frac{n - k - 1}{1 - r_{y1.2 \dots k}^2}} \quad (9.6.10)$$

que está distribuido como la t de Student con $n - k - 1$ grados de libertad.

A continuación se ilustra el procedimiento para el ejemplo ilustrativo probando $H_0: \rho_{12.y} = 0$ contra la alternativa $H_A: \rho_{12.y} \neq 0$. La t calculada es

$$t = .948 \sqrt{\frac{11 - 2 - 1}{1 - .948^2}}$$

$$= 8.425$$

Dado que la t calculada de 8.425 es mayor que la t tabulada de 3.5554 para 8 grados de libertad y $\alpha = .01$ para una prueba bilateral, puede rechazarse H_0 al nivel de significación de .01 y concluir que existe una correlación significativa entre la presión sistólica sanguínea y el peso cuando el nivel de colesterol en suero se mantiene constante. Las pruebas de significación para los otros coeficientes de correlación parcial se dejarán como ejercicio para el lector.

Aun cuando la situación considerada del análisis de correlación se limita al caso de tres variables, los conceptos y técnicas se aplican lógicamente al caso de cuatro o más variables. El número y complejidad de los cálculos aumentan rápidamente a medida que aumenta el número de variables.

Ejercicios

9.6.1 Se obtuvieron los siguientes datos de 12 varones con edades

<i>Estatura</i> (Y)	<i>Longitud del radio</i> (X_1)	<i>Longitud del fémur</i> (X_2)
149.0	21.00	42.50
152.0	21.79	43.70
155.7	22.40	44.75
159.0	23.00	46.00
163.3	23.70	47.00
166.0	24.30	47.90
169.0	24.92	48.95
172.0	25.50	49.90
174.5	25.80	50.30
176.1	26.01	50.90
176.5	26.15	50.85
179.0	26.30	51.10
Total 1992.1	290.87	573.85

$$\begin{aligned} \sum x_{1j}^2 &= 7087.6731 & \sum x_{2j}^2 &= 27541.8575 & \sum y_j^2 &= 331851.09 \\ \sum x_{1j}x_{2j} &= 13970.5835 & \sum x_{1j}y_j &= 48492.886 & \sum x_{2j}y_j &= 95601.09 \end{aligned}$$

- entre 12 y 18 años (todas las medidas están en centímetros):
- Encuentre el coeficiente de correlación múltiple de la muestra y pruebe la hipótesis nula de que $\rho_{y.12} = 0$
 - Encuentre cada uno de los coeficientes de correlación parcial y pruebe cada uno respecto al nivel de significación. Sea $\alpha = .05$ para todas las pruebas.
 - Determine el valor p para cada prueba.
 - Saque sus conclusiones.

9.6.2 Los siguientes datos se recopilaron de 15 muchachas obesas.

<i>Peso en kilogramos (Y)</i>	<i>Peso del cuerpo delgado (X₁)</i>	<i>Ingestión media diaria de calorías (X₂)</i>
79.2	54.3	2670
64.0	44.3	820
67.0	47.8	1210
78.4	53.9	2678
66.0	47.5	1205
63.0	43.0	815
65.9	47.1	1200
63.1	44.0	1180
73.2	44.1	1850
66.5	48.3	1260
61.9	43.5	1170
72.5	43.3	1852
101.1	66.4	1790
66.2	47.5	1250
99.9	66.1	1789
Total 1087.9	741.1	22739

$$\begin{aligned} \sum x_{1j}^2 &= 37,439.95 & \sum x_{2j}^2 &= 39,161.759 & \sum y_j^2 &= 81,105.63 \\ \sum x_{1j}x_{2j} &= 1,154,225.2 & \sum x_{1j}y_j &= 55,021.31 & \sum x_{2j}y_j &= 1,707,725.3 \end{aligned}$$

- Encuentre el coeficiente de correlación múltiple y pruébelo respecto al nivel de significación.
- Encuentre cada uno de los coeficientes de correlación parcial y pruebe cada uno respecto al nivel de significación. Sea $\alpha = .05$ para todas las pruebas.
- Determine el valor p para cada prueba.
- Saque sus conclusiones.

9.6.3 Utilice como referencia el ejercicio 9.3.5. Suponga que los datos se ajustan al modelo de correlación.

- a) Calcule el coeficiente de correlación múltiple y pruébelo respecto al nivel de significación.
- b) Calcule cada uno de los coeficientes de correlación parcial y pruebe cada uno respecto al nivel de significación. Sea $\alpha = .05$ para todas las pruebas.
- c) Determine el valor p para cada prueba.
- d) ¿Cuáles son sus conclusiones?

9.6.4 Utilice como referencia el ejemplo 9.6.1. Pruebe $r_{y1.2}$ y $r_{y2.1}$ para el nivel de significación de .05. Determine el valor p para cada prueba.

9.7 ELECCIÓN DE VARIABLES INDEPENDIENTES PARA LA ECUACIÓN DE REGRESIÓN MÚLTIPLE

Uno de los problemas más tediosos en el uso del análisis de regresión múltiple es decidir qué variables independientes deben incluirse en la ecuación. En la mayoría de los casos, la decisión final es el resultado de consideraciones tanto estadísticas como no estadísticas.

En las etapas iniciales de la determinación de la ecuación de regresión, el investigador se guiará por lo que sepa respecto a las variables relevantes y las que probablemente serán más útiles para los fines de predicción y estimación. Tomará también en cuenta los costos relativos y la facilidad para obtener las mediciones correspondientes.

En esta era de las computadoras, el volumen y complejidad de los cálculos relacionados con un gran número de variables no plantean el problema que alguna vez provocaron. Aun así, por lo general resulta conveniente (particularmente desde el punto de vista del costo y de la conveniencia para obtener las mediciones) incluir en la ecuación final menos variables independientes de las que se tengan. Es en este punto donde el investigador puede utilizar el análisis estadístico con el fin de que pueda llegar a una decisión. Se pueden seguir varios procedimientos. El método más completo, pero también el más tedioso y tardado incluso con la ayuda de una computadora, es el de realizar la regresión Y sobre todo subconjunto de las X_j , es decir, se realiza la regresión de Y sobre cada X , a continuación sobre cada pareja de X 's,

después sobre cada grupo de tres X 's, y así sucesivamente. La mejor de estas ecuaciones de regresión, de acuerdo con algún criterio estadístico, será la seleccionada, a menos que alguna consideración no estadística, como el costo, necesite un ajuste. Debido a la magnitud de los cálculos, este método no se utiliza con frecuencia.

Un segundo procedimiento, llamado método de ascenso o hacia adelante, consiste en introducir variables independientes, una a la vez, en la regresión y, en cada etapa, evaluar estadísticamente la "bondad" de la ecuación. El procedimiento continúa hasta que, de acuerdo con algún criterio estadístico, se obtiene una ecuación satisfactoria.

Un tercer método, llamado método de descenso o hacia atrás, es lo opuesto al método anterior. Mediante este método, se lleva a cabo la regresión de Y sobre todas las X_i y se eliminan entonces las variables independientes, una a la vez, hasta que se haya obtenido una ecuación satisfactoria.

Para más información acerca de estos y otros métodos para determinar qué variables independientes deben incluirse en el análisis se pueden consultar los libros y artículos escritos por Allen,¹⁰ Beale y colaboradores,¹¹ Draper y Smith,¹² Garside,¹³ Gorman y Toman,¹⁴ Hocking y Leslie,¹⁵ Larson y Bancroft,¹⁶ Lindley,¹⁷ Schultz y Goggans,¹⁸ Smillie,¹⁹ Sprent²⁰ y Summerfield y Lubin.²¹

9.8 RESUMEN

En este capítulo se examina la manera en que los conceptos y técnicas de los análisis de regresión lineal simple y de correlación se aplican al caso de varias variables. Se presenta e ilustra el método de los mínimos cuadrados para obtener la ecuación de regresión. Este capítulo trata también del cálculo de las medidas descriptivas, pruebas de significación y los usos que se hacen de la ecuación de regresión múltiple. Además, se describen los métodos y conceptos del análisis de correlación, incluyendo la correlación parcial. Para quienes deseen ampliar sus conocimientos acerca de los análisis de regresión y correlación múltiples, las referencias que se dan al final del capítulo proporcionan un buen principio.

Cuando no se satisfacen las suposiciones que sirven de fundamento para los métodos de regresión y correlación presentados en este y los anteriores capítulos, el investigador debe utilizar técnicas alternativas. Una alternativa es utilizar un método no paramétrico, como el que describe Daniel.^{22, 23}

Preguntas y ejercicios de repaso

1. ¿Cuáles son las suposiciones que fundamentan el análisis de regresión múltiple cuando se desea inferir acerca de la población de la cual se ha extraído la muestra?
2. ¿Cuáles son las suposiciones que fundamentan el modelo de correlación cuando el objetivo es la inferencia?
3. Explique completamente los siguientes términos:
 - a) Coeficiente de determinación múltiple
 - b) Coeficiente de correlación múltiple
 - c) Coeficiente de correlación simple
 - d) Coeficiente de correlación parcial
4. Describa una situación en su área particular de interés donde sería útil el análisis de regresión múltiple. Utilice datos reales o realistas y lleve a cabo un análisis de regresión completo.
5. Describa una situación en su área particular de interés donde sería útil el análisis de correlación múltiple. Utilice datos reales o realistas y lleve a cabo un análisis de correlación completo.

En los siguientes ejercicios, efectúe el análisis indicado y pruebe las hipótesis a los niveles de significación indicados. Calcule el valor p para cada prueba.

6. La siguiente tabla muestra algunos de los valores de la función pulmonar observados en 10 pacientes hospitalizados.

X_1 <i>Capacidad vital (litros)</i>	X_2 <i>Capacidad pulmonar total (litros)</i>	Y <i>Volumen expiratorio forzado (litros) por segundo</i>
2.2	2.5	1.6
1.5	3.2	1.0
1.6	5.0	1.4
3.4	4.4	2.6
2.0	4.4	1.2
1.9	3.3	1.5
2.2	3.2	1.6
3.3	3.3	2.3
2.4	3.7	2.1
.9	3.6	.7

Calcule el coeficiente de correlación múltiple y pruebe su significación al nivel de .05.

7. La siguiente tabla muestra el peso y los niveles totales de colesterol y triglicéridos en 15 pacientes con hiperlipoproteinemia primaria de tipo II justo antes de iniciarse el tratamiento.

<i>Y</i> <i>Peso (kg)</i>	<i>X</i> ₁ <i>Colesterol total</i> <i>(mg/100 ml)</i>	<i>X</i> ₂ <i>Triglicéridos</i> <i>(mg/100 ml)</i>
76	302	139
97	336	101
83	220	57
52	300	56
70	382	113
67	379	42
75	331	84
78	332	186
70	426	164
99	399	205
75	279	230
78	332	186
70	410	160
77	389	153
76	302	139

Calcule el coeficiente de correlación múltiple y pruebe su significación al nivel de .05.

8. En un estudio de la relación entre la excreción de creatinina, la estatura y el peso, se recopilaron los datos de la siguiente tabla a partir de 20 recién nacidos.

<i>Infante</i>	<i>Excreción de</i> <i>creatinina (mg/día)</i> <i>Y</i>	<i>Peso (kg)</i> <i>X</i> ₁	<i>Estatura (cm)</i> <i>X</i> ₂
1	100	9	72
2	115	10	76
3	52	6	59
4	85	8	68
5	135	10	60
6	58	5	58
7	90	8	70

Infante	Excreción de creatinina (mg/día)	Peso (kg)	Estatura (cm)
	Y	X_1	X_2
8	60	7	65
9	45	4	54
10	125	11	83
11	86	7	64
12	80	7	66
13	65	6	61
14	95	8	66
15	25	5	57
16	125	11	81
17	40	5	59
18	95	9	71
19	70	6	62
20	120	10	75

- a) Encuentre la ecuación de regresión múltiple que describa la relación entre estas variables.
- b) Calcule R^2 y efectúe un análisis de variancia.
- c) Sea $X_1 = 10$ y $X_2 = 60$ y encuentre el valor pronosticado de Y .
9. Se llevó a cabo un estudio para examinar aquellas variables que se pensaba estaban relacionadas con la satisfacción por el trabajo de los empleados no profesionistas de un hospital. Una muestra aleatoria de 15 empleados dio los siguientes resultados:

Calificación obtenida en la prueba de aptitud en el trabajo (Y)	Calificación obtenida por inteligencia (X_1)	Índice de ajuste personal (X_2)
54	15	8
37	13	1
30	15	1
48	15	7
37	10	4
37	14	2
31	8	3
49	12	7
43	1	9
12	3	1
30	15	1
37	14	2

<i>Calificación obtenida en la prueba de aptitud en el trabajo (Y)</i>	<i>Calificación obtenida por inteligencia (X₁)</i>	<i>Índice de ajuste personal (X₂)</i>
61	14	10
31	9	1
31	4	5

- a) Encuentre la ecuación de regresión múltiple que describa la relación que existe entre estas variables.
- b) Calcule el coeficiente de determinación múltiple y efectúe un análisis de variancia.
- c) Sea $X_1 = 10$ y $X_2 = 5$ y encuentre el valor pronosticado de Y .
10. Un grupo de médicos investigadores obtuvo el índice de adiposidad, la insulina basal y los valores de glucosa basal en 21 personas normales. Los resultados se muestran en la siguiente tabla. Los investigadores deseaban estudiar la intensidad de la asociación entre estas variables.

<i>Índice de adiposidad Y</i>	<i>Insulina basal (μU/ml) X₁</i>	<i>Glucosa basal (mg/100 ml) X₂</i>
90	12	98
112	10	103
127	14	101
137	11	102
103	10	90
140	38	108
105	9	100
92	6	101
92	8	92
96	6	91
114	9	95
108	9	95
160	41	117
91	7	101
115	9	86
167	40	106
108	9	84

<i>Indice de adiposidad</i> Y	<i>Insulina basal ($\mu U/ml$)</i> X_1	<i>Glucosa basal ($mg/100ml$)</i> X_2
156	43	117
167	17	99
165	40	104
168	22	85

Calcule el coeficiente de correlación múltiple y pruebe su significación al nivel de .05.

11. Como parte de un estudio para investigar la relación que existe entre el *stress* y varias otras variables, se recopilaron los siguientes datos de una muestra aleatoria simple de quince ejecutivos asociados.

<i>Medida del stress (Y)</i>	<i>Medida de la importancia de la empresa (X_1)</i>	<i>Número de años en la presente posición (X_2)</i>	<i>Salario anual ($\times 1,000$) (X_3)</i>	<i>Edad (X_4)</i>
101	812	15	\$30	38
60	334	8	20	52
10	377	5	20	27
27	303	10	54	36
89	505	13	52	34
60	401	4	27	45
16	177	6	26	50
184	598	9	52	60
34	412	16	34	44
17	127	2	28	39
78	601	8	42	41
141	297	11	84	58
11	205	4	31	51
104	603	5	38	63
76	484	8	41	30

- Encuentre la ecuación de regresión de mínimos cuadrados para estos datos.
- Construya la tabla de análisis de variancia y pruebe la hipótesis nula de no relación entre las cinco variables.
- Pruebe la hipótesis nula de que cada pendiente del modelo de regresión es igual a cero.

- d) Encuentre el coeficiente de determinación múltiple y el coeficiente de correlación múltiple. Sea $\alpha = .05$ y encuentre el valor p para cada prueba.

REFERENCIAS

Referencias citadas

1. George W. Snedecor y William G. Cochran, *Statistical Methods*, sexta edición, The Iowa State University Press, Ames, Iowa, 1967.
2. Robert G. D. Steel y James H. Torrie, *Principles and Procedures of Statistics*, McGraw-Hill, Nueva York, 1960.
3. R. L. Anderson y T. A. Bancroft, *Statistical Theory in Research*, McGraw-Hill, Nueva York, 1952.
4. Mordecai Ezekiel y Karl A. Fox, *Methods of Correlation and Regression Analysis*, tercera edición, Wiley, Nueva York, 1959.
5. M. H. Doolittle, "Method Employed in the Solution of Normal Equation and the Adjustment of a Triangulation," *U.S. Coast and Geodetic Survey Report*, 1878.
6. David Durand, "Joint Confidence Region for Multiple Regression Coefficients," *Journal of the American Statistical Association*, 49 (1954), 130–146.
7. R. C. Geary y C. E. V. Leser, "Significance Tests in Multiple Regression," *The American Statistician*, 22 (febrero, 1968), 20–21.
8. R. A. Fisher, "The General Sampling Distribution of the Multiple Correlation Coefficient," *Proceedings of the Royal Society A*, 121 (1928), 654–673.
9. K. H. Kramer, "Tables for Constructing Confidence Limits on the Multiple Correlation Coefficient," *Journal of the American Statistical Association*, 58 (1963), 1082–1085.
10. David M. Allen, "Mean Square Error of Prediction as a Criterion for Selecting Variables," *Technometrics*, 13 (1971), 469–475.
11. E. M. L. Beale, M. G. Kendall y D. W. Mann, "The Discarding of Variables in Multivariate Analysis," *Biometrika*, 54 (1967), 357–366.
12. N. R. Draper y H. Smith, *Applied Regression Analysis*, segunda edición, Wiley, Nueva York, 1981.
13. M. J. Garside, "The Best Sub-Set in Multiple Regression Analysis," *Applied Statistics*, 14 (1965), 196–200.

14. J. W. Gorman y R. J. Toman, "Selection of Variables for Fitting Equations to Data," *Technometrics*, 8 (1966), 27–52.
15. R. R. Hocking y R. N. Leslie, "Selection of the Best Sub-Set in Regression Analysis," *Technometrics*, 9 (1967), 531–540.
16. H. J. Larson y T. A. Bancroft, "Sequential Model Building for Prediction in Regression Analysis I," *Annals of Mathematical Statistics*, 34 (1963), 462–479.
17. D. V. Lindley, "The Choice of Variables in Multiple Regression," *Journal of the Royal Statistical Society B*, 30 (1968), 31–66.
18. E. F. Schultz, Jr. y J. F. Goggans, "A Systematic Procedure for Determining Potent Independent Variables in Multiple Regression and Discriminant Analysis," *Agri. Exp. Sta. Bull.* 336, Auburn University, 1961.
19. K. W. Smillie, *An Introduction to Regression and Correlation*, Academic Press, Nueva York, 1966.
20. Peter Sprent, *Models in Regression*, Methuen, Londres, 1969.
21. A. Summerfield y A. Lubin, "A Square Root Method of Selecting a Minimum Set of Variables in Multiple Regression: I, The Method," *Psychometrika*, 16 (3): 271 (1951).
22. Wayne W. Daniel, *Applied Nonparametric Statistics*, Houghton Mifflin, Boston, 1978.
23. Wayne W. Daniel, *Nonparametric, Distribution-Free, and Robust Procedures in Regression Analysis: A Selected Bibliography*, Vance Bibliographies, Monticello, Ill., junio, 1980.

Otras referencias, libros

1. Frank Andrews, James Morgan y John Sonquist, *Multiple Classification Analysis*, Ann Arbor, Survey Research Center, 1967.
2. T. W. Anderson, *Introduction to Multivariate Statistical Analysis*, Wiley, Nueva York, 1958.
3. Cuthbert Daniel y Fred S. Wood, *Fitting Equations to Data*, segunda edición, Wiley-Interscience, Nueva York, 1979.
4. Alan E. Treloar, *Correlation Analysis*, Burgess, Minneapolis, 1949.

Otras referencias, artículos de revistas

1. R. G. Newton y D. J. Spurrell, "A Development of Multiple Regression for the Analysis of Routine Data," *Applied Statistics*, 16 (1967), 51–64.

2. Potluri Rao, "Some Notes on Misspecification in Multiple Regression," *The American Statistician*, 25 (diciembre, 1971), 37-39.
3. Neil S. Weiss, "A Graphical Representation of the Relationships Between Multiple Regression and Multiple Correlation," *The American Statistician*, 24 (abril, 1970), 25-29.
4. E. J. Williamis, "The Analysis of Association Among Many Variates," *Journal of the Royal Statistical Society*, 29 (1967), 199-242.

Otras referencias, otras publicaciones

1. R. L. Bottenbery y Y. H. Ward, Jr., *Applied Multiple Linear Regression*, U.S. Department of Commerce, Office of Technical Services, AD 413128, 1963.
2. Wayne W. Daniel, *Ridge Regression: A Selected Bibliography*, Vance Bibliographies, Monticello, 111., octubre, 1980.
3. Wayne W. Daniel, *The Use of Dummy Variables in Regression Analysis: A Selected Bibliography With Annotations*, Vance Bibliographies, Monticello, 111., noviembre, 1979.
4. Wayne W. Daniel, *Outliers in Research Data: A Selected Bibliography*, Vance Bibliographies, Monticello, 111., julio, 1980.
5. Jean Draper, *Interpretation of Multiple Regression Analysis Part I, Problems of Interpreting Large Samples of Data*, The University of Arizona, College of Business and Public Administration, Division of Economics and Business Research, 1968.

10

La distribución ji-cuadrada y el análisis de frecuencias

10.1 INTRODUCCIÓN

En los capítulos que tratan de la estimación y pruebas de hipótesis se menciona brevemente la distribución ji-cuadrada cuando se trata de la obtención de intervalos de confianza para la variancia de una población y de probar la hipótesis acerca de la misma. Esta distribución, que es una de las que se utilizan más en las aplicaciones estadísticas, tiene muchos otros usos. Algunos de los más comunes se presentan en este capítulo junto con un estudio más completo de la propia distribución, que se trata en la sección siguiente.

10.2 PROPIEDADES MATEMÁTICAS DE LA DISTRIBUCIÓN JI-CUADRADA

La distribución ji-cuadrada puede deducirse a partir de distribuciones normales. Supóngase que a partir de una variable aleatoria Y distribuida normalmente con media μ y variancia σ^2 se seleccionan aleatoria e independientemente muestras de tamaño $n = 1$. Cada valor seleccionado puede transformarse en la variable normal unitaria z a través de la ya conocida fórmula:

$$z = \frac{y_i - \mu}{\sigma} \quad (10.2.1)$$

Cada valor de z puede elevarse al cuadrado para obtener z^2 . Cuando se estudia la distribución muestral de z^2 , se encuentra que sigue una distribución ji-cuadrada con un grado de libertad. Es decir,

$$\chi^2_{(1)} = \left(\frac{y - \mu}{\sigma} \right)^2 = z^2$$

Supóngase ahora que se seleccionan aleatoria e independientemente muestras de tamaño $n = 2$ de la población de valores de Y con distribución normal. Dentro de cada muestra, puede transformarse cada valor de y en la variable normal unitaria z y elevarla al cuadrado como antes. Si se suman los valores resultantes de z^2 para cada muestra, puede designarse esta suma por

$$\chi^2_{(2)} = \left(\frac{y_1 - \mu}{\sigma} \right)^2 + \left(\frac{y_2 - \mu}{\sigma} \right)^2 = z_1^2 + z_2^2$$

ya que sigue la distribución ji-cuadrada con dos grados de libertad, el número de términos independientes elevados al cuadrado que se sumaron.

Puede repetirse el procedimiento para cualquier tamaño de muestra n . En cada caso, la suma de los valores z^2 resultantes se distribuirá como una distribución ji-cuadrada, con n grados de libertad. En general, se tiene entonces que

$$\chi^2_{(n)} = z_1^2 + z_2^2 + \cdots + z_n^2 \quad (10.2.2)$$

sigue la distribución χ^2 con n grados de libertad. La forma matemática de la distribución ji-cuadrada es la siguiente:

$$f(u) = \frac{1}{\left(\frac{k}{2} - 1 \right)!} \frac{1}{2^{k/2}} u^{(k/2)-1} e^{-u/2}, \quad u > 0 \quad (10.2.2)$$

donde e es el número irracional 2.71823, ... y k es el número de grados de libertad. La variable u se designa por lo general por la letra griega ji (χ) y, en consecuencia, la distribución se conoce como distribución χ^2 . Como se señaló en el capítulo 5, la distribución χ^2 se ha tabulado en la tabla I. En las siguientes secciones se mencionan otros usos de esta tabla conforme se van necesitando.

La media y la variancia de la distribución χ^2 son, respectivamente, k y $2k$. El valor modal de esta distribución es $k - 2$ para valores de k mayores que o iguales a 2 y es de cero para $k = 1$.

La forma de la distribución χ^2 para varios valores de k se señalan en la figura 5.9.1. En esta figura se observa que las formas para $k = 1$ y $k = 2$ son bastante distintas de la forma general de la distribución para $k > 2$. En esta figura se observa también que χ^2 toma valores entre 0 y el infinito. No puede tomar valores negativos, ya que es la suma de valores que se han elevado al cuadrado.

Una característica final de la distribución χ^2 que vale la pena destacar es que la suma de dos o más variables χ^2 independientes también sigue una distribución χ^2 . En este capítulo se utiliza la distribución χ^2 al probar hipótesis donde los datos disponibles para el análisis están en la forma de frecuencias. Estos procedimientos de prueba de la hipótesis se estudian bajo el encabezado de *pruebas de bondad de ajuste, pruebas de independencia y pruebas de homogeneidad*. Se observará que, en cierto sentido, todas las pruebas χ^2 que se utilizan pueden imaginarse como pruebas de bondad del ajuste con las que se prueba este concepto en las frecuencias observadas con respecto a las frecuencias que se esperarían si los datos se obtuvieran bajo alguna hipótesis o teoría particular. Sin embargo, se reserva la expresión “bondad de ajuste” para utilizarla en un sentido más estricto. Se utiliza esta frase para referirse a la comparación de la distribución de una muestra con alguna distribución teórica que se supone describe la población de la cual provino la muestra. La justificación del uso de la distribución en estos casos se debe a Karl Pearson,¹ quien demostró que puede utilizarse la distribución χ^2 como una prueba de la concordancia entre la observación y la hipótesis siempre que los datos estén en la forma de frecuencias.

Un extenso estudio de la distribución χ^2 se encuentra en el libro escrito por Lancaster.²

10.3 PRUEBAS DE BONDAD DE AJUSTE

Como se ha señalado, resulta apropiada una prueba de bondad de ajuste cuando se desea decidir si una distribución observada de frecuencias es incompatible con alguna distribución preconcebida o establecida en una hipótesis.

Por ejemplo, tal vez sea necesario determinar si una muestra de valores observados de alguna variable aleatoria es compatible o no con la hipótesis de que se extrajo de una población de valores con distribución normal. El procedimiento para llegar a una decisión consiste

en colocar los valores en categorías o intervalos de clase mutuamente excluyentes y observar la frecuencia de ocurrencia de los valores en cada categoría. Puede aplicarse entonces lo que se sabe acerca de las distribuciones normales para determinar las frecuencias que podrían esperarse para cada categoría si la muestra hubiera provenido de una distribución normal. Si la discrepancia entre lo que se observó y lo que era de esperar, dado que el muestreo fue a partir de una distribución normal, es demasiado grande como para ser atribuida al azar, se concluye que la muestra no provino de una distribución normal. Si la discrepancia es de tal magnitud que pudo haberse debido al azar, se concluye que la muestra puede haber provenido de una distribución normal. De manera semejante, pueden llevarse a cabo pruebas de bondad de ajuste en casos donde la distribución planteada en la hipótesis es la de tipo binomial, de Poisson o cualquier otra distribución. A continuación, se ilustra esto con más detalle mediante algunos ejemplos.

Ejemplo 10.3.1 La distribución normal

Supóngase que un grupo de investigadores, que están realizando un estudio de hospitales en los Estados Unidos, reúne datos en una muestra de 250 hospitales, los cuales permiten calcular, para cada uno de los últimos, la razón del tiempo en que los pacientes permanecen internados, una variable que muestra, para un período de 12 meses, la razón del censo diario promedio respecto del número promedio de camas mantenidas. Supóngase que la muestra proporcionó la distribución de razones (expresadas como porcentajes) que se muestran en la tabla 10.3.1.

¿Proporcionan estos datos evidencia suficiente que indique que la muestra no provino de una población con distribución normal? La pregunta sugiere una prueba de la hipótesis nula, H_0 , de que los datos se extrajeron de una población con distribución normal, contra la alternativa, H_A , de que dichos datos no se extrajeron de una población de este tipo.

Dado que no se especifican la media y la variancia de la distribución supuesta en la hipótesis, deben utilizarse los datos de la muestra para estimarlas. Estos parámetros, o sus estimaciones, se necesitarán para calcular la frecuencia que se esperaría en cada intervalo de clase

Tabla 10.3.1 Resultados del estudio descrito en el ejemplo 10.3.1

<i>Razón del tiempo que el paciente permanece internado</i>	<i>Número de hospitales</i>
0.0 a 39.9	16
40.0 a 49.9	18
50.0 a 59.9	22
60.0 a 69.9	51
70.0 a 79.9	62
80.0 a 89.9	55
90.0 a 99.9	22
100.0 a 109.9	4
Total	250

cuando la hipótesis nula es verdadera. La media y la desviación estándar calculadas a partir de los datos agrupados de la tabla 10.3.1 con los métodos de las secciones 1.7 y 1.8 son las siguientes:

$$\bar{x} = 69.91$$

$$s = 19.02$$

Como paso siguiente en el análisis, debe obtenerse, para cada intervalo de clase, la frecuencia de ocurrencia de los valores que se esperarían si la hipótesis nula fuera verdadera, es decir, si, en efecto, la muestra hubiera sido extraída de una población de valores con distribución normal. Para hacerlo, primero se determina la frecuencia relativa esperada de ocurrencia de los valores para cada intervalo de clase y, a continuación, se multiplican estas frecuencias relativas esperadas por el número total de valores para obtener el número de valores esperado para cada intervalo.

Se recordará que, del estudio de la distribución normal, la frecuencia de ocurrencia de los valores iguales a o menores que algún valor especificado, por decir x_0 , de la variable aleatoria X con distribución normal, es igual al área bajo la curva y a la izquierda de x_0 , tal como se representa mediante el área sombreada de la figura 10.3.1. El valor numérico de esta área se obtiene convirtiendo x_0 en una variable normal estándar mediante la fórmula $z_0 = (x_0 - \mu)/\sigma$ y encontrando el valor apropiado en la tabla F. Este procedimiento se




Figura 10.3.1 Distribución normal que muestra la frecuencia relativa de ocurrencia de valores menores que o iguales a x_0 . El área sombreada representa la frecuencia relativa de ocurrencia de valores iguales a o menores que x_0 .

utiliza para obtener las frecuencias relativas esperadas que corresponden a cada uno de los intervalos de clase de la tabla 10.3.1 μ y σ se estiman con $\bar{x}$ y s , tal y como se calculan a partir de los datos agrupados de la muestra. El primer paso consiste en obtener los valores de z correspondientes al límite inferior de cada intervalo de clase. El área entre dos valores de z sucesivos dará la frecuencia relativa esperada de ocurrencia de los valores para el correspondiente intervalo de clase.

Por ejemplo, para obtener la frecuencia relativa esperada de ocurrencia de los valores en el intervalo de 40.0 a 49.9, se procede como sigue:

$$\text{El valor de } z \text{ correspondiente a } X = 40.0 \text{ es } z = \frac{40.0 - 69.91}{19.02} = -1.57$$

$$\text{El valor de } z \text{ correspondiente a } X = 50.0 \text{ es } z = \frac{50.0 - 69.91}{19.02} = -1.05$$

En la tabla F se encuentra que el área a la izquierda de -1.05 es de .1469, y que el área a la izquierda de -1.57 es de .0582. El área entre -1.05 y -1.57 es igual a $.1469 - .0582 = .0887$, que es igual a la frecuencia relativa esperada de ocurrencia de los valores de las razones del tiempo en que el paciente permanece internado dentro del intervalo de 40.0 a 49.9. Esto indica que si la hipótesis nula es verdadera, es decir, si los valores de la razón del tiempo de internado tienen distribución normal, debería esperarse que el 8.9 por ciento de los valores en la muestra estén entre 40.0 y 49.9. Cuando se multiplica el tamaño total de la muestra, 250, por .0887, se encuentra que la frecuencia esperada para el intervalo es de 22.18. Cálculos similares

Tabla 10.3.2 Intervalos de clase y frecuencias esperadas para el ejemplo 10.3.1

Intervalo de clase	$z = (x_i - \bar{x})/S$ en el límite inferior del intervalo	Frecuencia relativa esperada	Frecuencia esperada
<40.0		.0582	14.55
40.0 a 49.9	-1.57	.0887	22.18
50.0 a 59.9	-1.05	.1546	38.65
60.0 a 69.9	-.52	.1985	49.62
70.0 a 79.9	.00	.2019	50.48
80.0 a 89.9	.53	.1535	38.38
90.0 a 99.9	1.06	.0875	21.88
100.0 a 109.9	1.58	.0397	9.92
110.0 y mayores	2.11	.0174	4.35
Total		1.0000	250.00

dan las frecuencias esperadas para los demás intervalos, las que se ilustran en la tabla 10.3.2.

Se tiene interés ahora en examinar las magnitudes de las discrepancias entre las frecuencias observadas y las frecuencias esperadas, ya que se observa que los dos conjuntos de frecuencias no concuerdan. Se sabe que, aun cuando la muestra se extrajera de una población normal de valores, la variabilidad del muestreo por sí sola haría bastante improbable que las frecuencias observadas y esperadas concordaran perfectamente. Surge entonces la pregunta de si las discrepancias entre las frecuencias observadas y esperadas son lo suficientemente pequeñas como para tener la sensación de que es razonable que puedan haber ocurrido únicamente como resultado del azar cuando la hipótesis nula es verdadera. Si son de esta magnitud, uno no se inclinará a rechazar la hipótesis nula de que la muestra provino de una población con distribución normal.

Si las discrepancias son tan grandes que no parece razonable que puedan haberse producido únicamente como resultado del azar, cuando la hipótesis nula es verdadera, será de desearse que se rechace la hipótesis nula. El criterio contra el cual se juzga si las discrepancias son “grandes” o “pequeñas” lo proporciona la distribución χ^2 .

Puede demostrarse que cuando la hipótesis nula es verdadera, la estadística

$$X^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \quad (10.3.1)$$

está distribuida aproximadamente como una χ^2 con $k - r$ grados de libertad.

En la ecuación 10.3.1, O_i se refiere a la i -ésima frecuencia observada y E_i a la i -ésima frecuencia esperada. Al determinar los grados de libertad, k es igual al número de grupos para los cuales se cuenta con frecuencias observadas y esperadas, y r es el número de restricciones impuestas sobre la comparación dada. Se impone una restricción cuando la suma de las frecuencias esperadas se fuerza a ser igual a la suma de las frecuencias observadas, y se impone una restricción adicional para cada parámetro que se estima a partir de la muestra. Para un estudio completo de la justificación teórica de restar un grado de libertad para cada parámetro estimado, véase a Cramer.³

La cantidad $\sum [(O_i - E_i)^2 / E_i]$ será pequeña si las frecuencias observadas y esperadas tienen valores próximos y será grande si las diferencias son grandes.

El valor calculado de X^2 se compara con el valor tabulado de χ^2 con $k - r$ grados de libertad. Si X^2 es mayor que la χ^2 tabulada para cualquier valor de α , puede rechazarse la hipótesis nula al nivel de significación indicado.

A continuación se ilustra el procedimiento con los datos del ejemplo que se está tratando. En la tabla 10.3.3 se muestran las frecuencias observadas y esperadas, junto con cada valor de $(O_i - E_i)^2 / E_i$. El primer valor de la última columna, por ejemplo, se calcula a partir de $(16 - 14.55)^2 / 14.55 = .145$. Los otros valores de $(O_i - E_i)^2 / E_i$ se calculan de manera semejante.

En la tabla 10.3.3 se ve que $X^2 = \sum [(O_i - E_i)^2 / E_i] = 25.854$. Los grados de libertad apropiados son 9 (el número de grupos o intervalos de clase) - 3 (por las tres restricciones: que $\sum E_i = \sum O_i$ y estimar a μ y σ a partir de los datos de la muestra) = 6. Cuando se compara $X^2 = 25.854$ con los valores de χ^2 de la tabla I, se ve que es mayor que $\chi^2_{.995} = 18.548$, de tal manera que puede rechazarse la hipótesis nula de que la muestra provino de una población con distribución normal al nivel de significación de .005. En otras palabras, la probabilidad de obtener un valor de X^2 tan grande como 25.854, cuando la hipótesis nula es verdadera, es menor que 5 en 1000 ($p < .005$). Se dice entonces que tal evento raro no se producirá debido sólo al azar,

Tabla 10.3.3 Frecuencias observada y esperada y $(O_i - E_i)^2/E_i$ para el ejemplo 10.3.1

Intervalo de clase	Frecuencia observada (O_i)	Frecuencia esperada (E_i)	$(O_i - E_i)^2/E_i$
< 40.0	16	14.55	.145
40.0 a 49.9	18	22.18	.788
50.0 a 59.9	22	38.65	7.173
60.0 a 69.9	51	49.62	.038
70.0 a 79.9	62	50.48	2.629
80.0 a 89.9	55	38.38	7.197
90.0 a 99.9	22	21.88	.001
100.0 a 109.9	4	9.92	3.533
110.0 y mayores	0	4.35	4.350
Total	250	250.00	25.854

cuando H_0 es verdadera, por lo que se busca otra explicación. La otra explicación es que la hipótesis nula es falsa.

Algunas veces, los parámetros se especifican en la hipótesis nula. Debe tenerse en cuenta que si se hubieran especificado la media y la variancia de la población como parte de la hipótesis nula, no se hubiera tenido que estimarlas a partir de la muestra y los grados de libertad hubieran sido $9 - 1 = 8$.

Si los parámetros se estiman a partir de datos no agrupados de la muestra en lugar de los datos agrupados como en el ejemplo, es posible que la distribución de X^2 podría no ser lo suficientemente aproximada por la distribución ji-cuadrada para dar resultados satisfactorios. Este problema es analizado por Dahiya y Gurland⁴ y Watson.^{5,6,7} El mismo problema se encuentra cuando se estiman los parámetros independientemente de la muestra, como lo estudia Chase.⁸

Frecuencias esperadas pequeñas. Con frecuencia, en las aplicaciones de la prueba ji-cuadrada, las frecuencias esperadas para una o más categorías serán pequeñas, tal vez mucho menores que 1. En la literatura sobre el tema se señala con frecuencia que la aproximación de X^2 a χ^2 no es estrictamente válida cuando algunas de las frecuencias esperadas son pequeñas. Sin embargo, existe una controversia

entre los autores sobre qué magnitud de las frecuencias esperadas son permisibles antes de hacer algún ajuste o abandonar χ^2 en favor de alguna otra prueba alternativa. Algunos autores, especialmente los primeros que abordaron el tema, sugieren límites inferiores de 10, mientras que otros sugieren que todas las frecuencias esperadas no deben ser menores que 5. Cochran,^{9,10} quien escribió a principios de la década de 1950, sugiere que, para las pruebas de bondad de ajuste de distribuciones unimodales (como la normal), la frecuencia mínima esperada puede ser tan pequeña como 1. Si, en la práctica, se encuentran una o más frecuencias esperadas menores que 1, pueden combinarse categorías adyacentes para lograr el mínimo requerido. La combinación reduce el número de categorías y, por lo tanto, el número de grados de libertad. Tal parece que las sugerencias de Cochran han sido seguidas por casi todos los médicos en los últimos años. Investigaciones más recientes sobre el tema de las frecuencias esperadas pequeñas comprenden las de Roscoe y Byars,¹¹ Yarnold,¹² Tate y Hyer,¹³ Slakter^{14,15} y Lewontin y Felsenstein.¹⁶

Aunque suele encontrarse en la literatura el uso de la ji-cuadrada para probar la normalidad esta no es la prueba más apropiada para utilizarse cuando la distribución planteada en la hipótesis es continua. La prueba de Kolmogorov-Smirnov, descrita en el capítulo 11, fue diseñada especialmente para pruebas de bondad de ajuste que comprenden distribuciones continuas.

Ejemplo 10.3.2 La distribución binomial

En un estudio diseñado para determinar la aceptación por parte de los pacientes a un nuevo analgésico, 100 médicos seleccionaron, cada uno, una muestra de 25 pacientes para participar en el estudio. Cada paciente, después de haber tomado el nuevo analgésico durante un período especificado, fue interrogado para saber si prefería éste o el que había tomado regularmente con anterioridad.

Los resultados del estudio se muestran en la tabla 10.3.4.

Se tiene interés por determinar si estos datos son compatibles o no con la hipótesis de que se extrajeron de una población que sigue una distribución binomial. Una vez más, se utiliza la prueba ji-cuadrada de bondad de ajuste.

Dado que no se especifica el parámetro binomial, p , éste debe estimarse a partir de los datos de la muestra. Un total de 500 pacientes de los 2500 que participaron en el estudio dijeron que preferían

Tabla 10.3.4 Resultados del estudio descrito en el ejemplo 10.3.2

<i>Número de pacientes de 25, que prefieren el nuevo analgésico</i>	<i>Número de doctores que reportaron esta cantidad</i>	<i>Número total de pacientes que prefieren el nuevo analgésico recetado por el doctor</i>
0	5	0
1	6	6
2	8	16
3	10	30
4	10	40
5	15	75
6	17	102
7	10	70
8	10	80
9	9	81
10 ó más	0	0
Total	100	500

el nuevo analgésico, de modo que la estimación puntual de p es $\bar{p} = 500/2500 = .20$. Puede obtenerse la frecuencia relativa esperada evaluando la función binomial

$$f(x) = \binom{25}{x} .2^x .8^{25-x}$$

para $x = 0, 1, \dots, 25$. Por ejemplo, para encontrar la probabilidad de que de una muestra de 25 pacientes ninguno de ellos prefiera el nuevo analgésico cuando, en la población total la proporción verdadera de los que prefieren el nuevo analgésico es de .2, se calcularía.

$$f(0) = \binom{25}{0} .2^0 .8^{25-0}$$

Esto puede hacerse con mayor facilidad consultando la tabla C, donde se observa que $P(X = 0) = .0038$. La frecuencia relativa de ocurrencia de muestras de tamaño 25 en las que ningún paciente prefiera el nuevo analgésico es de .0038. Para obtener la frecuencia esperada correspondiente, se multiplica .0038 por 100 para obtener .38. Cálculos semejantes proporcionan las frecuencias esperadas restantes

Tabla 10.3.5 Cálculos para el ejemplo 10.3.2

<i>Cantidad de pacientes, de 25, que prefieren el nuevo analgésico</i>	<i>Cantidad de doctores que reportaron este número (Frecuencia observada, O_i)</i>	<i>Frecuencia relativa esperada</i>	<i>Frecuencia esperada, E_i</i>
0	5	.0038	.38
1	6	.0236	2.36
2	8	.0708	7.08
3	10	.1358	13.58
4	10	.1867	18.67
5	15	.1960	19.60
6	17	.1633	16.33
7	10	.1109	11.09
8	10	.0623	6.23
9	9	.0295	2.95
10 ó más	0	.0173	1.73
Total	100	1.0000	100.00

que, junto con las frecuencias esperadas, se muestran en la tabla 10.3.5. En esta tabla se observa que la primera frecuencia esperada es menor que 1, de modo que se sigue la sugerencia de Cochran y se combina este grupo con el segundo. Cuando se hace esto, todas las frecuencias esperadas son mayores que 1.

A partir de los datos, se calcula

$$X^2 = \frac{(11 - 2.74)^2}{2.74} + \frac{(8 - 7.08)^2}{7.08} + \cdots + \frac{(0 - 1.73)^2}{1.73} = 47.624$$

Los grados de libertad apropiados son 10 (el número de grupos que quedan después de combinar los dos primeros) menos 2 u 8. Se pierde un grado de libertad porque el total de las frecuencias esperadas se fuerza a ser igual a las frecuencias totales observadas y se sacrifica un grado de libertad porque se estima p a partir de los datos de la muestra.

Se compara la X^2 calculada con la χ^2 tabulada con 8 grados de libertad y se encuentra que es significativa al nivel de significación de .005. Se rechaza la hipótesis nula de que los datos provinieron de una distribución binomial.

Tabla 10.3.6 Cantidad de admisiones de emergencia a un hospital durante un período de 90 días

<i>Día</i>	<i>Admisiones de emergencia</i>	<i>Día</i>	<i>Admisiones de emergencia</i>	<i>Día</i>	<i>Admisiones de emergencia</i>	<i>Día</i>	<i>Admisiones de emergencia</i>
1.	2	24.	5	47.	4	70.	3
2.	3	25.	3	48.	2	71.	5
3.	4	26.	2	49.	2	72.	4
4.	5	27.	4	50.	3	73.	1
5.	3	28.	4	51.	4	74.	1
6.	2	29.	3	52.	2	75.	6
7.	3	30.	5	53.	3	76.	3
8.	0	31.	1	54.	1	77.	3
9.	1	32.	3	55.	2	78.	5
10.	0	33.	2	56.	3	79.	2
11.	1	34.	4	57.	2	80.	1
12.	0	35.	2	58.	5	81.	7
13.	6	36.	5	59.	2	82.	7
14.	4	37.	0	60.	7	83.	1
15.	4	38.	6	61.	8	84.	5
16.	4	39.	4	62.	3	85.	1
17.	3	40.	4	63.	1	86.	4
18.	4	41.	5	64.	3	87.	4
19.	3	42.	1	65.	1	88.	9
20.	3	43.	3	66.	0	89.	2
21.	3	44.	1	67.	3	90.	3
22.	4	45.	2	68.	2		
23.	3	46.	3	69.	1		

Ejemplo 10.3.3 La distribución de Poisson

El administrador de un hospital desea probar la hipótesis nula de que las admisiones de emergencia siguen una distribución de Poisson con $\lambda = 3$. Supóngase que durante un período de 90 días, el número de admisiones de emergencia fue como se señala en la tabla 10.3.6.

Los datos de la tabla 10.3.6 se resumen en la tabla 10.3.7.

Para obtener las frecuencias esperadas, se obtienen primero las frecuencias relativas esperadas al calcular la función de Poisson dada por la ecuación 3.4.1 para cada valor de la columna de la izquierda de la tabla 10.3.7. Por ejemplo, la primera frecuencia relativa esperada se obtiene al calcular

$$f(0) = \frac{e^{-3}3^0}{0!}$$

Tabla 10.3.7 Resumen de los datos presentados en la tabla 10.3.6

<i>Cantidad de admisiones de emergencia en un día</i>	<i>Cantidad de días en que se presentó esta cantidad de admisiones de emergencia</i>
0	5
1	14
2	15
3	23
4	16
5	9
6	3
7	3
8	1
9	1
10 ó más	0
Total	90

Tabla 10.3.8 Frecuencias observada y esperada y elementos de X^2 para el ejemplo 10.3.3

<i>Cantidad de admisiones de emergencia</i>	<i>Número de días en que ocurrió esta cantidad, O_i</i>	<i>Frecuencia relativa esperada</i>	<i>Frecuencia esperada</i>	$\frac{(O_i - E_i)^2}{E_i}$
0	5	.050	4.50	.056
1	14	.149	13.41	.026
2	15	.224	20.16	1.321
3	23	.224	20.16	.400
4	16	.168	15.12	.051
5	9	.101	9.09	.001
6	3	.050	4.50	.500
7	3	.022	1.98	.525
8	1	.008	.72	1.08
9	1	.003	.27	
10 ó más	0	.001	.09	
Total	90	1.000	90.00	3.664

Puede utilizarse la tabla E del apéndice para encontrar ésta y todas las demás frecuencias relativas esperadas necesarias. Cada una de las frecuencias relativas esperadas se multiplica por 90 para obtener las frecuencias esperadas correspondientes. Estos valores, junto con las frecuencias observadas y esperadas y los componentes de X^2 , $(O_i - E_i)^2/E_i$, se muestran en la tabla 10.3.8.

En la tabla 10.3.8 se observa que

$$X^2 = \sum \frac{(O_i - E_i)^2}{E_i} = \frac{(5 - 4.50)^2}{4.50} + \cdots + \frac{(2 - 1.08)^2}{1.08} = 3.664$$

Se observa también que las tres últimas frecuencias esperadas son menores que 1, de tal manera que deben combinarse para evitar tener frecuencias esperadas menores que 1. Esto significa que se tienen sólo nueve categorías eficaces para calcular los grados de libertad. Dado que se especificó el parámetro, λ , en la hipótesis nula, no se pierde un grado de libertad por razones de estimación, de modo que los grados de libertad apropiados son $9 - 1 = 8$. Al consultar la tabla I del apéndice, se encuentra que el valor crítico de χ^2 para 8 grados de libertad y $\alpha = .05$ es de 15.507, de manera que no puede rechazarse la hipótesis nula al nivel de significación de .05 o cualquier otro nivel de significación razonable ($p > .10$). Se concluye, por lo tanto, que las admisiones de emergencia en este hospital pueden seguir una distribución de Poisson con $\lambda = 3$. Al menos, los datos observados no arrojan duda alguna sobre dicha hipótesis.

Ejercicios

10.3.1 La siguiente tabla muestra la distribución de las determinaciones de ácido úrico en 250 pacientes. Pruebe la bondad de ajuste de estos datos a una distribución normal con $\mu = 5.74$ y $\sigma = 2.01$. Sea $\alpha = .01$

Determinación del ácido úrico	Frecuencia observada
< 1	1
1 a 1.99	5
2 a 2.99	15
3 a 3.99	24
4 a 4.99	43
5 a 5.99	50

Determinación del ácido úrico	Frecuencia observada
6 a 6.99	45
7 a 7.99	30
8 a 8.99	22
9 a 9.99	10
10 ó más	5
Total	250

- 10.3.2 Se reunieron los siguientes datos de 300 niñas de ocho años de edad. Pruebe, al nivel de significación de .05, la hipótesis nula de que los datos se extrajeron de una población con distribución normal. Utilice los métodos del capítulo 1 para calcular la media y desviación estándar de la muestra a partir de los datos agrupados.

Estatura en centímetros	Frecuencia observada
114 a 115.9	5
116 a 117.9	10
118 a 119.9	14
120 a 121.9	21
122 a 123.9	30
124 a 125.9	40
126 a 127.9	45
128 a 129.9	43
130 a 131.9	42
132 a 133.9	30
134 a 135.9	11
136 a 137.9	5
138 a 139.9	4
	300

- 10.3.3 La carátula de los expedientes de pacientes internados en un departamento de salud local contiene 10 datos. Una muestra de 100 expedientes reveló la siguiente distribución de datos erróneos.

Datos erróneos por cada 10	Número de expedientes
0	8
1	25
2	32
3	24
4	10
5 ó más	1
100	

Prueba la bondad de ajuste de estos datos a una distribución binomial con $p = .20$. Encuentre el valor p para esta prueba.

- 10.3.4 Durante los últimos 10 años, la siguiente distribución de accidentes fue observada por el médico encargado de la clínica de empleados de una gran empresa industrial.

Accidentes por mes	Cantidad de meses en que se presentaron dichos accidentes
0	2
1	10
2	15
3	30
4	28
5	15
6	10
7	6
8	2
9	1
10 o más	1
120	

¿Son compatibles estos datos con la hipótesis de que los accidentes en esta empresa siguen una distribución de Poisson con $\lambda = 4$? ¿Cuál es el valor p para esta prueba?

- 10.3.5 Los siguientes datos son las cantidades de un organismo particular que se han encontrado en 100 muestras de agua tomadas de un estanque.

Número de organismos por muestra	Frecuencias
0	15
1	30
2	25
3	20
4	5
5	4
6	1
7	0
100	

Pruebe la hipótesis nula de que estos datos fueron extraídos de una distribución de Poisson. Determine el valor p para esta prueba.

10.4 PRUEBAS DE INDEPENDENCIA

Otro uso, y quizá el más frecuente, de la distribución ji-cuadrada es probar la hipótesis nula de que dos criterios de clasificación, cuando se aplican al mismo conjunto de entidades, son independientes. Se dice que dos criterios de clasificación son independientes si la distribución de uno es la misma, sin importar cuál sea la distribución del otro. Por ejemplo, si el estado socioeconómico y área de residencia de los habitantes de cierta ciudad son independientes, se esperaría encontrar la misma proporción de familias en los grupos socioeconómicos bajo, medio y alto en todas las áreas de la ciudad.

La clasificación de un conjunto de entidades, de acuerdo con dos criterios, por decir personas, puede mostrarse mediante una tabla en la que los r renglones representan los diversos niveles de uno de los criterios de clasificación y las c columnas representan los diversos niveles del segundo criterio. Dicha tabla se conoce generalmente como *tabla de contingencia*. En la tabla 10.4.1 se muestra la clasifi-

Tabla 10.4.1 Clasificación con dos criterios de una población finita de entidades

Nivel del segundo criterio de clasificación	Nivel del primer criterio de clasificación					Total
	1	2	3	...	c	
1	N_{11}	N_{12}	N_{13}	...	N_{1c}	$N_{1.}$
2	N_{21}	N_{22}	N_{23}	...	N_{2c}	$N_{2.}$
3	N_{31}	N_{32}	N_{33}	...	N_{3c}	$N_{3.}$
...	...	...	...	...	...	...
r	N_{r1}	N_{r2}	N_{r3}	...	N_{rc}	$N_{r.}$
Total	$N_{.1}$	$N_{.2}$	$N_{.3}$	...	$N_{.c}$	N

cación de una población finita de entidades de acuerdo con dos criterios.

Se tiene interés en probar la hipótesis nula de que, en la población, los dos criterios de clasificación son independientes. Si se rechaza la hipótesis, se concluirá que los dos criterios de clasificación no son independientes. Se extraerá una muestra de tamaño n de la población de sucesos y, en una tabla como la 10.4.2, se presentarán la frecuencia de ocurrencia de los sucesos en la muestra correspondiente a las celdas formadas por las intersecciones de los renglones y columnas de la tabla 10.4.1, junto con los totales marginales.

Tabla 10.4.2 Clasificación con dos criterios de una muestra de entidades

Nivel del segundo criterio de clasificación	Nivel del primer criterio de clasificación					Total
	1	2	3	...	c	
1	n_{11}	n_{12}	n_{13}	...	n_{1c}	$n_{1.}$
2	n_{21}	n_{22}	n_{23}	...	n_{2c}	$n_{2.}$
3	n_{31}	n_{32}	n_{33}	...	n_{3c}	$n_{3.}$
...	...	...	...	...	...	...
r	n_{r1}	n_{r2}	n_{r3}	...	n_{rc}	$n_{r.}$
Total	$n_{.1}$	$n_{.2}$	$n_{.3}$	...	$n_{.c}$	n

Para cada celda, se calculan las frecuencias esperadas bajo la hipótesis nula de que los dos criterios de clasificación son independientes. Se comparan las frecuencias esperadas y observadas. Si la discrepancia es “pequeña”, puede mantenerse la hipótesis nula. Si la discrepancia es “grande”, se rechaza la hipótesis nula y se concluye que los dos criterios de clasificación no son independientes. La decisión de si la discrepancia entre las frecuencias observadas y esperadas es “grande” o “pequeña” se tomará en base a la magnitud de la cantidad calculada cuando se utiliza la ecuación 10.3.1, donde O_i y E_i se refieren respectivamente a las frecuencias observadas y esperadas de las celdas de la tabla 10.4.2. Sería más lógico designar a las frecuencias observadas y esperadas en estas celdas como O_{ij} y E_{ij} , pero para conservar sencilla la notación y evitar introducir otra fórmula, se ha elegido utilizar la notación más sencilla. Resultará útil pensar en las celdas como si estuvieran numeradas desde 1 hasta k , donde 1 se refiere a la celda 11 y k a la celda rc . Puede demostrarse que la X^2 definida de esta forma está distribuida aproximadamente como una χ^2 con $(r-1)(c-1)$ grados de libertad cuando la hipótesis nula es verdadera. Si el valor calculado de X^2 es mayor que el valor tabulado de χ^2 para algún α , se rechaza la hipótesis nula al nivel de significación α . El procedimiento se ilustra con el ejemplo siguiente.

Ejemplo 10.4.1

Un grupo de investigadores, estudiando la relación entre el tipo sanguíneo y la severidad de cierta afección en una población, reunió datos sobre 1500 personas, que se presentan en la tabla de contingencia que se ilustra en la tabla 10.4.3.

Tabla 10.4.3 Mil quinientas personas clasificadas por el grado de la afección y el tipo sanguíneo

Grado de la afección	Tipo sanguíneo				Total
	A	B	AB	O	
Ninguno	543	211	90	476	1320
Moderado	44	22	8	31	105
Severo	28	9	7	31	75
Total	615	242	105	538	1500

Los investigadores deseaban saber si estos datos eran compatibles con la hipótesis de que el grado de la afección y el tipo sanguíneo son independientes. El primer paso en el análisis es obtener la frecuencia para cada celda que se esperaría si, en efecto, los dos criterios de clasificación fueran independientes. Puede empezarse por calcular estimaciones de las diversas probabilidades marginales a partir de los totales marginales que se muestran en la tabla 10.4.3. La estimación de la probabilidad de que una persona seleccionada al azar, de la población de la cual se extrajo la muestra, no tenga la afección es de $1320/1500 = .88$; la probabilidad de que una persona seleccionada al azar tenga una forma moderada de la afección se estima que es de $105/1500 = .07$; y la probabilidad de que una persona seleccionada al azar tenga una forma severa de la afección se estima que es de $75/1500 = .05$. Asimismo, se estiman las probabilidades de que una persona seleccionada al azar de la población bajo estudio tenga sangre tipo A, B, AB y O como $615/1500 = .41$, $242/1500 = .16$, $105/1500 = .07$, y $538/1500 = .36$, respectivamente.

En el capítulo 2 se aprendió que (véase la ecuación 2.6.4), si dos eventos son independientes, la probabilidad de que ocurran conjuntamente es igual al producto de sus probabilidades individuales. Bajo la hipótesis nula de que el tipo sanguíneo y la severidad de la afección son independientes, se calcularía entonces la probabilidad estimada de que una persona seleccionada al azar no tenga, por ejemplo, la afección y tenga sangre tipo A como sigue:

$P(\text{sin la afección} \cap \text{sangre tipo A}) = P(\text{sin la afección}) \times P(\text{sangre tipo A})$

$$= \frac{1320}{1500} \cdot \frac{615}{1500} \\ = .3608$$

La probabilidad que acaba de calcularse es la estimación de la probabilidad de que una persona seleccionada al azar caiga en la primera celda de la tabla 10.4.3 cuando la hipótesis nula es verdadera. La estimación de la probabilidad de que una persona seleccionada al azar no tenga la afección y tenga sangre tipo B es de

$$\frac{1320}{1500} \cdot \frac{242}{1500} = .141973$$

Las probabilidades asociadas con cada una de las celdas restantes se calculan de igual forma.

Después de calcular las proabilidades estimadas asociadas con cada celda, pueden obtenerse las frecuencias esperadas correspondientes multiplicando la probabilidad de cada celda por 1500, el tamaño total de la muestra. Por ejemplo, la frecuencia esperada para la primera celda es de $(.3608)(1500) = 541.2$ y el número esperado de personas, de las 1500, que no tengan la afección y tengan sangre tipo B es de $(.141973)(1500) = 212.96$.

Al calcular las frecuencias esperadas, puede aplicarse una simplificación que ahorra bastante tiempo. Nótese que la frecuencia esperada para la primera celda puede expresarse como

$$P(\text{sin la afección} \cap \text{sangre tipo A})(1500) = \frac{1320}{1500} \cdot \frac{615}{1500} \cdot 1500$$

Uno de los denominadores 1500 se simplifica con el 1500 del numerador, quedando

$$\frac{(1320)(615)}{1500} = 541.20$$

Esto conduce al procedimiento simplificado de obtener las frecuencias esperadas de las celdas, dividiendo el producto de los totales marginales correspondientes entre el tamaño total de la muestra. Como otro ejemplo, nótese que el número esperado de personas, de las 1500, que no tienen la afección y tienen sangre tipo B es de $(242)(1320)/1500 = 212.96$. Las frecuencias observadas y esperadas para el ejemplo ilustrativo se muestran en la tabla 10.4.4, donde las frecuencias esperadas están entre paréntesis.

Tabla 10.4.4 Frecuencias observada y esperada para el ejemplo 10.4.1

Grado de la afección	Tipo sanguíneo				Total
	A	B	AB	O	
Ninguno	543(541.2)	211(212.96)	90(92.40)	476(473.44)	1320
Moderado	44(43.05)	22(16.94)	8(7.35)	31(37.66)	105
Severo	28(30.75)	9(12.10)	7(5.25)	31(26.90)	75
Total	615	242	105	538	1500

A partir de las frecuencias observadas y esperadas, puede calcularse que

$$\begin{aligned} X^2 &= \sum \frac{(O_i - E_i)^2}{E_i} \\ &= \frac{(543 - 541.2)^2}{541.2} + \frac{(211 - 212.96)^2}{212.96} + \cdots + \frac{(31 - 26.90)^2}{26.90} \\ &= .005987 + .018039 + \cdots + .624907 \\ &= 5.12 \end{aligned}$$

El valor calculado de $X^2 = 5.12$ se compara con los valores tabulados de χ^2 con 6 grados de libertad. Se observa que la X^2 calculada no es significativa en cualquier nivel razonable. Por ejemplo, el valor crítico de χ^2 para $\alpha = .10$ y 6 grados de libertad es de 10.645. Se concluye, entonces, que estos datos son compatibles con la hipótesis de que el grado de la afección y el tipo sanguíneo son independientes. Al menos estos datos, debido a la íntima concordancia entre las frecuencias observadas y esperadas, no proporcionan evidencia suficiente que indique una falta de independencia entre los dos criterios de clasificación.

Los grados de libertad se determinan multiplicando el número de renglones, r , menos 1, por el número de columnas, c , menos 1. Es decir, $(r - 1) \times (c - 1) = (3 - 1)(4 - 1) = 6$. El estudiante notará que el número de grados de libertad es igual al número de celdas de frecuencias de la tabla 10.4.1 que podrían llenarse arbitrariamente mientras se mantengan los totales marginales observados. Por ejemplo, dado que 1320 personas no tienen la afección y que 543 de éstos tienen sangre tipo A, 211 tienen sangre tipo B y 90 sangre tipo AB, deben tenerse 476 con sangre tipo O. Esto hace 3 grados de libertad. Aplicando la misma lógica al segundo renglón, se encuentra que sólo pueden llenarse arbitrariamente tres celdas, lo que da tres grados de libertad más. Cuando se intenta llenar las celdas del tercer renglón, se encuentra que estas frecuencias están ya determinadas por las frecuencias de los dos primeros renglones y, por lo tanto, el total de grados de libertad es de 6.

Puede encontrarse el problema de las frecuencias esperadas pequeñas que se estudió en la sección anterior cuando se analizan los datos de las tablas de contingencia. Aunque existe una falta de consenso en la forma de manejar este problema, muchos autores siguen actualmente la regla de Cochran.¹⁰ Este sugiere que, para tablas de contin-

gencia con más de 1 grado de libertad, puede permitirse una esperanza mínima de 1 si no más del 20 por ciento de las celdas tienen frecuencias esperadas de menos de 5. Para satisfacer esta regla, pueden combinarse renglones y columnas adyacentes cuando, al hacerlo, resulta lógico a la luz de otras consideraciones. Si X^2 está basada en menos de 30 grados de libertad, no pueden tolerarse frecuencias esperadas tan pequeñas como 2. En el ejemplo 10.4.1 no se tuvo la experiencia del problema de las frecuencias esperadas pequeñas, ya que todas ellas fueron mayores que 5.

La tabla de contingencia de 2×2 . A veces, cada uno de los dos criterios de clasificación puede dividirse en sólo dos categorías, o niveles. Cuando los datos se clasifican cruzados de esta manera, el resultado es una tabla de contingencia que consta de dos renglones y dos columnas. Dicha tabla suele conocerse como tabla de 2×2 . Cuando se aplica la regla $(r - 1)(c - 1)$ para encontrar los grados de libertad, a una tabla de 2×2 , el resultado es 1 grado de libertad. A continuación se ilustra esto con un ejemplo.

Ejemplo 10.4.2

Una muestra de 500 niños de una cierta escuela primaria, se clasificó en forma cruzada respecto a su estado de nutrición y desempeño académico. Los resultados se muestran en la tabla 10.4.5.

Los investigadores deseaban saber si podrían concluir que existe una relación entre el estado de nutrición y el desempeño académico. Una prueba ji-cuadrada resulta apropiada para llegar a una decisión. Puede calcularse el valor de X^2 calculando primero las frecuencias

Tabla 10.4.5 Estado de nutrición y desempeño académico de 500 niños de escuela primaria

<i>Desempeño académico</i>	<i>Estado de nutrición</i>		<i>Total</i>
	<i>Pobre</i>	<i>Bueno</i>	
Malo	105	15	120
Satisfactorio	80	300	380
Total	185	315	500