

Tabla 10.4.6 Tabla de contingencia de 2×2

Segundo criterio de clasificación	Primer criterio de clasificación		
	1	2	Total
1	a	b	$a + b$
2	c	d	$c + d$
Total	$a + c$	$b + d$	n

esperadas de las celdas en la forma que se estudió con anterioridad. Sin embargo, en el caso de una tabla de contingencia de 2×2 , X^2 puede calcularse mediante la siguiente fórmula simplificada:

$$X^2 = \frac{n(ad - bc)^2}{(a + c)(b + d)(a + b)(c + d)} \quad (10.4.1)$$

donde a , b , c y d son las frecuencias observadas de las celdas, como se muestra en la tabla 10.4.6. Para el ejemplo ilustrativo, se tiene que

$$\begin{aligned} X^2 &= \frac{500[(105)(300) - (15)(80)]^2}{(185)(315)(120)(380)} \\ &= 172.746 \end{aligned}$$

Cuando se compara el valor calculado de X^2 con los valores tabulados de χ^2 con 1 grado de libertad, se encuentra que la probabilidad de obtener un valor de X^2 tan grande o mayor que 172.746, cuando H_0 es verdadera, es menor que .005. El investigador puede concluir entonces que existe una relación entre las dos características bajo estudio.

En el análisis de tablas de contingencia de 2×2 , pueden surgir los problemas de cómo manejar las frecuencias esperadas pequeñas y los tamaños totales de muestras pequeñas. Cochran⁵ sugiere que no debe utilizarse la prueba χ^2 si $n < 20$ ó si $20 < n < 40$ y si cualquier frecuencia esperada es menor que 5. Cuando $n \geq 40$, puede tolerarse una frecuencia esperada de las celdas tan pequeña como 1.

Corrección de Yates. Las frecuencias observadas en una tabla de contingencia son discretas y, de este modo, dan lugar a una estadística

discreta, X^2 , que es aproximada por la distribución χ^2 , que es continua. Yates,¹⁷ en 1934, propuso un procedimiento para corregir esto en el caso de tablas de 2×2 . La corrección consiste en restar la mitad del número total de observaciones del valor absoluto de la cantidad $ad - bc$ antes de elevar al cuadrado. Es decir,

$$X^2_{\text{ corregida}} = \frac{n(|ad - bc| - .5n)^2}{(a + c)(b + d)(a + b)(c + d)} \quad (10.4.2)$$

En general, se ha convenido en que no se necesita corrección alguna para tablas de contingencia más grandes. Aunque la corrección de Yates se había utilizado ampliamente en el caso de tablas de 2×2 , los investigadores actuales, véase, por ejemplo, a Grizzle,¹⁸ Lancaster,¹⁹ Pearson²⁰ y Plackett²¹ han cuestionado su uso. El trabajo de Grizzle, en particular, ha reforzado el caso contra el uso de esta corrección, basándose en que, con demasiada frecuencia, conduce a una prueba demasiado conservadora; es decir, el uso de la corrección conduce con demasiada frecuencia al no rechazo de la hipótesis nula. Como resultado, algunos médicos están en contra de su uso. Aparentemente, esta es una recomendación que es razonable aceptar.

Como algo interesante, puede aplicarse la corrección de Yates al ejemplo en cuestión. Utilizando la ecuación 10.4.2 y los datos de la tabla 10.4.5, puede calcularse lo siguiente:

$$\begin{aligned} X^2_{\text{ corregida}} &= \frac{500 [105(300) - (15)(80)] - (.5)(500)]^2}{(185)(315)(120)(380)} \\ &= 169.907 \end{aligned}$$

Como podría esperarse, con una muestra de este tamaño, la diferencia entre los dos resultados no es considerable.

Las características de una prueba ji-cuadrada de independencia que la distingue de otras pruebas ji-cuadrada son las siguientes:

1. En general, se selecciona una sola muestra de una población de interés y las personas u objetos se clasifican en forma cruzada en base a las dos variables de interés.
2. El objetivo de calcular las frecuencias esperadas de las celdas está basado en la ley de probabilidad que establece que si dos eventos (aquí, los dos criterios de clasificación) son independientes, la probabilidad de que ocurran conjuntamente es igual al producto de sus probabilidades individuales.

3. Las hipótesis y conclusiones se establecen en términos de la independencia (o falta de ella) de las dos variables.

Ejercicios

En los siguientes ejercicios, lleve a cabo la prueba al nivel de significación indicado y determine el valor p .

- 10.4.1 Se clasificó en forma cruzada una muestra de 250 médicos en base a su especialidad y a la zona de la comunidad en que estaban trabajando. Los resultados fueron los siguientes:

Zona de la comunidad	Especialidad				Total
	A	B	C	D	
Norte	20	18	12	17	67
Sur	6	22	15	13	56
Este	4	6	14	11	35
Oeste	10	19	23	40	92
Total	40	65	64	81	250

¿Proporcionan estos datos la evidencia suficiente que indique una falta de independencia entre los dos criterios de clasificación? Sea $\alpha = .01$.

- 10.4.2 Quinientos empleados de una empresa que fabrica cierto producto, que se suponía estaba asociado con alteraciones respiratorias, se clasificaron en forma cruzada en base a su nivel de exposición al producto y si tenían o no los síntomas de tales alteraciones respiratorias. Los resultados se presentan en la siguiente tabla.

Presencia de síntomas	Nivel de exposición			Total
	Alto	limitado	Sin exposición conocida	
Sí	185	33	17	235
No	120	73	72	265
Total	305	106	89	500

¿Proporcionan estos datos la evidencia suficiente que indique, al nivel de significación de .01, una relación entre el nivel de exposición y la presencia de los síntomas de las alteraciones respiratorias?

- 10.4.3 Quinientos niños de escuela primaria se clasificaron en forma cruzada de acuerdo con el grupo socioeconómico y la presencia o ausencia de cierto defecto en la pronunciación. Los resultados fueron los siguientes.

Defecto en la pronunciación	Grupo socioeconómico				Total
	Superior	Medio superior	Medio inferior	Inferior	
Presente	8	24	32	27	91
Ausente	42	121	138	108	409
Total	50	145	170	135	500

¿Son compatibles estos datos con la hipótesis de que el defecto en la pronunciación no está relacionado con el estado socioeconómico?

- 10.4.4 A un grupo de 350 adultos, quienes participaron en una encuesta de salud, se les preguntó si llevaban o no una dieta. Las respuestas por sexos fueron las siguientes.

	Sexo		Total
	Masculino	Femenino	
A dieta	14	25	39
Sin dieta	159	152	311
Total	173	177	350

¿Sugieren estos datos que el estar a dieta depende del sexo? Sea $\alpha = .05$.

- 10.4.5 Una muestra de 500 estudiantes de bachillerato participó en un estudio diseñado con el fin de evaluar el grado de conocimiento respecto a un cierto grupo de enfermedades comunes de los estudiantes de este nivel. La tabla siguiente indica los estudiantes clasificados de acuerdo a su principal campo de estudio y al nivel de conocimiento del grupo de enfermedades.

Principal campo de estudio	Conocimiento de las enfermedades		Total
	Bueno	Deficiente	
Orientación premédica	31	91	122
Otras	19	359	378
Total	50	450	500

¿Sugieren estos datos que existe una relación entre el conocimiento del grupo de enfermedades y el principal campo de estudio de los estudiantes de bachillerato de los cuales se extrajo la presente muestra?

10.5 PRUEBAS DE HOMOGENEIDAD

Una característica de los ejemplos y ejercicios presentados en la última sección es que, en cada caso, se supuso que la muestra total había sido extraída antes de que las entidades se agruparan de acuerdo con los dos criterios de clasificación. Es decir, se determinó el número observado de entidades que caen en cada celda una vez que se extrajo la muestra. Como resultado, los totales de renglones y columnas son cantidades aleatorias que no están bajo el control del investigador. Se supone que la muestra extraída bajo estas condiciones es una sola muestra tomada de una sola población. Sin embargo, en ocasiones, los totales de renglones y columnas pueden estar bajo el control del investigador, es decir, el investigador puede especificar que esas muestras independientes se extraigan de varias poblaciones. En este caso, se dice que un conjunto de totales marginales es *fijo*, mientras que el

otro conjunto, que corresponde al criterio de clasificación aplicado a las muestras, es *aleatorio*. Como se ha visto, el primer procedimiento conduce a una prueba ji-cuadrada de independencia. La última situación conduce a una *prueba ji-cuadrada de homogeneidad*. Las dos situaciones no sólo comprenden procedimientos de muestreo distintos; también, conducen a preguntas e hipótesis nulas distintas. La prueba de independencia trata la pregunta: ¿son independientes los dos criterios de clasificación? La prueba de homogeneidad trata la pregunta: ¿las muestras extraídas son de poblaciones homogéneas con respecto a algún criterio de clasificación? En el último caso, la hipótesis nula establece que las muestras se extraen de la misma población. A pesar de estas diferencias en concepto y procedimiento de muestreo, las dos pruebas son matemáticamente idénticas, como se aprecia cuando se considera el ejemplo siguiente.

Ejemplo 10.5.1

Un investigador, estudiando el grado del uso de drogas entre estudiantes de bachillerato, que habían declarado ser adictos a ellas, seleccionó de este grupo una muestra de 150 alumnos del primer año, 135 del segundo año, 125 del tercer año y 100 del último año. Cada estudiante contestó un cuestionario en el que indicaba el grado de su uso de drogas como experimental, casual, o bien, moderado hasta intenso. Los resultados se muestran en la tabla 10.5.1. La manera de seleccionar las muestras, es decir, de seleccionar un número especificado de cada población, tiene el efecto de fijar los totales de los renglones de la tabla.

¿Son compatibles estos datos con la hipótesis de que las cuatro poblaciones son homogéneas con respecto al grado del uso de drogas? La estadística de prueba es la ahora conocida $X^2 = \sum [(O_i - E_i)^2 / E_i]$. Para proceder, se necesitan entonces las frecuencias esperadas para cada una de las celdas de la tabla 10.5.1.

Si las poblaciones son además homogéneas o, lo que es equivalente, si todas las muestras se extraen de la misma población, con respecto al uso de drogas, el mejor cálculo de la proporción en la población combinada de quienes han empleado las drogas sólo experimentalmente es de $215/510 = .4216$. Por lo mismo, si las cuatro poblaciones son homogéneas, esta probabilidad se interpreta como si se aplicara individualmente a cada una de las poblaciones. Por ejemplo, bajo la

Tabla 10.5.1 Grado del uso de fármacos entre 510 estudiantes de bachillerato clasificados según el curso.

Curso	Grado del uso de fármacos			Total
	Experimental	Casual	Moderado a intenso	
Primero	57	50	43	150
Segundo	57	58	20	135
Tercero	56	45	24	125
Ultimo	45	22	33	100
Total	215	175	120	510

hipótesis nula, $215/510$ es la mejor estimación de la probabilidad de que un estudiante seleccionado al azar de entre los adictos a las drogas las tome sólo con el fin de experimentar. Se esperaría encontrar entonces, que $(215/510) \cdot 150 = 63.24$ de los 150 alumnos de primer año las toman con fines experimentales. Asimismo, se esperaría encontrar que $(215/510) \cdot 135 = 56.91$ alumnos de segundo año, $(215/510) \cdot 125 = 52.70$ de tercer año y $(215/510) \cdot 100 = 42.16$ del último año las tomen con el mismo fin.

Una vez más se ve que el procedimiento simplificado de multiplicar los totales marginales apropiados y dividir entre el gran total proporciona las frecuencias esperadas para las celdas. Las frecuencias esperadas que han sido calculadas de esta forma, junto con las frecuencias observadas, se muestran en la tabla 10.5.2. Las frecuencias esperadas están entre paréntesis.

A partir de los datos de la tabla 10.5.2, se calcula la siguiente estadística de prueba:

$$X^2 = \frac{(57 - 63.24)^2}{63.24} + \frac{(50 - 51.47)^2}{51.47} + \cdots + \frac{(33 - 23.53)^2}{23.53} = 19.4$$

Se encuentra que los grados de libertad asociados con este valor son 6 cuando se aplica la regla $(r - 1)(c - 1)$. Consultando la tabla I, se encuentra que la probabilidad de obtener un valor de X^2 tan grande como 19.4 o mayor que él, cuando la hipótesis nula es verdadera, es

Tabla 10.5.2 Frecuencias observada y esperada para el ejemplo 10.5.1

Curso	Grado del uso de fármacos			Total
	Experimental	Casual	Moderado a intenso	
Primero	57(63.24)	50(51.47)	43(35.29)	150
Segundo	57(56.91)	58(46.32)	20(31.76)	135
Tercero	56(52.70)	45(42.89)	24(29.41)	125
Ultimo	45(42.16)	22(34.31)	33(23.53)	100
Total	215	175	120	510

menor que .005. La decisión es entonces rechazar la hipótesis nula. Como consecuencia, se concluye que las poblaciones no son homogéneas con respecto al grado del uso de drogas.

Las reglas para las frecuencias esperadas pequeñas, que se dieron en la sección anterior, se aplican cuando se lleva a cabo una prueba de homogeneidad.

Cuando la prueba ji-cuadrada de homogeneidad se utiliza para probar la hipótesis nula de que dos poblaciones son homogéneas, y cuando sólo existen dos niveles del criterio de clasificación, los datos pueden presentarse en una tabla de contingencia de 2×2 . El análisis es idéntico al análisis de las tablas de 2×2 dado en la sección 10.4.

En resumen, la prueba ji-cuadrada de homogeneidad tiene las siguientes características:

1. De antemano, dos o más poblaciones se identifican y, de cada una, se extrae una muestra independiente.
2. Los individuos u objetos de la muestra se colocan en categorías apropiadas de la variable de interés.
3. El cálculo de las frecuencias esperadas de las celdas se basa en el fundamento de que si las poblaciones son homogéneas, como se señaló en la hipótesis nula, la mejor estimación de la probabilidad de que un individuo u objeto caiga en una categoría particular de la variable de interés puede obtenerse juntando los datos de la muestra.
4. Las hipótesis y conclusiones se establecen en términos de la homogeneidad (con respecto a la variable de interés) de las poblaciones.

La prueba ji-cuadrada de homogeneidad para el caso de dos muestras constituye un método alternativo para probar la hipótesis nula de que las proporciones de las dos poblaciones son iguales. Se recordará que en la sección 6.6 se aprendió a probar $H_0: p_1 = p_2$ contra $H_A: p_1 \neq p_2$ por medio de la estadística

$$z = \frac{(\tilde{p}_1 - \tilde{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\bar{p}(1-\bar{p})}{n_1} + \frac{\bar{p}(1-\bar{p})}{n_2}}}$$

donde $\bar{p}$ se obtiene juntando los datos de las dos muestras independientes disponibles para el análisis.

Supóngase, por ejemplo, que en la prueba $H_0: p_1 = p_2$ contra $H_A: p_1 \neq p_2$, los datos de la muestra fueron los siguientes: $n_1 = 100$, $\tilde{p}_1 = .60$, $n_2 = 120$, $\tilde{p}_2 = .40$. Cuando se juntan los datos de la muestra se tiene que

$$\bar{p} = \frac{.60(100) + .40(120)}{100 + 120} = \frac{108}{220} = .4909$$

y

$$z = \frac{.60 - .40}{\sqrt{\frac{(.4909)(.5091)}{100} + \frac{(.4909)(.5091)}{120}}} = 2.95469$$

que es significativa al nivel de .05, ya que es mayor que el valor crítico de 1.96.

Si se desea probar la misma hipótesis utilizando el método de la ji-cuadrada, la tabla de contingencia sería:

Muestra	Característica presente		Total
	Sí	No	
1	60	40	100
2	48	72	120
Total	108	112	220

Mediante la ecuación 10.4.1, se calcula

$$X^2 = \frac{220[(60)(72) - (40)(48)]^2}{(108)(112)(100)(120)} = 8.7302$$

que es significativa al nivel de .05, ya que es mayor que el valor crítico de 3.841. Por lo tanto, se ve que se llega a la misma conclusión utilizando ambos métodos. Esto no es sorprendente ya que, como se explicó en la sección 10.2, $\chi_{(1)}^2 = z^2$. Nótese que $8.7302 = (2.95469)^2$ y que $3.841 = (1.96)^2$.

Ejercicios

En los ejercicios siguientes, lleve a cabo la prueba al nivel de significación indicado y determine el valor p .

- 10.5.1 En un estudio del estado de la caries dental en los niños de seis comunidades con niveles variables de fluoruro en el suministro de agua, se seleccionó una muestra de 125 niños de cada una de las comunidades y se les practicó un examen dental. La tabla siguiente señala el número de niños sin caries de cada muestra.

Comunidad	Número de niños en la muestra	Número de niños sin caries
A	125	38
B	125	8
C	125	30
D	125	44
E	125	64
F	125	32
Total	750	216

¿Son compatibles estos datos con la hipótesis de que las seis poblaciones son homogéneas con respecto a la proporción de niños sin caries dental?

- 10.5.2 En un estudio diseñado para investigar la relación entre el estado de nutrición y la capacidad para realizar ciertas tareas, 400 animales de laboratorio, que habían sido entrenados para

llevar a cabo estas tareas, se dividieron en cuatro grupos. Los cuatro grupos fueron alimentados con dietas distintas, representando diferentes niveles de deficiencias en la nutrición que iban desde una dieta bien balanceada (condición de tratamiento 1) hasta una altamente deficiente en nutrientes esenciales (condición de tratamiento 4). Después de que los animales habían sido sometidos a las dietas durante cierto tiempo, se probó su capacidad para realizar tareas de dificultad variable. Algunos animales fueron capaces sólo de realizar las tareas sencillas, algunos pudieron realizar tareas de dificultad moderada y otros pudieron efectuar las tareas más difíciles. La tabla siguiente muestra los 400 animales clasificados de acuerdo con la condición de tratamiento y el nivel de dificultad de la tarea llevada a cabo.

Dificultad de la tarea realizada	Condición de tratamiento				Total
	1	2	3	4	
Sencilla	3	12	27	49	91
Moderadamente difícil	13	62	36	48	159
Difícil	84	26	37	3	150
Total	100	100	100	100	400

¿Deben concluir los investigadores que existe una falta de homogeneidad entre los cuatro grupos con respecto a la capacidad para efectuar las tareas de dificultad variable?

- 10.5.3 Se seleccionó una muestra de los expedientes de un hospital que correspondían a pacientes cada uno de los cuales tenía cinco diagnósticos. Los registros se evaluaron con respecto a lo apropiado de la duración de la hospitalización. Los resultados se muestran en la tabla siguiente.

Diagnóstico	Hospitalización			Total
	Duración apropiada	Menos de la necesaria	Más de la necesaria	
I	31	6	13	50
II	49	2	4	55

Diagnóstico	Hospitalización			Total
	Duración apropiada	Menos de la necesaria	Más de la necesaria	
III	55	2	3	60
IV	42	9	24	75
V	33	3	9	45
Total	210	22	53	285

¿Sugieren estos datos una falta de homogeneidad entre los grupos de diagnóstico con respecto a la evaluación de la duración del internado? Sea $\alpha = .05$.

10.5.4 En un estudio sobre la contaminación atmosférica realizado en dos comunidades se seleccionó una muestra aleatoria de 200 familias de cada una de ellas. Se interrogó a uno de los miembros de cada familia acerca de si alguien de la familia se sentía afectado por la contaminación atmosférica. Las respuestas fueron las siguientes.

Comunidad	¿Algún miembro de la familia ha sido afectado por la contaminación atmosférica?		Total
	Sí	No	
I	43	157	200
II	81	119	200
Total	124	276	400

¿Pueden concluir los investigadores que las dos comunidades difieren con respecto a la variable de interés?

10.6 RESUMEN

En este capítulo se analizan algunos de los usos de la versátil distribución ji-cuadrada. Se estudian las pruebas ji-cuadrada de bondad de ajuste para las distribuciones normal, binomial y de Poisson. Se

observa que el procedimiento consiste en calcular la estadística

$$X^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

la cual mide la discrepancia entre las frecuencias observadas (O_i) y las esperadas (E_i) de ocurrencia de los valores en ciertas categorías discretas. Cuando la hipótesis nula apropiada es verdadera, esta cantidad se distribuye aproximadamente como una χ^2 . Cuando X^2 es mayor que el valor tabulado de χ^2 para algún α , se rechaza la hipótesis nula al nivel de significación α .

En este capítulo se analizan también las pruebas de independencia y de homogeneidad. Estas pruebas son matemáticamente equivalentes, pero conceptualmente distintas. Una vez más, estos criterios prueban en esencia la bondad de ajuste de los datos observados con los esperados bajo las hipótesis, respectivamente, de independencia de los dos criterios al clasificar los datos y la homogeneidad de las proporciones entre dos o más grupos.

Preguntas y ejercicios de repaso

1. Explique cómo puede deducirse la distribución ji-cuadrada.
2. ¿Cuáles son la media y la variancia de la distribución ji-cuadrada?
3. Explique cómo se calculan los grados de libertad para las pruebas ji-cuadrada de bondad de ajuste.
4. Enuncie la regla de Cochran para las frecuencias esperadas pequeñas en las pruebas de bondad de ajuste.
5. ¿Cómo se hace el ajuste en el caso de frecuencias esperadas pequeñas?
6. ¿Qué es una tabla de contingencia?
7. ¿Cómo se calculan los grados de libertad cuando se calcula un valor X^2 a partir de una tabla de contingencia?
8. Explique las razones que fundamentan el método de calcular las frecuencias esperadas en una prueba de independencia.
9. Explique la diferencia que existe entre una prueba de independencia y una prueba de homogeneidad.
10. Explique las razones que justifican el método de calcular las frecuencias esperadas en una prueba de homogeneidad.

11. Un estudio de 190 embarazos proporcionó los siguientes datos sobre la relación que existe entre la hipertensión de la madre y cierta complicación del embarazo.

Cierta complicación en el embarazo	Madre hipersensible		Total
	Sí	No	
Presente	23	55	78
Ausente	12	100	112
Total	35	155	190

¿Proporcionan estos datos evidencia suficiente que indique que las dos condiciones no son independientes? Sea $\alpha = .01$. ¿Cuál es el valor p ?

12. Una muestra de 150 portadores crónicos de cierto antígeno y una muestra de 500 no portadores reveló la siguiente distribución de grupos sanguíneos.

Grupo sanguíneo	Portadores	No portadores	Total
O	72	230	302
A	54	192	246
B	16	63	79
AB	8	15	23
Total	150	500	650

¿Puede concluirse a partir de estos datos que las dos poblaciones de las cuales se tomaron las muestras difieren con respecto a la distribución de grupos sanguíneos? Sea $\alpha = .05$. ¿Cuál es el valor p para esta prueba?

13. La tabla siguiente muestra a 200 hombres clasificados de acuerdo con su clase social y tipo de dolor de cabeza:

Muestra de estudio	Clase social			Total
	A	B	C	
Sin dolor de cabeza (en el año anterior)	6	30	22	58
Dolor de cabeza simple	11	35	17	63

Muestra de estudio	Clase social			Total
	A	B	C	
Dolor de cabeza unilatera- teral (sin migraña)	4	19	14	37
Migraña	5	25	12	42
Total	26	109	65	200

¿Proporcionan estos datos evidencia suficiente que indique que el dolor de cabeza y la clase social están relacionados? Sea $\alpha = .05$.

¿Cuál es el valor p para esta prueba?

14. La tabla siguiente muestra la distribución de frecuencias de las calificaciones obtenidas en una prueba de aptitud por 175 aspirantes a un programa de adiestramiento en fisioterapia:

Calificación	Número de aspirantes
10-14	3
15-19	18
20-24	13
25-29	17
30-34	19
35-39	25
40-44	28
45-49	20
50-54	18
55-59	12
60-64	8
65-69	4
Total	175

¿Proporcionan estos datos evidencia suficiente que indique que la población de calificaciones no está normalmente distribuida? Sea $\alpha = .05$. ¿Cuál es el valor p para esta prueba?

15. Varios estudios han aportado evidencia para apoyar la hipótesis de que la manipulación o "amansamiento" de las ratas durante las primeras etapas de su vida tiene resultados benéficos. Supóngase un estudio en el cual se compara una muestra de ratas manipuladas y una muestra de ratas sin amansar con respecto al estado total de salud, obteniéndose los siguientes resultados:

Estado de salud	Grupo		Total
	Amansado	Sin amansar	
Favorable	37	23	60
Malo	13	27	40
Total	50	50	100

¿Apoyarían estos datos la hipótesis? Sea $\alpha = .05$.

16. Un departamento local de salud patrocinó un programa de información sobre enfermedades venéreas que fue abierto para estudiantes de bachillerato del penúltimo y último años con edades que fluctuaban entre 16 y 19 años. El director del programa pensó que cada nivel de edades estaba igualmente interesado en saber más acerca de las enfermedades venéreas. Dado que cada nivel de edades estaba casi igualmente representado en el área de estudio, el director supuso que se reflejaría un igual interés en las enfermedades venéreas debido a la igual concurrencia de los estudiantes por nivel de edades durante la presentación del programa. La clasificación por edades de quienes concurrieron al programa fue la siguiente.

Edad	Número de concurrentes
16	26
17	50
18	44
19	40

¿Son incompatibles estos datos con la suposición del director del programa de que los estudiantes de los cuatro niveles de edades están igualmente interesados en el programa sobre enfermedades venéreas? Sea $\alpha = .05$. ¿Cuál es el valor de p para esta prueba?

17. En una encuesta, los niños menores de 15 años de edad que viven en la zona central de una gran ciudad fueron clasificados de acuerdo con el grupo étnico al que pertenecen y el nivel de hemoglobina que poseen. Los resultados fueron los siguientes:

Grupo étnico	Nivel de hemoglobina (gm/100 ml)			Total
	10.0 ó mayor	9.0-9.9	<9.0	
A	80	100	20	200
B	99	190	96	385
C	70	30	10	110
Total	249	320	126	695

¿Proporcionan estos datos evidencia suficiente que indique, al nivel de significación de .05, que las dos variables están relacionadas? ¿Cuál es el valor p para esta prueba?

18. Una muestra de los casos reportados de paperas en niños de edad preescolar mostró la siguiente distribución por edades:

Edad (años)	Número de casos
Menos de 1	6
1	20
2	35
3	41
4	48
Total	150

Pruebe la hipótesis de que los casos se presentan con igual frecuencia en las cinco categorías por edades. Sea $\alpha = .05$. ¿Cuál es el valor p para esta prueba?

19. A cada uno de los hombres de una muestra de tamaño 250 extraída de una población que se sospechaba sufría de las articulaciones se le preguntó cuál de tres síntomas era el que más presentaba. La misma pregunta se le hizo a una muestra de 300 mujeres que se sospechaba padecía la misma enfermedad. Los resultados fueron los siguientes:

Síntoma más molesto	Hombres	Mujeres
Rigidez matutina	111	102
Dolor nocturno	59	73
Edema en las articulaciones	80	125
	250	300

¿Proporcionan estos datos evidencia suficiente que indique que las dos poblaciones no son homogéneas con respecto a los síntomas principales. Sea $\alpha = .05$. ¿Cuál es el valor p para esta prueba? Para cada una de las situaciones siguientes, indique si es apropiada una hipótesis nula de homogeneidad o una hipótesis nula de independencia.

20. Un investigador deseaba comparar el estado de tres comunidades con respecto a la inmunidad ante la poliomielitis en niños en edad preescolar. Se extrajo una muestra de esos niños de cada una de las comunidades.
21. En un estudio de la relación que existe entre el fumar y las enfermedades respiratorias, se clasificó una muestra aleatoria de adultos con respecto al consumo de tabaco y el grado de los síntomas respiratorios.
22. Un médico, quien deseaba saber más acerca de la relación entre el fumar y las alteraciones al nacer, estudió los expedientes de salud de una muestra de madres y sus hijos incluyendo, hasta donde fuera posible, los fetos todavía vivos y los que fueron abortados espontáneamente.
23. Un grupo de médicos investigadores piensa que la incidencia de depresión es mayor entre las personas con hipoglicemia que entre las personas que no padecen esta enfermedad.

REFERENCIAS

Referencias citadas

1. Karl Pearson, "On the Criterion that a Given System of Deviations from the Probable in the Case of a Correlated System of Variables is such that it can be Reasonably Supposed to Have Arisen from Random Sampling," *The London, Edinburgh and Dublin Philo-*

- sophical Magazine and Journal of Science*, quinta serie, 50 (1900), 157–175. Reimpreso en *Karl Pearson's Early Statistical Papers*, Cambridge University Press, 1948.
2. H. O. Lancaster, *The Chi-Squared Distribution*, Wiley, Nueva York, 1969.
 3. Harald Cramer, *Mathematical Methods of Statistics*, Princeton University Press, Princeton, N.J., 1958.
 4. Ram C. Dahiya y John Gurland, "Pearson Chi-squared Test of Fit With Random Intervals," *Biometrika*, 59 (1972), 147–153.
 5. G. S. Watson, "On Chi-Square Goodness-of Fit Tests for Continuous Distributions," *Journal of the Royal Statistical Society, B*, 20 (1958), 44–72.
 6. G. S. Watson, "The χ^2 Goodness-of-Fit Test for Normal Distributions," *Biometrika*, 44 (1957), 336–348.
 7. G. S. Watson, "Some Recent Results in Chi-Square Goodness-of-Fit Tests," *Biometrics*, 15 (1959), 440–468.
 8. G. R. Chase, "On the Chi-Square Test When the Parameters Are Estimated Independently of the Sample," *Journal of the American Statistical Association*, 67 (1972), 609–611.
 9. William G. Cochran, "The χ^2 Test of Goodness of Fit," *Annals of Mathematical Statistics*, 23 (1952), 315–345.
 10. William G. Cochran, "Some Methods for Strengthening the Common χ^2 Tests," *Biometrics*, 10 (1954), 417–451.
 11. John T. Roscoe y Jackson A. Byars, "An Investigation of the Restraints with Respect to Sample Size Commonly Imposed on the Use of the Chi-Square Statistic," *Journal of the American Statistical Association*, 66 (1971), 755–759.
 12. James K. Yarnold, "The Minimum Expectation in X^2 Goodness-of-Fit Test and the Accuracy of Approximations for the Null Distribution," *Journal of the American Statistical Association*, 65 (1970), 864–886.
 13. Merle W. Tate y Leon A. Hyer, "Significance Values for an Exact Multinomial Tests and Accuracy of the Chi-Square Approximation," U.S. Department of Health Education, and Welfare, Office of Education Bureau of Research, agosto 1969.
 14. Malcolm J. Slakter, "Comparative Validity of the Chi-Square and Two Modified Chi-Square Goodness-of-Fit Tests for Small but Equal Expected Frequencies," *Biometrika*, 53 (1966), 619–23.
 15. Malcolm J. Slakter, "A Comparison of the Pearson Chi-Square and Kolmogorov Goodness-of-Fit Tests with Respect to Validity,"

- Journal of the American Statistical Association*, 60 (1965), 854–858.
16. R. C. Lewontin y J. Felsenstein, “The Robustness of Homogeneity Tests in $2 \times N$ Tables,” *Biometrics*, 21 (1965), 19–33.
 17. F. Yates, “Contingency Tables Involving Small Numbers and the χ^2 Tests,” *Journal of the Royal Statistical Society Supplement*, 1 1934 (Serie B), 217–235.
 18. J. E. Grizzle, “Continuity Correction in the χ^2 Test for 2×2 Tables,” *The American Statistician*, 21 (octubre, 1967), 28–32.
 19. H.O. Lancaster, “The Combination of Probabilities Arising from Data in Discrete Distributions,” *Biometrika*, 36 (1949), 370–382.
 20. E. S. Pearson, “The Choice of Statistical Test Illustrated on the Interpretation of Data in a 2×2 Table,” *Biometrika*, 34 (1947), 139–167.
 21. R. L. Plackett, “The Continuity Correction in 2×2 Tables,” *Biometrika*, 51 (1964), 427–338.

11

Estadísticas no paramétricas y de libre distribución

11.1 INTRODUCCIÓN

Los procedimientos de inferencia estadística que se han estudiado hasta aquí, con una excepción, se clasifican como *estadísticas paramétricas*. La única excepción son los usos de la ji-cuadrada: como una prueba de bondad del ajuste y como una prueba de independencia. Estos usos de la ji-cuadrada vienen bajo el título de *estadísticas no paramétricas*.

La pregunta obvia es ahora: ¿cuál es la diferencia? Como respuesta, recuérdese la naturaleza de los procedimientos de inferencia que se han clasificado como *paramétricos*. En cada caso, el interés se centró en estimar o probar una hipótesis acerca de uno o más parámetros de la población. Además, lo básico de estos procedimientos fue el que se conociera la distribución de la población de la cual se extrajeron las muestras que proporcionan la base para la inferencia.

Un ejemplo de una prueba estadística paramétrica es la ampliamente utilizada prueba *t*. Los usos más comunes de esta prueba son para probar una hipótesis acerca de la media de una sola población o la diferencia entre las medias de dos poblaciones. Una de las suposiciones que fundamentan el uso válido de esta prueba es que la población o poblaciones muestreadas tengan, al menos, una distribución aproximadamente normal.

Como se aprenderá, los procedimientos que se estudian en este capítulo no se refieren a parámetros de población ni dependen del

conocimiento de la población muestreada. Estrictamente hablando, sólo aquellos procedimientos que prueban hipótesis que no son afirmaciones acerca de parámetros de población se clasifican como *no paramétricos*, mientras que aquellos que no hacen suposición alguna acerca de la población muestreada se conocen como procedimientos *a libre distribución*. A pesar de esta diferencia, se acostumbran utilizar los términos *no paramétrico* y *a libre distribución* indistintamente y analizar los diversos procedimientos de ambos tipos bajo el título de *estadísticas no paramétricas*. Se seguirá esta convención. Este punto es tratado por Kendall y Sundrum¹ y Gibbons.²

La razón anterior implica las dos ventajas siguientes de las estadísticas no paramétricas.

1. Permiten la prueba de hipótesis que no constituyen afirmaciones acerca de valores de los parámetros poblacionales. Las pruebas ji-cuadrada de bondad de ajuste y de independencia son ejemplos de pruebas que tienen esta ventaja.
2. Las pruebas no paramétricas pueden utilizarse cuando se desconoce la distribución de la población muestreada.

Han sido enumeradas otras ventajas por varios autores, como por ejemplo, Gibbons,² Blum y Fattu,³ Moses⁴ y Siegel.⁵ Además de las dos ya mencionadas, las siguientes ventajas son las que se dan con más frecuencia.

3. Los procedimientos no paramétricos son más fáciles de calcular y, en consecuencia, se aplican con mayor rapidez que los procedimientos paramétricos. Esta puede ser una característica conveniente en ciertos casos, pero cuando el tiempo no es un factor importante, merece poca prioridad como criterio para elegir una prueba no paramétrica.
4. Los procedimientos no paramétricos pueden aplicarse cuando los datos que se están analizando constan simplemente de categorías o clasificaciones. Es decir, los datos pueden no estar basados en una escala de medición lo suficientemente sólida como para permitir las operaciones aritméticas necesarias para llevar a cabo los procedimientos paramétricos. El tema de las escalas de medición se analizará con más detalle en la sección siguiente.

Aunque las estadísticas no paramétricas tienen ciertas ventajas, también deben reconocerse sus desventajas. Moses⁴ ha destacado las siguientes.

1. El uso de procedimientos no paramétricos con datos que pueden manejarse con un procedimiento paramétrico conduce a un desperdicio de información.
2. La aplicación de algunas de las pruebas no paramétricas puede ser laboriosa para muestras grandes.

En un libro de texto de introducción general, la limitación del espacio impide la presentación de más de una muestra de procedimientos no paramétricos. Otros procedimientos estudiados a un nivel introductorio o intermedio pueden encontrarse en los textos escritos por Conover,⁶ Siegel,⁵ Bradley,⁷ Kraft y Van Eeden,⁸ Tate y Clelland,⁹ Gibbons,¹⁰ Mosteller y Rourke,¹¹ Pierce,¹² Noether,¹³ Hollander y Wolfe,¹⁴ Daniel,¹⁵ Marascuilo y McSweeney¹⁶ y Lehmann.¹⁷ Libros matemáticamente más rigurosos han sido escritos por Gibbons,² Hajek¹⁸ y Walsh.^{19, 20} Savage²¹ ha preparado una bibliografía de estadísticas no paramétricas.

11.2 ESCALAS DE MEDICIÓN _____

Como se señaló en la sección anterior, una de las ventajas de los procedimientos estadísticos no paramétricos es el hecho de que pueden utilizarse con datos basados en una escala de medición débil. Para comprender completamente el significado de esta afirmación, es necesario entender el significado de medición y de las diversas escalas de medición que se utilizan con más frecuencia. Este aspecto se estudia con considerable detalle en la literatura citada. Consulte, en particular, los escritos de Stevens.^{22, 23}

Medición. Esta puede definirse como la asignación de números a objetos o eventos de acuerdo con un conjunto de reglas. Las diversas escalas de medición son consecuencia del hecho de que la medición puede llevarse a cabo bajo diferentes series de reglas.

La escala nominal. La escala de medición más baja es la *escala nominal*. Como su nombre lo indica, consiste en “nombrar” las observaciones o clasificarlas en varias categorías mutuamente exclusivas y colectivamente exhaustivas. La práctica de utilizar números para distinguir entre los diversos diagnósticos médicos constituye una medición sobre una escala nominal. Otros ejemplos incluyen dicotomías

tales como masculino-femenino, sano-enfermo, de menos de 65 años de edad y de 65 y más, niño-adulto y casado-soltero. Como se ha visto, bajo ciertas condiciones, la prueba ji-cuadrada puede utilizarse para probar hipótesis acerca de la frecuencia de ocurrencia de observaciones en varias categorías nominales.

La escala ordinal. Siempre que las observaciones no sólo difieran de categoría a categoría, sino que puedan clasificarse por rango de acuerdo con algún criterio, se dice que se miden sobre una escala ordinal. Los pacientes convalescientes pueden caracterizarse como no mejorados, mejorados y bastante mejorados. Las personas pueden clasificarse de acuerdo con su estado socioeconómico como pobres, de clase media o ricos. La inteligencia de los niños puede estar por encima del promedio, en el promedio o por debajo de éste. En cada uno de estos ejemplos, todos los miembros de cualquiera de las categorías se consideran iguales, pero los miembros de una categoría se consideran inferiores, peores o menores que los de otra categoría que, a su vez, guardan una relación similar con los de otra categoría. Por ejemplo, un paciente bastante mejorado está en mejor estado de salud que uno clasificado como mejorado, mientras que un paciente que ha mejorado está en mejor condición que uno que no ha mejorado. Por lo común, es imposible inferir que la diferencia entre los miembros de una de las categorías y la categoría inmediata adyacente sea igual a la diferencia entre los miembros de esa categoría y los miembros de la categoría adyacente a ella. El grado de mejoría entre los no mejorados y los mejorados quizá no sea el mismo que el que existe entre los mejorados y los bastante mejorados. La implicación es que si se hiciera una división más fina que conduzca a más categorías, éstas podrían también ordenarse de manera semejante. La función de los números asignados a datos ordinales es la de ordenar (o asignar una categoría según el rango) las observaciones desde las más bajas hasta las más altas, de aquí el término ordinal. Se han desarrollado numerosas pruebas estadísticas no paramétricas para utilizarlas con datos ordinales.

La escala de intervalos. La *escala de intervalos* es una escala más especializada que la nominal o la ordinal en el sentido de que, con esta escala, no sólo es posible ordenar las mediciones, sino que se conoce también la distancia entre dos mediciones cualesquiera. Por decir algo, se sabe que la diferencia entre una medida de 20 y una medida

de 30 es igual a la diferencia entre las medidas de 30 y 40. La habilidad para hacer esto implica el uso de una distancia unitaria y un punto cero, los cuales son arbitrarios. El punto seleccionado como cero no es un cero verdadero en el sentido de que no indica una ausencia total de la cantidad que se está midiendo. Quizá el mejor ejemplo de una escala de intervalos sea la forma en que generalmente se mide la temperatura. La unidad de medición es el grado y el punto de comparación es el arbitrariamente seleccionado "cero grados". La escala de intervalos, a diferencia de las escalas nominal y ordinal, es una escala verdaderamente cuantitativa. Cuando se ha logrado la escala de intervalos para la medición y cuando se satisfacen las suposiciones del modelo, pueden utilizarse los procedimientos usuales de estadísticas paramétricas, como la prueba t y la prueba F .

La escala de razones. El nivel más alto de medición es la *escala de razones*. Esta escala se caracteriza por el hecho de que puede determinarse la igualdad de las razones, así como la igualdad de los intervalos. Para esta escala, es fundamental un punto cero verdadero. La medición de rasgos tan familiares como la estatura, el peso y la longitud, hacen uso de este tipo de escala. Cuando se ha logrado la escala de razones para la medición, puede utilizarse cualquier procedimiento estadístico siempre que se satisfagan las suposiciones del modelo particular que se ha utilizado.

Muchos autores, como por ejemplo Conover⁶ y Siegel,⁵ indican que pruebas estadísticas distintas requieren diferentes escalas de medición. Aunque esta idea parece seguirse en la práctica, Anderson,²⁴ Gaito,²⁵ Lord²⁶ y Armstrong²⁷ presentan otros puntos de vista interesantes. Este tema es estudiado también por Borgatta y Bohrnstedt.²⁸

11.3 LA PRUEBA DEL SIGNO

La conocida prueba t no es estrictamente válida para probar a) la hipótesis nula de que la media de una población es igual a algún valor particular, o bien, b) la hipótesis nula de que la diferencia entre las medias de dos poblaciones es igual a cero, a menos que se sepa (o el investigador se incline a suponer) que las poblaciones en cuestión están normalmente distribuidas. El caso b) se reconocerá como una situación que se analizó mediante la prueba de comparaciones pareas-

das dada en el capítulo 6. Cuando no pueden hacerse suposiciones de normalidad o cuando los datos disponibles son categorías en lugar de medidas sobre una escala de intervalos o de razones, debe buscarse una prueba alternativa. Aun cuando se sabe que la prueba *t* es algo insensible a las violaciones de la suposición de normalidad, hay casos en los que es deseable buscar una prueba alternativa.

Una prueba no paramétrica que se utiliza con frecuencia y que no depende de las suposiciones de la prueba *t*, o de mediciones que exceden la escala ordinal, es la *prueba del signo*. Esta prueba se centra en la mediana, más que en la media, como una medida de tendencia central o de localización. La mediana y la media serán iguales en distribuciones simétricas. La única suposición que fundamenta la prueba es que la distribución de la variable de interés es continua.

La prueba del signo toma su nombre del hecho de que los signos más y menos, más que los valores numéricos, proporcionan los datos en bruto que se utilizan en los cálculos. Se ilustrará el uso de esta prueba primero en el caso de una sola muestra y, a continuación, mediante un ejemplo que implique muestras pareadas.

Ejemplo 11.3.1

En una escuela para retrasados mentales, 10 niñas seleccionadas al azar recibieron instrucción especial sobre el cuidado y aseo personal. Dos semanas después de haber concluido el curso de instrucción, las niñas fueron entrevistadas por una enfermera y una trabajadora social, quienes asignaron a cada niña una calificación basada en su apariencia general. Los investigadores creían que, a lo más, las calificaciones alcanzarían el nivel de una escala ordinal. Tenían la sensación de que aun cuando una calificación de, por decir, 8 representaba una apariencia mejor que una calificación de 6, no se inclinaban a decir que la diferencia entre las calificaciones de 6 y 8 era igual a la diferencia entre, por decir, las calificaciones 8 y 10; o bien, que la diferencia entre las calificaciones de 6 y 8 representaba el doble de mejora que la diferencia entre las calificaciones de 5 y 6. Las calificaciones se muestran en la tabla 11.3.1.

A continuación, se utilizarán estos datos para probar, al nivel de significación de .05, la hipótesis nula de que la calificación mediana de la población hipotética, de la cual se supone se ha extraído la muestra, es 5 contra la alternativa de que la mediana no es 5. Este enunciado de la hipótesis alternativa implica una prueba bilateral.

Tabla 11.3.1 Calificaciones de aspecto general obtenidas por 10 niñas con retraso mental.

Niña	Calificación	Niña	Calificación
1	4	6	6
2	5	7	10
3	8	8	7
4	8	9	6
5	9	10	6

Tabla 11.3.2 Calificaciones por arriba (+) y por debajo (−) de la mediana establecida en la hipótesis en base a los datos del ejemplo 11.3.1.

Niña	1	2	3	4	5	6	7	8	9	10
Calificación relativa a la mediana establecida en la hipótesis	−	0	+	+	+	+	+	+	+	+

Como primer paso en la prueba de la hipótesis, se examinarán los datos de la tabla 11.3.1 para determinar qué calificaciones están por arriba y cuáles por debajo de la mediana de 5 planteada en la hipótesis. Si se asigna un signo más a aquellas calificaciones que están por arriba de la mediana establecida en la hipótesis y un menos a las que caen por debajo, se tienen los resultados que se muestran en la tabla 11.3.2.

Si la hipótesis nula fuera verdadera, es decir, si, en efecto, la mediana fuera 5, se esperaría encontrar que el número de calificaciones que caen por arriba y por debajo de 5 sean aproximadamente iguales. Esta línea de razonamiento sugiere otra forma en la que podría haberse enunciado la hipótesis nula, a saber, que la probabilidad de un signo más es igual a la probabilidad de uno menos, y estas probabilidades son, cada una, iguales a .5. Enunciada simbólicamente, la hipótesis sería

$$H_0: P(+) = P(-) = .5$$

En otras palabras, se esperaría casi el mismo número de signos más que de signos menos en la tabla 11.3.2 cuando H_0 es verdadera. La

observación de esta tabla revela que hay más signos más; específicamente, se observan ocho signos más, uno menos y un cero, el cual se asignó a la calificación que cayó exactamente en la mediana. El procedimiento habitual de manejar los ceros es eliminarlos del análisis y reducir n , el tamaño de la muestra de acuerdo con esta eliminación. Si se sigue este procedimiento, el problema se reduce a uno que consta de nueve observaciones, de las cuales ocho son signos más y uno es menos.

Dado que el número de signos más y menos no es el mismo, uno se pregunta si la distribución de los signos es lo suficientemente desproporcionada como para arrojar alguna duda sobre la hipótesis. Diciéndolo de otra forma, uno se pregunta si este pequeño número de signos menos pudo haber sido únicamente resultado del azar cuando la hipótesis nula es verdadera; o bien, si el número es tan pequeño que algo que no es el azar (es decir, una hipótesis nula falsa) es responsable de los resultados.

Con base en lo que se aprendió en el capítulo 3, parece razonable concluir que las observaciones de la tabla 11.3.2 constituyen un conjunto de n variables aleatorias independientes de la población de Bernoulli con parámetro p . Sea k = el número de signos menos, la distribución muestral de k tiene distribución binomial con parámetro $p = .5$, si la hipótesis nula es verdadera.

Puede determinarse la probabilidad de observar x o un menor número de signos menos cuando se da una muestra de tamaño n y parámetro p al calcular la siguiente expresión:

$$P(k \leq x | n, p) = \sum_{k=0}^x \binom{n}{k} p^k q^{n-k} \quad (11.3.1)$$

Para el ejemplo se calcularía

$$\binom{9}{0} (.5)^0 (.5)^{9-0} + \binom{9}{1} (.5)^1 (.5)^{9-1} = .00195 + .01758 = .0195$$

Puede utilizarse la tabla C y encontrar

$$P(k \leq 1 | 9, .5) = .0195$$

Con una prueba bilateral, un número muy pequeño de signos menos o de signos más provocaría el rechazo de la hipótesis nula. Dado que, en el ejemplo, se tiene un menor número de signos menos, la

atención se centra en estos signos más que en los signos más. Asignando a α el valor .05, se está diciendo que si el número de signos menos es tan pequeño que la probabilidad de observar tan pocos o, incluso, menos, es menor que .025 (la mitad de α), se rechazará la hipótesis nula. La probabilidad que se ha calculado, .0195, es menor que .025. Por lo tanto, se rechaza la hipótesis nula y se concluye que la calificación mediana no es de .5. El valor p para esta prueba es de $2(.0195) = .0390$.

Cuando los datos que van a analizarse constan de observaciones en parejas y no se satisfacen las suposiciones que fundamentan la prueba t , o la escala de medición es débil, puede utilizarse la prueba del signo para probar la hipótesis nula de que la diferencia entre las medianas es de 0. Una alternativa es enunciar la hipótesis nula en la forma siguiente:

$$P(X_i > Y_i) = P(X_i < Y_i) = .5$$

De la pareja de calificaciones, se toma una, digamos Y_i y se resta de la otra calificación, X_i . Si Y_i es menor que X_i , el signo de la diferencia es +, y si Y_i es mayor que X_i , el signo de la diferencia es -. Si la diferencia entre las medianas es 0, se esperaría que una pareja seleccionada al azar tenga precisamente la misma probabilidad de dar un + como un - cuando se hace la resta. Puede enunciarse entonces la hipótesis nula como

$$H_0: P(+) = P(-) = .5$$

En una muestra aleatoria formada por parejas, se esperaría encontrar que el número de signos + y de signos - sea aproximadamente igual. Si se tienen muchos más + o muchos más -, que los que pueden ser atribuidos al azar únicamente, cuando la hipótesis nula es verdadera, se tendrá alguna duda acerca de la veracidad de la hipótesis nula. Mediante la prueba del signo, puede decidirse cuántos de uno de los signos constituyen más de los que pueden ser atribuidos únicamente al azar.

Ejemplo 11.3.2

Se formaron doce parejas de pacientes de una clínica dental clasificándolos por factores tales como la edad, el sexo, la inteligencia y las calificaciones de higiene bucal inicial. Un miembro de cada pareja recibió instrucción acerca de la forma de cepillarse los dientes y otros

Tabla 11.3.3 Calificaciones de higiene oral de 12 personas que recibieron instrucción de higiene oral (X_i) y de 12 personas que no recibieron dicha instrucción (Y_i)

Número de pareja	Calificación	
	Instruida (X_i)	No instruida (Y_i)
1	1.5	2.0
2	2.0	2.0
3	3.5	4.0
4	3.0	2.5
5	3.5	4.0
6	2.5	3.0
7	2.0	3.5
8	1.5	3.0
9	1.5	2.5
10	2.0	2.5
11	3.0	2.5
12	2.0	2.5

temas de higiene bucal. Seis meses después, se examinaron los 24 individuos y se les asignó una calificación de higiene bucal mediante el examen de un especialista en higiene dental, quien ignoraba qué personas habían recibido la instrucción. Una calificación baja indica un alto nivel de higiene bucal. Los resultados se muestran en la tabla 11.3.3.

El investigador deseaba saber si podía concluir que la instrucción había producido un efecto benéfico. Si así era, este hecho se reflejaría en las calificaciones asignadas a los miembros de cada pareja. Si se toman las diferencias $X_i - Y_i$, es de esperar que se observen más signos — que + si la instrucción ha sido benéfica, ya que una baja calificación indica un nivel más alto de higiene oral. Si, en efecto, la instrucción es benéfica, la mediana de la población hipotética de tales diferencias sería menor que 0, es decir, negativa. Si, por otra parte, la instrucción no ha tenido efecto alguno, la mediana de esta población sería de cero. Las hipótesis nula y la alternativa son entonces,

H_0 : la mediana de las diferencias es cero.

H_A : la mediana de las diferencias es negativa.

Utilícese un nivel de significación de 0.5 y procédase a probar la hipótesis nula. Como se verá, el procedimiento es idéntico al procedi-

Tabla 11.3.4 Signos de las diferencias ($X_i - Y_i$) en las calificaciones de higiene oral de 12 personas instruidas (X_i) y 12 personas apareadas no instruidas (Y_i).

Pareja	1	2	3	4	5	6	7	8	9	10	11	12
Signo de las diferencias de las calificaciones obtenidas	—	0	—	+	—	—	—	—	—	—	+	—

miento de una sola muestra una vez que se han obtenido las diferencias de calificaciones para cada pareja. Haciendo las restas y observando los signos, se obtienen los resultados que se muestran en la tabla 11.3.4.

La naturaleza de la hipótesis indica una prueba unilateral, de modo que todo el $\alpha = .05$ se asocia con la región de rechazo que consta de todos los valores de k (donde k es igual al número de signos +) para los cuales la probabilidad de obtener tantos como esos o menos signos de más, debido únicamente al azar cuando H_0 es verdadera, es igual o menor que .05. En la tabla 11.3.4 se ve que el experimento condujo a un cero, dos signos más y nueve signos menos. Al eliminarse el cero, el tamaño efectivo de la muestra es de $n = 11$, con dos signos más y nueve signos menos. En otras palabras, dado que sólo unos pocos signos más provocarán el rechazo de la hipótesis nula, se desea conocer la probabilidad de obtener no más de dos signos más en los once ensayos, cuando la hipótesis nula es verdadera. Como se ha visto, la respuesta se obtiene calculando la expresión binomial apropiada. En este ejemplo, se encuentra que

$$P(k \leq 2 | 11, .5) = \sum_{k=0}^2 \binom{11}{k} (.5)^k (.5)^{11-k}$$

Consultando la tabla C, se encuentra que esta probabilidad es de .0327. Dado que .0327 es menor que .05, debe rechazarse H_0 y concluir que la diferencia de las medianas es negativa. Es decir, se concluye que la instrucción fue benéfica. Para esta prueba, $p = .0327$.

Como se ha demostrado, la prueba del signo puede utilizarse con una sola muestra o con dos muestras en las cuales cada miembro de una de las muestras se une con uno de los miembros de la otra muestra para formar una muestra de parejas. Se ha visto también que la hipótesis alternativa puede conducir a una prueba unilateral o a una

prueba bilateral. En cualquier caso, la atención se centra en el signo que se presenta con menos frecuencia y se calcula la probabilidad de obtener ese número o menos de ese signo.

Se utiliza el signo que se presenta con menos frecuencia como estadística de prueba debido a que las probabilidades binomiales de la tabla C son probabilidades “menores que o iguales a”. Utilizando el signo que ocurre con menos frecuencia, puede obtenerse la probabilidad que se necesita saber directamente de la tabla C sin tener que hacer resta alguna. Si las probabilidades de la tabla C fueran probabilidades “mayores que o iguales a”, como suelen encontrarse en las tablas de la distribución binomial, se utilizaría como estadística de prueba el signo que ocurriera con más frecuencia para tomar ventaja de la conveniencia de obtener directamente la probabilidad deseada de la tabla sin tener que hacer resta alguna. De hecho, en los presentes ejemplos, puede utilizarse como estadística de prueba el signo que se presente con más frecuencia, pero dado que la tabla C contiene probabilidades “menores que o iguales a”, se tendría que hacer una resta para obtener la probabilidad deseada. Como ilustración, considérese el último ejemplo. Si se utiliza como estadística de prueba el signo que ocurre con más frecuencia, que es el signo $-$, el valor de la estadística es 9. La probabilidad deseada es entonces la probabilidad de 9 ó más signos menos, cuando $n = 11$ y $p = .5$. Es decir, se necesita

$$P(k \geq 9 | 11, .5)$$

Sin embargo, dado que la tabla C contiene probabilidades “menores que o iguales a”, debe obtenerse esta probabilidad mediante sustracción. Es decir,

$$\begin{aligned} P(k \geq 9 | 11, .5) &= 1 - P(k \leq 8 | 11, .5) \\ &= 1 - .9673 \\ &= .0327 \end{aligned}$$

que es el resultado obtenido anteriormente.

Tamaño de la muestra. En el capítulo 4 se estudió que, cuando el tamaño de la muestra es grande y p está cercano a .5, la distribución binomial puede ser aproximada por la distribución normal. La regla empírica utilizada fue que resulta apropiada la aproximación normal cuando tanto np como nq son mayores que 5. Cuando $p = .5$, como

se estableció en la hipótesis en los dos ejemplos en cuestión, una muestra de tamaño 12 satisfaría la regla empírica. Siguiendo este razonamiento, puede utilizarse la aproximación normal cuando se usa la prueba del signo para probar la hipótesis nula de que la mediana o la diferencia de medianas es 0 y n es igual a, o mayor que 12. Gibbons² está de acuerdo con esta sugerencia, aunque Siegel⁵ recomienda que n sea, al menos, 25. Dado que el procedimiento implica la aproximación de una distribución continua mediante una distribución discreta, en general, se utiliza la corrección de continuidad de .5. La estadística de prueba es entonces

$$z = \frac{(k \pm .5) - .5n}{.5\sqrt{n}} \quad (11.3.2)$$

la cual se compara con el valor de z de la distribución normal unitaria que corresponde al nivel de significación elegido. En la ecuación 11.3.2, se utiliza $k + .5$ cuando $k < n/2$ y $k - .5$ se utiliza cuando $k > n/2$.

Además de las referencias ya citadas, la prueba del signo se estudia con considerable detalle en Dixon y Mood.²⁹

Ejercicios

- 11.3.1 A una muestra aleatoria de 15 estudiantes de enfermería se les hizo una prueba para medir su nivel de autoritarismo, obteniéndose los siguientes resultados.

Número del estudiante	1	2	3	4	5	6	7	8	9	10	11	12
Calificación de autoritarismo	75	90	85	110	115	95	132	74	82	104	88	124
Número del estudiante	13	14	15									
Calificación de autoritarismo	110	76	98									

Pruebe al nivel de significación de .05 la hipótesis nula de que la mediana de la calificación para la población muestreada es de 100. Determine el valor p .

- 11.3.2 A un grupo de 20 pacientes que asistían a una clínica de fisioterapia se les sometió a una determinada prueba diseñada para medir su nivel de motivación, antes de que participaran en un programa experimental de remotivación. Al término del programa, los pacientes fueron sometidos a una nueva prueba. Las calificaciones antes y después fueron las siguientes.

Paciente	Calificación		Paciente	Calificación	
	Antes	Después		Antes	Después
1	10	15	11	16	24
2	8	10	12	10	23
3	5	10	13	15	25
4	14	14	14	5	15
5	15	25	15	24	20
6	22	20	16	20	25
7	17	20	17	14	24
8	10	22	18	10	23
9	8	16	19	15	25
10	20	18	20	14	25

¿Se concluiría que el programa de remotivación es eficaz? Sea $\alpha = .05$. Una calificación alta indica un alto nivel de motivación. Determine el valor p .

11.4 LA PRUEBA DE LA MEDIANA

La prueba del signo para dos muestras, dada en la sección anterior, requirió que las muestras estuvieran relacionadas. Con frecuencia, se tiene interés en hacer inferencias basadas en dos muestras que no están relacionadas, es decir, que son independientes. Para probar la hipótesis nula de que dos muestras son extraídas de poblaciones con medias iguales, se utilizan las estadísticas t o z (dependiendo del tamaño de las muestras y de si se conocen o desconocen las variancias de las poblaciones) cuando se satisfacen las condiciones para estas pruebas paramétricas. Una contraparte no paramétrica la proporciona la prueba de la mediana, que puede utilizarse para probar la hipótesis nula de que dos muestras independientes se han extraído de poblaciones con medianas iguales. Esta prueba, atribuida principal-

mente a Mood³⁰ y Westenberg,³¹ la analizan también Brown y Mood³² y Moses,⁴ así como varias referencias ya citadas.

Las suposiciones que fundamentan esta prueba son *a)* las muestras se seleccionan independientemente y al azar de sus poblaciones respectivas, *b)* las poblaciones tienen la misma distribución, difiriendo sólo en su localización y *c)* la variable de interés es continua. El nivel de medición debe ser, al menos, ordinal. Las dos muestras no tienen que ser del mismo tamaño. El procedimiento de prueba puede demostrarse mejor mediante un ejemplo.

Ejemplo 11.4.1

Los miembros de una muestra aleatoria de 12 estudiantes varones de una escuela secundaria rural y de una muestra aleatoria independiente de 16 estudiantes varones de una escuela secundaria urbana fueron sometidos a una prueba para estimar su nivel de salud mental. Los resultados se muestran en la tabla 11.4.1.

Se desea determinar si puede concluirse que existe una diferencia en las medianas de las calificaciones de salud mental entre los muchachos de secundaria rural y urbana. Supóngase que se elige un nivel de significación de .05.

El primer paso en el procedimiento es calcular la mediana común de las dos muestras combinadas. Esto se hace ordenando las observaciones en orden ascendente y, dado que el número total de observacio-

Tabla 11.4.1 Calificaciones del nivel de salud mental en estudiantes varones de enseñanza secundaria.

<i>Escuela</i>			
<i>Urbana</i>	<i>Rural</i>	<i>Urbana</i>	<i>Rural</i>
35	29	25	50
26	50	27	37
27	43	45	34
21	22	46	31
27	42	33	
38	47	26	
23	42	46	
25	32	41	

Tabla 11.4.2 Calificaciones del nivel de salud mental en estudiantes varones de enseñanza secundaria.

	<i>Urbana</i>	<i>Rural</i>	<i>Total</i>
Número de calificaciones por arriba de la mediana	6	8	14
Número de calificaciones por abajo de la mediana	10	4	14
Total	16	12	28

nes es par, obteniendo la media de los dos números de en medio. Para el presente ejemplo, la mediana es de $(33 + 34)/2 = 33.5$.

Ahora, para cada grupo, se determina el número de observaciones que caen por arriba y por debajo de la mediana común. Las frecuencias resultantes se disponen en una tabla de 2×2 . Para el presente ejemplo, se obtiene la tabla 11.4.2.

Si, en efecto, las dos muestras provienen de poblaciones con la misma mediana, es de esperar que aproximadamente la mitad de las calificaciones en cada muestra estén por arriba de la mediana combinada y alrededor de la mitad por debajo. Si se satisfacen las condiciones relativas al tamaño de la muestra y a las frecuencias esperadas para una tabla de contingencia de 2×2 , como se trató en el capítulo 10, puede utilizarse la prueba ji-cuadrada con 1 grado de libertad a fin de probar la hipótesis nula de medianas iguales de las poblaciones. Por ejemplo, mediante la fórmula 10.4.1 se tiene que

$$X^2 = \frac{28[(6)(4) - (8)(10)]^2}{(16)(12)(14)(14)} = 2.33$$

Dado que $2.33 < 3.841$, el valor crítico de χ^2 con $\alpha = .05$ y 1 grado de libertad, no puede rechazarse la hipótesis nula en base a estos datos. Se concluye entonces que las dos muestras pueden haberse extraído de poblaciones con medianas iguales. Dado que $2.33 < 2.706$, se tiene que $p > .10$.

A veces, uno o más de los valores observados serán exactamente iguales a la mediana calculada y, por lo tanto, no caerán por arriba ni por debajo de ella. Nótese que si $n_1 + n_2$ es impar, al menos un valor siempre será exactamente igual a la mediana. Esto lleva al problema de qué hacer con las observaciones de este tipo. Siegel⁵ sugiere eliminarlas del análisis si $n_1 + n_2$ es grande y se tienen sólo unos cuan-

tos valores que caen en la mediana combinada, o bien, dividir las calificaciones en dos grupos: aquellas que son mayores que la mediana y las que no lo son, en cuyo caso, las observaciones que son iguales a la mediana se contarán en la segunda categoría. Senders³³ y Hays y Winkler³⁴ sugieren otros procedimientos. El problema es analizado con bastante detalle por Bradley.⁷

Antes de utilizar la prueba ji-cuadrada, debe verificar que se satisfacen las condiciones necesarias para una tabla de contingencia de 2×2 , estudiadas en el capítulo 10. De no ser así, puede utilizarse un procedimiento conocido como prueba exacta de Fisher.³⁵ Esta prueba es estudiada e ilustrada por Daniel.¹⁵

La prueba de la mediana se aplica lógicamente al caso en que se desea probar la hipótesis nula de que $k \geq 3$ muestras son de poblaciones con medianas iguales. Para esta prueba, puede construirse una tabla de contingencia de $2 \times k$ utilizando las frecuencias que caen por arriba y por debajo de la mediana calculada a partir de muestras combinadas. Si se satisfacen las condiciones para el tamaño de la muestra y las frecuencias esperadas, puede calcularse X^2 y compararse con el valor crítico de χ^2 con $k - 1$ grados de libertad. Senders³³ y Conover⁶ dan ejemplos numéricos para el caso en que intervienen más de dos muestras.

Ejercicios

- 11.4.1 Se revisaron quince expedientes de pacientes de dos hospitales y se asignó una calificación diseñada para estimar el nivel de los cuidados recibidos. Las calificaciones fueron las siguientes:

Hospital A: 99, 85, 73, 98, 83, 88, 99, 80, 74, 91, 80, 94, 94, 98, 80

Hospital B: 78, 74, 69, 79, 57, 78, 79, 68, 59, 91, 89, 55, 60, 55, 79

¿Se concluiría, al nivel de significación de .05, que las medianas de las dos poblaciones son distintas? Determine el valor p .

- 11.4.2 Se obtuvieron los siguientes valores de albúmina en el suero de 17 personas normales y 13 hospitalizadas.

¿Se concluiría, al nivel de significación de .05, que las medianas de las dos poblaciones muestreadas son distintas? Determine el valor p .

Albúmina en suero (g/100 ml)			
Personas normales		Personas hospitalizadas	
2.4	3.0	1.5	3.1
3.5	3.2	2.0	1.3
3.1	3.5	3.4	1.5
4.0	3.8	1.7	1.8
4.2	3.9	2.0	2.0
3.4	4.0	3.8	1.5
4.5	3.5	3.5	
5.0	3.6		
2.9			

11.5 LA PRUEBA DE MANN-WHITNEY

La prueba de la mediana analizada en la sección anterior no utiliza toda la información presente en las dos muestras cuando la variable de interés se mide por lo menos en una escala ordinal. Reducir el contenido de información de una observación para concluir si cae o no por arriba o por debajo de la mediana común, es desperdiciar información. Si, para probar la hipótesis deseada, se cuenta con un procedimiento que utilice más de la información inherente en los datos, dicho procedimiento debe utilizarse siempre que sea posible. Este procedimiento no paramétrico que puede utilizarse con frecuencia en lugar de la prueba de la mediana es la prueba de Mann-Whitney.³⁶ Dado que esta prueba se basa en los rangos de las observaciones, utiliza más información que la prueba de la mediana.

Las suposiciones que fundamentan la prueba de Mann-Whitney son las siguientes:

1. Las dos muestras, de tamaños n y m , respectivamente, que se utilizan para el análisis se han extraído independientemente y al azar de sus poblaciones respectivas.
2. La escala de medición es por lo menos ordinal.
3. Si las poblaciones son diferentes, difieren sólo en lo que respecta a sus medianas.

Cuando se satisfacen estas suposiciones, puede probarse la hipótesis nula de que las dos poblaciones tienen medianas iguales contra

cualquiera de tres alternativas posibles: 1) las poblaciones no tienen medianas iguales (prueba bilateral), 2) la mediana de la población 1 es mayor que la mediana de la población 2 (prueba unilateral), o bien, 3) la mediana de la población 1 es menor que la mediana de la población 2 (prueba unilateral). Si las dos poblaciones son simétricas, de modo que dentro de cada población la media y la mediana son las mismas, las conclusiones a las que se llegan respecto a las medias de las dos poblaciones se aplicarán también a las medianas de ambas poblaciones. El siguiente ejemplo ilustra el uso de la prueba de Mann-Whitney.

Ejemplo 11.5.1

En un experimento diseñado para estimar los efectos de la inhalación prolongada de óxido de cadmio, 15 animales de laboratorio sirvieron de sujetos para el experimento, mientras que 10 animales similares sirvieron de controles. La variable de interés fue el nivel de hemoglobina después del experimento. Los resultados se muestran en la tabla 11.5.1. Se desea saber si puede concluirse que la inhalación prolongada de óxido de cadmio disminuye el nivel de hemoglobina.

Tabla 11.5.1 Determinaciones de hemoglobina (gramos) en 25 animales de laboratorio.

<i>Animales expuestos (X)</i>	<i>Animales no Expuestos (Y)</i>
14.4	17.4
14.2	16.2
13.8	17.1
16.5	17.5
14.1	15.0
16.6	16.0
15.9	16.9
15.6	15.0
14.1	16.3
15.3	16.8
15.7	
16.7	
13.7	
15.3	
14.0	

Las hipótesis nula y alternativa son las siguientes:

$$H_0: M_X \geq M_Y$$

$$H_A: M_X < M_Y$$

donde M_X es la mediana de una población de animales expuestos al óxido de cadmio y M_Y es la mediana de una población de animales no expuesta a esta sustancia. Supóngase que $\alpha = .05$.

Para calcular la estadística de prueba, se combinan las dos muestras y se acomodan por rangos todas las observaciones, desde las más pequeñas hasta las más grandes, teniendo presente a cual muestra pertenece cada observación. Se asignan observaciones similares a un rango

Tabla 11.5.2 Datos y rangos originales para el ejemplo 11.5.1.

<i>X</i>	<i>Rango</i>	<i>Y</i>	<i>Rango</i>
13.7	1		
13.8	2		
14.0	3		
14.1	4.5		
14.1	4.5		
14.2	6		
14.4	7		
		15.0	8.5
		15.0	8.5
15.3	10.5		
15.3	10.5		
15.6	12		
15.7	13		
15.9	14		
		16.0	15
		16.2	16
		16.3	17
16.5	18		
16.6	19		
16.7	20		
		16.8	21
		16.9	22
		17.1	23
		17.4	24
		17.5	25
Total	145		

igual a la media de las posiciones del rango para el cual se establecieron. Los resultados de este paso se muestran en la tabla 11.5.2.

La estadística de prueba es

$$T = S - \frac{n(n+1)}{2} \quad (11.5.1)$$

donde n es el número de observaciones de la muestra X y S la suma de los rangos asignados a las observaciones de la muestra de la población de valores de X . La elección de los valores de la muestra que se marcan con X es arbitraria.

Si la mediana de la población X es, en efecto, más pequeña que la mediana de la población Y , como se especifica en la hipótesis alternativa, es de esperar (para muestras de igual tamaño) que la suma de los rangos asignados a las observaciones de la población X sea menor que la suma de los rangos asignados a las observaciones de la población Y . La estadística de prueba está basada en este razonamiento en tal forma que un valor de T suficientemente pequeño causará que se rechace la hipótesis $H_0: M_X \geq M_Y$.

Para el presente ejemplo, la regla de decisión es:

Se rechaza $H_0: M_X \geq M_Y$ si la T calculada es menor que W_α , donde W_α es el valor crítico de T obtenido al consultar la tabla M del apéndice con n , el número de observaciones de X ; m , el número de observaciones de Y ; y α , el nivel de significación elegido.

Para el ejemplo se tiene que, como se muestra en la tabla 11.5.2, $S = 145$, de modo que

$$T = 145 - \frac{15(15+1)}{2} = 25$$

Cuando se entra a la tabla M con $n = 15$, $m = 10$ y $\alpha = .05$, se encuentra que el valor crítico de W_α es de 45. Dado que $25 < 45$, se rechaza H_0 , y se concluye que M_X es menor que M_Y . De donde se deduce que la inhalación prolongada de óxido de cadmio sí disminuye el nivel de hemoglobina.

Dado que $22 < 25 < 30$, se tiene para esta prueba que $.005 > p > .001$.

Cuando n o m es mayor que 20, no puede utilizarse la tabla M del apéndice para obtener los valores críticos de la prueba de Mann-Whitney. Cuando este es el caso, puede calcularse lo siguiente

$$z = \frac{T - mn/2}{\sqrt{nm(n+m+1)/12}} \quad (11.5.2)$$

y se compara el resultado, en significación con los valores críticos de la distribución normal unitaria.

Si se iguala una gran proporción de las observaciones, puede utilizarse un factor de corrección propuesto por Noether.³⁷

Si se utiliza el procedimiento de Mann-Whitney para probar que

$$H_0: M_X \leq M_Y$$

contra la alternativa

$$H_A: M_X > M_Y$$

los valores de T lo suficientemente grandes causarán el rechazo de la hipótesis, de modo que la regla de decisión es:

Se rechaza $H_0: M_X \leq M_Y$ si la T calculada es mayor que $w_{1-\alpha}$, donde $w_{1-\alpha} = nm - W_\alpha$.

Para el caso de una prueba bilateral con

$$H_0: M_X = M_Y$$

$$H_A: M_X \neq M_Y$$

los valores de T calculados que sean lo suficientemente grandes o suficientemente pequeños causarán el rechazo de H_0 . La regla de decisión para este caso es entonces:

Se rechaza $H_0: M_X = M_Y$ si el valor de T calculado es menor que $w_{\alpha/2}$ o mayor que $w_{1-\alpha/2}$, donde $w_{\alpha/2}$ es el valor crítico de T para n , m y $\alpha/2$, dado en la tabla M del apéndice y $w_{1-\alpha/2} = nm - W_{\alpha/2}$.

Ejercicios

11.5.1 Los siguientes valores son las respuestas de los anticuerpos de personas que han recibido una dosis de refuerzo de uno de dos tipos de vacunas contra la rabia.

Tipo 1 (X): 1.25, 5.30, 1.70, 1.00, 8.50, 3.75, 8.10, 2.25, 5.6, 7.85

Tipo 2 (Y): .57, 3.90, 8.20, 1.20, 1.70, 1.00, 4.55, 5.20, 2.16, 1.90, 4.6

¿Puede concluirse con base en estos datos que los dos tipos de vacuna difieren en sus efectos? Sea $\alpha = .05$ y encuentre el valor p .

- 11.5.2 Los valores siguientes son los tiempos (en minutos) pasados en la sala de operaciones por 20 personas sometidas al mismo procedimiento quirúrgico. Once de las personas fueron pacientes del hospital A y 9 fueron del hospital B.

Hospital A: 35, 30, 33, 39, 41, 29, 30, 36, 45, 40, 31

Hospital B: 45, 38, 42, 50, 48, 51, 32, 37, 46

Con base en estos datos, ¿puede concluirse que, para el mismo procedimiento quirúrgico, los pacientes del hospital B tienden a permanecer más tiempo en la sala de operaciones que los pacientes del hospital A? Sea $\alpha = .01$ y encuentre el valor p .

11.6 LA PRUEBA DE BONDAD DE AJUSTE DE KOLMOGOROV-SMIRNOV

Cuando se desea determinar qué tan bien se conforma la distribución de los datos de la muestra a alguna distribución teórica, una prueba conocida como prueba de bondad de ajuste de Kolmogorov-Smirnov proporciona una alternativa para la prueba ji-cuadrada de bondad del ajuste, estudiada en el capítulo 10. Esta prueba debe su nombre a A. Kolmogorov y a N. V. Smirnov, dos matemáticos rusos que introdujeron dos pruebas estrechamente relacionadas en la década de 1930.

El trabajo de Kolmogorov³⁸ se refiere al caso de una muestra, como se analiza aquí. El trabajo de Smirnov³⁹ trata del caso que comprende dos muestras, en las cuales el interés se centra en probar la hipótesis de que las distribuciones de las dos poblaciones originales son idénticas. La prueba para la primera situación suele conocerse como prueba para una muestra de Kolmogorov-Smirnov. La prueba para el caso de dos muestras, conocida en general como prueba para dos muestras de Kolmogorov-Smirnov, no se estudiará aquí. Quienes estén

interesados en este tema deben consultar las referencias de Conover,⁶ Gibbons^{2, 10} y Daniel.¹⁵

Al utilizar la prueba de bondad del ajuste de Kolmogorov-Smirnov, se hace una comparación entre alguna función de distribución acumulada y teórica, $F_T(x)$, y la función de distribución acumulada de una muestra, $F_S(x)$. La muestra es una muestra aleatoria de una población con función de distribución acumulada, $F(x)$, desconocida. Se recordará (sección 3.2) que una función de distribución acumulada da la probabilidad de que X sea igual a o menor que un valor particular, x . Es decir, por medio de la función de distribución acumulada de la muestra, $F_S(x)$, puede determinarse $P(X \leq x)$. Si existe una estrecha concordancia entre las distribuciones acumuladas teórica y de la muestra, se apoya la hipótesis de que la muestra se extrajo de la población con la función de distribución acumulada que se especifica, $F_T(x)$. Sin embargo, si existe una discrepancia entre las funciones de distribución acumulada teórica y observada, demasiado grande como para ser atribuida únicamente al azar, se rechaza la hipótesis, cuando H_0 es verdadera.

La diferencia entre la función de distribución, acumulada y teórica, $F_T(x)$, y la función de distribución acumulada de la muestra, $F_S(x)$, se mide por medio de la estadística D , que es la distancia vertical máxima entre $F_S(x)$ y $F_T(x)$. Cuando resulta apropiada una prueba bilateral, es decir, cuando las hipótesis son:

$$\begin{aligned} H_0 : F(x) &= F_T(x), \text{ para todo } x \text{ desde } -\infty \text{ hasta } +\infty \\ H_A : F(x) &\neq F_T(x), \text{ para al menos un } x \end{aligned}$$

la estadística es

$$D = \sup_x |F_S(x) - F_T(x)| \quad (11.6.1)$$

la cual se lee, “ D es igual al supremo (máximo) sobre todos los x , del valor absoluto de la diferencia $F_S(x)$ menos $F_T(x)$ ”.

La hipótesis nula se rechaza al nivel de significación α si el valor calculado de D excede al valor mostrado en la tabla N para $1 - \alpha$ (prueba bilateral) y el tamaño de la muestra n . Son posibles las pruebas en las que la alternativa es unilateral. Gibbons¹⁰ y Goodman^{9,10} dan ejemplos numéricos.

Las suposiciones que fundamentan la prueba de Kolmogorov-Smirnov incluyen las siguientes:

1. La muestra es aleatoria.
2. La distribución $F_T(x)$ establecida en la hipótesis es continua.

Noether⁴¹ ha demostrado que cuando los valores de D se basan en una distribución teórica discreta, la prueba es conservadora. Cuando la prueba se utiliza entonces con datos discretos, el investigador debe tener presente que la probabilidad real de cometer un error del tipo I es, al menos, igual a α , el nivel de significación establecido. La prueba es también conservadora si tienen que estimarse uno o más parámetros a partir de los datos de la muestra.

Ejemplo 11.6.1

Las determinaciones de glucosa en sangre de 36 hombres adultos no obesos, en ayunas y aparentemente sanos, se muestran en la tabla 11.6.1. Se desea probar la hipótesis nula de que estos datos provienen de una población distribuida normalmente, con una media de 80 y una desviación estándar de 6. Las hipótesis apropiadas son las siguientes:

$$H_0: F(x) = F_T(x), \text{ para todo } x \text{ desde } -\infty \text{ hasta } +\infty$$

$$H_A: F(x) \neq F_T(x), \text{ para al menos un } x$$

El primer paso a seguir es calcular los valores de $F_S(x)$ como se muestra en la tabla 11.6.2.

Los valores de $F_T(x)$ se obtienen convirtiendo primero cada valor observado de x a un valor de la variable normal unitaria z . A partir de la tabla F del apéndice se encuentra entonces el área entre $-\infty$ y z . Con estas áreas, pueden calcularse los valores de $F_T(x)$. El proce-

Tabla 11.6.1 Niveles de glucosa en la sangre (mg/100 ml) de 36 hombres adultos no obesos, en ayunas y aparentemente sanos.

75	92	80	80	84	72
84	77	81	77	75	81
80	92	72	77	78	76
77	86	77	92	80	78
68	78	92	68	80	81
87	76	80	87	77	86

Tabla 11.6.2 Valores de $F_S(x)$ para el ejemplo 11.6.1.

x	Frecuencia	Frecuencia acumulada	$F_S(x)$
68	2	2	.0556
72	2	4	.1111
75	2	6	.1667
76	2	8	.2222
77	6	14	.3889
78	3	17	.4722
80	6	23	.6389
81	3	26	.7222
84	2	28	.7778
86	2	30	.8333
87	2	32	.8889
92	4	36	1.0000
	36		

Tabla 11.6.3 Pasos del cálculo de $F_T(x)$ para el ejemplo 11.6.1.

x	$z = (x - 80)/6$	$F_T(x)$
68	-2.00	.0228
72	-1.33	.0918
75	-.83	.2033
76	-.67	.2514
77	-.50	.3085
78	-.33	.3707
80	.00	.5000
81	.17	.5675
84	.67	.7486
86	1.00	.8413
87	1.17	.8790
92	2.00	.9772

dimiento, que es similar al utilizado para obtener las frecuencias relativas esperadas en la prueba ji-cuadrada de bondad del ajuste, se resume en la tabla 11.6.3.

La estadística de prueba D puede calcularse algebraicamente, o bien, puede determinarse gráficamente midiendo la distancia vertical




Figura 11.6.1 $F_S(x)$ y $F_T(x)$ para el ejemplo 11.6.1.

máxima entre las curvas de $F_S(x)$ y $F_T(x)$ en una gráfica. Las gráficas de las dos distribuciones se muestran en la figura 11.6.1.

El examen de las gráficas de $F_S(x)$ y $F_T(x)$ revela que $D \approx .16 = (.72 - .56)$. Utilizando como referencia la tabla N se observa que una D compuesta de .16 no es significativa a cualquier nivel razonable. Por lo tanto, no puede rechazarse H_0 . La muestra puede haber provenido de la distribución especificada. Dado que se tiene una prueba bilateral, y como $.16 < .174$, se tiene que $p > .20$.

Cálculase ahora el valor de D algebraicamente. Los valores posibles de $|F_S(x) - F_T(x)|$ se muestran en la tabla 11.6.4. Esta tabla muestra que el valor exacto de D es de .1547.

El lector debe tener en cuenta que al determinar el valor de D , no siempre es suficiente calcular y elegir de entre los valores posibles de $|F_S(x) - F_T(x)|$. La distancia vertical máxima entre $F_S(x)$ y $F_T(x)$ puede no ser un valor observado, x , pero sí algún otro valor de X . Esta situación se ilustra en la figura 11.6.2. Se observa que si sólo se consideran los valores de $|F_S(x) - F_T(x)|$ de los puntos terminales de la izquierda de las barras horizontales, se calcularía erróneamente el valor de D como $|.2 - .4| = .2$. Sin embargo, puede observarse al examinar la gráfica, que la distancia vertical máxima entre $F_S(x)$ y $F_T(x)$ está en el punto terminal derecho de la barra horizontal que se origina en el punto que corresponde a $x = .4$, por lo que el valor correcto de D es de $|.5 - .2| = .3$.

Puede determinarse algebraicamente el valor correcto de D al

Tabla 11.6.4 Cálculo de $|F_S(x) - F_T(x)|$ para el ejemplo 11.6.1.

x	$F_S(x)$	$F_T(x)$	$ F_S(x) - F_T(x) $
68	.0556	.0228	.0328
72	.1111	.0918	.0193
75	.1667	.2033	.0366
76	.2222	.2514	.0292
77	.3889	.3085	.0804
78	.4722	.3707	.1015
80	.6389	.5000	.1389
81	.7222	.5675	.1547
84	.7778	.7486	.0292
86	.8333	.8413	.0080
87	.8889	.8790	.0099
92	1.0000	.9772	.0228
—			—

calcular, además de las diferencias $|F_S(x) - F_T(x)|$, las diferencias $|F_S(x_{i-1}) - F_T(x_i)|$ para todos los valores de $i = 1, 2, \dots, r + 1$, donde r = el número de diferentes valores de x y $F_S(x_0) = 0$. El valor correcto de la estadística de prueba será entonces

$$D = \max_{1 \leq i \leq r} \{ \max [|F_S(x_i) - F_T(x_i)|, |F_S(x_{i-1}) - F_T(x_i)|] \} \quad (11.6.2)$$

Las ventajas y desventajas de la prueba de bondad de ajuste de Kolmogorov-Smirnov, en comparación con la prueba ji-cuadrada, han sido analizadas por Goodman,⁴⁰ Massey,⁴² Birnbaum⁴³ y Slakter.⁴⁴ Los siguientes puntos son algunos puntos de comparación importantes.

1. La prueba de Kolmogorov-Smirnov no requiere que las observaciones se agrupen como es el caso con la prueba ji-cuadrada. La consecuencia de esta diferencia es que la prueba de Kolmogorov-Smirnov utiliza toda la información presente en un conjunto de datos.

2. La prueba de Kolmogorov-Smirnov puede utilizarse con cualquier tamaño de muestra. Se recordará que se requieren ciertos tamaños mínimos de las muestras para el uso de la prueba ji-cuadrada.
3. Como se ha hecho notar, la prueba de Kolmogorov-Smirnov no es aplicable cuando los parámetros tienen que estimarse a partir de la muestra. La prueba ji-cuadrada puede utilizarse en estos casos, reduciendo los grados de libertad en 1, para cada parámetro estimado.
4. Ya se ha mencionado el problema de la suposición de una distribución teórica continua.




Figura 11.6.2 Gráfica de datos ficticios que indican los cálculos correctos de D .

Ejercicios

- 11.6.1 Los pesos durante la autopsia, del cerebro de 25 adultos que sufrían de cierta enfermedad, fueron los siguientes:

Peso del cerebro (gramos)				
859	1073	1041	1166	1117
962	1051	1064	1141	1202
973	1001	1016	1168	1255
904	1012	1002	1146	1233
920	1039	1086	1140	1348

¿Puede concluirse a partir de estos datos que la población muestreada no está distribuida normalmente con una media de 1050 y una desviación estándar de 50? Determine el valor p para esta prueba.

- 11.6.2 Los cocientes intelectuales de una muestra de 30 adolescentes arrestados por abuso de drogas en cierta jurisdicción metropolitana fueron los siguientes:

Cociente intelectual					
95	100	91	106	109	110
98	104	97	100	107	119
92	106	103	106	105	112
101	91	105	102	101	110
101	95	102	104	107	118

¿Proporcionan estos datos evidencia suficiente de que la población muestreada de las calificaciones de los coeficientes de inteligencia no está distribuida normalmente con media de 105 y desviación estándar de 10? Determine el valor p .

- 11.6.3 Para una muestra de personas aparentemente sanas que sirvieron de control en un experimento, se registraron las siguientes lecturas de presión sistólica sanguínea al inicio del experimento:

162	177	151	167
130	154	179	146
147	157	141	157
153	157	134	143
141	137	151	161

¿Puede concluirse con base en estos datos que la población de presiones sanguíneas de la cual se extrajo la muestra no está distribuida normalmente con media de 150 y desviación estándar de 12? Determine el valor p .

11.7 EL ANÁLISIS DE VARIANCIA, CON UN SOLO CRITERIO DE CLASIFICACIÓN POR RANGOS, DE KRUSKAL-WALLIS

En el capítulo 7 se estudia cómo puede utilizarse el análisis de variancia con un solo criterio de clasificación para probar la hipótesis nula de que las medias de varios grupos son iguales. Cuando no se satisfacen las suposiciones que fundamentan esta técnica, es decir, cuando las poblaciones de las cuales se extraen las muestras no están distribuidas normalmente con variancias iguales, o cuando los datos para el análisis constan sólo de rangos, puede utilizarse una alternativa no paramétrica para el análisis de variancia con un solo criterio de clasificación para probar la hipótesis de parámetros con igual localización. Como se señaló en la sección 11.4, la prueba de la mediana puede ampliarse para acomodar la situación que comprenda más de dos grupos. Sin embargo, una deficiencia de esta prueba es el hecho de que sólo utiliza una pequeña cantidad de la información disponible, es decir, si las observaciones están o no por arriba o por debajo de un solo número, el cual es la mediana de las muestras combinadas. Se cuenta con varias analogías no paramétricas para analizar la variancia, que utilizan más información, tomando en cuenta la magnitud de cada observación relativa a la magnitud de cualquier otra observación. Quizá el más conocido de estos procedimientos es el análisis de variancia con un solo criterio de clasificación por rangos de Kruskal-Wallis.⁴⁵

La aplicación de esta prueba comprende los siguientes pasos.

1. Las $n_1, n_2, \dots, n_k$ observaciones de los k grupos se combinan en una sola serie de tamaño n y se disponen en orden de magni-

tud desde la más pequeña hasta la más grande. Las observaciones se sustituyen entonces por rangos desde 1, que es el asignado a la observación menor, hasta n , que se asigna a la observación mayor. Cuando dos o más observaciones tienen el mismo valor, a cada una de ellas se le da la media de los rangos con los cuales está relacionado.

2. Los rangos asignados a las observaciones en cada uno de los k grupos se suman por separado para dar k sumas de rangos.
3. Se calcula la estadística de prueba

$$H = \frac{12}{n(n+1)} \sum_{j=1}^k \frac{R_j^2}{n_j} - 3(n+1) \quad (11.7.1)$$

En la ecuación 11.7.1,

k = el número de grupos.

n_j = el número de observaciones en el j -ésimo grupo.

n = el número de observaciones en todos los grupos combinados.

R_j = la suma de los rangos en el j -ésimo grupo.

4. Cuando se tienen tres grupos y cinco o menos observaciones en cada grupo, la significación de la H calculada se determina consultando la tabla O del apéndice. Cuando hay más de cinco observaciones en uno o más de los grupos, H se compara con los valores tabulados de la χ^2 con $k - 1$ grados de libertad. Lo adecuado de la aproximación ji-cuadrada para muestras pequeñas es tratado por Gabriel y Lachenbruch.⁴⁶

Ejemplo 11.7.1

Se estudiaron los efectos de dos medicamentos en el tiempo de reacción a cierto estímulo en tres grupos de animales de laboratorio. El grupo III sirvió como control, mientras que los animales del grupo I fueron tratados con el medicamento A y los del grupo II con el medicamento B antes de la aplicación del estímulo. La tabla 11.7.1 muestra los tiempos de reacción, en segundos, de los 13 animales.

¿Puede concluirse que las tres poblaciones representadas por las tres muestras difieren con respecto al tiempo de reacción? Puede llegarse a esa conclusión si puede rechazarse la hipótesis nula de que las tres poblaciones no difieren en sus tiempos de reacción.

Tabla 11.7.1 Tiempo de reacción, en segundos, de 13 animales de laboratorio.

<i>I</i>	<i>Grupo</i>	
	<i>II</i>	<i>III</i>
17	8	2
20	7	5
40	9	4
31	8	3
35		

Tabla 11.7.2 Datos de la tabla 11.7.1 sustituidos por rangos

<i>I</i>	<i>Grupo</i>	
	<i>II</i>	<i>III</i>
9	6.5	1
10	5	4
13	8	3
11	6.5	2
12		

$$R_1 = 55 \quad R_2 = 26 \quad R_3 = 10$$

Cuando se combinan los tres grupos en una sola serie y se les asigna un rango, puede construirse la tabla de rangos que se muestra en la tabla 11.7.2.

La hipótesis nula implica que las observaciones en las tres muestras constituyen una sola muestra de tamaño 13 de una sola población. Si este es el caso, es de esperar que los rangos estén bien distribuidos entre los tres grupos. En consecuencia es de esperar que la suma total de los rangos esté dividida entre los tres grupos, proporcionalmente al tamaño del grupo. Las desviaciones respecto a estas condiciones se reflejan en la magnitud de la estadística de prueba H . La hipótesis nula se rechazará si el valor calculado de H es tan grande que la probabilidad de obtener un valor de esa magnitud o mayor, cuando H_0 es verdadera, sea igual a, o menor que el nivel de importancia elegido, α .

A partir de los datos de la tabla 11.7.2 y la ecuación 11.7.1 se obtiene que

$$H = \frac{12}{13(13+1)} \left[\frac{(55)^2}{5} + \frac{(26)^2}{4} + \frac{(10)^2}{4} \right] - 3(13+1) \\ = 10.68$$

La tabla O muestra que cuando los n_j son 5, 4 y 4, la probabilidad de obtener un valor de $H \geq 10.68$ es menor que .009. Puede rechazarse la hipótesis nula al nivel de significación de .01 y puede concluirse que existe una diferencia en el tiempo promedio de reacción entre las tres poblaciones. Para esta prueba, $p < .009$.

Se notará que a dos valores de la muestra II se le asignó el rango de 6.5. Puede ajustarse el valor de H respecto a esta igualdad numérica dividiéndolo entre

$$1 - \frac{\sum T}{n^3 - n} \quad (11.7.2)$$

donde $T = t^3 - t$. La letra t se utiliza para designar el número de observaciones iguales en el número en un grupo de valores con igual número. En el presente ejemplo, existe sólo un grupo de valores iguales en número pero en general, puede haber varios grupos de valores iguales en número que conduzcan a varios valores de T . Dado que sólo se tuvieron dos observaciones de igual valor numérico en el grupo, se tiene que $T = 2^3 - 2 = 6$ y $\sum T = 6$, de modo que la expresión 11.7.2 es

$$1 - \frac{6}{13^3 - 13} = .9973$$

y

$$\frac{H}{1 - \frac{\sum T}{n^3 - n}} = \frac{10.68}{.9973} = 10.71$$

lo cual, de hecho, también es significativo al nivel de significación de .01.

Como es el caso aquí, el efecto del ajuste por empates es por lo general insignificante. Nótese también que el efecto del ajuste es in-

Tabla 11.7.3 Valor neto del capital en equipo por cama por tipo de hospital.

Tipo de hospital				
A	B	C	D	E
\$1735(11)	\$5260(35)	\$2790(20)	\$3475(26)	\$6090(40)
1520(2)	4455(28)	2400(12)	3115(22)	6000(38)
1476(1)	4480(29)	2655(16)	3050(21)	5894(37)
1688(7)	4325(27)	2500(13)	3125(23)	5705(36)
1702(10)	5075(32)	2755(19)	3275(24)	6050(39)
2667(17)	5225(34)	2592(14)	3300(25)	6150(41)
1575(4)	4613(30)	2601(15)	2730(18)	5110(33)
1602(5)	4887(31)	1648(6)		
1530(3)		1700(9)		
1698(8)				
$R_1 = 68$	$R_2 = 246$	$R_3 = 124$	$R_4 = 159$	$R_5 = 264$

crementar H , de modo que si la H no ajustada es significativa al nivel de significación elegido, no es necesario aplicar el ajuste.

A continuación, se ilustrará el procedimiento aplicable cuando se tienen más de tres grupos y, al menos, uno de los n_j es mayor que 5.

Ejemplo 11.7.2

La tabla 11.7.3 indica el valor neto del capital en equipo por cama para cada una de las muestras tomadas en cinco hospitales. Se desea determinar, por medio de la prueba de Kruskal-Wallis, si puede concluirse que el valor neto promedio del capital en equipo por cama difiere entre los cinco tipos de hospital. Los rangos de los 41 valores, junto con la suma de los rangos para cada grupo, se presentan en dicha tabla.

A partir de las sumas de los rangos, se tiene que

$$H = \frac{12}{41(41 + 1)} \left[\frac{(68)^2}{10} + \frac{(246)^2}{8} + \frac{(124)^2}{9} + \frac{(159)^2}{7} + \frac{(264)^2}{7} \right] - 3(41 + 1)$$
$$= 36.39$$

Consultando la tabla I con $k - 1 = 4$ grados de libertad, se encuentra que la probabilidad de obtener un valor de H tan grande o mayor

que 36.39, debido únicamente al azar, cuando no existe diferencia entre los grupos, es menor que .005. Se concluye entonces que existe una diferencia entre los grupos con respecto al valor promedio de la variable de interés.

Ejercicios

Para los ejercicios siguientes, se lleve a cabo la prueba al nivel de importancia indicado y determine el valor p .

- 11.7.1 La siguiente tabla indica los niveles del residuo de plaguicida (ppb) en las muestras de sangre de cuatro grupos de personas. Utilice la prueba de Kruskal-Wallis para probar, al nivel de significación de .05, la hipótesis nula de que no existe diferencia entre los grupos con respecto al nivel promedio de residuo de plaguicida.

Grupo			
A	B	C	D
10	4	15	7
37	35	5	11
12	32	10	10
31	19	12	8
11	33	6	2
9	18	6	5
44	11	9	4
12	7	11	5
15	32	9	2
42	17	14	6
23	8	15	3

- 11.7.2 Los siguientes valores son los honorarios diarios promedio cobrados a los pacientes hospitalizados para cierta intervención quirúrgica, obtenidos por muestras de hospitales localizados en tres diferentes partes del país.
¿Puede concluirse al nivel de significación de .05 que los grupos difieren con respecto a los honorarios diarios promedio?

	I	Grupo II	III
	\$80.75	\$58.63	\$84.21
	78.15	72.70	101.76
	85.40	64.20	107.74
	71.94	62.50	115.30
	82.05	63.24	126.15

- 11.7.3 Utilice como referencia los datos de la tabla 7.2.1 (ejemplo 7.2.1) y aplique la prueba de Kruskal-Wallis. Compare los resultados obtenidos con los que se obtuvieron cuando se utilizó la prueba F .
- 11.7.4 Utilice como referencia el ejercicio 7.2.1 y aplique la prueba de Kruskal-Wallis.
- 11.7.5 Utilice como referencia el ejercicio 7.2.2 y aplique la prueba de Kruskal-Wallis.
- 11.7.6 Utilice como referencia el ejercicio 7.2.3 y aplique la prueba de Kruskal-Wallis.
- 11.7.7 Utilice como referencia el ejercicio 7.2.4 y aplique la prueba de Kruskal-Wallis.

11.8 EL ANÁLISIS DE VARIANCIA, CON DOS CRITERIOS DE CLASIFICACIÓN POR RANGOS DE FRIEDMAN

Así como en alguna ocasión puede tenerse la necesidad de una analogía no paramétrica para el análisis paramétrico de variancia con un solo criterio de clasificación, también puede ser necesario analizar los datos de una clasificación con dos criterios, mediante métodos no paramétricos análogos al análisis de variancia con dos criterios de clasificación. Puede surgir esta necesidad debido a que no se satisfacen las suposiciones necesarias para el análisis paramétrico de la variancia, ya que la escala de medición utilizada es “frágil” o porque los resultados se necesitan rápidamente. Una prueba que suele utilizarse en estos casos es el análisis de variancia con dos criterios de clasificación por rangos, de Friedman.^{47, 48} Esta prueba es apropiada siempre que los datos se midan, al menos, en una escala ordinal y puedan disponerse significativamente en una clasificación con dos criterios, como se ha-

ce en el experimento en bloques aleatorizados **que se** estudió en el capítulo 7. El ejemplo siguiente ilustra este procedimiento.

Ejemplo 11.8.1

Se pidió a nueve fisioterapeutas que clasificaran tres modelos de estimuladores eléctricos de bajo voltaje según su preferencia. Un rango de 1 indica la primera preferencia. Los resultados se presentan en la tabla 11.8.1.

La hipótesis nula que va a probarse es que no existe diferencia en las preferencias por los modelos. La hipótesis alternativa es que los modelos **no son preferidos por igual**. Mediante la prueba de Friedman, será posible determinar si resulta razonable suponer que las columnas de rangos **se han extraído de la misma población**. Si la hipótesis nula es verdadera, debe esperarse que la distribución de los rangos observada dentro de cualquiera de las columnas sea el producto de factores aleatorios y, en consecuencia, debe esperarse que los números 1, 2 y 3 se presenten aproximadamente con la misma frecuencia en cada columna. Si, por otra parte, la hipótesis nula es falsa (es decir, si los modelos **no son preferidos igualmente**), debe esperarse una preponderancia de rangos relativamente altos (o bajos) por lo menos en una columna. Esta condición se reflejaría en las sumas de los rangos.

Tabla 11.8.1 Rangos asignados por fisioterapeutas a tres modelos de estimulador eléctrico de bajo voltaje.

Terapeuta	Modelo		
	A	B	C
1	2	3	1
2	2	3	1
3	2	3	1
4	1	3	2
5	3	2	1
6	1	2	3
7	2	3	1
8	1	3	2
9	1	3	2
R_j	15	25	14

La prueba de Friedman indicará si las sumas de los rangos que se observan son o no tan distintas que no sea probable que sean un resultado del azar, cuando H_0 es verdadera.

Dado que los datos consisten ya en categorías dentro de los bloques (renglones), el primer paso es sumar los rangos dentro de cada columna (tratamiento). Estas sumas son los R_j que se muestran en la tabla 11.8.1. Una estadística de prueba, denotada por Friedman como χ_r^2 , se calcula como sigue:

$$\chi_r^2 = \frac{12}{nk(k+1)} \sum_{j=1}^k (R_j)^2 - 3n(k+1) \quad (11.8.1)$$

donde n = el número de renglones (bloques) y k = el número de columnas (tratamientos). Los valores críticos para diversos valores de n y k se dan en la tabla P.

Para el ejemplo ilustrativo, se calcula

$$\begin{aligned} \chi_r^2 &= \frac{12}{9(3)(3+1)} [(15)^2 + (25)^2 + (14)^2] - 3(9)(3+1) \\ &= 8.222 \end{aligned}$$

Cuando se consulta la tabla Pa del apéndice, se encuentra que la probabilidad de obtener un valor de χ_r^2 tan grande como 8.222 debido únicamente al azar, cuando la hipótesis nula es verdadera, es de .016. Por lo tanto, puede rechazarse la hipótesis nula, y concluir que los tres modelos de estimulador eléctrico de bajo voltaje no se prefieren igualmente. Para esta prueba, $p = .016$.

Cuando los datos originales consisten en mediciones sobre una escala de intervalos o de razones, en lugar de rangos, se asignan rangos a las mediciones en base a sus magnitudes relativas dentro de los bloques. Si hay valores iguales, a cada valor se le asigna la media de todos los rangos que intervienen.

Cuando los valores de k , n o ambos exceden a los dados en la tabla P del apéndice, el valor crítico de χ_r^2 se obtiene consultando la tabla de χ^2 (tabla I) con el α elegido y los $k-1$ grados de libertad.

Ejemplo 11.8.2

La tabla 11.8.2 muestra las respuestas, en por ciento de disminución del flujo salival, de 16 animales de laboratorio después de recibir

Tabla 11.8.2 Porcentaje de disminución del flujo salival en animales de laboratorio después de la aplicación de diferentes dosis de atropina.

Número del animal	Dosis de atropina			
	A	B	C	D
1	29(1)	48(2)	75(3)	100(4)
2	72(2)	30(1)	100(3.5)	100(3.5)
3	70(1)	100(4)	86(2)	96(3)
4	54(2)	35(1)	90(3)	99(4)
5	5(1)	43(3)	32(2)	81(4)
6	17(1)	40(2)	76(3)	81(4)
7	74(1)	100(3)	100(3)	100(3)
8	6(1)	34(2)	60(3)	81(4)
9	16(1)	39(2)	73(3)	79(4)
10	52(2)	34(1)	88(3)	96(4)
11	8(1)	42(3)	31(2)	79(4)
12	29(1)	47(2)	72(3)	99(4)
13	71(1)	100(3.5)	97(2)	100(3.5)
14	7(1)	33(2)	58(3)	79(4)
15	68(1)	99(4)	84(2)	93(3)
16	70(2)	30(1)	99(3.5)	99(3.5)
R_j	20	36.5	44	59.5

diferentes niveles de dosis de atropina. En la tabla, se dan también los rangos (entre paréntesis) y la suma de éstos. Se desea saber si puede concluirse que los diferentes niveles de dosis producen respuestas distintas. Es decir, se prueba la hipótesis nula de ninguna diferencia en la respuesta entre los cuatro niveles de la dosis.

A partir de los datos, se calcula que

$$\begin{aligned}\chi_r^2 &= \frac{12}{16(4)(4+1)} [(20)^2 + (36.5)^2 + (44)^2 + (59.5)^2] - 3(16)(4+1) \\ &= 30.32\end{aligned}$$

Al consultar la tabla I se encuentra que, con $k-1=3$ grados de libertad, la probabilidad de obtener un valor de χ_r^2 tan grande como 30.32, debido únicamente al azar, es menor que .005. Se rechaza la hipótesis nula y se concluye que los diferentes niveles de dosis producen respuestas distintas.