

ESTADÍSTICA PARA LA INVESTIGACIÓN BIOMÉDICA

TERCERA EDICIÓN

P. Armitage/G. Berry

$$\chi^2 = \frac{\sum (O-E)^2}{E}$$

HARCOURT
BRACE

ESTADÍSTICA PARA LA INVESTIGACIÓN BIOMÉDICA

P. ARMITAGE

MA, PhD

*Emeritus Professor of Applied Statistics,
University of Oxford*

G. BERRY

MA, PhD

*Professor in Epidemiology and Biostatistics,
University of Sydney*

TERCERA EDICIÓN

HARCOURT
 BRACE

Madrid - Barcelona - Boston - Buenos Aires - Caracas - Filadelfia
Londres - México DF - Santafé de Bogotá - Sidney - Tokio - Toronto

Es una publicación

**HARCOURT
BRACE**



Revisión técnica

Jaume Estruch Peret

Ingeniero químico de la UPC. Barcelona

Versión en español de la tercera edición de la obra original en inglés *Statistical Methods in Medical Research*. Copyright ©MCMXCIV Blackwell Scientific Publications.

© 1997 edición en español

Harcourt Brace de España, S.A.

Juan Álvarez Mendizábal, 3, 2º

28008 Madrid. España

Quedan rigurosamente prohibidas, sin la autorización escrita de los titulares del Copyright, bajo las sanciones establecidas en las leyes, la reproducción parcial o total de esta obra por cualquier medio o procedimiento, comprendidos la reprografía y el tratamiento informático y la distribución de ejemplares de ella mediante alquiler o préstamo público. El infractor puede incurrir en responsabilidad penal y civil.

Harcourt Brace de España, S.A.
Harcourt Brace Publishers International
División Iberoamericana

EdiDE: Coordinación y producción editorial
Casanova 191, 3º 1ª
08036 Barcelona

ISBN edición original: 0-632-03695-8
ISBN edición española: 84-8174-158-2

Depósito legal: M.9433-1997

Impresión: Clamades, S.L.

Índice

Prólogo a la tercera edición	ix
1. El alcance de la estadística	1
1.1. Generalidades, 1	
1.2. Diagramas, 4	
1.3. Tabulación y proceso de datos, 6	
1.4. Resumen de datos numéricos, 13	
1.5. Media y otras medidas de tendencia central, 24	
1.6. Medidas de dispersión, 29	
2. Probabilidad	38
2.1. Significado de la probabilidad, 38	
2.2. Cálculos de probabilidad, 41	
2.3. Distribuciones de probabilidad, 44	
2.4. Valores esperados, 48	
2.5. Distribución binomial, 51	
2.6. Distribución de Poisson, 55	
2.7. Distribución normal (o de Gauss), 62	
2.8. Teorema de Bayes, 66	
2.9. Probabilidad subjetiva, 71	
3. Muestreo	73
3.1. Población y muestra, 73	
3.2. Error de muestreo de una medida, 74	
3.3. Error de muestreo de una proporción, 79	
3.4. Error de muestreo de una variancia, 80	
3.5. Error de muestreo de una diferencia, 83	
3.6. Otras fórmulas para la variancia, 84	
4. La inferencia estadística	87
4.1. Generalidades, 87	
4.2. Tests de significación e intervalos de confianza, 88	
4.3. inferencias a partir de las medias, 93	
4.4. Comparación de dos medias, 99	
4.5. Inferencias a partir de variancias, 107	
4.6. Comparación de dos variancias, 108	
4.7. Inferencias a partir de proporciones, 111	
4.8. Comparación de dos proporciones, 118	
4.9. Tablas 2 x 2 y pruebas de χ^2 , 125	
4.10. Inferencias a partir de recuentos, 133	

4.11.	Comparación de dos recuentos, 136	
4.12.	Probabilidad y métodos bayesianos, 139	
4.13.	Otros métodos bayesianos, 141	
5.	Regresión y correlación	145
5.1.	Asociación, 145	
5.2.	Regresión lineal, 147	
5.3.	Correlación, 153	
5.4.	Errores de muestreo en la regresión y en la correlación, 156	
5.5.	Regresión con respecto a la media, 162	
6.	Planificación de las investigaciones estadísticas	165
6.1.	Generalidades, 165	
6.2.	Planificación de sondeos: estimación de parámetros poblacionales, 166	
6.3.	Estudios para investigar asociaciones, 172	
6.4.	Diseño de experimentos, 176	
6.5.	Ensayos clínicos, 178	
6.6.	El tamaño de una investigación estadística, 184	
7.	Comparación de varios grupos	195
7.1.	Análisis de la variancia de un factor, 195	
7.2.	Método de ponderación, 202	
7.3.	Componentes de la variancia, 206	
7.4.	Comparaciones múltiples, 211	
7.5.	Comparación de varias proporciones: la tabla de contingencia $2 \times k$, 215	
7.6.	Tablas de contingencia generales, 218	
7.7.	Comparación de varias variancias, 220	
7.8.	Comparación de varias frecuencias: test de heterogeneidad de Poisson, 221	
8.	Otros diseños experimentales	224
8.1.	Análisis de la variancia de los factores: bloques aleatorios, 224	
8.2.	Diseño cruzado simple, 231	
8.3.	Diseños factoriales, 235	
8.4.	Cuadrados latinos, 245	
8.5.	Otros diseños incompletos, 250	
8.6.	Diseños en parcelas divididas, 253	
8.7.	Correlación intraclases, 259	
8.8.	Tablas no ortogonales de dos factores: algunos casos sencillos, 261	
9.	Análisis avanzado de datos de regresión lineal	268
9.1.	Aplicación del análisis de la variancia a la regresión, 268	
9.2.	Errores en ambas variables, 273	
9.3.	Rectas que pasan por el origen de regresión (rectas), 275	
9.4.	Regresión en grupos, 276	
9.5.	Análisis de la covariancia, 285	
10.	Mediciones múltiples	295
10.1.	Regresión múltiple, 295	
10.2.	Regresión múltiple en grupos, 317	

10.3.	Regresiones polinómicas y otras regresiones curvilíneas, 323	
10.4.	Regresión múltiple en el análisis de datos no ortogonales, 330	
10.5.	Métodos multivariantes, 332	
10.6.	Series temporales, 354	
10.7.	Mediciones repetidas y curvas de crecimiento, 359	
11.	Edición de datos	364
11.1.	Observaciones preliminares, 364	
11.2.	Transformaciones en general, 364	
11.3.	Transformaciones logarítmicas y por potenciación, 367	
11.4.	Transformaciones para proporciones, 369	
11.5.	Bondad del ajuste de las distribuciones de frecuencias, 372	
11.6.	Observaciones aberrantes (<i>outlying</i>), 377	
12.	Análisis avanzado de datos cualitativos	380
12.1	Introducción, 380	
12.2	Tendencia de las proporciones, 381	
12.3.	Tendencias en tablas de contingencia de mayores dimensiones, 385	
12.4.	Tendencias en recuentos, 388	
12.5.	Otros componentes de la χ^2 , 389	
12.6.	Combinación de tablas 2 x 2, 392	
12.7.	Combinación de tablas de mayores dimensiones, 397	
12.8.	Modelos lineales generalizados, 399	
12.9.	Estandarización, 413	
12.10.	Medida kappa de concordancia, 419	
13.	Métodos no paramétricos	424
13.1.	Introducción, 424	
13.2.	Pruebas de colocación con una muestra, 425	
13.3.	Comparación de dos grupos independientes, 428	
13.4.	Comparación entre varios grupos, 436	
13.5.	Correlación de rangos, 439	
13.6.	Comentarios generales, 442	
14.	Análisis de supervivencia	444
14.1.	Introducción, 444	
14.2.	Tablas de vida, 444	
14.3.	Estudios de seguimiento, 446	
14.4.	Errores de muestreo en las tablas de vida, 449	
14.5.	Estimación producto-límite de la supervivencia, 451	
14.6.	Test del rango (<i>logrank</i>), 451	
14.7.	Modelos paramétricos, 456	
14.8.	Modelos de regresión y de riesgo proporcional, 457	
14.9.	Métodos de los sujetos-años, 463	
15.	Métodos secuenciales	467
15.1.	Generalidades, 467	
15.2.	Tests secuenciales para datos binarios, 469	
15.3.	Aproximaciones normales, 474	

This One



7CH4-6EY-JGWL

15.4.	Planes secuenciales de grupos, 475	
15.5.	Conclusiones, 478	
16.	Métodos estadísticos en epidemiología	480
16.1.	Introducción, 480	
16.2.	Riesgo relativo, 481	
16.3.	Riesgo atribuible, 492	
16.4.	Tests diagnósticos y procedimientos de cribado, 495	
16.5.	Aglomeración de enfermedades, 502	
17.	Ensayo biológico	507
17.1.	Introducción, 507	
17.2.	Ensayos de rectas paralelas, 509	
17.3.	Ensayos de relación de pendientes, 516	
17.4.	Ensayos de respuesta cuántica, 518	
18.	Cálculo estadístico informatizado	522
18.1.	Introducción, 522	
18.2.	Proceso de datos, 523	
18.3.	Análisis estadístico, 524	
18.4.	Paquetes estadísticos, 525	
18.5.	Consideraciones generales, 528	
Apéndices. Tablas		529
A1	Áreas en el extremo o cola de la distribución normal, 530	
A2	Puntos percentuales de la distribución de χ^2 , 532	
A3	Puntos percentuales de la distribución de la t , 534	
A4	Puntos percentuales de la distribución de la F : $P = 0,05; 0,025; 0,01; 0,005$, 536	
A5	Puntos percentuales de la distribución del intervalo studentizado: $\alpha = 0,05; 0,01$, 540	
A6	Números aleatorios, 542	
A7	Puntos porcentuales para el test de la suma de rangos con signo de Wilcoxon, 547	
A8	Puntos porcentuales para el test de la suma de rangos de dos muestras de Wilcoxon, 548	
A9	Tamaño de la muestra para comparar dos proporciones, 549	
A10	Tabla del tamaño de la muestra para detectar el riesgo relativo en un estudio de caso-control, 550	
Bibliografía		551
Índice de autores		565
Índice de materias		573

Prólogo a la tercera edición

Hay numerosos y excelentes textos que sirven como introducción a la estadística médica, aportan una exposición simple y clara de las técnicas estadísticas básicas y describen algunos de los problemas con los que se encuentra el estadístico cuando aplica su ciencia a la medicina. El objetivo de este libro, al igual que en las ediciones anteriores, es un poco más ambicioso. Hemos tratado de reunir la mayoría de las técnicas estadísticas que se emplean con cierta frecuencia en la investigación médica y describirlas en términos que sean accesibles para quienes no dominan las matemáticas. Evidentemente, nuestro campo de aplicación coincide en parte con el de otros textos más generales de estadística aplicada. Sin embargo, la presente obra está dirigida explícitamente a aplicaciones médicas y esperamos que ofrezca dos ventajas especiales. En primer lugar, creemos que el uso de ejemplos seleccionados casi completamente a partir de proyectos de investigación médica ayudará al lector a comprender los conceptos básicos. En segundo término, la elección de los temas estadísticos refleja el alcance de su empleo en la investigación médica; algunos de estos temas no aparecerían en una obra general sobre estadística aplicada, pero en nuestro texto su presencia es natural.

La obra pretende ser de utilidad tanto para el investigador médico que no tenga una experiencia específica en matemáticas, aunque sí la capacidad de seguir unas fórmulas sencillas, como para el estadístico profesional interesado en las aplicaciones médicas. Desde el principio hasta el final se hace especial hincapié en los conceptos generales en que se fundamentan las técnicas estadísticas, los objetivos con los que se diseñan y las formas de cálculo que se requieren para su ejecución. Las demostraciones se consideran de importancia secundaria y, por lo general, se omiten o, si implican la realización de cálculos matemáticos relativamente simples, se indican en una letra de menor tamaño. El ámbito matemático consiste principalmente en manipulaciones algebraicas simples, y los símbolos empleados (como el uso del signo sumatorio) pueden aprenderse con mucha facilidad. Aunque en ocasiones se ha recurrido al uso de operaciones de cálculo y a matrices, el lector no familiarizado con estas técnicas podrá omitir acertadamente la lectura de estas partes sin perder la continuidad del texto. Hemos explicado, de una manera bastante detallada, algunos de los conceptos básicos que a menudo parecen difíciles en un primer encuentro, pero los lectores que ya estén familiarizados con éstos (p. ej., gracias a cursos introductorios) podrán omitir los capítulos iniciales y pasar a analizar de inmediato el material posterior. La investigación médica va adquiriendo un carácter cada vez más estadístico y se emplaza a los investigadores a que diseñen sus propios estudios y analicen sus propios datos consultando sólo esporádicamente a los estadísticos especializados. Esta obra será útil, sin duda, para ampliar el abanico de métodos estadísticos que pueden aplicarse con toda confianza y sin tener que recurrir a la ayuda de un experto.

La presente edición sigue el mismo enfoque general de las anteriores. Hemos conservado el mismo orden de los capítulos, aunque algunas partes se han redistribuido, se ha cambiado su numeración o se les ha dado un título distinto, y parte del material se ha transferido de un capítulo a otro. En los últimos años se ha constatado una producción abundante de

artículos que han desarrollado nuevos métodos estadísticos específicamente para la investigación médica, con varios miles de páginas cada año en las tres o cuatro revistas principales. Hemos tratado de tener en cuenta estos avances, en particular en las partes dedicadas a métodos bayesianos (caps. 2 y 4), ensayos clínicos (cap. 6) y análisis de la supervivencia (cap. 14). También hemos vuelto a escribir o hemos ampliado algunas partes más generales, especialmente en el capítulo 6, sobre determinación del tamaño de la muestra; en el capítulo 10, sobre diagnósticos de regresión; en el capítulo 12, sobre datos categóricos y en el capítulo 13 sobre métodos libres de distribución.

Se han introducido dos modificaciones que afectan a la presentación de los niveles de significación. En primer lugar, actualmente es innecesario remitir siempre los valores de P a algunos niveles estándar como 0,05 y 0,01. La mayoría de los paquetes estadísticos para ordenadores acotan valores precisos de P para tests tipo y recomendamos el uso de estos valores. La segunda modificación es más fundamental y se aplica al cálculo de valores de P en distribuciones discretas, como las que se producen en el análisis de datos binarios. Somos partidarios del valor de significación «semi- P », sugerido originalmente hace más de 40 años y que ha recibido recientemente una considerable atención en la literatura estadística. Se asocia a éste el concepto de los intervalos de confianza semi- P , que también recomendamos.

En el prólogo a la segunda edición señalamos el impacto que han tenido en la práctica estadística el uso generalizado de los ordenadores y la existencia de programas estadísticos potentes. Desde entonces (1987), la influencia de la informática ha crecido rápidamente. Pocos científicos, sean estadísticos, clínicos o investigadores de laboratorio, realizarían actualmente un análisis estadístico, por muy trivial que sea, sin un ordenador. De hecho, instamos enérgicamente a cualquier lector que tenga la intención de emplear seriamente los métodos descritos en este libro, a que tenga acceso a un ordenador equipado con uno de los programas estadísticos estándar (como los indicados en el cap. 18). Esta tendencia nos ha permitido eliminar o reducir las descripciones de algunos de los métodos diseñados para cálculos manuales. Sin embargo, hemos conservado deliberadamente algunas descripciones íntegras de los pasos intermedios de muchos de los cálculos para permitir al lector que comprenda mejor los pasos lógicos implicados, aunque en la práctica pocos de nuestros lectores, si acaso alguno, tendrán que realizar los cálculos como no sea con uno de estos programas estadísticos. En resumen, nuestro objetivo es explicar los conceptos y los métodos detallados de la manera más completa posible en un manual de ordenador. Los programas estadísticos tienen un desarrollo tan vertiginoso que parecía poco aconsejable proporcionar descripciones exhaustivas de algunos sistemas determinados. En el capítulo 18 se aportan algunas notas breves sobre algunos de éstos, que se pueden ampliar remitiéndose a los manuales pertinentes. En ocasiones hemos hecho referencia en el texto a programas específicos, cuando esto parecía conveniente (por lo general porque ofrecen posibilidades especiales).

Esperamos que los estadísticos que trabajan en la investigación médica o que están interesados en las aplicaciones médicas encuentren muchos aspectos de interés en esta revisión de su especialidad. En particular, la obra puede proporcionar un esquema muy útil para realizar cursos dirigidos a estudiantes de medicina o biología. Gran parte de la exposición y muchos de los ejemplos se basan en material utilizado en cursos de estadística para estudiantes posgraduados de medicina. Aunque en conjunto es más extenso de lo que se requeriría para un solo curso, el profesor de estadística no tendrá mucha dificultad en seleccionar las partes más apropiadas para un grupo específico de estudiantes.

Por una buena parte del material incluido en la obra, tanto de texto como de ilustraciones, damos nuestro agradecimiento a nuestros colaboradores actuales y antiguos. No hemos intentado atribuir de forma sistemática todos los datos citados, cuya procedencia original en algunos casos es actualmente dudosa; por esta razón pedimos disculpas a cualquier autor que los encuentre utilizados con fines insospechados en estas páginas. Tampoco hemos identificado todos los programas informáticos usados para los cálculos. No obstante, para el cálculo de los valores de P precisos, mencionados con anterioridad, encontramos especialmente práctico el empleo de un programa pequeño, el Arcus Pro-II, desarrollado por Iain E. Buchan, para abarcar muchos de los métodos descritos en este texto.

En la preparación de cada una de estas ediciones para la imprenta hemos contado con la ayuda de secretarías y de muchas otras personas, a quienes también deseamos hacer llegar nuestro agradecimiento.

P. Armitage
G. Berry

Capítulo 1

El alcance de la estadística

1.1. Generalidades

La estadística médica consiste, según qué opiniones, simplemente en formulaciones numéricas sobre materias médicas: cuántas personas fallecen por una determinada causa cada año, cuántas camas hospitalarias se encuentran disponibles en un área concreta o cuánto dinero se gasta en una determinada prestación médica. Estos hechos tienen una importancia administrativa clara. Para prever el número de camas de un servicio de obstetricia de una comunidad necesitamos conocer cuántas mujeres dan a luz en un período determinado y cuántas de ellas deben recibir cuidados en hospitales o maternidades. Los datos numéricos también ofrecen la base de numerosas investigaciones médicas; a lo largo de esta obra se dan múltiples ejemplos, aunque la intención no es confeccionar un listado o resumir información numérica de este tipo. Tales datos se pueden encontrar en las publicaciones oficiales de los departamentos nacionales o internacionales de salud, en los informes de investigaciones publicados y en los libros de texto y monografías sobre temas médicos. Esta obra hace referencia a lo general más que a lo particular, a la metodología más que a la información de datos particulares, a principios generales sobre la investigación estadística más que a resultados de estudios concretos.

La estadística puede definirse como la disciplina que se ocupa del tratamiento de los datos numéricos derivados de grupos de casos. A menudo, estos casos pueden ser personas; por ejemplo, aquellos que padecen una determinada enfermedad o los que viven en un área concreta. También pueden ser animales u otros organismos. Pueden ser, asimismo, diferentes unidades administrativas, como sucede cuando medimos la tasa de mortalidad por hospital en un grupo de hospitales. Pueden ser simplemente diferentes ocasiones en las que se ha realizado una determinada medida.

¿Por qué debemos interesarnos en las propiedades numéricas de los grupos de personas u objetos? En ocasiones se necesitan datos estadísticos por razones administrativas, como las mencionadas anteriormente: éstos pueden encontrarse en publicaciones oficiales; pueden extraerse de sistemas establecidos para la obtención de datos, como registros de cáncer o sistemas para la notificación de malformaciones congénitas; a veces, sin embargo, pueden requerir investigaciones estadísticas diseñadas.

Este libro trata de la utilización de la estadística en investigación médica y –contrastando con su empleo en materias administrativas– dicho uso no está exento de controversias. En ocasiones se dice que la estadística contribuye poco o nada al progreso de la medicina, porque el médico se ocupa en cada momento del tratamiento de un solo paciente y éste difiere del resto en aspectos importantes. Un célebre psiquiatra escribió en una carta a la revista *The Lancet*: «Nos vemos obligados a repetir el hecho de que si, en los últimos 30 años, uno hubiera prestado demasiada atención a los estadísticos, especialmente cuando no contaban con

el apoyo de los hallazgos al lado del lecho del paciente, el progreso de la psiquiatría de este país no habría llegado muy lejos». Al respecto deben señalarse dos puntos. Primero, la variabilidad de la enfermedad es un argumento *a favor* de la información estadística, no *en contra* de ella. Si el médico de cabecera detecta que en cierta ocasión un paciente con migraña se encuentra mejor tras la ingestión de zumo de ciruela, no puede deducir, a partir de esta única observación, que el zumo de ciruela constituye un tratamiento útil de la migraña. El médico necesita información estadística que muestre, por ejemplo, si en un grupo de enfermos se presenta con mayor frecuencia una mejora tras la administración de zumo de ciruela que después de otro tratamiento alternativo. En segundo lugar, es probable que los «hallazgos al lado del lecho del paciente» de la cita anterior sean esencialmente comparaciones estadísticas derivadas, desde hace tiempo, de la práctica clínica. La controversia es, entonces, si tal información debe almacenarse de un modo informal en la mente del médico o si debe recogerse y notificarse de manera sistemática. Muy pocos médicos adquieren, mediante su experiencia personal, información objetiva de todos los ámbitos de la medicina, y es parcialmente mediante la recogida, el análisis y la comunicación de información estadística que se construye y solidifica un cuerpo común de conocimiento.

La dificultad que plantea discutir sobre un solo caso es igualmente patente en los estudios sobre la etiología de la enfermedad. El hecho de que un individuo fumador de 50 cigarrillos al día y bebedor empedernido esté vivo y sano a los 95 años, no convencería a nadie de que estos hábitos favorecen la salud y aumentan la longevidad. Los individuos varían ampliamente en cuanto a su susceptibilidad frente a la enfermedad. Muchos no fumadores y abstemios mueren jóvenes. Para estudiar estas cuestiones se deben observar la morbilidad y la mortalidad de grupos de individuos con hábitos diferentes; es decir, se ha de realizar un estudio estadístico.

El primer capítulo de esta obra trata fundamentalmente acerca de algunas de las herramientas básicas de la recogida y la presentación de datos numéricos, una parte de la disciplina denominada habitualmente *estadística descriptiva*.

El estadístico necesita ir más allá de esta labor descriptiva en dos aspectos importantes: el primero, la posibilidad de mejorar la calidad de la información, planeando cuidadosamente la recogida de datos, y el segundo, saber que los procedimientos de *inferencia estadística* proporcionan una amplia gama de métodos objetivos para extraer conclusiones de los datos sobre los temas que se están investigando. La planificación y la inferencia deben gran parte de su desarrollo a la labor de R. A. (más tarde Sir Ronald) Fischer (1890-1962), cuya influencia es evidente en la práctica de la estadística moderna.

Casi todas las técnicas descritas en esta obra pueden utilizarse en una gran variedad de especialidades de la investigación médica e incluso en algunas ciencias no médicas. Para hacerse una idea puede ser útil mencionar cinco investigaciones bastante diferentes en las que los métodos estadísticos ocupan un lugar esencial.

1. Smith et al (1962) describieron un estudio sobre las concentraciones de anticuerpos tras la vacunación contra la fiebre amarilla. Los investigadores contaban con datos de las muestras de sangre obtenidas de casi 100 individuos y querían saber si el nivel de la producción de anticuerpos dependía de la concentración anterior a la vacunación, si dependía de la presencia de anticuerpos contra otros virus relacionados con el de la fiebre amarilla, si se alteraba la concentración de anticuerpos contra otros virus, etc. La investigación de todas estas posibles asociaciones era una labor fundamental. Además, la determinación

de la concentración de anticuerpos en cada muestra de sangre requería un experimento que consistía en inocular a varios grupos de animales mezclas de suero y diversas diluciones de virus, cuyos resultados debían interpretarse estadísticamente.

2. Mac Kie et al (1992) estudiaron la tendencia de la incidencia del melanoma maligno cutáneo primario en Escocia durante el período comprendido entre 1979 y 1989. Al evaluar esta clase de tendencias es importante tener en cuenta factores como los cambios en los criterios diagnósticos y en las definiciones de las clasificaciones de las enfermedades; los cambios en el patrón de derivaciones de los pacientes hacia la zona en estudio y desde ésta, y los cambios en la estructura de edad de la población. El grupo de estudio se constituyó teniendo en cuenta estos aspectos y estuvo compuesto por casi 4.000 pacientes. Los investigadores encontraron que la tasa de incidencia anual aumentó durante el período de 3,4 a 7,1 por 100.000 en el caso de los varones y de 6,6 a 10,4 en el de las mujeres. Estos hallazgos sugieren que la enfermedad, que se sabe es afectada por los niveles elevados de radiación ultravioleta, puede estar haciéndose más frecuente incluso en las zonas en que estos niveles son relativamente bajos.
3. Se sabe que las mujeres que han tenido un embarazo con un defecto del tubo neural (DTN) tienen un riesgo superior al de la media de presentar el mismo trastorno en un embarazo futuro. A principios de los años ochenta se publicó un estudio que sugería que el suplemento vitamínico en el período periconcepcional podía reducir este riesgo. En uno de los estudios, las mujeres que aceptaron participar recibieron una mezcla de vitaminas, entre ellas ácido fólico, y presentaron una incidencia mucho más baja de DTN en los embarazos posteriores que las mujeres que ya estaban embarazadas o que habían rechazado participar. Sin embargo, era posible que los resultados se explicasen por algunas diferencias sistemáticas entre las características de las que participaron y las de las que no lo hicieron. En el segundo estudio se trató de salvar esta ambigüedad seleccionando aleatoriamente a las mujeres para que recibieran un suplemento de ácido fólico o un placebo, pero la investigación era demasiado pequeña para dar resultados claros. El MRC Vitamin Study Research Group (1991) comunicó un ensayo clínico aleatorizado, mucho más grande, en el que se pudieron estudiar los efectos separados tanto del ácido fólico como de otras vitaminas. El desenlace fue claro. De 593 mujeres que recibieron ácido fólico y quedaron embarazadas, 6 presentaron un DTN; de las 602 que no recibieron la vitamina, 21 presentaron el defecto. No se puso de manifiesto el efecto de ninguna otra vitamina. Los métodos estadísticos confirmaron la primera impresión de que es muy improbable que el contraste entre el grupo que recibió ácido fólico y el grupo control sea debido al azar y puede atribuirse con confianza al tratamiento empleado.
4. La Organización Mundial de la Salud llevó a cabo un estudio multicéntrico y de caso-control en 12 centros participantes de 10 países para investigar la posible relación entre el cáncer de mama y el uso de anticonceptivos orales (WHO Collaborative Study of Neoplasia and Steroid Contraceptives, 1990). En cada hospital, las mujeres con cáncer de mama y que reunían los criterios específicos de edad y domiciliación se tomaron como casos. Los controles se seleccionaron a partir de las mujeres que ingresaban en el mismo hospital, que cumplían los mismos criterios de edad y domiciliación de los casos y que no sufrían un trastorno sospechoso de afectar las prácticas anticonceptivas. En el estudio se incluyeron 2.116 casos y 13.072 controles. El análisis de la asociación entre el cáncer de mama y el uso de anticonceptivos orales tuvo que examinar otras variables que se asocian al cáncer

de mama y que podrían diferir entre las usuarias y las no usuarias de anticonceptivos orales. Entre estas variables se estudiaron la edad, la edad en el primer nacimiento vivo (efecto 2,7 veces entre los 30 años o más y menos de edad de 20 años), un índice socioeconómico (efecto doble), el año de matrimonio y los antecedentes familiares de cáncer de mama (efecto triple). Después de tener en cuenta si eran necesarias estas tres variables de confusión, se calculó que el riesgo de cáncer de mama de las que tomaban anticonceptivos orales era 1,15 veces el riesgo de las que no los tomaban; una asociación débil en comparación con el tamaño de las asociaciones de algunas de las otras variables que tuvieron que examinarse.

5. Un ejemplo final del empleo de argumentos estadísticos es un estudio realizado para cuantificar el grado de enfermedad en lactantes menores de 6 meses, descrito por Cole et al (1991). Es importante que los padres y los médicos de cabecera cuenten con un método adecuado para identificar una enfermedad grave que requiera la consulta de un pediatra especialista. Si esto es posible, o no, sólo puede determinarse por el estudio de un gran número de lactantes, anotando los posibles signos y síntomas y determinando también la gravedad de la enfermedad. En este estudio los autores examinaron 28 síntomas y 47 signos físicos. El análisis mostró que bastaba con emplear 7 síntomas y 12 signos, y cada uno de ellos se asignó a una puntuación entera proporcional a su importancia. Seguidamente se obtuvo una puntuación de la enfermedad del niño sumando las puntuaciones de los signos o síntomas presentes. A continuación se clasificó la puntuación en 3 categorías: 0-7, 8-12 y 13 o más, que indicaban respectivamente buen estado o enfermedad leve, enfermedad moderada y enfermedad grave. Se predijo que el uso de esta puntuación clasificaría correctamente al 98% de los niños que estaban en buen estado o con enfermedad leve y que se identificaría de manera adecuada al 92% de los niños gravemente enfermos.

1.2. Diagramas

Uno de los principales métodos de presentación de la información estadística lo constituyen los diagramas. Las tendencias y los contrastes suelen percibirse con mayor rapidez y quizá son retenidos durante más tiempo en la memoria mediante la observación casual de un diagrama bien proporcionado, que por el escrutinio de los datos numéricos correspondientes, presentados en una tabla. Sin embargo, los diagramas deben ser sencillos, pues los que contienen demasiada información entrañan mayor dificultad en la interpretación y quizás el lector no quiera esforzarse. Además, cuando los datos se presentan en forma de diagrama se pierden los detalles. Por consiguiente, en cualquier análisis crítico de datos se debe hacer referencia a las cifras relevantes.

Los diagramas estadísticos responden a dos objetivos fundamentales. El primero es la presentación de la información estadística en artículos u otros informes, pensando que el lector apreciará una exposición simple y evocadora. Los datos estadísticos oficiales empresariales, financieros, médicos y demográficos suelen aparecer en los periódicos y en los informes anuales de los departamentos gubernamentales en forma de diagramas, y su poderoso impacto los convierte también en un posible instrumento de falseo de datos, en medios de información desaprensivos. El lector debería prestar poca atención a los diagramas, a menos que se explique claramente la definición de las cantidades representadas y las escalas en las que se representan. En los artículos de investigación es desaconsejable presentar los datos básicos

exclusivamente mediante diagramas, por la pérdida de detalle ya mencionada. Los diagramas deberían restringirse exclusivamente a subrayar puntos importantes concretos, presentando los detalles de las evidencias mediante tablas separadas.

Otro de los objetivos consiste en ayudar particularmente al análisis estadístico. El estadístico recurrirá a menudo a los diagramas para formarse una idea de la estructura de los datos y examinar las suposiciones que se plantean en un análisis. Este uso informal revelará a menudo nuevas características de los datos o sugerirá nuevas hipótesis que pueden investigarse con mayor detalle.

A lo largo de esta obra se comentan diferentes tipos de diagramas. En este apartado bastará mencionar algunos de sus principales usos mediante ejemplos de las publicaciones oficiales.

1. *Para comparar dos o más cifras.* La comparación se efectúa generalmente mediante barras de diferentes longitudes (fig. 1.1). Otro método común consiste en utilizar hileras de símbolos repetidos (*pictogramas*); por ejemplo, las poblaciones de diferentes países se pueden representar mediante hileras de «personas», cada una de las cuales representa a 1.000.000 de personas. Se debe tener cuidado de no usar símbolos de la misma forma pero de distinto tamaño, debido a la ambigüedad de su interpretación; por ejemplo, si las exportaciones de distintos países se representan con bolsas de diferentes tamaños, el lector puede preguntarse si las cantidades numéricas están representadas por las dimensiones lineales o por el área de las bolsas.
2. *Para expresar la distribución de objetos individuales o medidas en varias categorías.* La distribución de frecuencias de los diferentes valores de una medida numérica suele representarse mediante un histograma, método que se tratará más ampliamente en el apartado 1.4 (v. figs. 1.6 a 1.8). La distribución de individuos en categorías no numéricas puede expresarse con un *diagrama de barras* como en el apartado 1, en el cual la longitud de cada barra representa el número de observaciones (o *frecuencia*) en cada categoría. Si las fre-




Fig. 1.1. «Diagrama de barras» que muestra los porcentajes del producto nacional bruto gastado en 1987 en salud pública en 4 países. (Reproducido con autorización de Macklin, 1990.)

cuencias se expresan mediante porcentajes y éstos totalizan el 100%, el «pastel» o «diagrama circular» constituye un método de representación adecuado (fig. 1.2).

3. *Para expresar el cambio de alguna cantidad durante un período de tiempo.* En este caso se utiliza generalmente un gráfico cuyos puntos, que representan los valores de la cantidad en momentos sucesivos, se unen con varios segmentos en línea recta (fig. 1.3). Si los intervalos de tiempo son muy cortos, la gráfica puede transformarse, mediante suavización, en una curva. Si el intervalo de variación de las mediciones es pequeño y está situado a cierta distancia de cero, no es aconsejable comenzar la escala (por lo general representada verticalmente) en cero, porque ello dejaría la mayor parte del diagrama en blanco. Un origen distinto de cero debería indicarse con una línea en zigzag, que rompa el extremo inferior de la escala para atraer la atención del lector (fig. 1.3). Está claro que una tendencia suave se puede representar de modo tal que parezca más espectacular de lo que es en realidad, sólo eligiendo cuidadosamente un origen distinto de cero. Lamentablemente, para el médico sin escrúpulos es demasiado fácil apoyar la interpretación preferida de una tendencia temporal, pues sólo necesita la elección esmerada del origen de la escala. Un cambio brusco de escala en una zona del intervalo de variación es mucho más engañoso y debería evitarse siempre. En el capítulo 11 se presentan algunas escalas especiales basadas en transformaciones logarítmicas y de otras transformaciones.
4. *Para expresar la relación entre dos medicaciones, en una situación en la que se presentan apareadas.* La representación habitual es el diagrama de puntos (v. fig. 5.1), descrito con detalle en el capítulo 5. Las tendencias temporales, tratadas en el apartado 3, constituyen una forma particular de relación que merecía un comentario especial porque, con frecuencia, los datos consisten en una medición realizada en cada uno de los tiempos (estos tiempos suelen estar separados por espacios iguales). En general, los datos sobre relaciones no son tan estrictos y el gráfico continuo no suele ser apropiado.

1.3. Tabulación y proceso de datos

Otro modo de resumir y presentar algunas características importantes de un conjunto de datos es en forma de tabla. Existen muchas variantes, pero las características esenciales son que la estructura y el significado de una tabla se indiquen con encabezamientos o títulos y que el



Fig. 1.2. «Diagrama circular» que ilustra las proporciones de muertes infantiles de 3 años distintos en Inglaterra y País de Gales que se produjeron en intervalos del primer año de vida. El valor de cada categoría es proporcional al ángulo con respecto al centro del círculo y, en consecuencia, al área del sector.




Fig. 1.3. «Diagrama lineal» que muestra los cambios entre seis encuestas en la proporción de hombres (línea continua) y mujeres (línea discontinua) que eran fumadores habituales en Australia. (Adaptado de Hill et al, 1991.)

resumen estadístico se exprese en el cuerpo de la tabla mediante números. Con frecuencia, una tabla es bidimensional, en cuyo caso, las filas y las columnas definen dos modos distintos de categorizar los datos. Cada porción de una tabla definida por la combinación de una fila y una columna se denomina *casilla*. Las informaciones numéricas pueden ser recuentos del número de individuos en diferentes casillas, la media de los valores de algunas medidas (v. apartado 1.5) u otros índices más complejos.

Ehrenberg (1975, 1977) propone algunas normas útiles sobre la presentación de tablas para su publicación. Como puntos relevantes destacan evitar números que contengan muchos dígitos innecesarios (porque las cifras cortas y redondeadas transmiten su mensaje con mayor eficacia) y cuidar que la presentación permita comparar fácilmente los números que deben ser comparados.

La tabla 1.1, tomada de un informe sobre concepción asistida (AIH National Perinatal Statistics Unit, 1991), es un ejemplo en el que se resumen recuentos. Sintetiza la información de 5.115 mujeres que concibieron después de una fertilización *in vitro* (FIV) y muestra que la proporción de mujeres cuyo embarazo dio como resultado un nacimiento vivo estuvo relacionada con la edad. ¿Cómo se construye una tabla de este tipo? Aunque con un pequeño número de datos podría formarse una tabla de esta clase mediante la ordenación y el recuento manuales de los registros originales, la labor sería inmensa si hubiera muchas observaciones (como en la tabla 1.1) o si tuvieran que elaborarse muchas tablas.

Tabla 1.1. Desenlace de los embarazos según la edad materna (adaptado de AIH National Perinatal Statistics Unit, 1991).

Edad		Nacimientos vivos	Aborto espontáneo	Embarazo ectópico	Mortinatos	Terminación del embarazo	Total
< 25	Número	94	21	10	2	0	127
	%	74,0	16,5	7,9	1,6	0,0	100,0
25-29	Número	962	272	96	36	2	1.368
	%	70,3	19,9	7,0	2,6	0,1	99,9
30-34	Número	1.615	430	143	58	8	2.254
	%	71,7	19,1	6,3	2,6	0,4	100,1
35-39	Número	789	338	66	27	6	1.226
	%	64,4	27,6	5,4	2,2	0,5	100,1
40 +	Número	69	60	6	1	5	141
	%	48,9	42,6	4,3	0,7	3,5	100,0
Total	Número	3.529	1.121	321	124	21	5.116
	%	69,0	21,9	6,3	2,4	0,4	100,0

En primer lugar, es posible distinguir entre los problemas que implica preparar los datos de un modo adecuado para su tabulación y los problemas mecánicos (o electrónicos) que plantea su manipulación. Algunos estudios, en particular los experimentos de laboratorio en pequeña escala, originan una cantidad relativamente escasa de observaciones y, en consecuencia, los problemas causados por la preparación de los datos son simples. De hecho, este tipo de tabulaciones puede ser innecesario y el estadístico debe dedicarse exclusivamente a formas más complejas de análisis.

Por el contrario, la preparación de datos es un problema importante en numerosas investigaciones a gran escala, tanto si se trata de complejas mediciones automáticas de laboratorio como de un contexto «humano» en estudios clínicos o de otra índole. En ensayos terapéuticos y profilácticos a gran escala, en investigaciones sobre pronósticos, en estudios epidemiológicos y de medicina social y en muchos otros campos se puede incluir a un número elevado de personas como sujetos y en cada uno de ellos efectuarse muchas observaciones. Además, gran parte de la información puede ser difícil de obtener de forma clara, y la definición precisa de las variables a menudo exige una cuidadosa reflexión.

En la mayoría de las investigaciones de este tipo será necesario recoger la información en formularios o cuestionarios especialmente diseñados. El diseño de estos cuestionarios es estudiado con más detalle por Babbie (1989). Aquí pueden comentarse brevemente los siguientes puntos:

1. Existe la tentación de recoger más información de la necesaria por la posibilidad de que resulte útil en el presente estudio o en otro futuro, aunque ello puede suponer importantes desventajas. La recogida de datos cuesta dinero y, aunque el coste que representa recoger información extra de un individuo que ya se está considerando puede ser relativamente bajo, dicho coste siempre debe tenerse en cuenta. La desventaja más importante consiste en que la obtención de información útil marginal puede desvirtuar el valor de los datos esenciales. El entrevistador enfrentado a un cuestionario, con 50 apartados para cada

sujeto, será menos cuidadoso que en el caso de requerir sólo 20. Si existe un riesgo importante de falta de cooperación de los entrevistados, como sucede en los sondeos por correo que utilizan cuestionarios que deben ser rellenados por el propio sujeto, su extensión puede constituir una falta de incentivo y, en consecuencia, se debe disminuir el número de preguntas. De modo similar, si la recogida de datos se efectúa por teléfono, la cooperación del entrevistado disminuirá si éste supone que la comunicación durará mucho tiempo.

2. Se debe prestar especial atención al estilo empleado en las preguntas para evitar ambigüedades y para mantener el interés de la investigación. Cuando sea posible, las distintas categorías de respuestas que sean de interés se deben enumerar. Ello ayuda a evitar respuestas ambiguas y sin sentido y ahorra tiempo en la clasificación posterior de los resultados.

Por ejemplo:

¿Cuál es su situación laboral? (señale la respuesta con un círculo).

1. Labores domésticas sin trabajo remunerado fuera del hogar.
2. Empleo de media jornada (menos de 25 horas semanales).
3. Empleo con dedicación completa.
4. Desempleado buscando trabajo.
5. Retirado por incapacidad o enfermedad (por favor, especifique la causa)
6. Retirado por otros motivos.
7. Otra (por favor, especifíquela)

Si la respuesta a la pregunta es una cantidad numérica, se deben especificar las unidades. Por ejemplo:

Peso:..... kg.

En algunos casos se pueden emplear indistintamente varios tipos de unidades. Por ejemplo:

Altura: cm.

O pies pulgadas.

En otros casos puede ser suficiente con especificar cierto número de categorías. Por ejemplo:

¿Cuántos años hace que vive en esta ciudad? (señale la respuesta con un círculo).

1. Menos de 5
2. 5-9
3. 10-19
4. 20-29
5. 30-39
6. 40 o más.

Cuando la respuesta es cualitativa y, sin embargo, puede interpretarse como gradación de una escala unidimensional se pueden ofrecer varias posibles respuestas ordenadas. Por ejemplo:

Cuántos problemas ha tenido en el último mes con:

	Ninguno	Muy pocos	Pocos	Varios	Muchos
1. Su cónyuge	1	2	3	4	5
2. Otros miembros de su familia	1	2	3	4	5
3. Amigos	1	2	3	4	5
4. El dinero o los negocios	1	2	3	4	5
5. Su trabajo	1	2	3	4	5
6. Su salud	1	2	3	4	5

El siguiente paso consiste en transferir la información pertinente desde los registros originales a una forma adecuada para su análisis. Anteriormente, ello hubiera supuesto transferir los datos a tarjetas perforadas de 80 columnas, pero en la actualidad los datos son introducidos directamente desde una terminal de vídeo y a través de un ordenador a un disco (el propio disco duro del ordenador, un disquete o ambos). Las posibilidades de edición permiten corregir directamente los datos almacenados. Como ya no es necesario guardar una copia «dura» de los datos en una forma legible para el ordenador, es fundamental conservar copias de seguridad de los ficheros de datos para protegerse de un funcionamiento defectuoso del ordenador que pueda imposibilitar la lectura de un fichero determinado. Las copias de seguridad pueden guardarse en disquetes o en cinta magnética.

La entrada inicial de datos puede hacerse a través de un ordenador personal; a veces, la edición y el análisis también pueden completarse en este ordenador. Con otros conjuntos de datos es necesario transferir el análisis a un ordenador más potente, debido al tamaño de dicho conjunto o para obtener acceso a una variedad más amplia de *software*.

Hay dos estrategias para la entrada de datos. En la primera, los datos son considerados como una fila de caracteres y no se hace interpretación alguna hasta la creación de un fichero de datos. El segundo método es mucho más potente y requiere usar el ordenador de modo interactivo a medida que se introducen los datos. Así, los errores lógicos y los valores improbables (v. apartado 11.6) pueden ser indicados inmediatamente al operador. Si un error de este tipo se debe al operador, puede corregirse en el acto; en caso contrario sería necesario referirlo al investigador. Los cuestionarios muchas veces contienen preguntas que sólo son aplicables si se da una respuesta determinada a una pregunta anterior. Por ejemplo, si se intentan conocer los antecedentes detallados sobre el hábito de fumar, la primera pregunta podría ser: «¿Ha fumado alguna vez?». Si la respuesta es «sí», a continuación seguirían varias preguntas referentes a cuántos años ha fumado, a la cantidad y a las marcas de cigarrillos, etc. Por otra parte, si la respuesta es «no», estas preguntas no serían aplicables y habría que pasarlas por alto. Si se hace la entrada de datos a través de una terminal, el programa de control presentaría automáticamente en la pantalla la siguiente pregunta aplicable.

La entrada de datos a través de una terminal suele realizarse a partir de un cuestionario completo, mientras que en las entrevistas telefónicas es posible que el entrevistador lea una pregunta en la pantalla, introduzca la respuesta con el teclado, etc., con las bifurcaciones controladas por el ordenador. En este caso, cualquier error detectado podrá ser aclarado inmediatamente con el entrevistado.

Existen varias maneras de representar la información de un cuestionario en un registro informatizado. En el método más sencillo, la respuesta a cada pregunta se codifica en una o

1	Número del caso						
			1				4
2	Sexo	1 Varón					
		2 Mujer					5
3	Edad _____ años						
						6	7
4	Estado civil	1 Soltero					
		2 Casado					
		3 Viudo, divorciado o separado					
						8	
5	País de nacimiento _____						
						9	10

Fig. 1.4. Ejemplo de un fragmento de un cuestionario que incluye la codificación.

más columnas, cada una de las cuales contiene un dígito de 0 a 9. Ello significa que la información no numérica debe ser «codificada». Por ejemplo, la codificación de las primeras preguntas puede efectuarse como se señala en la figura 1.4. En algunos sistemas se deben introducir los ceros a la izquierda, es decir, si se reservan 3 dígitos para una variable como la presión diastólica sanguínea, la lectura 88 mmHg se codificaría 088, mientras que otros sistemas permiten la utilización de blancos en su lugar. Para el sujeto número 122, que era una mujer casada de 49 años, las primeras ocho columnas del registro mostrado en la figura 1.4 se grabarían con los siguientes códigos:

Columna	1	2	3	4	5	6	7	8
Código	0	1	2	2	2	4	9	2

El operador ha de conocer claramente qué código debe perforar para cada columna. Existen dos métodos posibles. Puede transferir la información del registro original a una «hoja de codificación», que presentará en cada columna de cada registro el código que debe ser perforado. Esta hoja puede ser un papel cuadriculado, en el que las filas representan los diferentes individuos y las columnas representan las del registro. Estas hojas de codificación están comercializadas. Excepto para trabajos poco extensos, es preferible diseñar hojas especiales que muestren claramente las distintas variables; esto reducirá la frecuencia de errores de transcripción. Otra solución consiste en incluir la codificación en el formulario básico para poder introducir los datos en el ordenador directamente a partir de dicho formulario, eliminando la necesidad de una hoja intermedia de codificación. Si se tiene cuidado en el diseño de dicho formulario, este segundo método es preferible porque elimina una fuente potencial de errores de copia. Éste es el enfoque mostrado en la figura 1.4, en la que las casillas de la derecha se utilizan para la codificación. Se muestran los códigos para las primeras 4 variables y el entrevistador puede rellenarlos inmediatamente. Para la variable 5 existen tantas posibilidades que no permiten mostrar todos los códigos. En su lugar, la respuesta podría registrarse de forma abierta, por ejemplo, «Grecia», y comprobar más tarde el código en un apartado detallado de instrucciones de codificación.

Ya hemos mencionado que es preferible utilizar el formulario o cuestionario simultáneamente para la codificación. Sin embargo, debe hacerse una salvedad. El propósito del cuestionario es obtener una información precisa y, por lo tanto, se debe eliminar cualquier factor que pueda cambiarla. Especialmente en los cuestionarios que son respondidos por el propio entrevistado, la presencia de casillas de codificación puede reducir la cooperación que de otro modo aquél ofrecería, aunque no se le obligue a utilizarlos. Esto puede deberse a una sensación de rechazo producida por el aspecto «oficial» del formulario o, simplemente, porque las casillas le confieren una apariencia menuda y apretada y, por ello, menos interesante. Esto no debería suponer un problema cuando participan entrevistadores, pero si existe alguna duda deben usarse hojas separadas de codificación.

Cuando la entrada de datos se realiza a través de una terminal, no se requieren casillas de codificación, pero es necesario tener cuidado en el diseño del cuestionario para asegurar que la información que el operador necesita pueda localizarse fácilmente.

El estadístico o el investigador que desea tabular los datos de varias maneras utilizando un ordenador debe tener acceso a un programa adecuado. Probablemente no será necesario elaborar un programa especial, porque los paquetes estadísticos de diferentes tareas corrientes como la tabulación están al alcance de cualquiera.

Es esencial que los datos y las instrucciones para los análisis especiales sean introducidos en el formato especificado por el programa. Por consiguiente, el investigador debería estudiar las especificaciones del programa antes de ordenar la introducción de los datos. En un estudio a gran escala que incluya un formulario, se deberían considerar estos temas antes de decidir definitivamente su diseño.

La mayoría de los métodos de análisis que se describirán a lo largo de esta obra pueden efectuarse empleando lenguajes o programas estadísticos estándar. Entre algunos de estos programas existentes en el mercado se cuentan: SAS, BMDP, SPSS y Minitab. En el capítulo 18 se trata el empleo de éstos y otros programas.

Aunque los ordenadores son cada vez más utilizados para el análisis, cuando se trata de pequeños conjuntos de datos es conveniente, a menudo, utilizar una calculadora de bolsillo. Estas máquinas realizan las operaciones aritméticas básicas a gran velocidad y tiene una amplia variedad de funciones matemáticas, como el cuadrado, la raíz cuadrada, la función exponencial, el logaritmo, etc. Una característica adicional particularmente útil en el trabajo estadístico es el cálculo automático y la acumulación de sumas de cuadrados de números. Algunas máquinas disponen de un conjunto de funciones especiales para análisis estadísticos. Esto es particularmente común en el cálculo automático de la media y de la desviación fija. En el mercado existen calculadoras programables que facilitan el uso repetido de fórmulas estadísticas.

Al usuario de una calculadora le resulta difícil a menudo saber qué redondeo se permite en los datos, en los pasos intermedios o finales del cálculo. Los ejemplos de esta obra permitirán deducir algunas pautas; sin embargo, pueden señalarse las siguientes consideraciones generales:

1. Los diferentes valores de una variable deberían expresarse con el mismo grado de precisión. Si se expresa una serie de alturas de niños redondeando al centímetro más próximo, pero algunas al 0,5 cm más próximo, esta precisión adicional se perderá en los cálculos realizados en la serie considerada como conjunto. En consecuencia, todas las mediciones se deberían redondear al centímetro más próximo por conveniencia del cálculo.

2. Una regla útil para redondear valores centrales (como una altura de 127,5 cm cuando se redondea a valores enteros) es hacerlo al número par más próximo. Es decir, 127,5 se redondearía a 128. Esta regla evitaría el pequeño sesgo que se produciría si las cifras se redondearan siempre por exceso o por defecto.
3. En casos excepcionales podría estar justificado expresar los resultados de los cálculos con una precisión ligeramente superior a la de los datos originales. Por ejemplo, si se mide una serie larga de alturas redondeándolas al centímetro más próximo, la media puede expresarse con un decimal. La explicación es que, como veremos, el efecto de los errores por redondeo se reduce al promediar.
4. Si una cantidad calculada durante un paso intermedio del cálculo se expresa con n cifras significativas, el resultado de cualquier multiplicación o división de esta cantidad tendrá, como máximo, n cifras válidas. Las cifras significativas son aquellas que hay desde el primer dígito distinto de cero hasta el último dígito significativo, independientemente de la posición de la coma decimal. Por ello, 1,002, 10,02, 100,200 (si este número es expresado redondeándolo al 100 más cercano) tienen cuatro cifras significativas. La imprecisión acumulada crece con operaciones sucesivas de multiplicación o división.
5. En el resultado de una suma o una resta son válidos tantos decimales como el sumando que tiene menos. En consecuencia, el resultado de sumar 101 (aproximado al entero más próximo) y 4,39 (que tiene dos decimales) es 105 (aproximado al entero más cercano). El último dígito puede contener un error de una unidad; por ejemplo, el número exacto correspondiente a 101 podría haber sido 101,42, en cuyo caso el resultado de la suma debería haber sido 105,81, o 106 aproximando al entero más próximo. Estas consideraciones son particularmente importantes en la resta. En los cálculos estadísticos, un número con mucha frecuencia se resta de otro de cuantía muy similar. El resultado de la resta tiene entonces muchos menos dígitos significativos que los números originales. Por ejemplo, $3.212,78 - 3.208,44 = 4,34$; en la resta se han perdido 3 dígitos. Por este motivo, es fundamental que en los pasos iniciales de un cálculo se mantengan más dígitos significativos de los necesarios para el resultado final.

Una consideración final sobre el cálculo es la importancia de mantener una distribución ordenada en el papel con encabezamientos adecuados, disponiendo los números en filas y columnas sin apiñarlos indebidamente. A menudo es conveniente utilizar papel cuadriculado con intervalos de 0,25 pulgadas o 0,5 cm, aproximadamente.

1.4. Resumen de datos numéricos

El material bruto de las investigaciones estadísticas consiste en observaciones individuales que casi siempre se deben resumir de algún modo para que puedan ser de utilidad. En los dos últimos apartados nos hemos referido al manejo de diagramas y tablas para presentar algunas de las características principales de un grupo de datos. Ahora debemos examinar con más detalle algunos tipos particulares de tablas y diagramas asociados. Como hemos visto, el objetivo de los métodos estadísticos va más allá de la mera presentación de datos e incluye la formulación de inferencias a partir de ellos. Estos dos aspectos –descripción e inferencia– no pueden separarse. No podemos referirnos a las herramientas descriptivas sin considerar

el fin para el que son necesarias. En los apartados siguientes adelantaremos algunos puntos sobre inferencia que se comentarán con más detalle en capítulos posteriores.

Cualquier clase de medida o clasificación en la que se hagan observaciones individuales se denomina *variable*. Por ejemplo, en un problema la variable podría ser una medida determinada de la función respiratoria en escolares y, en otro, podría ser el número de bacterias encontradas en muestras de agua. En la mayoría de los problemas existen muchas variables. En un estudio sobre la historia natural de cierta enfermedad, por ejemplo, es posible efectuar varias observaciones en cada paciente, mediante distintas variables que miden el estado clínico del paciente en diferentes momentos de la evolución de la enfermedad y también en ciertas variables, como la edad, que no están directamente relacionadas con la salud del paciente.

Es útil distinguir, en primer lugar, entre dos tipos de variables: *cualitativas* (o *categorías*) y *cuantitativas*. Las observaciones cualitativas son aquellas que no se caracterizan por una cantidad numérica, sino cuyos posibles valores consisten en varias categorías, anotando a cualquier individuo como perteneciente sólo a una de estas categorías. Son ejemplos característicos el sexo, el color del cabello, la muerte o supervivencia durante un tiempo determinado y la profesión. Las variables cualitativas pueden dividirse en observaciones *nominales* y *ordinales*. Una variable ordinal es aquella en la que las categorías tienen un orden natural claro. Por ejemplo, la fase de un cáncer en una localización determinada se puede clasificar como fase A, B, C o D, donde observaciones previas han indicado que hay una progresión a través de estas fases en secuencia de A a D. A veces, el hecho de que las fases estén ordenadas se puede indicar refiriéndose a ellas en términos de una cifra, es decir, fase 1, 2, 3 o 4, pero en este caso el uso de una cifra es una etiqueta y no indica que la variable sea cuantitativa. Una variable nominal es aquella para la cual no hay un orden natural de las categorías. Por ejemplo, la causa demostrada de la muerte podría clasificarse como enfermedad infecciosa, cáncer, enfermedad cardiovascular, etc. De nuevo, el hecho de que muchas veces a la causa de la muerte se le atribuya una cifra (el código de la Clasificación Internacional de Enfermedades o CIE) no oculta el hecho de que la variable sea nominal, y los códigos sirven sólo como etiquetas taquigráficas.

El problema de resumir datos nominales cualitativos es relativamente simple. La tarea principal consiste en contar el número de observaciones en varias categorías y quizás en expresarlas como proporciones o porcentajes de totales adecuados. Estos recuentos reciben muchas veces el nombre de *frecuencias* o *frecuencias relativas*. En las tablas 1.1 y 1.2 se proporcionan algunos ejemplos. Si se muestran las frecuencias relativas en ciertos subgrupos, es útil sumarlas para obtener 1,00 o 100%, de modo que el lector pueda ver fácilmente cuáles son las frecuencias totales que se han subdividido. (Se pueden pasar por alto algunas ligeras discrepancias en estos totales, debido al redondeo de frecuencias relativas. Por ejemplo, v. tablas 1.1 y 1.3.)

Las variables ordinales pueden resumirse del mismo modo que las nominales. Una diferencia estriba en que el orden de las categorías en cualquier tabla o figura está determinado previamente, mientras que en una variable nominal es arbitrario. El orden también permite el cálculo de *frecuencias relativas acumuladas*, que son las sumas de todas las frecuencias relativas hasta cada categoría.

Un tipo especialmente importante de observaciones cualitativas es aquel en que está presente o ausente cierta característica, de modo que las observaciones entran en una de las dos

Tabla 1.2. Resultados del examen de esputo 3 meses después de la intervención de un grupo de pacientes tratados con estreptomina y de un grupo control sin estreptomina.

	Estreptomina		Control	
	Frecuencia	%	Frecuencia	%
Extensión negativa, cultivo negativo	141	45,0	117	41,8
Extensión negativa, sin cultivo	90	28,8	67	23,9
Extensión y cultivo positivos	82	26,2	96	34,3
Total con resultado del esputo conocido	313	100,0	280	100,0
Resultados desconocidos	12		17	
Total	325		297	

categorías. Son ejemplos de este tipo de observación el sexo y la supervivencia o la muerte. Estas variables reciben varias denominaciones, como *dicotómicas*, *todo o nada* o *binarias*.

Las variables cuantitativas son aquellas en las cuales las observaciones individuales son cantidades numéricas, por lo general medidas o recuentos. Es útil clasificar las observaciones cuantitativas en variables *discretas* y *continuas*. Las medidas discretas son aquellas cuyos valores posibles son completamente distintos y se encuentran separados. Suelen ser recuentos como el número de veces que un individuo ha sido ingresado en el hospital en los últimos 5 años.

Las variables continuas pueden adoptar un intervalo de valores continuo e ininterrumpido. Como ejemplos podemos citar la estatura, el peso, la edad y la presión arterial. Las medidas continuas por lo general tienen un límite superior y un límite inferior. Por ejemplo, la estatura no puede ser inferior a cero. Probablemente hay un límite superior y uno inferior que es superior a cero e inferior a un valor determinado, pero resulta difícil decir dónde se encuentran. La distinción entre variables discretas y continuas no siempre es clara, porque en la práctica todas las mediciones continuas se redondean; por ejemplo, una serie de estaturas puede registrarse redondeándolas al centímetro más próximo y, por consiguiente, parecer discretas. Esta ambigüedad pocas veces constituye un escollo, porque los mismos métodos estadísticos a menudo pueden aplicarse tanto a las variables continuas como a las discretas, especialmente si la escala usada para estas últimas se subdivide de manera muy fina. Por otra parte, existen algunos métodos especiales aplicables a los recuentos que, como se ha visto, deben ser números enteros positivos. Los problemas encontrados al resumir datos cuantitativos son mucho más complejos que los de los datos cualitativos, por lo que el resto de este capítulo estará dedicado casi completamente a aquéllos.

A veces, una variable continua o cuantitativa discreta se puede resumir dividiendo el intervalo de valores en varias categorías o *grupos interválicos* y obtener, así, una tabla de frecuencias. Por ejemplo, para la edad podrían crearse varios grupos y colocar a cada individuo en uno de los grupos. La variable edad se ha transformado en una variable nueva, grupo de edad, que tiene todas las características de una variable categórica ordenada. Una variable de este tipo puede llamarse *variable interválica*.

Un primer paso práctico para resumir gran cantidad de datos cuantitativos es la formación de una *distribución de frecuencias*. Es una tabla que muestra el número de observaciones, o frecuencia, de diferentes valores o de ciertos intervalos de valores de la variable. En el caso

de una variable discreta con pocas categorías, la frecuencia puede tabularse en cada valor de la variable; en cambio, si los valores posibles presentan una amplitud muy grande, resultará práctico subdividir la amplitud en categorías. En la tabla 1.3 se muestra un ejemplo. (En este ejemplo el lector apreciará la distinción entre los dos tipos de recuentos: la variable, que constituye el número de lesiones de una membrana corioalantoidea determinada, y la frecuencia, que es el número de membranas en que la variable se encuentra dentro de un intervalo específico.) Con las medidas continuas *siempre* se deben formar grupos interválicos (tabla 1.4). En la tabla 1.4 también se tabulan las frecuencias relativas acumuladas. Éstas dan los porcentajes del total de sujetos que tienen una edad inferior al límite inferior del siguiente intervalo. Así, el 9,8% de los sujetos están en los grupos de edad de 25-34 años y de 35-44 años y por consiguiente son menores de 45 años.

Las ventajas de presentar los datos en forma de una distribución de frecuencias en lugar de hacerlo en una larga lista de observaciones individuales son tan evidentes que no necesitan subrayarse. Por otra parte, si sólo existen unas pocas observaciones, la distribución de frecuencias tendrá poco valor porque el número de casos pertenecientes a cada grupo sería demasiado pequeño para originar un patrón interpretable.

Vamos a examinar con más detalle la elaboración práctica de una distribución de frecuencias. Si se va a agrupar la variable se deben decidir los límites de los grupos. Por comodidad, se deben escoger, en la medida de lo posible, números «redondos». Por ejemplo, para las distribuciones de edad es habitual utilizar como extremos de los grupos múltiplos de 5 o de 10. Se debe tener cuidado al decidir el grupo en el que se incluirá una observación que coincida con uno de los extremos, y esto debe quedar claro para el lector. Generalmente, estas observaciones suelen incluirse en el grupo cuyo límite inferior coincide con la observación. Por ejemplo, en la tabla 1.3 un recuento de 20 lesiones se incluiría en el grupo 20-, que comprende todos los recuentos entre 20 y 29, y esta convención se indica con la notación usada para los grupos.

Tabla 1.3. Distribución de frecuencias del número de lesiones causadas por el virus de la varicela en membranas de huevo.

Número de lesiones	Frecuencia (número de membranas)	Frecuencia relativa (%)
0-	1	1
10-	6	8
20-	14	18
30-	14	18
40-	17	21
50-	8	10
60-	9	11
70-	3	4
80-	6	8
90-	1	1
100-	0	0
110-119	1	1
Total	80	101

Tabla 1.4. Distribución de frecuencias de las edades de 1357 pacientes de sexo masculino con cáncer de pulmón.

Edad (años)	Frecuencia (número de pacientes)	Frecuencia relativa (%)	Frecuencia relativa acumulada (%)
25-	17	1,3	1,3
35-	116	8,5	9,8
45-	493	36,3	46,1
55-	545	40,2	86,3
65-74	186	13,7	100,0
Total	1.357	100,0	

¿Cuántos grupos debe haber? No puede darse una regla exacta. Una norma práctica sería que, para conseguir una descripción concisa y útil de la naturaleza de la distribución, cinco grupos son demasiado pocos, y más de 20, excesivos. Si se elige un número de grupos muy elevado, el investigador puede encontrar que muchos grupos presentan frecuencias demasiado pequeñas para proporcionar una regularidad a la forma de la distribución. Para un tamaño determinado del intervalo de agrupación, esta dificultad aumentará a medida que se reduzca el número total de observaciones, y la elección del intervalo de agrupación puede, en consecuencia, depender de este número. Si existen dudas, es posible escoger grupos interválicos menores que los que se utilizarán finalmente y reunirlos del modo más apropiado después de haber hecho la distribución.

El recuento debe realizarse recorriendo sistemáticamente la lista de datos y haciendo una marca en el grupo apropiado. Este proceso se ilustra en la tabla 1.5. Es conveniente formar grupos de cinco marcas para facilitar el recuento. Se debería repetir todo el proceso como comprobación. Un método alternativo, que consiste en considerar cada grupo sucesivamente y contar las observaciones que caen en él, no es recomendable porque obliga a examinar toda la lista de observaciones, una vez para cada grupo (o más de una si es necesaria una comprobación), y ello conduce a errores.

Si el número de observaciones no es demasiado elevado (p. ej., menor de 50), se puede representar gráficamente una distribución de frecuencias mediante un diagrama como el de la figura 1.5. En este caso, cada observación es representada por un punto o por cualquier otro signo, frente al punto correspondiente de la escala. La forma general de la distribución puede apreciarse a simple vista y es fácil comparar visualmente dos o más distribuciones de la misma variable (como en la fig. 1.5). Éste no es un método adecuado cuando se cuenta con un elevado número de observaciones porque las marcas tienden a embarullarse; resulta más práctico un gráfico de *caja y bigote* (v. fig. 1.12).

Cuando el número de observaciones es grande, los datos originales pueden agruparse en una tabla de distribución de frecuencias; en este caso, el diagrama apropiado es el *histograma*. En este tipo de diagrama los valores de la variable se representan, por convención, en la escala horizontal, mientras que la escala vertical representa la frecuencia o la frecuencia relativa para cada valor o para cada grupo. Si la variable es discreta y no está agrupada (fig. 1.6), las frecuencias pueden representarse mediante líneas verticales. El método más general, que debe aplicarse si la variable está agrupada, consiste en dibujar rectángulos sobre cada grupo (figs. 1.7 y 1.8). Puede ocurrir que los grupos interválicos no tengan una amplitud constan-

Tabla 1.5. Elaboración práctica de una distribución de frecuencias.

Recuentos de tripanosomas en sangre de cola de rata, cada uno perteneciente a una célula diferente de un hemocitómetro															
4	6	2	2	2	1	3	5	1	2	2	3	2	4	1	1
5	3	2	6	4	3	3	1	2	6	7	3	5	5	2	2
5	5	6	2	5	1	3	1	9	1	1	2	2	4	1	1
4	4	4	6	1	2	2	1	2	1	0	3	3	4	3	1
4	2	6	2	3	3	7	4	2	6	1	5	2	2	1	9
3	4	4	1	4	6	4	2	5	4	5	4	5	5	6	2
3	1	0	1	5	5	2	2	6	1	3	1	1	1	5	3
1	0	1	5	3	3	6	8	2	0	1	3	6	2	3	5

Pasos en la formación de una distribución de frecuencias.

Recuentos	Primera marca	Primeras 5 marcas (leyendo horizontalmente)	Marcas resultantes	Frecuencia
0				4
1				27
2				27
3				20
4				16
5				17
6				12
7				2
8				1
9				2
				128

te. Por ejemplo, supongamos que en la tabla 1.3 decidimos unir los grupos 60–, 70–, 80–. La frecuencia total de este nuevo grupo es 18, pero sería erróneo representar esta frecuencia mediante un rectángulo cuya base se extendiera desde 60– hasta 90– y con una altura de 18. El procedimiento correcto consistiría en construir un rectángulo con una altura de 6, la frecuencia media de los 3 grupos (como está indicado con la línea de puntos en la fig. 1.7). Una manera de interpretar esta regla sería que la altura del rectángulo en un histograma es la frecuencia multiplicada por el grupo estándar de la variable (en este ejemplo, el grupo estándar es «10 lesiones»). Otra interpretación consiste en que la frecuencia de un grupo es más proporcional al *área* que a la altura del rectángulo (en este ejemplo, el área de cualquiera de los rectángulos originales o del rectángulo compuesto formado por la línea de puntos es 10 veces la frecuencia del grupo). Si la longitud del intervalo no varía, las áreas son proporcionales a las alturas, y las frecuencias están representadas tanto por las alturas como por las áreas.

La frecuencia relativa acumulada puede representarse mediante un diagrama lineal (fig. 1.9). La colocación de los puntos en el eje de la edad requiere especial atención, ya que




Fig. 1.5. Diagrama de puntos que muestra la distribución de la excreción urinaria de bufotenina en tres grupos de individuos. (Tomada de Räisänen y cols, 1984, con permiso de los autores y del editor de *The Lancet*.)




Fig. 1.6. Histograma que representa la distribución de frecuencias de una variable discreta no agrupada (número de varones en grupos de ocho).

en la distribución de frecuencias (tabla 1.4) se colocan las frecuencias relativas acumuladas en la columna final frente al inicio del grupo de edad en la siguiente línea. Es decir, como ninguno de los varones es menor de 25 años, en el eje vertical se sitúa cero en la edad 25 años; el 1,3% corresponde a menores de 35 años y por esta razón se coloca 1,3% en la edad 35 años, 9,8% en la edad 45 años, y así sucesivamente, hasta el 100% a los 75 años.

El *diagrama de tallo y hojas*, ilustrado en la tabla 1.6, es un método útil para tabular los datos originales y, al mismo tiempo, para representar la forma de la distribución de frecuencias. La primera columna de la tabla 1.6 constituye la cifra inicial del recuento, y en cada fila (el «tallo»), los números de la derecha (las «hojas») son los valores de la segunda cifra de las diversas observaciones de este grupo. Por consiguiente, la única observación en el primer grupo es 7, y las observaciones del segundo grupo son 10, 12, 14, 17, 17 y 19.

Las hojas se han ordenado en cada tallo. El parecido entre la forma del gráfico de tallo y hojas y la del histograma de la figura 1.7 es evidente.

El número de asteriscos (*) indica el número de cifras necesarias para cada hoja. De este modo, en la tabla 1.6 aparece un asterisco para indicar que las observaciones requieren sólo una cifra de las hojas además de la que encabeza la fila. Supongamos que en la distribución de la tabla 1.6 sólo hubieran aparecido cuatro valores aberrantes por encima de 100: por ejemplo, 112, 187, 191 y 248. Sería mejor utilizar un intervalo de mayor amplitud para estas lecturas que disponer de un número elevado de tallos sin hojas y de unos pocos con sólo una hoja. Las observaciones superiores a 100 se expresarían de la siguiente forma:

1**	12,	87,	91
2	48		




Fig. 1.7. Histograma que representa la distribución de frecuencias de una variable discreta agrupada (tabla 1.3).




Fig. 1.8. Histograma que representa la distribución de frecuencias de una variable continua (edad de 1 357 varones con cáncer de pulmón, tabla 1.4). Nótese que la variable que se muestra en esta figura es la edad exacta. La edad en el último aniversario es una variable discreta y sería representada por grupos desplazados medio año hacia la izquierda con respecto a los que se muestran aquí (v. tabla 1.8).




Fig. 1.9. Gráfica de frecuencia acumulada de las edades de 1.357 varones con cáncer de pulmón (tabla 1.4 y fig. 1.8).

En ocasiones puede ser aceptable perder algunas de las cifras menos significativas. Así, si dichos recuentos elevados se necesitan exclusivamente con una precisión de decenas, podrían expresarse como:

1**	199
2	5

que representan 110, 190, 190 y 250.

Para conocer otras variantes del diagrama de tallo y hojas, se recomienda la obra de Tukey (1977).

Tabla 1.6. Diagrama de tallo y hojas de una distribución del número de lesiones causadas por el virus de la viruela en membranas de huevo (v. tabla 1.3).

Número de lesiones	
0*	7
1	024779
2	11122266678999
3	00223456788999
4	01233346677888999
5	11234478
6	014567779
7	057
8	023447
9	8
10	
11	2

Si el propósito fundamental de una representación gráfica consiste en comparar dos o más distribuciones, el histograma no es la herramienta más adecuada. Los histogramas superpuestos suelen ser confusos, y los separados se encuentran demasiado distantes para permitir una buena comparación. En este caso es preferible el diagrama de puntos de la figura 1.5 o el gráfico de caja y bigote de la figura 1.12. Como alternativa, se pueden usar las representaciones de figuras tridimensionales que existen actualmente en los programas informáticos; en la figura 1.10 se muestra un ejemplo de un diagrama de barras representado en función de dos variables simultáneamente. Hay que tener cuidado de no engañarse con los efectos de la perspectiva.

La frecuencia de una distribución o de un histograma no se expresa a menudo como un recuento absoluto sino como una frecuencia relativa, es decir, como una proporción o porcen-




Fig. 1.10. Diagrama de barras «tridimensional» que muestra el riesgo relativo de cardiopatía coronaria según la concentración de colesterol de lipoproteínas de alta densidad (HDL) y según los triglicéridos. (Reproducido con autorización de Simons et al, 1991.)

taje de la frecuencia total. Si el grupo estándar de la variable, en los términos en los que están expresadas las frecuencias, es una unidad, el área total contenida en el histograma será 1 (o 100% si se utilizan frecuencias porcentuales) y el área entre 2 puntos cualesquiera será la frecuencia relativa en este intervalo.

Supongamos que tenemos una distribución de las frecuencias de alturas de 100 hombres agrupadas en intervalos de 1 cm. Las frecuencias serían bastante irregulares, especialmente cerca de los extremos de la distribución, a causa de las frecuencias bajas en alguno de los grupos. Si aumentara el número de observaciones, por ejemplo a 1.000, la tendencia de las frecuencias se suavizaría y podríamos reducir el agrupamiento a 0,5 cm, haciendo, sin embargo, que la escala vertical del histograma siga representando la frecuencia relativa por centímetros. Podríamos imaginar la perpetuación del proceso si no existiera un límite en la precisión de la medida de la longitud o en el número de observaciones que pudiéramos realizar. En esta situación imaginaria, el histograma se acercaría cada vez más a una curva uniforme, la *curva de frecuencias*, que puede considerarse como una forma ideal de histograma (fig. 1.11). El área contenida entre dos ordenadas trazadas sobre dos valores de la variable representará la frecuencia relativa de observaciones entre estos dos puntos. Estas curvas de frecuencia son útiles como modelos en los que se basa la teoría estadística y deberían interpretarse como aproximaciones ideales a los histogramas que podrían obtenerse en la práctica con un gran número de observaciones de una variante que pudiera medirse con mucha precisión.

Vamos a examinar ahora algunos rasgos que caracterizan a las distribuciones de frecuencia. El valor de la variable en el que la curva de frecuencias alcanza el máximo se denomina *moda*. La mayoría de las distribuciones de frecuencia en la práctica tienen una moda y se denominan *unimodales*. Por ejemplo, la moda de la distribución de frecuencias de la figura 1.6 es de 4 varones, y la de la tabla 1.3, 40-49 lesiones. En general como ocurre en estos dos ejemplos, la curva adopta una forma de «campana»; es decir, la moda se encuentra en algún punto entre los dos extremos de la distribución. Estos extremos, en los que las frecuencias son bajas, se denominan *colas*. Algunas distribuciones tienen la moda en un extremo de su amplitud. Por ejemplo, si se está estudiando la emisión de partículas gamma de algún material




Fig. 1.11. Histograma que representa la distribución de frecuencias de numerosas medidas finamente subdivididas, con una curva de frecuencias aproximada.

radiactivo, la distribución de frecuencias del intervalo de tiempo entre emisiones sucesivas presenta una configuración similar a la letra J (o, mejor aún, su imagen en espejo) con una moda igual a cero. De forma similar, si observamos familias con 4 hijos y registramos el número de ellas que cuentan con 0, 1, 2, 3 o 4 casos de poliomielitis, en 0 encontraremos una moda muy pronunciada.

Algunas distribuciones contendrán más de una moda debido a las inevitables fluctuaciones aleatorias de los números pequeños. Por ejemplo, en la tabla 1.3 las frecuencias observadas muestran varias modas con valores comprendidos entre 60-69, 80-89 y 110-119, aunque no deberíamos prestarles demasiada atención. En ocasiones se encuentran distribuciones que, aunque contengan un elevado número de observaciones, tienen más de una moda. Se ha discutido mucho si la distribución de la presión sanguínea de una gran población exenta de cualquier problema circulatorio es *bimodal*, es decir, si tiene dos modas, porque la presencia de una segunda moda en las presiones más elevadas que la moda principal podría indicar que una proporción importante de la población padece hipertensión esencial.

Otra característica de interés es la simetría o la ausencia de simetría de la distribución. Una distribución asimétrica se dice que está *sesgada*. La distribución de la figura 1.6 es muy simétrica alrededor de la moda. La de la tabla 1.3 y la de la figura 1.7, cuya cola superior es mayor que la inferior, se dice que presentan una *asimetría positiva*. Las distribuciones de la tabla 1.4 y de la figura 1.8 muestran una ligera asimetría negativa.

Otras dos características de las distribuciones revisten tanta importancia que les dedicaremos dos apartados separados. Se trata de la tendencia central, o localización general de la distribución en la escala de la variable, y del grado de variación de las observaciones alrededor del centro de la distribución. De hecho, las medidas de tendencia central y de variación son tan importantes que en primer lugar las trataremos sin hacer referencia a las distribuciones de frecuencia.

1.5. Media y otras medidas de tendencia central

A veces es importante ofrecer, mediante un solo número, alguna información sobre el nivel general de una serie de mediciones. Esta cifra puede denominarse *medida de localización*, *medida de tendencia central*, *media* o *promedio*. La más familiar de estas medidas es la *media aritmética* y suele identificarse con el «promedio». En estadística el término suele abreviarse como «media».

La media es la suma de las observaciones dividida por el número de observaciones. En estos casos, es difícil expresar verbalmente las reglas de cálculo y, por ello, haremos un inciso para acordar una anotación adecuada. Para referirse a una variable determinada suelen utilizarse símbolos algebraicos como x o y . Para cada variable puede existir una o varias observaciones. Si existen n observaciones de la variable x , se expresarán de la siguiente forma:

$$x_1, x_2, x_3, \dots, x_{n-1}, x_n$$

Las distintas x no deben disponerse, necesariamente, por orden de magnitud. Han de disponerse en el orden en que fueron observadas o calculadas. A menudo es útil hacer referencia a algún miembro típico del grupo para mostrar los cálculos que van a realizarse en cada miembro. Ello se efectúa introduciendo un subíndice genérico, (*dummy*), por lo general una i

o una j . Por consiguiente, si x es la altura de un escolar y $x_1, x_2, \dots, x_n$ son los n valores de x , un valor típico puede representarse por x_j .

La media aritmética de las x puede representarse por $\bar{x}$ (en lenguaje oral «x barra»). Así:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}.$$

La suma que aparece en el numerador puede indicarse utilizando el *signo sumatorio* Σ (letra mayúscula «sigma» del alfabeto griego) que significa «suma de» o «sumatorio de». Encima y debajo del signo sumatorio se indica la amplitud de los valores que abarca el subíndice. De este modo:

$$\text{y} \quad \sum_{i=1}^n x_i = x_1 + x_2 + \dots + x_n.$$

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}.$$

Si, como sucede en este ejemplo, están claros los valores que toma el subíndice a lo largo del sumatorio, se puede omitir la amplitud de éste e, incluso, en ocasiones el subíndice. Por ello:

$$\sum_{i=1}^n x_i$$

en ocasiones puede abreviarse como:

$$\Sigma x_i \text{ o } \Sigma x.$$

En ocasiones, en lugar del símbolo Σ se utiliza la letra mayúscula S . Es importante advertir que Σ representa una operación (la de la suma de las cantidades que siguen) más que una cantidad.

Mediante la introducción de *cambios de variables* se puede conseguir simplificar el cálculo de la media. En la tabla 1.7 se muestran algunos ejemplos sencillos. En 1 las x son muy próximas entre sí en relación con la media, y una variable cómoda para trabajar es $u = x - 100$, que provoca un cambio de origen. Obtenemos $\bar{u} = 5$ y volvemos a la variable original haciendo $\bar{x} = 100 + \bar{u} = 105$. En 2 un factor de 1.000 es superfluo para el cálculo. Por ello hacemos un cambio de escala, tomando como unidad de trabajo $u = x/1.000$. Obtenemos $\bar{u} = 5$ y volvemos a la variable original con la fórmula $\bar{x} = \bar{u} \times 1.000$. En 3 se ilustra un cambio conjunto de origen y de escala.

Los cambios de variables son muy útiles cuando los cálculos se efectúan mentalmente. En la práctica, es preferible efectuar los cálculos con una calculadora, aunque se realicen más de los necesarios, para evitar escribir las nuevas variables y, quizás, introducir errores al hacerlo. Sin embargo, el principio que subyace al cambio de variable es importante y el lector debe familiarizarse con su uso.

En ocasiones se necesita calcular la media de una serie de mediciones con las que se ha construido una distribución de frecuencias, sin poder recurrir a la lista original. Incluso aunque se tenga la lista original, si el número de observaciones es muy elevado y no se dispone de

Tabla 1.7. Utilización de cambios de variable en el cálculo de una media.

(1)		(2)		(3)	
x	$u = x - 100$	x	$u = x/1.000$	x	$u = (x - 1.000)/10$
102	2	2.000	2	1.020	2
104	4	4.000	4	1.040	4
105	5	5.000	5	1.050	5
109	9	9.000	9	1.090	9
	<u>20</u>		<u>20</u>		<u>20</u>
$\bar{u} = 20/4 = 5$		$\bar{u} = 20/4 = 5$		$\bar{u} = 20/4 = 5$	
$\bar{x} = 100 + \bar{u} = 105$		$\bar{x} = 1.000\bar{u} = 5.000$		$\bar{x} = 1.000 + 10\bar{u} = 1.050$	

la ayuda de un ordenador, se puede construir previamente la distribución para ahorrar trabajo de cálculo, aunque, si es posible, es preferible trabajar con las observaciones originales.

Si la distribución se expresa mediante agrupaciones de la variable original, los cálculos no proporcionarán el valor exacto de la media (excepto por casualidad). La media depende del valor exacto de cada observación, y estos valores se pierden cuando se adopta un sistema de agrupación. Lo máximo que podemos esperar es obtener un valor aproximado de la media. Los cálculos se ilustran en la tabla 1.8. Se debe elegir algún valor concreto para representar las operaciones de cada grupo, y lo más sencillo es suponer que se encuentra en el punto medio de cada grupo.

En la tabla 1.8, por lo tanto, suponemos que hay 17 observaciones a los 30 años, 116 observaciones a los 40 años, y así sucesivamente. Para obtener la edad media podríamos formar una suma añadiendo 30, 17 veces, 40, 116 veces, y así sucesivamente, y por último dividiendo por 1 357. La columna 1 muestra la contribución de cada grupo a la suma de las edades. La edad media calculada es de 55,7 años.

La determinación del punto medio de cada grupo requiere un conocimiento del alcance del redondeo —si éste se efectuó— de las lecturas originales. En el ejemplo anterior, el intervalo de edades de los individuos incluidos en el grupo 25— oscilaría desde 25 años y 0 días hasta 34 años y 364 días, y el punto medio sería 30 años. Por otra parte, si la variable fuera longitud en metros, redondeando al medio metro más próximo, el grupo incluiría las longitudes desde 24,75 hasta 34,75 m, y el punto medio valdría 29,75 m. Si las lecturas originales fueran números enteros o se redondearan al número entero más próximo, el punto medio sería 29,5. La edad es una variable poco usual porque se redondea por defecto. En muchas investigaciones, las edades se registran sólo como «edad en el último cumpleaños». La media de una serie de «edades en el último cumpleaños» será, aproximadamente, medio año por debajo de la media de las edades exactas, y es muy común expresarlo de esta manera sólo con añadir medio año para obtener una estimación de la edad media exacta. En el ejemplo de la tabla 1.8 hemos considerado necesaria la media exacta de la edad. Si hubiéramos querido obtener la media de la «edad en el último cumpleaños», el punto medio habría sido 29,5 (el punto medio de 25, 26, ..., 34), 39,5, etc., y la media calculada de la edad desde el último cumpleaños habría sido 55,2 años en lugar de 55,7.

Otra medida útil de tendencia central es la *mediana*. Si las observaciones se disponen en orden creciente o decreciente, la mediana es la observación central. Si el número de obser-

Tabla 1.8. Cálculo de la media a partir de la distribución de frecuencias (datos de la tabla 1.4).

Edad (años)	Frecuencia f	Punto medio x (años)	años
25-	17	30	510
35-	116	40	4,640
45-	493	50	24,650
55-	545	60	32,700
65-74	186	70	13,020
	1,357		75,520
$\bar{x} = \frac{75,520}{1,357} = 55,7 \text{ años}$			

vaciones, n , es impar, existirá una única mediana: la observación que ocupe la posición $(n + 1)/2$ a partir de cada extremo. Si n es par no existe en rigor una observación central y, en este caso, la mediana se define por convención como la media de las dos observaciones centrales: la observación $\frac{n}{2}$ y la $\frac{n}{2} + 1$ a partir de cada extremo.

La mediana presenta algunas desventajas en relación con la media:

1. No tiene en cuenta la magnitud exacta de la mayoría de las observaciones y por ello es menos eficaz que la media porque implica una pérdida de información.
2. Si se unen dos grupos de observaciones, la mediana del grupo resultante no puede expresarse a partir de las medianas de los dos grupos componentes. Ello no ocurre con la media. Si dos grupos con n_1 y n_2 observaciones tienen como medias $\bar{x}_1$ y $\bar{x}_2$, respectivamente, la media del grupo resultante de su unión es

$$(n_1\bar{x}_1 + n_2\bar{x}_2)/(n_1 + n_2).$$

3. La mediana es mucho menos manejable que la media para el tratamiento matemático, y se utiliza poco en las técnicas estadísticas muy complejas.

Sin embargo, la mediana suele ser útil para el trabajo descriptivo. Consideramos la siguiente serie de duración (en días) de la ausencia laboral por enfermedad:

1, 1, 2, 2, 3, 3, 4, 4, 4, 4, 5, 6, 6, 6, 6, 7, 8, 10, 10, 38, 80

Desde un punto de vista exclusivamente descriptivo, podría decirse que la media es engañosa. Debido a la naturaleza muy asimétrica de la distribución, la media de 10 días no es realmente típica de la serie como conjunto y, en este caso, la mediana de días podría ser un índice más útil. Otro aspecto es que en este tipo de distribuciones asimétricas la media está mucho más influida por la presencia de valores elevados aislados. Por consiguiente, la mediana es más estable que la media en el sentido de que fluctúa mucho menos de una serie de lecturas a otra.

El cálculo de una mediana a partir de una distribución agrupada de frecuencias se ilustra en la tabla 1.4. Necesitamos el valor de edad por debajo del cual se calcula que se sitúa el 50% de las observaciones. Tenemos que:

el 46,1% de los pacientes tienen una edad inferior a 55 años,

el 86,3% de los pacientes tienen una edad inferior a 65 años.

La mediana se encuentra claramente entre 55 y 65 años y se calcula mediante una interpolación lineal como la siguiente:

$$55 + \left(\frac{50,0 + 46,1}{86,3 - 46,1} \times 10 \right) = 56,0 \text{ años}$$

un valor muy ligeramente superior a la media de 55,7 años. Este método corresponde al gráfico de frecuencia acumulada (fig. 1.9). La mediana puede leerse en este gráfico encontrando el punto en el eje de la edad correspondiente al 50% del eje de la frecuencia relativa acumulada.

La media y la mediana coinciden si la serie de observaciones está distribuida simétricamente alrededor de su valor más frecuente (como casi sucede en el caso ilustrado en la tabla 1.8). En una distribución sesgada positivamente (como la de la tabla 1.3), la media será mayor que la mediana, mientras que en una distribución con asimetría negativa la mediana será mayor.

Una tercera medida de tendencia central, la moda, fue introducida en el apartado 1.4. No suele emplearse en los análisis estadísticos fundamentalmente a causa de la ambigüedad de su definición y porque las fluctuaciones de las frecuencias pequeñas tienden a originar falsas modas.

Por último, se debe hacer referencia a la *media geométrica*, muy utilizada en investigación en microbiología y en serología. A veces, las observaciones se expresan como *títulos*, que representan la primera dilución de ciertas suspensiones o reactivos en la que se producen ciertos fenómenos específicos, como la aglutinación de los hematíes. Si se efectúan varias observaciones repetidas durante la misma investigación, los valores posibles de un título serán múltiplos del mismo factor de dilución; por ejemplo, 2, 4, 8, 16, etc., para diluciones dobles. Con mucha frecuencia ocurre que una serie de títulos obtenidos, por ejemplo de diferentes sueros, presenta una acusada asimetría positiva a causa de que los intervalos vacíos entre los valores posibles son progresivamente mayores. Ahora bien, si una serie de números aumenta según un factor de multiplicación constante, sus logaritmos deben aumentar en función de una diferencia que equivale al logaritmo del factor de multiplicación. Por ejemplo, la serie de títulos 2, 4, 8, 16, etc., presenta logaritmos aproximadamente iguales a 0,3, 0,6, 0,9, 1,2, etc., que se incrementan sucesivamente en 0,3 ($= \log 2$). A menudo se comprueba empíricamente que la utilización del logaritmo del título, en lugar del título, da origen a una serie de observaciones que se distribuyen de forma más simétrica y para las cuales es más adecuado el uso de la media aritmética. Indiquemos el título por x y su logaritmo por $u (= \log x)$. La media aritmética de u , se mide, al igual que los valores individuales de u , en una escala logarítmica, y para volver a la escala original utilizamos la expresión

$\bar{x}_g = \text{antilog } \bar{u}$. Ésta se denomina media geométrica de x . Nunca puede ser mayor que la media aritmética, y ambas medias sólo coincidirán cuando todas las x sean iguales.

La media geométrica no puede utilizarse si las observaciones originales son negativas, dado que un número negativo no tiene logaritmo. Su empleo en series de diluciones es particularmente apropiado porque las series logarítmicas subyacentes están separadas por intervalos iguales, pero también se puede utilizar de un modo más general cuando una serie de lecturas positivas muestra un sesgo positivo que desaparece al manejar logaritmos. Por ello, las condiciones en que se puede utilizar son similares a aquellas en que se emplea la mediana e, incluso, para este tipo de datos, la mediana y la media geométrica tendrán valores similares. Como ejemplo, consideremos el siguiente grupo de títulos de anticuerpos: 4, 8, 16, 16, 64. Sus logaritmos son 0,60, 0,90, 1,20, 1,20, 1,81. La media del logaritmo es 1,142, y la media geométrica es el antilogaritmo de 1,142 = 13,9. Por otra parte, la media aritmética de los títulos es 21,6, y la mediana, 16.

En el apartado 11.3 se describe otra medida mucho menos utilizada, la *media armónica*.

1.6. Medidas de dispersión

Cuando se ha calculado el valor de la media de una serie de mediciones suele ser muy interesante expresar el grado de variación o dispersión alrededor de esta media. ¿Se encuentran todas las medidas próximas a la media o hay algunas muy dispersas en ambas direcciones? Esta cuestión es muy importante por motivos puramente descriptivos, como veremos más adelante con más detalle. También es importante porque la medida de la variación desempeña un papel fundamental en los métodos de inferencia estadística que se describen en esta obra. Para tomar un ejemplo sencillo, la fiabilidad de la media de 100 valores de una variable determinada depende del grado en que difieran las 100 lecturas entre sí; si éstas muestran poca variación, el valor de la media será más fiable y estará determinado con mayor precisión que si los 100 valores varían ampliamente. El papel de la dispersión en la inferencia estadística se estudiará con más detalle en capítulos posteriores de esta obra. Ahora nos centraremos en los aspectos descriptivos.

En trabajos de referencia es común encontrar un único número que expresa el valor de cierta cantidad biológica, y el lector no siempre se da cuenta de que dicho valor es un tipo de promedio. En un libro de nutrición, por ejemplo, el contenido en vitamina A del queso Cheddar se expresa como 2.000 unidades internacionales (UI) por cada 100 g. Es evidente que no todas las muestras de queso Cheddar contienen exactamente 2.000 UI por cada 100 g; en consecuencia, ¿cuánta variación existe entre una muestra y otra? Para tomar otro ejemplo de la nutrición, las calorías diarias necesarias para un varón de 25 años se cifran en 3.200. Este requerimiento debe variar de una persona a otra, pero ¿qué magnitud tiene esta variación?

Difícilmente podrá plantearse una sola respuesta a estas preguntas, porque la variación que se puede encontrar en una serie de medidas dependerá de las circunstancias en que se han realizado y, en particular, en la forma en que estas circunstancias varían de una lectura a otra. El contenido en vitamina A de las muestras de queso Cheddar puede variar por muchas razones: diferencias notables entre los lugares y los métodos de elaboración, variaciones en la composición de una muestra a otra, incluso en la misma remesa, edad del queso, etc. La variación de la medida registrada puede deberse en parte a un error de medición, por ejemplo, en el análisis de laboratorio o a errores del observador. De modo similar, si nos referimos a

la variación de la presión arterial debe quedar claro el tipo de comparación previsto. ¿Estamos considerando diferencias entre varios tipos de individuos (p. ej., grupos definidos por edad o por su situación clínica), diferencias entre individuos clasificados en el mismo grupo o variaciones entre las mediciones efectuadas a un mismo individuo en dos momentos distintos? ¿Han permanecido constantes los instrumentos de medida y el observador en toda la serie?

Vamos ahora a examinar algunos métodos de medida de la variación o dispersión de una serie de mediciones continuas.

Esta dispersión constituye una de las características de los datos ilustrada mediante una distribución de frecuencias. Sin embargo, es conveniente utilizar alguna cantidad para medir esta característica de los datos por varias razones. En primer lugar, por economía de la presentación. En segundo lugar, porque los métodos estadísticos que se describirán posteriormente requieren un índice como éste. Por último, porque los datos pueden estar demasiado dispersos para poder elaborar una distribución. En consecuencia, necesitamos una medida de *variación* o de *dispersión*.

Un candidato evidente es la *amplitud*, que se define como la diferencia entre los valores máximo y mínimo. (Nótese que la amplitud es una cantidad definida, medida en las mismas unidades que las de las observaciones originales. Si los valores superior e inferior de una serie de presiones arteriales diastólicas son 95 y 65 mmHg, podemos saber no sólo —como en una conversación— que la amplitud de lectura oscila entre 65 y 95 mmHg, sino que la amplitud *es* 30 mmHg.) La utilización de la amplitud como medida de variación presenta tres dificultades importantes. La primera es que el valor numérico considerado por la amplitud está determinado exclusivamente por dos de las observaciones originales. Es cierto que si afirmamos que las lecturas máxima y mínima tienen como valores 65 y 95, estamos diciendo algo sobre las otras lecturas —que se encuentran entre estos extremos—, pero sus valores no tienen efecto sobre la amplitud. En este ejemplo, la amplitud sería 30 si: *a*) el resto de las lecturas estuvieran concentradas entre 75 y 80, o *b*) estuvieran dispersas uniformemente entre 65 y 95. Una medida adecuada de la variación del conjunto de lecturas debería ser mayor en el caso *b* que en el caso *a*. En segundo lugar, la interpretación de la amplitud depende del número de observaciones. Si éstas se seleccionan en un grupo grande de forma seriada (p. ej., determinación de la presión arterial en un individuo tras otro), la amplitud no puede disminuir; aumentará cuando una nueva lectura caiga fuera del intervalo entre los dos extremos anteriores. La interpretación de la amplitud como medida de variación de un grupo considerado en conjunto dependerá del conocimiento del número de observaciones en las que se basa, lo cual representa un inconveniente; este requerimiento no es necesario, por ejemplo, en la interpretación de una media como medida de tendencia central. En tercer lugar, los cálculos basados en los valores extremos son muy poco fidedignos porque en dos investigaciones similares pueden aparecer diferencias pronunciadas entre estos extremos.

Si el número de observaciones no es demasiado pequeño, puede introducirse una modificación que evite la utilización de los valores extremos absolutos. Si las lecturas se disponen en orden creciente o decreciente, se pueden encontrar dos valores que corten una pequeña fracción de las observaciones en cada extremo, del mismo modo que la mediana divide la distribución en dos partes iguales. El valor por debajo del cual se encuentra un cuarto de las observaciones ordenadas se denomina *cuartil inferior*, el que es superado por un cuarto de las observaciones, *cuartil superior*, y la distancia entre ambos, *distancia intercuartil*. Ésta no se

halla sujeta a la segunda desventaja que presenta la amplitud, aunque sí lo está, en menor cuantía, a las restantes desventajas.

La evaluación de los cuartiles para un grupo de n valores se consigue calculando en primer lugar los intervalos correspondientes mediante las siguientes fórmulas:

$$r_l = \frac{1}{4}n + \frac{1}{2}$$

y

$$r_u = \frac{3}{4}n + \frac{1}{2}$$

y calculando a continuación los cuartiles como los valores correspondientes en el conjunto ordenado de valores, usando la interpolación si es necesario. Por ejemplo, en los datos sobre la duración de la ausencia del trabajo (pág. 27) donde n es 21, $r_l = 5 \frac{3}{4}$ y $r_u = 16 \frac{1}{4}$. Seguidamente se obtiene el cuartil inferior mediante la interpolación entre el 5º y el 6º valores; ambos son 3 días, de modo que el cuartil inferior también es 3 días. El cuartil superior se obtiene mediante la interpolación entre el 16º y el 17º valores, 7 y 8 días. La interpolación requiere desplazarse $\frac{1}{4}$ del camino entre el 16º valor hacia el 17º valor, para dar $7 + \frac{1}{4}(8 - 7) = 7 \frac{1}{4}$ días. Hay que señalar que no existe una convención estándar única para calcular los cuartiles. Algunos autores definen éstos en términos de los intervalos $r_l = \frac{1}{4}(n + 1)$ y $r_u = \frac{3}{4}(n + 1)$. También es frecuente redondear $\frac{1}{4}$ y $\frac{3}{4}$ al número entero más próximo y usar sólo la interpolación cuando ello implica el cálculo del punto medio entre dos valores. Las diferencias entre los resultados usando las diferentes convenciones son por lo general pequeñas y en la práctica carecen de importancia.

Los cuartiles son ejemplos particulares de la cantidad más general, el *percentil*. El valor por debajo del cual se sitúa el $P\%$ de los valores se denomina percentil P -ésimo. Así, los cuartiles inferior y superior son los percentiles 25º y 75º respectivamente. Los cuartiles o cualesquiera otros percentiles se pueden leer a partir de una gráfica de frecuencia relativa acumulada como la de la figura 1.9.

Un método práctico de representar la localización y la variabilidad de un conjunto de datos es el gráfico de caja y bigotes. La forma básica de este gráfico muestra una caja definida por los cuartiles superior e inferior y con la mediana marcada por una subdivisión de la caja. Los bigotes se extienden desde ambos extremos de la caja hasta los valores máximo y mínimo. Las elaboraciones de este gráfico muestran posibles valores aberrantes (v. apartado 11.6) separadamente más allá de los extremos de los bigotes mediante una nueva definición de los bigotes para tener una extensión máxima en términos del intervalo intercuartiles. Los gráficos de caja y bigotes facilitan la comparación visual de los grupos. En la figura 1.12 se muestra una comparación del peso de recién nacidos de dos grupos de madres vietnamitas inmigrantes; un grupo consumía una dieta tradicional, y el otro, una dieta no tradicional. En esta gráfica los bigotes se extienden hasta las observaciones más extremas dentro de $\pm 1,5$ intervalos intercuartiles de los cuartiles, y los puntos más extremos se muestran individualmente. La mediana y los cuartiles superiores del grupo que consumía la dieta no tradicional se ven claramente, al igual que la variabilidad más baja asociada a esta dieta.

Un planteamiento alternativo consiste en emplear todas las desviaciones con respecto a la media, $x_i - \bar{x}$. Es evidente que cuanto mayor sea la dispersión de las observaciones, mayor tenderá a ser la magnitud de estas desviaciones. No sería útil tomar la media de las desviaciones $x_i - \bar{x}$, porque unas serán negativas y otras positivas. De hecho,




Fig. 1.12. Gráfica de caja y bigotes en que se comparan las distribuciones del peso al nacer niños de dos grupos de madres vietnamitas (datos de J. Mitchell).

$$\begin{aligned}
 \sum (x_i - \bar{x}) &= \sum x_i - \sum \bar{x} \\
 &= \sum x_i - n\bar{x} \\
 &= 0 \text{ puesto que } \bar{x} = \sum x_i / n
 \end{aligned}$$

Por consiguiente, la media de las desviaciones $x_i - \bar{x}$ será siempre cero. Sin embargo, podríamos tomar la media de las desviaciones sin tener en cuenta su signo, es decir, considerándolas todas positivas. Estas cantidades se denominan valores absolutos de las desviaciones y se expresan como $|x_i - \bar{x}|$. Su media, $\sum |x_i - \bar{x}| / n$, se denomina *desviación media*. Esta medida presenta el inconveniente de ser difícil de manejar matemáticamente, y no la consideraremos en esta obra.

Otra manera de superar la dificultad que representan los signos positivos y negativos es elevar dichas diferencias al cuadrado. La medida de las desviaciones al cuadrado se denomina *variancia* y es una de las medidas más importantes en estadística. Su fórmula es:

$$\text{Variancia} = \frac{\sum (x_i - \bar{x})^2}{n} \quad (1.1)$$

El numerador a menudo se denomina *suma de los cuadrados alrededor de la media*. La variancia se mide en unidades de x al cuadrado. Por ejemplo, si x representa la altura en cen-

tímetros, la variancia se medirá en cm^2 . Esto podría parecer poco importante porque estas unidades suelen utilizarse como medidas de área. Si x fuera una medida de tiempo en segundos, sería poco deseable tener una dispersión medida en segundos al cuadrado. Por consiguiente, es conveniente emplear una medida de variación expresada en las unidades originales de x ; esto puede obtenerse extrayendo la raíz cuadrada de la variancia. Esta cantidad se conoce como *desviación tipo* o *estándar*, y su fórmula es;

$$\text{Desviación tipo} = \sqrt{\left[\frac{\sum (x_i - \bar{x})^2}{n} \right]} \quad (1.1a)$$

En la práctica, al calcular las variancias y las desviaciones estándar se sustituye casi siempre la n del denominador por $n - 1$. El motivo es que al aplicar los métodos de inferencia estadística, que se desarrollarán más adelante, es útil considerar el conjunto de observaciones como una *muestra* extraída de un grupo mucho más numeroso de lecturas posibles. Este grupo más numeroso suele denominarse *población*. Cuando calculamos una variancia o una desviación tipo podemos desear no describir simplemente la variación en la muestra que estamos tratando, sino también estimar, de la mejor forma posible, la variación en la población de la que suponemos que se ha extraído la muestra. En cierto modo (v. apartado 3.4), se obtiene una mejor estimación de la variancia poblacional utilizando como divisor $n - 1$ en lugar de n . Por este motivo, debemos usar casi siempre la fórmula para la *variancia estimada* o *variancia de la muestra*:

$$\text{Variancia estimada, } s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1} \quad (1.2)$$

y de modo análogo:

$$\text{Desviación tipo estimada, } s = \sqrt{\left[\frac{\sum (x_i - \bar{x})^2}{n - 1} \right]} \quad (1.2a)$$

Por convención, muy a menudo se omite la palabra «estimada», expresándose la «variancia» como s^2 y la «desviación tipo» como s .

La modificación del divisor, que sustituye n por $n - 1$, no reviste gran importancia cuando n es grande. Es mucho más importante para pequeños valores de n . Aunque la justificación teórica se analizará más ampliamente en el apartado 3.4, podemos ofrecer dos argumentos heurísticos que lo harán más verosímil. En primer lugar, consideremos el caso cuando $n = 1$, es decir que existe una única observación. Con la fórmula (1.1) con n como divisor, se obtiene una variancia de $0/1 = 0$. Ésta es una forma razonable de expresar la ausencia completa de variación en la observación disponible: ésta no difiere de sí misma. Por otra parte, una única observación no proporciona información alguna sobre la variación en la población de la que se extrajo la muestra; este hecho se ve reflejado en el cálculo de la variancia estimada, s^2 , mediante (1.2), que resulta $0/0$, es decir, una cantidad indeterminada.

En segundo lugar, en el caso general, cuando n toma cualquier valor, ya hemos visto que $\sum (x_i - \bar{x}) = 0$. Esto significa que si $n - 1$ de estas desviaciones $x_i - \bar{x}$ se eligen en forma arbitraria, automáticamente queda determinado el valor de la enésima (que es la suma de los $n - 1$ valores elegidos de $x_i - \bar{x}$ cambiada de signo). En otras palabras, sólo $n - 1$ de las n des-

Tabla 1.9. Cálculo de la variancia y de la desviación tipo estimadas: fórmula directa

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
8	0	0
5	-3	9
4	-4	16
12	4	16
15	7	49
5	-3	9
7	-1	1
$\Sigma x_i = 56$		$\Sigma (x_i - \bar{x})^2 = 100$
$n = 7$		
$\bar{x} = 56/7 = 8$		
$s^2 = 100/6 = 16,67$		
$s = \sqrt{16,67} = 4,08$		

viaciones que están elevadas al cuadrado en el numerador de (1.1) o (1.2) son *independientes*. El divisor $n - 1$ en (1.2) puede considerarse como el número de cantidades independientes en la suma de las desviaciones al cuadrado del numerador. El divisor $n - 1$ es, de hecho, un caso particular de un concepto más avanzado conocido como *grados de libertad* de un estimador de variancia, que será desarrollado en el apartado 3.4.

El cálculo directo de la variancia estimada se ilustra en la tabla 1.9. En este ejemplo concreto el cálculo es muy sencillo. En general, es probable que dos aspectos del método ocasionen problemas. Por una parte, pueden cometerse errores fácilmente al sustraer la media de cada lectura. Además, si la media no es un número «redondo» como sucede en este ejemplo, se deberá redondear. Entonces, necesitaremos escribir las desviaciones $x_i - \bar{x}$ con varios dígitos significativos incluidos en $\bar{x}$. Estas dificultades han llevado a utilizar ampliamente un método alternativo para calcular la suma de los cuadrados alrededor de la media, $\Sigma (x_i - \bar{x})^2$. Dicho método se basa en la siguiente identidad algebraica:

$$\begin{aligned}
 \Sigma (x_i - \bar{x})^2 &= \Sigma (x_i^2 - 2x_i\bar{x} + \bar{x}^2) \\
 &= \Sigma x_i^2 - 2\bar{x} \Sigma x_i + n\bar{x}^2 \\
 &= \Sigma x_i^2 - 2 \frac{(\Sigma x_i)^2}{n} + \frac{(\Sigma x_i)^2}{n} \\
 &= \Sigma x_i^2 - \frac{(\Sigma x_i)^2}{n}
 \end{aligned} \tag{1.3}$$

Ésta se denomina fórmula abreviada de la suma de los cuadrados alrededor de la media. La demostración de (1.3) se basa en que $\Sigma x_i = n\bar{x}$.

El punto importante de (1.3) y sus variantes es que los cálculos se realizan sin la necesidad de calcular las desviaciones individuales de la media, $x_i - \bar{x}$. La suma de los cuadrados de las observaciones originales, x_i se corrige sustrayendo una cantidad que depende exclusivamente de la media de x_i (o, lo que es lo mismo, del total). Este segundo término suele de-

Tabla 1.10. Cálculo de la variancia y de la desviación tipo estimadas: fórmula abreviada (los mismos datos que en la tabla 1.9).

x_i	x_i^2
8	64
5	25
4	16
12	144
15	225
5	25
7	49
<u>56</u>	<u>548</u>

$$\begin{aligned}
 \Sigma(x_i - \bar{x})^2 &= \Sigma x_i^2 - (\Sigma x_i)^2/n \\
 &= 548 - 56^2/7 \\
 &= 548 - 448 \\
 &= 100
 \end{aligned}$$

Pasos siguientes como en la tabla 1.9

nominarsse *término de corrección*, y la expresión completa, *suma de cuadrados corregida*.

El ejemplo anterior se plantea de nuevo en la tabla 1.10. Una vez más, obtenemos el resultado $\Sigma (x_i - \bar{x})^2 = 100$, y los cálculos siguientes son como los de la tabla 1.9.

La fórmula abreviada evita la necesidad de elevar al cuadrado desviaciones individuales con muchos dígitos significativos, pero incluye los cuadrados de x_i que pueden ser números grandes. Esto pocas veces ocasiona problemas si se usa una calculadora, aunque se debe procurar trabajar con suficientes dígitos en el término de corrección para ofrecer el número de dígitos necesario en la diferencia entre los dos términos. (Por ejemplo, si $\Sigma x_i^2 = 2.025$ y $(\Sigma x_i)^2/n = 2.019,3825$, la retención de estos decimales dará como resultado $\Sigma (x_i - \bar{x})^2 = 5,6175$; si el término de corrección hubiera sido redondeado al número entero más próximo, se habría obtenido $\Sigma (x_i - \bar{x})^2 = 6$, con una exactitud de un solo dígito significativo.) Además, este error por redondeo puede ocasionar problemas en el cálculo informatizado, y los programas de ordenador deberían usar la fórmula directa en lugar de la abreviada para la suma de los cuadrados alrededor de la media.

La mayoría de las calculadoras tiene una tecla de sumatorio que acumula n , Σx y Σx^2 en la memoria, por lo que pueden calcularse la media y la desviación tipo oprimiendo sucesivamente las teclas; esto último implica el cálculo de (1.3). Las calculadoras por lo general tienen teclas separadas para (1.1a) y para (1.2a), que se denominan muchas veces σ_n y σ_{n-1} respectivamente.

Si las observaciones se presentan bajo la forma de una distribución de frecuencias, la desviación tipo se puede obtener por un método análogo al utilizado para la media. Si se agrupa la variable original, sólo puede obtenerse una estimación aproximada de la desviación tipo. Los cálculos se ilustran en la tabla 1.11, que muestra los mismos datos que en los cálculos correspondientes a la media (tabla 1.8). La desviación tipo de x es 8,76 años.

El hecho de considerar que todos los valores de x de un grupo se pueden sustituir sin problemas por el punto medio del intervalo, aunque es razonable para el cálculo de la media, es un poco erróneo en el caso del cálculo de la desviación tipo por el siguiente motivo. Cuando una distribución es unimodal, como la de la tabla 1.11, las observaciones de cada grupo

Tabla 1.11. Cálculo de la desviación tipo a partir de la distribución de frecuencias (los mismos datos que en la tabla 1.8).

Edad (años)	Frecuencia f	Punto medio x (años)	años fx	(1)(2) fx^2
25-	17	30	510	15.300
35-	116	40	4.640	185.600
45-	493	50	24.650	1.232.500
55-	545	60	32.700	1.962.000
65-74	186	70	13.020	911.400
	1.357		75.520	4.306.800
	n		Σx	Σx^2

$$\Sigma(x - \bar{x})^2 = 4.306.800 - \frac{75.520^2}{1.357} = 103.948$$

$$s^2 = 103.948/1.356 = 76,66$$

$$s = \sqrt{76,66} = 8,76 \text{ años}$$

Obsérvese que Σx denota la suma sobre todas las n ($= 1.357$) observaciones. Se calcula como Σfx , donde el sumatorio se refiere ahora a los cinco grupos de edad. Asimismo, Σx^2 sobre todas las observaciones se calcula como Σfx^2 sobre los cinco grupos.

tenderán a agruparse hacia el centro de la distribución en lugar de hacerlo de forma homogénea a lo largo del intervalo. Es decir, que los valores medios de las observaciones en los intervalos 25- y 35- pueden ser algo mayores que 30 y 40, y los de los intervalos 55- y 65- algo menores que 60 y 70, respectivamente. Estos sesgos tenderán a compensarse en el cálculo de la media de edad y podrán despreciarse con toda seguridad. Sin embargo, la desviación tipo calculada tiende a ser exagerada. Una corrección adecuada para este efecto, denominada *corrección de Sheppard*, consiste en sustraer $h^2/12$ de la variancia calculada, donde h es el tamaño del intervalo de grupo. (Si el intervalo de grupo no es constante se puede utilizar un valor promedio.)

En este ejemplo, h es 10 y la variancia corregida sería:

$$76,66 - \frac{1}{12} (10^2) = 68,33$$

lo cual da

$$DT(x) = 8,27 \text{ años}$$

donde $DT()$ expresa la desviación tipo de la variable en cuestión. Dado que la corrección es muy pequeña, excepto que la agrupación sea en intervalos muy anchos, suele pasarse por alto.

La desviación tipo de un conjunto de mediciones se expresa con las mismas unidades que estas medidas y, por consiguiente, en las mismas que la media. A veces es útil describir la variabilidad expresando la desviación tipo como una proporción o como un porcentaje de la media. La medida resultante, denominada *coeficiente de variación*, es una cantidad adimensional (un número puro). Su expresión matemática es:

$$CV(x) = \frac{s}{\bar{x}} \times 100\% \quad (1.4)$$

El coeficiente de variación es muy útil como herramienta descriptiva en las situaciones en que se altera la desviación tipo en la misma proporción que la media debido a un cambio en las condiciones bajo las que se efectúan las mediciones. El coeficiente de variación no cambia y es una medida simple y útil de variabilidad. En el apartado 3.6 se tratará de nuevo con más detalle.

Capítulo 2

Probabilidad

2.1. Significado de la probabilidad

Un ensayo clínico pone de relieve que 50 pacientes que reciben el tratamiento A para cierta enfermedad se encuentran mejor, en promedio, que 50 pacientes similares que reciben el tratamiento B. ¿Es correcto suponer que el tratamiento A es realmente mejor que el B para esta enfermedad concreta? Para futuros pacientes ¿debería el investigador preferir A frente a B? Éstas son preguntas típicas que se plantean en cualquier investigación estadística. La primera atañe a la inferencia: ¿qué conclusiones pueden extraerse razonablemente de esta investigación? La segunda es una cuestión de decisión: ¿cuál es la elección racional para el tratamiento futuro, considerando la información proporcionada por el ensayo y las consecuencias conocidas o desconocidas de utilizar un tratamiento inferior? Se debe destacar que las respuestas a ambas preguntas, como casi todas las correspondientes a preguntas planteadas sobre datos estadísticos, están hasta cierto punto teñidas de incertidumbre. Pueden existir firmes indicios de que el tratamiento A es mejor que B, ¿pero podemos estar completamente seguros de que los pacientes que recibieron el tratamiento B no estaban más gravemente afectados que los que recibieron el A, y que esta variabilidad entre los pacientes no era una razón suficiente para explicar las distintas respuestas al tratamiento? Esta posibilidad puede parecer poco probable en determinada situación específica, pero raras veces es posible descartarla completamente. Por lo tanto, las preguntas formuladas deben recibir su respuesta expresada en términos de incertidumbre. Si ésta es baja, la conclusión será firme y la decisión segura. Si la incertidumbre es elevada, la investigación no permite extraer conclusiones. Por lo tanto es importante considerar la medida de dicha incertidumbre, y el instrumento adecuado para este propósito es la *teoría de la probabilidad*. Al principio la abordaremos de forma bastante teórica, mientras que en los capítulos posteriores se analizará su aplicación a distintos tipos de problemas estadísticos.

Si se lanza una moneda muchas veces y se anota el resultado de cada tirada, podemos obtener una secuencia como la siguiente (C significa cara y X cruz):

XXCXCCXCXXXCXCCXCCCCXXC...

Esta secuencia se denomina *secuencia aleatoria* o *serie aleatoria*, a cada posición de la secuencia se la llama *prueba*, y cada resultado a menudo se denomina *suceso*. Una secuencia aleatoria de sucesos binarios, como C y X en este ejemplo, a menudo recibe el nombre de *secuencia de Bernoulli* (James Bernoulli, 1654-1705). La secuencia aleatoria se caracteriza por la falta absoluta de un patrón de predicción. Al lanzar una moneda, la posibilidad de obtener C en cualquier momento es la misma que en cualquier otro, y no está influida por el resultado de los lanzamientos anteriores. (Al contrario de lo que algunos creen, la posibili-

dad de obtener una cara nunca aumentará ni disminuirá, aunque ya haya ocurrido una serie de, por ejemplo, seis caras.)

En este tipo de secuencia se descubrirá que, al aumentar la secuencia, la proporción de pruebas con un resultado particular va variando cada vez menos y tiende a un valor límite. Esta proporción se denomina *probabilidad* de un suceso en particular. La figura 2.1 muestra la proporción de caras después de realizar diversos números de lanzamientos, en un experimento real. Dado que la proporción tiende claramente a $1/2$, sería razonable decir que la probabilidad del suceso cara es aproximadamente $1/2$. Considerando la simetría seguramente hubiésemos llegado a esta misma conclusión antes de ver los resultados del experimento. Las ligeras diferencias en el grabado de cada uno de los lados de la moneda, posibles variaciones de densidad, e incluso algún sesgo en el método de lanzamiento, pueden hacer que la probabilidad se desvíe ligeramente de $1/2$, pero es poco probable que podamos realizar un experimento suficientemente prolongado para diferenciar entre una probabilidad de $0,5$ y una de $0,5001$.

El lector puede apreciar que esta definición de la probabilidad es bastante heurística. No podemos observar una secuencia de pruebas y decir sin ambigüedad «Esta secuencia es aleatoria», puesto que observamos sólo una porción finita de la secuencia y pueden existir patrones subyacentes, en los resultados que no son fácilmente distinguibles. Tampoco podemos observar una secuencia y establecer con precisión la probabilidad de un suceso específico; la probabilidad es una propiedad asintótica y sólo observamos una porción insuficiente de la secuencia. Sin embargo, existen muchos fenómenos que aparentemente se comportan de ese modo, y el concepto de secuencia aleatoria debe considerarse como un concepto ideal




Fig. 2.1. Proporción de caras en una secuencia de lanzamientos de una moneda, con una escala logarítmica para el número de lanzamientos. (Cramer, 1946, reproducida con autorización del autor y de los editores.)

que parece describir muy bien estos fenómenos. A continuación se exponen otros ejemplos de secuencias «aleatorias» empíricas (Bernoulli).

1. *Lanzamientos de un dado*. Si el dado está bien hecho, la probabilidad de cada suceso, del 1 al 6, es muy próxima a $1/6$.
2. *Sexo de recién nacidos vivos en una población humana amplia*. La probabilidad de que nazca un niño varón varía de una población a otra (p. ej., depende del índice de nacidos muertos), pero habitualmente se sitúa un poco por encima de $1/2$. En Inglaterra y Gales suele situarse en 0,515; la probabilidad de nacimiento de una mujer en correspondencia es $1 - 0,515 = 0,485$.
3. *Secuencia de resultados de exploraciones de cribado prenatales, clasificadas según la presencia o la ausencia de anormalidad fetal específica*. La probabilidad de que aparezca espina bífida abierta puede ser de 0,0012.

Una consecuencia de esta definición de la probabilidad es que ésta se mide con un número entre 0 y 1. Si un suceso nunca ocurre en ninguna de las pruebas de una secuencia aleatoria, su probabilidad es cero. Si ocurre en cada una de las pruebas, su probabilidad es la unidad.

Otra consecuencia es que la probabilidad no está definida por secuencias en las que la sucesión de sucesos sigue un patrón manifiestamente no aleatorio. Si se inventase una máquina que lanzase monedas dando como resultado cara y cruz en estricta alternancia (C, X, C, X, C, X, ..., etc.), la proporción asintótica de caras y cruces de la secuencia sería $1/2$, pero sería incorrecto decir que la probabilidad de cada suceso es $1/2$. La secuencia no es aleatoria, porque el comportamiento de cada prueba impar es diferente del de cada prueba par. Sería mejor pensar en esta serie como una combinación de dos series separadas: las pruebas impares en las que la probabilidad de obtener cara es de 1, y las pruebas pares en las que esta probabilidad es 0.

Este concepto de probabilidad proporciona una medida de la incertidumbre de ciertos tipos de fenómenos que ocurren en la naturaleza. Existe un elevado grado de seguridad de que un futuro nacimiento no presentará espina bífida porque la probabilidad de este suceso es baja. Existe una incertidumbre considerable sobre el sexo de un futuro nacimiento porque las probabilidades de ambos sucesos son aproximadamente $1/2$. Sin embargo, la definición es más restrictiva de lo que sería deseable. ¿Cuál es la probabilidad de que el tabaco sea una causa que contribuya al cáncer pulmonar? Esta pregunta utiliza la palabra «probabilidad» en un contexto coloquial perfectamente natural. No obstante, no se ajusta a nuestra definición técnica, porque es imposible pensar en una secuencia aleatoria de pruebas en las que el tabaco sea una causa de cáncer pulmonar en algunas pruebas y en otras no.

Más adelante veremos que la definición de probabilidad a partir de la «frecuencia», mencionada antes, puede utilizarse como base para la inferencia estadística, y una redefinición del problema a menudo puede aportar datos sobre la verosimilitud de una hipótesis como «El tabaquismo es una causa de cáncer pulmonar». Sin embargo, varios estadísticos teóricos, probabilistas y lógicos defienden una interpretación más amplia del concepto de probabilidad de lo que permite la definición mencionada. Según esta visión más amplia, la probabilidad se puede interpretar como una evaluación del grado de creencia en una proposición, y las afirmaciones directas sobre la probabilidad de que una hipótesis científica sea verdadera son correctas. En el apartado 2.9 volveremos a comentar este punto de vista, pero antes de desarrollarlo restringiremos nuestra atención a la definición a partir de la frecuencia.

2.2. Cálculos de probabilidad

El principal objetivo de la asignación de probabilidades numéricas es permitir la realización de cálculos a partir de estos números. Las dos operaciones básicas que nos ocupan son la *suma* y la *multiplicación*. En primer lugar consideramos la suma de probabilidades.

Consideremos una secuencia aleatoria de pruebas, en las que cada prueba tiene más de un resultado. En una serie de lanzamientos de un dado, por ejemplo, podemos preguntarnos cuál es la probabilidad de obtener un 1 o un 3. La respuesta está bastante clara. Si el dado es perfecto, la probabilidad de obtener un 1 es $1/6$, y la probabilidad de obtener un 3 es de $1/6$. Es decir que el 1 aparecerá en $1/6$ de las pruebas de una larga secuencia, y el 3 aparecerá con la misma proporción en la larga serie de pruebas. El 1 y el 3 nunca aparecerán juntos como resultado de una prueba. Por lo tanto, el suceso compuesto por los resultados «1 o 3» ocurrirá en $1/6 + 1/6$, o $1/3$, de todos los sucesos de una larga secuencia. Se han sumado las probabilidades de cada uno de los resultados individuales.

Nótese la importancia del hecho de que el 1 y el 3 no pueden aparecer en el mismo momento; en otras palabras, son *mutuamente excluyentes*. Sin esta condición, la ley de adición no puede ser válida. Por ejemplo, si se escoge al azar el nombre de un médico a partir del British Medical Register, la probabilidad de que este médico sea varón es de 0,8. La probabilidad de que el médico se haya graduado en una universidad de medicina inglesa es de 0,6. ¿Cuál es la probabilidad de que el médico sea un varón o se haya graduado en Inglaterra, o ambas características a la vez? Si se suman ambas probabilidades se obtiene $0,8 + 0,6 = 1,4$, lo cual es claramente erróneo, porque las probabilidades no pueden ser superiores a 1. El problema es que la probabilidad de un suceso doble —varón y graduado en Inglaterra— se ha evaluado dos veces, la primera como parte de la probabilidad de ser un varón, y la segunda como parte de la probabilidad de haberse graduado en Inglaterra. Para obtener la respuesta correcta se debe restar la probabilidad del doble suceso. Así, llamando A y B a los dos sucesos, obtenemos una expresión más general de la *ley aditiva*.

$$\begin{aligned} \text{Probabilidad de } A \text{ o } B \text{ o ambos} &= (\text{Probabilidad de } A) \\ &+ (\text{Probabilidad de } B) \\ &- (\text{Probabilidad de } A \text{ y } B) \end{aligned}$$

Es conveniente escribir dicha expresión de la siguiente forma:

$$P(A \text{ o } B \text{ o ambos}) = P(A) + P(B) - P(A \text{ y } B) \quad (2.1)$$

En este ejemplo particular, aún no hemos definido la probabilidad del suceso doble, pero seguramente será superior a 0,4 para asegurar que el lado derecho de la ecuación (2.1) sea menor a 1.

Si los dos sucesos son mutuamente excluyentes, el último término de (2.1) será cero, y obtendremos la *forma más sencilla de la ley aditiva*:

$$P(A \text{ o } B) = P(A) + P(B)$$

Supongamos que se realizan simultáneamente dos secuencias aleatorias de pruebas; por ejemplo, es posible lanzar al mismo tiempo un dado y una moneda. ¿Cuál es la *probabilidad*

conjunta de obtener una combinación particular de resultados, por ejemplo cara (C) en la moneda y un 5 en el dado? El resultado se obtiene mediante la *ley multiplicativa*:

$$P(C \text{ y } 5) = P(C) \times P(5, \text{ suponiendo que ya ha ocurrido } C) \quad (2.2)$$

O sea, la proporción de pares de pruebas con un resultado de C y 5, en una secuencia larga es igual a la proporción de C en la secuencia de pruebas con la moneda, multiplicada por la proporción de estos resultados en los que ocurre además un 5 en el dado. El segundo término de la parte derecha de (2.2) es un ejemplo de una *probabilidad condicional*, el primer elemento 5 está «condicionado» al segundo, C.

En este ejemplo particular, no hay razón para suponer que la probabilidad de obtener 5 en el dado está afectada por el resultado obtenido en el lanzamiento de la moneda. En otras palabras:

$$P(5, \text{ supuesto } C) = P(5)$$

Una notación frecuente es sustituir «supuesto» por una línea vertical, o sea $P(5|C)$. La probabilidad condicional es igual a la probabilidad incondicional. Estos dos sucesos se denominan *independientes*, y obtenemos la *forma más sencilla de la ley multiplicativa*:

$$\begin{aligned} P(C \text{ y } 5) &= P(C) \times P(5) \\ &= 1/2 \times 1/6 \\ &= 1/12 \end{aligned}$$

Efectivamente, en este ejemplo existen 12 combinaciones que ocurren con igual frecuencia en una secuencia muy larga: C1, C2, ..., C6, X1, X2, ..., X6.

En general, los pares de sucesos no tienen por qué ser independientes, y se debe utilizar la fórmula general de la ley multiplicativa (2.2). En el ejemplo citado antes nos referíamos a la probabilidad de que un médico fuera varón y que se hubiera graduado en Inglaterra. Si estos sucesos fueran independientes, podríamos calcularla de esta forma:

$$0,8 \times 0,6 = 0,48$$

y, designando a los sucesos A y B, (2.1) obtendríamos:

$$\begin{aligned} P(A \text{ o } B \text{ o ambos}) &= 0,80 + 0,60 - 0,48 \\ &= 0,92 \end{aligned}$$

A pesar de todo, estos sucesos pueden no ser independientes, porque algunas facultades de medicina aceptan mujeres con mayor facilidad que otras. El valor correcto de $P(A \text{ y } B)$ sólo podría obtenerse mediante una investigación directa.

Como otro ejemplo de falta de independencia, supongamos que en una población grande el 30% de los sujetos tiene los ojos azules. Tendríamos:

$$\begin{aligned} P(\text{ojo derecho azul}) &= 0,3 \\ P(\text{ojo izquierdo azul}) &= 0,3 \end{aligned}$$

$P(\text{ojo derecho azul y ojo izquierdo azul})$ no está dada por la siguiente fórmula:

$$P(\text{ojo derecho azul}) \times P(\text{ojo izquierdo azul}) = 0,09$$

Sino que se obtiene mediante la fórmula general (2.2):

$$\begin{aligned} P(\text{ojo derecho azul}) \times P(\text{ojo izquierdo azul, suponiendo que el ojo derecho es azul}) \\ = 0,3 \times 1,0 \\ = 0,3 \end{aligned}$$

La suma y la multiplicación pueden combinarse en el mismo cálculo. En el caso de la doble secuencia con una moneda y un dado, ¿cuál es la probabilidad de obtener cara y 2 o cruz y 4? Cada una de estas combinaciones tiene una probabilidad $1/12$ (por la ley multiplicativa para sucesos independientes). Cada combinación es un resultado posible de la doble secuencia y éstos son mutuamente excluyentes. Las probabilidades de $1/12$ pueden, por lo tanto, sumarse para dar una probabilidad final de $1/6$ de que ocurra una de las dos combinaciones.

Un ejemplo algo más complicado es la composición sexual de las familias con cuatro hijos. Como aproximación, podemos suponer que la proporción de nacimientos de varones es de 0,51, que los hijos de las familias pueden considerarse como elecciones al azar en una secuencia en que la probabilidad de obtener varones es de 0,51 y que la pregunta se refiere a todos los recién nacidos vivos, de modo que las diferencias de supervivencia no nos preocupan. La pregunta planteada es cuáles son las probabilidades de que una familia de cuatro esté compuesta por ningún varón, un varón, dos varones, tres varones y cuatro varones.

La probabilidad de que no haya ningún varón es la probabilidad de que cada uno de los cuatro hijos sea una mujer. La probabilidad de que el primer hijo sea una mujer es $1 - 0,51 = 0,49$. A partir de varias aplicaciones de la ley multiplicativa para sucesos independientes, la probabilidad de que los dos primeros hijos sean mujeres es $(0,49)^2$; la probabilidad de que los tres primeros hijos sean mujeres es $(0,49)^3$, y la probabilidad de que todos sean mujeres es $(0,49)^4 = 0,0576$. Más o menos una de cada 17 familias de 4 hijos tendrá cuatro mujeres. Si escribimos esto:

$$P(MMMM) = 0,0576$$

Una familia compuesta por un varón y tres mujeres puede constituirse de las siguientes formas: $VMMM$, $MVMM$, $MMVM$, $MMMV$, según cuál de los cuatro hijos sea el varón. Cada una de estas formas tiene una probabilidad de $(0,49)^3(0,51) = 0,0600$. Por lo tanto, la probabilidad total de un varón en la familia es, según la ley aditiva, la siguiente:

$$\begin{aligned} 0,0600 + 0,0600 + 0,0600 + 0,0600 \\ = 4(0,0600) \\ = 0,2400 \end{aligned}$$

Una familia con dos varones y dos mujeres puede formarse de las siguientes formas: $VVMM$, $VMVM$, $VMMV$, $MVVM$, $MVMV$, $MMVV$. Cada una de estas combinaciones tiene una probabilidad de $(0,49)^2(0,51)^2$, y la probabilidad total de obtener dos varones es de:

$$6(0,49)^2(0,51)^2 = 0,3747$$

Se procede de forma similar para los distintos tipos de composición familiar. Los resultados completos se muestran en la tabla 2.1.

Nótese que la suma de las probabilidades es igual a 1, como debe ser porque este total representa la probabilidad de obtener uno de los distintos tipos de composición familiar (siendo mutuamente excluyentes). Puesto que estos cinco tipos agotan todas las posibilidades, la probabilidad total debe ser la unidad. Si examinamos los registros de un amplio número de familias con cuatro hijos, ¿la proporción de los cinco tipos estaría cerca de los valores mostrados en la última columna? Seguramente serían muy similares, pero no sorprendería observar alguna ligera diferencia sistemática, porque las afirmaciones teóricas que fundamentan nuestro argumento pueden no ser del todo correctas. En primer lugar, la probabilidad de que ocurra un nacimiento de un varón puede variar ligeramente de una familia a otra (como ya señalamos en el apartado 2.1). Y, aún más importante, las familias que inician una línea de nacimientos desequilibrada con respecto a la distribución sexual, con varios nacimientos del mismo sexo, tienen mayores probabilidades de continuar con esta tendencia que las familias cuyos primeros nacimientos fueron más equilibrados. Los dos primeros nacimientos de familias que posteriormente proseguirán hacia un tercer hijo no serán representativos de las familias con dos hijos. Puede existir un sesgo similar en la progresión de tres a cuatro nacimientos. Debe suponerse que la magnitud de estos sesgos varía de una comunidad a otra, y existen datos recientes que confirman esta hipótesis aunque algunos se acercan más que otros a las probabilidades teóricas.

A veces, es conveniente expresar una probabilidad en términos de posibilidad («odd»), lo que equivale al cociente entre la probabilidad o proporción de que ocurra un suceso y la probabilidad o proporción (complementaria) de no ocurrencia. De esta forma, las posibilidades de obtener un 6 con un dado son $\frac{1}{5}$.

2.3. Distribuciones de probabilidad

La tabla 2.1 muestra nuestro primer ejemplo de *distribución de probabilidad*. Es decir, muestra cómo la probabilidad total, igual a 1, se distribuye entre los distintos tipos de familias. Una variable cuyos valores siguen la distribución de probabilidad se conoce como *variable aleatoria*. En la tabla 2.1 el número de varones de las familias es la variable aleatoria. Del mismo modo, el número de mujeres es una variable aleatoria.

Si una variable aleatoria puede asociarse a distintos puntos sobre una escala, la distribución de probabilidad puede representarse gráficamente mediante un histograma, del mismo

Tabla 2.1. Cálculos de las probabilidades de familias con distintas composiciones de sexos.

Composición		Probabilidad
Varones	Mujeres	
0	4	$(0,49)^4 = 0,0576$
1	3	$4(0,49)^3(0,51) = 0,2400$
2	2	$6(0,49)^2(0,51)^2 = 0,3747$
3	1	$4(0,49)(0,51)^3 = 0,2600$
4	0	$(0,51)^4 = 0,0677$
		1,0000

modo que las distribuciones de frecuencias. Consideraremos en primer lugar algunos ejemplos de variables aleatorias discretas.

En este caso la escala vertical del histograma mide la probabilidad de cada valor de la variable aleatoria, y cada probabilidad se representa como una línea vertical.

Ejemplo 2.1

Al repetir los lanzamientos de una moneda no trucada, los resultados representan una variable aleatoria con dos valores, C y X . Cada valor tiene una probabilidad de $1/2$. La distribución se muestra en la figura 2.2, en la que los dos sucesos, C y X , se han situado en puntos arbitrarios del eje horizontal.

Ejemplo 2.2

En un experimento genético cruzamos dos heterocigotos con genotipos Aa (es decir, que en un *locus* genético específico, cada progenitor tiene un gen tipo A y otro tipo a). Su prole estará constituida por homocigotos (aa o AA o heterocigotos (Aa), con las siguientes probabilidades:

Genotipo	N.º de genes		Probabilidad
	tipo A		
aa	0		1/4
Aa	1		1/2
AA	2		1/4
			1




Fig. 2.2. Distribución de probabilidades de una variable aleatoria con dos valores; el resultado del lanzamiento de una moneda con idénticas probabilidades para la cara y la cruz.




Fig. 2.3. Distribución de probabilidades de una variable aleatoria con tres valores; el número de genes tipo A en el genotipo de la progenie de un cruce $Aa \times Aa$.

Los tres genotipos pueden colocarse en distintos puntos de la escala, utilizando como variable aleatoria el número de genes tipo A. Esta variable aleatoria toma valores de 0, 1, y 2. La distribución de probabilidad se muestra en la figura 2.3.

Ejemplo 2.3

El tercer ejemplo consiste en el número de varones de las familias de cuatro hijos. Las probabilidades de cada caso particular comentadas en el apartado 2.2 se muestran en la tabla 2.1 y se representan gráficamente en la figura 2.4.

Cuando una variable aleatoria es continua, no está justificado referirse a las probabilidades de valores específicos de la variable, porque estas probabilidades son, en general, iguales a cero. Por ejemplo, la probabilidad de que la talla exacta de un varón sea de 178 cm es




Fig. 2.4. Distribución de probabilidades del número de varones en una familia con cuatro hijos, en el caso de que los nacimientos varones sean independientes y con probabilidad 0,51 (tabla 2.1).




Fig. 2.5. Función de densidad de probabilidad para una variable aleatoria continua.

igual a cero, porque en la población infinita de tallas exactas de varones adultos sólo una proporción muy pequeña tendrá exactamente 178 cm. Sin embargo, si consideramos un pequeño intervalo con centro en 178 cm, es decir entre $178 - h$ y $178 + h$, siendo h muy pequeño, encontraremos una pequeña probabilidad distinta de cero asociada a este intervalo. Además, la probabilidad será bastante proporcional a h . De modo que la probabilidad de presentar una talla entre 177,90 y 178,10 será casi el doble de la de presentar una talla entre 177,95 y 178,05. Así pues, es una representación razonable de la situación suponer que existe una *densidad de probabilidad* característica para el valor 178 cm, que puede escribirse como $f(178)$, de forma que la probabilidad de un pequeño intervalo entre $178 - h$ y $178 + h$ se aproxima mucho a:

$$2hf(178)$$

La distribución de probabilidad de una variable aleatoria continua, x , puede representarse mediante la curva de la función de densidad de probabilidad $f(x)$, como se muestra en la figura 2.5. De hecho, ésta es la curva de frecuencia que comentaremos en el apartado 1.4. El lector que esté familiarizado con las matemáticas reconocerá que $f(x)$ es la derivada, con respecto a x de la probabilidad $F(x)$ en la que la variable aleatoria toma un valor inferior o igual a x . $F(x)$ se denomina *función de distribución* y se representa como el área comprendida debajo de la curva (fig. 2.5) desde el extremo izquierdo (que puede localizarse en el infinito negativo) hasta el valor de x . La función de distribución que corresponde a la función de densidad de probabilidad de la figura 2.5 se representa en la figura 2.6. Nótese que la altura de la función de densidad es proporcional a la pendiente de la función de distribución; en nuestro ejemplo, estas dos cantidades son iguales a cero en los extremos inferior y superior de la variable y alcanzan el valor máximo en un punto intermedio.

La forma de la distribución de probabilidad puede caracterizarse por elementos ya utilizados en las distribuciones de frecuencia. En particular, podemos fijarnos en el número y la posición de las modas, los valores de la variable aleatoria en los que la probabilidad o (en el caso de variables continuas) la densidad de probabilidad alcanza su valor máximo. Podemos interesarnos también por la asimetría de una distribución de probabilidad.

Por analogía con los apartados 1.5 y 1.6 estamos especialmente interesados en la media y la desviación tipo de una variable aleatoria. En el siguiente apartado comentamos estos conceptos.




Fig. 2.6. Función de distribución correspondiente a la función de densidad de la figura 2.5.

2.4. Valores esperados

Hay ciertas dificultades para determinar qué quiere decir la expresión «media de una variable aleatoria». La media se ha definido antes sobre un número finito, n , de observaciones. Con una distribución de probabilidad como la de la tabla 2.1, el número de observaciones puede considerarse infinito. ¿En este caso cómo se calcula la media?

Supongamos que n es grande, tan grande que la frecuencia relativa de los distintos valores de una variable aleatoria discreta como la de la tabla 2.1 puede considerarse muy próxima a su probabilidad. Si fuera exactamente igual a las probabilidades, la distribución de las frecuencias del número de varones sería la siguiente:

x	
N.º de varones	Frecuencia
0	0,0576n
1	0,2400n
2	0,3747n
3	0,2600n
4	0,0677n
	n

El valor medio de x sería:

$$\frac{(0 \times 0,0576n) + (1 \times 0,2400n) + (2 \times 0,3747n) + (3 \times 0,2600n) + (4 \times 0,0677n)}{n}$$

El factor n puede eliminarse del numerador y del denominador de la ecuación. El resultado es 2,04. El tamaño n arbitrario de la muestra no aparece en la fórmula.

Si las probabilidades de 0, 1, ..., 4 varones se presentan como $P_0, P_1, \dots, P_4$, la fórmula de la media es:

$$(0 \times P_0) + (1 \times P_1) + (2 \times P_2) + (3 \times P_3) + (4 \times P_4)$$

Por lo general, si x es una variable aleatoria que toma valores $x_0, x_1, x_2, \dots$, con probabilidades de $P_0, P_1, P_2, \dots$, el valor medio de x se calcula del siguiente modo:

$$\sum_i x_i P_i \quad (2.3)$$

El valor medio de una variable aleatoria calculado de este modo a menudo se denomina *valor esperado*, *esperanza matemática* o simplemente *esperanza* de x , y las operaciones necesarias (multiplicación de cada valor de x por su probabilidad y, luego, suma de estos valores) se expresan con $E(x)$. El valor esperado de una variable aleatoria a menudo se inscribe con la letra griega μ (mu minúscula), para diferenciarlo de una media calculada a partir de un número finito de observaciones (representada habitualmente con símbolos como $\bar{x}$ o $\bar{y}$).

Como segundo ejemplo, consideremos la distribución de probabilidad de x , el número de genes tipo A de los genotipos del ejemplo 2.2. En este caso:

$$\begin{aligned} E(x) &= (0 \times 0,25) + (1 \times 0,50) + (2 \times 0,25) \\ &= 1 \end{aligned}$$

Si x sigue una distribución continua, la fórmula descrita anteriormente para $E(x)$ no puede utilizarse. Sin embargo, podemos considerar una distribución discreta en la que los posibles valores de x difieren por un pequeño intervalo de $2h$. A cada valor X_0 podemos atribuirle la probabilidad proporcionada por la distribución continua para valores de x comprendidos entre $X_0 - h$ y $X_0 + h$, la cual, como ya hemos comentado, será próxima a $2hf(X_0)$, si h es suficientemente pequeño. La esperanza de x en una distribución discreta puede calcularse mediante la fórmula general. Cuando el intervalo h se reduce, la distribución discreta se aproxima a la distribución continua, y en general el valor esperado se aproximará a la cantidad calculada mediante la fórmula:

$$\mu = \int_{-\infty}^{\infty} x f(x) dx$$

Ésta proporciona la definición del valor esperado de x para una distribución continua.

La *variancia* de una variable aleatoria se define como:

$$\text{Var}(x) = E(x - \mu)^2$$

es decir, que es el valor esperado del cuadrado de la diferencia con respecto a la media. Éste es un desarrollo obvio de la fórmula $\sum (x_i - \bar{x})^2/n$ para la variancia de un número finito de observaciones, n , puesto que esta cantidad es el valor medio del cuadrado de las diferencias

con respecto a la media de la muestra $\bar{x}$. La diferencia entre el denominador n o $n - 1$ pierde importancia cuando se trata de distribuciones de probabilidad, puesto que n es efectivamente infinito.

La variancia de una variable aleatoria habitualmente se representa con el símbolo σ^2 (σ es la letra griega sigma). La desviación tipo se representa también con la σ , y es la raíz cuadrada de la variancia.

Por analogía con la fórmula abreviada para la variancia de una muestra (apartado 1.6), resultará más manejable utilizar la siguiente relación:

$$\sigma^2 = E(x^2) - \mu^2$$

La demostración* es la siguiente:

$$\begin{aligned}\sigma^2 &= E(x - \mu)^2 \\ &= E(x^2 - 2x\mu + \mu^2) \\ &= E(x^2) - 2\mu E(x) + \mu^2 \\ &= E(x^2) - 2\mu^2 + \mu^2 \\ &= E(x^2) - \mu^2\end{aligned}\quad (2.4)$$

Ambas fórmulas de la variancia pueden ilustrarse mediante la distribución del ejemplo 2.2, en el que ya hemos obtenido $\mu = 1$. Mediante la fórmula directa realizamos los siguientes pasos:

x	P	$x - \mu$	$(x - \mu)^2$
0	0,25	-1	1
1	0,50	0	0
2	0,25	1	1

$$\begin{aligned}\sigma^2 &= E(x - \mu)^2 \\ \sigma^2 &= (1 \times 0,25) + (0 \times 0,50) + (1 \times 0,25) \\ &= 0,5\end{aligned}$$

Con la fórmula simplificada:

x	P	x^2
0	0,25	0
1	0,50	1
2	0,25	4

$$\begin{aligned}E(x^2) &= (0 \times 0,25) + (1 \times 0,50) + (4 \times 0,25) \\ &= 1,5; \\ \sigma^2 &= E(x^2) - \mu^2 \\ &= 1,5 - 1^2 \\ &= 0,5\end{aligned}$$

como en el caso anterior.

* Nótese que en esta demostración usamos algunas propiedades de las esperanzas, que se aceptan de forma intuitiva, pero que no demostraremos rigurosamente: a) al pasar de la segunda a la tercera línea, tenemos en cuenta que la esperanza de una suma (o diferencia) de dos variables aleatorias es la suma (o la diferencia) de sus esperanzas; b) al manejar el término central de la tercera línea tenemos en cuenta que la esperanza de la multiplicación de una variable aleatoria por una constante es igual a la multiplicación de su esperanza por la constante.

Hasta ahora hemos comentado las distribuciones de probabilidad de forma bastante general. En los tres apartados siguientes consideraremos tres distribuciones específicas que desempeñan un papel muy importante en la teoría y la práctica estadísticas.

2.5. Distribución binomial

Ya hemos comentado un caso con una distribución de este tipo en el ejemplo sobre la distribución de sexos en las familias de cuatro hijos del apartado 2.2.

Supongamos que tenemos una secuencia aleatoria en la que los sucesos de cada prueba individual son de tipo A o B , cuyas probabilidades de ocurrir son iguales a π y $1 - \pi$, respectivamente. (El símbolo π , abreviatura de la letra pi del alfabeto griego, se utiliza como una letra y no se relaciona con la constante matemática $\pi = 3,14159\dots$) En el ejemplo anterior, A y B eran varones y mujeres y π era 0,51.

Consideremos ahora un grupo de n observaciones de una secuencia aleatoria (en el ejemplo, $n = 4$). Es más correcto referirse a cada grupo como una «muestra» de n observaciones. ¿Cuál es la probabilidad de cierto número de A en esta muestra? Este número se reseña como r y, naturalmente, r puede ser 0, 1, 2, ..., $n - 1$, n . Además la *proporción* de las A de la muestra se define como $p = r/n$, y la *proporción* de las B como $q = (n - r)/n = 1 - p$.

Como en el ejemplo, argumentamos que la probabilidad de r A y $(n - r)$ B vale:

$$\pi^r (1 - \pi)^{n-r}$$

multiplicado por el número de formas en que se puede extraer r A de la muestra de n de sujetos. Este factor de multiplicación se denomina *coeficiente binomial*. En el ejemplo, los coeficientes binomiales se calcularon mediante una sencilla enumeración, pero naturalmente este procedimiento sería muy laborioso cuando n y r tuvieran valores grandes. El coeficiente binomial a menudo se representa como:

$$\binom{n}{r}$$

(que significa «combinaciones de r sobre n »

o nC_r ,

En la mayoría de los textos con tablas matemáticas se proporcionan tablas de coeficientes binomiales. Para valores de n y r moderados pueden calcularse directamente mediante la fórmula:

$$\binom{n}{r} = \frac{n(n-1)(n-2)\dots(n-r+1)}{1 \cdot 2 \cdot 3 \dots r} \quad (2.5)$$

(en la que los puntos aislados representan signos de multiplicación, y los puntos suspensivos significan que se utilizan todos los enteros intermedios). La cantidad $1 \cdot 2 \cdot 3 \dots r$ se denomina

« r factorial» o «factorial de r » y se escribe $r!$. La fórmula $n(n-1) \dots (n-r+1)$ del numerador de

$$\binom{n}{r}$$

puede escribirse,

$$\frac{n!}{(n-r)!},$$

de modo que la ecuación se transforma en:

$$\binom{n}{r} = \frac{n!}{r!(n-r)!} \quad (2.6)$$

En esta fórmula interviene, innecesariamente, una multiplicación complicada, pero llama la atención sobre la simetría del coeficiente binomial;

$$\binom{n}{r} = \binom{n}{n-r} \quad (2.7)$$

Además, esto es evidente por la definición. Cualquier selección de r objetos de una muestra de n es automáticamente una selección de los $n-r$ objetos restantes.

Si hacemos $r=0$ en (2.5) tanto el numerador como el denominador no tendrán sentido. Si $r=n$ obtendríamos:

$$\binom{n}{n} = \frac{n!}{n!} = 1$$

y, de acuerdo con la simetría, podemos escribir:

$$\binom{n}{0} = 1 \quad (2.8)$$

Éste es el resultado correcto puesto que sólo hay una forma de coger 0 A sobre n : que todos los n objetos sean B . Obsérvese que la ecuación (2.8) concuerda con la (2.6) si aceptamos que $0! = 1$, lo cual sólo es una convención puesto que $0!$ no está justificado por la definición de los factoriales, pero proporciona una extensión de la definición muy útil, que se utiliza generalmente en las matemáticas.

Los coeficientes binomiales requeridos en el ejemplo del apartado 2.2 podrían haberse calculado mediante la ecuación (2.5) del siguiente modo:

$$\begin{aligned} \binom{4}{0} &= 1 \\ \binom{4}{1} &= \frac{4}{1} = 4 \\ \binom{4}{2} &= \frac{4 \cdot 3}{1 \cdot 2} = 6 \end{aligned}$$

$$\binom{4}{3} = \frac{4 \cdot 3 \cdot 2}{1 \cdot 2 \cdot 3} = 4$$

$$\binom{4}{4} = \frac{4 \cdot 3 \cdot 2 \cdot 1}{1 \cdot 2 \cdot 3 \cdot 4} = 1$$

El triángulo de Pascal es una estrategia útil para obtener los coeficientes binomiales para valores de n pequeños sin realizar multiplicaciones:

n					1										
1					1		1								
2					1		2		1						
3					1		3		3		1				
4					1		4		6		4		1		
5					1		5		10		10		5		1
etc.											etc.				

En este triángulo de números, que puede continuarse indefinidamente, cada valor se obtiene sumando los dos valores adyacentes de la línea superior. Así, en la quinta línea (para $n = 4$):

$$4 = 1 + 3, \quad 6 = 3 + 3, \text{ etc.}$$

A lo largo de cada línea se hallan los coeficientes binominales:

$$\binom{n}{0}, \binom{n}{1}, \dots \text{ hasta } \binom{n}{n-1}, \binom{n}{n}$$

La probabilidad de que una muestra de n sujetos contenga r A y $(n-r)$ B , es

$$\binom{n}{r} \pi^r (1 - \pi)^{n-r} \quad (2.9)$$

Si esta expresión se calcula para cada valor de r desde 0 a n , la suma de estos $n + 1$ valores representará la probabilidad de obtener 0 A o 1 A o 2 A, etc., hasta n A. Éstos son los únicos resultados posibles y son mutuamente excluyentes; la suma de dichas probabilidades es por tanto 1. La comprobación de que así ocurre se obtiene algebraicamente a partir del teorema binomial:

$$\begin{aligned} \binom{n}{0} \pi^0 (1-\pi)^n &+ \binom{n}{1} \pi^1 (1-\pi)^{n-1} + \dots + \binom{n}{n} \pi^n (1-\pi)^0 \\ &= [\pi + (1-\pi)]^n \\ &= 1^n \\ &= 1 \end{aligned}$$

Este resultado va se ha verificado con el ejemplo de la tabla 2.1.

La esperanza matemática y la variancia de r pueden obtenerse aplicando las fórmulas generales (2.3) y (2.4) a la distribución de probabilidad (2.9) y utilizando los resultados algebraicos estándar sobre sumatorios de series. Debemos aplazar la demostración hasta que podamos aplicar algunos resultados generales que se presentan en el capítulo 3. Por el momento sólo damos los resultados:

$$E(r) = n\pi \quad (2.10)$$

y

$$\text{Var}(r) = n\pi(1 - \pi) \quad (2.11)$$

La fórmula de la esperanza es intuitivamente aceptable. El número de las A es igual al número de observaciones multiplicado por la probabilidad de que cada suceso individual sea una A . La esperanza del número de varones en una familia de cuatro hijos, en nuestro ejemplo anterior, se presentaba en el apartado 2.4, y resultaba ser 2,04. Ahora observamos que también se podía obtener este resultado mediante la fórmula (2.10):

$$E(r) = 4 \times 0,51 = 2,04$$

La fórmula (2.11) para la variancia es menos clara. Para un valor n dado, la $\text{Var}(r)$ alcanza el valor máximo cuando $\pi = 1 - \pi = 1/2$ [siendo entonces $\text{Var}(r) = (1/4)n$], y disminuye notablemente cuando π se aproxima a 0 o 1. Si π es muy pequeño, el factor $1 - \pi$ de (2.11) se aproxima mucho a 1, y la $\text{Var}(r)$ se aproxima a $n\pi$, valor de $E(r)$.

A menudo estaremos interesados en la distribución de probabilidades de p , la *proporción* de las A de la muestra. De hecho, $p = r \times (1/n)$, y el factor multiplicador $1/n$ es una constante para cada una de las muestras. Se comprende que:

$$E(p) = E(r) \times (1/n) = \pi \quad (2.12)$$

y

$$\text{Var}(p) = \text{Var}(r) \times (1/n)^2 = \frac{\pi(1 - \pi)}{n} \quad (2.13)$$

El cuadrado del factor multiplicador de la variancia se produce porque las unidades en las que se valora la variancia son el cuadrado de las unidades de la variable aleatoria.

A veces es mejor referirse a las desviaciones tipo de r o de p . Éstas representan la raíz cuadrada de sus correspondientes variancias.

$$DT(r) = \sqrt{[n\pi(1 - \pi)]}$$

y

$$DT(r) = \sqrt{\left[\frac{\pi(x_i - \bar{x})^2}{n - 1} \right]}$$

En el apartado 3.3 se comentan otras propiedades de la distribución binomial. Pearson y Hartley (1966; tabla 37) presentan una tabla pequeña de probabilidades para distintos valores de π y n . Otras tablas más completas para $n \leq 25$ se encuentran en Owen (1962; tabla 9.5), para $n < 50$ en los National Bureau of Standards (1950) y para $50 \leq n \leq 100$ en Romig (1947).

Ejemplo 2.4

La tabla 2.2 ha sido obtenida por Lancaster (1956), a partir de los datos publicados por Roberts et al (1939). Estos autores estudiaron 551 cruces entre ratas, con un progenitor heterocigoto para cada uno de cinco factores, y el otro progenitor homocigoto recesivo para cada uno de ellos. La distribución refleja el número de genes dominantes sobre cinco para cada progenie. La distribución teórica es la binomial, con $n = 5$ y $\pi = 1/2$. Las frecuencias «esperadas» obtenidas multiplicando las probabilidades binomiales por 551, se muestran en la tabla. La concordancia entre las frecuencias observadas y las esperadas es satisfactoria.

Tabla 2.2. Distribución del número de genes dominantes en cinco *loci*, en cruces entre progenitores heterocigotos para cada factor y homocigotos recesivos para cada uno (Lancaster, 1965).

Número de genes dominantes	Número de hijos	
	Observado	Esperado
0	17	17,2
1	81	86,1
2	152	172,2
3	180	172,2
4	104	86,1
5	17	17,2
	551	551,0

La distribución binomial se caracteriza por las variables matemáticas (π) y n . Variables como éstas, que caracterizan parcial o totalmente una distribución de probabilidad, se conocen como *parámetros*. Desde luego, son completamente distintas de las variables aleatorias. La figura 2.7 ilustra la forma de la distribución de varias combinaciones de (π) y n . Obsérvese que, para un valor particular de n , la distribución es simétrica para (π) = $1/2$ y asimétrica para (π) < $1/2$ o (π) > $1/2$, y que para un valor particular de (π) la asimetría disminuye a medida que n aumenta.

Los métodos estadísticos basados en la distribución binominal se describen con detalle en los apartados 4.7 a 4.9 y 7.5.

2.6. Distribución de Poisson

Esta distribución lleva el nombre del matemático francés S. D. Poisson (1781-1840). A veces es útil como caso particular de la distribución binomial, pero también es importante por sí misma cuando sucesos iguales ocurren aleatoriamente en función del tiempo, o cuando pequeñas partículas se distribuyen de forma aleatoria en el espacio.

Consideraremos en primer lugar los sucesos aleatorios en función del tiempo. Supongamos que cierto tipo de sucesos ocurren de manera repetida, con una frecuencia media de λ por unidad de tiempo pero siguiendo un patrón completamente aleatorio. Para que la idea de aleatoriedad sea más precisa podemos postular que en cada pequeño intervalo de tiempo h (p. ej., 1 mseg) la probabilidad de que ocurra el suceso es aproximadamente proporcional a h , es decir λh (p. ej., si se duplica h , la probabilidad de que el intervalo contenga el suceso también




Fig. 2.7. Distribución binomial para varios valores de π y n . La escala horizontal de cada gráfico representa valores de r .

se duplica). La probabilidad de que el intervalo contenga más de un suceso es proporcionalmente más pequeña cuanto menor sea h , y puede, por lo tanto, pasarse por alto. Además, supongamos que lo que ocurre en cualquier pequeño intervalo es independiente de lo que sucede en cualquier otro pequeño intervalo que no se superponga al primero.

Un ejemplo válido de este tipo de modelo de probabilidad es la emisión de partículas procedentes de algún tipo de material radiactivo. La frecuencia media o razón de emisión, λ , será constante, pero las partículas se emitirán de manera aleatoria, siendo equivalentes todos los pequeños intervalos sucesivos en el tiempo. El modelo es análogo, en forma continua, a las secuencias aleatorias de los ensayos independientes comentados en el apartado 2.1. Se lo denomina *proceso de Poisson*.




Fig. 2.8. Aparición de los sucesos en un proceso de Poisson. La escala de tiempo está subdividida en pequeños intervalos.

Supongamos que observamos períodos repetidos de tiempo, de una longitud T veces la unidad de tiempo, en un proceso de Poisson de razón λ . El número, x , de sucesos que ocurren en un período de tiempo determinado T , variará de un intervalo a otro. En realidad es una variable aleatoria, cuyos valores son 0, 1, 2, ..., etc. ¿Cuál es la probabilidad de un valor de x específico?

Una estimación del valor de x sería λT , la razón de aparición multiplicada por el intervalo de tiempo. Más adelante veremos que λT es la media de la distribución de x , y es conveniente representar λT con el símbolo μ .

Cualquier intervalo de tiempo T puede dividirse en numerosos subintervalos de longitud T/n (fig. 2.8). Si n es suficientemente grande, el número de sucesos de cada subintervalo casi siempre será 0, a veces 1 y, de forma excepcional superior a 1. Por lo tanto, la situación es casi igual a la secuencia de n ensayos binomiales (siendo cada ensayo la observación de un subintervalo), en cada uno de los cuales existe una probabilidad $\lambda(T/n) = \mu/n$ de que ocurra un suceso, y una probabilidad de $1 - \mu/n$ de que no ocurra. La probabilidad de que en la serie completa de n pruebas aparezcan exactamente x sucesos, según esta aproximación, vendrá dada por la distribución binomial:

$$\frac{n(n-1) \dots (n-x+1)}{x!} \left(\frac{\mu}{n}\right)^x \left(1 - \frac{\mu}{n}\right)^{n-x} \quad (2.14)$$

Esta aproximación mediante la ley binomial es mejor si n es grande. ¿Qué ocurre en la fórmula (2.14) si n aumenta indefinidamente? Podemos sustituir:

$$n(n-1) \dots (n-x+1)$$

por n^x puesto que x será despreciable en comparación a n . Del mismo modo podemos sustituir $(1 - \mu/n)^{n-x}$ por $(1 - \mu/n)^n$ puesto que $(1 - \mu/n)^x$ se aproxima a 1 cuando n aumenta. Matemáticamente se sabe que cuando n aumenta de forma indefinida, $(1 - \mu/n)^n$ se aproxima a $e^{-\mu}$, donde e es la base de los logaritmos naturales (neperianos) ($e = 2,718\dots$).

Así pues, en el caso de que n aumente indefinidamente, la probabilidad de x se aproxima a:

$$P_x = \frac{n^x}{x!} \left(\frac{\mu}{n}\right)^x e^{-\mu} = \frac{\mu^x e^{-\mu}}{x!} \quad (2.15)$$

La fórmula (2.15) define la probabilidad de la distribución de Poisson. La variable aleatoria x toma los valores 0, 1, 2, ..., cuyas sucesivas probabilidades se obtienen al insertar los valores de x en la fórmula (2.15). Por lo tanto:

$$\begin{aligned}
 P_0 &= e^{-\mu} \\
 P_1 &= \mu e^{-\mu} \\
 P_2 &= 1/2 \mu^2 e^{-\mu}, \text{ etc.}
 \end{aligned}$$

Obsérvese que, cuando $x = 0$, sustituimos $x!$ de (2.15) por el valor de 1, del mismo modo que hacíamos en la distribución binomial. Para verificar que la suma de las probabilidades es 1:

$$\begin{aligned}
 P_0 + P_1 + P_2 + \dots &= e^{-\mu} (1 + \mu + 1/2 \mu^2 + \dots) \\
 &= e^{-\mu} \times e^{\mu} \\
 &= 1,
 \end{aligned}$$

la sustitución de la serie infinita del lado derecho de la igualdad por e^{μ} es una equivalencia matemática clásica.

Antes de considerar otras propiedades de la distribución de Poisson, debemos señalar que puede aplicarse una demostración similar a la situación en qué partículas se distribuyen aleatoriamente en el espacio. Si el espacio es unidimensional (p. ej., la longitud de un hilo de algodón a lo largo del cual pueden aparecer defectos con una probabilidad constante para cada punto), la analogía es inmediata. En el espacio bidimensional (p. ej., una preparación de microscopia en la que las bacterias se distribuyen aleatoriamente mediante una técnica de mezcla perfecta), el área total de tamaño A puede dividirse en un gran número, n , de subdivisiones de área A/n ; la demostración sigue igual, reemplazando T por A . De forma similar, en un espacio tridimensional (bacterias bien mezcladas en una suspensión fluida), el volumen total, V , se divide en n pequeños volúmenes de tamaño V/n . En todas esas situaciones, el modelo considera partículas distribuidas aleatoriamente con una densidad λ por unidad de medida (área o volumen).

El número de partículas observadas en una longitud (área o volumen) de tamaño l [A o V] seguirá una distribución de Poisson (2.15), donde el parámetro $\mu = \lambda l$ (λA o λV).

En la figura 2.9 se muestran las formas de la distribución cuando $\mu = 1, 4$ y 15. Nótese que cuando $\mu = 1$, la distribución es muy asimétrica; cuando $\mu = 4$, la asimetría disminuye, y cuando $\mu = 15$, casi no existe asimetría.

La distribución (2.15) está determinada completamente por el parámetro μ . Todas las características de la distribución que pueden interesar se hallan en función sólo de μ . En especial, la media y la variancia son funciones sólo de μ . La media es:

$$\begin{aligned}
 E(x) &= \sum_{x=0}^{\infty} x P_x \\
 &= \sum_{x=0}^{\infty} \frac{x \mu^x e^{-\mu}}{x!} \\
 &= \sum_{x=1}^{\infty} \frac{\mu^x e^{-\mu}}{(x-1)!} \text{ ya que } \frac{x}{x!} = \frac{1}{(x-1)!}
 \end{aligned}$$

y el término del sumatorio que corresponde a $x = 0$, vale cero.




Fig. 2.9. Distribución de Poisson para varios valores de μ . La escala horizontal de cada gráfico representa los valores de x .

$$\begin{aligned}
 E(x) &= \mu \sum_{x=1}^{\infty} \frac{\mu^{x-1} e^{-\mu}}{(x-1)!} \\
 &= \mu \sum_{i=0}^{\infty} \frac{\mu^i e^{-\mu}}{i!}, \text{ Sustituyendo } i = x - 1 \\
 &= \mu,
 \end{aligned}$$

puesto que el sumatorio contiene todos los términos de la distribución de Poisson cuya suma es 1.

Para calcular la variancia, cuya fórmula simplificada es $E(x^2) - \mu^2$, en primer lugar hallamos que $E[x(x-1)] = E(x^2) - E(x)$.

$$\begin{aligned}
 E[x(x-1)] &= \sum_{x=0}^{\infty} x(x-1) P_x \\
 &= \mu^2 \sum_{x=2}^{\infty} \frac{\mu^{x-2} e^{-\mu}}{(x-2)!} \\
 &= \mu^2
 \end{aligned}$$

mediante la misma argumentación que antes. De modo que:

$$\begin{aligned} E(x^2) - E(x) &= \mu^2 \\ E(x^2) &= \mu^2 + E(x) \\ &= \mu^2 + \mu \end{aligned}$$

y

$$\begin{aligned} \text{Var}(x) &= E(x^2) - \mu^2 \\ &= (\mu^2 + \mu) - \mu^2 \\ &= \mu \end{aligned} \tag{2.16}$$

Por lo tanto, la variancia de x , como la media, es igual a μ . La desviación tipo será $\sqrt{\mu}$.

En bacteriología se utiliza a menudo la distribución de Poisson. Para estimar la densidad de microorganismos vivos de una suspensión, el bacteriólogo puede diluir la suspensión por un factor de 10^{-5} , por ejemplo, tomar muestras de la suspensión de 1 ml mediante una pipeta y verter el contenido en una placa que contenga un medio nutritivo en el que las bacterias pueden desarrollarse. Después de algún tiempo, cada microorganismo presente en el medio puede haber formado una colonia, y las colonias pueden contarse. Si la suspensión original estaba bien mezclada, los volúmenes de las muestras determinados con precisión y el medio nutritivo es uniformemente adecuado para producir el crecimiento, el número de colonias presentes en grandes series de placas debería seguir una distribución de Poisson. El número medio de colonias por placa, $\bar{x}$, es una estimación del número medio de bacterias por 10^{-5} ml de la suspensión original. El conocimiento de las propiedades teóricas de la distribución de Poisson permite medir la precisión de esta estimación (v. apartado 4.10).

De forma similar, en el caso del recuento total de microorganismos vivos o muertos, se pueden examinar con el microscopio distintas muestras repetidas de volumen constante y contar directamente los microorganismos.

Ejemplo 2.5

Como ejemplo, la tabla 2.3 muestra la distribución observada durante un recuento de bacteria nodular de las raíces (*Rhizobium trifolii*) en una cámara de recuento tipo Petroff-Hausser. Las frecuencias esperadas se obtienen calculando el número medio de microorganismos por cuadrado, $\bar{x}$, a partir de la distribución de frecuencias (resulta $\bar{x} = 2,50$) y calculando la probabilidad P_r de la distribución de Poisson sustituyendo μ por $\bar{x}$. Las frecuencias esperadas se obtienen a partir de $400 P_r$. Las frecuencias observadas concuerdan bastante bien con las esperadas. Este microorganismo suele producir una goma y, por lo tanto, se agrega rápidamente. En estas circunstancias, no se debe esperar encontrar una distribución de Poisson, pero los datos de la tabla 2.3 se recogieron para demostrar la eficacia de un método para impedir la agregación.

En la demostración de la distribución de Poisson se tuvo en cuenta el hecho de que la distribución binomial con una n grande y una π pequeña es una aproximación de la distribución de Poisson de media $\mu = n\pi$.

A la inversa, cuando la distribución correcta es de tipo binomial con una n grande y una π pequeña, podemos aproximarnos a ella mediante una distribución de Poisson de media $n\pi$. Por ejemplo, el número de muertes por una enfermedad específica en una amplia población

Tabla 2.3. Distribución de recuentos de bacteria nodular de las raíces (*Rhizobium trifolii*) en una cámara de recuento tipo Petroff-Hausser (datos de Wilson y Kullman, 1931).

Número de bacterias por cuadrado	Número de cuadrados	
	Observado	Esperado
0	34	32,8
1	68	82,1
2	112	102,6
3	94	85,5
4	55	53,4
5	21	26,7
6	12	11,1
7-	4	5,7
	400	399,9

de n sujetos con una probabilidad de muerte de π , es una distribución binomial, pero puede considerarse aproximadamente como una variable de Poisson con una media $\mu = n\pi$. Obsérvese que la desviación tipo de la teoría binomial es $\sqrt{n\pi(1-\pi)}$, mientras que la desviación tipo de la distribución de Poisson es $\sqrt{n\pi}$. Cuando π es muy pequeña, las dos ecuaciones son prácticamente iguales. En la tabla 2.4 se muestran las probabilidades de una distribución de Poisson con $\mu = 5$, y las de varias distribuciones binomiales con $n\pi = 5$. La semejanza entre las distribuciones binomial y de Poisson mejora cuando n aumenta (y, en consecuencia, π disminuye).

Las probabilidades de la distribución de Poisson se tabulan en las tablas 7 y 39 de Pearson y Hartley (1966).

Tabla 2.4. Distribuciones binomial y de Poisson con $\mu = 5$

r	π n	0,5 10	0,10 50	0,05 100	Poisson
0		0,0010	0,0052	0,0059	0,0067
1		0,0098	0,0286	0,0312	0,0337
2		0,0439	0,0779	0,0812	0,0842
3		0,1172	0,1386	0,1396	0,1404
4		0,2051	0,1809	0,1781	0,1755
5		0,2461	0,1849	0,1800	0,1755
6		0,2051	0,1541	0,1500	0,1462
7		0,1172	0,1076	0,1060	0,1044
8		0,0439	0,0643	0,0649	0,0653
9		0,0098	0,0333	0,0349	0,0363
10		0,0010	0,0152	0,0167	0,0181
> 10		0	0,0094	0,0115	0,0137
		1,0000	1,0000	1,0000	1,0000

2.7. Distribución normal (o de Gauss)

Las distribuciones binomial y de Poisson se refieren a una variable discreta. La distribución de probabilidad para variables continuas más importante es la de *Gauss* (C.F. Gauss, 1777-1855, matemático alemán) o, como habitualmente se la denomina, *distribución normal*. Las figuras 2.10 y 2.11 muestran dos distribuciones de frecuencia, las de la talla y la presión arterial. Ambas son aproximadamente simétricas y muestran una forma semejante a una campana, con un pico pronunciado en el medio y una disminución gradual de las frecuencias en las colas. Las frecuencias observadas se han aproximado mediante una curva suave, que en cada caso representa la densidad de la probabilidad de una distribución normal.

A menudo se observan distribuciones de frecuencias que se parecen a la distribución normal de probabilidad, pero esta forma no debe considerarse como una norma, a pesar de que el nombre «normal» puede prestarse a confusiones. Muchas distribuciones presentan una forma muy diferente a la «normal» y, sin embargo, no puede afirmarse que sean anormales en el sentido estricto de la palabra. La importancia de la distribución normal no consiste tanto en el hecho de que representa un amplio margen de las distribuciones de frecuencia observadas, sino en el lugar central que ocupa en la teoría de muestreo, como veremos en el capítulo 3. Para los objetivos que ahora nos ocupan, debemos considerar la distribución normal como una de las distintas formas teóricas para una variable aleatoria continua y proceder a describir alguna de sus propiedades.

La densidad de la probabilidad, $f(x)$, de una variable aleatoria, x , que sigue una distribución normal, se halla mediante la fórmula:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x-\mu)^2}{2\sigma^2} \right] \quad (2.17)$$




Fig. 2.10. Distribución de las tallas de varones adultos jóvenes, con una distribución aproximadamente normal. (Martin, 1949, tabla 17, grado 1.)




Fig. 2.11. Distribución de las presiones arteriales diastólicas de escolares, con una distribución aproximadamente normal. (Rose, 1962, tabla 1.)

en la que $\text{Exp}(z)$ es una forma cómoda de escribir la función exponencial e^z (siendo e la base de los logaritmos naturales), μ es el valor esperado o medio de x , y σ es la desviación tipo de x . (Nótese que π representa la constante matemática 3,14159..., y no, como en el apartado 2.5, un parámetro de la distribución binomial.)

La curva (2.17) se muestra en la figura 2.12, en cuyo eje horizontal están indicadas las posiciones de la μ y los valores de x que difieren de μ en $\pm \sigma$, $\pm 2\sigma$ y $\pm 3\sigma$. La simetría de la distribución con respecto a μ puede inferirse a partir de (2.17), puesto que al cambiar el signo, sin cambiar la magnitud de $x - \mu$, $f(x)$ no varía.

La figura 2.12 muestra que una proporción relativamente pequeña del área situada por debajo de la curva cae fuera de la pareja de valores $x = \mu + 2\sigma$ y $x = \mu - 2\sigma$. La zona situada debajo de la curva entre estos dos valores representa la probabilidad de que una variable




Fig. 2.12. Función de densidad de probabilidad de una distribución normal que muestra las escalas de la variable original y de la variable estandarizada.

aleatoria x tome un valor comprendido entre estos dos puntos (v. apartado 2.3). De hecho, la probabilidad de que x se encuentre dentro del intervalo $\mu \pm 2\sigma$ es muy próxima a 0,95, y la probabilidad de que x se encuentre fuera de este intervalo es 0,05.

Para el estadístico es importante poder hallar el área situada por debajo de cualquier parte de la distribución normal. En esta distribución, la función de densidad depende de dos parámetros μ y σ . Por lo tanto, podría pensarse que cualquier probabilidad pertinente debería calcularse separadamente para cada par de valores de μ y σ . Afortunadamente esto no ocurre así. En el apartado anterior comentamos la probabilidad de que x se encontrase dentro o fuera del intervalo $\mu \pm 2\sigma$ sin efectuar afirmación alguna sobre los valores de μ y σ . En realidad, las probabilidades dependen de la diferencia de x respecto a μ expresada como múltiplo de σ . Por ejemplo, los puntos indicados en el eje de la figura 2.12 se caracterizan por los múltiplos ± 1 , ± 2 y ± 3 , como puede apreciarse en la escala inferior. Las probabilidades de distintas partes de cualquier distribución normal pueden, por lo tanto, expresarse en términos de *desviación estandarizada* (o valor z).

$$z = \frac{x - \mu}{\sigma}$$

En la tabla 2.5 se muestran algunos resultados importantes. En la tabla A1 del apéndice se proporcionan resultados más detallados.

Tabla 2.5. Algunas probabilidades asociadas a la distribución normal.

Desviación estandarizada $z = (x - \mu)/\sigma$	Probabilidad de una desviación mayor	
	En ambas direcciones	En una dirección
0,0	1,000	0,500
1,0	0,317	0,159
2,0	0,046	0,023
3,0	0,0027	0,0013
1,645	0,10	0,05
1,960	0,05	0,025
2,576	0,01	0,005

La utilización de las tablas de distribución normal puede ilustrarse con el siguiente ejemplo.

Ejemplo 2.6

Las tallas de una amplia población de varones siguen estrechamente una distribución normal, con una media de 172,5 cm y una desviación tipo de 6,25 cm. Usaremos la tabla A1 para buscar la proporción de la población que corresponde a distintos intervalos de tallas.

1. *Más de 180 cm.* Si $x = 180$, la desviación estandarizada $z = (180 - 172,5)/6,25 = 1,20$. La proporción que buscamos es la probabilidad de que z sea superior a 1,20, la cual, según la tabla A1, es 0,115.
2. *Inferior a 170 cm.* $z = (170 - 172,5)/6,5 = -0,40$. La probabilidad de que z sea inferior a $-0,40$ es la misma que la de superar $+0,40$, es decir, de 0,345.
3. *Inferior a 185 cm.* $z = (185 - 172,5)/6,5 = 2,00$. La probabilidad de que z sea inferior a 2,00 es de 1 menos la probabilidad de superar 2,00, es decir, $1 - 0,023 = 0,977$.
4. *Entre 165 y 175 cm.* Para $x = 165$, $z = -1,20$; para $x = 175$, $z = 0,40$. La probabilidad de que z se encuentre entre $-1,20$ y $0,40$ es de 1 menos la probabilidad de que z se encuentre por debajo de $-1,20$ o por encima de $0,40$, es decir:

$$1 - (0,115 + 0,345) = 1 - 0,460 = 0,540$$

La distribución normal a menudo es útil como aproximación de las distribuciones binomial y de Poisson. La distribución binomial se aproxima a la forma de la distribución normal para cualquier valor de π cuando el otro parámetro n aumenta indefinidamente (fig. 2.7); la aproximación a la normalidad es más rápida para los valores de π próximos a $1/2$ que para los valores próximos 0 o 1, puesto que todas las distribuciones binomiales con $\pi = 1/2$ tienen la ventaja de ser simétricas. De este modo, si n es suficientemente grande, la variable binomial r (siguiendo la notación del apartado 2.5) puede considerarse que sigue una distribución casi normal, de media $n\pi$ y desviación tipo $\sqrt{n\pi(1-\pi)}$.

La distribución de Poisson de media μ se aproxima a la normalidad cuando μ aumenta indefinidamente (fig. 2.9). La variable de Poisson, x , puede considerarse entonces como aproximadamente normal como media μ y desviación tipo $\sqrt{\mu}$.

Si las tablas de la distribución normal se utilizan para proporcionar aproximaciones de las distribuciones binomial y de Poisson, debe tenerse en cuenta que estas dos distribuciones son de tipo discreto, mientras que la distribución normal es de tipo continuo. Es útil introducir lo que se conoce como *corrección de continuidad*, en la que la probabilidad exacta, por ejemplo, para la variable binomial r (que toma valores enteros) es aproximada por la probabilidad de una variable normal entre $r - 1/2$ y $r + 1/2$. De modo que la probabilidad de que una variable binomial tome valores mayores o iguales a r cuando $r > n\pi$ (o menores o iguales que

Tabla 2.6. Ejemplos de la aproximación de la distribución binomial a la distribución normal con corrección de continuidad.

π	n	Media $n\pi$	Desviación tipo $\sqrt{n\pi(1-\pi)}$	Valores de r	Probabilidad exacta	Aproximación normal con corrección de continuidad	
						z	Probabilidad
0,5	10	5	1,581	≤ 2	0,0547	1,581	0,0579
				≥ 8	0,0547		
0,1	50	5	2,121	≤ 2	0,1117	1,179	0,1192
				≥ 8	0,1221		
0,5	40	20	3,162	≤ 14	0,0403	1,739	0,0410
				≥ 26	0,0403		
0,2	100	20	4,000	≤ 14	0,0804	1,375	0,0846
				≥ 26	0,0875		

r cuando $r < n\pi$) se podrá aproximar mediante el área de la cola de la curva normal a partir de la desviación normal estandarizada:

$$z = \frac{|r - n\pi| - \frac{1}{2}}{\sqrt{[n\pi(1 - \pi)]}}$$

(las líneas verticales indican que se utiliza el «valor absoluto» o el valor numérico ignorando su signo).

Las tablas 2.6 y 2.7 ilustran las aproximaciones normales de algunas probabilidades para variables binomiales y de Poisson.

Tabla 2.7. Ejemplos de la aproximación de la distribución de Poisson a la distribución normal con corrección de continuidad.

Media μ	Desviación tipo $\sqrt{\mu}$	Valores de x	Probabilidad exacta	Aproximación normal con corrección de continuidad	
				$z = \frac{ x - \mu - \frac{1}{2}}{\sqrt{\mu}}$	Probabilidad
5	2,236	0	0,0067	2,013	0,0221
		≤ 2	0,1246	1,118	0,1318
		≥ 8	0,1334	1,118	0,1318
		≥ 10	0,0318	2,013	0,0221
20	4,472	≤ 10	0,0108	2,124	0,0168
		≤ 15	0,1565	1,006	0,1572
		≥ 25	0,1568	1,006	0,1572
		≥ 30	0,0218	2,124	0,0168
100	10,000	≤ 80	0,0226	1,950	0,0256
		≤ 90	0,1714	0,950	0,1711
		≥ 110	0,1706	0,950	0,1711
		≥ 120	0,0282	1,950	0,0256

2.8. Teorema de Bayes

En el apartado 2.1 se señaló que la definición de probabilidad a partir de la frecuencia no permite habitualmente otorgar un valor numérico a la probabilidad de que cierta proposición o hipótesis sea verdadera. Existen, sin embargo, algunas situaciones en las cuales las hipótesis alternativas pertinentes pueden considerarse como una secuencia aleatoria, de modo que es posible asignarle valores numéricos. Por ejemplo, el doctor responsable de una consulta puede estar interesado en la siguiente hipótesis: «Este paciente tiene la enfermedad A». Al considerar a dicho paciente como un miembro aleatorio de una gran secuencia de pacientes que acuden a la consulta, es posible asociar a esta hipótesis cierta probabilidad, es decir, la proporción de pacientes con enfermedad A en la serie de pacientes. Este proceso puede denominarse *probabilidad a priori*, puesto que es posible valorarlo (o al menos estimarlo *grosso modo*) mediante observaciones retrospectivas. Supongamos que el médico hace ciertas nuevas observaciones, después de las cuales vuelve a considerar la probabilidad de la hipótesis: «Este paciente tiene la enfermedad A». El nuevo valor puede denominarse *probabilidad a posteriori*, porque se refiere a la situación después de hacer las nuevas observaciones. Intuiti-

vamente, esperaríamos que la probabilidad *a posteriori* fuese superior a la probabilidad *a priori* si las nuevas observaciones fueran muy frecuentes en la hipótesis planteada y poco frecuentes en cualquier hipótesis alternativa. A la inversa, se esperaría que la probabilidad *a posteriori* fuese menor que la probabilidad *a priori* si las observaciones no se observasen con frecuencia en la enfermedad A pero fuesen comunes en otras situaciones.

Consideremos un ejemplo sencillo en el que sólo haya tres enfermedades posibles (A, B y C), con probabilidades *a priori* de π_A , π_B , y π_C (siendo $\pi_A + \pi_B + \pi_C = 1$). Supongamos que las observaciones del médico pertenezcan a una de cuatro categorías 1, 2, 3, 4 y que las distribuciones de las probabilidades de los distintos sucesos para cada enfermedad son las siguientes:

Enfermedad	Sucesos				Total
	1	2	3	4	
A	l_{A1}	l_{A2}	l_{A3}	l_{A4}	1
B	l_{B1}	l_{B2}	l_{B3}	l_{B4}	1
C	l_{C1}	l_{C2}	l_{C3}	l_{C4}	1

Supongamos que el médico observa el suceso 2. La probabilidad total de este suceso es:

$$\pi_A l_{A2} + \pi_B l_{B2} + \pi_C l_{C2}$$

Los tres términos de esta expresión son en realidad las probabilidades de la enfermedad A y el desenlace 2, de la enfermedad B y el desenlace 2 y de la enfermedad C y el desenlace 2. Por consiguiente, cuando el médico ha observado el desenlace 2, las probabilidades *a posteriori* de A, B y C, $(\pi)_{A/2}$, $(\pi)_{B/2}$ y $(\pi)_{C/2}$, son:

$$\frac{\pi_A l_{A2}}{\pi_A l_{A2} + \pi_B l_{B2} + \pi_C l_{C2}}, \frac{\pi_B l_{B2}}{\pi_A l_{A2} + \pi_B l_{B2} + \pi_C l_{C2}}, \frac{\pi_C l_{C2}}{\pi_A l_{A2} + \pi_B l_{B2} + \pi_C l_{C2}}$$

Las probabilidades *a priori* se han multiplicado por factores proporcionales a l_{A2} , l_{B2} y l_{C2} . Aunque estas tres cantidades son probabilidades simples, no forman parte de la misma distribución, al ser entradas de una columna de la tabla anterior y no de una fila. Las probabilidades de un desenlace determinado bajo hipótesis diferentes a menudo se denominan *verosimilitudes* de estas hipótesis.

Éste es un ejemplo del empleo del teorema de Bayes (que debe su nombre al clérigo inglés Thomas Bayes, 1702-1761). Por lo general, si la hipótesis H_i tiene una probabilidad *a priori* $(\pi)_i$ y un desenlace j tiene una probabilidad l_{ij} cuando H_i es verdadera, la probabilidad *a posteriori* de H_i después de observar el desenlace j es:

$$\pi_{i|j} = \frac{\pi_i l_{ij}}{\sum_h \pi_h l_{hj}} \quad (2.18)$$

Una forma alternativa de esta ecuación es la que se obtiene en términos de la probabilidad:

$$\frac{\pi_{i|j}}{1 - \pi_{i|j}} = \frac{\pi_i}{1 - \pi_i} \times \frac{l_{ij}}{l_{(\text{no } i)j}} \quad (2.19)$$

donde l_{ij} es la probabilidad del desenlace j si la hipótesis es i . La parte izquierda de la ecuación es la probabilidad *a posteriori* y los términos de la derecha de la ecuación son la probabilidad *a priori* y la razón de verosimilitud del desenlace j .

En algunos ejemplos, los sucesos serán variables aleatorias continuas, en cuyo caso los términos l_{ij} serán las densidades de la probabilidad en lugar de las probabilidades. La hipótesis H_i puede formar un conjunto continuo (p. ej., H_i puede especificar que la media μ de la distribución normal es igual a i , que puede por lo tanto tomar cualquier valor positivo o negativo); en este caso, el sumatorio del denominador de la ecuación (2.18) debe sustituirse por una integral. Sin embargo, el teorema de Bayes casi siempre adquiere la forma básica: las probabilidades *a priori* se convierten en probabilidades *a posteriori* mediante una multiplicación proporcional a las verosimilitudes.

El ejemplo proporciona una indicación sobre la forma de utilizar el teorema de Bayes como ayuda al diagnóstico. En la práctica existen serios problemas para estimar las probabilidades correctas de la población de pacientes bajo tratamiento; por ejemplo, la distribución de enfermedades observada en un centro específico está sujeta a variaciones con el tiempo. La determinación de las verosimilitudes exigirá estudios epidemiológicos extensos y bien planificados, y puede ser difícil definir las categorías de sucesos.

Una de las primeras aplicaciones del teorema de Bayes al diagnóstico médico fue la de Warner et al (1961), quienes examinaron los datos procedentes de un gran número de pacientes con enfermedad cardíaca congénita. Para 33 tipos de diagnósticos diferentes estimaron la probabilidad *a priori*, π_i , y las probabilidades l_{ij} de varias combinaciones de síntomas. En cada individuo se valoró la presencia de 50 síntomas, signos y otras variables. Incluso si todos ellos hubiesen sido dicotómicos habría existido 2^{50} valores posibles de j , y habría sido claramente imposible obtener una estimación fiable de todos los l_{ij} . Warner et al solucionaron el problema mediante una presunción, posteriormente empleada a menudo por otros profesionales de este campo, consistente en asumir que los síntomas y otras variables son estadísticamente independientes. La probabilidad de cualquier combinación de síntomas, j , puede obtenerse multiplicando conjuntamente las probabilidades separadas (o *marginales*) de cada uno. En este estudio se pudieron confirmar los diagnósticos de ciertos pacientes mediante una investigación exhaustiva. Dichos diagnósticos se compararon con los realizados mediante el teorema de Bayes y también con los de los cardiólogos experimentados utilizando la misma información. Sin embargo, la presunción de independencia de los síntomas es potencialmente peligrosa y no debe establecerse sin una cuidadosa reflexión previa.

En la revista *Medical Decision Making* se encuentran algunos artículos que ilustran el uso de métodos bayesianos y técnicas relacionadas de la teoría de decisiones para los problemas de diagnóstico, pronóstico y toma de decisiones médicos. En el artículo de Glasziou y Schwartz (1991) hay una revisión reciente del análisis de decisiones. El propósito aquí es proporcionar reglas para elegir entre las decisiones que se pueden tomar durante el curso del tratamiento médico. En estas decisiones pueden estar implicadas algunas cuestiones como llevar a cabo inmediatamente una operación o retrasar la decisión mientras el paciente se mantiene en observación o hasta disponer de los resultados de los análisis de laboratorio. Estas decisiones dependen no sólo de la valoración de las probabilidades de las enfermedades que pueden poner en peligro la vida del paciente, basadas en los indicios existentes, sino también de la valoración de la ganancia (o *utilidad*) que puede obtenerse de diversos desenlaces. Los

métodos bayesianos son cruciales para el cálculo de probabilidades, pero la asignación de utilidades puede ser difícil y de hecho muy subjetiva.

Para más detalles véanse Bailey (1977, apartado 4.7), Spiegelhalter y Knill-Jones (1984), Pauker y Kassirer (1992) y Weinstein y Fineberg (1980).

Ejemplo 2.7

Fraser y Franklin (1974) estudiaron 700 historias clínicas en pacientes afectos de enfermedad hepática. El conjunto inicial de más de 300 síntomas, signos y análisis se redujo a 97 variables para analizar. En particular, se agruparon algunos síntomas y signos clínicamente interdependientes, para reducir al máximo los problemas inherentes a la presunción de independencia que hemos comentado. Se omitieron los pacientes con diagnósticos poco frecuentes (los cuales representaban menos de 12 pacientes) o con diagnósticos múltiples, así como también los que presentaban historias clínicas incompletas. Quedaron 480 casos. Las probabilidades *a priori* se estimaron a partir de las frecuencias relativas de los diversos diagnósticos, y las verosimilitudes de una combinación específica de síntomas, signos y análisis se obtuvieron por multiplicación de las frecuencias marginales.

La aplicación del teorema de Bayes en cada historia clínica dio las probabilidades *a posteriori*. Por ejemplo, las probabilidades *a posteriori* de un paciente fueron:

Hepatitis infecciosa aguda	0,952
Hepatitis infecciosa colestásica	0,048
Todos los demás diagnósticos	0,000

En un amplio número de casos, el primero o los dos primeros diagnósticos presentaban una elevada probabilidad, como ocurre en este caso.

El primer análisis dio origen a algunas revisiones de las historias clínicas, ejercicio que se repitió en un grupo reducido de 419 pacientes. Los diagnósticos predichos se compararon con los verdaderos. El resultado se clasificó de equívoco si la probabilidad *a posteriori* más elevada era inferior a tres veces la magnitud de la segunda probabilidad. Se realizaron predicciones similares sólo basándose en las verosimilitudes (es decir, sin tener en cuenta las probabilidades *a priori*). Los resultados fueron:

	Correctos	Equívocos	Incorrectos
Verosimilitudes	316 (75%)	51 (12%)	52 (12%)
Bayes	325 (78%)	48 (11%)	46 (11%)

Parece probable que los resultados del análisis bayesiano hubieran mostrado una mayor mejora con respecto a los resultados de las verosimilitudes si no se hubiesen excluido las enfermedades poco frecuentes (porque las probabilidades *a priori* habrían sido relativamente más importantes).

Existe un peligro en la validación de este tipo de proceso de diagnóstico mediante el mismo grupo de datos del cual deriva el método, porque las estimaciones de las probabilidades son «mejores» para este grupo concreto y menos apropiadas para otros grupos. Fraser y Franklin comprobaron el método en 70 nuevos casos cuyos diagnósticos podían incluirse en el grupo considerado anteriormente. El método de Bayes dio 44 (63%) resultados correctos, 12 (17%) equívocos y 14 (20%) incorrectos. El método de las verosimilitudes también en esta ocasión fue ligeramente peor.


El siguiente ejemplo ilustra la aplicación del teorema de Bayes al consejo genético.

Ejemplo 2.8

A partir de la teoría genética se sabe que una mujer con un hermano hemofílico tiene una probabilidad de $1/2$ de ser portadora de un gen hemofílico. Una prueba de sonda diagnóstica de DNA recombinante proporciona información que contribuye a discriminar entre portadores y no portadores de un gen hemofílico. Se ha observado que el 90% de las mujeres conocidas como portadoras dan un resultado positivo en la prueba, mientras que el 20% de las no portadoras tienen un resultado positivo. Una mujer se realiza la prueba. ¿Cuál es la probabilidad de que sea portadora si el resultado es negativo?

La probabilidad puede valorarse usando (2.18). Supongamos que H_1 es la hipótesis de que la mujer es portadora, y H_2 , la de que no lo es. En este caso, $\pi_1 = \pi_2 = 0,5$. Si el desenlace j representa una prueba negativa, por tanto l_{1j} , la probabilidad de un resultado negativo si la mujer es portadora es igual a $1 - 0,9 = 0,1$, y l_{2j} , la probabilidad de un resultado negativo si la mujer no es portadora, es igual a $0,8$. Por lo tanto:

$$P(\text{portadora dada una prueba negativa}) = \frac{0,5 \times 0,1}{0,5 \times 0,1 + 0,5 \times 0,8}$$



Por lo tanto, la probabilidad *a posteriori* es menor que la probabilidad *a priori*, como cabía esperar puesto que la información adicional de que se dispone, una prueba negativa, es más probable si la mujer no es portadora.

Una representación gráfica del cálculo podría ser la siguiente: un cuadrado con un lado de longitud 1 se divide verticalmente de conformidad con las probabilidades *a priori* de cada hipótesis y, a continuación, cada columna se divide horizontalmente según las probabilidades del desenlace. Luego, mediante la regla de la multiplicación (2.2), cada uno de los cuatro rectángulos tiene un área igual a la probabilidad de la hipótesis y el desenlace correspondientes.

Una vez sabido que el desenlace es negativo, sólo el área sombreada es pertinente y la probabilidad de que la mujer sea portadora es la proporción del área sombreada que está en la columna de la condición de portadora, lo que se traduce en la misma respuesta numérica como aplicación directa de (2.18).

2.9. Probabilidad subjetiva

La utilización del teorema de Bayes descrita en el apartado 2.8 se limita sólo a situaciones en las que la hipótesis puede considerarse que tiene probabilidades *a priori* y *a posteriori* en el sentido habitual de una secuencia de observaciones. Sería muy atractivo si se pudieran otorgar probabilidades a hipótesis como la siguiente: «La utilización de la antitoxina tetánica en los casos de tétanos clínico reduce en más del 20% el desenlace mortal de la enfermedad», para la cual no es posible una interpretación en términos de frecuencias.

Supongamos que interpretamos la probabilidad de una hipótesis como nuestra medida del grado de confianza en que es verdad. Una probabilidad de cero correspondería a una falta completa de fe. El valor uno representaría la máxima seguridad. A continuación, este tipo de valores numéricos pueden manipularse con el teorema de Bayes; evaluaciones de confianza *a priori* pueden modificarse de acuerdo con la información proporcionada por variables aleatorias mediante multiplicación por verosimilitudes, originando evaluaciones de la confianza *a posteriori*. Muchos autores (Jeffreys, 1961; Good, 1950; Savage, 1954; Lindley, 1965) han defendido este método como base de la inferencia estadística y, en la actualidad, la denominada escuela bayesiana es muy influyente.

El principal problema es cómo determinar las probabilidades *a priori* de situaciones en las que las interpretaciones mediante frecuencias no tienen sentido. Una aproximación es aceptar reglas de «indiferencia» arbitraria para la distribución de las probabilidades entre las hipótesis alternativas cuando nos encontramos en un estado de ignorancia con respecto de su posibilidad relativa. Otra aproximación es preguntarse qué probabilidades estamos dispuestos a aceptar al hacer una apuesta sobre la verdad o la falsedad de una proposición específica. Si se decide que las probabilidades aceptables son 4 contra 1, se debe considerar que la proposición tiene una probabilidad de 1/5 o 0,2.

La parte principal de los métodos estadísticos descritos en esta obra se basan en el punto de vista de la probabilidad como frecuencia, y seguiremos al máximo este punto de vista. Los métodos bayesianos basados en cómodas reglas de indiferencia deseable (Lindley, 1965) a menudo se corresponden con precisión con los métodos más tradicionales, cuando se realizan los cambios de vocabulario adecuados. Indicaremos muchos de estos puntos de correspondencia (p. ej., en el apartado 4.12). No obstante, existen aspectos conflictivos entre los diferentes puntos de vista y no es correcto sugerir que sólo son distintas maneras de expresar una misma idea.

En nuestra opinión, tanto los métodos bayesianos como los no bayesianos cumplen una función propia en la metodología estadística. Si la finalidad de un análisis consiste en expresar la manera en que un conjunto de creencias iniciales se modifica por los indicios proporcionados por los datos, es evidente que los métodos bayesianos son los adecuados. Si se hace hincapié en estos indicios, sin necesidad de formular creencias *a priori* y *a posteriori*, el estadístico tiene dos opciones: usar los métodos basados en las frecuencias, como los que se describen más adelante en esta obra, o permanecer en el marco bayesiano calculando las

verosimilitudes (para una presentación directa o para su posible uso futuro en el teorema de Bayes). Los dos métodos pueden y deberían coexistir.

Los métodos bayesianos se explican con más detalle en los apartados 4.12 y 4.13. Se pueden encontrar explicaciones más exhaustivas en textos como el de Lee (1989) y, en un grado ligeramente más avanzado, en el de Box y Tiao (1973).

Capítulo 3

Muestreo

3.1. Población y muestra

La estadística como estudio se ocupa de las características de grandes conjuntos de observaciones individuales. Estos grandes conjuntos se denominan *poblaciones*. El término «población» se emplea con frecuencia en las conversaciones para referirse a grandes conjuntos de seres humanos u otros organismos vivos. El estadístico también se refiere a conjuntos de objetos inanimados, como certificados de nacimiento. También se hablará muchas veces de una población de observaciones; por ejemplo, la población de las tallas de los varones adultos residentes en Inglaterra en un momento determinado o la población de sucesos (muerte o supervivencia) en todos los pacientes que sufren una enfermedad específica durante cierto período.

Para estudiar las propiedades de algunas poblaciones, a menudo recurrimos a una *muestra* extraída de esta población. Una muestra constituye un subgrupo de individuos de la población, por lo general de número proporcionalmente pequeño, seleccionado de forma que sea representativo, hasta cierto límite, de la población. En la mayoría de las situaciones, la muestra no será totalmente representativa. Algo se pierde durante el proceso de muestreo. Es probable que cualquier muestra difiera en alguna forma de cualquier otra muestra que se hubiese podido escoger, y siempre existe un riesgo al tomar una muestra como representativa de una población. Sin embargo, es mucho lo que puede ganarse al tener que hacer sólo algunas observaciones. Si se realiza un censo de ámbito nacional mediante una entrevista, por ejemplo, a 1 de cada 100 individuos en lugar de tomar toda la población, será posible dedicar más recursos a la preparación de los entrevistadores, que serán pocos, y se obtendrán así unos registros más exactos.

El ejemplo más conocido de una encuesta por muestreo es tal vez el sondeo de opinión pública, en el que se entrevista a una pequeña proporción de la población para un objetivo concreto. En muchas encuestas por muestreo se estudian aspectos de medicina y sanidad. En el *United States National Health Interview Survey*, más de 2.000 personas son entrevistadas cada semana para tener una visión continua de la salud nacional. En Gran Bretaña se incluyen preguntas similares como parte del *General Household Survey*, que abarca a más de 10.000 hogares cada año. Aparte de estas encuestas continuas se llevan a cabo muchas encuestas *ad hoc* con fines específicos. Entre algunos ejemplos actuales en el Reino Unido se cuentan las encuestas sobre la salud dental, el hábito de fumar en los niños, salud y nutrición, alimentación infantil, y salud y actividad.

Las técnicas de diseño de encuestas sobre muestreo se estudian en el apartado 6.2. En éste sólo nos ocuparemos del procedimiento de muestreo más sencillo, el *muestreo aleatorio*; en el resto de este capítulo consideraremos las consecuencias de utilizar estos procedimientos en distintas circunstancias.

La primera fase consiste, en general, en definir el *marco del muestreo*, el cual es, fundamentalmente, una lista o forma de identificación de los individuos de la población que se va a muestrear. Por ejemplo, si el objetivo es extraer una muestra de los adultos que residen en Inglaterra, una forma correcta de definir el marco del muestreo es considerar la lista de personas registradas en el censo electoral (lista de individuos que pueden votar en las elecciones). Si la intención es muestrear pequeñas zonas del país, el marco del muestreo puede definirse realizando subdivisiones en el mapa mediante un entramado. Cuando se han definido los individuos elegibles se les puede asignar un número y el problema consiste en decidir qué números se deben seleccionar para formar la muestra.

¿Cómo debe elegirse la muestra? Si se conocen ciertas características de las poblaciones, quizá como resultado de otras encuestas, a veces se sugiere que la muestra debe escogerse mediante *selección intencionada*, por la cual se fuerza que ciertas características de la muestra se ajusten exactamente (o casi) a las de la población. Por ejemplo, al efectuar un muestreo para un estudio de mercado u opinión, algunas organizaciones utilizan el *muestreo por cuotas*, método mediante el cual cada entrevistador recibe instrucciones sobre ciertas características (como edad, sexo y estado social de los individuos que ha de seleccionar), eligiéndose proporciones de varios subgrupos que coincidan con las proporciones correspondientes de la población. La dificultad de este método consiste en que pueden existir graves diferencias entre la muestra y la población de origen con respecto a características que no se hayan tenido en cuenta. Nada justifica una confianza general sobre la representatividad de la muestra escogida mediante este procedimiento.

Por lo general es preferible aumentar algún tipo de muestreo aleatorio. En el *muestreo aleatorio simple*, cualquier posible muestra de un tamaño determinado de la población tiene la misma probabilidad de ser escogida. Una muestra específica puede, simplemente por azar, ser muy distinta de la población de origen. No obstante, la teoría de la probabilidad nos permite calcular la magnitud de estas diferencias. Gran parte del análisis estadístico se ocupa de la estimación de una magnitud probable de estos *errores de muestreo*. En este capítulo consideramos algunos de los resultados más importantes.

Para extraer una muestra aleatoria simple de una población podemos imaginar algún método físico de aleatorización. Por ejemplo, si se deben seleccionar al azar 10 individuos de una población de 100, se podría fabricar una tarjeta para cada uno de los miembros de la población, mezclarlas todas bien y seleccionar 10. Este método es pesado, especialmente si se realiza en poblaciones grandes. Es conveniente utilizar las tablas de *números aleatorios*, que dan los resultados de selecciones aleatorias muy extensas, elaboradas a partir de diversos métodos fiables. En la tabla A6 se muestra un conjunto de números aleatorios. En la página 545 se encontrarán las instrucciones para utilizar la tabla.

3.2. Error de muestreo de una medida

Supongamos que x es una variable cuantitativa aleatoria, con una media μ y una variancia σ^2 y que $\bar{x}$ es la medida de una muestra extraída al azar de n valores de x . Por ejemplo, x puede representar la presión arterial sistólica de los varones de 30 a 34 años de edad y empleados en la industria, y $\bar{x}$ la media de una muestra de n varones, extraída al azar de esta amplia población de origen. Podemos pensar que $\bar{x}$ es, por sí misma, una variable aleatoria, puesto que cada muestra tendrá su propia $\bar{x}$ y, si el procedimiento de muestreo aleatorio se repite infini-




Fig. 3.1. Distribución de una variable aleatoria y distribución muestral de las medias de muestras al azar tamaño n .

tas veces, se puede considerar que los valores de $\bar{x}$ siguen una distribución de probabilidad (fig. 3.1). La naturaleza de la distribución de $\bar{x}$ reviste gran importancia, ya que determina el grado de incertidumbre que se otorga a $\bar{x}$ precisamente mediante el proceso de muestreo.

Intuitivamente, parece que existen dos características que determinan la variabilidad de $\bar{x}$. En primer lugar depende de σ : cuanto más variable sea la presión arterial en la población industrial, más variables serán las medias de distintas muestras de tamaño n . En segundo lugar, la variabilidad de $\bar{x}$ depende de n : cuanto mayor sea el tamaño de cada muestra extraída al azar, más próximos serán los valores de $\bar{x}$ esperados.

La teoría matemática proporciona tres resultados básicos referidos a las distribuciones de $\bar{x}$, que revisten gran importancia en la estadística aplicada. La comprobación de los dos primeros resultados se realiza al final de este apartado, pero la comprobación del tercero sobrepasa los límites de este libro:

1. $E(\bar{x}) = \mu$. Es decir que la media de la distribución de las medias muestrales es la misma que la media de las medidas individuales.
2. $\text{Var}(\bar{x}) = \sigma^2/n$. La variancia de las medias muestrales es igual a la variancia de los valores individuales divididos por el tamaño de la muestra. De este modo se obtiene una ecuación que expresa formalmente la intuición antes descrita, de que la variabilidad de x depende de σ y de n ; la forma precisa cómo funciona esta dependencia no es fácil de descubrir. La desviación tipo de $\bar{x}$ es

$$\sqrt{\left(\frac{\sigma^2}{n}\right)} = \frac{\sigma}{\sqrt{n}} \quad (3.1)$$

Esta cantidad se denomina a menudo *error tipo* de la media, y se expresa $ET(\bar{x})$. Es conveniente utilizar esta nomenclatura para evitar la confusión entre la desviación tipo de x y la desviación tipo de $\bar{x}$; sin embargo, se debe recordar que el error tipo no es realmente un concepto nuevo: sólo es la desviación tipo de una cantidad calculada a partir de una muestra (en este caso, la media) en una serie infinitamente larga de muestreos repetidos.

3. Si la distribución de x es normal, $\bar{x}$ también tendrá una distribución normal. Aún resulta más importante el hecho de que, incluso si la distribución de x no es normal, la distribución de $\bar{x}$ será cada vez más próxima a la distribución normal con media μ y variancia σ^2/n cuanto mayor sea n . Esto se produce como consecuencia del formalismo matemático denominado *teorema del límite central*, y explica la importancia de la distribución normal en estadística.

En rigor, la distribución normal representa sólo la forma límite de la distribución del muestreo de $\bar{x}$ cuando n aumenta indefinidamente, pero proporciona una aproximación extraordinariamente buena de la distribución del muestreo incluso cuando n sea pequeña y la distribución de x esté muy alejada de la normalidad. La tabla 3.1 muestra los resultados de la selección de muestras aleatorias de cinco dígitos a partir de las tablas de números aleatorios. Estas tablas pueden considerarse como una distribución de probabilidad para una variable aleatoria discreta, x , que toma los valores 0, 1, 2, ..., 9 con la misma probabilidad de 0,1. Esta distribución está claramente alejada de la forma normal. La media y la variancia pueden calcularse por los métodos descritos en el apartado 2.4.

Tabla 3.1. Distribución de las medias de 2000 muestras de 5 números aleatorios.

Media, $\bar{x}$	Frecuencia
0,4-	1
0,8-	4
1,2-	11
1,6-	22
2,0-	43
2,4-	88
2,8-	104
3,2-	178
3,6-	196
4,0-	210
4,4-	272
4,8-	200
5,2-	193
5,6-	154
6,0-	129
6,4-	92
6,8-	52
7,2-	30
7,6-	13
8,0-	7
8,4-	1
	2.000

$$\begin{aligned}
 \mu &= E(x) = 0,1 (1 + 2 + \dots + 9) = 4,5 \\
 \sigma^2 &= E(x^2) - \mu^2 \\
 &= 0,1 (1^2 + 2^2 + \dots + 9^2) - (4,5)^2 \\
 &= 8,25 \\
 \sigma &= \sqrt{8,25} = 2,87 \\
 ET(\bar{x}) &= \sqrt{(8,25/5)} = \sqrt{1,65} = 1,28
 \end{aligned}$$

Se tomaron 2.000 muestras de tamaño 5 (mediante la generación de números aleatorios por un ordenador, en lugar de por la lectura de las tablas). Para cada muestra se calculó la media $\bar{x}$ y se ordenaron los 2.000 valores de $\bar{x}$ formando una distribución de frecuencias (tabla 3.1). Se puede apreciar que ésta tiene una forma similar a la de la distribución normal. El grado de semejanza puede observarse en la figura 3.2, que muestra el histograma que corresponde a la tabla 3.1, junto a una curva cuya altura es proporcional a la densidad de una distribución normal de media 4,5 y desviación tipo 1,28.




Fig. 3.2. Distribución de las medias de 2.000 muestras de cinco cifras aleatorias (tabla 3.1), con su aproximación a la distribución normal.

La teoría expuesta antes se aplica rigurosamente al muestreo aleatorio de una población infinita o a observaciones sucesivas e independientes de una variable aleatoria. Supongamos que se extrae una muestra de tamaño n de una población finita de tamaño N . El muestreo se efectúa generalmente *sin restitución*, lo que significa que un sujeto determinado de la población seleccionado para formar parte de la muestra no podrá volver a ser seleccionado otra vez para esta misma muestra. La esperanza matemática de $\bar{x}$ sigue siendo igual a μ , la media de la población. Sin embargo, la fórmula (3.1) se debe modificar mediante una «corrección de población finita», convirtiéndose en:

$$ET(\bar{x}) = \frac{\sigma}{\sqrt{n}} \sqrt{(1-f)} \quad (3.2)$$

donde $f = n/N$, *fracción de muestreo*. En (3.2), σ se define como desviación tipo de x en la población, utilizando el divisor $N - 1$. Así,

$$\mu = \frac{\sum_{i=1}^N x_i}{N}$$

y

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N - 1}$$

El efecto de la corrección de población finita, $1 - f$, es reducir considerablemente la variancia de muestreo cuando f se aproxima a 1, es decir, cuando el tamaño de la muestra se aproxima al de la población. Evidentemente, cuando $n = N$, $f = 1$ y $ET(\bar{x}) = 0$, sólo existe una posibilidad de muestra aleatoria, que consiste en todos los miembros de la población, y para esta muestra $x = \mu$.

El error de muestreo de la mediana de una muestra no tiene una expresión general sencilla. Sin embargo, en las muestras aleatorias procedentes de una distribución normal, el error tipo de la mediana cuando n es grande es aproximadamente de $1,253\sigma/\sqrt{n}$. El hecho de que este valor sea superior a $\sigma/\sqrt{n}$ demuestra que la mediana es más variable que la media de la muestra (o, dicho en términos técnicos, es menos *eficaz* como estimación de μ). Sin embargo, esta comparación depende de la presunción de normalidad de la distribución de x , y, para otras formas de distribución, la mediana proporciona una estimación más eficaz.

Demostraciones de los resultados 1 y 2

1. $E(x) = \mu$.

Llámense las observaciones individuales de la muestra, $x_1, x_2, \dots, x_n$. Luego,

$$\begin{aligned}\bar{x} &= (x_1 + x_2 + \dots + x_n)/n \\ &= (1/n)x_1 + (1/n)x_2 + \dots + (1/n)x_n\end{aligned}$$

Utilizando los pasos intuitivos mencionados en la nota al pie de la página 50.

$$E(\bar{x}) = (1/n)E(x_1) + (1/n)E(x_2) + \dots + (1/n)E(x_n)$$

Pero

$$E(x_1) = E(x_2) = \dots = E(x_n) = \mu$$

por tanto:

$$\begin{aligned}E(\bar{x}) &= (1/n)\mu + (1/n)\mu + \dots + (1/n)\mu \\ &= \mu\end{aligned}$$

puesto que hay n términos idénticos.

$$2. \text{Var}(\bar{x}) = \sigma^2/n$$

$$\text{Var}(\bar{x}) = E(\bar{x} - \mu)^2$$

$$= E\left(\frac{x_1 + x_2 + \dots + x_n}{n} - \mu\right)^2$$

$$= E\left[\frac{(x_1 - \mu) + (x_2 - \mu) + \dots + (x_n - \mu)}{n}\right]^2$$

$$= (1/n^2)E[(x_1 - \mu)^2 + (x_2 - \mu)^2 + \dots + 2(x_1 - \mu)(x_2 - \mu) + \dots]$$

donde los corchetes incluyen los términos elevados al cuadrado, del tipo $(x_i - \mu)^2$ y el doble de productos de términos del tipo $(x_i - \mu)(x_j - \mu)$. La esperanza matemática de cada término $(x_i - \mu)^2$ es σ^2 . La esperanza matemática de cada término $(x_i - \mu)(x_j - \mu)$ es cero, puesto que, para cualquier valor de x_i , x_j varía independientemente a lo largo de todos los valores posibles, de modo que $E(x_j - \mu) = 0$. Por lo tanto:

$$\begin{aligned}\text{Var}(\bar{x}) &= (1/n^2) (\sigma^2 + \sigma^2 + \dots \text{(hasta } n \text{ términos)} \dots + 0) \\ &= (1/n^2) (n\sigma^2) \\ &= \sigma^2/n\end{aligned}$$

3.3. Error de muestreo de una proporción

Este aspecto ya se ha comentado ampliamente en el apartado 2.5. Si los individuos de una población infinitamente grande se clasifican en dos tipos *A* y *B*, con probabilidades π y $1 - \pi$, el número r de sujetos tipo *A* de una muestra aleatoria de tamaño n sigue una distribución binomial. Ahora debemos aplicar los resultados del apartado 3.2 para comprobar la fórmula previamente proporcionada para la media y la variancia de r .

Supóngase que definimos una variable cuantitativa x que tiene el valor de 1 para cada sujeto tipo *A* y de 0 para los sujetos de tipo *B*. Debemos considerar x como una puntuación atribuida a cada componente de la población. El objeto de realizar esto es que en una muestra de n compuesta por r *A* y $(n - r)$ *B*,

$$\begin{aligned}\sum x &= (r \times 1) + [(n - r) \times 0] \\ &= r\end{aligned}$$

y

$$\bar{x} = r/n, = p \text{ de acuerdo con la notación del apartado 2.5.}$$

La proporción p de la muestra puede, por lo tanto, identificarse con la media de x de las muestras, y para analizar la variación muestral de p se pueden aplicar los resultados generales establecidos en el apartado 3.2. Debemos conocer la media y la desviación tipo poblacionales de x . A partir de las definiciones iniciales, éstas son:

$$\begin{aligned}E(x) &= (\pi \times 1) + [(1 - \pi) \times 0] \\ &= \pi\end{aligned}\tag{3.3}$$

y

$$\begin{aligned}\text{Var}(x) &= E(x^2) - [E(x)]^2 \\ &= (\pi \times 1^2) + [(1 - \pi) \times 0^2] - \pi^2 \\ &= \pi(1 - \pi)\end{aligned}$$

Y según (3.1):

$$\text{Var}(\bar{x}) = \frac{\pi(1 - \pi)}{n} \quad (3.4)$$

Escribiendo (3.3) y (3.4) en términos de p , en lugar de x y $\bar{x}$, tenemos:

$$y \quad E(p) = \pi$$

$$\text{Var}(p) = \frac{\pi(1 - \pi)}{n}$$

como en (2.12) y (2.13). Puesto que $r = np$,

$$y \quad E(r) = n\pi$$

$$\text{Var}(r) = n\pi(1 - \pi)$$

como en (2.10) y (2.11).

A partir del apartado 3.2 puede extraerse otra conclusión. Cuando n se aproxima al infinito, la distribución de $\bar{x}$ (o sea, la de p) se acerca a la distribución normal con su media y su variancia correspondiente. La simetría creciente ya se ha señalado en el apartado 2.5.

3.4. Error de muestreo de la variancia

Supóngase que una variable cuantitativa x sigue una distribución de media μ y variancia σ^2 . En una muestra de tamaño n , la estimación de la variancia es:

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

Al repetir varios muestreos aleatorios de la distribución, s^2 variará de una muestra a otra; será por sí misma una variable aleatoria. Consideremos la naturaleza de la variación de s^2 .

La esperanza matemática de s^2 puede obtenerse de la siguiente manera:

$$\begin{aligned} E(s^2) &= \frac{1}{n-1} E \left[\sum (x_i - \bar{x})^2 \right] \\ &= \frac{1}{n-1} E \left\{ \sum [(x_i - \mu) - (\bar{x} - \mu)]^2 \right\} \\ &= \frac{1}{n-1} E \left[\sum (x_i - \mu)^2 - 2 \sum (x_i - \mu)(\bar{x} - \mu) + \sum (\bar{x} - \mu)^2 \right] \\ &= \frac{1}{n-1} E \left[\sum (x_i - \mu)^2 - n(\bar{x} - \mu)^2 \right] \end{aligned}$$

puesto que:

$$\sum (x_i - \mu)(x - \mu) = \sum (x - \mu)^2 = n(x - \mu)^2$$

Ahora bien, $E(x_i - \mu)^2 = \sigma^2$ por definición, y $E(x - \mu)^2 = \text{Var}(x) = \sigma^2/n$. Por lo tanto:

$$\begin{aligned} E(s^2) &= \frac{1}{n-1} \left[n\sigma^2 - n \left(\frac{\sigma^2}{n} \right) \right] \\ &= \frac{1}{n-1} (n-1)\sigma^2 \\ &= \sigma^2 \end{aligned} \quad (3.5)$$

Otra forma de interpretar el resultado (3.5) es que s^2 es un estimador *no sesgado* de σ^2 . Esta propiedad determina que s^2 , cuyo divisor es $n-1$, sea una estimación satisfactoria de la variancia de la población: el estadístico (1.1), con un divisor igual a n , tiene una esperanza matemática $(n-1)\sigma^2/n$, la cual es menor que σ^2 . Obsérvese que $E(s)$ *no* es igual a σ ; en realidad, es menor que σ . Las razones para atribuir tanta importancia a $E(s^2)$ en lugar de a $E(s)$ se comentarán en los capítulos 7 y 8.

¿Qué puede comentarse sobre las distribuciones muestrales de s^2 ? Por el momento, analicémoslo suponiendo que se sigue rigurosamente la distribución normal. En este caso particular, s^2 está estrechamente relacionada a una familia de distribuciones denominadas distribuciones χ^2 (chi cuadrado), que a menudo poseen mucha importancia en el análisis estadístico. Es útil hacer un breve comentario sobre estas distribuciones antes de regresar a las distribuciones de s^2 , las cuales constituyen el principal objetivo de este apartado.

Llámesese X_1 a la desviación estandarizada que corresponde a la variable x . Así $X_1 = (x - \mu)/\sigma$. X_1^2 es una variable aleatoria, cuyo valor no puede ser negativo. La distribución de X_1^2 se denomina *distribución χ^2 con un grado de libertad* (1 gl), y a menudo se le llama distribución $\chi^2_{(1)}$. Se representa mediante la primera curva de la figura 3.3. Los *puntos porcentuales* de la distribución χ^2




Fig. 3.3. Función de densidad de probabilidad para las distribuciones χ^2 , en relación con distintos grados de libertad (gl).

se tabulan en la tabla A2. Los valores superados con una probabilidad P a menudo se denominan *percentiles* $100(1 - P)$; así, la columna encabezada por $P = 0,050$ da el percentil 95°. En este punto se pueden señalar dos aspectos:

1. $E(X_1^2) = E(x - \mu)^2 / \sigma^2 = r^2 = 1$. El valor medio de la distribución es 1.
2. Los percentiles pueden obtenerse a partir de los de la distribución normal. A partir de la tabla A1 podemos saber, por ejemplo, que existe una probabilidad de 0,05 de que $(x - \mu) / \sigma$ supere el valor +1,960 o que sea inferior a -1,960. Siempre que ocurra alguno de estos sucesos $(x - \mu)^2 / \sigma^2$ será mayor que $(1,960)^2 = 3,84$. Así, el nivel 0,05 de la distribución $\chi_{(1)}^2$ es 3,84. para todos los demás percentiles se encuentra una relación similar.

Si suponemos que x_1 y x_2 son observaciones independientes de x , y definimos:

$$X_2^2 = \frac{(x_1 - \mu)^2}{\sigma^2} + \frac{(x_2 - \mu)^2}{\sigma^2}$$

X_2^2 sigue lo que se conoce como *distribución de χ^2 con dos grados de libertad* ($\chi_{(2)}^2$). La variable X_2^2 , al igual que X_1^2 , es necesariamente positiva. Su distribución se muestra en la segunda curva de la figura 3.3, y los resultados se tabulan en la segunda fila de la tabla A2. Obsérvese que X_2^2 es la suma de dos observaciones independientes de X_1^2 . Por lo tanto:

$$E(X_2^2) = 2E(X_1^2) = 2$$

De forma similar, en una muestra de n observaciones independientes de x , se define:

$$X_n^2 = \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2} = \frac{\sum (x_i - \mu)^2}{\sigma^2} \quad (3.6)$$

Ésta sigue la distribución de χ^2 con n grados de libertad ($\chi_{(n)}^2$), y $E(X_n^2) = n$.

La figura 3.3 y la tabla A2 muestran que cuando los grados de libertad aumentan, la distribución de χ^2 se vuelve más simétrica. Efectivamente, como representa la suma de n variables $\chi_{(1)}^2$ independientes, el teorema del límite central (que se aplica a las sumas así como a las medias) muestra que $\chi_{(n)}^2$ tiende a la normalidad cuando n aumenta. La variancia de la distribución $\chi_{(n)}^2$ es igual a $2n$.

El resultado (3.6) nos permite encontrar la distribución de la suma de desviaciones al cuadrado, con respecto a la media, μ , de la población. En la fórmula de s^2 utilizamos la suma de cuadrados con respecto a la media, $\bar{x}$, de la muestra. Se puede demostrar que:

$$\sum (x_i - \bar{x})^2 \leq \sum (x_i - \mu)^2$$

De hecho, $\sum (x_i - \bar{x})^2 / \sigma^2$ sigue la distribución de $\chi_{(n-1)}^2$. El hecho de que se tomen las diferencias con respecto a la media de la muestra en lugar de la media de la población se compensa al restar un grado de libertad. Ahora bien,

$$\begin{aligned} s^2 &= \frac{\sum (x_i - \bar{x})^2}{n - 1} = \frac{\sigma^2}{n - 1} \frac{\sum (x_i - \bar{x})^2}{\sigma^2} \\ &= \frac{\sigma^2}{n - 1} \chi_{(n-1)}^2 \end{aligned}$$

Es decir, s^2 se comporta como $\sigma^2/(n-1)$ veces una variable $\chi^2_{(n-1)}$. Así,

$$E(s^2) = \frac{\sigma^2}{n-1} E(\chi^2_{(n-1)}) = \frac{\sigma^2}{n-1} (n-1) = \sigma^2$$

como comprobaremos directamente en (3.5) y

$$\begin{aligned} \text{Var}(s^2) &= \frac{\sigma^4}{(n-1)^2} \text{Var}(\chi^2_{(n-1)}) = \frac{\sigma^4}{(n-1)^2} 2(n-1) \\ &= \frac{2\sigma^4}{n-1} \end{aligned} \quad (3.7)$$

La fórmula (3.7) para la $\text{Var}(s^2)$ es verdadera sólo para muestras extraídas de una distribución normal; de hecho, toda la teoría de muestreo para s^2 es más sensible a la falta de normalidad que la de la media.

3.5. Error de muestreo de una diferencia

Muchas investigaciones estadísticas implican el análisis de las diferencias entre dos cantidades (p. ej., las diferencias entre la media del aumento de peso en dos grupos de animales sometidos a dietas distintas o la diferencia entre las proporciones de niños de 10 años de edad en dos regiones distintas, que muestran cierto nivel de anticuerpos séricos).

Por lo tanto, debemos preocuparnos mucho por el error de muestreo que se va a atribuir a las diferencias entre dos cantidades, como las medias o las proporciones calculadas a partir de dos muestras aleatorias independientes. En primer lugar, es mejor analizar el problema de forma general y, luego, considerar los casos particulares. Supóngase, entonces, que disponemos de dos variables aleatorias y_1 y y_2 , que y_1 se distribuye con una media m_1 y una variancia v_1 y que y_2 tiene una media m_2 y una variancia v_2 . Extraemos al azar una observación de y_1 y una observación aleatoria *independiente* de y_2 . ¿Qué podemos decir sobre la distribución de $y_1 - y_2$ en una serie infinita de repeticiones de este proceso?

$$E(y_1 - y_2) = E(y_1) - E(y_2) = m_1 - m_2 \quad (3.8)$$

$$\begin{aligned} \text{Var}(y_1 - y_2) &= E[(y_1 - y_2) - (m_1 - m_2)]^2 \\ &= E[(y_1 - m_1) - (y_2 - m_2)]^2 \\ &= E[(y_1 - m_1)^2 - 2(y_1 - m_1)(y_2 - m_2) + (y_2 - m_2)^2] \\ &= v_1 + v_2 \end{aligned} \quad (3.9)$$

siendo el término central de la línea media a la anterior igual a cero, porque para cualquier valor de y_1 , $E(y_2 - m_2) = 0$ y, en consecuencia, cuando y_1 varía, $E(y_1 - m_1)(y_2 - m_2)$ también será cero. Este término *no* sería igual a cero si y_1 y y_2 no hubiesen sido extraídas independientemente.

Ahora podemos aplicar los resultados generales de (3.8) y (3.9) al caso particular en el que $y_1 = \bar{x}_1$, la media de una muestra aleatoria de tamaño n_1 , extraída de una población de media μ_1 y variancia σ_1^2 , $y_2 = \bar{x}_2$, la media de una muestra aleatoria independiente, de tamaño n_2 y extraída de una población de media μ_2 y variancia σ_2^2 . En este caso, a partir de los resultados del apartado 3.2. tenemos:

$$m_1 = \mu_1 \quad y \quad v_1 = \sigma_1^2/n_1$$

$$m_2 = \mu_2 \quad y \quad v_2 = \sigma_2^2/n_2$$

Por lo tanto, según (3.8) y (3.9):

$$y \quad \left. \begin{aligned} E(\bar{x}_1 - \bar{x}_2) &= \mu_1 - \mu_2 \\ \text{Var}(\bar{x}_1 - \bar{x}_2) &= \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} \end{aligned} \right\} \quad (3.10)$$

De forma similar, supóngase que $y_1 = p_1$, la proporción de sujetos que presentan cierta característica en una muestra de tamaño n_1 , extraída de una población en la que esta característica aparece con una probabilidad π_1 , e $y_2 = p_2$, la proporción en una muestra independiente de tamaño n_2 , extraída de una población con un parámetro π_2 . En este caso, según el apartado 3.3,

$$m_1 = \pi_1 \quad y \quad v_1 = \pi_1(1 - \pi_1)/n_1$$

$$m_2 = \pi_2 \quad y \quad v_2 = \pi_2(1 - \pi_2)/n_2$$

En consecuencia, según (3.8) y (3.9)

$$y \quad \left. \begin{aligned} E(p_1 - p_2) &= \pi_1 - \pi_2 \\ \text{Var}(p_1 - p_2) &= \frac{\pi_1(1 - \pi_1)}{n_1} + \frac{\pi_2(1 - \pi_2)}{n_2} \end{aligned} \right\} \quad (3.11)$$

Los resultados de (3.10) y (3.11) tienen mucha importancia en los métodos estadísticos que se describirán en el siguiente capítulo. En este punto, es importante subrayar la condición de independencia. Si las dos muestras no son independientes, debido, por ejemplo, a alguna limitación en el diseño de la investigación, las fórmulas de esperanza matemática (3.10) y (3.11) no se alterarán, pero las fórmulas para las variancias no serán válidas.

3.6. Otras fórmulas para la variancia

En el apartado 3.5 hemos descrito una fórmula general para la variancia de la diferencia entre dos muestras aleatorias y la hemos aplicado a dos problemas de muestreo distintos. Es conveniente mencionar en este momento una o dos fórmulas para las variancias de distintas funciones de variables aleatorias independientes. Se dice que dos variables aleatorias son *independientes* si la distribución de una no es afectada por el valor que toma la otra. Una consecuencia importante de la independencia consiste en que los valores medios pueden multiplicarse. Es decir, si $y = x_1 x_2$, cuando x_1 y x_2 son independientes, entonces:

$$E(y) = E(x_1)E(x_2) \quad (3.12)$$

Función lineal

Supóngase que $x_1, x_2, \dots, x_k$ son variables aleatorias independientes e:

$$y = a_1 x_1 + a_2 x_2 + \dots + a_k x_k$$

siendo los valores de a constantes. En este caso,

$$\text{Var}(y) = a_1^2 \text{Var}(x_1) + a_2^2 \text{Var}(x_2) + \dots + a_k^2 \text{Var}(x_k) \quad (3.13)$$

El resultado de (3.9) es un caso específico de (3.13) cuando $k = 2$, $a_1 = 1$ y $a_2 = -1$.

La condición de independencia es importante. Si las x no son independientes, se deberá añadir una serie de términos en el miembro derecho de (3.13), por ejemplo:

$$2a_i a_j \text{Cov}(x_i, x_j) \quad (3.14)$$

donde «Cov» significa *covariancia* de x_i y x_j , la cual se define como:

$$\text{Cov}(x_i, x_j) = E\{[x_i - E(x_i)][x_j - E(x_j)]\}$$

La covariancia es la esperanza matemática del producto de las desviaciones de dos variables aleatorias con respecto a sus medias. Cuando las variables son independientes, la covariancia es cero [véase la demostración en (3.9)]. Cuando todas las k variables son independientes, todos los términos de las convariancias desaparecen y la ecuación se simplifica a (3.13).

Cociente

Supongamos que $y = x_1/x_2$ y que en esta ocasión x_1 y x_2 también son independientes. No puede establecerse fórmula general alguna para la variancia de y . En realidad, puede ser infinita. No obstante, si x_2 tiene un coeficiente de variación pequeño, la distribución de y será bastante similar a la distribución que tenga una variancia obtenida mediante la siguiente fórmula:

$$\text{Var}(y) = \frac{\text{Var}(x_1)}{[E(x_2)]^2} + \frac{[E(x_1)]^2}{[E(x_2)]^4} \text{Var}(x_2) \quad (3.15)$$

Obsérvese que si x_2 no tiene variabilidad alguna, (3.15) se reduce a:

$$\text{Var}(y) = \frac{\text{Var}(x_1)}{x_2^2}$$

la cual es exacta cuando x_2 es una constante.

Producto

Supongamos que $y = x_1 x_2$ donde x_1 y x_2 son independientes. Llamemos a las medias de x_1 y x_2 , μ_1 y μ_2 , y a sus variancias σ_1^2 y σ_2^2 . Entonces,

$$\begin{aligned}\text{Var}(y) &= E(y^2) - [E(y)]^2 \\ &= E(x_1^2)E(x_2^2) - [E(x_1)E(x_2)]^2 \\ &= (\mu_1^2 + \sigma_1^2)(\mu_2^2 + \sigma_2^2) - \mu_1^2 \mu_2^2 \\ &= \mu_1^2 \sigma_2^2 + \mu_2^2 \sigma_1^2 + \sigma_1^2 \sigma_2^2\end{aligned}\quad (3.16)$$

Obsérvese que en el paso de la primera a la segunda línea de esta demostración se aplica la presunción de que x_1 y x_2 son independientes. Por ejemplo, si x_1 y x_2 no fuesen independientes, $E(y) = E(x_1)E(x_2)$ no sería necesariamente cierto.

Funciones generales

Supóngase que se conocen la media y la variancia de una variable aleatoria x . ¿Podemos calcular la media y la variancia de cualquier función general de x , por ejemplo $3x^3$ o $\sqrt{\log x}$? No existe una fórmula sencilla, pero otra vez se dispone de una aproximación útil cuando el coeficiente de variación de x es pequeño. Debemos suponer que se dispone de ciertas nociones de cálculo. Llamemos y a la función de x . Entonces,

$$\text{Var}(y) \simeq \left(\frac{dy}{dx} \right)^2_{x=E(x)} \text{Var}(x) \quad (3.17)$$

El símbolo $\simeq$ significa «aproximadamente igual a». En (3.17) dy/dx es el coeficiente diferencial (o derivada) de y con respecto a x , evaluado para el valor medio de x .

Si y es la función de dos variables, x_1 y x_2 ,

$$\text{Var}(y) \simeq \left(\frac{\partial y}{\partial x_1} \right)^2 \text{Var}(x_1) + 2 \left(\frac{\partial y}{\partial x_1} \right) \left(\frac{\partial y}{\partial x_2} \right) \text{Cov}(x_1, x_2) + \left(\frac{\partial y}{\partial x_2} \right)^2 \text{Var}(x_2) \quad (3.18)$$

donde $\delta y / \delta x_1$ y $\delta y / \delta x_2$ son las derivadas *parciales* de y con respecto a x_1 y x_2 , y éstas han sido también evaluadas en los valores medios. El lector con conocimientos de cálculo matemático podrá obtener (3.9) como un caso particular de (3.18) cuando $\text{Cov}(x_1, x_2) = 0$. La extensión de (3.18) a k variables da lugar a (3.13) como caso particular. La ecuación (3.16) es otro caso particular de (3.18), cuando $\text{Cov}(x_1, x_2) = 0$. En (3.16), el último término es insignificante, si los coeficientes de variación de x_1 y x_2 son muy pequeños; los dos primeros términos concuerdan con (3.18).

Capítulo 4

La inferencia estadística

4.1. Generalidades

El razonamiento del capítulo 3 se dirigía fundamentalmente desde la población hacia la muestra. Dada la distribución de una variable en una población, obteníamos resultados con respecto a las distribuciones de varias cantidades, como la media y la variancia, calculadas a partir de observaciones en la muestra. Una cantidad de este tipo se denomina *estadístico*. Estos resultados tienen un interés directamente relacionado con la planificación de los estudios de muestreo, porque permiten al investigador estimar la precisión alcanzable con una muestra de un tamaño determinado y le ayudan a decidir su tamaño. Esta cuestión se tratará de nuevo en el apartado 6.6.

Sin embargo, todavía no nos hemos enfrentado a otro problema que interesa al investigador. Una vez extraída la muestra, ¿qué tipo de conclusiones pueden extraerse sobre la población, basándonos en la muestra? En este caso, el razonamiento toma una dirección opuesta a la utilizada previamente. Nosotros no conocemos las características de la población. Hemos extraído una muestra al azar y deseamos utilizar nuestros conocimientos sobre la teoría del muestreo para efectuar cualquier tipo de inferencia que pueda realizarse sobre la población. Habitualmente se plantea una dificultad fundamental. Las expresiones referentes a la variación muestral proporcionadas por las fórmulas de los errores tipo o de las variancias en el capítulo precedente incluyen en general algunos parámetros de la población. Por ejemplo, el error tipo de la media de la muestra es $\sigma/\sqrt{n}$. Si intentamos hacer alguna deducción sobre una distribución normal basándonos en una muestra extraída al azar, conoceremos el tamaño de la muestra, n , pero no la desviación tipo de la población, σ . Por consiguiente, no podemos calcular exactamente el error tipo. En otras situaciones se plantea una cuestión similar. El tema central de este capítulo lo constituyen los métodos para superar esta dificultad.

Continuaremos suponiendo que los datos de que disponemos forman una muestra extraída al azar de una población. Esto es cierto en determinados estudios de muestreo, gracias al diseño de la investigación. En otros estudios podrían utilizarse formas más complejas de muestreo; la consideración de algunos diseños más complejos se pospone hasta el capítulo 6. Una dificultad conceptual más importante es que en muchas investigaciones estadísticas no existe un proceso formal de muestreo a partir de una población bien definida. Por ejemplo, se puede calcular la prevalencia de cierta enfermedad para todos los habitantes de un pueblo y compararla con la de otro. Se puede llevar a cabo un ensayo clínico en una clínica, con la participación de todos los pacientes visitados durante un período determinado. Un médico puede comunicar la duración media de los síntomas en una serie consecutiva de 50 pacientes con una enfermedad determinada. Las lecturas individuales varían al azar si forman una muestra aleatoria o si son recogidas de un modo menos formal, y muchas veces será conveniente valorar el efecto que esta variabilidad básica ejerce sobre los cálculos estadís-

ticos que se realizan. ¿Cómo se puede hacer esto si no existe una población infinita ni una muestra extraída rigurosamente al azar?

Se puede hacer sosteniendo que las observaciones están sujetas al azar, a una variación no sistemática que las hace aparecer como observaciones de una variable aleatoria. La población formada por toda la distribución no es una entidad real y bien definida, pero podría ser útil considerarla como la población hipotética que sería generada si se pudiera contar con un número infinito de observaciones que mostraran el mismo tipo de variación aleatoria que las que disponemos. Este concepto parece satisfactorio cuando las observaciones varían sin seguir un patrón concreto. Estamos proponiendo un «modelo» o una estructura conceptual para la variación aleatoria y planteamos hacer todo tipo de afirmaciones sobre las características relacionadas con dicho modelo, como deseamos hacer afirmaciones sobre las características relacionadas con una población a partir de una muestra. A veces, la suposición de que los datos se comportan como una muestra extraída al azar es descaradamente irreal. Por ejemplo, podría existir una tendencia sistemática a que las primeras observaciones sean de mayor magnitud que las últimas. Estas tendencias y otras características sistemáticas se podrían evitar aumentando la complejidad del modelo. Cuando se hayan efectuado estas modificaciones todavía persistirá cierto grado de variación aparentemente aleatoria; su distribución de probabilidad subyacente constituye un legítimo objeto de estudio.

En los apartados 6.4 y 6.5 se considerarán algunos experimentos comparativos en los que se asignan al azar unidades experimentales a varios grupos que recibirán diferentes tratamientos. Será muy importante comparar dos o más conjuntos de observaciones realizadas en unidades que reciben diferentes tratamientos y valorar el grado en que estos contrastes son afectados por la variación aleatoria. En la mayoría de los experimentos, el conjunto global de individuos que constituyen las unidades no se seleccionan estrictamente por muestreo aleatorio; el ensayo clínico mencionado con anterioridad constituye un buen ejemplo. Sin embargo, a causa de la asignación aleatoria, las diferencias entre los grupos se comportan como diferencias entre muestras aleatorias: procedentes de la misma población, si todos los tratamientos son equivalentes, y de diferentes poblaciones, si los tratamientos difieren en sus efectos. Por lo tanto, la teoría muestral de las diferencias es aplicable directamente.

4.2. Tests de significación e intervalos de confianza

Tests de significación

A menudo los datos se recogen con el fin de responder preguntas específicas, como: *a)* ¿tienen los trabajadores de una industria determinada la función pulmonar reducida en comparación con un grupo control? o *b)* ¿es un nuevo tratamiento beneficioso para los que padecen una enfermedad determinada en comparación con el tratamiento existente? Estas preguntas se pueden responder planteando una hipótesis y, a continuación, usando los datos para examinar esta hipótesis. En general hay que guardar cierta precaución antes de afirmar que se ha establecido algún efecto, como una reducción de la función pulmonar o la mejoría de una tasa de curación. El modo de proceder consiste en plantear una hipótesis «nula», de que no se produce efecto alguno. Así, en *b*, la hipótesis nula consiste en que el nuevo tratamiento y el existente son igualmente beneficiosos. Luego, se puede afirmar un efecto sólo si los datos son incoherentes con esta hipótesis nula, o sea que es improbable que ocurra si ésta fuese verdadera.

El modo de proceder formal es uno de los métodos más importantes de inferencia estadística y se denomina *test de significación*. Supóngase que seleccionamos al azar una serie de observaciones a partir de una población y que estamos interesados en una hipótesis nula determinada que especifica valores para uno o más parámetros de la población. La pregunta que se plantea es la siguiente: ¿las observaciones de la muestra aclaran la verosimilitud de la hipótesis? Si la hipótesis nula fuese cierta, algunas muestras serían, en cierto sentido, razonablemente similares a las esperadas por la teoría del muestreo. Otras muestras tendrán ciertas características inesperadas si la hipótesis nula fuese cierta. Si se observara una muestra de este tipo, tendríamos razones para sospechar que la hipótesis nula es falsa.

El test de significación es una regla para decidir si una muestra en particular pertenece a la clase «probable» o «improbable» o, aún más útil, para valorar la magnitud del conflicto entre lo que encontramos en la muestra y lo que predecimos con la hipótesis nula. Evidentemente, la línea divisoria entre las clases «probable» e «improbable» es arbitraria, pero por lo general se define en términos de una probabilidad, P , que recibe el nombre de *nivel de significación*. Así, un resultado se declararía *significativo en el nivel del 5%*, si la muestra estaba en la clase que contenía aquellas muestras más alejadas de la hipótesis nula y aquella clase no contenía más del 5% de todas las muestras posibles. Una manera alternativa y frecuente de expresar este hecho consiste en afirmar que el resultado era estadísticamente significativo ($P < 0,05$).

El nivel del 5% y, en menor grado, el nivel del 1% han sido ampliamente aceptados como criterios prácticos para valorar la significación de las desviaciones con respecto a la hipótesis nula. En cierto modo esto es desafortunado, porque no debería haber una distinción rígida entre una desviación que apenas sobrepasa el nivel de significación del 5% y otra que casi consigue alcanzarlo. Tal vez es preferible evitar esta dicotomía («significativo» o «no significativo»), tratando de establecer *en qué medida* la desviación es significativa. Un modo práctico de hacer esta determinación consiste en determinar la probabilidad P de obtener, si la hipótesis nula fuese verdadera, una muestra tan extrema como la muestra obtenida o más extrema que ella. Una razón del origen del empleo de la dicotomía, significativo o no significativo, es que había que buscar los niveles de significación en tablas, como las A2, A3 y A4 del apéndice, y esto restringía la evaluación de la P a unas cotas. En la actualidad, los tests de significación se llevan a cabo con frecuencia en un ordenador y muchos programas de cálculo estadístico dan el valor calculado de la P . Es preferible citar este valor por lo que seguiremos esta práctica. Sin embargo, cuando los análisis se efectúan manualmente o el valor calculado para la P no se obtiene con el resultado del programa aplicado, podría señalarse una gama de valores. Esto debería hacerse de la manera más precisa posible, en particular cuando el resultado es «casi significativo», por consiguiente, es preferible « $0,05 < P < 0,1$ » que «no significativo ($P > 0,05$)».

El test que debe emplearse en una situación determinada dependerá de las alternativas planteadas frente a la hipótesis nula. Si ésta especifica la media y la desviación tipo de una distribución normal como μ_0 y σ_0 , un test de significación diseñado específicamente para detectar desviaciones de la media de la población con respecto a μ_0 podría basarse razonablemente en el examen de la media de la muestra, $\bar{x}$. Una prueba diseñada para detectar las desviaciones de la desviación tipo con respecto a σ_0 debería basarse en alguna medida de la variación de la muestra, como la desviación tipo de la muestra, s .

Aunque una desviación «significativa» proporciona cierto grado de indicio en contra de una hipótesis nula, es importante darse cuenta de que una desviación «no significativa» no proporciona indicios positivos a favor de dicha hipótesis. La situación consiste más bien en que no hemos logrado encontrar indicios firmes en contra de la hipótesis nula.

También es importante comprender la distinción entre significación estadística y significación clínica o importancia práctica. El análisis de un gran conjunto de datos podría dar indicios de una desviación muy significativa con respecto a la hipótesis nula, aunque es posible que la diferencia no tenga importancia práctica (porque el efecto es clínicamente inaplicable o porque es demasiado pequeño). Por el contrario, es posible que otra investigación no consiga mostrar un efecto significativo, quizá porque el estudio es demasiado pequeño o a causa de una variación aleatoria excesiva y, con todo, es posible que exista un efecto suficientemente grande para que revista importancia; la investigación podría haber sido demasiado insensible para revelarlo.

El test de significación generalmente es *bilateral*, en el sentido de que desviaciones suficientemente grandes con respecto a la hipótesis nula, en ambas direcciones, se considerarán significativas. Si, por alguna razón, estamos interesados en posibles desviaciones sólo en una dirección, por ejemplo, que un tratamiento nuevo sea superior a un tratamiento antiguo, sería razonable contar como significativas sólo aquellas muestras que difieren suficientemente de la hipótesis nula en dicha dirección. Este test se denomina *unilateral*. Para un test unilateral a un nivel del 5%, por ejemplo, sensible a desviaciones positivas con respecto a la hipótesis nula, una muestra sería significativa si perteneciese a la clase de muestras que se desvían más con respecto a la hipótesis nula en la dirección positiva y si esta clase contiene, como mucho, el 5% de las muestras posibles.

Un test unilateral al nivel P es, por consiguiente, el mismo que un test bilateral a nivel $2P$, excepto en que las desviaciones con respecto a la hipótesis nula sólo se cuentan en una dirección. En cierto sentido, la distinción es semántica. Por otra parte, podemos tener la tentación de usar tests unilaterales y no bilaterales porque el nivel de probabilidad es inferior y, en consecuencia, la significación *aparente* es mayor. La decisión de emplear un test unilateral *nunca* debería tomarse después de observar los datos y la dirección de la desviación. Antes de examinar los datos sólo debería decidirse la aplicación de un test unilateral si, por lo general las desviaciones en una dirección determinada son atribuidas siempre al azar y, por lo tanto, consideradas no significativas a pesar de su gran magnitud. Esta situación raras veces se plantea en la práctica, y es posible asegurar que los tests de significación casi siempre deben ser bilaterales. Lo haremos siempre así, excepto si se expresa lo contrario.

No es verosímil que ninguna hipótesis nula sea exactamente verdadera. ¿Por qué, entonces, debemos molestarnos en contrastarla, en lugar de rechazarla inmediatamente como poco verosímil? Hay diferentes situaciones en las que el uso de los tests de significación puede estar justificado:

1. *Para contrastar una hipótesis simplificadora.* Algunas veces la hipótesis nula ofrece un modelo simple para una situación que probablemente sea más compleja de lo que admite el modelo. Por ejemplo, al estudiar la relación entre dos variables, como se hace en el capítulo 5, para simplificar las cosas será útil suponer que la tendencia es lineal (es decir, sigue una línea recta) si no hay pruebas que indiquen lo contrario, aunque el sentido común nos diga que es muy improbable que la tendencia verdadera sea exactamente lineal.

2. *Para contrastar una hipótesis nula que puede ser aproximadamente cierta.* En un ensayo clínico en el que se pone a prueba un fármaco nuevo en comparación con un placebo, es posible que aquél sea casi inerte o que tenga un efecto acusado. La hipótesis nula de que el fármaco es completamente inerte (y, por consiguiente, tiene exactamente el mismo efecto que el placebo) es una aproximación cercana al estado posible de las cosas.
3. *Para examinar la dirección de una diferencia con respecto a un valor crítico.* Supóngase que estamos interesados en saber si cierto parámetro, θ , tiene un valor mayor o menor que un valor θ_0 . Podríamos contrastar la hipótesis nula de que θ es precisamente θ_0 . Puede ser evidente que esto no será cierto. Sin embargo, así tenemos la oportunidad de averiguar la dirección en que reside la diferencia. Si la hipótesis nula es rechazada significativamente, tendremos muchos indicios de que $\theta > \theta_0$ o de que $\theta < \theta_0$.

Intervalos de confianza

Cuestiones como las examinadas en el contexto del contraste de hipótesis pueden considerarse desde un punto de vista diferente, lo que da como resultado otro concepto muy importante de inferencia estadística. En lugar de preguntar: «¿es un nuevo tratamiento beneficioso para los que padecen una enfermedad determinada en comparación con el tratamiento existente?», podríamos preguntar: «¿cuál es la magnitud del beneficio de un tratamiento nuevo en comparación con el tratamiento existente para aquellos que padecen una enfermedad determinada?», podría responderse a esta pregunta mencionando una sola cifra, que se denomina *estimación de un punto*. Sin embargo, nos gustaría también tener alguna otra indicación del grado de exactitud de esta estimación. Esto nos lo proporciona el *intervalo de confianza*, que tiene una probabilidad especificada (el *coeficiente de confianza*) de contener el valor de la población. La probabilidad usada con mayor frecuencia es 95%. El intervalo recibe el nombre, por lo tanto, de intervalo de confianza del 95% y los extremos de estos intervalos son los *límites de confianza* del 95%; también se pueden emplear, en menor grado, límites de confianza del 90 o 99%. El intervalo de confianza proporciona una expresión formal de la incertidumbre que debe asociarse a la estimación de un punto a causa, exclusivamente, de los errores de muestreo.

Dos interpretaciones ligeramente distintas de un intervalo de confianza pueden ser de utilidad:

1. Los valores del parámetro incluido en el intervalo de confianza del 95% son precisamente aquellos que no serían rechazados significativamente por un test bilateral al nivel del 5%, porque existe sólo una probabilidad del 5% de que un intervalo no contenga el valor de la población. Por otra parte, todos los valores que se encuentren fuera del intervalo serían rechazados por un test bilateral al nivel del 5%.
2. Hemos señalado que el intervalo de confianza contiene el valor de la población con una probabilidad de 0,95. Esto no es lo mismo que decir que el valor de la población tiene una probabilidad de 0,95 de encontrarse dentro de los límites, porque dicho valor no es aleatorio. En un caso determinado, el valor de la población se encuentra comprendido o no en el intervalo. Lo que estamos haciendo es imaginar una serie repetida de muestras, extraídas al azar de una población con un valor del parámetro fijo. A la larga, el 95% de los intervalos de confianza comprenderán el valor del parámetro y entonces la fórmula de confian-

za será cierta. El 5% de las veces el intervalo no comprenderá el valor del parámetro y entonces la fórmula de confianza no será cierta. Si, en un problema determinado, calculamos un intervalo de confianza, es posible que no tengamos suerte y que éste sea uno del 5% de los casos en los que el intervalo no contiene el parámetro de la población. Sin embargo, estamos aplicando un procedimiento que funcionará el 95% de las veces. Para un planteamiento algo distinto, véase el apartado 4.12.

De *I* se deduce que un intervalo de confianza puede considerarse equivalente a efectuar un test de significación para todos los valores de un parámetro y no sólo el valor único correspondiente a la hipótesis nula. Así, el intervalo de confianza contiene más información que el correspondiente test de significación y, por esta razón, a veces se sostiene que los tests de significación podrían suministrarse con todos los resultados expresados en términos de una estimación además del intervalo de confianza de dicha estimación. Por otra parte, si se cita el valor del nivel de significación y no sólo si el resultado es o no significativo al nivel del 5%, se da información adicional a la proporcionada por el intervalo de confianza del 95%. Aproximadamente en los últimos 10 años ha habido una tendencia creciente a hacer más hincapié en expresar los resultados usando los intervalos de confianza y menos en los tests de significación (Rothman, 1978; Gardner y Altman, 1989). En general, recomendamos que, en lo posible, los resultados se expresen usando un intervalo de confianza y que también se cite el nivel de significación.

El empleo de intervalos de confianza facilita la distinción entre significación estadística y significación clínica o importancia práctica. En la figura 4.1, adaptada de Berry (1986,




Fig. 4.1. Intervalos de confianza que muestran las cinco interpretaciones posibles en términos de significación estadística e importancia práctica.

1988), se ilustran cinco interpretaciones posibles de un test de significación en términos del intervalo de confianza de una diferencia entre dos grupos: *a)* la diferencia es significativa y, con seguridad, suficientemente grande para tener importancia práctica; *b)* la diferencia es significativa, pero no está claro si es suficientemente grande para ser importante; *c)* la diferencia es significativa, pero demasiado pequeña para ser importante; *d)* la diferencia no es significativa, pero puede ser suficientemente grande para ser importante, y *e)* la diferencia no es significativa ni tampoco lo bastante grande para ser importante. Una de las tareas al planificar las investigaciones consiste en asegurarse de que una diferencia lo bastante grande para ser importante tenga la probabilidad, si existe realmente, de ser estadísticamente significativa y, por lo tanto, de poder ser detectada (v. apartado 6.6) y, posiblemente, en asegurarse de que esté claro o no si la diferencia es lo bastante grande para ser importante.

En los apartados siguientes se aplicarán estos dos métodos de inferencia estadística a varias situaciones diferentes y se explicará la metodología en detalle.

4.3. Inferencias a partir de las medias

Veamos en primer lugar la situación en la que la desviación tipo de la población, σ , es conocida. Más adelante expondremos qué debe hacerse cuando σ es desconocida.

σ conocida

Examinemos con más detalle el problema de contrastar la hipótesis nula (que representaremos por H_0) según la cual los parámetros de una distribución normal son $\mu = \mu_0$ y $\sigma = \sigma_0$, usando la media $\bar{x}$, de una muestra de tamaño n extraída al azar.

Si H_0 se cumple, sabemos, según el apartado 3.2, que la probabilidad de que $\bar{x}$ se encuentre fuera del intervalo definido por $\mu_0 - 1,96 \sigma_0/\sqrt{n}$ y $\mu_0 + 1,96 \sigma_0/\sqrt{n}$ es igual a sólo 0,05. Para un valor de $\bar{x}$ que se encuentre fuera de estos límites, la desviación normal estandarizada:

$$z = \frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}} \quad (4.1)$$

sería menor que $-1,96$ o mayor que $1,96$. Un valor de $\bar{x}$ como éste podría considerarse suficientemente alejado de μ_0 para plantear dudas sobre la hipótesis nula. La H_0 podría ser cierta pero, si lo fuera, habría aparecido una desviación extraordinariamente grande (perteneciente a una clase que sólo se presentaría al azar una de cada 20 veces). Por otra parte, este valor $\bar{x}$ sería más probable si μ tuviera un valor distinto de μ_0 , más próximo a la $\bar{x}$ observada. Los valores críticos específicos tomados aquí para z , $\pm 1,96$, corresponden al nivel de probabilidad arbitrario de 0,05. Si z es numéricamente mayor que $1,96$, se dice que la diferencia entre μ_0 y $\bar{x}$ es *significativa al nivel del 5%*. Del mismo modo, una diferencia aun más extrema que da un valor de z numéricamente mayor que $2,58$, en valor absoluto, es *significativo al nivel del 1%*. En lugar de usar niveles arbitrarios, como el 5 o el 1%, podríamos investigar dónde se encuentra el valor observado de $\bar{x}$ en el interior de las colas de la distribución muestral esperada. Un modo práctico de medir esta tendencia consiste en calcular la probabilidad, P , de obtener, si la hipótesis nula fuese cierta, un valor de $\bar{x}$ mayor o igual al valor observado. Si $\bar{x}$ es significativo precisamente al nivel del 5%, $z = \pm 1,96$ y $P = 0,05$ (proba-

bilidad dada para las dos colas de la distribución). Si $\bar{x}$ se encuentra por encima del nivel de significación del 5%, $z > 1,96$ o $< -1,96$ y $P < 0,05$. Si $\bar{x}$ no es significativa al nivel del 5%, $P > 0,05$ (fig. 4.2). Si, por ejemplo, el valor observado de z fuese 2,20, podría expresarse el valor exacto de P como 0,028 (a partir de la tabla A1) o, comparándolo con los puntos porcentuales de la distribución normal, podría escribirse $0,02 < P < 0,05$.

Ejemplo 4.1

Se ha observado que numerosos enfermos con cáncer en una localización determinada y en un estadio clínico determinado tienen una supervivencia media desde el diagnóstico de 38,3 meses, con una desviación tipo de 43,3 meses. Cien pacientes son tratados con una nueva técnica y su supervivencia media es de 46,9 meses. ¿Es este aparente incremento de la supervivencia media explicable por una fluctuación debida al azar?

Probamos la hipótesis nula de que los 100 resultados constituyen efectivamente una muestra extraída al azar de una población con una media $\mu_0 = 38,3$ y una desviación tipo $\sigma_0 = 43,3$. Nótese que esta distribución puede ser extremadamente asimétrica, puesto que con sólo una desviación igual a una desviación tipo por debajo de la media se obtiene un valor negativo ($38,3 - 43,3 = -5,0$) y ningún tiempo de supervivencia puede ser negativo. Sin embargo, 100 constituye un tamaño muestral razonablemente grande y podría resultar seguro emplear la teoría de la normalidad para la distribución de la media muestral. Siendo $n = 100$ y $\bar{x} = 46,9$, tenemos una desviación normal estandarizada igual a:

$$\frac{46,9 - 38,3}{(43,3/\sqrt{100})} = \frac{8,6}{4,33} = 1,99$$

Este valor sobrepasa apenas el valor del 5%, o sea 1,96 y, por tanto, la diferencia es significativa precisamente al nivel del 5% ($P < 0,05$). Remitiéndose a la tabla A1 del apéndice, el valor real de P es $2 \times 0,0233 = 0,047$.

Esta diferencia significativa sugiere que es poco probable que el incremento del tiempo medio de supervivencia se deba al azar. No sería prudente suponer que el nuevo tratamiento ha mejorado la




Fig. 4.2. Tests de significación al nivel del 5% basados en una desviación normal estandarizada. La desviación observada está señalada por una flecha.

supervivencia, porque algunas características de los pacientes podrían haber cambiado desde el registro de los primeros datos; por ejemplo, la enfermedad podía haber sido diagnosticada previamente. Todo lo que podemos decir es que es muy probable que la diferencia no sea un fenómeno debido al azar.

Supongamos que deseamos extraer conclusiones acerca de la media de una población, μ , sin concentrarnos en un único valor posible μ_0 . En términos aproximados, es más probable que μ esté cerca de $\bar{x}$ que muy lejos. ¿Podría precisarse más esta idea, afirmando algo acerca de la probabilidad de que μ se encuentre comprendida en un intervalo determinado alrededor de $\bar{x}$? Éste es el método del intervalo de confianza. Supongamos que la distribución de x es normal con una desviación tipo conocida, σ . Según la teoría general del muestreo (v. apartado 3.2), la probabilidad de que $\bar{x} - \mu$ se encuentre entre $-1,96\sigma/\sqrt{n}$ y $+1,96\sigma/\sqrt{n}$ es 0,95, es decir que:

$$-1,96\sigma/\sqrt{n} < \bar{x} - \mu < 1,96\sigma/\sqrt{n} \quad (4.2)$$

Reordenando la parte izquierda de la fórmula (4.2), o sea $-1,96\sigma/\sqrt{n} < \bar{x} - \mu$, se obtiene $\mu < \bar{x} + 1,96\sigma/\sqrt{n}$; del mismo modo, en la parte derecha se obtiene $\bar{x} - 1,96\sigma/\sqrt{n} < \mu$. Por consiguiente, (4.2) es equivalente a afirmar que:

$$\bar{x} - 1,96\sigma/\sqrt{n} < \mu < \bar{x} + 1,96\sigma/\sqrt{n} \quad (4.3)$$

La fórmula (4.3) que, como hemos visto, es cierta con una probabilidad de 0,95, afirma que μ se encuentra en un intervalo determinado denominado *intervalo de confianza* del 95%. Los extremos de este intervalo, que se denominan *límites de confianza* del 95%, son simétricos alrededor de $\bar{x}$ y (dado que se conocen σ y n) se pueden calcular a partir de los datos de la muestra. El intervalo de confianza proporciona una expresión formal de la incertidumbre que debe asociarse a $\bar{x}$, a causa, exclusivamente, de los errores del muestreo.

En la figura 4.3 se ilustra la interpretación 2 de un intervalo de confianza. Una serie imaginaria de muestras repetidas y elegidas al azar de una población con un valor fijo de μ dará valores diferentes de $\bar{x}$ y, por consiguiente, distintos intervalos de confianza. A la larga, sin embargo, el 95% de estos intervalos incluirán μ ; en cambio, en el 5%, $\bar{x}$ estará alejado de μ a más de 1,96 errores tipo (como en la cuarta muestra de la figura 4.3) y el intervalo no incluirá μ .

Ejemplo 4.1 (continuación)

En este ejemplo, los límites de confianza del 95% son:

$$\begin{aligned} 46,9 \pm (1,96) (4,33) \\ = 38,4 \text{ y } 55,4 \end{aligned}$$

El hecho de que este intervalo excluya como valor posible 38,3, sometido a test previamente, se corresponde con el hecho de que este valor fue rechazado precisamente con un test de significación al nivel del 5%.




Fig. 4.3. Límites de confianza (95%) de la media de una distribución normal con desviación tipo conocida en una serie de muestras de tamaño n extraídas al azar.

La suposición de la normalidad no es crucial si n es razonablemente grande, porque la distribución de $\bar{x}$ en las muestras de la mayoría de las poblaciones es casi normal.

Para un grado de confianza superior al 95% podemos emplear otro percentil de la distribución normal. Por ejemplo, los límites del 99% son:

$$\bar{x} \pm 2,850/\sqrt{n}$$

En general, los límites de confianza $1 - 2\alpha$ son:

$$\bar{x} \pm z_{2\alpha} \sigma/\sqrt{n}$$

donde $z_{2\alpha}$ es la desviación normal estandarizada excedida (en ambas direcciones) con una probabilidad 2α .

σ desconocida: distribución de la t

Supóngase ahora que deseamos probar una hipótesis nula que especifica el valor medio de una distribución normal ($\mu = \mu_0$), pero no especifica la variancia σ^2 , y que no tenemos prueba alguna de σ^2 aparte de la contenida en nuestra muestra. No es posible seguir el procedimiento señalado anteriormente porque no podemos calcular el error tipo de la media, $\sigma/\sqrt{n}$. Parece razonable reemplazar σ por la desviación tipo estimada de la muestra, s , obteniendo una desviación estandarizada:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \quad (4.4)$$

en lugar de la desviación normal z obtenida en (4.1). Se espera que el estadístico t siga una distribución muestral similar a la de z (es decir, aproximada a una distribución normal estandarizada con media 0 y variancia 1) cuando n es grande, porque entonces s será una buena aproximación de σ . Cuando n es pequeña, s puede diferir considerablemente de σ , puramente por azar, y ello será la causa de que t tenga una variabilidad debida al azar considerablemente mayor que z .

De hecho, t sigue lo que se conoce como la *distribución de la t con $n - 1$ grados de libertad*. Las distribuciones de la t forman una familia (como las distribuciones χ^2), que se caracterizan por un índice, los «grados de libertad», que en este ejemplo es uno menos que el tamaño de la muestra. A medida que los grados de libertad aumentan, la distribución de la t tiende hacia la distribución normal tipo (fig. 4.4). La tabla A3 del apéndice muestra los percentiles de t , es decir, los valores excedidos con probabilidades específicas, de diferentes valores de grados de libertad, v . Para $v = \infty$, los valores tabulados coinciden con los de la distribución normal estandarizada. El punto del 5%, que siempre excede el valor normal 1,960 es, no obstante, aproximadamente igual a 2,0 con todos los valores de v , excepto con los bastante pequeños. La distribución de la t fue deducida por W. S. Gosset (1876-1937) y se publicó en 1908 bajo el seudónimo de «Student». Esta distribución suele denominarse *distribución de la t de Student*.

La distribución de la t sólo es estrictamente válida si la distribución de x es normal. No obstante, es razonablemente «robusta», en el sentido de que es una aproximación válida para variables bastante alejadas de la normalidad.

El cálculo del intervalo de confianza se efectúa como antes, pero usando la distribución t en lugar de la distribución normal. Si:

$$t = \frac{\bar{x} - \mu}{s/\sqrt{n}}$$

la probabilidad de que la t se encuentre entre $+t_{n,0,05}$, el punto del 5% de la distribución de la t con $v = n - 1$ grados de libertad, es 0,95. Un pequeño reordenamiento da una fórmula equivalente: la probabilidad de que:




Fig. 4.4. Función de densidad de la probabilidad de las distribuciones de la t con 2, 5, 20 e infinitos grados de libertad. La última es la distribución normal estandarizada.

$$\bar{x} - t_{v, 0.05} (s/\sqrt{n}) < \mu < \bar{x} + t_{v, 0.05} (s/\sqrt{n}) \quad (4.5)$$

es igual a 0,95. Éste es el intervalo de confianza del 95%. Difiere de (4.3) en la sustitución del punto porcentual de la distribución normal por el de la distribución de la t , que como hemos visto es una cifra algo elevada. La necesidad de estimar el error tipo a partir de la muestra ha originado un intervalo basado en un múltiplo un poco mayor del error tipo.

Como en los tests de significación, la normalidad de la distribución de x es necesaria para la validez estricta de (4.5), pero las desviaciones moderadas con respecto a la normalidad tendrán poco efecto sobre la validez.

Ejemplo 4.2

Los siguientes datos son los pesos uterinos (en mg) de 20 ratas extraídas al azar de un grupo grande. ¿Es probable que el peso medio de todo el grupo sea 24 mg, un valor observado en estudios anteriores?

9	18	21	26
14	18	22	27
15	19	22	29
15	19	24	30
16	20	24	32

Aquí, $n = 20$, $\sum x = 420$ y $\bar{x} = 420/20 = 21,0$. Para t , necesitamos conocer la estimación del error tipo de la media, $s/\sqrt{n}$, que resulta práctico calcular como $\sqrt{s^2/n}$, para evitar el cálculo de dos raíces cuadradas separadas. Según la fórmula abreviada habitual:

$$\begin{aligned} \sum (x - \bar{x})^2 &= \sum x^2 - (\sum x)^2/n \\ &= 9484 - 8820 \\ &= 664, \\ s^2 &= 664/19 = 34,947 \\ s^2/n &= 34,947/20 = 1,7474 \\ \sqrt{(s^2/n)} &= 1,3219 \end{aligned}$$

y

$$t = \frac{21,0 - 24,0}{1,3219} = -2,27$$

Los grados de libertad son $v = 20 - 1 = 19$ y la tabla A3 muestra que los puntos porcentuales aplicables son:

P	0,05	0,02
t	2,093	2,539

En consecuencia, el valor observado es significativo a un nivel comprendido entre el 2 y el 5% ($0,02 < P < 0,05$). Si estos cálculos se realizaron en un ordenador que ha dado el nivel de significación

preciso, deberíamos haber obtenido $P = 0,035$. Se sugiere firmemente que el peso medio del grupo es diferente de 24 mg (y, de hecho, *inferior* a este valor).

Los límites de confianza del 95% de μ son:

$$21,00 \pm (2,093) (1,3219) \\ = 18,23 \text{ y } 23,77$$

La exclusión del valor 24 corresponde al resultado significativo de examinar este valor al nivel del 5%. Los límites del 99% son:

$$21,00 \pm (2,861) (1,3219) \\ = 17,22 \text{ y } 24,78$$

donde ahora está incluido 24, ya que este valor de μ no fue rechazado significativamente al nivel del 1%.

Los límites calculados aquí se denominan en ocasiones *límites fiduciarios*, término usado por R. A. Fisher en su aproximación al problema de la estimación de intervalos. La aproximación de Fisher estaba más relacionada con la interpretación 1 (v. pág. 98) que con la 2. Esta última fue señalada especialmente por J. Neyman (1894-1981), responsable del concepto de los límites de confianza. En la mayoría de los casos, los límites fiduciarios y de confianza coinciden numéricamente (como en este caso) y la interpretación es una cuestión de elección. En ocasiones aparecen pequeñas diferencias, circunstancia que ha motivado cierta polémica.

4.4. Comparación de dos medias

El error muestral de la diferencia entre dos medias se trató en el apartado 3.5. En él se señaló la importancia de la dependencia o independencia de dos muestras. Del mismo modo, distinguiremos dos situaciones: los casos apareados, en los que las dos muestras tienen el mismo tamaño y los individuos de una muestra están apareados con miembros específicos de la otra muestra, y los casos no apareados, en los que las muestras son independientes.

Casos apareados

Supóngase que tenemos dos muestras de tamaño n :

$$x_{11}, x_{12}, \dots, x_{1i}, \dots, x_{1n}$$

extraída al azar de una distribución de media μ_1 y variancia σ_1^2 , y

$$x_{21}, x_{22}, \dots, x_{2i}, \dots, x_{2n}$$

extraída al azar de una distribución de media μ_2 y variancia σ_2^2 . Si existe algún motivo por el que x_{1i} esté apareado con x_{2i} , será cierto que los valores altos de x_{1i} tenderán a estar asociados con los valores altos de x_{2i} , y los valores inferiores de una muestra con los inferiores

Tabla 4.1. Puntuaciones de ansiedad registradas en 10 pacientes que recibieron un nuevo fármaco y un placebo en un orden aleatorio.

Paciente	Escala de ansiedad		Diferencia d_i (fármaco – placebo)
	Fármaco	Placebo	
1	19	22	-3
2	11	18	-7
3	14	17	-3
4	17	19	-2
5	23	22	1
6	11	12	-1
7	15	14	1
8	19	11	8
9	11	19	-8
10	8	7	1
			-13

de la otra. Por ejemplo, x_{1i} y x_{2i} pueden representar lecturas de la presión arterial en el individuo i -ésimo en un grupo n , en cada una de dos ocasiones. Algunos individuos tenderán a dar valores altos en ambas ocasiones, y algunos, valores bajos. En estas situaciones,

$$E(x_{1i} - x_{2i}) = \mu_1 - \mu_2$$

pero la variancia de $(x_{1i} - x_{2i})$ es –aplicado (3.13) y (3.14)– menor que el valor de $\sigma_1^2 + \sigma_2^2$ que sería apropiado para observaciones independientes. En este caso $\bar{x}_1 - \bar{x}_2$, la diferencia entre las dos medias, es la media de n diferencias específicas $x_{1i} - x_{2i}$, y estas diferencias son independientes entre sí. El error muestral de $\bar{x}_1 - \bar{x}_2$ puede calcularse, por consiguiente, analizando las n diferencias individuales. Esto asegura automáticamente que cualquiera que sea la naturaleza de la relación entre las lecturas apareadas, el error muestral calculado es adecuado. Si las diferencias se distribuyen normalmente se pueden aplicar los métodos del apartado 4.3.

Ejemplo 4.3

En un pequeño ensayo clínico para valorar un nuevo tranquilizante en pacientes psiconeuróticos se administró a cada paciente un tratamiento con este fármaco durante una semana y un tratamiento con placebo durante otra semana. El orden en que se administraron ambos tratamientos se determinó al azar. Al final de cada semana, cada paciente llenó un cuestionario, en base al cual se asignó al paciente una «puntuación de ansiedad» (que comprendía valores entre 0 y 30), cuyos valores elevados correspondían a estados de ansiedad. Los resultados se muestran en la tabla 4.1.

La última columna de la tabla 4.1 muestra la diferencia, d_i , entre la puntuación de ansiedad del individuo i -ésimo para el fármaco y para el placebo. Un test de la t de los diez valores de d_i da:

$$\begin{aligned}\sum d_i &= -13 \\ \sum d_i^2 &= 203 \\ \sum (d_i - \bar{d})^2 &= 186,1\end{aligned}$$

Por consiguiente:

$$\begin{aligned}\bar{d} &= -1,30 \\ s^2 &= 186,1/9 = 20,68 \\ \sqrt{(s^2/n)} &= \sqrt{(20,68/10)} = \sqrt{2,068} = 1,438\end{aligned}$$

y, para probar la hipótesis nula $E(d_i) = 0$

$$t = \frac{-1,30}{1,438} = -0,90 \text{ con 9 gl}$$

La diferencia es claramente no significativa ($P = 0,39$).

Los límites de confianza del 95% de la diferencia media son:

$$\begin{aligned}-1,30 \pm (2,262)(1,438) \\ = -4,55 \text{ y } 1,95\end{aligned}$$

Para concluir, este ensayo clínico no aportó pruebas convincentes de que el nuevo tranquilizante redujera la ansiedad en comparación con el placebo ($P = 0,39$). El intervalo de confianza del 95% para la reducción de la ansiedad fue entre 4,6 puntos en una escala de 30 puntos a favor del tranquilizante y 2,0 unidades a favor del placebo.

En la tabla 4.1, algunos individuos, como los números 6 y 10, tienden a dar puntuaciones menores, mientras que otros, como los números 1 y 5, dan puntuaciones mayores con ambos tratamientos. Estas diferencias sistemáticas entre los individuos no son relevantes al comparar tratamientos y, por consiguiente, es apropiado que el método de la diferencia anule su efecto.

Casos no apareados

Supongamos que se extraen al azar $x_{11}, x_{12}, \dots, x_{1n_1}$ de una distribución de media μ_1 y variancia σ_1^2 , y $x_{21}, x_{22}, \dots, x_{2n_2}$, de una distribución de media μ_2 y variancia σ_2^2 . Supóngase que $\bar{x}_1$ y $\bar{x}_2$ son las medias de las muestras. Si las dos muestras son independientes, aplicando (3.10), tenemos:

$$\left. \begin{aligned}E(\bar{x}_1 - \bar{x}_2) &= \mu_1 - \mu_2 \\ \text{Var}(\bar{x}_1 - \bar{x}_2) &= \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\end{aligned} \right\} \quad (4.6)$$

Si las distribuciones de las x son normales y σ_1^2 , y σ_2^2 son conocidas, (4.6) puede utilizarse inmediatamente para hacer deducciones sobre $\mu_1 - \mu_2$. Para contrastar la hipótesis nula $\mu_1 = \mu_2$, la desviación normal estandarizada que se utiliza es:

$$z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\left(\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right)}}$$

Para los límites de confianza de $\mu_1 - \mu_2$ se añade el múltiplo apropiado del error estándar (o sea, del denominador de z) a cada lado de $\bar{x}_1 - \bar{x}_2$.

La normalidad de las x no es una restricción importante si los tamaños de la muestra no son demasiado pequeños, porque $\bar{x}_1 - \bar{x}_2$, al igual que $\bar{x}_1$, y $\bar{x}_2$ por separado asegura casi siempre una distribución normal. La falta de conocimientos sobre σ_1^2 y σ_2^2 supone un problema más grave. Estas variancias deben estimarse de algún modo. Distinguiremos dos situaciones; en la primera asumimos que σ_1^2 y σ_2^2 son iguales y utilizamos un estimador común para ambos parámetros, y en la segunda no haremos ninguna suposición.

Variancias iguales: test de la t para dos muestras

Existen muchas condiciones en las que es razonable asumir que $\sigma_1^2 = \sigma_2^2$.

1. Al contrastar una hipótesis nula según la cual dos muestras proceden de distribuciones con igual media y variancia. Por ejemplo, si las dos muestras son observaciones realizadas en pacientes tratados con un fármaco posiblemente activo y en otros pacientes tratados con un placebo sin acción farmacológica, la hipótesis nula podría especificar que el fármaco sea totalmente inerte. En este caso, la igualdad de variancias forma parte de la hipótesis nula del mismo modo que la igualdad de medias, aunque queremos un test basado en $\bar{x}_1 - \bar{x}_2$ para poder detectar fármacos que afecten especialmente el valor medio de x .
2. A partir de la experiencia general se puede saber que el tipo de cambios que distinguen a la muestra 1 de la muestra 2 puede afectar la media, pero no es probable que afecten apreciablemente la variancia. Los estimadores muestrales de la variancia, s_1^2 y s_2^2 , pueden diferir considerablemente, pero en tales casos deberíamos considerar que la mayor parte de la diferencia se debe a las fluctuaciones muestrales de s_1^2 y s_2^2 más que a una diferencia correspondiente en σ_1^2 y σ_2^2 .

Si σ_1^2 y σ_2^2 son iguales, su valor común se puede expresar como σ^2 sin subíndice ¿Cómo debería estimarse σ^2 ? A partir de la primera muestra, tenemos el estimador:

$$s_1^2 = \frac{\sum_{(1)} (x - \bar{x}_1)^2}{n_1 - 1}$$

en la que el subíndice (1) de $\sum$ expresa una suma en la primera muestra. En la segunda muestra, σ^2 es estimada por:

$$s_2^2 = \frac{\sum_{(2)} (x - \bar{x}_2)^2}{n_2 - 1}$$

Podría obtenerse un estimador común a partir de la simple media de s_1^2 y s_2^2 , pero es mejor trabajar con una media ponderada, otorgando más peso al estimador de la muestra mayor. Se puede demostrar que es apropiado tomar:

$$s^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{(n_1 - 1) + (n_2 - 1)}$$

$$= \frac{\sum_{(1)} (x - \bar{x}_1)^2 + \sum_{(2)} (x - \bar{x}_2)^2}{n_1 + n_2 - 2}$$

Este paso nos permite utilizar la distribución t con $n_1 + n_2 - 2$ grados de libertad como una solución exacta del problema si las x siguen una distribución exactamente normal, y como una solución aproximada si la distribución de las x no se separa demasiado de la normalidad.

En este caso, el error tipo de $\bar{x}_1 - \bar{x}_2$ se estima con la fórmula:

$$ET(\bar{x}_1 - \bar{x}_2) = \sqrt{\left[s^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \right]}$$

Para contrastar la hipótesis nula $\mu_1 = \mu_2$, hallaremos:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{ET(\bar{x}_1 - \bar{x}_2)}$$

que sigue la distribución t con $n_1 + n_2 - 2$ gl.

Los límites de la confianza se calculan mediante:

$$\bar{x}_1 - \bar{x}_2 \pm t_{v, 0.005} ET(\bar{x}_1 - \bar{x}_2)$$

para $v = n_1 + n_2 - 2$.

Ejemplo 4.4

Dos grupos de ratas hembras fueron sometidas a dietas con alto y bajo contenido en proteínas y se determinó el aumento de peso de cada rata entre los días 28º y 84º. Los resultados se muestran en la tabla 4.2.

Los cálculos realizados son los siguientes:

$\sum_{(1)} x =$	1.440	$\sum_{(2)} x =$	707
$n_1 =$	12	$n_2 =$	7
$\bar{x}_1 =$	120,0	$\bar{x}_2 =$	101,0
$\sum_{(1)} x^2 =$	177.832	$\sum_{(2)} x^2 =$	73.959
$(\sum_{(1)} x)^2/n_1 =$	172.800,00	$(\sum_{(2)} x)^2/n_2 =$	71.407,00
$\sum_{(1)} (x - \bar{x}_1)^2 =$	5.032,00	$\sum_{(2)} (x - \bar{x}_2)^2 =$	2.552,00
$s^2 = \frac{5.032 + 2.552}{17} = 446,12$			

$$\begin{aligned}
 ET (\bar{x}_1 - \bar{x}_2) &= \sqrt{[(446,12)] \left(\frac{1}{12} + \frac{1}{7}\right)} \\
 &= \sqrt{[(446,12) (0,22619)]} \\
 &= \sqrt{100,9} \\
 &= 10,04
 \end{aligned}$$

Para probar la hipótesis nula $\mu_1 = \mu_2$,

$$t = \frac{120,0 - 101,0}{10,04} = \frac{19,0}{10,04} = 1,89 \text{ con 17 gl } (P = 0,076)$$

La diferencia no es significativa a nivel del 5% y sólo sugeriría la evidencia de un efecto a causa de la dieta.

Los límites de confianza del 95% para $\mu_1 - \mu_2$ son:

$$\begin{aligned}
 &19,0 \pm (2,110)(10,04) \\
 &= 19,0 \pm 21,2 \\
 &= -2,2 \text{ y } 40,02
 \end{aligned}$$

El intervalo de valores probables de $\mu_1 - \mu_2$ es grande. Si el experimentador no se siente satisfecho con esta amplitud de incertidumbre, la solución más fácil consiste en repetir el experimento con un mayor número de observaciones. Valores mayores de n_1 y n_2 tenderán a disminuir el error tipo de $\bar{x}_1 - \bar{x}_2$ y, por lo tanto, a aumentar la precisión de la comparación.

Se podría intentar la aplicación del método para datos no apareados a los datos apareados. Esto sería incorrecto porque las diferencias sistemáticas entre los pares no se eliminarían, sino que formarían parte de la variancia utilizada en el denominador del estadístico t . Por consiguiente, la utilización del método para datos no apareados en un diseño con datos apareados disminuiría la sensibilidad del análisis, excepto en los casos en que el apareamiento no fuera efectivo.

Tabla 4.2. Aumento de peso (g) entre los días 28° y 84° de edad en ratas que recibieron dietas con contenidos alto y bajo en proteínas.

Alto contenido	Bajo contenido
134	70
146	118
104	101
119	85
124	107
161	132
107	94
83	
113	
129	
97	
123	
Total 1440	707

Variancias desiguales

En otras situaciones, puede ser evidente que las variancias difieren considerablemente o puede ser prudente admitir la posibilidad de que difieran. En el primer caso, una posible aproximación es trabajar con una escala de medida transformada (cap. 11). Si las medias y las variancias difieren, es posible encontrar una escala transformada, como el logaritmo de la medida original, en la cual las medias difieren pero las variancias son similares. Por otra parte, si las medias originales no difieren excesivamente, será difícil encontrar una transformación que reduzca sustancialmente la disparidad que existe entre las variancias.

En estas situaciones, el principal defecto de los métodos basados en la distribución t es el uso de un estimador común de la variancia. Es mejor estimar el error tipo de la diferencia entre las dos medias como:

$$ET(\bar{x}_1 - \bar{x}_2) = \sqrt{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)}$$

Una prueba de significación de la hipótesis nula podría basarse en el estadístico:

$$d = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)}}$$

que es aproximadamente una desviación normal estandarizada si n_1 y n_2 son razonablemente grandes. Del mismo modo, los límites de confianza aproximados se calculan con la fórmula:

$$\bar{x}_1 - \bar{x}_2 \pm z_{2\alpha} ET(\bar{x}_1 - \bar{x}_2)$$

en la cual $z_{2\alpha}$ es la desviación normal estandarizada apropiada correspondiente a la probabilidad bilateral 2α .

Sin embargo, este método no resulta más exacto para valores finitos de n_1 y n_2 de lo que sería el uso de una aproximación normal a la distribución de la t en caso de igualdad de variancias. El análogo apropiado de la distribución de la t es más complejo y más discutible que la distribución de la t . Una solución, debida a B. L. Welch, consiste en utilizar una distribución para d (p. ej., tabulada en Pearson y Hartley, 1966, tabla 11). El valor crítico para cualquier probabilidad particular depende de s_1^2/s_2^2 , n_1 y n_2 . Otra solución que también depende de s_1^2/s_2^2 , n_1 y n_2 es la propuesta por W. V. Behrens, tabulada como tabla VI en Fisher y Yates (1963). La distinción entre estas dos aproximaciones se debe a diferentes enfoques de la lógica de la inferencia estadística. El test de Welch es una interpretación de los niveles de probabilidad de los tests de significación o de los intervalos de confianza como el límite de frecuencias a largo plazo en muestras repetidas procedentes de las mismas poblaciones. El test de Behrens fue propuesto por R. A. Fisher como un ejemplo del uso de la inferencia fiduciaria y se deduce también de la aproximación bayesiana (v. apartado 4.12).

Una característica del método de Welch es que el valor crítico de d puede ser inferior al valor crítico de una distribución de la t con $n_1 + n_2 - 2$ gl y esto no resulta satisfactorio. Una solución aproximada más simple, que no tiene esta desventaja, consiste en contrastar d con

la distribución de la t con grados de libertad, v , dependiente de s_1^2/s_2^2 , n_1 y n_2 conforme a la fórmula siguiente:

$$\frac{(s_1^2/n_1 + s_2^2/n_2)^2}{v} = \frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1} \quad (4.7)$$

Esta fórmula, debida originalmente a Satterthwaite (1946), se puede deducir usando (3.7) y (3.18). Aunque dicho test emplea la distribución de la t , no debe confundirse con el test de la t para dos muestras, que es de uso más frecuente y se basa en variancias iguales. Este test aproximado está incluido en algunos programas de software estadísticos.

Ejemplo 4.5

Se preparó una suspensión de partículas víricas en dos diluciones distintas. Si las técnicas experimentales fueran perfectas, el preparado B debería tener una concentración 10 veces más alta que el preparado A. Se inocularon volúmenes iguales de cada suspensión en la membrana corioalantoidea de embriones de pollo. Tras un período de incubación adecuado, se extrajeron las membranas y se contó el número de vesículas que contenían. Las cifras son las siguientes:

Preparación	A	B
Recuentos	0	10
	0	13
	1	13
	1	14
	1	19
	1	20
	2	21
	2	26
	3	29

¿Coinciden estos resultados con la hipótesis de que, en una serie larga y suficiente de recuentos, la media de la preparación B será 10 veces mayor que la de la preparación A? Si los recuentos de B se dividen por 10 y se expresan como x_2 y los de A como x_1 , la cuestión que se plantea es si las medias x_1 y x_2 difieren significativamente.

Preparado	A	B
Recuentos	x_1	x_2
	0	1,0
	0	1,3
	1	1,3
	1	1,4
	1	1,9
	1	2,0
	2	2,1
	2	2,6
	3	2,9

$$\begin{array}{ll} n_1 = 9 & n_2 = 9 \\ \bar{x}_1 = 1,2222 & \bar{x}_2 = 1,8333 \\ s_1^2 = 0,9444 & s_2^2 = 0,4100 \end{array}$$

Las estimaciones de la variancia no son quizá suficientemente diferentes en este caso para causar una gran inquietud, pero se sabe, a partir de la experiencia con este tipo de datos, que las estimaciones de la variancia del recuento de vesículas, estandarizados según la dilución, como hicimos con x_2 , tienden a disminuir a medida que aumentan los recuentos originales. El exceso de s_1^2 sobre s_2^2 no se debe probablemente al error del muestreo. Tenemos:

$$d = \frac{1,2222 - 1,8333}{\sqrt{\left(\frac{0,9444}{9} + \frac{0,4100}{9}\right)}} = \frac{-0,6111}{0,3879} = -1,58$$

Nótese que cuando $n_1 = n_2$, como en este caso, d resulta tener exactamente el mismo valor numérico que t , porque la expresión incluida en la raíz cuadrada se puede expresar como:

$$\frac{s_1^2}{n} + \frac{s_2^2}{n}$$

o como

$$\frac{1}{2}(s_1^2 + s_2^2)\left(\frac{1}{n} + \frac{1}{n}\right)$$

Usando la aproximación de Satterthwaite, se puede remitir el test estadístico de 1,58 a la distribución de la t con grados de libertad dados por la fórmula:

$$v = \frac{0,1504^2}{0,1049^2/8 + 0,0455^2/8} = 13,8$$

Usando 14 gl, el nivel de significación es 0,14. Los límites de confianza del 95% para la diferencia entre las dos medias son:

$$\begin{aligned} & -0,6111 \pm 2,145 \times 0,3879 \\ & = -1,4 \text{ y } 0,2 \end{aligned}$$

4.5. Inferencias a partir de variancias

Para variables distribuidas según la ley normal, los métodos se deducen fácilmente de los resultados del apartado 3.4.

Supongamos que s^2 es el estimador habitual de la variancia de una muestra aleatoria de tamaño n que procede de una distribución normal con variancia σ^2 ; no es necesario especificar la media de la población. Para contrastar la hipótesis nula $\sigma^2 = \sigma_0^2$ se debe calcular:

$$X^2 = \frac{(n-1)s^2}{\sigma_0^2}, \text{ que equivale a } \frac{\sum(x - \bar{x})^2}{\sigma_0^2} \quad (4.8)$$

y compararlo con la distribución $\chi^2_{(n-1)}$. Para un test bilateral con un nivel de significación α , los valores críticos de χ^2 serán aquellos que corresponden a las probabilidades tabuladas para $1 - \frac{1}{2}\alpha$ y $\frac{1}{2}\alpha$. Por ejemplo, para un nivel de significación bilateral del 5% se deben

utilizar las entradas encabezadas por 0,975 y 0,025. Podemos expresar esto como $\chi^2_{n-1, 0.975}$ y $\chi^2_{n-1, 0.025}$.

Para los límites de confianza de σ^2 podemos decir que la probabilidad es, por ejemplo, 0,95 de que:

$$\chi^2_{n-1, 0.975} < \frac{\sum (x - \bar{x})^2}{\sigma^2} < \chi^2_{n-1, 0.025}$$

y, por lo tanto, de que:

$$\frac{\sum (x - \bar{x})^2}{\chi^2_{n-1, 0.025}} < \sigma^2 < \frac{\sum (x - \bar{x})^2}{\chi^2_{n-1, 0.975}}$$

Éstos son los límites de confianza deseados.

Como se indicó en el apartado 3.4, la teoría del muestreo de s^2 es especialmente sensible cuando no se cumplen las condiciones de normalidad; los resultados de este apartado se deberían interpretar con cautela si existen desviaciones importantes de la normalidad.

4.6. Comparación de dos variancias

Supongamos que dos muestras independientes contienen observaciones de una variable x , la primera muestra con n_1 observaciones y una variancia estimada s_1^2 , y la segunda muestra con n_2 observaciones y una variancia estimada s_2^2 . Si cada muestra procede de una distribución normal, se pueden comparar las dos estimaciones considerando la *razón* de las dos estimaciones de la variancia:

$$F = s_1^2/s_2^2$$

Si la hipótesis nula es cierta, se conoce exactamente la distribución de F , en pares repetidos de muestras de tamaño n_1 y n_2 (o, lo que es lo mismo, de los grados de libertad, $v_1 = n_1 - 1$ y $v_2 = n_2 - 1$) y no de la variancia σ^2 común de la población. No es posible efectuar una tabulación de las distribuciones F tan completa como la de la tabla A2 para las distribuciones χ^2 debido a que dependen de v_1 y v_2 . Los libros clásicos de tablas (Fisher y Yates, 1963; Pearson y Hartley, 1966; Geigy Scientific Tables, 1982) ofrecen una tabla de los valores críticos de F para cada uno de varios niveles de significación. En la tabla A4 se expone una versión abreviada.

Para valores concretos de v_1 y v_2 , F puede tomar valores mayores o menores que 1 y, pueden indicarse desviaciones significativas con respecto a la hipótesis nula con valores de F muy bajos o muy altos. Todos los valores críticos tabulados de F son, sin embargo, mayores que 1 y se refieren sólo a la cola superior de la distribución de F . Esto no constituye una restricción seria debido a que la identificación de las muestras con los números 1 y 2 es arbitraria, y una simple inversión de las identificaciones convertirá un cociente menor que 1 en uno mayor que 1.

Para utilizar la tabla A4, llamamos s_1^2 a la *mayor* de las dos variancias estimadas; v_1 es el número correspondiente de grados de libertad (que no es necesariamente el mayor de v_1 y v_2).

En la prueba bilateral se debe tener cuidado de usar la mitad del nivel de significación habitual como valor para la P de la tabla A4. Por ejemplo, para una prueba bilateral se utilizan las entradas con una $P = 0,025$.

Las tablas de la distribución F se pueden emplear para calcular los límites de confianza de σ_1^2/σ_2^2 . La razón:

$$F' = \frac{s_1^2/\sigma_1^2}{s_2^2/\sigma_2^2}$$

sigue la distribución F con ν_1 y ν_2 grados de libertad (en la hipótesis nula $\sigma_1^2 = \sigma_2^2$ y $F' = F$). En este caso ya no exigimos que $s_1^2 > s_2^2$. Llamemos F_{α, ν_1, ν_2} al valor crítico tabulado con F con ν_1 y ν_2 grados de libertad y para un nivel de significación unilateral α , y F_{α, ν_2, ν_1} a la entrada correspondiente con ν_2 y ν_1 intercambios. Entonces tenemos la probabilidad α , de que:

$$F' > F_{\alpha, \nu_1, \nu_2}$$

es decir, que:

$$F > F_{\alpha, \nu_1, \nu_2}(\sigma_1^2/\sigma_2^2);$$

y también es α , la probabilidad de que:

$$1/F' > F_{\alpha, \nu_2, \nu_1}$$

o también la de que:

$$F < (1/F_{\alpha, \nu_2, \nu_1})(\sigma_1^2/\sigma_2^2)$$

Por consiguiente, la probabilidad es $1 - 2\alpha$ de que:

$$(1/F_{\alpha, \nu_2, \nu_1})(\sigma_1^2/\sigma_2^2) < F < F_{\alpha, \nu_1, \nu_2}(\sigma_1^2/\sigma_2^2)$$

o de que:

$$F/F_{\alpha, \nu_1, \nu_2} < \sigma_1^2/\sigma_2^2 < F \times F_{\alpha, \nu_2, \nu_1}.$$

Por consiguiente, para un nivel de confianza del 95%, se debe dividir el valor observado de F por el valor $F_{0,025, \nu_1, \nu_2}$ tabulado y multiplicarlo por el valor $F_{0,025, \nu_2, \nu_1}$.

Ejemplo 4.6

Se dispone de dos métodos microscópicos, A y B, para medir dimensiones muy pequeñas. Observaciones repetidas del mismo patrón proporcionan las siguientes estimaciones de la variancia:

Método	A	B
Número de observaciones	$n_1 = 10$	$n_2 = 20$
Variancia estimada (micras ²)	$s_1^2 = 1,232$	$s_2^2 = 0,304$

Para un test de significación calculamos:

$$F = s_1^2/s_2^2 = 4,05$$

Los valores tabulados para $v_1 = 9$ y $v_2 = 19$ con una $P = 0,025$ es 2,88 y con una $P = 0,005$ es 4,40. (En la tabla A4 es necesario interpolar.) La razón observada es significativa al nivel bilateral del 1%, o sea $P = 0,010$.

Para calcular los límites de confianza del 95% necesitamos los valores tabulados:

$$F_{0,025, 9, 19} = 2,88$$

y

$$F_{0,025, 19, 9} = 3,69$$

(interpolando en la tabla si es necesario). Por consiguiente, los límites de confianza de la razón entre las variancias poblacionales σ_1^2/σ_2^2 son:

$$\frac{4,05}{2,88} = 1,24$$

y

$$(4,05)(3,69) = 14,9$$

Puede advertirse la existencia de dos conexiones entre las distribuciones F y otras distribuciones ya conocidas:

1. Cuando $v_1 = 1$, la distribución F es el cuadrado de una cantidad que sigue la distribución de la t con v_2 grados de libertad. Por ejemplo, para un nivel de significación del 5%, el valor tabulado de F para $v_1 = 1$ y para $v_2 = 10$ es 4,96; el valor bilateral para t con 10 gl es 2,228; $(2,228)^2 = 4,96$.

Se deduce esta relación porque un estadístico t es fundamentalmente la razón entre una variable normal con media cero y una estimación independiente de su desviación tipo. Elevando el numerador al cuadrado, se obtiene una variable χ^2 (equivalente a una estimación de la variancia con 1 gl) y, del mismo modo, elevando al cuadrado el denominador se obtiene una estimación de la variancia con el número apropiado de grados de libertad. Se deben incluir las colas positiva y negativa de la distribución de la t porque, una vez extraída la raíz cuadrada, se obtienen valores situados en la cola superior de la distribución F .

2. Cuando $v_2 = \infty$, la distribución F es la misma que la de una variable $\chi^2_{(v_1)}$ dividida por v_1 . Así, para $v_1 = 10$, $v_2 = \infty$, la F tabulada para un nivel de significación unilateral del 0,05 es 1,83; para $\chi^2_{(10)}$ es 18,31; $18,31/10 = 1,83$.

En este caso, el motivo es similar al que mencionamos antes. Una estimación de la variancia s_2^2 con $v_2 = \infty$ grados de libertad debe ser exactamente igual a la variancia poblacional σ^2 . Por ello, F debe escribirse: $s_1^2/\sigma^2 = \chi^2_{(v_1)}/v_1$ (v. apartado 3.4).

El test de la F y los límites de confianza asociados ofrecen un tratamiento exacto para comparar dos variancias estimadas procedentes de dos muestras *normales* independientes. Lamentablemente, los métodos son bastante sensibles a la suposición de normalidad (mucho más que en los usos correspondientes de la distribución de la t para comparar dos medias). Este defecto se denomina falta de *robustez*.

Los métodos descritos en este apartado sólo son apropiados para comparar dos estimaciones *independientes* de las variancias. En ocasiones, esta condición falla porque las observaciones de las dos muestras están apareadas, como en la primera situación considerada en el apartado 4.4. El método para este caso consiste en una técnica descrita en el capítulo 5 (p. 161).

4.7. Inferencias a partir de proporciones

Consideremos ahora la situación binomial estudiada en los apartados 2.5 y 3.3. Los individuos extraídos al azar de una población tienen una probabilidad π de ser el tipo A. En una muestra aleatoria de n individuos, una proporción $p(= r/n)$ es del tipo A. ¿Qué se puede decir sobre π ?

Supóngase, en primer lugar, que deseamos contrastar una hipótesis nula que especifique que π es igual a cierto valor π_0 . En esta hipótesis, el número de individuos del tipo A, r , encontrados en repetidas muestras extraídas al azar de tamaño n sigue una distribución binomial. Para expresar la desviación de cualquier valor observado, r , con respecto a su valor esperado $n\pi_0$, podríamos establecer hasta qué punto r cae en una de ambas colas de la distribución muestral. Como en el apartado 4.2, ello podría determinarse calculando la probabilidad de la cola. Aquí, la situación es algo distinta porque la distribución de r es discreta. ¿Debemos calcular la probabilidad de obtener una desviación mayor que la observada, $r - n\pi_0$, o la probabilidad de obtener una desviación al menos tan grande? Dado que estamos diciendo algo referente al grado de sorpresa obtenido con un resultado observado determinado, parece razonable incluir la probabilidad de este resultado en la suma. Entonces, si $r > n\pi_0$ y las probabilidades de la distribución binomial con parámetros π_0 y n son $P_0, P_1, \dots, P_n$, el valor P para una prueba unilateral será:

$$P_+ = P_r + P_{r+1} + \dots + P_n$$

En una prueba bilateral podríamos añadir las probabilidades de las desviaciones, al menos tan grandes como la observada, en la otra dirección. El valor P de la otra cola es:

$$P_- = P_{r'} + P_{r'+1} + \dots + P_0$$

donde r' es igual a $2n\pi_0 - r$ si es un número entero, o el más alto que sea menor que esta cantidad. El valor de P en el test bilateral es entonces $P = P_- + P_+$.

Por ejemplo, si $r = 8$, $n = 10$ y $\pi_0 = 1/2$,

$$P_+ = P_8 + P_9 + P_{10}$$

y

$$P_- = P_2 + P_1 + P_0$$

Si $r = 17$, $n = 20$ y $\pi_0 = 1/3$,

$$P_+ = P_{17} + P_{18} + P_{19} + P_{20}$$

$$P_- = 0$$

Si $r = 15$, $n = 20$ y $\pi_0 = 0,42$,

$$\begin{aligned}P_+ &= P_{15} + P_{16} + P_{17} + P_{18} + P_{19} + P_{20} \\P_- &= P_1 + P_0\end{aligned}$$

Una alternativa, quizá preferible, es calcular el valor bilateral de P , multiplicando por dos el valor unilateral (v. p. 132).

Se consigue una simplificación considerable aproximándose a la distribución binomial mediante la normal (apartado 2.7). En la hipótesis nula:

$$\frac{r - n\pi_0}{\sqrt{[n\pi_0(1 - \pi_0)]}}$$

es aproximadamente una desviación normal estandarizada. Utilizando la corrección de continuidad, el área de la cola requerida para pruebas de significación es aproximadamente el área situada más allá de una desviación normal estandarizada:

$$z = \frac{|r - n\pi_0| - \frac{1}{2}}{\sqrt{[n\pi_0(1 - \pi_0)]}} \quad (4.9)$$

y el resultado será significativo, por ejemplo, a nivel del 5%, si la probabilidad es menor que 0,05.

Ejemplo 4.7

En un ensayo clínico efectuado para comparar la eficacia de dos analgésicos, X e Y, cada uno de los 100 pacientes participantes recibió X durante una semana e Y durante otra semana, determinándose al azar el orden de administración de los medicamentos. A continuación, cada paciente manifestó su preferencia por uno de ambos fármacos: 65 pacientes prefirieron X, y 35, Y. ¿Es ésta una fuerte evidencia de que, a largo plazo, más pacientes preferirán el fármaco X?

Probemos la hipótesis nula de que las preferencias forman una serie aleatoria en la que la probabilidad de una preferencia por X sea 1/2. Esto sería cierto si X e Y fueran igualmente eficaces en todos los aspectos que afectan las opiniones de los pacientes. El error tipo de r es:

$$\sqrt{(100 \times \frac{1}{2} \times \frac{1}{2})} = \sqrt{25} = 5$$

La desviación observada, $r - n\pi_0$, es:

$$65 - 50 = 15$$

Con la corrección de continuidad, la desviación normal estandarizada es $(15 - 1/2)/5 = 2,90$. Sin la corrección de continuidad, el valor habría sido $15/5 = 3,00$, el cual presenta una diferencia bastante pequeña. En este caso, la corrección de continuidad se podía haber ignorado. El área de la cola nor-

mal para $z = 2,90$ es 0,0037; la desviación con respecto a la hipótesis nula es muy significativa y existe una fuerte evidencia a favor de X. El valor exacto de P obtenido mediante la distribución binomial es 0,0035, valor muy cercano al de la aproximación normal.

Los límites de confianza del 95% para π son los valores π_l y π_s , para los cuales el valor observado de r es significativo en el test unilateral al nivel del 2,5% (fig. 4.5). Estos valores pueden obtenerse rápidamente en las tablas de la distribución binomial y están tabulados en las *Geigy Scientific Tables*, 1982 (volumen 2, pp. 89-102). También se pueden obtener en Fisher y Yates (1963), tabla VIII1.

La aproximación normal puede utilizarse de diversas formas:

1. Las áreas de las colas se pueden estimar a partir de (4.9). Entonces, para los límites del 95%, las aproximaciones para π_l y π_s se calculan con las fórmulas:




Fig. 4.5. Distribuciones binomiales que ilustran los límites de confianza del 95% del parámetro π basados en una muestra con 5 individuos de cierto tipo sobre un total de 20. Para $\pi = \pi_l = 0,09$, la probabilidad de 5 o más es 0,025; para $\pi = \pi_s = 0,49$, la probabilidad de 5 o menos es 0,025.

$$\frac{r - n\pi_i - \frac{1}{2}}{\sqrt{[n\pi_i(1 - \pi_i)]}} = 1,96$$

y

$$\frac{r - n\pi_s + \frac{1}{2}}{\sqrt{[n\pi_s(1 - \pi_s)]}} = -1,96$$

2. En el método 1, si n es grande, el $1/2$ de la corrección de continuidad se puede omitir. El método 1 incluye la solución de una ecuación cuadrática para cada π_i y cada π_s ; el método 2 sólo incluye una ecuación cuadrática. Otra simplificación es la siguiente:
3. Sustituir $\pi_i(1 - \pi_i)$ y $\pi_s(1 - \pi_s)$ por $p(1 - p)$. Éste no es un paso tan drástico, porque $p(1 - p)$ sólo cambia mínimamente con los cambios de p , en especial para valores de p cercanos a $1/2$. Ignorando la corrección de continuidad, como en 2, la aproximación usada con mayor frecuencia para los límites de confianza del 95% es:

$$p \pm 1,96 \sqrt{(pq/n)}$$

siendo $q = 1 - p$, como de costumbre. En este caso, la simplificación se debe a la sustitución del error tipo de p , que incluye el valor desconocido de π por la forma aproximada $\sqrt{(pq/n)}$, que se puede calcular a partir de cantidades conocidas.

Los límites exactos se pueden calcular utilizando las tablas de la distribución F . Esto se deduce de la relación matemática existente entre la distribución binomial y las distribuciones F . Aunque esta propiedad matemática se conoce desde hace años, este método de trabajo no ha sido extensamente adoptado.

El límite inferior π_i es la solución de:

$$\sum_{j=r}^n \binom{n}{j} \pi_i^j (1 - \pi_i)^{n-j} = 0,025$$

Se demuestra que el miembro de la izquierda de esta ecuación es igual a la probabilidad de que una variable que siga la distribución F con $2n - 2r + 2$ y $2r$ grados de libertad sea mayor que $r(1 - \pi_i)/(n - r + 1)\pi_i$. Por consiguiente:

$$\frac{r(1 - \pi_i)}{(n - r + 1) \pi_i} = F_{0,025, 2n - 2r + 2, 2r}$$

Esto es:

$$\left. \begin{aligned} \text{y de forma análoga: } \pi_i &= \frac{r}{r + (n - r + 1) F_{0,025, 2n - 2r + 2, 2r}} \\ \text{(Miettinen, 1970). } \pi_s &= \frac{r + 1}{r + 1 + (n - r) F_{0,025, 2r + 2, 2n - 2r}^{-1}} \end{aligned} \right\} \quad (4.10)$$

Ejemplo 4.7 (continuación)

Con $n = 100$ y $p = 0,65$, los límites de confianza del 95% resultan ser 0,548 y 0,743.

Con el método 1 se obtienen 0,548 y 0,741, con el método 2, 0,552 y 0,736, y con el método 3:

$$\begin{aligned} 0,65 \pm 1,96 \sqrt{\left[\frac{(0,65)(0,35)}{100} \right]} \\ = 0,65 \pm (1,96)(0,0477) \\ = 0,557 \text{ y } 0,743 \end{aligned}$$

Para este ejemplo, el método 3 es bastante adecuado.

Ejemplo 4.8

Como ejemplo de lo que podría suceder con unos números pequeños, supóngase que $n = 20$ y $p = 0,25$. Los límites de confianza del 95% exactos son 0,087 y 0,491 (v. fig. 4.5).

Con el método 1 se obtienen 0,096 y 0,494; con el método 2, 0,112 y 0,469, y con el método 3, 0,060 y 0,440. En este caso, el método 3 es claramente menos apropiado que en el ejemplo 4.7. En general, no debería emplearse el método 3 si np o $n(1 - p)$ es pequeño (p. ej., menor que 10). Los métodos 2 y 3 también pueden ser poco fidedignos cuando $n\pi_i$ o $n(1 - \pi_i)$ es inferior a 5. En este caso, $n\pi_i$ es aproximadamente 2, por lo que no sorprende que el límite de confianza inferior tampoco resulte bien aproximado mediante la aproximación normal.

Ejemplo 4.9

Como ejemplo para hallar los límites exactos utilizando la distribución F , considérense los datos de la figura 4.5 en la cual $r = 5$ y $n = 20$.

Entonces,

$$\pi_r = 5/(5 + 16F_{0,025, 32, 10})$$

$$\pi_s = 6/(6 + 15F_{0,025, 12, 30}^{-1})$$

El valor de $F_{0,025, 32, 10}$ puede obtenerse por interpolación en la tabla A4, en la cual la interpolación es lineal con las inversas de los grados de libertad. Así,

$$\begin{aligned} F_{0,025, 32, 10} &= 3,37 - (3,37 - 3,08) \times \left(\frac{1}{24} - \frac{1}{32} \right) \bigg/ \frac{1}{24} \\ &= 3,30 \end{aligned}$$

Por consiguiente, $\pi_r = 0,0865$ y, como $F_{0,025, 12, 30} = 2,41$, $\pi_s = 0,4908$. En este ejemplo fue necesario interpolar uno de los valores de F y en él los grados de libertad del numerador exclusivamente, pero, en general, la interpolación sería necesaria para ambos valores de F y para los grados de libertad tanto del numerador como del denominador. Esto resulta pesado y se puede evitar utilizando un método

basado en la aproximación normal, excepto cuando este último proporcione valores para los que $n\pi_i$ o $n(1 - \pi_i)$ sea pequeño (p. ej., menor que 5).

Se ha señalado anteriormente que la discreción de la distribución de r hizo que las deducciones obtenidas a partir de proporciones fuesen algo diferentes de aquellas basadas en una variable con una distribución continua, y ahora explicamos estas diferencias. Para una variable continua, un test de significación exacto daría el resultado $P < 0,05$ exactamente en el 5% de las muestras extraídas al azar de una población en la que la hipótesis nula fuese verdadera, y el intervalo de confianza del 95% contendría el valor de la población del parámetro estimado exactamente para el 95% de las muestras elegidas al azar. Por lo general, en el caso de una variable discreta, ninguna de estas propiedades se cumple. Considérese una variable binomial a partir de una distribución con $n = 10$ y $\pi = 0,5$ (v. tabla 2.4). Usando el test exacto para la hipótesis de que $\pi = 0,5$, se encuentra una significación al nivel del 5% sólo para $r = 0, 1, 9$ o 10 y la probabilidad de un valor u otro es $0,022$. Por consiguiente, un resultado significativo al nivel del 5% se encontraría sólo en el 2,2% de las muestras elegidas al azar si la hipótesis nula fuese cierta. Esto no plantea dificultades si se señala el nivel preciso de P . Así, si $r = 1$, tenemos que $P = 0,022$; un resultado significativo al nivel de $0,022$ o menos se obtendría exactamente en el 2,2% de las muestras elegidas al azar. Por lo tanto, el mejor test aproximado es la aproximación normal con una corrección de la continuidad, obteniéndose, en este caso, $P = 0,027$.

Con el intervalo de confianza ocurre una situación similar. Los límites de confianza exactos del parámetro binomial son prudentes en el sentido de que la probabilidad de incluir el valor verdadero es, *al menos*, tan grande como el coeficiente de confianza nominal. Este hecho surge a partir de la decisión discutible de incluir el valor observado en el cálculo de probabilidades en el área de la cola. Los límites se denominan «exactos» porque se obtienen a partir de cálculos exactos de la distribución binomial y no mediante una aproximación, pero no porque el coeficiente de confianza se obtenga con exactitud. Este problema no puede resolverse, al igual que en el caso del test de significación, cambiando el coeficiente de confianza. En primer lugar, esto es difícil de hacer. En segundo lugar (y aún más importante), aunque en un test de significación es deseable estimar P con la mayor precisión posible, en el método del intervalo de confianza es perfectamente razonable especificar previamente el coeficiente de confianza en algún valor convencional, como el 95%. Los límites aproximados usando la corrección de la continuidad también tienden a ser prudentes. Sin embargo, los límites obtenidos mediante los métodos 2 y 3, que ignoran la corrección de la continuidad, tenderán a presentar una probabilidad de inclusión más cercana al valor nominal. Ello sugiere que descuidar la corrección de la continuidad no representa un problema grave y, en realidad, puede ser una ventaja.

Los problemas analizados anteriormente, debido a la discreción de la distribución, han causado mucha polémica en la literatura estadística, en particular con el análisis de datos recogidos para comparar dos proporciones, tema que se abordará en el apartado 4.9. Un método, sugerido por Lancaster (1952, 1961), consiste en usar los valores de *semi-P*. Recientemente se ha postulado este método con mayor amplitud (Williams, 1988; Barnard, 1989; Hirji, 1991; Upton, 1992). El valor de la *semi-P* en el caso de un test unilateral se obtiene incluyendo en la cola sólo la mitad de la probabilidad de la muestra observada. Así, en el caso

de una muestra binomial con r observadas de n , donde $r > n\pi_0$, el valor de la semi- P probando la hipótesis de que $\pi = \pi_0$ será:

$$\text{semi-}P_+ = 1/2P_r + P_{r+1} + \dots + P_n.$$

Hay que señalar que el valor de la semi- P no es la probabilidad de obtener un resultado significativo al azar cuando la hipótesis nula es cierta. De nuevo, supóngase una variable binomial a partir de una distribución, con $n = 10$ y $\pi = 0,5$ (v. tabla 2.4). Para la hipótesis de que $\pi = 0,5$, un valor de la semi- P inferior a 0,05 se encontraría sólo con $r = 0, 1, 9$ o 10 , puesto que el valor semi- P con $r = 2$ es $2[0,0010 + 0,0098 + 1/2 (0,0439)] = 0,0655$ y la probabilidad de un valor u otro es 0,022.

Barnard (1989) ha recomendado citar ambos valores, P y semi- P , basándose en que aquél es una medida de la significación estadística cuando los datos que se han de analizar se juzgan solos, mientras que ésta es la medida adecuada de la fuerza de los indicios en contra de la hipótesis que se contrasta, y ha de usarse junto con los indicios obtenidos de otros estudios. Esto se debe a que el valor de la semi- P tiene la característica deseable de que, cuando la hipótesis nula es verdadera, su valor promedio es 0,5 y esta propiedad la hace especialmente idónea como medida utilizable cuando se combinan los resultados de varios estudios para efectuar una valoración global (metaanálisis, cap. 7). Debido a que es poco frecuente que los resultados de un solo estudio se empleen sin el apoyo de otros estudios, nuestra recomendación consiste también en dar los dos valores, P y semi- P , pero haciendo más hincapié en éste.

En correspondencia con los valores de la semi- P tenemos los límites de confianza semi- P , calculados como aquellos que tomados como el valor de la hipótesis nula, dan un valor semi- P correspondiente, o sea, los límites del 95% corresponden a valores semi- P unilaterales de 0,025.

Cuando una aproximación normal es idónea, los valores P y semi- P corresponden a tests estadísticos calculados con la corrección de la continuidad y sin ella, respectivamente. Por consiguiente, los intervalos de confianza y los intervalos de confianza semi- P pueden basarse en aproximaciones normales, usando e ignorando la corrección de la continuidad, respectivamente. Así, los límites de confianza semi- P en el caso de una probabilidad binomial se obtendrían usando el método 2 y no el método 1 (p. 114).

Cuando las aproximaciones normales no son las idóneas, los valores semi- P se calculan sumando las probabilidades adecuadas. El cálculo de los límites semi- P es más engorroso, ya que no están incluidos en las grupos de tablas estándar y no hay una fórmula directa correspondiente a (4.10). Los límites pueden obtenerse con bastante rapidez por medio de un ordenador personal o una calculadora programable, ajustando la expresión que se va a evaluar mediante un argumento general y, a continuación, mediante ensayo y error, hallando los valores con los que se obtienen colas de 0,025.

Ejemplo 4.8 (continuación)

Los límites semi- P se obtienen con la fórmula:

$$P_0 + P_1 + P_2 + P_3 + P_4 + 1/2 P_5 = 0,975 \text{ o } 0,025$$

donde P_i es la probabilidad binomial (como en (2.9)) para i acontecimientos con $n = 20$ y $\pi = \pi_1$ o π_2 . Esta expresión se ajustó en un ordenador personal para π generales y, empezando con el conocimiento de que el intervalo de confianza sería ligeramente más estrecho que los límites de 0,0865 y 0,4908 obtenidos anteriormente, se encontró que los límites de confianza semi- P del 95% eran 0,098 y 0,470. Con el método I se obtiene la mejor aproximación a estos límites; sin embargo, como ya se ha señalado, el límite de confianza inferior se aproxima de manera menos adecuada mediante la aproximación normal, debido a que $n\pi_i$ es sólo aproximadamente 2.

4.8. Comparación de dos proporciones

Como en la comparación de dos medias tratada en el apartado 4.4, podemos distinguir dos situaciones según que los dos miembros individuales de ambas muestras estén apareados o no.

Casos apareados

Supóngase que en cada muestra existen N observaciones que forman N pares de observaciones. Denominando a las muestras 1 y 2 y describiendo a cada individuo como A o no A, existen claramente cuatro tipos de pares:

Tipo	Muestra		Número de pares
	1	2	
1	A	A	k
2	A	no A	r
3	no A	A	s
4	no A	no A	m

Si el número de pares de los cuatro tipos son como los que aparecen en la tabla anterior, los resultados se pueden presentar con una tabla 2 por 2:

		Muestra 2		
		A	no A	
Muestra 1	A	k	r	$k + r$
	no A	s	m	$s + m$
		$k + s$	$r + m$	N

Las proporciones de A individuos son $(k + r)/N$ en la muestra 1 y $(k + s)/N$ en la muestra 2. Estamos interesados en la diferencia entre las dos proporciones, que claramente es $(r - s)/N$.

Consideremos en primer lugar un test de significación. La hipótesis nula es que el valor esperado de $(r - s)/N$ es cero o, en otras palabras, que los valores esperados de r y s son iguales. Esto se puede contrastar adecuadamente centrando nuestra atención en los $r + s$ pares cuyos dos miembros son diferentes. Llamemos a $r + s$, n . En la hipótesis nula, con n pares no apareados o «no ligados», el número de pares de tipo 2 (o de tipo 3) seguiría una distribución

binomial con un parámetro igual a $1/2$. Por consiguiente, la prueba sigue exactamente los métodos del apartado 4.7. Considerando:

$$z = \frac{r - \frac{1}{2}n}{\frac{1}{2}\sqrt{n}} \quad (4.11)$$

como una desviación normal estandarizada, se obtiene un test para muestras grandes. Se puede aplicar una corrección de continuidad disminuyendo en $1/2$ el valor absoluto de $r - (1/2)n$. Esta prueba se conoce como test de McNemar. Una forma alternativa a (4.11), que incluye una corrección de continuidad, es:

$$z^2 = \frac{(|r - s| - 1)^2}{r + s} \quad (4.12)$$

donde z^2 se puede considerar como una variante de $\chi^2_{(1)}$. Éste es uno de los pocos cálculos estadísticos que se pueden realizar mentalmente (v. también 4.29).

Hay que señalar que, aunque el test de significación se basa en las dos frecuencias r y s , la diferencia estimada entre las proporciones de positivos y, por lo tanto, su error tipo también dependen de N . Es decir, los tests de la existencia de una diferencia provienen exclusivamente de los pares no empatados; una valoración de la *magnitud* de dicha diferencia debe referirse a los restantes datos. Hay que saber distinguir entre significación estadística y clínica, a la que se hace referencia en el apartado 4.2.

El cálculo de los límites de confianza para la diferencia entre las dos proporciones supone tener en cuenta la variación en el número de pares empatados, $r + s$. Esto se puede lograr deduciendo el error tipo a partir de las propiedades de la distribución multinomial, que es una extensión de la distribución binomial cuando hay más de dos clases. A continuación se obtienen los límites de confianza aproximados de la diferencia entre las dos proporciones, considerando que su error tipo es:

$$\frac{1}{N} \sqrt{\left[r + s - \left(\frac{(r - s)^2}{N} \right) \right]} \quad (4.13)$$

(Gardner y Altman, 1989) y usando la teoría normal habitual. Cuando se obtienen datos de este tipo en un estudio caso-control, a menudo se hace hincapié en la estimación de la razón de probabilidad *odds ratio*, v. los apartados (4.15) y (16.17).

Hay una discrepancia potencial entre el test (4.11) y los límites de confianza obtenidos usando (4.13). Si el test es apenas significativo al nivel del 5%, $z = 1,96$; el límite de confianza es superior a cero. Esto resulta así a causa del segundo término que hay dentro de la raíz cuadrada de (4.13). La discrepancia será ligera, salvo grandes diferencias entre r y s .

Ejemplo 4.10

Se cultivan 15 muestras de esputo en dos medios distintos, A y B, con el objeto de comparar la capacidad de los dos medios para detectar la presencia de bacilos de la tuberculosis. Los resultados se muestran en la tabla 4.3. La hipótesis nula, según la cual los medios tienen igual eficacia, se contrasta mediante la desviación normal estandarizada

$$z = \frac{12 - (\frac{1}{2})(14)}{\frac{1}{2}\sqrt{14}} = \frac{5}{1,871} = 2,67 \quad (P = 0,008)$$

Existen pocas dudas de que A es más eficaz que B. La corrección de continuidad reduce la desviación normal a $4,5/1,871 = 2,41$, que sigue siendo un resultado significativo.

Los límites de confianza del 95% para la diferencia entre las proporciones de esputo positivo en los dos medios, se obtienen efectuando las siguientes operaciones:

$$\begin{aligned} \frac{(12 - 2)}{50} \pm \frac{1,96\sqrt{(14 - 10^2/50)}}{50} \\ = 0,20 \pm 0,14 \\ = 0,06 \text{ y } 0,34 \end{aligned}$$

Prueba exacta para el caso de datos apareados

El planteamiento que hemos considerado se basa en la aproximación normal a una distribución discreta. La situación es similar a la tratada en el apartado 4.7, excepto en lo referente a la complicación de los pares empatados, k y m ; con la corrección de continuidad (4.11) que corresponde a (4.9) con $\pi_0 = 1/2$. El test de significación de (4.12) será satisfactorio excepto para valores pequeños de $r + s$ (menores de 10), y en tales casos se puede efectuar un test exacto de los pares no empatados $r + s$. Es posible que los límites de confianza calculados con el empleo de (4.13) no sean aproximaciones válidas incluso para valores de $r + s$ mayores de 10, especialmente si r y s difieren mucho. No existe una solución completamente satisfactoria. Un método consiste en basar los límites en los límites de confianza del 95% de la proporción

Tabla 4.3. Distribución de 50 muestras de esputo de acuerdo con los resultados del cultivo en dos medios.

Tipo	Medio		Número de esputos
	A	B	
1	+	+	20
2	+	-	12
3	-	+	2
4	-	-	16
			50

Tabla alternativa

		Medio B		Total
		+	-	
Medio A	+	20	12	32
	-	2	16	18
Total		22	28	50

de pares del tipo 2 sobre los pares no empatados $r + s$, que pueden obtenerse exactamente mediante los métodos 1 o 2 del apartado 4.7. Sin embargo, este método no tiene en cuenta la variación en $\sqrt{r + s}$.

Ejemplo 4.10 (continuación)

El nivel de significación exacto se obtiene efectuando la siguiente operación:

$$P = 2 \times \left(\frac{1}{2}\right)^{14} [1 + 14 + (14 \times 13/2)] = 0,013$$

El valor de la semi- P se obtiene tomando sólo la mitad del último término de la expresión anterior, que es igual a 0,007.

Los límites de confianza del 95% exactos de la proporción de pares del tipo 2 (tabla 4.3) sobre 14 pares del tipo 2 o 3 son 0,5718 y 0,9822. Por consiguiente, los correspondientes límites de confianza del 95% aproximados de la diferencia en proporciones sobre el total de 50 pares son:

$$(0,5718 - 0,4282) \times \frac{14}{50}$$

y

$$(0,9822 - 0,0178) \times \frac{14}{50}$$

$$= 0,04 \text{ y } 0,27$$

Los límites de confianza del 95% semi- P exactos de la proporción de pares del tipo 2 son 0,6026 y 0,9753 y éstos dan unos límites aproximados de 0,06 y 0,26 de la diferencia entre las proporciones.

El test exacto también se puede obtener usando la distribución F , como en (16.19).

Casos no apareados

Supongamos que existen dos poblaciones en las que las probabilidades de que un individuo muestre la característica A son π_1 y π_2 . Una muestra extraída al azar de la primera población de tamaño n_1 tiene r_1 miembros que presentan la característica (y una proporción $p_1 = r_1/n_1$), mientras que los valores correspondientes en una muestra independiente extraída de la segunda población son n_2 , r_2 y $p_2 = r_2/n_2$. Según (3.11) tenemos:

$$E(p_1 - p_2) = \pi_1 - \pi_2$$

y

$$\text{Var}(p_1 - p_2) = \frac{\pi_1(1 - \pi_1)}{n_1} + \frac{\pi_2(1 - \pi_2)}{n_2}$$

Para calcular los intervalos de confianza, desconocemos π_1 y π_2 , pero pueden sustituirse por p_1 y p_2 , respectivamente, obteniendo:

$$\text{Var}(p_1 - p_2) = \frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2} \quad (4.14)$$

donde:

$$q_1 = 1 - p_1$$

y

$$q_2 = 1 - p_2$$

Los límites aproximados se obtienen aplicando la teoría normal habitual.

Supóngase que queremos contrastar la hipótesis nula $\pi_1 = \pi_2$. Denominamos al valor común π . Entonces, p_1 y p_2 son estimaciones de π , y no existen motivos para estimar π (como en 4.14) mediante dos cantidades distintas en dos lugares diferentes de la expresión. Si la hipótesis nula es cierta, las dos muestras proceden efectivamente de la misma población, y la mejor estimación de π se obtendrá uniendo las dos muestras para dar:

$$p = \frac{r_1 + r_2}{n_1 + n_2}$$

La estimación combinada sustituye a π_1 y π_2 para dar:

$$\text{Var}(p_1 - p_2) = pq \left(\frac{1}{n_1} + \frac{1}{n_2} \right)$$

escribiendo como de costumbre $q = 1 - p$. A continuación se contrasta aproximadamente la hipótesis nula mediante la siguiente expresión.

$$z = \frac{p_1 - p_2}{\sqrt{pq \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

como una desviación normal estandarizada.

Ejemplo 4.11

En un ensayo clínico efectuado para valorar un nuevo tratamiento, A, en comparación con un método antiguo, B, los pacientes se dividieron al azar en dos grupos. De 257 pacientes tratados con el método A fallecieron 41; de los 244 tratados con el método B fallecieron 64. Es decir, $p_1 = 41/257 = 0,1595$ y $p_2 = 64/244 = 0,2623$.

La diferencia estimada entre las dos razones de mortalidad es $0,1595 - 0,2623 = -0,1028$. Para calcular los límites de confianza del 95% tomamos:

$$\text{Var}(p_1 - p_2) = \frac{(0,1595)(0,8405)}{257} + \frac{(0,2623)(0,7377)}{244}$$

$$= 0,0005216 + 0,0007930$$

$$= 0,0013146$$

$$\text{ET}(p_1 - p_2) = \sqrt{0,0013146} = 0,0363$$

Así, los límites de confianza del 95% son:

$$-0,1028 \pm (1,96) (0,0363) = -0,0317 \text{ y } -0,1739$$

el signo menos sirve simplemente para indicar en qué dirección se encuentra la diferencia.

Para la prueba de significación, calculamos la proporción combinada:

$$p = 105/501 = 0,2096$$

y estimamos el error tipo ($p_1 - p_2$) como:

$$\sqrt{\left[(0,2096)(0,7904) \left(\frac{1}{257} + \frac{1}{244}\right)\right]} \\ = 0,0364$$

Por consiguiente, la desviación normal es:

$$\frac{-0,1028}{0,0364} = -2,82 \quad (P = 0,005)$$

Hay fuertes indicios que apoyan la existencia de una diferencia a favor de A entre ambas tasas de mortalidad.

Nótese que en el ejemplo 4.11, el uso de p modificó el error tipo sólo de modo marginal, de 0,0363 a 0,0364. De hecho, es probable que sólo exista un cambio apreciable cuando n_1 y n_2 sean muy distintas y cuando p_1 y p_2 difieran sustancialmente. En otras circunstancias, cualquier fórmula del error tipo se puede considerar como una buena aproximación de la otra y usarse en consecuencia.

A menudo, en los estudios epidemiológicos resulta adecuado medir la diferencia entre dos proporciones mediante la razón entre ellas, p_1/p_2 , y no mediante la propia diferencia. Esta medida recibe el nombre de *razón de riesgos*, *razón de razones* o *riesgo relativo*, dependiendo del tipo de estudio efectuado. En estudios caso-control no puede evaluarse directamente el riesgo relativo, pero en muchas circunstancias la razón de probabilidad (OR), definida por la fórmula:

$$OR = \frac{p_1/(1 - p_1)}{p_2/(1 - p_2)} \quad (4.15)$$

es una buena aproximación al riesgo relativo (cap. 16). Desde el punto de vista del test de significación, no importa cuál es la medida empleada, y tanto el método anteriormente señalado como las ampliaciones indicadas en el siguiente apartado resultan adecuados.

Los límites de confianza de la razón de riesgos y de la razón de probabilidad requieren el empleo de logaritmos *naturales* o *neperianos*. En los logaritmos naturales la base es e ($= 2,7183$); el $\log_e x$ se escribe generalmente $\ln x$ y $\ln x = 2,3026 \log_{10} x$. La mayoría de las calculadoras de bolsillo tienen una tecla para $\ln x$ y para el antilogaritmo, el exponencial de x , que suele escribirse e^x , por lo que en general la fórmula de conversión no es necesaria.

Si escribimos R para p_1/p_2 , tenemos:

$$R = \frac{r_1/n_1}{r_2/n_2} \quad (4.16)$$

$$ET(\ln R) = \sqrt{\left(\frac{1}{r_1} - \frac{1}{n_1} + \frac{1}{r_2} - \frac{1}{n_2}\right)} \quad (4.17)$$

y el intervalo de confianza del 95% para R es:

$$\exp[\ln R \pm 1.96 ET(\ln R)]$$

En un estudio caso-control (apartado 6.3) debemos cambiar la notación, puesto que no hay muestras más grandes a partir de las dos poblaciones, pero en cambio los casos de enfermedad y los controles (no casos) se muestrean por separado y se establece su exposición a algún factor. Supóngase que las frecuencias son las siguientes:

		Casos	Controles	
Factor	+	a	c	$a + c$
	-	b	d	$b + d$
		$a + b$	$c + d$	n

Por consiguiente, se obtiene la razón de probabilidad (*odds ratio*) mediante la fórmula:

$$OR = \frac{ad}{bc} \quad (4.18)$$

y

$$ET[\ln(OR)] = \sqrt{\left(\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}\right)} \quad (4.19)$$

Ejemplo 4.12

Liddell et al (1984) publicaron un estudio caso-control en el que se investigó la asociación entre el carcinoma bronquial y la exposición al asbesto en las minas y los molinos de crisolita canadienses. Los datos son los siguientes:

Exposición al asbesto	Cáncer de pulmón	Controles
Expuestos	148 (a)	372 (c)
No expuestos	75 (b)	343 (d)

Los cálculos son los siguientes:

$$OR = (148 \times 343)/(75 \times 372) = 1,82$$

$$\ln OR = 0,599$$

$$ET(\ln OR) = \sqrt{\left(\frac{1}{148} + \frac{1}{75} + \frac{1}{372} + \frac{1}{343}\right)} = \sqrt{0,02569} = 0,160$$

$$\text{Intervalo de confianza del 95\% del } \ln OR = 0,599 \pm 1,96 \times 0,160 \\ = 0,285 \text{ a } 0,913;$$

$$\text{Intervalo de confianza del 95\% de } OR = \exp(0,285) \text{ a } \exp(0,913) \\ = 1,33 \text{ a } 2,49.$$

Estos límites a veces reciben el nombre de *límites logit* (apartado 16.2).

4.9. Tablas 2 x 2 y pruebas de χ^2

En la tabla 4.4 se muestra un método alternativo para presentar los datos del ejemplo 4.11. Este método se denomina *tabla de contingencia 2 x 2*. En el extremo inferior derecho de la tabla está indicada la frecuencia total, que en este ejemplo es 501. Esta frecuencia total se divide en dos dicotomías diferentes representadas por dos filas «horizontales» y dos columnas «verticales». En este ejemplo, las filas representan los dos tratamientos, y las columnas los dos resultados del tratamiento. En consecuencia, existen $2 \times 2 = 4$ combinaciones de categorías de filas y columnas, y las frecuencias correspondientes ocupan las cuatro *casillas internas* de la tabla. Las frecuencias totales de las dos filas y las de las dos columnas están indicadas a la derecha y en la parte inferior de la tabla y se denominan *totales marginales*.

Nosotros ya hemos utilizado una tabla 2 x 2 (tabla 4.3) para presentar los resultados con el fin de efectuar una comparación de proporciones en muestras apareadas, pero el propósito era ligeramente distinto del actual, que trata sólo del diseño con el caso de los datos *no apareados*.

En la tabla 4.4 nos interesan las posibles diferencias entre las tasas de mortalidad de ambos tratamientos. Dados los totales marginales de la tabla 4.4, podemos calcular fácilmente los números que se debían haber observado en el cuerpo de la tabla para igualar las tasas de mortalidad de A y B. Por ejemplo, en la casilla superior izquierda el número *esperado* es

Tabla 4.4. Tabla 2 x 2 que ilustra los resultados de un ensayo clínico.

Tratamiento	Resultado		Total
	Muerte	Supervivencia	
A	41	216	257
B	64	180	244
Total	105	396	501

$$\frac{105 \times 257}{501} = 53,862$$

porque la tasa de mortalidad total es 105/501 y existen 257 individuos tratados con A. En la tabla 4.5 se presentan las cifras esperadas similares que se pueden obtener para cada una de las cuatro casillas internas (las cifras observadas y esperadas se distinguen por las letras *O* y *E*, respectivamente). Las cifras esperadas no son números enteros y se han redondeado a 3 decimales. Obviamente, no se podrían observar 53,862 individuos en una casilla determinada. Estas cifras esperadas deberían considerarse como esperanzas o valores medios de un gran número de tablas posibles, con los mismos totales marginales que los observados, siendo cierta la hipótesis nula.

Nótese que los valores de la suma de *E* a lo largo de las filas y de las columnas son iguales a los totales marginales observados. Las *discrepancias*, medidas por las diferencias *O* – *E*, suman cero a lo largo de las filas y de las columnas; en otras palabras, las cuatro discrepancias son numéricamente idénticas (en este ejemplo, 12,862), siendo dos positivas y dos negativas.

En un sentido aproximado, cuanto mayores son las discrepancias, mayores indicios tenemos para rechazar la hipótesis nula. Por consiguiente, parecería razonable basar un test de significación de alguna manera en estas discrepancias. También parece razonable tener en cuenta el tamaño absoluto de las frecuencias: una discrepancia de 5 es mucho más importante si *E* = 5 que si *E* = 100.

Resulta apropiado calcular el siguiente índice:

$$X^2 = \sum \frac{(O - E)^2}{E} \quad (4.20)$$

Tabla 4.5. Frecuencias esperadas y contribuciones al X^2 de los datos de la tabla 4.4.

		Resultado		
Tratamiento		Muerte	Supervivencia	Total
A	<i>O</i>	41	216	257
	<i>E</i>	53,862	203,138	257
	<i>O</i> – <i>E</i>	–12,862	12,862	0
	$(O - E)^2$	165,431	165,431	
	$(O - E)^2/E$	3,071	0,814	
B	<i>O</i>	64	180	244
	<i>E</i>	51,138	192,862	244
	<i>O</i> – <i>E</i>	12,862	–12,862	0
	$(O - E)^2$	165,431	165,431	
	$(O - E)^2/E$	3,235	0,858	
Total	<i>O</i>	105	396	501
	<i>E</i>	105	396	
	<i>O</i> – <i>E</i>	0	0	

sumando sobre las cuatro casillas de la tabla. Las contribuciones de las cuatro casillas a X^2 se muestran en la tabla 4.5. El total es:

$$\begin{aligned} X^2 &= 3,071 + 0,814 + 3,235 + 0,858 \\ &= 7,978 \end{aligned}$$

En la hipótesis nula, X^2 sigue la distribución $\chi^2_{(1)}$ (v. apartado 3.4) y mejora la aproximación a medida que las frecuencias esperadas aumentan. Existe un grado de libertad porque solamente se necesita uno de los valores de E para completar toda la tabla. Según la tabla A2, el valor observado 7,978 se encuentra más allá del punto 0,01 de la distribución $\chi^2_{(1)}$ y, por consiguiente, la diferencia entre ambas razones de fatalidad es significativa al nivel del 1%.

El nivel de significación preciso puede obtenerse extrayendo la raíz cuadrada de 7,978 ($= 2,82$) y remitiéndose a la tabla A1; esto da como resultado 0,005.

En el apartado 4.8 hemos deducido una desviación normal estandarizada calculando el error tipo de la diferencia entre las dos proporciones, con lo cual se obtiene el valor numérico de 2,82. Éste coincide con el valor obtenido como la raíz cuadrada de X^2 . En realidad, se puede demostrar algebraicamente que el índice X^2 es siempre idéntico al cuadrado de la desviación tipo obtenida mediante el primer método. Por lo tanto, los niveles de probabilidad obtenidos mediante los dos tests coinciden siempre.

El índice X^2 suele expresarse como χ^2 aunque parece preferible reservar éste para la distribución teórica, expresando el valor calculado por X^2 .

Existen varias fórmulas alternativas para X^2 , de las cuales presentaremos una. Indiquemos las entradas en la tabla del siguiente modo:

		Columna		
		1	2	
Fila	1	a	b	r_1
	2	c	d	r_2
		s_1	s_2	N

Entonces:

$$X^2_c = \frac{(lad - bc)^2 - \frac{1}{4}N^2}{r_1 r_2 s_1 s_2} \quad (4.21)$$

Esta versión está especialmente indicada para utilizar una calculadora.

Tenemos pues dos test de significación completamente idénticos. La elección de uno u otro por el usuario es, en cierto modo, una cuestión de gusto y conveniencia; sin embargo, se deben hacer dos consideraciones. Primero, el método del error tipo, como hemos visto, no sólo proporciona un test de significación sino que conduce al cálculo de los intervalos de confianza. En general, un análisis estadístico que ofrezca simplemente un test de significación y no estime la magnitud del contraste aplicable teniendo en cuenta en cierta medida el error tipo debe considerarse inadecuado. Éste es, en consecuencia, un argumento de peso para calcular diferencias y errores tipo y para basar la prueba en estos valores y no en el índice X^2 . El principal argumento en contra es que, como veremos en el capítulo 7, el método X^2 se puede generalizar a las tablas de contingencia con más de dos filas o columnas.

Es importante recordar que el índice X^2 sólo puede calcularse a partir de tablas 2×2 cuyas entradas sean frecuencias. Un error común consiste en utilizarlo con una tabla cuyas entradas son medias de una variable determinada; este proceder es completamente equivocado.

Un método estrechamente relacionado para deducir un test de significación consiste en trabajar con una de las frecuencias de la tabla 2×2 . Con la notación anterior, la frecuencia expresada por a podría considerarse una variable aleatoria, podría valorarse su significación frente a su expectativa y se podría calcular condicionalmente el error tipo en los totales marginales. Este método procede de la siguiente manera, usando O , E y V para representar el valor observado, el valor esperado y la variancia de a :

$$\left. \begin{aligned} E &= \frac{(a+b)(a+c)}{N} \\ V &= \frac{(a+b)(c+d)(a+c)(b+d)}{N^2(N-1)} \\ X^2 &= \frac{(O-E)^2}{V} \end{aligned} \right\} \quad (4.22)$$

Aparte de un factor de $(N-1)/N$, (4.22) es equivalente a (4.21). Esta forma es especialmente práctica cuando se combinan los resultados de varios estudios, debido a que los valores de O , E y V se pueden sumar de un estudio a otro antes de calcular el test estadístico. Yusuf et al (1985) propusieron un método aproximado para estimar la razón de probabilidad y su error tipo mediante:

$$\left. \begin{aligned} OR &= \exp\left(\frac{O-E}{V}\right) \\ ET[\ln(OR)] &= \frac{1}{\sqrt{V}} \end{aligned} \right\} \quad (4.23)$$

Este método fue introducido por la combinación de estudios en los que el efecto era pequeño y se sabe que no es sesgado cuando la razón de probabilidad no es pequeña (Greenland y Salvan, 1990).

En el apartado 12.6 se proporcionan más detalles sobre estos métodos y, en el apartado 7.2, sobre su aplicación en revisiones o metaanálisis.

Ejemplo 4.13

Considérense los datos del ejemplo 4.12. Tenemos:

$$O = 148 \quad E = 123,62 \quad V = 42,038$$

y con (4.23) se obtiene:

$$\begin{aligned} OR &= \exp(24,38/42,038) = 1,79 \\ ET[\ln(OR)] &= 0,154. \end{aligned}$$

Estos valores se aproximan a los hallados en el ejemplo 4.12.

Tanto el error tipo como los test de las χ^2 se basan en aproximaciones que son válidas en particular cuando las frecuencias son altas. En general, está extendido el uso de dos métodos de mejora: la aplicación de la corrección de la continuidad y el cálculo de las probabilidades exactas.

Corrección de continuidad de las tablas 2 x 2

Este método fue descrito por F. Yates y suele denominarse *corrección de Yates*. La distribución $\chi^2_{(1)}$ se ha utilizado como una aproximación a la distribución de X^2 en la hipótesis nula y sujeta a totales marginales fijos. Con esta última reserva, sólo es posible un número finito de tablas. Por ejemplo, para los totales marginales de la tabla 4.4, se pueden generar todas las tablas posibles aumentando o disminuyendo una de las entradas, de unidad en unidad, hasta que esta entrada o alguna otra sea cero. (Más adelante, en este mismo apartado se considera con más detalle.) La situación se parece a la analizada en el apartado 2.7, donde se aproximó una distribución discreta (la binomial) mediante una distribución continua (la normal). En este caso sería razonable basar la prueba de significación en la probabilidad de la tabla observada o en una que mostrara una desviación más extrema con respecto a la hipótesis nula. Se consigue mejorar la estimación de esta probabilidad reduciendo el valor absoluto de la diferencia $O - E$ en $1/2$, antes de calcular X^2 . En el ejemplo 4.11 (tabla 4.5), esto significaría tomar $|O - E|$ igual a 12,362 en lugar de 12,862, y el valor corregido de X^2 , simbolizado por X^2_c , sería 7,369, algo menor que el valor no corregido pero también muy significativo.

La corrección de la continuidad tiene un efecto relativamente mayor cuando las frecuencias esperadas son bajas que cuando son altas. Con el empleo de la corrección de la continuidad se obtiene una aproximación del valor de P en el test exacto que se describe a continuación. Al igual que en las situaciones análogas explicadas en este capítulo (v. también p. 133), preferimos el valor de la semi- P , que corresponde al test de la χ^2 no corregido. Por consiguiente, recomendamos no emplear de manera sistemática la corrección de la continuidad.

La versión con corrección de continuidad (4.21):

$$X^2_c = \frac{(|ad - bc| - \frac{1}{2}N)^2 N}{r_1 r_2 s_1 s_2} \quad (4.24)$$

Si se aplica la corrección de continuidad en el test de la χ^2 , lógicamente se debe aplicar al test del error tipo. El procedimiento consiste en calcular $p_1 - p_2$ una vez que se han modificado las frecuencias en media unidad hacia sus valores esperados y manteniendo constante el error tipo. Así, en el ejemplo 4.11, deberíamos tener $p_{1(c)} = 41,5/257 = 0,1615$, $p_{2(c)} = 63,5/244 = 0,2602$, de donde $z_{(c)} = -0,0987/0,0364 = -2,71$. Como $(-2,71)^2 = 7,34$, el resultado concuerda con el de X^2_c , aparte de los errores de redondeo.

Test exacto para tablas 2 x 2

Cuando las frecuencias sean muy pequeñas, se plantearán dudas sobre la conveniencia de la aproximación χ^2 , incluso aunque se aplique la corrección de continuidad. Hacia mediados de

la década de 1930, R. A. Fisher, J. O. Irwin y F. Yates sugirieron, casi simultáneamente un test exacto, que consiste en calcular las probabilidades exactas de las posibles tablas escritas en la subsección anterior. La probabilidad de una tabla con frecuencias:

a	b	r_1
c	d	r_2
s_1	s_2	N

viene dada por la fórmula:

$$\frac{r_1!r_2!s_1!s_2!}{N!a!b!c!d!} \quad (4.25)$$

Ésta constituye, de hecho, la probabilidad de las frecuencias observadas de las casillas *condicionadas* a los totales marginales observados, bajo la hipótesis nula de no asociación entre las clasificaciones de las filas y de las columnas.

Dada una tabla observada, se pueden calcular las probabilidades de todas las tablas con los mismos totales marginales, y el valor P del test de significación se obtiene sumando estas probabilidades. El ejemplo 4.14 ilustra los cálculos y algunas de las dificultades de interpretación que se pueden plantear.

Ejemplo 4.14

Yates (1934) comentó los datos de la tabla 4.6 construida por M. Hellman.

Tabla 4.6. Datos de maloclusión dental en niños (Yates, 1934).

	Niños con:		Total
	Dientes normales	Maloclusión	
Con lactancia materna	4	16	20
Alimentados con biberón	1	21	22
Total	5	37	42

Existen seis posibles tablas con los mismos totales marginales que los observados, porque ni a ni c , según la notación adoptada previamente, pueden ser inferiores a 0 o superiores a 5, el total marginal más pequeño de la tabla. En la tabla 4.7 se muestran las frecuencias de las casillas de cada una de estas tablas.

Tabla 4.7. Frecuencias de las casillas en las tablas con los mismos totales marginales que los de la tabla 4.6.

0	20	20	1	19	20	2	18	20
5	17	22	4	18	22	3	19	22
5	37	42	5	37	42	5	37	42
3	17	20	4	16	20	5	15	20
2	20	22	1	21	22	0	22	22
5	37	42	5	37	42	5	37	42

La probabilidad de que $a = 0$ es, según (4.25):

$$P_0 = \frac{20!22!5!37!}{42!0!20!5!17!} = 0,03096$$

Para estos cálculos se utilizan con mucha frecuencia las tablas de factoriales logarítmicos (Fisher y Yates, 1963, tabla XXX); algunas calculadoras científicas tienen una tecla factorial (aunque ésta sólo puede funcionar correctamente con enteros inferiores a 70). Otra solución consiste en calcular la expresión para P_0 sin factoriales, mediante multiplicaciones y divisiones repetidas después de anular los factores comunes:

$$P_0 = \frac{22 \times 21 \times 20 \times 19 \times 18}{42 \times 41 \times 40 \times 39 \times 38} = 0,03096$$

Las probabilidades para $a = 1, 2, \dots, 5$ se pueden obtener sucesivamente. Así,

$$P_1 = \frac{5 \times 20}{1 \times 18} \times P_0$$

$$P_2 = \frac{4 \times 19}{2 \times 19} \times P_1, \text{ etc.}$$

Los resultados son:

a	Probabilidad
0	0,0310
1	0,1720
2	0,3440
3	0,3096
4	0,1253
5	0,0182
	1,0001

Ésta es la *distribución condicional* completa de los totales marginales observados, y, como es de esperar, las probabilidades suman la unidad. Nótese la importancia de trabajar con suficientes dígitos significativos en la primera probabilidad que se deba calcular; los cálculos anteriores se efectuaron con más decimales que los registrados, manteniendo en la calculadora cada probabilidad para el siguiente paso.

La tabla observada tiene una probabilidad igual a 0,1253. Para valorar su significación podríamos estimar en qué medida cae en la cola de la distribución, calculando la probabilidad de esta tabla o de una más extrema. Para un test unilateral, con este procedimiento se obtiene:

$$P = 0,1253 + 0,0182 = 0,1435$$

El resultado no es significativo, ni siquiera al nivel del 10%.

En un test bilateral se debe tener en cuenta la cola del otro extremo, y aquí se plantea cierta ambigüedad. Varios autores manifiestan que el valor de P de una cola se debería multiplicar por dos. En este ejemplo, la P de la prueba unilateral es igual a 0,1435, y la del test bilateral, a 0,2870. Una aproximación alternativa es calcular P como la probabilidad total de las tablas, en ambas colas, que sean como mínimo tan extremas como la observada, en el sentido de que tengan una probabilidad al menos tan pequeña. En este ejemplo deberíamos tener:

$$P = 0,1253 + 0,0182 + 0,0310 = 0,1745$$

Probablemente, es preferible el primer procedimiento, debido a que un resultado significativo se interpreta como un fuerte indicio de una diferencia *en la dirección observada* y tiene cierto mérito controlar la probabilidad debida al azar de un resultado como éste, no como la mitad del nivel de significación bilateral. Las tablas de Finney et al (1963) permiten efectuar tests de significación unilaterales con distintos niveles de significación, sin necesidad de hacer cálculos, siempre que las frecuencias no sean demasiado grandes.

Para calcular el valor de semi- P sólo se incluye la mitad de la probabilidad de la tabla observada, y así tenemos:

$$\text{semi-}P = 1/2 (0,1253) + 0,0182 = 0,0808$$

como valor unilateral; el valor bilateral puede obtenerse duplicando éste, lo que da 0,1617.

Los resultados de aplicar el test exacto en este ejemplo se pueden comparar con los obtenidos mediante el test de la χ^2 con la corrección de Yates. Encontramos que $X^2 = 2,39$ ($P = 0,12$) sin la corrección y $X_c^2 = 1,14$ ($P = 0,29$) al aplicarla. El nivel de probabilidad de 0,29 para X_c^2 coincide con el valor bilateral 0,29 del test exacto y el nivel de probabilidad de 0,12 para X^2 es una buena aproximación al valor exacto de semi- P de 0,16.

Cochran (1954) recomienda el uso del test exacto, prefiriéndolo al de la χ^2 con corrección de continuidad: a) si $N < 20$, o b) si $20 < N < 40$ y el valor esperado más pequeño es menor que 5. Con las calculadoras científicas modernas es mucho más fácil calcular el test exacto que antes, y se debería utilizar en cualquier tabla con un valor esperado menor de 5.

El test exacto y, por tanto, el test de la χ^2 con la corrección de Yates para la continuidad han sido criticados en los últimos 50 años con el fundamento de que son tests prudentes, en el sentido de que se encontrará un resultado significativo, por ejemplo al nivel del 5%, en menos del 5% de muestras hipotéticas, repetidas y elegidas al azar a partir de una población en la que la hipótesis nula es verdadera. Esta característica se explica en el apartado 4.7, destacándose que el problema es consecuencia de la naturaleza discreta de los datos y no ofrece dificultades si se señala el nivel preciso de P . Otras críticas se deben al hecho de que los

tests están condicionados por los márgenes observados, que con frecuencia no serían todos fijos. Así, en el ejemplo 4.14 podrían imaginarse repeticiones de muestreos en los que 20 lactantes alimentados con lactancia materna fueran comparados con 22 niños alimentados con biberón, pero en muchas de estas muestras el número de niños con dentaduras normales sería diferente de 5. Según el argumento condicional, cualquier inferencia acerca de la asociación entre la lactancia materna y las caries dentarias, debe hacerse dentro del contexto de que exactamente 5 niños tienen dentaduras normales. Si esta cifra hubiera sido distinta, la inferencia se habría hecho en este contexto diferente, pero esto no es aplicable a inferencias que pueden hacerse cuando hay 5 niños con dentaduras normales. Por consiguiente, no aceptamos los diversos argumentos propuestos para rechazar el test exacto basados en posibles muestras con totales diferentes en uno de los márgenes. Estas cuestiones fueron discutidas por Yates (1984) y en la discusión resultante, y por Barnard (1989) y Upton (1992), y no insistiremos en este punto. No obstante, el test exacto y el de la χ^2 corregido poseen la característica poco deseable de que el valor promedio del nivel de significación, cuando la hipótesis nula es verdadera, es superior a 0,5. El valor de semi- P evita este problema y, por lo tanto, es más adecuado cuando se combinan los resultados de varios estudios (v. apartado 4.7). En cuanto a una proporción única, el valor de semi- P corresponde a un test de la χ^2 no corregido, mientras que el valor exacto de P corresponde al test de la χ^2 corregido.

Los límites de confianza de la diferencia, la razón o la razón de probabilidad de dos proporciones basadas en los errores tipo obtenidos mediante las fórmulas (4.14), (4.17) y (4.19), respectivamente, son todos aproximados y se sospecharán los valores aproximados si una o más de las frecuencias de la tabla 2×2 son pequeñas. Se han propuesto varios métodos para obtener límites mejorados, pero todos ellos suponen interacciones y su ejecución con una calculadora es engorrosa. El caso de la razón de probabilidad es el más fácil. Aparte de los límites exactos, que requieren una cantidad excesiva de cálculos, los límites más satisfactorios son los de Cornfield (1956), véase el ejemplo 16.1, y los de Breslow y Day (1980, apartado 4.3) o los de Fleiss (1981, apartado 5.6). Koopman (1984) y Miettinen y Nurminen (1985) presentaron un método para la razón entre dos proporciones que puede programarse con bastante facilidad. El intervalo de confianza producido da una buena aproximación al coeficiente de confianza requerido, pero las dos probabilidades de las colas son desiguales a causa de la desviación. Gart y Nam (1988) propusieron una corrección de la desviación, pero su cálculo es pesado. Mee (1984) y Miettinen y Nurminen (1985) presentaron un método para la diferencia entre dos proporciones. Este método implica más cálculos que para los límites de la razón y, también en este caso, puede haber problemas a causa de la desviación (Gart y Nam, 1990).

4.10. Inferencias a partir de recuentos

Supongamos que x es un recuento, por ejemplo, del número de acontecimientos que ocurren durante un período de tiempo determinado o el número de objetos pequeños observados en una muestra biológica, asumiendo que se distribuyen según la distribución de Poisson con media μ (apartado 2.6). ¿Qué puede decirse acerca de μ ?

Supongamos, en primer lugar, que queremos contrastar una hipótesis nula que especifica que μ es igual a algún valor μ_0 . En esta hipótesis, x seguiría una distribución de Poisson

con esperanza μ_0 . La desviación de x con respecto al valor μ_0 se calcula según el grado en que x cae en las colas de la distribución hipotética. La situación es semejante a la de la distribución binomial (apartado 4.7). Por ello, si $x > \mu_0$ y las probabilidades de la distribución de Poisson son $P_0, P_1, \dots$, el valor de P de un test unilateral será:

$$\begin{aligned} P_r &= P_x + P_{x+1} + P_{x+2} + \dots \\ &= 1 - P_0 - P_1 - \dots - P_{x-1} \end{aligned}$$

Los métodos posibles para construir un test bilateral siguen los mismos principios que los del binomial comentados en el apartado 4.7.

Puede conseguirse también una simplificación considerable aproximando la distribución de Poisson a la normal (apartado 2.7). En la hipótesis nula, e incluyendo una corrección de continuidad,

$$z = \frac{|x - \mu_0| - \frac{1}{2}}{\sqrt{\mu_0}} \quad (4.26)$$

es aproximadamente una desviación normal estandarizada. La exclusión de la corrección de la continuidad corresponde al valor semi- P obtenido al incluir sólo $1/2 P_x$ en la suma de las probabilidades de Poisson.

Ejemplo 4.15

En un estudio realizado sobre trabajadores del asbesto, se siguió a un grupo numeroso durante varios años; 33 de ellos fallecieron por cáncer de pulmón. Teniendo en cuenta la edad, utilizando las tasas de mortalidad nacionales, el número esperado de muertes debidas a cáncer de pulmón fue 20,0. ¿Cuán fuertes son los indicios de que existe un exceso de muertes debidas a cáncer de pulmón?

Mediante la hipótesis nula, según la cual se aplicaron las tasas nacionales de mortalidad, el error tipo de x es $\sqrt{20,0} = 4,47$. La desviación observada es $33 - 20,0 = 13,0$. Aplicando la corrección de continuidad, la desviación normal estandarizada es $(13,0 - 0,5)/4,47 = 2,80$ y, por consiguiente, el área de una cola normal unilateral es 0,0026. El valor exacto unilateral de P , según la distribución de Poisson, es 0,0047 y, por lo tanto, el test normal exageró el grado de significación.

Los valores bilaterales pueden obtenerse multiplicando éstos por 2, y ambos métodos demuestran que los indicios de un exceso de mortalidad debida al cáncer de pulmón son contundentes.

El valor semi- P unilateral exacto es 0,0037 y la desviación normal estandarizada correspondiente es $13,0/4,47 = 2,91$; por consiguiente, el nivel unilateral es 0,0018.

Los límites de confianza del 95% de μ son dos valores μ_l y μ_u , para los cuales x es significativa en un test unilateral a nivel del 2,5%. Estos valores pueden obtenerse en las tablas de la distribución de Poisson (p. ej., Pearson y Hartley, 1966, tabla 7); Bailar y Ederer (1964) ofrecen una tabla de los factores de confianza. También se puede utilizar la tabla VIII de Fisher y Yates (1963).

- La aproximación normal se puede emplear de modo similar que en el caso binomial:
- 1. Las áreas de las colas se pueden estimar a partir de (4.26). Así, las aproximaciones para los límites del 95% se calculan con las fórmulas:

$$\frac{x - \mu_l - \frac{1}{2}}{\sqrt{\mu_l}} = 1,96$$

$$y \quad \frac{x - \mu_s + \frac{1}{2}}{\sqrt{\mu_s}} = -1,96$$

2. Si x es grande, en el método 1 se puede omitir la corrección de continuidad.
3. Sustituir $\sqrt{\mu_l}$ y $\sqrt{\mu_s}$ por $\sqrt{x}$. Esto sólo es válido para valores grandes (mayores que 100).

Los límites exactos se pueden calcular utilizando las tablas de la distribución de la χ^2 . Esto se deduce de las relaciones matemáticas que existen entre las distribuciones de Poisson y de χ^2 (v. Liddell, 1984). Los límites son:

$$y \quad \left. \begin{aligned} \mu_l &= \frac{1}{2} \chi^2_{2x, 0,975} \\ \mu_s &= \frac{1}{2} \chi^2_{2x+2, 0,025} \end{aligned} \right\} \quad (4.27)$$

Ejemplo 4.15 (continuación)

Con $x = 33$, se encuentra que los límites de confianza exactos del 95% son 22,7 y 46,3. El método 1 da 23,1 y 46,9; el método 2 23,5 y 46,3, y el método 3 21,7 y 44,3. En este ejemplo resultan adecuados los métodos 1 y 2. Los límites de confianza del 95% para la tasa de mortalidad relativa debida a cáncer de pulmón, expresados como la razón entre lo observado y lo esperado, son 22,7/20,0 y 46,3/20,0 = 1,14 y 2,32.

Los límites semi- P se obtienen con el método 2 y son 23,5/20,0 y 46,3/20,0 = 1,18 y 2,32.

Ejemplo 4.16

Como ejemplo en el que se deben calcular los límites exactos, supongamos que en una situación similar a la del ejemplo 4.15 se produjeron 2 muertes en comparación con una esperanza de 0,5. Entonces:

$$y \quad \begin{aligned} \mu_l &= \frac{1}{2} \chi^2_{4, 0,975} = 0,24 \\ \mu_s &= \frac{1}{2} \chi^2_{6, 0,025} = 7,22 \end{aligned}$$

Los límites de la razón de muertes observadas con respecto a las esperadas son 0,24/0,5 y 7,22/0,5 = 0,5 y 14,4. Los límites semi- P de μ pueden obtenerse mediante ensayo y error en una calculadora programable o en un ordenador personal, como los valores para los cuales $P(x=0) + P(x=1) + 1/2P(x=2) = 0,975$ o 0,025. Esto da $\mu_l = 0,335$ y $\mu_s = 6,61$, de modo que los límites semi- P de la razón entre las muertes observadas y las esperadas son 0,7 y 13,2. Los indicios a favor de una mortalidad excesiva son débiles, aunque los datos no excluyen la posibilidad de que la cifra observada sea excesiva.

Supóngase que en el ejemplo 4.16 no se han producido muertes; por lo tanto, el cálculo de un intervalo de confianza del 95% adolece de cierta ambigüedad. La estimación de un

punto de μ es cero y, como el límite inferior no puede ser superior a la estimación de un punto y tampoco puede ser negativo, su único valor posible es cero. Existe una probabilidad igual a cero de que el límite inferior sobrepase el valor verdadero de μ en lugar del valor nominal de 2,5% y una posibilidad consiste en calcular el límite superior como $\mu_s = 1/2 \chi^2_{2,0,05} = 3,00$, en lugar de $1/2 \chi^2_{2,0,025} = 3,69$; por lo tanto, la probabilidad de que el límite superior sea inferior al valor verdadero es aproximadamente 5%, y el intervalo tiene una cobertura aproximada del 95%. Esto es lógico y proporciona el intervalo de confianza del 95% más estrecho; sin embargo, parece preferible que el límite superior corresponda a 2,5% en la cola superior para obtener una interpretación uniforme. Resulta que el primer valor, $\mu = 3,00$, es el límite semi- P superior. Si bien es imposible encontrar un límite inferior con esta interpretación, resulta claro por el hecho de que el límite es igual a la estimación de un punto y de que ambos están en el extremo de los valores posibles. Este razonamiento es similar al de nuestra recomendación de que un nivel de significación bilateral debe ser el doble del nivel unilateral.

4.11. Comparación de dos recuentos

Supongamos que x_1 es un recuento que sigue la distribución de Poisson con media μ_1 . Del mismo modo, llamemos x_2 a un recuento que independientemente sigue la distribución de Poisson con media μ_2 . ¿Cómo podríamos contrastar la hipótesis nula $\mu_1 = \mu_2$?

Un método podría consistir en utilizar el hecho de que la variancia de $x_1 - x_2$ es $\mu_1 + \mu_2$ (en virtud de (2.16) y de (3.9)). La mejor estimación de $\mu_1 + \mu_2$, basándonos en la información de que disponemos, es $x_1 + x_2$. En la hipótesis nula, $E(x_1 - x_2) = \mu_1 - \mu_2 = 0$, y se puede considerar que $x_1 - x_2$ se distribuye según la ley normal, con la condición de que μ_1 y μ_2 no sean demasiado pequeños. De este modo:

$$z = \frac{x_1 - x_2}{\sqrt{x_1 + x_2}} \quad (4.28)$$

se puede considerar aproximadamente una desviación normal estandarizada.

En la prueba para comparar proporciones en un diseño para datos apareados ya se ha indicado un segundo método (apartado 4.8). De la frecuencia total $x_1 + x_2$, se observa, en la primera muestra, una porción x_1 . Escribiendo $r = x_1$ y $s = x_2$ en (4.11), tenemos:

$$z = \frac{x_1 - \frac{1}{2}(x_1 + x_2)}{\frac{1}{2}\sqrt{x_1 + x_2}} = \frac{x_1 - x_2}{\sqrt{x_1 + x_2}}$$

como en (4.28). Estos dos métodos conducen, por lo tanto, exactamente el mismo test.

Un tercer método utiliza un enfoque bastante distinto de la prueba χ^2 descrita para una tabla 2 x 2 en el apartado 4.9. Para cada frecuencia observada podemos considerar una frecuencia esperada en la hipótesis nula igual a $\frac{1}{2}(x_1 + x_2)$.

Observada	x_1	x_2
Esperada	$\frac{1}{2}(x_1 + x_2)$	$\frac{1}{2}(x_1 + x_2)$

Aplicando la fórmula habitual (4.20) para el estadístico χ^2 , tenemos:

$$\begin{aligned}
 X^2 &= \frac{[x_1 - \frac{1}{2}(x_1 + x_2)]^2}{\frac{1}{2}(x_1 + x_2)} + \frac{[x_2 - \frac{1}{2}(x_1 + x_2)]^2}{\frac{1}{2}(x_1 + x_2)} \\
 &= \frac{(x_1 - x_2)^2}{x_1 + x_2}
 \end{aligned}
 \tag{4.29}$$

A partir de un resultado general descrito en el apartado 4.20, X^2 sigue la distribución $\chi^2_{(1)}$, que ya conocemos como la distribución del cuadrado de una desviación normal estandarizada. En consecuencia, no resulta sorprendente que el X^2 calculado en (4.29) sea precisamente el cuadrado de la z obtenida en (4.28). El tercer método es equivalente a los otros dos y es útil para los cálculos, porque (4.29) no contiene ninguna raíz cuadrada.

Examinemos ahora un problema de estimación. ¿Qué puede decirse acerca de la relación μ_1/μ_2 ? El segundo método descrito se puede generalizar, cuando la hipótesis nula no es necesariamente cierta, diciendo que x_1 sigue una distribución binomial con parámetros $x_1 + x_2$ (la n del apartado 2.5) y $\mu_1/(\mu_1 + \mu_2)$ (la π del apartado 2.5). Los métodos del apartado 4.7 proporcionan así los límites de confianza para $\pi = \mu_1/(\mu_1 + \mu_2)$ y para μ_1/μ_2 , que es simplemente $\pi/(1 - \pi)$. Este método se ilustra en el ejemplo 4.17.

La diferencia $\mu_1 - \mu_2$ se estima con $x_1 - x_2$ y se puede aplicar la teoría normal como una aproximación, estimando el error tipo de $x_1 - x_2$ como en (4.28), mediante $\sqrt{(x_1 + x_2)}$.

Ejemplo 4.17

A un medio de cultivo se añadieron volúmenes iguales de dos cultivos bacterianos. Tras incubarlos, los números de colonias que crecieron en ambos medios fueron 13 y 31. Necesitamos conocer los límites de confianza de la razón de las concentraciones de los dos cultivos.

La razón estimada es $13/31 = 0,4194$. Según las tablas Geigy, una muestra binomial con 13 sucesos sobre 44 presenta los siguientes límites de confianza del 95% para π : 0,1676 y 0,4520. Calculando $\pi/(1 - \pi)$ para cada uno de estos límites, se obtienen los siguientes límites de confianza del 95% para μ_1/μ_2 :

$$0,1676/0,8324 = 0,2013$$

y

$$0,4520/0,5480 = 0,8248$$

Los límites semi- P para π , calculados exactamente como se describe en el apartado 4.7, son 0,1752 y 0,4418, lo cual da como resultado unos límites semi- P para μ_1/μ_2 de 0,2124 y 0,7915.

Cuando las frecuencias no son demasiado pequeñas, se pueden emplear las aproximaciones normales descritas en el apartado 4.7.

Ejemplo 4.18

Del mismo modo que en la distribución de una proporción, cuando n es grande y π pequeña, es una buena aproximación suponer que el número de sucesos r sigue la distribución de Poisson; luego la comparación de dos proporciones, en estas condiciones, se puede llevar a cabo utilizando los méto-

dos de este apartado. Supongamos, por ejemplo, que en un grupo de 1.000 varones, observado durante un año determinado, 20 presentan una enfermedad determinada, mientras que, en un segundo grupo de 500 varones, la enfermedad sólo ocurre en cuatro casos. ¿Existe una diferencia significativa entre estas dos proporciones? A esta pregunta se puede responder con los métodos descritos en el apartado 4.8. Como aproximación, podemos comparar la proporción observada de muertes en el grupo 2, $p = 4/24$, con una proporción teórica $\pi = 500/1.500 = 0,3333$. El test de la χ^2 equivalente sería el siguiente:

	Grupo 1	Grupo 2	Total
Casos observados	20	4	24
Casos esperados	$\frac{1000 \times 24}{1500} = 16$	$\frac{500 \times 24}{1500} = 8$	24

Con la corrección de continuidad

$$\begin{aligned} X_c^2 &= (3\frac{1}{2})^2/16 + (3\frac{1}{2})^2/8 \\ &= 0,766 + 1,531 \\ &= 2,30 \quad (P = 0,13) \end{aligned}$$

La diferencia no es significativa.

Sin la corrección de la continuidad, $X^2 = 3,00$ ($P = 0,083$).

Si se escribe el análisis completo de la tabla 2×2 , es evidente que dicho análisis abreviado difiere de la versión completa porque no tiene en cuenta las contribuciones a X^2 de los individuos no afectados. Como éstos son más numerosos que los casos, sus contribuciones a X^2 presentan denominadores grandes y, por consiguiente, se pueden omitir en comparación con los términos utilizados anteriormente. Queda claro, pues, que el método abreviado aquí descrito se debe usar sólo cuando las proporciones sean muy pequeñas.

Ejemplo 4.19

Consideremos una versión ligeramente distinta de la del ejemplo 4.18. Supóngase que los 20 casos del primer grupo se produjeron en el seguimiento de un gran grupo de varones durante un total de 1.000 varones-año, mientras que los cuatro casos del segundo grupo se produjeron en otro grupo numeroso seguido durante 500 varones-año. Individuos distintos pueden tener diferentes riesgos de padecer la enfermedad, pero si asumimos que cada hombre presenta un riesgo constante durante su período de observación y que la duración del seguimiento no está relacionada con los riesgos individuales, el número de casos en cada grupo seguirá aproximadamente la distribución de Poisson. Para contrastar la hipótesis nula, según la cual la media de riesgos por unidad de tiempo entre los dos grupos es igual, se puede aplicar el test de la χ^2 que aparece en el ejemplo 4.18.

Nótese, no obstante, que una diferencia significativa puede deberse a un error en las suposiciones. Una posibilidad es que el riesgo varíe con el tiempo y que las observaciones en un grupo se encuentren mucho más concentradas en los momentos de alto riesgo que en el caso del otro grupo; un ejemplo lo constituiría la comparación de muertes infantiles, en la que se podría observar un grupo durante un corto período de tiempo tras el nacimiento, cuando el riesgo es alto. Otra posibilidad es que las duraciones del seguimiento estén relacionadas con el riesgo individual. Supongamos, por ejemplo, que los individuos de alto riesgo se observaran durante períodos más prolongados que los individuos de bajo riesgo; el efecto sería un incremento del número de casos en aquel grupo.

En el capítulo 14 se presentan otros métodos para el análisis de datos de seguimiento.

4.12. Probabilidad y métodos bayesianos

Los métodos estadísticos descritos en este capítulo se basan en el concepto de la probabilidad relacionado con la frecuencia. Se han hecho constantes referencias a las muestras extraídas al azar de la misma población, y las probabilidades citadas en los tests de significación o los límites de confianza indicaban la frecuencia relativa de ciertos resultados (resultados «significativos» o la inclusión del valor de un parámetro en un intervalo de confianza) en una larga serie de estas repeticiones.

En el apartado 2.9 mencionamos otra aproximación, en la cual los valores numéricos asignados a probabilidades no se relacionaban necesariamente con el límite de las frecuencias y en las que se intentaba justificar el conocimiento previo mediante mediciones cuantitativas. Cualquier utilización sensible de la información estadística debe tener en cuenta el conocimiento y las valoraciones previas que hacen referencia a la credibilidad de varias hipótesis. En un experimento de adivinación de cartas realizado para investigar la percepción extrasensorial, por ejemplo, una puntuación en exceso de la esperanza debida al azar, que justo fuera significativa al nivel del 5% sería considerada por la mayoría de la gente de manera escéptica; muchos hubieran preferido pensar que el exceso era el resultado del azar (por no hablar de la posibilidad de la laxitud experimental) más que de una intervención de la telepatía o de la clarividencia. Por una parte, en un ensayo clínico efectuado para comparar un medicamento activo con un placebo, se habría aceptado ampliamente un resultado significativo similar como prueba del efecto del medicamento en la dirección observada, porque este tipo de hallazgos es muy frecuente. La cuestión planteada es si la experiencia previa se puede incorporar a la valoración cuantitativa de los datos estadísticos o si debería utilizarse de un modo más informal, junto al análisis estadístico.

Será útil desarrollar esta polémica, en los términos de un ejemplo relativamente simple. Llamemos a una distribución normal, como media μ y variancia σ^2 , $N(\mu, \sigma^2)$. Supóngase que observamos una variable aleatoria x , que sigue la distribución $N(\mu, 1)$ donde μ es desconocida. ¿Qué puede decirse sobre μ basándonos en la única observación x ? Los métodos estudiados en este capítulo nos conducirían a basar una prueba de significación en la desviación normal estandarizada $x - \mu$, y a calcular los límites de confianza tomando los percentiles normales estandarizados a cada lado de x (siendo los límites de confianza del 95% por ejemplo, $x \pm 1,960$).

Al comentar el teorema de Bayes en el apartado 2.8, indicamos que la probabilidad *a posteriori* de una hipótesis determinada se expresaba en términos de probabilidades y verosimilitudes *a priori*, siendo éstas las probabilidades de obtener los resultados observados en varias hipótesis alternativas. Como en este problema nos ocupamos de distribuciones continuas, debemos considerar las densidades de probabilidad y no las probabilidades. Las probabilidades de los distintos valores posibles de μ para una x observada se muestran en la figura 4.6. La curva, que muestra la *función de verosimilitud*, tiene exactamente la misma forma que una distribución normal de media x y variancia 1, pero no debería considerarse como una distribución de probabilidad, porque las ordenadas de cada valor representan una densidad de una distribución *diferente*.

Si las inferencias acerca de los parámetros se basan en el teorema de Bayes, la única forma de utilizar los valores observados de las variables aleatorias es por su situación en la función de verosimilitud. Además de utilizar las probabilidades *a priori*, existen argumentos




Fig. 4.6. Función de verosimilitud de una observación x de una distribución normal con variancia igual a la unidad. La verosimilitud de un valor particular de μ en el diagrama inferior es igual a la densidad de probabilidad de x de la distribución con media μ del diagrama superior.

sólidos para basar las inferencias en la función de verosimilitud. ¿Cómo se podría realizar esto? Una propuesta razonable sería tomar el valor del parámetro que tuviera la verosimilitud más alta de ser la «mejor» estimación de este parámetro. Éste es el método de la *verosimilitud máxima*, defendido y formulado por R. A. Fisher. Constituye el método general más útil de estimación estadística. En nuestro ejemplo, el valor de μ con mayor verosimilitud es (según la fig. 4.6) x , y deberíamos decir que x es la *estimación* (o *estimador*) de la *máxima verosimilitud* de μ .

En segundo lugar, para expresar una amplitud de posibles valores de μ alrededor de x , podríamos tomar todos aquellos valores cuya probabilidad no fuera menor que una fracción determinada de la verosimilitud máxima. Esta amplitud de intervalo dependería de la razón crítica. Por ejemplo, una razón igual a 0,146 incluiría valores de μ en un intervalo $x \pm 1,960$, que corresponde exactamente a nuestro intervalo de confianza del 95%. Con este cambio en la interpretación, llegamos a intervalos que tienen exactamente la misma forma que los intervalos de confianza.

Esta interpretación no hace referencia a las probabilidades *a priori*. Sabemos, por el teorema de Bayes (2.18), que las probabilidades *a priori* se transforman en probabilidades *a posteriori* por su interacción con las verosimilitudes. La distribución de probabilidades *a posteriori* dependerá, por consiguiente, de la elección de la distribución *a priori*. En nuestro ejemplo, se puede demostrar que si la distribución *a priori* de μ es $N(0, \sigma_0^2)$ la distribución *a posteriori*, tras observar el valor x , es:

$$N\left(\frac{x}{1 + 1/\sigma_0^2}, \frac{1}{1 + 1/\sigma_0^2}\right)$$

Veamos cómo depende esto de la elección de σ_0^2 . Si $\sigma_0^2 = 0$, significa que inicialmente estamos seguros de que $\mu = 0$. No resulta sorprendente que la media y la variancia de la distribución *a posteriori* sean, de manera similar, 0; nuestra certeza inicial no se ha modificado en modo alguno por la observación. En el otro extremo, el valor $\sigma_0^2 = \infty$ correspondería a un estado inicial de gran incertidumbre sobre μ . La distribución *a posteriori* es, en consecuencia, $N(x, 1)$. Esto es, precisamente, lo que representa la curva inferior de la figura 4.6 si la interpretamos, no como una función de verosimilitud, sino como una distribución de probabilidad. En este caso, el intervalo $x \pm 1.960$ podría considerarse como el que incluye el 95% de los valores centrales de la distribución *a posteriori*. Aquí tenemos, por consiguiente, otra interpretación del mismo resultado numérico.

La aplicación detallada de los métodos bayesianos a los problemas estadísticos corrientes se encuentra desarrollada en los dos tomos de Lindley (1965). En general, aunque no universalmente, se pueden establecer correspondencias entre los métodos bayesianos (con cambios apropiados en la interpretación) y los métodos corrientes de frecuencias, cuando se utiliza una distribución *a priori* adecuada y muy dispersa para indicar un estado de ignorancia inicial. Es interesante saber que la solución bayesiana al problema de comparar dos medias, cuando las variancias son distintas (apartado 4.4), la proporciona el test de Fisher-Behrens y no el de Welch. Una rama de la estadística en la que existen serias diferencias entre los planteamientos bayesianos y los no bayesianos es la del análisis secuencial, que se tratará en el capítulo 15.

En el siguiente apartado explicaremos brevemente algunas aplicaciones de los métodos bayesianos.

4.13. Otros métodos bayesianos

Reducción y predicción

En la explicación de la fórmula (4.30) señalamos que la media de la distribución *a posteriori* variaba entre cero (cuando la variancia *a priori* $\sigma_0^2 = 0$) y x (cuando $(\sigma_0^2 = \infty)$). En realidad, la media *a posteriori* está siempre dentro de estos límites. En otras palabras, el valor más probable de μ está reducido con respecto a la estimación de máxima verosimilitud x hacia la media *a priori* de cero. La magnitud proporcionada de la reducción depende de la razón entre la variancia *a priori* y la variancia de la función de verosimilitud.

De modo más general, pero considerando todavía una distribución *a priori* y una verosimilitud normales, podríamos sustituir x por la media $\bar{x}$ de una muestra de tamaño n , distribuida como $N(\mu, \sigma^2/n)$ (donde previamente teníamos $(\sigma^2/n = 1)$ y podríamos permitir que la distribución *a priori* de μ fuera $N(\mu_0, \sigma_0^2)$ (donde previamente teníamos $\mu_0 = 0$). Ahora, la distribución *a posteriori* de μ es:

$$N\left(\frac{\bar{x} + \mu_0 \sigma^2/n\sigma_0^2}{1 + \sigma^2/n\sigma_0^2}, \frac{\sigma^2/n}{1 + \sigma^2/n\sigma_0^2}\right) \quad (4.31)$$

Aquí hay que señalar dos puntos. Como antes, la media *a posteriori* está entre la estimación simple $\bar{x}$ y la media *a priori* μ_0 ; en otras palabras, la estimación se ha reducido hacia la media *a priori*. En segundo lugar, la reducción proporcionada será muy pequeña si n es muy grande (cuando los indicios a partir de los datos aplastan la información *a priori*) o si σ_0^2 es muy grande (cuando los indicios *a priori* son muy débiles). En cualquiera de estas situaciones, la distribución *a posteriori* estará centrada aproximadamente alrededor de la estimación familiar $\bar{x}$, con la variancia habitual σ^2/n .

Aunque estos resultados se refieren al caso específico de una distribución *a priori* normal y a una verosimilitud normal, se encuentran resultados normales con otras distribuciones, y el caso normal a menudo proporciona una buena aproximación para otras situaciones. Sin embargo, la reducción hacia la media *a priori* por lo general requiere una distribución *a priori* unimodal. Si la distribución *a priori* tuviera dos o más modas bien separadas, como podría ser el caso de algunos rasgos genéticos, la tendencia consistiría en reducirse hacia la moda mayor más próxima, lo cual podría ocurrir en sentido opuesto a la media *a priori* global.

Como ejemplo adicional de reducción, considérese el cálculo de la proporción de una población, π , a partir de una muestra elegida al azar de tamaño n en la cual r individuos son afectados de alguna manera. Los resultados del muestreo, que suponen la distribución binomial, fueron analizados en los apartados 2.5 y 3.3. En el método bayesiano necesitamos una distribución *a priori* para π . En este caso está claro que una distribución resulta inadecuada, ya que π debe encontrarse entre 0 y 1. La familia más práctica y flexible de distribuciones para este propósito es la de las distribuciones beta, la función de densidad de la que toma la forma:

$$f(\pi) = \text{constante} \times \pi^{r_0-1} (1 - \pi)^{n_0-r_0-1} \quad (4.32)$$

donde los dos parámetros r_0 y $n_0 - r_0$ deben ser positivos. La media de la distribución *a priori* es $\pi_0 = r_0/n_0$ y la variancia disminuye a medida que n_0 aumenta. Por lo tanto, la información *a priori* fuerte está representada por valores altos de n_0 .

Con (4.32) como distribución *a priori* y con $p = r/n$ como proporción observada de individuos afectados, la distribución *a posteriori* adquiere la misma forma que (4.32), sustituyendo r_0 y n_0 por $r + r_0$ y $n + n_0$, respectivamente. Por lo tanto, la media es:

$$\hat{\pi} = \frac{r + r_0}{n + n_0} \quad (4.33)$$

que se encuentra entre p y π_0 . Por consiguiente, la estimación de la proporción de la población se ha reducido con respecto a la estimación de la muestra, p , hacia la media *a priori*, π_0 . Para indicios *a priori* muy débiles y una muestra grande (n_0 pequeña, n grande), la estimación *a posteriori* tendrá un valor muy cercano a la proporción de la muestra, p . Para indicios *a priori* fuertes y una muestra pequeña (n_0 grande, n pequeña), la estimación tendrá un valor cercano a la media *a priori*, π_0 .

Veamos ahora el problema que existe para predecir los resultados de una muestra futura elegida al azar a partir de la misma población de la que se extrajo la muestra actual. En el primer caso examinado anteriormente, de una distribución *a priori* normal y una distribución normal para los datos, supóngase que la muestra futura tenga un tamaño n_f y representemos

la media desconocida de esta muestra por $\bar{x}_1$. Si conociéramos el valor de μ , la distribución de $\bar{x}_1$ sería $N(\mu, \sigma^2/n_1)$. En realidad, μ es desconocida, pero su distribución *a posteriori* está dada por la fórmula (4.31). La distribución global de $\bar{x}_1$ se obtiene al generar la distribución del muestreo, con una variancia σ^2/n_1 , para cada valor de μ en la distribución *a posteriori*. El resultado es una distribución normal con la misma media que en la fórmula (4.31), pero con una variancia aumentada con respecto a la de (4.31) en una cantidad σ^2/n_1 . En la situación simple de indicios *a priori* muy débiles o de una muestra inicial muy grande (σ_0^2 o n muy grande), la distribución predictiva de $\bar{x}_1$ se convierte en:

$$N\left[\bar{x}, \sigma^2\left(\frac{1}{n} + \frac{1}{n_1}\right)\right]$$

Esto expresa de manera eficaz que, en ausencia de conocimientos previos, la mejor estimación en x_1 es x , que la variación de x_1 alrededor de x es esencialmente la misma que la diferencia entre las dos estimaciones y que la variancia de esta diferencia es la suma de las variancias por separado. Las distribuciones predictivas bayesianas pueden ser de utilidad en situaciones en las que los investigadores no están seguros de efectuar más observaciones y desean predecir el intervalo probable de error de tales observaciones. Desde luego, una suposición importante es que la muestra futura, en caso de ser extraída, provendría de la misma distribución que la ya observada y, a menudo, la validez de esta suposición se pondría en duda. Para una descripción del empleo de las distribuciones predictivas en ensayos clínicos, véanse, por ejemplo, Spiegelhalter et al (1986).

El fenómeno de la reducción, descrito anteriormente, está relacionado estrechamente con el de la *regresión con respecto a la media*, que desde hace muchas décadas es familiar para los epidemiólogos y otros científicos. Esto se explicará en el contexto de la regresión en el apartado 5.5.

Al considerar el empleo de métodos bayesianos, la cuestión crucial que se ha de tener en cuenta es si la especificación formal de una distribución *a priori* refleja adecuadamente la incertidumbre del usuario acerca de los parámetros en estudio. En la estimación de la proporción de una población, en que podría haber datos aplicables de estudios anteriores, no ha de asumirse que deban emplearse automáticamente para n_0 y r_0 en (4.33) el tamaño y la muestra y el número de individuos afectados previos. El estudio previo puede haberse llevado a cabo en circunstancias diferentes y en una población distinta en aspectos importantes de la población actual, y es posible que su conexión precisa sea difícil de determinar. En la investigación científica es preferible presentar los resultados de cada estudio de la forma más objetiva posible, sin suposiciones previas, pero aprovechando las oportunidades que aparezcan para comparar los resultados con datos anteriores y, si es conveniente, combinar los resultados de diferentes estudios (v. apartados 6.5 y 7.2).

Hay otras situaciones en las que los investigadores pueden introducir sus opiniones mediante una distribución *a priori* subjetiva. Estas situaciones se plantean en particular cuando hay que tomar decisiones, por ejemplo, sobre la continuación de cierta línea de investigación. Aunque no necesariamente hay que utilizar la teoría de las decisiones formales (a la que se hace referencia en el apartado 2.8), será adecuado no sólo aplicar el estudio más reciente en que se haya tratado esta cuestión, sino también formarse un juicio con todos los demás conocimientos relacionados. Los métodos bayesianos pueden aportar un útil método de síntesis.

Métodos bayesianos empíricos

Hay muchas situaciones en las que se dispone de estadísticas para cada uno de los grupos que comparten alguna característica común. Los resultados pueden diferir de un grupo a otro, pero las características comunes sugieren que la información obtenida a partir de todo el conjunto de datos está relacionada con las inferencias de cualquier grupo determinado, como suplemento para la estadística específica de dicho grupo. Los siguientes son algunos ejemplos:

1. Las mediciones de pruebas bioquímicas en pacientes con un diagnóstico específico. Las mediciones repetidas en un paciente determinado pueden fluctuar y, por lo tanto, su media está sujeta a errores de muestreo, pero los resultados provenientes de todo el conjunto de datos muestran el nivel medio de dicho paciente.
2. Las pruebas de detección biológica efectuadas en una gran cantidad de sustancias para detectar una posible actividad farmacológica. Los resultados de las pruebas en una sustancia determinada están sujetos a errores aleatorios, pero de nuevo el conjunto total de datos proporciona indicios sobre la distribución de los niveles medios de actividad.
3. Las tasas de mortalidad o morbilidad en un gran número de regiones pequeñas, cada una de las cuales está sujeta a un error aleatorio. En este caso también se proporciona información relacionada con una región específica por la distribución de las tasas del conjunto total de datos o, al menos, para un subconjunto de regiones adyacentes.

En este tipo de estudios parece razonable que los resultados del grupo específico (paciente, sustancia o región, en los ejemplos anteriores) se consideren extraídos de la misma distribución *a priori* que en los demás grupos, a menos que haya características diferenciadas que hagan que esta suposición sea poco razonable (como una forma especial de enfermedad en 1 o una propiedad química importante en 2). La probabilidad que ha de emplearse en el teorema de Bayes dependerá de la forma específica de datos observados en un grupo determinado y, a menudo, se deducirá de resultados estándar de medias, proporciones, recuentos, etc. La distribución *a priori* plantea mayor dificultad porque está relacionada con los valores «verdaderos» de los parámetros de grupos diferentes y éstos sólo pueden ser estimados. En 3, por ejemplo, la tasa de mortalidad «verdadera» de una región determinada sólo podrá estimarse a partir de la tasa observada. La variabilidad de las observadas será siempre superior a la de las tasas verdaderas, a causa de los errores de muestreo adicionales que afectan a aquéllas.

El objetivo de los métodos bayesianos empíricos consiste en estimar la distribución *a priori* a partir de los datos observados, mediante el ajuste de los errores de muestreo y, a continuación, usar el teorema de Bayes para estimar el parámetro pertinente en un grupo determinado. El efecto general, como en el análisis previo, consiste en reducir las estimaciones a partir de las obtenidas de ese grupo específico hacia aquellas adecuadas para todo el conjunto de datos. Como antes, la reducción proporcionada depende de las magnitudes relativas de la variación entre grupos y del error de muestreo del grupo en cuestión. En 3, por ejemplo, una región muy pequeña sin casos observados puede tener una estimación ajustada de la tasa considerablemente superior a cero, a causa de la verosimilitud de que la tasa de cero observada sea una fluctuación de muestreo a la baja. Una región grande con una tasa elevada basada en una muestra grande tendría un ajuste a la baja, pero éste sería relativamente pequeño porque la verosimilitud desempeñaría un papel dominante en el teorema de Bayes. Algunos ejemplos de estimaciones bayesianas empíricas de tasas regionales son descritas por Clayton y Kaldor (1987) y por Marshall (1991). Breslow (1990) ofrece un útil estudio de métodos bayesianos empíricos y otros métodos bayesianos en diversas aplicaciones médicas.

Capítulo 5

Regresión y correlación

5.1. Asociación

En capítulos anteriores hemos tratado el análisis estadístico de las observaciones de una sola variable. En algunos problemas los datos se dividían en dos grupos y se podía considerar que la dicotomía definía una segunda variable. Estos problemas de dos muestras son, sin embargo, ejemplos muy artificiales de una relación entre dos variables.

En este capítulo examinaremos de un modo más general la asociación entre dos variables cuantitativas. Nos centraremos en las situaciones en que la tendencia general es lineal, es decir, a medida que una variable cambia, la otra variable sigue en *promedio* una tendencia que puede representarse, aproximadamente, por una línea recta. En los capítulos 9 y 10 se analizarán situaciones más complejas.

La técnica gráfica básica para representar situaciones con dos variables es el *diagrama de puntos*. Resulta práctico representar los datos de este modo antes de intentar cualquier análisis numérico. En la figura 5.1 se ilustra un ejemplo. En general, los datos hacen referencia a un número de *individuos*, cada uno de los cuales proporciona observaciones de ambas variables. En el diagrama de puntos, cada variable se representa en uno de los ejes de coordenadas y, en consecuencia, cada individuo define un punto cuyas coordenadas constituyen los valores observados de las dos variables. En la figura 5.1 los individuos son ciudades, y las dos variables son la tasa de mortalidad infantil y un índice de superpoblación determinado.

El diagrama de puntos ofrece una ilustración compacta de la distribución de cada variable y de la relación que existe entre ambas. El análisis estadístico posterior sirve para varios fines. En primer lugar, proporciona medidas numéricas de algunas de las características básicas de la relación, del mismo modo que la media y la desviación tipo ofrecen medidas concisas de las características más importantes de la distribución de una variable. En segundo lugar, el investigador puede desear predecir el valor de una variable cuando se conoce el valor de la otra variable. En general será imposible predecirlo con completa seguridad, pero podemos esperar decir algo acerca del valor medio y de la variabilidad de la variable medida. Por ejemplo, en la figura 5.1 parece que una ciudad con 0,6 personas por habitación tenía la probabilidad en 1961, de una tasa de mortalidad infantil de aproximadamente 20 por cada 1.000 nacimientos vivos como promedio, con una amplitud probable entre 14 y 26. Es de esperar que un análisis más preciso proporcione cifras más fidedignas que estas estimaciones aproximadas.

En tercer lugar, el investigador podría desear valorar la significación de la dirección de una tendencia aparente. Por ejemplo, basándose en la figura 5.1, ¿podría afirmarse con seguridad que la mortalidad infantil aumenta en promedio a medida que se incrementa el índice de superpoblación, o la tendencia aparente en esta dirección podría haberse presentado simplemente por azar?




Fig. 5.1. Diagrama de puntos que muestra el número medio de individuos por habitación y la mortalidad infantil por cada 1.000 nacidos vivos en los 83 municipios de Inglaterra y del País de Gales en 1961.

Otro propósito podría ser corregir las mediciones de una variable por el efecto de otra variable. En un estudio sobre el volumen espiratorio forzado (FEV) en trabajadores de la industria del cadmio que habían estado expuestos durante un número determinado de años a los vapores de dicho metal, se comparó su FEV con el de otros trabajadores no expuestos. El FEV medio del primer grupo fue menor que el del segundo. Sin embargo, los individuos del primer grupo eran mayores que los del segundo y el FEV tiende a disminuir con la edad. La cuestión que se plantea es si la diferencia en el FEV medio podría explicarse simplemente por la diferencia de edad. Para responder este interrogante, se debe estudiar con más detalle la relación entre el FEV y la edad. El método se describirá en el apartado 9.5.

Debemos ser cuidadosos en la distinción entre *asociación* y *causalidad*. Dos variables están asociadas si la distribución de una es afectada por un conocimiento del valor de la otra. Esto no significa que una variable sea la *causa* de la otra. Existe una fuerte asociación entre el número absoluto de divorcios en el Reino Unido durante la primera mitad de este siglo y la cantidad de tabaco importado (siendo en este caso los «individuos» en el diagrama de puntos, los años. De ello no se concluye que el tabaco sea una causa importante de descontento marital ni que aquellos cuyos matrimonios se han roto adquieran el hábito tabáquico por consuelo. Asociación no implica causalidad.

Una distinción adicional se establece en las situaciones en que ambas variables se pueden considerar aleatorias y en que los individuos se seleccionan al azar o, al menos, sin hacer referencia a los valores de cada variable, y las situaciones en que el investigador selecciona deliberadamente los valores de una variable. Un ejemplo de la primera situación lo constituye un estudio sobre la relación entre la estatura y la presión arterial de los escolares, en el que los individuos se restringen a un sexo y a un grupo de edad. En este caso es posible que la muestra no se haya extraído estrictamente al azar, sino que se la considere aproximadamente representativa de una población de niños de esta edad y sexo, de la misma región y del mismo tipo de escuela. Un ejemplo de la segunda situación lo constituye un estudio sobre el crecimiento de los niños entre ciertas edades. La naturaleza de la relación entre la estatura y la edad, que se reflejaría en un diagrama de puntos, dependería mucho del intervalo de edades elegido y de la distribución de edades dentro de él. Volveremos a este punto en el apartado 5.3.

5.2. Regresión lineal

Supóngase que efectuamos observaciones sobre las variables x e y para cada uno de los individuos de un grupo grande y que estamos interesados en la forma en que y cambia en promedio a medida que x toma diferentes valores. Si es apropiado considerar y una variable aleatoria para cualquier valor dado de x , podemos preguntarnos de qué modo la esperanza de y cambia con x . La distribución de probabilidad de y cuando x es conocida se denomina *distribución condicionada*, y la esperanza condicionada se representa por $E(y | x)$. En este momento no hacemos suposición alguna con respecto a si x es una variable aleatoria o no. En un estudio sobre estaturas y presiones arteriales efectuado en individuos elegidos al azar, ambas variables serían aleatorias; si x e y fueran, respectivamente, la edad y la altura de los niños seleccionados de acuerdo con la edad, sólo y sería aleatoria.

La esperanza condicionada, $E(y | x)$, depende en general de x . Esta dependencia se denomina *función de regresión* de y sobre x . Si $E(y | x)$ se representa mediante una función de x , forma la *curva de regresión*. En la figura 5.2 se ilustran dos ejemplos. La regresión de la figura 5.2*b* difiere en dos aspectos de la regresión de la figura 5.2*a*. La curva de b es una línea recta: la *recta de regresión* de y sobre x . En segundo lugar, la variación de y con respecto a x fija, es constante en b , mientras que en a la variación cambia a medida que x aumenta. La regresión en b se denomina *homocedástica*, y en a , *heterocedástica*.

La situación representada en la figura 5.2*b* es importante no sólo a causa de su simplicidad sino también porque en la labor científica se presentan con frecuencia regresiones que son aproximadamente lineales y homocedásticas. En la presente discusión debemos realizar una suposición adicional: la distribución de y para una x determinada es normal.

Por consiguiente, el modelo se puede describir diciendo que para una x dada, y sigue una distribución normal con media:

$$E(y | x) = a + \beta x$$

(la ecuación general de una línea recta) y variancia σ^2 (una constante). Un conjunto de datos consiste en n pares de observaciones que se representan por $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, sien-




Fig. 5.2. Dos curvas de regresión de y sobre x . *a*: no lineal y heterocedástica. *b*: lineal y homocedástica. Las distribuciones ilustradas representan las de los valores de y para ciertos valores de x .

do cada y_i una observación independiente de la distribución $N(\alpha + \beta x_i, \sigma^2)$. ¿Cómo podríamos estimar los parámetros α , β y σ^2 que caracterizan el modelo?

Argumentos teóricos* conducen a la siguiente regla: α y β se obtienen mediante estimadores de «mínimos cuadrados», a y b , cantidades que minimizan la suma de cuadrados *residual*, $\sum (y_i - Y_i)^2$, donde Y_i se obtiene mediante la ecuación de regresión estimada:

$$Y_i = a + bx_i \quad (5.1)$$

Ésta es, intuitivamente, una propuesta atractiva. La recta de regresión se traza a través de los n puntos del diagrama de puntos de forma que minimice la suma de cuadrados de las distancias, $y_i - Y_i$, de los puntos con respecto a la recta; estas distancias se miden paralelas al eje y (fig. 5.3).

Mediante cálculos elementales se puede demostrar que a y b están dados por las fórmulas:

$$a = \bar{y} - b\bar{x} \quad (5.2)$$

$$b = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \quad (5.3)$$

Una comprobación sencilla es la siguiente. Nótese en primer lugar que para cada n números $p_1, p_2, \dots, p_n$ la cantidad P que minimiza $\sum (p_i - P)^2$ es $P = \bar{p}$. Para demostrar esto último, nótese que, para cada P :

$$\sum (p_i - P)^2 = \sum (p_i - \bar{p})^2 + n(\bar{p} - P)^2 \quad (5.4)$$

* Los estimadores de «mínimos cuadrados» de α y β también son los estimadores de máxima verosimilitud (v. apartado 4.12); además, entre todos los estimadores no sesgados, éstos tienen los errores tipo más pequeños.




Fig. 5.3. Recta de regresión lineal ajustada por mínimos cuadrados que muestra una desviación tipo entre un valor observado y_i y el valor Y_i dado por la recta de regresión.

[como puede demostrarse desarrollando $(p_i - P)^2$ como $[(p_i - \bar{p}) + (\bar{p} - P)]^2$]. El miembro derecho de 5.4 es un mínimo cuando el segundo término es cero, es decir, cuando $P = \bar{p}$.

Ahora consideremos $S = \sum (y_i - Y_i)^2 = \sum (y_i - a - bx_i)^2$. Para cada valor de b , el S mínimo aparece cuando:

$$a = \sum (y_i - bx_i) / n$$

(a partir del resultado precedente con $p_i = y_i - bx_i$): es decir,

$$a = (\bar{y} - b\bar{x})$$

como en (5.2). La recta de regresión puede expresarse como:

$$\begin{aligned} Y_i &= a + bx_i \\ &= \bar{y} + b(x_i - \bar{x}) \end{aligned} \quad (5.5)$$

de lo que se deduce que la recta pasa a través el punto $(\bar{x}, \bar{y})$.

Ahora debemos encontrar el valor b que minimiza:

$$\begin{aligned}
 S &= \sum [y_i - \bar{y} - b(x_i - \bar{x})]^2 \\
 &= \sum (x - \bar{x})^2 \left[b - \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2} \right]^2 + \sum (y - \bar{y})^2 - \frac{[\sum (x - \bar{x})(y - \bar{y})]^2}{\sum (x - \bar{x})^2} \quad (5.6)
 \end{aligned}$$

como puede verse multiplicando el término derecho. (Se ha eliminado el sufijo i por conveniencia). El segundo y el tercer términos de (5.6) no incluyen b . El primer término es una suma de cuadrados y no puede ser negativo; sin embargo, vale cero cuando:

$$b = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2}$$

que representa, por consiguiente, el valor de b requerido, como en (5.3).

Nótese que el valor mínimo de S está dado por los dos últimos términos de 5.6, a saber:

$$\sum (y - \bar{y})^2 - \frac{[\sum (x - \bar{x})(y - \bar{y})]^2}{\sum (x - \bar{x})^2} \quad (5.7)$$

Finalmente, puede demostrarse que un estimador no sesgado de σ^2 es

$$s_0^2 = \frac{\sum (y - Y)^2}{n - 2} \quad (5.8)$$

la suma de cuadrados residual, con $\sum (y - Y)^2$ obteniéndose de (5.7). El divisor $n - 2$ también se denomina muchas veces grados de libertad residuales; s_0^2 la *media cuadrática residual* y, s_0 , la *desviación tipo alrededor de la regresión*.

Las cantidades a y b se denominan *coeficientes de regresión*; este término suele utilizarse especialmente para b , la pendiente de la recta de regresión.

La expresión del numerador de (5.3) es la suma de productos de las desviaciones de x e y alrededor de sus medias. Una fórmula abreviada análoga de (1.3) es útil para la labor de cálculo. Con un argumento similar al utilizado para derivar (1.3), encontramos:

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n} \quad (5.9)$$

Obsérvese que una suma de cuadrados alrededor de la media debe ser positiva o cero, mientras que una suma de productos de las desviaciones alrededor de la media puede ser negativa, en cuyo caso, según (5.3), b también será negativo.

La teoría anterior se ilustra en el siguiente ejemplo, que también se empleará posteriormente después de tratar otros puntos. Todos los cálculos necesarios en una regresión lineal simple son factibles con el empleo de una calculadora científica, pero en la actualidad lo más habitual es usar un programa estadístico en un ordenador o una calculadora con teclas para ajustar una regresión, por lo que los cálculos reales no serían una preocupación.

Ejemplo 5.1

La tabla 5.1 proporciona los valores del peso al nacer x y del aumento de peso entre los días 70 y 100 de vida y , expresado como porcentaje del peso al nacer para 32 bebés. En la figura 5.4 se presenta un

Tabla 5.1. Pesos de 32 bebés al nacer y sus aumentos de peso entre los días 70 y 100 después del nacimiento expresados como porcentajes de los pesos al nacer

x , peso al nacer (oz.)	y , aumento de peso, días 70-100 (como % de x)
72	68
112	63
111	66
107	72
119	52
92	75
126	76
80	118
81	120
84	114
115	29
118	42
128	48
128	50
123	69
116	59
125	27
126	60
122	71
126	88
127	63
86	88
142	53
132	50
87	111
123	59
133	76
106	72
103	90
118	68
114	93
94	91

diagrama de puntos que sugiere la existencia de una asociación en sentido negativo entre las dos variables. Ello parece bastante verosímil: cuando el peso al nacer es bajo, cabría esperar que la velocidad de crecimiento consiguiente, *relativa al peso en el nacimiento*, fuera alta, y viceversa. La tendencia parece ser razonablemente lineal.

A partir de la tabla 5.1, procedemos del siguiente modo:

$$\begin{array}{lll}
 n = 32 & \sum x = 3576 & \sum y = 2281 \\
 & \bar{x} = 3576/32 & \bar{y} = 2281/32 \\
 & = 111,75 & = 71,28 \\
 \\
 \sum x^2 = 409.880 & \sum xy = 246.032 & \sum y^2 = 179.761 \\
 (\sum x)^2/n = 399.618,00 & (\sum x)(\sum y)/n = 254.901,75 & (\sum y)^2/n = 162.592,53 \\
 \sum (x - \bar{x})^2 = 10.262,00 & \sum (x - \bar{x})(y - \bar{y}) = -8869,75 & \sum (y - \bar{y})^2 = 17.168,47
 \end{array}$$

Para predecir el incremento de peso a partir del peso al nacer se necesita la regresión de y sobre x .

$$b = - \frac{8\,869,75}{10\,262,00} \\ = -0,8643$$

La ecuación de la recta de regresión es, según 5.5:

$$Y = 71,28 - 0,8643(x - 111,75) \\ = 167,87 - 0,8643x$$

Para trazar la línea, son suficientes las coordenadas de dos puntos, pero es más seguro calcular tres. Tomando $x = 80, 100$ y 140 como números redondeados adecuados que caen dentro de los límites de x utilizados en la figura 5.4, encontramos:

x	Y
80	98,73
100	81,44
140	46,87

A continuación se traza la recta de regresión que pasa por los tres puntos con estas coordenadas, presentada en la figura 5.4.

Nótese que cuando x cambia desde 80 hasta 120 (es decir, por un factor $3/2$), y cambia en promedio desde 100 hasta 65 (es decir, por un factor de alrededor de $2/3$).

Según la definición de y , esto implica que el aumento *absoluto* de peso es independiente de x .

En las situaciones en que x e y son variables aleatorias puede ser útil considerar la regresión de x sobre y . Esto muestra que el valor medio de x , para una y determinada, cambia con los valores de y .

La recta de regresión de x sobre y se puede calcular mediante fórmulas análogas a las ya utilizadas, intercambiando x e y . Para evitar confusiones entre las dos rectas, será útil escribir la ecuación de regresión de y sobre x como

$$Y = \bar{y} + b_{y,x}(x - \bar{x})$$

con $b_{y,x}$, obtenida con (5.3). La ecuación de regresión de x sobre y es entonces:

$$X = \bar{x} + b_{x,y}(y - \bar{y})$$

con:

$$b_{x,y} = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (y - \bar{y})^2}$$

En la figura 5.4 se puede apreciar que ambas rectas son, en general, distintas. Ambas pasan por el punto $(\bar{x}, \bar{y})$ que, por consiguiente, constituye su punto de intersección. En el ejem-




Fig. 5.4. Diagrama de puntos que ilustra el peso al nacer, x , y el incremento de peso entre los días 70 y 100, como porcentaje de x , en 32 niños, con las dos rectas de regresión (tabla 5.1.).

plo 5.1 deberíamos interesarnos en principio en la regresión de y sobre x , dado que sería natural estudiar el modo en que los cambios de peso varían con el peso al nacer e investigar la distribución de dichos cambios para un valor determinado, y no la distribución de los pesos al nacer para un determinado cambio de peso. En algunas circunstancias, ambas regresiones pueden tener interés.

5.3. Correlación

Cuando tanto x como y son variables aleatorias puede ser útil tener una medida de la intensidad con que la relación entre ambas variables se aproxima a la situación extrema en la que cada punto del diagrama de puntos cae exactamente en una línea recta. Este índice lo proporciona el *coeficiente de correlación del producto-momento* (o, simplemente, *coeficiente de correlación*), definido por:

$$r = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{[\sum (x - \bar{x})^2 \sum (y - \bar{y})^2]}} \quad (5.10)$$

Se puede demostrar que, para cualquier conjunto de datos, r se encuentra entre los límites de -1 y $+1$. La figura 5.5 muestra cinco conjuntos de datos en los que la variación en x y en y permanece aproximadamente constante de un conjunto a otro. Las marcadas diferencias entre los cinco diagramas de puntos están resumidas por los valores de r . En la figura 5.5, a y e son ejemplos de una correlación perfecta en la que el valor de y está determinado *exactamente* como una función lineal de x . Los puntos se encuentran exactamente sobre una línea recta; si ambas variables aumentan al mismo tiempo, como en a , $r = +1$, mientras que si una variable disminuye a medida que la otra aumenta, como en e , $r = -1$. En ambos casos, las dos rectas de regresión coinciden. La figura 5.5c representa una situación muy diferente, en la que $r = 0$. Los dos coeficientes de regresión $b_{y,x}$ y $b_{x,y}$ también son iguales a cero y las rectas de regresión son perpendiculares. En b , donde $0 < r < 1$, y en d , donde $-1 < r < 0$, se ilustran situaciones intermedias.

En este caso, las dos rectas de regresión se disponen formando un ángulo, pero apuntan en la misma dirección.

Una fórmula más adecuada para el cálculo del coeficiente de correlación a partir de la fórmula abreviada para la suma de cuadrados y producto es:

$$r = \frac{\sum xy - (\sum x)(\sum y)/n}{\sqrt{[\sum x^2 - (\sum x)^2/n][\sum y^2 - (\sum y)^2/n]}} \quad (5.11)$$

Según 5.7, la suma de cuadrados de y alrededor de la recta de regresión de y sobre x es:

$$\sum (y - \bar{y})^2 \left\{ 1 - \frac{[\sum (x - \bar{x})(y - \bar{y})]^2}{\sum (x - \bar{x})^2 \sum (y - \bar{y})^2} \right\} = \sum (y - \bar{y})^2 \times (1 - r^2) \quad (5.12)$$

Ello proporciona una interpretación útil del valor numérico de r . El coeficiente de correlación al cuadrado es la fracción por la cual la suma de cuadrados de y se reduce para dar la suma de cuadrados de las desviaciones con respecto a su regresión sobre x . El mismo resultado es cierto si x y y se intercambian en (5.12). En la figura 5.5a y e , $r^2 = 1$, y (5.12) se iguala a cero. En c , $r^2 = 0$ y no se afecta la suma de cuadrados de cada variable por la regresión sobre la otra. En b y d se producen algunas reducciones porque $0 < r^2 < 1$.

También pueden deducirse fácilmente otras dos fórmulas a partir de las de los coeficientes de regresión y correlación:

$$y \quad \left. \begin{aligned} b_{y,x} &= r \frac{s_y}{s_x} \\ b_{x,y} &= r \frac{s_x}{s_y} \end{aligned} \right\} \quad (5.13)$$

donde s_x y s_y son las desviaciones tipo muestrales de x e y . Se verifica que:

$$b_{y,x} b_{x,y} = r^2$$




Fig. 5.5. Cinco diagramas de puntos con las rectas de regresión que ilustran diferentes valores del coeficiente de correlación. a: $r = 1$; b: $0 < r < 1$; c: $r = 0$; d: $-1 < r < 0$; e: $r = -1$.

El coeficiente de correlación ha desempeñado un papel importante en la historia de los métodos estadísticos. Actualmente, tiene mucho menos valor que los coeficientes de regresión. Si dos variables están correlacionadas, generalmente es mucho más útil estudiar las posiciones de una o de las dos rectas de regresión, lo cual permite predecir una variable en términos de la otra, en lugar de resumir el grado de correlación con un índice sencillo.

Es especialmente importante el hecho de que la validez del coeficiente de correlación se restringe cuando ambas variables se observan en una selección aleatoria de individuos. Si se efectúa una selección a partir de una gran población de individuos, restringiendo los valores de una variable, por ejemplo x , a un intervalo limitado, el valor absoluto del coeficiente de correlación tenderá a disminuir. Por ejemplo, en los datos de la figura 5.4, los coeficientes de correlación calculados en los subgrupos de los datos obtenidos, limitando la amplitud de los valores de x , son los siguientes:

	Amplitud de x		Número de observaciones	Coeficiente de correlación
	Límite superior	Límite inferior		
Todos los datos	70	150	32	-0,668
Subgrupos	85	135	27	-0,565
	100	120	11	-0,578
	105	115	6	-0,325

Por el contrario, si el estudio se limita a los individuos con valores extremos de x (incluyendo tanto los valores altos como los bajos), el valor absoluto del coeficiente de correlación tenderá a aumentar. Por ejemplo, si centramos la atención en los individuos cuyo peso al nacer fue inferior a 100 oz (= 2,834 kg.) o mayor que 125 oz (= 3,542 kg.), el coeficiente de correlación resultante es -0,735.

La interpretación del valor numérico de un coeficiente de correlación calculado a partir de los datos seleccionados por los valores de una variable resulta entonces muy difícil.

5.4. Errores de muestreo en la regresión y en la correlación

Supóngase que en el modelo de regresión del apartado 5.2 se generan conjuntos repetidos de datos, cada uno de ellos con los mismos n valores de x , pero con valores de y que varían al azar. Los estadísticos $\bar{y}$, a y b variarán de un conjunto de datos a otro. Sus variancias muestrales se obtienen del siguiente modo:

$$\text{Var}(\bar{y}) = \sigma^2/n \quad (5.14)$$

utilizando un argumento similar al del apartado 3.2. Nótese que aquí σ^2 es la variancia de y para la x fija no, como en (3.1), la variancia total de y .

$$\text{Var}(b) = \text{Var} \left[\frac{\sum y(x - \bar{x})}{\sum (x - \bar{x})^2} \right]$$

[dado que $\sum (x - \bar{x})(y - \bar{y}) = \sum (x - \bar{x})y$, los términos restantes desaparecen],

$$\begin{aligned} &= \frac{1}{[\sum (x - \bar{x})^2]^2} \sum (x - \bar{x})^2 \text{Var}(y) \\ &= \frac{\sigma^2}{\sum (x - \bar{x})^2} \end{aligned} \quad (5.15)$$

$$\begin{aligned} \text{Var}(a) &= \text{Var}(\bar{y} - b\bar{x}) \\ &= \text{Var}(\bar{y}) + \bar{x}^2 \text{Var}(b) \end{aligned}$$

(porque puede demostrarse que b y $\bar{y}$ tienen una covariancia igual a cero).

$$= \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum (x - \bar{x})^2} \right] \quad (5.16)$$

Las fórmulas (5.14) a (5.16) incluyen el parámetro σ^2 . Si se efectúan inferencias a partir de un grupo de n pares de observaciones de x e y , σ^2 será desconocida. Sin embargo, sí es posible estimarla mediante el cuadrado de la media cuadrática residual, s_0^2 (5.8). Las variancias estimadas entonces serán:

$$\text{Var}(\bar{y}) = s_0^2/n \quad (5.17)$$

$$\text{Var}(b) = s_0^2/\sum (x - \bar{x})^2 \quad (5.18)$$

y

$$\text{Var}(a) = s_0^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum (x - \bar{x})^2} \right] \quad (5.19)$$

y se pueden contrastar las hipótesis sobre $\bar{y}$ a o b , utilizando la distribución t con $n - 2$ gl. Por ejemplo, para contrastar la hipótesis nula de que $\beta = 0$, es decir, que el valor de la media de y en la población general no varía con x , el estadístico:

$$t = \frac{b}{\text{ET}(b)} \quad (5.20)$$

puede remitirse a la distribución t para $n - 2$ gl, siendo $\text{ET}(b)$ la raíz cuadrada de (5.18). Del mismo modo, los límites de confianza de β , por ejemplo, al nivel del 95%, se pueden obtener utilizando la siguiente fórmula:

$$b \pm t_{n-2, 0.05} \text{ET}(b)$$

Un aspecto importante acerca del estadístico t (5.20) se observa escribiendo b como $b_{y,x}$ y utilizando (5.3), (5.7), (5.8) y (5.10). Encontramos que:

$$t = r \sqrt{\frac{n-2}{1-r^2}} \quad (5.21)$$

Como r es simétrica con respecto a x e y , se demuestra que para cualquier grupo de n pares de observaciones, si calculamos el estadístico t a partir de $b_{y,x}$ e (intercambiando x e y en las fórmulas) a partir de $b_{x,y}$, los dos valores de t serán iguales a (5.21). Al efectuar la prueba de significación para una regresión y una correlación iguales a cero, es indiferente que contrastemos $b_{y,x}$, $b_{x,y}$ o r . Sin embargo, debemos recordar que en algunos problemas sólo una de las regresiones puede tener una interpretación sensible y que será natural expresar la prueba en términos de esta regresión.

Ejemplo 5.1. (continuación del apartado 5.2)

La suma de cuadrados de las desviaciones de y con respecto a la recta de regresión es, según (5.7):

$$\begin{aligned} 17.168,47 - \frac{(-8.869,75)^2}{10.262,00} \\ = 17.168,47 - 7.666,39 \\ = 9.502,08 \end{aligned}$$

La media cuadrática residual es, según (5.8):

$$\begin{aligned}s_0^2 &= 9.502,08/(32 - 2) \\ &= 316,74\end{aligned}$$

Según (5.18):

$$\begin{aligned}\text{Var}(b) &= 316,74/10.262,00 \\ &= 0,030865 \\ \text{ET}(b) &= \sqrt{0,030865} \\ &= 0,1757\end{aligned}$$

Según (5.20):

$$\begin{aligned}t &= 0,8643/0,1757 \\ &= 4,92 \text{ con } 30 \text{ gl } (P < 0,001)\end{aligned}$$

También podemos calcular el coeficiente de correlación:

$$\begin{aligned}r &= \frac{-8869,75}{\sqrt{[(10.262,00)(17.168,47)]}} \\ &= \frac{8869,75}{13.273,39} \\ &= -0,668\end{aligned}$$

y, según (5.21):

$$\begin{aligned}t &= -0,668 \sqrt{\left(\frac{30}{0,554}\right)} \\ &= -4,92\end{aligned}$$

El error muestral de un coeficiente de correlación ya se introdujo en relación con una prueba de la hipótesis nula, según la cual el valor de su población es cero. Éste es el contexto en el que suele plantearse la pregunta. Con menor frecuencia es posible que deseemos calcular los límites de confianza para el valor de la población cuando los individuos que proporcionan observaciones apareadas pueden considerarse extraídos al azar de alguna población. Aquí se plantea la necesidad de definir la naturaleza de la distribución bidimensional de x e y . Una forma adecuada es la *distribución normal bivalente*. En la figura 5.6 se muestra un esbozo de ella. Se trata de una generalización de la conocida distribución normal univariante, en la que la distribución de y para una x dada es normal con variancia constante, la distribución de x para una y dada es también normal con variancia constante y ambas regresiones son lineales. En muestras grandes procedentes de una distribución como ésta, el error tipo del coeficiente de correlación, r , es aproximadamente $(1 - r^2)/\sqrt{n}$, un resultado que permite calcular límites de confianza aproximados. Existen métodos más perfeccionados para muestras pequeñas (*Geigy Scientific Tables*, 1982, vol. 2, capítulo sobre métodos estadísticos, apartado 19A).

La utilidad de estos resultados está limitada por la importancia de asumir la normalidad bivalente y también por la dificultad, ya mencionada, de interpretar los valores numéricos de un coeficiente de correlación.




Fig. 5.6. Representación tridimensional de una distribución normal bivalente en la que la dimensión vertical representa la densidad de probabilidad. (Tomada de Yule y Kendall, 1950, con autorización de los autores y de los editores.)

Errores de predicción

La mejor estimación de la media de y para un valor determinado de x , por ejemplo x_0 , está dada por la ecuación de regresión:

$$Y = a + bx_0 = \bar{y} + b(x_0 - \bar{x}) \quad (5.22)$$

La variancia muestra de Y es:

$$\begin{aligned} \text{Var}(Y) &= \text{Var}(\bar{y}) + (x_0 - \bar{x})^2 \text{Var}(b) \\ &= \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x - \bar{x})^2} \right] \end{aligned}$$

que puede estimarse utilizando la fórmula:

$$\text{Var}(Y) = s_0^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x - \bar{x})^2} \right]$$

De nuevo, se requiere la distribución t con $n - 2$ gl. Por ejemplo, los límites de confianza del 95% para la media estimada son:

$$Y \pm t_{n-2, 0.05} s_0 \sqrt{\left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x - \bar{x})^2} \right]} \quad (5.23)$$

En (5.23), la amplitud del intervalo de confianza aumenta con $(x_0 - \bar{x})^2$ y, en consecuencia, tiene un valor mínimo $x_0 = \bar{x}$. La figura 5.7 muestra los límites de varios colores de x_0 del ejemplo 5.1. La razón del incremento de la amplitud del intervalo es que los pequeños errores tipo de b tendrán un efecto mayor sobre los valores de x_0 distantes de $\bar{x}$, que sobre los valores próximos a ésta. La recta de regresión puede interpretarse como un segmento capaz de moverse libremente hacia arriba y hacia abajo (que corresponde al error de $\bar{y}$) y de girar alrededor de un punto central (que corresponde al error de b). Los puntos cercanos a los extremos de la barra estarán entonces sujetos a mayores oscilaciones que los puntos próximos al centro.

El problema de predicción es distinto cuando se estima un valor individual y_0 de y correspondiente a un valor x_0 determinado. La mejor estimación es de nuevo el valor dado por la ecuación de regresión, pero los límites de error son distintos de los obtenidos en el caso anterior. Se pueden distinguir dos problemas.

1. Se requiere una única predicción. Los límites apropiados no son estrictamente los límites de confianza, porque la cantidad que se debe estimar es un valor dado de una variable aleatoria y no un parámetro de una distribución. Sin embargo, si escribimos

$$y_0 = Y + \varepsilon$$

donde ε es la desviación de y_0 a partir del valor estimado Y , tenemos:

$$\begin{aligned} \text{Var}(y_0) &= \text{Var}(Y) + \text{Var}(\varepsilon) \\ &= \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x - \bar{x})^2} \right] \end{aligned} \quad (5.24)$$

y los límites,

$$Y \pm t_{n-2, 0.05} s_0 \sqrt{\left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x - \bar{x})^2} \right]} \quad (5.25)$$

incluirán y_0 el 95% de las veces.

2. El objetivo podría consistir en estimar los límites que contienen cierto porcentaje (p. ej., el 95%) de los valores de y cuando $x = x_0$. Estos límites son:

$$\alpha + \beta x_0 \pm 1,96\sigma$$

y son estimados por:

$$a + bx_0 \pm 1,96s_0 = Y \pm 1,96s_0 \quad (5.26)$$

Estos límites representan una distancia fija con respecto a la recta de regresión y están incluidos en los límites (5.25). Cuando n es muy grande, $t_{n-2, 0.05}$ es cercano a 1,96 y el segundo y el tercer términos incluidos en la raíz cuadrada de (5.25) son muy pequeños; por consiguiente (5.25) y (5.26) son casi idénticas (5.25).




Fig. 5.7. Límites de confianza (95%) del valor medio estimado de y para valores específicos, x_0 , de x (datos idénticos a los de la fig. 5.4.).

Por último, debería recordarse que la predicción a partir de una fórmula de regresión puede estar sujeta a errores distintos de los del muestreo. El modelo lineal puede ser una descripción inadecuada de la relación entre dos variables. Un examen visual del diagrama de puntos proporcionará una verificación parcial. Los métodos analíticos se describen en el apartado 9.1. Por supuesto, puede persistir una no linealidad insospechada porque los datos disponibles no indiquen nada sobre ella. El peligro que plantea utilizar el método erróneo es particularmente grave si se lo intenta extrapolar más allá de los límites de los valores observados. Por ejemplo, en la figura 5.1 sería muy peligroso utilizar la regresión de y sobre x para predecir la mortalidad infantil de las ciudades con un índice de población de 0,4 o 1,0.

Comparación de variancias en dos muestras apareadas

Volvamos ahora a la comparación de dos variancias, tratada en el apartado 4.6 para el caso de muestras independientes. Supongamos que las muestras son de igual tamaño, n , y que existe una relación natural entre un valor particular de x_{1i} de una muestra y el miembro correspondiente x_{2i} de la segunda muestra. Definimos $X_i = x_{1i} + x_{2i}$ y $Y_i = x_{1i} - x_{2i}$, la suma y la diferencia de las observaciones apareadas. Así, tenemos:

Par	Valores de x_1	Valores de x_2	Suma	Diferencia
1	x_{11}	x_{21}	X_1	Y_1
2	x_{12}	x_{22}	X_2	Y_2
.	.	.	.	.
.	.	.	.	.
.	.	.	.	.
n	x_{1n}	x_{2n}	X_n	Y_n

Llámesse x'_{ij} a la desviación de x_{ij} con respecto a su esperanza:

$$\begin{aligned}
 \text{Cov}(X_1, Y_1) &= E[(x'_{1i} + x'_{2i})(x'_{1i} - x'_{2i})] \\
 &= E[(x'_{1i})^2 - (x'_{2i})^2] \\
 &= \text{Var}(x_{1i}) - \text{Var}(x_{2i})
 \end{aligned} \tag{5.27}$$

Una prueba de igualdad de $\text{Var}(x_{1i})$ y $\text{Var}(x_{2i})$ es, en consecuencia, lo mismo que una prueba de la hipótesis según la cual la covariancia de X_i e Y_i es cero, lo cual significa que el coeficiente de correlación también debe ser cero. El numerador de (5.11) es un múltiplo de la covariancia muestral de las dos variables. Por consiguiente, la prueba de igualdad de variancias podría efectuarse mediante alguna de las pruebas equivalentes descritas antes para las hipótesis de asociación nula entre X_i e Y_i . Esta prueba es obra de E.J.G. Pitman. Su adaptación con fines de estimación ha sido descrita por Snedecor y Cochran (1980, apartado 10.8).

5.5. Regresión con respecto a la media

El término «regresión» fue introducido por Sir Francis Galton (1822-1911) para expresar el hecho de que para muchas características hereditarias, como la estatura, las mediciones en los hijos son en promedio más cercanas a la media de la población que a los correspondientes valores de sus padres. El coeficiente de regresión de la estatura del hijo sobre la del padre es inferior a 1. La regresión de la estatura del padre sobre la del hijo también es inferior a 1; así pues si se mira hacia delante o atrás en las generaciones hay una *regresión con respecto a la media*.

En varias especialidades de la medicina es frecuente observar fenómenos similares. Por ejemplo, supóngase que la presión arterial sistólica de una persona, determinada por el promedio de 5 lecturas, es de 162 mmHg. Este valor es algo superior a la media probable de la población, que es por ejemplo, de 140 mmHg. Si se hace otra lectura del mismo sujeto, *en promedio* tenderá a ser inferior a 162 mmHg. Por el contrario, un sujeto con una media muestral inferior a la media de la población tenderá a mostrar un incremento al repetir la medición.

La explicación se halla estrechamente relacionada con la correspondiente a la reducción del apartado 4.13 y prevé una descripción pertinente de los *componentes de la variancia* en el apartado 7.3. Supóngase que las lecturas repetidas de la presión arterial en el i -ésimo sujeto siguen una distribución con una media μ_i y una variancia σ^2 , y que los valores de μ_i va-

rían de un sujeto a otro con una media μ_0 y una variancia σ_0^2 . (Como se señala en el apartado 7.3, σ^2 y σ_0^2 son «componentes de la variancia» en sujetos y entre sujetos, respectivamente.) En términos de la explicación del apartado 4.13, puede considerarse que la variación entre sujetos es una distribución *a priori* para μ_i , y que la distribución de lecturas repetidas en un individuo proporciona la probabilidad. Se deduce de la explicación del apartado 4.13 que, en un sujeto con una presión arterial media de $\bar{x}_i$ basada en n observaciones, la estimación de la media verdadera μ_i tenderá a reducirse con respecto a $\bar{x}_i$ hacia la media de la población μ_0 , al igual que el valor medio de un conjunto futuro de lecturas repetidas.

Supóngase que se extraen dos muestras independientes de tamaño n en cada sujeto, con medias $\bar{x}_{i1}$ y $\bar{x}_{i2}$ para el i -ésimo sujeto. El coeficiente de correlación entre $\bar{x}_{i1}$ y $\bar{x}_{i2}$ es:

$$\rho = \frac{\sigma_0^2}{\sigma_0^2 + \sigma^2/n} \quad (5.28)$$

Si las distribuciones *entre* sujetos e *intrasujetos* son normales, la distribución conjunta de $\bar{x}_1$ y $\bar{x}_2$ será bivalente normal, como en la figura 5.6, y (5.28) también medirá el coeficiente de regresión de cualquiera de las medias en la otra. Si no hubiera una variación *intrasujetos* ($\sigma^2 = 0$), este coeficiente de regresión sería la unidad. Por consiguiente, la regresión hacia la media se mide por $1 - \rho$; así, cuanto más pequeño es ρ , mayor es la regresión hacia la media. Se producirán valores pequeños de ρ cuando σ_0^2 sea pequeña en relación con el error tipo de las medias, por ejemplo, cuando existe poca heterogeneidad real entre sujetos. Se producirán valores altos de ρ cuando la información previa sea relativamente vaga y el error tipo sea relativamente pequeño, por ejemplo con muestras muy grandes.

En algunos estudios de intervenciones médicas, los sujetos son seleccionados mediante pruebas de detección preliminares, como tener valores elevados de una medición experimental pertinente. Por ejemplo, en estudios sobre agentes reductores del colesterol se pueden seleccionar los sujetos con niveles séricos de colesterol por encima de un valor crítico, bien en una sola determinación, bien en la media de determinaciones repetidas. En promedio, incluso sin efectos del agente examinado, posteriores lecturas en los mismos sujetos tenderían a una regresión hacia la media. Por consiguiente, una reducción significativa inferior a los valores previos al tratamiento no proporciona indicios convincentes de un efecto del tratamiento. No obstante, si se dispone de estimaciones precisas de los componentes de la variancia, es posible calcular y tener en cuenta la magnitud de la regresión con respecto a la media. Gardner y Heady (1973) estudiaron este efecto, en relación con el colesterol, la presión arterial y la ingesta calórica diaria, y dieron fórmulas de los efectos de la regresión para varios niveles del punto de corte inicial de la detección. Como se ha señalado anteriormente, el efecto se reduce aumentando el número de observaciones efectuadas en la detección inicial. Johnson y George (1991) ampliaron este trabajo distinguiendo entre dos fuentes de variación *intrasujetos*: el error de medición y las fluctuaciones fisiológicas. Este último tipo de variación puede originar fluctuaciones que no son independientes, mostrando tal vez tendencias cíclicas o de otro tipo, un tema explicado en el apartado 10.6. En este caso, el aumento del tamaño inicial de la muestra puede producir un efecto más pequeño sobre el fenómeno de la regresión con respecto a la media de lo que se esperaría en otro caso.

Ejemplo 5.2

Irwig et al (1991) examinaron los efectos de la regresión con respecto a la media sobre la detección de los niveles elevados de colesterol sanguíneo en unos individuos. Estos investigadores estudiaron tres poblaciones hipotéticas con los siguientes valores medios (todos los valores citados aquí y a continuación se expresan en unidades de mmol/l): A, 5,2; B, 5,8, y C, 6,4. Estos valores están basados en datos de sondeos y son característicos de varones menores de 35 años y mujeres menores de 45 años (A); varones de 35-74 años y mujeres de 45-64 años (B), y mujeres de 65 años o más (C). Los cálculos están basados en el modelo descrito anteriormente, pero con la suposición (confirmada también por observaciones) de que el logaritmo del nivel de colesterol, no así el propio nivel, está distribuido normalmente *entre* sujetos e *intrasujetos*, con una varianza intrasujetos constante.

Las directrices tipo clasificarían los niveles inferiores a 5,2 como «deseables»; los niveles entre 5,2 y 6,1, como «límtrofes altos», y los superiores a 6,1, como «altos». Irwig et al. ilustran los efectos de la regresión con respecto a la media de varias maneras. Por ejemplo, un individuo del grupo B con una sola medición de detección igual a 9,0 tendría una media verdadera estimada de 8,4 con unos límites de confianza del 80% de 7,7 y 9,2. Si el valor de 9,0 estaba basado en tres mediciones, el nivel verdadero estimado sería 8,8 (límites, 8,3 y 9,3) es decir, un efecto de regresión menos pronunciado que el de mediciones únicas.

Un aspecto importante que se ha de tener en cuenta es que los individuos podrían quedar clasificados en el lado equivocado del umbral. Por ejemplo, un individuo del grupo A con una medición en la detección de 4,9 tendría una probabilidad de 0,26 de tener una media verdadera superior al umbral de 5,2. Para una medición en la detección igual a 5,8, la probabilidad de que el nivel verdadero sea inferior a 5,2 es de 0,10.

Otros cálculos se refieren a la valoración de una intervención destinada a reducir el colesterol sanguíneo. Supóngase que una intervención produce una reducción media del 13% (esta cifra se basa en los resultados de un estudio determinado). En un individuo del grupo B con tres mediciones antes y una después de la intervención, y con una media previa a la intervención de 7,8, una disminución observada del 25% corresponde a una disminución verdadera estimada del 19%, mientras que una disminución observada del 0% (sin cambio aparente) corresponde a una disminución verdadera estimada del 5%. En cada caso hay un desplazamiento hacia el cambio medio poblacional igual al 13%.

Los autores concluyen que el control de los cambios en los niveles de colesterol desempeñaría sólo un papel limitado en el tratamiento de los pacientes y que la interpretación de dichos cambios tendría en cuenta la regresión con respecto a la media. También afirman que el umbral recomendado de 5,2 mmol/l es demasiado bajo, puesto que es probable que sea superado por la media poblacional. Muchos individuos tienen mediciones únicas inferiores al umbral y por esta razón se los puede tranquilizar. Sin embargo, es posible que tengan valores verdaderos superiores al umbral.

Capítulo 6

Planificación de las investigaciones estadísticas

6.1. Generalidades

Las investigaciones estadísticas –aquellas en las que se efectúan observaciones sobre grupos de individuos– implican necesariamente la presencia de variación al azar. Si todos los pacientes que padecen un resfriado común presentaran síntomas bien definidos durante exactamente 7 días, sería posible demostrar los beneficios de un medicamento como paliativo de los síntomas administrándolo sólo a un paciente. Si los síntomas sólo duraran 5 días, la reducción podría atribuirse con seguridad al nuevo tratamiento. Del mismo modo, si la presión arterial fuera una función exacta de la edad, no variara de una persona a otra ni, en ocasiones, en la misma persona, se podría determinar la presión arterial a los 55 años de edad con una sola observación. Estos estudios no serían de naturaleza estadística y no requerirían un análisis estadístico. Naturalmente, esto no es lo que sucede. La duración de los síntomas de un resfriado común varía de un episodio a otro; la presión arterial varía entre los individuos y de un momento a otro. Por consiguiente, las comparaciones de los efectos de diferentes tratamientos médicos se deben efectuar en grupos de pacientes; los estudios de los patrones fisiológicos requieren sondeos poblacionales.

En la planificación de un estudio estadístico pueden plantearse numerosos problemas administrativos y técnicos. Éstos serán característicos de cada campo particular de investigación y no pueden analizarse completamente en este contexto general. Dos aspectos de la planificación, que afectan de modo especial al estadístico, estarán presentes casi invariablemente. El investigador deseará que las inferencias formuladas en un estudio sean suficientemente precisas y que los resultados sean aplicables a la cuestión que se está planteando. Las consideraciones en cuanto al diseño estadístico de una investigación se relacionan especialmente con los aspectos generales referentes a estos dos objetivos. Algunas de las cuestiones que se plantean son: *a)* cómo seleccionar a los individuos sobre los que se van a realizar las observaciones; *b)* cómo decidir el número de observaciones que se ha de realizar en los diferentes grupos, y *c)* cómo asignar las observaciones entre diferentes categorías posibles de individuos (como grupos de animales que reciben diferentes tratamientos o grupos de personas que viven en diferentes áreas).

Es útil hacer una distinción conceptual entre dos tipos distintos de investigaciones estadísticas, el *experimento* y el *sondeo* o *encuesta*. La experimentación implica una interferencia planteada en el curso natural de los acontecimientos de tal forma que su efecto se pueda observar. En el sondeo, el investigador es un observador más pasivo, que interfiere lo menos posible en los fenómenos que desea registrar. Es fácil pensar en ejemplos extremos para ilustrar esta antítesis pero, en la práctica, a veces es difícil establecer esta distinción. Consideremos, por ejemplo, la siguiente serie de estudios estadísticos.

1. Una encuesta sobre los tipos de vehículos de motor que pasan por un punto de control durante cierto período.
2. Una encuesta de opinión pública.
3. Un estudio sobre la función respiratoria (medida con diferentes métodos) en trabajadores de una industria determinada.
4. Observaciones sobre los tiempos de supervivencia de ratones de tres cepas diferentes, tras la inoculación de una misma dosis de una sustancia tóxica.
5. Un ensayo clínico para comparar las ventajas de la cirugía y del tratamiento conservador en pacientes que padecen una afección determinada y a los que ambos tratamientos se asignan al azar.

Los estudios 1 a 3 son claramente sondeos o encuestas, aunque incluyan una cantidad creciente de interferencia con lo espontáneo. El estudio 5 es claramente un experimento. El estudio 4 ocupa una posición equívoca. En sus aspectos estadísticos es claramente un sondeo, porque el objetivo es observar o comparar ciertas características de tres cepas de ratón. Sin embargo, la característica de interés requiere la forma de interferencia más extrema –la muerte del animal– y las técnicas no estadísticas manejadas son más semejantes a las de un experimento de laboratorio que las requeridas en la mayoría de los sondeos.

En los dos apartados siguientes trataremos algunos de los principios generales de la planificación de los sondeos y, a continuación, esbozaremos los principios del diseño experimental.

6.2. Planificación de sondeos: estimación de parámetros poblacionales

Es útil distinguir entre *sondeos descriptivos*, diseñados para proporcionar estimaciones de algunas características simples de las poblaciones, y *sondeos analíticos*, diseñados para investigar asociaciones entre ciertas variables. Ejemplos del primer tipo son las encuestas para estimar la prevalencia de algunas enfermedades en una población o la distribución de frecuencias de las consultas médicas durante cierto período de tiempo. Un ejemplo del segundo tipo podría ser un estudio sobre la asociación entre el uso de un medicamento y la aparición de un efecto adverso particular. La distinción no es nítida en modo alguno. En un sondeo poblacional podríamos estar interesados también en asociaciones; por ejemplo, la de la prevalencia de una enfermedad y la edad de una persona. Por otro lado, en un sondeo de asociación podría ser bastante razonable considerar la asociación en cuestión como un parámetro poblacional y preguntarnos cómo varía de una población a otra. Sin embargo, en los sondeos poblacionales el objetivo principal recae sobre la provisión de estimadores adecuados de las características de una población bien definida; en los sondeos analíticos, que se tratarán en el apartado 6.3, la definición de población es menos importante que la relación entre las variables.

El interés estadístico de los sondeos poblacionales surge en primer lugar cuando éstos se llevan a cabo mediante métodos de muestreo. Algunos sondeos se realizan por enumeración completa, los censos poblacionales son ejemplos conocidos. Las ventajas del muestreo se basan en la economía de coste, de mano de obra y de tiempo. Además, como se indicó en el apartado 3.1, la menor escala de una encuesta muestral puede permitir realizar observaciones más válidas.

En el apartado 3.1 se introdujo el concepto de estructura de muestreo y se presentó un

ejemplo con una forma de muestreo aleatorio frente a una forma de selección intencionada, como el muestreo por cuotas. El muestreo aleatorio simple ha constituido el modelo para todos los resultados básicos de la teoría del muestreo. Ahora podemos considerar algunas formas alternativas al muestreo aleatorio.

Muestreo sistemático

Cuando las unidades o los individuos de una población se listan u ordenan de forma sistemática, puede ser conveniente disponer las unidades elegidas de modo que ocupen determinadas posiciones relativas en la estructura muestral, seleccionando al azar la primera unidad. Por ejemplo, para extraer una muestra de una de cada 50 entradas de un fichero, la primera ficha se podría seleccionar eligiendo un número al azar del 1 al 50 y, a continuación, se incluiría cada ficha que ocupara la posición 50 a partir de la anterior. Si el número elegido para empezar fue el 39, las fichas seleccionadas serían las que ocuparan las posiciones 39, 89, 139, 189, ..., etc. A esta muestra se la denomina *muestra sistemática*.

...	(5,3)	...	(5,8)	...	(5,13)	...
	.		.		.	
	.		.		.	
	.		.		.	
...	(10,3)	...	(10,8)	...	(10,13)	...
	.		.		.	
	.		.		.	
	.		.		.	
...	(15,3)	...	(15,8)	...	(15,13)	...

Otro ejemplo podría plantearse en un muestreo bidimensional. Supongamos que se va a realizar un estudio de salud en unidades geográficas determinadas por una rejilla rectangular. Si debemos seleccionar, por ejemplo, una de cada 25 unidades, las coordenadas iniciales «vertical» y «horizontal» podrían elegirse al azar, cada una de ellas entre los números 1 y 5. Si los números aleatorios iniciales fueran 5 y 3, las unidades seleccionadas tendrían las posiciones que se muestran (el primer número representa la posición «vertical», y el segundo, la «horizontal»).

A menudo el muestreo sistemático es, cuando menos, tan preciso como el muestreo aleatorio. Sin embargo, es particularmente peligroso si la ordenación de las unidades en la estructura muestral impone una correlación positiva entre unidades cuya distancia es igual al intervalo de muestreo. En el ejemplo geográfico anterior, si existiera una serie de valles desde el este hasta el oeste, separados entre sí cinco unidades, casi todas las unidades elegidas estarían muy pobladas o casi todas muy poco pobladas. El error tipo del método podría ser anormalmente elevado. En general, será difícil estimar el error de muestreo a partir de una única muestra sistemática, a menos que se asuma que estas correlaciones no existen y que la muestra se puede considerar prácticamente aleatoria. Una estrategia útil es escoger simultáneamente varias muestras sistemáticas mediante diferentes elecciones del punto de partida.

La media u otro estadístico apropiado podría calcularse por separado para cada muestra sistemática y la variancia muestral de la media global se calcularía mediante la fórmula usual en términos de variancia de las medias separadas.

Muestreo estratificado

En este método, la población se divide en varios subgrupos o *estratos*, cada uno de los cuales es muestreado aleatoriamente con un tamaño de muestra conocido. Supóngase que deseamos estimar la media de una variable determinada en la población y que los estratos están definidos de forma que la media varía considerablemente de un estrato a otro. En el muestreo aleatorio simple la distribución de las observaciones en los estratos variará de una muestra a otra, y esta ausencia de control contribuirá a la variabilidad de la media muestral. Por el contrario, en muestreos repetidos con la *misma* distribución entre estratos, este componente de variabilidad es irrelevante.

Los estratos pueden definirse cualitativamente, por ejemplo, en un estudio de salud nacional, se pueden tomar como estratos las diferentes regiones del país. Éstos también podrían definirse en términos de una o más variables cuantitativas, por ejemplo, grupos de edad. La fracción del estrato que se va a muestrear puede ser constante o variar de un estrato a otro. Los puntos importantes son: *a*) que la distribución de la población y de la muestra sobre los estratos debe ser conocida y *b*) que la variabilidad entre los estratos debe ser lo más alta posible o, de modo equivalente, que cada estrato debe ser lo más homogéneo posible.

Supongamos que existen k estratos y que en el estrato i el tamaño de la población es N_i y que la media y la variancia de la variable x son, respectivamente μ_i y σ_i^2 . Del estrato i se extrae al azar una muestra de tamaño n_i ; la fracción muestral n_i/N_i se simbolizará como f_i . La media muestral y la estimación de la variancia en el estrato i son $\bar{x}_i$ y σ_i^2 . El tamaño total de la población es:

$$N = \sum_{i=1}^k N_i$$

y el tamaño total de la muestra:

$$n = \sum_{i=1}^k n_i$$

La media de x en la población es, evidentemente:

$$\mu = \frac{\sum N_i \mu_i}{N}$$

La estimación adecuada de μ es:

$$\hat{\mu} = \frac{\sum N_i \bar{x}_i}{N} \quad (6.1)$$

donde se aprecia fácilmente, que no está sesgada. Porque $E(\bar{x}_i) = \mu_i$, $E(\hat{\mu}) = \sum N_i \mu_i / N = \mu$. La variancia de $\hat{\mu}$ es:

$$\begin{aligned} \text{Var}(\hat{\mu}) &= \frac{1}{N^2} \sum N_i^2 \text{Var}(\bar{x}_i) \\ &= \frac{1}{N^2} \sum \frac{N_i^2 \sigma_i^2}{n_i} (1 - f_i) \end{aligned} \quad (6.2)$$

según (3.2), la cual puede estimarse a partir de la muestra con la fórmula:

$$\text{Var}(\hat{\mu}) = \frac{1}{N^2} \sum \frac{N_i^2 s_i^2}{n_i} (1 - f_i) \quad (6.3)$$

Si todas las f_i son pequeñas, los términos $1 - f_i$ pueden sustituirse por la unidad. En general, (6.2) será más pequeño que la variancia de la media de una muestra aleatoria, porque los términos σ_i^2 sólo miden la variabilidad *intraestratos*. La variabilidad entre las μ_i es inaplicable.

Si n no varía y las f_i son pequeñas, $\text{Var}(\hat{\mu})$ se hace mínima si las n_i son elegidas lo más proporcionalmente posible a $N_i \sigma_i$. En consecuencia, si σ_i es constante de un estrato a otro, las n_i deberían escogerse en proporción a N_i , y la fracción muestral debería ser constante. Los estratos con σ_i relativamente grandes tienen en correspondencia fracciones muestrales elevadas. En general, se conocerá poco de σ_i antes de llevar a cabo el muestreo, y la elección de una fracción muestral constante será la estrategia más razonable.

Si el estudio se ha diseñado para estimar una proporción, π , se sustituirán $\bar{x}_i$ y μ_i de las fórmulas anteriores por p_i y π_i , las proporciones observadas y verdaderas en el estrato i , σ_i^2 por $\pi_i (1 - \pi_i)$ y σ_i^2 por $n_i p_i (1 - p_i) / (n_i - 1)$ [siendo éste el estimador de la variancia de una muestra de tamaño n_i en el que $n_i p_i$ observaciones son 1 y $n_i (1 - p_i)$ son 0].

Aparte de aumentar la precisión en la estimación de la media poblacional, la estratificación puede adoptarse para proporcionar estimaciones razonablemente precisas de las medias de cada uno de los estratos. Ello puede conducir a desviarse con respecto a las asignaciones óptimas descritas anteriormente para que ninguno de los tamaños muestrales de los distintos estratos sean demasiado pequeños.

Ejemplo 6.1

Se desea estimar la prevalencia de una situación determinada (es decir, la proporción de individuos afectados) en una población de 5.000 individuos, por medio de una muestra de tamaño 100. Supongamos que se sabe que la prevalencia está asociada a la edad y que la población puede dividirse en tres estratos definidos en función de la edad, con los siguientes números de individuos.

Estratos i	Edad (años)	N_i
1	0-14	1.200
2	15-44	2.200
3	45-	1.600
		5.000

Supongamos que las prevalencias verdaderas π_i en los diferentes estratos son las siguientes:

Estrato i	π_i
1	0,02
2	0,08
3	0,15

Es fácil verificar que la prevalencia global $\pi (= \sum N_i \pi_i / \sum N_i)$, vale 0,088. Una muestra aleatoria simple de tamaño $n = 100$ proporcionaría entonces un estimador p , con una variancia $(0,088)(0,912)/100 = 0,000803$.

Para realizar un muestreo estratificado con asignación óptima de los tamaños de las muestras a los estratos, éstos se deberían elegir en proporción a $N_i \sqrt{[\pi_i(1 - \pi_i)]}$. Los valores de esta cantidad en los tres estratos son 168, 597 y 571, que corresponden, respectivamente, a las proporciones 0,126, 0,447 y 0,427. Por consiguiente, los tamaños muestrales óptimos son $n_1 = 12$, $n_2 = 45$ y $n_3 = 43$, o números muy cercanos (existiendo pocas dudas sobre el efecto del redondeo al entero más cercano). A esto lo denominaremos asignación A. Ésta depende de las π_i , desconocidas y, por consiguiente, difícilmente puede utilizarse en la práctica. Si sabemos muy poco sobre la variación probable de π_i podríamos elegir las n_i proporcionales a las N_i , ignorando el efecto de la variación en la desviación tipo. Ello representaría $n_1 = 24$, $n_2 = 44$ y $n_3 = 32$, a lo que llamaremos asignación B. En tercer lugar, podríamos tener alguna idea sobre el aumento de la prevalencia con la edad (y, por consiguiente, de la desviación tipo) y por ello ajustar la asignación bastante arbitrariamente para obtener $n_1 = 20$, $n_2 = 40$ y $n_3 = 40$ (asignación C).

El estimador π está dado, en cada caso, por la fórmula equivalente de (6.1):

$$\hat{\pi} = \frac{\sum N_i p_i}{N}$$

donde p_i es la prevalencia estimada en el estrato i . La variancia de π se calcula con la fórmula equivalente de (6.2) en la que debemos omitir los términos f_i por ser pequeños:

$$\text{Var}(\pi) = \frac{1}{N^2} \sum \frac{N_i^2 \pi_i (1 - \pi_i)}{n_i}$$

Los valores de $\text{Var}(\pi)$ para las tres asignaciones son los siguientes:

Asignación	$\text{Var}(\pi)$
A	0,000714
B	0,000779
C	0,000739

Como cabía esperar, la variancia menor corresponde a A y la mayor a B, siendo esta última sólo algo menor que la variancia para una muestra aleatoria.

Muestreo de etapas múltiples

En este método, la estructura de muestreo se divide en una población de «unidades muestrales de primera etapa», de la que se extrae una muestra de «primera etapa». Ésta suele ser una muestra aleatoria simple, aunque puede ser también una muestra sistemática o estratificada; asimismo, puede tratarse, como veremos, de una muestra aleatoria en la cual algunas unidades de primera etapa tengan mayor probabilidad de selección que otras. Cada unidad de primera etapa seleccionada se subdivide en «unidades de muestreo de segunda etapa» que son muestreadas. El proceso puede continuar tantas veces como convenga.

El muestreo por etapas múltiples presenta dos ventajas principales. En primer lugar, permite concentrar los recursos sobre un número limitado de porciones de la estructura muestral global, con la consiguiente reducción del coste. En segundo lugar, es adecuado para aquellas situaciones en las que no se dispone de una estructura muestral completa antes de comenzar la investigación. Se requiere una lista de las unidades de primera etapa, mientras que las unidades de segunda etapa sólo necesitan enumerarse en las unidades de primera etapa seleccionadas para la muestra.

Consideremos como ejemplo una encuesta de salud de los trabajadores de una especialidad industrial determinada. Es probable que no exista una lista completa de todos los individuos de la especialidad, pero puede ser fácil obtener una lista de factorías, las cuales representarían las unidades de primera etapa. Se podría obtener una lista de los individuos de cada factoría seleccionada en la primera etapa y seleccionar una muestra de segunda etapa a partir de esta lista. Además de la ventaja que supone elaborar listas de individuos exclusivamente en las factorías seleccionadas en la primera etapa, este procedimiento representa una reducción de los costes y permite concentrar la investigación en las factorías seleccionadas, en lugar de requerir el examen de una muestra de individuos repartida por las distintas zonas del país.

La reducción de los costes y recursos se acompaña, lamentablemente, de una pérdida de precisión cuando se compara con el muestreo aleatorio simple. Supóngase que en el ejemplo anterior extraemos una muestra de 20 factorías y, de cada una de ellas, muestras de segunda etapa de 50 individuos. Si existe una variación sistemática entre las factorías, debida a la variación en las condiciones de salud en las diferentes zonas del país o a circunstancias ocupacionales, esta variación estará representada sólo por una muestra de 20 unidades de primera etapa. En cambio, una muestra aleatoria de 1.000 individuos representaría 1.000 elecciones aleatorias de unidades de primera etapa (algunas de las cuales, por supuesto, podrían elegirse más de una vez) y, por consiguiente, ofrecería una mejor estimación de la media nacional.

Una estrategia útil en el muestreo en dos etapas es la *autoponderación*. A cada unidad de primera etapa se le adscribe una probabilidad de selección, que es proporcional al número de unidades de segunda etapa que contiene. A continuación se obtienen muestras de segunda etapa de igual tamaño. Cada unidad de segunda etapa tiene, en el conjunto de la población, la misma probabilidad de ser elegida, y las fórmulas necesarias para las estimaciones resultan de algún modo más sencillas.

En ocasiones, en la última etapa del muestreo se lleva a cabo una observación completa de todas las unidades disponibles. En el ejemplo de la industria, una vez instalado el equipo de estudio en la factoría, supone un coste extra mínimo examinar a todos los individuos e, incluso, puede ser útil para evitar el malestar ocasionado por invitar a participar a unos trabajadores y a otros no.

Otras consideraciones

La planificación, la realización y el análisis de los estudios sobre muestras originan muchos problemas que no es posible analizar en esta obra. Los textos de Moser y Kalton (1971) y Yates (1981) contienen excelentes comentarios sobre los aspectos prácticos del muestreo. En un informe de la Organización Mundial de la Salud (1966) se describen brevemente aplicaciones a estudios de morbilidad y a investigaciones en salud pública. Para los aspectos teó-

ricos más importantes pueden consultarse los textos de Cochran (1977) y Yates (1981).

La teoría estadística de los estudios sobre muestras está íntimamente relacionada con la medida del error tipo. Esta estrecha relación puede conducir al investigador a soslayar la importancia de los errores no muestrales. En un estudio amplio, los errores tipo pueden ser tan pequeños que los errores no muestrales sistemáticos sean mucho más importantes. Además, en una enumeración completa, como un censo poblacional, los errores tipo desaparecen totalmente, pero pueden existir errores no muestrales muy importantes.

Algunos errores no muestrales son no sistemáticos y no sesgan el promedio. Un ejemplo podría ser la inexactitud aleatoria de la lectura proporcionada por un instrumento de medida. Estos errores contribuyen simplemente a la variabilidad de la observación en cuestión y, por consiguiente, disminuyen la precisión del estudio. Otros errores son sistemáticos y causan un sesgo en el valor de la media que no disminuye al aumentar el tamaño de la muestra; por ejemplo, en una encuesta de salud puede faltar sistemáticamente el registro de algunas enfermedades.

Uno de los tipos más importantes de error sistemático es el debido a la cobertura inadecuada de la estructura de la muestra, tanto a causa de una falta de cooperación por parte de los individuos como a que el investigador encuentra difícil efectuar las observaciones correctas. Por ejemplo, en una encuesta, algunas personas pueden rechazar ser entrevistadas y otras pueden ser difíciles de encontrar, haber cambiado su dirección o incluso haber muerto. Los individuos perdidos por alguno de estos motivos pueden ser probablemente atípicos en la población en varios aspectos relevantes. Por consiguiente, se debe realizar un esfuerzo para incluir a todos los individuos elegidos en la encuesta, intentando conseguir los datos importantes de los que no responden o concentrándolos en una submuestra de ellos para que sus características puedan, al menos, estimarse.

Por último se debe citar otro tipo importante de estudio, el *estudio longitudinal*. Muchas investigaciones hacen referencia a los cambios de ciertas medidas a lo largo de un período de tiempo: por ejemplo, el crecimiento y desarrollo de los niños durante un período de 10 años o los cambios de la presión arterial durante el embarazo. Es preferible, cuando sea posible, estudiar cada individuo durante el período que interesa, más que tomar diferentes muestras de individuos en momentos distintos. Algunos problemas estadísticos son comentados por Goldstein (1979).

6.3. Estudios para investigar asociaciones

Una cuestión planteada con frecuencia en las investigaciones epidemiológicas sobre la etiología de la enfermedad es si una manifestación de salud-enfermedad se asocia a ciertas características o hábitos personales, a aspectos particulares del ambiente en el que vive la persona o a ciertas experiencias que ésta ha vivido. A continuación plantearemos algunos ejemplos.

1. ¿Está relacionado el riesgo de muerte por cáncer de pulmón con el número de cigarrillos fumados en la actualidad y en los años precedentes?
2. ¿Está relacionado el riesgo de que un niño muera a causa de una leucemia aguda con la exposición o no de la madre a irradiación durante el embarazo?

3. ¿Está aumentando el riesgo de aparición de una enfermedad determinada en individuos que fueron tratados con un medicamento determinado durante una enfermedad anterior?

Algunas veces es posible contestar preguntas como éstas mediante experimentación controlada, en la cual el factor personal sospechoso se puede administrar o retirar a criterio del investigador; así, en el ejemplo 3 sería posible que el investigador administrara el medicamento a algunos pacientes y a otros no, para comparar los resultados. En tales casos, las preguntas están relacionadas con los efectos causales. ¿Es este medicamento una *causa* parcial de esta enfermedad? Más a menudo, sin embargo, la aproximación experimental es inabordable. El investigador debe entonces contentarse con observar que existe una *asociación* entre el factor y la enfermedad y determinar el riesgo, mencionado en el apartado 5.1, si desea inferir un vínculo causal.

Estas situaciones suelen investigarse mediante determinados tipos de estudios más que con experimentos. En este caso, la población precisa que se debe encuestar no suele ser un aspecto prioritario. Una razón es que en los estudios epidemiológicos suele ser administrativamente imposible estudiar una población regional o nacional. Sin embargo, el investigador puede tener facilidades para estudiar un grupo ocupacional concreto o una población geográficamente relacionada con un centro médico particular. En segundo lugar, aunque la media o las frecuencias relativas de las diferentes variables puedan variar de algún modo de una población a otra, es poco probable que la magnitud y la dirección de las asociaciones entre variables varíen de forma importante entre grupos ocupacionales o poblaciones geográficas diferentes.

Existen dos diseños fundamentales en las encuestas etiológicas: el estudio *caso-control* (a veces conocido como estudio *caso-referente*) y el estudio de *cohortes*. En un estudio caso-control se compara un grupo de individuos afectados de una enfermedad determinada con un grupo control de individuos no afectados. En general la información se obtiene de forma retrospectiva y hace referencia a la frecuencia de los diferentes factores personales o ambientales en cada grupo que pudieran asociarse a la enfermedad. Este tipo de estudio es adecuado para situaciones raras que difícilmente se encontrarían en una muestra poblacional aleatoria. Al considerar un grupo de individuos afectados, uno está tomando una fracción muestral mucho mayor de los casos que de los controles. El método también es apropiado cuando la clasificación por enfermedades es simple (particularmente en el caso de una clasificación dicotómica mediante la presencia o la ausencia de una circunstancia específica), pero se deben estudiar varios posibles factores etiológicos. Una ventaja adicional es que mediante la encuesta retrospectiva es posible obtener rápidamente la información de interés.

En un estudio de cohortes, una población de individuos, seleccionada generalmente por criterios geográficos u ocupacionales más que por aspectos médicos, es estudiada mediante una enumeración completa o mediante una muestra representativa. La población se clasifica en función del factor o de los factores de interés y se sigue prospectivamente a lo largo del tiempo a fin de observar las frecuencias de aparición de varias manifestaciones de enfermedad y su relación con las clasificaciones según factores etiológicos. La naturaleza prospectiva del estudio de cohortes determina que por lo general dure más que el estudio caso-control y que pueda ser administrativamente más complejo. Sus ventajas son que es posible estudiar simultáneamente muchas situaciones médicas y que se puede obtener información directa sobre la salud de cada individuo durante un intervalo de tiempo.

Los estudios caso-control y de cohortes suelen denominarse, respectivamente, estudios *retrospectivos* y *prospectivos*. Estos últimos términos suelen ser apropiados, aunque la nomen-

clatura en ocasiones induce a error, dado que un estudio de cohortes puede estar basado completamente en informes retrospectivos. Por ejemplo, si se dispone de informes médicos sobre los trabajadores de una factoría durante los últimos 30 años, un estudio de cohortes podría relacionar a los trabajadores empleados hace 30 años y estar basado en informes sobre su salud de los 30 años posteriores. Un estudio de este tipo se denomina en ocasiones *estudio prospectivo histórico*.

Un problema central de un estudio caso-control es el método utilizado para seleccionar los controles. De forma ideal, los controles deberían ser en promedio similares a los casos en todos los aspectos, excepto en las circunstancias médicas bajo estudio y en los factores etiológicos asociados. Los casos suelen seleccionarse en uno o más hospitales y deben compartir características de la población que acude a estos hospitales, como las condiciones ambientales y sociales y las características étnicas. Es preferible seleccionar a los miembros del grupo control en la misma área o áreas y, quizás, en los mismos hospitales, pero que padezcan enfermedades bastante distintas y que no compartan los mismos factores etiológicos. Además, las frecuencias con que aparecen ciertos factores en general variarán con la edad y el sexo. Por ello, las comparaciones entre los grupos de casos y de controles deben tener en cuenta las distribuciones de edad y sexo en ambos grupos. Estos ajustes se evitan generalmente emparejando cada individuo afectado con un individuo control que se elige deliberadamente del mismo sexo y de la misma edad y que comparta las otras características demográficas que se consideren importantes.

Las consideraciones comentadas en el apartado 6.2 sobre los errores no muestrales, especialmente los referentes a la no respuesta, también son importantes en los estudios etiológicos. Las no respuestas constituyen siempre un peligro potencial y se debe intentar reducirlas a la proporción más baja posible.

En un estudio de cohortes en el que la incidencia de una enfermedad específica tiene un interés particular, se puede adoptar el método de caso-control eligiendo, para cada caso nuevo, un grupo control de no casos seleccionados al azar. En este método, denominado por Mantel (1973) *estudio retrospectivo sintético*, debe tenerse la precaución de evitar la selección repetida de los mismos individuos que los controles para más de un caso (Robins et al, 1989).

Ejemplo 6.2

Doll Hill (1950) publicaron los resultados de un estudio retrospectivo sobre la etiología del cáncer de pulmón. Se comparó un grupo de 709 pacientes afectos de carcinoma pulmonar procedentes de 20 hospitales con un grupo de 709 pacientes sin carcinoma pulmonar y un tercer grupo de 637 pacientes con carcinoma de estómago, colon o recto. Para cada paciente con cáncer de pulmón se seleccionó un paciente control del mismo hospital y sexo y pertenecientes al mismo intervalo de edad de 5 años. Cada paciente de cada grupo fue entrevistado utilizando el mismo cuestionario.

Las únicas diferencias sustanciales entre el grupo de casos y el grupo de controles fueron las que hacían referencia a sus hábitos tabáquicos. Algunos de los hallazgos se resumen en la tabla 6.1. La diferencia en la proporción de no fumadores en ambos grupos es claramente significativa en el caso de los varones. (Si se necesita un test de significación para datos de este tipo, un método apropiado sería la prueba de la diferencia de dos proporciones apareadas, descrita en el apartado 4.8.) El grupo de pacientes con otras formas de cáncer tenía antecedentes tabáquicos similares a los del grupo control y diferían notablemente de los del grupo con cáncer de pulmón. Las comparaciones de este tercer grupo

Tabla 6.1. Consumo de tabaco reciente en pacientes con carcinoma pulmonar y en pacientes control sin carcinoma pulmonar (Doll y Hill, 1950).

	No fumadores	Consumo diario de cigarrillos					Total
		1-	5-	15-	25-	50-	
<i>Varones</i>							
Carcinoma pulmonar	2	33	250	196	136	32	649
Controles	27	55	293	190	71	13	649
<i>Mujeres</i>							
Carcinoma pulmonar	19	7	19	9	6	0	60
Controles	32	12	10	6	0	0	60

son más complicadas porque los pacientes individuales no estaban apareados con los miembros del grupo con cáncer de pulmón ni con los del grupo control y presentaban una distribución de edad algo distinta. El posible efecto de la edad fue considerado mediante métodos de estandarización por edad (apartado 12.9).

El artículo de Doll y Hill constituye una ilustración excelente del cuidado que debe tomarse para evitar sesgos debidos a diferencias inesperadas entre los grupos de casos y controles o a diferentes estándares de recogida de datos. Este estudio y otros semejantes sugieren firmemente la existencia de una asociación entre el tabaco y el riesgo de aparición de cáncer pulmonar. Sin embargo, estos estudios retrospectivos dan pie a argumentos sobre la conveniencia de una elección particular del grupo control; se obtiene poca información sobre el tiempo de relación implicado y ninguna sobre la asociación entre el hábito tabáquico y otras enfermedades distintas a las seleccionadas para el estudio. Doll y Hill (1954, 1956, 1964) llevaron a cabo un estudio de cohortes enviando cuestionarios a los 59.600 médicos del Reino Unido en octubre de 1951. Recibieron respuestas del 68,2% de los encuestados (34.440 varones y 6.917 mujeres). Estos médicos fueron seguidos durante 20 años. Se obtuvieron notificaciones de fallecimientos debidos a varias causas y se perdió la pista de 103 (Doll y Peto, 1976). En la tabla 6.2 se muestran algunos de los resultados obtenidos en los médicos varones. Los grupos definidos por varias categorías de fumadores presentan diferentes distribuciones de edad, y las tasas de mortalidad mostradas en la tabla también se estandarizaron según la edad (apartado 12.9). El hábito de fumar cigarrillos aparece de nuevo asociado a un incremento evidente en la tasa de mortalidad por cáncer pulmonar y también muestra una asociación menor con las tasas de mortalidad debidas a otras causas diversas.

Tabla 6.2. Tasas anuales de mortalidad estandarizada entre médicos varones para las tres causas de muerte relacionadas con el hábito tabáquico (Doll y Peto, 1976).

	Número de muertes	Tasa de mortalidad estandarizada por 100 varones					
		No fumadores	Ex fumadores	Fumadores actuales	Fumadores actuales (g/día)		
					1-14	15-24	25-
Carcinoma pulmonar	441	10	43	104	52	106	224
Bronquitis crónica y enfisema	254	3	44	50	38	50	88
Isquemia coronaria	3.191	413	533	565	501	598	677

Este estudio prospectivo ofrece unos indicios claros de que la asociación entre el tabaco y el cáncer pulmonar es causal. Muchos médicos que fumaban al inicio del estudio abandonaron el hábito durante el período de seguimiento, y en 1971 los médicos fumaban menos de la mitad que los individuos de la misma edad de la población general. La tasa de mortalidad por cáncer de pulmón en el conjunto de médicos varones (estandarizada por edad y expresada como una fracción de la tasa nacional de mortalidad) descendió uniformemente durante el período de 20 años de seguimiento.

La medición del grado de asociación entre el riesgo de enfermedad y la presencia de un factor etiológico se comenta en detalle en el apartado 16.2.

6.4. Diseño de experimentos

Consideremos ahora la planificación de experimentos para comparar los efectos de varios tratamientos en algunos tipos de unidades experimentales. El investigador debe decidir el tratamiento que se ha de aplicar en cada unidad particular. Veamos algunos ejemplos:

1. Una comparación de los efectos producidos por la inoculación de diferentes dosis de una sustancia química en animales. Las unidades serán animales.
2. Un ensayo profiláctico para comparar la efectividad de diferentes vacunas frente al sarampión en niños. Cada niño recibirá una de las vacunas y se puede considerar como la unidad experimental.
3. Una comparación de diferentes métodos para aliviar las molestias en un paciente que padece episodios recurrentes de una enfermedad crónica. Las sucesivas ocasiones en las que aparecen las crisis constituyen en este caso la unidad experimental para la que se elige el tratamiento.
4. Un estudio sobre las ventajas relativas de distintos programas comunitarios de educación sanitaria. Cada programa sería aplicado en un área distinta y estas áreas formarían las unidades experimentales.

En todos estos ejemplos la cuestión fundamental es cómo se asignarán los tratamientos a las unidades disponibles. Evidentemente, uno deseará evitar cualquier disparidad importante entre las características de las unidades que reciben los diferentes tratamientos. Por ejemplo, en el caso 2, sería peligroso administrar una vacuna a todos los niños de una escuela y otra vacuna a todos los niños de una segunda escuela, porque la exposición de los dos grupos de niños al sarampión podría ser bastante distinta. En consecuencia, sería difícil decidir si la diferente incidencia de sarampión se debió a los poderes protectores de las vacunas o a diferentes grados de exposición a la infección.

Sería posible manipular los diferentes grupos de unidades experimentales que van a recibir los tratamientos para que fueran similares en varios aspectos importantes. Por ejemplo, en el caso 1, se podrían formar grupos de animales con el mismo peso medio; en el caso 2 los niños de diferentes escuelas y de distintos grupos de edad podrían representarse equitativamente en cada grupo de tratamiento. Aunque el investigador sea cuidadoso en equilibrar los factores que parecen importantes, nunca podrá asegurar que los grupos de tratamiento no difieren de forma acusada en algún factor que también es importante pero que ha sido olvidado en la asignación.

La solución aceptada para este dilema es la planteada por Fisher en las décadas de 1920 y 1930; la asignación debería incorporar un elemento *aleatorio*. En su forma más simple,

significa que la elección del tratamiento para cada unidad debería efectuarse mediante un acto aleatorio independiente, como echar una moneda o utilizar una tabla de números aleatorios. Ello conduciría a cierta incertidumbre con respecto al número de unidades asignadas finalmente a cada tratamiento, y si dicho número estuviera preestablecido se podrían tomar los grupos escogiendo muestras al azar de tamaños apropiados a partir de la totalidad de unidades experimentales. En la página 545 se dan instrucciones más detalladas para el uso de tablas de números aleatorios.

En los ensayos clínicos a menudo se desconoce con antelación el número total de pacientes, dado que muchos de ellos pueden estar disponibles para ser incluidos en el ensayo después de que éste ha comenzado. El método más simple consiste en asignar el tratamiento mediante una elección aleatoria independiente para cada paciente. Existe un método en el cual el número de unidades asignadas a cada tratamiento se mantiene igual. Éste se denomina *aleatorización restringida o por bloques permutados* y se describe en la página 545.

A veces se utiliza, como método alternativo a la asignación aleatoria, una forma de *asignación sistemática*, análoga a la del muestreo sistemático. Las unidades se colocan en un orden determinado y a continuación se asignan sistemáticamente a los grupos de tratamiento. Por ejemplo, en un ensayo clínico con entrada seriada se podría llevar a cabo una asignación de los dos tratamientos mediante una estricta alternancia. Este método presenta casi todas las ventajas y desventajas del muestreo sistemático. Sólo es desaconsejable cuando la ordenación inicial de las unidades presenta alguna variación sistemática de tipo cíclico que transcurra al mismo tiempo que el ciclo de asignación. En los ensayos clínicos es poco probable que esto ocurra, pero, si la asignación es sistemática y por consiguiente conocida para el investigador responsable de formar las listas de pacientes, aquél podría estar influido por este conocimiento al decidir la ordenación y, por ello, originar un sesgo (v. apartado 6.5). La alternancia y otras formas de asignación sistemática deberían evitarse en favor de los métodos aleatorios estrictos.

Un segundo principio importante del diseño experimental es el de la *replicación o repetición*, el uso de más de una unidad experimental para cada tratamiento. Con la replicación se cumplen varios propósitos. En primer lugar, una cantidad adecuada de replicación asegura que las comparaciones entre tratamientos sean suficientemente precisas; por ejemplo, el error tipo de la diferencia entre dos medias disminuye a medida que aumenta la cantidad de replicación en cada grupo. En segundo lugar, el efecto de la variabilidad del muestreo sólo puede estimarse si existe un grado adecuado de replicación. Por ejemplo, al comparar las medias de dos grupos, si el tamaño de ambas muestras fuera 2 los grados de libertad en el test t de Student serían sólo 2 (apartado 4.4); los valores de t para 2 gl son muy elevados y, por lo tanto, el test pierde mucha efectividad, simplemente a causa de la falta de adecuación de la estimación de la variancia intragrupos. En tercer lugar, la replicación puede ser útil para permitir que las observaciones cubran una gran variedad de circunstancias experimentales. Por ejemplo, al comparar dos técnicas quirúrgicas, podría ser útil organizar un ensayo cooperativo en el que se compararan los métodos en cierto número de hospitales para estudiar los efectos de las variaciones en la práctica médica y quirúrgica y, quizás, en el tipo concreto de enfermedad.

Un tercer principio básico hace referencia a la reducción de la variabilidad debida al azar entre las unidades experimentales. La fórmula del error tipo de una media, $\sigma/\sqrt{n}$, muestra que el efecto del error aleatorio puede reducirse aumentando n (más replicación) o disminuyen-

do σ . Esto sugiere que las unidades experimentales deberían ser lo más homogéneas posible en su respuesta al tratamiento. Sin embargo, un esfuerzo tan importante para hacer desaparecer la heterogeneidad tenderá a ser contradictorio con el tercer propósito de la replicación planteado, es decir el deseo de cubrir una amplia variedad de circunstancias que no son objeto de estudio. Por ejemplo, en un ensayo clínico se puede realizar una comparación precisa restringiendo la edad, el sexo, la situación clínica y otras características de los pacientes, pero estas restricciones pueden dificultar la generalización a partir de los resultados. Una solución útil a este problema consiste en subdividir las unidades en subgrupos relativamente homogéneos, a los que se denomina *bloques*. A continuación se pueden asignar al azar los tratamientos dentro de los bloques para que cada uno de ellos constituya un pequeño experimento. La precisión del conjunto de comparaciones entre tratamientos se determina mediante la variabilidad en los bloques debida al azar más que por la que existe *entre* los distintos bloques. Esto se denomina *diseño en bloques aleatorios*. En el capítulo 8 se estudian diseños más complejos, que permiten simultáneamente más de una fuente de variación extraña. Otros aspectos tratados en dicho capítulo son los diseños para comparar simultáneamente más de un conjunto de tratamientos, aquellos que son apropiados para situaciones similares a las del muestreo por etapas múltiples en las que algunas unidades son subdivisiones de otras y aquellos que permiten tener en cuenta las diversas formas de restricción natural impuestas por el material experimental.

Ya hemos mencionado un tipo importante de experimentos controlados: los ensayos clínicos y profilácticos. Éstos ejemplifican la mayoría de las características generales de la experimentación, aunque también hacen emerger algunos problemas especiales que se tratarán con mayor extensión en el siguiente apartado.

6.5. Ensayos clínicos

Los ensayos clínicos son experimentos controlados para comparar la efectividad de diferentes medidas terapéuticas. El término *ensayo clínico* se utiliza a menudo en un sentido amplio para incluir los ensayos controlados de medidas profilácticas en individuos que todavía no padecen la enfermedad en estudio y los ensayos sobre aspectos administrativos de los cuidados médicos, como la elección del cuidado domiciliario u hospitalario para un tipo de paciente determinado. Cochrane (1972) utiliza el término *ensayo controlado aleatorio*.

Los ensayos clínicos efectuados con la finalidad de ser estudios de investigación autorizados, con asignación al azar, reciben el nombre de ensayos clínicos de *fase III*. Los estudios de *fase I* son proyectos iniciales para delimitar las dosis, a menudo con voluntarios normales. Los ensayos clínicos de *fase II* son pequeños estudios de detección en pacientes, diseñados para seleccionar los agentes suficientemente prometedores para garantizar el inicio de ensayos clínicos de fase III más amplios. Los estudios de *fase IV* están relacionados con la vigilancia poscomercialización y normalmente toman la forma de sondeos y no de ensayos clínicos comparativos.

Los ensayos clínicos y profilácticos, controlados estrictamente mediante asignación al azar, datan de la década de 1940. La mayoría de los primeros ensayos de colaboración organizados por el Medical Research Council fueron descritos por Hill (1962). Cualquier propuesta para realizar un ensayo clínico se debe examinar cuidadosamente desde un punto de vista

ético, para que ningún médico permita que se administre a un paciente bajo sus cuidados un tratamiento considerado claramente inferior, excepto que el problema tratado sea muy benigno. Existen muchas situaciones en las que los beneficios relativos de los tratamientos alternativos no son en modo alguno evidentes. Los médicos pueden aceptar en estos casos la asignación al azar, hasta que la duda se resuelva. La posibilidad de que la acumulación gradual de datos modifique la postura ética del investigador puede conducir a la adopción de un diseño *secuencial* (cap. 15).

La organización de un ensayo clínico requiere una planificación previa cuidadosa. Esto es particularmente cierto en los ensayos multicéntricos, que son cada vez más comunes en el estudio de las enfermedades crónicas y en otras afecciones que se presentan de forma demasiado excepcional en un centro para proporcionar un número suficiente de casos. Los objetivos y los métodos del ensayo deberán describirse con detalle en un documento, que suele denominarse *protocolo*. Éste contendrá los detalles médicos y administrativos específicos del problema en estudio. Asimismo, debería incluir definiciones claras sobre los tipos de pacientes que se admitirán y las medidas terapéuticas que se utilizarían. Se debe establecer el número de pacientes y la duración prevista del reclutamiento y, cuando sea procedente, la duración del seguimiento; en el apartado 6.6 se describen algunos métodos relevantes. Dado que no es posible abarcar todos los aspectos de la planificación y ejecución de un ensayo se recomienda consultar a Hill (1991, cap. 23), Schwartz et al (1980), Friedman et al (1985), Shapiro y Louis (1983), Pocock (1983) y Busye et al (1984). Uno o dos aspectos merecen una atención especial. La exposición que sigue está dirigida a los ensayos terapéuticos, aunque la mayoría de los puntos son igualmente aplicables al contexto de los ensayos en medicina preventiva o cuidados médicos.

Definición de los pacientes

La gran mayoría de las enfermedades que se han de estudiar debe quedar clara en las fases iniciales de la planificación. Los detalles menores pueden estar menos establecidos. ¿Debe limitarse el sexo y la edad de los pacientes? ¿Ha de definirse la gravedad de la enfermedad con criterios estrictos? ¿Debe excluirse a los pacientes con ciertas situaciones asociadas? Estos criterios de elección han de considerarse de forma diferente en cada ensayo, pero el punto comentado en párrafos anteriores, al hacer referencia a la replicación, debería estar presente. Es prudente inclinarse en la dirección de la permisividad. Esto no sólo incrementará el número de pacientes (con la condición de que los recursos necesarios para su inclusión estén disponibles), sino que también permitirá comparar los tratamientos por separado para cada categoría de pacientes. La admisión de un amplio espectro de pacientes no impide en modo alguno su división en subgrupos homogéneos para el análisis de los resultados. Sin embargo, es menos probable que las comparaciones basadas en pequeños subgrupos detecten las diferencias reales entre los efectos del tratamiento que las pruebas basadas en el conjunto completo de datos. Existe además el peligro de que, al efectuar demasiadas comparaciones sobre diferentes subgrupos, una o más pruebas tengan fácilmente un resultado significativo debido sólo al azar (v. comentarios sobre el «dragado de datos» en el apartado 7.4). Los subgrupos que *a priori* llaman la atención se deberían definir en el protocolo y considerarlos al planificar el tamaño del ensayo.

Definición de los tratamientos

También las pautas terapéuticas que se deben comparar suelen conocerse ampliamente desde el inicio. ¿Debe definirse y estandarizarse hasta el último detalle? En un ensayo multicéntrico, los diferentes centros pueden desear adoptar variantes menores de la misma pauta o utilizar diferentes terapias concomitantes. Con frecuencia es mejor permitir la inclusión de todas estas variaciones en el estudio, en particular si son comunes en la práctica médica, que introducir un grado de estandarización que no pueda ser aceptado ampliamente durante el ensayo o más adelante.

En muchas medidas terapéuticas es común modificar el programa previsto de acuerdo con las circunstancias del paciente. Por ejemplo, la dosis de un fármaco puede depender de la respuesta terapéutica o de la aparición de efectos secundarios. En los ensayos con tales tratamientos existe un fuerte motivo para mantener la flexibilidad; muchos ensayos han recibido críticas una vez concluidos debido a que los regímenes de tratamiento habían sido excesivamente rígidos.

Valoración de la respuesta

Los efectos relativos de los tratamientos se compararán midiendo una o más respuestas en cada paciente en uno o varios momentos, tras el inicio del tratamiento. Dichas respuestas pueden consistir en síntomas relatados por el paciente, signos comprobados por el médico o medidas técnicas, como los resultados de las pruebas analíticas. A menudo es posible que la medida de la respuesta esté influida por el hecho de que el paciente, el médico o cualquier asistente técnico que participe en la medición conozcan el tratamiento utilizado. Si no se toman precauciones, se pueden presentar sesgos importantes. Pueden aparecer falsas diferencias entre tratamientos que tenían la misma efectividad u obtener resultados similares entre tratamientos que difieren realmente en sus efectos.

En un ensayo por *simple ciego*, el paciente ignora la identidad del tratamiento asignado. Un ensayo por *doble ciego* es aquel en el cual el médico u otro experto técnico que valora la respuesta también desconoce la identidad del tratamiento. En los ensayos clínicos, el enmascaramiento suele realizarse mediante fórmulas especiales de fármacos. Por supuesto, algunos fármacos producen efectos colaterales característicos que no pueden ser ocultados al médico o incluso a un paciente bien informado. Si el ensayo está diseñado para valorar la efectividad de un medicamento concreto en comparación con la ausencia de tratamiento, puede existir una diferencia en la respuesta que es bastante inespecífica (debida al hecho de hacer algo frente a no hacer nada). Suele conseguirse un control efectivo de este problema mediante el uso de un *placebo* (una preparación inerte elaborada de forma tal que sea indistinguible del agente supuestamente activo).

Entrada en el estudio y asignación del tratamiento

Como ya se ha mencionado, el protocolo definirá los criterios de inclusión de los pacientes para su admisión en el ensayo. Puede ser útil para cada centro mantener un registro de todos

los pacientes considerados para su posible admisión (p. ej., todos los pacientes con la enfermedad en cuestión) con el fin de mostrar el grado en que los pacientes participantes en el ensayo han sido seleccionados sobre la población total de pacientes y (si se efectúa una selección posterior) sobre la población que satisface los criterios de inclusión.

Un paciente elegible se debería admitir formalmente en el ensayo introduciendo su nombre en un registro y asignándole un número seriado. Se debe determinar la asignación al azar del tratamiento lo antes posible. Es importante que la asignación no se conozca antes de la admisión, porque el conocimiento o la sospecha del tratamiento que corresponderá al próximo paciente puede afectar la decisión del investigador de admitir o no a un enfermo concreto cuya entrada se está considerando. Esto excluye claramente los sistemas de asignación sistemática y pone de relieve que las futuras asignaciones al azar deben, de algún modo, ser desconocidas para el investigador. También se deberían evitar los sistemas de codificación rígidos, como aquellos en los que se codifica como X el fármaco activo y como Y el placebo: con estos sistemas, si el código no se cumple en un paciente, dicho incumplimiento se mantiene durante el resto del ensayo. Con frecuencia resulta satisfactorio utilizar sobres cerrados que llevan en el exterior el número seriado y en el interior la asignación del tratamiento. En muchos ensayos multicéntricos la asignación se realiza a través de una llamada telefónica a un centro coordinador que cuenta con la lista de asignación aleatoria.

Esta lista debe prepararse con antelación. Como se mencionó en el apartado 6.4, se puede utilizar la asignación aleatoria restringida (bloques permutados), para asegurar que los números de pacientes asignados a los diferentes tratamientos se mantengan parejos. Este tipo de esquema se puede aplicar separadamente a cada centro y quizá también a varios subgrupos o estratos definidos por variables de importancia pronóstica. La estratificación pronóstica se debe mantener en un mínimo. No es necesario estratificar numerosos factores, porque el efecto de estas variables se puede tener en cuenta en análisis posteriores; si se utilizan muchos factores, la mayoría de los estratos serán demasiado pequeños para permitir una comparación adecuada de los tratamientos. Además, muchos médicos que intervienen en el ensayo clínico prefieren no estratificar, y depositan su confianza en la selección aleatoria para conseguir una amplia similitud entre los grupos de tratamiento y ajustan después los efectos de las variables pronósticas.

Una alternativa a la asignación aleatoria por bloques permutados, cuando es necesario equilibrar los grupos simultáneamente para varias variables pronósticas, es proporcionada por diversas formas de *minimización*. El objetivo en este caso consiste en asignar a los pacientes de manera que se minimice (en cierto sentido) la disparidad presente entre los grupos, teniendo en cuenta simultáneamente una diversidad de variables pronósticas. La minimización se ejecuta de manera más óptima con la ayuda de un ordenador. Véase una descripción más detallada en Pocock (1983, pp. 83-86).

Exclusiones, retiradas y desviaciones del protocolo

Los pacientes no deberían ser excluidos, salvo raras excepciones, después de la asignación aleatoria de tratamiento. La posibilidad de excluir a un paciente determinado puede depender del tratamiento recibido, y el hecho de permitir la retirada de los pacientes puede afectar la efectividad de la asignación aleatoria y producir comparaciones sesgadas.

Puede ocurrir que un pequeño número de pacientes no cumpla los criterios de inclusión después de la asignación aleatoria: sólo deben ser omitidos si queda claro que no se produce sesgo alguno (p. ej. cuando las pruebas diagnósticas se han realizado antes de la asignación aleatoria, pero no se dispone de los resultados hasta después de cierto tiempo).

Una fuente de problemas más importante es la aparición de desviaciones con respecto a los procedimientos terapéuticos considerados en el protocolo. Se debería intentar animar a los participantes a seguir rigurosamente el protocolo y excluir, mediante los criterios de inclusión, los tipos de pacientes (como los de edad avanzada) que estén relacionados con la causa de las desviaciones del protocolo. Sin embargo, algunas desviaciones son más difíciles de evitar y pueden implicar la retirada del tratamiento asignado y su sustitución por otro alternativo o que el paciente abandone los cuidados del investigador. Sería bastante incorrecto excluir tales casos de los grupos a los que fueron asignados. Éstos son casi siempre atípicos con respecto a la población global, y es posible que algunas formas de desviación del protocolo aparezcan con mayor probabilidad con uno de ambos tratamientos. Además, la cuestión planteada en el ensayo es exactamente la comparación de una estrategia frente a otra, estrategias que consisten en utilizar regímenes terapéuticos particulares, cuando sea posible, sabiendo que necesariamente se producirán desviaciones en pacientes individuales. Desde un punto de vista pragmático (Schwartz y Lellouch, 1967), tanto las desviaciones del protocolo como los casos en los que se puede mantener el tratamiento ideal constituyen parte de la estrategia global de tratamiento.

Del mismo modo, es peligroso omitir en el análisis de los ensayos cualquier acontecimiento u otras respuestas que aparezcan durante períodos especificados después de iniciado el tratamiento. Por ejemplo, se puede pensar que un medicamento no ejerce efecto alguno antes de transcurrida una semana y que se deban descartar los efectos adversos que aparezcan en dicho período. Estos efectos se deberían omitir sólo cuando se acepte universalmente la suposición subyacente; si no, se plantea nuevamente la posibilidad de sesgos. Del mismo modo, los acontecimientos, como las muertes accidentales que se consideren no relacionadas con la enfermedad en cuestión, deberían soslayarse sólo si su irrelevancia está fuera de toda disputa (¡y esto raras veces ocurre en las muertes accidentales!).

El criterio de incluir en el análisis, en lo posible, a todos los pacientes de los grupos a los que fueron asignados aleatoriamente recibe el nombre de método de *intención de tratar*. Surgirán dificultades si los pacientes se han retirado del estudio antes de medir la respuesta pertinente. En los ensayos clínicos en los que el principal criterio de respuesta es la mortalidad, es posible determinar el estado de supervivencia de cada paciente en un intervalo específico después de entrar en el estudio, a partir de un sistema de registro nacional de mortalidad. En otros ensayos clínicos, en los que las respuestas clínicas cruciales se miden en los exámenes de seguimiento, es posible que inevitablemente falten algunas lecturas. Este problema no tiene soluciones completamente satisfactorias. Un método consiste en pasar a cuenta nueva la última respuesta disponible de cada paciente. Otro consiste en asignar una puntuación arbitrariamente baja a la respuesta ausente. Brown (1992), por ejemplo, sugiere asignar una puntuación igual a la respuesta mediana observada en un grupo con placebo y, a continuación, agrupar en una categoría amplia de respuesta a los pacientes de todos los grupos con una puntuación igual o peor. Seguidamente se pueden comparar los grupos de tratamiento mediante el test de Mann-Whitney (apartado 13.3). Este tipo de métodos puede ser de utilidad, incluso inevitable, si hay respuestas cruciales ausentes, pero implica el sacrificio de la

información, y la estimación puede resultar sesgada. La mejor solución consiste en evitar al máximo posible las retiradas mediante una meticulosa planificación.

Metaanálisis: revisiones

Con la reciente proliferación de ensayos clínicos es cada vez más frecuente encontrar varios ensayos realizados con protocolos que guardan una estrecha relación entre sí. Es improbable que los ensayos clínicos sean duplicados exactos: los agentes investigados pueden ser administrados de diferentes maneras o con dosificaciones diferentes o pueden ser sustancias diferentes aunque relacionadas; los pacientes se encontrarán en la misma categoría amplia de enfermedad, pero los criterios de inclusión, como la edad o la gravedad de la enfermedad, pueden variar. En estas situaciones, las comparaciones entre tratamientos no serán idénticas entre un ensayo clínico y otro, pero cabe esperar que sean similares. Los resultados de un ensayo clínico determinado pueden tener demasiado error aleatorio para dar una indicación clara de la eficacia relativa de los tratamientos, mientras que todo el conjunto de datos puede presentar un aspecto coherente, con una estimación más precisa del efecto del tratamiento debido al mayor tamaño de la muestra.

Los estudios que combinan datos de ensayos clínicos relacionados se denominan *metaanálisis* o *revisiones*. Algunos ejemplos serían los metaanálisis del bloqueo beta en el infarto de miocardio (Yusuf et al, 1985), el tratamiento antiplaquetario en las enfermedades vasculares (Antiplatelet Trialists' Collaboration, 1988) y las terapias hormonal o citotóxica o la inmunoterapia para el cáncer precoz de mama (Early Breast Cancer Trialists' Collaborative Group, 1992).

En el apartado 7.2 se describen algunos métodos estadísticos útiles para los metaanálisis. Un punto importante que se ha de considerar es que los datos de diferentes ensayos clínicos no deben ser agrupados antes de hacer comparaciones entre los tratamientos. Cada ensayo clínico es un «bloque», en el sentido explicado en el apartado 6.4. Se hacen contrastes entre tratamientos por separado en cada ensayo clínico, se examina su coherencia entre un ensayo y otro y, a continuación, se juntan para proporcionar una estimación global de un efecto terapéutico.

Hay que tener la precaución de asegurarse de que la selección de los estudios no introduzca sesgo alguno. Por ejemplo, puede ser importante incluir datos no publicados y publicados, ya que es más probable que los ensayos clínicos que muestran pruebas claras de efectos terapéuticos sean publicados que los que no muestran estas pruebas (fenómeno conocido como *sesgo de publicación*). Véase un análisis más detallado de los principios fundamentales de los metaanálisis, por ejemplo los artículos, en Yusuf et al, (1987) y también en Chalmers et al, (1987).

Test de equivalencia

Algunos ensayos clínicos no tienen la finalidad de detectar posibles diferencias en la eficacia, sino mostrar que los tratamientos, dentro de ciertos límites estrechos, son igualmente eficaces. Esta situación se origina en particular en los estudios de fase I llevados a cabo en

la industria farmacéutica. Estos *estudios de equivalencia* pueden referirse a los niveles séricos producidos por diferentes formulaciones del mismo agente activo o pueden implicar respuestas clínicas a fármacos estrechamente relacionados.

En un estudio de equivalencia, un test de la hipótesis nula de igual eficacia es inaplicable, ya que un test con un número excesivamente bajo de observaciones no podrá excluir diferencias posiblemente importantes. Supóngase que la diferencia pertinente en la eficacia es medida por un parámetro θ , asumiendo el valor cero cuando los tratamientos son igualmente eficaces. Es necesario definir dos límites de tolerancia $\theta_l < 0$ y $\theta_s > 0$, el intervalo entre el que están los límites de equivalencia. El investigador se encontrará en posición de asegurar una equivalencia si puede afirmarse que $\theta > \theta_l$ y también que $\theta < \theta_s$. Sería necesario confirmar estas últimas afirmaciones mediante tests de significación tipo frente a dos límites de tolerancia o, de forma equivalente, observando que el intervalo de confianza adecuado para θ se encuentra totalmente dentro de los límites de equivalencia (si los tests unilaterales contra los límites de tolerancia está por ejemplo, al nivel del 5%, el coeficiente de confianza equivalente tiene que ser el 90%).

6.6. El tamaño de una investigación estadística

Una de las preguntas que se plantean con mayor frecuencia en la planificación de un estudio estadístico, y también una de las más difíciles de responder, es: ¿cuántas observaciones se deben efectuar? Cuanto mayor es el tamaño de la muestra o la longitud del experimento, más precisas serán las estimaciones de los parámetros y de sus diferencias. La dificultad estriba en decidir qué grado de precisión se debe pretender. Un incremento del tamaño de un estudio o de un experimento cuesta más dinero y requiere más tiempo. En ocasiones, los recursos financieros o el tiempo disponible imponen un límite y el investigador deseará efectuar tantas observaciones como permitan los recursos, teniendo en cuenta en el presupuesto el tiempo y los costes del proceso de análisis de los datos. En otras situaciones no existirán límites evidentes y el investigador deberá ponderar los beneficios que implica aumentar la precisión frente al coste de aumentar la recogida de datos o la experimentación. En algunas ramas de la tecnología, el problema se puede analizar desde un punto de vista puramente económico, aunque ello será posible en muy pocas ocasiones en investigación médica porque es difícil medir en términos financieros los beneficios de la información experimental o de encuestas.

En cualquier revisión de estos problemas en la fase de planificación es probable que sea importante relacionar el tamaño de la muestra con un grado de precisión determinado. Consideraremos el problema de comparar las medias de dos poblaciones, μ_1 y μ_2 , suponiendo que tienen la misma desviación tipo σ , y que se deben tomar dos muestras aleatorias iguales de tamaño n . Si se sabe que las dos desviaciones tipo son distintas, los resultados siguientes pueden considerarse como una aproximación (tomando σ^2 como la media de las dos variancias). Si se comparan dos proporciones, π_1 y π_2 , σ puede ser aproximada mediante el siguiente promedio:

$$\sqrt{\frac{1}{2}[\pi_1(1 - \pi_1) + \pi_2(1 - \pi_2)]}$$

Consideremos ahora tres maneras posibles de especificar la precisión deseada.

1. *Dado el error tipo.* Supóngase que se exige que el error tipo de la diferencia entre las medias observadas, $\bar{x}_1 - \bar{x}_2$, sea menor que ε , lo cual equivale a decir que la amplitud de los intervalos de confianza del 95% no ha de ser superior a $\pm 2\varepsilon$. Esto implica que:

$$\sigma \sqrt{(2/n)} < \varepsilon$$

o

$$n > 2\sigma^2/\varepsilon^2$$
(6.4)

Si el requisito es que el error tipo de la media de la muestra sea menor que ε , la desigualdad correspondiente para n es:

$$n > \sigma^2/\varepsilon^2$$
(6.5)

2. *Dada la diferencia que ha de ser significativa.* Podríamos requerir que cuando $\bar{x}_1 - \bar{x}_2$ fuera mayor en valores absolutos que algún valor d_0 , entonces fuera significativa a algún nivel determinado (digamos a nivel bilateral 2α). Si simbolizamos por $z_{2\alpha}$ la desviación normal estandarizada excedida (en ambas direcciones) con una probabilidad 2α (para $2\alpha = 0,05$, $z_{2\alpha} = 1,96$). Entonces:

$$d_1 > z_{2\alpha} \sigma \sqrt{(2/n)}$$

$$n > 2 \left(\frac{z_{2\alpha} \sigma}{d_1} \right)^2$$
(6.6)

3. *Dado un poder frente a una diferencia especificada.* El criterio 2 se define en términos de una diferencia observada, d . La verdadera diferencia, δ , puede ser mayor o menor que d , y parece preferible basar el requisito en el valor de δ . Podría ser posible especificar un valor de δ que llamaremos δ_0 , que uno no quisiera dejar de detectar, en el sentido de que cuando $\delta > \delta_0$ se espera obtener un resultado significativo al nivel bilateral, por ejemplo, 2α . Sin embargo, no se puede garantizar una diferencia significativa. Las fluctuaciones del muestreo pueden producir un valor de $|d|$ mucho menor que $|\delta|$ y no significativamente distinto de cero. La probabilidad de que esto ocurra se simboliza por β y hace referencia al *error de tipo II*, es decir, la probabilidad de no llegar a detectar una diferencia real (falso negativo). El nivel de significación hace referencia al *error tipo I*, que es la probabilidad de rechazar incorrectamente la hipótesis nula (falso positivo). Mientras que el error de tipo I se mantiene en valores bajos eligiendo el nivel de significación apropiado durante el análisis, el error de tipo II sólo puede controlarse durante la etapa del diseño. Se podría especificar que el error de tipo II no fuera mayor que un valor bajo determinado o, de manera equivalente, que la probabilidad de detectar correctamente la diferencia como significativa, $1 - \beta$, no debería ser menor que un valor alto determinado. Este valor se denomina *poder* del estudio.

La situación se representa en la figura 6.1. Los valores positivos de d son significativos al nivel establecido si:

$$d > z_{2\alpha} \text{ET}(d)$$
(6.7)




Fig. 6.1. Distribuciones de d . La distribución de la izquierda representa la hipótesis nula y la de la derecha la hipótesis alternativa. El área sombreada verticalmente representa el nivel de significación (error de tipo I), y el área sombreada horizontalmente, el error de tipo II.

es decir, d se encuentra más allá del punto A. Para un poder $> 1 - \beta$ el punto A debe encontrarse a la izquierda de un punto que limita una probabilidad unilateral igual a β en la distribución de la derecha. Es decir:

$$z_{2\alpha} \text{ET}(d) < \delta_0 - z_{2\beta} \text{ET}(d)$$

o

$$\delta_1 > (z_{2\alpha} + z_{2\beta}) \text{ET}(d) \quad (6.8)$$

Si d representa la diferencia $\bar{x}_1 - \bar{x}_2$ de las medias de una variable continua entre dos grupos, cada uno de ellos de tamaño n , entonces $\text{ET}(d) = \sigma \sqrt{(2/n)}$ y (6.8) se transforma en:

$$n > 2 \left[\frac{(z_{2\alpha} + z_{2\beta})\sigma}{\delta_1} \right]^2 \quad (6.9)$$

La distinción entre 2 y 3 es importante. Por ejemplo, si $2\alpha = 0,05$ y $1 - \beta = 0,95$, $z_{2\alpha} = 1,96$ y $z_{2\beta} = 1,64$. Si se iguala d_0 a δ_0 , los valores de n dados por (6,9) y (6.6) presentan la relación $(1,96 + 1,64)^2 : 1,96^2$ o 3,4:1.

Hemos supuesto, tanto en 2 como en 3, que la hipótesis nula que se está examinando especifica un valor cero para la diferencia verdadera, δ . Esto suele ocurrir así, pero hay situaciones en las que la hipótesis nula especifica un valor no igual a cero, δ_0 para δ . Por ejemplo, en un test de equivalencia (apartado 6.5), se podría hacer el test contra cualquiera de los dos límites de tolerancia (θ_l y θ_s en el apartado 6.5), requiriendo una potencia alta si el valor verdadero de δ está suficientemente dentro de los límites de tolerancia (θ_l , θ_s). En general, en los ensayos clínicos, es posible que se desee examinar si una diferencia es claramente superior a la diferencia «importante» mínima (v. fig. 4.1), y no simplemente si es superior a cero (Meier, 1975; Freedman et al, 1984). Las fórmulas (6.6) a (6.9) siguen siendo válidas, siempre que d_0 se interprete como la diferencia entre $\bar{x}_1 - \bar{x}_2$ y δ_0 , y δ_1 sea reemplazado por $\delta_1 - \delta_0$.

Ejemplo 6.3

Se debe comparar la función pulmonar de dos grupos de varones mediante el volumen espiratorio forzado (PEV). Según trabajos previos, la desviación tipo del PEV es 0,51. Se utiliza un nivel de sig-

nificación bilateral del 0,05 y se requiere un poder del 80% para detectar una diferencia en las medias entre ambos grupos de 0,25. ¿Cuántos individuos debe haber en cada grupo?

Utilizando (6.9) con $z_{2\alpha} = 1,96$, $z_{2\beta} = 0,842$, $\sigma = 0,5$ y $\delta_0 = 0,25$ obtenemos:

$$n > 2 \left[\frac{(1,96 + 0,842)(0,5)}{0,25} \right]^2 \\ = 62,8$$

Por consiguiente se deben incluir 63 individuos en cada grupo.

El problema del tamaño de la muestra se expresa generalmente como un problema de determinar el *tamaño de la muestra* dado el *poder* y la magnitud del *efecto especificado* que se va a detectar. Pero podría considerarse como el problema de encontrar cualquiera de estos tres elementos para valores determinados de los otros dos. Éste es muchas veces un método útil, ya que el tamaño de la muestra puede estar limitado por otras consideraciones. Luego, las preguntas pertinentes son: ¿qué efecto podría detectarse o cuál sería el poder? El ejemplo siguiente examina el problema inverso de estimar qué puede conseguirse con un tamaño determinado de la muestra.

Ejemplo 6.4

Examinemos la situación del ejemplo 6.3, pero supóngase que se dispone de recursos para incluir sólo a 50 varones de cada grupo.

a) ¿Cuál sería el poder del estudio?

Sustituyendo en (6.9) con $z_{2\beta}$ desconocido se obtiene:

$$50 = 2 \left[\frac{(1,96 + z_{2\beta})(0,5)}{0,25} \right]^2$$

y, por consiguiente:

$$z_{2\beta} = 0,540$$

Según la tabla A1 del apéndice este valor corresponde a un poder de:

$$1 - 0,2946 = 0,7054 \text{ o } 71\%$$

b) ¿Qué tamaño de la diferencia media entre los grupos podría detectarse con un poder del 80%?

Sustituyendo en (6.9) δ_0 desconocido se obtiene:

$$50 = 2 \left[\frac{(1,96 + 0,842)(0,5)}{\delta_1} \right]^2$$

y, por consiguiente, $\delta_0 = 0,28$. Podría detectarse una diferencia media de 0,281.

Obsérvese que si ya se ha determinado el tamaño de la muestra para una δ_0 especificada, el valor revisado se obtiene rápidamente señalando que la diferencia que se puede detectar es proporcional a la recíproca de la raíz cuadrada del tamaño de la muestra. Por lo tanto, puesto que $\delta_0 = 0,25$, se calculó una muestra de tamaño 62,8; luego, para una muestra de tamaño 50 tenemos un $\delta_0 = 0,25 \times \sqrt{(62,8/50)} = 0,28$.

Las fórmulas presentadas supone conocer la desviación tipo, σ . En la práctica, raras veces se la conoce previamente, pero el investigador podrá utilizar algunas estimaciones de σ basadas en datos previos que considere razonablemente precisos. Las aproximaciones enumeradas anteriormente se pueden modificar de dos maneras. La primera consistirá en reconocer que los valores exigidos de n sólo se pueden especificar en términos de la razón de un intervalo crítico (ε , d_0 o δ_0) frente a una desviación tipo estimada o verdadera (s o σ). Por ejemplo, en 1 podríamos especificar el error tipo estimado como un múltiplo determinado de s ; en 2, d_0 se debería especificar como cierto múltiplo de s ; en 3, el poder podría especificarse frente a un cociente determinado de δ_0 y σ . En 2 y en 3, como el contraste de hipótesis utiliza la distribución t más que la normal, los valores exigidos para n serán mayores que los ofrecidos por (6.6) o (6.9), pero los ajustes sólo serán importantes para muestras pequeñas, es decir, las que den 30 gl o menos para la desviación tipo (DT) estimada. En este caso se puede obtener un tamaño de muestra ajustado mediante un segundo uso de (6.9), reemplazando $z_{2\alpha}$ y $z_{2\beta}$ por los valores correspondientes de la distribución t , con los grados de libertad dados por el tamaño de la muestra obtenido en la aplicación inicial de (6.9).

La especificación de las distancias críticas como múltiplos de una desviación tipo desconocida constituyen una sugerencia atractiva. Una aproximación alternativa podría ser estimar σ mediante una experiencia piloto pequeña y, a continuación, utilizar este valor en las fórmulas (6.4) y (6.9) para proporcionar una estimación del tamaño total de la muestra, n . De nuevo, es necesario realizar algún ajuste a causa de la incertidumbre introducida por la estimación de σ , aunque el efecto será pequeño siempre que la muestra piloto inicial no sea demasiado pequeña.

El análisis anterior se ha planteado en términos de dos muestras independientes, en que el análisis es el test de la t para dos muestras (apartado 4.4). Si los dos grupos son apareados, el método de análisis sería el test de la t para datos apareados y se emplearía la fórmula 6.8 sustituyendo el $ET(d)$ por $\sigma/\sqrt{n}$, donde σ es la desviación tipo de la diferencia entre valores apareados y n es el número de pares. En términos de los métodos de análisis de la variancia, que se introducirán en el capítulo 7, σ es la desviación tipo «residual».

La comparación de dos proporciones independientes sigue un enfoque similar. En este caso, el error tipo de la diferencia depende de los valores de las proporciones (apartado 4.8). Según la aproximación 3, la especificación consistiría en la necesidad de detectar una diferencia entre las proporciones verdaderas π_1 y π_2 , utilizando un test de la hipótesis nula, según la cual cada proporción es igual al valor promedio, π . La ecuación correspondiente a (6.9) es:

$$n > \left\{ \frac{z_{2\alpha} \sqrt{[2\pi(1-\pi)]} + z_{2\beta} \sqrt{[\pi_1(1-\pi_1) + \pi_2(1-\pi_2)]}}{\pi_1 - \pi_2} \right\}^2 \quad (6.10)$$

Esta ecuación es algo más complicada que (6.9) porque el error tipo de la diferencia entre las dos proporciones observadas es diferente para las hipótesis nula y alternativa (apartado 4.8).

El empleo de la fórmula 6.10 da tamaños de muestras que son adecuados cuando se va a determinar la significación estadística usando el test de la χ^2 corregido (4.21). Fleiss et al (1980) muestran que para el test con corrección de la continuidad (4.24), debería sumarse $2|\pi_1 - \pi_2|$ a la solución dada por (6.10).

Casagrande et al (1978) ofrecen tablas para determinar los tamaños de las muestras que están basadas en los tests exactos para tablas 2 x 2 (apartado 4.9) y Fleiss (1981) muestra un

conjunto detallado de tablas basadas en una fórmula que proporciona una buena aproximación a los valores exactos. En la tabla A9 se obtiene el tamaño de la muestra necesario en cada uno de los dos grupos, calculado usando (6.10) e incluyendo la corrección de la continuidad para algunas situaciones frecuentes. Aunque en general estamos a favor de los tests no corregidos, la tabla A9 se remite a la versión corregida puesto que en los casos en que la diferencia tiene consecuencias prácticas sería aconsejable estimar al alza.

Ejemplo 6.5

Se planea un ensayo sobre un nuevo tratamiento. La proporción de éxito del tratamiento tipo que se va a utilizar como control es 0,25. Si el nuevo tratamiento aumenta la razón de éxitos a 0,35 y se necesita detectar una mejoría con un nivel de significación bilateral del 5% y con un poder del 90%, ¿cuántos pacientes se deberían incluir en cada grupo?

Utilizando (6.10) con $\pi_1 = 0,25$, $\pi_2 = 0,35$, $\pi = 0,3$, $z_{2\alpha} = 1,96$ y $z_{2\beta} = 1,282$ obtenemos:

$$n > \left[\frac{1,96 \sqrt{0,42} + 1,282 \sqrt{(0,1875 + 0,2275)}}{0,1} \right]^2$$

$$= 439,4$$

Aplicando la corrección de Fleiss et al obtenemos:

$$n = 439,4 + 2/0,1$$

$$= 459,4$$

Según la tabla A9, el tamaño de la muestra es de 459 (el mismo valor se obtiene en las tablas de Casagrande et al y Fleiss).

Test de equivalencia

En el test de equivalencia (apartado 6.5), el problema del tamaño de la muestra es diferente. Si π_1 y π_2 son las tasas de éxito de dos tratamientos, sería necesario con un poder igual a $1 - \beta$ que el intervalo de confianza de la estimación de la diferencia $\pi_1 - \pi_2$ esté dentro de los límites θ_l y θ_s . A menudo se llevan a cabo ensayos clínicos de equivalencia para determinar que un tratamiento conservador propuesto (tratamiento 2) sea al menos tan bueno como el tratamiento existente (tratamiento 1). Por consiguiente, sólo el límite superior es pertinente, de modo que se emplea un intervalo de confianza unilateral. Si denotamos θ_s por δ ($> \pi_1 - \pi_2$), es necesario que el límite de confianza superior no exceda a δ . Con números iguales de pacientes en ambos grupos, el número de pacientes en cada grupo, n , está dado por:

$$n = [\pi_1(1 - \pi_1) + \pi_2(1 - \pi_2)] \left[\frac{z_{2\alpha} + z_{2\beta}}{\delta - (\pi_1 - \pi_2)} \right]^2 \quad (6.11)$$

(Makuch y Simon, 1978). A menudo es conveniente asumir que $\pi_1 = \pi_2 = \pi$ y (6.11) se simplifica a:

$$n = 2\pi(1 - \pi) \left(\frac{z_{1\alpha} + z_{2\beta}}{\delta} \right)^2 \quad (6.12)$$

La ecuación (6.12) también se aplica en el caso en que los dos tratamientos tienen condiciones iguales y se requiere que el intervalo de confianza esté dentro de los límites $-\delta$ y $+\delta$, pero entonces se establecería el valor de z_{α} para un intervalo bilateral.

Ejemplo 6.6

Se planea hacer un ensayo clínico sobre la reparación laparoscópica de la hernia en comparación con una reparación convencional de ésta. Con una reparación convencional, aproximadamente el 5% de los pacientes presentará una recurrencia de la hernia dentro de un plazo de 5 años debido a una ruptura de la reparación. Si la tasa de ruptura es la misma después de la reparación laparoscópica que de la convencional, ¿cuántos pacientes son necesarios para demostrar que la tasa de recurrencia con la reparación laparoscópica es, como mucho, un 5% superior que con la reparación convencional?

Con un poder del 80% y empleando un intervalo de confianza del 95%, el número de pacientes en cada grupo es, según (6.12):

$$2(0,95)(0,05) \left(\frac{1,645 + 0,842}{0,05} \right)^2 = 235$$

Por lo tanto, se necesitaría un total de 470 pacientes.

Machin y Campbell (1987) ofrecen tablas para el tamaño de la muestra en ensayos clínicos del test de equivalencia.

Estudios caso-control

En un estudio caso-control la medida de la asociación es la razón de probabilidad o riesgo relativo aproximado (apartado 4.8 y cap. 16). Para probar las hipótesis, los datos se disponen en una tabla 2 x 2 y el test de significación es por tanto una comparación entre las proporciones de los individuos en los grupos caso y control que están expuestos al factor de riesgo. Por consiguiente, el problema de la determinación del tamaño de la muestra se puede convertir al problema de comparar dos proporciones independientes. Los controles representan la población general y se requiere especificar la proporción de controles expuestos al factor de riesgo, p . El primer paso consiste en encontrar la proporción de casos, p' , que resultaría expuesta para una razón de probabilidad específica, OR_1 .

Por definición:

$$\frac{p'}{1 - p'} = OR_1 \times \frac{p}{1 - p}$$

Por consiguiente:

$$p' = OR_1 \times \frac{p}{p(OR_1) + 1 - p} \quad (6.13)$$

Para eliminar este paso y la necesidad de interpolar en tablas como la A9, se han elaborado tablas que están indexadas por la proporción de expuestos en los controles y el valor específico de la razón de probabilidad verdadera para el que se requiere establecer la significación estadística. La tabla A10 es una tabla breve que abarca las situaciones requeridas con frecuencia. Esta tabla se basa en (6.13) y en (6.10) con la corrección de la continuidad. Schlesselman (1982) ofrece un conjunto más amplio de tablas; éstas dan tamaños de muestras más pequeños que la tabla A10, puesto que Schlesselman no incluyó la adición de Fleiss para la corrección de la continuidad.

Ejemplo 6.7

Se planifica un estudio caso-control para valorar la relación entre una enfermedad y un factor de riesgo. Se estima que el 20% de la población general está expuesto al factor de riesgo. Se requiere detectar una asociación si el riesgo relativo es 2 o superior, con un poder del 80% al nivel de significación del 5%. ¿Cuántos casos y controles se requieren?

Usando (6.13) con una $p = 0,2$ y una $OR_1 = 2,0$ se obtiene $p' = 0,3333$. Así, usando (6.10), con $\pi_1 = 0,3333$ y $\pi_2 = 0,2$, y empleando la corrección de la continuidad, se obtiene $n = 186,5$. Por lo tanto, el estudio debe comprender por lo menos 187 casos y el mismo número de controles. Los cálculos anteriores pueden evitarse mediante el uso directo de la tabla A10, que da una $n = 187$.

Formulación inversa

Para el problema inverso de determinar el poder o el tamaño del efecto que se podría detectar con un tamaño de la muestra determinado pueden emplearse las fórmulas, pero las tablas son menos prácticas. Como muchas veces es necesario tener en cuenta lo que puede lograrse con una gama de tamaños de muestras, resulta práctico poder calcular soluciones aproximadas de manera más simple. Esto se consigue señalando que, en (6.9), δ_0 es proporcional a $1/\sqrt{n}$ y $z_{2\alpha} + z_{2\beta}$ es proporcional a $\sqrt{n}$. Estas relaciones se aplican exactamente para una variable continua, pero también forman una aproximación razonable para comparar proporciones.

Ejemplo 6.8

En el ejemplo 6.5 supongamos que sólo se dispone de 600 pacientes, de modo que $n = 300$.

a) ¿Qué tamaño de la diferencia podría detectarse con un poder del 90%?

Aproximadamente:

$$\begin{aligned}\delta_1 &= 0,10 \times \sqrt{(459,4/300)} \\ &= 0,124\end{aligned}$$

Empleando (6.10) se obtiene $\delta_0 = 0,126$, de modo que la aproximación es buena. Podría detectarse un aumento de la tasa de éxito hasta aproximadamente un 37,6%.

b) ¿Cuál sería el poder para detectar una diferencia de 0,1?

Aproximadamente

$$\begin{aligned}1,96 + z_{2\beta} &= (1,96 + 1,282) \times \sqrt{(300/459,4)} \\ &= 2,620\end{aligned}$$

Por consiguiente, $z_{2\beta} = 0,660$ y el poder revisado es 74,5%.

Empleando (6.10) se obtiene $z_{\alpha\beta} = 0,626$ y un poder revisado del 73,4%.

Grupos de tamaños desiguales

Por lo general, al comparar dos grupos, resulta óptimo tener números iguales en cada grupo. A veces, sin embargo, el número disponible en un grupo puede ser limitado, por ejemplo en el caso de una enfermedad rara en un estudio caso-control. En este caso se puede aumentar el poder en una cantidad limitada teniendo más en el otro grupo. Si un grupo contiene m sujetos, y el otro, rm , el estudio es aproximadamente equivalente a un estudio con n en cada grupo donde:

$$\frac{2}{n} = \frac{1}{m} + \frac{1}{rm}$$

O sea:

$$m = \frac{(r + 1)n}{2r} \quad (6.14)$$

Esta expresión se deduce igualando las expresiones para el error tipo de la diferencia entre dos medias usadas en un test de la t para dos muestras y es exacta para una variable continua y aproximada para la comparación de dos proporciones. Fleiss et al (1980) ofrecen una fórmula para el caso general de comparar dos proporciones cuando las dos muestras no tienen tamaños iguales, y su fórmula es adecuada para el problema inverso de estimar el poder a partir de tamaños de muestras conocidas.

El número total de sujetos en el estudio es:

$$\frac{(r + 1)^2}{4r} \times 2n$$

que es un mínimo para $r = 1$.

Ejemplo 6.9

En el ejemplo 6.7 supongamos que no se puede contar con 187 casos. ¿Cuántos casos serían necesarios si hubiese dos controles por caso?

Usando (6.14):

$$\begin{aligned} m &= \frac{3(186,5)}{4} \\ &= 139,9 \end{aligned}$$

Es decir, serían necesarios 140 casos y 280 controles. Usando la fórmula más exacta ofrecida por Fleiss et al (1980), $m = 132,8$, de modo que la aproximación ha sobrestimado ligeramente el tamaño de la muestra.

Retiradas y desviaciones del protocolo

Puede tenerse en cuenta una proporción de sujetos que se retiran o que se pierden a lo largo del estudio. Si una proporción θ se pierde, de modo que las variables de resultado no se registran, el análisis final se basará en $1 - \theta$ veces el número de sujetos que entran en el estudio. Para asegurar un tamaño suficiente de la muestra al final del estudio sería necesario empezar con una muestra de tamaño n' , dado por:

$$n' = \frac{n}{1 - \theta}$$

donde n es el tamaño de la muestra determinado por los métodos presentados previamente en este apartado.

En un ensayo clínico de comparación de un tratamiento activo con un placebo, en el que una proporción de pacientes ϕ se desvía del protocolo, por ejemplo al interrumpir el tratamiento, entonces, como se explicó en el apartado 6.5, es importante continuar observando a estos pacientes e incluirlos en el análisis en el grupo en el que fueron asignados aleatoriamente. Si se supone que estos pacientes responderán de la misma manera que los pacientes que recibían placebo, la diferencia entre los dos grupos de tratamiento se reduce en un factor igual a $1 - \phi$ y, puesto que el tamaño necesario para la muestra es proporcional a la recíproca del cuadrado de una diferencia específica, tenemos:

$$n' = \frac{n}{(1 - \phi)^2}$$

(Donner, 1984). Como es posible que los sujetos que se retiran o se desvían del protocolo no sean representativos del grupo total del estudio, existe la posibilidad de comparaciones sesgadas y esto no puede eliminarse aumentando el tamaño de la muestra.

Otras consideraciones

Las situaciones consideradas en este apartado son relativamente simples y consisten en comparar dos grupos sin características complicadas. La determinación del tamaño de la muestra es facilitada a menudo por el uso de tablas y, además de las mencionadas anteriormente, el texto de Lemeshow et al (1990) contiene varios grupos de tablas. Incluso en estas situaciones simples es necesario tener una idea razonable de la forma probable de los datos que se van a recoger antes de calcular el tamaño de la muestra. Por ejemplo, cuando se comparan medias es necesario tener una estimación de la desviación tipo, o al comparar proporciones, en la fase de planificación, se requiere el tamaño aproximado de una de las proporciones. Esta información puede hallarse a partir de estudios previos usando las mismas variables o puede obtenerse de un estudio piloto. En situaciones más complicadas se necesita más información, pero se puede emplear en principio (6.9), siempre que sea posible encontrar una expresión para σ , la desviación tipo pertinente a la comparación de interés.

Para una comparación de proporciones usando muestras apareadas, donde el test de significación se basa en los pares no empatados (apartado 4.8), es necesario tener información sobre la eficacia probable del equiparamiento, que determinaría la proporción de pares que

estaban empatados (Connor, 1987). Como es posible que dicha información no sea fácil de obtener, en la determinación del tamaño de la muestra a menudo se ignora el efecto del equiparamiento, pero ello daría como resultado una muestra de mayor tamaño de lo necesario si el equiparamiento fuera eficaz (Parker y Bregman, 1986).

Entre otras situaciones más complicadas se incluye tener en cuenta las variables de confusión (cap. 12), la regresión múltiple (cap. 10) y el análisis de la supervivencia (cap. 14). Schlesselman (1982) considera el cálculo del tamaño de la muestra en presencia de un factor de confusión (v. también Donner, 1984; Woolson et al, 1986). Nam (1987) examina el cálculo del tamaño de la muestra para detectar una tendencia en las proporciones, en que el análisis emplea los métodos obtenidos en el apartado 12.2. Freedman (1982) analiza el cálculo del tamaño de la muestra (y ofrece tablas) en ensayos clínicos en que se compara la proporción en la cual un acontecimiento, como la recidiva o el fallecimiento, es la medida de resultado, una forma de análisis de la supervivencia. Lemeshow et al (1990) y Machin y Campbell (1987) también ofrecen tablas para el cálculo del tamaño de la muestra en el análisis de la supervivencia.

Muchas investigaciones tratan sobre más de una variable medida en el mismo individuo. Por ejemplo, en un sondeo sobre morbilidad, se puede registrar en cada persona una amplia variedad de síntomas, así como los resultados de ciertos test diagnósticos. Por consiguiente, las muestras de tamaños considerados suficientes para un determinado objetivo pueden ser inadecuados para otros. En muchas investigaciones el tamaño elegido será el mayor de los requeridos para cada una de las distintas variables separadamente; no importa demasiado que para algunas variables el tamaño de la muestra sea innecesariamente grande. Por el contrario, en otras, esto puede ser un inconveniente, porque tanto el coste como los problemas que aparecen al efectuar observaciones adicionales son considerables. Una estrategia adecuada en estas circunstancias es el *muestreo multifase*. En la primera fase se observan algunas variables en todos los miembros de la muestra inicial. En la segunda fase se extrae una submuestra de la muestra inicial mediante muestreo aleatorio o con otros métodos descritos en el apartado 6.2. Las otras variables se observan sólo en los miembros de la submuestra. El proceso podría extenderse claramente a más de dos fases.

Algunos censos poblacionales han consistido en muestreos con varias fases, la primera de las cuales constituía el 100% de la muestra sobre la que se formulaban algunas preguntas. En la segunda fase se planteaban algunas preguntas sobre una submuestra (p. ej., a uno de cada 10 miembros de la población). La justificación sería que se requiere una enumeración completa de ciertos datos demográficos básicos, si bien, para determinados propósitos (quizás una información referente a la fertilidad o al grado de ocupación laboral), se obtendría una precisión adecuada usando una muestra de uno de cada 10. Restringiendo estas últimas cuestiones a una muestra relativamente pequeña se consiguen ahorros económicos importantes.

Capítulo 7

Comparación de varios grupos

7.1. Análisis de la variancia de un factor

El conjunto de técnicas denominado *análisis de la variancia* constituye un potente método para analizar el modo en el que el valor medio de una variable es afectado por diferentes tipos de clasificaciones de los datos. Esta aparente paradoja de la nomenclatura –según la cual las técnicas tienen que ver con la comparación de medias más que con la de variancias– se aclarará cuando estudiemos el método en detalle.

En el apartado 4.4 ya hemos utilizado la distribución de la t para la comparación de las medias de dos grupos de datos, distinguiendo entre datos apareados e independientes. El *análisis de la variancia de un factor*, objetivo del presente apartado, es una generalización del test de la t para datos independientes, apropiada para cualquier número de grupos. Como veremos, es equivalente al test de la t para datos independientes cuando existen dos grupos. En el apartado 8.1 se describirá la extensión análoga del test de la t para datos apareados.

Algunos ejemplos de clasificación de datos mediante un factor en varios grupos son:

1. La determinación de la reducción del azúcar en sangre en grupos de conejos a los que se han administrado diferentes dosis de insulina.
2. El valor de un determinado test funcional respiratorio en varones pertenecientes a un mismo grupo de edad para un número de categorías profesionales diferentes.
3. Los volúmenes de líquido obtenidos en un experimento utilizando varias pipetas para medir una cantidad estándar, agrupando las diferentes medidas de cada pipeta.

En cada uno de estos ejemplos se plantea un interrogante similar. ¿Qué se puede decir acerca de la variación de la reducción del azúcar en sangre de un grupo a otro, en los test funcionales respiratorios de una categoría ocupacional a otra o en el volumen de líquido de una pipeta a otra? Sin embargo, existen diferencias importantes, en cuanto a la naturaleza de la clasificación en grupos en estos tres ejemplos. En el primer ejemplo, los grupos se definen por la dosis de insulina y tienen un orden natural; en el segundo ejemplo los grupos no poseen una ordenación única aunque se podrían sugerir algunas clasificaciones razonables de los grupos (p. ej., de acuerdo con el esfuerzo físico, la demanda intelectual, etc.), y en el tercero, los grupos de datos no poseen casi con toda certeza un orden natural. En este apartado trataremos situaciones en las que no se tiene en cuenta una ordenación lógica de los grupos ya sea porque, como en el caso 3, no existe ninguna, o porque la consideración de la ordenación se difiere hasta las últimas etapas del análisis.

Supóngase que existen k grupos de observaciones de una variable, y , y que el grupo i contiene n_i observaciones. La numeración de los grupos de 1 a k será arbitraria, aunque si existe una ordenación natural de los grupos será razonable emplearla en la numeración. El resto de la notación es la siguiente:

Grupo	1	2	...	i	...	k	Todos los grupos combinados
Número de observaciones	n_1	n_2	...	n_i	...	n_k	$N = \sum_{i=1}^k n_i$
Media de y	$\bar{y}_1$	$\bar{y}_2$	...	$\bar{y}_i$	...	$\bar{y}_k$	$\bar{y} = T/N$
Suma de y	T_1	T_2	...	T_i	...	T_k	$T = \sum_{i=1}^k T_i$
Suma de y^2	S_1	S_2	...	S_i	...	S_k	$S = \sum_{i=1}^k S_i$

Nótese que las entradas N , T y S en la última columna son las sumas a lo largo de las correspondientes filas, aunque $\bar{y}$ no es la suma de las $\bar{y}_i$ ($\bar{y}$ será la *media* de las $\bar{y}_i$, si todas las n_i son iguales; en el resto de casos, $\bar{y}$ es la *media ponderada* de las $\bar{y}_i$, $\sum n_i \bar{y}_i / \sum n_i$). Numérense de modo arbitrario las observaciones dentro de cada grupo y llamemos y_{ij} a la observación j del grupo i .

Cuando se haga una suma sobre las N observaciones, contribuyendo cada una de ellas una sola vez en aquélla, emplearemos el signo sumatorio

$$\sum_{i,j}$$

o, en el texto, $\sum_{i,j}$. Cuando se opere con la suma de los k grupos, cada uno de ellos interviniendo una sola vez, emplearemos el signo

$$\sum_i$$

o $\sum_i$, mientras que la suma de los miembros de un grupo particular se simbolizará

$$\sum_j$$

o $\sum_j$.

La desviación de cada observación con respecto a la *media global*, $\bar{y}$, puede separarse en dos partes del siguiente modo:

$$y_{ij} - \bar{y} = (y_{ij} - \bar{y}_i) + (\bar{y}_i - \bar{y}) \quad (7.1)$$

El primer término de la derecha de (7.1) es la desviación de y_{ij} respecto a su *media de grupo*, $\bar{y}_i$, y el segundo término es la desviación de la media del grupo con respecto a la media general. Más adelante veremos que cuando cada uno de estos términos se eleva al cuadrado y se suman sobre todas las observaciones se obtiene un resultado similar:

$$\sum_{i,j} (y_{ij} - \bar{y})^2 = \sum_{i,j} (y_{ij} - \bar{y}_i)^2 + \sum_{i,j} (\bar{y}_i - \bar{y})^2 \quad (7.2)$$

Este resultado significa que la suma «total» de cuadrados de las desviaciones con respecto a la media de todos los N valores de y puede dividirse en dos partes: a) la suma de los cuadrados de las desviaciones de cada lectura alrededor de la media de su grupo correspondiente, y b) la suma de cuadrados de las desviaciones de cada media de grupo alrededor de la media general (contándose una vez para cada observación). Podemos escribir este resultado del siguiente modo:

$$SC \text{ total} = SC \text{ intragrupos} + SC \text{ entre grupos},$$

siendo SC la suma de cuadrados.

Si existen grandes diferencias entre las medias de los grupos, es probable que la SC entre grupos sea mayor que la SC intragrupos. Si, por otra parte, todas las $\bar{y}_i$ son casi iguales y aún existe una considerable variación intragrupos, es probable que suceda lo contrario. Los tamaños relativos de las SC entre grupos e intragrupos deberían, por consiguiente, ofrecer una oportunidad para valorar la variación entre las medias de los grupos en comparación con la variación intragrupos.

Para comprobar (7.2) escribimos:

$$\begin{aligned} \sum_{i,j} (y_{ij} - \bar{y})^2 &= \sum_{i,j} [(y_{ij} - \bar{y}_i) + (\bar{y}_i - \bar{y})]^2 \\ &= \sum_{i,j} (y_{ij} - \bar{y}_i)^2 + 2 \sum_{i,j} (y_{ij} - \bar{y}_i)(\bar{y}_i - \bar{y}) + \sum_{i,j} (\bar{y}_i - \bar{y})^2 \\ &= \sum_{i,j} (y_{ij} - \bar{y}_i)^2 + 2 \sum_i 0(\bar{y}_i - \bar{y}) + \sum_{i,j} (\bar{y}_i - \bar{y})^2 \\ &= \sum_{i,j} (y_{ij} - \bar{y}_i)^2 + \sum_{i,j} (\bar{y}_i - \bar{y})^2 \end{aligned}$$

el paso de la segunda a la tercera línea es posible porque el sumatorio del centro se puede efectuar grupo por grupo y para el grupo i $\sum_j (y_{ij} - \bar{y}_i) = 0$. Por consiguiente, el sumatorio total vale cero. Nótese que la SC entre grupos se puede escribir:

$$\sum_{i,j} (\bar{y}_i - \bar{y})^2 = \sum_i n_i (\bar{y}_i - \bar{y})^2$$

porque la contribución $(\bar{y}_i - \bar{y})^2$ es la misma para todas las n_i observaciones del grupo i .

Es más conveniente plantear la partición de la SC total utilizando fórmulas análogas a la fórmula abreviada (1.3) para la SC alrededor de la media en una muestra única. Dichas fórmulas se obtienen del siguiente modo

1. $SC \text{ total}$

$$\sum_{i,j} (y_{ij} - \bar{y})^2 = S - \frac{T^2}{N} \quad (7.3)$$

aplicando directamente (1.3)

2. *SC intragrupos.*Para el grupo i

$$\sum_j (y_{ij} - \bar{y}_i)^2 = S_i - \frac{T_i^2}{n_i}$$

Por consiguiente, sumando los k grupos,

$$\begin{aligned} \sum_{ij} (y_{ij} - \bar{y}_i)^2 &= \left(S_1 - \frac{T_1^2}{n_1} \right) + \dots + \left(S_k - \frac{T_k^2}{n_k} \right) \\ &= \sum_i S_i - \sum_i (T_i^2/n_i) \\ &= S - \sum_i (T_i^2/n_i) \end{aligned} \quad (7.4)$$

3. *SC entre grupos.*

Sustrayendo a partir de (7.2)

$$\begin{aligned} \sum_{ij} (\bar{y}_i - \bar{y})^2 &= \text{SC total} - \text{SC intragrupos} \\ &= S - (T^2/N) - \left[S - \sum_i (T_i^2/n_i) \right] \\ &= \sum_i (T_i^2/n_i) - T^2/N \end{aligned} \quad (7.5)$$

Nótese que, según (7.5), la SC entre grupos se puede expresar completamente en términos de los totales de grupo, T_i , y los tamaños de cada grupo, n_i (y, por consiguiente, en términos de $\bar{y}_i$ y n_i , dado que $T_i = n_i \bar{y}_i$). Ello muestra claramente que representa la variación entre las medias de grupo y de ningún modo la variación en el interior de cada grupo.

Resumiendo estos resultados, contamos con las siguientes fórmulas para dividir la suma total de cuadrados.

$$\left. \begin{array}{ll} \text{Entre grupos} & \sum_i (T_i^2/n_i) - T^2/N \\ \text{Intragrupos} & S - \sum_i (T_i^2/n_i) \\ \text{Total} & S - T^2/N \end{array} \right\} \quad (7.6)$$

Consideremos ahora el problema de probar la existencia de diferencias reales entre los grupos. Supóngase que las n_i observaciones del grupo i forman una muestra aleatoria extraída de una población con media μ_i y variancia σ^2 . Como en el test de la t bilateral, de momento asumimos que σ^2 es la misma para todos los grupos. Para examinar los indicios de diferencias entre las μ_i deberemos comprobar la hipótesis nula de que μ_i no varía siendo igual a un valor común desconocido μ . Tres formas de estimar σ^2 son las siguientes:

1. *A partir de la SC total.* El conjunto global de N observaciones puede considerarse como una muestra aleatoria de tamaño N y, por consiguiente,

$$s_T^2 = \frac{\text{SC total}}{N - 1}$$

es un estimador no sesgado de σ^2 .

2. *A partir de la SC intragrupos.* Se pueden obtener estimaciones no sesgadas a partir de cada grupo sucesivamente:

$$\frac{S_1 - T_1^2/n_1}{n_1 - 1}, \frac{S_2 - T_2^2/n_2}{n_2 - 1}, \dots, \frac{S_k - T_k^2/n_k}{n_k - 1}$$

Se puede deducir una estimación combinada basada exclusivamente en la variación intragrupos (mediante una extensión del procedimiento empleado en el test de la t para dos muestras) añadiendo los numeradores y denominadores de estos cocientes, para obtener la *media cuadrática (MC) intragrupos*.

$$s_i^2 = \frac{\text{SC intragrupos}}{\sum_i (n_i - 1)} = \frac{\text{SC intragrupos}}{N - k}$$

3. *A partir de la SC entre grupos.* Como s_r^2 y s_i^2 no están sesgados,

$$E(s_r^2) = \sigma^2; \text{ de ahí } E(\text{SC total}) = (N - 1)\sigma^2$$

$$E(s_i^2) = \sigma^2; \text{ de ahí } E(\text{SC intragrupos}) = (N - k)\sigma^2$$

Restando (7.8) de (7.7),

$$\begin{aligned} E(\text{SC entre grupos}) &= (N - 1)\sigma^2 - (N - k)\sigma^2 \\ &= (k - 1)\sigma^2 \end{aligned}$$

La *MC entre grupos* proporciona una tercera estimación no sesgada,

$$s_e^2 = \frac{\text{SC entre grupos}}{k - 1}$$

El divisor $k - 1$ es razonable, siendo uno menos el número de grupos, de la misma manera que el divisor de s_i^2 es uno menos el número de observaciones.

Estos resultados se mantienen si la hipótesis nula es cierta. Sin embargo, supóngase que μ_i no son iguales. La MC intragrupos sigue siendo una estimación no sesgada de σ^2 , porque está basada exclusivamente en la variación intragrupos. La MC entre grupos, al estar basada en la variación entre las medias de grupo, tenderá a crecer. De hecho, en general, cuando las μ_i difieren:

$$E(s_e^2) = \sigma^2 + \frac{\sum_i n_i (\mu_i - \bar{\mu})^2}{k - 1} \quad (7.9)$$

donde $\bar{\mu}$ es la medida ponderada de las μ_i , $\sum_i n_i \mu_i / N$. Se puede obtener información sobre la existencia de diferencias en las μ_i mediante una comparación de s_e^2 y s_i^2 . En la hipótesis nula estas dos medias cuadráticas estiman la misma cantidad y, por consiguiente, no deberán ser muy diferentes. Si la hipótesis nula no es cierta, s_e^2 es, de acuerdo con (7.9), mayor en promedio que σ^2 y tenderá a ser mayor que s_i^2 .

Un test apropiado para la hipótesis nula puede, en consecuencia, basarse en el *cociente de la variancia (CV)* s_e^2/s_i^2 , que puede simbolizarse por F . La distribución de F depende de la naturaleza de las distribuciones de las y_{ij} alrededor de su media, $\bar{y}_i$. Si se asume que estas dis-

tribuciones son normales, se puede demostrar que s_e^2 y s_t^2 se comportan como dos estimaciones independientes de la variancia, con $k - 1$ y $N - k$ grados de libertad respectivamente.

La distribución F se ha tratado en el apartado 4.6. Las desviaciones con respecto a la hipótesis nula tenderán a proporcionar valores de F mayores que la unidad. Un test de significación de la hipótesis nula debería, por lo tanto, considerar significativos sólo aquellos valores de F suficientemente grandes. Es decir que se requiere una prueba unilateral. Como se comprobó en el apartado 4.6, los niveles críticos de F están tabulados en términos de probabilidades unilaterales, por lo que los valores tabulados (tabla A4) se aplican directamente a la presente situación. (De hecho, la forma unilateral de tabulación se debe a las necesidades del análisis de la variancia.)

Si $k = 2$, la situación considerada antes es precisamente aquella para la que se introdujo el test de la t para datos independientes en el apartado 4.4. El cociente de variancia F , tendrá 1 y $N - 2$ gl y t tendrá $n_1 + n_2 - 2$, o sea, $N - 2$ gl. De hecho, las dos soluciones son equivalentes en el sentido de que: a) el valor de F es igual al cuadrado del valor de t , y b) la distribución de F con 1 y $N - 2$ gl es exactamente la misma que la distribución del cuadrado de una variable que sigue la distribución de la t con $N - 2$ gl. La primera afirmación puede demostrarse algebraicamente en pocas líneas. La segunda se ha considerado en el apartado 4.6.

Si $k = 2$ y $n_1 = n_2 = \frac{1}{2}N$ (o sea, existen dos grupos de igual tamaño) un resultado útil es que la SC entre grupos (7.5) puede expresarse en la forma alternativa:

$$\frac{(T_1 - T_2)^2}{N} \quad (7.10)$$

Si $k > 2$, podríamos desear examinar la diferencia entre un par de medias determinado, elegido porque el contraste entre estos determinados grupos presenta un interés lógico. El error tipo de la diferencia entre dos medias, digamos $\bar{y}_g$ e $\bar{y}_h$, puede estimarse con la siguiente fórmula:

$$ET(\bar{y}_g - \bar{y}_h) = \sqrt{\left[s_t^2 \left(\frac{1}{n_g} + \frac{1}{n_h} \right) \right]} \quad (7.11)$$

y la diferencia $\bar{y}_g - \bar{y}_h$ comprobada comparando:

$$t = \frac{\bar{y}_g - \bar{y}_h}{ET(\bar{y}_g - \bar{y}_h)}$$

con la distribución de la t con $N - k$ grados de libertad (porque éste es el número de grados de libertad asociado al estimador de la variancia s^2). Los límites de confianza de la diferencia de medias pueden establecerse del modo habitual, utilizando los percentiles tabulados de t para $N - k$ grados de libertad. La única función del análisis de la variancia en esta comparación particular ha sido sustituir la estimación de la variancia con $n_g + n_h - 2$ grados de libertad (que se utiliza en el test de la t bilateral para dos muestras independientes) por la MC intragrupos con $N - k$ grados de libertad. Ésta podría ser una importante ventaja si n_g y n_h son pequeñas. Sin embargo, ello se ha conseguido suponiendo que todos los grupos están sujetos a la misma variancia intragrupos, y si existen dudas sobre la validez de este supuesto será conveniente confiar en los datos de los dos grupos aislados.

Si *a priori* no existen contrastes entre grupos que llamen nuestra atención, los análisis adicionales sobre las diferencias entre las medias dependen en gran parte del test de la F en el análisis de la variancia. Si el cociente de variancias no es significativo o, incluso, si lo es ligeramente, tiene poco sentido examinar las diferencias entre pares de medias. Si F es significativo, contamos con una evidencia razonable de que existen diferencias reales entre medias y que son lo suficientemente grandes para mostrarse por encima de la variación al azar. Parece natural considerar lo que puede decirse acerca del sentido y de la magnitud de estas diferencias. Este punto volverá a tratarse en el apartado 7.4.

Ejemplo 7.1

En cada uno de cuatro experimentos sobre el uso de tetracloruro de carbono como veneno para lombrices, se infestaron diez ratas con larvas. Ocho días más tarde se administró tetracloruro de carbono a cinco ratas; las cinco restantes se consideraron controles. Al cabo de 2 días se sacrificaron las ratas y se contó el número de lombrices adultas. Se consideró útil examinar la significación de las diferencias entre las medias de los cuatro grupos control. Si fuera posible establecer diferencias significativas, éstas podrían estar relacionadas con cambios definibles de las condiciones de los experimentos, y se debería pretender una reducción de la variación en futuros trabajos. En la tabla 7.1 se muestran los resultados y los detalles de los cálculos efectuados. El valor de F es 2,27; la comparación con el

Tabla 7.1. Análisis de variancia de un factor: diferencias entre cuatro grupos de ratas control según el recuento de lombrices adultas.

	Experimento.				Todos los grupos
	1	2	3	4	
	279	378	172	381	
	338	275	335	346	
	334	412	335	340	
	198	265	282	471	
	303	286	250	318	
T_i	1.452	1.616	1.374	1.856	$T = 6.298$
n_i	5	5	5	5	$N = 20$
y_i	290,4	323,2	274,8	371,2	
S_i	434.654	540.274	396.058	703.442	$S = 2.074.428$
T^2/n_i	421.661	522.291	377.575	688.947	

$$\begin{aligned}\text{Entre grupos SC} &= 421.661 + \dots + 688.947 - (6.298)^2/20 \\ &= 2.010.474 - 1.983.240 \\ &= 27.234\end{aligned}$$

$$\begin{aligned}\text{Total SC} &= 2.074.428 - 1.983.240 \\ &= 91.188\end{aligned}$$

$$\begin{aligned}\text{Intragrupo SC} &= 91.188 - 27.234 \\ &= 63.954\end{aligned}$$

Análisis de la variancia

	SC	gl	MC	CV
Entre grupos	27.234	3	9.078	2,27
Intragrupos	63.954	16	3.997	
Total	91.188	19		

valor F de la tabla para $v_1 = 3$ y $v_2 = 16$ muestra que el resultado no es significativo para $P = 0,05$. (Realmente $P = 0,12$.)

El error tipo de la diferencia entre dos medias es $\sqrt{2(3997)/5} = 40,0$. Nótese que la diferencia entre $\bar{y}_3$ e $\bar{y}_4$ es más de dos veces el error tipo, pero dado que el valor F no es significativo, no deberíamos prestar mayor atención a esta comparación particular a menos que existiera un interés especial previo (v. también apartado 7.4).

Dos suposiciones importante subyacentes en el test del análisis de la variancia de un factor son: a) la normalidad de la distribución de y_{ij} alrededor de su media μ_i y b) la igualdad de las variancias en los distintos grupos. La prueba de F no es excesivamente sensible a desviaciones moderadas de la normalidad, pero a menudo merecerá la pena considerar si alguna forma de transformación (cap. 11) mejorará este aspecto. La suposición acerca de la igualdad de variancias es más seria. Ya se ha sugerido que para comparar dos medias cuando existen dudas sobre la validez de un estimador de la variancia intragrupo común, podría ser conveniente estimar la variancia de los dos grupos por separado. Una transformación de la escala de medida puede ofrecer una casi igualdad de variancias. Si con ello tampoco se consigue, se podría obtener una prueba aproximada para diferencias entre medias mediante el método descrito en el apartado 7.2.

7.2. Método de ponderación

En el análisis de la variancia de un factor estamos interesados en una serie de k medias, $\bar{y}_i$, que puede tener diferentes variancias porque los tamaños n_i de los grupos pueden diferir. Nos preguntamos si las $\bar{y}_i$ podrían considerarse *homogéneas*, en el sentido de que podrían diferir de algún valor común debido a variaciones en el muestreo, o si se deberían considerar *heterogéneas*, en el sentido de que es poco probable que la variación del muestreo explique las diferencias entre ellas.

Ahora consideraremos un método para abordar otros problemas de este tipo, que presenta una amplia generalidad. Depende de ciertas suposiciones que pueden ser o no exactamente verdaderas en algunas aplicaciones concretas, pero que, sin embargo, es muy útil para proporcionar soluciones aproximadas a algunos problemas. La situación general consiste en que hay datos disponibles en k grupos, cada uno de los cuales proporciona una estimación de algún parámetro. En primer lugar, deseamos examinar si hay indicios de heterogeneidad entre las estimaciones y, seguidamente, en ausencia de heterogeneidad, obtener una sola estimación del parámetro a partir de todo el conjunto de datos.

Supongamos que observamos k cantidades, $Y_1, Y_2, \dots, Y_k$, y sabemos que Y_i es $N(\mu_i, V_i)$, donde las medias μ_i son desconocidas pero se conocen las variancias V_i . Para comprobar la hipótesis de que todas las μ_i son iguales a algún valor específico, podríamos calcular una suma de cuadrados *ponderada*:

$$G_0 = \sum_i [(Y_i - \mu)^2 / V_i] = \sum_i w_i (Y_i - \mu)^2 \quad (7.12)$$

donde $w_i = 1/V_i$. La cantidad G_0 es la suma de cuadrados de k desviaciones normales estandarizadas que, según (3.6), sigue la distribución $\chi^2_{(k)}$.

Sin embargo, para contrastar la hipótesis de homogeneidad no acostumbramos a desear que se especifique el valor μ . Sustituimos μ por la media *ponderada*

$$\bar{Y} = \frac{\sum_i w_i Y_i}{\sum_i w_i} \quad (7.13)$$

y calculamos

$$G = \sum_i w_i (Y_i - \bar{Y})^2 \quad (7.14)$$

La cantidad w_i se denomina *factor de ponderación*; nótese que es el recíproco de la variancia V_i , según lo cual si, por ejemplo, Y_1 es más precisa que Y_2 , entonces $V_1 < V_2$ y $w_1 > w_2$, y Y_1 estará más ponderada.

Con unas transformaciones sencillas se obtiene la siguiente fórmula:

$$G = \sum_i w_i Y_i^2 - \left(\sum_i w_i Y_i \right)^2 / \sum_i w_i \quad (7.15)$$

Nótese que si todos los $w_i = 1$, (7.14), obtenemos la suma de desviaciones al cuadrado alrededor de la media usual, Y se convierte en la habitual media no ponderada y (7.15) en la fórmula abreviada general (1.3).

Se puede demostrar que en la hipótesis nula de homogeneidad, G se distribuye según $\chi^2_{(k-1)}$. La sustitución de μ por $\bar{Y}$ ha conducido a una pérdida de 1 gl. Los valores altos de G ofrecen un fuerte indicio en contra de la homogeneidad.

Si se acepta la homogeneidad, a menudo será razonable estimar μ , el valor común de las μ_i . La mejor estimación (en el sentido de tener la menor variancia) es la media ponderada $\bar{Y}$, definida anteriormente. Además, si la hipótesis nula de homogeneidad es cierta, $\text{Var}(\bar{Y}) = 1/\sum_i w_i$, y los límites de confianza de μ se pueden obtener utilizando los percentiles de la distribución normal. Así, los límites de confianza del 95% son:

$$\bar{Y} \pm 1.96 \sqrt{(1/\sum_i w_i)}$$

Veamos cómo podría aplicarse este teoría general al problema de comparar k medias independientes, empleando la notación al apartado 7.1. Escribamos $Y_i = \bar{y}_i$ y $V_i = \sigma^2/n_i$. Entonces,

$$\bar{Y} = \sum_i n_i \bar{y}_i / \sum_i n_i = \bar{y}$$

en la media global, y

$$G = \frac{\sum_i n_i (\bar{y}_i - \bar{y})^2}{\sigma^2} = \frac{\text{SC entre grupos}}{\sigma^2}$$

Si σ^2 fuera conocida, se podría comparar G a partir de la distribución $\chi^2_{(k-1)}$. En la práctica, estimamos σ^2 a partir de la MC intragrupos, s_i^2 , y sustituimos G por:

$$G' = \frac{\text{SC entre grupos}}{s_i^2} = \frac{(k-1)s_E^2}{s_i^2}$$

Esto es $k-1$ veces el cociente de variancias que, como ya hemos visto, sigue la distribución F con $k-1$ y $N-k$ grados de libertad. Para estos grados de libertad, las distribuciones de $(k-1)F$ y $\sigma_{(k-1)}^2$ son exactamente equivalentes cuando $N = \infty$ (v. apartado 4.6). Para valores razonablemente grandes de N , los dos métodos proporcionan resultados muy similares.

Consideremos ahora la posibilidad mencionada al final del apartado 7.1, de que los grupos tengan diferentes variancias σ_i^2 . Escribamos $Y_i = \bar{y}_i$ y $V_i = \sigma_i^2/n$. De nuevo las σ_i^2 son desconocidas, pero pueden estimarse mediante la fórmula:

$$s_i^2 = [S_i - (T_i^2/n_i)]/(n_i - 1)$$

y calcular unos factores de ponderación aproximados o *empíricos* como:

$$w'_i = n_i/s_i^2$$

Calculamos la suma de cuadrados ponderada (7.15) del siguiente modo:

$$G'' = \sum_i w'_i \bar{y}_i^2 - (\sum_i w'_i \bar{y}_i)^2 / \sum_i w'_i$$

En la hipótesis nula de homogeneidad de la μ , G'' se distribuye aproximadamente como $\chi_{(k-1)}^2$, indicando los valores altos una disparidad excesiva entre las $\bar{y}_i$. La aproximación es cada vez más imprecisa para valores pequeños de n_i (inferiores a 10, aproximadamente); James (1951) y Welch (1951) plantearon un método más perfeccionado. Para una aplicación de este método en una comparación de conjuntos de recuentos de pústulas, véase Armitage (1957, p. 579).

Una aplicación importante del método de ponderación se presenta en los metaanálisis de los ensayos clínicos (apartado 6.5). El parámetro que se va a estimar es muchas veces la razón de probabilidad de dos proporciones (p. ej., la proporción de pacientes que fallecen o que sufren un acontecimiento crítico en cada uno de dos tratamientos). Una estimación de la razón de probabilidad usada con frecuencia (y, por tanto, de la razón de proporciones cuando éstas son bajas) es la dada por (4.23).

Supóngase que el logaritmo de la razón de probabilidad toma el valor μ en cada uno de k ensayos clínicos y su estimación a partir del i -ésimo ensayo clínico es

$$Y_i = \frac{O_i - E_i}{V_i}$$

con

$$\text{Var}(Y_i) = \frac{1}{V_i}$$

donde O_i y E_i son las cantidades observada y esperada de acontecimientos críticos en cada uno de los tratamientos y V_i se calcula, como en (4.22), a partir de la tabla 2 x 2 para el ensayo clínico. Luego, la media ponderada (7.13) se convierte en

y entre grupos, respectivamente. En la figura 7.2 se ilustra esta situación. Los datos de que disponemos consisten en una muestra aleatoria de tamaño n para cada uno de k grupos extraídos al azar.

Consideremos en primer lugar la variancia de la media $\bar{y}_i$ de una única muestra. Tenemos:

$$\bar{y}_i - \mu = (\mu_i - \mu) + (\bar{y}_i - \mu_i)$$

en la que los dos términos entre paréntesis representan fuentes de variación independientes (la de μ_i alrededor de μ y la de $\bar{y}_i$ alrededor de μ_i). Por consiguiente, aplicando (3.13):

$$\begin{aligned}\text{Var}(\bar{y}_i) &= \text{Var}(\mu_i) + \text{Var}(\bar{y}_i, \text{ dado } \mu_i) \\ &= \sigma_E^2 + (\sigma^2/n)\end{aligned}\quad (7.17)$$

Ahora, el análisis de la variancia tendrá la siguiente estructura:

	gl	MSq
Entre grupos	$k - 1$	s_E^2
Intragrupos	$k(n - 1)$	s_i^2
Total	$nk - 1 (= N - 1)$	

La SC entre grupos es (con la notación para T_i y T definida como en el apartado 7.1):

$$\begin{aligned}& \frac{\sum T_i^2}{n} - \frac{T^2}{N} \\ &= n[\sum \bar{y}_i^2 - (\sum \bar{y}_i)^2/k]\end{aligned}$$

con los sumatorios definidos desde $i = 1$ hasta k . Por consiguiente, la MC entre grupos s_E^2 :

$$\begin{aligned}&= n[\sum \bar{y}_i^2 - (\sum \bar{y}_i)^2/k] / (k - 1) \\ &= n \text{ veces un estimador no sesgado de la } \text{Var}(\bar{y}_i) \\ &= n \text{ veces un estimador no sesgado de } \sigma_E^2 + \sigma^2/n, \text{ según (7.17)} \\ &= n \text{ veces un estimador no sesgado de } n\sigma_E^2 + \sigma^2\end{aligned}$$

Esto es:

$$E(s_E^2) = \sigma^2 + n\sigma_E^2 \quad (7.18)$$

Este importante resultado es similar a (7.9), que es el resultado análogo para la situación en la que las μ_i son fijas.

La MC intragrupos es (según el apartado 7.1) una estimación no sesgada de σ^2 . Por ello, el resultado (7.18) confirma la verosimilitud del test de la F para la hipótesis nula de $\sigma_E^2 = 0$, y en este caso las dos medias cuadráticas son estimaciones no sesgadas de σ^2 . Si $\sigma_E^2 > 0$, s_E^2 será en promedio mayor que s_i^2 , y F tenderá a ser mayor que 1.




Fig. 7.2. Componentes de la variancia entre grupos e intragrupos, con distribuciones normales para cada componente de la variación aleatoria.

Para estimar σ_E^2 , téngase en cuenta que:

$$\begin{aligned} E(s_E^2 - s_I^2) &= E(s_E^2) - E(s_I^2) \\ &= (\sigma^2 + n\sigma_E^2) - \sigma^2 \\ &= n\sigma_E^2 \end{aligned}$$

Por lo tanto, un estimador no sesgado de σ_E^2 está dado por:

$$\hat{\sigma}_E^2 = \frac{s_E^2 - s_I^2}{n}$$

Si $s_E^2 < s_I^2$ (como ocurre a menudo si σ_E^2 es cero o cercano a cero), $\hat{\sigma}_E^2$ es negativo. Cuando esto ocurre, se puede sustituir $\hat{\sigma}_E^2$ por 0, pero debe subrayarse que entonces se pierde la naturaleza no sesgada de (7.19).

Ejemplo 7.2

Bacharach et al (1940) llevaron a cabo un experimento sobre un «factor de difusión», una sustancia que, cuando se hallaba presente en una inoculación en la piel de conejos, disolvía las ampollas causadas por la inoculación. Inocularon la misma dosis en seis zonas distintas del lomo de cada uno de los seis animales. Su diseño experimental permitió realizar un estudio sobre la influencia del lugar concreto y del orden de administración, pero no existió indicio alguno de que estos factores tuvieran

efecto y podemos considerar que los datos constituyen una clasificación de un factor entre animales e intraanimales. La variable analizada es el diámetro de la ampolla (cm²).

Un análisis de la variancia fue el siguiente:

	SC	gl	MC	CV
Entre grupos	12,8333	5	2,5667	4,39
Intragrupos	17,5266	30	0,5842	
Total	30,3599	35		

Tenemos:

$$\hat{\sigma}_e^2 = (2,5667 - 0,5842)/6 \\ = 0,3304$$

Los dos componentes de la variancia se estiman del siguiente modo, expresado cada uno como porcentaje del total:

Entre animales	$\hat{\sigma}_e^2$	0,3304	36%
Intraanimales	s_j^2	0,5842	64%
Total	$\hat{\sigma}_e^2 + s_j^2$	0,9146	100%

La suma de los dos componentes es la variancia estimada de una única lectura en un conejo elegido al azar, y el análisis muestra que, de esta variancia total, el 36% se estima que es atribuible a diferencias sistemáticas entre conejos. (Para el análisis posterior de estos datos, véase más adelante, y también el ejemplo 8.6, en la p. 254.)

Los límites de confianza de σ^2 se obtienen a partir de la SC intragrupos empleando la distribución χ^2 , como en el apartado 4.5. El cálculo de los límites de confianza de σ_e^2 es más problemático. Boardman (1974) recomienda una solución aproximada. Para los límites de confianza del 100(1 - α)% se requieren varias entradas en la tabla de las F correspondientes a un nivel tabulado para un solo factor de $\frac{1}{2}\alpha$. Así, para los límites de confianza del 95% necesitamos las entradas correspondientes a $\hat{P} = 0,025$. Designando F_{v_1, v_2} a la entrada con v_1 o v_2 grados de libertad y haciendo $f_1 = k-1, f_2 = k(n-1)$, necesitamos:

$$\begin{aligned} F_1 &= F_{f, f_1} \\ F_2 &= F_{f, \infty} \\ F_3 &= F_{f, f_1} \\ F_4 &= F_{\infty, f_1} \\ F &= \text{valor observado, } s_e^2/s_1^2 \end{aligned}$$

Entonces, el límite superior de σ_e^2 es:

$$\hat{\sigma}_{es}^2 = F_4 \left(F - \frac{1}{F_3} \right) \left(\frac{s_1^2}{n} \right) \quad (7.20)$$

y el límite inferior es:

$$\hat{\sigma}_{el}^2 = \left(\frac{F - F_1}{F_2} \right) \left(\frac{s_i^2}{n} \right) \quad (7.21)$$

Nótese que el límite inferior es cero si $F = F_1$, y esto sucede si F es justamente significativo según el test habitual. Si $F < F_1$, el límite inferior será negativo y, en algunos casos, el límite superior también será negativo. Para más comentarios referentes a esta aparente anomalía, véase Scheffé (1959, apartado 7.2). La validez de estos límites dependerá fuertemente de la suposición de normalidad, sobre todo en el caso de la variación entre grupos.

Ejemplo 7.2, (continuación)

Los límites de confianza del 95% de σ^2 son (según el apartado 4.5):

$$\frac{17,5266}{46,98}$$

y

$$\frac{17,5266}{16,79}$$

es decir,

$$0,373 \text{ y } 1,044$$

siendo los divisores los percentiles apropiados de la distribución de $\chi^2_{(30)}$.

Para calcular los límites de confianza de σ^2 necesitamos los siguientes valores tabulados de F , siendo $f_1 = 5$, $f_2 = 30$:

$$F_1 = 3,03, F_2 = 2,57, F_3 = 6,23, F_4 = 6,02$$

y la F observada es 4,39. En consecuencia, según (7.20) y (7.21):

$$\hat{\sigma}_{es}^2 = (6,02) \left(4,39 - \frac{1}{6,23} \right) (0,0974) = 2,48$$

y

$$\hat{\sigma}_{el}^2 = \left(\frac{4,39 - 3,03}{2,57} \right) (0,0974) = 0,052$$

Los amplios márgenes de error asociados a estas estimaciones dejan claro que las contribuciones porcentuales del 36% y del 64% son también estimaciones imprecisas.

Si el número de observaciones en cada grupo es desigual, siendo n_i el correspondiente al grupo i , (7.19) debe modificarse del siguiente modo:

$$\bar{Y} = \frac{\sum (O_i - E_i)}{\sum V_i} \quad (7.16)$$

con:

$$\text{Var}(\bar{Y}) = \frac{1}{\sum V_i}$$

El estadístico de heterogeneidad (7.15), distribuido aproximadamente como $\chi^2_{(k-1)}$, se convierte en:

$$G = \sum \frac{(O_i - E_i)^2}{V_i} - \frac{[\sum (O_i - E_i)]^2}{\sum V_i}$$

que es la suma a lo largo de los k ensayos clínicos.

Como se señaló en el apartado 4.9, este método está sesgado cuando el efecto del tratamiento es amplio (es decir, cuando la razón de probabilidad se aleja mucho de la unidad). El informe del Early Breast Cancer Trialists' Collaborative Group (1990) sugiere que el sesgo no es grave si la razón de probabilidad está comprendida dentro del doble de su cantidad en cualquiera de las dos direcciones y si hay por lo menos varias docenas de acontecimientos críticos en total. En situaciones más dudosas es preferible aplicar el método de ponderar hacia las estimaciones directas del logaritmo de la razón de probabilidad dadas por el logaritmo de (4.18).




Fig. 7.1. Metaanálisis de los resultados de mortalidad en ensayos clínicos de la ablación de ovario en mujeres menores de 50 años con cáncer precoz de mama, subdivididas según la presencia o la ausencia de quimioterapia citotóxica (Early Breast Cancer Trialists' Collaborative Group, 1992, fig. 9). En esta presentación el área de un cuadrado negro es proporcional a V_i y, por lo tanto, representa la precisión de la estimación de dicho ensayo clínico o grupo de ensayos clínicos. El nivel de significación para un test bilateral se presenta como « $2p$ ». (Reproducida con permiso de los autores y editores.)

La figura 7.1 muestra los resultados de un metaanálisis usando estos métodos. En este ejemplo, que es característico de muchos otros, ninguno de los ensayos clínicos concretos muestra un efecto terapéutico claro; sin embargo, los resultados de los diversos ensayos clínicos son coherentes y los valores agrupados de cada uno de los dos subgrupos y del conjunto total de datos tienen intervalos de confianza estrechos, lo cual constituye un indicio claro de un efecto.

Si los resultados del ensayo clínico son claramente heterogéneos, el primer paso debería ser considerar si esto puede ser explicado por diferencias conocidas entre las características de los ensayos clínicos: tipos de pacientes, agentes sometidos a examen, etc. Si hay sólo uno o dos ensayos clínicos incompatibles con los restantes, la mejor solución sería comunicarlos por separado y agrupar el resto.

No obstante, en ocasiones puede haber una heterogeneidad general, no explicable por las características conocidas y no limitada a una pequeña minoría de ensayos clínicos. Es posible adoptar dos métodos alternativos. En uno puede citarse la estimación agrupada (7.16), con sus límites relativamente estrechos, como adecuada para la mezcla concreta de pacientes y las características del estudio encontradas en estos ensayos clínicos, reconociendo que una mezcla diferente hubiera dado un resultado diferente (Yusuf et al, 1985; Early Breast Cancer Trialists' Collaborative Group, 1990). El segundo método consiste en afirmar que la variación inexplicada entre ensayos clínicos es una forma de variación aleatoria, cuya magnitud se puede estimar, y hay que tenerla en cuenta al citar la precisión de la estimación agrupada (DerSimonian y Laird, 1986). Éste es el denominado modelo de «efectos aleatorios» (v. apartado 7.3) y es un ejemplo del método empírico de Bayes descrito brevemente en el apartado 4.13. Estos dos métodos son explicados con mayor detalle por Berlin et al (1989), Pocock y Hughes (1990) y Whitehead y Whitehead (1991).

7.3. Componentes de la variancia

En algunos estudios que conducen al análisis de la variancia de un factor, es posible que los grupos no revistan gran interés considerados individualmente, aunque pueden representar una interesante fuente de variación. El resultado de una prueba de pipeteo puede, por ejemplo, variar de una pipeta a otra. Una comparación entre un par de pipetas en concreto tendría poco interés; además, un test de la hipótesis nula de que distintas pipetas dan en promedio resultados idénticos sería inútil, porque seguramente debe existir una diferencia sistemática entre los instrumentos. Una cuestión más relevante aquí sería determinar qué *magnitud* tiene la variación entre pipetas cuando se compara con lecturas repetidas de la misma pipeta.

Un procedimiento útil es considerar los k grupos como seleccionados al azar a partir de una población de estos grupos. Esto no es estrictamente correcto, pero sirve como una indicación de que los grupos revisten interés sólo como representantes de cierto tipo de variación. Esta estructura se denomina *modelo II* o *modelo de efectos aleatorios*, el cual difiere del *modelo I* o *modelo de efectos fijos*, considerado en el apartado 7.1.

Supóngase, en primer lugar, que cada grupo tiene el mismo número, n , de observaciones. (Según la notación del apartado 7.1 todas las n_i son iguales a n .) Sea μ_i la media «verdadera» para el grupo i . Supóngase asimismo que en la población de grupos, μ_i se distribuye con media μ y variancia σ_E^2 . Las lecturas efectuadas en el grupo i tienen como media μ_i y como variancia σ^2 . Las cantidades σ^2 y σ_E^2 se denominan *componentes de la variancia* intragrupos

$$\hat{\sigma}_\varepsilon^2 = \frac{s_\varepsilon^2 - s_f^2}{n_0} \quad (7.22)$$

donde

$$n_0 = \frac{1}{(k-1)} \left[N - \frac{(\sum n_i^2)}{N} \right]$$

Otra dificultad es que (7.22) no es necesariamente el mejor método para estimar σ_ε^2 . La elección del método depende, sin embargo, de la razón desconocida de los componentes de la variancia que se van a estimar, y (7.22) será en general un método sensible si los n_i no son muy distintos. Véanse Robertson (1962) y Stuart y Ord. (1983, apartado 36.26).

7.4. Comparaciones múltiples

Volvamos ahora al modelo de efectos fijos del apartado 7.1. Al finalizar los datos con este modelo suele ser importante no considerar únicamente la tabla del análisis de la variancia y su test de la F , sino también examinar las diferencias entre los grupos más estrechamente para observar los patrones que aparecen. De hecho, por lo general es aconsejable expresar los valores $\bar{y}_i$ y sus errores tipo, calculados como $s_i/\sqrt{n_i}$, usando la media cuadrática intragrupos s_ε^2 excepto que la asunción de la variancia constante sea claramente inapropiada.

El error tipo de la diferencia entre dos medias está dado por (7.11), y la distribución de la t puede emplearse para obtener un test de significación o para asignar los límites de confianza, como se indicó en el apartado 7.1. Si todas las n_i son iguales (a n), a veces es útil calcular la *menor diferencia significativa* para un nivel de significación determinado. Por ejemplo, para el nivel del 5%, dicha diferencia vale:

$$t_{f_2, 0.05} s_\varepsilon \sqrt{(2/n)}$$

donde $f_2 = k(n-1)$ son los grados de libertad intragrupos. Las diferencias significativas entre pares de medias que son significativas a este nivel pueden escogerse a simple vista.

En ocasiones, el interés se centra en comparaciones entre las medias de grupo más que en las simples diferencias. Éstas suelen ser medibles utilizando un *contraste lineal* de la siguiente manera:

$$L = \sum \lambda_i \bar{y}_i \quad (7.23)$$

donde $\sum \lambda_i = 0$. Según (3.13):

$$\text{Var}(L) = \sum \lambda_i^2 \text{Var}(\bar{y}_i)$$

y el error tipo de L se estima entonces como

$$\text{ET}(L) = s_\varepsilon \sqrt{(\sum \lambda_i^2/n)} \quad (7.24)$$

A continuación puede aplicarse el test de la t o calcularse los límites de confianza.

Algunos ejemplos de contrastes lineales son los siguientes:

1. *Un contraste de un grupo con la media de varios otros grupos.* Un grupo puede tener una identidad especial, quizá como un grupo control, y es posible que exista alguna razón para juntar un conjunto de otros q grupos (p. ej., si se han aplicado tratamientos parecidos a estos grupos). La comparación que interesa podrá entonces ser:

$$\bar{y}_c - \left(\sum_{i=1}^q \bar{y}_i \right) / q$$

que, cuando se multiplica por q , se convierte en:

$$L_1 = q\bar{y}_c - \sum_{i=1}^q \bar{y}_i$$

un caso particular de (7.23) con $\lambda_c = q$, $\lambda_i = -1$ para todos los i del conjunto de q grupos y $\lambda_i = 0$ en el resto de casos. Nótese que $\sum \lambda_i = 0$.

2. *Un coeficiente de regresión lineal.* Supóngase que un conjunto de q grupos se asocia a una variable x_i (p. ej., la dosis de una sustancia determinada). Podría tener interés preguntarse si la regresión de y sobre x es significativa. Utilizando el resultado citado en la deducción de (5.15):

$$L_2 = \sum (x_i - \bar{x}) \bar{y}_i$$

que de nuevo constituye un caso particular de (7.23) con $\lambda_i = x_i - \bar{x}$, y nuevamente $\sum \lambda_i = 0$.

3. *Una diferencia entre dos medias.* La diferencia entre $\bar{y}_g$ e $\bar{y}_h$ es otro caso de (7.23) con $\lambda_g = 1$, $\lambda_h = -1$ y las otras $\lambda_i = 0$.

Para cualquier contraste lineal, L , el estadístico t , con $k(n-1)$ grados de libertad, se obtiene mediante (7.24):

$$t = \frac{L}{\text{ET}(L)} = \frac{L}{S_1 \sqrt{(\sum \lambda_i^2/n)}}$$

Como hemos visto, el cuadrado de t sigue la distribución F con 1 y $k(n-1)$ grados de libertad. Entonces:

$$F = t^2 = \frac{L^2}{s_1^2 \sum \lambda_i^2/n} = \frac{s_1^2}{s_j^2}$$

donde $s_1^2 = L^2/(\sum \lambda_i^2/n)$. De hecho, s_1^2 puede considerarse como una media cuadrática con 1 gl, obtenida a partir de una SC también igual a s_1^2 , que se puede demostrar forma parte de la SC entre grupos del análisis de la variancia. El análisis adopta entonces la siguiente forma:

	SC	gl	MC	CV
<i>Entre grupos</i>				
Debido a L	$L^2/(\sum \lambda_i^2/n)$	1	s_1^2	$F_1 = s_1^2/s_j^2$
Otros contrastes	$\sum T_i^2/n - T^2/n - L^2/(\sum \lambda_i^2/n)$	$k-2$	s_R^2	$F_2 = s_R^2/s_j^2$
<i>Intragrupos</i>				
	$S - \sum T_i^2/n$	$k(n-1)$	s_j^2	
Total	$S - T^2/nk$	$nk-1$		

Los tests de significación separados están ahora dados por: a) F_1 con 1 y $k(n-1)$ grados de libertad para el contraste de L , que, como hemos visto, es equivalente al test de la t para L , y b) F_2 , con $k-2$ y $k(n-1)$ grados de libertad para las diferencias entre medias de grupo distintas a las medidas por L .

Supóngase que existen dos o más contrastes lineales de interés.

$$L_1 = \sum \lambda_{1i} \bar{y}_i, \quad L_2 = \sum \lambda_{2i} \bar{y}_i, \text{ etc.}$$

¿Es posible incorporar todos los grados de libertad individuales de estos contrastes en el mismo análisis de la variancia? Es posible, con la condición de que los contrastes lineales no estén correlacionados cuando la hipótesis nula sea cierta, y la condición para ello es que para cualquier par de contrastes (p. ej., L_p y L_q) la suma de productos de los coeficientes sea cero:

$$\sum_{i=1}^k \lambda_{pi} \lambda_{qi} = 0$$

En tal caso, se dice que L_p y L_q son *ortogonales*. Si existen k' contrastes ortogonales de este tipo, el análisis de la variancia se desarrollará del siguiente modo:

	SC	gl
<i>Entre grupos</i>		
Debido a L_1	$L_1^2 / (\sum \lambda_{1i}^2 / n)$	1
Debido a L_2	$L_2^2 / (\sum \lambda_{2i}^2 / n)$	1
⋮	⋮	⋮
Debido a $L_{k'}$	$L_{k'}^2 / (\sum \lambda_{k'i}^2 / n)$	1
Otros contrastes	$\sum T_i^2 / n - T^2 / n - \sum_{j=1}^{k'} L_j^2 / (\sum \lambda_{ji}^2 / n)$	$k - k' - 1$
<i>Intragrupos</i>	$S - \sum T_i^2 / n$	$k(n - 1)$
Total	$S - T^2 / nk$	$nk - 1$

con los sumatorios no indicados comprendidos desde $i = 1$ hasta k .

El uso directo del test de la t o de los test de la F es apropiado para las diferencias entre medias o para contrastes lineales más generales que surgen de forma natural de la estructura de la investigación. Sin embargo, se debe reconocer una dificultad. Si existen k grupos, existen $1/2k(k - 1)$ pares de medias que podrían ser comparados y no existe límite en cuanto al número de contrastes lineales que pueden plantearse. Todas estas comparaciones no son independientes, pero queda bastante claro que, incluso cuando la hipótesis nula es cierta, en cualquier grupo de datos es probable que alguno de estos contrastes resulte significativo. Una investigación suficientemente minuciosa revelará a menudo la existencia de contrastes significativos aparecidos puramente por causa del azar. Ello no debe importar si se restringe el escrutinio a aquellas comparaciones para las que fue diseñado el estudio. Si, en cambio, los datos se someten a lo que a veces se denomina procedimiento de *dragado* —una búsqueda de contrastes significativos en los que inicialmente no se había pensado—, existe un peligro real de que se considerara significativo un número determinado de contrastes, aparecidos casi todos por causa del azar.

Se han ideado algunos procedimientos para reducir la probabilidad de que ello ocurra. Se denominan métodos de *comparaciones múltiples* o de *inferencia simultánea* y son descritos en detalle por Miller (1981). Nosotros mencionamos brevemente dos métodos, uno para diferencias entre medias y el otro para contrastes lineales más generales.

El primer método, basado en la distribución de la *amplitud estudentizada*, se debe a Newman (1939) y a Keuls (1952). Dado un conjunto de p medias, cada una de ellas basada

en n observaciones, la amplitud estudentizada Q , es la amplitud de las $\bar{y}_i$ dividida por el error tipo estimado. En una notación obvia:

$$Q = \frac{\bar{y}_{\max} - \bar{y}_{\min}}{s/\sqrt{n}} \quad (7.25)$$

Se ha estudiado la distribución de Q , bajo la hipótesis nula de que todas las μ_i son iguales; en la tabla A5 figuran algunos puntos que limitan áreas superiores del 5% y del 1%. Éstos dependen del número de grupos, p , y de los grados de libertad intragrupos, f_2 , y se escriben $Q_{p;0.05}$ y $Q_{p;0.01}$. El procedimiento consiste en ordenar las $\bar{y}_i$ por orden de magnitud y contrastar la amplitud estudentizada para todos los pares de medias adyacentes (lo cual se reduce realmente al test de la t), lo mismo para todas las tríadas adyacentes y a continuación para todos los grupos de cuatro medias adyacentes, etc. Se dice que dos medias difieren significativamente sólo si todos los tests para grupos de medias incluyendo a estas dos dan un resultado significativo. Este procedimiento se efectúa con mayor frecuencia en el sentido opuesto al indicado, comenzando por todas las k medias, siguiendo con los dos grupos de $k-1$ medias adyacentes, etc. El motivo de ello es que si en alguno de los pasos se encuentra una Q no significativa, este conjunto de medias no requiere ser considerado en los tests posteriores. Por ejemplo, el test se para después de la primera etapa si Q no es significativa para todas las medias.

El siguiente ejemplo se ha tomado de la obra de Miller (apartado 6.1). Cinco medias ordenadas son 16,1, 17,0, 20,7, 21,1 y 26,5, $n = 5$, $f_2 = 20$ y el error tipo $s\sqrt{5} = 1,2$. Los valores de $Q_{p;0.05}$ para $p = 2, 3, 4$ y 5 son respectivamente, 2,95, 3,58, 3,96 y 4,23. Se efectúan pruebas sucesivamente para $p = 5, 4, 3$ y 2 . Los resultados obtenidos son los siguientes (se han subrayado las agrupaciones no significativas):

A	B	C	D	E
16,1	17,0	20,7	21,1	26,5

La interpretación es que E difiere de $\{A, B, C, D\}$ y que en este último grupo A difiere de C y D , y B ocupa una posición ambigua.

En el ejemplo 7.1, en el que se observó que $\bar{y}_3$ e $\bar{y}_4$ diferían en más de dos veces el error tipo de la diferencia, la Q calculada para todos los grupos es:

$$(371,2 - 274,8)/\sqrt{(3997/5)} = 96,4/28,3 = 3,41$$

y, según la tabla A5, $Q_{4;0.05}$ es 4,05, y el test no muestra diferencia significativa alguna, como se podría haber esperado teniendo en cuenta el test de la F no significativa.

El procedimiento de Newman-Keuls tiene la propiedad de que, para un conjunto de grupos con igual μ , la probabilidad de declarar una diferencia significativa entre cualesquiera de ellos es, al menos, igual al nivel elegido (0,05 en los ejemplos anteriores).

Si se han «dragado» contrastes lineales distintos a las diferencias, el número infinito de posibles elecciones sugiere que debería utilizarse un procedimiento muy conservador, es decir, uno que indique significaciones con mucha menor facilidad que el test de la t . Scheffé (1959) propuso el siguiente método. Un contraste lineal, L , se declara significativo, por ejemplo a nivel del 5%, si el valor absoluto de $L/ET(L)$ supera:

$$\sqrt{[(k-1)F_{0.05}]} \quad (7.26)$$

donde $F_{0,05}$ es el punto del 5% tabulado de la distribución de F con $k-1$ y $k(n-1)$ grados de libertad. Cuando $k=2$, esta regla es equivalente al empleo del test t . Para $k>2$, este procedimiento es evidentemente conservador en comparación con un test de la t , ya que el valor numérico de (7.26) puede exceder considerablemente el nivel del 5% de la t con $k(n-1)$ grados de libertad. El método de Scheffé tiene la propiedad de que si la hipótesis nula de que todas las μ_i son iguales es cierta, sólo en un 5% de los casos será posible encontrar un contraste lineal que sea significativo con este test. Cualquier contraste significativo con este test, incluso aunque se lo descubra a través de un proceso exhaustivo de «dragado» de datos, puede considerarse con un grado de confianza relativamente razonable. En el ejemplo 7.1, el contraste entre las medias de los experimentos 3 y 4 resulta $L/ET(L) = (371,2 - 274,8)/40,0 = 2,41$; con el test de Scheffé el valor del 5% sería $\sqrt{3(3,24)} = 3,12$ y el contraste observado no debería considerarse significativo.

Hay que hacer de nuevo hincapié en que los métodos de Newman-Keuls y de Scheffé y otros muchos métodos de comparación múltiple son deliberadamente conservadores para reducir la probabilidad de que aparezcan demasiadas diferencias significativas debidas al azar en cualquier estudio. Estos métodos son apropiados sólo cuando se están comparando medias de un modo exploratorio para observar qué podría «salir». Cuando se efectúan comparaciones que fluyen de forma natural del plan del experimento o de la encuesta, el test generalmente apropiado es el de la t .

7.5. Comparación de varias proporciones: la tabla de contingencia $2 \times k$

En (4.8) y en (4.9) la comparación de dos proporciones se consideró desde dos puntos de vista: el error tipo de la diferencia entre dos proporciones y el test de significación de la χ^2 aplicado a la tabla de contingencia 2×2 . Vimos que estas dos aproximaciones conducen a tests de significación de la hipótesis nula equivalentes.

Cuando se deben comparar más de dos proporciones, el cálculo de errores tipo entre pares de proporciones plantea cuestiones semejantes a las analizadas en el apartado 7.4, son posibles muchas comparaciones y puede aparecer un número indebido de diferencias significativas por causa del azar. Sin embargo, un test de significación global, análogo al del test de la F en el análisis de la variancia, está dado por una ampliación sencilla del test de la χ^2 .

Supóngase que existen k grupos de observaciones y que en el grupo i se han observado n_i individuos, de los cuales, r_i muestran una característica determinada (p. ej., ser «positivo»). Llamemos p_i a la proporción de positivos r_i/n_i . Los datos pueden presentarse del siguiente modo:

Grupo	1	2	...	i	...	k	Todos los grupos combinados
Positivo	r_1	r_2	...	r_i	...	r_k	R
Negativo	$n_1 - r_1$	$n_2 - r_2$	...	$n_i - r_i$	...	$n_k - r_k$	$N - R$
Total	n_1	n_2	...	n_i	...	n_k	N
Proporción de positivos	p_1	p_2	...	p_i	...	p_k	$P = R/N$

Las frecuencias forman una tabla de contingencia $2 \times k$ (en la que existen 2 filas y k columnas, excluyendo los totales marginales). El test de χ^2 sigue el mismo procedimiento que

la tabla 2×2 (apartado 4.9). Para cada una de las frecuencias observadas, O , una frecuencia esperada se calcula con la fórmula:

$$E = \frac{\text{Total fila} \times \text{Total columna}}{N} \quad (7.27)$$

se calcula la cantidad $(O - E)^2/E$, y, por último,

$$X^2 = \sum \frac{(O - E)^2}{E} \quad (7.28)$$

realizando el sumatorio sobre las $2k$ casillas de la tabla.

Bajo la hipótesis nula de que las k muestras han sido extraídas al azar de poblaciones con la misma proporción de positivos, X^2 se distribuye aproximadamente como una distribución de $\chi^2_{(k-1)}$, mejorando dicha aproximación a medida que aumentan las frecuencias. En el apartado 7.6 se da una indicación sobre el alcance de la validez de la distribución $\chi^2_{(k-1)}$ para el caso de frecuencias pequeñas. No se requiere corrección de la continuidad porque, a menos que las frecuencias observadas sean muy pequeñas, el número de tablas que se pueden formar con los mismos totales marginales observados es muy grande, y la distribución de X^2 es, en consecuencia, más continua que en el caso de la tabla 2×2 .

Existe una fórmula alternativa para X^2 , que reviste cierto interés. El valor $O - E$ para una casilla de la primera fila de la tabla (p. ej., los positivos del grupo i) vale:

$$r_i - Pn_i$$

fácilmente se ve que sólo difiere en el signo del valor correspondiente a la casilla de los negativos del grupo i :

$$(n_i - r_i) - (1 - P)n_i = -(r_i - Pn_i)$$

Por consiguiente, la contribución a X^2 de estas dos casillas es:

$$(r_i - Pn_i)^2 \left(\frac{1}{Pn_i} + \frac{1}{Qn_i} \right)$$

donde $Q = 1 - P$. La expresión del segundo paréntesis se simplifica al cálculo, para dar la siguiente expresión para X^2 :

$$X^2 = \frac{\sum n_i(p_i - P)^2}{PQ} \quad (7.29)$$

y el sumatorio corresponde en este caso a todos los k grupos. Una pequeña modificación en el sumatorio de (7.29) proporciona dos expresiones equivalentes:

$$X^2 = \frac{\sum n_i p_i^2 - NP^2}{PQ}$$

$$X^2 = \frac{\sum (r_i^2/n_i) - R^2/N}{PQ} \quad (7.30)$$

Las dos últimas expresiones son más adecuadas como fórmulas para el cálculo que (7.29).

La expresión (7.29) y los resultados del apartado 7.2 proporcionan una indicación de la razón por la cual X^2 sigue la distribución $\chi^2_{(k-1)}$. En la formulación general del apartado 7.2 podemos sustituir Y_i por p_i , V_i por PQ/n_i y w_i por n_i/PQ . La media ponderada $\bar{Y}$ resulta:

$$\frac{\sum (n_i p_i / PQ)}{\sum (n_i / PQ)} = \frac{\sum n_i p_i}{\sum n_i} = \frac{R}{N} = P$$

y, según (7.14) el test estadístico de contraste G , que se distribuye según $\chi^2_{(k-1)}$, resulta:

$$X^2 = \sum_i \frac{n_i (p_i - P)^2}{PQ}$$

coincidiendo con (7.29). Nos hemos apartado de las asunciones subyacentes a (7.14) en dos aspectos: la variación de p_i es binomial, no normal, y la variancia verdadera, σ_p^2 , ha sido sustituida por la variancia estimada, PQ/n_i . La importancia de estas dos aproximaciones disminuye a medida que las frecuencias esperadas aumentan de tamaño.

Ejemplo 7.3

La tabla 7.2 muestra los números de individuos de varios grupos de edad que, en un análisis presentaron, o no, huevos de *Schistosoma mansoni* en las heces.

El número de positivos esperado para el grupo de edad 0- es

$$(57)(101)/288 = 19,99$$

El conjunto de frecuencias esperadas para las diez casillas de la tabla es:

						Total
	19,99	9,70	15,83	8,11	3,36	57
	81,01	39,30	64,17	32,89	13,64	231
Total	101	49	80	41	17	288

El hecho de que las frecuencias esperadas reproduzcan los mismos totales marginales es un control útil.

La contribución a X^2 de la primera casilla es:

$$(14 - 19,99)^2 / 19,99 = 1,79$$

Tabla 7.2. Presencia o ausencia de huevos de *Schistosoma mansoni* en las heces.

Edad (años)	0-	10-	20-	30-	40-	Total
Positivos	14	16	14	7	6	57
Negativos	87	33	66	34	11	231
Total	101	49	80	41	17	288

y el conjunto de contribuciones para las 10 casillas es:

1,79	4,09	0,21	0,15	2,07
0,44	1,01	0,05	0,04	0,51

resultando un total igual a:

$$X^2 = 10,36$$

Los grados de libertad son $k - 1 = 4$, para los cuales el punto del 5% es 9,49. Las desviaciones de la hipótesis nula son, en consecuencia, significativas al nivel del 5% ($p = 0,035$).

En este ejemplo, la clasificación de las columnas está basada en una variable continua, la edad, y sería natural preguntarse si las proporciones de positivos muestran alguna suave tendencia con la edad. Las proporciones estimadas, con sus errores tipos calculados como $\sqrt{(p,q/n)}$, son:

0,14	0,33	0,18	0,17	0,35
$\pm 0,03$	$\pm 0,07$	$\pm 0,04$	$\pm 0,06$	$\pm 0,12$

estando la última basada en números particularmente pequeños. No se observa una tendencia clara (en el apartado 12.2 se proporciona un método para comprobar una tendencia). Alrededor de la mitad de la contribución a X^2 surge del segundo grupo de edad (10-19 años) y parece que la proporción de positivos en este grupo es mayor que en los grupos de edad vecinos.

Para ilustrar el uso de (7.30) tomemos los números de positivos r_j . Entonces

$$X^2 = (14^2/101 + \dots + 6^2/17 - 57^2/288)/(0,1979) \quad (0,8021)$$

donde $P = 57/288 = 0,1979$. Esto da:

$$X^2 = 10,37$$

igual que antes; la discrepancia se debe a errores de redondeo. Nótese que si, en lugar de los positivos, se hubieran indicado los *negativos* por r_j , los términos del numerador de (7.30) habrían sido diferentes, pero el resultado habría sido el mismo.

7.6. Tablas de contingencia generales

La forma de la tabla considerada en el último apartado puede ser generalizada para permitir más de dos filas. Supóngase que una frecuencia total, N , se subdivide en r categorías de fila y en c categorías de columna. La hipótesis nula, correspondiente a las planteadas en las situaciones más sencillas, es que las probabilidades de caer en las diversas columnas son independientes de las filas o, de modo equivalente, que las probabilidades de las distintas filas son las mismas para cada columna.

El test de la χ^2 sigue exactamente el test aplicado en los casos más sencillos. Para cada casilla del cuerpo de la tabla se calcula una frecuencia esperada, E , con (7.27) y se obtiene el índice X^2 a partir de (7.28) sumando a lo largo de las rc casillas. Existen varias fórmulas alternativas, aunque ninguna es tan simple como (7.29) o (7.30) y probablemente es conveniente referirse a la fórmula básica (7.28). Bajo la hipótesis nula, X^2 sigue la distribución $\chi^2_{(f)}$, siendo $f = (r - 1)(c - 1)$. Este número de grados de libertad debe considerarse como el número de elecciones arbitrarias de las frecuencias en el cuerpo de la tabla, con la restricción de que deben sumar los mismos marginales que aquellos observados y, en consecuencia, dar los mismos valores de E . (Si las entradas en $r - 1$ filas y $c - 1$ columnas se establecen arbitrariamente, las de las otras filas y columnas estarán determinadas por los totales marginales.)

De nuevo, la distribución de χ^2 es una aproximación cuya validez aumenta a medida que lo hacen las frecuencias esperadas. Una regla más o menos exacta (Cochran, 1954) es que la aproximación es válida con la condición de que las relativamente pocas frecuencias esperadas sean menores de 5 (p. ej. 1 casilla de cada 5 o más, o 2 casillas de cada 10 o más), y que ninguna frecuencia esperada sea menor de 1. En las tablas con frecuencias esperadas menores, el resultado del test de significación debería tomarse con precaución. Si el resultado no es claramente significativo o no significativo es conveniente reagrupar algunas filas y/o columnas en las que existan frecuencias esperadas bajas y volver a calcular X^2 (por supuesto, con un número menor de grados de libertad). Véanse las sugerencias planteadas por Cochran (1954, p. 420).

Ejemplo 7.4

La tabla 7.3 muestra los resultados obtenidos en un ensayo para comparar los efectos del ácido paraamino-salicílico (PAS) y la estreptomycin en el tratamiento de la tuberculosis pulmonar. En cada casilla de la tabla se muestran las frecuencias observadas, O , las frecuencias esperadas, E , y las diferencias $O - E$. Por ejemplo, para la primera casilla, $E = (99)(139)/273 = 50,41$.

Nótese que los valores de $O - E$ suman cero a lo largo de cada fila y de cada columna, siendo una verificación útil de los cálculos.

$$\begin{aligned} X^2 &= (5,59)^2/50,41 + \dots + (12,58)^2/22,42 \\ &= 17,64 \end{aligned}$$

Los grados de libertad de la distribución de χ^2 son $(3 - 1)(3 - 1) = 4$, y, según la tabla A2, el punto correspondiente al 1% es 13,28. La relación entre tratamiento y tipo de esputo es por consiguiente significativa al nivel del 1%. ($P = 0,0014$). Las magnitudes y los signos de las diferencias, $O - E$, muestran claramente que la principal diferencia se encuentra entre el PAS (que tiende a dar más resultados positivos) y el tratamiento combinado (que tiende a dar más resultados negativos).

El test exacto de Fisher (apartado 4.9) se puede ampliar a una tabla $r \times c$ general (Mehta y Patel, 1983). El nivel exacto de probabilidad es igual a la suma de todas las probabilidades inferiores o iguales a la tabla observada, donde las probabilidades se calculan de conformidad con la hipótesis nula de que no hay relación alguna y de que todos los totales marginales son fijos. Esto corresponde a un test de dos colas, usando el método alternativo de calcular la otra cola en una tabla 2×2 (p. 131), pero como el test es de relación general, no hay colas

Tabla 7.3. Grados de positividad de los esputos de pacientes con tuberculosis pulmonar tratados con PAS, estreptomycinina o una combinación de ambos fármacos (Médical Research Council, 1950).

Tratamiento		Esputo			Total
		Extensión negativa	Extensión negativa, cultivo positivo	Extensión negativa, cultivo negativo	
PAS	<i>O</i>	56	30	13	99
	<i>E</i>	50,41	23,93	24,66	
	<i>O - E</i>	5,59	6,07	-11,66	
Estreptomycinina		46	18	20	84
		42,77	20,31	20,92	
		3,23	-2,31	-0,92	
Estreptomycinina y PAS		37	18	35	90
		45,82	21,76	22,42	
		-8,82	-3,76	12,58	
Total		139	66	68	273

definidas. En el programa PROC FREQ de SAS, este cálculo puede obtenerse como «EXACT» y es factible cuando $n < 5(r - 1)(c - 1)$, y también en StatXact (v. cap. 18).

7.7. Comparación de varias variancias

El análisis de la variancia de un factor (apartado 7.1) es una generalización del test de la *t* para dos muestras (apartado 4.4). En ocasiones se requiere una generalización del test de la *F* (utilizado en el apartado 4.6 para la comparación de dos variancias), para el caso en que se deben comparar más de dos estimaciones de la variancia. Por ejemplo, en el análisis de la variancia de un factor, el propósito principal es comparar medias, pero uno podría desear comprobar las diferencias entre variancias, por el interés intrínseco de esta comparación y porque el análisis de la variancia incluye la aseveración de que las variancias de grupo son iguales.

Supongamos que existen *k* estimaciones de la variancia, s_i^2 , posiblemente con distintos grados de libertad, v_i . (Si el grupo *i* contiene n_i observaciones, $v_i = n_i - 1$). Basándose en la suposición de que las observaciones están seleccionadas al azar a partir de distribuciones normales, existe un test de significación aproximado debido a Bartlett (1937) que consiste en calcular:

$$\bar{s}^2 = \sum v_i s_i^2 / \sum v_i$$

$$M = (\sum v_i) \ln \bar{s}^2 - \sum v_i \ln s_i^2$$

y

$$C = 1 + \frac{1}{3(k-1)} \left[\sum \left(\frac{1}{v_i} \right) - \frac{1}{\sum v_i} \right]$$

siguiendo M/C la distribución de $\chi^2_{(k-1)}$. Aquí « $\ln$ » se refiere a logaritmo *natural* (v. p. 124). Es probable que la cantidad sea cercana a 1, y sólo es necesario calcularla en casos especiales. Snedecor y Cochran (1989, apartado 13.10) ofrecen ejemplos exhaustivos.

El test de Bartlett es quizá menos útil de lo que cabría esperar por dos motivos. Primero, al igual que el test de la F , es bastante sensible para la no normalidad. Segundo, con muestra de tamaño moderado, las variancias verdaderas σ_i^2 deben diferir considerablemente para que exista una posibilidad razonable de obtener un test con resultado significativo. En otras palabras, incluso si M/C no es significativo, las s_i^2 estimadas pueden diferir sustancialmente y, en consecuencia, también las verdaderas σ_i^2 . Si la posible desigualdad de σ_i^2 es importante, puede ser prudente asumirla aunque el resultado no fuera significativo. En algunas situaciones no es muy importante que exista una moderada desigualdad de las σ_i^2 , por lo que nuevamente el test de significación no es aplicable.

7.8. Comparación de varias frecuencias: test de heterogeneidad de Poisson

Supóngase que disponemos de k recuentos, $x_1, x_2, \dots, x_i, x_k$. Quizá fuera interesante comprobar si éstos podrían razonablemente haber sido extraídos al azar de distribuciones de Poisson con la misma media μ (desconocida). Como vimos en el apartado 2.6, en numerosos experimentos en microbiología se puede esperar que muchos recuentos sucesivos sigan una distribución de Poisson si la técnica experimental es perfecta. Con métodos técnicos imperfectos los recuentos seguirán distribuciones de Poisson de medias *diferentes*. En el recuento bacteriológico, por ejemplo, la suspensión puede mezclarse de modo inadecuado, produciéndose una aglutinación de los microorganismos. Los volúmenes de la suspensión inoculada para los diferentes recuentos pueden ser desiguales. El medio de cultivo puede ser insuficiente para mantener el crecimiento. En cada una de estas circunstancias está presente una heterogeneidad de los recuentos esperados y es probable que se manifieste por una excesiva variabilidad de los recuentos observados. Por ello, parece razonable basar un test en la suma de cuadrados alrededor de la media de x_i . La siguiente fórmula ofrece un test estadístico apropiado:

$$\chi^2 = \frac{\sum (x - \bar{x})^2}{\bar{x}} \quad (7.31)$$

el cual, bajo la hipótesis nula de μ constante, se distribuye aproximadamente como una $\chi^2_{(k-1)}$. El método se denomina indistintamente test de *heterogeneidad* o de *dispersión* de Poisson.

La fórmula (7.31) puede justificarse desde dos puntos de vista. Primero está íntimamente relacionada con el test estadístico (4.8) utilizado para comprobar la variancia de una distribución normal. En la presente hipótesis nula, la distribución es la de Poisson, que, según sabemos, es similar a la distribución normal si μ no es demasiado pequeña. Además $\sigma^2 = \mu$, que puede estimarse más fácilmente a partir de los datos mediante la media muestral $\bar{x}$. Sustituyendo σ^2 por $\bar{x}$ en (4.8) se obtiene (7.31). En segundo lugar, podríamos argumentar que, dado el recuento total $\sum x$, la frecuencia «esperada» del recuento i bajo la hipótesis nula es $\sum x/k = \bar{x}$. Aplicando la fórmula habitual para un índice χ^2 , $\sum [(O - E)^2/E]$, se obtiene inmediatamente (7.31). De hecho, dado que la distribución de Poisson puede considerarse

como una forma límite de la binomial para n grandes y p pequeñas, el presente test puede considerarse como una forma límite del test de la χ^2 para una tabla $2 \times k$ (apartado 7.5) cuando R/N es muy pequeña y todas las n_i son iguales; en estas circunstancias no es difícil comprobar que (7.29) es equivalente a (7.31).

Ejemplo 7.5

Los siguientes datos fueron proporcionados por «Student» (1907), quien fue el primero en subrayar el papel de la distribución de Poisson en microbiología.

Se efectuaron 20 recuentos con un citómetro de células de levadura:

2	4	4	8
3	3	5	6
7	7	2	7
4	8	5	4
4	1	5	7

Y así:

$$\begin{aligned}
 k &= 20, \\
 \sum x &= 96, \\
 \bar{x} &= 4,8, \\
 \sum x^2 &= 542 \\
 (\sum x)^2/k &= 460,8 \\
 \sum (x - \bar{x})^2 &= 81,2. \\
 X^2 &= 81,2/4,8 = 16,92 \text{ con } 19 \text{ gl } (P = 0,60).
 \end{aligned}$$

No existe indicio alguno de una variabilidad en exceso con respecto a la esperada en la distribución de Poisson.

Al relacionar X^2 con la distribución de $\chi^2_{(k-1)}$, habitualmente debemos efectuar un test unilateral, porque la heterogeneidad tiende a dar valores altos de X^2 . En ocasiones, sin embargo, las desviaciones de la distribución de Poisson conducirán a una variabilidad reducida. En los recuentos microbiológicos ello podría deberse a la omisión de recuentos que difieren ampliamente de la media; Lancaster (1950) ha demostrado que los técnicos poco entrenados en el recuento de células sanguíneas (lo cual en circunstancias ideales ofrece otro ejemplo de la teoría de Poisson) tienden a omitir los valores extremos o repiten observaciones, presumiblemente debido a que infravaloran la repercusión de la variación aleatoria. Otras causas de una reducida variabilidad son la incapacidad de registrar con precisión los recuentos altos (p. ej., debido a la imbricación de colonias bacterianas) o la interferencia física entre partículas que evita que muchas se dispongan juntas. Este último fenómeno ha sido estudiado por Lancaster (1950) en el recuento de hematíes.

El uso de la distribución de $\chi^2_{(k-1)}$ en el test de heterogeneidad es una aproximación, pero bastante correcta con la condición de que $\bar{x}$ sea mayor de 5, e incluso da buenos resultados

para valores mucho menores de $\bar{x}$ (tan bajos como 2) con la condición de que k no sea demasiado pequeño (> 15). Para valores muy pequeños de $\bar{x}$, Fisher (1950, 1964) ha indicado la forma de obtener un test exacto; el método es ilustrado por Oldham (1968, apartado 5.15).

Por último, nótese que para $k = 2$, (7.31) es equivalente a $(x_1 - x_2)^2 / (x_1 + x_2)$, que fue empleada como una variante de $\chi^2_{(1)}$ en el apartado 4.11.

Capítulo 8

Otros diseños experimentales

8.1. Análisis de la variancia de dos factores: bloques aleatorios

En este capítulo examinaremos otros diseños experimentales y los correspondientes métodos de análisis de los datos. La mayoría de éstos determinan diversas formas de análisis de la variancia. Analizaremos estudios en los que los cambios de los valores de la media de alguna variable representan el principal interés, pero en los que los datos tienen una estructura más complicada que la de las clasificaciones de un factor estudiadas en los apartados 7.1 a 7.4.

La extensión más simple es la de los datos clasificados de dos formas: por un grupo de categorías que pueden ser representadas, por ejemplo, por las filas de una tabla y por otro conjunto que forma las columnas. Esta estructura se presenta naturalmente en el diseño experimental de «bloques aleatorios», en el que una clasificación define distintos tratamientos y la otra consiste en distintos bloques de material experimental. Si hay r bloques y c tratamientos y cada bloque contiene c unidades experimentales a las que se asigna el tratamiento de forma aleatoria, habrá un total de $N = rc$ observaciones de cualquier variable dividida simultáneamente en r bloques de c observaciones cada uno, y en c grupos de tratamiento con r observaciones en cada uno.

En otras situaciones experimentales, tanto las filas como las columnas de la tabla de dos factores pueden representar distintos tipos de tratamiento. Por ejemplo, en un experimento sobre la coagulación de la sangre, se pueden medir tiempos de coagulación para cada combinación de r períodos de almacenamiento de plasma y c concentraciones de adrenalina mezclada con el plasma. Éste es un ejemplo sencillo de *experimento factorial*, que se describe de forma más general en el apartado 8.3. La diferencia entre esta situación y el experimento con bloques aleatorios es que en éste se introduce la clasificación de los bloques principalmente con el fin de conseguir una mayor precisión para la comparación entre tratamientos; las diferencias entre los bloques habitualmente no tienen interés intrínseco.

Las clasificaciones de dos factores también pueden surgir en trabajos no experimentales, tanto al clasificar datos recogidos en una encuesta como al disponer la recogida de datos en una clasificación de dos factores.

Consideremos en primer lugar la situación en que sólo existe una observación en cada combinación de una fila y una columna; para la fila i y la columna j la observación es y_{ij} . Para representar el posible efecto de las clasificaciones de filas y columnas sobre el valor medio de y_{ij} , consideremos un «modelo aditivo» en el que:

$$E(y_{ij}) = \mu + \alpha_i + \beta_j \quad (8.1)$$

donde α_i y β_j son constantes que caracterizan las filas y las columnas. Escogiendo correctamente μ podemos obtener:

y

$$\sum_{i=1}^r \alpha_i = 0$$

$$\sum_{j=1}^c \beta_j = 0$$

Según (8.1), el efecto de pertenecer a una fila en lugar de otra hace variar el valor medio sumando o restando una cantidad constante independientemente de la columna a la que pertenece la observación. Los cambios entre columnas tienen un efecto similar de adición o resta. Cualquier valor y_{ij} observado variará aleatoriamente alrededor de su valor esperado obtenido mediante (8.1). Suponemos que:

$$y_{ij} = E(y_{ij}) + \varepsilon_{ij} \quad (8.2)$$

donde ε_{ij} se distribuye de forma independiente y normal con una variancia constante σ^2 . Los supuestos no son necesariamente verdaderos; luego consideraremos diversas formas de comprobar su veracidad y de superar las dificultades debidas a desviaciones con respecto al modelo.

Denótese el total y la media de la fila i mediante R_i e $\bar{y}_i$, los de la columna j mediante C_j e $\bar{y}_j$, y los de todo el grupo de $N = rc$ observaciones mediante T e $\bar{y}$ (tabla 8.1). Como en el análisis simple de la variancia, la suma de cuadrados total, $\sum (y_{ij} - \bar{y})^2$, se dividirá en varias partes. Para cada una de estas desviaciones de la media, $y_{ij} - \bar{y}$, se comprueba que:

$$y_{ij} - \bar{y} = (\bar{y}_i - \bar{y}) + (\bar{y}_j - \bar{y}) + (y_{ij} - \bar{y}_i - \bar{y}_j + \bar{y}) \quad (8.3)$$

Los tres términos de la derecha reflejan que $\bar{y}_{ij}$ difiere de $\bar{y}$ en parte a causa de una característica diferencial de la fila i , en parte a causa de una característica diferencial de la columna j y en parte por una cantidad que no puede explicarse ni por las diferencias de las filas ni

Tabla 8.1. Notación de los datos de un análisis de la variancia de dos factores.

		Columna						Total	Media, R_i/c
		1	2	...	j	...	c		
Fila	1	y_{11}	y_{12}	...	y_{1j}	...	y_{1c}	R_1	$\bar{y}_1$
	2	y_{21}	y_{22}	...	y_{2j}	...	y_{2c}	R_2	$\bar{y}_2$
	.	.	.	.	.	.	.	.	.
	.	.	.	.	.	.	.	.	.
	.	.	.	.	.	.	.	.	.
	i	y_{i1}	y_{i2}	...	y_{ij}	...	y_{ic}	R_i	$\bar{y}_i$
	.	.	.	.	.	.	.	.	.
	.	.	.	.	.	.	.	.	.
Total	r	$\underline{y_{r1}}$	$\underline{y_{r2}}$	...	$\underline{y_{rj}}$	...	$\underline{y_{rc}}$	R_r	$\bar{y}_r$
		$\underline{\quad}$	$\underline{\quad}$	...	$\underline{\quad}$	...	$\underline{\quad}$	$\underline{\quad}$	$\underline{\quad}$
Total		C_1	C_2	...	C_j	...	C_c	T	
Media	C/r	$\bar{y}_{.1}$	$\bar{y}_{.2}$	...	$\bar{y}_{.j}$	...	$\bar{y}_{.c}$		$(\bar{y} = T/N)$

de las columnas. Si se eleva (8.3) al cuadrado y se suma para todas las N observaciones, se obtiene (los sufijos i, j se suponen bajo cada signo de sumatorio):

$$\sum (y_{ij} - \bar{y})^2 = \sum (\bar{y}_i - \bar{y})^2 + \sum (\bar{y}_j - \bar{y})^2 + \sum (y_{ij} - \bar{y}_i - \bar{y}_j + \bar{y})^2 \quad (8.4)$$

Para demostrar (8.4) tenemos que comprobar que todos los productos que aparecen al elevar al cuadrado el miembro de la derecha de (8.3) son iguales a cero. Por ejemplo $\sum (\bar{y}_i - \bar{y})(y_{ij} - \bar{y}_i - \bar{y}_j + \bar{y}) = 0$. Estos resultados pueden comprobarse fácilmente mediante cálculos algebraicos sencillos.

Los tres términos de la derecha de (8.4) se denominan suma de cuadrados (SC) entre filas, SC entre columnas y SC residual. Los dos primeros tienen exactamente la misma forma que las sumas de cuadrados entre grupos del análisis de la variancia de un factor y puede utilizarse el método abreviado para su cálculo (v. (7.5)):

$$\text{Entre filas:} \quad \sum (\bar{y}_i - \bar{y})^2 = \sum_{i=1}^r R_i^2/c - T^2/N$$

$$\text{Entre columnas:} \quad \sum (\bar{y}_j - \bar{y})^2 = \sum_{j=1}^c C_j^2/r - T^2/N$$

La SC total se calcula de forma similar:

$$\sum (y_{ij} - \bar{y})^2 = \sum y_{ij}^2 - T^2/N$$

y la SC residual se obtiene mediante una resta:

$$\text{SC residual} = \text{SC total} - \text{SC entre filas} - \text{SC entre columnas} \quad (8.5)$$

Hasta aquí, el análisis es puramente una consecuencia de identidades algebraicas. Las interrelaciones mostradas antes son verdaderas independientemente de la validez del modelo. Ahora completaremos el análisis de la variancia con algunos pasos cuya validez depende de la validez del modelo. En primer lugar, los grados de libertad se asignan como se indica en la tabla 8.2. Los de las filas y las columnas derivan del análisis simple de la variancia; si la única clasificación se hubiera realizado entre filas, por ejemplo, la primera línea de la tabla 8.2 se mostraría como entre grupos, y las SC presentadas en la tabla 8.2 como entre columnas y residual se sumarían para formar la SC intragrupos. Con $r-1$ y $c-1$ gl para las filas y las columnas, respectivamente, y $N-1$ para la suma de cuadrados total, los grados de libertad para la SC residual se obtienen por resta:

$$(rc-1) - (r-1) - (c-1) = rc - r - c + 1 = (r-1)(c-1)$$

Las medias cuadráticas (MC) de las filas, las columnas y residual se obtienen en cada caso mediante la fórmula: $\text{MC} = \text{SC}/\text{grados de libertad}$, y las de las filas y las columnas pueden contrastarse frente a la media de cuadrado residual, s^2 , como se muestra en la tabla 8.2. Por ejemplo, el contraste para las filas tiene la siguiente justificación. En el caso de la hipótesis nula (que denominaremos H_R) en la que todas las constantes de las filas α_i de (8.1) son igua-

Tabla 8.2. Tabla del análisis de la variancia de dos factores.

	SC	gl	MC	CV
Entre filas	$\sum_i R_i^2/c - T^2/N$	$r - 1$	s_R^2	$F_R = s_R^2/s^2$
Entre columnas	$\sum_j C_j^2/r - T^2/N$	$c - 1$	s_C^2	$F_C = s_C^2/s^2$
Residual	Por resta	$(r - 1)(c - 1)$	s^2	
Total	$\sum_{i,j} y_{ij}^2 - T^2/N$	$rc - 1$ ($= N - 1$)		

les (y, por lo tanto, iguales a cero, puesto que $\sum \alpha_i = 0$), tanto s_R^2 como s^2 son estimaciones no sesgadas de σ^2 . Si H_R es falsa, de modo que α_i sea diferente, s_R^2 tiene un valor esperado mayor que σ^2 , mientras que s^2 sigue siendo una estimación no sesgada de σ^2 . Por lo tanto, F_R tiende a ser mayor que 1, y unos valores suficientemente elevados indican una desviación con respecto a H_R . Este test es válido con cualquier valor de β_j , puesto que al añadir las constantes de todas las lecturas de una columna específica no afecta s_R^2 ni s^2 .

De forma similar, F_C proporciona un test de la hipótesis nula H_C en el que todas las $\beta_j = 0$, independientemente de los valores de α_i .

Si el modelo activo (8.1) no es cierto, la SC residual resultará inflada por las diferencias entre $E(y_{ij})$ y las aproximaciones dadas por el modelo aditivo mejor ajustado, y la MC residual será en este caso una estimación no sesgada de una cantidad mayor que la variancia aleatoria. ¿Cómo podemos saber si esto ha ocurrido? Existen dos formas distintas de analizarlo. La primera de ellas consiste en examinar los *residuales*. Éstos son las expresiones individuales $y_{ij} - \bar{y}_i - \bar{y}_j + \bar{y}$. Su SC se obtuvo a partir de (8.4) mediante resta, pero podría haberse calculado por la evaluación directa de todos los N residuales y sumando sus cuadrados. Los residuales suman cero para cada fila y para cada columna al igual que las diferencias entre frecuencias observadas y esperadas de una tabla de contingencia (apartado 7.6) y, al igual que en las tablas de contingencia, el número de grados de libertad, $(r - 1)(c - 1)$, es el número de valores de los residuales que pueden escogerse de forma independiente (los demás se determinarán automáticamente). A causa de la falta de independencia, los residuales no representan lo mismo que los términos de error aleatorio ε_{ij} de (8.2), aunque poseen unas propiedades de distribución muy similares. En particular no deberían mostrar ningún patrón notable. A veces, los residuales de una zona de una tabla de dos factores parecen tener un mismo signo predominante. Siempre que la ordenación de las filas y columnas tenga algún significado, esto sugeriría que las constantes del efecto de las filas no son las mismas para todas las columnas. Puede haber una correlación entre el tamaño del residual y el valor «esperado»* $\bar{y}_i + \bar{y}_j - \bar{y}$; esto sugeriría que una modificación de la escala daría una mejor concordancia con un modelo aditivo.

Otro planteamiento consiste en realizar observaciones repetidas; esto se comenta con detalle después del ejemplo 8.1.

* Éste es el valor esperado sobre la base de los efectos medios de las filas y las columnas, como puede observarse mediante la expresión equivalente $\bar{y} + (\bar{y}_i - \bar{y}) + (\bar{y}_j - \bar{y})$.

Ejemplo 8.1

La tabla 8.3 muestra los resultados de un experimento de bloques aleatorios para comparar los efectos de cuatro diferentes métodos de tratamiento de plasma sobre el tiempo de coagulación. Las muestras de plasma de ocho individuos (los «bloques») se asignaron a los cuatro tratamientos según un orden aleatorio.

El término de corrección T^2/N , expresado por TC, es necesario para tres términos de la columna de SC, y es útil calcularlo al inicio. El análisis es sencillo, y los test de las F muestran que las diferencias entre individuos y entre tratamientos son altamente significativas. Las diferencias entre los individuos no nos interesan mucho, puesto que el objetivo principal del experimento era el estudio de las diferencias entre tratamientos. El error tipo de la diferencia entre las medias de dos tratamientos es $\sqrt{[2(0,6559)/8]} = 0,405$. Como es evidente, los tratamientos 1, 2 y 3 no difieren significativamente entre sí, pero el tratamiento 4 proporciona un tiempo de coagulación medio significativamente superior al de los demás.

A continuación, para ilustrar el ejemplo se muestran los residuales:

Individuo	Tratamiento				Total
	1	2	3	4	
1	-0,86	-0,27	-0,10	1,22	-0,01
2	-0,33	1,66	-0,87	-0,45	0,01
3	0,37	-0,54	1,33	-1,15	0,01
4	0,37	-1,04	-0,17	0,85	0,01
5	0,69	0,08	0,15	-0,93	-0,01
6	-0,51	0,38	0,05	0,07	-0,01
7	0,21	-0,10	-0,13	-0,01	-0,03
8	0,04	-0,17	-0,30	0,42	-0,01
Total	-0,02	0,00	-0,04	0,02	-0,04

La primera entrada, por ejemplo, se calcula a partir de la tabla 8.3, como sigue:

$$8,4 - 9,95 - 9,30 + 9,99 = -0,86$$

La SC de los 32 residuales del cuerpo de la tabla es 13,7744, lo cual concuerda con el valor obtenido mediante una resta en la tabla 8.3, ignorando los errores de redondeo. (Estos errores justifican también el hecho de que los residuales no sumen exactamente cero a lo largo de las filas y las columnas.) A partir de la tabla de residuales no se observa un patrón específico y tampoco parece que la distribución sea muy diferente de la normal. Existen 16 valores negativos y 16 valores positivos; los tres valores absolutos más elevados son positivos (1,66, 1,33 y 1,22), lo que sugiere levemente que la distribución del error aleatorio puede presentar una ligera inclinación positiva.

Si el modelo lineal (8.1) es falso se dice que existe una *interacción* entre los efectos de las filas y las columnas. En ausencia de interacción, las diferencias esperadas entre observaciones en distintas columnas son las mismas para todas las filas (y esta afirmación es verdadera si intercambiamos las palabras «columnas» y «filas»). Si existe una interacción, las dife-

Tabla 8.3. Tiempo de coagulación en minutos del plasma de ocho individuos tratados con cuatro métodos.

Individuo	Tratamiento				Total	Media
	1	2	3	4		
1	8,4	9,4	9,8	12,2	39,8	9,95
2	12,8	15,2	12,9	14,4	55,3	13,82
3	9,6	9,1	11,2	9,8	39,7	9,92
4	9,8	8,8	9,9	12,0	40,5	10,12
5	8,4	8,2	8,5	8,5	33,6	8,40
6	8,6	9,9	9,8	10,9	39,2	9,80
7	8,9	9,0	9,2	10,4	37,5	9,38
8	7,9	8,1	8,2	10,0	34,2	8,55
Total	74,4	77,7	79,5	88,2	319,8	
Media	9,30	9,71	9,94	11,02		(9,99)

Término de corrección, $TC = (319,8)^2/32$	= 3.196,0013
SC entre individuos = $[(39,8)^2 + \dots + (34,2)^2]/4 - TC$	= 78,9888
SC entre tratamientos = $[(74,4)^2 + \dots + (88,2)^2]/8 - TC$	= 13,0163
SC total = $(8,4)^2 + \dots + (10,0)^2 - TC$	= 105,7788
SC residual = $105,7788 - 78,9888 - 13,0163$	= 13,7737

Análisis de variancia

	SC	gl	MC	CV	
Individuos	78,9888	7	11,2841	17,20	($P < 0,001$)
Tratamientos	13,0163	3	4,3388	6,62	($P < 0,003$)
Residual	13,7737	21	0,6559	1,00	
Total	105,7788	31			

rencias esperadas en las columnas varían de una fila a otra (y de forma similar, las diferencias esperadas en las filas varían de una columna a otra). Con una sola observación en cada casilla de columna/fila, el efecto de la interacción se mezcla estrechamente con el de la variación residual. Sin embargo, supóngase que se dispone de más de una observación por casilla. La variación entre observaciones *dentro de la misma casilla* proporciona una evidencia directa sobre la variancia *aleatoria* σ^2 y, por lo tanto, puede utilizarse como base para la comparación de los residuales entre casillas. Esto se ilustra en el siguiente ejemplo.

Ejemplo 8.2

En la tabla 8.4 se muestran unos datos hipotéticos relacionados con los de la tabla 8.3. Hay tres individuos y tres tratamientos, y para cada combinación individuo-tratamiento se realizan tres observaciones repetidas. Se verá que la media de cada grupo de tres repeticiones concuerda con el valor mostrado en la tabla 8.3 para el mismo individuo y el mismo tratamiento. En cada grupo de repeticiones se muestra el total, T_{ij} , y la suma de cuadrados, S_{ij} (como se indica para T_{ij} y S_{ij}).

Las SC entre individuos y entre tratamientos se obtienen directamente utilizando el divisor 9 para las SC de las filas (o columnas) puesto que hay 9 observaciones en cada fila (o columna), y utilizando el divisor 27 en el término de corrección. La SC de la interacción se obtiene de forma similar al residual de la tabla 8.3, pero utilizando los totales T_{ij} como base para los cálculos. Así:

$$\begin{aligned} \text{SC de la interacción} &= \text{SC para las diferencias entre las 9 casillas individuo/tratamiento} - \\ &\quad - \text{SC entre individuos} - \text{SC entre tratamientos} \end{aligned}$$

Tabla 8.4. Tiempo de coagulación (en minutos) del plasma de tres individuos con tres métodos de tratamiento y tres repeticiones para cada combinación.

Individuo	Tratamiento			Total	
	2	3	4		
6	9,8	9,9	11,3	R_1 91,8	
	10,1	9,5	10,7		
	9,8	10,0	10,7		
	T_{11} 29,7	29,4	32,7		
	S_{11} 294,09	288,26	356,67		
7	9,2	9,1	10,3	R_2 85,8	
	8,6	9,1	10,7		
	9,2	9,4	10,2		
	T_{21} 27,0	27,6	31,2		
	243,24	253,98	324,62		
8	8,4	8,6	9,8	R_3 78,9	
	7,9	8,0	10,1		
	8,0	8,0	10,1		
	T_{31} 24,3	24,6	30,0		
	196,97	201,96	300,06		
Total	C_1 81,0	C_2 81,6	C_3 93,9	T 256,5	$\sum y^2$ 2459,85

$$TC = T^2/27 = 2.436,75$$

$$SC \text{ entre individuos} = [(91,8)^2 + \dots + (78,9)^2]/9 - TC = 9,2600$$

$$SC \text{ entre tratamientos} = [(81,0)^2 + \dots + (93,9)^2]/9 - TC = 11,7800$$

$$SC \text{ de la interacción} = [(29,7)^2 + \dots + (30,0)^2]/3 - TC - SC \text{ entre individuos} - SC \text{ entre tratamientos} = 0,7400$$

$$SC \text{ total} = (9,8)^2 + \dots + (10,1)^2 - TC = 2459,85 - TC = 23,1000$$

$$SC \text{ residual} = \text{Total} - \text{Individuos} - \text{Tratamientos} - \text{Interacción} = 1,3200$$

Análisis de variancia

	SC	gl	MC	CV
Individuos	9,2600	2	4,6300	63,1
Tratamientos	11,7800	2	5,8900	80,3
Interacción	0,7400	4	0,1850	2,52 ($P = 0,077$)
Residual	1,3200	18	0,0733	1,00
Total	23,1000	26		

y los grados de libertad son, en correspondencia, $8 - 2 - 2 = 4$. La SC total se obtiene según la fórmula habitual, y la SC residual se obtiene restando. La SC residual podría haberse obtenido directamente como la suma, sobre las 9 casillas, de la suma de cuadrados con respecto a la media de cada tres valores, o sea:

$$(S_{11} - T_{11}^2/3) + (S_{12} - T_{12}^2/3) + \dots + (S_{33} - T_{33}^2/3)$$

Los tests de las F muestran que los efectos de los individuos y los tratamientos son muy significativos. El término de interacción no es significativo al nivel del 5%, pero el índice de la variancia es

bastante elevado. Esto se debe principalmente a que el valor medio del individuo 8 con el tratamiento 4 es superior al esperado.

La interpretación de las interacciones significativas y la interpretación de los tests para los «efectos principales» (individuos y tratamientos de los ejemplos 8.1 y 8.2) cuando existen interacciones se comentarán en el apartado siguiente.

En el ejemplo 8.2 el número de repeticiones en cada combinación fila-columna fue constante. Éste no es un requisito indispensable. El número de observaciones en la fila i y la columna j , n_{ij} , puede variar, pero el método de análisis indicado en el ejemplo 8.2 es válido sólo cuando los valores n_{ij} son proporcionales a las frecuencias totales de filas y columnas, las cuales se expresan como n_i y n_j .

$$n_{ij} = \frac{n_i n_j}{N} \quad (8.6)$$

En el ejemplo 8.2, todas las n_i y n_j eran iguales a 9, N era 27, y $n_{ij} = 81/27 = 3$, para todas las i y j . Si (8.6) no es cierta, el intento de seguir el método de análisis estándar podría conducir a SC negativas para la interacción o la residual, lo cual es, por supuesto, una situación imposible. En el apartado 8.7 se describen métodos de análisis apropiados.

En una clasificación de dos factores sin repeticiones y $c = 2$, la situación es la misma que aquella en que se empleó el test de la t para datos apareados en el apartado 4.4. Existe una fiel analogía con la relación entre el análisis de la variancia de un factor y el test de la t para dos muestras señalado en el apartado 7.1. En el caso de dos factores, el test de la F proporcionado por el análisis de la variancia es equivalente al test de la t para datos apareados en que: a) F es numéricamente igual a t^2 ; b) el estadístico F tiene 1 y $r - 1$ gl, mientras que t tiene $r - 1$ gl y, como se indica en el apartado 4.6, las distribuciones de t^2 y F son idénticas. La MC residual en el análisis de la variancia es igual a la mitad del valor s^2 correspondiente al test de la t , ya que ésta es una estimación de la variancia de la diferencia entre dos lecturas.

8.2. Diseño cruzado simple

El diseño cruzado se usa ampliamente en ensayos clínicos en los que cada sujeto puede recibir tratamientos diferentes en períodos sucesivos de administración. Por lo tanto, es el más idóneo en el caso de tratamientos que buscan el alivio rápido de los síntomas en enfermedades crónicas, en las que el estado a largo plazo del paciente permanece bastante estable. En el caso más sencillo, con dos tratamientos, A y B, un grupo de pacientes escogidos al azar (grupo I) recibe tratamientos en el orden AB, mientras que el otro grupo (grupo II) los recibe en el orden BA. Puede haber un número diferente de pacientes en ambos grupos.

El diseño tiene el siguiente esquema:

	Período «de rodaje»	Período 1	Lavado (washout)	Período 2
Lectura	z_{ij}	y_{ij1}		y_{ij2}
Grupo I (n_1)	—	A	—	B
Grupo II (n_2)	—	B	—	A

Aquí, las «lecturas» son observaciones de alguna medida idónea del estado del paciente (p. ej., medición de pruebas respiratorias, frecuencia de ataques de algún tipo, etc.). Los dos períodos de administración están separados por un período de «lavado» (*washout*) para permitir que el estado del paciente vuelva a un nivel no influido, en lo posible, por el tratamiento empleado previamente. (En un estudio de fármacos, por ejemplo, debería ser lo bastante largo para permitir prácticamente la eliminación del fármaco usado en el período 1.) El período de «rodaje» es opcional, pero podría ofrecer una oportunidad al paciente para acomodarse y al investigador para hacer una observación «basal» z_{ij} . Las respuestas y_{ij1} e y_{ij2} a menudo se efectúan hacia el final de los períodos de tratamiento, para permitir un máximo efecto de éste, pero también pueden ser medias o máximos de una serie de observaciones realizadas durante todos los períodos.

La notación de las lecturas es la siguiente: el subíndice i indica el grupo ($i = 1$ para el grupo I, $i = 2$ para el grupo II); j identifica el sujeto en el grupo; el subíndice final indica la primera o segunda respuesta. Las mediciones más importantes son las respuestas activas y_{ij1} e y_{ij2} , pero, como veremos, las lecturas basales z_{ij} pueden ser muy útiles.

Es posible analizar estos datos mediante un análisis de la variancia (Hills y Armitage, 1979), aunque cuando n_1 y n_2 son desiguales, el análisis es «no ortogonal» (apartado 8.8). De hecho, resulta más sencillo emplear los tests de las t ; el ejemplo 8.3 ilustra el método con las respuestas de un ensayo sin datos basales.

Ejemplo 8.3

En un ensayo clínico de un nuevo fármaco para el tratamiento de la enuresis se administró a cada uno de 29 pacientes un fármaco durante un período de 14 días y un placebo durante un período separado de 14 días, siendo el orden de administración escogido de forma aleatoria para cada paciente. La tabla 8.5 muestra el número de noches sin enuresis experimentadas durante cada período de tratamiento.

Se podría obtener un test de la eficacia relativa de la medicación y el placebo a partir de la serie completa de 29 observaciones apareadas. Para ello necesitaríamos las 29 diferencias de (fármaco-placebo). Para el grupo I éstas son las diferencias (período 1 – período 2), d_{1j} , mostradas en la tabla 8.5. Para el grupo II requeriríamos el cambio del signo de las diferencias d_{2j} . Escribiendo $d_{2j}^* = d_{1j}$ y $d_{1j}^* = -d_{2j}$, podemos realizar un test de la t sobre los 29 valores de d_{ij}^* . Esto da:

$$\begin{aligned}\bar{d}^* &= 2,172, \\ s^2 &= 11,005 \\ \text{ET}(\bar{d}^*) &= \sqrt{(11,005/29)} = 0,616 \\ t &= \bar{d}^*/\text{ET}(\bar{d}^*) = 3,53 \text{ con } 28 \text{ gl } (P = 0,001)\end{aligned}$$

Este análisis sugiere firmemente que el fármaco aumenta el número de noches sin enuresis en comparación con el placebo. No obstante, es insatisfactorio ya que no tiene en cuenta el orden en que cada paciente recibe los dos tratamientos. Esto podría ser especialmente importante si existiera un efecto sistemático del período, por ejemplo si los pacientes tendieran a presentar mejor alivio en el período 1 que en el período 2.

Las respuestas medias en los dos períodos para los dos grupos son las siguientes:

Tabla 8.5. Número de noches sin enuresis sobre 14, en pacientes con enuresis nocturna tratados con fármaco y placebo.

Período: Tratamiento N.º del paciente, y_j	Grupo I		Diferencia (1 - 2) d_{1j}	Suma (1 + 2) e_{1j}
	1	2		
	A (fármaco) y_{1j1}	B (placebo) y_{1j2}		
1	8	5	3	13
2	14	10	4	24
3	8	0	8	8
4	9	7	2	16
5	11	6	5	17
6	3	5	-2	8
7	6	0	6	6
8	0	0	0	0
9	13	12	1	25
10	10	2	8	12
11	7	5	2	12
12	13	13	0	26
13	8	10	-2	18
14	7	7	0	14
15	9	0	9	9
16	10	6	4	16
17	2	2	0	4

Período: Tratamiento N.º del paciente, y_j	Grupo II		Diferencia (1 - 2) d_{2j}	Suma (1 + 2) e_{2j}
	1	2		
	B (placebo) y_{2j1}	A (fármaco) y_{2j2}		
1	12	11	1	23
2	6	8	-2	14
3	13	9	4	22
4	8	8	0	16
5	8	9	-1	17
6	4	8	-4	12
7	8	14	-6	22
8	2	4	-2	6
9	8	13	-5	21
10	9	7	2	16
11	7	10	-3	17
12	7	6	1	13

Período	1	2	Diferencia (1 - 2)
Grupo I: tratamiento	A	B	
	$\bar{y}_{11} = 8,118$	$\bar{y}_{12} = 5,294$	$\bar{d}_1 = 2,824$
Grupo II: tratamiento	B	A	
	$\bar{y}_{21} = 7,667$	$\bar{y}_{22} = 8,917$	$\bar{d}_2 = -1,250$

Para examinar la presencia de un efecto por el tratamiento, podemos probar la diferencia entre $\bar{d}_1$ y $\bar{d}_2$, ya que, si no existiera dicho efecto, las esperanzas de $\bar{d}_1$ y $\bar{d}_2$ serían iguales. La comparación implica un test de la t para dos muestras estándar, que da:

$$t = (\bar{d}_1 - \bar{d}_2) / \text{ET}(\bar{d}_1 - \bar{d}_2) \text{ en } n_1 + n_2 - 2 \text{ gl}$$

donde

$$\text{ET}(\bar{d}_1 - \bar{d}_2) = \sqrt{\left[s_d^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \right]}$$

y s_d^2 es la estimación promediada intragrupos de la variancia de la d_{ij} . En este ejemplo, $\bar{d}_1 - \bar{d}_2 = 4,074$, $s_d^2 = 10,767$ y $\text{ET}(\bar{d}_1 - \bar{d}_2) = 1,237$, dando $t = 4,074/1,237 = 3,29$ con 27 gl ($P = 0,003$). El resultado es parecido al dado por el análisis aproximado previo.

Para examinar el efecto del período, confrontamos $\bar{d}_1$ y $\bar{d}_2$, ya que, si no existiera dicho efecto, las esperanzas de $\bar{d}_1$ y $\bar{d}_2$ serían iguales en magnitud pero de signos opuestos. Se usa el mismo error tipo que para $\bar{d}_1 - \bar{d}_2$. En el ejemplo, esto da $t = 1,574/1,237 = 1,27$ con 27 gl ($P = 0,21$), que no proporciona indicio alguno de un efecto del período.

Se estima la magnitud del efecto del tratamiento como $1/2(\bar{d}_1 - \bar{d}_2) = 2,037$ noches sin enuresis de 14, y su error tipo como $\frac{1}{2} \text{ET}(\bar{d}_1 - \bar{d}_2) = 0,618$. El intervalo de confianza del 95% para el efecto del tratamiento es, por lo tanto, $2,037 \pm (2,052)(0,618) = 0,77$ a $3,31$ días. El multiplicador aquí es $t_{27; 0,05} = 2,052$.

En el análisis ilustrado en el ejemplo 8.3 se asume que la respuesta es afectada aditivamente por los efectos del tratamiento y del período. Esta suposición no es necesariamente verdadera. Puede haber una interacción tratamiento $\times$ período (TP) debida a alguna de varias razones:

1. Si el período de lavado (*washout*) es demasiado corto, la respuesta en el período 2 podría ser afectada por el tratamiento recibido en el período 1, además del recibido en el 2.
2. Aunque el período de lavado sea suficientemente largo para eliminar el fármaco del período 1, su efecto psicológico y fisiológico podría persistir en el período 2.
3. Si el efecto del período es fuerte, cambiando el nivel general de respuesta del período 1 al período 2, se podría cambiar el efecto del tratamiento simplemente porque varía según porciones diferentes de la escala de medición.

Se obtiene una prueba de la existencia de una interacción TP de la siguiente manera. Si no hay interacción TP, la suma de las dos respuestas del individuo j en el grupo i , $e_{ij} = y_{ij1} + y_{ij2}$, debería ser (aparte del error aleatorio) la misma tanto si el sujeto pertenece al grupo I como al grupo II, ya que en cualquier caso e_{ij} incluye contribuciones para los tratamientos A y B y para los períodos 1 y 2. Si hay una interacción, e_{ij} tenderá a ser más alta en un grupo que en el otro. Por ejemplo, si A es mucho más eficaz que B, y hay un fuerte efecto postergado de A, el grupo I tenderá a tener los valores más favorables de e_{ij} . Por lo tanto, podemos examinar la diferencia entre los dos valores medios de e_{ij} , $\bar{e}_1$ y $\bar{e}_2$, empleando nuevamente un test de la t para dos muestras. De todas formas, aquí la estimación promediada de la variancia intragrupos, s_e^2 es la de e_{ij} , no (como antes) de la d_{ij} . Dado que la e_{ij} varía en parte debido a la variancia entre los individuos, deberíamos esperar que $s_e^2 > s_d^2$.

Ejemplo 8.3 (continuación)

En la tabla 8.5 se dan los valores de e_{ij} . Las dos medias son $\bar{e}_1 = 13,412$, $\bar{e}_2 = 16,583$. La estimación de la variancia agrupada es $s_e^2 = 41,890$ (considerablemente mayor que s_d^2 , tal como se esperaba) y

$$ET(\bar{e}_1 - \bar{e}_2) = \sqrt{\left[(41,890) \left(\frac{1}{17} + \frac{1}{12} \right) \right]} = 2,440$$

Por lo tanto, $t = (13,412 - 16,583)/2,440 = -1,30$ con 27 gl ($P = 0,20$). No hay indicios claros de una interacción TP y, por lo tanto, el análisis anterior parece razonable.

Si hay una interacción TP, tendrá poco sentido contrastar y estimar el efecto del tratamiento sobre toda la serie de datos, como en el ejemplo 8.3. El período 1 por sí mismo proporciona una prueba perfectamente válida de A contra B, ya que los sujetos se distribuyeron de forma aleatoria entre los dos tratamientos. El valor del período 2 es incierto, puesto que los individuos (aunque originariamente escogidos al azar) han sufrido diferentes experiencias antes de entrar al período 2. El mejor procedimiento, por lo tanto, es hacer un test para dos muestras con los valores de los y_{ij1} del período 1, estimando el efecto del tratamiento a partir de la diferencia entre las dos medias, $\bar{y}_{11} - \bar{y}_{21}$. Desafortunadamente, esta comparación está sometida a una variación entre sujetos y es por lo tanto, menos precisa que el planteamiento cruzado.

Un inconveniente semejante sucede en el test de interacción. Éste se basa en la variación entre individuos, que si es muy grande dará un test de la t relativamente insensible. Puede haber en realidad una interacción considerable, suficientemente grande para afectar de forma notable la estimación del efecto del tratamiento, que sin embargo permanece indetectable.

Por consiguiente, el análisis esbozado anteriormente puede ser algo peligroso a menos que se disponga de un conocimiento previo firme, tal vez obtenido a partir de estudios similares en el pasado, de que es probable que la interacción sea despreciable.

Este inconveniente puede solucionarse en gran medida usando las lecturas basales z_{ij} . (Armitage y Hills, 1982, analizan el uso de segundas lecturas basales efectuadas durante el período de lavado.) Para cada sujeto calculamos la diferencia:

$$e'_{ij} = e_{ij} - 2z_{ij}$$

y contrastamos la diferencia de las medias $\bar{e}'_1 - \bar{e}'_2$ y no $\bar{e}_1 - \bar{e}_2$. Como la sustracción de $2z_{ij}$ sobre e'_{ij} elimina el nivel general de respuestas de cada individuo, las e'_{ij} no están afectadas por la variación entre sujetos y cabe esperar que serán menos variables que las e_{ij} .

Se puede emplear un mecanismo similar para la valoración del efecto del tratamiento mediante el período 1, cuando existe interacción. Se calcula una respuesta corregida, $y'_{ij1} = y_{ij1} - z_{ij}$, y se efectúa un test de la t para dos muestras en las medias $\bar{y}'_{11}$ e $\bar{y}'_{21}$. Otra vez, la variación intragrupos de los valores y'_{ij1} debería ser menor que la de los valores y_{ij1} .

Algunas de las ambigüedades del diseño cruzado simple son eliminadas por diseños cruzados mayores, con más de dos períodos y quizá con más de dos grupos secuenciales (Jones y Kenward, 1989).

8.3. Diseños factoriales

En el apartado 8.1 se describió un ejemplo de un diseño para un experimento factorial en el que la variable analizada era el tiempo de coagulación de la sangre. Se medían los efectos de dos factores: r períodos de almacenamiento y c concentraciones de adrenalina. Se efectuaron observaciones con cada combinación de períodos de almacenamiento y concentraciones

de adrenalina. Hay dos factores aquí, uno en r niveles y el otro en c niveles, y el diseño se designa *factorial* $r \times c$.

Este diseño se opone a lo que a veces se considera como un buen principio de experimentación, a saber, que sólo debe cambiarse un factor a la vez. Las ventajas de la experimentación factorial con respecto al planteamiento de un solo factor fueron señaladas por Fisher. Si hacemos una observación en cada una de las combinaciones rc , podemos efectuar comparaciones de los efectos medios de los diferentes períodos de almacenamiento basándonos en c observaciones en cada período. Para obtener la misma precisión con un diseño no factorial deberíamos escoger una concentración específica de adrenalina y hacer c observaciones por cada período de almacenamiento: rc en total. Esto no nos daría información alguna sobre el efecto de variar la concentración de adrenalina. Un experimento para aclarar este factor con la misma precisión que el diseño factorial necesitaría rc observaciones más, todas con el mismo período de almacenamiento. Por lo tanto, necesitaría el doble de observaciones que un diseño factorial. Además, este último permite una comparación del efecto de un factor con niveles diferentes del otro: permite la detección de una interacción entre los dos factores. Esto no puede efectuarse sin el método factorial.

El diseño de dos factores considerado en el apartado 8.1 puede generalizarse claramente para permitir el estudio simultáneo de tres o más factores. Estrictamente, la designación «diseño factorial» debería reservarse para situaciones en las que todos los factores fueran tratamientos experimentales controlables y en las que todas las combinaciones de niveles se asignaran aleatoriamente a las unidades experimentales. Sin embargo, el análisis es fundamentalmente el mismo en la situación algo diferente en la que uno o más factores representan una forma de bloqueo: una fuente de variancia conocida o sospechada que puede ser útilmente eliminada al comparar los tratamientos reales. Por lo tanto, incluiremos esta extensión del diseño factorial en la presente exposición.

La notación se convierte en un problema si buscamos una generalización completa, por lo cual analizamos en detalle un diseño de tres factores. Las direcciones de la generalización deben estar claras. Supongamos que hay tres factores: A con I niveles, B con J niveles y C con K niveles. Como en el apartado 8.1, consideramos un modelo lineal para el cual la respuesta media al nivel i de A, al nivel j de B y al nivel k de C es:

$$E(y_{ijk}) = \mu + \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk} \quad (8.7)$$

con $\sum_i \alpha_i = \dots = \sum_j (\alpha\beta)_{ij} = \dots = \sum_i (\alpha\beta\gamma)_{ijk} = 0$, etc. Aquí los términos como $(\alpha\beta)_{ij}$ deben interpretarse como constantes únicas, eligiéndose la notación para indicar la interpretación de cada término como una interacción entre dos o más factores. Las constantes α_i miden los efectos de los diferentes niveles del factor A promediados sobre los distintos niveles de los otros factores; a éstos se los denomina *efectos principales* de A. La constante $(\alpha\beta)_{ij}$ indica la magnitud en que la respuesta media en el nivel i de A y en el nivel j de B, promediada sobre todos los niveles de C, no es determinada sólo por α_i y β_j , y, por lo tanto, mide un aspecto de la interacción de A y B. Se denomina *término de interacción de primer orden* o *término de interacción de dos factores*. De forma similar, la constante $(\alpha\beta\gamma)_{ijk}$ indica cómo la respuesta media en la combinación triple de A, B y C no es determinada sólo por efectos principales y por términos de interacción de primer orden. Se denomina *término de interacción de segundo orden* o *término de interacción de tres factores*.

Tabla 8.6. Estructura del análisis de la variancia para un diseño de tres factores con repeticiones.

	SC	gl	MC	CV (= MC/s ²)
Efectos principales				
A	S_A	$I - 1$	s_A^2	F_A
B	S_B	$J - 1$	s_B^2	F_B
C	S_C	$K - 1$	s_C^2	F_C
Interacciones de 2 factores				
AB	S_{AB}	$(I - 1)(J - 1)$	s_{AB}^2	F_{AB}
AC	S_{AC}	$(I - 1)(K - 1)$	s_{AC}^2	F_{AC}
BC	S_{BC}	$(J - 1)(K - 1)$	s_{BC}^2	F_{BC}
Interacciones de 3 factores				
ABC	S_{ABC}	$(I - 1)(J - 1)(K - 1)$	s_{ABC}^2	F_{ABC}
Residual	S_R	$IKJ(n - 1)$	s^2	1
Total	S	$N - 1$		

Para completar el modelo, supongamos que y_{ijk} se distingue normalmente alrededor de $E(y_{ijk})$ con una variancia residual constante σ^2 .

Supongamos ahora que hacemos n observaciones en cada combinación de A, B y C. El número total de observaciones es $nIJK = N$. La estructura del análisis de la variancia se muestra en la tabla 8.6. Los grados de libertad de los efectos principales y de las interacciones de dos factores se deducen directamente de los resultados de los análisis de dos factores. Los grados de libertad de la interacción de tres factores son una extensión natural. Los grados de libertad residuales son $IKJ(n - 1)$ porque hay $n - 1$ gl entre las repeticiones de cada una de las IKJ combinaciones de factores. Los términos de SC se calculan de la siguiente manera.

1. *Efectos principales.* Igual que para un análisis de un factor, recordando que el divisor del cuadrado del total de un grupo es el número total de observaciones de este grupo. Por lo tanto, si el total para el nivel i de A es $T_{i\cdot}$, y el gran total es T , la SC para A es:

$$\sum_i T_{i\cdot}^2 / nJK - T^2 / N \quad (8.8)$$

2. *Interacciones de dos factores.* Se forma una tabla de totales de dos dimensiones, se calcula las SC apropiada a partir de estos totales y se sustraen las SC de los dos efectos principales relacionados. Para AB, por ejemplo, supongamos que T_{ij} es el total de los niveles i de A y de los niveles j de B. Entonces:

$$S_{AB} = \left(\sum_{i,j} T_{ij}^2 / nK - T^2 / N \right) - S_A - S_B \quad (8.9)$$

3. *Interacciones de tres factores.* Se forma una tabla de totales de tres dimensiones, se calcula la SC de dichos totales y se restan las SC de todas las interacciones entre dos factores y las de efectos principales relacionados. Si T_{ijk} es el total de la combinación de los tres factores A, B y C en los niveles i, j y k , respectivamente.

$$S_{ABC} = \left(\sum_{i,j,k} T_{ijk}^2 / n - T^2 / N \right) - S_{AB} - S_{AC} - S_{BC} - S_A - S_B - S_C \quad (8.10)$$

4. *Total*. Como de costumbre mediante:

$$\sum_{i,j,k,r} y_{ijk}^2 - T^2/N$$

donde el sufijo r (desde 1 a n) denota una de las n observaciones repetidas de cada combinación de factores.

5. *Residual*. Mediante resta. También podría obtenerse sumando, sobre todas las combinaciones de tres factores, la SC entre repeticiones:

$$\sum_{i,j,k} \left(\sum_{r=1}^n y_{ijk}^2 - T_{ijk}^2/n \right) \quad (8.11)$$

Esta formulación alternativa desafortunadamente no proporciona una comprobación independiente para el cálculo aritmético ya que se deduce inmediatamente a partir de las otras expresiones.

Los términos de las MC se obtienen como siempre a partir de SC/gl. Cada uno de éstos dividido por la MC residual, s^2 , proporciona un test de la F de la hipótesis nula apropiada con respecto a los efectos principales o interacciones. Por ejemplo, F_A (probado con $I - 1$ e $IJK(n - 1)$ grados de libertad) proporciona un test de la hipótesis nula que todas las α_i son iguales a cero; es decir, que las respuestas medias en niveles diferentes de A, promediadas sobre todos los niveles de los otros factores, son todas iguales. Algunos problemas de interpretación de esta serie bastante compleja de tests se consideran al final de este apartado.

Supongamos que $n = 1$, de modo que no hay repetición. Los grados de libertad del residual se convierten en cero, ya que $n - 1 = 0$. Lo mismo ocurre con su SC, ya que todas las contribuciones de los paréntesis en (8.11) son cero, al ser sumas de cuadrados con respecto a la media de una sola observación. Por lo tanto, la línea «residual» no aparece en el análisis. La situación es exactamente la misma que en el análisis de dos factores con una observación por casilla. La práctica habitual consiste en tomar la interacción de mayor orden (en este caso, ABC) como término residual y calcular las proporciones F usando esta MC como denominador. Igual que en el análisis de dos factores, esto será satisfactorio si el término de interacción de mayor orden en el *modelo* (en nuestro caso $(\alpha\beta\gamma)_{ijk}$) es igual a cero o casi cero. Si este término es considerable, la MC residual provisional, s_{ABC}^2 , tenderá a ser más alta que σ^2 y los tests serán insensibles.

Ejemplo 8.4

La tabla 8.7* muestra los pesos relativos de las glándulas suprarrenales derechas (expresadas como una fracción del peso del cuerpo, $\times 10^4$) de ratones obtenidos cruzando padres de cuatro cepas. De cada una de las 16 combinaciones de cepas de los padres se usaron cuatro ratones (dos de cada sexo).

Éste es un diseño de tres factores. Los factores —la cepa de la madre, la cepa del padre y el sexo— no son, desde luego, tratamientos experimentales impuestos por una distribución aleatoria. Sin embargo, representan fuentes potenciales de variación cuyos efectos principales e interacciones pueden es-

* Los datos fueron proporcionados amablemente por los doctores R. L. Collins y R. J. Meckler. En su artículo (Collins y Meckler, 1965) se analizan los resultados de las dos glándulas suprarrenales.

Tabla 8.7. Pesos relativos de las suprarrenales derechas de ratones.

Cepa de la madre	Cepa del padre								Totales		
	1		2		3		4				
	♀	♂	♀	♂	♀	♂	♀	♂	♀	♂	♀+♂
1	0,93	0,69	1,76	0,67	1,46	0,88	1,45	0,95	12,57	6,57	19,14
	1,70	0,83	1,58	0,73	1,89	0,96	1,80	0,86			
2	1,42	0,50	1,85	0,72	2,14	1,00	1,94	0,63	15,25	6,08	21,33
	1,96	0,74	1,69	0,66	2,17	0,96	2,08	0,87			
3	2,22	0,86	1,96	1,04	1,62	0,82	1,51	0,82	15,32	6,69	22,01
	2,33	0,98	2,09	0,96	1,63	0,57	1,96	0,64			
4	1,25	0,56	1,56	1,08	1,88	1,00	1,85	0,43	13,39	6,32	19,71
	1,76	0,75	1,90	0,80	1,81	1,11	1,38	0,59			
Total	13,57	5,91	14,39	6,66	14,60	7,30	13,97	5,79	56,53	25,66	
	19,48		21,05		21,90		19,76				82,19

TC = 105,5499

Análisis de variancia

	gl	SC	MC	CV
Cepa de la madre, M	3	0,3396	0,1132	2,87
Cepa del padre, P	3	0,2401	0,0800	2,03
Sexo del animal, S	1	14,8900	14,8900	376,96 ($P < 0,001$)
MP	9	1,2988	0,1443	3,65 ($P = 0,003$)
MS	3	0,3945	0,1315	3,33 ($P = 0,032$)
PS	3	0,0245	0,0082	0,21
MPS	9	0,2612	0,0290	0,73
Residual	32	1,2647	0,0395	1,00
Total	63	18,7134		

Diferencias ♀-♂

Cepa de la madre	Cepa del padre				Total
	1	2	3	4	
1	1,11	1,94	1,51	1,44	6,00
2	2,14	2,16	2,35	2,52	9,17
3	2,71	2,05	1,86	2,01	8,63
4	1,70	1,58	1,58	2,21	7,07
Total	7,66	7,73	7,30	8,18	30,87

tudiarse. Los grados de libertad se muestran en la tabla. Las SC para los efectos principales se deducen fácilmente a partir de los subtotales. Para la cepa de la madre, por ejemplo, es:

$$[(19,14)^2 + \dots + (19,71)^2]/16 - TC$$

donde el término de corrección, TC, es $(82,19)^2/64 = 105,5499$. La interacción de dos factores, MP, se obtiene así:

$$[(4,15)^2 + \dots + (4,25)^2]/4 - TC - S_M - S_P$$

donde 4,15 es la suma de las cuatro respuestas en la primera casilla ($0,93 + 1,70 + 0,69 + 0,83$), y S_M y S_P son las SC de los dos efectos principales. De manera similar, la interacción de tres factores se obtiene así:

$$[(2,63)^2 + (1,52)^2 + \dots + (3,23)^2 + (1,02)^2]/2 - TC - S_M - S_P - S_S - S_{MP} - S_{MS} - S_{PS}$$

Aquí las cantidades 2,63, etc., son subtotales de pares de respuestas ($2,63 = 0,93 + 1,70$). La SC residual se puede obtener por resta una vez que se ha obtenido la SC total. Alternativamente, como comprobación, se puede obtener a partir de las *diferencias* entre observaciones repetidas:

$$[(0,93 - 1,70)^2 + \dots + (0,43 - 0,59)^2]/2 = 1,2648$$

la diferencia con respecto al valor obtenido por resta se debe al error de redondeo.

Cuando, como en este ejemplo, uno de los factores tiene sólo dos niveles, se puede simplificar el cálculo del efecto principal y de las interacciones en que interviene este factor, considerando los contrastes entre los dos niveles del factor. Las diferencias entre los totales de las dos hembras y de los dos machos, en cada cruce de los padres, son las que se muestran al pie de la tabla 8.7. La SC del efecto principal, S, según (7.10), está dada por $(30,87)^2/64 = 14,8900$, igual que antes. La SC de MS es:

$$[(6,00)^2 + \dots + (7,07)^2]/16 - 14,8900 = 0,3944$$

la de PS es:

$$[(7,66)^2 + \dots + (8,18)^2]/16 - 14,8900 = 0,0244$$

y la SC de MPS es:

$$[(1,11)^2 + \dots + (2,21)^2]/4 - 14,8900 - S_{MS} - S_{PS} = 0,2614$$

Estas SC concuerdan con las de la tabla 8.7, aparte de los errores de redondeo.

Los tests de las F demuestran que los efectos principales M y P no son significativos, aunque cada razón de la variancia es mayor que 1. La interacción MP es muy significativa. El efecto principal del sexo es muy significativo y también su interacción con M. Para aclarar los efectos de la cepa es provechoso tabular las sumas de observaciones de los 16 cruces:

Cepa de la madre	Cepa del padre				Total
	1	2	3	4	
1	4,15	4,74	5,19	5,06	19,14
2	4,62	4,92	6,27	5,52	21,33
3	6,39	6,05	4,64	4,93	22,01
4	4,32	5,34	5,80	4,25	19,71
Total	19,48	21,05	21,90	19,76	82,19

Las cepas 2 y 3 dan lecturas relativamente altas tanto para M como para P, lo cual sugiere un efecto sistemático que no ha conseguido significación para ninguno de los padres por separado. La interacción se debe en parte a la lectura alta de (M3, P1).

Cada uno de los 16 totales de las casillas es la suma de cuatro lecturas, y la diferencia entre dos cualesquiera tiene un error tipo de $\sqrt{[(2)(4)(0,0395)]} = 0,56$. Para M3 la diferencia entre P1 y P3 es significativamente positiva, mientras que por cada una de las otras cepas maternas la diferencia P1 - P3 es negativa, de manera significativa en M2 y M4. Una inversión similar la proporcionan las cuatro entradas de M2 y M3, P2 y P3.

La interacción MS puede estudiarse a partir de la tabla anterior de contrastes del sexo. Cada uno de los totales de las filas tiene un error tipo $\sqrt{16(0,0395)} = 0,80$. Las cepas maternas 2 y 3 muestran diferencias de sexo significativamente mayores que M1, y M2 también es significativamente mayor que M4. Este aspecto puede observarse a partir del margen derecho de la tabla 8.7, donde las respuestas altas para M2 y M3 se muestran con fuerza en la descendencia femenina, pero no en la masculina.

Este tipo de experimento, en que se cruzan padres de ambos sexos de varias cepas, se denomina *cruce dialélico*. Existen métodos especiales de análisis que toman en cuenta el efecto general de cada cepa, presentado tanto por los machos como por las hembras, y los efectos específicos de determinados cruces (Bulmer, 1980).

Diseño factorial 2^p

Un término de interacción en el análisis de un diseño factorial tendrá en general varios grados de libertad y representará desviaciones de varios tipos con respecto a un modelo aditivo. Por lo tanto, es posible que la interpretación de una interacción significativa requiera una meditación concienzuda. No obstante, si todos los factores tienen dos niveles, cada uno de los efectos principales y cada una de las interacciones tendrán sólo 1 gl; como consecuencia representan contrastes lineales que pueden interpretarse con relativa facilidad. Si por ejemplo hay cuatro factores, cada uno de ellos en dos niveles, el diseño se denomina $2 \times 2 \times 2 \times 2$, o diseño 2^4 , y en general, para p factores cada uno de ellos en dos niveles, el diseño se designa 2^p . El análisis de los diseños 2^p se puede simplificar por el cálculo directo de cada contraste lineal. Ilustraremos el procedimiento de un diseño 2^3 .

Supongamos que hay n observaciones de cada una de las 8 ($=2^3$) combinaciones de factores. Dado que cada factor tiene dos niveles, podemos, por convenciones idóneas, considerar que cada factor es positivo o negativo (p. ej., por la presencia o la ausencia de algunas características). Denominando los factores A, B y C, podemos identificar cada combinación de factores escribiendo en letras minúsculas los factores que son positivos. Así (ab) indica la combinación con A y B positivos y C negativa, mientras que (c) indica la combinación con sólo C positiva; la combinación con todos los factores negativos se escribirá (1). En fórmulas se puede suponer que estos símbolos significan los totales de las n observaciones en las diferentes combinaciones de factores.

Se puede estimar el efecto principal de A por la diferencia entre la respuesta media en todas las combinaciones con A positiva y la de todas las combinaciones con A negativa. Esto es un contraste lineal:

$$\frac{(a) + (ab) + (ac) + (abc)}{4n} - \left[\frac{(1) + (b) + (c) + (bc)}{4n} \right] = [A]/4n \quad (8.12)$$

donde

$$[A] = -(1) + (a) - (b) + (ab) - (c) + (ac) - (bc) + (abc) \quad (8.13)$$

reordenando los términos para introducir los factores en orden.

Los efectos principales de B y C se definen de manera similar.

La interacción de dos factores entre A y B representa la diferencia entre el efecto estimado de A cuando B es positivo, y la misma diferencia cuando B es negativo. Esto es:

$$\frac{(ab) + (abc) - (b) - (bc)}{2n} - \left[\frac{(a) + (ac) - (1) - (c)}{2n} \right] = [AB]/2n \quad (8.14)$$

donde

$$[AB] = (1) - (a) - (b) + (ab) + (c) - (ac) - (bc) + (abc) \quad (8.15)$$

Para evitar la incomodidad del divisor $2n$ en (8.14) mientras que en (8.12) aparece $4n$, es útil volver a definir la interacción como $[AB]/4n$, esto es como la mitad de la diferencia mencionada antes. Obsérvese que los términos en (8.15) tienen un signo positivo cuando A y B son ambos positivos o negativos, y un signo negativo si no es así. Obsérvese también que $[AB]/4n$ puede escribirse:

$$\frac{(ab) + (abc) - (a) - (ac)}{4n} - \left[\frac{(b) + (bc) - (1) - (c)}{4n} \right]$$

que es la mitad de la diferencia entre el efecto estimado de B cuando A es positivo y el estimado cuando A es negativo. Esto revela la naturaleza simétrica de $[AB]$.

La interacción de tres factores $[ABC]$ puede interpretarse asimismo de varias maneras equivalentes. Representa, por ejemplo, la diferencia entre la interacción estimada $[AB]$ cuando C es positiva y cuando C es negativa. Aparte del divisor, esta diferencia se mide por

$$\begin{aligned} [ABC] &= [(c) - (ac) - (bc) + (abc)] - [(1) - (a) - (b) + (ab)] \\ &= -(1) + (a) + (b) - (ab) + (c) - (ac) - (bc) + (abc) \end{aligned} \quad (8.16)$$

y nuevamente es conveniente definir la interacción como $[ABC]/4n$.

Los resultados se resumen en la tabla 8.8. Obsérvese que los signos positivos y negativos de la interacción de dos factores se obtienen fácilmente multiplicando los coeficientes de los correspondientes efectos principales y los de la interacción de tres factores, multiplicando los coeficientes de $[A]$ y $[BC]$, $[B]$ y $[AC]$, o $[C]$ y $[AB]$.

La columna final de la tabla 8.8 muestra la fórmula de la SC y (dado que cada uno tiene 1 gl) de la MC de cada término del análisis. Cada término como $[A]$, $[AB]$, etc., tiene una variancia $8n\sigma^2$ en la hipótesis nula correspondiente [ya que cada uno de los totales (1), (a), etc., tiene una variancia $n\sigma^2$]. Por consiguiente, $[A]^2/8n$ es una estimación de σ^2 . En general, para un factorial 2^p , los divisores de los contrastes lineales son $2^{p-1}n$, y los de las SC son 2^p , los divisores de los contrastes lineales son $2^{p-1}n$, y los de las SC son $2^p n$.

La significación de los efectos principales y de las interacciones puede probarse de manera equivalente mediante test de la t . La MC residual, s^2 , tiene $8(n-1)$ gl y la variancia de

Tabla 8.8. Cálculo de los efectos principales e interacciones de un diseño factorial 2^3 .

Efectos		Multiplicador del total								Divisor para el contraste	Contribución a la SC
		(1)	(a)	(b)	(ab)	(c)	(ac)	(bc)	(abc)		
Efectos principales	A	-1	1	-1	1	-1	1	-1	1	4n	$[A]^2/8n$
	B	-1	-1	1	1	-1	-1	1	1	4n	$[B]^2/8n$
	C	-1	-1	-1	-1	1	1	1	1	4n	$[C]^2/8n$
Interacciones de 2 factores	AB	1	-1	-1	1	1	-1	-1	1	4n	$[AB]^2/8n$
	AC	1	-1	1	-1	-1	1	-1	1	4n	$[AC]^2/8n$
	BC	1	1	-1	-1	-1	-1	1	1	4n	$[BC]^2/8n$
Interacciones de 3 factores	ABC	-1	1	1	-1	1	-1	-1	1	4n	$[ABC]^2/8n$

cada uno de los contrastes $[A]$, $[AB]$, etc., se estima como $8ns^2$, para dar un test de la t con $8(n-1)$ gl.

Interpretación de experimentos factoriales con interacciones significativas

El análisis de un experimento factorial a gran escala proporciona una oportunidad para contrastar simultáneamente varios efectos principales e interaccionales. La complejidad de esta situación a veces da origen a interpretaciones ambiguas. Los siguientes puntos pueden ser útiles.

1. El hecho de que dos o más factores interactúen, o no, dependerá de la escala de medidas de la variable analizada. A veces se puede obtener una interpretación más sencilla de los datos realizándolos después de hacer una transformación logarítmica o de otro tipo (v. capítulo 11). Por ejemplo, si ignoramos el error debido al azar, las respuestas mostradas a continuación en (a), presentan una interacción entre A y B. Las mostradas en (b) no presentan interacción. Las respuestas en (b) son las raíces cuadradas de las de (a).

A	B		B	
	Bajo	Alto	Bajo	Alto
Bajo	9	16	3	4
Alto	16	25	4	5
	(a)		(b)	

Vale la pena buscar una escala de medidas donde las interacciones sean pequeñas o insignificantes especialmente si los efectos principales de un factor, medio a niveles diferentes del otro u otros, se relacionan fielmente a las respuestas medias de estos niveles. Si los efectos principales estimados de cualquier factor están en *direcciones opuestas* para diferentes niveles del otro u otros, es probable que las transformaciones no sean útiles.

Este tipo de efecto recibe el nombre de interacción *cualitativa* y es probable que sea más importante que una interacción *cuantitativa*, en la que el efecto de una variable es cambiada en magnitud pero no en dirección por los niveles de otras variables.

2. En un experimento multifactorial muchas interacciones se ponen a prueba independientemente; no será muy sorprendente que una de éstas sea ligeramente significativa por pura casualidad. Por lo tanto, las interacciones que no se consideran intrínsecamente verosímiles deberían analizarse con precaución, excepto que sean muy significativas (es decir, significativas a un nivel de probabilidad pequeño, como el 1%). Otro material útil es el «gráfico seminormal» (apartado 11.5).
3. Si varias interacciones de orden alto son no significativas, sus SC a menudo se acumulan a la SC residual para proporcionar un número mayor de gl y, por lo tanto, tests más sensibles de los efectos principales o interacciones de orden bajo.

Quedan otros puntos de interpretación que es más útil estudiar por separado, según se considere que los factores relacionados tengan efectos fijos o efectos aleatorios (apartado 7.3).

Efectos fijos

Si existen ciertas interacciones, muchas veces se pueden evidenciar mejor citando los valores medios de la variable en cada una de las combinaciones de factores implicados. Por ejemplo, en un experimento con A, B y C a 2, 3 y 4 niveles, respectivamente, si la única interacción significativa fuera BC, se citarían los valores medios en cada una de las 12 combinaciones de los niveles de B y C. Éstos podrían ir acompañados de una mención del error tipo de la diferencia entre dos de estas medias. De esta forma el lector sería capaz de ver rápidamente las características esenciales de la interacción. Considérese la siguiente tabla de medias:

Nivel de B	Nivel de C			
	1	2	3	4
1	2,17	2,25	2,19	2,24
2	1,96	2,01	1,89	1,86
3	2,62	2,67	2,83	2,87

(Error tipo de la diferencia entre dos medias = 0,05)

Evidentemente, el efecto de C no es detectable en el nivel 1 de B; en el nivel 2 de B los dos niveles más altos de C muestran una disminución de la media; en el nivel 3 de B los dos niveles más altos de C muestran un aumento.

En situaciones como ésta, los efectos principales de B y C no revisten gran interés. Si el efecto de C varía con el nivel de B, el efecto principal mide el efecto medio de C sobre los niveles de B; como depende de la elección de los niveles de B, normalmente será una cantidad bastante artificial y, por lo tanto, de consideración poco valiosa. De forma similar, si una interacción de tres factores es significativa y se cree que existe, las interacciones entre dos factores cualesquiera de los implicados son conceptos bastantes artificiales.

Efectos aleatorios

Si, en el ejemplo previo, A y C fueran factores de efecto fijo y B un factor de efecto aleatorio, la presencia de una interacción entre B y C no excluiría un interés por el efecto princi-

pal de C (considerado no como un término medio sobre los niveles específicos de B escogidos en el experimento, sino como un término medio sobre toda la población de los niveles potenciales de B). En ciertas circunstancias (comentadas más adelante) se prueba la hipótesis nula para el efecto principal de C comparando la MC de C con la MC de la interacción BC. Si C tiene más de dos niveles, se puede obtener más información centrándose en un contraste específico entre los niveles de C (p. ej., una comparación del nivel 1 con el nivel 4) y obtener la interacción de este contraste con el factor B.

Si en un diseño multifactorial uno de los factores es un sistema de bloques, generalmente será natural que se considere éste como un factor de efecto aleatorio. Supóngase que los otros factores son tratamientos controlados (p. ej. A, B y C). Se puede comparar cada uno de los efectos principales e interacciones de A, B y C con la correspondiente interacción con los bloques. Con frecuencia, las diversas interacciones en que intervienen los bloques se diferencian sólo en lo que cabría esperar por la variación aleatoria, y las SC se pueden reunir para obtener más grados de libertad.

Las situaciones mencionadas en los párrafos anteriores son ejemplos en los que resulta adecuado un *modelo mixto* (algunos de los factores con efectos fijos y otros con efectos aleatorios). Si sólo hay un factor aleatorio (como ocurre con los bloques en el ejemplo del párrafo anterior), se puede probar cualquier efecto principal o interacción de los otros factores en comparación con la correspondiente interacción con el factor aleatorio. Por ejemplo, si D es el factor aleatorio, se podría probar A en comparación con AD, AB comparada con ABD. La justificación de este proceder se deduce al interpretar los términos de interacción que implican a D en el modelo similar a (8.7) como observaciones independientes de variables aleatorias con una media igual a cero. El concepto de interacción aleatoria es razonable; por ejemplo, si D es un sistema de bloques, se puede considerar que cualquier contraste lineal que represente parte de un efecto principal o interacción de los otros factores varía aleatoriamente de un bloque a otro. Lo que es más discutible, no obstante, es la suposición de que todos los componentes de (8.7) para una interacción específica, por ejemplo, AD, tienen la misma distribución y son independientes entre sí. De ahí la sugerencia, hecha anteriormente, de que sería preferible centrar la atención en contrastes lineales específicos. Se podría medir cualquiera de estos contrastes, L , por separado en cada bloque y poner a prueba su valor medio mediante un test de la t .

Cuando hay más de dos factores aleatorios surgen más problemas porque es posible que no existan tests válidos para algunos de los efectos principales e interacciones. Para más detalles, véase Snedecor y Cochran (1989, apartado 16.14).

8.4. Cuadrados latinos

Supóngase que deseamos comparar los efectos de a tratamientos en un experimento en el que hay otras dos fuentes conocidas de variación, cada una con a niveles. Un diseño factorial completo, que contenga sólo una observación en cada combinación de factores, requeriría a^3 observaciones.

Considérese el siguiente diseño, en el que $a = 4$. Los tratamientos principales están indicados por A, B, C y D, y los dos factores secundarios, por las filas y columnas de la tabla.

	Columnas			
Filas	1	2	3	4
1	D	B	C	A
2	C	D	A	B
3	A	C	B	D
4	B	A	D	C

Sólo se han efectuado a^2 ($=16$) observaciones, ya que en cada combinación de una fila y una columna únicamente se ha usado uno de los cuatro tratamientos. Sin embargo, el diseño está ingeniosamente equilibrado, en el sentido de que cada tratamiento ocurre precisamente una vez en cada fila y precisamente una vez en cada columna. Si el efecto de efectuar una observación en la fila 1 y no en la fila 2 consiste en añadir una cantidad constante a la medición observada, la diferencias entre las medias de los cuatro tratamientos no se afectan por el tamaño de esta constante. En este sentido, una variación sistemática entre filas o, de manera similar entre columnas, no afecta las comparaciones de los tratamientos y puede decirse que ha sido eliminada por la elección del diseño.

Estos diseños, denominados *cuadrados latinos*, se utilizaron en un principio en experimentos de agricultura en los que las filas y las columnas representaban tiras en dos direcciones perpendiculares a través de un campo. Surgen ejemplos análogos en investigaciones médicas cuando se deben aplicar tratamientos a una serie bidimensional de unidades experimentales. Por ejemplo, se pueden inocular varias sustancias por vía subcutánea sobre una red bidimensional de puntos en la piel de un ser humano o un animal. En un ensayo de difusión en placa, es posible introducir varias diluciones de un preparado antibiótico en los agujeros de una placa de agar sembrada con bacterias e incubada, estando la zona de inhibición formada por la difusión del antibiótico alrededor de cada hueco y en relación con la dilución utilizada.

En otros experimentos, las filas y las columnas pueden representar dos fuentes identificables de variación que, sin embargo, no son, geográficamente significativas. El cuadrado latino se usa aquí como una generalización sencilla de un diseño de bloques aleatorios, y las filas y columnas representan dos sistemas diferentes de bloques. A continuación citaremos algunos ejemplos.

1. Un experimento en animales en el que las filas representan camadas y las columnas representan días diferentes en los que se realiza el experimento. Cada animal recibe un tratamiento diferente.
2. Un estudio cruzado ampliado en el que las filas representan diferentes sujetos y las columnas representan el orden de administración de los tratamientos. Aquí, cada sujeto recibe los diferentes tratamientos en ocasiones distintas. Como en el ejemplo citado en el apartado 8.2, el investigador debe probar que la respuesta observada en cualquier ocasión esté influida sólo por el tratamiento en curso dado y no por cualquier tratamiento precedente. Es fácil pensar en situaciones en las que hay efecto de arrastre, tanto del efecto farmacológico de un fármaco administrado previamente como (en ciertos experimentos) del efecto psicológico de los tratamientos anteriores. Algunos cuadrados latinos están balanceados para ciertos efectos residuales y pueden usarse para su estimación. Se deben principalmente a E. J. Williams y son descritos por Cochran y Cox (1957, apartado 4.6a).

Los cuadros latinos se emplean a veces en situaciones en las que las filas, las columnas o ambas representan formas de tratamiento bajo control del experimentador. Entonces llevan a cabo algunas de las funciones de los diseños factoriales, con la importante condición de que faltan algunas de las combinaciones de factores. Esto tiene importantes consecuencias que señalaremos más adelante.

En un diseño de bloques aleatorio los tratamientos se distribuyen aleatoriamente dentro de cada bloque. ¿Cómo puede aplicarse la aleatoriedad en un cuadrado latino, el cual evidentemente es una disposición muy sistemática? Para cualquier valor de a se pueden escribir muchos cuadrados posibles. Se introducen las garantías de la aleatoriedad haciendo una elección aleatoria a partir de estos posibles cuadrados. En Fisher y Yates (1963) y en casi todos los libros sobre diseño experimental se dan detalles completos del procedimiento. El lector no iría muy equivocado si construye un cuadrado latino de la medida correcta cambiando tratamientos cíclicamente en un lugar en filas sucesivas

A	B	C	D
D	A	B	C
C	D	A	B
B	C	D	A

y después permuta las filas y las columnas aleatoriamente.

Como un modelo aditivo para el análisis del cuadrado latino, supongamos que la respuesta, y_{ijk} , para la fila i , la columna j y el tratamiento k está dada por

$$y_{ijk} = \mu + \alpha_i + \beta_j + \gamma_k + \epsilon_{ijk} \quad (8.17)$$

donde μ representa la media general α_i, β_j y γ_k son constantes características de la fila, la columna y el tratamiento específicos correspondientes, y ϵ_{ijk} es una observación aleatoria de una distribución normal con media cero y variancia σ^2 . El modelo es, de hecho, el de un experimento de tres factores sin interacciones.

La notación de las observaciones se muestra en la tabla 8.9. El análisis, desarrollado al pie de la tabla 8.9, sigue líneas conocidas. Las SC de las filas, las columnas y los tratamientos se obtienen por la fórmula habitual a base de los subtotales; la SC total también se obtiene como de costumbre, y el término residual se obtiene por resta:

$$SC \text{ residual} = SC \text{ total} - (SC \text{ de filas} + SC \text{ de columnas} + SC \text{ de tratamientos}).$$

Los grados de libertad de los tres factores son, evidentemente, $a - 1$; los grados de libertad residuales se obtienen por resta: $a^2 - 3a + 2 = (a - 1)(a - 2)$.

La base de la división de la SC total es la siguiente ecuación:

$$y_{ijk} - \bar{y} = (\bar{y}_{i.} - \bar{y}) + (\bar{y}_{.j} - \bar{y}) + (\bar{y}_{..k} - \bar{y}) + (y_{ijk} - \bar{y}_{i.} - \bar{y}_{.j} - \bar{y}_{..k} + 2\bar{y}) \quad (8.18)$$

Cuando cada término se eleva al cuadrado y se efectúa un sumatorio a lo largo de todas las a^2 observaciones, se obtienen las cuatro SC. Los términos de productos, como $\sum (\bar{y}_{i.} - \bar{y})(\bar{y}_{.j} - \bar{y})$, son todos iguales a cero como en el análisis de dos vías del apartado 8.1.

Tabla 8.9. Notación de un experimento de cuadros latinos.

Fila	Columna					Total	Media	Tratamiento	Total	Media
	1	2	...	j	...	a				
1						R_1	$\bar{y}_{1..}$	1	T_1	$\bar{y}_{..1}$
2						R_2	$\bar{y}_{2..}$	2	T_2	$\bar{y}_{..2}$
.						.	.	.	.	.
.						.	.	.	.	.
.						.	.	.	.	.
i				y_{ia}		R_i	$\bar{y}_{i..}$	k	T_k	$\bar{y}_{..k}$
.						.	.	.	.	.
.						.	.	.	.	.
.						.	.	.	.	.
a						R_a	$\bar{y}_{a..}$	a	T_a	$\bar{y}_{..a}$
Total	$\bar{C}_1$	$\bar{C}_2$	...	$\bar{C}_j$	...	$\bar{C}_a$			$\bar{T}$	
Media	$\bar{y}_{.1.}$	$\bar{y}_{.2.}$		$\bar{y}_{.j.}$		$\bar{y}_{.a.}$	$\bar{y}$			

Análisis de variancia

	SC	gl	MC	CV
Filas	$\sum R_i^2/a - T^2/a^2$	$a - 1$	s_R^2	$F_R = S_R^2/s^2$
Columnas	$\sum C_j^2/a - T^2/a^2$	$a - 1$	s_C^2	$F_C = S_C^2/s^2$
Tratamientos	$\sum T_k^2/a - T^2/a^2$	$a - 1$	s_T^2	$F_T = S_T^2/s^2$
Residual	Por resta	$(a - 1)(a - 2)$	s^2	
Total	$y^2_{..} - T^2/a^2$	$a^2 - 1$		

Si el modelo aditivo (8.17) es correcto se pueden probar las tres hipótesis nulas sobre la igualdad de las α , β y γ mediante los tests de las F correspondientes. Los límites de confianza de las diferencias entre pares de constantes (p. ej., entre dos filas) o de otros contrastes lineales pueden formarse directamente, y estimarse los errores tipo en términos de s^2 . No obstante, el modelo aditivo puede ser incorrecto. Si las filas y columnas son de bloques, el efecto de no aditividad aumentará la estimación de la variancia residual. Los tests de las diferencias entre filas o entre columnas no tienen gran interés en este caso, y la aleatoriedad asegura la validez de los test y de las estimaciones de las diferencias de tratamiento; automáticamente se toma en cuenta la imprecisión adicional mediante el valor aumentado de s^2 . Si, por otro lado, las filas y columnas son tratamientos, la no aditividad significa que existen algunas interacciones. El problema consiste ahora en que las interacciones no pueden medirse independientemente de los efectos principales, y pueden surgir errores graves. Por lo tanto, en los dos grupos de circunstancias, la aditividad de las respuestas es una característica deseable, aunque su ausencia es más lamentable en el segundo caso que en el primero.

Ejemplo 8.5

El experimento de Bacharach et al (1940) considerado en el ejemplo 7.2 se diseñó como un cuadrado latino. El diseño y las mediciones se muestran en la tabla 8.10. Los objetivos del experimento eran estudiar los posibles efectos del orden de administración en una serie de inoculaciones en el mismo animal (el factor «tratamiento», representado en la citada tabla por números romanos), elegir entre seis posiciones en la piel del animal (el factor fila) y también valorar la variación entre animales (el factor columna) en comparación con la variación entre los animales.

Tabla 8.10. Mediciones de la superficie de ampollas (cm²) después de la inoculación de factor difusor en la piel de conejos en localizaciones a-f en el lomo de los animales, escribiendo el orden de administración como i-vi (Bacharach et al, 1940).

		Animales							
Posición		1	2	3	4	5	6	Total	Media
a		III	V	IV	I	VI	II		
		7,9	8,7	7,4	7,4	7,1	8,2	46,7	7,783
b		IV	II	VI	V	III	I		
		6,1	8,2	7,7	7,1	8,1	5,9	43,1	7,183
c		I	III	V	VI	II	IV		
		7,5	8,1	6,0	6,4	6,2	7,5	41,7	6,950
d		VI	I	III	II	IV	V		
		6,9	8,5	6,8	7,7	8,5	8,5	46,9	7,817
e		II	IV	I	III	V	VI		
		6,7	9,9	7,3	6,4	6,4	7,3	44,0	7,333
f		V	VI	II	IV	I	III		
		7,3	8,3	7,3	5,8	6,4	7,7	42,8	7,133
Total		42,4	51,7	42,5	40,8	42,7	45,1	265,2	
Media		7,067	8,617	7,083	6,800	7,117	7,517		7,367
Orden		I	II	III	IV	V	VI		
Total		43,0	44,3	45,0	45,2	44,0	43,7		
Media		7,167	7,383	7,500	7,533	7,333	7,283		
								$\sum y_{ij}^2 = 1.984,0000$	
								$T^2/36 = 1.953,6401$	
<i>Análisis de la variancia</i>									
		SC	gl	MC	CV				
Filas (localización)		3,8332	5	0,7667	1,17				
Columnas (animales)		12,8333	5	2,5667	3,91	(P = 0,012)			
Tratamientos (orden)		0,5632	5	0,1106	<1				
Residual		13,1302	20	0,6565	1,00				
Total		30,3599	35						

La SC total se obtiene como de costumbre:

$$1.984,0000 - 1.953,6401 = 30,3599$$

La SC de las diferencias entre los animales se calcula como:

$$[(42,4)^2 + (51,7)^2 + \dots + (45,1)^2]/6 - 1.953,6401 = 12,8333$$

los otros dos efectos principales se deducen de forma similar, y la SC residual se obtiene por resta. El cociente de la variancia para el orden es menor que 1 y no requiere ser comparado con la tabla de *F*. El de las posiciones es, con seguridad, no significativo. El único efecto significativo es el de las diferencias entre animales, y en el ejemplo 7.2 se llevó a cabo un examen detallado del componente entre animales de la variancia.

Repetición de los cuadrados latinos

Una restricción importante de los cuadrados latinos es, por supuesto, la necesidad de que los números de las filas, columnas y tratamientos sean iguales. La naturaleza del material experimental y el objetivo del experimento exigen a menudo que la medida del cuadrado sea pequeña. Por otro lado, las comparaciones de los tratamientos estimadas a partir de un solo cuadrado latino pueden ser bastante imprecisas. Por lo tanto, a menudo es deseable alguna forma de repetición.

La repetición en un experimento como el del ejemplo 8.5 puede tomar varias formas, por ejemplo: *a)* si los seis animales de la tabla 8.10 fuesen de la misma camada, el experimento podría repetirse con varias camadas, empleándose una nueva asignación aleatoria con cada una de ellas; *b)* si no hubiese clasificación por camadas, podría emplearse un diseño único como el de la tabla 8.10 con varios animales en cada columna; *c)* si el experimento se repitiera con los *mismos seis animales*, en varias ocasiones, debería emplearse de nuevo otra asignación aleatoria en cada ocasión. En este tipo de diseños repetidos hay que tener cuidado de especificar los efectos que se va a contrastar y la asignación correcta de los grados de libertad.

8.5. Otros diseños incompletos

El cuadrado latino puede considerarse un diseño que tiene en cuenta simultáneamente dos fuentes extrañas de variancia —las filas y las columnas— o bien un diseño factorial incompleto que permite la estimación de tres efectos principales —filas, columnas y tratamientos— a partir de observaciones de sólo una fracción de las posibles combinaciones de niveles de factores.

Se conocen muchos otros tipos de diseños incompletos. En este apartado se estudian brevemente algunos de estos diseños, omitiendo detalles de construcción y análisis. Cox (1958, capítulos 11 y 12) ofrece una explicación mucho más amplia de las características e intenciones de varios diseños; para los detalles del análisis estadístico se debe consultar a Cochran y Cox (1957). La mayoría de los diseños escritos en este apartado tienen un uso limitado en investigaciones industriales y agrícolas. Quizás esto se debe en parte a una apreciación inadecuada de los diseños menos conocidos por los investigadores médicos, pero también es probable que los problemas organizativos de experimentación sean más graves en la investigación médica que en muchos otros campos, característica que tendería a favorecer el uso de los diseños simples.

Cuadrados grecolatinos

El cuadrado latino generaliza el diseño de bloques aleatorizados controlando la variación debida a dos factores bloqueadores. El cuadrado grecolatino extiende esta idea superponiendo en un cuadrado latino un sistema adicional de clasificación que está equilibrado con respecto a las filas, las columnas y los tratamientos. Por convención se lo representa mediante letras del alfabeto griego. Por ejemplo, el siguiente diseño podría utilizarse para un experimento parecido al descrito en el ejemplo 8.5:

A α	B β	C γ	D δ	E ϵ
B δ	C ϵ	D α	E β	A γ
C β	D γ	E δ	A ϵ	B α
D ϵ	E α	A β	B γ	C δ
E γ	A δ	B ϵ	C α	D β

Nótese que tanto las letras «latinas» como las griegas forman cuadrados latinos con las filas y las columnas, y también que cada letra latina se presenta precisamente una vez con cada letra griega. Supóngase que el experimentador desea comparar los efectos de cinco dosis diferentes de factor difusor, tomando en cuenta simultáneamente el orden de administración, las diferencias entre animales y las diferencias entre posiciones en los dorsos de los animales. Podría emplearse el diseño ilustrado asignando aleatoriamente columnas a cinco animales diferentes, filas a cinco posiciones, letras griegas a las cinco posiciones en el orden de administración y letras latinas a las cinco diluciones.

Un punto general que se ha de recordar en relación con los cuadrados grecolatinos es que el número de grados de libertad para la MC residual es invariablemente bajo. Por lo tanto, a no ser que se pueda obtener de manera fidedigna una estimación de la variancia del error a partir de datos extraños, muchas veces será deseable introducir suficientes repeticiones para proporcionar una estimación adecuadamente precisa de la variación aleatoria.

Diseños de bloques incompletos

En muchas situaciones en que exista un sistema natural de bloques, se descarta un diseño de bloques aleatorios porque el número de tratamientos es mayor que el número de unidades experimentales que se pueden formar adecuadamente dentro de un bloque. Esta limitación puede deberse a restricciones físicas: en un experimento con inoculaciones intradérmicas en animales, en el que cada animal forma un bloque, puede haber un límite del número de sitios de inoculación. La limitación puede ser por conveniencia: si se efectúan mediciones clínicas repetidas en cada uno de un número determinado de pacientes, es posible que no sea deseable someter a ningún paciente a más de unas pocas de estas observaciones. Puede haber un límite de tiempo: por ejemplo, un bloque puede consistir en observaciones hechas en un solo día. A veces, cuando se puede formar un número adecuado de unidades en cada bloque, es posible que ello no sea deseable porque conduce a un grado excesivamente alto de variación dentro del bloque.

Una solución posible a estas dificultades consiste en el uso de un *diseño de bloques incompletos*, en el que se utiliza sólo una selección de los tratamientos en cualquier bloque. En general esto conducirá a diseños sin la atractiva simetría de un diseño de bloques aleatorio. No obstante, ciertos diseños, denominados *diseños de bloques incompletos balanceados*, conservan un considerable grado de simetría al asegurar que cada tratamiento se produce el mismo número de veces y que cada par de tratamientos ocurre conjuntamente en un bloque el mismo número de veces.

Existen varias categorías de diseños de bloques incompletos balanceados, cuyos detalles pueden encontrarse en textos de diseño experimental. El carácter incompleto del diseño introduce cierta complejidad en el análisis. Para comparar los efectos medios de tratamientos diferentes, por ejemplo, resulta insatisfactorio comparar simplemente las medias observadas

de todas las unidades que reciben estos tratamientos, ya que dichas medias estarán afectadas por diferencias entre bloques. Por lo tanto, las medias observadas se ajustan de cierta manera para tener en cuenta las diferencias sistemáticas entre bloques. Esto es equivalente a obtener contrastes entre tratamientos únicamente a partir de diferencias intrabloques. Para más detalles, véase Cochran y Cox (1957, apartado 9.3).

Otra clase de diseños, los *cuadrados de Youden* o *cuadrados latinos incompletos*, son similares a los diseños de bloques incompletos balanceados, pero poseen la característica adicional de que una segunda fuente de variación extraña es controlada por la introducción de una clasificación por columnas. Tienen la misma relación con los diseños de bloques incompletos balanceados que los cuadrados latinos con los diseños de bloques aleatorios.

En un cuadrado de Youden las clasificaciones por filas y por columnas entran en el diseño de diferentes maneras. El número de filas (bloques) es igual al número de tratamientos, de manera que cada columna contiene todos los tratamientos; el número de columnas es inferior al número de tratamientos, de modo que en cada fila sólo se emplea una selección de tratamientos. A veces se requieren diseños para un control de dos factores de la variabilidad, en situaciones en que ambas clasificaciones deben tratarse de una manera incompleta. En este caso puede ser de utilidad un tipo de diseño, denominado *grupo de cuadrados en «celosía» balanceados*. Si se desea una descripción breve, véase Cox (1958, apartado 11.3 (iii)); si se desean detalles, véase Cochran y Cox (1957, cap. 12).

En un diseño de bloques incompletos balanceados todos los tratamientos se tratan de una manera simétrica. Por ejemplo, todos los contrastes entre pares de tratamientos se estiman con igual precisión. Otros diseños de bloques incompletos conservan parte de la simetría, aunque no toda, de los diseños balanceados. Pueden adoptarse cuando se desean estimar deliberadamente unos contrastes con mayor precisión que otros. También es posible que, debido a restricciones físicas en el tamaño del experimento, no pueda emplearse ninguno de los diseños balanceados. Los *diseños «en celosía»* (no deben confundirse con los cuadrados en «celosía»), en particular, son útiles cuando debe compararse un número grande de tratamientos y cuando sea probable que el diseño balanceado más pequeño sea demasiado grande para su uso práctico.

A veces puede ser necesario emplear diseños de bloques incompletos que carecen de todo grado de simetría. Véanse algunos ejemplos complejos en Pearce (1965).

Repetición fraccionada y confusión

Cuando las filas y columnas de un cuadrado latino representan diferentes factores de tratamiento, y las letras latinas representan un tercer factor de tratamiento, se trata de un diseño factorial incompleto. Como hemos visto al analizar el cuadrado latino, una consecuencia es que se pueden estudiar los efectos principales de los factores si se asume que las interacciones están ausentes. Existen muchos otros diseños factoriales incompletos o *fraccionados* en los que se utiliza sólo una fracción de todas las posibles combinaciones de niveles de factores, con la consecuencia de que no todos los efectos principales o interacciones pueden investigarse por separado.

Estos diseños pueden ser muy útiles para experimentos con un gran número de factores, en los que el número de observaciones necesarias para un experimento factorial completo es mayor que el que es conveniente usar o en los que los efectos principales pueden estimarse

con suficiente precisión con una cantidad de observaciones menor que la completa. Si por el uso de diseños factoriales fraccionados se debe sacrificar la capacidad para estimar algunos de los efectos principales o interacciones, normalmente será conveniente perder información sobre las interacciones de mayor orden antes que los efectos principales o interacciones de menor orden, porque es improbable que aquéllas sean grandes sin que éstas también parezcan grandes, mientras que lo contrario no es cierto. Otro aspecto que se ha de recordar consiste en que las SC de interacciones de mayor orden a menudo se reúnen en los análisis de variancia para obtener una estimación de la variancia residual. El sacrificio de la información sobre algunas de éstas reducirá los grados de libertad residuales y, si esto ocurre de forma demasiado espectacular, se obtendrá una estimación poco precisa del error, excepto que se disponga de una estimación a partir de otros datos.

Los diseños factoriales fraccionados han sido muy usados en trabajos industriales y agrícolas, en los que hay que estudiar los efectos simultáneos de números grandes de factores y en los que a menudo se fija la atención en los efectos principales y en las interacciones de orden bajo.

Otra manera de reducir un diseño factorial completo, en un experimento en bloques, consiste en disponer que cada bloque contenga sólo una selección de las posibles combinaciones de factores. El diseño se elige para asegurarse de que algunos efectos, de forma característica los efectos principales y las interacciones de orden bajo, puedan estimarse a partir de contrastes *intra bloques*; en cambio, otros (de menor interés) se calculan a partir de contrastes *entre bloques*. En este último caso se dice que el contraste está *confundido con bloques* y, desde luego, se calculan con menor precisión que los efectos no confundidos.

8.6. Diseños en parcelas divididas

En un diseño factorial en el que se producen confusiones con bloques, como se esbozó al final del apartado 8.5, son importantes dos tipos de variación aleatoria: la variación entre unidades experimentales dentro de un bloque y la variación entre bloques. En algunos diseños factoriales simples es conveniente reconocer dos formas de unidad experimental, una de las cuales es una subdivisión de la otra, y disponer que los niveles de algunos factores se extiendan a través de las unidades más grandes, mientras que los niveles de los otros factores se extienden a través de las subunidades más pequeñas dentro de las grandes.

Este principio fue explotado al principio en experimentos agrícolas, en los cuales los diseños se denominan *diseños de parcelas divididas*. En algunos experimentos agrícolas es conveniente dividir el campo en «parcelas principales» y comparar los niveles de un factor (p. ej., la suma de los diferentes microorganismos del suelo) asignándolos aleatoriamente a las parcelas principales. Al mismo tiempo, cada parcela principal se divide en varias «subparcelas» a las cuales se asignan al azar los niveles de algún otro factor (p. ej., fertilizantes diferentes), exactamente como en un experimento de bloques aleatorios. La comparación de los fertilizantes estaría sujeta a la variación aleatoria entre subparcelas, que probablemente sería menor que la variación entre las parcelas principales que afecta a las comparaciones de microorganismos. Así, éstos se comparan con menor precisión que los fertilizantes. Es probable que esta desigualdad de precisión sea aceptada debido a la conveniencia de que se puedan diseminar microorganismos sobre superficies relativamente grandes de suelo.

Se plantean situaciones similares en experimentos médicos y en otros experimentos biológicos. En general, las unidades experimentales se denominan «parcelas» y, por lo tanto, es más adecuado denominar al diseño *parcelas divididas*. Otro término utilizado es el de *diseños anidados*. A continuación proporcionamos algunos ejemplos de la distinción entre unidades principales y las subunidades.

Unidad principal	Subunidad
Sujeto humano o animal particular	Ocasiones diferentes con el mismo sujeto animal
Camada	Animales de una camada
Día	Períodos durante un día

En el primero de estos casos podría emplearse un diseño de parcelas divididas para comparar los efectos a largo plazo de los fármacos A_1 , A_2 y A_3 y, simultáneamente, los efectos a corto plazo de los fármacos B_1 , B_2 y B_3 . Supóngase que hay 12 sujetos, cada uno de los cuales debe recibir uno de los tratamientos A_1 , A_2 o A_3 ; cada sujeto es observado durante tres períodos, en los cuales se administran B_1 , B_2 y B_3 en orden aleatorio. El diseño, determinado por asignaciones aleatorias de las A a los diferentes sujetos y de las B a los períodos en los sujetos, debería ser de la siguiente manera.

Paciente	Fármaco A durante todo el experimento	Fármaco B durante el período		
		1	2	3
1	A_3	B_1	B_3	B_2
2	A_1	B_1	B_2	B_3
3	A_1	B_3	B_1	B_2
4	A_2	B_3	B_2	B_1
5	A_3	B_2	B_3	B_1
6	A_2	B_2	B_1	B_3
7	A_1	B_1	B_2	B_3
8	A_3	B_3	B_1	B_2
9	A_3	B_1	B_3	B_2
10	A_2	B_2	B_1	B_3
11	A_1	B_2	B_1	B_3
12	A_2	B_2	B_1	B_3

El análisis de estos diseños se ilustra en el ejemplo 8.6, utilizando datos provenientes de un estudio y no de un experimento.

Ejemplo 8.6

Los datos de la tabla 8.11 se han tomado de un estudio de la prevalencia de infecciones respiratorias superiores. La variable que desea analizar es el número de torundas positivas para neumococo durante un período determinado. Se hicieron observaciones en 18 familias, formadas, cada una de ellas, por el padre, la madre y tres hijos, el menor de los cuales fue siempre un niño de edad preescolar. Los

Tabla 8.11. Número de torundas positivas para neumococo durante períodos fijos.

Categoría de hacinamiento	Número seriado de la familia	Situación familiar					Total
		Padre	Madre	Hijo			
				1	2	3	
Muy hacinada	1	5	7	6	25	19	62
	2	11	8	11	33	35	98
	3	3	12	19	6	21	61
	4	3	19	12	17	17	68
	5	10	9	15	11	17	62
	6	9	0	6	9	5	29
		—	—	—	—	—	—
		41	55	69	101	114	380
Hacinada	7	11	7	7	15	13	53
	8	10	5	8	13	17	53
	9	5	4	3	18	10	40
	10	1	9	4	16	8	38
	11	5	5	10	16	8	38
	12	7	3	13	17	18	58
		—	—	—	—	—	—
		39	33	45	95	86	298
No hacinada	13	6	3	5	7	3	24
	14	9	6	6	14	10	45
	15	2	2	6	15	8	33
	16	0	2	10	16	21	49
	17	3	2	0	3	14	22
	18	6	2	4	7	20	39
		—	—	—	—	—	—
		26	17	31	62	76	212
Total		106	105	145	258	276	890

Tabla 8.12. Análisis de la variancia de los datos de la tabla 8.11.

	SC	gl	MC	CV contra	
				a	b
<i>Entre familias</i>	1.146,09	17			
Hacinamiento	470,49	2	235,24		5,22*
Residual	675,60	15	45,04 ^b	1,78	1,00
<i>Intrafamilias</i>	3.122,80	72			
Situación	1.533,67	4	383,42	15,17**	
Situación x hacinamiento	72,40	8	9,05	0,36	
Residual	1.516,73	60	25,28 ^c	1,00	
Total	4.268,89	89			

* $P = 0,019$ ** $P < 0,001$

hijos se numeraron 1, 2 y 3 en orden decreciente de edad. Seis familias constituyeron una selección aleatoria de familias que vivían en condiciones de «muy hacinadas», seis en condiciones «hacinadas» y seis en condiciones «no hacinadas».

El primer punto destacable es que existen dos tipos de variación aleatoria: entre las familias (las unidades principales en este ejemplo) y entre las personas intrafamilias (las subunidades). Las comparaciones entre los grados de hacinamiento se deben hacer *entre las familias*; las comparaciones de la situación familiar se realizan *intrafamilias*. En diseños de cualquier complejidad es una buena idea empezar el análisis subdividiendo los grados de libertad. El resultado se muestra en la columna gl de la tabla 8.12. El total de grados de libertad es 89, ya que hay 90 observaciones. Éstos se dividen (como en el análisis de la variancia de una vía) en 17 ($= 18 - 1$) entre las familias y 72 ($= 18 \times 4$) intrafamilias. Los grados de libertad entre las familias se dividen (igual que en los análisis de un factor) en 2 ($= 3 - 1$) entre grados de hacinamiento y 15 ($= 3 \times 5$) para la variación residual dentro de las categorías de hacinamiento. Los grados de libertad intrafamilias se dividen en 4 ($= 5 - 1$) entre categorías de la situación familiar, 8 ($= 4 \times 2$) para la interacción entre los dos efectos principales, y 60 para la variación residual intrafamilia. La última cifra puede obtenerse por resta ($60 = 72 - 4 - 8$) o considerando esta fuente de variación una interacción entre el residual entre familias y el factor situación familiar ($60 = 15 \times 4$). Nos podemos preguntar por qué la interacción entre la situación familiar y el hacinamiento se designa intrafamilias cuando un efecto principal está entre las familias y el otro es intrafamilias. La razón es que esta interacción mide el grado en que las diferencias de situación familiar, que son intrafamilias, varían de un grado de hacinamiento a otro; por lo tanto, se basa enteramente en contrastes intrafamilias.

El cálculo de las SC se efectúa según los métodos conocidos. Así:

$$\begin{aligned} \text{Término de corrección, TC} &= (890)^2/90 &&= 8.801,11 \\ \text{SC total} &= 5^2 + 7^2 + \dots + 20^2 - \text{TC} &&= 4.268,89 \\ \text{SC entre las familias} &= (62^2 + \dots + 39^2)/5 - \text{TC} &&= 1.146,09 \\ \text{SC intrafamilias} &= \text{SC total} - \text{SC entre las familias} &&= 3.122,80 \end{aligned}$$

Subdividiendo la SC entre las familias:

$$\begin{aligned} \text{SC de hacinamiento} &= (380^2 + 298^2 + 212^2)/30 - \text{TC} &&= 470,49 \\ \text{Residual} &= \text{SC entre familias} - \text{SC hacinamiento} &&= 675,60 \end{aligned}$$

Subdividiendo la SC intrafamilias:

$$\begin{aligned} \text{SC situación familiar} &= (106^2 + \dots + 276^2)/18 - \text{TC} &&= 1.533,67 \\ \text{SC S} \times \text{H} &= (41^2 + \dots + 72^2)/6 - \text{TC} - \text{SC de situación familiar} - \text{SC hacinamiento} &&= 72,40 \\ \text{Residual} &= \text{SC intrafamilias} - \text{SC de situación familiar} - \text{SC S} \times \text{H} &&= 1.516,73 \end{aligned}$$

Los cocientes de variancias en comparación con la MC residual intrafamilias demuestran que las diferencias a causa de la situación familiar son muy significativas; volveremos a este punto más adelante. La interacción no es significativa; por lo tanto no hay evidencia de que los efectos relativos de la situación familiar varíen de un grupo de hacinamiento a otro. El cociente de variancias de 1,78 entre los dos residuales está precisamente en la frontera de la significación al nivel del 5%. Pero *a priori*, deberíamos esperar que la variancia residual entre familias fuera mayor que la intrafamilias y, desde

luego debemos comprobar el efecto principal del hacinamiento en comparación el residual entre familias. El cociente de variancias, 5,22, es significativo.

Las medias de los diferentes miembros de la familia son:

<i>P</i>	<i>M</i>	Hijo		
		1	2	3
5,9	5,8	8,1	14,3	15,3

El error tipo de la diferencia entre dos medias es $\sqrt{[2(25,28)/18]} = 1,68$. Obviamente no hay diferencias significativas entre el padre, la madre y el hijo mayor, pero los dos menores tienen medias significativamente más altas que los otros miembros de la familia.

Los diseños de parcelas divididas más complejos pueden ser más útiles que el diseño descrito antes. Por ejemplo, la estructura impuesta en las unidades principales (que en el ejemplo 8.6 fue una clasificación simple de un factor) podría ser un diseño aleatorio de bloques o algo más complejo. La sección de las subunidades del análisis aumentaría de manera equivalente por el aislamiento de las interacciones correspondientes. De manera similar, se podría hacer más compleja la estructura de las subunidades. Otra dirección de generalización consiste en crear más de dos niveles en la jerarquía de las unidades anidadas. En un estudio similar al del ejemplo 8.6 podría haber varios períodos de observación para cada individuo, durante los cuales se administrasen diferentes tratamientos. Entonces habría una tercera sección en el análisis, intraindividuos, con su correspondiente MC residual. En ninguno de estos casos el análisis debería causar dificultades una vez comprendido el método precedente.

El siguiente ejemplo ilustra un caso en el que hay tres niveles de unidades anidadas, pero en el que el diseño es muy simple. No hay factores estructurales, siendo el propósito del análisis sólo estimar los componentes de la variación aleatoria.

Ejemplo 8.7

En la tabla 8.13 se indican los recuentos de emisiones de partículas durante períodos de 1.000 segundos, de 30 alícuotas del mismo tamaño de un material radiactivo. Cada alícuota se coloca dos veces en el contador. Hay tres fuentes de variación aleatoria, cada una de ellas con su componente de variancias, como se indica a continuación.

1. La variación entre alícuotas, con un componente de variancia σ_2^2 . Esto puede deberse a ligeras variaciones de tamaño o de radiactividad, o a diferencias en la técnica entre las 30 ocasiones en que se examinaron las diferentes alícuotas.
2. La variación sistemática entre encuentros repetidos que produce cambios en el nivel esperado del recuento, con un componente de variancia σ_1^2 . Esto puede deberse a sesgos sistemáticos en los recuentos, que afectan a recuentos diferentes de distintas maneras o a la irregularidad del aparato, debido quizás a la variación en el modo en que se coloca el material en el contador.
3. La variación aleatoria desde un período de tiempo a otro permaneciendo constantes todas las otras condiciones; el componente de variancia es σ_0^2 . No hay repetición de recuentos en condiciones constantes pero sabemos que esta forma de variación sigue la distribución de Poisson (apartado 2.6), en la cual la variancia es igual a la media. La media variará poco a lo largo de todo el ex-

Tabla 8.13. Recuentos de radiactividad durante periodos de 1.000 segundos.

Alícuota	Recuentos		Alícuota	Recuentos	
1	281	291	16	325	267
2	309	347	17	284	296
3	316	356	18	255	281
4	289	277	19	347	285
5	322	292	20	326	302
6	287	321	21	347	307
7	338	320	22	292	344
8	333	275	23	322	308
9	319	311	24	294	272
10	258	302	25	307	303
11	338	294	26	281	331
12	319	281	27	284	322
13	307	247	28	287	305
14	279	259	29	318	352
15	326	272	30	307	301

perimento, pero con una buena aproximación podríamos estimar el σ_0^2 por la media observada para todos los datos, 303,6.

El análisis de la variancia es el mismo que para una clasificación de un factor y es el siguiente:

	SC	gl	MC	Valor esperado de MC
Entre alícuotas	19.898	29	686,1	$\sigma_0^2 + \sigma_1^2 + \sigma_2^2$
Intraalícuotas	20.196	30	673,2	$\sigma_0^2 + \sigma_1^2$
Total	40.094	59		
Poisson			303,6	σ_0^2

Los valores esperados de las MC se deducen según el apartado 7.3, si observamos que el componente de variancia en las alícuotas es $\sigma_0^2 + \sigma_1^2$ (dado que las diferencias entre los recuentos repetidos son afectadas por la variación tanto del tipo 2 como del tipo 3 y que el componente entre alícuotas es σ_2^2).

Así pues, las estimaciones de los componentes de la variancia se obtienen de la siguiente manera:

$$\begin{aligned}\sigma_2^2 &= (686,1 - 673,2)/2 = 6,4 \\ \sigma_1^2 &= 673,2 - 303,6 = 369,6 \\ \sigma_0^2 &= 303,6\end{aligned}$$

Estas estimaciones se hallan, por supuesto, sujetas al error de muestreo, pero claramente no hay indicios de ningún componente grande σ_2^2 , debido a las diferencias entre alícuotas. Los recuentos repetidos varían, no obstante, considerablemente más de lo que puede explicarse por la distribución de Poisson.

8.7. Correlación intraclases

Otra situación en la que se usan los componentes de la variancia es aquella en la que hay varios miembros correlacionados intraclases. Esto puede ocurrir de varias maneras; por ejemplo, una clase podría ser un par de gemelos o una clase podría ser una muestra o un individuo con un elemento medido usando varios métodos distintos. Una medida usada a veces en esta situación recibe el nombre de *coeficiente de correlación intraclases*.

Con un par de gemelos idénticos existe la ambigüedad de calcular el coeficiente de correlación usando (5.10), puesto que los dos valores no tienen un orden específico que podría usarse para etiquetarlos como x e y . Esto podría hacerse al azar, pero el resultado dependería de la aleatorización empleada. Para evitar esto se consideran todas las posibilidades, lo cual significa que cada par se observa por las dos caras, es decir, como (x, y) y como (y, x) . El coeficiente de correlación se calcula a partir de los $2n$ pares así formados y esto proporciona una estimación de la correlación requerida, aunque la precisión de esta estimación sería más cercana a aquella basada en una muestra de n pares, no $2n$. La correlación calculada de esta manera alcanza un valor máximo de 1 sólo si todos los pares de valores se encuentran en una línea recta que pasa por el origen y con una pendiente igual a la unidad.

Supongamos que existe un método nuevo para medir alguna variable y que es necesario calcular la concordancia entre los valores obtenidos usando el método nuevo y los obtenidos con un método ya existente. Podrían recogerse datos en los que varios individuos fueran medidos usando cada método, obteniendo un par de valores correspondientes a cada individuo. Una correlación alta con respecto a una recta que no pasa por el origen o con una pendiente diferente de 1 no representaría una concordancia útil entre los métodos en lo que concierne al usuario, aunque, si esto ocurriese, sería posible calibrar el método nuevo para obtener una mejor concordancia. Así, aunque, a diferencia de los gemelos, no hay ambigüedad acerca de la identificación intrapares, necesitamos una medida de correlación que sólo será igual a la unidad si las dos mediciones son idénticas en cada individuo.

El coeficiente de correlación intraclases es una medida de la correlación entre los valores obtenidos con cualquiera de los dos métodos elegidos al azar en el mismo individuos (clase) y tiene la propiedad descrita antes. La correlación calculada a partir de $2n$ pares, como ya se ha mencionado previamente, es aproximadamente igual al coeficiente de correlación intraclases, excepto cuando n es pequeña. El método está estrechamente relacionado con los componentes de la variancia (apartados 7.3 y 8.6) y aplicando esta metodología es más práctico y más exacto que formar pares múltiples. En general, puede haber más de dos métodos para contrastar y suponemos que hay m métodos, cada uno de ellos evaluado en n sujetos. Por lo tanto, el diseño es equivalente a los bloques aleatorizados (apartado 8.1), en los que los métodos son examinados intrasujetos, es decir, los bloques. Hay tres fuentes de variación, cada una de ellas con su componente de la variancia.

1. Variación entre sujetos, con un componente de variancia σ_s^2 .
2. Variación sistemática entre los métodos, con un componente de la variancia σ_m^2 . Esta variabilidad representa las diferencias entre métodos.
3. Variación aleatoria de una medición a otra, con un componente de la variancia σ^2 , adicional a las fuentes de variación 1 y 2.

Por consiguiente, el análisis de la variancia de dos factores tiene la forma siguiente:

	gl	MC	Valor esperado de MC
Entre sujetos (clases)	$n - 1$	M_s	$s^2 + m^2$
Entre métodos	$m - 1$	M_m	$s^2 + ns_m^2$
Residual	$(n - 1)(m - 1)$	M_r	s^2

El coeficiente de correlación intraclases se define como la correlación entre dos mediciones cualesquiera en el mismo sujeto, usando métodos elegidos aleatoriamente. Los tres componentes de variación contribuyen a la variancia de cada medición y, como las dos mediciones se hacen en el mismo sujeto, el componente de la variancia que representa la variación entre sujetos es común a las dos mediciones.

Por consiguiente, el coeficiente de correlación intraclases es:

$$\rho_I = \frac{\sigma_s^2}{\sigma_s^2 + \sigma_m^2 + \sigma^2}$$

Igualando las MC en el análisis de la variancia a las esperadas se obtiene la siguiente estimación de ρ_I (Bartko, 1966):

$$r_I = \frac{M_s - M_r}{M_s + (m - 1)M_r + \frac{m}{n}(M_m - M_r)} \quad (8.19)$$

Para $m = 2$ se puede obtener el coeficiente de correlación de la siguiente manera: sean x_i^1 y x_i^2 los valores con los métodos 1 y 2, respectivamente, en el sujeto i . Definimos $t_i = x_i^1 + x_i^2$ y $d_i = x_i^1 - x_i^2$ como la suma y la diferencia del par de valores. Calculamos la diferencia media, $\bar{d}$, y las desviaciones tipo de t_i y d_i , s_t y s_d , respectivamente. Entonces:

$$r_I = \frac{s_t^2 - s_d^2}{s_t^2 + s_d^2 + \frac{2}{n}(n\bar{d}^2 - s_d^2)} \quad (8.20)$$

Es fácil ver a partir de esta fórmula que la diferencia sistemática entre los métodos reduce el coeficiente de correlación intraclases, debido a la inclusión de $\bar{d}^2$ en el denominador. Un índice relacionado fielmente, el coeficiente de correlación de concordancia, fue aportado por Lin (1992).

Una formulación alternativa es adecuada cuando no hay razón para suponer que haya diferencias sistemáticas entre los valores dentro de una clase, por ejemplo un par de gemelos. Luego, no hay ninguna entrada en el análisis de la variancia entre métodos; M_r se calcula a partir de un análisis de la variancia con un solo factor (apartado 7.1) con $n(m - 1)$ grados de libertad y el último término del denominador de (8.19) se omite (Snedecor y Cochran, 1989, apartado 13.5).

Otra situación en la que el método puede ser de utilidad es aquella en la que una característica que no se puede medir objetivamente es evaluada por dos o más evaluadores, y el nivel de concordancia entre éstos, que se puede denominar la *fiabilidad* de las puntuaciones, es crítico para la manera en que se usan los datos.

Ejemplo 8.8

En un estudio efectuado por Bergen et al (1992) dos evaluadores valoraron la discinesia tardía según una escala que tomaba valores enteros del 0 al 28. En una serie de valoraciones hubo 168 sujetos con el siguiente resumen estadístico:

$$\bar{t} = 16,39, \quad s_t = 7,71, \quad \bar{d} = 0,28, \quad s_d = 1,89$$

Si se aplica (8.20) se obtiene:

$$r_t = \frac{7,71^2 - 1,89^2}{7,71^2 + 1,89^2 + \frac{2}{168}(168 \times 0,28^2 - 1,89^2)}$$

$$= 0,885$$

La concordancia entre los dos evaluadores fue muy buena y la diferencia media de 0,28 y la variación en la diferencia (DT 1,89) fueron pequeñas en comparación con el total medio de 16,4 con una DT de 7,7. Por consiguiente, se consideró aceptable combinar las apreciaciones de los dos evaluadores y en el análisis principal usamos el valor medio.

El coeficiente de correlación intraclases está estrechamente relacionado con la medida de kappa de concordancia (cap. 12) usada cuando las puntuaciones se anotan en una escala categórica (Fleiss, 1975).

El coeficiente de correlación intraclases tiene la misma peculiaridad que el coeficiente de correlación producto-momento, es decir, que el valor está influido por la selección de sujetos sobre los cuales se define. Si los sujetos son muy variables, el coeficiente de correlación intraclases tenderá a ser elevado, mientras que en un grupo más homogéneo de pacientes será más bajo. Otro problema radica en que el coeficiente de correlación intraclases también combina información a partir de la diferencia sistemática entre métodos con la variación aleatoria entre mediciones. Por lo tanto, el coeficiente de correlación intraclases es una medida que combina tres características de los datos a partir de los cuales se calcula. Esto puede no ser importante si el único propósito de calcular el coeficiente es valorar la concordancia entre métodos en un estudio determinado, pero las comparaciones entre los coeficientes de correlación intraclases de varios estudios son difíciles de interpretar. Una evaluación más completa de la concordancia entre métodos la proporciona el análisis de las diferencias, d_i (Altman, 1991, pp. 397-401). Un gráfico de d_i frente a la media, $1/2 t_i$, permite determinar si la diferencia sistemática entre los métodos o la variación aleatoria difieren según el valor medio y, de no ser así, si la diferencia entre los métodos se puede resumir por $\bar{d}$ y s_d . Si la variación aleatoria aumenta con el valor medio, puede ser conveniente un análisis de las diferencias después de una transformación logarítmica (apartado 9.3).

8.8. Tablas no ortogonales de dos factores: algunos casos sencillos

Muchos grupos de datos presentan un diseño demasiado desbalanceado para que resulte apropiada cualquiera de las formas estándar del análisis de la variancia. El problema consiste en que es posible que los diversos contrastes lineales que juntos representan las fuentes de va-

riación en las que estamos interesados no sean ortogonales en el sentido del apartado 7.4 y que las correspondientes SC no sumen el SC total. Retrasaremos el estudio general del análisis de los diseños no ortogonales hasta el apartado 10.4. No obstante, hay una o dos situaciones especiales que pueden analizarse convenientemente en este punto. En el apartado 8.5 hemos mencionado el análisis de los diseños de bloques desbalanceados (Pearce, 1965). En este apartado estudiaremos algunos de los problemas más sencillos que se plantean con las tablas de dos factores.

En el apartado 8.1 se afirmó que es posible analizar los datos de dos factores con repetición por el método estándar si las frecuencias de las casillas, n_{ij} , son proporcionadas, es decir proporcionales a las frecuencias marginales de filas y columnas. En muchos casos esto no ocurre así. La tentativa de utilizar el método estándar de análisis puede tener consecuencias erróneas o incluso absurdas; por ejemplo, ¿una SC de interacciones puede aparecer como una cantidad negativa!

Nunca hay problemas para obtener la SC residual, ya que está disponible inmediatamente a partir de la variación intracasillas agrupada; depende sólo de la clasificación de un factor entre casillas e intracasillas, y con este fin podemos tener frecuencias arbitrarias en las casillas. El problema, por lo tanto, es obtener la SC para los efectos principales de las filas y columnas y su interacción. La mejor estrategia, de hecho, es probar primero la interacción. Si ésta no es significativa y no hay una fuerte suposición previa de que esté presente una interacción considerable, podemos proceder a examinar los efectos principales de las filas y columnas. Si se cree que hay interacción, no tiene mucho sentido comprobar los efectos principales frente a la SC residual. Para factores de efecto fijo es mejor explorar la interacción examinando las medias de las casillas, calculando sus errores tipo a partir de la MC residual. Para efectos aleatorios o un modelo mixto con interacción, a menudo será mejor estudiar contrastes simples entre niveles de factores.

Se dispone de un método aproximado útil si las frecuencias de las casillas n_{ij} , son casi proporcionadas. Entonces pueden reemplazarse por «seudofrecuencias».

$$n'_{ij} = n_i n_j / N$$

que son exactamente proporcionales a las frecuencias marginales. El total observado, T_{ij} , de los valores de y en la casilla (i, j) es reemplazado ahora por el pseudototal,

$$T'_{ij} = n'_{ij} \bar{y}_{ij}$$

donde $\bar{y}_{ij}$ es la media observada, T_{ij}/n_{ij} . El análisis de la variancia procede entonces como si las frecuencias observadas y los totales hubieran sido n'_{ij} y T'_{ij} (aunque es probable que aquéllas no sean enteras).

Lecturas ausentes

Consideraremos ahora algunos métodos que pueden emplearse si el diseño está exactamente balanceado excepto por un número muy pequeño de lecturas ausentes. Antes de analizar cualquier aspecto técnico es importante destacar uno general que surge siempre que una observación deseada está ausente por alguna razón. El hecho de que no se haga la observación

podría estar relacionado con su magnitud; por ejemplo, es posible que un instrumento de medición no registre valores especialmente altos. Si pierde entonces una información esencial, y ninguna manipulación estadística puede suprimir el sesgo causado por esta ausencia. Asumiremos aquí que la ausencia no está relacionada con la magnitud de la observación que se debió hacer.

Considérese en primer lugar una tabla de dos factores con repeticiones iguales (r observaciones en cada casilla) excepto que en una casilla falta una lectura. Se puede calcular la SC residual, al ser una SC intracasillas, directamente de los datos. Una aproximación adecuada para el cálculo de la SC para los efectos principales y las interacciones consiste en reemplazar la lectura ausente por el valor medio observado en la casilla afectada. El diseño se equilibra entonces y puede analizarse de la forma habitual, excepto que se resta 1 gl para la SC residual y la SC total.

En una tabla de dos factores sin repeticiones (como en un experimento simple de bloques aleatorios), se sigue un procedimiento parecido, pero la observación sustituida depende ahora de los efectos de las filas y las columnas estimados a partir de los datos restantes. Se puede demostrar que el valor introducido debería ser tal que minimizara la SC residual en el análisis de la variancia de los datos incluyendo dicho valor. Este criterio conduce a un uso simple del cálculo diferencial. Un requerimiento equivalente es que el *residual* de la unidad ausente, calculado después de la sustitución, debe ser igual a cero. Siguiendo la notación de la tabla 8.1, supóngase que la observación y_{ij} está ausente. Es reemplazada por el valor:

$$y'_{ij} = \frac{rR_i + cC_j - T}{(r-1)(c-1)} \quad (8.21)$$

donde R_i , C_j y T son los totales de la fila afectada, la columna afectada y todo el grupo, respectivamente, *ignorando la unidad ausente*. Se efectúa entonces el análisis habitual. La SC residual y la SC total tienen, respectivamente $(r-1)(c-1)-1$ y $rc-2$ gl. La MC residual estima correctamente la variancia residual. Las SC de las filas y columnas son ambas, demasiado altas. La corrección para el test de las columnas, por ejemplo, consiste en restar:

$$\frac{[R_i - (c-1)y'_{ij}]^2}{c(c-1)^2} \quad (8.22)$$

de la media cuadrática de las columnas. Para una comparación entre la media de la columna afectada y la de otra columna se deben calcular las medias *después* de la sustitución de y_{ij} . El error tipo de la diferencia entre las dos medias es entonces:

$$\sqrt{\left\{s^2 \left[\frac{2}{r} + \frac{c}{r(r-1)(c-1)} \right] \right\}} \quad (8.23)$$

Existen métodos similares para otros diseños, como los cuadrados latinos, pero no los describiremos aquí ya que, al disponer de métodos generales para el análisis de datos no ortogonales mediante el uso de ordenadores, estos métodos especiales resultan casi superfluos. Si faltan dos lecturas o más en un análisis de dos factores sin repeticiones, de forma iterativa se puede emplear el método descrito antes. Otra vez omitimos detalles porque normalmente es preferible emplear los métodos más generales.

Tabla (2 x c) o (r x 2)

Volvamos ahora al caso general donde las n_{ij} ni siquiera son aproximadamente proporcionadas. Si hay sólo dos filas o dos columnas, existe una solución exacta sin demasiada complejidad.

Supóngase que hay dos filas: una tabla 2 x c. Con la notación habitual para las medias de las casillas podríamos estimar el efecto de las filas en la columna j mediante:

$$d_j = \bar{y}_{1j} - \bar{y}_{2j}$$

La variancia de d_j se estima como s^2/w_j donde:

$$w_j = \frac{1}{\frac{1}{n_{1j}} + \frac{1}{n_{2j}}} = \frac{n_{1j}n_{2j}}{n_{1j} + n_{2j}} \quad (8.24)$$

Según el apartado 7.2, la mejor estimación del efecto global de la fila es la media ponderada de las d_j :

$$\bar{d} = \sum_j w_j d_j / \sum_j w_j \quad (8.25)$$

y la interacción se representa mediante la SC ponderada de las d_j con respecto a $\bar{d}$:

$$\sum_j w_j (d_j - \bar{d})^2$$

que también se puede escribir, como en (7.15):

$$\sum_j w_j d_j^2 - \frac{(\sum_j w_j d_j)^2}{\sum_j w_j} \quad (8.26)$$

La fórmula (8.26), entonces, es la SC de las interacciones en el análisis de la variancia:

Si la MC de (8.26) no es significativa y deseamos continuar asumiendo la ausencia de interacción, se podría obtener la SC de las filas. Ésta es proporcionada por el segundo término de (8.26):

$$(\sum w_j d_j)^2 / \sum w_j \quad (8.27)$$

Se puede elaborar ahora un análisis de la variancia a partir de las siguientes SC:

<i>Entre las casillas</i>	Mediante la fórmula habitual, utilizando T_{ij}
Filas (ajustadas por columnas)	Según (8.27)
Columnas (no ajustadas)	Mediante la fórmula habitual, utilizando C_j
Interacción	Según (8.26)
<i>Intracasillas</i>	Mediante la fórmula habitual

Se puede comprobar, con cierta facilidad algebraica, que los tres componentes de las SC entre casillas suman correctamente. Si los tres componentes se calculan por separado, no es necesario calcular el término entre casillas, excepto que se desee como verificación aritmética. Obsérvese que el término de columnas (no ajustado) no reviste mayor interés por sí mismo, ya que, si existe un efecto de fila, las medias de la columna variarán en parte debido a la ponderación relativa variable dada a las dos filas.

Para un test válido para las columnas, se pueden ajustar las medias de columnas. Alternativamente es posible calcular la SC de las columnas ajustada mediante resta en una subdivisión alternativa de la SC entre casillas:

a) Entre casillas	Mediante la fórmula habitual, usando T_{ij}
b) Filas (no ajustadas)	Mediante la fórmula habitual, usando R_i
c) Columnas (ajustadas por filas)	Por resta, (a) - (b) - (d)
d) Interacción	Según (8.26)

Ejemplo 8.9

La tabla 8.14 muestra las cantidades de accidentes cerebrovasculares sufridos durante un período determinado por 41 varones, cada uno de los cuales se había recuperado de un accidente cerebrovascular previo y era hipertenso. Dieciséis de estos varones recibieron tratamiento de fármacos hipotensores y 25 formaron un grupo de control sin dicho tratamiento. Los datos se muestran en forma de distribuciones de frecuencias, ya que la variable analizada sólo toma los valores 0, 1, 2 y 3. Éste no fue un ensayo controlado con asignación al azar, pero de todas formas fue útil investigar si la diferencia en las cantidades medias de accidentes entre ambos grupos fue significativa y, dado que las distribuciones de edades de ambos grupos eran notoriamente diferentes, se consideró que podría ser importante tener en cuenta la edad. Las dos filas de la tabla 8.14 representan los dos grupos de tratamiento, y las tres columnas, los tres grupos de edad.

Tabla 8.14. Distribuciones de las cantidades de accidentes cerebrovasculares sufridos por varones de grupos con tratamiento hipotensivo y de control, subdivididos por grupos de edad.

		Edad (años)		
		40- Número de varones	50- Número de varones	60- Número de varones
Grupo de control	0	0	3	4
	1	1	3	8
	2	0	4	1
	3	0	1	0
		—	—	—
		1	11	13
Grupo con tratamiento	0	4	7	1
	1	0	4	0
		—	—	—
		4	11	1

Los pasos preliminares del análisis se muestran en la tabla 8.15. La suma T_{ij} y la suma de cuadrados S_{ij} de las n_{ij} observaciones de la fila i y la columna j se obtienen de la manera habitual para una distribución de frecuencias (v. tablas 1.8 y 1.11). Las entradas restantes son sencillas.

Los siguientes pasos son calcular la SC total y la SC entre casillas. La SC total es:

$$S - TC = 45 - 20,5122 = 24,4878$$

La SC entre casillas es:

$$(1,0000 + 17,8182 + \dots + 0,0000) - TC = 7,4528$$

La SC intracasillas se deduce por resta

La SC de la interacción es, según (8.26),

$$5,8949 - 5,8706 = 0,0243$$

y la SC de los tratamientos, ajustada según la edad, es 5,8706. La SC no ajustada por edad se deduce por resta:

$$7,4528 - 5,8706 - 0,0243 = 1,5579$$

pero también se podría haber obtenido directamente como:

$$\begin{aligned} \sum_j (C_j^2/n_j) - TC &= 22,0702 - 20,5122 \\ &= 1,5580 \end{aligned}$$

siendo la discrepancia con respecto a 1,5579 debida a un error de redondeo. Este análisis, desarrollado a la izquierda de la parte inferior de la tabla 8.15, proporciona tests de la F para tratamientos y para la interacción $T \times E$. La diferencia entre los tratamientos es muy significativa; la interacción es muy pequeña y se halla lejos de ser significativa.

Para probar el efecto de la edad ajustado según los tratamientos, calcúlese la SC de los tratamientos no ajustada:

$$\begin{aligned} \sum_i (R_i^2/n_i) - TC &= 26,0000 - 20,5122 \\ &= 5,4878 \end{aligned}$$

y la SC de edades ajustada se obtiene por resta:

$$7,4528 - 5,4878 - 0,0243 = 1,9407$$

El test de la F demuestra que el efecto de la edad no es significativo, ($P = 0,15$).

En la publicación original (Marshall, 1964) se tuvo en cuenta de manera similar el posible efecto de la presión arterial y también se incluyeron datos de pacientes de sexo femenino.

Para un método alternativo de análisis, véase el ejemplo 10.5 en la página 330. Tanto el análisis presente como el del ejemplo 10.5 podrían criticarse por el supuesto de que la variable analizada (can-

Tabla 8.15. Análisis de los datos de la tabla 8.14.

		Edad <i>j</i>	40– 1	50– 2	60– 3	Todas las edades			
Grupo	<i>i</i>					<i>R_i</i>	<i>n_i</i>		
Control	1	<i>T_{1j}</i>	1	14	10	25	25		
		<i>n_{1j}</i>	1	11	13				
		<i>y_{1j}</i>	1,0000	1,2727	0,7692				
		<i>S_{1j}</i>	1	28	12				
		<i>T_{1j}²/n_{1j}</i>	1,0000	17,8182	7,6923				
Tratado	2	<i>T_{2j}</i>	0	4	0	4	16		
		<i>n_{2j}</i>	4	11	1				
		<i>y_{2j}</i>	0,0000	0,3636	0,0000				
		<i>S_{2j}</i>	0	4	0				
		<i>T_{2j}²/n_{2j}</i>	0,0000	1,4545	0,0000				
		<i>C_j</i>	1	18	10			<i>T</i> = 29	<i>S</i> = 45
		<i>n_j</i>	5	22	14				
		<i>d_j</i>	1,0000	0,9091	0,7692				
		<i>w_j</i>	0,8000	5,5000	0,9286				
		<i>w_jd_j</i>	0,8000	5,0000	0,7143				
<i>C_j²/n_j</i>	0,2000	14,7273	7,1429						

TC, $T^2/N = 20,5122$

Análisis de la variancia

	SC	gl	MC	CV		SC	gl	MC	CV
Entre casillas	7,4528	5							
Tratamiento					Tratamiento				
(ajustado)	5,8706	1	5,8706	12,06*	(no ajustado)	5,4878	1		
Edad (no					Edad				
ajustada)	1,5579	2			(ajustada)	1,9407	2	0,9704	1,99
T x E	0,0243	2	0,0122	< 1					
Intracasillas	17,0350	35	0,4867	1,00					
Total	24,4878	40							

* $P < 0,001$

tividad de accidentes) se distribuye normalmente con una variancia constante. Esto probablemente está lejos de la verdad para una variable que toma valores enteros pequeños, un tipo de datos en los cuales a menudo es más apropiada la distribución de Poisson. En el ejemplo 12.11 de la página 406 se describe una aproximación alternativa utilizando un modelo lineal generalizado.

Capítulo 9

Análisis avanzado de datos de regresión lineal

9.1. Aplicación del análisis de la variancia a la regresión

En los dos últimos capítulos se ha empleado el análisis de la variancia para estudiar el efecto sobre la medida de una variable aleatoria de distintos tipos de clasificación de los datos en categorías cualitativas. Volvamos ahora al modelo de regresión lineal, del capítulo 5, en el que el valor medio de y está relacionado linealmente con otra variable x y consideremos el análisis de la variancia en esta situación.

Supongamos que, como en el apartado 5.2, existen n pares de valores $(x_1, y_1), \dots, (x_n, y_n)$, y que la línea de regresión ajustada de y sobre x está definida por la fórmula:

$$Y = a + bx \quad (9.1)$$

estando a y b definidos por (5.2) y (5.3).

La desviación de y_i con respecto a la media $\bar{y}$ puede dividirse en dos partes:

$$y_i - \bar{y} = (y_i - Y_i) + (Y_i - \bar{y}) \quad (9.2)$$

donde Y_i es el valor de y calculado a partir de la línea de regresión cuando $x = x_i$ (9.1).

Puede demostrarse que cuando ambos lados de (9.2) se elevan al cuadrado, y se suman los términos desde $i = 1$ hasta n , la suma de los productos de los términos de la derecha es cero, de modo que aparece la siguiente relación:

$$\sum (y_i - \bar{y})^2 = \sum (y_i - Y_i)^2 + \sum (Y_i - \bar{y})^2 \quad (9.3)$$

El término de la izquierda es la suma de cuadrados (SC) total; el primer término de la derecha es la SC de las desviaciones de las y observadas con respecto a la línea de regresión, y el segundo es la SC con respecto a los valores medios de Y_i predichos por la línea de regresión. En resumen:

$$\text{SC total} = \text{SC con respecto a la regresión} + \text{SC debidas a la recta de regresión}$$

En la figura 9.1a, la mayor parte de la SC total se explica por la SC con respecto a la recta de regresión; por el contrario, en la figura 9.1b, la regresión representa la mayor parte de la SC total.

En (5.7) se propuso una fórmula para $\sum (y_i - Y_i)^2$. A partir de (1.3) y (5.9) se derivan las fórmulas que se muestran en la tabla 9.1 (se han eliminado los sufijos i).




Fig. 9.1. Subdivisión en dos partes de una desviación con respecto a la media: con respecto a la línea de regresión y debida a la regresión. En *a* la regresión de *x* sobre *y* explica una porción mucho menor de la variación total de *y* que en *b*.

Tabla 9.1. Análisis de la variancia para la regresión lineal.

	SC	gl	MC	CV
Debida a la regresión	$\frac{[\sum xy - (\sum x)(\sum y)/n]^2}{\sum x^2 - (\sum x)^2/n}$	1	s_1^2	S_1^2/S_0^2
Con respecto a la regresión	Restando	$n - 2$	s_0^2	
Total	$\sum y^2 - (\sum y)^2/n$	$n - 1$		

Supóngase que, como en el apartado 5.2, las *y* se distribuyen independientemente y de forma normal, con una variancia σ^2 , con respecto a los valores esperados dados por:

$$E(y) = \alpha + \beta x \quad (9.4)$$

Se puede comprobar la hipótesis nula $\beta = 0$ (que equivale a decir que la esperanza matemática de *y* es constante, independientemente del valor de *x*) mediante el análisis de la variancia de la tabla 9.1. Si $\beta = 0$, s_1^2 y s_0^2 son estimaciones no sesgadas e independientes de σ^2 . Si $\beta \neq 0$, s_0^2 será una estimación no sesgada de σ^2 (v. (5.8)), pero s_1^2 será una estimación con un valor superior σ^2 . Se puede emplear, por lo tanto, el cociente de variancias $F = s_1^2/s_0^2$, con 1 y $n - 2$ grados de libertad (gl) para comprobar si $\beta = 0$.

La significación de la línea de regresión se ha examinado anteriormente mediante:

$$t = \frac{b}{ET(b)} = \frac{b}{s_0/\sqrt{\sum(x - \bar{x})^2}}$$

con $n - 2$ gl (según (5.18) y (5.20)). Utilizando la fórmula (5.3) en el caso de *b*, se comprueba fácilmente que $F = t^2$ y (como, por ejemplo, en los apartados 4.6 y 7.1) ambos tests son equivalentes.

Ejemplo 9.1

El análisis de la variancia de y , a partir de los datos del ejemplo 5.1 (pp. 150 y 157) es el siguiente:

	SC	gl	MC	CV	
Debido a la regresión	7.666,39	1	7.666,39	24,2	($P < 0,001$)
Respecto a la regresión	9.502,08	30	316,74	1,00	
Total	17.168,47	31			

La SC ya se había obtenido en las páginas 150 y 157. El valor de t obtenido anteriormente era $-4,92$; obsérvese que $(4,92)^2 = 24,2$, que es el valor de F .

Test de linealidad

A menudo no es suficiente saber si la pendiente de una regresión lineal es significativa, sino que también hay que analizar si existe algún motivo para dudar de la afirmación de linealidad de la regresión.

Si los datos proporcionan varias lecturas repetidas de y para determinados valores de x , es posible obtener fácilmente un test de linealidad. Supóngase que en un valor x_i de x existen n_i observaciones de y , con una media $\bar{y}_i$. Cada grupo de repeticiones forma lo que denominaremos un *vector*. La figura 9.2 muestra tres situaciones distintas. En *a*, la regresión lineal parece ser compatible con los valores observados en que las medias $\bar{y}_i$ de los conjuntos se encuentran bastante cercanas a la línea de regresión. Sin embargo, en *b* y *c*, las medias de los conjuntos se desvían de la línea de regresión en mayor grado de lo que se podría explicar razonablemente por la variación intravalores. En el caso de *b* parece que la desviación es sistemática, lo cual sugiere una línea de regresión en forma de curva. En *c*, la desviación no parece seguir patrón alguno, lo cual sugiere la existencia de una fuente de variación suplementaria asociada a cada vector; por ejemplo, si cada vector se refiriese a observaciones realizadas en los animales de una jaula, la localización de la jaula en el laboratorio podría afectar a todo el vector.

Al comentar la figura 9.2, se hace una comparación aproximada entre la magnitud de las desviaciones de las medias de los vectores con respecto a la línea de regresión y las desviaciones intravector. Formalmente la comparación se hace de la siguiente forma. Para cada valor de y del vector que corresponde a un x_i , el residual $y - Y_i$ puede dividirse en dos partes:

$$y - Y_i = (y - \bar{y}_i) + (\bar{y}_i - Y_i) \quad (9.5)$$

Después de elevar al cuadrado ambos miembros de la ecuación y sumar a lo largo de todas las observaciones, desaparece la suma de los productos de ambos términos de la derecha y queda una partición de la SC residual:

$$\sum (y - Y_i)^2 = \sum (y - \bar{y}_i)^2 + \sum (\bar{y}_i - Y_i)^2 \quad (9.6)$$

estando definidos los sumatorios sobre todas las n observaciones. El primer término de la derecha es la SC con respecto a las medias de vector; el segundo término es la SC de las des-




Fig. 9.2. Desviaciones de medias de vectores con respecto a la regresión lineal. Las de *a* se explican por variaciones intravectores; las de *b* sugieren una desviación sistemática con respecto a la linealidad, mientras que las de *c* sugieren que existe otra fuente de variación.

Tabla 9.2. Análisis de la variancia con test de linealidad.

	SC	gl	MC	CV
Debida a la regresión	(Como en la tabla 9.1)	1	s_1^2	$F_1 = s_1^2/s_2^2$
Desviación de las medias de los vectores con respecto a la regresión	(Restando)	$k - 2$	s_1^2	$F_2 = s_1^2/s_2^2$
Residual intravectores	$\sum y^2 - \sum (T_i^2/n_i)$	$n - k$	s_2^2	
Total	$\sum y^2 - (\sum y)^2/n$	$n - 1$		

viaciones entre la media de cada vector y la línea de regresión. El primero es precisamente lo que se obtendría como SC intravectores en un análisis de la variancia de un factor de las y sin referirse a las x .

Las fórmulas de cálculo se muestran en la tabla 9.2, donde k representa el número de vectores, y T_i es la suma de valores de y en el vector i . El cociente de variancia (CV) F_2 examina la desviación entre las medias de los vectores y la regresión lineal, y F_1 examina la desviación de β con respecto a cero asumiendo que la regresión es lineal. Si F_2 no es significativa y $n - k$ es pequeño, puede ser útil combinar las SC en la segunda y tercera líneas del análisis, volviendo a la tabla 9.1. Si F_2 es significativa, deberá plantearse si la falta de linealidad es de tipo *b* o de tipo *c*. Si es de tipo *b*, deberá ajustarse algún tipo de regresión no lineal (v. apartado 10.3). El tipo *c* puede manejarse aproximadamente examinando s_1^2 frente a s_2^2 mediante el cociente de las variancias de $F_1^* = s_1^2/s_2^2$ con 1 y $k - 2$ gl.

Ejemplo 9.2

En un método para ensayar el efecto de la vitamina D, las ratas se alimentaban con una dieta deficiente en dicha vitamina durante 2 semanas o más hasta que se producía raquitismo. A continuación se suplementaba la dieta con una dosis entre varias, de un preparado estándar de vitamina D o con un preparado de prueba que se comparaba con la anterior. Después de 2 semanas, se valoró el grado de curación del raquitismo mediante una radiografía de la rodilla derecha de los animales. La fotografía se comparó con un conjunto de fotografías de referencia numeradas del 0 al 12 según el grado de cicatrización (en orden creciente).

En la tabla 9.3 se muestran los resultados obtenidos con tres dosis de vitamina D. Cada puntuación es el promedio de cuatro valoraciones de una sola radiografía. La experiencia general en este tipo de ensayos sugiere que existe una regresión lineal de la puntuación y sobre el logaritmo de la dosis, x .

La SC total es:

$$314,2500 - (89,00)^2/31 = 58,7339$$

y la SC residual intradosis es:

$$314,2500 - (32,4000 + 87,7813 + 152,3269) = 41,7418$$

Tabla 9.3. Valoración radiológica de la cicatrización ósea según tres dosis de vitamina D.

Dosis (UI)	3,5	7	14	
Log dosis, x_i	0,544	0,845	1,146	Total
	0	1,50	2,00	
	0	2,50	2,50	
	1,00	5,00	5,00	
	2,75	6,00	4,00	
	2,75	4,25	5,00	
	1,75	2,75	4,00	
	2,75	1,50	2,50	
	2,25	3,00	3,50	
	2,25		3,00	
	2,50		2,00	
			3,00	
			4,00	
			4,00	
T_i	18,00	26,50	44,50	89,00
n_i	10	8	13	31
$\bar{y}_i$	1,8000	3,3125	3,4231	
$\sum y^2$	43,1250	106,3750	164,7500	314,2500
T^2/n_i	32,4000	87,7813	152,3269	

Análisis de la variancia

	SC	gl	MC	CV	
Debido a la regresión	14,0880	1	14,0880	9,45	($P = 0,005$)
Desviación de las medias de cada dosis	2,9041	1	2,9041	1,95	($P = 0,17$)
Residual intradosis	41,7418	28	1,4908	1,00	
Total	58,7339	30			

Los cálculos de la SC debida a la regresión se basan en el hecho de que hay sólo tres valores de x . Así,

$$\begin{aligned}\sum x &= 10(0,544) + 8(0,845) + 13(1,146) = 27,098 \\ \sum (x - \bar{x})^2 &= 10(0,544)^2 + 8(0,845)^2 + 13(1,146)^2 - (27,098)^2/31 = 2,0576\end{aligned}$$

y

$$\begin{aligned}\sum (x - \bar{x})(y - \bar{y}) &= (0,544)(18,00) + (0,845)(26,50) + (1,146)(44,50) \\ &\quad - (27,098)(89,00)/31 = 5,3840\end{aligned}$$

a partir de lo cual:

$$SC \text{ debida a la regresión} = (5,3840)^2/2,0576 = 14,0880$$

El cociente de las variancias para las desviaciones de las medias de cada dosis no es significativo y, por lo tanto, se refuerza la conclusión de que la regresión es efectivamente lineal con este método de ensayo. La pendiente de la recta de regresión es, naturalmente, muy significativa.

Si las observaciones no se encuentran agrupadas para valores fijos de x , la comprobación de la linealidad es menos sencilla. A menudo es correcto formar grupos a lo largo de la escala de x y tratar los datos como si los vectores correspondieran a los puntos medios de los grupos de x . También se pueden utilizar alternativamente los métodos del apartado 10.3 para ajustar curvas de regresión no lineal.

9.2. Errores en ambas variables

Al estudiar la regresión de y sobre x no ha sido necesario considerar ninguna forma de variación aleatoria de los valores de x . Evidentemente, en muchos conjuntos de datos, los valores de x varían de forma aleatoria, ya sea porque las unidades individuales sobre las que se realizan las mediciones se han seleccionado por un proceso aleatorio, o bien porque cualquier observación de x está sujeta a errores de medición o a cualquier otra forma de perturbación aleatoria. En la fórmula de regresión habitual estas consideraciones son inaplicables. Sin embargo, hay preguntas que no se solucionan por el análisis de regresión, y en las que son importantes los errores aleatorios de x . Fundamentalmente son problemas que se refieren a los valores de x observados si no hubiera habido error aleatorio alguno.

Supóngase que cualquier par de valores observados (x , y) puede considerarse que difiere, por errores aleatorios, del par de valores «reales» (X , Y) relacionados linealmente. Así,

$$Y = \alpha + \beta X \tag{9.7}$$

donde observamos:

$$x = X + \delta \tag{9.8}$$

y

$$y = Y + \varepsilon$$

y δ y ε se distribuyen independientemente el uno del otro y también de X e Y . Supóngase que δ se distribuye según $N(0, \sigma_\delta^2)$ y ε como $N(0, \sigma_\varepsilon^2)$ (fig. 9.3).

El primer punto que se ha de señalar es que si el problema reside en la predicción del comportamiento de y o Y en función de x (el valor observado), es adecuado realizar un análisis corriente de la regresión. Esta situación es muy frecuente. Si y es la valoración de un cambio clínico y x es un valor bioquímico, el objetivo del análisis puede ser evaluar la fiabilidad con la que puede predecirse y a partir de x . Cualquier valor de x utilizado en el análisis estará sujeto a variaciones aleatorias debidas a fluctuaciones fisiológicas y a errores de medición, pero pueden ignorarse porque las predicciones se realizarán a partir de valores de x que están también sujetos a tales fluctuaciones.

Sin embargo, supóngase que el objetivo es la estimación del valor de β , la pendiente de la recta que relaciona Y con X (no con x). Es probable que este problema se plantee en dos circunstancias distintas:

1. El valor «verdadero» X puede tener mucho mayor interés que el valor «observado» x , porque las consideraciones futuras se harán en función de X y no de x . Por ejemplo, en un estudio geográfico, x puede representar el tamaño medio de las familias de una ciudad específica estimado a partir del estudio, e y puede representar algún indicador sanitario de esta ciudad. La magnitud del componente de error aleatorio de x puede ser peculiar de este estudio específico y carecer de importancia en futuros trabajos. Cualquier análisis debe basarse en los efectos del valor medio real, X , sobre y .
2. La ecuación (9.7) puede expresar una *relación funcional* entre los valores reales X e Y , que tiene un especial interés científico. Por ejemplo, si X e Y representan, respectivamente, el volumen y la masa de distintas muestras de un metal, la ecuación (9.7) con $\alpha = 0$ representaría la relación entre X e Y , siendo β la densidad. La estimación de β sería un objetivo razonable, pero se encuentran complicaciones porque tanto X como Y están afectadas por errores aleatorios de medición, de modo que el investigador observa pares de valores (x, y) .

La estimación de α y β a partir de pares de valores observados (x, y) es un problema complicado (Kendall, 1951, 1952; Sprent, 1969). Una conclusión general es que b , el coefi-




Fig. 9.3. Desviaciones de los valores observados con respecto a una relación funcional lineal con errores en ambas variables.

ciente de regresión de y sobre x , en promedio subestima β . El valor esperado de b es, aproximadamente:

$$\beta' = \beta \left[1 - \frac{\sigma_{\delta}^2}{\text{Var}(x)} \right] \quad (9.9)$$

Si puede estimarse σ_{δ}^2 (p. ej., mediante un estudio experimental con observaciones repetidas de un mismo valor de X), podrá estimarse el término de corrección entre corchetes, y aplicarse una corrección a la estimación b de la pendiente.

En muchas situaciones no es posible hacer una estimación directa de $\sigma^2 \delta$ porque no existe manera de seleccionar observaciones con diferentes valores de x pero con un mismo valor de X . Habitualmente, esta situación se presenta cuando el investigador se enfrenta a un conjunto de pares (x, y) que muestra una tendencia lineal que desea representar, como una línea recta sin distinguir entre x e y como requiere el análisis de regresión. Debe asegurarse que el uso posterior de la recta no colocará una de las variables en el papel de variable predictora, y que una sola línea desempeñará una función útil al representar la tendencia general. Si no existen bases suficientes para una afirmación razonable sobre σ_{δ}^2 y σ_{ϵ}^2 es mejor hacer una sencilla aproximación visual: dibújese a mano una línea que atraviese el conjunto de puntos y evítese cualquier afirmación sobre errores de muestreo.

Hay una situación especial e interesante en la que x es una *variable controlada*. Supóngase que se sabe que x es diferente de X según un error aleatorio como en (9.8), pero que el valor de x es seleccionado por el investigador. Por ejemplo, al aspirar un líquido en una pipeta, el investigador intenta conseguir un volumen x específico y considerará que ha realizado el experimento con un volumen x , aunque el valor real es X y difiere de x por un error aleatorio. Si no existe un sesgo sistemático, la ecuación (9.8) representará esta situación, pero la diferencia importante entre este problema y el anterior es que el error aleatorio δ es independiente de x , mientras que el caso anterior lo era de X . Por consiguiente, como señaló Berkson (1950), el coeficiente de regresión de y sobre x en este caso sí proporciona una estimación no sesgada de β , y es correcto utilizar los métodos de análisis de regresión habituales.

9.3. Rectas que pasan por el origen de regresión (rectas)

A veces existen fuertes razones para suponer que la línea de regresión debe pasar por el origen, en el sentido que cuando $x = 0$, el valor medio de y también debe ser 0. Por ejemplo, en un experimento psicológico, el sujeto debe adivinar la distancia desde el punto de caída de un haz de luz a la derecha o a la izquierda de una marca. Si la distancia estimada hacia la derecha es y (las distancias hacia la izquierda corresponden a $y < 0$) y la distancia real es x , un sujeto con respuestas sin sesgo a la izquierda ni a la derecha tendría $E(y) = 0$ cuando $x = 0$.

La regresión de y sobre x tomaría la forma:

$$Y = \beta x \quad (9.10)$$

y la solución de los cuadrados mínimos es similar a la del análisis de regresión habitual, excepto si las SC y los productos no se corrigen para las desviaciones con respecto a los valores medios. De este modo, la estimación de β es:

$$b = \Sigma xy / \Sigma x^2 \quad (9.11)$$

y la SC con respecto a la regresión es:

$$\Sigma y^2 - (\Sigma xy)^2 / \Sigma x^2$$

con $n - 1$ (no $n - 2$) gl.

Este resultado supone, como es habitual, que la variancia residual de y es independiente de x . En muchos problemas en que parece adecuada la existencia de una recta que pase por el origen, en especial cuando las variables adoptan sólo valores positivos, en realidad no es así. A menudo la variabilidad de y tiene una tendencia a aumentar a medida que aumenta x . En este caso es posible utilizar otras soluciones de cuadrados mínimos:

1. Si la $\text{Var}(y)$ residual se incrementa en proporción a x , la mejor estimación de β es $b_1 = \Sigma y / \Sigma x = \bar{y} / \bar{x}$, es decir, la razón entre las dos medias. Un ejemplo de esta situación ocurre en los experimentos de recuento de la radiactividad en los que se observa el mismo material en períodos repetidos de diferentes duraciones. Si x_i es un intervalo de tiempo e y_i el recuento correspondiente, la teoría de Poisson muestra que $\text{Var}(y_i) = E(y_i | x_i) \propto x_i$. La estimación de la media de recuentos por unidad de tiempo es, como cabría esperarse, $\Sigma y / \Sigma x$, el recuento total dividido por el período total de tiempo.
2. Si la *desviación tipo* residual de y aumenta en proporción a x , la mejor estimación de β es $b_2 = \Sigma (y/x) / n$, la media de los cocientes individuales.

En estos problemas se requiere una recta de regresión, en lugar de una interrelación funcional (apartado 9.2). Supóngase que x e y son estimaciones de una sustancia bioquímica obtenida mediante dos métodos distintos. Si y es la estimación con el método más fiable y x se obtiene mediante un método rápido pero menos fiable, puede ser razonable estimar y a partir de x y resultar adecuado el empleo de uno de los métodos anteriores. Si la pregunta es ¿qué magnitud tienen las diferencias entre x e y ?, no hay motivo alguno para considerar el problema como una regresión de y sobre x en lugar de x sobre y . En este caso es útil reescribir (9.10) como:

$$\log Y = \log \beta + \log x$$

y tomar los valores individuales de $z = \log y - \log x$ como estimaciones de $\log \beta$. Si la variación aleatoria de z es más o menos independiente de x o de y (lo cual puede comprobarse mediante sencillos gráficos de dispersión), el valor medio de z será la mejor estimación de $\log \beta$, obteniéndose los límites de confianza mediante la distribución t como se hace habitualmente con cualquier media. Esta situación es aproximadamente equivalente a la situación 2. Si la variación aleatoria de z depende fuertemente de x o de y , se pueden agrupar las observaciones y calcular un valor promedio ponderado (v. apartado 7.2).

9.4. Regresión en grupos

Con frecuencia, los datos se clasifican en grupos, y dentro de cada uno de ellos se puede postular una regresión de y sobre x . Por ejemplo, la regresión del volumen espiratorio forzado

sobre la edad puede considerarse por separado en individuos de distintos grupos laborales. A menudo es interesante observar las posibles diferencias entre sus líneas de regresión.

En este apartado consideraremos las comparaciones entre las pendientes de las líneas rectas de regresión. Si la pendiente difiere claramente de un grupo a otro, en este caso, naturalmente, también diferirán los valores medios de y , al menos para algunos valores de x . En la figura 9.4a las pendientes de las rectas de regresión difieren de un grupo a otro. Las rectas que representan los grupos i e ii se cruzan. Las rectas de i e iii y de ii e iii se cruzarían si se extendieran lo suficiente, pero en estos casos existen dudas sobre la validez de las regresiones lineales más allá de los valores observados de x .

Si las pendientes no difieren entre sí, las rectas serán paralelas, como en las figuras 9.4b y c, y en este punto es interesante preguntarse si, como ocurre en b, las rectas se diferencian por su altura sobre el eje x [que depende del coeficiente α de la ecuación $E(y) = \alpha + \beta x$] o si, como ocurre en c, las rectas coinciden. En la práctica, las rectas de regresión ajustadas raras veces muestran *exactamente* la misma pendiente o posición, y el problema consiste en valorar en qué medida las diferencias entre las rectas pueden atribuirse a una variación aleatoria. Las diferencias de posición entre rectas paralelas se comentan en el apartado 9.5. En éste centraremos nuestra atención en el problema de la diferencia entre pendientes.




Fig. 9.4. Diferencias entre rectas de regresión ajustadas a tres grupos de observaciones. Las rectas difieren en su pendiente y posición en a, solamente por su posición en b, y coinciden en c. i, ii, iii.

Supóngase que existen k grupos con n_i pares de observaciones en el grupo i . Los valores medios de x e y del grupo i se denominan $\bar{x}_i$ e $\bar{y}_i$, y la recta de regresión se calcula como en el apartado 5.2 mediante:

$$Y_i = \bar{y}_i + b_i(x - \bar{x}_i) \quad (9.12)$$

Si todas las n_i son suficientemente grandes puede realizarse una aproximación satisfactoria estimando la variancia de cada b_i mediante (5.18) e ignorar la imprecisión de estas estimaciones de la variancia. Variando ligeramente la notación de (5.18), llamaremos s_i^2 la MC residual del grupo i , y $\sum_{(i)}(x - \bar{x}_i)^2$ a la SC de la diferencia de x con respecto a $\bar{x}_i$. Obsérvese que el sufijo i colocado entre paréntesis al lado del sumatorio indica que la suma se efectúa exclusivamente para el grupo i ; es decir:

$$\sum_{(i)}(x - \bar{x}_i)^2 = \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2$$

Siguiendo el método del apartado 7.2, escribimos:

$$w_i = \frac{1}{\text{Var}(b_i)} = \frac{\sum_{(i)}(x - \bar{x}_i)^2}{s_i^2} \quad (9.13)$$

y calculamos:

$$G = \sum w b_i^2 - (\sum w b_i)^2 / \sum w_i \quad (9.14)$$

En la hipótesis nula según la cual las pendientes β_i verdaderas son todas iguales, G sigue aproximadamente una distribución de $\chi^2_{(k-1)}$. Los valores de G elevados indican desviaciones con respecto a la hipótesis nula, es decir diferencias reales entre los β_i . Si el valor de G no es significativo y se acepta provisionalmente la hipótesis nula, el valor común de β de las β_i se estima mejor a partir de la media ponderada:

$$\bar{b} = \sum w_i b_i / \sum w_i \quad (9.15)$$

con una variancia estimada:

$$\text{Var}(\bar{b}) = 1 / \sum w_i \quad (9.16)$$

La variación de muestreo de $\bar{b}$ es aproximadamente normal.

Es difícil decir lo grande que deben ser las n_i para utilizar esta aproximación con seguridad. Seguramente el riesgo es menor si ninguno de los valores de n_i es menor que 20.

Puede conseguirse un tratamiento más exacto si se hace un supuesto suplementario: que las variancias residuales σ_i^2 sean todas iguales. Supóngase que este valor común es σ^2 . Consideraremos en primer lugar la situación en la que $k = 2$, como comparación entre dos pendientes que puede efectuarse utilizando la distribución t . Si $k > 2$, es necesario realizar un análisis de la variancia.

Dos grupos

La variancia residual σ^2 puede estimarse como sigue:

$$s_1^2 = \frac{\sum_{(1)} (y - Y_1)^2}{n_1 - 2}$$

$$= \frac{\sum_{(1)} (y - \bar{y}_1)^2 - [\sum_{(1)} (x - \bar{x}_1)(y - \bar{y}_1)]^2 / \sum_{(1)} (x - \bar{x}_1)^2}{n_1 - 2}$$

o por la correspondiente MC para el segundo grupo, s_2^2 . Puede obtenerse una estimación promediada (muy similar a la del test de la t para dos muestras):

$$s^2 = \frac{\sum_{(1)} (y - Y_1)^2 + \sum_{(2)} (y - Y_2)^2}{n_1 + n_2 - 4} \quad (9.17)$$

Para comparar b_1 y b_2 estimamos:

$$\text{Var}(b_1 - b_2) = s^2 \left[\frac{1}{\sum_{(1)} (x - \bar{x}_1)^2} + \frac{1}{\sum_{(2)} (x - \bar{x}_2)^2} \right] \quad (9.18)$$

La diferencia se contrasta mediante:

$$t = \frac{b_1 - b_2}{\text{ET}(b_1 - b_2)} \text{ con } n_1 + n_2 - 4 \text{ gl} \quad (9.19)$$

siendo los grados de libertad del denominador de (9.17).

Si se considera un valor común para la pendiente de la recta de regresión de ambos grupos, el valor β puede estimarse mediante:

$$b = \frac{\sum_{(1)} (x - \bar{x}_1)(y - \bar{y}_1) + \sum_{(2)} (x - \bar{x}_2)(y - \bar{y}_2)}{\sum_{(1)} (x - \bar{x}_1)^2 + \sum_{(2)} (x - \bar{x}_2)^2} \quad (9.20)$$

siendo la estimación de la variancia:

$$\text{Var}(b) = s^2 / [\sum_{(1)} (x - \bar{x}_1)^2 + \sum_{(2)} (x - \bar{x}_2)^2] \quad (9.21)$$

Resulta claro que las ecuaciones (9.20) y (9.21) pueden fácilmente ser equivalentes a (9.15) y (9.16) si en los cálculos de w_i en (9.13), las estimaciones separadas de las variancias s_i^2 se sustituyen por la estimación común s^2 . Para tests o cálculos de los límites de confianza de β empleando (9.21) debe usarse la distribución t con $n_1 + n_2 - 4$ gl.

Donde se acepta una pendiente común sería más habitual estimar s^2 como la MC residual con respecto a las rectas paralelas (9.34), que tendría $n_1 + n_2 - 3$ gl.

Ejemplo 9.3

La tabla 9.4 indica la edad y la capacidad vital (en litros) de cada uno de 84 varones que trabajan en la industria del cadmio, los cuales se dividen en tres grupos: A_1 , expuestos a los gases de cadmio durante al menos 10 años; A_2 , expuestos a los gases de cadmio durante menos de 10 años, y B, ninguna exposición a los gases de cadmio. El principal objetivo del estudio era analizar si la exposición a dichos gases se asociaba a un cambio de la función respiratoria. Sin embargo, se espera que los individuos del grupo A_1 tengan mayor edad en promedio que los de los grupos A_2 o B, y se sabe que las pruebas de función respiratoria disminuyen con la edad. Por lo tanto, es necesario establecer una comparación para corregir las discrepancias entre las edades medias de los distintos grupos.

En primer lugar mostraremos los cálculos para los dos grupos, uniendo los grupos A_1 y A_2 (denominando A a este grupo) y comparando los grupos A y B.

Las SC y los productos de las desviaciones con respecto a la media, y las pendientes separadas b_i son las siguientes:

Grupo	i	n_i	$\sum_{i0}(x - \bar{x}_i)^2$	$\sum_{i0}(x - \bar{x}_i)(y - \bar{y}_i)$	$\sum_{i0}(y - \bar{y}_i)^2$	b_i
A	1	40	4,397,38	- 236,385	26,5812	- 0,0538
B	2	44	6,197,16	- 189,712	20,6067	- 0,0306
Total			10,594,54	- 426,097	47,1879	(- 0,0402)

Las SC con respecto a las regresiones son:

$$\sum_{i1}(y - Y_1)^2 = 26,5812 - (-236,385)^2/4397,38 = 13,8741$$

y

$$\sum_{i2}(y - Y_2)^2 = 20,6067 - (-189,712)^2/6197,16 = 14,7991$$

Por consiguiente:

$$s^2 = (13,8741 + 14,7991)/(40 + 44 - 3) = 0,3584$$

y, para la diferencia entre b_1 y b_2 , usando (9.18) y (9.19):

$$\begin{aligned}
 t &= \frac{-0,0538 - (-0,0306)}{\sqrt{[(0,3584)\left(\frac{1}{4397,38} + \frac{1}{6197,16}\right)]}} \\
 &= -0,0232/0,0118 \\
 &= -1,97 \text{ con } 80 \text{ gl}
 \end{aligned}$$

La diferencia es casi significativa al nivel del 5%. Este ejemplo continúa en la página 284.

Tabla 9.4. Edades y capacidades vitales de tres grupos de trabajadores de la industria del cadmio. x : edad en el último cumpleaños (años); y : capacidad vital (litros).

Grupo A ₁ Exposición > 10 años		Grupo A ₂ Exposición < 10 años		Grupo B No expuestos			
x	y	x	y	x	y	x	y
39	4,62	29	5,21	27	5,29	43	4,02
40	5,29	29	5,17	25	3,67	41	4,99
41	5,52	33	4,88	24	5,82	48	3,86
41	3,71	32	4,50	32	4,77	47	4,68
45	4,02	31	4,47	23	5,71	53	4,74
49	5,09	29	5,12	25	4,47	49	3,76
52	2,70	29	4,51	32	4,55	54	3,98
47	4,31	30	4,85	18	4,61	48	5,00
61	2,70	21	5,22	19	5,86	49	3,31
65	3,03	28	4,62	26	5,20	47	3,11
58	2,73	23	5,07	33	4,44	52	4,76
59	3,67	35	3,64	27	5,52	58	3,95
		38	3,64	33	4,97	62	4,60
		38	5,09	25	4,99	65	4,83
		43	4,61	42	4,89	62	3,18
		39	4,73	35	4,09	59	3,03
		38	4,58	35	4,24		
		42	5,12	41	3,88		
		43	3,89	38	4,85		
		43	4,62	41	4,79		
		37	4,30	36	4,36		
		50	2,70	36	4,02		
		50	3,50	41	3,77		
		45	5,06	41	4,22		
		48	4,06	37	4,94		
		51	4,51	42	4,04		
		46	4,66	39	4,51		
		58	2,88	41	4,06		
Sumas 597	47,39	1.058	125,21			1.751	196,33
Número de observaciones	12		28				44
$\sum x^2$	30.613		42.260				75.879
$\sum xy$	2.280,01		4.624,93				7.623,33
$\sum y^2$	198,8903		572,4599				896,6401

El diagrama de puntos de la figura 9.5 muestra las rectas de regresión con pendientes b_A y b_B ajustadas por separado a los dos grupos, así como también las dos rectas paralelas con pendiente b . La fuerte inclinación de la pendiente del grupo A puede deberse parcial o totalmente a una curvatura en la regresión; se sugiere que el valor medio de y a valores altos de x es más bajo que lo predicho por las regresiones lineales (v. p. 284). Otra posibilidad es que una regresión lineal sea correcta para cada grupo, pero que en los individuos del grupo A la capacidad vital se reduzca más rápidamente con la edad que en los individuos del grupo B.




Fig. 9.5. Diagrama de dispersión que muestra la edad y la capacidad vital de 84 varones que trabajan en la industria del cadmio, divididos en tres grupos (tabla 9.4). Grupo A₁ ●. Grupo A₂ ◐. Grupo B ○.

Más de dos grupos

Para simplificar la notación llamemos a la SC con respecto a la media de x en el grupo i :

$$S_{xxi} \quad (9.22)$$

en lugar de

$$\sum_{(i)} (x - \bar{x}_i)^2$$

a la suma de productos de las desviaciones, S_{xyi} , etc. Entonces, con cualquier número de grupos, la pendiente b agrupada se obtiene por la generalización de (9.20):

$$b = \frac{\sum_i S_{xyi}}{\sum_i S_{xxi}} \quad (9.23)$$

En ese momento pueden trazarse rectas paralelas por los puntos medios $(\bar{x}_i, \bar{y}_i)$, cada uno con la misma pendiente b . Para el grupo i tendríamos la siguiente ecuación:

$$Y_{ci} = \bar{y}_i + b(x - \bar{x}_i) \quad (9.24)$$

El subíndice c se emplea para indicar que el valor predicho Y_{ci} se obtiene a partir de la pendiente común, b .

La desviación de cualquier valor observado y con respecto a su media grupal $\bar{y}_i$ puede fraccionarse del siguiente modo:

$$y - \bar{y}_i = (y - Y_i) + (Y_i - Y_{ci}) + (Y_{ci} - \bar{y}_i) \quad (9.25)$$

De nuevo, se puede demostrar que las SC de estos componentes pueden sumarse del mismo modo. Lo cual significa

$$\begin{aligned} \text{SC intragrupos} &= \text{SC residual con respecto a rectas separadas} \\ &+ \text{SC debida a las diferencias entre } b_i \text{ y } b \\ &+ \text{SC debida al ajuste de la pendiente común } b \end{aligned} \quad (9.26)$$

El término intermedio de la derecha nos interesa particularmente en este momento. Puede obtenerse observando que la SC debida a la pendiente común es:

$$\left(\sum_i S_{xyi} \right)^2 / \sum_i (S_{xxi}) \quad (9.27)$$

esto se deduce directamente de (5.7) y de (9.23). A partir de resultados anteriores:

$$\text{SC intragrupos} = \sum_i S_{yyi} \quad (9.28)$$

y la SC residual con respecto a rectas separadas

$$= \sum_i [S_{yyi} - (S_{xyi})^2 / S_{xxi}] \quad (9.29)$$

De (9.26), (9.27), (9.28) y (9.29):

$$\text{SC debida a las diferencias de pendiente} = \sum_i \frac{(S_{xyi})^2}{S_{xxi}} - \frac{(\sum_i S_{xyi})^2}{\sum_i S_{xxi}} \quad (9.30)$$

Debe tenerse en cuenta que (9.30) es equivalente a:

$$\sum_i W_i b_i^2 - \frac{(\sum_i W_i b_i)^2}{\sum_i W_i} \quad (9.31)$$

donde $W_i = S_{xxi} = \sigma^2 / \text{Var}(b_i)$, y que la pendiente de los datos agrupados b es igual a $\sum W_i b_i / \sum W_i$, la media ponderada de las b_i . La SC debida a las diferencias en la pendiente es así, esencialmente, una suma de cuadrados ponderada de las b_i con respecto a la media ponderada b , siendo las ponderaciones (como es habitual) inversamente proporcionales a las variancias de muestreo (v. apartado 7.2.).

El análisis se resume en la tabla 9.5. Sólo hay 1 gl para la pendiente conjunta, puesto que la SC es proporcional al cuadrado de un contraste lineal, b . En la segunda línea hay $(k-1)$ gl, y se justifican porque la SC mide las diferencias entre k pendientes independientes, b_i . Los grados de libertad residuales se deducen porque hay (n_i-2) gl para el grupo i y $\sum_i (n_i-2) = n-2k$. El total de grados de libertad intragrupos es, correctamente, $n-k$. Se deduce inmediatamente el test de la F para las diferencias entre las pendientes.

Tabla 9.5. Análisis de la variancia de las diferencias entre pendientes de regresión.

	SC	gl	MC	CV
Debida a la pendiente común	$\frac{(\sum_i S_{xyi})^2}{\sum_i S_{xxi}}$	1		
Diferencia entre pendientes	$\sum_i \frac{(S_{xyi})^2}{S_{xxi}} - \frac{(\sum_i S_{xyi})^2}{\sum_i S_{xxi}}$	$k - 1$	S_A^2	$F_A = s_A^2/s^2$
Residual con respecto a rectas separadas	$\sum_i S_{yyi} - \sum_i \frac{(S_{xyi})^2}{S_{xxi}}$	$n - 2k$	s^2	
Intragrupos	$\sum_i S_{yyi}$	$n - k$		

Ejemplo 9.3 (continuación)

Analizamos ahora la significación de las diferencias entre las tres pendientes. Las SC y los productos de las desviaciones con respecto a la media, y las pendientes separadas, son los siguientes:

Grupo	i	n_i	S_{xx}	S_{xy}	S_{yy}	b_i
A ₁	1	12	912,26	-77,643	11,7393	-0,0851
A ₂	2	28	2.282,71	-106,219	12,5476	-0,0465
B	3	44	6.197,16	-189,712	20,6067	-0,0306
Total		84	9.392,12	-373,574	44,8936	(-0,0398)

La SC debida a la pendiente común es:

$$(-373,574)^2/9392,12 = 14,8590$$

Las SC residuales con respecto a las rectas separadas usando (9.29) son:

$$\sum_{(1)} (y - Y_1)^2 = 5,1310; \quad \sum_{(2)} (y - Y_2)^2 = 7,6050; \quad \sum_{(3)} (y - Y_3)^2 = 14,7991$$

Por lo tanto, la SC residual total con respecto a las rectas separadas es:

$$5,1310 + 7,6040 + 14,7991 = 27,5351$$

La SC intragrupos es 44,8936. La SC para las diferencias entre las pendientes puede obtenerse mediante resta:

$$44,8936 - 14,8590 - 27,5351 = 2,4995$$

También puede calcularse directamente:

$$\frac{(-77,643)^2}{912,25} + \frac{(-106,219)^2}{2282,71} + \frac{(-189,712)^2}{6197,16} + \frac{(-373,574)^2}{9392,12} = 2,4995$$

Ahora puede completarse el análisis de la variancia.

	SC	gl	MC	CV
Pendiente común	14,8590	1	14,8590	42,09 ($P < 0,001$)
Entre pendientes	2,4995	2	1,2498	3,54 ($P = 0,034$)
Residuales separados	27,5351	78	0,3530	
Intragrupos	44,8936	81		

Las diferencias entre las pendientes son más significativas que en el análisis de dos grupos. Las estimaciones de las pendientes separadas, con sus errores tipo calculados en términos de la MC residual con 78 grados de libertad, son:

$$b_{A1} = -0,0851 \pm 0,0197, \quad b_{A2} = -0,0465 \pm 0,0124, \quad b_B = -0,0306 \pm 0,0075$$

El grupo A_1 , el más expuesto, proporciona la pendiente más fuerte. La figura 9.6 muestra las regresiones separadas y también las tres rectas paralelas.

La duda acerca de la linealidad sugiere, además, que podría ser más adecuada una regresión curvilínea; sin embargo, el análisis con una recta de regresión cuadrática (v. apartado 10.3) muestra que la no linealidad es bastante no significativa.




Fig. 9.6. Rectas de regresión paralelas y rectas con pendientes separadas, para trabajadores del cadmio (fig. 9.5).

El test del análisis de la variancia, naturalmente, también puede aplicarse cuando $k = 2$. Los resultados serán completamente equivalentes al test de la t descrito al inicio de este apartado, siendo el valor de F , como siempre, el cuadrado del valor correspondiente de t .

9.5. Análisis de la covariancia

Si después de un análisis como el descrito en el apartado anterior no hay una razón de peso para afirmar que existen diferencias entre las pendientes de las líneas de regresión de los distintos grupos, se plantean las siguientes preguntas. ¿Qué puede decirse de la posición relativa de rectas de regresión paralelas? ¿Existe alguna razón para creer que las rectas verdaderas tienen una posición distinta, como en la figura 9.4b, o pueden coincidir, como en la figu-

ra 9.4c? ¿Qué error de muestreo se asocia a la estimación de la diferencia entre la posición de las líneas de dos grupos específicos?

El conjunto de técnicas relacionadas con estas preguntas se denomina *análisis de la covariancia*. La pertenencia del nombre se verá a lo largo de este apartado.

Antes de describir los detalles técnicos es útil señalar ciertas diferencias importantes en relación con los objetivos del análisis de la covariancia y en las circunstancias en que debe emplearse:

Objetivo principal

1. *Corregir el sesgo*. Si se sabe qué cambios de x afectan el valor medio de y , y que los grupos comparados son diferentes en cuanto a sus valores de $\bar{x}$, se comprende que ciertas diferencias entre los valores de $\bar{y}$ pueden ser atribuidas, en parte, a diferencias entre las $\bar{x}$. Debemos eliminar al máximo este efecto. Por ejemplo, si y es el volumen espiratorio forzado (FEV) y x es la edad, una comparación entre los FEV medios de varones de distintos grupos ocupacionales puede ser afectada por las diferencias en las medias de sus edades. Si las regresiones son lineales y paralelas, eso significa que compararemos las posiciones relativas de las rectas de regresión.
2. *Reducir la variación aleatoria*. Incluso si los distintos grupos tienen valores de $\bar{x}$ muy similares, es posible aumentar la precisión de la comparación de los valores de $\bar{y}$ utilizando la variación residual de y con respecto a la regresión sobre x en lugar de analizar las y aisladamente.

Tipo de investigación

1. *Estudio no controlado*. En numerosas situaciones se realizan observaciones en unidades que van a parar libremente a los grupos en cuestión (sin ningún tipo de asignación controlada). De hecho, a menudo no existe control alguno, lo cual origina el sesgo comentado antes.
2. *Estudio controlado*. En un experimento planificado, en el que las unidades experimentales se asignan aleatoriamente a distintos grupos, las diferencias entre valores de $\bar{x}$ de varios grupos no serán, a la larga, mayores que lo que se esperaría por la teoría de muestreo. Naturalmente a veces se producirán grandes diferencias fortuitas de las $\bar{x}$. Puede ser tan importante corregir este efecto como en un estudio no controlado. En cualquier caso, incluso cuando los valores de $\bar{x}$ sean muy similares, es posible que merezca la pena buscar una precisión suplementaria como se ha descrito antes para reducir la variación aleatoria.

Dos grupos

Si los test de las t basados en (9.19) no muestran diferencia significativa alguna entre las pendientes se pueden ajustar dos rectas paralelas con una pendiente común dada por (9.23). Las ecuaciones de las dos rectas paralelas, son como en (9.24):

$$Y_{c1} = \bar{y}_1 + b(x - \bar{x}_1)$$

y

$$Y_{c2} = \bar{y}_2 + b(x - \bar{x}_2)$$

La diferencia entre los valores de Y para un valor dado de x , es por lo tanto:

$$\begin{aligned} d &= Y_{c1} - Y_{c2} \\ &= \bar{y}_1 - \bar{y}_2 - b(\bar{x}_1 - \bar{x}_2) \end{aligned} \quad (9.32)$$

(v. la fig. 9.7).

El error de muestreo de d se debe, en parte, al de $\bar{y}_1 - \bar{y}_2$, y en parte, al de b (el término $\bar{x}_1 - \bar{x}_2$ no tiene error tipo puesto que consideramos que x es una variable no aleatoria). Las tres variables, $\bar{y}_1$, $\bar{y}_2$ y b son independientes; en consecuencia:

$$\text{Var}(d) = \text{Var}(\bar{y}_1) + \text{Var}(\bar{y}_2) + (\bar{x}_1 - \bar{x}_2)^2 \text{Var}(b)$$

$$= \sigma^2 \left[\frac{1}{n_1} + \frac{1}{n_2} + \frac{(\bar{x}_1 - \bar{x}_2)^2}{S_{xx1} + S_{xx2}} \right]$$

cuya estimación es:

$$s_c^2 \left[\frac{1}{n_1} + \frac{1}{n_2} + \frac{(\bar{x}_1 - \bar{x}_2)^2}{S_{xx1} + S_{xx2}} \right] \quad (9.33)$$

donde s_c^2 es la MC residual con respecto a las rectas paralelas:

$$s_c^2 = \frac{S_{yy1} + S_{yy2} - \frac{(S_{xy1} + S_{xy2})^2}{S_{xx1} + S_{xx2}}}{n_1 + n_2 - 3} \quad (9.34)$$

Obsérvese que s_c^2 difiere de la s^2 de (9.17). Ésta es la MC residual con respecto a rectas separadas y equivale al s^2 de la tabla 9.5. La MC residual s_c^2 de (9.34) se obtiene en las rectas




Fig. 9.7. Análisis de la covarianza para dos grupos, que ilustra la fórmula de la diferencia vertical, d , entre rectas paralelas.

paralelas (puesto que el paralelismo es un supuesto inicial en el análisis de la covariancia), y podría obtenerse de la tabla 9.5 agrupando la segunda y la tercera líneas del análisis. Los grados de libertad resultantes serían $(k-1) + (n-2k) = n-k-1$, que equivalen a los $n_1 + n_2 - 3 (= n-3)$ de (9.34) cuando $k=2$.

El error tipo de d , la raíz cuadrada de (9.33), puede utilizarse en un test de la t . En la hipótesis nula, en la que las rectas de regresión coinciden, $E(d) = 0$ y

$$t = d/ET(d)$$

tiene $(n_1 + n_2 - 3)$ grados de libertad. Los límites de confianza de la diferencia verdadera, $E(d)$, se obtienen de la forma habitual.

Ejemplo 9.4

Los datos del ejemplo 9.3 se emplearán ahora en un análisis de la covariancia. En primer lugar ilustraremos los cálculos para dos grupos: el A, agrupado y expuesto, y el B, no expuesto.

Usando las SC y los productos obtenidos anteriormente tenemos:

$$S_{xxA} + S_{xxB} = 10.594,54$$

$$S_{xyA} + S_{xyB} = -426,097$$

$$S_{yyA} + S_{yyB} = 47,1879$$

También:

$$n_A = 40, \quad n_B = 44,$$

$$\bar{x}_A = 41,38, \quad \bar{x}_B = 39,80,$$

$$\bar{y}_A = 4,315, \quad \bar{y}_B = 4,462$$

A partir de (9.23):

$$b = -0,0402$$

a partir de (9.32):

$$d = -0,0835$$

a partir de (9.34):

$$s_c^2 = 0,3710$$

a partir de (9.33):

$$\text{Var}(d) = 0,01779$$

$$ET(d) = 0,1334$$

y

$$t = -0,0835/0,1334 = -0,63 \text{ con } 81 \text{ gl}$$

La diferencia d es claramente no significativa ($P = 0,53$).

Este análisis se basa en el supuesto de que las rectas de regresión son paralelas en los grupos A y B. Sin embargo, como se señala en el ejemplo 9.3, hay indicios que sugieren que las pendientes

son diferentes. Supóngase que abandonamos la suposición del paralelismo y ajustamos rectas con pendientes separadas, b_A y b_B . La diferencia más pronunciada entre los valores predichos se produce con las edades altas. Por ejemplo, la diferencia a los 60 años es:

$$\begin{aligned}d' &= \bar{y}_A - \bar{y}_B + b_A(60 - \bar{x}_A) - b_B(60 - \bar{x}_B) \\ &= -0,5306\end{aligned}$$

y

$$\begin{aligned}\text{Var}(d') &= \text{Var}(\bar{y}_A) + \text{Var}(\bar{y}_B) + (60 - \bar{x}_A)^2 \text{Var}(b_A) + (60 - \bar{x}_B)^2 \text{Var}(b_B) \\ &= (0,3584) \left[\frac{1}{40} + \frac{1}{44} + \frac{(18,62)^2}{4397,38} + \frac{(20,20)^2}{6197,16} \right] \\ &= 0,06896\end{aligned}$$

Por tanto, $t = d'/\text{ET}(d') = -2,02$ con 80 gl ($P = 0,05$).

Por consiguiente, dicho test sugiere que, a pesar del resultado no significativo en el análisis principal del test de la covarianza, puede haber una diferencia en la capacidad vital media, al menos en los valores más altos de edad. La significación estadística de este hallazgo es, naturalmente, un reflejo de la diferencia entre las pendientes, que tenía un nivel similar de significación estadística.

Más de dos grupos

Las rectas paralelas pueden ajustarse a varios grupos como se indica en el apartado 9.4. La pendiente agrupada b se obtiene a partir de (9.23), y la recta para el grupo i se obtiene mediante (9.24).

Las posiciones relativas de las rectas se expresan adecuadamente mediante el cálculo de la media *corregida* del valor de y de cada grupo. Supóngase que el grupo i presentaba un valor medio de x igual a una constante arbitraria x_0 en lugar de $\bar{x}_i$. A partir de (9.24) podríamos estimar que la media de y debería ser:

$$\bar{y}'_i = \bar{y}_i + b(x_0 - \bar{x}_i) \quad (9.35)$$

Se observa fácilmente que la diferencia, por ejemplo, entre $\bar{y}'_1$ y $\bar{y}'_2$ es igual a la d obtenida por (9.32). Si todas las rectas de regresión coinciden, todas las $\bar{y}'_i$ serían iguales. Si la recta del grupo i se encuentra por encima de todas las demás, para un valor fijo de x , $\bar{y}'_i$ será la media corregida más elevada (fig. 9.8).

En la hipótesis nula de que las rectas de regresión verdaderas de los diferentes grupos coinciden, las medias corregidas $\bar{y}'_i$ diferirán simplemente por error de muestreo. El test correcto se complica por el hecho de que los errores de muestreo de $\bar{y}'_i$ no son independientes puesto que la variable aleatoria b está presente en cada una de las fórmulas (9.35). El procedimiento se indica en la tabla 9.6.

Las columnas (1) y (3) contienen las SC de análisis sencillos de la variancia de un factor de y y x , respectivamente. Los grados de libertad habituales se muestran en la columna (4). La columna (2) contiene el correspondiente análisis de la *covarianza* de x y y , característica que da nombre a todo el proceso. Ésta es una técnica que no habíamos encontrado antes, pero es bastante análoga al análisis de la variancia correspondiente de x , por ejemplo, radiando la diferencia en que cualquier *cuadrado* de una cantidad del análisis de la variancia que




Fig. 9.8. Análisis de la covariancia con tres grupos. Se muestra la media corregida $\bar{y}'$ del grupo i .

Tabla 9.6. Análisis de la covariancia de k grupos; regresión de y sobre x .

Sumas de cuadrados y de productos no corregidos				Corregidos			
(1) y^2	(2) xy	(3) x^2	(4) gl	(5) SC	(6) gl	(7) MC	(8) CV
<i>Entre grupos</i>							
$(S_{yy})_E$	$(S_{xy})_E$	$(S_{xx})_E$	$k - 1$	(Restando)	$k - 1$	s_E^2	$F = s_E^2/s_r^2$
<i>Intragrupos</i>							
$(S_{yy})_I$	$(S_{xy})_I$	$(S_{xx})_I$	$k - 1$	$(S_{yy})_I - (S_{xy})_I^2/(S_{xx})_I$	$n - k - 1$	s_r^2	
<i>Total</i>							
$(S_{yy})_T$	$(S_{xy})_T$	$(S_{xx})_T$	$n - 1$	$(S_{yy})_T - (S_{xy})_T^2/(S_{xx})_T$	$n - 2$		

afecte a x se sustituye en el análisis de la covariancia por el producto de los términos x e y correspondientes.

Por consiguiente, las SC de y se calculan exactamente como en el análisis de la variancia con un solo factor (apartado 7.1), y las SC de x , de manera similar. Las sumas de productos de x e y son las siguientes. La notación debe ser clara.

1. Entre grupos:

$$\frac{(\sum_{(1)}x)(\sum_{(1)}y)}{n_1} + \dots + \frac{(\sum_{(k)}x)(\sum_{(k)}y)}{n_k} - \frac{(\sum x)_T(\sum y)_T}{n}$$

2. Intragrupos:

$$(\sum xy)_T - \left[\frac{(\sum_{(1)}x)(\sum_{(1)}y)}{n_1} + \dots + \frac{(\sum_{(k)}x)(\sum_{(k)}y)}{n_k} \right]$$

3. Total:

$$(\sum xy)_T - \frac{(\sum x)_T(\sum y)_T}{n}$$

Las entradas de la columna (5), en las filas «intragrupos» y «total» se obtienen mediante las fórmulas de SC con respecto a la regresión habitual, utilizando las entradas de las columnas (1) a (3). Se denominan *sumas de cuadrados corregidas*. La SC total corregida es simplemente la SC de residuales con respecto a una sola recta de regresión ajustada a todos los datos y tiene los $n - 2$ gl habituales. La SC intragrupos corregida es la SC de residuales con respecto a las rectas de regresión paralelas; es la suma de las SC de las rectas segunda y tercera de la tabla 9.5 y tiene $n - k - 1$ gl. La SC entre grupos corregida se obtiene restando la SC intragrupos corregida de la SC corregida total. Los grados de libertad también se restando lugar a $n - 2 - (n - k - 1) = k - 1$. Las MC se obtienen según el procedimiento habitual y dan lugar a un test de la F .

¿Por qué la SC entre grupos corregida se obtiene restando y no se forma como los demás términos corregidos? Podríamos haber esperado que se obtuviera mediante:

$$(S_{yy})_E - (S_{xy})_E^2 / (S_{xx})_E$$

con $k - 2$ gl. En realidad, (9.36) representa una parte y no la totalidad de la SC entre grupos corregida. Anotemos el resultado de la resta realizada en la columna (5) de la tabla 9.6. Es el siguiente:

$$\begin{aligned} & [(S_{yy})_T - (S_{xy})_T^2 / (S_{xx})_T] - [(S_{yy})_I - (S_{xy})_I^2 / (S_{xx})_I] \\ &= [(S_{yy})_T - (S_{yy})_I] + (S_{xy})_I^2 / (S_{xx})_I - (S_{xy})_T^2 / (S_{xx})_T \\ &= [(S_{yy})_E - (S_{xy})_E^2 / (S_{xx})_E] + [(S_{xy})_E^2 / (S_{xx})_E + (S_{xy})_I^2 / (S_{xx})_I - (S_{xy})_T^2 / (S_{xx})_T] \end{aligned} \quad (9.37)$$

usando el hecho de que $(S_{yy})_T - (S_{yy})_I = (S_{yy})_E$. El primer término entre corchetes de (9.37) es el mismo que (9.36); representa las desviaciones de las medias de los grupos con respecto a una recta de regresión ajustada a la variación entre grupos, es decir, ajustada a las medias de los grupos. El segundo término entre corchetes de (9.37) es del mismo tipo que (9.30) y representa la diferencia entre la pendiente de las rectas de regresión paralelas ajustadas *intragrupos* y la de la recta de regresión *entre grupos* ajustada a las medias de los grupos. Este último componente tiene 1 gl porque representa un contraste entre dos variables aleatorias, la pendiente intragrupos $b = (S_{xy})_I / (S_{xx})_I$ y la pendiente entre grupos, $b_E = (S_{xy})_E / (S_{xx})_E$. En resumen:

$$\begin{aligned} & \text{SC corregida entre grupos } (k - 1 \text{ gl}) \\ &= \text{SC de las medias de los grupos respecto a la regresión entre grupos } (k - 2 \text{ gl}) \\ &+ \text{SC de la comparación entre } b \text{ y } b_E \text{ (1 gl)} \end{aligned} \quad (9.38)$$

Así, cada uno de los términos después de la igualdad en (9.38) refleja un tipo de desviación de la hipótesis nula en la que las rectas de regresión coinciden. Esto se ilustra en la fi-

gura 9.9. En a , b y b_e son aproximadamente iguales y el principal componente de (9.38) es la variación de las medias de los grupos con respecto a la regresión entre grupos. En la figura 9.9b, las medias se sitúan en una recta, pero las pendientes entre grupos e intragrupos son distintas; en este caso el principal componente de (9.38) es el segundo término. En la figura 9.9c, ambos tipos de variación son importantes.

La SC entre grupos corregida de la tabla 9.6 proporciona así un test general de las desviaciones con respecto a la hipótesis nula de rectas de regresión que coinciden. Si es necesario también puede desglosarse como en (9.38).

Las medias corregidas (9.35) proporcionan un resumen adecuado de la posición relativa de las rectas paralelas. La variancia de muestreo de $\bar{y}_i'$ se estima mediante

$$\begin{aligned}\text{Var}(\bar{y}_i') &= \text{Var}(\bar{y}_i) + (x_0 - \bar{x}_i)^2 \text{Var}(b) \\ &= s_e^2 \left[\frac{1}{n_i} + \frac{(x_0 - \bar{x}_i)^2}{(S_{xx})_w} \right]\end{aligned}\quad (9.39)$$

que varía de un grupo a otro y no sólo a causa de n_i , sino también por el término $(x_0 - \bar{x}_i)^2$, el cual aumenta al distanciarse $\bar{x}_i$ de x_0 en cualquier dirección.

La elección arbitraria de x_0 puede evitarse centrando la atención en las diferencias entre las medias corregidas. Por ejemplo, se pueden comparar los grupos i y j mediante:

$$\bar{y}_i' - \bar{y}_j' = (\bar{y}_i - \bar{y}_j) - b(\bar{x}_i - \bar{x}_j) \quad (9.40)$$




Fig. 9.9. Análisis de la covarianza: distintos tipos de desviaciones con respecto a la hipótesis nula de rectas de regresión que coinciden.

como puede observarse a partir de (9.35). Esta fórmula no incluye x_0 , puesto que está claro que $\bar{y}_i - \bar{y}_j$ representa la distancia vertical entre las rectas de regresión paralelas y, por lo tanto, es independiente de x_0 .

$$\text{Var}(\bar{y}_i - \bar{y}_j) = s_e^2 \left[\frac{1}{n_i} + \frac{1}{n_j} + \frac{(\bar{x}_i - \bar{x}_j)^2}{(S_{xx})_w} \right] \quad (9.41)$$

Además, se puede efectuar inmediatamente un test de significación y calcular los límites de confianza, tomando la raíz cuadrada de (9.41) como ET ($\bar{y}_i - \bar{y}_j$), y con la distribución de t con $n - k - 1$ gl.

Ejemplo 9.4 (continuación)

Usamos ahora los datos completos como ejemplo de un análisis de la covariancia con tres grupos. El análisis de la covariancia es el siguiente:

	No corregido				Corregido			
	y^2	xy	x^2	gl	SC	gl	MC	CV
Entre grupos	2,7473	-57,390	1.254,69	2	0,1616	2	0,0808	0,22
Intragrupos	44,8936	-373,574	9.392,12	81	30,0347	80	0,3754	
Total	47,6409	-430,964	10.646,81	83	30,1963	82		

$$b = -373,574/9.392,12 = -0,0398$$

$$\text{Var}(b) = 0,3754/9.392,12 = 0,00003997$$

$$\text{ET}(b) = 0,00632$$

Se pueden calcular los valores corregidos, usando (9.35) con $x_0 = 40,5$, la media global.

Por consiguiente:

$$\bar{y}_{A1} = 3,949 - 0,0398(40,5 - 49,75) = 4,32$$

$$\bar{y}_{A2} = 4,472 - 0,0398(40,5 - 37,79) = 4,36$$

$$\bar{y}_B = 4,462 - 0,0398(40,5 - 39,80) = 4,43$$

Como en el análisis de dos grupos, sería más prudente abandonar la presunción de paralelismo y comparar las posiciones de las rectas no paralelas, por ejemplo, a la edad de 60 años. Esto se deja como ejercicio para el lector. Otro método equivalente para el análisis de estos datos se presenta en el ejemplo 10.3, usando la regresión múltiple.

Al considerar la posibilidad de emplear el análisis de la covariancia con un conjunto específico de datos, debe cuidarse especialmente la identificación de las variables dependientes e independientes. Si en el análisis de la covariancia de y sobre x existen diferencias significativas entre grupos, esto no implica que lo mismo suceda en la regresión de x sobre y . En muchos casos, éste es un problema académico porque el investigador está claramente inte-

Capítulo 10

Mediciones múltiples

10.1. Regresión múltiple

En las primeras consideraciones sobre la regresión realizadas en los capítulos 5 y 9 nos hemos referido a la relación entre el valor medio de una variable y el valor de otra variable, centrándonos especialmente en la situación de que dicha relación puede representarse por una recta.

A menudo es conveniente expresar el valor medio de una variable en términos no de otra variable, sino de varias. Algunos ejemplos ilustrarán ciertos objetivos ligeramente distintos de este planteamiento.

1. El propósito principal puede ser estudiar el efecto sobre la variable y de cambios en una única variable x_1 , pero se debe admitir que y puede verse afectada por otras muchas variables x_2, x_3 , etc. Por lo tanto se debe estudiar el efecto sobre y de cambios simultáneos de x_1, x_2, x_3 , etc. En el análisis de datos sobre la función respiratoria de los trabajadores de una industria en concreto, como los considerados en los ejemplos 9.3 y 9.4 el efecto de la duración de la exposición a un peligro puede ser el interés principal. No obstante, la función respiratoria es afectada por la edad y ésta se halla relacionada con la duración de la exposición. Por lo tanto se debe estudiar el efecto simultáneo sobre la función respiratoria de la edad y la exposición de modo que se pueda estimar el efecto de la exposición en trabajadores de una edad determinada.
2. Es posible que se desee conocer a fondo algunos mecanismos causales descubriendo cuál de las variables de un conjunto $x_1, x_2, \dots$, tiene aparentemente más influencia sobre una variable dependiente y. Por ejemplo, la tasa de recién nacidos varía considerablemente en diferentes ciudades de Gran Bretaña. Relacionando la tasa de recién nacidos muertos simultáneamente con un gran número de variables que describen las ciudades –por ejemplo, variables económicas, sociales, meteorológicas o demográficas– sería posible encontrar los factores que ejercen una influencia particular sobre la tasa de recién nacidos muertos (v. Sutherland, 1946). Otro ejemplo se halla en el estudio de las variaciones del coste por paciente en los distintos hospitales. Esto presumiblemente depende de forma acusada de la «mezcla de pacientes» –las proporciones de los distintos tipos de pacientes admitidos–, así como de otros factores. Un estudio de los efectos simultáneos de algunas de estas variables puede explicar, en gran parte, la variación de los costes hospitalarios y, prestar atención a determinados hospitales cuyos costes altos o bajos están fuera de la línea de la predicción, puede sugerir nuevos factores de suma importancia.
3. Para predecir el valor de la variable dependiente en futuros sujetos. Después del tratamiento con procedimientos ablativos de pacientes con un cáncer de mama avanzado, el pronóstico es muy incierto. Si puede demostrarse que el progreso futuro depende de distintas variables existentes en el momento de la cirugía, sería posible predecir qué pacientes

tienen un pronóstico malo y considerar métodos alternativos de tratamiento para ellas (Armitage et al, 1969).

La técnica apropiada se denomina *regresión múltiple*. En general, el planteamiento consiste en expresar el valor medio de la variable *dependiente* en términos de los valores de un conjunto de otras variables, normalmente denominadas variables *independientes*. La nomenclatura es confusa, ya que algunas de estas variables pueden estar o bien estrechamente relacionadas de forma lógica entre sí (p. ej., una podría ser la edad y la otra el cuadrado de la edad) o bien muy correlacionadas (p. ej., la estatura y la longitud del brazo). Es preferible emplear los términos variables *predictoras* o *explicativas*, o *covariantes*, y normalmente seguiremos esta práctica.

Los datos que analizaremos se componen de observaciones sobre un conjunto de n sujetos, cada uno de los cuales proporciona un valor de la variable dependiente, y , y un valor de cada una de las variables predictoras, $x_1, x_2, \dots, x_p$. El número de variables predictoras, p , debe ser, de preferencia, considerablemente menor que el número de observaciones, n , y las mismas variables p predictoras deben estar disponibles para cada sujeto en cualquier análisis.

Supongamos que, para valores concretos de $x_1, x_2, \dots, x_p$, un valor observado de y se especifica mediante el siguiente modelo lineal:

$$y = a + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + e \quad (10.1)$$

donde e es un término de error. Se supone que los valores de e para cada sujeto se distribuyen independientemente con media cero y variancia σ^2 . Las constantes $\beta_1, \beta_2, \dots, \beta_p$ se denominan *coeficientes de regresión parcial*; en algunos casos α se denomina *ordenada en el origen*. El coeficiente β_1 es la cantidad en que y cambia en promedio cuando x_1 cambia en una unidad y las demás x_i permanecen constantes. En general, β_1 será distinto del coeficiente ordinario de regresión de y sobre x_1 porque éste representa el efecto de los cambios en x_1 sobre los valores medios de y sin ningún intento de mantener constantes las restantes variables.

Los coeficientes $\alpha, \beta_1, \beta_2, \dots, \beta_p$ son cantidades ideales, cuantificables únicamente a partir de un número infinito de observaciones. En la práctica, de n observaciones, debemos obtener estimaciones de los coeficientes y, por lo tanto, una estimación de la ecuación de regresión:

$$Y = a + b_1 x_1 + b_2 x_2 + \dots + b_p x_p \quad (10.2)$$

Las teorías estadísticas indican que un método satisfactorio para obtener la ecuación de regresión estimada consiste en tomar los coeficientes en los que se reducen al mínimo las sumas de los cuadrados (SC) de los residuales, $\sum (y - Y)^2$. Nótese que aquí y es un valor observado e Y es el valor predicho por (10.2) en base a las variables predictoras. Una consecuencia de este planteamiento es que la ecuación de regresión (10.2) se cumple si todas las variables toman sus valores medios. Así pues:

$$\bar{y} = a + b_1 \bar{x}_1 + b_2 \bar{x}_2 + \dots + b_p \bar{x}_p$$

y, por consiguiente, a puede sustituirse en (10.2) por:

$$\bar{y} - b_1 \bar{x}_1 - b_2 \bar{x}_2 - \dots - b_p \bar{x}_p$$

obteniendo la siguiente ecuación de regresión:

$$Y = \bar{y} + b_1(x_1 - \bar{x}_1) + b_2(x_2 - \bar{x}_2) + \dots + b_p(x_p - \bar{x}_p) \quad (10.3)$$

En (5.5) se obtuvo el resultado equivalente para una regresión simple.

Nos encontramos ahora con el problema de encontrar los coeficientes de regresión parcial, b_j . Emplearemos una extensión de la anotación introducida en el capítulo 9; por ejemplo:

$$S_{x_j x_j} = \sum x_j^2 - (\sum x_j)^2/n$$

$$S_{x_j y} = \sum x_j y - (\sum x_j)(\sum y)/n$$

y así sucesivamente.

El método de mínimos cuadrados da un conjunto de ecuaciones lineales simultáneas en b_j :

$$\begin{aligned} (S_{x_1 x_1})b_1 + (S_{x_1 x_2})b_2 + \dots + (S_{x_1 x_p})b_p &= S_{x_1 y} \\ (S_{x_2 x_1})b_1 + (S_{x_2 x_2})b_2 + \dots + (S_{x_2 x_p})b_p &= S_{x_2 y} \\ \vdots & \\ (S_{x_p x_1})b_1 + (S_{x_p x_2})b_2 + \dots + (S_{x_p x_p})b_p &= S_{x_p y} \end{aligned} \quad (10.4)$$

Éstas son las denominadas *ecuaciones normales*, y representan la extensión multivariada de la ecuación para b del apartado 5.2. Existen p ecuaciones para p incógnitas, $b_1, b_2, \dots, b_p$, y en general existe una única solución. Los coeficientes numéricos de la parte izquierda de (10.4) forman una *matriz* que es simétrica con respecto a la diagonal que se forma desde el extremo superior izquierdo al extremo inferior derecho; por ejemplo, $S_{x_1 x_2} = S_{x_2 x_1}$. Dichos coeficientes incluyen sólo las x . Los de la parte derecha incluyen también las y .

Existen varios métodos para resolver (10.4). Los que estén familiarizados con el álgebra de matrices sabrán que este problema se puede solucionar en términos de la *matriz inversa* y puesto que, como veremos más adelante, la matriz inversa se requiere para la inferencia, éste es el método de elección.

La ecuación (10.4) puede expresarse en forma matricial como:

$$\mathbf{S}_{xx} \mathbf{b} = \mathbf{S}_{xy} \quad (10.5)$$

donde $\mathbf{S}_{xx}$ es una matriz simétrica $p \times p$ cuyo término general es $S_{x_j x_j}$, $\mathbf{b}$ es el vector $p \times 1$ de los coeficientes b_j , y $\mathbf{S}_{xy}$ es el vector $p \times 1$ de los términos $S_{x_j y}$. La solución de dichas ecuaciones es:

$$\mathbf{b} = \mathbf{S}_{xx}^{-1} \mathbf{S}_{xy} \quad (10.6)$$

donde $\mathbf{S}_{xx}^{-1}$ es la matriz inversa de $\mathbf{S}_{xx}$. Si el término general de esta inversa es c_{ij} , entonces (10.6) se puede expresar:

$$\begin{aligned}
 b_1 &= c_{11}(S_{x1y}) + c_{12}(S_{x2y}) + \dots + c_{1p}(S_{xpy}) \\
 b_2 &= c_{21}(S_{x1y}) + c_{22}(S_{x2y}) + \dots + c_{2p}(S_{xpy}) \\
 &\vdots \\
 b_p &= c_{p1}(S_{x1y}) + c_{p2}(S_{x2y}) + \dots + c_{pp}(S_{xpy})
 \end{aligned} \tag{10.7}$$

La complejidad de los cálculos se incrementa rápidamente con el valor de p , pero desde que es posible utilizar programas informáticos para el análisis de la regresión múltiple, la complejidad de los cálculos no representa problema alguno para el investigador. Para $p = 2$ los cálculos se llevan fácilmente a cabo en una calculadora. Ilustraremos el método general considerando detalladamente un ejemplo en el cual $p = 2$.

Ejemplo 10.1

Los datos mostrados en la tabla 10.1 se han extraído de un ensayo clínico para comparar dos fármacos hipotensores empleados para reducir la presión arterial durante las intervenciones quirúrgicas (Robertson y Armitage, 1959). La variable dependiente, y , es el «tiempo de recuperación» (en minutos) transcurrido entre el momento en que se interrumpió la administración del fármaco y el momento en que la presión arterial sistólica volvió a 100 mmHg. Los datos proporcionados se refieren a uno de los dos fármacos empleados en el examen. El tiempo de recuperación es muy variable, y un problema de sumo interés es saber hasta qué punto depende de la cantidad de fármaco empleada y del nivel al que disminuyó la presión arterial durante la hipotensión. Las dos variables predictoras son:

- x_1 : log (cantidad de fármaco empleado, en mg)
- x_2 : nivel medio de presión arterial sistólica durante la hipotensión (en mmHg)

Los 53 pacientes se dividieron en tres grupos según el tipo de intervención quirúrgica. Inicialmente ignoraremos esta clasificación y analizaremos los datos como si se tratase de un solo grupo. Las posibles diferencias entre los grupos se toman en consideración en el apartado 10.2.

La tabla 10.1 muestra los valores de x_1 , x_2 y y de los 53 pacientes. Más adelante nos referiremos a las columnas encabezadas por Y e $y - \bar{Y}$. Debajo de los datos se muestran las medias y las SC y las sumas de productos con respecto a las medias de las tres variables. Las ecuaciones (10.4) son:

$$\left. \begin{aligned}
 6,01758 b_1 + 64,0958 b_2 &= 96,4392 \\
 64,0958 b_1 + 3.105,89 b_2 &= 704,566
 \end{aligned} \right\} \tag{10.8}$$

Se puede obtener la matriz inversa aplicando un programa estándar de ordenador. Alternativamente, para esta matriz 2×2 se puede obtener de la manera siguiente. En primer lugar, se calcula el determinante, D , de la matriz,

$$\begin{aligned}
 D &= (6,01758)(3.105,89) - 64,0958^2 \\
 &= 18.689,94 - 4.108,27 \\
 &= 14.581,67
 \end{aligned}$$

Tabla 10.1. Información sobre el empleo de un fármaco hipotensor. x_1 = log (dosis empleada, en mg); x_2 = media de la presión arterial sistólica durante la hipotensión (mmHg); y período de recuperación (minutos).

x_1	x_2	y	Y	$y - Y$	x_1	x_2	y	Y	$y - Y$
Grupo A: «Menor» no torácica ($n_A = 20$)					Grupo B (cont.)				
2,26	66	7	29,3	- 22,3	2,70	73	39	34,7	4,3
1,81	52	10	28,6	- 18,6	1,90	56	28	27,9	0,1
1,78	72	18	13,6	4,4	2,78	83	12	29,4	- 17,4
1,54	67	4	11,5	- 7,5	2,27	67	60	28,8	31,2
2,06	69	10	22,4	- 12,4	1,74	84	10	4,1	5,9
1,74	71	13	13,4	- 0,4	2,62	68	60	36,3	23,7
2,56	88	21	20,6	0,4	1,80	64	22	19,8	2,2
2,29	68	12	28,5	- 16,5	1,81	60	21	22,9	- 1,9
1,80	59	9	23,4	- 14,4	1,58	62	14	16,1	- 2,1
2,32	73	65	25,7	39,3	2,41	76	4	25,7	- 21,7
2,04	68	20	22,6	- 2,6	1,65	60	27	19,1	7,9
1,88	58	31	26,0	5,0	2,24	60	26	33,1	- 7,1
1,18	61	23	7,3	15,7	1,70	59	28	21,0	7,0
2,08	68	22	25,6	- 1,6	Grupo C: Torácica ($n_C = 13$)				
1,70	69	13	13,9	- 0,9	2,45	84	15	20,9	- 5,9
1,74	55	9	24,8	- 15,8	1,72	66	8	16,5	- 8,5
1,90	67	50	20,0	30,0	2,37	68	46	30,4	15,6
1,79	67	12	17,4	- 5,4	2,23	65	24	29,3	- 5,3
2,11	68	11	24,3	- 13,3	1,92	69	12	19,1	- 7,1
1,72	59	8	21,5	- 13,5	1,99	72	25	18,6	6,4
Grupo B: «Mayor» no torácica ($n_B = 20$)					1,99	63	45	25,0	20,0
1,74	68	26	15,5	10,5	2,35	56	72	38,5	33,5
1,60	63	16	15,8	0,2	1,80	70	25	15,5	9,5
2,15	65	23	27,4	- 4,4	2,36	69	28	29,5	- 1,5
2,26	72	7	25,0	- 18,0	1,59	60	10	17,7	- 7,7
1,65	58	11	20,6	- 9,6	2,10	51	25	36,2	- 11,2
1,63	69	8	12,2	- 4,2	1,80	61	44	22,0	22,0
2,40	70	14	29,7	- 15,7					
Resumen estadístico para todos los sujetos									
$n = 53$									
$\sum x_1 = 105,60$			$\sum x_2 = 3,516$		$\sum y = 1,203$				
$\bar{x}_1 = 1,9925$			$\bar{x}_2 = 66,340$		$\bar{y} = 22,698$				
$S_{x_1x_1} = 6,01758$			$S_{x_1x_2} = 64,0958$		$S_{x_1y} = 96,4392$				
			$S_{x_2x_2} = 3,105,89$		$S_{x_2y} = -704,566$				
					$S_{yy} = 13,791,2$				

Entonces,

$$\begin{aligned}
 c_{11} &= 3,105,89/D \\
 &= 3,105,89/14,581,67 \\
 &= 0,213000 \\
 c_{12} &= -(64,0958)/14,581,67 \\
 &= -0,00439564 (= c_{21}) \\
 c_{22} &= 6,01758/14,581,67 \\
 &= 0,000412681
 \end{aligned}$$

Así pues, la matriz inversa es:

SC total = SC con respecto a la regresión + SC debida a la regresión

calculando la SC debida a la regresión mediante (10.12) y obteniendo la SC residual con respecto a la regresión restando. Esta subdivisión permite un análisis de variancia. La subdivisión de los grados de libertad (gl) es la siguiente:

$$\begin{array}{lcl} \text{Total} & = & \text{con respecto a la regresión} + \text{Debida a la regresión} \\ n - 1 & = & (n - p - 1) \qquad \qquad \qquad + p \end{array}$$

El cociente de variancia:

$$F = \frac{\text{MC debida a la regresión}}{\text{MC con respecto a la regresión}} \quad (10.13)$$

proporciona un test global de la hipótesis nula de que $\beta_1 = \beta_2 = \dots = \beta_p = 0$, es decir, que todas las variables predictoras son inútiles.

El cociente

$$\frac{\text{SC debida a la regresión}}{\text{SC total}} \quad (10.14)$$

a menudo se escribe R^2 (por analogía con el resultado similar (5.12) para r^2 en la regresión simple). La cantidad R se denomina *coeficiente de correlación múltiple*. R^2 debe tener valores entre 0 y 1, y su raíz cuadrada ser positiva. En general no puede atribuirse valor alguno a la dirección de una correlación múltiple con más de una variable predictora y así R siempre recibe un valor positivo. El test apropiado de la significación del coeficiente de correlación múltiple es el test de la F ya descrito.

R^2 debe aumentar a medida que se introducen nuevas variables en la regresión y, por consiguiente, no puede usarse para comparar regresiones con distinto número de variables. El valor de R^2 puede ajustarse para tener en cuenta la contribución al azar de cada variable incluida restando el valor esperado si ninguna variable estuviera relacionada con y . El valor ajustado, R_a^2 , se calcula mediante:

$$\begin{aligned} R_a^2 &= R^2 - \frac{p}{n - p - 1} (1 - R^2) \\ &= \frac{(n - 1)R^2 - p}{n - p - 1} \end{aligned} \quad (10.15)$$

R^2 no es una medida satisfactoria de la bondad del ajuste de la regresión ajustada. Si hay valores repetidos de y para ciertos valores de las variables explicativas, es posible calcular la bondad del ajuste subdividiendo la SC con respecto a la regresión en dos componentes, uno que represente las desviaciones de la media de las repeticiones con respecto a la regresión, y el otro, la variabilidad intrarrepeticiones (apartado 9.1 y v. Healy, 1984). Sin repeticiones la bondad del ajuste no se puede examinar estrictamente, pero los métodos para evaluar la conveniencia del modelo se explican más adelante en este apartado.

R^2 ajustado más grande (10.15) o el estadístico C_p de Mallows relacionado (v. Draper y Smith, 1981, apartado 6.2).

Todos estos métodos de selección del modelo pueden obtenerse con el programa PROC REG de SAS, con la opción *SELECTION*; el método 4 requiere mucho más tiempo de ordenador que los otros y es probable que sólo sea posible efectuarlo con algunas variables explicativas.

Ninguno de los métodos mencionados proporciona tácticas infalibles en el difícil problema de seleccionar variables predictoras. Algunas veces se debería retener cierta variable aunque no tuviese efectos significativos, debido a su importancia lógica en el problema específico. En ocasiones, las relaciones lógicas entre algunas de las variables sugieren que se debería retener una variable concreta con preferencia a otra. En algunos casos, debe incluirse o eliminarse un grupo de variables como grupo y no individualmente; por ejemplo, un grupo de variables *ficticias* que representan una sola característica (apartado 10.2). En otros casos, algunas variables sólo pueden incluirse lógicamente si también se incluyen una o más variables adicionales; por ejemplo, un término de interacción sólo debe incluirse en presencia de los efectos principales correspondientes (apartado 10.4). No obstante, a menudo la selección automática es un buen recurso de exploración, aun cuando el conjunto seleccionado de variables deba modificarse basándose en el sentido común.

Colinealidad

Ya hemos mencionado en la página 304 que pueden surgir dificultades si algunas de las variables explicativas están muy correlacionadas. Esta situación se conoce como *colinealidad* o *multicolinealidad*. Por lo general, la colinealidad aparece si existe una relación casi lineal entre algunas de las variables explicativas en la regresión. En este caso los cambios grandes en una variable explicativa se pueden compensar eficazmente mediante cambios grandes en otras variables, de modo que conjuntos muy distintos de coeficientes de regresión proporcionen casi la misma SC residual. Los coeficientes de regresión pueden ser numéricamente inverosímiles e, incluso, en gran parte inservibles.

La colinealidad es una característica de las variables explicativas independientemente de los valores de la variable dependiente. A menudo se puede reconocer la colinealidad a partir de la matriz de correlaciones de las variables explicativas. Si las dos variables están muy correlacionadas, esto implica una colinealidad entre aquellas dos variables. Por otra parte, es posible que se produzca la colinealidad entre un conjunto de tres variables o más y que ninguna de las correlaciones entre estas variables sea especialmente grande, de modo que resulta útil efectuar una verificación formal de los cálculos de la regresión. Una medida de la colinealidad entre x_i y las otras variables explicativas se obtiene por la proporción de la variabilidad en x_i que es explicada por las otras variables, R_i^2 , cuando x_i es la variable dependiente en una regresión sobre las otras x . La variancia de b_i en la regresión de y sobre x_i a x_p , es proporcional al valor recíproco de $1 - R_i^2$ (v. Wetherill et al, 1986, apartado 4.3), de modo que los valores de R_i^2 cercanos a 1 originarán un aumento de la variancia para la estimación de b_i . El *factor de inflación de la variancia* (FIV) para la variable i se define como:

$$\text{FIV} = \frac{1}{1 - R_i^2}$$

sencilla del apartado 9.1. En general, con un total de n observaciones recogidas en k grupos, los grados de libertad se dividen de la siguiente manera:

	gl	
(i) Entre grupos	$k - 1$	
(ii) Debido a la regresión		p
(iii) Desviaciones de la regresión		$k - p - 1$
(iv) Intragrupos	$n - k$	
Total	$n - 1$	

La SC para (iii) se obtiene por resta, (i) – (ii), y la conveniencia del modelo se contrasta con el cociente de las variancias de las líneas (iii) y (iv).

En general, el planteamiento anterior no será factible, ya que las observaciones no se recogen en grupos de repeticiones.

Gráficos residuales

Se puede obtener mucha información por el estudio gráfico de los residuales, $y - \hat{Y}$. Estos valores y los valores predichos $\hat{Y}$ a menudo son impresos por el ordenador. Los valores de los datos del ejemplo 10.1 se muestran en la tabla 10.1. Describimos ahora algunos diagramas de puntos potencialmente útiles, en los que se presentan los residuales. Uno de ellos se muestra en la figura 10.1, que está relacionada con el ejemplo 10.1.

1. *Gráfica de $y - \hat{Y}$ frente a $\hat{Y}$* (fig. 10.1a). Los residuales nunca están correlacionados con el valor predicho, como muestra (10.11). No obstante, el diagrama de puntos puede proporcionar algunos indicadores útiles. La distribución de los residuales puede ser marcadamente no normal; en la figura 10.1a se sugiere cierto rasgo positivo. Este rasgo positivo y otras desviaciones de la normalidad también pueden detectarse construyendo un histograma de los residuales o una gráfica normal (apartado 11.5; el ejemplo 11.2 se aplica a los datos del ejemplo 10.1). La variabilidad de los residuales puede no ser constante: en la figura 10.1a parece aumentar a medida que lo hace $\hat{Y}$. Ambas deficiencias a veces pueden corregirse mediante la transformación de la variable y y el reanálisis (cap. 11). En este ejemplo existe algún indicio de que podría ser apropiado repetir el análisis después de una transformación logarítmica (apartado 11.3) de y , pero éste no es nuestro objetivo. En algunos casos la tendencia en la variabilidad puede requerir un análisis ponderado (v. más adelante). Aun cuando la correlación sea igual a cero, puede haber una tendencia no lineal pronunciada; en ese caso, es probable que aparezca también en los diagramas de tipo 2, a continuación.
2. *Diagrama de $y - \hat{Y}$ frente a x_j* (fig. 10.1b y c). Se pueden representar los residuales frente a los valores de alguna o de todas las variables. De nuevo, la correlación debe ser siempre igual a cero. Sin embargo, puede existir una tendencia no lineal, por ejemplo con residuales que tienden a aumentar hasta un valor máximo cerca de la media, $\bar{x}_j$, y que disminuyen en cualquier de los lados, como se sugiere tal vez en la figura 10.1c, o muestran una tendencia con un valor mínimo cercano a $\bar{x}_j$. Este tipo de tendencias sugiere que el efecto de x_j no se expresa adecuadamente en el modelo por el término lineal. La sugerencia




Fig. 10.1. Residuales del tiempo de recuperación a partir de los datos de regresión múltiple de la tabla 10.1 dibujados en comparación con: los valores predichos (a); x_1 , log cantidad de fármaco (b); x_2 , media de la presión sistólica durante el período de hipotensión (c); el producto $x_1 x_2$ (d); y la edad (e).





Fig. 10.1. (continuación)

Comprobación estadística de los residuales

Aunque las gráficas de los residuales pueden proporcionar mucha información en la identificación de posibles valores aberrantes, hay otros métodos formales que también pueden ser de utilidad. Algunos *métodos diagnósticos de regresión* están dirigidos a la identificación de puntos específicos que son discrepantes con respecto a la regresión a través de los puntos restantes o bien tienen una influencia desproporcionada sobre la ecuación de la regresión ajustada, o ambos casos. Los conceptos se ilustran en la figura 10.2 en términos de una regresión univariante, aunque estos métodos tienen una aplicación máxima en la regresión multivariante, en la que no es fácil elaborar representaciones gráficas. En la figura 10.2a se muestra una regresión a través de nueve puntos. La figura 10.2b presenta un punto adicional




Fig. 10.2. Cinco regresiones que ilustran el efecto de un punto adicional que puede ser un punto aberrante, influyente o ambos. En *a* se muestra la regresión a través de nueve puntos. De *b* a *e* se ha añadido un décimo punto, indicado por *x*, y se muestra la regresión a través del conjunto de diez puntos (línea continua), además de la regresión a través de los nueve puntos originales (línea discontinua).

que es distante de los otros nueve puntos, pero que está cercano a la regresión a través de estos 9 puntos; dicho punto no afecta la pendiente de la regresión ajustada. En la figura 10.2c hay otro punto que es distante de los otros nueve puntos y se encuentra debajo de la recta de regresión a través de estos nueve puntos; evidentemente no es un valor aberrante, pero la inclusión de este punto reduce la pendiente de la recta ajustada a dos tercios de su valor; el punto adicional influye en la determinación de la regresión. En la figura 10.2d el punto adicional de nuevo influye en el cambio de la regresión, pero también parece ser un valor aberrante con respecto a la regresión a través de los otros nueve puntos. Finalmente, en la figura 10.2e el punto adicional está dentro de los límites de los x valores de los nueve puntos restantes; es claramente un valor aberrante pero no tiene un efecto marcado sobre la pendiente de la recta ajustada. Consideremos en primer lugar la identificación de los puntos aberrantes.

Se obtiene el residual en cada punto mediante $e_i = y_i - Y_i$. El *residual estandarizado* se define como $z_i = e_i/s$. A primera vista parecería que e_i es una estimación de E_i en (10.1). Sin embargo, esto no es estrictamente cierto porque los residuales no son independientes, esto se deduce porque los puntos observados se han usado para ajustar la regresión y la suma de los residuales es cero. Sin embargo, si n es mucho mayor que p , los residuales estandarizados tienen una desviación tipo promedio de aproximadamente la unidad, y la desviación tipo variará de un punto a otro. Un punto que sea distante de los otros, en términos de los x valores, es especialmente importante para fijar la recta de regresión, puesto que en este punto se pueden obtener cambios relativamente grandes en la posición de la recta ajustada con cambios más pequeños en todos los demás puntos; esto se ilustra en la figura 10.2b, a d. Se dice que un punto de este tipo tiene una *influencia* alta, siendo la influencia una medida de la distancia estandarizada entre el punto en el espacio x multivariante y la media en este espacio a lo largo de todos los puntos. La influencia, h_i , se encuentra dentro de los límites $1/n$ y 1 y tiene un valor medio de $(p+1)/n$. El error tipo de cada residual depende de la influencia y se estima como $s\sqrt{(1-h_i)}$.

Esto nos lleva a la definición del *residual «estudentizado»*:

$$r_i = \frac{e_i}{s\sqrt{(1-h_i)}} \quad (10.18)$$

Los residuales «estudentizados» se distribuyen aproximadamente como la distribución t con $n-p-1$ gl.

Es posible otra mejora señalando que si un punto, por ejemplo i , es un valor aberrante, tendrá un residual grande, que inflará la estimación de la desviación tipo, s . Esto significa que tanto z_i como r_i disminuirán, de modo que el hecho de que el punto sea un valor aberrante hace, paradójicamente, más difícil detectar que tiene un residual alto. Un rodeo consiste en usar una estimación de la desviación tipo que sea independiente del punto i . Puede obtenerse una estimación de este tipo ajustando la regresión a los datos excluyendo el punto i . Si se designa esta estimación de la desviación tipo mediante $s_{(-i)}$ y se define el residual como:

$$t_i = \frac{e_i}{s_{(-i)}\sqrt{(1-h_i)}} \quad (10.19)$$

se obtiene el *residual jackknife*. Según (10.18):

$$t_i = r_i \left(\frac{s}{s_{(-i)}} \right) \quad (10.20)$$

y puede demostrarse matemáticamente que:

$$t_i = r_i \sqrt{\left(\frac{n-p-2}{n-p-1-r_i^2} \right)} \quad (10.21)$$

de modo que los residuales *jackknife* se calculan fácilmente en cada punto sin tener que ajustar las n regresiones separadas, cada una de ellas excluyendo un punto. Los residuales *jackknife* se distribuyen como la distribución t con $n-p-2$ gl.

La definición de t_i podría parecer sólo un ajuste usando una estimación más adecuada de la desviación tipo, pero en realidad es mucho más que esto. Supóngase que se redefiniera el residual como la diferencia entre la y_i observada y el valor, $Y_{(-i)}$, que se predeciría para el punto i , usando la regresión basada en todos los puntos excepto aquél. Podría calcularse el error tipo de este valor predicho usando la ampliación multivariante de (5.24). Luego se define como residual estandarizado:

$$t_i = \frac{y_i - Y_{(-i)}}{\text{ET}(Y_{(-i)})} \quad (10.22)$$

El residual definido de esta manera, como residual «estudentizado» externamente, es matemáticamente equivalente al residual *jackknife* definido en (10.21). Por consiguiente, cada residual *jackknife* es un residual estandarizado con respecto a la regresión, ajustado usando todos los datos excepto el punto en consideración. Esta propiedad matemática muy destacada depende de la influencia. Los lectores interesados en los aspectos matemáticos pueden consultar a los textos de Cook y Weisberg (1982) y de Belsley et al. (1980), donde el tratamiento matemático es más exhaustivo.

Estos residuales se presentan en la tabla 10.2 en relación con los datos mostrados en la figura 10.2. La columna encabezada como D_{10} se explicará más adelante. Como todos los residuales están estandarizados y son independientes de la escala en la que se miden y y x , hay que elegir dichas escalas de modo que tanto la pendiente de la recta como la desviación tipo en la figura 10.2a sean la unidad. En la figura 10.2b a e se presentan los estadísticos diagnósticos residuales correspondientes al décimo punto adicional. Cuando son considerados frente a la distribución t con ocho y siete gl, respectivamente, los residuales «estudentizado» y *jackknife* claramente no son destacados en el caso de la figura 10.2b o c. En la figura 10.2d y e se muestra la sensibilidad superior del residual *jackknife*; los valores inferiores del residual «estudentizado», r_{10} , en estos dos casos, son consecuencia del aumento de la desviación tipo debido al valor aberrante en examen. En el caso de la figura 10.2d y e se sugiere que el punto adicional es un posible valor aberrante por los valores del residual *jackknife*. Examinemos ahora la formulación de un test de significación de los residuales.

En el caso de la figura 10.2 d, $t_{10} = 2,84$ y si esto se calcula como un estadístico t con 7 gl, $P = 0,025$. No obstante, no se tiene en cuenta que este residual se ha elegido como el más alto, en magnitud absoluta, y el efecto es bastante considerable y aumenta al hacerlo el valor de n . Por lo tanto, el nivel de significación exigido es la probabilidad de que el residual más alto en un grupo de n residuales sea tanto o más grande que el valor observado. Esta probabilidad es la de que no todos los 10 residuales estén en la porción central de la distribución y se obtiene mediante la fórmula: $P = 1 - (1 - 0,025)^{10} = 0,22$, que recibe el nombre de *corrección de Bonferroni*. Un método equivalente de evaluación consiste en trabajar con una probabilidad de significación crítica más baja, y el residual más alto sería significativo con

punto cuya eliminación cambia los coeficientes de regresión a valores fuera de la región de confianza del 50% de las estimaciones, usando todo el conjunto de datos. Los valores de la influencia, h_i , son importantes para determinar D_i . Es posible demostrar matemáticamente que:

$$D_i = \frac{r_i^2 h_i}{(p + 1)(1 - h_i)} \quad (10.23)$$

Según la tabla 10.2, el punto adicional, tanto en 10.2c como en d , tiene una distancia de Cook superior a 1 y esto confirma la impresión obtenida a partir de las gráficas de que estos puntos son influyentes en la determinación de los coeficientes de regresión.

El valor medio de la influencia es $(p + 1)/n$ y a veces se sugiere que los puntos con una influencia alta, por ejemplo superior a $2(p + 1)/n$, deben ser escrutados. Estos puntos son especialmente distantes de la posición media de los puntos en términos de las x variables. Aunque una buena práctica consiste en verificar meticulosamente los datos, un punto con una influencia alta pero para el que no haya indicios de que sea un aberrante o un punto influyente no es causa de alarma. Estos puntos son beneficiosos para reducir los errores tipo de los coeficientes de regresión y, si fuese posible complementar un conjunto de datos recogiendo más datos, una buena selección de valores de x sería aquella con valores con influencias altas.

Ejemplo 10.2

A continuación se presentan los residuales, las influencias y las distancias de Cook correspondientes a algunos de los puntos del ejemplo 10.1. Se han incluido todos los puntos con residuales «estudentizados» superiores a 2 de magnitud absoluta, así como los puntos con influencias superiores a 0,11 y los dos puntos con las distancias de Cook más altas.

Paciente	x_1	x_2	y	r	t	h	D
A ₁	2,26	66	7	-1,53	-1,55	0,035	0,028
A ₇	2,56	88	21	0,03	0,03	0,173	0,000
A ₁₀	2,32	73	65	2,71	2,90	0,041	0,104
A ₁₃	1,18	61	23	1,14	1,14	0,133	0,066
A ₁₇	1,90	67	50	2,04	2,11	0,021	0,030
B ₁₀	2,78	83	12	-1,27	-1,28	0,150	0,095
B ₁₁	2,27	67	60	2,14	2,22	0,034	0,053
B ₁₂	1,74	84	10	0,44	0,44	0,200	0,016
C ₁	2,45	84	15	-0,42	-0,42	0,121	0,008
C ₈	2,35	56	72	2,41	2,53	0,123	0,270
C ₁₂	2,10	51	25	-0,81	-0,81	0,133	0,033
C ₁₃	1,80	61	44	1,51	1,53	0,029	0,023

El residual «estudentizado» más grande es 2,71, correspondiente al décimo paciente del grupo A. El residual *jackknife* es igual a 2,90. ¿Es éste un punto aberrante? El residual *jackknife* se calcula como un valor t con 49 gl. Esto da una $P = 0,0056$ y un valor ajustado de P de $1 - 0,9944^{33} = 0,26$. O bien, remitiéndose a la tabla A8 de Kleinbaum et al. (1988), el valor crítico correspondiente a un nivel de

significación de 0,1 es 3,28. Como el residual *jackknife* es inferior a este valor, tenemos que $P > 0,1$. El residual más alto no es excepcional después de ajustar por el hecho de que es el más alto de los 53 residuales.

El examen de las distancias de Cook correspondientes a los 53 puntos demuestra que no hay puntos con una influencia indebida sobre la regresión. El valor más alto de D_i es 0,27, correspondiente al octavo sujeto del grupo C. Este punto se encuentra arriba y a la izquierda de la figura 10.1c.

La influencia media es $3/53 = 0,057$. Hay siete puntos con una influencia superior al doble de este valor, pero sólo uno de ellos tiene un residual excepcional. Éste es el punto con la distancia de Cook más alta identificada con anterioridad, pero incluso en este punto el residual no es especialmente alto, dado que hay 53 puntos. Por consiguiente, no hay un motivo especial de preocupación acerca de los puntos de influencia o distancia indebida con respecto al conjunto principal de puntos.

Todos los cálculos y gráficos explicados anteriormente para la detección de puntos aberrantes e influyentes se llevan a cabo de manera cómoda mediante un ordenador. Por ejemplo, los valores de los residuales, influencia y distancia de Cook se obtienen con el programa PROC REG de SAS y se pueden representar o analizar.

En el apartado 11.6 se indican las circunstancias en que puede ser legítimo excluir los puntos aberrantes. Las mismas consideraciones son válidas para los puntos influyentes. Desde luego los datos no deben excluirse simplemente porque parezcan discrepar de alguna manera de los restantes datos, pero hay que comprobarlos meticulosamente en caso de que exista un error en alguna etapa entre la recogida de datos y su transferencia al ordenador. Cuando no sea así, es importante reconocer estos datos discrepantes y estimar cómo influyen en las interpretaciones que podrían hacerse.

Análisis ponderado

En ocasiones se sabe que los distintos valores de y tienen diferentes variancias residuales. Supongamos que se sabe, o se puede dar por sentado, que la variancia de y_i es σ^2/w_i , donde σ^2 es generalmente desconocida, pero se conocen los pesos w_i . En otras palabras, conocemos las precisiones *relativas* de las distintas observaciones. El procedimiento de corrección consiste en seguir el método general de regresión múltiple, sustituyendo todas las sumas como $\sum x_i$ y $\sum y_i$ por $\sum w_i x_i$ y $\sum w_i y_i$ (el subíndice i , que identifica cada observación, aquí se ha omitido para evitar la confusión con j que identifica una variable explicativa). De forma similar se ponderan todas las sumas de cuadrados y de productos: $\sum y_i^2$ es sustituido por $\sum w_i y_i^2$, $\sum x_i x_k$ por $\sum w_i x_i x_k$, y al calcular las sumas de cuadrados y de productos n es sustituida por $\sum w_i$ (v. (7.15)).

Los tests de la t , los tests de la F y los intervalos de confianza son entonces válidos. La MC residual es una estimación de σ^2 y, en ciertas situaciones, se puede contrastar frente a una estimación independiente de σ^2 . Por ejemplo, en la situación desarrollada en la página 307, donde las observaciones se recogen en grupos con combinaciones determinadas de valores de variables predictoras, se puede considerar que y_i es la media de n_i observaciones para una combinación específica de valores de x . La variancia de y_i es entonces σ^2/n_i y el análisis puede llevarse a cabo por regresión ponderada, con $w_i = n_i$. La MC residual será la misma que la obtenida de la línea (iii) del análisis de la página 307, y puede compararse (como se indica en párrafos anteriores) frente a la MC intragrupos de la línea (iv).

10.2. Regresión múltiple en grupos

Cuando cada observación pertenece a uno de los k grupos formados por una clasificación de un factor, pueden surgir problemas como los planteados en los apartados 9.4 y 9.5. ¿Pueden las ecuaciones con las mismas b (aunque tal vez con diferentes valores de a) ajustarse en los diferentes grupos o cada grupo debe tener su propio conjunto de valores de b ? (Esto es una generalización de la comparación de pendientes del apartado 9.4.) Si los mismos valores de b son apropiados para todos los grupos, ¿se puede usar la misma a (lo cual conduce a una sola ecuación para todos los datos) o cada grupo debe tener su propia a ? (Ésta es una generalización del análisis de covarianza del apartado 9.5.)

Los métodos de abordaje son ampliaciones bastante sencillas de los empleados previamente, por lo que se indicarán de forma breve. Supongamos que existen, en general, n observaciones recogidas en k grupos, con p variables predictoras observadas a lo largo de todo el proceso. Para examinar si los mismos valores de b son apropiados para todos los grupos, se puede deducir un análisis de variancia análogo al de la tabla 9.5 con la siguiente subdivisión de grados de libertad:

	gl
(i) Debidos a la regresión con valores de b comunes	p
(ii) Diferencias entre los valores de b	$p(k-1)$
(iii) Residuales con respecto a regresiones separadas	$n - (p+1)k$
Intragrupos	$n - k$

Los grados de libertad concuerdan con los de la tabla 9.5 cuando $p = 1$. La SC intragrupos es exactamente la misma que en la tabla 9.5. La SC de (iii) se obtiene ajustando una ecuación de regresión separada para cada uno de los k grupos y sumando las SC residuales resultantes. El residual del grupo i tiene $n_i - (p+1)$ gl, y éstos suman $n - (p+1)k$. La SC de (i) se obtiene por un simple cálculo de regresión múltiple usando las SC y las sumas de productos agrupados *intragrupos* a lo largo de todo el proceso; ésta es la generalización apropiada de la primera línea de la tabla 9.5. La SC de (ii) se obtiene por resta. Los gl, obtenidos también por resta, son verosímiles, ya que esta SC representa diferencias entre k valores de b_1 , entre k valores de b_2 , y así sucesivamente; existen p variables predictivas, correspondiendo cada una a $k-1$ gl.

Puede ser más conveniente disponer de una comparación bastante más específica de algunos coeficientes de regresión que la proporcionada por el test global descrito antes. Para un coeficiente determinado, b_j , por ejemplo, las k regresiones múltiples separadas proporcionan k valores, cada uno con su error tipo. A menudo bastarán unas comparaciones sencillas de éstos, usando por ejemplo (9.14) con pesos iguales a las recíprocas de las variancias de los valores separados.

El análisis de la covarianza supone valores comunes de b y examina las diferencias entre los valores de a . La SC corregida y sus grados de libertad se obtienen mediante la siguiente generalización de la tabla 9.6:

	SC corregida	gl
(iv) Entre grupos	Por restando	$k-1$
(v) Intragrupos	Residual respecto a la regresión intragrupos	$n - k - p$
(vi) Total	Residual respecto a la regresión total	$n - p - 1$

La SC total corregida (vi) se obtiene por un único cálculo de regresión múltiple para todos los datos, los gl son $n - p - 1$ como es habitual. La de (v) se obtiene como el residual para el cálculo de regresión usando sumas *intragrupos* de cuadros y productos; de hecho es el residual correspondiente al término de regresión (i) en la tabla anterior y es la suma de la SC para (ii) y (iii) en dicha tabla. La de (iv) se obtiene por resta. Las medias corregidas análogas a (9.35) se obtienen de la siguiente manera:

$$\bar{y}_i = \bar{y}_i + b_1(x_{01} - \bar{x}_{01}) + b_2(x_{02} - \bar{x}_{02}) + \dots + b_p(x_{0p} - \bar{x}_{0p}) \quad (10.24)$$

donde $b_1, b_2, \dots, b_p$ son los coeficientes de regresión intragrupos, y $\bar{x}_{ij}$ es la media de x_j en el grupo i . La diferencia corregida entre dos grupos, por ejemplo grupos 1 y 2, es:

$$\bar{y}_1 - \bar{y}_2 = (\bar{y}_1 - \bar{y}_2) - \sum_j b_j(\bar{x}_{1j} - \bar{x}_{2j}) \quad (10.25)$$

y su variancia estimada es:

$$\text{Var}(\bar{y}_1 - \bar{y}_2) = s_c^2 \left[\frac{1}{n_1} + \frac{1}{n_2} + \sum_j c_{jj}(\bar{x}_{1j} - \bar{x}_{2j})^2 + 2 \sum_{j \neq h} c_{jh}(\bar{x}_{1j} - \bar{x}_{2j})(\bar{x}_{1h} - \bar{x}_{2h}) \right] \quad (10.26)$$

El segundo sumatorio se define sobre todos los pares de variables predictoras. La fórmula general de (10.26) se obtiene de (3.13) y de (3.14), siendo las variancias y covariancias de los valores de b dados por (10.16) y (10.17). Los valores de c son los elementos de la matriz inversa obtenida en la regresión intragrupos, y s_c^2 es la SC residual de la línea (v) en la página 317.

Las técnicas de regresión múltiple ofrecen una alternativa para el análisis de la covariancia, posibilitando que todos los análisis se hagan por una aplicación de la regresión múltiple. Considérese en primer lugar el caso de dos grupos. Introduzcamos una nueva variable z , que recibe el valor 1 en todas las observaciones del grupo 1, y el valor 0 en todas las observaciones del grupo 2. Como modelo para los datos en conjunto, supóngase que:

$$E(y) = \alpha + \delta z + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p \quad (10.27)$$

Debido a la definición de z , (10.27) es equivalente a suponer que:

$$E(y) = \begin{cases} \alpha + \delta + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p & \text{para el grupo 1} \\ \alpha + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p & \text{para el grupo 2} \end{cases} \quad (10.28)$$

que es precisamente el modelo requerido para el análisis de la covariancia. Según (10.28), los coeficientes de regresión en las x son los mismos en ambos grupos, pero existe una diferencia δ entre las intersecciones. El test de significación habitual en el análisis de covariancia contrasta la hipótesis que afirma que $\delta = 0$. Como (10.27) y (10.28) son equivalentes, se deduce de (10.27) que el análisis en su totalidad puede ser ejecutado por una única regresión múltiple de y sobre $z, x_1, x_2, \dots, x_p$. La nueva variable, z se denomina *variable ficticia* o *indicadora*. El coeficiente δ es el de regresión parcial de y sobre z , y se estima de la manera habitual por el análisis de regresión múltiple, dando una estimación, por ejemplo d . La variancia de d se estima como siempre a partir de (10.16) y se obtienen los test y los límites

de confianza apropiados empleando la distribución de t . Nótese que la MC residual tiene $(n - p - 2)$ gl (puesto que la introducción de z aumenta el número de variables predictoras de p a $p + 1$) y que esto concuerda con (v) en la página 317 (siendo $k = 2$).

Cuando $k > 2$, el procedimiento descrito se generaliza por la introducción de $k - 1$ variables ficticias. Éstas pueden definirse de muchas maneras equivalentes. Un método conveniente es el siguiente. La tabla muestra los valores que toma cada una de las variables ficticias en todas las observaciones de cada grupo.

Grupo	Variables ficticias			
	z_1	z_2	$\dots$	z_{k-1}
1	1	0	$\dots$	0
2	0	1	$\dots$	0
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$k - 1$	0	0		1
k	0	0		0

El modelo especifica que:

$$E(y) = \alpha + \delta_1 z_1 + \dots + \delta_{k-1} z_{k-1} + \beta_1 x_1 + \dots + \beta_p x_p \quad (10.29)$$

y la ecuación de regresión múltiple ajustada es:

$$Y = a + d_1 z_1 + \dots + d_{k-1} z_{k-1} + b_1 x_1 + \dots + b_p x_p \quad (10.30)$$

Los coeficientes de regresión $d_1, d_2, \dots, d_{k-1}$ representan contrastes entre los valores medios de y para los grupos 1, 2, ..., $k - 1$ y para el grupo k , después de la corrección de las diferencias en las x . El test de significación global de la hipótesis nula según el cual $\delta_1 = \delta_2 = \dots = \delta_{k-1} = 0$ fue hecho previamente por el test de la F con $k - 1$ y $n - k - p$ gl ((iv) y (v) (en p. 317)). El procedimiento equivalente aquí es contrastar la significación global de $d_1, d_2, \dots, d_k$ suprimiendo las variables ficticias del análisis (p. 303). Esto conduce exactamente al mismo test de la F .

Si el investigador está interesado en un contraste entre el grupo k y uno de los demás grupos, se dispone inmediatamente de la d_i apropiada, con su error tipo dado por el análisis de regresión; en realidad, d_i es igual a la diferencia entre las medias corregidas $\bar{y}'_i - \bar{y}'_k$. En un contraste entre dos grupos distintos del grupo k , por ejemplo grupos 1 y 2, usaremos:

$$\bar{y}'_1 - \bar{y}'_2 = d_1 - d_2$$

y

$$\text{Var}(d_1 - d_2) = \text{Var}(d_1) + \text{Var}(d_2) - 2 \text{Cov}(d_1, d_2)$$

y obteniéndose las variancias y covariancias como de costumbre mediante (10.16) y (10.17).

Ejemplo 10.1 (continuación)

Los datos de la tabla 10.1 se han analizado hasta ahora como un grupo único. Sin embargo, la tabla 10.1 muestra una clasificación de los pacientes según el tipo de intervención quirúrgica, y deberíamos preguntarnos si una sola ecuación de regresión múltiple es apropiada para los tres grupos. En realidad, esta pregunta debería haber aparecido en una fase previa del análisis, antes de prestar atención al examen de la regresión global.

Se puede llevar a cabo un análisis exploratorio examinando los residuales, $y - Y$, de la tabla 10.1. Los valores medios de los residuales en los tres grupos son:

$$A: -2,53 \quad B: -0,46 \quad C: 4,60$$

Estos valores sugieren la posibilidad de que el tiempo medio de recuperación, para valores dados de x_1 y x_2 , aumente desde el grupo A, pasando por el grupo B, hasta el grupo C. Sin embargo, los residuales son muy variables y no está muy claro si dichas diferencias son significativas. Un problema adicional es si los coeficientes de regresión son constantes de un grupo a otro. Si los puntos en la figura 10.1b y c se distinguen según su pertenencia a los grupos A, B o C, existen ligeras sugerencias referidas a que las pendientes de las relaciones varían entre grupos, pero de nuevo la situación se halla lejos de ser bien definida.

Como primer paso en un análisis más formal, calculamos regresiones múltiples separadas para los tres grupos. Los resultados se resumen como sigue:

	Grupo A	Grupo B	Grupo C
n	20	20	13
$b_1 \pm ET(b_1)$	$7,83 \pm 13,78$	$22,76 \pm 9,19$	$36,16 \pm 15,86$
$b_2 \pm ET(b_2)$	$0,300 \pm 0,553$	$-1,043 \pm 0,469$	$-1,197 \pm 0,550$
SC residual	3.995,8	3.190,3	2.228,8
MC residual (gl)	235,0 (17)	187,7 (17)	222,9 (10)
$\bar{x}_1$	1,9150	2,0315	2,0515
$\bar{x}_2$	66,250	66,850	65,692
$\bar{y}$	18,400	22,800	29,154

Los valores residuales de $\bar{y}$ muestran diferencias en la misma dirección indicada en los residuales globales. Sin embargo, las diferencias se explican en parte por las diferencias en los valores de $\bar{x}_1$ y $\bar{x}_2$. Los valores predichos por las tres regresiones múltiples, para valores de x_1 y x_2 iguales a las medias globales, 1,9925 y 66,340, respectivamente, son:

$$A: 19,03 \quad B: 22,44 \quad C: 26,24$$

más próximos entre sí que las medias no ajustadas mostradas en la tabla anterior.

Existen diferencias considerables entre los coeficientes de regresión estimados a través de los tres grupos, pero los errores tipo son grandes. Usando los métodos citados en el apartado 9.4, podemos examinar la homogeneidad de cada coeficiente por separado, empleando las inversas de las variancias como coeficientes de ponderación. Esto da, como estadístico χ^2 aproximado con 2 gl, 1,86 para b_1 y 4,62 para b_2 , ninguno de ellos significativo a los niveles usuales. No podemos sumar estos estadísticos $\chi^2_{(2)}$, puesto que b_1 y b_2 no son independientes. Para un análisis más completo de la totalidad de los

lo que da rectas de pendientes e intersecciones diferentes para los dos grupos. El coeficiente γ_j es la diferencia entre las pendientes sobre x_j en los dos grupos. El test de significación global para la hipótesis nula que $\gamma_1 = \gamma_2 = \dots = \gamma_p = 0$ se examina eliminando las w_j variables de la regresión para obtener el test de la F con p y con $n - 2p - 2$ gl.

Cuando $k > 2$ el procedimiento anterior se generaliza deduciendo $p(k - 1)$ variables, $w_{ij} = z_i x_j$ y se obtiene un test global de regresiones paralelas en todos los grupos mediante el test compuesto de los coeficientes de regresión para todas las w_{ij} . Éste es un test de la F con $p(k - 1)$ y con $n - (p + 1)k$ gl.

En el procedimiento anterior el orden de introducción (o de eliminación) de las variables es crucial. La w_{ij} sólo debe incluirse en regresiones en las que también se incluyan las correspondientes variables z_i y x_j . Tres regresiones se ajustan secuencialmente en las siguientes variables:

- (i) $x_1, \dots, x_p$;
- (ii) $x_1, \dots, x_p, \quad z_1, \dots, z_k$;
- (iii) $x_1, \dots, x_p, \quad z_1, \dots, z_k, \quad w_{11}, \dots, w_{kp}$.

Estas tres regresiones a su vez corresponden a las figuras 9.4c, b y a, respectivamente.

En esta formulación podría haber motivo de preocupación sobre la colinealidad, ya que es probable que haya una correlación alta entre términos como w_{ij} y z_i . En el caso de los datos del ejemplo 10.1, ajustando todo el modelo con ocho variables, hubo valores del factor de inflación de la variable hasta 149. Esto podría haberse resuelto mediante el centrado, pero el análisis perdió una precisión carente de importancia, usando la regresión PROC REG del programa SAS, de modo que la colinealidad no causó una preocupación de orden práctico.

Ejemplo 10.3

El análisis de tres grupos de los ejemplos 9.3 y 9.4 puede efectuarse introduciendo dos variables ficticias: z_1 , que toma el valor 1 en el grupo A_1 y el valor 0 en los demás casos, y z_2 , que toma el valor 1 en el grupo A_2 y 0 en los demás casos. Como antes, y representa la capacidad vital, y x la edad. Se obtienen dos variables nuevas: $w_1 = xz_1$ y $w_2 = xz_2$. Las regresiones múltiples de y sobre x , de y sobre x, z_1 y z_2 , y de y sobre x, z_1, z_2, w_1 y w_2 dan la siguiente tabla de análisis de la variancia:

	gl	SC	MC	CV
1. Debido a la regresión en x	1	17,4446		
2. Debido a la introducción de z_1 y z_2 [= (4) - (1)]	2	0,1617	0,0808	0,22
3. Residual con respecto a la regresión en x, z_1 y z_2	80	30,0347	0,3754	
4. Debido a la regresión en x, z_1 y z_2	3	17,6063		
5. Debido a la introducción de w_1 y w_2 [= (6) - (4)]	2	2,4994	1,2497	3,54
6. Debido a la regresión en x, z_1, z_2, w_1 y w_2	5	20,1057		
7. Residual con respecto a la regresión en x, z_1, z_2, w_1 y w_2	78	27,5352	0,3530	
Total	83	47,6410		

Aparte de los errores de redondeo, las líneas 5 y 7 concuerdan con el análisis de la variancia en el ejemplo 9.3 de la página 284 y las líneas 2 y 3 son las mismas que en el ejemplo 9.4.

Para el modelo del análisis de la covariancia, los coeficientes de regresión parcial y sus errores tipo son los siguientes:

$$\begin{aligned}a &= 6,0449 \\d_1 &= -0,1169 \pm 0,2092 \\d_2 &= -0,0702 \pm 0,1487 \\b_1 &= -0,0398 \pm 0,0063 \quad (t = -6,29)\end{aligned}$$

Los coeficientes d_1 y d_2 son estimaciones de las diferencias corregidas entre los grupos A_1 y A_2 , respectivamente, y el grupo B; ninguna de estas diferencias es significativa. El coeficiente b_1 , que representa el efecto de la edad, es muy significativo.

Para el modelo con pendientes separadas los coeficientes son los siguientes (usando c para representar las estimaciones de γ):

$$\begin{aligned}a &= 5,6803 \\d_1 &= 2,5031 \pm 1,0418 \\d_2 &= 0,5497 \pm 0,5759 \\b_1 &= 0,0306 \pm 0,0075 \\c_1 &= 0,0545 \pm 0,0211 \\c_2 &= 0,0159 \pm 0,0145\end{aligned}$$

Los coeficientes c_1 y c_2 representan estimaciones de las diferencias en la pendiente sobre la edad entre los grupos A_1 y A_2 , respectivamente, y el grupo B. Como se ha señalado antes, hay diferencias significativas entre las pendientes ($F = 3,54$ con 2 y 78 gl, $P = 0,034$). Las estimaciones de las pendientes correspondientes a los grupos A_1 , A_2 y B son $-0,0306 - 0,0545 = -0,0851$, $-0,0306 - 0,0159 = 0,0465$ y $-0,0306$, respectivamente, que concuerdan con los valores encontrados anteriormente al ajustar las regresiones correspondientes a cada grupo por separado (p. 285).

10.3. Regresiones polinómicas y otras regresiones curvilíneas

Ya se mencionó en el apartado 10.1 la posibilidad de crear nuevas variables predictoras, definidas como los cuadrados de las variables existentes, para hacer frente a las relaciones no lineales o *curvilíneas*. Ésta es una idea importante, cuyo estudio resulta más fácil en situaciones en las que existe originalmente una sola variable predictora, x .

En lugar de la ecuación de regresión lineal:

$$E(y) = \alpha + \beta x \quad (10.33)$$

introducida en el apartado 5.2, consideramos el modelo *polinómico*:

$$E(y) = \alpha + \beta_1 x + \beta_2 x^2 + \dots + \beta_p x^p \quad (10.34)$$

La potencia más alta de x , simbolizada aquí por p , se denomina *grado* del polinomio. En la figura 10.3 se muestran algunas formas características de curvas polinómicas de grado bajo.




Fig. 10.4. Regresiones polinómicas ajustadas a los datos de la evolución de la población (tabla 10.3). $p = 1$ (—); $p = 3$ (---); $p = 5$ (....).

La tabla 10.3 muestra los valores predichos a partir de polinomios de hasta el sexto grado, y la figura 10.4 ilustra los ajustes obtenidos por las curvas lineal ($p = 1$), cúbica ($p = 3$) y de quinto grado ($p = 5$). Las entradas de la tabla 10.3 muestran que la MC residual se reduce considerablemente por la introducción de un término cúbico y esta curva parece, según la figura 10.4, proporcionar un ajuste excelente. Sin embargo, existen ligeras fluctuaciones sistemáticas de grupos de puntos adyacentes con respecto a la cúbica, y la tabla 10.3 muestra que la introducción de los términos de quinto grado produce una disminución significativa de la MC residual (ya que el valor de t de este coeficiente es significativo).

El proceso podría continuarse, pero es dudoso que pueda lograrse algún propósito útil. Estamos ante un dilema menor. No existe razón teórica alguna para esperar precisamente una curva polinómica más un error aleatorio. La cúbica es una aproximación a la curva suave de mejor ajuste, pero es posible obtener algunas (aunque significativas) mejoras introduciendo diversos términos de grado superior. Nótese que es evidente la mejora en el acuerdo entre los valores observados y los predichos en el período comprendido entre 1801 y 1971. La extrapolación o la predicción fuera de este período constituye otro asunto. La curva cúbica proporciona una concordancia adecuada entre los valores observados y los predichos de 1981. La curva de quinto grado es mucho menos satisfactoria. Éste es un hallazgo bastante común y aboga firmemente por el uso de un polinomio con el menor grado posible para un ajuste aceptable, aun cuando los términos de mayor grado proporcionen reducciones notables de la variación residual dentro de los límites ajustados.

Las distintas potencias de x , que forman las variables predictoras en (10.34), están correlacionadas entre sí, a menudo en grado sumo. En ocasiones esto produce dificultades de

cálculo debido a la colinealidad (apartado 10.1). Por lo general es posible vencer estas dificultades redefiniendo las potencias de x como desviaciones de sus propios valores medios o mediante el centrado (Healy, 1963).

Estas intercorrelaciones de las potencias de x significan que el coeficiente de una potencia determinada en la ecuación de regresión ajustada dependerá de que otras potencias estén presentes en la ecuación, como ocurre de hecho a menudo en la regresión múltiple. Si las potencias fuesen transformadas a un conjunto equivalente de variables predictoras que no estuviesen correlacionadas, deberíamos ser capaces de ajustar sucesivamente polinomios de mayor grado por métodos relativamente sencillos, sin volver a calcular los coeficientes obtenidos antes. Esto resulta práctico sobre todo cuando los valores de x están espaciados por intervalos iguales, como ocurre normalmente en los experimentos controlados (donde las x pueden representar las cantidades de alguna sustancia) o en series temporales (donde las x pueden ser puntos equidistantes de tiempo). El método emplea los denominados *polinomios ortogonales*. En Fisher y Yates (1963) se dan detalles completos y las tablas de referencia necesarias.

Los polinomios ortogonales proporcionan una manera útil de incorporar la regresión curvilínea en el análisis de la variancia de datos balanceados. Supongamos que cierto factor se representa por una variable x que se observa en k valores equidistantes,

$$x_1, x_2 = x_1 + h, \dots, x_k = x_1 + (k-1)h$$

Supongamos que existen n observaciones en cada grupo, y que los totales observados de y son:

$$T_1, T_2, \dots, T_k$$

Si $k = 2$, el coeficiente de regresión, b , de y sobre x , se calcula claramente por:

$$\frac{T_2 - T_1}{nh}$$

y la SC debida a la regresión con 1 gl coincide con la SC entre grupos, es decir:

$$\frac{(T_2 - T_1)^2}{2n}$$

(como en (7.10)).

Si $k = 3$, podríamos considerar una regresión cuadrática sobre x que se ajustaría exactamente a los datos, puesto que siempre es posible encontrar una curva cuadrática que pasa por tres puntos. Para obtener la ecuación de regresión, defínanse dos nuevas variables (los polinomios ortogonales):

$$\begin{aligned} X_1 &= (x - \bar{x})/h \\ X_2 &= 3X_1^2 - 2 \end{aligned} \quad (10.35)$$

de modo que X_1 tome los valores $-1, 0$ y 1 , y X_2 tome los valores $1, -2$ y 1 . La ecuación de regresión puede expresarse:

$$Y = \bar{y} + b_1 X_1 + b_2 X_2 \quad (10.36)$$

donde:

$$b_1 = (T_3 - T_1)/2n$$

y

$$b_2 = (T_3 - 2T_2 + T_1)/6n$$

La ecuación puede expresarse en base a x y x^2 sustituyendo (10.35) en (10.36).

Las SC debidas a los términos lineal y cuadrático (que son independientes, cada una con 1 gl, y que totalizan la SC entre grupos) son:

$$S_1 = \frac{(T_3 - T_1)^2}{2n}$$

y

$$S_2 = \frac{(T_3 - 2T_2 + T_1)^2}{6n}$$

El método puede generalizarse claramente para valores más altos de k (v. tabla A18 de Snedecor y Cochran (1989)). Los aspectos más útiles de la generalización son las SC de los términos lineal y cuadrático. Éstos toman la forma $(\sum \lambda_i T_i)^2 / \sum \lambda_i^2$, donde para el término lineal las λ_i son enteros centrados con respecto al cero (p. ej., -1, 0, 1 para $k = 3$; -3, -1, 1, 3 para $k = 4$). Para el término cuadrático cada λ_i se obtiene elevando al cuadrado la λ_i correspondiente para el término lineal, restando la media de los valores así obtenidos y multiplicando por una constante práctica, si esto es necesario para obtener valores enteros. Estas SC explican 2 gl del total de los $(k - 1)$ gl entre grupos. Los $(k - 3)$ gl restantes representan desviaciones con respecto a la curva cuadrática y se pueden contrastar frente al residual apropiado del análisis. Si es necesario se pueden aislar sucesivamente el término cúbico y los de mayor orden hasta que la MC de las desviaciones alcance un nivel suficientemente bajo.

A veces se encuentran algunas formas de tendencia curvilínea, distintas a las representadas por los polinomios. En la figura 10.5 se ilustran dos ejemplos. El primero de ellos es una *regresión asintótica*, en la que la recta de regresión se aproxima exponencialmente a un límite superior o inferior. La ecuación de regresión es entonces no lineal en los coeficientes y el método de ajuste se vuelve más complejo (v. Draper y Smith, 1981, cap. 10).

El segundo ejemplo ilustrado en la figura 10.5 es una *regresión periódica*, en la que la ecuación de regresión subyacente tiene la forma senoidal:

$$Y = \alpha_0 + \alpha_1 \sin(\beta x + \gamma) \quad (10.37)$$

Esto representa una curva cíclica con amplitud $\pm \alpha_1$ y la longitud de onda $360/\beta$ (si los ángulos se miden en grados).

La regresión periódica es analizada ampliamente por Bliss (1958). Una tendencia cíclica no puede describirse siempre por una simple curva senoidal. En el apartado 10.6 se exponen situaciones más complejas (v. sobre todo el ejemplo 10.9). Sin embargo, a veces es posible aplicar el modelo más simple y es útil, a modo de alternativa, a la hipótesis nula según la cual no existe una tendencia cíclica.

Un ejemplo de este tipo de test fue presentado por Edwards (1961) para examinar la periodicidad en una serie de recuentos efectuados en puntos de tiempo equidistantes. Descri-




Fig. 10.5. Dos formas de regresión no lineal. a) asintótica; b) periódica.

bimos aquí una ligera variante del test de Edwards, desarrollado por Smith (1961). Supóngase que existen k recuentos N_i , con un recuento total de $N = \sum N_i$. Por ejemplo, se pueden clasificar los episodios neurológicos por la hora del día ($k = 24$), o las anomalías congénitas por el mes de nacimiento ($k = 12$).

Si la ecuación de regresión (10.37) debe tener un ciclo completo de k intervalos de tiempo, se puede expresar en la forma alternativa:

$$E(N_i) = \alpha_0 + \beta_1 \sin \theta_i + \beta_2 \cos \theta_i$$

donde $\theta_i = (i - 1/2) (360/k)$. Aquí α_0 representa el recuento medio, y β_1 y β_2 determinan conjuntamente la amplitud y la fase de la curva senoidal. Con $k = 12$, por ejemplo, $\theta_1 = 15^\circ$, $\theta_2 = 45^\circ$, y así sucesivamente. Considérese ahora una regresión múltiple de N_i sobre $\sin \theta_i$ y $\cos \theta_i$. Se puede demostrar que estas dos variables explicativas son ortogonales, y la SC de N_i debida a la regresión es, por lo tanto, la suma de las dos SC en regresiones simples sobre las dos variables por separado. Se puede considerar que la variación residual de las N_i tiene una distribución de Poisson, y es posible estimar la variancia residual por el recuento medio, $\bar{N}$. Si la SC de la regresión se divide por $\bar{N}$, el estadístico resultante se distribuye aproximadamente como $\chi^2_{(2)}$. Es:

$$(2/\bar{N}) [(\sum N_i \sin \theta_i)^2 + (\sum N_i \cos \theta_i)^2] \quad (10.38)$$

St. Leger (1876) demostró que la aproximación de (10.38) a la distribución de la $\chi^2_{(2)}$ no es satisfactoria con N menor de 200 y dio valores mejorados para los niveles de significación.

Walter y Elwood (1975) ampliaron el método para hacer frente a magnitudes desiguales de intervalos de tiempo y para una población variable de un riesgo. Esto hace que el segundo ejemplo dado, el de las anomalías congénitas por mes de nacimiento, sea más apropiado, ya que se pueden tener en cuenta el número diferente de días en un mes y las variaciones en las cantidades de nacimientos de un mes a otro.

10.4. Regresión múltiple en el análisis de datos no ortogonales

El análisis de la variancia se empleó en el capítulo 8 para estudiar los efectos separados de diversos factores, para datos clasificados en diseños que presentan algún grado de equilibrio. Estos denominados *diseños ortogonales* permiten que en el mismo análisis se presenten simultáneamente las sumas de los cuadrados que representan diferentes fuentes de variación. Como se observó en el apartado 8.8, la no ortogonalidad en un diseño produce muchas veces considerables complicaciones en el análisis.

La regresión múltiple, introducida en el apartado 10.1, es un método potente para estudiar los efectos simultáneos de diversas variables predictoras sobre una variable aleatoria y no requiere condiciones especiales de equilibrio en sus valores. Como hemos visto, el efecto de cualquier variable o de cualquier grupo de variables se puede mostrar por un análisis de la variancia. Por lo tanto, podríamos esperar que los métodos de regresión múltiple fueran útiles para el análisis de los datos clasificados en un diseño desbalanceado. En el apartado 10.2 se consideró el análisis de covariancia como un caso particular de regresión múltiple, siendo representada la clasificación en grupos por un sistema de variables ficticias. Se puede adoptar este planteamiento para cualquier factor con dos o más niveles. Se obtiene un test de significación para cualquier factor efectuando dos regresiones múltiples: en primer lugar, incluyendo las variables falsas que representan el factor, y en segundo lugar, sin dichas variables. Para un análisis completo de cualquier conjunto de datos pueden requerirse muchas regresiones múltiples.

Ejemplo 10.5

Consideramos los datos de la tabla 8.14, los cuales se analizaron por métodos especiales apropiados para tablas de dos entradas, si bien también habríamos podido adoptar el método general descrito anteriormente. Definiremos las siguientes variables ficticias:

$$x_1 = \begin{cases} 1 & \text{para el grupo control} \\ 0 & \text{para el grupo tratado} \end{cases}$$

$$x_2 = \begin{cases} 1 & \text{para el grupo de edad de 40 años o más} \\ 0 & \text{para los demás casos} \end{cases}$$

$$x_3 = \begin{cases} 1 & \text{para el grupo de edad de 50 años o más} \\ 0 & \text{para los demás casos} \end{cases}$$

Estas variables representan los efectos principales de los dos factores, tratamiento y edad; para tener en cuenta una posible interacción necesitamos otras dos variables:

$$x_4 = x_1 x_2$$

y

$$x_5 = x_1 x_3$$

La variable dependiente y es el número de accidentes; las distribuciones de frecuencias de y se muestran en la tabla 8.14. El número total de observaciones es 41. A modo de ejemplo de la especificación de las variables, el único sujeto del grupo control de 40 años o más, tiene los siguientes valores:

x_1	x_2	x_3	x_4	x_5	y
1	1	0	1	0	1

Para obtener la SC requerida para el análisis de la variancia indicado en la tabla 8.15, necesitaremos las regresiones múltiples mostradas en la tabla 10.4. En muchos programas informáticos éstas pueden solicitarse como parte de la misma tarea.

La SC residual de a es 17,0350, la misma que la residual intracasillas de la tabla 8.15, puesto que las cinco variables ficticias, x_1 a x_5 , explican exactamente las diferencias entre las seis casillas. La diferencia entre b y a es 0,0243 con 2 gl, la misma que la SC de la interacción $T \times E$ en la tabla 8.15. Habiendo visto, por el test de la F dada en la tabla 8.15 que la interacción no es significativa, examinamos los tratamientos por la diferencia $c - b$ que es 5,8706 con 1 gl es decir, esencialmente la misma que la SC de tratamientos corregida de la tabla 8.15. A modo de test de la edad, $d - b = 1,9407$ con 2 gl, lo cual coincide de nuevo con la SC de la edad de la tabla 8.15.

Muchos paquetes estadísticos tienen programas para efectuar este tipo de análisis. A menudo se usa el nombre *modelo lineal general* y debe distinguirse del *modelo lineal generalizado*, más complejo, que se describirá en el apartado 12.8. Al interpretar los resultados de un análisis de este tipo hay que tener cuidado de asegurarse de que el test del efecto de un factor determinado no quede distorsionado por la presencia o la ausencia de factores correlacionados. En particular, en los datos con una estructura factorial, debe tenerse en cuenta la advertencia dada en la página 244, contra el examen de los efectos principales en presencia de interacciones que impliquen los factores pertinentes.

Freund et al. (1986) describen cuatro maneras diferentes mediante las que es posible calcular las SC en modelos lineales generales. En resumen, el tipo I resulta adecuado cuando se introducen los factores en un orden predeterminado; el tipo II muestra la contribución de cada factor en presencia de todos los demás, excepto las interacciones que implican a dicho factor; en los tipos III y IV, las interacciones definidas en el modelo se conservan incluso para examinar los efectos principales. Los autores defienden el tipo III, lo cual contradice el consejo dado antes, aunque no habría dificultades si el modelo se definiera explícitamente sin interacciones. El tipo II corresponde a una estrategia más encomiable que consiste en contrastar las interacciones en presencia de efectos principales, bien contrastando estos efectos principales sin interacciones (si éstas se pueden ignorar sin peligro), bien no estudiando efecto principal alguno (si se considera que hay interacciones).

Tabla 10.4. Regresiones múltiples requeridas para el análisis de los datos de la tabla 8.14.

Regresión	SC residual	gl
y en x_1, x_2, x_3, x_4, x_5	17,0350 (a)	35
y en x_1, x_2, x_3	17,0593 (b)	37
y en x_1, x_3	22,9299 (c)	38
y en x_1	19,0000 (d)	39

10.5. Métodos multivariantes

En la regresión múltiple cada individuo aporta observaciones simultáneas de diversas variables; así, estos datos son *multivariantes*. A pesar de ello, sólo una de éstas, la variable dependiente, puede considerarse una variable aleatoria, y el propósito del análisis es explicar, tanto como sea posible, la variación de dicha variable dependiente en términos de múltiples variables predictoras. La regresión múltiple es, por lo tanto, una extensión de los otros métodos ya considerados en esta obra y, en esencia, no incorpora nuevos conceptos fuera de los introducidos en el capítulo 5 para una regresión lineal simple con una sola variable independiente. La función de las variables predictoras en la regresión múltiple es clasificar los individuos de modo que se asemeja bastante a las clasificaciones cualitativas en un diseño experimental.

El *análisis multivariante* es un conjunto de técnicas apropiadas para situaciones en las que se tiene que estudiar simultáneamente la variación debida al azar de diversas variables. El tema es amplio y se trata en muchas obras; los textos de Kendall (1980) Chatfield y Collins (1980) y Krzanowski son introductorios, y los de Mardia et al (1979) son más avanzados. Si bien no podemos ahondar aquí en detalles, en este apartado presentamos una breve revisión de algunos de los métodos que se han mostrado útiles en la investigación médica.

Un punto general que se ha de señalar es que los tests de significación desempeñan un papel mucho menos importante en el análisis multivariante que en el univariante. Como se señaló en el comentario 3 de la página 91, a menudo un test de significación univariante resulta de utilidad para obtener una indicación inmediata de la dirección probable de una desviación con respecto a la hipótesis nula. Con los datos multivariantes no es posible una interpretación simple de este tipo. Si, por ejemplo, un test de significación muestra que es inverosímil que dos muestras multivariantes provengan de la misma población, es posible que no resulte evidente en qué sentido son diferentes: si, por ejemplo, hay diferencias claras en cada una de las variantes de los componentes o sólo en algunas de ellas. Por consiguiente, en los métodos que se describen a continuación lo más importante es la estimación, es decir, tratar de describir la naturaleza de la estructura de los datos. No obstante, los tests de significación a veces desempeñan un papel humilde, en particular en análisis preliminares de datos antes de aplicar más métodos de investigación, y describiremos algunas de las técnicas más útiles.

Componentes principales

A menudo se efectúan observaciones sobre un número mediano o grande de variables para cada individuo, a pesar de que el número de variables que se requiere determinar en cada individuo sea mucho menor. Por ejemplo, en la página 10 se muestra un cuestionario que incluye seis preguntas distintas acerca del estrés o la angustia. El propósito de estas distintas preguntas podría ser obtener información sobre el estrés o la angustia total del individuo sin preocuparse por la razón que los ha motivado. Se plantean varias preguntas sólo porque con una sola no conseguiríamos nuestro propósito. En ocasiones conocemos lo suficiente el campo de aplicación para permitirnos calcular un resultado o una variable combinada; por ejemplo, las respuestas a las seis preguntas mencionadas pueden combinarse promediándolas para obtener una variable más simple, «estrés». En otros casos necesitaremos un análisis para determinar cuáles son las variables que pueden combinarse.

Supóngase que tenemos observaciones sobre p variables, $x_1, x_2, \dots, x_p$, hechas en cada uno de n individuos. Podemos preguntarnos si sería posible combinar estas variables para que resultara un número menor de ellas que nos diese prácticamente toda la información sobre las diferencias entre los individuos. Una manera de expresarlo es definir nuevas variables:

$$\begin{aligned} y_1 &= a_{11}x_1 + a_{12}x_2 + \dots + a_{1p}x_p \\ y_2 &= a_{21}x_1 + a_{22}x_2 + \dots + a_{2p}x_p \end{aligned} \quad (10.39)$$

etc., de modo que y_1 tenga la mayor variancia posible y así represente mejor que cualquier otra combinación lineal de las x las diferencias generales entre los individuos. (Si no establecemos restricciones en los valores de a_{ij} esto resulta un requerimiento inútil, ya que valores más grandes de los coeficientes nos llevarán a una mayor variancia de y_1 ; por eso nosotros estandarizamos su magnitud general requiriendo que $\sum_{j=1}^p a_{ij}^2 = 1$). Entonces podríamos escoger y_2 tal que no se correlacionase con y_1 y que tenga la siguiente mayor variancia, y así sucesivamente. Si $p = 3$, las observaciones pueden representarse en un diagrama tridimensional con n puntos, tal vez aglomerados con la forma de una aeronave. El primer *componente principal*, y_1 , representará las distancias del largo de la aeronave. El segundo componente, y_2 , representará las distancias en la dirección más ancha perpendicular a la longitud (p. ej., de un lado al otro); el tercero y último componente, y_3 , representará entonces la distancia desde lo más alto hasta lo más bajo de la nave. En general hay p componentes principales, pero la variación de todos, exceptuando unos pocos, puede ser bastante pequeña. Si en el ejemplo anterior la aeronave fuera muy plana, casi como un disco, y_3 tendría una variación muy pequeña y la determinación de la posición de un individuo en el diagrama podría hacerse casi perfectamente mediante y_1 e y_2 .

El método de análisis implica el cálculo de raíces latentes de la covariancia o matriz de correlación. La mayoría de los ordenadores tienen programas estándar con este fin. Es importante destacar que si se cambia la escala de medida de cualquier factor, incluso por un factor multiplicador, todos los resultados cambian. Ello ha llevado a algunos autores a estandarizar desde el inicio cada variable dividiéndola por su desviación tipo, lo cual equivale a trabajar con la matriz de correlación.

La interpretación de cualquiera de los componentes, por ejemplo el j , definido por (10.39), implica la consideración de los valores relativos de los coeficientes a_{ij} de dicho componente. Si todos los coeficientes fuesen aproximadamente iguales, el componente podría entonces interpretarse como un promedio de todas las variables. Si algunos coeficientes fuesen pequeños, podrían ignorarse entonces las variables correspondientes a interpretar el componente basándose en un subconjunto de las variables originales. La aplicación del método sólo habrá reducido útilmente la dimensionalidad de los datos si los componentes pueden interpretarse de modo tal que representen algunas características significativas. Por lo tanto, la interpretación es, hasta cierto punto, subjetiva y requiere el conocimiento del campo de aplicación.

Dado que la interpretación de cada componente se efectúa en términos de las variables originales, sería más ilustrativo evaluar cada componente en términos de sus correlaciones con dichas variables, en lugar de hacerlo en términos de los coeficientes a_{ij} . Estas correlaciones para los componentes principales calculados se obtienen a partir de la matriz de correlación multiplicando cada componente por la raíz cuadrada de la raíz latente correspondiente.

Tales correlaciones se denominan *correlaciones de componentes* o *pesos*, aunque la segunda denominación se usa a veces para los coeficientes de la fórmula (10.39).

Otro aspecto del análisis es decidir el número de componentes que se van a incluir. Si bien se han sugerido diversos métodos, ninguno de ellos ha sido aceptado universalmente; la elección se efectúa teniendo en cuenta la interpretación de los componentes. Pocas veces vale la pena incluir un nuevo componente, excepto si es posible darle una interpretación razonable.

Una vez decidido el número de componentes que ha de incluirse, los datos se habrán disminuido efectivamente a un número igual de dimensiones; por ejemplo, si se aceptan dos componentes, se considera que las observaciones caen en un espacio bidimensional y que se ignoran las $p - 2$ dimensiones restantes de las variables originales. Un punto en el espacio bidimensional se representa mediante las coordenadas con respecto a dos ejes; usando la representación (10.39) el punto sería (y_1, y_2) . Hay, sin embargo, muchas maneras de construir los ejes. Restringiéndonos a ejes ortogonales, es decir ejes que forman un ángulo recto entre sí, se podría rotar el par de ejes con respecto al origen, con lo cual no cambiaría la relación ortogonal entre ellos. Las coordenadas de un punto cambiarían, por ejemplo a (y'_1, y'_2) , pero la configuración geométrica de los puntos quedaría inalterada. De acuerdo con (10.39) deberíamos tener:

$$\begin{aligned} y'_1 &= a'_{11}x_1 + a'_{12}x_2 + \dots + a'_{1p}x_p \\ y'_2 &= a'_{21}x_1 + a'_{22}x_2 + \dots + a'_{2p}x_p \end{aligned} \quad (10.40)$$

etcétera. Si encontráramos una rotación tal que los componentes definidos en (10.40) pudiesen interpretarse más fácilmente que los de (10.39) habríamos mejorado el análisis. Se han propuesto algunos criterios para elegir una rotación, pero el más ampliamente usado es el método *varimax*. En este método el objetivo es que para cada componente los coeficientes se dividan en dos grupos, con los más cercanos a cero en un grupo, y los más grandes en el otro. Esto es, cada componente expresa un subconjunto de las variables originales con el mínimo de contaminación de las variables no pertenecientes a dicho subconjunto. Los componentes rotados ya no son principales, y la relación entre los coeficientes de (10.40) y las correlaciones de los componentes es más complicada que la de los componentes principales.

Siempre que los componentes se hayan estandarizados para tener una variancia unitaria antes de aplicar el procedimiento de rotación, resulta que los componentes rotados no se correlacionan con otros.

Se puede emplear la ecuación (10.39) o la (10.40) para asignar valores de cada componente para cada individuo. Estos valores se denominan *puntuaciones de los componentes* y se pueden usar en pasos adicionales del análisis en lugar de todo el conjunto de variables x . Algunas veces, por ejemplo, las puntuaciones de los componentes se emplean como un conjunto reducido de variables independientes en un análisis de regresión de otras variables no consideradas en el análisis de componentes principales.

Ejemplo 10.6

Cockcroft et al (1982) en un ensayo clínico registraron las respuestas a 20 preguntas diseñadas para caracterizar a los pacientes con insuficiencia respiratoria crónica según los efectos de su enfermedad en la vida diaria. Las respuestas se registraron uniendo con una línea dos afirmaciones contrarias

Variable	10	11	12	13	14	15	16	17	18	19
1 Buen estado de salud										
2 Optimista con respecto al futuro										
3 Nunca me falta el aire										
4 La falta de aire no me molesta										
5 Toso raramente										
6 La tos no me molesta										
7 Nunca respiro con silbidos										
8 Raramente me siento enfermo										
9 Mi estado ha mejorado										
10 Nunca me preocupo por el futuro										
11 Confío en que puedo luchar por las cosas	0,71									
12 La salud depende de mí	0,26	0,46								
13 Vale la pena intentar cualquier cosa	0,32	0,21	-0,02							
14 Mi mujer está contenta de mi situación	0,01	0,11	0,20	-0,11						
15 Tengo ganas de salir	0,12	-0,02	-0,20	0,31	-0,29					
16 Me relajo con otras personas	0,24	0,15	-0,01	0,59	-0,07	0,50				
17 Mantengo a la familia	0,03	0,04	-0,03	0,03	0,43	-0,13	-0,09			
18 Hago una contribución útil	0,21	0,63	0,50	0,09	0,05	-0,18	0,05	0,09		
19 Acepto mi situación	0,52	0,27	0,17	0,08	0,30	-0,26	0,22	0,25	0,23	
20 Me siento feliz	0,28	0,18	0,04	-0,03	-0,23	0,20	0,07	-0,11	0,18	0,27

variables en los componentes (10.39) son óptimos, es posible que esto ocurra sólo en un conjunto determinado de datos. Cuantitativamente, los componentes no son necesariamente generalizables fuera del conjunto de datos, a pesar de que pudieran serlo cualitativamente. Podría ser preferible escoger pesos iguales en cada componente después de verificar que los subconjuntos de variables que definen cada componente son razonables, con el objetivo de lograr una mayor capacidad de generalización y de estandarización entre los investigadores.

Análisis por factores

Este método ha sido ampliamente empleado por los psicólogos. Está estrechamente relacionado con el análisis de componentes principales, pero se diferencia de él en que supone un modelo definido para el modo en que las variables observadas x_i son influidas por ciertos factores hipotéticos subyacentes. Supóngase que las x_i son pruebas educativas aplicadas a niños y que cada prueba refleja de modo distinto ciertos factores, por ejemplo, inteligencia general, facilidad verbal, habilidad aritmética, velocidad de trabajo, etc. Imaginemos que cada individuo tiene un valor para cada uno de estos factores comunes, $f_1, f_2, f_3, \dots$, los cuales no se correlacionan, pero que no pueden medirse directamente. El modelo de análisis del factorial es:

$$\begin{aligned}x_1 &= b_{11}f_1 + b_{12}f_2 + b_{13}f_3 + \dots + \mu_1 + \varepsilon_1 \\x_2 &= b_{21}f_1 + b_{22}f_2 + b_{23}f_3 + \dots + \mu_2 + \varepsilon_2\end{aligned}\tag{10.41}$$

etc. Aquí μ_i es la media de x_i y ε_i es el residual específico del test de la i después de tomar en consideración las contribuciones de los factores. Los valores de los factores, $f_1, f_2, f_3, \dots$ varían de un individuo a otro, pero tienen como media cero y una variancia igual a 1. Se supone que no están correlacionados entre sí ni con los residuales. Los valores b_{ij} son constantes, como los coeficientes de regresión, que indican en qué medida es afectado cada test por cada factor. Los factores b_{ij} se denominan *pesos de los factores*; si las x_i se estandarizan a una media igual a cero y una variancia igual a 1, los pesos de los factores b_{ij} es la correlación entre el test de la i y el factor j . La variancia en x_i que es explicada por el modelo de factores (10.41) se denomina *comunalidad*; para x_i estandarizadas la comunalidad es la proporción de variancia explicada.

Los pesos de los factores, las comunalidades y el número de factores requeridos deben estimarse a partir de los datos, generalmente de la matriz de correlación muestral. Obviamente no se pueden emplear métodos de regresión múltiple porque se desconocen los valores de las f . Una buena explicación se encuentra en Lawley y Maxwell (1971). Si el modelo básico se puede justificar mediante fundamentos psicológicos, cabe esperar que un análisis factorial aporte alguna noción sobre el número de factores que aparentemente afectan las puntuaciones de los tests y que muestre qué tests están más estrechamente relacionados con ciertos factores. El lugar del análisis de factores en otros campos científicos es muy dudoso. A veces se usa en situaciones para las cuales pueden resultar más apropiados métodos multivariantes más sencillos, con menos supuestos. Por ejemplo, la interpretación que hacemos de los pesos de los factores es generalmente muy similar a la de los coeficientes de los primeros componentes principales.

Análisis discriminante

Supóngase que tenemos k grupos de individuos con n_i individuos en el grupo i y que en cada individuo medimos p variables, $x_1, x_2, \dots, x_p$. Necesitamos una regla para discriminar entre los grupos, de modo que para cualquier nuevo individuo que se sabe que procede de un grupo (siendo desconocido el grupo en particular), se podría aplicar la regla y asignar el individuo al grupo más apropiado. Esta situación puede darse en estudios taxonómicos en las que las x son medidas físicas y los grupos son especies. La regla asignaría entonces cada nuevo individuo a una especie u otra, dependiendo de sus características físicas. Otro ejemplo podría ser su aplicación en el diagnóstico diferencial. Se harían observaciones en pacientes reconocidos como pertenecientes a grupos diagnósticos determinados. El objetivo sería definir una regla para asignar cada nuevo paciente a uno de estos grupos midiendo las mismas variables. En cada uno de estos ejemplos y en todas las aplicaciones de funciones discriminantes, la clasificación original en grupos se debe hacer independientemente de las variables x . En la situación diagnóstica, por ejemplo, el diagnóstico de los pacientes podría determinarse por procedimientos firmes pero arduos, y es posible que se desee comprobar la fiabilidad con que pueden conseguirse los mismos diagnósticos usando variables (las x) que son más baratas o menos molestas para el paciente. Alternativamente, es posible que los diagnósticos correctos se consigan sólo con el transcurso del tiempo y que se desee determinarlos mediante variables medidas en estadios precoces de la enfermedad.

Consideremos en primer lugar la situación en que $k = 2$, llamando a los dos grupos A y B. Podemos abordar el problema desde tres puntos de vista distintos, cada uno de los cuales nos llevará a la misma solución.

1. Función discriminante lineal de Fisher

Supóngase que buscamos una función lineal:

$$z = b_1x_1 + b_2x_2 + \dots + b_px_p \quad (10.42)$$

Si ésta va a ser útil para discriminar bien entre los grupos, podríamos esperar que los valores medios de z en los dos grupos estén razonablemente separados en comparación con la variación de z intragrupos. Podemos, por lo tanto, tratar de buscar valores de las b tales que el cociente:

$$D^2 = \frac{(\bar{z}_A - \bar{z}_B)^2}{\text{variancia de } z \text{ intragrupos}} \quad 10.43$$

sea lo mayor posible. La variancia estimada de z será, en general, distinta en los dos grupos, pero podemos calcular una estimación agrupada como en el test de la t para dos muestras.

La solución a este problema es la siguiente:

- a) Calcular las sumas agrupadas de cuadrados y de productos de las x intragrupos, dividir por $n_A + n_B - 2$ para obtener la matriz de variancias y covariancias intragrupos, y obtener la matriz inversa cuyo término general llamaremos c_{ij} . Aquí, n_A y n_B son el número de individuos en los grupos A y B, respectivamente.
- b) Calcular las b del modo siguiente:

$$\begin{aligned}
 b_1 &= c_{11}(\bar{x}_{A1} - \bar{x}_{B1}) + c_{12}(\bar{x}_{A2} - \bar{x}_{B2}) + \dots + c_{1p}(\bar{x}_{Ap} - \bar{x}_{Bp}) \\
 b_2 &= c_{21}(\bar{x}_{A1} - \bar{x}_{B1}) + c_{22}(\bar{x}_{A2} - \bar{x}_{B2}) + \dots + c_{2p}(\bar{x}_{Ap} - \bar{x}_{Bp}) \\
 &\vdots \\
 b_p &= c_{p1}(\bar{x}_{A1} - \bar{x}_{B1}) + c_{p2}(\bar{x}_{A2} - \bar{x}_{B2}) + \dots + c_{pp}(\bar{x}_{Ap} - \bar{x}_{Bp})
 \end{aligned} \tag{10.44}$$

Aquí $\bar{x}_{Ai}$ es la media de x_i en el grupo A y así sucesivamente.

Para usar (10.42) a fin de asignar futuros individuos a uno de los dos grupos mencionados, necesitamos un punto de corte para discriminar entre A y B. Una regla completamente simétrica sería usar la media, z_0 , de $\bar{z}_A$ y $\bar{z}_B$, a partir de (10.42)

$$\begin{aligned}
 \bar{z}_A &= b_1 \bar{x}_{A1} + b_2 \bar{x}_{A2} + \dots + b_p \bar{x}_{Ap} \\
 \bar{z}_B &= b_1 \bar{x}_{B1} + b_2 \bar{x}_{B2} + \dots + b_p \bar{x}_{Bp}
 \end{aligned} \tag{10.45}$$

y, por consiguiente,

$$z_0 = b_1 \left(\frac{\bar{x}_{A1} + \bar{x}_{B1}}{2} \right) + b_2 \left(\frac{\bar{x}_{A2} + \bar{x}_{B2}}{2} \right) + \dots + b_p \left(\frac{\bar{x}_{Ap} + \bar{x}_{Bp}}{2} \right) \tag{10.46}$$

Si $z_A > z_B$, la regla de asignación será: asignar un individuo a A si $z > z_0$ y a B si $z < z_0$. Muchos programas de ordenador calculan el valor de z de cada individuo en las dos muestras originales. Así pues, es posible contar cuántos individuos de ambos grupos habrían sido clasificados erróneamente por esta regla de asignación. Desafortunadamente esto da una visión demasiado optimista, dado que la regla de asignación se ha determinado para ser la mejor (en cierto sentido) para estas dos muestras en particular y es probable que en promedio se comporte algo peor con observaciones posteriores de ambos grupos (v. Hills, 1966).

La regla de asignación basada en z_0 se ha concebido para reducir al mínimo la suma de dos probabilidades de mala clasificación (la de asignar a un individuo del grupo A al grupo B y la de asignar a un individuo del grupo B al grupo A). Dos situaciones nos llevan a ciertas modificaciones. En la primera supóngase que los individuos provienen de una población en la que se sabe, por experiencia previa, que la proporción en la categoría A, p_A , es diferente a la de la categoría B, $p_B (= 1 - p_A)$. Entonces sería razonable tener esto en cuenta cambiando el punto de corte para aumentar la probabilidad de asignación al grupo con la mayor probabilidad *a priori*. Ésta es una situación en la que puede aplicarse el teorema de Bayes (apartado 2.8) para ajustar las probabilidades *a priori* usando las observaciones en un individuo para obtener probabilidades *a posteriori*. Si se escoge este método podría aumentarse el punto de corte en $\ln(p_B/p_A)$, suponiendo nuevamente que $z_A > z_B$ (de otro modo el punto de corte debería disminuirse). En segundo lugar, las consecuencias de una clasificación equivocada podrían no ser simétricas. En un *diagnóstico de cribado* (v. apartado 16.4), por ejemplo, las consecuencias de pasar por alto un caso de enfermedad (falso negativo) podrían ser más graves que clasificar erróneamente como enfermo a un individuo sano (falso positivo). En el primer caso el tratamiento podría retrasarse varios meses y, de esta forma, empeorar mucho el pronóstico, mientras que en el segundo es posible que el individuo sufra sólo el inconveniente de someterse a más pruebas antes de ser clasificado como sano. Si se pudieran cuantificar las consecuencias de los dos tipos de clasificación errónea, el objetivo de la discriminación sería reducir al mínimo el valor esperado de esta puntuación en cada individuo.

A menudo estas puntuaciones se denominan costes, pero esta terminología no implica que los resultados deban expresarse en términos monetarios. Si c_A es la penalización al fallar en la clasificación de un individuo A en su grupo A y c_B se define de modo análogo, entonces el punto de corte se puede aumentar en $\ln(c_B/c_A)$. De este modo sólo necesitamos el cociente entre las dos penalizaciones.

Otro modo de valorar la eficacia de la discriminación consiste en calcular la razón D^2 a partir de (10.43). Su raíz cuadrada, D , se denomina *distancia generalizada*, o *distancia de Mahalanobis*, entre los dos grupos. Si D es mayor que aproximadamente 4, la situación es similar a dos distribuciones univariantes cuyas medias difieren en más de 4 desviaciones tipo: la superposición es bastante pequeña y las posibilidades de clasificación errónea son igualmente pequeñas. Una fórmula alternativa de D^2 , equivalente a (10.43), es:

$$D^2 = \sum b_i (\bar{x}_{Ai} - \bar{x}_{Bi}) \quad (10.47)$$

2. Regla de verosimilitud

Si se tuviera una sola variable, x , que siguiera una distribución continua en cada grupo, sería natural asignar un individuo al grupo que diera la mayor densidad de probabilidad para el valor observado de x ; otro modo de expresarlo es diciendo que la asignación se hace al grupo de mayor verosimilitud. Si hay varias x no podemos representar con facilidad la densidad de probabilidad, pero dada la forma matemática de la distribución de las x es posible calcular esta densidad o verosimilitud. Un caso particular es la *distribución normal multivariante*; ésta implica, entre otras cosas, que cada x por separado sigue una distribución normal y que todas las regresiones de una variable sobre cualquier grupo de otras variables son lineales. Si las x siguieran distribuciones normales multivariantes con las mismas variancias y correlaciones en el grupo A y en el grupo B, pero con distintas medias, se encontraría que la razón de las verosimilitudes de A y B depende de una función lineal:

$$z = \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

y las β serían estimadas de las dos muestras iniciales precisamente mediante las b , como se calculó en el apartado 1. La regla descrita en dicho apartado, en la cual la asignación se hace a A o a B según que $z > z_0$ o que $z < z_0$, es equivalente a preguntarse cuál de los dos grupos tiene mayor verosimilitud estimada.

En la práctica, desde luego, las distribuciones multivariantes no son corrientes y, tal vez, lo son menos que las distribuciones univariantes. No obstante, la función discriminante (10.42) parece ser un buen indicador de las verosimilitudes relativas de los dos grupos.

3. Regresión con una variable dependiente ficticia

Supóngase que definimos una variable y que toma el valor 1 en el grupo A y 0 en el grupo B. Juntando todas las observaciones en un solo grupo, podríamos hacer la regresión múltiple de y en $x_1, x_2, \dots, x_p$. Ello daría una función lineal de las x , la cual predeciría los valores observados de y lo mejor posible. Si el coeficiente de correlación múltiple es suficientemente alto, los valores predichos de y en los grupos A y B deberían estar bastante separados (agrupán-

dose cerca de los valores observados de 1 y 0). Se puede demostrar que la función de regresión estimada es (excepto en un valor constante) la misma que la función lineal discriminante obtenida por el método del apartado 1. Ésta es una identidad útil puesto que el método 3 puede hacerse en un ordenador con un programa de regresión múltiple, mientras que el método 1 requiere un programa especial.

Otra ventaja del método de regresión es que el test habitual del cociente de la variancia para la significación de la regresión múltiple puede interpretarse también como un test válido para la función discriminante. La hipótesis nula es que en los dos grupos de los que se extraen las muestras, las x tienen exactamente la misma distribución conjunta; en este caso, por supuesto, no puede hacerse discriminación alguna. Además los habituales tests de la t de los coeficientes de regresión parcial muestran eficazmente la importancia de determinadas variables en la discriminación.

Aunque la regresión múltiple es un buen método para el cálculo de la función discriminante, es importante advertir que el modelo habitual de regresión múltiple ya no es válido. Generalmente, en la regresión múltiple y es una variable aleatoria y las x son variables arbitrarias. En nuestro problema, la x son variables aleatorias e y es un valor arbitrario que caracteriza los dos grupos. Relacionado con ello podemos decir que el valor promedio de y para un determinado conjunto de x no debe interpretarse como la probabilidad de que un individuo con esas x sea asignado al grupo A y no al grupo B; si la ecuación de regresión se interpretara de esta forma, podría llevarnos a predecir algunas probabilidades mayores que 1 o menores que 0.

El análisis habitual de la variancia de y correspondiente al análisis de regresión múltiple es un buen método de estimación de la distancia generalizada, D :

$$D^2 = \frac{(n_A + n_B)(n_A + n_B - 2)}{n_A n_B} \times \frac{\text{SC debida a regresión}}{\text{SC con respecto a regresión}} \quad (10.48)$$

Es fácil obtener programas informáticos para el cálculo y , como para todos los métodos multivariantes, la disponibilidad de un *software* adecuado es esencial. Con el propósito de ilustrar el método consideraremos un ejemplo con dos variables.

Ejemplo 10.7

Los datos de la tabla 10.7 pertenecen a 79 niños afectados de enfermedad hemolítica del recién nacido, de los cuales 63 sobrevivieron y 16 murieron. En cada niño se registró la concentración de hemoglobina en el cordón, x (medida en g/100 ml) y la concentración de bilirrubina, y (mg/100 ml). Queremos predecir, mediante estos dos valores, si un niño determinado tiene más probabilidad de sobrevivir o de morir.

Siguiendo el método 1, la matriz de la covariancia intragrupos y su inversa son:

	8,3641	- 1,6851
	- 1,6851	1,6061
y	0,151602	0,159057
	0,159057	0,789510

Tabla 10.7. Concentraciones de hemoglobina y bilirrubina en niños afectados por la enfermedad hemolítica del recién nacido. x : hemoglobina (g/100 ml); y : bilirrubina (mg/100 ml).

<i>Supervivientes (n = 63)</i>							
x	y	x	y	x	y	x	y
18,7	2,2	15,8	3,7	14,3	3,3	11,8	4,5
17,8	2,7	15,8	3,0	14,1	3,7	11,6	3,7
17,8	2,5	15,8	1,7	14,0	5,8	10,9	3,5
17,6	4,1	15,6	1,4	13,9	2,9	10,9	4,1
17,6	3,2	15,6	2,0	13,8	3,7	10,9	1,5
17,6	1,0	15,6	1,6	13,6	2,3	10,8	3,3
17,5	1,6	15,4	4,1	13,5	2,1	10,6	3,4
17,4	1,8	15,4	2,2	13,4	2,3	10,5	6,3
17,4	2,4	15,3	2,0	13,3	1,8	10,2	3,3
17,0	0,4	15,1	3,2	12,5	4,5	9,9	4,0
17,0	1,6	14,8	1,8	12,3	5,0	9,8	4,2
16,6	3,6	14,7	3,7	12,2	3,5	9,7	4,9
16,3	4,1	14,7	3,0	12,2	2,4	8,7	5,5
16,1	2,0	14,6	5,0	12,0	2,8	7,4	3,0
16,0	2,6	14,3	3,8	12,0	3,5	5,7	4,6
16,0	0,8	14,3	4,2	11,8	2,3		
						875,5	194,7

Fallecidos (n = 16)

x	y	x	y
15,8	1,8	7,1	5,6
12,3	5,6	6,7	5,9
9,5	3,6	5,7	6,2
9,4	3,8	5,5	4,8
9,2	5,6	5,3	4,8
8,8	5,6	5,3	2,8
7,6	4,7	5,1	5,8
7,4	6,8	3,4	3,9
		124,1	77,3

Sumas de cuadrados y de productos intragrupos

	S_{xx}	S_{xy}	S_{yy}
Supervivientes	500,6593	- 108,4219	96,6943
Fallecidos	143,3794	- 21,3281	26,9744
Agrupados	644,0387	- 129,7500	123,6687
Variancia/covariancia	8,3641	- 1,6851	1,6061

Las medias y sus diferencias y medias son:

	$\bar{x}$	$\bar{y}$
Supervivientes	13,897	3,090
Fallecidos	7,756	4,831
Diferencia $S - F$	6,141	- 1,741
Media, $\frac{1}{2} (S + F)$	10,827	3,961

De (10.44) se deduce,

$$T^2 = \left(\frac{n_A n_B}{n_A + n_B} \right) D^2 \quad (10.50)$$

Éste es el cuadrado del máximo valor posible de t que podría obtenerse en un test de la t para dos muestras en cualquier combinación lineal de las p variables. Si la hipótesis nula fuese cierta,

$$\frac{(n_A + n_B - p - 1)}{(n_A + n_B - 2)p} T^2 \quad (10.51)$$

sigue la distribución F con p y $n_A + n_B - p - 1$ gl. Si $p = 1$, (10.51) se reduce al cuadrado del estadístico t habitual.

En el ejemplo 10.7 no es realmente importante efectuar un test de significación, ya que la figura 10.6 muestra con claridad que las dos distribuciones bivariantes difieren significativamente. Sin embargo, como ilustración de los cálculos, tenemos:

$$T^2 = \left(\frac{63 \times 16}{79} \right) \times 4,709 = 60,08$$

y, puesto que $p = 2$, $76T^2/(77 \times 2) = 29,65$ se remite a la distribución F con 2 y 76 gl, lo cual da una $P < 0,001$. La diferencia es muy significativa, como se esperaba. En la mayoría de las aplicaciones del test de la T^2 de Hotelling resulta útil explorar más cualquier resultado significativo mediante el cálculo de la distribución discriminante, para demostrar la mejor manera en que se combinan las variantes para revelar la diferencia entre los grupos.

Datos apareados: estadístico de la T^2 para una muestra de Hotelling

En la mayoría de los problemas de discriminación, en particular cuando el objetivo consiste en obtener reglas de asignación, los individuos de las dos poblaciones no estarán apareados o emparejados de ninguna manera. Sin embargo, en las situaciones relacionadas explicadas antes, en que los tratamientos se comparan con datos multivariantes, es muy posible que las observaciones individuales estén apareadas. Por ejemplo, podrían administrarse dos tratamientos en diferentes ocasiones y observar las respuestas clínicas de cada aplicación del tratamiento. O bien, con un tratamiento único, podrían hacerse observaciones antes y después de su administración.

En este tipo de estudios es natural trabajar con las diferencias, bien entre dos tratamientos, bien entre las lecturas antes y después del tratamiento. Cada sujeto proporcionará un conjunto multivariante de diferencias, $d_1, d_2, \dots, d_p$ y las preguntas naturales que se plantean son las siguientes: a) ¿hay algún indicio de que los valores esperados de las diferencias sean distintos de cero? y b) si es así, ¿cuál es la naturaleza de estos efectos?

El procedimiento es una variante simple de los métodos para dos muestras descritos anteriormente. Supóngase que hay n sujetos, cada uno de los cuales proporciona un conjunto multivariante de p diferencias, d_i . Las sumas de cuadrados y productos corregidos de las d se calculan de la manera habitual y las variancias y covariancias estimadas se obtienen dividiendo por $n - 1$. Se obtiene la matriz inversa, con el término general c_{ij} . Los coeficientes b_i de la función discriminante se calculan como en (10.44), pero sustituyendo los términos $x_{Ai} - x_{Bi}$ de (10.44) por las diferencias medias d_i . A continuación se obtiene el test estadístico como:

$$T^2 = n \cdot b \cdot d_i \quad (10.52)$$

Finalmente, si la hipótesis nula es cierta,

$$\frac{(n-p)T^2}{p(n-1)} \quad (10.53)$$

sigue la distribución F con p y con $n-p$ grados de libertad. Si el resultado es significativo, los coeficientes de la función discriminante indicarán la manera en que las variantes se combinan para dar el efecto más significativo.

Ejemplo 10.8

La tabla 10.8 muestra datos seleccionados de un pequeño ensayo clínico piloto efectuado con el fin de comparar la eficacia y la inocuidad de varios tratamientos para la prevención de la anemia en lactantes prematuros durante los primeros meses de vida. La tabla se refiere a 10 lactantes que recibieron un tratamiento determinado y presenta las mediciones de cuatro variables tomadas cuando los niños te-

Tabla 10.8. Mediciones de eficacia y seguridad en 10 lactantes prematuros que recibieron tratamiento para la prevención de la anemia.

Edad (días)	Hemoglobina (g/dl)		Plaquetas ($\times 10^9/l$)		Leucocitos ($\times 10^9/l$)		Presión arterial sistólica (mmHg)	
	25	50	25	50	25	50	25	50
Número de paciente								
1	10,5	10,5	700	596	8,0	9,8	71	65
2	10,4	11,4	363	370	16,0	7,6	54	68
3	10,4	10,2	456	645	10,9	16,1	67	69
4	15,6	13,3	260	301	8,6	8,0	77	82
5	16,3	13,9	387	385	8,4	11,1	60	60
6	11,2	10,2	375	431	13,1	12,6	65	75
7	11,8	10,3	472	337	15,0	10,4	71	69
8	12,8	12,8	469	244	16,2	9,9	61	63
9	10,3	9,1	381	505	16,3	13,0	72	70
10	8,9	11,2	526	539	11,8	8,7	57	65

Cambios desde el día 25^o hasta el día 50^o

	Hemoglobina d_1	Plaquetas $\times 10^{-1}$ d_2	Log leucocitos $\times 10, d_3$	Presión arterial sistólica d_4
1	0,0	- 1,0	0,9	- 6
2	1,0	0,1	- 3,2	14
3	- 0,2	1,9	1,7	2
4	- 2,3	0,4	- 0,3	5
5	- 2,4	0,0	1,2	0
6	- 1,0	0,6	- 0,2	10
7	- 1,5	- 1,4	- 1,6	- 2
8	0,0	- 2,2	- 2,1	2
9	- 1,2	1,2	- 1,0	- 2
10	2,3	0,1	- 1,3	8

$L_3 - L_1 = -(Z_1 + Z_2)$.] Si se representan las observaciones: *a*) con W_1 y W_2 como ejes, y *b*) con Z_1 y Z_2 como ejes, se verá que los diagramas de puntos son básicamente similares, difiriendo sólo en la orientación y la escala de los ejes. Así pues, el uso de ambas funciones canónicas es equivalente al método de la verosimilitud. En general, usando $k - 1$ funciones canónicas se obtiene la misma discriminación que con el método de la verosimilitud. La idea que nos lleva a usar funciones canónicas es reducir la dimensionalidad, y la única ventaja de este método reside en, si es posible, usar sólo unas pocas variables sin perder la capacidad de discriminación. Para profundizar más en este punto véase Marriott (1974).

Sistemas de puntuación mediante funciones canónicas

Supóngase que se mide una variable en una escala de p valores desde 1 hasta p . Por ejemplo, la respuesta de un paciente al tratamiento puede graduarse en categorías desde «mucho peor» (valor 1) hasta «mucho mejor» (valor p). Esta secuencia de enteros equidistantes puede no ser la mejor escala para el análisis de los datos. El mejor método de puntuación dependerá de los criterios que se desee optimizar. Supongamos, por ejemplo, que los pacientes se clasifican en k grupos de tratamiento. Sería razonable escoger un sistema de puntuación que aumentara al máximo las diferencias entre tratamientos en comparación con las diferencias intratratamientos. Con tal fin considérese un conjunto de p variables ficticias $x_1, x_2, \dots, x_p$, tal que si un paciente se clasifica en la categoría j , su valor de x_j es 1, y el de todas las otras x_i es 0. Ahora escojamos la primera variable canónica de las x , por ejemplo:

$$g = l_1 x_1 + l_2 x_2 + \dots + l_p x_p$$

Entonces, g tomará el valor l_j en la categoría j y definirá el sistema que aumenta al máximo la razón de las SC entre grupos con respecto a la intragrupos. No hay, sin embargo, garantías de que las puntuaciones sigan en magnitud el orden natural de las categorías. Bradley et al (1962) han demostrado cómo puede elevarse al máximo la razón entre las SC siempre y cuando no existan inversiones en el orden natural.

Es posible que el investigador desee un sistema de puntuación que esté lo más correlacionado posible con alguna otra variable. Por ejemplo, en los experimentos dosis-respuesta en serología, se puede clasificar una respuesta como $--, -, 0, +$ o $++$, y puede ser útil cambiar estas categorías por una puntuación que presente una buena regresión lineal con el logaritmo de la dosis de algún reactivo. El método es parecido al empleado en el problema previo, debiéndose maximizar la SC debida a la regresión con respecto a la SC total (para un ejemplo, v. Ipsen, 1955).

Análisis de conglomerados (análisis de clusters)

El análisis de componentes y el análisis de factores son métodos «internos» de análisis en los cuales los individuos no se clasifican por criterios que no sean las variables usadas en el análisis. En algunos problemas no se impone un agrupamiento inicial de los datos; sin embargo, el objetivo del análisis es determinar si se puede formar un sistema natural de grupos con los individuos. Es posible que no se especifique por adelantado el número de grupos que se desean. Desde luego, los grupos pueden establecerse de modo absolutamente arbitrario, pero

el investigador busca un sistema mediante el cual los individuos de un mismo grupo se asemejen entre sí (en los valores que toman las variables) más que los de otros grupos. Esta explicación es bastante vaga, pero hay diversos modos de definir grupos que la hacen más explícita. Además de los capítulos correspondientes de Chatfield y Collins (1980), Kendall (1980) y Krzanowski (1988), un texto introductorio sobre el tema es el de Everitt (1980), mientras que un tratamiento más matemático puede encontrarse en Mardia et al (1979, cap. 13).

Se pueden distinguir ampliamente dos planteamientos. El primero consiste en realizar un análisis de componentes principales de todos los datos. Si la mayor parte de la variación es explicable por los dos o tres primeros componentes, se pueden ver las características principales de una dispersión multidimensional en un diagrama de puntos bidimensional o, tal vez, en una representación bidimensional de un modelo tridimensional. De esta forma se evidenciará cualquier agrupación de los individuos –al menos en sus características principales– aunque podrán cuestionarse las definiciones precisas de los grupos. Si la dispersión no es representada en gran parte por los dos o tres primeros componentes, el método será mucho menos útil.

Un planteamiento muy parecido es el del *análisis de correspondencias* (desarrollado extensamente en Francia con el nombre de *analyse des correspondances*). En este caso, las variables son categóricas y pueden representarse por variables falsas o indicadoras, como en la página 318. Las funciones lineales de las variables indicadoras se seleccionan de modo que la dispersión multidimensional sea aproximada de la mejor forma posible por un diagrama con un número reducido de dimensiones (generalmente dos). Los individuos de una categoría concreta de respuesta pueden representarse por un punto en este diagrama y, así, identificar fácilmente conglomerados interesantes de individuos. Greenacre (1984) proporciona una explicación muy completa sobre el tema y una lista (pp. 317 y 318) de algunas referencias de aplicaciones médicas.

El segundo planteamiento, el de la *taxonomía numérica*, es analizado con detalle por Sneath y Sokal (1973). La idea es calcular un índice de similitud o de disimilitud para cada par de individuos. La definición precisa de este índice dependerá de la naturaleza de las variables. Si se registran todas las variables en una escala continua, un buen índice de disimilitud podría ser la distancia en un espacio multidimensional entre los dos puntos cuyas coordenadas son los valores de las variables de dos individuos; este índice es la distancia euclídea. Si, como en algunas aplicaciones clínicas, las variables son dicotómicas (que expresan la presencia o la ausencia de alguna característica), un buen índice de similitud podría ser la proporción de variables en las que los dos individuos muestran la misma respuesta. Otras medidas son estudiadas ampliamente por Sneath y Sokal. Una vez calculados los índices de similitud se efectúa una especie de ordenación de modo que los individuos con valores más altos de dicho índice se clasifiquen en el mismo grupo. Una vez elegido un método de formación de conglomerados, este proceso se puede efectuar con un ordenador.

Una aplicación médica que se nos ocurre es la definición de un sistema de enfermedades relacionadas. Hayhoe et al (1964), por ejemplo, han estudiado la clasificación de las leucemias agudas desde este punto de vista. La utilidad de dichos métodos dependerá de que las clasificaciones resultantes sean útiles en la realidad. Por ejemplo, sería deseable que la definición de categorías de enfermedades hiciera sugerencias sobre su etiología, recomendaciones sobre su futuro tratamiento o, al menos, proporcionara un sistema útil de contabilización de las

estadísticas de supervivencia. Uno de los problemas en las aplicaciones médicas es cómo definir en general los grupos que se hayan creado por el método de formación de conglomerados. No bastará, desde luego, una lista de individuos pertenecientes a los grupos y se requieren algunas definiciones más generales.

El análisis de conglomerados también puede usarse para agrupar variables en lugar de individuos, esto es, crear grupos de variables de modo que las de un mismo grupo, midan la misma característica de los individuos, o una muy parecida, mientras que los distintos grupos expresen características diferentes. Este objetivo es parecido al del análisis de componentes principales, y cuando las variables se miden en una escala continua, probablemente sea mejor para dicho fin este segundo método. Por ejemplo, si aplicamos el análisis de conglomerados a los datos del ejemplo 10.6, los grupos resultantes de variables son muy parecidos a los obtenidos usando los componentes principales.

Los diversos métodos para definir grupos darán generalmente resultados distintos cuando se apliquen a los mismos datos. El método más apropiado en un caso determinado depende de la estructura de los datos, la cual a menudo es desconocida. Efectivamente, cada método obliga a supuestos implícitos sobre el tipo de agrupamiento esperado y, si estos supuestos no son válidos, los resultados carecerán de significado. Por ello sugerimos emplear el análisis de conglomerados sólo en los casos en que otros métodos multivariantes resulten inapropiados e interpretar los resultados con gran cautela.

Para finalizar, cabe señalar que el método de análisis de grupos no debe confundirse con el problema de determinar si los casos de una enfermedad se producen en conglomerados a lo largo del tiempo, del espacio o en familias. Este problema debe abordarse por otros métodos, que se consideran en el apartado 16.5.

Escalas multidimensionales

Supóngase que se dispone de datos de un conjunto de individuos y que es posible deducir un índice de similitud o de disimilitud entre cada par de individuos. Este índice podría ser parecido a los considerados en la exposición del análisis de conglomerados. El método de escalas multidimensionales es un modo de disponer a los individuos en un espacio de pocas dimensiones de modo que las distancias entre los puntos en el espacio sean aproximadamente las mismas que las medidas de disimilitud. En particular, si con dos dimensiones obtenemos una representación adecuada, es posible representar a los individuos en un gráfico bidimensional y, a partir de la observación de cómo los individuos quedan organizados en dicho gráfico, efectuar alguna interpretación útil. Por ejemplo, los individuos pueden haber quedado dispuestos en grupos.

Este método, al igual que otros muchos métodos multivariantes, es un intento de reducir la dimensionalidad. Si se miden las disimilitudes usando un conjunto de variables continuas, tiene un objetivo parecido al análisis de componentes principales.

Para más detalles sobre este método véanse Chatfield y Collins (1980).

Consideraciones finales

Todos los métodos multivariantes requieren muchos cálculos y su aplicación se ha extendido sólo en las dos últimas décadas. El desarrollo de programas informáticos ha hecho que

correctiva para prevenir cambios peligrosamente grandes. La predicción y el control también son importantes en las estadísticas vitales, por ejemplo, en el control de malformaciones congénitas.

Puede considerarse que el problema de las series temporales es de regresión —la medida en cuestión sería una variable dependiente, con el tiempo como variable explicativa—, pero los métodos descritos en los capítulos 5 y 9 y en los apartados precedentes de este capítulo no parecen ser muy útiles. En primer lugar, las tendencias mostradas por las series a largo plazo no parecen ser representables por las simples funciones matemáticas consideradas hasta ahora. En segundo lugar, aunque es probable que las observaciones individuales muestren fluctuaciones aparentemente aleatorias con respecto a cualquier tendencia a largo plazo, es improbable que estas desviaciones se distribuyan de forma independiente. Si una observación de una variable fisiológica es algo mayor que la tendencia general, es probable que las observaciones vecinas también sean algo mayores que las esperadas. Esta forma de correlación entre los componentes aleatorios de las observaciones vecinas se denomina *correlación en serie*. Algunas veces el efecto puede ser el contrario. En una serie de notificaciones de una enfermedad infecciosa en años sucesivos, un valor alto en un año determinado puede asociarse a valores bajos en los años adyacentes, porque un alto porcentaje de la población adquiere inmunidad durante los años de incidencia elevada. En ocasiones, el efecto aparente de la correlación en serie puede extenderse a observaciones separadas por varias unidades de tiempo, aunque en general se encuentra que cuanto mayor es el lapso de tiempo entre las observaciones apareadas, menor es el valor absoluto de la correlación en serie.

Para vencer estos problemas se han desarrollado varios métodos de análisis estadístico, basados en modelos algo más complicados que los de la regresión simple. Sus detalles son demasiado complejos para describirlos en su totalidad aquí. Daremos sólo un breve repaso a dos tipos de planteamientos generales. Para más detalles véase Chatfield (1989) o Diggle (1990).

Conviene distinguir entre los análisis de *dominio temporal* y los de *dominio de frecuencias*. Los dos enfoques son, de hecho, matemáticamente equivalentes, en el sentido que un tipo de análisis puede derivarse del otro. Sin embargo, cada uno de ellos destaca distintas características de una serie temporal, y puede ser útil considerarlos por separado. El dominio temporal explica relaciones entre observaciones realizadas en distintos tiempos, en particular correlaciones en serie con diferentes retrasos. En el dominio de frecuencias, las observaciones se consideran compuestas por contribuciones de términos periódicos con distintas frecuencias. El análisis en este caso se refiere a las dimensiones relativas con distintas frecuencias, como en la descomposición espectral de la luz.

Antes de adentrarnos en estos dos planteamientos vale la pena citar algunos puntos elementales:

1. En el análisis de cualquier serie temporal es importante representar los datos antes de hacer cálculos. Una inspección visual puede revelar características de los datos, como la heterogeneidad de distintas secciones o una distribución enormemente no normal, que podría afectar la elección del método de análisis (en el último caso tal vez proceda una transformación inicial de los datos).
2. Buscar valores muy alejados del resto e investigar si hay alguna razón especial para una lectura aberrante que justifique su exclusión.

3. Muchas series muestran una clara tendencia a largo plazo. A menudo es útil suprimirla desde el comienzo, ajustando una recta u otra curva sencilla o tomando las diferencias entre observaciones sucesivas. Entonces el análisis de series temporales puede aplicarse a los residuales con respecto la curva ajustada o a las diferencias sucesivas.

Dominio temporal

Una clase importante de modelos es la de las *series autorregresivas*. Aquí, el valor esperado de la variable dependiente en cualquier momento depende en parte de los valores en momentos previos en el tiempo. En el más simple de estos modelos, el esquema *autorregresivo de primer orden* (o de *Markov*), la dependencia es sólo con respecto a la observación inmediatamente precedente. Si Y_t indica la desviación con respecto a la media a largo plazo en el momento t , el proceso de primer orden puede expresarse por la ecuación:

$$Y_t = \rho Y_{t-1} + \varepsilon_t$$

donde ε_t son errores aleatorios, distribuidos independientemente alrededor de una media igual a cero. Si la serie ha de ser estacionaria, o sea que debe mantener las mismas propiedades estadísticas a lo largo del tiempo, el coeficiente ρ debe estar entre -1 y $+1$. Si la variancia de Y_t es σ^2 , la variancia de ε_t será $\sigma^2(1 - \rho^2)$. La correlación entre los valores adyacentes de Y_t es ρ , y entre los valores separados por un retraso de k unidades de tiempo es ρ^k . Así, valores de ρ cercanos a $+1$ conducen a series en las que las observaciones de puntos vecinos tienden a estar cerca entre sí, mientras que tramos más largos de la serie presentan características más dispares. Este cese de comportamiento ilustra el peligro de aplicar métodos estadísticos tipo a diferentes porciones de una serie temporal. Con un valor alto de ρ sería muy fácil encontrar dos grupos, cada uno de ellos, por ejemplo, de cinco observaciones adyacentes, tales que hubiera poca variación dentro de cada grupo, pero con una gran diferencia entre las dos medias. Un test de la t para dos muestras podría mostrar una diferencia «significativa» pero el nivel de probabilidad no tendría un sentido útil porque el supuesto de independencia que se necesita para un test de la t no se cumple. Este punto reviste particular importancia cuando los dos conjuntos difieren en alguna característica específica, como la presencia de un tipo de intervención entre los dos períodos. No puede atribuirse una diferencia «significativa» al efecto de dicha intervención, ya que es posible que reflejase simplemente la estructura de una serie temporal que es estacionaria a largo plazo. Por el contrario, valores de ρ cercanos a -1 muestran una oscilación notoria entre valores vecinos, posibilidad que ya fue indicada en la página 355.

El proceso de primer orden fue propuesto por Wilson et al (1981) como representación de mediciones repetidas de la presión arterial hechas con intervalos de 5 minutos. Sin embargo, su análisis funcionaba sólo con series cortas y no queda claro que resulte apropiado con series más largas. Marks (1982) utilizó series autorregresivas más generales, con dependencia en más de una lectura previa, en un estudio sobre las relaciones entre diferentes niveles hormonales en ratas que recibían inyecciones hormonales después de una ooforectomía. Este estudio ilustra la manera en que los modelos autorregresivos, en los que los valores previos actúan como variables explicativas, también pueden incorporar otras variables explicativas como los valores actuales o los previos en otras series temporales.

Otro amplio conjunto de modelos es el de los esquemas de *medias móviles*. Si x_1, x_2, x_3 , etc., son variables aleatorias independientes, las cantidades

$$y_2 = \frac{1}{3}(x_1 + x_2 + x_3), y_3 = \frac{1}{3}(x_2 + x_3 + x_4), \text{ etc.}$$

son ejemplos de promedios móviles simples. Nótese que y_2 e y_3 están correlacionados, debido a los términos comunes x_2 y x_3 , pero y_2 e y_5 no están correlacionados, ya que no tienen términos en común. La serie y_i es un ejemplo sencillo de un esquema de medias móviles, pudiéndose obtener esquemas más generales cambiando el número de x para cada y y también sus pesos. Aunque las series temporales no suelen formarse de manera explícita tomando simplemente medias móviles, pueden encontrarse, sin embargo, series de un comportamiento similar, que muestran correlaciones positivas en un intervalo estrecho de observaciones vecinas. Es posible obtener una amplia variedad de modelos diferentes para las series temporales combinando las características autorregresivas y de medias móviles. Para más explicaciones sobre cómo distinguir entre los distintos modelos, véanse Box y Jenkins (1976).

Ya hemos hecho referencia al problema de la monitorización de series temporales de mediciones clínicas o de otra índole con la intención de detectar cambios en el patrón estadístico. La mayoría de las aplicaciones médicas han adoptado métodos derivados del control de calidad industrial, en la cual por lo general se supone que las observaciones varían independientemente. Así, Weatherall y Haskey (1976) describen métodos para controlar la incidencia de malformaciones congénitas, usando cartas de control de calidad, diseñados para detectar lecturas aberrantes, y métodos de sumas acumuladas (cusum) diseñados para detectar cambios en la tasa de incidencia media. En esta aplicación se puede dar por sentado que la variación aleatoria sigue la distribución de Poisson. Rowlands et al (1983) describen la aplicación de métodos similares para controlar datos usados en el radioinmunoanálisis de rutina de la progesterona. En muchos casos no será válido el supuesto de independencia en series. Smith et al (1983) y Trimble et al (1983) describen un abordaje bayesiano para monitorizar los valores de creatinina plasmática en individuos sometidos a trasplante renal. Con la formulación de un modelo específico para sus datos obtienen la probabilidad de que, en cualquier fase, el proceso esté en un estado de evolución estacionario, de que se ha producido un cambio en el nivel de respuesta o en la pendiente o de que la observación realizada quede muy alejada del resto.

Dominio de frecuencias

En este método se descompone la serie temporal en varios componentes periódicos de una forma senoidal como en el modelo de regresión periódica del apartado 10.3. Luego se hacen deducciones sobre las amplitudes de ondas de distintas frecuencias. El primer método que vamos a considerar, el análisis armónico, se refiere a fluctuaciones periódicas con frecuencias predeterminadas. El segundo método, el análisis espectral, permite estudiar simultáneamente toda la banda de frecuencias.

Análisis armónico

Si se tienen k observaciones separadas por intervalos de tiempos regulares, se puede reproducir exactamente todo el conjunto de datos en base a k parámetros, a saber un parámetro para

su papel habitual. Como se ha señalado en el apartado 8.4, el elemento de aleatorización en la elección de un determinado cuadrado latino asegura que las deducciones sobre los efectos del tratamiento sean válidas, tanto si la respuesta sigue un modelo aditivo como si no lo hace.

Tratamientos invariables en el tiempo

En muchas investigaciones cada sujeto recibe el mismo tratamiento durante todo el período de estudio, en el cual se miden las respuestas en diversas ocasiones. Los distintos individuos pueden recibir tratamientos diferentes o pueden clasificarse de otras maneras. Un ejemplo sería un experimento que incluyera una prueba de tolerancia a la glucosa, en la que se efectúan mediciones de la glucemia en intervalos de una hora después de la ingestión de glucosa. Los individuos podrían clasificarse según el diagnóstico clínico y también por la posible administración de agentes hipoglucemiantes orales.

En estudios de este tipo la atención puede dirigirse a: *a)* la descripción precisa de la tendencia de la respuesta en el tiempo o *b)* los contrastes entre distintos grupos de sujetos, o a ambos. Analizaremos ambos casos por separado.

Tendencias temporales y curvas de crecimiento

Hemos mencionado brevemente dos ejemplos de este tipo al referirnos a los estudios longitudinales en el apartado 6.2: el crecimiento y el desarrollo de los niños a lo largo de un período de 10 años y los cambios en la presión arterial durante el embarazo. Cuando hay una tendencia clara y sistemática en la respuesta en función del tiempo, esta tendencia recibe a menudo el nombre de *curva de crecimiento*. La tendencia puede ser aproximadamente lineal, pero con frecuencia habrá un indicio claro de curvatura y puede sugerirse el ajuste de un polinomio de orden bajo. Sin embargo, los métodos descritos en el apartado 10.3 no pueden aplicarse inmediatamente, debido a una posible correlación en serie. Es posible que los métodos simples, como el ajuste de polinomios a las respuestas medias en diferentes momentos, brinden una estimación razonable de la tendencia media, pero no darán una estimación correcta de su precisión. Dos planteamientos generales son los siguientes:

1. Se pueden ajustar polinomios separados a las respuestas de cada individuo, por ejemplo usando polinomios ortogonales (apartado 10.3). Se pueden promediar entre los sujetos los términos de orden lineal, cuadrático y, si es necesario, superior; es posible construir entonces la curva de crecimiento total a partir de estos términos medios. Se puede determinar la precisión de esta curva media por métodos estándar, pero debe tenerse en cuenta que cualesquiera dos componentes, como la respuesta media y el término lineal, estarán generalmente correlacionados; su correlación será la misma que la observada entre estos componentes en individuos diferentes.

Darby y Fearn (1979) adoptaron un método similar en un estudio longitudinal sobre la presión arterial en niños. Usando métodos bayesianos demostraron que su análisis ofrecía predicciones mucho mejores sobre futuras lecturas en niños concretos que las obtenidas por rectas de regresión simple para cada niño por separado. Ello obedece al gran error aleatorio que se asocia a las extrapolaciones de rectas de regresión correspondientes a series pequeñas de observaciones.

2. El conjunto de observaciones realizadas sobre un individuo en diferentes ocasiones puede considerarse una única observación multivariante. Se pueden estimar las variancias y covariancias de las respuestas en las distintas ocasiones directamente a partir de los datos. Si se ajusta un polinomio a los datos de cada individuo, los coeficientes de los diversos términos (lineal, cuadrático, etc.) son funciones lineales de las observaciones iniciales y se pueden obtener también sus variancias y covariancias. Es posible obtener los coeficientes de la curva media promediando los valores correspondientes de cada individuo y calcular el error tipo de la estimación de la media en cualquier momento. Grizzle y Allen (1969) y Morrison (1976) proporcionan más detalles.

Hills (1968) sugirió una variante simple de este procedimiento. Si la tendencia global es lineal, las primeras diferencias (o sea las diferencias entre observaciones sucesivas) deben ser aproximadamente iguales, al margen de fluctuaciones aleatorias; las segundas diferencias (o sea las diferencias entre las primeras diferencias) deben ser aproximadamente cero en promedio. De forma similar, si la tendencia fuera cuadrática, las terceras diferencias deben ser aproximadamente cero en promedio. Por lo tanto, se puede examinar si resulta apropiado añadir términos a un polinomio evaluando la desviación media con respecto a cero de las diferencias de orden creciente. Esto puede efectuarse con un test multivariante tipo (test de la T^2 de Hotelling), siempre que los errores aleatorios no sean enormemente anormales.

Evaluación de los efectos de factores entre sujetos

Supóngase que hay m grupos, cada uno de los cuales contiene r sujetos, y que cada individuo da respuestas en k ocasiones sucesivas. El propósito principal de la investigación será probablemente comparar los m grupos, pero también puede ser de interés la naturaleza de la tendencia temporal. Superficialmente parece un experimento de parcelas divididas, considerando a los individuos como «unidades», y uno puede estar tentado a asignar grados de libertad en un análisis de la variancia de la siguiente manera:

<i>Entre sujetos</i>	$mr - 1$
Grupos	$m - 1$
Residual	$m(r - 1)$
<i>Intrasujetos</i>	$mr(k - 1)$
Ocasiones	$k - 1$
Grupos $\times$ ocasiones	$(m - 1)(k - 1)$
Residual	$m(r - 1)(k - 1)$

Sin embargo, los tests de cocientes de las variancias usados generalmente en un análisis de parcelas divididas (apartado 8.6) no son apropiadas en este caso. El test de la F habitual para grupos, basado en la parte de la tabla «entre sujetos», es válida, puesto que las respuestas de los diferentes individuos son independientes. Sin embargo los tests de la F habituales de la porción «intrasujetos» no sirven, ya que no toman en cuenta la posible correlación en serie entre las observaciones sucesivas en un mismo individuo. Puede hacerse un ajuste aproximado disminuyendo los grados de libertad intrasujetos (Box, 1954; Greenhouse y Geisser, 1959). Greenhouse y Geisser (1959) y Morrison (1976) describen métodos multivariantes más precisos.

Se han descrito los avances recientes en los artículos presentados en el Taller de 1986 de métodos para el análisis de datos longitudinales en estudios epidemiológicos y clínicos, publicados en *Statistics in Medicine*, 1988; 7 (1/2) y en el Simposio sobre análisis de datos longitudinales de 1991, publicado en *Statistics in Medicine*, 1992, 11 (14/15).

Una manera de incorporar la correlación entre medidas sucesivas consiste en el modelado autorregresivo. Cada valor de la variable dependiente, con excepción del primero, es regresionado en las variables de interés, incluyendo como covariante el valor de la variable dependiente en la ocasión previa. La inclusión de este covariante significa que se tiene en cuenta la correlación de valores sucesivos intraindividuos. Excepto al final de la serie de cada individuo, cada valor de la variable dependiente está en dos regresiones, primero como la variable dependiente y segundo como covariante. Rosner y Muñoz (1988) demostraron que este método se puede adaptar para tener en cuenta visitas ausentes y espaciadas de manera desigual. Bergen et al. (1992) aplicaron este método a los datos de hasta cinco exámenes anuales de pacientes que recibían medicación neuroléptica, para relacionar la puntuación AIMS, una medida usada en los estudios sobre la discinesia tardía, con diversas características de los pacientes y la medicación en cada intervalo anual. En este estudio, 235 pacientes contribuyeron con 678 pares de exámenes; 646 de estos pares se produjeron con un año de separación, y 32, con 2 años de separación, porque faltaron a una visita. El coeficiente de regresión sobre el valor en la visita previa un año antes, que es una estimación de la correlación entre visitas sucesivas, fue 0,6 y, después de tener en cuenta este hecho, se valoraron los efectos de otras variables.

Otro procedimiento se basa en la *ecuación de la estimación generalizada*. Zeger et al. (1988) ilustraron este método en datos consistentes en cuatro exámenes anuales de 527 niños, en que el objetivo del análisis fue determinar si la probabilidad de que un niño tuviera una infección respiratoria estaba asociada al hábito de fumar de la madre. Se emplearon varios patrones de correlación entre visitas sucesivas, y las estimaciones y los tests estadísticos fueron similares en los distintos patrones; sin embargo, la suposición de ausencia de correlación entre visitas sucesivas lleva a concluir de manera incorrecta que hay indicios firmes de un efecto causado por el tabaquismo de la madre.

Capítulo 11

Edición de datos

11.1. Observaciones preliminares

La frase «edición de datos» puede evocar una imagen del estadístico como un artificioso manipulador de indicios, capaz, mediante una cuidadosa selección de datos, de brindar un soporte irrefutable para cualquier hipótesis establecida. Nuestro propósito es mucho menos siniestro. Todos los métodos estadísticos se fundamentan en ciertas suposiciones, por ejemplo sobre la forma de distribución o de relación entre variables. Estos supuestos raras veces son exactos. Es razonable suponer, sin embargo, que en un caso específico sean suficientemente verdaderos para hacer los métodos pertinentes de análisis válidos y útiles. Con frecuencia, al observar originalmente los datos, éstos presentan algún rasgo claramente incompatible con el modelo teórico. Una acción posible podría ser intentar el desarrollo de una teoría especial para esta situación; ésta es normalmente la manera como se producen los nuevos descubrimientos en metodología estadística. Con mayor frecuencia será posible considerar los datos desde un punto de vista sensiblemente diferente usando, por ejemplo, una escala distinta de media para una o más variables y emplear entonces métodos estándar de análisis.

Los tres apartados siguientes se refieren a diversos métodos de transformación de variables a distintas escalas. En el apartado 11.5 se describen métodos simples para verificar si los datos se distribuyen normalmente. En el apartado 11.6 tratamos una cuestión más conflictiva sobre la detección de los *valores aberrantes* (*outliers*), es decir, las observaciones que difieren tanto de lo que se podría esperar según los datos restantes, que cabría sospechar un error grosero.

La mayoría de los procedimientos descritos en este capítulo son apropiados para las primeras fases del examen de datos, antes de que se lleven a cabo análisis más detallados. Es importante señalar el enorme valor de los instrumentos descriptivos simples (distribuciones de frecuencia, valores medios, diagramas de puntos, etc.) en este examen preliminar de datos. En particular es difícil exagerar el valor de los métodos gráficos, como los diagramas de puntos. Más adelante se describen detalladamente algunos recursos gráficos.

11.2. Transformaciones en general

Entendemos por transformación el cambio de escala de medida para una variable. Las transformaciones *lineales*, que implican como máximo un cambio en el origen y un factor de escala (como el cambio de grados Fahrenheit a grados centígrados en la medición de temperaturas), pueden ser útiles en la simplificación aritmética (como vimos al usar unidades de trabajo en el apartado 1.5) o satisfacer al investigador por ser la nueva escala más inteligible que la anterior. Sin embargo, dichas escalas raras veces afectan los aspectos esenciales del análisis estadístico. Son más importantes las transformaciones no lineales, en las que los in-

crementos iguales sobre la escala original no corresponden a incrementos iguales en la nueva escala. Algunos ejemplos son el logaritmo y la raíz cuadrada.

Las transformaciones tienen cinco finalidades principales, de las cuales las tres primeras son las más importantes:

1. Estabilizar variancias.
2. Linealizar relaciones.
3. Hacer más normales las distribuciones.
4. Simplificar el uso de datos con otras características difíciles.
5. Permitir la presentación de resultados en una escala de media aceptable.

Transformaciones para estabilizar las variancias

Muchos métodos estadísticos requieren que la variancia residual de los distintos subgrupos de datos sea constante. Si no es así, debería ser posible una solución aproximada en la que los distintos subgrupos se ponderaran diferencialmente, como se explicó en el apartado 7.2. Una solución más sencilla sería transformar a una escala en la que las variancias residuales fueran aproximadamente constantes. Supóngase que la variable original es x y la variable transformada es y , siendo ésta alguna función concreta de x . Entonces (3.17) muestra que, para que la $\text{Var}(y)$ sea constante, la siguiente relación debería ser aproximadamente cierta:

$$\frac{dy}{dx} = \frac{\text{constante}}{\sqrt{[\text{Var}(x)]}} \quad (11.1)$$

Si la $\text{Var}(x)$ es conocida como una función de x [o, más estrictamente, de $E(x)$], la expresión (11.1) facilita que se encuentre y como una función de x , es decir, define la transformación apropiada. En el siguiente apartado se consideran algunos ejemplos.

Transformaciones que linealizan

Si una línea de regresión, denominada v sobre u , es claramente no lineal, una solución satisfactoria puede ser ajustar una función curvilínea como en el apartado 10.3. De nuevo, sin embargo, puede ser más sencillo transformar una o ambas variables con el fin de obtener una relación casi lineal. El problema es especialmente serio cuando la variable dependiente es una proporción, la cual necesariamente toma valores entre 0 y 1; a menudo se encuentran curvas de regresión similares a las mostradas en la figura 11.2a. Las transformaciones para proporciones se estudian por separado en el apartado 11.4.

Transformaciones de normalización

En este caso se plantea una cuestión similar. Se puede incorporar una variación no normal a un modelo teórico, pero los métodos de análisis resultantes a menudo son muy complejos. Afortunadamente, muchos de los métodos estándar de análisis son *robustos* (es decir, poco sensibles a la no normalidad), y esta razón particular para la transformación es menos convincente que las otras dos. Si los tres criterios principales mencionados entran en conflicto en cuanto a las transformaciones requeridas para satisfacerlos, la necesidad de la normalidad




Fig. 11.1. Diagrama de puntos de datos hipotéticos representados: *a)* con una escala aritmética para la ordenada x ; *b)* con una escala aritmética para el $\log x$, y *c)* con una escala logarítmica para x (usando papel semilogarítmico).

es lo menos importante. Por fortuna, a menudo ocurre que la misma transformación simultáneamente estabiliza la variancia, produce relaciones lineales y proporciona distribuciones más cercanas a la normalidad (fig. 11.1).

En el apartado 11.5 se describen métodos para verificar las desviaciones de la normalidad.

11.3. Transformaciones logarítmicas y por potenciación

En la transformación logarítmica se cambia de una variable, x , a otra, y , mediante la ecuación:

$$y = \log x \quad (11.2)$$

En distintas ramas de las ciencias médicas, como la microbiología y la hematología, se acostumbra a emplear logaritmos *comunes*, en base 10. Si es necesario, se puede indicar esta característica escribiendo $\log_{10} x$. En el trabajo puramente matemático, así como en la mayoría de las fórmulas que surgen en estadística, es más práctico el logaritmo *natural* o neperiano (apartado 4.8).

La transformación logarítmica (tanto con logaritmos comunes como con logaritmos naturales) sólo puede llevarse a cabo para valores positivos de x , puesto que $\log 0 = -\infty$ y los logaritmos de los números negativos no existen. A medida que x aumenta, se requieren cambios cada vez mayores para obtener cambios iguales en y , como se muestra en el siguiente ejemplo (donde y es el logaritmo común):

x	2	20	200	2.000
y	0,3	1,3	2,3	3,3

Cabe esperar, por lo tanto, que la transformación logarítmica tienda a estabilizar variancias cuando, en los datos originales, la $\text{Var}(x)$ tendiese a aumentar notablemente con x . De hecho, (11.1) muestra que la $\text{Var}(y)$ será aproximadamente constante cuando $\text{Var}(x) \propto [E(x)]^2$. Afirmaciones equivalentes son que la desviación tipo de x es proporcional a la media o que el coeficiente de variación de x es constante.

En segundo lugar, si x está relacionada con una variable u por una tendencia con una pendiente que se incrementa consistentemente, (11.2) a menudo producirá una relación más lineal entre y y u , si se «comprime» la parte superior de la escala de x .

En tercer lugar, si la distribución de una variable x , que toma valores positivos, tiene un sesgo positivo, (11.2) reducirá este sesgo y puede producir una distribución de y más cercana a la normalidad.

Las figuras 11.1a y b ilustran una situación en la que la transformación logarítmica de x a y contribuye simultáneamente a estabilizar la variancia, a linealizar la relación con u y a proporcionar distribuciones más normales. Este tipo de situaciones se dan a menudo cuando una variable x se limita a valores positivos y puede variar dentro de un amplio intervalo; algunos ejemplos son los tiempos de supervivencia y las cantidades o concentraciones de alguna sustancia. La figura 11.1c ilustra el uso de una *escala logarítmica* para x . Las cantidades indicadas en el eje vertical son valores de x , pero las distancias entre ellos son proporcionales a las distancias entre los valores correspondientes de y . El efecto es precisamente el mismo que en b, donde los logaritmos, y , se buscaron en tablas y se representaron en una escala aritmética.

tica ordinaria. Se puede comprar papel con escalas como las de c , al que se conoce como *papel semilogarítmico*. Otra variedad, en ocasiones denominado *papel doble logarítmico*, tiene escalas logarítmicas a lo largo de ambos ejes. Los gráficos suelen trazarse empleando un ordenador, en cuyo caso las variables transformadas se calculan y se representan.

La relación entre la transformación logarítmica y la media geométrica se ha descrito en el apartado 1.5, donde se hizo especial referencia al uso de la transformación en los estudios microbiológicos y serológicos. Si se requieren límites de confianza para una media geométrica, se deben obtener de la manera habitual en la escala logarítmica y convertirlos de nuevo a la escala original.

Al usar logaritmos resulta adecuado trabajar con dos decimales como máximo.

Las transformaciones por potenciación se definen mediante la ecuación:

$$y = x^c \quad (11.3)$$

De nuevo, éstas se emplean principalmente para una variable x que sólo toma valores positivos. La ecuación (11.3) representa una familia de transformaciones distinguidas por el valor de c . Los valores de c menores que 1 producen transformaciones con propiedades similares a las de las transformaciones logarítmicas. En realidad, las propiedades estadísticas de éstas son equivalentes a las de la transformación por potenciación (11.3) a medida que c se aproxima estrechamente a cero. Esto se observa mejor mediante una versión estandarizada de (11.3), usada por ejemplo por Box y Cox (1964):

$$y = \frac{x^c - 1}{c} \quad (11.4)$$

A medida que c se aproxima a cero, y se aproxima a $\ln x$.

Existen dos valores determinados de $c < 1$ que requieren comentario.

1. $c = 1/2$: *transformación raíz cuadrada*. Ésta es, según (11.1), la transformación de estabilización de variancia apropiada cuando $\text{Var}(x) \propto E(x)$. Sabemos por (2.16) que esto es cierto en los recuentos que siguen la distribución de Poisson; la transformación de la raíz cuadrada, por consiguiente, se emplea muchas veces en este tipo de datos, por ejemplo, para el análisis de recuentos microbiológicos o recuentos de sucesos casuales como los accidentes. A partir de (3.17), si x sigue una distribución de Poisson con $[\text{Var}(x) = E(x)]$, e $y = \sqrt{x}$, entonces $\text{Var}(y) \approx 1/4$. Esto proporciona una verificación útil de si la variación residual entre recuentos, después de eliminar el efecto de diversos factores conocidos, está o no por debajo del nivel esperado por la teoría de Poisson. En un análisis de variancia de y , por ejemplo, la media cuadrática (MC) residual podría compararse con un valor teórico de 1/4 (con infinitos grados de libertad).
2. $c = -1$: *transformación inversa*. Ésta estabiliza la variancia si $\text{Var}(x)$ es proporcional a $[E(x)]^4$, una forma bastante espectacular de incremento de la variancia. Un rasgo de la transformación recíproca es que valores elevados de x corresponden a valores de y cercanos a cero, y que, más allá de cierto valor de x , los incrementos adicionales en x sólo ocasionan disminuciones insignificantes de y . Esto es especialmente útil en el análisis de datos sobre el tiempo de supervivencia en experimentos con animales en los que la mayoría de las observaciones proporcionan un tiempo de supervivencia razonablemente corto, aun-

riable explicativa pertinente (como la dosis de insecticida) en los extremos de su escala probablemente no provocarán un gran cambio en la proporción. Es probable que se encuentre, de hecho, una curva de regresión *sigmoide* como la de la figura 11.2a. Finalmente, es probable que la distribución binomial del error aleatorio se sesgue en direcciones opuestas cuando la proporción se acerque a 0 o 1.

Con frecuencia se usan dos transformaciones para las proporciones. Tienen efectos muy similares y son raros los ejemplos en que una de ellas se muestra claramente inferior a las demás:




Fig. 11.2. Curva de respuesta hipotética representada en: a) con una escala aritmética para la ordenada p ; b) con una escala aritmética para el probit de p , y c) con una escala de «probabilidad» para p (usando papel de probabilidad).

de valores de E_i inferiores a 5; es mejor evitar los valores menores que 2. Esto puede hacerse acumulando casillas adyacentes con valores pequeños de E_i .

Ejemplo 11.1

En la tabla 2.3 (p. 61) se muestran ciertas frecuencias observadas de recuentos bacterianos, con frecuencias esperadas calculadas a partir de la distribución de Poisson con la misma media que la observada. Ninguna casilla tiene frecuencias muy pequeñas, aunque si la tabla original hubiese mostrado frecuencias para $x = 7$ y $x > 7$ por separado, es probable que hubiera sido necesario acumularlas para el test de la χ^2 . El valor de X^2 es 6,02 y los grados de libertad son 6, puesto que hay ocho grupos, y un parámetro y la frecuencia total se calcularon a partir de los datos. Las discrepancias no son significativas (de la tabla A2, $0,25 < P < 0,5$, o $P = 0,42$). Como se mencionó en la página 61, ello sugiere que el tratamiento antiacumulación ha sido eficaz.

El test de la χ^2 usando (11.8) es un test «híbrido» o cruzado, sensible a una variedad de tipos de desviación con respecto a la forma de distribución asumida. Si el interés se centra alrededor de una forma específica de divergencia con respecto al modelo postulado, es probable que el test de la χ^2 del ajuste sea demasiado insensible. Al estudiar las desviaciones de los recuentos microbiológicos con respecto a la distribución de Poisson, por ejemplo, a menudo será importante examinar si hay un aumento de la variabilidad, y la mejor manera de hacerlo consiste en el test de la heterogeneidad de Poisson (7.31) del apartado 7.8.

Examen de la normalidad

Aunque no debe esperarse que los datos reales sigan exactamente una distribución normal, por lo general resulta práctico que las variables continuas no se alejen drásticamente de la normalidad. Ya se han explicado las transformaciones para mejorar la aproximación a la normalidad. Es útil contar con un recurso visual rápido para comprobar la normalidad aproximada de una distribución observada, tanto en el estudio inicial de los datos como después de una transformación. Esto puede llevarse a cabo mediante la representación gráfica de la distribución acumulada sobre un papel de probabilidad (v. apartado 11.4). Si las observaciones están agrupadas los puntos extremos entre los grupos se pueden trazar en el eje horizontal, y las frecuencias acumuladas hasta cada valor extremo se representan en la escala de probabilidad transformada. Cualquier desviación sistemática con respecto a la distribución normal producirá una desviación sistemática con respecto a una línea recta en este gráfico. Si las observaciones no están agrupadas, se puede: a) introducir un sistema práctico de intervalos de grupos; b) disponer las observaciones en orden de magnitud y representarlas en papel de probabilidad, siendo la ordenada de la observación i de n , la proporción $p' = (2i - 1)/2n$; c) representar las observaciones individuales en un *papel milimetrado corriente* frente a las denominadas *puntuaciones normales* (v. apartado 13.3).

Los gráficos normales son especialmente útiles para comprobar la bondad del ajuste de un modelo, como una regresión múltiple, en la cual los términos de error tienen una distribución normal. Si el modelo se ajusta por métodos estándar, los residuales deben comportarse de forma parecida a una muestra de una distribución normal, lo cual puede comprobarse

mediante un gráfico normal. La mayoría de los paquetes informáticos ofrecen listados de residuales y muchos brindan gráficos normales.

Ejemplo 11.2

En la tabla 10.1 (p. 299) se presentan residuales después de ajustar una regresión múltiple. ¿Presentan éstos una distribución normal? Es preferible trabajar con los residuales «estudentizados», r , que tienen una media 0 y una desviación tipo 1. El gráfico de la probabilidad normal se muestra en la figura 11.3, representado gráficamente según el método b_2 y que en la ordenada muestra la desviación normal y no la p' . Esta figura muestra algunas desviaciones con respecto a la normalidad, con un déficit de valores bajos y un exceso de valores altos, es decir, una indicación de sesgo positivo.

Otra aplicación de los gráficos normales aparece en los experimentos factoriales 2^p , donde a menudo es útil comprobar la significación conjunta de numerosos efectos principales e interacciones (v. p. 243). Según la hipótesis nula de que ninguno de los efectos principales está presente, los contrastes observados deberían seguir una distribución aproximadamente normal. Los signos de los contrastes son, sin embargo, arbitrarios, y es útil hacer un test visual que ignore estos signos. En el *gráfico seminormal* (Daniel, 1959), los contrastes observados se disponen en orden de magnitud absoluta (ignorando el signo) y se representan en la mitad superior de una hoja de papel de probabilidad. El valor $\frac{1}{2}(1 + p')$, que varía entre $\frac{1}{2}$ y 1, se usa como ordenada. El gráfico seminormal indica cuál de los contrastes sugiere la presencia de efectos reales, en caso de existir alguno.

El test de la χ^2 de bondad del ajuste cuando se emplea para una variable continua implica la formación de grupos de manera que las suposiciones necesarias para que el test estadístico se distribuya aproximadamente como una χ^2 se satisfagan; y no hay una sola manera de hacer esto. Otro test que evita esto es el test de Kolmogorov-Smirnov. Este test se basa en una comparación de las funciones de distribución observada e hipotética. En primer lugar, las




Fig. 11.3. Gráfico normal de residuales «estudentizados». La probabilidad acumulada se representa gráficamente en la ordenada en términos de la desviación normal frente al residual en la abscisa.

Otro test de la normalidad de uso frecuente es el de Shapiro-Wilk. Este test se fundamenta en la comparación de dos medidas de la variabilidad de los datos, que serían iguales en el caso de una distribución normal pero no en caso contrario. La primera medida de este tipo es la suma de cuadrados con respecto a la media, mientras que la segunda es el cuadrado de una suma ponderada de diferencias entre pares de valores, donde cada par consiste en valores correspondientes de cada lado de la mediana. Los valores de los datos se representan como $x_1, x_2, \dots, x_n$ y, después de clasificar en orden ascendente, como $x_{(1)}, x_{(2)}, \dots, x_{(n)}$. Luego, el test estadístico es:

$$W = \frac{\left[\sum_{i=1}^k a_i (x_{(n-i+1)} - x_{(i)}) \right]^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (11.10)$$

donde k es la parte integral de $\frac{1}{2}n$. Los coeficientes a_i dependen de n y son tabulados por Conover (1980, tabla A17). El test estadístico tiene que hallarse dentro de los límites de $0 < W \leq 1$ y sería 1 para una distribución normal. Los valores bajos de W indican la ausencia de normalidad, y Conover (1980, tabla A18) presenta los valores críticos.

Ejemplo 11.4

Los aumentos de peso de 7 ratas alimentadas con una dieta baja en proteínas son 70, 85, 94, 101, 107, 118 y 132 g (tabla 4.2). La suma de cuadrados con respecto a la media, 101,0, es 2.552,0. La diferencia entre los dos valores extremos, $132 - 70 = 62$, es una medida de variabilidad, al igual que las diferencias entre los dos valores extremos siguientes, $118 - 85 = 33$, y el siguiente $107 - 94 = 13$. Estas diferencias se combinan, usando los coeficientes de la tabla A17 de Conover, obteniéndose:

$$(0,6233)(62) + (0,3031)(33) + (0,1401)(13) = 50,47$$

y

$$W = (50,47)^2 / 2.552,0 = 0,9981$$

Remitiendo a la tabla A18 de Conover (1980) encontramos que estos siete valores son excepcionalmente cercanos a la distribución normal, $P > 0,99$.

El cálculo, tanto de la modificación de Shapiro-Wilks como de la de Lilliefors del test de Kolmogorov-Smirnov es extremadamente engorroso a mano, por lo que en general se obtienen usando un *software* estadístico; por ejemplo, el SAS permite el cálculo de estos test estadísticos en su procedimiento UNIVARIATE.

Ejemplo 11.3 (continuación)

El valor de W es 0,9320; $P = 0,006$. Dicho test también muestra indicios significativos de ausencia de normalidad.

Aunque los tests de normalidad ocupan un lugar en la comprobación de las suposiciones de un análisis, no puede sobrevalorarse su importancia ya que muchos de los métodos son válidos porque el tamaño de la muestra es suficiente para hacerse cargo de la ausencia de normalidad mediante la operación del teorema del límite central. Por ejemplo, un test de la t para dos muestras (apartado 4.4) es exactamente correcto si las dos muestras provienen de distribuciones normales con variancias iguales, y lo contrario es aproximadamente válido si la aproximación mejora al aumentar n_1 y n_2 y cuanto más cercanas están las distribuciones a la normalidad. Cuanto más grandes son los valores de n_1 y n_2 , mayor es la anormalidad que puede tolerarse, pero es precisamente en esta situación cuando la ausencia de normalidad es más fácil de detectar. Es probable que el valor del estadístico de Shapiro-Wilks, W , sea más pertinente que su significación estadística.

11.6. Observaciones aberrantes (*outlying*)

En ocasiones una observación aislada puede estar afectada por un craso error, sea de medición, de registro o debido a un incumplimiento súbito de los estándares generales de investigación aplicados a los datos restantes. Es importante detectar, en lo posible, tales errores, en parte porque es probable que invaliden los supuestos en que se fundamentan los métodos estándar de análisis y, en parte, porque los errores crasos pueden distorsionar seriamente las estimaciones, por ejemplo, de las medias.

Los errores de registro pueden reducirse a menudo verificando cuidadosamente todos los pasos mediante los que los resultados son copiados sobre el papel y reduciendo al mínimo el número de pasos de transcripción entre el registro original y los datos finales. Con frecuencia se tendrá una sospecha de la medición original. La medición puede ser repetible (p. ej., la estatura de un individuo si ha transcurrido un período corto desde la primera medición) o se debe tener la posibilidad de comprobarla remitiéndose a un documento autorizado (p. ej., un certificado de nacimiento, si se duda de la edad). Es mucho más fácil el caso en que se sospecha fuertemente que la observación es errónea pero no puede hacerse comprobación independiente alguna. A continuación, en los apartados «Verificaciones estadísticas» y «Estimación robusta» se consideran algunas posibles maneras de proceder. Primero nos referiremos a algunos métodos para detectar errores burdos.

Verificaciones lógicas

Algunos valores pueden considerarse imposibles o extremadamente improbables en virtud del significado de la variable. Con frecuencia se conocen los extremos de su variación de manera suficiente para permitir establecer límites superiores y/o inferiores; por ejemplo, la estatura de un varón adulto menor de 140 cm o mayor de 205 cm será sospechosa. Otros resultados serían imposibles debido a las relaciones entre las variables; por ejemplo, un niño de 10 años no puede estar casado. Este tipo de comprobaciones puede hacerse rutinariamente, una vez que se han definido las reglas de aceptabilidad. Pueden hacerse con facilidad por ordenador, posiblemente cuando se introducen los datos (apartado 1.3); de hecho, los procedimientos de edición de este tipo de datos deberían formar parte regularmente del análisis informático de grandes conjuntos de datos.

Existen métodos similares para problemas más complejos, aunque la elección del método es, como en el caso más simple de la media, a menudo arbitrario, y los detalles del análisis pueden ser complicados. En la regresión múltiple, por ejemplo, se puede sospechar que se producen esporádicas desviaciones importantes más a menudo de lo que ocurriría si los errores tuvieran una distribución normal. Hay métodos de regresión robusta que dan menor importancia a los residuales extremos que el método de mínimos cuadrados. Draper y Smith (1981, apartado 6.14) incluyen un breve comentario sobre el tema.

Capítulo 12

Análisis avanzado de datos cualitativos

12.1. Introducción

Los datos cualitativos muestran las frecuencias con las que las observaciones se hallan en varias categorías o combinaciones de categorías. Algunos de estos métodos básicos de manipulación de datos se han explicado en capítulos anteriores, en particular en los apartados 2.5, 3.3, 4.7, 4.8, 7.5 y 7.6. En el presente capítulo reunimos las técnicas más avanzadas para el tratamiento de los datos cualitativos. A partir de aquí es útil hacer una distinción entre tres tipos diferentes de clasificación en categorías, según las variables descritas en el apartado 1.4.

1. Variables *nominales*, en las que no hay una ordenación implicada.
2. Variables *ordinales*, en las que las categorías adoptan una ordenación natural, aunque no están necesariamente asociadas a una medición cuantitativa.
3. Variables *cuantitativas*, en las que las categorías están ordenadas según su asociación a una medición cuantitativa.

A menudo es útil considerar las variables tanto ordinales como cuantitativas como *ordenadas* y distinguir en particular entre los datos nominales y los ordenados. Sin embargo, a veces los datos pueden ser contrastados desde más de un punto de vista. Por ejemplo, los datos cuantitativos podrían considerarse simplemente ordinales si pareciese importante tener en cuenta la ordenación, pero no confiar demasiado en la variable subyacente específica. Los datos ordenados podrían considerarse puramente nominales si pareciese haber diferencias entre los efectos de categorías diferentes que no estuviesen relacionados con su orden natural. Por lo tanto, se requieren métodos que puedan adaptarse a una amplia gama de situaciones.

Muchos de los tests de las χ^2 introducidos anteriormente implican tests estadísticos distribuidos como χ^2 con varios grados de libertad. En cada caso el test fue sensible a desviaciones con respecto a la hipótesis nula, lo cual podría ocurrir de varias maneras. Por ejemplo, en una tabla de contingencia $2 \times k$, la hipótesis nula postula la igualdad entre las proporciones esperadas de individuos en cada columna que coinciden con la primera fila. Hay k de estas proporciones y la hipótesis nula se puede falsificar si cualquiera de ellas difiere de las otras. Estos tests pueden considerarse técnicas «híbridas», capaces de servir para diferentes propósitos. Sin embargo, si estuviésemos interesados en cierta forma de desviación de la hipótesis nula, sería posible formular un test que fuese particularmente sensible a esta situación, aunque tal vez menos eficaz que el test de la χ^2 híbrido en la detección de otras formas de desviación. A veces, estos tests especialmente dirigidos pueden obtenerse subdividiendo el estadístico χ^2 total en porciones que siguen las distribuciones χ^2 con números reducidos de grados de libertad.

La situación es muy similar a la encontrada en el análisis de la variancia, donde a veces una suma de cuadrados (SC) puede subdividirse en porciones, con números reducidos de grados de libertad, que representan contrastes específicos entre grupos (apartado 7.4).

En los apartados 12.2 y 12.3 describimos métodos para detectar tendencias en las probabilidades que se hallan en observaciones de una serie de categorías ordenadas. En el apartado 12.4 se explica un método similar para una sola serie de recuentos. En el apartado 12.5 se describen otras dos situaciones, en las que el estadístico χ^2 calculado para una tabla de contingencia se subdivide para aclarar modos específicos con los que las variables categóricas pueden asociarse. En los apartados 12.6 y 12.7 se generalizan algunos de los métodos descritos anteriormente para situaciones en las que los datos están estratificados (es decir, divididos en subgrupos), de manera que las tendencias pueden ser contrastadas intraestratos y, finalmente, agrupadas.

Muchas de las técnicas descritas en estos apartados hacen uso de las distribuciones χ^2 , ampliamente utilizadas en capítulos anteriores. Sin embargo, estos métodos de la χ^2 se han diseñado casi exclusivamente para examinar la significación. En muchos problemas con datos categóricos la estimación de parámetros pertinentes que describen la naturaleza de posibles asociaciones entre variables es mucho más importante que la realización de tests de significación de la hipótesis nula. El apartado 12.8 trata sobre un procedimiento general para modelar las relaciones entre variables, de las que algunos casos particulares son pertinentes a los datos categóricos. En el apartado 12.9 describimos métodos de estandarización, en particular en relación con datos estadísticos vitales.

Hay tratamientos más completos del análisis de datos cualitativos en las monografías de Agresti (1990), Cox y Snell (1989), Fienberg (1980) y Fleiss (1981).

12.2. Tendencia de las proporciones

Supóngase que en una tabla de contingencia $2 \times k$, como la que hemos comentado en el apartado 7.5, los k grupos siguen un orden natural. Pueden corresponder a valores o a grupos de valores distintos, de una variable cuantitativa como la edad, o a categorías cualitativas, como la gravedad de una enfermedad, que pueden ordenarse, pero a las que no se puede asignar fácilmente un valor numérico. El test de la $\chi^2_{(k-1)}$ se ha diseñado para detectar diferencias entre las k proporciones de observaciones de la primera fila. Más específicamente podríamos preguntarnos si la tendencia de las proporciones desde el grupo 1 al k es significativa.

Para que la exposición sea más práctica asignaremos los grupos a las filas de la tabla, que se convierte ahora en una tabla $k \times 2$ en lugar de una $2 \times k$.

Podemos asignar una variable cuantitativa, x , a los k grupos. Si la definición de los grupos usa una variable de este tipo, se puede elegir como x . Si la definición es cualitativa, x podrá asumir valores enteros de 1 a k . La notación será la siguiente:

Grupo	Variable x	Frecuencia		Total	Proporción positiva
		Positiva	Negativa		
1	x_1	r_1	$n_1 - r_1$	n_1	p_1
2	x_2	r_2	$n_2 - r_2$	n_2	p_2
...	...	...	...	...	...
i	x_i	r_i	$n_i - r_i$	n_i	p_i
...	...	...	...	...	...
k	x_k	r_k	$n_k - r_k$	n_k	p_k
Todos los grupos combinados		R	$N - R$	N	$P(= R/N)$

El numerador del estadístico χ^2 , X^2 , es, a partir de (7.29):

$$\sum n_i(p_i - P)^2$$

una suma ponderada de cuadrados de los p_i con respecto a la medida (ponderada) P (v. el análisis después de (7.30)). Esta ecuación es también una SC entre grupos corriente, de una variable y que toma el valor 1 para cada elemento positivo y el valor 0 para los elementos negativos. Esta SC puede dividirse (como en el apartado 9.1) en una SC debida a la regresión de y sobre x y en una SC de la desviación con respecto a la regresión lineal. Si existe una tendencia de p_i con x_i podemos analizar, en primer lugar, cuál de estas dos porciones es mayor que el valor esperado por azar. Dividiendo esta porción por PQ , el denominador de (7.29), se obtiene un estadístico de la χ^2 , X_1^2 , el cual forma parte de X^2 y es especialmente sensible a esta tendencia.

Una pequeña manipulación algebraica (Armitage, 1955) nos proporcionará la siguiente fórmula para X_1^2 :

$$X_1^2 = \frac{N(N \sum r_i x_i - R \sum n_i x_i)^2}{R(N-R)[N \sum n_i x_i^2 - (\sum n_i x_i)^2]} \quad (12.1)$$

La diferencia entre ambos estadísticos,

$$X_2^2 = X^2 - X_1^2 \quad (12.2)$$

puede considerarse como un test estadístico $\chi^2_{(k-2)}$ que contrasta las desviaciones con respecto a la regresión lineal de p_i sobre x_i . Como es habitual, dichos tests son aproximados, pero es probable que la aproximación sea correcta si sólo una pequeña proporción de las frecuencias esperadas es inferior a 5. En estas condiciones es adecuado el test de la tendencia, pero también con mayor amplitud, ya que se basa en una función lineal de las frecuencias y es probable que sea satisfactorio siempre cuando sólo una pequeña proporción de las frecuencias esperadas sea menor que aproximadamente 2 y que éstas no se presenten en filas adyacentes. Se puede elaborar un test exacto siguiendo el mismo razonamiento que el empleado en el test exacto de Fisher para una tabla 2×2 (apartado 4.9). Condicional a los totales marginales, el test supone la evaluación de la probabilidad de que el $\sum r_i x_i$ sea al menos tan grande como el valor observado (Agresti, 1990, apartado 4.8.2). El método del test exacto incluye gran cantidad de cálculos y sólo es factible con el *software* estadístico adecuado (v. cap. 18).

Ejemplo 12.1

En el análisis de los datos resumidos en la tabla 12.1 sería razonable preguntarse si la proporción de pacientes que aceptan la propuesta de su médico de cabecera de hacerse una mamografía de detección tiende a disminuir a medida que aumenta el tiempo transcurrido desde la última visita. El primer paso consiste en decidir las puntuaciones que representan las cuatro categorías de períodos. Es posible usar puntos medios de los intervalos de tiempo, 3 meses, 9 meses, etc., pero el último intervalo, al ser abierto, sería molesto. En cambio, emplearemos puntuaciones enteras separadas por intervalos iguales, como se muestra en la tabla.

Tabla 12.1. Número de pacientes que se sometieron, o no, a una mamografía de detección, clasificados según el tiempo transcurrido desde la última visita al médico de cabecera (Irwig et al, 1990).

Tiempo desde la última visita	Puntuación x	Asistencia		Total	Proporción de asistentes
		Sí	No		
< 6 meses	0	59	97	156	0,378
6-12 meses	1	10	31	41	0,244
1-2 años	2	12	36	48	0,250
> 2 años	3	5	28	33	0,152
		86	192	278	

De (12.1):

$$\begin{aligned}
 \chi^2_1 &= \frac{(278) [(278)(49) - (86)(236)]^2}{(86)(192) [(278)(530) - (236)^2]} \\
 &= (1,2383 \times 10^{10}) / (0,15132 \times 10^{10}) \\
 &= 8,18
 \end{aligned}$$

que, como variable $\chi^2_{(1)}$, es muy significativo ($P = 0,004$).

El estadístico global $\chi^2_{(3)}$, de (7.28) o (7.30), se calcula como:

$$X^2 = 8,92$$

Así pues, el test para analizar desviaciones con respecto a una tendencia lineal resulta:

$$\begin{aligned}
 \chi^2_2 &= X^2 - \chi^2_1 \\
 &= 8,92 - 8,18 \\
 &= 0,74
 \end{aligned}$$

como variable $\chi^2_{(2)}$, la cual es claramente no significativa. Así, hay una tendencia definida que bien puede originar disminuciones aproximadamente iguales en la proporción de pacientes que se sometieron a la mamografía al cambiar sucesivamente a las categorías que representan períodos más largos desde la última visita.

Otras fórmulas son equivalentes o casi equivalentes a (12.1). El coeficiente de regresión de y en x , que mide la velocidad a la cual la proporción p_i cambia con la puntuación x_i , se calcula mediante la expresión:

$$b = \frac{NT}{N \sum n_i x_i^2 - (\sum n_i x_i)^2} \quad (12.3)$$

donde

$$T = \sum r_i x_i - \frac{R \sum n_i x_i}{N} = \sum x_i (r_i - e_i) \quad (12.4)$$

El método para comparar dos medias es, desde luego, el test de la t para dos muestras. El método analizado ahora ofrece una alternativa al test de la t , que puede ser preferible para respuestas categóricas puesto que, por lo general, los datos están alejados de la normalidad.

La diferencia entre las puntuaciones medias en la primera y la segunda columnas de la tabla (o sea para las respuestas positivas y negativas) es:

$$d = \frac{NT}{R(N - R)} \quad (12.7)$$

donde T está dada por (12.4). Puesto que $d^2/\text{Var}(d) = X^2_{1\alpha}$, dado por (12.6), se puede comprobar fácilmente que:

$$\text{Var}(d) = \sigma_x^2 \left(\frac{1}{R} + \frac{1}{N - R} \right) \quad (12.8)$$

donde σ_x^2 es la variancia de x :

$$\sigma_x^2 = \frac{\sum n_i x_i^2 - \frac{(\sum n_i x_i)^2}{N}}{N - 1} \quad (12.9)$$

Obsérvese que (12.9) es la variancia de x para los datos completos y no la variancia dentro de las columnas separadas. Si la hipótesis no es verdadera, (12.8) sobrevalorará la variancia de d , y los límites de confianza para la diferencia entre las medias calculados según (12.8) tenderán a ser demasiado amplios.

El test de la diferencia entre medias descrito con anterioridad está relacionado fielmente con los tests no paramétricos de Wilcoxon y de Mann-Whitney que se describen más adelante (v. apartado 13.3).

12.3. Tendencias en tablas de contingencia de mayores dimensiones

Los tests de tendencia también pueden aplicarse a tablas de contingencia de mayores dimensiones que la tabla $k \times 2$ estudiada en el apartado 12.2. La ampliación a más de dos columnas de frecuencias da origen a dos posibilidades: las columnas pueden ser nominales (o sea no ordenadas) u ordenadas. En el primer caso podríamos contrastar las diferencias en las puntuaciones medias de las filas entre columnas diferentes; esto sería una alternativa al análisis de la variancia de un factor, igual que el test de la χ^2 basado en (12.7) y (12.8) es una alternativa al test de la t para dos muestras. En el segundo caso, de categorías de columnas ordenadas, el problema podría ser examinar la regresión de un conjunto de puntuaciones en el otro o, de modo equivalente, la correlación entre las puntuaciones de las filas y de las columnas. Ambas situaciones se ilustran con un ejemplo, en el que los métodos de análisis siguen fielmente los descritos por Yates (1948).

Ejemplo 12.2

Se llevó a cabo un estudio en 66 madres cuyos recién nacidos habían muerto, para valorar la relación entre su estado de sufrimiento y el grado de apoyo (Tudehope et al, 1986). El dolor se registró según

una escala ordenada cualitativa de cuatro categorías, y el grado de apoyo, según una escala ordinal de tres categorías (tabla 12.2). El test estadístico global (7,28) es 9,96 (6 gl), lo cual es claramente no significativo. No obstante, el examen de la tabla de contingencia sugiere que las madres que contaban con un buen apoyo sintieron menos dolor que las que recibieron escaso apoyo. Además, las que tuvieron un apoyo adecuado manifestaron un sentimiento intermedio, y este efecto se pasa por alto en el test global. El propósito del test de la tendencia es obtener un test más sensible en este aspecto concreto.

En primer lugar ignoramos el ordenamiento de las columnas, considerándolas como tres categorías diferentes de una variable nominal. Los cálculos se llevan a cabo de la siguiente manera.

1. Asignamos puntuaciones a las filas (x) y a las columnas (y): se han usado valores enteros a partir de 1. Representamos los totales de las filas por R_i , $i = 1$ a r ; los totales de las columnas, por C_j , $j = 1$ a c , y el número total de sujetos, por N .
2. En cada columna calculamos la suma de las puntuaciones de las filas, X_j , y la puntuación media $\bar{x}_j$. En la primera columna:

$$X_1 = (17 \times 1) + (6 \times 2) + (3 \times 3) + (1 \times 4) = 42,$$

$$\bar{x}_1 = 42/27 = 1,56$$

Este cálculo también se lleva a cabo para la columna de totales de las filas, lo cual da 126. Este valor sirve para verificar los valores de X_j que suman a lo largo de las columnas dando este valor. Este total es la suma de las puntuaciones de las filas correspondientes a todas las madres, es decir $\sum x = 126$.

3. Calculamos la SC de las puntuaciones de las filas correspondientes a todas las madres:

$$\sum x^2 = (34 \times 1) + (12 \times 4) + (12 \times 9) + (8 \times 16)$$

$$= 318$$

Corregimos esta SC para la media:

$$S_{xx} = 318 - 126^2/66 = 77,455$$

4. Ahora puede efectuarse un test de la igualdad de las puntuaciones medias $\bar{x}_j$. El test estadístico es:

Tabla 12.2. Número de madres según el estado de sufrimiento y el grado de apoyo (datos de Tudehope et al, 1986).

Estado de sufrimiento	Puntuación de la fila X_i	Apoyo			Total R_i	Suma de puntuaciones de las columnas Y_j
		Bueno	Adecuado	Malo		
I	1	17	9	8	34	59
II	2	6	5	1	12	19
III	3	3	5	4	12	25
IV	4	1	2	5	8	20
Total C_j		27	21	18	66	123
Puntuación de la columna y_j		1	2	3		
Suma de puntuaciones de las filas X_j		42	42	42	126	
Puntuación media $\bar{x}_j$		1,56	2,00	2,33		

$$\begin{aligned}
 X^2 &= (N-1) [\sum (X_j^2/C_j) - (\sum x)^2/N]/S_{xx} \\
 &= \frac{65}{77,455} \left(\frac{42^2}{27} + \frac{42^2}{21} + \frac{42^2}{18} - \frac{126^2}{66} \right) \\
 &= 5,70
 \end{aligned}
 \tag{12.10}$$

Éste puede considerarse un estadístico $\chi^2_{(c-1)}$, es decir, $\chi^2_{(2)}$. No es bastante significativo al nivel del 5% ($P = 0,058$), pero sí suficientemente aproximado para permitir que un test de la tendencia aparente en las medias de las columnas, $\bar{x}_j$, sea significativo. Por lo tanto, ahora hacemos uso de las puntuaciones de las columnas, y_j .

5. Repetimos los pasos 2 y 3, operando a través de las filas en lugar de hacerlo a lo largo de las columnas. No es necesario calcular las puntuaciones medias.

$$\begin{aligned}
 \sum y &= 123 \\
 \sum y^2 &= 273 \\
 S_{yy} &= 273 - 123^2/66 \\
 &= 43,773
 \end{aligned}$$

6. Calculamos la suma de productos de la suma de puntuaciones de las filas, X_j , y las correspondientes puntuaciones de las columnas, y_j .

$$\sum X_j y_j = (42 \times 1) + (42 \times 2) + (42 \times 3) = 252$$

Este total es $\sum xy$ para todas las madres y debe corregirse para las medias:

$$\begin{aligned}
 S_{xy} &= 252 - (123 \times 126)/66 \\
 &= 17,182
 \end{aligned}$$

7. El test estadístico de la tendencia en las puntuaciones medias $\bar{x}_j$ es:

$$\begin{aligned}
 X^2 &= (N-1) S_{xy}^2 / (S_{xx} S_{yy}) \\
 &= 65 \times 17,182^2 / (77,455 \times 43,773) \\
 &= 5,66
 \end{aligned}
 \tag{12.11}$$

Éste es aproximadamente un estadístico $\chi^2_{(1)}$, y es significativo ($P = 0,017$). En este ejemplo, la mayor parte de la diferencia entre las medias de las columnas reside en la tendencia. Esto resulta evidente en el examen de las medias de las columnas, y el resultado correspondiente de los test estadísticos consiste en que el test estadístico global de 5,70 (2 gl) para la igualdad de las medias de las columnas puede subdividirse en 5,66 (1 gl) para la tendencia lineal y, restando, 0,04 (1 gl) para las desviaciones con respecto a la tendencia.

Obsérvese que el test estadístico (12.11) es $N-1$ veces el cuadrado del coeficiente de correlación entre las puntuaciones de las filas y de las columnas, y ésta puede ser una manera práctica de calcularlo en un ordenador. Cuando $r = 2$, (12.10) contrasta la igualdad de c proporciones y es idéntico a (7.30) excepto por un factor multiplicador de $(N-1)/N$; (12.11) contrasta la tendencia en las proporciones y es idéntico a (12.6).

Tanto (12.10) como (12.11) están incluidos en el programa PROC FREQ de SAS, el primero como «ANOVA statistic» y el segundo como «Mantel-Haenszel chi-square».

12.4. Tendencias en recuentos

En muchos problemas del tipo explicado en el apartado 12.2, las proporciones en estudio son muy pequeñas. Por ejemplo, si las frecuencias en la columna «positiva» de la tabla de la página 381 son mucho más pequeñas que las de la columna «negativa», casi toda la contribución al test estadístico proviene de la primera columna. En el límite, como las p_i se vuelven muy pequeñas y las n_i se vuelven muy grandes, tanto (12.1) como (12.6) adquieren la forma siguiente:

$$\chi^2_{IP} = \frac{[\sum x_i(r_i - e_i)]^2}{\sum e_i x_i^2 - (\sum e_i x_i)^2 / R} \quad (12.12)$$

El subíndice P se usa para dicho test estadístico porque en esta situación limitante las frecuencias observadas r_i pueden considerarse como variables de Poisson con medias (conforme a la hipótesis nula) e_i , los valores esperados. En algunas aplicaciones los valores esperados son proporcionales a los sujetos-años de exposición de los individuos pertenecientes a cada categoría (v. apartado 14.9).

Ejemplo 12.3

Con los datos mostrados en la tabla 12.3 se calculan las frecuencias esperadas de muertes maternas en proporción a las cantidades de madres en los diferentes períodos, obteniéndose la suma total observada de 127. El estadístico $\chi^2_{(7)}$ total, calculado como $\sum (r_i - e_i)^2 / e_i$, es 3,91, claramente no significativo. Aunque la totalidad de esta cantidad se atribuyese a la regresión lineal, apenas alcanzaría el nivel de significación del 5% con 1 gl. Sin embargo, se sugiere un exceso de fallecimientos en los primeros años y un déficit posteriormente. De hecho, la aplicación de (12.12) da $\chi^2_{IP} = 1,27$ ($P = 0,26$). Evidentemente, en esta población en particular no hay indicios firmes de una reducción gradual de la tasa de mortalidad materna.

Tabla 12.3. Mortalidad materna en Nueva Gales del Sur, correspondiente a primíparas de 40 años o más (Wilcocks y Lancaster, 1951).

Años	Puntuación x_i (punto medio - 1900)	Número de madres	Muertes maternas	
			Observadas, r_i	Esperadas, e_i
1894-1900	- 2,5	346	10	6,603
1901-1907	4,5	454	9	8,664
1908-1910	9,5	272	3	5,191
1911-1920	16,0	1.133	23	21,621
1921-1930	26,0	1.546	32	29,503
1931-1937	34,5	909	17	17,347
1938-1942	40,5	699	13	13,339
1943-1948	46,0	1.296	20	24,732
Total		6.655	127	127,000

12.5. Otros componentes de la χ^2

La mayoría de los estadísticos χ^2 descritos hasta ahora en este capítulo pueden considerarse componentes del estadístico total χ^2 para una tabla de contingencia. A continuación se presentan otros dos ejemplos de la subdivisión de los estadísticos χ^2 .

Clasificación jerárquica

En el apartado 12.2, el numerador del estadístico de $\chi^2_{(k-1)}$ (7.29) se consideró como la SC entre grupos de una variable ficticia y , que toma los valores 0 y 1. Procedimos a subdividirla de la forma habitual. También pueden utilizarse otros tipos de subdivisión, como los que se mostraron en los capítulos 7 y 8, si son adecuados a los datos en estudio. Por ejemplo, si los k grupos forman una distribución factorial y si las n_i son iguales o proporcionales a los totales marginales para cada factor por separado, se podrían emplear las técnicas habituales para separar SC y , por lo tanto, los componentes del estadístico de $\chi^2_{(k-1)}$, representando efectos principales e interacciones.

Cuando los grupos forman una clasificación jerárquica no es necesario imponer condición alguna a las n_i .

Ejemplo 12.4

La tabla 12.4 muestra las proporciones de moscas eliminadas por dos insecticidas diferentes. Hay dos series de cada insecticida, y cada una de las cuatro series ha sido sometida a dos tests. El test de la $\chi^2_{(7)}$ global nos da:

$$\begin{aligned} \chi^2_{(7)} &= (2^2/51 + \dots + 9^2/48 - 45^2/391)/(0,8849)(0,1151) \\ &= 1,6628/0,1019 = 16,32 \text{ con 7 gl} \end{aligned}$$

que es significativa ($P = 0,022$). Ésta puede dividirse de la siguiente forma:

Entre tests (4 gl):

$$\begin{aligned} \chi^2_{(4)} &= \frac{(2^2/51 + 5^2/48 - 7^2/99) + \dots + (11^2/50 + 9^2/48 - 20^2/98)}{0,1019} \\ &= 2,75 \quad (P = 0,60) \end{aligned}$$

Tabla 12.4. Proporción de moscas caseras exterminadas en experimentos con dos insecticidas.

Insecticida Serie Test	A				Total A	B				Total B	Total A + B
	A1		A2			B1		B2			
	1	2	1	2		1	2	1	2		
<i>Moscas</i>											
Exterminadas	49	43	43	48	183	41	44	39	39	163	346
Supervivientes	2	5	4	1	12	5	8	11	9	33	45
Total	51	48	47	49	195	46	52	50	48	196	391
Proporción de moscas exterminadas					0,9385					0,8316	0,8849




Fig. 12.1. Subdivisión del estadístico de $\chi^2_{(4)}$ de la tabla 12.5. Las subtablas (a) a (d) muestran una posible partición en estadísticos de $\chi^2_{(1)}$ independientes. Las subtablas e y f muestran dos formas de combinar los contrastes.

Existen distintas formas de subdividir una tabla de contingencia. En el ejemplo 12.5, la tabla elemental *a* podría haberse escogido como cualquiera de las tablas 2 x 2 que forman parte de la tabla global. La elección, como en el ejemplo, a menudo dependerá de los datos, es decir, se realizará después de la inspección inicial de los datos. Existe, pues, el riesgo de «dragado», y esto debe reconocerse en cualquier interpretación del análisis. En el ejemplo 12.5, naturalmente, la relación entre el grupo O y la úlcera péptica es demasiado fuerte, para explicarla como una relación espuria.

12.6. Combinación de tablas 2 x 2

A veces se dispone de varias tablas 2 x 2 relacionadas con el mismo problema y parece natural combinar las evidencias de una asociación entre los factores de filas y columnas. Por ejemplo, puede existir cierto número de estudios retrospectivos, cada uno de los cuales proporciona datos sobre una posible asociación entre cierta enfermedad y cierto factor ambiental. O, en un ensayo clínico multicéntrico, cada centro puede proporcionar evidencias sobre una posible diferencia entre las proporciones de pacientes cuyo estado mejora con el tratamiento A y con el B.

Éstos son ejemplos de *estratificación*. En un ensayo clínico, por ejemplo, los datos son *estratificados* por centros, y el objetivo es estudiar el efecto del tratamiento sobre la mejoría de los pacientes *intraestratos*.

¿Cómo deben combinarse estos datos? El primer punto que se ha de señalar es que agrupar las frecuencias de distintas tablas y examinar la asociación sugerida por la tabla de frecuencias agrupadas puede ser equívoco. Los siguientes datos hipotéticos ilustran una situación extrema.

Ejemplo 12.6

Se supone que las frecuencias del ángulo inferior izquierdo de la tabla 12.6 se han obtenido en un estudio retrospectivo en el que se compararon 1.000 pacientes que padecían cierta enfermedad con 1.000 individuos control. La proporción de sujetos con la característica A es ligeramente superior en el grupo control que en el grupo con la enfermedad. Por lo tanto, estos datos sugieren, si acaso, que existe una asociación negativa entre la enfermedad y el factor A, aunque naturalmente la diferencia estaría lejos de ser significativa. Sin embargo, supóngase que los dos grupos no habían sido apareados con respecto al sexo y que los valores para los dos sexos por separado son los que se muestran en la parte superior izquierda de la tabla.

Para cada sexo existe una asociación positiva entre la enfermedad y el factor A, como puede demostrarse al comparar las frecuencias observadas de la izquierda con las frecuencias esperadas de la derecha. Éstas se calculan mediante el procedimiento habitual, separadamente para cada sexo; por ejemplo $144 = (240)(600)/1.000$. Lo que ocurre es que el grupo control tiene una mayor proporción de mujeres que el grupo que presenta la enfermedad, y que las mujeres tienen una prevalencia mayor de factor A que los varones. La asociación sugerida por las frecuencias agrupadas es opuesta a la dirección sugerida por cada una de las tablas desglosadas. Las variables de este tipo, como el sexo en este caso, que se relacionan tanto con la presencia de enfermedad como con un factor de interés, se denominan *variables de confusión*.

¿Cómo deben agruparse los indicios de tablas separadas? No existe una sola respuesta. El procedimiento que ha de adoptarse depende de si el objetivo primario es verificar la significación de una tendencia de filas y columnas en una dirección para todos los datos o si debe medirse la asociación y, en caso de existir, su dirección.

En algunas situaciones resulta natural o práctico estudiar la asociación en cada tabla observando la diferencia entre dos proporciones. Supóngase que en la *i*-ésima tabla estamos interesados en una comparación entre la proporción de elementos clasificados como «positivos» en cada una de las dos categorías A y B, y que las frecuencias en esta tabla son las siguientes:

Tabla 12.6. Estudio retrospectivo para analizar la asociación entre una enfermedad y un factor etiológico; datos subdivididos según el sexo.

		Frecuencias observadas		Total	Frecuencias esperadas	
		Enfermedad	Control		Enfermedad	Control
Varones	A	160	80	240	144	96
	no A	440	320	760	456	304
		600	400	1.000	600	400
Mujeres	A	240	330	570	228	342
	no A	160	270	430	172	258
		400	600	1.000	400	600
Varones + mujeres	A	400	410	810	(372)	(438)
	no A	600	590	1.190	(628)	(562)
		1.000	1.000	2.000		

Ejemplo 12.7

La tabla 12.7 muestra algunos resultados extraídos de un ensayo que comparó la mortalidad por tétanos en pacientes que habían recibido antitoxina con la de pacientes que no la habían recibido. Los tratamientos se asignaron aleatoriamente, pero, por azar, una mayor proporción de los individuos del grupo sin antitoxina presentó una enfermedad más grave (definida en términos de período de incubación y período de inicio de los espasmos). La tercera categoría (gravedad desconocida) no reviste importancia numérica, pero puede incluirse en los cálculos. Los resultados globales apoyan el uso de antitoxina, pero esto puede ser en parte a causa de una distribución de casos más favorable.

El test de Cochran se realiza del siguiente modo:

Grupo	p_{oi}	d_i	$p_{oi}q_{oi}$	w_i
I	$37/47 = 0,7872$	0,1319	0,1675	11,62
II	$10/29 = 0,3448$	0,3233	0,2259	6,83
III	$2/3 = 0,6667$	0,5000	0,2222	0,67
				<u>19,12</u>

$$\bar{d} = 4,0758/19,12 = 0,2132$$

$$ET(\bar{d}) = (\sqrt{3,6381})/19,12 = 0,0997$$

$$\bar{d}/ET(\bar{d}) = 2,14$$

inferior al nivel de significación del 5% ($P = 0,032$).

Otra manera de resolver el problema de combinar tablas 2×2 se conoce como el método de Mantel-Haenszel (Mantel y Haenszel, 1959). El número de individuos positivos en el grupo A, r_{Ai} , puede compararse con su frecuencia esperada:

$$e_{Ai} = r_{Ai} n_{Ai} / n_{.i}$$

La variancia de la discrepancia entre las frecuencias observada y esperada es:

$$\text{Var}(r_{Ai} - e_{Ai}) = \frac{n_{Ai} n_{Bi} r_{.i} (n_{.i} - r_{.i})}{n_{.i}^2 (n_{.i} - 1)} \quad (12.17)$$

Tabla 12.7. Mortalidad por tétanos en un ensayo clínico para comparar los efectos del empleo o no de antitoxina. Clasificación de los pacientes según la gravedad de la enfermedad (tomada de Brown et al. 1960).

Grupo de gravedad	Sin antitoxina	Con antitoxina	Muerdes/ total	Proporción de muertes
	Muerdes/ total	Proporción de muertes		
I (gravedad extrema)	22/26	0,8462	15/21	0,7143
II (gravedad menor)	6/11	0,5455	4/18	0,2222
III (gravedad desconocida)	1/1	1,0000	1/2	0,5000

un test de la asociación en la tabla i -ésima es proporcionado por el estadístico $\chi^2_{(1)}$:

$$X^2_{MH} = \frac{(r_{Ai} - e_{Ai})^2}{\text{Var}(r_{Ai} - e_{Ai})} \quad (12.18)$$

que es, de hecho, igual a (4.22) y al estadístico χ^2 habitual (4.21) multiplicado por el factor $(n_j - 1)/n_j$, que es casi la unidad con muestras de tamaño grande. Si se desea, puede obtenerse una corrección de la continuidad análoga a (4.24) restando 1/2 del valor absoluto de la discrepancia antes de elevar al cuadrado el numerador de (12.18).

Para comprobar la asociación en el conjunto de tablas combinadas simplemente sumamos las discrepancias y sus variancias, para obtener el estadístico combinado:

$$X^2_{MH} = \frac{[\sum (r_{Ai} - e_{Ai})]^2}{\sum \text{Var}(r_{Ai} - e_{Ai})} \quad (12.19)$$

que se distribuye aproximadamente como una χ^2 con 1 gl. Si no fuera por los factores multiplicantes $(n_j - 1)/n_j$ esta fórmula concordaría exactamente con la expresión $\bar{d}^2/\text{Var}(\bar{d})$ del método de Cochran (Radhakrishna, 1965). Por esta razón, este procedimiento a menudo recibe el nombre de método de Cochran-Mantel-Haenszel.

Ejemplo 12.7 (continuación)

Con los datos de la tabla 12.7 los cálculos para el test de Mantel-Haenszel proceden de la siguiente forma:

Grupo	r_{Ai}	e_{Ai}	$r_{Ai} - e_{Ai}$	$\text{Var}(r_{Ai} - e_{Ai})$
I	22	20,468	1,532	1,988
II	6	3,793	2,207	1,598
III	1	0,667	0,333	0,222
	$\overline{29}$	$\overline{24,928}$	$\overline{4,072}$	$\overline{3,808}$

$$X^2_{MH} = (4,072)^2/3,808 = 4,35$$

$$X_{MH} = 2,09$$

un poco menos significativo que la desviación estandarizada de 2.14 obtenida anteriormente con el método de Cochran. El cambio en este caso se debe a los factores de multiplicación usados en los cálculos de la variancia. Con la corrección de la continuidad:

$$X^2_{MHc} = 3,35, X_{MHc} = 1,83 (P = 0,067)$$

El test de Mantel-Haenszel es válido incluso cuando algunos o todos los estratos tienen frecuencias totales pequeñas. Un caso particular se da cuando cada estrato consiste en un par equiparado. Luego, (12.19) es equivalente al test de McNemar, (4.12). Es probable que el test sea válido siempre que $\sum e_{Ai}$ y los totales correspondientes en las otras tres casillas sean todos superiores a 5. De no ser éste el caso, es posible un tratamiento exacto. Es una amplia-

ción del test exacto en una sola tabla 2×2 (apartado 4.9). El nivel de significación para un factor es la probabilidad de que $\sum_{Ai}$ sea igual o superior a su valor observado, por lo que para cualquier valor de $\sum_{Ai}$ la probabilidad se calcula considerando todas las combinaciones posibles de tablas a lo largo de los estratos que producen este total (Mehta et al, 1985; Hirji et al, 1988; Agresti, 1990, apartado 7.4.4). Los cálculos sólo son factibles con el *software* adecuado (v. cap.18).

12.7. Combinación de tablas de mayores dimensiones

El tipo de problemas comentado en el apartado 12.6 puede aparecer también con tablas de mayor tamaño. Es posible que el investigador esté interesado en la asociación entre dos factores cualitativos, con r y c categorías, respectivamente, y que existan datos para k subgrupos o estratos, formando así k tablas separadas. Podemos distinguir entre: *a*) factores de filas y columnas, ambos nominales; *b*) un factor (p. ej. columnas) nominal y el otro ordinal, y *c*) filas y columnas, ambas ordinales. En cada caso el método de Mantel-Haenszel proporciona un procedimiento útil. La idea general consiste en obtener discrepancias entre las frecuencias observadas y las esperadas si no hubiese asociación alguna entre filas y columnas intraestratos. Si se desea una explicación más completa, véanse Kuritz et al. (1988).

Cuando ambos factores son nominales, la cuestión consiste en determinar si hay alguna asociación entre las filas y las columnas, que formen un patrón razonablemente coherente a través de los distintos estratos. Un método natural consiste en obtener frecuencias esperadas a partir de los márgenes de cada tabla (7.27), sumarlas a lo largo de los k estratos y comparar las frecuencias totales observadas y esperadas en las rc combinaciones fila-columna. Puede sentirse la tentación de efectuar un test de la χ^2 corriente en estas frecuencias agrupadas, usando (7.28). Sin embargo, esto no es del todo correcto, ya que las frecuencias esperadas no se han obtenido directamente de las frecuencias marginales agrupadas. El estadístico X^2 de (7.28) no sigue la distribución χ^2 con $(r-1)(c-1)$ gl: los grados de libertad correctos deberían ser ligeramente inferiores, lo cual hace que los valores altos de X^2 sean más significativos de lo que podría pensarse en un principio. Es probable que el efecto sea pequeño y, a menudo, será conveniente emplearlo como aproximación práctica aunque moderada, advirtiendo que los efectos son algo más significativos de lo que parecen.

Un test de la χ^2 correcto requiere el álgebra de matrices y ha sido descrito, por ejemplo, por Kuritz et al. (1988), y para tablas con $r = 2$ filas, por Breslow y Day (1980, apartado 4.5). El test se ejecuta mediante distintos programas informáticos, como por ejemplo «estadístico de asociación general» en el programa PROC FREQ de SAS. Con un solo estrato, el test estadístico es $(N-1)/N$ veces el estadístico habitual (7.28). Para $r = c = 2$, de modo que se combina una serie de tablas 2×2 , el test estadístico es idéntico al estadístico de Mantel-Haenszel (12.19).

En el segundo caso, de filas ordinales y columnas nominales, se requiere una generalización del test de la $\chi^2_{(c-1)}$ para la igualdad de puntuaciones medias $\bar{x}_j$ dado por (12.10). Una solución es el «estadístico ANOVA» del programa PROC FREQ de SAS. El caso con $c = 2$ tiene un interés particular, al ser la versión estratificada del test de tendencias en proporciones explicada en el apartado 12.2 (Mantel, 1963). Usando el índice h para designar un estrato en concreto, las cantidades T_h y $\text{Var}(T_h)$ se calculan a partir de (12.4) y (12.5) y la tendencia global es contrastada por el estadístico:

Tabla 12.8. Combinación de tendencias en las proporciones del personal de quirófano con anticuerpos frente a antígenos de la fiebre por humidificador.

		Edad (años)							
		-34 ($h = 1$)		35-44 ($h = 2$)		45- ($h = 3$)		Total	
Duración de la exposición (años)	Puntuación x	Anticuerpos							
		+	-	+	-	+	-	+	-
< 1	1	0	9	2	5	0	3	2	17
1-5	2	3	7	2	2	6	1	11	10
> 5	3	3	0	4	2	5	6	12	8
		6	16	8	9	11	10	25	35
$\sum x_{ih} f_{ih}$		15		18		27		60	
$\sum x_{ih}^2 f_{ih}$		10,36		15,53		26,19		52,08	
T_h		4,64		2,47		0,81		7,92	
Var (T_h)		2,15		3,43		2,87		8,45	

$$X^2 = \frac{(\sum_h T_h)^2}{\sum_h \text{Var} (T_h)} \quad (12.20)$$

distribuido aproximadamente como $\chi^2_{(1)}$.

Ejemplo 12.8

La tabla 12.8 muestra algunos datos de un estudio de Cockcroft et al. (1981). El personal que trabajó en un quirófano fue sometido a pruebas para detectar anticuerpos frente a antígenos del humidificador. El objetivo del estudio era establecer si había alguna relación entre la prevalencia de los anticuerpos y el tiempo de trabajo en el quirófano. La edad estuvo relacionada con la duración de la exposición y con los anticuerpos y fue necesario examinar la asociación de interés después de tener en cuenta la edad. Los cálculos se muestran en la tabla 12.8. El test estadístico es:

$$\begin{aligned} X^2 &= (7,92)^2/8,45 \\ &= 7,42 \text{ (1 gl)} \end{aligned}$$

Así pues, había indicios de alguna asociación después de tener en cuenta la edad ($P = 0,006$); si la edad se hubiese ignorado, la asociación habría parecido más fuerte ($X^2_{1a} = 9,53$ con el empleo de 12.6), pero su validez se habría puesto en duda debido al efecto de confusión de la edad.

El tercer caso, con dos factores ordinales, conduce (Mantel, 1963) a una generalización del estadístico de tipo correlación (12.11) distribuido aproximadamente como $\chi^2_{(1)}$:

$$X^2 = \frac{(\sum_h S_{xyh})^2}{\sum_h [S_{xsh} S_{ysh} / (N_h - 1)]} \quad (12.21)$$

Finalmente, en los recuentos mostrados en el apartado 12.4 es útil señalar la versión estratificada del test de tendencias. También en este caso, con el empleo del subíndice h para designar un estrato en concreto, el estadístico $\chi^2_{(1)}$ es:

$$\chi^2_{1P} = \frac{\left\{ \sum_h \left[\sum_i x_{hi}(r_{hi} - e_{hi}) \right] \right\}^2}{\sum_h \left[\sum_i e_{hi} x_{hi}^2 - (\sum_i e_{hi} x_{hi})^2 / R_h \right]} \quad (12.22)$$

Esta fórmula se obtiene a partir de (12.12) mediante la suma de los estratos antes de elevar al cuadrado el numerador y efectuando también la suma del denominador. Darby y Reissland (1981) hacen uso de este estadístico al comparar el número de muertes por varias causas en trabajadores expuestos a distintas dosis de radiación (la variable x) con las cantidades esperadas a partir de las personas-años de riesgo en las diferentes categorías (v. apartado 14.9). Los estratos fueron definidos por diversas características personales, incluidos la edad y el tiempo transcurrido desde el inicio de la ocupación.

12.8. Modelos lineales generalizados

En el capítulo 10 hemos examinado la regresión lineal múltiple y hemos observado que en este método el valor medio de la variable dependiente se expresa como una función lineal de un conjunto de variables explicativas y que para un valor observado de la variable dependiente existiría un término de error (10.1). El método clásico se aplica al caso en que los términos de error se distribuyen independiente y normalmente con media 0 y variancia constante. Por lo tanto, el método no puede aplicarse estrictamente en los casos en que la variable dependiente es cualitativa. Y, aún así, el concepto de una relación entre la distribución de una variable dependiente y varias variables explicativas es tan válido cuando la variable dependiente es cualitativa como cuando es continua. Por ejemplo, considérese una variable binomial que represente la presencia o la ausencia de enfermedad. Para un grupo homogéneo de sujetos, el número de afectados por la enfermedad se distribuirá según la distribución binomial con una probabilidad constante de padecer la enfermedad (apartado 2.5). A menudo, los sujetos no proceden de un grupo homogéneo sino que difieren en diversas variables asociadas a la probabilidad de presentar la enfermedad. Esto es, existiría una relación entre la probabilidad de presentar la enfermedad y un grupo de variables explicativas. Esta relación habitualmente no sería lineal, puesto que una relación lineal implicaría que las probabilidades sobrepasan el intervalo legítimo de 0 a 1 para algunos valores de las variables explicativas. Para ajustar la relación al marco de una regresión lineal es necesario aplicar una transformación, lo cual conduce a los métodos de *regresión logística* y de *análisis de probits*, que se estudiarán más adelante. Un segundo ejemplo sería cuando la variable dependiente se distribuye según la distribución de Poisson (apartado 2.6) y la esperanza del procedimiento de Poisson se relaciona con un número de variables explicativas. Aunque los métodos de regresión para analizar variables cualitativas se conocen desde hace varias décadas (p. ej., la 1.ª edición del texto de Finney *Probit Analysis*, en 1947), sólo se han utilizado ampliamente en situaciones diversas desde hace alrededor de una década. Un importante artículo de Nelder y Wedderburn (1972) desarrolló el concepto de *modelos lineales generalizados*, que situaba todos los modelos utilizados corrientemente dentro de un marco unificado. Esto condujo a la introducción de *software* informático para llevar a cabo los cálculos.

En este apartado consideramos algunas de las propiedades de los modelos lineales generalizados e ilustramos sus aplicaciones mediante ejemplos. Los lectores interesados en una exposición más detallada deben remitirse a los textos de McCullagh y Nelder (1989) y de Dobson (1990). Cox y Snel (1989) y Hosmer y Lemeshow (1989) proporcionan detalles sobre la regresión logística.

Teoría general

Considérese una variable aleatoria y distribuida según la densidad de probabilidad $f(y; \mu)$ donde μ es el valor esperado de y ; es decir,

$$E(y) = \mu \quad (12.23)$$

Supóngase que para cada observación y existe un conjunto de variables explicativas $x_1, x_2, \dots, x_p$ y que μ depende de los valores de estas variables. Supóngase además que después de alguna transformación de μ , $g(\mu)$, la relación es lineal; es decir,

$$\eta = g(\mu) = \alpha + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p \quad (12.24)$$

Luego, la relación entre y y las variables explicativas es un *modelo lineal generalizado*. La transformación, $g(\mu)$, se denomina *función de enlace*, puesto que proporciona el enlace entre la parte lineal del modelo, η , y su parte aleatoria, representada por μ . La función lineal, η , se denomina *predictor lineal*, y la distribución de y , $f(y; \mu)$, es la *distribución del error*.

Distribución normal

Cuando la distribución del error es normal, el modelo clásico de regresión lineal es:

$$E(y) = \alpha + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

Por lo tanto, a partir de (12.23) y (12.24), $\eta = \mu$ y la función de enlace es la igualdad $g(\mu) = \mu$. Así, la conocida regresión lineal múltiple forma parte de la familia de modelos lineales generalizados.

Distribución binomial

Puesto que el predictor lineal de (12.24) cubre un intervalo ilimitado, la función de enlace debe transformar μ , la probabilidad binomial, desde el intervalo 0 a 1 hasta el de $-\infty$ a ∞ . Dos transformadores que se emplean comúnmente para ello son la transformación probit (11.5)

$$g(\mu) = \Phi^{-1}(\mu)$$

donde Φ es la función de distribución acumulada de una variable normal estandarizada, y la transformación logit (11.7)

$$g(\mu) = \ln[\mu/(1 - \mu)]$$

$$y = \ln \left(\frac{r + \frac{1}{2}}{n - r + \frac{1}{2}} \right) \quad (12.28)$$

Si hay más valores esporádicos de p iguales a 0 o 1, probablemente será más acertado emplear (12.28) durante todo el proceso, pero es preferible utilizar el método de la máxima verosimilitud. El empleo de (12.28) también reduce el sesgo con valores pequeños de n .

A partir de (2.13) y (3.17), una fórmula aproximada para $\text{Var}(y)$ es:

$$\text{Var}(y) \simeq \frac{1}{n\pi(1 - \pi)} \quad (12.29)$$

que pueden estimarse mediante:

$$\frac{1}{npq} \quad (12.30)$$

Definiendo un coeficiente de ponderación

$$w = pq \quad (12.31)$$

podemos asociar un peso nw al logit y , y de ese modo ponderar cada valor de y en proporción inversa a su variancia. Éste es el planteamiento general adoptado en un análisis ponderado (apartado 7.2) y podemos esperar que el método general de regresión ponderada nos proporcione una solución aproximada.

Este modelo sería del tipo mostrado en (12.25). El método propuesto *no* es exacto; en primer lugar, porque las y no se distribuyen normalmente en sus valores poblacionales y, en segundo lugar, porque la ponderación utilizada para cualquier y no está exactamente en proporción inversa a la $\text{Var}(y)$, al expresarse en función de la proporción estimada p . Por esta razón, la ponderación a menudo se denomina *empírica*.

En los problemas que requieren un enfoque mediante el análisis de la variancia, la ponderación empírica sustituye al número de observaciones de un subgrupo determinado. Puesto que los distintos valores de nw serán en general diferentes, la situación es análoga a un diseño experimental desbalanceado y a menudo pueden emplearse los métodos de análisis no ortogonal (apartado 10.4).

Ejemplo 12.9

La tabla 12.9 muestra algunos datos comunicados por Lombard y Doering (1974) a partir de una encuesta sobre conocimientos acerca del cáncer. Estos datos fueron utilizados por otros autores (Dyke y Patterson, 1952; Naylor, 1964). Cada línea de la tabla corresponde a una combinación específica de factores en una ordenación factorial 2^4 , siendo n el número de sujetos en cada categoría y r el número de sujetos que obtuvieron una buena puntuación en sus respuestas al cuestionario sobre conocimientos acerca del cáncer. Los cuatro factores eran: A, lectura de periódicos; B, escuchar programas de radio; C, lecturas serias; D, asistencia a conferencias.

A pesar de que los datos se obtuvieron a partir de una encuesta y no de un experimento aleatorio, podemos analizar cuidadosamente el efecto de los cuatro factores principales y de sus interacciones

Tabla 12.9. Conjunto de proporciones factoriales 2⁴ (Lombard y Doering, 1947).

Combinación de factores	(1) Número de sujetos <i>n</i>	(2) N.º de sujetos con buenas puntuaciones <i>r</i>	(3) Proporción (2)/(1) <i>p</i>	(4) Logit (<i>p</i>) <i>y</i>	(5) Coeficiente de ponderación <i>w = pq</i>	(6) Ponderación (1) x (5) <i>nw</i>	(7) Variancia 1/(6) <i>1/nw</i>
(1)	477	84	0,176	-1,54	0,1450	69,16	0,014
(a)	231	75	0,325	-0,73	0,2194	50,68	0,020
(b)	63	13	0,206	-1,35	0,1636	10,31	0,097
(ab)	94	35	0,372	-0,52	0,2336	21,96	0,046
(c)	150	67	0,447	-0,21	0,2472	37,08	0,027
(ac)	378	201	0,532	0,13	0,2490	94,12	0,011
(bc)	32	16	0,500	0,00	0,2500	8,00	0,125
(abc)	169	102	0,604	0,42	0,2392	40,42	0,025
(d)	12	2	0,167	-1,61	0,1391	1,67	0,600
(ad)	13	7	0,538	0,15	0,2486	3,23	0,310
(bd)	7	4	0,571	0,29	0,2450	1,72	0,581
(abd)	12	8	0,667	0,69	0,2222	2,67	0,375
(cd)	11	3	0,273	-0,98	0,1985	2,18	0,459
(acd)	45	27	0,600	0,41	0,2400	10,80	0,093
(bcd)	4	1	0,250	-1,10	0,1875	0,75	1,333
(abcd)	31	23	0,742	1,06	0,1914	5,93	0,169

sobre el conocimiento acerca del cáncer. En un diseño 2^p factorial con efectivos desproporcionados, el análisis habitual de la variancia no es apropiado, pero pueden estimarse los efectos principales y las interacciones, aunque ya no sean ortogonales.

Por ejemplo, en el efecto principal de A, los otros tres factores forman ocho estratos. El efecto de A puede estimarse en cada estrato, y dichas estimaciones pueden combinarse adecuadamente. El método es, en esencia, el mismo que el usado en (8.25) para la estimación de un efecto de fila en una tabla $2 \times c$ no ortogonal. Cada estrato proporciona una diferencia, $d = y_1 - y_2$, una $\text{Var}(d)$ estimada, obtenida a partir de la suma de las dos entradas en la columna (7) de la tabla 12.9, y una ponderación igual a la recíproca de la $\text{Var}(d)$. Éstas son las siguientes:

	d	$\text{Var}(d)$	w
$(a) - (1)$	0,81	0,034	29,2
$(ab) - (b)$	0,83	0,143	7,0
$(ac) - (c)$	0,34	0,038	26,6
$(abc) - (bc)$	0,42	0,150	6,7
$(ad) - (d)$	1,76	0,910	1,1
$(abd) - (bd)$	0,40	0,956	1,0
$(acd) - (cd)$	1,39	0,552	1,8
$(abcd) - (bcd)$	2,16	1,502	0,7
			74,1

Los valores de d pueden combinarse en una media ponderada, como en (8.25), lo cual da:

$$\bar{d} = 47,67/74,1 = 0,643$$

$$\text{Var}(\bar{d}) = 1/\sum w = 0,0135$$

y

$$(\text{ET})(\bar{d}) = 0,116$$

Un test del efecto se obtiene mediante $d/\text{ET}(d)$, evaluado como desviación normal estandarizada, o su cuadrado como una variación $\chi^2_{(1)}$. Las estimaciones de los cuatro efectos principales, con errores tipo y test estadísticos, son las siguientes:

	$\bar{d}$	$\text{ET}(\bar{d})$	z	P
A	0,643	0,116	5,54	< 0,001
B	0,292	0,124	2,35	0,019
C	0,997	0,111	8,98	< 0,001
D	0,441	0,196	2,25	0,024

El método aproximado es adecuado cuando el tamaño de la mayoría de las muestras es razonablemente grande y pocas p se encuentran cerca de 0 o 1. Si las proporciones p se basan sólo en $n = 1$ observación, sus valores serán 0 o 1, y no podrá emplearse el método empírico. Esta situación ocurre en el análisis de datos de pronóstico, en los que se clasifica cada paciente como «éxito» o «fracaso» se observan diversas variables explicativas x_j y el objeto del estudio es predecir la probabilidad de «éxito» en función de las x .

Máxima verosimilitud

Un método general de estimación, el de la *máxima verosimilitud*, presenta ciertas propiedades teóricas deseables y puede aplicarse en las circunstancias comentadas anteriormente, cuando el método empírico no es satisfactorio. La verosimilitud de los datos es proporcional a la probabilidad de obtenerlos (apartado 2.8). Para datos cuya forma de distribución es conocida y cuyo valor medio se proporciona en función de un modelo lineal generalizado, se puede hallar la probabilidad de los datos observados empleando las distribuciones de probabilidad adecuadas. Por ejemplo, en la regresión logística se puede calcular la probabilidad de cada grupo o cada sujeto empleando en (2.9) la probabilidad binomial de (12.25) y la verosimilitud de la totalidad de los datos es el producto de dichas probabilidades de todos los grupos o sujetos. Esta verosimilitud depende de los valores de los coeficientes de regresión, y las estimaciones de la máxima verosimilitud de estos coeficientes de regresión son los valores que aumentan al máximo la verosimilitud, es decir, los valores en que los datos tienen mayor probabilidad de ocurrir. Por motivos teóricos, así como por razones prácticas, es preferible trabajar con el logaritmo de la verosimilitud. De este modo, lo que se maximiza es la log-verosimilitud, L . Este método también proporciona el error tipo de los coeficientes de regresión estimados, así como los tests de significación de las hipótesis específicas.

Por analogía con el análisis de la variancia para una variable continua, en los modelos lineales generalizados se emplea el *análisis de desviación*. La *desviación* se define como el doble de la diferencia entre la log-verosimilitud de un modelo que se ajuste perfectamente y la del modelo actual, y sus grados de libertad asociados son iguales a la diferencia del número de parámetros entre estos dos modelos. Cuando la distribución del error queda totalmente definida por el vínculo entre las partes aleatoria y lineal del modelo —como es el caso de las variables binomiales y de Poisson, pero no el de una variable normal que también requiera el tamaño de la variancia—, las desviaciones siguen aproximadamente la distribución χ^2 y pueden emplearse para evaluar la significación. En particular pueden utilizarse las reducciones de la desviación causadas por la adición de términos suplementarios al modelo, para valorar si esta inclusión ha producido una mejoría significativa del modelo. Este procedimiento es análogo al que se ha descrito en el apartado 10.4 para una variable continua.

El procedimiento de ajuste del modelo usando el método de la máxima verosimilitud a menudo implica una iteración, es decir, la repetición de una secuencia de cálculos hasta conseguir una solución estable. Se emplean ponderaciones ajustadas y, dado que éstas dependen de las estimaciones de los parámetros, cambiarán de un ciclo a otro de la iteración. La solución aproximada obtenida mediante la ponderación empírica puede ser el primer ciclo de este proceso iterativo, y el conjunto del proceso a menudo se denomina *ponderación iterativa de cuadrados mínimos*. No explicaremos los detalles técnicos de este procedimiento, porque es bastante tedioso y resulta indispensable utilizar un programa informático general, por ejemplo, PROC LOGISTIC en el programa SAS, LOGISTIC REGRESSION en SPSS o GLIM (para mayor información sobre el método de la verosimilitud máxima véase Wetherill, 1981).

Ejemplo 12.10

Los datos utilizados en el ejemplo 12.9 se analizarán ahora mediante la máxima verosimilitud. Hay 16 grupos de sujetos; y un modelo que contenga todos los efectos principales y todas las interacciones se

ajustaría a los datos perfectamente. Por lo tanto, por definición su desviación sería cero y puede servir como punto de referencia a la valoración del ajuste de modelos más sencillos.

El primer modelo de regresión logística que se ha ajustado es el que contiene sólo los efectos principales. Esto da origen a un modelo en el que el logit de la probabilidad de obtener una buena puntuación se estima mediante:

	- 1,460	+ 0,650A	+ 0,310B	+ 0,981C	+ 0,420D
(ET):	0,115	0,122	0,111	0,191	
Z:	5,65	2,54	8,84	2,20	
P:	< 0,001	0,011	< 0,001	0,028	

Aquí, los términos relacionados con A, B, C y D se incluyen cuando estos factores están presentes; de lo contrario, se omiten.

Las estimaciones de los efectos principales y de sus errores tipo se acercan a las estimaciones ponderadas dadas en el ejemplo 12.9. La significación de los efectos principales se puede examinar mediante el cociente entre su estimación y su error tipo calculado como desviación normal estandarizada. Esto se conoce como test de *Wald*, y su cuadrado, como el χ^2 de *Wald*. También puede establecerse la significación mediante el análisis de la desviación ajustando el modelo que contenga sólo los efectos principales de B, C y D, lo cual da una desviación de 45,47 con 12 gl. La suma del efecto principal de A al modelo reduce la desviación a 13,59 con 11 gl, de modo que el test de la desviación para el efecto de A, después de tener en cuenta B, C y D, es $45,47 - 13,59 = 31,88$ como una aproximación de $\chi^2_{(1)}$. Dicho test es numéricamente equivalente al test de la z, ya que $\sqrt{31,88} = 5,65$, pero en general no se espera una coincidencia tan exacta. Aunque en este caso no se requieren tests de la desviación de los efectos principales, por lo general sí son necesarios. Por ejemplo, si se ajustara un factor con más de dos niveles, usando variables ficticias (apartado 10.2), se requeriría un test de la desviación, aplicando los grados de libertad correctos.

La desviación asociada al modelo que incluye todos los efectos principales es 13,59 con 11 gl, lo cual representa las 11 interacciones no incluidas en el modelo. Si se toma la desviación como una $\chi^2_{(11)}$, no hay indicios de que las interacciones sean significativas, y el modelo sólo con los efectos principales es un buen ajuste. Todavía existe la posibilidad de que una de las dos interacciones de dos factores sea significativa. Por lo tanto, es prudente incluir, por turnos, cada una de las seis interacciones de dos factores en el modelo. Por ejemplo, cuando se incluye la interacción de dos tipos de lecturas, AC, la desviación se reduce a 10,72 con 10 gl. Esta interacción tiene, por lo tanto, una $\chi^2_{(1)}$ aproximada de 2,87, que no es significativa ($P = 0,091$). De forma análoga, ninguna de las dos interacciones restantes es significativa.

Ejemplo 12.11

Considérense los datos de la tabla 8.14 que ya se han analizado en los ejemplos 8.9 y 10.5. Los datos incluyen 41 varones clasificados en tres grupos de edad y en dos grupos de tratamiento. La variable que se analiza es el número de accidentes cerebrovasculares. Esta variable toma valores enteros, y el valor observado más alto es 3. Si se considera que el número de accidentes tiene una distribución de Poisson con una esperanza que depende de la edad y del grupo de tratamiento, entonces será adecuado aplicar un modelo log-lineal (12.26).

Se han ajustado varios modelos a escala log-lineal y se ha construido el siguiente análisis de la desviación:

Análisis de la desviación

Ajuste	Desviación	gl	Efecto	Diferencia de la desviación	gl
Término constante	40,54	40			
Tratamiento, T	31,54	39	T (no ajustado)	9,00	1
Edad, E	37,63	38	E (no ajustada)	2,91	2
T + E	28,84	37	T (ajustado)	8,79	1
			E (ajustada)	2,70	2
T + E + T x E	27,04	35	T x A	1,80	2

La valoración del efecto del tratamiento teniendo en cuenta la edad se obtiene a partir de la diferencia de la desviación, después de añadir el efecto del tratamiento a un modelo que ya contiene la edad, o sea $37,63 - 28,84 = 8,79$ (1 gl). De forma similar, el efecto de la edad ajustado según el tratamiento tiene un test estadístico de 2,70 (2 gl). Como antes, no existen indicios de interacción entre el tratamiento y la edad o de que la edad sea un efecto principal.

El modelo log-lineal que ajusta sólo el tratamiento es:

$$\ln \mu = 0,00 - 1,386 (\text{grupo que recibe tratamiento})$$

$$ET: (0,536)$$

que proporciona esperanzas ajustadas de $\exp(0,00) = 1,00$ para el grupo control y $\exp(-1,386) = 0,25$ para el grupo que recibe tratamiento. Estos valores son idénticos a los valores observados (25 accidentes en 25 varones del grupo control y 4 accidentes en 16 varones del grupo que recibe tratamiento), pero esta circunstancia cambiaría si se hubiese demostrado que era necesario ajustar para la edad.

La desviación de 27,04 con 35 gl después de ajustar para todos los efectos es una medida de lo bien que el modelo de Poisson se ajusta a los datos. Sin embargo, no sería válido considerar esta desviación como una aproximación $\chi^2_{(35)}$ a causa del pequeño número sobre el cual se basa. Nótese que esta restricción no se aplica a los tests de efectos principales e interacciones, puesto que estas comparaciones se basan en datos amalgamados, como se ha ilustrado en el caso del efecto del tratamiento.

Los datos del ejemplo 10.7 podrían analizarse utilizando la regresión logística. En este caso, cada una de las proporciones observadas se basa en una sola observación. Como modelo podemos suponer que el logit de la probabilidad de supervivencia de la población, Y , estaba relacionado con la hemoglobina, x_1 , y con la bilirrubina, x_2 , mediante la fórmula de regresión logística lineal (12.25):

$$Y = \alpha + \beta_1 x_1 + \beta_2 x_2$$

La aplicación del método de la máxima verosimilitud dará las siguientes estimaciones de α , β_1 , y β_2 con sus respectivos errores tipo:

$$\begin{aligned}\hat{\alpha} &= -2,354 \pm 2,416 \\ \hat{\beta}_1 &= 0,5324 \pm 0,1487 \\ \hat{\beta}_2 &= -0,4892 \pm 0,3448\end{aligned}\tag{12.32}$$

go relativo de cáncer en veteranos en comparación con los no veteranos, después de controlar la edad, es $\exp(-0,0035) = 1,00$. Los límites de confianza del 95% son $\exp(-0,0035 \pm 1,96 \times 0,0555) = 0,89$ y 1,11.

Regresión polítoma

Los procedimientos descritos en apartados anteriores de este capítulo para el análisis de datos categóricos ordinales están limitados en dos aspectos. Son correctos para estructuras de datos relativamente simples, en que los factores en estudio son pocos; hasta ahora se ha hecho hincapié principalmente en los tests de significación y apenas se ha analizado la necesidad de describir la naturaleza de las asociaciones reveladas por los tests. Ambas limitaciones son resueltas por modelos lineales generalizados, que relacionan la distribución de la respuesta categórica ordinal con varias variables explicativas. Como las variables de respuesta de este tipo tienen más de dos categorías, a menudo se las denomina *respuestas polítomas*, y a los procedimientos correspondientes, *regresión polítoma*.

Estos planteamientos se describen muy brevemente a continuación. Las dos primeras son generalizaciones de la regresión logística, y la tercera está relacionada con explicaciones anteriores (v. (12.7)) acerca de comparaciones entre puntuaciones medias.

Modelo logits acumulados

Desígnese la variable de respuesta polítoma como Y , y una categoría determinada de Y , como j . El conjunto de variables explicativas $x_1, x_2, \dots, x_p$ se designará mediante el vector $\mathbf{x}$. Si

$$F_j(\mathbf{x}) = P(Y \leq j, \text{ dado } \mathbf{x})$$

y

$$\begin{aligned} L_j(\mathbf{x}) &= \text{logit } F_j(\mathbf{x}) \\ &= \ln \left[\frac{F_j(\mathbf{x})}{1 - F_j(\mathbf{x})} \right] \end{aligned}$$

El modelo se describe mediante la ecuación:

$$L_j(\mathbf{x}) = \alpha_j - \beta^* \mathbf{x} \quad (12.34)$$

donde $\beta^* \mathbf{x}$ representa la función lineal habitual de las variables explicativas, $\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$.

Este modelo proporciona eficazmente una regresión logística, como en (12.25), para cada una de las variables binarias producidas al extraer límites entre dos categorías adyacentes. Por ejemplo, si hay cuatro categorías numeradas del 1 al 4, hay tres variables binarias que representan los fraccionamientos entre 1 y 2-4, 1-2 y 3-4, y 1-3 y 4. Además, los coeficientes de regresión β para las variables explicativas son los mismos para todos los fraccionamientos, aunque el término de intersección α_j varía según el fraccionamiento.

Aunque podría efectuarse una regresión logística tipo para cualquiera de las divisiones, se requiere un análisis bastante más complejo para tener en cuenta las interrelaciones entre

los datos para diferentes divisiones. Existen programas informáticos (p. ej., en SAS) para estimar los coeficientes en el modelo y su precisión, bien mediante la máxima verosimilitud (como en LOGIST de SAS), bien mediante mínimos cuadrados ponderados (como en CATMOD de SAS); este último es menos fidedigno cuando muchas de las frecuencias de los datos originales son bajas.

Modelo de categorías adyacentes

Aquí definimos los logits en términos de las probabilidades para categorías adyacentes. Definimos:

$$L_j = \ln \left(\frac{\pi_j}{\pi_{j+1}} \right)$$

donde π_j es la probabilidad de encontrarse en la categoría de respuesta j . El modelo se describe mediante la ecuación:

$$L_j(x) = \alpha_j - \beta'x \quad (12.35)$$

Cuando sólo hay dos categorías de respuesta, (12.34) y (12.35) son completamente equivalentes y tanto el modelo de logits acumulados como el de categorías adyacentes se reducen a la regresión logística común. En el caso más general, con más de dos categorías, existen programas informáticos para el cálculo de los coeficientes. Por ejemplo, el CATMOD de SAS emplea mínimos cuadrados ponderados.

Modelo de respuesta media

Supóngase que se asignan puntuaciones x a las categorías, como en el apartado 12.2, y désígnese como $M(x)$ la puntuación media de los individuos con variables explicativas x . El modelo especifica la misma relación lineal que en la regresión múltiple:

$$M(x) = \alpha - \beta'x \quad (12.36)$$

El procedimiento es, por lo tanto, una generalización del que está en la base de la comparación de las puntuaciones medias por (12.7) en el caso simple de dos grupos. En el caso general, los coeficientes de regresión no pueden calcularse con exactitud mediante métodos de regresión múltiple tipo, porque puede haber desviaciones grandes con respecto a la normalidad y disparidades en la variancia. Tampoco es posible explotar con facilidad variancias exactas como (12.5). Existen programas informáticos para el cálculo mediante mínimos cuadrados ponderados (p. ej., CATMOD de SAS).

Elección del modelo

La elección entre los modelos descritos anteriormente, o entre cualesquiera otros, es en gran medida empírica: ¿cuál es el más práctico de emplear y cuál de ellos describe mejor los

muerte. Consideraremos la situación habitual, es decir, la estandarización de las tasas de mortalidad según la edad.

La idea básica de la estandarización es que introducimos una *población estándar* con una estructura fija de edades. La mortalidad de cualquier *población especial* se ajusta entonces para tener en cuenta las discrepancias en la estructura de edades entre ambas poblaciones. Existen dos estrategias principales: los métodos de estandarización *directos* e *indirectos*. A continuación ofreceremos una breve explicación que puede ampliarse con Hill y Hill (1991), Liddell (1960) o Kalton (1968).

Se empleará la siguiente notación.

Grupo de edad	Estándar			Especial		
	(1)	(2)	(3) Tasa de mortalidad (2)/(1)	(4)	(5)	(6) Tasa de mortalidad (5)/(4)
1	Población N_1	Muertes R_1	P_1	Población n_1	Muertes r_1	p_1
...						
i	N_i	R_i	P_i	n_i	r_i	p_i
...						
k	N_k	R_k	P_k	n_k	r_k	p_k

Método directo

La tasa de mortalidad estandarizada de una población especial, mediante el método directo, es:

$$p' = \frac{\sum N_i p_i}{\sum N_i} \quad (12.37)$$

Ésta se obtiene aplicando las tasas especiales de mortalidad, p_i , a los tamaños estándar de la población, N_i . Alternativamente se puede considerar que p' es la media ponderada de p_i , utilizando N_i como ponderación. La variancia de p' puede estimarse como:

$$\text{Var}(p') = \frac{\sum (N_i^2 p_i q_i / n_i)}{(\sum N_i)^2} \quad (12.38)$$

donde $q_i = 1 - p_i$; si, como ocurre a menudo, todas las p_i son pequeñas y la variancia binomial de p_i , $p_i q_i / n_i$, puede sustituirse por el término de Poisson $p_i / n_i (= r_i / n_i^2)$, dando:

$$\text{Var}(p') \simeq \frac{\sum (N_i^2 p_i / n_i)}{(\sum N_i)^2} \quad (12.39)$$

Para comparar dos poblaciones especiales, A y B, podemos calcular una tasa estandarizada para cada (p'_A y p'_B) y considerar:

$$\bar{d} = p'_A - p'_B$$

A partir de (12.37),

$$\bar{d} = \frac{\sum N_i(p_{Ai} - p_{Bi})}{\sum N_i}$$

que tiene exactamente la misma forma que (12.14), con $w_i = N_i$ y $d_i = p_{Ai} - p_{Bi}$ como en (12.13)). Este método difiere del test de Cochran sólo en el empleo de un sistema de pesos distintos. La variancia de $\bar{d}$ se obtiene mediante:

$$\text{Var}(\bar{d}) = \frac{\sum N_i^2 \text{Var}(d_i)}{(\sum N_i)^2} \quad (12.40)$$

con $\text{Var}(d_i)$ proporcionada por (12.16). También en este caso cuando las p_{0i} son pequeñas, q_{0i} puede considerarse aproximadamente igual a 1 en (12.16).

La variancia dada por (12.39) puede resultar no satisfactoria para la construcción de los límites de confianza si el número de muertes en los grupos de edad separados es pequeño, puesto que la aproximación normal es entonces no satisfactoria y los límites de Poisson son asimétricos (apartado 4.10). La tasa estandarizada (12.37) es una suma ponderada de los recuentos de Poisson, r_i . Dobson et al. (1991) proporcionaron un método para calcular un intervalo de confianza aproximado basado en el intervalo de confianza del número total de muertes.

Ejemplo 12.13

En la tabla 12.11 podría calcularse la tasa estandarizada p^* para cada población. ¿Cuál debe tomarse como población estándar? No existe una respuesta única a esta pregunta. La elección puede no afectar en demasía la comparación de dos poblaciones, aunque es seguro que afectará los valores absolutos de las tasas estandarizadas. Si el contraste entre las tasas específicas según la edad varía mucho en distintos grupos de edad, deberemos decidir si deseamos que las tasas estandarizadas reflejen especialmente la posición de ciertas partes de la escala de edades; por ejemplo, puede ser conveniente otorgar menos peso a los grupos de mayor edad porque el objetivo del estudio es principalmente la comparación de la mortalidad en edades tempranas o porque la información para las edades superiores es menos fiable o porque las tasas de mortalidad en edades altas están más afectadas por el error de muestreo.

En la tabla 12.11 se proporcionan las tasas estandarizadas según tres opciones de población estándar: a) población A, b) población B y c) una hipotética población C cuya distribución proporcionada se encuentra a medio camino entre A y B, o sea:

$$N_{Ci} \propto \frac{1}{2} \left(\frac{n_{Ai}}{\sum n_{Ai}} + \frac{n_{Bi}}{\sum n_{Bi}} \right)$$

Obsérvese que para el método a) la tasa estandarizada según A coincide con la tasa bruta; de forma similar, para b) la tasa estandarizada de B coincide con la tasa bruta. Aunque los valores absolutos de las tasas estandarizadas de las tres opciones de población estándar son distintas, en términos generales es el mismo en cada caso.

Tabla 12.11. Tasas de mortalidad (TM) de dos poblaciones, A y B, con el método de estandarización directa, utilizando A, B y una población intermedia C.

Edad (años)	A				B				C			
	Población		TM específica por edad por 1.000		Población		TM específica por edad por 1.000		Población		TM específica por edad por 1.000	
	Miles	%	Muertes		Miles	%	Muertes		Miles	%	Muertes	
0-	2.000	8,97	10.000	4,76	185	14,51	4.100	22,16	1.174	11,74	1.174	11,74
5-	1.900	8,12	800	0,42	170	13,33	100	0,59	1.072	10,72	1.072	10,72
10-	1.700	7,26	700	0,41	160	12,55	100	0,62	990	9,90	990	9,90
15-	1.900	8,12	2.000	1,05	120	9,41	180	1,50	876	8,76	876	8,76
20-	1.700	7,26	1.700	1,00	100	7,84	190	1,90	755	7,55	755	7,55
25-	1.500	6,41	1.400	0,93	80	6,27	160	2,00	634	6,34	634	6,34
30-	1.500	6,41	1.700	1,13	70	5,49	170	2,43	595	5,95	595	5,95
35-	1.500	6,41	2.700	1,80	65	5,10	200	3,08	576	5,76	576	5,76
40-	1.600	6,84	4.800	3,00	65	5,10	270	4,15	597	5,97	597	5,97
45-	1.500	6,41	7.800	5,20	60	4,71	370	6,17	556	5,56	556	5,56
50-	1.500	6,41	14.200	9,47	55	4,31	530	9,64	536	5,36	536	5,36
55-	1.500	6,41	23.800	15,87	40	3,14	690	17,25	478	4,78	478	4,78
60-	1.300	5,56	34.900	26,85	30	2,35	880	29,33	396	3,96	396	3,96
65-	900	3,85	40.700	45,22	30	2,35	1.500	50,00	310	3,10	310	3,10
70-	600	2,56	42.000	70,00	20	1,57	1.520	76,00	207	2,07	207	2,07
75-	700	2,99	98.100	140,14	25	1,96	4.100	164,00	248	2,48	248	2,48
Total	23.400	99,99	287.300		1.275	99,99	15.060		10.000		10.000	
Tasa bruta												
<i>a) Estandarización según la población A</i>												
Muertes esperadas			287.300									
Tasa estandarizada				12,28							11,81	
<i>b) Estandarización según la población B</i>												
Muertes esperadas			10.242									
Tasa estandarizada				8,03							11,81	
<i>c) Estandarización según la población C</i>												
Muertes esperadas			101.657									
Tasa estandarizada				10,17							13,73	

Ejemplo 12.14

La tabla 12.12 muestra algunos datos sobre mortalidad ocupacional, campo en el que la tasa de mortalidad estandarizada se emplea a menudo. La población especial representa a los granjeros que en 1951 tenían de 20 a 65 años. La población estándar representa a todos los varones de estos grupos de edad, tanto a los que trabajan como a los que están jubilados. Se empleará la mortalidad de los granjeros durante un período de 5 años, para reducir los errores de muestreo, y el número de muertes esperadas y observadas se expresó en base a un período de 5 años.

La TME es:

$$100 M = \frac{(100)(7.678)}{11.005} = 69,8\%$$

y

$$\text{Var}(\text{SMR}) = 10^4 \text{Var}(M)$$

$$= \frac{(10^4)(7.678)}{(11.005)^2} \text{ a partir de (12.43)}$$

$$= 0,634$$

y

$$\text{ET}(\text{SMR}) = 0,80\%$$

En las estadísticas vitales es característico encontrar un error tipo de la TME tan pequeño como el del ejemplo 12.14, razón por la cual, en este tipo de estudios, los errores de muestreo a menudo se ignoran. De hecho, existen problemas en la interpretación de las estadísticas sobre mortalidad ocupacional que a menudo eclipsan a los errores de muestreo. Por ejemplo, las profesiones pueden estar registradas de forma menos fiable en el censo que en los registros de defunción, y ello puede originar sesgos en la estimación de las tasas de mortalidad de ciertas profesiones. Incluso cuando los datos son totalmente fiables, no está claro si la existencia de una TME particularmente elevada o baja para una profesión específica representa un riesgo de salud en esta profesión o una tendencia en grupos de sujetos específicos para adoptar esta profesión. En el ejemplo 12.14, por ejemplo, la TME de los granjeros puede ser baja porque el trabajo en las granjas es saludable o porque es improbable que los sujetos con poca salud trabajen en granjas o porque están más predispuestos a dejar este

Tabla 12.12. Mortalidad de los granjeros de Inglaterra y Gales de 1949 a 1953, en comparación con la de la población de varones.

Edad i	(1) Tasa de mortalidad anual $\times 10.000$, todos varones (1949-1953) $(1/5) P_i \times 10^5$	(2) Granjeros, censo de la población de 1951 n_i	(3) Muertes de granjeros 1949-1953 r_i	(4) Muertes en 5 años $5 \times (1) \times (2) \times 10^{-5}$ $n_i P_i$
20-	129,8	8.481	87	55
25-	152,5	39.729	289	303
35-	280,4	65.700	733	921
45-	816,2	73.376	1.998	2.994
55-64	2.312,4	58.226	4.571	6.732
			7.678	11.005

Fuente: Registrar General of England and Wales (1958).

tipo de trabajo. Obsérvese también que en el grupo de edad inferior existe un *exceso* de muertes entre los granjeros (87 observadas, 55 esperadas). Cualquier método de estandarización entraña un riesgo de sobresimplificación, y los investigadores siempre deberían comparar las tasas específicas según la edad para averiguar si los contrastes entre poblaciones varían mucho con la edad.

El método de estandarización indirecta es muy similar al descrito como comparación entre frecuencias observadas y esperadas en la página 395. De hecho, si en la comparación entre dos grupos, A y B, la población estándar se definiera como la población agrupada A + B, los métodos serían exactamente los mismos que los usados en el método de Cochran-Mantel-Haenszel (pág. 396). En la página 414 hemos visto que el test de Cochran es equivalente a una comparación entre dos tasas estandarizadas *directamente*. Por lo tanto, existe un vínculo estrecho entre los métodos directo e indirecto cuando la población estándar se elige como la suma de dos poblaciones especiales.

La TME es una media ponderada, a lo largo de grupos de edad separados, de los cocientes entre las tasas de mortalidad observadas en la población especial y las tasas de mortalidad en la población estándar, con ponderaciones que dependen de la distribución de edades de la población especial. Esto significa que las TME calculadas para varias poblaciones especiales no son estrictamente comparables (Yule, 1934), puesto que se han calculado con diferentes ponderaciones. Las TME serán comparables según la hipótesis de que el cociente entre las tasas de mortalidad en la población especial y en la población estándar es independiente de la edad, es decir, en una situación de riesgos proporcionales (apartado 14.8).

La relación entre los modelos lineales estandarizados y los generalizados ha sido estudiada por Little y Pullum (1979) y por Freeman y Holford (1980).

12.10. Medida kappa de concordancia

Cuando una variable categórica es difícil de registrar objetivamente, es práctica común usar más de un evaluador para estimar la variable y emplear en el análisis principal de datos la media o la mediana de los valores. No obstante, es prudente confirmar, antes del cálculo de cualquier tipo de valor promedio, que los evaluadores empleen las categorías de manera similar, ya que de otro modo no estaría claro qué representan los valores promedio. Dos ejemplos son la evaluación de la clasificación de un trastorno en una escala con dos categorías, o más basadas en una valoración de los signos y síntomas iniciales y la lectura de radiografías de tórax.

En primer lugar, considérese el caso en que sólo hay dos categorías, presencia o ausencia de algún proceso patológico, y supóngase que los dos evaluadores valoran a n sujetos independientemente. Luego, los resultados se pueden distribuir en una tabla 2×2 de la siguiente manera:

Evaluador 1	Evaluador 2		
	Presente	Ausente	
Presente	a	b	$a + b$
Ausente	c	d	$c + d$
	$a + c$	$b + d$	n

Una manera natural de evaluar la concordancia entre los evaluadores consistiría en señalar que éstos coinciden en $a + d$ sujetos y expresarlo en términos del número de pacientes como el cociente $(a + d)/n$. Dos ejemplos ilustran la desventaja de este planteamiento simple:

A

Evaluador 1	Evaluador 2		
	Presente	Ausente	
Presente	5	5	10
Ausente	5	85	90
	10	90	100

B

Evaluador 1	Evaluador 2		
	Presente	Ausente	
Presente	35	5	40
Ausente	5	55	60
	40	60	100

En estos dos ejemplos los evaluadores coinciden en el 90% de los sujetos, pero la discrepancia parece mayor en el ejemplo A que en el B, puesto que en el primero hay coincidencia en que el trastorno está presente sólo en 5 sujetos de los 15 valorados al menos por uno de los evaluadores como portador del proceso patológico, mientras que en el segundo se coincide en que el trastorno está presente en 35 de los 45 sujetos calificados como portadores del proceso al menos por uno de los evaluadores.

Las dificultades se deben a que no se ha efectuado recuento alguno de las coincidencias que podrían producirse debido al azar. Si no hubiese una concordancia real entre los evaluadores, las frecuencias esperadas en las casillas de la tabla 2×2 serían determinadas al azar. Por ejemplo, se esperaría que en A hubiese 81 sujetos calificados de negativos por ambos evaluadores y un sujeto calificado como positivo por ambos, donde estas cifras esperadas se han calculado exactamente por los mismos métodos usados para calcular las frecuencias esperadas en un test de la χ^2 (apartado 4.9). La concordancia observada para 90 sujetos no parece ser impresionante cuando se contrasta con una concordancia esperada para 82 pacientes. En el ejemplo B el número esperado de concordancias es sólo de 52 y el número observado es mucho mayor.

El razonamiento anterior constituye la base de la medida *kappa* de concordancia, introducida por Cohen (1960). El método se explica como sigue: en primer lugar, se define I_o como medida observada de concordancia, e I_e como medida esperada correspondiente. Luego:

$$I_o = \frac{a + d}{n}$$

$$I_e = \frac{(a + c)(a + b) + (b + d)(c + d)}{n^2}$$

En segundo lugar, kappa se define como la diferencia entre la concordancia observada y la esperada como fracción de la diferencia máxima. Como el valor máximo de I_o es 1, esto da:

$$\kappa = \frac{I_o - I_e}{1 - I_e} \quad (12.45)$$

En los ejemplos A y B los valores de kappa son 0,44 y 0,79, respectivamente. El valor máximo de kappa es 1, que representa una concordancia perfecta, y tomará el valor cero si la concor-

dancia sólo se debe al azar. Aunque los valores negativos son matemáticamente posibles, lo cual representa una coincidencia en la falta de concordancia, en la práctica es improbable que se produzcan.

Ejemplo 12.15

En un estudio llevado a cabo por Bergen et al. (1992), dos evaluadores valoraron la discinesia tardía puntuando siete elementos en una escala de 5 puntos, codificados del 0 al 4. Según una definición de la discinesia tardía, habría dos puntuaciones mínimas de 2 o una con un mínimo de 3. En una serie de evaluaciones hubo 168 sujetos y la concordancia fue la siguiente:

Evaluador B	Evaluador A		
	Presente	Ausente	
Presente	123	10	133
Ausente	6	29	35
	129	39	168

Luego:

$$I_o = \frac{152}{168} = 0,905$$

$$I_e = \frac{129 \times 133 + 39 \times 35}{168^2} = 0,656$$

$$k = \frac{0,905 - 0,656}{1 - 0,656} = 0,72$$

La concordancia entre los dos evaluadores fue buena, de manera que las dos evaluaciones se combinaron y se registró la discinesia tardía en los pacientes que fueron diagnosticados por ambos evaluadores.

Kappa ponderada

Cuando hay más de dos categorías y están ordenadas, una diferencia entre evaluadores de sólo una categoría es una discrepancia menor que una diferencia de dos categorías, y una diferencia de tres categorías indicaría aún una mayor discrepancia, etc. Evidentemente, es deseable incorporar esto en una medida de concordancia, lo cual se lleva a cabo empleando la *kappa ponderada* (Cohen, 1968). Esta medida se calcula asignando un peso, w_i , a los sujetos en los cuales los evaluadores difieren en i categorías. Cuando los evaluadores están de acuerdo, el peso es la unidad, o sea, $w_0 = 1$. Si hay k categorías, la discrepancia máxima es de $k - 1$ categorías y a esto se le asigna un peso cero. El conjunto más frecuente de pesos para los valores intermedios consiste en que estén igualmente espaciados, lo que da:

$$w_i = 1 - \frac{i}{k - 1}$$

Resumiendo, tenemos:

$$I_o = 823,1/862 = 0,955$$

$$I_e = 788,0/862 = 0,914$$

$$k = \frac{0,955 - 0,914}{1 - 0,914} = 0,48$$

Hay una concordancia mediana.

La kappa ponderada y el coeficiente de correlación intraclases están relacionados, y si los pesos se obtuvieron como $w_i = 1 - i^2/(k - 1)^2$, la kappa ponderada y el coeficiente de correlación intraclases serían iguales excepto en los términos en $1/n$. En el ejemplo 12.16 la kappa ponderada usando estos pesos fue 0,620, y el coeficiente de correlación intraclases, usando los valores de las categorías, 0, 1, ..., 7, fue 0,621. Se deduce que el valor de kappa es afectado por la selección de sujetos a lo largo de los cuales se define, así como por la concordancia fundamental entre observadores. En cuanto al coeficiente de correlación intraclases, esto carece de importancia si el único propósito consiste en valorar la discrepancia entre evaluadores en un estudio en concreto, pero las comparaciones entre las kappas de diferentes estudios son difíciles de interpretar.

El error tipo de una kappa puede estimarse pero rara vez es necesario, ya que la estimación de la concordancia por lo general no es un fin en sí mismo. Asimismo, la discrepancia por lo general es mejor que la debida al azar, y un test de significación de la hipótesis nula de que no hay concordancia es innecesaria. Véanse más detalles en el capítulo 13 de Fleiss (1981). Según este autor, los valores de kappa superiores a 0,75 representan una concordancia excelente; los valores entre 0,4 y 0,75, una concordancia regular a buena, y los valores inferiores a 0,4, una concordancia mala. Usar una medida con una concordancia tan mala tendría poco sentido ya que no resultaría claro qué representa la medida.

Capítulo 13

Métodos no paramétricos

13.1. Introducción

Algunos de los métodos estadísticos descritos anteriormente en relación con los datos cualitativos implican suposiciones bastante simples: por ejemplo, los métodos χ^2 a menudo comprueban hipótesis simples sobre las probabilidades para diversas categorías (que son iguales o que son proporcionales a ciertas probabilidades marginales). Los métodos usados para los datos cuantitativos, en cambio, se basan en supuestos relativamente complejos sobre formas de distribución (que la variación aleatoria es normal, de Poisson, etc.). Es probable que estos supuestos sean claramente falsos; para superar este problema a veces argüimos que estos métodos son *robustos*, es decir, poco sensibles a la no normalidad. Otras veces podemos usar transformaciones para hacer los supuestos más verosímiles.

Obviamente, habría que decir algo sobre métodos que evitaran supuestos innecesarios sobre las distribuciones. Estos métodos denominados *métodos independientes de la distribución* o métodos-tests no paramétricos, existen y son ampliamente usados por algunos estadísticos. Los métodos estadísticos estándar con frecuencia utilizan estadísticos que de forma bastante obvia estiman ciertos parámetros de población; por ejemplo, la variación estimada de la muestra, s^2 , estima el parámetro poblacional σ^2 . En los métodos no paramétricos se hace poco hincapié en los parámetros poblacionales, puesto que su objetivo es evitar una forma de función particular para una distribución poblacional. Las hipótesis que han de ser contrastadas habitualmente se relacionan más con la naturaleza de la distribución en conjunto que con los valores supuestos por algunos de sus parámetros. Por esta razón a menudo se las denomina *hipótesis no paramétricas*, y a las técnicas adecuadas, tests o *métodos no paramétricos*.

La justificación del uso de los métodos no paramétricos residirá habitualmente en una de las siguientes directrices.

1. No normalidad obvia.
2. No normalidad posible, tal vez en grado muy pronunciado, pero los tamaños de las muestras pueden ser demasiado pequeños para establecer si ello es así o no.
3. Búsqueda de una técnica estadística rápida, que implique cálculos escasos o sencillos. Muchos métodos no paramétricos poseen esta propiedad: a menudo se usa el epíteto de J. W. Tukey «métodos rápidos y sucios» para describirlos.
4. Una medición para analizar puede constar de un número de categorías ordenadas, como --, -, 0, + y ++ para grados de mejoría clínica, o varias observaciones pueden formar un orden de rangos (p. ej., se puede pedir a los pacientes que clasifiquen seis fórmulas farmacéuticas según lo agradable de su sabor). En estos casos el investigador puede no estar dispuesto a asignar una escala numérica, pero desear emplear métodos que tengan presente el orden de rango de las observaciones. Muchos métodos no paramétricos son de este tipo.

El primer tipo de datos a que se hace referencia aquí, es decir los datos categóricos ordinales, ya ha sido explicado en el capítulo 12. Existe, de hecho, una relación estrecha entre algunos de los métodos descritos en el capítulo 12 y los que se explicarán en este capítulo.

Los métodos descritos en los siguientes apartados son simplemente algunas de las técnicas no paramétricas más útiles. Se trata sobre todo de tests de significación y no siempre se adaptan fácilmente para los fines de la estimación. No obstante, muchas veces puede decirse que la estadística empleada en los tests estima algo, aun cuando el parámetro estimado puede tener un interés limitado. Por consiguiente, aquí se describen brevemente algunos procedimientos de estimación, aunque se hará hincapié en los tests de significación. En el apartado 13.6 se tratan algunas de las cuestiones generales acerca del empleo de los métodos no paramétricos.

Se ofrecen explicaciones más completas de los métodos no paramétricos en los textos de Siegel y Castellan (1988), que se centran en los tests de significación, Lehmann (1975) y Conover (1980).

13.2. Pruebas de colocación con una muestra

En este apartado consideramos contrastes de la hipótesis nula sobre si la distribución de una variable aleatoria x es simétrica con respecto a cero. Si, en algún problema, la hipótesis natural que se contrasta es la de simetría con respecto a algún otro valor, μ , todo lo que ha de hacerse es restar μ en cada observación; entonces se puede emplear el test de simetría con respecto a cero. La necesidad de comprobar la simetría con respecto a cero surge con frecuencia en comparaciones apareadas de dos tratamientos, donde la variable x es igual a la diferencia entre dos lecturas emparejadas.

El test de la teoría normal para esta hipótesis es, naturalmente, el test de la t con una sola muestra. Ilustraremos estos métodos remitiéndonos a la tabla 4.1, cuyos datos se analizaron por un test de la t apareada en el ejemplo 4.3.

Test del signo

Supóngase que las observaciones en una muestra de tamaño n son $x_1, x_2, \dots, x_n$ y, de éstas, r son positivas y s negativas. Algunos de los valores de x podrían ser exactamente cero, en cuyo caso no se contarían ni con los positivos ni con los negativos. La suma $r + s$ podría, por lo tanto, ser menor que n , y se denominará n' .

En la hipótesis nula, los valores positivos y negativos de x son igualmente probables. Por lo tanto, tanto r como s siguen una distribución binomial con parámetros n' (en lugar de la n del apartado 2.5) y $1/2$ (por el parámetro π del apartado 2.5). Valores excesivamente grandes o pequeños de r (o, de forma equivalente, de s) pueden ser contrastados con exactitud mediante las tablas de la distribución binomial. Para muestras suficientemente grandes puede emplearse cualquiera de las aproximaciones normales (4.11), (4.12), (4.28) (4.29), con r y s sustituyendo a x_1 y x_2 en (4.28) y (4.29).

Ejemplo 13.1

Considérense las diferencias de la columna final de la tabla 4.1. Aquí, $n' = n = 10$ (ya que no hay valores cero), $r = 4$ y $s = 6$. Para un test de significación bilateral, el nivel de probabilidad equivale al doble

de la probabilidad de $r \leq 4$, que, según las tablas de distribución binomial, es 0,75. La aproximación normal, con una corrección de la continuidad, daría para un test $\chi^2_{(1)}$:

$$\chi^2 = \frac{(|6 - 4| - 1)^2}{6 + 4} = 0,10 \quad (P = 0,75)$$

El veredicto concuerda con el del test de la t del ejemplo 4.3: no hay indicios de que las diferencias en la puntuación de ansiedad tiendan a ser positivas con mayor (o menor) frecuencia que negativas.

El valor de semi- P (v. apartado 4.7) a partir de la distribución binomial es 0,55, lo cual corresponde al valor de $\chi^2_{(1)}$ no corregida de 0,40 ($P = 0,53$). Obsérvese que estos valores de semi- P se aproximan más al resultado del test de la t del ejemplo 4.3, donde, con $t = -0,90$ con 9 gl, $P = 0,39$.

Test de la suma de rangos con signo

Obviamente, el test de signos pierde eficacia al ignorar cualquier otra información sobre las magnitudes numéricas de las observaciones que no sea su signo. Si una proporción elevada de las observaciones numéricamente grandes fueran positivas, se reforzaría la evidencia de que la distribución es asimétrica con respecto a cero. Parece razonable tener en cuenta esta evidencia. El test de la suma de rangos con signo de Wilcoxon (1945) actúa de la siguiente manera. Las observaciones se disponen en orden ascendente de magnitud, ignorando el signo, y reciben rangos de 1 a n' (los valores cero se ignoran, al igual que en el test de signos). Sea T_+ la suma de los rangos de los valores positivos y T_- la de los negativos. Según la hipótesis nula, no se esperaría que T_+ y T_- se diferenciases enormemente; su suma $T_+ + T_-$ es $(1/2) n' (n' + 1)$; por lo tanto, un test adecuado consistiría en evaluar la probabilidad de un valor de, por ejemplo, T_+ , igual o mayor que el observado. La tabla A7 proporciona los valores críticos para los T_+ y T_- más pequeños, para tests bilaterales a los niveles del 5 y del 1% para un valor n' de hasta 25. La distribución está completamente tabulada por Lehmann (1975, tabla H) para n' hasta 20; los restantes percentiles se incluyen en *Geigy Scientific Tables* (1982, p. 163). Para valores superiores de n' , T_+ y T_- están aproximadamente distribuidos normalmente con una variancia $n' (n' + 1) (2n' + 1)/24$, y una desviación normal estandarizada, cuya corrección de la continuidad, se obtiene mediante:

$$\frac{|T_+ - \frac{1}{4} n' (n' + 1)| - \frac{1}{2}}{\sqrt{[n' (n' + 1) (2n' + 1)/24]}} \quad (13.1)$$

Si algunas de las observaciones coinciden numéricamente, se les asigna rangos empatados iguales a la media de los rangos que se hubieran usado en caso de no coincidir. Esta característica reduce la variancia de T_+ en $(t^3 - t)/48$ por cada grupo de t rangos empatados, y los valores críticos mostrados en la tabla A7 son un poco conservadores (es decir, el resultado es algo más significativo que lo sugerido por la tabla).

Ejemplo 13.2

Las 10 diferencias de la tabla 4.1 podrían clasificarse según rango numérico de la siguiente manera:

	1	2	3	4		6	7		9	10
Rango	Igual $2\frac{1}{2}$				5	$6\frac{1}{2}$		8	$9\frac{1}{2}$	
Valor numérico	1	1	1	1	2	3	3	7	8	8
Signo	+	+	+	-	-	-	-	-	+	-

$$T_+ = 2\frac{1}{2} + 2\frac{1}{2} + 2\frac{1}{2} + 9\frac{1}{2} = 17,$$

$$T_- = 2\frac{1}{2} + 5 + 6\frac{1}{2} + 6\frac{1}{2} + 8 + 9\frac{1}{2} = 38.$$

De la tabla A7 se obtiene que, para $n' + 10$, el punto 5% para el mínimo de T_+ y T_- es 8. Tanto T_+ como T_- exceden este valor crítico y el efecto es claramente no significativo.

Para el test con muestra grande, calculamos:

$$E(T_+) = \frac{1}{2}(10)(11) = 27,5$$

$$\text{Var}(T_+) = \frac{10(11)(21)}{24} - \frac{1}{48}[(4^3 - 4) + (2^3 - 2) + (2^3 - 2)]$$

$$= 96,25 - 1,50$$

$$= 94,75$$

$$ET(T_+) = \sqrt{94,75} = 9,73$$

y la desviación normal estandarizada es $(10,5 - 0,5)/9,73 = 1,03$, claramente no significativa (según la tabla A1, $P = 0,303$). Según la tabla de Lehmann, ignorando los empates, la probabilidad del resultado observado o de uno mayor es 0,322. Los dos valores P citados aquí son aproximados (uno debido a la aproximación normal, el otro debido a los empates), pero concuerdan razonablemente bien.

Estimación

Supóngase que las observaciones (o diferencias, en el caso de una comparación apareada como en el ejemplo 13.2) se distribuyen simétricamente, no alrededor de cero, como se especifica por la hipótesis nula, sino alrededor de algún otro valor, μ . ¿Cómo podemos hacer la mejor estimación de μ ? Una sugerencia obvia es la media de la muestra. Otra es la mediana de la muestra, que, si se resta de cada observación, daría la esperanza nula en el test del signo, ya que habría cantidades iguales de diferencias positivas y negativas. Una sugerencia ligeramente mejor sería la relacionada con el test de los rangos con signo. Podríamos elegir aquel valor $\hat{\mu}$ que, restado de cada observación, diera la esperanza nula en el test de los rangos con signo. No es difícil ver que el test estadístico T_+ es el número de valores positivos entre las «medias de los pares» las cuales se forman obteniendo la media de cada par de observaciones (incluida cada observación consigo misma). La estimación $\hat{\mu}$ es la mediana de estas medias de los pares.

Los límites de confianza de $\hat{\mu}$ son los valores que, si se restan de cada observación, apenas dan un resultado significativamente alto o bajo. Con este fin pueden emplearse todas las n lecturas. Los límites pueden obtenerse clasificando las $(1/2)n(n+1)$ medias de los pares y tomando los valores cuyos rangos son uno más que la entrada correcta en la tabla A7 y el rango simétrico se obtiene restando este resultado de $(1/2)n(n+1) + 1$. Es decir, uno excluye el número tabulado de observaciones de cada extremo de las series categorizadas. Si

Interrelaciones entre tests

Existen, en primer lugar, dos relaciones entre los dos estadísticos de Mann-Whitney y entre los dos de Wilcoxon:

$$U_{XY} + U_{YX} = n_1 n_2 \quad (13.3)$$

$$T_1 + T_2 = \frac{1}{2} (n_1 + n_2) (n_1 + n_2 + 1) \quad (13.4)$$

Éstos demuestran que los tests basados en cualquiera de los dos estadísticos de cada par son equivalentes; por ejemplo, dados T_1 y los tamaños de las dos muestras, se puede calcular inmediatamente T_2 a partir de (13.4).

En segundo lugar, los tres tests están interrelacionados por las siguientes fórmulas:

$$U_{YX} = T_1 - \frac{1}{2} n_1 (n_1 + 1), \quad (13.5)$$

$$U_{XY} = T_2 - \frac{1}{2} n_2 (n_2 + 1) \quad (13.6)$$

y

$$S = U_{XY} - U_{YX}$$

como ya vimos en (13.2).

Los tres tests son exactamente equivalentes. A partir de (13.5), por ejemplo, la probabilidad de obtener un valor de T_1 mayor o igual al observado coincide con la probabilidad correspondiente a un valor de U_{YX} mayor o igual al observado. Por lo tanto, a partir de los tests de significación basados en T_1 y en U_{YX} obtendremos exactamente el mismo nivel de significación. La elección entre estos dos tests depende sólo de la familiaridad con una forma de cálculo determinada y de la facilidad de acceso a las tablas.

Las distribuciones de probabilidad de los diversos estadísticos son independientes de las distribuciones de x e y . Se han hecho las tabulaciones para tamaños de muestra pequeños y moderados, en situaciones en las que no hay empates. La tabla A8 proporciona los valores críticos de T_1 (las muestras se etiquetan de forma que $n_1 \leq n_2$). La tabla sirve para tests bilaterales a los niveles del 5 y del 1%, para n_1 y n_2 hasta 15. Se pueden encontrar tablas más extensas en *Geigy Scientific Tables* (1982, pp. 156-162); la distribución exacta (en términos de U_{YX}) se encuentra en Lehmann (1975, tabla B) para algunos valores más pequeños de n_1 y n_2 . Más allá de los límites de la tabla A8, es adecuado utilizar la aproximación normal basada en las fórmulas de la variancia de la tabla 13.1, a menos que el valor más pequeño de n_1 y n_2 sea inferior a 4.

Cuando hay empates, las fórmulas de la variancia se modifican como se muestra en la tabla 13.1. Los sumatorios de las fórmulas se aplican sobre todos los grupos de observaciones empatadas, siendo t el número de observaciones de un grupo determinado. Al igual que ocurre en el test de la suma de rangos con signo, las tablas de valores críticos son algo conservadoras en presencia de empates.

Ejemplo 13.3

Ilustramos el uso de la S de Kendall y del test equivalente de la U de Mann-Whitney, en el grupo de datos expuesto en la tabla 13.2. Las observaciones son las mediciones de los cambios porcentuales de

Tabla 13.2. Cambio porcentual del área de úlcera gástrica después de 3 meses de tratamiento (Doll y Pygott, 1952).

	Número	
X: pacientes ingresados	32	-100 ⁽¹²⁾ , -93, -92, -91 ⁽²⁾ , -90, -85, -83, -81, -80, -78, -46, -40, -34, 0, 29, 62, 75, 106, 147, 1.321.
Y: pacientes ambulatorios	32	-100 ⁽⁵⁾ , -93, -89, -80, -78, -75, -74, -72, -71, -66, -59, -41, -30, -29, -26, -20, -15, 20, 25, 37, 55, 68, 73, 75, 145, 146, 220, 1.044

Nota: -100⁽⁵⁾ indica que existen 5 observaciones en -100, etc.

la superficie de úlceras gástricas después de 3 meses de tratamiento, realizándose la comparación entre 32 pacientes hospitalizados y 32 pacientes ambulatorios. Un cambio porcentual es una medición difícil; su valor mínimo es -100 (cuando la úlcera ha desaparecido); cada grupo contiene varias lecturas agrupadas en este límite inferior o cerca de él. En la otra dirección se pueden registrar valores muy grandes (cuando la úlcera inicialmente era muy pequeña y aumentó mucho durante el período de observación).

Un aspecto que puede observarse en el cálculo de la S cuando hay empates, es que no es necesario contar $1/2$ por cada empate (x, y) , porque estas contribuciones forman parte tanto de U_{xy} como de U_{yx} y, por lo tanto, quedan anuladas en la S según (13.2). Por consiguiente podemos calcular S como $P - Q$ donde P y Q se calculan como U_{xy} y U_{yx} , exceptuando que no se suma nada por los empates (x, y) .

En este ejemplo, sean x los pacientes hospitalizados e y los pacientes ambulatorios. Para calcular P , se toma cada miembro de la muestra x por turno y se cuenta el número de miembros de la muestra de y mayores que este valor. Para los primeros valores de x , encontramos:

x_i	-100 ⁽¹²⁾	-93	-92	-91 ⁽²⁾	-90	-85 ...
Número de $y_j > x_i$	27	26	26	26	26	25 ...

Así,

$$P = 12(27) + 5(26) + 3(25) + 24 + 23 + 17 + 2(16) + 11 + 9 + 7 + 2(4) + 2 + 0 = 662$$

$$Q = 5(20) + 19 + 15 + 11 + 7(10) + 9 + 5(7) + 2(6) + 2(5) + 2(4) + 3 + 2(2) + 2(1) = 298$$

y

$$S = 662 - 298 = 364$$

De la tabla 13.1,

$$\text{Var}(S) = \frac{(32)(32)}{3(64)(63)} [64^3 - 64 - (17^3 - 17) - \dots]$$

en la que se han omitido los términos surgidos de los grupos pequeños de empates (como las dos observaciones en -93), ya que fácilmente pueden considerarse mucho más pequeños que los otros términos.

$$\text{Var}(S) = (0,084656)(257,184)$$

$$= 21,772$$

$$\text{ET}(S) = \sqrt{21,772} = 147,5$$

Utilizando la aproximación normal, la desviación normal estandarizada es $364/147,5 = 2,47$ ($P = 0,014$).

En la versión de Mann-Whitney, cada empate contribuye en $1/2$ a U_{xy} y a U_{yx} . Así, por ejemplo,

$$U_{yx} = 5(26) + 19\frac{1}{2} + 15 + 11\frac{1}{2} + \dots$$

$$= 330$$

$$E(U_{yx}) = \frac{1}{2}(32)(32) = 512$$

$$U_{yx} - E(U_{yx}) = -182 (= \frac{1}{2}S)$$

$$\text{Var}(U_{yx}) = 5,443 (= \frac{1}{4}\text{Var}(S))$$

y la desviación estandarizada es $-2,47$, al igual que antes aparte del signo.

Éste es un ejemplo en el que la diferencia entre las muestras de x y de y no se habría detectado mediante un test de la t . Las distribuciones son sumamente no normales, y el test de la t con dos muestras nos da $t = 0,51$ (claramente no significativa).

La capacidad de estos tests de dos muestras para manipular los empates nos proporciona una interesante conexión con algunos tests ya descritos para las tablas de contingencia. En el ejemplo 12.1, por ejemplo, que ilustra el test para una tendencia en las proporciones, cabría preguntarse si la distribución del tiempo transcurrido desde la última visita es el mismo para los que acuden y para los que no acuden. Tomando los cuatro períodos como los valores de una variable fuertemente agrupada, podrían aplicarse los tests no paramétricos recién descritos. Puede demostrarse (Armitage, 1955) que la desviación normal resultante es exactamente la misma que X_{1a} , la raíz cuadrada del estadístico dado por (12.6), con la condición de que, en este último test, las puntuaciones x reciban valores iguales a los rangos intermedios de los diferentes grupos. En el ejemplo 12.1 serían 78,5, 177,0, 221,5 y 262,0. Cuando se emplean estas puntuaciones, que se denominan *ridits modificados*, el test de Wilcoxon/Mann-Whitney y el test de la tendencia de las proporciones dada por (12.6) son completamente equivalentes. En este ejemplo, el estadístico $\chi^2_{(1)}$, $X^2_{(1a)}$, es 8,48 ($P = 0,003$).

Una tabla de contingencia 2×2 es un caso extremo de esta situación, y aquí la desviación normal con respecto al test no paramétrico (tomando debidamente en cuenta los empates) es la misma que en la aproximación normal usual de los apartados 4.8 y 4.9, aparte de un factor de $\sqrt{(n-1)/n}$.

Estimación

Supóngase que las dos distribuciones tienen la misma forma, pero difieren en su localización por un desplazamiento δ a lo largo de la escala de medición, siendo ésta positiva cuando las x tienden a ser superiores a las y . El parámetro δ , con límites de confianza, puede calcularse de la siguiente manera. En primer lugar, obsérvese que U_{yx} es el número de pares para los

cuales $x_i > y_j$. Por consiguiente, si se forman todas las $n_1 n_2$ diferencias $x_i - y_j$, U_{yx} es el número de valores positivos (suponiendo que no hay empates); así, U_{yx} es un test estadístico para la hipótesis de que la diferencia entre las medianas es cero. Si se resta una cantidad constante δ de todas las x y, por lo tanto, de todas las diferencias, las dos muestras se extraerían eficazmente de la misma distribución y la hipótesis nula sería verdadera. Si se vuelve a calcular U_{yx} después de la resta, ésta proporcionaría un test para la hipótesis de que el desplazamiento o diferencia mediana es realmente δ . Por lo tanto, los límites de confianza para el desplazamiento se obtienen encontrando los valores que, restados de todas las diferencias, dan un resultado en el límite de la significación. Si las diferencias se categorizan, el intervalo de confianza es la porción media de la distribución, con varias diferencias excluidas de ambos extremos conforme al valor crítico del test de la U_{yx} . El número de valores que se ha de excluir puede evaluarse aplicando la tabla A8 y (13.5), como se ilustra en el siguiente ejemplo. Una estimación de un punto del parámetro δ se obtiene por la mediana de las diferencias, ya que éste es el valor que, restado de todas las diferencias, haría que el test estadístico fuese igual a su esperanza.

Ejemplo 13.4

Los datos de la tabla 4.2 pueden clasificarse de la siguiente manera, representando los valores altos y bajos de proteínas en los grupos 1 y 2, respectivamente. Así, $n_1 = 7$ y $n_2 = 12$.

Valores		Rangos	
Alto en proteínas	Bajo en proteínas	Alto en proteínas	Bajo en proteínas
	70		1
83	85	2	3
	94		4
97	101	5	6
104		7	
107		8,5	
	107		8,5
113		10	
	118		11
119		12	
123		13	
124		14	
129		15	
	132		16
134		17	
146		18	
164		19	
	Suma de rangos	$T_2 = 140,5$	$T_1 = 49,5$
		$n_2 = 12$	$n_1 = 7$

Según la tabla A8 habría una diferencia significativa en el nivel del 5% si $T_1 \leq 46$; aplicando (13.5), es decir, si $U_{yx} \leq 18$. Por consiguiente, 18 de las diferencias son eliminadas de cada extremo del conjunto de diferencias ordenadas para obtener el intervalo de confianza del 95%. Las 84 diferencias, contenido alto en proteínas menos contenido bajo en proteínas, se tabulan a continuación.

Contenido bajo en proteínas	Contenido alto en proteínas											
	83	97	104	107	113	119	123	124	129	134	146	161
70	13	27	34	37	43	49	53	54	59	64	76	91
85	-2	12	19	22	28	34	38	39	44	49	61	76
94	-11	3	10	13	19	25	29	30	35	40	52	67
101	-18	-4	3	6	12	18	22	23	28	33	45	60
107	-24	-10	-3	0	6	12	16	17	22	27	39	54
118	-35	-21	-14	-11	-5	1	5	6	11	16	28	43
132	-49	-35	-28	-25	-19	-13	-9	-8	-3	2	14	29

La mediana de estas 84 diferencias es 18,5, y si se excluyen las 18 diferencias más altas y las 18 diferencias más bajas, se obtiene un intervalo de confianza del 95% de -3 a 40. Estos valores tienen una concordancia estrecha con los encontrados aplicando la distribución de la t en el ejemplo 4.4, como cabía esperar puesto que los datos satisfacen las condiciones para este análisis.

Para los valores no incluidos dentro de los límites de la tabla A8, se obtiene una aproximación al número de diferencias que debe excluirse de cada extremo del conjunto ordenado mediante la parte entera de:

$$\frac{1}{2} n_1 n_2 - z \sqrt{\left[\frac{n_1 n_2 (n_1 + n_2 + 1)}{12} \right]}$$

Los métodos de estimación descritos anteriormente podrían aplicarse a los datos del ejemplo 13.3. Los límites de confianza del 95% se calculan como -66 y -2, en las unidades de cambio porcentual usadas en la tabla 13.2. No obstante, el método es inadecuado en este caso, ya que la hipótesis de un desplazamiento constante en las distribuciones es bastante irreal en vista de la aglomeración de observaciones en el límite inferior de -100%. Es necesario usar otros parámetros para describir la diferencia entre los grupos. Por ejemplo, podría describirse la diferencia entre las proporciones de observaciones en el límite inferior, o menos del -90%. Un método alternativo, que puede aplicarse en cualquier caso del test de Wilcoxon/Mann-Whitney, consiste en señalar que el estadístico $U_{xy}/n_1 n_2$ sea claramente una estimación de la probabilidad de que un valor de x elegido al azar sea inferior a un valor de y elegido al azar. Sin embargo, la variancia de dicho estadístico es difícil de evaluar ya que depende de la manera precisa en que las dos distribuciones difieren; es importante comprender que la variancia binomial habitual para una proporción con $n_1 n_2$ observaciones es completamente inadecuada en este caso, ya que las $n_1 n_2$ diferencias no son independientes.

Puntuaciones normales

Una aproximación alternativa al problema no paramétrico con dos muestras la proporcionan las *puntuaciones normales* de Fisher-Yates. En lugar de usar rangos, las observaciones se transforman en diferentes grupos de puntuaciones que dependen únicamente de los rangos en la muestra combinada de tamaño n . La puntuación para la observación con número de rango r es, en realidad, numéricamente igual al valor medio de la observación r más pequeña en una muestra de n de una distribución normal estandarizada, $N(0,1)$. Fisher y Yates (1963, tabla XX) han dispuesto las puntuaciones en tablas para distintos tamaños de muestras.

Ahora estas puntuaciones pueden considerarse un método de transformación a la normalidad, como paso preliminar al uso de métodos normales estándar, y éste es, por lo general, un uso perfectamente adecuado del método. No obstante, los métodos normales introducen inevitablemente una aproximación, cuya validez dependerá en cierta medida de las distribuciones originales.

Si se deseara tener un test no paramétrico, podría calcularse la diferencia entre las medias de los grupos de puntuaciones y aprovechar el hecho de que su distribución de muestreo no depende de la distribución de las observaciones originales. Klotz (1964) proporciona unas tablas.

Un uso secundario de las puntuaciones normales consiste en proporcionar un test gráfico de normalidad (v. apartado 11.5). Dadas las observaciones de la muestra, $z_1, z_2, \dots, z_n$, clasificadas en orden, puede tratarse z_i frente a la puntuación normal i de una muestra de n . Si la muestra procede de una distribución normal, los puntos deberían situarse muy cerca de una línea recta (la proximidad será más cercana para las muestras grandes que para las pequeñas). Las desviaciones sistemáticas de la normalidad tenderán a producir una no linealidad, de forma semejante a como ocurría en el uso de la transformación probit o del papel de probabilidad (apartado 11.4).

En el apartado 13.6 se incluyen más comentarios generales acerca del valor de los tests no paramétricos con dos muestras.

13.4. Comparación entre varios grupos

Grupos relacionados: test de Friedman

Supóngase que tenemos más de dos grupos de observaciones y que los datos también se clasifican mediante una estructura en bloques, de manera que dichos datos forman una clasificación de dos factores del tipo explicado en el apartado 8.1, donde se describió el análisis de dos factores de la variancia de un diseño en bloques aleatorizados. Supóngase que hay t tratamientos y b bloques. Friedman (1937) proporcionó un test no paramétrico para una distribución de este tipo, que es una generalización del test con signos para más de dos grupos. El test se basa en la clasificación de los valores dentro de cada bloque.

El procedimiento del test se explica mejor si se considera un análisis de dos factores de la variancia de los rangos, usando las fórmulas del apartado 8.1. En un análisis de este tipo las sumas de cuadrados (SC) y sus grados de libertad se pueden escribir de la siguiente manera:

	SC	gl
Bloques	0	0
Tratamientos	S_{tr}	$t - 1$
Residual	S_{res}	$(b - 1)(t - 1)$
Total	S_{tot}	$b(t - 1)$

Tanto la SC como los grados de libertad para los bloques son cero porque la suma de los rangos es la misma para cada bloque, o sea $(1/2)t(t + 1)$. En el cálculo de las SC el término de corrección (T^2/N en la tabla 8.2) es $(1/4)bt(t + 1)^2$. La forma habitual del test estadístico de Friedman es:

$$T_1 = \frac{b(t - 1)S_{tr}}{S_{tot}} \quad (13.7)$$

que se distribuye aproximadamente como χ^2_{t-1} . Dicho estadístico es la relación entre la SC de tratamiento y la media cuadrática (MC) total en el análisis de la variancia. Un test estadístico en cierta forma preferible es análogo a la relación de la variancia habitual en el análisis de la variancia, es decir, la relación entre la MC de tratamiento y la MC residual:

$$T_2 = \frac{(b - 1)S_{tr}}{S_{tot} - S_{tr}} \quad (13.8)$$

que se distribuye aproximadamente como F , con $t - 1$ y $(t - 1)(b - 1)$ gl.

Cuando no hay empates puede calcularse la SC total, S_{tot} , directamente como $bt(t + 1)(2t + 1)/6$, y las fórmulas para los test estadísticos a menudo hacen uso de esta expresión. Cuando $t = 2$, el test estadístico T_1 es idéntico al test estadístico con signos sin una corrección de la continuidad.

Ejemplo 13.5

La tabla 13.3 muestra los datos presentados en la tabla 8.3 con los valores dentro de cada bloque ordenados por rangos.

El efecto de los tratamientos es muy significativo mediante cualquiera de los dos tests, de conformidad con el análisis del ejemplo 8.1. Obsérvese que T_2 es más significativo que T_1 ; esto por lo general será cierto cuando el efecto en cualquier caso sea muy significativo, porque la MC residual usada como base para T_2 será entonces considerablemente más baja que la MC total usada en T_1 . Ésta es la razón por la que generalmente se prefiere el segundo de los dos tests.

En algunos estudios es posible comparar los tratamientos intraestratos o intrabloques, pero con más de una observación por tratamiento en cada estrato, y los números de repeticiones pueden quedar desequilibrados, como en el ejemplo 8.9. Nos referiremos a esta situación más adelante en este apartado.

Tabla 13.3. Tiempos de coagulación del plasma de 8 sujetos, tratados con cuatro métodos, después de clasificar los cuatro valores dentro de cada sujeto.

Sujeto	Tratamiento				Total
	1	2	3	4	
1	1	2	3	4	10
2	1	4	2	3	10
3	2	1	4	3	10
4	2	1	3	4	10
5	2	1	3,5	3,5	10
6	1	3	2	4	10
7	1	2	3	4	10
8	1	2	3	4	10
Total	11,0	16,0	23,5	29,5	80

Término de corrección = $80^2/32 = 200$

SC entre tratamientos, $S_{tr} = (11,0^2 + 16,0^2 + 23,5^2 + 29,5^2)/8 - 200$
 $= 24,9375$

SC total, $S_{tot} = 1^2 + 2^2 + \dots + 4^2 - 200 = 39,5$

$T_1 = 8 \times 3 \times 24,9375/39,5 = 15,5$ (como $\chi^2_{(3)}; P = 0,002$),

$T_2 = 7 \times 24,9375/14,5625 = 11,9$ (como $F_{(3,21)}; P < 0,001$)

Grupos independientes: test de Kruskal-Wallis

Supóngase que tenemos más de dos grupos de observaciones y los datos de una clasificación de un factor del tipo explicado en el apartado 7.1, donde se describió el análisis de la variancia de un factor. Supóngase que hay t grupos. Un test no paramétrico para una situación de este tipo sería una generalización del test de Mann-Whitney o del test de rangos con signo de Wilcoxon para más de dos grupos. Kruskal y Wallis (1952) proporcionaron una generalización. Dicho test se basa en la clasificación por rangos de todos los valores y, a continuación, prosigue mediante un método que tiene semejanzas con el análisis de la variancia de un factor sobre los rangos.

Supóngase que hay n_i observaciones para el grupo i , y sea $N = \sum n_i$. Las observaciones están clasificadas por rangos de 1 a N y éstos se hallan sujetos a un análisis de la variancia de un factor. Sea T_i la suma de los rangos en el grupo i . Se representan la SC para grupos corregida mediante S_{tr} y la SC total corregida como S_{tot} . En estos cálculos el término de corrección es proporcionado por $(1/4)N(N+1)^2$. Luego, el test estadístico se calcula como:

$$T = \frac{(N-1)S_{tr}}{S_{tot}} \quad (13.9)$$

distribuido aproximadamente como $\chi^2_{(t-1)}$. Si no hay empates, puede evaluarse S_{tot} directamente y la fórmula para el test estadístico se simplifica a:

$$T = \frac{12}{N(N+1)} \sum T_i^2/n_i - 3(N+1) \quad (13.10)$$

Tabla 13.4. Recuentos de gusanos adultos en cuatro grupos, cada uno de 5 ratas, después de clasificar.

	Experimento			
	1	2	3	4
	6	17	1	18
	14	5	12,5	16
	11	19	12,5	15
	2	4	7	20
	9	8	3	10
Total	42	53	36	79

$$\text{Término de corrección} = 1/4 \times 20 \times 441 = 2.205$$

$$\text{SC entre tratamientos, } S_{\text{gr}} = (42^2 + 53^2 + 36^2 + 79^2) / 5 - 2.205 = 217$$

$$\text{SC total, } S_{\text{tot}} = 6^2 + 17^2 + \dots + 10^2 - 2.205 = 664,5$$

Ejemplo 13.6

La tabla 13.4 muestra los datos de la tabla 7.1, clasificados del 1 al 20. Según la fórmula (13.9), $T = 19 \times 217/664,5 = 6,20$ (como $\chi^2_{(3)}; P = 0,10$). Si se emplea (13.10) a pesar del único par de rangos empatados, $T = 12 \times 2.422/(20 \times 21) - 3 \times 21 = 6,20$ nuevamente; el efecto de este pequeño grado de tipificación en los rangos es despreciable. Las conclusiones del análisis son muy similares a las del análisis de la variancia del ejemplo 7.1: las diferencias no son significativas.

Cuando los datos son estratificados por uno o más factores (p. ej., si los datos como los de la tabla 13.4 se obtienen cada día entre varios) el test de Kruskal-Wallis necesita adaptarse para tener en cuenta la estratificación. No intentaremos aquí una explicación exhaustiva, en parte porque los métodos se vuelven muy arduos y en parte porque, para conjuntos de datos más complejos, puede ser aconsejable pensar en un método de regresión múltiple para los datos originales o para un conjunto de datos transformados.

Sin embargo, hay que señalar dos puntos. En primer lugar, si hay dos tratamientos, de modo que la solución necesaria es una versión estratificada del test de Wilcoxon/Mann-Whitney, Van Elteren (1960) ha descrito un test basado en una suma ponderada del estadístico T_{ih} de la suma de rangos de Wilcoxon (donde el subíndice h se refiere a un estrato en concreto). En segundo lugar, los datos de este tipo a menudo aparecen en situaciones en que las observaciones están densamente agrupadas, de modo que los grupos pueden considerarse categorías en una variable categórica ordinal. El análisis de este tipo de datos ya se ha explicado brevemente en (12.20) (p. 397-398).

13.5. Correlación de rangos

Supóngase que en un grupo de n individuos, cada uno proporciona observaciones sobre dos variables, x e y . La proximidad de la asociación entre x e y se mide habitualmente mediante el coeficiente de correlación de producto-momento, r (apartado 5.3). El uso de este estadístico podría considerarse censurable debido a las siguientes razones: a) se basa en el concepto de

proximidad a la regresión lineal y su valor podría afectarse de forma espectacular por una transformación no lineal; *b*) las mediciones que se han de analizar pueden ser cualitativas, aunque ordenadas, y es posible que el investigador no desee asumir ninguna escala numérica determinada, y *c*) la variación de muestreo de r depende de la distribución de las variables, suponiéndose generalmente la normalidad (se podría desear un planteamiento no paramétrico).

Estas objeciones serían superadas por un coeficiente de correlación que dependiera sólo de los rangos de las observaciones. Para preservar la posibilidad de comparación con el coeficiente de correlación producto-momento, r , un coeficiente de correlación de rangos debería tener por lo menos las siguientes propiedades.

1. Debería situarse entre -1 y $+1$, tomando el valor de $+1$ cuando los individuos se clasifican exactamente en el mismo orden por x y por y , y -1 cuando el orden es opuesto.
2. Para muestras grandes en las que la distribución de x es independiente de y (y a la inversa), el valor debería ser cero.

Puede obtenerse un coeficiente de correlación de rango satisfactorio a partir del estadístico S de Kendall descrito en el apartado 13.3, con una generalización de la definición empleada. El número total de pares de individuos es $(1/2)n(n-1)$. Sea P el número de pares que se han clasificado en el mismo orden por x y por y , y Q el número de pares cuyas clasificaciones están en orden opuesto. Luego:

$$S = P - Q$$

(La definición anterior es un caso particular de éste, en que una variable representa una dicotomía en los dos grupos, estando el grupo X clasificado antes que el grupo Y , y la otra variable representa la medición bajo test, siendo tanto x_i como y_i al igual que en la definición previa, valores de esta segunda variable.)

Se define ahora el coeficiente de correlación de rango, τ como:

$$\tau = \frac{S}{\frac{1}{2}n(n-1)} \quad (13.11)$$

Es fácil observar que para una coincidencia completa de las clasificaciones, $\tau = 1$, y para una inversión completa $\tau = -1$. Un test de significación de la hipótesis nula en que la clasificación de x es independiente de la clasificación de y puede realizarse cómodamente en S . La esperanza matemática nula en S (al igual que τ) es cero y, en ausencia de empates:

$$\text{Var}(S) = n(n-1)(2n+5)/18 \quad (13.12)$$

Si hay empates, se modifica (13.12) obteniendo:

$$\begin{aligned} \text{Var}(S) = & \frac{1}{18} \left[n(n-1)(2n+5) - \sum_i t(t-1)(2t+5) - \sum_u u(u-1)(2u+5) \right] \\ & + \frac{1}{9n(n-1)(n-2)} \left[\sum_i t(t-1)(t-2) \right] \left[\sum_u u(u-1)(u-2) \right] \\ & + \frac{1}{2n(n-1)} \left[\sum_i t(t-1) \right] \left[\sum_u u(u-1) \right] \end{aligned}$$

teral, la probabilidad de significación sería $2 \times 0,023 = 0,046$, aún demasiado baja. Por lo tanto se sugiere definitivamente una asociación entre las dos clasificaciones.

El coeficiente de correlación de rangos es, según (13.11):

$$\tau = \frac{23}{\frac{1}{2}(10)(9)} = \frac{23}{45} = 0,51$$

Para la aproximación normal al test de significación, según (13.12):

$$\text{Var}(S) = 10(9)(25)/8 = 125$$

$$\text{ET}(S) = 11,18$$

Es útil aplicar una corrección de la continuidad de 1 unidad, ya que los posibles valores de S resultan separados por un intervalo de 2 unidades. La desviación normal estandarizada es $22/11,18 = 1,97$, por la cual $P = 0,049$, bastante cerca del valor exacto.

Para este conjunto de datos el coeficiente de correlación de Spearman es 0,68. El test de la t aproximada según (5.21) da un valor de $t = 2,66$ con 8 gl ($P = 0,029$). Un nivel de significación más exacto, que tiene en cuenta la discreción de la distribución, es 0,031. Estos dos valores son más pequeños, lo cual indica un resultado más significativo que el del test de Kendall. Sin embargo, medidas diferentes de asociación que no son lógicamente equivalentes alcanzarán necesariamente niveles diferentes de significación, y el lector debe recordar que el método elegido para la presentación final no debe seleccionarse por el mero hecho de que muestra la mayor significación.

13.6. Comentarios generales

Los tests no paramétricos se apoyan en argumentos teóricos notablemente sólidos. Supóngase que, en el problema con dos muestras del apartado 13.3, se deseara comprobar la hipótesis nula de que las dos muestras fueron extraídas desde la misma distribución y que el test tenga un poder alto sobre las hipótesis alternativas, especificando que las distribuciones se diferencian sólo en su colocación, es decir, que se podría transformar una distribución en la otra con un simple cambio en la escala de medidas.

Si las distribuciones son normales con la misma variancia el test de la t es el más eficiente, pero el test de rangos (Wilcoxon, Mann-Whitney o Kendall) tiene una eficiencia* relativa de 0,96. Si las distribuciones no son normales, la eficiencia relativa del test de rangos nunca es inferior a 0,86 y puede ser infinitamente alta. Para detectar un cambio en la colocación, por lo tanto, el test de rangos nunca es mucho peor que el test de la t y, en cambio, puede ser mucho mejor.

Además, el test no paramétrico basado en puntuaciones normales tiene una eficiencia relativa sobre el test de la t en cuanto que nunca es menor que la unidad y puede ser infinita. ¿Por qué, entonces, no usar siempre el test de rangos o el de puntuación normal con preferencia al test de la t ? La primera cuestión que ha de señalarse es que los tests de significación son sólo una parte del aparato de análisis estadístico. El principal propósito de un análisis

* Esta medida de eficiencia puede interpretarse como la proporción de los tamaños de muestra necesaria a fin de obtener cierto poder para detectar un pequeño cambio de colocación determinado.

Capítulo 14

Análisis de supervivencia

14.1. Introducción

En muchos estudios la variable de mayor interés es el tiempo transcurrido antes de un desenlace. Este desenlace puede ser la muerte o el fallecimiento causado por una enfermedad en particular, por lo que al análisis de este tipo de datos a menudo se le denomina *análisis de supervivencia*.

Un ejemplo de este tipo de estudios es un ensayo clínico para el tratamiento de un tumor maligno en el que el pronóstico es poco esperanzador; la muerte o la remisión del tumor son las resoluciones consideradas. Estos estudios incluyen a menudo individuos cuyo tipo de desenlace no es aún conocido en el momento del análisis. Aunque el tiempo que tales pacientes pueden sobrevivir se desconoce, existe cierta información acerca de su valor ya que deberá ser mayor que el tiempo de supervivencia actual; a una observación de esta clase se la denomina valor *censurado*. Los métodos de análisis deben ser capaces de tratar con valores censurados. A menudo, al principio de un ensayo, se observa un número de variables, y la supervivencia se relaciona con los valores de estas variables, es decir, las variables son pronósticas. Los métodos de análisis deberían ser capaces de considerar la distribución de las variables pronósticas en los grupos bajo estudio.

El número de estos estudios ha aumentado en las dos últimas décadas. Asimismo, se han desarrollado métodos estadísticos para su estudio, muchos de ellos durante la década de 1970. Algunos de estos métodos se describirán en este capítulo. Los lectores interesados en un conocimiento más detallado deben remitirse a las obras de Kalbfleisch y Prentice (1980), Lawless (1982) y Cox y Oakes (1984) y a los dos artículos de Peto et al (1976, 1977).

Una segunda situación en que se utiliza el análisis de supervivencia se da en el estudio de la mortalidad laboral cuando se requiere investigar si un grupo de trabajadores expuestos a un contaminante están sufriendo mayor mortalidad. Los sujetos entran a formar parte del estudio con un buen estado de salud, no como en el caso del ensayo clínico donde los sujetos padecen una enfermedad. Por ello, un método de análisis muy común ha sido la comparación de la mortalidad observada, en relación con el tiempo transcurrido y la causa, con la mortalidad esperada basándose en la población de la cual forma parte el grupo estudiado.

Dado que la mayoría de los métodos de análisis se basan en la aproximación a las tablas de vida, éstas se describen a continuación.

14.2. Tablas de vida

La *tabla de vida*, desarrollada inicialmente por el astrónomo E. Halley (1656-1742), es una de las herramientas básicas en la estadística demográfica y en la ciencia actuarial. En el apartado 12.9 ya se ha mencionado la estandarización como un método de resumir un grupo de

tasas de mortalidad para edades específicas, obteniéndose así una medida compuesta de la mortalidad observada en una comunidad para todas las edades, lo que permite útiles comparaciones con otros grupos de población. La tabla de vida es un procedimiento alternativo para resumir información correspondiente a otros atributos similares. Su propósito es mostrar el patrón de supervivencia de un grupo de individuos a lo largo de su vida, mediante las citadas tasas específicas por edades.

Las tablas de vida pueden construirse de dos formas distintas a partir de datos de mortalidad de una población numerosa, a las que se denomina comúnmente *tabla de vida actual* y *tabla de vida de cohortes* o *de generaciones*. La tabla de vida actual describe el patrón de supervivencia de un grupo de individuos a lo largo de su vida mediante las tasas de mortalidad actuales por edades observadas en una comunidad concreta. Este grupo es necesariamente hipotético. Un grupo de individuos que en la actualidad tenga 60 años experimentará aproximadamente la tasa actual de mortalidad específica de las edades 60-61, pero aquellos que sobrevivan 10 años tendrán, en el undécimo, no la tasa actual *correspondiente* a 70-71 años sino la correspondiente *a entonces*. Así, la tabla de vida actual proporciona más una idea general sobre la mortalidad actual que una descripción de la mortalidad real correspondiente a un grupo determinado.

El método de elaboración de las tablas de vida actuales publicadas en documentos nacionales de estadística demográfica o las usadas por compañías de seguros es bastante complejo (Chiang, 1984). Hill y Hill (1991) presentan una versión simplificada. Las principales características de una tabla de vida se muestran en la tabla 14.1, cuyo lado izquierdo resume la tabla de vida inglesa N.º 10 basada en la mortalidad de los varones ingleses y galeses durante 1930-1932. La segunda columna nos da q_x , la probabilidad de que un individuo de x años exactos de edad muera antes de su próximo cumpleaños. La tercera columna muestra l_x , el número de individuos entre un millar de nacidos vivos que sobrevivirán hasta su x º cumpleaños. Para sobrevivir este período, un individuo debe sobrevivir el primer año de vida, el segundo, etc. Consecuentemente,

$$l_x = l_0 p_0 p_1 \cdots p_{x-1} \quad (14.1)$$

donde $p_x = 1 - q_x$. Esta fórmula puede comprobarse en la tabla 14.1 para $x = 1$, pero no subsecuentemente ya que los valores de q_x sólo se dan para determinados valores de x . A este tipo de tablas se las denomina *tablas de vida abreviadas*.

La cuarta columna muestra e_x , la esperanza de vida para una edad x . Ésta es la longevidad media adicional a partir de x para todas las l_x personas vivas a una edad x . En una tabla completa, e_x puede calcularse aproximadamente como:

$$e_x = (l_{x+1} + l_{x+2} + \cdots) / l_x + \frac{1}{2} \quad (14.2)$$

donde el paréntesis es el total de años vividos a partir de una edad x por los l_x individuos si aquellos que murieran entre las edades y y $y + 1$ lo hicieran justo después del y º cumpleaños, y el $1/2$ es una corrección para el hecho de que las muertes se producen a lo largo de todo el año, lo que añade medio año a la supervivencia media esperada.

La tabla de vida de una cohorte describe la supervivencia real de un grupo, o «cohorte», de individuos nacidos en fechas semejantes. Por ejemplo, los nacidos en 1900 están sujetos

Tabla 14.1. Tablas de vida actual y de cohorte para varones de Inglaterra y Gales nacidos alrededor de 1931.

Edad, años x	Tablas de vida actual 1930-1932			Tabla de vida de la cohorte 1931
	Probabilidad de muerte entre x y $x + 1$ de edad	Supervivientes según la tabla de vida	Expectativa de vida	Supervivientes según la tabla de vida
	q_x	l_x	e_x	l_x
0	0,0719	1000	58,7	1000
1	0,0153	928,1	62,2	927,8
5	0,0034	900,7	60,1	903,6
10	0,0015	890,2	55,8	894,8
20	0,0032	872,4	46,8	884,2
30	0,0034	844,2	38,2	874,1
40	0,0056	809,4	29,6	861,8
50	0,0113	747,9	21,6	829,7
60	0,0242	636,2	14,4	—
70	0,0604	433,6	8,6	—
80	0,1450	162,0	4,7	—

durante su primer año de vida a la mortalidad de menores de un año correspondiente al 1900-1901; si sobreviven 10 años están sujetos a la mortalidad para esta edad en 1910-1911, etc. La tabla de vida de una cohorte resume la mortalidad en las diferentes edades cuando el grupo analizado tiene esta edad determinada. El lado derecho de la tabla 14.1 resume la columna l_x para una tabla de vida de una cohorte de varones ingleses y galeses nacidos en los 5 años centrados alrededor de 1931. Como cabía esperar, el valor de l_x en las dos tablas de vida es muy parecido, siendo dependiente de la mortalidad infantil en los mismos años. En edades superiores, los valores de l_x son mayores en la tabla de vida de una cohorte ya que se basa en las tasas de mortalidad para tales edades contadas desde 1931, y dichas tasas son inferiores a las tasas de 1931.

Las dos formas de tabla de vida son útiles para estudios demográficos y epidemiológicos. Las tablas de vida actuales resumen la mortalidad actual y pueden utilizarse como alternativa a los métodos de estandarización para comparar los patrones de mortalidad en diferentes comunidades. Las tablas de vida de cohortes son particularmente útiles en estudios de mortalidad laboral, en los que un grupo puede ser seguido durante un período prolongado (apartado 14.9).

14.3. Estudios de seguimiento

Numerosas investigaciones médicas se relacionan con el patrón de supervivencia de un grupo determinado de pacientes (p. ej., los que padecen un tipo específico de enfermedad maligna). La supervivencia promedio será probablemente mucho menor que la correspondiente a la población general. Dado que es de suponer que la edad pasa a ser menos importante que el progreso de la enfermedad, es natural medir la supervivencia en relación con la evolución de la enfermedad, por ejemplo la fecha en que aparecieron los primeros síntomas o el momento en que se efectuó una intervención concreta.

Consideraremos de forma más detallada la aplicación del método de las tablas de vida para estudios de seguimiento de este tipo. En un principio estos métodos son aplicables a situaciones en las que el desenlace final no es necesariamente la muerte, sino otros acontecimientos no mortales, como la reaparición de los síntomas y signos después de una remisión, si bien en estos casos no es posible determinar el tiempo de recaída de forma precisa, mientras que el de supervivencia sí puede determinarse de forma precisa. De hecho, el suceso puede ser tanto favorable como desfavorable; la desaparición de los síntomas después del inicio de un tratamiento es un ejemplo. La siguiente argumentación se refiere a la supervivencia posterior a una intervención.

En este tipo de estudios habitualmente los pacientes son observados durante períodos variables de tiempo, algunos mucho después de ser intervenidos y otros enseguida después de la intervención. Algunos pacientes habrán fallecido, en momentos que generalmente pueden determinarse de forma bastante precisa, otros estarán vivos en el momento del análisis, otros pueden haberse perdido entre un control y el siguiente, otros habrán sido excluidos del estudio por razones médicas (p. ej., la aparición de otra enfermedad o una muerte accidental).

Si no existiesen complicaciones como las mencionadas, y cada paciente fuera seguido hasta su fallecimiento, la construcción de una tabla de vida en términos de tiempo postoperatorio sería una tarea fácil. La tasa de supervivencia, de la tabla de vida, l_x , es l_0 veces la proporción de tiempos de supervivencia mayor que x . El problema se reduciría a la obtención de la distribución del tiempo de supervivencia, una tarea muy elemental. Para superar las complicaciones por datos incompletos se construyen tablas como la 14.2.

Esta tabla es la adaptación de la proporcionada por Berkson y Gage (1950) en uno de los primeros artículos en que se describía el método. En los datos originales, los intervalos de tiempo eran medidos a partir del momento de alta del hospital, pero para los fines de nues-

Tabla 14.2. Cálculos de la tabla de vida para pacientes con una enfermedad maligna determinada (adaptada de Berkson y Gage, 1950).

(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
Intervalo desde la intervención entre los años x y $x+1$	Último registro durante este intervalo		Supervivientes al iniciar el intervalo	Número ajustado al riesgo	Probabilidad estimada de muerte	Probabilidad estimada de supervivencia	Porcentaje de supervivientes después de x años
	Fallecidos d_x	Retirados w_x	n_x	n'_x	q_x	p_x	l_x
0-1	90	0	374	374,0	0,2406	0,7594	100
1-2	76	0	284	284,0	0,2676	0,7324	75,9
2-3	51	0	208	208,0	0,2452	0,7548	55,6
3-4	25	12	157	151,0	0,1656	0,8344	42,0
4-5	20	5	120	117,5	0,1702	0,8298	35,0
5-6	7	9	95	90,5	0,0773	0,9227	29,1
6-7	4	9	79	74,5	0,0537	0,9463	26,8
7-8	1	3	66	64,5	0,0155	0,9845	25,4
8-9	3	5	62	59,5	0,0504	0,9496	25,0
9-10	2	5	54	51,5	0,0388	0,9612	23,7
10-	21	26	47	—	—	—	22,8

tra exposición los hemos sustituido por intervalos a partir de la intervención. Las columnas 1 a 8 se construyen de la siguiente manera.

Columna 1. La elección de los intervalos de tiempo dependerá de la naturaleza de los datos. En el presente estudio se muestran estimaciones de las tasas de supervivencia para años enteros hasta 10, después de la intervención. Si la supervivencia a partir de 10 años hubiera sido de particular interés, los intervalos podrían haberse extendido fácilmente más allá de los 10 años. En este caso, para evitar que la tabla fuera demasiado engorrosa, habría sido útil usar intervalos de dos años, por lo menos en algunos grupos. El uso de intervalos de distintas longitudes no presenta dificultades. Véase un ejemplo en Merrell y Shulman, 1955.

Columnas 2 y 3. Los pacientes estudiados se clasifican ahora de acuerdo con el intervalo de tiempo durante el cual se controló su situación por última vez. Si este último control era de defunción, el paciente se contabiliza en la columna 2; si en el último control el paciente estaba vivo, se contabiliza en la columna 3. De este modo, el término «retirados» incluye pacientes recientemente vivos, que podrían observarse en posteriores estudios de seguimiento, y aquellos con los que, por alguna razón, se ha perdido el contacto.

Columna 4. El número de pacientes vivos al inicio del intervalo se obtiene acumulando las columnas 2 y 3 desde el final. Así, el número de supervivientes a los 10 años es $21 + 26 = 47$. El número de supervivientes a los 9 años incluye a los 47 anteriores más los $2 + 5 = 7$ fallecidos o retirados en el intervalo 9–10 años; así el valor es de $47 + 7 = 54$.

Columna 5. El número ajustado al riesgo en el intervalo x a $x + 1$ es:

$$n'_x = n_x - \frac{1}{2}w_x \quad (14.3)$$

El objetivo de esta fórmula es dar un denominador a la columna siguiente. La razón de esto se explica más adelante.

Columna 6. La probabilidad de muerte estimada en el intervalo x a $x + 1$ es:

$$q_x = d_x/n'_x \quad (14.4)$$

Por ejemplo, en la primera línea,

$$q_0 = 90/374,0 = 0,2406$$

El cambio de n_x por n'_x es necesario porque los w_x retirados están necesariamente bajo riesgo sólo durante una parte del intervalo. Es posible hacer un tratamiento más complejo de los retirados, particularmente cuando se conoce el momento de retirada en el intervalo. Sin embargo, en general es suficientemente adecuado asumir que las retiradas tienen el mismo efecto que si la mitad de ellas estuvieran bajo riesgo durante todo el período, de ahí, la aproximación (14.3). Una explicación alternativa es que si los w_x pacientes no se hubieran retirado, deberíamos esperar aproximadamente un número $(1/2) q_x w_x$ de fallecimientos extra. El número total de fallecidos sería entonces de $d_x + (1/2) q_x w_x$ y deberíamos estimar la tasa de mortalidad como:

$$q_x = \frac{d_x + \frac{1}{2}q_x w_x}{n_x} \quad (14.5)$$

Puede verse fácilmente que (14.5) es equivalente a (14.3) y (14.4).

$$\text{Var}(l_x) = l_x^2 \sum_{i=0}^{x-1} \frac{d_i}{n_i'(n_i' - d_i)}$$

En la tabla 14.2, por ejemplo, cuando $l_4 = 35,0\%$

$$\begin{aligned} \text{Var}(l_4) &= (35,0)^2 \left[\frac{90}{(374)(284)} + \frac{76}{(284)(208)} + \frac{51}{(208)(157)} + \frac{25}{(151)(126)} \right] \\ &= 6,14 \end{aligned} \quad (14.7)$$

y

$$\text{ET}(l_4) = \sqrt{6,14} = 2,48$$

Los límites aproximados con el 95% de confianza para l_4 serán:

$$35,0 \pm (1,96)(2,48) = 30,1 \text{ y } 39,9$$

La aplicación de (14.7) puede producir valores imposibles de límite de confianza fuera del intervalo de 0 a 100%. Una alternativa para evitar este hecho es aplicar la doble transformación logarítmica, $\ln(-\ln l_x)$, a (14.6), con $l_0 = 1$, de forma de l_x sea una proporción con valores permisibles entre 0 y 1 (Kalbfleisch y Prentice, 1980). Así, la fórmula de Greenwood se modifica para obtener límites de confianza del 95% para l_x de:

$$l_x^{\exp(\pm 1,96s)} \quad (14.8)$$

donde

$$s = \text{ET}(l_x) / (-l_x \ln l_x)$$

En el ejemplo anterior, $l_4 = 0,35$, $\text{ET}(l_4) = 0,0248$, $s = 0,0675$, $\exp(1,96s) = 1,14$, $\exp(-1,96s) = 0,876$ y los límites son $0,35^{1,14}$ y $0,35^{0,876}$ lo que equivale a 0,302 y 0,399. En este caso, en que los límites obtenidos utilizando (14.7) no están cerca de los límites del intervalo permitido, (14.8) proporciona casi los mismo valores que (14.7).

Peto et al (1977) proporcionan una fórmula para $\text{ET}(l_x)$ que es más fácil de calcular que (14.7):

$$\text{ET}(l_x) = l_x \sqrt{[(1 - l_x)/n_x']} \quad (14.9)$$

Como en (14.8), es esencial trabajar con l_x como proporción. En el ejemplo, (14.9) proporciona $\text{ET}(l_4) = 0,0258$. (14.9) es conservadora, pero puede ser más apropiada en el período de incremento de la incertidumbre al final de las tablas de vida cuando ya hay pocos supervivientes en estudio.

Chiang (1984, cap. 8) proporciona métodos para calcular la variancia muestral de diversas entradas en la tabla de vida, incluida la esperanza de vida.

14.5. Estimación producto-límite de la supervivencia

La tabla de vida estimada dada en la tabla 14.2 se obtuvo después de dividir el período de seguimiento en intervalos de tiempo. En algunos casos, los datos sólo pueden obtenerse en forma de grupos y con frecuencia es conveniente resumir los datos en grupos. Sin embargo, la formación de éstos puede implicar una elección arbitraria de los intervalos de tiempo, lo cual puede evitarse con el método propuesto por Kaplan y Meier (1958). En este método, efectivamente, los datos se analizan como si estuvieran agrupados en un gran número de intervalos de tiempo tan cortos como la precisión del registro lo permita. De esta forma, si la supervivencia se ha registrado con una precisión de un día, los intervalos utilizados serán de un día. Supongamos que en el tiempo t_j hay d_j fallecidos y que, justo antes de que ocurrieran estas muertes, el número de sujetos supervivientes era n'_j . Entonces, la probabilidad de fallecimiento para el tiempo t_j será:

$$q_j = d_j / n'_j \quad (14.10)$$

Esta fórmula equivale a (14.4). Por convención si se eliminan algunos sujetos en el tiempo t_j , se considera que han sobrevivido: el mismo tiempo que los fallecidos en el tiempo t_j y la corrección propuesta en (14.3) no se aplica. Para la mayoría de los intervalos de tiempo $d_j = 0$, por lo tanto $q_j = 0$ y la probabilidad de supervivencia $p_j (= 1 - q_j) = 1$. Estos intervalos pueden ignorarse en el cálculo de las supervivencias de la tabla de vida como producto de supervivencias según (14.6). La supervivencia para un tiempo t , l_t , se estimará, pues, mediante:

$$l_t = \prod_j p_j = \prod_j \frac{n'_j - d_j}{n'_j} \quad (14.11)$$

en la que el producto se realiza sobre todos los intervalos en los que ha habido algún fallecimiento, hasta t inclusive. Esta estimación se denomina estimación *producto-límite*, ya que corresponde al límite del producto presentado en (14.6) cuando los intervalos de tiempo tienden a cero. Este estimador es también el de máxima verosimilitud. Las estimaciones obtenidas se expresan siempre en forma gráfica. La curva de supervivencia consta de líneas horizontales con escalones verticales para cada fallecimiento (fig. 14.1). Los cálculos pueden observarse en la tabla 14.4.

14.6. Test del rango (*logrank*)

El test que se describe en este apartado se utiliza para la comparación de dos o más grupos de datos de supervivencia. El primer paso es ordenar los tiempos de supervivencia, los observados y los censurados. Supóngase, por ejemplo, que hay dos grupos, A y B. Si para un tiempo t_j hubiera d_j fallecimientos y n'_{jA} y n'_{jB} sujetos vivos justo antes de t_j en los grupos A y B, respectivamente, los datos podrían presentarse en una tabla 2 x 2:

	Fallecidos	Supervivientes	Total
Grupo A	d_{jA}	$n'_{jA} - d_{jA}$	n'_{jA}
Grupo B	d_{jB}	$n'_{jB} - d_{jB}$	n'_{jB}
Total	d_j	$n'_j - d_j$	n'_j

Excepto para los tiempos de supervivencia empatados, $d_j = 1$ y cada d_{jA} y d_{jB} es 0 o 1. Nótese también que si un sujeto se pierde o retira en t_j , es considerado riesgo durante aquel tiempo, y, por lo tanto, incluido en n'_j .

En la hipótesis nula de que el riesgo de muerte es el mismo para los dos grupos, podría esperarse que el número de muertes en cualquier momento se distribuyera entre los dos grupos proporcionalmente a los números riesgo. Esto es:

$$\left. \begin{aligned} E(d_{jA}) &= n'_{jA} d_j / n'_j, \\ \text{Var}(d_{jA}) &= \frac{d_j (n'_j - d_j) n'_{jA} n'_{jB}}{n_j'^2 (n'_j - 1)} \end{aligned} \right\} \quad (14.12)$$

En caso de que $d_j = 1$, (14.12) se simplifica a:

$$\begin{aligned} E(d_{jA}) &= p'_{jA} \\ \text{Var}(d_{jA}) &= p'_{jA} (1 - p'_{jA}) \end{aligned}$$

donde $p'_{jA} = n'_{jA} / n'_j$ la proporción de supervivientes que existe en el grupo A.

La diferencia entre d_{jA} y $E(d_{jA})$ es una evidencia contra la hipótesis nula. El test del rango es la combinación de estas diferencias en todos los tiempos en que se hayan registrado fallecimientos. Es análogo del test de Mantel-Haenszel para la combinación de datos a lo largo de niveles (v. el apartado 12.6), que Mantel (1966) introdujo de este modo por primera vez.

Sumando sobre todos los tiempos de muerte, j , obtenemos:

$$\begin{aligned} O_A &= \sum d_{jA} \\ E_A &= \sum E(d_{jA}) \\ V_A &= \sum \text{Var}(d_{jA}) \end{aligned}$$

E_A puede considerarse el número de muertes «esperadas» en el grupo A, pero, dado que en algunas circunstancias E_A puede sobrepasar el número de individuos que empiezan en el grupo, una descripción más detallada es la *extensión de la exposición al riesgo de fallecimiento* (Peto et al. 1977). Un test estadístico para la equivalencia de las tasas de mortalidad en los dos grupos es:

$$\chi^2_1 = \frac{(O_A - E_A)^2}{V_A} \quad (14.13)$$

lo que corresponde aproximadamente a la distribución de la $\chi^2_{(1)}$. Un test estadístico alternativo más simple que no requiere el cálculo de las variancias es:

$$\chi^2_2 = \frac{(O_A - E_A)^2}{E_A} + \frac{(O_B - E_B)^2}{E_B} \quad (14.14)$$

Este estadístico también sigue aproximadamente una $\chi^2_{(1)}$.

En la práctica el uso de (14.14) suele ser adecuado, pero peca de conservador (Peto y Pike, 1973).

El test del rango puede generalizarse a más de dos grupos. El sumatorio de (14.14) se amplía para cubrir todos los grupos, y O_A y E_A , etc., se calculan igual que si hubiera dos grupos. El test estadístico tendría $k - 1$ gl si hubiese k grupos.

Los cocientes O_A/E_A y O_B/E_B se denominan tasas de mortalidad relativa y estiman la relación entre la tasa de mortalidad de cada grupo y la tasa de mortalidad entre ambos grupos combinados. El cociente entre las dos tasas relativas estima la tasa de mortalidad en el grupo A en relación con la del grupo B, a veces denominada *razón de riesgo*. La razón de riesgo y la variabilidad del muestreo están dadas por

$$\left. \begin{aligned} h &= \frac{O_A/E_A}{O_B/E_B} \\ \text{ET} [\ln(h)] &= \sqrt{\left(\frac{1}{E_A} + \frac{1}{E_B}\right)} \end{aligned} \right\} \quad (14.15)$$

Una estimación alternativa es:

$$\left. \begin{aligned} h &= \exp\left(\frac{O_A - E_A}{V_A}\right) \\ \text{ET} [\ln(h)] &= \sqrt{\frac{1}{V_A}} \end{aligned} \right\} \quad (14.16)$$

(Machin y Gardner, 1989). La fórmula (14.16) es similar a (4.23). Tanto (14.15) como (14.16) están sesgadas, y los intervalos de confianza basados en los errores tipo tendrán una cobertura menor que la nominal cuando la razón de riesgo no sea cercana a la unidad. La fórmula (14.15) es menos sesgada y es conveniente para h inferior a 3, pero para razones de riesgo más altas se puede calcular un error tipo ajustado (Berry et al, 1991) o es aconsejable un análisis más complejo (apartado 14.8).

Ejemplo 14.1

En la tabla 14.3 se presentan los datos de supervivencia correspondientes a pacientes con linfoma histiocítico difuso según el estadio de su tumor (datos obtenidos de McKelvey et al, 1976). La supervivencia se mide en días desde la entrada en el ensayo clínico. Había pequeñas diferencias de supervivencia entre los dos grupos de tratamiento que no se tienen en cuenta en este ejemplo.

En la tabla 14.4 se presentan los cálculos de la estimación producto-límite de la tabla de vida para el grupo en el estadio 3, y en la figura 14.1 se muestra la comparación de supervivencia entre los dos estadios. Es evidente que la supervivencia es mayor, en promedio, en los pacientes que presentan un tumor en el estadio 3 que en el estadio 4. Esta diferencia puede comprobarse formalmente mediante el test del rango.

Los cálculos básicos necesarios para el test del rango se presentan en la tabla 14.5. Con objeto de abreviar, sólo se muestran los fallecimientos ocurridos al principio y al final del período de observa-

Tabla 14.3. Supervivencia de pacientes con linfoma histiocítico difuso según el estadio del tumor.

Supervivencia (días)								
Estadio 3	6	19	32	42	42	43*	94	126*
	169*	207	211*	227*	253	255*	270*	310*
	316*	335*	346*					
Estadio 4	4	6	10	11	11	11	13	17
	20	20	21	22	24	24	29	30
	30	31	33	34	35	39	40	41*
	43*	45	46	50	56	61*	61*	63
	68	82	85	88	89	90	93	104
	110	134	137	160*	169	171	173	175
	184	201	222	235*	247*	260*	284*	290*
	291*	302*	304*	341*	345*			

* Aún vivos (valores censurados).

Tabla 14.4. Cálculo de la estimación producto-límite de la tabla de vida para datos tomados del estadio 3 del tumor de la tabla 14.3.

Tiempo (días) t_j	Fallecidos d_j	Vivos al inicio del día n_j	Probabilidad estimada de		Porcentaje de supervivientes al final del día l_j
			Muerte q_j	Supervivencia p_j	
0	—	19	—	—	100
6	1	19	0,0526	0,9474	94,7
19	1	18	0,0556	0,9444	89,5
32	1	17	0,0588	0,9412	84,2
42	2	16	0,1250	0,8750	73,7
94	1	13	0,0769	0,9231	68,0
207	1	10	0,1000	0,9000	61,2
253	1	7	0,1429	0,8571	52,5

ción. Los dos grupos se señalan mediante los subíndices 3 y 4, y no mediante A y B como se ha efectuado en la descripción general.

Aplicando (14.13) se obtiene:

$$\begin{aligned}
 X_1^2 &= (8 - 16,6870)^2 / 11,2471 \\
 &= 8,6870^2 / 11,2471 \\
 &= 6,71 \quad (P = 0,010)
 \end{aligned}$$

Para calcular (14.14), primero calculamos E_d mediante la igualdad $O_3 + O_4 = E_3 + E_4$.

Así, $E_4 = 37,3130$ y

$$\begin{aligned}
 X_2^2 &= 8,6870^2 (1/16,6870 + 1/37,3130) \\
 &= 6,54 \quad (P = 0,010)
 \end{aligned}$$

Así se demuestra que la diferencia mostrada en la figura 14.1 difícilmente puede deberse al azar.

El test del rango es un test no paramétrico. Se pueden obtener otros tests modificando el test de la suma de rangos de Wilcoxon (apartado 13.3), de forma que éstos pueden aplicarse para comparar tiempos de supervivencia en dos grupos en el caso de que algunos tiempos de supervivencia sean valores censurados (Cox y Oakes 1984, p. 124). Dicho test parece ser más sensible que el del rango para situaciones en las que la proporción de sucesos en los tiempos iniciales es mayor que en los finales.

14.7. Modelos paramétricos

En los estudios sobre mortalidad la variable de interés es el tiempo de supervivencia. Una aproximación posible al análisis es postular una distribución para los tiempos de supervivencia y estimar los parámetros de esta distribución a partir de los datos. Esta aproximación se aplica normalmente tomando como punto de partida un modelo para la tasa de mortalidad y determinando la forma de la distribución del tiempo de supervivencia resultante.

La tasa de mortalidad variará habitualmente en función del tiempo transcurrido desde la entrada en el estudio, t , y será designada por $\lambda(t)$; algunas veces a $\lambda(t)$ se la denomina *función de riesgo*. Supongamos que la densidad de probabilidad del tiempo de supervivencia es $f(t)$ y que su correspondiente función de distribución es $F(t)$. Entonces, dado que la tasa de mortalidad es el cociente entre fallecidos y la proporción de población superviviente, tenemos,

$$\left. \begin{aligned} \lambda(t) &= \frac{f(t)}{1 - F(t)} \\ &= f(t)/S(t) \end{aligned} \right\} \quad (14.17)$$

donde $S(t) = 1 - F(t)$ es la proporción de supervivientes, a la que se denomina *función de supervivencia*.

La ecuación (14.17) permite que $f(t)$ y $S(t)$ sean especificados en términos de $\lambda(t)$. En lugar de analizar la fórmula general consideraremos algunos casos particulares. La forma más simple es aquella en que la tasa de mortalidad es una constante; es decir, $\lambda(t) = \lambda$ para todo t . Integrando entonces (14.17) respecto de t , y teniendo en cuenta que $f(t)$ es la derivada de $F(t)$ (apartado 2.3), tenemos:

$$\lambda t = -\ln [S(t)] \quad (14.18)$$

Es decir:

$$S(t) = \text{Exp}(-\lambda t)$$

El tiempo de supervivencia tiene una distribución exponencial de media $1/\lambda$. Si esta distribución es apropiada entonces, según (14.18), una representación del logaritmo de la función de supervivencia frente al tiempo nos daría una línea recta que pasaría por el origen.

Los datos de un grupo de sujetos constan de varios fallecimientos con tiempos de supervivencia conocidos y un número de supervivientes para los cuales la supervivencia censurada también es conocida. Estos datos pueden utilizarse para estimar λ , utilizando el método de máxima verosimilitud (apartado 12.8). Para un valor determinado de λ la verosimilitud consta del producto de los valores $f(t)$ para los fallecimientos y $S(t)$ para los supervivientes. La estimación de máxima verosimilitud de λ , el error tipo de la estimación y el test de significa-

ción frente a un valor hipotético se obtienen utilizando el método general de la máxima verosimilitud aunque, en este caso en particular, la solución puede hallarse directamente sin iteración.

La restricción principal del modelo exponencial estriba en el supuesto de que la tasa de mortalidad es independiente del tiempo. No sería razonable esperar que este supuesto fuera cierto excepto en el caso de intervalos de tiempo muy cortos. Una vía de solución para esta restricción es dividir el período de seguimiento en intervalos de tiempo menores y asumir que la tasa de mortalidad es constante dentro cada intervalo, pero distinta en los diferentes intervalos (Holford, 1976).

Otro método para evitar el supuesto de que el riesgo es constante es utilizar un modelo paramétrico distinto de la tasa de mortalidad. Un posible modelo es el presentado por Weibull, definido por:

$$\lambda(t) = \alpha \gamma t^{\gamma-1} \quad (14.19)$$

donde γ es mayor que 1. Este modelo ha demostrado ser válido para describir la incidencia del cáncer en los seres humanos en relación con la edad (Cook et al, 1969) y para el tiempo después de la exposición a algún agente cancerígeno en experimentos con animales (Pike, 1966). Un segundo modelo es el que considera que el riesgo aumenta exponencialmente con la edad, esto es,

$$\lambda(t) = \alpha \text{Exp}(\beta t)$$

Éste es el riesgo según Gompertz, quien describe de forma bastante correcta la tasa de mortalidad por cualquier causa en adultos. También se ha utilizado un modelo en que los tiempos de muerte se distribuyen log-normalmente, pero tiene el inconveniente de que la tasa de riesgo asociada empieza a descender en algún momento.

14.8. Modelos de regresión y de riesgo proporcional

Sería atípico analizar un solo grupo de individuos homogéneos, por lo que el método básico debe extenderse para afrontar situaciones reales en las que la tasa de riesgo debe modelarse para ser capaz de representar dependencias con respecto a otras variables registradas para cada sujeto, además del tiempo. Por ejemplo, en un ensayo clínico podría postularse que la tasa de riesgo depende del tratamiento, lo que podría representarse mediante una o más variables ficticias (apartado 10.2). De nuevo, si un número de variables pronósticas fuera conocido, la tasa de riesgo se podría expresar como una función de estas variables. En general, la tasa de riesgo podría escribirse como una función de ambos, tiempo y covariantes, o sea como $\lambda(t, x)$ donde x representa el conjunto de covariantes $(x_1, x_2, \dots, x_k)$.

Ziping y Armitage (1966) consideraron una variable pronóstica, x , el logaritmo del recuento de leucocitos, y una distribución exponencial de supervivencia mediante:

$$\lambda(t, x) = (\alpha + \beta x)^{-1}$$

por lo tanto, el tiempo de supervivencia medio era lineal con respecto a x . El análisis consistía en la estimación de α y β . Un inconveniente de esta representación es que la tasa de riesgo

podría ser negativa para valores de x elevados (a partir de que β fuera negativa). Un modelo alternativo que evita este inconveniente, propuesto por Glasser (1967), es:

$$\lambda(t, x) = \alpha \text{Exp}(\beta x)$$

por lo tanto, el logaritmo del tiempo de supervivencia medio era lineal en x .

Generalmente el riesgo dependerá del tiempo, y puede escribirse como:

$$\lambda(t, x) = \lambda_0(t) \text{Exp}(\beta x) \quad (14.20)$$

donde βx representa la función de regresión $\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$ y $\lambda_0(t)$ es la parte del riesgo dependiente del tiempo; $\lambda_0(t)$ podría representar cualquiera de los modelos considerados en los apartados anteriores u otras funciones paramétricas de t . La ecuación (14.20) es un modelo de regresión en términos de las covariantes. También se lo denomina modelo de *riesgos proporcionales*, ya que los riesgos para los diferentes grupos de covariantes conservan la misma proporción para todo t . Los datos pueden analizarse paramétricamente utilizando (14.20), suponiendo que se asuma alguna forma determinada para $\lambda_0(t)$. Los parámetros $\lambda_0(t)$ y los coeficientes de regresión β podrían ser estimados. Las inferencias deberán plantearse en función de la estimación $\mathbf{b}$ de β , y los parámetros de $\lambda_0(t)$ no tendrán interés directo.

Otra manera de representar el efecto de las covariantes consiste en suponer que la distribución del tiempo de supervivencia cambia multiplicando la escala de tiempo por $\exp(\beta'x)$, es decir, que el logaritmo del tiempo de supervivencia aumenta en $\beta'x$. Luego, el riesgo se escribiría:

$$\lambda(t, x) = \lambda_0[t \exp(-\beta'x)] \exp(-\beta'x) \quad (14.21)$$

Esto se denomina *modelo del tiempo de fallo acelerado*. Para la distribución exponencial, $\lambda_0(t) = \lambda$, (14.20) y (14.21) son equivalentes, con $\beta' = -\beta$, de modo que el modelo del tiempo de fallo acelerado es también un modelo de riesgos proporcionales. Lo mismo se aplica para el Weibull (14.19), con $\beta' = -\beta/\gamma$, pero en general el modelo del tiempo de fallo acelerado no sería un modelo de riesgos proporcionales.

En varios paquetes de cálculo estadístico existen procedimientos para ajustar modelos del tipo expuesto en el párrafo anterior. Por ejemplo, en el programa SAS, usando la instrucción PROC LIFEREG es posible ajustar varios modelos paramétricos, como el exponencial, el Weibull y el log-normal.

Modelo de riesgos proporcionales de Cox

Dado que a menudo se desconoce una forma paramétrica adecuada de $\lambda_0(t)$ y, en cualquier caso, no tiene interés primordial, sería más práctico si no fuera necesario usar una forma determinada de $\lambda_0(t)$ en la ecuación (14.20). Ésta fue la aproximación introducida por Cox (1972). El modelo es entonces no paramétrico con respecto al tiempo, pero paramétrico en términos de las covariantes. La estimación de β y las inferencias se desarrollan considerando la información obtenida cada vez que ocurre un fallecimiento. Consideremos una muerte ocurrida en un tiempo t_j y supongamos que hay n_j' sujetos vivos justo antes de t_j , que los

valores de x correspondientes a estos sujetos son $x_1, x_2, \dots, x_n$ y que el sujeto fallecido se designa, sin pérdida de generalización, por el subíndice 1. El conjunto de n_j' sujetos en riesgo se denomina *grupo de riesgo*. El riesgo de fallecimiento en un tiempo t_j correspondiente a cada sujeto del grupo de riesgo está dado por la ecuación (14.20). Ello no nos proporciona medidas absolutas de riesgo, pero sí el riesgo relativo de cada sujeto, ya que aunque $\lambda_0(t_j)$ es desconocida, es la misma para cada sujeto. De este modo, la probabilidad de que la muerte observada en t_j fuera la del sujeto muerto en este momento es:

$$p_j = \exp(\beta x_1) / \sum \exp(\beta x_i) \quad (14.22)$$

donde el sumatorio se aplica a todos los miembros del grupo de riesgo. Se obtienen términos similares por cada momento en que ocurre un fallecimiento y se combinan para obtener una verosimilitud. Técnicamente se denomina *verosimilitud parcial*, puesto que sus componentes se obtienen condicionados a los tiempos en que las muertes ocurren y a la composición del grupo de riesgo en dichos momentos. Los tiempos reales en que ocurren las muertes no se emplean, pero el orden de los tiempos de fallecimiento y de control, es decir, los rangos, determina los grupos de riesgo. De este modo, el método comparte, en cuanto al tratamiento del tiempo, semejanzas con el test del rango no paramétrico (capítulo 13) y con el test del rango, que también está condicionado por los grupos de riesgo.

Como el tiempo se emplea de manera no paramétrica, la ocurrencia de empates, bien de tiempos de fallecimiento, bien suponiendo un tiempo de fallecimiento y un tiempo de control, ocasiona algunas complicaciones. Como con los tests no paramétricos explicados en el capítulo 13, éste no es un problema grave a menos que los empates sean amplios. El procedimiento más simple consiste en usar todo el grupo de riesgo, de todos los individuos vivos justo antes del momento empatado, para todos los individuos empatados (Breslow, 1974).

El modelo es ajustado mediante el método de verosimilitud máxima, y para lo cual suele emplearse un *software* estadístico específico, como la instrucción PROC PHREG del programa SAS. En el ejemplo 14.2 se detallan algunos de los pasos del proceso de ajuste para ilustrar los fundamentos del método.

Ejemplo 14.2

Los datos de la tabla 14.3 y del ejemplo 14.1 pueden analizarse utilizando la aproximación de Cox. Defínase una variable ficticia x que toma valor cero para el estadio 3 y un valor 1 para el estadio 4. Entonces, las tasas de mortalidad calculadas mediante (14.20) son $\lambda_0(t)$ para el estadio 3 y $\lambda_0(t) \text{Exp}(\beta)$ para el estadio 4, siendo $\text{Exp}(\beta)$ la tasa de mortalidad del estadio 4 en relación con el estadio 3. La primera muerte ocurrió después de 4 días (tabla 14.5) cuando el grupo de riesgo estaba formado por 19 sujetos en el estadio 3 y 61 en el estadio 4. El fallecimiento se produjo en un sujeto en estadio 4, y la probabilidad de que una muerte producida en ese momento correspondiera a un sujeto en el estadio 4 la deducimos mediante (14.22).

$$p_1 = \text{Exp}(\beta) / [19 + 61 \text{Exp}(\beta)]$$

El segundo momento en que se produjeron muertes fue a los 6 días. Hubo dos muertes con este tiempo de supervivencia y este empate se trata aproximadamente asumiendo que ambas fueron simul-

puesta con distribución normal (apartado 10.1). En correspondencia con el test del análisis de la variancia para la supresión de un conjunto de variables está el *test de Wald*, que proporciona un estadístico distribuido aproximadamente como la χ^2 con q grados de libertad, para probar la supresión de q covariantes. Con $q = 1$, la χ^2 de Wald con 1 gl es equivalente a la desviación normal estandarizada, como se empleó en el ejemplo 14.2.

Métodos diagnósticos

Las gráficas de la supervivencia frente al tiempo, por lo general con alguna transformación de uno o ambos elementos, son útiles para verificar la distribución del riesgo. A menudo se emplea a este efecto el *riesgo integrado* o *acumulado*, definido como:

$$H(t) = \int_0^t \lambda(u) du = -\ln[S(t)] \quad (14.23)$$

El riesgo integrado puede obtenerse a partir de la estimación de Kaplan Meier de $S(t)$ usando (14.23) o a partir del riesgo acumulado, evaluado como la suma de los riesgos discretos estimados en todos los tiempos del acontecimiento hasta t . Una gráfica de $\ln H(t)$ frente a $\ln t$ es lineal, con una pendiente de γ para el Weibull o con una pendiente 1 para el exponencial. La misma gráfica para subgrupos diferentes de individuos definidos mediante valores covariantes puede orientar acerca de si un modelo de riesgos proporcionales o del tiempo de fallo acelerado es la elección más adecuada para el efecto de las covariantes. En un modelo de riesgos proporcionales las curvas están separadas por distancias verticales constantes, y para un modelo del tiempo de fallo acelerado, por distancias horizontales constantes. Estas dos condiciones se cumplen si las gráficas son lineales, lo cual refleja el hecho de que tanto el Weibull como el exponencial son modelos de riesgos proporcionales y de tiempo de fallo acelerado. De otro modo sería difícil distinguir entre las dos posibilidades frente al contexto de la variabilidad debida al azar, pero entonces los dos modelos pueden dar inferencias similares de los efectos de las covariantes (Solomon, 1984). La elección de una forma de distribución concreta puede evitarse usando el modelo semiparamétrico de Cox, y las inferencias sobre los efectos de las covariantes serán similares con el modelo de Cox a las inferencias con una forma de distribución adecuada (Kay, 1977; Byar, 1983). Sin embargo, el empleo de una forma de distribución tenderá a proporcionar estimaciones ligeramente más precisas de los coeficientes de regresión.

Como se ha descrito en el apartado 10.1, a menudo las gráficas residuales son útiles para verificar los supuestos del modelo y para determinar si deberían incluirse covariantes adicionales. Con los datos de supervivencia, lo que un residual significa no es tan claro como lo es para una variable de desenlace continua. Un método es el *residual martingale* («doble o nada»), definido en términos del desenlace y del riesgo acumulado hasta el momento del acontecimiento o la censura; para un acontecimiento, el residual martingale («doble o nada») es $1 - H(t)$ y para un individuo censurado el residual es $-H(t)$. Estos residuales tienen una media de aproximadamente cero y una desviación tipo igual a la unidad, pero se distribuyen en forma asimétrica, con valores negativos altos para supervivientes a largo plazo y un máximo de 1 para un superviviente a corto plazo. Este sesgo hace que estos residuales sean difíciles de interpretar.

con distintas tablas de tasas de mortalidad, y cuando se estudia una causa determinada de fallecimiento, las muertes debidas a otras causas son tratadas a efectos prácticos como supervivientes suprimidos. Para cualquier causa de muerte el número observado se trata como una variable de Poisson con una esperanza matemática igual al número esperado (ejemplo 4.15). El método es similar a la estandarización indirecta de las tasas de mortalidad (apartado 12.9) y el cociente entre las muertes observadas y las esperadas recibe a menudo la denominación de tasa de mortalidad estandarizada (TME).

Ejemplo 14.3

Un grupo de 512 trabajadores de una fábrica de asbesto fue seguido en función del tiempo (Newhouse et al, 1985). Se incluyeron todos los varones que empezaron a trabajar en puestos concretos en cualquier momento posterior a 1933 y se determinó la mortalidad para cada sujeto a lo largo de cada período de 10 años después de la entrada como empleado en la fábrica, hasta el final de 1980. La mortalidad causada por cáncer de pulmón fue particularmente relevante. Los sujeto-años de riesgo y las tasas de mortalidad por cáncer de pulmón en Inglaterra y Gales se muestran en la tabla 14.6 en grupos de 5 años de edad y períodos de 10 años (en el trabajo original los períodos utilizados eran de 5 años).

El número esperado de fallecimientos por cáncer de pulmón es:

$$(82 \times 2 + 62 \times 1 + 13 \times 1 + \dots + 72 \times 756) \times 10^{-5} = 13,8$$

El número observado fue 67, por lo tanto, la TME es de $67/13,8 = 4,9$. Utilizando los métodos dados en el apartado 4.10, un test de la hipótesis nula según el cual los trabajadores del asbesto experimentan la mortalidad nacional es:

$$z = (67 - 13,8) / \sqrt{13,8} = 14,3 \quad (P < 0,001)$$

y los límites de confianza del 95% para la TME son 3,8 y 6,2.

Tabla 14.6. Sujeto-años de riesgo (*y*) en trabajadores del asbesto y tasas de mortalidad por 100.000 (*d*) por cáncer de pulmón para varones de Inglaterra y Gales.

Grupo de edad	Período							
	1941-1950		1951-1960		1961-1970		1971-1980	
	<i>y</i>	<i>d</i>	<i>y</i>	<i>d</i>	<i>y</i>	<i>d</i>	<i>y</i>	<i>d</i>
25-29	82	2	62	1	13	1	3	1
30-34	148	3	273	4	156	3	43	2
35-39	74	9	446	10	435	8	141	6
40-44	41	21	395	25	677	22	290	16
45-49	33	46	229	58	749	54	485	46
50-54	23	78	172	124	590	119	642	106
55-59	14	112	158	216	399	226	621	201
60-64	11	137	109	294	288	370	479	346
65-69	4	137	78	343	185	508	273	530
70-74	0	107	47	325	124	562	151	651
75+	0	86	16	270	58	518	72	756

Si γ_{ij} se modela en términos del estrato edad-período y un conjunto de covariantes por

$$\ln \gamma_{ij} = \alpha_j + \beta_1 x_{ij1} + \beta_2 x_{ij2} + \dots + \beta_p x_{ijp}$$

luego

$$\ln \mu_{ij} = \ln n_{ij} + \alpha_j + \beta_1 x_{ij1} + \beta_2 x_{ij2} + \dots + \beta_p x_{ijp} \quad (14.25)$$

Éste es un modelo lineal generalizado para una variable de Poisson (12.26) con el término adicional $\ln n_{ij}$. Una aplicación es proporcionada en el ejemplo 12.12 (p. 409). Breslow y Day (1987, cap. 4) proporcionan detalles más completos y ejemplos exhaustivos.

En muchos casos, los métodos externo (14.24) e interno (14.25) darán inferencias similares sobre el efecto de las covariantes. Este último tiene la ventaja de que no hay suposición alguna de que las tasas de mortalidad en todos los estratos edad-período sigan un modelo de riesgos proporcionales con respecto a la población de referencia, pero la precisión de las comparaciones es ligeramente peor que con el método externo. Una combinación de ambos métodos, usando (14.24) para el grupo global y los subgrupos principales y (14.25) para el modelado de la regresión, ofrece la ventaja de estimar los efectos de las covariantes y de también cómo la mortalidad en el grupo global se compara con la de la población de la que forma parte. Checkoway et al. (1993) exponen un ejemplo en el que se llevó a cabo dicha combinación.

Capítulo 15

Métodos secuenciales

15.1. Generalidades

En la mayoría de los ejemplos descritos en los capítulos precedentes podría suponerse que el número de observaciones se determina con bastante independencia de los valores numéricos de las observaciones. En los experimentos de laboratorio controlados el número de observaciones habitualmente se decide de antemano. En otros estudios médicos, como los ensayos clínicos o los estudios epidemiológicos, el tamaño muestral conveniente puede depender de la facilidad con que las observaciones puedan llevarse a cabo o de la proporción de pacientes apropiados a los que se tenga acceso. Incluso en este caso, sin embargo, el tamaño de la muestra no está necesariamente afectado por los valores observados de las variables aleatorias sobre las que se efectúa el análisis.

En dichas circunstancias parece razonable considerar el tamaño de la muestra como una variable, cuya importancia principal reside en su efecto sobre la precisión del estudio, sin proporcionar por sí misma información alguna sobre los contrastes que se hallan bajo estudio. Al evaluar el efecto de la variación aleatoria suele imaginarse que está fijado el tamaño de la muestra; es decir, nos preguntamos cuál será la variación aleatoria que va a observarse en hipotéticas repeticiones de la investigación con el mismo tamaño muestral.

Otros tipos de investigaciones son bastante distintos en cuanto a que el tamaño conveniente del estudio puede ser no sólo impredecible antes de su comienzo sino que incluso puede depender de los valores numéricos de las observaciones. Determinadas clases de observación pueden, por ejemplo, conducir a una conclusión relativamente temprana del estudio, mientras que otras pueden conducir a una investigación prolongada. Este tipo de estudio se denomina *secuencial*. Si el aspecto secuencial del diseño es suficientemente formal, será descrito mediante una *regla de cese*, que define de qué modo la decisión de detener la investigación depende de los resultados obtenidos. La regla de cese es, pues, una característica especial de los diseños secuenciales, complementando otras características más familiares como la aleatorización y la construcción de bloques (en experimentos) y la selección al azar (en encuestas).

Los métodos de análisis de datos recogidos secuencialmente constituyen el tema denominado *análisis secuenciales*, y los trabajos clásicos sobre ellos se deben a Wald (1947).

Antes de considerar brevemente los métodos concretos de diseño y análisis secuencial sería conveniente indicar algunas de las posibles razones para utilizar métodos secuenciales.

Economía

En la inspección muestral industrial puede haber numerosos materiales para clasificar como de buena o mala calidad sobre la base de tests cuyos resultados están sujetos a variación

aleatoria. En la industria farmacéutica, por ejemplo, se pueden clasificar compuestos según su actividad específica de acuerdo con su actuación en un test biológico. En lugar de llevar a cabo una larga experimentación con cada fármaco, puede ser más eficiente experimentar secuencialmente, de modo que la mayoría de los compuestos se rechazan rápidamente mientras que una minoría de fármacos con resultados prometedores se someten a más observaciones antes de adoptar una decisión (Armitage y Schneiderman, 1958; King, 1963). Este tipo de procedimientos secuenciales normalmente reduce el número total de experimentaciones y, quizás, el coste de la operación global, obteniéndose al mismo tiempo un nivel determinado de discriminación entre buena y mala calidad.

Para lograr una precisión especificada

En el apartado 6.6 indicamos que el tamaño de una muestra aleatoria necesario para reducir el error tipo de una media a un nivel especificado depende de la desviación tipo residual, σ . Si inicialmente se desconoce σ , puede estimarse a partir de un estudio piloto. Por otra parte podríamos incluir el estudio piloto en el muestreo definitivo si se mantiene una secuencia de estimaciones de σ , utilizando todas las observaciones realizadas hasta el momento y deteniendo el estudio cuando el error tipo estimado alcance el nivel requerido.

Supóngase que en una muestra aleatoria de tamaño n procedente de una distribución con media μ y variancia σ^2 , la media estimada es $\bar{x}_n$ y la desviación tipo estimada es s_n . Los subíndices enfatizan el hecho de que ambos estadísticos cambiarán al azar a medida que n aumente. El error tipo estimado de $\bar{x}_n$ es:

$$ET(\bar{x}_n) = S_n \sqrt{n} \quad (15.1)$$

y, aunque s_n fluctuará de forma aleatoria, dicho error tipo tenderá a disminuir a medida que n aumente.

Supóngase que el propósito de la investigación es estimar μ con una precisión dada, como en el apartado 6.6 criterio 1 (p. 185); en concreto, supóngase que requerimos que $ET(\bar{x}_n) < \epsilon$. Entonces, una regla de finalización apropiada sería continuar el muestreo hasta que $S_n \sqrt{n}$ sea menor que ϵ .

Se plantea entonces la cuestión de si la fórmula (15.1) para el error tipo es válida para esta forma de muestreo secuencial; su interpretación original se efectuó en términos de muestras repetidas con un tamaño muestral fijo. La respuesta es, en forma general, que el método es válido. En primer lugar, si escogemos interpretar el error tipo como medida de la dispersión de la función de verosimilitud, o como la desviación tipo de la distribución *a posteriori* con conocimiento previo disperso (apartado 4.12), tenemos un resultado importante: *las funciones de verosimilitud y las distribuciones a posteriori no están afectadas por la elección de una regla de cese*. El diseño secuencial es, desde este punto de vista, irrelevante. En segundo lugar, desde el punto de vista más tradicional, basado en frecuencias, los límites de confianza usuales son aproximadamente válidos, en particular en muestras razonablemente grandes. Es decir, si el procedimiento muestral secuencial se repite muchas veces, los límites de confianza del 95% usuales incluirán el valor verdadero μ aproximadamente el 95% de las veces.

ración correcta de los indicios *en este determinado momento*. El principio enunciado en el apartado anterior muestra que las probabilidades relativas de distintos parámetros (en este ejemplo, los diferentes valores de la probabilidad π de obtener una preferencia por A) no están afectadas por la regla de cese. No obstante, se ha producido alguna selección de indicios. El investigador se ha dado a sí mismo un largo número de indicios. El investigador se ha dado a sí mismo un largo número de oportunidades para detenerse al nivel del 5%. Incluso si la hipótesis nula es verdadera, existe una probabilidad sustancial de que se encuentre un resultado «significativo», probabilidad que se incrementará evidentemente a lo largo de la duración del test.

La situación es muy similar a la considerada en el apartado 7.4 en relación con las comparaciones múltiples. La probabilidad, dada la hipótesis nula, de que un test secuencial se detenga con un veredicto en favor de un tratamiento u otro puede denominarse nivel de significación *global* (un término más formal es el de probabilidad de un error del tipo I; v. apartado 6.6). Para controlar que el nivel de significación global sea menor del 5%, por ejemplo, se requiere un nivel de significación mucho mayor (es decir, una probabilidad *menor*) para valorar los resultados en cada uno de los pasos. Esta condición es insuficiente por sí misma para determinar la regla de cese: se pueden elaborar distintas reglas para satisfacer un nivel

Tabla 15.1 Ejemplo ilustrativo del uso repetido de tests de significación en series de preferencias para uno de dos fármacos analgésicos.

Número de paciente	Preferencia	(1) Número acumulado de preferen- cias por A	Valores críticos para (1) al nivel de significación bilateral del 5%
1	B	0	—
2	A	1	—
3	A	2	—
4	A	3	—
5	A	4	—
6	A	5	0,6
7	A	6	0,7
8	B	6	0,8
9	B	6	1,8
10	A	7	1,9
11	A	8	1,10
12	B	8	2,10
13	B	8	2,11
14	A	9	2,12
15	A	10	3,12
16	A	11	3,13
17	A	12	4,13
18	A	13	4,14
19	A	14	4,15
20	B	14	5,15
21	A	15	5,16
22	B	15	5,17
23	A	16	6,17
24	A	17	6,18
25	A	18	7,18

de significación global específico. La teoría de Wald (1947) proporciona un importante método general. Armitage (1975) Whitehead (1992) describen con detalle algunos planes secuenciales bastantes distintos, diseñados especialmente para ensayos médicos; estos métodos se exponen a continuación.

Supongamos que la regla de cese es detener el test si los datos acumulados en cualquier estadio muestran una diferencia significativa al nivel nominal bilateral 2α , o detenerla después de N estadios si el test no se ha detenido antes. Para lograr un nivel de significación global bilateral, 2α , del 5%, ¿qué valor debería escogerse para $2\alpha'$, el nivel de significación en un estadio cualquiera? La respuesta depende claramente de N ; cuanto mayor sea N , menor debe ser $2\alpha'$. En la tabla 15.2 se dan algunos resultados.

La parte izquierda de la tabla 15.2 se refiere a los tests de significación repetidos basados en la distribución binomial, como en el ejemplo del principio de este apartado. El lado derecho se refiere a los test repetidos en series acumuladas de observaciones sobre variables aleatorias distribuidas normalmente cuando la variancia es conocida, una situación que se trata con más detalle en el apartado 15.3. La diferencia entre los dos conjuntos de resultados de la tabla 15.2 surge principalmente de la discontinuidad de la distribución binomial.

La elección de N , el tamaño muestral máximo de un test secuencial, dependerá bastante de las mismas consideraciones que las descritas en el apartado 6.6. En concreto, como en el criterio 3 de dicho apartado, uno puede desear que se seleccione un diseño secuencial que no sólo controle el nivel de significación global, 2α , sino que tenga un poder especificado, denominado $1 - \beta$, de proporcionar un resultado significativo cuando cierta alternativa a la hipótesis nula sea verdadera. En el test binomial descrito anteriormente, una hipótesis alternativa determinada podría especificar que la probabilidad de una preferencia por el fármaco A, la cual denominamos π , es algún valor π_1 distinto de $1/2$. Si el diseño secuencial es simétrico, proporcionará automáticamente el mismo poder para $\pi = \pi_0 (= 1 - \pi_1)$ que para $\pi = \pi_1$. Por ejemplo, si $\pi_1 = 0,8$ y $\pi_0 = 0,2$, la hipótesis $\pi = \pi_1$ indica un beneficio por el uso del fármaco A, y la hipótesis $\pi = \pi_0$ indica un beneficio igual por el uso del fármaco B; cada una de estas hipótesis alternativas tendría la misma posibilidad de ser detectada mediante un diseño secuencial simétrico.

Tabla 15.2. Test de significación repetida sobre observaciones binomiales acumuladas y observaciones normales; niveles de significación nominal para utilizar en todos los tests individuales, de forma que el nivel global $2\alpha = 0,05$.

Número de estadios N	Nivel de significación nominal bilateral, $2\alpha'$, para tests individuales	
	Binominal	Normal
1	—	0,050
5	—	0,015
10	0,031	0,010
15	0,023	0,008
20	0,022	0,007
50	0,013	0,005
100	0,008	0,004
150	0,007	0,003

La tabla 15.3 muestra los tamaños muestrales máximos y los niveles de significación para tests individuales, de diseños secuenciales binomiales con un nivel de significación global $2\alpha = 0,05$ y un poder de $1 - \beta = 0,95$ con distintos valores alternativos de π . Éstos son ejemplos de diseños para *tests de significación repetida* (TSR). Armitage (1975) proporciona tablas más extensas (tablas 3.9 a 3.12).

Cualquiera de los diseños binomiales (TSR) de la tabla 15.3 se puede representar gráficamente mediante un diagrama como el de la figura 15.1 (que representa el plan con $\pi_1 = 0,85$). En este diagrama, el eje horizontal representa el número de preferencias registradas en cualquier estadio. El eje vertical representa la diferencia entre los números de preferencias por A y por B. Los límites se obtienen a partir de la distribución binomial. El curso de cualquier ensayo se refleja en un gráfico, trazando desde el origen una línea en zigzag y desplazándola una unidad a la derecha y hacia arriba (es decir, en dirección «noreste») por cada preferencia por A, y una unidad a la derecha y hacia abajo (dirección «sudeste») por cada preferencia por B. Los datos representados en la figura 15.1 se han tomado de un ensayo para valorar algunos supresores de la tos (Snell y Armitage, 1957; v. también Armitage, 1975, ejemplo 3.3); A es un fármaco activo y B es un placebo. Los resultados se resumen en la tabla 15.4. La superioridad del fármaco activo se demostró en la decimoséptima preferencia y hubiese sido razonable terminar el ensayo en ese punto o poco después de él. En realidad, como muestra la tabla 15.4, se obtuvieron algunas preferencias adicionales (quizá porque el tratamiento ya había empezado para dichos pacientes), y éstas tendían a confirmar los primeros resultados.

Originalmente, este ensayo se diseñó con métodos algo distintos de análisis secuencial (*planes restringidos*; Armitage, 1975, p. 52). Una comparación de la figura 15.1 con la figura 3.7 de dicha obra o con el gráfico en el artículo original muestra que los dos planes son muy similares; la diferencia esencial radica en que los primeros planes tenían límites prácticamente lineales, mientras que los actuales son bastante más curvados. Otra diferencia es que en los primeros planes se modificó la parte vertical del extremo interrumpiendo el ensayo tan pronto como quedó claro que no podía alcanzarse ninguno de los límites más externos; al límite resultante se le dio la forma: <. Aquí podría utilizarse el mismo procedimiento.

En cualquier ensayo que utilice series de preferencias, es probable que algunas comparaciones no den una preferencia en una dirección determinada. En los datos de la tabla 15.4, por ejemplo, algunos pacientes no quisieron manifestar preferencia por un preparado u otro. Para los fines de un test de significación sólo se utilizan las preferencias definidas; se pueden ig-

Tabla 15.3. Tamaño muestral máximo, N , y niveles de significación nominal para tests individuales, $2\alpha'$, para planes binomiales con tests de significación repetidas (TSR) con nivel global $2\alpha = 0,05$ y poder $1 - \beta = 0,95$ frente a varios valores de π distintos del valor nulo 0,5.

π_1	$2\alpha'$	N
0,95	0,0313	10
0,90	0,0225	16
0,85	0,0193	25
0,80	0,0147	38
0,75	0,0118	61
0,70	0,0081	100

norar las restantes. Sin embargo, al estimar los méritos relativos de los tratamientos reviste suma importancia saber si muchos pacientes no fueron capaces de manifestar una preferencia, y cualquier resumen de los datos debe contener una especificación clara de este aspecto.

15.3. Aproximaciones normales

El ejemplo presentado en la tabla 15.1 y gran parte del apartado 15.2 se refieren a los datos binarios; la tabla 15.3 resume brevemente las características de algunos planes binomiales de TSR. El tipo de datos obtenido en los ensayos clínicos es muy variado y no puede tratarse en detalle en este capítulo. Es conveniente, sin embargo, tomar en consideración planes para probar la media de una distribución normal con variancia conocida, no tanto porque dicha situación se plantee con frecuencia en la práctica (las distribuciones son a menudo no normales y las variancias por lo general desconocidas), sino porque puede utilizarse como una buena aproximación a un amplio abanico de situaciones.

Supongamos que en un test para comparar dos tratamientos, A y B, la variable respuesta, d , se distribuye como $N(\mu, \sigma^2)$, y que $\mu = 0$ bajo la hipótesis nula de que A y B tienen los mismos efectos (d podría muy bien ser la diferencia entre las respuestas emparejadas de A y B). Podemos desear seleccionar un plan TSR que: a) controle el nivel de significación global en 2α , y b) proporcione una potencia $1 - \beta$ frente a un valor alternativo $\mu = \mu_1$ o la situación opuesta con $\mu = -\mu_1$. La tabla 15.5 resume las características de algunos planes con $2\alpha = 0,05$ y $1 - \beta = 0,95$. Como en el apartado 15.2, $2\alpha'$ es el nivel de significación nominal y N es el número máximo de respuestas que se van a observar; k es la desviación normal estandarizada con una probabilidad $2\alpha'$ de excederla (así, en la tabla A1, $z = k$ y $P = 2\alpha'$). Un procedimiento gráfico adecuado es trazar $y = \sum d$ frente al número de observaciones n , con dos límites externos que representan el rechazo de la hipótesis nula en favor de A o B.

Armitage (1975, tablas 5.5 y 5.6) proporciona tablas más extensas.

Estos planes (TSR) para las variables normalmente distribuidas se pueden utilizar como aproximaciones para situaciones más generales, incluyendo, por ejemplo, tests de dos muestras. Supóngase que estamos interesados en un parámetro, θ , que la hipótesis nula especifica que $\theta = 0$ y que queremos un poder elevado frente a una hipótesis alternativa de que $\theta = \theta_1$ o que $\theta = -\theta_1$. Dejemos que las probabilidades de error sean 2α y β , como antes.

Tabla 15.5. Tamaño muestral máximo, N , nivel de significación nominal para tests individuales $2\alpha'$, y desviación normal estandarizada, k , para planes normales con test de significación repetidas (TSR), siendo el nivel global $2\alpha = 0,05$ y el poder $1 - \beta = 0,95$ frente a diversos valores de $d_1 = \mu_1/\sigma$.

$d_1 = \mu_1/\sigma$	$2\alpha'$	k	N
0,3	0,003	2,95	200
0,4	0,004	2,89	111
0,5	0,005	2,84	71
0,6	0,005	2,80	49
0,8	0,006	2,73	28
1,0	0,008	2,65	17
1,2	0,009	2,60	12
1,4	0,012	2,52	8

Tabla 15.6. Características de planes secuenciales de grupo para variables normales, con N test repetidos al nivel nominal $2\alpha'$ y m observaciones entre puntos de inspección sucesivos para un nivel de significación global $2\alpha = 0,05$ y un poder $1 - \beta = 0,95$ frente a distintos valores de $\delta_1 = \mu_1 \sqrt{m/s}$.

N	$2\alpha'$	k	$\delta_1 = \mu_1 \sqrt{m/s}$
2	0,029	2,18	2,66
3	0,022	2,29	2,22
4	0,018	2,36	1,95
5	0,016	2,41	1,76
6	0,014	2,45	1,62
7	0,013	2,48	1,51
8	0,012	2,51	1,42
9	0,011	2,54	1,34
10	0,011	2,56	1,28

Como en el apartado 15.3, los planes para variables de respuesta normal, como los de la tabla 15.6, se pueden utilizar como soluciones aproximadas a problemas más generales. Supóngase, como antes, que estamos estudiando un parámetro θ y queremos probar la hipótesis nula de que $\theta = 0$ frente a los valores alternativos θ_1 y $-\theta_1$. Como antes, supóngase que $\theta_1/\text{Var}(\hat{\theta})$ se incrementa en una cantidad I entre dos. En tal caso, la tabla 15.6 puede utilizarse, con δ_1 representado $\theta_1 \sqrt{I}$, o $\theta_1 \sqrt{\text{Var}(\hat{\theta})}$, donde $\text{Var}(\hat{\theta})$ es la variancia de $\hat{\theta}$ después de n inspecciones.

Ejemplo 15.1

En un ensayo estudiado por Pocock (1983, p. 192), Cockburn et al (1980) compararon el efecto de administrar un suplemento de vitamina D a mujeres embarazadas con un tratamiento de control, midiendo la respuesta mediante la concentración plasmática de calcio del bebé 6 días después del nacimiento. La desviación tipo de la respuesta (mg/100 ml) fue de aproximadamente 1,2. Supóngase que en un ensayo de este tipo fuera necesario detectar un cambio en la media de calcio plasmático de 0,3 mg/100 ml y que se pretendiera examinar los datos después de obtener tres grupos de respuestas aproximadamente iguales. ¿Cuántas mujeres se deberían incluir en cada grupo?

Supóngase que cada uno de los tres grupos contiene m_0 mujeres en cada uno de los dos tratamientos. Utilizando la fórmula general y el plan con $N = 3$ de la tabla 15.6 podemos escribir θ para simbolizar la diferencia en los valores medios entre los dos grupos, y $\theta_1 = 0,3$. Después de n estadios ($n = 1, 2$ y 3), $\text{Var}(\hat{\theta}) = 2\sigma_0^2/m_0n$, y en consecuencia, $\delta_1 = \theta_1/\sqrt{2\sigma_0^2/m_0}$ con $\sigma_0^2 = (1,2)^2 = 1,44$. En la tabla 15.6 tenemos también que $\delta_1 = 2,22$. Así pues,

$$2,22 = 0,3 \sqrt{\left[\frac{m_0}{2(1,44)} \right]}$$

y

$$m_0 = \frac{2(1,44)(2,22)^2}{(0,3)^2} = 157,7 \text{ es decir, } 160.$$

Estas conclusiones ilustran la necesidad de realizar ensayos extensos en el estudio de enfermedades con baja incidencia de sucesos críticos, en las que sólo conseguiremos reducciones moderadas en la tasa de sucesos, pero incluso mejoras modestas de este tipo podrían ser de suma importancia.

15.5. Conclusiones

Es importante señalar que las reglas de cese secuenciales no deberían considerarse inviolables una vez que se han establecido. Existen dos razones principales para esta observación.

1. Las consideraciones que conducen a la elección de un plan secuencial en particular incluyen varias elecciones bastante arbitrarias. Después de realizar estas elecciones, pueden cambiar varias circunstancias relevantes: puede disminuir la tasa de entrada de pacientes al ensayo, puede ser razonable revisar los objetivos del ensayo que se lleva a cabo en función de trabajos recién publicados, etc. Por supuesto, sería incorrecto cambiar las reglas de cese acordadas simplemente porque los resultados son inesperados y, quizá, no deseados.
2. La decisión de detener un test por razones éticas debe depender de otros factores al margen del análisis secuencial. Será necesario considerar los efectos secundarios de los tratamientos, las diferencias entre los tratamientos en cuanto a la facilidad de administración y, quizás, en cuanto al coste, los datos procedentes de otras fuentes, la verosimilitud de los hallazgos aparentes en comparación con la posibilidad de que estén afectados por errores aleatorios, etc. El análisis secuencial debería, pues, contemplarse como una pauta en un aspecto de la decisión, que tiene en cuenta explícitamente el efecto de inspecciones repetidas de los datos, y no como el único determinante de la decisión.

Todos los planes descritos en este capítulo incluyen tests de significación repetida con algún nivel fijo de significación nominal. Se han propuesto y examinado muchas otras formas de la regla de cese; para mayores detalles deben consultarse publicaciones como la de Whitehead (1992) y Jennison y Turnbull (1990). En particular, los diseños secuenciales de grupos pueden construirse con niveles de significación nominal que varían de un estadio a otro. Por ejemplo, Peto et al. (1976) y O'Brien y Fleming (1979) han sugerido dos aproximaciones bastante distintas que tienen una menor probabilidad de conducir a un cese muy temprano que los planes TSR explicados. Se puede manifestar que, en consecuencia, son más apropiados para situaciones en las que *a priori* sólo se esperan pequeñas diferencias.

Cada uno de los métodos expuestos en el párrafo precedente exige que la regla de cese esté determinada previamente. Los esquemas difieren en la manera en que la probabilidad de un cese temprano (el nivel de significación global o probabilidad de error de tipo I, cuando la hipótesis nula se cumple) se distribuya a lo largo de los límites. Sin embargo, muchas veces resultará poco práctico o inadecuado fijar de antemano el número y las veces de inspecciones de los datos. Lan y DeMets (1983) han descrito un método mediante el cual la probabilidad determinada previamente de error de tipo I puede «gastarse» de una manera flexible, decidiéndose el esquema para la comodidad del equipo de control de datos, aunque independientemente de los resultados del ensayo clínico (v. también Kim y DeMets, 1992).

Un planteamiento bastante distinto (Lan et al, 1982, 1984) es el de la *abreviación estocástica*, mediante el cual un ensayo clínico se puede detener prematuramente si, en alguna fase, la conclusión que se hubiera extraído en el punto de terminación propuesto es ya bastante

clara. Esta propuesta suele postularse para situaciones en que los resultados provisionales de dos tratamientos, por ejemplo, son muy similares, y cuando puede predecirse que la diferencia final será casi con toda seguridad no significativa. Aunque este procedimiento puede ser de utilidad para permitir que los recursos de investigación se desvíen a direcciones más prometedoras, existe el peligro de atribuir una importancia excesiva a los resultados de un test de significación final. No obstante, los datos que demuestran unos efectos no significativos atribuidos al tratamiento pueden ser valiosos para cálculos, especialmente si contribuyen a metaanálisis. Puede ser poco juicioso terminar estos estudios prematuramente, en particular cuando no hay una diferencia entre tratamientos que proporcione una razón ética para la interrupción.

Los métodos descritos en este capítulo y los explicados en los párrafos anteriores se han desarrollado desde un punto de vista no bayesiano. Como se indicó en el apartado 15.1, en el método bayesiano la regla de cese no está relacionada con las inferencias que se obtendrán en algún estadio. Sería razonable interrumpir un ensayo clínico cada vez que la distribución *a posteriori* sugiriese un indicio fuerte de una ventaja clara de un tratamiento. Esta aproximación al diseño y análisis de ensayos clínicos ha sido muy defendida, por ejemplo por Berry (1987a, b) y Spiegelhalter y Freedman (1988). Hay algunos puntos en los que los dos métodos pueden interactuar. Por ejemplo, en la abreviación estocástica la predicción del resultado futuro puede efectuarse de manera útil mediante métodos bayesianos, como en el apartado 4.13 (Spiegelhalter et al, 1986; Armitage, 1988; Spiegelhalter y Freedman, 1988). Grossman et al. (1994) han explicado el diseño de ensayos clínicos secuenciales de grupos que conservan las probabilidades de error de tipo I aunque suponen límites determinados por una formulación bayesiana, en que la distribución *a priori* representa el escepticismo inicial acerca del posible efecto del tratamiento.

Finalmente, señalamos que en los ensayos clínicos puede resultar útil basar una regla de cese en tests de una diferencia no cero entre efectos de tratamientos (Meier, 1975; Freedman et al, 1984; v. también apartado 6.6). Todos los métodos secuenciales expuestos en este capítulo pueden adaptarse fácilmente basando los límites en los tests del valor no cero exigido.

Capítulo 16

Métodos estadísticos en epidemiología

16.1. Introducción

No existe una definición estándar de la rama de la ciencia médica denominada *epidemiología*. En términos generales, la epidemiología se ocupa de la distribución de las enfermedades o de un trastorno fisiológico y de los factores que influyen en tal distribución. Actualmente suele incluirse dentro de su ámbito el estudio de las enfermedades crónicas, así como las enfermedades transmisibles que originan las epidemias clásicas. En cierto sentido, el tema se solapa con la *medicina social*, la *medicina comunitaria* o la *salud pública*. Estos términos son, a su vez, difíciles de definir de manera precisa, pero generalmente se entiende que incluyen temas sociales y administrativos, como la organización de servicios sanitarios, que no pueden considerarse parte de la epidemiología.

Por definición, la epidemiología se ocupa de ciertas características de grupos de individuos más que de individuos particulares e, inevitablemente, origina problemas de carácter estadístico. Muchos de éstos son conceptualmente similares a los problemas estadísticos que se presentan en otras ramas de la ciencia médica, y por descontado en otras ciencias que nada tienen que ver con la medicina, y pueden enfocarse mediante los métodos de análisis descritos anteriormente en este libro; varios ejemplos citados en capítulos anteriores se han extraído de estudios epidemiológicos. Otros problemas metodológicos de la epidemiología, aunque de interés estadístico, están estrechamente relacionados con consideraciones no estadísticas y no pueden estudiarse aquí. Algunos ejemplos son la interpretación de datos estadísticos vitales y de salud, que requiere un conocimiento profundo de los procedimientos administrativos para el registro de este tipo de datos y para la clasificación de enfermedades y causas de muerte (Benjamin, 1968; Organización Mundial de la Salud, 1978) y el uso apropiado y el desarrollo potencial de varios tipos de registros médicos (Acheson, 1967). Existe también gran cantidad de estudios relacionados con la teoría matemática de las enfermedades epidémicas. Las monografías de Bailey (1975) y Becker (1989) nos ofrecen un resumen muy útil de este trabajo. Para referencias generales sobre métodos epidemiológicos el lector puede consultar a Alderson (1983), Elwood (1988), Hennekens et al (1987), Kelsey et al (1986), Kelinbaum et al (1982), Miettinen (1985) y Rothman (1986).

En este capítulo consideramos brevemente algunos problemas que surgen en la investigación epidemiológica, para los cuales se han desarrollado procedimientos estadísticos especiales.

Dado que la epidemiología se ocupa de la distribución de las enfermedades en poblaciones, se requieren unas medidas sumarias para la descripción del grado de enfermedad en una población. Hay dos medidas básicas: la incidencia y la prevalencia.

La *incidencia* es una medida de la proporción en que ocurren nuevos casos de enfermedad en una población previamente libre de ella. Así, la incidencia, que indicaremos por I , se define como:

$$I = \frac{\text{Número de casos nuevos en un período de tiempo}}{\text{Población de riesgo}}$$

El período se especifica en las unidades en las que se expresa la proporción. A menudo, el valor se multiplica por una base, como 1.000 o 1.000.000, para evitar pequeñas fracciones decimales. Por ejemplo, hubo 256 nuevos casos de cáncer de páncreas en varones en el sur de Australia en 1990 de una población de 2,903 millones de individuos. La incidencia fue de 256/2,903 por millón y por año.

La *prevalencia*, indicada por P , es una medida de la frecuencia de la enfermedad existente en un tiempo dado y se define como:

$$P = \frac{\text{Número total de casos en un tiempo dado}}{\text{Población total en ese momento}}$$

Tanto la incidencia como la prevalencia dependen en general de la edad y, posiblemente, del sexo, y deberían calcularse cifras específicas tanto para el sexo como para la edad.

Las tasas de incidencia y de prevalencia están relacionadas, ya que un caso incidente es, tan pronto como ocurre, un caso prevalente, y permanece como tal hasta la recuperación o la muerte (sin tener en cuenta la emigración y la inmigración). Suponiendo que la situación sea estable, la relación entre ambas medidas nos la da:

$$P = It \quad (16.1)$$

donde t es la duración media de la enfermedad. En enfermedades crónicas, en las cuales no hay recuperación, t sería la supervivencia media después de la aparición de la enfermedad.

16.2. Riesgo relativo

En el apartado 6.3 se estudiaron los métodos de cohortes y de casos-control para el estudio de la etiología de las enfermedades. En tales estudios es habitual hacer comparaciones entre grupos con diferentes características, en particular entre un grupo de individuos expuesto a algún factor y otro grupo no expuesto. Se requiere una medida del aumento del riesgo (si lo hay) de contraer una enfermedad en particular en el grupo expuesto con respecto al no expuesto. La medida que generalmente usamos es el cociente de las incidencias en los grupos comparados, al que denominamos *riesgo relativo* (ϕ). Así,

$$\phi = I_E / I_{NE} \quad (16.2)$$

donde I_E e I_{NE} son las tasas de incidencia en los expuestos y no expuestos, respectivamente. Esta medida también puede denominarse *cociente de riesgo*.

En un estudio de cohortes el riesgo relativo puede estimarse directamente, ya que las estimaciones pueden hacerse tanto para I_E como para I_{NE} . En un estudio de caso-control, el riesgo relativo no puede estimarse inmediatamente, ya que ni I_E ni I_{NE} pueden ser estimadas. Ahora consideraremos cómo hallar una solución útil a esta cuestión.

Supóngase que cada individuo de una población amplia se ha clasificado como positivo o negativo de acuerdo con algún factor potencialmente etiológico, y positivo o negativo de acuerdo a un estado de enfermedad. El factor podría basarse en una clasificación actual (por lo general, en un estudio retrospectivo) en los antecedentes del individuo. El estado de la enfermedad puede referirse a la presencia o la ausencia de cierta categoría de la enfermedad en un momento determinado o a cierto acontecimiento (como el diagnóstico o la muerte) durante un período establecido, es decir, a la *prevalencia* y la *incidencia*, respectivamente.

Para cualquier categorización de este tipo la población puede enumerarse en una tabla 2×2 como la que se muestra a continuación. Las entradas en la tabla son *proporciones* de la población total.

		Enfermedad		
		+	-	
Factor	+	P_1	P_3	$P_1 + P_3$
	-	P_2	P_4	$P_2 + P_4$
		$P_1 + P_2$	$P_3 + P_4$	1

(16.3)

Si se conocieran estas proporciones, la asociación (si la hubiese) entre el factor y la enfermedad podría medirse mediante el cociente de los riesgos de tener la enfermedad para los expuestos y para los no expuestos al factor.

$$\begin{aligned} \text{Cociente de riesgo} &= \frac{P_1}{(P_1 + P_3)} \div \frac{P_2}{(P_2 + P_4)} \\ &= \frac{P_1(P_2 + P_4)}{P_2(P_1 + P_3)} \end{aligned} \quad (16.4)$$

Cuando los casos son incidentes, el cociente de riesgo es el riesgo relativo.

Ahora bien, en muchas situaciones (aunque no en todas) en que se efectúan estudios etiológicos, la proporción de sujetos clasificados como positivos a una enfermedad será pequeña. Esto es, P_1 será pequeña en comparación con P_3 y P_2 lo será en comparación con P_4 . En tal caso, (16.4) será prácticamente igual a:

$$\frac{P_1 P_4}{P_2 P_3} (= \psi, \text{ por ejemplo}) \quad (16.5)$$

Al cociente (16.5) se lo denomina apropiadamente *razón de probabilidad* (ya que es el cociente de P_1/P_3 con P_2/P_4 , y estas dos cantidades pueden considerarse como probabilidad a favor de tener una enfermedad), pero a menudo nos referimos a ella como *riesgo relativo aproximado* (debido a la aproximación mencionada) o, simplemente, como *riesgo relativo*. Otro término es el *cociente cruzado* (ya que los dos productos $P_1 P_4$ y $P_2 P_3$ que aparecen en (16.5) se obtienen multiplicando en diagonal en la tabla).

La razón de probabilidad (16.5) podría estimarse a partir de una muestra aleatoria de la población o a partir de una muestra estratificada según los dos niveles del factor (como un

estudio prospectivo de cohortes empezado un tiempo antes de hacer las valoraciones de la enfermedad). Podría estimarse también a partir de una muestra estratificada en función de los dos estados de enfermedad (o sea a partir de un estudio de casos y controles), y es este hecho el que determina su utilidad como medida del riesgo relativo. Supóngase que se lleva a cabo un estudio de casos y controles mediante la selección de dos muestras aleatorias de individuos enfermos y no enfermos, y que las *frecuencias* (no proporciones) son las siguientes, usando la notación del apartado 4.8:

		Enfermedad		
		+	-	
		(casos)	(controles)	
Factor	+	a	c	$a + c$
	-	b	d	$b + d$
		$a + b$	$c + d$	n

(16.6)

Con frecuencia, desde luego, el plan de muestreo nos llevará a igual número de casos y de controles; entonces $a + b = c + d = (1/2)n$. Ahora bien, a/b puede considerarse una estimación razonable de P_1/P_2 , y c/d estima de modo similar P_3/P_4 . La razón de probabilidad observada:

$$\hat{\psi} = \frac{ad}{bc} \quad (16.7)$$

es el cociente entre a/b y c/d , y puede, por lo tanto, tomarse como una estimación de:

$$\frac{P_1}{P_2} \div \frac{P_3}{P_4} = \frac{P_1 P_4}{P_2 P_3} (= \psi)$$

la razón de probabilidad de la población o el riesgo relativo aproximado definido por (16.5).

En los estudios de casos y controles es difícil satisfacer el supuesto de que los grupos de casos y controles son muestras aleatorias a partir del mismo grupo de población pertinente. No obstante, las estimaciones del riesgo relativo derivadas de los estudios de casos y controles a menudo concuerdan bastante bien con las obtenidas en estudios corroborativos de cohorte, y la teoría parece ser útil como una guía aproximada. En los estudios retrospectivos los casos a menudo se aparean con individuos de control para diversos factores (el efecto de este apareamiento se estudia más adelante).

La ecuación (16.7) es idéntica a (4.18) y la mejor manera de considerar la variación de muestreo de una razón de probabilidad es en la escala logarítmica como en (4.19) de manera que, aproximadamente:

$$\text{Var}(\ln \hat{\psi}) = \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d} \quad (16.8)$$

Los límites aproximados, conocidos como *límites logit*, pueden obtenerse como en el ejemplo 4.12. Si alguna de las frecuencias de las casillas es pequeña, deben emplearse métodos más complejos, como los expuestos en el apartado 4.9. Aparte de los límites exactos

proporciones relativas en las filas de la tabla 2×2 , en las columnas o en las filas y columnas por igual. Un procedimiento, ilustrado más adelante en el ejemplo 16.2, consiste en tomar las distintas estimaciones de $\ln \psi$ y ponderarlas mediante la recíproca de la variancia de muestreo (16.8). Se pueden combinar entonces las estimaciones tomando una media ponderada y examinar su heterogeneidad mediante un índice del tipo χ^2 como (7.15) (Woolf, 1955). Este método falla cuando los subgrupos contienen pocos sujetos y resulta por tanto inapropiado con la estratificación creciente de un conjunto de datos. Aunque en estas circunstancias el método puede mejorarse sumando $1/2$ a cada una de las frecuencias observadas, es preferible usar un método alternativo de combinación atribuido a Mantel y Haenszel (1959). En muchas situaciones con este método se obtienen resultados similares a los conseguidos con el método de Woolf, pero el método de Mantel y Haenszel es más robusto cuando algunos de los estratos contienen frecuencias pequeñas; en concreto es posible usarlo incluso sin modificaciones cuando algunas de las frecuencias son cero. El método fue introducido en el apartado 12.6 como test de significación. Ahora damos más detalles desde el punto de vista de la estimación. Las frecuencias de la tabla 2×2 para la i -ésima subdivisión se nombran mediante la notación de (16.6) con el subíndice i . La estimación acumulada de Mantel-Haenszel de ψ es entonces:

$$R_{MH} = \frac{\sum (a_i d_i / n_i)}{\sum (b_i c_i / n_i)} \quad (16.12)$$

Mantel y Haenszel formularon un test de significación para la hipótesis de que $\psi = 1$. Si no hubiera asociación entre el factor y la enfermedad, el valor esperado y la variancia de a_i estarían dados, como en (12.7) (14.12), por:

$$E(a_i) = \frac{(a_i + b_i)(a_i + c_i)}{n_i}$$

$$\text{Var}(a_i) = \frac{(a_i + b_i)(c_i + d_i)(a_i + c_i)(b_i + d_i)}{n_i^2(n_i - 1)}$$

El test se calcula sumando las diferencias entre los valores observados y los esperados de a_i en los subgrupos. Dado que estos subgrupos son independientes, la variancia de la suma de las diferencias es igual a la suma de las variancias por separado. Ello nos da como test estadístico:

$$X_{MH}^2 = \frac{\left[\sum a_i - \sum E(a_i) \right]^2}{\sum \text{Var}(a_i)} \quad (16.13)$$

que es aproximadamente una $\chi^2_{(1)}$ (v. (12.19)). Si se desea, se puede incluir una corrección de la continuidad.

Actualmente se dispone de varias opciones para estimar la variancia de R_{MH} y, en consecuencia, para la construcción de los límites de confianza. En primer lugar, usando el método propuesto por Miettinen (1976), es posible establecer los límites de confianza basados en tests. Si se conociera el error tipo de $\ln R_{MH}$ entonces, de conformidad con la teoría normal, un test estadístico de la hipótesis $\psi = 1$ ($\ln \psi = 0$) sería:

		Controles		
		Factor +	Factor -	
Casos	Factor +	t	r	a
	Factor -	s	u	b
		c	d	$1/2n$

(16.16)

Los totales marginales de (16.16) son las frecuencias de las casillas de la tabla inicial (16.6). La estimación de Mantel-Haenszel es entonces:

$$R = \frac{r}{s} \quad (16.17)$$

Puede demostrarse que ésta es una estimación particularmente satisfactoria si el riesgo relativo verdadero, medido mediante la razón cruzada de las probabilidades (16.5), es el mismo para cada par. El test estadístico de Mantel-Haenszel es el mismo que el del test de McNemar (4.11).

Se hacen inferencias tratando la r como una variable binomial con un tamaño muestral de $r + s$. Se podrían aplicar entonces los métodos del apartado 4.7 y los límites de confianza del riesgo relativo, ψ_l y ψ_s , obtenidos a partir de los del parámetro binomial π mediante la relación:

$$\psi = \frac{\pi}{1 - \pi}$$

Liddell (1983) demostró que los límites dados por (4.10) simplifican después la transformación anterior, dando:

$$\left. \begin{aligned} \psi_l &= \frac{r}{(s+1)F_{0.025, 2(s+1), 2r}} \\ \psi_s &= \frac{(r+1)F_{0.025, 2(r+1), 2s}}{s} \end{aligned} \right\} \quad (16.18)$$

y que un test exacto de $\psi = 1$ está dado por:

$$F = \frac{r}{s+1} \quad (16.19)$$

examinada frente a la distribución F con $2(s+1)$ y $2r$ gl (en esta formulación si $r < s$, r y s podrían intercambiarse). Podemos usar dicho test exacto en lugar del aproximado de McNemar (apartado 4.8).

Un aspecto general es que el logaritmo de ψ es, a partir de (16.5):

$$\ln(P_1/P_3) - \ln(P_2/P_4) =$$

= logit (probabilidad de enfermedad cuando el factor es positivo) -
- logit (probabilidad de enfermedad cuando el factor es negativo)

Podemos considerar apropiados los métodos de análisis propuestos en este apartado si el efecto de cambiar del factor + al factor - representa cambiar la probabilidad de estar enfermo por una cifra constante en la *escala de logits*. En el apartado 12.8 se ha visto que éste es un enfoque general razonable para un amplio abanico de problemas, pero en algún ejemplo en concreto puede estar lejos de la realidad. El investigador debería, por lo tanto, prevenirse de suponer que un riesgo relativo calculado en un estudio sea necesariamente aplicable en circunstancias algo distintas.

El ejemplo 16.2 aplica los métodos anteriores para combinar varios estudios en un análisis resumido. Se puede considerar un ejemplo simple de metaanálisis (apartado 7.2).

Ejemplo 16.2

La tabla 16.1 resume los resultados de 10 estudios retrospectivos en los que se clasificó a pacientes con cáncer de pulmón y sujetos-control en fumadores y no fumadores. En la mayoría o en todos los estudios los casos y los controles hubieran sido apareados, pero los datos originales generalmente no se presentaban con suficiente detalle para poder estimar el riesgo relativo a partir de (16.17) y no se utiliza el apareamiento en este análisis. (El efecto de ignorar el apareamiento cuando está presente es que, si acaso, infraestimaremos la desviación del riesgo relativo con respecto a la unidad). Los datos fueron recopilados por Cornfield (1956) y utilizados también por Gart (1962).

Definiendo w_i como la recíproca de la $\text{Var}(\ln \hat{\psi}_i)$ a partir de (16.8), la media ponderada resulta ser:

$$\frac{\sum w_i \ln \hat{\psi}_i}{\sum w_i} = \frac{161,36}{105,4} = 1,531$$

y la estimación agrupada de ψ es $\exp(1,531) = 4,62$.

Para el test de heterogeneidad, el estadístico $\chi^2_{(9)}$ es:

$$\sum w_i (\ln \hat{\psi}_i)^2 - \frac{(\sum w_i \ln \hat{\psi}_i)^2}{\sum w_i} = 253,678 - 247,061 = 6,62 \quad (P = 0,68)$$

Está claro que no hay fuertes indicios de heterogeneidad entre estimaciones separadas. Parece, desde luego, que el riesgo relativo varía hasta cierto punto de un estudio a otro, especialmente debido a que el factor «fumador» tiene un abanico de actividad muy amplio. Sin embargo, la variación muestral de las distintas estimaciones es obviamente demasiado amplia para que aparezca tal variación real. Si suponemos que toda la variación se debe al error de muestreo, la variancia de la media ponderada de $\ln \hat{\psi}_i$ puede obtenerse como:

$$\frac{1}{\sum w_i} = 0,00949$$

Los límites de confianza del 95% aproximados de $\ln \psi$ son:

$$1,531 \pm (1,96) \sqrt{0,00949} = 1,340 \text{ y } 1,722$$

Los límites correspondientes de ψ se obtienen mediante exponenciales, como 3,82 y 5,60.

Tabla 16.1. Combinación de los riesgos relativos de 10 estudios retrospectivos sobre el hábito de fumar y el cáncer de pulmón (Cornfield, 1956; Gart, 1962).

Número de estudio	Pacientes con cáncer de pulmón				Pacientes de control				Método de Woolf					Método de Mantel-Haenszel			
	Fuma- dores	No fuma- dores	Fuma- dores	No fuma- dores	Fuma- dores	No fuma- dores	Fuma- dores	No fuma- dores									
	a_i	b_i	c_i	d_i	a_i	b_i	c_i	d_i						a_i/n_i	b_i/n_i	$E(a_i)$	$Var(a_i)$
					$\hat{\psi}_i$	$\ln \hat{\psi}_i$	$1/d_i$	$1/a_i + 1/b_i + 1/c_i + 1/d_i$	$w_i = 1/(1)$	$w_i \ln \hat{\psi}_i$	n_i	$a_i d_i/n_i$	$b_i c_i/n_i$	$E(a_i)$			
1	83	3	72	14	5.38	1.683	0.4307	2.3	2.3	3.87	172	6.756	1.256	77.50		3.85	
2	90	3	227	43	5.68	1.737	0.3721	2.7	2.7	4.69	363	10.661	1.876	81.21		7.68	
3	129	7	81	19	4.32	1.463	0.2156	4.6	4.6	6.73	236	10.386	2.403	121.02		5.67	
4	412	32	299	131	5.64	1.730	0.0447	22.4	22.4	38.75	874	61.753	10.947	361.19		33.18	
5	1,350	7	1,296	61	9.08	2.206	0.1608	6.2	6.2	13.68	2,714	30.343	3.343	1,323.00		16.58	
6	60	3	106	27	5.09	1.627	0.3965	2.5	2.5	4.07	196	8.265	1.622	53.36		5.57	
7	459	18	534	81	3.87	1.353	0.0720	13.9	13.9	18.81	1,092	34.047	8.802	433.76		22.17	
8	499	19	462	56	3.18	1.157	0.0747	13.4	13.4	15.50	1,036	26.973	8.473	480.50		17.41	
9	451	39	1,729	636	4.25	1.447	0.0300	33.3	33.3	48.19	2,855	100.468	23.619	374.15		73.30	
10	260	5	259	28	5.62	1.726	0.2434	4.1	4.1	70.08	522	13.188	2.346	249.16		7.76	
Total	3,793	136	5,065	1,096				105.4	105.4	161.37		302,840	64,687	3,554.85		193.17	

En el apartado 14.6 se observó que el test del rango (*logrank*) para analizar los datos de supervivencia era similar al test de Mantel-Haenszel. La comparación entre (16.20) y (14.22) demuestra que el método de regresión logística en un estudio de caso-control apareado es similar al modelo de riesgos proporcionales para el análisis de supervivencia. Puede considerarse un estudio de caso-control como una muestra de un hipotético estudio de cohorte; de hecho, para que fuera válido debería ser sólo eso. No hay, por lo tanto, coincidencia en que los métodos derivados originalmente para el análisis de los estudios de cohorte puedan también aplicarse a los estudios caso-control.

Un análisis basado en (16.20) puede llevarse a cabo usando la instrucción PROC PHREG del programa SAS, en que cada conjunto de caso-control define un estrato.

16.3. Riesgo atribuible

Todas las implicaciones de un exceso de riesgo dependen no sólo del valor del riesgo relativo sino también de la proporción de población positiva con respecto a un factor etiológico. Un riesgo relativo moderado aplicable a una alta proporción de la población produciría más casos de enfermedad que un riesgo relativo alto aplicable sólo a una pequeña proporción de la población. El *riesgo atribuible* es una medida de asociación, debida a Levin (1953), que da cuenta de la proporción de la población en riesgo. La terminología no está completamente estandarizada y existen otros nombres para designar esta medida, como *fracción etiológica*, *riesgo atribuible poblacional* y *fracción atribuible*. El riesgo atribuible se define como la proporción de casos en la población total que pueden atribuirse al factor de riesgo. Generalmente se calcula en circunstancias en que se considera justificable inferir causalidad a partir de una asociación observada. Entonces puede interpretarse como la proporción de casos en la población que son debidos al factor y, por lo tanto, como una medida de la importancia de eliminar el factor como parte de una estrategia de prevención de la enfermedad.

Supóngase que I_p es la incidencia de una enfermedad en la población y, como antes, I_E e I_{NE} son las incidencias de los expuestos y de los no expuestos, respectivamente. Entonces, el exceso de incidencia atribuible al factor es $I_p - I_{NE}$ y, dividiéndolo por la incidencia en la población, obtenemos el riesgo atribuible:

$$\lambda = \frac{I_p - I_{NE}}{I_p} \quad (16.21)$$

Ahora supóngase que una proporción θ_E de la población está expuesta al factor. Entonces,

$$\begin{aligned} I_p &= \theta_E I_E + (1 - \theta_E) I_{NE} \\ &= \theta_E \phi I_{NE} + (1 - \theta_E) I_{NE} \\ &= I_{NE} [1 + \theta_E (\phi - 1)] \end{aligned} \quad (16.22)$$

donde ϕ es el riesgo relativo, y la segunda línea se obtiene a partir de (16.2). Sustituyendo en (16.21) obtenemos:

$$\lambda = \frac{\theta_E (\phi - 1)}{1 + \theta_E (\phi - 1)} \quad (16.23)$$

La formulación anterior se ha realizado en términos de un factor que incrementa el riesgo, es decir, un riesgo relativo mayor que la unidad. Para un factor que sea protector, es decir con un riesgo relativo inferior a la unidad, debe hacerse una formulación ligeramente distinta; Kleinbaum et al (1982, cap. 9) abordan este punto.

Concluimos este apartado considerando la variación de muestreo de una estimación del riesgo atribuible poblacional a partir de un estudio de caso-control y un ejemplo.

Considérense los datos de la fórmula (16.6) en un estudio de caso-control. Dado que $a/(a+b)$ estima $P_1/(P_1+P_2)$ o θ_1 , y ad/bc estima ψ , el cual es aproximadamente ϕ , una sustitución en (16.24) nos da como estimación de λ :

$$\begin{aligned}\hat{\lambda} &= \frac{a}{a+b} \left(1 - \frac{bc}{ad}\right) \\ &= \frac{ad-bc}{d(a+b)}\end{aligned}\quad (16.25)$$

Conviene trabajar con $\ln(1-\hat{\lambda})$ ya que, como demostró Walter (1975), esta variable se distribuye aproximadamente de modo normal.

$$\begin{aligned}1 - \hat{\lambda} &= \frac{bd+bc}{d(a+b)} \\ &= \frac{b}{a+b} \bigg/ \frac{d}{c+d} \\ &= \frac{1 - \hat{\theta}_1}{1 - \hat{\theta}_2}\end{aligned}$$

y

$$\ln(1 - \hat{\lambda}) = \ln(1 - \hat{\theta}_1) - \ln(1 - \hat{\theta}_2)$$

donde $\hat{\theta}_1$ es un estimador de $P_1/(P_1+P_2)$ y $\hat{\theta}_2$ de $P_3/(P_3+P_4)$. $\hat{\theta}_1$ y $\hat{\theta}_2$ son estimadores independientes de proporciones; entonces, utilizando (3.4) y (3.17) obtenemos:

$$\text{Var}[\ln(1 - \hat{\lambda})] = \frac{a}{b(a+b)} + \frac{c}{d(c+d)} \quad (16.26)$$

Ejemplo 16.3

Considérense los datos del estudio 1 de la tabla 16.1, en la que 83 de 86 pacientes con cáncer de pulmón eran fumadores, en comparación con 72 de 86 de los controles. Entonces, usando (16.25) y (16.26),

$$\begin{aligned}\hat{\lambda} &= \frac{83 \times 14 - 3 \times 72}{14 \times 86} \\ &= 0,7857 \\ \ln(1 - \hat{\lambda}) &= -1,540 \\ \text{Var}[\ln(1 - \hat{\lambda})] &= \frac{83}{3 \times 86} + \frac{72}{14 \times 86} \\ &= 0,3815\end{aligned}$$

Así pues, los límites del 95% de $\ln(1 - \hat{\lambda})$ son aproximadamente:

$$\begin{aligned} & -1,540 \pm (1,96) \sqrt{0,3815} \\ & = -2,751 \text{ y } -0,329 \end{aligned}$$

Los límites correspondientes de $\hat{\lambda}$ son 0,281 y 0,936.

Whittemore (1983) amplió la medida de Levin para cubrir los casos de variables de confusión. Cuando éstas se tienen en cuenta mediante un análisis estratificado, el riesgo relativo se calcula, muchas veces, usando el método de Mantel-Haenszel, que puede emplearse para calcular el riesgo atribuible mediante (16.24). Kuritz y Landis (1988) aplicaron este método en un estudio de caso-control emparejado y propusieron un método para calcular el intervalo de confianza. Greenland (1987) estableció estimadores de la variancia para el riesgo atribuible basados en la variabilidad de muestreo de R_{MH} (16.15); dichos estimadores son satisfactorios tanto para estratos grandes como para datos escasos, o sea, datos divididos en un gran número de estratos con pequeñas cantidades en cada estrato.

16.4. Tests diagnósticos y procedimientos de cribado

En los estudios epidemiológicos se usan ampliamente los test diagnósticos, basados ya sea en observaciones clínicas o bien en técnicas de laboratorio, mediante las cuales los individuos son clasificados como sanos o como pertenecientes a una categoría de enfermedad entre varias. Dichos tests son, desde luego, importantes en toda la medicina y en particular forman la base de programas de cribado para el diagnóstico precoz de enfermedades. La mayoría de los tests son instrumentos imperfectos, en el sentido de que individuos sanos pueden ser clasificados erróneamente como enfermos, e individuos enfermos pueden no ser detectados. ¿Cómo deberíamos valorar la capacidad de un test diagnóstico en concreto para establecer el diagnóstico correcto tanto en individuos sanos como enfermos?

Fiabilidad de los tests diagnósticos

Supóngase que cada individuo en una población grande puede clasificarse como verdaderamente positivo o negativo para un diagnóstico en particular. Este diagnóstico cierto podría basarse en métodos más refinados que los usados en el test o en la aparición de una evidencia con el tiempo, por ejemplo en la autopsia. Para cada clase de individuos, verdaderos positivos o verdaderos negativos, podemos considerar las probabilidades de que el test dé un veredicto positivo o negativo, como en la tabla siguiente.

			Test		Total
	+	-	+	-	
Verdadero	+	$1 - \beta$	β		1
	-	α	$1 - \alpha$		1

(16.27)

Un individuo situado en la esquina superior derecha de esta tabla 2×2 se denomina *falso negativo*; β es la probabilidad de un falso negativo, y $1 - \beta$ es lo que se denomina *sensibilidad* del test. Los individuos situados en la esquina inferior izquierda se designan *falsos positivos*; α es la probabilidad de un falso positivo, y $1 - \alpha$ es la *especificidad* del test. Aquí hay una analogía con los tests de significación. Si la hipótesis nula es que un individuo es un verdadero negativo, y un resultado positivo del test se considera «significativo», así pues, α es análoga al nivel de significación, y $1 - \beta$ análogo al poder de detectar la hipótesis alternativa de que un individuo sea un verdadero positivo (p. 185).

Está claro que es deseable que un test tenga valores de α y β pequeños, si bien son muy pertinentes otras consideraciones, como el coste y la facilidad de aplicación. A igualdad de condiciones, si el test A tiene valores menores de α y β que un test B, entonces aquél puede considerarse como mejor. Supóngase, no obstante, que el test A tiene un valor menor de α pero mayor de β . A menos que pueda asociarse algún peso relativo a los dos tipos de error —falsos negativos y falsos positivos—, no puede emitirse un juicio claro. Si consideramos que los dos errores tienen aproximadamente la misma importancia, un método natural de combinación es la suma de las dos probabilidades de error, $\alpha + \beta$. Youden (1950) propuso un índice esencialmente equivalente.

$$J = 1 - (\alpha + \beta) \quad (16.28)$$

Si el test no tiene valor diagnóstico, $\alpha = 1 - \beta$ y $J = 0$. Si el test es invariablemente correcto, $\alpha = \beta = 0$ y $J = 1$. Valores de J entre -1 y 0 aparecerán si el resultado del test estuviera negativamente asociado al diagnóstico correcto, pero en la práctica esto no suele suceder.

El uso del índice de Youden supone implícitamente que la especificidad y la sensibilidad tienen igual importancia, ya que a α y a β se les da igual peso en (16.28). Puede haber importantes razones en contra de este punto de vista. En primer lugar, los dos tipos de error tendrán consecuencias muy distintas, y a menudo será razonable dar mayor peso a un falso negativo que a un falso positivo; esta consideración sugiere dar mayor peso a β que a α , y nos llevaría a elegir un procedimiento con un valor β/α relativamente pequeño. Por otro lado, si la enfermedad es poco frecuente, los falsos negativos serán pocos, y el número de individuos diagnosticados erróneamente podría reducirse al mínimo eligiendo $\beta > \alpha$. Estas dos consideraciones entran claramente en conflicto. Debemos buscar una solución en vista de las consecuencias de los errores diagnósticos en la enfermedad en cuestión.

Hasta aquí el tema se ha tratado en términos de probabilidades. En la práctica éstas podrían estimarse a partir de estudios. Supóngase que un estudio especial de una muestra aleatoria de la población dio las siguientes frecuencias:

		Test	
		+	-
Verdadero	+	a	b
	-	c	d

(16.29)

La probabilidad de un falso negativo será estimada por $\hat{\beta} = b/(a + b)$, y la probabilidad de un falso positivo mediante $\hat{\alpha} = c/(c + d)$. El índice de Youden, J , podría estimarse mediante $\hat{J} =$

$1 - (\hat{\alpha} + \hat{\beta})$. Los errores de muestreo de estas estimaciones se derivan de expresiones binomiales estándar.

Un aspecto importante que debía destacarse es que las proporciones esperadas de diagnósticos erróneos entre los *aparentemente* positivos y negativos dependen no sólo de α y de β , sino también de la prevalencia real de la enfermedad. Podemos comprobarlo a partir de los dos grupos de frecuencias siguientes. En cada caso tanto la especificidad como la sensibilidad es 0,9.

Caso a

	Test		
	+	-	
Verdadero	+	450 50	500
	-	50 450	500
	500	500	1.000

Proporción

de verdaderos + 0,90 0,10

Caso b

	Test		
	+	-	
Verdadero	+	90 10	100
	-	90 810	900
	180	820	1.000

(16.30)

0,50 0,01

La proporción de verdaderos positivos entre los aparentemente positivos se denomina a veces *valor predictivo de un resultado positivo*; la proporción de verdaderos negativos entre los aparentemente negativos es el *valor predictivo de un resultado negativo*. En el caso a, la prevalencia de verdaderos es $500/1.000 = 0,5$; el valor predictivo de un resultado positivo es alto (0,9). En el caso b; sin embargo, donde la prevalencia de verdaderos es $100/1.000 = 0,1$, el mismo valor predictivo es sólo 0,5. Los valores predictivos son probabilidades condicionales de los resultados del test y pueden calcularse mediante el teorema de Bayes (apartado 2.8) con las prevalencias de enfermedad y no enfermedad como probabilidades previas, y las verosimilitudes de los resultados de test obtenidos a partir de la sensibilidad y la especificidad.

El caso b ilustra la situación en muchos procedimientos de cribado presintomático en los que la prevalencia de verdaderos es baja. De los individuos encontrados positivos mediante el test de cribado, una proporción bastante alta de ellos podrían ser falsos positivos. Para evitar esta situación puede modificarse algunas veces el test para disminuir la α , pero esto a menudo dará como resultado un valor incrementado de β y, como consecuencia, un valor menor de $1 - \beta$; el número de falsos positivos entre los aparentemente positivos habrá disminuido, pero a costa de la reducción en el número de verdaderos positivos detectados.

El tipo de modificación al que nos hemos referido en la última frase es particularmente adecuado cuando el test, a pesar de ser dicotómico, se basa en una medición continua. Algunos ejemplos son el diagnóstico de diabetes por el nivel de glucemia o el de glaucoma por la presión intraocular. Cualquier cambio en el nivel crítico de la medición afectará a α y β . Un modelo muy simple para esta situación sería suponer que la variable, x , en la que se basa el test, se distribuye normalmente con la misma variancia σ^2 para las poblaciones normal y enferma, pero con distintas medias, μ_N y μ_E (fig. 16.1). Para cualquier α dada, el valor de β depende únicamente de la distancia estandarizada entre las medias,

$$\Delta = \frac{\mu_E - \mu_N}{\sigma}$$

Si el valor crítico del test es el punto medio entre las medias, $(1/2)(\mu_N + \mu_E)$, tanto α como β serán iguales al área de una única cola de la distribución normal más allá de una desviación estandarizada de $(1/2)\Delta$. Por lo tanto, para comparar los méritos de distintos tests podrían compararse sus valores de Δ ; los tests con valores de Δ altos diferenciarán mejor entre los grupos normal y enfermo que los tests con valores bajos. Aquí hay una clara analogía con la distancia generalizada como medida de la eficacia de una función discriminante (p. 341); la discriminación se hace en este caso por la variable única x .

En lugar de una clasificación de todo o nada, como sanos o enfermos, en ocasiones resulta útil expresar la fuerza de la evidencia de que un individuo corresponda a uno de los dos grupos. Para el modelo descrito anteriormente, el logaritmo del cociente de verosimilitud está linealmente relacionado con x , como puede verse en la parte inferior de la figura 16.1. (Éste es un caso particular del resultado más general para las funciones discriminativas, al que nos hemos referido en la p. 341.) El cociente de verosimilitud podría, según el teorema de Bayes (apartado 2.8), combinarse con el cociente de probabilidades previas para dar el cociente de probabilidades posteriores. Supóngase, por ejemplo, que un valor concreto de x correspondiera a un cociente de verosimilitud de 10 y que la probabilidad previa de un individuo en-




Fig. 16.1. Realización de un test diagnóstico basado en una variable distribuida normalmente cuando los grupos normal y enfermo difieren en la media pero presentan igual variancia. La figura inferior muestra, sobre la escala logarítmica, el cociente de la verosimilitud de que una observación provenga de un grupo enfermo frente a la que provenga de un grupo normal.

fermo (o sea la prevalencia en la población) fuera 0,01. La probabilidad posterior de que el individuo esté enfermo es entonces:

$$\frac{10}{1} \times \frac{0,01}{0,99} = 0,10 \text{ a } 1.$$

Es, pues, más probable que el individuo esté sano que enfermo; como en el caso *b* de (16.30), donde la prevalencia era baja, una alta proporción de aparentemente positivos son, en realidad, falsos positivos.

Es improbable que los supuestos subyacentes al análisis anterior se cumplan fielmente en la práctica. Es posible que las distribuciones no sean normales y tengan variancias distintas; pueden existir diversas categorías de enfermedad, cada una de ellas con una distribución distinta de x . Sin embargo, los conceptos que aquí hemos presentado generalmente ofrecen unas buenas bases para argumentar la realización de un test diagnóstico. Para una exposición más extensa, véanse Greenhouse y Mantel (1950).

Otra manera de expresar la situación mostrada en la figura 16.1 es la *curva característica operativa receptor* (COR). Se trata de un diagrama lineal con la sensibilidad, $1 - \beta$, trazada verticalmente y la tasa de falsos positivos, α , en el eje horizontal. También puede mostrarse mediante una escala inversa de la especificidad, $1 - \alpha$. La curva COR se construye encontrando la especificidad y la sensibilidad para una gama de valores de x . La figura 16.2 muestra una curva COR correspondiente a la figura 16.1. Las combinaciones posibles de sensibilidad y especificidad que se pueden elegir variando los valores críticos del test se interpretan a partir de la curva. Los tests con las curvas COR más alejadas hacia la esquina superior izquierda son los mejores tests.

Los errores de una clasificación incorrecta no se limitan a la clasificación por enfermedad. En un estudio retrospectivo de caso-control, por ejemplo, la clasificación por enfermedad debería basarse, al parecer, en métodos de diagnóstico muy precisos, pero la clasificación por factores a menudo depende de la recogida de datos y, por lo tanto, no será muy precisa.




Fig. 16.2. Curva característica operativa receptor (COR) correspondiente a la figura 16.1.




Fig. 16.3. Representación esquemática de los acontecimientos en el desarrollo de una enfermedad crónica, con un procedimiento de cribado durante la fase asintomática.

La estimación del tiempo de ventaja es algo compleja (Walter y Day, 1983; Day y Walter, 1984). Deberían tenerse en cuenta los siguientes puntos para la situación en que se tiene un cribado simple:

1. El tiempo de ventaja es una variable aleatoria, en parte porque y varía según los individuos, pero también porque t puede ocurrir en cualquier punto entre T_2 y T_3 (o incluso fuera de este intervalo, en cuyo caso la enfermedad no será detectada por el cribado). Si y fuese constante, el tiempo de ventaja medio, L , para aquellos individuos cuya enfermedad se hubiese detectado por el cribado sería $1/2m$. Sin embargo, puesto que y varía, los tiempos de latencia largos tienen mayor probabilidad de contener un punto de cribado y están más representados en el grupo de «detectados» que en el conjunto total de casos. (Éste es un ejemplo de «muestreo con sesgo de longitud».) Una consecuencia es que $L = 1/2 [m + (\sigma^2/m)]$, donde σ^2 es la variancia de y .
2. Podríamos estar interesados en el tiempo guía medio para el conjunto total de casos, que incluiría a aquellos en los que no se ha detectado la enfermedad. Lo denominamos tiempo de guía del programa y es igual a $(1 - \beta)L$, donde β es la proporción de falsos negativos (es decir, casos equivocados).
3. Para estimar m , puede usarse la relación (16.1),

$$P = Im \quad (16.31)$$

donde P es la prevalencia de la enfermedad presintomática (la cual puede estimarse a partir de los resultados del cribado teniendo en cuenta los falsos negativos) e I es la incidencia de enfermedad sintomática (que se podría estimar a partir de una serie de control).

4. La estimación de σ^2 , necesaria para el cálculo de L , es más problemática que la de m , y podría requerir algún supuesto más sobre la forma funcional de la distribución de y .

La exposición hasta aquí se ha hecho en términos de una única ocasión de cribado. En la práctica será preferible considerar una serie de ocasiones de cribado, de modo que cada individuo que presente la enfermedad en un momento dado, tenga la oportunidad de someterse a cribado mientras la enfermedad sea presintomática (v. Walter y Day, 1983; Day y Walter, 1984).

16.5. Aglomeración de enfermedades

Muchos estudios epidemiológicos se ocupan de la detección de algún tipo de aglomeración de los casos de cierta enfermedad (aglomeración en el tiempo, en el espacio o en ambos). Por ejemplo, se puede investigar si los casos de una malformación congénita determinada (los cuales podrían producirse según una tasa bastante constante en una comunidad) aparecen con una frecuencia anormalmente alta en unos años determinados. Tal tendencia a la aglomeración en el tiempo podría indicar algunos factores etiológicos, como infecciones víricas maternas, que fueron particularmente graves en determinados años. De nuevo, es posible sospechar que ciertas formas de enfermedad son más frecuentes en personas que viven o trabajan en áreas determinadas, tal vez debido a factores ambientales característicos de esos lugares. Los grupos resultantes de esta aglomeración pueden ser familias o comunidades; esta agregación familiar puede deberse también a factores ambientales, pero asimismo podría estar causada por infecciones intrafamiliares o una predisposición genética a la enfermedad. En los estudios sobre la posible etiología infecciosa de enfermedades raras, como la leucemia o ciertas malformaciones congénitas, la aglomeración en el espacio o en el tiempo será menos interesante que una asociación espacio-tiempo a la vez. Con este término nos referimos a una tendencia, para los casos que están relativamente cercanos en el espacio, a estar también relativamente cercanos en el tiempo.

La mayoría de estos problemas originan consideraciones complicadas, que no podrán tratarse de lleno aquí. Este apartado contiene una breve referencia de algunas de esas consideraciones. Para obtener más detalles puede consultarse la bibliografía.

Debería hacerse una advertencia general contra la sobreinterpretación como sorprendentes de determinadas aglomeraciones. A menudo, los estudios epidemiológicos se efectúan después de haber advertido algunas coincidencias atípicas. El grado de aglomeración puede ser «significativo» cuando se considera en forma aislada, pero podría ser no obstante un fenómeno puramente debido al azar. Se podrían haber puesto a examen muchas otras posibles ocasiones de aglomeración, en otros lugares o en otros períodos; si se hubieran estudiado, tal vez no se habría encontrado nada destacable con excepción del caso original que motivó la investigación. Por lo tanto, nuestra atención podría dirigirse sólo a la más extrema de un gran número de fluctuaciones aleatorias. De modo parecido, en cualquier estudio hay a menudo muchas maneras de analizar los datos para posibles aglomeraciones. Dar cuenta únicamente del método de análisis que proporciona el hallazgo más significativo es ofrecer una interpretación engañosa de la situación real. El problema se asemeja al de las comparaciones múltiples (apartado 7.4), pero en el contexto actual el número de comparaciones posibles parece ser tan grande y tan difícil de definir que no se dispone de un método satisfactorio de ajuste.

Aglomeraciones en función del tiempo

Un enfoque bastante sencillo para muchos problemas de este tipo es dividir el tiempo en intervalos iguales, expresar la tasa de incidencia en cada intervalo en forma de proporción y evaluar la significación de las diferencias entre esas proporciones por un método estándar de tablas de contingencia $2 \times k$. Si la población de riesgo es prácticamente constante y la tasa de incidencia es baja, el número de casos presentes en los distintos intervalos seguirá, según la

hipótesis nula de riesgo constante, una distribución de Poisson; puede usarse el test habitual de heterogeneidad (apartado 7.8). En el apartado 10.3 se describe un test realizado por Edwards (1961), especialmente sensible para la aglomeración estacional de casos.

Sería lógico centrar la atención en el máximo de los diversos números de casos, desde el punto de vista de que la aglomeración esporádica podría producirse en sólo uno o dos intervalos de tiempo. Ederer et al (1964) describen algunos métodos con este fin.

Aglomeraciones geográficas

Es posible aplicar métodos bastante parecidos para detectar aglomeraciones geográficas que pueden resultar en diferencias de incidencia entre distintos grupos de personas. Por lo general será útil subdividir la población total en áreas administrativas que contendrán distintas cantidades de individuos; en este caso no puede aplicarse la distribución de Poisson, pero sí los métodos de tablas de contingencia.

Si no se conoce la distribución geográfica de la población, puede ser útil realizar un estudio de caso-control para demostrar si los casos están más cercanos entre sí en algún sentido que un grupo comparable de controles. Lloyd y Roberts (1973), por ejemplo, aplicaron este método para el estudio de la aglomeración geográfica de malformaciones congénitas de los miembros, en Cardiff. La distribución de las diferencias entre todos los pares de casos puede compararse con la de las distancias entre los pares de controles, para observar si se producen distancias pequeñas con mayor frecuencia en los casos que en los controles. Supóngase que hay n casos y m controles. Mediante un ordenador se podría realizar un *test de permutación*, haciendo selecciones aleatorias repetidas de n individuos a partir del total de $m + n$, y contando el número de pares cercanos, Z , dentro de cada conjunto de n . Viendo si cae en las colas de la distribución de Z formadas por las permutaciones aleatorias, podemos juzgar la significación del valor *observado* de Z . Alternativamente, los valores de $E(Z)$ y $Var(Z)$ en la distribución de la permutación pueden calcularse mediante una adaptación de una fórmula exacta derivada del test de Knox para la aglomeración espacio-tiempo descrita en la página 504 (David y Barton, 1966; Mantel, 1967; Smith y Pike, 1974). Cuzick y Edwards (1990) propusieron un test basado en la distribución geográfica de casos y controles. Para cada caso se encuentran los k vecinos más próximos, y el número de éstos que son casos forma la base de un test. Se lleva a cabo con diferentes valores de k y los resultados se combinan en un test global.

En ocasiones surge la pregunta de si los casos de una enfermedad en concreto que suceden en un tiempo determinado tienden a agruparse cerca de una localización bien definida, como una planta industrial sospechosa de estar emitiendo material tóxico. Aquí la población podría subdividirse en subgrupos de acuerdo con la distancia al foco y realizarse un test para determinar si la incidencia de la enfermedad es especialmente alta en el subgrupo más cercano al foco o, tal vez, si disminuye con la distancia. Si se desconoce la distribución geográfica de la población, un estudio de caso-control puede aclarar si es más probable que los casos de cierta región estén cerca del foco que un grupo comparable de controles.

Gardner (1989) consideró los problemas que implicaba establecer si había una asociación de los cánceres infantiles con la proximidad a las instalaciones nucleares.

combinan en un test estadístico que es sensible a la aglomeración geográfica. Se produce un test de la aglomeración en el tiempo de manera similar, y el test de aglomeración en el espacio y el tiempo se basa en promedios ponderados de los términos de interacción, tomando como ponderaciones el producto de las ponderaciones para espacio y tiempo. El método se aplicó a los 329 casos de enfermedad de Creutzfeldt-Jakob identificados en Francia durante el período 1968-1982, definiendo el espacio en términos de 94 departamentos.

Aglomeraciones en familia

La aglomeración de la enfermedad en familias puede deberse a un agente infeccioso o a una causa genética. Éstas son las causas principales que justifican un estudio de agregación familiar, pero éste a menudo puede complicarse por otras causas. Los miembros de una misma familia o casa familiar comparten el mismo entorno natural y las mismas condiciones sociales, todo lo cual puede afectar la incidencia de una enfermedad determinada. La edad es una complicación adicional, en especial en estudios de hermanos, ya que éstos tienden a tener edades más similares que los miembros de distintas generaciones.

Si prescindimos de estas complicaciones, la evaluación de la heterogeneidad de la incidencia de una enfermedad entre familias parece un problema similar al de evaluar la heterogeneidad entre cualesquiera otros grupos de individuos. Sin embargo, hay un problema especial de *determinación*. Los datos familiares pueden recogerse de varios modos distintos, como indicamos más adelante. Debemos advertir al lector que la nomenclatura, en particular los términos «selección» y «comprobación», están lejos de ser estándar.

1. *Comprobación a través de las familias.* Aquí la familia se selecciona como una unidad, ya sea de un marco muestral de familias (tal vez identificadas por sus padres) o bien por la inclusión de todas las familias de una región.
2. *Comprobación a través de los casos.* En este método las familias se obtienen a través de los individuos afectados. (Es un método natural si se desea estimar la proporción de individuos afectados entre los parientes cercanos de los individuos afectados. A los casos originales se los denomina «probandos» o «propósitos».) Una consecuencia inmediata es que no se incluyen las familias en las cuales ningún individuo está afectado; por lo tanto, la frecuencia de éstos no se observa directamente. Hay tres subdivisiones importantes de la comprobación a través de los casos:
 - a) *Comprobación completa*, en la cual todos los individuos afectados son probandos, y las familias con más de un probando se cuentan sólo una vez, o cuando se obtienen a partir de un registro de probandos en el cual cada familia puede aparecer sólo una vez (p. ej., a partir del registro de nacimientos en un período de 6 meses).
 - b) *Comprobación única*, en la cual la fracción muestral es tan pequeña que sólo se incluye una pequeña fracción de familias, y la posibilidad de que una familia se cuente más de una vez se pasa por alto.
 - c) *Comprobación múltiple incompleta*, en la cual las familias pueden determinarse a través de cualquiera de los individuos afectados, con una cierta probabilidad (generalmente desconocida) de determinación a través de cada miembro afectado.

La importancia de estas distinciones es la siguiente. Supóngase que estamos estudiando familias de tamaño n y que el riesgo es constante para cada persona (como los rasgos determinados por la herencia mendeliana recesiva, en los cuales el riesgo en los descendientes de

padres que llevan ambos el gen es de $1/4$). En 1 y en $2a$ las frecuencias esperadas de familias con r individuos afectados, sobre la hipótesis nula de un riesgo constante para cada persona, estarán dadas por una distribución binomial, faltando en $2a$ el término para $r = 0$. En $2b$, sin embargo, la probabilidad de que una familia con r individuos afectados sea determinada es proporcional a r ; las frecuencias esperadas serán entonces proporcionales a las probabilidades binomiales multiplicadas por r . En $2c$ la situación es intermedia: las familias con más individuos afectados tienen una mayor probabilidad de ser seleccionadas, pero hasta un grado que depende de la probabilidad desconocida de determinación a través de cualquier individuo.

Estas distinciones han sido muy consideradas en la investigación genética (Baley, 1961) y han dado origen a numerosos métodos de estimación del riesgo medio por individuo y de la evaluación de la heterogeneidad. Un método simple y útil para el caso $2a$ ha sido, por ejemplo, publicado por Gart (1968). Haenszel (1959) expone el problema concretamente en relación con estudios sobre enfermedades crónicas. Aquí normalmente no es apropiado el supuesto de un riesgo uniforme y puede ser necesario comparar la proporción de individuos afectados entre los familiares de los casos con los propios de una muestra de individuos de control, tal vez obtenidos mediante el método 1 . Al comparar la prevalencia de la enfermedad entre los dos grupos se deben tener en cuenta los efectos de la edad y cualesquiera otros factores de importancia conocida.

de ensayo se denomina *ensayo de dilución analítico*; que quizá raras veces existe en la realidad. En la práctica, la mayoría de las respuestas biológicas son específicas para un conjunto de sustancias, estrechamente relacionadas quizá desde el punto de vista químico, como las diversas penicilinas. En tales casos la potencia puede depender hasta cierto punto del sistema de ensayo, ya que las diferentes variedades de las sustancias activas pueden tener efectos diferenciales en distintos sistemas biológicos. Un ensayo que para un sistema biológico en concreto se comporta *como si* la situación ideal fuese verdadera se denomina *ensayo de dilución comparativo*.

El término «bioensayo» se utiliza a menudo en un sentido más amplio, para indicar cualquier experimento en el que se observan respuestas específicas a agentes aplicados externamente en animales u otros sistemas biológicos. El objetivo de este tipo de experimentos es a menudo medir los efectos de varios agentes sobre la variable de respuesta, sin efectuar intento alguno de estimar la potencia relativa. Esta práctica es común, por ejemplo, en los programas extensos para probar nuevos fármacos, pesticidas, aditivos alimentarios, etc., para detectar efectos carcinogénicos potenciales. Es corriente incluir, en un conjunto de experimentos sobre varios preparados de test, observaciones de preparados control. Éstos pueden incluir tanto controles «negativos» (materiales inertes) como controles «positivos» (carcinógenos conocidos). El objetivo es detectar preparados de test que muestren cualquier efecto carcinogénico más que estimar potencias relativas. En este capítulo nos limitaremos a los bioensayos en el sentido más específico descrito al principio de este apartado, cuyo propósito central es la estimación de la potencia relativa.

La forma más simple de ensayo es el *ensayo directo*, en el cual se administran dosis crecientes de S y T a una unidad experimental hasta que se produce cierto suceso crítico. Esta situación es rara; un ejemplo es el ensayo de digitálicos preparados en el conejillo de Indias, en el que el suceso crítico es el paro cardíaco. La dosis administrada a cualquier animal es una medida de la tolerancia individual de ese animal, que puede esperarse que varíe de un animal a otro por causas biológicas y ambientales. En cualquier ocasión y para un animal en particular, supongamos que la dosis tolerada de S fuese X_S y la de T, X_T (en la práctica, por supuesto, sólo se puede observar una de ellas). Entonces la potencia, p , de T en términos de S estaría dada por X_S/X_T . Si S y T fuesen, cada una, administradas a grandes muestras aleatorias de una población de animales, las dosis toleradas X_S y X_T formarían dos distribuciones relacionadas entre sí como en la figura 17.1a. La distribución X_S diferiría de la de X_T por el factor multiplicador p , exactamente como si se ampliase o redujese la escala debido a este factor. A partir de muestras aleatorias de T y S, p podría estimarse mediante las distribuciones de X_T y X_S . El problema de estimación es mucho más simple si las dosis se registran logarítmicamente, como en la figura 17.1b. Si $x_S = \log X_S$ y $x_T = \log X_T$, podemos estimar el $\log p$ a partir de las dos medias muestrales $\bar{x}_S$ y $\bar{x}_T$ mediante:

$$M = \bar{x}_S - \bar{x}_T$$

Automáticamente se garantiza que las distribuciones de x_S y x_T tendrán la misma forma, y en la práctica tienden a ser razonablemente normales. La teoría de la distribución de t en el caso de dos muestras proporciona límites de confianza para el $\log p$, centrados alrededor de M , y (tomando antilogaritmos) los correspondientes límites para p . Desafortunadamente, la administración continua de dosis y la respuesta inmediata que se necesita en los ensayos directos




Fig. 17.1. Ensayo directo. Distribución de dosis de tolerancia y sus logaritmos para preparados estándar y de test.

raras veces son factibles. En su lugar el investigador debe confiar en los *métodos indirectos*, que consisten en administrar dosis predeterminadas de T y S a grupos de unidades experimentales y observar las respuestas resultantes. En los dos apartados siguientes se toman en consideración dos modelos distintos para esta situación.

17.2. Ensayos de rectas paralelas

Supóngase que en un sistema de ensayo determinado, la respuesta media, y , está linealmente relacionada con el logaritmo de la dosis, x . Es decir, para un logaritmo de la dosis x_s de S, la respuesta esperada es:

$$E(y) = \alpha + \beta x_s \quad (17.1)$$

Por otra parte, se obtendría la misma respuesta esperada mediante el logaritmo de la dosis x_T de T, teniendo en cuenta que $x_s - x_T = \log p$, el logaritmo de la relación de potencias de T en función de S. Consecuentemente la ecuación de la recta de regresión para T es:

$$\begin{aligned} E(y) &= \alpha + \beta (x_T + \log p) \\ &= (\alpha + \beta \log p) + \beta x_T \end{aligned} \quad (17.2)$$

Las rectas de regresión (17.1) y (17.2) para S y T, respectivamente, son paralelas, pero difieren en la posición si el $\log p$ es distinto de cero (es decir, si p es distinto de 1). La distancia horizontal entre las dos rectas es $\log p$.

En cualquier ensayo se observarán valores de y para varios valores de x_s para S y a valores de x_T para T. Las relaciones de regresión (17.1) y (17.2) se calculan ajustando dos rectas paralelas exactamente como en el apartado 9.4 (ecuación 9.24), obteniendo las ecuaciones:

$$Y_s = \bar{y}_s + b(x_s - \bar{x}_s) \quad (17.3)$$

$$Y_T = \bar{y}_T + b(x_T - \bar{x}_T) \quad (17.4)$$

La estimación, M , del logaritmo de la relación de potencias es la diferencia de $x_s - x_T$ cuando $Y_s = Y_T$; según (17.3) y (17.4), esto conduce a:

$$M = \bar{x}_S - \bar{x}_T - \frac{\bar{y}_S - \bar{y}_T}{b} \quad (17.5)$$

La posición se indica en la figura 17.2. La única diferencia en el énfasis con respecto al tratamiento del problema considerado en el apartado 9.4 es que en aquél nos interesábamos por el cálculo de la distancia vertical entre las rectas paralelas, mientras que ahora estimamos, según (17.5), la distancia horizontal.

Nótese que si la regresión no es lineal, las dos curvas de regresión continuarán siendo «paralelas» en el sentido que su distancia *horizontal* en la escala de logaritmos de dosis será constante. En general, pues, la distancia *vertical* no será constante, a menos que la regresión sea lineal. Para lograr una regresión lineal puede ser necesaria alguna transformación de la variable respuesta. En el análisis descrito a continuación, asumimos también que la variancia residual con respecto a la recta es normal y tiene variancia constante. Puede ser difícil cumplir dichas condiciones simultáneamente.

Supóngase que existen n_s y n_T observaciones sobre S y T, respectivamente, y que la media cuadrática (MC) residual con respecto a las rectas paralelas (la s_c^2 de (9.34) es s^2 . Una fórmula aproximada para la $\text{Var}(M)$, según (3.15), es:

$$\text{Var}(M) \simeq \frac{s^2}{b^2} \left[\frac{1}{n_S} + \frac{1}{n_T} + \frac{(\bar{y}_S - \bar{y}_T)^2}{b^2 \Sigma(S_{xx})} \right] \quad (17.6)$$

donde $\Sigma(S_{xx})$ es la suma de cuadrados (SC) total de x intrapreparados. El último término entre corchetes también puede expresarse, según (17.5), como:




Fig. 17.2. Ensayos de rectas paralelas. Rectas de regresión real y ajustadas para preparaciones estándar y de test.

la pendiente de las rectas paralelas es significativa al nivel requerido para los límites de confianza.

Ejemplo 17.1

La tabla 17.1 presenta los resultados de un ensayo clínico con vitamina D, en que se empleó un preparado estándar de vitamina D, S, y una preparación test, I. Los datos correspondientes a S ya se han dado en la tabla 9.3, y el método del ensayo se describe con más detalle en el ejemplo 9.2. En la figura 17.3 se trazan en una gráfica los valores medios de la variable de respuesta y correspondientes a las distintas dosis de cada preparado contra el logaritmo de la dosis, x .

Un cálculo preliminar de las dos pendientes separadas da $b_1 = 2,6166$ para S y $b_2 = 2,7962$ para I. El test de $b_1 - b_2$, como en la página 279, da $t = -0,20$ con 57 gl, lo cual evidentemente no es significativo. Por lo tanto, procedemos con los cálculos de potencia. Los estadísticos básicos aplicables son los siguientes:

Grupo	n	$\bar{x}$	$\bar{y}$	S_{xx}	S_{xy}	S_{yy}	S_{yy} intradosis
S	31	0,8741	2,8710	2,0576	5,3840	58,7339	41,7418
I	30	1,0000	1,8833	5,4361	15,2005	63,8417	20,9583
				<u>7,4937</u>	<u>20,5845</u>	<u>122,5756</u>	<u>62,7001</u>

La S_{yy} intradosis se obtuvo según la desviación tipo de la página 272; la de I se obtiene del mismo modo.

En este momento del análisis es instructivo derivar el análisis de la variancia que aparece en la tabla 17.2. Las SC de los puntos 1, 2, 6 y 7 son, todas ellas, claras. Las de 3 y 4 se obtienen aplicando el método de la última parte del ejemplo 9.3, y la de 5 se deduce mediante la diferencia. El cociente de las variancias entre las pendientes confirma los resultados del test de la t descritos anteriormente (los 57 gl usados en aquel caso corresponden a una agrupación de los puntos 5 y 6 en la tabla 17.2) y apoya el supuesto de una regresión de rectas paralelas.

Procediendo con el análisis, la pendiente común se estima como:

$$b = \frac{20,5845}{7,4937} = 2,7469$$

y según (17.5),

$$\begin{aligned} M &= 0,8741 - 1,0000 - \frac{2,8710 - 1,8833}{2,7469} \\ &= -0,1259 - 0,3596 \\ &= -0,4855 \end{aligned}$$

La estimación de la potencia es:

$$\text{antilog } M = 0,327$$

medida en unidades internacionales (UI) por miligramo (siendo éstas las escalas en las que se miden las dosis de S e I). Como comprobación aproximada deducimos de la tabla 17.1 que las dosis de 3,5,

Tabla 17.1. Evaluación radiográfica de la cicatrización ósea con distintas dosis de dos preparados.

<i>Preparado estándar de vitamina D</i>					
Dosis (UI)	3,5	7	14		
Log dosis, x	0,544	0,845	1,146		Total
	0	1,50	2,00		
	0	2,50	2,50		
	1,00	5,00	5,00		
	2,75	6,00	4,00		
	2,75	4,25	5,00		
	1,75	2,75	4,00		
	2,75	1,50	2,50		
	2,25	3,00	3,50		
	2,25		3,00		
	2,50		2,00		
			3,00		
			4,00		
			4,00		
Número	10	8	13		31
Media	1,8000	3,3125	3,4231		
<i>Preparado I</i>					
Dosis (mg)	2,5	5	10	20	40
Log dosis, x	0,398	0,699	1,000	1,301	1,602
	0	1,00	1,50	3,00	3,50
	1,00	1,50	1,00	3,00	3,50
	0	1,50	2,00	5,50	4,50
	0	1,00	3,50	2,50	3,50
	0	1,00	2,00	1,00	3,50
	0,50	0,50	0	2,00	3,00
Número	6	6	6	6	6
Media	0,2500	1,0833	1,6667	2,8333	3,5833

7 y 10 UI de S dan aproximadamente las mismas respuestas medias que 10, 20 y 40 mg de I, que sugiere que I tiene una potencia de alrededor de 0,35 UI/mg.

Para considerar la variación muestral de M necesitamos la MC residual con respecto a las rectas paralelas. Se obtiene de la tabla 17.2 como:

$$\begin{aligned}
 s^2 &= \frac{62,7001 + 3,2837 + 0,0481}{53 + 4 + 1} \\
 &= 66,0319/58 \\
 &= 1,1385
 \end{aligned}$$

que es ligeramente distinta de la MC intradosis de la tabla 17.2. Mediante (17.9), teniendo en cuenta que $t_{58; 0,05} = 2,002$,

$$\begin{aligned}
 g &= \frac{(2,002)^2 (1,1385)}{(2,7469)^2 (7,4937)} \\
 &= 0,081
 \end{aligned}$$

Éste es suficientemente pequeño para permitir el uso de la fórmula aproximada (17.6).

<i>Entre dosis</i>	$k_s + k_T$	
Regresión		2
Desviación del modelo		$k_s + k_T - 2$
<i>Intradosis</i>	$n - k_s - k_T - 1$	
Total	$n - 1$	

La SC para las desviaciones del modelo puede subdividirse en las siguientes partes:

Blancos	1
Intersección	1
No linealidad para las dosis distintas de cero	$k_s + k_T - 4$
	$k_s + k_T - 2$

La SC para los «blancos» indica si las observaciones de los «blancos» son suficientemente compatibles con el resto. Se puede obtener reajustando la regresión múltiple con una variable ficticia más (1 para «blancos» y 0 para los demás casos) y fijándose en la reducción en SC correspondiente a las desviaciones. Un test sobre el cociente de las variancias significativo para los «blancos» podría indicar no linealidad para dosis muy bajas; si los restantes tests fuesen satisfactorios, el ensayo todavía podría analizarse adecuadamente omitiendo los «blancos».

La SC para la «intersección» muestra si se puede justificar el ajuste de los datos a dos rectas que se cruzan en el eje vertical. La significación estadística aquí es más seria y normalmente indica la invalidez del sistema de ensayo. Se puede obtener ajustando dos rectas separadas a las observaciones a dosis distintas de cero de S y a las de dosis distintas de cero de T. La diferencia en residuales entre este análisis y el análisis al que nos hemos referido anteriormente (en el test los «blancos») da la SC requerida.

El tercer componente, debido a la no linealidad en las dosis distintas de cero, puede obtenerse ya sea por sustracción o bien directamente, mediante dos regresiones separadas (con $k_s - 2$ gl para S y con $k_T - 2$ gl para T añadidos a los $k_s + k_T - 4$ gl requeridos).

En Finney (1978, cap. 7) pueden hallarse más detalles y ejemplos. Dicho autor también analiza el uso de diseños simétricos que permiten la simplificación del análisis mediante el uso de contrastes lineales.

17.4. Ensayos de respuesta cuántica

A menudo la respuesta es cuántica, como en los ensayos directos que, sin embargo, deben realizarse indirectamente por selección de dosis y observación de las respuestas obtenidas. Si una dosis concreta de un preparado se aplica a n_i unidades experimentales, el investigador observará que un número de respuestas, denominadas r_i , son positivas y $n_i - r_i$ son negativas. Los siguientes son ejemplos de ensayos que producen este tipo de respuesta como sigue:

1. *Piretrina*: la respuesta es la muerte en moscas domésticas.
2. *Insulina*: la respuesta es la presencia de convulsiones en ratones.
3. *Preparaciones de virus*: la respuesta es la presencia del crecimiento vírico en membranas de huevo.




Fig. 17.6. Ensayos de respuesta cuántica. Curvas de respuestas reales y ajustadas para preparados estándar y de test.

Las relaciones (17.18) se pueden ajustar iterativamente por el procedimiento de la máxima verosimilitud descrito en el apartado 12.8, utilizando una variable ficticia para distinguir entre S y T, como en el apartado 10.4. Si escribimos $\alpha_T = \alpha_S + \delta$, el logaritmo de la relación de potencias está dado por $\log \rho = \delta/\beta$. Puede utilizarse un programa de ordenador para modelos lineales generalizados a fin de obtener los estimadores a_s , d y b de α_s , δ y β , respectivamente; entonces ρ se calcula mediante $M = d/b$. A partir de (3.18), una fórmula aproximada para $\text{Var}(M)$ es:

$$\text{Var}(M) \approx \frac{V_d}{b^2} - \frac{2dC_{db}}{b^3} + \frac{d^2 V_b}{b^4}$$

donde $V_d = \text{Var}(d)$, $C_{db} = \text{Cov}(d, b)$ y $V_b = \text{Var}(b)$. Estas variancias y la covariancia se pueden obtener a partir de los resultados que suministre el ordenador. Los límites de confianza aproximados del 100 $(1 - 2\alpha)\%$ para $\log \rho$ son entonces:

$$M \pm z_{2\alpha} \sqrt{\text{Var}(M)}$$

donde $z_{2\alpha}$ es la desviación normal estandarizada habitual. Los límites para ρ se obtienen tomando antilogaritmos.

Por analogía con (17.8), el teorema de Fieller puede utilizarse para dar aproximaciones más fiables. Los límites para el $\log \rho$ se obtienen entonces mediante:

$$\frac{M - \frac{gC_{db}}{V_b} \pm \frac{z_{2\alpha}}{b} \left[V_d - 2MC_{db} + M^2V_b - g \left(V_d - \frac{C_{db}^2}{V_b} \right) \right]^{\frac{1}{2}}}{1 - g}$$

donde

$$g = \frac{z_{2\alpha}^2 V_b}{b^2}$$

Se pueden obtener tests de la χ^2 aproximadas para a) paralelismo y b) linealidad, mediante el análisis de la desviación, tomando a) la diferencia entre las desviaciones del modelo ajustado y un modelo con pendientes separadas para S y T, y b) la desviación del último modelo.

El uso de la transformación logística en los ensayos biológicos fue muy defendida por J. Berkson, quien propugnó el ajuste de curvas no iterativo mediante el uso de ponderaciones empíricas (Berkson, 1944). Los cálculos de la máxima verosimilitud para la transformación probit son descritos ampliamente, con ejemplos, por Finney (1971), y este método, denominado *análisis de probits*, en general es quizá más utilizado en los ensayos biológicos que el correspondiente método logit. No existe prueba alguna para sugerir que un modelo es más compatible con los datos reales que el otro; las curvas ajustadas con los dos métodos son invariablemente muy similares.

Otro grupo de métodos abreviados para el análisis de ensayos de respuesta cuántica intentan medir la distancia horizontal entre las dos curvas de respuesta del logaritmo de la dosis sin estimar enteramente las curvas. La posición de cada una de las curvas en el primer diagrama de la figura 17.6 se puede resumir por la dosis en la que $P = 0,5$. Esto se denomina DE50 (DE representa la «dosis efectiva») o *dosis efectiva mediana*; es claramente la mediana de la distribución de tolerancia subyacente. Las DE50 para T y S están en la relación $1:p$. Si se calcularan mediante X_{OT} y X_{OS} , la relación X_{OS}/X_{OT} proporcionaría una estimación de p ; de forma equivalente, la cantidad

$$M = \log X_{OS} - \log X_{OT}$$

estimaría el valor de $\log p$.

La DE50 recibe algunas veces nombres ligeramente distintos según el tipo de respuesta: DL50 o dosis letal mediana si la respuesta es letal; DI50 si la respuesta es la proporción de animales protegidos por un agente inmunizante frente a una dosis crítica de organismos virulentos, etc. Se puede calcular a ojo a partir de un gráfico de las respuestas observadas, pero una estimación subjetiva de este tipo adolecerá de su falta de reproductibilidad, incluso sobre los mismos datos, y la desventaja adicional de que es virtualmente imposible obtener una estimación adecuada del error muestral. Hasta hace poco tiempo muchos métodos simples objetivos de cálculo de la DE50 eran de uso corriente, pero la gran disponibilidad de programas informáticos para el análisis eficiente de datos de respuesta cuántica los ha convertido en anticuados. Finney (1978, apartados 18.6 a 18.8) proporciona una información completa.

Tabla 18.1. Etapas en el proceso de manipulación de datos.

Etapa	Operaciones
<i>Proceso de datos</i>	
Recogida	Registro de las observaciones
Transferencia	Codificación: transferencia de datos al ordenador para su almacenamiento
Verificación	Verificación; corrección
<i>Análisis estadístico</i>	
Organización	Clasificación; derivación de variables nuevas; tabulación; ordenación
Cálculo	Aplicación de métodos estadísticos que implican el cálculo de fórmulas estándar

La mayoría de las descripciones de análisis estadístico —en general este libro no es una excepción— parten del supuesto de que podemos acceder a los datos en algún formato estándar. Por ejemplo, el cálculo del test estadístico de χ^2 para una tabla 2 x 2 (4.21) es casi un cálculo trivial que puede efectuarse en menos de un minuto en la más simple de las calculadoras electrónicas. Pero, como expusimos antes, establecer las frecuencias de la tabla de contingencia dista mucho de ser un asunto trivial. Cuando consideramos el papel de los ordenadores, es ventajoso pensar en todo el proceso que requieren los datos, desde su recogida hasta el análisis completo. Para su estudio, es conveniente dividir el proceso en cinco fases (tabla 18.1); las tres primeras fases suelen designarse proceso de datos, y las dos últimas, análisis estadístico. Com primera aproximación, analizaremos las 5 fases secuencialmente, pero entre ellas hay interacciones, tanto «hacia atrás» como «hacia delante».

18.2. Proceso de datos

Recogida de datos

Esta fase se trata en el capítulo 1 (pp. 8 a 10). A menudo durante esta fase no se utilizan ordenadores, pero, en algunos casos, los datos pueden registrarse directamente en un ordenador. En cualquier caso, el diseño de la fase de recogida de datos deberá facilitar, en la medida de lo posible, la entrada de los datos a un ordenador.

Transferencia

Esta fase también se ha tratado en el capítulo 1 (pp. 10 a 12). A menudo requiere codificar todos los datos de forma numérica (fig. 1.4). El formato de los datos debe ser compatible con el paquete estadístico que intenta utilizarse. Puede ser útil introducir los datos de modo que se produzca el mínimo de errores posible, y entonces emplear un programa especial de edición para tener los datos en el formato requerido por el paquete estadístico. Cuando los datos se expresan en forma numérica en un formato estrictamente definido, no debería existir problema alguno, pero debe tenerse cuidado con la información que falta (*missing*). Una opción es dejar las entradas correspondientes en blanco, pero, dado que no existe uniformi-

lo que permite la ejecución de métodos nuevos. Esta posibilidad del Genstat lo hace popular entre los estadísticos que están desarrollando una nueva metodología o que desean ensayar variantes de métodos existentes. El Genstat tiene recursos particularmente buenos para el análisis de experimentos diseñados.

GLIM

El sistema *Generalized Linear Interactive Modelling (GLIM)* se introdujo inicialmente en 1974. Fue escrito para ajustar modelos lineales generalizados y para permitir la operación en modalidad interactiva. Esto permite al investigador probar diferentes modelos y avanzar de acuerdo con los resultados de cada ajuste. Así, es posible añadir o despremiar variables y evaluar el efecto de dicho cambio en el modelo, antes de decidir el siguiente paso. Resulta más adecuado en conjuntos de datos de tamaño pequeño a moderado. Recientemente, Francis et al. (1993) y Aitken et al. (1989) han editado un manual y dan una descripción y ejemplos de su uso.

Otros paquetes se han desarrollado específicamente para los PC sin haber pasado por la etapa de los *mainframe*. Periódicamente se publican revisiones del *software* estadístico en el *American Statistician* y en *Applied Statistics*. Algunos de los paquetes más populares usados para el análisis estadístico son SYSTAT (Wilkinson, 1990), STATA (Computing Resource Center, 1992) y SPIDA (Gebski et al, 1992). EGRET (Statistics and Epidemiology Research Corporation, 1988) se ha hecho popular para el análisis de datos epidemiológicos, y Epi Info (Dean et al, 1990) es útil para el diseño de cuestionarios epidemiológicos.

Un avance reciente y emocionante es el de StatXact (CYTEL Software Corporation, 1991). Éste por primera vez pone a disposición, en forma práctica, varios cálculos exactos para datos discretos. Entre éstos se cuentan el test exacto para una tabla $r \times c$ (apartado 7.6), que también puede obtenerse en SAS, un test de la tendencia exacta para una tabla $r \times 2$ con filas ordenadas (apartado 12.2) y el test exacto para la combinación de tablas 2×2 , adecuado para los cálculos cuando falla el test de Mantel-Haenszel (apartado 12.6). Asimismo, permite el cálculo de los niveles de significación de semi- P , cuyo uso recomendamos para datos discretos (apartados 4.7 y 4.9). Ha sido necesaria gran cantidad de investigación para producir un paquete que lleve a cabo estos cálculos, incluso en los rápidos ordenadores existentes actualmente. Algunos paquetes relacionados son el LogXact para regresión logística y EaSt para ensayos clínicos secuenciales de grupos con datos de supervivencia.

Los distintos paquetes se han presentado como entidades diferenciadas. Aunque pueden ser considerados como tales y un usuario con un buen conocimiento práctico de uno solo de los paquetes estadísticos generales, como SAS, SPSS o BMDP, podrá ejecutar los análisis más necesarios, algunos usuarios prefieren usar paquetes diferentes para partes diferentes de un análisis. Esto se facilita usando archivos de salida provenientes de una ejecución de un paquete como entrada para otro. La transferencia de un análisis de un paquete a otro es facilitada por los programas de utilidades, como dmbs/copy y Stat/Transfer, que permiten una

Tabla A2. Puntos percentuales de la distribución de χ^2

La función tabulada es $\chi^2_{\alpha, \nu}$, el valor excedido con una probabilidad P en una distribución de χ^2 con ν grados de libertad (el punto percentual 100 P).




Grados de libertad, ν	Probabilidad de un valor superior, P									
	0,975	0,900	0,750	0,500	0,250	0,100	0,050	0,025	0,010	0,001
1	—	0,02	0,10	0,45	1,32	2,71	3,84	5,02	6,63	10,83
2	0,05	0,21	0,58	1,39	2,77	4,61	5,99	7,38	9,21	13,82
3	0,22	0,58	1,21	2,37	4,11	6,25	7,81	9,35	11,34	16,27
4	0,48	1,06	1,92	3,36	5,39	7,78	9,49	11,14	13,28	18,47
5	0,83	1,61	2,67	4,35	6,63	9,24	11,07	12,83	15,09	20,52
6	1,24	2,20	3,45	5,35	7,84	10,64	12,59	14,45	16,81	22,46
7	1,69	2,83	4,25	6,35	9,04	12,02	14,07	16,01	18,48	24,32
8	2,18	3,49	5,07	7,34	10,22	13,36	15,51	17,53	20,09	26,12
9	2,70	4,17	5,90	8,34	11,39	14,68	16,92	19,02	21,67	27,88
10	3,25	4,87	6,74	9,34	12,55	15,99	18,31	20,48	23,21	29,59
11	3,82	5,58	7,58	10,34	13,70	17,28	19,68	21,92	24,72	31,26
12	4,40	6,30	8,44	11,34	14,85	18,55	21,03	23,34	26,22	32,91
13	5,01	7,04	9,30	12,34	15,98	19,81	22,36	24,74	27,69	34,53
14	5,63	7,79	10,17	13,34	17,12	21,06	23,68	26,12	29,14	36,12
15	6,27	8,55	11,04	14,34	18,25	22,31	25,00	27,49	30,58	37,70

16	6,91	9,31	11,91	15,34	19,37	23,54	26,30	28,85	32,00	39,25
17	7,56	10,09	12,79	16,34	20,49	24,77	27,59	30,19	33,41	40,79
18	8,23	10,86	13,68	17,34	21,60	25,99	28,87	31,53	34,81	42,31
19	8,91	11,65	14,56	18,34	22,72	27,20	30,14	32,85	36,19	43,82
20	9,59	12,44	15,45	19,34	23,83	28,41	31,41	34,17	37,57	45,32
21	10,28	13,24	16,34	20,34	24,93	29,62	32,67	35,48	38,93	46,80
22	10,98	14,04	17,24	21,34	26,04	30,81	33,92	36,78	40,29	48,27
23	11,69	14,85	18,14	22,34	27,14	32,01	35,17	38,08	41,64	49,73
24	12,40	15,66	19,04	23,34	28,24	33,20	36,42	39,36	42,98	51,18
25	13,12	16,47	19,94	24,34	29,34	34,38	37,65	40,65	44,31	52,62
26	13,84	17,29	20,84	25,34	30,43	35,56	38,89	41,92	45,64	54,05
27	14,57	18,11	21,75	26,34	31,53	36,74	40,11	43,19	46,96	55,48
28	15,31	18,94	22,66	27,34	32,62	37,92	41,34	44,46	48,28	56,89
29	16,05	19,77	23,57	28,34	33,71	39,09	42,56	45,72	49,59	58,30
30	16,79	20,60	24,48	29,34	34,80	40,26	43,77	46,98	50,89	59,70
40	24,43	29,05	33,66	39,34	45,62	51,80	55,76	59,34	63,69	73,40
50	32,36	37,69	42,94	49,33	56,33	63,17	67,50	71,42	76,15	86,66
60	40,48	46,46	52,29	59,33	66,98	74,40	79,08	83,30	88,38	99,61
70	48,76	55,33	61,70	69,33	77,58	85,53	90,53	95,02	100,42	112,32
80	57,15	64,28	71,14	79,33	88,13	96,58	101,88	106,63	112,33	124,84
90	65,65	73,29	80,62	89,33	98,64	107,56	113,14	118,14	124,12	137,21
100	74,22	82,36	90,13	99,33	109,14	118,50	124,34	129,56	135,81	149,45

Resumida de la tabla 8 de Pearson y Hartley (1966) con permiso de los autores y editores.

Tabla A3. Puntos percentuales de la distribución de la t

Total para
ambos extremos
o colas, P



La función tabulada es $t_{\alpha, \nu}$, el valor excedido en ambas direcciones con una probabilidad P en una distribución de t con ν grados de libertad (el punto percentual 100 P).

Grados de libertad, ν	Probabilidad de un valor superior, P												
	0,9	0,8	0,7	0,6	0,5	0,4	0,3	0,2	0,1	0,05	0,02	0,01	0,001
1	0,158	0,325	0,510	0,727	1,000	1,376	1,963	3,078	6,314	12,706	31,821	63,657	636,619
2	0,142	0,289	0,445	0,617	0,816	1,061	1,386	1,886	2,920	4,303	6,965	9,925	31,598
3	0,137	0,277	0,424	0,584	0,765	0,978	1,250	1,638	2,353	3,182	4,541	5,841	12,924
4	0,134	0,271	0,414	0,569	0,741	0,941	1,190	1,533	2,132	2,776	3,747	4,604	8,610
5	0,132	0,267	0,408	0,559	0,727	0,920	1,156	1,476	2,015	2,571	3,365	4,032	6,869
6	0,131	0,265	0,404	0,553	0,718	0,906	1,134	1,440	1,943	2,447	3,143	3,707	5,959
7	0,130	0,263	0,402	0,549	0,711	0,896	1,119	1,415	1,895	2,365	2,998	3,499	5,408
8	0,130	0,262	0,399	0,546	0,706	0,889	1,108	1,397	1,860	2,306	2,896	3,355	5,041
9	0,129	0,261	0,398	0,543	0,703	0,883	1,100	1,383	1,833	2,262	2,821	3,250	4,781
10	0,129	0,260	0,397	0,542	0,700	0,879	1,093	1,372	1,812	2,228	2,764	3,169	4,587
11	0,129	0,260	0,396	0,540	0,697	0,876	1,088	1,363	1,796	2,201	2,718	3,106	4,437
12	0,128	0,259	0,395	0,539	0,695	0,873	1,083	1,356	1,782	2,179	2,681	3,055	4,318
13	0,128	0,259	0,394	0,538	0,694	0,870	1,079	1,350	1,771	2,160	2,650	3,012	4,221
14	0,128	0,258	0,393	0,537	0,692	0,868	1,076	1,345	1,761	2,145	2,624	2,977	4,140
15	0,128	0,258	0,393	0,536	0,691	0,866	1,074	1,341	1,753	2,131	2,602	2,947	4,073

16	0,128	0,258	0,392	0,535	0,690	0,865	1,071	1,337	1,746	2,120	2,583	2,921	4,015
17	0,128	0,257	0,392	0,534	0,689	0,863	1,069	1,333	1,740	2,110	2,567	2,898	3,965
18	0,127	0,257	0,392	0,534	0,688	0,862	1,067	1,330	1,734	2,101	2,552	2,878	3,922
19	0,127	0,257	0,391	0,533	0,688	0,861	1,066	1,328	1,729	2,093	2,539	2,861	3,883
20	0,127	0,257	0,391	0,533	0,687	0,860	1,064	1,325	1,725	2,086	2,528	2,845	3,850
21	0,127	0,257	0,391	0,532	0,686	0,859	1,063	1,323	1,721	2,080	2,518	2,831	3,819
22	0,127	0,256	0,390	0,532	0,686	0,858	1,061	1,321	1,717	2,074	2,508	2,819	3,792
23	0,127	0,256	0,390	0,532	0,685	0,858	1,060	1,319	1,714	2,069	2,500	2,807	3,767
24	0,127	0,256	0,390	0,531	0,685	0,857	1,059	1,318	1,711	2,064	2,492	2,797	3,745
25	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,316	1,708	2,060	2,485	2,787	3,725
26	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,315	1,706	2,056	2,479	2,779	3,707
27	0,127	0,256	0,389	0,531	0,684	0,855	1,057	1,314	1,703	2,052	2,473	2,771	3,690
28	0,127	0,256	0,389	0,530	0,683	0,855	1,056	1,313	1,701	2,048	2,467	2,763	3,674
29	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,311	1,699	2,045	2,462	2,756	3,659
30	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,310	1,697	2,042	2,457	2,750	3,646
40	0,126	0,255	0,388	0,529	0,681	0,851	1,050	1,303	1,684	2,021	2,423	2,704	3,551
60	0,126	0,254	0,387	0,527	0,679	0,848	1,046	1,296	1,671	2,000	2,390	2,660	3,460
120	0,126	0,254	0,386	0,526	0,677	0,845	1,041	1,289	1,658	1,980	2,358	2,617	3,373
∞	0,126	0,253	0,385	0,524	0,674	0,842	1,036	1,282	1,645	1,960	2,326	2,576	3,291

Reproducida de la tabla 3 de Fisher y Yates (1963) con permiso de los autores y editores.

5	0.05	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.68	4.53	4.36
	0.025	10.01	8.43	7.76	7.39	7.15	6.98	6.85	6.76	6.52	6.28	6.02
	0.01	16.26	13.27	12.06	11.39	10.97	10.67	10.46	10.29	9.89	9.47	9.02
	0.005	22.78	18.31	16.53	15.56	14.94	14.51	14.20	13.96	13.38	12.78	12.14
6	0.05	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.00	3.84	3.67
	0.025	8.81	7.26	6.60	6.23	5.99	5.82	5.70	5.60	5.37	5.12	4.85
	0.01	13.75	10.92	9.78	9.15	8.75	8.47	8.26	8.10	7.72	7.31	6.88
	0.005	18.63	14.54	12.92	12.03	11.46	11.07	10.79	10.57	10.03	9.47	8.88
7	0.05	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.57	3.41	3.23
	0.025	8.07	6.54	5.89	5.52	5.29	5.12	4.99	4.90	4.67	4.42	4.14
	0.01	12.25	9.55	8.45	7.85	7.46	7.19	6.99	6.84	6.47	6.07	5.65
	0.005	16.24	12.40	10.88	10.05	9.52	9.16	8.89	8.68	8.18	7.65	7.08
8	0.05	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.28	3.12	2.93
	0.025	7.57	6.06	5.42	5.05	4.82	4.65	4.53	4.43	4.20	3.95	3.67
	0.01	11.26	8.65	7.59	7.01	6.63	6.37	6.18	6.03	5.67	5.28	4.86
	0.005	14.69	11.04	9.60	8.81	8.30	7.95	7.69	7.50	7.01	6.50	5.95
9	0.05	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.07	2.90	2.71
	0.025	7.21	5.71	5.08	4.72	4.48	4.32	4.20	4.10	3.87	3.61	3.33
	0.01	10.56	8.02	6.99	6.42	6.06	5.80	5.61	5.47	5.11	4.73	4.31
	0.005	13.61	10.11	8.72	7.96	7.47	7.13	6.88	6.69	6.23	5.73	5.19
10	0.05	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	2.91	2.74	2.54
	0.025	6.94	5.46	4.83	4.47	4.24	4.07	3.95	3.85	3.62	3.37	3.08
	0.01	10.04	7.56	6.55	5.99	5.64	5.39	5.20	5.06	4.71	4.33	3.91
	0.005	12.83	9.43	8.08	7.34	6.87	6.54	6.30	6.12	5.66	5.17	4.64
12	0.05	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.69	2.51	2.30
	0.025	6.55	5.10	4.47	4.12	3.89	3.73	3.61	3.51	3.28	3.02	2.72
	0.01	9.33	6.93	5.95	5.41	5.06	4.82	4.64	4.50	4.16	3.78	3.36
	0.005	11.75	8.51	7.23	6.52	6.07	5.76	5.52	5.35	4.91	4.43	3.90

Continúa

Tabla A4 (continúa)

gl para el denomi- nador, v_2	P	gl para el numerador, v_1										
		1	2	3	4	5	6	7	8	12	24	∞
14	0.05	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.53	2.35	2.13
	0.025	6.30	4.86	4.24	3.89	3.66	3.50	3.38	3.29	3.05	2.79	2.49
	0.01	8.86	6.51	5.56	5.04	4.69	4.46	4.28	4.14	3.80	3.43	3.00
	0.005	11.06	7.92	6.68	6.00	5.56	5.26	5.03	4.86	4.43	3.96	3.44
16	0.05	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.42	2.24	2.01
	0.025	6.12	4.69	4.08	3.73	3.50	3.34	3.22	3.12	2.89	2.63	2.32
	0.01	8.53	6.23	5.29	4.77	4.44	4.20	4.03	3.89	3.55	3.18	2.75
	0.005	10.58	7.51	6.30	5.64	5.21	4.91	4.69	4.52	4.10	3.64	3.11
18	0.05	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.34	2.15	1.92
	0.025	5.98	4.56	3.95	3.61	3.38	3.22	3.10	3.01	2.77	2.50	2.19
	0.01	8.29	6.01	5.09	4.58	4.25	4.01	3.84	3.71	3.37	3.00	2.57
	0.005	10.22	7.21	6.03	5.37	4.96	4.66	4.44	4.28	3.86	3.40	2.87
20	0.05	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.28	2.08	1.84
	0.025	5.87	4.46	3.86	3.51	3.29	3.13	3.01	2.91	2.68	2.41	2.09
	0.01	8.10	5.85	4.94	4.43	4.10	3.87	3.70	3.56	3.23	2.86	2.42
	0.005	9.94	6.99	5.82	5.17	4.76	4.47	4.26	4.09	3.68	3.22	2.69

30	0,05	4,17	3,32	2,92	2,69	2,53	2,42	2,33	2,27	2,09	1,89	1,62
	0,025	5,57	4,18	3,59	3,25	3,03	2,87	2,75	2,65	2,41	2,14	1,79
	0,01	7,56	5,39	4,51	4,02	3,70	3,47	3,30	3,17	2,84	2,47	2,01
	0,005	9,18	6,35	5,24	4,62	4,23	3,95	3,74	3,58	3,18	2,73	2,18
40	0,05	4,08	3,23	2,84	2,61	2,45	2,34	2,25	2,18	2,00	1,79	1,51
	0,025	5,42	4,05	3,46	3,13	2,90	2,74	2,62	2,53	2,29	2,01	1,64
	0,01	7,31	5,18	4,31	3,83	3,51	3,29	3,12	2,99	2,66	2,29	1,80
	0,005	8,83	6,07	4,98	4,37	3,99	3,71	3,51	3,35	2,95	2,50	1,93
60	0,05	4,00	3,15	2,76	2,53	2,37	2,25	2,17	2,10	1,92	1,70	1,39
	0,025	5,29	3,93	3,34	3,01	2,79	2,63	2,51	2,41	2,17	1,88	1,48
	0,01	7,08	4,98	4,13	3,65	3,34	3,12	2,95	2,82	2,50	2,12	1,60
	0,005	8,49	5,79	4,73	4,14	3,76	3,49	3,29	3,13	2,74	2,29	1,69
120	0,05	3,92	3,07	2,68	2,45	2,29	2,17	2,09	2,02	1,83	1,61	1,25
	0,025	5,15	3,80	3,23	2,89	2,67	2,52	2,39	2,30	2,05	1,76	1,31
	0,01	6,85	4,79	3,95	3,48	3,17	2,96	2,79	2,66	2,34	1,95	1,38
	0,005	8,18	5,54	4,50	3,92	3,55	3,28	3,09	2,93	2,54	2,09	1,43
∞	0,05	3,84	3,00	2,60	2,37	2,21	2,10	2,01	1,94	1,75	1,52	1,00
	0,025	5,02	3,69	3,12	2,79	2,57	2,41	2,29	2,19	1,94	1,64	1,00
	0,01	6,63	4,61	3,78	3,32	3,02	2,80	2,64	2,51	2,18	1,79	1,00
	0,005	7,88	5,30	4,28	3,72	3,35	3,09	2,90	2,74	2,36	1,90	1,00

Resumienda de la tabla 18 de Pearson y Hartley (1966) con permiso de los autores y editores.

Para los valores de v_1 y v_2 no mostrados, la interpolación es aproximadamente lineal entre los valores inversos de v_1 y v_2 .

Tabla A5. Puntos percentuales de la distribución del intervalo studentizado:
 $\alpha = 0,05; 0,01$



La función tabulada es $Q_{p, \alpha}$, el valor excedido con una probabilidad α en la distribución del intervalo studentizado para p grupos y para f_3 grados de libertad intragrupos (el punto percentual 100 α). Los valores para $\alpha = 0,05$ se muestran en negrita.

f_2	Números de grupos, p									
	2	3	4	5	6	7	8	9	10	
5	3,64 5,70	4,60 6,98	5,22 7,80	5,67 8,42	6,03 8,91	6,33 9,32	6,58 9,67	6,80 9,97	6,99 10,24	
6	3,46 5,24	4,34 6,33	4,90 7,03	5,30 7,56	5,63 7,97	5,90 8,32	6,12 8,61	6,32 8,87	6,49 9,10	
7	3,34 4,95	4,16 5,92	4,68 6,54	5,06 7,01	5,36 7,37	5,61 7,68	5,82 7,94	6,00 8,17	6,16 8,37	
8	3,26 4,75	4,04 5,64	4,53 6,20	4,89 6,62	5,17 6,96	5,40 7,24	5,60 7,47	5,77 7,68	5,92 7,86	
9	3,20 4,60	3,95 5,43	4,41 5,96	4,76 6,35	5,02 6,66	5,24 6,91	5,43 7,13	5,59 7,33	5,74 7,49	
10	3,15 4,48	3,88 5,27	4,33 5,77	4,65 6,14	4,91 6,43	5,12 6,67	5,30 6,87	5,46 7,05	5,60 7,21	
12	3,08 4,32	3,77 5,05	4,20 5,50	4,51 5,84	4,75 6,10	4,95 6,32	5,12 6,51	5,27 6,67	5,39 6,81	

14	3,03 4,21	3,70 4,89	4,11 5,32	4,41 5,63	4,64 5,88	4,83 6,08	4,99 6,26	5,13 6,41	5,25 6,54
16	3,00 4,13	3,65 4,79	4,05 5,19	4,33 5,49	4,56 5,72	4,74 5,92	4,90 6,08	5,03 6,22	5,15 6,35
18	2,97 4,07	3,61 4,70	4,00 5,09	4,28 5,38	4,49 5,60	4,67 5,79	4,82 5,94	4,96 6,08	5,07 6,20
20	2,95 4,02	3,58 4,64	3,96 5,02	4,23 5,29	4,45 5,51	4,62 5,69	4,77 5,84	4,90 5,97	5,01 6,09
30	2,89 3,89	3,49 4,45	3,85 4,80	4,10 5,05	4,30 5,24	4,46 5,40	4,60 5,54	4,72 5,65	4,82 5,76
40	2,86 3,82	3,44 4,37	3,79 4,70	4,04 4,93	4,23 5,11	4,39 5,26	4,52 5,39	4,63 5,50	4,73 5,60
60	2,83 3,76	3,40 4,28	3,74 4,59	3,98 4,82	4,16 4,99	4,31 5,13	4,44 5,25	4,55 5,36	4,65 5,45
120	2,80 3,70	3,36 4,20	3,68 4,50	3,92 4,71	4,10 4,87	4,24 5,01	4,36 5,12	4,47 5,21	4,56 5,30
∞	2,77 3,64	3,31 4,12	3,63 4,40	3,86 4,60	4,03 4,76	4,17 4,88	4,29 4,99	4,39 5,08	4,47 5,16

Resumida de la tabla 29 de Pearson y Hartley (1966) con permiso de los autores y editores.

Tabla A6. Números aleatorios

		I																											
03	47	43	73	86	36	96	47	36	61	46	98	63	71	62	33	26	16	80	45	60	11	14	10	95					
97	74	24	67	62	42	81	14	57	20	42	53	32	37	32	27	07	36	07	51	24	51	79	89	73					
16	76	62	27	66	56	50	26	71	07	32	90	79	78	53	13	55	38	58	59	88	97	54	14	10					
12	56	85	99	26	96	96	68	27	31	05	03	72	93	15	57	12	10	14	21	88	26	49	81	76					
55	59	56	35	64	38	54	82	46	22	31	62	43	09	90	06	18	44	32	53	23	83	01	30	30					
16	22	77	94	39	49	54	43	54	82	17	37	93	23	78	87	35	20	96	43	84	26	34	91	64					
84	42	17	53	31	57	24	55	06	88	77	04	74	47	67	21	76	33	50	25	83	92	12	06	76					
63	01	63	78	59	16	95	55	67	19	98	10	50	71	75	12	86	73	58	07	44	39	52	38	79					
33	21	12	34	29	78	64	56	07	82	52	42	07	44	38	15	51	00	13	42	99	66	02	79	54					
57	60	86	32	44	09	47	27	96	54	49	17	46	09	62	90	52	84	77	27	08	02	73	43	28					
18	18	07	92	46	44	17	16	58	09	79	83	86	19	62	06	76	50	03	10	55	23	64	05	05					
26	62	38	97	75	84	16	07	44	99	83	11	46	32	24	20	14	85	88	45	10	93	72	88	71					
23	42	40	64	74	82	97	77	77	81	07	45	32	14	08	32	98	94	07	72	93	85	79	10	75					
52	36	28	19	95	50	92	26	11	97	00	56	76	31	38	80	22	02	53	53	86	60	42	04	53					
37	85	94	35	12	83	39	50	08	30	42	34	07	96	88	54	42	06	87	98	35	85	29	48	39					
70	29	17	12	13	40	33	20	38	26	13	89	51	03	74	17	76	37	13	04	07	74	21	19	30					
56	62	18	37	35	96	83	50	87	75	97	12	25	93	47	70	33	24	03	54	97	77	46	44	80					
99	49	57	22	77	88	42	95	45	72	16	64	36	16	00	04	43	18	66	79	94	77	24	21	90					
16	08	15	04	72	33	27	14	34	09	45	59	34	68	49	12	72	07	34	45	99	27	72	95	14					
31	16	93	32	43	50	27	89	87	19	20	15	37	00	49	52	85	66	60	44	38	68	88	11	80					
68	34	30	13	70	55	74	30	77	40	44	22	78	84	26	04	33	46	09	52	68	07	97	06	57					
74	57	25	65	76	59	29	97	68	60	71	91	38	67	54	13	58	18	24	76	15	54	55	95	52					
27	42	37	86	53	48	55	90	65	72	96	57	69	36	10	96	46	92	42	45	97	60	49	04	91					
00	39	68	29	61	66	37	32	20	30	77	84	57	03	29	10	45	65	04	26	11	04	96	67	24					
29	94	98	94	24	68	49	69	10	82	53	75	91	93	30	34	25	20	57	27	40	48	73	51	92					

16	90	82	66	59	83	62	64	11	12	67	19	00	71	74	60	47	21	29	68	02	02	37	03	31
11	27	94	75	06	06	09	19	74	66	02	94	37	34	02	76	70	90	30	86	38	45	94	30	38
35	24	10	16	20	33	32	51	26	38	79	78	45	04	91	16	92	53	56	16	02	75	50	95	98
38	23	16	86	38	42	38	97	01	50	87	75	66	81	41	40	01	74	91	62	48	51	84	08	32
31	96	25	91	47	96	44	33	49	13	34	86	82	53	91	00	52	43	48	85	27	55	26	89	62
66	67	40	67	14	64	05	71	95	86	11	05	65	09	68	76	83	20	37	90	57	16	00	11	66
14	90	84	45	11	75	73	88	05	90	52	27	41	14	86	22	98	12	22	08	07	52	74	95	80
68	05	51	18	00	33	96	02	75	19	07	60	62	93	55	59	33	82	43	90	49	37	38	44	59
20	46	78	73	90	97	51	40	14	02	04	02	33	31	08	39	54	16	49	36	47	95	93	13	30
64	19	58	97	79	15	06	15	93	20	01	90	10	75	06	40	78	78	89	62	02	67	74	17	33
05	26	93	70	60	22	35	85	15	13	92	03	51	59	77	59	56	78	06	83	52	91	05	70	74
07	97	10	88	23	09	98	42	99	64	61	71	62	99	15	06	51	29	16	93	58	05	77	09	51
68	71	86	85	85	54	87	66	47	54	73	32	08	11	12	44	95	92	63	16	29	56	24	29	48
26	99	61	65	53	58	37	78	80	70	42	10	50	67	42	32	17	55	85	74	94	44	67	16	94
14	65	52	68	75	87	59	36	22	41	26	78	63	06	55	13	08	27	01	50	15	29	39	39	43
17	53	77	58	71	71	41	61	50	72	12	41	94	96	26	44	95	27	36	99	02	96	74	30	83
90	26	59	21	19	23	52	23	33	12	96	93	02	18	39	07	02	18	36	07	25	99	32	70	23
41	23	52	55	99	31	04	49	69	96	10	47	48	45	88	13	41	43	89	20	97	17	14	49	17
60	20	50	81	69	31	99	73	68	68	35	81	33	03	76	24	30	12	48	60	18	99	10	72	34
91	25	38	05	90	94	58	28	41	36	45	37	59	03	09	90	35	57	29	12	82	62	54	65	60
34	50	57	74	37	98	80	33	00	91	09	77	93	19	82	74	94	80	04	04	45	07	31	66	49
85	22	04	39	43	73	81	53	94	79	33	62	46	86	28	08	31	54	46	31	53	94	13	38	47
09	79	13	77	48	73	82	97	22	21	05	03	27	24	83	72	89	44	05	60	35	80	39	94	88
88	75	80	18	14	22	95	75	42	49	39	32	82	22	49	02	48	07	70	37	16	04	61	67	87
90	96	23	70	00	39	00	03	06	90	55	85	78	38	36	94	37	30	69	52	90	89	00	76	33

Continúa

II

53	74	23	99	67	61	32	28	69	84	94	62	67	86	24	98	33	41	19	95	47	53	53	38	09
63	38	06	86	54	99	00	65	26	94	02	82	90	23	07	79	62	67	80	60	75	91	12	81	19
35	30	58	21	46	06	72	17	10	94	25	21	31	75	96	49	28	24	00	49	55	65	79	78	07
63	43	36	82	69	65	51	18	37	88	61	38	44	12	45	32	92	85	88	65	54	34	81	85	35
98	25	37	55	26	01	91	82	81	46	74	71	12	94	97	24	02	71	37	07	03	92	18	66	75
02	63	21	17	69	71	50	80	89	56	38	15	70	11	48	43	40	45	86	98	00	83	26	91	03
64	55	22	21	82	48	22	28	06	00	61	54	13	43	91	82	78	12	23	29	06	66	24	12	27
85	07	26	13	89	01	10	07	82	04	59	63	69	36	03	69	11	15	83	80	13	29	54	19	28
58	54	16	24	15	51	54	44	82	00	62	61	65	04	69	38	18	65	18	97	85	72	13	49	21
34	85	27	84	87	61	48	64	56	26	90	18	48	13	26	37	70	15	42	57	65	65	80	39	07
03	92	18	27	46	57	99	16	96	56	30	33	72	85	22	84	64	38	56	98	99	01	30	98	64
62	95	30	27	59	37	75	41	66	48	86	97	80	61	45	23	53	04	01	63	45	76	08	64	27
08	45	93	15	22	60	21	75	46	91	98	77	27	85	42	28	88	61	08	84	69	62	03	42	73
07	08	55	18	40	45	44	75	13	90	24	94	96	61	02	57	55	66	83	15	73	42	37	11	61
01	85	89	95	66	51	10	19	34	88	15	84	97	19	75	12	76	39	43	78	64	63	91	08	25
72	84	71	14	35	19	11	58	49	26	50	11	17	17	76	86	31	57	20	18	95	60	78	46	75
88	78	28	16	84	13	52	53	94	53	75	45	69	30	96	73	89	65	70	31	99	17	43	48	76
45	17	75	65	57	28	40	19	72	12	25	12	74	75	67	60	40	60	81	19	24	62	01	61	16
96	76	28	12	54	22	01	11	94	25	71	96	16	16	88	68	64	36	74	45	19	59	50	88	92
43	31	67	72	30	24	02	94	08	63	38	32	36	66	02	69	36	38	25	39	48	03	45	15	22
50	44	66	44	21	66	06	58	05	62	68	15	54	35	02	42	35	48	96	32	14	52	41	52	48
22	66	22	15	86	26	63	75	41	99	58	42	36	72	24	58	37	52	18	51	03	37	18	39	11
96	24	40	14	51	23	22	30	88	57	95	67	47	29	83	94	69	40	06	07	18	16	36	78	86
31	73	91	61	19	60	20	72	93	48	98	57	07	23	69	65	95	39	69	58	56	80	30	19	44
78	60	73	99	84	43	89	94	36	45	56	69	47	07	41	90	22	91	07	12	78	35	34	08	72

Notas sobre la utilización de los números aleatorios (Tabla A6)

1. Permutación aleatoria

Se trata de hacer una reordenación de números enteros de 1 a n con igual probabilidad de elección de cada uno de ellos.

Debe comenzar en un punto arbitrario de la tabla. Utilice tantas columnas de la tabla como dígitos tenga n (p. ej., si $n = 16$, utilice 2 columnas). Siga las columnas hacia abajo y continúe en el siguiente grupo de columnas escribiendo los números de 1 a n a medida que se vayan encontrando. Expresé 03 como 3, etc. Ignore 00, $n + 1$, $n + 2$, ..., 99. Ignore las repeticiones.

Se han publicado tablas directas, p. ej., en Fisher y Yates (1963), en Cochran y Cox (1957) y en Cox (1958). Para $n > 20$, véase Moses y Oakford (1963).

2. Selección aleatoria de una muestra de tamaño n a partir de una población de tamaño N

Numere los miembros de la población de 1 a N , comience una permutación aleatoria de N y pare cuando haya elegido n números. Los números escogidos componen la muestra requerida.

3. Asignación aleatoria

Para asignar aleatoriamente a n individuos en k grupos (p. ej., en un estudio experimental), forme una permutación aleatoria de n y divídala de izquierda a derecha en grupos de tamaño apropiado. No es necesario continuar la permutación más allá del punto en el que se han creado $k - 1$ grupos, pues los individuos restantes han de estar ya necesariamente incluidos en el grupo k .

4. Asignación aleatoria con entrada seriada

En este caso, n puede ser desconocido. Si la asignación se realiza para 2 tratamientos con igual probabilidad, utilice números pares e impares. Para 3 tratamientos utilice 1-3, 4-6, 7-9, ignorando el 0, etcétera.

5. Asignación aleatoria restringida (bloques permutados) con entrada seriada

En ocasiones, es aconsejable asegurar que el número de elementos asignados a tratamientos distintos sean iguales en diversos momentos; por ejemplo, dos tratamientos se han de equilibrar tras disponer cada grupo de 10 individuos. En este caso seleccione 5 individuos de cada grupo de 10 para un tratamiento (como en el apartado 2); los otros 5 se asignan al otro tratamiento.

6. Uso ampliado de tablas

Las tablas pueden utilizarse también leyendo las entradas en direcciones distintas, por ejemplo siguiendo las filas. Si en una investigación se necesitan varias selecciones aleatorias, hay que utilizar partes diferentes de la tabla. Existen tablas más extensas en otros textos, por ejemplo en Fisher y Yates (1963).

7. Utilización de ordenadores

La mayoría de los microordenadores y también muchas calculadoras poseen generadores de números aleatorios que los proporcionan en diversos formatos (p. ej., en monodígitos o en pares de dígitos). Estos números pueden utilizarse directamente en lugar de recurrir a la tabla.

Tabla A8. Puntos porcentuales para el test de la suma de rangos de dos muestras de Wilcoxon

Definir n_1 como el menor de los tamaños de las dos muestras ($n_1 \leq n_2$). Calcular T_1 como la suma de rangos de la muestra 1, y $E(T_1) = 1/2n_1(n_1 + n_2 + 1)$. Calcular T' como T_1 si $T_1 \leq E(T_1)$ y como $n_1(n_1 + n_2 + 1) - T_1$ si $T_1 > E(T_1)$. El resultado es significativo al nivel bilateral del 5% (o del 1%) si T' es menor o igual que el valor tabulado superior (o inferior) (siendo la probabilidad real del área de la cola inferior o igual al valor nominal). Si hay empates, el resultado tiene algo más de significación que la señalada aquí.

n_2	p	Tamaño de la muestra menor, n_1												
		4	5	6	7	8	9	10	11	12	13	14	15	
4	0,05	10												
	0,01	—												
5	0,05	11	17											
	0,01	—	15											
6	0,05	12	18	26										
	0,01	10	16	23										
7	0,05	13	20	27	36									
	0,01	10	16	24	32									
8	0,05	14	21	29	38	49								
	0,01	11	17	25	34	43								
9	0,05	14	22	31	40	51	62							
	0,01	11	18	26	35	45	56							
10	0,05	15	23	32	42	53	65	78						
	0,01	12	19	27	37	47	58	71						
11	0,05	16	24	34	44	55	68	81	96					
	0,01	12	20	28	38	49	61	73	87					
12	0,05	17	26	35	46	58	71	84	99	115				
	0,01	13	21	30	40	51	63	76	90	105				
13	0,05	18	27	37	48	60	73	88	103	119	136			
	0,01	13	22	31	41	53	65	79	93	109	125			
14	0,05	19	28	38	50	62	76	91	106	123	141	160		
	0,01	14	22	32	43	54	67	81	96	112	129	147		
15	0,05	20	29	40	52	65	79	94	110	127	145	164	184	
	0,01	15	23	33	44	56	69	84	99	115	133	151	171	

Resumida de *Geigy Scientific Tables* (1982), con permiso de los autores y editores.

Tabla A10. Tabla del tamaño de la muestra para detectar el riesgo relativo en un estudio de caso-control

Esta tabla se emplea para determinar el tamaño de la muestra necesaria para encontrar la razón de probabilidad estadísticamente significativa (test bilateral del 5%) en un estudio de caso-control con un número igual de casos y de controles. La razón de probabilidad especificada se denomina *OR*, y *p* es la proporción de controles que se espera sean expuestos. Para cada par de valores la cifra superior corresponde a un poder del 90%, y la inferior, a un poder del 80%. El tamaño de la muestra tabulado se refiere al número de *casos* necesarios. La tabla se obtiene aplicando (6.13) y (6.10) con una corrección de la continuidad.

Nota: Si $p > 0,5$, trabajar con $p' = 1 - p$ y $OR' = 1/OR$

Proporción de controles expuestos, <i>p</i>	<i>OR</i> (razón de probabilidad)							
	0,5	1,5	2,0	2,5	3,0	4,0	5,0	10,0
0,05	1369	2347	734	393	259	150	105	43
	1044	1775	560	301	200	117	82	34
0,1	701	1266	402	219	146	87	62	27
	534	958	307	168	113	68	48	22
0,15	479	913	295	163	110	67	48	23
	366	691	225	125	85	52	38	19
0,2	370	743	244	136	93	58	43	21
	282	562	187	105	72	45	34	17
0,25	306	647	216	122	85	53	40	21
	233	490	165	94	66	42	32	17
0,3	264	590	200	115	80	51	39	22
	202	447	153	88	62	40	31	18
0,35	236	556	192	111	79	51	39	23
	180	421	147	86	61	40	31	18
0,4	216	538	188	111	79	52	41	24
	165	407	144	85	61	41	32	20
0,45	203	533	189	112	81	54	43	26
	155	403	145	87	63	43	34	21
0,5	194	538	194	116	85	58	46	29
	148	407	148	90	66	45	36	23

- Belsley D. A., Kuh E. and Welsch R. E. (1980) *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. New York: Wiley.
- Benjamin B. (1968) *Health and Vital Statistics*. London: Allen and Unwin.
- Bergen J., Kitchin R. and Berry G. (1992) Predictors of the course of tardive dyskinesia in patients receiving neuroleptics. *Biol. Psychiatry* **32**, 580-594.
- Berkson J. (1944) Application of the logistic function to bio-assay. *J. Am. Stat. Ass.* **39**, 357-365.
- Berkson J. (1950) Are there two regressions? *J. Am. Stat. Ass.* **45**, 164-180.
- Berkson J. and Gage R. P. (1950) Calculation of survival rates for cancer. *Proc. Staff. Meet. Mayo Clin.* **25**, 270-286.
- Berlin J. A., Laird N. M., Sacks H. S. and Chalmers T. C. (1989) A comparison of statistical methods for combining event rates from clinical trials. *Stat. Med.* **8**, 141-151.
- Berry D. A. (1987a) Statistical inference, designing clinical trials, and pharmaceutical company decisions. *Statistician* **36**, 181-189.
- Berry D. A. (1987b) Interim analysis in clinical research. *Cancer Invest.* **5**, 469-477.
- Berry G. (1983) The analysis of mortality by the subject-years method. *Biometrics* **39**, 173-184.
- Berry G. (1986, 1988) Statistical significance and confidence intervals. *Med. J. Aust.* **144**, 618-619; reprinted in *Br. J. Clin. Pract.* **42**, 465-468.
- Berry G., Kitchin R. M. and Mock P. A. (1991) A comparison of two simple hazard ratio estimators based on the logrank test. *Stat. Med.* **10**, 749-755.
- Bliss C. I. (1958) *Periodic Regression in Biology and Climatology*, Bull. No. 615. New Haven: Connecticut Agricultural Experimental Station.
- Boardman T. J. (1974) Confidence intervals for variance components—a comparative Monte Carlo study. *Biometrics* **30**, 251-262.
- Box G. E. P. (1954) Some theorems on quadratic forms applied in the study of analysis of variance problems. II. Effects of inequality of variance and of correlation between errors in the two-way classification. *Ann. Math. Stat.* **25**, 484-498.
- Box G. E. P. and Cox D. R. (1964) An analysis of transformation (with Discussion). *J. R. Stat. Soc. B* **26**, 211-252.
- Box G. E. P. and Jenkins G. M. (1976) *Time Series Analysis: Forecasting and Control*, revised edn. San Francisco: Holden-Day.
- Box G. E. P. and Tiao G. C. (1973) *Bayesian Inference in Statistical Analysis*. Reading, Massachusetts: Addison-Wesley.
- Bradley R. A., Katti S. K. and Coons I. J. (1962) Optimal scaling for ordered categories. *Psychometrika* **27**, 355-374.
- Breslow N. E. (1974) Covariance analysis of censored survival data. *Biometrics* **30**, 89-99.
- Breslow N. E. (1984) Elementary methods of cohort analysis. *Int. J. Epidemiol.* **13**, 112-115.
- Breslow N. (1990) Biostatistics and Bayes (with Discussion). *Stat. Sci.* **5**, 269-298.
- Breslow N. and Day N. E. (1980) *Statistical Methods in Cancer Research, Volume 1—The Analysis of Case-Control Studies*, Scientific Publications No. 32. Lyon: International Agency for Research on Cancer.
- Breslow N. E. and Day N. E. (1987) *Statistical Methods in Cancer Research, Volume 2—The Design and Analysis of Cohort Studies*, Scientific Publications No. 82. Lyon: International Agency for Research on Cancer.
- Breslow N. E. and Liang K. Y. (1982) The variance of the Mantel-Haenszel estimator. *Biometrics* **38**, 943-952.
- Brown A., Mohamed S. D., Montgomery R. D., Armitage P. and Laurence D. R. (1960). Value of a large dose of antitoxin in clinical tetanus. *Lancet* **ii**, 227-230.
- Brown C. C. (1982) On a goodness of fit test for the logistic model based on score statistics. *Commun. Stat.-Theor. Meth.* **11**, 1087-1105.
- Brown M. B. (1992) A test for the difference between two treatments in a continuous measure of outcome when there are dropouts. *Cont. Clin. Trials* **13**, 213-225.
- Buck A. A. and Gart J. J. (1966) Comparison of a screening test and a reference test in epidemiologic studies. I. Indices of agreement and their relation to prevalence. *Am. J. Epidemiol.* **83**, 586-592.
- Bulmer M. G. (1980) *The Mathematical Theory of Quantitative Genetics*. Oxford: Oxford-University Press.

- Buyse M. E., Staquet M. J. and Sylvester R. J. (eds) (1984) *Cancer Clinical Trials: Methods and Practice*. Oxford: Oxford University Press.
- Byar D. P. (1983) Analysis of survival data: Cox and Weibull models with covariates. In *Statistics in Medical Research: Methods and Issues with Applications in Cancer Research*, eds V. Mike and K. Stanley, pp. 365-401. New York: Wiley.
- Casagrande J. T., Pike M. C. and Smith P. G. (1978) The power function of the 'exact' test for comparing two binomial distributions. *Appl. Stat.* **27**, 176-180.
- Chalmers T. C., Berrier J., Sacks H. S., Levin H., Reitman D. and Nagalingan R. (1987) Meta-analysis of clinical trials as a scientific discipline. II: Replicate variability and comparison of studies that agree and disagree. *Stat. Med.* **6**, 733-744.
- Chatfield, C. (1989) *The Analysis of Time Series: An Introduction*, 4th edn. London: Chapman and Hall.
- Chatfield C. and Collins A. J. (1980) *Introduction to Multivariate Analysis*. London: Chapman and Hall.
- Checkoway H., Heyer N. J., Demers P. A. and Breslow N. E. (1993) Mortality among workers in the diatomaceous earth industry. *Br. J. Ind. Med.* **50**, 586-597.
- Chen C.-H. and Wang P. C. (1991) Diagnostic plots in Cox's regression model. *Biometrics* **47**, 841-850.
- Chiang C. L. (1984) *The Life Table and its Applications*. Malabar, Florida: Krieger.
- Clayton D. G. (1991) A Monte Carlo method for Bayesian inference in frailty models. *Biometrics* **47**, 467-485.
- Clayton D. and Cuzick J. (1985) Multivariate generalizations of the proportional hazards model (with Discussion). *J. R. Stat. Soc. A* **148**, 82-117.
- Clayton D. and Kaldor J. (1987) Empirical Bayes estimates of age-standardized relative risks for use in disease mapping. *Biometrics* **43**, 671-681.
- Cochran W. G. (1954) Some methods for strengthening the common χ^2 tests. *Biometrics* **10**, 417-451.
- Cochran W. G. (1977) *Sampling Techniques*, 3rd edn. New York: Wiley.
- Cochran W. G. and Cox G. M. (1957) *Experimental Designs*, 2nd edn. New York: Wiley.
- Cochrane A. L. (1972) *Effectiveness and Efficiency: Random Reflections on Health Services*. London: Nuffield Provincial Hospitals Trust.
- Cockburn R., Belton R., Purvis R. J., Giles M. M., Brown J. K., Turner T. L., Wilkinson E. M., Forfar J. O., Barrie W. J. M., McKay G. S. and Pocock S. J. (1980) Maternal vitamin D intake and mineral metabolism in mothers and their newborn infants. *Br. Med. J.* **281**, 11-14.
- Cockcroft A., Edwards J., Bevan C., Campbell L., Collins G., Houston K., Jenkins D., Latham S., Saunders M. and Trotman D. (1981) An investigation of operating theatre staff exposed to humidifier fever antigens. *Br. J. Ind. Med.* **38**, 144-151.
- Cockcroft A., Berry G., Brown E. B. and Exall C. (1982) Psychological changes during a controlled trial of rehabilitation in chronic respiratory disability. *Thorax* **37**, 413-416.
- Cody R. P. and Smith J. K. (1991) *Applied Statistics and the SAS Programming Language*, 3rd edn. New York: North-Holland.
- Cohen J. (1960) A coefficient of agreement for nominal scales. *Educ. Psychol. Meas.* **20**, 37-46.
- Cohen J. (1968) Weighted kappa: nominal scale agreement with provision for scale disagreement or partial credit. *Psychol. Bull.* **70**, 213-220.
- Cole T. J., Morley C. J., Thornton A. J. and Fowler M. A. (1991) A scoring system to quantify illness in babies under 6 months of age. *J. R. Stat. Soc. A* **154**, 287-304.
- Coleman M., Douglas A., Hermon C. and Peto J. (1986) Cohort study analysis with a FORTRAN computer program. *Int. J. Epidemiol.* **15**, 134-137.
- Collins R. L. and Meckler R. J. (1965) Histology and weight of the mouse adrenal: a diallel genetic study. *J. Endocrinol.* **31**, 95-105.
- Computing Resource Center (1992) *Stata Reference Manual: Release 3*, 5th edn. Santa Monica, California: Computing Resource Center.
- Connor R. J. (1987) Sample size for testing differences in proportions for the paired-sample design. *Biometrics* **43**, 207-211.
- Conover W. J. (1980) *Practical Nonparametric Statistics*, 2nd edn. New York: Wiley.

- Cook P., Doll R. and Fellingham S.A. (1969) A mathematical model for the age distribution of cancer in man. *Int. J. Cancer* **4**, 93-112.
- Cook R. D. (1977) Detection of influential observations in linear regression. *Technometrics* **19**, 15-18.
- Cook R. D. and Weisberg S. (1982) *Residuals and Influence in Regression*. New York and London: Chapman and Hall.
- Cookson W. O. C. M., de Klerk N. H., Musk A. W., Armstrong B. K., Glancy J. J. and Hobbs M. S. T. (1986) Prevalence of radiographic asbestosis in crocidolite miners and millers at Wittenoom, Western Australia. *Br. J. Ind. Med.* **43**, 450-457.
- Cornfield J. (1956) A statistical property arising from retrospective studies. *Proc. Third Berkeley Symp. Math. Stat. Prob.* **4**, 135-148.
- Cox D. R. (1958) *Planning of Experiments*. New York: Wiley.
- Cox D. R. (1972) Regression models and life-tables (with Discussion). *J. R. Stat. Soc. B* **34**, 187-220.
- Cox D. R. and Oakes D. (1984) *Analysis of Survival Data*. London: Chapman and Hall.
- Cox D. R. and Snell E. J. (1989) *Analysis of Binary Data*, 2nd edn. London: Chapman and Hall.
- Cramer H. (1946) *Mathematical Methods of Statistics*. Princeton: Princeton University Press.
- Cutler S. J. and Ederer F. (1958) Maximum utilization of the life table method in analysing survival. *J. Chron. Dis.* **8**, 699-712.
- Cuzick J. and Edwards R. (1990) Spatial clustering for inhomogeneous populations (with Discussion). *J. R. Stat. Soc. B* **52**, 73-104.
- CYTEL Software Corporation (1991) *Stat Xact—Statistical Software for Exact Nonparametric Inference, User Manual Version 2* Cambridge, Massachusetts: CYTEL Software Corporation.
- Daniel C. (1959) Use of half-normal plots in interpreting factorial two-level experiments. *Technometrics* **1**, 311-341.
- Darby S. C. and Fearn T. (1979) The Chatham Blood Pressure Study. An application of Bayesian growth curve models to a longitudinal study of blood pressure in children. *Int. J. Epidemiol.* **8**, 15-21.
- Darby S. C. and Reissland J. A. (1981) Low levels of ionizing radiation and cancer—are we underestimating the risk? (with Discussion). *J. R. Stat. Soc. A* **144**, 298-331.
- David F. N. and Barton D. E. (1966) Two space-time interaction tests for epidemicity. *Br. J. Prev. Soc. Med.* **20**, 44-48.
- Day N. E. and Walter S. D. (1984) Simplified models of screening for chronic disease: estimation procedures from mass screening programmes. *Biometrics* **40**, 1-14.
- Dean A. G., Dean J. A., Burton A. H. and Dicker R. C. (1990) *Epi Info, Version 5: a Word Processing, Database, and Statistics Program for Epidemiology on Microcomputers*. Stone Mountain, Georgia: USD, Incorporated.
- DerSimonian R. and Laird N. (1986) Meta-analysis in clinical trials. *Cont. Clin. Trials* **7**, 177-188.
- Diamond E. L. and Lilienfeld A. M. (1962a) Effects of errors in classification and diagnosis in various types of epidemiological studies. *Am. J. Public Health* **52**, 1137-1144.
- Diamond E. L. and Lilienfeld A. M. (1962b) Misclassification errors in 2 x 2 tables with one margin fixed: some further comments. *Am. J. Public Health* **52**, 2106-2110.
- Diggle P. J. (1990) *Time Series—A Biostatistical Introduction*. Oxford: Clarendon Press.
- Dixon W. J. (chief ed.) (1990) *BMDP Statistical Software Manual, Volumes 1 & 2*. Los Angeles: University of California Press.
- Dobson A. J. (1990) *An Introduction to Generalized Linear Models*. London: Chapman and Hall.
- Dobson A. J., Kuulasmaa K., Eberle E. and Scherer J. (1991) Confidence intervals for weighted sums of Poisson parameters. *Stat. Med.* **10**, 457-462.
- Doll R. (1952) The causes of death among gas-workers with special reference to cancer of the lung. *Br. J. Ind. Med.* **9**, 180-185.
- Doll R. and Hill A. Bradford (1950) Smoking and carcinoma of the lung. Preliminary report. *Br. Med. J.* **ii**, 739-748.
- Doll R. and Hill A. Bradford (1954) The mortality of doctors in relation to their smoking habits. A preliminary report. *Br. Med. J.* **i**, 1451-1455.
- Doll R. and Hill A. Bradford (1956) Lung cancer and other causes of death in relation to smoking. A second report on the mortality of British doctors. *Br. Med. J.* **ii**, 1071-1081.

- Freedman L. S., Lowe D. and Macaskill P. (1984) Stopping rules for clinical trials incorporating clinical opinion. *Biometrics* **40**, 575-586.
- Freeman D. H. and Holford T. R. (1980) Summary rates. *Biometrics* **36**, 195-205.
- Freund R. J., Littell R. C. and Spector P. C. (1986) *SAS System for Linear Models, 1986 Edition*. Cary: SAS Institute Inc.
- Friedman L. M., Furberg C. D. and DeMets D. L. (1985) *Fundamentals of Clinical Trials*, 2nd edn. Boston: Wright.
- Friedman M. (1937) The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *J. Am. Stat. Ass.* **32**, 675-701.
- Gardner M. J. (1989) Review of reported increases of childhood cancer rates in the vicinity of nuclear installations in the UK. *J. R. Stat. Soc. A* **152**, 307-325.
- Gardner M. J. and Altman D. G. (eds) (1989) *Statistics with Confidence: Confidence Intervals and Statistical Guidelines*. London: British Medical Journal.
- Gardner M. J. and Haddy J. A. (1973) Some effects of within-person variability in epidemiological studies. *J. Chron. Dis* **26**, 781-795.
- Gart J. J. (1962) On the combination of relative risks. *Biometrics* **18**, 601-610.
- Gart J. J. (1968) A simple nearly efficient alternative to the simple sib method in the complete ascertainment case. *Ann. Hum. Genet.* **31**, 283-291.
- Gart J. J. and Buck A. A. (1966) Comparison of a screening test and a reference test in epidemiologic studies. II. A probabilistic model for the comparison of diagnostic tests. *Am. J. Epidemiol.* **83**, 593-602.
- Gart J. J. and Nam J. (1988) Approximate interval estimation of the ratio of binomial parameters: a review and corrections for skewness. *Biometrics* **44**, 323-338.
- Gart J. J. and Nam J. (1990) Approximate interval estimation of the difference in binomial parameters: correction for skewness and extension to multiple tables. *Biometrics* **46**, 637-643.
- Geary D. N., Huntington E. and Gilbert R. J. (1992) Analysis of multivariate data from four dental clinical trials. *J. R. Stat. Soc. A* **155**, 77-89.
- Gebski V., Leung O., McNeil D. and Lunn D. (1992) *SPIDA User's Manual, Version 6*. Eastwood, New South Wales: Statistical Computing Laboratory.
- Geigy Scientific Tables (1982) Vol. 2: *Introduction to Statistics, Statistical Tables, Mathematical Formulae*, 8th edn. Basle: Ciba-Geigy.
- Genstat 5 Committee (1987) *Genstat 5: Reference Manual*. Oxford: Clarendon Press.
- Gevens A. S. (1980) Pattern recognition of human brain electrical potentials. *IEEE Trans. Patt. Anal. Mach. Intell.* **PAMI-2**, 383-404.
- Glasser M. (1967) Exponential survival with covariance. *J. Am. Stat. Ass.* **62**, 561-568.
- Glasziou P. P. and Schwartz (1991) Clinical decision analysis. *Med. J. Aust.* **154**, 105-110.
- Goldstein H. (1979) *The Design and Analysis of Longitudinal Studies*. London: Academic Press.
- Good I. J. (1950) *Probability and the Weighing of Evidence*. London: Griffin.
- Greenacre M. J. (1984) *Theory and Applications of Correspondence Analysis*. London: Academic Press.
- Greenhouse S. W. and Geisser S. (1959) On methods in the analysis of profile data. *Psychometrika* **24**, 95-112.
- Greenhouse S. W. and Mantel N. (1950) The evaluation of diagnostic tests. *Biometrics* **6**, 399-412.
- Greenland S. (1987) Variance estimators for attributable fraction estimates consistent in both large strata and sparse data. *Stat. Med.* **6**, 701-708.
- Greenland S. and Salvendy A. (1990) Bias in the one-step (Peto) method for pooling study results. *Stat. Med.* **9**, 247-252.
- Greenwood M. (1926) *The Natural Duration of Cancer*. Rep. Publ. Hlth. Med. Subj., No. 33. London: HM Stationery Office.
- Grizzle J. E. and Allen D. M. (1969) Analysis of growth and dose response curves. *Biometrics* **25**, 357-381.
- Grossman J., Parmar M. K. B., Spiegelhalter D. J. and Freedman L. S. (1994) A unified method for monitoring and analysing controlled trials. *Stat. Med.* **13**.
- Haenszel W. (1959) Some problems in the estimation of familial risks of disease. *J. Nat. Cancer Inst.* **23**, 487-505.

- Hauck W. W. (1979) The large sample variance of the Mantel-Haenszel estimator of a common odds ratio. *Biometrics* **35**, 817-819.
- Hayhoe F. G. J., Quaglino D. and Doll R. (1964) *The Cytology and Cyto-chemistry of Acute Leukaemias*. Med. Res. Coun. Spec. Rep. Ser., No. 304. London: HM Stationery Office.
- Healy M. J. R. (1952) Some statistical aspects of anthropometry. *J. R. Stat. Soc. B* **14**, 164-177.
- Healy M. J. R. (1963) Fitting a quadratic. *Biometrics* **19**, 362-363.
- Healy M. J. R. (1981) Some problems of repeated measurements (with Discussion). In *Perspectives in Medical Statistics*, eds J. F. Bithell and R. Coppi, pp. 155-171. London: Academic Press.
- Healy M. J. R. (1984) The use of R^2 as a measure of goodness of fit. *J. R. Stat. Soc. A* **147**, 608-609.
- Hennekens C.H., Buring J.E. and Mayrent S. L. (eds) (1987) *Epidemiology in Medicine*. Boston: Little, Brown.
- Hill A. Bradford (1962) *Statistical Methods in Clinical and Preventive Medicine*. Edinburgh: Livingstone.
- Hill A. Bradford and Hill I. D. (1991) *Bradford Hill's Principles of Medical Statistics*, 12th edn. London: Arnold.
- Hill D. J., White V. M. and Gray N. J. (1991) Australian patterns of tobacco smoking in 1989. *Med. J. Aust.* **154**, 797-801.
- Hills M. (1966) Allocation rules and their error rates. *J. R. Stat. Soc. B*, **28**, 1-20.
- Hills M. (1968) A note on the analysis of growth curves. *Biometrics* **24**, 192-196.
- Hills M. and Armitage P. (1979) The two-period cross-over clinical trial. *Br. J. Clin. Pharmacol.* **8**, 7-20.
- Hirji K. F. (1991) A comparison of exact, mid-P, and score tests for matched case-control studies. *Biometrics* **47**, 487-496.
- Hirji K. F., Mehta C. R. and Patel N. R. (1988) Exact inference for matched case-control studies. *Biometrics* **44**, 803-814.
- Holford T. R. (1976) Life tables with concomitant information. *Biometrics* **32**, 587-597.
- Hosmer D. W. and Lemeshow S. (1989) *Applied Logistic Regression*. New York: Wiley.
- Ipsen J. (1955) Appropriate scores in bio-assays using death-times and survivor symptoms. *Biometrics* **11**, 465-480.
- Irwig L., Turnbull D. and McMurchie M. (1990) A randomised trial of general practitioner-written invitations to encourage attendance at screening mammography. *Community Health Stud.* **14**, 357-364.
- Irwig L., Glasziou P., Wilson A. and Macaskill P. (1991) Estimating an individual's true cholesterol level and response to intervention. *J. Am. Med. Ass.* **266**, 1678-1685.
- James G. S. (1951) The comparison of several groups of observations when the ratios of the population variances are unknown. *Biometrika* **38**, 324-329.
- Jeffreys H. (1961) *Theory of Probability*, 3rd edn. Oxford: Clarendon Press.
- Jennison C. and Turnbull B. W. (1990) Interim monitoring of clinical trials. *Stat. Sci.* **5**, 299-317.
- Johnson W. D. and George V. T. (1991) Effect of regression to the mean in the presence of within-subject variability. *Stat. Med.* **10**, 1295-1302.
- Jones B. and Kenward M. G. (1989) *Design and Analysis of Cross-Over Trials*. London: Chapman and Hall.
- Kalbfleisch J. D. and Prentice R. L. (1980) *The Statistical Analysis of Failure Time Data*. New York: Wiley.
- Kalton G. (1968) Standardization: a technique to control for extraneous variables. *Appl. Stat.* **17**, 118-136.
- Kaplan E. L. and Meier P. (1958) Nonparametric estimation from incomplete observations. *J. Am. Stat. Ass.* **53**, 457-481.
- Kay R. (1977) Proportional hazard regression models and the analysis of censored survival data. *Appl. Statist.* **26**, 227-237.
- Kelsey J. L., Thompson W. D. and Evans A. S. (1986) *Methods in Observational Epidemiology*. New York: Oxford University Press.
- Kendall M. G. (1951, 1952) Regression, structure and functional relationship. Part I. *Biometrika* **38**, 11-25; Part II, *Biometrika* **39**, 96-108.
- Kendall M. G. (1980) *Multivariate Analysis*, 2nd edn. London: Griffin.
- Kendall M. G. and Gibbons J. D. (1990) *Rank Correlation Methods*, 5th edn. London: Arnold.
- Keuls M. (1952) The use of 'Studentized range' in connection with an analysis of variance. *Euphytica* **1**, 112-122.
- Kim K. and DeMets D. L. (1992) Sample size determination for group sequential clinical trials with immediate response. *Stat. Med.* **11**, 1391-1399.
- King E. P. (1963) A statistical design for drug screening. *Biometrics* **19**, 429-440.

- Kleinbaum D. G., Kupper L. L. and Morgenstern H. (1982) *Epidemiologic Research-Principles and Quantitative Methods*. Belmont, California: Lifetime Learning Publications.
- Kleinbaum D. G., Kupper L. L. and Muller K. E. (1988) *Applied Regression Analysis and Other Multivariable Methods*, 2nd edn. Boston: PWS-Kent.
- Klotz J. H. (1964) On the normal scores two-sample rank test. *J. Am. Stat. Ass.* **59**, 652-664.
- Knox E. G. (1964) Epidemiology of childhood leukaemia in Northumberland and Durham. *Br. J. Prev. Soc. Med.* **18**, 17-24.
- Koopman P. A. R. (1984) Confidence intervals for the ratio of two binomial proportions. *Biometrics* **40**, 513-517.
- Kruskal W. H. and Wallis W. A. (1952) Use of ranks in one-criterion variance analysis. *J. Am. Stat. Ass.* **47**, 583-621.
- Krzanowski W. J. (1988) *Principles of Multivariate Analysis: A User's Perspective*. Oxford: Clarendon Press.
- Kuritz S. J. and Landis J. R. (1988) Attributable risk estimation from matched case-control data. *Biometrics* **44**, 355-367.
- Kuritz S. J., Landis J. R. and Koch G. G. (1988) A general overview of Mantel-Haenszel methods: applications and recent developments. *Ann. Rev. Public Health* **9**, 123-160.
- Lan K. K. G. and DeMets D. L. (1983) Discrete sequential boundaries for clinical trials. *Biometrika* **70**, 659-663.
- Lan K. K. G., Simon R. and Halperin M. (1982) Stochastically curtailed tests in long-term clinical trials. *Commun. Stat. C* **1**, 207-219.
- Lan K. K. G., DeMets D. L. and Halperin M. (1984) More flexible sequential and non-sequential designs in long-term clinical trials. *Commun. Stat.-Theor. Meth* **13**, 2339-2353.
- Lancaster H. O. (1950) Statistical control in haematology. *J. Hyg. Camb.* **48**, 402-417.
- Lancaster H. O. (1952) Statistical control of counting experiments. *Biometrika* **39**, 419-422.
- Lancaster H. O. (1961) Significance tests in discrete distributions. *J. Am. Stat. Ass.* **56**, 223-234.
- Lancaster H. O. (1965) Symmetry in multivariate distributions. *Aust. J. Stat.* **7**, 115-126.
- Lawless J. F. (1982) *Statistical Models and Methods for Lifetime Data*. New York: Wiley.
- Lawley D. N. and Maxwell A. E. (1971) *Factor Analysis as a Statistical Method*, 2nd edn. London: Butterworths.
- Lee P. M. (1989) *Bayesian Statistics: an Introduction*. London: Arnold.
- Lehmann E. L. (1975) *Nonparametrics: Statistical Methods Based on Ranks*. San Francisco: Holden-Day.
- Lemeshow S. and Hosmer D. W. (1982) A review of goodness of fit statistics for use in the development of logistic regression models. *Am. J. Epidemiol.* **115**, 92-106.
- Lemeshow S., Hosmer D. W., Klar J. and Lwanga S. K. (1990) *Adequacy of Sample Size in Health Studies*. Chichester: Wiley.
- Levin M. L. (1953) The occurrence of lung cancer in man. *Acta Un. Int. Cancer* **9**, 531-541.
- Liddell F. D. K. (1960) The measurement of occupational mortality. *Br. J. Ind. Med.* **17**, 228-233.
- Liddell F. D. K. (1983) Simplified exact analysis of case-referent studies: matched pairs; dichotomous exposure. *J. Epidemiol. Community Health* **37**, 82-84.
- Liddell F. D. K. (1984) Simple exact analysis of the standardized mortality ratio. *J. Epidemiol. Community Health* **38**, 85-88.
- Liddell F. D. K. (1988) The development of cohort studies in epidemiology: a review. *J. Clin. Epidemiol.* **41**, 1217-1237.
- Liddell F. D. K., McDonald J. C. and Thomas D. C. (1977) Methods of cohort analysis: appraisal by application to asbestos mining (with Discussion). *J. R. Stat. Soc. A* **140**, 469-491.
- Liddell F. D. K., Thomas D. C., Gibbs G. W. and McDonald J. C. (1984) Fibre exposure and mortality from pneumoconiosis, respiratory and abdominal malignancies in chrysotile production in Quebec, 1926-75. *Ann. Acad. Med.* **13** (Suppl), 340-342.
- Lin L. I.-K. (1992) Assay validation using the concordance correlation coefficient. *Biometrics* **48**, 599-604.
- Lindley D. V. (1965) *Introduction to Probability and Statistics from a Bayesian Viewpoint. Part 1. Probability. Part 2. Inference*. Cambridge: Cambridge University Press.
- Little R. J. and Pullum T. W. (1979) The general linear model and direct standardization—a comparison. *Sociol. Meth. Res.* **7**, 475-501.

- Lloyd S. and Roberts C. J. (1973) A test for space clustering and its application to congenital limb defects in Cardiff. *Br. J. Prev. Soc. Med.* **27**, 188-191.
- Lombard H. L. and Doering C. R. (1947) Treatment of the four-fold table by partial correlation as it relates to public health problems. *Biometrics* **3**, 123-128.
- McCullagh P. and Nelder J. A. (1989) *Generalized Linear Models*, 2nd edn. London: Chapman and Hall.
- McGilchrist C. A. and Aisbett C. W. (1991) Regression with frailty in survival analysis. *Biometrics* **47**, 461-466.
- McKelvey M., Gottlieb J. A., Wilson H. E., Haut A., Talley R., Stephens R., Lane M., Gamble J., Jones S. E., Grozea P., Gutterman J., Coltman C. and Moon T. E. (1976) Hydroxyldaunomycin (Adriamycin) combination chemotherapy in malignant lymphoma. *Cancer* **38**, 1484-1493.
- MacKie R., Hunter J. A. A., Aitchison T. C., Hole D., McLaren K., Rankin R., Blessing K., Evans A. T., Hutcheon A. W., Jones D. H., Soutar D. S., Watson A. C. H., Cornbleet M. A. and Smyth J. F. for the Scottish Melanoma Group (1992) Cutaneous malignant melanoma, Scotland, 1979-89. *Lancet* **339**, 971-975.
- Machin D. and Campbell M. J. (1987) *Statistical Tables for the Design of Clinical Trials*. Oxford: Blackwell Scientific Publications.
- Machin D. and Gardner M. J. (1989) Calculating confidence intervals for survival time analyses. In *Statistics with Confidence-Confidence Intervals and Statistical Guidelines*, eds M. J. Gardner and D. G. Altman, pp. 64-70. London: British Medical Journal.
- Macklin J. (1990) *Setting the Agenda for Change*. Background Paper, 1. Melbourne: National Health Strategy.
- Makuch R. and Simon R. (1978) Sample size requirements for evaluating a conservative therapy. *Cancer Treat. Rep.* **62**, 1037-1040.
- Mantel N. (1963) Chi-square tests with one degree of freedom: extensions of the Mantel-Haenszel procedure. *J. Am. Stat. Ass.* **58**, 690-700.
- Mantel N. (1966) Evaluation of survival data and two new rank order statistics arising in its consideration. *Cancer Chemother. Rep.* **50**, 163-170.
- Mantel N. (1967) The detection of disease clustering and a generalized regression approach. *Cancer Res.* **27**, 209-220.
- Mantel N. (1973) Synthetic retrospective studies and related topics. *Biometrics* **29**, 479-486.
- Mantel N. and Haenszel W. (1959) Statistical aspects of the analysis of data from retrospective studies of disease. *J. Nat. Cancer Inst.* **22**, 719-748.
- Mardia K. V., Kent J. T. and Bibby J. M. (1979) *Multivariate Analysis*. London: Academic Press.
- Marks R. G. (1982) Measuring the correlation between time series of hormonal data. *Stat. Med.* **1**, 49-57.
- Marriott F. H. C. (1974) *The Interpretation of Multiple Observations*. London: Academic Press.
- Marshall J. (1964) A trial of long-term hypotensive therapy in cerebrovascular disease. *Lancet* **i**, 10-12.
- Marshall R. J. (1991) Mapping disease and mortality rates using empirical Bayes estimators. *Appl. Stat.* **40**, 283-294.
- Martin W. J. (1949) *The Physique of Young Adult Males*. Med. Res. Coun. Mem., No. 20. London: HM Stationery Office.
- Matthews J. N. S., Altman D. G., Campbell M. J. and Royston P. (1990) Analysis of serial measurements in medical research. *Br. Med. J.* **300**, 230-235.
- Medical Research Council (1950) Treatment of pulmonary tuberculosis with streptomycin and para-amino-salicylic acid. *Br. Med. J.* **ii**, 1073-1085.
- Mee R. W. (1984) Confidence bounds for the difference between two probabilities. *Biometrics* **40**, 1175-1176.
- Mehta C. R. and Patel N. R. (1983) A network algorithm for performing Fisher's exact test in $r \times c$ contingency tables. *J. Am. Stat. Ass.* **78**, 427-434.
- Mehta C. R., Patel N. R. and Gray R. (1985) Computing an exact confidence interval for the common odds ratio in several 2 by 2 contingency tables. *J. Am. Stat. Ass.* **80**, 969-973.
- Meier P. (1975) Statistics and medical experimentation. *Biometrics* **31**, 511-529.
- Merrell M. and Shulman L. E. (1955) Determination of prognosis in chronic disease, illustrated by systemic lupus erythematosus. *J. Chron. Dis.* **1**, 12-32.
- Miettinen O. S. (1969) Individual matching with multiple controls in the case of all-or-none responses. *Biometrics* **25**, 339-355.

- Miettinen O. S. (1970) Estimation of relative risk from individually matched series. *Biometrics* **26**, 75-86.
- Miettinen O. S. (1976) Estimability and estimation in case-referent studies. *Am. J. Epidemiol.* **103**, 226-235.
- Miettinen O. S. (1985) *Theoretical Epidemiology: Principles of Occurrence Research in Medicine*. New York: Wiley.
- Miettinen O. and Nurminen M. (1985) Comparative analysis of two rates. *Stat. Med.* **4**, 213-226.
- Miller R. G., Jr. (1981) *Simultaneous Statistical Inference*, 2nd edn. New York: Springer-Verlag.
- Minitab Inc. (1991) *Minitab Reference Manual, PC Version, Release 8*. State College, Pennsylvania: Minitab Inc.
- Morrison D. F. (1976) *Multivariate Statistical Methods*, 2nd edn. New York: McGraw-Hill.
- Moser C. A. and Kalton G. (1971) *Survey Methods in Social Investigation*, 2nd edn. London: Heinemann.
- Moses L.E. and Oakford R.V. (1963) *Tables of Random Permutations*. London: Allen and Unwin.
- MRC Vitamin Study Group (1991) Prevention of neural tube defects: results of the Medical Research Council Vitamin Study. *Lancet* **338**, 131-137.
- Murdoch J and Barnes J.A. (1968) *Statistical Tables for Science, Engineering and Management*. London: Macmillan.
- Nam J. (1987) A simple approximation for calculating sample sizes for detecting linear trend in proportions. *Biometrics* **43**, 701-705.
- National Bureau of Standards (1950) *Tables of the Binomial Probability Distribution*. Applied Mathematics Series No. 7. Washington: US Dept of Commerce.
- Naylor A. F. (1964) Comparisons of regression constants fitted by maximum likelihood to four common transformations of binomial data. *Ann. Hum. Genet.* **27**, 241-246.
- Nelder J. A. and Wedderburn R. W. M. (1972) Generalized linear models. *J. R. Stat. Soc. A* **135**, 370-384.
- Newell D. J. (1962) Errors in the interpretation of errors in epidemiology. *Am. J. Public Health* **52**, 1925-1928.
- Newell D. J., Greenberg B. G., Williams T. F. and Veazey P. B. (1961) Use of cohort life tables in family studies of disease. *J. Chron. Dis.* **13**, 439-452.
- Newhouse M. L., Berry G. and Wagner J. C. (1985) Mortality of factory workers in east London 1933-80. *Br. J. Ind. Med.* **42**, 4-11.
- Newman D. (1939) The distribution of range in samples from a normal population, expressed in terms of an independent estimate of standard deviation. *Biometrika* **31**, 20-30.
- O'Brien P. C. and Fleming T. R. (1979) A multiple testing procedure for clinical trials. *Biometrics* **35**, 549-556.
- Oldham P. D. (1968) *Measurement in Medicine: the Interpretation of Numerical Data*. London: English Universities Press.
- Owen D. B. (1962) *Handbook of Statistical Tables*. London: Pergamon.
- Parker R. A. and Bregman D. J. (1986) Sample size for individually matched case-control studies. *Biometrics* **42**, 919-926.
- Pauker S. G. and Kassirer J. P. (1992) Decision analysis. In *Medical Uses of Statistics*, 2nd edn., eds J. C. Bailar III and F. Mosteller, pp. 159-179. Boston: NEJM Books.
- Pearce S. C. (1965) *Biological Statistics: an Introduction*. New York: McGraw-Hill.
- Pearson E. S. and Hartley H. O. (1966) *Biometrika Tables for Statisticians, Vol. 1*, 3rd edn. Cambridge: Cambridge University Press.
- Peto R. and Pike M. C. (1973) Conservatism of the approximation $\sum(0 - E)_i^2/E$ in the logrank test for survival data or tumor incidence data. *Biometrics* **29**, 579-584.
- Peto R., Pike M. C., Armitage P., Breslow N. E., Cox D. R., Howard S. V., Mantel N., McPherson K., Peto J. and Smith P. G. (1976, 1977) Design and analysis of randomized clinical trials requiring prolonged observation of each patient. I. Introduction and design. *Br. J. Cancer* **34**, 585-612; II. Analysis and examples. *Br. J. Cancer* **35**, 1-39.
- Pike M. C. (1996) A method of analysis of a certain class of experiments in carcinogenesis. *Biometrics* **22**, 142-161.
- Pike M. C. and Morrow R. H. (1970) Statistical analysis of patient-control studies in epidemiology-factor under investigation an all-or-none variable. *Br. J. Prev. Soc. Med.* **24**, 42-44.
- Pike M. C. and Smith P. G. (1968) Disease clustering: a generalization of Knox's approach to the detection of space-time interactions. *Biometrics* **24**, 541-556.

- Smith C. E. Gordon, Turner L. H. and Armitage P. (1962) Yellow fever vaccination in Malaya by subcutaneous injection and multiple puncture. *Bull. World Health Org.* **27**, 717-727.
- Smith P. G. (1982) Spatial and temporal clustering. In *Cancer Epidemiology and Prevention*, eds D. Schottenfeld and J. F. Fraumeni, Chap. 22, pp. 391-407. Philadelphia: Saunders.
- Smith P. G. and Pike M. C. (1974) A note on a 'close pairs' test for space clustering. *Br. J. Prev. Soc. Med.* **28**, 63-64.
- Sneath P. H. A. and Sokal R. R. (1973) *Numerical Taxonomy*. San Francisco: Freeman.
- Snedecor G. W. and Cochran W. G. (1989) *Statistical Methods*, 8th edn. Ames: Iowa State University Press.
- Snell E. S. and Armitage P. (1957) Clinical comparison of diamorphine and pholcodine as cough suppressants, by a new method of sequential analysis. *Lancet* **i**, 860-862.
- Solomon P. J. (1984) Effect of misspecification of regression models in the analysis of survival data. *Biometrika* **71**, 291-298.
- Spiegelhalter D. J. and Freedman L. S. (1988) Bayesian approaches to clinical trials (with Discussion). In *Bayesian Statistics, 3*, eds J. M. Bernardo, M. H. DeGroot, D. V. Lindley and A. F. M. Smith, pp. 453-477. Oxford: Oxford University Press.
- Spiegelhalter D. J. and Knill-Jones R. P. (1984) Statistical and knowledge-based approaches to clinical decision-support systems, with an application to gastroenterology (with Discussion). *J. R. Stat. Soc. A* **147**, 35-76.
- Spiegelhalter D. J., Freedman L. S. and Blackburn P. R. (1986) Monitoring clinical trials; conditional or predictive power? *Cont. Clin. Trials* **7**, 8-17.
- Sprent P. (1969) *Models in Regression and Related Topics*. London: Methuen.
- SPSS Inc. (1990) *SPSS Reference Guide*. Chicago: SPSS.
- Statistics and Epidemiology Research Corporation (1988) *EGRET-Users' Manual*. Seattle: Statistics and Epidemiology Research Corporation.
- Stuart A. and Ord J. K. (1983) *Kendall's Advanced Theory of Statistics*, Vol. 3. London: Arnold.
- 'Student' (W. S. Gosset) (1907) On the error of counting with a haemocytometer. *Biometrika* **5**, 351-360.
- Sutherland I. (1946) The stillbirth-rate in England and Wales in relation to social influences. *Lancet* **ii**, 953-956.
- Therneau T. M., Grambsch P. M. and Fleming T. R. (1990) Martingale-based residuals for survival models. *Biometrika* **77**, 147-60.
- Trimble I. M. G., West M., Knapp M. S., Pownall R. and Smith A. F. M. (1983) Detection of renal allograft rejection by computer. *Br. Med. J.* **286**, 1695-1699.
- Truett J., Cornfield J. and Kannel W. (1967) A multivariate analysis of the risk of coronary heart disease in Framingham. *J. Chron. Dis.* **20**, 511-524.
- Tudehope D. I., Iredell J., Rodgers D. and Gunn A. (1986) Neonatal death: grieving families. *Med. J. Aust.* **144**, 290-292.
- Tukey J. W. (1977) *Exploratory Data Analysis*. Reading, Massachusetts: Addison-Wesley.
- Upton G. J. G. (1992) Fisher's exact test. *J. R. Stat. Soc. A* **155**, 395-402.
- van Elteren P. H. (1960) On the combination of independent two-sample tests of Wilcoxon. *Bull. Inst. Int. Statist.* **37**, 351-361.
- Wald A. (1947) *Sequential Analysis*. New York: Wiley.
- Walter S. D. (1975) The distribution of Levin's measure of attributable risk. *Biometrika* **62**, 371-374.
- Walter S. D. and Day N. E. (1983) Estimation of the duration of a preclinical state using screening data. *Am. J. Epidemiol.* **118**, 865-886.
- Walter S. D. and Elwood J. M. (1975) A test for seasonality of events with a variable population at risk. *Br. J. Prev. Soc. Med.* **29**, 18-21.
- Warner H. R., Toronto A. F., Veasey L. G. and Stephenson R. (1961) A mathematical approach to medical diagnosis. *J. Am. Med. Ass.* **177**, 177-183.
- Weatherall J. A. C. and Haskey J. C. (1976) Surveillance of malformations. *Br. Med. Bull.* **32**, 39-44.
- Weinstein M. C. and Fineberg H. V. (1980) *Clinical Decision Analysis*. Philadelphia: Saunders.
- Welch B. L. (1951) On the comparison of several mean values: an alternative approach. *Biometrika* **38**, 330-336.
- Wetherill G. B. (1981) *Intermediate Statistical Methods*. London: Chapman and Hall.

- Wetherill G. B., Duncombe P., Kenward M., Köllerström J., Paul S. R. and Vowden B. J. (1986) *Regression Analysis with Applications*. London: Chapman and Hall.
- Whitehead A. and Whitehead J. (1991) A general parametric approach to the meta-analysis of randomized clinical trials. *Stat. Med.* **10**, 1665-1677.
- Whitehead J. (1992) *The Design and Analysis of Sequential Clinical Trials*, 2nd edn. Chichester: Horwood.
- Whittemore A. S. (1983) Estimating attributable risk from case-control studies. *Am J. Epidemiol.* **117**, 76-85.
- WHO Collaborative Study of Neoplasia and Steroid Contraceptives (1990) Breast cancer and combined oral contraceptives results from a multinational study. *Br. J. Cancer* **61**, 110-119.
- Wilcocks W. J. and Lancaster H. O. (1951) Maternal mortality in New South Wales with special reference to age and parity. *J. Obstet. Gynaec. Br. Emp.* **58**, 945-960.
- Wilcoxon F. (1945) Individual comparisons by ranking methods. *Biometrics Bull.* **1**, 80-83.
- Wilkinson L. (1990) *SYSTAT: The System for Statistics*. Evanston, Illinois: SYSTAT, Inc.
- Williams D. A. (1988) Tests for differences between several small proportions. *Appl. Stat.* **37**, 421-434.
- Wilson P. D., Hebel J. R. and Sherwin R. (1981) Screening and diagnosis when within-individual observations are Markov-dependent. *Biometrics* **37**, 553-565.
- Wilson P. W. and Kullman E. D. (1931) A statistical inquiry into methods for estimating numbers of rhizobia. *J. Bacteriol.* **22**, 71-90.
- Woolf B. (1955) On estimating the relation between blood group and disease. *Ann. Hum. Genet.* **19**, 251-253.
- Woolson R. F., Bean J. A. and Rojas P. B. (1986) Sample size for case-control studies using Cochran's statistic. *Biometrics* **42**, 927-932.
- World Health Organization (1966) *Sampling Methods in Morbidity Surveys and Public Health Investigations*. Technical Report Series No. 336. Geneva: WHO.
- World Health Organization (1978) *Manual of the International Statistical Classification of Diseases, Injuries and Causes of Death*, 9th revision, Vols 1 and 2. Geneva: WHO.
- Yates F. (1934) Contingency tables involving small numbers and the χ^2 test. *J. R. Stat. Soc., Suppl.* **1**, 217-235.
- Yates F. (1948) The analysis of contingency tables with groupings based on quantitative characters. *Biometrika* **35**, 176-181.
- Yates F. (1981) *Sampling Methods for Censures and Surveys*, 4th edn. London: Griffin.
- Yates F. (1982) Regression models for repeated measurements. *Biometrics* **38**, 850-853.
- Yates F. (1984) Tests of significance for 2 x 2 contingency tables (with Discussion). *J. R. Stat. Soc. A* **147**, 426-463.
- Youden W. J. (1950) Index for rating diagnostic tests. *Cancer* **3**, 32-35.
- Yule G. U. (1934) On some points relating to vital statistics, more especially statistics of occupational mortality. *J. R. Stat. Soc. A* **97**, 1-84.
- Yule G. U. and Kendall M. G. (1950) *An Introduction to the Theory of Statistics*, 14th edn. London: Griffin.
- Yusuf S., Peto R., Lewis J., Collins R. and Sleight P. (1985) Beta-blockade during and after myocardial infarction: an overview of the randomized clinical trials. *Prog. Cardiovasc. Dis.* **27**, 335-371.
- Yusuf S., Simon R. and Ellenberg S. (eds) (1987) Proceedings of the Workshop on Methodologic Issues in Overviews of Randomized Clinical Trials. *Stat. Med.* **6**, 217-409.
- Zeger S. L., Liang K.-Y. and Albert P. S. (1988) Models for longitudinal data: a generalized estimating equation approach. *Biometrics* **44**, 1049-1060.
- Zippin C. and Armitage P. (1966) Use of concomitant variables and incomplete survival information in the estimation of an exponential survival parameter. *Biometrics* **22**, 665-672.

Índice de autores

- Acheson E.D. 480
Agresti A. 381, 382, 397, 413
Aisbett C.W. 462
Aitchison T.C. 3
Aitken M. 527
Albert P.S. 363
Alderson M. 480
Altman D.G. 92, 119, 261, 361, 363
Alvey N. 526
Allen D.M. 361
Anderson D. 526
Armitage P. 3, 204, 232, 235, 296, 297, 382, 395, 433, 444, 450, 452, 457, 468, 471, 472, 474, 478, 479
Armstrong B.K. 422
Atkinson A.C. 310
- Babbie E.R. 8
Bacharach A.L. 208, 249, 250
Bailar J.C. 134
Bailey N.T.J. 69, 480, 505, 506
Baptista J. 484
Barnard G.A. 116, 117, 133
Barnes J.A. 531
Barnett V. 378
Barrie W.J.M. 378
Bartko J.J. 260
Bartlett M.S. 220
Barton D.E. 503
Bean J.A. 194
Becker N.G. 480
Belsley D.A. 313
Belton R. 476
Benjamin D. 480
Bennett B.M. 133
Bergen J. 261, 363, 421
- Berkson J. 275, 447, 448, 449, 521
Berlin J.A. 206
Berrier J. 183
Berry D.A. 479
Berry G. 22, 92, 260, 334, 363, 421, 453, 464, 465, 484
Bevan C. 398
Bibby J.M. 331, 352
Blackburn P.R. 143, 479
Blessing K. 3
Blevins D. 174
Bliss C.I. 328
Boardman T.J. 210
Box G.E.P. 77, 357, 361, 368
Bradley R.A. 352
Bregman D.J. 194
Breslow N.E. 133, 144, 397, 444, 450, 452, 465, 466, 478, 486, 492, 528
Brown A. 395
Brown C.C. 409
Brown E.B. 334
Brown J.K. 476
Brown M.B. 182
Buck A.A. 500
Bulmer M.G. 241
Buring J.E. 480
Burton A.H. 527
Buyse M.E. 179
Byar D.P. 461
- Campbell I. 398
Campbell M.J. 190, 194, 361, 363
Casagrande J.T. 188
Castellan N.J. Jr. 425
Clayton D. 144, 463
Cockburn R. 476

- Cockcroft A. 334, 398
 Cochran W.G. 133, 162, 171, 219, 220, 245, 247, 250, 251, 252, 260, 328, 391, 392, 394, 396
 Cochrane A.L. 178
 Cody R.P. 526
 Cohen J. 420, 421
 Cole T.J. 4
 Coleman M. 527
 Coltman C. 453
 Collins A.J. 331, 352, 353
 Collins G. 398
 Collins R. 129, 183, 206
 Collins R.L. 238
 Connor R.J. 194
 Conover W.J. 374, 375, 376, 425
 Cook P. 457
 Cook R.D. 313, 315, 316
 Cookson W.O.C.M. 422
 Coons I.J. 352
 Copas J.C. 296
 Cornbleet M.A. 3
 Cornfield J. 133, 408, 484, 488, 489
 Cox D.R. 250, 252, 368, 381, 400, 456, 409, 444, 450, 452, 455, 458, 478
 Cox G.M. 247, 250, 251, 252
 Cramer H. 39
 Cutler S.J. 449
 Cuzick J. 463, 503

 Chalmers T.C. 183, 206
 Chance M.R.A. 208, 248, 250
 Chatfield C., 332, 352, 353, 355
 Checkoway H. 466
 Chen C.-H. 462
 Chiang C.L. 445, 450

 Daniel C. 374
 Darby S.C. 360, 419
 David F.N. 503
 Dawson W.M. 55
 Day N.E. 133, 397, 465, 466, 486, 492, 500, 501, 528
 De Klerk N.H. 422
 De Mets D.L. 179, 478, 479
 Dean A.G. 527
 Dean J.A. 527
 Demers P.A. 466
 Der Simonian R. 206
 Diamond E.L. 499
 Dicker R.C. 527
 Diggle P.J. 355
 Dixon W.J. 526
 Dobson A.J. 400, 415
 Doering C.R. 402, 403
 Doll R. 174, 175, 352, 432, 457, 463,
 Donner A. 193, 194
 Douglas A. 527
 Draper N.R. 305, 306, 328, 379
 Duncombe P. 306
 Dyke G.V. 402

 Eberle E. 415
 Ederer F. 134, 449, 503
 Edwards J. 398
 Edwards J.H. 328, 503
 Edwards R. 503
 Ehrenberg A.S.C. 294
 Elwood J.M. 329, 480
 Ellenberg S. 183
 Ellery C. 484
 Evans A.S. 480
 Evans A.T. 3
 Everitt B. 352
 Exall C. 334

 Fearn T. 360
 Fellingham S.A. 457
 Fienberg S.E. 381
 Fineberg H.V. 69
 Finkelstein D.M. 424
 Finney D.J. 133, 371, 507, 515, 517, 518, 521
 Fisher R.A. 105, 108, 113, 131, 134, 223, 247, 327, 371, 372, 436
 Flamant R. 179
 Fleiss J.L. 133, 188, 261, 381, 423,
 Fleming T.R. 462, 478
 Forfar J.O. 476
 Fowler M.A. 4
 Francis B. 527
 Franklin D.A. 69

- Kalbfleisch J.D. 444, 450, 460
 Kaldor J. 144
 Kalton G. 171, 414
 Kannel W. 408
 Kaplan E.L. 451
 Kärkkäinen J. 19
 Kassirer J.P. 69
 Katti S.K. 352
 Kay R. 461
 Kelsey J.L. 480
 Kemp K.W. 357
 Kendall M.G. 158, 274, 332, 352, 440, 441
 Kent J.T. 331, 352
 Kenward M.G. 235, 306
 Keuls M. 214
 Kim K. 479
 King E.P. 468
 Kitchin R. 260, 363, 421, 453
 Klar J. 193, 194
 Kleinbaum D.G. 306, 314, 314, 315, 480, 494, 500
 Klotz J.H. 436
 Knapp M.S. 357
 Knill-Jones R.P. 69
 Knox E.G. 504
 Koch G.G. 397
 Köllerström J. 306
 Koopman P.A.R. 133
 Kruskal W.H. 438
 Krzanowski W.J. 332, 350, 352
 Kuh E. 313
 Kullman E.D. 61
 Kupper L.L. 306, 314, 315, 480, 494, 500
 Kuritz S.J. 397, 495
 Kuulasmaa K. 415

 Laird N. 206
 Lan K.K.G. 478, 479
 Lancaster H.O. 55, 116, 222, 388
 Landis J.R. 397, 495
 Lane M. 453
 Lane P. 526
 Latham S. 398
 Latscha R. 133
 Laurence D.R. 395

 Lawless J.F. 444
 Lawley D.N. 338
 Lee P.M. 77
 Lehmann E.L. 425, 426, 430
 Lellouch J. 179, 182
 Lemeshow S. 193, 194, 400, 409
 Leung O. 527
 Levin H. 183
 Levin M.L. 492
 Lewis J. 129, 183, 206
 Lewis T. 378
 Liang K.Y. 363, 486
 Liddell F.D.K. 124, 135, 414, 463, 487, 492
 Lilienfeld A.M. 499
 Lin L.I.-K. 260
 Lindley D.V. 71, 141
 Littell R.C. 331
 Little R.J. 419
 Lombard H.L. 402, 403
 Louis T.A. 179
 Lowe D. 186, 479
 Lunn D. 527
 Lwanga S.K. 193, 194

 Lloyd S. 503

 Macaskill P. 163, 186, 479
 MacKie R. 3
 Macklin J. 5
 MacLennan R. 484
 Machin D. 190, 194, 453
 Madden M. 55
 Makuch R. 189
 Mantel N. 174, 395, 396, 398, 444, 450, 452, 478, 485, 490, 499, 503, 505
 Mardia K.V. 332, 352
 Marks R.G. 357
 Marriott F.H.C. 351
 Marshall J. 266
 Marshall R.J. 144
 Martin W.J. 62
 Matthews J.N.S. 362, 363
 Maxwell A.E. 338
 Mayrent S.L. 480
 McCallum J. 21

- Welch B.L. 204
Welsch R.E. 313
West M. 357
Westgarth D.R. 369
Wetherill G.B. 306, 406
White V.M. 7
Whitehead A. 206
Whitehead J. 206, 471, 475, 478
Whittemore A.S. 495
Wilcocks W.J. 388
Wilcoxon F. 426
Wilkinson E.M. 476
Wilkinson L. 527
Wilson A. 163
Wilson D.W. 357
Wilson H.E. 453
Wilson P.D. 356
Wilson P.W. 61
Williams D.A. 116
Williams T.F. 450
Woolf B. 485
Woolson R.F. 194
Yates F. 105, 108, 113, 130, 132, 133, 134, 171,
247, 327, 363, 371, 372, 363, 436
Youden W.J. 496
Yule G.U. 158, 419
Yusuf S. 128, 183, 206
Zeger S.L. 363
Zippin C. 457

Índice de materias

A

Aberrantes, valores, 311-316, 356, 364, 376-378
Abreviación estocástica, 479
Accidentes cerebrovasculares, 265-267
– transformación raíz cuadrada, 368
Acontecimientos, 38
– independientes, 42
– mutuamente excluyentes, 41
Acumulación, comparación proporciones, 122
– estimación varianza prueba *t* dos muestras, 102
– frecuencias tabla contingencia, 219, 392
– interacciones, residual, 244
Aglomeración enfermedades, 353, 502-506
– familias, 505, 506
– geográfica, 502-504
– tiempo, 502, 503
– – espacio, 502, 504, 505
Ajuste mediante análisis covarianza, 285-294
– – estandarización, 413-419
– – medias diseños bloques incompletos, 251
– número riesgo tabla vida, 447-448
– sumas cuadrados tabla dos factores no ortogonal, 265-267, 331
Aleatorio, asignación, 177, 286, 546
– – ajuste después, 286
– modelo efectos, 206, 245
– muestreo, 167-171, 546
– – números, 74, 76-78, 177
– – – generador, 77, 546
– – – instrucciones, 546
– – – tabla, 542-545
– permutación, 546
– secuencia, 38
– serie, 38
– variable, 44

Aleatorización, asignación tratamientos, 177, 286, 546
– cuadrados latinos, 247, 359
– restringida; véase Bloques permutados
Analgésicos, 112, 469, 470
Análisis armónico, 358
– – complejos, 279
– – covarianza, 146, 285-294, 362
– – dos grupos, 271-289
– – forma regresión múltiple, 318, 319
– – identificación variable dependiente, 294
– – medias corregidas, 289, 292, 293
– – objetivos, 285, 286
– – varios grupos, 289-294
– datos explicativos, 525
– desviación, 405-407
– discriminante, asignación, 339-342, 344, 345, 351, 354
– – cociente verosimilitud, 341, 342, 350, 351
– – distancia generalizada, 340, 341, 342, 498
– – función discriminante lineal Fisher (dos grupos), 339-345, 348-351, 354
– – mediante regresión variables ficticias, 342, 342
– – regresión logística, 345, 354, 407, 408
– – separación máxima grupos, 340, 341
– espectral, 358, 359
– factores, 338, 339, 354
– varianza, cruzado simple, 231-232
– – cuadrados latinos, 247-249
– – diseño factorial, 224-245
– – dos factores, 224, 231-232
– – – no ortogonal, 261-267
– – factor, 195-215
– – modelo mixto, 245
– – – *I* (efectos fijos), 206

Análisis varianza modelo II (efectos aleatorios), 206

– – multivariante, 348-350

– – pruebas contrastes, 211-213

– – regresión, 268-273, 283-285

– – – múltiple, 300-305, 316-323

– varios grupos, 348-351

Anemia, 347-348

Anomalías congénitas, 329, 330, 357

Anticonceptivos orales, 3

Anticuerpos, pruebas, 2-3, 398

Áreas pequeñas, tasas, 144

Asbesto, 125, 137, 134, 135, 464, 465

Asignación aleatoria, 177, 286, 546

– errores, 340, 344, 345

– experimentación, 176, 177

– función discriminante, 339-342, 344, 345, 351, 354

– óptima, muestra estratificada, 168-171

– sistemática, 177

Asociación encuestas, 166, 172-176

– entre variables, 145-147

– espacio tiempo, 502, 504, 505

– grado, 176

Autoponderación, 171

B

Barras, diagrama, 4

Bartlett, prueba, 221

Bayes, teorema, 66-72, 141-144, 341, 498

Bayesianos, métodos, 66-72, 141-144, 307, 357, 479, 528

– empíricos, 144

Bebés, enfermedad, 3-4

Bernouilli, secuencia, 38-40

Beta, distribución, 142

Bimodal, distribución, 24

Binarios, datos, 13

– distribución continua fundamental, 380, 498, 522; *véase también* Binomial; Categóricos, datos; Modelo lineal generalizado; Proporciones;

– regresión, 365, 402

Binomial, coeficiente, 51

– distribución, 51-55

– – ajuste, 371

– – aproximación normal, 65-66, 112-119

– – – Poisson, 57, 58, 61, 62, 477

– – desviación estándar, 54

– – límites confianza proporción, 113-118, 121

– – media, 54

– – pruebas secuenciales, 469-474

– – – significación, 111-118

– – – signos, 425, 426

– – relacionada distribución F , 114, 115, 487

– – riesgo relativo, 487

– – tablas, 54

– – término cero ausente, 506

– – varianza, 54

– teorema, 53

Bioensayo; *véase* Biológico, ensayo

Biológico, ensayo, vitamina D, 272-273, 274, 512-515; *véase también* Ensayo; Potencia

Bloques, 178

– confusión, 253

– diseño bloques aleatorios, 178, 226, 359, 362

– – no balanceados, 252

– – incompletos, 251, 252

– – balanceados, 251

– permutados, 177, 180-181, 546

BMDP, 12, 526-528

Bondad ajuste, distribuciones, 371-376

– modelo lineal generalizado, 408, 409

– prueba Kolmogorov-Smirnov, 374-375, 376

– – normal, 371-376, 436; *véase también*

Distribución normal

– regresión logística, 408, 409

– – múltiple, 307-316

Bonferroni, corrección, 313

Bronquitis crónica, 175

C

Cadmio, capacidad vital trabajadores, 145, 279-280, 284, 285, 288, 289, 293, 294, 322, 323

Calculadoras, 12, 13, 116, 124, 298, 522, 528

- Cálculo estadístico, 12, 522-558; *véase también* Ordenadores
- Cáncer, cabeza, cuello, 460
- conocimientos, 402-404, 406
 - exmilitares, 410, 411
 - gástrico, 390-392
 - incidencia edades, 457
 - linfoma, 453-455
 - mama, 3-4, 204, 205, 295, 296, 484
 - melanoma, 2-3
 - páncreas, 481
 - pulmón, distribución edades, 16-22
 - - tabaco, 172, 174-176, 488-490, 495
 - - trabajadores asbesto, 125, 137, 134, 135, 464, 465
 - tiempo supervivencia, 94-96, 444, 447-451, 453-455, 459, 459
- Canónicas, variantes, 348-352
- Carcinogénesis, experimentos, 457
- Cardiopatía coronaria; *véase* Cardiovascular, enfermedad
- isquémica; *véase* Cardiovascular, enfermedad
- Cardiovascular, patología, 175, 407, 477; *véase también* Cerebrovascular, patología
- Cargas factores, 338
- Casilla, 7
- bigote, gráfico, 31, 32
 - frecuencias casi proporcionadas, 262
 - - proporcionadas, 231, 262
 - repeticiones intracasillas, 228-231
- Casos-contróles, combinación tablas 2 x 2, 392, 393, 484-486
- conglomerados, 503
 - elección controles, 173-176
 - emparejados, 174, 486, 487, 491, 492
 - estratificación, 392, 393, 484-486, 495
 - estudio, 163-164, 481, 495
 - - retrospectivo sintético, 174
 - modelos lineales generalizados, 491, 492
 - programas informáticos, 528
 - regresión logística, 491, 492
 - riesgo relativo, 190, 191, 481-495, 500, 500
- Casos-referentes, estudio; *véase* Casos-contróles, estudio
- Categorías adyacentes, modelo, 412
- Categorías ordenadas, 351, 352, 380-389, 397-399, 424; *véase también* Rango
- Catégoricos, datos, 14
- Causalidad, 145, 147, 172, 176, 295
- Censo, 167
- errores no muestreo, 171
 - muestra multifase, 194
- Centrado, 306, 327
- Cerebrovascular, patología, 265-267, 331, 407
- Cifras decimales, 13
- significativas, 13
- Clasificación datos (rangos), 522, 523
- - correlación, 439-442
 - - empates, 432-433
 - - enfermedades, 13, 352, 480
 - - jerárquica, pruebas $(ji)^2$, 389-390
 - - prueba suma (dos muestras), 429-435, 442, 443, 455
 - - - - tabla, 548
 - - - rangos signo, 426-429
 - - - - tabla, 547
 - - puntuaciones normales, 373, 435, 436
- Cociente cruzado, 483
- estimaciones varianza; *véase* Cociente cruzado
 - mortalidad estandarizada (CME), 415-419, 464, 465
 - proporciones, 123-125
- Cochran, prueba, 394-396, 415
- Codificación, 10-12, 523, 524
- tratamientos, 180-181
- Coeficiente confianza, 92
- correlación múltiple, 301
 - regresión parcial, 296
 - variación, 36-37, 85, 86, 367
 - varianza, 302
- Cohortes, estudio (encuesta), 173-176, 481-483, 492
- tablas vida, 445-447
- Colinealidad, 305-307
- factor inflación varianza, 306
 - tolerancia, 306
- Combinación, ponderación, 202-206
- recuentos, 275
 - riesgos relativos, 204, 205, 484-486

- Combinación tablas contingencia generales, 397-399
 - 2 x 2, 204, 205, 392-396, 484-486
 - tendencias, 397-399
- Comparación dos recuentos, 136-138, 222
 - — — medias apareadas, 99-101, 188
 - — — — no apareadas, 101-107, 184-187, 200, 212
 - — — — pendientes, 278-280
 - — — — proporciones, apareadas, 118-119
 - — — — combinación conjuntos datos, 204, 205, 392-396, 484-486
 - — — — no apareadas, 121-124, 137, 138, 188, 189
 - — — — secuenciales, 477
 - — varianzas apareadas, 110, 111, 161, 162
 - — — no apareadas, 108-111
 - medias corregidas covarianza, 293
 - múltiple, 201, 211-213, 471, 502
 - posiciones rectas regresión; véase Análisis covarianza
 - tasas mortalidad, 413-419
 - varios recuentos, 220-221-222, 502, 503
 - — medias, 195-215
 - — pendientes, 276-277, 285
 - — proporciones, 215-219
 - — varianzas, 220-221
- Componente correlaciones (cargas), 333
 - periódicos, 358
 - principales, 332-333, 338, 353
 - puntuaciones, 334
 - varianza, 162, 206-210, 257-260
- Comprobación, 505, 506
 - completa, 506
 - incompleta múltiple, 506
 - simple, 506
- Comunalidad, 338
- Concordancia, 259-261
 - medida kappa, ponderada, 419-424
- Confusión, 253
 - variable, 194, 393
- Conglomerados, análisis, 352-353
- Contracción, 142-144, 162
- Control, 357
 - calidad, 357
 - datos ensayos clínicos, 475
- Controlada, variable, 275
- Controles, elección, 173-176, 508
- Cook, distancia, 314-316, 409
- Corrección continuidad distribución binomial, 65, 66, 112-119
 - — — Poisson, 65, 66
 - — no usada tablas mayor tamaño, 216
 - — prueba rangos, 426, 442
 - — — signos, 426
 - — tablas 2 x 2, 128, 129, 132, 133, 138
 - — medias análisis covarianza, 289, 292, 293
 - — población finita, 77, 78
 - — sumas cuadrados análisis covarianza, 291, 292
 - — término (TC), 228
- Correlación coeficiente (producto-momento), 153-155, 439
 - — efecto selección, 154
 - — error estándar, 154
 - — prueba valor cero, 157
 - — intraclass, 259-261, 424
 - — matrices, 333, 338
 - — múltiple, 301
 - — producto-momento; véase Coeficiente correlación
 - — puntuaciones, 388
 - — rangos, 439-442
 - — seriada, 355-357
 - — serie, 355-357
- Correspondencia, análisis, 352
- Coste atención pacientes, 295
 - mala clasificación, 341
- Covariante, 296, 457-463
 - estudios casos-contróles, 491
- Covarianza, 84, 85
 - análisis; véase Análisis covarianza
 - coeficientes regresión parciales, 302
- Cox, modelo datos supervivencia, 458-463, 492
- Cribaje, diagnóstico, 163, 164, 341, 496, 498, 500, 501
 - fármacos, 144, 468
 - mamografía, 383
- Cruce dialéctico, 241
- Cuadrados, aleatorización, 247, 359
 - balanceados, efecto residual, 247
 - latinos, 245-249, 359, 362
 - mínimos, 148-149, 263, 296

- Ensayo, metaanálisis, 183, 205, 206
 - métodos secuenciales, 179, 469-479
 - multicéntrico, 179
 - – mutuamente excluyentes, 42
 - placebo, 180-181
 - pragmático, 181
 - preferencias analgésicos, 112, 469, 470
 - preparación datos, 8
 - problemas éticos, 179, 469, 478
 - procedimientos cribaje, 500
 - profiláctico, 176, 178
 - protocolo, 179
 - prueba equivalencia, 183, 189, 190
 - quimioterapia antituberculosa, 14-15, 219, 220
 - secuencia aleatoria, 38
 - supresorios, 472-474
 - tamaño, 478
 - tranquilizantes, 100-101
 - – tratamientos, 180
 - vitaminas ENT, 3
- Entrada anterógrada, procedimiento, 304
- Enuresis, 232-234
- Epidemiología, 480-506
 - aglomeración enfermedades, 353, 502-506
 - matemática, 480
 - pruebas diagnósticas, 495-500
 - riesgo atribuible, 492-495
 - – relativo, 179-180, 481-495, 500
- Error, asignación mediante función discriminante, 340, 344, 345
 - clasificación factores, 500
 - coeficiente correlación, 159
 - – regresión, 156, 157
 - diagnóstico, 341, 496-500
 - distribución, 400
 - dos variables, 273-275
 - – – especificación; véase también Muestreo, varianza
 - estándar (EE), 75
 - – media, 75
 - – mediana, 77
 - – necesidad estimar, 87, 96
 - – proporciones, 75, 114
 - redondeo, 12, 13, 34, 35
 - registro, 376-378
- Error sistemático, 171, 172
 - tipo I, 185, 471
 - – II, 185
- Escala análoga visual, 334
 - multidimensional, 353
- Especificidad, pruebas diagnósticas, 496
 - respuesta ensayo, 507
- Esperanza, 48-50
 - condicionada, 147
 - cuadrados mínimos, 199
 - variables continuas, 49
 - – discretas, 48
 - vida, 445, 446, 451
- Esperanza condicionada, 147
- Espujo clasificación ensayo clínico, 15, 219, 220
 - cultivo dos medios, 120, 121
- Estadística, definición, 1
 - descriptiva, 2, 14
 - oficial, 4
 - vital, 354, 413, 414, 445, 480
- Estadístico, 87
- Estandarización, 174, 413-419
 - directa, 415, 415
 - indirecta, 415-419
 - modelo lineal generalizado, 419
 - relación entre métodos, 418
 - variables, 333, 338
- Estaturas, distribución, 62, 64, 65
- Estimación, cuadrados mínimos, 148, 263, 296
 - encuestas, 166-194
 - intervalo, 91-93
 - máxima verosimilitud, 140, 148, 405
 - no paramétrica, 425, 427-429, 433-435, 442, 443
 - – sesgada, 81
 - robusta, 378
 - secuencial, 468
- Estimador no sesgado, 80
- Estratificación, análisis no paramétrico, 438, 439
 - estudio casos-contróles, 392, 393, 484-486, 495
 - tablas contingencia, 392-399
- Estrato, 167
- Estreptomina, resultados esputo tratamiento, 15, 219, 220

Estudio histórico, 173, 463; *véase también*
 Estudio cohortes
 – prospectivo, 173
 – retrospectivo, 173; *véase también* Estudio
 casos-contróles
 Etiología, 2
 – encuestas investigación, 172-176, 481-495
 Experimentos, 165
 – diseño, 176-178, 235
 – aleatorización simple, 177
 – bloques aleatorios, 178, 224, 359, 362
 – – incompletos, 251, 252
 – confusión, 253
 – cruzados, 231-232-235, 359, 362, 469
 – cuadrados grecolatinos, 250
 – – latinos, 245-249, 359, 362
 – factoriales, 224, 235-245, 402-404
 – replicación fraccionada, 252, 253
 – unidades fraccionadas, 253-259, 361, 362
 Exposición riesgo, 452
 Extrapolación, peligro, 161, 326

F

Factor difusión, 208, 209, 249
 Factorial, 51
 Falso negativo/positivo, 185, 341, 496-500
 Familias, aglomeración enfermedades, 505, 506
 – infecciones, 255, 256
 Fármacos, cribaje, 144, 468
 – ensayos; *véase* Ensayos clínicos
 Fiabilidad, 260; *véase también* Concordancia
 Fieller, teorema, 511, 518, 520
 Fisher-Behrens, prueba, 105, 141
 Formularios, 8-12
 Fracción atribuible, 492
 – etiológica, 492
 Fraccional factorial, 252, 253
 Fragilidad, 462, 463
 Frecuencia, 4
 – acumulada, 15, 20
 – curva, 23
 – distribución, 14-24
 – bimodal, 24

Frecuencia, distribución cálculo desviación
 estándar, 35-37
 – – – discretas, 15
 – – – media, 25, 26
 – – – mediana, 27
 – – colas, 24
 – – intervalo agrupación, 16, 17, 19, 36
 – – marcado, 17, 18
 – – modalidad, 23
 – – número grupos, 17
 – – sesgo, 24
 – – unimodal, 23
 – – variables continuas, 15
 – dominio, 355, 358, 359
 – esperada combinación tablas 2 x 2, 395, 396
 – pequeña $(ji)^2$, 132, 216, 219, 372, 382, 407,
 409
 – – pruebas bondad ajuste, 371, 372
 – – tablas grandes, 216, 219
 – – – 2 x 2, 126
 – relativa, 14, 15
 – seudofrecuencia, 262
 Friedman, prueba, 436-438
 Función enlace, 400
 – proporcional, 457-463
 – pulmonar; *véase* Función respiratoria
 – riesgo, 456
 – varianza, 84-86

G

Generalizado, distancia, 340, 341, 342, 498
 – ecuación estimación, 363
 – modelos ensayos cuánticos, 519-521
 – – estandarización, 419, 465
 – – estudios casos-contróles, 491, 492
 – – lineales, 399-413, 519-521
 – – programas informáticos, 400, 406, 519,
 526-527
 Genética causalidad enfermedades, 502, 505,
 506
 – cruces cinco loci, 55
 – – dos heterocigotes, 44, 45, 49, 50
 – estudios, comprobación, 505, 506

Otras obras de interés

BIOESTADÍSTICA

Norman, G.R. - Streiner, D.L.

MÉTODOS DE INVESTIGACIÓN

Aplicados a la atención primaria de salud

Argimón, J.M. - Jiménez, J.

DISEÑO DE LA INVESTIGACIÓN CLÍNICA

Un enfoque epidemiológico

Hulley, S.B. - Cummings, S.R.

ENSAYOS CLÍNICOS CON MEDICAMENTOS

Fundamentos básicos, metodología y práctica

Bakke, O.M. - Cladellas, X.C. - García Alonso, F.

BIOFÍSICA

Tercera edición

Frumento, A.S.

MEDICINA INTERNA

FARRERAS/ROZMAN

Decimotercera edición

Rozman, C.

EL MANUAL MERCK

de diagnóstico y terapéutica

Novena edición

Merck

ISBN 84-8174-158-2



9 788481 741582