



CARRERA: Ing. Electrónica

PROGRAMA ANALÍTICO DE ASIGNATURA

NOMBRE DE LA ACTIVIDAD CURRICULAR: APRENDIZAJE AUTOMÁTICO

Año Académico: 2025

Área: Sistemas de Control

Bloque: Tecnologías Aplicadas

Nivel: 6to

Tipo: Electiva

Modalidad: Cuatrimestral

Cargas horarias totales:

<i>Horas reloj</i>	<i>Horas cátedra</i>	<i>Horas cátedra semanales</i>
48	64	4

FUNDAMENTACIÓN

La inteligencia artificial se está haciendo cada vez más presente en diversos sistemas y dispositivos, dotándolos de un alto valor agregado, siendo el aprendizaje automático (Machine Learning), un campo de conocimiento clave para perfiles de ingeniería. En ese sentido, resulta muy importante acompañar en la formación a aquellas personas que estén interesadas en comprender y desarrollar sistemas de aprendizaje automático, capacitarlas para diseñar arquitecturas, dimensionarlas, entrenar y poner en producción algoritmos que resuelvan problemas de ingeniería.

OBJETIVOS (APRENDIZAJE/LOGROS A ALCANZAR)

- Interpretar el contexto y los conceptos base del aprendizaje automático dentro del campo de la Inteligencia Artificial para el abordaje de cada tipo de problemas.
- Afianzar el análisis estadístico de los datos y medir la eficiencia de las soluciones para la comparación de soluciones en algoritmos de aprendizaje automático.



- Interpretar algoritmos clásicos de aprendizaje automático para la determinación de su aplicación y uso en diferentes problemas.
- Desarrollar habilidades en la visualización de métricas y resultados para optimizar el ajuste y la mejora de los algoritmos de aprendizaje automático.
- Comprender, diseñar y dimensionar arquitecturas de aprendizaje profundo para la definición y justificación de su uso de acuerdo a los problemas y sus especificaciones.
- Utilizar distintas técnicas de ajuste de parámetros y de selección de hiperparámetros de los algoritmos para la preparación de los mismos de acuerdo al problema.
- Conocer el hardware y las plataformas existentes para el entrenamiento y la puesta en producción de los algoritmos en problemas reales.

CONTENIDOS

Contenidos mínimos

- Introducción al Aprendizaje Automático.
- Repaso de álgebra, álgebra matricial.
- Introducción al lenguaje Python en el entorno Jupyter (Notebook).
- Repaso de probabilidad, estadística, Bayes y clasificadores estadísticos para aprendizaje automático.
- Modelos de aprendizaje automático tradicional.
- Análisis exploratorio de un conjunto de datos.
- Métodos para la visualización de resultados y métricas para su evaluación.
- Redes neuronales.
- Algoritmos de entrenamiento para redes neuronales.
- Arquitecturas de aprendizaje profundo.}
- Ajuste de hiper parámetros y selección de modelos.
- Transferencia de aprendizaje y ajuste fino.

Contenidos analíticos

Unidad 1. Introducción al Aprendizaje Automático.

Presentar el mapa de áreas de estudio de la Inteligencia Artificial, abordaje orientado a datos en la solución de problemas, desde estadísticas hasta Deep Learning. Paradigmas del Aprendizaje Automático. Enfoque orientado a datos, parámetros entrenables e hiperparámetros, aprendizaje supervisado, no supervisado y por



refuerzo. Conjuntos de datos.

Unidad 2. Repaso de álgebra, álgebra matricial.

Operaciones básicas entre matrices, vectorización de operaciones, paralelización y procesamiento por lotes.

Unidad 3. Introducción al lenguaje Python en el entorno Jupyter (Notebook).

Programación utilizando python, librerías estándar y librerías de álgebra matricial y manejo de conjuntos de datos. Introducción a Jupyter notebooks. Presentación de herramientas fundamentales para la materia. Todas las prácticas serán realizadas con estas herramientas como base.

Unidad 4. Repaso de probabilidad, estadística, Bayes y clasificadores estadísticos para aprendizaje automático.

Probabilidad, estadística, Bayes, clasificadores y regresores.

Unidad 5. Modelos de aprendizaje automático tradicional.

Generalización, regularización, estandarización, calibración. KNN, Decision Tree, Random Forest. Tratamiento de conjuntos desbalanceados, técnicas de aumento de datos.

Unidad 6. Análisis exploratorio de un conjunto de datos.

Análisis de distribuciones, varianza y correlación, búsqueda de insights y presentación de información para análisis exploratorio. Selección de conjuntos de datos.

Unidad 7. Métodos para la visualización de resultados y métricas para su evaluación.

Matriz de confusión, curva ROC, AUC, Exactitud, Precisión, Recall(sensibilidad), MSE. Ingeniería y selección de características.

Unidad 8. Redes neuronales.

Neuronas. Red neuronal. Perceptrón. Perceptrón multicapa. Funciones de activación. Step, lineales, sigmoideas, ReLU, gaussianas, softmax y otras.

Unidad 9. Algoritmos de entrenamiento para redes neuronales.

Backpropagation. Gradiente descendente. Función de pérdidas, función de costo. Sobreentrenamiento y subentrenamiento. Momento, RMSProp, Adam. Velocidad de aprendizaje. Validación.



Unidad 10. Arquitecturas de aprendizaje profundo.

Redes Neuronales Completamente conectadas, Redes Neuronales Convolucionales, Capas de convolución, capas de pooling, Autoencoders y otras.

Unidad 11. Ajuste de hiper parámetros y selección de modelos.

Aplicación de métodos de exploración de hiperparámetros, y comparación de métricas de performance entre modelos.

Unidad 12. Transferencia de aprendizaje y ajuste fino.

Transferencia de aprendizaje y sus bloques: Backbone y Head, y ajuste fino aplicados a clasificación y regresión. Arquitecturas base de redes profundas estandarizadas para transferencia de conocimiento (Alexnet, VGG, Resnet, otras).

DISTRIBUCIÓN DE CARGA HORARIA ENTRE ACTIVIDADES TEÓRICAS Y PRÁCTICAS

Modalidad organizativa de las clases	Horas Reloj totales presenciales	Horas reloj virtuales totales	Horas totales
Teórica	30	0	30
Formación práctica	18	0	18
Total de horas			48

Tipo de prácticas	Horas Reloj totales presenciales	Horas reloj totales virtuales	Lugar donde se desarrolla la práctica
Formación experimental	8	0	Laboratorios 105, 108, 109 y 110 del Dpto de Ing. Electrónica UTN.BA sede Medrano
Problemas abiertos de Ingeniería (ABP)	10	0	Aula
Proyecto y diseño	0	0	
Otras:	0	0	
Práctica supervisada	0	0	
Total de horas			



ESTRATEGIAS DE ENSEÑANZA Y ACTIVIDADES DE APRENDIZAJE

Modalidades de enseñanza empleadas según tipo de actividad (teórica-práctica):

- Clases con desarrollo de temas teóricos a cargo del cuerpo docente.
- Ejemplos prácticos, organización de comisiones de trabajo para la ejecución de trabajos prácticos, que se defienden frente al resto del curso con una dinámica similar a la defensa de una tesina, según un reglamento preestablecido. Los Trabajos Prácticos que se realizan son:
 - TP1: Análisis exploratorio de datos y modelos de aprendizaje automático.
 - TP2: Aprendizaje profundo y Transfer learning con redes neuronales.
 - TP Integrador para promoción: Trabajo integrador sobre un tema consensuado con la cátedra.
- Recursos didácticos para el desarrollo de las distintas actividades (guías, esquemas, lecturas previas, computadoras, software, otros).
- Apuntes, esquemas, lecturas previas, computadoras con software específico, proyector.

MODALIDAD DE EVALUACIÓN

Régimen de aprobación a partir del nuevo reglamento de estudios según la ordenanza Nº 1549. Opcional 3B: Dos evaluaciones, más una tercera evaluación globalizadora opcional.

Evaluaciones Parciales

- Trabajos prácticos a desarrollar en equipo.
- Defensa frente a la clase de acuerdo a un reglamento consensuado al principio de cuatrimestre.

Requisitos para la regularidad

- Cumplir con el régimen de asistencia.
- Aprobación de los trabajos prácticos con nota igual o superior a 6 (seis).
- Se brindará la posibilidad de recuperar hasta un trabajo práctico, que actualizará la nota, para cumplir con la regularidad.

Requisitos para la promoción

- Tener aprobados los trabajos prácticos con nota igual o superior a 8 (ocho)
- Rendir la tercer evaluación globalizadora, y aprobar con nota igual o superior a 8 (ocho), dicha evaluación consiste en realizar y defender un trabajo final, sobre un tema consensuado con la cátedra.



- Se brindará la posibilidad de recuperar hasta un trabajo práctico para cumplir con la nota de promoción.

Requisitos para la aprobación

- Realizar y defender un trabajo final, sobre un tema consensuado con la cátedra, y aprobarlo con nota igual o superior a 6 (seis).

ARTICULACIÓN HORIZONTAL Y VERTICAL CON OTRAS MATERIAS

El Aprendizaje Automático está enmarcado dentro del campo de la Inteligencia Artificial. A su vez esta materia está fuertemente asentada en estadística, álgebra y análisis matemático, profundizando los contenidos vistos en Probabilidad y Estadística necesarios para analizar datos y resultados, utilizando herramientas del álgebra de matrices para un procesamiento optimizado y aplicando herramientas como la convolución vista en Análisis de Señales y Sistemas para el procesamiento de datos y la construcción de capas de convolución. También requiere utilizar principios de programación, manejo de datos e informática vistos en Informática II. Esta materia se vincula horizontalmente con la electiva Introducción a la Inteligencia Artificial (del área de Sistemas de Control), complementándola con las nuevas herramientas que provee el aprendizaje profundo.

Los docentes, que integran el GIAR, facilitan la transferencia de los últimos hallazgos en Aprendizaje Automático, que aportan a otras materias tales como Técnicas Digitales, Informática II, Procesamiento Digital de Señales, Proyecto Final, Medidas Electrónicas, Introducción a la Inteligencia Artificial, Aplicaciones de la Inteligencia Artificial, Procesamiento Digital de Imágenes. En otros casos permiten la vinculación con estas materias mediante la realización de trabajos prácticos integradores coordinados.

CRONOGRAMA ESTIMADO DE CLASES

CLASE	Contenidos/Actividad	Modalidad
1	Introducción al Aprendizaje Automático.	Virtual Sincrónica
2	Repaso de álgebra, álgebra matricial.	Presencial
3	Introducción al lenguaje Python en el entorno Jupyter (Notebook).	Virtual Sincrónica



4	Repaso de probabilidad, estadística, Bayes y clasificadores estadísticos para aprendizaje automático.	Presencial
5	Modelos de aprendizaje automático tradicional.	Virtual Sincrónica
6	Modelos de aprendizaje automático tradicional.	Virtual Sincrónica
7	Análisis exploratorio de un conjunto de datos.	Virtual Sincrónica
8	Métodos para la visualización de resultados y métricas para su evaluación.	Virtual Sincrónica
9	Presentación y defensa de trabajos prácticos de los temas vistos	Presencial
10	Redes neuronales.	Virtual Sincrónica
11	Algoritmos de entrenamiento para redes neuronales.	Virtual Sincrónica
12	Algoritmos de entrenamiento para redes neuronales.	Virtual Sincrónica
13	Arquitecturas de aprendizaje profundo.	Virtual Sincrónica
14	Ajuste de hiper parámetros y selección de modelos.	Virtual Sincrónica
15	Transferencia de aprendizaje y ajuste fino.	Virtual Sincrónica
16	Presentación y defensa de trabajos prácticos de los temas vistos	Presencial

BIBLIOGRAFÍA OBLIGATORIA

Bishop, C. M. (2006). Pattern Recognition and Machine Learning (Information Science and Statistics). Springer.

Géron A. (2022) Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow

Goodfellow, I., Bengio, Y. y Courville, A. (2016). Deep Learning Book. MIT Press.

Zhang A, Lipton Z., Li M. y Smola A. (2023) Dive into Deep Learning.

BIBLIOGRAFÍA COMPLEMENTARIA

Gómez, J. C. y Verrastro, C. (2013), Aprendizaje por refuerzo. SASE.



Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A. y Bengio, Y. (2014). Generative Adversarial Networks. Advances in Neural Information Processing Systems. 3. doi: 10.1145/3422622.

Krizhevsky A., Sutskever I. y Hinton G.E. (2012) Imagenet classification with deep convolutional neural networks. Neural Information Processing Systems. 25. doi: 10.1145/3065386.

LeCun, Y., Bottou, L., Bengio, Y. y Haffner P. (1998) Gradient-based learning applied to document recognition, Proceedings of the IEEE. 86. 2278 - 2324. doi: 10.1109/5.726791.

Russell, S. y Norvig, P. (2003). Inteligencia Artificial, Un Enfoque Moderno (2ª ed.), Prentice Hall Hispanoamericana.

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. y Salakhutdinov, R. (2014). Dropout: a simple way to prevent neural networks from overfitting. Journal of Machine Learning Research. 15. 1929-1958.

Sutton, R. S. y Barto, A. G. (2018) Reinforcement learning: An introduction. MIT press.

Wang, Z., Bovik, A. C. y Sheikh, H. R. (2005). Structural similarity-based image quality assessment. Digital Video Image Quality and Perceptual Coding, Ser. Series in Signal Processing and Communications. 10. doi: 1201/9781420027822.ch7.

CORRELATIVAS

Plan 95A y Plan 23:

- Requisitos para cursar y rendir:

Tener cursadas las asignaturas: Técnicas Digitales II, Análisis de Señales y Sistemas

Tener aprobadas las asignaturas: Probabilidad y Estadística, Informática II