





Richard L. Burden

J. Douglas Faires

Análisis numérico



Séptima
edición

Material protegido por derechos de autor

Contenido

1 Preliminares matemáticos 1

- 1.1 Repaso de cálculo 2
- 1.2 Errores de redondeo y aritmética de una computadora 18
- 1.3 Algoritmos y convergencia 31
- 1.4 Software numérico 40

2 Soluciones de ecuaciones de una variable 47

- 2.1 El método de bisección 48
- 2.2 Iteración de punto fijo 55
- 2.3 El método de Newton 66
- 2.4 Análisis de error para los métodos iterativos 78
- 2.5 Convergencia acelerada 86
- 2.6 Ceros de polinomios y el método de Müller 91
- 2.7 Una visión general de métodos y de software 101

3 Interpolación y aproximación polinomial 104

- 3.1 Interpolación y polinomio de Lagrange 107
- 3.2 Diferencias divididas 122
- 3.3 Interpolación de Hermite 133
- 3.4 Interpolación de trazadores cúbicos 141
- 3.5 Curvas paramétricas 156
- 3.6 Reseña de métodos y de software 163

4 Diferenciación e integración numéricas 166

- 4.1 Diferenciación numérica 167
- 4.2 Extrapolación de Richardson 178
- 4.3 Elementos de la integración numérica 186
- 4.4 Integración numérica compuesta 196
- 4.5 Integración de Romberg 207
- 4.6 Métodos adaptativos de cuadratura 213
- 4.7 Cuadratura gaussiana 220
- 4.8 Integrales múltiples 227
- 4.9 Integrales impropias 241
- 4.10 Reseña de métodos y software 247

5 Problemas de valor inicial para ecuaciones diferenciales ordinarias 249

- 5.1 Teoría elemental de los problemas de valor inicial 251
- 5.2 Método de Euler 256
- 5.3 Métodos de Taylor de orden superior 266
- 5.4 Métodos de Runge-Kutta 272
- 5.5 Control del error y el método de Runge-Kutta-Fehlberg 282
- 5.6 Métodos multipasos 289
- 5.7 Métodos multipasos con tamaño variable de paso 301
- 5.8 Métodos de extrapolación 307
- 5.9 Ecuaciones de orden superior y sistemas de ecuaciones diferenciales 313
- 5.10 Estabilidad 324
- 5.11 Ecuaciones diferenciales rígidas 334
- 5.12 Reseña de métodos y de software 342

6 Métodos directos para resolver sistemas lineales 344

- 6.1 Sistemas de ecuaciones lineales 345
- 6.2 Estrategias de pivoteo 359
- 6.3 Álgebra lineal e inversas de matrices 370
- 6.4 Determinante de una matriz 383
- 6.5 Factorización de matrices 388
- 6.6 Tipos especiales de matrices 398
- 6.7 Reseña de métodos y de software 413

7 Métodos iterativos en el álgebra matricial 417

- 7.1 Normas de vectores y de matrices 418
- 7.2 Vectores y valores característicos 430
- 7.3 Métodos iterativos para resolver sistemas lineales 437
- 7.4 Estimaciones de error y refinamiento iterativo 454
- 7.5 El método del gradiente conjugado 465
- 7.6 Reseña de métodos y de software 481

8 Teoría de la aproximación 483

- 8.1 Aproximación discreta por mínimos cuadrados 484
- 8.2 Polinomios ortogonales y aproximación por mínimos cuadrados 498
- 8.3 Polinomios de Chebyshev y economización de las series de potencias 507
- 8.4 Aproximación mediante la función racional 517
- 8.5 Aproximación polinomial trigonométrica 529
- 8.6 Transformadas rápidas de Fourier 537
- 8.7 Reseña de métodos y de programas de cómputo 548

9 Aproximación de los valores característicos 550

- 9.1 Álgebra lineal y valores característicos 551
- 9.2 Método de la potencia 560
- 9.3 Método de Householder 577
- 9.4 Algoritmo QR 585
- 9.5 Reseña de métodos y programas de cómputo 597

10 Soluciones numéricas de sistemas de ecuaciones no lineales 600

- 10.1 Puntos fijos para funciones de varias variables 602
- 10.2 Método de Newton 611
- 10.3 Métodos cuasi-Newton 620
- 10.4 Métodos del descenso más rápido 628
- 10.5 Métodos de homotopía y de continuación 635
- 10.6 Reseña de métodos y de programas de cómputo 643

11 Problemas con valor en la frontera para ecuaciones diferenciales ordinarias 645

- 11.1 El método del disparo lineal 646
- 11.2 El método del disparo para problemas no lineales 653
- 11.3 Métodos de diferencias finitas para los problemas lineales 660
- 11.4 Métodos de diferencias finitas para problemas no lineales 667
- 11.5 El método de Rayleigh-Ritz 672
- 11.6 Reseña de métodos y de programas de cómputo 688

12 Soluciones numéricas para las ecuaciones diferenciales parciales 691

- 12.1 Ecuaciones diferenciales parciales elípticas 694
- 12.2 Ecuaciones diferenciales parciales parabólicas 704
- 12.3 Ecuaciones diferenciales parciales hiperbólicas 718
- 12.4 Una introducción al método de elementos finitos 726
- 12.5 Reseña de métodos y de programas de cómputo 741

Bibliografía 743

Respuestas a ejercicios seleccionados 753

Índice 831

Prefacio

Acerca del texto

Hemos elaborado este material para una serie de cursos acerca de la teoría y aplicación de las técnicas de aproximación numérica. Está diseñado sobre todo para estudiantes orientados a las matemáticas, ciencias e ingeniería que han concluido su curso de cálculo en licenciatura. Será de utilidad estar familiarizado con los fundamentos del álgebra de matrices y las ecuaciones diferenciales, aunque en el texto presentamos un material introductorio adecuado para estos temas, de modo que estos cursos no son prerrequisitos.

Las ediciones anteriores de *Análisis numérico* se utilizan en situaciones muy variadas. En algunos casos, se enfatizó el análisis matemático en que se basa el desarrollo de las técnicas de aproximación y no los propios métodos; en otros, el énfasis fue a la inversa. Asimismo, el libro se utiliza como referencia básica para cursos iniciales posteriores a la licenciatura en programas de ingeniería y ciencias de la computación; como base para un examen de actuaría en métodos numéricos, donde es común el estudio autodidacta; y en cursos de análisis introductorio impartidos en universidades internacionales. Hemos tratado de adaptar el libro a estos usuarios tan diversos sin comprometer nuestro propósito original:

Ofrecer una introducción a las técnicas modernas de aproximación; explicar cómo, por qué y cuándo se espera que funcionen; y proporcionar una base firme para el estudio posterior del análisis numérico y el cómputo científico.

El libro contiene suficiente material para un año completo de estudio, aunque tal vez los lectores lo utilicen sólo para un curso de un semestre. En ese lapso, los estudiantes aprenden a identificar qué problemas requieren métodos numéricos para su solución y ven ejemplos de la propagación (o difusión) del error que puede ocurrir al aplicarlos. Además, reconocen cómo aproximar con precisión las soluciones de problemas que no se pueden resolver con exactitud y aprenden técnicas de estimación de cotas (o límites) del error en las aproximaciones. El resto del texto sirve como referencia para métodos no considerados en el curso. El tratamiento de un año o un semestre es consistente con los propósitos del texto.

Casi todos los conceptos del texto se ilustran mediante ejemplos; esta edición contiene más de 2,000 ejercicios probados en clase que abarcan desde aplicaciones elementales

de los métodos y los algoritmos hasta generalizaciones y extensiones de la teoría. Además, los conjuntos de ejercicios incluyen muchos problemas de aplicación de diversas áreas de la ingeniería, así como de las ciencias físicas, de la computación, biológicas y sociales. Las aplicaciones elegidas demuestran en forma concisa cómo se pueden aplicar los métodos numéricos en situaciones reales.

Existen varios paquetes de *software* para realizar cálculos matemáticos simbólicos. De éstos, predominan en el medio académico Derive, Maple y Mathematica. Las versiones escolares de estos paquetes están disponibles a precios razonables y funcionan en la mayoría de las computadoras. Aunque existen diferencias importantes entre los paquetes, tanto en desempeño como en precio, todos pueden realizar operaciones comunes de cálculo y álgebra.

El hecho de contar con un paquete para el cálculo simbólico puede ser muy útil en el estudio de las técnicas de aproximación. Los resultados de la mayor parte de nuestros ejemplos y ejercicios se generaron a partir de problemas para los que *pueden* determinarse los valores exactos, pues esto permite examinar el desempeño del método de aproximación. A menudo, las soluciones exactas se pueden obtener con relativa facilidad mediante cálculo simbólico. Además, para muchas técnicas numéricas, el análisis del error exige acotar una derivada ordinaria o parcial de orden superior de una función, lo cual puede ser una tarea tediosa y poco instructiva cuando se dominan las técnicas del cálculo. Las derivadas se pueden obtener rápidamente en forma simbólica y un poco de ingenio permite que un cálculo simbólico ayude también en el proceso de acotación.

Se eligió a Maple como paquete estándar debido al uso generalizado, pero Derive o Mathematica se pueden sustituir con sólo ligeras modificaciones. También, se agregaron ejemplos y ejercicios donde se tiene la impresión que un sistema de álgebra por computadora podría traer beneficios significativos y se analizaron los métodos de aproximación que usa Maple cuando no es posible resolver un problema de manera exacta.

Novedades en esta edición

La séptima edición incluye dos nuevas secciones importantes. El método del gradiente conjugado preconditionado se agregó al capítulo 7 para proporcionar un tratamiento más completo de la solución numérica de los sistemas de ecuaciones lineales. Se presenta como una técnica de aproximación iterativa para resolver sistemas lineales positivos definidos. De esta forma, es particularmente útil para aproximar la solución de sistemas dispersos de gran tamaño.

En el capítulo 10 se añadió una sección sobre métodos de homotopía y continuación. Éstos proporcionan una técnica muy distinta, que en fechas recientes ha llamado mucho la atención, para aproximar las soluciones de sistemas de ecuaciones no lineales.

También se añaden en todo el libro grandes listados de código Maple, pues los revisores consideraron útil esta característica en la sexta edición. Hemos actualizado todo el código Maple a la versión 6, que es la más reciente. Las personas familiarizadas con nuestras ediciones anteriores verán que casi todas las páginas mejoraron de alguna manera. Se actualizaron y revisaron las referencias y se han agregado nuevos ejercicios. Esperamos que todos estos cambios le parezcan benéficos para la enseñanza y el estudio del análisis numérico; la mayor parte de ellos han sido motivados por cambios en la presentación del material a nuestros propios estudiantes.

Otra modificación importante en esta edición es un sitio en Internet* en

<http://www.as.ysu.edu/~fares/Numerical-Analysis/>

En este sitio colocaremos programas actualizados conforme cambie el software, así como respuestas a los comentarios realizados por usuarios del libro. También podemos agregar nuevo material que podría incluirse en ediciones posteriores, en la forma de archivos PDF que pueden ser consultados por los usuarios.

Esperamos que esto amplíe la vida de la séptima edición, a la vez que mantenga actualizado el material.

*La información contenida en este sitio está en inglés. Asimismo, esta casa editorial no se hace responsable si en algún momento desaparece el sitio o cambia de dirección.

Algoritmos

Como en las ediciones anteriores, se proporciona un algoritmo detallado y estructurado sin el listado del programa para cada método en el texto. Los algoritmos aparecen de forma que los estudiantes puedan codificarlos, aun con poca experiencia en programación.

Los programas para cada algoritmo están escritos en FORTRAN, Pascal y C. Además, los hemos codificado por medio de Maple y Mathematica, así como MATLAB, un paquete de software ampliamente utilizado para aplicaciones del álgebra lineal. Esto debe garantizar que se dispone de un conjunto de programas para la mayor parte de los sistemas de cómputo.

Por medio de los algoritmos se obtienen programas que dan los resultados correctos para los ejemplos y ejercicios en el texto, pero de ningún modo se intentó escribir software profesional de carácter general. En particular, los algoritmos no siempre están escritos de una forma que conduce al programa *más efectivo* en términos de requisitos de tiempo o almacenamiento. Cuando ocurre un conflicto entre escribir un algoritmo extremadamente eficaz y uno algo distinto que ilustre mejor las características importantes del método, se opta por lo segundo.

Acerca de los complementos en la dirección www.thomsonlearning.com.mx

En el sitio, el lector encontrará información sobre este libro y podrá, además, consultar los archivos electrónicos de los algoritmos que aparecen en el texto (en distintos formatos). Para cada algoritmo hay un programa C, Fortran, Maple, Mathematica, MATLAB y Pascal; y para cada sistema hay varios programas, cuya aplicación depende de la versión del software que se emplee; esos programas se ejemplifican con un problema del texto, de modo que el usuario pueda resolverlo en el lenguaje de su elección e identifique la entrada (INPUT) y la salida (OUTPUT); éstos pueden también modificarse para resolver otros problemas. Las entradas y salidas son casi las mismas en cada sistema de programación.

Material protegido por derechos de autor

Los programas pueden correrse en una computadora que posea los sistemas operativos MS-DOS, Windows o Macintosh. Sin embargo, se requiere un software apropiado, como un compilador para Pascal, Fortran, C, o algún sistema algebraico para computadora (Maple, Mathematica o MATLAB). El lector encontrará seis subdirectorios para cada lenguaje y los archivos complementarios.


Todos los programas están en archivos ASCII y hojas de cálculo; y pueden modificarse mediante un procesador de palabras, capaz de crear un archivo estándar de ASCII (de los llamados "sólo texto").

Los archivos README se presentan en formato ASCII y PDF, y se incluyen con los archivos del programas, de manera que los sistemas de programación puedan ejecutarse en forma individual.

Sugerencias para un curso

Análisis numérico está diseñado para que los profesores puedan elegir entre los temas, así como el nivel de rigor teórico y el énfasis en las aplicaciones. En concordancia con estos propósitos, proporcionamos referencias detalladas para los resultados no demostrados en el texto y las aplicaciones utilizadas para indicar la importancia práctica de los métodos. Las referencias son las que tienen más posibilidades de ser halladas en las bibliotecas de las universidades y se actualizaron para reflejar la edición más reciente en el momento en que este libro se imprimió. También incluimos citas de artículos originales de investigación cuando consideramos que el material es accesible a nuestros lectores.

En el siguiente diagrama de flujo se indican los prerrequisitos de cada capítulo. La única desviación de este diagrama se describe en la nota al pie de página, al inicio de la sección 3.4. La mayor parte de las secuencias posibles que pueden generarse con este diagrama, los autores las utilizaron en *Youngstown State University*.



Agradecimientos

Nos sentimos muy afortunados porque muchos de nuestros estudiantes y colegas nos han comunicado sus impresiones acerca de las ediciones anteriores de este libro. Todos estos comentarios fueron tomados en cuenta y se procuró incluir todas las sugerencias acordes con los principios del libro; asimismo, agradecemos a todos aquellos que se han tomado un tiempo para contactarnos e informarnos de mejoras que podemos hacer en versiones posteriores.

En particular, queremos agradecer el esfuerzo de las siguientes personas:

Glen Granzow, Idaho State University
José Miguel, Universidad Peruana Cayetano Heredia, Lima, Perú
John M. Neuberger, Northern Arizona University
L. G. de Pillis, Harvey Mudd College

Agradecemos en particular a nuestro amigo y alguna vez alumno, Jim Baglama, de *Ball State University*. Jim estuvo de acuerdo en revisar ampliamente esta edición y nos ayudó a actualizar las secciones de bibliografía y software. Es muy gratificante ver el desarrollo de nuestros estudiantes en su profesión.

Otra persona que se desempeña bien en su profesión, aunque de manera muy distinta, es nuestro editor Gary Ostedt, gerente sobresaliente de nuestros proyectos y gran amigo en lo personal. Extrañaremos en gran medida su dirección y apoyo, y aprovechamos la oportunidad para desearle lo mejor en su pronto retiro de Brooks/Cole.

Igual que en las ediciones anteriores de este libro, aprovechamos la ayuda de los estudiantes de Youngstown State University para preparar la séptima edición. Nuestra hábil asistente para esta edición fue Laurie Marinelli, a la que agradecemos su trabajo. También queremos expresar nuestra gratitud a los colegas académicos y administrativos de Youngstown State University por darnos la oportunidad y facilitarnos los medios para concluir este proyecto.

Por último, quisiéramos agradecer a quienes han utilizado y adoptado las diversas ediciones de *Análisis numérico* en estos años. Es maravilloso saber de tantos estudiantes y jóvenes profesores que utilizan nuestro libro en su primer encuentro con el estudio de los métodos numéricos. Esperamos que esta edición continúe esta tendencia y apoye el gusto de los estudiantes por el análisis numérico. Si usted tiene sugerencias para mejorar el material que puedan incorporarse en las próximas ediciones del libro, agradeceremos sus comentarios en las siguientes direcciones de correo electrónico:

Richard L. Burden
burden@math.ysu.edu
J. Douglas Faires
fares@math.ysu.edu

Preliminares matemáticos

. . .

En los primeros cursos de química se introduce la *ley del gas ideal*,

$$PV = NRT,$$

que relaciona la presión P , el volumen V , la temperatura T y el número de moles N de un gas "ideal". En esta ecuación, R es una constante que depende del sistema de medida.


Suponga que se realizan dos experimentos para comprobar esta ley con el mismo gas en cada caso. En el primer experimento,

$$\begin{aligned} P &= 1.00 \text{ atm}, & V &= 0.100 \text{ m}^3, \\ N &= 0.00420 \text{ mol}, & R &= 0.08206. \end{aligned}$$

Por medio de la ley del gas ideal se predice que la temperatura del gas será

$$T = \frac{PV}{NR} = \frac{(1.00)(0.100)}{(0.00420)(0.08206)} = 290.15 \text{ K} = 17^\circ\text{C}.$$

Al medir la temperatura del gas, vemos que la temperatura real es 15°C .



Luego, repetimos el experimento con los mismos valores de R y N , pero se incrementa la presión por un factor de dos y se reduce el volumen por el mismo factor. Como el producto PV es el mismo, la temperatura prevista aún es 17°C , pero ahora la temperatura real del gas es de 19°C .

Por supuesto que se sospecha de la ley del gas ideal, pero antes de concluir que la ley no es válida en esta situación es necesario examinar los datos para ver si el error se puede atribuir a los resultados experimentales. En caso afirmativo, podríamos determinar la precisión necesaria en nuestros resultados experimentales para garantizar que no ocurra un error de esta magnitud.

El análisis del error que surge en los cálculos es un tema importante en el análisis numérico y se presenta en la sección 1.2. Esta aplicación particular se considera en el ejercicio 28 de esa sección.

Este capítulo contiene un breve repaso de temas de cálculo elemental de una variable, necesarios en capítulos posteriores, junto con una introducción a la convergencia, el análisis del error y la representación de los números en los dispositivos utilizados para la realización de los cálculos.

1.1 Repaso de cálculo

Los conceptos de *límite* y *continuidad* de una función son fundamentales en el estudio del cálculo diferencial.

Definición 1.1 Una función f definida en un conjunto X de números reales tiene el **límite** L en x_0 , denotado por

$$\lim_{x \rightarrow x_0} f(x) = L,$$


si, dado cualquier número real $\epsilon > 0$, existe un número real $\delta > 0$ tal que $|f(x) - L| < \epsilon$, siempre que $x \in X$ y $0 < |x - x_0| < \delta$. (Véase la figura 1.1.) ■

Definición 1.2 Sea f una función definida en un conjunto X de números reales y $x_0 \in X$. Entonces f es **continua** en x_0 si

$$\lim_{x \rightarrow x_0} f(x) = f(x_0).$$

La función f es continua en el conjunto X si es continua en cada número en X . ■

Figura 1.1



$C(X)$ denota al conjunto de funciones que son continuas en X . Cuando X es un intervalo de la recta real, se omiten los paréntesis en esta notación. Por ejemplo, el conjunto de todas las funciones continuas en el intervalo cerrado $[a, b]$ se denota $C[a, b]$.

El *límite de una sucesión* de números reales o complejos se define de manera similar.

Definición 1.3 Sea $\{x_n\}_{n=1}^{\infty}$ una sucesión infinita de números reales o complejos. La sucesión $\{x_n\}_{n=1}^{\infty}$ tiene el *límite* x (*converge a* x) si, para cualquier $\epsilon > 0$, existe un entero positivo $N(\epsilon)$ tal que $|x_n - x| < \epsilon$, siempre que $n > N(\epsilon)$. La notación

$$\lim_{n \rightarrow \infty} x_n = x, \quad \text{o} \quad x_n \rightarrow x \quad \text{cuando} \quad n \rightarrow \infty,$$

significa que la sucesión $\{x_n\}_{n=1}^{\infty}$ converge a x . ■

En el siguiente teorema se relacionan los conceptos de convergencia y continuidad.

Teorema 1.4 Si f es una función definida en un conjunto X de números reales y $x_0 \in X$, entonces las siguientes afirmaciones son equivalentes:

- f es continua en x_0 ;
- Si $\{x_n\}_{n=1}^{\infty}$ es cualquier sucesión en X que converge a x_0 , entonces $\lim_{n \rightarrow \infty} f(x_n) = f(x_0)$. ■

Supondremos que son continuas las funciones por considerar en el análisis de los métodos numéricos, pues éste es un requisito mínimo para tener un comportamiento predecible. Las funciones discontinuas pueden interrumpirse en los puntos de interés, lo que puede causar dificultades al intentar aproximar una solución a un problema. Por lo general los supuestos más elaborados acerca de una función conducen a mejores resultados de aproximación. Por ejemplo, una función con gráfica uniforme se comportará, por lo gene-

ral, de manera más predecible que una en forma de sierra. La condición de suavidad se basa en el concepto de derivada.


Definición 1.5 Sea f una función definida en un intervalo abierto que contiene a x_0 . La función f es **derivable** en x_0 si

$$f'(x_0) = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0}$$

existe. El número $f'(x_0)$ es la **derivada** de f en x_0 . Una función que tiene derivada en cada número de un conjunto X es **derivable** en X .

La derivada de f en x_0 es la pendiente de la recta tangente a la gráfica de f en $(x_0, f(x_0))$, como se muestra en la figura 1.2. ■

Figura 1.2



Teorema 1.6 Si la función f es derivable en x_0 , entonces f es continua en x_0 . ■


El conjunto de todas las funciones que tienen n derivadas continuas en X se denota $C^n(X)$, y el conjunto de funciones que tienen derivadas de todos los órdenes en X se denota $C^\infty(X)$. Las funciones polinomiales, racionales, trigonométricas, exponenciales y logarítmicas están en $C^\infty(X)$, donde X consta de todos los números para los que están definidas las funciones. Si X es un intervalo de la recta real, se omiten de nuevo los paréntesis en esta notación.

Los siguientes teoremas son fundamentales en la deducción de métodos para la estimación del error. Las demostraciones de estos teoremas y de los demás resultados sin referencia en esta sección se pueden encontrar en cualquier texto de cálculo.

Teorema 1.7 (Teorema de Rolle)

Suponga que $f \in C[a, b]$ y que f es derivable en (a, b) . Si $f(a) = f(b)$, entonces existe un número c en (a, b) tal que $f'(c) = 0$. (Véase la figura 1.3.) ■

Figura 1.3


**Teorema 1.8 (Teorema del valor medio)**

Si $f \in C[a, b]$ y f es derivable en (a, b) , entonces existe un número c en (a, b) tal que

$$f'(c) = \frac{f(b) - f(a)}{b - a}. \quad (\text{Véase la figura 1.4.})$$

■

Figura 1.4


**Teorema 1.9 (Teorema de los valores extremos)**

Si $f \in C[a, b]$, entonces existen $c_1, c_2 \in [a, b]$ tales que $f(c_1) \leq f(x) \leq f(c_2)$ para toda $x \in [a, b]$. Además, si f es derivable en (a, b) , entonces los números c_1 y c_2 aparecen en los extremos de $[a, b]$, o bien donde se anula f' . (Véase la figura 1.5.)

■

Como se mencionó en el prefacio, cuando sea adecuado usaremos el sistema de álgebra por computadora, Maple. Los sistemas de álgebra por computadora son útiles para la derivación simbólica y el trazo de gráficas. Ambas técnicas se ilustran en el ejemplo 1.

Figura 1.5



EJEMPLO 1 Determine $\max_{a \leq x \leq b} |f(x)|$ para

$$f(x) = 5 \cos 2x - 2x \sin 2x$$

en los intervalos $[1, 2]$ y $[0.5, 1]$.

Primero ilustraremos las capacidades gráficas de Maple. Para tener acceso al paquete de graficación se escribe la instrucción

```
>with(plots);
```

A continuación aparecen las instrucciones del paquete. Se introduce la definición de f al escribir

```
>f:=5*cos(2*x)-2*x*sen(2*x);
```

La respuesta de Maple es

$$f := 5 \cos(2x) - 2x \sin(2x)$$

Para graficar f en el intervalo $[0.5, 2]$, use la instrucción

```
>plot(f,x=0.5..2);
```

La gráfica aparece como en la figura 1.6, en la cual se pueden determinar las coordenadas de cualquier punto sobre la gráfica al mover el apuntador del ratón al punto deseado y oprimir el botón izquierdo. Esta técnica se utiliza para estimar las intersecciones con los ejes y los extremos de las funciones.


Completamos el ejemplo usando el teorema de valores extremos. Primero, consideremos el intervalo $[1, 2]$. Para obtener la primera derivada $g = f'$, se escribe

```
>g:=diff(f,x);
```

la respuesta de Maple es

$$g := -12 \sin(2x) - 4x \cos(2x)$$

Figura 1.6



Luego, podemos resolver $g(x) = 0$ para $1 \leq x \leq 2$, con la instrucción


```
>fsolve(g,x,1,.2);
```

con lo cual se obtiene 1.358229874, y se calcula $f(1.358229874)$ mediante

```
>evalf(subs(x=1.358229874,f));
```

Como $f(1) = -3.899329037$ y $f(2) = -0.241008124$, tenemos, para el intervalo $[1, 2]$, un valor máximo de $f(2) = -0.241008124$, como se muestra en la figura 1.7, y un

Figura 1.7



valor mínimo aproximado de $f(1.358229874) = -5.675301338$. Por tanto,

$$\max_{1 \leq x \leq 2} |5 \cos 2x - 2x \sin 2x| \approx |f(1.358229874)| = 5.675301338.$$

Si tratamos de resolver $g(x) = 0$, para $0.5 \leq x \leq 1$, vemos que al introducir

```
>fsolve(g,x,0.5..1);
```


Maple responde con

$$\text{fsolve}(-12 \sin(2x) - 4x \cos(2x), x, .5..1)$$

lo cual indica que Maple no pudo encontrar una solución en $[0.5, 1]$. Si grafica g , verá que no hay soluciones en este intervalo, y el máximo ocurre en un extremo. Por tanto, f' nunca se anula en $[0.5, 1]$, como se muestra en la figura 1.8, y como $f(0.5) = 1.860040545$ y $f(1) = -3.899329037$, tenemos

$$\max_{0.5 \leq x \leq 1} |5 \cos 2x - 2x \sin 2x| = |f(1)| = 3.899329037. \quad \blacksquare$$

Figura 1.8



El otro concepto básico del cálculo que usaremos ampliamente es la integral de Riemann.

Definición 1.10 La integral de Riemann de la función f en el intervalo $[a, b]$ es el siguiente límite, si éste existe:

$$\int_a^b f(x) dx = \lim_{\max \Delta x_i \rightarrow 0} \sum_{i=1}^n f(z_i) \Delta x_i$$


donde los números $x_0, x_1, \dots, x_n$ satisfacen $a = x_0 \leq x_1 \leq \dots \leq x_n = b$, y $\Delta x_i = x_i - x_{i-1}$ para toda $i = 1, 2, \dots, n$ y z_i se elige de manera arbitraria en el intervalo $[x_{i-1}, x_i]$. ■

Toda función continua f en $[a, b]$ es Riemann-integrable en $[a, b]$. Esto nos permite elegir, para fines de cálculo, los puntos x_i uniformemente distribuidos en $[a, b]$, y para cada $i = 1, 2, \dots, n$, elegir $z_i = x_i$. En este caso,

$$\int_a^b f(x) dx = \lim_{n \rightarrow \infty} \frac{b-a}{n} \sum_{i=1}^n f(x_i),$$

donde los números que aparecen en la figura 1.9 como x_i son $x_i = a + i(b-a)/n$.

Figura 1.9



En nuestro estudio del análisis numérico necesitaremos otros dos resultados. El primero es una generalización del teorema del valor medio para integrales.

Teorema 1.11 (Teorema del valor medio ponderado para integrales)

Suponga que $f \in C[a, b]$, que la integral de Riemann de g existe en $[a, b]$ y que $g(x)$ no cambia de signo en $[a, b]$. Entonces existe un número c en (a, b) tal que


$$\int_a^b f(x)g(x) dx = f(c) \int_a^b g(x) dx. \quad \blacksquare$$

Cuando $g(x) \equiv 1$, el teorema 1.11 es el del valor medio para integrales que proporciona el **valor promedio** de la función f en el intervalo $[a, b]$ como

$$f(c) = \frac{1}{b-a} \int_a^b f(x) dx.$$

(Véase la figura 1.10.)

Figura 1.10



Por lo general, la demostración del teorema 1.11 no se da en un curso básico de cálculo, pero se puede encontrar en la mayor parte de los textos de análisis (véase, por ejemplo, [Fu, p. 162]).

El otro teorema que necesitaremos y que normalmente no se presenta en un curso básico de cálculo se deduce al aplicar de manera sucesiva el teorema de Rolle a $f, f', \dots$, y, por último, a $f^{(n-1)}$.

Teorema 1.12 (Teorema generalizado de Rolle)

Suponga que $f \in C[a, b]$ es n veces derivable en (a, b) . Si $f(x)$ se anula en los $n + 1$ números distintos $x_0, \dots, x_n$ en $[a, b]$, entonces existe un número c en (a, b) tal que $f^{(n)}(c) = 0$. ■


El siguiente teorema es el del valor intermedio. Aunque su enunciado parece razonable, la demostración está fuera del alcance de un curso usual de cálculo. Sin embargo, se puede encontrar en la mayor parte de los textos de análisis (véase, por ejemplo, [Fu, p. 67]).

Teorema 1.13 (Teorema del valor intermedio)

Si $f \in C[a, b]$ y K es cualquier número entre $f(a)$ y $f(b)$, entonces existe un número c en (a, b) tal que $f(c) = K$. ■

En la figura 1.11 se muestra una elección del número garantizado por el teorema del valor intermedio. En este ejemplo hay otras dos posibilidades.

Figura 1.11



EJEMPLO 2 Para mostrar que $x^5 - 2x^3 + 3x^2 - 1 = 0$ tiene una solución en el intervalo $[0, 1]$, considere $f(x) = x^5 - 2x^3 + 3x^2 - 1$. Puesto que

$$f(0) = -1 < 0 < 1 = f(1)$$

y f es continua, el teorema del valor intermedio indica que existe un número x en $0 < x < 1$ para el que $x^5 - 2x^3 + 3x^2 - 1 = 0$. ■

Como vimos en el ejemplo 2, el teorema del valor intermedio sirve para determinar si existen soluciones de ciertos problemas. Sin embargo, no proporciona un método eficaz para determinar tales soluciones. Estudiaremos este tema en el capítulo 2.

El último teorema en este repaso de cálculo describe los polinomios de Taylor. Éstos se usan ampliamente en el análisis numérico.

Teorema 1.14 (Teorema de Taylor)

Suponga que $f \in C^n[a, b]$, que $f^{(n+1)}$ existe en $[a, b]$ y $x_0 \in [a, b]$. Para cada $x \in [a, b]$, existe un número $\xi(x)$ entre x_0 y x tal que

$$f(x) = P_n(x) + R_n(x),$$

donde

$$\begin{aligned} P_n(x) &= f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2!}(x - x_0)^2 + \cdots + \frac{f^{(n)}(x_0)}{n!}(x - x_0)^n \\ &= \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!}(x - x_0)^k \end{aligned}$$

y

$$R_n(x) = \frac{f^{(n+1)}(\xi(x))}{(n+1)!}(x - x_0)^{n+1}. \quad \blacksquare$$

En este caso, $P_n(x)$ es el n -ésimo polinomio de Taylor para f respecto a x_0 , y $R_n(x)$ se llama el **término del residuo** (o **error de truncamiento**) asociado a $P_n(x)$. La serie infinita obtenida al tomar el límite de $P_n(x)$ cuando $n \rightarrow \infty$ es la **serie de Taylor** para f en torno a x_0 . En el caso $x_0 = 0$, el polinomio de Taylor suele llamarse **polinomio de Maclaurin**, y la serie de Taylor se nombra **serie de Maclaurin**.

El término **error de truncamiento** se refiere al error implícito al usar una suma truncada, o finita, para aproximar la suma de una serie infinita.

EJEMPLO 3 Determine (a) el segundo y (b) el tercer polinomio de Taylor para $f(x) = \cos x$ respecto a $x_0 = 0$, y use estos polinomios para aproximar $\cos(0.01)$. (c) Con el tercer polinomio de Taylor y su término de residuo aproxime $\int_0^1 \cos x \, dx$.

Como $f \in C^\infty(\mathbb{R})$, el teorema de Taylor se puede aplicar a cualquier $n \geq 0$. Además,

$$f'(x) = -\sin x, \quad f''(x) = -\cos x, \quad f'''(x) = \sin x \quad \text{y} \quad f^{(4)}(x) = \cos x.$$

de modo que


$$f(0) = 1, \quad f'(0) = 0, \quad f''(0) = -1 \quad \text{y} \quad f'''(0) = 0.$$

a. Para $n = 2$ y $x_0 = 0$, tenemos

$$\cos x = 1 - \frac{1}{2}x^2 + \frac{1}{6}x^3 \operatorname{sen} \xi(x),$$

donde $\xi(x)$ es un número entre 0 y x . (Véase la figura 1.12.)

Figura 1.12



Para $x = 0.01$, el polinomio de Taylor y el término del residuo son

$$\begin{aligned} \cos 0.01 &= 1 - \frac{1}{2}(0.01)^2 + \frac{1}{6}(0.01)^3 \operatorname{sen} \xi(x) \\ &= 0.99995 + 0.1\overline{6} \times 10^{-6} \operatorname{sen} \xi(x), \end{aligned}$$

donde $0 < \xi(x) < 0.01$. (La barra sobre el 6 en $0.1\overline{6}$ se usa para indicar que este dígito se repite de manera indefinida.) Puesto que $|\operatorname{sen} \xi(x)| < 1$ para toda x , tenemos

$$|\cos 0.01 - 0.99995| \leq 0.1\overline{6} \times 10^{-6},$$

de modo que la aproximación 0.99995 coincide por lo menos con los primeros cinco dígitos de $\cos 0.01$, y

$$\begin{aligned} 0.9999483 &< 0.99995 - 1.\overline{6} \times 10^{-6} \leq \cos 0.01 \leq 0.99995 + 1.\overline{6} \times 10^{-6} \\ &< 0.9999517. \end{aligned}$$

La cota de error es mucho mayor que el error real. Esto se debe, en parte, a la pobre cota que usamos para $|\operatorname{sen} \xi(x)|$. Se puede demostrar que para todo valor de x , tenemos $|\operatorname{sen} x| \leq |x|$. Como $0 \leq \xi < 0.01$, podríamos usar el hecho de que $|\operatorname{sen} \xi(x)| \leq 0.01$ en la fórmula para el error, lo que produce la cota $0.1\overline{6} \times 10^{-8}$.

- b. Como $f'''(0) = 0$, el tercer polinomio de Taylor con término de residuo en torno a $x_0 = 0$ es

$$\cos x = 1 - \frac{1}{2}x^2 + \frac{1}{24}x^4 \cos \tilde{\xi}(x),$$

donde $0 < \tilde{\xi}(x) < 0.01$. El polinomio de aproximación es el mismo, y la aproximación aún es 0.99995, pero ahora tenemos una mucho mejor garantía de precisión. Puesto que $|\cos \tilde{\xi}(x)| \leq 1$ para toda x , tenemos

$$\left| \frac{1}{24} x^4 \cos \tilde{\xi}(x) \right| \leq \frac{1}{24} (0.01)^4 (1) \approx 4.2 \times 10^{-10}.$$

De modo que

$$|\cos 0.01 - 0.99995| \leq 4.2 \times 10^{-10},$$

y

$$\begin{aligned} 0.99994999958 &= 0.99995 - 4.2 \times 10^{-10} \\ &\leq \cos 0.01 \leq 0.99995 + 4.2 \times 10^{-10} = 0.99995000042. \end{aligned}$$

En las dos primeras partes de este ejemplo se ilustran los dos objetivos del análisis numérico. El primero es encontrar una aproximación, que los polinomios de Taylor proporcionan en ambas partes. El segundo es determinar la precisión de la aproximación. En este caso, el tercer polinomio de Taylor fue mucho más informativo que el segundo, aunque ambos dieron la misma aproximación.

- c. Usamos el tercer polinomio de Taylor para obtener

$$\begin{aligned} \int_0^{0.1} \cos x \, dx &= \int_0^{0.1} \left(1 - \frac{1}{2}x^2 \right) dx + \frac{1}{24} \int_0^{0.1} x^4 \cos \tilde{\xi}(x) \, dx \\ &= \left[x - \frac{1}{6}x^3 \right]_0^{0.1} + \frac{1}{24} \int_0^{0.1} x^4 \cos \tilde{\xi}(x) \, dx \\ &= 0.1 - \frac{1}{6} (0.1)^3 + \frac{1}{24} \int_0^{0.1} x^4 \cos \tilde{\xi}(x) \, dx. \end{aligned}$$

Por tanto,

$$\int_0^{0.1} \cos x \, dx \approx 0.1 - \frac{1}{6} (0.1)^3 = 0.0998\bar{3}.$$

Se puede determinar una cota para el error en esta aproximación a partir de la integral del término del residuo de Taylor y el hecho de que $|\cos \tilde{\xi}(x)| \leq 1$ para toda x :

$$\begin{aligned} \frac{1}{24} \left| \int_0^{0.1} x^4 \cos \tilde{\xi}(x) \, dx \right| &\leq \frac{1}{24} \int_0^{0.1} x^4 |\cos \tilde{\xi}(x)| \, dx \\ &\leq \frac{1}{24} \int_0^{0.1} x^4 \, dx = 8.\bar{3} \times 10^{-8}. \end{aligned}$$

Como el valor real de esta integral es

$$\int_0^{0.1} \cos x \, dx = \left. \sin x \right|_0^{0.1} = \sin 0.1 \approx 0.099833417,$$

el error real para esta aproximación es 8.332×10^{-8} , que está dentro de la cota de error. ■

En el ejemplo 3, también podríamos usar un sistema de álgebra por computadora. Por medio de Maple, se define a f como

```
>f:=cos(x);
```

Maple nos permite colocar varios enunciados en un renglón y usar los dos puntos para eliminar las respuestas de Maple. Por ejemplo, obtenemos el tercer polinomio de Taylor con

```
>s3:=taylor(f,x=0,4): p3:=convert(s3, polynom);
```

La primera parte calcula la serie de Taylor con cuatro términos (grado 3) y el residuo desarrollado respecto a $x_0 = 0$. La segunda parte convierte la serie $s3$ en el polinomio $p3$ al eliminar el residuo. Para obtener 11 cifras decimales en el resultado, introducimos

```
>Digits:=11;
```

y evaluamos $f(0.01)$, $P_3(0.01)$ y $|f(0.01) - P_3(0.01)|$ con

```
>y1:=evalf(subs(x=0.01,f));
>y2:=evalf(subs(x=0.01,p3));
>err:=abs(y1-y2);
```

Esto produce $y_1 = f(0.01) = 0.99995000042$, $y_2 = P_3(0.01) = 0.99995000000$ y $|f(0.01) - P_3(0.01)| = .42 \times 10^{-9}$.

Para obtener una gráfica similar a la figura 1.12, introducimos

```
>plot({ f,p3 },x=-Pi..Pi);
```

Las instrucciones para las integrales son

```
>q1:=int(f, x=0..0.1);
>q2:=int(p3, x=0..0.1);
>err:=abs(q1-q2);
```

con lo cual se obtienen los valores

$$q_1 = \int_0^{0.1} f(x) \, dx = 0.099833416647 \quad \text{y} \quad q_2 = \int_0^{0.1} P_3(x) \, dx = 0.099833333333,$$

con error 0.83314×10^{-7} .

En los incisos (a) y (b) del ejemplo se muestra cómo dos técnicas pueden producir la misma aproximación pero con diversas garantías de precisión. Recuerde que determinar las aproximaciones es sólo parte de nuestro objetivo. Una parte igualmente importante es determinar al menos una cota para la precisión de la aproximación.

CONJUNTO DE EJERCICIOS 1.1

- Demuestre que las siguientes ecuaciones tienen al menos una solución en los intervalos dados.
 - $x \cos x - 2x^2 + 3x - 1 = 0$, $[0.2, 0.3]$ y $[1.2, 1.3]$
 - $(x - 2)^2 - \ln x = 0$, $[1, 2]$ y $[e, 4]$
 - $2x \cos(2x) - (x - 2)^2 = 0$, $[2, 3]$ y $[3, 4]$
 - $x - (\ln x)^x = 0$, $[4, 5]$
- Determine intervalos que contengan soluciones a las siguientes ecuaciones.
 - $x - 3^{-x} = 0$
 - $4x^2 - e^x = 0$
 - $x^3 - 2x^2 - 4x + 3 = 0$
 - $x^3 + 4.001x^2 + 4.002x + 1.101 = 0$
- Demuestre que $f'(x)$ se anula al menos una vez en los intervalos dados.
 - $f(x) = 1 - e^x + (e - 1) \sin((\pi/2)x)$, $[0, 1]$
 - $f(x) = (x - 1) \tan x + x \sin \pi x$, $[0, 1]$
 - $f(x) = x \sin \pi x - (x - 2) \ln x$, $[1, 2]$
 - $f(x) = (x - 2) \sin x \ln(x + 2)$, $[-1, 3]$
- Determine $\max_{a \leq x \leq b} |f(x)|$ para las siguientes funciones e intervalos.
 - $f(x) = (2 - e^x + 2x)/3$, $[0, 1]$
 - $f(x) = (4x - 3)/(x^2 - 2x)$, $[0.5, 1]$
 - $f(x) = 2x \cos(2x) - (x - 2)^2$, $[2, 4]$
 - $f(x) = 1 + e^{-\cos(x - 1)}$, $[1, 2]$
- Use el teorema del valor intermedio y el teorema de Rolle para mostrar que la gráfica de $f(x) = x^3 + 2x + k$ cruza el eje x exactamente una vez, sin importar el valor de la constante k .
- Suponga que $f \in C[a, b]$ y que $f'(x)$ existe en (a, b) . Demuestre que si $f'(x) \neq 0$ para toda x en (a, b) , entonces puede existir a lo sumo un número p en $[a, b]$ tal que $f(p) = 0$.
- Sea $f(x) = x^3$.
 - Determine el segundo polinomio de Taylor $P_2(x)$ en torno a $x_0 = 0$.
 - Calcule $R_2(0.5)$ y el error real al usar $P_2(0.5)$ para aproximar $f(0.5)$.
 - Repita el inciso (a) usando $x_0 = 1$.
 - Repita el inciso (b) con el polinomio del inciso (c).
- Obtenga el tercer polinomio de Taylor $P_3(x)$ para la función $f(x) = \sqrt{x + 1}$ en torno a $x_0 = 0$. Aproxime $\sqrt{0.5}$, $\sqrt{0.75}$, $\sqrt{1.25}$ y $\sqrt{1.5}$ usando $P_3(x)$, y calcule los errores reales.
- Determine el segundo polinomio de Taylor $P_2(x)$ para la función $f(x) = e^x \cos x$ en torno a $x_0 = 0$.
 - Use $P_2(0.5)$ para aproximar $f(0.5)$. Determine una cota superior para el error $|f(0.5) - P_2(0.5)|$ por medio de la fórmula para el error y compárela con el error real.
 - Calcule una cota para el error $|f(x) - P_2(x)|$ al usar $P_2(x)$ para aproximar $f(x)$ en el intervalo $[0, 1]$.
 - Aproxime $\int_0^1 f(x) dx$ por medio de $\int_0^1 P_2(x) dx$.
 - Calcule una cota superior para el error en (c) mediante $\int_0^1 |R_2(x)| dx$ y compárela con el error real.
- Repita el ejercicio 9 con $x_0 = \pi/6$.
- Determine el tercer polinomio de Taylor $P_3(x)$ para la función $f(x) = (x - 1) \ln x$ respecto a $x_0 = 1$.

- a. Use $P_3(0.5)$ para aproximar $f(0.5)$. Determine una cota superior para el error $|f(0.5) - P_3(0.5)|$ por medio de la fórmula para el error y compárelo con el error real.
 - b. Calcule una cota para el error $|f(x) - P_3(x)|$ al usar $P_3(x)$ para aproximar $f(x)$ en el intervalo $[0.5, 1.5]$.
 - c. Aproxime $\int_{0.5}^{1.5} f(x) dx$ usando $\int_{0.5}^{1.5} P_3(x) dx$.
 - d. Calcule una cota superior para el error en (c) mediante $\int_{0.5}^{1.5} |R_3(x)| dx$, y compárela con el error real.
12. Sean $f(x) = 2x \cos(2x) - (x-2)^2$ y $x_0 = 0$.
- a. Determine el tercer polinomio de Taylor $P_3(x)$ y úselo para aproximar $f(0.4)$.
 - b. Use la fórmula del error en el teorema de Taylor y determine con ella una cota superior para el error $|f(0.4) - P_3(0.4)|$. Calcule el error real.
 - c. Determine el cuarto polinomio de Taylor $P_4(x)$ y úselo para aproximar $f(0.4)$.
 - d. Con la fórmula del error en el teorema de Taylor determine una cota superior para el error $|f(0.4) - P_4(0.4)|$. Calcule el error real.
13. Calcule el cuarto polinomio de Taylor $P_4(x)$ para la función $f(x) = xe^{x^2}$ en torno a $x_0 = 0$.
- a. Calcule una cota superior para $|f(x) - P_4(x)|$, con $0 \leq x \leq 0.4$.
 - b. Aproxime $\int_0^{0.4} f(x) dx$ usando $\int_0^{0.4} P_4(x) dx$.
 - c. Determine una cota superior para el error en (b) usando $\int_0^{0.4} |R_4(x)| dx$.
 - d. Aproxime $f'(0.2)$ usando $P_4'(0.2)$ y calcule el error.
14. Use el término del error de un polinomio de Taylor para estimar el error implicado al emplear $\sin x \approx x$ para aproximar $\sin 1^\circ$.
15. Use un polinomio de Taylor respecto a $\pi/4$ para aproximar $\cos 42^\circ$ con una precisión de 10^{-6} .
16. Sea $f(x) = e^{x/2} \sin(x/3)$. Utilice Maple para determinar lo siguiente.
- a. El tercer polinomio de Maclaurin $P_3(x)$.
 - b. $f^{(4)}(x)$ y una cota para el error $|f(x) - P_3(x)|$ en $[0, 1]$.
17. Sea $f(x) = \ln(x^2 + 2)$. Utilice Maple para determinar lo siguiente.
- a. El polinomio de Taylor $P_3(x)$ para f desarrollada en torno a $x_0 = 1$.
 - b. El error máximo $|f(x) - P_3(x)|$ para $0 \leq x \leq 1$.
 - c. El polinomio de Maclaurin $\tilde{P}_3(x)$ para f .
 - d. El error máximo $|f(x) - \tilde{P}_3(x)|$ para $0 \leq x \leq 1$.
 - e. ¿ $\tilde{P}_3(0)$ aproxima a $f(0)$ mejor de lo que $\tilde{P}_3(1)$ aproxima a $f(1)$?
18. Sean $f(x) = (1-x)^{-1}$ y $x_0 = 0$. Determine el n -ésimo polinomio de Taylor $P_n(x)$ para $f(x)$ en torno a x_0 . Determine un valor de n necesario para que $P_n(x)$ aproxime a $f(x)$ hasta 10^{-6} en $[0, 0.5]$.
19. Sean $f(x) = e^x$ y $x_0 = 0$. Determine el n -ésimo polinomio de Taylor $P_n(x)$ para $f(x)$ respecto a x_0 . Determine un valor de n necesario para que $P_n(x)$ aproxime a $f(x)$ hasta 10^{-6} en $[0, 0.5]$.
20. Obtenga el n -ésimo polinomio de Maclaurin $P_n(x)$ para $f(x) = \arctan x$.
21. El polinomio $P_2(x) = 1 - \frac{1}{2}x^2$ se usará para aproximar $f(x) = \cos x$ en $[-\frac{1}{2}, \frac{1}{2}]$. Determine una cota para el error máximo.
22. El n -ésimo polinomio de Taylor para una función f en x_0 se conoce a veces como un polinomio de grado n a lo sumo, que aproxima "mejor" a f cerca de x_0 .
- a. Explique por qué es adecuada esta descripción.
 - b. Determine el polinomio cuadrático que mejor aproxima una función f cerca de $x_0 = 1$ si la recta tangente en $x_0 = 1$ tiene la ecuación $y = 4x - 1$ y si $f''(1) = 6$.

23. Para obtener la aproximación 2.5 de e se utiliza un polinomio de Maclaurin para e^x . La cota del error en esta aproximación se calcula como $E = \frac{1}{6}$. Determine una cota para el error en E .
24. La función error definida como

$$\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2} dt$$

proporciona la probabilidad de que cualquiera de una serie de ensayos esté a menos de x unidades de la media, suponiendo que los ensayos tienen una distribución normal con media 0 y desviación estándar $\sqrt{2}/2$. Esta integral no se puede evaluar en términos de funciones elementales, de modo que se debe usar una técnica de aproximación.

- a. Integre la serie de Maclaurin para e^{-x^2} con el fin de mostrar que

$$\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \sum_{k=0}^{\infty} \frac{(-1)^k x^{2k+1}}{(2k+1)k!}$$

- b. La función error también se puede expresar en la forma

$$\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} e^{-x^2} \sum_{k=0}^{\infty} \frac{2^k x^{2k+1}}{1 \cdot 3 \cdot 5 \cdots (2k+1)}.$$

Verifique que las dos series coinciden para $k = 1, 2, 3$ y 4. [Sugerencia: Use la serie de Maclaurin para e^{-x^2} .]

- c. Use la serie del inciso (a) para aproximar $\operatorname{erf}(1)$ hasta 10^{-7} .
- d. Use el mismo número de términos del inciso (c) para aproximar $\operatorname{erf}(1)$ con la serie del inciso (b).
- e. Explique por qué hay dificultades al usar la serie del inciso (b) para aproximar $\operatorname{erf}(x)$.
25. Una función $f: [a, b] \rightarrow \mathbb{R}$ satisface una condición de Lipschitz con constante de Lipschitz L en $[a, b]$ si, para cada $x, y \in [a, b]$, tenemos $|f(x) - f(y)| \leq L|x - y|$.
- a. Demuestre que si f satisface una condición de Lipschitz con constante de Lipschitz en un intervalo $[a, b]$, entonces $f \in C[a, b]$.
- b. Demuestre que si f tiene una derivada acotada en $[a, b]$ por L , entonces f satisface una condición de Lipschitz con constante de Lipschitz L en $[a, b]$.
- c. Dé un ejemplo de una función que es continua en un intervalo cerrado pero que no satisfaga una condición de Lipschitz en el intervalo.
26. Suponga que $f \in C[a, b]$, que x_1 y x_2 están en $[a, b]$ y que c_1 y c_2 son constantes positivas. Demuestre que existe un número ξ entre x_1 y x_2 tal que

$$f(\xi) = \frac{c_1 f(x_1) + c_2 f(x_2)}{c_1 + c_2}.$$

27. Sean $f \in C[a, b]$ y p en el intervalo abierto (a, b) .
- a. Suponga que $f(p) \neq 0$. Demuestre que existe $\delta > 0$ tal que $f(x) \neq 0$ para toda x en $[p - \delta, p + \delta]$, donde $[p - \delta, p + \delta]$ es subconjunto de $[a, b]$.
- b. Suponga que $f(p) = 0$ y sea $k > 0$ un valor dado. Demuestre que existe $\delta > 0$ tal que $|f(x)| \leq k$ para toda x en $[p - \delta, p + \delta]$, donde $[p - \delta, p + \delta]$ es subconjunto de $[a, b]$.

El bit de la extrema izquierda es cero, lo cual indica que el número es positivo. Los siguientes 11 bits, 10000000011, que dan la característica, son equivalentes al número decimal

$$c = 1 \cdot 2^{10} + 0 \cdot 2^9 + \cdots + 0 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0 = 1024 + 2 + 1 = 1027.$$

La parte exponencial del número es, por tanto, $2^{1027-1023} = 2^4$. Los últimos 52 bits especifican que la mantisa es

$$f = 1 \cdot \left(\frac{1}{2}\right)^1 + 1 \cdot \left(\frac{1}{2}\right)^3 + 1 \cdot \left(\frac{1}{2}\right)^4 + 1 \cdot \left(\frac{1}{2}\right)^5 + 1 \cdot \left(\frac{1}{2}\right)^8 + 1 \cdot \left(\frac{1}{2}\right)^{12}.$$

En consecuencia, este número de máquina representa con precisión al número decimal

$$(-1)^s 2^{c-1023} (1+f) = (-1)^0 \cdot 2^{1027-1023} \left(1 + \left(\frac{1}{2} + \frac{1}{8} + \frac{1}{16} + \frac{1}{32} + \frac{1}{256} + \frac{1}{4096} \right) \right) \\ = 27.56640625.$$

Sin embargo, el siguiente número de máquina menor es

[illegible]

y el siguiente número de máquina mayor es

[illegible]

Esto significa que nuestro número de máquina original representa no sólo a 27.56640625, sino también a la mitad de los números reales que están entre 27.56640625 y los dos números de máquina más próximos a él. Para ser precisos, representa a cualquier número real en el intervalo

[27.566406249999982236431605997495353221893310546875,
27.5664062500000017763568394002504646778106689453125).

El menor número positivo normalizado que puede representarse tiene ceros en todas partes, excepto en el bit del extremo derecho (donde tiene un 1) y es equivalente a

$$2^{-1023} \cdot (1 + 2^{-52}) \approx 10^{-308}$$

y el mayor tiene un cero al principio seguido de unos: es equivalente a

$$2^{1024} \cdot (2 - 2^{-52}) \approx 10^{308}$$

Los números que aparecen en los cálculos y tienen una magnitud menor que 2^{-1023} . $(1+2^{-52})$ producen un **desbordamiento de la capacidad mínima o subdesbordamiento** y, por lo general, se igualan a cero. Los números mayores que $2^{1024} \cdot (2-2^{-32})$ producen un **desbordamiento*** y hacen que se detengan los cálculos.

El uso de dígitos binarios tiende a encubrir las dificultades de cálculo que aparecen al usar una colección finita de números de máquina para representar a todos los números reales. Para examinar estos problemas, supondremos, para mayor claridad, que los números de máquina se representan en la forma de punto flotante *decimal* normalizada

$$\pm 0, d_1 d_2 \dots d_n \times 10^n, \quad 1 \leq d_i \leq 9, \quad \text{y} \quad 0 \leq d_i \leq 9,$$

para cada $i = 1, 2, \dots, k$. Los números de esta forma se llaman *números de máquina decimales con k dígitos*.

* N. del R.T.: Estos conceptos se conocen también como: *overflow* y *underflow*.

Cualquier número positivo real dentro del intervalo numérico de la máquina se puede normalizar como

$$y = 0.d_1d_2\dots d_kd_{k+1}d_{k+2}\dots \times 10^a.$$

La forma de punto flotante de y , que denotamos $fl(y)$, se obtiene terminando la mantisa de y en k cifras decimales. Hay dos formas de realizar esto. Un método, llamado **truncamiento**, consiste simplemente en cortar los dígitos $d_{k+1}d_{k+2}\dots$ para obtener

$$fl(y) = 0.d_1d_2\dots d_k \times 10^a.$$

El otro método, llamado **redondeo**, suma $5 \times 10^{a-(k+1)}$ a y y luego trunca el resultado para obtener un número de la forma

$$fl(y) = 0.\delta_1\delta_2\dots \delta_k \times 10^a.$$

Así, al redondear, si $d_{k+1} \geq 5$, sumamos 1 a d_k para obtener $fl(y)$; es decir, *redondeamos hacia arriba*. Si $d_{k+1} < 5$, simplemente truncamos todo excepto los primeros k dígitos; así, *redondeamos hacia abajo*. Si el redondeo es hacia abajo, entonces $\delta_i = d_i$ para cada $i = 1, 2, \dots, k$. Sin embargo, los dígitos podrían cambiar si el redondeo es hacia arriba.

EJEMPLO 1 El número π tiene un desarrollo decimal infinito de la forma $\pi = 3.14159265\dots$. Escrito en forma decimal normalizada, tenemos

$$\pi = 0.314159265\dots \times 10^1.$$

La forma de punto flotante de π con un truncamiento a cinco cifras es

$$fl(\pi) = 0.31415 \times 10^1 = 3.1415.$$

Puesto que la sexta cifra del desarrollo decimal de π es 9, la forma de punto flotante de π con un redondeo a cinco cifras es

$$fl(\pi) = (0.31415 + 0.00001) \times 10^1 = 3.1416. \quad \blacksquare$$

El error que resulta al sustituir un número por su forma de punto flotante es el **error de redondeo** (sin importar si se determinó por truncamiento o redondeo). En la siguiente definición se describen dos métodos para medir errores de aproximación.

Definición 1.15 Si p^* es una aproximación de p , el **error absoluto** es $|p - p^*|$ y el **error relativo** es $\frac{|p - p^*|}{|p|}$, siempre que $p \neq 0$. $\blacksquare$

Considere los errores absoluto y relativo al representar p por p^* en el ejemplo siguiente.

EJEMPLO 2 a. Si $p = 0.3000 \times 10^1$ y $p^* = 0.3100 \times 10^1$, el error absoluto es 0.1 y el error relativo es 0.3333×10^{-1} .

- b. Si $p = 0.3000 \times 10^{-3}$ y $p^* = 0.3100 \times 10^{-3}$, el error absoluto es 0.1×10^{-4} y el error relativo es $0.333\bar{3} \times 10^{-1}$.
- c. Si $p = 0.3000 \times 10^4$ y $p^* = 0.3100 \times 10^4$, el error absoluto es 0.1×10^3 y el error relativo es de nuevo $0.333\bar{3} \times 10^{-1}$.

Este ejemplo muestra que ocurre el mismo error relativo, $0.333\bar{3} \times 10^{-1}$, para una gran variedad de errores absolutos. Como una medida de la precisión, el error absoluto puede llevar a confusiones, en tanto que el error relativo es más significativo, pues toma en cuenta el tamaño del valor. ■

La siguiente definición utiliza el error relativo como una medida de las cifras significativas de precisión para una aproximación.

Definición 1.16 El número p^* aproxima a p con t cifras significativas si t es el mayor entero no negativo para el cual

$$\frac{|p - p^*|}{|p|} < 5 \times 10^{-t}.$$

En la tabla 1.1 se ilustra la naturaleza continua de las cifras significativas al enumerar, para diversos valores de p , la mínima cota superior de $|p - p^*|$, que se denota $\max |p - p^*|$, cuando p^* coincide con p hasta cuatro cifras significativas.

Tabla 1.1.

p	0.1	0.5	100	1000	5000	9990	10000
$\max p - p^* $	0.00005	0.00025	0.05	0.5	2.5	4.995	5.

De regreso a la representación de los números en la máquina, vemos que $fl(y)$ como punto flotante para el número y tiene el error relativo

$$\left| \frac{y - fl(y)}{y} \right|.$$

Si se usan k cifras decimales y el truncamiento para la representación en la máquina de

$$y = 0.d_1d_2\dots d_kd_{k+1}\dots \times 10^n,$$

entonces

$$\begin{aligned} \left| \frac{y - fl(y)}{y} \right| &= \left| \frac{0.d_1d_2\dots d_kd_{k+1}\dots \times 10^n - 0.d_1d_2\dots d_k \times 10^n}{0.d_1d_2\dots \times 10^n} \right| \\ &= \left| \frac{0.d_{k+1}d_{k+2}\dots \times 10^{n-k}}{0.d_1d_2\dots \times 10^n} \right| = \left| \frac{0.d_{k+1}d_{k+2}\dots}{0.d_1d_2\dots} \right| \times 10^{-k}. \end{aligned}$$

Como $d_1 \neq 0$, el valor mínimo del denominador es 0.1. El 1 es la cota superior del numerador. En consecuencia,

$$\left| \frac{y - fl(y)}{y} \right| \leq \frac{1}{0.1} \times 10^{-k} = 10^{-k+1}.$$

De manera similar, una cota para el error relativo al usar la aritmética de redondeo a k cifras es $0.5 \times 10^{-k+1}$. (Véase el ejercicio 24.)

Observe que las cotas para el error relativo al usar la aritmética con k cifras son independientes del número representado. Este resultado se debe a la manera en que se distribuyen los números de máquina a lo largo de la recta real. Debido a la forma exponencial de la característica, se usa la misma cantidad de números decimales de máquina para representar cada uno de los intervalos $[0.1, 1]$, $[1, 10]$ y $[10, 100]$. De hecho, dentro de los límites de la máquina, la cantidad de números decimales de máquina en $[10^n, 10^{n+1}]$ es constante para todo entero n .

Además de la representación imprecisa de los números, la aritmética realizada en una computadora no es exacta. La aritmética implica el manejo de los dígitos binarios mediante diversas operaciones de corrimiento, o lógicas. Como la mecánica real de estas operaciones no es pertinente a esta presentación, diseñaremos nuestro propio enfoque de la aritmética de una computadora. Aunque nuestra aritmética no dará la imagen exacta, bastará para explicar los problemas potenciales. (Para una explicación de la mecánica real, el lector deberá consultar textos de ciencias de la computación más orientados a los aspectos técnicos, como [Ma], *Computer System Architecture*.)

Suponga que se tienen las representaciones de punto flotante $fl(x)$ y $fl(y)$ para los números reales x y y , y que los símbolos $\oplus$, $\ominus$, $\otimes$, $\oslash$ representan las operaciones de suma, resta, multiplicación y división en la máquina, respectivamente. Supondremos que se usa una aritmética con un número finito de cifras dada por

$$\begin{aligned}x \oplus y &= fl(fl(x) + fl(y)), & x \otimes y &= fl(fl(x) \times fl(y)), \\x \ominus y &= fl(fl(x) - fl(y)), & x \oslash y &= fl(fl(x) \div fl(y)).\end{aligned}$$

Esto corresponde a realizar la aritmética exacta con las representaciones de punto flotante de x y y , para luego convertir el resultado exacto en su representación de punto flotante con un número finito de cifras.

La aritmética de redondeo se lleva a cabo fácilmente en un sistema de álgebra por computadora. La instrucción de Maple

```
>Digits:=t;
```

hace que toda la aritmética se redondee a t cifras. Por ejemplo, $fl(fl(x) + fl(y))$ se realiza con aritmética de redondeo a t cifras mediante

```
>evalf(evalf(x)+evalf(y));
```

La ejecución de la aritmética de truncamiento a t cifras es más difícil y requiere una serie de pasos o un procedimiento. En el ejercicio 27 se estudia este problema.

EJEMPLO 3 Suponga que $x = \frac{5}{7}$, $y = \frac{1}{3}$ y que se usa el truncamiento a cinco cifras para los cálculos aritméticos donde intervienen x y y . En la tabla 1.2 se enumeran los valores de estas operaciones de tipo computadora con $fl(x) = 0.71428 \times 10^0$ y $fl(y) = 0.33333 \times 10^0$. ■

Tabla 1.2

Operación	Resultado	Valor real	Error absoluto	Error relativo
$x \oplus y$	0.10476×10^1	22/21	0.190×10^{-4}	0.182×10^{-4}
$x \ominus y$	0.38095×10^0	8/21	0.238×10^{-5}	0.625×10^{-5}
$x \otimes y$	0.23809×10^0	5/21	0.524×10^{-5}	0.220×10^{-4}
$y \oslash x$	0.21428×10^1	15/7	0.571×10^{-4}	0.267×10^{-4}

Como el máximo error relativo para las operaciones del ejemplo 3 es 0.267×10^{-4} , la aritmética produce resultados satisfactorios con cinco cifras. Suponga, sin embargo, que también tenemos los números $u = 0.714251$, $v = 98765.9$ y $w = 0.111111 \times 10^{-4}$, de modo que $fl(u) = 0.71425 \times 10^0$, $fl(v) = 0.98765 \times 10^5$ y $fl(w) = 0.11111 \times 10^{-4}$. (Elegimos estos números para ilustrar algunos problemas que pueden surgir con la aritmética cuando se tiene una cantidad finita de cifras.)

En la tabla 1.3, $x \ominus u$ produce un error absoluto pequeño, pero un error relativo grande. La división posterior entre el número pequeño w o la multiplicación por el número grande v aumenta el error absoluto, sin modificar el error relativo. La suma de los números grande y pequeño u y v produce un error absoluto grande pero no uno relativo similar.

Tabla 1.3

Operación	Resultado	Valor real	Error absoluto	Error relativo
$x \ominus u$	0.30000×10^{-4}	0.34714×10^{-4}	0.471×10^{-5}	0.136
$(x \ominus u) \oplus w$	0.29629×10^1	0.34285×10^1	0.465	0.136
$(x \ominus u) \otimes v$	0.29629×10^1	0.34285×10^1	0.465	0.136
$u \oplus v$	0.98765×10^5	0.98766×10^5	0.161×10^1	0.163×10^{-4}

Uno de los los cálculos más comunes que producen errores tiene que ver con la cancelación de cifras significativas debido a la resta de números casi iguales. Suponga que dos números casi iguales x y y , con $x > y$, tienen las representaciones de k cifras

$$fl(x) = 0.d_1d_2 \dots d_p\alpha_{p+1}\alpha_{p+2} \dots \alpha_k \times 10^p,$$

y

$$fl(y) = 0.d_1d_2 \dots d_p\beta_{p+1}\beta_{p+2} \dots \beta_k \times 10^p.$$

La forma de punto flotante de $x - y$ es

$$fl(fl(x) - fl(y)) = 0.\sigma_{p+1}\sigma_{p+2} \dots \sigma_k \times 10^{p-p},$$

donde

$$0.\sigma_{p+1}\sigma_{p+2} \dots \sigma_k = 0.\alpha_{p+1}\alpha_{p+2} \dots \alpha_k - 0.\beta_{p+1}\beta_{p+2} \dots \beta_k.$$

El número de punto flotante utilizado para representar $x - y$ tiene a lo sumo $k - p$ cifras significativas. Sin embargo, en la mayor parte de los dispositivos de cálculo a $x - y$ se le asignarán k cifras, de modo que las últimas p se anularán o serán asignadas al azar. En todos los cálculos posteriores con $x - y$ se tendrá el problema de contar con $k - p$ cifras significativas, pues una cadena de cálculos no es más precisa que su parte más débil.

Si una representación con un número finito de cifras o un cálculo introduce un error, éste aumenta al dividir entre un número con magnitud pequeña (o, en forma equivalente, al multiplicar por un número con magnitud grande). Suponga, por ejemplo, que el número z tiene la aproximación con un número finito de cifras $z + \delta$, donde el error δ surge por la representación o un cálculo anterior. Suponga ahora que dividimos entre $\varepsilon = 10^{-n}$, donde $n > 0$. Entonces

$$\frac{z}{\varepsilon} \approx fl\left(\frac{fl(z)}{fl(\varepsilon)}\right) = (z + \delta) \times 10^n.$$

Así, el error absoluto en esta aproximación, $|\delta| \times 10^n$, es el error absoluto original, $|\delta|$, multiplicado por el factor 10^n .

EJEMPLO 4 Sean $p = 0.54617$ y $q = 0.54601$. El valor exacto de $r = p - q$ es $r = 0.00016$. Suponga que la resta se realiza con una aritmética de cuatro cifras. Al redondear p y q a cuatro cifras, tenemos $p^* = 0.5462$ y $q^* = 0.5460$, respectivamente, y $r^* = p^* - q^* = 0.0002$ es la aproximación de cuatro cifras de r . Como

$$\frac{|r - r^*|}{|r|} = \frac{|0.00016 - 0.0002|}{|0.00016|} = 0.25,$$

el resultado sólo tiene una cifra significativa, en tanto que la precisión para p^* y q^* fue de cuatro y cinco cifras significativas, respectivamente.

Si se usa el truncamiento para obtener las cuatro cifras, las aproximaciones de cuatro cifras de p , q y r son $p^* = 0.5461$, $q^* = 0.5460$ y $r^* = p^* - q^* = 0.0001$. Con esto se obtiene

$$\frac{|r - r^*|}{|r|} = \frac{|0.00016 - 0.0001|}{|0.00016|} = 0.375,$$

lo que también produce sólo una cifra de precisión. ■

La pérdida de precisión debida al error de redondeo se puede evitar a menudo mediante la reformulación del problema, como se muestra en el siguiente ejemplo.

EJEMPLO 5 La fórmula cuadrática establece que las raíces de $ax^2 + bx + c = 0$, cuando $a \neq 0$, son

$$x_1 = \frac{-b + \sqrt{b^2 - 4ac}}{2a} \quad \text{y} \quad x_2 = \frac{-b - \sqrt{b^2 - 4ac}}{2a}. \quad (1.1)$$

Con aritmética de redondeo a cuatro cifras, considere esta fórmula aplicada a la ecuación $x^2 + 62.10x + 1 = 0$, cuyas raíces son aproximadamente

$$x_1 = -0.01610723 \quad \text{y} \quad x_2 = -62.08390.$$

En esta ecuación, b^2 es mucho mayor que $4ac$, de modo que el numerador en el cálculo de x_1 implica la *resta* de números casi iguales. Como

$$\begin{aligned} \sqrt{b^2 - 4ac} &= \sqrt{(62.10)^2 - (4.000)(1.000)(1.000)} = \sqrt{3856. - 4.000} = \sqrt{3852}, \\ &= 62.06, \end{aligned}$$

tenemos

$$f1(x_1) = \frac{-62.10 + 62.06}{2.000} = \frac{-0.04000}{2.000} = -0.02000,$$

una mala aproximación a $x_1 = -0.01611$, con el error relativo grande

$$\frac{|-0.01611 + 0.02000|}{|-0.01611|} \approx 2.4 \times 10^{-1}.$$

Por otro lado, el cálculo de x_2 implica la *suma* de los números casi iguales $-b$ y $-\sqrt{b^2 - 4ac}$. Esto no presenta problemas, pues

$$f1(x_2) = \frac{-62.10 - 62.06}{2.000} = \frac{-124.2}{2.000} = -62.10$$

tiene el error relativo pequeño

$$\frac{|-62.08 + 62.10|}{|-62.08|} \approx 3.2 \times 10^{-4}.$$

Para obtener una aproximación más precisa con redondeo a cuatro cifras para x_1 , se cambia la forma de la fórmula cuadrática mediante la *racionalización del numerador*:

$$x_1 = \frac{-b + \sqrt{b^2 - 4ac}}{2a} \left(\frac{-b - \sqrt{b^2 - 4ac}}{-b - \sqrt{b^2 - 4ac}} \right) = \frac{b^2 - (b^2 - 4ac)}{2a(-b - \sqrt{b^2 - 4ac})},$$

lo que se simplifica como una fórmula cuadrática alternativa

$$x_1 = \frac{-2c}{b + \sqrt{b^2 - 4ac}}. \quad (1.2)$$

Al usar (1.2) tenemos

$$f(x_1) = \frac{-2.000}{62.10 + 62.06} = \frac{-2.000}{124.2} = -0.01610,$$

con el pequeño error relativo 6.2×10^{-4} . ■

La técnica de racionalización se puede aplicar también para obtener la siguiente fórmula cuadrática alternativa para x_2 :

$$x_2 = \frac{-2c}{b - \sqrt{b^2 - 4ac}}. \quad (1.3)$$

Esta forma se utilizará si b es un número negativo. Sin embargo, en el ejemplo 5, el uso incorrecto de esta fórmula para x_2 no sólo produciría la resta de números casi iguales, sino también la división entre el resultado pequeño de esta resta. La imprecisión que esta combinación produce,

$$f(x_2) = \frac{-2c}{b - \sqrt{b^2 - 4ac}} = \frac{-2.000}{62.10 - 62.06} = \frac{-2.000}{0.04000} = -50.00,$$

tiene el gran error relativo 1.9×10^{-1} .

La pérdida de precisión debida a un error de redondeo también se puede reducir reordenando los cálculos, como se muestra en el siguiente ejemplo.

EJEMPLO 6 Evalúe $f(x) = x^3 - 6.1x^2 + 3.2x + 1.5$ en $x = 4.71$ con una aritmética de tres cifras.

En la tabla 1.4 se dan los resultados intermedios de los cálculos. Verifique con cuidado estos resultados para asegurarse de que es correcto su concepto de aritmética con un número finito de cifras. Observe que los valores truncados a tres cifras sólo conservan las tres primeras, sin ningún redondeo; estos valores difieren de manera significativa de los valores redondeados a tres cifras.

Tabla 1.4

	x	x^2	x^3	$6.1x^2$	$3.2x$
Exacto	4.71	22.1841	104.487111	135.32301	15.072
Tres cifras (truncamiento)	4.71	22.1	104.	134.	15.0
Tres cifras (redondeo)	4.71	22.2	105.	135.	15.1

$$\text{Exacto: } f(4.71) = 104.487111 - 135.32301 + 15.072 + 1.5 \\ = -14.263899;$$

$$\text{Tres cifras (truncamiento): } f(4.71) = ((104. - 134.) + 15.0) + 1.5 = -13.5;$$

$$\text{Tres cifras (redondeo): } f(4.71) = ((105. - 135.) + 15.1) + 1.5 = -13.4.$$

Los errores relativos para los métodos con tres cifras son

$$\left| \frac{-14.263899 + 13.5}{-14.263899} \right| \approx 0.05, \quad \text{para truncamiento}$$

y

$$\left| \frac{-14.263899 + 13.4}{-14.263899} \right| \approx 0.06, \quad \text{para redondeo.}$$

Como método alternativo, $f(x)$ se puede escribir de una manera **anidada** como

$$f(x) = x^3 - 6.1x^2 + 3.2x + 1.5 = ((x - 6.1)x + 3.2)x + 1.5.$$

Esto da como resultado

$$\text{Tres cifras (truncamiento): } f(4.71) = ((4.71 - 6.1)4.71 + 3.2)4.71 + 1.5 = -14.2$$

y una respuesta con redondeo a tres cifras de -14.3 . Los nuevos errores relativos son

$$\text{Tres cifras (truncamiento): } \left| \frac{-14.263899 + 14.2}{-14.263899} \right| \approx 0.0045;$$

$$\text{Tres cifras (redondeo): } \left| \frac{-14.263899 + 14.3}{-14.263899} \right| \approx 0.0025.$$

El anidamiento redujo el error relativo para la aproximación por truncamiento a menos de 10% del original. Para la aproximación por redondeo, la mejora ha sido más drástica; el error en este caso se redujo más de 95%. ■

Los polinomios *siempre* deben expresarse en forma anidada antes de realizar cualquier evaluación, pues esta forma minimiza el número de cálculos aritméticos. La disminución del error en el ejemplo 6 se debe a la reducción de los cálculos, de cuatro multiplicaciones y tres sumas a dos multiplicaciones y tres sumas. Una forma de reducir los errores de redondeo consiste en reducir el número de cálculos que pueden producir errores.

CONJUNTO DE EJERCICIOS 1.2

1. Calcule el error absoluto y el error relativo en las aproximaciones de p mediante p^* .

a. $p = \pi, p^* = 22/7$

b. $p = \pi, p^* = 3.1416$

c. $p = e, p^* = 2.718$

d. $p = \sqrt{2}, p^* = 1.414$

- e. $p = e^{10}, p^* = 22000$ f. $p = 10^\pi, p^* = 1400$
 g. $p = 8!, p^* = 39900$ h. $p = 9!, p^* = \sqrt{18\pi} (9/e)^9$
2. Determine el mayor intervalo en que debe estar p^* para aproximar p con un error relativo de a lo sumo 10^{-4} para cada valor de p .
 a. π b. e c. $\sqrt{2}$ d. $\sqrt[3]{7}$
3. Suponga que p^* debe aproximar a p con un error relativo a lo sumo 10^{-3} . Determine el máximo intervalo en que debe estar p^* para cada valor de p .
 a. 150 b. 900 c. 1500 d. 90
4. Realice los siguientes cálculos (i) en forma exacta, (ii) mediante una aritmética de truncamiento a tres cifras y (iii) con una aritmética de redondeo a tres cifras. (iv) Calcule los errores relativos en los incisos (ii) y (iii).
 a. $\frac{4}{5} + \frac{1}{3}$ b. $\frac{4}{5} \cdot \frac{1}{3}$
 c. $\left(\frac{1}{3} - \frac{3}{11}\right) + \frac{3}{20}$ d. $\left(\frac{1}{3} + \frac{3}{11}\right) - \frac{3}{20}$
5. Use una aritmética de redondeo a tres cifras para los siguientes cálculos. Calcule el error absoluto y el error relativo con el valor exacto determinado a por lo menos cinco cifras.
 a. $133 + 0.921$ b. $133 - 0.499$
 c. $(121 - 0.327) - 119$ d. $(121 - 119) - 0.327$
 e. $\frac{\frac{13}{14} - \frac{6}{7}}{2e - 5.4}$ f. $-10\pi + 6e - \frac{3}{62}$
 g. $\left(\frac{2}{9}\right) \cdot \left(\frac{9}{7}\right)$ h. $\frac{\pi - \frac{22}{7}}{\frac{1}{17}}$
6. Repita el ejercicio 5 usando una aritmética de redondeo a cuatro cifras.
 7. Repita el ejercicio 5 con una aritmética de truncamiento a tres cifras.
 8. Repita el ejercicio 5 mediante una aritmética de truncamiento a cuatro cifras.
 9. Los primeros tres términos no nulos de la serie de Maclaurin para la función arco tangente son $x - (1/3)x^3 + (1/5)x^5$. Calcule el error absoluto y el error relativo en las siguientes aproximaciones de π usando el polinomio en vez de la función arco tangente.
 a. $4\left[\arctan\left(\frac{1}{2}\right) + \arctan\left(\frac{1}{3}\right)\right]$ b. $16\arctan\left(\frac{1}{5}\right) - 4\arctan\left(\frac{1}{239}\right)$
10. El número e se puede definir como $e = \sum_{n=0}^{\infty} (1/n!)$, donde $n! = n(n-1) \cdots 2 \cdot 1$ para $n \neq 0$ y $0! = 1$. Calcule el error absoluto y el error relativo en las siguientes aproximaciones de e :
 a. $\sum_{n=0}^5 \frac{1}{n!}$ b. $\sum_{n=0}^{10} \frac{1}{n!}$
11. Sea
- $$f(x) = \frac{x \cos x - \sin x}{x - \sin x}.$$
- a. Calcule $\lim_{x \rightarrow 0} f(x)$.
 b. Use una aritmética de redondeo a cuatro cifras para evaluar $f(0.1)$.
 c. Reemplace cada función trigonométrica por su tercer polinomio de Maclaurin y repita el inciso (b).
 d. El valor real es $f(0.1) = -1.99899998$. Determine el error relativo para los valores obtenidos en los incisos (b) y (c).

establezca $m = \frac{c}{a}$, siempre que $a \neq 0$;

$$d_1 = d - mb;$$

$$f_1 = f - me;$$

$$y = \frac{f_1}{d_1};$$

$$x = \frac{(e - by)}{a}.$$

Resuelva los siguientes sistemas lineales mediante una aritmética de redondeo a cuatro cifras.

a. $1.130x - 6.990y = 14.20$

b. $1.013x - 6.099y = 14.22$

c. $8.110x + 12.20y = -0.1370$

d. $-18.11x + 112.2y = -0.1376$

20. Repita el ejercicio 19 con una aritmética de truncamiento a cuatro cifras.

21. a. Demuestre que la técnica de anidamiento de polinomios descrita en el ejemplo 6 también sirve para evaluar

$$f(x) = 1.01e^{4x} - 4.62e^{3x} - 3.11e^{2x} + 12.2e^x - 1.99.$$

b. Use una aritmética de redondeo a tres cifras, con el supuesto de que $e^{1.53} = 4.62$ y el hecho de que $e^{nx} = (e^x)^n$ para evaluar $f(1.53)$ según lo dado en el inciso (a).

c. Repita el inciso (b) pero primero anide los cálculos.

d. Compare las aproximaciones de los incisos (b) y (c) con el resultado real hasta tres cifras $f(1.53) = -7.61$.

22. Un paralelepípedo rectangular tiene lados de longitudes 3, 4 y 5 cm, medidos al centímetro más cercano. ¿Cuáles son las mejores cotas inferior y superior para el volumen de este paralelepípedo y cuáles para el área de su superficie?

23. Sea $P_n(x)$ el polinomio de Maclaurin de grado n para la función arco tangente. Por medio de Maple con 75 cifras decimales determine el valor de n necesario para aproximar π dentro de 10^{-25} con las fórmulas siguientes.

a. $4 \left[P_n\left(\frac{1}{2}\right) + P_n\left(\frac{1}{3}\right) \right]$

b. $16P_n\left(\frac{1}{5}\right) - 4P_n\left(\frac{1}{239}\right)$

24. Suponga que $fl(y)$ es una aproximación de y con un redondeo a k cifras. Demuestre que

$$\left| \frac{y - fl(y)}{y} \right| \leq 0.5 \times 10^{-k+1}.$$

[Sugerencia: si $d_{k+1} < 5$, entonces $fl(y) = 0.d_1d_2 \dots d_k \times 10^n$. Si $d_{k+1} \geq 5$, entonces $fl(y) = 0.d_1d_2 \dots d_k \times 10^n + 10^{n-k}$.]

25. El coeficiente binomial

$$\binom{m}{k} = \frac{m!}{k!(m-k)!}$$

describe el número de formas para elegir un subconjunto de k objetos en un conjunto con m elementos.

a. Suponga que los números decimales de máquina tienen la forma

$$\pm 0.d_1d_2d_3d_4 \times 10^n, \quad \text{con } 1 \leq d_i \leq 9, 0 \leq d_i \leq 9 \quad \text{si } i = 2, 3, 4 \quad \text{y} \quad |n| \leq 15.$$

¿Cuál es el mayor valor de m para el que el coeficiente binomial $\binom{m}{k}$, pueda calcularse para cualquier k mediante la definición sin causar desbordamiento?

- b. Demuestre que $\binom{n}{k}$ también se puede calcular como

$$\binom{m}{k} = \binom{m}{k} \left(\frac{m-1}{k-1} \right) \cdots \left(\frac{m-k+1}{1} \right).$$

- c. ¿Cuál es el mayor valor de m para que el coeficiente binomial $\binom{m}{3}$ pueda calcularse mediante la fórmula del inciso (b) sin causar un sobreflujo?
- d. Use la ecuación en (b) y una aritmética de truncamiento a cuatro cifras para calcular el número de manos posibles de 5 cartas en una baraja con 52 cartas. Calcule los errores real y relativo.
26. Sea $f \in C[a, b]$ una función cuya derivada existe en (a, b) . Suponga que se evaluará a f en x_0 en (a, b) , pero en vez de calcular el valor real $f(x_0)$, el valor aproximado $\tilde{f}(x_0)$, es el valor real de f en $x_0 + \epsilon$; es decir, $\tilde{f}(x_0) = f(x_0 + \epsilon)$.
- a. Use el teorema del valor medio para estimar el error absoluto $|f(x_0) - \tilde{f}(x_0)|$ y el error relativo $|f(x_0) - \tilde{f}(x_0)| / |f(x_0)|$, suponiendo que $f(x_0) \neq 0$.
- b. Si $\epsilon = 5 \times 10^{-6}$ y $x_0 = 1$, calcule las cotas de los errores absoluto y relativo para
- i. $f(x) = e^x$ ii. $f(x) = \sin x$
- c. Repita el inciso (b) con $\epsilon = (5 \times 10^{-6})x_0$ y $x_0 = 10$.
27. El siguiente procedimiento de Maple trunca un número de punto flotante x en t cifras.

```
chop:=proc(x,t);
  if x=0 then 0
  else
    e:=trunc(evalf(log10(abs(x))));
    if e>0 then e:=e+1 fi;
    x2:=evalf(trunc(x*10^(t-e))*10^(-t));
  fi
end;
```

Verifique que el procedimiento funciona para los siguientes valores.

28. En el ejemplo inicial de este capítulo se describió un experimento físico relativo a la temperatura de un gas bajo presión. En esta aplicación, teníamos que $P = 1.00$ atmósfera, $V = 0.100 \text{ m}^3$, $N = 0.00420$ moles y $R = 0.08206$. Al despejar T en la ley del gas ideal tenemos

$$T = \frac{PV}{NR} = \frac{(1.00)(0.100)}{(0.00420)(0.008206)} = 290.15 \text{ K} = 17^\circ \text{C}.$$

En el laboratorio se determinó que bajo estas condiciones la temperatura T era de 15°C , y que al duplicar la presión y reducir el volumen a la mitad, T era igual a 19°C . Suponga que los datos están redondeados con una precisión igual al número de cifras dadas y demuestre que las cifras del laboratorio están dentro de las cotas de precisión de la ley del gas ideal.

1.3 Algoritmos y convergencia

En el texto estaremos analizando procedimientos de aproximación, llamados *algoritmos*, relacionados con series de cálculos. Un **algoritmo** es un procedimiento que describe, sin ambigüedades, una serie finita de pasos a realizar en un orden específico. El objeto del algoritmo es poner en práctica un procedimiento para resolver un problema o aproximarse a una solución del problema.

Usaremos un **seudocódigo** para describir los algoritmos. Este pseudocódigo especifica la forma de la entrada por proporcionar y la forma de la salida deseada. No con todos los procedimientos numéricos se obtiene una salida satisfactoria para una entrada elegida de manera arbitraria. Como consecuencia, en cada algoritmo se incorpora una técnica para detenerlo, independiente de la técnica numérica, para evitar ciclos infinitos.

En los algoritmos se usan dos símbolos de puntuación:

Un punto (.) indica el fin de un paso,

el punto y coma (;) separa las tareas dentro de un paso.

Las sangrías se usan para indicar que los grupos de enunciados deben considerarse como una sola entidad.

Las técnicas de formación de ciclos en los algoritmos son controladas por un contador, como por ejemplo,

Para $i = 1, 2, \dots, n$

Establezca $x_i = a_i + i \cdot h$

o por una condición, como

Mientras $i < N$ ejecute Pasos 3–6.

Para permitir una ejecución condicional, usamos las construcciones estándar

Si ... entonces

o

Si ... entonces

otras

construcciones

Los pasos en los algoritmos siguen las reglas de la construcción estructurada de programas. Los hemos organizado de modo que haya pocas dificultades para traducir el pseudocódigo a cualquier lenguaje de programación adecuado para las aplicaciones científicas.

A los algoritmos se les añaden comentarios escritos en cursivas y dentro de paréntesis para distinguirlos de los enunciados de los algoritmos.

EJEMPLO 1 Un algoritmo para calcular

$$\sum_{i=1}^N x_1 + x_2 + \dots + x_N$$

donde N y los números $x_1, x_2, \dots, x_N$ están dados, se describe como sigue:

ENTRADA $N, x_1, x_2, \dots, x_N$

SALIDA $SUMA = \sum_{i=1}^N x_i$

Paso 1 Establezca $SUMA = 0$. (Inicializa el acumulador.)

Paso 2 Para $i = 1, 2, \dots, N$ haga
 fijar $SUMA = SUMA + x_i$. (Agrega el siguiente término.)

Paso 3 SALIDA ($SUMA$);
 PARAR.

EJEMPLO 2 El N -ésimo polinomio de Taylor para $f(x) = \ln x$ desarrollado en torno a $x_0 = 1$ es

$$P_N(x) = \sum_{i=1}^N \frac{(-1)^{i+1}}{i} (x-1)^i,$$

y el valor de $\ln 1.5$ con ocho cifras decimales es 0.40546511. Suponga que queremos calcular el valor mínimo de N necesario para que

$$|\ln 1.5 - P_N(1.5)| < 10^{-3}$$

sin usar el término del residuo en el polinomio de Taylor. En los cursos de cálculo aprendimos que si $\sum_{n=1}^{\infty} a_n$ es una serie alternante con límite A cuyos términos disminuyen en magnitud, entonces A y la N -ésima suma parcial $A_N = \sum_{n=1}^N a_n$ difieren por menos que la magnitud del $(N+1)$ -ésimo término; es decir,

$$|A - A_N| \leq |a_{N+1}|.$$

El siguiente algoritmo usa esta cota.

ENTRADA valor x , tolerancia TOL , número máximo de iteraciones M .

SALIDA grado N del polinomio o un mensaje de error.

Paso 1 Establezca $N = 1$;

$y = x - 1$;

$SUMA = 0$;

$POTENCIA = y$;

$TÉRMINO = y$;

$SIGNO = -1$. (Se usa para ejecutar la alternancia de signos.)

Paso 2 Mientras $N \leq M$ realice los Pasos 3-5.

 Paso 3 Fijar $SIGNO = -SIGNO$. (Alterna los signos.)

$SUMA = SUMA + SIGNO \cdot TÉRMINO$; (Acumula los términos.)

$POTENCIA = POTENCIA \cdot y$;

$TÉRMINO = POTENCIA/(N+1)$. (Calcula el siguiente término.)

Paso 4 Si $|TÉRMINO| < TOL$ entonces (Verifica la precisión.)
 SALIDA (N);
 PARAR. (El procedimiento tuvo éxito.)

Paso 5 Fijar $N = N + 1$. (Prepara la siguiente iteración.)

Paso 6 SALIDA('El método falló'); (El procedimiento no tuvo éxito.)
 PARAR.

La entrada de nuestro problema es $x = 1.5$, $TOL = 10^{-5}$ y tal vez $M = 15$. Esta elección de M proporciona una cota superior para el número de cálculos que estamos dispuestos a realizar, reconociendo la posibilidad de que falle el algoritmo si se excede esta cota. El hecho de que la salida sea el valor de N o el mensaje de error depende de la precisión del dispositivo utilizado para realizar los cálculos. ■

Nos interesa elegir métodos que produzcan resultados precisos (según las circunstancias) para una amplia variedad de problemas. Uno de los criterios que siempre trataremos de imponer sobre un algoritmo es que los cambios pequeños en los datos iniciales produzcan otros correspondientes en los resultados finales. Un algoritmo que satisfaga esta propiedad es **estable**; en caso contrario, **inestable**. Algunos algoritmos sólo son estables para ciertas elecciones de datos iniciales; a estos se les llama **condicionalmente estables**. Caracterizaremos las propiedades de estabilidad de los algoritmos siempre que sea posible.

Para continuar nuestro análisis del crecimiento de los errores de redondeo y su relación con la estabilidad de un algoritmo, suponga que se introduce un error de magnitud $E_0 > 0$ en cierta etapa de los cálculos y que se denota por E_n la magnitud del error después de n operaciones sucesivas. Los dos casos que surgen con más frecuencia en la práctica se definen como sigue.

Definición 1.17 Suponga que $E_0 > 0$ denota un error inicial y E_n representa la magnitud de un error después de n operaciones sucesivas. Si $E_n = CnE_0$, donde C es una constante independiente de n , entonces se dice que el crecimiento del error es **lineal**. Si $E_n = C^n E_0$ para alguna $C > 1$, entonces el crecimiento del error se denomina **exponencial**. ■

Normalmente es inevitable el crecimiento lineal del error y, cuando C y E_0 son pequeños, por lo general son aceptables los resultados. Por otro lado, hay que evitar el crecimiento exponencial del error, pues el término C^n crece incluso para valores de n relativamente pequeños. Esto conduce a imprecisiones inaceptables, sin importar el tamaño de E_0 . En consecuencia, un algoritmo que exhibe un crecimiento lineal del error es estable, pero no así un algoritmo con crecimiento exponencial del error. (Véase la figura 1.13 de la página 34.)


EJEMPLO 3 La ecuación recursiva

$$p_n = \frac{10}{3} p_{n-1} - p_{n-2}, \quad \text{para } n = 2, 3, \dots$$

tiene la solución

$$p_n = c_1 \left(\frac{1}{3}\right)^n + c_2 3^n,$$

Figura 1.13



para cualesquiera constantes c_1 y c_2 pues

$$\begin{aligned} \frac{10}{3} p_{n-1} - p_{n-2} &= \frac{10}{3} \left[c_1 \left(\frac{1}{3} \right)^{n-1} + c_2 3^{n-1} \right] - \left[c_1 \left(\frac{1}{3} \right)^{n-2} + c_2 3^{n-2} \right] \\ &= c_1 \left(\frac{1}{3} \right)^{n-2} \left[\frac{10}{3} \cdot \frac{1}{3} - 1 \right] + c_2 3^{n-2} \left[\frac{10}{3} \cdot 3 - 1 \right] \\ &= c_1 \left(\frac{1}{3} \right)^{n-2} \left(\frac{1}{9} \right) + c_2 3^{n-2} (9) = c_1 \left(\frac{1}{3} \right)^n + c_2 3^n = p_n. \end{aligned}$$

Si $p_0 = 1$ y $p_1 = \frac{1}{3}$, tenemos $c_1 = 1$ y $c_2 = 0$, de modo que $p_n = \left(\frac{1}{3}\right)^n$ para toda n . Suponga que usa una aritmética de redondeo a cinco cifras para calcular los términos de la sucesión dada por esta ecuación. Entonces $\hat{p}_0 = 1.0000$ y $\hat{p}_1 = 0.33333$, lo cual requiere modificar las constantes a $\hat{c}_1 = 1.0000$ y $\hat{c}_2 = -0.12500 \times 10^{-5}$. Así que la sucesión $\{\hat{p}_n\}_{n=0}^{\infty}$ generada está dada por

$$\hat{p}_n = 1.0000 \left(\frac{1}{3} \right)^n - 0.12500 \times 10^{-5} (3)^n,$$

y el error de redondeo,

$$p_n - \hat{p}_n = 0.12500 \times 10^{-5} (3^n),$$

crece en forma exponencial con n . Esto se refleja en las imprecisiones extremas después de los primeros términos, como se muestra en la tabla 1.5.

Por otro lado, la ecuación de recurrencia

$$p_n = 2p_{n-1} - p_{n-2}, \quad \text{para } n = 2, 3, \dots$$

Tabla 1.5

n	$\hat{p}_n$ calculado	p_n correcto	Error relativo
0	0.10000×10^1	0.10000×10^1	
1	0.33333×10^0	0.33333×10^0	
2	0.11110×10^0	0.11111×10^0	9×10^{-5}
3	0.37000×10^{-1}	0.37037×10^{-1}	1×10^{-3}
4	0.12230×10^{-1}	0.12346×10^{-1}	9×10^{-3}
5	0.37660×10^{-2}	0.41152×10^{-2}	8×10^{-2}
6	0.32300×10^{-3}	0.13717×10^{-2}	8×10^{-2}
7	-0.26893×10^{-2}	0.45725×10^{-3}	7×10^0
8	-0.92872×10^{-2}	0.15242×10^{-3}	6×10^1

tiene la solución $p_n = c_1 + c_2 n$ para las constantes c_1 y c_2 porque

$$\begin{aligned} 2p_{n-1} - p_{n-2} &= 2(c_1 + c_2(n-1)) - (c_1 + c_2(n-2)) \\ &= c_1(2-1) + c_2(2n-2-n+2) = c_1 + c_2 n = p_n. \end{aligned}$$

Si $p_0 = 1$ y $p_1 = \frac{1}{3}$, las constantes en esta ecuación se convierten en $c_1 = 1$ y $c_2 = -\frac{2}{3}$, de modo que $p_n = 1 - \frac{2}{3}n$. Con una aritmética de redondeo a cinco cifras se obtiene $\hat{p}_0 = 1.0000$ y $\hat{p}_1 = 0.33333$. En consecuencia, las constantes con redondeo a cinco cifras son $\hat{c}_1 = 1.0000$ y $\hat{c}_2 = -0.66667$. Así,

$$\hat{p}_n = 1.0000 - 0.66667n,$$

y el error por redondeo es

$$p_n - \hat{p}_n = \left(0.66667 - \frac{2}{3}\right)n,$$

que crece linealmente con n . Esto se refleja en la estabilidad que aparece en la tabla 1.6. ■

Tabla 1.6

n	$\hat{p}_n$ calculado	p_n correcto	Error relativo
0	0.10000×10^1	0.10000×10^1	
1	0.33333×10^0	0.33333×10^0	
2	-0.33330×10^0	-0.33333×10^0	9×10^{-5}
3	-0.10000×10^1	-0.10000×10^1	0
4	-0.16667×10^1	-0.16667×10^1	0
5	-0.23334×10^1	-0.23333×10^1	4×10^{-5}
6	-0.30000×10^1	-0.30000×10^1	0
7	-0.36667×10^1	-0.36667×10^1	0
8	-0.43334×10^1	-0.43333×10^1	2×10^{-5}

Los efectos del error por redondeo se pueden reducir mediante una aritmética de orden superior, como la opción de precisión doble o múltiple en la mayor parte de las computadoras. El uso de la aritmética de doble precisión presenta las desventajas de más tiempo de cómputo y no se elimina el crecimiento del error por redondeo, sino solamente se pospone hasta realizar otros cálculos.

Un método para estimar el error de redondeo consiste en usar aritmética de intervalos (es decir, conservar los valores máximo y mínimo en cada paso), de modo que, al final, obtenemos un intervalo que contiene al valor real. Desafortunadamente, se necesitaría un intervalo muy pequeño para una ejecución razonable.

Puesto que se usan con frecuencia las técnicas iterativas relacionadas con sucesiones, esta sección concluye con un breve análisis de cierta terminología usada para describir la rapidez a la que ocurre la convergencia cuando se emplea una técnica numérica. En general, quisiéramos que la técnica convergiese lo más rápido posible. Se usa la siguiente definición para comparar las razones de convergencia de varios métodos.

Definición 1.18 Suponga que $\{\beta_n\}_{n=1}^{\infty}$ es una sucesión cuyo valor de convergencia es cero y que $\{\alpha_n\}_{n=1}^{\infty}$ converge a un número α . Si existe una constante positiva K tal que

$$|\alpha_n - \alpha| \leq K|\beta_n|, \quad \text{para } n \text{ grande,}$$

entonces decimos que $\{\alpha_n\}_{n=1}^{\infty}$ converge a α con **rapidez de convergencia** $O(\beta_n)$. Esta expresión se lee "O mayúscula de β_n ". Se indica escribiendo $\alpha_n = \alpha + O(\beta_n)$. ■

Aunque la definición 1.18 permite comparar $\{\alpha_n\}_{n=1}^{\infty}$ con una sucesión arbitraria $\{\beta_n\}_{n=1}^{\infty}$, en casi todas las situaciones usamos

$$\beta_n = \frac{1}{n^p},$$

para algún número $p > 0$. Por lo general, se tiene interés en el mayor valor de p tal que $\alpha_n = \alpha + O(1/n^p)$.

EJEMPLO 4 Suponga que, para $n \geq 1$,

$$\alpha_n = \frac{n+1}{n^2} \quad \text{y} \quad \hat{\alpha}_n = \frac{n+3}{n^3}.$$

Aunque $\lim_{n \rightarrow \infty} \alpha_n = 0$ y $\lim_{n \rightarrow \infty} \hat{\alpha}_n = 0$, la sucesión $\{\hat{\alpha}_n\}$ converge en este límite mucho más rápido que la sucesión $\{\alpha_n\}$, usando la aritmética de redondeo a cinco cifras, como se muestra en la tabla 1.7.

Tabla 1.7

n	1	2	3	4	5	6	7
α_n	2.00000	0.75000	0.44444	0.31250	0.24000	0.19444	0.16327
$\hat{\alpha}_n$	4.00000	0.62500	0.22222	0.10938	0.064000	0.041667	0.029155

Si $\beta_n = 1/n$ y $\hat{\beta}_n = 1/n^2$, vemos que

$$|\alpha_n - 0| = \frac{n+1}{n^2} \leq \frac{n+n}{n^2} = 2 \cdot \frac{1}{n} = 2\beta_n$$

y

$$|\hat{\alpha}_n - 0| = \frac{n+3}{n^3} \leq \frac{n+3n}{n^3} = 4 \cdot \frac{1}{n^2} = 4\hat{\beta}_n.$$

de modo que

$$\alpha_n = 0 + O\left(\frac{1}{n}\right) \quad \text{y} \quad \hat{\alpha}_n = 0 + O\left(\frac{1}{n^2}\right).$$

La rapidez de convergencia de $\{\alpha_n\}$ a cero es similar a la convergencia de $\{1/n\}$ a cero, en tanto que $\{\hat{\alpha}_n\}$ converge a cero con una rapidez similar a la de la sucesión $\{1/n^2\}$, la cual converge más rápido. ■

También usamos la notación “O mayúscula” para describir la rapidez de convergencia de funciones.

Definición 1.19 Suponga que $\lim_{h \rightarrow 0} G(h) = 0$ y $\lim_{h \rightarrow 0} F(h) = L$. Si existe una constante positiva K tal que

$$|F(h) - L| \leq K|G(h)|, \quad \text{para } h \text{ suficientemente pequeña,}$$

entonces escribimos $F(h) = L + O(G(h))$. ■

Por lo común, las funciones que usamos para la comparación tienen la forma $G(h) = h^p$, donde $p > 0$. Nos interesa el mayor valor de p para el que $F(h) = L + O(h^p)$.

EJEMPLO 5 En el ejemplo 3(b) de la sección 1.1 vimos que el tercer polinomio de Taylor da

$$\cos h = 1 - \frac{1}{2}h^2 + \frac{1}{24}h^4 \cos \tilde{\xi}(h),$$

para algún número $\tilde{\xi}(h)$ entre cero y h . En consecuencia,

$$\cos h + \frac{1}{2}h^2 = \frac{1}{24}h^4 \cos \tilde{\xi}(h).$$

De este resultado se deduce que

$$\cos h + \frac{1}{2}h^2 = 1 + O(h^4),$$

pues $|(\cos h + \frac{1}{2}h^2) - 1| = |\frac{1}{24} \cos \tilde{\xi}(h)| h^4 \leq \frac{1}{24} h^4$. Esto implica que, cuando $h \rightarrow 0$, $\cos h + \frac{1}{2}h^2$ converge a su límite, 1, casi tan rápido como h^4 converge a 0. ■

CONJUNTO DE EJERCICIOS 1.3

1. a. Con aritmética de truncamiento de tres cifras calcule la suma $\sum_{i=1}^{10} (1/i^2)$. Utilice primero $\frac{1}{1} + \frac{1}{4} + \cdots + \frac{1}{100}$ y luego $\frac{1}{100} + \frac{1}{81} + \cdots + \frac{1}{1}$. ¿Cuál método es más preciso? ¿Por qué?
- b. Escriba un algoritmo para sumar la serie finita $\sum_{i=1}^N x_i$ en orden inverso.
2. El número e se define como $e = \sum_{n=0}^{\infty} (1/n!)$ donde $n! = n(n-1) \cdots 2 \cdot 1$ para $n \neq 0$ y $0! = 1$. Use la aritmética de truncamiento de cuatro cifras para calcular la siguiente aproximación de e y determine los errores absoluto y relativo.

$$\text{a. } e \approx \sum_{n=0}^3 \frac{1}{n!}$$

$$\text{b. } e \approx \sum_{j=0}^5 \frac{1}{(5-j)!}$$

$$\text{c. } e \approx \sum_{n=0}^{10} \frac{1}{n!}$$

$$\text{d. } e \approx \sum_{j=0}^{10} \frac{1}{(10-j)!}$$

3. La serie de Maclaurin para la función $\arctan$ converge en $-1 < x \leq 1$ y está dada por

$$\arctan x = \lim_{n \rightarrow \infty} P_n(x) = \lim_{n \rightarrow \infty} \sum_{i=1}^n (-1)^{i+1} \frac{x^{2i-1}}{2i-1}.$$

- Use el hecho de que $\tan \pi/4 = 1$ para determinar el número de términos n de la serie que debemos sumar para garantizar que $|4P_n(1) - \pi| < 10^{-3}$.
 - El lenguaje de programación C++ requiere que el valor aproximado de π esté dentro de 10^{-10} . ¿Cuántos términos de la serie debemos sumar para obtener este grado de precisión?
4. En el ejercicio 3 se detalla un método poco efectivo para obtener una aproximación de π . El método se puede mejorar de manera sustancial si se considera que $\pi/4 = \arctan \frac{1}{2} + \arctan \frac{1}{3}$ y se evalúa la serie para el $\arctan$ en $\frac{1}{2}$ y en $\frac{1}{3}$. Calcule el número de términos que debemos sumar para garantizar que la aproximación de π esté dentro de 10^{-3} .
5. Otra fórmula para calcular π se puede deducir de la identidad $\pi/4 = 4 \arctan \frac{1}{5} - \arctan \frac{1}{239}$. Calcule el número de términos que debemos sumar para garantizar que la aproximación de π esté dentro de 10^{-3} .
6. Determine la rapidez de convergencia de las siguientes sucesiones cuando $n \rightarrow \infty$.

$$\text{a. } \lim_{n \rightarrow \infty} \sin \frac{1}{n} = 0$$

$$\text{b. } \lim_{n \rightarrow \infty} \sin \frac{1}{n^2} = 0$$

$$\text{c. } \lim_{n \rightarrow \infty} \left(\sin \frac{1}{n} \right)^2 = 0$$

$$\text{d. } \lim_{n \rightarrow \infty} [\ln(n+1) - \ln(n)] = 0$$

7. Determine las razones de convergencia de las siguientes funciones cuando $h \rightarrow 0$.

$$\text{a. } \lim_{h \rightarrow 0} \frac{\sin h}{h} = 1$$

$$\text{b. } \lim_{h \rightarrow 0} \frac{1 - \cos h}{h} = 0$$

$$\text{c. } \lim_{h \rightarrow 0} \frac{\sin h - h \cos h}{h} = 0$$

$$\text{d. } \lim_{h \rightarrow 0} \frac{1 - e^h}{h} = 1$$

8. a. ¿Cuántas multiplicaciones y sumas se necesitan para determinar una suma de la siguiente forma?

$$\sum_{i=1}^n \sum_{j=1}^i a_i b_j$$

- b. Modifique la suma del inciso (a) en una forma equivalente que reduzca el número de cálculos.

9. Suponga que se tiene el polinomio $P(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0$ y x_0 . Construya un algoritmo para evaluar $P(x_0)$ por medio de una multiplicación anidada.
10. En el ejemplo 5 de la sección 1.2 se dan fórmulas alternativas para las raíces x_1 y x_2 de $ax^2 + bx + c = 0$. Construya un algoritmo con entrada a , b , c y salida x_1 , x_2 que permita calcular las raíces x_1 y x_2 (que pueden ser iguales o complejos conjugados) mediante la mejor fórmula para cada raíz.
11. Construya un algoritmo cuya entrada sea un entero $n \geq 1$, los números $x_0, x_1, \dots, x_n$ y un número x cuya salida sea el producto $(x - x_0)(x - x_1) \dots (x - x_n)$.
12. Suponga que

$$\frac{1-2x}{1-x+x^2} + \frac{2x-4x^3}{1-x^2+x^4} + \frac{4x^3-8x^7}{1-x^4+x^8} + \dots = \frac{1+2x}{1+x+x^2},$$

para $x < 1$ y sea $x = 0.25$. Escriba y ejecute un algoritmo que calcule el número de términos necesarios en el miembro izquierdo de la ecuación, de modo que este lado izquierdo difiera del lado derecho en menos de 10^{-6} .

13. a. Suponga que $0 < q < p$ y que $\alpha_n = \alpha + O(n^{-p})$. Demuestre que $\alpha_n = \alpha + O(n^{-q})$.
 b. Construya una tabla con los valores de $1/n$, $1/n^2$, $1/n^3$ y $1/n^4$ para $n = 5, 10, 100$ y 1000 y analice las variaciones en las tasas de convergencia de estas sucesiones a medida que crece n .
14. a. Suponga que $0 < q < p$ y que $F(h) = L + O(h^p)$. Demuestre que $F(h) = L + O(h^q)$.
 b. Elabore una tabla con los valores de h , h^2 , h^3 y h^4 para $h = 0.5, 0.1, 0.01$ y 0.001 , y analice las variaciones en las tasas de convergencia de estas potencias de h cuando h tiende a cero.
15. Suponga que cuando x tiende a cero,

$$F_1(x) = L_1 + O(x^\alpha) \quad \text{y} \quad F_2(x) = L_2 + O(x^\beta).$$

Sean c_1 y c_2 constantes no nulas, y defina

$$F(x) = c_1 F_1(x) + c_2 F_2(x) \quad \text{y} \quad G(x) = F_1(c_1 x) + F_2(c_2 x).$$

Demuestre que si $\gamma = \min\{\alpha, \beta\}$, entonces, cuando x tiende a cero,

$$\text{a. } F(x) = c_1 L_1 + c_2 L_2 + O(x^\gamma) \quad \text{b. } G(x) = L_1 + L_2 + O(x^\gamma).$$

16. La sucesión $\{F_n\}$ descrita por $F_0 = 1$, $F_1 = 1$ y $F_{n+2} = F_n + F_{n+1}$, si $n \geq 0$, se llama *sucesión de Fibonacci*. Sus términos aparecen de manera natural en muchas especies botánicas, en particular aquellas cuyos pétalos o escamas están ordenados en la forma de una espiral logarítmica. Considere la sucesión $\{x_n\}$, donde $x_n = F_{n+1}/F_n$. Suponiendo que existe $\lim_{n \rightarrow \infty} x_n = x$, demuestre que $x = (1 + \sqrt{5})/2$. Este número se llama la *razón áurea*.
17. La sucesión de Fibonacci también satisface la ecuación

$$F_n = \hat{F}_n = \frac{1}{\sqrt{5}} \left[\left(\frac{1 + \sqrt{5}}{2} \right)^n - \left(\frac{1 - \sqrt{5}}{2} \right)^n \right].$$

- a. Escriba un procedimiento en Maple para calcular F_{100} .
- b. Use Maple con el valor predeterminado por omisión de `Digits` seguido de `evalf` para calcular $\hat{F}_{100}$.
- c. ¿Por qué el resultado del inciso (a) es más preciso que el del inciso (b)?
- d. ¿Por qué el resultado del inciso (b) se obtiene más rápido que el del inciso (a)?
- e. ¿Qué se obtiene al usar la instrucción `simplify` en vez de `evalf` para calcular $\hat{F}_{100}$?
18. La serie armónica $1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \dots$ diverge, pero la sucesión $\gamma_n = 1 + \frac{1}{2} + \dots + \frac{1}{n} - \ln n$ converge, pues $\{\gamma_n\}$ es una sucesión acotada no creciente. El límite $\gamma = 0.5772156649\dots$ de la sucesión $\{\gamma_n\}$ se llama constante de Euler.
 - a. Use el valor predeterminado de `Digits` en Maple para calcular el valor de n para que γ_n esté a menos de 10^{-2} de γ .
 - b. Use el valor predeterminado de `Digits` en Maple para calcular el valor de n para que γ_n esté a menos de 10^{-3} de γ .
 - c. ¿Qué ocurre si se usa el valor predeterminado de `Digits` en Maple para calcular el valor de n para que γ_n esté a menos de 10^{-4} de γ ?

1.4 Software numérico

Los paquetes de computación utilizados para aproximar las soluciones numéricas están disponibles en diversas formas. En este libro incluimos los programas escritos en C, FORTRAN, Maple, Mathematica, MATLAB y Pascal con los cuales pueden solucionarse los problemas de los ejemplos y ejercicios. Estos programas darán resultados satisfactorios para la mayor parte de los problemas que necesite resolver, aunque sean de los llamados programas de *propósito específico*. Usamos este término para distinguirlos de los disponibles en las bibliotecas de subrutinas matemáticas. Los programas en estos paquetes se llamarán de *propósito general*.

Distinta de los algoritmos y programas que se incluyen en este libro, es la finalidad de los programas de propósito general, éstos ofrecen medios para reducir los errores atribuidos al redondeo de la computadora y al desbordamiento tanto de la capacidad mínima como máxima. También describen el intervalo de entradas que conducirá a resultados con cierto nivel de exactitud. Como éstas son características que dependen de la máquina, los paquetes de propósito general usan parámetros que describen las características de punto flotante de la computadora utilizada para realizar los cálculos.

Para ilustrar algunas diferencias entre los programas incluidos en un paquete de propósito general y los programas que empleamos en este libro, consideremos un algoritmo con el que se calcula la norma euclidiana de un vector $\mathbf{x} = (x_1, x_2, \dots, x_n)'$ de dimensión n . Con frecuencia, esta norma se usa en programas de gran tamaño y se define como

$$\|\mathbf{x}\|_2 = \left[\sum_{i=1}^n x_i^2 \right]^{1/2}.$$

La norma da una medida para la distancia del vector $\mathbf{x}$ al vector $\mathbf{0}$. Por ejemplo, el vector $\mathbf{x} = (2, 1, 3, -2, -1)'$ tiene

$$\|\mathbf{x}\|_2 = [2^2 + 1^2 + 3^2 + (-2)^2 + (-1)^2]^{1/2} = \sqrt{19},$$

de modo que su distancia desde $\mathbf{0} = (0, 0, 0, 0, 0)'$ es $\sqrt{19} \approx 4.36$.

Veamos un algoritmo del tipo que presentaríamos para este problema. El algoritmo no tiene parámetros que dependan de la máquina ni garantías de precisión, pero dará resultados precisos "la mayor parte de los casos".

ENTRADA $n, x_1, x_2, \dots, x_n$.

SALIDA NORMA.

Paso 1 Tome $SUMA = 0$.

Paso 2 Para $i = 1, 2, \dots, n$ establezca $SUMA = SUMA + x_i^2$.

Paso 3 Tome $NORMA = SUMA^{1/2}$.

Paso 4 SALIDA (NORMA);
PARAR.

Es fácil escribir y comprender un programa basado en este algoritmo. Sin embargo, el programa podría no dar la precisión suficiente por varias razones. Por ejemplo, la magnitud de algunos números podría ser demasiado grande o pequeña para poder representarse con precisión en el sistema de punto flotante de la computadora. Además, el orden usual de los cálculos podría no dar los mejores resultados, o la rutina para obtener la raíz cuadrada del software común podría no ser la más adecuada para el problema. Las cuestiones de este tipo son analizadas por los diseñadores de algoritmos al escribir programas para software de propósito general. Con frecuencia, estos programas se utilizan como subprogramas para resolver problemas mayores, de modo que deben incorporar controles que nosotros no necesitaremos.

Consideremos ahora un algoritmo para un programa de software de propósito general que permita calcular la norma euclidiana. En primer lugar, es posible que un componente x_i del vector esté dentro del rango de la máquina, pero no así el cuadrado del componente. Esto puede ocurrir cuando algún $|x_i|$ es tan pequeño que x_i^2 cause un subdesbordamiento o cuando algún $|x_i|$ es tan grande que x_i^2 cause un desbordamiento. También es posible que todos los términos estén dentro del rango de la máquina, pero que haya un desbordamiento por la suma del cuadrado de uno de los términos a la suma recién calculada.

Como los criterios de exactitud dependen de la computadora utilizada para realizar los cálculos, el algoritmo incorpora algunos parámetros dependientes de la máquina. Suponga que estamos trabajando en una computadora hipotética con base 10, con $t \geq 4$ cifras de precisión, un exponente mínimo $emín$, y un exponente máximo $emáx$. Entonces el conjunto de números de punto flotante en esta máquina consta de 0 y de los números de la forma

$$x = f \cdot 10^e, \quad \text{donde} \quad f = \pm(f_1 10^{-1} + f_2 10^{-2} + \cdots + f_t 10^{-t}),$$

donde $1 \leq f_1 \leq 9$ y $0 \leq f_i \leq 9$ para cada $i = 2, \dots, t$, y donde $emín \leq e \leq emáx$. Estas restricciones implican que el número positivo más pequeño representado en esta máquina es $\sigma = 10^{emín-1}$, de modo que cualquier número calculado x con $|x| < \sigma$ provoca un subdesbordamiento y hace que x se iguale a cero. El mayor número positivo es $\lambda = (1 - 10^{-t})10^{emáx}$, y cualquier número calculado x con $|x| > \lambda$ produce un desbordamiento. Cuando hay subdesbordamiento, el programa continúa sin que haya una pérdida significativa de exactitud. Si ocurre un desbordamiento, fallará el programa.

El algoritmo supone que las características de punto flotante de la máquina se describen mediante los parámetros N , x , S , y , Y . N es el número máximo de datos que se pueden sumar con al menos $t/2$ cifras de precisión. Esto significa que el algoritmo tratará de calcular la norma de un vector $\mathbf{x} = (x_1, x_2, \dots, x_n)$ sólo si $n \leq N$. Para resolver el problema de subdesbordamiento-desbordamiento, los números no nulos de punto flotante se separan en tres grupos: los números x de pequeña magnitud, que satisfacen $0 < |x| < y$; los números x de magnitud media, donde $y \leq |x| < Y$; y los números x de gran magnitud, donde $Y \leq |x|$. Los parámetros y y Y se eligen de modo que no se presenten problemas de subdesbordamiento-desbordamiento al sumar los números de magnitud mediana y elevarlos al cuadrado. Al elevar al cuadrado los números de pequeña magnitud puede ocurrir un subdesbordamiento, por lo cual se usa un factor escalar S mucho mayor que 1, de ese modo $(Sx)^2$ evita el subdesbordamiento aunque no lo haga x^2 . Al sumar y elevar al cuadrado los números de gran magnitud se puede tener un desbordamiento, de modo que en este caso se usa un factor de escala mucho menor que 1 para garantizar que $(sx)^2$ no provoque un desbordamiento al calcularlo e incorporarlo en una suma, aun cuando x^2 genere problemas.

Para evitar los cambios de escala innecesarios, y y Y se eligen de modo que el intervalo de números de magnitud media sea lo más amplio posible. El siguiente algoritmo es

una modificación del descrito en [Brow, K, p. 471]. Éste incorpora un procedimiento para cambiar la escala de las componentes del vector que tienen magnitud pequeña hasta encontrar una componente de magnitud mediana. Luego, se invierte la escala de la suma anterior y se continúa elevando al cuadrado y sumando números pequeños y medianos hasta encontrar una componente de gran magnitud. Una vez que aparece ésta, el algoritmo escala la suma anterior y se procede a cambiar la escala, elevar al cuadrado y sumar los números restantes. Supone que al pasar de los números pequeños a los medianos, los números pequeños no escalados resultan insignificantes en comparación con los números medianos. De manera similar, al pasar de números medianos a grandes, los números medianos no escalados son insignificantes comparados con los números grandes. Así, hay que elegir los parámetros de escalamiento de modo que los números sean anulados (igualados a cero) sólo cuando realmente sean insignificantes. Las relaciones usuales entre las características de la máquina descritas por t , σ , λ , $emín$, $emáx$ y los parámetros N , s , S , y y Y aparecen después del algoritmo.

En el algoritmo se utilizan tres banderas para indicar las diversas etapas del proceso de suma. Estas banderas reciben sus valores iniciales en el paso 3. La BANDERA 1 es 1 hasta que aparezca un componente mediano o grande; entonces se transforma en 0. La BANDERA 2 es 0 mientras se sumen números pequeños, se convierte en 1 al encontrar un número mediano por primera vez y vuelve a ser 0 al aparecer un número grande. La BANDERA 3 es igual a 0 al principio y se transforma en 1 cuando aparece un número grande por vez primera. En el paso 3 también se introduce la bandera HECHO, que es igual a 0 hasta concluir los cálculos, y, una vez terminados, vuelve a ser 1.

ENTRADA $N, s, S, y, Y, \lambda, n, x_1, x_2, \dots, x_n$.

SALIDA NORMA o un mensaje pertinente de error.

Paso 1 Si $n \leq 0$ entonces SALIDA ('El entero n debe ser positivo');
PARAR.

Paso 2 Si $n \geq N$ entonces SALIDA ('El entero n es demasiado grande');
PARAR.

Paso 3 Tome $SUMA = 0$;
BANDERA1 = 1; (Se están sumando los números pequeños.)
BANDERA2 = 0;
BANDERA3 = 0;
HECHO = 0;
 $i = 1$.

Paso 4 Mientras ($i \leq n$ y BANDERA1 = 1) haga Paso 5.

Paso 5 Si $|x_i| < y$ entonces establezca $SUMA = SUMA + (Sx_i)^2$;
 $i = i + 1$
si no establezca BANDERA1 = 0. (Se halló un número que no es tan pequeño.)

Paso 6 Si $i > n$ entonces establezca $NORMA = (SUMA)^{1/2}/S$;
HECHO = 1
si no establezca $SUMA = (SUMA/S)/S$; (Cambia la escala de números grandes.)
BANDERA2 = 1.

Paso 7 Mientras ($i \leq n$ y BANDERA2 = 1) efectúe Paso 8. (Suma de números medianos.)

- Paso 8** Si $|x_i| < Y$ entonces establezca $SUMA = SUMA + x_i^2$;
 $i = i + 1$
 si no establezca $BANDERA2 = 0$. (Se ha encontrado un número grande.)
- Paso 9** Si $HECHO = 0$ entonces
 si $i > n$ entonces establezca $NORMA = (SUMA)^{1/2}$;
 $HECHO = 1$
 o bien establezca $SUMA = ((SUMA)s)s$; (Cambia de escala a los números grandes.)
 $BANDERA3 = 1$.
- Paso 10** Mientras ($i \leq n$ y $BANDERA3 = 1$) ejecute Paso 11.
- Paso 11** Establezca $SUMA = SUMA + (sx_i)^2$; (Suma los números grandes.)
 $i = i + 1$.
- Paso 12** Si $HECHO = 0$ entonces
 si $SUMA^{1/2} < \lambda s$ entonces establezca $NORMA = (SUMA)^{1/2}/s$;
 $HECHO = 1$
 o bien establezca $SUMA = \lambda$. (La norma es demasiado grande.)
- Paso 13** Si $HECHO = 1$ entonces SALIDA ('La norma es', $NORMA$)
 o bien SALIDA ('Norma $\geq$ ', $NORMA$, 'ocurrió un desbordamiento').
- Paso 14** PARAR.

Las relaciones entre las características de la máquina t , σ , λ , $emín$, $emáx$ y los parámetros del algoritmo N , s , S , y y Y fueron elegidas en [Brow W, p. 471] como:

$$\begin{aligned}
 N &= 10^e, & \text{donde } e_N &= \lfloor (t - 2)/2 \rfloor, & \text{el mayor entero menor o igual a } (t - 2)/2; \\
 s &= 10^e, & \text{donde } e_s &= \lfloor -(emáx + e_N)/2 \rfloor; \\
 S &= 10^e, & \text{donde } e_S &= \lceil (1 - emín)/2 \rceil, & \text{el menor entero mayor o igual a } (1 - emín)/2; \\
 y &= 10^e, & \text{donde } e_y &= \lceil (emín + t - 2)/2 \rceil; \\
 Y &= 10^e, & \text{donde } e_Y &= \lfloor (emáx - e_N)/2 \rfloor.
 \end{aligned}$$

La confiabilidad incorporada a este algoritmo de propósito general ha incrementado en gran medida el grado de dificultad en comparación con el algoritmo de propósito específico mostrado antes en esta sección.

Existen muchos tipos de software comerciales disponibles y de dominio público de propósito general para el análisis numérico. La mayor parte de los primeros software fueron escritos para supercomputadoras (*mainframe*); una buena referencia para esto es *Sources and Developments of Mathematical Software*, editado por Wayne Cowell [Co]. Ahora que la computadora de escritorio se ha vuelto bastante poderosa, se dispone de software numérico común para las computadoras personales y estaciones de trabajo. La mayor parte de este software está escrito en FORTRAN, aunque algunos paquetes están escritos en C, C++ y FORTRAN90.

En 1971 [WR] presentó algunos procedimientos en ALGOL para el cálculo de matrices. Luego, a partir de un paquete de subrutinas de FORTRAN basadas en los procedimientos de ALGOL, se obtuvieron las rutinas EISPACK. Éstas están documentadas en los manuales publicados por Springer-Verlag como parte de su serie *Lecture Notes in Computer*

Sciences [Sm, B] y [Gar]. Las subrutinas en FORTRAN se usan para calcular valores y vectores característicos para una amplia variedad de matrices. El proyecto EISPACK fue el primer paquete de software numérico a gran escala que estuvo disponible para el dominio público y fue la gúfa de muchos paquetes posteriores. EISPACK recibe mantenimiento de netlib y aparece en la dirección <http://www.netlib.org/eispack>.

LINPACK es un paquete de subrutinas de FORTRAN para analizar y resolver sistemas de ecuaciones lineales y problemas lineales de mínimos cuadrados. La documentación de este paquete está en [DBMS] y aparece en <http://www.netlib.org/linpack>. [CV] da una introducción paso a paso a LINPACK, EISPACK y BLAS (por sus siglas en inglés de, subrutinas básicas de álgebra lineal, Basic Linear Algebra Subprograms).

El paquete LAPACK, lanzado al mercado en 1992, es una biblioteca de subrutinas de FORTRAN superior a LINPACK y EISPACK, que integra estos dos conjuntos de algoritmos en un paquete unificado y actualizado. El software se reestructuró para lograr mayor eficiencia con procesadores vectoriales y otros multiprocesadores de alto rendimiento o de memoria compartida. LAPACK se amplió en profundidad y alcance en la versión 3.0, disponible en FORTRAN, FORTRAN90, C, C++ y JAVA. FORTRAN90, C y JAVA sólo están disponibles como interfaces de lenguaje o traducciones de las bibliotecas en FORTRAN de LAPACK. El paquete BLAS no forma parte de LAPACK, pero el código de BLAS se distribuye con LAPACK. El texto *LAPACK User's Guide*, tercera edición [An] está disponible en SIAM o en http://www.netlib.org/lapack/lug/lapack_lug.html. Todo LAPACK o algunas de sus rutinas individuales pueden obtenerse por medio de netlib en netlibornl.gov, netlibresearch.att.com, o <http://www.netlib.org/lapack>.

Existen otros paquetes de dominio público que sirven para resolver ciertos tipos de problemas. La información acerca de estos programas se puede obtener por medio de correo electrónico, enviando el mensaje "help" a alguna de las siguientes direcciones: netlibresearch.att.com, netlibornl.gov, netlibnrc.no o netlibdraci.cs.uow.edu.au o a la dirección uucp address uunet!research!netlib. Como alternativa a netlib, puede usar Xnetlib para buscar en la base de datos y obtener el software. Hay más información en el artículo *Software Distribution using Netlib*, de Dongarra, Roman y Wade [DRW].

Estos paquetes son muy eficaces, exactos y confiables. Además, se han probado en forma exhaustiva y su documentación es fácil de consultar. Aunque estos programas son portátiles, es bueno investigar su compatibilidad con la máquina y leer con detenimiento toda la documentación. Los programas verifican casi todas las contingencias particulares que podrían producir errores y fallas. Al final de cada capítulo analizaremos algunos de los paquetes adecuados de propósito general.

Los paquetes comerciales también representan lo más avanzado en métodos numéricos. Por lo general, su contenido se basa en los paquetes de dominio público, pero incluyen técnicas para casi cualquier tipo de problema.

IMSL (del inglés International Mathematical Software Library, bibliotecas internacionales en matemáticas y estadística) incluye las bibliotecas MATH, STAT y SFUN para matemáticas numéricas, estadística y funciones especiales del análisis numérico, respectivamente. Estas bibliotecas contienen más de 900 subrutinas disponibles originalmente en FORTRAN 77 y ahora en C++, FORTRAN90 y JAVA. Con estas subrutinas se resuelven los problemas más comunes de análisis numérico. En 1970, IMSL se convirtió en la primera biblioteca científica de gran escala para las supercomputadoras (*mainframe*). Desde entonces, las bibliotecas han estado disponibles para sistemas de cómputo que van desde las supercomputadoras hasta las computadoras personales. Éstas pueden adquirirse en Visual Numerics, 9990 Richmond Ave S400, Houston, TX 77042-4548, con dirección en Internet <http://www.vni.com>. Los paquetes se entregan en forma compilada, con amplia

documentación. Hay un programa ejemplo para cada rutina, así como información básica de referencia. Las IMSL contienen métodos para sistemas lineales, análisis de sistemas característicos, interpolación y aproximación, integración y derivación, ecuaciones diferenciales, transformadas, ecuaciones no lineales, optimización y operaciones básicas con matrices y vectores. La biblioteca contiene además muchas rutinas de estadística.

El Numerical Algorithms Group (NAG) se fundó en 1970, en Reino Unido. NAG ofrece más de 1000 subrutinas en una biblioteca de FORTRAN 77, cerca de 400 subrutinas en una biblioteca en C, más de 200 subrutinas en su biblioteca de FORTRAN 90 y una biblioteca numérica de FORTRAN MPI para máquinas en paralelo y cúmulos de estaciones de trabajo o computadoras personales. Un subconjunto de su biblioteca en FORTRAN 77 (la NAG Foundation Library) está disponible para computadoras personales y estaciones de trabajo donde el espacio está limitado. Las bibliotecas NAG C, FORTRAN 90 y FORTRAN MPI ofrecen muchas de las mismas rutinas de la biblioteca FORTRAN. El manual del usuario de NAG incluye instrucciones y ejemplos, junto con una salida muestra para cada una de las rutinas. [Ph] es una introducción útil para las rutinas NAG. La biblioteca NAG contiene rutinas que permiten realizar la mayor parte de las tareas estándar de análisis numérico de manera similar a las IMSL. También incluye algunas rutinas de estadística y un conjunto de rutinas gráficas. La biblioteca se puede comprar en Numerical Algorithms Group, Inc., 1400 Opus Place, Suite 200, Downers Grove, IL 60515-5702, con dirección en Internet <http://www.nag.com>.

Los paquetes IMSL y NAG están diseñados para los matemáticos, científicos e ingenieros que desean llamar desde un programa las subrutinas FORTRAN de alta calidad dentro de un programa. La documentación que incluyen los paquetes comerciales explica el programa maestro que se necesita para usar las rutinas de la biblioteca. Los siguientes tres paquetes de software son ambientes independientes. Al activarlos, el usuario teclea instrucciones para que el paquete resuelva el problema. Sin embargo, cada paquete permite programar dentro del lenguaje de sus instrucciones.

MATLAB es un laboratorio de matrices que originalmente era un programa en FORTRAN publicado por Cleve Moler [Mo]. El laboratorio se basa sobre todo en las subrutinas EISPACK y LINPACK, aunque se han incorporado funciones como sistemas lineales, integración numérica, trazadores cúbicos, ajuste de curvas, optimización, ecuaciones diferenciales ordinarias y herramientas gráficas. MATLAB está escrito actualmente en C y en lenguaje ensamblador, y la versión para computadora personal requiere un coprocesador numérico. La estructura básica consiste en realizar operaciones con matrices, como determinar los valores característicos de una matriz introducida desde la línea de instrucciones o desde un archivo externo mediante llamadas de funciones. Éste es un poderoso sistema autosuficiente que resulta muy útil para la enseñanza de álgebra lineal aplicada. MATLAB está en el mercado desde 1985 y puede adquirirse en The Math Works, Inc., Cochituate Place, 24 Prime Park Way, Natick, MA 01760. La dirección de correo electrónico de The Math Works es infomathworks.com y la dirección en Internet es <http://www.mathworks.com>. El software de MATLAB está diseñado para ejecutarse en muchas computadoras, incluyendo las computadoras personales compatibles con IBM, APPLE Macintosh y las estaciones de trabajo SUN. La versión de MATLAB para el estudiante no requiere un coprocesador pero lo usará en caso que esté disponible.

El segundo paquete es GAUSS, un sistema matemático y estadístico producido por Lee E. Ediefson y Samuel D. Jones en 1985. Está codificado en lenguaje ensamblador y se basa en EISPACK y LINPACK. Como en el caso de MATLAB, dispone de integración, derivación, sistemas no lineales, transformadas rápidas de Fourier y gráficas. GAUSS está menos orientado a la enseñanza en álgebra lineal y más hacia el análisis estadístico de

datos. Este paquete también usa un coprocesador numérico si está disponible. Puede adquirirse en Aptech Systems, Inc., 23804 S.E. Kent-Kangley Road, Maple Valley, WA 98038 (infoaptech.com).

El tercer paquete es Maple, un sistema de álgebra por computadora desarrollado en 1980 por The Symbolic Computational Group de la Universidad de Waterloo. El diseño del sistema Maple original se presenta en el artículo de B.W. Char, K.O. Geddes, W.M. Gentleman y G.H. Gonnet [CGGG]. Maple está en el mercado desde 1985 y se consigue en Waterloo Maple Inc., 57 Erb Street, Waterloo ON N2L 6C2. La dirección de correo electrónico de Waterloo Maple es info@maplesoft.com y la dirección en Internet es <http://www.maplesoft.com>. Maple está escrito en C y tiene la capacidad de manejar la información de manera simbólica, lo cual permite al usuario obtener respuestas exactas en vez de valores numéricos. Con Maple se pueden obtener respuestas exactas a problemas matemáticos como integrales, ecuaciones diferenciales y sistemas lineales. Contiene una estructura de programación y permite guardar texto e instrucciones en sus archivos de hoja de trabajo. Luego, estas hojas de trabajo se pueden introducir en Maple y ejecutar las instrucciones. Debido a sus características de cálculo simbólico, cálculo numérico y hojas de trabajo, se eligió a Maple como lenguaje para este texto. En todo el libro se intercalan instrucciones de Maple.

Existen muchos paquetes que pueden ser catalogados como paquetes de supercalculadora para computadoras personales. Sin embargo, estos no deben confundirse con el software de propósito general mencionado aquí. Si usted tiene interés en alguno de estos paquetes, debe leer *Supercalculators on the PC* por B. Simon y R.M. Wilson [SW].

Para obtener más información acerca del software y las bibliotecas de software consulte los libros de Cody y Waite [CW] y Kockler [Ko]; así como en el artículo de 1995 de Dongarra y Walker [DW]. En el libro de Chaitini-Chatelin y Frayse [CF] y el artículo de Goldberg [Go] hay más información acerca del cálculo de punto flotante.

Algunos libros dedicados a la aplicación de técnicas numéricas en computadoras en paralelo son Schendell [Sche], Phillips y Freeman [PF] y Golub y Ortega [GO].

CAPÍTULO 2


Soluciones de ecuaciones de una variable

. . .

El crecimiento de una población numerosa puede modelarse durante periodos breves, con sólo suponer que ésta crece constantemente con el tiempo a una tasa que es proporcional al número de habitantes que existen en ese tiempo. Si denotamos con $N(t)$ la cantidad de habitantes en el tiempo t y con λ el índice constante de natalidad, la población satisface la ecuación diferencial

$$\frac{dN(t)}{dt} = \lambda N(t).$$

La solución de esta ecuación es $N(t) = N_0 e^{\lambda t}$, donde N_0 denota la población inicial.



Este modelo exponencial es válido sólo cuando la población se halla aislada, es decir, sin que exista inmigración proveniente del exterior. Si se permite la inmigración con una tasa constante r la ecuación diferencial que rige la situación será

$$\frac{dN(t)}{dt} = \lambda N(t) + r,$$

cuya solución es

$$N(t) = N_0 e^{\lambda t} + \frac{r}{\lambda} (e^{\lambda t} - 1).$$

Supóngase que cierta población tiene inicialmente un millón de habitantes, que 435 000 de ellos inmigran hacia la comunidad durante el primer año y que 1 564 000 se encuentran en ella al final del año 1. Si queremos determinar la natalidad de esta población, debemos determinar λ en la ecuación

$$1\,564\,000 = 1\,000\,000 e^{\lambda} + \frac{435\,000}{\lambda} (e^{\lambda} - 1).$$

Los métodos numéricos que se tratan en este capítulo sirven para obtener aproximaciones a las soluciones de este tipo de ecuaciones, cuando no es posible obtener respuestas exactas con métodos algebraicos. En el ejercicio 20 de la sección 2.3 se considera la solución de este problema en particular.

2.1 El método de bisección

En este capítulo estudiaremos uno de los problemas básicos de la aproximación numérica: el problema de la búsqueda de raíces. Consiste en obtener una raíz, o solución, de una ecuación de la forma $f(x) = 0$ para una función dada f . (Al número x se le llama también *cero* de f .) El problema de encontrar una aproximación a la raíz de una ecuación se remonta por lo menos al año 1700 a.C. Una tabla cuneiforme que pertenece a la Yale Babylonian Collection, y que data de este periodo, da un número sexagesimal (base 60) equivalente a 1.414222 como aproximación a $\sqrt{2}$, resultado que tiene una precisión de hasta 10^{-5} . Esta aproximación se puede determinar mediante una técnica descrita en el ejercicio 19 de la sección 2.2.


La primera técnica, que se basa en el teorema del valor intermedio, se conoce con el nombre de **método de bisección** o de **búsqueda binaria**. Supongamos que f es una función continua definida en el intervalo $[a, b]$ con $f(a)$ y $f(b)$ de signos diferentes. De acuerdo con el teorema del valor intermedio, existe un número p en (a, b) tal que $f(p) = 0$. Si bien el procedimiento se aplica aunque exista más de una raíz en el intervalo (a, b) , por razones de simplicidad suponemos que la raíz de este intervalo es única. El método requiere dividir varias veces a la mitad los subintervalos de $[a, b]$ y, en cada paso, localizar la mitad que contenga a p .

Para empezar, supongamos que $a_1 = a$ y $b_1 = b$, y sea p_1 el punto medio de $[a, b]$; es decir,

$$p_1 = a_1 + \frac{b_1 - a_1}{2} = \frac{a_1 + b_1}{2}.$$

Si $f(p_1) = 0$, entonces $p = p_1$; de no ser así, entonces $f(p_1)$ tiene el mismo signo que $f(a_1)$ o $f(b_1)$. Si $f(p_1)$ y $f(a_1)$ tienen el mismo signo, entonces $p \in (p_1, b_1)$ y tomamos $a_2 = p_1$ y $b_2 = b_1$. Si $f(p_1)$ y $f(a_1)$ tienen signos opuestos, entonces $p \in (a_1, p_1)$ y tomamos $a_2 = a_1$ y $b_2 = p_1$. Después volvemos a aplicar el proceso al intervalo $[a_2, b_2]$. Esto nos da el método que se describe en el algoritmo 2.1 (Véase fig. 2.1).

Figura 2.1



ALGORITMO 2.1

Bisección

Para obtener una solución a $f(x) = 0$ dada la función f continua en el intervalo $[a, b]$, donde $f(a)$ y $f(b)$ tienen signos opuestos:

ENTRADA extremos a, b ; tolerancia TOL ; número máximo de iteraciones N_0 .

SALIDA solución aproximada p o mensaje de error.

Paso 1 Tome $i = 1$;
FA = $f(a)$.

Paso 2 Mientras $i \leq N_0$ haga pasos 3-6.

Paso 3 Tome $p = a + (b - a)/2$; (Calcule p_i)
FP = $f(p)$.

Paso 4 Si $FP = 0$ o $(b - a)/2 < TOL$ entonces
 SALIDA (p); (Procedimiento terminado satisfactoriamente.)
 PARAR.

Paso 5 Tome $i = i + 1$.

Paso 6 Si $FA \cdot FP > 0$ entonces tome $a = p$; (Calcule a_i, b_i)
 $FA = FP$
 si no tome $b = p$.

Paso 7 SALIDA ('El método fracasó después de N_0 iteraciones, $N_0 = \cdot, N_0$);
 (Procedimiento terminado sin éxito.)
 PARAR.

A continuación describiremos otros procedimientos de paro que pueden aplicarse en el paso 4 del algoritmo 2.1 o a cualquiera de las técnicas iterativas que se estudian en este capítulo. Por ejemplo, seleccione una tolerancia $\epsilon > 0$ y genere $p_1, \dots, p_N$ hasta que se satisfaga una de las siguientes condiciones:

$$|p_N - p_{N-1}| < \epsilon, \quad (2.1)$$

$$\frac{|p_N - p_{N-1}|}{|p_N|} < \epsilon, \quad p_N \neq 0, \quad \text{o} \quad (2.2)$$

$$|f(p_N)| < \epsilon. \quad (2.3)$$

Por desgracia, al usar cualquiera de estos criterios de paro pueden surgir problemas. Por ejemplo, existen sucesiones $\{p_n\}_{n=0}^{\infty}$ con la propiedad de que las diferencias $p_n - p_{n-1}$ convergen a cero, mientras que la sucesión diverge (ejercicio 15). También es posible que $f(p_n)$ esté cercano a cero, mientras que p_n difiere significativamente de p (véase el ejercicio 14.) En caso de que no se conozcan f o p , la desigualdad (2.2) es el mejor criterio de paro al que puede recurrirse, ya que verifica el error relativo.

Cuando se generan aproximaciones por medio de la computadora, conviene fijar el número máximo de iteraciones que se efectuarán; así se evitará introducir un ciclo infinito, posibilidad que puede presentarse cuando la sucesión diverge (y también cuando el programa no está codificado correctamente). Esto se hace en el paso 2 del algoritmo 2.1, donde se estableció la frontera inicial N_0 y el procedimiento terminaba si $i > N_0$.

Obsérvese que para iniciar el algoritmo de bisección, hay que encontrar un intervalo $[a, b]$, de modo que $f(a) \cdot f(b) < 0$. En cada paso, la longitud del intervalo que se sabe que contiene un cero de f se reduce en un factor de 2; por tanto, conviene escoger un intervalo inicial $[a, b]$ lo más pequeño posible. Por ejemplo, si $f(x) = 2x^3 - x^2 + x - 1$, entonces

$$f(-4) \cdot f(4) < 0 \quad \text{y} \quad f(0) \cdot f(1) < 0,$$

de manera que el algoritmo de bisección pueda emplearse en uno de los intervalos $[-4, 4]$ o $[0, 1]$. Al comenzar el algoritmo de bisección en $[0, 1]$ y no en $[-4, 4]$, la cantidad de iteraciones necesarias para alcanzar determinada exactitud disminuirá en 3.