

$$\begin{aligned}
 \text{d. } 0.5x_1 + 0.25x_2 &= 0.35, \\
 0.35x_1 + 0.8x_2 + 0.4x_3 &= 0.77, \\
 0.25x_2 + x_3 + 0.5x_4 &= -0.5, \\
 x_3 - 2x_4 &= -2.25.
 \end{aligned}$$

7. Sea A la matriz tridiagonal de 10×10 dada por $a_{ii} = 2$, $a_{i,i+1} = a_{i,i-1} = -1$, para cada $i = 2, \dots, 9$, y en $a_{11} = a_{10,10} = 2$, $a_{12} = a_{10,9} = -1$. Sea b el vector columna de dimensión diez dado por $b_1 = b_{10} = 1$ y $b_i = 0$ para cada $i = 2, 3, \dots, 9$. Resuelva $Ax = b$ por medio de la factorización de Crout para sistemas tridiagonales.
8. Modifique la factorización LDL' para factorizar una matriz simétrica A . [Nota: no siempre es posible la factorización.] Aplique el nuevo algoritmo a las siguientes matrices:

$$\text{a. } A = \begin{bmatrix} 3 & -3 & 6 \\ -3 & 2 & -7 \\ 6 & -7 & 13 \end{bmatrix}$$

$$\text{b. } A = \begin{bmatrix} 3 & -6 & 9 \\ -6 & 14 & -20 \\ 9 & -20 & 29 \end{bmatrix}$$

$$\text{c. } A = \begin{bmatrix} -1 & 2 & 0 & 1 \\ 2 & -3 & 2 & -1 \\ 0 & 2 & 5 & 6 \\ 1 & -1 & 6 & 12 \end{bmatrix}$$

$$\text{d. } A = \begin{bmatrix} 2 & -2 & 4 & -4 \\ -2 & 3 & -4 & 5 \\ 4 & -4 & 10 & -10 \\ -4 & 5 & -10 & 14 \end{bmatrix}$$

9. ¿Cuáles de las matrices simétricas del ejercicio 8 son definidas positivas?

10. Obtenga α de modo que $A = \begin{bmatrix} \alpha & 1 & -1 \\ 1 & 2 & 1 \\ -1 & 1 & 4 \end{bmatrix}$ sea definida positiva.

11. Obtenga α de modo que $A = \begin{bmatrix} 2 & \alpha & -1 \\ \alpha & 2 & 1 \\ -1 & 1 & 4 \end{bmatrix}$ sea definida positiva.

12. Obtenga α y $\beta > 0$ de modo que la matriz

$$A = \begin{bmatrix} 4 & \alpha & 1 \\ 2\beta & 5 & 4 \\ \beta & 2 & \alpha \end{bmatrix}$$

sea estrictamente diagonal dominante.

13. Obtenga $\alpha > 0$ y $\beta > 0$ de modo que la matriz

$$A = \begin{bmatrix} 3 & 2 & \beta \\ \alpha & 5 & \beta \\ 2 & 1 & \alpha \end{bmatrix}$$

es estrictamente dominante en sentido diagonal.

14. Suponga que A y B son matrices de $n \times n$ estrictamente diagonal dominante.

- ¿Es $-A$ estrictamente diagonal dominante?
- ¿Es A' estrictamente diagonal dominante?
- ¿Es $A + B$ estrictamente diagonal dominante?
- ¿Es A^2 estrictamente diagonal dominante?
- ¿Es $A - B$ estrictamente diagonal dominante?

15. Suponga que A y B son matrices definidas positivas de $n \times n$.

- ¿Es $-A$ definida positiva?
- ¿Es A' definida positiva?
- ¿Es $A + B$ definida positiva?
- ¿Es A^2 definida positiva?
- ¿Es $A - B$ definida positiva?

16. Sea

$$A = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 1 \\ -1 & 1 & \alpha \end{bmatrix}.$$

Calcule todos los valores de α para los cuales

- A es singular.
- A es estrictamente diagonal dominante.
- A es simétrica.
- A es definida positiva.

17. Sea

$$A = \begin{bmatrix} \alpha & 1 & 0 \\ \beta & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix}$$

Obtenga los valores de α y de β para los cuales

- A es singular.
- A es estrictamente diagonal dominante.
- A es simétrica.
- A es definida positiva.

18. Suponga que A y B conmutan, es decir, $AB = BA$. ¿Deben conmutar también A' y B' ?

19. Construya una matriz A que no sea simétrica, pero para la cual $x'Ax > 0$ para toda $x \neq 0$.

20. Demuestre que puede efectuarse la eliminación gaussiana en A sin intercambios de renglones, si y sólo si todas las primeras submatrices principales de A son no singulares. [Sugerencia: divida todas las matrices de la ecuación

$$A^{(k)} = M^{(k-1)}M^{(k-2)} \dots M^{(1)}A$$

entre las columnas k -ésima y $(k+1)$ -ésima y horizontalmente entre los renglones k -ésimo y $(k+1)$ -ésimo (véase el ejercicio 10 de la sección 6.3). Demuestre que la no singularidad de la primera submatriz principal de A equivale a $a_{11}^{(0)} \neq 0$.]

21. Las matrices tridiagonales suelen marcarse mediante la notación

$$A = \begin{bmatrix} a_1 & c_1 & 0 & \dots & 0 \\ b_2 & a_2 & c_2 & \dots & 0 \\ 0 & b_3 & \dots & \dots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & \dots & 0 & b_n & a_n \end{bmatrix}$$

para subrayar que no es necesario tener en cuenta todos sus elementos. Reescriba el algoritmo de factorización de Crout utilizando esta notación y modifique la notación de l_{ij} y de u_{ij} en una forma similar.

22. Demuestre el teorema 6.29. [Sugerencia: demuestre que $|u_{i,i+1}| < 1$ para cada $i = 1, 2, \dots, n-1$ y que $|l_{ii}| > 0$ para cada $i = 1, 2, \dots, n$. Deduzca que $\det A = \det L \cdot \det U \neq 0$.]
23. Suponga que $V = 5.5$ volts en el primer ejemplo de este capítulo. Al reordenar las ecuaciones, podemos formar un sistema lineal tridiagonal. Use el algoritmo de factorización de Crout para obtener la solución del sistema modificado.
24. Use el algoritmo de factorización de Crout para construir el conteo de operaciones para resolver un sistema lineal de $n \times n$.
25. En un trabajo de Dorn y Burdick [DB] se indica lo siguiente: la longitud promedio de las alas que resulta de aparear tres variedades mutantes de moscas de fruta (*Drosophila melanogaster*) puede expresarse en forma de la matriz simétrica

$$A = \begin{bmatrix} 1.59 & 1.69 & 2.13 \\ 1.69 & 1.31 & 1.72 \\ 2.13 & 1.72 & 1.85 \end{bmatrix},$$

donde a_{ij} denota la longitud promedio de las alas de una cría obtenida al aparear un macho de tipo i con una hembra de tipo j .

- a. ¿Cuál es la importancia física de la simetría de esta matriz?
 - b. ¿Es la matriz definida positiva? De ser así, demuéstrelo; en caso contrario, obtenga un vector $\mathbf{x}$ distinto de cero para el cual $\mathbf{x}'A\mathbf{x} \leq 0$.
26. Suponga que la matriz definida positiva A tiene la factorización de Choleski $A = LL'$ y también la factorización $A = \hat{L}D\hat{L}'$, donde D es la matriz diagonal con elementos positivos diagonales $d_{11}, d_{22}, \dots, d_{nn}$. Sea $D^{1/2}$ la matriz diagonal con elementos diagonales $\sqrt{d_{11}}, \sqrt{d_{22}}, \dots, \sqrt{d_{nn}}$.
- a. Demuestre que $D = D^{1/2}D^{1/2}$.
 - b. Demuestre que $L = \hat{L}D^{1/2}$.

6.7 Reseña de métodos y de software

En este capítulo estudiamos los métodos directos para resolver los sistemas lineales. Un sistema lineal consta de n ecuaciones con n incógnitas expresadas en la notación matricial como $A\mathbf{x} = \mathbf{b}$. Estas técnicas utilizan una serie finita de operaciones aritméticas para determinar la solución exacta del sistema, sujeta únicamente al error de redondeo. Descubrimos que el sistema lineal $A\mathbf{x} = \mathbf{b}$ tiene una solución única si y sólo si existe A^{-1} lo cual equivale a $\det A \neq 0$. La solución del sistema lineal es el vector $\mathbf{x} = A^{-1}\mathbf{b}$.

Explicamos las técnicas de pivoteo para reducir al mínimo los efectos del error de redondeo, que pueden dominar la solución cuando se emplean métodos directos. Describimos el pivoteo parcial, el pivoteo parcial escalado y el pivoteo total. Recomendamos los dos primeros procedimientos para resolver la generalidad de los problemas, pues ambos disminuyen los efectos del error de redondeo sin aumentar excesivamente los cálculos adicionales. El pivoteo total deberá emplearse si se sospecha que el error de redondeo es grande. En la sección 7.4 veremos algunos procedimientos para estimar este error.

Demostramos que, con ligeras modificaciones, la eliminación gaussiana produce una factorización de la matriz A en LU , donde L es una matriz triangular inferior con unos en la diagonal y donde U es una matriz triangular superior. A este proceso se le llama factorización de Doolittle. No todas las matrices no singulares pueden ser factorizadas en esta forma, pero una permutación de los renglones dará siempre una factorización de la forma $PA = LU$, donde P es la matriz de permutación con que se rearreglan los renglones de A . La ventaja de la factorización consiste en que el trabajo se reduce cuando se resuelven sistemas lineales $A\mathbf{x} = \mathbf{b}$ con la misma matriz de coeficientes A y con diferentes vectores $\mathbf{b}$.

Cuando la matriz A es definida positiva, las factorizaciones adoptan una forma más simple. Por ejemplo, la factorización de Choleski presenta la forma $A = LL^T$, donde L es una matriz triangular inferior. Las matrices definidas positivas también pueden factorizarse en la forma $A = LDU$ donde L es una matriz triangular inferior con unos en la diagonal y donde D es la diagonal. Con estas factorizaciones, es posible simplificar el manejo de A . Si A es tridiagonal, la factorización LU ofrecerá una forma muy simple: L tiene unos en la diagonal principal y 0 en las demás, salvo en la diagonal situada inmediatamente debajo de la diagonal principal. Además, U tiene exclusivamente elementos distintos de cero en la diagonal principal y en la diagonal situada por arriba.

Los métodos directos son los procedimientos de elección en la generalidad de los sistemas lineales. Los métodos especiales se recomiendan en el caso de matrices tridiagonales, con banda y definidas positivas. En el caso general, se recomienda la eliminación gaussiana o los métodos de factorización LU , que permiten el pivoteo. En estos casos, conviene vigilar los efectos del error de redondeo. En la sección 7.4 veremos cómo estimar los errores de los métodos directos.

Los sistemas lineales grandes, en los cuales ocurren fundamentalmente elementos cero en patrones regulares, pueden resolverse de manera eficiente aplicando un procedimiento iterativo como los que se exponen en el capítulo 7. Este tipo de sistemas se presenta, por ejemplo, cuando se emplean técnicas de diferencia finita para resolver problemas con valor de frontera, aplicación muy común en la solución numérica de las ecuaciones diferenciales parciales.

A veces es muy difícil resolver un sistema lineal grande que tiene básicamente elementos distintos de cero o cuando los elementos cero no muestran un patrón predecible. La matriz asociada al sistema puede colocarse en un almacenamiento secundario en la forma particionada y las partes se introducen en la memoria principal sólo cuando se requieren para los cálculos. Los métodos que requieren almacenamiento secundario pueden ser iterativos o directos, pero generalmente exigen técnicas de las estructuras de datos y la teoría de gráficas. Al lector que desee profundizar en el tema le recomendamos consultar [BuR] y [RW], donde encontrará una amplia explicación de las técnicas actuales.

Los programas para realizar operaciones con matrices y la solución directa de los sistemas lineales implantados en IMSL y NAG se basan en LAPACK, paquete de subrutinas de dominio público. Este paquete contiene una excelente documentación que también puede obtenerse de libros acerca de él. Concentraremos nuestra atención en varias de las subrutinas que vienen en las tres fuentes anteriores.

LAPACK trae un conjunto de operaciones de nivel inferior, denominado Basic Linear Algebra Subprograms (BLAS). El nivel 1 de BLAS generalmente contiene operaciones vectoriales con datos de entrada y conteos de operaciones de $O(n)$. El nivel 2 consta de operaciones de matrices y vectores con datos de entrada y conteo de operaciones $O(n^2)$. El nivel 3 consta de las operaciones matriciales con datos de entrada y conteos de operaciones $O(n^3)$. Por ejemplo, en el nivel 1 la subrutina SCOPY sobrescribe un vector y con un vector x ; SSCAL calcula α veces un escalar por un vector x ; SAXPY agrega a un vector un escalar multiplicado por un vector ($y = \alpha \cdot x + y$); SDOT calcula el producto interno o escalar de dos vectores; SNRM2 calcula la norma euclidiana de un vector aplicando un método semejante al de la sección 1.4, ISAMAX calcula el índice de un componente vectorial que da el valor máximo absoluto de todos los componentes. En el nivel 2, SGEMV calcula el producto de una matriz y un vector y el nivel 3, SGEMM calcula el producto de una matriz y un vector.

Las subrutinas de LAPACK con que se resuelven los sistemas lineales factorizan primero la matriz A . La factorización depende del tipo de matriz, en la siguiente forma:

1. Matriz general $PA = LU$;
2. Matriz definida positiva $A = LL^t$;
3. Matriz simétrica $A = LDL^t$;
4. Matriz tridiagonal $A = LU$ (en forma de banda).

La subrutina STRTRS resuelve un sistema lineal triangular cuando la matriz es triangular inferior o superior.

La subrutina SGETRF factoriza PA en LU como operación preliminar de la subrutina SGETRS, la cual calcula después la solución de $Ax = b$. La subrutina SGETRI sirve para construir la inversa de una matriz A y para calcular la determinante de A una vez que ésta fue factorizada por medio de SGETRF.

La factorización de Choleski para una matriz definida positiva A se obtiene mediante la subrutina SPOTRF. El sistema lineal $Ax = b$ puede resolverse, entonces, aplicando la subrutina SPOTRS. Con SPOTRI pueden calcularse las inversas y los determinantes de las matrices definidas positivas, cuando se utiliza la factorización de Choleski. Si A es simétrica, la factorización LDL^t se obtiene aplicando SSYTRF. Después, los sistemas lineales pueden resolverse por medio de SSYTRS. Si se desean inversas o determinantes, puede utilizarse SSYTRI.

Muchas de las subrutinas de LINPACK, y su sucesor LAPACK, pueden ejecutarse por medio de MATLAB. Una matriz no singular A se factoriza aplicando el comando

$$[L, U, P] = lu(A)$$

en la forma $PA = LU$, donde P es la matriz de permutación que se define al realizar el pivoteo parcial para resolver un sistema lineal que contenga A . Si en MATLAB se definieron la matriz no singular A y el vector b , el comando

$$x = A \setminus b$$

resuelve el sistema lineal usando primero el comando de factorización $PA = LU$. Después resuelve el sistema triangular inferior $Lz = b$ para z por medio del comando,

$$z = L \setminus b$$

Esto se acompaña de una solución del sistema triangular superior $Ux = z$ aplicando el comando

$$x = U \setminus z$$

Otros comandos de MATLAB incluyen el cálculo de la inversa, la transpuesta y el determinante de la matriz A por medio de los comandos $inv(A)$, A' y $det(A)$, respectivamente.

La biblioteca IMSL incluye equivalentes de casi todas las subrutinas de LAPACK y además algunas extensiones. Se les asigna un nombre que indica las tareas que realizan, a saber:

1. Se usan las tres primeras letras del nombre.
 - a. LSL: resuelve un sistema lineal
 - b. LFT: factoriza una matriz de coeficientes
 - c. LFS: resuelve un sistema lineal dados los factores de LFT
 - d. LFD: calcula los determinantes de los factores dados
 - e. LIN: calcula la inversa de los factores dados

2. Las dos últimas letras indican el tipo de matriz en cuestión.
 - a. RG: real general
 - b. RT: real triangular
 - c. DS: real definida positiva
 - d. SF: real simétrica
 - e. RB: real con banda

Por ejemplo, la rutina LFTDS factoriza una matriz real positiva definida.

La biblioteca NAG cuenta con muchas subrutinas de métodos directos para resolver sistemas lineales, las cuales se asemejan a las de LAPACK y de IMSL. Por ejemplo, la subrutina F04AEF resuelve sistemas lineales mediante la factorización de Crout. La subrutina F04ATF resuelve un solo sistema lineal mediante la factorización de Crout, igual que F04AEF. La subrutina F04EAF resuelve un solo sistema lineal en el que la matriz es real y tridiagonal, y F04ASF lo resuelve cuando la matriz es real y positiva definida. Las matrices inversas pueden calcularse por medio de F07AJF después de usar F07ADF para una matriz real y para F01ABF en el caso de una matriz definida positiva. Un determinante puede calcularse con F03AAF. La factorización puede obtenerse usando F07ADF en la factorización *LU* de una matriz real y usando F01LEF con una matriz tridiagonal; los sistemas lineales pueden resolver, entonces, mediante F07AEF. La factorización de Choleski para una matriz definida positiva puede obtenerse aplicando F07FDF, y un sistema lineal puede obtenerse aplicando F07FEF. La biblioteca NAG también incluye manejo de matriz y vectores de nivel inferior.


En Golub y Van Loan [GV], en Forsythe y Moler [FM] y en Stewart [St], se puede encontrar información complementaria sobre la solución numérica de sistemas lineales y de matrices. El empleo de métodos directos para resolver grandes sistemas analíticos se explica ampliamente en George y Liu [GL] y en Pissanetzky [Pi]. Coleman y Van Loan [CV] estudian la utilización de BLAS, LINPACK y MATLAB.

CAPÍTULO 7

Métodos iterativos en el álgebra matricial

...

Los armazones son estructuras ligeras capaces de soportar cargas pesadas. En el diseño de puentes, los miembros de la estructura están conectados con juntas rotatorias de pasador que permiten transferir las fuerzas de un miembro a otro. La figura anexa muestra una estructura que se mantiene estacionaria en el extremo inferior de la izquierda ①, que se desplaza horizontalmente en el extremo inferior derecho ④ y que tiene juntas de pasador en ①, ②, ③ y ④. Se coloca una carga de 10 000 newtons (N) en la junta ③ y las fuerzas que actúan sobre los miembros de la estructura tienen magnitudes dadas por f_1, f_2, f_3, f_4 y f_5 como se observa en la figura. El miembro de soporte estacionario tiene una fuerza horizontal F_1 y una fuerza vertical F_2 , pero el miembro de soporte móvil tiene únicamente la fuerza vertical F_3 .



Si la estructura está en equilibrio estático, las fuerzas en cada junta deben agregarse al vector cero, de modo que la suma de las componentes horizontal y vertical de las fuerzas en cada junta debe ser cero. Esto genera el sistema de ecuaciones lineales que aparecen

Material protegido por derechos de autor

en la tabla adjunta. Una matriz de 8×8 que lo describe tiene 46 elementos cero y apenas 18 elementos no cero. Las matrices con un alto porcentaje de elementos cero reciben el nombre de *esparcidas* y, a menudo, se resuelven aplicando métodos iterativos más que directos. La solución iterativa de este sistema se incluye en el ejercicio 18 de la sección 7.3.

Junta	Componentes horizontales	Componentes verticales
①	$-F_1 + \frac{\sqrt{2}}{2}f_1 + f_2 = 0$	$\frac{\sqrt{2}}{2}f_1 - F_2 = 0$
②	$-\frac{\sqrt{2}}{2}f_1 + \frac{\sqrt{3}}{2}f_4 = 0$	$-\frac{\sqrt{2}}{2}f_1 - f_3 + \frac{1}{2}f_4 = 0$
③	$-f_2 + f_3 = 0$	$f_3 - 10\,000 = 0$
④	$-\frac{\sqrt{3}}{2}f_4 - f_3 = 0$	$\frac{1}{2}f_4 - F_3 = 0$

Los métodos estudiados en el capítulo 6 usaron métodos directos para resolver un sistema de $n \times n$ ecuaciones lineales de la forma $Ax = b$. En este capítulo estudiaremos los métodos iterativos con que se resuelve un sistema de este tipo.

7.1 Normas de vectores y de matrices

En el capítulo 2 explicamos los métodos iterativos para obtener las raíces de ecuaciones de la forma $f(x) = 0$. Encontramos una aproximación inicial (o aproximaciones), y luego determinamos otras nuevas basándonos en qué tan bien las aproximaciones anteriores satisfacen la ecuación. Antes de empezar el estudio de los métodos iterativos con que se resuelven los sistemas lineales, necesitamos contar primero con un medio que nos permita medir la distancia entre los vectores columna n -dimensionales, para determinar si una serie de esos vectores convergen a una solución del sistema. En la práctica, también necesitamos esta medida cuando la solución se obtiene por los métodos directos expuestos en el capítulo 6. Estos requirieron muchas operaciones aritméticas, y el uso de la aritmética de dígitos finitos conduce sólo a una aproximación de la solución real del sistema.

Denotemos con $\mathbb{R}^n$ el conjunto de todos los vectores columna n -dimensionales con componentes de números reales. Si queremos definir una distancia en $\mathbb{R}^n$ utilizaremos la noción de una norma.

Definición 7.1 Una norma vectorial en $\mathbb{R}^n$ es una función, $\|\cdot\|$, de $\mathbb{R}^n$ a $\mathbb{R}$ con las siguientes propiedades:

- (i) $\|x\| \geq 0$ para toda $x \in \mathbb{R}^n$,
- (ii) $\|x\| = 0$ si y sólo si $x = 0$,
- (iii) $\|\alpha x\| = |\alpha| \|x\|$ para todo $\alpha \in \mathbb{R}$ y $x \in \mathbb{R}^n$,
- (iv) $\|x + y\| \leq \|x\| + \|y\|$ para todo $x, y \in \mathbb{R}^n$.

Necesitaremos sólo dos normas específicas en $\mathbb{R}^n$ aunque en el ejercicio 2 se presenta una tercera norma de este vector.

Como los vectores de $\mathbb{R}^n$ son vectores columna, conviene utilizar la notación de la transpuesta que se vio en la sección 6.3, cuando representamos un vector en función de sus componentes. Por ejemplo, el vector

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

se escribirá $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$.

Definición 7.2 Las normas l_2 y l_∞ del vector $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ están definidas por

$$\|\mathbf{x}\|_2 = \left\{ \sum_{i=1}^n x_i^2 \right\}^{1/2} \quad \text{y} \quad \|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|.$$

La norma l_2 se llama **norma euclídeana** del vector $\mathbf{x}$, dado que representa la noción común de distancia respecto al origen en caso de que $\mathbf{x}$ esté en $\mathbb{R}^1 \equiv \mathbb{R}$, $\mathbb{R}^2$, o bien $\mathbb{R}^3$. Por ejemplo, la norma l_2 del vector $\mathbf{x} = (x_1, x_2, x_3)^T$ denota la longitud del segmento de recta que une los puntos $(0, 0, 0)$ y (x_1, x_2, x_3) . En la figura 7.1 se muestra la frontera de los vectores en $\mathbb{R}^2$ y $\mathbb{R}^3$ que tienen la norma l_2 menor que 1. La figura 7.2 contiene un ejemplo semejante de la norma l_∞ .

Figura 7.1





Figura 7.2



EJEMPLO 1 El vector $\mathbf{x} = (-1, 1, -2)^T$ en $\mathbb{R}^3$ tiene las normas

$$\|\mathbf{x}\|_2 = \sqrt{(-1)^2 + (1)^2 + (-2)^2} = \sqrt{6}$$

y

$$\|\mathbf{x}\|_\infty = \max\{|-1|, |1|, |-2|\} = 2.$$

Es fácil demostrar que las propiedades de la definición 7.1 se aplican también a la norma l_∞ pues provienen de resultados semejantes para valores absolutos. Por ejemplo, si $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ y $\mathbf{y} = (y_1, y_2, \dots, y_n)^T$, entonces

$$\|\mathbf{x} + \mathbf{y}\|_\infty = \max_{1 \leq i \leq n} |x_i + y_i| \leq \max_{1 \leq i \leq n} (|x_i| + |y_i|) \leq \max_{1 \leq i \leq n} |x_i| + \max_{1 \leq i \leq n} |y_i| = \|\mathbf{x}\|_\infty + \|\mathbf{y}\|_\infty.$$

Si queremos demostrar que

$$\|\mathbf{x} + \mathbf{y}\|_2 \leq \|\mathbf{x}\|_2 + \|\mathbf{y}\|_2, \quad \text{para todo } \mathbf{x}, \mathbf{y} \in \mathbb{R}_n,$$

necesitamos una famosa desigualdad.

Teorema 7.3 (Desigualdad de Cauchy-Buniakowsky-Schwarz)

Para toda $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ y $\mathbf{y} = (y_1, y_2, \dots, y_n)^T$, en $\mathbb{R}^n$,

$$\mathbf{x}^T \mathbf{y} = \sum_{i=1}^n x_i y_i \leq \left\{ \sum_{i=1}^n x_i^2 \right\}^{1/2} \left\{ \sum_{i=1}^n y_i^2 \right\}^{1/2} = \|\mathbf{x}\| \cdot \|\mathbf{y}\|. \quad (7.1)$$

Demostración Si $y = 0$ o $x = 0$, el resultado será inmediato porque ambos lados de la desigualdad son cero.

Supongamos que $y \neq 0$ y que $x \neq 0$. Para cada $\lambda \in \mathbb{R}$,

$$0 \leq \|x - \lambda y\|_2^2 = \sum_{i=1}^n (x_i - \lambda y_i)^2 = \sum_{i=1}^n x_i^2 - 2\lambda \sum_{i=1}^n x_i y_i + \lambda^2 \sum_{i=1}^n y_i^2,$$

así que

$$2\lambda \sum_{i=1}^n x_i y_i \leq \sum_{i=1}^n x_i^2 + \lambda^2 \sum_{i=1}^n y_i^2 = \|x\|_2^2 + \lambda^2 \|y\|_2^2.$$

Como $\|x\|_2 > 0$ y $\|y\|_2 > 0$, podemos hacer $\lambda = \|x\|_2 / \|y\|_2$ para obtener

$$\left(2 \frac{\|x\|_2}{\|y\|_2}\right) \left(\sum_{i=1}^n x_i y_i\right) \leq \|x\|_2^2 + \frac{\|x\|_2^2}{\|y\|_2^2} \|y\|_2^2 = 2\|x\|_2^2,$$

así

$$2 \sum_{i=1}^n x_i y_i \leq 2\|x\|_2^2 \frac{\|y\|_2}{\|x\|_2} = 2\|x\|_2 \|y\|_2.$$

Por tanto,

$$x^T y = \sum_{i=1}^n x_i y_i \leq \|x\|_2 \|y\|_2 = \left\{ \sum_{i=1}^n x_i^2 \right\}^{1/2} \left\{ \sum_{i=1}^n y_i^2 \right\}^{1/2} \quad \blacksquare$$

Con este resultado vemos que para cada $x, y \in \mathbb{R}^n$,

$$\|x + y\|_2^2 = \sum_{i=1}^n (x_i + y_i)^2 = \sum_{i=1}^n x_i^2 + 2 \sum_{i=1}^n x_i y_i + \sum_{i=1}^n y_i^2 \leq \|x\|_2^2 + 2\|x\|_2 \|y\|_2 + \|y\|_2^2,$$

lo cual nos da la última propiedad de la norma

$$\|x + y\|_2 \leq (\|x\|_2^2 + 2\|x\|_2 \|y\|_2 + \|y\|_2^2)^{1/2} = \|x\|_2 + \|y\|_2.$$

La norma de un vector proporciona una medida de la distancia entre un vector arbitrario y el vector cero; por ello, podemos definir la **distancia entre dos vectores** como la norma de la diferencia de los vectores.

Definición 7.4 Si $x = (x_1, x_2, \dots, x_n)^T$ y $y = (y_1, y_2, \dots, y_n)^T$ son vectores en $\mathbb{R}^n$, las distancias l_2 y l_∞ entre x y y están definidas por

$$\|x - y\|_2 = \left\{ \sum_{i=1}^n (x_i - y_i)^2 \right\}^{1/2} \quad y \quad \|x - y\|_\infty = \max_{1 \leq i \leq n} |x_i - y_i|. \quad \blacksquare$$

EJEMPLO 2 El sistema lineal

$$\begin{aligned} 3.3330x_1 + 15920x_2 - 10.333x_3 &= 15913, \\ 2.2220x_1 + 16.710x_2 + 9.6120x_3 &= 28.544, \\ 1.5611x_1 + 5.1791x_2 + 1.6852x_3 &= 8.4254 \end{aligned}$$

tiene la solución $(x_1, x_2, x_3)' = (1, 1, 1)'$. Si efectuamos la eliminación gaussiana en la aritmética de redondeo a cinco dígitos utilizando el pivoteo parcial (algoritmo 6.2), la solución que se obtiene es

$$\tilde{\mathbf{x}} = (\tilde{x}_1, \tilde{x}_2, \tilde{x}_3)' = (1.2001, 0.99991, 0.92538)'.$$

Las mediciones de $\mathbf{x} - \tilde{\mathbf{x}}$ están dadas por

$$\begin{aligned} \|\mathbf{x} - \tilde{\mathbf{x}}\|_{\infty} &= \max\{|1 - 1.2001|, |1 - 0.99991|, |1 - 0.92538|\} \\ &= \max\{0.2001, 0.00009, 0.07462\} = 0.2001 \end{aligned}$$

y por

$$\begin{aligned} \|\mathbf{x} - \tilde{\mathbf{x}}\|_2 &= [(1 - 1.2001)^2 + (1 - 0.99991)^2 + (1 - 0.92538)^2]^{1/2} \\ &= [(0.2001)^2 + (0.00009)^2 + (0.07462)^2]^{1/2} = 0.21356. \end{aligned}$$

Aunque las componentes $\tilde{x}_2$ y $\tilde{x}_3$ son buenas aproximaciones de x_2 y de x_3 , la componente $\tilde{x}_1$ es una aproximación deficiente de x_1 , y $|x_1 - \tilde{x}_1|$ domina las normas. ■

El concepto de distancia en $\mathbb{R}^n$ también sirve para definir el límite de una sucesión de vectores en este espacio.

Definición 7.5 Se dice que una sucesión $\{\mathbf{x}^{(k)}\}_{k=1}^{\infty}$ de vectores en $\mathbb{R}^n$ converge a $\mathbf{x}$ respecto a la norma $\|\cdot\|$ si dado cualquier $\varepsilon > 0$, existe un entero $N(\varepsilon)$ tal que

$$\|\mathbf{x}^{(k)} - \mathbf{x}\| < \varepsilon, \quad \text{para todo } k \geq N(\varepsilon). \quad \blacksquare$$

Teorema 7.6 La sucesión de vectores $\{\mathbf{x}^{(k)}\}$ converge a $\mathbf{x}$ en $\mathbb{R}^n$ respecto a $\|\cdot\|_{\infty}$ si y sólo si $\lim_{k \rightarrow \infty} x_i^{(k)} = x_i$, para cada $i = 1, 2, \dots, n$. ■

Demostración Supongamos que $\{\mathbf{x}^{(k)}\}$ converge en $\mathbf{x}$ respecto a $\|\cdot\|_{\infty}$. Dado cualquier $\varepsilon > 0$, existe un entero $N(\varepsilon)$ tal que para toda $k \geq N(\varepsilon)$,

$$\max_{i=1,2,\dots,n} |x_i^{(k)} - x_i| = \|\mathbf{x}^{(k)} - \mathbf{x}\|_{\infty} < \varepsilon.$$

Este resultado implica que $|x_i^{(k)} - x_i| < \varepsilon$, para cada $i = 1, 2, \dots, n$, de modo que para cada i , $\lim_{k \rightarrow \infty} x_i^{(k)} = x_i$.

Por el contrario, supongamos que $\lim_{k \rightarrow \infty} x_i^{(k)} = x_i$, para cada $i = 1, 2, \dots, n$. Para cualquier $\varepsilon > 0$, sea $N_i(\varepsilon)$, para cada i , la representación de un entero con la propiedad de que

$$|x_i^{(k)} - x_i| < \varepsilon,$$

siempre que $k \geq N_i(\varepsilon)$.

Definimos $N(\varepsilon) = \max_{i=1,2,\dots,n} N_i(\varepsilon)$. Si $k \geq N(\varepsilon)$, entonces

$$\max_{i=1,2,\dots,n} |x_i^{(k)} - x_i| = \|\mathbf{x}^{(k)} - \mathbf{x}\|_\infty < \varepsilon.$$

Esto implica que $\{\mathbf{x}^{(k)}\}$ converge a $\mathbf{x}$ con respecto a $\|\cdot\|_\infty$. ■ ■ ■

EJEMPLO 3 Definamos $\mathbf{x}^{(k)} \in \mathbb{R}^4$ como

$$\mathbf{x}^{(k)} = (x_1^{(k)}, x_2^{(k)}, x_3^{(k)}, x_4^{(k)})^T = \left(1, 2 + \frac{1}{k}, \frac{1}{k^2}, e^{-k} \sin k\right)^T.$$

Puesto que $\lim_{k \rightarrow \infty} 1 = 1$, $\lim_{k \rightarrow \infty} (2 + 1/k) = 2$, $\lim_{k \rightarrow \infty} 1/k^2 = 0$ y $\lim_{k \rightarrow \infty} e^{-k} \sin k = 0$. El teorema 7.6 implica que la sucesión $\{\mathbf{x}^{(k)}\}$ converge a $(1, 2, 0, 0)^T$ respecto a $\|\cdot\|_\infty$. ■

Es muy complicado demostrar directamente que la sucesión del ejemplo 3 converge a $(1, 2, 0, 0)^T$ respecto a la norma l_2 . Resulta más fácil probar el siguiente resultado y aplicarlo después a este caso especial.

Teorema 7.7 Para todo $\mathbf{x} \in \mathbb{R}^n$,

$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \sqrt{n} \|\mathbf{x}\|_\infty.$$

Demostración Sea x_j la coordenada de $\mathbf{x}$ tal que $\|\mathbf{x}\|_\infty = \max_{1 \leq j \leq n} |x_j| = |x_j|$. Entonces

$$\|\mathbf{x}\|_\infty^2 = |x_j|^2 = x_j^2 \leq \sum_{i=1}^n x_i^2 = \|\mathbf{x}\|_2^2,$$

por tanto

$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2,$$


y

$$\|\mathbf{x}\|_2^2 = \sum_{i=1}^n x_i^2 \leq \sum_{i=1}^n x_j^2 = nx_j^2 = n\|\mathbf{x}\|_\infty^2,$$

por tanto $\|\mathbf{x}\|_2 \leq \sqrt{n} \|\mathbf{x}\|_\infty$. ■ ■ ■

La figura 7.3 muestra gráficamente este resultado cuando $n = 2$.

Figura 7.3



EJEMPLO 4 En el ejemplo 3 vimos que la sucesión $\{\mathbf{x}^{(k)}\}$, definida por

$$\mathbf{x}^{(k)} = \left(1, 2 + \frac{1}{k}, \frac{3}{k^2}, e^{-k} \sin k \right)^t,$$

converge a $\mathbf{x} = (1, 2, 0, 0)^t$ respecto a $\|\cdot\|_\infty$. Dada cualquier $\varepsilon > 0$, existe un entero $N(\varepsilon/2)$ con la propiedad de que

$$\|\mathbf{x}^{(k)} - \mathbf{x}\|_\infty < \frac{\varepsilon}{2},$$

siempre que $k \geq N(\varepsilon/2)$. Conforme al teorema 7.7, lo anterior implica que

$$\|\mathbf{x}^{(k)} - \mathbf{x}\|_2 < \sqrt{4} \|\mathbf{x}^{(k)} - \mathbf{x}\|_\infty < 2(\varepsilon/2) = \varepsilon,$$

cuando $k \geq N(\varepsilon/2)$. Por tanto, $\{\mathbf{x}^{(k)}\}$ converge a $\mathbf{x}$ respecto a $\|\cdot\|_2$. ■

Puede demostrarse que todas las normas de $\mathbb{R}^n$ son equivalentes respecto a la convergencia; es decir, si $\|\cdot\|$ y $\|\cdot\|'$ son dos normas cualesquiera en $\mathbb{R}^n$ y si $\{\mathbf{x}^{(k)}\}_{k=1}^\infty$ tiene el límite $\mathbf{x}$ respecto a $\|\cdot\|$ entonces $\{\mathbf{x}^{(k)}\}_{k=1}^\infty$ también tendrá el límite $\mathbf{x}$ respecto a $\|\cdot\|'$. La demostración de este hecho para el caso general se encuentra en [Or2, p. 8]. Del teorema 7.7 se deduce el caso de las normas $\|\cdot\|_2$ y $\|\cdot\|_\infty$.

En las secciones siguientes de este capítulo, y de otros posteriores, necesitaremos métodos para determinar la distancia entre las matrices de $n \times n$. Para ello se requiere una vez más el concepto de norma.

Definición 7.8 Una **norma matricial** sobre el conjunto de todas las matrices de $n \times n$ es una función de valor real, $\|\cdot\|$, definida en este conjunto y que satisface para todas las matrices A y B de $n \times n$ y todos los números reales α :

- (i) $\|A\| \geq 0$.
- (ii) $\|A\| = 0$, si y sólo si A es O , la matriz con todas las entradas cero.

- (iii) $\|\alpha A\| = |\alpha| \|A\|$.
- (iv) $\|A + B\| \leq \|A\| + \|B\|$.
- (v) $\|AB\| \leq \|A\| \|B\|$. ■

La distancia entre las matrices A y B de $n \times n$ respecto a esta norma matricial es $\|A - B\|$.

Aunque las normas matriciales se pueden obtener de varias formas, aquí únicamente consideraremos las que son consecuencia natural de las normas vectoriales l_2 y l_∞ .

El siguiente teorema no es difícil de demostrar, y su demostración se deja para el ejercicio 13.

Teorema 7.9 Si $\|\cdot\|$ es una norma vectorial de $\mathbb{R}^n$, entonces

$$\|A\| = \max_{\|x\|=1} \|Ax\|$$

es una norma matricial. ■

A ésta se le llama **norma matricial natural** o *inducida* asociada con la norma vectorial. En este libro supondremos que todas las normas matriciales son naturales, a menos que especifiquemos lo contrario.

Para cualquier $z \neq 0$, tenemos que $x = z/\|z\|$ es un vector unitario. Por lo tanto,

$$\max_{\|x\|=1} \|Ax\| = \max_{z \neq 0} \left\| A \left(\frac{z}{\|z\|} \right) \right\| = \max_{z \neq 0} \frac{\|Az\|}{\|z\|},$$

y podemos escribir en forma alternativa

$$\|A\| = \max_{z \neq 0} \frac{\|Az\|}{\|z\|}. \quad (7.2)$$

El siguiente corolario del teorema 7.9 es consecuencia de esta representación de $\|A\|$.

Corolario 7.10 Para todo vector $z \neq 0$, matriz A y cualquier norma natural $\|\cdot\|$, tenemos

$$\|Az\| \leq \|A\| \cdot \|z\| \quad \blacksquare$$

La medida dada a una matriz conforme a la norma natural describe cómo la matriz extiende los vectores unitarios relacionados con esa norma. La extensión máxima es la norma de la matriz. Las normas matriciales que consideraremos aquí tienen las formas

$$\|A\|_\infty = \max_{\|x\|_\infty=1} \|Ax\|_\infty, \quad \text{la norma } l_\infty$$

y

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2, \quad \text{la norma } l_2.$$

Figura 7.4





Figura 7.5



En las figuras 7.4 y 7.5 se incluye un ejemplo de estas normas cuando $n = 2$.

La norma l_∞ de una matriz tiene una representación interesante respecto a sus elementos.

Teorema 7.11 Si $A = (a_{ij})$ es una matriz de $n \times n$, entonces

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|.$$

■

Demostración Primero demostremos que $\|A\|_\infty \leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$. Sea x un vector columna n -dimensional con $1 = \|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$. Puesto que Ax también es un vector columna n -dimensional,

$$\|Ax\|_\infty = \max_{1 \leq i \leq n} |(Ax)_i| = \max_{1 \leq i \leq n} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \max_{1 \leq i \leq n} |x_j|.$$

Dado que $\max_{1 \leq j \leq n} |x_j| = \|x\|_\infty = 1$, tenemos

$$\|A\|_\infty \leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|.$$

En consecuencia,

$$\|A\|_\infty = \max_{\|x\|_\infty=1} \|Ax\|_\infty \leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|. \quad (7.3)$$

Ahora necesitamos demostrar la desigualdad opuesta, $\|A\|_\infty \geq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$. Sea p un entero tal que

$$\sum_{j=1}^n |a_{pj}| = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|,$$

y sea x el vector con las componentes

$$x_j = \begin{cases} 1, & \text{si } a_{pj} \geq 0, \\ -1, & \text{si } a_{pj} < 0, \end{cases}$$

Entonces $\|x\|_\infty = 1$ y $a_{pj}x_j = |a_{pj}|$, para toda $j = 1, 2, \dots, n$, así que

$$\|Ax\|_\infty = \max_{1 \leq i \leq n} \left| \sum_{j=1}^n a_{ij} x_j \right| \geq \left| \sum_{j=1}^n a_{pj} x_j \right| = \left| \sum_{j=1}^n |a_{pj}| \right| = \sum_{j=1}^n |a_{pj}| = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|.$$

Este resultado implica que

$$\|A\|_\infty = \max_{\|x\|_\infty=1} \|Ax\|_\infty \geq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|,$$

lo cual, junto con la desigualdad (7.3), nos da

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|.$$

■ ■ ■

EJEMPLO 5 Si

$$A = \begin{bmatrix} 1 & 2 & -1 \\ 0 & 3 & -1 \\ 5 & -1 & 1 \end{bmatrix},$$

entonces

$$\sum_{j=1}^3 |a_{1j}| = |1| + |2| + |-1| = 4,$$

$$\sum_{j=1}^3 |a_{2j}| = |0| + |3| + |-1| = 4,$$

y

$$\sum_{j=1}^3 |a_{3j}| = |5| + |-1| + |1| = 7;$$

así que

$$\|A\|_{\infty} = \max\{4, 4, 7\} = 7. \quad \blacksquare$$

En la siguiente sección veremos un método alternativo con el que se obtiene la norma l_2 de una matriz.

CONJUNTO DE EJERCICIOS 7.1

- Obtenga $\|x\|_{\infty}$ y $\|x\|_2$ para los siguientes vectores.
 - $x = (3, -4, 0, \frac{1}{2})^T$
 - $x = (2, 1, -3, 4)^T$
 - $x = (\sin k, \cos k, 2^k)^T$ para un entero positivo fijo k
 - $x = (4/(k+1), 2/k^2, k^2 e^{-k})^T$ para un entero positivo fijo k
- Verifique que la función $\|\cdot\|_1$, definida en $\mathbb{R}^n$ por

$$\|x\|_1 = \sum_{i=1}^n |x_i|,$$

es una norma de $\mathbb{R}^n$.

- Obtenga $\|x\|_1$ para los vectores del ejercicio 1.
 - Demuestre que para todo $x \in \mathbb{R}^n$, $\|x\|_1 \geq \|x\|_2$.
- Demuestre que las siguientes sucesiones son convergentes y encuentre sus límites.
 - $x^{(k)} = (1/k, e^{1-k}, -2/k^2)^T$
 - $x^{(k)} = (e^{-k} \cos k, k \sin(1/k), 3 + k^{-2})^T$
 - $x^{(k)} = (ke^{-k^2}, (\cos k)/k, \sqrt{k^2 + k} - k)^T$
 - $x^{(k)} = (e^{1/k}, (k^2 + 1)/(1 - k^2), (1/k^2)(1 + 3 + 5 + \cdots + (2k - 1)))^T$
 - Obtenga $\|\cdot\|_{\infty}$ para las matrices siguientes.
 - $\begin{bmatrix} 10 & 15 \\ 0 & 1 \end{bmatrix}$
 - $\begin{bmatrix} 10 & 0 \\ 15 & 1 \end{bmatrix}$

$$\text{c. } \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

$$\text{d. } \begin{bmatrix} 4 & -1 & 7 \\ -1 & 4 & 0 \\ -7 & 0 & 4 \end{bmatrix}$$

5. Los sistemas lineales siguientes $A\mathbf{x} = \mathbf{b}$ tienen a $\mathbf{x}$ como la solución real y a $\bar{\mathbf{x}}$ como una solución aproximada. Calcule $\|\mathbf{x} - \bar{\mathbf{x}}\|_\infty$ y $\|A\bar{\mathbf{x}} - \mathbf{b}\|_\infty$.

a. $\frac{1}{2}x_1 + \frac{1}{3}x_2 = \frac{1}{63},$

$$\frac{1}{3}x_1 + \frac{1}{4}x_2 = \frac{1}{144},$$

$$\mathbf{x} = \left(\frac{1}{7}, -\frac{1}{6}\right)',$$

$$\bar{\mathbf{x}} = (0.142, -0.166)',$$

b. $x_1 + 2x_2 + 3x_3 = 1,$

$$2x_1 + 3x_2 + 4x_3 = -1,$$

$$3x_1 + 4x_2 + 6x_3 = 2,$$

$$\mathbf{x} = (0, -7, 5)',$$

$$\bar{\mathbf{x}} = (-0.33, -7.9, 5.8)',$$

c. $x_1 + 2x_2 + 3x_3 = 1,$

$$2x_1 + 3x_2 + 4x_3 = -1,$$

$$3x_1 + 4x_2 + 6x_3 = 2,$$

$$\mathbf{x} = (0, -7, 5)',$$

$$\bar{\mathbf{x}} = (-0.2, -7.5, 5.4)',$$

d. $0.04x_1 + 0.01x_2 - 0.01x_3 = 0.06,$

$$0.2x_1 + 0.5x_2 - 0.2x_3 = 0.3,$$

$$x_1 + 2x_2 + 4x_3 = 11,$$

$$\mathbf{x} = (1.827586, 0.6551724, 1.965517)',$$

$$\bar{\mathbf{x}} = (1.8, 0.64, 1.9)',$$

6. La norma matricial $\|\cdot\|_1$, definida por $\|A\|_1 = \max_{1 \leq j \leq n} \|A\mathbf{e}_j\|_1$, puede calcularse mediante la fórmula

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|,$$

donde la norma vectorial $\|\cdot\|_1$ se definió en el ejercicio 2. Obtenga $\|\cdot\|_1$ para las matrices del ejercicio 4.

7. Demuestre con un ejemplo que $\|\cdot\|_\infty$, definida por $\|A\|_\infty = \max_{1 \leq i \leq n} |a_{ii}|$, no define una norma matricial.

8. Demuestre que $\|\cdot\|_\infty$ definida por

$$\|A\|_\infty = \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|,$$

es una norma matricial. Obtenga $\|\cdot\|_\infty$ para las matrices del ejercicio 4.

9. a. La norma de Frobenius (que no es una norma natural) se define para una matriz A de $n \times n$ por medio de

$$\|A\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2}$$

Demuestre que $\|\cdot\|_F$ es una norma matricial.

- b. Obtenga $\|\cdot\|_p$ para las matrices del ejercicio 4.
- c. Para cualquier matriz A , demuestre que $\|A\|_2 \leq \|A\|_p \leq n^{1/2} \|A\|_2$.
10. En el ejercicio 9 definimos la norma de Frobenius para una matriz. Demuestre que para cualquier matriz A de $n \times n$ y para cualquier vector $\mathbf{x}$ de $\mathbb{R}^n$, $\|A\mathbf{x}\|_2 \leq \|A\|_F \|\mathbf{x}\|_2$.
11. Sea S una matriz definida positiva de $n \times n$. Para toda $\mathbf{x}$ en $\mathbb{R}^n$ defina $\|\mathbf{x}\| = (\mathbf{x}'S\mathbf{x})^{1/2}$. Demuestre que esto define una norma en $\mathbb{R}^n$. [Sugerencia: use la descomposición de Choleski de S para demostrar primero que $\mathbf{x}'S\mathbf{y} = \mathbf{y}'S\mathbf{x} \leq (\mathbf{x}'S\mathbf{x})^{1/2} (\mathbf{y}'S\mathbf{y})^{1/2}$.]
12. Sea S una matriz real y no singular, y sea $\|\cdot\|$ cualquier norma de $\mathbb{R}^n$. Defina $\|\cdot\|'$ por medio de $\|\mathbf{x}\|' = \|S\mathbf{x}\|$. Demuestre que $\|\cdot\|'$ también es una norma en $\mathbb{R}^n$.
13. Demuestre que si $\|\cdot\|$ es una norma vectorial en $\mathbb{R}^n$, entonces $\|A\| = \max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\|$ es una norma matricial.
14. El siguiente extracto de *Mathematics Magazine* [Sz] contiene una forma alterna de demostrar la desigualdad de Cauchy-Buniakowsky-Schwarz.
- a. Demuestre que cuando $\mathbf{x} \neq \mathbf{0}$ y $\mathbf{y} \neq \mathbf{0}$ tenemos

$$\frac{\sum_{i=1}^n x_i y_i}{\left(\sum_{i=1}^n x_i^2\right)^{1/2} \left(\sum_{i=1}^n y_i^2\right)^{1/2}} = 1 - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i}{\left(\sum_{j=1}^n x_j^2\right)^{1/2}} - \frac{y_i}{\left(\sum_{j=1}^n y_j^2\right)^{1/2}} \right)^2.$$

- b. Use el resultado de la parte (a) para demostrar que

$$\sum_{i=1}^n x_i y_i \leq \left(\sum_{i=1}^n x_i^2\right)^{1/2} \left(\sum_{i=1}^n y_i^2\right)^{1/2}.$$

7.2 Vectores y valores característicos

Una matriz $n \times m$ se puede considerar como una función que usa la multiplicación de matrices para llevar vectores m -dimensionales en vectores n -dimensionales en sí mismo. En este caso, ciertos vectores no nulos $\mathbf{x}$ son paralelos a $A\mathbf{x}$, lo que significa que existe una constante λ tal que $A\mathbf{x} = \lambda\mathbf{x}$. Para estos vectores, tenemos $(A - \lambda I)\mathbf{x} = \mathbf{0}$. Existe una relación muy estrecha entre estos números λ y la posibilidad de que un método iterativo converja. En esta sección estudiaremos tal relación.

Definición 7.12 Si A es una matriz cuadrada, el polinomio definido por

$$p(\lambda) = \det(A - \lambda I)$$

recibe el nombre de **polinomio característico** de A . ■


No es difícil demostrar (véase el ejercicio 7) que p es un polinomio de grado n y, en consecuencia, que tiene como máximo n ceros distintos, algunos de los cuales pueden ser complejos. Si λ es un cero de p , entonces como $\det(A - \lambda I) = 0$, el teorema 6.16 en la sección 6.4 implica que el sistema lineal definido por $(A - \lambda I)\mathbf{x} = \mathbf{0}$ tiene otra solución que no es $\mathbf{x} = \mathbf{0}$. Deseamos estudiar los ceros de p y las soluciones distintas de cero correspondientes a estos sistemas.

Definición 7.13 Si p es el polinomio característico de la matriz A , los ceros de p se llaman **valores característicos** o **propios** de esa matriz. Si λ es un valor característico de A y si $\mathbf{x} \neq \mathbf{0}$ tiene la

propiedad de que $(A - \lambda I)\mathbf{x} = \mathbf{0}$ entonces a $\mathbf{x}$ se le llama **vector característico** o **propio** de la matriz A correspondiente al valor característico λ . ■

Si $\mathbf{x}$ es un vector característico asociado al valor característico λ , entonces $A\mathbf{x} = \lambda\mathbf{x}$, por lo cual la matriz A transforma al vector $\mathbf{x}$ en un múltiplo escalar de sí misma. Si λ es real y $\lambda > 1$, entonces A tiene el efecto de extender a $\mathbf{x}$ en un factor de λ , como se observa en la figura 7.6(a). Si $0 < \lambda < 1$, entonces A reduce a $\mathbf{x}$ en un factor de λ [véase la figura 7.6(b)]. Cuando $\lambda < 0$, los efectos son semejantes [véase la figura 7.6(c) y (d)], aunque se invierte la dirección de $A\mathbf{x}$.

Figura 7.6

**EJEMPLO 1** Sea

$$A = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 1 & -1 \\ -1 & 1 & 1 \end{bmatrix}.$$

Para calcular los valores característicos de A , consideremos

$$p(\lambda) = \det(A - \lambda I) = \det \begin{bmatrix} 1-\lambda & 0 & 2 \\ 0 & 1-\lambda & -1 \\ -1 & 1 & 1-\lambda \end{bmatrix} = (1-\lambda)(\lambda^2 - 2\lambda + 4).$$

Los valores característicos de A son las soluciones de $p(\lambda) = 0$, que son $\lambda_1 = 1$, $\lambda_2 = 1 + \sqrt{3}i$ y $\lambda_3 = 1 - \sqrt{3}i$.

Un vector característico $\mathbf{x}$ de A asociado a λ_1 es una solución del sistema $(A - \lambda_1 I)\mathbf{x} = \mathbf{0}$:

$$\begin{bmatrix} 0 & 0 & 2 \\ 0 & 0 & -1 \\ -1 & 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

Por tanto,

$$2x_3 = 0, \quad -x_3 = 0 \quad \text{y} \quad -x_1 + x_2 = 0,$$

lo cual implica que

$$x_3 = 0, \quad x_2 = x_1 \quad \text{y} \quad x_1 \text{ arbitraria.}$$

La elección $x_1 = 1$ produce el vector característico $(1, 1, 0)^T$ correspondiente al valor característico $\lambda_1 = 1$. Para esta elección tenemos que $\|(1, 1, 0)^T\|_\infty = 1$.

La elección $x_1 = \sqrt{2}/2$ produce un vector característico correspondiente a λ con

$$\left\| \left(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2}, 0 \right)^T \right\|_2 = 1.$$

Puesto que λ_2 y λ_3 son números complejos, sus vectores característicos correspondientes también lo son. A fin de encontrar un vector característico para λ_2 , resolvemos el sistema

$$\begin{bmatrix} 1 - (1 + \sqrt{3}i) & 0 & 2 \\ 0 & 1 - (1 + \sqrt{3}i) & -1 \\ -1 & 1 & 1 - (1 + \sqrt{3}i) \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

Una solución de este sistema es el vector

$$\left(-\frac{2\sqrt{3}}{3}i, \frac{\sqrt{3}}{3}i, 1 \right)^T.$$

De modo similar, el vector

$$\left(\frac{2\sqrt{3}}{3}i, -\frac{\sqrt{3}}{3}i, 1 \right)^T.$$

es un vector característico correspondiente al valor característico $\lambda_3 = 1 - \sqrt{3}i$. ■

Maple tiene la función `Eigenvals` que calcula los valores característicos y, de manera opcional, los vectores característicos de una matriz. Para el ejemplo visto introducimos lo siguiente:

```
>with(linalg);
>A:=matrix(3,3,[1,0,2,0,1,-1,-1,1,1]);
>evalf(Eigenvals(A));
[1.000000000 + 1.732050807I, 1.000000000 - 1.732050807I, 1.000000000]
```

Con esto se calculan los valores característicos

$$\lambda_2 = 1 + \sqrt{3}i, \quad \lambda_3 = 1 - \sqrt{3}i, \quad \lambda_1 = 1.$$

Para calcular los valores y vectores característicos utilizamos

```
>evalf(Eigenvals(A,B));
```

Los valores característicos se calculan y muestran como antes; los vectores característicos se indican en las columnas de B . Si todos los valores característicos son reales, cada columna de B da un vector característico. Sin embargo, en nuestro ejemplo mostramos B aplicando

```
>evalm(B);
```


$$B = \begin{bmatrix} 1.154700538 & .6324555321 \cdot 10^{-10} & .7453559925 \\ -.5773502680 & .1264911064 \cdot 10^{-9} & .7453559926 \\ -.2581988896 \cdot 10^{-19} & 1.000000000 & -.72572776 \cdot 10^{-11} \end{bmatrix}$$

Las dos primeras columnas corresponden a las partes real e imaginaria de los vectores característicos correspondientes a los valores característicos λ_2 y λ_3 . Por tanto, un vector característico de λ_2 es

$$\begin{bmatrix} 1.154700538 \\ -.5773502680 \\ -.2581988896 \cdot 10^{-19} \end{bmatrix} + \begin{bmatrix} .6324555321 \cdot 10^{-10} \\ .1264911064 \cdot 10^{-9} \\ 1.000000000 \end{bmatrix} i \approx \begin{bmatrix} 1.154700538 \\ -.5773502680 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} i;$$

es decir,

$$(1.154700538, -0.5773502680, i)^T = \left(\frac{2\sqrt{3}}{3}, -\frac{\sqrt{3}}{3}, i \right)^T.$$

Dado que cualquier múltiplo de un vector característico es también un vector característico, tenemos

$$(1, -0.5, 0.8660254i)$$

como vector característico. Al multiplicar cada coordenada por $-(2\sqrt{3}/3)i$ se obtiene el vector característico del ejemplo 1:

$$\left(-\frac{2\sqrt{3}}{3}i, \frac{\sqrt{3}}{3}i, 1 \right)^T.$$

Como λ_1 es real, la tercera columna de B es un vector característico correspondiente a λ_1 .

Los conceptos de valores y vectores característicos se explican aquí por una razón práctica de cálculo, pero se presentan con cierta frecuencia en el estudio de los sistemas físicos. De hecho, tienen tanto interés que el capítulo 9 está dedicado íntegramente a su aproximación numérica.

Definición 7.14 El radio espectral $\rho(A)$ de una matriz A está definido por

$$\rho(A) = \max |\lambda|, \quad \text{donde } \lambda \text{ es un valor característico de } A.$$

(Recuérdese que, para $\lambda = \alpha + \beta i$ complejo, tenemos $|\lambda| = (\alpha^2 + \beta^2)^{1/2}$) ■

En el caso de la matriz del ejemplo 1,

$$\rho(A) = \max\{1, |1 + \sqrt{3}i|, |1 - \sqrt{3}i|\} = \max\{1, 2, 2\} = 2.$$

Como se puede apreciar en el siguiente teorema, el radio espectral guarda estrecha relación con la norma de una matriz.

Teorema 7.15 Si A es una matriz de $n \times n$, entonces

- (i) $\|A\|_2 = [\rho(A^T A)]^{1/2}$,
- (ii) $\rho(A) \leq \|A\|$, para cualquier norma natural $\|\cdot\|$. ■

Demostración La demostración de la parte (i) requiere mayor información sobre los valores característicos que la que tenemos en el momento actual. Al lector que desee mayores detalles concernientes a la demostración, le recomendamos consultar [Or2, p. 21].

Para probar la parte (ii), supongamos que λ es un valor característico de A con el vector característico $\mathbf{x}$ donde $\|\mathbf{x}\| = 1$. (El ejercicio 6 nos garantiza que existe ese vector.) Dado que $A\mathbf{x} = \lambda\mathbf{x}$, para cualquier norma natural

$$|\lambda| = |\lambda| \cdot \|\mathbf{x}\| = \|\lambda\mathbf{x}\| = \|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\| = \|A\|.$$

Por tanto,

$$\rho(A) = \max|\lambda| \leq \|A\|.$$

■ ■ ■

La parte (i) del teorema 7.15 implica que si A es simétrica, entonces $\|A\|_2 = \rho(A)$ (véase el ejercicio 10).

Un resultado interesante y útil, que se parece a la parte (ii) del teorema 7.15, es que para cualquier matriz A y para todo $\varepsilon > 0$ existe una norma natural $\|\cdot\|$ con la propiedad de que $\rho(A) < \|A\| < \rho(A) + \varepsilon$. En consecuencia, $\rho(A)$ es la cota máxima inferior de las normas naturales de A . La demostración de este resultado viene en [Or2, p. 23].

EJEMPLO 2 Si

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ -1 & 1 & 2 \end{bmatrix},$$

entonces

$$A^T A = \begin{bmatrix} 1 & 1 & -1 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ -1 & 1 & 2 \end{bmatrix} = \begin{bmatrix} 3 & 2 & -1 \\ 2 & 6 & 4 \\ -1 & 4 & 5 \end{bmatrix}.$$

Si queremos calcular $\rho(A^T A)$, necesitamos los valores característicos de $A^T A$. Si

$$\begin{aligned} 0 &= \det(A^T A - \lambda I) \\ &= \det \begin{bmatrix} 3-\lambda & 2 & -1 \\ 2 & 6-\lambda & 4 \\ -1 & 4 & 5-\lambda \end{bmatrix} \\ &= -\lambda^3 + 14\lambda^2 - 42\lambda = -\lambda(\lambda^2 - 14\lambda + 42), \end{aligned}$$

entonces

$$\lambda = 0 \quad \text{o} \quad \lambda = 7 \pm \sqrt{7},$$

así que

$$\|A\|_2 = \sqrt{\rho(A^T A)} = \sqrt{\max\{0, 7 - \sqrt{7}, 7 + \sqrt{7}\}} = \sqrt{7 + \sqrt{7}} \approx 3.106. \quad \blacksquare$$

Las operaciones del ejemplo 2 se pueden realizar con Maple, haciendo

```

>with(linalg);
>A:=matrix(3,3,[1,1,0,1,2,1,-1,1,2]);
>B:=transpose(A);
>C:=multiply(A,B);
>evalf(Eigenvals(C));
[0.1097678465 10-8, 4.354248690, 9.645751311]

```

Como $\|A\|_2 = \sqrt{\rho(A^T A)} = \sqrt{\rho(C)}$, tenemos

$$\|A\|_2 = \sqrt{9.645751311} = 3.105760987.$$

Maple también calcula $\|A\|_2 = \sqrt{7 + \sqrt{7}}$ directamente, con el comando

```
>norm(A,2);
```

Para determinar la norma l_∞ de A , se reemplaza el último comando con

```
>norm(A,infinity);
```

Al estudiar los métodos iterativos de matrices, es muy importante saber cuándo las potencias de una matriz se vuelven pequeñas (es decir, cuándo todos los elementos se aproximan a cero). A este tipo de matrices se les llama *convergentes*.

Definición 7.16 Llamamos *convergente* a una matriz de $n \times n$ si

$$\lim_{k \rightarrow \infty} (A^k)_{ij} = 0, \quad \text{para cada } i = 1, 2, \dots, n \text{ y } j = 1, 2, \dots, n. \quad \blacksquare$$

EJEMPLO 3 Sea

$$A = \begin{bmatrix} \frac{1}{2} & 0 \\ \frac{1}{4} & \frac{1}{2} \end{bmatrix}.$$

Al calcular las potencias de A obtenemos:

$$A^2 = \begin{bmatrix} \frac{1}{4} & 0 \\ \frac{1}{4} & \frac{1}{4} \end{bmatrix}, \quad A^3 = \begin{bmatrix} \frac{1}{8} & 0 \\ \frac{3}{16} & \frac{1}{8} \end{bmatrix}, \quad A^4 = \begin{bmatrix} \frac{1}{16} & 0 \\ \frac{1}{8} & \frac{1}{16} \end{bmatrix}.$$

y, en general,

$$A^k = \begin{bmatrix} (\frac{1}{2})^k & 0 \\ \frac{k}{2^{k+1}} & (\frac{1}{2})^k \end{bmatrix}.$$

Dado que

$$\lim_{k \rightarrow \infty} \left(\frac{1}{2}\right)^k = 0 \quad \text{y} \quad \lim_{k \rightarrow \infty} \frac{k}{2^{k+1}} = 0,$$

A es una matriz convergente. ■

En el ejemplo 3 la matriz convergente A tiene $\rho(A) = \frac{1}{2}$, porque $\frac{1}{2}$ es el único valor característico de A . Esto ejemplifica la importante conexión que existe entre el radio espectral de una matriz y su convergencia, como se verá más a fondo en el siguiente resultado.

Teorema 7.17 Las siguientes afirmaciones son equivalentes.

- (i) A es una matriz convergente.
- (ii) $\lim_{n \rightarrow \infty} \|A^n\| = 0$, para alguna norma natural.
- (iii) $\lim_{n \rightarrow \infty} \|A^n\| = 0$, para todas las normas naturales.
- (iv) $\rho(A) < 1$.
- (v) $\lim_{n \rightarrow \infty} A^n \mathbf{x} = \mathbf{0}$, para toda $\mathbf{x}$.

La prueba de este teorema se encuentra en [IK, p. 14].

CONJUNTO DE EJERCICIOS 7.2

1. Calcule los valores característicos y los vectores característicos asociados de las siguientes matrices.

a. $\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$

b. $\begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}$

c. $\begin{bmatrix} 0 & \frac{1}{2} \\ \frac{1}{2} & 0 \end{bmatrix}$

d. $\begin{bmatrix} 1 & 1 \\ -2 & -2 \end{bmatrix}$

e. $\begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 0 \\ 0 & 0 & 3 \end{bmatrix}$

f. $\begin{bmatrix} -1 & 2 & 0 \\ 0 & 3 & 4 \\ 0 & 0 & 7 \end{bmatrix}$

g. $\begin{bmatrix} 2 & 1 & 1 \\ 2 & 3 & 2 \\ 1 & 1 & 2 \end{bmatrix}$

h. $\begin{bmatrix} 3 & 2 & -1 \\ 1 & -2 & 3 \\ 2 & 0 & 4 \end{bmatrix}$

2. Calcule el radio espectral de las matrices del ejercicio 1.
3. ¿Cuáles de las matrices del ejercicio 1 son convergentes?
4. Sean $A_1 = \begin{bmatrix} 1 & 0 \\ \frac{1}{4} & \frac{1}{2} \end{bmatrix}$ y $A_2 = \begin{bmatrix} \frac{1}{2} & 0 \\ 16 & \frac{1}{2} \end{bmatrix}$. Demuestre que A_1 no es convergente, pero A_2 es convergente.
5. Obtenga $\|\cdot\|_2$ para todas las matrices del ejercicio 1.
6. Demuestre que si λ es un valor característico de una matriz A , y si $\|\cdot\|$ es una norma vectorial, entonces existe un vector característico $\mathbf{x}$ asociado a λ con $\|\mathbf{x}\| = 1$.
7. Demuestre que el polinomio característico $p(\lambda) = \det(A - \lambda I)$ para la matriz A de $n \times n$ es un polinomio de n -ésimo grado. [Sugerencia: desarrolle $\det(A - \lambda I)$ a lo largo del primer renglón y use inducción matemática en n .]
8. a. Demuestre que si A es una matriz de $n \times n$, entonces

$$\det A = \prod_{i=1}^n \lambda_i,$$

donde $\lambda_1, \dots, \lambda_n$ son valores característicos de A . [Sugerencia: considere $p(0)$.]

- b. Demuestre que A es singular si y sólo si $\lambda = 0$ es un valor característico de A .

9. Sea λ un valor característico de la matriz A de $n \times n$ y sea $\mathbf{x} \neq \mathbf{0}$ un vector característico asociado.
 - a. Demuestre que λ también es un valor característico de A^t .
 - b. Demuestre que para todo entero $k \geq 1$, λ^k es un valor característico de A^k con el vector característico $\mathbf{x}$.
 - c. Demuestre que si existe A^{-1} , entonces $1/\lambda$ es un valor característico de A^{-1} con el vector característico $\mathbf{x}$.
 - d. Generalice las partes (b) y (c) a $(A^{-1})^k$ para los enteros $k \geq 2$.
 - e. Dado el polinomio $q(x) = q_0 + q_1x + \cdots + q_kx^k$, defina $q(A)$ como la matriz $q(A) = q_0I + q_1A + \cdots + q_kA^k$. Demuestre que $q(\lambda)$ es un valor característico de $q(A)$ con el vector característico $\mathbf{x}$.
 - f. Sea $\alpha \neq \lambda$. Demuestre que si $A - \alpha I$ es no singular, entonces $1/(\lambda - \alpha)$ es un valor característico de $(A - \alpha I)^{-1}$ con el vector característico $\mathbf{x}$.
10. Demuestre que si A es simétrica, entonces $\|A\|_2 = \rho(A)$.
11. En el ejercicio 11 de la sección 6.3 supusimos que la contribución de un escarabajo hembra de cierto tipo a la población de escarabajos de años futuros podía expresarse mediante la matriz

$$A = \begin{bmatrix} 0 & 0 & 6 \\ \frac{1}{2} & 0 & 0 \\ 0 & \frac{1}{3} & 0 \end{bmatrix},$$

donde el elemento del i -ésimo renglón y de la j -ésima columna representa la contribución probabilística de un escarabajo de edad j a la población de hembras de edad i en el año siguiente.

- a. ¿Tiene la matriz A valores característicos reales? De ser así, determine dichos valores y los vectores característicos asociados.
- b. Si una muestra de esta especie se necesitara para efectuar experimentos de laboratorio que año tras año tuvieran una proporción constante en cada grupo de edad, ¿qué criterios se impondrían a la población inicial para estar seguros de que se cumpliría este requisito?
12. Encuentre matrices A y B para las cuales $\rho(A + B) > \rho(A) + \rho(B)$. (Esto demuestra que $\rho(A)$ no puede ser una norma matricial.)
13. Demuestre que, si $\|\cdot\|$ es una norma natural cualquiera, entonces $(1/\|A^{-1}\|) \leq |\lambda| \leq \|A\|$ para todo valor característico λ de una matriz no singular A .

7.3 Métodos iterativos para resolver sistemas lineales

En esta sección describiremos los métodos iterativos de Jacobi y Gauss-Seidel, métodos clásicos que datan de fines del siglo XVIII. Los métodos iterativos rara vez se usan para resolver sistemas lineales de pequeña dimensión, ya que el tiempo necesario para conseguir una exactitud satisfactoria rebasa el que requieren los métodos directos, como el de la iluminación gaussiana. Sin embargo, en el caso de sistemas grandes con un alto porcentaje de elementos cero, son eficientes tanto en almacenamiento de computadora como en el tiempo de cómputo. Este tipo de sistemas se presentan constantemente en los análisis de circuitos y en la solución numérica de los problemas con valor en la frontera y de ecuaciones diferenciales parciales.

Un método iterativo con el cual se resuelve el sistema lineal $A\mathbf{x} = \mathbf{b}$ comienza con una aproximación inicial $\mathbf{x}^{(0)}$ a la solución $\mathbf{x}$ y genera una sucesión de vectores $\{\mathbf{x}^{(k)}\}_{k=0}^{\infty}$ que converge a $\mathbf{x}$. Los métodos iterativos traen consigo un proceso que convierte el sistema $A\mathbf{x} = \mathbf{b}$ en otro equivalente de la forma $\mathbf{x} = T\mathbf{x} + \mathbf{c}$ para alguna matriz fija T y un vector $\mathbf{c}$.

Luego de seleccionar el vector inicial $\mathbf{x}^{(0)}$ la sucesión de los vectores de la solución aproximada se genera calculando

$$\mathbf{x}^{(k)} = T\mathbf{x}^{(k-1)} + \mathbf{c},$$

para cada $k = 1, 2, 3, \dots$. Este resultado debería recordarnos la iteración de punto fijo que estudiamos en el capítulo 2.

EJEMPLO 1 El sistema lineal $A\mathbf{x} = \mathbf{b}$ dado por

$$\begin{aligned} E_1: & 10x_1 - x_2 + 2x_3 = 6, \\ E_2: & -x_1 + 11x_2 - x_3 + 3x_4 = 25, \\ E_3: & 2x_1 - x_2 + 10x_3 - x_4 = -11, \\ E_4: & 3x_2 - x_3 + 8x_4 = 15 \end{aligned}$$

tiene la solución única $\mathbf{x} = (1, 2, -1, 1)^T$. Para convertir $A\mathbf{x} = \mathbf{b}$ en la forma $\mathbf{x} = T\mathbf{x} + \mathbf{c}$, resolvemos la ecuación E_i para x_i con cada $i = 1, 2, 3, 4$ y así obtenemos

$$\begin{aligned} x_1 &= \frac{1}{10}x_2 - \frac{1}{5}x_3 + \frac{3}{5}, \\ x_2 &= \frac{1}{11}x_1 + \frac{1}{11}x_3 - \frac{3}{11}x_4 + \frac{25}{11}, \\ x_3 &= -\frac{1}{5}x_1 + \frac{1}{10}x_2 + \frac{1}{10}x_4 - \frac{11}{10}, \\ x_4 &= -\frac{3}{8}x_2 + \frac{1}{8}x_3 + \frac{15}{8}. \end{aligned}$$

Si queremos escribir esto en la forma $\mathbf{x} = T\mathbf{x} + \mathbf{c}$, utilizamos

$$T = \begin{bmatrix} 0 & \frac{1}{10} & -\frac{1}{5} & 0 \\ \frac{1}{11} & 0 & \frac{1}{11} & -\frac{3}{11} \\ -\frac{1}{5} & \frac{1}{10} & 0 & \frac{1}{10} \\ 0 & -\frac{3}{8} & \frac{1}{8} & 0 \end{bmatrix} \quad \text{y} \quad \mathbf{c} = \begin{bmatrix} \frac{3}{5} \\ \frac{25}{11} \\ -\frac{11}{10} \\ \frac{15}{8} \end{bmatrix}.$$

En el caso de una aproximación inicial, hacemos $\mathbf{x}^{(0)} = (0, 0, 0, 0)^T$. Entonces $\mathbf{x}^{(1)}$ está dado por

$$\begin{aligned} x_1^{(1)} &= \frac{1}{10}x_2^{(0)} - \frac{1}{5}x_3^{(0)} + \frac{3}{5} = 0.6000, \\ x_2^{(1)} &= \frac{1}{11}x_1^{(0)} + \frac{1}{11}x_3^{(0)} - \frac{3}{11}x_4^{(0)} + \frac{25}{11} = 2.2727, \\ x_3^{(1)} &= -\frac{1}{5}x_1^{(0)} + \frac{1}{10}x_2^{(0)} + \frac{1}{10}x_4^{(0)} - \frac{11}{10} = -1.1000, \\ x_4^{(1)} &= -\frac{3}{8}x_2^{(0)} + \frac{1}{8}x_3^{(0)} + \frac{15}{8} = 1.8750. \end{aligned}$$

Las iteraciones adicionales $\mathbf{x}^{(k)} = (x_1^{(k)}, x_2^{(k)}, x_3^{(k)}, x_4^{(k)})^T$, se generan de manera parecida y se incluyen en la tabla 7.1.

Tabla 7.1

k	0	1	2	3	4	5	6	7	8	9	10
$x_1^{(k)}$	0.000	0.6000	1.0473	0.9326	1.0152	0.9890	1.0032	0.9981	1.0006	0.9997	1.0001
$x_2^{(k)}$	0.0000	2.2727	1.7159	2.053	1.9537	2.0114	1.9922	2.0023	1.9987	2.0004	1.9998
$x_3^{(k)}$	0.0000	-1.1000	-0.8052	-1.0493	-0.9681	-1.0103	-0.9945	-1.0020	-0.9990	-1.0004	-0.9998
$x_4^{(k)}$	0.0000	1.8750	0.8852	1.1309	0.9739	1.0214	0.9944	1.0036	0.9989	1.0006	0.9998

La decisión de parar después de diez iteraciones se basó en el criterio

$$\frac{\|\mathbf{x}^{(10)} - \mathbf{x}^{(9)}\|_\infty}{\|\mathbf{x}^{(10)}\|_\infty} = \frac{8.0 \times 10^{-4}}{1.9998} < 10^{-3}.$$

De hecho, $\|\mathbf{x}^{(10)} - \mathbf{x}\|_\infty = 0.0002$. ■

El método del ejemplo 1 se denomina **método iterativo de Jacobi**, y consiste en resolver la i -ésima ecuación en $A\mathbf{x} = \mathbf{b}$ para x_i a fin de obtener (a condición de que $a_{ii} \neq 0$)

$$x_i = \sum_{j=1, j \neq i}^n \left(-\frac{a_{ij} x_j}{a_{ii}} \right) + \frac{b_i}{a_{ii}}, \quad \text{para } i = 1, 2, \dots, n$$

y generar cada $x_i^{(k)}$ a partir de los componentes de $\mathbf{x}^{(k-1)}$ cuando $k \geq 1$ por medio de

$$x_i^{(k)} = \frac{\sum_{j=1, j \neq i}^n \left(-a_{ij} x_j^{(k-1)} \right) + b_i}{a_{ii}}, \quad \text{para } i = 1, 2, \dots, n. \quad (7.4)$$

El método se escribe en la forma $\mathbf{x}^{(k)} = T \mathbf{x}^{(k-1)} + \mathbf{c}$ separando A en sus partes diagonales y fuera de la diagonal. Para comprobar esto, sea D la matriz diagonal cuya diagonal es la misma que A , sea $-L$ la parte estrictamente triangular inferior de la parte A y sea $-U$ la parte estrictamente triangular superior de A . Con esta notación,

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

se divide en

$$A = \begin{bmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & & \\ \vdots & & \ddots & \\ 0 & \cdots & 0 & a_{nn} \end{bmatrix} - \begin{bmatrix} 0 & \cdots & 0 \\ -a_{21} & \ddots & \\ \vdots & & -a_{n,n-1} \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} - \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ & 0 & \ddots & \\ & & & -a_{n-1,n} \\ 0 & \cdots & & 0 \end{bmatrix}$$

$$= D - L - U.$$

Entonces transformamos la ecuación $A\mathbf{x} = \mathbf{b}$, o $(D - L - U)\mathbf{x} = \mathbf{b}$, en

$$D\mathbf{x} = (L + U)\mathbf{x} + \mathbf{b}.$$

y, si D^{-1} existe, es decir, si $a_{ii} \neq 0$ para cada i , entonces

$$\mathbf{x} = D^{-1}(L + U)\mathbf{x} + D^{-1}\mathbf{b}.$$

Esto da origen a la forma matricial del método iterativo de Jacobi:

$$\mathbf{x}^{(k)} = D^{-1}(L + U)\mathbf{x}^{(k-1)} + D^{-1}\mathbf{b}, \quad k = 1, 2, \dots \quad (7.5)$$

Al introducir la notación $T_j = D^{-1}(L + U)$ y $\mathbf{c}_j = D^{-1}\mathbf{b}$, esta técnica tiene la forma

$$\mathbf{x}^{(k)} = T_j \mathbf{x}^{(k-1)} + \mathbf{c}_j. \quad (7.6)$$

En la práctica, la ecuación (7.4) se usa en el cálculo y la (7.6) se emplea con fines teóricos.

En el algoritmo 7.1 se pone en ejecución el método iterativo de Jacobi.

ALGORITMO

7.1

Método iterativo de Jacobi

Para resolver $A\mathbf{x} = \mathbf{b}$ dada una aproximación inicial $\mathbf{x}^{(0)}$:

ENTRADA el número de ecuaciones e incógnitas n ; los elementos a_{ij} , $1 \leq i, j \leq n$ de la matriz A ; los elementos b_i , $1 \leq i \leq n$ de $\mathbf{b}$; los elementos XO_i , $1 \leq i \leq n$ de $\mathbf{XO} = \mathbf{x}^{(0)}$; la tolerancia TOL ; el número máximo de iteraciones N .

SALIDA la solución aproximada $x_1, \dots, x_n$ o el mensaje de que se rebasó el número de iteraciones.

Paso 1 Tome $k = 1$.

Paso 2 Mientras ($k \leq N$) haga pasos 3-6.

Paso 3 Para $i = 1, \dots, n$

$$\text{tome } x_i = \frac{-\sum_{j \neq i}^n (a_{ij} XO_j) + b_i}{a_{ii}}.$$

Paso 4 Si $\|\mathbf{x} - \mathbf{XO}\| < TOL$ entonces **SALIDA** ($x_1, \dots, x_n$);
(Procedimiento terminado exitosamente.)
PARAR.

Paso 5 Tome $k = k + 1$.

Paso 6 Para $i = 1, \dots, n$ tome $XO_i = x_i$.

Paso 7 **SALIDA** ('Número máximo de iteraciones excedido');
(Procedimiento terminado sin éxito.)
PARAR.

El paso 3 del algoritmo requiere que $a_{ii} \neq 0$ para cada $i = 1, 2, \dots, n$. Si uno de los elementos a_{ii} es cero y si el sistema es no singular, podemos reordenar las ecuaciones de modo que ningún $a_{ii} = 0$. Si queremos acelerar la convergencia, debemos arreglar las ecuaciones de modo que a_{ii} sea lo más grande posible. Este tema se trata de manera más detallada en secciones posteriores en este capítulo.

Otro posible criterio de interrupción en el paso 4 consiste en iterar hasta que

$$\frac{\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|}{\|\mathbf{x}^{(k)}\|}$$

sea menor que alguna tolerancia prescrita. Para ello podemos emplear cualquier norma adecuada, siendo la usual l_∞ .

Un análisis de la ecuación (7.4) sugiere una mejora del algoritmo 7.1. Si queremos calcular $x_i^{(k)}$, utilizamos las componentes de $\mathbf{x}^{(k-1)}$. Como para $i > 1$, ya se calcularon $x_1^{(k)}, \dots, x_{i-1}^{(k)}$, y probablemente sean mejores aproximaciones de las soluciones reales $x_1, \dots, x_{i-1}$ que $x_1^{(k-1)}, \dots, x_{i-1}^{(k-1)}$, parece más razonable calcular $x_i^{(k)}$, por medio de los valores calculados más recientemente. Esto es, podemos usar

$$x_i^{(k)} = \frac{-\sum_{j=1}^{i-1} (a_{ij}x_j^{(k)}) - \sum_{j=i+1}^n (a_{ij}x_j^{(k-1)}) + b_i}{a_{ii}}, \quad (7.7)$$

para cada $i = 1, 2, \dots, n$, en vez de la ecuación (7.4). A esta modificación se le llama **método iterativo de Gauss-Seidel** y se explica en el siguiente ejemplo.

EJEMPLO 2 El sistema lineal dado por

$$\begin{aligned} 10x_1 - x_2 + 2x_3 &= 6, \\ -x_1 + 11x_2 - x_3 + 3x_4 &= 25, \\ 2x_1 - x_2 + 10x_3 - x_4 &= -11, \\ 3x_2 - x_3 + 8x_4 &= 15 \end{aligned}$$

se resolvió en el ejemplo 1 por medio del método iterativo de Jacobi. Al incorporar la ecuación (7.7) en el algoritmo 7.1 se obtienen las ecuaciones empleadas con cada $k = 1, 2, \dots$,

$$\begin{aligned} x_1^{(k)} &= \frac{1}{10}x_2^{(k-1)} - \frac{1}{5}x_3^{(k-1)} + \frac{3}{5}, \\ x_2^{(k)} &= \frac{1}{11}x_1^{(k)} + \frac{1}{11}x_3^{(k-1)} - \frac{3}{11}x_4^{(k-1)} - \frac{25}{11}, \\ x_3^{(k)} &= -\frac{1}{5}x_1^{(k)} + \frac{1}{10}x_2^{(k)} + \frac{1}{10}x_4^{(k-1)} - \frac{11}{10}, \\ x_4^{(k)} &= -\frac{3}{8}x_2^{(k)} + \frac{1}{8}x_3^{(k)} + \frac{15}{8}. \end{aligned}$$

Siendo $\mathbf{x}^{(0)} = (0, 0, 0, 0)^t$, generamos las iteraciones de la tabla 7.2.

Tabla 7.2

k	0	1	2	3	4	5
$x_1^{(k)}$	0.0000	0.6000	1.030	1.0065	1.0009	1.0001
$x_2^{(k)}$	0.0000	2.3272	2.037	2.0036	2.0003	2.0000
$x_3^{(k)}$	0.0000	-0.9873	-1.014	-1.0025	-1.0003	-1.0000
$x_4^{(k)}$	0.0000	0.8789	0.9844	0.9983	0.9999	1.0000

Dado que

$$\frac{\|x^{(5)} - x^{(4)}\|_{\infty}}{\|x^{(5)}\|_{\infty}} = \frac{0.0008}{2.000} = 4 \times 10^{-4},$$

se acepta $x^{(5)}$ como una aproximación razonable de la solución. Nótese que en el ejemplo 1 el método de Jacobi requirió el doble de iteraciones para alcanzar el mismo grado de exactitud. ■

Si queremos expresar el método de Gauss-Seidel en forma matricial, multiplicaremos ambos lados de la ecuación (7.7) por a_{ii} y reunimos todos los k -ésimos términos de iteración, lo que nos da

$$a_{i1}x_1^{(k)} + a_{i2}x_2^{(k)} + \cdots + a_{ii}x_i^{(k)} = -a_{i,i+1}x_{i+1}^{(k-1)} - \cdots - a_{in}x_n^{(k-1)} + b_i,$$

para cada $i = 1, 2, \dots, n$. Al escribir todas las n ecuaciones obtenemos

$$\begin{array}{rcl} a_{11}x_1^{(k)} & = & -a_{12}x_2^{(k-1)} - a_{13}x_3^{(k-1)} - \cdots - a_{1n}x_n^{(k-1)} + b_1, \\ a_{21}x_1^{(k)} + a_{22}x_2^{(k)} & = & -a_{23}x_3^{(k-1)} - \cdots - a_{2n}x_n^{(k-1)} + b_2, \\ \vdots & & \\ a_{n1}x_1^{(k)} + a_{n2}x_2^{(k)} + \cdots + a_{nn}x_n^{(k)} & = & b_n. \end{array}$$

y con las definiciones anteriores de D , L y U , se deduce que la forma matricial del método de Gauss-Seidel es

$$(D - L)x^{(k)} = Ux^{(k-1)} + b$$

o bien

$$x^{(k)} = (D - L)^{-1}Ux^{(k-1)} + (D - L)^{-1}b, \text{ para cada } k = 1, 2, \dots \quad (7.8)$$

Si usamos $T_g = (D - L)^{-1}U$ y $c_g = (D - L)^{-1}b$, el método de Gauss-Seidel tiene la forma

$$x^{(k)} = T_g x^{(k-1)} + c_g. \quad (7.9)$$

Para que la matriz triangular inferior $D - L$ sea no singular, es necesario y suficiente que $a_{ii} \neq 0$ para cada $i = 1, 2, \dots, n$.

En el algoritmo 7.2 se implanta el método de Gauss-Seidel.

ALGORITMO 7.2

Método iterativo de Gauss-Seidel

Para resolver $Ax = b$ dada una aproximación inicial $x^{(0)}$:

ENTRADA el número de ecuaciones e incógnitas n ; los elementos a_{ij} , $1 \leq i, j \leq n$ de la matriz A ; los elementos b_i , $1 \leq i \leq n$ de b ; los elementos $x_i^{(0)}$, $1 \leq i \leq n$ de $x^{(0)}$; la tolerancia TOL ; el número máximo de iteraciones N .

SALIDA la solución aproximada $x_1, \dots, x_n$ o el mensaje de que se rebasó el número de iteraciones.

Paso 1 Tome $k = 1$.

Paso 2 Mientras ($k \leq N$) haga los pasos 3-6.

Paso 3 Para $i = 1, \dots, n$

$$\text{tome } x_i = \frac{-\sum_{j=1}^{i-1} a_{ij} x_j - \sum_{j=i+1}^n a_{ij} x_{O_j} + b_i}{a_{ii}}.$$

Paso 4 Si $\|x - x_O\| < \text{TOL}$ entonces **SALIDA** ($x_1, \dots, x_n$)
(Procedimiento terminado exitosamente.)
PARAR.

Paso 5 Tome $k = k + 1$.

Paso 6 Para $i = 1, \dots, n$ tome $x_{O_i} = x_i$.

Paso 7 **SALIDA** ('Número máximo de iteraciones excedido');
(Procedimiento terminado sin éxito.)
PARAR. ■

Los comentarios que acompañan al algoritmo 7.1 respecto a los criterios de reordenación e interrupción, también se aplican al algoritmo 7.2 de Gauss-Seidel.

Los resultados de los ejemplos 1 y 2 parecen implicar que este método es superior al de Jacobi, y generalmente es así. Hay sistemas lineales donde el método de Jacobi converge y el de Gauss-Seidel no, y hay otros donde éste converge y aquél no. (Véanse ejercicios 9 y 10.)

A fin de estudiar la convergencia de los métodos generales de iteración, consideramos la fórmula

$$x^{(k)} = T x^{(k-1)} + c, \quad \text{para cada } k = 1, 2, \dots,$$

donde $x^{(0)}$ es arbitrario.

Lema 7.18 Si el radio espectral $\rho(T)$ satisface $\rho(T) < 1$, entonces existe $(I - T)^{-1}$ y

$$(I - T)^{-1} = I + T + T^2 + \dots = \sum_{j=0}^{\infty} T^j. \quad \blacksquare$$

Demostración Como $Tx = \lambda x$ es verdadera exactamente cuando $(I - T)x = (1 - \lambda)x$ tenemos λ como un valor característico de T exactamente cuando $1 - \lambda$ es un valor característico de $I - T$. Pero $|\lambda| \leq \rho(T) < 1$ y, por tanto, $\lambda = 1$ no es un valor característico de T y 0 tampoco puede serlo de $I - T$. Por tanto, $(I - T)^{-1}$ existe.

Sea $S_m = I + T + T^2 + \dots + T^m$. Entonces

$$(I - T)S_m = (I + T + T^2 + \dots + T^m) - (T + T^2 + \dots + T^{m+1}) = I - T^{m+1},$$

y como T es convergente, el resultado obtenido al final de la sección 7.2 implica que

$$\lim_{m \rightarrow \infty} (I - T)S_m = \lim_{m \rightarrow \infty} (I - T^{m+1}) = I.$$

Por tanto $(I - T)^{-1} = \lim_{m \rightarrow \infty} S_m = I + T + T^2 + \dots = \sum_{j=0}^{\infty} T^j. \quad \blacksquare \blacksquare \blacksquare$

Teorema 7.19 Para cualquier $\mathbf{x}^{(0)} \in \mathbb{R}^n$, la sucesión $\{\mathbf{x}^{(k)}\}_{k=0}^{\infty}$ definida por

$$\mathbf{x}^{(k)} = T\mathbf{x}^{(k-1)} + \mathbf{c}, \quad \text{para cada } k \geq 1, \quad (7.10)$$

converge a la solución única de $\mathbf{x} = T\mathbf{x} + \mathbf{c}$ si y sólo si $\rho(T) < 1$. ■

Demostración Supongamos primero que $\rho(T) < 1$. Entonces,

$$\begin{aligned} \mathbf{x}^{(k)} &= T\mathbf{x}^{(k-1)} + \mathbf{c} \\ &= T(T\mathbf{x}^{(k-2)} + \mathbf{c}) + \mathbf{c} \\ &= T^2\mathbf{x}^{(k-2)} + (T + I)\mathbf{c} \\ &\vdots \\ &= T^k\mathbf{x}^{(0)} + (T^{k-1} + \cdots + T + I)\mathbf{c}. \end{aligned}$$

Puesto que $\rho(T) < 1$, la matriz T es convergente y

$$\lim_{k \rightarrow \infty} T^k \mathbf{x}^{(0)} = \mathbf{0}.$$

El lema 7.18 implica que

$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \lim_{k \rightarrow \infty} T^k \mathbf{x}^{(0)} + \left(\sum_{j=0}^{\infty} T^j \right) \mathbf{c} = \mathbf{0} + (I - T)^{-1} \mathbf{c} = (I - T)^{-1} \mathbf{c}.$$

Por tanto, la sucesión $\{\mathbf{x}^{(k)}\}$ converge al vector $\mathbf{x} = (I - T)^{-1} \mathbf{c}$ y $\mathbf{x} = T\mathbf{x} + \mathbf{c}$.

Para mostrar el recíproco, mostraremos que para cada $\mathbf{z} \in \mathbb{R}^n$, tenemos $\lim_{k \rightarrow \infty} T^k \mathbf{z} = \mathbf{0}$. Por el teorema 7.17, esto es equivalente a $\rho(T) < 1$.

Sea $\mathbf{z}$ un vector arbitrario, y $\mathbf{x}$ la única solución de $\mathbf{x} = T\mathbf{x} + \mathbf{c}$. Definimos $\mathbf{x}^{(0)} = \mathbf{x} - \mathbf{z}$, y para $k \geq 1$, $\mathbf{x}^{(k)} = T\mathbf{x}^{(k-1)} + \mathbf{c}$. Entonces $\{\mathbf{x}^{(k)}\}$ converge a $\mathbf{x}$. Además,

$$\mathbf{x} - \mathbf{x}^{(k)} = (T\mathbf{x} + \mathbf{c}) - (T\mathbf{x}^{(k-1)} + \mathbf{c}) = T(\mathbf{x} - \mathbf{x}^{(k-1)}),$$

de modo que

$$\mathbf{x} - \mathbf{x}^{(k)} = T(\mathbf{x} - \mathbf{x}^{(k-1)}) = T^2(\mathbf{x} - \mathbf{x}^{(k-2)}) = \cdots = T^k(\mathbf{x} - \mathbf{x}^{(0)}) = T^k \mathbf{z}.$$

Por tanto

$$\lim_{k \rightarrow \infty} T^k \mathbf{z} = \lim_{k \rightarrow \infty} T^k(\mathbf{x} - \mathbf{x}^{(0)}) = \lim_{k \rightarrow \infty} (\mathbf{x} - \mathbf{x}^{(k)}) = \mathbf{0}.$$

Como $\mathbf{z} \in \mathbb{R}^n$ era arbitrario, esto implica que T es una matriz convergente y que $\rho(T) < 1$. ■ ■ ■

La comprobación del siguiente corolario se parece a las demostraciones del corolario 2.4, se incluye en el ejercicio 11.

Corolario 7.20 Si $\|T\| < 1$ para toda norma matricial natural y si $\mathbf{c}$ es un vector cualquiera, entonces la sucesión $\{\mathbf{x}^{(k)}\}_{k=0}^{\infty}$ definida por $\mathbf{x}^{(k)} = T\mathbf{x}^{(k-1)} + \mathbf{c}$ converge, para cualquier $\mathbf{x}^{(0)} \in \mathbb{R}^n$, a un vector $\mathbf{x} \in \mathbb{R}^n$, y las siguientes cotas de error son válidas:

- (i) $\|x - x^{(k)}\| \leq \|T\|^k \|x^{(0)} - x\|;$
 (ii) $\|x - x^{(k)}\| \leq \frac{\|T\|^k}{1 - \|T\|} \|x^{(0)} - x^{(1)}\|.$ ■

Hemos visto que los métodos iterativos de Jacobi y de Gauss-Seidel pueden escribirse como

$$x^{(k)} = T_J x^{(k-1)} + c_J \quad \text{y} \quad x^{(k)} = T_G x^{(k-1)} + c_G,$$

por medio de las matrices

$$T_J = D^{-1}(L + U) \quad \text{y} \quad T_G = (D - L)^{-1}U.$$

Si $\rho(T_J)$ o $\rho(T_G)$ son menores que 1, entonces la sucesión correspondiente $\{x^{(k)}\}_{k=0}^\infty$ convergirá en la solución x de $Ax = b$. Por ejemplo, el esquema de Jacobi tiene

$$x^{(k)} = D^{-1}(L + U) x^{(k-1)} + D^{-1}b,$$

y, si $\{x^{(k)}\}_{k=0}^\infty$ converge en x , entonces

$$x = D^{-1}(L + U)x + D^{-1}b.$$

Lo anterior significa que

$$Dx = (L + U)x + b \quad \text{y} \quad (D - L - U)x = b.$$

Puesto que $D - L - U = A$, la solución x satisface $Ax = b$.

Ahora podemos proporcionar condiciones de suficiencia fácilmente verificables para la convergencia de los métodos de Jacobi y de Gauss-Seidel. (Para demostrar la convergencia del esquema de Jacobi, véase el ejercicio 12, y para el de Gauss-Seidel consúltese [Or2, p. 120].)

Teorema 7.21 Si A es estrictamente diagonal dominante, entonces con cualquier elección de $x^{(0)}$, tanto el método de Jacobi como el de Gauss-Seidel dan sucesiones $\{x^{(k)}\}_{k=0}^\infty$ que convergen a la solución única de $Ax = b$. ■

En el corolario 7.20 vemos la relación entre la rapidez de la convergencia y el radio espectral de la matriz de iteración T . Como las desigualdades se mantienen para toda norma matricial natural, del enunciado que viene después del teorema 7.15 se deduce que

$$\|x^{(k)} - x\| \approx \rho(T)^k \|x^{(0)} - x\|. \quad (7.11)$$

Por tanto, conviene seleccionar el método iterativo con mínimo $\rho(T) < 1$ para un sistema particular $Ax = b$. No existen resultados generales que nos digan cuál de los dos métodos, si el de Jacobi o el de Gauss-Seidel, será más eficaz en un sistema lineal arbitrario. Sin embargo, en casos especiales sí conocemos la respuesta, como se demuestra en el siguiente teorema. La demostración de este resultado viene en [Y, pp. 120-127].

Teorema 7.22 (Stein-Rosenberg)

Si $a_{ij} \leq 0$, para cada $i \neq j$ y si $a_{ii} > 0$ para cada $i = 1, 2, \dots, n$, entonces será válida una y sólo una de las siguientes afirmaciones:

- a. $0 \leq \rho(T_R) < \rho(T_J) < 1$;
- b. $1 < \rho(T_J) < \rho(T_R)$;
- c. $\rho(T_J) = \rho(T_R) = 0$;
- d. $\rho(T_J) = \rho(T_R) = 1$.

En el caso especial que se describe en el teorema 7.22, vemos en la parte (a) que cuando un método da convergencia, entonces ambos la dan, y el método de Gauss-Seidel converge más rápidamente que el de Jacobi. La parte (b) indica que, cuando un método diverge, entonces ambos divergen, y la divergencia es más pronunciada en el de Gauss-Seidel.

La rapidez de convergencia de un procedimiento depende del radio espectral de la matriz relacionada con el método; por ello, una forma de seleccionar un procedimiento que acelere la convergencia consiste en seleccionar un método cuya matriz asociada tenga un radio espectral mínimo. Antes de describir un procedimiento para escogerlo, debemos explicar un nuevo medio de medir el grado en que una aproximación de la solución de un sistema lineal difiere de la verdadera solución. El método usa el vector que se describe en la siguiente definición.

Definición 7.23 Supongamos que $\bar{x} \in \mathbb{R}^n$ es una aproximación a la solución del sistema lineal definido por $Ax = b$. El vector residual de $\bar{x}$ respecto a este sistema es $r = b - A\bar{x}$. ■

En procedimientos como el método de Jacobi o de Gauss-Seidel, un vector residual se asocia a cada cálculo de una componente de la aproximación al vector solución. El método tiene por objeto generar una sucesión de aproximaciones que harán que los vectores residuales asociados converjan rápidamente a cero. Supóngase que

$$r_i^{(k)} = (r_{1i}^{(k)}, r_{2i}^{(k)}, \dots, r_{ni}^{(k)})^T$$

denota el vector residual del método de Gauss-Seidel correspondiente al vector solución $x_i^{(k)}$, aproximado definido por

$$x_i^{(k)} = (x_1^{(k)}, x_2^{(k)}, \dots, x_{i-1}^{(k)}, x_i^{(k-1)}, \dots, x_n^{(k-1)})^T.$$

La m -ésima componente de $r_i^{(k)}$ es

$$r_{mi}^{(k)} = b_m - \sum_{j=1}^{i-1} a_{mj} x_j^{(k)} - \sum_{j=i}^n a_{mj} x_j^{(k-1)}, \quad (7.12)$$

o, en forma equivalente,

$$r_{mi}^{(k)} = b_m - \sum_{j=1}^{i-1} a_{mj} x_j^{(k)} - \sum_{j=i+1}^n a_{mj} x_j^{(k-1)} - a_{mi} x_i^{(k-1)},$$

para toda $m = 1, 2, \dots, n$.

En particular, la i -ésima componente de $r_i^{(k)}$ es

$$r_{ii}^{(k)} = b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} - a_{ii} x_i^{(k-1)}.$$

así que

$$a_{ii}x_i^{(k-1)} + r_{ii}^{(k)} = b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)}. \quad (7.13)$$

Pero recuerde que, en el método de Gauss-Seidel, se decide que $x_i^{(k)}$ sea

$$x_i^{(k)} = \frac{1}{a_{ii}} \left[b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \right], \quad (7.14)$$

de modo que la ecuación (7.13) puede reescribirse así

$$a_{ii}x_i^{(k-1)} + r_{ii}^{(k)} = a_{ii}x_i^{(k)}.$$

En consecuencia, el método de Gauss-Seidel puede caracterizarse escogiendo $x_i^{(k)}$ para que satisfaga

$$x_i^{(k)} = x_i^{(k-1)} + \frac{r_{ii}^{(k)}}{a_{ii}}. \quad (7.15)$$

Podemos deducir otra conexión entre los vectores residuales y el método de Gauss-Seidel. Consideremos el vector residual $\mathbf{r}_{i+1}^{(k)}$, asociado al vector $\mathbf{x}_{i+1}^{(k)} = (x_{i+1}^{(k)}, \dots, x_n^{(k)}, x_{i+1}^{(k-1)}, \dots, x_n^{(k-1)})^T$. Conforme a (7.12), la i -ésima componente de $\mathbf{r}_{i+1}^{(k)}$ es

$$\begin{aligned} r_{i,i+1}^{(k)} &= b_i - \sum_{j=1}^i a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \\ &= b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} - a_{ii}x_i^{(k)}. \end{aligned}$$

La ecuación (7.14) implica que $r_{i,i+1}^{(k)} = 0$. Así pues, en cierto modo el método de Gauss-Seidel se caracteriza también por seleccionar $x_{i+1}^{(k)}$ de manera que la i -ésima componente $r_{i,i+1}^{(k)}$ sea cero.

Sin embargo, el seleccionar $x_{i+1}^{(k)}$ de modo que una coordenada del vector residual sea cero no suele ser la forma más eficiente de disminuir el tamaño global del vector $\mathbf{r}_{i+1}^{(k)}$. Al modificar el procedimiento de Gauss-Seidel como se da en la ecuación (7.15)

$$x_i^{(k)} = x_i^{(k-1)} + \omega \frac{r_{ii}^{(k)}}{a_{ii}}, \quad (7.16)$$

para ciertas opciones de ω positivo la norma del vector residual se reduce, y se logra una convergencia significativamente más rápida.

A los métodos que contienen la ecuación (7.16) se les llama **métodos de relajación**. En las selecciones de ω con $0 < \omega < 1$, reciben el nombre de **métodos de subrelajación** y pueden servir para obtener la convergencia de algunos sistemas que no son convergentes con el método de Gauss-Seidel. Para las selecciones de ω con $1 < \omega$, a los procedimientos se les denomina **métodos de sobrerelajación** y sirven para acelerar la convergencia de sistemas que son convergentes con el método de Gauss-Seidel. Estos procedimientos se designan con la abreviatura **SOR** (*Successive Over-Relaxation*, sobrerelajación sucesiva) y son de gran utilidad en la resolución de sistemas lineales que se presentan en la solución numérica de algunas ecuaciones diferenciales parciales.

Antes de mostrar las ventajas del método SOR, es conveniente señalar que mediante la ecuación (7.13) con $m = i$, podemos reformular la ecuación (7.16) con fines de cálculo, como sigue:

$$x_i^{(k)} + (1 - \omega)x_i^{(k-1)} + \frac{\omega}{a_{ii}} \left[b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right].$$

Para determinar la matriz del método SOR, reescribimos lo anterior como

$$a_{ii} x_i^{(k)} + \omega \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} = (1 - \omega) a_{ii} x_i^{(k-1)} - \omega \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} + \omega b_i,$$

así que

$$(D - \omega L)x^{(k)} = [(1 - \omega)D + \omega U]x^{(k-1)} + \omega b$$

o bien

$$x^{(k)} = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]x^{(k-1)} + \omega(D - \omega L)^{-1}b. \quad (7.17)$$

Si utilizamos $T_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$ y $c_\omega = \omega(D - \omega L)^{-1}b$, podemos expresar el método SOR en la forma

$$x^{(k)} = T_\omega x^{(k-1)} + c_\omega. \quad (7.18)$$

EJEMPLO 3 El sistema lineal $Ax = b$ dado por

$$\begin{aligned} 4x_1 + 3x_2 &= 24, \\ 3x_1 + 4x_2 - x_3 &= 30, \\ -x_2 + 4x_3 &= -24, \end{aligned}$$

tiene la solución $(3, 4, -5)^T$. Los métodos de Gauss-Seidel y SOR con $\omega = 1.25$ se emplearán para resolver este sistema, usando $x^{(0)} = (1, 1, 1)^T$ en ambos métodos. Las ecuaciones para el método de Gauss-Seidel son

$$\begin{aligned} x_1^{(k)} &= -0.75x_2^{(k-1)} + 6, \\ x_2^{(k)} &= -0.75x_1^{(k)} + 0.25x_3^{(k-1)} + 7.5, \\ x_3^{(k)} &= 0.25x_2^{(k)} - 6, \end{aligned}$$

y las ecuaciones para el método SOR con $\omega = 1.25$ son

$$\begin{aligned} x_1^{(k)} &= -0.25x_1^{(k-1)} - 0.9375x_2^{(k-1)} + 7.5, \\ x_2^{(k)} &= -0.9375x_1^{(k)} - 0.25x_2^{(k-1)} + 0.3125x_3^{(k-1)} + 9.375, \\ x_3^{(k)} &= 0.3125x_2^{(k)} - 0.25x_3^{(k-1)} - 7.5. \end{aligned}$$

En las tablas 7.3 y 7.4 se incluyen las primeras siete iteraciones para cada método. Para que las iteraciones tengan una exactitud de siete cifras decimales, el método de Gauss-Seidel requiere 34 iteraciones, en contraste con las 14 iteraciones que exige el método de sobrerelajación con $\omega = 1.25$. ■

Tabla 7.3 Gauss-Seidel

k	0	1	2	3	4	5	6	7
$x_1^{(k)}$	1	5.250000	3.1406250	3.0878906	3.0549316	3.0343323	3.0214577	3.0134110
$x_2^{(k)}$	1	3.812500	3.8828125	3.9267578	3.9542236	3.9713898	3.9821186	3.9888241
$x_3^{(k)}$	1	-5.046875	-5.0292969	-5.0183105	-5.0114441	-5.0071526	-5.0044703	-5.0027940

Tabla 7.4 SOR con $\omega = 1.25$

k	0	1	2	3	4	5	6	7
$x_1^{(k)}$	1	6.312500	2.6223145	3.1333027	2.9570512	3.0037211	2.9963276	3.0000498
$x_2^{(k)}$	1	3.5195313	3.9585266	4.0102646	4.0074838	4.0029250	4.0009262	4.0002586
$x_3^{(k)}$	1	-6.6501465	-4.6004238	-5.0966863	-4.9734897	-5.0057135	-4.9982822	-5.0003486

La pregunta obvia que hemos de preguntar es cómo se selecciona el valor apropiado de ω . Aunque no se conoce una respuesta completa a esta pregunta para el sistema lineal general $n \times n$, los resultados siguientes serán útiles en algunos casos.

Teorema 7.24 (Kahan)

Si $a_{ii} \neq 0$ para cada $i = 1, 2, \dots, n$, entonces $\rho(T_\omega) \geq |\omega - 1|$. Ello significa que el método SOR puede converger sólo si $0 < \omega < 2$. ■

La demostración de este teorema viene en el ejercicio 13. La demostración de los dos siguientes resultados se encuentra en [Or2, pp. 123-133]. Estos resultados se utilizarán en el capítulo 12.

Teorema 7.25 (Ostrowski-Reich)

Si A es una matriz definida positiva y si $0 < \omega < 2$, entonces el método SOR converge para cualquier elección del vector inicial aproximado $\mathbf{x}^{(0)}$. ■

Teorema 7.26 Si A es una matriz definida positiva y tridiagonal, entonces $\rho(T_\omega) = [\rho(T_J)]^2 < 1$, y la elección óptima de ω para el método SOR es

$$\omega = \frac{2}{1 + \sqrt{1 - [\rho(T_J)]^2}}.$$

Con esta elección de ω , tenemos $\rho(T_\omega) = \omega - 1$. ■

EJEMPLO 4 En el ejemplo 3, la matriz dada

$$A = \begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix},$$

es definida positiva y tridiagonal, de modo que se aplica el teorema 7.26. Dado que:

$$T_f = D^{-1}(L + U) = \begin{bmatrix} \frac{1}{4} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{4} \end{bmatrix} \begin{bmatrix} 0 & -3 & 0 \\ -3 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & -0.75 & 0 \\ -0.75 & 0 & 0.25 \\ 0 & 0.25 & 0 \end{bmatrix},$$

tenemos

$$T_f - \lambda I = \begin{bmatrix} -\lambda & -0.75 & 0 \\ -0.75 & -\lambda & 0.25 \\ 0 & 0.25 & -\lambda \end{bmatrix},$$

así que

$$\det(T_f - \lambda I) = -\lambda(\lambda^2 - 0.625).$$

Por tanto,

$$\rho(T_f) = \sqrt{0.625}$$

y

$$\omega = \frac{2}{1 + \sqrt{1 - [\rho(T_f)]^2}} = \frac{2}{1 + \sqrt{1 - 0.625}} \approx 1.24.$$

Esto explica la rápida convergencia que se obtuvo en el ejemplo 1 mediante $\omega = 1.25$. ■

Concluimos esta sección con el algoritmo 7.3, con el cual se ejecuta el método SOR.

ALGORITMO

7.3

Método SOR

Para resolver $Ax = b$ dado el parámetro ω y la aproximación inicial $x^{(0)}$:

ENTRADA el número de ecuaciones e incógnitas n ; los elementos a_{ij} , $1 \leq i, j \leq n$, de la matriz A , los elementos b_i , $1 \leq i \leq n$, de b ; los elementos xO_i , $1 \leq i \leq n$, de $XO = x^{(0)}$; el parámetro ω , la tolerancia TOL ; el número máximo de iteraciones N .

SALIDA la solución aproximada $x_1, \dots, x_n$ o el mensaje de que se rebasó el número de iteraciones.

Paso 1 Tome $k = 1$.

Paso 2 Mientras ($k \leq N$) haga los pasos 3-6.

Paso 3 Para $i = 1, \dots, n$

$$\text{tome } x_i = (1 - \omega)xO_i + \frac{\omega(-\sum_{j=1}^{i-1} a_{ij}x_j - \sum_{j=i+1}^n a_{ij}xO_j + b_i)}{a_{ii}}.$$

Paso 4 Si $\|x - XO\| < TOL$ entonces **SALIDA** ($x_1, \dots, x_n$);
(Procedimiento terminado exitosamente).
PARAR.

Paso 5 Tome $k = k + 1$.

Paso 6 Para $i = 1, \dots, n$ tome $XO_i = x_i$.

Paso 7 SALIDA ('Número máximo de iteraciones excedido');
(Procedimiento terminado sin éxito.)
PARAR.

CONJUNTO DE EJERCICIOS 7.3

1. Obtenga las dos primeras iteraciones del método de Jacobi para los siguientes sistemas lineales, usando $\mathbf{x}^{(0)} = \mathbf{0}$:

$$\begin{aligned} \text{a. } 3x_1 - x_2 + x_3 &= 1, \\ 3x_1 + 6x_2 + 2x_3 &= 0, \\ 3x_1 + 3x_2 + 7x_3 &= 4. \end{aligned}$$

$$\begin{aligned} \text{b. } 10x_1 - x_2 &= 9, \\ -x_1 + 10x_2 - 2x_3 &= 7, \\ -2x_2 + 10x_3 &= 6. \end{aligned}$$

$$\begin{aligned} \text{c. } 10x_1 + 5x_2 &= 6, \\ 5x_1 + 10x_2 - 4x_3 &= 25, \\ -4x_2 + 8x_3 - x_4 &= -11, \\ -x_3 + 5x_4 &= -11. \end{aligned}$$

$$\begin{aligned} \text{d. } 4x_1 + x_2 - x_3 + x_4 &= -2, \\ x_1 + 4x_2 - x_3 - x_4 &= -1, \\ -x_1 - x_2 + 5x_3 + x_4 &= 0, \\ x_1 - x_2 + x_3 + 3x_4 &= 1. \end{aligned}$$

$$\begin{aligned} \text{e. } 4x_1 + x_2 + x_3 + x_4 &= 6, \\ -x_1 - 3x_2 + x_3 + x_4 &= 6, \\ 2x_1 + x_2 + 5x_3 - x_4 - x_5 &= 6, \\ -x_1 - x_2 - x_3 + 4x_4 &= 6, \\ 2x_2 - x_3 + x_4 + 4x_5 &= 6. \end{aligned}$$

$$\begin{aligned} \text{f. } 4x_1 - x_2 - x_4 &= 0, \\ -x_1 + 4x_2 - x_3 - x_5 &= 5, \\ -x_2 + 4x_3 - x_6 &= 0, \\ -x_1 + 4x_4 - x_5 &= 6, \\ -x_2 - x_4 + 4x_5 - x_6 &= -2, \\ -x_3 - x_5 + 4x_6 &= 6. \end{aligned}$$

2. Repita el ejercicio 1 empleando el método de Gauss-Seidel.
3. Aplique el método de Jacobi para resolver los sistemas lineales del ejercicio 1, con $TOL = 10^{-3}$ en la norma l_∞ .
4. Repita el ejercicio 3 utilizando el algoritmo de Gauss-Seidel.
5. Obtenga las dos primeras iteraciones del método SOR con $\omega = 1.1$ para los siguientes sistemas lineales usando $\mathbf{x}^{(0)} = \mathbf{0}$:

$$\begin{aligned} \text{a. } 3x_1 - x_2 + x_3 &= 1, \\ 3x_1 + 6x_2 + 2x_3 &= 0, \\ 3x_1 + 3x_2 + 7x_3 &= 4. \end{aligned}$$

$$\begin{aligned} \text{b. } 10x_1 - x_2 &= 9, \\ -x_1 + 10x_2 - 2x_3 &= 7, \\ -2x_2 + 10x_3 &= 6. \end{aligned}$$

$$\begin{array}{ll}
 \text{c. } 10x_1 + 5x_2 & = 6, \\
 5x_1 + 10x_2 - 4x_3 & = 25, \\
 -4x_2 + 8x_3 - x_4 & = -11, \\
 -x_3 + 5x_4 & = -11. \\
 \text{d. } 4x_1 + x_2 - x_3 + x_4 & = -2, \\
 x_1 + 4x_2 - x_3 - x_4 & = -1, \\
 -x_1 - x_2 + 5x_3 + x_4 & = 0, \\
 x_1 - x_2 + x_3 + 3x_4 & = 1. \\
 \text{e. } 4x_1 + x_2 + x_3 + x_4 & = 6, \\
 -x_1 - 3x_2 + x_3 + x_4 & = 6, \\
 2x_1 + x_2 + 5x_3 - x_4 - x_5 & = 6, \\
 -x_1 - x_2 - x_3 + 4x_4 & = 6, \\
 2x_2 - x_3 + x_4 + 4x_5 & = 6. \\
 \text{f. } 4x_1 - x_2 - x_4 & = 0, \\
 -x_1 + 4x_2 - x_3 - x_5 & = 5, \\
 -x_2 + 4x_3 - x_6 & = 0, \\
 -x_1 + 4x_4 - x_5 & = 6, \\
 -x_2 - x_4 + 4x_5 - x_6 & = -2, \\
 -x_3 - x_5 + 4x_6 & = 6.
 \end{array}$$

6. Repita el ejercicio 1 usando $\omega = 1.3$.
7. Aplique el método SOR con $\omega = 1.2$ para resolver los sistemas lineales del ejercicio 5 con una tolerancia $TOL = 10^{-3}$ en la norma l_∞ .
8. Determine cuáles matrices del ejercicio 5 son tridiagonales y definidas positivas. Repita el ejercicio 7 con estas matrices utilizando la selección óptima de ω .
9. El sistema lineal

$$\begin{array}{l}
 2x_1 - x_2 + x_3 = -1, \\
 2x_1 + 2x_2 + 2x_3 = 4, \\
 -x_1 - x_2 + 2x_3 = -5
 \end{array}$$

tiene la solución $(1, 2, -1)^T$.

- a. Muestre que $\rho(T_J) = \frac{\sqrt{5}}{2} > 1$.
- b. Muestre que el método de Jacobi con $\mathbf{x}^{(0)} = \mathbf{0}$ no da una buena aproximación después de 25 iteraciones.
- c. Muestre que $\rho(T_G) = \frac{1}{2}$.
- d. Use el método de Gauss-Seidel con $\mathbf{x}^{(0)} = \mathbf{0}$ para la solución al sistema lineal hasta 10^{-5} en la norma l_∞ .

10. El sistema lineal

$$\begin{array}{l}
 x_1 + 2x_2 - 2x_3 = 7, \\
 x_1 + x_2 + x_3 = 2, \\
 2x_1 + 2x_2 + x_3 = 5
 \end{array}$$

tiene la solución $(1, 2, -1)^T$.

- a. Muestre que $\rho(T_J) = 0$.
- b. Use el método de Jacobi con $\mathbf{x}^{(0)} = \mathbf{0}$ para aproximar la solución al sistema lineal hasta 10^{-5} en la norma l_∞ .
- c. Muestre que $\rho(T_G) = 2$.
- d. Muestre que el método de Gauss-Seidel aplicado como en la parte (b) no da una buena aproximación después de 25 iteraciones.

11. a. Demuestre que

$$\|x^{(k)} - x\| \leq \|T\|^k \|x^{(0)} - x\| \quad \text{y} \quad \|x^{(k)} - x\| \leq \frac{\|T\|^k}{1 - \|T\|} \|x^{(1)} - x^{(0)}\|,$$

donde T es una matriz de $n \times n$ con $\|T\| < 1$ y

$$x^{(k)} = Tx^{(k-1)} + c, \quad k = 1, 2, \dots,$$

Con $x^{(0)}$ arbitrario, $c \in \mathbb{R}^n$ y $x = Tx + c$.

- b. Aplique, cuando sea posible, las cotas al ejercicio 1 usando la norma l_∞ .
12. Demuestre que si A es estrictamente diagonal dominante, entonces $\|T\|_\infty < 1$.
13. Demuestre el teorema 7.24. [Sugerencia: si $\lambda_1, \dots, \lambda_n$ son valores característicos de T_ω entonces $\det T_\omega = \prod_{i=1}^n \lambda_i$. Dado que $\det D^{-1} = \det(D - \omega L)^{-1}$ y el determinante de un producto de matrices es el producto de los determinantes de los factores, el resultado se deduce de la ecuación (7.17).]
14. Suponga que un objeto puede estar en cualquiera de los $n + 1$ puntos uniformemente espaciados $x_0, x_1, \dots, x_n$ en la línea. Cuando un objeto se encuentra ubicado en el lugar x_i tendrá las mismas probabilidades de desplazarse hacia x_{i-1} o hacia x_{i+1} y no puede dirigirse directamente hacia ningún otro lugar. Considere las probabilidades $(P_i)_{i=0}^n$ de que un objeto que parte del lugar x_i llegue al extremo izquierdo x_0 antes de alcanzar el extremo derecho x_n . Por supuesto, $P_0 = 1$ y $P_n = 0$. Dado que el objeto puede desplazarse hacia x_i sólo a partir de x_{i-1} o de x_{i+1} y lo hace con la probabilidad $\frac{1}{2}$ para cada uno de esos lugares,

$$P_i = \frac{1}{2} P_{i-1} + \frac{1}{2} P_{i+1}, \quad \text{para cada } i = 1, 2, \dots, n-1.$$

- a. Demuestre que

$$\begin{bmatrix} 1 - \frac{1}{2} & 0 & \dots & 0 \\ -\frac{1}{2} & 1 - \frac{1}{2} & \dots & 0 \\ 0 & -\frac{1}{2} & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & -\frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} P_1 \\ P_2 \\ \vdots \\ P_{n-1} \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

- b. Resuelva este sistema usando $n = 10, 50$ y 100 .
- c. Cambie las probabilidades a α y $1 - \alpha$ para el movimiento hacia la izquierda y derecha, respectivamente, y después derive el sistema lineal semejante al de la parte (a).
- d. Repita la parte (b) con $\alpha = \frac{1}{3}$.
15. Utilice todos los métodos aplicables de esta sección para obtener las soluciones del sistema lineal de $Ax = b$ con una exactitud de 10^{-3} en la norma l_∞ .

$$a_{ij} = \begin{cases} 2i, & \text{cuando } j = i \text{ e } i = 1, 2, \dots, 80, \\ 0.5i, & \text{cuando } \begin{cases} j = i + 2 \text{ e } i = 1, 2, \dots, 78, \\ j = i - 2 \text{ e } i = 3, 4, \dots, 80, \end{cases} \\ 0.25i, & \text{cuando } \begin{cases} j = i + 4 \text{ e } i = 1, 2, \dots, 76, \\ j = i - 4 \text{ e } i = 5, 6, \dots, 80, \end{cases} \\ 0, & \text{de lo contrario,} \end{cases}$$

y aquellos de b son $b_i = \pi$, para cada $i = 1, 2, \dots, 80$.

16. Suponga que A es una matriz definida positiva,
- Demuestre que podemos escribir $A = D - L - L'$, donde D es diagonal con $d_{ii} > 0$ para cada $1 \leq i \leq n$ y donde L es triangular. Más aún, demuestre que $D - L$ es no singular.
 - Sean $T_g = (D - L)^{-1}L'$ y $P = A - T_g^t A T_g$. Demuestre que P es simétrica.
 - Demuestre que T_g también puede escribirse como $T_g = I - (D - L)^{-1}A$.
 - Sea $Q = (D - L)^{-1}A$. Demuestre que $T_g = I - Q$ y que $P = Q^t[AQ^{-1} - A + (Q^t)^{-1}A]Q$.
 - Demuestre que $P = Q^t D Q$ y que P es una matriz definida positiva.
 - Sea λ un valor característico de T_g con el vector característico $x \neq 0$. Use la parte (b) para demostrar que $x^t P x > 0$ implica que $|\lambda| < 1$.
 - Demuestre que T_g es convergente y que el método de Gauss-Seidel converge.
17. Extienda el método de demostración en el ejercicio 14 al método SOR con $0 < \omega < 2$.
18. Las fuerzas que actúan sobre la estructura de un puente, descritas al inicio de este capítulo, satisfacen las ecuaciones de la siguiente tabla:

Junta	Componentes horizontales	Componentes verticales
①	$-F_1 + \frac{\sqrt{2}}{2}f_1 + f_2 = 0$	$\frac{\sqrt{2}}{2}f_1 + F_2 = 0$
②	$-\frac{\sqrt{2}}{2}f_1 + \frac{\sqrt{3}}{2}f_4 = 0$	$-\frac{\sqrt{2}}{2}f_1 - f_3 + \frac{1}{2}f_4 = 0$
③	$-f_2 + f_3 = 0$	$f_3 - 10\,000 = 0$
④	$-\frac{\sqrt{3}}{2}f_4 - f_3 = 0$	$\frac{1}{2}f_4 - F_3 = 0$

Este sistema lineal puede expresarse en forma matricial.

$$\begin{bmatrix} -1 & 0 & 0 & \frac{\sqrt{2}}{2} & 1 & 0 & 0 & 0 \\ 0 & -1 & 0 & \frac{\sqrt{2}}{2} & 0 & 0 & 0 & 0 \\ 0 & 0 & -1 & 0 & 0 & 0 & \frac{1}{2} & 0 \\ 0 & 0 & 0 & -\frac{\sqrt{2}}{2} & 0 & -1 & \frac{1}{2} & 0 \\ 0 & 0 & 0 & 0 & -1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & -\frac{\sqrt{2}}{2} & 0 & 0 & \frac{\sqrt{3}}{2} & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & -\frac{\sqrt{3}}{2} & -1 \end{bmatrix} \begin{bmatrix} F_1 \\ F_2 \\ F_3 \\ f_1 \\ f_2 \\ f_3 \\ f_4 \\ f_5 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 10\,000 \\ 0 \\ 0 \end{bmatrix}$$

- Explique por qué se reordenó el sistema de ecuaciones.
- Aproxime la solución del sistema lineal resultante con una exactitud de 10^{-2} en la norma l_∞ , utilizando como aproximación inicial el vector cuyos elementos son todos unos con (i) el método de Gauss-Seidel, (ii) el método de Jacobi y (iii) el método SOR con $\omega = 1.25$.

7.4 Estimaciones de error y refinamiento iterativo

Desde el punto de vista intuitivo parece razonable que, si $\bar{x}$ es una aproximación a la solución x de $Ax = b$ y si el vector residual $r = b - A\bar{x}$ tiene la propiedad de que $\|r\| = \|b - A\bar{x}\|$ es pequeño, entonces $\|x - \bar{x}\|$ también será pequeño. A menudo este es el caso, pero algunos sistemas, que en la práctica se presentan con frecuencia, no poseen esta propiedad.

EJEMPLO 1 El sistema lineal $Ax = b$ dado por

$$\begin{bmatrix} 1 & 2 \\ 1.0001 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 3 \\ 3.0001 \end{bmatrix}$$

tiene la solución única $x = (1, 1)^T$. La aproximación deficiente $\bar{x} = (3, 0)^T$ tiene el vector residual

$$r = b - A\bar{x} = \begin{bmatrix} 3 \\ 3.0001 \end{bmatrix} - \begin{bmatrix} 1 & 2 \\ 1.0001 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ -0.0002 \end{bmatrix},$$


de modo que $\|r\|_\infty = 0.0002$. Aunque la norma del vector residual es pequeña, la aproximación $\bar{x} = (3, 0)^T$ es evidentemente muy deficiente; de hecho, $\|x - \bar{x}\|_\infty = 2$. ■

La dificultad del ejemplo 1 se explica muy fácilmente haciendo notar que la solución del sistema representa la intersección de las líneas

$$I_1: x_1 + 2x_2 = 3 \quad \text{y} \quad I_2: 1.0001x_1 + 2x_2 = 3.0001.$$

El punto $(3, 0)$ se encuentra en I_1 , y las líneas son casi paralelas. Esto significa que $(3, 0)$ también está cerca de I_2 , a pesar de que difiere significativamente del punto de intersección $(1, 1)$. (Véase la Fig. 7.7.)

Figura 7.7



Evidentemente el ejemplo 1 se elaboró para demostrar las dificultades que pueden surgir y que de hecho surgen. De no haber sido las líneas casi coincidentes, cabría esperar que un vector residual pequeño implicase una aproximación exacta.

En el contexto general, no podemos recurrir a la geometría del sistema para obtener un indicio de cuándo pueden presentarse problemas. Sin embargo, sí podemos conseguir esta información si consideramos las normas de la matriz A y su inversa.

Teorema 7.27 Supongamos que $\bar{x}$ es una aproximación a la solución de $Ax = b$, que A es una matriz no singular y que r es el vector residual de $\bar{x}$. Entonces, para toda norma natural,

$$\|x - \bar{x}\| \leq \|r\| \cdot \|A^{-1}\|$$

y si $\mathbf{x} \neq \mathbf{0}$ y $\mathbf{b} \neq \mathbf{0}$.

$$\frac{\|\mathbf{x} - \bar{\mathbf{x}}\|}{\|\mathbf{x}\|} \leq \|A\| \cdot \|A^{-1}\| \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|}, \quad (7.19)$$

Demostración Dado que $\mathbf{r} = \mathbf{b} - A\bar{\mathbf{x}} = A\mathbf{x} - A\bar{\mathbf{x}}$ y A es no singular, $\mathbf{x} - \bar{\mathbf{x}} = A^{-1}\mathbf{r}$, el Teorema 7.11 de la sección 7.1 implica que

$$\|\mathbf{x} - \bar{\mathbf{x}}\| = \|A^{-1}\mathbf{r}\| \leq \|A^{-1}\| \cdot \|\mathbf{r}\|.$$

Más aún, como $\mathbf{b} = A\mathbf{x}$, tenemos $\|\mathbf{b}\| \leq \|A\| \cdot \|\mathbf{x}\|$ y, por tanto, $1/\|\mathbf{x}\| \leq \|A\|/\|\mathbf{b}\|$ y

$$\frac{\|\mathbf{x} - \bar{\mathbf{x}}\|}{\|\mathbf{x}\|} \leq \frac{\|A\| \cdot \|A^{-1}\|}{\|A\|} \|\mathbf{r}\|. \quad \blacksquare$$

Las desigualdades del teorema 7.27 implican que las cantidades $\|A^{-1}\|$ y $\|A\| \cdot \|A^{-1}\|$ ofrecen un indicio de la conexión entre el vector residual y la exactitud de la aproximación. En general, el error relativo $\|\mathbf{x} - \bar{\mathbf{x}}\|/\|\mathbf{x}\|$ es de gran interés y, de acuerdo con la desigualdad (7.19), está acotado por el producto de $\|A\| \cdot \|A^{-1}\|$ con el residual relativo de esta aproximación $\|\mathbf{r}\|/\|\mathbf{b}\|$. En esta aproximación puede usarse cualquier norma adecuada; el único requisito es que se utilice de manera uniforme en todo el proceso.

Definición 7.28 El número de condición de una matriz no singular A relativo a la norma $\|\cdot\|$ es

$$K(A) = \|A\| \cdot \|A^{-1}\|. \quad \blacksquare$$

Con esta notación, las desigualdades del teorema 7.27 se convierten en

$$\|\mathbf{x} - \bar{\mathbf{x}}\| \leq K(A) \frac{\|\mathbf{r}\|}{\|A\|}$$

y en

$$\frac{\|\mathbf{x} - \bar{\mathbf{x}}\|}{\|\mathbf{x}\|} \leq K(A) \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|}.$$

Para toda matriz no singular A y norma natural $\|\cdot\|$,

$$1 = \|I\| = \|A \cdot A^{-1}\| \leq \|A\| \cdot \|A^{-1}\| = K(A).$$

Una matriz A es **bien condicionada** si $K(A)$ está cerca a 1 y es **mal condicionada** si $K(A)$ es significativamente mayor que 1. Dentro de este contexto, el término condición se refiere a la seguridad relativa de que un vector residual pequeño implica una solución aproximada exacta correspondiente.

EJEMPLO 2 La matriz del sistema considerado en el ejemplo 1 fue

$$A = \begin{bmatrix} 1 & 2 \\ 1.0001 & 2 \end{bmatrix}.$$

que tiene $\|A\|_\infty = 3.0001$. Esta norma no se considerará grande. Sin embargo,

$$A^{-1} = \begin{bmatrix} -10000 & 10000 \\ 5000.5 & -5000 \end{bmatrix}, \text{ así } \|A^{-1}\|_\infty = 20000,$$

y, para la norma infinito, $K(A) = (20000)(3.0001) = 60002$. En este ejemplo, el tamaño del número de condición nos impedirá tomar decisiones apresuradas sobre la precisión, basadas en el residuo de la aproximación. ■

En Maple el número de condición K_∞ puede calcularse así:

```
>with(linalg) ;
>A:=matrix(2,2,[1,2,1.0001,2]);
>cond(A);
```

60002.00000

Aunque el número de condición de una matriz depende por completo de las normas de la matriz y de su inversa, en la práctica el cálculo de la inversa está sujeto al error de redondeo y depende de la exactitud con que se efectúen los cálculos. Si las operaciones incluyen la aritmética con t dígitos significativos de precisión, el número aproximado de condición de la matriz A es la norma de la matriz multiplicada por la norma de la aproximación a la inversa de A , la cual se obtiene empleando la aritmética con t dígitos. De hecho, este número de condición también depende del método con que se calcule la inversa de A .

Si suponemos que la solución aproximada del sistema lineal $Ax = b$ se determina empleando la aritmética con t dígitos y la eliminación gaussiana, podemos demostrar (véase [FM, pp. 45-47]) que el vector residual r para la aproximación $\bar{x}$ tiene

$$\|r\| \approx 10^{-t} \|A\| \cdot \|\bar{x}\|. \quad (7.20)$$

A partir de la aproximación anterior puede obtenerse una estimación del número efectivo de condición en la aritmética de t dígitos, sin invertir la matriz A . En la práctica, la aproximación supone que todas las operaciones realizadas en la eliminación gaussiana se efectúan con la aritmética de t dígitos, pero que las que se requieren para determinar el residuo se realizan con la aritmética de doble precisión (es decir, de $2t$ dígitos). Con esta técnica no se incrementa mucho el número de operaciones de cálculo; además se elimina considerablemente la pérdida de exactitud que implica la resta de números casi iguales que ocurre en el cálculo del residuo.

La aproximación del número de condición con t dígitos $K(A)$ proviene de la consideración del sistema lineal

$$Ay = r.$$

La solución de este sistema se puede aproximar fácilmente, pues ya se calcularon los multiplicadores de la eliminación gaussiana. De hecho $\bar{y}$, la solución aproximada de $Ay = r$, satisface

$$\bar{y} \approx A^{-1}r = A^{-1}(b - A\bar{x}) = A^{-1}b - A^{-1}A\bar{x} = x - \bar{x}; \quad (7.21)$$

y

$$x \approx \bar{x} + \bar{y}.$$

Por tanto, $\bar{y}$ es una estimación del error producido cuando $\bar{x}$ aproxima la solución x al sistema original. Las ecuaciones (7.20) y (7.21) implican que

$$\|\bar{y}\| \approx \|x - \bar{x}\| = \|A^{-1}r\| \leq \|A^{-1}\| \cdot \|r\| \approx \|A^{-1}\| (10^{-t}\|A\| \cdot \|\bar{x}\|) = 10^{-t} \|\bar{x}\| K(A).$$

Esto nos da una aproximación del número de condición que interviene en la solución del sistema $Ax = b$ usando la eliminación gaussiana y el tipo de aritmética de dígito t que acabamos de describir

$$K(A) \approx \frac{\|\bar{y}\|}{\|\bar{x}\|} 10^t. \quad (7.22)$$

EJEMPLO 3 El sistema lineal dado por

$$\begin{bmatrix} 3.3330 & 15920 & -10.333 \\ 2.2220 & 16.710 & 9.6120 \\ 1.5611 & 5.1791 & 1.6852 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 15913 \\ 28.544 \\ 8.4254 \end{bmatrix}$$

tiene la solución exacta $x = (1, 1, 1)^t$.

Con la eliminación gaussiana y con la aritmética de redondeo a cinco dígitos podemos obtener las matrices aumentadas

$$\begin{bmatrix} 3.3330 & 15920 & -10.333 & : & 15913 \\ 0 & -10596 & 16.501 & : & 10580 \\ 0 & -7451.4 & 6.5250 & : & -7444.9 \end{bmatrix} \quad \text{y} \quad \begin{bmatrix} 3.3330 & 15920 & -10.333 & : & 15913 \\ 0 & -10596 & 16.501 & : & -10580 \\ 0 & 0 & -5.0790 & : & -4.7000 \end{bmatrix}.$$

La solución aproximada de este sistema es

$$\bar{x} = (1.2001, 0.99991, 0.92538)^t.$$

El vector residual correspondiente a $\bar{x}$ se calcula con doble precisión y resulta ser

$$r = b - A\bar{x}$$

$$= \begin{bmatrix} 15913 \\ 28.544 \\ 8.4254 \end{bmatrix} - \begin{bmatrix} 3.3330 & 15920 & -10.333 \\ 2.2220 & 16.710 & 9.6120 \\ 1.5611 & 5.1791 & 1.6852 \end{bmatrix} \begin{bmatrix} 1.20001 \\ 0.99991 \\ 0.92538 \end{bmatrix}$$

$$= \begin{bmatrix} 15913 \\ 28.544 \\ 8.4254 \end{bmatrix} - \begin{bmatrix} 15913.00518 \\ 28.26987086 \\ 8.611560367 \end{bmatrix} = \begin{bmatrix} -0.00518 \\ 0.27412914 \\ -0.186160367 \end{bmatrix},$$

por tanto,

$$\|r\|_{\infty} = 0.27413.$$

La estimación del número de condición dado en la explicación anterior se obtiene resolviendo primero el sistema $Ay = r$ para $\bar{y}$:

$$\begin{bmatrix} 3.3330 & 15920 & -10.333 \\ 2.2220 & 16.710 & 9.6120 \\ 1.5611 & 5.1791 & 1.6852 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} -0.00518 \\ 0.27413 \\ -0.18616 \end{bmatrix}.$$

Lo anterior significa que $\bar{y} = (-0.20008, 8.9987 \times 10^{-5}, 0.074607)^T$. Al utilizar la estimación en la ecuación (7.22), obtenemos

$$K(A) = 10^5 \frac{\|\bar{y}\|_\infty}{\|\bar{x}\|_\infty} = \frac{10^5(0.20008)}{1.2001} = 16672. \quad (7.23)$$

Si queremos determinar el número de condición *exacto* de A , primero debemos construir A^{-1} . La aritmética de redondeo a cinco dígitos aplicada a los cálculos produce la aproximación:

$$A^{-1} = \begin{bmatrix} -1.1701 \times 10^{-4} & -1.4983 \times 10^{-1} & 8.5416 \times 10^{-1} \\ 6.2782 \times 10^{-5} & 1.2124 \times 10^{-4} & -3.0662 \times 10^{-4} \\ -8.6631 \times 10^{-5} & 1.3846 \times 10^{-1} & -1.9689 \times 10^{-1} \end{bmatrix}.$$

El teorema 7.11 implica que $\|A^{-1}\|_\infty = 1.0041$ y $\|A\|_\infty = 15934$.

En consecuencia, la matriz A mal condicionada tiene

$$K(A) = (1.0041)(15934) = 15999.$$

La estimación en (7.23) está muy cerca de $K(A)$ y requiere un esfuerzo de cálculo mucho menor.

Puesto que se conoce la solución real $\mathbf{x} = (1, 1, 1)^T$ para este sistema, podemos calcular ambas cosas.

$$\|\mathbf{x} - \bar{\mathbf{x}}\|_\infty = 0.2001 \quad \text{y} \quad \frac{\|\mathbf{x} - \bar{\mathbf{x}}\|_\infty}{\|\mathbf{x}\|_\infty} = \frac{0.2001}{1} = 0.2001.$$

Las cotas de error del teorema 7.27 para estos valores son

$$\|\mathbf{x} - \bar{\mathbf{x}}\|_\infty \leq K(A) \frac{\|\mathbf{r}\|_\infty}{\|A\|_\infty} = \frac{(15999)(0.27413)}{15934} = 0.27525$$

y

$$\frac{\|\mathbf{x} - \bar{\mathbf{x}}\|_\infty}{\|\mathbf{x}\|_\infty} \leq K(A) \frac{\|\mathbf{r}\|_\infty}{\|\mathbf{b}\|_\infty} = \frac{(15999)(0.27413)}{15913} = 0.27561. \quad \blacksquare$$

En la ecuación (7.21) utilizamos la estimación $\bar{y} = \mathbf{x} - \bar{\mathbf{x}}$, donde $\bar{y}$ es la solución aproximada del sistema $A\mathbf{y} = \mathbf{r}$. En general, $\bar{\mathbf{x}} + \bar{\mathbf{y}}$ es una aproximación más exacta a la solución del sistema lineal $A\mathbf{x} = \mathbf{b}$ que la aproximación original $\bar{\mathbf{x}}$. El método en que se aplica esta suposición recibe el nombre de **refinamiento iterativo**, o mejora iterativa, y consiste en efectuar las iteraciones en el sistema cuyo lado derecho es el vector residual de las aproximaciones sucesivas hasta conseguir resultados con una exactitud satisfactoria.

El proceso se aplica mediante la aritmética de t dígitos y, si $K_\infty(A) \approx 10^q$, entonces después de k iteraciones de refinamiento iterativo, la solución tiene aproximadamente el más pequeño de los t y $k(t - q)$ dígitos correctos. Si el sistema está bien condicionado, una o dos iteraciones indicarán que la solución es exacta. Los sistemas mal condicionados también pueden mejorarse mucho, salvo en el caso de que la matriz A esté tan mal condicionada con $K_\infty(A) > 10^t$. En tal caso deberá emplearse el aumento de precisión en los cálculos.

En el algoritmo 7.4 se pone en ejecución el método de refinamiento iterativo.

ALGORITMO
7.4
Refinamiento iterativo

Para aproximar la solución del sistema lineal $Ax = b$:

ENTRADA el número de ecuaciones e incógnitas n ; los elementos a_{ij} , $1 \leq i, j \leq n$ de la matriz A ; los elementos b_i , $1 \leq i \leq n$ de b ; el número máximo de iteraciones N ; la tolerancia TOL ; el número de dígitos de precisión t .

SALIDA la aproximación $xx = (xx_1, \dots, xx_n)$ o el mensaje de que se rebasó el número de iteraciones y una aproximación $COND$ a $K_\infty(A)$.

Paso 0 Resuelva el sistema $Ax = b$ para $x_1, \dots, x_n$ por la eliminación gaussiana guardando los multiplicadores m_{ij} , $j = i + 1, i + 2, \dots, n$, $i = 1, 2, \dots, n - 1$ y señalando intercambios de renglones.

Paso 1 Tome $k = 1$.

Paso 2 Mientras ($k \leq N$) haga los pasos 3-9.

Paso 3 Para $i = 1, 2, \dots, n$ (Calcule r_i)

$$\text{tome } r_i = b_i - \sum_{j=1}^i a_{ij} x_j$$

(Realice los cálculos con aritmética de doble precisión.)

Paso 4 Resuelva el sistema lineal $Ay = r$ usando la eliminación gaussiana en el mismo orden que en el paso 0.

Paso 5 Para $i = 1, \dots, n$ tome $xx_i = x_i + y_i$.

Paso 6 Si $k = 1$ entonces tome $COND = \frac{\|y\|_\infty}{\|xx\|_\infty} 10^t$.

Paso 7 Si $\|x - xx\|_\infty < TOL$ entonces **SALIDA** (xx);
SALIDA ($COND$);
 (Procedimiento terminado exitosamente.)
PARAR.

Paso 8 Tome $k = k + 1$.

Paso 9 Para $i = 1, \dots, n$ tome $x_i = xx_i$.

Paso 10 **SALIDA** ('Número máximo de iteraciones excedido');
SALIDA ($COND$);
 (Procedimiento terminado sin éxito.)
PARAR.

Si se emplea la aritmética de t dígitos, un procedimiento adecuado para interrumpir el procedimiento en el paso 7 consiste en iterar hasta que $|y_i^{(k)}| \leq 10^{-t}$, para cada $i = 1, 2, \dots, n$.

EJEMPLO 4 En el ejemplo 3 encontramos la aproximación del problema en cuestión mediante la aritmética de cinco dígitos y la eliminación gaussiana es

$$\tilde{\mathbf{x}}^{(1)} = (1.2001, 0.99991, 0.92538)^T$$

y la solución de $A\mathbf{y} = \mathbf{r}^{(1)}$ es

$$\tilde{\mathbf{y}}^{(1)} = (-0.20008, 8.9987 \times 10^{-5}, 0.074607)^T.$$

De acuerdo con el paso 5 de este algoritmo,

$$\tilde{\mathbf{x}}^{(2)} = \tilde{\mathbf{x}}^{(1)} + \tilde{\mathbf{y}}^{(1)} = (1.0000, 1.0000, 0.99999)^T,$$

y el error real de esta aproximación es

$$\|\mathbf{x} - \tilde{\mathbf{x}}^{(2)}\|_{\infty} = 1 \times 10^{-5}.$$

Al aplicar la técnica sugerida para interrumpir el algoritmo, calculamos $\mathbf{r}^{(2)} = \mathbf{b} - A\tilde{\mathbf{x}}^{(2)}$ y resolvemos el sistema $A\mathbf{y}^{(2)} = \mathbf{r}^{(2)}$, lo cual nos da

$$\tilde{\mathbf{y}}^{(2)} = (1.5002 \times 10^{-9}, 2.0951 \times 10^{-10}, 1.0000 \times 10^{-5})^T.$$

Y como $\|\mathbf{y}^{(2)}\|_{\infty} \leq 10^{-5}$, llegamos a la conclusión de que

$$\tilde{\mathbf{x}}^{(3)} = \tilde{\mathbf{x}}^{(2)} + \tilde{\mathbf{y}}^{(2)} = (1.0000, 1.0000, 1.0000)^T$$

es suficientemente exacto, lo cual sin duda es correcto. ■

A lo largo de esta sección hemos supuesto que en el sistema lineal $A\mathbf{x} = \mathbf{b}$, la matriz A y el vector $\mathbf{b}$ pueden representarse de manera exacta. Desde un punto de vista realista, los elementos a_{ij} y b_j se modificarán o perturbarán en una cantidad δa_{ij} y δb_j , lo cual hará que se resuelva el sistema lineal

$$(A + \delta A)\mathbf{x} = \mathbf{b} + \delta \mathbf{b}$$

en vez de $A\mathbf{x} = \mathbf{b}$. En condiciones normales, si $\|\delta A\|$ y $\|\delta \mathbf{b}\|$ son pequeñas (en el orden de 10^{-t}), la aritmética de t dígitos debería producir una solución $\tilde{\mathbf{x}}$ para la cual $\|\mathbf{x} - \tilde{\mathbf{x}}\|$ es correspondientemente pequeña. Sin embargo, en el caso de sistemas mal condicionados hemos visto que aunque A y $\mathbf{b}$ pueden representarse con exactitud, los errores de redondeo pueden hacer que $\|\mathbf{x} - \tilde{\mathbf{x}}\|$ sea grande. El siguiente teorema relaciona las perturbaciones del sistema lineal con el número de condición de una matriz. La demostración de este resultado se encuentra en [Or2, p. 33].

Teorema 7.29 Supongamos que A es una matriz no singular y que

$$\|\delta A\| < \frac{1}{\|A^{-1}\|}.$$

La solución $\tilde{\mathbf{x}}$ de $(A + \delta A)\tilde{\mathbf{x}} = \mathbf{b} + \delta \mathbf{b}$ aproxima la solución $\mathbf{x}$ de $A\mathbf{x} = \mathbf{b}$ con una estimación de error

$$\frac{\|\mathbf{x} - \tilde{\mathbf{x}}\|}{\|\mathbf{x}\|} \leq \frac{K(A)\|A\|}{\|A\| - K(A)\|\delta A\|} \left(\frac{\|\delta \mathbf{b}\|}{\|\mathbf{b}\|} + \frac{\|\delta A\|}{\|A\|} \right). \quad (7.24)$$

■

La estimación en la desigualdad (7.24) establece que, si la matriz A está bien condicionada (es decir, si $K(A)$ no es demasiado grande), entonces cambios pequeños de A y $\mathbf{b}$ producirán cambios pequeños en la solución $\mathbf{x}$. En cambio, si A está mal condicionada, entonces los cambios pequeños de A y $\mathbf{b}$ pueden producir también cambios grandes en $\mathbf{x}$.

El teorema es independiente del procedimiento numérico usado para resolver $A\mathbf{x} = \mathbf{b}$. Mediante el análisis de error hacia atrás de Wilkinson (véase [Wil1] o [Wil2]) podemos demostrar que, si la eliminación gaussiana con pivoteo se emplea para resolver $A\mathbf{x} = \mathbf{b}$ en la aritmética de t dígitos, la solución numérica $\tilde{\mathbf{x}}$ es la solución real de un sistema lineal:

$$(A + \delta A)\tilde{\mathbf{x}} = \mathbf{b}, \quad \text{donde} \quad \|\delta A\|_{\infty} \leq f(n)10^{1-t} \max_{i,j,k} |a_{ij}|^{(k)}.$$

Wilkinson descubrió que en la práctica $f(n) \approx n$ y, en el peor de los casos, $f(n) \leq 1.01(n^3 + 3n^2)$.

CONJUNTO DE EJERCICIOS 7.4

1. Calcule los números de condición de las siguientes matrices en relación con $\|\cdot\|_{\infty}$.

a. $\begin{bmatrix} \frac{1}{2} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{4} \end{bmatrix}$

b. $\begin{bmatrix} 3.9 & 1.6 \\ 6.8 & 2.9 \end{bmatrix}$

c. $\begin{bmatrix} 1 & 2 \\ 1.00001 & 2 \end{bmatrix}$

d. $\begin{bmatrix} 1.003 & 58.09 \\ 5.550 & 321.8 \end{bmatrix}$

e. $\begin{bmatrix} 1 & -1 & -1 \\ 0 & 1 & -1 \\ 0 & 0 & -1 \end{bmatrix}$

f. $\begin{bmatrix} 0.04 & 0.01 & -0.01 \\ 0.2 & 0.5 & -0.2 \\ 1 & 2 & 4 \end{bmatrix}$

2. Los siguientes sistemas lineales $A\mathbf{x} = \mathbf{b}$ tienen a $\mathbf{x}$ como solución real y a $\tilde{\mathbf{x}}$ como solución aproximada. Con los resultados del ejercicio 1 calcule $\|\mathbf{x} - \tilde{\mathbf{x}}\|_{\infty}$ y $K_{\infty}(A) \frac{\|\mathbf{b} - A\tilde{\mathbf{x}}\|_{\infty}}{\|\mathbf{b}\|_{\infty}}$.

a. $\frac{1}{2}x_1 + \frac{1}{3}x_2 = \frac{1}{63},$

b. $3.9x_1 + 1.6x_2 = 5.5,$

$\frac{1}{3}x_1 + \frac{1}{4}x_2 = \frac{1}{168},$

$6.8x_1 + 2.9x_2 = 9.7,$

$\mathbf{x} = \left(\frac{1}{7}, -\frac{1}{6}\right)^T,$

$\tilde{\mathbf{x}} = (1, 1)^T,$

$\tilde{\mathbf{x}} = (0.142, -0.166)^T.$

$\tilde{\mathbf{x}} = (0.98, 1.1)^T.$

c. $x_1 + 2x_2 = 3,$

d. $1.003x_1 + 58.09x_2 = 68.12,$

$1.0001x_1 + 2x_2 = 3.0001,$

$5.550x_1 + 321.8x_2 = 377.3,$

$\mathbf{x} = (1, 1)^T,$

$\mathbf{x} = (10, 1)^T,$

$\tilde{\mathbf{x}} = (0.96, 1.02)^T.$

$\tilde{\mathbf{x}} = (-10, 1)^T.$

$$e. \quad x_1 - x_2 - x_3 = 2\pi,$$

$$x_2 - x_3 = 0,$$

$$-x_3 = \pi.$$

$$\mathbf{x} = (0, -\pi, -\pi)',$$

$$\mathbf{\tilde{x}} = (-0.1, -3.15, -3.14)'$$

$$f. \quad 0.04x_1 + 0.01x_2 - 0.01x_3 = 0.06,$$

$$0.2x_1 + 0.5x_2 - 0.2x_3 = 0.3$$

$$x_1 + 2x_2 + 4x_3 = 11,$$

$$\mathbf{x} = (1.827586, 0.6551724, 1.965517)',$$

$$\mathbf{\tilde{x}} = (1.8, 0.64, 1.9)'$$

3. El sistema lineal

$$\begin{bmatrix} 1 & 2 \\ 1.0001 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 3 \\ 3.0001 \end{bmatrix}$$

tiene la solución $(1, 1)'$. Transforme A ligeramente en

$$\begin{bmatrix} 1 & 2 \\ 0.9999 & 2 \end{bmatrix},$$

y considere el sistema lineal

$$\begin{bmatrix} 1 & 2 \\ 0.9999 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 3 \\ 3.0001 \end{bmatrix}.$$

Calcule la solución nueva mediante la aritmética de redondeo a cinco dígitos y compare después el error real con el estimado (7.24). ¿Es A una matriz mal condicionada?

4. El sistema lineal $A\mathbf{x} = \mathbf{b}$ dado por

$$\begin{bmatrix} 1 & 2 \\ 1.00001 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 3 \\ 3.00001 \end{bmatrix}$$

tiene la solución $(1, 1)'$. Use la aritmética de redondeo a siete dígitos para obtener la solución del sistema perturbado

$$\begin{bmatrix} 1 & 2 \\ 1.000011 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 3.00001 \\ 3.00003 \end{bmatrix}$$

y después compare el error real con el estimado (7.24). ¿Es A una matriz mal condicionada?

5. a. En una computadora, use la aritmética de precisión simple para resolver el siguiente sistema lineal por medio de la eliminación gaussiana con el algoritmo de sustitución hacia atrás 6.1.

$$\frac{1}{3}x_1 - \frac{1}{3}x_2 - \frac{1}{3}x_3 - \frac{1}{3}x_4 - \frac{1}{3}x_5 = 1$$

$$\frac{1}{3}x_2 - \frac{1}{3}x_3 - \frac{1}{3}x_4 - \frac{1}{3}x_5 = 0$$

$$\frac{1}{3}x_3 - \frac{1}{3}x_4 - \frac{1}{3}x_5 = -1$$

$$\frac{1}{3}x_4 - \frac{1}{3}x_5 = 2$$

$$\frac{1}{3}x_5 = 7$$

b. Calcule el número de condición de la matriz para el sistema en relación con $\|\cdot\|_\infty$.

c. Encuentre la solución exacta del sistema lineal.

6. La matriz de Hilbert de $n \times n$, $H^{(n)}$, definida por

$$H_{ij}^{(n)} = \frac{1}{1 + j - i}, \quad 1 \leq i, j \leq n,$$

es una matriz mal condicionada que se presenta al resolver las ecuaciones normales de los coeficientes del polinomio de mínimos cuadrados (véase el ejemplo 1 de la sección 8.2).

- a. Demuestre que

$$[H^{(4)}]^{-1} = \begin{bmatrix} 16 & -120 & 240 & -140 \\ -120 & 1200 & -2700 & 1680 \\ 240 & -2700 & 6480 & -4200 \\ -140 & 1680 & -4200 & 2800 \end{bmatrix},$$

y calcule $K_{\infty}(H^{(4)})$.

- b. Demuestre que

$$[H^{(5)}]^{-1} = \begin{bmatrix} 25 & -300 & 1050 & -1400 & 630 \\ -300 & 4800 & -18900 & 26880 & -12600 \\ 1050 & -18900 & 79380 & -117600 & 56700 \\ -1400 & 26880 & -117600 & 179200 & -88200 \\ 630 & -12600 & 56700 & -88200 & 44100 \end{bmatrix},$$

y calcule $K_{\infty}(H^{(5)})$.

- c. Resuelva el sistema lineal

$$H^{(4)} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

con la aritmética de redondeo a cinco dígitos y después compare el error real con el estimado en (7.24).

7. Demuestre que si B es singular, entonces

$$\frac{1}{K(A)} \leq \frac{\|A - B\|}{\|A\|}.$$

[Sugerencia: existe un vector con $\|x\| = 1$, tal que $Bx = 0$. Derive la estimación utilizando $\|Ax\| \geq \|x\| \|A^{-1}\|^{-1}$.]

8. Use el ejercicio 7 para estimar los números de condición de las siguientes matrices:

a. $\begin{bmatrix} 1 & 2 \\ 1.0001 & 2 \end{bmatrix}$

b. $\begin{bmatrix} 3.9 & 1.6 \\ 6.8 & 2.9 \end{bmatrix}$

9. Use la aritmética de redondeo a cuatro dígitos para calcular la inversa H^{-1} de la matriz H de Hilbert de 3×3 , y luego calcule $\hat{H} = (H^{-1})^{-1}$. Determine $\|H - \hat{H}\|_{\infty}$.

7.5 El método del gradiente conjugado

El método del gradiente conjugado de Hestenes y Stiefel [HS] fue desarrollado originalmente como un método directo diseñado para resolver un sistema lineal $n \times n$ definido positivo. Como método directo, por lo general es inferior a la eliminación gaussiana con pivoteo, pues ambos métodos requieren n pasos para determinar una solución y los pasos del método del gradiente conjugado tienen un costo mayor en cálculos que los de la eliminación gaussiana.

Sin embargo, el método del gradiente conjugado es muy útil como método iterativo de aproximación para resolver sistemas esparcidos de gran tamaño con entradas no nulas que aparecen con patrones predecibles. Estos problemas surgen con frecuencia al resolver problemas con valores en la frontera. Cuando la matriz está preconditionada para que los cálculos sean más eficaces, se obtienen buenos resultados aproximadamente en $\sqrt{n}$ pasos. Empleado de esta manera, este método es preferible sobre la eliminación gaussiana y los métodos iterativos ya analizados.

En esta sección supondremos que la matriz A es definida positiva. Usaremos la notación de *producto interior*

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}'\mathbf{y}, \quad (7.25)$$

donde $\mathbf{x}$ y $\mathbf{y}$ son vectores n -dimensionales. También necesitaremos algunos resultados usuales del álgebra lineal. En la sección 9.1 aparece un repaso de este material.

El siguiente resultado es una consecuencia sencilla de las propiedades de las transpuestas (véase el ejercicio 12).

Teorema 7.30 Para cualesquiera vectores $\mathbf{x}$, $\mathbf{y}$, y $\mathbf{z}$ y cualquier número real α , tenemos

- (i) $\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle$;
- (ii) $\langle \alpha \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{x}, \alpha \mathbf{y} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle$;
- (iii) $\langle \mathbf{x} + \mathbf{z}, \mathbf{y} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{z}, \mathbf{y} \rangle$;
- (iv) $\langle \mathbf{x}, \mathbf{x} \rangle \geq 0$;
- (v) $\langle \mathbf{x}, \mathbf{x} \rangle = 0$ si y sólo si $\mathbf{x} = \mathbf{0}$. ■

Cuando A es definida positiva, $\langle \mathbf{x}, A\mathbf{x} \rangle = \mathbf{x}'A\mathbf{x} > 0$ a menos que $\mathbf{x} = \mathbf{0}$. Además, como A es simétrica, tenemos que $\mathbf{x}'A\mathbf{y} = \mathbf{x}'A'\mathbf{y} = (A\mathbf{x})'\mathbf{y}$, por lo que en este caso tenemos que para cada $\mathbf{x}$ y $\mathbf{y}$,

$$\langle \mathbf{x}, A\mathbf{y} \rangle = \langle A\mathbf{x}, \mathbf{y} \rangle. \quad (7.26)$$

El siguiente resultado es una herramienta básica en el desarrollo del método del gradiente conjugado.

Teorema 7.31 El vector $\mathbf{x}^*$ es una solución del sistema lineal definido positivo $A\mathbf{x} = \mathbf{b}$ si y sólo si $\mathbf{x}^*$ minimiza

$$g(\mathbf{x}) = \langle \mathbf{x}, A\mathbf{x} \rangle - 2\langle \mathbf{x}, \mathbf{b} \rangle. \quad \blacksquare$$

Demostración Sean $\mathbf{x}$ y $\mathbf{v} \neq \mathbf{0}$ vectores fijos y t un número real variable. Tenemos que

$$\begin{aligned} g(\mathbf{x} + t\mathbf{v}) &= \langle \mathbf{x} + t\mathbf{v}, A\mathbf{x} + tA\mathbf{v} \rangle - 2\langle \mathbf{x} + t\mathbf{v}, \mathbf{b} \rangle \\ &= \langle \mathbf{x}, A\mathbf{x} \rangle + t\langle \mathbf{v}, A\mathbf{x} \rangle + t\langle \mathbf{x}, A\mathbf{v} \rangle + t^2\langle \mathbf{v}, A\mathbf{v} \rangle - 2\langle \mathbf{x}, \mathbf{b} \rangle - 2t\langle \mathbf{v}, \mathbf{b} \rangle \\ &= \langle \mathbf{x}, A\mathbf{x} \rangle - 2\langle \mathbf{x}, \mathbf{b} \rangle + 2t\langle \mathbf{v}, A\mathbf{x} - \mathbf{b} \rangle + t^2\langle \mathbf{v}, A\mathbf{v} \rangle, \end{aligned}$$

de modo que

$$g(\mathbf{x} + t\mathbf{v}) = g(\mathbf{x}) + 2t\langle \mathbf{v}, A\mathbf{x} - \mathbf{b} \rangle + t^2\langle \mathbf{v}, A\mathbf{v} \rangle. \quad (7.27)$$

Como $\mathbf{x}$ y $\mathbf{v}$ están fijos, definimos la función cuadrática h en t como

$$h(t) = g(\mathbf{x} + t\mathbf{v}).$$

Entonces h asume un valor mínimo cuando $h'(t) = 0$, pues su coeficiente en t^2 , $\langle \mathbf{v}, A\mathbf{v} \rangle$, es positivo. Como

$$h'(t) = 2\langle \mathbf{v}, A\mathbf{x} - \mathbf{b} \rangle + 2t\langle \mathbf{v}, A\mathbf{v} \rangle,$$

el mínimo aparece cuando

$$\hat{t} = -\frac{\langle \mathbf{v}, A\mathbf{x} - \mathbf{b} \rangle}{\langle \mathbf{v}, A\mathbf{v} \rangle} = \frac{\langle \mathbf{v}, \mathbf{b} - A\mathbf{x} \rangle}{\langle \mathbf{v}, A\mathbf{v} \rangle},$$

y de la ecuación (7.27)

$$\begin{aligned} h(\hat{t}) &= g(\mathbf{x}) - 2\frac{\langle \mathbf{v}, \mathbf{b} - A\mathbf{x} \rangle}{\langle \mathbf{v}, A\mathbf{v} \rangle} \langle \mathbf{v}, \mathbf{b} - A\mathbf{x} \rangle + \left(\frac{\langle \mathbf{v}, \mathbf{b} - A\mathbf{x} \rangle}{\langle \mathbf{v}, A\mathbf{v} \rangle} \right)^2 \langle \mathbf{v}, A\mathbf{v} \rangle \\ &= g(\mathbf{x}) - \frac{\langle \mathbf{v}, \mathbf{b} - A\mathbf{x} \rangle^2}{\langle \mathbf{v}, A\mathbf{v} \rangle}. \end{aligned}$$

Así, para cualquier vector $\mathbf{v} \neq \mathbf{0}$, tenemos que $g(\mathbf{x} + \hat{t}\mathbf{v}) < g(\mathbf{x})$ a menos que $\langle \mathbf{v}, \mathbf{b} - A\mathbf{x} \rangle = 0$, en cuyo caso $g(\mathbf{x}) = g(\mathbf{x} + \hat{t}\mathbf{v})$. Este es el resultado básico necesario para demostrar el teorema 7.31.

Supongamos que $\mathbf{x}^*$ satisface $A\mathbf{x}^* = \mathbf{b}$. Entonces $\langle \mathbf{v}, \mathbf{b} - A\mathbf{x}^* \rangle = 0$ para cualquier vector $\mathbf{v}$ y $g(\mathbf{x})$ no puede ser menor que $g(\mathbf{x}^*)$. Así, $\mathbf{x}^*$ minimiza a g .

Por otro lado, supongamos que $\mathbf{x}^*$ es un vector que minimiza g . Entonces, para cualquier vector $\mathbf{v}$, tenemos $g(\mathbf{x}^* + \hat{t}\mathbf{v}) \geq g(\mathbf{x}^*)$. Así, $\langle \mathbf{v}, \mathbf{b} - A\mathbf{x}^* \rangle = 0$. Esto implica que $\mathbf{b} - A\mathbf{x}^* = \mathbf{0}$ y, en consecuencia, $A\mathbf{x}^* = \mathbf{b}$. ■ ■ ■

Para iniciar con el método del gradiente conjugado, elegimos $\mathbf{x}$, una solución aproximada de $A\mathbf{x} = \mathbf{b}$ y $\mathbf{v} \neq \mathbf{0}$, para obtener una *dirección de búsqueda* en la cual alejarse de $\mathbf{x}$ para mejorar la aproximación. Sea $\mathbf{r} = \mathbf{b} - A\mathbf{x}$ el vector residual asociado a $\mathbf{x}$, con

$$t = \frac{\langle \mathbf{v}, \mathbf{b} - A\mathbf{x} \rangle}{\langle \mathbf{v}, A\mathbf{v} \rangle} = \frac{\langle \mathbf{v}, \mathbf{r} \rangle}{\langle \mathbf{v}, A\mathbf{v} \rangle}.$$

Si $\mathbf{r} \neq \mathbf{0}$ y si $\mathbf{v}$ y $\mathbf{r}$ no son ortogonales, entonces $\mathbf{x} + t\mathbf{v}$ da un menor valor de g que $g(\mathbf{x})$ y posiblemente esté más cerca de $\mathbf{x}^*$ que $\mathbf{x}$. Esto sugiere el siguiente método.

Sea $\mathbf{x}^{(0)}$ una aproximación inicial a $\mathbf{x}^*$ y sea $\mathbf{v}^{(0)} \neq \mathbf{0}$ una dirección de búsqueda inicial. Para $k = 1, 2, 3, \dots$, calculamos:

$$t_k = \frac{\langle \mathbf{v}^{(k)}, \mathbf{b} - A\mathbf{x}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle},$$

$$\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} + t_k \mathbf{v}^{(k)}$$

y elegimos una nueva dirección de búsqueda $\mathbf{v}^{(k+1)}$. El objetivo es hacer esta elección de modo que la sucesión de aproximaciones $\{\mathbf{x}^{(k)}\}$ converja rápidamente a $\mathbf{x}^*$.

Para elegir las direcciones de búsqueda, vemos a g como una función de las componentes de $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$. Así,

$$g(x_1, x_2, \dots, x_n) = \langle \mathbf{x}, A\mathbf{x} \rangle - 2\langle \mathbf{x}, \mathbf{b} \rangle = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - 2 \sum_{i=1}^n x_i b_i.$$

Al calcular las derivadas parciales con respecto de las variables componente x_i tenemos

$$\frac{\partial g}{\partial x_i}(\mathbf{x}) = 2 \sum_{j=1}^n a_{ij} x_j - 2 b_i.$$

Por tanto, el gradiente de g es

$$\nabla g(\mathbf{x}) = \left(\frac{\partial g}{\partial x_1}(\mathbf{x}), \frac{\partial g}{\partial x_2}(\mathbf{x}), \dots, \frac{\partial g}{\partial x_n}(\mathbf{x}) \right)^T = 2(A\mathbf{x} - \mathbf{b}) = -2\mathbf{r},$$

donde el vector $\mathbf{r}$ es el vector residual para $\mathbf{x}$.

El cálculo de varias variables nos dice que la dirección de máximo descenso en el valor de $g(\mathbf{x})$ es la dirección dada por $-\nabla g(\mathbf{x})$; es decir, en la dirección del residual $\mathbf{r}$. El método que elige

$$\mathbf{v}^{(k+1)} = \mathbf{r}^{(k)} = \mathbf{b} - A\mathbf{x}^{(k)}$$

se llama el *método de máximo descenso*. Aunque en la sección 10.4 veremos que este método tiene su mérito para sistemas no lineales y problemas de optimización, no se usa para los sistemas lineales debido a su convergencia lenta.

Un método alternativo usa un conjunto de vectores de dirección no nulos $\{\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(n)}\}$ que satisfacen

$$\langle \mathbf{v}^{(i)}, A\mathbf{v}^{(j)} \rangle = 0, \quad \text{si } i \neq j.$$

Esto se llama **condición de A-ortogonalidad** y el conjunto de vectores $\{\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(n)}\}$ es **A-ortogonal**. No es difícil mostrar que un conjunto de vectores A-ortogonales asociados con la matriz definida positiva A es linealmente independiente. (Véase el Ejercicio 13(a).) Este conjunto de direcciones de búsqueda da

$$t_k = \frac{\langle \mathbf{v}^{(k)}, \mathbf{b} - A\mathbf{x}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle} = \frac{\langle \mathbf{v}^{(k)}, \mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle}$$

$$\text{y } \mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} + t_k \mathbf{v}^{(k)}.$$

El siguiente teorema muestra que esta elección de direcciones de búsqueda da la convergencia en a lo más n pasos, de modo que como método directo produce la solución exacta, suponiendo que la aritmética sea exacta.

Teorema 7.32 Sea $\{v^{(1)}, \dots, v^{(n)}\}$ un conjunto A -ortogonal de vectores no nulos asociados con la matriz A definida positiva y sea $x^{(0)}$ arbitrario. Sean

$$t_k = \frac{\langle v^{(k)}, b - Ax^{(k-1)} \rangle}{\langle v^{(k)}, Av^{(k)} \rangle} \quad \text{y} \quad x^{(k)} = x^{(k-1)} + t_k v^{(k)},$$

para $k = 1, 2, \dots, n$. Entonces, suponiendo una aritmética exacta, $Ax^{(n)} = b$. ■

Demostración Como para cada $k = 1, 2, \dots, n$,

$$x^{(k)} = x^{(k-1)} + t_k v^{(k)},$$

tenemos

$$\begin{aligned} Ax^{(n)} &= Ax^{(n-1)} + t_n Av^{(n)} \\ &= (Ax^{(n-2)} + t_{n-1} Av^{(n-1)}) + t_n Av^{(n)} \\ &\vdots \\ &= Ax^{(0)} + t_1 Av^{(1)} + t_2 Av^{(2)} + \dots + t_n Av^{(n)}. \end{aligned}$$

Al restar b de este resultado tenemos

$$Ax^{(n)} - b = Ax^{(0)} - b + t_1 Av^{(1)} + t_2 Av^{(2)} + \dots + t_n Av^{(n)}.$$

Ahora calculamos el producto interior de ambos lados con el vector $v^{(k)}$ y usamos las propiedades del producto interior y el hecho de que A es simétrica para obtener

$$\begin{aligned} \langle Ax^{(n)} - b, v^{(k)} \rangle &= \langle Ax^{(0)} - b, v^{(k)} \rangle + t_1 \langle Av^{(1)}, v^{(k)} \rangle + \dots + t_n \langle Av^{(n)}, v^{(k)} \rangle \\ &= \langle Ax^{(0)} - b, v^{(k)} \rangle + t_1 \langle v^{(1)}, Av^{(k)} \rangle + \dots + t_n \langle v^{(n)}, Av^{(k)} \rangle. \end{aligned}$$

La propiedad de A -ortogonalidad implica, para cada k ,

$$\langle Ax^{(n)} - b, v^{(k)} \rangle = \langle Ax^{(0)} - b, v^{(k)} \rangle + t_k \langle v^{(k)}, Av^{(k)} \rangle. \quad (7.28)$$

Sin embargo,

$$t_k = \frac{\langle v^{(k)}, b - Ax^{(k-1)} \rangle}{\langle v^{(k)}, Av^{(k)} \rangle},$$

de modo que

$$\begin{aligned} t_k \langle v^{(k)}, Av^{(k)} \rangle &= \langle v^{(k)}, b - Ax^{(k-1)} \rangle \\ &= \langle v^{(k)}, b - Ax^{(0)} + Ax^{(0)} - Ax^{(1)} + \dots - Ax^{(k-2)} + Ax^{(k-2)} - Ax^{(k-1)} \rangle \\ &= \langle v^{(k)}, b - Ax^{(0)} \rangle + \langle v^{(k)}, Ax^{(0)} - Ax^{(1)} \rangle + \dots + \langle v^{(k)}, Ax^{(k-2)} - Ax^{(k-1)} \rangle. \end{aligned}$$

Pero para cualquier i ,

$$\mathbf{x}^{(i)} = \mathbf{x}^{(i-1)} + t_i \mathbf{v}^{(i)} \quad \text{y} \quad A\mathbf{x}^{(i)} = A\mathbf{x}^{(i-1)} + t_i A\mathbf{v}^{(i)},$$

de modo que

$$A\mathbf{x}^{(i-1)} - A\mathbf{x}^{(i)} = -t_i A\mathbf{v}^{(i)}.$$

Así,

$$t_k \langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle = \langle \mathbf{v}^{(k)}, \mathbf{b} - A\mathbf{x}^{(0)} \rangle - t_1 \langle \mathbf{v}^{(k)}, A\mathbf{v}^{(1)} \rangle - \dots - t_{k-1} \langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k-1)} \rangle.$$

Debido a la A -ortogonalidad $\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(i)} \rangle = 0$ para $i \neq k$, de modo que

$$\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle t_k = \langle \mathbf{v}^{(k)}, \mathbf{b} - A\mathbf{x}^{(0)} \rangle.$$

De la ecuación (7.28),

$$\begin{aligned} \langle A\mathbf{x}^{(n)} - \mathbf{b}, \mathbf{v}^{(k)} \rangle &= \langle A\mathbf{x}^{(0)} - \mathbf{b}, \mathbf{v}^{(k)} \rangle + \langle \mathbf{v}^{(k)}, \mathbf{b} - A\mathbf{x}^{(0)} \rangle \\ &= \langle A\mathbf{x}^{(0)} - \mathbf{b}, \mathbf{v}^{(k)} \rangle + \langle \mathbf{b} - A\mathbf{x}^{(0)}, \mathbf{v}^{(k)} \rangle \\ &= \langle A\mathbf{x}^{(0)} - \mathbf{b}, \mathbf{v}^{(k)} \rangle - \langle A\mathbf{x}^{(0)} - \mathbf{b}, \mathbf{v}^{(k)} \rangle \\ &= 0. \end{aligned}$$

El vector $A\mathbf{x}^{(n)} - \mathbf{b}$ es ortogonal al conjunto A -ortogonal de vectores $\{\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(n)}\}$. Esto implica (véase el ejercicio 13(b)) que $A\mathbf{x}^{(n)} - \mathbf{b} = \mathbf{0}$. ■ ■ ■

EJEMPLO 1 Considere la matriz definida positiva

$$A = \begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix}.$$

Sea $\mathbf{v}^{(1)} = (1, 0, 0)^T$, $\mathbf{v}^{(2)} = (-3/4, 1, 0)^T$ y $\mathbf{v}^{(3)} = (-3/7, 4/7, 1)^T$. Por cálculo directo,

$$\langle \mathbf{v}^{(1)}, A\mathbf{v}^{(2)} \rangle = \mathbf{v}^{(1)T} A\mathbf{v}^{(2)} = (1, 0, 0) \begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} -3/4 \\ 1 \\ 0 \end{bmatrix} = 0,$$

$$\langle \mathbf{v}^{(1)}, A\mathbf{v}^{(3)} \rangle = (1, 0, 0) \begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} -3/7 \\ 4/7 \\ 1 \end{bmatrix} = 0,$$

y

$$\langle \mathbf{v}^{(2)}, A\mathbf{v}^{(3)} \rangle = \left(-\frac{3}{4}, 1, 0\right) \begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} -3/7 \\ 4/7 \\ 1 \end{bmatrix} = 0.$$

Así, $\{\mathbf{v}^{(1)}, \mathbf{v}^{(2)}, \mathbf{v}^{(3)}\}$ es un conjunto A -ortogonal.

El sistema lineal

$$\begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 24 \\ 30 \\ -24 \end{bmatrix},$$

tiene la solución exacta $\mathbf{x}^* = (3, 4, -5)^T$. Para aproximar esta solución, sea $\mathbf{x}^{(0)} = (0, 0, 0)^T$. Como $\mathbf{b} = (24, 30, -24)^T$, tenemos

$$\mathbf{r}^{(0)} = \mathbf{b} - A\mathbf{x}^{(0)} = \mathbf{b} = (24, 30, -24)^T,$$

de modo que

$$\langle \mathbf{v}^{(1)}, \mathbf{r}^{(0)} \rangle = \mathbf{v}^{(1)T} \mathbf{r}^{(0)} = 24, \quad \langle \mathbf{v}^{(1)}, A\mathbf{v}^{(1)} \rangle = 4 \quad \text{y} \quad t_0 = \frac{24}{4} = 6.$$

Así,

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + t_0 \mathbf{v}^{(1)} = (0, 0, 0)^T + 6(1, 0, 0)^T = (6, 0, 0)^T.$$

Continuando de esta manera,

$$\mathbf{r}^{(1)} = \mathbf{b} - A\mathbf{x}^{(1)} = (0, 12, -24)^T; \quad t_1 = \frac{\langle \mathbf{v}^{(2)}, \mathbf{r}^{(1)} \rangle}{\langle \mathbf{v}^{(2)}, A\mathbf{v}^{(2)} \rangle} = \frac{12}{7/4} = \frac{48}{7};$$

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + t_1 \mathbf{v}^{(2)} = (6, 0, 0)^T + \frac{48}{7} \left(-\frac{3}{4}, 1, 0 \right)^T = \left(\frac{6}{7}, \frac{48}{7}, 0 \right)^T;$$

$$\mathbf{r}^{(2)} = \mathbf{b} - A\mathbf{x}^{(2)} = \left(0, 0, -\frac{120}{7} \right)^T; \quad t_2 = \frac{\langle \mathbf{v}^{(3)}, \mathbf{r}^{(2)} \rangle}{\langle \mathbf{v}^{(3)}, A\mathbf{v}^{(3)} \rangle} = \frac{-120/7}{24/7} = -5;$$

y

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + t_2 \mathbf{v}^{(3)} = \left(\frac{6}{7}, \frac{48}{7}, 0 \right)^T + (-5) \left(-\frac{3}{7}, \frac{4}{7}, 1 \right)^T = (3, 4, -5)^T.$$

Como aplicamos la técnica $n = 3$ veces, ésta es la solución real. ■

Antes de analizar la forma de determinar el conjunto A -ortogonal, continuaremos nuestro desarrollo. El uso de un conjunto A -ortogonal $\{\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(n)}\}$ de vectores de dirección da lo que se llama un método de *dirección conjugada*. El siguiente teorema muestra la ortogonalidad de los vectores residuales $\mathbf{r}^{(k)}$ y los vectores de dirección $\mathbf{v}^{(j)}$. En el ejercicio 14 se considera una demostración de ese resultado mediante inducción matemática.

Teorema 7.33 Los vectores residuales $\mathbf{r}^{(k)}$, donde $k = 1, 2, \dots, n$, para un método de dirección conjugada, satisfacen las ecuaciones

$$\langle \mathbf{r}^{(k)}, \mathbf{v}^{(j)} \rangle = 0, \quad \text{para cada } j = 1, 2, \dots, k. \quad \blacksquare$$