

El método del gradiente conjugado de Hestenes y Stiefel elige las direcciones de búsqueda $\{v^{(k)}\}$ durante el proceso iterativo de modo que los vectores residuales $\{r^{(k)}\}$ sean mutuamente ortogonales. Para construir los vectores de dirección $\{v^{(1)}, v^{(2)}, \dots\}$ y las aproximaciones $\{x^{(1)}, x^{(2)}, \dots\}$, partimos de una aproximación inicial $x^{(0)}$ y usamos la dirección de máximo descenso $r^{(0)} = b - Ax^{(0)}$ como la primera dirección de búsqueda $v^{(1)}$.

Suponga que hemos calculado las direcciones conjugadas $v^{(1)}, \dots, v^{(k-1)}$ y las aproximaciones $x^{(1)}, \dots, x^{(k-1)}$ con

$$x^{(k-1)} = x^{(k-2)} + t_{k-1} v^{(k-1)},$$

donde

$$\langle v^{(i)}, Av^{(j)} \rangle = 0 \quad \text{y} \quad \langle r^{(i)}, r^{(j)} \rangle = 0 \quad \text{para} \quad i \neq j.$$

Si $x^{(k-1)}$ es la solución de $Ax = b$, hemos terminado. En caso contrario $r^{(k-1)} = b - Ax^{(k-1)} \neq 0$ y el teorema 7.33 implica que $\langle r^{(k-1)}, v^{(i)} \rangle = 0$ para $i = 1, 2, \dots, k-1$. Entonces usamos $r^{(k-1)}$ para generar $v^{(k)}$ haciendo

$$v^{(k)} = r^{(k-1)} + s_{k-1} v^{(k-1)},$$

Queremos elegir s_{k-1} de modo que

$$\langle v^{(k-1)}, Av^{(k)} \rangle = 0.$$

Como

$$Av^{(k)} = Ar^{(k-1)} + s_{k-1} Av^{(k-1)}$$

y

$$\langle v^{(k-1)}, Av^{(k)} \rangle = \langle v^{(k-1)}, Ar^{(k-1)} \rangle + s_{k-1} \langle v^{(k-1)}, Av^{(k-1)} \rangle,$$

tendremos $\langle v^{(k-1)}, Av^{(k)} \rangle = 0$ cuando

$$s_{k-1} = - \frac{\langle v^{(k-1)}, Ar^{(k-1)} \rangle}{\langle v^{(k-1)}, Av^{(k-1)} \rangle}.$$

También se puede mostrar que con esta elección de s_{k-1} tenemos $\langle v^{(k)}, Av^{(i)} \rangle = 0$. Para cada $i = 1, 2, \dots, k-2$ [Lu, p. 245]. Así, $\{v^{(1)}, \dots, v^{(k)}\}$ es un conjunto A -ortogonal.

Una vez elegido $v^{(k)}$, calculamos

$$\begin{aligned} t_k &= \frac{\langle v^{(k)}, r^{(k-1)} \rangle}{\langle v^{(k)}, Av^{(k)} \rangle} = \frac{\langle r^{(k-1)} + s_{k-1} v^{(k-1)}, r^{(k-1)} \rangle}{\langle v^{(k)}, Av^{(k)} \rangle} \\ &= \frac{\langle r^{(k-1)}, r^{(k-1)} \rangle}{\langle v^{(k)}, Av^{(k)} \rangle} + s_{k-1} \frac{\langle v^{(k-1)}, r^{(k-1)} \rangle}{\langle v^{(k)}, Av^{(k)} \rangle}. \end{aligned}$$

Por el teorema 7.33, $\langle v^{(k-1)}, r^{(k-1)} \rangle = 0$, de modo que

$$t_k = \frac{\langle r^{(k-1)}, r^{(k-1)} \rangle}{\langle v^{(k)}, Av^{(k)} \rangle}. \quad (7.29)$$

Así,

$$\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} + t_k \mathbf{v}^{(k)}.$$

Para calcular $\mathbf{r}^{(k)}$, multiplicamos por A y restamos $\mathbf{b}$ para obtener

$$A\mathbf{x}^{(k)} - \mathbf{b} = A\mathbf{x}^{(k-1)} - \mathbf{b} + t_k A\mathbf{v}^{(k)}$$

o bien

$$\mathbf{r}^{(k)} = \mathbf{r}^{(k-1)} - t_k A\mathbf{v}^{(k)}.$$

Así,

$$\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle = \langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k)} \rangle - t_k \langle A\mathbf{v}^{(k)}, \mathbf{r}^{(k)} \rangle = -t_k \langle \mathbf{r}^{(k)}, A\mathbf{v}^{(k)} \rangle.$$

Además, de la ecuación (7.29),

$$\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle = t_k \langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle,$$

de modo que

$$\begin{aligned} s_k &= -\frac{\langle \mathbf{v}^{(k)}, A\mathbf{r}^{(k)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle} = -\frac{\langle \mathbf{r}^{(k)}, A\mathbf{v}^{(k)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle} \\ &= \frac{(1/t_k)\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}{(1/t_k)\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle} = \frac{\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}{\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle}. \end{aligned}$$

En resumen, tenemos las fórmulas

$$\mathbf{r}^{(0)} = \mathbf{b} - A\mathbf{x}^{(0)}, \quad \mathbf{v}^{(1)} = \mathbf{r}^{(0)},$$

y para $k = 1, 2, \dots, n$,

$$\begin{aligned} t_k &= \frac{\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle}, \\ \mathbf{x}^{(k)} &= \mathbf{x}^{(k-1)} + t_k \mathbf{v}^{(k)}, \\ \mathbf{r}^{(k)} &= \mathbf{r}^{(k-1)} - t_k A\mathbf{v}^{(k)}, \\ s_k &= \frac{\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}{\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle}, \\ \mathbf{v}^{(k+1)} &= \mathbf{r}^{(k)} + s_k \mathbf{v}^{(k)}. \end{aligned} \tag{7.30}$$

En vez de presentar un algoritmo para el método del gradiente conjugado mediante estas fórmulas, ampliaremos el método para incluir el *precondicionamiento*. Si la matriz A es mal condicionada, este método es altamente susceptible a los errores de redondeo. Así, aunque la respuesta exacta debería obtenerse en n pasos, esto no es usual. Como método directo, el método del gradiente conjugado no es tan bueno como la eliminación gaussiana con pivoteo. El principal uso del método del gradiente conjugado es como método iterativo

aplicado a un sistema mejor condicionado. En este caso, con frecuencia se obtiene una solución aproximada aceptable en cerca de $\sqrt{n}$ pasos.

Para aplicar el método a un sistema mejor condicionado, queremos elegir una matriz no singular de condicionamiento C de modo que

$$\tilde{A} = C^{-1}A(C^{-1})^t$$

esté mejor condicionada. Para simplificar la notación, usaremos la matriz C^{-1} para referirnos a $(C^{-1})^t$.

Consideremos el sistema lineal

$$\tilde{A} \tilde{x} = \tilde{b},$$

donde $\tilde{x} = C^t x$ y $\tilde{b} = C^{-1} b$. Entonces

$$\tilde{A} \tilde{x} = (C^{-1} A C^{-1}) (C^t x) = C^{-1} A x.$$

Así, podríamos resolver $\tilde{A} \tilde{x} = \tilde{b}$ en términos de $\tilde{x}$ y luego obtener x multiplicando por C^{-t} . Sin embargo, en vez de escribir de nuevo las ecuaciones (7.30) usando $\tilde{r}^{(k)}$, $\tilde{v}^{(k)}$, $\tilde{i}_k$, $\tilde{x}^{(k)}$ y s_k , incorporamos el preconditionamiento de manera implícita.

Como

$$\tilde{x}^{(k)} = C^t x^{(k)},$$

tenemos

$$\tilde{r}^{(k)} = \tilde{b} - \tilde{A} \tilde{x}^{(k)} = C^{-1} b - (C^{-1} A C^{-1}) C^t x^{(k)} = C^{-1} (b - A x^{(k)}) = C^{-1} r^{(k)}.$$

Sean $\tilde{v}^{(k)} = C^t v^{(k)}$ y $w^{(k)} = C^{-1} r^{(k)}$. Entonces

$$\tilde{s}_k = \frac{\langle \tilde{r}^{(k)}, \tilde{r}^{(k)} \rangle}{\langle \tilde{r}^{(k-1)}, \tilde{r}^{(k-1)} \rangle} = \frac{\langle C^{-1} r^{(k)}, C^{-1} r^{(k)} \rangle}{\langle C^{-1} r^{(k-1)}, C^{-1} r^{(k-1)} \rangle},$$

de modo que

$$\tilde{s}_k = \frac{\langle w^{(k)}, w^{(k)} \rangle}{\langle w^{(k-1)}, w^{(k-1)} \rangle}. \quad (7.31)$$

Así,

$$\tilde{i}_k = \frac{\langle \tilde{r}^{(k-1)}, \tilde{r}^{(k-1)} \rangle}{\langle \tilde{v}^{(k)}, \tilde{A} \tilde{v}^{(k)} \rangle} = \frac{\langle C^{-1} r^{(k-1)}, C^{-1} r^{(k-1)} \rangle}{\langle C^t v^{(k)}, C^{-1} A C^{-1} C^t v^{(k)} \rangle} = \frac{\langle w^{(k-1)}, w^{(k-1)} \rangle}{\langle C^t v^{(k)}, C^{-1} A v^{(k)} \rangle}$$

y

$$\tilde{i}_k = \frac{\langle w^{(k-1)}, w^{(k-1)} \rangle}{\langle v^{(k)}, A v^{(k)} \rangle}. \quad (7.32)$$

Además,

$$\tilde{x}^{(k)} = \tilde{x}^{(k-1)} + \tilde{i}_k \tilde{v}^{(k)}, \quad \text{de modo que} \quad C^t x^{(k)} = C^t x^{(k-1)} + \tilde{i}_k C^t v^{(k)}$$

y

$$x^{(k)} = x^{(k-1)} + \tilde{i}_k v^{(k)}. \quad (7.33)$$

Continuando de esta forma,

$$\tilde{\mathbf{r}}^{(k)} = \tilde{\mathbf{r}}^{(k-1)} - \tilde{t}_k \tilde{A} \tilde{\mathbf{v}}^{(k)},$$

de modo que

$$C^{-1} \mathbf{r}^{(k)} = C^{-1} \mathbf{r}^{(k-1)} - \tilde{t}_k C^{-1} A C^{-1} \tilde{\mathbf{v}}^{(k)}, \quad \mathbf{r}^{(k)} = \mathbf{r}^{(k-1)} - \tilde{t}_k A C^{-1} C \mathbf{v}^{(k)},$$

y

$$\mathbf{r}^{(k)} = \mathbf{r}^{(k-1)} - \tilde{t}_k A \mathbf{v}^{(k)}. \quad (7.34)$$

Por último,

$$\tilde{\mathbf{v}}^{(k+1)} = \tilde{\mathbf{r}}^{(k)} + \tilde{s}_k \tilde{\mathbf{v}}^{(k)} \quad \text{y} \quad C \mathbf{v}^{(k+1)} = C^{-1} \mathbf{r}^{(k)} + \tilde{s}_k C \mathbf{v}^{(k)},$$

y así

$$\mathbf{v}^{(k+1)} = C^{-1} C^{-1} \mathbf{r}^{(k)} + \tilde{s}_k \mathbf{v}^{(k)} = C^{-1} \mathbf{w}^{(k)} + \tilde{s}_k \mathbf{v}^{(k)}. \quad (7.35)$$

El método del gradiente conjugado preconditionado se basa en el uso de las ecuaciones (7.31) a (7.35) en el orden (7.32), (7.33), (7.34), (7.31), (7.35). El algoritmo 7.5 implanta este procedimiento.

ALGORITMO 7.5

Método del gradiente conjugado preconditionado

Para resolver $A\mathbf{x} = \mathbf{b}$ dada la matriz de preconditionamiento C^{-1} y la aproximación inicial $\mathbf{x}^{(0)}$;

ENTRADA el número de ecuaciones e incógnitas n ; las entradas a_{ij} , $1 \leq i, j \leq n$ de la matriz A ; las entradas b_j , $1 \leq j \leq n$ del vector $\mathbf{b}$; las entradas γ_{ij} , $1 \leq i, j \leq n$ de la matriz de preconditionamiento C^{-1} , las entradas x_j , $1 \leq j \leq n$ de la aproximación inicial $\mathbf{x} = \mathbf{x}^{(0)}$, el número máximo de iteraciones N ; tolerancia TOL .

SALIDA la solución aproximada $x_1, \dots, x_n$ y el residual $r_1, \dots, r_n$ o un mensaje indicando que ha excedido el número de iteraciones

Paso 1 Tome $\mathbf{r} = \mathbf{b} - A\mathbf{x}$; (Calcule $\mathbf{r}^{(0)}$.)

$\mathbf{w} = C^{-1}\mathbf{r}$; (Nota: $\mathbf{w} = \mathbf{w}^{(0)}$)

$\mathbf{v} = C^{-t}\mathbf{w}$; (Nota: $\mathbf{v} = \mathbf{v}^{(1)}$)

$\alpha = \sum_{j=1}^n w_j^2$

Paso 2 Tome $k = 1$.

Paso 3 Mientras ($k \leq N$) haga los pasos 4-7.

Paso 4 Si $\|\mathbf{v}\| < TOL$, entonces

SALIDA ('Vector solución'; $x_1, \dots, x_n$);

SALIDA ('con residual'; $r_1, \dots, r_n$);

(El procedimiento tuvo éxito.)

PARAR.

Paso 5 Tome $\mathbf{u} = A\mathbf{v}$; (Nota: $\mathbf{u} = A\mathbf{v}^{(k)}$)

$$t = \frac{\alpha}{\sum_{j=1}^n v_j u_j}; \quad (\text{Nota: } t = t_k)$$

$$\begin{aligned} \mathbf{x} &= \mathbf{x} + t \mathbf{v}; \text{ (Nota: } \mathbf{x} = \mathbf{x}^{(k)}) \\ \mathbf{r} &= \mathbf{r} - t \mathbf{u}; \text{ (Nota: } \mathbf{r} = \mathbf{r}^{(k)}) \\ \mathbf{w} &= \mathbf{C}^{-1} \mathbf{r}; \text{ (Nota: } \mathbf{w} = \mathbf{w}^{(k)}) \\ \beta &= \sum_{j=1}^n w_j^2. \text{ (Nota: } \beta = \langle \mathbf{w}^{(k)}, \mathbf{w}^{(k)} \rangle) \end{aligned}$$

Paso 6 Si $|\beta| < TOL$ entonces

si $\|\mathbf{r}\| < TOL$ entonces

SALIDA ('Vector solución'; $x_1, \dots, x_n$);

SALIDA('con residual'; $r_1, \dots, r_n$);

(El procedimiento tuvo éxito).

PARAR.

Paso 7 Tome $s = \beta/\alpha$; ($s = s_k$)

$\mathbf{v} = \mathbf{C}^{-1} \mathbf{w} + s \mathbf{v}$; (Nota: $\mathbf{v} = \mathbf{v}^{(k+1)}$)

$\alpha = \beta$; (Actualice α .)

$k = k + 1$.

Paso 8 Si $(k > n)$ entonces

SALIDA ('Se ha excedido el número máximo de iteraciones.');

(El procedimiento no tuvo éxito.)

PARAR.

El siguiente ejemplo ilustra los cálculos en un problema sencillo.

EJEMPLO 2 El sistema lineal $A\mathbf{x} = \mathbf{b}$ dado por

$$\begin{aligned} 4x_1 + 3x_2 &= 24, \\ 3x_1 + 4x_2 - x_3 &= 30, \\ -x_2 + 4x_3 &= -24 \end{aligned}$$

tiene la solución $(3, 4, -5)^T$ y fue considerada en el ejemplo 3 de la sección 7.3. En ese ejemplo se usaron el método de Gauss-Seidel y el método SOR. Usaremos el método del gradiente conjugado sin preconditionamiento, de modo que $\mathbf{C} = \mathbf{C}^{-1} = \mathbf{I}$. Sea $\mathbf{x}^{(0)} = (0, 0, 0)^T$. Entonces

$$\mathbf{r}^{(0)} = \mathbf{b} - A\mathbf{x}^{(0)} = \mathbf{b} = (24, 30, -24)^T;$$

$$\mathbf{w} = \mathbf{C}^{-1} \mathbf{r}^{(0)} = (24, 30, -24)^T;$$

$$\mathbf{v}^{(1)} = \mathbf{C}^{-1} \mathbf{w} = (24, 30, -24)^T;$$

$$\alpha = \langle \mathbf{w}, \mathbf{w} \rangle = 2052.$$

Comenzamos la primera iteración con $k = 1$. Entonces

$$\mathbf{u} = A\mathbf{v}^{(1)} = (186.0, 216.0, -126.0)^T;$$

$$t_1 = \frac{\alpha}{\langle \mathbf{v}^{(1)}, \mathbf{u} \rangle} = 0.1469072165;$$

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + t_1 \mathbf{v}^{(1)} = (3.525773196, 4.407216495, -3.525773196)^T;$$

$$\mathbf{r}^{(1)} = \mathbf{r}^{(0)} - t_1 \mathbf{u} = (-3.32474227, -1.73195876, -5.48969072)^T;$$

$$\mathbf{w} = \mathbf{C}^{-1} \mathbf{r}^{(1)} = \mathbf{r}^{(1)};$$

$$\beta = \langle \mathbf{w}, \mathbf{w} \rangle = 44.19029651;$$

$$s_1 = \frac{\beta}{\alpha} = 0.02153523222;$$

$$\mathbf{v}^{(2)} = \mathbf{C}^{-1} \mathbf{w} + s_1 \mathbf{v}^{(1)} = (-2.807896697, -1.085901793, -6.006536293)^T;$$

Tome

$$\alpha = \beta = 44.19029651.$$

Ahora podemos iniciar la segunda iteración. Tenemos

$$\mathbf{u} = \mathbf{A} \mathbf{v}^{(2)} = (-14.48929217, -6.760760967, -22.94024338)^T;$$

$$t_2 = 0.2378157558;$$

$$\mathbf{x}^{(2)} = (2.858011121, 4.148971939, -4.954222164)^T;$$

$$\mathbf{r}^{(2)} = (0.121039698, -0.124143281, -0.034139402)^T;$$

$$\mathbf{w} = \mathbf{C}^{-1} \mathbf{r}^{(2)} = \mathbf{r}^{(2)};$$

$$\beta = 0.03122766148;$$

$$s_2 = 0.0007066633163;$$

$$\mathbf{v}^{(3)} = (0.1190554504, -0.1249106480, -0.03838400086)^T.$$

Tome

$$\alpha = \beta = 0.03122766148.$$

Por último, la tercera iteración da

$$\mathbf{u} = \mathbf{A} \mathbf{v}^{(3)} = (0.1014898976, -0.1040922099, -0.0286253554)^T;$$

$$t_3 = 1.192628008;$$

$$\mathbf{x}^{(3)} = (2.999999998, 4.000000002, -4.999999998)^T;$$

$$\mathbf{r}^{(3)} = (0.36 \times 10^{-8}, 0.39 \times 10^{-8}, -0.141 \times 10^{-8})^T.$$

Como $\mathbf{x}^{(3)}$ es casi la solución exacta, el error de redondeo no afectó de manera significativa el resultado. En el ejemplo 3 de la sección 7.3, el método de Gauss-Seidel requirió 34 iteraciones, y el método SOR, con $\omega = 1.25$, requirió 14 iteraciones para una precisión de 10^{-7} . Sin embargo, debemos destacar que en este ejemplo estamos comparando en realidad un método directo con métodos iterativos. ■

El siguiente ejemplo ilustra el efecto del preconditionamiento en una matriz pobremente condicionada. En este ejemplo y en lo sucesivo, $D^{-1/2}$ representará la matriz dia-

gonal cuyas entradas son los recíprocos de las raíces cuadradas de las entradas diagonales de la matriz de coeficientes A .

EJEMPLO 3 El sistema lineal $A\mathbf{x} = \mathbf{b}$ con

$$A = \begin{bmatrix} 0.2 & 0.1 & 1 & 1 & 0 \\ 0.1 & 4 & -1 & 1 & -1 \\ 1 & -1 & 60 & 0 & -2 \\ 1 & 1 & 0 & 8 & 4 \\ 0 & -1 & -2 & 4 & 700 \end{bmatrix} \quad \text{y} \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix}$$

tiene la solución

$$\mathbf{x}^* = (7.859713071, 0.4229264082, -0.07359223906, -0.5406430164, 0.01062616286)^T.$$

La matriz A es simétrica y definida positiva, pero está mal condicionada, con número de condición $K_\infty(A) = 13961.71$. Usaremos la tolerancia 0.01 y compararemos los resultados obtenidos con los métodos iterativos de Jacobi, Gauss-Seidel y SOR (con $\omega = 1.25$) y con el método del gradiente conjugado, con $C^{-1} = I$. Luego establecemos el preconditionamiento eligiendo C^{-1} como $D^{-1/2}$, la matriz cuyas entradas diagonales son los recíprocos de las raíces cuadradas de las entradas diagonales de la matriz definida positiva A . Los resultados aparecen en la tabla 7.5. El método del gradiente conjugado preconditionado da la aproximación más precisa con el menor número de iteraciones. ■

Tabla 7.5

Método	Número de iteraciones	$\mathbf{x}^{(k)}$	$\ \mathbf{x}^* - \mathbf{x}^{(k)}\ _\infty$
Jacobi	49	(7.86277141, 0.42320802, -0.07348669, -0.53975964, 0.01062847) ^T	0.00305834
Gauss-Seidel	15	(7.83525748, 0.42257868, -0.07319124, -0.53753055, 0.01060903) ^T	0.02445559
SOR ($\omega = 1.25$)	7	(7.85152706, 0.42277371, -0.07348303, -0.53978369, 0.01062286) ^T	0.00818607
Gradiente conjugado	5	(7.85341523, 0.42298677, -0.07347963, -0.53987920, 0.008628916) ^T	0.00629785
Gradiente conjugado (Precondicionado)	4	(7.85968827, 0.42288329, -0.07359878, -0.54063200, 0.01064344) ^T	0.00009312

Con frecuencia, el método del gradiente conjugado preconditionado se usa en la solución de sistemas lineales de gran tamaño, con una matriz esparcida y definida positiva. Estos sistemas deben resolverse para aproximar soluciones de problemas con valores en la frontera en ecuaciones diferenciales ordinarias (secciones 11.3, 11.4, 11.5). Mientras más grande sea el sistema, más impresionante será el método del gradiente conjugado, pues reduce de manera significativa el número de iteraciones necesarias. En estos sistemas, la matriz de preconditionamiento C es aproximadamente igual a L en la factorización de Choleski LL^T de A . Por lo general, las entradas pequeñas de A se ignoran y se aplica el método de Choleski para obtener lo que se llama una factorización incompleta LL^T de A . Así, $C^{-1}C^{-1} \approx A^{-1}$ y se obtiene una buena aproximación. En Kelley [Kelley] se puede obtener más información acerca del método del gradiente conjugado.

CONJUNTO DE EJERCICIOS 7.5

1. El sistema lineal

$$\begin{aligned}x_1 + \frac{1}{2}x_2 &= \frac{5}{21}, \\ \frac{1}{2}x_1 + \frac{1}{3}x_2 &= \frac{11}{84}\end{aligned}$$

tiene la solución $(x_1, x_2)^T = (1/6, 1/7)^T$.

- Resuelva el sistema lineal mediante una eliminación gaussiana, con aritmética de redondeo a dos dígitos.
- Resuelva el sistema lineal mediante el método del gradiente conjugado ($C = C^{-1} = I$) con una aritmética de redondeo a dos dígitos.
- ¿Cuál método da la mejor respuesta?
- Elija $C^{-1} = D^{-1/2}$. ¿Mejora esta elección al método del gradiente conjugado?

2. El sistema lineal

$$\begin{aligned}0.1x_1 + 0.2x_2 &= 0.3, \\ 0.2x_1 + 113x_2 &= 113.2\end{aligned}$$

tiene la solución $(x_1, x_2)^T = (1, 1)^T$. Repita las instrucciones del ejercicio 1 para este sistema lineal.

3. El sistema lineal

$$\begin{aligned}x_1 + \frac{1}{2}x_2 + \frac{1}{3}x_3 &= \frac{5}{6}, \\ \frac{1}{2}x_1 + \frac{1}{3}x_2 + \frac{1}{4}x_3 &= \frac{5}{12}, \\ \frac{1}{3}x_1 + \frac{1}{4}x_2 + \frac{1}{5}x_3 &= \frac{17}{60}\end{aligned}$$

tiene la solución $(1, -1, 1)^T$.

- Resuelva el sistema lineal mediante eliminación gaussiana, con aritmética de redondeo a tres dígitos.
 - Resuelva el sistema lineal mediante el método del gradiente conjugado con una aritmética de redondeo a tres dígitos.
 - ¿Mejora el pivoteo la respuesta en (a)?
 - Repita la parte (b) con $C^{-1} = D^{-1/2}$. ¿Mejora esto la respuesta en (b)?
4. Repita el ejercicio 3 usando la aritmética de precisión simple en una computadora.
5. Realice sólo dos pasos del método del gradiente conjugado con $C = C^{-1} = I$ en cada uno de los siguientes sistemas lineales. Compare los resultados de las partes (b), (c), (d) y (f) con los obtenidos en los ejercicios 1, 2 y 5 de la sección 7.3.

$$\begin{aligned}\text{a. } 3x_1 - x_2 + x_3 &= 1, \\ -x_1 + 6x_2 + 2x_3 &= 0, \\ x_1 + 2x_2 + 7x_3 &= 4,\end{aligned}$$

$$\begin{aligned}\text{c. } 10x_1 + 5x_2 &= 6, \\ 5x_1 + 10x_2 - 4x_3 &= 25, \\ -4x_2 + 8x_3 - x_4 &= -11, \\ -x_3 + 5x_4 &= -11.\end{aligned}$$

$$\begin{aligned}\text{b. } 10x_1 - x_2 &= 9, \\ -x_1 + 10x_2 - 2x_3 &= 7, \\ -2x_2 + 10x_3 &= 6.\end{aligned}$$

$$\begin{aligned}\text{d. } 4x_1 + x_2 - x_3 + x_4 &= -2, \\ x_1 + 4x_2 - x_3 - x_4 &= -1, \\ -x_1 - x_2 + 5x_3 + x_4 &= 0, \\ x_1 - x_2 + x_3 + 3x_4 &= 1.\end{aligned}$$

$$\begin{aligned} \text{e. } 4x_1 + x_2 + x_3 + x_5 &= 6, \\ x_1 + 3x_2 + x_3 + x_4 &= 6, \\ x_1 + x_2 + 5x_3 - x_4 - x_5 &= 6, \\ x_2 - x_3 + 4x_4 &= 6, \\ x_1 - x_3 + x_5 &= 6. \end{aligned}$$

$$\begin{aligned} \text{f. } 4x_1 - x_2 - x_4 &= 0, \\ -x_1 + 4x_2 - x_3 - x_5 &= 5, \\ -x_2 + 4x_3 - x_6 &= 0, \\ -x_1 + 4x_4 - x_5 &= 6, \\ -x_2 - x_4 + 4x_5 - x_6 &= -2, \\ -x_3 - x_5 + 4x_6 &= 6. \end{aligned}$$

6. Repita el ejercicio 5 con $C^{-1} = D^{-1/2}$.
7. Repita el ejercicio 5 con $TOL = 10^{-3}$ en la norma l_∞ . Compare los resultados de las partes (b), (c), (d) y (f) con los obtenidos en los ejercicios 3, 4 y 7 de la sección 7.3.
8. Repita el ejercicio 7 con $C^{-1} = D^{-1/2}$.
9. Use (i) el método de Jacobi, (ii) el método de Gauss-Seidel, (iii) el método SOR con $\omega = 1.3$ y (iv) el método del gradiente conjugado con preconditionamiento y $C^{-1} = D^{-1/2}$ para encontrar soluciones del sistema lineal $Ax = b$ con una precisión de 10^{-5} en la norma l_∞ .

a.

$$a_{i,j} = \begin{cases} 4, & \text{si } j = i \text{ e } i = 1, 2, \dots, 16, \\ -1, & \text{si } \begin{cases} j = i + 1 \text{ e } i = 1, 2, 3, 5, 6, 7, 9, 10, 11, 13, 14, 15, \\ j = i - 1 \text{ e } i = 2, 3, 4, 6, 7, 8, 10, 11, 12, 14, 15, 16, \\ j = i + 4 \text{ e } i = 1, 2, \dots, 12, \\ j = i - 4 \text{ e } i = 5, 6, \dots, 16, \end{cases} \\ 0, & \text{en otro caso} \end{cases}$$

y

$$b = (1.902207, 1.051143, 1.175689, 3.480083, 0.819600, -0.264419, \\ -0.412789, 1.175689, 0.913337, -0.150209, -0.264419, 1.051143, \\ 1.966694, 0.913337, 0.819600, 1.902207)$$

b.

$$a_{i,j} = \begin{cases} 4, & \text{si } j = i \text{ e } i = 1, 2, \dots, 25, \\ \begin{cases} j = i + 1 \text{ e } i = \{1, 2, 3, 4, 6, 7, 8, 9, 11, 12, 13, 14, \\ 16, 17, 18, 19, 21, 22, 23, 24, \} \\ j = i - 1 \text{ e } i = \{2, 3, 4, 5, 7, 8, 9, 10, 12, 13, 14, 15, \\ 17, 18, 19, 20, 22, 23, 24, 25, \} \\ j = i + 5 \text{ e } i = 1, 2, \dots, 20, \\ j = i - 5 \text{ e } i = 6, 7, \dots, 25, \end{cases} \\ 0, & \text{en otro caso} \end{cases}$$

y

$$\mathbf{b} = (1, 0, -1, 0, 2, 1, 0, -1, 0, 2, 1, 0, -1, 0, 2, 1, 0, -1, 0, 2, 1, 0, -1, 0, 2)^T$$

c.

$$a_{ij} = \begin{cases} 2i, & \text{si } j = i \text{ e } i = 1, 2, \dots, 40, \\ -1, & \text{si } \begin{cases} j = i + 1 \text{ e } i = 1, 2, \dots, 39, \\ j = i - 1 \text{ e } i = 2, 3, \dots, 40, \end{cases} \\ 0, & \text{en otro caso} \end{cases}$$

$$\text{y } b_i = 1.5i - 6, \text{ para cada } i = 1, 2, \dots, 40.$$

10. Resuelva el sistema lineal del ejercicio 12(a) y (b) de la sección 7.3 usando el método del gradiente conjugado con $C^{-1} = I$.
11. Sean

$$A_1 = \begin{bmatrix} 4 & -1 & 0 & 0 \\ -1 & 4 & -1 & 0 \\ 0 & -1 & 4 & -1 \\ 0 & 0 & -1 & 4 \end{bmatrix}, \quad -I = \begin{bmatrix} -1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & -1 \end{bmatrix},$$

$$\text{y } \mathbf{0} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

Forme la matriz A de 16×16 con la siguiente partición.

$$A = \begin{bmatrix} A_1 & -I & 0 & 0 \\ -I & A_1 & -I & 0 \\ 0 & -I & A_1 & -I \\ 0 & 0 & -I & A_1 \end{bmatrix}.$$

$$\text{Sea } \mathbf{b} = (1, 2, 3, 4, 5, 6, 7, 8, 9, 0, 1, 2, 3, 4, 5, 6)^T.$$

- a. Resuelva $A\mathbf{x} = \mathbf{b}$ usando el método del gradiente conjugado con tolerancia 0.05.
- b. Resuelva $A\mathbf{x} = \mathbf{b}$ usando el método del gradiente conjugado preconditionado con $C^{-1} = D^{-1/2}$ y tolerancia 0.05.
- c. ¿Existe alguna tolerancia para la cual los métodos de la parte (a) y la (b) requieran un número distinto de iteraciones?
12. Use las propiedades de la transpuesta dadas en el teorema 6.13 para demostrar el teorema 7.30.
13. a. Muestre que un conjunto A -ortogonal de vectores no nulos asociados con una matriz definida positiva es linealmente independiente.
- b. Muestre que si $\{\mathbf{v}^{(1)}, \mathbf{v}^{(2)}, \dots, \mathbf{v}^{(n)}\}$ es un conjunto de vectores A -ortogonales no nulos en $\mathbb{R}^n$ y $\mathbf{z}^T \mathbf{v}^{(i)} = 0$, para cada $i = 1, 2, \dots, n$, entonces $\mathbf{z} = \mathbf{0}$.
14. Demuestre el teorema 7.33 usando inducción matemática, como sigue:
- a. Muestre que $\langle \mathbf{r}^{(1)}, \mathbf{v}^{(1)} \rangle = 0$.
- b. Suponga que $\langle \mathbf{r}^{(k)}, \mathbf{v}^{(j)} \rangle = 0$, para cada $k \leq l$ and $j = 1, 2, \dots, k$ y muestre que esto implica que $\langle \mathbf{r}^{(l+1)}, \mathbf{v}^{(j)} \rangle = 0$, para cada $j = 1, 2, \dots, l$.
- c. Muestre que $\langle \mathbf{r}^{(l+1)}, \mathbf{v}^{(l+1)} \rangle = 0$.

7.6 Reseña de métodos y de software

En este capítulo estudiamos los métodos iterativos para aproximar la solución de los sistemas lineales. Comenzamos con el método de Jacobi y el de Gauss-Seidel, como una introducción a estos métodos. Ambas técnicas requieren una aproximación inicial arbitraria $\mathbf{x}^{(0)}$ y generan una secuencia de vectores $\mathbf{x}^{(i+1)}$ utilizando la ecuación de la forma

$$\mathbf{x}^{(i+1)} = T\mathbf{x}^{(i)} + \mathbf{c}.$$

Se señaló que el método convergerá si y sólo si el radio espectral de la matriz de iteración $\rho(T) < 1$ y que, cuanto más pequeño sea el radio espectral, más rápida será la convergencia. El análisis de los vectores residuales del método de Gauss-Seidel culminó en el método iterativo SOR, el cual involucra un parámetro ω que acelera la convergencia.

Estos métodos iterativos y modificaciones se emplean ampliamente en la resolución de los sistemas lineales que se presentan en la solución numérica de los problemas relacionados con el valor de frontera y de las ecuaciones diferenciales parciales (véanse los capítulos, 11 y 12). A menudo estos sistemas son extensos, con más de 10 000 ecuaciones con 10 000 incógnitas y se encuentran esparcidas con sus elementos distintos de cero en posiciones predecibles. Los métodos iterativos también son útiles en otros sistemas grandes esparcidos y es fácil adaptarlos para aprovecharlos eficientemente en las computadoras en paralelo.

Casi todos los paquetes comerciales y de dominio público que contienen métodos iterativos para resolver un sistema lineal de ecuaciones requieren un preconditionamiento para su método. Con frecuencia, se logra una convergencia más rápida de los casos iterativos introduciendo un preconditionamiento; éste produce un sistema equivalente de ecuaciones que, esperamos, exhiba mejores características de convergencia que el sistema original. La biblioteca IMSL tiene la subrutina PCGRC, que es un método de gradiente conjugado preconditionado. La biblioteca NAG tiene varias subrutinas con el prefijo F11 para resolver sistemas lineales en forma iterativa. Todas las subrutinas se basan en subespacios de Krylov. Saad [Sa2] tiene una descripción detallada de los métodos con subespacios de Krylov. Los paquetes LINPACK y LAPACK contienen sólo métodos directos para resolver sistemas lineales; sin embargo, los paquetes contienen muchas subrutinas que son utilizadas por los paquetes iterativos. Los paquetes de dominio público IML++, ITPACK, SLAP y Templates contienen métodos iterativos. MATLAB contiene varios métodos iterativos que también se basan en subespacios de Krylov. Por ejemplo, el comando $x = \text{PCG}(A, b)$ ejecuta el método del gradiente conjugado preconditionado para resolver el sistema lineal $Ax = b$. Algunos de los parámetros opcionales de entrada de PCG son: TOL, una tolerancia para la convergencia; MAXIT, el número máximo de iteraciones; y M para el preconditionamiento.

Los conceptos de número de condición y de matriz mal condicionadas se expusieron en la sección 7.4. Muchas de las subrutinas con que se resuelve un sistema lineal o se factoriza una matriz con la factorización LU contienen verificaciones para las matrices mal condicionadas y además ofrecen una estimación del número de condición.

La subrutina SGETRF de LAPACK factoriza la matriz real A en una factorización LU, proporcionando además el ordenamiento de renglones para la matriz de permutación P , donde $PA = LU$. La subrutina SGECON también ofrece el número de condición de A . LAPACK cuenta con otras subrutinas para matrices especiales; por ejemplo, SPOTRF efectúa la factorización de Choleski para una matriz definida, positiva A y SPOCON estima el recíproco del número de condición usando la factorización de Choleski calculada por SPOTRF.

La biblioteca IMSL tiene subrutinas que estiman el número de condición. Por ejemplo, la subrutina LFCRG calcula la factorización LU ; $PA = LU$ de la matriz A y además ofrece una estimación del número de condición. La biblioteca NAG dispone de subrutinas semejantes.



LAPACK, LINPACK, la biblioteca IMSL y la biblioteca NAG cuentan con subrutinas que mejoran una solución de un sistema lineal mal condicionado. Las subrutinas prueban el número de condición y después usan el refinamiento iterativo para obtener la solución más exacta posible con la precisión que ofrece la computadora.

El lector que desee más información sobre los métodos iterativos con que se resuelven los sistemas lineales, puede consultar en Varga [Var], Young [Y], Hageman y Young [HY] y el libro reciente de Axelsson [Ax]. Los métodos iterativos para sistemas grandes esparcidos se describen en Barrett y otros autores [Barr], Hackbusch [Hac] Kelley [Kelley] y Saad [Sa2].

Teoría de la aproximación

• • •

La ley de Hooke establece que, cuando se aplica una fuerza a un resorte fabricado de material uniforme, la longitud del resorte es una función lineal de la fuerza aplicada. Podemos escribir la función lineal como $F(l) = k(l - E)$, donde $F(l)$ representa la fuerza requerida para extender el resorte l unidades, la constante E representa la longitud del resorte sin que se aplique fuerza alguna y la constante k es la constante del resorte.



Supongamos que queremos determinar la constante de un resorte cuya longitud inicial es de 5.3 plg. Aplicamos al resorte las fuerzas de 2, 4 y 6 lb consecutivamente y observamos que su longitud aumenta a 7.0, 9.4 y 12.3 plg, respectivamente. Un análisis rápido muestra que los puntos (0, 5.3), (2, 7.0), (4, 9.4) y (6, 12.3) no se encuentran exactamente en una línea recta. Aunque podríamos utilizar un par aleatorio de estos puntos de datos para aproximar la



constante del resorte, parecería más razonable obtener la línea que aproxime *mejor* todos los puntos de datos para determinar la constante. En el capítulo que ahora nos ocupa estudiaremos este tipo de aproximación; la aplicación del resorte se incluye en el ejercicio 7 de la sección 8.1.

El estudio de la teoría de la aproximación comprende dos tipos generales de problemas. Uno se presenta cuando una función se da de manera explícita, pero queremos encontrar un tipo "más simple" de ella —un polinomio, por ejemplo— que nos sirva para determinar los valores aproximados de una función dada. El otro problema de la teoría se refiere a la adaptación de las funciones a ciertos datos y a la búsqueda de la función "óptima" en una clase que podamos emplear para representar los datos.

En el capítulo 3 nos ocupamos de ambos problemas. El polinomio de Taylor de grado n alrededor del número x_0 constituye una excelente aproximación a una función f diferenciable multiplicada por $(n + 1)$ en una pequeña vecindad de x_0 . Los polinomios interpolantes de Lagrange o, más generalmente, los polinomios oscilantes se trataron como polinomios de aproximación y como polinomios para ajustar determinados datos. En ese capítulo explicamos los trazadores cúbicos, las limitaciones para estas técnicas, y también se tratan otras rutas de crecimiento.

8.1 Aproximación discreta por mínimos cuadrados

Consideremos el problema de estimar los valores de una función en puntos no tabulados, si contamos con los datos experimentales de la tabla 8.1.

Tabla 8.1

x_i	y_i	x_i	y_i
1	1.3	6	8.8
2	3.5	7	10.1
3	4.2	8	12.5
4	5.0	9	13.0
5	7.0	10	15.6

La figura 8.1 muestra una gráfica de los valores de la tabla 8.1. Esta gráfica sugiere que la relación real entre x y y es lineal. La razón probable de que ninguna recta se ajuste a estos datos es que éstos tienen cierto error: no es razonable exigir que la función de aproximación coincida exactamente con los datos. De hecho, tal función introduciría oscilaciones que no estaban presentes en un inicio. Por ejemplo, el polinomio de interpolación de noveno grado para los datos que aparecen en la figura 8.2 se obtiene en Maple mediante los comandos

```
>p:=interp([1,2,3,4,5,6,7,8,9,10],
           [1.3,3.5,4.2,5.0,7.0,8.8,10.1,12.5,13.0,15.6],x);
>plot((p),x=1..10);
```

Es claro que este polinomio es un mal predictor de la información entre varios de los puntos de dato. Sería mejor encontrar la "mejor" (en cierto sentido) recta de aproximación, aunque ésta no coincida con los datos en punto alguno.

Figura 8.1





Figura 8.2



Sea $a_1x_i + a_0$ el i -ésimo valor de la recta de aproximación y y_i el i -ésimo valor dado para y . El problema de determinar la ecuación de la mejor aproximación lineal en el sentido absoluto consiste en hallar los valores de a_0 y a_1 que minimicen

$$E_\infty(a_0, a_1) = \max_{1 \leq i \leq 10} |y_i - (a_1x_i + a_0)|.$$

A lo anterior comúnmente se le llama problema **minimax**, y no se puede resolver mediante métodos elementales.

Otro método para determinar la mejor aproximación lineal implica hallar los valores de a_0 y a_1 que minimicen

$$E_1(a_0, a_1) = \sum_{i=1}^{10} |y_i - (a_1 x_i + a_0)|.$$

Esta cantidad se llama **desviación absoluta**. Para minimizar una función de dos variables, necesitamos igualar a cero sus derivadas parciales y resolver en forma simultánea las ecuaciones resultantes. En el caso de la desviación absoluta, necesitamos hallar a_0 y a_1 tales que

$$0 = \frac{\partial}{\partial a_0} \sum_{i=1}^{10} |y_i - (a_1 x_i + a_0)| \quad \text{y} \quad 0 = \frac{\partial}{\partial a_1} \sum_{i=1}^{10} |y_i - (a_1 x_i + a_0)|.$$

La complejidad de este procedimiento radica en que la función valor absoluto no es derivable en cero, y no necesariamente se pueden obtener las soluciones de este par de ecuaciones.

El método de **mínimos cuadrados** para resolver este problema requiere determinar la mejor línea de aproximación, cuando el error es la suma de los cuadrados de las diferencias entre los valores de y en la línea aproximación y los valores de y dados. Por tanto, hay que encontrar las constantes a_0 y a_1 que reduzcan al mínimo el error de mínimos cuadrados:

$$E_2(a_0, a_1) = \sum_{i=1}^{10} [y_i - (a_1 x_i + a_0)]^2.$$

El método de mínimos cuadrados es el procedimiento más adecuado para determinar las mejores aproximaciones lineales, pero hay importantes consideraciones teóricas que lo favorecen. El método minimax generalmente le da demasiado valor relativo a un pequeño elemento de datos que contiene un gran error. El método que utiliza la desviación absoluta simplemente promedia el error en varios puntos, sin dar suficiente valor relativo a un punto que está muy alejado de la aproximación. El método de mínimos cuadrados concede mayor valor relativo al punto que está alejado del resto de los datos, pero no permitirá que ese punto domine enteramente la aproximación. Una razón más para explicar el método de mínimos cuadrados es estudiar la distribución estadística del error. (Véase [Lar, pp. 463-481].)

El problema general de ajustar la mejor recta con mínimos cuadrados a una colección de datos $\{(x_i, y_i)\}_{i=1}^m$ implica minimizar el error total,

$$E = E_2(a_0, a_1) = \sum_{i=1}^m [y_i - (a_1 x_i + a_0)]^2,$$

con respecto a los parámetros a_0 y a_1 . Para que haya un mínimo, debemos tener

$$0 = \frac{\partial}{\partial a_0} \sum_{i=1}^m [y_i - (a_1 x_i + a_0)]^2 = 2 \sum_{i=1}^m (y_i - a_1 x_i - a_0) (-1)$$

y

$$0 = \frac{\partial}{\partial a_1} \sum_{i=1}^m [y_i - (a_1 x_i + a_0)]^2 = 2 \sum_{i=1}^m (y_i - a_1 x_i - a_0) (-x_i).$$

Estas ecuaciones se simplifican en las ecuaciones normales:

$$a_0 \cdot m + a_1 \sum_{i=1}^m x_i = \sum_{i=1}^m y_i \quad \text{y} \quad a_0 \sum_{i=1}^m x_i + a_1 \sum_{i=1}^m x_i^2 = \sum_{i=1}^m x_i y_i.$$

La solución de este sistema de ecuaciones es

$$a_0 = \frac{\sum_{i=1}^m x_i^2 \sum_{i=1}^m y_i - \sum_{i=1}^m x_i y_i \sum_{i=1}^m x_i}{m \left(\sum_{i=1}^m x_i^2 \right) - \left(\sum_{i=1}^m x_i \right)^2} \quad (8.1)$$

y

$$a_1 = \frac{m \sum_{i=1}^m x_i y_i - \sum_{i=1}^m x_i \sum_{i=1}^m y_i}{m \left(\sum_{i=1}^m x_i^2 \right) - \left(\sum_{i=1}^m x_i \right)^2}. \quad (8.2)$$

EJEMPLO 1 Considere los datos de la tabla 8.1. Obtenga la línea de mínimos cuadrados que aproxima estos datos, extendiendo la tabla y sumando las columnas como se indica en las columnas tercera y cuarta de la tabla 8.2.

Tabla 8.2

x_i	y_i	x_i^2	$x_i y_i$	$P(x_i) = 1.538x_i - 0.360$
1	1.3	1	1.3	1.18
2	3.5	4	7.0	2.72
3	4.2	9	12.6	4.25
4	5.0	16	20.0	5.79
5	7.0	25	35.0	7.33
6	8.8	36	52.8	8.87
7	10.1	49	70.7	10.41
8	12.5	64	100.0	11.94
9	13.0	81	117.0	13.48
10	15.6	100	156.0	15.02
55	81.0	385	572.4	$E = \sum_{i=1}^{10} (y_i - P(x_i))^2 \approx 2.34$

Las ecuaciones normales (8.1) y (8.2) implican que


$$a_0 = \frac{385(81) - 55(572.4)}{10(385) - (55)^2} = -0.360$$

y que

$$a_1 = \frac{10(572.4) - 55(81)}{10(385) - (55)^2} = 1.538,$$

de modo que $P(x) = 1.538x - 0.360$. En la figura 8.3 se muestran la gráfica de esta línea y los puntos de datos. En la tabla 8.2 se incluyen los valores aproximados obtenidos con el método de mínimos cuadrados en los puntos de datos. ■

Figura 8.3



De modo similar se resuelve el problema general de aproximar un conjunto de datos $\{(x_i, y_i) \mid i = 1, 2, \dots, m\}$, con un polinomio algebraico

$$P_n(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0.$$

De grado $n < m - 1$ mediante el procedimiento de mínimos cuadrados. Para disminuir al mínimo el error de mínimos cuadrados, es necesario seleccionar las constantes $a_0, a_1, \dots, a_n$.

$$\begin{aligned} E_2 &= \sum_{i=1}^m (y_i - P_n(x_i))^2 \\ &= \sum_{i=1}^m y_i^2 - 2 \sum_{i=1}^m P_n(x_i) y_i + \sum_{i=1}^m (P_n(x_i))^2 \\ &= \sum_{i=1}^m y_i^2 - 2 \sum_{i=1}^m \left(\sum_{j=0}^n a_j x_i^j \right) y_i + \sum_{i=1}^m \left(\sum_{j=0}^n a_j x_i^j \right)^2 \\ &= \sum_{i=1}^m y_i^2 - 2 \sum_{j=0}^n a_j \left(\sum_{i=1}^m y_i x_i^j \right) + \sum_{j=0}^n \sum_{k=0}^n a_j a_k \left(\sum_{i=1}^m x_i^{j+k} \right) \end{aligned}$$

Igual que en el caso lineal, para reducir al mínimo E es necesario que $\partial E/\partial a_j = 0$ para cada $j = 0, 1, \dots, n$. Así, para cada j ,

$$0 = \frac{\partial E}{\partial a_j} = -2 \sum_{i=1}^m y_i x_i^j + 2 \sum_{k=0}^n a_k \sum_{i=1}^m x_i^{j+k}.$$

Esto nos da $n + 1$ ecuaciones normales en las $n + 1$ incógnitas a_j ,

$$\sum_{k=0}^n a_k \sum_{i=1}^m x_i^{j+k} = \sum_{i=1}^m y_i x_i^j, \quad \text{para cada } j = 0, 1, \dots, n. \quad (8.3)$$

Conviene escribir las ecuaciones como sigue:

$$\begin{aligned} a_0 \sum_{i=1}^m x_i^0 + a_1 \sum_{i=1}^m x_i^1 + a_2 \sum_{i=1}^m x_i^2 + \cdots + a_n \sum_{i=1}^m x_i^n &= \sum_{i=1}^m y_i x_i^0, \\ a_0 \sum_{i=1}^m x_i^1 + a_1 \sum_{i=1}^m x_i^2 + a_2 \sum_{i=1}^m x_i^3 + \cdots + a_n \sum_{i=1}^m x_i^{n+1} &= \sum_{i=1}^m y_i x_i^1, \\ &\vdots \\ a_0 \sum_{i=1}^m x_i^n + a_1 \sum_{i=1}^m x_i^{n+1} + a_2 \sum_{i=1}^m x_i^{n+2} + \cdots + a_n \sum_{i=1}^m x_i^{2n} &= \sum_{i=1}^m y_i x_i^n. \end{aligned}$$

Puede demostrarse (véase el ejercicio 14) que las *ecuaciones normales* tienen una solución única, a condición de que las x_i sean distintas.

EJEMPLO 2 Ajuste los datos de la tabla 8.3 con el polinomio discreto de mínimos cuadrados de segundo grado. En este problema, $n = 2$, $m = 5$, y las tres ecuaciones normales son

$$\begin{aligned} 5a_0 + 2.5a_1 + 1.875a_2 &= 8.7680, \\ 2.5a_0 + 1.875a_1 + 1.5625a_2 &= 5.4514, \\ 1.875a_0 + 1.5625a_1 + 1.3828a_2 &= 4.4015. \end{aligned}$$

Tabla 8.3

i	1	2	3	4	5
x_i	0.00	0.25	0.50	0.75	1.00
y_i	1.0000	1.2840	1.6487	2.1170	2.7183

Podemos resolver este sistema con un programa de álgebra por computadora. En Maple, primero definimos las ecuaciones

```
>eq1:=5*a0+2.5*a1+1.875*a2=8.7680;
>eq2:=2.5*a0+1.875*a1+1.5625*a2=5.4514;
>eq3:=1.875*a0+1.5625*a1+1.3828*a2=4.4015;
```

Para resolver el sistema hacemos

```
>solve({eq1,eq2,eq3},{a0,a1,a2});
```

lo que implica, con `Digits:=5`;

$$a_0 = 1.0051, \quad a_1 = 0.86468 \quad \text{y} \quad a_2 = 0.84316.$$

Así pues, el polinomio de mínimos cuadrados de segundo grado que ajusta los datos anteriores es $P_2(x) = 1.0051 + 0.86468x + 0.84316x^2$, cuya gráfica aparece en la figura 8.4. En los valores dados de x_i tenemos las aproximaciones que se dan en la tabla 8.4.

El error total,

$$E_2 = \sum_{i=1}^5 (y_i - P(x_i))^2 = 2.74 \times 10^{-4},$$

es el menor que puede obtenerse usando un polinomio que sea como máximo de segundo grado. ■

Figura 8.4




Tabla 8.4

i	1	2	3	4	5
x_i	0	0.25	0.50	0.75	1.00
y_i	1.0000	1.2840	1.6487	2.1170	2.7183
$P(x_i)$	1.0051	1.2740	1.6482	2.1279	2.7129
$y_i - P(x_i)$	-0.0051	0.0100	0.0004	-0.0109	0.0054

Maple tiene una función llamada `fit` en la biblioteca `stats` para calcular la aproximación del ejemplo 2 con el código de Maple:

Material protegido por derechos de autor

```

>with(stats)
>xvals:=[0,0.25,0.5,0.75,1];
>yvals:=[1,1.284,1.6487,2.117,2.7183];
>z:=fit[leastsquare]([x,y],y=a*x^2+b*x+c,{a,b,c})
([xvals,yvals]);

```

Maple regresa el resultado

$$z := y = .8436571429x^2 + .8641828571x + 1.005137143$$

Para obtener una aproximación $y(1.7)$, escribimos

```
>evalf(subs(x=1.7,z));
```

para obtener $y = 4.912417143$.

Algunas veces conviene suponer que los datos tienen una relación exponencial. Para ello, la función de aproximación debe tener la forma

$$y = be^{ax} \quad (8.4)$$

o bien la forma

$$y = bx^a, \quad (8.5)$$

para algunas constantes a y b . El problema que implica aplicar el método de mínimos cuadrados en este tipo de situación se debe al intento de reducir al mínimo

$$E = \sum_{i=1}^m (y_i - be^{ax})^2, \quad \text{en el caso de la ecuación (8.4),}$$

o bien

$$E = \sum_{i=1}^m (y_i - bx_i^a)^2, \quad \text{en el caso de la ecuación (8.5).}$$

Las ecuaciones normales asociadas a estos procedimientos se obtienen de

$$0 = \frac{\partial E}{\partial b} = 2 \sum_{i=1}^m (y_i - be^{ax})(-e^{ax})$$

y de

$$0 = \frac{\partial E}{\partial a} = 2 \sum_{i=1}^m (y_i - be^{ax})(-bx_i e^{ax}), \quad \text{en el caso de la ecuación (8.4),}$$

o bien de

$$0 = \frac{\partial E}{\partial b} = 2 \sum_{i=1}^m (y_i - bx_i^a)(-x_i^a)$$

y

$$0 = \frac{\partial E}{\partial a} = 2 \sum_{i=1}^m (y_i - bx_i^a)(-b(\ln x_i)x_i^a) \text{ en el caso de la ecuación (8.5).}$$

Generalmente no es posible obtener una solución exacta para cualquiera de estos sistemas en a y en b .

El método que suele emplearse cuando se sospecha que los datos tienen una relación exponencial, consiste en considerar el logaritmo de la ecuación de aproximación:

$$\ln y = \ln b + ax, \quad \text{en el caso de la ecuación (8.4),}$$

y

$$\ln y = \ln b + a \ln x, \quad \text{en el caso de la ecuación (8.5).}$$

En uno y otro caso surge ahora un problema lineal, y las soluciones para $\ln b$ y a pueden obtenerse modificando debidamente las ecuaciones normales (8.1) y (8.2).

Sin embargo, la aproximación así obtenida *no* es la de mínimos cuadrados del problema original, y en algunos casos puede diferir significativamente de la aproximación de los mínimos cuadrados al problema original. En la aplicación del ejercicio 13 se describe este problema. Esa aplicación será reconsiderada como ejercicio 7 en la sección 10.3, donde la solución exacta del problema de los mínimos cuadrados se aproxima empleando los métodos adecuados para resolver los sistemas de ecuaciones no lineales.

EJEMPLO 3 Consideremos el conjunto de datos de las tres primeras columnas de la tabla 8.5.

Tabla 8.5

i	x_i	y_i	$\ln y_i$	x_i^2	$x_i \ln y_i$
1	1.00	5.10	1.629	1.0000	1.629
2	1.25	5.79	1.756	1.5625	2.195
3	1.50	6.53	1.876	2.2500	2.814
4	1.75	7.45	2.008	3.0625	3.514
5	2.00	8.46	2.135	4.0000	4.270
	7.50		9.404	11.875	14.422

Si graficamos x_i con $\ln y_i$, los datos parecen tener una relación lineal, de modo que es razonable suponer una aproximación de la forma

$$y = be^{ax} \quad \text{o} \quad \ln y = \ln b + ax.$$

Al extender la tabla y sumar las columnas apropiadas, obtenemos los datos residuales de la tabla 8.5.

Si utilizamos las ecuaciones normales (8.1) y (8.2),

$$a = \frac{(5)(14.422) - (7.5)(9.404)}{(5)(11.875) - (7.5)^2} = 0.5056$$

y

$$\ln b = \frac{(11.875)(9.404) - (14.422)(7.5)}{(5)(11.875) - (7.5)^2} = 1.122.$$

Puesto que $b = e^{1.122} = 3.071$, la aproximación adopta la forma


$$y = 3.071e^{0.5056x},$$

que, en los puntos de datos, proporciona los valores de la tabla 8.6 (véase la figura 8.5). ■

Tabla 8.6

i	x_i	y_i	$3.071e^{0.5056x_i}$
1	1.00	5.10	5.09
2	1.25	5.79	5.78
3	1.50	6.53	6.56
4	1.75	7.45	7.44
5	2.00	8.46	8.44

Figura 8.5



CONJUNTO DE EJERCICIOS 8.1

1. Calcule el polinomio lineal de mínimos cuadrados para los datos del ejemplo 2.
2. Calcule el polinomio de mínimos cuadrados de segundo grado para los datos del ejemplo 1 y compare el error total E en los dos polinomios.

3. Obtenga los polinomios de mínimos cuadrados de primero, segundo y tercer grados para los datos de la tabla anexa. En cada caso calcule el error E . Grafique los datos y los polinomios.

x_i	1.0	1.1	1.3	1.5	1.9	2.1
y_i	1.84	1.96	2.21	2.45	2.94	3.18

4. Obtenga los polinomios de mínimos cuadrados de primero, segundo y tercer grados para los datos de la tabla adjunta. En cada caso calcule el error E . Grafique los datos y los polinomios.

x_i	0	0.15	0.31	0.5	0.6	0.75
y_i	1.0	1.004	1.031	1.117	1.223	1.422

5. Con los datos

x_i	4.0	4.2	4.5	4.7	5.1	5.5	5.9	6.3	6.8	7.1
y_i	102.56	113.18	130.11	142.05	167.53	195.14	224.87	256.73	299.50	326.72

- Construya el polinomio de mínimos cuadrados de primer grado y calcule el error.
- Construya el polinomio de mínimos cuadrados de segundo grado y calcule el error.
- Construya el polinomio de mínimos cuadrados de tercer grado y calcule el error.
- Construya la aproximación de mínimos cuadrados de la forma be^{ax} y calcule el error.
- Construya la aproximación de mínimos cuadrados de la forma bx^a y calcule el error.

6. Repita el ejercicio 5 con los siguientes datos.

x_i	0.2	0.3	0.6	0.9	1.1	1.3	1.4	1.6
y_i	0.050446	0.098426	0.33277	0.72660	1.0972	1.5697	1.8487	2.5015

7. En el primer ejemplo de este capítulo, describimos un experimento para determinar la constante de resorte k según la ley de Hooke:

$$F(l) = k(l - E).$$

La función F es la fuerza necesaria para alargar el resorte l unidades, donde la constante $E = 5.3$ plg, es la longitud del resorte sin estirar.

- Suponga que se realizan mediciones de la longitud l , en pulgadas, para los pesos aplicados $F(l)$, en libras, como se indica en la tabla anexa:

$F(l)$	l
2	7.0
4	9.4
6	12.3

Obtenga la aproximación de mínimos cuadrados para k .

- b. Se efectuán más mediciones, obteniéndose los datos adicionales:

$F(t)$	t
3	8.3
5	11.3
8	14.4
10	15.9

Calcule la nueva aproximación de mínimos cuadrados para k . Después, compare el error total en las partes (a) y (b).

8. La tabla siguiente contiene las calificaciones de las tareas escolares y las de los exámenes finales de 30 estudiantes de análisis numérico. Encuentre la ecuación de la recta de mínimos cuadrados para estos datos, y use esta recta para determinar la calificación de la tarea escolar que se requiere para predecir las calificaciones mínimas A (90%) y D (60%) en los exámenes finales.

Tarea	Examen final	Tarea	Examen final
302	45	323	83
325	72	337	99
285	54	337	70
339	54	304	62
334	79	319	66
322	65	234	51
331	99	337	53
279	63	351	100
316	65	339	67
347	99	343	83
343	83	314	42
290	74	344	79
326	76	185	59
233	57	340	75
254	45	316	45

9. La tabla siguiente muestra los promedios de puntos-calificación de 20 estudiantes universitarios de matemáticas y ciencias de la computación, junto con la puntuación que obtuvieron en la parte correspondiente a las matemáticas del examen American College Testing Program (programa de pruebas para las universidades estadounidenses), mientras cursaban la enseñanza media. Grafique los datos y obtenga para ellos una ecuación de recta de mínimos cuadrados.

Puntuación ACT	Promedio de grados de puntos	Puntuación ACT	Promedio de grados de puntos
28	3.84	29	3.75
25	3.21	28	3.65
28	3.23	27	3.87
27	3.63	29	3.75
28	3.75	21	1.66
33	3.20	28	3.12
28	3.41	28	2.96
29	3.38	26	2.92
23	3.53	30	3.10
27	2.03	24	2.81

10. El siguiente conjunto de datos, presentados al Senate Antitrust Subcommittee de Estados Unidos, muestra las características comparativas de choque-supervivencia de automóviles de varios tipos. Obtenga la recta de mínimos cuadrados que aproxima estos datos. (La tabla contiene el porcentaje de vehículos accidentados en los cuales la lesión más seria fue fatal o grave.)

Tipo	Peso promedio	Ocurrencia porcentual
1. Regular de lujo, de fabricación nacional	4800 lb	3.1
2. Regular intermedio, de fabricación nacional	3700 lb	4.0
3. Económico regular, de fabricación nacional	3400 lb	5.2
4. Compacto de fabricación nacional	2800 lb	6.4
5. Compacto de fabricación extranjera	1900 lb	9.6

11. Para determinar una relación entre el número de peces y el de las especies de peces en muestras tomadas de una parte de Great Barrier Reef, P. Sale y R. Dybdahl [SD]. Ajuste un polinomio lineal de mínimos cuadrados al siguiente conjunto de datos, que se recopilaron de muestras formadas durante un periodo de 2 años. Sea x el número de peces de la muestra y sea y el número de especies de la muestra.

x	y	x	y	x	y
13	11	29	12	60	14
15	10	30	14	62	21
16	11	31	16	64	21
21	12	36	17	70	24
22	12	40	13	72	17
23	13	42	14	100	23
25	13	55	22	130	34

Determine el polinomio lineal de mínimos cuadrados para estos datos.

12. Para determinar una relación funcional entre el coeficiente de atenuación y el grosor de una muestra de taconita, V. P. Singh [Si] ajusta un conjunto de datos por medio de un polinomio lineal de mínimos cuadrados. Los datos siguientes están tomados de una gráfica de ese trabajo. Obtenga el polinomio lineal de mínimos cuadrados que ajuste esos datos.

Espesor (cm)	Coefficiente de atenuación (dB/cm)
0.040	26.5
0.041	28.1
0.055	25.2
0.056	26.0
0.062	24.0
0.071	25.0
0.071	26.4
0.078	27.2
0.082	25.6
0.090	25.0
0.092	26.8

Espesor (cm)	Coefficiente de atenuación (dB/cm)
0.100	24.8
0.105	27.0
0.120	25.0
0.123	27.3
0.130	26.9
0.140	26.2

13. En un trabajo relacionado con el estudio de la eficiencia de la utilización de la energía por las larvas de la polilla modesta (*Pachysphinx modesta*), L. Schroeder [Schrl] utilizó los siguientes datos para determinar una relación entre W , el peso de las larvas vivas en gramos, y R , el consumo de oxígeno de las larvas en mililitros/hora. Por razones biológicas, se supone que entre W y R existe una relación de la forma $R = bW^a$.

a. Encuentre el polinomio logarítmico lineal de mínimos cuadrados usando

$$\ln R = \ln b + a \ln W.$$

b. Calcule el error asociado a la aproximación en la parte (a):

$$E = \sum_{i=1}^{37} (R_i - bW_i^a)^2.$$

c. Modifique la ecuación logarítmica de mínimos cuadrados de la parte (a) agregando el término cuadrático $c(\ln W)^2$, y después determine el polinomio logarítmico cuadrático de mínimos cuadrados.

d. Determine la fórmula y calcule el error asociado a la aproximación de la parte (c).

W	R	W	R	W	R	W	R	W	R
0.017	0.154	0.025	0.23	0.020	0.181	0.020	0.180	0.025	0.234
0.087	0.296	0.111	0.357	0.085	0.260	0.119	0.299	0.233	0.537
0.174	0.363	0.211	0.366	0.171	0.334	0.210	0.428	0.783	1.47
1.11	0.531	0.999	0.771	1.29	0.87	1.32	1.15	1.35	2.48
1.74	2.23	3.02	2.01	3.04	3.59	3.34	2.83	1.69	1.44
4.09	3.58	4.28	3.28	4.29	3.40	5.48	4.15	2.75	1.84
5.45	3.52	4.58	2.96	5.30	3.88			4.83	4.66
5.96	2.40	4.68	5.10					5.53	6.94

14. Demuestre que las ecuaciones normales (8.3) resultantes de la aproximación discreta de mínimos cuadrados producen una matriz simétrica no singular y que, por tanto, tienen una solución única. [Sugerencia: sea $A = (a_{ij})$, donde

$$a_{ij} = \sum_{k=1}^n x_k^{i+j-2}$$

y $x_1, x_2, \dots, x_n$ son distintos con $n < m - 1$. Supongamos que A es singular y que $c \neq 0$ es tal que $c^T A c = 0$. Demuestre que el polinomio de n -ésimo grado cuyos coeficientes son las coordenadas de c tiene más de n raíces; después use esto para establecer una contradicción.]

8.2 Polinomios ortogonales y aproximación por mínimos cuadrados

En la sección anterior estudiamos el problema de la aproximación por mínimos cuadrados para ajustar una colección de datos. El otro problema de aproximación mencionado en la introducción se refiere a la aproximación de funciones.

Supongamos que $f \in C[a, b]$ y que se requiere un polinomio $P_n(x)$ de grado máximo n , el cual reducirá al mínimo el error

$$\int_a^b [f(x) - P_n(x)]^2 dx.$$


Si queremos determinar un polinomio de aproximación de mínimos cuadrados, esto es, un polinomio que reduzca al mínimo esta expresión, usamos

$$P_n(x) = a_n x^n + a_{n-1} x^{n-1} + \cdots + a_1 x + a_0 = \sum_{k=0}^n a_k x^k,$$

y, como se observa en la figura 8.6, definimos

$$E = E(a_0, a_1, \dots, a_n) = \int_a^b \left(f(x) - \sum_{k=0}^n a_k x^k \right)^2 dx.$$

Figura 8.6



El problema consiste en encontrar coeficientes reales $a_0, a_1, \dots, a_n$ que reduzcan E al mínimo. Una condición necesaria para que los números $a_0, a_1, \dots, a_n$ hagan eso es que

$$\frac{\partial E}{\partial a_j} = 0, \quad \text{para cada } j = 0, 1, \dots, n.$$

Dado que

$$E = \int_a^b [f(x)]^2 dx - 2 \sum_{k=0}^n a_k \int_a^b x^k f(x) dx + \int_a^b \left(\sum_{k=0}^n a_k x^k \right)^2 dx,$$

tenemos

$$\frac{\partial E}{\partial a_j} = -2 \int_a^b x^j f(x) dx + 2 \sum_{k=0}^n a_k \int_a^b x^{j+k} dx.$$

Por tanto, si queremos obtener $P_n(x)$ debemos resolver las $(n+1)$ ecuaciones normales

$$\sum_{k=0}^n a_k \int_a^b x^{j+k} dx = \int_a^b x^j f(x) dx, \quad \text{para cada } j = 0, 1, \dots, n, \quad (8.6)$$

para las $(n+1)$ incógnitas a_j . Puede demostrarse que las ecuaciones normales siempre tienen una solución única, siempre que $f \in C[a, b]$. (Véase el Ejercicio 15.)

EJEMPLO 1 Encuentre el polinomio de aproximación de mínimos cuadrados de segundo grado para la función $f(x) = \sin \pi x$ en el intervalo $[0, 1]$. Las ecuaciones normales para $P_2(x) = a_2 x^2 + a_1 x + a_0$ son

$$\begin{aligned} a_0 \int_0^1 1 dx + a_1 \int_0^1 x dx + a_2 \int_0^1 x^2 dx &= \int_0^1 \sin \pi x dx, \\ a_0 \int_0^1 x dx + a_1 \int_0^1 x^2 dx + a_2 \int_0^1 x^3 dx &= \int_0^1 x \sin \pi x dx, \\ a_0 \int_0^1 x^2 dx + a_1 \int_0^1 x^3 dx + a_2 \int_0^1 x^4 dx &= \int_0^1 x^2 \sin \pi x dx. \end{aligned}$$

Al realizar la integración se obtiene

$$a_0 + \frac{1}{2}a_1 + \frac{1}{3}a_2 = \frac{2}{\pi}, \quad \frac{1}{2}a_0 + \frac{1}{3}a_1 + \frac{1}{4}a_2 = \frac{1}{\pi}, \quad \frac{1}{3}a_0 + \frac{1}{4}a_1 + \frac{1}{5}a_2 = \frac{\pi^2 - 4}{\pi^3}.$$

Estas tres ecuaciones con tres incógnitas pueden resolverse para obtener


$$a_0 = \frac{12\pi^2 - 120}{\pi^3} \approx -0.050465 \quad \text{y} \quad a_1 = -a_2 = \frac{720 - 60\pi^2}{\pi^3} \approx 4.12251.$$

En consecuencia, la aproximación del polinomio de mínimos cuadrados de segundo grado para $f(x) = \sin \pi x$ en $[0, 1]$ es $P_2(x) = -4.12251x^2 + 4.12251x - 0.050465$. (Véase la figura 8.7.) ■

En el ejemplo 1 se ilustra el problema que implica obtener una aproximación del polinomio de mínimos cuadrados. Un sistema lineal $(n+1) \times (n+1)$ debe resolverse para las incógnitas $a_0, \dots, a_n$. Los coeficientes del sistema lineal tienen la forma

$$\int_a^b x^{j+k} dx = \frac{b^{j+k+1} - a^{j+k+1}}{j+k+1},$$

Figura 8.7



sistema lineal que no tiene una solución numérica que se pueda calcular fácilmente. La matriz del sistema lineal se conoce como **matriz de Hilbert**. Esta matriz mal condicionada constituye un ejemplo clásico para demostrar los problemas del error de redondeo. (Véase el ejercicio 6 de la sección 7.4.)

Otra desventaja se parece a la situación que se presentó cuando por primera vez tratamos los polinomios de Lagrange en la sección 3.1. Los cálculos efectuados para obtener el mejor polinomio de n -ésimo grado, $P_n(x)$, no reduce el trabajo que se requiere para calcular $P_{n+1}(x)$, o sea el polinomio del grado mayor siguiente.

A continuación explicaremos otra técnica con que se obtienen las aproximaciones de mínimos cuadrados. La técnica resulta ser eficiente desde el punto de vista de los cálculos a realizar; una vez que se conoce $P_n(x)$ es fácil determinar $P_{n+1}(x)$. Para facilitar la exposición necesitaremos aprender otros conceptos nuevos.

Definición 8.1 Se dice que el conjunto de funciones $\{\phi_0, \dots, \phi_n\}$ es **linealmente independiente** en $[a, b]$ si, siempre que

$$c_0\phi_0(x) + c_1\phi_1(x) + \dots + c_n\phi_n(x) = 0, \quad \text{para cualquier } x \in [a, b],$$

se tiene que $c_0 = c_1 = \dots = c_n = 0$. De lo contrario se dice que el conjunto de funciones es **linealmente dependiente**. ■

Teorema 8.2 Si $\phi_j(x)$ es un polinomio de j -ésimo grado para cada $j = 0, 1, \dots, n$, entonces $\{\phi_0, \dots, \phi_n\}$ es linealmente independiente en cualquier intervalo $[a, b]$. ■

Demostración Supongamos que $c_0, \dots, c_n$ son números reales para los cuales

$$P(x) = c_0\phi_0(x) + c_1\phi_1(x) + \dots + c_n\phi_n(x) = 0, \quad \text{para cualquier } x \in [a, b].$$

Como el polinomio $P(x)$ se anula en $[a, b]$, los coeficientes de todas las potencias de x son cero. En particular, el coeficiente de x^n es cero. Y puesto que $c_n\phi_n(x)$ es el único término

de $P(x)$ que contiene x^n , hemos de tener $c_n = 0$ y

$$P(x) = \sum_{j=0}^{n-1} c_j \phi_j(x).$$

En esta representación de $P(x)$ el único término que contiene una potencia de x^{n-1} es $c_{n-1}\phi_{n-1}(x)$, de modo que este término también debe ser cero y

$$P(x) = \sum_{j=0}^{n-2} c_j \phi_j(x).$$

En forma similar, las constantes restantes $c_{n-2}, c_{n-3}, \dots, c_1, c_0$ son todas cero, lo cual significa que $\{\phi_0, \phi_1, \dots, \phi_n\}$ es linealmente independiente. ■ ■ ■

EJEMPLO 2 Sea $\phi_0(x) = 2$, $\phi_1(x) = x - 3$ y $\phi_2(x) = x^2 + 2x + 7$. De acuerdo con el teorema 8.2, $\{\phi_0, \phi_1, \phi_2\}$ es linealmente independiente en cualquier intervalo $[a, b]$. Supongamos que $Q(x) = a_0 + a_1x + a_2x^2$. Demostraremos que existen constantes c_0, c_1 y c_2 tales que $Q(x) = c_0\phi_0(x) + c_1\phi_1(x) + c_2\phi_2(x)$. Nótese que

$$1 = \frac{1}{2}\phi_0(x), \quad x = \phi_1(x) + 3 = \phi_1(x) + \frac{3}{2}\phi_0(x),$$

y que

$$\begin{aligned} x^2 &= \phi_2(x) - 2x - 7 = \phi_2(x) - 2\left[\phi_1(x) + \frac{3}{2}\phi_0(x)\right] - 7\left[\frac{1}{2}\phi_0(x)\right] \\ &= \phi_2(x) - 2\phi_1(x) - \frac{13}{2}\phi_0(x). \end{aligned}$$

Por tanto,

$$\begin{aligned} Q(x) &= a_0\left[\frac{1}{2}\phi_0(x)\right] + a_1\left[\phi_1(x) + \frac{3}{2}\phi_0(x)\right] + a_2\left[\phi_2(x) - 2\phi_1(x) - \frac{13}{2}\phi_0(x)\right] \\ &= \left(\frac{1}{2}a_0 + \frac{3}{2}a_1 - \frac{13}{2}a_2\right)\phi_0(x) + [a_1 - 2a_2]\phi_1(x) + a_2\phi_2(x), \end{aligned}$$

de modo que cualquier polinomio cuadrático se puede expresar como una combinación lineal de $\phi_0(x)$, $\phi_1(x)$ y $\phi_2(x)$. ■

La situación descrita en el ejemplo 2 se cumple en un caso mucho más general. Sea Π_n el conjunto de todos los polinomios de grado máximo n . El siguiente resultado se utiliza ampliamente en muchas aplicaciones del álgebra lineal. En el ejercicio 13 veremos su comprobación.

Teorema 8.3 Si $\{\phi_0(x), \phi_1(x), \dots, \phi_n(x)\}$ es un conjunto de polinomios linealmente independientes en Π_n , entonces todo polinomio en Π_n puede escribirse de manera única como una combinación lineal de $\phi_0(x), \phi_1(x), \dots, \phi_n(x)$. ■

Para explicar la aproximación general de la función, es necesario presentar antes los conceptos de funciones de peso y ortogonalidad.


Definición 8.4 A una función integrable w se le llama **función de peso** en el intervalo I si $w(x) \geq 0$, para toda x en I , pero $w(x) \neq 0$ en cualquier subintervalo de I . ■

Una función de peso tiene por objeto asignar diferentes grados de importancia a las aproximaciones en ciertas partes del intervalo. Por ejemplo, la función peso

$$w(x) = \frac{1}{\sqrt{1-x^2}}$$

pone menos énfasis cerca del centro del intervalo $(-1, 1)$ y mayor cuando $|x|$ se hulla cerca del uno (véase la figura 8.8). Esta función de peso se empleará en la siguiente sección.

Figura 8.8



Supongamos que $\{\phi_0, \phi_1, \dots, \phi_n\}$ es un conjunto de funciones linealmente independientes en $[a, b]$, que w es una función de peso en $[a, b]$ y que, para $f \in C[a, b]$, se busca una combinación lineal

$$P(x) = \sum_{k=0}^n a_k \phi_k(x)$$

para reducir al mínimo el error

$$E(a_0, \dots, a_n) = \int_a^b w(x) \left[f(x) - \sum_{k=0}^n a_k \phi_k(x) \right]^2 dx.$$

Este problema se reduce a la situación que se planteó al inicio de esta sección en el caso especial cuando $w(x) = 1$ y $\phi_k(x) = x^k$, para cada $k = 0, 1, \dots, n$.

Las ecuaciones normales asociadas a este problema se derivan del hecho de que para cada $j = 0, 1, \dots, n$,

$$0 = \frac{\partial E}{\partial a_j} = 2 \int_a^b w(x) \left[f(x) - \sum_{k=0}^n a_k \phi_k(x) \right] \phi_j(x) dx.$$

El sistema de ecuaciones normales puede escribirse

$$\int_a^b w(x) f(x) \phi_j(x) dx = \sum_{k=0}^n a_k \int_a^b w(x) \phi_k(x) \phi_j(x) dx, \quad \text{para } j = 0, 1, \dots, n.$$

Si podemos elegir las funciones $\phi_0, \phi_1, \dots, \phi_n$ de modo que

$$\int_a^b w(x) \phi_k(x) \phi_j(x) dx = \begin{cases} 0, & \text{cuando } j \neq k, \\ \alpha_j > 0, & \text{cuando } j = k, \end{cases} \quad (8.7)$$

entonces las ecuaciones normales se reducen a

$$\int_a^b w(x) f(x) \phi_j(x) dx = a_j \int_a^b w(x) [\phi_j(x)]^2 dx = a_j \alpha_j,$$

para cada $j = 0, 1, \dots, n$ y fácilmente obtenemos

$$a_j = \frac{1}{\alpha_j} \int_a^b w(x) f(x) \phi_j(x) dx.$$

Por tanto, el problema de aproximación por mínimos cuadrados se simplifica considerablemente, cuando se seleccionan las funciones $\phi_0, \phi_1, \dots, \phi_n$ que satisfagan la condición de *ortogonalidad* en la ecuación (8.7). En lo que resta de esta sección estudiaremos los conjuntos de este tipo.

Definición 8.5 Se dice que $\{\phi_0, \phi_1, \dots, \phi_n\}$ es un **conjunto ortogonal de funciones** en el intervalo $[a, b]$ respecto a la función de peso w , si

$$\int_a^b w(x) \phi_j(x) \phi_k(x) dx = \begin{cases} 0, & \text{cuando } j \neq k, \\ \alpha_k > 0, & \text{cuando } j = k. \end{cases}$$

Si además, $\alpha_k = 1$ para cada $k = 0, 1, \dots, n$, se dice que el conjunto es **ortonormal**. ■

Esta definición, junto con los comentarios que la anteceden, da origen al siguiente teorema.

Teorema 8.6 Si $\{\phi_0, \dots, \phi_n\}$ es un conjunto ortogonal de funciones en un intervalo $[a, b]$ respecto a la función de peso w , entonces la aproximación por mínimos cuadrados a f en $[a, b]$ respecto a w es

$$P(x) = \sum_{k=0}^n a_k \phi_k(x),$$

donde, para cada $k = 0, 1, \dots, n$,

$$a_k = \frac{\int_a^b w(x) \phi_k(x) f(x) dx}{\int_a^b w(x) [\phi_k(x)]^2 dx} = \frac{1}{\alpha_k} \int_a^b w(x) \phi_k(x) f(x) dx. \quad \blacksquare$$

Aunque la definición 8.5 y el teorema 8.6 son válidos para una clase amplia de funciones ortogonales, sólo tomaremos en cuenta conjuntos ortogonales de polinomios. El siguiente teorema, que tiene como fundamento el **proceso de Gram-Schmidt**, describe cómo construir polinomios ortogonales en $[a, b]$ respecto a la función de peso w .

Teorema 8.7 El conjunto de las funciones polinomiales $\{\phi_0, \phi_1, \dots, \phi_n\}$ definida en la siguiente forma es ortogonal en $[a, b]$ respecto a la función de peso w :

$$\phi_0(x) = 1, \quad \phi_1(x) = x - B_1, \quad \text{para cada } x \text{ en } [a, b],$$

donde

$$B_1 = \frac{\int_a^b x w(x) [\phi_0(x)]^2 dx}{\int_a^b w(x) [\phi_0(x)]^2 dx},$$

y cuando $k \geq 2$,

$$\phi_k(x) = (x - B_k) \phi_{k-1}(x) - C_k \phi_{k-2}(x), \quad \text{para cada } x \text{ en } [a, b],$$

donde

$$B_k = \frac{\int_a^b x w(x) [\phi_{k-1}(x)]^2 dx}{\int_a^b w(x) [\phi_{k-1}(x)]^2 dx}$$

y

$$C_k = \frac{\int_a^b x w(x) \phi_{k-1}(x) \phi_{k-2}(x) dx}{\int_a^b w(x) [\phi_{k-2}(x)]^2 dx}. \quad \blacksquare$$

El teorema 8.7 ofrece un procedimiento recursivo para construir un conjunto de polinomios ortogonales. La demostración de este teorema se logra al aplicar la inducción matemática al grado del polinomio $\phi_n(x)$.

Corolario 8.8 Para toda $n > 0$, el conjunto de las funciones polinomiales $\{\phi_0, \dots, \phi_n\}$ dado en el teorema 8.7 es linealmente independiente en $[a, b]$ y

$$\int_a^b w(x) \phi_n(x) Q_k(x) dx = 0,$$

para todo polinomio $Q_k(x)$ de grado $k < n$. ■

Demostración Puesto que $\phi_n(x)$ es un polinomio de n -ésimo grado, el teorema 8.2 implica que $\{\phi_0, \dots, \phi_n\}$ es un conjunto linealmente independiente.

Sea $Q_k(x)$ un polinomio de k -ésimo grado. De acuerdo con el teorema 8.3, existen los números $c_0, \dots, c_k$ tales que

$$Q_k(x) = \sum_{j=0}^k c_j \phi_j(x).$$

Por tanto,

$$\int_a^b w(x) Q_k(x) \phi_n(x) dx = \sum_{j=0}^k c_j \int_a^b w(x) \phi_j(x) \phi_n(x) dx = \sum_{j=0}^k c_j \cdot 0 = 0,$$

porque ϕ_n es ortogonal a ϕ_j para cada $j = 0, 1, \dots, k$. ■ ■ ■

EJEMPLO 3 El conjunto de los **polinomios de Legendre**, $\{P_n(x)\}$, es ortogonal en $[-1, 1]$ respecto a la función de peso $w(x) = 1$. La definición clásica de estos polinomios requiere que $P_n(1) = 1$ para cualquier n , y se utiliza una relación recursiva para generar los polinomios cuando $n \geq 2$. No hace falta esta normalización en nuestra exposición; los polinomios de aproximación de mínimos cuadrados que se generan en ambos casos son esencialmente los mismos. Al aplicar el procedimiento recursivo del teorema 8.7 con $P_0(x) = 1$ obtenemos

$$B_1 = \frac{\int_{-1}^1 x \, dx}{\int_{-1}^1 1 \, dx} = 0 \quad \text{y} \quad P_1(x) = (x - B_1)P_0(x) = x.$$

También,

$$B_2 = \frac{\int_{-1}^1 x^3 \, dx}{\int_{-1}^1 x^2 \, dx} = 0 \quad \text{y} \quad C_2 = \frac{\int_{-1}^1 x^2 \, dx}{\int_{-1}^1 1 \, dx} = \frac{1}{3},$$


y, por tanto,

$$P_2(x) = (x - B_2)P_1(x) - C_2P_0(x) = (x - 0)x - \frac{1}{3} \cdot 1 = x^2 - \frac{1}{3}.$$

Los polinomios de Legendre de orden superior que aparecen en la figura 8.9 se deducen de manera análoga. Aunque la integración puede ser tediosa, no es difícil con un sistema de álgebra por computadora. Por ejemplo, el comando de Maple `int` se usa para calcular las integrales B_3 y C_3 :

```
>B3:=int(x*(x^2-1/3)^2,x=-1..1)/int(x^2-1/3)^2,x=-1..1);
>C3:=int(x*(x^2-1/3)*x,x=-1..1)/int(x^2,x=-1..1);
```

Figura 8.9



de donde $B_3 = 0$ and $C_3 = \frac{4}{15}$. Así,

$$P_3(x) = x P_2(x) - \frac{4}{15} P_1(x) = x^3 - \frac{1}{3}x - \frac{4}{15}x = x^3 - \frac{3}{5}x.$$

Los dos siguientes polinomios de Legendre son $P_4(x) = x^4 - \frac{6}{7}x^2 + \frac{3}{35}$ y $P_5(x) = x^5 - \frac{10}{9}x^3 + \frac{5}{21}x$. ■

Los polinomios de Legendre se mencionaron en la sección 4.7, donde utilizamos sus raíces como los nodos de la cuadratura gaussiana.

CONJUNTO DE EJERCICIOS 8.2

- Obtenga la aproximación polinomial lineal de mínimos cuadrados a $f(x)$ en el intervalo indicado si
 - $f(x) = x^2 + 3x + 2$, $[0, 1]$;
 - $f(x) = x^3$, $[0, 2]$;
 - $f(x) = \frac{1}{x}$, $[1, 3]$;
 - $f(x) = e^x$, $[0, 2]$;
 - $f(x) = \frac{1}{2} \cos x + \frac{1}{3} \sin 2x$, $[0, 1]$;
 - $f(x) = x \ln x$, $[1, 3]$.
- Obtenga la aproximación polinomial de mínimos cuadrados de segundo grado a las funciones e intervalos del ejercicio 1.
- Obtenga la aproximación polinomial lineal en el intervalo $[-1, 1]$ para las siguientes funciones.
 - $f(x) = x^2 - 2x + 3$
 - $f(x) = x^3$
 - $f(x) = \frac{1}{x+2}$
 - $f(x) = e^x$
 - $f(x) = \frac{1}{2} \cos x + \frac{1}{3} \sin 2x$
 - $f(x) = \ln(x+2)$
- Obtenga la aproximación polinomial de mínimos cuadrados de segundo grado en el intervalo $[-1, 1]$ para las funciones del ejercicio 3.
- Calcule el error E para las aproximaciones del ejercicio 3.
- Calcule el error E para las aproximaciones del ejercicio 4.
- Utilice el proceso de Gram-Schmidt para construir $\phi_0(x)$, $\phi_1(x)$, $\phi_2(x)$ y $\phi_3(x)$ en los siguientes intervalos.
 - $[0, 1]$
 - $[0, 2]$
 - $[1, 3]$
- Repita el ejercicio 1 usando los resultados del ejercicio 7.
- Repita el ejercicio 2 usando los resultados del ejercicio 7.
- Obtenga el polinomio de aproximación de mínimos cuadrados de tercer grado para las funciones del ejercicio 1 usando los resultados del ejercicio 7.
- Use el procedimiento de Gram-Schmidt para calcular L_1 , L_2 y L_3 , donde $\{L_0(x), L_1(x), L_2(x), L_3(x)\}$ es un conjunto ortogonal de polinomios en $(0, \infty)$ respecto a las funciones de peso $w(x) = e^{-x}$ y $L_0(x) = 1$. Los polinomios que se obtienen con este procedimiento reciben el nombre de **polinomios de Laguerre**.

12. Use los polinomios de Laguerre calculados en el ejercicio 11 para obtener los polinomios de mínimos cuadrados de primero, segundo y tercer grados en el intervalo $(0, \infty)$ respecto a la función de peso $w(x) = e^{-x}$ para las siguientes funciones:
- a. $f(x) = x^2$ b. $f(x) = e^{-x}$ c. $f(x) = x^3$ d. $f(x) = e^{-2x}$
13. Suponga que $\{\phi_0, \phi_1, \dots, \phi_n\}$ es un conjunto lineal independiente cualquiera en Π_n . Demuestre que para todo elemento $Q \in \Pi_n$ existen constantes únicas $c_0, c_1, \dots, c_n$ tales que

$$Q(x) = \sum_{k=0}^n c_k \phi_k(x).$$

14. Demuestre que, si $\{\phi_0, \phi_1, \dots, \phi_n\}$ es un conjunto ortogonal de funciones en $[a, b]$ respecto a la función de peso w , entonces $\{\phi_0, \phi_1, \dots, \phi_n\}$ es un conjunto linealmente independiente.
15. Demuestre que las ecuaciones normales (8.6) tienen una solución única. [Sugerencia: demuestre que la única solución de la función $f(x) = 0$ es $a_j = 0, j = 0, 1, \dots, n$. Multiplique la ecuación (8.6) por a_j y sume sobre todas las j . Intercambie el signo de integral y sumatoria para obtener $\int_a^b [P(x)]^2 dx = 0$. Por tanto, $P(x) = 0$, así que $a_j = 0$ para $j = 0, \dots, n$. De aquí que, la matriz de coeficientes es no singular y la ecuación (8.6) tiene una solución única.]

8.3 Polinomios de Chebyshev y economización de las series de potencias

Los polinomios de Chebyshev $\{T_n(x)\}$ son ortogonales en $(-1, 1)$ respecto a la función de peso $w(x) = (1 - x^2)^{-1/2}$. Aunque pueden derivarse por el método que se explicó en la sección anterior, resulta más fácil dar su definición y demostrar después que satisfacen las propiedades de ortogonalidad requeridas.

Con $x \in [-1, 1]$, defina

$$T_n(x) = \cos[n \arccos x], \quad \text{para cada } n \geq 0. \quad (8.8)$$

No es obvio de esta definición que para cada n , $T_n(x)$ es un polinomio en x , pero ahora mostraremos este hecho. Observe primero que

$$T_0(x) = \cos 0 = 1 \quad \text{y} \quad T_1(x) = \cos(\arccos x) = x.$$

Para $n \geq 1$, al introducir la sustitución $\theta = \arccos x$ esta ecuación se transforma en

$$T_n(\theta(x)) = T_n(\theta) = \cos(n\theta), \quad \text{donde } \theta \in [0, \pi].$$

Se deriva una relación de recurrencia al observar que

$$T_{n+1}(\theta) = \cos(n\theta) \cos \theta - \sin(n\theta) \sin \theta$$

y que

$$T_{n-1}(\theta) = \cos(n\theta) \cos \theta + \sin(n\theta) \sin \theta.$$

Al sumar estas ecuaciones obtenemos

$$T_{n+1}(\theta) = 2 \cos(n\theta) \cos \theta - T_{n-1}(\theta).$$

Al volver a la variable x , obtenemos, para $n \geq 1$

$$T_{n+1}(x) = 2x \cos(n \arccos x) - T_{n-1}(x)$$

o

$$T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x). \quad (8.9)$$

Como $T_0(x) = 1$ y $T_1(x) = x$, la relación de recurrencia implica que $T_n(x)$ es un polinomio de grado n con coeficiente principal 2^{n-1} , cuando $n \geq 1$.

Los tres polinomios de Chebyshev que le siguen son

$$T_2(x) = 2xT_1(x) - T_0(x) = 2x^2 - 1,$$

$$T_3(x) = 2xT_2(x) - T_1(x) = 4x^3 - 3x,$$


y

$$T_4(x) = 2xT_3(x) - T_2(x) = 8x^4 - 8x^2 + 1.$$

En la figura 8.10 se muestran las gráficas de T_1 , T_2 , T_3 y T_4 . Para demostrar la ortogonalidad de los polinomios de Chebyshev, consideremos

$$\int_{-1}^1 \frac{T_n(x)T_m(x)}{\sqrt{1-x^2}} dx = \int_{-1}^1 \frac{\cos(n \arccos x) \cos(m \arccos x)}{\sqrt{1-x^2}} dx.$$

Figura 8.10



Al reintroducir la sustitución $\theta = \arccos x$ se obtiene

$$d\theta = -\frac{1}{\sqrt{1-x^2}} dx$$

y

$$\int_{-1}^1 \frac{T_n(x) T_m(x)}{\sqrt{1-x^2}} dx = - \int_{\pi}^0 \cos(n\theta) \cos(m\theta) d\theta = \int_0^{\pi} \cos(n\theta) \cos(m\theta) d\theta.$$

Supongamos que $n \neq m$. Dado que

$$\cos(n\theta) \cos(m\theta) = \frac{1}{2} [\cos(n+m)\theta + \cos(n-m)\theta],$$

tenemos

$$\begin{aligned} \int_{-1}^1 \frac{T_n(x) T_m(x)}{\sqrt{1-x^2}} dx &= \frac{1}{2} \int_0^{\pi} \cos((n+m)\theta) d\theta + \frac{1}{2} \int_0^{\pi} \cos((n-m)\theta) d\theta \\ &= \left[\frac{1}{2(n+m)} \sin((n+m)\theta) + \frac{1}{2(n-m)} \sin((n-m)\theta) \right]_0^{\pi} \\ &= 0. \end{aligned}$$

Usando un método similar también podemos demostrar que, cuando $n = m$,

$$\int_{-1}^1 \frac{[T_n(x)]^2}{\sqrt{1-x^2}} dx = \frac{\pi}{2}, \quad \text{para cada } n \geq 1. \quad (8.10)$$

Los polinomios de Chebyshev sirven para reducir al mínimo el error de aproximación. Veremos cómo se usan para resolver dos problemas de este tipo:

1. Una colocación óptima de los puntos interpolantes para reducir al mínimo el error en la interpolación de Lagrange.
2. Un medio de reducir el grado de un polinomio de aproximación con una pérdida de exactitud mínima.

El siguiente resultado se refiere a los ceros y a los puntos extremos de T_n .

Teorema 8.9 El polinomio de Chebyshev $T_n(x)$ de grado $n \geq 1$ tiene n ceros simples en $[-1, 1]$ en

$$\bar{x}_k = \cos\left(\frac{2k-1}{2n}\pi\right), \quad \text{para cada } k = 1, 2, \dots, n.$$

Más aún, $T_n(x)$ toma sus extremos absolutos en

$$\bar{x}'_k = \cos\left(\frac{k\pi}{n}\right), \quad \text{con} \quad T_n(\bar{x}'_k) = (-1)^k, \quad \text{para cada } k = 0, 1, \dots, n. \quad \blacksquare$$

Demostración Si utilizamos

$$\bar{x}_k = \cos\left(\frac{2k-1}{2n}\pi\right), \quad \text{para cada } k = 1, 2, \dots, n,$$

entonces

$$T_n(\bar{x}_k) = \cos(n \arccos \bar{x}_k) = \cos\left(n \arccos\left(\cos\left(\frac{2k-1}{2n}\pi\right)\right)\right) = \cos\left(\frac{2k-1}{2}\pi\right) = 0,$$

y cada $\bar{x}_k$ es un cero distinto de T_n . Por ser $T_n(x)$ un polinomio de n -ésimo grado, todos los ceros de T_n deben ser de esta misma forma.

Para demostrar la segunda parte, primero obsérvese que

$$T'_n(x) = \frac{d}{dx} [\cos(n \arccos x)] = \frac{n \operatorname{sen}(n \arccos x)}{\sqrt{1-x^2}},$$

y que, cuando $k = 1, 2, \dots, n-1$,

$$T'_n(\bar{x}'_k) = \frac{n \operatorname{sen}\left(n \arccos\left(\cos\left(\frac{k\pi}{n}\right)\right)\right)}{\sqrt{1 - \left[\cos\left(\frac{k\pi}{n}\right)\right]^2}} = \frac{n \operatorname{sen}(k\pi)}{\operatorname{sen}\left(\frac{k\pi}{n}\right)} = 0.$$

Como $T_n(x)$ es un polinomio de n -ésimo grado, su derivada $T'_n(x)$ es un polinomio de $(n-1)$ -ésimo grado y todos los ceros de $T'_n(x)$ ocurren en estos $n-1$ puntos. Las otras únicas posibilidades de los extremos de $T_n(x)$ se presentan en los extremos del intervalo $[-1, 1]$; es decir, $\bar{x}'_0 = 1$ y $\bar{x}'_n = -1$. Por tanto, para cualquier $k = 0, 1, \dots, n$, tenemos

$$T_n(\bar{x}'_k) = \cos\left(n \arccos\left(\cos\left(\frac{k\pi}{n}\right)\right)\right) = \cos(k\pi) = (-1)^k,$$

en cada valor par de k ocurre un máximo, y en cada valor impar un mínimo. ■ ■ ■

Los polinomios mónicos de Chebyshev (los que tienen coeficiente principal 1) $\hat{T}_n(x)$ se derivan del polinomio de Chebyshev $T_n(x)$ al dividirlos por el coeficiente principal 2^{n-1} . Por tanto,

$$\hat{T}_0(x) = 1 \quad \text{y} \quad \hat{T}_n(x) = \frac{1}{2^{n-1}} T_n(x), \quad \text{para cada } n \geq 1. \quad (8.11)$$

La relación de recurrencia satisfecha por los polinomios de Chebyshev implica que


$$\begin{aligned} \hat{T}_2(x) &= x \hat{T}_1(x) - \frac{1}{2} \hat{T}_0(x) \quad \text{y} \\ \hat{T}_{n+1}(x) &= x \hat{T}_n(x) - \frac{1}{4} \hat{T}_{n-1}(x), \quad \text{para cada } n \geq 2. \end{aligned} \quad (8.12)$$

En la figura 8.11 se muestran las gráficas de $\hat{T}_1$, $\hat{T}_2$, $\hat{T}_3$, $\hat{T}_4$ y $\hat{T}_5$.

Como $\hat{T}_n(x)$ es sólo un múltiplo de $T_n(x)$, el teorema 8.9 implica que los ceros de $\hat{T}_n(x)$ también ocurren en

$$\bar{x}_k = \cos\left(\frac{2k-1}{2n}\pi\right), \quad \text{para cada } k = 1, 2, \dots, n.$$

Figura 8.11



y que los valores extremos de $\tilde{T}_n(x)$, para $n \geq 1$, se presentan en

$$\bar{x}'_k = \cos\left(\frac{k\pi}{n}\right), \quad \text{con} \quad \tilde{T}_n(\bar{x}'_k) = \frac{(-1)^k}{2^{n-1}}, \quad \text{para cada } k = 0, 1, 2, \dots, n. \quad (8.13)$$

Denotemos con $\tilde{\Pi}_n$ el conjunto de todos los polinomios mónicos de n -ésimo grado. En la ecuación (8.13) se expresa la relación que da origen a una importante propiedad de minimización que distingue a $\tilde{T}_n(x)$ de otros miembros de $\tilde{\Pi}_n$.

Teorema 8.10 Los polinomios de la forma $\tilde{T}_n(x)$, cuando $n \geq 1$, tienen la propiedad de que

$$\frac{1}{2^{n-1}} = \max_{x \in [-1, 1]} |\tilde{T}_n(x)| \leq \max_{x \in [-1, 1]} |P_n(x)|, \quad \text{para cualquier } P_n(x) \in \tilde{\Pi}_n.$$

Además, la igualdad puede darse sólo si $P_n = \tilde{T}_n$. ■

Demostración Supongamos que $P_n(x) \in \tilde{\Pi}_n$ y que

$$\max_{x \in [-1, 1]} |P_n(x)| \leq \frac{1}{2^{n-1}} = \max_{x \in [-1, 1]} |\tilde{T}_n(x)|.$$

Sea $Q = \tilde{T}_n - P_n$. Como $\tilde{T}_n(x)$ y $P_n(x)$ son polinomios mónicos de n -ésimo grado, $Q(x)$ es un polinomio de grado a lo más $(n-1)$. Más aún, en los puntos extremos de $\tilde{T}_n(x)$,

$$Q(\bar{x}'_k) = \tilde{T}_n(\bar{x}'_k) - P_n(\bar{x}'_k) = \frac{(-1)^k}{2^{n-1}} - P_n(\bar{x}'_k).$$

Dado que

$$|P_n(\bar{x}'_k)| \leq \frac{1}{2^{n-1}}, \quad \text{para cada } k = 0, 1, \dots, n,$$

tenemos

$$Q(\bar{x}'_k) \leq 0 \quad \text{cuando } k \text{ es impar} \quad \text{y} \quad Q(\bar{x}'_k) \geq 0 \quad \text{cuando } k \text{ es par.}$$

Como Q es continua, el teorema de valor intermedio implica que el polinomio $Q(x)$ tiene, al menos, un cero entre $\bar{x}'_j$ y $\bar{x}'_{j+1}$ para cada $j = 0, 1, \dots, n-1$. Por tanto, Q tiene al menos n ceros en el intervalo $[-1, 1]$. Pero el grado de $Q(x)$ es menor que n , así que $Q = 0$. Ello implica que $P_n = \tilde{T}_n$. ■ ■ ■

Este teorema sirve para contestar la pregunta de dónde colocar los nodos interpolantes para reducir al mínimo el error de la interpolación de Lagrange. El teorema 3.3 aplicado al intervalo $[-1, 1]$ establece que si, $x_0, \dots, x_n$ son números distintos en el intervalo $[-1, 1]$ y si $f \in C^{n+1}[-1, 1]$, entonces, para cada $x \in [-1, 1]$, existe un número $\xi(x)$ en $(-1, 1)$ con

$$f(x) - P(x) = \frac{f^{(n+1)}(\xi(x))}{(n+1)!} (x-x_0)(x-x_1) \cdots (x-x_n),$$

donde $P(x)$ denota el polinomio interpolante de Lagrange. En general, no se tiene control sobre $\xi(x)$ por lo cual, para reducir al mínimo el error mediante una colocación habilidosa de los nodos $x_0, \dots, x_n$, obtenemos $x_0, \dots, x_n$ para reducir al mínimo la cantidad

$$|(x-x_0)(x-x_1) \cdots (x-x_n)|$$

a lo largo del intervalo $[-1, 1]$.

Puesto que $(x-x_0)(x-x_1) \cdots (x-x_n)$ es un polinomio mónico de grado $(n+1)$, acabamos de ver que el mínimo se obtiene si y sólo si

$$(x-x_0)(x-x_1) \cdots (x-x_n) = \tilde{T}_{n+1}(x).$$

El valor máximo de $|(x-x_0)(x-x_1) \cdots (x-x_n)|$ se minimiza cuando hacemos que x_k sea el $(k+1)$ -ésimo cero de $\tilde{T}_{n+1}$, para cada $k = 0, 1, \dots, n$, esto es, cuando x_k es

$$\bar{x}_{k+1} = \cos \frac{2k+1}{2(n+1)} \pi.$$

Como $\max_{x \in [-1, 1]} |\tilde{T}_{n+1}(x)| = 2^{-n}$, esto también implica que

$$\frac{1}{2^n} = \max_{x \in [-1, 1]} |(x-\bar{x}_1) \cdots (x-\bar{x}_{n+1})| \leq \max_{x \in [-1, 1]} |(x-x_0) \cdots (x-x_n)|$$

para cualquier selección de $x_0, x_1, \dots, x_n$ en el intervalo $[-1, 1]$. El siguiente corolario se extrae de esta explicación.

Corolario 8.11 Si $P(x)$ es el polinomio interpolante de grado a lo más n en las raíces de $\tilde{T}_{n+1}(x)$, entonces

$$\max_{x \in [-1, 1]} |f(x) - P(x)| \leq \frac{1}{2^n(n+1)!} \max_{x \in [-1, 1]} |f^{(n+1)}(x)|, \quad \text{para cada } f \in C^{n+1}[-1, 1].$$

■

Este método de seleccionar puntos para reducir al mínimo el error de interpolación, también se aplica a un intervalo cerrado general $[a, b]$ empleando el cambio de variables

$$\tilde{x} = \frac{1}{2}[(b - a)x + a + b]$$

para transformar los números $\tilde{x}_k$ del intervalo $[-1, 1]$ en el correspondiente número $\tilde{x}_k$ del intervalo $[a, b]$ como se muestra en el siguiente ejemplo.

EJEMPLO 1 Sea $f(x) = xe^x$ en el intervalo $[0, 1.5]$. Se construirán dos polinomios interpolantes de grado tres como máximo. Primero, empleamos los nodos uniformemente espaciados $x_0 = 0$, $x_1 = 0.5$, $x_2 = 1$ y $x_3 = 1.5$ para obtener

$$L_0(x) = -1.3333x^3 + 4.0000x^2 - 3.6667x + 1,$$

$$L_1(x) = 4.0000x^3 - 10.000x^2 + 6.0000x,$$

$$L_2(x) = -4.0000x^3 + 8.0000x^2 - 3.0000x,$$

$$L_3(x) = 1.3333x^3 - 2.000x^2 + 0.66667x.$$

En el caso de los valores que se dan en las dos primeras columnas de la tabla 8.7, el primer polinomio está dado por

$$P_3(x) = 1.3875x^3 + 0.057570x^2 + 1.2730x.$$

Tabla 8.7

x	$f(x) = xe^x$	$\tilde{x}$	$f(\tilde{x}) = xe^x$
$x_0 = 0.0$	0.00000	$\tilde{x}_0 = 1.44291$	6.10783
$x_1 = 0.5$	0.824361	$\tilde{x}_1 = 1.03701$	2.92517
$x_2 = 1.0$	2.71828	$\tilde{x}_2 = 0.46299$	0.73560
$x_3 = 1.5$	6.72253	$\tilde{x}_3 = 0.05709$	0.060444

En el caso del segundo polinomio interpolante, se transforman los ceros $\tilde{x}_k = \cos((2k + 1)/8)\pi$, cuando $k = 0, 1, 2, 3$, de $\tilde{T}_4$, desde $[-1, 1]$ a $[0, 1.5]$ mediante la transformación lineal

$$\tilde{x}_k = \frac{1}{2}[(1.5 - 0)\tilde{x}_k + (1.5 + 0)] = 0.75 + 0.75\tilde{x}_k$$

para obtener

$$\tilde{x}_0 = 1.44291, \quad \tilde{x}_1 = 1.03701, \quad \tilde{x}_2 = 0.46299 \quad \text{y} \quad \tilde{x}_3 = 0.05709.$$

Entonces, para este conjunto de nodos, los coeficientes polinomiales de Lagrange se calculan así:

$$\tilde{L}_0(x) = 1.8142x^3 - 2.8249x^2 + 1.0264x - 0.049728,$$

$$\tilde{L}_1(x) = -4.3799x^3 + 8.5977x^2 - 3.4026x + 0.16705,$$

$$\tilde{L}_2(x) = 4.3799x^3 - 11.112x^2 + 7.1738x - 0.37415,$$

$$\tilde{L}_3(x) = -1.8142x^3 + 5.3390x^2 - 4.7976x + 1.2568.$$

Los valores funcionales que se requieren en estos polinomios se dan en las dos últimas columnas de la tabla 8.7. El polinomio interpolante de grado a lo más tres está dado por


$$\tilde{P}_3(x) = 1.3811x^3 + 0.044652x^2 + 1.3031x - 0.014352.$$

Para efectos de comparación, en la tabla 8.8 se incluyen varios valores de x , junto con los valores de $f(x)$, $P_3(x)$ y de $\tilde{P}_3(x)$. De la tabla se puede ver que, aunque el error al utilizar $P_3(x)$ es menor que al utilizar $\tilde{P}_3(x)$ cerca de la mitad de la tabla, el error máximo que implica usar $\tilde{P}_3(x)$, 0.0180, es considerablemente menor que cuando se emplea $P_3(x)$, lo cual da el error 0.0290. (Véase la Fig. 8.12.) ■

Tabla 8.8

x	$f(x) = xe^x$	$P_3(x)$	$ xe^x - P_3(x) $	$\tilde{P}_3(x)$	$ xe^x - \tilde{P}_3(x) $
0.15	0.1743	0.1969	0.0226	0.1868	0.0125
0.25	0.3210	0.3435	0.0225	0.3358	0.0148
0.35	0.4967	0.5121	0.0154	0.5064	0.0097
0.65	1.245	1.233	0.012	1.231	0.014
0.75	1.588	1.572	0.016	1.571	0.017
0.85	1.989	1.976	0.013	1.974	0.015
1.15	3.632	3.650	0.018	3.644	0.012
1.25	4.363	4.391	0.028	4.382	0.019
1.35	5.208	5.237	0.029	5.224	0.016

Figura 8.12



Los polinomios de Chebyshev también sirven para disminuir el grado de un polinomio de aproximación, con una pérdida mínima de exactitud. Como estos polinomios tienen un valor absoluto mínimo/máximo que se distribuye uniformemente en el intervalo,

pueden usarse para reducir el grado de un polinomio de aproximación, sin que se rebase la tolerancia de error.

Por ejemplo, aproximemos un polinomio arbitrario de n -ésimo grado

$$P_n(x) = a_n x^n + a_{n-1} x^{n-1} + \cdots + a_1 x + a_0$$

en $[-1, 1]$ con un polinomio de grado $n-1$ como máximo. El objetivo es seleccionar $P_{n-1}(x)$ en Π_{n-1} de modo que

$$\max_{x \in [-1, 1]} |P_n(x) - P_{n-1}(x)|$$

sea lo menor posible.

Primero observamos que $(P_n(x) - P_{n-1}(x))/a_n$ es un polinomio mónico de n -ésimo grado. Al aplicar el teorema 8.10 obtenemos

$$\max_{x \in [-1, 1]} \left| \frac{1}{a_n} (P_n(x) - P_{n-1}(x)) \right| \geq \frac{1}{2^{n-1}}.$$

La igualdad ocurre precisamente cuando

$$\frac{1}{a_n} (P_n(x) - P_{n-1}(x)) = \tilde{T}_n(x).$$

Esto significa que deberemos seleccionar

$$P_{n-1}(x) = P_n(x) - a_n \tilde{T}_n(x),$$

y con esta elección tenemos el valor mínimo de

$$\max_{x \in [-1, 1]} |P_n(x) - P_{n-1}(x)| = |a_n| \max_{x \in [-1, 1]} \left| \frac{1}{a_n} (P_n(x) - P_{n-1}(x)) \right| = \frac{|a_n|}{2^{n-1}}.$$

EJEMPLO 2 Aproximaremos la función $f(x) = e^x$ en el intervalo $[-1, 1]$ mediante el cuarto polinomio de Maclaurin

$$P_4(x) = 1 + x + \frac{x^2}{2} + \frac{x^3}{6} + \frac{x^4}{24},$$

que tiene el error de truncamiento

$$|R_4(x)| = \frac{|f^{(5)}(\xi(x))||x^5|}{120} \leq \frac{e}{120} \approx 0.023, \quad \text{para } -1 \leq x \leq 1.$$

Supongamos que un error de 0.05 es tolerable y que nos gustaría reducir el grado del polinomio de aproximación sin rebasar esta cota.

El polinomio de tercer grado, o menor, que mejor aproxima uniformemente $P_4(x)$ en $[-1, 1]$ es

$$\begin{aligned} P_3(x) &= P_4(x) - a_4 \tilde{T}_4(x) = 1 + x + \frac{x^2}{2} + \frac{x^3}{6} + \frac{x^4}{24} - \frac{1}{24} \left(x^4 - x^2 + \frac{1}{8} \right) \\ &= \frac{191}{192} + x + \frac{13}{24} x^2 + \frac{1}{6} x^3. \end{aligned}$$

Con esta selección tenemos

$$|P_4(x) - P_3(x)| = |a_4 T_4(x)| \leq \frac{1}{24} \cdot \frac{1}{2^3} = \frac{1}{192} \leq 0.0053.$$

Al agregar esta cota de error a la cota del error de truncamiento de Maclaurin, obtenemos

$$0.023 + 0.0053 = 0.0283,$$

que se encuentra dentro del error permisible de 0.05.

El polinomio de segundo o menor grado que mejor aproxima uniformemente a $P_3(x)$ en $[-1, 1]$ es

$$\begin{aligned} P_2(x) &= P_3(x) - \frac{1}{6} T_3(x) \\ &= \frac{191}{192} + x + \frac{13}{24}x^2 + \frac{1}{6}x^3 - \frac{1}{6}\left(x^3 - \frac{3}{4}x\right) = \frac{191}{192} + \frac{9}{8}x + \frac{13}{24}x^2. \end{aligned}$$

Sin embargo,

$$|P_3(x) - P_2(x)| = \left| \frac{1}{6} T_3(x) \right| = \frac{1}{6} \left(\frac{1}{2} \right)^2 = \frac{1}{24} \approx 0.042,$$

que, al ser agregado a la cota de error ya acumulada de 0.0283, rebasa la tolerancia de 0.05. En consecuencia, el polinomio de menor grado que mejor aproxima a e^x en $[-1, 1]$ con una cota de error menor que 0.05 es

$$P_3(x) = \frac{191}{192} + x + \frac{13}{24}x^2 + \frac{1}{6}x^3.$$

La tabla 8.9 incluye la función y los polinomios de aproximación en varios puntos de $[-1, 1]$. Nótese que los valores tabulados de P_2 se encuentran, con mucho, dentro de la tolerancia de 0.05, aunque la cota de error de $P_2(x)$ la rebasa. ■

Tabla 8.9

x	e^x	$P_4(x)$	$P_3(x)$	$P_2(x)$	$ e^x - P_2(x) $
-0.75	0.47237	0.47412	0.47917	0.45573	0.01664
-0.25	0.77880	0.77881	0.77604	0.74740	0.03140
0.00	1.00000	1.00000	0.99479	0.99479	0.00521
0.25	1.28403	1.28402	1.28125	1.30990	0.02587
0.75	2.11700	2.11475	2.11979	2.14323	0.02623

CONJUNTO DE EJERCICIOS 8.3

- Use los ceros de T_3 y construya un polinomio interpolante de segundo grado para las siguientes funciones en el intervalo $[-1, 1]$.
 - $f(x) = e^x$
 - $f(x) = \sin x$
 - $f(x) = \ln(x + 2)$
 - $f(x) = x^4$

- Encuentre las cotas para el error máximo de las aproximaciones del ejercicio 1 en el intervalo $[-1, 1]$.
- Use los ceros de $\tilde{T}_4$ y construya un polinomio interpolante de tercer grado para las funciones del ejercicio 1.
- Repita el ejercicio 2 con las aproximaciones calculadas en el ejercicio 3.
- Use los ceros de $\tilde{T}_3$ y las transformaciones del intervalo dado, y construya un polinomio interpolante de segundo grado para las siguientes funciones.

a. $f(x) = \frac{1}{x}, \quad [1, 3]$

b. $f(x) = e^{-x}, \quad [0, 2]$

c. $f(x) = \frac{1}{2} \cos x + \frac{1}{3} \sin 2x, \quad [0, 1]$

d. $f(x) = x \ln x, \quad [1, 3]$

- Encuentre el sexto polinomio de Maclaurin para xe^x , y con la economización de Chebyshev obtenga una aproximación de menor grado, sin que el error sea mayor que 0.01 en $[-1, 1]$.
- Encuentre el sexto polinomio de Maclaurin para $\sin x$ y use la economización de Chebyshev para obtener una aproximación polinomial de menor grado, sin que el error sea mayor que 0.01 en $[-1, 1]$.
- Demuestre que para cualesquiera enteros positivos i y j con $i > j$, tenemos que $T_i(x)T_j(x) = \frac{1}{2}[T_{i+j}(x) + T_{i-j}(x)]$.
- Demuestre que para cualquier polinomio de Chebyshev $T_n(x)$, tenemos

$$\int_{-1}^1 \frac{|T_n(x)|^2}{\sqrt{1-x^2}} dx = \frac{\pi}{2}.$$

8.4 Aproximación mediante la función racional

Los polinomios algebraicos ofrecen ventajas muy claras que pueden emplearse en la aproximación:

- se cuenta con suficientes polinomios para aproximar una función continua en un intervalo cerrado sin exceder una tolerancia arbitraria;
- los polinomios se evalúan fácilmente en valores arbitrarios y
- hay derivadas e integrales de polinomios que pueden determinarse fácilmente.

La desventaja del uso de los polinomios en la aproximación es su tendencia a oscilar. A menudo esto hace que en la aproximación polinomial las cotas de error rebasen significativamente el error promedio de aproximación, pues las cotas de error se determinan mediante el error máximo de aproximación. En esta sección estudiaremos los métodos que distribuyen ese error más uniformemente en el intervalo de aproximación. En estas técnicas intervienen las funciones racionales.

Una función racional r de grado N tiene la forma

$$r(x) = \frac{p(x)}{q(x)},$$

donde $p(x)$ y $q(x)$ son los polinomios cuyos grados suman N .

Todo polinomio es una función racional (tomemos simplemente $q(x) = 1$), y por eso la aproximación mediante funciones racionales genera resultados que no son peores a los que se consiguen por medio de la aproximación con polinomios. Sin embargo, las funcio-

nes racionales cuyo numerador y denominador tienen el mismo grado o un grado casi idéntico producen resultados superiores a los métodos que usan polinomios, y ello con la misma cantidad de cálculos. (Esta afirmación se basa en la suposición de que los cálculos requeridos en la división son aproximadamente iguales a los de la multiplicación.) Las funciones racionales ofrecen una ventaja más: permiten una aproximación eficiente de las funciones que tienen discontinuidades infinitas cerca del intervalo de aproximación, pero fuera de él. En este caso, la aproximación polinomial casi siempre resulta inaceptable.

Supongamos que r es una función racional de grado $N = n + m$ de la forma

$$r(x) = \frac{p(x)}{q(x)} = \frac{p_0 + p_1x + \cdots + p_nx^n}{q_0 + q_1x + \cdots + q_mx^m},$$

por medio de la cual aproximamos una función f en un intervalo cerrado I que contiene al cero. Para que r esté definida en cero se requiere que $q_0 \neq 0$. Podemos suponer que $q_0 = 1$, porque de no ser así simplemente reemplazamos $p(x)$ por $p(x)/q_0$ y $q(x)$ por $q(x)/q_0$. En consecuencia, hay $N + 1$ parámetros $q_1, q_2, \dots, q_m, p_0, p_1, \dots, p_n$ disponibles para aproximar f por medio de r .

El método de aproximación de Padé selecciona los $N + 1$ parámetros de modo que $f^{(k)}(0) = r^{(k)}(0)$ para cada $k = 0, 1, \dots, N$. La aproximación de Padé es una extensión de la aproximación polinomial de Taylor a las funciones racionales. De hecho, cuando $n = N$ y $m = 0$, la aproximación de Padé es simplemente el N -ésimo polinomio de Maclaurin.

Consideremos la diferencia

$$f(x) - r(x) = f(x) - \frac{p(x)}{q(x)} = \frac{f(x)q(x) - p(x)}{q(x)} = \frac{f(x) \sum_{i=0}^m q_i x^i - \sum_{i=0}^n p_i x^i}{q(x)},$$

y supongamos que f tiene la expansión de la serie de Maclaurin $f(x) = \sum_{i=0}^{\infty} a_i x^i$. Entonces

$$f(x) - r(x) = \frac{\sum_{i=0}^{\infty} a_i x^i \sum_{i=0}^m q_i x^i - \sum_{i=0}^n p_i x^i}{q(x)}. \quad (8.14)$$

El objetivo es seleccionar las constantes $q_1, q_2, \dots, q_m$ y $p_0, p_1, \dots, p_n$ de tal forma que

$$f^{(k)}(0) - r^{(k)}(0) = 0, \quad \text{para cada } k = 0, 1, \dots, N.$$

En la sección 2.4 (véase, en especial, el ejercicio 10) comprobamos que lo anterior equivale a que $f - r$ tenga un cero de multiplicidad $N + 1$ en $x = 0$. En consecuencia, seleccionamos $q_1, q_2, \dots, q_m$ y $p_0, p_1, \dots, p_n$ de manera que el numerador del lado derecho de la ecuación (8.14),

$$(a_0 + a_1x + \cdots)(1 + q_1x + \cdots + q_mx^m) - (p_0 + p_1x + \cdots + p_nx^n), \quad (8.15)$$

no tenga términos de un grado menor o igual que N .

Con el fin de simplificar la notación definimos $p_{n+1} = p_{n+2} = \cdots = p_N = 0$ y $q_{m+1} = q_{m+2} = \cdots = q_N = 0$. Ahora podemos escribir el coeficiente de x^k en la expresión (8.15) así

$$\left(\sum_{i=0}^k a_i q_{k-i} \right) - p_k.$$

Por tanto, la función racional de la aproximación de Padé proviene de la solución de las $N + 1$ ecuaciones lineales:

$$\sum_{i=0}^k a_i q_{i-1} = p_k, \quad k = 0, 1, \dots, N$$

en las $N + 1$ incógnitas $q_1, q_2, \dots, q_m, p_0, p_1, \dots, p_n$.

EJEMPLO 1 El desarrollo de la serie de Maclaurin para e^{-x} es

$$\sum_{i=0}^{\infty} \frac{(-1)^i}{i!} x^i.$$

Para encontrar la aproximación de Padé a e^{-x} de quinto grado con $n = 3$ y $m = 2$ se requiere seleccionar p_0, p_1, p_2, p_3, q_1 y q_2 de manera que los coeficientes de x^k para $k = 0, 1, \dots, 5$ sean cero en la expresión

$$\left(1 - x + \frac{x^2}{2} - \frac{x^3}{6} + \dots\right) (1 + q_1 x + q_2 x^2) - (p_0 + p_1 x + p_2 x^2 + p_3 x^3).$$

Al expandir y agrupar los términos obtenemos

$$\begin{aligned} x^5: \quad & -\frac{1}{120} + \frac{1}{24} q_1 - \frac{1}{6} q_2 = 0; & x^2: \quad & \frac{1}{2} - q_1 + q_2 = p_2; \\ x^4: \quad & \frac{1}{24} - \frac{1}{6} q_1 + \frac{1}{2} q_2 = 0; & x^1: \quad & -1 + q_1 = p_1; \\ x^3: \quad & -\frac{1}{6} + \frac{1}{2} q_1 - q_2 = p_3; & x^0: \quad & 1 = p_0. \end{aligned}$$

Para resolver el sistema en Maple usamos los siguientes comandos:

```
>eq1:=-1+q1=p1;
>eq2:=1/2-q1+q2=p2;
>eq3:=-1/6+1/2*q1-q2=p3;
>eq4:=1/24-1/6*q1+1/2*q2=0;
>eq5:=1/120+1/24*q1-1/6*q2=0;
>solve({eq1,eq2,eq3,eq4,eq5},{q1,q2,p1,p2,p3});
```

lo que da

$$p_0 = 1, \quad p_1 = -\frac{3}{5}, \quad p_2 = \frac{3}{20}, \quad p_3 = -\frac{1}{60}, \quad q_1 = \frac{2}{5} \quad \text{y} \quad q_2 = \frac{1}{20}.$$

Tabla 8.10

x	e^{-x}	$P_5(x)$	$ e^{-x} - P_5(x) $	$r(x)$	$ e^{-x} - r(x) $
0.2	0.81873075	0.81873067	8.64×10^{-8}	0.81873075	7.55×10^{-9}
0.4	0.67032005	0.67031467	5.38×10^{-6}	0.67031963	4.11×10^{-7}
0.6	0.54881164	0.54875200	5.96×10^{-5}	0.54880763	4.00×10^{-6}
0.8	0.44932896	0.44900267	3.26×10^{-4}	0.44930966	1.93×10^{-5}
1.0	0.36787944	0.36666667	1.21×10^{-3}	0.36781609	6.33×10^{-5}

Por tanto, la aproximación de Padé es

$$r(x) = \frac{1 - \frac{3}{5}x + \frac{3}{20}x^2 - \frac{1}{60}x^3}{1 + \frac{3}{5}x + \frac{1}{20}x^2}.$$

En la tabla 8.10 se dan los valores de $r(x)$ y $P_5(x)$, el quinto polinomio de Maclaurin. En este ejemplo la aproximación de Padé es evidentemente superior. ■

Con Maple puede calcularse la aproximación de Padé. Primero se calcula la serie de Maclaurin con el comando:

```
>series(exp(-x),x);
```

para obtener

$$1 - x + \frac{1}{2}x^2 - \frac{1}{6}x^3 + \frac{1}{24}x^4 - \frac{1}{120}x^5 + O(x^6).$$

La aproximación de Padé con $n = 3$ y $m = 2$ se calcula mediante el comando

```
>g:=convert(%,ratpoly,3,2);
```

donde % se refiere al resultado del cálculo anterior, o sea a la serie. El resultado es

$$g := \frac{1 - \frac{3}{5}x + \frac{3}{20}x^2 - \frac{1}{60}x^3}{1 + \frac{3}{5}x + \frac{1}{20}x^2},$$

y entonces podemos calcular $g(0.8)$ introduciendo

```
>evalf(subs(x=0.8,g));
```

para obtener .4493096647.

En el algoritmo 8.1 se ejecuta el método de aproximación de Padé.

ALGORITMO 8.1

Método de aproximación racional de Padé

Para obtener la aproximación racional

$$r(x) = \frac{p(x)}{q(x)} = \frac{\sum_{i=0}^n p_i x^i}{\sum_{j=0}^m q_j x^j}$$

para determinada función $f(x)$:

ENTRADA enteros no negativos m y n .

SALIDA coeficientes $q_0, q_1, \dots, q_m$ y $p_0, p_1, \dots, p_n$.

Paso 1 Tome $N = m + n$.

Paso 2 Para $i = 0, 1, \dots, N$ tome $a_i = \frac{f^{(i)}(0)}{i!}$.

(Los coeficientes del polinomio de Maclaurin son $a_0, \dots, a_N$, los cuales se pueden introducir en lugar de calcularse.)

Paso 3 Tome $q_0 = 1$;

$$p_0 = a_0.$$

Paso 4 Para $i = 1, 2, \dots, N$ haga los pasos 5-10. (Utilice un sistema lineal con matriz B .)

Paso 5 Para $j = 1, 2, \dots, i - 1$
si $j \leq n$ entonces tome $b_{i,j} = 0$.

Paso 6 Si $i \leq n$ entonces tome $b_{i,i} = 1$.

Paso 7 Para $j = i + 1, i + 2, \dots, N$ tome $b_{i,j} = 0$.

Paso 8 Para $j = 1, 2, \dots, i$
si $j \leq m$ entonces tome $b_{i,n+j} = -a_{i-j}$.

Paso 9 Para $j = n + i + 1, n + i + 2, \dots, N$ tome $b_{i,j} = 0$.

Paso 10 Tome $b_{i,n+1} = a_i$.

(Pasos 11-22 resuelven el sistema lineal usando el pivoteo parcial.)

Paso 11 Para $i = n + 1, n + 2, \dots, N - 1$ haga los pasos 12-18.

Paso 12 Sea k el entero más pequeño con $i \leq k \leq N$ y $|b_{k,i}| = \max_{i \leq j \leq N} |b_{j,i}|$.
(Obtenga el elemento de pivote.)

Paso 13 Si $b_{k,i} = 0$ entonces SALIDA ("El sistema es singular");
PARAR.

Paso 14 Si $k \neq i$ entonces (Intercambie el renglón i y el renglón k)
para $j = i, i + 1, \dots, N + 1$ tome

$$\begin{aligned} b_{\text{copy}} &= b_{i,j}; \\ b_{i,j} &= b_{k,j}; \\ b_{k,j} &= b_{\text{copy}} \end{aligned}$$

Paso 15 Para $j = i + 1, i + 2, \dots, N$ haga los pasos 16-18. (Efectúe la eliminación.)

Paso 16 Tome $xm = \frac{b_{j,i}}{b_{i,i}}$.

Paso 17 Para $k = i + 1, i + 2, \dots, N + 1$
tome $b_{j,k} = b_{j,k} - xm \cdot b_{i,k}$.

Paso 18 Tome $b_{j,i} = 0$.

Paso 19 Si $b_{N,N} = 0$ entonces SALIDA ("El sistema es singular");
PARAR.

Paso 20 Si $m > 0$ entonces tome $q_m = \frac{b_{N,N+1}}{b_{N,N}}$. (Comience la sustitución hacia atrás.)

Paso 21 Para $i = N - 1, N - 2, \dots, n + 1$ tome $q_{i-n} = \frac{b_{i,N+1} - \sum_{j=i+1}^N b_{i,j} q_{j-n}}{b_{i,i}}$.

Paso 22 Para $i = n, n-1, \dots, 1$ tome $p_i = b_{i,n+1} - \sum_{j=i+1}^N b_{ij} q_{j-n}$.

Paso 23 SALIDA ($q_0, q_1, \dots, q_n, p_0, p_1, \dots, p_n$);

PARAR. (Procedimiento terminado exitosamente.) ■

Es interesante comparar la cantidad de operaciones aritméticas necesarias para calcular $P_5(x)$ y $r(x)$ en el ejemplo 1. Si usamos la multiplicación anidada, $P_5(x)$ puede expresarse como

$$P_5(x) = \left(\left(\left(\left(-\frac{1}{120}x + \frac{1}{24} \right)x - \frac{1}{6} \right)x + \frac{1}{2} \right)x - 1 \right)x + 1.$$

Suponiendo que los coeficientes de $1, x, x^2, x^3, x^4$ y x^5 se representan como decimales, un solo cálculo de $P_5(x)$ en forma anidada requiere cinco multiplicaciones y cinco sumas/restas.

Al utilizar la multiplicación anidada, $r(x)$ se expresa así

$$r(x) = \frac{\left(\left(-\frac{1}{60}x + \frac{1}{20} \right)x - \frac{3}{5} \right)x + 1}{\left(\frac{1}{20}x + \frac{2}{5} \right)x + 1},$$

y, por tanto, un solo cálculo de $r(x)$ requiere cinco multiplicaciones, cinco sumas/restas y una división. En consecuencia, el esfuerzo de cálculo requerido parece favorecer a la aproximación polinomial. Pero, al reexpresar $r(x)$ mediante la división continua, podemos escribir

$$\begin{aligned} r(x) &= \frac{1 - \frac{3}{5}x + \frac{3}{20}x^2 - \frac{1}{60}x^3}{1 + \frac{1}{5}x + \frac{1}{20}x^2} \\ &= \frac{-\frac{1}{3}x^3 + 3x^2 - 12x + 20}{x^2 + 8x + 20} \\ &= -\frac{1}{3}x + \frac{17}{3} + \frac{(-\frac{152}{3}x - \frac{280}{3})}{x^2 + 8x + 20} \\ &= -\frac{1}{3}x + \frac{17}{3} + \frac{-\frac{152}{3}}{\left(x + \frac{117}{19} + \frac{3125/361}{x + (35/19)} \right)} \end{aligned}$$

o bien

$$r(x) = -\frac{1}{3}x + \frac{17}{3} + \frac{-\frac{152}{3}}{\left(x + \frac{117}{19} + \frac{3125/361}{x + (35/19)} \right)} \quad (8.16)$$

Escrito de esta forma, un cálculo simple de $r(x)$ requiere una multiplicación, cinco sumas/restas y dos divisiones. Si la cantidad de cálculos necesarios en la división es aproximadamente igual a la que se requiere en la multiplicación, el esfuerzo de cálculo necesario para evaluar $P_5(x)$ es significativamente mayor que el que se realiza al evaluar $r(x)$.

Se da el nombre de aproximación por **fracción continua**, al hecho de expresar una aproximación de función racional en una forma como la de la ecuación (8.16). Es una técnica clásica de aproximación de gran interés actual, porque esta representación es eficiente.

te desde el punto de vista de cálculos requeridos. Sin embargo, se trata de una técnica especializada de la cual no nos ocuparemos más. Un tratamiento bastante exhaustivo de este tema y de la aproximación racional en general se encuentra en [RR, pp. 285-322].

Aunque la aproximación de la función racional del ejemplo 1 dio resultados mejores que los de la aproximación polinomial del mismo grado, la aproximación presenta una exactitud extremadamente variable. La aproximación en 0.2 tiene una exactitud de 8×10^{-9} , mientras que en 1.0 la aproximación y la función concuerdan apenas con una exactitud de 7×10^{-5} . Esta variación de la exactitud es previsible, porque la aproximación de Padé se basa en la representación de e^{-x} , con el polinomio de Taylor, y esta representación presenta una variación de exactitud muy amplia en $[0.2, 1.0]$.

Para obtener una aproximación de la función racional que sea uniformemente más exacta, utilizamos los polinomios de Chebyshev. El método general de la aproximación de Chebyshev a la función racional funciona de la misma manera que la aproximación de Padé, salvo que todo término x^k en la primera se reemplaza con el k -ésimo polinomio $T_k(x)$ de Chebyshev.

Supóngase que queremos aproximar la función f mediante una función racional r de N -ésimo grado, escrita en la forma

$$r(x) = \frac{\sum_{k=0}^n p_k T_k(x)}{\sum_{k=0}^m q_k T_k(x)}, \quad \text{cuando } N = n + m \text{ y } q_0 = 1.$$

Al escribir $f(x)$ en una serie que contenga los polinomios de Chebyshev, obtenemos

$$f(x) = \sum_{k=0}^{\infty} a_k T_k(x)$$

dato

$$f(x) - r(x) = \sum_{k=0}^{\infty} a_k T_k(x) - \frac{\sum_{k=0}^n p_k T_k(x)}{\sum_{k=0}^m q_k T_k(x)}$$

o bien

$$f(x) - r(x) = \frac{\sum_{k=0}^{\infty} a_k T_k(x) \sum_{k=0}^m q_k T_k(x) - \sum_{k=0}^n p_k T_k(x)}{\sum_{k=0}^m q_k T_k(x)}. \quad (8.17)$$

Se eligen los coeficientes $q_1, q_2, \dots, q_m$ y $p_0, p_1, \dots, p_n$ de modo que el numerador del lado derecho de esta ecuación tenga coeficientes cero para $T_k(x)$ cuando $k = 0, 1, \dots, N$. Esto significa que

$$(a_0 T_0(x) + a_1 T_1(x) + \dots)(T_0(x) + q_1 T_1(x) + \dots + q_m T_m(x)) - (p_0 T_0(x) + p_1 T_1(x) + \dots + p_n T_n(x))$$

no tiene términos de un grado menor o igual que N .

En el procedimiento de Chebyshev surgen dos problemas que lo hacen un método más difícil de implantar que el método de Padé. Uno de ellos se da porque el producto del polinomio $q(x)$ y la serie de $f(x)$ contienen productos de los polinomios de Chebyshev. Este problema se resuelve utilizando la relación

$$T_i(x) T_j(x) = \frac{1}{2} [T_{i+j}(x) + T_{|i-j|}(x)]. \quad (8.18)$$

(Véase el ejercicio 8 de la sección 8.3.) El otro problema es más difícil de resolver y requiere el cálculo de la serie de Chebyshev para $f(x)$. En teoría, no es más fácil porque si

$$f(x) = \sum_{k=0}^{\infty} a_k T_k(x),$$

entonces la ortogonalidad de los polinomios de Chebyshev implica que

$$a_0 = \frac{1}{\pi} \int_{-1}^1 \frac{f(x)}{\sqrt{1-x^2}} dx \quad \text{y} \quad a_k = \frac{2}{\pi} \int_{-1}^1 \frac{f(x) T_k(x)}{\sqrt{1-x^2}} dx, \quad \text{donde } k \geq 1.$$

No obstante, en la práctica estas integrales rara vez se evalúan en forma cerrada, y para cada evaluación se requiere un método de integración numérica.

EJEMPLO 2 Los cinco primeros términos de la expansión de Chebyshev para e^{-x} son

$$\begin{aligned} \tilde{P}_5(x) = & 1.266066T_0(x) - 1.130318T_1(x) + 0.271495T_2(x) - 0.044337T_3(x) \\ & + 0.005474T_4(x) - 0.000543T_5(x). \end{aligned}$$

Para determinar la aproximación racional de quinto grado de Chebyshev con $n = 3$ y $m = 2$ se requiere seleccionar p_0, p_1, p_2, p_3, q_1 y q_2 tales que para $k = 0, 1, 2, 3, 4$ y 5 los coeficientes de $T_k(x)$ sean cero en la expansión

$$\tilde{P}_5(x)[T_0(x) + q_1T_1(x) + q_2T_2(x)] - [p_0T_0(x) + p_1T_1(x) + p_2T_2(x) + p_3T_3(x)].$$

Al usar la relación (8.18) y al reunir los términos, obtenemos las ecuaciones

$$\begin{aligned} T_0: & 1.266066 - 0.565159q_1 + 0.1357485q_2 = p_0, \\ T_1: & -1.130318 + 1.401814q_1 - 0.587328q_2 = p_1, \\ T_2: & 0.271495 - 0.587328q_1 + 1.268803q_2 = p_2, \\ T_3: & -0.044337 + 0.138485q_1 - 0.565431q_2 = p_3, \\ T_4: & 0.005474 - 0.022440q_1 + 0.135748q_2 = 0, \\ T_5: & -0.000543 + 0.002737q_1 - 0.022169q_2 = 0. \end{aligned}$$

La solución de este sistema genera la función racional

$$r_T(x) = \frac{1.055265T_0(x) - 0.613016T_1(x) + 0.077478T_2(x) - 0.004506T_3(x)}{T_0(x) + 0.378331T_1(x) + 0.022216T_2(x)}$$

Al inicio de la sección 8.3 encontramos que

$$T_0(x) = 1, \quad T_1(x) = x, \quad T_2(x) = 2x^2 - 1, \quad T_3(x) = 4x^3 - 3x.$$

Al usar esos valores para convertir la expresión anterior en una expresión que contenga potencias de x , obtenemos

$$r_T(x) = \frac{0.977787 - 0.599499x + 0.154956x^2 - 0.018022x^3}{0.977784 + 0.378331x + 0.044432x^2}.$$

La tabla 8.11 contiene los valores de $r_T(x)$ y para facilitar la comparación los valores de $r(x)$ que se obtuvieron en el ejemplo 1. Obsérvese que la aproximación dada por $r(x)$ es superior a la de $r_T(x)$ para $x = 0.2$ y 0.4 ; pero el error máximo de $r(x)$ es 6.33×10^{-5} en comparación con 9.13×10^{-6} para $r_T(x)$. ■

Tabla 8.11

x	e^{-x}	$r(x)$	$ e^{-x} - r(x) $	$r_T(x)$	$ e^{-x} - r_T(x) $
0.2	0.81873075	0.81873075	7.55×10^{-9}	0.81872510	5.66×10^{-6}
0.4	0.67032005	0.67031963	4.11×10^{-7}	0.67031310	6.95×10^{-6}
0.6	0.54881164	0.54880763	4.00×10^{-6}	0.54881292	1.28×10^{-6}
0.8	0.44932896	0.44930966	1.93×10^{-5}	0.44933809	9.13×10^{-6}
1.0	0.36787944	0.36781609	6.33×10^{-5}	0.36787155	7.89×10^{-6}

La aproximación de Chebyshev puede generarse por medio del algoritmo 8.2.

ALGORITMO 8.2

Aproximación racional de Chebyshev

Para obtener la aproximación racional

$$r_T(x) = \frac{\sum_{k=0}^n p_k T_k(x)}{\sum_{k=0}^m q_k T_k(x)}$$

de una función determinada $f(x)$:

ENTRADA enteros no negativos m y n .

SALIDA coeficientes $q_0, q_1, \dots, q_m$ y $p_0, p_1, \dots, p_n$.

Paso 1 Tome $N = m + n$.

Paso 2 Tome $a_0 = \frac{2}{\pi} \int_0^\pi f(\cos \theta) d\theta$. (El coeficiente a_0 es doble para lograr la eficiencia en el proceso de cálculo.)

Para $k = 1, 2, \dots, N + m$ tome

$$a_k = \frac{2}{\pi} \int_0^\pi f(\cos \theta) \cos k\theta d\theta.$$

(Las integrales se pueden evaluar usando un procedimiento de integración numérica o los coeficientes pueden introducirse directamente.)

Paso 3 Tome $q_0 = 1$.

Paso 4 Para $i = 0, 1, \dots, N$ haga pasos 5-9. (Utilice un sistema lineal con matriz B .)

Paso 5 Para $j = 0, 1, \dots, i$
si $j \leq n$ entonces tome $b_{ij} = 0$.

Paso 6 Si $i \leq n$ entonces tome $b_{ij} = 1$.

Paso 7 Para $j = i + 1, i + 2, \dots, n$ tome $b_{ij} = 0$.

Paso 8 Para $j = n + 1, n + 2, \dots, N$

si $i \neq 0$ entonces tome $b_{i,j} = -\frac{1}{2} (a_{i+j-n} + a_{i-j+n})$

si no, tome $b_{i,j} = -\frac{1}{2} a_{j-n}$.

Paso 9 Si $i \neq 0$ entonces tome $b_{i,N+1} = a_i$

si no, tome $b_{i,N+1} = \frac{1}{2} a_i$.

(Los pasos 10-21 resuelven el sistema lineal usando el pivoteo parcial.)

Paso 10 Para $i = n+1, n+2, \dots, N-1$ haga los pasos 11-17.

Paso 11 Sea k el entero más pequeño con $i \leq k \leq N$ y

$|b_{k,i}| = \max_{i \leq j \leq N} |b_{j,i}|$. (Obtenga el elemento de pivote.)

Paso 12 Si $b_{k,i} = 0$ entonces SALIDA ("El sistema es singular").

PARAR.

Paso 13 Si $k \neq i$ entonces (Intercambie el renglón i y el renglón k .)

para $j = i, i+1, \dots, N+1$ tome

$b_{copy} = b_{i,j}$

$b_{i,j} = b_{k,j}$

$b_{k,j} = b_{copy}$

Paso 14 Para $j = i+1, i+2, \dots, N$ haga los pasos 15-17. (Efectúe la eliminación.)

Paso 15 Tome $xm = \frac{b_{j,i}}{b_{i,i}}$.

Paso 16 Para $k = i+1, i+2, \dots, N+1$

tome $b_{j,k} = b_{j,k} - xm \cdot b_{i,k}$.

Paso 17 Tome $b_{j,i} = 0$.

Paso 18 Si $b_{N,N} = 0$ entonces SALIDA ("El sistema es singular");

PARAR.

Paso 19 Si $m > 0$ entonces tome $q_m = \frac{b_{N,N+1}}{b_{N,N}}$. (Comience la sustitución hacia atrás.)

Paso 20 Para $i = N-1, N-2, \dots, n+1$ tome $q_{i-n} = \frac{b_{i,N+1} - \sum_{j=i+1}^N b_{i,j} q_{j-n}}{b_{i,i}}$.

Paso 21 Para $i = n, n-1, \dots, 0$ tome $p_i = b_{i,N+1} - \sum_{j=n+1}^N b_{i,j} q_{j-n}$.

Paso 22 SALIDA ($q_0, q_1, \dots, q_m, p_0, p_1, \dots, p_n$);

PARAR. (Procedimiento terminado exitosamente.) ■

Mediante el uso de Maple podemos obtener la expansión de la serie de Chebyshev y la aproximación racional de Chebyshev. Para hacer los polinomios de Chebyshev accesibles a Maple se introduce el comando

```
>with(orthopoly,T);
```

El procedimiento para calcular la serie de Chebyshev como una aproximación es

```
>g:=numapprox[chebyshev](exp(-x),x,0.000001);
```

donde el tercer parámetro especifica la exactitud requerida. El resultado es

$$\begin{aligned} g:= & 1.266065878 T(0, x) - 1.130318208 T(1, x) + .2714953396 T(2, x) \\ & - .04433684985 T(3, x) + .005474240442 T(4, x) \\ & - .0005429263119 T(5, x) + .00004497732296 T(6, x) \\ & - .3198436462 \cdot 10^{-5} T(7, x) \end{aligned}$$

y podemos evaluar $g(0.8)$ utilizando

```
>evalf(subs(x=0.8,g));
```

para obtener .4493288893.

Para obtener la aproximación racional de Chebyshev, partimos de la serie de Chebyshev

```
>restart;
>numapprox[chebyshev](exp(-x),x,0.000001);
```

como antes, y luego introducimos

```
>g:=convert(%,ratpoly,3,2);
```

que da por resultado

$$\begin{aligned} g:= & (1.050531166 T(0, x) - .6016362122 T(1, x) + .07417897149 T(2, x) \\ & - .004109558353 T(3, x))/(T(0, x) + .3870509565 T(1, x) \\ & + .02365167312 T(2, x)) \end{aligned}$$

Como ya vaciamos la memoria de Maple, necesitamos reintroducir el comando

```
>with(orthopoly,T);
```

para que podamos evaluar $g(0.8)$ mediante

```
>evalf(subs(x=0.8,g));
```

y obtener .4493317579.

El método de Chebyshev no produce la mejor aproximación de la función racional, en el sentido de la aproximación cuyo error máximo sea el menor posible. No obstante, podemos usar este método como punto de arranque de un procedimiento iterativo denominado segundo algoritmo de Remes que converge a la mejor aproximación. En [RR, pp. 292-305] y en [Po, pp. 90-92] encontramos una explicación de las técnicas de que consta este método y un perfeccionamiento de este algoritmo.

CONJUNTO DE EJERCICIOS 8.4

- Determine todas las aproximaciones de Padé de segundo grado para $f(x) = e^{2x}$. Compare los resultados en $x_i = 0.2i$, para $i = 1, 2, 3, 4, 5$, con los valores reales $f(x_i)$.
- Determine todas las aproximaciones de Padé de tercer grado para $f(x) = x \ln(x+1)$. Compare los resultados en $x_i = 0.2i$, para $i = 1, 2, 3, 4, 5$, con los valores reales $f(x_i)$.
- Determine la aproximación de Padé de quinto grado con $n = 2$ y $m = 3$ para $f(x) = e^x$. Compare los resultados en $x_i = 0.2i$, para $i = 1, 2, 3, 4, 5$, con los del quinto polinomio de Maclaurin.
- Repita el ejercicio 3 usando esta vez la aproximación de Padé de quinto grado con $n = 3$ y $m = 2$. Compare los resultados en x_i con los que se obtuvieron en el ejercicio 3.
- Determine la aproximación de Padé de sexto grado con $n = m = 3$ para $f(x) = \sin x$. Compare los resultados en $x_i = 0.1i$, para $i = 0, 1, \dots, 5$, con los resultados exactos y con los del sexto polinomio de Maclaurin.
- Determine las aproximaciones de sexto grado de Padé con (a) $n = 2, m = 4$ y (b) $n = 4, m = 2$ para $f(x) = \sin x$. Compare los resultados en cada x_i con los obtenidos en el ejercicio 5.
- La tabla 8.10 contiene los resultados de la aproximación de Padé de quinto grado con $n = 3$ y $m = 2$, el quinto polinomio de Maclaurin, y los valores exactos de $f(x) = e^{-x}$ cuando $x_i = 0.2i$, para $i = 1, 2, 3, 4$ y 5. Compare estos resultados con los producidos en otras aproximaciones de Padé de quinto grado.

a. $n = 0, m = 5$

b. $n = 1, m = 4$

c. $n = 3, m = 2$

d. $n = 4, m = 1$

- Expresé las siguientes funciones racionales en forma de fracción continua:

a. $\frac{x^2 + 3x + 2}{x^2 - x + 1}$

b. $\frac{4x^2 + 3x - 7}{2x^3 + x^2 - x + 5}$

c. $\frac{2x^3 - 3x^2 + 4x - 5}{x^2 + 2x + 4}$

d. $\frac{2x^3 + x^2 - x + 3}{3x^3 + 2x^2 - x + 1}$

- Obtenga todas las aproximaciones racionales de Chebyshev de segundo grado para $f(x) = e^{-x}$. ¿Cuáles ofrecen las mejores aproximaciones a $f(x) = e^{-x}$ en $x = 0.25, 0.5$ y 1?
- Obtenga todas las aproximaciones racionales de Chebyshev de tercer grado para $f(x) = \cos x$. ¿Cuáles ofrecen las mejores aproximaciones a $f(x) = \cos x$ para $x = \pi/4$ y $\pi/3$?
- Obtenga la aproximación racional de Chebyshev de cuarto grado con $n = m = 2$ para $f(x) = \sin x$. Compare los resultados en $x_i = 0.1i$, para $i = 0, 1, 2, 3, 4, 5$ con los obtenidos en el ejercicio 5 mediante la aproximación de Padé de sexto grado.
- Obtenga todas las aproximaciones racionales de Chebyshev de quinto grado para $f(x) = e^x$. Compare los resultados en $x_i = 0.2i$, para $i = 1, 2, 3, 4, 5$ obtenidos con esta aproximación con los obtenidos en los ejercicios 3 y 4.
- Si queremos aproximar exactamente $f(x) = e^x$ para su inclusión en una biblioteca de matemáticas, primero restringimos el dominio de f . Dado un número real x , divídalo entre $\ln \sqrt{10}$ para obtener la relación

$$x = M \cdot \ln \sqrt{10} + s,$$

donde M es un entero y s es un número real que satisface $|s| \leq \frac{1}{2} \ln \sqrt{10}$.

- Demuestre que $e^x = e^s \cdot 10^{M/2}$.

- b. Construya una aproximación de la función racional para e^x usando $n = m = 3$. Estime el error cuando $0 \leq |x| \leq \frac{1}{2} \ln \sqrt{10}$.
- c. Diseñe una implantación de e^x usando los resultados de las partes (a) y (b) y las aproximaciones

$$\frac{1}{\ln \sqrt{10}} = 0.8685889638 \quad \text{y} \quad \sqrt{10} = 3.162277660.$$

14. Si queremos aproximar exactamente $\sin x$ y $\cos x$ para su inclusión en una biblioteca de matemáticas, primero restringimos sus dominios. Dado un número real x , divídalo entre π para obtener la relación

$$|x| = M\pi + s, \quad \text{donde } M \text{ es una integral y } |s| \leq \frac{\pi}{2}.$$

- a. Demuestre que $\sin x = \operatorname{sgn}(x) \cdot (-1)^M \cdot \sin s$.
- b. Construya una aproximación racional a $\sin s$ usando $n = m = 4$. Estime el error cuando $0 \leq |s| \leq \pi/2$.
- c. Diseñe una implantación de $\sin x$ usando las partes (a) y (b).
- d. Repita la parte (c) para $\cos x$ aplicando el hecho de que $\cos x = \sin(x + \pi/2)$.

8.5 Aproximación polinomial trigonométrica

El uso de las series de las funciones seno y coseno para representar funciones arbitrarias comenzó en la década de 1750, con el estudio del movimiento de un resorte en vibración. Este problema fue estudiado por Jean d'Alembert y luego también por el matemático más destacado de la época, Leonhard Euler. Pero fue Daniel Bernoulli el primero en proponer el uso de sumas infinitas de senos y cosenos como solución al problema, sumas que ahora conocemos con el nombre de series de Fourier. A principios del siglo XIX, Jean Baptiste Joseph Fourier las utilizó para estudiar el flujo de calor y formuló una teoría muy completa sobre el tema.

La primera observación en el desarrollo de las series de Fourier es que, para todo entero positivo n , el conjunto de las funciones $\{\phi_0, \phi_1, \dots, \phi_{2n-1}\}$ donde

$$\phi_0(x) = \frac{1}{2},$$

$$\phi_k(x) = \cos kx, \quad \text{para cada } k = 1, 2, \dots, n,$$

y

$$\phi_{n+k}(x) = \sin kx, \quad \text{para cada } k = 1, 2, \dots, n-1,$$

es un conjunto ortogonal en $[-\pi, \pi]$ con respecto a $u(x) = 1$. Esta ortogonalidad se deduce del hecho de que, para todo entero j , las integrales de $\sin jx$ y $\cos jx$ en $[-\pi, \pi]$ son 0, y podemos reescribir los productos de las funciones seno y coseno como sumas utilizando las tres identidades trigonométricas

$$\begin{aligned}
 \operatorname{sen} t_1 \operatorname{sen} t_2 &= \frac{1}{2} [\cos(t_1 - t_2) - \cos(t_1 + t_2)], \\
 \cos t_1 \cos t_2 &= \frac{1}{2} [\cos(t_1 - t_2) + \cos(t_1 + t_2)], \\
 \operatorname{sen} t_1 \cos t_2 &= \frac{1}{2} [\operatorname{sen}(t_1 - t_2) + \operatorname{sen}(t_1 + t_2)].
 \end{aligned}
 \tag{8.19}$$

Sea $\mathcal{T}_n$ el conjunto de todas las combinaciones lineales de las funciones $\phi_0, \phi_1, \dots, \phi_{2n-1}$. A este conjunto se le denomina conjunto de **polinomios trigonométricos** de grado menor o igual que n . (En algunas obras se incluye una función adicional en el conjunto, $\phi_{2n}(x) = \operatorname{sen} nx$.)

Para una función $f \in C[-\pi, \pi]$, queremos obtener la aproximación de *mínimos cuadrados continuos* mediante las funciones de $\mathcal{T}_n$ en la forma

$$S_n(x) = \frac{a_0}{2} + a_n \cos nx + \sum_{k=1}^{n-1} (a_k \cos kx + b_k \operatorname{sen} kx).$$

Dado que el conjunto de funciones $\{\phi_0, \phi_1, \dots, \phi_{2n-1}\}$ es ortogonal en $[-\pi, \pi]$ respecto a $w(x) = 1$, del teorema 8.6 se deduce que la elección apropiada de coeficientes es

$$a_k = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \cos kx \, dx, \quad \text{para cada } k = 0, 1, 2, \dots, n,$$

y

$$b_k = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \operatorname{sen} kx \, dx, \quad \text{para cada } k = 1, 2, \dots, n-1.$$

El límite de $S_n(x)$ cuando $n \rightarrow \infty$ se denomina **serie de Fourier** para f . Las series de Fourier se usan para describir la solución de varias ecuaciones diferenciales, ordinarias y parciales, que aparecen en situaciones físicas.

EJEMPLO 1 Para determinar el polinomio trigonométrico a partir de $\mathcal{T}_n$ que aproxime a

$$f(x) = |x|, \quad \text{para } -\pi < x < \pi,$$

hay que encontrar

$$a_0 = \frac{1}{\pi} \int_{-\pi}^{\pi} |x| \, dx = -\frac{1}{\pi} \int_{-\pi}^0 x \, dx + \frac{1}{\pi} \int_0^{\pi} x \, dx = \frac{2}{\pi} \int_0^{\pi} x \, dx = \pi,$$

$$a_k = \frac{1}{\pi} \int_{-\pi}^{\pi} |x| \cos kx \, dx = \frac{2}{\pi} \int_0^{\pi} x \cos kx \, dx = \frac{2}{\pi k^2} [(-1)^k - 1],$$

para cada $k = 1, 2, \dots, n$; y

$$b_k = \frac{1}{\pi} \int_{-\pi}^{\pi} |x| \operatorname{sen} kx \, dx = 0, \quad \text{para cada } k = 1, 2, \dots, n-1.$$

El que las b_k sean todas 0 se deduce del hecho de que $g(x) = |x| \operatorname{sen} kx$ es una función impar para cada k , y la integral de cualquier función impar en todo intervalo de la forma $[-a, a]$ es 0. (Véanse los Ejercicios 13 y 14.) Así pues, el polinomio trigonométrico obte-