

búsquedas invariables y búsquedas de patrones, no requieren la evaluación de las derivadas de la función. Por otro lado, los *métodos gradiente* usan algunas veces la primera y otras la segunda derivada para encontrar el óptimo. El capítulo introduce el *gradiente* y el *Hessian*, los cuales son representaciones multidimensionales de la primera y segunda derivadas. El método de *paso ascendente/descendente* es entonces cubierto con algún detalle. A esto le siguen descripciones de algunos métodos avanzados: *gradiente conjugado*, el *método de Newton*, el *método de Marquardt* y los *métodos cuasi-Newton*.

El capítulo 15 se dedica a la *optimización restringida*. La *programación lineal* se describe con detalle usando ambos: la representación gráfica y el *método simplex*. El análisis detallado de *optimización restringida no lineal* está fuera del alcance de este libro, pero se dará un repaso a los principales enfoques. Además, se ilustra cómo tales problemas, junto con los estudiados en los capítulos 13 y 14, se pueden obtener con las librerías y paquetes de software como Excel, Mathcad e IMSL.


El capítulo 16 extiende los conceptos anteriores a problemas actuales de la ingeniería. Se utilizan aplicaciones de la ingeniería para ilustrar cómo se formulan los problemas de optimización y en qué forma se provee una visualización en la aplicación de las técnicas de solución en la práctica profesional.

Se incluye un epílogo al final de la parte cuatro. Éste contiene un repaso de los métodos analizados en los capítulos 13, 14 y 15. Este repaso incluye una descripción de los elementos de juicio relacionados con el uso apropiado de cada técnica. Esta sección también provee referencias de algunos métodos numéricos que van más allá del alcance de este texto.

PT4.3.2 Metas y objetivos

Objetivos de estudio. Después de haber analizado la parte cuatro, usted tendrá suficiente información para plantear con éxito una amplia variedad de problemas de la ingeniería relacionados con la optimización. En general, usted debería dominar las técnicas, haber aprendido a evaluar su confiabilidad y detectar métodos alternativos de análisis para un problema particular. Además, de estas metas generales, deberían ser asimilados los conceptos específicos dados en la tabla PT4.2 para un aprendizaje comprensivo del material de la parte cuatro.

Objetivos computacionales. Usted debería ser capaz de escribir un subprograma que implemente una búsqueda simple unidimensional (como la búsqueda dorada o la interpolación cuadrática) y multidimensional (como el método de búsqueda aleatorio). Además, programas de librerías como el IMSL y los paquetes de software tales como Excel o Mathcad tienen una variedad de capacidades para la optimización. Usted puede usar esta parte del libro para familiarizarse con todas estas capacidades.

**FIGURA PT4.5**

Esquema de la organización del material en la parte cuatro: Optimización.

TABLA PT4.2 Objetivos de estudio específicos para la parte cuatro.

1. Comprender por qué y dónde ocurre la optimización al resolver problemas de ingeniería.
2. Comprender los elementos principales del problema de optimización en general: función objetivo, variables de decisión y restricciones.
3. Ser capaz de distinguir entre la optimización lineal y no lineal, y entre problemas restringidos y no restringidos.
4. Poder definir la relación dorada y comprender cómo realiza una eficiente optimización unidimensional.
5. Localizar el óptimo de una función con una sola variable con la búsqueda de la sección dorada, interpolación cuadrática y el método de Newton. También, reconozca los elementos de juicio entre estos enfoques, con particular atención en los valores iniciales y en la convergencia.
6. Ser capaz de escribir un programa y resolverlo para el óptimo y la función multivariable usando búsqueda aleatoria.
7. Comprender las ideas detrás de los patrones de búsqueda, direcciones conjugadas y el método de Powell.
8. Poder definir y evaluar el gradiente y Hessian de una función multivariable, ambas en forma analítica y numérica.
9. Calcular a mano el óptimo de una función con dos variables, usando el método de paso ascendente/descendente.
10. Comprender las ideas básicas detrás de los métodos del gradiente conjugado, de Newton, de Marquardt y de cuasi-Newton. En particular, comprender los elementos de juicio de los enfoques y reconocer cómo cada uno mejora sobre el paso ascendente/descendente.
11. Ser capaz de reconocer y acondicionar un problema de programación lineal para representar aplicaciones de los problemas en ingeniería.
12. Poder resolver un problema de programación lineal bidimensional con ambos métodos: el gráfico y el simplex.
13. Comprender los cuatro posibles resultados de un problema de programación lineal.
14. Ser capaz de acondicionar y resolver problemas de optimización restringidos no lineales mediante un paquete de software.

CAPÍTULO 13


Optimización unidimensional no restringida

Esta sección describirá las técnicas para encontrar el mínimo o máximo de una función de una sola variable, $f(x)$. Una imagen útil en este sentido es la unidimensional “montaña rusa”, como la función ilustrada en la figura 13.1. Recuerde de la parte dos, que la localización de una raíz fue complicada por el hecho de que varias raíces ocurren para una sola función. De manera similar, ambos, el óptimo local y el óptimo global, pueden ocurrir en optimización. Tales casos son llamados *multimodal*. En casi todos los ejemplos, estaremos interesados en encontrar el valor absoluto máximo o mínimo de una función. Así, debemos cuidar de no equivocarnos con un óptimo local en vez de un óptimo global.

Distinguir un extremo global de un extremo local puede ser un problema difícil para el caso general. Existen tres formas usuales de enfocar este problema. Primero, la visualización en el comportamiento de funciones de bajas dimensiones puede algunas veces obtenerse en forma gráfica. Segundo, determinar la óptima con base en los valores iniciales, que varían muy ampliamente y quizá sean generados en forma aleatoria, y después seleccionar el más grande de éstos como global. Por último, cambiar el punto de inicio asociado con un óptimo local y ver si la rutina regresa a un mejor punto, o siempre regresa al mismo punto. Aunque todos estos planteamientos tienen su utilidad, el hecho es que en algunos problemas (usualmente los más grandes), quizá no hay una forma práctica de asegurar que se ha localizado un óptimo global. Sin embargo, aunque se

FIGURA 13.1

Una función que asintóticamente se aproxima a cero en más y menos ∞ y tiene dos puntos máximos y dos puntos mínimos en la vecindad del origen. Los dos puntos a la derecha son los óptimos locales, mientras que los dos de la izquierda son globales.



debería ser siempre sensible al tema, se tiene la fortuna de que hay numerosos problemas en la ingeniería donde se puede localizar el global óptimo en una forma no ambigua.

Como en la localización de raíces, la optimización en una dimensión se puede dividir en métodos que usan intervalos y métodos abiertos. Como se describirá en la próxima sección, la búsqueda de sección dorada, es un ejemplo de un método de intervalo que depende de los valores iniciales y que contiene un solo óptimo. Éste es seguido por un procedimiento de intervalo algo más sofisticado (la interpolación cuadrática).

El método final descrito en este capítulo es un método abierto que se basa en la idea del cálculo de que se puede encontrar el mínimo o máximo al resolver $f'(x) = 0$. Esto reduce el problema de optimización para encontrar la raíz de $f'(x)$ mediante las técnicas de esa clase descritas en la parte dos. En seguida se mostrará una versión de este planteamiento (el método de Newton).

13.1 BÚSQUEDA DE LA SECCIÓN DORADA

Al resolver para la raíz de sólo una ecuación no lineal, la meta fue la de encontrar la variable x que diera *cero* en la función $f(x)$. La *optimización de una sola variable* tiene como meta encontrar el valor de x que generará un *extremo*, ya sea un máximo o un mínimo de $f(x)$.


La búsqueda de la sección dorada es una técnica simple, de búsqueda de una sola variable de propósito general. Es similar en esencia al enfoque de la bisección para localizar raíces (capítulo 5). Recuerde que la bisección depende del intervalo definido, especificado por un valor inicial inferior (x_l) y un valor inicial superior (x_u), que ajusta a una sola raíz. La presencia de una raíz entre estas fronteras se verifica al determinar que $f(x_l)$ y $f(x_u)$ tienen signos diferentes. La raíz se estima entonces como el punto medio de este intervalo,

$$x_r = \frac{x_l + x_u}{2}$$

El paso final en una iteración por bisección involucró determinar el intervalo más pequeño. Esto se hizo al reemplazar cualquiera de las fronteras x_l o x_u , que tuvieran un valor de la función con el mismo signo que $f(x_r)$. Un efecto útil de este procedimiento fue que el nuevo valor x_r , reemplazará a una de las fronteras anteriores.

Ahora se puede desarrollar un procedimiento similar para localizar el óptimo de una función unidimensional. Por simplicidad, nos concentraremos sobre el problema de encontrar un máximo. Cuando se analice el algoritmo de cómputo, se describirán las pequeñas modificaciones necesarias para simular un mínimo.

Como con el método de la bisección, se puede comenzar por definir un intervalo que contenga una sola respuesta. Es decir, el intervalo debería contener un solo máximo, y por esto es llamado *unimodal*. Podemos adoptar la misma nomenclatura que para la bisección, donde x_l y x_u definen los límites inferior y superior de ese intervalo. Sin embargo, en contraste con bisección, se necesita una nueva estrategia para encontrar un máximo dentro del intervalo. En vez de usar solamente dos valores función (los cuales son suficientes para detectar un cambio de signo, y por tanto un cero), se necesitarían tres valores función para detectar si ocurre un máximo. Así, se ha escogido un punto adicional dentro del intervalo. Después, se toma un cuarto punto. Entonces, la prueba

**FIGURA 13.2**

El paso inicial del algoritmo de búsqueda de la sección dorada involucra escoger dos puntos interiores de acuerdo con la razón dorada.

para el máximo podría aplicarse para discernir si el máximo ocurre dentro de los primeros tres o en los últimos tres puntos.

La clave para hacer eficiente este procedimiento es la mejor elección de los puntos intermedios. Como en la bisección, la meta es minimizar las funciones evaluación al reemplazar los valores anteriores con los nuevos.

Esta meta se puede alcanzar al especificar que las siguientes dos condiciones se cumplan (véase figura 13.2):

$$\ell_0 = \ell_1 + \ell_2 \quad (13.1)$$

$$\frac{\ell_1}{\ell_0} = \frac{\ell_2}{\ell_1} \quad (13.2)$$

La primera condición especifica que la suma de las dos sublongitudes ℓ_1 y ℓ_2 debe ser igual a la longitud original del intervalo. La segunda indica que el cociente o razón de las longitudes debe ser igual. La ecuación (13.1) se puede sustituir en la (13.2),

$$\frac{\ell_1}{\ell_1 + \ell_2} = \frac{\ell_2}{\ell_1} \quad (13.3)$$

Si se toma el recíproco y $R = \ell_2/\ell_1$, se llega a

$$1 + R = \frac{1}{R} \quad (13.4)$$

o

$$R^2 + R - 1 = 0 \quad (13.5)$$

la cual se puede resolver para la raíz positiva

$$R = \frac{-1 + \sqrt{1 - 4(-1)}}{2} = \frac{\sqrt{5} - 1}{2} = 0.61803... \quad (13.6)$$

Cuadro 13.1 La razón dorada y los números de Fibonacci

En muchas culturas, a ciertos números se les otorga cualidades. Por ejemplo, en Occidente se suele decir "el 7 de la suerte" y "viernes 13". Los antiguos griegos llamaron al siguiente número la "razón dorada":


$$\frac{\sqrt{5} - 1}{2} = 0.61803 \dots$$

Esta razón fue empleada para un gran número de propósitos, incluyendo el desarrollo del rectángulo como en la figura 13.3. Estas proporciones fueron consideradas por los griegos como estéticamente agradables. Entre otras cosas, muchos de los templos siguieron esta forma.

La razón dorada se relaciona con importantes series matemáticas conocidas como los números de Fibonacci, los cuales son:

0, 1, 1, 2, 3, 5, 8, 13, 21, 34, ...

Así, cada número después de los dos primeros representa la suma de los dos precedentes. Esta secuencia detonó en muchas áreas diversas de la ciencia y la ingeniería. En el contexto del presente análisis, una interesante propiedad de la secuencia de Fibonacci relaciona la razón de números consecutivos en la secuencia; es decir, $0/1 = 0$, $1/1 = 1$, $1/2 = 0.5$, $2/3 = 0.667$, $3/5 = 0.6$, $5/8 = 0.625$, $8/13 = 0.615$, y así sucesivamente. ¡Como suponemos, la razón de números consecutivos se aproxima a la razón dorada!

**FIGURA 13.3**

El Partenón de Atenas, Grecia, fue construido en el siglo V antes de Cristo. Sus dimensiones frontales pueden casi ajustarse en forma exacta dentro de un rectángulo dorado.

Este valor, el cual se conoce desde la antigüedad, es llamado la razón dorada (vea el cuadro 13.1). Ya que permite encontrar en forma eficiente el óptimo, es el elemento clave del método de la sección dorada que hemos desarrollado conceptualmente. Ahora derivemos un algoritmo para implementar este procedimiento en la computadora.


Como se mencionó antes y se ilustra en la figura 13.4, el método comienza con dos valores iniciales, x_l y x_u , que contienen un extremo local de $f(x)$. Después, dos puntos interiores x_1 y x_2 se escogen de acuerdo con la razón dorada,

$$d = \frac{\sqrt{5} - 1}{2} (x_u - x_l)$$

$$x_1 = x_l + d$$

$$x_2 = x_u - d$$

La función se evalúa en estos dos puntos interiores. Dos resultados pueden ocurrir:

**FIGURA 13.4**

a) El paso inicial del algoritmo de búsqueda de la sección dorada involucra escoger dos puntos interiores de acuerdo con la razón dorada. b) El segundo paso involucra definir un nuevo intervalo que incluya el óptimo.

1. Si, como es el caso en la figura 13.4, $f(x_1) > f(x_2)$, entonces el dominio de x a la izquierda de x_2 , de x_l a x_2 , se puede eliminar, ya que no contiene el máximo. Para este caso, x_2 pasa a ser el nuevo x_l para la siguiente vuelta.
2. Si ha ocurrido que $f(x_2) > f(x_1)$, entonces el dominio de x a la derecha de x_1 , de x_1 a x_u podría ser eliminado. En este caso x_1 pasa a ser el nuevo x_u para la siguiente iteración.

Ahora, éste es el beneficio real del uso de la razón dorada. Debido a que los x_l y x_u originales se han escogido mediante la razón dorada, no se tiene que recalcular todos los valores de la función para la siguiente iteración. Por ejemplo, para el caso expuesto en la figura 13.4, el anterior x_l pasa a ser el nuevo x_2 . Esto significa que ya se tiene el valor para el nuevo $f(x_2)$, puesto que es el mismo valor de la función en el anterior x_l .

Para completar el algoritmo, ahora sólo se necesita determinar el nuevo x_1 . Esto se realiza con la misma proporcionalidad que antes,

$$x_1 = x_l + \frac{\sqrt{5} - 1}{2}(x_u - x_l)$$

Un procedimiento similar podría usarse para el caso alternativo donde el óptimo está en la izquierda del subintervalo.

Como las iteraciones se repiten, el intervalo que contiene el extremo se reduce rápidamente. De hecho, en cada vuelta el intervalo se reduce por un factor de la razón dorada (aproximadamente el 61.8%). Esto significa que después de 10 vueltas, el intervalo se acorta a cerca de 0.618^{10} o 0.008 o 0.8% de su longitud inicial. Después de 20 vueltas, se acerca al 0.0066%. Esta reducción no es tan buena como la que se alcanza con bisección, pero éste es un problema más difícil.

EJEMPLO 13.1 Búsqueda de la sección dorada

Enunciado del problema. Use la búsqueda de la sección para encontrar el máximo de

$$f(x) = 2 \sin x - \frac{x^2}{10}$$

dentro del intervalo $x_l = 0$ y $x_u = 4$.

Solución. Primero, se usa la razón dorada para crear los dos puntos anteriores

$$d = \frac{\sqrt{5} - 1}{2} (4 - 0) = 2.472$$

$$x_1 = 0 + 2.472 = 2.472$$

$$x_2 = 4 - 2.472 = 1.528$$

La función se puede evaluar en los puntos interiores

$$f(x_2) = f(1.528) = \frac{1.528^2}{10} - 2 \sin(1.528) = 1.765$$

$$f(x_1) = f(2.472) = 0.63$$

Debido a que $f(x_2) > f(x_1)$, el máximo en el intervalo está definido por x_l , x_2 y x_1 . Así, para el nuevo intervalo, la frontera inferior permanece $x_l = 0$, y x_1 pasa a ser la frontera superior; esto es, $x_u = 2.472$. Además, el primer valor x_2 pasa a ser el nuevo x_l ; esto es, $x_l = 1.528$. Además, no se tiene que recalcular $f(x_1)$ ya que se determinó en la iteración previa como $f(1.528) = 1.765$.

Todo lo que falta es calcular la nueva razón dorada y x_2 ,

$$d = \frac{\sqrt{5} - 1}{2} (2.472 - 0) = 1.528$$

$$x_2 = 4 - 1.528 = 0.944$$

La evaluación de la función en x_2 es $f(0.944) = 1.531$. Como este valor es menor que el valor de la función en x_l , el máximo está en el intervalo prescrito por x_2 , x_l y x_u .

El proceso se puede repetir, con los resultados tabulados en seguida:

<i>i</i>	x_l	$f(x_l)$	x_2	$f(x_2)$	x_1	$f(x_1)$	x_u	$f(x_u)$	<i>d</i>
1	0	0	1.5279	1.7647	2.4721	0.6300	4.0000	-3.1136	2.4721
2	0	0	0.9443	1.5310	1.5279	1.7647	2.4721	0.6300	1.5279
3	0.9443	1.5310	1.5279	1.7647	1.8885	1.5432	2.4721	0.6300	0.9443
4	0.9443	1.5310	1.3050	1.7595	1.5279	1.7647	1.8885	1.5432	0.5836
5	1.3050	1.7595	1.5279	1.7647	1.6656	1.7136	1.8885	1.5432	0.3607
6	1.3050	1.7595	1.4427	1.7755	1.5279	1.7647	1.6656	1.7136	0.2229
7	1.3050	1.7595	1.3901	1.7742	1.4427	1.7755	1.5279	1.7647	0.1378
8	1.3901	1.7742	1.4427	1.7755	1.4752	1.7732	1.5279	1.7647	0.0851

Observe que el máximo actual está resaltado para cada iteración. Después de ocho iteraciones, el máximo ocurre en $x = 1.4427$ con un valor función de 1.7755. Así, el resultado es convergente sobre el valor verdadero de 1.7757 en $x = 1.4276$.

Recuerde que por bisección (véase sección 5.2.1), se puede calcular un límite superior exacto en cada iteración. Usando un razonamiento similar, un límite superior para la búsqueda de la sección dorada se puede derivar como sigue.

Una vez que se completa una iteración, el óptimo estará en uno de los dos intervalos. Si x_2 es el valor de la función óptima, estará en el intervalo inferior (x_l, x_2, x_1) . Si x_1 es el valor de la función en el punto óptimo, estará en el intervalo superior (x_2, x_1, x_u) . Debido a que los puntos interiores son simétricos, cualquier caso se puede usar para definir el error.

Observando en el intervalo superior, si el valor verdadero estuviera en el extremo izquierdo, la máxima distancia de la estimada podría ser

$$\begin{aligned}
 \Delta x_a &= x_1 - x_2 \\
 &= x_l + R(x_u - x_l) - x_u + R(x_u - x_l) \\
 &= (x_l - x_u) + 2R(x_u - x_l) \\
 &= (2R - 1)(x_u - x_l)
 \end{aligned}$$

$$\text{o } 0.236 (x_u - x_l)$$

Si el valor verdadero estuviera en el extremo derecho, la máxima distancia de la estimada podría ser

$$\begin{aligned}
 \Delta x_b &= x_u - x_1 \\
 &= x_u - x_l - R(x_u - x_l) \\
 &= (1 - R)(x_u - x_l)
 \end{aligned}$$

o $0.382 (x_u - x_l)$. Por tanto, este caso podría representar el error máximo. Tal resultado puede entonces ser normalizado al valor óptimo para esa iteración, x_{opt} para dar

$$\varepsilon_a = (1 - R) \left| \frac{x_u - x_l}{x_{\text{opt}}} \right| 100\%$$

Esta estimación proporciona una base para terminar las iteraciones.

FIGURA 13.5

Algoritmo para la búsqueda de la sección dorada.

```

FUNCTION Gold (xlow,xhigh,maxit,es,fx)
  R = (50.5 - 1)/2
  xl = xlow; xu = xhigh
  iter = 1
  d = R * (xu - xl)
  x1 = xl + d; x2 = xu - d
  f1 = f(x1)
  f2 = f(x2)
  IF f1 > f2 THEN
    xopt = x1
    fx = f1
  ELSE
    xopt = x2
    fx = f2
  END IF
  DO
    d = R*d
    IF f1 > f2 THEN
      xl = x2
      x2 = x1
      x1 = xl + d
      f2 = f1
      f1 = f(x1)
    ELSE
      xu = x1
      x1 = x2
      x2 = xu - d
      f1 = f2
      f2 = f(x2)
    END IF
    iter = iter + 1
    IF f1 > f2 THEN
      xopt = x1
      fx = f1
    ELSE
      xopt = x2
      fx = f2
    END IF
    IF xopt ≠ 0. THEN
      ea = (1 - R) * ABS((xu - xl) / xopt) * 100.
    END IF
    IF ea ≤ es OR iter ≥ maxit EXIT
  END DO
  Gold = xopt
END Gold

```

a) Maximización

b) Minimización

En la figura 13.5a, se presenta el pseudocódigo del algoritmo de búsqueda de la sección dorada. En la figura 13.5b se listan las pequeñas modificaciones para convertir el algoritmo a minimización. En ambas versiones el valor x para el óptimo se regresa como el valor función (*dorado*). Además, el valor de $f(x)$ en el óptimo se regresa como la variable $f(x)$.

Usted se preguntará por qué hemos hecho énfasis en la reducción de las funciones evaluación de la búsqueda de la sección dorada. Por supuesto, para resolver una sola optimización, la velocidad ahorrada podría ser insignificante. Sin embargo, hay dos importantes contextos donde minimizar el número de evaluaciones de la función puede ser importante. Éstos son


1. *Muchas evaluaciones.* Existe casos donde el algoritmo de búsqueda de la sección dorada puede ser una parte de muchos más cálculos. En tales casos, ésta podría llamarse muchas veces. Por tanto, manteniendo las evaluaciones de la función a un mínimo podría dar grandes dividendos para esos casos.
2. *Tiempo consumido en la evaluación.* Por razones pedagógicas, se usan funciones simples en la mayoría de nuestros ejemplos. Usted debería entender que una función puede ser muy compleja y consumir mucho tiempo en su evaluación. Por ejemplo, en una parte posterior de este libro, se describirá cómo se puede usar la optimización para estimar los parámetros de un modelo que consiste de un sistema de ecuaciones diferenciales. Para tales casos, la "función" involucró tiempo consumido en la integración del modelo. Cualquier método que minimiza tales evaluaciones podría ser ventajoso.

13.2 INTERPOLACIÓN CUADRÁTICA

La interpolación cuadrática tiene la ventaja del hecho que un polinomio de segundo orden con frecuencia proporciona una buena aproximación a la forma de $f(x)$ cercana a un óptimo (véase figura 13.6).

FIGURA 13.6

Ilustración gráfica de la interpolación cuadrática.



Así como existe sólo una línea recta para conectar dos puntos, hay únicamente una cuadrática o parábola para conectar tres puntos. De esta forma, si se tiene tres puntos que juntos contienen un óptimo, se puede ajustar una parábola a los puntos. Después se puede diferenciar e igualar el resultado a cero, y resolver para una estimación de la óptima x . Se puede demostrar que después de un manejo algebraico el resultado es

$$x_3 = \frac{f(x_0)(x_1^2 - x_2^2) + f(x_1)(x_2^2 - x_0^2) + f(x_2)(x_0^2 - x_1^2)}{2f(x_0)(x_1 - x_2) + 2f(x_1)(x_2 - x_0) + 2f(x_2)(x_0 - x_1)} \quad (13.7)$$

donde x_0, x_1 y x_2 son los valores que fijan el extremo, y x_3 es el valor de x que corresponde al máximo valor del ajuste cuadrático a los valores iniciales.

EJEMPLO 13.2 Interpolación cuadrática

Enunciado del problema. Use la interpolación cuadrática para aproximar el máximo de

$$f(x) = 2 \sin x - \frac{x^2}{10}$$

con valores iniciales de $x_0 = 0$, $x_1 = 1$ y $x_2 = 4$.

Solución. El valor de la función en los tres valores se puede evaluar,

$$\begin{array}{ll} x_0 = 0 & f(x_0) = 0 \\ x_1 = 1 & f(x_1) = 1.5829 \\ x_2 = 4 & f(x_2) = -3.1136 \end{array}$$

y sustituyendo en la ecuación (13.7) se obtiene,

$$x_3 = \frac{0(1^2 - 4^2) + 1.5829(4^2 - 0^2) + (-3.1136)(0^2 - 1^2)}{2(0)(1 - 4) + 2(1.5829)(4 - 0) + 2(-3.1136)(0 - 1)} = 1.5055$$

la cual tiene un valor de la función de $f(1.5055) = 1.7691$.

Después, se puede emplear una estrategia similar a la de la búsqueda de la sección dorada para determinar cuál punto se descartará. Ya que el valor de la función para el nuevo punto es mayor que para el punto intermedio (x_1) y el nuevo valor de x está a la derecha del punto intermedio, el valor de inicio inferior (x_0) se descarta. Por tanto, para la próxima iteración,

$$\begin{array}{ll} x_0 = 1 & f(x_0) = 1.5829 \\ x_1 = 1.5055 & f(x_1) = 1.7691 \\ x_2 = 4 & f(x_2) = -3.1136 \end{array}$$

la cual se sustituye en la ecuación (13.7) para obtener

$$x_3 = \frac{1.5829(1.5055^2 - 4^2) + 1.7691(4^2 - 1^2) + (-3.1136)(1^2 - 1.5055^2)}{2(1.5829)(1.5055 - 4) + 2(1.7691)(4 - 1) + 2(-3.1136)(1 - 1.5055)} \\ = 1.4903$$

la cual tiene un valor de la función de $f(1.4903) = 1.7714$.

El proceso se puede repetir, con los resultados tabulados abajo:

i	x_0	$f(x_0)$	x_1	$f(x_1)$	x_2	$f(x_2)$	x_3	$f(x_3)$
1	0.0000	0.0000	1.0000	1.5829	4.0000	-3.1136	1.5055	1.7691
2	1.0000	1.5829	1.5055	1.7691	4.0000	-3.1136	1.4903	1.7714
3	1.0000	1.5829	1.4903	1.7714	1.5055	1.7691	1.4256	1.7757
4	1.0000	1.5829	1.4256	1.7757	1.4903	1.7714	1.4266	1.7757
5	1.4256	1.7757	1.4266	1.7757	1.4903	1.7714	1.4275	1.7757

Así, dentro de las cinco iteraciones, el resultado es rápidamente convergente sobre el valor verdadero de 1.7757 en $x = 1.4276$.

Deberíamos mencionar que así como en el método de la falsa posición, la interpolación cuadrática puede quedarse con sólo un extremo de intervalo convergiendo. Así, la convergencia puede ser lenta. Como prueba de lo anterior, observe que en nuestro ejemplo, 1.0000 fue un punto final para la mayoría de las iteraciones.

Este método, así como otros que usan polinomiales de tercer orden, se puede formular en algoritmos que contienen pruebas de convergencia, cuidadosas estrategias de selección para los puntos que habrán de retenerse en cada iteración e intentos de minimizar la acumulación del error de redondeo. En particular, vea el método de Brent's en Press y cols. (1992).

13.3 MÉTODO DE NEWTON

Recuerde que el método de Newton-Raphson del capítulo 6, es un método abierto que encuentra la raíz de x como una función tal que $f(x) = 0$. El método se resume como

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$$

Se puede usar un planteamiento similar abierto para encontrar un óptimo de $f(x)$ al definir una nueva función, $g(x) = f'(x)$. Así, como el mismo valor óptimo x^* satisface ambos

$$f'(x^*) = g(x^*) = 0$$

se puede usar lo siguiente

$$x_{i+1} = x_i - \frac{f'(x_i)}{f''(x_i)} \quad (13.8)$$

como una técnica para encontrar el mínimo o máximo de $f(x)$. Se debería observar que esta ecuación puede también derivarse al escribir una serie de Taylor de segundo orden para $f(x)$ e igualar la derivada de la serie a cero. El método de Newton es abierto y similar al de Newton-Raphson porque no requiere de valores iniciales que contengan el óptimo. Además, también comparte la desventaja de poder ser divergente. Por último, es una buena idea verificar que la segunda derivada tenga usualmente el signo correcto para confirmar que la técnica converge sobre el resultado deseado.

EJEMPLO 13.3 Método de Newton

Enunciado del problema. Use el método de Newton para encontrar el máximo de

$$f(x) = 2 \sin x - \frac{x^2}{10}$$

con un valor inicial de $x_0 = 2.5$.

Solución. La primera y segunda derivadas de la función se puede evaluar como

$$f'(x) = 2 \cos x - \frac{x}{5}$$

$$f''(x) = -2 \sin x - \frac{1}{5}$$

las cuales se sustituyen en la ecuación (13.8) para obtener

$$x_{i+1} = x_i - \frac{2 \cos x_i - x_i/5}{-2 \sin x_i - 1/5}$$

Al sustituir el valor inicial se obtiene

$$x_1 = 2.5 - \frac{2 \cos 2.5 - 2.5/5}{-2 \sin 2.5 - 1/5} = 0.99508$$

la cual tiene un valor de la función de 1.57859. La segunda iteración da

$$x_2 = 0.995 - \frac{2 \cos 0.995 - 0.995/5}{-2 \sin 0.995 - 1/5} = 1.46901$$

la cual tiene un valor de la función de 1.77385.

El proceso se repite, con los resultados abajo tabulados:

i	x	$f(x)$	$f'(x)$	$f''(x)$
0	2.5	0.57194	-2.10229	-1.39694
1	0.99508	1.57859	0.88985	-1.87761
2	1.46901	1.77385	-0.09058	-2.18965
3	1.42764	1.77573	-0.00020	-2.17954
4	1.42755	1.77573	0.00000	-2.17952

Así, dentro de las cuatro iteraciones, el resultado converge en forma rápida sobre el valor verdadero.

Aunque el método de Newton trabaja bien en algunos casos, no es práctico en otros donde las derivadas no se pueden evaluar en forma conveniente. Para estos casos, se dispone de otros procedimientos que no involucran la evaluación de la derivada. Por ejemplo, un método de Newton, en versión como la secante, se puede desarrollar al usar aproximaciones por diferencia finita para las evaluaciones de la derivada.

Una restricción mayor con respecto al procedimiento es que puede divergir con base en la naturaleza de la función y la calidad del valor inicial. Así, usualmente se emplea sólo cuando se está cerca del óptimo. Las técnicas híbridas que usan procedimientos con intervalos lejos del óptimo y los métodos abiertos cercanos al óptimo intentan explotar los puntos fuertes de ambos procedimientos.

Esto concluye nuestro tratamiento de los métodos para encontrar el óptimo de funciones de una sola variable. Algunos ejemplos de ingeniería se presentan en el capítulo 16. Por otra parte, las técnicas descritas aquí son un importante elemento de algunos procedimientos para optimizar funciones multivariables, que se analizarán en el próximo capítulo.

PROBLEMAS

13.1 Dada la fórmula

$$f(x) = x^2 - 8x + 12$$

- Determine en forma analítica el máximo y el valor correspondiente de x para esta función (use por ejemplo, diferenciación).
- Verifique que con la ecuación (13.7) se obtienen los mismos resultados con base en los valores iniciales $x_0 = 0$, $x_1 = 2$ y $x_2 = 6$.

13.2 Dada la función

$$f(x) = -1.5x^6 - 2x^4 + 12x$$

- Grafique la función.
- Use métodos analíticos para probar que la función es cóncava para todos los valores de x .
- Diferencie la función y después use un método de localización de raíces para determinar el máximo de $f(x)$ y el valor correspondiente de x .

13.3 Encuentre el valor de x que maximiza $f(x)$ en el problema 13.2, usando la búsqueda de la sección dorada. Emplee los valores iniciales de $x_l = 0$ y $x_u = 2$ y realice 3 iteraciones.

13.4 Repita el problema 13.3, pero ahora use interpolación cuadrática. Emplee valores iniciales de $x_0 = 0$, $x_1 = 1$, $x_2 = 2$ y realice 3 iteraciones.

13.5 Repita el problema 13.3, pero ahora use el método de Newton. Emplee un valor inicial de $x_0 = 2$ y realice tres iteraciones.

13.6 Analice las ventajas y desventajas de la búsqueda de la sección dorada, interpolación cuadrática y el método de Newton para localizar un óptimo valor en una dimensión.

13.7 Emplee los siguientes métodos para determinar el máximo de

$$f(x) = 2x - 1.75x^2 + 1.1x^3 - 0.25x^4$$

- Búsqueda de la sección dorada ($x_l = -2$, $x_u = 4$, $\epsilon_s = 1\%$).
- Interpolación cuadrática ($x_0 = 1.75$, $x_1 = 2$, $x_2 = 2.25$, iteraciones = 5).
- Método de Newton ($x_0 = 2.5$, $\epsilon_s = 1\%$).

13.8 Considere la siguiente función:

$$f(x) = 6x + 7.5x^2 + 3x^3 + x^4$$

Use métodos analíticos y gráficos para mostrar que la función tiene un mínimo para algún valor de x en el rango $-2 \leq x \leq 1$.

13.9 Emplee los siguientes métodos para encontrar el máximo de la función del problema 13.8:

- Búsqueda de la sección dorada ($x_l = -2$, $x_u = 1$, $\epsilon_s = 1\%$).

- b) Interpolación cuadrática ($x_0 = -2$, $x_1 = -1$, $x_2 = 1$, iteraciones = 5).
 c) Método de Newton ($x_0 = -1$, $\varepsilon_s = 1\%$).

13.10 Considere la siguiente función:

$$f(x) = x^4 + \frac{1}{x}$$

Realice 10 iteraciones con interpolación cuadrática para ubicar el mínimo. Comente sobre la convergencia de sus resultados ($x_0 = 0.1$, $x_1 = 0.5$, $x_2 = 5.0$).

13.11 Considere la siguiente función:

$$f(x) = 2 + 5x + 6x^2 + 2x^3 + 2x^4$$

Localice el mínimo al encontrar la raíz de la derivada de esta función. Use bisección con valores iniciales de $x_l = -2$ y $x_u = 1$.

13.12 Determine el mínimo de la función del problema 13.11 con los siguientes métodos:

- a) Método de Newton ($x_0 = -1$, $\varepsilon_s = 1\%$).
 b) Método de Newton, pero ahora usando aproximación por diferencias finitas para estimar las derivadas.

$$f'(x_i) \cong \frac{f(x_i + \delta x_i) - f(x_i - \delta x_i)}{2\delta x_i}$$

$$f''(x_i) \cong \frac{f(x_i + \delta x_i) - 2f(x_i) + f(x_i - \delta x_i)}{\delta x_i^2}$$

donde δ = una fracción de perturbación (= 0.01). Use un valor inicial de $x_0 = -1$ e itere para $\varepsilon_s = 1\%$.

13.13 Desarrolle un subprograma usando un programa o lenguaje macro para implementar el algoritmo de la búsqueda de la sección dorada. Diseñe el subprograma de tal forma que esté expresamente diseñado para localizar un máximo. La subrutina deberá tener las siguientes características:

- Verifique si los valores iniciales ajustan a un máximo. Si no es así, la subrutina deberá implementar el algoritmo, pero deberá regresar mostrando un mensaje de error.

- Itere hasta que el error relativo esté por debajo de un criterio de paro o exceda un máximo número de iteraciones.
- Regrese ambos al óptimo de x y $f(x)$.
- Minimice el número evaluaciones de función.

Pruebe su programa con el mismo problema dado en el ejemplo 13.1.

13.14 Desarrolle un subprograma como el descrito en el problema 13.13, pero ahora haga un reconocimiento para determinar si el problema involucra minimización o maximización, y después con base en este reconocimiento implemente en forma adecuada la búsqueda de la sección dorada.

13.15 Desarrolle un subprograma usando un programa o lenguaje macro para implementar el algoritmo de interpolación cuadrática. Diseñe el subprograma de tal forma que esté expresamente diseñado para localizar un máximo. La subrutina deberá tener las siguientes características:

- Utilice como base en dos valores iniciales y haga que el programa genere el tercer valor inicial a la mitad del intervalo.
- Verifique si los valores iniciales ajustan a un máximo. Si no es así, la subrutina no debe implementar el algoritmo, pero debe regresar un mensaje de error.
- Itere hasta que el error relativo esté por debajo de un criterio de paro o exceda un número máximo de iteraciones.
- Encuentre ambos, el óptimo x y $f(x)$.
- Minimice el número evaluaciones de función.

Pruebe su programa con el mismo problema como en el ejemplo 13.2.

13.16 Desarrolle un subprograma mediante un programa o lenguaje macro para implementar el método de Newton. La subrutina deberá tener las siguientes características:

- Itere hasta que el error relativo esté por debajo de un criterio de paro o exceda un número máximo de iteraciones.
- Encuentre ambos, el óptimo x y $f(x)$.

Pruebe su programa con el mismo problema del ejemplo 13.3.

CAPÍTULO 14

Optimización multidimensional sin restricciones

Este capítulo describe las técnicas para encontrar el mínimo o máximo de una función de varias variables. Recuerde del capítulo 13 que nuestra imagen visual de una búsqueda unidimensional fue como una montaña rusa. Para el caso en dos dimensiones, la imagen es ahora como la de montañas y valles (véase figura 14.1). Para problemas de grandes dimensiones, no son posibles imágenes adecuadas.

Se ha optado por limitar este capítulo a los casos en dos dimensiones. Se adoptará este planteamiento debido a que las formas características esenciales de las búsquedas multidimensionales son a menudo más comunicativas visualmente.


Las técnicas para la optimización multidimensional sin restricciones se pueden clasificar de varias formas. Para propósitos del presente análisis, se dividirán dependiendo de si se requiere la evaluación de la derivada. Los procedimientos que no requieren dicha evaluación se llaman *métodos no gradientes* o *directos*. Aquellos que requieren las derivadas son llamados *métodos gradientes* o *métodos de descenso* (o *ascenso*).

14.1 MÉTODOS DIRECTOS

Estos métodos varían de procedimientos de fuerza bruta simple a técnicas más elegantes que intentan explotar la naturaleza de la función. Se empezará el análisis con el procedimiento de fuerza bruta.

FIGURA 14.1

La forma más tangible de visualizar búsquedas en dos dimensiones es en el contexto de ascender una montaña (maximización) o descender a un valle (minimización). a) Mapa topográfico bidimensional (2-D) de la montaña que corresponde a la gráfica tridimensional (3-D) de la montaña en el inciso b).



14.1.1 Búsqueda aleatoria

Un simple ejemplo del procedimiento de fuerza bruta es llamado el *método de la búsqueda aleatoria*. Como su nombre lo indica, este método evalúa en forma repetida la función mediante la selección aleatoria de valores de la variable independiente. Si un número suficiente de muestras se lleva a cabo, el óptimo será eventualmente localizado.

EJEMPLO 14.1 Método de la búsqueda aleatoria

Enunciado del problema. Use un generador de números aleatorio para localizar el máximo de

$$f(x, y) = y - x - 2x^2 - 2xy - y^2 \quad (\text{E14.1.1})$$

en el dominio acotado por $x = -2$ a 2 , y $y = 1$ a 3 . El dominio se describe en la figura 14.2. Observe que un solo máximo de 1.5 ocurre en $x = -1$ y $y = 1.5$.

Solución. Los generadores de números aleatorios en forma típica generan valores entre 0 y 1 . Si se designa a tal número como r , la siguiente fórmula puede ser usada para generar valores de x aleatorios en un rango de x_l a x_u :

$$x = x_l + (x_u - x_l)r$$

Para la presente aplicación, $x_l = -2$ y $x_u = 2$, y la fórmula es

$$x = -2 + (2 - (-2))r = -2 + 4r$$


Ésta se puede probar al sustituir 0 y 1 para obtener -2 y 2 , respectivamente.

De forma similar para y , una fórmula para el presente ejemplo se puede desarrollar como

$$y = y_l + (y_u - y_l)r = 1 + (3 - 1)r = 1 + 2r$$

FIGURA 14.2

Ecuación [E14.1.1] que muestra el máximo en $x = -1$ y $y = 1.5$.



El siguiente código en Fortran 90 usa la subrutina RANDOM de un número aleatorio hecha en un Fortran 90 visual y digital (Digital Visual Fortran 90) para generar pares (x, y) . Éstos se sustituyen en la ecuación (E14.1.1). El máximo valor de entre estas pruebas aleatorias se guarda en la variable *maxf*, y los valores correspondientes de x y y en *maxx* y *maxy*, respectivamente. Se toma un total de 300 muestras y los resultados se despliegan cada 30 iteraciones.

```

Program Jump

IMPLICIT NONE
INTEGER :: i,j,iter
REAL :: x,y,f,fn,maxf,maxx,maxy,rnd

f(x, y) = y - x - 2.*x**2 - 2.*x*y - y**2

maxf = -999.e9

DO i = 1, 10
  DO j = 1, 30
    iter = iter + 1
    CALL Random(rnd)
    x = -2. + 4. * rnd
    y = 1. + 2. * rnd
    fn = f(x, y)
    IF (fn.GT.maxf) THEN
      maxf = fn
      maxx = x
      maxy = y
    END IF
  END DO
  PRINT *, iter, maxx, maxy, maxf
END DO

```

OUTPUT:

30	-9.483753E-01	1.525812	1.241338
60	-9.483753E-01	1.525812	1.241338
90	-9.799424E-01	1.510029	1.248693
120	-9.799424E-01	1.510029	1.248693
150	-9.799424E-01	1.510029	1.248693
180	-9.799424E-01	1.510029	1.248693
210	-9.799424E-01	1.510029	1.248693
240	-9.938087E-01	1.503096	1.249875
270	-1.003075	1.498462	1.249969
300	-1.003075	1.498462	1.249969

Los resultados indican que la técnica rápidamente arriba al máximo verdadero.

Este simple procedimiento de fuerza bruta trabaja aun en discontinuidades y funciones no diferenciables. Además, siempre encuentra el óptimo global más que el local. Su

principal deficiencia es que como crece el número de variables independientes, el esfuerzo de implementación requerido puede ser gravoso. Además, no es eficiente, ya que no toma en cuenta el comportamiento de la función realzada. Los procedimientos restantes descritos en este capítulo toman en cuenta el comportamiento de la función, así como los resultados de las iteraciones previas para mejorar la velocidad de convergencia. En consecuencia, aunque la búsqueda aleatoria puede probar ser útil en un contexto de problemas específicos, los siguientes métodos tienen una utilidad más general y casi siempre tienen la ventaja de tener una convergencia más eficiente.

Se debe observar que se dispone de técnicas de búsqueda más sofisticadas. Éstas son procedimientos heurísticos que fueron desarrollados para manejar problemas no lineales y/o discontinuos que la optimización clásica usualmente no maneja bien, si no es que todos. Simulación de recocido, búsqueda tabú, redes neuronales artificiales y algoritmos genéticos son unos pocos ejemplos. El más ampliamente utilizado es el *algoritmo genético*, con un número disponible de paquetes comerciales. Holland (1975), iniciador del procedimiento del algoritmo genético, y Goldberg (1989) y Davis (1991) proporcionan buena revisión de la teoría y aplicación del método.


14.1.2 Univariabilidad y búsquedas patrón

Es muy agradable tener un procedimiento eficiente de optimización que no requiera evaluar las derivadas. El método de búsqueda aleatoria, antes descrito, no requiere la evaluación de la derivada, pero no es muy eficiente. En esta sección se describe un procedimiento, el método de búsqueda univariable, que es más eficiente y además no requiere la evaluación de la derivada.

La estrategia básica a resaltar del *método de búsqueda univariable* es que cambia una variable a la vez para mejorar la aproximación, mientras las otras variables se mantienen constantes. Dado que únicamente se cambia una variable, el problema se reduce a una secuencia de búsquedas en una dimensión, que se puede resolver mediante una variedad de métodos (entre ellos los descritos en el capítulo 13).

FIGURA 14.3

Descripción gráfica de cómo se conduce una búsqueda univariable.



Realicemos una búsqueda univariable por medio de una gráfica, como se muestra en la figura 14.3. Se comienza en el punto 1, y se mueve a lo largo del eje x con la y constante hacia el máximo en el punto 2. Se puede ver que el punto 2 es un máximo al observar que la trayectoria a lo largo del eje x justo toca una línea del contorno en el punto. Luego, muévase a lo largo del eje y con la x constante hacia el punto 3. Continúe este proceso generando los puntos 4, 5, 6, etcétera.


Aunque se está moviendo en forma gradual hacia el máximo, la búsqueda comienza a ser menos eficiente al moverse a lo largo de una angosta cresta hacia el máximo. Sin embargo, también observe que las líneas unen puntos alternos tales como 1-3, 3-5 o 2-4; el punto 4-6 va en la dirección general del máximo. Esas trayectorias presentan una oportunidad para llegar directamente a lo largo de la cresta hacia el máximo. Tales trayectorias son llamadas *direcciones patrón*.

Se dispone de algoritmos formales que capitalizan la idea de las direcciones patrón para encontrar los valores óptimos en forma eficiente. El más conocido de dichos algoritmos es el llamado *método de Powell*. Éste se basa en la observación (véase la figura 14.4) de que si los puntos 1 y 2 se obtienen por búsquedas en una dimensión en la misma dirección, pero con diferentes puntos de partida, entonces la línea formada por 1 y 2 podría dirigirse hacia el máximo. Tales líneas son llamadas *direcciones conjugadas*.

En efecto, se puede demostrar que si $f(x, y)$ es una función cuadrática, las búsquedas secuenciales a lo largo de las direcciones conjugadas convergerán exactamente en un número finito de pasos, sin importar el punto de partida. Puesto que una función general no lineal a menudo puede estar razonablemente aproximada a una función cuadrática, los métodos basados en direcciones conjugadas son por lo común bastante eficientes y son en realidad convergentes en forma cuadrática cuando se aproximan al óptimo.

Se implementará en forma gráfica una versión simplificada del método de Powell para encontrar el máximo de

FIGURA 14.4
Direcciones conjugadas.






FIGURA 14.5
Método de Powell.

$$f(x, y) = c - (x - a)^2 - (y - b)^2$$

donde a , b y c son constantes positivas. Esta ecuación resulta en contornos circulares en el plano x, y , como se muestra en la figura 14.5.

Se inicia la búsqueda en el punto 0 con las direcciones iniciales h_1 y h_2 . Observe que h_1 y h_2 no son necesariamente direcciones conjugadas. Desde cero, se mueve a lo largo de h_1 hasta un máximo que es localizado en el punto 1. Después se busca del punto 1 a lo largo de la dirección h_2 para encontrar el punto 2. Luego, para una nueva búsqueda en la dirección h_3 a través de los puntos 0 y 2. Se busca a lo largo de esta dirección hasta que se localice el máximo en el punto 3. Luego la búsqueda va del punto 3 en la dirección h_2 hasta que se localice el máximo en el punto 4. Del punto 4 se llega al punto 5, pero de nuevo buscando a lo largo de h_3 . Ahora, obsérvese que ambos puntos, 5 y 3, se han localizado por búsqueda en la dirección h_3 , desde dos puntos diferentes. Powell ha demostrado que h_4 (formado por los puntos 3 y 5) y h_3 son direcciones conjugadas. Así, buscando desde el punto 5 a lo largo de h_4 , nos llevará directamente al máximo.

El método de Powell se puede refinar para hacerlo más eficiente, pero los algoritmos formales van más allá del alcance de este texto. Sin embargo, es un método eficiente que converge en forma cuadrática sin requerir evaluación de la derivada.

14.2 MÉTODOS GRADIENTE

Como su nombre lo indica, los *métodos gradiente* usan en forma explícita información de la derivada para generar algoritmos eficientes que localicen el óptimo. Antes de describir los procedimientos específicos, primero se revisarán algunos conceptos y operaciones matemáticas clave.

14.2.1 Gradientes y Hessians

Recuerde del cálculo que la primera derivada de una función unidimensional proporciona una pendiente o tangente de la función que es diferenciada. Desde el punto de vista de la optimización, ésta es una información útil. Por ejemplo, si la pendiente es positiva, nos indica que al aumentar la variable independiente nos conducirá a un valor más alto de la función que se está explorando.

Del cálculo, también recuerde que la primera derivada puede indicarnos cuándo se ha encontrado un valor óptimo, puesto que éste es el punto donde la derivada tiende a cero. Además, el signo de la segunda derivada puede indicarnos si se ha alcanzado un mínimo (positivo en la segunda derivada) o un máximo (negativo en la segunda derivada).

Esas ideas fueron útiles para los algoritmos de búsqueda en una dimensión que se exploró en el capítulo anterior. Sin embargo, para entender por completo las búsquedas multidimensionales, se debe primero entender cómo la primera y la segunda derivada se expresan en un contexto multidimensional.


El gradiente. Suponga que se tiene una función en dos dimensiones $f(x, y)$. Un ejemplo podría ser su altura sobre una montaña como una función de su posición. Suponga que usted está en un lugar específico sobre la montaña (a, b) y quiere saber la pendiente en una dirección arbitraria. Una forma para definir la dirección es a lo largo de un nuevo eje h que forma un ángulo θ con el eje x (véase figura 14.6). La elevación a lo largo de este nuevo eje puede pensarse como una nueva función $g(h)$. Si usted define su posición como si estuviera en el origen de este eje (es decir, $h = 0$), la pendiente en esta dirección podría designarse como $g'(0)$. Esta pendiente, que es llamada *derivada direccional*, se puede calcular a partir de las derivadas parciales a lo largo de los ejes x y y por

$$g'(0) = \frac{\partial f}{\partial x} \cos \theta + \frac{\partial f}{\partial y} \sin \theta \quad (14.1)$$

donde las derivadas parciales son evaluadas con $x = a$ y $y = b$.

FIGURA 14.6

El gradiente direccional se define a lo largo de un eje h que forma un ángulo θ con el eje x .



Suponiendo que su meta es obtener la mayor elevación con el siguiente paso, ahora la pregunta lógica podría ser: ¿En qué dirección está el paso de ascenso? La respuesta es clara, porque matemáticamente se hace referencia a él como el *gradiente*, el cual se define como

$$\nabla f = \frac{\partial f}{\partial x} \mathbf{i} + \frac{\partial f}{\partial y} \mathbf{j} \quad (14.2)$$

Este vector también es referido como “del f ”. El cual representa la derivada direccional de $f(x, y)$ en el punto $x = a$ y $y = b$.

La notación vectorial proporciona un medio conciso para generalizar el gradiente a n dimensiones, como

$$\nabla f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(\mathbf{x}) \\ \frac{\partial f}{\partial x_2}(\mathbf{x}) \\ \vdots \\ \frac{\partial f}{\partial x_n}(\mathbf{x}) \end{bmatrix}$$

¿Cómo se usa el gradiente? Para el problema de subir la montaña, si lo que interesa es ganar elevación tan rápidamente como sea posible, el gradiente nos indica en qué dirección movernos y cuánto ganaremos por tomarla. ¡Observe, sin embargo, que dicha estrategia no necesariamente nos lleva en una trayectoria directa a la cima! Más tarde, en este capítulo, se analizará estas ideas con mayor profundidad.

EJEMPLO 14.2 Utilización del gradiente para evaluar la trayectoria de paso ascendente

Enunciado del problema. Emplee el gradiente para evaluar la dirección del paso ascendente para la función

$$f(x, y) = xy^2$$

en el punto $(2, 2)$. Se considera que la x positiva está dirigida hacia el este y la y positiva apunta al norte.

Solución. Primero, la elevación se puede determinar como

$$f(4, 2) = 2(2)^2 = 8$$

Ahora, las derivadas parciales pueden ser evaluadas,

$$\frac{\partial f}{\partial x} = y^2 = 2^2 = 4$$

$$\frac{\partial f}{\partial y} = 2xy = 2(2)(2) = 8$$

las cuales se pueden usar para determinar el gradiente como

$$\nabla f = 4\mathbf{i} + 8\mathbf{j}$$

Este vector puede ser bosquejado en un mapa topográfico de la función, como en la figura 14.7. Esto inmediatamente nos indica que la dirección que debe tomarse es

$$\theta = \tan^{-1}\left(\frac{8}{4}\right) = 1.107 \text{ radianes } (= 63.4^\circ)$$

respecto al eje x . La pendiente en esta dirección, la cual es la magnitud de ∇f , puede ser calculada como

$$\sqrt{4^2 + 8^2} = 8.944$$

Así, durante el primer paso, inicialmente se ha ganado 8.944 unidades de aumento de elevación de pendiente por unidad de distancia recorrida a lo largo de la trayectoria empinada. Observe que la ecuación (14.1) da el mismo resultado,


$$g'(0) = 4 \cos(1.107) + 8 \sin(1.107) = 8.944$$

Note que para cualquier otra dirección, digamos $\theta = 1.107/2 = 0.5235$, $g'(0) = 4 \cos(0.5235) + 8 \sin(0.5235) = 7.608$, la cual es más pequeña.

Al moverse hacia adelante, tanto la dirección como la magnitud del paso de la trayectoria cambiarán. Estos cambios se pueden cuantificar en cada paso mediante el gradiente, y la dirección del ascenso se modificará de acuerdo con esto.

FIGURA 14.7

La flecha sigue la dirección de pasos ascendente calculado con el gradiente.



Se puede obtener una cierta perspectiva al inspeccionar la figura 14.7. Como se indica, la dirección del paso ascendente es perpendicular, u *ortogonal*, al contorno en la elevación en la coordenada (2, 2). Ésta es una característica general del gradiente.


Además de definir la trayectoria de paso, se puede también usar la primera derivada para discernir si se ha alcanzado un óptimo. Como en el caso para una función de una dimensión, si las derivadas parciales con respecto a x y y son cero, se ha alcanzado el óptimo en dos dimensiones.

El Hessian. Para problemas de una dimensión, ambas derivadas, la primera y la segunda, proporcionan información valiosa para la búsqueda del óptimo. La primera derivada $a)$ proporciona una trayectoria más grande de la función y $b)$ indica que se ha alcanzado el óptimo. Una vez en el óptimo, la segunda derivada indicará si es un máximo [negativo $f''(x)$] o un mínimo [positivo $f''(x)$]. En los párrafos anteriores, se ilustró cómo el gradiente proporciona la mejor trayectoria local para problemas multidimensionales. Ahora, se examinará cómo se usa la segunda derivada en tales contextos.

Puede esperarse que si las segundas derivadas parciales con respecto a x y y son ambas negativas, entonces se ha alcanzado un máximo. La figura 14.8 muestra una función en la que esto no es cierto. El punto (a, b) de esta gráfica parece ser un mínimo cuando se observa a lo largo, ya sea de la dimensión x o de la y . En ambos casos, las segundas deri-

FIGURA 14.8

Un punto de silla [$x = a$ y $y = b$]. Observe que al ser vista la curva a lo largo de las direcciones x y y , la función parece ir hacia un mínimo (la segunda derivada es positiva), mientras que al verse a lo largo del eje $x = y$, es cóncava hacia abajo (la segunda derivada es negativa).



vadas parciales son positivas. Sin embargo, si la función se observa a lo largo de la línea $y = x$, puede verse que ocurre un máximo en el mismo punto. Esta forma es llamada de *silla* y, claramente, no ocurren ni un máximo ni un mínimo en el punto.

Ya sea que ocurra un máximo o un mínimo, esto involucra no sólo a las parciales con respecto a x y y , sino también a la segunda parcial con respecto a x y y . Suponiendo que las derivadas parciales sean continuas en y cerca del punto que habrá de evaluarse, se puede calcular la siguiente cantidad:

$$|H| = \frac{\partial^2 f}{\partial x^2} \frac{\partial^2 f}{\partial y^2} - \left(\frac{\partial^2 f}{\partial x \partial y} \right)^2 \quad (14.3)$$

Pueden ocurrir tres casos:

- Si $|H| > 0$ y $\partial^2 f / \partial x^2 > 0$, entonces $f(x, y)$ tiene un mínimo local.
- Si $|H| > 0$ y $\partial^2 f / \partial x^2 < 0$, entonces $f(x, y)$ tiene un máximo local.
- Si $|H| < 0$, entonces $f(x, y)$ tiene un punto de silla.

La cantidad $|H|$ es igual al determinante de una matriz formada con las segundas derivadas.¹

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} \quad (14.4)$$

donde esta matriz se encuentra formalmente referida como el *Hessiano* de f .

Además proporciona un medio para discernir si una función multidimensional ha alcanzado el óptimo; el Hessiano tiene otros usos en optimización (por ejemplo, para la forma multidimensional del método de Newton). En particular, permite búsquedas que incluyen curvatura de segundo orden para obtener resultados superiores.

Aproximaciones por diferencias finitas. Se debe mencionar que, para los casos donde son difíciles o inconvenientes de calcular en forma analítica, ambos, el gradiente y el determinante de Hessiano, se pueden evaluar numéricamente. En la mayoría de los casos se emplea el procedimiento que se introdujo en la sección 6.3.3 para el método de la secante modificado. Esto es, las variables independientes se pueden modificar ligeramente para generar las derivadas parciales requeridas. Por ejemplo, si se adopta el procedimiento de diferencias centrales, éstas se pueden calcular como

$$\frac{\partial f}{\partial x} = \frac{f(x + \delta x, y) - f(x - \delta x, y)}{2\delta x} \quad (14.5)$$

$$\frac{\partial f}{\partial y} = \frac{f(x, y + \delta y) - f(x, y - \delta y)}{2\delta y} \quad (14.6)$$

$$\frac{\partial^2 f}{\partial x^2} = \frac{f(x + \delta x, y) - 2f(x, y) + f(x - \delta x, y)}{\delta x^2} \quad (14.7)$$

¹ Observe que $\partial^2 f / (\partial x \partial y) = \partial^2 f / (\partial y \partial x)$.

$$\frac{\partial^2 f}{\partial y^2} = \frac{f(x, y + \delta y) - 2f(x, y) + f(x, y - \delta y)}{\delta y^2} \quad (14.8)$$

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{f(x + \delta x, y + \delta y) - f(x + \delta x, y - \delta y) - f(x - \delta x, y + \delta y) + f(x - \delta x, y - \delta y)}{4\delta x \delta y} \quad (14.9)$$

donde δ es un valor fraccional algo pequeño.

Observe que los métodos empleados en paquetes de software comerciales también usan diferencias hacia adelante. Además, ellos son usualmente más complicados que las aproximaciones enlistadas en las ecuaciones (14.5) a la (14.9). Por ejemplo, la librería IMSL basa la perturbación en el ϵ de la máquina. Dennis y Schnabel (1996) proporcionan más detalles sobre el procedimiento.

Sin importar cómo se implemente la aproximación, el punto importante es que se pueda tener la opción de evaluar el gradiente y/o el Hessian en forma analítica. Esto puede algunas veces ser una tarea ardua, pero el comportamiento del algoritmo puede ser lo bastante benéfico como para que el esfuerzo valga la pena. Las derivadas de forma cerrada serán exactas, pero lo más importante es que reduce las evaluaciones de la función. Este último punto tiene un impacto crítico en el tiempo de ejecución.


Por otro lado, usted practicará con frecuencia la opción de calcular estas cantidades internamente mediante procedimientos numéricos. En muchos casos, el comportamiento será el adecuado y se evita la dificultad de numerosas diferenciaciones parciales. Tal podría ser el caso de los optimizadores usados en ciertas hojas de cálculo y paquetes de software matemático (por ejemplo, Excel). En tales casos, se podría no tener la opción de introducir un gradiente y un Hessian derivado en forma analítica. Sin embargo, para problemas de tamaño pequeño o moderado esto no es una gran desventaja.

14.2.2 Método de pasos ascendente

Una estrategia obvia para subir una colina podría ser determinar la pendiente máxima en la posición inicial y después comenzar a caminar en esa dirección. Pero claramente surge otro problema casi de inmediato. A menos que usted realmente tenga suerte y empiece sobre una cresta que apunta directamente a la cima, tan pronto como se mueva, su camino podría divergir en la dirección de pasos ascendente.

Al darse cuenta de este hecho, usted podría adoptar la siguiente estrategia. Podría caminar una distancia corta a lo largo de la dirección gradiente. Luego podría detenerse, reevaluar el gradiente y caminar otra distancia corta. Mediante la repetición de este proceso podría llegar eventualmente al pico de la colina.

Aunque tal estrategia parece ser superficialmente buena, no es muy práctica. En particular, la reevaluación continua del gradiente puede ser demandante en términos computacionales. Se prefiere un planteamiento que involucre moverse en un camino fijo a lo largo del gradiente inicial hasta que $f(x, y)$ detenga los incrementos; es decir, pase a ser el nivel a lo largo de su dirección de viaje. Este punto de paro pasa a ser el punto inicial donde ∇f es reevaluada y se sigue una nueva dirección. El proceso se repite hasta que se alcance la cima. Este procedimiento es conocido como *método de pasos ascen-*

**FIGURA 14.9**

Representación gráfica del método de pasos ascendente.

dente.² Es la más directa de las técnicas de búsqueda del gradiente. La idea básica detrás del procedimiento se describe en la figura 14.9.

Comenzaremos en un punto inicial (x_0, y_0) etiquetado como "0" en la figura. En este punto, se determina la dirección de pasos ascendente; esto es, el gradiente. Entonces se busca a lo largo de la dirección del gradiente, h_0 , hasta que se encuentra un máximo, el cual es etiquetado como "1" en la figura. El proceso entonces se repite.

Así, el problema se puede dividir en dos partes: 1) determinar la "mejor" dirección para la búsqueda y 2) establecer "el mejor valor" a lo largo de esa dirección de búsqueda. Como se verá, la efectividad de varios algoritmos descritos en las siguientes páginas depende de qué tan hábil seamos en ambas partes.


Por ahora, el método de pasos ascendente usa el método del gradiente como su elección para la "mejor" dirección. Se ha mostrado ya cómo se evalúa el gradiente en el ejemplo 14.1. Ahora, antes de examinar cómo se lleva el algoritmo para localizar el máximo a lo largo de la dirección de pasos, se debe hacer una pausa para explorar el modo de transformar una función de x y y en una función de h a lo largo de la dirección gradiente.

Comenzando en x_0 y y_0 , las coordenadas de cualquier punto en la dirección gradiente pueden expresarse como

$$x = x_0 + \frac{\partial f}{\partial x} h \quad (14.10)$$

$$y = y_0 + \frac{\partial f}{\partial y} h \quad (14.11)$$

² Debido a nuestro énfasis sobre la maximización, se usará la terminología de *pasos ascendente*. Al mismo enfoque se puede usar también para la minimización en este caso se usará la terminología de *pasos descendente*.

**FIGURA 14.10**

La relación entre una dirección arbitraria h y las coordenadas x y y .

donde h es la distancia a lo largo del eje h . Por ejemplo, supóngase que $x_0 = 1$ y $y_0 = 2$ y $\nabla f = 3\mathbf{i} + 4\mathbf{j}$, como se muestra en la figura 14.10. Las coordenadas de cualquier punto a lo largo del eje h están dadas por

$$x = 1 + 3h \quad (14.12)$$

$$y = 2 + 4h \quad (14.13)$$

El siguiente ejemplo ilustra la forma en que se pueden usar estas transformaciones para convertir una función de dos dimensiones de x y y en una función h de una dimensión.

EJEMPLO 14.3 Desarrollando una función 1-D a lo largo de la dirección gradiente

Enunciado del problema. Suponga que se tiene la siguiente función de dos dimensiones:

$$f(x, y) = 2xy + 2x - x^2 - 2y^2$$

Desarrolle una versión unidimensional de esta ecuación a lo largo de la dirección gradiente en el punto $x = -1$ y $y = 1$.

Solución. Las derivadas parciales se pueden evaluar en $(-1, 1)$.

$$\frac{\partial f}{\partial x} = 2y + 2 - 2x = 2(1) + 2 - 2(-1) = 6$$

$$\frac{\partial f}{\partial y} = 2x - 4y = 2(-1) - 4(1) = -6$$

Por tanto, el vector gradiente es

$$\nabla f = 6\mathbf{i} - 6\mathbf{j}$$

Para encontrar el máximo, se podría buscar a lo largo de la dirección gradiente; esto es, a lo largo de un eje h que corre a lo largo de la dirección de este vector. La función se puede expresar a lo largo de este eje como

$$\begin{aligned} f(x_0 + \frac{\partial f}{\partial x}h, y_0 + \frac{\partial f}{\partial y}h) &= f(-1 + 6h, 1 - 6h) \\ &= 2(-1 + 6h)(1 - 6h) + 2(-1 + 6h) - (-1 + 6h)^2 - 2(1 - 6h)^2 \end{aligned}$$

donde las derivadas parciales se evalúan en $x = -1$ y $y = 1$.

Al combinar términos, se desarrolla una función de una sola dimensión $g(h)$ que mapea $f(x, y)$ a lo largo del eje h .

$$g(h) = -180h^2 + 72h - 7$$

Ahora que se ha desarrollado una función a lo largo del camino de pasos ascendente, se puede explorar cómo resolver la segunda pregunta. Esto es, ¿qué tan lejos a lo largo de este camino se puede viajar? Un procedimiento podría ser moverse a lo largo de este camino hasta encontrar el máximo de esta función. Identificaremos la localización de este máximo como h^* . El cual es el valor del paso que maximiza g (y por tanto, f) en la dirección gradiente. Tal problema es equivalente a encontrar el máximo de una función de una sola variable h . Lo cual se puede hacer mediante diferentes técnicas de búsqueda de una dimensión como las analizadas en el capítulo 13. Así, se pasa de encontrar el óptimo de una función de dos dimensiones a realizar una búsqueda de una dimensión a lo largo de la dirección gradiente.

Este método es llamado de *pasos ascendente* cuando se usa un paso arbitrario de tamaño h . Si se encuentra que un valor de un solo paso h^* nos lleva directamente al máximo a lo largo de la dirección gradiente, el método es llamado *óptimo de pasos ascendente*.

EJEMPLO 14.4 Óptimo de pasos ascendente

Enunciado del problema. Maximice la siguiente función:

$$f(x, y) = 2xy + 2x - x^2 - 2y^2$$

usando los valores iniciales, $x = -1$ y $y = 1$.

Solución. Debido a que esta función es muy simple, se podría generar primero una solución analítica. Para hacer esto, las derivadas parciales se evalúan como

$$\begin{aligned} \frac{\partial f}{\partial x} &= 2y + 2 - 2x = 0 \\ \frac{\partial f}{\partial y} &= 2x - 4y = 0 \end{aligned}$$

Este par de ecuaciones se pueden resolver para el óptimo, $x = 2$ y $y = 1$. Las segundas derivadas parciales también se pueden determinar y evaluar en el óptimo

$$\frac{\partial^2 f}{\partial x^2} = -2$$

$$\frac{\partial^2 f}{\partial y^2} = -4$$

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{\partial^2 f}{\partial y \partial x} = 2$$

y el determinante de Hessian se calcula [véase ecuación (14.3)],

$$|H| = -2(-4) - 2^2 = 4$$

Por lo tanto, debido a que $|H| > 0$ y $\partial^2 f / \partial x^2 < 0$, el valor de la función $f(2, 1)$ es un máximo.

Ahora se implementará el método de pasos ascendente. Recuerde que al final del ejemplo 14.3 ya se había implementado los pasos iniciales del problema al generar

$$g(h) = -180h^2 + 72h - 7$$

Ahora, ya que ésta es una simple parábola, se puede localizar directamente el máximo (es decir, $h = h^*$) resolviendo el problema,


$$\begin{aligned} g'(h^*) &= 0 \\ -360h^* + 72 &= 0 \\ h^* &= 0.2 \end{aligned}$$

Esto significa que si se viaja a lo largo del eje h , $g(h)$ alcanza un valor mínimo cuando $h = h^* = 0.2$. Este resultado se puede sustituir en las ecuaciones (14.10) y (14.11) y resolver para las coordenadas (x, y) correspondientes a este punto,

$$\begin{aligned} x &= -1 + 6(0.2) = 0.2 \\ y &= 1 - 6(0.2) = -0.2 \end{aligned}$$

FIGURA 14.11

El método del paso ascendente para alcanzar el óptimo.



Este paso se describe en la figura 14.11 cuando se mueve del punto 0 al 1.

El segundo paso es simplemente implementado al repetir el procedimiento. Primero, las derivadas parciales se pueden evaluar en el nuevo punto de inicio $(0.2, -0.2)$ para obtener

$$\frac{\partial f}{\partial x} = 2(-0.2) + 2 - 2(0.2) = 1.2$$

$$\frac{\partial f}{\partial y} = 2(0.2) - 4(-0.2) = 1.2$$

Por tanto, el vector gradiente es

$$\nabla f \approx 1.2\mathbf{i} + 1.2\mathbf{j}$$

Esto significa que la dirección de pasos es ahora dirigida hacia arriba y a la derecha a un ángulo de 45° con respecto al eje x (véase la figura 14.11). Las coordenadas a lo largo de este nuevo eje h se puede ahora expresar como

$$x = 0.2 + 1.2h$$

$$y = -0.2 + 1.2h$$

Al sustituir estos valores en la función se obtiene

$$f(0.2 + 1.2h, -0.2 + 1.2h) = g(h) = -1.44h^2 + 2.88h + 0.2$$

El paso h^* nos lleva al máximo a lo largo de la dirección buscada y puede entonces calcularse directamente como

$$g'(h^*) = -2.88h^* + 2.88 = 0$$

$$h^* = 1$$

Este resultado se puede sustituir en las ecuaciones (14.10) y (14.11) y resolver para las coordenadas (x, y) correspondientes a este nuevo punto,

$$x = 0.2 + 1.2(1) = 1.4$$

$$y = -0.2 + 1.2(1) = 1$$

Como se describe en la figura 14.11, nos movemos a las nuevas coordenadas, etiquetada como punto 2 en la gráfica, y al hacer esto se mueve más cerca del máximo. El procedimiento se puede repetir con el resultado final que converge a la solución analítica, $x = 2$ y $y = 1$.

Puede demostrarse que el método de pasos descendente es linealmente convergente. Además, tiende a moverse muy lentamente a lo largo de crestas largas y angostas. Esto es porque el nuevo gradiente en cada punto máximo será perpendicular a la dirección original. Así, la técnica toma muchos pasos pequeños de cruce en la dirección de la ruta hacia la cima. Por tanto, aunque es confiable, hay otros procedimientos que convergen mucho más rápido, particularmente en la vecindad de un óptimo. El resto de la sección es dedicada a esos métodos.

14.2.3 Procedimientos de gradiente avanzado

Método del gradiente conjugado (Fletcher-Reeves). En la sección 14.1.2, se ha visto cómo en el método de Powell las direcciones conjugadas mejoran mucho la eficiencia de la búsqueda univariable. De manera similar, se puede también mejorar la convergencia lineal de pasos ascendentes por medio de gradientes conjugados. En efecto, un método de optimización que usa gradientes conjugados para definir la dirección de búsqueda, se puede demostrar que es cuadráticamente convergente. Esto también asegura que el método optimizará una función cuadrática exactamente en un número finito de pasos sin importar el punto de inicio. Dado que muchas funciones con buen comportamiento pueden aproximarse razonablemente bien por una cuadrática en la vecindad de un óptimo, los procedimientos de convergencia cuadrática son a menudo muy eficientes cerca de un óptimo.

Se ha visto cómo empezando con dos direcciones de búsqueda arbitrarias, el método de Powell produce nuevas direcciones de búsqueda conjugadas. Este método es cuadráticamente convergente y no requiere la información del gradiente. Por otro lado, si la evaluación de las derivadas es práctica, se puede utilizar algoritmos que combinen las ideas de pasos descendente y conjugar las direcciones para lograr un comportamiento inicial más sólido y de convergencia rápida como la técnica que gravita hacia el óptimo. El *algoritmo de gradiente conjugado Fletcher-Reeves* modifica el método de pasos ascendente al imponer la condición de que las direcciones de búsqueda del gradiente sucesivas sean mutuamente conjugadas. La prueba y el algoritmo van más allá del alcance del texto, pero se describen en Rao (1996).

Método de Newton. El método de Newton para una sola variable (recuerde la sección 13.3) se puede extender a los casos de multivariable. Escriba una serie de Taylor de segundo orden para $f(\mathbf{x})$ cerca de $\mathbf{x} = \mathbf{x}_i$,

$$f(\mathbf{x}) = f(\mathbf{x}_i) + \nabla f^T(\mathbf{x}_i)(\mathbf{x} - \mathbf{x}_i) + \frac{1}{2}(\mathbf{x} - \mathbf{x}_i)^T H_i(\mathbf{x} - \mathbf{x}_i)$$

donde H_i es la matriz Hessian. En el mínimo,

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}_j} = 0 \quad \text{para } j = 1, 2, \dots, n$$


Así,

$$\nabla f = \nabla f(\mathbf{x}_i) + H_i(\mathbf{x} - \mathbf{x}_i) = 0$$

Si H es no singular,

$$\mathbf{x}_{i+1} = \mathbf{x}_i - H_i^{-1} \nabla f \quad (14.14)$$

la cual se puede demostrar que converge en forma cuadrática cerca del óptimo. Este método de nuevo se comporta mejor que el método de pasos ascendentes (véase la figura 14.12). Sin embargo, observe que este método requiere ambos, el cálculo de las segundas derivadas y la inversión de la matriz, en cada iteración. Así, el método no es muy útil en la práctica para funciones con grandes números de variables. Además, el método de Newton puede no converger si el punto inicial no está cerca del óptimo.

**FIGURA 14.12**

Cuando el punto inicial es cercano al punto óptimo, siguiendo el gradiente puede ser ineficiente. Los métodos de Newton intentan la búsqueda a lo largo de una trayectoria directa hacia el óptimo (línea sólida).

Método de Marquardt. Se sabe que el método de pasos ascendente aumenta el valor de la función aun si el punto inicial está lejos del óptimo. Por otro lado, ya se ha descrito el método de Newton, el cual converge con rapidez cerca del máximo. El *método de Marquardt* usa el método de pasos descendente cuando x está lejos de x^* , y el método de Newton cuando x se acerca a un óptimo. Esto se puede llevar a cabo al modificar la diagonal del Hessian en la ecuación (14.14),

$$\tilde{H}_i = H_i + \alpha_i I$$

donde α_i es una constante positiva e I es la matriz de identidad. Al inicio del procedimiento, α_i se supone que es grande y

$$\tilde{H}_i^{-1} \approx \frac{1}{\alpha_i} I$$

la cual reduce la ecuación (14.14) al método de pasos ascendente. En tanto continúan las iteraciones, α_i se aproxima a cero y el método pasa a ser el de Newton.

Así, el método de Marquardt ofrece lo mejor de ambos mundos: comienza en forma lenta y confiable desde valores de inicio pobres y luego acelera en forma rápida cuando se aproxima al óptimo. Por desgracia, el método todavía requiere la evaluación del Hessian y la inversión de las matrices a cada paso.

Debería observarse que el método de Marquardt es ante todo usado para problemas de mínimos cuadrados. Por ejemplo, la librería del IMSL contiene una subrutina para este propósito.

Métodos de Quasi-Newton. Los métodos de Quasi-Newton, o métodos de variable métrica buscan estimar el camino directo hacia el óptimo en forma similar al método de Newton. Sin embargo, observe que la matriz Hessian en la ecuación (14.14) se compone de las segundas derivadas de f que varían de paso a paso. Los métodos de Quasi-Newton intentan evitar estas dificultades al aproximar H con otra matriz A sólo por medio de las primeras derivadas parciales de f . El procedimiento involucra comenzar con una aproximación inicial de H^{-1} y actualizar y mejorarla con cada iteración. Estos métodos son llamados de Quasi-Newton porque no usan el Hessian verdadero, sino más bien una aproximación. Así, se tienen dos aproximaciones al trabajar en forma simultánea: 1) la aproximación original de la serie de Taylor y 2) la aproximación Hessian.

Hay dos métodos principales de este tipo: los algoritmos de *Davidon-Fletcher-Powell* (DFP) y el de *Broyden-Fletcher-Goldfarb-Shanno* (BFGS). Ellos son similares excepto en detalles concernientes a cómo manejan los errores de redondeo y su convergencia. BFGS es por lo general reconocido como superior en la mayoría de los casos. Rao (1996) proporciona detalles y declaraciones formales de ambos algoritmos, el DFP y el BFGS.

PROBLEMAS

14.1 Encuentre la derivada direccional de

$$f(x, y) = 2x^2 + y^2$$

en la dirección de $\mathbf{h} = 3\mathbf{i} + 2\mathbf{j}$.

14.2 Encuentre el vector gradiente y la matriz Hessian para cada una de las siguientes funciones

a) $f(x, y) = 2xy^2 + 3e^{xy}$

b) $f(x, y, z) = x^2 + y^2 + 2z^2$

c) $f(x, y) = \ln(x^2 + 2xy + 3y^2)$

14.3 Dada

$$f(x, y) = 2xy + 1.5y - 1.25x^2 - 2y^2$$

Construya y resuelva un sistema de ecuaciones algebraicas lineales que maximice $f(x)$. Observe que esto se realiza al igualar a cero las derivadas parciales de f con respecto a x y y .

14.4

a) Empezar con un valor inicial de $x = 1$ y $y = 1$ y emplee dos aplicaciones del método de pasos ascendente a $f(x, y)$ para el problema 14.3.

b) Construya una gráfica con los resultados del inciso a) anterior mostrando la trayectoria de la búsqueda.


Encuentre el valor mínimo de

$$f(x, y) = (x - 2)^2 + (y - 3)^2$$

empezando en $x = 1$ y $y = 1$, usando el método de pasos descendente con un criterio de paro de $\varepsilon_s = 1\%$.

FIGURA P14.9

La búsqueda de la malla.



14.6 Realice una iteración del método de pasos ascendente para localizar el máximo de

$$f(x, y) = 3.5x + 2y + x^2 - x^4 - 2xy - y^2$$

mediante los valores iniciales $x = 0$, $y = 0$. Emplee el método de bisección para encontrar el tamaño de paso óptimo en la dirección de la búsqueda del gradiente.

14.7 Efectúe una iteración del método de pasos descendente del gradiente óptimo para localizar el mínimo de

$$f(x, y) = -7x + 1.2x^2 + 11y + 2y^2 - 2xy$$

con valores iniciales $x = 0$ y $y = 0$.

14.8 Desarrolle un subprograma usando un programa o lenguaje macro para implementar el método de búsqueda aleatoria.

Diseñe el subprograma de tal forma que esté expresamente diseñado para localizar un máximo. Pruebe el programa con $f(x, y)$ del problema 14.6. Use un rango de -2 a 2 para ambos x y y .

14.9 La *búsqueda por malla* es otro procedimiento de fuerza bruta para optimización. La versión en dos dimensiones se describe en la figura P14.9. Las dimensiones de x y y se dividen en pequeños incrementos para crear una malla. La función se evalúa entonces en cada nodo de la malla. Cuanto más densa sea la malla, es más probable localizar el óptimo.

Desarrolle un subprograma por medio de un programa o lenguaje macro para implementar el método de búsqueda por malla. Diseñe el subprograma de tal forma que esté expresamente diseñado para localizar un máximo. Pruebe su programa con el problema del ejemplo 14.1.

CAPÍTULO 15

Optimización restringida

Este capítulo aborda problemas de optimización donde entran en juego las restricciones. Primero, se analizarán problemas donde ambas, la función objetivo y las restricciones, son lineales. Para tales casos, se dispone de métodos especiales que aprovechan la linealidad de las funciones realzadas. Los llamados métodos de programación lineal y sus algoritmos resultantes, resuelven con gran eficiencia problemas muy grandes con miles de variables y restricciones. Dichos métodos se usan en un amplio rango de problemas en la ingeniería y la administración.

Después, se retomará en forma breve un problema más general de optimización restringida no lineal. Finalmente, se proporcionará una revisión de cómo se puede emplear los paquetes de software y librerías para la optimización.

15.1 PROGRAMACIÓN LINEAL

La *programación lineal* (o PL por simplicidad) es un procedimiento de optimización que trata de cumplir con un objetivo como el de maximizar las utilidades o minimizar el costo, en presencia de restricciones como lo son las fuentes limitadas. El término *lineal* denota que las funciones matemáticas que representan ambos, el objetivo y las restricciones, son lineales. El término *programación* no significa “programación en computadora”, más bien denota “programar” o “fijar una agenda” (Revelle y cols. 1997).

15.1.1 Forma estándar

El problema básico de programación lineal consiste en dos partes principales: la función objetivo y un conjunto de restricciones. Para un problema de maximización, la función objetivo es por lo general expresada como

$$\text{Maximizar } Z = c_1x_1 + c_2x_2 + \cdots + c_nx_n \quad (15.1)$$

donde c_j = pago por cada unidad de la j -ésima actividad que se lleva a cabo y x_j = magnitud de la j -ésima actividad. Así, el valor de la función objetivo, Z , es el pago total debido al número total de actividades, n .

Las restricciones se pueden representar en forma general como

$$a_{j1}x_1 + a_{j2}x_2 + \cdots + a_{jn}x_n \leq b_i \quad (15.2)$$

donde a_{ij} = cantidad de i -ésima fuente que se consume por cada unidad de j -ésima actividad y b_i = cantidad de la i -ésima fuente que está disponible. Esto es, las fuentes son limitadas.

El segundo tipo general de restricción específica que todas las actividades deben tener un valor positivo.

$$x_1 \geq 0 \quad (15.4)$$

En el contexto actual, esto expresa la noción realística de que, para algunos problemas, la actividad negativa es físicamente imposible (por ejemplo, no se puede producir bienes negativos).

Juntas, la función objetivo y las restricciones, especifican el problema de programación lineal. Éstas indican que se trata de maximizar la amortización para un número de actividades bajo la restricción de que éstas utilizan cantidades finitas de fuentes. Antes de mostrar cómo se puede obtener este resultado, se desarrollará un ejemplo.

EJEMPLO 15.1 Inicializando el problema PL

Enunciado del problema. Se desarrolla el siguiente problema del área de la ingeniería química. Sin embargo, éste es relevante para todas las áreas de la ingeniería que tienen que ver con la producción de productos con fuentes limitadas.

Suponga que una planta procesadora de gasolina recibe cada semana una cantidad fija de materia prima para gasolina. Esta última se procesa en dos tipos de gasolina, de calidad regular y premium. Estas clases de gasolina son de alta demanda; es decir, se tiene garantizada su venta y se obtiene diferentes utilidades para la compañía. Sin embargo, su producción involucra ambas restricciones, tiempo y almacenaje en sitio. Por ejemplo, sólo una de las clases se puede producir a la vez, y las instalaciones están abiertas solamente 80 horas por semana. Además, existe un límite de almacenamiento para cada uno de los productos. Todos estos factores se enlistan abajo (observe que una tonelada métrica, o ton, es igual a 1 000 kg):

Recurso	Producto		Disponibilidad del recurso
	Regular	Premium	
Materia prima para la gasolina	7 m ³ /tonelada	11 m ³ /tonelada	77 m ³ /semana
Tiempo de producción	10 hr/tonelada	8 hr/tonelada	80 hr/semana
Almacenamiento	9 toneladas	6 toneladas	
Aprovechamiento	150/tonelada	175/tonelada	

Desarrolle una formulación de programación lineal para maximizar las utilidades de esta operación.

Solución. El ingeniero que opera esta planta debe decidir la cantidad a producir de cada gasolina para maximizar las utilidades. Si las cantidades producidas cada semana de gasolinas regular y premium son designadas x_1 y x_2 , respectivamente, la ganancia total se puede calcular como

$$\text{Ganancia total} = 150x_1 + 175x_2$$

o escribirla como una función objetivo en programación lineal,

$$\text{Maximizar } Z = 150x_1 + 175x_2$$

Las restricciones se pueden desarrollar en una forma similar. Por ejemplo, el total de gasolina cruda utilizada se puede calcular como

$$\text{Total de gasolina utilizada} = 7x_1 + 11x_2$$

Este total no puede exceder el abastecimiento disponible de 77 m³/semana, así que la restricción se puede representar como

$$7x_1 + 11x_2 \leq 77$$

Las restricciones restantes se pueden desarrollar en una forma similar, la formulación total resultante para la PL está dada por

$$\text{Maximizar } Z = 150x_1 + 175x_2 \quad (\text{maximizar la ganancia})$$

Sujeta a

$$7x_1 + 11x_2 \leq 77 \quad (\text{restricciones de materiales})$$

$$10x_1 + 8x_2 \leq 80 \quad (\text{restricción de tiempo})$$

$$x_1 \leq 9 \quad (\text{restricción de almacenaje "regular"})$$

$$x_2 \leq 6 \quad (\text{restricción de almacenaje "premium"})$$

$$x_1, x_2 \geq 0 \quad (\text{restricciones positivas})$$

Observe que el conjunto de ecuaciones anterior constituye la formulación completa de PL. Las explicaciones en los paréntesis de la derecha se han incluido para clarificar el significado de cada ecuación.

15.1.2 Solución gráfica

Debido a que las soluciones gráficas están limitadas a dos y tres dimensiones, tienen utilidad práctica limitada. Sin embargo, son muy útiles para demostrar algunos conceptos básicos que resaltan las técnicas algebraicas generales usadas para resolver problemas con grandes dimensiones en la computadora.

Para un problema en dos dimensiones, como el del ejemplo 15.1, la solución espacial se define como un plano con x_1 medida a lo largo de la abscisa y x_2 , a lo largo de la ordenada. Como las restricciones son lineales, se pueden trazar sobre este plano como líneas rectas. Si el problema de PL se formula adecuadamente (es decir, si tiene una solución), estas líneas restrictivas delinearán una región, llamada el *espacio de solución factible*, englobando todas las posibles combinaciones de x_1 y x_2 que obedecen las restricciones y, por tanto, representan soluciones factibles. La función objetivo para un valor particular de Z se puede trazar como otra línea recta y sobrepuesta en este espacio. El valor de Z puede entonces ser ajustado hasta que esté en el máximo valor, mientras todavía toca el espacio factible. Este valor de Z representa la solución óptima. Los valores correspondientes de x_1 y x_2 , donde Z toca el espacio de solución factible, representan los valores óptimos para las actividades. El siguiente ejemplo deberá ayudar a clarificar el procedimiento.

EJEMPLO 15.2 Solución gráfica

Enunciado del problema. Desarrolle una solución gráfica para el problema de procesamiento de gasolina que se derivó antes en el ejemplo 15.1:

$$\text{Maximizar } Z = 150x_1 + 175x_2$$

Sujeta a

$$7x_1 + 11x_2 \leq 77 \quad (1)$$

$$10x_1 + 8x_2 \leq 80 \quad (2)$$

$$x_1 \leq 9 \quad (3)$$

$$x_2 \leq 6 \quad (4)$$

$$x_1 \geq 0 \quad (5)$$

$$x_2 \geq 0 \quad (6)$$

Se ha numerado las restricciones para identificarlas en la siguiente solución gráfica.

Solución. Primero, se pueden trazar las restricciones sobre el espacio de solución. Por ejemplo, se puede formular la primera restricción como una línea al reemplazar la desigualdad por un signo de igual y resolver para x_2 :

$$x_2 = -\frac{7}{11}x_1 + 7$$

Así, como en la figura 15.1a, los valores posibles de x_1 y x_2 que obedecen dicha restricción se hallan por debajo de esta línea (la dirección es designada en la gráfica por la pequeña flecha). Las otras restricciones se pueden evaluar en forma similar, como sobrepuestas sobre la figura 15.1a. Observe cómo éstas encierran una región donde todas se encuentran. Éste es el espacio de solución factible (el área *ABCDE* en la gráfica).

Además de definir el espacio factible, la figura 15.1a también proporciona un conocimiento adicional. En particular, se puede ver que la restricción 3 (almacenamiento de gasolina regular) es "redundante". Esto es, el espacio de solución factible no resulta afectado si fuese suprimida.

Después, se puede agregar la función objetivo a la gráfica. Para hacer esto, se debe escoger un valor de Z . Por ejemplo, para $Z = 0$ la función objetivo es ahora

$$0 = 150x_1 + 175x_2$$

o, resolviendo para x_2

$$x_2 = -\frac{150}{175}x_1$$

Como se muestra en la figura 15.1b, ésta representa una línea punteada interceptando el origen. Ahora, puesto que estamos interesados en maximizar Z , se puede aumentar ésta a digamos 600, y la función objetivo es

$$x_2 = \frac{600}{175} - \frac{150}{175}x_1$$




FIGURA 15.1

solución gráfica de un problema de programación lineal. a) Las restricciones definen un espacio de solución factible. b) La función objetivo se puede incrementar hasta que alcance el valor más alto que cumpla con todas las restricciones. Cálculamente, se mueve hacia arriba y a la derecha hasta que toca el espacio factible en un solo punto óptimo.

Así, incrementando el valor de la función objetivo, la línea se mueve lejos del origen. Como la línea todavía está dentro del espacio de solución, nuestro resultado es aún factible. Sin embargo, por la misma razón, todavía hay espacio para mejorarlo. Por tanto, Z se puede seguir aumentando hasta que un incremento adicional lleve la función objetivo más allá de la región factible. Como se muestra en la figura 15.1b, el valor máximo de Z corresponde a 1 400 aproximadamente. En este punto, x_1 y x_2 son casi igual a 4.9 y 3.9, en forma respectiva. Así, la solución gráfica indica que si se producen estas cantidades de gasolinas regular y premium, se alcanzará una máxima utilidad de casi 1 400.

Además de determinar los valores óptimos, el procedimiento gráfico proporciona conocimientos adicionales en el problema. Esto se puede apreciar al sustituir de nuevo las soluciones en las ecuaciones restrictivas.

$$7(4.9) + 11(3.9) \cong 77$$

$$10(4.9) + 8(3.9) \cong 80$$

$$4.9 \leq 9$$

$$3.9 \leq 6$$

En consecuencia, como queda también claro en la gráfica, producir la cantidad óptima de cada producto nos lleva directamente al punto donde se encuentran las restricciones de las fuentes (1) y del tiempo (2). Tales restricciones se dice que están *enlazadas*. Además, la gráfica también hace evidente que ninguna de las restricciones de almacena-

miento [(3) y (4)] actúan como una limitante. Tales restricciones se conocen como *no enlazadas*. Esto nos lleva a la conclusión práctica de que, para este caso, se puede aumentar las utilidades, ya sea con un incremento en el abastecimiento de fuentes (la gasolina cruda) o en el tiempo de producción. Además, esto indica que el aumento del almacenamiento podría no tener impacto sobre las utilidades.

El resultado obtenido en el ejemplo anterior es uno de los cuatro posibles resultados que por lo general se puede obtener en un problema de programación lineal. Éstos son:

1. *Solución única.* Como en el ejemplo, la función objetivo máxima intercepta un solo punto.
2. *Soluciones alternas.* Suponga que la función objetivo del ejemplo tuviera coeficientes, de tal forma que fueran paralelos precisamente a una de las restricciones. En nuestro problema ejemplo, una forma en la cual esto podría ocurrir, sería que las utilidades fueran cambiadas a \$140/ton y \$220/ton. Entonces, más que un solo punto, el problema podría tener un número infinito de óptimos correspondientes a un segmento de línea (véase figura 15.2a).
3. *Solución no factible.* Como en la figura 15.2b, es posible que el problema esté formulado de tal manera que no exista solución factible. Esto puede deberse a que se trata con un problema sin solución o a errores en la formulación del problema. Lo último puede resultar si el problema está tan sobrerrestringido que ninguna solución puede satisfacer todas las restricciones.
4. *Problemas sin límite.* Como en la figura 15.2c, esto usualmente significa que el problema está bajorrestringido y, por tanto, con finales abiertos. Como para el caso de la solución no factible, puede a menudo surgir de errores cometidos durante la especificación del problema.

Ahora supongamos que nuestro problema involucra una solución única. El procedimiento gráfico podría sugerir una estrategia numerativa para dar con el máximo. De la

FIGURA 15.2

Además de una sola ecuación óptima (por ejemplo, figura 15.1b), existen otros tres resultados posibles de un problema de programación lineal: a) alternativa óptima, b) solución no factible y c) en resultado sin límites.




figura 15.1, debería quedar claro que siempre ocurre el óptimo en uno de los puntos esquina donde se encuentran dos restricciones. Tal punto se conoce de manera formal como un *punto extremo*. Así, fuera del número infinito de posibilidades en el espacio de decisión y enfocándonos sobre los puntos extremo, claramente se reducen las opciones posibles.

Además, se puede reconocer que no todo punto extremo es factible; esto es, satisfacer todas las restricciones. Por ejemplo, observe que el punto *F* en la figura 15.1a es un punto extremo, pero no es factible. Si nos limitamos a *puntos extremos factibles*, se reduce el campo factible todavía más.

Por último, una vez que se ha identificado todos los puntos extremo factibles, el que ofrezca el mejor valor de la función objetivo representará la solución óptima. Se podría encontrar esta solución óptima mediante la exhaustiva (e ineficiente) evaluación del valor de la función objetivo en cada punto extremo factible. En la siguiente sección se analiza el método simplex, que ofrece una estrategia preferible que representa en forma gráfica un rumbo selectivo a través de la secuencia de puntos extremos factibles para arribar al óptimo de una manera extremadamente eficiente.

15.1.3 El método simplex

El método simplex se basa en la suposición de que la solución óptima estará en un punto extremo. Así, el procedimiento debe ser capaz de discernir si durante la solución a un problema ocurre un punto extremo. Para realizar esto, las ecuaciones con restricciones se reformulan como igualdades por medio de la introducción de las llamadas variables de holgura.

Variables de holgura. Como lo indica su nombre, una *variable de holgura* mide cuánto de una fuente restringida está disponible; es decir, cuánta "holgura" de la fuente está disponible. Por ejemplo, recuerde la fuente restringida que se usó en los ejemplos 15.1 y 15.2:

$$7x_1 + 11x_2 \leq 77$$

Se puede definir una variable de holgura S_1 como la cantidad de gasolina cruda que no se usa para un nivel de producción particular (x_1, x_2) . Si esta cantidad se agrega al lado izquierdo de la restricción, forma la relación exacta

$$7x_1 + 11x_2 + S_1 = 77$$

Ahora se reconoce lo que la variable de holgura nos indicaba. Si ésta es positiva, significa que se tiene algo de "holgura" para esta restricción. Esto es, se cuenta con algo más de recursos que no han sido utilizados por completo. Si es negativa, nos indica que nos hemos excedido en la restricción. Finalmente, si es cero, denota que se cumplió exactamente con la restricción. Es decir, se dispuso de todo el recurso. Puesto que ésta es exactamente la condición donde las líneas de restricción se intersectan, la variable de holgura proporciona un medio para detectar puntos extremos.

Una variable de holgura diferente se desarrolla para cada ecuación restringida, resultando en lo que se llama *versión completamente aumentada*,

$$\text{Maximizar } Z = 150x_1 + 175x_2$$

Sujeta a

$$7x_1 + 11x_2 + S_1 = 77 \quad (15.4a)$$

$$10x_1 + 8x_2 + S_2 = 80 \quad (15.4b)$$

$$x_1 + S_3 = 9 \quad (15.4c)$$

$$x_2 + S_4 = 6 \quad (15.4d)$$

$$x_1, x_2, S_1, S_2, S_3, S_4 \geq 0$$

Advierta cómo se han formulado de igual modo las cuatro ecuaciones, de tal manera que las incógnitas están alineadas en las columnas. Se hizo así para resaltar que ahora se trata de un sistema de ecuaciones algebraicas lineales (recuerde la parte tres). En la siguiente sección se mostrará cómo se pueden usar estas ecuaciones para determinar los puntos extremo en forma algebraica.

Solución algebraica. En contraste con la parte tres, donde se tenía n ecuaciones con n incógnitas, nuestro sistema ejemplo [ecuaciones (15.4)] está *subespecificado*; esto es, tiene más incógnitas que ecuaciones. En términos generales, hay n variables estructuradas (es decir, las incógnitas originales), m excedentes o variables de holgura (una por restricción), y $n + m$ variables totales (estructuradas más excedentes). Para el problema de la producción de gasolina se tienen 2 variables estructuradas, 4 variables de holgura y 6 variables totales. Así, el problema involucra resolver 4 ecuaciones con 6 incógnitas.

La diferencia entre el número de incógnitas y el de ecuaciones (igual a 2 en nuestro problema) está directamente relacionada con la forma en que se puede distinguir un punto extremo factible. En forma específica, cada punto factible tiene 2 variables de las 6 que se igualaron a cero. Por ejemplo, los cinco puntos esquina del área $ABCDE$ tienen los siguientes valores cero:

Punto extremo	Variables cero
A	x_1, x_2
B	x_2, S_2
C	S_1, S_2
D	S_1, S_4
E	x_1, S_4

Esta observación nos lleva a concluir que los puntos extremo se pueden determinar en la forma estándar al igualar las dos variables a cero. En nuestro ejemplo, esto reduce el problema a una forma soluble de 4 ecuaciones con 4 incógnitas. Por ejemplo, para el punto E , haciendo $x_1 = S_4 = 0$ se reduce la forma estándar a

$$11x_2 + S_1 = 77$$

$$8x_2 + S_2 = 80$$

$$+ S_3 = 9$$

$$x_2 = 6$$

la cual se puede resolver para $x_2 = 6$, $S_1 = 11$, $S_2 = 32$ y $S_3 = 9$. Junto con $x_1 = S_4 = 0$, estos valores definen el punto E .

Para generalizar, una solución básica para m ecuaciones lineales con n incógnitas se desarrolla al igualar $n - m$ variables a cero, y resolviendo las m ecuaciones para las m incógnitas restantes. Las variables cero son formalmente referidas como *variables no básicas*, mientras las m variables restantes son llamadas *variables básicas*. Si todas las variables básicas son no negativas, el resultado es llamado *solución factible básica*. El óptimo será una de éstas.

Ahora un procedimiento directo para determinar la solución óptima podría ser calcular todas las soluciones básicas, para determinar cuáles son factibles, y entre ellas, cuál tiene el valor de Z más grande. Pero éste no es un buen procedimiento por dos razones.

Primero, para problemas de tamaños moderados, el procedimiento puede involucrar resolver una gran cantidad de ecuaciones. Para m ecuaciones con n incógnitas, se deben resolver

$$C_m^n = \frac{n!}{m!(n-m)!}$$

ecuaciones simultáneas. (Por ejemplo, si hay 10 ecuaciones ($m = 10$) con 16 incógnitas ($n = 16$), se podría tener 8 008 [= 16!/(10! 6!)] sistemas 10×10 de ecuaciones a resolver!

Segundo, una porción significativa de éstas puede ser no factible. Por ejemplo, en el problema actual de los $C_6^4 = 15$ puntos extremos, sólo 5 son factibles. Claramente, si se pudiese evitar resolver todos estos sistemas innecesarios, se podría desarrollar un algoritmo más eficiente. Un procedimiento como tal se describe a continuación.

Implementación del método simplex. El método simplex evita las ineficiencias descritas en la sección anterior. Esto lo realiza al comenzar con una solución factible básica. Luego se mueve a través de una secuencia con las otras soluciones factibles básicas que sucesivamente mejoran el valor de la función objetivo. En forma eventual, se alcanza el valor óptimo y termina el método.

Se ilustrará el procedimiento mediante el problema de procesamiento de la gasolina de los ejemplos 15.1 y 15.2. El primer paso es empezar en una solución factible básica (es decir, en una esquina del punto extremo del espacio factible). Para casos como los nuestros, un punto de inicio obvio podría ser el A ; esto es, $x_1 = x_2 = 0$. Las 6 ecuaciones originales con 4 incógnitas serían

$$\begin{aligned} S_1 &= 77 \\ S_2 &= 80 \\ S_3 &= 9 \\ S_4 &= 6 \end{aligned}$$

Así, los valores iniciales de las variables básicas son dados automáticamente como iguales a los lados derecho de las restricciones.

Antes de proceder al siguiente paso, la información inicial se puede ahora resumir en un formato tabular conveniente llamado *representación*. Como se muestra en la tabla de la siguiente página, la representación proporciona un resumen conciso de la información clave que constituye el problema de programación lineal.

Básica	Z	x_1	x_2	S_1	S_2	S_3	S_4	Solución	Intercepción
Z	1	-150	-175	0	0	0	0	0	
S_1	0	7	11	1	0	0	0	77	11
S_2	0	10	8	0	1	0	0	80	8
S_3	0	1	0	0	0	1	0	9	9
S_4	0	0	1	0	0	0	1	6	∞

Observe que para propósitos de la representación, la función objetivo se expresa como

$$Z - 150x_1 - 175x_2 - 0S_1 - 0S_2 - 0S_3 - 0S_4 = 0 \quad (15.5)$$

El siguiente paso implica moverse a una nueva solución factible básica que nos lleva a una mejora de la función objetivo. Esto se lleva a cabo al aumentar una variable actual no básica (en este punto, x_1 o x_2) por arriba de cero para que Z aumente. Recuerde que, para el ejemplo actual, los puntos extremos deben tener 2 valores cero. Por tanto, una de las variables básicas actuales (S_1 , S_2 , S_3 o S_4) deben también igualarse a cero.

Para resumir este paso importante: una de las variables no básicas actuales debe hacerse básica (no cero). Esta variable se llama *variable de entrada*. En el proceso, una de las variables básicas actuales se hace no básica (cero). Esta variable se llama *variable de salida*.

Ahora, desarrollaremos un procedimiento matemático para seleccionar las variables de entrada y salida. Debido a la convención de cómo se escribe la función objetivo [véase ecuación (15.5)], la variable de entrada puede ser cualquier variable en la función objetivo que tenga un coeficiente negativo (ya que esto hará a Z más grande). La variable con el valor negativo más grande se escoge de manera convencional porque nos lleva usualmente al incremento más grande en Z . Para nuestro caso, x_2 podría ser la variable de entrada puesto que su coeficiente, -175 , es más negativo que el coeficiente de x_1 , -150 .

En este punto se puede consultar la solución gráfica por visualización. Se comienza en el punto A , como se muestra en la figura 15.3. Con base en su coeficiente, se debería escoger x_2 para introducirlo. Sin embargo, para continuar con este breve ejemplo, seleccionamos x_1 puesto que se observa en la gráfica que nos llevará más rápido al máximo.

Después, se debe escoger la variable de salida de entre las variables básicas actuales (S_1 , S_2 , S_3 o S_4). Se puede ver gráficamente que hay dos posibilidades. Moviéndonos al punto B se tendrá S_2 igual a cero, mientras que al movernos al punto F tendremos S_1 igual a cero. Sin embargo, por la gráfica también queda claro que F no es posible, ya que queda fuera del espacio de solución factible. Así, se decide mover de A a B .

¿Cómo se detecta el mismo resultado en forma matemática? Una forma es calcular los valores para los cuales las líneas de restricción interceptan el eje o línea que corresponde a la variable de salida (en nuestro caso, el eje x_1). Se puede calcular este valor como la razón del lado derecho de la restricción (la columna "Solución" de la representación) al coeficiente correspondiente de x_1 . Por ejemplo, para la primera variable de holgura restrictiva S_1 , el resultado es

$$\text{Intercepción} = \frac{77}{7} = 11$$

Las intersecciones restantes se pueden calcular y enlistar como la última columna de la tabla. Como 8 es el entero positivo más pequeño, esto significa que la segunda línea


**FIGURA 15.3**

Ilustración gráfica de cómo se mueve en forma sucesiva el método simplex a través de soluciones básicas factibles para llegar al óptimo de manera eficiente.

restringida se alcanzará primero en tanto x_1 aumente. Por tanto, S_2 debería ser la variable de entrada.

En este punto, se ha movido al punto B ($x_2 = S_2 = 0$), y la nueva solución básica es ahora

$$\begin{aligned} 7x_1 + S_1 &= 77 \\ 10x_1 &= 80 \\ x_1 + S_3 &= 9 \\ S_4 &= 6 \end{aligned}$$

La solución de este sistema de ecuaciones define en forma efectiva los valores de las variables básicas en el punto B : $x_1 = 8$, $S_1 = 21$, $S_3 = 1$, $S_4 = 6$.

La tabla se puede usar para realizar los mismos cálculos al emplear el método de Gauss-Jordan. Recuerde que la estrategia básica detrás de Gauss-Jordan implica convertir el elemento pivote a 1 y después eliminar los coeficientes en la misma columna arriba y abajo del elemento pivote (recuerde la sección 9.7).

Para este ejemplo, el renglón pivote es S_2 (la variable de entrada) y el elemento pivote es 10 (el coeficiente de la variable de salida, x_1). Al dividir el renglón entre 10 y reemplazar S_2 por x_1 se tiene

Básica	Z	x_1	x_2	S_1	S_2	S_3	S_4	Solución	Intercepción
Z	1	-150	-175	0	0	0	0	0	
S_1	0	7	11	1	0	0	0	77	
x_1	0	1	0.8	0	0.1	0	0	8	
S_3	0	1	0	0	0	1	0	9	
S_4	0	0	1	0	0	0	1	6	

Después, los coeficientes x_1 en los otros renglones se pueden eliminar. Por ejemplo, para el renglón de la función objetivo, el renglón pivote se multiplica por -150 y se resta el resultado del primer renglón para dar

Z	x_1	x_2	S_1	S_2	S_3	S_4	Solución
1	-150	-175	0	0	0	0	0
-0	$-(-150)$	$-(-120)$	-0	$-(-15)$	0	0	$(1\ 200)$
1	0	-55	0	15	0	0	1 200

Operaciones similares se pueden ejecutar en los renglones restantes para obtener la nueva tabla

Básica	Z	x_1	x_2	S_1	S_2	S_3	S_4	Solución	Intercepción
Z	1	0	-55	0	15	0	0	1 200	
S_1	0	0	5.4	1	-0.7	0	0	21	3.889
x_1	0	1	0.8	0	0.1	0	0	8	10
S_3	0	0	-0.8	0	-0.1	1	0	1	-1.25
S_4	0	0	1	0	0	0	1	6	6

Así, la nueva tabla resume toda la información para el punto B. Esto incluye el hecho de que el movimiento ha aumentado la función objetivo a $Z = 1\ 200$.

Esta tabla se puede usar entonces para representar el próximo, y en este caso, el punto final. Sólo una más de las variables, x_2 , tiene un valor negativo en la función objetivo, y se escoge, por tanto, como la variable de salida. De acuerdo con los valores de la intercepción (ahora calculados como la columna de solución sobre los coeficientes de la columna x_2), la primera restricción tiene el valor positivo más pequeño y, por tanto, se selecciona a S_1 como la variable de entrada. Así, el método simplex mueve los puntos de B a C en la figura 15.3. Por último, la eliminación Gauss-Jordan se puede implementar para resolver las ecuaciones simultáneas. El resultado es la tabla final,

Básica	Z	x_1	x_2	S_1	S_2	S_3	S_4	Solución
Z	1	0	0	10.1852	7.8704	0	0	1 413.889
x_2	0	0	1	0.1852	-0.1296	0	0	3.889
x_1	0	1	0	-0.1481	0.2037	0	0	4.889
S_3	0	0	0	0.1481	-0.2037	1	0	4.111
S_4	0	0	0	-0.1852	0.1296	0	1	2.111

Se sabe que éste es el resultado final porque no quedan coeficientes negativos en el renglón de la función objetivo. La solución final se tabula como $x_1 = 3.889$ y $x_2 = 4.889$, los cuales dan una función objetivo máxima de $Z = 1\ 413.889$. Además, como S_1 y S_4 están todavía en la base, sabemos que la solución está limitada por la primera y

15.2 OPTIMIZACIÓN RESTRINGIDA NO LINEAL

Existe un número de procedimientos para el manejo de problemas de optimización no lineal en la presencia de restricciones. Dichos procedimientos se pueden dividir en forma general en directos e indirectos (Rao, 1996). Un procedimiento típico indirecto usa las muy conocidas *funciones de penalización*. Éstas involucran colocar expresiones adicionales para hacer la función objetivo menos óptima en tanto la solución se aproxima a la restricción. Así, la solución será no aceptada por violar las restricciones. Aunque tales métodos pueden ser útiles en algunos problemas, pueden ser difíciles cuando el problema involucra muchas restricciones.

El método de *búsqueda del gradiente reducido generalizado*, o GRG (por sus siglas en inglés), es uno de los más populares métodos directos (para detalles, véase Lasdon y cols., 1978; Lasdon y Smith, 1992). Éste es, de hecho, el método no lineal usado en el Solver de Excel.

Primero “reduce” el problema a uno de optimización no restringida. Esto lo hace al resolver un conjunto de ecuaciones no lineales para las variables básicas en términos de variables no básicas. Después, se resuelve el problema no restringido usando procedimientos similares a los descritos en el capítulo 14. Se escoge primero una dirección de búsqueda. La selección por default es un procedimiento *cuasi-Newton* (BFGS) que, como se describió en el capítulo 14, requiere el almacenamiento de una aproximación de la matriz Hessian. Este procedimiento se ejecuta muy bien en la mayoría de los casos. El procedimiento del *gradiente conjugado* está también disponible en Excel como una alternativa para problemas grandes. El Solver de Excel tiene la excelente característica que en forma automática cambia al método del gradiente conjugado dependiendo de la disponibilidad de almacenamiento. Una vez que se ha establecido la dirección de búsqueda, se lleva a cabo la búsqueda en una dimensión a lo largo de esa dirección mediante un procedimiento de tamaño de paso variable.

15.3 OPTIMIZACIÓN CON PAQUETES DE SOFTWARE

Los paquetes de software y librerías tienen grandes capacidades para la optimización. En esta sección, se dará una introducción a algunos de los más útiles.

15.3.1 Mathcad

Mathcad contiene una función en modo numérico llamada **Find**, que se puede usar para resolver hasta 50 ecuaciones algebraicas no lineales simultáneas con restricciones de desigualdad. El uso de esta función para aplicaciones no restringidas se describió en la parte dos. Si **Find** falla en la localización de una solución que satisface las ecuaciones y restricciones, regresa con un mensaje de error “no se encontró solución”. Sin embargo, Mathcad contiene también una función similar llamada **Minerr**. Esta función da resultados de solución que minimizan los errores en las restricciones aun cuando no puedan encontrarse soluciones exactas. Esta función resuelve ecuaciones y acomoda varias restricciones mediante el método Lenenberg-Marquardt tomando de los algoritmos de dominio público MINPACK, desarrollados y publicados por el Laboratorio Nacional Argonne.

Hagamos un ejemplo donde se utiliza **Find** para resolver un sistema de ecuaciones no lineales con restricciones que introducen los valores iniciales de $x = -1$ y $y = 1$ mediante los símbolos definidos como se muestra en la figura 15.4. La instrucción **Given** entonces le indica a Mathcad que se debe introducir un sistema de ecuaciones. Observe que para esta aplicación Mathcad requiere el uso de un signo de igual simbólico, tecleado como [Ctrl] = y > para separar los lados izquierdo y derecho de una ecuación. Ahora se calcula el vector que consiste de $xval$ y $yval$ usando **Find**(x, y) y los valores son mostrados con un signo igual.


Una gráfica que muestra las ecuaciones y restricciones, así como la solución, se puede insertar en cualquier lugar sobre la hoja de cálculo al hacer clic en la ubicación deseada. Esto coloca una retícula roja en esa localización. Entonces se usa la secuencia Insert/Graph/X-Y Plot en el menú para colocar un gráfico vacío sobre la hoja de cálculo con símbolos matemáticos para las expresiones que habrán de graficarse y para los rangos de los ejes x y y . Cuatro variables se trazan sobre el eje y como se muestra (las mitades inferior y superior de la ecuación para el círculo, la función lineal y un patrón cruzado que representa la restricción $x > 2$). Los rangos para estos casos son x para las mitades del círculo superior e inferior, ξ para la línea y η para la restricción. Mathcad realiza el resto para producir la gráfica. Una vez que se ha creado la gráfica, se puede usar del menú la secuencia Format/Graph/X-Y Plot para variar el tipo de gráfica, cambiar color, tipo y grueso de la línea de la función, y agregar títulos, etiquetas y otras características. La gráfica y los valores numéricos para $xval$ y $yval$ ilustran excelentemente la solución, así como la intersección del círculo y la línea en la región $x > 2$.

15.3.2 Programación lineal en Excel

Existe una variedad de paquetes de software especialmente diseñados para implementar programación lineal. Sin embargo, como su disponibilidad es amplia, este análisis se

FIGURA 15.4

Pantalla de Mathcad de un problema de optimización restringida no lineal.



concentrará en la hoja de cálculo Excel. Esta involucra usar la opción Solver que antes no empleó en el capítulo 7 para localizar raíces.

La manera en la cual se usa Solver para programación lineal es similar a nuestras aplicaciones previas en el sentido de que los datos se introducen en las celdas de la hoja de cálculo. La estrategia básica es llegar a una celda que esté optimizada como una función de las variaciones de las otras celdas sobre la hoja de cálculo. El siguiente ejemplo ilustra cómo se puede realizar esto para el problema de procesamiento de la gasolina.

EJEMPLO 15.3 Usando el Solver de Excel para un problema de programación lineal

Enunciado del problema. Utilice una hoja de cálculo en Excel para calcular los valores adecuados en el problema del procesamiento de la gasolina examinado en este capítulo.

Solución. Una hoja de cálculo de Excel para calcular los valores pertinentes en el problema de procesamiento de gasolina es mostrado en la figura 15.5. Las celdas no sombreadas son las que contienen los datos numéricos y leyendas. Las celdas sombreadas involucran las cantidades que se calculan con base en las otras celdas. Reconozca que la celda a ser maximizada es la D12, la cual contiene la utilidad total. Las celdas que cambian son B4: C4, en las cuales se tiene las cantidades de la gasolina producida regular y premium.

Una vez que se crea la hoja de cálculo, se selecciona Solver del menú Tools (Herramientas). En esta etapa un recuadro de diálogo se mostrará, requiriendo de usted la infor-

FIGURA 15.5

Acondicionamiento de una hoja de cálculo en Excel para usar el Solver para la programación lineal.

	A	B	C	D	E
1	Problema para el proces. de gasolina				
2					
3		Regular	Premium	Total	Disponib.
4	Producido	0	0		
5					
6	Materia prima	7	11	0	77
7	Tiempo	10	8	0	80
8	Almacen. de regular			0	9
9	Almacen. de premium			0	6
10					
11	Aprov. por unidad	150	175		
12	Aprovechamiento	0	0	0	

$= B6 \cdot B4 + C6 \cdot C4$
 $= B7 \cdot B4 + C7 \cdot C4$
 $= B4$
 $= C4$
 $= B4 \cdot B11$
 $= C4 \cdot C11$
 $= B12 + C12$

mación pertinente. Estas celdas pertinentes del recuadro de diálogo de Solver se llenarán como

Ubique la celda dentro:	D12
Igual a	☒ máx ☐ mín ☐ igual a 0
Al cambiar celdas	B4:C4
Sujeto a:	D6<=E6 D7<=E7 D8<=E8 D9<=E9

Se debe incluir las restricciones una por una al seleccionar el botón "Add". Esto abrirá un recuadro de diálogo como el siguiente

Celda de referencia:

Restricción

D6

<=

E6

Como se muestra, la restricción donde el total de materia prima para la gasolina (celda D6) debe ser menor o igual que el abastecimiento disponible (E6) se puede agregar como se ejemplificó. Después de agregar cada una de las restricciones, el botón "Add" puede ser seleccionado. Cuando se haya introducido las cuatro restricciones, seleccionamos el botón OK para regresar al recuadro de diálogo del Solver.

Ahora, antes de la ejecución, se debería seleccionar el botón options del Solver y revisar el recuadro rotulado como "Assume linear model" (Suponer modelo lineal). Esto hará que Excel emplee una versión del algoritmo simplex (en lugar del Solver no lineal más general que normalmente usa) que acelera su aplicación.

FIGURA 15.6

Hoja de cálculo de Excel con la solución al problema de programación lineal.

	A	B	C	D	E
1	Problema para el proces. de gasolina				
2					
3		Regular	Prémium	Total	Disponib.
4	Producido	4.888889	3.888889		
5					
6	Materia prima	7	11	77	77
7	Tiempo	10	8	80	80
8	Almacen. de regular			4.888889	9
9	Almacen. de prémium			3.888889	6
10					
11	Aprov. por unidad	150	175		
12	Aprovechamiento	733.3333	680.5556	1413.8889	

Después de seleccionar esta opción, regrese el menú Solver. Cuando seleccione el botón OK, se abrirá un recuadro de diálogo con un reporte sobre el éxito de la operación. Para el caso actual, el Solver obtiene la solución correcta (véase figura 15.6).

Además de obtener la solución, el Solver también proporciona algunos reportes resumen útiles. Éstos serán explorados en las aplicaciones de la ingeniería que se describen en la sección 16.2.

15.3.3 Excel para optimización no lineal

La manera de usar Solver para optimización no lineal es similar a nuestras aplicaciones anteriores en cuanto a que los datos son introducidos en las celdas de la hoja de cálculo. Una vez más, la estrategia básica es tener una sola celda a optimizar como una función de las variaciones de las otras celdas sobre la hoja de cálculo. El siguiente ejemplo ilustra cómo hacer esto para el problema del paracaidista que se acondicionó en la introducción de esta parte del libro (recuerde el ejemplo PT4.1).

EJEMPLO 15.4 Uso del Solver de Excel para la optimización restringida no lineal

Enunciado del problema. Recuerde que en el ejemplo PT4.1 se desarrolló una optimización restringida no lineal para minimizar el costo de la caída de un paracaídas en un campo de refugiados. Los parámetros para este problema son

Parámetro	Símbolo	Valor	Unidades
Masa total	M_t	2 000	kg
Aceleración de la gravedad	g	9.8	m/s ²
Coefficiente de costo (constante)	c_0	200	\$
Coefficiente de costo (por longitud)	c_1	56	\$/m
Coefficiente de costo (por área)	c_2	0.1	\$/m ²
Velocidad crítica de impacto	v_c	20	m/s
Efecto del área sobre el arrastre	k_c	3	kg/(s·m ²)
Altura inicial de caída	z_0	500	m

Sustituyendo estos valores en las ecuaciones (PT4.11) a (PT4.19) se obtiene

$$\text{Minimizar } C = n(200 + 56\ell + 0.1A^2)$$

sujeto a

$$v \leq 20$$

$$n \geq 1$$

donde n es un entero y todas las otras variables son reales. Además, las siguientes cantidades se definen como

$$A = 2\pi r^2$$

$$\ell = \sqrt{2}r$$

$$c = 3A$$

$$m = \frac{M_t}{n} \quad (15.6)$$

$$t = \text{raíz} \left[500 - \frac{9.8m}{c}t + \frac{9.8m^2}{c^2}(1 - e^{-(c/m)t}) \right] \quad (15.7)$$

$$v = \frac{9.8m}{c}(1 - e^{-(c/m)t})$$

Use Excel para resolver este problema para las variables diseño r y n que minimicen el costo C .

Solución. Antes de implementar este problema en Excel, se debe primero enfrentar el problema de establecer la raíz en la formulación anterior [ecuación (15.7)]. Un método podría ser desarrollar un macro para implementar un método de localización de raíces, tal como el de la bisección o de la secante. (Advierta que se ilustrará cómo realizar esto en el próximo capítulo, en la sección 16.3.)

Mientras tanto, un procedimiento más fácil es posible mediante el desarrollo de la siguiente solución por iteración por punto fijo en la ecuación (15.7),

$$t_{i+1} = \left[500 + \frac{9.8m^2}{c^2}(1 - e^{-(c/m)t_i}) \right] \frac{c}{9.8m} \quad (15.8)$$

Así, t se puede ajustar hasta que se satisfaga la ecuación (15.8). Se puede demostrar que para el rango de parámetros usados en este problema, la fórmula siempre converge.

Ahora, ¿cómo se puede resolver esta ecuación en una hoja de cálculo? Como se muestra abajo, se puede fijar dos celdas de manera que tengan un valor para t y para el lado derecho de la ecuación (15.8) [es decir, $f(t)$]. Se puede teclear la ecuación (15.8) en la celda B21 de tal forma que tome su valor tiempo de la celda B20 y los otros valores de los parámetros de celdas de cualquier otro lugar de la hoja (véase a continuación cómo se construye toda la hoja). Después colóquese en la celda B20 y apunte su valor a la celda B21.

	A	B
20	t	0
21	$f(t)$	0.480856

$$= \left[500 + \frac{9.8m^2}{c^2}(1 - e^{-(c/m)t}) \right] \frac{c}{9.8m}$$

Una vez que se introducen estas fórmulas, se desplegará en forma inmediata el mensaje de error: "no se puede resolver referencias circulares", ya que B20 depende de B21 y viceversa. Ahora, vaya a las selecciones Tools/Options del menú y seleccione calculation

(cálculo). Del recuadro de diálogo calculation, verifique que aparezca "iteración" y presione "OK". En forma inmediata la hoja de cálculo iterará estas celdas y el resultado aparecerá como

	A	B
20	1	10.2551
21	f(i)	10.25595

Así, las celdas convergerán sobre la raíz. Si se quiere tener más precisión, sólo presione la tecla F9 para que se realicen más iteraciones (el default es 100 iteraciones, que se pueden cambiar si se desea).

En la figura 15.7 se muestra cómo establecer una hoja de cálculo en Excel para calcular los valores pertinentes. Las celdas no sombreadas son las que contienen los datos numéricos y las leyendas. Las celdas sombreadas involucran cantidades que se calculan con base en las otras celdas. Por ejemplo, la masa en B17 se calculó con la ecuación (15.6) con base en los valores de M_i (B4) y n (E5). Observe también que algunas celdas son redundantes. Por ejemplo, la celda E11 se direcciona a la celda E5. Esta repetición en la celda E11 muestra que la estructura de las restricciones es evidente en la hoja. Finalmente, note que la celda que habrá de minimizarse es E15, que contiene el costo total. Las celdas a cambiar son E4:E5, en las cuales se tiene el radio y el número de paracaídas.

FIGURA 15.7

Acondicionamiento de una hoja de cálculo en Excel para el problema de optimización no lineal referente al paracaídas.

	A	B	C	D	E	F	G
1	Problema de optimización del paracaídas						
2							
3	Parámetros:			Variables de diseño:			
4	M_i	2000		r	1		
5	g	9.8		n	1		
6	cost1	200					
7	cost2	56		Restricciones:			
8	cost3	0.1					
9	v_c	20		variables		tipo	limite
10	k_c	3		v	95.87867	<=	
11	z_0	500		n	1	>=	1
12							
13	Valores calculados:			Función objetivo:			
14	A	6.283185					
15	I	1.414214		Costo	283.1438		
16	c	18.84956					
17	m	2000					
18							
19	Raíz: localización:						
20	1						
21	f(i)						

Una vez que se ha creado la hoja de cálculo, se elige la selección Solver del menú Tools. En esta etapa se desplegará un recuadro de diálogo, requiriendo la información pertinente. Las celdas pertinentes en el recuadro de diálogo Solver se podrían llenar como

Ubique la celda dentro:	E5
Igual a	☐ máx ☒ mín ☐ igual a
Al cambiar celdas	0
E4:E5	
Sujeto a:	
E10<=G10	
E11<=G11	
E5=entero	

Se debe agregar las restricciones una por una al seleccionar el botón "Add". Esto abrirá un recuadro de diálogo como el siguiente

Celda de referencia:

Restricción

E10

<=

G10

FIGURA 15.8

Hoja de cálculo en Excel con la solución del problema de optimización no lineal referente al paracaídas.

	A	B	C	D	E	F	G
1	Problema de optimización del paracaídas						
2							
3	Parámetros:			Variables de diseño:			
4	Mt	2000		r	2.943651		
5	g	9.8		n	6		
6	cost1	200					
7	cost2	56		Restricciones:			
8	cost3	0.1					
9	vc	20		variables		tipo	limite
10	kc	3		v	20.00001	<=	20
11	z0	500		n	6	>=	1
12							
13	Valores calculados:			Función objetivo:			
14	A	54.44432					
15	l	4.162952		Costo	4377.262		
16	c	163.333					
17	m	333.3333					
18							
19	Raíz: localización:						
20	l	27.04076					
21	lu	27.04076					

Como se muestra, la restricción en la que la velocidad real del impacto (celda E10) debe ser menor o igual a la velocidad requerida (G10), puede ser agregada como se hizo en el ejemplo. Después de agregar cada restricción se puede seleccionar el botón "Add". Observe que la flecha hacia abajo le permite escoger entre varios tipos de restricciones ($\leq$, $\geq$, $=$ y entero). Así, se puede forzar el número de paracaídas (E5) para que sea un entero.

Cuando se hayan introducido las tres restricciones, se selecciona el botón OK para regresar al recuadro de diálogo Solver. Cuando seleccione el botón OK se abrirá un recuadro de diálogo con un reporte sobre el éxito de la operación. Para el caso presente, el Solver obtiene la solución correcta como la que se muestra en la figura 15.8.

De esta forma, se determina que el costo mínimo de 4 377.26 ocurrirá si se reparte en seis paquetes con un radio del paracaídas de 2.944 m. Además de obtener la solución, el Solver también proporciona algunos reportes resumen útiles. Éstos serán explorados en las aplicaciones de la ingeniería que se describirán en la sección 16.2.

15.3.4 IMSL

IMSL tiene varias subrutinas en Fortran para optimización (véase tabla 15.1). El presente análisis se concentrará en la rutina UVMID. Esta rutina localiza el punto mínimo de una función suave para una sola variable mediante evaluaciones de la función y primeras derivadas.

UVMID es implementado por el siguiente enunciado CALL:

```
CALL UVMID (F, G, XGUESS, ERREL, GTOL, MAXFN, A, B, X, FX, GX)
```

donde F = FUNCIÓN suministrada por el usuario para calcular el valor de la función a ser minimizada. La forma es $F(X)$, donde X = punto en el cual se evalúa la función. (Entrada). X no debería ser cambiada por F, y F = valor de la función calculado en el punto X. (Salida)

G = FUNCIÓN suministrada por el usuario para calcular la derivada de la función, donde G = valor de la función calculada en el punto X. (Salida)

F y G se deben declarar como EXTERNAL en el programa de llamado

XGUESS = Un valor inicial del punto mínimo de F. (Entrada)

ERREL = Exactitud relativa requerida del valor final de X. (Entrada)

GTOL = Tolerancia derivativa usada para decidir si el punto actual es un mínimo. (Entrada)

MAXFN = Número máximo de ecuaciones permitido de la función. (Entrada)

A = Punto extremo inferior del intervalo en el cual se localiza el máximo. (Entrada)

B = Punto extremo superior del intervalo en el cual se localiza el máximo. (Entrada)

FX = Valor de la función en X. (Salida)

GX = Valor de la derivada en X. (Salida)

TABLA 15.1 Rutinas IMSL para optimización.

Categoría	Rutina	Capacidad
Minimización no restringida		
Función univariable	UVMIF UVMID UVMGS	Usando sólo valores de la función Utilizando valores de la función y de la primera derivada Función no suave
Función multivariable	UMINF UMING UMIDH UMIAH UMCGF UMCGG UMPOL	Usando gradiente por diferencias finitas Utilizando gradiente analítico Empleando Hessian por diferencias finitas Usando Hessian analítico Utilizando gradiente conjugado con gradiente por diferencias finitas Empleando gradiente conjugado con gradiente analítico Función no suave
Mínimos cuadrados no lineales	UNLSF UNLSJ	Utilizando Jacobiano por diferencias finitas Usando Jacobiano analítico
Minimización con límites simples	BCONF BCONG BCODH BCOAH BCPOL BCLSF BCLSJ	Usando gradiente por diferencias finitas Utilizando gradiente analítico Empleando Hessian por diferencias finitas Usando Hessian analítico Función no suave Mínimos cuadrados no lineales mediante Jacobiano por diferencias finitas Mínimos cuadrados no lineales mediante Jacobiano analítico
Minimización restringida lineal	DLPRS QPROG LCONF LCONG	Programación lineal densa Programación cuadrática Función objetivo general con gradiente por diferencias finitas Función objetivo general con gradiente analítico
Minimización restringida no lineal	NCONF NCONG	Usando gradiente por diferencias finitas Utilizando gradiente analítico
Rutinas de servicio	CDGRD FDGRD FDHES GDHES FDJAC CHGRD CHHES CHJAC GGUES	Gradiente por diferencias centrales Gradiente por diferencias hacia adelante Hessian por diferencias hacia adelante Hessian por diferencias hacia adelante mediante gradiente analítico Jacobiano por diferencias hacia adelante Verificación del gradiente proporcionado por el usuario Revisión del Hessian dado por el usuario Verificación del Jacobiano proporcionado por el usuario Puntos de inicio generados