

Siguiendo el procedimiento de la sección anterior, tomamos la derivada de la ecuación (17.18) con respecto de cada uno de los coeficientes desconocidos del polinomio, como en

$$\begin{aligned}\frac{\partial S_r}{\partial a_0} &= -2 \sum (y_i - a_0 - a_1 x_i - a_2 x_i^2) \\ \frac{\partial S_r}{\partial a_1} &= -2 \sum x_i (y_i - a_0 - a_1 x_i - a_2 x_i^2) \\ \frac{\partial S_r}{\partial a_2} &= -2 \sum x_i^2 (y_i - a_0 - a_1 x_i - a_2 x_i^2)\end{aligned}$$

Estas ecuaciones se pueden igualar a cero y reordenar para desarrollar el siguiente conjunto de ecuaciones normal:

$$\begin{aligned}(n)a_0 + \left(\sum x_i\right)a_1 + \left(\sum x_i^2\right)a_2 &= \sum y_i \\ \left(\sum x_i\right)a_0 + \left(\sum x_i^2\right)a_1 + \left(\sum x_i^3\right)a_2 &= \sum x_i y_i \\ \left(\sum x_i^2\right)a_0 + \left(\sum x_i^3\right)a_1 + \left(\sum x_i^4\right)a_2 &= \sum x_i^2 y_i\end{aligned}\quad (17.19)$$

donde todas las sumatorias son de $i = 1$ hasta n . Observe que las tres ecuaciones anteriores son lineales y tienen tres incógnitas: a_0 , a_1 y a_2 . Los coeficientes de las incógnitas se pueden evaluar de manera directa a partir de los datos observados.

Para este caso, vemos que el problema de determinar un polinomio por mínimos cuadrados de segundo orden es equivalente a resolver un sistema de tres ecuaciones lineales simultáneas. Las técnicas para resolver tales ecuaciones fueron analizadas en la parte tres.

El caso en dos dimensiones puede extenderse con facilidad a un polinomio de m -ésimo orden como

$$y = a_0 + a_1 x + a_2 x^2 + \cdots + a_m x^m + e$$

El análisis anterior se puede fácilmente extender a este caso más general. Así, podemos reconocer que la determinación de los coeficientes de un polinomio de m -ésimo orden es equivalente a resolver un sistema de $m + 1$ ecuaciones lineales simultáneas. Para este caso, el error estándar se formula como

$$s_{y/x} = \sqrt{\frac{S_r}{n - (m + 1)}} \quad (17.20)$$


Esta cantidad es dividida entre $n - (m + 1)$, ya que $(m + 1)$ coeficientes obtenidos de los datos ($a_0, a_1, \dots, a_m$) se usaron para calcular S_r ; así, hemos perdido $m + 1$ grados de libertad. Además del error estándar, un coeficiente de determinación puede ser calculado para una regresión de polinomios con la ecuación (17.10).

EJEMPLO 17.5 Regresión de polinomios

Enunciado del problema. Ajustar a un polinomio de segundo orden los datos en las dos primeras columnas de la tabla 17.4.

TABLA 17.4 Cálculos para un análisis de error del ajuste cuadrático por mínimos cuadrados.

x_i	y_i	$(y_i - \bar{y})^2$	$(y_i - a_0 - a_1x_i - a_2x_i^2)^2$
0	2.1	544.44	0.14332
1	7.7	314.47	1.00286
2	13.6	140.03	1.08158
3	27.2	3.12	0.80491
4	40.9	239.22	0.61951
5	61.1	1 272.11	0.09439
Σ	152.6	2 513.39	3.74657

**FIGURA 17.11**

Ajuste de un polinomio de segundo orden.

Solución. A partir de los datos dados,

$$\begin{aligned}
 m &= 2 & \sum x_i &= 15 & \sum x_i^4 &= 979 \\
 n &= 6 & \sum y_i &= 152.6 & \sum x_i y_i &= 585.6 \\
 \bar{x} &\approx 2.5 & \sum x_i^2 &= 55 & \sum x_i^2 y_i &= 2488.8 \\
 \bar{y} &= 25.433 & \sum x_i^3 &= 225 & &
 \end{aligned}$$

Por tanto, las ecuaciones lineales simultáneas son

$$\begin{bmatrix} 6 & 15 & 55 \\ 15 & 55 & 225 \\ 55 & 225 & 979 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 152.6 \\ 585.6 \\ 2488.8 \end{bmatrix}$$

Resolviendo estas ecuaciones con una técnica tal como la eliminación de Gauss se tiene $a_0 = 2.47857$, $a_1 = 2.35929$ y $a_2 = 1.86071$. Por tanto, la ecuación cuadrática por mínimos cuadrados para este caso es

$$y = 2.47857 + 2.35929x + 1.86071x^2$$

El error estándar del estimado con base en la regresión de polinomios es [véase ecuación (17.20)]

$$s_{y/x} = \sqrt{\frac{3.74657}{6-3}} = 1.12$$

El coeficiente de determinación es

$$r^2 = \frac{2513.39 - 3.74657}{2513.39} = 0.99851$$

y el coeficiente de correlación es $r = 0.99925$.

Estos resultados indican que el 99.851% de la incertidumbre original la resolvió el modelo. Este resultado soporta la conclusión de que la ecuación cuadrática representa un excelente ajuste, como es también evidente de la figura 17.11.

17.2.1 Algoritmo para regresión de polinomios

Un algoritmo para regresión de polinomios es expuesto en la figura 17.12. Observe que la principal tarea es la generación de los coeficientes de las ecuaciones normal [véase ecuación (17.19)]. (El pseudocódigo para el cumplimiento de esto se halla presente en la figura 17.13.) Entonces, las técnicas de la parte tres se pueden aplicar para resolver estas ecuaciones simultáneas para los coeficientes.

Un problema potencial asociado con la implementación de regresión de polinomios en la computadora es que las ecuaciones normales algunas veces están mal condicionadas. Esto es en particular cierto para versiones de orden superior. Para esos casos, los coeficientes calculados podrían ser altamente susceptibles al error de redondeo y, en consecuencia, los resultados pueden ser inexactos. Entre otras cosas, este problema se relaciona con la estructura de las ecuaciones normal y por el hecho de que para los polinomios de orden superior las ecuaciones normales pueden tener coeficientes muy grandes y muy pequeños. Esto se debe a los coeficientes y sumatorias de los datos elevados a potencias.

FIGURA 17.12

Algoritmo para la implementación de polinomios y regresión lineal múltiple.

- | |
|--|
| <p>Paso 1: Introduzca el orden del polinomio sujeto a ajuste, m.</p> <p>Paso 2: Integre el número de datos, n.</p> <p>Paso 3: Si $n < m + 1$, imprima un mensaje de error que indique que la regresión no es posible y termine el proceso. Si $n \geq m + 1$, continúe.</p> <p>Paso 4: Calcule los elementos de la ecuación normal en la forma de una matriz aumentada.</p> <p>Paso 5: Resuelva la matriz aumentada para los coeficientes $a_0, a_1, a_2, \dots, a_m$, por medio de un método de eliminación.</p> <p>Paso 6: Imprima los coeficientes.</p> |
|--|

```

DO i = 1, order + 1
  DO j = 1, i
    k = i + j - 2
    sum = 0
    DO l = 1, n
      sum = sum + xkl
    END DO
    aij = sum
    aji = sum
  END DO
  sum = 0
  DO l = 1, n
    sum = sum + yl · xli-1
  END DO
  ai, order + 2 = sum
END DO

```

FIGURA 17.13

Pseudocódigo para ensamblar los elementos de las ecuaciones normal para regresión de polinomios.

Aunque las estrategias para disminuir el error de redondeo analizado en la parte tres, tal como el pivoteo, pueden ayudar a remediar en forma parcial este problema, una alternativa más simple es usar una computadora con más alta precisión. Por fortuna, la mayoría de los problemas prácticos están limitados a polinomios de orden inferior para los cuales el error de redondeo es insignificante. En situaciones donde se requieren versiones de orden superior, se dispone de otras alternativas para ciertos tipos de datos. Sin embargo, esas técnicas (tal como polinomios ortogonales) están más allá del alcance de este libro. El lector debería consultar textos sobre regresión, como el de Draper y Smith (1981), para información adicional con respecto al problema y posibles alternativas.

EJEMPLO 17.6 Regresión de polinomios por medio de la computadora

Enunciado del problema. En el software de Métodos Numéricos TOOLKIT adjunto a este libro se tiene un programa de computadora de uso amigable para implementar la regresión de polinomios. Se puede usar este software para el ajuste de polinomios con los siguientes datos:

x	2	4	5	6	6	7	9	1	0.5	7.5
y	6	2	3	7	8	8	1	5	3	7

Solución. Presione el ajuste de datos con el botón Curve sobre el menú principal del TOOLKIT para obtener una pantalla en blanco similar a la de la figura 17.14. Esta pantalla contiene espacios para la entrada y salida de información necesaria para ajustar los datos con un polinomio de regresión por mínimos cuadrados de m -ésimo orden.

El primer paso es presionar los valores de entrada X contra Y en la tabla e introducir hasta 100 pares de valores para X y Y. Después usted podría decidir graficar los datos

Resolviendo estas ecuaciones con una técnica tal como la eliminación de Gauss se tiene $a_0 = 2.47857$, $a_1 = 2.35929$ y $a_2 = 1.86071$. Por tanto, la ecuación cuadrática por mínimos cuadrados para este caso es

$$y = 2.47857 + 2.35929x + 1.86071x^2$$

El error estándar del estimado con base en la regresión de polinomios es [véase ecuación (17.20)]

$$s_{y/x} = \sqrt{\frac{3.74657}{6-3}} = 1.12$$

El coeficiente de determinación es

$$r^2 = \frac{2513.39 - 3.74657}{2513.39} = 0.99851$$

y el coeficiente de correlación es $r = 0.99925$.

Estos resultados indican que el 99.851% de la incertidumbre original la resolvió el modelo. Este resultado soporta la conclusión de que la ecuación cuadrática representa un excelente ajuste, como es también evidente de la figura 17.11.

17.2.1 Algoritmo para regresión de polinomios

Un algoritmo para regresión de polinomios es expuesto en la figura 17.12. Observe que la principal tarea es la generación de los coeficientes de las ecuaciones normal [véase ecuación (17.19)]. (El pseudocódigo para el cumplimiento de esto se halla presente en la figura 17.13.) Entonces, las técnicas de la parte tres se pueden aplicar para resolver estas ecuaciones simultáneas para los coeficientes.

Un problema potencial asociado con la implementación de regresión de polinomios en la computadora es que las ecuaciones normales algunas veces están mal condicionadas. Esto es en particular cierto para versiones de orden superior. Para esos casos, los coeficientes calculados podrían ser altamente susceptibles al error de redondeo y, en consecuencia, los resultados pueden ser inexactos. Entre otras cosas, este problema se relaciona con la estructura de las ecuaciones normal y por el hecho de que para los polinomios de orden superior las ecuaciones normales pueden tener coeficientes muy grandes y muy pequeños. Esto se debe a los coeficientes y sumatorias de los datos elevados a potencias.

FIGURA 17.12

Algoritmo para la implementación de polinomios y regresión lineal múltiple.

- Paso 1:** Introduzca el orden del polinomio sujeto a ajuste, m .
- Paso 2:** Integre el número de datos, n .
- Paso 3:** Si $n < m + 1$, imprima un mensaje de error que indique que la regresión no es posible y termine el proceso. Si $n \geq m + 1$, continúe.
- Paso 4:** Calcule los elementos de la ecuación normal en la forma de una matriz aumentada.
- Paso 5:** Resuelva la matriz aumentada para los coeficientes $a_0, a_1, a_2, \dots, a_m$, por medio de un método de eliminación.
- Paso 6:** Imprima los coeficientes.

```

DO i = 1, order + 1
  DO j = 1, i
    k = i + j - 2
    sum = 0
    DO l = 1, n
      sum = sum + xkl
    END DO
    aij = sum
    aji = sum
  END DO
  sum = 0
  DO l = 1, n
    sum = sum + yl · xli-1
  END DO
  ai, order + 2 = sum
END DO

```

FIGURA 17.13

Pseudocódigo para ensamblar los elementos de las ecuaciones normal para regresión de polinomios.

Aunque las estrategias para disminuir el error de redondeo analizado en la parte tres, tal como el pivoteo, pueden ayudar a remediar en forma parcial este problema, una alternativa más simple es usar una computadora con más alta precisión. Por fortuna, la mayoría de los problemas prácticos están limitados a polinomios de orden inferior para los cuales el error de redondeo es insignificante. En situaciones donde se requieren versiones de orden superior, se dispone de otras alternativas para ciertos tipos de datos. Sin embargo, esas técnicas (tal como polinomios ortogonales) están más allá del alcance de este libro. El lector debería consultar textos sobre regresión, como el de Draper y Smith (1981), para información adicional con respecto al problema y posibles alternativas.

EJEMPLO 17.6 Regresión de polinomios por medio de la computadora

Enunciado del problema. En el software de Métodos Numéricos TOOLKIT adjunto a este libro se tiene un programa de computadora de uso amigable para implementar la regresión de polinomios. Se puede usar este software para el ajuste de polinomios con los siguientes datos:

x	2	4	5	6	6	7	9	1	0.5	7.5
y	6	2	3	7	8	8	1	5	3	7


Solución. Presione el ajuste de datos con el botón Curve sobre el menú principal del TOOLKIT para obtener una pantalla en blanco similar a la de la figura 17.14. Esta pantalla contiene espacios para la entrada y salida de información necesaria para ajustar los datos con un polinomio de regresión por mínimos cuadrados de m -ésimo orden.

El primer paso es presionar los valores de entrada X contra Y en la tabla e introducir hasta 100 pares de valores para X y Y. Después usted podría decidir graficar los datos


solos antes de realizar decisiones con respecto al orden del polinomio. Esto se hace mediante un procedimiento similar al descrito en el ejemplo 2.1. La inspección de los datos muestra dos picos y sugiere que un polinomio de al menos cuarto orden sería el adecuado. Para nuestro ejemplo, primero intentaremos un polinomio de quinto orden. Simplemente introduzca un valor de 5 para el orden del polinomio y grafique los parámetros en el cuadro Entrada de parámetros y haga clic en los botones de red Calc y Plot (en el proceso cambian los botones a un color negro) para producir la figura 17.14. La forma para determinar el mejor orden se puede explorar al examinar cómo el error estándar varía como una función del orden de regresión. Los resultados para varios órdenes de regresión en el ajuste se tabula en la siguiente página:

FIGURA 17.14

Pantalla del TOOLKIT de métodos numéricos para una regresión polinomial de quinto orden.

**FIGURA 17.15**

Gráfica de una regresión polinomial de octavo orden.



Orden	1	2	3	4	5	6	7	8
Error estándar	2.71	2.69	2.34	1.38	1.00	1.12	1.17	1.15

Observe que el error estándar cae de manera dramática del orden 3 al 4 y alcanza un mínimo para el polinomio de orden 5. Esto sugiere que no se ha ganado mucho al gastar en esfuerzo de cómputo para ejecutar la regresión más alta que la de quinto orden.

La figura 17.15 muestra las gráficas para el caso de un octavo orden. Para este caso, los puntos extremo empiezan a ser un problema en una manera similar a la de la interpolación de orden superior (analizaremos este fenómeno con más detalle en el próximo capítulo). La figura 17.15 muestra que el polinomio de octavo orden produce valores de Y negativos para valores de X entre 8 y 9. Observe también en las figuras 17.14 y 17.15 que mientras las curvas de regresión siguen la tendencia de los datos, es altamente inapropiado extrapolar los valores Y más allá del rango de los datos para X .

La interpolación se puede ejecutar al introducir un valor en la tabla para X en el Calc Y para una X introducida. Por ejemplo, en $X = 3$, $Y = 2.304472$ como calculada con el polinomio de quinto orden (véase la figura 17.14).

Por último, demos un vistazo a la tabla de resultados en la parte derecha inferior. Los primeros tres resultados son resúmenes estadísticos de la regresión: error estándar, coeficiente de determinación y coeficiente de correlación. Observe cómo esos valores cambian para diferentes órdenes de regresión. La barra de despliegue sobre la tabla de resultados se usa para observar los coeficientes reales de la regresión de polinomios. De nuevo, esos valores cambian con diferentes órdenes.

17.3 REGRESIÓN LINEAL MÚLTIPLE

Una extensión útil de la regresión lineal es el caso donde y es una función lineal de dos o más variables independientes. Por ejemplo, y podría ser una función lineal de x_1 y x_2 , como en

$$y = a_0 + a_1x_1 + a_2x_2 + e$$

Tal ecuación es en particular útil cuando se ajustan datos experimentales donde la variable sujeta a estudio es a menudo una función de otras dos variables. Para este caso en dos dimensiones, la "línea" de regresión pasa a ser un "plano" (véase la figura 17.16).

Como en los casos anteriores, los "mejores" valores de los coeficientes son determinados al realizar la suma de los cuadrados de los residuos,

$$S_r = \sum_{i=1}^n (y_i - a_0 - a_1x_{1i} - a_2x_{2i})^2 \quad (17.21)$$

y diferenciando con respecto a cada uno de los coeficientes desconocidos,

$$\begin{aligned} \frac{\partial S_r}{\partial a_0} &= -2 \sum (y_i - a_0 - a_1x_{1i} - a_2x_{2i}) \\ \frac{\partial S_r}{\partial a_1} &= -2 \sum x_{1i} (y_i - a_0 - a_1x_{1i} - a_2x_{2i}) \end{aligned}$$


**FIGURA 17.16**

Ilustración gráfica de regresión lineal múltiple donde y es una función lineal de x_1 y x_2 .

$$\frac{\partial S_r}{\partial a_2} = -2 \sum x_{2i} (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i})$$

Los coeficientes dan la suma mínima de los cuadrados de los residuos y se obtienen al igual las derivadas parciales a cero y expresando el resultado en forma de matriz como

$$\begin{bmatrix} n & \sum x_{1i} & \sum x_{2i} \\ \sum x_{1i} & \sum x_{1i}^2 & \sum x_{1i} x_{2i} \\ \sum x_{2i} & \sum x_{1i} x_{2i} & \sum x_{2i}^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_{1i} y_i \\ \sum x_{2i} y_i \end{bmatrix} \quad (17.22)$$

EJEMPLO 17.7 Regresión lineal múltiple

Enunciado del problema. Los siguientes datos se calcularon con la ecuación $y = 5 + 4x_1 - 3x_2$:

x_1	x_2	y
0	0	5
2	1	10
2.5	2	9
1	3	0
4	6	3
7	2	27

Use regresión lineal múltiple para ajustar estos datos.

Solución. Las sumatorias requeridas para desarrollar la ecuación (17.22) se calculan en la tabla 17.5. El resultado es

$$\begin{bmatrix} 6 & 16.5 & 14 \\ 16.5 & 76.25 & 48 \\ 14 & 48 & 54 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} = \begin{Bmatrix} 54 \\ 243.5 \\ 100 \end{Bmatrix}$$

la cual se puede resolver mediante un método como el de eliminación de Gauss para

$$a_0 = 5 \quad a_1 = 4 \quad a_2 = -3$$

que es consistente con la ecuación original a partir de la cual los datos se derivaron.

TABLA 17.5 Cálculos requeridos para desarrollar las ecuaciones normal para el ejemplo 17.7.

y	x_1	x_2	x_1^2	x_2^2	x_1x_2	x_1y	x_2y
5	0	0	0	0	0	0	0
10	2	1	4	1	2	20	10
9	2.5	2	6.25	4	5	22.5	18
0	1	3	1	9	3	0	0
3	4	6	16	36	24	12	18
27	7	2	49	4	14	189	54
Σ	54	16.5	76.25	54	48	243.5	100

El caso anterior en dos dimensiones se puede fácilmente extender a m dimensiones, como en

$$y = a_0 + a_1x_1 + a_2x_2 + \cdots + a_mx_m + e$$

donde el error estándar se formula como

$$s_{y/x} = \sqrt{\frac{S_r}{n - (m + 1)}}$$

y el coeficiente de determinación se calcula como en la ecuación (17.10). En la figura 17.17 se enlista un algoritmo para preparar las ecuaciones normal.

Aunque hay ciertos casos donde una variable está linealmente relacionada con otras dos o más variables, la regresión múltiple tiene utilidad adicional en la derivación de ecuaciones de potencias de la forma general

$$y = a_0x_1^{a_1}x_2^{a_2}\cdots x_m^{a_m}$$

Tales ecuaciones son extremadamente útiles cuando se ajustan datos experimentales. Para usar regresión lineal múltiple, la ecuación se transforma al tomar su logaritmo para obtener

$$\log y = \log a_0 + a_1 \log x_1 + a_2 \log x_2 + \cdots + a_m \log x_m$$

```

DO i = 1, order + 1
  DO j = 1, i
    sum = 0
    DO l = 1, n
      sum = sum + xi-1,l · xj-1,l
    END DO
    aij = sum
    aji = sum
  END DO
  sum = 0
  DO l = 1, n
    sum = sum + yl · xi-1,l
  END DO
  ai, order+2 = sum
END DO

```

FIGURA 17.17

Pseudocódigo para ensamblar los elementos de las ecuaciones normal para regresión múltiple. Observe que además de guardar las variables independientes en $x_{1,i}$, $x_{2,i}$, etcétera, los 1 se deben guardar en $x_{0,i}$ para trabajar este algoritmo.

Esta transformación es similar en esencia a la que se usó en la sección 17.1.5 y en el ejemplo 17.4 para ajustar a una ecuación por potencias cuando y fue una función de una sola variable x . La sección 20.4 proporciona un ejemplo de tal aplicación para dos variables independientes.

17.4 FORMA GENERAL LINEAL POR MÍNIMOS CUADRADOS

Hasta este punto nos hemos concentrado en la mecánica de obtención de ajustes por mínimos cuadrados para algunas funciones simples con datos. Antes de cambiar a regresión no lineal, hay varios puntos que nos gustaría analizar para enriquecer nuestra comprensión del material precedente.

17.4.1 Formulación general de una matriz para mínimos cuadrados lineales

En páginas anteriores hemos introducido tres tipos de regresión: lineal simple, polinomial y lineal múltiple. De hecho, estas tres pertenecen al siguiente modelo general de mínimos cuadrados lineales:

$$y = a_0 z_0 + a_1 z_1 + a_2 z_2 + \cdots + a_m z_m + e \quad (17.23)$$

donde $z_0, z_1, \dots, z_m$ son las $m + 1$ funciones diferentes. Se puede ver con facilidad cómo la regresión lineal simple y múltiple encajan dentro de este modelo; es decir $z_0 = 1, z_1 = x_1, z_2 = x_2, \dots, z_m = x_m$. Además, la regresión de polinomios se incluye también si las z son monomios simples como en $z_0 = x^0 = 1, z_1 = x, z_2 = x^2, \dots, z_m = x^m$.

Observe que la terminología "lineal" se refiere sólo a la dependencia del modelo sobre sus parámetros (es decir, las a). Como en el caso de regresión de polinomios, las mismas funciones pueden ser altamente no lineales. Por ejemplo, las z pueden ser sinusoidales, como en

$$y = a_0 + a_1 \cos(\omega t) + a_2 \sin(\omega t)$$

Tal formato es la base del análisis de Fourier descrito en el capítulo 19.

Por otro lado, un modelo de apariencia simple como

$$f(x) = a_0 (1 - e^{-a_1 x})$$

es ciertamente no lineal porque no puede ser manejado en el formato de la ecuación (17.23). Regresaremos a tales modelos al final de este capítulo.

Mientras tanto, la ecuación (17.23) se puede expresar en notación matricial como

$$\{Y\} = [Z]\{A\} + \{E\} \quad (17.24)$$

donde $[Z]$ es una matriz de los valores calculados de las funciones z en los valores medidos de las variables independientes,

$$[Z] = \begin{bmatrix} z_{01} & z_{11} & \cdots & z_{m1} \\ z_{02} & z_{12} & \cdots & z_{m2} \\ \vdots & \vdots & \ddots & \vdots \\ z_{0n} & z_{1n} & \cdots & z_{mn} \end{bmatrix}$$

donde m es número de variables en el modelo y n es el número de datos. Como $n \geq m + 1$, usted debería reconocer que la mayoría de las veces $[Z]$ no es una matriz cuadrada.

El vector columna $\{Y\}$ contiene los valores observados de la variable dependiente

$$\{Y\}^T = [y_1 \quad y_2 \quad \cdots \quad y_n]$$

El vector columna $\{A\}$ contiene los coeficientes desconocidos

$$\{A\}^T = [a_0 \quad a_1 \quad \cdots \quad a_m]$$

y el vector columna $\{E\}$ contiene los residuos

$$\{E\}^T = [e_1 \quad e_2 \quad \cdots \quad e_n]$$

Como se realizó a través de este capítulo, la suma de los cuadrados de los residuos para este modelo se pueden definir como

$$S_r = \sum_{i=1}^n \left(y_i - \sum_{j=0}^m a_j z_{ji} \right)^2$$

Esta cantidad se puede minimizar al tomar su derivada parcial con respecto a cada uno de los coeficientes y fijar los resultados de la ecuación igual a cero. La salida de este proceso son las ecuaciones normal que se pueden expresar brevemente en forma de matriz como

$$[Z]^T [Z] \{A\} = [Z]^T \{Y\} \quad (17.25)$$

Se puede demostrar que la ecuación (17.25) es, de hecho, equivalente a las ecuaciones normal desarrolladas antes para regresión lineal simple, polinomial y múltiple.

Nuestra principal motivación para las anteriores ha sido ilustrar la unión entre los tres procedimientos y mostrar cómo se pueden expresar de manera simple en la misma notación matricial. También acondiciona la etapa para la siguiente sección donde asimilaremos algo de conocimiento en las estrategias preferidas para resolver la ecuación (17.25). La notación matricial tendrá también relevancia cuando veamos regresión no lineal en la última sección de este capítulo.

17.4.2 Técnicas de solución

En los análisis anteriores en este capítulo hemos encubierto el tema de las técnicas numéricas específicas para resolver las ecuaciones normales. Ahora que hemos establecido la unión entre los diversos modelos, podemos explorar esta cuestión con mayor detalle.

Primero, debería quedar claro que Gauss-Seidel no puede usarse aquí debido a que las ecuaciones normal no son diagonalmente dominantes. De esta manera dejamos a un lado los métodos de eliminación. Para los actuales propósitos, podemos dividir esas técnicas en tres categorías: 1) métodos de descomposición *LU*, incluyendo eliminación de Gauss, 2) método de Cholesky y 3) procedimiento de inversión de matrices. Obviamente hay traslapes en esta clasificación. Por ejemplo, el método de Cholesky es, de hecho, una descomposición *LU*, y todos los procedimientos se pueden formular de tal forma que pueden generar la matriz inversa. Sin embargo, esta clasificación tiene su mérito en cada categoría y ofrece beneficios con respecto a la solución de las ecuaciones normales.

Descomposición *LU*. Si usted está interesado sólo en aplicar un ajuste por mínimos cuadrados para el caso donde se conoce de antemano el modelo adecuado, cualquiera de los procedimientos de descomposición *LU* descritos en el capítulo 9 son perfectamente aceptables. De hecho, se puede también emplear la formulación de una descomposición no *LU* de eliminación de Gauss. Ésta es una tarea de programación relativamente directa para incorporar cualquiera de estos procedimientos en un algoritmo de mínimos cuadrados lineales. De hecho, si se ha seguido un enfoque modular, esto es casi trivial.

Método de Cholesky. El algoritmo de descomposición de Cholesky tiene varias ventajas con respecto a la solución del problema general de regresión lineal. Primero, está expresamente diseñado para resolver matrices simétricas como las ecuaciones normal. De este modo, es rápido y requiere menos espacio de almacenamiento para resolver tales sistemas. Segundo, es idealmente adecuado para casos donde el orden del modelo [es decir, el valor de *m* en la ecuación (17.23)] no es conocido de antemano (véase Ralston y Rabinowitz, 1978). Un caso sujeto a tratamiento sería la regresión de polinomios. Para este caso, podríamos saber *a priori* si un polinomio lineal cuadrático, cúbico o de orden superior es el "mejor" modelo para describir nuestros datos. Debido tanto a la forma en la cual las ecuaciones normales se construyen como a la manera en la que procede el algoritmo de Cholesky (véase figura 11.3), podemos desarrollar en forma sucesiva modelos de orden superior de un modo en extremo eficiente. En cada paso podríamos examinar la suma residual del error de los cuadrados (¡y una gráfica!) para examinar si la inclusión de términos de orden superior mejoran de manera significativa el ajuste.

La situación análoga para regresión lineal múltiple ocurre cuando se agregan variables independientes, una a la vez, al modelo. Suponga que la variable dependiente de interés es una función de un número de variables independientes: por ejemplo, temperatura, contenido de humedad, presión, etcétera. Podríamos primero realizar una regresión lineal con la temperatura y calcular un error residual. En seguida se podría incluir el contenido de humedad para realizar una regresión múltiple de dos variables y ver si la variable adicional resulta en una mejora al ajuste. El método de Cholesky hace eficiente el proceso, ya que la descomposición del modelo lineal podría solamente ser añadido al incorporar una nueva variable.

Procedimiento de la matriz inversa. De la ecuación (PT3.6), recuerde que la matriz inversa se puede emplear para resolver la ecuación (17.25), como en

$$\{A\} = [Z]^T [Z]^{-1} \{[Z]^T \{Y\}\} \quad (17.26)$$

Cada uno de los métodos de eliminación se puede usar para determinar la inversa y, así, pueden ser usados para implementar la ecuación (17.26). Sin embargo, como aprendimos en la parte tres, éste es un enfoque ineficiente para resolver un conjunto de ecuaciones simultáneas. Así, si estuviéramos justamente interesados en resolver los coeficientes de regresión, es preferible utilizar la aproximación de descomposición LU sin inversión. No obstante desde una perspectiva estadística, hay un número de razones por las cuales podríamos estar interesados en obtener la inversa y examinar sus coeficientes. Esas razones se analizarán después.

17.4.3 Aspectos estadísticos de la teoría de mínimos cuadrados

En la sección PT5.2.1, revisamos un número de estadística descriptiva que puede usarse para describir una muestra. Aquéllas incluyen la media aritmética, la desviación estándar y la varianza.

Además de obtener una solución para los coeficientes de regresión, la formulación de la matriz de la ecuación (17.26) proporciona estimaciones de su estadística. Se puede demostrar (Draper y Smith, 1981) que la diagonal y los términos fuera de la diagonal de la matriz $[Z]^T [Z]^{-1}$ dan, respectivamente, las varianzas y las covarianzas¹ de las a . Si los elementos de la diagonal de $[Z]^T [Z]^{-1}$ son designados como z_{ii}^{-1} , entonces

$$\text{var } (a_{i-1}) = z_{ii}^{-1} s_{y/x}^2 \quad (17.27)$$

y

$$\text{cov } (a_{i-1}, a_j) = z_{i-1,j}^{-1} s_{y/x}^2 \quad (17.28)$$

Estas estadísticas poseen un número de aplicaciones importantes. Para nuestros actuales propósitos, ilustraremos cómo se pueden usar para desarrollar intervalos de confianza para el intercepto y la pendiente.

¹La covarianza es una estadística que mide la dependencia de una variable con otra. Así, $\text{cov}(x, y)$ indica la dependencia de x y y . Por ejemplo, $\text{cov}(x, y) = 0$ podría indicar que x y y son totalmente independientes.

Mediante un enfoque similar al visto en la sección PT5.2.3, se puede demostrar que los límites inferior y superior del intercepto se pueden formular como (véase Milton y Arnold 1995 para más detalles)

$$L = a_0 - t_{\alpha/2, n-2} s(a_0) \quad U = a_0 + t_{\alpha/2, n-2} s(a_0) \quad (17.29)$$

donde $s(a_j)$ = error estándar del coeficiente $a_j = \sqrt{\text{var}(a_j)}$. De manera similar, los límites inferior y superior de la pendiente se pueden formular como

$$L = a_1 - t_{\alpha/2, n-2} s(a_1) \quad U = a_1 + t_{\alpha/2, n-2} s(a_1) \quad (17.30)$$

El siguiente ejemplo ilustra cómo esos intervalos se pueden usar para hacer inferencias cuantitativas relacionadas con la regresión lineal.

EJEMPLO 17.8 Intervalos de confianza para regresión lineal

Enunciado del problema. En el ejemplo 17.3 usamos regresión para desarrollar la siguiente relación entre mediciones y predicciones del modelo:

$$y = -0.859 + 1.032x$$

donde y = predicciones del modelo y x = mediciones. Concluimos que había una buena concordancia entre los dos debido a que el intercepto fue aproximadamente igual a 0 y la pendiente, a 1. Recalculé la regresión pero ahora use la aproximación matricial para estimar los errores estándar de los parámetros. Después emplee esos errores para desarrollar los intervalos de confianza y úselos para hacer declaraciones probabilísticas con respecto a la bondad del ajuste.

Solución. Los datos se pueden escribir en un formato matricial para regresión lineal simple como:

$$[Z] = \begin{bmatrix} 1 & 10 \\ 1 & 16.3 \\ 1 & 23 \\ \vdots & \vdots \\ 1 & 50 \end{bmatrix} \quad \{Y\} = \begin{Bmatrix} 8.953 \\ 16.405 \\ 22.607 \\ \vdots \\ 49.988 \end{Bmatrix}$$

Se puede entonces usar la transposición y multiplicación de la matriz para generar las ecuaciones normal como

$$[Z]^T [Z] \{A\} = [Z]^T \{Y\}$$

$$\begin{bmatrix} 15 & 548.3 \\ 548.3 & 22191.21 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \end{Bmatrix} = \begin{Bmatrix} 552.741 \\ 22421.43 \end{Bmatrix}$$

La inversión de la matriz puede ser usada para obtener la pendiente e intercepto como

$$\{A\} = [Z]^T [Z]^{-1} [Z]^T \{Y\}$$

$$= \begin{bmatrix} 0.688414 & -0.01701 \\ -0.01701 & 0.000465 \end{bmatrix} \begin{Bmatrix} 552.741 \\ 22421.43 \end{Bmatrix} = \begin{Bmatrix} -0.85872 \\ 1.031592 \end{Bmatrix}$$

De esta manera, el intercepto y la pendiente se determinan como $a_0 = -0.85872$ y $a_1 = 1.031592$, respectivamente. Estos valores a su vez se pueden usar para calcular el error estándar del estimado como $s_{y/x} = 0.863403$. Este valor puede utilizarse junto con los elementos diagonal de la matriz inversa para calcular los errores estándar de los coeficientes,

$$s(a_0) = \sqrt{z_{11}^{-1} s_{y/x}^2} = \sqrt{0.688414(0.863403)^2} = 0.716372$$

$$s(a_1) = \sqrt{z_{22}^{-1} s_{y/x}^2} = \sqrt{0.000465(0.863403)^2} = 0.018625$$

La estadística, $t_{\alpha/2, n-1}$ necesaria para un 95% de intervalo de confianza con $n - 2 = 15 - 2 = 13$ grados de libertad puede ser determinada de una tabla estadística o mediante software. Usamos una función de Excel, TINV, para obtener el valor adecuado, como en

$$= \text{TINV}(0.05, 13)$$

la cual da un valor de 2.160368. Las ecuaciones (17.29) y (17.30) se pueden entonces usar para calcular los intervalos de confianza como

$$\begin{aligned} a_0 &= -0.85872 \pm 2.160368(0.716372) \\ &= -0.85872 \pm 1.547627 = [-2.40634, 0.688912] \end{aligned}$$

$$\begin{aligned} a_1 &= 1.031592 \pm 2.160368(0.018625) \\ &= 1.031592 \pm 0.040237 = [0.991355, 1.071828] \end{aligned}$$

Observe que los valores deseados (0 para el intercepto y pendiente, y 1 para el intercepto) están dentro de los intervalos. Sobre la base de este análisis podríamos hacer las siguientes declaraciones con respecto a la pendiente: tenemos fuertes fundamentos para pensar que la pendiente de la línea de regresión real está dentro del intervalo de 0.991355 a 1.071828. Debido a que 1 está dentro de este intervalo, tenemos también bases fuertes para creer que el resultado soporta la concordancia entre las mediciones y el modelo. Como cero está dentro del intervalo del intercepto, una declaración similar se puede hacer con respecto del intercepto.

Lo anterior es una introducción limitada al enriquecedor tema de la inferencia estadística y su relación con la regresión. Hay muchas más que están lejos del alcance de este libro. Nuestra principal intención ha sido mostrar el poder del enfoque matricial al ajuste general lineal por mínimos cuadrados. Usted debería consultar algunos de los excelentes libros sobre el tema (por ejemplo, Draper y Smith 1981) para información adicional. Además, debería observar qué paquetes de software y librerías pueden generar ajustes de regresión por mínimos cuadrados junto con información relevante para la estadística inferencial. Exploraremos algunas de esas capacidades cuando se describan esos paquetes al final del capítulo 19.

17.5 REGRESIÓN NO LINEAL

Hay muchos casos en ingeniería donde modelos no lineales deben ser ajustados con datos. En el contexto actual, esos modelos se definen como aquellos que tienen dependencia no lineal de sus parámetros. Por ejemplo,

$$f(x) = a_0 (1 - e^{-a_1 x}) + e \quad (17.31)$$

Esta ecuación no puede ser manejada de acuerdo con el formato general de la ecuación (17.23).

Como se hizo con los mínimos cuadrados lineales, la regresión no lineal se basa en la determinación de los valores de los parámetros que minimizan la suma de los cuadrados de los residuos. Sin embargo, para el caso no lineal, la solución debe proceder en una forma iterativa.

El *método de Gauss-Newton* es un algoritmo para minimizar la suma de los cuadrados de los residuos entre datos y ecuaciones no lineales. El concepto clave que resalta la técnica es que una expansión por serie de Taylor se usa para expresar la ecuación no lineal original en una forma lineal aproximada. Entonces, la teoría de mínimos cuadrados se puede usar para obtener nuevas estimaciones de los parámetros que se mueven en la dirección de minimizar el residuo.

Para ilustrar cómo se hace esto, primero se puede expresar de manera general la relación entre la ecuación no lineal y los datos como

$$y_i = f(x_i; a_0, a_1, \dots, a_m) + e_i$$

donde y_i = valor medido de la variable dependiente, $f(x_i; a_0, a_1, \dots, a_m)$ = ecuación que es una función de la variable independiente x_i y una función no lineal de los parámetros $a_0, a_1, \dots, a_m$, y e_i = error aleatorio. Por conveniencia, este modelo se puede expresar de forma abreviada al omitir los parámetros,

$$y_i = f(x_i) + e_i \quad (17.32)$$

El modelo no lineal puede ser expandido dentro de una serie de Taylor alrededor de valores de parámetro y reducido después de las primeras derivadas. Por ejemplo, para un caso de dos parámetros

$$f(x_i)_{j+1} = f(x_i)_j + \frac{\partial f(x_i)_j}{\partial a_0} \Delta a_0 + \frac{\partial f(x_i)_j}{\partial a_1} \Delta a_1 \quad (17.33)$$

donde j = son los valores iniciales, $j + 1$ = predicción, $\Delta a_0 = a_{0,j+1} - a_{0,j}$, y $\Delta a_1 = a_{1,j+1} - a_{1,j}$. De esta forma, hemos linearizado el modelo original con respecto a los parámetros. La ecuación (17.33) se puede sustituir en la (17.32) para obtener

$$y_i - f(x_i)_j = \frac{\partial f(x_i)_j}{\partial a_0} \Delta a_0 + \frac{\partial f(x_i)_j}{\partial a_1} \Delta a_1 + e_i$$

o en forma matricial [compárela con la ecuación (17.24)],

$$\{D\} = [Z_j] \{\Delta A\} + \{E\} \quad (17.34)$$

donde $[Z_j]$ es la matriz de las derivadas parciales de la función evaluada en el valor inicial j ,

$$[Z_j] = \begin{bmatrix} \partial f_1 / \partial a_0 & \partial f_1 / \partial a_1 \\ \partial f_2 / \partial a_0 & \partial f_2 / \partial a_1 \\ \vdots & \vdots \\ \partial f_n / \partial a_0 & \partial f_n / \partial a_1 \end{bmatrix}$$

donde n = número de datos y $\partial f_i / \partial a_k$ = derivada parcial de la función con respecto al k -ésimo parámetro evaluado en el i -ésimo punto. El vector $\{D\}$ contiene las diferencias entre las mediciones y los valores de la función,

$$\{D\} = \begin{Bmatrix} y_1 - f(x_1) \\ y_2 - f(x_2) \\ \vdots \\ y_n - f(x_n) \end{Bmatrix}$$

y el vector $\{\Delta A\}$ contiene los cambios en los valores de los parámetros,

$$\{\Delta A\} = \begin{Bmatrix} \Delta a_0 \\ \Delta a_1 \\ \vdots \\ \Delta a_m \end{Bmatrix}$$

Si se aplica la teoría de mínimos cuadrados lineales a la ecuación (17.34) resulta en las siguientes ecuaciones normal [recuerde la ecuación (17.25)]:

$$[Z_j]^T [Z_j] \{\Delta A\} = [Z_j]^T \{D\} \quad (17.35)$$

Así, el procedimiento consiste en resolver la ecuación (17.35) para $\{\Delta A\}$, la cual se puede emplear para calcular valores mejorados para los parámetros, como en

$$a_{0,j+1} = a_{0,j} + \Delta a_0$$

y

$$a_{1,j+1} = a_{1,j} + \Delta a_1$$

Este procedimiento se repite hasta que la solución converge (es decir, hasta)

$$|\varepsilon_a|_k = \left| \frac{a_{k,j+1} - a_{k,j}}{a_{k,j+1}} \right| 100\% \quad (17.36)$$

está por debajo de un criterio de paro aceptable.

EJEMPLO 17.9 Método de Gauss-Newton

Enunciado del problema. Ajuste la función $f(x; a_0, a_1) = a_0(1 - e^{-a_1 x})$ con los datos:

x	0.25	0.75	1.25	1.75	2.25
y	0.28	0.57	0.68	0.74	0.79

Use los valores iniciales de $a_0 = 1.0$ y $a_1 = 1.0$ para los parámetros. Observe que para estos valores la suma inicial de los cuadrados de los residuos es 0.0248.

Solución. Las derivadas parciales de la función con respecto a los parámetros son

$$\frac{\partial f}{\partial a_0} = 1 - e^{-a_1 x} \quad (\text{E17.9.1})$$

y

$$\frac{\partial f}{\partial a_1} = a_0 x e^{-a_1 x} \quad (\text{E17.9.2})$$

Las ecuaciones (E17.9.1) y (E17.9.2) se pueden usar para evaluar la matriz

$$[Z_0] = \begin{bmatrix} 0.2212 & 0.1947 \\ 0.5276 & 0.3543 \\ 0.7135 & 0.3581 \\ 0.8262 & 0.3041 \\ 0.8946 & 0.2371 \end{bmatrix}$$

Esta matriz multiplicada por su traspuesta resulta en

$$[Z_0]^T [Z_0] = \begin{bmatrix} 2.3193 & 0.9489 \\ 0.9489 & 0.4404 \end{bmatrix}$$

la cual de nuevo se puede invertir para dar

$$[Z_0]^T [Z_0]^{-1} = \begin{bmatrix} 3.6397 & -7.8421 \\ -7.8421 & 19.1678 \end{bmatrix}$$

El vector $\{D\}$ consiste en las diferencias entre las mediciones y las predicciones del modelo,

$$\{D\} = \begin{bmatrix} 0.28 - 0.2212 \\ 0.57 - 0.5276 \\ 0.68 - 0.7135 \\ 0.74 - 0.8262 \\ 0.79 - 0.8946 \end{bmatrix} = \begin{bmatrix} 0.0588 \\ 0.0424 \\ -0.0335 \\ -0.0862 \\ -0.1046 \end{bmatrix}$$

Ésta es multiplicada por $[Z_0]^T$ para obtener

$$[Z_0]^T \{D\} = \begin{bmatrix} -0.1533 \\ -0.0365 \end{bmatrix}$$

El vector $\{\Delta A\}$ es entonces calculado al resolver la ecuación (17.35) para

$$\Delta A = \begin{Bmatrix} -0.2714 \\ 0.5019 \end{Bmatrix}$$

la cual puede ser agregada al parámetro inicial supuesto para dar

$$\begin{Bmatrix} a_0 \\ a_1 \end{Bmatrix} = \begin{Bmatrix} 1.0 \\ 1.0 \end{Bmatrix} + \begin{Bmatrix} -0.2714 \\ 0.5019 \end{Bmatrix} = \begin{Bmatrix} 0.7286 \\ 1.5019 \end{Bmatrix}$$

Así, las estimaciones mejoradas de los parámetros son $a_0 = 0.7286$ y $a_1 = 1.5019$. Los nuevos parámetros resultan en una suma de los cuadrados de los residuos igual a 0.0242. La ecuación (17.36) se puede usar para calcular ϵ_0 y ϵ_1 igual a 37 y 33%, respectivamente. El cálculo podría repetirse hasta que esos valores estén abajo del criterio de paro preescrito. El resultado final es $a_0 = 0.79186$ y $a_1 = 1.6751$. Estos coeficientes dan una suma de los cuadrados de los residuos de 0.000662.

Un problema potencial con el método de Gauss-Newton como se ha desarrollado hasta ahora es que las derivadas parciales de la función pueden ser difíciles de evaluar. En consecuencia, muchos programas de computadora usan diferentes ecuaciones para aproximar las derivadas parciales. Un método es

$$\frac{\partial f_i}{\partial a_k} \approx \frac{f(x_i; a_0, \dots, a_k + \delta a_k, \dots, a_m) - f(x_i; a_0, \dots, a_k, \dots, a_m)}{\delta a_k} \quad (17.37)$$

donde δ = perturbación fraccional pequeña.

El método de Gauss-Newton tiene una variedad de otros posibles defectos:

1. Puede converger con lentitud.
2. Puede oscilar ampliamente; es decir, cambia en forma continua de dirección.
3. Puede no converger.

Se han desarrollado modificaciones del método (Booth y Peterson, 1958; Hartley, 1961) para remediar los defectos.

Además, aunque hay varios procedimientos expresamente diseñados para regresión, uno más general es usar rutinas de optimización no lineal como las descritas en la parte cuatro. Para hacer esto, se hace una suposición de los parámetros, y se calcula la suma de los cuadrados de los residuos. Por ejemplo, para la ecuación (17.31) esto se podría calcular como

$$S_r = \sum_{i=1}^n [y_i - a_0(1 - e^{-a_1 x_i})]^2 \quad (17.38)$$

Entonces, los parámetros se podrían ajustar de manera sistemática para minimizar S_r , mediante técnicas de búsqueda descritas previamente en el capítulo 14. Ilustraremos el modo para hacer esto cuando describamos las aplicaciones del software al final del capítulo 19.

PROBLEMAS

17.1 Dados los datos

0.90	1.42	1.30	1.55	1.63
1.32	1.35	1.47	1.95	1.66
1.96	1.47	1.92	1.35	1.05
1.85	1.74	1.65	1.78	1.71
2.29	1.82	2.06	2.14	1.27

determine a) la media, b) la desviación estándar, c) la varianza, d) el coeficiente de variación y e) el intervalo de confianza al 95% para la media.

17.2 Construya un histograma para los datos del problema 17.1. Use un rango de 0.6 a 2.4 con intervalos de 0.2.

17.3 Con los datos

15	6	18	21	26	28	32
39	22	28	24	27	27	33
2	12	17	34	29	31	38
45	36	41	37	43	38	26

determine a) la media, b) la desviación estándar, c) la varianza, d) el coeficiente de variación y e) el intervalo de confianza al 90% para la media. f) Construya un histograma. Use un rango de 0 a 55 con incrementos de 5. g) Suponga que la distribución es normal y que su estimación de la desviación estándar es válida, calcule el rango (esto es, los valores inferior y superior) que abarquen el 68% de las lecturas. Determine si esto es una estimación válida para los datos en este problema.

17.4 Use la regresión por mínimos cuadrados para ajustar a una línea recta a

x	1	3	5	7	10	12	13	16	18	20
y	4	5	6	5	8	7	6	9	12	11

Junto con la pendiente y el intercepto, calcule el error estándar del estimado y el coeficiente de correlación. Grafique los datos y la línea de regresión. Después repita el problema, pero ahora haga la regresión de x contra y (es decir, cambie las variables). Interprete sus resultados.

17.5 Use regresión por mínimos cuadrados para ajustar a una línea recta a

x	5	6	10	14	16	20	22	28	28	36	38
y	30	22	28	14	22	16	8	8	14	0	4

Junto con la pendiente y el intercepto, calcule el error estándar del estimado y el coeficiente de correlación. Grafique los datos y la línea de regresión. Si alguien hizo una medición adicional de $x = 5$, $y = 5$, ¿podría usted esperar, con base en un asegura-

miento visual y en el error estándar, que la medición fue válida o fallida? Justifique su conclusión.

17.6 Use regresión por mínimos cuadrados para ajustar a una línea recta a

x	2	3	4	7	8	9	5	5
y	9	6	5	10	9	11	2	3

a) Junto con la pendiente y el intercepto, calcule el error estándar de la estimación y el coeficiente de correlación. Grafique los datos y la línea recta. Valide el ajuste.

b) Recalcule a), pero ahora use regresión polinomial para ajustar los datos a una parábola. Compare los resultados con aquellos de a).

17.7 Ajuste un modelo de razón de crecimiento saturado con

x	0.75	2	2.5	4	6	8	8.5
y	0.8	1.3	1.2	1.6	1.7	1.8	1.7

Grafique los datos y la ecuación. Encuentre el error estándar.

17.8 Ajuste los datos del problema 17.7 a una ecuación de potencias. Grafique los datos y la ecuación y encuentre el error estándar.

17.9 Adecue los datos del problema 17.7 a una parábola. Grafique los datos y la ecuación y encuentre el error estándar.

17.10 Ajuste los siguientes datos a una ecuación de potencias

x	2.5	3.5	5	6	7.5	10	12.5	15	17.5	20
y	7	5.5	3.9	3.6	3.1	2.8	2.6	2.4	2.3	2.3

Grafique y contra x junto con la ecuación de potencias.

17.11 Adecue los siguientes datos a un modelo exponencial

x	0.4	0.8	1.2	1.6	2.0	2.3
y	750	1000	1400	2000	2700	3750

Grafique los datos y la ecuación en papel estándar así como en gráfico logarítmico. Analice sus resultados.

17.12 Ajuste los datos del problema 17.11 a una parábola. Grafique los datos y la ecuación.

17.13 Con los datos

x	5	10	15	20	25	30	35	40	45	50
y	16	25	32	33	38	36	39	40	42	42

use regresión por mínimos cuadrados para ajustar a) a una línea recta, b) a una ecuación de potencias, c) a una ecuación de razón de crecimiento saturado y d) a una parábola. Grafique los datos junto con todas las curvas. ¿Es superior alguna de las curvas? Si es así, justifique.

17.14 Use regresión lineal múltiple para ajustar

x_1	0	1	1	2	2	3	3	4	4
x_2	0	1	2	1	2	1	2	1	2
y	15	18	12.8	25.7	20.6	35.0	29.8	45.5	40.3

Calcule los coeficientes, el error estándar del estimado y el coeficiente de correlación.

17.15 Use regresión lineal múltiple para ajustar

x_1	0	0	1	2	0	1	2	2	1
x_2	0	2	2	4	4	6	6	2	1
y	15	19	12	11	24	22	15	5	19

Calcule los coeficientes, el error estándar del estimado y el coeficiente de correlación.

17.16 Use regresión no lineal para ajustar los siguientes datos a una parábola

x	0.075	0.5	1	1.2	1.7	2.0	2.3
y	600	800	1200	1400	2050	2650	3750

17.17 Use regresión no lineal para ajustar los datos del problema 17.13 a una ecuación de razón de crecimiento saturado.

17.18 Recalcule el ajuste por regresión de los problemas a) 17.4 y b) 17.13 mediante el procedimiento de la matriz. Estime los errores estándar y desarrolle intervalos de confianza al 90% para la pendiente y el intercepto.

17.19 Desarrolle, depure y pruebe un subprograma en ya sea un lenguaje de alto nivel o en lenguaje macro de su elección para implementar regresión lineal. Entre otras cosas: a) Agregue comentarios para documentar el código y b) determine el error estándar y el coeficiente de determinación.

17.20 Use el software de Métodos Numéricos TOOLKIT para resolver los problemas a) 17.4, b) 17.5, c) 17.6, d) 17.9 y e) 17.12.

CAPÍTULO 18

Interpolación

Usted a menudo habrá tenido la oportunidad de estimar valores intermedios entre datos precisos. El método más común que se usa para este propósito es la interpolación del polinomio. Recuerde que la fórmula general para un polinomio de n -ésimo orden es


$$f(x) = a_0 + a_1x + a_2x^2 + \cdots + a_nx^n \quad (18.1)$$

Para $n + 1$ puntos, hay uno y sólo un polinomio de orden n que pasa a través de todos los puntos. Por ejemplo, hay sólo una línea recta (es decir, un polinomio de primer orden) que conecta dos puntos (vea la figura 18.1a). De manera similar, únicamente una parábola conecta un conjunto de tres puntos (ver figura 18.1b). *Interpolación polinomial* consiste en determinar el único polinomio de n -ésimo orden que ajuste $n + 1$ puntos. Este polinomio entonces proporciona una fórmula para calcular valores intermedios.

Aunque hay uno y sólo un polinomio de n -ésimo orden que ajusta $n + 1$ puntos, existe una variedad de formatos matemáticos en los cuales este polinomio puede expresarse. En este capítulo describiremos dos alternativas que son muy adecuadas para la implementación en computadora: los polinomios de Newton y de Lagrange.

FIGURA 18.1

Ejemplos de interpolación polinomial: a) de primer orden (lineal) conectando dos puntos, b) de segundo orden (cuadrática o parabólica) enlazando tres puntos y c) de tercer orden (cúbica) conectando cuatro puntos.



18.1 DIFERENCIA DIVIDIDA DE NEWTON PARA LA INTERPOLACIÓN DE POLINOMIOS

Como se mencionó antes, existe una variedad de formas alternativas para expresar una interpolación de un polinomio. La *diferencia dividida de Newton para la interpolación de polinomios* está entre los modelos más populares y útiles. Antes de presentar la ecuación general, introduciremos la primera y segunda versión debido a su interpretación visual simple.

18.1.1 Interpolación lineal

El modo más simple de interpolación es conectar dos puntos con una línea recta. Esta técnica, llamada *interpolación lineal*, se ilustra en forma gráfica en la figura 18.2. Mediante triángulos semejantes,

$$\frac{f_1(x) - f(x_0)}{x - x_0} = \frac{f(x_1) - f(x_0)}{x_1 - x_0}$$


la cual se puede reordenar para dar

$$f_1(x) = f(x_0) + \frac{f(x_1) - f(x_0)}{x_1 - x_0} (x - x_0) \quad (18.2)$$

que es una *fórmula de interpolación lineal*. La notación $f_1(x)$ designa que es una interpolación de polinomios de primer orden. Observe que además de representar la

FIGURA 18.2

Ilustración gráfica de interpolación lineal. Las áreas sombreadas indican los triángulos semejantes usados para obtener la fórmula de interpolación lineal [véase la ecuación (18.2)]



pendiente de la línea que conecta los puntos, el término $[f(x_1) - f(x_0)]/(x_1 - x_0)$ es una aproximación por diferencia dividida finita de la primera derivada [recuerde la ecuación (4.17)]. En general, cuanto más pequeño sea el intervalo de datos, mejor será la aproximación. Esto se debe al hecho de que, en tanto el intervalo disminuya, una función continua se aproximará mejor por una línea recta. Esta característica se demuestra en el siguiente ejemplo.

EJEMPLO 18.1 Interpolación lineal

Enunciado del problema. Estime el logaritmo natural de 2 mediante interpolación lineal. Primero, realice el cálculo por interpolación entre $\ln 1 = 0$ y $\ln 6 = 1.791759$. Después, repita el procedimiento, pero use un intervalo más pequeño de $\ln 1$ a $\ln 4$ (1.386294). Observe que el valor real de $\ln 2$ es 0.6931472.

Solución. Usaremos la ecuación (18.2) y una interpolación lineal para $\ln(2)$ de $x_0 = 1$ a $x_1 = 6$ para dar

$$f_1(2) = 0 + \frac{1.791759 - 0}{6 - 1} (2 - 1) = 0.3583519$$


que representa un error de $\epsilon_t = 48.3\%$. Con el intervalo más pequeño de, $x_0 = 1$ a $x_1 = 4$ se obtiene

$$f_1(2) = 0 + \frac{1.386294 - 0}{4 - 1} (2 - 1) = 0.4620981$$

Así, con el intervalo más corto se reduce el error relativo porcentual a $\epsilon_t = 33.3\%$. Ambas interpolaciones se muestran en la figura 18.3, junto con la función real.

FIGURA 18.3

Dos interpolaciones lineales para estimar $\ln 2$. Observe cómo el intervalo más pequeño proporciona una mejor estimación.



18.1.2 Interpolación cuadrática

El error en el ejemplo 18.1 resulta de nuestra aproximación a una curva con una línea recta. Por consiguiente, una estrategia para mejorar la estimación es introducir alguna curvatura en la línea que conecta los puntos. Si tres puntos de los datos están disponibles, esto puede realizarse con un polinomio de segundo orden (también conocido como polinomio cuadrático o *parábola*). Una forma en particular conveniente para este propósito es

$$f_2(x) = b_0 + b_1(x - x_0) + b_2(x - x_0)(x - x_1) \quad (18.3)$$

Observe que aunque la ecuación (18.3) parecería diferir del polinomio general [véase ecuación (18.1)], las dos ecuaciones son equivalentes. Esto puede demostrarse al multiplicar los términos de la ecuación (18.3) para dar

$$f_2(x) = b_0 + b_1x - b_1x_0 + b_2x^2 + b_2x_0x_1 - b_2xx_0 - b_2xx_1$$

o, agrupando términos,

$$f_2(x) = a_0 + a_1x + a_2x^2$$

donde

$$a_0 = b_0 - b_1x_0 + b_2x_0x_1$$

$$a_1 = b_1 - b_2x_0 - b_2x_1$$

$$a_2 = b_2$$

Así, las ecuaciones (18.1) y (18.3) son formulaciones alternativas equivalentes del único polinomio de segundo orden que une los tres puntos.

Un procedimiento simple puede usarse para determinar los valores de los coeficientes. Para b_0 , la ecuación (18.3) con $x = x_0$ puede ser usada para calcular

$$b_0 = f(x_0) \quad (18.4)$$

La ecuación (18.4) puede sustituirse en la (18.3), la cual puede evaluarse en $x = x_1$ para

$$b_1 = \frac{f(x_1) - f(x_0)}{x_1 - x_0} \quad (18.5)$$

Por último, las ecuaciones (18.4) y (18.5) se pueden sustituir en la (18.3), la cual puede evaluarse en $x = x_2$ y resolver (después de algunas manipulaciones algebraicas) para

$$b_2 = \frac{\frac{f(x_2) - f(x_1)}{x_2 - x_1} - \frac{f(x_1) - f(x_0)}{x_1 - x_0}}{x_2 - x_0} \quad (18.6)$$

Note que, como fue el caso con la interpolación lineal, b_1 todavía representa la pendiente de la línea que une los puntos x_0 y x_1 . Así, los primeros dos términos de la ecuación (18.3) son equivalentes a la interpolación lineal de x_0 a x_1 , como se especificó antes en la ecuación (18.2). El último término, $b_2(x - x_0)(x - x_1)$, introduce la curvatura de segundo orden en la fórmula.

Antes de ilustrar cómo usar la ecuación (18.3), debemos examinar la forma del coeficiente b_2 . Es muy similar a la aproximación por diferencias divididas finitas de la segunda derivada que se introdujo antes en la ecuación (4.24). Así, la ecuación (18.3) comienza a manifestar una estructura que es muy similar a la serie de expansión de Taylor. Esta observación será objeto de más exploración cuando relacionemos los polinomios de interpolación de Newton con la serie de Taylor en la sección 18.1.4. Pero primero, desarrollaremos un ejemplo que muestra cómo se usa la ecuación (18.3) para interpolar entre tres puntos.

EJEMPLO 18.2 Interpolación cuadrática

Enunciado del problema. Ajuste los tres puntos usados en el ejemplo 18.1 a un polinomio de segundo orden:

$$\begin{aligned} x_0 &= 1 & f(x_0) &= 0 \\ x_1 &= 4 & f(x_1) &= 1.386294 \\ x_2 &= 6 & f(x_2) &= 1.791759 \end{aligned}$$

Use el polinomio para evaluar $\ln 2$.

Solución. Aplicando la ecuación (18.4) se obtiene


$$b_0 = 0$$

La ecuación (18.5) da

$$b_1 = \frac{1.386294 - 0}{4 - 1} = 0.4620981$$

FIGURA 18.4

Uso de interpolación cuadrática para estimar $\ln 2$. Para comparación se incluye también la interpolación lineal de $x = 1$ a 4.



y con la ecuación (18.6) se obtiene

$$b_2 = \frac{\frac{1.791759 - 1.386294}{6 - 4} - 0.4620981}{6 - 1} = -0.0518731$$

Sustituyendo estos valores en la ecuación (18.3) se obtiene la fórmula cuadrática

$$f_2(x) = 0 + 0.4620981(x - 1) - 0.0518731(x - 1)(x - 4)$$

que puede evaluarse en $x = 2$ para

$$f_2(2) = 0.5658444$$

la cual representa un error relativo de $\varepsilon_t = 18.4\%$. Así, la curvatura introducida por la fórmula cuadrática (véase la figura 18.4) mejora la interpolación comparada con el resultado que se obtiene mediante líneas rectas en el ejemplo 18.1 y figura 18.3.

18.1.3 Forma general de la interpolación de polinomios de Newton

El análisis anterior puede ser generalizado para ajustar un polinomio de n -ésimo orden a $n + 1$ datos. El polinomio de n -ésimo orden es

$$f_n(x) = b_0 + b_1(x - x_0) + \cdots + b_n(x - x_0)(x - x_1) \cdots (x - x_{n-1}) \quad (18.7)$$

Como se hizo antes con las interpolaciones lineales y cuadráticas, los puntos de los datos evaluaban los coeficientes $b_0, b_1, \dots, b_n$. Para un polinomio de n -ésimo orden se requiere $n + 1$ puntos: $[x_0, f(x_0)], [x_1, f(x_1)], \dots, [x_n, f(x_n)]$. Usamos estos datos y las siguientes ecuaciones para evaluar los coeficientes:

$$b_0 = f(x_0) \quad (18.8)$$

$$b_1 = f[x_1, x_0] \quad (18.9)$$

$$b_2 = f[x_2, x_1, x_0] \quad (18.10)$$

⋮

$$b_n = f[x_n, x_{n-1}, \dots, x_1, x_0] \quad (18.11)$$

donde las evaluaciones de la función puestas entre paréntesis son diferencias divididas finitas. Por ejemplo, la primera diferencia dividida finita se representa por lo general como

$$f[x_i, x_j] = \frac{f(x_i) - f(x_j)}{x_i - x_j} \quad (18.12)$$

La *segunda diferencia dividida finita*, la cual representa la diferencia de las dos primeras diferencias divididas, se expresa por lo general como

i	x_i	$f(x_i)$	Primero	Segundo	Tercero
0	x_0	$f(x_0)$	$f[x_1, x_0]$	$f[x_2, x_1, x_0]$	$f[x_3, x_2, x_1, x_0]$
1	x_1	$f(x_1)$	$f[x_2, x_1]$	$f[x_3, x_2, x_1]$	
2	x_2	$f(x_2)$	$f[x_3, x_2]$		
3	x_3	$f(x_3)$			

FIGURA 18.5

Ilustración gráfica de la naturaleza recursiva de las diferencias divididas finitas.

$$f[x_i, x_j, x_k] = \frac{f[x_i, x_j] - f[x_j, x_k]}{x_i - x_k} \quad (18.13)$$

En forma similar, la n -ésima diferencia dividida finita es

$$f[x_n, x_{n-1}, \dots, x_1, x_0] = \frac{f[x_n, x_{n-1}, \dots, x_1] - f[x_{n-1}, x_{n-2}, \dots, x_0]}{x_n - x_0} \quad (18.14)$$

Estas diferencias pueden usarse para evaluar los coeficientes en las ecuaciones (18.8) hasta la (18.11), las cuales entonces se sustituirán en la ecuación (18.7) para obtener el polinomio de interpolación

$$f_n(x) = f(x_0) + (x - x_0)f[x_1, x_0] + (x - x_0)(x - x_1)f[x_2, x_1, x_0] + \dots + (x - x_0)(x - x_1) \dots (x - x_{n-1})f[x_n, x_{n-1}, \dots, x_0] \quad (18.15)$$


que es conocido como *polinomio de interpolación por diferencias divididas de Newton*. Debe observarse que no es necesario que los datos utilizados en la ecuación (18.15) sean igualmente espaciados o que los valores de la abscisa deban estar en orden ascendente, como se ilustra en el siguiente ejemplo. También, observe cómo las ecuaciones (18.12) a (18.14) son recursivas (es decir, las diferencias de órdenes mayores se calculan al tomar diferencias de orden menor, véase la figura 18.5). Esta propiedad será aprovechada cuando desarrollemos un programa eficiente en la computadora dentro de la sección 18.1.5 para implementar el método.

EJEMPLO 18.3 Interpolando polinomios mediante la diferencia dividida de Newton

Enunciado del problema. En el ejemplo 18.2, los datos en $x_0 = 1$, $x_1 = 4$ y $x_2 = 6$ se utilizaron para estimar $\ln 2$ con una parábola. Ahora, agregando un cuarto punto ($x_3 = 5$; $f(x_3) = 1.609438$), calcule el $\ln 2$ con una interpolación del polinomio de Newton de tercer orden.

Solución. El polinomio de tercer orden utilizando la ecuación (18.7) con $n = 3$, es

$$f_3(x) = b_0 + b_1(x - x_0) + b_2(x - x_0)(x - x_1) + b_3(x - x_0)(x - x_1)(x - x_2)$$

**FIGURA 18.6**

Uso de la interpolación cúbica para estimar $\ln 2$.

Las primeras diferencias divididas para el problema son [véase la ecuación (18.12)]

$$f[x_1, x_0] = \frac{1.386294 - 0}{4 - 0} = 0.4620981$$

$$f[x_2, x_1] = \frac{1.791759 - 1.386294}{6 - 4} = 0.2027326$$

$$f[x_3, x_2] = \frac{1.609438 - 1.386294}{5 - 6} = 0.1823216$$

Las segundas diferencias divididas son [véase la ecuación (18.13)]

$$f[x_2, x_1, x_0] = \frac{0.2027326 - 0.4620981}{6 - 1} = -0.05187311$$

$$f[x_3, x_2, x_1] = \frac{0.1823216 - 0.2027326}{5 - 4} = -0.02041100$$

La tercera diferencia dividida es [véase la ecuación (18.14) con $n = 3$]

$$f[x_3, x_2, x_1, x_0] = \frac{-0.02041100 - (-0.05187311)}{5 - 1} = 0.007865529$$

Los resultados para $f[x_1, x_0]$, $f[x_2, x_1, x_0]$ y $f[x_3, x_2, x_1, x_0]$ representan los coeficientes b_1 , b_2 y b_3 de la ecuación (18.7). Junto con $b_0 = f(x_0) = 0.0$, la ecuación (18.7) es

$$f_3(x) = 0 + 0.4620981(x-1) - 0.05187311(x-1)(x-4) \\ + 0.007865529(x-1)(x-4)(x-6)$$

que puede usarse para evaluar $f_3(2) = 0.6287686$, el cual representa un error relativo de $\varepsilon_i = 9.3\%$. El polinomio cúbico completo se muestra en la figura 18.6.

18.1.4 Errores al interpolar polinomios de Newton

Observe que la estructura de la ecuación (18.15) es similar a la serie de expansión de Taylor en el sentido de que se agrega términos en forma secuencial para capturar el comportamiento de alto orden de la función en turno. Estos términos son diferencias divididas finitas y, así, representan aproximaciones de las derivadas de orden mayor. Por consiguiente, como ocurrió con la serie de Taylor, si la verdadera función subyacente es un polinomio de n -ésimo orden, el polinomio sujeto a interpolación de n -ésimo con base en $n+1$ puntos dará resultados exactos.

También, como fue el caso con la serie de Taylor, puede obtenerse una formulación para el error de truncamiento. Recuerde de la ecuación (4.6) que el error de truncamiento para la serie de Taylor podría expresarse por lo general como

$$R_n = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x_{i+1} - x_i)^{n+1} \quad (4.6)$$

donde ξ está en alguna parte en el intervalo x_i a x_{i+1} . Para una interpolación de n -ésimo orden, una relación análoga para el error es

$$R_n = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x - x_0)(x - x_1) \cdots (x - x_n) \quad (18.16)$$

donde ξ está en alguna parte en el intervalo que contiene la incógnita y los datos. Para esta fórmula que habrá de usarse, la función en turno debe ser conocida y diferenciable. Por lo común éste no es el caso. Por fortuna, una formulación alternativa está disponible y no requiere conocimiento previo de la función. Más bien, usa una diferencia dividida finita para aproximar la derivada $(n+1)$ -ésima,

$$R_n = f[x, x_n, x_{n-1}, \dots, x_0](x - x_0)(x - x_1) \cdots (x - x_n) \quad (18.17)$$

donde $f[x, x_n, x_{n-1}, \dots, x_0]$ es la $(n+1)$ -ésima diferencia dividida finita. Debido a que la ecuación (18.17) contiene la incógnita $f(x)$, no puede resolverse para el error. Sin embargo, si se dispone de un dato adicional $f(x_{n+1})$, la ecuación (18.17) puede usarse para estimar el error, como en

$$R_n \cong f[x_{n+1}, x_n, x_{n-1}, \dots, x_0](x - x_0)(x - x_1) \cdots (x - x_n) \quad (18.18)$$

EJEMPLO 18.4 Estimación del error para el polinomio de Newton

Enunciado del problema. Use la ecuación (18.18) para estimar el error para la interpolación del polinomio de segundo orden del ejemplo 18.2. Use los datos adicionales $f(x_3) = f(5) = 1.609438$ para obtener sus resultados.




FIGURA 18.10

Una ilustración visual del racional detrás del polinomio de Lagrange. Esta figura muestra un caso de segundo orden. Cada uno de los tres términos en la ecuación (18.23) pasa a través de uno de los puntos y es cero en los otros dos. La sumatoria de los tres términos, por tanto, es un polinomio único de segundo orden $f_2(x)$ que pasa exactamente a través de los puntos.

Observe que, como en el caso del método de Newton, la versión de Lagrange tiene un error estimado de [véase ecuación (18.17)]

$$R_n = f[x, x_n, x_{n-1}, \dots, x_0] \prod_{i=0}^n (x - x_i)$$

De este modo, si se tiene un punto adicional en $x = x_{n+1}$, se puede obtener un error estimado. Sin embargo, como no se emplean las diferencias divididas finitas como parte del algoritmo de Lagrange, esto se hace muy ocasionalmente.

Las ecuaciones (18.20) y (18.21) se programan de manera muy simple para implementarse en una computadora. La figura 18.11 muestra el pseudocódigo que se puede emplear para este propósito.

En resumen, para casos donde el orden del polinomio es desconocido, el método de Newton tiene ventajas en el conocimiento que proporciona respecto al comportamiento de las fórmulas de diferente orden. Además, el error estimado expuesto por la ecuación (18.18) se integra de manera usual en el cálculo del polinomio de Newton debido a que


```

FUNCTION Lagrng(x, y, n, x)
  sum = 0
  DO i = 0, n
    product = yi
    DO j = 0, n
      IF i ≠ j THEN
        product = product * (x - xj) / (xi - xj)
      ENDIF
    END DO
    sum = sum + product
  END DO
  Lagrng = sum
END Lagrng

```

FIGURA 18.11

Pseudocódigo para implementar la interpolación de Lagrange. Este algoritmo se acondiciona para calcular una sola predicción de n -ésimo orden, donde $n + 1$ es el número de datos.

la estimación emplea una diferencia finita (véase el ejemplo 18.5). De esta manera, para cálculos exploratorios, a menudo se prefiere el método de Newton.


Cuando se ejecuta sólo una interpolación, las formulaciones de Lagrange y Newton requieren un notable esfuerzo computacional. Sin embargo, la versión de Lagrange es un poco más fácil de programar. Debido a que no requiere de cálculos y almacenaje de diferencias divididas, la forma de Lagrange se usa a menudo cuando el orden del polinomio se conoce *a priori*.

EJEMPLO 18.7 Interpolación de Lagrange usando la computadora

Enunciado del problema. Podemos usar el algoritmo de la figura 18.11 para estudiar un análisis de tendencia para un problema que se relaciona con nuestro conocido caso del paracaidista en caída. Suponga que desarrollamos cierta instrumentación para medir la velocidad del paracaidista. Los datos de medición obtenidos para un caso de prueba en particular son

Tiempo, s	Velocidad medida v, cm/s
1	800
3	2 310
5	3 090
7	3 940
13	4 755

Nuestro problema es estimar la velocidad del paracaidista en $t = 10$ s para tener las mediciones faltantes entre $t = 7$ y $t = 13$ s. Estamos conscientes que el comportamiento de la interpolación de polinomios puede ser inesperado. Por tanto, construiremos polinomios de 4, 3, 2 y 1 órdenes para comparar los resultados.

**FIGURA 18.12**

Gráficas que exponen a) cuarto orden, b) tercer orden, c) segundo orden y d) interpolaciones de primer orden.

Solución. El algoritmo de Lagrange se usa para construir polinomios de interpolación de cuarto, tercer, segundo y primer orden.

El polinomio de cuarto orden y los datos de entrada se pueden graficar como se muestra en la figura 18.12a. Es evidente a partir de esta gráfica que el valor estimado de y en $x = 10$ es mayor que la tendencia global de los datos.

Desde la figura 18.12b hasta la 18.12d se muestran las gráficas de los resultados de los cálculos para las interpolaciones de los polinomios de tercer, segundo y primer orden. Se observa que mientras más bajo sea el orden, menor será el valor estimado de la velocidad en $t = 10$ s. Las gráficas de la interpolación de polinomios indican que los polinomios de alto orden tienden a sobrepasar la tendencia de los datos. Esto sugiere que las versiones de primer o segundo orden son las más adecuadas para este análisis de tendencia en particular. Debe recordarse, que debido a que tratamos con datos inciertos, la regresión de hecho podría ser la más adecuada.

El ejemplo anterior ilustró que los polinomios de alto orden tienden a ser mal condicionados; esto es, tienden a ser altamente sensibles a los errores de redondeo. El mismo problema se aplica a la regresión con polinomios de orden superior. La aritmética de doble precisión ayuda algunas veces a disminuir el problema. Sin embargo, en tanto el orden aumente, habrá un punto para el cual el error de redondeo interferirá con la habilidad para interpolar mediante el procedimiento simple que se abordó en este punto.

18.3 COEFICIENTES DE UN POLINOMIO DE INTERPOLACIÓN

Aunque el polinomio de Newton y el de Lagrange son adecuados para determinar valores intermedios entre puntos, no proporcionan un polinomio conveniente de la forma convencional

$$f(x) = a_0 + a_1x + a_2x^2 + \cdots + a_nx^n \quad (18.24)$$

Un método directo para calcular los coeficientes de este polinomio se basa en el hecho de que $n + 1$ puntos se requieren para determinar los $n + 1$ coeficientes. Así, se puede usar ecuaciones algebraicas lineales simultáneas para calcular las a . Por ejemplo, suponga que usted desea calcular los coeficientes de la parábola

$$f(x) = a_0 + a_1x + a_2x^2 \quad (18.25)$$

Se requiere tres puntos: $[x_0, f(x_0)]$, $[x_1, f(x_1)]$ y $[x_2, f(x_2)]$. Cada uno se puede sustituir en la ecuación (18.25) para dar

$$\begin{aligned} f(x_0) &= a_0 + a_1x_0 + a_2x_0^2 \\ f(x_1) &= a_0 + a_1x_1 + a_2x_1^2 \\ f(x_2) &= a_0 + a_1x_2 + a_2x_2^2 \end{aligned} \quad (18.26)$$

De esta manera, las x son los puntos conocidos y las a las incógnitas. Como hay el mismo número de ecuaciones que incógnitas, la ecuación (18.26) se podría resolver con un método de eliminación de la parte tres.

Debe observarse que el procedimiento anterior no es el método disponible más eficiente para determinar los coeficientes de una interpolación de polinomios. Press y cols. (1986) proporcionan un análisis y códigos de cómputo para procedimientos más eficaces. Cualquiera que sea la técnica empleada, se debe tener precaución con el orden. Los sistemas como el de la ecuación (18.26) están notoriamente mal condicionados. Ya sean resueltos con un método de eliminación o con un algoritmo eficiente, los coeficientes resultantes pueden ser altamente inexactos, en particular para n grandes. Cuando se usan para una interpolación subsecuente a menudo se obtiene resultados erróneos.

En resumen, si usted se interesa en determinar un punto intermedio, emplee la interpolación de Newton o Lagrange. Si lo que desea es determinar una ecuación con la forma de la (18.24), límitese a polinomios de orden inferior y verifique sus resultados cuidadosamente.

18.4 INTERPOLACIÓN INVERSA

Como su nomenclatura lo implica, los valores de $f(x)$ y x en la mayoría de los contextos de interpolación son las variables dependientes e independientes, en forma respectiva. En consecuencia, los valores de las x están típicamente espaciados en forma uniforme. Un ejemplo simple es una tabla de valores tabulados para la función $f(x) = 1/x$,

x	1	2	3	4	5	6	7
$f(x)$	1	0.5	0.3333	0.25	0.2	0.1667	0.1429

Ahora suponga que usted debe usar los mismos datos, pero que se le ha dado un valor para $f(x)$ y debe determinar el valor correspondiente de x . Por ejemplo, para los datos anteriores, suponga que se le pide determinar el valor de x que corresponda a $f(x) = 0.3$. Para este caso, como la función está disponible y se puede manejar en forma fácil, la respuesta correcta se determina directamente como $x = 1/0.3 = 3.3333$.

puntos en una secuencia diferente. La figura 18.9 muestra los resultados para el caso de invertir el orden de los datos originales; esto es, $x_0 = 3.5$, $x_1 = 2.5$, $x_2 = 1.5$, y así sucesivamente. Como los puntos iniciales para este caso se hallan cercanos y espaciados en cualquier lado de $\ln 2$, el error disminuye mucho más rápido que para la situación original. En el segundo término, el error se redujo a menos de $\varepsilon_i = 2\%$. Se podría emplear otras combinaciones para obtener diferentes velocidades de convergencia.

El ejemplo anterior ilustra la importancia de la selección de los puntos base. Como se podría intuir en forma obvia, los puntos deberían estar centrados alrededor y tan cerca como sea posible de las incógnitas. Esta observación es también soportada por un análisis directo de la ecuación para estimar el error [vea ecuación (18.17)]. Si suponemos que la diferencia dividida finita no varía mucho a lo largo del rango de datos, el error es proporcional al producto: $(x - x_0)(x - x_1) \dots (x - x_n)$. Por lógica, los puntos base más cercanos son a x , la magnitud más pequeña de este producto.

18.2 INTERPOLACIÓN DE POLINOMIOS DE LAGRANGE

La *interpolación de polinomios de Lagrange* es simplemente una reformulación del polinomio de Newton que evita el cálculo por diferencias divididas. Se puede expresar de manera concisa como

$$f_n(x) = \sum_{i=0}^n L_i(x)f(x_i) \quad (18.20)$$

donde

$$L_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j} \quad (18.21)$$

donde Π designa el "producto de". Por ejemplo, la versión lineal ($n = 1$) es

$$f_1(x) = \frac{x - x_1}{x_0 - x_1} f(x_0) + \frac{x - x_0}{x_1 - x_0} f(x_1) \quad (18.22)$$

y la versión de segundo orden es

$$\begin{aligned} f_2(x) = & \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} f(x_0) + \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)} f(x_1) \\ & + \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)} f(x_2) \end{aligned} \quad (18.23)$$

La ecuación (18.20) se puede derivar de manera directa a partir del polinomio de Newton (véase cuadro 18.1). Sin embargo, el racional resaltado de la formulación de Lagrange se puede captar de manera directa al darse cuenta que cada término $L_i(x)$ será

1 en $x = x_i$ y 0 en todos los otros puntos de la muestra (véase la figura 18.10). De esta manera, cada producto $L_i(x)f(x_i)$ toma el valor de $f(x_i)$ en el punto de muestra x_i . En consecuencia, la sumatoria de todos los productos designados para la ecuación (18.20) es el único polinomio de n -ésimo orden que pasa de manera exacta a través de todos los $n + 1$ puntos.

EJEMPLO 18.6 Interpolación de polinomios de Lagrange

Enunciado del problema. Use una interpolación del polinomio de Lagrange de primer y segundo orden para evaluar $\ln 2$ con base en los datos dados en el ejemplo 18.2:

$$\begin{aligned} x_0 &= 1 & f(x_0) &= 0 \\ x_1 &= 4 & f(x_1) &= 1.386294 \\ x_2 &= 6 & f(x_2) &= 1.791760 \end{aligned}$$

Solución. El polinomio de primer orden [véase ecuación (18.22)] se puede usar para obtener la estimación en $x = 2$,

$$f_1(2) = \frac{2-4}{1-4}0 + \frac{2-1}{4-1}1.386294 = 0.4620981$$

De manera similar, el polinomio de segundo orden se desarrolla como [véase ecuación (18.23)]

$$\begin{aligned} f_2(2) &= \frac{(2-4)(2-6)}{(1-4)(1-6)}0 + \frac{(2-1)(2-6)}{(4-1)(4-6)}1.386294 \\ &\quad + \frac{(2-1)(2-4)}{(6-1)(6-4)}1.791760 = 0.5658444 \end{aligned}$$

Como se esperaba, ambos resultados concuerdan con los que se obtuvieron antes al usar la interpolación para el polinomio de Newton.

Cuadro 18.1 Obtención de la forma de Lagrange a partir directamente de la interpolación del polinomio de Newton

El polinomio de interpolación de Lagrange se puede obtener de manera directa a partir de la formulación del polinomio de Newton. Haremos esto únicamente para el caso del polinomio de primer orden [véase ecuación (18.2)]. Para obtener la forma de Lagrange, reformulamos las diferencias divididas. Por ejemplo, la primera diferencia dividida,

$$f[x_1, x_0] = \frac{f(x_1) - f(x_0)}{x_1 - x_0} \quad (\text{B18.1.1})$$

se puede reformular como

$$f[x_1, x_0] = \frac{f(x_1)}{x_1 - x_0} + \frac{f(x_0)}{x_0 - x_1} \quad (\text{B18.1.2})$$

la cual es referida como *forma simétrica*. Al sustituir la ecuación (B18.1.2) en (18.2) se obtiene

$$f_1(x) = f(x_0) + \frac{x - x_0}{x_1 - x_0}f(x_1) + \frac{x - x_1}{x_0 - x_1}f(x_0)$$

Por último, al agrupar términos similares y simplificar se tiene la forma del polinomio de Lagrange,

$$f_1(x) = \frac{x - x_1}{x_0 - x_1}f(x_0) + \frac{x - x_0}{x_1 - x_0}f(x_1)$$

Tal problema se conoce como *interpolación inversa*. Para un caso más complicado, usted debe intentar cambiar los valores $f(x)$ y x [es decir, sólo grafique x contra $f(x)$] y use un procedimiento como la interpolación de Lagrange para determinar el resultado. Por desgracia, cuando usted invierte las variables no hay garantía de que los valores junto con la nueva abscisa [los $f(x)$] sean espaciados uniformemente. De hecho, en muchos casos, los valores serán "agrandados". Es decir, tendrán la apariencia de una escala logarítmica con algunos puntos adyacentes muy agrupados y otros muy dispersos. Por ejemplo, para $f(x) = 1/x$ el resultado es

$f(x)$	0.1429	0.1667	0.2	0.25	0.3333	0.5	1
x	7	6	5	4	3	2	1

Tal espaciamiento no uniforme sobre la abscisa a menudo lleva a oscilaciones en el resultado de la interpolación de polinomios. Esto puede ocurrir aun para polinomios de orden inferior.

Una estrategia alterna es ajustar un polinomio de n -ésimo orden, $f_n(x)$, a los datos originales [es decir, con $f(x)$ contra x]. En la mayoría de los casos, como las x están espaciadas de manera uniforme, este polinomio no estará mal condicionado. La respuesta a su problema entonces toma en cuenta la determinación del valor de x que haga que este polinomio sea igual al dado por $f(x)$. Así, ¡el problema de interpolación se reduce a un problema de raíces!

Por ejemplo, para el problema antes descrito, un simple procedimiento podría ser ajustar los tres puntos a un polinomio cuadrático: (2, 0.5), (3, 0.3333) y (4, 0.25). El resultado sería

$$f_2(x) = 1.08333 - 0.375x + 0.041667x^2$$

La respuesta al problema de interpolación inversa para determinar la x correspondiente a $f(x) = 0.3$ sería equivalente a la determinación raíces de

$$0.3 = 1.08333 - 0.375x + 0.041667x^2$$

Para este caso simple, la fórmula cuadrática se puede usar para calcular

$$x = \frac{0.375 \pm \sqrt{(-0.375)^2 - 4(0.041667)(0.78333)}}{2(0.041667)} = \frac{5.704158}{3.295842}$$

Así, la segunda raíz, 3.296, es una buena aproximación del valor real de 3.333. Si se desea una exactitud adicional, se podría emplear un polinomio de tercer o cuarto orden junto con uno de los métodos para la localización de raíces de la parte dos.

18.5 COMENTARIOS ADICIONALES

Antes de proceder con la siguiente sección, se debe mencionar dos temas adicionales: interpolación con datos igualmente espaciados y extrapolación.

Como ambos polinomios, el de Newton y Lagrange, son compatibles con datos espaciados en forma arbitraria, usted se preguntaría por qué hemos puesto el caso especial de datos igualmente espaciados (véase cuadro 18.2). Antes de la llegada de las computadoras digitales, esas técnicas tenían gran utilidad para interpolación a partir de

Cuadro 18.2 Interpolación con datos igualmente espaciados

Si los datos están igualmente espaciados y en orden ascendente, entonces la variable independiente tiene los valores de

$$\begin{aligned}x_1 &= x_0 + h \\x_2 &= x_0 + 2h \\&\vdots \\x_n &= x_0 + nh\end{aligned}$$

donde h es el intervalo, o tamaño de paso, entre los datos. Con esta base, las diferencias divididas finitas se pueden expresar en forma concisa. Por ejemplo, la segunda diferencia dividida hacia adelante es

$$f[x_0, x_1, x_2] = \frac{\frac{f(x_2) - f(x_1)}{x_2 - x_1} - \frac{f(x_1) - f(x_0)}{x_1 - x_0}}{x_2 - x_0}$$

la cual se puede expresar como

$$f[x_0, x_1, x_2] = \frac{f(x_2) - 2f(x_1) + f(x_0)}{2h^2} \quad (\text{B18.2.1})$$

ya que $x_1 - x_0 = x_2 - x_1 = (x_2 - x_0)/2 = h$. Ahora recuerde que la segunda diferencia hacia adelante es igual al numerador de la ecuación (4.24)

$$\Delta^2 f(x_0) = f(x_2) - 2f(x_1) + f(x_0)$$

Por tanto, la ecuación (B18.2.1) se puede representar como

$$f[x_0, x_1, x_2] = \frac{\Delta^2 f(x_0)}{2!h^2}$$

o, en general

$$f[x_0, x_1, \dots, x_n] = \frac{\Delta^n f(x_0)}{n!h^n} \quad (\text{B18.2.2})$$

Mediante la ecuación (B18.2.2), podemos expresar el polinomio de interpolación de Newton [véase ecuación (18.15)] para el caso de datos igualmente espaciados como

$$\begin{aligned}f_n(x) &= f(x_0) + \frac{\Delta f(x_0)}{h}(x - x_0) \\&\quad + \frac{\Delta^2 f(x_0)}{2!h^2}(x - x_0)(x - x_0 - h) \\&\quad + \dots + \frac{\Delta^n f(x_0)}{n!h^n}(x - x_0)(x - x_0 - h) \\&\quad \dots [x - x_0 - (n-1)h] + R_n\end{aligned} \quad (\text{B18.2.3})$$

donde lo que resta es lo mismo que en la ecuación (18.16). Esta ecuación es conocida como *fórmula de Newton* o *fórmula hacia adelante de Newton-Gregory*. Se puede simplificar más al definir una nueva cantidad, α :

$$\alpha = \frac{x - x_0}{h}$$

Esta definición se puede usar para desarrollar las siguientes expresiones simplificadas para los términos en la ecuación (B18.2.3):

$$\begin{aligned}x - x_0 &= \alpha h \\x - x_0 - h &= \alpha h - h = h(\alpha - 1) \\&\vdots \\x - x_0 - (n-1)h &= \alpha h - (n-1)h = h(\alpha - n + 1)\end{aligned}$$

las cuales se sustituyen en la ecuación (B18.2.3) para dar

$$\begin{aligned}f_n(x) &= f(x_0) + \Delta f(x_0)\alpha + \frac{\Delta^2 f(x_0)}{2!}\alpha(\alpha - 1) \\&\quad + \dots + \frac{\Delta^n f(x_0)}{n!}\alpha(\alpha - 1) \dots (\alpha - n + 1) + R_n\end{aligned} \quad (\text{B18.2.4})$$

donde

$$R_n = \frac{f^{(n+1)}(\xi)}{(n+1)!} h^{n+1} \alpha(\alpha - 1)(\alpha - 2) \dots (\alpha - n)$$

Esta notación concisa tendrá utilidad en nuestra derivación y en el análisis de error de las fórmulas de integración en el capítulo 21.

Además de la fórmula hacia adelante, están disponibles las fórmulas hacia atrás y central de Newton-Gregory. Para información adicional con respecto a interpolación para datos igualmente espaciados se puede consultar a Carnahan, Luther y Wilkes (1969).

Solución. Recuerde que en el ejemplo 18.2 la interpolación del polinomio de segundo orden proporcionó una estimación de $f_2(2) = 0.5658444$, que representa un error de $0.6931472 - 0.5658444 = 0.1273028$. Si se hubiera conocido el valor real, como es común que suceda, la ecuación (18.18), junto con el valor adicional en x_3 , pudo usarse para estimar el error, como en

$$R_2 = f[x_3, x_2, x_1, x_0](x - x_0)(x - x_1)(x - x_2)$$

o

$$R_2 = 0.007865529(x - 1)(x - 4)(x - 6)$$

donde el valor para la diferencia dividida finita de tercer orden es como la que se calculó antes en el ejemplo 18.3. Esta relación puede evaluarse en $x = 2$ para

$$R_2 = 0.007865529(2 - 1)(2 - 4)(2 - 6) = 0.0629242$$

la cual es del mismo orden de magnitud que el error real.

Del ejemplo anterior y de la ecuación (18.18), debe estar claro que el error estimado para el polinomio de n -ésimo orden es equivalente a la diferencia entre el $(n + 1)$ -ésimo orden y la predicción de n -ésimo orden. Es decir,

$$R_n = f_{n+1}(x) - f_n(x) \quad (18.19)$$

En otras palabras, el incremento que se agrega al caso del n -ésimo orden para crear el caso de $(n + 1)$ -ésimo orden [es decir, la ecuación (18.18)] se interpreta como una estimación del n -ésimo orden de error. Esto puede verse con claridad al reordenar la ecuación (18.19) para dar

$$f_{n+1}(x) = f_n(x) + R_n$$

La validez de este procedimiento es afirmada por el hecho de que la serie es fuertemente convergente. Para tal situación, la predicción del $(n + 1)$ -ésimo orden debería ser mucho más cercana al valor real que la predicción del n -ésimo orden. En consecuencia, la ecuación (18.19) conforma nuestra definición estándar de error al representar la diferencia entre la verdadera y una aproximación. Sin embargo, observe que mientras todos los otros errores estimados para procedimientos iterativos introducidos hasta ahora se determinaron como una predicción actual menos una previa, la ecuación (18.19) representa una predicción futura menos una presente. Esto significa que para una serie en convergencia rápida, el error estimado de la ecuación (18.19) podría ser menor que el verdadero. Esto representaría una calidad muy poco atractiva si el error estimado fuera a emplearse como un criterio de paro. Sin embargo, como será expuesto en la siguiente sección, la interpolación de polinomios de alto orden son muy sensibles a errores en los datos (es decir, están mal condicionados). Cuando se emplean para interpolación, a menudo se obtienen predicciones que divergen en forma significativa del valor verdadero. Si se prevén tales errores, la ecuación (18.19) es más sensible para dicha divergencia. Como tal, es más valioso para la clase de análisis de datos exploratorios para lo cual el polinomio de Newton es el más adecuado.

18.1.5 Algoritmo de cómputo para la interpolación del polinomio de Newton

Tres propiedades hacen que la interpolación del polinomio de Newton sea muy atractiva para las aplicaciones en la computadora:

1. Como en la ecuación (18.7), se puede desarrollar de manera secuencial versiones de orden mayor con la adición de un solo término a la siguiente ecuación de orden inferior. Esto facilita la evaluación de algunas de las versiones de diferente orden en el mismo programa. Tal capacidad es en especial valiosa cuando el orden del polinomio no es conocido *a priori*. Al agregar nuevos términos en forma secuencial, podemos determinar cuándo se alcanza un punto de disminución de regreso (es decir, cuando la adición de términos de orden superior ya no mejora de manera significativa la estimación, o en ciertas situaciones de hecho la aleja). Las ecuaciones para estimar el error que se analizan en el punto 3 son útiles para visualizar un criterio objetivo para identificar este punto de términos disminuidos.
2. Las diferencias divididas finitas que constituyen los coeficientes del polinomio [ecuaciones (18.8) hasta (18.11)] se pueden calcular de manera eficaz. Es decir, como en la ecuación (18.14) y la figura 18.5, se usa diferencias del orden inferior para calcular las de alto orden. Por medio de la información determinada antes, los coeficientes se pueden calcular de manera eficiente. El algoritmo en la figura 18.7 contiene un esquema semejante.
3. El error estimado [véase la ecuación (18.18)] puede ser muy simple de incorporar en un algoritmo de cómputo debido a la manera secuencial en la cual se construye la predicción.

FIGURA 18.7

Un algoritmo para el polinomio de interpolación de Newton escrito en pseudocódigo.

```

SUBROUTINE NewtInt (x, y, n, xi, yint, ea)
  LOCAL fddn,n
  DO i = 0, n
    fddi,0 = yi
  END DO
  DO j = 1, n
    DO i = 0, n - j
      fddij = (fddi+j-1 - fddij-1) / (xi+j - xi)
    END DO
  END DO
  xterm = 1
  yint0 = fdd0,0
  DO order = 1, n
    xterm = xterm * (xi - xorder-1)
    yint2 = yintorder-1 + fdd0,order * xterm
    Eaorder-1 = yint2 - yintorder-1
    yintorder = yint2
  END DO
END NewtInt

```

Todas las características anteriores pueden aprovecharse y ser incorporadas en un algoritmo general para implementar el polinomio de Newton (véase la figura 18.7). Observe que el algoritmo consiste en dos partes: el primero determina los coeficientes a partir de la ecuación (18.7); el segundo establece las predicciones y su error asociado. La utilidad de este algoritmo se demuestra en el ejemplo siguiente.

EJEMPLO 18.5 Estimación del error para determinar el orden adecuado de interpolación

Enunciado del problema. Después de incorporar el error [véase la ecuación (18.18)], utilice el algoritmo de cómputo que se muestra en la figura 18.7 y la siguiente información para evaluar $f(x) = \ln x$ en $x = 2$:

x	$f(x) = \ln x$
0	1
4	1.3862944
6	1.7917595
5	1.6094379
3	1.0986123
1.5	0.4054641
2.5	0.9162907
3.5	1.2527630

Solución. Los resultados al emplear el algoritmo de la figura 18.7 para obtener una solución se muestran en la figura 18.8. El error estimado, junto con el error real (con

FIGURA 18.8

Los resultados de un programa, con base en el algoritmo de la figura 18.7, para evaluar $\ln 2$.

```

NUMBER OF POINTS? 8
X( 0 ), y( 0 ) = ? 1.0
X( 1 ), y( 1 ) = ? 4.1.3862944
X( 2 ), y( 2 ) = ? 6.1.7917595
X( 3 ), y( 3 ) = ? 5.1.6094379
X( 4 ), y( 4 ) = ? 3.1.0986123
X( 5 ), y( 5 ) = ? 1.5,0.40546411
X( 6 ), y( 6 ) = ? 2.5,0.91629073
X( 7 ), y( 7 ) = ? 3.5,1.2527630

INTERPOLATION AT X = 2
ORDER      F(X)      ERROR
0          0.000000  0.462098
1          0.462098  0.103746
2          0.565844  0.062924
3          0.628769  0.046953
4          0.675722  0.021792
5          0.697514  -0.003616
6          0.693898  -0.000459
7          0.693439

```


base en el hecho de que $\ln 2 = 0.6931472$), se ilustran en la figura 18.9. Observe que el error estimado y el real son similares y que su concordancia mejora en tanto se aumente el orden. A partir de estos resultados se puede concluir que la versión de quinto orden da una buena estimación y que los términos de orden superior no resaltan en forma significativa la predicción.

Este ejercicio también ilustra la importancia de colocar el orden de los puntos. Por ejemplo, hasta la estimación del tercer orden, la razón de mejora es lenta debido a que los puntos que se agregaron (en $x = 4, 6$ y 5) están distantes y a un lado del punto de análisis en $x = 2$. La estimación de cuarto orden muestra algo de mejora ya que el nuevo punto en $x = 3$ está cercano a la incógnita. Sin embargo, la disminución más dramática en el error está asociada con la inclusión del término de quinto orden mediante los datos en $x = 1.5$. No sólo está este punto cercano a la incógnita, sino que también se halla en el lado opuesto de la mayoría de los otros puntos. En consecuencia, el error se reduce a casi un orden de magnitud.

El significado de la posición y secuencia de los datos se puede también ilustrar al usar los mismos datos para obtener una estimación para el $\ln 2$, pero considerando los

FIGURA 18.9

Porcentaje de errores relativos para la predicción de $\ln 2$ como una función del orden de la interpolación polinomial.




**FIGURA 18.13**

Ilustración de la divergencia posible de una predicción extrapolada. La extrapolación se basa en el ajuste de una parábola a través de los primeros tres puntos conocidos.

tablas con argumentos igualmente espaciados. De hecho, una estructura computacional conocida como tabla de diferencias divididas fue desarrollada para facilitar la implementación de esas técnicas. (La figura 18.5 es un ejemplo de esa tabla.)

Sin embargo, como las fórmulas son subconjuntos de esquemas de Newton y Lagrange compatibles con computadora y debido a las muchas funciones tabulares disponibles, como subrutinas de librerías, la necesidad para las versiones igualmente espaciadas ha disminuido. A pesar de esto, por su relevancia las hemos incluido en este tema en las últimas partes de este libro. En particular, son necesarias para obtener fórmulas de integración numérica que emplean de manera típica datos igualmente espaciados (véase el capítulo 21). Como las fórmulas de integración numérica tienen relevancia en la solución de ecuaciones diferenciales ordinarias, el material del cuadro 18.2 tiene también significado en la parte siete.


Extrapolación es el proceso de estimar un valor de $f(x)$ que se tiene fuera del rango de los puntos base conocidos, $x_0, x_1, \dots, x_n$ (véase la figura 18.13). En una sección anterior, mencionamos que la interpolación más exacta es usualmente obtenida cuando las incógnitas están cerca del centro de los puntos base. Obviamente, esto no se cumple cuando las incógnitas se encuentran fuera del rango y, en consecuencia, el error en extrapolación puede ser muy grande. Como se ilustra en la figura 18.13, la naturaleza de extremos abiertos de la extrapolación representa un paso en la incógnita, ya que el proceso extiende la curva más allá de la región conocida. Como tal, la curva real podría con facilidad divergir de la predicción. Por tanto, se debe tener extremo cuidado al realizar ejercicios donde surja un caso que se deba extrapolar.

INTERPOLACIÓN SEGMENTARIA

En la sección anterior, se usó polinomios de n -ésimo orden para interpolar entre $n + 1$ datos. Por ejemplo, para ocho puntos se puede derivar un perfecto polinomio de séptimo orden. Esta curva podría capturar todas las curvaturas (al menos hasta e incluso la séptima derivada) sugeridas por los puntos. Sin embargo, hay casos en los que estas funciones pueden llevar a resultados erróneos debido a errores de redondeo y puntos lejanos. Un

FIGURA 18.14

Una representación visual de una situación donde las segmentarias son interpolaciones polinomiales de orden superior. La función que habrá de ajustarse pasa por un incremento súbito en $x = 0$. Los incisos a) a c) indican que el cambio abrupto induce oscilaciones al interpolar polinomiales. En contraste, como las curvas se limitan a tercer orden con transiciones suaves, la segmentaria cúbica d) proporciona una aproximación mucho más aceptable.



procedimiento alternativo es aplicar polinomios de orden inferior a subconjuntos de datos. Tales polinomios conectores son llamados *funciones segmentarias*.

Por ejemplo, curvas de tercer orden empleadas para conectar cada par de datos son llamadas *segmentarias cúbicas*. Esas funciones se pueden construir de tal forma que las conexiones entre las ecuaciones cúbicas adyacentes resultan visualmente suaves. Sobre la superficie, podría parecer que la aproximación de tercer orden de las segmentarias sería inferior a la expresión de séptimo orden. Usted se preguntaría por qué una segmentaria podría ser siempre preferible.

La figura 18.14 ilustra una situación donde una segmentaria se comporta mejor que una polinomial de orden superior. Éste es el caso donde una función es por lo general suave pero conlleva un cambio abrupto en algún lugar a lo largo de la región de interés. El incremento de paso expuesto en la figura 18.14 es un ejemplo extremo de tal cambio y sirve para ilustrar este punto.


De la figura 18.14a hasta la 18.14c se ilustra cómo un polinomio de orden superior tiende a formar una curva a través de oscilaciones bruscas en la vecindad con un cambio súbito. En contraste, la segmentaria también conecta los puntos, pero debido a sus cambios limitados de tercer orden, las oscilaciones se mantienen a un mínimo. Como tal, la segmentaria usualmente proporciona una aproximación superior del comportamiento de las funciones que tienen cambios locales y abruptos.

El concepto de la segmentaria se origina de la técnica de dibujo con una cinta delgada y flexible (llamada *curvígrafo*) para dibujar curvas suaves a través de un conjunto de puntos. El proceso se expone en la figura 18.15 para una serie de cinco pasadores (datos). En esta técnica, el dibujante coloca un papel sobre una mesa de madera y golpea los clavos o pasadores en el papel (y la mesa) en la ubicación de los datos. Una curva suave resulta al entrelazar la cinta entre los pasadores. De aquí que se haya adoptado el nombre de "segmentaria cúbica" para los polinomios de este tipo.

En esta sección, se usarán primero funciones lineales simples para introducir algunos conceptos básicos y problemas asociados con la interpolación segmentaria. Entonces obtendremos un algoritmo para el ajuste de datos con segmentarias cuadráticas. Por último, presentamos material sobre la segmentaria cúbica, la cual es la versión más común y útil en la práctica de la ingeniería.

FIGURA 18.15

La técnica de dibujo al usar una segmentaria para dibujar curvas suaves a través de una serie de puntos. Observe cómo en los puntos extremo, la segmentaria trata de enderezarse. Esto es conocido como una segmentaria "natural".



18.6.1 Segmentarias lineales

La conexión más simple entre dos puntos es por medio de una línea recta. Las segmentarias de primer orden para un grupo de datos ordenados pueden definirse como un conjunto de funciones lineales,

$$f(x) = f(x_0) + m_0(x - x_0) \quad x_0 \leq x \leq x_1$$

$$f(x) = f(x_1) + m_1(x - x_1) \quad x_1 \leq x \leq x_2$$

$$f(x) = f(x_{n-1}) + m_{n-1}(x - x_{n-1}) \quad x_{n-1} \leq x \leq x_n$$

donde m_i es la pendiente de la línea recta que conecta los puntos:

$$m_i = \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i} \quad (18.27)$$

Estas ecuaciones se pueden usar para evaluar la función en cualquier punto entre x_0 y x_n para localizar primero el intervalo dentro del cual está el punto. Después se usa la ecuación adecuada para determinar el valor de la función dentro del intervalo. El método es obviamente idéntico al de la interpolación lineal.

EJEMPLO 18.8 Segmentarias de primer orden

Enunciado del problema. Ajuste los datos de la tabla 18.1 con segmentarias de primer orden. Evalúe la función en $x = 5$.

Solución. Se puede usar los datos para determinar las pendientes entre puntos. Por ejemplo, para el intervalo $x = 4.5$ a $x = 7$ la pendiente se puede calcular mediante la ecuación (18.27):

$$m = \frac{2.5 - 1}{7 - 4.5} = 0.60$$

Las pendientes para los otros intervalos se pueden calcular y las segmentarias resultantes de primer orden se grafican en la figura 18.16a. El valor en $x = 5$ es 1.3.

TABLA 18.1

Datos para ser ajustados con funciones segmentarias.

x	$f(x)$
3.0	2.5
4.5	1.0
7.0	2.5
9.0	0.5


Una inspección visual a la figura 18.16a indica que la principal desventaja de las segmentarias de primer orden es que no son suaves. En esencia, en los puntos donde dos segmentarias se encuentran (llamado *nodo*), la pendiente cambia de forma abrupta. En términos formales, la primera derivada de la función es discontinua en esos puntos. Esta deficiencia se resuelve al usar segmentarias polinomiales de orden superior que aseguren suavidad en los nodos al igualar derivadas en esos puntos, como se analiza en la siguiente sección.

18.6.2 Segmentarias cuadráticas

Para asegurar que las derivadas m -ésimas son continuas en los nodos, se debe usar una segmentaria de al menos $m + 1$ orden. A menudo se usan con más frecuencia en la práctica los polinomios de tercer orden o segmentarias cúbicas para asegurar derivadas

FIGURA 18.16

Ajuste segmentario de un conjunto de cuatro puntos. a) Segmentaria lineal, b) segmentaria cuadrática y c) segmentaria cúbica, se grafica también con una interpolación polinomial cúbica.



continuas de primer y segundo orden. Aunque las derivadas de tercer orden y mayores podrían ser discontinuas cuando se usa segmentarias cúbicas, usualmente no puede detectarse en forma visual y en consecuencia son ignoradas.

Debido a que la obtención de segmentarias cúbicas está algo involucrada, lo hemos escogido en una sección subsecuente. Hemos decidido primero ilustrar el concepto de interpolación segmentaria mediante polinomios de segundo orden. Esas "segmentarias cuadráticas" tienen primeras derivadas continuas en los nodos. Aunque las segmentarias cuadráticas no aseguran segundas derivadas iguales en los nodos, sirven muy bien para demostrar el procedimiento general en el desarrollo de segmentarias de orden superior.

El objetivo de las segmentarias cuadráticas es derivar un polinomio de segundo orden para cada intervalo entre datos. El polinomio para cada intervalo se puede representar de manera general como

$$f_i(x) = a_i x^2 + b_i x + c_i \quad (18.28)$$

La figura 18.17 ha sido incluida para ayudar a clarificar la notación. Para $n + 1$ datos ($i = 0, 1, 2, \dots, n$) existen n intervalos y, en consecuencia, $3n$ constantes desconocidas (las a , b y c) por evaluar. Por tanto, se requieren $3n$ ecuaciones o condiciones para evaluar las incógnitas. Éstas son:

1. Los valores de la función de polinomios adyacentes deben ser iguales a los nodos interiores. Esta condición se puede representar como


$$a_{i-1}x_{i-1}^2 + b_{i-1}x_{i-1} + c_{i-1} = f(x_{i-1}) \quad (18.29)$$

$$a_i x_{i-1}^2 + b_i x_{i-1} + c_i = f(x_{i-1}) \quad (18.30)$$

para $i = 2$ a n . Como sólo se usa nodos interiores, las ecuaciones (18.29) y (18.30) proporcionan cada una $n - 1$ condiciones del total de $2n - 2$.

FIGURA 18.17

Notación usada para derivar segmentarias cuadráticas. Observe que hay n intervalos y $n + 1$ datos. El ejemplo mostrado es para $n = 3$.



2. Las primera y última funciones deben pasar a través de los puntos extremo. Esto agrega dos ecuaciones adicionales:

$$a_1x_0^2 + b_1x_0 + c_1 = f(x_0) \quad (18.31)$$

$$a_nx_n^2 + b_nx_n + c_n = f(x_n) \quad (18.32)$$

para un total de $2n - 2 + 2 = 2n$ condiciones.

3. Las primeras derivadas en los nodos interiores deben ser iguales. La primera derivada de la ecuación 18.28 es

$$f'(x) = 2ax + b$$

Por tanto, la condición se puede representar de manera general como

$$2a_{i-1}x_{i-1} + b_{i-1} = 2a_ix_{i-1} + b_i \quad (18.33)$$

para $i = 2$ a n . Esto proporciona otras $n - 1$ condiciones para un total de $2n + n - 1 = 3n - 1$. Como se tiene $3n$ incógnitas, se tiene una condición corta. A menos que tengamos alguna información adicional con respecto a las funciones o sus derivadas, debemos tomar una selección arbitraria para calcular de manera exitosa las constantes. Aunque hay un número de elecciones diferentes que se pueden tomar, seleccionamos la siguiente:

4. Suponga que en el primer punto la segunda derivada es cero. Como la segunda derivada de la ecuación 18.28 es $2a_i$, esta condición se puede expresar matemáticamente como

$$a_1 = 0 \quad (18.34)$$

La interpretación visual de esta condición es que los dos primeros puntos se conectarán con una línea recta.

EJEMPLO 18.9 Segmentarias cuadráticas

Enunciado del problema. Ajustar por medio de segmentarias cuadráticas los mismos datos que se usaron en el ejemplo 18.8 (véase tabla 18.1). Use los resultados para calcular el valor en $x = 5$.

Solución. Para este problema, se tienen 4 datos con $n = 3$ intervalos. Por tanto, $3(3) = 9$ incógnitas por ser determinadas. Las ecuaciones (18.29) y (18.30) dan $2(3) - 2 = 4$ condiciones:

$$20.25a_1 + 4.5b_1 + c_1 = 1.0$$

$$20.25a_2 + 4.5b_2 + c_2 = 1.0$$

$$49a_2 + 7b_2 + c_2 = 2.5$$

$$49a_3 + 7b_3 + c_3 = 2.5$$

Evaluando a las funciones primera y última en los valores inicial y final se agregan 2 ecuaciones más [véase ecuación (18.31)]:

$$9a_1 + 3b_1 + c_1 = 2.5$$

y [véase ecuación (18.32)]

$$81a_3 + 9b_3 + c_3 = 0.5$$

La continuidad de las derivadas crea un adicional de $3 - 1 = 2$ [véase ecuación (18.33)]:

$$9a_1 + b_1 = 9a_2 + b_2$$

$$14a_2 + b_2 = 14a_3 + b_3$$

Por último, la ecuación (18.34) especifica que $a_1 = 0$. Como esta ecuación especifica a_1 de manera exacta, el problema se reduce a la resolución de ocho ecuaciones simultáneas. Estas condiciones se pueden expresar en forma matricial como

$$\begin{bmatrix} 4.5 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 20.25 & 4.5 & 1 & 0 & 0 & 0 \\ 0 & 0 & 49 & 7 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 49 & 7 & 1 \\ 3 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 81 & 9 & 1 \\ 1 & 0 & -9 & -1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 14 & 1 & 0 & -14 & -1 & 0 \end{bmatrix} \begin{bmatrix} b_1 \\ c_1 \\ a_2 \\ b_2 \\ c_2 \\ a_3 \\ b_3 \\ c_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 2.5 \\ 2.5 \\ 2.5 \\ 0.5 \\ 0 \\ 0 \end{bmatrix}$$

Esas ecuaciones se pueden resolver mediante las técnicas de la parte tres, con los resultados:

$$\begin{array}{lll} a_1 = 0 & b_1 = -1 & c_1 = 5.5 \\ a_2 = 0.64 & b_2 = -6.76 & c_2 = 18.46 \\ a_3 = -1.6 & b_3 = 24.6 & c_3 = -91.3 \end{array}$$

las cuales pueden sustituirse en las ecuaciones cuadráticas originales para desarrollar la siguiente relación para cada intervalo:

$$\begin{array}{ll} f_1(x) = -x + 5.5 & 3.0 \leq x \leq 4.5 \\ f_2(x) = 0.64x^2 - 6.76x + 18.46 & 4.5 \leq x \leq 7.0 \\ f_3(x) = -1.6x^2 + 24.6x - 91.3 & 7.0 \leq x \leq 9.0 \end{array}$$

Cuando se usa f_2 , la predicción para $x = 5$ es, por tanto,

$$f_2(5) = 0.64(5)^2 - 6.76(5) + 18.46 = 0.66$$

El ajuste total por segmentarias se ilustra en la figura 18.16b. Observe que hay dos desventajas que se alejan del ajuste: 1) la línea recta que conecta los primeros dos puntos y 2) la segmentaria para el último intervalo parece oscilar demasiado. Las segmentarias cúbicas de la siguiente sección no exhiben estas desventajas y, en consecuencia, son más adecuadas para interpolación segmentaria.

18.6.3 Segmentarias cúbicas

El objetivo en las segmentarias cúbicas es obtener un polinomio de tercer orden para cada intervalo entre los nodos, como en

$$f_i(x) = a_i x^3 + b_i x^2 + c_i x + d_i \quad (18.35)$$

Así, para $n + 1$ datos ($i = 0, 1, 2, \dots, n$), existen n intervalos y, por consiguiente, $4n$ incógnitas constantes para evaluar. Como con las segmentarias cuadráticas, se requieren $4n$ condiciones para evaluar las incógnitas. Éstas son:

1. Los valores de la función deben ser iguales en los nodos interiores ($2n - 2$ condiciones).
2. La primera y última funciones deben pasar a través de los puntos extremo (2 condiciones).
3. Las primeras derivadas en los nodos interiores deben ser iguales ($n - 1$ condiciones).
4. Las segundas derivadas en los nodos interiores deben ser iguales ($n - 1$ condiciones).
5. Las segundas derivadas en los nodos extremo son cero (2 condiciones).

La interpretación visual de la condición 5 es que la función se vuelve una línea recta en los nodos extremo. La especificación de tal condición extremo nos lleva a lo que se denomina como segmentaria "natural". Se le da este nombre debido a que el dibujo segmentario se comporta en esta forma (véase figura 18.15).

Si el valor de la segunda derivada en los nodos extremo no es cero (es decir, existe alguna curvatura), esta información se puede usar de manera alterna para suministrar las dos condiciones finales.

Los cinco tipos de condiciones anteriores proporcionan un total de $4n$ ecuaciones requeridas para resolver los $4n$ coeficientes. Mientras sea ciertamente posible desarrollar segmentarias cúbicas en esta forma, presentamos una técnica alterna que requiere la solución de sólo $n - 1$ ecuaciones. Aunque la obtención de este método (véase cuadro 18.3) es algo menos directo que para las segmentarias cuadráticas, la ganancia en eficiencia bien vale el esfuerzo.

La derivación del cuadro 18.3 resulta en la siguiente ecuación cúbica para cada intervalo:

$$\begin{aligned} f_i(x) = & \frac{f_i''(x_{i-1})}{6(x_i - x_{i-1})} (x_i - x)^3 + \frac{f_i''(x_i)}{6(x_i - x_{i-1})} (x - x_{i-1})^3 \\ & + \left[\frac{f(x_{i-1})}{x_i - x_{i-1}} - \frac{f''(x_{i-1})(x_i - x_{i-1})}{6} \right] (x_i - x) \\ & + \left[\frac{f(x_i)}{x_i - x_{i-1}} - \frac{f''(x_i)(x_i - x_{i-1})}{6} \right] (x - x_{i-1}) \end{aligned} \quad (18.36)$$

Esta ecuación contiene sólo dos incógnitas (las segundas derivadas al final de cada intervalo). Esas incógnitas se pueden evaluar mediante la siguiente ecuación:

$$\begin{aligned} & (x_i - x_{i-1}) f''(x_{i-1}) + 2(x_{i+1} - x_{i-1}) f''(x_i) + (x_{i+1} - x_i) f''(x_{i+1}) \\ & = \frac{6}{x_{i+1} - x_i} [f(x_{i+1}) - f(x_i)] + \frac{6}{x_i - x_{i-1}} [f(x_{i-1}) - f(x_i)] \end{aligned} \quad (18.37)$$

Cuadro 18.3 Derivación de segmentarias cúbicas

El primer paso en la derivación (Cheney y Kincaid, 1985) se basa en la observación de cómo cada par de nodos se conecta por una cúbica, la segunda derivada dentro de cada intervalo es una línea recta. La ecuación (18.35) se puede diferenciar dos veces para verificar esta observación. Con esta base, la segunda derivada se puede representar con una interpolación polinomial de Lagrange de primer orden [véase ecuación (18.22)]:

$$f_i''(x) = f_i''(x_{i-1}) \frac{x - x_i}{x_{i-1} - x_i} + f_i''(x_i) \frac{x - x_{i-1}}{x_i - x_{i-1}} \quad (\text{B18.3.1})$$

donde $f_i''(x)$ es el valor de la segunda derivada en cualquier punto x dentro de i -ésimo intervalo. Así, esta ecuación es una línea recta que conecta la segunda derivada en el primer nodo $f''(x_{i-1})$ con la segunda derivada en el segundo nodo $f''(x_i)$.

Después, la ecuación (B18.3.1) se puede integrar dos veces para obtener una expresión para $f_i(x)$. Sin embargo, esta expresión contendrá dos constantes desconocidas de integración. Esas constantes se pueden evaluar al llamar a la función de condiciones de igualdad $f(x)$ debe ser igual a $f(x_{i-1})$ en x_{i-1} y $f(x)$ debe ser igual a $f(x_i)$ en x_i . Al realizar estas evaluaciones, resulta la siguiente ecuación cúbica:

$$f_i(x) = \frac{f_i''(x_{i-1})}{6(x_i - x_{i-1})} (x_i - x)^3 + \frac{f_i''(x_i)}{6(x_i - x_{i-1})} (x - x_{i-1})^3 + \left[\frac{f(x_{i-1})}{x_i - x_{i-1}} - \frac{f''(x_{i-1})(x_i - x_{i-1})}{6} \right] (x_i - x) + \left[\frac{f(x_i)}{x_i - x_{i-1}} - \frac{f''(x_i)(x_i - x_{i-1})}{6} \right] (x - x_{i-1}) \quad (\text{B18.3.2})$$

Ahora, es claro que esta relación es una expresión mucho más complicada para una segmentaria cúbica para el i -ésimo intervalo que, digamos, la ecuación (18.35). Sin embargo, observe que

contiene solo dos "coeficientes" desconocidos, las segundas derivadas al inicio y al final del intervalo $-f''(x_{i-1})$ y $f''(x_i)$. De esta forma, si podemos determinar la segunda derivada adecuada en cada nodo, la ecuación (B18.3.2) es un polinomial de tercer orden que se puede usar para interpolar dentro del intervalo.

Las segundas derivadas se evalúan al llamar las condiciones de que las primeras derivadas en los nodos deben ser continuas:

$$f'_{i-1}(x_i) = f'_i(x_i) \quad (\text{B18.3.3})$$

La ecuación (B18.3.2) puede diferenciarse con el fin de dar una expresión para la primera derivada. Si esto se hace tanto para el $(i-1)$ -ésimo, como para i -ésimo intervalo y los dos resultados se igualan de acuerdo con la ecuación (B18.3.3), resulta la siguiente relación:

$$\begin{aligned} & (x_i - x_{i-1})f''(x_{i-1}) + 2(x_{i+1} - x_{i-1})f''(x_i) \\ & + (x_{i+1} - x_i)f''(x_{i+1}) \\ & = \frac{6}{x_{i+1} - x_i} [f(x_{i+1}) - f(x_i)] \\ & + \frac{6}{x_i - x_{i-1}} [f(x_i) - f(x_{i-1})] \end{aligned} \quad (\text{B18.3.4})$$

Si la ecuación (B18.3.4) se escribe para todos los nodos interiores, $n-1$ ecuaciones simultáneas resultan con $n+1$ segundas derivadas desconocidas. Sin embargo, ya que ésta es una segmentaria cúbica natural, las segundas derivadas en los nodos extremo son cero y el problema se reduce a $n-1$ ecuaciones con $n-1$ incógnitas. Además, observe que el sistema de ecuaciones será tridiagonal. Así, no sólo reducimos el número de ecuaciones, sino que las forjamos en una forma que es en extremo fácil de resolver (recuerde la sección 11.1.1).

Si esta ecuación es descrita para todos los nodos interiores, resulta $n-1$ ecuaciones simultáneas con $n-1$ incógnitas. (Recuerde que las segundas derivadas en los nodos extremo son cero.) La aplicación de esas ecuaciones se ilustra en el siguiente ejemplo.

EJEMPLO 18.10 Segmentarias cúbicas

Enunciado del problema. Ajuste por segmentarias cúbicas los mismos datos que se usaron en los ejemplos 18.8 y 18.9 (véase tabla 18.1). Utilice los resultados para estimar el valor en $x = 5$.

Solución. El primer paso es emplear la ecuación (18.37) para generar un conjunto de ecuaciones simultáneas que serán utilizadas para determinar las segundas derivadas en los nodos. Por ejemplo, para el primer nodo interior se usan los siguientes datos:

$$\begin{aligned}x_0 &= 3 & f(x_0) &= 2.5 \\x_1 &= 4.5 & f(x_1) &= 1 \\x_2 &= 7 & f(x_2) &= 2.5\end{aligned}$$

Estos valores pueden sustituirse en la ecuación (18.37) para dar

$$\begin{aligned}(4.5 - 3)f''(3) + 2(7 - 3)f''(4.5) + (7 - 4.5)f''(7) \\= \frac{6}{7 - 4.5}(2.5 - 1) + \frac{6}{4.5 - 3}(2.5 - 1)\end{aligned}$$

Debido a la condición de la segmentaria natural, $f''(3) = 0$, y la ecuación se reduce a

$$8f''(4.5) + 2.5f''(7) = 9.6$$

En una forma similar, la ecuación (18.37) se aplica al segundo punto interior para obtener

$$2.5f''(4.5) + 9f''(7) = -9.6$$

Estas dos ecuaciones pueden resolverse simultáneamente para dar

$$f''(4.5) = 1.67909$$

$$f''(7) = -1.53308$$

Estos valores se sustituyen entonces en la ecuación (18.36), junto con los valores de las x y las $f(x)$, para obtener

$$\begin{aligned}f_1(x) &= \frac{1.67909}{6(4.5 - 3)}(x - 3)^3 + \frac{2.5}{4.5 - 3}(4.5 - x) \\&\quad + \left[\frac{1}{4.5 - 3} - \frac{1.67909(4.5 - 3)}{6} \right](x - 3)\end{aligned}$$

o

$$f_1(x) = 0.186566(x - 3)^3 + 1.666667(4.5 - x) + 0.246894(x - 3)$$

Esta ecuación es la segmentaria cúbica para el primer intervalo. Sustituciones similares se pueden hacer para desarrollar las ecuaciones para el segundo y tercer intervalo:

$$\begin{aligned}f_2(x) &= 0.111939(7 - x)^3 - 0.102205(x - 4.5)^3 - 0.299621(7 - x) \\&\quad + 1.638783(x - 4.5)\end{aligned}$$

y

$$f_3(x) = -0.127757(9 - x)^3 + 1.761027(9 - x) + 0.25(x - 7)$$

Se puede emplear las tres ecuaciones para calcular los valores dentro de cada intervalo. Por ejemplo, el valor en $x = 5$, el cual está dentro del segundo intervalo, se calcula como

$$f_2(5) = 0.111939(7 - 5)^3 - 0.102205(5 - 4.5)^3 - 0.299621(7 - 5) + 1.638783(5 - 4.5) = 1.102886$$

Se calculan otros valores y los resultados se grafican en la figura 18.16c.

Los resultados de los ejemplos 18.8 a 18.10 se resumen en la figura 18.16. Observe la mejora progresiva del ajuste conforme nos movemos de lineales a cuadráticas y a segmentarias cúbicas. También hemos sobrepuesto un polinomio de interpolación cúbica sobre la figura 18.16c. Aunque la segmentaria cúbica consiste en una serie de curvas de tercer orden, la resultante difiere de la obtenida al usar el polinomio de tercer orden. Esto se debe al hecho de que la segmentaria natural no requiere de segundas derivadas en los nodos extremo, mientras que el polinomio cúbico no tiene tal restricción.

18.6.4 Algoritmo de cómputo para segmentarias cúbicas

El método para calcular segmentarias cúbicas, descrito en la sección anterior, es ideal para la implementación en computadora. Recuerde que, con algunas manipulaciones inteligentes, el método se reduce a la resolución de $n - 1$ ecuaciones simultáneas. Un beneficio extra de la derivación implica, como lo especifica la ecuación (18.37), que el sistema de ecuaciones es tridiagonal. Como se describió en la sección 11.1, los algoritmos están disponibles para resolver tales sistemas en una manera en extremo eficiente. La figura 18.18 muestra una estructura computacional que incorpora esas características.

Observe que la rutina en la figura 18.18 regresa sólo un valor interpolado, y_u , para un valor dado de la variable dependiente, x_u . Ésta es sólo una forma con la cual se puede implementar la interpolación segmentaria. Por ejemplo, a usted le gustaría determinar ahora los coeficientes y después realizar muchas interpolaciones. Además, la rutina da tanto la primera derivada (dy) como la segunda (dy^2) en x_u . Aunque no es necesario calcular esas cantidades, son útiles en muchas aplicaciones de la interpolación segmentaria.

PROBLEMAS

18.1 Estime el logaritmo de 5 de base 10 ($\log 5$) mediante interpolación lineal.

- Interpole entre $\log 4 = 0.60206$ y $\log 6 = 0.7781513$.
- Interpole entre $\log 4.5 = 0.6532125$ y $\log 5.5 = 0.7403627$.

Para cada una de las interpolaciones, calcule el porcentaje de error relativo con base en el error real.

18.2 Ajuste con un polinomio de interpolación de Newton de segundo orden para estimar $\log 5$ por medio de los datos del problema 18.1. Calcule el error relativo porcentual real.

18.3 Ajuste con un polinomio de interpolación de Newton de tercer orden para estimar $\log 5$ usando los datos del problema 18.1.

18.4 Dados los datos

x	1	2	2.5	3	4	5
$f(x)$	1	5	7	8	2	1

- Calcule $f(3.4)$ mediante polinomios de interpolación de Newton de orden 1 a 3. Escoja la secuencia de puntos para su estimación con el fin de obtener la mejor exactitud posible.
- Utilice la ecuación (18.18) para estimar el error para cada predicción.

18.5 Dados los datos

SUBROUTINE Spline (x,y,n,xu,yu,dy,d2y)

LOCAL e_n, f_n, g_n, r_n, d2x_n

CALL Tridiag(x,y,n,e,f,g,r)

CALL Decomp(e,f,g,n-1)

CALL Subst(e,f,g,r,n,-1,d2x)

CALL Interpol(x,y,n,d2x,xu,yu,dy,d2y)

END Spline

SUBROUTINE Tridiag (x, y, n, e, f, g, r)

f₁ = 2 * (x₂ - x₀)

g₁ = (x₂ - x₁)

r₁ = 6 / (x₂ - x₁) * (y₂ - y₁)

r₁ = r₁ + 6 / (x₁ - x₀) * (y₀ - y₁)

DO i = 2, n - 2

e_i = (x_i - x_{i-1})

f_i = 2 * (x_{i+1} - x_{i-1})

g_i = (x_{i+1} - x_i)

r_i = 6 / (x_{i+1} - x_i) * (y_{i+1} - y_i)

r_i = r_i + 6 / (x_i - x_{i-1}) * (y_{i-1} - y_i)

END DO

e_{n-1} = (x_{n-1} - x_{n-2})

f_{n-1} = 2 * (x_n - x_{n-2})

r_{n-1} = 6 / (x_n - x_{n-1}) * (y_n - y_{n-1})

r_{n-1} = r_{n-1} + 6 / (x_{n-1} - x_{n-2}) * (y_{n-2} - y_{n-1})

END Tridiag

SUBROUTINE Interpol (x,y,n,d2x,xu,yu,dy,d2y)

flag = 0

i = 1

DO

IF xu ≥ x_{i-1} AND xu ≤ x_i THEN

c1 = d2x_{i-1} / 6 / (x_i - x_{i-1})

c2 = d2x_i / 6 / (x_i - x_{i-1})

c3 = (y_{i-1} / (x_i - x_{i-1}) - d2x_{i-1} * (x_i - x_{i-1}) / 6

c4 = (y_i / (x_i - x_{i-1}) - d2x_i * (x_i - x_{i-1}) / 6

t1 = c1 * (x_i - xu)³

t2 = c2 * (xu - x_{i-1})³

t3 = c3 * (x_i - xu)

t4 = c4 * (xu - x_{i-1})

yu = t1 + t2 + t3 + t4

t1 = -3 * c1 * (x_i - xu)²

t2 = 3 * c2 * (xu - x_{i-1})²

t3 = -c3

t4 = c4

dy = t1 + t2 + t3 + t4

t1 = 6 * c1 * (x_i - xu)

t2 = 6 * c2 * (xu - x_{i-1})

d2y = t1 + t2

flag = 1

ELSE

i = i + 1

END IF

IF i = n + 1 OR flag = 1 EXIT

END DO

IF flag = 0 THEN

PRINT "outside range"

pause

END IF

END Interpol

FIGURA 18.18

Algoritmo para interpolación segmentaria cúbica.

x	1	2	3	5	6
$f(x)$	4.75	4	5.25	19.75	36

Calcule $f(4)$ usando polinomios de interpolación de Newton de orden 1 a 4. Escoja sus puntos base para obtener una buena exactitud. ¿Qué le indican los resultados con respecto al orden que se usó de los polinomios para generar los datos en la tabla?

18.6 Repita los problemas 18.1 hasta 18.3 mediante polinomios de Lagrange.

18.7 Repita el problema 18.5 usando el polinomio de Lagrange de orden 1 a 3.

18.8 Emplee interpolación inversa usando interpolación de polinomios cúbica y bisección para determinar el valor de x que corresponda a $f(x) = 0.3$ para los siguientes datos tabulados,

x	1	2	3	4	5	6	7
$f(x)$	1	0.5	0.3333	0.25	0.2	0.1667	0.1429

18.9 Emplee interpolación inversa para determinar el valor de x que corresponda a $f(x) = 0.93$ para los siguientes datos tabulados,

x	0	1	2	3	4	5
$f(x)$	0	0.5	0.8	0.9	0.941176	0.961538

Observe que los valores en la tabla fueron generados con la función $f(x) = x^2/(1 + x^2)$.

- Determine en forma analítica el valor correcto.
- Use interpolación cuadrática y la fórmula cuadrática para determinar numéricamente el valor.
- Use interpolación cúbica y bisección para determinar el valor de manera numérica.

18.10 Desarrolle segmentarias cuadráticas para los primeros 5 datos en el problema 18.4 y prediga $f(3.4)$ y $f(2.2)$.

18.11 Desarrolle segmentarias cúbicas para los datos en el problema 18.5, y a) prediga $f(4)$ y $f(2.5)$ y b) verifique que $f_2(3)$ y $f_3(3) = 5.25$.

18.12 Determine los coeficientes de la parábola que pasa a través de los tres últimos puntos del problema 18.4.

18.13 Determine los coeficientes de la ecuación cúbica que pasa a través de los primeros cuatro puntos del problema 18.5.

18.14 Desarrolle, depure y pruebe un programa de prueba en un lenguaje de alto nivel o un lenguaje macro de su elección para

implementar interpolación de polinomios de Newton con base en la figura 18.7.

18.15 Pruebe el programa que desarrolló en el problema 18.14 para los mismos cálculos del ejemplo 18.5.

18.16 Use el programa que desarrolló en el problema 18.14 para resolver los problemas 18.1 hasta 18.3.

18.17 Use el programa que desarrolló en el problema 18.14 para resolver los problemas 18.4 y 18.5. En el problema 18.4, utilice todos los datos para desarrollar polinomios de primer orden al quinto. Para ambos problemas, grafique el error estimado contra el orden.

18.18 Desarrolle, depure y pruebe un subprograma en lenguajes de alto nivel o en un lenguaje macro de su elección para implementar interpolación de Lagrange. Con base en el pseudocódigo de la figura 18.11. Pruébalo con los mismos datos del ejemplo 18.7.

18.19 Una aplicación útil de la interpolación de Lagrange es llamada *tabla de consulta*. Como su nombre lo implica, ésta involucra "consultar" un valor intermedio de la tabla. Para desarrollar un algoritmo como tal, la tabla de x y los valores de $f(x)$ se guardan primero en un par de arreglos unidimensionales. Esos valores se pasan entonces a una función junto con el valor de x que usted quiera evaluar. La función entonces ejecuta dos tareas. Primero, va por la tabla hasta que encuentra el intervalo dentro del cual está la incógnita. Después se aplica una técnica como la interpolación de Lagrange para determinar el valor adecuado de $f(x)$. Desarrolle tal función usando un polinomio de Lagrange cúbico para realizar la interpolación. Para valores intermedios es una excelente selección, ya que la incógnita estará ubicada en el intervalo medio de los cuatro puntos necesarios para generar la cúbica. Sea cuidadoso con los intervalos primero y último donde éste no es el caso. También tenga su código para detectar cuándo requiere el usuario un valor fuera del rango de las x . Para tales casos, la función debería mostrar un error de mensaje. Pruebe su programa para $f(x) = \ln x$ mediante datos desde $x = 0, 1, 2, \dots, 10$.

18.20 Desarrolle, depure y pruebe un subprograma en un lenguaje de alto nivel o un lenguaje macro de su elección para implementar interpolación segmentaria cúbica con base en la figura 18.18. Pruebe el programa con los mismos datos del ejemplo 18.10.

18.21 Use el software que desarrolló en el problema 18.20 para ajustar segmentarias cúbicas a través de los datos en los problemas 18.4 y 18.5. Para ambos casos, prediga $f(2.25)$.

CAPÍTULO 19


Aproximación de Fourier

Hasta aquí, nuestra representación de interpolación ha enfatizado los polinomios estándar (es decir, combinaciones de los monomios $1, x, x^2, \dots, x^m$ (véase figura 19.1a). Ahora veremos otra clase de funciones que son de mucha importancia en la ingeniería. Éstas son las funciones trigonométricas $1, \cos x, \cos 2x, \dots, \cos nx, \sin x, \sin 2x, \dots, \sin nx$ (figura 19.1b).

Los ingenieros con frecuencia tratan con sistemas que oscilan o vibran. Como podría esperarse, las funciones trigonométricas juegan un papel importante en el modelado de tales problemas en contexto. La aproximación de Fourier representa un esquema sistemático al usar series trigonométricas para este propósito.

FIGURA 19.1

Los primeros cinco
a) monomios y b) funciones
trigonométricas. Observe
que para los intervalos
mostrados, ambos tipos de
función tienen un valor de
rango entre -1 y 1 . Sin
embargo, note que los
valores pico para los
monomios ocurren todos en
los extremos, mientras que
para las funciones
trigonométricas los picos
están más uniformemente
distribuidos a través del
intervalo.



Una de las características de un análisis de Fourier es que trata con ambos dominios: el tiempo y la frecuencia. Como algunos ingenieros no se sienten muy cómodos con el último, se ha desarrollado una larga fracción del material subsecuente para una revisión general de la aproximación de Fourier. Un aspecto importante de esta revisión será familiarizarse con el dominio de la frecuencia. Esta orientación es después seguida por una introducción a los métodos numéricos para calcular transformadas de Fourier discretas.


19.1 AJUSTE DE CURVAS CON FUNCIONES SINUSOIDALES

Una función periódica $f(t)$ es una para la cual

$$f(t) = f(t + T) \quad (19.1)$$

FIGURA 19.2

Además de las funciones trigonométricas tales como senos y cosenos, las funciones periódicas incluyen formas de onda como la son a) la onda cuadrada y b) la onda de dientes de sierra. Más allá de estas formas idealizadas, las señales periódicas en naturaleza pueden ser c) no ideales y d) contaminadas por ruido. Las funciones trigonométricas se pueden usar para representar y analizar todos estos casos.



donde T es una constante llamada periodo, que es el valor más pequeño para el cual es válida la ecuación (19.1). Ejemplos comunes incluyen formas en onda tales como cuadradas y dientes de sierra (véase figura 19.2). Las más fundamentales son las funciones sinusoidales.

En el presente análisis se usará el término *sinusoide* para representar cualquier forma de onda que se pueda describir como un seno o coseno. No existe una convención muy clara para escoger alguna función, y en cualquier caso, los resultados serán idénticos. Para este capítulo se usará el coseno, el cual se puede expresar de manera general como

$$f(t) = A_0 + C_1 \cos(\omega_0 t + \theta) \quad (19.2)$$

Así, cuatro parámetros sirven para caracterizar el sinusoide (véase figura 19.3). El *valor medio* A_0 , ajusta la altura promedio por arriba de la abscisa. La *amplitud* C_1 especifica la

FIGURA 19.3

a) Una gráfica de la función sinusoidal $y(t) = A_0 + C_1 \cos(\omega_0 t + \theta)$. Para este caso, $A_0 = 1.7$, $C_1 = 1$, $\omega_0 = 2\pi/T = 2\pi/(1.5 \text{ s})$, y $\theta = \pi/3$ radianes $= 1.0472$ ($\approx 0.25 \text{ s}$). Otros parámetros usados para describir la curva son la frecuencia $f = \omega_0/(2\pi)$, la cual para este caso es 1 ciclo/(1.5 s), y el periodo $T = 1.5 \text{ s}$. b) Una expresión alterna para la misma curva es $y(t) = A_0 + A_1 \cos(\omega_0 t) + B_1 \sin(\omega_0 t)$. Los tres componentes de esta función son ilustrados en b), donde $A_1 = 0.5$ y $B_1 = -0.866$. La sumatoria de las tres curvas en b) da la curva simple en a).

