

Data Warehousing

Introducción

El fin del siglo XX y el comienzo del siglo XXI encuentra a las empresas frente a un escenario en que la competencia es fenomenal (producto de la globalización) y en el que los negocios necesitan apoyarse indefectiblemente en técnicas y metodologías que los conduzcan simultáneamente al incremento de sus dividendos, junto con un mejor servicio al cliente y un buen posicionamiento en el mercado.

Estos objetivos revitalizan y potencian la importancia de la información como recurso básico para el desarrollo competitivo de las empresas. Una de las preocupaciones principales de los directivos de esta época es cómo lograr la coherencia y compatibilidad entre las metas corporativas y las de los sistemas de información. Entre éstas, se destaca lograr la mayor utilidad de la información disponible. Obsérvese que hemos mencionado “disponible”: el hecho de que una empresa mantenga almacenados millones de datos en sus bases de datos operacionales no significa que aquellos que son necesarios para una decisión se encuentren disponibles en el momento y en condiciones de ser utilizados para tal fin. Los *mainframes* (computadores de gran porte) fueron concebidos en su momento como “cárceles de datos” que procuraban eficientización de captura de datos, en lugar de distribución de información. Las bases de datos han sido construidas en sus versiones originales para satisfacer fundamentalmente las necesidades de información al ejecutar las operaciones cotidianas de las empresas (transacciones); el énfasis en su construcción se centró en la eficiencia del procesamiento (recuperación y actualización con facilidad), en la eliminación de redundancia de datos y en la centralización de la administración de los datos (seguridad, control de acceso, niveles de autorización para actualizaciones o modificaciones). Estas funciones integran el tipo de procesamiento denominado OLTP (*On – Line – Transaction – Processing*, Procesamiento de transacciones en línea).

A diferencia de las bases de datos operacionales, el *Data Warehouse* reúne información de varias fuentes. Esta recopilación opera a través del tiempo y almacena en un único lugar la información generada en distintos momentos por distintas aplicaciones de software (que a su vez han utilizado distintas tecnologías de almacenamiento y variadas técnicas de gestión de bases de datos).

Además, el nivel de detalle que presentan los datos en las bases tradicionales suele no ser adecuado para apoyar la toma de decisiones. El *Data Warehouse*, por lo tanto, debe reunir esos datos y asociar otros, para presentar la información de forma tal que sirva como soporte de decisiones. El impacto sobre las ventas será más relevante si, explotando las tendencias del mercado, se logra conocer mejor el camino para mejorar el diseño del producto y el servicio a los clientes.

Parte de la información que utiliza el *Data Warehouse* proviene de datos históricos contenidos en las bases de datos operacionales, que habitualmente se eliminan de éstas por no resultar necesarias para las aplicaciones transaccionales. Por lo tanto, el volumen de información contenida en un *Data Warehouse* es mayor que en las bases de datos operacionales, debido a que la primera debe contener información histórica además de los datos actuales.

Desde el punto de vista tecnológico, y en razón de la magnitud de la información que debe administrar, un *Data Warehouse* almacena esa información en varios medios de almacenamiento.

Concepto de *Data Warehousing*

Debemos ver al *Data Warehousing* como una tecnología: su propósito es reunir información de distintas fuentes y efectuar un proceso de implementación de un proyecto de *Data Warehouse*.

De acuerdo con la definición de W.H. Inmon¹ – creador del concepto – “un Data Warehouse es un conjunto de datos integrados orientados a una materia, que varían con el tiempo y que no son transitorios, los cuales soportan el proceso de toma de decisiones de una administración”.

Resumiendo conceptos extraídos de la bibliografía especializada, podemos destacar las siguientes características que ayudan a describir y comprender **qué es un *Data Warehouse***.

- Es un depósito de datos, independientes de los sistemas operativos y de las aplicaciones existentes, que satisfacen diversos requerimientos.
- Es una forma de arquitectura de estructura de datos.

¹ Inmon, W. *Building the Data Warehouse*, QED Technical Publishing Group, 1992.

- Es un proceso que utiliza datos provenientes de diversas fuentes, algunas internas y otras externas, y que permite atender consultas para toma de decisiones.
- Los datos contenidos en un *Data Warehouse* constituyen la historia detallada de los negocios de la empresa y su relación con los clientes. Las empresas que sepan aprovechar esos recursos estarán mejor posicionadas para lograr ventajas competitivas.
- Un *Data Warehouse* es un sistema de aplicación empresarial que contiene su propia base de datos.
- La construcción y desarrollo de un *Data Warehouse* exitoso requiere la integración de varios componentes de tecnología y la habilidad para hacerlos funcionar todos juntos.
- La finalidad de un *Data Warehouse* consiste en ayudar al usuario empresarial a conocer el pasado y planear el futuro.

Usos y aplicaciones de un *Data Warehouse*

Los usos y aplicaciones de un *Data Warehouse* dependen del tipo de necesidad y capacidad creativa para decidir qué poseen los usuarios de información. Un *Data Warehouse* no se compra: se lo **construye**. (En todo caso se compran las herramientas para construirlo). La figura 18.1 muestra las funciones y aplicaciones en las que puede participar un *Data Warehouse*.




Figura 18.1 Funciones y aplicaciones de un *Data Warehouse*

Las bases para el desarrollo de un *Data Warehouse*

Es lógico pensar que la construcción y despliegue de un *Data Warehouse* requiere aplicar tecnologías avanzadas que utilicen herramientas (productos de software) de última generación.

Pero además del enfoque tecnológico es fundamental destacar el enfoque empresarial (aplicación de técnicas empresariales).

El enfoque empresarial parte de la necesidad de determinar los requerimientos corporativos y traducirlos en consultas que puedan ser respondidas a través del *Data Warehouse*. Para ello el *Data Warehouse* conserva información histórica y actual sobre un negocio, lo cual permite la recuperación de datos que, bajo la forma de informes, facilita el descubrimiento y la comprensión de patrones de comportamiento (explotación de tendencias) y de tendencias desde donde se derivan conclusiones o recomendaciones para los futuros cursos de acción.

Construcción de un *Data Warehouse*

El mercado de software ofrece una gran variedad de “soluciones informáticas” destinadas a satisfacer distintos tipos de requerimientos de herramientas que faciliten la disposición de información por parte de empresarios y de analistas corporativos para la toma de decisiones o seguimiento de cursos de acción.

Pero estas “soluciones” (paquetes de software) deben ser aplicadas sobre una base de datos que esté preparada para apoyar tales procedimientos. Esta base de datos específica es un *Data Warehouse*. El *Data Warehouse* se genera a partir de otras bases de datos operacionales, y debe estar capacitada para enlazarse con otros procesos fuera de su ámbito. El *Data Warehouse* almacena información resumida que se estructura en función de temas empresariales; por ejemplo, referidos a clientes y productos. De acuerdo con éstos, el

Data Warehouse resultará útil en la medida que se apliquen con inteligencia herramientas de análisis sobre los datos almacenados en el mismo. Esa utilidad será distribuida entre un amplio rango de usuarios empresariales. Para ello deberá emplearse tecnología que efectúe los procesos necesarios para trasladar información desde su base de datos operacional al almacenamiento que requiere el *Data Warehouse*.

La construcción de un *Data Warehouse* requiere la presencia de una **arquitectura** (arquitectura es el arte de crear) que identifique e integre los distintos componentes (bloques⁹ de las denominadas “soluciones informáticas”. Para ello es necesario formular un diagrama conceptual al que H.S. Grill y P.C. Rao² denominan **arquitectura de referencia**. Este diagrama constituye la base para construir un *Data Warehouse*. En la figura 18.2 se presenta una descripción gráfica que intenta mostrar un marco general de un *Data Warehouse* y de los componentes que lo integran.




Figura 18.2 Elementos componentes de un Data Warehouse

Obsérvese en la figura la presencia de cuatro bloques: **Fuentes de datos (1)**; **Data Warehouse (2)**; **Data Mart (3)**; **Uso de Información (4)** y de tres capas: **Aplicaciones (A)**; **Infraestructura operativa (B)** e **Infraestructura Técnica (C)**. Los bloques representan funciones atinentes al *Data Warehouse*; las capas horizontales se refieren al ambiente en el que se apoyan los bloques para implementar el *Data Warehouse*.

Recuérdese que el objetivo fundamental en la construcción de un *Data Warehouse* es **transformar datos en conocimiento**. Para ello es necesario ensamblar datos existentes en distintas fuentes (bloque 1) siguiendo instrucciones precisas para obtener un resultado, que es un conjunto de datos analíticos que queda almacenado en un depósito especial que es el *Data Warehouse* (bloque 2) o el *Data Mart* (bloque 3), a efectos de que los usuarios finales puedan acceder con facilidad a estos últimos para utilizar su contenido y, en consecuencia, obtener **conocimiento** (bloque 4). En razón de que en reiteradas oportunidades se menciona la utilización del concepto de **metadatos** daremos previamente una explicación de su significado.

Un **metadato** es información que describe un dato. Es un contexto de *Data Warehouse* el **metadato** contiene información que define los datos de las fuentes, precisando su semántica, su origen, su formato, su contenido, la fecha en que fue creado y las reglas de gestión asociadas.

Podría simbolizarse un **metadato** como un mapa de ruta hacia un dato: hace referencia a la ubicación del dato (cómo llegar a él) y al contenido de la información asociada al dato. Ampliando la definición sintética que describimos más arriba, podemos agregar que los **metadatos** abarcan todos los aspectos relacionados con el *Data Warehouse* y son necesarios como apoyo de sus elementos componentes.

Los **metadatos** cumplen las siguientes finalidades:

- Permiten ubicar diferente tipo de información contenida en el *Data Warehouse*:
 - o Área tema.
 - o Nombres y alias definidos por el usuario final.
 - o Servidores.
 - o Bases de datos.
 - o Tablas.
 - o Índices.

La ubicación interesa a quienes hacen uso de aplicaciones empresariales; también a quienes elaboran programas que utilizan el contenido del *Data Warehouse*.

² Gill, Harjinder S. y Rao, Prakash, *Data Warehousing. La integración de información para la mejor toma de decisiones*, Prentice Hall Hispanoamericana, México, 1996, p. 29.

- Mantienen información sobre los mecanismos por los cuales se extraen datos de las bases operacionales y se transfieren al *Data Warehouse*, debiendo efectuar modificaciones de dimensión o de formato, establecer parámetros o rangos de valores, aplicar reglas para salvar la inconsistencia entre datos almacenados en las fuentes operacionales, etcétera.
- Se vinculan con las reglas que determinan los controles de acceso y las condiciones de seguridad.
- Contienen reglas y procedimientos definidos por el usuario final (por ejemplo, algoritmos de resumen). Definen la forma en que un tipo de información (por ejemplo, un resumen) deriva de otra información (datos de detalle). Incorporan una dimensión de tiempo a los datos históricos: estos agruparán por año o períodos menores, conforme a la necesidad de análisis.
- Deben mantenerse registros sobre la fecha de su creación a efectos de permitir posteriores análisis de evolución histórica. También deben administrar los criterios que se hayan definido con respecto a período de permanencia de los datos y momentos de depuración.

Luego de aclarar el concepto de **metadato** y de señalar sus principales funciones, se analiza a continuación el significado de los componentes de la figura 18.2 y la participación de los **metadatos** con relación a los mismos.

El bloque (1) **Fuentes de datos** comprende los siguientes elementos:

- **Bases operacionales de datos:** contienen datos provenientes de aplicaciones de transacciones habituales de la empresa.
- **Datos de herencia:** son datos no necesarios para ejecutar procesos de operaciones actuales, pero que resultan importantes por su valor histórico; deben, por lo tanto, ser incorporados al *Data Warehouse*, incluyendo la fecha de su vigencia.
- **Fuentes externas:** se refiere a datos que interesan con relación a la materia a la que se orienta el *Data Warehousing*, pero que deben ser obtenidos fuera de la empresa, tales como aquellos datos que surgen de informes de organismos especializados en temas financieros, bursátiles, de investigación del mercado, etc., y que por lo tanto deben ser adquiridos.

En este bloque de Fuentes de datos los **metadatos** para las fuentes contienen la información sobre los datos de las fuentes.

El bloque (2) *Data Warehouse* se compone con los siguientes elementos³:

- Componentes de **Refinamiento:** sus funciones son estandarizar los datos, filtrar y pulir, registrar la fecha de la fuente de datos y verificar la calidad de los datos. Los **metadatos** de este componente contiene los nombres de los datos estándar, la fecha de los datos seleccionados y la fuente de los mismos.
- Componentes de **Reingeniería:** sus funciones se orientan a exponer los datos de tal forma que puedan servir en el nivel de análisis adecuado a los requerimientos del usuario final. Esto significa desarrollar las siguientes actividades:
 - Integrar datos que provienen de distintas aplicaciones y exponerlos de manera diferente.
 - Separar datos en distintas magnitudes de tiempo, o bien, segmentarlos en función de las distintas unidades de negocios o por regiones geográficas.
 - Resumir información en base a reglas previamente definidas (determinar qué campos se debe totalizar, cómo se integra el total, en dónde se debe almacenar el total). Este proceso de resumen produce el agregado de nuevos campos en el *Data Warehouse*, para albergar los totales resultantes. Además, las reglas predeterminadas para la acumulación significan una especificación que también deben almacenarse como metadato dentro del *Data Warehouse*.
 - Incorporar campos adicionales al *Data Warehouse* para almacenar datos resultantes de cálculos automáticos que se efectúan sobre datos de campos existentes. Las reglas para ejecutar esos cálculos deben manejarse como metadatos dentro del *Data Warehouse*.
 - Hacer consistentes aquellos datos que provienen de diferentes fuentes y que requieren, por lo tanto, un proceso de reformulación de su formato.
- Componentes de **Generación de Data Warehouse:**
Sus funciones son:
 - Modelar la información en el *Data Warehouse*. El modelo de datos del *Data Warehouse* deriva del modelo de datos de la empresa.

³ Gill, H.S. y Rao, P.C., Ibid., p. 32.

- Condensar (reducir) la información voluminosa en magnitudes manejables.

Los **metadatos** del *Data Warehouse* participan en la descripción de la base de datos, en las rutas y reglas de navegación del *Data Warehouse* y en el glosario empresarial.

El bloque (3) *Data Mart*⁴ representa una implementación de *Data Warehouse* pero referida a un ámbito de datos y funciones más limitado. Puede tener como usuario a un único departamento dentro de la corporación.

Las organizaciones empresariales pueden disponer de un *Data Warehouse* y opcionalmente de una o varias *Data Mart*. También puede ocurrir que las corporaciones implementen varias *Data Mart* sin estructurar un *Data Warehouse*.

En las organizaciones donde conviven el *Data Warehouse* y el *Data Mart*, éste último opera a partir del contenido del primero.

Los componentes para construir un *Data Mart* son similares a los del *Data Warehouse*. **Refinamiento y reingeniería**. Cuando la información para construir el *Data Mart* surge del *Data Warehouse*, las actividades de refinamiento y reingeniería se aplican a la filtración y ajuste de esa información, a la generación de nuevos resúmenes y a la asignación de fechas a los nuevos datos generados.

En el futuro se espera obtener una mejor respuesta a consultas al *Data Warehouse*, cuando se logre integrar el Sistema de Gestión de Base de Datos (componente básico de soporte de almacenamiento) con los nuevos tipos de datos, en forma tal de almacenar y administrar estructuras multimedia integradas por documentos, sonidos, imágenes, etc.⁵. Por su parte, la evolución de Internet aportará un nuevo valor a estas técnicas enriqueciendo sus resultados y mejorando los procesos de tomas de decisiones.

El bloque (4) **Uso de Información** se compone de dos elementos⁶:

- **Acceso y Recuperación**: el acceso puede ser directo al *Data Warehouse* sin pasar por el *Data Mart*, o bien directo al *Data Mart*. Una función fundamental de este elemento es la de transformar los datos extraídos en “vistas multidimensionales”, o bien, almacenarlos en una base de datos multidimensional y mantenerlos reservados para disponer de ellos en un análisis posterior. El concepto de **multidimensión** es importante en el tratamiento de un *Data Warehouse*. Una **dimensión** es un eje de análisis que corresponde normalmente a los temas de interés del *Data Warehouse*, tales como dimensión temporal, dimensión cliente, dimensión productos, dimensión geográfica (o territorio).

En la actualidad, las empresas deben enfrentar el desafío de la globalización y de la competitividad. Por lo tanto, deben buscar formas de reducir costos y descubrir nuevas oportunidades y nichos de mercado, para colocar sus productos diferenciados y mejorar la satisfacción del cliente. Todo esto es muy difícil de lograr. Pero este desafío encuentra respuesta en algunas técnicas modernas como las que estamos analizando. Para ello es necesario un análisis e interpretación de los datos desde varias perspectivas: se trata de un análisis **multidimensional**. A través del análisis multidimensional los datos se representan mediante dimensiones, tales como cliente, producto, territorio, tiempo. Cada dimensión tiene componentes que integran una jerarquía bajo la forma de país, región, provincia, ciudad.

El análisis multidimensional permite analizar muchos datos empresariales que se relacionan entre sí. Así, un usuario podría consultar (y obtener respuesta) respecto del volumen de ventas en el primer trimestre del año o de un conjunto determinado de productos de las sucursales del norte. Aquí las dimensiones (múltiples) son: territorio (sucursales del norte), producto (un conjunto determinado) y tiempo (primer trimestre del año). El sistema prevé la posibilidad de modificar los ejes del análisis (para examinar desde distintas perspectivas) y además, navegar por las dimensiones, avanzado a través de las mismas para profundizar en niveles cada vez más detallados de datos, o bien, ascendiendo a niveles superiores de datos resumidos (consolidados). Los metadatos, dentro de este componente, proporcionan una ruta de navegación para consultas y herramientas de profundización en detalles.

⁴ *Data Mart* es un subconjunto de los datos empresariales orientado hacia un conjunto menor de usuarios o funciones de negocios.

⁵ Franco, Jean Michel, *El Data Warehouse. El Data Mining*, Ediciones Gestión 2000, Barcelona, p. 39.

⁶ Gill, H. S. y Rao, P. C., ob. Cit., pp. 36-37.

- **Análisis y Reporte:** Este componente se encarga del manejo de las herramientas que obtienen resultados del *Data Warehouse* y del *Data Mart* (son herramientas para informes y soporte de decisiones). Los metadatos, dentro del componente de Análisis y Reporte, almacenan los informes y consultas predefinidos. De manera que el usuario puede recuperar esos elementos a través de los metadatos que los generan.

La capa de **Aplicaciones** de la figura 18.2 se refiere a las distintas partes (iniciativas o aplicaciones) en que se descompone cada tema tratado en el *Data Warehouse*. Una iniciativa es un proyecto de decisión que se incorpora (en forma iterativa) en la construcción de un *Data Warehouse*. Las aplicaciones deben ser definidas en cuanto a objetivos, frecuencia y periodicidad de los análisis.

La capa **Infraestructura y Administración de Datos** soporta a los componentes (bloques) descriptos más arriba, y sobre ella se apoyan las aplicaciones de decisión. La infraestructura se presenta en dos niveles: un nivel **técnico**, que comprende a los productos (programas) que instalan las tecnologías que se aplican, y un nivel **operativo**, que se refiere a los procedimientos para administrar los datos y utilizar el sistema.

Las actividades concernientes a la **administración de los datos**, comprenden las tareas de extracción de datos seleccionados y su posterior proceso de refinamiento y reingeniería e incorporación en el *Data Warehouse*. También se requieren actividades referentes a la administración de metadatos, que consisten en la administración de los metadatos que utiliza el *Data Warehouse* (por ejemplo, la descripción de los datos almacenados, sus definiciones estándar, las áreas tema, los campos de condensación (resumen), la descripción de consultas predefinidas). Para desarrollar y luego desplegar el *Data Warehouse* también es necesario transportar datos a través de los bloques; este proceso requiere redes de transferencia y esquemas de seguridad y autenticación.

Metodología para construir un *Data Warehouse*

Los pasos para definir, construir y utilizar un *Data Warehouse* son similares a los que integran la metodología de desarrollo de ciclo de vida de sistemas de información. Sin embargo, debemos recordar una afirmación comentada en esta unidad: el *Data Warehouse* **no se compra; se construye**. Ahora bien; la construcción debe ser efectuada partiendo de componentes (productos de software) que se comercializan, es decir, aquellos que se venden en el mercado de software.

El desafío para los consultores y analistas en tecnología informática radica en diseñar una arquitectura que actúe como referencia (sería como el plano de un edificio), y a partir de ahí investigar y seleccionar aquellos productos ofrecidos por los fabricantes de software que mejor se adecuen a esa arquitectura.

La figura 18.3 muestra cómo la arquitectura propuesta surge como resultado de determinar los requerimientos empresariales. Una vez diseñada la arquitectura del *Data Warehouse* y contemplado los estándares y políticas de gestión del procesamiento de información en la empresa, se podrán seleccionar los productos (componentes) que mejor satisfagan los requerimientos técnicos del *Data Warehouse*.




Figura 18.3 Arquitectura propuesta para la construcción de *Data Warehouse*

Una metodología para construir un *Data Warehouse* comenzará, como es natural para todo proyecto, con un **planeamiento**. El desarrollo de esta etapa dependerá del nivel de madurez (grado de tecnificación) de su infraestructura tecnológica y nivel de experiencia en gestión de procesamiento informático. En una situación de madurez razonable se aplicará un enfoque de implementación *top-down*, en el que se considera primero los requerimientos empresariales a los que debe atender el *Data Warehouse* proyectado. Cuando el grado de madurez de la organización en desarrollo tecnológico no esté aún avanzando, es preferible adoptar una

estrategia de implementación *botton-up* (de abajo hacia arriba), es decir, de lo particular a lo general: comenzando con una parte del conjunto de requerimientos empresariales.

En todo planeamiento no puede faltar la consideración de un estudio de factibilidad económica. La estimación del costo de implementación del *Data Warehouse* es fundamental como base para la determinación del ROI (*Return on Investment*, Retorno de la inversión) que arrojará el proyecto. Una forma de estimar el costo, a nivel de detalle, es partiendo de la arquitectura de referencia (figura 18.2) e intentando costear entre las distintas opciones que ofrece el mercado y los distintos componentes en forma individual: Fuentes de Datos, *Data Warehouse*, *Data Mart*, Gestión de Acceso, Administración de Datos, Infraestructura. Con respecto a los beneficios que compensarán estos costos y ayudarán al retorno de la inversión, debe considerarse el impacto del *Data Warehouse* en cuanto a aprovechamiento de oportunidades, mejor identificación de necesidades del cliente, conservación de la cartera de clientes frente a los embates de la competencia y generación de nuevos ingresos.

Otros aspectos que deben ser objeto de planeamiento es la determinación del destino (o destinatarios) de la información contenida en el *Data Warehouse* proyectado; es decir, definir sus usuarios (unidades de negocios, sectores, departamentos, estaciones de trabajo, etc.) y la dimensión del metamodelo del *Data Warehouse*. El metamodelo es el modelo que contiene la definición de los datos del *Data Warehouse*⁷.

Otra decisión que también debe formar parte del proceso de planeamiento consiste en determinar si el proyecto incluye la implementación de solamente un *Data Warehouse*, un *Data Warehouse* acompañado de uno o varios *Data Mart*, o bien, solamente *Data Mart* (uno o varios). En el primer caso se trataría de una arquitectura que centralice en un *Data Warehouse* se alimente a todos los usuarios.

La segunda etapa de la metodología que aquí se describe se refiere a la determinación de las **Funciones** que debe satisfacer el *Data Warehouse*. Estas funciones dependerán de las expectativas de los distintos sujetos asociados de alguna manera a un *Data Warehouse*. Para definir las funciones en esta etapa, deben especificarse los siguientes aspectos:

- **Desde la perspectiva del empresario:**
 - Objetivos empresariales.
 - Destinatarios de la información.
 - Identificación de áreas tema: mercados, ventas, pedidos, dimensión tiempo.
 - Nivel de detalle de la información que podrá suministrar el *Data Warehouse*: desagregación de datos, resumen y adición.
- **Desde la perspectiva de la tecnología:**
 - Identificación de elementos de datos y sus relaciones, y de los metadatos contenidos en los bloques de la figura 18.2.
 - Definición de las funciones de aplicaciones.
 - Determinación del lenguaje de programación, del acceso al sistema de administración de bases de datos y del acceso a los protocolos de comunicación.
 - Determinación de la tecnología aplicable en cada uno de los bloques contenidos en la figura 18.2: Fuentes de Datos, *Data Warehouse*, *Data Mart*, acceso a usuario final.
- **Desde la perspectiva del usuario final:**
 - Tipo de consultas que pueden obtener respuesta a través de un *Data Warehouse*.
Ejemplos:
 - Determinar cuáles fueron los cinco mayores clientes por volumen de venta de la unidad de negocios “electrodomésticos” en el primer trimestre de este año.
 - Detectar cuál fue el producto que dejó mayores ingresos durante el año anterior en la región norte.
 - Identificar cuáles son los medios de transporte que prefieren nuestros clientes para el envío de nuestros productos.
 - Posibilidades de aumentar la profundización del nivel de detalle de los datos.
 - Posibilidades de aplicar ***Data Mining*** (identificar modelos o patrones ocultos del comportamiento de datos).

La tercera etapa de la metodología es de **Análisis**. Esta etapa consiste en transformar los requerimientos de funciones formulados en la etapa anterior en una forma de definiciones (modelos lógicos o metamodelos que

⁷ Gill, H.S. y Rao, P.C., Ibid., p.87.

describan los mecanismos de conexión entre los bloques de fuentes de datos *Data Warehouse*, *Data Mart* y medios de acceso del usuario final), a partir de las cuales se podrá encarar el **Diseño** (cuarta etapa) del *Data Warehouse*.

La etapa de **Diseño** se ocupa de transformar los modelos lógicos en modelos físicos. Esto se consigue mediante la definición de **especificaciones** para los programas de computación, que serán en definitiva los que ejecuten los procesos.

La quinta etapa es la de **Construcción**. Se trata aquí de ensamblar los distintos componentes diseñados físicamente en la etapa anterior, debiéndose cumplir previamente algunos requisitos fundamentales:

- Decidir qué componentes elaborar internamente y cuáles adquirir ya confeccionados.
- Investigar el mercado de oferta de componentes (productos de software) y seleccionar los que se consideraban más apropiados para el proyecto en desarrollo (el diagrama de la figura 18.2 ayuda a estos fines).

Dichos componentes comprenden funciones de:

- Adecuación de las bases de datos a requerimientos del *Data Warehouse* y del *Data Mart*.
- Extracción de datos de las fuentes de datos.
- Conversión de datos a través de resúmenes y adiciones.
- Facilidades para ejecución de consultas.
- Considerar la posibilidad de aprovechar las capacidades ya existentes en la empresa (en tecnología, plataformas) que sean compatibles con el Diseño del *Data Warehouse*, e incorporarlas al proyecto (razones de aprovechamiento de inversiones).

La sexta etapa es la de **Prueba**. Todo sistema de información debe pasar por el examen de cumplimiento de satisfacción de requerimientos definidos en la etapa correspondiente, como así también por la verificación de la calidad, integridad y forma de exposición (detallada o sintética) de la información suministrada. Todo esto hace a la confiabilidad en el sistema.

La séptima etapa es la de **Instalación y Utilización** del *Data Warehouse*. Una cuestión fundamental en esos momentos es la sincronización entre los nuevos componentes, la nueva tecnología y la infraestructura existente. También deben observarse los mecanismos de seguridad y acceso.

Con respecto a la utilización, por parte de los usuarios finales, de la información que puede proveer una *Data Warehouse*, deben tenerse en consideración algunos aspectos específicos que diferencian a esta tecnología de la que se aplica con relación a la mayoría de los sistemas de información, tal como lo exponen Gill y Rao⁸, y que se explican a continuación:

- a. Las formas de expresión de la información contenida en un *Data Warehouse* deben ser interpretables por personas que utilizan un lenguaje de negocios. Esto incluye su relación con los metadatos.
- b. La provechosa utilización de la información de un *Data Warehouse* exige que los usuarios noten la necesidad de disponer de esa información en momentos de toma de decisiones. Gill y Rao exponen claramente su afirmación de que la información así obtenida sea considerada como una mercancía, que debe crear una demanda que debe ser atractiva y que el consumidor (usuario en este caso) debe percibir su utilidad.

La última etapa (octava) de la metodología de construcción de un *Data Warehouse* puede denominarse **Optimización** del *Data Warehouse*. La optimización puede surgir como consecuencia del surgimiento de nuevos requerimientos a cubrir, no satisfechos en la primera iteración del desarrollo del *Data Warehouse*. Esto supone la ejecución de una sucesión de iteraciones a través de las cuales se adaptan los datos (nuevos resúmenes o adiciones, incorporación de nuevas fuentes de datos) o bien se formulan nuevas aplicaciones o se amplía la distribución de la información.

Diferencias entre “Infocentro” y *Data Warehouse*

El **Infocentro** surgió como consecuencia de la necesidad de acceder a los datos almacenados en una base de datos operacional. Pero la información que puede brindar un Infocentro se encuentra muy limitada. El cuadro de la figura 18.4 muestra una comparación entre las definiciones de Infocentro y de *Data Warehouse*; donde surgen las diferencias entre ambos conceptos.

⁸ Gill, H.S. y Rao, P.C., Ibid., pp. 107 – 108.

DEFINICIÓN DE INFOCENTRO	DEFINICIÓN DE <i>DATA WAREHOUSE</i> (*)
Colección de datos	Colección de datos
Orientados al tema	Orientados al tema
Integrados	Integrados
Volátiles	No Volátiles
Actuales	Historiados
Organizados para el apoyo de	Organizados para el apoyo de
Un proceso de decisión puntual	Un proceso de ayuda a la decisión

* **Fuente:** Inmon. W.H. y Hackathron, R.D., *Using the Data Warehouse*, Wilwe-QUED-Publication, 1994

Figura 18.4 Comparación entre Inforcentro y Data Warehouse.

Analizando las dos definiciones mencionadas se derivan las siguientes diferencias:

- a. La información contenida en un Infocentro se alimenta con valores provenientes de los sistemas de aplicaciones operacionales. Esto significa que cada vez que comienza un nuevo ciclo de alimentación (actualización) el nuevo valor reemplaza al anterior. Por lo tanto, los datos son actuales, y no queda historia de ese valor (volatilidad). Por el contrario, la no volatilidad es un atributo fundamental del *Data Warehouse*.
- b. El uso que pueden hacer los usuarios de la información varía según el concepto en el que se ubiquen: en la noción del *Data Warehouse* los usuarios pueden obtener conclusiones referentes a tendencias (distintos tiempos de registración de esos valores), permitiendo definiciones de estrategias a más largo plazo.
- c. Generalmente los Infocentros contienen información de fuentes de datos internas; difícilmente consolidan datos externos con datos operacionales (tal como lo ejecuta el *Data Warehouse*).
- d. Como explica Jean-Michel Franco⁹ “el Infocentro es una herramienta, mientras que el *Data Warehouse* es una arquitectura”.

El Concepto de Data Mining

Definición y aplicaciones

Un *Data Mining* (traducido como “minería de datos”) es un conjunto de tecnologías (o herramientas) capaces de analizar la información almacenada en un *Data Warehouse* y capaces de ayudar a descubrir relaciones insospechadas, tendencias, modelos de comportamiento o correlaciones entre los datos contenidos en el *Data Warehouse*.

El propósito de las herramientas de *Data Mining* es examinar una base de datos, formular una hipótesis, verificarla mediante pruebas, y, si éstas resulta satisfactorias, suministrar ese nuevo conocimiento al usuario. Generalmente las hipótesis se describen bajo la forma de reglas. Estas pueden adquirir la forma de funciones, por ejemplo, del tipo: $y = ax + b$. en esta función se intenta descubrir relaciones entre variables x e y , siendo a y b valores reales.

En el ámbito de mercadotecnia se pueden descubrir relaciones entre clientes y productos (y así gestionar una promoción comercial más específica o dirigida), detectar hábitos de consumo ocultos dentro de esa información histórica y definir perfiles de consumidores o usuarios (esto reduce gastos de promoción e incrementa su efectividad).

En el mundo moderno, el *Data Mining* ayuda a corregir u orientar estrategias en materia de televentas, consecuencia de análisis de respuestas.

En el ámbito del seguro, las compañías pueden efectuar análisis de riesgo para localizar las características de clientes de alto riesgo. Analizando los hábitos de pago, una entidad crediticia puede prever el nivel de riesgo de conceder un crédito a un solicitante.

Una publicación periodística¹⁰ señala una tendencia de gestión empresarial que se observa en bancos y organizaciones de Estados Unidos de Norteamérica, que consiste en otorgar un trato personal a cada cliente que recurre a la institución para efectuar una operación o solicitar una consideración especial; por ejemplo,

⁹ Franco, J.M., ob. Cit., p.35.

¹⁰ “Si los clientes no generan ganancias, deshágase de ellos”, *La Nación*, Sección Segunda, 08/01//1999.

“solicitar una tasa de interés más baja en su tarjeta de crédito” o que “no se debiten veintiocho dólares de multa que cobra el banco cada vez que alguien emite un cheque sin fondos”. En estos casos el operador del banco tiene ante su vista una pantalla con información “inteligente” acerca de ese cliente y una señal representada por un cuadrado pequeño – cuyo color puede ser verde, amarillo o rojo – del cual depende en gran parte su respuesta. Así, cuando la señal es roja significa que la cuenta del cliente que consulta genera pérdidas para el banco (las operaciones que efectúa ese cliente no son suficientemente rentables); y en ese caso no se accede a la solicitud. El cuadrado verde indica que las operaciones del cliente con la institución generan ganancias razonables; ello aconsejaría poner buena predisposición para acceder a la solicitud. El color amarillo significa que con tales clientes hay posibilidad de negociar.

La publicación citada, agrega que el sistema informático de ese banco “demora apenas quince segundos en mostrar la categoría del cliente”. El algoritmo o fórmula que se utiliza en estos casos no fue revelado por el banco, pero se conoce que toma en consideración cifras de balances, operaciones efectuadas en la cuenta, cantidad de visitas al banco y otras variables. De acuerdo con sus directivos “no todos los clientes son iguales”. Estos sistemas informáticos que analizan la dimensión clientes, recorren las bases de datos y descartan a los clientes menos rentables (o bien les cobran más caro), mientras otorgan beneficios a los mejores (desde el punto de vista del banco).

Debe tenerse presente, a fin de ubicar al lector en el tema, que el centro de información del banco que estamos comentando estimaba recibir cerca de 45 millones de llamadas de clientes en el año 1999, lo que da una idea sobre el alcance de la gestión.

La conclusión es que, luego de varios intentos de tender una red para atraer a la mayor cantidad de clientes posibles, algunas instituciones han cambiado su estrategia y se han vuelto selectivas: desean conservar clientes que generen ganancias y no pérdidas. Para ello disponen ahora de herramientas informáticas que provean la información adecuada.

La misma publicación cita otro ejemplo acerca de la tendencia que estamos señalando, referido en este caso a un proveedor de servicios buscapersonas. Durante mucho tiempo esta empresa tuvo como meta incrementar permanentemente su participación en el mercado (estrategia frecuente hasta hace algunos años en la gestión de negocio). Sin embargo, luego de analizar información de cada cliente, concluyó en que “existen clientes que reciben muchas llamadas, pero que sólo pagan tarifas muy bajas”. Esto no resultaba rentable para la compañía (se trata de una empresa de cerca de 10 millones de suscriptores).

Con relación a la medicina, el *Data Mining* ayuda en el análisis de respuestas a los diagnósticos y tratamientos.

Una diferencia entre las herramientas de ayuda a decisión y el *Data Mining*, es en que en las primeras, la iniciativa sobre qué elementos se deben observar o analizar corresponde al usuario. En cambio, el *Data Mining*, toma la iniciativa por sí mismo y descubre correlaciones existentes pero ocultas entre los datos. De ahí que mediante esta herramienta sea posible anticipar una hipótesis o detectar un comportamiento inusual en un cliente.

Modelado de datos

Se describió más arriba al *Data Mining* como una herramienta apta para explorar diferentes variables y descubrir, a partir de ese análisis, modelos, relaciones o comportamientos. Estos modelos se obtendrán a partir de información que se presente estructurada, bajo la forma de filas y columnas. Cada fila contendrá un registro de la base de datos. Cada columna representa una variable. Por ejemplo, para un archivo de alumnos se podrá definir un conjunto de características que serán distintas para los varones y para las mujeres.

Analizaremos un caso: supongamos que en una universidad se encare un proyecto para determinar si existe correlación de alumnos aprobados entre las materias denominadas correlativas. Supongamos también que durante un cuatrimestre de dicten las siguientes materias: Programación, Sistemas Administrativos, Teoría de Sistemas, Sistemas Operativos y Base de Datos, y que las materias correlativas sean Programación y Base de Datos. Por último, que los registros de notas expresen que en ese cuatrimestre sólo cuatro alumnos (A, B, C, y D) cursaron las cinco materias y que los resultados fueron los siguientes:

- El alumno A aprobó Programación, Sistemas Administrativos, Sistemas Operativos y Base de Datos.
- El alumno B aprobó Programación y Base de Datos.
- El alumno C aprobó Programación, Sistemas Administrativos, Teoría de Sistemas y Base de Datos.
- El alumno D aprobó Sistemas Operativos.

Para descubrir la posibilidad de correlación entre materias aprobadas, se deberá estructurar la información bajo una forma matricial (cada celda indicará si la materia fue aprobada o no). La tabla de la figura 18.5 muestra los resultados.

Materia Alumno	Programación	Sistemas administrativos	Teoría de sistemas	Sistemas operativos	Base de Datos
A	Aprobó	Aprobó	Desaprobó	Aprobó	Aprobó
B	Aprobó	Desaprobó	Desaprobó	Desaprobó	Aprobó
C	Aprobó	Aprobó	Aprobó	Desaprobó	Aprobó
D	Desaprobó	Desaprobó	Desaprobó	Aprobó	Desaprobó

Figura 18.5. Información estructurada en forma matricial

Una herramienta que explore esta información, analizando el comportamiento de las materias aprobadas, puede llegar a la conclusión de que **todos los alumnos que aprobaron Programación aprobaron también Base de Datos**.

No obstante la conclusión anterior, será necesario considerar dos aspectos:

a. **Volumen de datos analizados:**

Cuando el volumen de datos es significativo, los procesos de *Data Warehousing* y de *Data Mining* llevan tiempo y requieren potencia (máquinas servidoras de envergadura). Una manera de reducir ese volumen es procesando muestras por medio de técnicas que brinda la Estadística, y agrupando datos contenidos en las bases de datos. Debe observarse que trabajar con muestreo implica correr el riesgo de que la muestra no sea realmente representativa del total de información existente, pues el proceso puede ocultar nichos de datos no detectables solamente con muestras. Lo mismo ocurre con técnicas de agregación. Por ejemplo, en una investigación de mercado en el que la estadística se refleja tomando como unidad de tiempo la semana, pueden no detectarse diferencias significativas entre el volumen de ventas de los primeros días y los últimos de la semana.

b. **Validación de los modelos descubiertos:**

Si se formularon hipótesis a través de la aplicación de herramientas de *Data Mining*, es necesario validar los modelos descubiertos mediante pruebas con el ingreso de nuevos datos que confirmen los resultados previamente obtenidos. Las pruebas de validez permitirán asegurar la calidad de los conocimientos extraídos.

BIBLIOGRAFIA

LARDENT, Alberto, R. Sistemas de información para la gestión empresarial: planeamiento, tecnología y calidad. 1era. Edición. Buenos Aires. Ed. Pearson Education. 2001. Capitulo 18. 544p.
ISBN: 987-9460-43-X