

a resumir la información más relevante del informe y tenerlo listo la mañana siguiente para Charlotte. Trabajó hasta muy tarde en la noche para reunir los datos de las páginas del informe, pero al final obtuvo tres tablas, una para cada alternativa de las estrategias de precios. Cada tabla muestra la probabilidad correspondiente de varias cantidades de ventas dado el nivel de competencia (alto, medio o bajo) que desarrollen las otras compañías.

La mañana siguiente Charlotte bebe otra de sus bebidas energéticas. Jeannie y Reggie llegarán a su oficina en cualquier momento y, con su ayuda, tendrá que decidir qué hacer con Brainet. ¿Debe lanzar el producto? Si así es, ¿qué precio debe tener?

Cuando Jeannie y Reggie entran en la oficina, Jeannie exclama: “Amigos, acabo de hablar con nuestra compañía de estudio de mercado. Dicen que pueden hacer el estudio sobre la situación de la competencia para la introducción de Brainet y entregar los resultados en una semana.”

“¿Cuánto quieren por el estudio?”

“Sabía que me preguntarías eso, Reggie. Quieren 10 000 dólares, y pienso que es un precio justo.”

En este punto Charlotte interviene en la conversación. “¿Tenemos algunos datos acerca de la calidad del trabajo de esta compañía?”

“Sí, yo tengo unos informes aquí. Después de analizarlos, llegué a la conclusión de que la compañía de estudios de mercado no es muy buena para predecir el entorno competitivo para precios medios o bajos. Por lo tanto, no debemos pedirles que hagan el estudio si nos decidimos por una de estas estrategias de precio. Pero en el caso de un precio alto, lo hacen bastante bien: dado que la competencia resulta ser alta, ellos han proporcionado el pronóstico correcto 80% del tiempo, mientras que 15% del tiempo pronosticaron competencia media en esa situación. Cuando la competencia resulta ser media, han pronosticado competencia alta 15% del tiempo y media 80% del tiempo. Por último, en el caso de competencia baja, los números fueron 90% de las veces un pronóstico correcto, 7% una predicción ‘media’ y 3% una predicción ‘alta’”.

Charlotte cree que estos números son demasiado para ella. “¿No contamos con una estimación sencilla de cómo reaccionará el mercado?”

“¿Te refieres a probabilidades *a priori*? Seguro, por nuestra experiencia, la posibilidad de enfrentar una competencia alta es de 20%, mientras que es de 70% para una competencia media y 10% para una baja”. Jeannie siempre tiene las cifras listas cuando se necesitan.

Ahora sólo queda sentarse y darle algún sentido a todo esto...

■ **TABLA 1** Distribución de probabilidad de unidades vendidas dado un precio alto (\$50)

Ventas	Nivel de competencia		
	Alto	Medio	Bajo
50 000 unidades	0.2	0.25	0.3
30 000 unidades	0.25	0.3	0.35
20 000 unidades	0.55	0.45	0.35

■ **TABLA 2** Distribución de probabilidad de unidades vendidas, dado un precio medio (\$40)

Ventas	Nivel de competencia		
	Alto	Medio	Bajo
50 000 unidades	0.25	0.30	0.40
30 000 unidades	0.35	0.40	0.50
20 000 unidades	0.40	0.30	0.10

■ **TABLA 3** Distribución de probabilidad de unidades vendidas, dado un precio bajo (\$30)

Ventas	Nivel de competencia		
	Alto	Medio	Bajo
50 000 unidades	0.35	0.40	0.50
30 000 unidades	0.40	0.50	0.45
20 000 unidades	0.25	0.10	0.05

- a) Para el análisis inicial pase por alto la oportunidad de obtener más información con la contratación de la compañía de estudios de mercado. Identifique las acciones alternativas y los estados de la naturaleza. Construya la matriz de pagos. Después formule el problema de decisión como un árbol de decisiones. Distinga con claridad entre los nodos de decisión y los de probabilidad e incluya los datos relevantes.
- b) ¿Cuál debe ser la decisión de Charlotte si usa el criterio de la posibilidad máxima? ¿El criterio del pago máximo?
- c) ¿Cuál es la decisión de Charlotte si usa la regla de decisión de Bayes?
- d) Ahora considere la posibilidad de realizar el estudio de mercado. Desarrolle el árbol de decisión correspondiente. Calcule las probabilidades relevantes y analice el árbol de decisión. ¿Debe Cerebrosoft pagar 10 000 dólares por la investigación de mercado? ¿Cuál es la política óptima global?

■ RESUMEN DE LOS CASOS ADICIONALES EN EL SITIO EN INTERNET DE ESTE LIBRO (www.mhhe.com/hillier)

CASO 15.2 Apoyo inteligente al conductor

El director ejecutivo de Bay Area Automobile Gadgets contempla la posibilidad de agregar un dispositivo examinador de caminos al sistema de soporte al conductor de la compañía. Se debe tomar una serie de decisiones. ¿Es necesario realizar investigación básica en el examinador de caminos? Si la investigación es exitosa, ¿debe la compañía desarrollar el producto o vender la tecnología? En el caso de un desarrollo exitoso del producto, ¿debería la compañía lanzar el producto al mercado o vender el concepto? Es necesario aplicar análisis de decisiones para afrontar estos temas. Parte del análisis involucrará el uso de la función de utilidad del director ejecutivo.

CASO 15.3 ¿Quién quiere ser millonario?

Usted es un participante en el juego “¿Quién quiere ser millonario?” y acaba de responder correctamente la pregunta de los 250 000 dólares. Si usted decide seguir adelante con la pregunta de los 500 000 dólares y después con la del millón de dólares,

tiene la opción de usar la línea “telefonee a un amigo” en una de las preguntas con el fin de mejorar sus probabilidades de contestar correctamente. Usted desea usar el análisis de decisiones (incluyendo el árbol de decisiones y la teoría de la utilidad) para decidir cómo proceder.

CASO 15.4 University Toys y los personajes de acción de un profesor de ingeniería

University Toys ha desarrollado una serie de personajes de acción de un profesor de ingeniería para la escuela de ingeniería local y la administración debe decidir cómo vender los muñecos en un ambiente de incertidumbre acerca de la demanda de este producto. Una opción consiste en tomar la decisión de invertir todo el esfuerzo en su producción, publicidad y ventas. Otra, consiste en probar el producto en el mercado en primera instancia. Un problema con esta última opción es que hay un rumor de que la competencia está por lanzar al mercado un producto similar. Es necesario llevar a cabo el análisis de decisiones (incluyendo el árbol de decisiones y el análisis de sensibilidad) con el fin de decidir la manera de proceder.

16

CAPÍTULO

Cadenas de Markov

El capítulo 15 se enfocó en la toma de decisiones ante la incertidumbre de *uno* o más eventos futuros, con la intención de conocer el verdadero estado de la naturaleza. Sin embargo, algunas decisiones deben tomar en cuenta la incertidumbre acerca de *muchos* eventos futuros. Ahora se presentará el fundamento de la toma de decisiones en este contexto más amplio.

En particular, este capítulo presenta modelos de probabilidad de procesos que *evolucionan en el tiempo* de una manera probabilística. Tales procesos se llaman *procesos estocásticos*. Después de una introducción breve de los procesos estocásticos generales en la primera sección, el resto del capítulo se dedica a un tipo especial de proceso que se denomina *cadena de Markov*. Las cadenas de Markov tienen la propiedad particular de que las probabilidades que describen la forma en que el proceso evolucionará en el futuro dependen sólo del estado actual en que se encuentra el proceso y, por lo tanto, son independientes de los eventos que ocurrieron en el pasado. Muchos procesos se ajustan a esta descripción, por lo que las cadenas de Markov constituyen una clase de modelo probabilístico de gran importancia.

Por ejemplo, usted podrá observar en el capítulo siguiente que las *cadenas de Markov de tiempo continuo* (descritas en la sección 16.8) se utilizan para formular gran parte de los modelos básicos de la *teoría de colas*. Las cadenas de Markov también proporcionan las bases para el estudio de los *modelos de decisión de Markov* en el capítulo 19. Existe una amplia gama de aplicaciones de las cadenas de Markov. Un gran número de libros y artículos presentan algunas de estas aplicaciones. Una de ellas constituye la referencia seleccionada 4 que describe las aplicaciones en áreas tan diversas como la clasificación de los clientes, la secuencia del DNA, el análisis de redes genéticas, la estimación de la demanda de ventas a través del tiempo y el valor del crédito. También se presenta, en el recuadro de aplicación de la sección 16.2, un ejemplo que involucra el valor del crédito, mientras que el recuadro de aplicación de la sección 16.8 se relaciona con el mantenimiento de máquinas. La referencia seleccionada 6 hace hincapié en las aplicaciones en finanzas y la 3 describe aplicaciones para el análisis de la estrategia del beisbol. La lista continúa de manera indefinida, pero por el momento veremos una descripción de los procesos estocásticos en general y de las cadenas de Markov en particular.

16.1 PROCESOS ESTOCÁSTICOS

Un **proceso estocástico** se define como una colección indexada de variables aleatorias $\{X_t\}$, donde el índice t toma valores de un conjunto T dado. Con frecuencia T se considera el conjunto de enteros no negativos mientras que X_t representa una característica de interés cuantificable en el tiempo t . Por ejemplo, X_t puede representar los niveles de inventario al final de la semana t .

Los procesos estocásticos son de interés para describir el comportamiento de un sistema en operación durante algunos periodos. Un proceso estocástico tiene la siguiente estructura.

La condición actual del sistema puede estar en una de $M + 1$ categorías mutuamente excluyentes llamadas **estados**. Por conveniencia en la notación, estos estados se etiquetan $0, 1, 2, \dots, M$. La

variable aleatoria X_t representa el *estado del sistema* en el tiempo t , de manera que sus únicos valores posibles son $0, 1, \dots, M$. El sistema se observa en puntos del tiempo dados, etiquetados $t = 0, 1, 2, \dots$. De esta forma, los procesos estocásticos $\{X_t\} = \{X_0, X_1, X_2, \dots\}$ proporcionan una representación matemática de la forma en que evoluciona la condición del sistema físico a través del tiempo.

Este tipo de procesos se conocen como procesos estocásticos de *tiempo discreto con espacio de estados finito*. Excepto en el caso de la sección 16.8, éste será el único tipo de procesos estocásticos que se estudiará en este capítulo. (En la sección 16.8 se describen ciertos procesos estocásticos de *tiempo continuo*.)

Ejemplo de clima

El clima en el pueblo de Centerville puede cambiar con rapidez de un día a otro. Sin embargo, las posibilidades de tener clima seco (sin lluvia) mañana es de alguna forma mayor si hoy está seco, es decir, si no llueve. En particular, la probabilidad de que mañana esté seco es de **0.8** si hoy está seco, pero es de sólo **0.6** si hoy llueve. Estas probabilidades no cambian si se considera la información acerca del clima en los días anteriores a hoy.

La evolución del clima día tras día en Centerville es un proceso estocástico. Si se comienza en algún día inicial (etiquetado como día 0), el clima se observa cada día t , para $t = 0, 1, 2, \dots$. El estado del sistema en el día t puede ser

Estado 0 = El día t es seco

o bien

Estado 1 = El día t es lluvioso

Así, para $t = 0, 1, 2, \dots$, la variable aleatoria X_t toma los valores,

$$X_t = \begin{cases} 0 & \text{si día } t \text{ es seco} \\ 1 & \text{si día } t \text{ es lluvioso} \end{cases}$$

El proceso estocástico $\{X_t\} = \{X_0, X_1, X_2, \dots\}$ proporciona una representación matemática de la forma en que evoluciona el clima en Centerville a través del tiempo.

Ejemplo de inventarios

La tienda de fotografía de Dave tiene el siguiente problema de inventario. El negocio tiene en almacén un modelo especial de cámara que se puede solicitar cada semana. Sean $D_1, D_2, \dots$ representen las *demandas* respectivas de esta cámara (el número de unidades que se venderían si el inventario no se agota) durante la primera, segunda semanas, $\dots$, respectivamente, entonces, la variable aleatoria D_t (para $t = 1, 2, \dots$) es

D_t = número de cámaras que se venderían en la semana t si el inventario no se agota. (Este número incluye las ventas perdidas cuando se agota el inventario.)

Se supone que las D_t son variables aleatorias independientes e idénticamente distribuidas que tienen una *distribución Poisson* con media de 1. Sea X_0 el número de cámaras que se tiene en el momento de iniciar el proceso, X_1 el número de cámaras que se tienen al final de la semana 1, X_2 el número de cámaras al final de la semana 2, etc., entonces la variable aleatoria X_t (para $t = 0, 1, 2, \dots$) es

X_t = número de cámaras disponibles al final de la semana t .

Suponga que $X_0 = 3$, de manera que la semana 1 se inicia con tres cámaras a mano.

$$\{X_t\} = \{X_0, X_1, X_2, \dots\}$$

es un proceso estocástico donde la variable aleatoria X_t representa el estado del sistema en el tiempo t , a saber

Estado en el tiempo t = número de cámaras disponibles al final de la semana t .

Como propietario de la tienda, Dave desearía aprender más acerca de cómo evoluciona este proceso estocástico a través del tiempo mientras se utilice la política de pedidos actual que se describe a continuación.

Al final de cada semana t (sábado en la noche), la tienda hace un pedido que le entregan en el momento de abrir la tienda el lunes. La tienda usa la siguiente política para ordenar:

Si $X_t = 0$, ordena 3 cámaras.

Si $X_t > 0$, no ordena ninguna cámara.

En consecuencia, el nivel de inventarios fluctúa entre un mínimo de cero y un máximo de tres cámaras, por lo que los estados posibles del sistema en el tiempo t (al final de la semana t) son

Estados posibles = 0, 1, 2, o 3 cámaras disponibles.

Como cada variable aleatoria X_t ($t = 0, 1, 2, \dots$) representa el estado del sistema al final de la semana t , sus únicos valores posibles son 0, 1, 2, 3. Las variables aleatorias X_t son dependientes y se pueden evaluar en forma iterativa por medio de la expresión

$$X_{t+1} = \begin{cases} \max\{3 - D_{t+1}, 0\} & \text{si } X_t = 0 \\ \max\{X_t - D_{t+1}, 0\} & \text{si } X_t \geq 1, \end{cases}$$

para $t = 0, 1, 2, \dots$

Estos ejemplos se usarán como ilustración en muchas de las secciones que siguen. En la sección 16.2 se define con más detalle el tipo de procesos estocásticos que se analizará en este capítulo.

16.2 CADENAS DE MARKOV

Es necesario hacer algunos supuestos sobre la distribución conjunta de $X_0, X_1, \dots$ para obtener resultados analíticos. Un supuesto que conduce al manejo analítico es que el proceso estocástico es una cadena de Markov, que tiene la siguiente propiedad esencial:

Se dice que un proceso estocástico $\{X_t\}$ tiene la **propiedad markoviana** si $P\{X_{t+1} = j | X_0 = k_0, X_1 = k_1, \dots, X_{t-1} = k_{t-1}, X_t = i\} = P\{X_{t+1} = j | X_t = i\}$, para $t = 0, 1, \dots$ y toda sucesión $i, j, k_0, k_1, \dots, k_{t-1}$.

En palabras, esta propiedad markoviana establece que la probabilidad condicional de cualquier “evento” futuro dados cualquier “evento” pasado y el estado actual $X_t = i$, es *independiente* de los eventos pasados y sólo depende del estado actual del proceso.

Un proceso estocástico $\{X_t\}$ ($t = 0, 1, \dots$) es una **cadena de Markov** si presenta la *propiedad markoviana*.

Las probabilidades condicionales $P\{X_{t+1} = j | X_t = i\}$ de una cadena de Markov se llaman **probabilidades de transición** (de un paso). Si para cada i y j ,

$$P\{X_{t+1} = j | X_t = i\} = P\{X_1 = j | X_0 = i\}, \quad \text{para toda } t = 1, 2, \dots,$$

entonces se dice que las probabilidades de transición (de un paso) son *estacionarias*. Así, tener **probabilidades de transición estacionarias** implica que las probabilidades de transición no cambian con el tiempo. La existencia de probabilidades de transición (de un paso) estacionarias también implica que, para cada i, j y n ($n = 0, 1, 2, \dots$),

$$P\{X_{t+n} = j | X_t = i\} = P\{X_n = j | X_0 = i\}$$

para toda $t = 0, 1, \dots$. Estas probabilidades condicionales se llaman **probabilidades de transición de n pasos**.

Para simplificar la notación de las probabilidades de transición estacionarias, sea

$$p_{ij} = P\{X_{t+1} = j | X_t = i\},$$

$$p_{ij}^{(n)} = P\{X_{t+n} = j | X_t = i\}.$$

Así, las probabilidades de transición de n pasos $p_{ij}^{(n)}$ son simplemente la probabilidad condicional de que el sistema se encuentre en el estado j exactamente después de n pasos (unidades de tiempo), dado que comenzó en el estado i en cualquier tiempo t . Cuando $n = 1$ observe que $p_{ij}^{(1)} = p_{ij}$.¹

Como las $p_{ij}^{(n)}$ son probabilidades condicionales, deben ser no negativas y, como el proceso debe hacer una transición a algún estado, deben satisfacer las propiedades

$$p_{ij}^{(n)} \geq 0, \quad \text{para toda } i \text{ y } j; n = 0, 1, 2, \dots,$$

y

$$\sum_{j=0}^M p_{ij}^{(n)} = 1 \quad \text{para toda } i; n = 0, 1, 2, \dots$$

Una notación conveniente para representar las probabilidades de transición de n pasos es la *matriz de transición de n pasos*

$$\mathbf{P}^{(n)} = \begin{matrix} & \begin{matrix} \text{Estado} & 0 & 1 & \dots & M \end{matrix} \\ \begin{matrix} 0 \\ 1 \\ \vdots \\ M \end{matrix} & \begin{bmatrix} p_{00}^{(n)} & p_{01}^{(n)} & \dots & p_{0M}^{(n)} \\ p_{10}^{(n)} & p_{11}^{(n)} & \dots & p_{1M}^{(n)} \\ \dots & \dots & \dots & \dots \\ p_{M0}^{(n)} & p_{M1}^{(n)} & \dots & p_{MM}^{(n)} \end{bmatrix} \end{matrix}$$

Observe que la probabilidad de transición en un renglón y columna dados es la de la transición *del* estado en ese renglón *al* estado en la columna. Cuando $n = 1$, el superíndice n no se escribe y se hace referencia a ésta como una *matriz de transición*.

Las cadenas de Markov que se estudian en este capítulo tienen las siguientes propiedades:

1. Un número finito de estados.
2. Probabilidades de transición estacionarias.

También se supondrá que se conocen las probabilidades iniciales $P\{X_0 = i\}$ para toda i .

Formulación del ejemplo del clima como una cadena de Markov

En el ejemplo del clima que se presentó en la sección anterior, recuerde que la evolución del clima día tras día en Centerville se ha formulado como un proceso estocástico $\{X_t\}$ ($t = 0, 1, 2, \dots$) donde

$$X_t = \begin{cases} 0 & \text{si día } t \text{ es seco} \\ 1 & \text{si día } t \text{ es lluvioso} \end{cases}$$

$$P\{X_{t+1} = 0 | X_t = 0\} = 0.8,$$

$$P\{X_{t+1} = 0 | X_t = 1\} = 0.6$$

Aún más, como estas probabilidades no cambian si también se toma en cuenta la información del clima antes del día de hoy (día t),

$$P\{X_{t+1} = 0 | X_0 = k_0, X_1 = k_1, \dots, X_{t-1} = k_{t-1}, X_t = 0\} = P\{X_{t+1} = 0 | X_t = 0\}$$

$$P\{X_{t+1} = 0 | X_0 = k_0, X_1 = k_1, \dots, X_{t-1} = k_{t-1}, X_t = 1\} = P\{X_{t+1} = 0 | X_t = 1\}$$

¹ Para $n = 0$, $p_{ij}^{(0)}$ es $P\{X_0 = j | X_0 = i\}$, que es igual a 1 cuando $i = j$ y es 0 cuando $i \neq j$.

Recuadro de aplicación

Merrill Lynch es una firma líder en servicios integrales financieros que brinda servicios de corretaje, de inversiones y bancarios a clientes al menudeo y a pequeños negocios a la vez que ayuda a las grandes corporaciones e instituciones alrededor del mundo a formar capital. Uno de los afiliados de Merrill Lynch, *Merrill Lynch (ML) Bank USA*, cuenta con activos por más de 60 000 millones de dólares obtenidos mediante la aceptación de depósitos provenientes de los clientes al menudeo de Merrill Lynch a los que utiliza para financiar préstamos y realizar inversiones.

En el año 2000, ML Bank USA comenzó a otorgar líneas de crédito revolviente a sus clientes corporativos. En cosa de unos años, el banco había desarrollado un portafolios de alrededor de 13 000 millones de dólares en compromisos de líneas de crédito con más de 100 instituciones. Antes de llegar a este punto, se le solicitó al eficiente grupo de investigación de operaciones guiar a los administradores de éste cada vez más grande portafolios mediante el uso de técnicas de investigación de operaciones con el fin de evaluar el *riesgo de liquidez* (situación que consiste en que el banco no pueda cumplir con sus obligaciones de dinero en efectivo) asociado con sus obligaciones de línea de crédito actuales y en el futuro.

El grupo de investigación de operaciones desarrolló un *modelo de simulación* (el tema del capítulo 20) con este objetivo. Sin embargo, el más importante potencial de este modelo consiste en una *cadena de Markov* que describe la evolución del valor del crédito de cada cliente a través del tiempo. Los estados de la cadena de Markov son los diferentes valores po-

sibles del crédito (que varían desde *la inversión más alta hasta la inversión por omisión*) que se le asignan a las principales compañías a través de agencias de clasificación de créditos como Standard and Poor's y Moody's. La probabilidad de transición desde el estado i hasta el j de la matriz de transición de una determinada compañía se define como la probabilidad de que la agencia de clasificación de créditos cambie la clasificación de la compañía del estado i al j de un mes a otro con base en los patrones históricos de compañías similares.

Esta aplicación de la investigación de operaciones (incluyendo las cadenas de Markov) permitió a ML Bank USA *liberar alrededor de 4 000 millones de dólares de liquidez para utilizarlos en otra cosa*, así como también expandir su portafolios de compromisos en líneas de crédito más de 60% en menos de dos años. Otros de los beneficios que se obtuvieron a partir de dicho estudio fueron la capacidad para evaluar escenarios muy riesgosos y llevar a cabo la planeación a largo plazo. Este sorprendente trabajo hizo que Merrill Lynch se hiciera merecedora del prestigiado *Premio Wagner para la Excelencia en la Práctica de la Investigación de Operaciones* en 2004.

Fuente: Duffy, T., M. Hatzakis, W. Hsu, R. Labe, B. Liao, X. Luo, J. Oh, A. Setya y L. Yang: "Merrill Lynch Improves Liquidity Risk Management for Revolving Credit Lines", en *Interfaces*, **35**(5): 353-369, septiembre-octubre de 2005. (En el sitio en internet de este libro —www.mhhe.com/hillier— se proporciona una liga hacia este artículo.)

para $t = 0, 1, \dots$ y toda sucesión $k_0, k_1, \dots, k_{t-1}$. Estas ecuaciones también deben cumplirse si $X_{t+1} = 0$ se reemplaza con $X_{t+1} = 1$. (La razón es que los estados 0 y 1 son mutuamente excluyentes y son los únicos estados posibles; por ende, las probabilidades de los dos estados deben sumar 1.) Por lo tanto, el proceso estocástico tiene la *propiedad markoviana*, lo que lo convierte en una cadena de Markov.

Si se usa la notación que se introdujo en esta sección, las probabilidades de transición (de un paso) son

$$\begin{aligned} p_{00} &= P\{X_{t+1} = 0 \mid X_t = 0\} = 0.8, \\ p_{10} &= P\{X_{t+1} = 0 \mid X_t = 1\} = 0.6 \end{aligned}$$


para toda $t = 1, 2, \dots$, por lo que éstas son las probabilidades de transición *estacionarias*. Además,

$$\begin{aligned} p_{00} + p_{01} &= 1 \quad \text{entonces} \quad p_{01} = 1 - 0.8 = 0.2, \\ p_{10} + p_{11} &= 1 \quad \text{entonces} \quad p_{11} = 1 - 0.6 = 0.4, \end{aligned}$$

Por lo tanto, la matriz de transición es

$$\mathbf{P} = \begin{array}{cc} \text{Estado} & \begin{matrix} 0 & 1 \end{matrix} \\ \begin{matrix} 0 \\ 1 \end{matrix} & \begin{bmatrix} p_{00} & p_{01} \\ p_{10} & p_{11} \end{bmatrix} \end{array} = \begin{array}{cc} \text{Estado} & \begin{matrix} 0 & 1 \end{matrix} \\ \begin{matrix} 0 \\ 1 \end{matrix} & \begin{bmatrix} 0.8 & 0.2 \\ 0.6 & 0.4 \end{bmatrix}$$

donde estas probabilidades de transición se refieren a la transición *del* estado del renglón *al* estado de la columna. Tenga en mente que el estado 0 hace referencia a un día seco, mientras que el estado 1 significa que el día es lluvioso, así que estas probabilidades de transición proporcionan la probabilidad del estado del clima el día de mañana, dado el estado del clima del día de hoy.



■ FIGURA 16.1

Diagrama de transición de estados del ejemplo del clima.

El diagrama de transición de estado de la figura 16.1 presenta de manera gráfica la misma información que proporciona la matriz de transición. Los nodos (círculos) representan los dos estados posibles del clima, mientras que las flechas muestran las transiciones posibles de un día al siguiente (se incluye la opción de regresar al mismo estado). Cada una de las probabilidades de transición se escribe a continuación de la flecha correspondiente.

Las matrices de transición de n pasos se presentarán en la siguiente sección.

Formulación del ejemplo de inventarios como una cadena de Markov

Si se regresa al ejemplo de inventarios que se desarrolló en la sección anterior, recuerde que X_t es el número de cámaras en almacén al final de la semana t (antes de ordenar más), donde X_t representa el *estado del sistema* en el tiempo t (el fin de la semana t). Dado que el estado actual es $X_t = i$, la expresión al final de la sección 16.1 indica que X_{t+1} depende sólo de D_{t+1} (la demanda en la semana $t + 1$) y X_t . Como X_{t+1} es independiente de la historia del sistema de inventarios antes del tiempo t , el proceso estocástico $\{X_t\}$ ($t = 0, 1, \dots$) tiene la *propiedad markoviana* y por lo tanto es una cadena de Markov.

A continuación se verá cómo obtener las probabilidades de transición (de un paso), es decir, los elementos de la *matriz de transición* (de un paso)

$$\mathbf{P} = \begin{array}{c|cccc} \text{Estado} & 0 & 1 & 2 & 3 \\ \hline 0 & p_{00} & p_{01} & p_{02} & p_{03} \\ 1 & p_{10} & p_{11} & p_{12} & p_{13} \\ 2 & p_{20} & p_{21} & p_{22} & p_{23} \\ 3 & p_{30} & p_{31} & p_{32} & p_{33} \end{array}$$

dado que D_{t+1} tiene una distribución Poisson con media de 1. Entonces,

$$P\{D_{t+1} = n\} = \frac{(1)^n e^{-1}}{n!}, \quad \text{para } n = 0, 1, \dots,$$

por lo que (expresando con tres dígitos significativos) se tiene,

$$P\{D_{t+1} = 0\} = e^{-1} = 0.368,$$

$$P\{D_{t+1} = 1\} = e^{-1} = 0.368,$$

$$P\{D_{t+1} = 2\} = \frac{1}{2}e^{-1} = 0.184,$$

$$P\{D_{t+1} \geq 3\} = 1 - P\{D_{t+1} \leq 2\} = 1 - (0.368 + 0.368 + 0.184) = 0.080.$$

Para el primer renglón de $\mathbf{P}$ se trata de la transición del estado $X_t = 0$ a algún estado X_{t+1} . Como se indica al final de la sección 16.1,

$$X_{t+1} = \max\{3 - D_{t+1}, 0\} \quad \text{si } X_t = 0.$$

Por lo tanto, para la transición a $X_{t+1} = 3$, o $X_{t+1} = 2$ o $X_{t+1} = 1$,

$$p_{03} = P\{D_{t+1} = 0\} = 0.368,$$

$$p_{02} = P\{D_{t+1} = 1\} = 0.368,$$

$$p_{01} = P\{D_{t+1} = 2\} = 0.184.$$

Una transición de $X_t = 0$ a $X_{t+1} = 0$ implica que la demanda de cámaras en la semana $t + 1$ es 3 o más, después que se agregaron tres cámaras al inventario agotado al principio de la semana, de manera que

$$p_{00} = P\{D_{t+1} \geq 3\} = 0.080.$$

En el caso de los otros dos renglones de **P**, la fórmula al final de la sección 16.1 del siguiente estado es

$$X_{t+1} = \max \{X_t - D_{t+1}, 0\} \quad \text{si} \quad X_t \geq 1.$$

Esto implica que $X_{t+1} \leq X_t$ entonces, $p_{12} = 0$, $p_{13} = 0$ y $p_{23} = 0$. En el caso de las otras transiciones,

$$p_{11} = P\{D_{t+1} = 0\} = 0.368,$$

$$p_{10} = P\{D_{t+1} \geq 1\} = 1 - P\{D_{t+1} = 0\} = 0.632,$$

$$p_{22} = P\{D_{t+1} = 0\} = 0.368,$$

$$p_{21} = P\{D_{t+1} = 1\} = 0.368,$$


$$p_{20} = P\{D_{t+1} \geq 2\} = 1 - P\{D_{t+1} \leq 1\} = 1 - (0.368 + 0.368) = 0.264.$$

En el último renglón de **P**, la semana $t + 1$ comienza con tres cámaras en inventario y los cálculos de las probabilidades de transición son exactamente los mismos que las del primer renglón. En consecuencia, la matriz de transición completa (expresándola con tres dígitos significativos) es

$$\mathbf{P} = \begin{array}{c|cccc} \text{Estado} & 0 & 1 & 2 & 3 \\ \hline 0 & 0.080 & 0.184 & 0.368 & 0.368 \\ 1 & 0.632 & 0.368 & 0 & 0 \\ 2 & 0.264 & 0.368 & 0.368 & 0 \\ 3 & 0.080 & 0.184 & 0.368 & 0.368 \end{array}$$

La información que proporciona la matriz de transición también se puede describir mediante el diagrama de transición de estados de la figura 16.2. En el diagrama, los cuatro estados posibles del número de cámaras que se tienen al final de la semana se representan por medio de los cuatro nodos (círculos). Las flechas muestran las transiciones posibles de un estado a otro o, en ocasiones,

■ **FIGURA 16.2**
Diagrama de transición de estados del ejemplo de inventarios.



de regreso al mismo estado, cuando la tienda de cámaras transita del final de una semana al final de la siguiente. El número junto a cada flecha proporciona la probabilidad de que ocurra esa transición en particular cuando la tienda de cámaras tiene el estado que está en la base de la flecha.

Ejemplos adicionales de cadenas de Markov

Ejemplo de acciones. Considere el siguiente modelo del valor de una acción. Al final de un día dado se registra el precio. Si la acción subió, la probabilidad de que suba mañana es de **0.7**. Si la acción bajó, la probabilidad de que suba mañana es de sólo **0.5**. (Para simplificar, cuando la acción permanezca con el mismo precio se considerará un aumento.) Ésta es una cadena de Markov, donde los estados posibles de cada día son los siguientes:

Estado 0: El precio de la acción subió este día.

Estado 1: El precio de la acción bajó este día.

La matriz de transición que muestra cada probabilidad de ir desde un estado particular hoy hasta un estado particular mañana, está dada por

$$\mathbf{P} = \begin{array}{c} \text{Estado} \quad 0 \quad 1 \\ \begin{array}{c} 0 \\ 1 \end{array} \left[\begin{array}{cc} 0.7 & 0.3 \\ 0.5 & 0.5 \end{array} \right] \end{array}$$

La forma del diagrama de transición de estado de este ejemplo es exactamente la misma que la del ejemplo 16.1, por lo que no se repetirá aquí. La única diferencia radica en que las probabilidades de transición en el diagrama son ligeramente diferentes (0.7 reemplaza a 0.8, 0.3 reemplaza a 0.2 y 0.5 reemplaza a 0.6 y 0.4 en la figura 16.1).

Segundo ejemplo de acciones. Suponga ahora que el modelo del mercado de acciones se cambia de manera que el hecho de que una acción suba mañana depende de que haya subido hoy y ayer. En particular, si la acción subió los dos días, ayer y hoy, la probabilidad de que suba mañana es de **0.9**. Si la acción subió hoy pero ayer bajó, la probabilidad de que mañana suba es de **0.6**. Si la acción bajó hoy pero ayer subió, la probabilidad de que mañana suba es de **0.5**. Por último, si bajó durante estos dos días, la probabilidad de que mañana suba es de **0.3**. Si se define el estado como la representación del hecho de que la acción baje o suba hoy, el sistema ya no es una cadena de Markov. Sin embargo, se puede transformar en una de ellas si se definen los estados como sigue:²

Estado 0: la acción aumentó hoy y ayer.

Estado 1: la acción aumentó hoy y ayer bajó.

Estado 2: la acción bajó hoy y ayer aumentó.


Estado 3: la acción bajó hoy y ayer.

Estos datos conducen a una cadena de Markov de cuatro estados con la siguiente matriz de transición:

$$\mathbf{P} = \begin{array}{c} \text{Estado} \quad 0 \quad 1 \quad 2 \quad 3 \\ \begin{array}{c} 0 \\ 1 \\ 2 \\ 3 \end{array} \left[\begin{array}{cccc} 0.9 & 0 & 0.1 & 0 \\ 0.6 & 0 & 0.4 & 0 \\ 0 & 0.5 & 0 & 0.5 \\ 0 & 0.3 & 0 & 0.7 \end{array} \right] \end{array}$$

La figura 16.3 muestra el diagrama de transición de estado de este ejemplo. Una característica interesante del ejemplo que revela este diagrama y todos los valores de 0 de la matriz de transición es que gran parte de las transiciones del estado i al j son imposibles en un solo paso. En otras palabras, $p_{ij} = 0$ para 8 de las 16 entradas de la matriz de transición. Sin embargo, observe cómo

² De nuevo se considera un descenso cuando el nivel de inventarios se mantiene igual. Este ejemplo demuestra que las cadenas de Markov pueden incorporar una cantidad arbitraria de historia, pero a costa de aumentar en forma significativa el número de estados.



■ **FIGURA 16.3**
Diagrama de transición
de estado para el segundo
ejemplo de inventarios.

siempre es posible ir de cualquier estado i a cualquier estado j (incluyendo $j = i$) en dos pasos. Lo mismo es válido en el caso de tres pasos, cuatro pasos, etc. Por lo tanto, $p_{ij}^{(n)} > 0$ para $n = 2, 3, \dots$ para toda i y j .


Ejemplo de juego. Otro ejemplo se refiere al juego. Suponga que un jugador tiene 1 dólar y que cada jugada gana 1 dólar con probabilidad $p > 0$ o pierde 1 dólar con probabilidad $1 - p > 0$. El juego termina cuando el jugador acumula 3 dólares o cuando quiebra. Este modelo es una cadena de Markov en la que los estados representan la fortuna del jugador, esto es, 0, 1, 2 o 3 dólares, con la matriz de transición dada por

$$\mathbf{P} = \begin{array}{c} \text{Estado} \\ \begin{array}{c} 0 \\ 1 \\ 2 \\ 3 \end{array} \end{array} \begin{array}{c} \begin{array}{ccccc} & 0 & 1 & 2 & 3 \end{array} \\ \left[\begin{array}{cccc} 1 & 0 & 0 & 0 \\ 1-p & 0 & p & 0 \\ 0 & 1-p & 0 & p \\ 0 & 0 & 0 & 1 \end{array} \right] \end{array}$$

El diagrama de transición de estado de este ejemplo se muestra en la figura 16.4. Dicho diagrama demuestra que una vez que el proceso entra a un estado 0 o 3, permanecerá en ese estado indefinidamente, puesto que $p_{00} = 1$ y $p_{33} = 1$. Los estados 0 y 3 son ejemplos de lo que se conoce como **estado absorbente** (un estado que nunca se deja una vez que el proceso entra en él). Nos enfocaremos en el análisis de los estados absorbente en la sección 16.7.

Observe que tanto en el ejemplo de inventario como en el del jugador, las etiquetas numéricas de los estados que alcanza el proceso coinciden con la expresión física del sistema, es decir, los niveles de inventario real y la fortuna del jugador, respectivamente, mientras que las etiquetas numéricas de los estados en el ejemplo de la acción no tienen significado físico.

■ **FIGURA 16.4**
Diagrama de transición de
estado de un ejemplo de
juegos.



16.3 ECUACIONES DE CHAPMAN-KOLMOGOROV

En la sección 16.2 se introdujo la probabilidad de transición de n pasos $p_{ij}^{(n)}$. Las *ecuaciones de Chapman-Kolmogorov* proporcionan un método para calcular estas probabilidades de transición de n pasos:

$$p_{ij}^{(n)} = \sum_{k=0}^M p_{ik}^{(m)} p_{kj}^{(n-m)}, \quad \text{para toda } i = 0, 1, \dots, M, \\ j = 0, 1, \dots, M, \\ \text{y cualquier } m = 1, 2, \dots, n-1, \\ n = m+1, m+2, \dots.^3$$

Estas ecuaciones simplemente señalan que al ir del estado i al estado j en n pasos, el proceso estará en algún estado k después de exactamente m (menor que n) pasos. Así, $p_{ik}^{(m)} p_{kj}^{(n-m)}$ es sólo la probabilidad condicional de que, si comienza en el estado i , el proceso vaya al estado k después de m pasos y después al estado j en $n-m$ pasos. Por lo tanto, al resumir estas probabilidades condicionales sobre todos los estados posibles k se debe obtener $p_{ij}^{(n)}$. Los casos especiales de $m = 1$ y $m = n-1$ conducen a las expresiones

$$p_{ij}^{(n)} = \sum_{k=0}^M p_{ik} p_{kj}^{(n-1)}$$

y

$$p_{ij}^{(n)} = \sum_{k=0}^M p_{ik}^{(n-1)} p_{kj},$$

para todos los estados i y j . Estas expresiones permiten que las probabilidades de transición de n pasos se puedan obtener a partir de las probabilidades de transición de un paso de manera recursiva. Esta relación recursiva se explica mejor con la notación matricial (vea el apéndice 4). Para $n = 2$, estas expresiones se convierten en

$$p_{ij}^{(2)} = \sum_{k=0}^M p_{ik} p_{kj}, \quad \text{para todos los estados } i \text{ y } j$$

donde las $p_{ij}^{(2)}$ son los elementos de la matriz $\mathbf{P}^{(2)}$. También note que estos elementos se obtienen al multiplicar la matriz de transición de un paso por sí misma; esto es,

$$\mathbf{P}^{(2)} = \mathbf{P} \cdot \mathbf{P} = \mathbf{P}^2.$$

De la misma manera, las expresiones anteriores de $p_{ij}^{(n)}$ cuando $m = 1$ y $m = n-1$ indican que la matriz de probabilidades de transición de n pasos es

$$\begin{aligned} \mathbf{P}^{(n)} &= \mathbf{P} \mathbf{P}^{(n-1)} = \mathbf{P}^{(n-1)} \mathbf{P} \\ &= \mathbf{P} \mathbf{P}^{n-1} = \mathbf{P}^{n-1} \mathbf{P} \\ &= \mathbf{P}^n. \end{aligned}$$

Entonces, la matriz de probabilidades de transición de n pasos $\mathbf{P}^n$ se puede obtener al calcular la n -ésima potencia de la matriz de transición de un paso $\mathbf{P}$.

Matrices de transición de n pasos del ejemplo del clima

En el caso del ejemplo del clima que se presentó en la sección 16.1, ahora se usarán las fórmulas anteriores para calcular las diferentes matrices de transición de n pasos a partir de la matriz de transición $\mathbf{P}$ (de un paso) que se obtuvo en la sección 16.2. Para iniciar, la matriz de transición de dos pasos es

$$\mathbf{P}^{(2)} = \mathbf{P} \cdot \mathbf{P} = \begin{bmatrix} 0.8 & 0.2 \\ 0.6 & 0.4 \end{bmatrix} \begin{bmatrix} 0.8 & 0.2 \\ 0.6 & 0.4 \end{bmatrix} = \begin{bmatrix} 0.76 & 0.24 \\ 0.72 & 0.28 \end{bmatrix}.$$

³ Estas ecuaciones también se cumplen en el caso trivial, cuando $m = 0$ o $m = n$, pero $m = 1, 2, \dots, n-1$ son los únicos casos de interés.

Así, si el clima está en el estado 0 (seco) en un día particular, la probabilidad de estar en el estado 0 dos días después es 0.76, por lo que la probabilidad de estar en el estado 1 (lluvia) es 0.24. En forma similar, si el clima está en el estado 1 ahora, la probabilidad de estar en el estado 0 dos días después es 0.72 mientras que la probabilidad de estar en el estado 1 es 0.28.

Las probabilidades del estado del clima tres, cuatro o cinco días a futuro también se pueden leer de la misma forma a partir de las matrices de transición de tres, cuatro y cinco pasos que se calculan con tres dígitos significativos a continuación.

$$\begin{aligned}\mathbf{P}^{(3)} = \mathbf{P}^3 &= \mathbf{P} \cdot \mathbf{P}^2 = \begin{bmatrix} 0.8 & 0.2 \\ 0.6 & 0.4 \end{bmatrix} \begin{bmatrix} 0.76 & 0.24 \\ 0.72 & 0.28 \end{bmatrix} = \begin{bmatrix} 0.752 & 0.248 \\ 0.744 & 0.256 \end{bmatrix} \\ \mathbf{P}^{(4)} = \mathbf{P}^4 &= \mathbf{P} \cdot \mathbf{P}^3 = \begin{bmatrix} 0.8 & 0.2 \\ 0.6 & 0.4 \end{bmatrix} \begin{bmatrix} 0.752 & 0.248 \\ 0.744 & 0.256 \end{bmatrix} = \begin{bmatrix} 0.75 & 0.25 \\ 0.749 & 0.251 \end{bmatrix} \\ \mathbf{P}^{(5)} = \mathbf{P}^5 &= \mathbf{P} \cdot \mathbf{P}^4 = \begin{bmatrix} 0.8 & 0.2 \\ 0.6 & 0.4 \end{bmatrix} \begin{bmatrix} 0.75 & 0.25 \\ 0.749 & 0.251 \end{bmatrix} = \begin{bmatrix} 0.75 & 0.25 \\ 0.75 & 0.25 \end{bmatrix}\end{aligned}$$

Observe que la matriz de transición de cinco pasos tiene la interesante característica de que los dos renglones poseen elementos idénticos. Ello refleja el hecho de que la probabilidad del clima que está en un estado particular es en esencia independiente del estado del clima cinco días antes. Por lo tanto, las probabilidades de cualquier renglón de esta matriz de transición de cinco pasos se denominan *probabilidades del estado estable* de la cadena de Markov.

Más adelante se hará un estudio más profundo de las probabilidades del estado estable de una cadena de Markov, donde se incluye cómo obtenerlas de un modo más directo, al inicio de la sección 16.5.

Matrices de transición de n pasos del ejemplo de inventarios

De nuevo en el ejemplo de inventarios, incluido en la sección 16.1, calcularemos ahora sus matrices de transición de n pasos con tres dígitos decimales con $n = 2, 4$ y 8 . Para comenzar, su matriz de transición de un solo paso $\mathbf{P}$ que se obtuvo en la sección 16.2 puede usarse para obtener la matriz de transición de dos pasos $\mathbf{P}^{(2)}$ de la siguiente forma:

$$\begin{aligned}\mathbf{P}^{(2)} = \mathbf{P}^2 &= \begin{bmatrix} 0.080 & 0.184 & 0.368 & 0.368 \\ 0.632 & 0.368 & 0 & 0 \\ 0.264 & 0.368 & 0.368 & 0 \\ 0.080 & 0.184 & 0.368 & 0.368 \end{bmatrix} \begin{bmatrix} 0.080 & 0.184 & 0.368 & 0.368 \\ 0.632 & 0.368 & 0 & 0 \\ 0.264 & 0.368 & 0.368 & 0 \\ 0.080 & 0.184 & 0.368 & 0.368 \end{bmatrix} \\ &= \begin{bmatrix} 0.249 & 0.286 & 0.300 & 0.165 \\ 0.283 & 0.252 & 0.233 & 0.233 \\ 0.351 & 0.319 & 0.233 & 0.097 \\ 0.249 & 0.286 & 0.300 & 0.165 \end{bmatrix}.\end{aligned}$$

Por ejemplo, dado que se tiene una cámara en existencia al final de la semana, la probabilidad de que no haya cámaras en inventario dos semanas después es de 0.283, esto es $p_{10}^{(2)} = 0.283$. De manera similar, dado que se tienen dos cámaras al final de una semana, la probabilidad de que haya tres cámaras en inventario dos semanas después es de 0.097; esto es, $p_{23}^{(2)} = 0.097$.

La matriz de transición de cuatro pasos también se puede obtener de la siguiente manera:

$$\begin{aligned}\mathbf{P}^{(4)} = \mathbf{P}^4 &= \mathbf{P}^{(2)} \cdot \mathbf{P}^{(2)} \\ &= \begin{bmatrix} 0.249 & 0.286 & 0.300 & 0.165 \\ 0.283 & 0.252 & 0.233 & 0.233 \\ 0.351 & 0.319 & 0.233 & 0.097 \\ 0.249 & 0.286 & 0.300 & 0.165 \end{bmatrix} \begin{bmatrix} 0.249 & 0.286 & 0.300 & 0.165 \\ 0.283 & 0.252 & 0.233 & 0.233 \\ 0.351 & 0.319 & 0.233 & 0.097 \\ 0.249 & 0.286 & 0.300 & 0.165 \end{bmatrix} \\ &= \begin{bmatrix} 0.289 & 0.286 & 0.261 & 0.164 \\ 0.282 & 0.285 & 0.268 & 0.166 \\ 0.284 & 0.283 & 0.263 & 0.171 \\ 0.289 & 0.286 & 0.261 & 0.164 \end{bmatrix}.\end{aligned}$$

Por ejemplo, dado que queda una cámara al final de una semana, 0.282 es la probabilidad de que no haya cámaras en inventario cuatro semanas más tarde; es decir, $p_{10}^{(4)} = 0.282$. De igual manera, dado que quedan dos cámaras en el almacén al final de cierta semana, se tiene una probabilidad de 0.171 de que haya tres cámaras en el almacén cuatro semanas después; esto es, $p_{23}^{(4)} = 0.171$.

Las probabilidades de transición del número de cámaras en inventario dentro de ocho semanas se puede leer de la misma forma a partir de la matriz de transición de ocho pasos que se calcula a continuación.

$$\begin{aligned} \mathbf{P}^{(8)} &= \mathbf{P}^8 = \mathbf{P}^{(4)} \cdot \mathbf{P}^{(4)} \\ &= \begin{bmatrix} 0.289 & 0.286 & 0.261 & 0.164 \\ 0.282 & 0.285 & 0.268 & 0.166 \\ 0.284 & 0.283 & 0.263 & 0.171 \\ 0.289 & 0.286 & 0.261 & 0.164 \end{bmatrix} \begin{bmatrix} 0.289 & 0.286 & 0.261 & 0.164 \\ 0.282 & 0.285 & 0.268 & 0.166 \\ 0.284 & 0.283 & 0.263 & 0.171 \\ 0.289 & 0.286 & 0.261 & 0.164 \end{bmatrix} \\ &= \begin{array}{c} \text{Estado} \\ \begin{matrix} 0 \\ 1 \\ 2 \\ 3 \end{matrix} \end{array} \begin{array}{c} \begin{matrix} 0 & 1 & 2 & 3 \end{matrix} \\ \begin{bmatrix} 0.286 & 0.285 & 0.264 & 0.166 \\ 0.286 & 0.285 & 0.264 & 0.166 \\ 0.286 & 0.285 & 0.264 & 0.166 \\ 0.286 & 0.285 & 0.264 & 0.166 \end{bmatrix} \end{array} \end{aligned}$$

De igual modo que en la matriz de transición de cinco pasos del ejemplo del clima, esta matriz tiene la interesante característica de que sus renglones tienen elementos idénticos. De nuevo, la razón es que las probabilidades en cualquier renglón son las *probabilidades del estado estable* de esta cadena de Markov, es decir, las probabilidades del estado del sistema después de un tiempo suficiente han llegado a un punto en el que el estado inicial ya no es relevante.

En el IOR Tutorial se incluye una rutina para calcular $\mathbf{P}^{(n)} = \mathbf{P}^n$ para cualquier entero positivo $n \leq 99$.

Probabilidades de estado incondicionales

Recuerde que las probabilidades de transición de uno o de n pasos son probabilidades *condicionales*; por ejemplo, $P\{X_n = j | X_0 = i\} = p_{ij}^{(n)}$. Se supone que n es lo suficientemente pequeña como para que estas probabilidades todavía no sean las del *estado estable*. En este caso, si se desea la probabilidad *incondicional* $P\{X_n = j\}$, es necesario que se especifique la distribución de probabilidad del estado inicial, o sea, $p\{X_0 = i\}$ para $i = 0, 1, \dots, M$. Entonces

$$P\{X_n = j\} = P\{X_0 = 0\} p_{0j}^{(n)} + P\{X_0 = 1\} p_{1j}^{(n)} + \dots + P\{X_0 = M\} p_{Mj}^{(n)}.$$

En el ejemplo de inventarios se supuso que al inicio se contaba con tres unidades en inventario, es decir, $X_0 = 3$. Así, $P\{X_0 = 0\} = P\{X_0 = 1\} = P\{X_0 = 2\} = 0$ y $P\{X_0 = 3\} = 1$. Por lo tanto, la probabilidad (incondicional) de que haya tres cámaras en inventario dos semanas después de que el sistema se puso en marcha es $P\{X_2 = 3\} = (1)p_{33}^{(2)} = 0.165$.

16.4 CLASIFICACIÓN DE ESTADOS EN UNA CADENA DE MARKOV

Acabamos de ver en la parte final de la sección anterior que las probabilidades de transición de n pasos del ejemplo del inventario convergen hacia las probabilidades del estado estable después de un número de pasos suficiente. Sin embargo, esto no es válido para todas las cadenas de Markov. Las propiedades a largo plazo de una cadena de Markov dependen en gran medida de las características de sus estados y de la matriz de transición. Para describir con más detalle las propiedades de una cadena de Markov es necesario presentar algunos conceptos y definiciones que se refieren a estos estados.

Se dice que el estado j es **accesible** desde el estado i si $p_{ij}^{(n)} > 0$ para alguna $n \geq 0$. (Recuerde que $p_{ij}^{(n)}$ es sólo la probabilidad condicional de llegar al estado j después de n pasos, si el sistema está en el estado i .) Entonces, que el estado j sea accesible desde el estado i significa que es posible que el sistema llegue finalmente al estado j si comienza en el estado i . Esto es particularmente vá-

lido para el ejemplo del clima (vea la figura 16.1) puesto que $p_{ij} > 0$ para toda i y j . En el ejemplo de inventarios (vea la figura 16.2), $p_{ij}^{(2)} > 0$ para todo i y j de manera que cada estado es accesible desde cualquier otro estado. En general, una condición suficiente para que *todos* los estados sean accesibles es que exista un valor de n para el que $p_{ij}^{(n)} > 0$ para todo i y j .

En el ejemplo del juego que se presentó al final de la sección 16.2 (vea la figura 16.4), el estado 2 no es accesible desde el estado 3. Esto se puede deducir del contexto del juego (una vez que el jugador llega al estado 3 nunca lo deja), lo que implica que $p_{32}^{(n)} = 0$ para toda $n \geq 0$. Sin embargo, aun cuando el estado 2 *no* es accesible desde el estado 3, el estado 3 *sí es* accesible desde el estado 2 puesto que, con $n = 1$, la matriz de transición del final de la sección 16.2 indica que $p_{23} = p > 0$.

Si el estado j es accesible desde el estado i y el estado i es accesible desde el estado j , entonces se dice que los estados i y j se **comunican**. En el ejemplo de inventarios, todos los estados se comunican. En el ejemplo del juego, los estados 2 y 3 no se comunican. En general:

1. Cualquier estado se comunica consigo mismo (porque $p_{ii}^{(0)} = P\{X_0 = i | X_0 = i\} = 1$).
2. Si el estado i se comunica con el estado j , entonces el estado j se comunica con el estado i .
3. Si el estado i se comunica con el estado j y éste con el estado k , entonces el estado i se comunica con el estado k .

Las propiedades 1 y 2 se deducen de la definición de estados que se comunican, mientras que la propiedad 3 se deriva de las ecuaciones de Chapman-Kolmogorov.

Como resultado de estas propiedades de comunicación se puede hacer una partición del espacio de estados en **clases** separadas, donde se dice que dos estados que se comunican pertenecen a la misma clase. (Una clase puede consistir en un solo estado.) Si existe sólo una clase, es decir, si todos los estados se comunican, se dice que la cadena de Markov es **irreducible**. Tanto en el ejemplo del clima como en el de inventarios, la cadena de Markov es irreducible. En el primer ejemplo de las acciones (sección 16.2), la cadena de Markov también es irreducible. El ejemplo del juego contiene tres clases; el estado 0 forma una clase, el estado 3 forma otra y los estados 1 y 2 forman una tercera clase.

Estados recurrentes y estados transitorios

Con frecuencia es útil saber si un proceso que comienza en un estado regresará alguna vez a él. La siguiente es una posibilidad.

Un estado se llama estado **transitorio** si, después de haber entrado a este estado, el proceso *nunca* *regresa* a él. Por consiguiente, el estado i es transitorio si y sólo si existe un estado j ($j \neq i$) que es accesible desde el estado i , pero no viceversa, esto es, el estado i no es accesible desde el estado j .

Así, si el estado i es transitorio y el proceso visita este estado, existe una probabilidad positiva (quizá incluso de 1) de que el proceso se moverá al estado j y nunca regresará al estado i . En consecuencia, un estado transitorio será visitado sólo un número finito de veces. Para ilustrar lo anterior, considere el ejemplo del juego que se presentó al final de la sección 16.2. Su diagrama de transición de estado que se muestra en la figura 16.4 indica que ambos estados (1 y 2) son transitorios ya que el proceso los abandonará tarde o temprano para entrar al estado 0 o al 3 y, después, permanecerá en dicho estado de manera indefinida.

Cuando se inicia en el estado i , otra posibilidad es que el proceso *definitivamente* regrese a ese estado.

Se dice que un estado es **recurrente** si, después de haber entrado a este estado, el proceso *definitivamente* regresará a ese estado. Por consiguiente, un estado es recurrente si y sólo si no es transitorio.

Como un estado recurrente será visitado de nuevo después de cada visita, podría ser visitado un número infinito de veces si el proceso continuara por siempre. Por ejemplo, todos los estados en los diagramas de transición de estado que se muestran en las figuras 16.1, 16.2 y 16.3 son estados recurrentes debido a que el proceso siempre regresará a cada uno de ellos. Inclusive en el ejemplo del juego, los estados 0 y 3 son recurrentes debido a que el proceso se mantendrá regresando de manera inmediata a uno de estos estados en forma indefinida, una vez que el proceso haya entrado a ese estado. Observe en la figura 16.4 cómo finalmente el proceso entrará a cualquiera de los estados 0 y 3 y, después, ya nunca los abandonará.

Si el proceso entra en cierto estado y permanece en él al siguiente paso, se considera un *regreso* a ese estado. En consecuencia, el siguiente tipo de estado se considera un tipo especial de estado recurrente.

Un estado se llama estado **absorbente** si, después de haber entrado ahí, el proceso *nunca saldrá* de él. Por consiguiente, el estado i es un estado absorbente si y sólo si $p_{ii} = 1$.

Como se acaba de mencionar, tanto el estado 0 como el 3 del ejemplo del juego están de acuerdo con esta definición, por lo que ambos son estados absorbentes, así como también un tipo especial de estado recurrente. En la sección 16.7 se estudiarán los estados absorbentes con más detalle.

La recurrencia es una propiedad de clase. Es decir, todos los estados de una clase son recurrentes o son transitorios. Más aún, en una cadena de Markov de estado finito, no todos los estados pueden ser transitorios. Entonces, todos los estados de una cadena de Markov de estado finito irreducible son recurrentes. Sin duda, se puede identificar una cadena de Markov de estado finito irreducible (y, por lo tanto, concluir que todos los estados son recurrentes) demostrando que todos los estados del proceso se comunican. Ya se hizo notar que una condición suficiente para que *todos* los estados sean accesibles (y, por lo tanto, se comuniquen unos con otros) es que exista un valor de n para el cual $p_{ij}^{(n)} > 0$ para toda i y j . En este contexto, todos los estados del ejemplo de inventarios (vea la figura 16.2) son recurrentes, puesto que $p_{ij}^{(2)}$ es positiva para toda i y j . De manera parecida, el primer ejemplo sobre las acciones contiene sólo estados recurrentes, puesto que p_{ij} es positiva para toda i y j . Cuando se calcula $p_{ij}^{(2)}$ para toda i y j en el segundo ejemplo de acciones de la sección 16.2 (vea la figura 16.3) se concluye que todos los estados son recurrentes porque $p_{ij}^{(2)} > 0$ para toda i y j .

Como otro ejemplo, suponga que un proceso de Markov tiene la siguiente matriz de transición:

$$\mathbf{P} = \begin{array}{c|ccccc} & \text{Estado} & 0 & 1 & 2 & 3 & 4 \\ \hline & 0 & \left[\begin{array}{ccccc} \frac{1}{4} & \frac{3}{4} & 0 & 0 & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & \frac{1}{3} & \frac{2}{3} & 0 \\ 1 & 0 & 0 & 0 & 0 \end{array} \right] \end{array}$$

Observe que el estado 2 es absorbente (y, por lo tanto, recurrente), porque si el proceso entra en él (tercer renglón de la matriz), nunca sale. El estado 3 es transitorio porque una vez que el proceso se encuentra en él, existe una probabilidad positiva de nunca regresar. La probabilidad de que el proceso vaya del estado 3 al estado 2 en el primer paso es $\frac{1}{3}$. Si el proceso está en el estado 2, permanece en ese estado. Cuando el proceso deja el estado 4, nunca vuelve. Los estados 0 y 1 son recurrentes. Para comprobar todo lo anterior, observe en $\mathbf{P}$ que si el proceso comienza en cualquier de estos estados, nunca sale de ellos. Aún más, cuando el proceso se mueve de uno de estos estados al otro, siempre regresa al estado original.

Propiedades de periodicidad

Otra propiedad útil de las cadenas de Markov es la de *periodicidad*. El **periodo** de un estado i se define como el entero t ($t > 1$) si $p_{ii}^{(n)} = 0$ para todos los valores de n distintos de $t, 2t, 3t, \dots$, y t es el entero más grande con esta propiedad. En el problema del juego (fin de la sección 16.2), al comenzar en el estado 1, es posible que el proceso entre al estado 1 sólo en los tiempos 2, 4, $\dots$, en cuyo caso se dice que el estado 1 tiene periodo 2. Esto es evidente si se observa que el jugador puede salir a mano (ni ganar ni perder) sólo en los tiempos 2, 4, $\dots$, lo que se puede verificar si se calcula $p_{11}^{(n)}$ para toda n y se observa que $p_{11}^{(n)} = 0$ para n impar. También es posible ver en la figura 16.4 que el proceso siempre toma dos pasos para regresar al estado 1 hasta que el proceso es absorbido en cualquiera de los estados 0 o 3. (La misma conclusión también se aplica al estado 2.)

Si existen dos números consecutivos s y $s + 1$ tales que el proceso puede encontrarse en el estado i en los tiempos s y $s + 1$, se dice que el estado tiene periodo 1 y se llama **aperiódico**.

Igual que la recurrencia es una propiedad de clase, se puede demostrar que la periodicidad también lo es. Esto es, si el estado i de una clase tiene periodo t , todos los estados de esa clase tienen

periodo t . En el ejemplo del juego, el estado 2 tiene periodo 2 porque está en la misma clase que el estado 1 y, como se vio, el estado 1 tiene periodo 2.

Es posible que una cadena de Markov tenga tanto una clase de estados recurrentes como una de estados transitorios donde las dos clases tienen diferentes periodos mayores que 1. Si el lector desea ver una cadena de Markov donde se presente esta situación, **otro ejemplo** de este tipo se proporciona en la sección Worked Examples del sitio en internet de este libro.

En una cadena de Markov de estado finito, los estados recurrentes aperiódicos se llaman **ergódicos**. Se dice que una cadena de Markov es *ergódica* si todos sus estados son ergódicos. En seguida se verá que una propiedad clave a largo plazo de una cadena de Markov que es tanto irreducible como ergódica es que sus probabilidades de transición de n pasos convergirán a las probabilidades del estado estable conforme n se haga más grande.

16.5 PROPIEDADES A LARGO PLAZO DE LAS CADENAS DE MARKOV

Probabilidades de estado estable

Mientras se calculaban las matrices de transición de n pasos de los ejemplos del clima y de inventarios en la sección 16.3, se observó una característica interesante de estas matrices. Si n es lo suficientemente grande ($n = 5$ en el ejemplo del clima y $n = 8$ en el ejemplo de inventarios), todos los renglones de la matriz tienen elementos idénticos, lo que significa que la probabilidad de que el sistema esté en cada estado j ya no depende del estado inicial del sistema. En otras palabras, parece que existe una probabilidad límite de que el sistema se encuentre en el estado j después de un número grande de transiciones, y que esta probabilidad es independiente del estado inicial. En realidad, estas propiedades del comportamiento a largo plazo de un proceso de Markov de estado finito se cumplen en condiciones relativamente generales, como se resume a continuación.

Para una cadena de Markov irreducible ergódica el $\lim_{n \rightarrow \infty} p_{ij}^{(n)}$ existe y es independiente de i .

Aún más,

$$\lim_{n \rightarrow \infty} p_{ij}^{(n)} = \pi_j > 0,$$

donde las π_j satisfacen de manera única las siguientes **ecuaciones de estado estable**

$$\pi_j = \sum_{i=0}^M \pi_i p_{ij}, \quad \text{para } j = 0, 1, \dots, M,$$

$$\sum_{j=0}^M \pi_j = 1.$$

Si usted prefiere trabajar con un sistema de ecuaciones en forma matricial, este sistema (excluyendo la ecuación $\text{sum} = 1$) también puede expresarse como

$$\pi_j = \pi P.$$

donde $\pi = (\pi_0, \pi_1, \dots, \pi_M)$.

Las π_j se llaman **probabilidades de estado estable** de la cadena de Markov. El término *probabilidad de estado estable* significa que la probabilidad de encontrar el proceso en cierto estado, por ejemplo j , después de un número grande de transiciones tiende al valor π_j , y es independiente de la distribución de probabilidad inicial definida para los estados. Es importante observar que la probabilidad de estado estable *no* significa que el proceso se establezca en un estado. Por el contrario, el proceso continúa haciendo transiciones de un estado a otro y en cualquier paso n la probabilidad de transición del estado i al estado j es todavía p_{ij} .

También se puede interpretar las π_j como *probabilidades estacionarias* (que no deben confundirse con las probabilidades de transición estacionarias) en el siguiente sentido. Si la probabilidad *inicial* de encontrarse en estado j está dada por π_j (esto es, $P\{X_0 = j\} = \pi_j$) para toda j , entonces la probabilidad de encontrar el proceso en el estado j en el tiempo $n = 1, 2, \dots$ también está dada por π_j (es decir, $P\{X_n = j\} = \pi_j$).

Debe observarse que las ecuaciones de estado estable consisten en $M + 2$ ecuaciones con $M + 1$ incógnitas. Como el sistema tiene una solución única, al menos una de las ecuaciones debe ser redundante, por lo que se puede eliminar. No puede ser la ecuación

$$\sum_{j=0}^M \pi_j = 1,$$

como $\pi_j = 0$ para toda j satisfaría las otras $M + 1$ ecuaciones. Aún más, las soluciones de las otras $M + 1$ ecuaciones de estado estable tienen una solución única con una constante multiplicativa y es la ecuación final la que fuerza la solución a ser una distribución de probabilidad.

Aplicación al ejemplo del clima. El ejemplo del clima que se introdujo en la sección 16.1 y se formuló en la sección 16.2 tiene sólo dos estados (seco y lluvioso), por lo que las ecuaciones anteriores de estado estable se convierten en

$$\begin{aligned}\pi_0 &= \pi_0 p_{00} + \pi_1 p_{10}, \\ \pi_1 &= \pi_0 p_{01} + \pi_1 p_{11}, \\ 1 &= \pi_0 + \pi_1.\end{aligned}$$

Lo que se intuye detrás de la primera ecuación es que, en el estado estable, la probabilidad de quedar en el estado 0 después de la siguiente transición debe ser igual a 1) la probabilidad de estar en el estado 0 ahora y luego permanecer en el estado 0 después de la siguiente transición más 2) la probabilidad de estar en el estado 1 ahora y luego hacer la transición al estado 0. La lógica de la segunda ecuación es la misma, sólo que está en términos del estado 1. La tercera ecuación sólo expresa el hecho de que las probabilidades de estos estados mutuamente excluyentes deben sumar 1.

En referencia a las probabilidades de transición de la sección 16.2 de este ejemplo, estas ecuaciones se convierten en

$$\begin{aligned}\pi_0 &= 0.8\pi_0 + 0.6\pi_1, & \text{así} & \quad 0.2\pi_0 = 0.6\pi_1, \\ \pi_1 &= 0.2\pi_0 + 0.4\pi_1, & \text{así} & \quad 0.6\pi_1 = 0.2\pi_0, \\ 1 &= \pi_0 + \pi_1.\end{aligned}$$

Observe que una de las dos primeras ecuaciones es redundante puesto que ambas ecuaciones se reducen a $\pi_0 = 3\pi_1$. Al combinar estos resultados con la tercera ecuación se producen de inmediato las siguientes probabilidades de estado estable:

$$\pi_0 = 0.25, \quad \pi_1 = 0.75$$

Éstas son las mismas probabilidades que las que se obtuvieron en cada renglón de la matriz de cinco pasos que se calculó en la sección 16.3, debido a que cinco transiciones probaron ser suficientes para que las probabilidades de estado sean en esencia independientes del estado inicial.

Aplicación al ejemplo de inventarios. El ejemplo de inventarios que se introdujo en la sección 16.1 y se formuló en la sección 16.2 tiene cuatro estados. Por lo tanto, las ecuaciones de estado estable se pueden expresar como

$$\begin{aligned}\pi_0 &= \pi_0 p_{00} + \pi_1 p_{10} + \pi_2 p_{20} + \pi_3 p_{30}, \\ \pi_1 &= \pi_0 p_{01} + \pi_1 p_{11} + \pi_2 p_{21} + \pi_3 p_{31}, \\ \pi_2 &= \pi_0 p_{02} + \pi_1 p_{12} + \pi_2 p_{22} + \pi_3 p_{32}, \\ \pi_3 &= \pi_0 p_{03} + \pi_1 p_{13} + \pi_2 p_{23} + \pi_3 p_{33}, \\ 1 &= \pi_0 + \pi_1 + \pi_2 + \pi_3.\end{aligned}$$

Al sustituir los valores de p_{ij} (vea la matriz de transición en la sección 16.2) en estas ecuaciones se obtiene

$$\begin{aligned}\pi_0 &= 0.080\pi_0 + 0.632\pi_1 + 0.264\pi_2 + 0.080\pi_3, \\ \pi_1 &= 0.184\pi_0 + 0.368\pi_1 + 0.368\pi_2 + 0.184\pi_3, \\ \pi_2 &= 0.368\pi_0 + 0.368\pi_2 + 0.368\pi_3, \\ \pi_3 &= 0.368\pi_0 + 0.368\pi_3, \\ 1 &= \pi_0 + \pi_1 + \pi_2 + \pi_3.\end{aligned}$$

Cuando se resuelven en forma simultánea las últimas cuatro ecuaciones se obtiene la solución

$$\pi_0 = 0.286, \quad \pi_1 = 0.285, \quad \pi_2 = 0.263, \quad \pi_3 = 0.166,$$

que en esencia son los resultados que aparecen en la matriz $\mathbf{P}^{(8)}$ de la sección 16.3. En consecuencia, después de muchas semanas, la probabilidad de encontrar cero, una, dos y tres cámaras en el almacén tiende a 0.286, 0.285, 0.263 y 0.166, respectivamente.

Más acerca de las probabilidades de estado estable. En el IOR Tutorial se incluye una rutina para resolver las ecuaciones de estado estable para obtener las probabilidades de estado estable. Además, en la sección Worked Examples de nuestro sitio en internet se incluye **otro ejemplo** de aplicación de las probabilidades de estado estable (que explica la utilización de la técnica que se describe en la siguiente subsección) para determinar la mejor alternativa entre varias con base en el costo.

Existen otros resultados importantes respecto de las probabilidades de estado estable. En particular, si i y j son estados recurrentes que pertenecen a clases distintas, entonces

$$p_{ij}^{(n)} = 0, \quad \text{para toda } n.$$

Este resultado es una consecuencia de la definición de clase.

De manera similar, si j es un estado transitorio, entonces

$$\lim_{n \rightarrow \infty} p_{ij}^{(n)} = 0, \quad \text{para toda } i.$$

De este modo, la probabilidad de encontrar el proceso en un estado transitorio después de un número grande de transiciones tiende a cero.

Costo promedio esperado por unidad de tiempo

La subsección anterior estudió las cadenas de Markov de estado finito irreducible cuyos estados son ergódicos (recurrentes y aperiódicos). Si se relaja el requerimiento de que los estados sean aperiódicos, entonces el límite

$$\lim_{n \rightarrow \infty} p_{ij}^{(n)}$$

puede no existir. Para ilustrar este punto considere la matriz de transición de dos estados

$$\mathbf{P} = \begin{array}{c|cc} \text{Estado} & 0 & 1 \\ \hline 0 & 0 & 1 \\ 1 & 1 & 0 \end{array}.$$

Si el proceso comienza en el estado 0 en el tiempo 0, estará en el estado 0 en los tiempos 2, 4, 6, . . . y en el estado 1 en los tiempos 1, 3, 5, . . . Entonces, $p_{00}^{(n)} = 1$ si n es par y $p_{00}^{(n)} = 0$ si n es impar, de manera que el

$$\lim_{n \rightarrow \infty} p_{00}^{(n)}$$

no existe. Sin embargo, el siguiente límite siempre existe para una cadena de Markov irreducible de estado finito:

$$\lim_{n \rightarrow \infty} \left(\frac{1}{n} \sum_{k=1}^n p_{ij}^{(k)} \right) = \pi_j,$$

donde las π_j satisfacen las ecuaciones de estado estable de la subsección anterior.

Este resultado es en extremo importante para calcular el *costo promedio a largo plazo por unidad de tiempo* asociado a una cadena de Markov. Suponga que se incurre en un costo (u otra función de penalización) $C(X_t)$ cuando el proceso se encuentra en el estado X_t en el tiempo t , para $t = 0, 1, 2, \dots$. Observe que $C(X_t)$ es una variable aleatoria que toma cualquiera de los valores $C(0)$,

$C(1), \dots, C(M)$ y que la función $C(\cdot)$ es independiente de t . El costo promedio esperado en el que se incurre a lo largo de los primeros n periodos está dado por la expresión

$$E\left[\frac{1}{n} \sum_{t=1}^n C(X_t)\right].$$

Si se usa el resultado de que

$$\lim_{n \rightarrow \infty} \left(\frac{1}{n} \sum_{k=1}^n p_{ij}^{(k)} \right) = \pi_j,$$

se puede demostrar que el *costo promedio esperado por unidad de tiempo* (a largo plazo), está dado por

$$\lim_{n \rightarrow \infty} E\left[\frac{1}{n} \sum_{t=1}^n C(X_t)\right] = \sum_{j=0}^M \pi_j C(j).$$

Aplicación al ejemplo de inventarios. A manera de ejemplo, considere el problema de inventarios que se presentó en la sección 16.1, donde la solución de las π_j se obtuvo en una subsección anterior. Suponga que la tienda de cámaras encuentra que se debe asignar un cargo por almacenamiento por cada cámara que permanece en la tienda al final de la semana. El costo se carga de la siguiente manera:

$$C(x_t) = \begin{cases} 0 & \text{si } x_t = 0 \\ 2 & \text{si } x_t = 1 \\ 8 & \text{si } x_t = 2 \\ 18 & \text{si } x_t = 3 \end{cases}$$

Mediante el uso de las probabilidades de estado estable que se dedujeron en esta sección, el costo promedio esperado por semana, a largo plazo, por mantener el inventario, se puede obtener de la ecuación anterior; esto es,

$$\lim_{n \rightarrow \infty} E\left[\frac{1}{n} \sum_{t=1}^n C(X_t)\right] = 0.286(0) + 0.285(2) + 0.263(8) + 0.166(18) = 5.662.$$

Observe que otra medida del costo promedio esperado (a largo plazo) por unidad de tiempo es el *costo promedio real por unidad de tiempo* (a largo plazo). Se puede demostrar que esta última medida está dada por

$$\lim_{n \rightarrow \infty} \left[\frac{1}{n} \sum_{t=1}^n C(X_t) \right] = \sum_{j=0}^M \pi_j C(j)$$

en esencia para todas las trayectorias del proceso. Así, ambas medidas conducen al mismo resultado. Estos resultados también se pueden usar para interpretar el significado de las π_j . Para hacerlo, sea

$$C(X_t) = \begin{cases} 1 & \text{si } X_t = j \\ 0 & \text{si } X_t \neq j. \end{cases}$$

La fracción esperada del número de veces (a largo plazo) que el sistema se encuentra en el estado j está dada entonces por

$$\lim_{n \rightarrow \infty} E\left[\frac{1}{n} \sum_{t=1}^n C(X_t)\right] = \lim_{n \rightarrow \infty} E(\text{fracción de veces que el sistema está en el estado } j) = \pi_j.$$

De igual manera, π_j se puede interpretar también como la fracción o porcentaje real (a largo plazo) del número de veces que el sistema se encuentra en el estado j .

Costo promedio esperado por unidad de tiempo de funciones de costo complejas

En la subsección anterior, la función de costo se basó nada más en el estado en el que se encuentra el proceso en el tiempo t . En muchos problemas importantes el costo también puede depender de otra variable aleatoria.

Por ejemplo, en el problema de inventarios de la sección 16.1, suponga que debe tomarse en cuenta el costo de ordenar y el costo de penalización por demanda insatisfecha (los costos de almacenaje son pequeños, por lo que se pasarán por alto). Es razonable suponer que el número de cámaras ordenadas al principio de la semana t depende sólo del estado del proceso X_{t-1} (el número de cámaras que se tiene) cuando se hace el pedido al final de la semana $t-1$. Sin embargo, el costo de la demanda que no se satisfizo durante la semana t dependerá de la demanda D_t . Por lo tanto, el costo total (costo de ordenar más costo de la demanda insatisfecha) de la semana t es una función de X_{t-1} y de D_t , esto es, $C(X_{t-1}, D_t)$.

Bajo los supuestos de este ejemplo se puede demostrar que (a largo plazo) el *costo promedio esperado por unidad de tiempo* está dado por

$$\lim_{n \rightarrow \infty} E \left[\frac{1}{n} \sum_{t=1}^n C(X_{t-1}, D_t) \right] = \sum_{j=0}^M k(j) \pi_j,$$

donde

$$k(j) = E[C(j, D_t)],$$

y esta última esperanza (condicional) se toma respecto de la distribución de probabilidad de la variable aleatoria D_t , dado el estado j . De manera similar, el costo promedio real (a largo plazo) por unidad de tiempo está dado por

$$\lim_{n \rightarrow \infty} \left[\frac{1}{n} \sum_{t=1}^n C(X_{t-1}, D_t) \right] = \sum_{j=0}^M k(j) \pi_j.$$

Se deben asignar valores numéricos a las dos componentes de $C(X_{t-1}, D_t)$ en este ejemplo, es decir, el costo del pedido y el costo de penalización por la demanda insatisfecha. Si se ordena $z > 0$ cámaras, se incurre en un costo de $(10 + 25z)$ dólares. Si no se ordenan cámaras, no hay cargos por ordenar. Cada unidad de demanda insatisfecha (ventas perdidas), tiene un costo de 50 dólares. Entonces, dada la política de ordenar descrita en la sección 16.1, el costo en la semana t está dado por

$$C(X_{t-1}, D_t) = \begin{cases} 10 + (25)(3) + 50 \max\{D_t - 3, 0\} & \text{si } X_{t-1} = 0 \\ 50 \max\{D_t - X_{t-1}, 0\} & \text{si } X_{t-1} \geq 1, \end{cases}$$

para $t = 1, 2, \dots$. En consecuencia,

$$C(0, D_t) = 85 + 50 \max\{D_t - 3, 0\},$$

de manera que

$$\begin{aligned} k(0) &= E[C(0, D_t)] = 85 + 50E(\max\{D_t - 3, 0\}) \\ &= 85 + 50[P_D(4) + 2P_D(5) + 3P_D(6) + \dots], \end{aligned}$$

donde $P_D(i)$ es la probabilidad de que la demanda sea igual a i , según una distribución de Poisson con media de 1, de manera que $P_D(i)$ se vuelve despreciable para i mayor que los valores cercanos a 6. Como $P_D(4) = 0.015$, $P_D(5) = 0.003$ y $P_D(6) = 0.001$, se tiene que $k(0) = 86.2$. También, si se usa $P_D(2) = 0.184$ y $P_D(3) = 0.061$ y se calcula en forma similar, se obtienen los siguientes resultados

$$\begin{aligned} k(1) &= E[C(1, D_t)] = 50E(\max\{D_t - 1, 0\}) \\ &= 50[P_D(2) + 2P_D(3) + 3P_D(4) + \dots] \\ &= 18.4, \end{aligned}$$

$$\begin{aligned} k(2) &= E[C(2, D_t)] = 50E(\max\{D_t - 2, 0\}) \\ &= 50[P_D(3) + 2P_D(4) + 3P_D(5) + \dots] \\ &= 5.2, \end{aligned}$$

y

$$\begin{aligned} k(3) &= E[C(3, D_t)] = 50E(\max\{D_t - 3, 0\}) \\ &= 50[P_D(4) + 2P_D(5) + 3P_D(6) + \cdots] \\ &= 1.2. \end{aligned}$$

Así, el costo promedio esperado (a largo plazo) por semana está dado por

$$\sum_{j=0}^3 k(j)\pi_j = 86.2(0.286) + 18.4(0.285) + 5.2(0.263) + 1.2(0.166) = \$31.46.$$

Éste es el costo asociado con la política de ordenar descrita en la sección 16.1. El costo de otras políticas se puede evaluar de manera similar a fin de identificar la política que minimiza el costo promedio esperado semanal.

Los resultados de esta subsección se presentaron sólo en términos del ejemplo de inventarios, pero los resultados (no numéricos) se cumplen para otros problemas siempre y cuando se satisfagan las siguientes condiciones:

1. $\{X_t\}$ es una cadena de Markov irreducible (estado finito).
2. Asociada con esta cadena de Markov se tiene una secuencia de variables aleatorias $\{D_t\}$, independientes e idénticamente distribuidas.
3. Para una m fija, $m = 0, \pm 1, \pm 2, \dots$, se incurre en un costo $C(X_t, D_{t+m})$ en el tiempo t , para $t = 0, 1, 2, \dots$
4. La secuencia $X_0, X_1, X_2, \dots, X_t$ debe ser independiente de D_{t+m} .

En particular, si se satisfacen estas condiciones, entonces

$$\lim_{n \rightarrow \infty} E \left[\frac{1}{n} \sum_{t=1}^n C(X_t, D_{t+m}) \right] = \sum_{j=0}^M k(j)\pi_j,$$

donde

$$k(j) = E[C(j, D_{t+m})],$$

y esta última esperanza condicional se toma respecto de la distribución de probabilidad de la variable aleatoria D_t dado el estado j . Más aún,

$$\lim_{n \rightarrow \infty} \left[\frac{1}{n} \sum_{t=1}^n C(X_t, D_{t+m}) \right] = \sum_{j=0}^M k(j)\pi_j$$

para las partes esenciales de todas las trayectorias del proceso.

16.6 TIEMPOS DE PRIMERA PASADA

La sección 16.3 se dedicó a encontrar las probabilidades de transición de n pasos del estado i al estado j . Con frecuencia es conveniente poder hacer afirmaciones en términos de probabilidades sobre el número de transiciones que hace el proceso al ir del estado i al estado j por primera vez. Este lapso se llama **tiempo de primera pasada** al ir del estado i al estado j . Cuando $j = i$, este tiempo de primera pasada es igual al número de transiciones hasta que el proceso regresa al estado inicial i . En este caso, el tiempo de primera pasada se llama **tiempo de recurrencia** del estado i .

Para ilustrar estas definiciones, reconsidere el ejemplo de inventarios que se presentó en la sección 16.1, donde X_t es el número de cámaras en inventario al final de la semana t y se comienza con $X_0 = 3$. Suponga que ocurrió lo siguiente

$$X_0 = 3, \quad X_1 = 2, \quad X_2 = 1, \quad X_3 = 0, \quad X_4 = 3, \quad X_5 = 1.$$

En este caso, el tiempo de primera pasada para ir del estado 3 al estado 1 es de dos semanas, el tiempo de primera pasada para ir del estado 3 al estado 0 es de tres semanas y el tiempo de recurrencia del estado 3 es de cuatro semanas.

En general, los tiempos de primera pasada son variables aleatorias. Las distribuciones de probabilidad dependen de las probabilidades de transición del proceso. En particular, $f_{ij}^{(n)}$ denota la probabilidad de que el tiempo de primera pasada del estado i al j sea igual a n . Para $n > 1$, este tiempo de primera pasada es n si la primera transición es del estado i a algún estado k ($k \neq j$) y después el tiempo de primera pasada del estado k al estado j es $n - 1$. Por lo tanto, estas probabilidades satisfacen las siguientes relaciones recursivas:

$$\begin{aligned} f_{ij}^{(1)} &= p_{ij}^{(1)} = p_{ij}, \\ f_{ij}^{(2)} &= \sum_{k \neq j} p_{ik} f_{kj}^{(1)}, \\ f_{ij}^{(n)} &= \sum_{k \neq j} p_{ik} f_{kj}^{(n-1)}. \end{aligned}$$

Entonces, la probabilidad de un tiempo de primera pasada del estado i al j en n pasos, se puede calcular de manera recursiva a partir de las probabilidades de transición de un paso.

En el ejemplo de inventarios, la distribución de probabilidad de los tiempos de primera pasada al ir del estado 3 al estado 0 se obtiene de las relaciones recursivas como sigue:

$$\begin{aligned} f_{30}^{(1)} &= p_{30} = 0.080, \\ f_{30}^{(2)} &= p_{31}f_{10}^{(1)} + p_{32}f_{20}^{(1)} + p_{33}f_{30}^{(1)} \\ &= 0.184(0.632) + 0.368(0.264) + 0.368(0.080) = 0.243, \\ &\vdots \end{aligned}$$

donde p_{3k} y $f_{k0}^{(1)} = p_{k0}$ se obtienen de la matriz de transición (de un paso) dada en la sección 16.2.

Para i y j fijas, las $f_{ij}^{(n)}$ son números no negativos tales que

$$\sum_{n=1}^{\infty} f_{ij}^{(n)} \leq 1.$$

Sin embargo, esta suma puede ser estrictamente menor que 1, lo que significa que un proceso que al iniciar se encuentra en el estado i puede no alcanzar nunca el estado j . Cuando la suma sí es igual a 1, las $f_{ij}^{(n)}$ (para $n = 1, 2, \dots$) pueden considerarse como una distribución de probabilidad de la variable aleatoria, el tiempo de primera pasada.

Aunque puede ser tedioso calcular $f_{ij}^{(n)}$ para toda n , es relativamente sencillo obtener el tiempo esperado de primera pasada del estado i al estado j . Sea μ_{ij} esta esperanza, que se define como

$$\mu_{ij} = \begin{cases} \infty & \text{si } \sum_{n=1}^{\infty} f_{ij}^{(n)} < 1 \\ \sum_{n=1}^{\infty} n f_{ij}^{(n)} & \text{si } \sum_{n=1}^{\infty} f_{ij}^{(n)} = 1. \end{cases}$$

Siempre que

$$\sum_{n=1}^{\infty} f_{ij}^{(n)} = 1,$$

μ_{ij} satisface, de manera única, la ecuación

$$\mu_{ij} = 1 + \sum_{k \neq j} p_{ik} \mu_{kj}.$$

Esta ecuación reconoce que la primera transición desde el estado i puede ser al estado j o a algún otro estado k . Si es al estado j , el tiempo de primera pasada es 1. Dado que la primera transición es a algún estado k ($k \neq j$), lo que ocurre con probabilidad p_{ik} , el tiempo esperado de primera pasada condicional del estado i al estado j es $1 + \mu_{kj}$. Cuando se combinan estos hechos, y se suman todas las posibilidades de la primera transición, se llega a esta ecuación.

En el ejemplo del inventario, estas ecuaciones de μ_{ij} se pueden usar para calcular el tiempo esperado hasta que ya no se tengan cámaras en el almacén, dado que el proceso se inicia cuando se

tienen tres cámaras. Este tiempo esperado es igual que el tiempo esperado de primera pasada μ_{30} . Como todos los estados son recurrentes, el sistema de ecuaciones conduce a las expresiones

$$\begin{aligned}\mu_{30} &= 1 + p_{31}\mu_{10} + p_{32}\mu_{20} + p_{33}\mu_{30}, \\ \mu_{20} &= 1 + p_{21}\mu_{10} + p_{22}\mu_{20} + p_{23}\mu_{30}, \\ \mu_{10} &= 1 + p_{11}\mu_{10} + p_{12}\mu_{20} + p_{13}\mu_{30},\end{aligned}$$

o

$$\begin{aligned}\mu_{30} &= 1 + 0.184\mu_{10} + 0.368\mu_{20} + 0.368\mu_{30}, \\ \mu_{20} &= 1 + 0.368\mu_{10} + 0.368\mu_{20}, \\ \mu_{10} &= 1 + 0.368\mu_{10}.\end{aligned}$$

La solución simultánea de este sistema es

$$\begin{aligned}\mu_{10} &= 1.58 \text{ semanas}, \\ \mu_{20} &= 2.51 \text{ semanas}, \\ \mu_{30} &= 3.50 \text{ semanas},\end{aligned}$$

de manera que el tiempo esperado hasta que la tienda se quede sin cámaras es 3.50 semanas. Al hacer estos cálculos para μ_{30} también se obtienen μ_{20} y μ_{10} .

En el caso de μ_{ij} con $j = i$, μ_{ii} es el número esperado de transiciones hasta que el proceso regrese al estado inicial i , y se llama **tiempo esperado de recurrencia** del estado i . Después de obtener las probabilidades de estado estable ($\pi_0, \pi_1, \dots, \pi_M$) como se describió en la sección anterior, los tiempos esperados de recurrencia se calculan de inmediato como

$$\mu_{ii} = \frac{1}{\pi_i}, \quad \text{para } i = 0, 1, \dots, M.$$

Entonces, en el ejemplo de inventario, donde, $\pi_0 = 0.286$, $\pi_1 = 0.285$, $\pi_2 = 0.263$ y $\pi_3 = 0.166$, los tiempos de recurrencia esperados correspondientes son

$$\begin{aligned}\mu_{00} &= \frac{1}{\pi_0} = 3.50 \text{ semanas}, & \mu_{22} &= \frac{1}{\pi_2} = 3.80 \text{ semanas}, \\ \mu_{11} &= \frac{1}{\pi_1} = 3.51 \text{ semanas}, & \mu_{33} &= \frac{1}{\pi_3} = 6.02 \text{ semanas}.\end{aligned}$$

16.7 ESTADOS ABSORBENTES

En la sección 16.4 se señaló que el estado k se llama *estado absorbente* si $p_{kk} = 1$, de manera que una vez que la cadena llega al estado k permanece ahí para siempre. Si k es un estado absorbente y el proceso comienza en el estado i , la probabilidad de llegar en *algún* momento a k se llama **probabilidad de absorción** al estado k , dado que el sistema comenzó en el estado i . Esta probabilidad se denota por f_{ik} .

Si existen dos o más estados absorbentes en una cadena de Markov y es evidente que el proceso será absorbido en uno de estos estados, es deseable encontrar estas probabilidades de absorción. Dichas probabilidades pueden obtenerse con sólo resolver un sistema de ecuaciones lineales que considera todas las posibilidades de la primera transición y después, dada la primera transición, considera la probabilidad condicional de absorción al estado k . En particular, si el estado k es un estado absorbente, el conjunto de probabilidades de absorción f_{ik} satisface el sistema de ecuaciones

$$f_{ik} = \sum_{j=0}^M p_{ij}f_{jk}, \quad \text{para } i = 0, 1, \dots, M,$$

sujeta a las condiciones

$$\begin{aligned}f_{kk} &= 1, \\ f_{ik} &= 0, \quad \text{si el estado } i \text{ es recurrente e } i \neq k.\end{aligned}$$

Las probabilidades de absorción son importantes en las caminatas aleatorias. Una **caminata aleatoria** es una cadena de Markov con la propiedad de que, si el sistema se encuentra en el estado i , entonces en una sola transición, o bien permanecerá en i o se moverá a uno de los dos estados inmediatamente adyacentes a i . Por ejemplo, la caminata aleatoria con frecuencia se usa como modelo para situaciones que incluyen juegos de azar.

Un segundo ejemplo de juegos. Para ilustrar el uso de probabilidades de absorción en una caminata aleatoria, considere un ejemplo sobre juegos de azar similar al que se presentó en la sección 16.2, pero ahora suponga que dos jugadores (A y B), con 2 dólares cada uno, aceptan seguir jugando y apostar 1 dólar cada vez hasta que uno de ellos quiebre. La probabilidad de que A gane una apuesta es $\frac{1}{3}$, por lo que la probabilidad de que gane B es $\frac{2}{3}$. El número de dólares que tiene el jugador A antes de cada apuesta (0, 1, 2, 3 o 4) proporciona los estados de una cadena de Markov con la matriz de transición

$$\mathbf{P} = \begin{array}{c|ccccc} & \text{Estado} & 0 & 1 & 2 & 3 & 4 \\ \hline & 0 & 1 & 0 & 0 & 0 & 0 \\ & 1 & \frac{2}{3} & 0 & \frac{1}{3} & 0 & 0 \\ & 2 & 0 & \frac{2}{3} & 0 & \frac{1}{3} & 0 \\ & 3 & 0 & 0 & \frac{2}{3} & 0 & \frac{1}{3} \\ & 4 & 0 & 0 & 0 & 0 & 1 \end{array}.$$

Si se inicia en el estado 2, la probabilidad de absorción al estado 0 (A pierde todo su dinero) se puede obtener al resolver para f_{20} a partir del sistema de ecuaciones que se proporcionó al comienzo de la sección,

$$f_{00} = 1 \text{ (puesto que el estado 0 es un estado absorbente),}$$

$$f_{10} = \frac{2}{3} f_{00} + \frac{1}{3} f_{20},$$

$$f_{20} = \frac{2}{3} f_{10} + \frac{1}{3} f_{30},$$

$$f_{30} = \frac{2}{3} f_{20} + \frac{1}{3} f_{40},$$

$$f_{40} = 0 \text{ (puesto que el estado 4 es un estado absorbente).}$$

De este sistema de ecuaciones se obtiene

$$f_{20} = \frac{2}{3} \left(\frac{2}{3} + \frac{1}{3} f_{20} \right) + \frac{1}{3} \left(\frac{2}{3} f_{20} \right) = \frac{4}{9} + \frac{4}{9} f_{20},$$

que se reduce a $f_{20} = \frac{4}{5}$ como la probabilidad de absorción en el estado 0.

De manera similar, la probabilidad de que A termine con 4 dólares (B quiebre) cuando comienza con 2 dólares (estado 2) se obtiene al obtener f_{24} del sistema de ecuaciones,

$$f_{04} = 0 \text{ (puesto que 0 es un estado absorbente),}$$

$$f_{14} = \frac{2}{3} f_{04} + \frac{1}{3} f_{24},$$

$$f_{24} = \frac{2}{3} f_{14} + \frac{1}{3} f_{34},$$

$$f_{34} = \frac{2}{3} f_{24} + \frac{1}{3} f_{44},$$

$$f_{44} = 1 \text{ (puesto que 4 es un estado absorbente).}$$

De aquí se obtiene

$$f_{24} = \frac{2}{3} \left(\frac{1}{3} f_{24} \right) + \frac{1}{3} \left(\frac{2}{3} f_{24} + \frac{1}{3} \right) = \frac{4}{9} f_{24} + \frac{1}{9},$$

de manera que $f_{24} = \frac{1}{5}$ es la probabilidad de absorción en el estado 4.

Ejemplo de evaluación de crédito. Existen muchas otras situaciones en las cuales los estados absorbentes tienen un papel importante. Considere una tienda departamental que clasifica el saldo de la cuenta de un cliente como pagada (estado 0), 1 a 30 días de retraso (estado 1), 31 a 60 días de retraso (estado 2) o mala deuda (estado 3). Las cuentas se revisan cada *mes* y se determina el estado de cada cliente. En general, los créditos no se extienden y se espera que los deudores paguen sus cuentas lo más pronto posible. En ocasiones, los clientes no pagan en la fecha límite. Si esto ocurre cuando el saldo queda dentro de los 30 días de retraso, la tienda considera que este cliente permanece en el estado 1. Si esto ocurre cuando el saldo está entre 31 y 60 días de retraso, la tienda considera que el cliente se mueve al estado 2. Los clientes que tienen más de 60 días de retraso se clasifican en la categoría de una mala deuda (estado 3), en cuyo caso envía las cuentas a una agencia de cobro.

Después de examinar los datos de años anteriores en la progresión mes a mes de los clientes individuales de estado a estado, la tienda ha desarrollado la siguiente matriz de transición:⁴

Estado \ Estado	0: Saldo pagado	1: 1 a 30 días de retraso	2: 31 a 60 días de retraso	3: Mala deuda
0: saldo pagado	1	0	0	0
1: 1 a 30 días de retraso	0.7	0.2	0.1	0
2: 31 a 60 días de retraso	0.5	0.1	0.2	0.2
3: mala deuda	0	0	0	1

Aunque cada cliente acaba por llegar al estado 0 o al estado 3, la tienda se interesa en determinar la probabilidad de que un cliente llegue a ser un mal deudor dado que la cuenta pertenece al estado de 1 a 30 días de retraso, y de igual forma, si se encuentra en 31 a 60 días de retraso.

Para obtener esta información debe resolverse el conjunto de ecuaciones que se presentó al principio de esta sección para obtener f_{13} y f_{23} . Las siguientes dos ecuaciones se obtienen por sustitución:

$$f_{13} = p_{10}f_{03} + p_{11}f_{13} + p_{12}f_{23} + p_{13}f_{33},$$

$$f_{23} = p_{20}f_{03} + p_{21}f_{13} + p_{22}f_{23} + p_{23}f_{33}.$$

Como $f_{03} = 0$ y $f_{33} = 1$, ahora se tienen dos ecuaciones con dos incógnitas, esto es,

$$(1 - p_{11})f_{13} = p_{13} + p_{12}f_{23},$$

$$(1 - p_{22})f_{23} = p_{23} + p_{21}f_{13}.$$

Al sustituir los valores de la matriz de transición se llega a

$$0.8f_{13} = 0.1f_{23},$$

$$0.8f_{23} = 0.2 + 0.1f_{13},$$

y la solución es

$$f_{13} = 0.032,$$

$$f_{23} = 0.254.$$

Entonces, alrededor de 3% de los clientes cuyas cuentas tienen de 1 a 30 días de retraso y alrededor de 25% de los clientes con 31 a 60 días de retraso llegan a ser malos deudores.

16.8 CADENAS DE MARKOV DE TIEMPO CONTINUO

En todas las secciones anteriores se supuso que el parámetro t del tiempo es discreto (es decir, $t = 0, 1, 2, \dots$). Este supuesto es adecuado para muchos problemas, pero existen ciertos casos

⁴Los clientes que pagaron su saldo (en el estado 0) y después se retrasan en el pago de nuevas compras se consideran clientes “nuevos” que inician en el estado 1.

(como en algunos modelos de colas, que se estudiarán en el capítulo 17) en los que se requiere un parámetro (llamado t') de tiempo continuo, debido a que la evolución del proceso se observa de manera *continua* a través del tiempo. La definición de cadena de Markov que se dio en la sección 16.2 también se extiende a esos procesos continuos. Esta sección está dedicada a la descripción de estas “cadenas de Markov de tiempo continuo” y sus propiedades.

Formulación

Como se hizo con anterioridad, se etiquetan los **estados** posibles del sistema $0, 1, \dots, M$. Si se comienza en el tiempo 0 y se deja que el parámetro de tiempo t' corra de manera continua para $t' \geq 0$, sea la variable aleatoria $X(t')$ el estado del sistema en el tiempo t' . Entonces $X(t')$ toma uno de sus $(M + 1)$ valores posibles en un intervalo $0 \leq t' < t_1$, después salta a otro valor en el siguiente intervalo $t_1 \leq t' < t_2$ y así sucesivamente, donde los puntos de tránsito ($t_1, t_2, \dots$) son puntos aleatorios en el tiempo (*no* necesariamente enteros).

Ahora considere los tres puntos en el tiempo 1) $t' = r$ (donde $r \geq 0$), 2) $t' = s$ (donde $s > r$) y 3) $t' = s + t$ (donde $t > 0$), interpretados como sigue:

$$\begin{aligned} t' = r & \text{ es un tiempo pasado,} \\ t' = s & \text{ es el tiempo actual,} \\ t' = s + t & \text{ es } t \text{ unidades de tiempo hacia el futuro.} \end{aligned}$$

Por lo tanto, el estado del sistema se ha observado en los tiempos $t' = s$ y $t' = r$. Estos estados se etiquetan como

$$X(s) = i \quad \text{y} \quad X(r) = x(r).$$

Dada esta información, el paso natural es buscar la distribución de probabilidad del estado del sistema en el tiempo $t' = s + t$. En otras palabras, ¿cuál es la probabilidad

$$P\{X(s + t) = j \mid X(s) = i \text{ y } X(r) = x(r)\}, \quad \text{para } j = 0, 1, \dots, M?$$

Suele ser muy difícil calcular estas probabilidades condicionales. Sin embargo, esta tarea se simplifica en gran medida si el proceso estocástico involucrado posee la siguiente propiedad clave.

Un proceso estocástico de tiempo continuo $\{X(t'); t' \geq 0\}$ tiene la **propiedad markoviana** si

$$P\{X(t + s) = j \mid X(s) = i \text{ y } X(r) = x(r)\} = P\{X(t + s) = j \mid X(s) = i\},$$

para toda $i, j = 0, 1, \dots, M$ y para toda $r \geq 0, s > r$, y $t > 0$.

Observe que $P\{X(t + s) = j \mid X(s) = i\}$ es una **probabilidad de transición**, igual que las probabilidades de transición de las cadenas de Markov de tiempos discretos que se estudió en las secciones anteriores, donde la única diferencia es que ahora no es necesario que t sea entero.

Si las probabilidades de transición son independientes de s , de manera que

$$P\{X(t + s) = j \mid X(s) = i\} = P\{X(t) = j \mid X(0) = i\}$$

para toda $s > 0$, se llaman **probabilidades de transición estacionarias**.

Para simplificar la notación se denotará estas probabilidades estacionarias por

$$p_{ij}(t) = P\{X(t) = j \mid X(0) = i\},$$

donde se hará referencia a $p_{ij}(t)$ como la **función de probabilidad de transición de tiempo continuo**. Se supone que

$$\lim_{t \rightarrow 0} p_{ij}(t) = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j. \end{cases}$$

Ahora se pueden definir las cadenas de Markov de tiempo continuo que se estudiarán en esta sección.

Un proceso estocástico de tiempo continuo $\{X(t'); t' \geq 0\}$ es una **cadena de Markov de tiempo continuo** si presenta la *propiedad markoviana*.

Recuadro de aplicación

La compañía **PSA Peugeot Citroën**, cuya matriz se encuentra en Francia, es una de las fábricas de autos más grandes del mundo. Cuando se tomó la decisión de introducir 25 nuevos modelos entre 2001 y 2004, la administración de PSA decidió rediseñar sus talleres de carrocerías con el fin de que las de varios modelos pudieran ensamblarse en sólo uno de ellos. Se le asignó a un grupo de IO las tareas de supervisar el proceso de diseño y desarrollar herramientas para evaluar, con antelación, la eficiencia de las líneas de producción de cualquier modelo en los talleres.

El equipo de IO desarrolló métodos aproximados rápidos y métodos detallados más extensos para realizar esta tarea. Sin embargo, un factor clave que debía ser incorporado en todos los métodos era determinar la frecuencia con que cada una de las máquinas del taller se descomponía y, por lo tanto, debía ser reparada, lo cual detenía el flujo de trabajo en ese taller. El grupo de IO utilizó una *cadena de Markov de tiempo continuo* para representar la evolución de cada tipo de máquina en el cambio que representa que la máquina esté en estado operativo (que funcione correctamente) y sin funcionar (descompuesta). Por lo tanto, la cadena de Markov sólo tiene dos estados, *en funcionamiento* y *descompuesta*, con un periodo

(pequeño) de transición entre los estados en funcionamiento y descompuesta y un periodo de transición (más largo) entre los estados *descompuesta* y *en funcionamiento*. El equipo llegó a la conclusión de que la velocidad de transición entre ambos estados es esencialmente el mismo sin tomar en cuenta si la máquina en realidad trabaja o está ociosa, por lo que no es necesario dividir el primero de ellos en los estados en *operación* y *ocioso*.

Esta aplicación de la IO, que incluyó esta sencilla cadena de Markov de tiempo continuo, tuvo un efecto dramático en la compañía. Mediante una mejora sustancial de la eficiencia de las líneas de producción en los talleres PSA con una mínima inversión de capital y sin comprometer la calidad, dicha aplicación **contribuyó con 130 millones de dólares a las ganancias de PSA** (alrededor de 6.5% de la ganancia total) sólo en el primer año.

Fuente: A. Patchong, T. Lemoine y G. Kern: "Improving Car Body Production at PSA Peugeot Citroën", en *Interfaces*, **33**(1): 36-49, enero-febrero de 2003. (En el sitio en internet de este libro —www.mhhe.com/hillier—) se proporciona una liga hacia este artículo.)

Aquí se restringirá el estudio a las cadenas de Markov de tiempo continuo con las siguientes propiedades.

1. Un número finito de estados.
2. Probabilidades de transición estacionarias.

Algunas variables aleatorias importantes

En el análisis de las cadenas de Markov de tiempo continuo, un conjunto importante de variables aleatorias es el siguiente.

Cada vez que el proceso entra en el estado i , la cantidad de tiempo que pasa en ese estado antes de moverse a uno diferente es una variable aleatoria T_i , donde $i = 0, 1, \dots, M$.

Suponga que el proceso entra en el estado i en el tiempo $t' = s$. Entonces, para cualquier cantidad de tiempo fijo $t > 0$, observe que $T_i > t$ si y sólo si $X(t') = i$ para toda t' en el intervalo $s \leq t' \leq s + t$. Por lo tanto, la propiedad markoviana (con probabilidades de transición estacionarias) implica que

$$P\{T_i > t + s \mid T_i > s\} = P\{T_i > t\}.$$

Ésta es una condición bastante rara para una distribución de probabilidad. Dice que la distribución de probabilidad del tiempo *que falta* para que el proceso haga una transición fuera de un estado dado siempre es la misma, independientemente de cuánto tiempo haya pasado el proceso en ese estado. En efecto, la variable aleatoria no tiene memoria; el proceso olvida su historia. Existe sólo una distribución de probabilidad (continua) que posee esta propiedad, la *distribución exponencial*. Esta distribución tiene un solo parámetro, llámese q , donde la media es $1/q$ y la función de distribución acumulada es

$$P\{T_i \leq t\} = 1 - e^{-qt}, \quad \text{para } t \geq 0.$$

(En la sección 17.4 se describirá con detalle las propiedades de la distribución exponencial.)

Este resultado conduce a una forma equivalente para describir una cadena de Markov de tiempo continuo:

1. La variable aleatoria T_i tiene una distribución exponencial con media $1/q_i$.
2. Cuando sale de un estado i , el proceso se mueve a otro estado j , con probabilidad p_{ij} , donde p_{ij} satisface las condiciones

$$p_{ii} = 0 \quad \text{para toda } i,$$

y

$$\sum_{j=0}^M p_{ij} = 1 \quad \text{para toda } i.$$

3. El siguiente estado que se visita después del estado i es independiente del tiempo que pasó en el estado i .

Igual que las probabilidades de transición de un paso tuvieron un papel primordial para describir una cadena de Markov de tiempos discretos, el papel análogo en el caso de la cadena de Markov de tiempo continuo lo tienen las intensidades de transición.

Las **intensidades de transición** son

$$q_i = -\frac{d}{dt}p_{ii}(0) = \lim_{t \rightarrow 0} \frac{1 - p_{ii}(t)}{t}, \quad \text{para } i = 0, 1, 2, \dots, M,$$

y

$$q_{ij} = \frac{d}{dt}p_{ij}(0) = \lim_{t \rightarrow 0} \frac{p_{ij}(t)}{t} = q_i p_{ij}, \quad \text{para todo } j \neq i,$$

donde $p_{ij}(t)$ es la *función de probabilidad de transición de tiempo continuo* que se presentó al principio de la sección y p_{ij} es la probabilidad descrita en la propiedad 2 del párrafo anterior. Más aún, q_i , según se definió aquí, también resulta ser el parámetro de la distribución exponencial de T_i (vea la propiedad 1 del párrafo anterior).

La interpretación intuitiva de q_i y q_{ij} es que son *tasas de transición*. En particular, q_i es la *tasa de transición hacia fuera del estado i* en el sentido de que q_i es el número esperado de veces que el proceso deja el estado i por unidad de tiempo que pasa en el estado i . (De esta forma, q_i es el recíproco del tiempo esperado que el proceso pasa en el estado i por cada visita al estado i ; es decir, $q_i = 1/E[T_i]$.) De manera similar, q_{ij} es la *tasa de transición del estado i al estado j* en el sentido de que q_{ij} es el número esperado de veces que el proceso transita del estado i al estado j por unidad de tiempo que pasa en el estado i . Así,

$$q_i = \sum_{j \neq i} q_{ij}.$$

Igual que q_i es el parámetro de la distribución exponencial de T_i , cada q_{ij} es el parámetro de una distribución exponencial de una variable aleatoria relacionada que se describe en seguida.

Cada vez que el proceso entra al estado i , la cantidad de tiempo que pasará en el estado i antes de que ocurra una transición al estado j (si no ocurre antes una transición a algún otro estado) es una variable aleatoria T_{ij} , donde $i, j = 0, 1, \dots, M$ y $j \neq i$. Las T_{ij} son variables aleatorias independientes, donde cada T_{ij} tiene una *distribución exponencial* con parámetro q_{ij} , de manera que $E[T_{ij}] = 1/q_{ij}$. El tiempo que pasa en el estado i hasta que ocurre una transición (T_i) es el *mínimo* (sobre $j \neq i$) de las T_{ij} . Cuando ocurre la transición, la probabilidad de que sea al estado j es $p_{ij} = q_{ij}/q_i$.

Probabilidades de estado estable

Igual que las probabilidades de transición de una cadena de Markov de tiempos discretos satisfacen las ecuaciones de Chapman-Kolmogorov, la función de probabilidad de transición de tiempo con-

tinuo satisface estas ecuaciones. Entonces, para cualesquiera estados i y j , y números no negativos t y s ($0 \leq s \leq t$),

$$p_{ij}(t) = \sum_{k=0}^M p_{ik}(s)p_{kj}(t-s).$$

Se dice que un par de estados i y j *se comunican* si existen tiempos t_1 y t_2 tales que $p_{ij}(t_1) > 0$ y $p_{ji}(t_2) > 0$. Se dice que todos los estados que se comunican forman una *clase*. Si todos los estados de una cadena forman una sola clase, es decir, si la cadena de Markov es *irreducible* (lo que se supondrá de aquí en adelante), entonces,

$$p_{ij}(t) > 0, \quad \text{para toda } t > 0 \text{ y todos los estados } i \text{ y } j.$$

Aún más,

$$\lim_{t \rightarrow \infty} p_{ij}(t) = \pi_j$$

siempre existe y es independiente del estado inicial de la cadena de Markov, para $j = 0, 1, \dots, M$. Estas probabilidades limitantes se conocen como las **probabilidades de estado estable** (o *probabilidades estacionarias*) de la cadena de Markov.

Las π_j satisfacen las ecuaciones

$$\pi_j = \sum_{i=0}^M \pi_i p_{ij}(t), \quad \text{para } j = 0, 1, \dots, M \text{ y para toda } t \geq 0.$$

Sin embargo, las siguientes **ecuaciones de estado estable** proporcionan un sistema de ecuaciones más útil para obtener las probabilidades de estado estable:

$$\pi_j q_j = \sum_{i \neq j} \pi_i q_{ij}, \quad \text{para } j = 0, 1, \dots, M.$$

y

$$\sum_{j=0}^M \pi_j = 1.$$

La ecuación de estado estable del estado j tiene una interpretación intuitiva. El lado izquierdo ($\pi_j q_j$) es la *tasa* a la que el proceso *deja* el estado j , puesto que π_j es la probabilidad (estable) de que el proceso esté en el estado j y q_j es la tasa de transición hacia fuera de j dado que el proceso se encuentra en el estado j . De manera similar, cada término del lado derecho ($\pi_i q_{ij}$) es la *tasa* a la que el proceso *entra* al estado j desde el estado i , puesto que q_{ij} es la tasa de transición del estado i al j dado que el proceso se encuentra en el estado i . Si se suma sobre toda $i \neq j$, todo el lado derecho proporciona la tasa a la que el proceso entra al estado j desde cualquier otro estado. Por eso la ecuación global establece que la tasa a la cual el proceso deja el estado j debe ser igual a la tasa a la que entra en el estado j . Así, esta ecuación es análoga a las ecuaciones de conservación del flujo de los cursos de ingeniería y ciencias.

Como cada una de las primeras $M + 1$ *ecuaciones de estado estable* requiere que las dos tasas estén *balanceadas* (sean iguales), a veces estas ecuaciones se llaman **ecuaciones de balance**.

Ejemplo. Un taller tiene dos máquinas idénticas en operación continua excepto cuando se descomponen. Como lo hacen con bastante frecuencia, la tarea con más alta prioridad para la persona de mantenimiento que trabaja tiempo completo es repararlas cuando sea necesario.

El tiempo que se requiere para reparar una máquina tiene distribución exponencial con media de $\frac{1}{2}$ día. Una vez que se termina la reparación, el tiempo que transcurre hasta la siguiente descompostura tiene distribución exponencial con media de un día. Estas distribuciones son independientes.

Defina la variable aleatoria $X(t')$ como

$$X(t') = \text{número de máquinas descompuestas en el tiempo } t',$$

de forma que los valores posibles de $X(t')$ son 0, 1, 2. Por lo tanto, si se corre el parámetro t' de manera continua desde el tiempo 0, el proceso estocástico de tiempo continuo $\{X(t'); t' \geq 0\}$ proporciona la evolución del número de máquinas descompuestas.

Como tanto el tiempo de reparación como el tiempo hasta la siguiente descompostura tienen distribuciones exponenciales, $\{X(t'); t' \geq 0\}$ es una *cadena de Markov de tiempo continuo*⁵ con estados 0, 1, 2. En consecuencia, se pueden usar las probabilidades de estado estable dadas en la subsección anterior para encontrar la distribución de probabilidad de estado estable del número de máquinas descompuestas. Para hacer esta tarea se debe determinar todas las *tasas de transición*, esto es, las q_i y q_{ij} para $i, j = 0, 1, 2$.

El estado (número de máquinas descompuestas) aumenta en 1 cuando ocurre una descompostura y disminuye en 1 cuando se termina una reparación. Como tanto las descomposturas como las reparaciones ocurren una a la vez, $q_{02} = 0$ y $q_{20} = 0$. El tiempo esperado de reparación es de $\frac{1}{2}$ día, de manera que la tasa a la que se terminan las reparaciones (cuando hay máquinas descompuestas) es 2 por día, lo que implica que $q_{21} = 2$ y $q_{10} = 2$. De manera similar, el tiempo esperado hasta que se descompone una máquina en operación es de un día, de manera que la tasa a la que se descompone (cuando está en operación) es de un por día; esto implica que $q_{12} = 1$. Durante los tiempos en los que las dos máquinas operan, las descomposturas ocurren a una tasa de $1 + 1 = 2$ por día, por lo que $q_{01} = 2$.

Estas tasas de transición se resumen en el diagrama de tasas que se muestra en la figura 16.5. Se pueden usar para calcular la *tasa de transición total* hacia fuera de cada estado.

$$\begin{aligned} q_0 &= q_{01} = 2. \\ q_1 &= q_{10} + q_{12} = 3. \\ q_2 &= q_{21} = 2. \end{aligned}$$

Si se sustituyen todas las tasas en las ecuaciones de estado estable de la subsección anterior, se obtiene:

$$\begin{aligned} \text{Ecuación de balance para el estado 0: } & 2\pi_0 = 2\pi_1 \\ \text{Ecuación de balance para el estado 1: } & 3\pi_1 = 2\pi_0 + 2\pi_2 \\ \text{Ecuación de balance para el estado 2: } & 2\pi_2 = \pi_1 \\ \text{Las probabilidades suman 1: } & \pi_0 + \pi_1 + \pi_2 = 1 \end{aligned}$$


Cualquiera de las ecuaciones de balance (por ejemplo, la segunda) se puede eliminar como redundante, y la solución simultánea de las ecuaciones restantes proporciona la distribución de estado estable como

$$(\pi_0, \pi_1, \pi_2) = \left(\frac{2}{5}, \frac{2}{5}, \frac{1}{5}\right).$$

Entonces, en el largo plazo, ambas máquinas estarán descompuestas en forma simultánea 20% del tiempo y una máquina estará descompuesta otro 40% del tiempo.

En el siguiente capítulo (sobre teoría de colas) se incluyen muchos ejemplos de cadenas de Markov de tiempo continuo. En realidad, la mayor parte de los modelos básicos de la teoría

■ **FIGURA 16.5**
Diagrama de tasas del
ejemplo de una cadena
de Markov de tiempo
continuo.



⁵ La prueba de este hecho necesita usar dos propiedades de la distribución exponencial que se presentan en la sección 17.4 (la *falta de memoria* y que el *mínimo de exponenciales es exponencial*), puesto que estas propiedades implican que las variables aleatorias T_{ij} que se introdujeron antes sin duda tienen distribución exponencial.

de colas cae dentro de esta categoría. El ejemplo que se acaba de dar en realidad se ajusta a uno de estos modelos (la variación de fuente de entrada finita al modelo $M/M/s$ que se incluye en la sección 17.6).

■ REFERENCIAS SELECCIONADAS

1. Bhat, U. N. y G. K. Miller: *Elements of Applied Stochastic Processes*, 3a. ed., Wiley, Nueva York, 2002.
2. Bini, D., G. Latouche y B. Meini: *Numerical Methods for Structured Markov Chains*, Oxford University Press, Nueva York, 2005.
3. Bukiet, B., E. R. Harold y J. L. Palacios: "A Markov Chain Approach to Baseball", en *Operations Research*, **45**: 14-23, 1997.
4. Ching, W. K. y M. K. Ng: *Markov Chains: Models, Algorithms and Applications*, Springer, Nueva York, 2006.
5. Grassmann, W. K. (ed.) *Computational Probability*; Kluwer Academic Publishers (actualmente Springer), Boston, MA, 2000.
6. Mamon, R. S. y R. J. Elliot (eds.): *Hidden Markov Models in Finance*, Springer, Nueva York, 2007.
7. Resnick, S. I.: *Adventures in Stochastic Processes*, Birkhäuser, Boston, 1992.
8. Tijms, H. C.: *A First Course in Stochastic Models*, Wiley, Nueva York, 2003.

■ AYUDAS DE APRENDIZAJE PARA ESTE CAPÍTULO EN EL SITIO EN INTERNET DE ESTE LIBRO (www.mhhe.com/hillier)

Ejemplos resueltos:

Ejemplos para el capítulo 16

Rutinas automáticas en IOR Tutorial:

Introducción de una matriz de transición (Enter Transition Matrix)

Ecuaciones Chapman-Kolmogorov (Chapman-Kolmogorov Equations)

Probabilidades de estado estable (Steady-State Probabilities)

Archivo de LINGO para ejemplos seleccionados "Ch. 16—Markov Chains"

Glosario para el capítulo 16

Vea el apéndice 1 para la documentación del software.

■ PROBLEMAS

Los símbolos a la izquierda de algunos problemas (o de sus incisos) significan lo siguiente:

C: Use la computadora con las rutinas automáticas correspondientes mencionadas con anterioridad (u otras equivalentes) para resolver el problema.

Un asterisco en el número del problema indica que al final del libro se da al menos una respuesta parcial.

16.2-1. Lea el artículo de referencia que describe el estudio de IO que se resume en el recuadro de aplicación que se presentó en la sección 16.2. Describa de manera breve la forma en que se aplicó una cadena de Markov a este estudio. Después, elabore una lista de los beneficios financieros y de otro tipo que arrojó dicho estudio.

16.2-2. Suponga que la probabilidad de lluvia mañana es de 0.5 si hoy llueve y que la probabilidad de un día claro (sin lluvia) mañana es de 0.9 si hoy está despejado. Suponga además que estas probabilidades no cambian si también se proporciona información sobre el clima de días anteriores a hoy.

a) Explique por qué los supuestos establecidos implican que la *propiedad markoviana* se cumple en el caso de la evolución del clima.

b) Formule la evolución del clima como una cadena de Markov mediante la definición de sus estados y la construcción de su matriz de transición (de un paso).

16.2-3. Considere la segunda versión del modelo de mercado de acciones que se presentó en la sección 16.2. Si mañana la acción

sube o no depende de si subió o no hoy y ayer. Si la acción subió hoy y ayer, mañana subirá con probabilidad α_1 . Si la acción subió hoy y ayer bajó, mañana subirá con probabilidad α_2 . Si la acción bajó hoy y ayer subió, la probabilidad de que suba mañana es α_3 . Por último, si la acción bajó hoy y ayer, la probabilidad de que suba mañana es α_4 .

- Construya la matriz de transición de un paso para la cadena de Markov.
- Explique por qué los estados que se utilizaron para esta cadena de Markov hacen que la definición matemática de la propiedad markoviana se cumpla aunque lo que pase en el futuro (mañana) depende de lo que ocurrió en el pasado (ayer) y en el presente (hoy).

16.2-4. Reconsidere el problema 16.2-3. Suponga ahora que el hecho de que la acción suba mañana depende de si subió o no hoy, ayer y anteayer. ¿Puede este problema formularse como una cadena de Markov? Si se puede, ¿cuáles son los estados posibles? Explique por qué estos estados dan al proceso la *propiedad markoviana*, mientras que los estados del problema 16.2-3 no lo hacen.

16.3-1. Reconsidere el problema 16.2-2.

- Utilice la rutina de las *ecuaciones de Chapman-Kolmogorov* del IOR Tutorial para encontrar la matriz de transición de n pasos $\mathbf{P}^{(n)}$ para $n = 2, 5, 10, 20$.
- La probabilidad de que llueva hoy es de 0.5. Use los resultados del inciso a) para determinar la probabilidad de que llueva dentro de n días, para $n = 2, 5, 10, 20$.
- Utilice la rutina de *probabilidades de estado estable* del IOR Tutorial para determinar las probabilidades de estado estable del clima. Compare las probabilidades de las matrices de transición de n pasos del inciso a) compare estas probabilidades de estado estable conforme n crece.

16.3-2. Suponga que una red de comunicaciones transmite dígitos binarios, 0 o 1, y que cada dígito se transmite 10 veces sucesivas. Durante cada transmisión, la probabilidad de que ese dígito se transmita correctamente es de 0.995. En otras palabras, existe una probabilidad de 0.005 de que el dígito transmitido se registre con el valor opuesto al final de la transmisión. Para cada transmisión después de la primera, el dígito transmitido es el que se registra al final de la transmisión anterior. Si X_0 denota el dígito binario que entra al sistema, X_1 el dígito binario que se apunta después de la primera transmisión, X_2 el dígito binario que se anota después de la segunda transmisión, ..., entonces $\{X_n\}$ es una cadena de Markov.

- Determine la matriz de transición (de un paso).
- Utilice el IOR Tutorial para encontrar la matriz de transición de 10 pasos $\mathbf{P}^{(10)}$. Utilice este resultado para identificar la probabilidad de que un dígito que entra a la red se registre correctamente después de la última transmisión.
- Suponga que la red se rediseña para mejorar la probabilidad de la exactitud de una sola transmisión de 0.995 a 0.998. Repita el inciso b) para encontrar la nueva probabilidad de que un dígito que entra a la red se registre correctamente después de la última transmisión.

16.3-3.* Una partícula se mueve sobre un círculo por puntos marcados 0, 1, 2, 3, 4 (en el sentido de las manecillas del reloj). La partícula

comienza en el punto 0. En cada paso tiene una probabilidad de 0.5 de moverse un punto en el sentido de las manecillas del reloj (0 sigue al 4) y una probabilidad de 0.5 de moverse un punto en el sentido opuesto. Sea X_n ($n \geq 0$) la localización en el círculo después del paso n . $\{X_n\}$ es entonces una cadena de Markov.

- Encuentre la matriz de transición (de un paso).
- Utilice el IOR Tutorial para determinar la matriz de transición de n pasos $\mathbf{P}^{(n)}$ para $n = 5, 10, 20, 40, 80$.
- Utilice el IOR Tutorial para determinar las probabilidades de estado estable de los estados de la cadena de Markov. Compare las probabilidades de la matriz de transición de n pasos que se obtuvo en el inciso b) con estas probabilidades de estado estable conforme n crece.

16.4-1.* Dadas las siguientes matrices de transición (de un paso) de una cadena de Markov, determine las clases de las cadenas de Markov y si son recurrentes o no.

$$a) \mathbf{P} = \begin{array}{c|cccc} \text{Estado} & 0 & 1 & 2 & 3 \\ \hline 0 & 0 & 0 & \frac{1}{3} & \frac{2}{3} \\ 1 & 1 & 0 & 0 & 0 \\ 2 & 0 & 1 & 0 & 0 \\ 3 & 0 & 1 & 0 & 0 \end{array}$$

$$b) \mathbf{P} = \begin{array}{c|cccc} \text{Estado} & 0 & 1 & 2 & 3 \\ \hline 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ 2 & 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ 3 & \frac{1}{2} & 0 & 0 & \frac{1}{2} \end{array}$$

16.4-2. Dadas las siguientes matrices de transición (de un paso) de una cadena de Markov, determine las clases de las cadenas de Markov y si son recurrentes o no.

$$a) \mathbf{P} = \begin{array}{c|cccc} \text{Estado} & 0 & 1 & 2 & 3 \\ \hline 0 & 0 & \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \\ 1 & \frac{1}{3} & 0 & \frac{1}{3} & \frac{1}{3} \\ 2 & \frac{1}{3} & \frac{1}{3} & 0 & \frac{1}{3} \\ 3 & \frac{1}{3} & \frac{1}{3} & \frac{1}{3} & 0 \end{array}$$

$$b) \mathbf{P} = \begin{array}{c|ccc} \text{Estado} & 0 & 1 & 2 \\ \hline 0 & 0 & 0 & 1 \\ 1 & \frac{1}{2} & \frac{1}{2} & 0 \\ 2 & 0 & 1 & 0 \end{array}$$

16.4-3. Dada la siguiente matriz de transición (de un paso), determine las clases de la cadena de Markov y si son recurrentes o no.

$$\mathbf{P} = \begin{array}{c|ccccc} \text{Estado} & 0 & 1 & 2 & 3 & 4 \\ \hline 0 & \frac{1}{4} & \frac{3}{4} & 0 & 0 & 0 \\ 1 & \frac{3}{4} & \frac{1}{4} & 0 & 0 & 0 \\ 2 & \frac{1}{3} & \frac{1}{3} & \frac{1}{3} & 0 & 0 \\ 3 & 0 & 0 & 0 & \frac{3}{4} & \frac{1}{4} \\ 4 & 0 & 0 & 0 & \frac{1}{4} & \frac{3}{4} \end{array}$$

16.4-4. Determine el periodo de los estados de la cadena de Markov que tiene la siguiente matriz de transición (de un paso).

$$P = \begin{array}{c|ccccc} \text{Estado} & 0 & 1 & 2 & 3 & 4 & 5 \\ \hline 0 & 0 & 0 & 0 & \frac{2}{3} & 0 & \frac{1}{3} \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 & 0 & 0 & 0 \\ 3 & 0 & \frac{1}{4} & 0 & 0 & \frac{3}{4} & 0 \\ 4 & 0 & 0 & 1 & 0 & 0 & 0 \\ 5 & 0 & \frac{1}{2} & 0 & 0 & \frac{1}{2} & 0 \end{array}$$

16.4-5. Considere la cadena de Markov que tiene la siguiente matriz de transición (de un paso).

$$P = \begin{array}{c|ccccc} \text{Estado} & 0 & 1 & 2 & 3 & 4 \\ \hline 0 & 0 & \frac{4}{5} & 0 & \frac{1}{5} & 0 \\ 1 & \frac{1}{4} & 0 & \frac{1}{2} & \frac{1}{4} & 0 \\ 2 & 0 & \frac{1}{2} & 0 & \frac{1}{10} & \frac{2}{5} \\ 3 & 0 & 0 & 0 & 1 & 0 \\ 4 & \frac{1}{3} & 0 & \frac{1}{3} & \frac{1}{3} & 0 \end{array}$$

- Determine las clases de esta cadena de Markov y, para cada clase, determine si es recurrente o transitoria.
- Para cada una de las clases identificadas en el inciso a), determine el periodo de los estados de esa clase.

16.5-1. Reconsidere el problema 16.2-2. Suponga ahora que las probabilidades dadas, 0.5 y 0.9, se sustituyen por valores arbitrarios α y β , respectivamente. Obtenga las *probabilidades de estado estable* del estado del clima en términos de α y β .

16.5-2. Se dice que una matriz de transición P es doblemente estocástica si la suma de los elementos de cada columna es igual a 1; esto es,

$$\sum_{i=0}^M p_{ij} = 1, \quad \text{para toda } j.$$

Si esta cadena es irreducible y aperiódica y consiste en $M + 1$ estados, demuestre que

$$\pi_j = \frac{1}{M + 1}, \quad \text{para } j = 0, 1, \dots, M.$$

16.5-3. Reconsidere el problema 16.3-3. Use los resultados del problema 16.5-2 para encontrar las probabilidades de estado estable de esta cadena de Markov. Luego encuentre qué pasa con estas probabilidades si, en cada paso, la probabilidad de moverse a un punto en el sentido de las manecillas del reloj cambia a 0.9 y la probabilidad de moverse a un punto en sentido opuesto cambia a 0.1.

c 16.5-4. La cervecería más importante de la costa oeste (denotada con la letra A) ha contratado a un experto en IO para que analice su posición en el mercado. En especial, la empresa está preocupada por las actividades de su mayor competidor (denotada con la letra B). El analista piensa que el cambio de marca se puede modelar como una cadena de Markov que incluya tres estados: los estados A y B repre-

sentan a los clientes que beben cerveza que producen las mencionadas cervcerías y el estado C representa todas las demás marcas. Los datos se toman cada mes y el analista construye la siguiente matriz de transición (de un paso) con datos históricos.

	A	B	C
A	0.7	0.2	0.1
B	0.2	0.75	0.05
C	0.1	0.1	0.8

¿Cuáles son los porcentajes de mercado en el estado estable de las dos cervcerías grandes?

16.5-5. Considere el siguiente problema de inventario de sangre al que se enfrenta un hospital. Se tiene necesidad de un tipo raro de sangre, como AB, Rh negativo. La demanda D (en pintas) durante un periodo de tres días está dada por

$$\begin{aligned} P\{D = 0\} &= 0.4, & P\{D = 1\} &= 0.3, \\ P\{D = 2\} &= 0.2, & P\{D = 3\} &= 0.1. \end{aligned}$$

Observe que la demanda esperada es de una pinta, puesto que $E(D) = 0.3(1) + 0.2(2) + 0.1(3) = 1$. Suponga que se surte sangre cada tres días. El hospital propone una política para recibir una pinta en cada entrega y usar primero la más antigua. Si se requiere más sangre de la que hay en el banco se hace un pedido de emergencia a un alto costo. La sangre se descarta si en 21 días no se ha usado. Denote el estado del sistema como el número de pintas en inventario exactamente después de una entrega. Observe que debido a la política de descartar la sangre, el estado más grande posible es 7.

- Construya la matriz de transición (de un paso) para esta cadena de Markov.
- Encuentre las probabilidades de estado estable para los estados de esta cadena de Markov.
- Use los resultados de b) para encontrar la probabilidad de estado estable de que sea necesario descartar una pinta durante un periodo de tres días. (*Sugerencia:* Si se usa primero la sangre más vieja, una pinta tiene 21 días sólo si el estado es 7 y entonces $D = 0$.)
- Utilice los resultados de b) para encontrar la probabilidad de estado de que se necesite una entrega de emergencia durante los tres días entre entregas normales.

c 16.5-6. En la sección 16.5 se calculó el costo promedio esperado (a largo plazo) por semana (basado sólo en costos de ordenar y costos de la demanda insatisfecha) del ejemplo del inventario de cámaras de la sección 16.1. Suponga que se cambia la política de inventarios. Siempre que el número de cámaras al final de la semana sea 0 o 1, se coloca una orden que aumente este número hasta 3. De otra manera, no se coloca una orden.

Calcule de nuevo el costo promedio esperado (a largo plazo) por semana con esta nueva política de inventarios.

16.5-7.* Considere el ejemplo de inventarios de la sección 16.1 con el siguiente cambio en la política. Si el nivel del inventario al final de la semana es 0 o 1, se ordenan dos cámaras adicionales. De otra manera, no se ordena ninguna. Suponga que los costos de almacenamiento son los mismos que en la segunda subsección de la sección 16.5.

- c a) Encuentre las probabilidades de estado estable de los estados de esta cadena de Markov.
- b) Encuentre el costo de almacenamiento esperado a largo plazo por semana.

16.5-8. Considere la siguiente política de inventarios para cierto producto. Si la demanda durante un periodo excede el número de unidades disponibles, esta demanda insatisfecha se considera como un faltante y se surte cuando se recibe la siguiente orden. Sea Z_n ($n = 0, 1, \dots$) la cantidad de inventario menos el número de unidades faltantes antes de ordenar al final del siguiente periodo n ($Z_0 = 0$). Si Z_n es cero o positivo, no hay pedidos atrasados. Si Z_n es negativo, entonces $-Z_n$ representa el número de unidades faltantes y el inventario es 0. Si al final del periodo n , $Z_n < 1$, se hace un pedido de $2m$ unidades, donde m es el entero más pequeño tal que $Z_n + 2m \geq 1$. Las órdenes se surten de inmediato.

Sean $D_1, D_2, \dots$, las demandas respectivas de un producto en los periodos 1, 2, $\dots$. Suponga que las D_n son variables aleatorias, independientes e idénticamente distribuidas que toman los valores 0, 1, 2, 3, 4, cada uno con probabilidad $\frac{1}{5}$. Sea X_n la cantidad en inventario después de ordenar al final del periodo n (con $X_0 = 2$), entonces

$$X_n = \begin{cases} X_{n-1} - D_n + 2m & \text{si } X_{n-1} - D_n < 1 \\ X_{n-1} - D_n & \text{si } X_{n-1} - D_n \geq 1 \end{cases} \quad (n = 1, 2, \dots),$$

donde $\{X_n\}$ ($n = 0, 1, \dots$) es una cadena de Markov. Tiene sólo dos estados, 1 y 2, ya que sólo se ordena cuando $Z_n = 0, -1, -2$ o -3 , en cuyo caso se pide 2, 2, 4 y 4 unidades, con lo que queda $X_n = 2, 1, 2, 1$, respectivamente.

- a) Encuentre la matriz de transición (de un paso).
- b) Use las ecuaciones de estado estable para determinar a mano las probabilidades de estado estable.
- c) Ahora use el resultado del problema 16.5-2 para encontrar las probabilidades de estado estable.
- d) Suponga que el costo de ordenar es $(2 + 2m)$ si se coloca una orden, y 0 en el caso contrario. El costo del inventario por periodo es Z_n si $Z_n \geq 0$ y cero en otro caso. El costo por incumplimiento en cada periodo es $-4Z_n$ si $Z_n < 0$ y cero en el otro caso. Encuentre el costo promedio esperado (a largo plazo) por unidad de tiempo.

16.5-9 Una unidad importante consta de dos componentes colocadas en paralelo. La unidad tiene un desempeño satisfactorio si una de las dos componentes está en operación. Por lo tanto, sólo se opera una de ellas a la vez, pero ambas se mantienen operativas (capaces de operar) tanto como sea posible, reparándolas cuando se necesite. Un componente operativo tiene una probabilidad de 0.2 de descomponerse en un periodo dado. Cuando ocurre, el componente en paralelo opera, si está operativo, al comenzar el siguiente periodo. Sólo se puede reparar un componente a la vez. Una reparación se inicia al principio del primer periodo disponible y termina al final del siguiente. Sea X_t un vector con dos elementos U y V , donde U es el número de componentes operativos al final del periodo t y V el número de periodos de reparación que transcurren para componentes que todavía no son operativos. Entonces, $V = 0$ si $U = 2$ o si $U = 1$ y la reparación del componente no operativo se está realizando. Como la reparación toma dos periodos, $V = 1$ si $U = 0$ (pues el componente no operativo espera iniciar su reparación mientras la otra entra al segundo periodo) o si $U = 1$ y el componente no operativo está en su segundo periodo. Así, el espacio de estados contiene cuatro estados $(2, 0), (1, 0), (0, 1)$

y $(1, 1)$. Denote estos estados por 0, 1, 2, 3, respectivamente. $\{X_t\}$ ($t = 0, 1, \dots$) es una cadena de Markov (suponga que $X_0 = 0$) con matriz de transición (de un paso)

$$P = \begin{matrix} & \begin{matrix} \text{Estado} & 0 & 1 & 2 & 3 \end{matrix} \\ \begin{matrix} 0 \\ 1 \\ 2 \\ 3 \end{matrix} & \begin{bmatrix} 0.8 & 0.2 & 0 & 0 \\ 0 & 0 & 0.2 & 0.8 \\ 0 & 1 & 0 & 0 \\ 0.8 & 0.2 & 0 & 0 \end{bmatrix} \end{matrix}$$

- c a) ¿Cuál es la probabilidad de que la unidad no esté operable después de n periodos (porque ambas componentes estén descompuestas), para $n = 2, 5, 10, 20$?
- c b) ¿Cuáles son las probabilidades de estado estable del estado de esta cadena de Markov?
- c) Si cuesta 30 000 dólares por periodo que la unidad no opere (ambas componentes descompuestas) y cero en otro caso, ¿cuál es el costo promedio esperado (a la larga) por periodo?

16.6-1. Una computadora se inspecciona cada hora. Se encuentra que está trabajando o que está descompuesta. En el primer caso, la probabilidad de que siga así la siguiente hora es de 0.95. Si está descompuesta, se repara, lo que puede llevar más de una hora. Siempre que la computadora esté descompuesta (sin importar cuánto tiempo pase), la probabilidad de que siga descompuesta una hora más es de 0.5.

- a) Construya la matriz de transición de un paso de esta cadena de Markov.
- b) Utilice el enfoque descrito en la sección 16.6 para encontrar las μ_{ij} (el tiempo esperado de primera pasada del estado i al estado j) para toda i y j .

16.6-2. Un fabricante tiene una máquina que cuando empieza a operar al inicio del día tiene una probabilidad de 0.1 de descomponerse en algún momento de ese día. Cuando esto ocurre, la reparación se hace al siguiente día y se termina al finalizar ese día.

- a) Formule la evolución del estado de la máquina como una cadena de Markov; identifique los tres estados posibles al final del día y después construya la matriz de transición (de un paso).
- b) Utilice el enfoque descrito en la sección 16.6 para encontrar las μ_{ij} (tiempo esperado de primera pasada del estado i al estado j) para toda i y j . Use estos resultados para identificar la siguiente descompostura después de que se ha terminado una reparación.
- c) Ahora suponga que la máquina tiene ya 20 días sin descomponerse desde la última reparación. Compare el número esperado de días completos que, *en adelante*, la máquina permanecerá en operación antes de la siguiente descompostura con el resultado correspondiente del inciso b) cuando se acaba de completar una reparación. Proporcione una explicación.

16.6-3. Reconsidere el problema 16.6-2. Suponga que el fabricante tiene una máquina de repuesto que usa sólo cuando la máquina principal está en reparación. Durante el día de reparación, la máquina de repuesto tiene una probabilidad de 0.1 de descomponerse, en cuyo caso se repara el siguiente día. Denote los estados del sistema por (x, y) , donde x y y toman valores 1 o 0 según si la primera máquina (x) y la máquina de repuesto (y) están en operación (valor 1) o no (valor 0) al final del día. [Sugerencia: observe que $(0, 0)$ no es un estado posible.]

- a) Construya la matriz de transición (de un paso) de esta cadena de Markov.
 b) Encuentre el *tiempo esperado de recurrencia* del estado (1, 0).

16.6-4. Considere el ejemplo de inventarios de la sección 16.1 pero ahora la demanda tiene la siguiente distribución de probabilidad:

$$P\{D = 0\} = \frac{1}{4}, \quad P\{D = 2\} = \frac{1}{4},$$

$$P\{D = 1\} = \frac{1}{2}, \quad P\{D \geq 3\} = 0.$$

La política de órdenes cambia al ordenar exactamente dos cámaras al final de la semana si el inventario es cero. Como antes, no se ordena si hay cámaras en inventario. Suponga que se tiene una cámara (al final de la semana) cuando se instituye la política.

- a) Construya la matriz de transición (de un paso).
 b) Encuentre la distribución de probabilidad del estado de esta cadena de Markov n semanas después de instituir la nueva política de inventarios, para $n = 2, 5, 10$.
 c) Encuentre las μ_{ij} (el tiempo esperado de primera pasada del estado i al j) para toda i y j .
 d) Encuentre las probabilidades de estado estable del estado de esta cadena de Markov.
 e) Bajo el supuesto de que la tienda paga un costo de almacenamiento por cada cámara que queda en la repisa al final de la semana, de acuerdo con la función $C(0) = 0$, $C(1) = \$2$ y $C(2) = \$8$, encuentre el costo promedio de almacenamiento a largo plazo por semana.

16.6-5. Un proceso de producción incluye una máquina que se deteriora con rapidez tanto en la calidad como en la cantidad de producción con el trabajo pesado, por lo que se inspecciona al final de cada día. Después de la inspección se clasifica la condición de la máquina en uno de cuatro estados posibles:

Estado	Condición
0	Tan buena como nueva
1	Operable: deterioro mínimo
2	Operable: deterioro mayor
3	Inoperable y reemplazada por una tan buena como nueva

El proceso se puede modelar como una cadena de Markov con matriz de transición (de un paso) $\mathbf{P}$ dada por

Estado	0	1	2	3
0	0	$\frac{7}{8}$	$\frac{1}{16}$	$\frac{1}{16}$
1	0	$\frac{3}{4}$	$\frac{1}{8}$	$\frac{1}{8}$
2	0	0	$\frac{1}{2}$	$\frac{1}{2}$
3	1	0	0	0

- c) Encuentre las probabilidades de estado estable.
 b) Si los costos respectivos por estar en los estados 0, 1, 2, 3 son 0, 1 000, 3 000 y 6 000 dólares, ¿cuál es el costo diario esperado a largo plazo?
 c) Encuentre el *tiempo de recurrencia esperado* del estado 0 (esto es, el tiempo esperado que una máquina se puede usar antes de tener que reemplazarla).

16.7-1. Considere el siguiente problema de la ruina de un jugador. Un jugador apuesta 1 dólar en cada jugada. Tiene una probabilidad p de ganar y $q = 1 - p$ de perder. Continuará jugando hasta que quiebren o reúna una fortuna de T dólares. Sea X_n la fortuna del jugador en la n -ésima jugada. Entonces,

$$X_{n+1} = \begin{cases} X_n + 1 & \text{con probabilidad } p \\ X_n - 1 & \text{con probabilidad } q = 1 - p \end{cases} \quad \text{para } 0 < X_n < T,$$

$$X_{n+1} = X_n, \quad \text{para } X_n = 0, \text{ o } T.$$

$\{X_n\}$ es una cadena de Markov. El jugador comienza con X_0 dólares, donde X_0 es un entero positivo menor que T .

- a) Determine la matriz de transición (de un paso) de la cadena de Markov.
 b) Encuentre las clases de la cadena de Markov.
 c) Sea $T = 3$ y $p = 0.3$. Use la notación de la sección 16.7 para encontrar $f_{10}, f_{1T}, f_{20}, f_{2T}$.
 d) Sea $T = 3$ y $p = 0.7$. Encuentre $f_{10}, f_{1T}, f_{20}, f_{2T}$.

16.7-2. Un fabricante de videograbadoras está tan seguro de su calidad que ofrece garantía de reposición total si un aparato falla dentro de los dos primeros años. Con base en datos compilados, la compañía ha notado que sólo 1% de sus grabadoras fallan durante el primer año, mientras que 5% de ellas sobreviven el primer año pero fallan durante el segundo. La garantía no cubre grabadoras ya reemplazadas.

- a) Formule la evolución del estado de una grabadora como una cadena de Markov cuyos estados incluyen dos estados absorbentes que representan la necesidad de cubrir la garantía o el hecho de que una grabadora sobreviva el periodo de garantía. Después construya la matriz de transición (de un paso).
 b) Utilice el enfoque descrito en la sección 16.7 para encontrar la probabilidad de que el fabricante tenga que cubrir una garantía.

16.8-1. Lea el artículo de referencia que describe el estudio de IO que se resume en el recuadro de aplicación que se presentó en la sección 16.8. Describa de manera breve la forma en que se aplicó una cadena de Markov de tiempo continuo a este estudio. Después, elabore una lista de los beneficios financieros y de otro tipo que arrojó dicho estudio.

16.8-2. Reconsidere el ejemplo que se presentó al final de la sección 16.8. Suponga que ahora se agrega al taller una tercera máquina, idéntica a las dos primeras. La persona de mantenimiento debe atender todas las máquinas.

- a) Desarrolle un *diagrama de tasas* de esta cadena de Markov.
 b) Construya las *ecuaciones de estado estable*.
 c) Resuelva estas ecuaciones para obtener las *probabilidades de estado estable*.

16.8-3. El estado de una cadena de Markov de tiempo continuo está definido como el número de trabajos que hay en el momento actual en cierto centro de trabajo, donde se permite un máximo de dos trabajos, los cuales llegan individualmente. Siempre que hay menos de tres trabajos, el tiempo que transcurre hasta la siguiente llegada tiene una distribución exponencial con media de dos días. Los trabajos se procesan uno a la vez y dejan el centro de inmediato. Los

tiempos de procesado tienen una distribución exponencial con media de un día.

- a)* Construya el *diagrama de tasas* de esta cadena de Markov.
- b)* Escriba las *ecuaciones de estado estable*.
- c)* Resuelva estas ecuaciones para obtener las *probabilidades de estado estable*.

17

CAPÍTULO

Teoría de colas

Las *colas* (líneas de espera) son parte de la vida diaria. Todos esperamos en colas para comprar un boleto para el cine, hacer un depósito en el banco, pagar en el supermercado, enviar un paquete por correo, obtener comida en la cafetería, subir a un juego en la feria, etc. Nos hemos acostumbrado a una considerable cantidad de esperas, pero todavía nos molesta cuando éstas son demasiado largas.

Sin embargo, tener que esperar no sólo es una molestia personal. El tiempo que la población de un país pierde al esperar en las colas es un factor importante tanto de la calidad de vida como de la eficiencia de su economía.

También ocurren grandes ineficiencias debido a otros tipos de espera que no son personas en una cola. Por ejemplo, cuando las *máquinas* esperan ser reparadas pueden provocarse pérdidas de producción. Los *vehículos* (incluso barcos y camiones) que deben esperar su descarga pueden retrasar envíos subsecuentes. Los *aviones* que esperan despegar o aterrizar pueden desorganizar la programación posterior de vuelos. Los retrasos de las transmisiones de *telecomunicaciones* por saturación de líneas pueden causar fallas inesperadas en los datos. Cuando los *trabajos de manufactura* esperan su proceso se puede perturbar el proceso de producción. El retraso de los *trabajos de servicio* respecto de su fecha de entrega es una causa de pérdida de negocios futuros.

La *teoría de colas* es el estudio de la espera en las distintas modalidades. Utiliza los *modelos de colas* para representar los tipos de *sistemas de líneas de espera* (sistemas que involucran colas de algún tipo) que surgen en la práctica. Las fórmulas de cada modelo indican cuál debe ser el desempeño del sistema correspondiente y señalan la cantidad promedio de espera que ocurrirá en diversas circunstancias.

Por lo tanto, estos modelos de líneas de espera son muy útiles para determinar cómo operar un sistema de colas de la manera más eficaz. Proporcionar demasiada capacidad de servicio para operar el sistema implica costos excesivos; pero si no se cuenta con suficiente capacidad de servicio surgen esperas excesivas con todas sus desafortunadas consecuencias. Los modelos permiten encontrar un balance adecuado entre el costo de servicio y la cantidad de espera.

Después de una exposición general, en este capítulo se presenta la mayoría de los modelos de líneas de espera elementales y sus resultados básicos. En la sección 17.10 se estudia cómo puede usarse la información que proporciona la teoría de colas para diseñar sistemas que minimicen el costo total de servicio y espera. Después, en el capítulo 26 (en el sitio en internet de este libro) se profundiza en la aplicación de la teoría de colas en este sentido.

■ 17.1 EJEMPLO PROTOTIPO

La sala de urgencias del HOSPITAL GENERAL proporciona cuidados médicos rápidos a los casos de emergencia que llegan en ambulancia o vehículos particulares. En todo momento se cuenta con un médico de guardia. No obstante, debido a la creciente tendencia a usar estas instalaciones para casos de urgencia en lugar de ir a una clínica privada, cada año el hospital experimenta un

aumento continuo del número de pacientes que llegan a la sala de emergencias. Como resultado, es bastante común que los pacientes que llegan durante las horas pico (temprano en la tarde) tengan que esperar turno para recibir el tratamiento del médico. Por ello, se ha presentado una propuesta para asignar un segundo médico a esta sala durante esas horas pico, para que se puedan atender dos casos de emergencia al mismo tiempo. Se ha pedido al ingeniero administrador del hospital que estudie esta opción.

El ingeniero comenzó por reunir los datos históricos pertinentes y hacer una proyección de ellos al siguiente año. Reconoció que la sala de urgencias es un sistema de líneas de espera y aplicó varios modelos de teoría de colas para predecir las características de la espera en el sistema con uno y dos médicos, como se verá más adelante en este capítulo (vea las tablas 17.2 y 17.3).

■ 17.2 ESTRUCTURA BÁSICA DE LOS MODELOS DE COLAS

Proceso básico de colas

El proceso básico supuesto por la mayoría de los modelos de colas es el siguiente. Los *clientes* que requieren un servicio se generan en el tiempo en una *fuelle de entrada*. Luego, entran al *sistema* y se unen a una *cola*. En determinado momento se selecciona un miembro de la cola para proporcionarle el servicio mediante alguna regla conocida como *disciplina de la cola*. Se lleva a cabo el servicio que el cliente requiere mediante un *mecanismo de servicio*, y después el cliente sale del sistema de colas. En la figura 17.1 se describe este proceso.


Se pueden hacer muchos supuestos sobre los distintos elementos del proceso de colas que se analizarán a continuación.

Fuente de entrada (población potencial)

Una característica de la fuente de entrada es su tamaño. El *tamaño* es el número total de clientes que pueden requerir servicio en determinado momento, es decir, el número total de clientes potenciales. Esta población a partir de la cual surgen las unidades que llegan se conoce como **población de entrada**. Puede suponerse que el tamaño es *infinito* o *finito* (de modo que también se dice que la fuente de entrada es *ilimitada* o *limitada*). Debido a que los cálculos son mucho más sencillos en el caso del tamaño infinito, este supuesto se hace a menudo aun cuando el tamaño real sea un número fijo relativamente grande, y debe tomarse como un supuesto implícito en cualquier modelo en el que no se establezca otra cosa. Desde una perspectiva analítica, el caso finito es más complejo puesto que el número de clientes que conforman la cola afecta al número potencial de clientes fuera del sistema en cualquier momento; pero debe hacerse este supuesto de finitud si la tasa a la que la fuente de entrada genera clientes nuevos es afectada en forma significativa por el número de clientes existentes en el sistema de líneas de espera.

También se debe especificar el patrón estadístico mediante el cual se generan los clientes en el tiempo. El supuesto normal es que se generan de acuerdo con un *proceso Poisson*; es decir, el número de clientes que llegan hasta un momento específico tiene una distribución de Poisson. Como se analizará en la sección 17.4, este caso corresponde a aquel cuyas llegadas al sistema ocurren de manera aleatoria pero con cierta tasa media fija y sin que importe cuántos clientes están ya ahí (por lo que el *tamaño* de la fuente de entrada es *infinito*). Un supuesto equivalente es que la distribución

■ FIGURA 17.1
Proceso básico de colas.



de probabilidad del tiempo que transcurre entre dos llegadas consecutivas es *exponencial*. (En la sección 17.4 se describen las propiedades de esta distribución.) Se hace referencia al tiempo que transcurre entre dos llegadas consecutivas como **tiempo entre llegadas**.

También debe especificarse cualquier otro supuesto no usual sobre el comportamiento de los clientes. Un ejemplo sería cuando se pierde un cliente porque *desiste o se rehúsa* a entrar al sistema porque la cola es demasiado larga.

Cola

La cola es donde los clientes esperan *antes* de recibir el servicio. Una cola se caracteriza por el número máximo permisible de clientes que puede admitir. Las colas pueden ser *finitas* o *infinitas*, según si dicho número es finito o infinito. El supuesto de una *cola infinita* es el estándar de la mayoría de los modelos, incluso en situaciones en las que en realidad existe una cota superior (relativamente grande) sobre el número permitido de clientes, puesto que manejar una cota así puede ser un factor que complique el análisis. En los sistemas de colas en los que la cota superior es tan pequeña que se llega a ella con cierta frecuencia, es necesario suponer una *cola finita*.

Disciplina de la cola

La disciplina de la cola se refiere al orden en el que sus miembros se seleccionan para recibir el servicio. Por ejemplo, puede ser: primero en entrar, primero en salir; aleatoria; de acuerdo con algún procedimiento de prioridad o con algún otro orden. En los modelos de colas se supone como normal a la disciplina de primero en entrar, primero en salir, a menos que se establezca de otra manera.

Mecanismo de servicio

El mecanismo de servicio consiste en una o más *estaciones de servicio*, cada una de ellas con uno o más *canales de servicio paralelos*, llamados **servidores**. Si existe más de una estación de servicio, el cliente puede recibirlo de una secuencia de ellas (*canales de servicio en serie*). En una estación dada, el cliente entra en uno de estos canales y el servidor le presta el servicio completo. Los modelos de colas deben especificar el arreglo de las estaciones y el número de servidores (canales paralelos) en cada una de ellas. Los modelos más elementales suponen una estación, ya sea con un servidor o con un número finito de servidores.


El tiempo que transcurre desde el inicio del servicio para un cliente hasta su terminación en una estación se llama **tiempo de servicio** (o *duración del servicio*). Un modelo de un sistema de colas determinado debe especificar la distribución de probabilidad de los tiempos de servicio de cada servidor (y tal vez de los distintos tipos de clientes), aunque es común suponer la *misma* distribución para todos los servidores (todos los modelos en este capítulo se basan en este supuesto). La distribución del tiempo de servicio que más se usa en la práctica (por ser más manejable que cualquier otra) es la distribución *exponencial* que se presenta en la sección 17.4, por lo que casi todos los modelos de este capítulo serán de este tipo. Otras distribuciones de tiempos de servicio importantes son la distribución *degenerada* (tiempos de servicio constantes) y la distribución *Erlang* (gamma) que se ilustran en los modelos de la sección 17.7.

El proceso de colas elemental

Como ya se ha señalado, la teoría de colas se aplica a muchos tipos diferentes de situaciones. El tipo que prevalece es el siguiente: una sola línea de espera (que a veces puede estar vacía) se forma frente a una estación de servicio, dentro de la cual se encuentra uno o más servidores. Cada cliente generado por una fuente de entrada recibe el servicio de uno de los servidores, quizá después de esperar un poco en la cola (línea de espera). En la figura 17.2 se presenta un esquema del sistema de colas del que se habla.

Observe que el proceso que se ilustra en el ejemplo de la sección 17.1 es de este tipo. La fuente de entrada genera clientes en la forma de casos urgentes que requieren cuidado médico. La sala de urgencias es la instalación de servicio y los médicos son los servidores.

Un servidor no tiene que ser un solo individuo; puede ser un grupo de personas, por ejemplo, una cuadrilla de reparación que combina fuerzas para realizar, de manera simultánea, el servicio que solicita el cliente. Aún más, los servidores ni siquiera tienen que ser personas. En muchos




■ **FIGURA 17.2**
Sistema de colas elemental
(cada cliente se indica con
una C y cada servidor con
una S).

casos puede ser una máquina, un vehículo, un dispositivo electrónico, etc. En esta misma línea de ideas, los clientes que conforman la cola no tienen que ser personas. Por ejemplo, pueden ser unidades que esperan ser procesadas en cierto tipo de máquina, o automóviles que deben pasar por una caseta de cobro.

En realidad, no es necesario que se forme una línea de espera física delante de una estructura material que constituye la estación de servicio. Los miembros de la cola pueden estar dispersos en un área mientras esperan que el servidor venga a ellos, como las máquinas que esperan reparación. El servidor o grupo de servidores asignados a un área constituyen la estación de servicio de esa área. De todas maneras, la teoría de colas proporciona, entre otros, un número promedio de clientes en espera —el tiempo promedio de espera—, puesto que es irrelevante si los clientes esperan en grupo o no. El único requisito esencial para poder aplicar la teoría de colas es que los cambios en el número de clientes que esperan un servicio ocurran como si prevaleciera la situación física que se describe en la figura 17.2 (o una contraparte válida).

Con excepción de la sección 17.9, todos los modelos de colas que se presentan en este capítulo son del tipo elemental que se esquematiza en la figura 17.2. Muchos de ellos se basan en el supuesto de que todos los *tiempos entre llegadas* y todos los *tiempos de servicio* son independientes e idénticamente distribuidos. Por convención, estos modelos se etiquetan de la siguiente manera:



donde: M = distribución exponencial (markoviana), como se describe en la sección 17.4,

D = distribución degenerada (tiempos constantes), como se expone en la sección 17.7,

E_k = distribución Erlang (parámetro de forma = k), como se describe en la sección 17.7,

G = distribución general (permite cualquier distribución arbitraria),¹ como se presenta en la sección 17.7.

¹Al referirse a los tiempos entre llegadas, se substituyó, de manera convencional, el símbolo G por GI = distribución general independiente.

Por ejemplo, el modelo $M/M/s$ que se presenta en la sección 17.6 supone que tanto los tiempos entre llegadas como los de servicio tienen distribución exponencial y que el número de servidores es s (cualquier entero positivo). El modelo $M/G/1$ que se estudia en la sección 17.7 supone que los tiempos entre llegadas siguen una distribución exponencial pero no pone restricciones a la distribución de los tiempos de servicio, mientras que el número de servidores está restringido a sólo 1. En la sección 17.7 se presentan algunos otros modelos que se ajustan a este esquema de etiquetas.

Terminología y notación

A menos que se establezca otra cosa, se utilizará la siguiente terminología estándar:

Estado del sistema = número de clientes en el sistema.

Longitud de la cola = número de clientes que esperan servicio.

= estado del sistema *menos* número de clientes a quienes se les da el servicio.

$N(t)$ = número de clientes en el sistema de colas en el tiempo t ($t \geq 0$).

$P_n(t)$ = probabilidad de que exactamente n clientes estén en el sistema en el tiempo t , dado el número en el tiempo 0.

s = número de servidores (canales de servicio en paralelo) en el sistema de colas.

λ_n = tasa media de llegadas (número esperado de llegadas por unidad de tiempo) de nuevos clientes cuando hay n clientes en el sistema.

μ_n = tasa media de servicio en todo el sistema (número esperado de clientes que completan su servicio por unidad de tiempo) cuando hay n clientes en el sistema. *Nota:* μ_n representa la tasa *combinada* a la que todos los servidores *ocupados* (aquellos que están sirviendo a un cliente) logran terminar sus servicios.

λ, μ, ρ = vea el párrafo siguiente.

Cuando λ_n es constante para toda n , esta constante se denota por λ . Cuando la tasa media de servicio *por servidor ocupado* es constante para toda $n \geq 1$, esta constante se denota por μ . (En este caso, $\mu_n = s\mu$ cuando $n \geq s$, es decir, cuando los s servidores están ocupados.) En estas circunstancias, $1/\lambda$ y $1/\mu$ es el *tiempo esperado entre llegadas* y el *tiempo esperado de servicio*, respectivamente. Asimismo, $\rho = \lambda/(s\mu)$ es el **factor de utilización** de la instalación de servicio, es decir, la fracción esperada de tiempo que los servidores individuales están ocupados, puesto que $\lambda/(s\mu)$ representa la fracción de la capacidad de servicio del sistema ($s\mu$) que *utilizan* en promedio los clientes que llegan (λ).

También se requiere cierta notación para describir los resultados de *estado estable*. Cuando un sistema de colas apenas inicia su operación, el estado del sistema (el número de clientes que esperan en el sistema) se encuentra bastante afectado por el estado inicial y el tiempo que ha pasado desde el inicio. Se dice entonces que el sistema se encuentra en **condición transitoria**. Sin embargo, una vez que ha pasado suficiente tiempo, el estado del sistema se vuelve, en esencia, independiente del estado inicial y del tiempo transcurrido (excepto en circunstancias no usuales).² En este contexto, se puede decir que el sistema ha alcanzado su **condición de estado estable**, en la que la distribución de probabilidad del estado del sistema se conserva (la distribución *estacionaria* o de *estado estable*) a través del tiempo. La teoría de colas tiende a dedicar su análisis a la condición de estado estable, en parte porque el caso transitorio es analíticamente más difícil. (Existen algunos resultados transitorios pero en general están más allá del alcance de este libro.) La notación siguiente supone que el sistema se encuentra en la *condición de estado estable*:

P_n = probabilidad de que haya exactamente n clientes en el sistema.

L = número esperado de clientes en el sistema = $\sum_{n=0}^{\infty} nP_n$.

²Cuando λ y μ están definidos, estas circunstancias poco usuales se refieren a que $\rho \geq 1$, en cuyo caso el estado del sistema tiende a crecer en forma continua conforme pasa el tiempo.

$$L_q = \text{longitud esperada de la cola (excluye los clientes que estan en servicio)} \\ = \sum_{n=s}^{\infty} (n - s)P_n.$$

$\mathcal{W}$ = tiempo de espera en el sistema (incluye tiempo de servicio) para cada cliente.

$$W = E(\mathcal{W}).$$

$\mathcal{W}_q$ = tiempo de espera en la cola (excluye tiempo de servicio) para cada cliente.

$$W_q = E(\mathcal{W}_q).$$

Relaciones entre L , W , L_q y W_q

Suponga que λ_n es una constante λ para toda n . Se ha demostrado que en un proceso de colas en estado estable,

$$L = \lambda W.$$

(Dado que John D. C. Little proporciono la primera demostracion rigurosa, a veces se le da el nombre de **formula de Little**.) Ademas, la misma demostracion prueba que

$$L_q = \lambda W_q.$$

Si las λ_n no son iguales, entonces λ se puede sustituir en estas ecuaciones por $\bar{\lambda}$, la tasa *promedio* entre llegadas a largo plazo. (Mas adelante se vera como se puede determinar $\bar{\lambda}$ en algunos casos basicos.)

Ahora suponga que el tiempo medio de servicio es una constante $1/\mu$, para toda $n \geq 1$. Se tiene entonces que

$$W = W_q + \frac{1}{\mu}.$$

Estas relaciones son en extremo importantes, puesto que permiten determinar las cuatro cantidades fundamentales: L , W , L_q y W_q en cuanto se encuentra analticamente el valor de una de ellas. Esta situacion es afortunada, ya que suele ser mucho mas facil determinar una de ellas que las otras al resolver un modelo de colas a partir de los principios basicos.

17.3 EJEMPLOS DE SISTEMAS DE COLAS REALES

Puede parecer que la descripcion de los sistemas de colas de la seccion 17.2 es algo abstracta y que solo es aplicable en situaciones practicas bastante especiales. Por el contrario, los sistemas de colas se aplican con sorprendente frecuencia en una amplia variedad de contextos. Para ampliar el horizonte sobre sus aplicaciones, se mencionaran brevemente varios ejemplos reales de sistemas de colas que pertenecen a varias categoras generales. Despues se describiran sistemas de colas en algunas compaas prominentes (y en una ciudad) y los estudios premiados que se llevaron a cabo para disear estos sistemas.

Algunas clases de sistemas de colas

Una clase importante de sistemas de colas que se encuentra en la vida diaria es el **sistema de servicio comercial**, en donde los clientes externos reciben un servicio de una organizacion comercial. Muchos de estos sistemas incluyen un servicio de persona a persona en un local fijo, como una peluquera (los peluqueros son los servidores), el servicio de una cajera de banco, las cajas de cobro de un supermercado y una cola en una cafetera (canales de servicio en serie). Sin embargo, muchos otros sistemas son de un tipo diferente, como la reparacion de aparatos domesticos (el servidor va hacia el cliente), una maquina de monedas (el servidor es una maquina) y una gasolinera (los clientes son automoviles).

Otra clase importante es la de **sistemas de servicio de transporte**. En algunos de estos sistemas los vehiculos son los clientes, como los automoviles que esperan para pasar por una caseta de cobro o un semforo (el servidor), un camion de carga o un barco que esperan que una cuadrilla

les dé el servicio de carga o descarga y un avión que espera aterrizar o despegar en una pista (el servidor). (Un estacionamiento es un ejemplo poco usual de este tipo, en el que los automóviles son los clientes y los espacios son los servidores, pero no existe una cola porque si un estacionamiento está lleno, los clientes se van a otro.) En otros casos, los vehículos son los servidores, como los taxis, los camiones de bomberos y los elevadores.

En años recientes, la teoría de colas se ha aplicado más a los **sistemas de servicio interno** donde los clientes que reciben el servicio son *personal interno* o parte de la organización. Los ejemplos incluyen sistemas de manejo de materiales, en donde las unidades de manejo de materiales (los servidores) mueven cargas (los clientes); sistemas de mantenimiento, en los cuales las brigadas de mantenimiento (los servidores) reparan máquinas (los clientes) y puestos de inspección en los que los inspectores de control de calidad (los servidores) inspeccionan artículos (los clientes). Las instalaciones para empleados y los departamentos que les prestan servicio también entran en esta categoría. Además, las máquinas se pueden ver como servidores cuyos clientes son los trabajos que están procesando. Un ejemplo relacionado muy importante es un centro de cómputo en el que la computadora se puede ver como el servidor.

Existe un reconocimiento creciente de que la teoría de colas también se puede aplicar a **sistemas de servicio social**. Por ejemplo, un sistema judicial es una red de colas, donde las cortes son las instalaciones de servicio, los jueces (o los jurados) son los servidores y los casos que esperan el proceso son los clientes. Un sistema legislativo es una red de colas similar, en el cual los clientes son los asuntos que el congreso va a tratar. Algunos sistemas de salud pública son sistemas de colas. En la sección 17.1 se vio un ejemplo (la sala de urgencias de un hospital), pero también las ambulancias, las máquinas de rayos X y las camas del hospital pueden actuar como servidores en sus propios sistemas. En forma parecida, las familias en espera de viviendas de interés social u otros servicios pueden ser clientes de un sistema de colas.

Aun cuando éstas son cuatro clases amplias de sistemas de colas, la lista todavía no se agota. En realidad, la teoría de colas comenzó a principios de siglo con aplicaciones a ingeniería telefónica (el fundador de la teoría de colas, A. K. Erlang, era empleado de la Danish Telephone Company, en Copenhague), y la ingeniería telefónica constituye todavía una importante aplicación. Lo que es más, cada individuo tiene sus propias líneas de espera personales: tareas, libros que leer, etc. Estos ejemplos son suficientes para sugerir que los sistemas de colas sin duda se presentan con toda frecuencia en muchas áreas de la sociedad.

Algunas aplicaciones de teoría de colas ganadoras de premios

El prestigioso premio *Franz Edelman Awards for Management Science Achievement* es otorgado cada año por el Institute of Operations Research and Management Sciences (INFORMS) a la mejor aplicación de IO del año. Un buen número de estos premios se ha otorgado por aplicaciones innovadoras de la teoría de colas al diseño de sistema de colas.

Dos de dichas aplicaciones de la teoría de colas ganadoras de premios se describen en las viñetas de aplicación más adelante en este capítulo (secciones 17.6 y 17.9). Las referencias seleccionadas al final del capítulo también incluyen una muestra de artículos que describen otras aplicaciones ganadoras de premios. (En el sitio en internet de este libro se proporciona un enlace hacia todos estos artículos, incluyendo las viñetas de aplicación.) A continuación se describe, en forma breve, algunas de dichas aplicaciones de la teoría de colas.

Como se mencionó en la referencia seleccionada A1, uno de los primeros ganadores del premio en la competencia Edelman fue *Xerox Corporation*. La compañía acababa de introducir un sistema de duplicado nuevo que sería en especial valioso para quienes lo compraran. Por lo tanto, los clientes demandaban que los representantes técnicos de Xerox redujeran los tiempos de espera de la reparación de máquinas. Un equipo de IO aplicó la teoría de colas para estudiar la mejor manera de cumplir con este nuevo requerimiento de servicio. El resultado fue reemplazar la asignación previa de territorios a un técnico por territorios más grandes asignados a tres personas. Este cambio tuvo un efecto drástico en la reducción del tiempo de espera promedio de los clientes y en el incremento de más de 50% del empleo de los técnicos. (El capítulo 11 de la referencia seleccionada 9 presenta el estudio de un caso que se basa en esta aplicación de la teoría de colas por parte de Xerox Corporation.)

L. L. Bean, Inc., la empresa más grande de telemercadeo y ventas por catálogo, realizó un estudio ganador de premio cuyo apoyo primordial fue la teoría de colas para determinar cómo

asignar sus recursos de telecomunicaciones, tema que se describe en la referencia seleccionada A4. Las llamadas telefónicas que llegan al centro para hacer pedidos son los clientes de un gran sistema de colas, mientras que los agentes son los servidores. Las preguntas clave que se hicieron durante el estudio fueron las siguientes:

1. ¿Con cuántas líneas troncales de teléfono se debe contar para atender las llamadas que entran al centro?
2. ¿Cuántos agentes de ventas por teléfono deben programarse en diferentes periodos?
3. ¿Cuántas posiciones para llamadas en espera debe haber para que los clientes esperen a un agente? (Observe que el número limitado de llamadas en espera ocasiona que el sistema tenga una cola finita.)

Por cada combinación interesante de estas tres cantidades, los modelos de colas proporcionan una medida de desempeño del sistema. Dadas estas medidas, el equipo de IO evaluó con cuidado el costo de las ventas perdidas debido a que algunos clientes escucharan tono de ocupado o de llamada en espera por mucho tiempo. Cuando se agregó el costo de los recursos de telemercadeo, el equipo pudo encontrar la combinación de las tres cantidades que minimiza el costo total esperado. El resultado fue un ahorro anual de costos de 9 a 10 millones de dólares.

Otro ganador del primer premio del concurso Edelman fue AT&T por un estudio que combinaba el uso de la teoría de colas y la simulación (tema del capítulo 20). Como se describió en la referencia seleccionada A2, los modelos de colas se aplicaron tanto a la red de telecomunicaciones de AT&T como al entorno de centros de llamadas de los clientes de la compañía que tenían estos centros. El objetivo del estudio fue desarrollar un sistema amigable de PC que los clientes pudieran usar para que la empresa los guiara en el proceso de diseñar o rediseñar sus centros de llamadas. Como éstos constituyen una de las industrias de más rápido crecimiento en Estados Unidos, para cuando se escribió este artículo, los clientes de negocios de AT&T habían usado este sistema más de 2 000 veces. El resultado fue una ganancia anual de más de 750 millones de dólares generada por estos clientes.

Hewlett-Packard (HP) es una manufacturera de equipo electrónico multinacional líder en su ramo. En 1993 la compañía instaló un sistema de línea de ensamble mecanizado para fabricar impresoras de inyección de tinta en su planta de Vancouver, Washington, para satisfacer la explosiva demanda de este tipo de impresoras. Pronto se hizo evidente que el sistema instalado no sería tan rápido ni tan confiable como para satisfacer las metas de producción de la compañía. En consecuencia, se formó un equipo conjunto de científicos de la administración de HP y del Massachusetts Institute of Technology (MIT) para estudiar cómo rediseñar el sistema para mejorar su desempeño.

Como se describe en la referencia seleccionada A3 sobre este estudio ganador de premios, el equipo de HP/MIT se percató con rapidez de que el sistema de línea de ensamble se podría modelar como un tipo especial de sistema de colas donde los clientes (las impresoras que debían ensamblarse) pasarían a través de una serie de servidores (operaciones de ensamblaje) en una secuencia fija. Un modelo de colas especial para este tipo de sistema proporcionó con rapidez los resultados analíticos que se necesitaban para determinar el modo en que el sistema debería rediseñarse para lograr la capacidad que se requería de la forma más económica. Los cambios incluyeron la incorporación de espacios de almacenamiento en puntos estratégicos para mantener de mejor manera el flujo de trabajo hacia las estaciones subsecuentes y para contrarrestar el efecto de la descompostura de las máquinas. El nuevo diseño incrementó alrededor de 50% la productividad y produjo aumentos en las ganancias de aproximadamente 280 millones de dólares por ventas de impresoras así como utilidades adicionales por productos accesorios. Esta aplicación innovadora del modelo de colas especial también le dio a HP un nuevo método para crear diseños de sistemas rápidos y eficaces en otras áreas de la compañía.

17.4 PAPEL DE LA DISTRIBUCIÓN EXPONENCIAL

En gran medida, las características operativas de los sistemas de colas están determinadas por dos propiedades estadísticas, a saber, la distribución de probabilidad de los *tiempos entre llegadas* (vea “Fuente de entrada” en la sección 17.2) y la distribución de probabilidad de los *tiempos de servicio* (vea “Mecanismo de servicio” en la sección 17.2). En los sistemas de colas reales, estas distribucio-

nes pueden tomar casi cualquier forma. (La única restricción es que no pueden presentarse valores negativos.) Sin embargo, para formular un *modelo* de teoría de colas como una representación del sistema real, es necesario especificar la forma supuesta de cada una de estas distribuciones. Para que sea útil, la forma supuesta debe ser lo *suficientemente realista* como para que el modelo proporcione *predicciones razonables*, pero al mismo tiempo debe ser lo *suficientemente sencilla* para que sea *matemáticamente manejable*. Con estas consideraciones en mente, la distribución de probabilidad más importante en la teoría de colas es la *distribución exponencial*.

Suponga que una variable aleatoria T representa ya sea los tiempos entre llegadas o los tiempos de servicio. (Se hace referencia a los hechos que marcan el final de estos tiempos, de llegadas o de terminación de un servicio, como *eventos*.) Se dice que esta variable aleatoria tiene una *distribución exponencial con parámetro α* si su función de densidad de probabilidad es

$$f_T(t) = \begin{cases} \alpha e^{-\alpha t} & \text{para } t \geq 0 \\ 0 & \text{para } t < 0, \end{cases}$$

como se muestra en la figura 17.3. En este caso, las probabilidades acumuladas son

$$\begin{aligned} P\{T \leq t\} &= 1 - e^{-\alpha t} \\ P\{T > t\} &= e^{-\alpha t} \end{aligned} \quad (t \geq 0),$$

y el valor esperado y la variancia de T son

$$\begin{aligned} E(T) &= \frac{1}{\alpha}, \\ \text{var}(T) &= \frac{1}{\alpha^2}. \end{aligned}$$

¿Cuáles son las implicaciones para el modelo de colas si se supone que T tiene una distribución exponencial? Para explorar esta pregunta se examinarán seis propiedades de la distribución exponencial.

Propiedad 1: $f_T(t)$ es una función de t estrictamente *decreciente* de t ($t \geq 0$).


Una consecuencia de la propiedad 1 es que

$$P\{0 \leq T \leq \Delta t\} > P\{t \leq T \leq t + \Delta t\}$$

para cualesquiera valores estrictamente positivos de Δt y t . [Ésta es una consecuencia del hecho de que estas probabilidades son el área bajo la curva de $f_T(t)$ en el intervalo indicado de longitud Δt , y la altura promedio de la curva es menor para la segunda probabilidad que para la primera.] Por lo tanto, no sólo es posible sino también bastante probable que T tome un valor pequeño cercano a cero. En realidad,

$$P\left\{0 \leq T \leq \frac{1}{2} \frac{1}{\alpha}\right\} = 0.393$$

■ **FIGURA 17.3**
Función de densidad de probabilidad de la distribución exponencial.



mientras que

$$P\left\{\frac{1}{2} \frac{1}{\alpha} \leq T \leq \frac{3}{2} \frac{1}{\alpha}\right\} = 0.383,$$

de manera que es más probable que el valor que tome T sea “pequeño” [esto es, menor que la mitad de $E(T)$] que “cercano” a su valor esperado [es decir, no más alejado que la mitad de $E(T)$], aun cuando el segundo intervalo tiene el doble de amplitud que el primero.

¿En realidad, ésta es una propiedad razonable de T en un modelo de colas? Si T representa los *tiempos de servicio*, la respuesta depende de la naturaleza general del servicio en cuestión, como se verá a continuación.

Si el servicio que se requiere es en esencia idéntico para cada cliente y el servidor realiza siempre la misma secuencia de operaciones, entonces los tiempos de servicio reales tienden a ser cercanos al tiempo esperado de servicio. Pueden ocurrir pequeñas desviaciones de la media, pero por lo general se deben a variaciones menores en la eficiencia del servidor. Un tiempo de servicio tan pequeño que quede muy por debajo de la media es en realidad imposible, puesto que se necesita cierta cantidad mínima de tiempo para realizar las operaciones de servicio que se requieren, aunque el servidor trabaje a la mayor velocidad. Es claro que la distribución exponencial no proporciona una aproximación cercana a la distribución de tiempos de servicio en este tipo de situación.

Por otro lado, considere el tipo de situación en la que las tareas específicas que tiene que realizar el servidor difieren de un cliente a otro. La naturaleza general del servicio puede ser la misma, pero la cantidad y tipo específico de servicio difieren. Por ejemplo, éste es el caso en el problema de la sala de emergencia del Hospital General que se presentó en la sección 17.1. El médico se enfrenta a una gran variedad de problemas de su profesión. En la mayor parte de los casos puede proporcionar el tratamiento que se requiere con bastante rapidez pero, en ocasiones, el paciente necesita un cuidado más especializado. De igual manera, los supervisores de bancos y supermercados son servidores de este tipo general, en donde el servicio que prestan suele ser breve, pero en ocasiones se extiende. Parece posible una distribución exponencial de los tiempos de servicio en este tipo de situación.

Si T representa los *tiempos entre llegadas*, la propiedad 1 descarta las situaciones en las que los clientes que llegan al sistema tienden a posponer su entrada si ven que otro cliente entra antes que ellos. Por otro lado, es totalmente congruente con el fenómeno común de las llegadas “aleatorias” que se describe con las propiedades subsecuentes. Así, cuando se grafican los tiempos entre llegadas contra el tiempo, a veces tienen la apariencia de estar aglomerados con grandes separaciones entre cada aglomeración, debido a la gran probabilidad de que los tiempos entre llegadas sean pequeños y la poca probabilidad de que ocurran tiempos entre llegadas grandes, pero un patrón tan irregular es exactamente parte de la verdadera aleatoriedad.

Propiedad 2: Falta de memoria.

Esta propiedad se puede expresar en forma matemática como

$$P\{T > t + \Delta t \mid T > \Delta t\} = P\{T > t\}$$

para cualesquiera cantidades positivas de t e Δt . En otras palabras, la distribución de probabilidad del tiempo que falta hasta que ocurra el evento (llegada o terminación de servicio) siempre es la misma, sin importar cuánto tiempo (Δt) haya pasado. En efecto, el proceso “olvida” su historia. Este sorprendente fenómeno ocurre con la distribución exponencial debido a que

$$\begin{aligned} P\{T > t + \Delta t \mid T > \Delta t\} &= \frac{P\{T > \Delta t, T > t + \Delta t\}}{P\{T > \Delta t\}} \\ &= \frac{P\{T > t + \Delta t\}}{P\{T > \Delta t\}} \\ &= \frac{e^{-\alpha(t+\Delta t)}}{e^{-\alpha\Delta t}} \\ &= e^{-\alpha t} \\ &= P\{T > t\}. \end{aligned}$$

En el caso de los *tiempos entre llegadas*, esta propiedad describe la situación común en donde el tiempo que transcurre hasta la siguiente llegada está totalmente influenciado por el momento en que ocurrió la última llegada. En el caso de los *tiempos de servicio*, esta propiedad es más difícil de interpretar. No debe esperarse que se cumpla cuando el servidor tiene que realizar la misma secuencia fija de operaciones para cada cliente, porque entonces un servicio largo y lento debe implicar que tal vez queda muy poco por hacer. Sin embargo, en la clase de situación en la que las operaciones de servicio que se requieren difieren entre los clientes, la afirmación matemática de la propiedad es bastante realista. En este caso, si ha pasado un tiempo de servicio considerable, la única implicación puede ser que este cliente en particular requiera un servicio más extenso que los demás.

Propiedad 3: El *mínimo* de diversas variables aleatorias exponenciales independientes tiene una distribución exponencial.

Para establecer matemáticamente esta propiedad, sean $T_1, T_2, \dots, T_n$ variables aleatorias exponenciales *independientes* con parámetros $\alpha_1, \alpha_2, \dots, \alpha_n$, respectivamente. También sea U la variable aleatoria cuyo valor es igual al *mínimo* de los valores que toman $T_1, T_2, \dots, T_n$; es decir,

$$U = \min \{T_1, T_2, \dots, T_n\}.$$

Así, si T_i representa el tiempo que pasa hasta que ocurre un tipo especial de evento, entonces U representa el tiempo que pasa hasta que ocurre el *primero* de los n eventos diferentes. Ahora, observe que para cualquier $t \geq 0$,

$$\begin{aligned} P\{U > t\} &= P\{T_1 > t, T_2 > t, \dots, T_n > t\} \\ &= P\{T_1 > t\}P\{T_2 > t\} \cdots P\{T_n > t\} \\ &= e^{-\alpha_1 t} e^{-\alpha_2 t} \cdots e^{-\alpha_n t} \\ &= \exp\left(-\sum_{i=1}^n \alpha_i t\right), \end{aligned}$$

de manera que, sin duda, U tiene distribución exponencial con parámetro

$$\alpha = \sum_{i=1}^n \alpha_i.$$

Esta propiedad tiene algunas implicaciones para los tiempos entre llegadas en los modelos de colas. En particular, suponga que existen varios (n) tipos *diferentes* de clientes, pero que los tiempos entre llegadas de *cada* tipo (tipo i) tienen distribución exponencial con parámetro α_i ($i = 1, 2, \dots, n$). De acuerdo con la propiedad 2, el tiempo *que falta* a partir de un instante específico hasta la llegada del siguiente cliente del tipo i tendrá esta misma distribución. Por ello, sea T_i este tiempo restante medido a partir del instante en que llega un cliente de *cualquier* tipo. La propiedad 3 dice entonces que U , el tiempo entre llegadas del sistema de colas completo, tiene distribución exponencial con parámetro α definido por la última ecuación. Como resultado, se puede hacer caso omiso de la distinción entre los clientes y seguir teniendo tiempos entre llegadas exponenciales en el modelo de colas.

Sin embargo, estas implicaciones son todavía más importantes para los *tiempos de servicio* en los modelos de colas que tienen más de un servidor, de lo que son para los tiempos entre llegadas. Por ejemplo, considere la situación en la que todos los servidores tienen la misma distribución exponencial de tiempo de servicio, con parámetro μ . En este caso, sea n el número de servidores que *en este momento* prestan servicio y sea T_i el tiempo *que falta* para que el servidor i ($i = 1, 2, \dots, n$) complete el servicio, que también tiene distribución exponencial con parámetro $\alpha_i = \mu$. Se puede concluir que U , el tiempo hasta la siguiente terminación de servicio para cualquier servidor, tiene una distribución exponencial con parámetro $\alpha = n\mu$. En efecto, el sistema de colas, *en este momento*, actúa como un sistema de un *solo* servidor, en el que los tiempos de servicio tienen una distribución exponencial con parámetro $n\mu$. En este capítulo se hará uso frecuente de esta implicación al analizar los modelos de varios servidores.

Cuando se usa esta propiedad, algunas veces es útil también determinar las probabilidades de *cuál* de las variables aleatorias exponenciales será la que tiene el valor mínimo. Por ejemplo, puede

quererse encontrar la probabilidad de que un servidor j en particular termine primero de servir a un cliente entre los n servidores ocupados. Es bastante sencillo (vea el problema 17.4-9) demostrar que esta probabilidad es proporcional al parámetro α_j . En particular, la probabilidad de que T_j resulte ser el menor de las n variables aleatorias es

$$P\{T_j = U\} = \frac{\alpha_j}{\sum_{i=1}^n \alpha_i}, \quad \text{para } j = 1, 2, \dots, n.$$

Propiedad 4: Relación con la distribución de Poisson.

Suponga que el *tiempo* entre dos ocurrencias consecutivas de un tipo específico de evento (esto es, llegadas o terminación de servicio por un servidor siempre ocupado) tiene una distribución exponencial con parámetro α . La propiedad 4 está relacionada con la implicación resultante sobre la distribución de probabilidad del *número* de veces que ocurre este evento en un periodo dado. En particular, sea $X(t)$ el número de ocurrencias en el tiempo t ($t \geq 0$), donde el tiempo 0 es el instante en el que comienza la cuenta. La implicación es que

$$P\{X(t) = n\} = \frac{(\alpha t)^n e^{-\alpha t}}{n!}, \quad \text{para } n = 0, 1, 2, \dots;$$

es decir, $X(t)$ tiene una distribución de Poisson con parámetro αt . Por ejemplo, para $n = 0$,

$$P\{X(t) = 0\} = e^{-\alpha t},$$

que es exactamente la probabilidad que se obtuvo a partir de la distribución exponencial para que ocurra el *primer* evento después de un tiempo t . La media de la distribución de Poisson es

$$E\{X(t)\} = \alpha t,$$

de manera que el número esperado de eventos *por unidad de tiempo* es α . Por lo tanto, se dice que α es la *tasa media* a la que ocurren los eventos. Cuando se cuentan los eventos de manera continua, se dice que el proceso de conteo $\{X(t); t \geq 0\}$ es un **proceso de Poisson** con parámetro α (la tasa media).

Esta propiedad brinda información útil sobre la *terminación de servicio* cuando los tiempos de servicio tienen una distribución exponencial con parámetro μ . Esta información se obtiene al definir $X(t)$ como el número de servicios completos logrados por un servidor *siempre ocupado* en un tiempo transcurrido t , donde $\alpha = \mu$. En el caso de modelos de *múltiples* servidores, también se puede definir $X(t)$ como el número de terminaciones de servicio logradas por n servidores siempre ocupados en un tiempo transcurrido t , donde $\alpha = n\mu$.

Esta propiedad es útil en particular para describir el comportamiento probabilístico de las *llegadas* cuando los tiempos entre ellas siguen una distribución exponencial con parámetro λ . En este caso, $X(t)$ sería el *número* de llegadas en un tiempo transcurrido t , donde $\alpha = \lambda$ es la *tasa media de llegadas*. En consecuencia, las llegadas ocurren de acuerdo con un **proceso de entradas de Poisson** con parámetro λ . Este tipo de modelos se describe también con el supuesto de que tienen *llegadas de Poisson*.

Algunas veces se dice que las llegadas ocurren *aleatoriamente*, lo cual significa que suceden de acuerdo con un proceso de entradas de Poisson. Una interpretación intuitiva de este fenómeno es que cada periodo de longitud fija tiene la *misma* oportunidad de tener una llegada sin importar cuándo ocurrió la llegada anterior, como lo sugiere la siguiente propiedad.

Propiedad 5: Para todos los valores positivos de t , $P\{T \leq t + \Delta t \mid T > t\} \approx \alpha \Delta t$, para un Δt pequeño.

Todavía se interpreta T como el tiempo que pasa desde el último evento de cierto tipo (llegada o terminación de servicio) hasta el siguiente evento, y suponga que ha transcurrido un tiempo t sin que ocurra un evento. Se sabe, de acuerdo con la propiedad 2, que la probabilidad de que ocurra un evento dentro del siguiente intervalo, de longitud fija Δt , es una *constante* (que se identificará en el siguiente párrafo), sin que importe el tamaño de t . La propiedad 5 va más allá pues agrega

que, cuando el valor de Δt es pequeño, esta probabilidad constante se puede aproximar de manera muy cercana por $\alpha \Delta t$. Lo que es más, cuando se consideran distintos valores pequeños de Δt , esta probabilidad es, en esencia, *proporcional* a Δt , con factor de proporcionalidad igual α . En realidad, α es la *tasa media* a la cual ocurren los eventos (vea la propiedad 4), por lo que el *número esperado* de eventos en el intervalo de longitud Δt es *exactamente* $\alpha \Delta t$. La única razón por la que la probabilidad de que ocurra un evento difiere de este valor es la posibilidad de que ocurra *más de un evento*, lo cual tiene una probabilidad despreciable cuando Δt es pequeño.

Para comprobar de manera matemática por qué se cumple la propiedad 5, observe que el valor constante de la probabilidad (para un valor fijo de $\Delta t > 0$) es sólo

$$\begin{aligned} P\{T \leq t + \Delta t \mid T > t\} &= P\{T \leq \Delta t\} \\ &= 1 - e^{-\alpha \Delta t}, \end{aligned}$$

para cualquier $t \geq 0$. Por esta razón, como la expansión de la serie e^x para cualquier exponente x es

$$e^x = 1 + x + \sum_{n=2}^{\infty} \frac{x^n}{n!},$$

se concluye que

$$\begin{aligned} P\{T \leq t + \Delta t \mid T > t\} &= 1 - 1 + \alpha \Delta t - \sum_{n=2}^{\infty} \frac{(-\alpha \Delta t)^n}{n!} \\ &\approx \alpha \Delta t, \quad \text{para } \Delta t \text{ pequeño,}^3 \end{aligned}$$

porque los términos de la sumatoria se vuelven despreciables para valores de $\alpha \Delta t$ suficientemente pequeños.

Como en los modelos de colas T se pueden representar ya sea tiempos entre llegadas o tiempos de servicio, esta propiedad proporciona una aproximación conveniente de la probabilidad de que ocurra el evento de interés en el siguiente intervalo pequeño (Δt). También se puede hacer un análisis exacto basado en esta aproximación, tomando los límites apropiados cuando $\Delta t \rightarrow 0$.

Propiedad 6: No afecta agregar o desagregar.

Esta propiedad es importante para verificar que el *proceso de entrada* es de *Poisson*. Entonces, se describirá en estos términos, aunque también se aplica directamente a la distribución exponencial (tiempos entre llegadas exponenciales) debido a la propiedad 4.

Primero se considera agregar (combinar) varios procesos de entrada de Poisson en un proceso de entrada global. En particular, suponga que existen varios (n) tipos *diferentes* de clientes, en donde los clientes de cada tipo (tipo i) llegan de acuerdo a un *proceso de llegadas de Poisson* con parámetro λ_i ($i = 1, 2, \dots, n$). Suponga que se trata de procesos de Poisson *independientes*. La propiedad dice que el proceso de entrada *agregado* (llegada de todos los clientes sin importar de qué tipo sean) también debe ser de Poisson, con parámetro (tasa de llegada) $\lambda = \lambda_1 + \lambda_2 + \dots + \lambda_n$. En otras palabras, si se está en un proceso de Poisson *no afecta agregar*.

Esta parte de la propiedad se deduce de manera directa de las propiedades 3 y 4. Esta última implica que los tiempos entre llegadas de los clientes de tipo i tienen una distribución exponencial con parámetro λ_i . Para esta situación idéntica, ya se analizó en la propiedad 3 que esto implica que los tiempos entre llegadas de todos los clientes también deben tener una distribución exponencial, con parámetro $\lambda = \lambda_1 + \lambda_2 + \dots + \lambda_n$. Si se usa la propiedad 4, de nuevo implica que el proceso de entrada agregado es de Poisson.

La segunda parte de la propiedad 6 (“no afecta desagregar”) se refiere al caso contrario, en el que se sabe que el proceso de entrada *agregado* (que se obtuvo con la combinación de procesos de entrada para diferentes tipos de clientes) es de Poisson con parámetro λ . El cuestionamiento ahora

³ De manera más precisa,

$$\lim_{\Delta t \rightarrow 0} \frac{P\{T \leq t + \Delta t \mid T > t\}}{\Delta t} = \alpha.$$