

concierna a la naturaleza del proceso de entrada *desagregado* de los tipos de clientes individuales. Si se supone que cada cliente que llega tiene una probabilidad fija p_i de pertenecer al tipo i ($i = 1, 2, \dots, n$), con

$$\lambda_i = p_i \lambda \quad \text{y} \quad \sum_{i=1}^n p_i = 1,$$

la propiedad dice que el proceso de entrada de los clientes tipo i también debe ser de Poisson con parámetro λ_i . En otras palabras, si se está en un proceso de Poisson, *no afecta desagregar*.

Como ejemplo de la utilidad de esta segunda parte de la propiedad, considere la siguiente situación. Los clientes, sin hacer distinciones, llegan de acuerdo con un proceso de Poisson con parámetro λ . Cada cliente que llega tiene una probabilidad fija p de *desistir* (irse sin entrar al sistema de colas), de manera que la probabilidad de entrar es $(1 - p)$. Desde este punto de vista, existen dos tipos de clientes: aquellos que desisten y aquellos que entran al sistema. La propiedad dice que cada tipo llega de acuerdo con un proceso de Poisson, con parámetros $p\lambda$ y $(1 - p)\lambda$, respectivamente. Por lo tanto, al usar el último proceso de Poisson, los modelos de colas que suponen llegadas de Poisson todavía se pueden usar para analizar el funcionamiento del sistema de colas para aquellos clientes que entran al sistema.

Otro ejemplo en la sección Worked Examples del sitio en internet de este libro ilustra la aplicación de varias de las propiedades de la distribución exponencial que se presentan en esta sección.

17.5 PROCESO DE NACIMIENTO Y MUERTE

La mayor parte de los modelos elementales de colas suponen que las entradas (llegada de clientes) y las salidas (clientes que se van) del sistema ocurren de acuerdo con un *proceso de nacimiento y muerte*. Este importante proceso de teoría de probabilidad tiene aplicaciones en varias áreas. Sin embargo, en el contexto de la teoría de colas, el término **nacimiento** se refiere a la *llegada* de un nuevo cliente al sistema de colas, mientras que el término **muerte** se refiere a la *salida* del cliente servido. El *estado* del sistema en el tiempo t ($t \geq 0$), denotado por $N(t)$, es el número de clientes que hay en el sistema de colas en el tiempo t . El proceso de nacimiento y muerte describe en *términos probabilísticos* cómo cambia $N(t)$ al aumentar t . En general, sostiene que los nacimientos y muertes *individuales* ocurren de manera *aleatoria*, y que sus tasas medias de ocurrencia dependen del estado actual del sistema. De manera más precisa, los supuestos del proceso de nacimiento y muerte son los siguientes:

Supuesto 1. Dado $N(t) = n$, la distribución de probabilidad actual del tiempo que *falta* para el próximo *nacimiento* (llegada) es *exponencial* con parámetro λ_n ($n = 0, 1, 2, \dots$).

Supuesto 2. Dado $N(t) = n$, la distribución de probabilidad actual del tiempo que *falta* para la próxima *muerte* (terminación de servicio) es *exponencial* con parámetro μ_n ($n = 1, 2, \dots$).

Supuesto 3. La variable aleatoria del supuesto 1 (el tiempo que falta hasta el próximo *nacimiento*) y la variable aleatoria del supuesto 2 (el tiempo que falta hasta la siguiente *muerte*) son mutuamente independientes. La siguiente transición del estado del proceso es

$$n \rightarrow n + 1 \text{ (un solo nacimiento)}$$

o


$$n \rightarrow n - 1 \text{ (una sola muerte),}$$

lo que depende de cuál de las dos variables es más pequeña.

En el caso de un sistema de colas, λ_n y μ_n representan, respectivamente, la *tasa media de llegada* y la *tasa media de terminaciones de servicio*, cuando hay n clientes en el sistema. En algunos sistemas de colas, los valores de las λ_n serán las mismas para todos los valores de n , y las μ_n también serán las mismas para toda n excepto para aquella n tan pequeña que el servidor esté desocupado (es decir, $n = 0$). Sin embargo, las λ_n y las μ_n también pueden variar en forma considerable con n para algunos sistemas de colas.

■ FIGURA 17.4

Diagrama de tasas del proceso de nacimiento y muerte.



Por ejemplo, una de las formas en las que λ_n puede ser diferente para valores distintos de n es si los clientes potenciales que llegan se pueden *perder* (rechazar la entrada al sistema) con mayor probabilidad a medida que n aumenta. De manera similar, μ_n puede ser diferente ante valores distintos de n debido a que existe una mayor probabilidad de que los clientes *renuncien* (se vayan sin haber sido servidos) a medida que aumenta el tamaño de la cola. Uno de los ejemplos de la sección Ejemplos resueltos del sitio en internet de este libro ilustra un sistema de líneas de espera donde existe tanto pérdida como renuncia. Entonces, este ejemplo demuestra cómo los resultados generales del proceso de nacimiento y muerte generan de manera directa varias medidas de desempeño de este sistema de colas.

Análisis del proceso de nacimiento y muerte

Como consecuencia de los supuestos 1 y 2, el proceso de nacimiento y muerte es un tipo especial de *cadena de Markov de tiempo continuo* (vea en la sección 16.8 la descripción de una cadena de Markov de tiempo continuo y sus propiedades y una introducción al procedimiento general para encontrar las probabilidades de estado estable que se aplicará en el resto de la sección). Los modelos de colas que se pueden representar mediante una cadena de Markov de tiempo continuo son mucho más manejables en el sentido analítico que cualquier otro modelo.

Como la propiedad 4 de la distribución exponencial implica que las λ_n y μ_n son tasas medias (vea la sección 17.4), estos supuestos se pueden resumir en el diagrama de tasas que se muestra en la figura 17.4. Las flechas de este diagrama muestran las únicas *transiciones* posibles en el estado del sistema (como lo especifica el supuesto 3) y el elemento junto a cada flecha es la tasa media de esa transición (según los supuestos 1 y 2) cuando el sistema se encuentra en el estado que hay en la base de la flecha.

Excepto en algunos casos especiales, el análisis del proceso de nacimiento y muerte es complicado cuando el sistema se encuentra en condición *transitoria*. Se han obtenido algunos resultados sobre esta distribución de probabilidad de $N(t)$ pero son demasiado complicados para darles un buen uso práctico. Por otro lado, es bastante directo derivar esta distribución *después* de que el sistema ha alcanzado la condición de *estado estable* (en caso de que pueda alcanzarla). Este desarrollo parte del diagrama de tasas, como se describe a continuación.

Considere cualquier estado particular n ($n = 0, 1, 2, \dots$) del sistema. Suponga que en el tiempo 0 se inicia el conteo del número de veces que el sistema entra a este estado y el número de veces que sale de él, como se denota en seguida:

$E_n(t)$ = número de veces que el proceso entra al estado n hasta el tiempo t .

$L_n(t)$ = número de veces que el proceso sale del estado n hasta el tiempo t .

Como los dos tipos de eventos (entrar y salir) deben alternarse, estos dos números serán iguales o diferirán en sólo 1; es decir,

$$|E_n(t) - L_n(t)| \leq 1.$$

Al dividir ambos lados entre t y después hacer que $t \rightarrow \infty$ se obtiene

$$\left| \frac{E_n(t)}{t} - \frac{L_n(t)}{t} \right| \leq \frac{1}{t}, \quad \text{entonces} \quad \lim_{t \rightarrow \infty} \left| \frac{E_n(t)}{t} - \frac{L_n(t)}{t} \right| = 0.$$

Si se dividen $E_n(t)$ y $L_n(t)$ entre t se obtiene la *tasa real* (número de eventos por unidad de tiempo) a la que ocurren estos dos tipos de eventos, y cuando $t \rightarrow \infty$ se obtiene la *tasa media* (número esperado de eventos por unidad de tiempo):

$$\lim_{t \rightarrow \infty} \frac{E_n(t)}{t} = \text{tasa media a la que el proceso entra al estado } n.$$

$$\lim_{t \rightarrow \infty} \frac{L_n(t)}{t} = \text{tasa media a la que el proceso sale del estado } n.$$

Estos resultados conducen al siguiente principio clave:

Principio de tasa de entrada = tasa de salida. Para cualquier estado n ($n = 0, 1, 2, \dots$) del sistema, la tasa media de entrada = tasa media de salida.

La ecuación que expresa este principio se llama **ecuación de balance** del estado n . Después de construir las ecuaciones de balance de todos los estados en términos de las probabilidades P_n desconocidas, se puede resolver este sistema de ecuaciones (más una ecuación que establezca que las probabilidades deben sumar 1) para encontrarlas.

A fin de ilustrar una ecuación de balance, considere el estado 0. El proceso entra a este estado *sólo* desde el estado 1. En consecuencia, la probabilidad de estado estable de encontrarse en el estado 1 (P_1) representa la proporción de tiempo que *es posible* que el proceso entre al estado 0. Dado que el proceso se encuentra en el estado 1, la tasa media de entrada al estado 0 es μ_1 . (En otras palabras, para cada unidad acumulada de tiempo que el proceso pasa en el estado 1, el número esperado de veces que lo dejaría para entrar al estado 0 es μ_1 .) Desde cualquier *otro* estado, esta tasa media es 0. Por lo tanto, la tasa media global a la que el proceso deja su estado actual para entrar al estado 0 (la *tasa media de entrada*) es

$$\mu_1 P_1 + 0(1 - P_1) = \mu_1 P_1.$$

Por el mismo razonamiento, la *tasa media de salida* debe ser $\lambda_0 P_0$, de manera que la ecuación de balance del estado 0 es

$$\mu_1 P_1 = \lambda_0 P_0.$$

En el caso de todos los demás estados, existen dos transiciones posibles, hacia adentro y hacia afuera del estado. Entonces, cada lado de las ecuaciones de balance de estos estados representa la *suma* de las tasas medias de las dos transiciones incluidas. Por lo demás, el razonamiento es igual que para el estado 0. Estas ecuaciones de balance se resumen en la tabla 17.1.

Observe que la primera ecuación de balance contiene dos variables (P_0 y P_1), las primeras dos ecuaciones contienen tres variables (P_0 , P_1 y P_2), y así sucesivamente, de manera que siempre se tiene una variable “adicional”. Por lo tanto, el procedimiento para resolver estas ecuaciones es despejar todas las variables en términos de una de ellas, entre las cuales la más conveniente es P_0 . La primera ecuación se usa para despejar P_1 en términos de P_0 ; después se usa este resultado y la segunda ecuación para obtener P_2 en términos de P_0 , etc. Al final, el requisito de que la suma de todas las probabilidades debe ser igual a 1 se puede usar para evaluar P_0 .

■ **TABLA 17.1** Ecuaciones de balance del proceso de nacimiento y muerte

Estado	Tasa de entrada = Tasa de salida
0	$\mu_1 P_1 = \lambda_0 P_0$
1	$\lambda_0 P_0 + \mu_2 P_2 = (\lambda_1 + \mu_1) P_1$
2	$\lambda_1 P_1 + \mu_3 P_3 = (\lambda_2 + \mu_2) P_2$
$\vdots$	$\vdots$
$n - 1$	$\lambda_{n-2} P_{n-2} + \mu_n P_n = (\lambda_{n-1} + \mu_{n-1}) P_{n-1}$
n	$\lambda_{n-1} P_{n-1} + \mu_{n+1} P_{n+1} = (\lambda_n + \mu_n) P_n$
$\vdots$	$\vdots$

Resultados del proceso de nacimiento y muerte

Al aplicar este procedimiento se obtienen los siguientes resultados:

Estado:

$$\begin{aligned}
 0: \quad P_1 &= \frac{\lambda_0}{\mu_1} P_0 \\
 1: \quad P_2 &= \frac{\lambda_1}{\mu_2} P_1 + \frac{1}{\mu_2} (\mu_1 P_1 - \lambda_0 P_0) = \frac{\lambda_1}{\mu_2} P_1 = \frac{\lambda_1 \lambda_0}{\mu_2 \mu_1} P_0 \\
 2: \quad P_3 &= \frac{\lambda_2}{\mu_3} P_2 + \frac{1}{\mu_3} (\mu_2 P_2 - \lambda_1 P_1) = \frac{\lambda_2}{\mu_3} P_2 = \frac{\lambda_2 \lambda_1 \lambda_0}{\mu_3 \mu_2 \mu_1} P_0 \\
 &\vdots \\
 n-1: \quad P_n &= \frac{\lambda_{n-1}}{\mu_n} P_{n-1} + \frac{1}{\mu_n} (\mu_{n-1} P_{n-1} - \lambda_{n-2} P_{n-2}) = \frac{\lambda_{n-1}}{\mu_n} P_{n-1} = \frac{\lambda_{n-1} \lambda_{n-2} \cdots \lambda_0}{\mu_n \mu_{n-1} \cdots \mu_1} P_0 \\
 n: \quad P_{n+1} &= \frac{\lambda_n}{\mu_{n+1}} P_n + \frac{1}{\mu_{n+1}} (\mu_n P_n - \lambda_n P_n) = \frac{\lambda_n}{\mu_{n+1}} P_n = \frac{\lambda_n \lambda_{n-1} \cdots \lambda_0}{\mu_{n+1} \mu_n \cdots \mu_1} P_0 \\
 &\vdots
 \end{aligned}$$

Para simplificar la notación, sea

$$C_n = \frac{\lambda_{n-1} \lambda_{n-2} \cdots \lambda_0}{\mu_n \mu_{n-1} \cdots \mu_1}, \quad \text{para } n = 1, 2, \dots,$$

y después se define $C_n = 1$ para $n = 0$. En este contexto, las probabilidades de estado estable son

$$P_n = C_n P_0, \quad \text{para } n = 0, 1, 2, \dots$$

El requisito

$$\sum_{n=0}^{\infty} P_n = 1$$

implica que

$$\left(\sum_{n=0}^{\infty} C_n \right) P_0 = 1,$$

así,

$$P_0 = \left(\sum_{n=0}^{\infty} C_n \right)^{-1}.$$

Cuando un modelo de líneas de espera se basa en el proceso de nacimiento y muerte, de manera que el estado del sistema n representa el número de clientes en el sistema de colas, las medidas clave de desempeño del sistema (L , L_q , W y W_q) se pueden obtener de inmediato después de calcular las P_n mediante las fórmulas anteriores. Las definiciones de L y L_q que se dieron en la sección 17.2 especifican que

$$L = \sum_{n=0}^{\infty} n P_n, \quad L_q = \sum_{n=s}^{\infty} (n - s) P_n.$$

Lo que es más, las relaciones que se dieron en la sección 17.2 conducen a

$$W = \frac{L}{\lambda}, \quad W_q = \frac{L_q}{\lambda},$$

donde $\bar{\lambda}$ es la tasa de llegadas *promedio* a largo plazo. Como λ_n es la tasa media de llegadas cuando el sistema se encuentra en el estado n ($n = 0, 1, 2, \dots$) y P_n es la proporción de tiempo que el sistema está en este estado,

$$\bar{\lambda} = \sum_{n=0}^{\infty} \lambda_n P_n.$$

Varias de las expresiones que se acaban de presentar incluyen sumas con un número infinito de términos. Por fortuna, estas sumas tienen soluciones analíticas de muchos casos especiales interesantes⁴ como se verá en la siguiente sección. En otros casos, se puede aproximar al sumar un número finito de términos en una computadora.

Estos resultados de estado estable se desarrollaron bajo el supuesto de que los parámetros λ_n y μ_n tienen valores tales que el proceso, en realidad, puede *alcanzar* la condición de estado estable. Este supuesto *siempre* se cumple si $\lambda_n = 0$ para algún valor de n mayor que el estado inicial, de forma que sólo son posibles un número finito de estados (aquellos menores que esta n). También se cumple *siempre* cuando λ y μ están definidas (vea “Terminología y notación” en la sección 17.2) y $\rho = \lambda/(s\mu) < 1$. No se cumple si $\sum_{n=1}^{\infty} C_n = \infty$.

En la sección 17.6 se describen varios modelos de colas que son casos especiales del proceso de nacimiento y muerte. Los resultados de estado estable generales dados en los recuadros se utilizarán una y otra vez para obtener los resultados específicos para estos modelos.

17.6 MODELOS DE COLAS BASADOS EN EL PROCESO DE NACIMIENTO Y MUERTE

Como se puede asignar cualquier valor no negativo a cada una de las tasas medias $\lambda_0, \lambda_1, \dots$ y $\mu_1, \mu_2, \dots$ del proceso de nacimiento y muerte, se cuenta con una gran flexibilidad para modelar un sistema de colas. Los modelos que acaso sean los que más se usan en teoría de colas se basan directamente en este proceso. De acuerdo con los supuestos 1 y 2 (y la propiedad 4 de la distribución exponencial), se dice que estos modelos tienen **entradas de Poisson y tiempos de servicio exponencial**. Los modelos difieren sólo en los supuestos sobre cómo cambian las λ_n y las μ_n según el estado n . En esta sección se presentarán tres modelos de tres tipos importantes de sistemas de colas.

Modelo M/M/s

Como se describió en la sección 17.2, el modelo M/M/s supone que todos los *tiempos entre llegadas* son independientes e idénticamente distribuidos de acuerdo con una distribución exponencial (es decir, el proceso de entrada es de Poisson), que todos los *tiempos de servicio* son independientes e idénticamente distribuidos de acuerdo con otra distribución exponencial y que el número de servidores es s (cualquier entero positivo). En consecuencia, este modelo es sólo un caso especial del proceso de nacimiento y muerte cuando la *tasa media de llegadas* al sistema de colas y la *tasa media de servicio por servidor ocupado* son constantes (λ y μ , respectivamente) e independientes del estado del sistema. Cuando el sistema tiene sólo *un servidor* ($s = 1$), la implicación es que los parámetros del proceso de nacimiento y muerte son $\lambda_n = \lambda$ ($n = 0, 1, 2, \dots$) y $\mu_n = \mu$ ($n = 1, 2, \dots$). En la figura 17.5a se muestra el diagrama de tasas resultante.

Sin embargo, cuando el sistema tiene *varios servidores* ($s > 1$), no es tan sencillo expresar μ_n , como se explica en seguida.

Tasa de servicio de sistema: La tasa del servicio del sistema μ_n representa la tasa media de los servicios terminados de todo el sistema de colas cuando existen n clientes en él. En

⁴ Estas soluciones se basan en los siguientes resultados de la suma de cualquier serie geométrica:

$$\sum_{n=0}^N x^n = \frac{1 - x^{N+1}}{1 - x}, \quad \text{para cualquier } x \neq 1,$$

$$\sum_{n=0}^{\infty} x^n = \frac{1}{1 - x}, \quad \text{si } |x| < 1.$$

el caso de múltiples servidores y $n > 1$, μ_n no es lo mismo que μ , la tasa media de servicio por servidor ocupado. En lugar de eso,

$$\begin{aligned}\mu_n &= n\mu & \text{cuando } n \leq s, \\ \mu_n &= s\mu & \text{cuando } n \geq s.\end{aligned}$$

Mediante el uso de estas fórmulas de μ_n , el diagrama con las tasas del proceso nacimiento-muerte que se muestra en la figura 17.4 se reduce a los diagramas de las tasas que se muestran en la figura 17.5 del modelo $M/M/s$.

Cuando $s\mu$ excede la tasa media de llegadas λ , es decir, cuando

$$\rho = \frac{\lambda}{s\mu} < 1,$$

un sistema de colas que se ajuste a este modelo tarde o temprano alcanzará la condición de estado estable. En esta situación se pueden aplicar directamente los resultados de estado estable que se obtuvieron en la sección 17.5 al proceso de nacimiento y muerte. Estos resultados se simplifican mucho para este modelo y proporcionan expresiones cortas de P_n , L , L_q , etc., como se mostrará a continuación.

Resultados en el caso de un servidor ($M/M/1$). Para $s = 1$, los factores C_n del proceso de nacimiento y muerte se reducen a

$$C_n = \left(\frac{\lambda}{\mu}\right)^n = \rho^n, \quad \text{para } n = 0, 1, 2, \dots$$

Por lo tanto,

$$P_n = \rho^n P_0, \quad \text{para } n = 0, 1, 2, \dots,$$

donde


$$\begin{aligned}P_0 &= \left(\sum_{n=0}^{\infty} \rho^n\right)^{-1} \\ &= \left(\frac{1}{1-\rho}\right)^{-1} \\ &= 1 - \rho.\end{aligned}$$

Así

$$P_n = (1 - \rho)\rho^n, \quad \text{para } n = 0, 1, 2, \dots$$

■ FIGURA 17.5

Diagrama de tasas del modelo $M/M/s$.



Recuadro de aplicación

KeyCorp, una compañía cuya casa matriz está en Cleveland, Ohio, se encuentra dentro de las 500 compañías de Fortune. Es la decimotercera compañía bancaria más grande de Estados Unidos. Emplea a 19 000 personas, tiene activos por 93 000 millones de dólares y ganancias anuales por 6 700 millones de dólares. La compañía se enfoca en prestar servicios bancarios a los consumidores y cuenta con 2.4 millones de clientes repartidos en 1 300 sucursales y oficinas afiliadas.

Para impulsar el crecimiento de sus negocios, la gerencia de KeyCorp puso en marcha un amplio estudio de IO para determinar la forma de mejorar el servicio a los clientes (el cual se define como la reducción del tiempo de espera para recibir el servicio), y a la vez conservar los costos de personal en un rango moderado. Se fijó una objetivo en cuanto a la calidad del servicio que consistía en que el tiempo de espera de los clientes debería ser menor a 5 minutos.

La herramienta clave para analizar este problema fue el *modelo de colas M/M/s*, el cual demostró ser el más conveniente para esta aplicación. Para aplicarlo, se recabaron datos que revelaron que el tiempo de servicio promedio que se requería para procesar un cliente era muy elevado, del orden de 246 segundos. Con este tiempo promedio de servicio y tasa de arribo en la media típicamente, el modelo indicó que era necesario un incremento de 30% del número de personas que brindan atención a los clientes con el fin de cumplir con el objetivo de calidad del servicio. Esta opción extremadamente

costosa llevó a la alta gerencia a concluir que era necesario llevar a cabo una amplia campaña para reducir de manera drástica el tiempo de servicio promedio mediante la reingeniería de las sesiones con los clientes y del fomento de una mejor administración del personal. En un periodo de tres años, esta campaña dio como resultado una reducción del tiempo de servicio promedio hasta llegar a 115 segundos. La aplicación frecuente del modelo *M/M/s* reveló la forma en que la meta de calidad del servicio puede sobrepasarse de manera significativa, a la vez que se pueden reducir los niveles de personal mediante una programación optimizada de los empleados en las diferentes sucursales del banco.

El resultado neto se ha reflejado en **ahorros de casi 20 millones de dólares por año con un servicio significativamente mejorado** que permite que 96% de los clientes tengan que esperar menos de 5 minutos. Esta mejora se extendió a toda la compañía ya que el porcentaje de sucursales que cumple el objetivo de calidad de servicio aumentó de 42 a 94 por ciento. Diferentes estudios también confirman un incremento significativo en la satisfacción del cliente.

Fuente: S. K. Kotha, M. P. Barnum y D. A. Bowen: "KeyCorp Service Excellence Management System", en *Interfaces*, **26**(1): 54-74, enero-febrero de 1996. (En el sitio en internet de este libro www.mhhe.com/hillier se proporciona una liga hacia este artículo.)

En consecuencia,

$$\begin{aligned} L &= \sum_{n=0}^{\infty} n(1 - \rho)\rho^n \\ &= (1 - \rho)\rho \sum_{n=0}^{\infty} \frac{d}{d\rho} (\rho^n) \\ &= (1 - \rho)\rho \frac{d}{d\rho} \left(\sum_{n=0}^{\infty} \rho^n \right) \\ &= (1 - \rho)\rho \frac{d}{d\rho} \left(\frac{1}{1 - \rho} \right) \\ &= \frac{\rho}{1 - \rho} = \frac{\lambda}{\mu - \lambda}. \end{aligned}$$

En forma similar,

$$\begin{aligned} L_q &= \sum_{n=1}^{\infty} (n - 1)P_n \\ &= L - 1(1 - P_0) \\ &= \frac{\lambda^2}{\mu(\mu - \lambda)}. \end{aligned}$$

Cuando $\lambda \geq \mu$, esto es, la tasa media de llegadas excede la tasa media de servicio, la solución anterior "no sirve" (puesto que la suma para calcular P_0 diverge). En este caso, la cola "explota" y crece sin límite. Si el sistema de colas comienza a operar sin clientes presentes, puede ser que el

servidor se dé abasto con los que llegan durante un periodo corto, pero a la larga le será imposible. (Aun cuando $\lambda = \mu$, el número *esperado* de clientes en el sistema crecerá sin límite y con lentitud a través del tiempo y, aunque siempre es posible un regreso temporal a no tener clientes, las probabilidades de tener números grandes de clientes crecen en forma significativa con el tiempo.)

Si se supone de nuevo que $\lambda < \mu$, se puede obtener la distribución de probabilidad del *tiempo de espera en el sistema* (se incluye el tiempo de servicio) W de una llegada aleatoria cuando la disciplina de la cola es primero en entrar, primero en salir. Si esta llegada encuentra n clientes en el sistema, tendrá que esperar $n + 1$ tiempos de servicio exponenciales, inclusive el propio. (Para el cliente que en la actualidad se encuentra en servicio, recuerde la propiedad de falta de memoria de la distribución exponencial que se presentó en la sección 17.4.) Por lo tanto, sean $T_1, T_2, \dots$ las variables aleatorias independientes de los tiempos de servicio que tienen una distribución exponencial con parámetro μ , y sea

$$S_{n+1} = T_1 + T_2 + \dots + T_{n+1}, \quad \text{para } n = 0, 1, 2, \dots,$$

de manera que S_{n+1} representa el tiempo de espera *condicional*, dado que hay n clientes en el sistema. Como se analiza en la sección 17.7, se sabe que S_{n+1} tiene *distribución de Erlang*.⁵ Como la probabilidad de que una llegada aleatoria encuentre n clientes en el sistema es P_n , se concluye que

$$P\{W > t\} = \sum_{n=0}^{\infty} P_n P\{S_{n+1} > t\},$$

lo que después de una manipulación algebraica considerable (vea el problema 17.6-17) se reduce a

$$P\{W > t\} = e^{-\mu(1-\rho)t}, \quad \text{para } t \geq 0.$$

La conclusión sorprendente es que W tiene una distribución *exponencial* con parámetro igual a $\mu(1 - \rho)$. Por lo tanto,

$$\begin{aligned} W = E(W) &= \frac{1}{\mu(1 - \rho)} \\ &= \frac{1}{\mu - \lambda}. \end{aligned}$$

Estos resultados *incluyen* el tiempo de servicio en el tiempo de espera. En algunos contextos (por ejemplo, el problema de la sala de emergencia del Hospital General descrito en la sección 17.1), el tiempo de espera más importante es hasta que comienza el servicio. Considere el *tiempo de espera en la cola* (excluya el tiempo de servicio) W_q de la llegada aleatoria cuando la disciplina de la cola es primero en llegar, primero en salir. Si esta llegada no encuentra clientes en el sistema, se le sirve de inmediato, de manera que

$$P\{W_q = 0\} = P_0 = 1 - \rho.$$

Si encuentra $n > 0$ clientes, entonces tendrá que esperar n tiempos de servicio exponenciales hasta que su propio servicio comience, de forma que

$$\begin{aligned} P\{W_q > t\} &= \sum_{n=1}^{\infty} P_n P\{S_n > t\} \\ &= \sum_{n=1}^{\infty} (1 - \rho) \rho^n P\{S_n > t\} \\ &= \rho \sum_{n=0}^{\infty} P_n P\{S_{n+1} > t\} \\ &= \rho P\{W > t\} \\ &= \rho e^{-\mu(1-\rho)t}, \quad \text{para } t \geq 0. \end{aligned}$$

⁵ Fuera del contexto de teoría de colas, esta distribución se conoce como *distribución gamma*.

Observe que W_q no tiene en realidad una distribución exponencial porque $P\{\mathcal{W}_q = 0\} > 0$. Sin embargo, la distribución *condicional* de $\mathcal{W}_q$, dado que $\mathcal{W}_q > 0$, no tiene una distribución exponencial con parámetro $\mu(1 - \rho)$, como lo tiene $\mathcal{W}$, porque

$$P\{\mathcal{W}_q > t \mid \mathcal{W}_q > 0\} = \frac{P\{\mathcal{W}_q > t\}}{P\{\mathcal{W}_q > 0\}} = e^{-\mu(1-\rho)t}, \quad \text{para } t \geq 0.$$

Al obtener la media de esta distribución (no condicional) de W_q (o aplicar una de las dos fórmulas $L_q = \lambda W_q$ o $W_q = W - 1/\mu$), resulta

$$W_q = E(\mathcal{W}_q) = \frac{\lambda}{\mu(\mu - \lambda)}.$$

Si desea ver **otro ejemplo** que aplica el modelo $M/M/1$, en la sección Worked Examples del sitio en internet de este libro se presenta uno de ellos para determinar qué tipo de equipo de manejo de materiales debe comprar una compañía.

Resultados del caso de varios servidores ($s > 1$). Cuando $s > 1$, los factores C_n se convierten en

$$C_n = \begin{cases} \frac{(\lambda/\mu)^n}{n!} & \text{para } n = 1, 2, \dots, s \\ \frac{(\lambda/\mu)^s}{s!} \left(\frac{\lambda}{s\mu}\right)^{n-s} = \frac{(\lambda/\mu)^n}{s! s^{n-s}} & \text{para } n = s, s+1, \dots \end{cases}$$

En consecuencia, si $\lambda < s\mu$ [de manera que $\rho = \lambda/(s\mu) < 1$], entonces

$$\begin{aligned} P_0 &= 1 / \left[1 + \sum_{n=1}^{s-1} \frac{(\lambda/\mu)^n}{n!} + \frac{(\lambda/\mu)^s}{s!} \sum_{n=s}^{\infty} \left(\frac{\lambda}{s\mu}\right)^{n-s} \right] \\ &= 1 / \left[\sum_{n=0}^{s-1} \frac{(\lambda/\mu)^n}{n!} + \frac{(\lambda/\mu)^s}{s!} \frac{1}{1 - \lambda/(s\mu)} \right], \end{aligned}$$

donde el término para $n = 0$ en la última suma lleva al valor correcto de 1 debido a la convención de que $n! = 1$ cuando $n = 0$. Estos factores C_n dan también

$$P_n = \begin{cases} \frac{(\lambda/\mu)^n}{n!} P_0 & \text{si } 0 \leq n \leq s \\ \frac{(\lambda/\mu)^n}{s! s^{n-s}} P_0 & \text{si } n \geq s. \end{cases}$$

Más aún,

$$\begin{aligned} L_q &= \sum_{n=s}^{\infty} (n-s) P_n \\ &= \sum_{j=0}^{\infty} j P_{s+j} \\ &= \sum_{j=0}^{\infty} j \frac{(\lambda/\mu)^s}{s!} \rho^j P_0 \\ &= P_0 \frac{(\lambda/\mu)^s}{s!} \rho \sum_{j=0}^{\infty} \frac{d}{d\rho} (\rho^j) \\ &= P_0 \frac{(\lambda/\mu)^s}{s!} \rho \frac{d}{d\rho} \left(\sum_{j=0}^{\infty} \rho^j \right) \end{aligned}$$

$$\begin{aligned}
&= P_0 \frac{(\lambda/\mu)^s}{s!} \rho \frac{d}{d\rho} \left(\frac{1}{1-\rho} \right) \\
&= \frac{P_0 (\lambda/\mu)^s \rho}{s! (1-\rho)^2}; \\
W_q &= \frac{L_q}{\lambda}; \\
W &= W_q + \frac{1}{\mu}; \\
L &= \lambda \left(W_q + \frac{1}{\mu} \right) = L_q + \frac{\lambda}{\mu}.
\end{aligned}$$

En la figura 17.6 se muestra cómo cambian L con ρ para diferentes valores de s .

El método de un solo servidor para encontrar la distribución de probabilidad de los tiempos de espera se puede extender al caso de varios servidores. Al aplicarlo se obtiene⁶ (para $t \geq 0$)


$$P\{^sW > t\} = e^{-\mu t} \left[\frac{1 + P_0 (\lambda/\mu)^s}{s! (1-\rho)} \left(\frac{1 - e^{-\mu t(s-1-\lambda/\mu)}}{s-1-\lambda/\mu} \right) \right]$$

y

$$P\{^sW_q > t\} = (1 - P\{^sW_q = 0\})e^{-s\mu(1-\rho)t},$$

■ FIGURA 17.6

Valores de L del modelo $M/M/s$ (sección 17.6).



⁶ Cuando $s - 1 - \lambda/\mu = 0$, $(1 - e^{-\mu t(s-1-\lambda/\mu)})/(s-1-\lambda/\mu)$ debe sustituirse por μt .

donde

$$P\{\mathcal{W}_q = 0\} = \sum_{n=0}^{s-1} P_n.$$

Las fórmulas anteriores de las distintas medidas de desempeño (incluyendo las P_n) son bastante tediosas para hacer los cálculos a mano. Sin embargo, el archivo de Excel de este capítulo en OR Courseware incluye una plantilla Excel que realiza todos los cálculos simultáneos para cualesquiera valores de t , s , λ y μ dado que $\lambda < s\mu$.

Si $\lambda \geq s\mu$, de forma que si la tasa media de llegadas excede a la tasa media máxima de servicio, la cola crece sin límite y las soluciones de estado estable anteriores no se pueden aplicar.

Ejemplo del Hospital General con el modelo M/M/s. En el problema de la sala de emergencia del Hospital General (vea la sección 17.1), el ingeniero administrador ha concluido que los casos de emergencia llegan casi de manera aleatoria (*proceso de entrada de Poisson*), por lo que los tiempos entre llegadas tienen una distribución exponencial. También llegó a la conclusión de que el tiempo que necesita un médico para atender a los pacientes sigue aproximadamente una *distribución exponencial*. Con base en este contexto, eligió el modelo M/M/s para hacer un estudio preliminar de este sistema de colas.

Al proyectar los datos disponibles del turno de la tarde al año próximo, estima que los pacientes llegarán a una tasa *promedio* de uno cada media hora. Un médico requiere un promedio de 20 minutos para atender al paciente. Si se usa una hora como unidad de tiempo,

$$\frac{1}{\lambda} = \frac{1}{2} \text{ horas por cliente}$$

y

$$\frac{1}{\mu} = \frac{1}{3} \text{ horas por cliente,}$$

■ **TABLA 17.2** Resultados de estado estable del modelo M/M/s del problema del Hospital General

	$s = 1$	$s = 2$
ρ	$\frac{2}{3}$	$\frac{1}{3}$
P_0	$\frac{1}{3}$	$\frac{1}{2}$
P_1	$\frac{2}{9}$	$\frac{1}{3}$
P_n para $n \geq 2$	$\frac{1}{3} \left(\frac{2}{3}\right)^n$	$\left(\frac{1}{3}\right)^n$
L_q	$\frac{4}{3}$	$\frac{1}{12}$
L	2	$\frac{3}{4}$
W_q	$\frac{2}{3}$ horas	$\frac{1}{24}$ horas
W	1 hora	$\frac{3}{8}$ horas
$P\{\mathcal{W}_q > 0\}$	0.667	0.167
$P\left\{\mathcal{W}_q > \frac{1}{2}\right\}$	0.404	0.022
$P\{\mathcal{W}_q > 1\}$	0.245	0.003
$P\{\mathcal{W}_q > t\}$	$\frac{2}{3}e^{-t}$	$\frac{1}{6}e^{-4t}$
$P\{W > t\}$	e^{-t}	$\frac{1}{2}e^{-3t}(3 - e^{-t})$

de manera que

$$\lambda = 2 \text{ clientes por hora}$$

y

$$\mu = 3 \text{ clientes por hora.}$$

Las dos alternativas bajo consideración son: continuar con un solo médico durante este turno ($s = 1$) o agregar un segundo médico ($s = 2$). En ambos casos,

$$\rho = \frac{\lambda}{s\mu} < 1,$$

de forma que el sistema debe acercarse a la condición de estado estable. (En realidad, como λ varía un poco durante los otros turnos, el sistema nunca alcanzará verdaderamente la condición de estado estable, pero el ingeniero administrador piensa que los resultados correspondientes proporcionarán una buena aproximación.) Por lo tanto, usa las ecuaciones anteriores para obtener los resultados que se muestran en la tabla 17.2.

Con base en estos resultados, concluye en forma tentativa que para el siguiente año sería inadecuado un solo médico para brindar atención con relativa prontitud, lo que es necesario en la sala de emergencias de un hospital. Más adelante se verá (sección 17.8) cómo el ingeniero rectifica su conclusión cuando aplica otro modelo de colas que le proporciona una mejor representación de algunos aspectos cruciales del sistema de líneas de espera real.

Se puede ver **otro ejemplo** de una aplicación del modelo $M/M/1$ en la sección Worked Examples del sitio en internet de este libro, donde el problema consiste en determinar si tres empleados de un restaurante de comida rápida deben trabajar juntos como un servidor rápido o por separado como tres servidores considerablemente más lentos.

Variación de cola finita al modelo $M/M/s$ (llamado modelo $M/M/s/K$)

En el análisis de la sección 17.2 se mencionó que los sistemas de colas a veces tienen una *cola finita*; esto es, no se permite que el número de clientes en el sistema exceda un número especificado (denotado por K), por lo que la capacidad de la cola es $K - s$. A cualquier cliente que llega cuando la cola está “llena” se le niega la entrada al sistema y este cliente lo deja para siempre. Desde el punto de vista del proceso de nacimiento y muerte, la tasa media de entrada al sistema se hace cero en estos momentos. Por lo mismo, la única modificación necesaria en el modelo $M/M/s$ para introducir una cola finita es cambiar los parámetros λ_n a

$$\lambda_n = \begin{cases} \lambda & \text{para } n = 0, 1, 2, \dots, K - 1 \\ 0 & \text{para } n \geq K. \end{cases}$$

Como $\lambda_n = 0$ para algunos valores de n , un sistema de colas que se ajuste a este modelo alcanzará en algún momento la condición de estado estable, aun cuando $\rho = \lambda/s\mu \geq 1$.

Por lo general este modelo se etiqueta como $M/M/s/K$, donde la presencia del cuarto símbolo lo distingue del modelo $M/M/s$. La única diferencia en la formulación de los dos modelos es que K es finito en el modelo $M/M/s/K$ y $K = \infty$ en el modelo $M/M/s$.

La interpretación física usual del modelo $M/M/s/K$ es que se cuenta con un *espacio limitado de espera* que admite un máximo de K clientes en el sistema. Por ejemplo, en el problema de la sala de emergencias del Hospital General, este sistema en realidad tendría una cola finita si sólo hubiera K camillas para los pacientes y si la política fuera mandar a otro hospital a aquellos que llegan cuando no hay lugares disponibles.

Otra interpretación posible es que los clientes que llegan dejarán el sistema y se “irán a otra parte” cuando encuentren demasiados clientes (K) en el sistema antes que ellos, pues no están dispuestos a soportar una larga espera. Este fenómeno de desistir es bastante común en los sistemas de

servicio comercial, pero existen otros modelos disponibles (por ejemplo, vea el problema 17.5-5) que se ajustan mejor a esta situación.

El diagrama de tasas de este modelo es idéntico al que se muestra en la figura 17.5 para el modelo $M/M/s$, excepto que se detiene en el estado K .

Resultados en el caso de un servidor ($M/M/1/K$). En este caso,

$$C_n = \begin{cases} \left(\frac{\lambda}{\mu}\right)^n = \rho^n & \text{para } n = 0, 1, 2, \dots, K \\ 0 & \text{para } n > K. \end{cases}$$

Entonces, para $\rho \neq 1$.⁷

$$\begin{aligned} P_0 &= \frac{1}{\sum_{n=0}^K (\lambda/\mu)^n} \\ &= 1 / \left[\frac{1 - (\lambda/\mu)^{K+1}}{1 - \lambda/\mu} \right] \\ &= \frac{1 - \rho}{1 - \rho^{K+1}}, \end{aligned}$$

de manera que

$$P_n = \frac{1 - \rho}{1 - \rho^{K+1}} \rho^n, \quad \text{para } n = 0, 1, 2, \dots, K.$$

Entonces,

$$\begin{aligned} L &= \sum_{n=0}^K n P_n \\ &= \frac{1 - \rho}{1 - \rho^{K+1}} \rho \sum_{n=0}^K \frac{d}{d\rho} (\rho^n) \\ &= \frac{1 - \rho}{1 - \rho^{K+1}} \rho \frac{d}{d\rho} \left(\sum_{n=0}^K \rho^n \right) \\ &= \frac{1 - \rho}{1 - \rho^{K+1}} \rho \frac{d}{d\rho} \left(\frac{1 - \rho^{K+1}}{1 - \rho} \right) \\ &= \rho \frac{-(K+1)\rho^K + K\rho^{K+1} + 1}{(1 - \rho^{K+1})(1 - \rho)} \\ &= \frac{\rho}{1 - \rho} - \frac{(K+1)\rho^{K+1}}{1 - \rho^{K+1}}. \end{aligned}$$

Como es usual (cuando $s = 1$),

$$L_q = L - (1 - P_0).$$

Note que los resultados anteriores no exigen que $\lambda < \mu$ (esto es, que $\rho < 1$).

Cuando $\rho < 1$, se puede verificar que el segundo término de la última expresión de L converge hacia 0 cuando $K \rightarrow \infty$, por lo que, sin duda, todos los resultados anteriores convergen hacia los resultados correspondientes que se obtuvieron antes en el caso del modelo $M/M/1$.

La distribución de los tiempos de espera se puede deducir si se utiliza el mismo razonamiento que para el modelo $M/M/1$ (vea el problema 17.6-28). Sin embargo, no se han obtenido expresiones sencillas en este caso, por lo que es preciso efectuar los cálculos en una computadora. Por fortuna, aun cuando en este modelo $L \neq \lambda W$ y $L_q \neq \lambda W_q$ puesto que las λ_n no son iguales para toda n (vea el

⁷ Si $\rho = 1$, entonces $P_n = 1/(K+1)$ para $n = 0, 1, 2, \dots, K$, de forma que $L = K/2$.

final de la sección 17.2), sí se pueden obtener los tiempos de espera *esperados* de los clientes que llegan al sistema, en forma directa de las expresiones que se dieron al final de la sección 17.5:

$$W = \frac{L}{\lambda}, \quad W_q = \frac{L_q}{\lambda},$$

donde

$$\begin{aligned} \bar{\lambda} &= \sum_{n=0}^{\infty} \lambda_n P_n \\ &= \sum_{n=0}^{K-1} \lambda P_n \\ &= \lambda(1 - P_K). \end{aligned}$$

Resultados en el caso de varios servidores ($s > 1$). Debido a que este modelo no permite más de K clientes en el sistema, K es el número máximo de servidores que pueden tenerse. Suponga que $s \leq K$. En este caso, C_n se expresa como

$$C_n = \begin{cases} \frac{(\lambda/\mu)^n}{n!} & \text{para } n = 0, 1, 2, \dots, s \\ \frac{(\lambda/\mu)^s}{s!} \left(\frac{\lambda}{s\mu}\right)^{n-s} = \frac{(\lambda/\mu)^n}{s! s^{n-s}} & \text{para } n = s, s+1, \dots, K \\ 0 & \text{para } n > K. \end{cases}$$

Así,

$$P_n = \begin{cases} \frac{(\lambda/\mu)^n}{n!} P_0 & \text{para } n = 1, 2, \dots, s \\ \frac{(\lambda/\mu)^n}{s! s^{n-s}} P_0 & \text{para } n = s, s+1, \dots, K \\ 0 & \text{para } n > K, \end{cases}$$

donde

$$P_0 = 1 / \left[\sum_{n=0}^s \frac{(\lambda/\mu)^n}{n!} + \frac{(\lambda/\mu)^s}{s!} \sum_{n=s+1}^K \left(\frac{\lambda}{s\mu}\right)^{n-s} \right].$$

(Estas fórmulas aplican la convención de que $n! = 1$ cuando $n = 0$.)

Si se adapta a este caso la derivación de L_q del modelo $M/M/s$, se llega a

$$L_q = \frac{P_0(\lambda/\mu)^s \rho}{s!(1-\rho)^2} [1 - \rho^{K-s} - (K-s)\rho^{K-s}(1-\rho)],$$

donde $\rho = \lambda/(s\mu)$.⁸ Se puede demostrar que

$$L = \sum_{n=0}^{s-1} nP_n + L_q + s \left(1 - \sum_{n=0}^{s-1} P_n\right).$$

Y W y W_q se obtienen a partir de estas cantidades, como se mostró en el caso de un solo servidor.

El archivo de Excel de este capítulo incluye una plantilla para calcular las medidas de desempeño anteriores (inclusive las P_n) de este modelo.

Un caso especial e interesante de este modelo es cuando $K = s$, de manera que la capacidad de la cola es $K - s = 0$. En este caso, los clientes que llegan cuando todos los servidores están ocupados dejan el sistema de inmediato y se pierden. Esto ocurrirá, por ejemplo, en una red telefónica con s líneas troncales de manera que cuando todas estas líneas están ocupadas, quien llama obtiene una

⁸ Si $\rho = 1$, es necesario aplicar la regla de L'Hôpital dos veces a esta expresión de L_q . De otra manera, todos estos resultados se cumplen para toda $\rho > 0$. La razón para que este sistema de colas alcance la condición de estado estable aun cuando $\rho \geq 1$ es que $\lambda_n = 0$ para toda $n \geq K$, de modo que el número de clientes en el sistema no puede seguir creciendo en forma indefinida.

señal de ocupado y cuelga. Este tipo de sistema (un “sistema de colas” sin cola) se conoce como *sistema de pérdidas Erlang*, porque el primero que lo estudió a principios del siglo xx fue A. K. Erlang, un ingeniero en telefonía holandés, a quien se considera el fundador de la teoría de colas.

Ahora resulta común que los sistemas telefónicos de un centro de llamadas proporcionen algunas líneas extras que colocan a la persona que llama en espera, pero los clientes adicionales obtendrán una señal de ocupado. Dicho sistema también se ajusta a este modelo, donde $(K - s)$ es el número de líneas adicionales que colocan las llamadas en espera. Uno de los ejemplos de la sección Worked Examples del sitio en internet de este libro ilustra la aplicación de este modelo a un sistema como el descrito.

Variación de fuente de entrada finita al modelo $M/M/s$

Ahora suponga que la única diferencia con el modelo $M/M/s$ (según se definió en la sección 17.2) es que la *fente de entrada* está *limitada*; es decir, el tamaño de la *población potencial* es *finito*. En este caso, sea N el tamaño de esa población. Cuando el número de clientes en el sistema de colas es n ($n = 0, 1, 2, \dots, N$), existen sólo $N - n$ clientes *potenciales* restantes en la fuente de entrada.

La aplicación más importante de este modelo es el problema de reparación de máquinas, en el que se asigna a uno o más técnicos la responsabilidad de mantener en operación cierto grupo de N máquinas dando servicio a cada una de las que se descomponen. (El ejemplo que se presentó al final de la sección 16.8 ilustra esta aplicación cuando se usa el procedimiento general para resolver cualquier *cadena de Markov de tiempo continuo* en lugar de las fórmulas específicas disponibles para el proceso de nacimiento y muerte.) Se considera que un técnico de mantenimiento es un servidor individual en el sistema de colas si trabaja en forma independiente en máquinas diferentes, mientras que los miembros de una cuadrilla completa se toman como un servidor si trabajan unidos en cada máquina. Las máquinas constituyen la población potencial. Cada una se considera un cliente en el sistema de colas cuando está descompuesta en espera de ser reparada, mientras que cuando está en operación está fuera del sistema.

Observe que todos los miembros de la población potencial alternan entre estar *adentro* y *afuera* del sistema de colas. Entonces, el análogo del modelo $M/M/s$ que se ajusta a esta situación supone que el *tiempo afuera* de cada miembro (esto es, el tiempo que pasa desde que deja el sistema hasta que regresa) tiene una *distribución exponencial* con parámetro λ . Cuando n miembros están *adentro* y, por supuesto, $N - n$ miembros están *afuera*, la distribución de probabilidad actual del tiempo que *falta* para la próxima llegada al sistema es la distribución del *mínimo* de los *tiempos restantes afuera* de esos $N - n$ miembros. Las propiedades 2 y 3 de la distribución exponencial implican que esta distribución debe ser exponencial con parámetro $\lambda_n = (N - n)\lambda$. Así, el modelo es sólo un caso especial del proceso de nacimiento y muerte que tiene el diagrama de tasas que se presenta en la figura 17.7.

Como $\lambda_n = 0$ para $n = N$, cualquier sistema que se ajuste a este modelo alcanzará en algún momento la condición de estado estable. Los resultados disponibles se resumen de la siguiente manera:

Resultados para el caso de un solo servidor ($s = 1$). Cuando $s = 1$, los factores C_n de la sección 17.5 se reducen a

$$C_n = \begin{cases} N(N-1) \cdots (N-n+1) \left(\frac{\lambda}{\mu}\right)^n = \frac{N!}{(N-n)!} \left(\frac{\lambda}{\mu}\right)^n & \text{para } n \leq N \\ 0 & \text{para } n > N, \end{cases}$$

para este modelo. Entonces, si se usa de nuevo la convención de que $n! = 1$ cuando $n = 0$,

$$P_0 = 1 / \sum_{n=0}^N \left[\frac{N!}{(N-n)!} \left(\frac{\lambda}{\mu}\right)^n \right];$$


$$P_n = \frac{N!}{(N-n)!} \left(\frac{\lambda}{\mu}\right)^n P_0, \quad \text{si } n = 1, 2, \dots, N;$$

$$L_q = \sum_{n=1}^N (n-1)P_n,$$

a) Caso de un solo servidor ($s = 1$)

$$\lambda_n = \begin{cases} (N - n)\lambda, & \text{para } n = 0, 1, 2, \dots, N \\ 0, & \text{para } n \geq N \end{cases}$$


$$\mu_n = \mu, \quad \text{para } n = 1, 2, \dots$$



b) Caso de varios servidores ($s > 1$)

$$\lambda_n = \begin{cases} (N - n)\lambda, & \text{para } n = 0, 1, 2, \dots, N \\ 0, & \text{para } n \geq N \end{cases}$$

$$\mu_n = \begin{cases} n\mu, & \text{para } n = 1, 2, \dots, s \\ s\mu, & \text{para } n = s + 1, \dots \end{cases}$$



■ FIGURA 17.7

Diagrama de tasas de las variaciones de fuente de entrada finita al modelo $M/M/s$.

que se puede reducir a

$$L_q = N - \frac{\lambda + \mu}{\lambda}(1 - P_0);$$

$$L = \sum_{n=0}^N nP_n = L_q + 1 - P_0$$

$$= N - \frac{\mu}{\lambda}(1 - P_0).$$

Por último,

$$W = \frac{L}{\lambda} \quad \text{y} \quad W_q = \frac{L_q}{\lambda},$$

donde

$$\bar{\lambda} = \sum_{n=0}^{\infty} \lambda_n P_n = \sum_{n=0}^N (N - n)\lambda P_n = \lambda(N - L).$$

En este punto podría resultar útil referirse en forma retrospectiva al ejemplo del final de la sección 16.8, porque se ajusta por completo a este modelo del caso de un solo servidor. En particular, $N = 2$, $\lambda = 1$ y $\mu = 2$ para ese ejemplo, así que $P_0 = 0.4$, $P_1 = 0.4$, $P_2 = 0.2$, y así sucesivamente.

Resultados para el caso de varios servidores ($s > 1$). Para $N \geq s > 1$,

$$C_n = \begin{cases} \frac{N!}{(N - n)!n!} \left(\frac{\lambda}{\mu}\right)^n & \text{para } n = 0, 1, 2, \dots, s \\ \frac{N!}{(N - n)!s!s^{n-s}} \left(\frac{\lambda}{\mu}\right)^n & \text{para } n = s, s + 1, \dots, N \\ 0 & \text{para } n > N. \end{cases}$$

Entonces,

$$P_n = \begin{cases} \frac{N!}{(N - n)!n!} \left(\frac{\lambda}{\mu}\right)^n P_0 & \text{si } 0 \leq n \leq s \\ \frac{N!}{(N - n)!s!s^{n-s}} \left(\frac{\lambda}{\mu}\right)^n P_0 & \text{si } s \leq n \leq N \\ 0 & \text{si } n > N, \end{cases}$$

donde

$$P_0 = 1 / \left[\sum_{n=0}^{s-1} \frac{N!}{(N-n)!n!} \left(\frac{\lambda}{\mu} \right)^n + \sum_{n=s}^N \frac{N!}{(N-n)!s!s^{n-s}} \left(\frac{\lambda}{\mu} \right)^n \right].$$

Por último,

$$L_q = \sum_{n=s}^N (n-s)P_n$$

y

$$L = \sum_{n=0}^{s-1} nP_n + L_q + s \left(1 - \sum_{n=0}^{s-1} P_n \right),$$

con lo que después se obtienen W y W_q igual que en el caso de un servidor.

El archivo de Excel de este capítulo contiene una plantilla para realizar todos los cálculos anteriores.

Se dispone de tablas extensas⁹ para los resultados numéricos de este modelo, tanto en el caso de uno como de varios servidores.

Se ha demostrado¹⁰ que en ambos casos, las fórmulas anteriores para obtener P_n y P_0 (y por ende L_q , L , W y W_q) también se cumplen para una generalización de este modelo. En particular, se puede eliminar el supuesto de que los tiempos que los miembros de la población potencial pasan fuera del sistema de colas tienen una *distribución exponencial*, aunque esto ponga al modelo fuera del contexto del proceso de nacimiento y muerte. Siempre que estos tiempos tengan distribuciones idénticas con media $1/\lambda$ (y se cumpla el supuesto de tiempos de servicio exponencial), estos tiempos fuera pueden tener *cualquier* distribución de probabilidad.

17.7 MODELOS DE COLAS CON DISTRIBUCIONES NO EXPONENCIALES

Todos los modelos de teoría de colas de la sección anterior (excepto el de una generalización) se basan en el proceso de nacimiento y muerte, lo que hace necesario que tanto los tiempos entre llegadas como los de servicio tengan distribuciones *exponenciales*. Como ya se dijo en la sección 17.4, este tipo de *distribuciones* de probabilidad tiene muchas propiedades convenientes para la teoría de colas, pero sólo en cierto tipo de sistemas de colas proporciona un ajuste razonable. En particular, el supuesto de tiempos entre llegadas exponenciales implica que las llegadas ocurren al azar (proceso de entrada de Poisson), lo cual es una aproximación razonable en muchas situaciones pero *no* cuando las llegadas están programadas o reguladas con todo cuidado. Todavía más, las distribuciones de tiempos de servicio reales con frecuencia se desvían bastante de la forma exponencial, en particular cuando los requerimientos de servicio de los clientes son muy parecidos. Por ello, es importante disponer de otros modelos de colas que usen otras distribuciones de probabilidad.

Desafortunadamente, el análisis matemático de los modelos de colas con distribuciones no exponenciales es mucho más difícil. Sin embargo, se han podido obtener algunos resultados útiles con algunos modelos. El análisis está más allá del nivel de este libro, pero en esta sección se resumirán los modelos y se describirán sus resultados.

Modelo M/G/1

Como se dijo en la sección 17.2, el modelo M/G/1 supone que el sistema de colas tiene un *servidor* y un *proceso de entradas de Poisson* (tiempos entre llegadas exponenciales) con una tasa media de llegadas fija λ . Como siempre, se supone que los clientes tienen tiempos de servicio *independientes* con la misma distribución de probabilidad, pero no se imponen restricciones sobre cuál debe ser esta distribución de tiempos de servicio. En realidad, sólo es necesario conocer (o estimar) la media $1/\mu$ y la variancia σ^2 de esta distribución.

⁹ L. G. Peck y R. N. Hazelwood, *Finite Queueing Tables*, Wiley, Nueva York, 1958.

¹⁰ B. D. Bunday y R. E. Scraton, "The G/M/r Machine Interference Model", en *European Journal of Operational Research*, 4: 399-402, 1980.

Cualquier sistema de líneas de espera de este tipo podrá alcanzar, en algún momento, una condición de estado estable si $\rho = \lambda/\mu < 1$. Los resultados de estado estable disponibles¹¹ de este modelo general son los siguientes:

$$P_0 = 1 - \rho,$$

$$L_q = \frac{\lambda^2 \sigma^2 + \rho^2}{2(1 - \rho)},$$

$$L = \rho + L_q,$$

$$W_q = \frac{L_q}{\lambda},$$

$$W = W_q + \frac{1}{\mu}.$$

Si se toma en cuenta la complejidad que representa el análisis de un modelo que permite *cualquier* distribución de tiempos de servicio, es notable que se haya podido obtener una fórmula tan sencilla de L_q . Esta fórmula es uno de los resultados más importantes de la teoría de colas gracias a la facilidad con que se aplica y al predominio de los sistemas $M/G/1$ en la práctica. Esta ecuación de L_q (o su contraparte de W_q) con frecuencia recibe el nombre de **fórmula de Pollaczek-Khintchine**, en honor de dos pioneros del desarrollo de teoría de colas que dedujeron la fórmula de manera independiente a principios de la década de 1930.

Observe que para cualquier tiempo de servicio esperado fijo $1/\mu$, L_q , L , W_q y W se incrementan cuando σ^2 aumenta. Este resultado es importante porque indica que la congruencia del servidor tiene gran trascendencia en el desempeño de la instalación de servicio, no sólo en su velocidad promedio. Este punto esencial se ilustra en la siguiente subsección.

Cuando la distribución de los tiempos de servicio es exponencial, $\sigma^2 = 1/\mu^2$ y los resultados anteriores se reducen a los correspondientes al modelo $M/M/1$ que se presentó al inicio de la sección 17.6.

La flexibilidad total en cuanto a la distribución de los tiempos de servicio que proporciona este modelo es en extremo útil, por lo que es lamentable que no se haya tenido éxito en el desarrollo de resultados análogos en el caso de varios servidores. Ahora bien, se han logrado algunos resultados para más de un servidor en los importantes casos especiales descritos en los dos modelos siguientes. (Se dispone de plantillas de Excel en el archivo de este capítulo para realizar los cálculos del modelo $M/G/1$ y los dos modelos que siguen, cuando $s = 1$.)

Modelo $M/D/s$

Cuando el servicio consiste básicamente en la misma tarea rutinaria que el servidor realiza para todos los clientes, tiende a haber poca variación en el tiempo de servicio que se requiere. Muchas veces, el modelo $M/D/s$ proporciona una representación razonable de este tipo de situaciones porque supone que todos los tiempos de servicio son iguales a una *constante* fija (la distribución de tiempos de servicio *degenerada*) y que tiene un proceso de entradas de *Poisson* con tasa media de llegadas fija λ .

Cuando sólo se tiene un servidor, el modelo $M/D/1$ es un caso especial del modelo $M/G/1$, donde $\sigma^2 = 0$, con lo que la *fórmula de Pollaczek-Khintchine* se reduce a

$$L_q = \frac{\rho^2}{2(1 - \rho)},$$

donde a partir de este valor de L_q se pueden obtener L , W_q y W como ya se demostró. Observe que el valor de estas L_q y W_q es exactamente igual a *la mitad* que en el caso de tiempos de servicio exponenciales de la sección 17.6 (el modelo $M/M/1$) en el que $\sigma^2 = 1/\mu^2$, y entonces al decrecer σ^2 pueden mejorar mucho las medidas de desempeño de un sistema de colas.

¹¹ También se dispone de una fórmula recursiva para calcular la distribución de probabilidad del número de clientes en el sistema; vea A. Hordijk y H. C. Tijms: "A Simple Proof of the Equivalence of the Limiting Distribution of the Continuous-Time and the Embedded Process of the Queue Size in the $M/G/1$ Queue", en *Statistica Neerlandica*, **36**:97-100, 1976.

En el caso de la versión de más de un servidor de este modelo ($M/D/s$) se dispone de un método complicado¹² para obtener la distribución de probabilidad de estado estable del número de clientes en el sistema y su media [si se supone que $\rho = \lambda/(s\mu) < 1$]. Existen tabulaciones de estos resultados para muchos casos¹³ y también se dispone de gráficas como la de la figura 17.8 para las medias (L).


Modelo $M/E_k/s$

El modelo $M/D/s$ supone una variación *cero* en los tiempos de servicio ($\sigma = 0$), mientras que la distribución *exponencial* de tiempos de servicio supone una variación muy grande ($\sigma = 1/\mu$). Entre estos dos casos extremos hay un gran intervalo ($0 < \sigma < 1/\mu$), donde caen la mayor parte de las distribuciones de tiempos de servicio *reales*. Otro tipo de distribución teórica de tiempos de servicio que concuerda con este espacio intermedio es la **distribución de Erlang** (llamada así en honor del fundador de la teoría de colas).

La función de densidad de probabilidad de la distribución de Erlang es

$$f(t) = \frac{(\mu k)^k}{(k-1)!} t^{k-1} e^{-k\mu t}, \quad \text{para } t \geq 0,$$

■ **FIGURA 17.8**
Valores de L del modelo
 $M/D/s$ (sección 17.7).



¹² Vea N. U. Prabhu: *Queues and Inventories*, Wiley, Nueva York, 1965, pp. 32-34; también vea pp. 286-288 en la referencia seleccionada 5.

¹³ F. S. Hillier y O. S. Yu, con D. Avis, L. Fossett, F. Lo y M. Reiman, *Queueing Tables and Graphs*, Elsevier North-Holland, Nueva York, 1981.

donde μ y k son parámetros estrictamente positivos de la distribución y k está restringido a valores enteros. (Excepto por esta restricción de entero y la definición de los parámetros, esta distribución es idéntica a la *distribución gamma*.) Su media y desviación estándar son

$$\text{Media} = \frac{1}{\mu}$$

y

$$\text{Desviación estándar} = \frac{1}{\sqrt{k}} \frac{1}{\mu}.$$

En este contexto, k es el parámetro que especifica el grado de variabilidad de los tiempos de servicio con relación a la media. Por lo general, se hace referencia a k como el *parámetro de forma*.

La distribución de Erlang es muy importante en teoría de colas por dos razones. Para describir la primera suponga que $T_1, T_2, \dots, T_k$ son k variables aleatorias independientes con una distribución *exponencial* idéntica, cuya media es $1/(k\mu)$. Entonces, su suma,


$$T = T_1 + T_2 + \dots + T_k$$

tiene una distribución de *Erlang* con parámetros μ y k . La presentación de la distribución exponencial en la sección 17.4 sugiere que el tiempo requerido para realizar cierto tipo de tareas podría tener una distribución exponencial. Sin embargo, el servicio total solicitado por un cliente puede incluir una secuencia de k tareas, y no sólo una, realizadas por el servidor. Si las tareas respectivas tienen una distribución exponencial idéntica de su duración, el tiempo total de servicio tendrá una distribución de Erlang; éste sería el caso, por ejemplo, si el servidor debiera realizar la *misma* tarea exponencial k veces para cada cliente.

La distribución de Erlang también es útil debido a que es una gran familia (dos parámetros) de distribuciones que permiten sólo valores no negativos. Así, por lo general se puede obtener una aproximación razonable de la distribución empírica de los tiempos de servicio si se usa una distribución de Erlang. En realidad, tanto la distribución *exponencial* como la *degenerada* (constante) son casos especiales de distribución de Erlang con $k = 1$ y $k = \infty$, respectivamente. Los valores intermedios de k proporcionan distribuciones intermedias con media $= 1/\mu$, moda $= (k - 1)/(k\mu)$ y varianza $= 1/(k\mu^2)$, como lo sugiere la figura 17.9. Por lo tanto, después de estimar la media y la varianza de una distribución de servicio empírica, estas fórmulas de la media y la varianza se pueden usar para elegir el valor de k que se ajuste a estas estimaciones de manera más cercana.

Ahora considere el modelo $M/E_k/1$, que es el caso especial del modelo $M/G/1$ donde los tiempos de servicio tienen una distribución de Erlang con parámetro de forma $= k$. Cuando se aplica la

■ **FIGURA 17.9**
Familia de distribuciones
Erlang con media constante $1/\mu$.



fórmula de Pollaczek-Khintchine con $\sigma^2 = 1/(k\mu^2)$ (y los resultados correspondientes dados por $M/G/1$) se obtiene

$$L_q = \frac{\lambda^2/(k\mu^2) + \rho^2}{2(1 - \rho)} = \frac{1 + k}{2k} \frac{\lambda^2}{\mu(\mu - \lambda)},$$

$$W_q = \frac{1 + k}{2k} \frac{\lambda}{\mu(\mu - \lambda)},$$


$$W = W_q + \frac{1}{\mu},$$

$$L = \lambda W.$$

Con varios servidores ($M/E_k/s$) se puede aprovechar la relación de la distribución de Erlang con la distribución exponencial que se acaba de describir para formular un proceso de nacimiento y muerte *modificado* (cadena de Markov de parámetro continuo) en términos de las fases del servicio exponencial individual (k por cliente) y no en términos de los clientes. Sin embargo, no ha sido posible derivar una solución general de estado estable [cuando $\rho = \lambda/(s\mu) < 1$] para la distribución de probabilidad del número de clientes en el sistema, como se hizo en la sección 17.5. Más bien se necesitaría una teoría avanzada para resolver en forma numérica los casos individuales. Una vez más, estos resultados se han obtenido y tabulado para casos numéricos.¹⁴ Las medias (L) también se proporcionan en la gráfica de la figura 17.10 para algunos casos donde $s = 2$.

La sección Worked Examples del sitio en internet de este libro incluye **otro ejemplo** en el que se aplica el modelo $M/E_k/s$ para $s = 1$ y $s = 2$ para seleccionar la alternativa menos costosa.

■ **FIGURA 17.10**
Valores de L del modelo
 $M/E_k/2$ (sección 17.7).




¹⁴ Idem.

Modelos sin entradas de Poisson

Todos los modelos de colas que se han presentado hasta ahora han supuesto un proceso de entradas de Poisson (tiempos entre llegadas exponenciales). No obstante, este supuesto se viola si las llegadas se programan o regulan de alguna forma que evite que ocurran de manera aleatoria, en cuyo caso se necesita otro modelo.


Se dispone de tres modelos de este tipo siempre que los tiempos de servicio tengan distribución exponencial con un parámetro fijo. Estos modelos se obtienen al *invertir* las distribuciones supuestas de *tiempos entre llegadas* y *tiempos de servicio* de los tres modelos anteriores. El primero de ellos ($GI/M/s$) no impone restricciones sobre el tipo de distribución de los *tiempos entre llegadas*. En este caso se dispone de algunos resultados de estado estable¹⁵ (en especial sobre las distribuciones de tiempos de espera) de las dos versiones del modelo de uno y varios servidores, pero no son ni cercanamente tan convenientes como las expresiones sencillas del modelo $M/G/1$. El segundo modelo nuevo ($D/M/s$) supone que todos los tiempos entre llegadas son iguales a una *constante* fija, que representaría un sistema de colas en el que se *programan* las llegadas a intervalos regulares. El tercer modelo ($E_k/M/s$) supone una distribución de *Erlang* de los tiempos entre llegadas que maneja el espacio intermedio entre llegadas *regulares programadas* (constante) y *completamente aleatorias* (exponencial). En el caso de estos dos últimos modelos, que incluyen los valores de L que se dan en las gráficas de las figuras 17.11 y 17.12, se cuenta con tabulaciones¹⁶ de resultados que se obtuvieron con base en cálculos extensos.

■ **FIGURA 17.11**
Valores de L del modelo
 $D/M/s$ (sección 17.7).



¹⁵ Por ejemplo, vea pp. 248-260 de la referencia seleccionada 5.

¹⁶ Hillier y Yu, *op. cit.*



■ **FIGURA 17.12**
Valores de L del modelo $E_k/M/2$ (sección 17.7).

Si ni los tiempos entre llegadas ni el tiempo de servicio de un sistema de colas tienen distribución exponencial, entonces existen tres modelos de colas adicionales para los que también se tienen resultados.¹⁷ Uno de estos modelos ($E_m/E_k/s$) supone una distribución de Erlang de ambos tiempos. Los otros dos ($E_k/D/s$ y $D/E_k/s$) suponen que uno de estos tiempos tiene una distribución de Erlang y el otro es igual a una constante fija.

Otros modelos

Aunque en esta sección se ha visto un gran número de modelos de colas con distribuciones no exponenciales, la lista está muy lejos de agotarse. Por ejemplo, otra distribución que se usa a veces ya sea para los tiempos entre llegadas o para los de servicio es la **distribución hiperexponencial**. La característica esencial de esta distribución es que, si bien sólo permite valores no negativos, su desviación estándar σ es más grande que su media $1/\mu$. Esta característica es opuesta a la distribución de Erlang, donde $\sigma < 1/\mu$ en todos los casos excepto cuando $k = 1$ (distribución exponencial), que tiene $\sigma = 1/\mu$. Para ilustrar una situación representativa en la que puede ocurrir que $\sigma > 1/\mu$, suponga que el servicio en cuestión es la reparación de alguna máquina o vehículo. Si muchas de las reparaciones resultan rutinarias (tiempos de servicio pequeños) pero en ocasiones se requiere una reparación general extensa (con tiempos de servicio grandes), entonces la desviación estándar de los tiempos de servicio tiende a ser grande respecto de la media, en cuyo caso se puede usar la distribución hiperexponencial para representarlos. En particular, esta distribución supone que existen probabilidades fijas, p y $(1 - p)$, para la clase de reparación que ocurrirá, y que el tiempo

¹⁷ Idem.

que se requiere para cada clase tiene una distribución exponencial, pero que los parámetros de estas dos distribuciones exponenciales son diferentes. (En general, la distribución hiperexponencial es una composición de este tipo de dos o más distribuciones exponenciales.)

Otra familia de distribuciones que comienza a ser de uso general consiste en **distribuciones tipo fase** (algunas de ellas se llaman *distribuciones erlangianas generalizadas*). Estas distribuciones se obtienen mediante el desglose del tiempo total en cierto número de fases, cada una con distribución exponencial, donde los parámetros de estas distribuciones exponenciales pueden ser diferentes y las fases pueden ser ya sea en serie o en paralelo (o ambos). Un grupo de fases *en paralelo* significa que el proceso elige al azar *una* de las fases cada vez, de acuerdo con probabilidades especificadas. En realidad, este enfoque es la forma en que se deriva la distribución hiperexponencial, por lo que esta distribución es un caso especial de las distribuciones tipo fase. Otro caso especial es la distribución de Erlang, que tiene la restricción de que todas sus k fases están en serie y de que tienen el *mismo* parámetro de sus distribuciones exponenciales. Cuando se eliminan estas restricciones se obtiene mayor flexibilidad en las distribuciones tipo fase para ajustarse a la distribución real de los tiempos entre llegadas o de servicio en los sistemas de colas en estudio. Esta flexibilidad es valiosa en especial cuando, al usar la distribución real en forma directa sobre el modelo, el manejo analítico resulta casi imposible, mientras que la razón de la *media* entre la *desviación estándar* de la distribución real no se acerca a las razones disponibles ($\sqrt{k}$ para $k = 1, 2, \dots$) de la distribución de Erlang.

Los modelos de colas que usan distribuciones tipo fase todavía se pueden representar mediante una *cadena de Markov de tiempo continuo*, puesto que están contruidos a partir de algunas combinaciones de las distribuciones exponenciales. Por lo general, esta cadena de Markov tiene un número infinito de estados, debido a lo cual obtener la distribución de estado estable de los estados del sistema implica resolver un sistema infinito de ecuaciones lineales que tienen una estructura relativamente complicada. La solución de tales sistemas está muy lejos de ser un trabajo rutinario, pero avances teóricos recientes permiten, en algunos casos, resolver estos modelos en forma numérica. Existen tabulaciones extensas¹⁸ de estos resultados de modelos con varias distribuciones tipo fase (que incluyen la distribución hiperexponencial).

17.8 MODELOS DE COLAS CON DISCIPLINA DE PRIORIDADES

En los modelos con disciplina de prioridades, la disciplina de la cola se basa en un *sistema prioritario*. El orden en el que se seleccionan los clientes para darles el servicio se basa en sus prioridades asignadas.

Muchos sistemas reales se ajustan a este tipo de modelos mucho mejor que a otros disponibles. Los trabajos urgentes se hacen antes que otros trabajos y los clientes importantes tienen precedencia sobre otros. Con frecuencia, el uso de modelos con disciplina de prioridades proporciona un refinamiento muy aceptable en comparación con otros modelos de colas más usuales.

Se presentarán dos modelos básicos con disciplina de prioridades. Como ambos se basan en los mismos supuestos, excepto por la naturaleza de las prioridades, primero se describen los modelos juntos y después se resumen sus resultados por separado.

Los modelos

Ambos modelos suponen que existen N *clases de prioridad* (la clase 1 tiene la prioridad más alta y la clase N la más baja) y que siempre que un servidor queda libre para comenzar el servicio de un nuevo cliente, el cliente que se selecciona es el miembro de la clase prioritaria *más alta* representada en la cola y que haya esperado más. En otras palabras, los clientes se seleccionan para comenzar su servicio en el orden de sus clases de prioridad, pero sobre la base de primero en entrar, primero en salir dentro de cada clase prioritaria. Se supone que cada clase prioritaria está sometida a un proceso de entradas de *Poisson* y tiempos de servicio *exponenciales*. El modelo también supone, en cierta manera restrictiva, que el tiempo medio de servicio es el *mismo* para todas las clases prioritarias, pero permite que la tasa media de llegadas difiera entre ellas.

¹⁸ L. P. Seelen, H. C. Tijms y M. H. Van Hoorn: *Tables for Multi-Server Queues*, North-Holland, Amsterdam, 1985.

La distinción entre los dos modelos se basa en que una de las prioridades es *sin interrupción* y la otra *con interrupción*. Cuando se aplica el modelo de **prioridades sin interrupción** no se puede regresar a la cola a un cliente que se encuentra en servicio (interrumpirlo) si entra un cliente de prioridad más alta al sistema de colas. Por lo tanto, una vez que el servidor comienza a atender a un cliente, el servicio debe terminar sin interrupción. El primer modelo supone prioridades sin interrupción.

Cuando se aplica el modelo de **prioridades con interrupción**, el cliente de prioridad más baja que se encuentre en servicio es *interrumpido* (va de regreso a la cola) cada vez que entra un cliente con prioridad más alta al sistema de colas. En esta situación se libera un servidor para que el servicio al recién llegado comience de inmediato. (Cuando un servidor *termina* un servicio, se selecciona el siguiente cliente para comenzar otro servicio como se describió al principio de esta subsección, de manera que, por lo general, un cliente interrumpido regresará a servicio y, después de suficientes intentos, finalmente terminará.) Debido a la propiedad de falta de memoria de la distribución exponencial (vea la sección 17.4), no es necesario preocuparse por definir el punto en el que comienza un servicio cuando regresa un cliente interrumpido; la distribución del tiempo de servicio *restante* es *siempre* la misma. (En cualquier otra distribución de servicio, es importante distinguir entre sistemas *con interrupción* y *continuación*, en los que el servicio a un cliente que se interrumpió se retoma en el punto de interrupción, y los sistemas *con interrupción* y *repetición*, donde el servicio debe comenzar de nuevo.) El segundo modelo supone prioridades con interrupción.

En ambos modelos se pasa por alto esta distinción entre clientes en diferentes clases prioritarias. La propiedad 6 de la distribución exponencial (vea la sección 17.4) implica que todos los clientes llegan de acuerdo con un proceso de entradas de Poisson. Más aún, todos los clientes tienen la *misma* distribución exponencial de tiempos de servicio. En consecuencia, los dos modelos en realidad se ajustan al modelo $M/M/s$ que se estudió en la sección 17.6, *excepto* por el orden en que se sirve a los clientes. Entonces, cuando sólo se cuenta el número *total* de clientes en el sistema, se puede aplicar la distribución de estado estable del modelo $M/M/s$ en ambos modelos. Por lo tanto, las fórmulas de L y L_q también sirven, al igual que los resultados del tiempo esperado de espera (de la fórmula de Little), W y W_q , para un cliente elegido en forma aleatoria. Lo que cambia es la *distribución* de los tiempos de espera que se obtuvo en la sección 17.6 bajo el supuesto de una disciplina de primero en llegar, primero en salir. Cuando se aplica la disciplina de prioridades, esta distribución tiene una *varianza* mucho mayor puesto que los tiempos de espera de los clientes de las clases de prioridad alta tienden a ser mucho menores que con la disciplina de primero en entrar, primero en salir, mientras que los tiempos de espera de las clases de prioridad baja tienden a ser mucho mayores. Al seguir el mismo razonamiento, el desglose del número total de clientes en el sistema tiende a poner un peso desproporcionado en las clases prioritarias bajas. Esta condición es el motivo de que se impongan prioridades sobre el sistema de colas. Se desea *mejorar* las *medidas de desempeño* de cada clase prioritaria alta a costa del desempeño de las clases de prioridad baja. Para determinar cuál es la mejora lograda es necesario obtener estas medidas en términos de *tiempo de espera esperado en el sistema* y el *número esperado de clientes en el sistema* de las clases de prioridad individuales. En seguida se obtendrán expresiones de estas medidas en los dos modelos.

Resultados en el modelo con prioridades sin interrupción

Sea W_k el tiempo esperado de espera en el sistema en estado estable (lo cual incluye el tiempo de servicio) de un miembro de la clase de prioridad k . Entonces,

$$W_k = \frac{1}{AB_{k-1}B_k} + \frac{1}{\mu}, \quad \text{para } k = 1, 2, \dots, N,$$

$$\text{donde } A = s! \frac{s\mu - \lambda}{r^s} \sum_{j=0}^{s-1} \frac{r^j}{j!} + s\mu,$$

$$B_0 = 1,$$

$$B_k = 1 - \frac{\sum_{i=1}^k \lambda_i}{s\mu},$$

s = número de servidores,

μ = tasa media de servicio por servidor ocupado,

λ_i = tasa media de llegadas de la clase de prioridad i ,

$$\lambda = \sum_{i=1}^N \lambda_i,$$

$$r = \frac{\lambda}{\mu}.$$

(Estos resultados suponen que

$$\sum_{i=1}^k \lambda_i < s\mu,$$

de manera que la clase de prioridad k puede alcanzar una condición de estado estable.) La *fórmula de Little* se aplica a las clases individuales de prioridad, por lo que L_k , el número esperado de miembros de la clase de prioridad k en el sistema de colas (incluso los que están en servicio), es

$$L_k = \lambda_k W_k, \quad \text{para } k = 1, 2, \dots, N.$$

Para determinar el tiempo esperado de espera en la cola (sin incluir el tiempo de servicio) de la clase de prioridad k , sólo se resta $1/\mu$ de W_k ; la longitud esperada de la cola correspondiente se obtiene de nuevo si se multiplica por λ_k . En el caso especial en el que $s = 1$, la expresión de A se reduce a $A = \mu^2/\lambda$.

En el OR Courseware se proporciona una plantilla de Excel para realizar los cálculos anteriores.

En la sección Worked Examples del sitio en internet de este libro se da **un ejemplo** que ilustra la aplicación del modelo de prioridades sin interrupción para determinar cuántos tornos debe tener una fábrica cuando los trabajos por realizar caen en tres clases de prioridad.

Variación de un servidor en el modelo de prioridades sin interrupción

El supuesto anterior de que el tiempo de servicio esperado $1/\mu$ es el mismo para todas las clases prioritarias es bastante restrictivo. En la práctica, a veces se viola este supuesto debido a diferencias en los requerimientos de servicio entre las clases de prioridad.

Por fortuna, en el caso especial de un servidor, es posible admitir tiempos esperados de servicio distintos y de todas formas obtener resultados útiles. Sea $1/\mu_k$ la media de la distribución exponencial del tiempo de servicio de la clase de prioridad k , entonces

$$\mu_k = \text{tiempo medio de servicio de la clase de prioridad } k, \quad \text{para } k = 1, 2, \dots, N.$$

Así, el tiempo esperado de estado estable en el sistema de un miembro de prioridad k es

$$W_k = \frac{a_k}{b_{k-1}b_k} + \frac{1}{\mu_k}, \quad \text{para } k = 1, 2, \dots, N,$$

$$\text{donde } a_k = \sum_{i=1}^k \frac{\lambda_i}{\mu_i^2},$$

$$b_0 = 1,$$

$$b_k = 1 - \sum_{i=1}^k \frac{\lambda_i}{\mu_i}.$$

Este resultado es válido mientras

$$\sum_{i=1}^k \frac{\lambda_i}{\mu_i} < 1,$$

que permite a la clase con prioridad k alcanzar una condición de estado estable. La fórmula de Little se puede usar como se describió para obtener las otras medidas de desempeño de cada clase prioritaria.

Resultados en el modelo de prioridades con interrupción

En el modelo de prioridades con interrupción, se necesita retomar el supuesto de que el tiempo esperado de servicio es el mismo para todas las clases de prioridad. Con la misma notación que en el modelo anterior, el hecho de poder interrumpir cambia el tiempo esperado *total* en el sistema (incluido el tiempo total de servicio) a

$$W_k = \frac{1/\mu}{B_{k-1}B_k}, \quad \text{para } k = 1, 2, \dots, N,$$

en el caso de *un servidor* ($s = 1$). Cuando $s > 1$, la W_k se puede calcular mediante un proceso iterativo que se ilustrará con el ejemplo del Hospital General. La L_k que se acaba de definir todavía satisface la relación

$$L_k = \lambda_k W_k, \quad \text{para } k = 1, 2, \dots, N.$$

Los resultados correspondientes de la cola (excluyendo los clientes en servicio) también se pueden obtener a partir de W_k y L_k igual que en el caso de prioridades sin interrupción. Debido a la propiedad de falta de memoria de la distribución exponencial (vea la sección 17.4), las interrupciones no afectan el proceso de servicio (ocurrencias de terminaciones de servicio) de ninguna manera. El tiempo total esperado de servicio de cualquier cliente es $1/\mu$.

El archivo de Excel de este capítulo incluye una plantilla para calcular las medidas de desempeño anteriores en el caso de un solo servidor.

Ejemplo del Hospital General con prioridades

En el problema de la sala de urgencias del Hospital General, el ingeniero administrador observó que los pacientes no son atendidos sobre la base de primero en llegar, primero en salir. En su lugar, parece que la enfermera que realiza las admisiones divide a los pacientes en tres grandes categorías: 1) casos *críticos*, en los que el tratamiento inmediato es vital para la supervivencia; 2) casos *serios*, en los que un tratamiento rápido es importante para prevenir mayor daño, y 3) casos *estables*, en los que el tratamiento puede retrasarse sin consecuencias médicas adversas. Entonces, se atiende a los pacientes en este orden de prioridad, esto es, los pacientes de la misma categoría por lo general son atendidos según la regla de primero en llegar, primero en salir. Un médico interrumpe el tratamiento de un paciente si llega un caso nuevo de una categoría de prioridad más alta. Alrededor de 10% de los pacientes caen en la primera categoría, 30% en la segunda y 60% en la tercera. Debido a que los enfermos más graves se internan en el hospital después de recibir los primeros auxilios, el tiempo promedio de tratamiento por un médico en la sala de urgencias en realidad no difiere mucho entre estas categorías.

El ingeniero ha decidido emplear el modelo de colas con disciplina de prioridades como una representación razonable de este sistema de colas, en el que las tres categorías de pacientes constituyen las tres clases de prioridad del modelo. Como el tratamiento se interrumpe debido a la llegada de un caso de prioridad más alta, la *versión de prioridades con interrupción* es la apropiada. Dados los datos que se tenían desde antes ($\mu = 3$ y $\lambda = 2$), los porcentajes anteriores conducen a $\lambda_1 = 0.2$, $\lambda_2 = 0.6$ y $\lambda_3 = 1.2$. La tabla 17.3 proporciona los tiempos de espera esperados en la cola que resultan (*excluyendo* los tiempos de servicio) para las respectivas clases de prioridad¹⁹ cuando hay un médico ($s = 1$) o dos médicos ($s = 2$) de guardia. (En dicha tabla también se presentan los resultados correspondientes a la versión de prioridades sin interrupción para mostrar el efecto de las interrupciones.)

Obtención de resultados de prioridades con interrupción. Estos resultados de prioridades con interrupción con $s = 2$ se obtuvieron de la manera siguiente. Como los tiempos de espera de los clientes de la clase de prioridad 1 no se ven afectados por la presencia de clientes de clases de prioridad más baja, W_1 será la misma que para cualesquiera otros valores de λ_2 y λ_3 , incluyendo

¹⁹ Observe que estos tiempos esperados ya no se pueden interpretar como el tiempo esperado antes de que comience el tratamiento cuando $k > 1$, porque el tratamiento puede ser interrumpido por lo menos una vez, lo que causa un tiempo de espera adicional antes de terminar el servicio.

■ **TABLA 17.3** Resultados de estado estable del modelo de disciplina de prioridades del problema del Hospital General

	Prioridades con interrupción		Prioridades sin interrupción	
	$s = 1$	$s = 2$	$s = 1$	$s = 2$
A	—	—	4.5	36
B_1	0.933	—	0.933	0.967
B_2	0.733	—	0.733	0.867
B_3	0.333	—	0.333	0.667
$W_1 - \frac{1}{\mu}$	0.024 horas	0.00037 horas	0.238 horas	0.029 horas
$W_2 - \frac{1}{\mu}$	0.154 horas	0.00793 horas	0.325 horas	0.033 horas
$W_3 - \frac{1}{\mu}$	1.033 horas	0.06542 horas	0.889 horas	0.048 horas

$\lambda_2 = 0$ y $\lambda_3 = 0$. Entonces, W_1 debe ser igual a W en el modelo correspondiente de una clase (modelo $M/M/s$ de la sección 17.6) con $s = 2$, $\mu = 3$ y $\lambda = \lambda_1 = 0.2$, que conduce a

$$W_1 = W = 0.33370 \text{ horas, para } \lambda = 0.2$$

así

$$W_1 - \frac{1}{\mu} = 0.33370 - 0.33333 = 0.00037 \text{ horas.}$$

Ahora considere las dos primeras clases de prioridad. De nuevo observe que los clientes de las clases de prioridad más baja (en este caso sólo la clase 3) no afectan a los clientes de estas dos clases en nada y por lo tanto se pueden pasar por alto en el análisis. Sea $\bar{W}_{1-2}$ tiempo esperado de espera en el sistema (incluido el tiempo de servicio) de una llegada aleatoria en cualquiera de estas dos clases, de manera que la probabilidad de que esta llegada pertenezca a la clase 1 es $\lambda_1/(\lambda_1 + \lambda_2) = \frac{1}{4}$ y de que pertenezca a la clase 2 es $\lambda_2/(\lambda_1 + \lambda_2) = \frac{3}{4}$. Por lo tanto,

$$\bar{W}_{1-2} = \frac{1}{4}W_1 + \frac{3}{4}W_2.$$

Lo que es más, como el tiempo de espera esperado es el mismo para cualquier disciplina de la cola, $\bar{W}_{1-2}$ también debe ser igual a W para el modelo $M/M/s$ de la sección 17.6, con $s = 2$, $\mu = 3$ y $\lambda = \lambda_1 + \lambda_2 = 0.8$, lo que conduce a

$$\bar{W}_{1-2} = W = 0.33937 \text{ horas, para } \lambda = 0.8.$$

Cuando se combinan estos hechos se obtiene

$$W_2 = \frac{4}{3} \left[0.33937 - \frac{1}{4} (0.33370) \right] = 0.34126 \text{ horas.}$$

$$\left(W_2 - \frac{1}{\mu} = 0.00793 \text{ horas.} \right)$$

Por último, sea $\bar{W}_{1-3}$ el tiempo de espera esperado en el sistema (incluido el tiempo de servicio) de una llegada aleatoria de cualquiera de las tres clases de prioridad, tal que las probabilidades respectivas de que pertenezca a la clase 1, 2 o 3 son 0.1, 0.3 y 0.6. Entonces,

$$\bar{W}_{1-3} = 0.1W_1 + 0.3W_2 + 0.6W_3.$$

Más aún, $\bar{W}_{1-3}$ también debe ser igual a la W del modelo $M/M/s$ en la sección 17.6, con $s = 2$, $\mu = 3$ y $\lambda = \lambda_1 + \lambda_2 + \lambda_3 = 2$, de manera que (de la tabla 17.2)

$$\bar{W}_{1-3} = W = 0.375 \text{ horas, para } \lambda = 2.$$

En consecuencia,

$$\begin{aligned}
 W_3 &= \frac{1}{0.6} [0.375 - 0.1(0.33370) - 0.3(0.34126)] \\
 &= 0.39875 \text{ horas.} \\
 \left(W_3 - \frac{1}{\mu} \right) &= 0.06542 \text{ horas.}
 \end{aligned}$$

También se podrían usar, de la misma forma, los resultados correspondientes de W_q del modelo $M/M/s$ de la sección 17.6 para deducir de manera directa las cantidades $W_q - 1/\mu$.

Conclusiones. Cuando $s = 1$, los valores $W_k - 1/\mu$ de la tabla 17.3 en el caso de prioridades con interrupción indican que, si se proporciona un solo médico, puede ocurrir que algunos casos críticos esperen alrededor de un minuto y medio (0.024 horas) en promedio, los casos serios esperarían más de 9 minutos y los casos estables más de 1 hora. (Compare estos resultados con la espera promedio $W_k - \frac{2}{3}$ hora, para todos los pacientes, que se obtuvo en la tabla 17.2 con la disciplina de primero en entrar, primero en salir.) Ahora bien, estos valores representan *esperanzas estadísticas*, por lo que algunos pacientes tendrán que esperar bastante más que el promedio de su clase de prioridad. Esta espera no sería tolerable para los casos críticos y serios, en los que unos minutos pueden ser vitales. Por el contrario, los resultados con $s = 2$ en la tabla 17.3 (prioridades con interrupción) indican que si se agrega un segundo médico, casi se eliminaría la espera de todos los pacientes menos los estables. El ingeniero recomendó que el próximo año se asignaran dos médicos a la sala de urgencias durante las primeras horas de la tarde. El consejo directivo del Hospital General adoptó esta recomendación y, al mismo tiempo, aumentó el costo por el uso de esas instalaciones.

17.9 REDES DE COLAS

Hasta ahora se han tomado en cuenta nada más los sistemas de colas que tienen una estación de servicio con uno o más servidores, pero, en realidad, los sistemas de colas que se encuentran en los estudios de IO a veces son *redes de colas*, es decir, redes de instalaciones de servicio en las que los clientes solicitan el servicio de algunas o todas ellas. Por ejemplo, las órdenes que se procesan en un taller se deben programar a través de una secuencia de máquinas entre un grupo (instalaciones de servicio). Es necesario, entonces, estudiar toda la red para obtener información sobre el tiempo esperado total, número esperado de clientes en todo el sistema, etcétera.

Debido a la importancia de las redes de colas, hay mucha actividad de investigación en esta área. Sin embargo, es un campo difícil y aquí se dará sólo una breve introducción.

El descubrimiento e implicaciones de un resultado de importancia fundamental para las redes de colas merecen atención especial. Se trata de la *propiedad de equivalencia* del *proceso de entrada* de los clientes y un *proceso de salida* de los que se van, en ciertos sistemas de colas.

Propiedad de equivalencia: suponga que una instalación de servicio tiene s servidores, un proceso de entradas Poisson con parámetro λ y la misma distribución de los tiempos de servicio de cada servidor con parámetro μ (el modelo $M/M/s$), en donde $s\mu > \lambda$. Entonces, la *salida* en estado estable de esta instalación de servicio también es un proceso de Poisson con parámetro λ .

Observe que esta propiedad no tiene supuestos sobre el tipo de disciplina de la cola que se usa. Ya sea primero en entrar, primero en salir, aleatorio o incluso una disciplina de prioridades como la de la sección 17.8, los clientes que ya fueron atendidos dejarán la instalación de servicio de acuerdo con un proceso de Poisson. La implicación esencial de este hecho para las redes de colas es que si estas unidades tienen que pasar a otra estación para continuar su servicio, esta segunda estación *también* tendrá entradas de Poisson. Con una distribución exponencial de los tiempos de servicio la propiedad de equivalencia se cumplirá también para esta instalación que puede proporcionar entradas de Poisson para una tercera instalación, y así sucesivamente. A continuación se presentarán las consecuencias de dos tipos básicos de redes.

Recuadro de aplicación

Por muchas décadas, **General Motors Corporation (GM)** gozó de tener la posición de líder mundial en la industria automotriz antes de que Toyota ocupara dicho lugar. GM tiene operaciones de manufactura en 32 países, emplea a más de 300 000 personas a nivel mundial y genera ganancias anuales cercanas a los 200 000 millones de dólares. Sin embargo, desde finales de los ochenta, cuando la productividad de las plantas de GM ocupaba un lugar muy por debajo de la industria, la posición en el mercado de la compañía se ha deteriorado debido a la creciente competencia extranjera.

Para contrarrestar los efectos de dicha competencia, la alta administración de GM inició hace muchos años un proyecto de IO a largo plazo con el fin de predecir y mejorar la producción en las cientos de líneas de montaje de la compañía en todo el mundo. El objetivo fue incrementar en gran medida la productividad de sus operaciones de manufactura y, por ende, lograr una ventaja estratégica competitiva.

La herramienta analítica más importante que se utilizó en este proyecto ha sido un *modelo de colas complejo* que utiliza un simple modelo de un solo servidor. El modelo consta de una línea de producción de dos estaciones, cada una de las cuales se modela como un sistema de colas de un solo servidor con tiempos constantes entre llegadas y tiempos constantes de servicio con las excepciones siguientes. En ocasiones, el servidor (comúnmente llamado máquina) de cada estación sale de servicio y no vuelve a trabajar sino hasta que se repara. El servidor de la primera estación también se apaga cuando termina un servicio y el búffer entre las estaciones se llena. El servidor de la segunda estación se detiene cuando termina un servicio y no ha recibido todavía un trabajo proveniente de la primera estación.

El siguiente paso en el análisis consiste en extender este modelo de colas a una línea de producción de dos estaciones a un modelo de una línea de producción con cualquier número de estaciones. Este modelo de colas mayor se utiliza después para analizar la forma en que las líneas de producción deben diseñarse a fin de maximizar su producción. (La técnica de *simulación* que se describirá en el capítulo 20 también se utiliza para este propósito en líneas de producción relativamente complejas.)

Esta *aplicación de la teoría de colas* (y simulación), junto con los sistemas de recolección de datos que la soportan, ha dado enormes beneficios a GM. De acuerdo con fuentes imparciales de la industria, sus plantas, que una vez fueron de las menos productivas en la industria, ahora se encuentran entre las más altas. Las mejoras resultantes en cuanto a producción en más de 30 plantas de automóviles y 10 países han representado una **ganancia de 2 100 millones de dólares en ahorros y ganancias comprobados**. Estos dramáticos resultados llevaron a General Motors a ganar en 2005 el primer lugar en la competencia internacional por el Premio Franz Edelman al desempeño en investigación de operaciones y ciencias de la administración.

Fuente: J. M. Alden, L. D. Burns, T. Costy, R. D. Hutton, C. A. Jackson, D. S. Kim, K. A. Kohls, J. H. Owen, M. A. Turnquist y D. J. Vander Veen, "General Motors Increases Its Production Throughput", en *Interfaces*, **36**(1): 6-25, enero-febrero de 2006. (En el sitio en internet de este libro www.mhhe.com/hillier se proporciona una liga hacia este artículo.)

Colas infinitas en serie

Suponga que todos los clientes deben recibir servicio en una *serie* de m instalaciones, en una secuencia fija. Además, que cada instalación tiene una cola infinita (el número de clientes que acepta no tiene límite), de manera que las instalaciones en serie forman un sistema de *colas infinitas en serie*. Suponga, además, que los clientes llegan a la primera instalación de acuerdo con un proceso de Poisson con parámetro λ y que cada instalación i ($i = 1, 2, \dots, m$) tiene la misma distribución exponencial de tiempos de servicio con parámetro μ_i de sus s_i servidores, donde $s_i \mu_i > \lambda$. Debido a la propiedad de equivalencia se puede decir que (en condiciones de estado estable) cada instalación de servicio tiene entrada Poisson con parámetro λ . Entonces, se puede usar el modelo elemental $M/M/s$ de la sección 17.6 (o su contraparte con disciplina de prioridades de la sección 17.8) para analizar cada instalación de servicio en forma independiente de las otras.

Al poder usar el modelo $M/M/s$ para obtener las medidas de desempeño de cada instalación independiente, en lugar de analizar la interacción entre las instalaciones, se logra una simplificación enorme. Por ejemplo, la probabilidad de tener n clientes en una instalación en particular está dada por la fórmula de P_n de la sección 17.6 del modelo $M/M/s$. La *probabilidad conjunta* de n_1 clientes en la instalación 1, n_2 clientes en la instalación 2, etc., es, entonces, el *producto* de las probabilidades individuales obtenidas de esta manera sencilla. En particular, esta probabilidad conjunta se puede expresar como

$$P\{(N_1, N_2, \dots, N_m) = (n_1, n_2, \dots, n_m)\} = P_{n_1} P_{n_2} \cdots P_{n_m}.$$

(Esta forma sencilla de solución se llama **solución en forma de producto**.) De manera similar, el tiempo de espera total esperado y el número esperado de clientes en el sistema completo se pueden obtener con sólo sumar las cantidades correspondientes que se obtuvieron de cada instalación.

Desafortunadamente, la propiedad de equivalencia y sus implicaciones no se cumplen en el caso de colas *finitas* que se presentó en la sección 17.6. En realidad, este caso es importante en la práctica, puesto que, con frecuencia, existen limitaciones definidas de la longitud de la cola que admite cada instalación de servicio de una red. Por ejemplo, es común que se proporcione sólo un pequeño espacio para almacenaje en cada instalación (estación de trabajo) de una línea de producción. Para este tipo de sistemas de colas finitas en serie no se dispone de una solución en forma de producto sencilla. En su lugar, se deben analizar las instalaciones en forma conjunta y sólo se han obtenido resultados limitados.

Redes de Jackson

Los sistemas de colas infinitas en serie no son las únicas redes de colas en las que se puede usar el modelo $M/M/s$ para analizar cada instalación de servicio de manera independiente. Otro tipo importante de redes con esta propiedad (solución en forma de producto) son las *redes de Jackson*, que reciben este nombre en honor a James R. Jackson, quien primero estableció, hace ya varias décadas, las características de las redes y demostró que se cumple esta propiedad.

Las características de una red de Jackson son las mismas supuestas para el sistema de colas infinitas en serie, excepto que ahora los clientes visitan las instalaciones en diferente orden (y pueden no llegar a todas). Para cada instalación, los clientes que llegan provienen *tanto* de afuera del sistema (de acuerdo con un proceso de Poisson) como de otras instalaciones. A continuación se resumen estas características.

Una **red de Jackson** es un sistema de m instalaciones de servicio en donde la instalación i ($i = 1, 2, \dots, m$) tiene:

1. Una cola infinita
2. Clientes que llegan de afuera del sistema según un proceso de entrada Poisson con parámetro a_i
3. s_i servidores con distribución exponencial de tiempos de servicio con parámetro μ_i .

Un cliente que deja la instalación i se encamina después a la instalación j ($j = 1, 2, \dots, m$) con probabilidad p_{ij} o sale del sistema con probabilidad

$$q_i = 1 - \sum_{j=1}^m p_{ij}.$$

Cualquier red de este tipo tendrá la siguiente propiedad.

En condiciones de estado estable, cada instalación j ($j = 1, 2, \dots, m$) de una red de Jackson se comporta como si fuera un sistema de colas $M/M/s$ *independiente* con tasa de llegadas

$$\lambda_j = a_j + \sum_{i=1}^m \lambda_i p_{ij},$$

donde $s_i \mu_i > \lambda_i$.

Esta propiedad clave no se puede *demostrar* en forma directa a partir de la propiedad de equivalencia (el razonamiento lleva a caminar en círculos), pero sí proporciona un *fundamento intuitivo*. Este punto de vista intuitivo (no tan correcto en el sentido técnico) es que, en cada instalación i , los procesos de entrada desde las diferentes fuentes (externa y de otras instalaciones) *son procesos de Poisson independientes*, de manera que el proceso de entrada *agregado* es de Poisson con parámetro λ_i (propiedad 6 de la sección 17.4). La propiedad de equivalencia dice entonces que el proceso de *salida agregado* de la instalación i debe ser Poisson con parámetro λ_i . Al desagregar este proceso de salida (otra vez propiedad 6), el proceso de los clientes que salen de la instalación i a la instalación j debe ser Poisson con parámetro $\lambda_i p_{ij}$. Este proceso se convierte en uno de los procesos de *entrada* de Poisson de la instalación j , lo que ayuda a mantener la serie de procesos de Poisson en todo el sistema.

La ecuación anterior para obtener λ_j se basa en el hecho de que λ_i es tanto la *tasa de salida* como la tasa de entrada de todos los clientes que utilizan la instalación i . Como p_{ij} es la proporción de clientes que salen de la instalación i para ir a la instalación j , la tasa a la que estos clientes de la

instalación i llegan a la instalación j es $\lambda_i p_{ij}$. Al sumar estos productos sobre toda i y después agregar esta suma a a_j , se obtiene la *tasa de llegadas total* a la instalación j desde todas las fuentes.

Para calcular λ_j a partir de esta ecuación se requiere conocer las λ_i para $i \neq j$, pero estas λ_i también son incógnitas dadas por las ecuaciones correspondientes. Por lo tanto, el procedimiento es obtener *simultáneamente* $\lambda_1, \lambda_2, \dots, \lambda_m$ mediante la solución simultánea de todo el sistema de ecuaciones lineales, con λ_j para $j = 1, 2, \dots, m$. En el IOR Tutorial se incluye una plantilla de Excel para obtener las λ_j de esta manera.

Para ilustrar estos cálculos, considere una red de Jackson con tres estaciones de servicio que tienen los parámetros que se muestran en la tabla 17.4. Al sustituirlos en la fórmula de λ_j para $j = 1, 2, 3$, se obtiene

$$\begin{aligned}\lambda_1 &= 1 + 0.1\lambda_2 + 0.4\lambda_3 \\ \lambda_2 &= 4 + 0.6\lambda_1 + 0.4\lambda_3 \\ \lambda_3 &= 3 + 0.3\lambda_1 + 0.3\lambda_2.\end{aligned}$$

(Piense en cada una de las ecuaciones para ver por qué dan la tasa de llegadas total.) La solución simultánea de este sistema es

$$\lambda_1 = 5, \quad \lambda_2 = 10, \quad \lambda_3 = 7\frac{1}{2}.$$

Dada esta solución simultánea, se pueden analizar las tres estaciones de servicio de *manera independiente* mediante las fórmulas del modelo $M/M/s$ que se presentó en la sección 17.6. Por ejemplo, para obtener la distribución del número de clientes $N_i = n_i$ en la estación i , note que

$$\rho_i = \frac{\lambda_i}{s_i \mu_i} = \begin{cases} \frac{1}{2} & \text{para } i = 1 \\ \frac{1}{2} & \text{para } i = 2 \\ \frac{3}{4} & \text{para } i = 3. \end{cases}$$

Al sustituir estos valores (y los parámetros de la tabla 17.4) en la fórmula de P_n se obtiene,

$$\begin{aligned}P_{n_1} &= \frac{1}{2} \left(\frac{1}{2} \right)^{n_1} && \text{para la instalación 1,} \\ P_{n_2} &= \begin{cases} \frac{1}{3} & \text{para } n_2 = 0 \\ \frac{1}{3} & \text{para } n_2 = 1 \\ \frac{1}{3} \left(\frac{1}{2} \right)^{n_2-1} & \text{para } n_2 \geq 2 \end{cases} && \text{para la instalación 2,} \\ P_{n_3} &= \frac{1}{4} \left(\frac{3}{4} \right)^{n_3} && \text{para la instalación 3.}\end{aligned}$$

La *probabilidad conjunta* de (n_1, n_2, n_3) está dada por la forma de solución de producto,

$$P\{(N_1, N_2, N_3) = (n_1, n_2, n_3)\} = P_{n_1} P_{n_2} P_{n_3}.$$

■ **TABLA 17.4** Datos del ejemplo de una red de Jackson

Instalación j	s_j	μ_j	a_j	p_{ij}		
				$i = 1$	$i = 2$	$i = 3$
$j = 1$	1	10	1	0	0.1	0.4
$j = 2$	2	10	4	0.6	0	0.4
$j = 3$	1	10	3	0.3	0.3	0

De manera similar, el número esperado de clientes L_i , en la estación i se puede calcular como en la sección 17.6:

$$L_1 = 1, \quad L_2 = \frac{4}{3}, \quad L_3 = 3.$$

El número *total* de clientes esperado en todo el sistema es

$$L = L_1 + L_2 + L_3 = 5\frac{1}{3}.$$

La obtención de W , el tiempo esperado de espera *total* en el sistema (incluido el servicio) de un cliente tiene un pequeño truco. No se puede simplemente sumar los tiempos de espera esperados en cada una de las estaciones porque un cliente no necesariamente llega a cada una de ellas sólo una vez. No obstante, se puede usar la fórmula de Little, donde la tasa de llegadas al sistema λ es la suma de las tasas de llegadas *desde afuera* a las estaciones, $\lambda = a_1 + a_2 + a_3 = 8$. Entonces,

$$W = \frac{L}{a_1 + a_2 + a_3} = \frac{2}{3}.$$

En conclusión debe señalarse que existen otros tipos de redes de colas (más complicados), donde las estaciones de servicio se pueden analizar de manera independiente de las otras. En realidad, encontrar redes de colas con una solución en forma de producto ha sido como el Santo Grial para la investigación en esta área. Las referencias seleccionadas 3 y 12 contienen información adicional.

17.10 APLICACIÓN DE LA TEORÍA DE COLAS

Debido al valor de la información que proporciona la teoría de colas, ésta se usa con amplitud para dirigir el diseño (o rediseño) de sistemas de líneas de espera. A continuación se explicará cómo se aplica para este fin.

Las decisiones más comunes que deben tomarse cuando se diseña un sistema de colas es cuántos servidores se deben proporcionar. Sin embargo, hay otra serie de decisiones que también pueden ser necesitadas. Las posibles decisiones incluyen:

1. Número de servidores en cada instalación de servicio.
2. Eficiencia de los servidores.
3. Número de instalaciones de servicio.
4. Cantidad de espacio para espera en la cola.
5. Algunas prioridades para diferentes categorías de clientes.

De manera típica, las dos consideraciones primordiales cuando se deben tomar estos tipos de decisiones son 1) el costo en el que se incurre al dar el servicio y 2) las consecuencias de hacer que los clientes esperen en el sistema de colas. Si se proporciona demasiada capacidad de servicio se ocasionan costos excesivos. Si se proporciona una cantidad muy limitada se producen esperas excesivas. En este contexto, la meta es encontrar un trueque adecuado entre el costo del servicio y el tamaño de la espera.

Existen dos enfoques básicos para realizar la búsqueda de este equilibrio. El primero es establecer uno o más criterios para lograr un nivel satisfactorio del servicio en términos de cuánta espera sería aceptable. Por ejemplo, un criterio posible podría ser no exceder cierto número de minutos. Otro podría ser que al menos 95% de los clientes no deben esperar más de determinado número de minutos. También se pueden utilizar criterios similares en términos del número esperado de clientes en el sistema (o la distribución de probabilidad de esta cantidad). El criterio también puede establecerse en términos del tiempo de espera o del número de clientes en la cola en lugar de en el sistema. Una vez que se ha seleccionado el criterio o los criterios, por lo general es sencillo utilizar prueba y error para encontrar el diseño menos costoso del sistema de colas que satisface todos los criterios.

El otro criterio básico para buscar la mejor compensación implica evaluar los costos asociados con las consecuencias de hacer esperar a los clientes. Por ejemplo, suponga que el sistema de colas

es un *sistema de servicio interno* (como se describió en la sección 17.3), donde los clientes son los empleados de una empresa comercial. Si se hace que éstos esperen en el sistema de colas, se ocasiona una *pérdida de productividad*, lo que provoca *pérdidas monetarias*. Esta pérdida es el **costo de espera** asociado con el sistema de líneas de espera. Al expresar este costo de espera como una función del tamaño de la espera, el problema de determinar el mejor diseño del sistema de colas se puede definir como la minimización del *costo total* esperado (costo del servicio más costo de espera) por unidad de tiempo.

A continuación se describe este último enfoque para enfrentar el problema de determinar el número óptimo de servidores que deben proporcionarse.

¿Cuántos servidores deben proporcionarse?

Para formular la función objetivo cuando la variable de decisión es el número de servidores s , sea

$E(CT)$ = costo total esperado por unidad de tiempo,

$E(CS)$ = costo de servicio esperado por unidad de tiempo,

$E(CW)$ = costo de espera por unidad de tiempo.

Entonces, el objetivo es seleccionar el número de servidores para

$$\text{Minimizar } E(CT) = E(CS) + E(CW).$$

Cuando el costo de cada uno de los servidores es el mismo, el **costo de servicio** es

$$E(CS) = C_s s,$$

donde C_s es el costo marginal de un servidor por unidad de tiempo. Para evaluar CW para cualquier valor de s , observe que $L = \lambda W$ proporciona el tamaño de la espera total en el sistema de colas por unidad de tiempo. Por lo tanto, cuando el costo de espera es proporcional al tamaño de la espera, este costo puede expresarse como

$$E(CW) = C_w L,$$

donde C_w es el costo de espera por unidad de tiempo de cada cliente en el sistema de colas. En consecuencia, después de estimar las constantes, C_s y C_w , la meta es elegir el valor de s para

$$\text{Minimizar } E(CT) = C_s s + C_w L.$$

Al elegir el modelo de colas que se ajusta al sistema de colas, el valor de L se puede obtener a partir de varios valores de s . Al aumentar s , disminuye L , al principio con rapidez y después más lentamente.


En la figura 17.13 se presenta la forma general de las curvas de $E(CS)$, $E(CW)$ y $E(CT)$ contra el número de servidores s . (Para una mejor conceptualización, se han dibujado estas curvas como continuas a pesar de que los únicos valores factibles de s son $s = 1, 2, \dots$) Al calcular $E(CT)$ para valores consecutivos de s hasta que $E(CT)$ deja de disminuir y en su lugar comienza a crecer, es evidente la forma de encontrar el número de servidores que minimiza el costo total. El siguiente ejemplo ilustra este proceso.

Ejemplo

El taller Acme Machine tiene un depósito para las herramientas que necesitan los mecánicos del taller. Los despachadores tienen en su poder las herramientas hasta que llegan los mecánicos y las solicitan. Después las recogen cuando éstos ya no las necesitan. Los supervisores han presentado quejas pues sus mecánicos pasan demasiado tiempo esperando ser atendidos en el depósito de herramientas, por lo que parece que debería haber *más* despachadores. Por otro lado, la administración ejerce presión por reducir gastos en la planta, reducción que conduciría a tener *menos* despachadores. Para resolver estas presiones conflictivas, se ha realizado un estudio de IO para determinar con exactitud cuántos despachadores debe tener el depósito de herramientas.

El depósito de herramientas constituye un sistema de colas, en el cual los despachadores son los servidores y los mecánicos los clientes. Después de recopilar algunos datos sobre los tiempos

■ **FIGURA 17.13**
Forma de las curvas de costo esperado para determinar el número de servidores que se debe proporcionar.



entre llegadas y los tiempos de servicio, el equipo de IO ha concluido que el modelo que se ajusta mejor a este sistema de colas es el $M/M/s$. Las estimaciones de la tasa media de llegada λ y la tasa media de servicio (por servidor) μ son

$$\lambda = 120 \text{ clientes por hora,}$$

$$\mu = 80 \text{ clientes por hora,}$$

por lo que el factor de utilización de los dos despachadores es

$$\rho = \frac{\lambda}{s\mu} = \frac{120}{2(80)} = 0.75.$$

El costo total para la compañía por cada despachador del depósito de herramientas es de alrededor de \$20 por hora, por lo cual $C_s = \$20$. Mientras un mecánico esté ocupado, el valor de su trabajo para la compañía promedia \$48 por hora, por lo que $C_w = \$48$. Por lo tanto, el equipo de IO necesita determinar el número de servidores (despachadores) s para

$$\text{Minimizar } E(CT) = \$20s + \$48L.$$

En el OR Courseware se proporciona una plantilla de Excel para calcular estos costos con el modelo $M/M/s$. Todo lo que debe hacerse es introducir los datos del modelo junto con el costo de servicio unitario C_s , el costo de espera unitario C_w y el número de servidores s que se desea probar. Entonces la plantilla calcula $E(CS)$, $E(CW)$ y $E(CT)$, operación que se ilustra en la figura 17.14 con $s = 3$ en este ejemplo. Cuando se introduce en forma repetida valores alternativos de s , la plantilla puede revelar cuál valor minimiza $E(CT)$ en cuestión de segundos.

En la tabla 17.5 se muestran los datos que se generarían a partir de esta plantilla al repetir estos cálculos para $s = 1, 2, 3, 4$ y 5 . Como el factor de utilización de $s = 1$ es $\rho = 1.5$, un solo despachador sería incapaz de atender a los clientes, por lo que esta opción se debe desechar. Todos los valores más grandes de s son factibles, pero $s = 3$ tiene el costo total esperado más pequeño. Aún más, $s = 3$ reduciría el costo total esperado actual de $s = 2$ en \$61 por hora. Por lo tanto, a pesar de la orden actual de la administración de reducir gastos (lo que incluye el costo de los despachadores en el depósito de herramientas), el equipo de IO recomienda que se agregue un tercer despachador. Observe que esta recomendación reduciría el factor de utilización de los despachadores de un ya modesto 0.75 hasta 0.5. Sin embargo, debido al gran aumento de la productividad de los mecánicos (que son mucho más caros que los despachadores) lograda gracias a la reducción del tiempo que pasan en espera en el depósito de herramientas, la administración adopta la recomendación.

Otros temas

En el capítulo 26 del sitio en internet de este libro se expande de manera considerable la aplicación de la teoría de colas, lo que incluye temas que no se consideraron en este capítulo.

Por ejemplo, el análisis que se muestra en la figura 17.14 y en la tabla 17.5 supone que el tiempo de espera es proporcional a la cantidad de tiempo en espera, pero algunas veces éste no es el caso. Si una compañía tiene a uno o dos de sus empleados en su sistema de colas, ello puede no ser muy serio en términos de la pérdida de productividad porque otros pueden ser capaces de manejar todo el trabajo productivo disponible. Sin embargo, si existen más empleados en el sistema de colas se puede provocar un mayor incremento de pérdida de productividad y la resultante reducción de las ganancias, por lo que el costo de espera se convierte en una función no lineal del número de empleados en el sistema. De manera similar, las consecuencias para un sistema de servicio comercial de hacer esperar a sus clientes pueden ser mínimas en el caso de esperas cortas pero mucho más serias cuando las esperas se prolongan. En este caso, el costo de la espera se convierte en una función no lineal del tiempo de espera. En la sección 26.3 se describe la formulación de las funciones de costos de espera no lineales y el cálculo posterior de $E(CW)$ con dichas funciones.

En la sección 26.4 se expone un modelo de decisión donde las variables de decisión son *tanto* el número de servidores como la tasa media de servicio de los servidores. Un tema interesante que

■ FIGURA 17.14

La plantilla de Excel en la que se usa análisis económico para seleccionar un número de servidores con el modelo $M/M/s$ se aplica aquí al ejemplo del taller de Acme Machine con $s = 3$.

	A	B	C	D	E	F	G
1	Análisis económico del ejemplo del taller Acme Machine						
2							
3			Datos			Resultados	
4		$\lambda =$	120	(tasa media de llegada)		$L =$	1.736842105
5		$\mu =$	80	(tasa media de servicio)		$L_q =$	0.236842105
6		$s =$	3	(núm. servidores)			
7						$W =$	0.014473684
8		$\Pr(W > t) =$	0.02581732			$W_q =$	0.001973684
9		si $t =$	0.05				
10						$\rho =$	0.5
11		$\text{Prob}(W_q > t) =$	0.00058707				
12		si $t =$	0.05			n	P_n
13						0	0.210526316
14		Análisis económico				1	0.315789474
15		$C_s =$	\$20.00	(costo/servidor/unidad de tiempo)		2	0.236842105
16		$C_w =$	\$48.00	(costo de espera/unidad de tiempo)		3	0.118421053
17						4	0.059210526
18		Costo de servicio	\$60.00			5	0.029605263
19		Costo de espera	\$83.37			6	0.014802632
20		Costo total	\$143.37			7	0.007401316

	B	C
18	Costo de servicio	$=C_s*s$
19	Costo de espera	$=C_w*L$
20	Costo total	$=\text{CostoDeServicio}+\text{CostoDeEspera}$

Nombre del rango	Celda
CostoDeServicio	C18
CostoDeEspera	C19
C_s*s	C15
C_w*L	C16
L	G4
s	C6
CostoTotal	C20

■ **TABLA 17.5** Cálculo de $E(CT)$ de valores alternativos de s en el ejemplo del taller Acme Machine

s	ρ	L	$E(CS) = C_s s$	$E(CW) = C_w L$	$E(CT) = E(CS) + E(CW)$
1	1.50	∞	\$20	∞	∞
2	0.75	3.43	\$40	\$164.57	\$204.57
3	0.50	1.74	\$60	\$83.37	\$143.37
4	0.375	1.54	\$80	\$74.15	\$154.15
5	0.30	1.51	\$100	\$72.41	\$172.41

surge aquí es si es mejor tener *un servidor rápido* (varias personas que trabajan juntas para servir a cada cliente con rapidez) o *varios servidores lentos* (varias personas que trabajan por separado para servir a diferentes clientes).

También en la sección 26.4 se presenta un modelo de decisión donde las variables de decisión son el número de instalaciones de servicio y el número de servidores por instalación para dar servicio a una población de clientes potenciales. Dada la tasa media de llegada de toda la población, el aumento del número de instalaciones permite la disminución de la tasa media de llegada (carga de trabajo) a cada una de ellas. El número de instalaciones de servicio también afecta cuánto tiempo necesitará cada cliente para trasladarse desde y hacia la instalación más cercana. En este caso, el costo de espera debe ser una función del tiempo total perdido por un cliente mientras espera en una instalación de servicio o se traslada desde y hacia una de ellas. Es por esto que en la sección 26.5 se presentan algunos modelos de tiempo de traslado para determinar el tiempo de viaje esperado de cada cliente.

■ 17.11 CONCLUSIONES

Los sistemas de colas son muy comunes en la sociedad. La adecuación de estos sistemas puede tener un efecto importante sobre la calidad de vida y la productividad.

Para estudiar estos sistemas, la teoría de colas formula modelos matemáticos que representan su operación y luego los utiliza para obtener medidas de desempeño. Este análisis proporciona información vital para diseñar, de manera eficiente, sistemas que logren un balance apropiado entre el costo de prestar el servicio y el asociado con la espera por ese servicio.

En este capítulo se describieron los modelos básicos de teoría de colas de los que se obtienen resultados muy útiles. Se considerarían muchos otros modelos interesantes si el espacio lo permitiera. En realidad, han aparecido en la literatura técnica varios miles de artículos de investigación que formulan y/o analizan modelos de colas, y cada año se publican más.

La *distribución exponencial* tiene un papel fundamental en la teoría de colas para representar la distribución de los tiempos entre llegadas y de servicio, puesto que este supuesto permite representar un sistema de colas como una *cadena de Markov de tiempo continuo*. Por la misma razón, son de gran utilidad las *distribuciones tipo fase* como la *distribución de Erlang*, donde se desglosa el tiempo total en fases individuales que tienen distribuciones exponenciales. Con algunos supuestos adicionales se han obtenido importantes resultados analíticos sólo para un pequeño número de modelos de colas.

Los modelos de disciplina de prioridades son útiles para la situación común en la que se da prioridad a algunas categorías de clientes sobre otras para recibir el servicio.

En otra situación común los clientes deben recibir servicio en distintas estaciones o instalaciones. Los modelos de redes de colas se usan cada vez más en estas situaciones. Ésta es un área especialmente activa en la investigación actual.

Cuando no se dispone de un modelo manejable que proporcione una representación razonable del sistema bajo estudio, un enfoque usual es obtener los datos de desempeño pertinentes mediante el desarrollo de un programa de computadora para simular la operación del sistema. Esta técnica se presenta en el capítulo 20.

En la sección 17.10 se describe brevemente cómo se puede usar la teoría de colas para ayudar a planear en forma adecuada los sistemas de colas y después, en el capítulo 26 (en el sitio en internet de este libro), se hace un estudio más a fondo acerca de este tema.

■ REFERENCIAS SELECCIONADAS

1. Asmussen, S.: *Applied Probability and Queues*, 2a. ed., Springer, Nueva York, 2003.
2. Balsamo, S., V. de Nitto Personé y R. Onvural: *Analysis of Queueing Networks with Blocking*, Kluwer Academic Publishers (actualmente Springer), Boston, 2001.
3. Chen, H. y D. D. Yao: *Fundamentals of Queueing Networks: Performance, Asymptotics, and Optimization*, Springer, Nueva York, 2001.
4. El-Taha, M. y S. Stidham, Jr.: *Sample-Path Analysis of Queueing Systems*, Kluwer Academic Publishers (actualmente Springer), Boston, 1998.
5. Gross, D. y C. M. Harris: *Fundamentals of Queueing Theory*, 3a. ed., Wiley, Nueva York, 1998.
6. Hall, R. W. (ed): *Patient Flow: Reducing Delay in Healthcare Delivery*, Springer, Nueva York, 2006.
7. Hall, R. W.: *Queueing Methods: For Services and Manufacturing*, Prentice Hall, Upper Saddle River, NJ, 1991.
8. Hassin, R. y M. Haviv: *To Queue or Not to Queue; Equilibrium Behavior in Queueing Systems*, Kluwer Academic Publishers (actualmente Springer), Boston, 2008.
9. Hillier, F. S. y M. S. Hillier: *Introduction to Management Science: A Modeling and Case Studies Approach with Spreadsheets*, 3a. ed., McGraw-Hill/Irwin, Burr Ridge, IL, 2008, capítulo 11.
10. Papadopoulos, H. T., C. Heavy y J. Browne: *Queueing Theory in Manufacturing Systems Analysis and Design*, Chapman Hall, Londres, 1993.
11. Prabhu, N. U.: *Foundations of Queueing Theory*, Kluwer Academic Publishers, Boston, 1997.
12. Serfozo, R.: *Introduction to Stochastic Networks*, Springer, Nueva York, 1999.
13. Stidham, S., Jr.: "Analysis, Design, and Control of Queueing Systems", en *Operations Research*, **50**: 197-216, 2002.
14. Tian, N. y Z. G. Zhang: *Vacation Queueing Models: Theory and Applications*, Springer, Nueva York, 2006.

Algunas aplicaciones de la teoría de colas que han ganado premios

(En el sitio en internet de este libro, www.mhhe.com/hillier, se proporciona una liga hacia estos artículos.)

- A1. Bleuel, W. H.: "Management Science's Impact on Service Strategy" en *Interfaces*, **5**(1, Parte 2): 4-12, noviembre de 1975.
- A2. Brigandi, A. J., D. R. Dargon, M. J. Sheehan y T. Spencer III: "AT&T's Call Processing Simulator (CAPS) Operational Design for Inbound Call Centers", en *Interfaces*, **24**(1): 6-28, enero-febrero de 1994.
- A3. Burman, M., S. B. Gershwin y C. Suyematsu: "Hewlett-Packard Uses Operations Research to Improve the Design of a Printer Production Line", en *Interfaces*, **28**(1): 24-36, enero-febrero de 1998.
- A4. Quinn, P., B. Andrews y H. Parsons: "Allocating Telecommunications Resources at L. L. Bean, Inc.", en *Interfaces*, **21**(1): 75-91, enero-febrero de 1991.
- A5. Ramaswami, V., D. Poole, S. Ahn, S. Byers y A. Kaplan: "Ensuring Access to Emergency Services in the Presence of Long Internet Dial-Up Calls", en *Interfaces*, **35**(5): 411-422, septiembre-octubre de 2005.
- A6. Samuelson, D. A.: "Predictive Dialing for Outband Telephone Call Centers", en *Interfaces*, **29**(5): 66-81, septiembre-octubre de 1999.
- A7. Swersy, A. J., L. Goldring y E. D. Geyer, Sr.: "Improving Fire Department Productivity: Merging Fire and Emergency Medical Units in New Haven", en *Interfaces*, **23**(1): 109-129, enero-febrero de 1993.
- A8. Vandaele, N. J., M. R. Lambrecht, N. De Schuyter y R. Cremmery: "Spicer Off-Highway Products Division-Brugge Improves Its Lead-Time and Scheduling Performance", en *Interfaces*, **30**(1): 83-95, enero-febrero de 2000.

■ AYUDAS DE APRENDIZAJE PARA ESTE CAPÍTULO EN EL SITIO EN INTERNET DE ESTE LIBRO (www.mhhe.com/hillier)

Ejemplos resueltos:

Ejemplos del capítulo 17

Ejemplos de demostración en el IOR Tutor:

Red de Jackson

Archivos de Excel “Ch. 17—Queueing Theory”:

Plantilla para el modelo $M/M/s$

Plantilla para la variación de cola finita del modelo $M/M/s$

Plantilla para la variación de población finita del modelo $M/M/s$

Plantilla para el modelo $M/G/1$

Plantilla para el modelo $M/D/1$

Plantilla para el modelo $M/E_k/1$

Plantilla para el modelo de prioridades sin interrupción

Plantilla para el modelo de prioridades con interrupción

Plantilla para el análisis económico del número de servidores $M/M/s$

Archivo de LINGO para ejemplos seleccionados “Ch. 17—Queueing Theory”

Glosario del capítulo 17

Vea el apéndice 1 para la documentación del software.

■ PROBLEMAS²⁰

A la izquierda de los siguientes problemas (o de sus partes) una T indica que el uso de una de las plantillas que se mencionan puede ser útil. Un asterisco en el número del problema indica que al final del libro se proporciona al menos una respuesta parcial.

17.2-1.* Considere una peluquería común. Demuestre que es un sistema de colas mediante la descripción de sus componentes.

17.2-2.* Newell y Jeff son dos peluqueros que operan de manera independiente. Tienen dos sillas para clientes que esperan su corte, porque el número de clientes en el sistema varía entre 0 y 4. Para $n = 1, 2, 3, 4$, la probabilidad P_n de que haya exactamente n clientes en el sistema es $P_0 = \frac{1}{16}$, $P_1 = \frac{4}{16}$, $P_2 = \frac{6}{16}$, $P_3 = \frac{4}{16}$, $P_4 = \frac{1}{16}$.

- Calcule L . ¿Cómo describiría el significado de L a Newell y Jeff?
- En el caso de cada valor posible del número de clientes en el sistema, especifique cuántos clientes hay en la cola. Después calcule L_q . ¿Cómo describiría el significado de L_q a Newell y Jeff?
- Determine el número esperado de clientes que estarán siendo atendidos.
- Dado que llega un promedio de 4 clientes por hora y esperan el corte, determine W y W_q . Describa estas cantidades en términos que Newell y Jeff comprendan.

- Dado que Newell y Jeff son igual de rápidos para hacer sus trabajos, ¿cuál es la duración esperada de un corte?

17.2-3. La tienda de alimentos Mom-and-Pop's tiene un estacionamiento pequeño con tres espacios reservados para los clientes. Si la tienda está abierta los autos llegan y usan un espacio con una tasa media de 2 por hora. Para $n = 0, 1, 2, 3$, la probabilidad P_n de que haya exactamente n espacios ocupados es $P_0 = 0.1$, $P_1 = 0.2$, $P_2 = 0.4$, $P_3 = 0.3$.

- Describa la interpretación de este estacionamiento como un sistema de colas. En particular, identifique los clientes y los servidores. ¿Cuál es el servicio que se proporciona? ¿Qué constituye el tiempo de servicio? ¿Cuál es la capacidad de la cola?
- Determine las medidas de desempeño básicas: L , L_q , W y W_q de este sistema de colas.
- Use los resultados de b) para determinar el tiempo promedio que un auto permanece en el espacio.

17.2-4. Diga si cada afirmación sobre la cola de un sistema de líneas de espera es falsa o verdadera y justifique su respuesta con referencias específicas al capítulo.

- La cola es donde los consumidores esperan en el sistema hasta que termina su servicio.
- Los modelos de colas suponen por convención que la cola puede tener sólo un número limitado de clientes.
- La disciplina de la cola más común es primero en llegar, primero en salir.

²⁰ Vea también al final del capítulo 26 (en el sitio en internet de este libro) problemas que implican la aplicación de teoría de colas.

17.2-5. El Midtown Bank siempre tiene dos cajeras en servicio. Los clientes llegan a las cajas a una tasa media de 40 por hora. Una cajera requiere en promedio 2 minutos para servir a un cliente. Cuando ambas cajeras están ocupadas, el cliente que llega se une a una cola y espera a que lo atiendan. Por experiencia se sabe que los clientes esperan en la cola un promedio de 1 minuto antes de pasar a la caja.

- Describa por qué éste es un sistema de líneas de espera.
- Determine las medidas de desempeño básicas: W_q , W , L y L_q de este sistema. (*Sugerencia:* No se conocen las distribuciones de probabilidad de los tiempos entre llegadas y los tiempos entre servicio de este sistema de colas, por lo que será necesario usar las relaciones entre estas medidas de desempeño para ayudarlo a responder la pregunta.)

17.2-6. Explique por qué el factor de utilización ρ del único servidor del sistema debe ser igual a $1 - P_0$, donde P_0 es la probabilidad de tener 0 clientes en el sistema.

17.2-7. Se tienen dos sistemas de colas, Q_1 y Q_2 . La tasa media de llegadas de los clientes, la tasa media de servicio por servidor ocupado y el número esperado de clientes en el estado estable de Q_2 duplican los valores correspondientes de Q_1 . Sea W_i = el tiempo esperado de espera en el sistema en estado estable de Q_i , para $i = 1, 2$. Determine W_2/W_1 .

17.2-8. Considere un sistema de colas con un servidor que tiene *cualquier* distribución de tiempos de servicio y *cualquier* distribución de tiempos entre llegadas (el modelo $GI/G/1$). Use sólo las definiciones básicas y las relaciones de la sección 17.2 para verificar las siguientes relaciones generales:

- $L = L_q + (1 - P_0)$.
- $L = L_q + \rho$.
- $P_0 = 1 - \rho$.

17.2-9. Demuestre que

$$L = \sum_{n=0}^{s-1} nP_n + L_q + s \left(1 - \sum_{n=0}^{s-1} P_n \right)$$

Use las definiciones estadísticas de L y L_q en términos de P_n .

17.3-1. Identifique los clientes y los servidores del sistema de colas en cada una de las situaciones siguientes.

- La caja de salida de un supermercado.
- Una estación de bomberos.
- La caseta de pago para cruzar un puente.
- Un taller de reparación de bicicletas.
- Un muelle de carga y descarga.
- Un grupo de máquinas semiautomáticas asignadas a un operador.
- El equipo de manejo de materiales de una fábrica.
- Un taller de plomería.
- Un taller que produce artículos sobre pedido.
- Un grupo de secretarías.

17.4-1. Suponga que un sistema de colas tiene dos servidores, distribución de tiempos entre llegadas exponencial con media de 2 horas y distribución de tiempos de servicio exponencial con media de 2 horas para cada servidor. Lo que es más, a las 12:00 del día acaba de llegar un cliente.

- ¿Cuál es la probabilidad de que la siguiente llegada ocurra *i*) antes de la 1:00 p.m., *ii*) entre la 1:00 y las 2:00 p.m., *iii*) después de las 2:00 p.m.?

b) Suponga que no llegan más clientes antes de la 1:00 p.m. Ahora, ¿cuál es la probabilidad de que la siguiente llegada tenga lugar entre la 1:00 y las 2:00 p.m.?

c) ¿Cuál es la probabilidad de que el número de llegadas entre la 1:00 y las 2:00 p.m. sea *i*) 0, *ii*) 1 y *iii*) 2 o más?

d) Si ambos servidores están ocupados a la 1:00 p.m., ¿cuál es la probabilidad de que *ningún* cliente haya completado su servicio *i*) antes de las 2:00 p.m., *ii*) antes de la 1:10 p.m., *iii*) antes de la 1:01 p.m.?

17.4-2.* Los trabajos que deben realizarse en una máquina específica llegan de acuerdo con un proceso de entradas de *Poisson* con tasa media de 2 por hora. Suponga que la máquina se descompone y su reparación tardará 1 hora. ¿Cuál es la probabilidad de que el número de trabajos que lleguen durante este tiempo sea *a*) 0, *b*) 2, *c*) 5 o más?

17.4-3. El tiempo que requiere un mecánico para reparar una máquina tiene una distribución exponencial con media de 4 horas. Sin embargo, una herramienta especial reduciría esta media a 2 horas. Si el mecánico repara una máquina en menos de 2 horas, se le pagan \$100; de otra manera se le pagan \$80. Determine el aumento esperado en el pago del mecánico si usa esta herramienta especial.

17.4-4. Un sistema de colas de tres servidores tiene un proceso de llegadas controlado que proporciona clientes a tiempo para mantener siempre ocupados a los servidores. Los tiempos de servicio tienen una distribución exponencial con media de 0.5.

Se observa el arranque del sistema con los tres servidores que inician el servicio en el tiempo $t = 0$. La primera terminación ocurre en $t = 1$. Dada esta información, determine el tiempo esperado después de $t = 1$ hasta que ocurre la siguiente terminación de servicio.

17.4-5. Un sistema de colas tiene tres servidores con tiempos de servicio esperados de 30, 20 y 15 minutos. Los tiempos de servicio tienen una distribución exponencial. Cada servidor ha estado ocupado con el cliente actual durante 10 minutos. Determine el tiempo esperado que falta para la siguiente terminación de un servicio.

17.4-6. Considere un sistema de colas con dos tipos de clientes. Los clientes tipo 1 llegan de acuerdo con un proceso de *Poisson* a una tasa media de 5 por hora. Los clientes tipo 2 también llegan con un proceso de *Poisson* a una tasa media de 5 por hora. El sistema tiene dos servidores, que atienden a ambos tipos de clientes. Para los dos tipos el tiempo de servicio tiene una distribución exponencial con media de 10 minutos. El servicio es tipo primero en entrar, primero en salir.

- ¿Cuál es la distribución de probabilidad (y su media) del tiempo entre llegadas consecutivas de clientes de cualquier tipo?
- Cuando llega un cliente tipo 2, encuentra dos clientes tipo 1 en el proceso de ser servidos y ningún otro cliente en el sistema. ¿Cuál es la distribución de probabilidad (y su media) del tiempo de espera de este cliente tipo 2 en la cola?

17.4-7. Considere un sistema de colas con dos servidores donde todos los tiempos de servicio son independientes e idénticamente distribuidos según una distribución exponencial con media de 10 minutos. Cuando llega un cliente, encuentra que los dos servidores están ocupados y que no hay nadie en espera en la cola.

- ¿Cuál es la distribución de probabilidad (con su media y desviación estándar) del tiempo de espera de este cliente en la cola?
- Determine el valor esperado y la desviación estándar del tiempo de espera de este cliente en el sistema.

- c) Suponga que el cliente espera en la cola 5 minutos después de su llegada. Dada esta información, ¿de qué manera cambia el valor esperado y la desviación estándar del tiempo de espera en el sistema a partir de las respuestas que obtuvo en el inciso b)?

17.4-8. Diga si cada una de las siguientes afirmaciones de los tiempos de servicio con distribución exponencial es falsa o verdadera y justifique su respuesta con referencia al texto específico (cite la página) en el capítulo.

- El valor esperado y la varianza de los tiempos de servicio son siempre iguales.
- La distribución exponencial es una buena aproximación de la distribución de los tiempos de servicio cuando cada cliente requiere las mismas operaciones.
- En una instalación de s servidores, $s > 1$, con exactamente s clientes en el sistema, una nueva llegada tendrá un tiempo de espera exponencial antes de entrar a servicio de $1/\mu$ unidades de tiempo, donde μ es la media de la tasa de servicio de cada servidor ocupado.

17.4-9. En el caso de la propiedad 3 de la distribución exponencial, sean $T_1, T_2, \dots, T_n$ variables aleatorias exponenciales independientes con parámetros $\alpha_1, \alpha_2, \dots, \alpha_n$ y sea $U = \min\{T_1, T_2, \dots, T_n\}$. Demuestre que la probabilidad de que cierta variable T_j sea la menor de las n variables es

$$P\{T_j = U\} = \alpha_j / \sum_{i=1}^n \alpha_i \quad \text{para } j = 1, 2, \dots, n.$$

(Sugerencia: $P\{T_j = U\} = \int_0^\infty P\{T_i > T_j \text{ para toda } i \neq j | T_j = t\} \alpha_j e^{-\alpha_j t} dt$.)

17.5-1. Considere el proceso de nacimiento y muerte con todas las $\mu_n = 2$ ($n = 1, 2, \dots$), $\lambda_0 = 3$, $\lambda_1 = 2$, $\lambda_2 = 1$ y $\lambda_n = 0$ para $n = 3, 4, \dots$

- Construya el diagrama de tasas.
- Calcule P_0, P_1, P_2, P_3 y P_n para $n = 4, 5, \dots$
- Calcule L, L_q, W y W_q .

17.5-2. Considere el proceso de nacimiento y muerte con tres estados posibles (0, 1 y 2), cuyas probabilidades respectivas de estado estable son P_0, P_1 y P_2 . Las tasas de nacimiento y muerte se resumen en la siguiente tabla:

Estado	Tasa de nacimiento	Tasa de muerte
0	4	—
1	2	4
2	0	6

- Construya el diagrama de tasas de este proceso de nacimiento y muerte.
- Desarrolle las ecuaciones de balance.
- Resuelva estas ecuaciones para encontrar P_0, P_1 y P_2 .
- Use las fórmulas generales del proceso de nacimiento y muerte para calcular P_0, P_1 y P_2 . También calcule L, L_q, W y W_q .

17.5-3. Considere el proceso de nacimiento y muerte con las siguientes tasas medias. Las tasas de nacimiento son $\lambda_0 = 2$, $\lambda_1 = 3$, $\lambda_2 = 2$, $\lambda_3 = 1$ y $\lambda_n = 0$ para $n > 3$. Las tasas de muerte son $\mu_1 = 3$, $\mu_2 = 4$, $\mu_3 = 1$ y $\mu_n = 2$ para $n > 4$.

- Construya el diagrama de tasas de este proceso.
- Desarrolle las ecuaciones de balance.
- Resuelva estas ecuaciones para encontrar la distribución de probabilidad de estado estable $P_0, P_1, \dots$
- Utilice las fórmulas generales del proceso de nacimiento y muerte para calcular $P_0, P_1, \dots$. También calcule L, L_q, W y W_q .

17.5-4. Considere el proceso de nacimiento y muerte con todas las $\lambda_n = 2$ ($n = 0, 1, \dots$), $\mu_1 = 2$ y $\mu_n = 4$ para $n = 2, 3, \dots$

- Construya el diagrama de tasas.
- Calcule P_0 y P_1 . Después dé una expresión general de P_n en términos de P_0 para $n = 2, 3, \dots$
- Considere un sistema de colas de dos servidores que se ajusta a este proceso, ¿cuál es la tasa media de llegadas y la tasa media de servicio por servidor que está ocupado?

17.5-5.* Una gasolinera cuenta con una bomba de gasolina. Los automóviles que desean cargar llegan según un proceso de Poisson a una tasa media de 15 por hora. Sin embargo, si la bomba está en operación, los clientes potenciales pueden *desistir* (ir a otra gasolinera). En particular, si hay n autos en ella, la probabilidad de que un cliente potencial que llega desista es $n/3$ para $n = 1, 2, 3$. El tiempo necesario para servir un auto tiene distribución exponencial con media de 4 minutos.

- Construya el diagrama de tasas del sistema de colas.
- Desarrolle las ecuaciones de balance.
- Resuelva estas ecuaciones para encontrar la distribución de probabilidad de estado estable del número de autos en la gasolinera. Verifique que la solución sea la misma que la solución general del proceso de nacimiento y muerte.
- Encuentre el tiempo de espera esperado (incluido el servicio) de los automóviles que se quedan.

17.5-6. Un trabajador debe mantener dos máquinas en condiciones de operación. El tiempo que trabaja una máquina antes de descomponerse tiene distribución exponencial con media de 10 horas. El tiempo que tarda el empleado para reparar la máquina tiene distribución exponencial con media de 8 horas.

- Demuestre que este proceso se ajusta al proceso de nacimiento y muerte mediante la definición de los estados, los valores de $\lambda_n = 2$ y μ_n , y la construcción del diagrama de tasas.
- Calcule las P_n .
- Calcule L, L_q, W y W_q .
- Determine el porcentaje de tiempo que el trabajador de mantenimiento está ocupado.
- Determine el porcentaje de tiempo que trabaja cada una de las máquinas.
- Consulte el ejemplo casi idéntico de *cadenas de Markov de tiempo continuo* de la sección 16.8. Describa la relación entre la cadena de Markov de tiempo continuo y el proceso de nacimiento y muerte que permite aplicar cualquiera de los dos al mismo problema.

17.5-7. Considere un sistema de colas de un servidor donde los tiempos entre llegadas tienen una distribución exponencial con parámetro λ y los tiempos de servicio tienen una distribución exponencial con parámetro μ . Además, los clientes *desisten* (dejan el sistema de colas sin pasar a servicio) si su tiempo de espera en la cola es demasiado largo. En particular, suponga que el tiempo que cada cliente está dispuesto a esperar en la cola antes de desistir tiene una distribución exponencial con media de $1/\theta$.

- a) Construya el diagrama de tasas de este sistema.
- b) Desarrolle las ecuaciones de balance.

17.5-8* Un supermercado pequeño tiene una sola caja con un cajero de tiempo completo. Los clientes llegan a la caja de manera “aleatoria” (proceso de entradas de Poisson) con tasa media de 30 por hora. Cuando sólo hay un cliente en la caja, el cajero lo atiende solo, con un tiempo de servicio esperado de 1.5 min, pero el muchacho que ayuda tiene instrucciones fijas de que si hay más de un cliente en la caja ayude al cajero a empacar la mercancía. Esta ayuda reduce el tiempo esperado de servicio a 1 min. En ambos casos, la distribución de estos tiempos de servicio es exponencial.

- a) Construya el diagrama de tasas de este sistema.
- b) Obtenga la distribución de probabilidad de estado estable del número de clientes en la caja.
- c) Obtenga L de este sistema. (*Sugerencia:* Consulte el desarrollo de L del modelo $M/M/1$ al principio de la sección 17.6.) Utilice esta información para determinar L_q , W y W_q .

17.5-9. Un departamento de una empresa tiene una operadora de procesador de textos. Los documentos que se producen en él se entregan para ser procesados de acuerdo con un proceso de Poisson con un tiempo esperado entre llegadas de 30 min. Cuando la operadora tiene sólo un documento que procesar el tiempo esperado de servicio es de 20 minutos. Cuando hay más de un documento, la ayuda de edición reduce este tiempo a 15 min. En ambos casos, los tiempos de servicio tienen distribución exponencial.

- a) Construya el diagrama de tasas de este sistema.
- b) Encuentre la distribución de estado estable del número de documentos que la operadora ya recibió pero todavía no procesa.
- c) Desarrolle L de este sistema. (*Sugerencia:* consulte el desarrollo de L del modelo $M/M/1$ de la sección 17.6.) Use esta información para determinar L_q , W y W_q .

17.5-10. Los clientes llegan a un sistema de colas de acuerdo con un proceso Poisson con tasa media de llegadas de 2 clientes por minuto. Los tiempos de servicio tienen distribución exponencial con media de 1 minuto. Existe un número ilimitado de servidores por lo que los clientes nunca esperan que comience su servicio. Calcule las probabilidades de estado estable de que haya justo un cliente en el sistema.

17.5-11. Suponga que un sistema de colas de un servidor cumple todos los supuestos del proceso de nacimiento y muerte *excepto* que los clientes siempre llegan en *pares*. La tasa media de llegadas es de 2 pares por hora (4 clientes por hora) y la tasa media de servicio (cuando el servidor está ocupado) es de 5 clientes por hora.

- a) Construya el diagrama de tasas de este sistema.
- b) Desarrolle las ecuaciones de balance.
- c) Con propósitos de comparación, dibuje el diagrama de tasas del sistema correspondiente que se ajusta por completo al proceso de nacimiento y muerte, es decir, los clientes llegan *individualmente* a una tasa media de 4 horas.

17.5-12. Considere un sistema de líneas de espera de un solo servidor con cola finita que puede manejar un máximo de 2 clientes *excluyendo* los que están en servicio. El servidor puede proporcionar *servicio en grupo* a 2 clientes a la vez; el tiempo de servicio tiene distribución exponencial con media de 1 unidad de tiempo independiente del número que se atiende. Cuando la cola no está llena, los clientes llegan en forma individual según un proceso de Poisson con tasa media de 1 por unidad de tiempo.

- a) Suponga que el servidor *debe* servir a 2 clientes al mismo tiempo. Por lo tanto, aunque el servidor esté desocupado cuando hay sólo 1 cliente en el sistema, debe esperar a que llegue otro antes de comenzar el servicio. Formule el modelo de colas como una cadena de Markov de tiempo continuo, defina los estados y construya el diagrama de tasas. Elabore las ecuaciones de balance; no las resuelva.
- b) Ahora suponga que el tamaño del grupo es 2 sólo si hay 2 clientes en el sistema al terminar el servicio anterior. Por ello, si el servidor está libre cuando hay nada más 1 cliente, deberá atenderlo y cualquiera que llegue después deberá esperar en la cola hasta que el servidor termine con este cliente. Formule el modelo de colas que resulta como cadena de Markov de tiempo continuo; defina los estados y construya el diagrama de tasas. Construya las ecuaciones de balance, pero no las resuelva.

17.5-13. Considere un sistema de colas con dos clases de clientes, dos servidores para atenderlos y *sin cola*. Los clientes potenciales de cada clase llegan según un proceso Poisson con tasa media de 10 clientes por hora de la clase 1 y 5 clientes por hora de la clase 2, pero estos clientes se pierden si no pueden entrar a servicio de inmediato.

Cada cliente de la clase 1 que entra al sistema recibirá servicio de cualquiera de los servidores que esté desocupado; los tiempos de servicio tienen distribución exponencial con tasa media de 5 minutos.

Cada cliente de la clase 2 que entra al sistema requiere la *atención simultánea de los dos servidores* (los dos trabajan juntos como un servidor); los tiempos de servicio tienen distribución exponencial con media de 5 minutos. En consecuencia, un cliente de este tipo se pierde a menos que ambos servidores estén libres para servirlos de inmediato.

- a) Formule el modelo como una cadena de Markov de tiempo continuo; defina los estados y el diagrama de tasas.
- b) Describa cómo puede ajustarse la formulación del inciso a) al proceso de nacimiento y muerte.
- c) Use los resultados del proceso de nacimiento y muerte para calcular la distribución conjunta de estado estable del número de clientes de cada clase en el sistema.
- d) Para cada clase de clientes, ¿cuál es la fracción esperada de llegadas que no pueden entrar al sistema?

17.6-1. Lea el artículo de referencia que describe el estudio de IO que se resume en la Viñeta de aplicación que se presentó en la sección 17.6. Describa de manera breve la forma en que se aplicó la teoría de colas a este estudio. Después, elabore una lista de los beneficios financieros y no financieros que arrojó dicho estudio.

17.6-2.* La compañía 4M tiene un torno como pieza central del trabajo de la planta. Los trabajos llegan según un proceso Poisson con tasa media de 2 por día. El tiempo de procesamiento de cada trabajo tiene distribución exponencial con media de $\frac{1}{4}$ día. Como los trabajos son grandes, si no están en proceso se guardan en un almacén a cierta distancia de la máquina. Sin embargo, para ahorrar tiempo al traerlos, el gerente de producción propone agregar espacio para 3 trabajos en proceso además del que está en el torno (el resto seguirá almacenándose). Con esta propuesta, ¿qué proporción de tiempo será adecuado el espacio junto al torno para los trabajos en espera?

- a) Calcule su respuesta con las fórmulas disponibles.
- T b)** Use la plantilla de Excel para obtener las probabilidades necesarias para responder a la pregunta.

17.6-3. Los clientes llegan a un sistema de colas de un servidor según un proceso de Poisson con tasa media de 30 por hora. Si el servidor trabaja en forma continua, el número de clientes que puede atender en una hora tiene distribución de Poisson con media de 50. Determine la proporción del tiempo durante el cual nadie espera servicio.

17.6-4. Considere el modelo $M/M/1$ con $\lambda < \mu$.

- Determine la probabilidad de estado estable de que el tiempo real que espera un cliente sea mayor que el tiempo esperado de espera, es decir, $P\{W > W_q\}$.
- Determine la probabilidad de estado estable de que el tiempo real de espera en la cola sea mayor que el tiempo esperado de espera en la cola, esto es, $P\{W_q > W_q\}$.

17.6-5. Verifique las siguientes relaciones de un sistema de colas $M/M/1$:

$$\lambda = \frac{(1 - P_0)^2}{W_q P_0}, \quad \mu = \frac{1 - P_0}{W_q P_0}.$$

17.6-6. Es necesario determinar cuánto espacio de almacén para material en proceso conviene asignar a un centro de trabajo en una nueva fábrica. Los trabajos llegan de acuerdo con un proceso de Poisson con tasa media de 4 por hora, y el tiempo que se requiere para realizar el proceso necesario tiene distribución exponencial con media de 0.2 horas. Cuando los trabajos que esperan requieren más espacio de almacén que el asignado, el exceso se concentra en un depósito temporal en un lugar menos conveniente. Si cada trabajo requiere un pie cuadrado de suelo en el almacén del centro de trabajo, ¿cuánto espacio se debe proporcionar para acomodar todos los trabajos a) 50%, b) 90%, c) 99% del tiempo? Deduzca una expresión analítica para responder a estas tres preguntas. *Sugerencia:* La suma de una serie geométrica es

$$\sum_{n=0}^N x^n = \frac{1 - x^{N+1}}{1 - x}.$$

17.6-7. Considere las siguientes afirmaciones sobre un sistema de colas $M/M/1$ y su factor de utilización ρ . Diga si cada una es falsa o verdadera y justifique su respuesta.

- La probabilidad de que un cliente tenga que esperar antes de ser servido es proporcional a ρ .
- El número esperado de clientes en el sistema es proporcional a ρ .
- Si ρ se incrementa de $\rho = 0.9$ a $\rho = 0.99$, el efecto de cualquier otro incremento de ρ sobre L , L_q , W y W_q será relativamente pequeño siempre que $\rho < 1$.

17.6-8. Los clientes llegan a un sistema de colas según un proceso de Poisson con tiempo esperado entre llegadas de 25 minutos. Los tiempos de servicio tienen distribución exponencial con media de 30 minutos.

Diga si cada una de las siguientes afirmaciones sobre el sistema es falsa o verdadera y justifique su respuesta.

- El servidor definitivamente estará ocupado siempre después de la llegada del primer cliente.
- La cola crecerá sin límite.
- Si se agrega un segundo servidor con la misma distribución de servicio, el sistema puede alcanzar una condición de estado estable.

17.6-9. Diga si cada una de las siguientes afirmaciones sobre un sistema de colas $M/M/1$ es falsa o verdadera y justifique su respuesta;

para ello haga referencia a afirmaciones específicas (cite las páginas) en el capítulo.

- El tiempo de espera en el sistema tiene distribución exponencial.
- El tiempo de espera en la cola tiene distribución exponencial.
- El tiempo de espera condicional en el sistema, dado el número de clientes que hay, tiene distribución de Erlang (gamma).

17.6-10. La tienda de abarrotes Friendly Neighbor tiene una caja de salida con un cajero de tiempo completo. Los clientes llegan al azar con una tasa media de 20 por hora. La distribución del tiempo de servicio es exponencial con media de 2 minutos. En ocasiones, esta situación causa una cola larga y quejas de los clientes. Como no hay lugar para otra caja, el gerente piensa en contratar a otra persona que ayude a empacar los víveres y reduzca el tiempo esperado de servicio a 1.5 minutos, todavía con distribución exponencial.

El gerente quiere que el porcentaje de tiempo en el que hay más de 2 clientes en la caja fuera menor a 25%. También desea que no más de 5% de los clientes tengan que esperar 5 minutos o más antes de iniciar su servicio o 7 minutos o más antes de terminarlo.

- Use las fórmulas del modelo $M/M/1$ para calcular L , L_q , W y W_q , P_0 , P_1 y P_2 de la operación actual. ¿Cuál es la probabilidad de que haya más de dos clientes en la caja?
- Use la plantilla de Excel para elaborar este modelo, y verifique sus respuestas en a). Encuentre la probabilidad de que el tiempo de espera antes de iniciar el servicio exceda de 5 minutos, y la probabilidad de que el tiempo de espera antes de terminar el servicio sea mayor a 7 minutos.
- Repita el inciso a) para la alternativa de ayuda.
- Repita el inciso b) para esta alternativa.
- ¿Qué enfoque se debe usar para satisfacer el criterio del gerente lo mejor posible?

17.6-11. El aeropuerto internacional de Centerville tiene dos pistas, una sólo para despegues y otra sólo para aterrizajes. Los aviones llegan al espacio de Centerville para pedir instrucciones de aterrizaje según un proceso de Poisson con tasa media de 10 por hora. El tiempo que se requiere para realizar un aterrizaje después de la aprobación tiene distribución exponencial con media de 3 minutos, proceso que debe estar terminado antes de aprobar otro aterrizaje. Los aviones en espera de pista vuelan en círculos.

La administración de aviación federal tiene varios criterios respecto del nivel seguro de congestión de aviones en espera para aterrizar. Estos criterios dependen de varios factores en cada aeropuerto, como el número de pistas disponibles para ello. En el caso de Centerville los criterios son 1) el número promedio de aviones en espera no debe exceder de 1, 2) 95% del tiempo, el número real de aviones en espera no debe exceder de 4, 3) para 99% de los aviones, el tiempo que vuelan en círculos antes de aterrizar no debe exceder de 30 minutos (exceder este tiempo suele requerir el envío del avión a otro aeropuerto para aterrizaje de emergencia antes de que se agote el combustible).

- Evalúe la precisión con que se cumplen estos criterios.
- Una línea aérea importante piensa incluir este aeropuerto en sus rutas, lo cual aumentaría la tasa media de llegadas a 15 aviones por hora. Evalúe con qué exactitud se cumplirían los criterios si dicha empresa comenzara a operar en Centerville.
- Para atraer más negocios [incluso la línea aérea del inciso b)], la administración del aeropuerto piensa añadir otra pista de aterrizaje. Se estima que con el tiempo esta medida aumentaría la

tasa media de llegadas a 25 aviones por hora. Evalúe con qué exactitud se cumplirían los criterios si esto ocurriera.

T 17.6-12. El Security & Trust Bank tiene 4 cajeros para atender a sus clientes, los cuales llegan según un proceso de Poisson con tasa media de 2 por minuto. Sin embargo, el negocio crece y la gerencia pronostica que esta tasa será de 3 por minuto dentro de un año. El tiempo de transacciones entre el cajero y el cliente tiene distribución exponencial con media de 1 minuto.

La gerencia ha establecido las siguientes políticas para lograr un nivel de servicio satisfactorio. El número promedio de clientes que esperan en la cola para iniciar su servicio no debe exceder de 1. Al menos 95% del tiempo, el número de clientes en la cola no debe exceder de 5. En el caso de al menos 95% de los clientes, el tiempo de espera para iniciar el servicio no debe exceder de 5 minutos.

- Use el modelo $M/M/s$ para determinar si se cumplen estas políticas.
- Evalúe si se cumplirán estas políticas dentro de un año si no cambia el número de cajeros.
- Determine cuántos cajeros se necesitarán dentro de un año para cumplir por completo las políticas.

17.6-13. Considere el modelo $M/M/s$.

- Suponga que sólo hay un servidor y que el tiempo esperado de servicio es exactamente de 1 minuto. Compare L de los casos en que la tasa media de llegadas es 0.5, 0.9 y 0.99 clientes por minuto. Haga lo mismo con L_q , W y W_q y $P\{W > 5\}$. ¿Qué puede concluir sobre el efecto del factor de utilización creciente ρ de valores pequeños (como, $\rho = 0.5$) a valores grandes (como $\rho = 0.9$) y aún más grandes cercanos a 1 (como, $\rho = 0.99$)?
- Ahora suponga que se cuenta con dos servidores y que el tiempo esperado de servicio es exactamente de 2 minutos. Siga las instrucciones del inciso a).

T 17.6-14. Considere el modelo $M/M/s$ con tasa media de llegadas de 10 clientes por hora y tiempo de servicio esperado de 5 min. Use la plantilla de Excel de este modelo para obtener e imprimir las medidas de desempeño (con $t = 10$ y $t = 0$ para las dos probabilidades de tiempo de espera) cuando el número de servidores es 1, 2, 3, 4 y 5. Entonces, para los siguientes criterios posibles de nivel satisfactorio de servicio (donde la unidad de tiempo es 1 minuto), use los resultados impresos para determinar cuántos servidores se necesitan para satisfacer los criterios.

- $L_q \leq 0.25$
- $L \leq 0.9$
- $W_q \leq 0.1$
- $W \leq 6$
- $P\{W_q > 0\} \leq 0.01$
- $P\{W > 10\} \leq 0.2$
- $\sum_{n=0}^s P_n \geq 0.95$

17.6-15. Una estación de gasolina con sólo una bomba emplea la siguiente política: si un cliente tiene que esperar, el precio es de \$3.50 por galón; si no tiene que esperar, el precio es de \$4.00 por galón. Los clientes llegan según un proceso de Poisson a una tasa media de 20 por hora. Los tiempos de servicio tienen distribución exponencial con media de 2 minutos. Los clientes que llegan siempre esperan hasta que compran la gasolina. Determine el precio esperado de la gasolina por galón.

17.6-16. Un sistema de colas $M/M/1$ tiene una tasa media de llegadas λ y tasa media de servicio μ . Un cliente recibe n dólares si cuando llega hay n clientes en el sistema. Determine el costo esperado en dólares por cliente.

17.6-17. En la sección 17.6 se obtuvieron las siguientes ecuaciones del modelo $M/M/1$:

$$(1) \quad P\{W > t\} = \sum_{n=0}^{\infty} P_n P\{S_{n+1} > t\}.$$

$$(2) \quad P\{W > t\} = e^{-\mu(1-\rho)t}.$$

Demuestre que la ecuación (1) se reduce en forma algebraica a la ecuación (2). (*Sugerencia:* Use diferenciación, álgebra e integración.)

17.6-18. En los siguientes casos, derive W_q de manera directa; desarrolle y reduzca una expresión análoga a la ecuación (1) del problema 17.6-17. (*Sugerencia:* Use el tiempo de espera esperado *condicional* en la cola dado que una llegada aleatoria encuentra n clientes en el sistema.)

- El modelo $M/M/1$
- El modelo $M/M/s$

T 17.6-19. Considere un sistema de colas $M/M/2$ con $\lambda = 3$ y $\mu = 2$. Determine la tasa media a la que ocurren las terminaciones de servicio durante los periodos en que no hay clientes en espera en la cola.

T 17.6-20. Un sistema de colas $M/M/2$ tiene $\lambda = 4$ por hora y $\mu = 6$ por hora. Determine la probabilidad de que un cliente que llega espere más de 30 minutos en la cola dado que hay al menos 2 clientes en el sistema.

17.6-21.* En la compañía de seguros Blue Chip Life, las funciones de depósito de cierto producto de inversión se asignan a un empleado y el retiro a otro. Los formularios de depósito llegan al escritorio de Clara a una tasa media de 16 por hora (proceso Poisson). Las formas de retiro llegan al escritorio de Carmen a una tasa media de 14 por hora (proceso Poisson). El tiempo que se requiere para procesar cualquier transacción tiene distribución exponencial con tasa media de 3 minutos. Para reducir el tiempo esperado de espera en el sistema de ambas formas los actuarios recomiendan: 1) capacitar a las dos empleadas para manejar depósitos y retiros y 2) poner los dos tipos de transacciones en una sola cola con acceso a ambas empleadas.

- Determine el tiempo esperado de espera en el sistema de cada tipo de llegada con el proceso actual. Combine los resultados y calcule el tiempo esperado de espera en el sistema de una llegada de cualquier tipo.
- Si se adoptan las recomendaciones, determine el tiempo esperado de espera en el sistema de las transacciones que llegan.
- Suponga que, si se adoptan las recomendaciones, el resultado sería un pequeño aumento en el tiempo esperado de proceso. Utilice la plantilla de Excel de $M/M/s$ para determinar, por prueba y error, el tiempo esperado de proceso (dentro de 0.001 horas) que haría que el tiempo esperado de espera en el sistema de una llegada aleatoria fuera en esencia el mismo de los procesos actuales y con las recomendaciones.

17.6-22. La compañía People's Software acaba de abrir un centro de asistencia técnica por teléfono para su nuevo software. Dos técnicos toman las llamadas; el tiempo que se requiere para responder a las preguntas de cada cliente tiene distribución exponencial con media

de 8 minutos. Las llamadas llegan según un proceso de Poisson con tasa media de 10 por hora.

Se espera que el año próximo la tasa media de llamadas disminuya a 5 por hora, por lo que el plan es reducir el número de técnicos a uno.

- T a)** Suponga que μ seguirá en 7.5 llamadas por hora el siguiente año, y determine L , L_q , W y W_q de ambos sistemas (actual y en un año). En el caso de cada medida de desempeño, ¿qué sistema da el menor valor?
- b)** Suponga que μ se ajustará cuando sólo haya un técnico. Obtenga por métodos algebraicos el valor de μ que da el mismo valor de W del sistema actual.
- c)** Repita el inciso **b)** con W_q en lugar de W .

17.6-23. Considere una generalización del modelo $M/M/1$ en la que el servidor necesita “entrar en calor” al principio de un periodo de trabajo y sirve al primer cliente del periodo a una tasa más lenta que a los otros. En particular, si un cliente que llega encuentra el servidor desocupado, experimenta un tiempo de servicio con distribución exponencial con parámetro μ_1 . Pero si encuentra al servidor ocupado su tiempo de servicio tendrá distribución exponencial con parámetro μ_2 , donde $\mu_1 < \mu_2$. Los clientes llegan de acuerdo con un proceso Poisson con tasa media de λ .

- a)** Formule este modelo como una cadena de Markov de tiempo continuo; defina los estados y construya el diagrama de tasas correspondiente.
- b)** Desarrolle las ecuaciones de balance.
- c)** Suponga que se especifican los valores numéricos de μ_1 , μ_2 y λ , y que $\lambda < \mu_2$ (de manera que existe una distribución de estado estable). Como este modelo tiene un número infinito de estados, la distribución de estado estable es la solución simultánea de un número infinito de ecuaciones de balance (más la ecuación de la suma de las probabilidades igual a 1). Suponga que no puede obtener una solución analítica y desea usar la computadora para resolver el modelo numérico. Considere que es imposible resolver un número infinito de ecuaciones y describa en forma breve qué se puede hacer con estas ecuaciones para obtener una aproximación de la distribución de estado estable. ¿En qué circunstancias esta aproximación será esencialmente exacta?
- d)** Dado que se ha obtenido la distribución de estado estable, dé expresiones explícitas para L , L_q , W y W_q .
- e)** Dada esta distribución de estado estable, desarrolle una expresión de $P\{W > t\}$ análoga a la ecuación (1) del problema 17.6-17.

17.6-24. Para cada modelo siguiente, escriba las ecuaciones de balance y demuestre que la solución que se dio en la sección 17.6, de la distribución de estado estable del número de clientes en el sistema, las satisface.

- a)** Modelo $M/M/1$.
- b)** Variación de cola finita de $M/M/1$, con $K = 2$.
- c)** Variación de fuente de entrada finita de $M/M/1$, con $N = 2$.

T 17.6-25. Considere un sistema telefónico con tres líneas. Las llamadas siguen un proceso de Poisson con una tasa media de 6 por hora. La duración de las llamadas tiene distribución exponencial con tasa de media de 15 minutos. Si todas las líneas están ocupadas, las llamadas se ponen en espera hasta que esté disponible una línea.

- a)** Imprima las medidas de desempeño de la plantilla de Excel de este sistema (con $t = 1$ hora y $t = 0$ de las probabilidades respectivas de tiempo de espera).

- b)** Utilice el resultado impreso de $P\{W_q > 0\}$ para identificar la probabilidad de estado estable de que una llamada sea tomada de inmediato (sin quedar en espera). Verifique esta probabilidad con los resultados de P_n .
- c)** Utilice los resultados impresos para identificar las probabilidades de estado estable del número de llamadas en espera.
- d)** Imprima las nuevas medidas de desempeño si las llamadas se pierden cuando todas las líneas están ocupadas. Con los resultados identifique la probabilidad de estado estable de que una llamada que llega se pierda.

17.6-26.* Janet planea abrir un pequeño autolavado y debe decidir cuánto espacio debe asignar a los autos que esperan. Ella estima que los clientes llegarán de manera aleatoria (proceso Poisson) a una tasa media de 1 cada 4 minutos, a menos que el área de espera esté llena, en cuyo caso los clientes que llegan llevarán su auto a otra parte. El tiempo total atribuible al lavado de un automóvil tiene distribución exponencial con media de 3 minutos. Compare la fracción de clientes potenciales que se pierden por falta de espacio de espera si se proporcionan **a)** 0, **b)** 2 y **c)** 4 espacios (además del lugar de lavado).

17.6-27. Considere la variación de cola finita del modelo $M/M/s$. Derive la expresión de L_q dada en la sección 17.6 de este modelo.

17.6-28. En el caso de la variación de cola finita del modelo $M/M/1$, desarrolle una expresión análoga a la ecuación (1) del problema 17.6-17 de las siguientes probabilidades:

- a)** $P\{W > t\}$.
- b)** $P\{W_q > t\}$.

[Sugerencia: Las llegadas ocurren sólo cuando el sistema no está lleno, por lo que la probabilidad de que una llegada aleatoria encuentre n clientes es $P_n/(1 - P_K)$.]

17.6-29. George planea abrir un negocio de revelado de fotografías que dará atención a los clientes en su automóvil, con una sola ventanilla de servicio que abrirá alrededor de 200 horas al mes en un área comercial muy activa. El espacio de un carril de espera de los automóviles de los clientes está disponible por una renta de \$200 al mes por cada lugar de automóvil. George necesita decidir cuántos lugares de automóvil debe proporcionar a sus clientes.

Si se excluye este costo de renta del carril de automóviles en espera, George cree que promediará una ganancia de \$4 por cliente servido (nada para un cliente que va a entregar su película y \$8 cuando se recogen las fotografías). También estima que los clientes llegarán a una tasa media de 20 por hora, aunque aquellos que encuentren el carril lleno se verán obligados a irse. La mitad de los clientes que encuentren el carril lleno deseará entregar su película, mientras que la otra mitad deseará recoger sus fotografías. La mitad que desea entregar la película hará dicha entrega en alguna otra parte. La otra mitad de los clientes que encuentren lleno el carril no se perderá porque tratará después hasta que pueda entrar para recoger sus fotografías. George supone que el tiempo necesario para servir a un cliente tendrá una distribución exponencial con una media de 2 minutos.

- T a)** Encuentre L y la tasa media a la cual los clientes se pierden cuando el número de lugares para automóvil es 2, 3, 4 y 5.
- b)** Calcule W a partir de L en los casos considerados en **a)**.
- c)** Utilice los resultados en **a)** para calcular la disminución de la tasa media a la que los clientes se pierden cuando el número de lugares para automóvil se incrementa de 2 a 3, de 3 a 4 y de 4 a 5. Después calcule el aumento de la ganancia esperada por hora

(sin incluir los costos de renta por el espacio para automóviles) en cada uno de estos tres casos.

- d) Compare el incremento de la ganancia esperada que se encontró en c) con el costo por hora de rentar cada lugar para automóvil. ¿Qué conclusión obtiene acerca del número de lugares para automóvil que George debe proporcionar?

17.6-30. En Forrester Manufacturing se ha asignado a un técnico el mantenimiento de tres máquinas. La distribución de probabilidad del tiempo de operación de cada máquina antes de descomponerse es exponencial con media de 9 horas. El tiempo de reparación también tiene distribución exponencial con media de 2 horas.

- a) ¿Qué modelo de colas se ajusta a este sistema?
 T b) Con este modelo encuentre la distribución de probabilidad del número de máquinas descompuestas y su media.
 c) Use la media para calcular el tiempo esperado entre la descompostura de una máquina y la terminación de su reparación.
 d) ¿Cuál es la fracción esperada de tiempo que el técnico está ocupado?
 T e) Como aproximación burda, suponga que la fuente de entrada es infinita y las entradas son de Poisson con una tasa media de 3 cada 9 horas. Compare el resultado del inciso b) con el que obtenga con esta aproximación i) con el modelo $M/M/s$ y ii) con el modelo de cola finita $M/M/s$ con $K = 3$.
 T f) Repita b) con un segundo técnico que ayuda a reparar una segunda máquina si más de una de ellas requiere reparación.

17.6-31. Reconsidere el proceso de nacimiento y muerte específico descrito en el problema 17.5-1.

- a) Identifique un modelo de colas (y el valor de sus parámetros) de la sección 17.6 que se ajuste a este proceso.
 T b) Use la plantilla de Excel correspondiente para obtener las respuestas a los incisos b) y c) del problema 17.5-1.

T 17.6-32.* La Dolomite Corporation planea una nueva fábrica. Se han asignado máquinas automáticas a un departamento. Se contratará un pequeño número (a determinar) de operarios para darles servicio ocasional (carga, descarga, ajuste, preparación, etc.), y debe decidirse cómo organizarlos. La alternativa 1 es asignar a cada operario sus máquinas. La alternativa 2 es agruparlos para que el operario desocupado dé servicio a la siguiente máquina que lo necesite. La alternativa 3 es combinarlos en una cuadrilla y que juntos atiendan cualquier máquina.

El tiempo de operación (entre la terminación de un servicio y la necesidad de atender una máquina de nuevo) de cada máquina tiene distribución exponencial con media de 150 minutos. El tiempo de servicio tiene distribución exponencial con media de 15 minutos (alternativas 1 y 2) o 15 minutos dividido entre el número de operarios (alternativa 3). Para que el departamento logre la tasa de producción que se requiere, las máquinas deben operar por lo menos 89% del tiempo en promedio.

- a) En el caso de la alternativa 1, ¿cuál es el número máximo de máquinas asignadas a un operario para lograr la tasa de producción? ¿Cuál es la utilización resultante de cada operario?
 b) En el caso de la alternativa 2, ¿cuál es el número mínimo de operarios necesario para lograr la tasa de producción? ¿Cuál es la utilización de cada operario?
 c) En el caso de la alternativa 3, ¿cuál es el tamaño mínimo de la cuadrilla necesario para lograr la tasa de producción? ¿Cuál es la utilización resultante de la cuadrilla?

17.6-33. Un taller tiene tres máquinas idénticas que presentan fallas de cierto tipo. Se cuenta con un sistema de mantenimiento para realizar las operaciones de mantenimiento (recarga) que requiere una máquina que falla. El tiempo necesario para realizar cada operación tiene distribución exponencial con media de 30 minutos. Con probabilidad de $\frac{1}{3}$, esta operación debe realizarse una segunda vez (con la misma distribución del tiempo) para dejar la máquina en un estado operativo satisfactorio. El sistema de mantenimiento trabaja sólo en una máquina que falla a la vez; además, realiza todas las operaciones (una o dos) que requiere esa máquina sobre la base de primero en entrar, primero en salir. Después de reparada, el tiempo hasta que la máquina vuelve a fallar tiene distribución exponencial con media de 3 horas.

- a) ¿Cómo deben definirse los estados del sistema para formularlo como cadena de Markov de tiempo continuo? (*Sugerencia:* Dado que se está realizando la primera operación en una máquina que falló, terminar *con éxito* esta operación y terminarla *sin éxito* son dos eventos independientes. Use la propiedad 6 para desagregar la distribución exponencial.)
 b) Construya el diagrama de tasas correspondiente.
 c) Desarrolle las ecuaciones de balance.

17.7-1.* Considere el modelo $M/G/1$.

- a) Compare el tiempo esperado de espera en la cola si la distribución del tiempo de servicio es i) exponencial, ii) constante y iii) de Erlang con la cantidad de variación (es decir, la desviación estándar) a la mitad entre los casos constante y exponencial.
 b) ¿Cuál es el efecto sobre el tiempo de espera esperado en la cola y sobre la longitud esperada de la cola si λ y μ se duplican y la escala de la distribución de tiempos de servicio se cambia de acuerdo con estos datos?

17.7-2. Considere el modelo $M/G/1$ con $\lambda = 0.2$ y $\mu = 0.25$.

- T a) Use la plantilla de Excel para este modelo (o cálculos a mano) para encontrar las medidas de desempeño L , L_q , W y W_q de los siguientes valores de σ : 4, 3, 2, 1, 0.
 b) ¿Cuál es la razón de L_q con $\sigma = 4$ entre L_q con $\sigma = 0$? ¿Qué dice esto de la importancia de reducir la variabilidad de los tiempos de servicio?
 c) Calcule la reducción en L_q cuando σ se reduce de 4 a 3, de 3 a 2, de 2 a 1 y de 1 a 0. ¿Cuál es la reducción más grande? ¿Cuál es la menor?
 d) Use prueba y error en la plantilla para aproximar cuánto debe aumentar μ con $\sigma = 4$ para lograr la misma L_q que con $\mu = 0.25$ y $\sigma = 0$.

17.7-3. Diga si las siguientes afirmaciones sobre un sistema de colas $M/G/1$, donde σ^2 es la variancia de los tiempos de servicio. Establezca si es falsa o verdadera y justifique su respuesta.

- a) Si se incrementa σ^2 (con λ y μ fijos) aumentarán L_q y L , pero W_q y W no cambiarán.
 b) Cuando se elige entre una tortuga (μ y σ^2 pequeños) y una liebre (μ y σ^2 grandes) como servidor, la tortuga siempre gana porque proporciona una L_q pequeña.
 c) Con λ y μ fijos, el valor de L_q con distribución de tiempos de servicio exponencial es el doble que cuando los tiempos de servicio son constantes.
 d) Entre las distribuciones posibles (con λ y μ fijos), la distribución exponencial da el valor más grande de L_q .

17.7-4. Marsha despacha café expreso. Los clientes siguen un proceso de Poisson con tasa media de 25 por hora. El tiempo necesario para

que Marsha sirva a un cliente tiene distribución exponencial con media de 90 segundos.

- Con el modelo $M/G/1$ encuentre L , L_q , W y W_q .
- Suponga que sustituyen a Marsha por una máquina expendedora que requiere exactamente 90 segundos de operación por cliente. Encuentre L , L_q , W y W_q .
- ¿Cuál es la razón de L_q en $b)$ entre L_q en $a)$?
- Utilice por prueba y error la plantilla de Excel del modelo $M/G/1$ para aproximar cuánto debe Marsha reducir su tiempo de servicio para lograr la misma L_q que con la máquina expendedora.

17.7-5. Antonio tiene un taller de reparación de calzado. Los pares de zapatos que llegan para reparación siguen un proceso de Poisson con tasa media de 1 par por hora. El tiempo de reparación por zapato individual tiene distribución exponencial con media de 15 minutos.

- Considere la formulación de este sistema de colas si se toma cada zapato (y no el par) como un cliente. Construya un diagrama de tasas y desarrolle las ecuaciones de balance, pero no resuelva el sistema.
- A continuación, considere la formulación de este sistema de colas cuando los pares de zapatos se consideran los clientes. Identifique el modelo específico que se ajusta a esta formulación.
- Calcule el número esperado de pares en el taller.
- Calcule el tiempo esperado desde que el cliente deja un par hasta que está reparado y listo para entregarlo.
- Use la plantilla de Excel correspondiente para verificar sus respuestas a los incisos $c)$ y $d)$.

17.7-6.* Una base de mantenimiento de Friendly Skies Airline tiene instalaciones para la reparación general de un solo motor de avión a la vez. Para poner los aviones descompuestos en operación lo más pronto posible, la política ha sido alternar la reparación general de los cuatro motores de cada avión. En otras palabras, sólo se repara un motor cada vez que un avión llega a la base. Con esta política, los aviones llegan de acuerdo con un proceso de Poisson a una tasa media de 1 al día. El tiempo que se requiere para reparar un motor (una vez iniciado el servicio) tiene una distribución exponencial con media de $\frac{1}{2}$ día.

Se ha propuesto cambiar esta política por la de reparar los cuatro motores de cada avión consecutivamente cada vez que una aeronave llegue a la base. Aunque este procedimiento cuadruplicaría el tiempo esperado de servicio, cada avión iría a la base sólo la cuarta parte de las veces.

La administración debe decidir si debe continuar con este sistema o adoptar la propuesta. El objetivo es minimizar el tiempo promedio de vuelo que la flota completa pierde por día debido a las reparaciones generales de los motores.

- Compare las dos alternativas respecto del tiempo promedio de vuelo perdido por avión cada vez que llega a la base de mantenimiento.
- Compare las dos alternativas respecto del número promedio de aviones que pierden tiempo de vuelo por estar en la base.
- ¿Cuál de estas comparaciones es la adecuada para que la administración tome la decisión? Explique su respuesta.

17.7-7. Reconsidere el problema 17.7-6. La administración adoptó la propuesta pero desea analizar el nuevo sistema de colas.

- ¿Cómo debe definirse el estado del sistema para formular el modelo como cadena de Markov?
- Construya el diagrama de tasas correspondiente.

17.7-8. En el área de producción, la compañía McAllister tiene dos depósitos de herramientas cada uno con *un* dependiente. Un depósito maneja sólo las herramientas para maquinaria pesada y el otro el resto. En cada uno de ellos, los mecánicos llegan a pedir herramientas con una tasa media de 18 por hora y el tiempo de servicio esperado es de 3 minutos.

Como los mecánicos se quejan de que al ir a los depósitos deben esperar demasiado, se propone combinarlos para que cualquier dependiente maneje cualquier tipo de herramienta que solicite. Se piensa que la tasa media de llegadas combinadas al depósito se duplicará a 36 por hora y que el tiempo esperado de servicio seguirá en 3 minutos. Sin embargo, no se conoce la *forma* de la distribución de probabilidad de los tiempos entre llegadas y de servicio, y no está claro qué modelo de colas es el más apropiado.

Compare el estado actual y la propuesta respecto del número esperado de mecánicos en el (los) depósito(s) de herramientas y del tiempo esperado de espera (con servicio) de cada mecánico. Con este fin, tabule los datos de los cuatro modelos de las figuras 17.6, 17.8, 17.10 y 17.11 (use $k = 2$ cuando se trate de una distribución de Erlang).

17.7-9.* Considere un sistema de colas de un servidor con entradas de Poisson, tiempos de servicio de Erlang y cola finita. En particular, suponga que $k = 2$, la tasa media de llegadas es de 2 clientes por hora, el tiempo de servicio esperado es de 0.25 horas y el máximo número de clientes que admite el sistema es 2. Este sistema se puede formular como cadena de Markov de tiempo continuo al dividir cada tiempo de servicio en dos etapas consecutivas, cada una con distribución exponencial con media de 0.125 horas, y al definir el estado del sistema como (n, p) , donde n es el número de clientes en el sistema ($n = 0, 1, 2$) y p indica la etapa del servicio en la que se encuentra el cliente ($p = 0, 1, 2$, donde $p = 0$ significa que ningún cliente está en servicio).

- Construya el diagrama de tasas correspondiente. Escriba las ecuaciones de balance y úselas para obtener la distribución de estado estable del estado de esta cadena de Markov.
- Utilice la distribución de estado estable que obtuvo en el inciso $a)$ para identificar la distribución de estado estable del número de clientes en el sistema (P_0, P_1, P_2) y el número esperado de clientes en el sistema en el estado estable (L).
- Compare los resultados de $b)$ con los que se obtendrían si la distribución de tiempos de servicio fuese exponencial.

17.7-10. Considere el modelo $E_2/M/1$ con $\lambda = 4$ y $\mu = 5$, que se puede formular como cadena de Markov de tiempo continuo al dividir cada tiempo entre llegadas en dos etapas consecutivas, con distribución exponencial con media de $1/(2\lambda) = 0.125$ y al definir el estado del sistema como (n, p) , donde n es el número de clientes en el sistema ($n = 0, 1, 2, \dots$) y p indica la etapa de la siguiente llegada (que todavía no está en el sistema) ($p = 1, 2$).

Construya el diagrama de tasas correspondiente (pero no resuelva).

17.7-11. Una compañía tiene un técnico que da servicio a un grupo grande de máquinas que están en operación. Si considera a este grupo como una fuente de entrada infinita, las descomposturas individuales son de Poisson con tasa media de 1 por hora. Para cada descompostura existe una probabilidad de 0.9 de que sólo necesite una reparación menor, en cuyo caso el tiempo para repararla tiene distribución exponencial con media de $\frac{1}{2}$ hora. De otra manera, se requiere una reparación mayor, y el tiempo para repararla tiene distribución exponencial con media de 5 horas. Como ambas distribuciones *condicio-*

nales son exponenciales, la distribución *incondicional* (combinada) de los tiempos de reparación es *hiperexponencial*.

- Calcule la media y la desviación estándar de esta distribución hiperexponencial. [Sugerencia: Use las relaciones generales de teoría de probabilidad: para cualquier variable aleatoria X y cualquier par de eventos mutuamente excluyentes, E_1 y E_2 , $E(X) = E(X|E_1)P(E_1) + E(X|E_2)P(E_2)$ y $\text{var}(X) = E(X^2) - E(X)^2$.] Compare esta desviación estándar con la de una distribución exponencial que tiene esta media.
- Calcule P_0 , L_q , L , W_q y W de este sistema de colas.
- ¿Cuál es el valor condicional de W , dado que la máquina necesita reparación mayor? ¿Reparación menor? ¿Cuál es la división de L entre máquinas que requieren las dos reparaciones? (Sugerencia: La fórmula de Little se aplica a las categorías individuales de máquinas.)
- ¿Cómo se definen los estados del sistema para formularlo como cadena de Markov de tiempo continuo? (Sugerencia: Considere qué información se necesita además del número de máquinas descompuestas para que la distribución condicional del tiempo que falta hasta el próximo evento de cada tipo sea exponencial.)
- Construya el diagrama de tasas correspondiente.

17.7-12. Considere la variación de cola finita del modelo $M/G/1$, donde K es el número máximo de clientes que acepta el sistema. Para $n = 1, 2, \dots$, sea X_n la variable aleatoria del número de clientes en el sistema en el tiempo t_n cuando se completa el servicio del n -ésimo cliente (no cuenta el cliente que está saliendo). Los tiempos $\{t_1, t_2, \dots\}$ se llaman *puntos de regeneración*. $\{X_n\}$ ($n = 1, 2, \dots$) es una cadena de Markov de tiempo discreto y se conoce como *cadena de Markov anidada*. Estas cadenas de Markov son útiles para estudiar las propiedades de los procesos estocásticos de tiempo continuo como el modelo $M/G/1$.

Considere el caso especial donde $K = 4$, el tiempo de servicio de clientes sucesivos es una constante fija, por ejemplo 10 minutos, y la tasa media de llegadas es 1 cada 50 minutos. Por lo tanto, $\{X_n\}$ es una cadena de Markov anidada con estados 0, 1, 2, 3. (Como nunca hay más de cuatro clientes en el sistema, no puede haber más de 3 en un punto de regeneración.) El sistema se observa en las salidas sucesivas, así X_n nunca puede decrecer en más de 1. Las probabilidades de transición que resultan en un incremento de X_n se obtienen directo de la distribución Poisson.

- Encuentre la matriz de transición de un paso de la cadena de Markov anidada. (Sugerencia: Obtenga la probabilidad de transición del estado 3 al estado 3; use la probabilidad de 1 o más llegadas en lugar de sólo la de 1 llegada; proceda igual con las otras transiciones al estado 3.)
- Utilice la rutina adecuada en el área de cadenas de Markov del IOR Tutorial para encontrar las probabilidades de estado estable del número de clientes en el sistema en los puntos de regeneración.
- Calcule el número esperado de clientes en el sistema en los puntos de regeneración y compárelos con L del modelo $M/D/1$ (con $K = \infty$ sección 17.7).

17.8-1.* Southeast Airlines es una línea aérea que da servicio en Florida. Su oficina de boletos en cierto aeropuerto de Orlando tiene un agente. Hay dos colas, una para pasajeros de primera clase y otra para los de clase turista. Cuando el agente está listo para atender otro cliente, sirve al siguiente de primera clase si hay uno. Si no lo hay, sirve al siguiente de clase turista. Los tiempos de servicio tienen

distribución exponencial con media de 3 minutos para ambos tipos de clientes. En las 12 horas por día que abre la oficina, los pasajeros de primera clase llegan de manera aleatoria a una tasa media de 2 por hora y 10 por hora los de clase turista.

- ¿Qué tipo de modelo se ajusta a este sistema de colas?
- Encuentre las medidas medias de desempeño L , L_q , W y W_q de ambos tipos de pasajeros.
- ¿Cuál es el tiempo de espera esperado antes de iniciar el servicio a los clientes de primera como fracción del tiempo de los de clase turista?
- Determine el número promedio de horas por día que está ocupado el agente.

T 17.8-2. Considere el modelo con prioridades sin interrupción de la sección 17.8. Suponga que sólo hay dos clases de prioridad, con $\lambda_1 = 2$ y $\lambda_2 = 3$. Cuando diseñe este sistema puede elegir entre dos posibilidades: 1) un servidor rápido ($\mu = 6$) y 2) dos servidores lentos ($\mu = 3$).

Compare estas alternativas con las cuatro medidas de desempeño usuales (W , L , W_q , L_q) de las clases individuales de prioridad (W_1 , W_2 , L_1 , L_2 , etc.). ¿Qué alternativa se debe preferir si la preocupación primordial es el tiempo de espera esperado en el sistema por la clase de prioridad 1 (W_1)? ¿Cuál es preferible si la preocupación es el tiempo esperado en la cola por la clase de prioridad 1?

17.8-3. Considere el modelo con prioridades sin interrupción de la sección 17.8. Suponga que hay tres clases de prioridades, con $\lambda_1 = 1$, $\lambda_2 = 1$ y $\lambda_3 = 1$. Los respectivos tiempos de servicio esperados de las clases 1, 2 y 3 son 0.4, 0.3 y 0.2; en consecuencia, $\mu_1 = 2.5$, $\mu_2 = 3\frac{1}{3}$ y $\mu_3 = 5$.

- Calcule W_1 , W_2 y W_3 .
- Repita el inciso a) a la aproximación de aplicar el modelo general de prioridades sin interrupción de la sección 17.8. Como el modelo supone tiempos de servicio esperados iguales para todas las clases, use un tiempo de 0.3 en lugar de $\mu = 3\frac{1}{3}$. Compare los resultados con los que obtuvo en a) y evalúe si la aproximación que proporciona este supuesto es buena.

T 17.8-4.* Cierta centro de trabajo dentro de un taller se puede representar como un sistema de colas con un servidor, en el que los trabajos tienen llegadas de Poisson con tasa media de 8 por día. Aunque las llegadas son de tres tipos, el tiempo que se requiere para realizar cualquier trabajo tiene la misma distribución exponencial, con media de 0.1 días. La práctica ha sido realizarlos en el orden en que llegan, pero es importante que los trabajos del tipo 1 no esperen mucho, mientras que este detalle no importa tanto con trabajos tipo 2 y casi no tiene importancia si se trata de los del tipo 3. Los tres tipos llegan con tasas medias respectivas de 2, 4 y 2 por día. Como los tres tipos han experimentado retrasos bastante grandes en promedio, se propone seleccionarlos según una disciplina de prioridades apropiada.

Compare el tiempo de espera esperado (con servicio) de cada tipo de trabajo si la disciplina de la cola es a) primero en entrar, primero en salir, b) prioridades sin interrupción y c) prioridades con interrupción.

T 17.8-5. Reconsidere el problema de la sala de urgencias del *Hospital General* de la sección 17.8. Suponga que se ha precisado la definición de las categorías de pacientes a fin de pasar los casos marginales a una categoría más baja. En consecuencia, sólo 5% de los pacientes se clasificará como caso crítico, 20% como caso serio y 75% como

caso estable. Desarrolle una tabla que muestre los datos que se presentaron en la tabla 17.4 de este problema revisado.

17.8-6. Considere el sistema del problema 17.4-6. Suponga que los clientes tipo 1 son más importantes que los tipo 2. Si se cambiara la disciplina de la cola de primero en entrar, primero en salir a un sistema de prioridades con prioridad sin interrupción de los clientes tipo 1 sobre los clientes tipo 2, ¿aumentaría, disminuiría o no cambiaría el número total de clientes en el sistema?

- Determine la respuesta sin realizar cálculos y después presente el razonamiento que lo llevó a su conclusión.
- Verifique su conclusión en *a*) al encontrar el número total esperado de clientes en el sistema con cada disciplina de la cola.

17.8-7. Considere el modelo de colas con disciplina de prioridades con interrupción de la sección 17.8. Suponga que $s = 1$, $N = 2$ y $(\lambda_1 + \lambda_2) < \mu$; y sea P_{ij} la probabilidad de estado estable de que haya i miembros de prioridad alta y j miembros de prioridad baja en el sistema ($i = 0, 1, 2, \dots; j = 0, 1, 2, \dots$). Use un método análogo al descrito en la sección 17.5 para derivar un sistema de ecuaciones lineales cuya solución simultánea sea P_{ij} . No obtenga esta solución.

17.9-1. Lea el artículo de referencia que describe el estudio de investigación de operaciones que se resume en la Viñeta de aplicación que se presentó en la sección 17.9. Describa de manera breve la forma como se aplicó la teoría de colas a este estudio. Después, elabore una lista de los beneficios financieros y no financieros que arrojó dicho estudio.

17.9-2. Considere un sistema de colas con dos servidores al que los clientes llegan de dos fuentes diferentes. De la fuente 1, siempre llegan 2 a la vez y el tiempo entre llegadas consecutivas de pares de clientes es exponencial con media de 20 minutos. La fuente 2 es en sí misma un sistema de colas con dos servidores que tiene entradas de Poisson con media de 7 clientes por hora y el tiempo de servicio por servidor es exponencial con media de 15 minutos. Cuando termina el servicio de un cliente en la fuente 2, de inmediato entra al sistema de colas estudiado para recibir otro servicio. En este último sistema, la disciplina de la cola es prioridades con interrupción y los clientes de la fuente 1 tienen prioridad sobre los de la fuente 2. Sin embargo, los tiempos de servicio son independientes e idénticamente distribuidos para ambos tipos de clientes según una distribución exponencial con media de 6 minutos.

- Primero estudie el problema de derivar la distribución de estado estable *sólo* del número de clientes de la fuente 1 que hay en el sistema. Use una formulación de cadenas de Markov de tiempo continuo para definir los estados y construir el diagrama de tasas que facilite el desarrollo de esta distribución (pero no la obtenga).
- A continuación, enfóquese en el problema de derivar la distribución de estado estable del número *total* de clientes de los dos tipos en el sistema de colas. Utilice una formulación de cadenas de Markov de tiempo continuo; defina los estados y construya el diagrama de tasas que facilite la derivación de esta distribución (pero no la obtenga).
- Ahora examine el problema de derivar la distribución *conjunta* de estado estable del número de clientes de cada tipo en el sistema. Use una formulación de cadenas de Markov de tiempo continuo para definir los estados y construir el diagrama de tasas para derivar esta distribución (pero no la obtenga).

17.9-3. Considere un sistema de dos colas infinitas en serie, donde cada instalación de servicio tiene un servidor. Todos los tiempos de servicio son independientes y tienen distribución exponencial con media de 3 minutos en la instalación 1 y 4 min en la instalación 2. La instalación 1 tiene entradas Poisson con tasa media de 10 por hora.

- Encuentre la distribución de estado estable del número de clientes en la instalación 1 y después en la 2. Muestre la forma de solución de producto de la distribución *conjunta* del número en las respectivas instalaciones.
- ¿Cuál es la probabilidad de que ambos servidores estén desocupados?
- Encuentre el número *total* esperado de clientes en el sistema y el tiempo de espera esperado *total* (con servicio) de un cliente.

17.9-4. Bajo los supuestos de la sección 17.9 para un sistema de colas infinitas en serie, este tipo de redes de colas es un caso especial de una red de Jackson. Demuestre que esto es cierto con la descripción del sistema como una red de Jackson, incluya la especificación de los valores de a_j y de la p_{ij} , dada λ de este sistema.

17.9-5. Considere una red de Jackson con tres instalaciones de servicio cuyos parámetros tienen los valores que se muestran en la siguiente tabla.

Instalación j	s_j	μ_j	a_j	P_{ij}		
				$i = 1$	$i = 2$	$i = 3$
$j = 1$	1	25	6	0	0.2	0.4
$j = 2$	1	30	8	0.5	0	0.3
$j = 3$	1	20	4	0.4	0.3	0

- Encuentre la tasa de llegadas total de cada instalación.
- Encuentre la distribución de estado estable del número de clientes en la instalación 1, en la 2 y en la 3. Después, muestre la forma de solución de producto de la distribución conjunta del número en cada instalación.
- ¿Cuál es la probabilidad de que todas las instalaciones tengan colas vacías (sin clientes que esperan servicio)?
- Encuentre el número total esperado de clientes en el sistema.
- Encuentre el tiempo de espera esperado total (que incluye los tiempos de servicio) de un cliente.

T 17.10-1. Al describir el análisis económico del número de servidores que debe proporcionarse en un sistema de colas, en la sección 17.10 se indica que la función objetivo es minimizar $E(CT) = C_s s + C_w L$. El propósito de este problema es explorar el efecto de los tamaños relativos de C_s y C_w sobre el número óptimo de servidores.

Suponga que el sistema de colas se ajusta al modelo $M/M/s$ con $\lambda = 8$ y $\mu = 10$ clientes por hora. Use la plantilla de Excel del OR Courseware para el análisis económico con $M/M/s$ y encuentre el número óptimo de servidores en cada caso.

- $C_s = \$100$ y $C_w = \$10$.
- $C_s = \$100$ y $C_w = \$100$.
- $C_s = \$10$ y $C_w = \$100$.

T 17.10-2.* Jim McDonald, gerente del restaurante de hamburguesas McBurger, sabe que proporcionar un servicio rápido es la clave del éxito. Es posible que los clientes que esperan mucho vayan a otro lugar la próxima vez. Estima que cada minuto que un cliente tiene que esperar antes de terminar su servicio le cuesta un promedio

de 30 centavos en negocio futuro perdido. Por lo tanto, desea estar seguro de siempre tener suficientes cajas abiertas para que la espera sea mínima. Un empleado de tiempo parcial opera cada caja, obtiene la orden del cliente y cobra. El costo total de cada empleado es de \$9 por hora.

Durante la hora del almuerzo, los clientes llegan según un proceso de Poisson a una tasa media de 66 por hora. Se estima que el tiempo necesario para servir a un cliente tiene distribución exponencial con media de 2 minutos.

Determine cuántas cajas debe abrir Jim durante este tiempo para minimizar su costo total esperado por hora.

T 17.10-3. La compañía Garret-Tompkins tiene tres copiadoras para uso de sus empleados. Sin embargo, debido a quejas recientes de la cantidad de tiempo que pierden en espera de que se desocupe una copiadora, la gerencia planea agregar una o más.

Durante las 2 000 horas de trabajo al año, los empleados llegan al área de copiado según un proceso de Poisson con tasa media de 40 por hora. Se cree que el tiempo que cada empleado necesita una

copiadora tiene distribución exponencial con media de 4 minutos. El costo promedio de la productividad perdida debida al tiempo que pasa un empleado en el área de copiado se estima en \$40 por hora. La renta de cada copiadora es de \$4 000 por año.

Determine cuántas copiadoras debe tener la compañía para minimizar su costo total esperado por hora.

17.11-1. De la parte inferior de las referencias seleccionadas que se proporcionan al final del capítulo, elija una de estas aplicaciones de teoría de colas ganadoras de premios. Lea este artículo y después escriba un resumen de dos páginas de la aplicación y los beneficios (financieros y no financieros) que ésta proporciona.

17.11-2. De la parte inferior de las referencias seleccionadas que se proporcionan al final del capítulo, elija tres de ellas que se refieran a aplicaciones de teoría de colas ganadoras de premios. En el caso de cada una de ellas, lea el artículo y después escriba un resumen de una página de la aplicación y los beneficios (financieros y no financieros) que ésta proporciona.

CASOS

CASO 17.1 Reducción de inventario en proceso

Jim Wells, vicepresidente de manufactura en Northern Airplane Company, está alterado. Su caminata de esta mañana por la planta más importante de la compañía lo dejó de mal humor. Sin embargo, ahora puede descargar su temperamento en Jerry Carstairs, el gerente de producción de la planta, a quien acaba de llamar a su oficina.

“Jerry, acabo de regresar de recorrer la planta y estoy muy enojado.” “¿Cuál es el problema, Jim?” “Bueno, sabes cuánto he recalado la necesidad de disminuir nuestro inventario en proceso.” “Sí, hemos trabajado duro en eso”, responde Jerry. “¡Pues no lo suficiente!” Jim sube más la voz. “¿Sabes lo que encontré junto al proceso?” “No.” “Cinco hojas de metal esperando que las formen en secciones de alas. Después, exactamente en el área siguiente de inspección, ¡13 secciones de alas! El inspector estaba revisando una de ellas, pero las otras 12 sólo estaban ahí. Tú sabes que tenemos un par de cientos de miles de dólares atados en cada una de esas secciones de ala, es decir, tenemos algunos millones de dólares en metal terriblemente costoso sólo en espera. ¡No podemos tener eso!”

El consternado Jerry Carstairs intenta responder. “Sí, Jim, estoy consciente de que la estación de inspección es un cuello de botella. Casi nunca está tan mal como la encontraste esta mañana.” “Eso espero, claro”, replica Jim, “pero necesitas prevenir que algo tan perjudicial ocurra ni siquiera en ocasiones. ¿Qué propones hacer al respecto?” Es notorio que ahora Jerry se anima al responder. “Bueno, en realidad, ya he estado trabajando en este problema; tengo un par de propuestas en la mesa y ya pedí a un analista de IO, que es parte de mi personal, que estudie estas propuestas y regrese con recomendaciones.” “Bien”, dice Jim, “me da gusto ver que tratas de resolverlo. Dale a esto tu prioridad más alta y repórtame cuanto antes”. “Está bien”, promete Jerry.

El siguiente es el problema que Jerry y su analista de IO estudian. Cada una de 10 prensas idénticas se usa para formar las secciones de alas a partir de hojas de metal con un procesamiento especial. Las hojas llegan de manera aleatoria al grupo de prensas con una tasa media de 7 por hora. El tiempo que requiere la prensa para formar una sección de ala a partir de la hoja de metal tiene distribución exponencial con media de 1 hora. Cuando termina, la sección de ala llega de manera aleatoria a una estación de inspección con la misma tasa media que las hojas llegan a las prensas (7 por hora). Un solo inspector tiene el trabajo de tiempo completo de inspeccionar las secciones de ala para asegurar que cumplen con las especificaciones. Cada inspección toma 7 y 1/2 minutos, de manera que puede inspeccionar 8 secciones por hora. Esta tasa de inspección ha dado como resultado una cantidad promedio sustancial de inventario en proceso en la estación de inspección (esto es, el número promedio de secciones de ala que esperan pasar la inspección es bastante grande), además del que se encuentra en el grupo de máquinas.

El costo de este inventario en proceso se estima en \$8 por hora por cada hoja de metal en las prensas o cada sección de ala en la estación de inspección. Por lo tanto, Jerry Castairs tiene dos propuestas alternativas para reducir el nivel de inventario en proceso.

La propuesta 1 es usar un poco menos de potencia en las prensas (lo que aumentaría su tiempo promedio para formar una sección de ala a 1.2 horas), de manera que el inspector pudiera mantener el paso con su producción. Esta medida también reduciría el costo de energía para operar las máquinas de \$7.00 a \$6.50 por hora. (Por el contrario, incrementar la potencia al máximo aumentaría este costo a \$7.50 por hora y disminuiría el tiempo promedio para formar cada sección de ala a 0.8 horas.)

La propuesta 2 es sustituir el inspector por uno más joven para esta tarea. Éste es un poco más rápido (aunque con alguna