




UNI- NORTE - SEDE REGIONAL
Estelí, Nicaragua

Estadística Básica para Ingenieros



$$X^2 = \frac{12}{nk(k+1)} \sum_{j=1}^k R^2 - 3n(k+1)$$

20/01/2012

Luis María Dicovski Riobóo

Índice

Introducción.....	1
Capítulo 1. Estadística Descriptiva.....	2
1.1 Introducción.	2
1.2 Análisis de datos, Tablas de Distribución de frecuencias y Tablas de Contingencia.....	5
1.3 Gráficos	14
1.4 Medidas de Tendencia Central	20
1.4.1 Media Aritmética.....	21
1.4.2 La Mediana	22
1.4.3 La Moda	23
1.4.4 Otras medidas de tendencia central.....	25
1.4.4.1 La Media Geométrica.....	25
1.4.4.2 La Media Cuadrática	25
1.4.4.3 Cuartiles, Deciles y Percentiles.....	25
1.5 Medidas de Dispersión o de Variabilidad.....	27
1.5.1 El Rango	27
1.5.2 El Desvío Estándar.....	27
1.5.3 La Varianza	29
1.5.4 El Coeficiente de variación	29
1.6 Otras medidas útiles en Estadística Descriptiva	30
1.6.1 La Asimetría o Sesgo	30
1.6.2 La Curtosis	32
1.7 Muestras y Población.....	33
1.7.1 Muestreo Aleatorio Simple	34
1.7.2 Muestreo Estratificado.....	36
1.7.3 Muestreo por Conglomerados.....	37
1.7.4 Muestreo Sistemático.....	38
Capítulo 2. Teoría Elemental de Probabilidades	40
2.1 Introducción a las Probabilidades	40
2.2 Términos Básicos.	40
2.3 Propiedades de la Probabilidad	42
2.3.1 Regla de la Suma.....	43
2.3.2 Regla del producto.	44
2.4 Probabilidad condicionada.....	45
2.5 Teorema de Bayes	47
2.5.1 Regla de la probabilidad total.....	47
2.5.2 Planteo del Teorema de Bayes	48
2.6 Técnicas de conteo: Combinaciones y Permutaciones.....	52

Capítulo 3. Variables aleatorias y sus distribuciones.	55
3.1 Distribuciones de Frecuencia, Introducción.	55
3.2 Variables aleatorias.	57
El Desvío Estándar y el Teorema de Chebyshev	62
3.3 Distribución Normal.....	63
3.4 Distribución “t” de Student	67
3.5 La distribución X^2 de Pearson.....	69
3.6 La distribución “F” de Fisher- Snedecor.....	70
3. 7 La distribución Binomial	71
3.8 Distribución de Poisson	74
Capítulo 4. Estimación y prueba de hipótesis.....	77
4.1 Estimación por Intervalos de Confianza.....	77
4.2 Generalidades de las pruebas de Hipótesis	79
4.3 Prueba de hipótesis con la distribución “t”	82
4.3.1 La media de una muestra pertenece a una población con media conocida..	82
4.3.2 Comparaciones por parejas de muestras no independientes o apareadas...	83
4.3.3 Las medias de dos muestras o grupos pertenecen a una misma población .	84
Capítulo 5. Análisis de Correlación y Regresión.	87
5.1 Correlación	87
5.2 Regresión	89
5.2.1 Ecuación de Regresión Lineal	90
5.2.2 Análisis de Regresión Múltiple.....	95
5.3 Coeficientes de Correlación Parcial y Múltiple	96
5.4 Estimadores “b” de la ecuación de Regresión Lineal Múltiple	98
5.5 Pruebas de Hipótesis de Correlación y Regresión	101
Capítulo 6. Diseño y Análisis de Experimentos	107
6.1 Experimentación, conceptos básicos.....	107
6.2 Modelos ANDEVA	109
6.3 Andeva uni factorial, anova one way, diseño DCA.	113
6.4 ANDEVA para un Diseño BCA	122
6.5 Diseño de Cuadro Latino	129
6.6 Diseño en Cuadro Greco Latino	135
6.7 Análisis de la varianza de dos factores con interacción.....	136
Capítulo 7. Estadística no paramétrica.....	141
7.1 Introducción a la Estadística No paramétrica.....	141
7.2 Prueba del signo.....	142
7.3 Prueba ji-cuadrado, χ^2	146
7.4 Análisis de Variancia no paramétrico.....	150
7.4.1 Prueba de Kruskall Wallis.	150
7.4.2 Análisis bilateral por jerarquías de Friedman	152

7.5 Coeficiente de correlación de Ranking de Spearman	154
Capítulo 8. Control estadístico de la calidad	157
8.1 Calidad, conceptos	157
8.2 Diagramas de Control	157
8.3 Diagramas de control por Mediciones.....	159
8.3.1 Diagrama de Medias $\bar{X}$ con límites definidos por los Rangos	160
8.3.2 Diagrama de Rangos (R)	162
8.3.3 Diagrama de Medias con límites definidos por los Desvíos estándares, S.	162
8.3.4 Diagrama de Medias de Desvíos estándares, S.	163
8.3.4 Valores individuales (X-ind).....	164
8.4 Diagramas de control por atributos	165
8.4.1 Diagrama “p”	167
8.4.2 Diagrama “n p”	169
8.4.3 Diagrama “c”, número de defectos	170
8.4.4 Diagrama “u”, número de defectos por unidad	172
Bibliografía Consultada	174

Introducción

Este texto básico de estadística está diseñando y organizado en función del contenido de la mayoría de los temas que se aborda en las asignaturas de Estadística I y Estadística II que se imparte en las carreras de Ingeniería en Sistemas, Civil, Industrial y Agroindustrial de la Universidad Nacional de Ingeniería, UNI, Nicaragua. Sin embargo por su forma sencilla y asequible con que se trató de abordar los diferentes temas, este texto puede ser útil como libro de texto en otras carreras universitarias.

En el contenido se ha tratado de mantener un enfoque utilitario, práctico, respetando el principio que la Estadística debe ser una herramienta fundamental para describir procesos y tomar decisiones en el trabajo cotidiano de un Ingeniero. Se trató de romper la dicotomía entre teoría y realidad, respondiendo permanentemente a la pregunta ¿Cuándo puedo usar esta teoría? ¿Qué me permite conocer o responder la misma? Si podemos describir “la estadística” como: *“un conjunto de técnicas para describir grupos de datos y para tomar decisiones en ausencia de una información completa”*. ¡Este texto de estadística para ingenieros trata de respetar esta definición!

Por lo anterior y respetando el principio de asequibilidad, es que buena cantidad de los ejercicios del texto fueron generados en el aula con la información que tienen los estudiantes a la mano. Creo que la estadística no puede funcionar si primero no se sabe cómo generar el dato, cómo organizar la información en una matriz numérica, analizar las variables usando un programa estadístico computacional para finalmente interpretar la información en un lenguaje entendible por cualquier lector.

Por último, para realizar los ejercicios de este texto y construir gráficos digitales se sugiere utilizar el programa estadístico INFOSTAT, el cual dispone de una versión de uso libre que se puede descargar gratuitamente desde la página www.infostat.com.ar .

Capítulo 1. Estadística Descriptiva

Objetivos

- ☞ Reflexionar sobre el uso de la estadística a través de situaciones de la vida profesional.
- ☞ Introducir a la recolección de datos a partir de un problema del entorno de un ingeniero y desde la experiencia del estudiante.
- ☞ Construir medidas de tendencia central, de variabilidad y diferentes tipos de Gráficos más comunes que permite una tabla de distribución de frecuencia, TDF.
- ☞ Diferenciar las diferentes formas de muestreos para estudiar el contexto socioeconómico.
- ☞ Calcular de forma representativa el tamaño de una muestra con variables construidas con ejemplos de su carrera.

1.1 Introducción.

La estadística, es una ciencia relativamente nueva pero con miles de años de uso empírico, María y José parten de Nazaret a Belén para ser censados por los romanos. ¡Hace 2000 años éste imperio llevaba un control estadístico de lo que poseían sus colonias para cobrarles impuestos! En la actualidad los procedimientos estadísticos son de particular importancia en las diferentes ciencias, para reducir y abstraer datos. Una definición que describe la estadística de manera utilitaria es la que dice que es: *“un conjunto de técnicas para describir grupos de datos y para tomar decisiones en ausencia de una información completa”*. La estadística a diferencia de la matemática no genera resultados exactos, los resultados siempre tienen asociada un grado de incertidumbre o error. La estadística trata de lograr una aproximación de la realidad, la cual es siempre mucho más compleja y rica que el modelo que podemos abstraer. Si bien esta ciencia es ideal para describir procesos cuantitativos, tiene serios problemas para explicar “por qué” cualitativo de las cosas.


En general podemos hablar de dos tipos de estadísticas, las *descriptivas* que nos permiten resumir las características de grandes grupos de individuos y las *inferenciales* que nos permite dar respuestas a preguntas (hipótesis) sobre poblaciones grandes a partir de datos de grupos pequeños o muestras.

La estadística tiene serios problemas para explicar el “por qué”

Construcción de Variables a partir de información.

Para poder analizar datos, ya sea de forma manual o por computadora, hay que entender que trataremos a partir del estudio de la realidad observable crear un modelo numérico teórico donde se estudian variables para describirlas y analizar sus relaciones. Para hacer esto primero es necesario definir algunos términos teóricos.

Variable: es una característica observable y que varía, una característica constante en el grupo de estudio, no es una variable. Por ejemplo en el conjunto de estudiantes de la Universidad, ser “estudiante de una determinada carrera” es una variable, pero ser “Bachiller” es una constante. Las variables se pueden clasificar de diferentes maneras, un enfoque es reconocer dos grandes grupos de variables las Cualitativas y Cuantitativas.



Variables Cualitativas o Categóricas, son aquellas que se ordenan en categorías debido a su carácter subjetivo y absoluto, pueden ser de dos tipos “nominales”, u “ordinales”. En las variables nominales los valores **no** pueden ser sometidos a un criterio de orden o importancia como por ejemplo “el sexo de una persona” o “el departamento de origen”. Los atributos, en control de calidad, son variables nominales: Ej. “defectuoso”, “no defectuoso”. En cambio las variables Ordinales pueden tomar distintos valores que se pueden ordenar siguiendo una escala establecida, aunque no es necesario que el intervalo entre mediciones sea uniforme, por ejemplo: leve, moderado, grave.

Variables Cuantitativas, son aquellas en que sus características están expresadas en valores numéricos, éstas asumen cualquier valor y pueden variar en cualquier cantidad, sobre una escala aritmética e infinita y pueden subdividirse en dos tipos “continuas” y “discretas o contables”.

Las variables Continuas o Reales pueden adquirir cualquier valor dentro de un intervalo especificado de valores, permite siempre que se encuentre un valor nuevo entre dos valores previos, aceptan valores con fracciones de enteros. El rendimiento de un lote de frijol se mide en qq/mz es una variable continua. Generalmente estas variables se obtienen de medir o pesar.

Las variables Discretas presentan interrupciones en la escala de valores que puede tomar. Estas separaciones o interrupciones indican la ausencia de valores entre los distintos valores específicos que la variable pueda asumir por número de miembros de una familia es una variable discreta, se cuenta y entre dos personas no hay un valor intermedio, no existe 1.5 personas, no hay fracciones de enteros.

Las variables generan “datos”, con ellos se hace la estadística y cada uno de éstos ocupa una celda de una matriz o base de datos. La Matriz de datos es un ordenamiento de datos en fila y columnas donde cada fila es un individuo, una parcela, una muestra, una unidad experimental o una encuesta determinada y cada columna:

una variable. Los programas Access, Excel, Infostat y SPSS ordenan los datos en forma de matriz numérica. Por ejemplo en una encuesta (cuestionario) cada pregunta que se tiene, genera al menos, una variable generalmente discreta. Hay casos donde una pregunta puede generar muchas variables de tipo dicotómico, SI- NO.

Ejercicio 1.1: Construya variables relacionadas con su carrera, 5 nominales, 5 ordinales, 5 continuas y 5 ordinales.

Ejercicio 1.2 Clasifique las siguientes variables.


- Peso de un estudiante.
- Diámetro de una casa.
- Color de ojos.
- Tipo de techo.
- Vida útil de un monitor
- # de ladrillos de una pared.
- Belleza de una flor.
- Temperatura semanal.
- Largo de peces de un estanque.
- Diámetro de un tornillo

1.2 Análisis de datos, Tablas de Distribución de frecuencias y Tablas de Contingencia

“A partir de la realidad observable se debe crear un modelo numérico teórico para intentar estudiar ésta realidad”

Una vez que los datos se han codificado, transferidos a una matriz y guardado en una computadora podemos proceder a analizarlos, proceso que se hace con un programa estadístico como SPSS o INFOSTAT, de forma manual solo se pueden manejar pocos datos y variables es por ello que el énfasis de este libro está más en la interpretación de resultados que en los procedimientos de cálculo.

El procedimiento de análisis sugerido se esquematiza en la figura siguiente:



En general el investigador debe buscar de primero cómo describir sus datos y posteriormente efectuar el análisis estadístico para relacionar las variables generadas. Los tipos de análisis son variados y cada método tiene su razón de ser un propósito específico, “la estadística no es un fin en sí misma, sino una herramienta para analizar datos”.

Los principales análisis que pueden efectuarse son:

- Estadística descriptiva de las variables.
- Pruebas de hipótesis para la toma de decisiones.

“la estadística está ligada a la toma, organización, presentación y análisis de un grupo de datos”.

Una primera tarea luego de construir una tabla o matriz de datos, es explorarlos buscando información atípica o anormal y corregir los casos que la información extraña se deba a una mala digitación o error en la recolección de datos.

Lo siguiente para observar el comportamiento de los datos es realizar una “distribución frecuencias” en forma de tabla y gráficos. Para esto, los datos se agrupan en clases o categorías y para grupo se calcula las frecuencias absolutas y relativas.

En este momento es importante poder definir el tipo de escala de medición usada, sucesión de medidas que permite organizar datos o para agrupar los datos, en este sentido se pueden reconocer diferentes escalas:

- Las Escalas Nominales, son discontinuas y se usan cuando describimos algo dándole un nombre a cada categoría o clase y estas son mutuamente excluyentes.

A cada categoría se le adjudica un valor numérico. Por ejemplo la variable Departamento con las categorías “Estelí, Nueva Segovia, Madriz, Otra”.

- Las Escalas Ordinales, son discontinuas y se usan donde hay un orden jerárquico de un conjunto de objetos o eventos con respecto a algún atributo específico, por ejemplo ordenar los ingresos en tres niveles: “alto = 1”, “medio = 2” y “bajo = 3”.
- Las Escalas de Intervalos Iguales, estas pueden ser sumadas, restadas multiplicadas y divididas sin afectar las distancias relativas entre las calificaciones. Por ejemplo las medidas de temperatura en Grados C⁰, las calificaciones de un examen en una escala de 1 a 100. En esta escala el “0” es arbitrario y no necesariamente representa ausencia, también nos dice que un valor de 30 puntos de un examen de español no necesariamente representa la mitad de conocimiento de un valor de 60 puntos.
- Las Escala de Razón Constante, tienen todas las propiedades de las Escalas de intervalos más un cero absoluto, por ejemplo las medidas de tiempo, peso y distancia, el valor “0” representa ausencia del valor.

Un caso especial de escala ordinal es la escala de Likert, esta escala es muy usada en las ciencias sociales y se usa para medir actitudes, “Una actitud es una predisposición aprendida para responder consistentemente de una manera favorable o desfavorable”. Así las personas tenemos actitudes hacia muy diversos objetos o símbolos, por ejemplo: actitudes hacia la política económica, un profesor, la ley, nosotros, etc. Las actitudes están relacionadas con el comportamiento que mantenemos. Estas mediciones de actitudes deben interpretarse como “síntomas” y no como hechos. Esta escala es bipolar porque mide tanto el grado positivo como negativo de cada enunciado y consiste en un conjunto de ítem presentado en forma de afirmaciones o juicios ante los cuales se pide reacción a los sujetos en estudio en una escala de 5 puntos, cada punto tiene un valor numérico. Un ejemplo de cómo calificar con afirmaciones positivas es ¿Le gusta cómo se imparte la clase de estadística?:

- 1- Muy en desacuerdo, 2- En desacuerdo, 3- Ni de acuerdo, ni en desacuerdo,
- 4- De acuerdo, 5-Muy de acuerdo.

Estar de acuerdo con la idea presentada significa un puntaje mayor.

Ejercicio 1.3: entre los participantes del grupo de clases tomar datos de 15 variables al menos por ejemplo: Edad, Sexo, Procedencia, etc. Y luego ordénalos en forma de matriz de datos, recodifique la información cualitativa en numérica.

Organización de una matriz de información a partir de un cuestionario de una encuesta.

Una encuesta impersonal con preguntas cerradas en un cuestionario es una manera de recolectar mucha información rápidamente que luego se puede codificarla fácilmente y que puede analizarse estadísticamente. La debilidad de este instrumento es que no siempre la gente responde adecuadamente y que las respuestas generadas se limitan a las opciones previamente definidas, en general la realidad es mucho más rica que lo que creemos ocurre a priori. Para los que trabajan con entrevistas hay que saber que también la información que se genera de las entrevistas puede luego tabularse numéricamente de la misma manera que una encuesta con cuestionario.

Cuestionarios: Al diseñar un cuestionario esta debe ayudar a responder a las preguntas que genera la hipótesis del trabajo, un error común es hacer una encuesta primero y luego que se han recolectado los datos, se solicita a un estadístico que no ayude a analizar la información, “la lógica es al revés” se debe pensar cómo se analizará la información desde el mismo momento que se diseña la encuesta. Se sugiera que las variables cualitativas (ej. nombres) se deben recodificar al momento del llenado de la base de datos creando variables numéricas discretas, por ej. Si quiero clasificar las becas que otorga una Universidad puedo codificar a estas de la siguiente manera: Beca interna, Beca externa y No beca.

Si las opciones que genera una variable discreta permite hacer combinaciones de las respuestas se sugiere crear muchas variables dicotómicas del tipo “Si o No”. Veamos un ejemplo: Si se pregunta: que prácticas de en los cultivos realiza un campesino, estas pueden ser varias y combinadas como: Insecticidas Botánicos, Trampas amarillas, Barreras vivas, Semilla resistente etc. En este caso lo que se hace es

generar un variable del tipo “Si, No” para cada opción de práctica de cultivo, generando muchas variables en una sola pregunta.

Para crear una base de datos hay que recordar que se está obteniendo una matriz de datos donde en la primera fila se tiene el nombre abreviado de la variable y en el resto de las filas los datos para cada encuesta o individuo en estudio. Las variables cualitativas se deben recodificar, veamos el siguiente ejemplo hipotético de 8 encuestas:

Encuesta	Sexo	Edad	Ingresos semanales C\$	Comunidad	Labor realizada
1	V	31	1,394	2	3
2	V	35	1,311	4	2
3	V	43	1,300	2	3
4	V	28	1,304	3	1
5	M	45	1,310	1	3
6	M	36	1,443	2	2
7	M	21	1,536	2	3
8	M	32	1,823	1	3

Esta matriz se puede codificar así: la variable “Sexo”: varón, mujer. Para la variable “comunidad” hay 4 tipos diferentes donde: 1= Estelí, 2= Condega, 3= Pueblo Nuevo y 4= Limay y para “Labor realizado”: 1= en otra finca, 2= en la ciudad y 3= en la propia finca.

Ejercicio 1.4: Intente codificar numéricamente las respuestas que se generan a partir de la encuesta de caracterización socioeconómica, que a continuación se detalla, discuta las posibles respuestas, diga si las preguntas están bien formuladas, sugiera si alguna de ellas está de más y que preguntas propone para completar la información.

Hoja de Encuesta

Número de ficha _____

Fecha: _____

Primer Apellido _____ Segundo Apellido _____

Nombres: _____ Año _____

Dirección: _____

Estado Civil: _____ Número de personas que habitan la vivienda _____

Nivel de estudio de ellos _____ Edad de cada una de ellos _____

Profesión: _____

Ejercicio 1.5:

- Defina variables para caracterizar a los estudiantes del curso con el objetivo de determinar posibles causas que tengan influencia en el rendimiento académico del grupo.
- Cree una base de datos de al menos 25 individuos. Ver ejemplo.

Ejemplo de una matriz de datos generados con datos de estudiantes.

<i>notas</i>	<i>edad</i>	<i>altura</i>	<i>Sexo</i>	<i>Peso</i>	<i>Origen</i>	<i>Ingresos</i>	<i>Becas</i>	<i>opinión</i>
74	25	1.75	Varon	140	No	Alto	No	3
70	18	1.55	Mujer	110	Estelí	Media	Si	3
80	24	1.85	Varon	150	Estelí	Media	Si	2
70	20	1.54	Mujer	117	Estelí	Media	No	4
78	24	1.65	Varon	150	No	Alto	No	5
85	19	1.8	Varon	150	Estelí	Media	No	5
70	19	1.7	Varon	140	No	Media	Si	5
75	20	1.5	Mujer	112	Estelí	Alto	Si	1
70	18	1.7	Varon	160	Estelí	Alto	No	4
85	18	1.67	Varon	120	No	Alto	No	4
77	18	1.63	Varon	135	Estelí	Alto	No	2
75	20	1.52	Mujer	110	Estelí	Media	No	3
80	18	1.75	Varon	110	Estelí	Media	Si	3
80	21	1.73	Varon	160	No	Media	Si	3
80	17	1.6	Mujer	114	No	Alto	No	2
78	18	1.5	Mujer	128	No	Alto	No	5
75	20	1.7	Mujer	120	Estelí	Alto	No	5
90	19	1.65	Mujer	130	No	Alto	Si	4
70	22	1.65	Varon	140	No	Media	Si	2
78	18	1.8	Varon	174	No	Media	Si	4

Códigos: Opinión: Conformidad con las clases: 1= Muy en Desacuerdo, 2= en Desacuerdo, 3= Indiferente, 4= De Acuerdo, 5= Muy de Acuerdo.

Principios a utilizar al construir una Tabla de Distribución de Frecuencias, TDF.

Aunque esta tabla sirve para resumir información de variables discretas o continuas, de manera particular la TDF permite transformar una variable continua, a una variable discreta definida por el número de intervalos y su frecuencia. Esta transformación permite construir gráficos de histogramas o polígonos. Con Variables continuas como (peso, altura, producción / superficie, etc.) el recorrido de la variable se parte en intervalos semiabiertos, las clases.

Lo primero para construir una TDF es definir el “número de clases” o intervalos a crear y el “ancho” de cada intervalo. Para que los gráficos permitan visualizar tendencias de la variable en estudios, el número de clases se recomienda que no sean menor de 3 ni mayor de 20. Al ancho de clase se calcula dividiendo el Rango (valor mayor – valor menor), con un valor que debe variar entre 3 y 20. Hay que utilizar más clases cuando se tiene más datos disponibles, si el número de clases es muy grande es posible tener muchas clases vacías, si es demasiado pequeño podrían quedar ocultas características importantes de los datos al agruparlos. Se tendría que determinar el número de clases a partir de la cantidad de datos presente y de su uniformidad, en general con menos de treinta datos se usa una TDF con 3-5 clases, para tener un criterio sobre el número de clases en función del número de datos ver la tabla siguiente .

Tabla para determinar el número de clases de una TDF

Número datos	Número de clases
30-50	5-7
51-100	6-10
101-250	7-12
+250	10-20

El valor central de una clase se llama “marca de clase”, este valor se usa para construir los gráficos de polígonos de frecuencia. Veamos un ejemplo de cómo se construye una

Tabla de Distribución de Frecuencias. Es importante resaltar que con las variables nominales no se construyen intervalos, límites ó marcas de clase, esto no tiene sentido con este tipo de variable.

Ejemplo con Datos de ingresos de 24 familias. Variable: Ingresos semanales en C\$ por familia, n = 24 datos.

1,450	1,443	1,536	1,394	1,623	1,650
1,480	1,355	1,350	1,430	1,520	1,550
1,425	1,360	1,430	1,450	1,680	1,540
1,304	1,260	1,328	1,304	1,360	1,600


Secuencia de actividades

- Se calcula el Rango de los datos, valor mayor menos valor menor: $1680 - 1,260 = 420$ C\$.
- Ancho de clase: El rango se divide en cuatro, $420/4 = 105$ C\$, se ajusta a 100 C\$ y de esta manera el número de clases queda en cinco.
- Se construye los límites inferiores y superiores de cada clase como intervalos semiabiertos,
- Luego se cuentan las frecuencias por clase, esto es la Frecuencia Absoluta
- Se calcula la Frecuencia Relativa (Frecuencia Absoluta / n)
- Se hace Frecuencia Acumulada. que es la suma de las frecuencias absolutas. También se pueden hacer las frecuencias expresadas en porcentajes.

Tabla de Distribución de frecuencias, TDF.

Clase	Límite Inferior Igual a	Lim. Superior Menor a	Marca de clase	Frecuencia Absoluta	Frecuencia Relativa	Frecuencia Acumulada
1	1,200	<1,300	1,250	1	0.04	1
2	1,300	<1,400	1,350	8	0.33	9
3	1,400	<1,500	1,450	7	0.29	16
4	1,500	<1,600	1,550	4	0.17	20
5	1,600	<1,700	1,650	4	0.17	24
			Total	24	1.00	

Ejemplo de gráfico construido con estos datos



“Histograma y Polígono de Frecuencias Relativas de Ingresos semanales de 24 familias del Barrio Virginia Quintero, Estelí. 2008”

Se puede observar que la información que lleva el gráfico es completa, incluye todos los datos y permite explicar el contenido del mismo por ejemplo: la barra de mayor altura contiene la moda y al no ser un gráfico simétrico concluyo que la media y mediana son diferentes y que los datos son sesgados hay un agrupamiento de frecuencias a la izquierda del centro.

Una manera de representar una distribución de Frecuencias es:

1. Por medio de un gráfico de Barras con variables nominales.
2. Con un Histograma con variables continuas.
3. Un polígono de Frecuencias cuando se quieren mostrar las frecuencias absolutas.
4. Con un gráfico de Pastel cuando se tienen porcentajes o proporciones.

Tablas de contingencia

Las tablas de contingencia, o tablas cruzadas, se usan para resumir la relación de variables cualitativas con pocas categorías, incluso dicotómicas. Estas tablas generalmente vinculan dos variables y en las celdas generadas se muestran las

frecuencias absolutas o relativas de las variables involucradas, también se puede mostrar los porcentajes. En las filas suele ir la variable más importante y si se muestran las frecuencias relativas éstas se calculan por fila. Las sumas de las filas y las columnas generan frecuencias marginales y en la celda de la esquina inferior derecha se tiene el total de datos. Con estas tablas se pueden construir gráficos de barras bivariados. A continuación a modo de ejemplo se muestran dos tablas, una de frecuencias absolutas y otra de frecuencias relativas de los datos de una sección de 31 estudiantes, las variables en estudio son: “sexo” y “si disponen de beca”. Cómo en este estudio la variable más importante de cruce es sexo, ésta se ubica en las filas y así se observan las frecuencias relativas.


<i>Frecuencias absolutas</i>				<i>Frecuencias relativas por filas</i>			
<i>En columnas: Beca</i>				<i>En columnas: Beca</i>			
<u>Sexo</u>	<u>No</u>	<u>Si</u>	<u>Total</u>	<u>Sexo</u>	<u>No</u>	<u>Si</u>	<u>Total</u>
Mujer	10	7	17	Mujer	0.59	0.41	1.00
Varón	7	7	14	Varón	0.50	0.50	1.00
<u>Total</u>	<u>17</u>	<u>14</u>	<u>31</u>	<u>Total</u>	<u>0.55</u>	<u>0.45</u>	<u>1.00</u>

Ejercicio 1.6 Realizar una tabla de frecuencias con una variable discreta (contable) y una variable continua (medible) de la matriz generada con los datos obtenidos en clase. Con dos variables cualitativas construye una tabla de contingencia.

1.3 Gráficos

Los gráficos nos permiten presentar la información que dan los datos de manera rápida, resumida y fácil de entender. Los gráficos se pueden clasificar de múltiples maneras pero en éste texto los consideraremos como: univariados, bivariados y multivariados, según el número de variables involucradas.

Gráficos univariados, Ejemplo de edad de una muestra de personas, datos presentados en forma de Histograma de frecuencias. En este gráfico las barras se encuentran unidas, no habiendo espacio entre las barras. Para su construcción primero se tiene que hacer una tabla de distribución de frecuencias, TDF, donde se precisen los límites reales de frecuencia, que se usan para construir las barras. El centro de cada barra es la “marca de clase”, esta medida se usa para construir polígonos.



Histograma de Frecuencias absolutas, de la edad, de una muestra de personas de una comunidad rural del Departamento de Estelí. 2008.

Este gráfico univariado se acompaña de estadística descriptiva como medias, medianas, desvíos estándares, coeficientes de variación e intervalos de confianza.

“Gráfico de Pastel o Sectores” Ejemplo del nivel de educación, de una muestra de 598 personas de origen rural. Este Gráfico creado con frecuencias y porcentajes, permite resaltar segmentos de clases determinadas.






Gráfico de pastel o sectores.

“Gráfico de Barras bivariado”. Ejemplo de las notas de tres asignaturas presentadas en forma de barras. Este resume la media de notas obtenido por asignatura. Entre barra y barra hay un espacio. El gráfico observado a continuación se construyó con una variable nominal, asignatura y una variable continua, nota.



“Polígono de Frecuencias” Ejemplo de un donde se grafica en el tiempo el desarrollo de una enfermedad, tizón temprano, en el follaje de las plantas de tomate. Este polígono se construye con los valores medio de cada clase, Marca de clase y las frecuencias por clase.


El Polígono es una línea quebrada que se construye uniando los puntos medios en la parte superior de cada barra, marca de clase de un histograma



Polígono de frecuencias acumuladas, en porcentaje del desarrollo de una enfermedad fungosa, en plantas de tomate.

Gráficos Multivariados. Son gráficos que incorporan 2 o más variables.

Gráfico de Barras que incorpora 4 variables dicotómicas (si- no)



Este tipo de gráfico permite resumir de manera muy eficiente la información de hasta 6 o 7 variables. Es ideal para usar con variables dicotómicas, SI y NO.

Gráfico De Barras,

Bivariado en Agrupamientos




Gráfico bivariado, se puede acompañar de una tabla de contingencia de frecuencias o porcentajes y con una prueba estadística X^2 de independencia.

Gráfico Bivariado De Barras Apiladas





Gráfico bivariado que reduce el número de barras y por lo tanto se simplifica el diseño. Se puede construir con frecuencias o porcentajes



“Un Gráfico permite ver rápidamente lo que dicen los datos”

Ejercicio 1.7. Realizar un gráfico de barras y un gráfico de Pastel a partir de los datos recolectados en clase.

1.4 Medidas de Tendencia Central

Al forjarnos una imagen mental de la distribución de frecuencias de un conjunto de mediciones, una de las primeras apreciaciones descriptivas de interés es una medida de tendencia central, es decir, una que localiza el centro de la distribución.

Una de las medidas de tendencia central más común y útil es la media común o “media aritmética”, pero también son de importancia, según las circunstancias y el tipo de variables la “moda” y la “mediana”. Otras medidas de tendencia central menos usadas son la “media geométrica” y la “media cuadrática”.

La sumatoria, un concepto básico introductorio:

En matemática, el símbolo Griego Sigma “ Σ ” en mayúscula se utiliza para indicar sumatoria de datos donde:

$$\sum_1^n x_i = x_1 + x_2 + x_3 + x_4 + \dots + x_n$$

Siendo “x” un valor de una medición de la variable en estudio e “i” un índice que varía de “1 a n”. El número de datos de la muestra se identifica con la letra “n”.

1.4.1 Media Aritmética

La media aritmética o simplemente media de un conjunto de mediciones es la medida de tendencia central más usada y conocida. Esta medida se simboliza como $\bar{x}$ (x con raya) cuando representa la media de una muestra y como μ (letra griega minúscula) para representar la media poblacional. Tanto " $\bar{x}$ " o " μ " son la suma de todos los valores de la muestra o población divididos por el número de casos. En el caso de la media de una muestra esta es igual a: " $\bar{x} = (x_1 + x_2 + x_3 + \dots + x_n) / n$ " donde "n" es el número de datos de la muestra y "x" el valor numérico del dato. La fórmula simplificada de la media es:

$$\bar{x} = \frac{\sum_1^n x_i}{n}$$

Cuando se tienen datos agrupados en una distribución de frecuencias se obtiene el punto medio de cada intervalo y se determina media de la siguiente manera:

$$\bar{x} = (\sum_1^k x_M f) / n$$

Donde "k" es el número de intervalos, "n" el número total de datos, "f" es la frecuencia de la clase y " x_M " el punto medio de cada intervalo.

Una debilidad de la media aritmética es su sensibilidad a valores extremos de la distribución y que carece de sentido para variables medidas con un nivel nominal u ordinal.

Media Aritmética

$$\bar{x} = \frac{\sum_1^n x_i}{n} \text{ Muestra}$$

$$\mu = \frac{\sum_1^N x_i}{N} \text{ Población}$$

"n" es el número de datos de la muestra y "N" el de la población.

Ejemplo de cálculo de una media

Si tengo la nota de un examen de matemáticas de 10 estudiantes en una escala de 1 a 100 donde:

Estudiante	“Variable Nota = x_i ”	Valor de x_i
Luis	X_1	62
Alberto	X_2	68
Juan	X_3	92
Pedro	X_4	88
Roberto	X_5	55
María	X_6	79
Raquel	X_7	89
Luisa	X_8	92
Rosa	X_9	67
Diana	X_{10}	69
	$\sum_{i=1}^{10} x_i =$	761.

En este caso “i” varia de 1 a 10.

Media de notas de los estudiantes = $(\sum_{i=1}^{10} x_i)/10 = 761/10 = \mathbf{76.1}$

1.4.2 La Mediana

La segunda medida de tendencia central es la mediana. La mediana “ M_e ” de un conjunto de mediciones “ $x_1, x_2, x_3, \dots, x_n$ ” es el valor de “x” que se encuentra en el punto medio o centro cuando se ordenan los valores de menor a mayor, ranking. Esta medida no sufre la influencia de valores extremos atípicos.

Si las mediciones de un conjunto de datos se ordenan de menor a mayor valor y “n” es impar, la mediana corresponderá a la medición con el orden “ $(n + 1) / 2$ ”. Si el número de mediciones es par, n = par, la mediana se escoge como el valor de “x” a la mitad de las dos mediciones centrales, es decir como el valor central entre la medición con ranking “n/2” y la que tiene ranking “ $(n/2) + 1$ ”.

Reglas para calcular la mediana

- Ordenar las mediciones de menor a mayor
- Si “n” es impar, la mediana “m” es la medición con rango “ $(n + 1) / 2$ ”
- Si “n” es par, la mediana “m” es el valor de “x” que se encuentra a la mitad entre la medición con ranking “n / 2” y la medición con ranking “ $(n / 2) + 1$ ”.

datos de menor a mayor:

Estudiante	"Datos ordenados"	Valor de x_i
Roberto	1	55
Luis	2	62
Rosa	3	67
Alberto	4	68
Diana	5	69
María	6	79
Pedro	7	88
Raquel	8	89
Juan	9	92
Luisa	10	92

Como "n" es par, la mediana es igual a la mitad entre la medición con ranking " $n / 2$ " y la medición con ranking " $(n/2) + 1$ ", donde $n / 2 = 5$ y $(n / 2) + 1 = 6$.

El dato 5 vale 69 y el dato 6=79, entonces "la mediana" es igual a $69 + 79 / 2 = 74$

En este ejemplo la mediana es semejante a la media.

1.4.3 La Moda

La moda, M_o , es la medida de tendencia central más fácil de calcular y también es la más sujeta a fluctuaciones cuando cambian unos pocos valores de la distribución. Por esta razón la moda se suele usar para una evaluación rápida de la tendencia central. La moda se define como "el valor más frecuente de una distribución". En una tabla de frecuencias, la frecuencia mayor es la que contiene a la moda. Esta medida se usa más y tiene más sentido cuando se describen datos nominales, de hecho es la única medida de tendencia central que funciona con este tipo de escala.



La moda es el valor más frecuente y funciona bien con escalas nominales

Comparaciones entre las diferentes medidas

Las tres medidas de tendencia central, la media, mediana y moda, no son igualmente útiles para obtener una medida de tendencia central. Por el contrario, cada una de estas medidas tiene características que hacen que su empleo sea una ventaja en ciertas condiciones y en otras no.

La media es la medida de tendencia central, generalmente más usada y tiene la característica que incorpora todos los datos de la variable en su cálculo por lo tanto su valor suele ser más estable. Además se suele preferir en la construcción de pruebas de hipótesis, estadística inferencial. Se usa sin problema cuando las distribuciones tienen forma simétrica y no existen valores extremos atípicos.

La mediana suele ser la medida preferida cuando se emplea una escala ordinal, estas son las situaciones donde el valor asignado a cada caso no tiene otro significado más que el indicar el orden entre los casos. Por ejemplo saber en una clase cuales alumnos están dentro del 50% con mejores notas y cuales dentro del 50% con peores notas. También se suele preferir la mediana cuando unos pocos valores extremos distorsionan el valor de la media. Por ejemplo si tengo 9 personas con 0 ingresos y una sola que tiene ingresos de 10 unidades, la media dar a entender que la mayoría recibe 1 unidad, cuando esto no es real.

La moda en ciertas condiciones puede ser la más apropiada, por ejemplo cuando se quiere información rápida y cuando la precisión no sea un factor especialmente importante. En ciertos casos solo esta medida tiene sentido por ejemplo si un equipo de fútbol lleva la estadística por jugador (escala ordinal) de la cantidad de pases que realiza por juego, la Moda detecta quien es el que mejor distribuyendo la pelota, en este caso la media y la mediana no tendrían significado, solo la moda.

Aunque no necesariamente una escala de medida nos debe decir qué tipo de medida de tendencia central debemos usar, pero si nos ayuda a determinar cuál es la más apropiada.

Un aspecto interesante entre las tres medidas es su comportamiento referente a la simetría que toma una distribución. Cuando las distribuciones son simétricas, sin sesgo, caso de la distribución Normal que tiene forma de campana, “la media, la mediana y la moda coinciden”. Si la distribución es asimétrica con sesgo positivo, hay más datos hacia la izquierda de la media, entonces “la media es mayor que la mediana y esta mayor que la moda”. Si ocurre lo contrario, el sesgo es negativo, entonces “la media es menor que la mediana y ésta menor que la moda”.

1.4.4 Otras medidas de tendencia central

1.4.4.1 La Media Geométrica

La media geométrica se define como $\bar{x}_g = \sqrt[n]{x_1 x_2 x_3 \dots x_n}$, por ejemplo la media geométrica de los valores “4, 5, 4, 6” es $\bar{x}_g = \sqrt[4]{(4)(5)(4)(6)} = 4.68$

Su valor siempre es menor o igual a la media aritmética. Una ventaja de su uso es que considera todos los valores de la distribución y es menos sensible que la media aritmética a los valores extremos, sin embargo es de cálculo complicado y si un valor vale 0 se anula.

1.4.4.2 La Media Cuadrática

Se construye a partir de suma de los cuadrados de un conjunto de valores. Su forma de

cálculo es $\bar{x}_c = \sqrt{\frac{x_1^2 + x_2^2 + x_3^2 + \dots + x_n^2}{n}}$, si tomamos los valores anteriores la

media cuadrática tiene el siguiente valor $\bar{x}_c = \sqrt{\frac{4^2 + 5^2 + 4^2 + 6^2}{4}} = 4.81$

Se utiliza cuando se quiere evitar los efectos de los signos negativos. Ésta media solo puede tomar valores positivos.


1.4.4.3 Cuartiles, Deciles y Percentiles

Cuartiles: si a un conjunto de datos se ordena de mayor a menor, el valor central es la mediana, este valor divide el grupo, en dos subgrupos cada uno con el 50 % de los datos. Si a cada subgrupo ordenado se le marca el valor central, tenemos así tres

valores seleccionados que llamaremos Cuartiles, Q_1 , Q_2 y Q_3 . Estos valores dividen al conjunto de datos en cuatro grupos con igual número de términos, cada cuartil contiene el 25% de los datos. La mediana es el cuartil dos, Q_2 . Con los Cuartiles se construye un gráfico especial, “el diagrama de caja”, este permite visualizar la variabilidad de los datos por Cuartil.

En el diagrama de caja, el centro de la caja es el Q_2 , la mediana, los bordes de la caja son el Q_1 y el Q_3 . En los extremos del diagrama se trazan dos rayas horizontales que representan los valores máximo y mínimo de la distribución y que no se consideran anómalos. Para hallar los valores de las rayas se multiplica la amplitud inter cuartil ($Q_3 - Q_1$) por 1,5 y el resultado se suma a Q_3 y se resta a Q_1 . Por último, por encima y por debajo de las rayas se representan de forma individual los valores extremos y anómalos de la distribución.

Diagrama de caja, variable: cantidad de carne consumida por año.



Deciles, si el conjunto de valores, ordenados de mayor a menor, se dividen en diez partes iguales, los valores que dividen los datos se llaman deciles y son nueve, D_1 , D_2 ,... D_9 .

Percentiles, si se tiene un conjunto de datos muy numerosos y a este se lo divide en 100 partes iguales, cada valor que divide los datos se llama percentil, $P_1, P_2, P_3, \dots, P_{99}$.

1.5 Medidas de Dispersión o de Variabilidad

Las medidas de variabilidad indican la dispersión de los datos en la escala de medición y son tan importantes como las medidas de tendencia central y así como éstas son valores puntuales en una distribución, las medidas de dispersión son “intervalos”, distancias o un número de unidades en la escala de medición. Este tipo de medida se complementa con las medidas de centralidad y ambas permiten describir a la mayoría de las distribuciones. Los tipos de medidas de Dispersión más comunes son: “el Rango”, “el Desvío Estándar” y la “Varianza”.


1.5.1 El Rango

El Rango, Recorrido o Amplitud de un conjunto de mediciones, “es la diferencia entre el valor mayor y el valor menor”, indica el número necesario y mínimo de unidades, en la escala de medición, para incluir los valores mínimo y máximo. Es la medida de dispersión más fácil de calcular, pero también es la menos estable al estar fuertemente influenciada por valores extremos atípicos.

Cuanto más grande es el rango, mayor será la dispersión de los datos de una distribución. Es adecuada para medir la variación de pequeños conjuntos de datos.

1.5.2 El Desvío Estándar

El Desvío Estándar es la medida de dispersión más ampliamente usada y es la más estable ya que depende de todos los valores de la distribución. Es la media de desviación de los valores con respecto a la media, aunque una definición completa sería: “la raíz cuadrada de la suma de las desviaciones alrededor de la media, elevadas al cuadrado y divididas entre el número de casos menos uno” en el caso de “S”.



Desvío Estándar “S”: la raíz cuadrada de la suma de las desviaciones alrededor de la media, elevadas al cuadrado y divididas entre el número de casos menos uno.

Cuando se trabaja con muestras el desvío estándar se simboliza con una “S” y con la letra sigma minúscula “ σ ” cuando se usan datos de una población. Su fórmula de cálculo tradicional es:

$$\sigma = \sqrt{\left(\sum_1^N (x_i - \mu)^2\right) / N}$$

$$S = \sqrt{\left(\sum_1^n (x_i - \bar{x})^2\right) / (n - 1)}$$

Donde i es cualquier valor de “1” a “n” o “N”, y “n” es el número total de datos de la muestra y “N” de la población.

El desvío estándar, “S” o “ σ ”, se interpreta como cuanto se desvía de la media un conjunto de valores. Este valor se grafica como un intervalo, el cual tiene un valor menor que el del rango. Esta medida tiene sentido cuando las variables son cuantitativas.

Cálculo del desvío estándar “S” por suma de cuadrados, para datos no agrupados.

El desvío estándar se puede expresar también de la siguiente manera:

$$S = \sqrt{\frac{\sum_1^n x^2 - \frac{(\sum_1^n x)^2}{n}}{n - 1}}$$

Esta forma de resolución es equivalente a la forma de cálculo tradicional, es de más fácil resolución cuando se tiene calculadoras de mano que hacen sumas de cuadrados.

Cálculo del desvío estándar “S” para datos agrupados

$$S = \sqrt{\frac{\sum_{i=1}^k (x_i - \bar{x})^2 f}{n - 1}}$$

Donde “ x_i ” es la marca de clase “i”, “k” en el número de clases, “f” frecuencia por clase y “n” en número total de datos.

Ejemplo de cálculo de Desvío Estándar “S”

Con el ejemplo de las notas de matemáticas haremos cálculo de “S”

$$\begin{aligned} \text{“S”} &= \sqrt{\frac{((55 - 76.1)^2 + (62 - 76.1)^2 + (67 - 76.1)^2 + (68 - 76.1)^2 + (69 - 76.1)^2 + (79 - 76.1)^2 + (88 - 76.1)^2 + (89 - 76.1)^2 + (92 - 76.1)^2 + (92 - 76.1)^2)}{9}} \\ &= 13.6 \end{aligned}$$

Se sugiere hacer estos cálculos usando una calculadora científica en función estadística.

1.5.3 La Varianza

La varianza es el desvío estándar elevado al cuadrado y se simboliza con “ S^2 ” cuando es de una muestra, o “ σ^2 ” cuando es poblacional. Este es una medida que se usa en muchas pruebas de Hipótesis estadísticas, por ejemplo “el Análisis de Varianza, ANDEVA” que se basa en la descomposición y relación de las varianzas de las causas de variación de los datos. Pero para fines descriptivos se prefiere usar el desvío estándar en vez de la varianza, que suele ser un valor mayor y difícil de interpretar.

1.5.4 El Coeficiente de variación

El coeficiente de variación, CV, es un cociente entre el desvío estándar y la media de los datos, expresado en porcentaje, $CV = \frac{S}{\bar{x}} 100$. Este coeficiente permite comparar la variabilidad de diferentes muestras en una misma variable o la variabilidad existente

entre variables diferentes. Una investigación experimental en el campo agropecuario que tenga un CV menor al 10 %, muestra que en el experimento hubo un muy buen control del error experimental entre las diferentes repeticiones, sin embargo en procesos productivos industriales éste valor de variabilidad en una variable de salida, sería muy alto, en general se aceptan valores muy pequeños, inferiores al 1%.

Interpretación de las medidas de tendencia central y de la variabilidad.

Cabe destacar que al describir nuestros datos, debemos interpretar nuestros datos de tendencia central y de variabilidad en conjunto y no de manera separada. Con la media y el desvío estándar se pueden construir intervalos donde están la mayoría de los datos. La moda, mediana y el rango pueden completar la información sobre la distribución y así tener una buena idea de lo que sucede con la variable en estudio.

En una variable continua:

- *La media, la mediana y la moda son puntos en una recta.*
- *El desvío estándar y el rango son intervalos.*

1.6 Otras medidas útiles en Estadística Descriptiva


Cuando los polígonos de frecuencia de una variable se presentan en forma de curva hay dos medidas esenciales para describir estas curvas: “La Asimetría” y la “Curtosis”.

1.6.1 La Asimetría o Sesgo

La Asimetría es una medida necesaria para conocer cuánto se parece nuestra distribución a la distribución teórica de una “curva normal”, curva con forma de campana, y constituye un indicador del lado de la curva donde se agrupan las frecuencias. Esta medida se construye con el valor medio, la mediana y el desvío estándar. Si el valor del sesgo es cero (asimetría = 0), la curva de distribución es simétrica, en este caso coinciden los valores de la media, la mediana y la moda. Cuando el sesgo es positivo, la media es mayor que la mediana, quiere decir que hay valores agrupados hacia la izquierda de la curva y la cola de la distribución es más

larga a la derecha. Cuando el sesgo es negativo, la media es menor a la mediana, significa que los valores tienden a agruparse hacia la derecha de la curva, por encima de la media y la cola de la distribución es más larga a la izquierda. Su forma de cálculo original es: $Sesgo = \frac{3(\bar{x} - Moda)}{s}$ pero como aproximadamente se cumple que “Media – Moda = 3 (Media - Mediana)”, se usa la siguiente forma de cálculo práctico del sesgo:

$$Sesgo = \frac{3(\bar{x} - Me)}{s}$$



Histograma de consumo de cereal en Kg/ año por habitante de diferentes países. En este gráfico se observa una asimetría o sesgo positivo de 0.93, hay un agrupamiento de datos a la izquierda de la curva de distribución normal, curva en color negro.

Sesgo estandarizado, es una medida que se calcula de la siguiente manera:

$$Sesgo_{estandarizado} = \frac{Sesgo}{\sqrt{6/n}}$$

Para datos que siguen una distribución normal (ver Capítulo 3) el sesgo estandarizado debe caer dentro de un intervalo (-2,+2).

1.6.2 La Curtosis

La curtosis es una medida que indica o mide lo plano o puntiaguda que es una curva de distribución. Cuando esta es cero, curtosis = 0, significa que se trata de una curva Normal. Si es positiva, quiere decir que la curva o distribución o polígono es más puntiaguda o levantada que la curva normal (curva leptocúrtica). Si es negativa quiere decir que es más plana (curva mesocúrtica).

$$\text{Curtosis} = \frac{\sum_{i=1}^n (x_i - \bar{x})^4 / n}{s^4}$$

Curtosis estandarizada, es una medida que se se calcula de la siguiente manera:

$$\text{Curtosis}_{\text{estandarizada}} = \frac{\text{curtosis}}{\sqrt{24/2}}.$$

Para datos que siguen una distribución normal (ver

Capítulo 3) la curtosis estandarizada debe caer dentro de un intervalo (-2,+2).

Definición:

Las medidas calculadas a partir de la población, Ej. “μ” y “σ” se llaman PARÁMETROS

Las medidas calculadas a partir de las muestras, Ej. “ $\bar{x}$ ” “S” se llaman ESTADÍSTICOS

Ejercicio 1.8:

Tomando como fuente de datos las variables continuas recolectadas a partir de los datos que generen los estudiantes en clase deben construir:

- medidas de tendencia central: medias, modas, medianas.
- medidas de dispersión: desviación estándar y rango.
- distribución de frecuencias.
- espacios: $\bar{x} \pm 2$ “S” y determinar cuántos datos entran en este intervalo.
- gráficos de barras, histogramas y gráficos de pastel.

Ejercicio 1.9:

Se tiene los datos de 30 años de precipitaciones de San Ramón, Matagalpa. Calcule los datos promedios y el coeficiente de variación de los 30 años y de forma quinquenal (cada 5 años). Haga una tabla de los valores máximos y mínimos quinquenales. Comente si observa alguna tendencia de variación de lluvias.

Datos de precipitaciones, San Ramón Matagalpa

Año	Mm	Año	Mm	Año	mm
1970	1793	1980	2373	1990	1583
1971	1610	1981	1854	1991	1302
1972	1126	1982	1470	1992	1651
1973	1647	1983	1185	1993	2250
1974	1344	1984	1522	1994	1361
1975	1820	1985	1154	1995	2072
1976	974	1986	1383	1996	1869
1977	1248	1987	1335	1997	1499
1978	1530	1988	2266	1998	2980
1979	1164	1989	1038	1999	2175

1.7 Muestras y Población.

Llamaremos **población** a un conjunto homogéneo de elementos en el que se estudia una característica dada. El censo es la forma de estudio de todos los elementos de una población. Frecuentemente no es posible estudiar toda la población ya que suele ser económicamente inviable o llevar tanto tiempo que es impracticable.

Como generalmente no se puede estudiar la población, se selecciona un conjunto representativo de elementos de esta, que llamaremos **muestra**. Cuando la muestra está bien escogida podemos obtener información de la población similar a la de un censo, pero con mayor rapidez y menor costo.

La clave de un procedimiento de muestreo es garantizar que la muestra sea representativa de la población. Por lo tanto cualquier información al respecto de las diferencias entre sus elementos debe tenerse en cuenta para seleccionar la muestra, estas diferencias originan diferentes tipos de muestreo, los cuales se describen a continuación.

1.7.1 Muestreo Aleatorio Simple

Es la manera más sencilla de hacer muestreo. Decimos que una muestra es aleatoria cuando:

- Cada elemento de la población tiene la misma probabilidad de ser elegido.
- La población es idéntica en todas las extracciones de muestreo. Esta característica es irrelevante si el tamaño de la población (N) es grande en relación al tamaño de la muestra (n).

El muestreo aleatorio simple debe utilizarse cuando los elementos de la población son homogéneo respecto a las características a estudiar, es decir a priori no conocemos que elementos de la población tendrán valores altos de ella. El primer problema al aplicar esta forma de muestreo, es calcular el “n”, número de elementos de la muestra.

Cálculo de “n” por ecuación predeterminada: Cuando la fracción n / N a priori se determina que será mayor que 0.1, un método para determinar “n” de manera aproximada es el siguiente:
$$n = \frac{Npq}{(N-1)D + pq}$$

Dónde:


- Los valores “p” y “q”, probabilidades de una distribución binomial, cumplen que “ $p + q = 1$ ” y generalmente se acepta si éstos no son conocidos que “ $p = q = 0.5$ ”.
- “D” es un valor que se vincula al error de estimación prefijado donde “ $D = B^2 / 4$ ”
- “B” es el error de estimación que se debe fijar y generalmente fluctúa entre 0.01 y 0.10
- “ $p \times q$ ” es la variancia de una distribución binomial, de una pregunta dicotómica, tema que se aborda más adelante, que tiene 2 posibles respuestas por ejemplo al fabricar un producto éste puede ser Defectuoso-Aceptable.

Si bien este modelo es bastante teórico es un método muy usado para aproximar un valor de “n” entrevistados, cuando se realiza investigación social o para determinar el tamaño de muestra de un lote de piezas donde lo que se evalúa es si éstas están defectuosas o no, muestreo por atributos.

Cálculo de “n” Gráficamente: Se sabe que a más grande la muestra mejor ésta estima la media de la población, sin embargo hay un momento que la media que se calcula a partir de la muestra casi no cambia, aunque ésta aumente de tamaño, en ese momento el tamaño de la muestra comienza a ser óptimo.

Esta estabilidad de medias se puede observar gráficamente con un gráfico de medias. La primera media de este gráfico se hace con un dato de la población, el segundo con dos datos, el tercero con tres datos y así sucesivamente, hasta que en el gráfico las medias casi no fluctúen entre muestra y muestra. A continuación se muestra un ejemplo de 15 datos de notas que obtuvieron 15 estudiantes en la asignatura de Física. En la fila tercera se calcularon las medias consecutivos, con un dato, dos datos, tres datos... hasta 15 datos. Se observa que a partir de 10 datos, la media se estabiliza en el valor 75, el valor de “n”, tamaño de muestra para esta variable estaría entre 11 y 12 datos.

72	68	82	88	65	79	89	92	67	69	75	79	71	78	75
$\bar{X}_1$	$\bar{X}_2$	$\bar{X}_3$	$\bar{X}_4$	$\bar{X}_5$	$\bar{X}_6$	$\bar{X}_7$	$\bar{X}_8$	$\bar{X}_9$	$\bar{X}_{10}$	$\bar{X}_{11}$	$\bar{X}_{12}$	$\bar{X}_{13}$	$\bar{X}_{14}$	$\bar{X}_{15}$
72	70	74	77	75	76	78	79	78	77	77	77	77	77	77



Cálculo empírico para lotes y atributos. Si en un proceso industrial se tienen lotes, volumen de producción por tiempo o por cantidad de materia prima, para realizar un muestreo del proceso productivo por atributos, por ejemplo artículos sanos o defectuosos, se puede seguir el siguiente criterio, el cual es una adaptación resumida del método desarrollado por el ejército de EEUU en su norma Military Standar 414.

Tabla sobre el número de piezas a muestrear

Tamaño del Lote	% de piezas de la muestra
60-300	10
301-1000	5
1001-5000	2
+ 5000	1

1.7.2 Muestreo Estratificado

Se denomina muestra estratificada aquella en que los elementos de la población se dividen en clases o estratos. La muestra se toma asignando un número o cuota de miembros a cada estrato y escogiendo los elementos por muestreo aleatorio simple dentro del estrato.

Cuando dispongamos de información sobre la población conviene tenerla en cuenta al seleccionar la muestra. Un ejemplo clásico son las encuestas de opinión, donde los elementos (personas) son heterogéneas en algunas variables como: sexo, edad, profesión, etc. Interesa en estos casos que la muestra tenga una composición análoga a la población, lo que se consigue mediante una muestra estratificada. En concreto si existen “k” estratos de tamaño $N_1 \dots N_k$ y tales que $N = N_1 + N_2 + \dots + N_k$ se tomará una muestra “n” que garantice una presencia adecuada de cada estrato “ n_i ”.

Una forma sencilla para dividir el tamaño total de la muestra “n” entre los estratos de “ n_i ” es por el Método de Asignación Proporcional, el cual toma en cuenta el tamaño relativo del estrato de la población, por ejemplo si en la población hay un 55 % de mujeres y un 45 % de hombres, mantendremos esta proporción en la muestra. En general se hará de la manera “ $n_i = n N_i / N$ ”.

1.7.3 Muestreo por Conglomerados

Existen situaciones donde ni el muestreo aleatorio simple ni el estratificado son aplicables, ya que no disponemos de una lista con el número de elementos de la población ni en los posibles estratos. En estos casos típicamente los elementos de la población se encuentran de manera natural agrupados en conglomerados, cuyo número es conocido, por ejemplo la población rural se distribuye en comunidades y los habitantes de un barrio en manzanas. Si suponemos que cada uno de estos habitantes es parte de un conglomerado que pertenece a una población total de conglomerados semejantes para una variable dada, podemos seleccionar algunos conglomerados al azar y dentro de ellos analizar a todos sus elementos o una muestra aleatoria simple.

El muestreo por conglomerados y tiene la ventaja de simplificar la recogida de la información, no es necesario visitar todos los conglomerados para recolectar una muestra. El inconveniente obvio es que, si los conglomerados son heterogéneos entre sí, cómo se analizan solo algunos de ellos, la muestra final puede ser no representativa de la población, algo así sucede si estudio a fondo una comunidad en lo referente a un

opinión dada y se supone que los resultados son representativos de un conjunto de comunidades, pero si esta comunidad estudiada tiene opiniones distintas del resto, los resultados no serán representativos de la población, por ejemplo las poblaciones con más recursos suelen tener opiniones diferentes a las de menos recurso.

En resumen las ideas de estratificación y de conglomerados son opuestas, la estratificación funciona tanto mejor cuanto mayor sean las diferencias entre los estratos y más homogéneas sean estos internamente. Los conglomerados funcionan si hay poca diferencia entre ellos y son muy heterogéneos internamente, que incluyan toda la variabilidad de la población en el conglomerado.

1.7.4 Muestreo Sistemático

Cuando los elementos de la población están en una lista o un censo, se puede utilizar el muestreo sistemático. Supongamos que tenemos una población de tamaño “ N ” y se desea una muestra de tamaño “ n ” y sea “ K ” un valor entero más próximo a la relación “ n/N ”. La muestra sistemática se toma eligiendo al azar, con números aleatorios, un elemento entre los primeros “ K ” elementos y se denomina “ n_1 ”. El muestreo se realiza seleccionando los elementos “ $(n_1 + K)$; $(n_1 + 2 K)$, etc.” a intervalos fijos de “ K ” hasta completar la muestra. Si el orden de los elementos en la lista es al azar, este procedimiento es equivalente al muestreo aleatorio simple, aunque resulta más fácil de llevar a cabo sin errores.

Si el orden de los elementos es tal que los más próximos tienden a ser más semejantes que los alejados, el muestreo sistemático tiende a ser más preciso que el aleatorio simple al cubrir más homogéneamente toda la población.

El muestreo sistemático puede utilizarse conjuntamente con el estratificado para seleccionar la muestra dentro de cada estrato.

La regla general que se aplica a los procedimientos de muestreo es que:
“cualquier información previa debe utilizarse para asegurar mayor representatividad de la muestra”.

Ejercicio 1.10:

Suponga que quiere conocer la opinión de una comunidad donde hay 50 personas adultas, $N = 50$. ¿Cuál es el tamaño de “n” mínimo a calcular?

¿Cuál sería el valor de “n” con una ciudad de 50,000 habitantes?


Discuta que método de muestreo usaría si quiere estudiar la opinión de la gente de 12 barrios semejantes en cuanto a su nivel de vida y forma de generar sus ingresos.

Capítulo 2. Teoría Elemental de Probabilidades

Objetivos

- ☞ Definir conceptos básicos de probabilidad a partir de situaciones cotidianas.
- ☞ Aplicar las Reglas de Adición y Multiplicación de probabilidades en la resolución de problemas observables.
- ☞ Valorar la importancia de utilizar la teoría de la probabilidad condicional en modelos aplicados.
- ☞ Construir ejemplos del uso del teorema de Bayes al describir situaciones del entorno profesional.

2.1 Introducción a las Probabilidades



Con esta teoría se estudian fenómenos naturales con el fin de descubrir regularidades en la ocurrencia de los mismos. Esta ciencia comenzó a desarrollarse en la Francia Monárquica cuando los aristócratas se preocuparon en el estudio de los juegos de azar, dados, cartas, ruletas, etc. Sin embargo, hoy día, sus aplicaciones abundan en las diferentes ciencias, por ejemplo su teoría se usa en el diseño de modelos de mejoramiento genético,

análisis de experimentos, predicciones del tiempo, predicción de vida útil de un equipo, etc. En nuestra vida diaria aplicamos inconscientemente probabilidades cuando compramos un billete de lotería o llevamos un paraguas al ver el cielo nublado.

2.2 Términos Básicos.

Experimento aleatorio: Es el proceso que permite obtener una o varias observaciones, de los cuales no se puede predecir de antemano su resultado.

Espacio Muestral “ Ω ”: Todos los posibles resultados de un experimento.


Evento “A”: Algún resultado del experimento que nos interesa.

Ejemplo: Experimento: tirar un dado.

Espacio muestral " Ω "= (1, 2, 3, 4, 5, 6)

Evento "A" = sale 5.

Probabilidades, definición Clásica:



Si la probabilidad de un evento "A" se define como la frecuencia relativa de "A" en el espacio muestral " Ω " y se denota como $P(A)$.

$$P(A) = \frac{\text{\# casos favorables A}}{\text{\# casos Totales de } \Omega}$$

Es la definición más antigua y se atribuye al matemático francés Pierre Laplace (1749-1827); también se conoce con el nombre de probabilidad a priori, pues para calcularla, es necesario conocer, antes de realizar el experimento aleatorio, el espacio muestral y el número de resultados o sucesos elementales que entran a formar parte del suceso.

La aplicación de la definición clásica de probabilidad puede presentar dificultades de aplicación cuando el espacio muestral es infinito o cuando los posibles resultados de un experimento no tienen iguales probabilidades. Por ejemplo En un proceso de fabricación de artículos puede haber piezas defectuosas, si queremos determinar la probabilidad de que una pieza sea defectuosa, no podemos utilizar la definición clásica pues necesitaríamos conocer previamente el resultado del proceso de fabricación. Para resolver estos casos, se hace una extensión de la definición de probabilidad, de manera que se pueda aplicar con menos restricciones, llegando así a la definición frecuencial de probabilidad

Probabilidades, definición frecuencial:

$$P(A) = \lim_{n \rightarrow \infty} \frac{n(A)}{n}$$

La definición frecuencial define la probabilidad de la proporción o frecuencia relativa del suceso como el límite cuando “n” tiende al infinito. Es imposible llegar a este límite, ya que no podemos repetir el experimento un número infinito de veces, pero si podemos repetirlo muchas veces y observar como las frecuencias relativas tienden a estabilizarse.

En esta definición frecuencial, la probabilidad se llama también probabilidad a posteriori, ya que sólo podemos dar la probabilidad de un suceso después de repetir y observar un gran número de veces el experimento aleatorio correspondiente. En un experimento aleatorio, en la medida que aumenta “n”, la frecuencia relativa de un suceso se aproxima cada vez más a su probabilidad teórica, esto se conoce como la Ley de los Grandes Números.

Un ejemplo de cómo construir probabilidades, en una región se toma una muestra de 800 fincas de las cuales 640 siembran frijol de forma manual y 160 con bueyes. En este caso hay 2 eventos: Siembra manual y Siembra con bueyes y existen las probabilidades, P (bueyes) y la P (manual), asociados ambas a la frecuencia de ocurrencia de cada evento. Se estima que la probabilidad de elegir una parcela al azar y que ésta fue sembrada con bueyes, P (bueyes) es de $160/800 = 0.20$ ó 20 %.



2.3 Propiedades de la Probabilidad

Las probabilidades tienen ciertas propiedades como:

- Esta es un valor en el intervalo “0-1”, $0 \leq P(A) \leq 1$
- Si el evento A es más probable que B $\Leftrightarrow P(A) \geq P(B)$
- Un Evento cierto, que seguramente ocurre, tiene probabilidad 1.
- Un Evento imposible, que nunca ocurrirá, tiene probabilidad 0.
- Tiene dos reglas básicas que la estructuran: la regla de la suma y la regla del producto.

2.3.1 Regla de la Suma.

La regla general de la suma de probabilidades de dos eventos es:

$P(A \text{ ó } B) = P(A + B) = P(A) + P(B) - P(AB)$, lo que es equivalente a:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Siendo: $A \cup B = A$ “unión” B

Un caso especial más sencillo sucede si dos eventos “A” y “B” son incompatibles, esto quiere decir que los eventos “A” y “B” no pueden ocurrir al mismo tiempo $P(A \cap B) = 0$. (Un ejemplo de eventos incompatibles es cuando se tira una vez un dado y que salgan al mismo tiempo el número 1 y el número 6.)

En casos de eventos incompatibles la probabilidad que ocurra “A” ó “B” es $P(A \text{ ó } B) = P(A) + P(B) = P(A \cup B)$

Ejemplo, si se arroja dos veces una moneda al aire, la probabilidad que salga una vez “escudo” y el otro “número” sin importar el orden, es la probabilidad de los eventos “escudo, número” y “número, escudo”. Debido a que son cuatro los eventos posibles “ Ω ”= escudo –número, número –escudo, número – número y escudo-escudo y cada uno con igual probabilidad, cada uno de estos eventos tiene una $P = 0.25$, de ocurrencia. Por lo tanto la ocurrencia de “escudo-número” más “número –escudo” es de “ $P(n, e) + P(e, n)$ ”, que en valor de probabilidades es de **$P(0.25) + P(0.25) = 0.5$**

Ejercicio 2.1. En la matrícula de primer año de la universidad, 150 estudiantes son originarios del departamento de Estelí, 60 estudiantes del departamento de Nueva Segovia y 100 estudiantes del resto del país. ¿Cuál es la probabilidad que un estudiante tomado al azar no sea del departamento de Estelí?

Ejercicio 2.2. Si la probabilidad anual de que en una ciudad ocurra un movimiento telúrico mayor de 5 grados Richter es del 0.01 y la probabilidad que se inunde por

lluvias es del 0.02 anual. ¿Cuál es la probabilidad que en un mismo año la ciudad sufra un terremoto y una inundación?

Ejercicio 2.3. Se hace un juego donde se tira un dado una vez, y se gana si sale el número 1,2 ó 3. Si sale un número diferente se pierde. ¿Qué es más probable perder o ganar?

2.3.2 Regla del producto.

Si dos eventos “A” y “B” son **independientes**, si “A” no influye de ninguna manera en “B” y viceversa. Entonces la probabilidad que los eventos independientes “A” y “B” ocurran al mismo tiempo es $P(A \text{ y } B) = P(A \cap B) = P(A) \times P(B)$. Siendo $A \cap B$ la “intersección” B.

Por ejemplo si la Probabilidad de un nacimiento de un niño es 0.5, $P(\text{niño}) = 0.5$, la probabilidad que dos mujeres en su primer parto tengan hijos varones es un evento independiente, uno no influye sobre otro, la $P(\text{niño, niño})$ es de $0.5^2 = 0.25$.

Una paradoja es que una persona que compra todas las semanas la lotería, para un sorteo dado, tiene la misma probabilidad de sacar el premio mayor que una persona que compró un número por primera vez.

Ejercicio 2.4: Estime la probabilidad que al elegir por sorteo dos estudiantes del grupo de clase, ambos sean varones. Considere que la misma persona elegida en el primer sorteo puede ser elegida en el segundo. Determinar también cuáles eventos forman “ Ω ” es este caso.

2.4 Probabilidad condicionada

Como la probabilidad está ligada a nuestra ignorancia sobre los resultados de la experiencia, el hecho de que ocurra un suceso, puede cambiar la probabilidad de los demás resultados que ocurran luego. El proceso de realizar la historia de un caso, explorar y realizar pruebas complementarias ilustra este principio, cuando más se conoce de lo que ocurrió, mejor se puede predecir el futuro, la “probabilidad condicionada” se nutre de este principio.

La probabilidad de que ocurra el suceso “A” dado que ha ocurrido el suceso “B” es la “ $P(A|B)$ ”, se denomina probabilidad condicionada y se define.

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad \text{Si } P(B) \neq 0$$

De lo anterior se deduce que: $P(A \cap B) = P(A|B) P(B)$

La condición que $P(B) > 0$, es necesaria para una buena definición de probabilidad condicional. Es de notar que si A y B son sucesos independientes, la $P(A|B)$ es igual a la $P(A)$, es otro enfoque de mirar independencia. Cómo regla general se enuncia que:

Dos eventos A y B son independientes si y sólo si: $P(A|B) = P(A)$ y $P(B|A) = P(B)$ que es lo mismo: $P(A \cap B) = P(A) \times P(B)$

Ejemplo: Se conoce que los estudiantes de la UNI tienen las siguientes preferencias en el consumo de gaseosas:

Consumo de Gaseosas por semana	Varones	Mujeres	Total
No consume	30	10	40
1-5 veces	50	25	75
Más de 5 veces	20	15	35

Total	100	50	150
-------	-----	----	-----

Si de un grupo de jóvenes del bar de la universidad, se selecciona al azar un estudiante varón ¿Cuál es la probabilidad que ese que ese joven haya consumido más de 5 gaseosas por semana? En este problema ya no es necesarios conocer el número total de estudiantes, porque al seleccionar a un individuo del sexo masculino, los individuos del sexo femenino no son tomados en cuenta. Entonces se puede definir la probabilidad deseada como ¿Qué probabilidad existe de que un individuo beba más de 5 gaseosas a la semana dado que el individuo seleccionado sea varón? Esta es una probabilidad condicional y se resuelve de la siguiente manera:

$$P(C_{+5}|S_v) = \frac{P(C_{+5} \cap S_v)}{P(S_v)} = (20/150) / (100/150) = 20/100 = 0.2, \text{ donde "C" es por consumo y "S" por sexo.}$$

Ejercicio 2.5 Si se tiene una escuela de 200 alumnos distribuidos en tres aulas: A, B y C. Por sexo: mujer, y varón; como sigue:

Aula/ Sexo	Varón	Mujer
A	20	20
B	30	30
C	56	44
Total	106	94

¿Cuál es la probabilidad que un estudiante, sin importar el sexo, sea del aula B?

¿Cuál es la probabilidad que un estudiante que pasa por el corredor sea del aula A, si el estudiante es mujer?

Ejercicio 2.6 En un aula hay 6 estudiantes realizando un examen, dos son mujeres y cuatro son varones. ¿Cuál es la probabilidad que finalice una mujer de segunda dado que el primero en finalizar fue un hombre?

Si la solución es:

$$P(M \setminus V) = \frac{P(M \cap V)}{P(V)} = \frac{8/30}{4/6} = \frac{2}{5}$$


¿Explicar cómo se construyeron los valores 8/30 y 4/6?

2.5 Teorema de Bayes

2.5.1 Regla de la probabilidad total


Si se tiene una partición de sucesos A_i que son un conjunto de sucesos mutuamente excluyentes y que cubren todo el espacio muestral.

$$A_1 \cup A_2 \cup \dots \cup A_n = \Omega \text{ y } A_i \cap A_j = \emptyset \quad \forall i \neq j$$



Y si el conjunto de sucesos A_i que forman una partición del espacio muestral y sucede que $p(A_i) \neq 0 \quad \forall A_i$. Entonces si ocurre un suceso B dentro del mismo espacio muestral y se cumple que:

$$P(B) = P(B \cap A_1) + P(B \cap A_2) + \dots + P(B \cap A_n)$$



Entonces se llamara a $P(B)$ como “*probabilidad total*”, la cual se puede interpretar como una media ponderada de los diferentes $P(B|A_i)$.

$P(B)$ también se puede expresar cómo la sumatoria de las probabilidades condicionadas por la probabilidad del evento A correspondiente.

$$P(B) = P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + \dots + P(B|A_n)P(A_n) = \sum_{i=1}^n P(B|A_i)P(A_i)$$


2.5.2 Planteo del Teorema de Bayes

El teorema de Bayes, enunciado por Thomas Bayes y publicada por primera vez en 1763, parte de una situación en la que ocurran una serie de sucesos A_i que son una partición completa de un espacio muestral Ω y donde $P(A_i) \neq 0$. Pero también dentro del mismo espacio muestral existe un suceso B , tal que $P(B) \neq 0$, y que las probabilidades de ocurrencia de B son distintas según el suceso A_i que haya ocurrido, tal como se explica en la regla de la probabilidad total.

Conociendo que ha ocurrido el suceso B , la fórmula del teorema de Bayes nos indica como modifica esta información las probabilidades de los sucesos A_i . Se resalta que al disponer información de B se cambian las probabilidades de A_i . El teorema se presenta algebraicamente de la siguiente manera:

$$P(A_i \setminus B) = \frac{P(B \setminus A_i)P(A_i)}{\sum_{i=1}^n P(B \setminus A_i)P(A_i)}$$

Ejemplo con los datos de preferencias de consumo de gaseosas de los estudiantes de la UNI se puede construir el siguiente diagrama de Bayes:



Resolviendo por Bayes, la probabilidad que una mujer no consuma gaseosas es:

$$P(\text{NoC} \setminus M) = \frac{P(M \setminus \text{NoC})P(\text{NoC})}{P(M \setminus \text{NoC})P(\text{NoC}) + P(M \setminus 1-5)P(1-5) + P(M \setminus +5)P(+5)}$$

$$P(\text{NoC} \setminus M) = \frac{0.27 (0.25)}{0.27 (0.25) + 0.50 (0.33) + 0.23 (0.43)} = 0.20$$

Ejercicio resuelto usando el teorema de Bayes:

Tres máquinas, A, B y C, producen el 45%, 30% y 25%, respectivamente, del total de las piezas producidas en una fábrica. Los porcentajes de producción defectuosa de estas máquinas son del 3%, 4% y 5%.

- Seleccionamos una pieza al azar; calcula la probabilidad de que sea defectuosa.
(probabilidad Total)


- b. Tomamos, al azar, una pieza y resulta ser defectuosa; calcula la probabilidad de haber sido producida por la máquina *B*.
- c. ¿Qué máquina tiene la mayor probabilidad de haber producido la citada pieza defectuosa?

Sea D = "la pieza es defectuosa" y N = "la pieza no es defectuosa". La información del problema puede expresarse en el diagrama de árbol adjunto.

- a. Para calcular la probabilidad de que la pieza elegida sea defectuosa, $P(D)$, por la propiedad de la probabilidad total,

$$\begin{aligned}
 P(\text{Total}) = P(D) &= P(A) \cdot P(D|A) + P(B) \cdot P(D|B) + P(C) \cdot P(D|C) = \\
 &= 0.45 \times 0.03 + 0.30 \times 0.04 + 0.25 \times 0.05 = 0.038
 \end{aligned}$$

Resolución por diagrama de árbol. Un diagrama de árbol es una representación gráfica de un experimento que consta de pasos, donde cada uno de los pasos tiene un número finito de maneras de ser llevado a cabo.



- b. Debemos calcular $P(B|D)$. Por el teorema de Bayes,

$$P(B|D) = \frac{P(B)P(D|B)}{P(A)P(D|A) + P(B)P(D|B) + P(C)P(D|C)}$$

$$\frac{0.3(0.04)}{0.45(0.03) + 0.3(0.04) + 0.25(0.05)} = \frac{12}{38} = 0.316$$

- c. Calculamos $P(A|D)$ y $P(C|D)$, comparándolas con el valor de $P(B|D)$ ya calculado. Aplicando el teorema de Bayes, obtenemos:

$$P(A|D) = \frac{0.45(0.03)}{0.45(0.03) + 0.3(0.04) + 0.25(0.05)} = \frac{135}{380} = 0.355$$

$$P(C|D) = \frac{0.25(0.05)}{0.45(0.03) + 0.3(0.04) + 0.25(0.05)} = \frac{125}{380} = 0.329$$

La máquina con mayor probabilidad de haber producido la pieza defectuosa es la A, sin embargo las tres máquinas tienen probabilidades semejantes de producir piezas defectuosas.

Ejercicio 2.7 El reporte meteorológico ha anunciado tres posibilidades para el día de mañana: que llueva: probabilidad del 50%, que salga el sol: probabilidad del 30% y que esté nublado: probabilidad del 20%.

Según estos posibles estados meteorológicos y datos históricos de comportamiento vehicular, la posibilidad de que ocurra un accidente es la siguiente: si llueve: probabilidad de accidente del 20%, si sale el sol: probabilidad de accidente del 10% y si está nublado: probabilidad de accidente del 5%. Si se sabe que ocurrió un accidente, ¿Cuál es la probabilidad de que haya llovido?

¿Cuál es la probabilidad de que haya salido el sol?

¿Cuál es la probabilidad de que haya estado nublado?

Ejercicio 2.8 Cierta artículo es manufacturado por tres fábricas: F1, F2 y F3. Se sabe que la primera produce el doble de artículos que la segunda y que ésta (F2) y la tercera producen el mismo número de artículos (durante un período de tiempo especificado, el

mismo para las tres). Se sabe también que el 1.5% de los artículos producidos por las dos primeras fábricas es defectuoso, mientras que en la tercera los es el 3.5%.

Se colocan juntos todos los artículos producidos por las tres fábricas y se escoge uno al azar.

¿Cuál es la Probabilidad de que un artículo sea Defectuoso?

¿Cuál Fábrica tiene la mayor probabilidad de haber producido el artículo Defectuosos?

2.6 Técnicas de conteo: Combinaciones y Permutaciones

Las técnicas de conteo son aquellas que son usadas para enumerar eventos difíciles de cuantificar de forma directa. Estas técnicas sirven para construir probabilidades. Dentro de estas técnicas tenemos las combinaciones y las permutaciones.

Combinaciones:

La expresión " $C_{m,n}$ " representa las combinaciones de "m" elementos, formando subgrupos de "n" elementos. Con esta técnica no se toma en cuenta el orden de los elementos de cada subgrupo. Para calcular el número de combinaciones se aplica la siguiente fórmula:

$$C_{mn} = \frac{m!}{n!(m-n)!}$$

El término " $n!$ " se denomina "factorial de n" y es la multiplicación de todos los números que van desde "n" hasta 1. Por ejemplo: $4! = 4 \times 3 \times 2 \times 1 = 24$

Ejemplo: Si tomamos el conjunto $A = \{a, b, c, d\}$, ¿cuántos subconjuntos de 2 elementos cada uno se pueden obtener?

Haciéndolos se obtienen: $\{a, b\}$, $\{a, c\}$, $\{a, d\}$, $\{b, c\}$, $\{b, d\}$, $\{c, d\}$. Son seis los

subconjuntos. $C_{4,2} = \frac{4!}{2!(4-2)!} = 6$

Ejemplo: Cuantas combinaciones de 10 elementos agrupándolos en subgrupos de 4 elementos sin importar el orden se pueden obtener: $C_{10,4}$

$$C_{10,4} = \frac{10!}{4!(10-4)!} = \frac{10 \cdot 9 \cdot 8 \cdot 7 \cdot 6 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1}{(4 \cdot 3 \cdot 2 \cdot 1)(6 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1)} = 210$$

Se pueden formar 210 subgrupos diferentes de 4 elementos, a partir de los 10 elementos.

Ejemplo: Un grupo de clases está compuesto por 17 mujeres y 20 varones ¿cuál es la probabilidad que entre los dos mejores estudiantes, 1 sean mujer y 1 varón?

$$\text{Probabilidad } (1_m, 1_v) = \frac{C_{17,1} C_{20,1}}{C_{37,2}} = \frac{17(20)}{666} = 0.51$$

Permutaciones:

La expresión "**P_{m,n}**" representa las variaciones de "m" elementos, formando subgrupos de "n" elementos. En este caso, un subgrupo se diferenciará del resto, bien por los elementos que lo forman, o bien por el orden de dichos elementos. Para calcular el número de permutaciones se aplica la siguiente fórmula:

$$P_{mn} = \frac{m!}{(m-n)!}$$

Ejemplo: Sea A= letras {a, b, c, d}, ¿cuántos subgrupos de dos letras se pueden obtener?

Lo que se pide es formar permutaciones u ordenaciones de 2 letras, cuando el total de letras es 4. $P_{(4,2)}$ En este caso $n=2$ y $m=4$. Las "palabras" de 2 letras formadas son: ab, ac, ad, ba, bc, bd, ca, cb, cd, da, db, dc. En total son 12.

$$P_{4,2} = \frac{4!}{(4-2)!} = 12$$

Ejemplo: Las permutaciones de 10 elementos agrupándolos en subgrupos de 4 elementos, $P_{(10,4)}$, son:

$$P_{10,4} = \frac{10!}{(10-4)!} = \frac{10 \cdot 9 \cdot 8 \cdot 7 \cdot 6 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1}{(6 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1)} = 5,040$$

Podríamos formar 5.040 subgrupos diferentes de 4 elementos, a partir de los 10 elementos.

Ejercicio 2.9. De entre 9 personas debemos formar un equipo técnico de 3 individuos. ¿Cuántas diferentes formas existen para formar el equipo?

Ejercicio 2.10. Una persona tiene 4 CD diferentes de música clásica y 3 CD de música moderna, determine de cuantas maneras diferentes:

- a) Puede acomodar solo los CD de música clásica en un estante.
- b) Si acomoda todos los CD a la vez.

Ejercicio 2.11. Una persona olvido su clave de acceso a una caja fuerte, la clave está formada por 3 números, determina cuantas formas diferentes puede tener la clave si no se permite repetir los números.

Capítulo 3. Variables aleatorias y sus distribuciones.

Objetivos

- ☞ Aplicar el concepto de variable aleatoria con ejemplos del campo laboral.
- ☞ Explicar las distribuciones de variables discretas y continuas más usadas en la resolución de problemas de investigación de las ingenierías.

3.1 Distribuciones de Frecuencia, Introducción.

“Los modelos estadísticos son un puente entre la muestra observada y la población desconocida.”

Hasta éste capítulo nos hemos ocupado de descripciones de muestras usando tablas, gráficos y medidas como la media y la varianza. Pero generalmente nuestro interés va más allá que una simple descripción, suele haber interés en tratar de generalizar los resultados de la muestra hacia el grupo total, es decir la Población. Para generalizar podemos usar modelos estadísticos teóricos diseñados por estadísticos famosos como Poisson, Gosset, Fisher y otros.

Hoy en día los modelos estadísticos teóricos son frecuentemente utilizados para observar y comprender fenómenos naturales o productivos que implican el estudio de variables con sus características en poblaciones de datos. El instrumento conceptual que permitirá esta generalización es un modelo de la población, es decir una representación simbólica de su comportamiento. Los modelos estadísticos van a actuar de puente entre lo observado, la muestra y lo desconocido, la población.

Las distribuciones de probabilidad están relacionadas con las distribuciones de frecuencias. Una distribución de frecuencias teórica es una distribución de probabilidades que describe la forma en que se espera que varíen los resultados

empíricos. Debido a que estas distribuciones tratan sobre expectativas de que algo suceda, resultan ser modelos útiles para hacer inferencias y para tomar decisiones en condiciones de incertidumbre.

Las distribuciones de probabilidad son idealizaciones de los polígonos de frecuencias. En el caso de una variable estadística continua consideramos el histograma de frecuencias relativas, y se puede comprobar que al aumentar el número de datos y el número de clases el histograma tiende a estabilizarse llegando a convertirse su perfil en la gráfica de una función.

Una distribución de frecuencias son las frecuencias observadas de todos los resultados de un experimento que se presentaron cuando ya se efectuó el experimento, es empírica. Mientras que una distribución de probabilidad es un listado de las probabilidades de todos los posibles resultados que podrían obtenerse si el experimento se va a llevar a cabo, es teórica.

Las distribuciones de probabilidad pueden basarse en consideraciones teóricas o en una estimación subjetiva de la posibilidad. Se pueden basar también en la experiencia. Las distribuciones de probabilidad se clasifican en “continuas y discretas”. En la distribución de probabilidad “discreta” la variable aleatoria, la que toma los posibles resultados del experimento, sólo toma un número limitado de valores, por ejemplo que un ladrillo tomado “sea defectuoso” o “no”.

En una distribución de probabilidad continua, la variable que se está considerando puede tomar cualquier valor dentro de un intervalo dado, por ejemplo “los ladrillos de

una población que pesen entre 1,5-1,6 Kg”. Las distribuciones discretas se asemejan a las distribuciones continuas, cuando éstas tienen muchos resultados posibles, todos muy cercanos entre sí.

3.2 Variables aleatorias.

Una variable es aleatoria si toma los valores de los resultados de un experimento aleatorio. Esta variable puede ser discreta o continua. De manera general se puede decir que si el experimento toma un número finito de valores o un número infinito pero numerable, que se puede contar, tenemos una variable aleatoria discreta. En el otro extremo, si el experimento puede tomar cualquier valor dentro de un intervalo dado, entonces se trata de una variable aleatoria continua, generalmente estas son las variables que se miden o se pesan. Las variables aleatorias definidas sobre espacios discretos se llaman variables aleatorias discretas y las definidas sobre espacios continuos se llaman continuas.

Se puede pensar en una variable aleatoria como un valor o una magnitud que cambia de una presentación a otra, sin seguir una secuencia predecible. Los valores de una variable aleatoria son los valores numéricos correspondientes a cada posible resultado de un experimento aleatorio. Una variable aleatoria asocia un número o más generalmente una característica a todo resultado posible del experimento. Por ejemplo, si consideramos el experimento que consiste en realizar mediciones de la concentración de un producto en una solución, nos interesa la variable aleatoria $X =$ “valor medido de la concentración de azúcar en una salsa.” Otro ejemplo de variable aleatoria asociada a un proceso de fabricación, al experimento de escoger un elemento producido, y considerar la variable aleatoria $X =$ “duración de vida de un monitor de una computadora hasta el fallo”. Ambas variables anteriores son continuas. Un ejemplo de variable aleatoria discreta es el número de televisores fallados por lote de producción mensual.

Función de densidad de probabilidad: Es la función que mide la concentración de la probabilidad alrededor de los valores de una variable aleatoria. A cada valor de una variable aleatoria discreta o a un intervalo de una variable aleatoria continua, le corresponde una probabilidad asociada. Ejemplo: Si en un hospital se espera que nazcan tres bebés. Representamos “varón” por v y “niña” por $\tilde{n}$.


El espacio muestral $\Omega = \{vvv, vv\tilde{n}, v\tilde{n}v, \tilde{n}vv, v\tilde{n}\tilde{n}, \tilde{n}v\tilde{n}, \tilde{n}\tilde{n}v, \tilde{n}\tilde{n}\tilde{n}\}$

La probabilidad de cada suceso elemental es $1/8$. Por ejemplo $p(vvv) = 1/8$, ya que la probabilidad de nacer un varón en un nacimiento es aproximadamente un $1/2$ y cómo los nacimientos son independientes, $p(vvv) = (1/2)^3$.

Si se define la variable aleatoria. X : “número varones nacidos en 4 partos”, la cual puede tomar los valores $\{0, 1, 2, 3, 4\}$. Se buscan todos sucesos de la muestra que dan lugar a cada valor de la variable y a ese valor se le asigna la probabilidad del suceso correspondiente.

X	Sucesos	p_x
0	$\{\tilde{n}\tilde{n}\tilde{n}\tilde{n}\}$	$1/16$
1	$\{\tilde{n}\tilde{n}\tilde{n}v, \tilde{n}\tilde{n}v\tilde{n}, \tilde{n}v\tilde{n}\tilde{n}, v\tilde{n}\tilde{n}\tilde{n}\}$	$4/16$
2	$\{\tilde{n}\tilde{n}vv, \tilde{n}v\tilde{n}v, \tilde{n}vv\tilde{n}, v\tilde{n}v\tilde{n}, vv\tilde{n}\tilde{n}, v\tilde{n}\tilde{n}v\}$	$6/16$
3	$\{\tilde{n}vvv, v\tilde{n}vv, vv\tilde{n}v, vvv\tilde{n}\}$	$4/16$
4	$\{vvvv\}$	$1/16$

A esta función p_x se le denomina *función densidad de probabilidad (f_x)*, que actúa de distinta manera en las variables discretas que en las continuas. En el caso de las variables discretas, como en el ejemplo, es una función que da una probabilidad a cada valor de la variable.



Sin embargo para las variables continuas la probabilidad de que una variable tome cualquier valor concreto es 0, por lo tanto la f_x sólo permite calcular la probabilidad para un intervalo del tipo $(a < X < b)$, mediante el cálculo de la integral correspondiente. Para simplificar el cálculo con variables aleatorias continuas, se aproximan estas a funciones conocidas y con tablas de probabilidades, ahora con programas computacionales, se pueden buscar los valores de $P(a < X < b)$.

Distribución acumulativa o función de distribución. Función que acumula probabilidades asociadas a una variable aleatoria. Su notación es $F(x) = p(X \leq x)$. Para el ejemplo anterior, $F(X)$ es:

X	f_x	F_x
0	1/16	1/16
1	4/16	5/16
2	6/16	11/16
3	4/16	15/16
4	1/16	16/16

En variables continuas $F(X) = P(X \leq a) = \int_{-\infty}^a f(x)dx$

La probabilidad de que la variable esté dentro de un intervalo $[a - b]$ se calcula:

$$P(a \leq x \leq b) = F(b) - F(a)$$

La probabilidad de que la variable continua tome un valor particular se puede expresar como: $F(c) - F(c) = 0$. Esto explica la idea de que para el caso de una variable aleatoria continua no tiene sentido trabajar con la probabilidad de un valor particular, ya que esta vale 0. Por ejemplo de una población de personas, la probabilidad que una persona mida exactamente 1.75000... cm es de cero. Sin embargo hay probabilidad para un intervalo dado de altura como 1,70-1.80 cm, esto es un área bajo una curva de probabilidad.

Parámetros característicos de una función de densidad de probabilidad, esperanza y varianza.

Valor esperado o esperanza matemática o promedio

$$\mu_X = E(X) = \sum x f(x) \quad \text{Caso discreto}$$

$$\mu_X = E(X) = \int_{-\infty}^{\infty} x f(x) dx \quad \text{Caso continuo}$$

Cambio de variable, si X es una variable aleatoria cualquier función de ella, $h(x)$, es también una variable aleatoria, en consecuencia también se define el promedio es esta nueva variable aleatoria de la siguiente manera.

$$\mu_X = E[h(x)] = \sum h(x) f(x) \quad \text{Caso discreto}$$

$$\mu_X = E[h(x)] = \int_{-\infty}^{\infty} h(x) f(x) dx \quad \text{Caso continuo}$$

Ejemplo con una variable discreta: Si en una bolsa tengo 5 marcadores de 5 colores diferentes: azul, amarillo, negro, rojo, verde. Y el experimento consiste en extraer un marcador y observar su color ¿Cuál es la probabilidad media?

La variable “X” solo puede tomar el valor 1 y para todos los colores $f(x) = 1/5$. En consecuencia la media es

$$\mu_x = \sum_{x=1}^5 x f(x) = 1 \frac{1}{5} + 1 \frac{1}{5} + \dots + 1 \frac{1}{5} = 1$$

Si se define ahora una nueva función sobre “X”: $h(x)$ = “C\$ a pagar”, qué se define de la siguiente manera, al sacar un marcador de la bolsa: si X sale azul o amarillo $h(x)$ 90 C\$, si X sale negro $h(x)$ 450 C\$ y si X sale rojo o verde $h(x)$ es 0 C\$.

X	h(x)
1	90
2	90
3	450
4	0
5	0

¿Cuál es el valor medio de esta nueva función?

$$\mu_x = \sum_{x=1}^5 h(x) f(x) = 90 \frac{1}{5} + 90 \frac{1}{5} + 450 \frac{1}{5} + 0 + 0 = 126$$

¿Qué significa 126? es el valor promedio luego de jugar mucho tiempo, si se juega un número grande de veces el juego de sacar un marcador de la bolsa reponiendo el marcador que sale, la ganancia final esperada sería como si por cada jugada se hubiera ganado 126 C\$. Si la apuesta por jugar costara menos de esto, el juego sería ventajoso para el jugador, si costara más, sería ventajoso para el casino. Se debe considerar que el juego sería justo si la apuesta costara exactamente 126 C\$, igual probabilidades de ganar por el casino y por el jugador. Como regla general los juegos de azar son injustos para el jugador y ventajosos para el casino. La experiencia y la estadística nos enseñan que el jugador consuetudinario de juegos de azar, a la larga siempre pierde, por dos motivos: juega con desventaja de probabilidades y con menos capital que el casino.

Varianza

Es una medida de variabilidad de la variable aleatoria y se define como:

$$\sigma_x^2 = E(x - \mu_x)^2$$

Para el cálculo se usa ésta otra fórmula equivalente:

$$\sigma_x^2 = E(x^2) - \mu_x^2$$

La varianza mide la dispersión de la variable aleatoria alrededor de la media. Ejemplo de cálculo de varianza: si ocurren tres nacimientos de bebés, la esperanza y la varianza de la variable aleatoria X “varones nacidos” es:

$$E(X) = 0 \times 1/8 + 1 \times 3/8 + 2 \times 3/8 + 3 \times 1/8 = 3/2 = 1,5$$

$$\sigma_x^2 = E(x^2) - \mu_x^2 = 0^2 \times 1/8 + 1^2 \times 3/8 + 2^2 \times 3/8 + 3^2 \times 1/8 - (3/2)^2 = 3/4$$

$$\sigma_x = \sqrt{\sigma_x^2} = \sqrt{3/4} = 0.866$$

Ejercicio 3.1: En los casinos el juego de ruleta mesa tiene 38 números, esto incluye el número 0 y doble 00. Si usted apuesta una moneda a un número y gana, el casino le paga 36 monedas. ¿Este es un juego justo? Justificar la respuesta.

El Desvío Estándar y el Teorema de Chebyshev

La desigualdad de Chebyshev, matemático Ruso del siglo XIX, dice que la probabilidad de que una variable aleatoria “x” esté distanciada de su media en más de “a” veces la desviación estándar, es menor o igual que $\frac{1}{a^2}$. Si E(x) es la media (o la esperanza matemática) y σ es el desvío estándar, entonces podemos definir la siguiente relación:

$$P(|x - E(x)| \geq a\sigma) \leq \frac{1}{a^2}, \text{ por ejemplo si } a = 2$$

$$P(|x - E(x)| \geq 2\sigma) \leq 0.25 \text{ ó } P(|x - E(x)| < 2\sigma \geq 0.75)$$

Tomando en cuenta el teorema de Chebyshev se pueden asumir las siguientes reglas sobre el uso del desvío estándar:

Sin importar el tipo de distribución de los datos, se cumple que:

- El intervalo $\bar{x} \pm 2$ “S” contendrá al menos $\frac{3}{4}$ de los datos.
- El intervalo $\bar{x} \pm 3$ “S” contendrá al menos $\frac{8}{9}$ de los datos.

Ejercicio 3.2 Una industria produce ventanas cuya ancho tiene una media de 250 cm y una desviación estándar de 1.80 cm ¿Construya un intervalo donde se encuentre al menos el 8/9 de los datos?

3.3 Distribución Normal


La distribución Normal es un modelo teórico desarrollado por el matemático Abraham de Moivre en 1773, y que comúnmente es aproximado en fenómenos naturales que generan variables aleatorias y continuas. Esta representa la distribución de frecuencias de una población de valores que hoy conocemos como *curva normal*, la cual tiene forma de una campana simétrica. Esta depende para su construcción de dos parámetros:

- μ media poblacional, que se localiza en el centro de la del eje horizontal.
- σ desviación estándar poblacional.

Para una variable “x” con media μ y desviación estándar σ que está normalmente distribuida, escribimos: “x” es $N(\mu, \sigma)$. La función de densidad de la distribución normal es:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Ejemplo de una distribución de frecuencias de mg. de aflotoxinas (toxinas) en muestras de maíz y la curva Normal teórica.




Características de una distribución Normal. Si un Distribución de datos empíricos tiene aproximadamente el perfil o forma de campana normal se cumple que:

- El intervalo $\mu \pm \sigma$ contendrá aproximadamente el 68 % de los datos.
- El intervalo $\mu \pm 2 \sigma$ contendrá aproximadamente el 95 % de los datos.
- El intervalo $\mu \pm 3 \sigma$ contendrá aproximadamente casi la totalidad de los datos, 99.74 %.

Un tipo de distribución Normal especial es la distribución Normal Tipificada (0,1), simbolizada con la letra “Z”. Esta distribución se usa mucho en pruebas de hipótesis ya que cualquier dato “ x_i ” de una variable normal (μ, σ) se puede convertir en dato “ z_i ” de una variable normal tipificada con la siguiente transformación:

$$Z_i = \frac{x_i - \mu}{\sigma}$$


Luego con una tabla normal tipificada es fácil determinar probabilidades por intervalos para diferentes valores de la variable “x”. Esta distribución funciona relativamente bien para hacer probabilidades cuando se tiene más de 30 datos, y estos tienen una distribución en forma de campana. A continuación se observa un gráfico de una distribución normal tipificada (0,1) donde está sombreado un intervalo de ± 1.96 desvío estándar.



Ejercicio 3.3. Si la media de edad de los alumnos de la universidad es de 21 años, con un desvío estándar de 3.2 años. ¿Cuál es la probabilidad que un estudiante tenga más de 28 años?

$Z_{28} = \frac{(28 - 21)}{3.2} = 2.1875$, se debe buscar la $P (z_i \geq 2,1875)$ en una tabla

normal tipificada que resulta como $0.5 - 0.4854$ (el valor de tabla) = 0.014. Este problema se puede resolver gráficamente usando el programa INFOSTAT, con el módulo aplicaciones didácticas.



El área sombreada es la respuesta, que un estudiante tenga más de 28 años y tiene una probabilidad de 0,014.

Ejercicio 3.4 Una fábrica produce puertas cuya altura tiene una distribución normal con media de 250 cm y una desviación estándar de 2.60 cm

¿Cuál es la probabilidad que una puerta seleccionada de este grupo tenga una altura entre 244 y 255 cm?

Ejercicio 3.5 Una población de niños en edad escolar tiene una media de 11.5 años y un desvío estándar de 3 años. ¿Cuál es la probabilidad de que un niño sea entre 8.5 y 14.5 años, más de 10, y menos de 12?


Ejercicio 3.6 La media de notas de un grupo de estudiantes es 70 y el desvío estándar es 10. ¿Cuál es la probabilidad que un estudiante obtenga más de 80 puntos? ¿Cuál es la proporción de aplazados esperados ($P < 60$ puntos)?

Ejercicio 3.7 Se producen quesos con un diámetro es 35cm y se acepta una varianza de 0.1 cm². Si por problemas de envase se rechaza productos con diámetros menores a 34.5cm y mayores a 35.5 ¿Cuál es la probabilidad de rechazo de la producción por problemas de envase?

3.4 Distribución “t” de Student

La curva Normal y Normal Tipificada son modelos teóricos adecuados para describir muchas poblaciones naturales, basándose en dos parámetros μ y σ . Sin embargo por lo general en los trabajos experimentales se trabaja con muestras pequeñas y con μ y σ desconocidos, lo que da inseguridad sobre el uso de la distribución Normal cuando se desconocen estos parámetros o se tiene pocos datos. Un investigador, Gosset (seudónimo Student) estudió éste problema y llegó a la conclusión que la distribución Normal no funciona bien con muestras pequeñas, de tamaño menor a 30 datos, y diseñó una distribución que supera este problema. Luego esta distribución se llamaría “t” de Student en honor a Gosset.

Esta distribución es simétrica, con forma de campana y su media vale 0. Cuando hay pocos datos la campana es más aplanada que una campana Normal, con de 30 datos la distribución “t” es casi igual que la distribución Normal Tipificada (0,1). Esta Distribución se usa extensivamente para construir intervalos de confianza de σ y para realizar pruebas de hipótesis de: uno y dos promedias, del coeficiente de correlación y de los coeficientes beta en la regresión lineal.




Se observa que a más datos, la campana es más alta, con valores menos dispersos y semejante a una curva Normal.

Ejemplo Se sabe que la media histórica de edad de los estudiantes de una universidad es de 21 años. ¿Cuál es la probabilidad que un grupo de 30 estudiantes tenga un promedio de edad mayor a 22 años? En este grupo se calculó S, desvío estándar, y este era de 5 años. La forma de cálculo del estadístico es $t = \frac{\bar{x} - \mu}{S / \sqrt{n-1}}$

En este caso $t = \frac{22-21}{5/\sqrt{29}} = 0.92$. La probabilidad de éste valor se resuelve gráficamente con el módulo de aplicaciones didácticas de INFOSTAT, "P" vale 0.18.

Gráfico de Función de Densidad de la Distribución "t", n=29



Ejercicio 3.9 Históricamente se venden postes con un diámetro de 25cm, y con una varianza de 64 cm. Si el comprador rechaza un lote si este tiene un promedio de diámetro menor a 24 cm. ¿Cuál es la probabilidad de rechazar un lote de 100 postes? Resolver con el módulo didáctico de INFOSTAT.

3.5 La distribución χ^2 de Pearson


La distribución χ^2 , χ es la minúscula de la letra griega ji, se genera a partir de “n” variables aleatorias independientes normales con media “0” y varianza “1”. Si realizamos la siguiente operación: $\chi_n^2 = z_1^2 + \dots + z_n^2$

Es decir elevamos los “n” valores generados al cuadrado y los sumamos. Si aplicamos este procedimiento muchas veces, obtendremos la distribución de una variable que solo depende del número de sumandos, “n”. Esta distribución se denomina χ^2 con “n-1” grados de libertad. Esta distribución no posee valores negativos por ser creada a partir de suma de valores cuadrados.

Este tipo de distribución se usa extensivamente en pruebas de hipótesis sobre:

- Distribuciones, por ejemplo para verificar si una distribución observada se comporta como una distribución Normal.
- Independencia, para verificar si dos variables nominales son independientes o no.

Función de densidad de una Distribución Chi cuadrada:



3.6 La distribución “F” de Fisher- Snedecor.


La distribución “F” de Fisher - Snedecor surge del cociente de dos distribuciones χ^2 independientes, con “n” y “m” grados de libertad respectivamente. Un valor “F” se define matemáticamente de la siguiente manera:

$$F_{n,m} = \frac{\chi_n^2/n}{\chi_m^2/m}$$

La distribución de “F” es asimétrica y comienza del valor “0”, no posee valores negativos, al igual que la distribución χ^2 .

Este tipo de distribución se usa mucho en pruebas de hipótesis comparando de más de dos promedios, o verificando la existencia de los coeficientes de regresión lineal, pruebas de Análisis de Variancia, donde:

- Hipótesis nula, las medias de los tratamientos pertenecen a una misma media poblacional $H_0: \bar{x}_1, \bar{x}_2 \dots \bar{x}_n \in \mu$
- Hipótesis nula, los coeficientes de la regresión lineal no existen $H_0: \beta_1 = \beta_2 = \beta_3 \dots = \beta_k = 0$



3. 7 La distribución Binomial

Se utiliza para construir probabilidades con variables discretas, es decir cuyos valores son contables. Este modelo se aplica a poblaciones finitas de las que tomamos elementos al azar con reemplazamiento y también a poblaciones conceptualmente infinitas, como son las piezas que generara una máquina, siempre que el proceso generador sea estable (proporción de pieza defectuosas constante a largo plazo) y sin memoria (el resultado en cada momento es independiente de lo previamente ocurrido).

Un experimento Binomial tiene las siguientes características:

- Las observaciones se clasifican en dos categorías, por ejemplo A = aceptable y D = defectuoso.
- La proporción de elementos A y D en la población es constante y no se modifica, siendo en este caso “p” la probabilidad de defectuosos y “q” la probabilidad de aceptables.
- Las observaciones son independientes, es decir que la probabilidad de elemento defectuoso es siempre la misma y no se modifica por cualquier combinación de elementos defectuosos o aceptables observados.

Ejemplos de este proceso son:

- Observar cinco varones en 12 nacimientos.
- Ganar 4 veces apostando a docena en diez tiradas sucesivas de una ruleta
- La aparición de 10 plantas enfermas en 100 plantas de cultivo.
- Tener 5 ladrillos defectuosos en un lote de 500 ladrillos.

Generalizando, la variable binomial posee siempre 2 eventos, por ejemplo “A” y “B”. Se define como “x”:

x = número de elementos del evento “A” al observar “n” experimentos

Conociendo que:

- “p” es la probabilidad de ocurrencia del evento A
- “q” es la probabilidad de ocurrencia del evento B

Siendo $q = 1-p$. Por lo tanto la probabilidad de encontrar “x” elementos que cumplen el evento “A” luego de “n” repeticiones del experimento, se define como P (x):

$$P(x) = \binom{n}{x} p^x q^{n-x} \quad \text{siendo } x = 0, 1, \dots, n$$

Siendo $\binom{n}{x}$ las posibles combinaciones de ocurrencia de “x” en “n” experimentos que se resuelve de la siguiente manera:

$$\binom{n}{x} = \frac{n!}{x! (n - x)!}$$

Estos problemas se pueden resolver directamente o con una tabla de probabilidades binomiales. Una distribución binomial **B(n, p)** se parece a una normal tanto más cuanto mayor es el producto “n p”. Cuando “n p” superan el valor 5, la aproximación es casi perfecta. En estas condiciones:

B(n, p) se aproxima a una distribución normal, $N(np, \sqrt{npq})$

Veamos un ejemplo donde se usa esta distribución,

Ejemplo 1 ¿Cuál es la probabilidad de nacer 5 varones en 12 nacimientos? Este problema se puede resolver con un diagrama de árbol de probabilidades, pero se hace muy complicado. Por distribución Binomial se resuelve el problema de la siguiente manera.

Si sabemos que:

- “A” evento varón
- “B” evento no varón, es decir mujer.
- “p” probabilidad de varón = 0.5
- “q” probabilidad de mujer = 0.5
- “n” son 12 nacimientos totales
- “x” son 5 nacimientos de varones

Por lo tanto:

$$P(5 \text{ varones}) = \binom{12}{5} 0.5^5 0.5^{12-5}$$

$$\text{Donde } \binom{12}{5} = \frac{12!}{5!(12-5)!} = 792$$

$$P(5 \text{ varones}) = 792(0.5^5)0.5^7 = 792 (0.03125) (0.0078125) = \mathbf{0.19}$$

Ejemplo 2. Existe una empresa que produce vasos, y se sabe que históricamente el 2 % de estos salen fallados. Por otro lado existe un comprador que tolera el 2 % de

fallos, si el valor es mayor rechaza el lote completo que quiere comprar. Se decide tomar una muestra de 100 vasos, ¿Cuál es la probabilidad de que el comprador acepte el lote?

$$P(x \leq 2) = P(x = 0) + P(x = 1) + P(x = 2) = 0.67$$

$$P(x = 0) = \binom{100}{0} 0.02^0 0.98^{100} = 0.13$$

$$P(x = 1) = \binom{100}{1} 0.02^1 0.98^{99} = 0.27$$

$$P(x = 1) = \binom{100}{2} 0.02^2 0.98^{98} = 0.27$$

Ejercicio 3.10 El Ministerio del Trabajo reporta que 20% de la fuerza de trabajo en un pueblo está desempleada. De una muestra de 14 trabajadores, calcule las siguientes probabilidades con la fórmula de la distribución binomial ($n=14$, $p=0.2$): Resuelva:

1. Tres están desempleados. Respuesta: $P(x=3)=.250$

2. Al menos un trabajador está desempleado.

$$\text{Respuesta: } P(x \geq 1) = 1 - P(x=0) = 1 - .044 = .956$$

3. A lo más dos trabajadores están desempleados.

$$\text{Respuesta: } P(x \leq 2) = .044 + .154 + .250 = .448$$

Ejercicio 3.11 Si el 15 % de las piezas producidas por una máquina son defectuosas, ¿cuál es la probabilidad de que entre cuatro piezas elegidas al azar, a lo sumo una sea defectuosa? Respuesta: $P(x \leq 1)=.89$

Ejercicio 3.12 Si de seis a siete de la tarde se admite que un número de teléfono de cada cinco está comunicando, ¿cuál es la probabilidad de que, cuando se marquen 10 números de teléfono elegidos al azar, sólo comuniquen dos? Respuesta: $P(x=2) = .30$

3.8 Distribución de Poisson

El límite de la distribución binomial donde la probabilidad de éxito es muy pequeña y n es grande se llama distribución de probabilidades de Poisson. La distribución de

Poisson es una distribución de probabilidad discreta que expresa la probabilidad de un número de eventos ocurriendo en un tiempo fijo si estos eventos ocurren con un valor medio conocido, y son independientes del tiempo desde el último evento. Esta distribución fue desarrollada por Simeón Poisson en 1781–1840.

Esta distribución permite construir probabilidades de una variable binomial, sólo conociendo el valor de su promedio histórico, μ

La distribución de Poisson se puede describir matemáticamente por la fórmula:

$$P(x) = \frac{\mu^x \varepsilon^{-\mu}}{x!}$$

Donde μ es la media aritmética del número de ocurrencias en un intervalo específico de tiempo, ε es la constante 2.71828 y “X” es el número de ocurrencias. El número medio de éxitos, μ , se puede determinar en situaciones binomiales por “n p”, donde “n” es el número de ensayos y p la probabilidad de éxito. La varianza de la distribución de Poisson también es igual a “n p”.

En general utilizaremos la distribución de Poisson como una aproximación de experimentos binomiales donde el número de pruebas es muy alto, pero la probabilidad de éxito muy baja. En la práctica esta distribución se utiliza para calcular la probabilidad de un número específico de eventos, durante un período o espacio particular. El tiempo o la cantidad de espacio suele ser la variable aleatoria.

Ejemplo: Se está haciendo un estudio para ampliar una terminal de taxis y se sabe que en las horas de la tarde de 6-10 PM el número medio de llegadas es 4.0 personas por hora. ¿Cuál es la probabilidad de 4 llegadas en una hora?

$$P(4) = (4^4) (e^{-4}) / 4! = 0.1954.$$

Ejercicio 3.13 La producción de computadoras trae asociada una probabilidad de defecto del 1.5%, si se toma un lote o muestra de 100 computadoras, obtener la probabilidad de que existan 2 o menos computadoras con defectos. Respuesta: 0.80

Ejercicio 3.14 Se calcula que en la ciudad el 20% de las personas tienen afición a mirar TV de noche, si tomamos una muestra de 150 personas al azar ¿Calcular la probabilidad de que 25 de ellos tengan el hábito de mirar TV de noche?

Ejercicio 3.15 El 6% de los registros contables de una empresa presentan algún problema, si un auditor toma una muestra de 50 registros ¿Calcular probabilidad de que existan exactamente tres registros con problemas? Respuesta: 0.22

Ejercicio 3.16 Si cada una de las 18 gallinas de un gallinero pone de promedio 0.5 huevos al día. Si se recogen los huevos cada 24 horas.

¿Cuál es el número medio de huevos que se recogen en cada visita? ¿Cuál es la probabilidad de que $x \geq 5$? Respuesta: 9 y 0.94

Ejercicio 3.17 Como una forma de hacer control de calidad en una empresa comercializadora de puertas de madera, el dueño exige que antes de salir de la fábrica cada puerta sea revisada en busca de imperfecciones en la superficie de madera. El encargado de control de calidad encontró que el número medio de puertas con imperfecciones es de 0.05%. ¿Cuál es la probabilidad de un lote con 100 puertas tenga 4 imperfecciones o menos? Respuesta: 0.44

Capítulo 4. Estimación y prueba de hipótesis.

Objetivos

- Utilizar el concepto de los intervalos de confianza al describir información generada a partir de datos.
- Explicar cómo una prueba de hipótesis sirve para contestar preguntas de investigación.
- Diferenciar grupos o tratamientos de conjunto de datos, utilizando pruebas de Student y pruebas de varianzas.
- Realizar pruebas de independencia Chi cuadrado con ejemplos aplicables a su carrera.

Se debe poder hacer conclusiones generales para toda la población, a partir del estudio de las muestras.

4.1 Estimación por Intervalos de Confianza.

En estadística difícilmente se conoce el valor exacto de los parámetros, (Ej.: μ y σ) de una población, sin embargo estos se pueden estimar. Por lo tanto podemos definir estimación al conjunto de técnicas que permiten dar un valor aproximado de un parámetro a partir de estadísticos, estimadores, generados por los datos (Ej.: $\bar{X}$, S , n). Un estimador puntual de un parámetro es un valor que puede ser considerado representativo de este y se obtiene a partir de alguna función de la muestra, por Ej., $\bar{X}$, media muestral, estima puntualmente μ , la media poblacional. Una propiedad que se suele pedir a los estimadores es que no tengan sesgo, lo que significa que el valor esperado, esperanza del estimador, sea igual al parámetro a estimar, esta propiedad la tiene la media aritmética y la varianza.

La estimación por intervalos consiste en la obtención de un intervalo dentro del cual estará el valor del parámetro estimado, con una cierta probabilidad. Un uso de la

distribución Normal y de la “t” de Student es la creación de Intervalos de confianza, estimación por intervalos, de las medias poblacionales, μ , esta se puede estimar por un intervalo calculado a partir del “S” y $\bar{x}$, de muestras.

El intervalo de confianza de μ con un 95 de confianza, IC 95 %, es el más usado y para muestras de más de 30 datos se calcula como:

$$\text{IC}_{95\%} \text{ de } \mu = \bar{x} \pm 1.96 (s / \sqrt{n})$$


Para menos de 30 datos se usa:

$$\text{IC}_{95\%} \text{ de } \mu = \bar{x} \pm “t_{95}” (s / \sqrt{n-1}),$$

Donde “t” es el valor dado por la distribución “t” de Student con “n-1” Grados de Libertad, para un 95 % se busca el valor del “t” 0.975, ya que esta es una prueba de dos colas.

El IC 95 % dice que con un 95 % de confiabilidad en este intervalo encuentro la media de la población, el cual desconozco. El gráfico de IC 95 % se usa cuando se cruza una variable que genera grupos, con una variable continua. En este gráfico se observan las medias de cada grupo con sus intervalos de confianza al 95 %, estos en forma de dos rayas. Veamos un ejemplo de este tipo.

Gráfico de Medias e Intervalos de Confianza de μ , “ $t_{95\%}$ ”, desagregada por año, del Sabor de los Cafés Especiales de Nicaragua.



En este tipo de gráfico es interesante observar si los intervalos de confianza de las diferentes medias tienen valores superpuestos, ya que si no es así, al hacer una prueba de hipótesis lo más probable es que la respuesta sea de hipótesis alternativa, las “medias con sus intervalos de confianza no superpuestos” pertenecen a una distinta media poblacional.

Ejercicio 4.1 Una fábrica produce puertas, una muestra de 50 de éstas arroja que tienen una altura media de 250 cm y una desviación estándar de 2.60 cm. ¿Construir el intervalo de confianza de la media poblacional?

4.2 Generalidades de las pruebas de Hipótesis

Una prueba de hipótesis es una pregunta relativa a una o varias poblaciones, que puede ser cierta o no y que se va a responder a partir de los datos muestrales. Las hipótesis estadísticas se pueden contrastar con la información generada de las muestras y siempre se tienen el riesgo que si se aceptan como si se rechazan se puede cometer un error. En las ingenierías las pruebas de hipótesis se suelen utilizar cuando se evalúan nuevas técnicas, tomando como referencia de comparación la técnica tradicional. La hipótesis formulada con intención de rechazarla se llama

hipótesis nula y se representa por H_0 . Rechazar H_0 implica aceptar una hipótesis alternativa (H_A).

Cuando se acepta o se rechaza una hipótesis puede ocurrir que:

	H_0 cierta	H_0 falsa, H_A cierta
H_0 rechazada	Error tipo I (α)	Decisión correcta
H_0 no rechazada	Decisión correcta	Error tipo II (β)

α = probabilidad de rechazar H_0 siendo H_0 cierta.

β = probabilidad de aceptar H_0 siendo H_0 falsa.

Enfoque tecnológico. Se debe tener en cuenta que generalmente es más peligroso el error de tipo I, que suele significar cambiar la técnica tradicional por una nueva cuando esto no se debía hacer, en cambio el error de tipo II suele significar que se rechaza una nueva técnica cuando lo correcto era aceptarla como mejor. El concepto es que generalmente es mejor ser conservador, no aceptar el cambio de técnica sino se está muy seguro que este cambio es ventajoso.

Los pasos necesarios para realizar un contraste relativo a un parámetro θ son:

1. Establecer la hipótesis nula en términos de igualdad:

$$H_0: \theta = \theta_0$$

2. Establecer la hipótesis alternativa, que puede hacerse de tres maneras, dependiendo del interés del investigador:

$$H_0: \theta \neq \theta_0, \theta > \theta_0, \theta < \theta_0$$

En el primer caso se habla de contraste bilateral. En los otros dos casos se tiene un contraste unilateral, derecho en el segundo caso, o izquierdo en el tercer caso.

3. Elegir un *nivel de significación*: nivel crítico para “ α ”, generalmente del 5 % en las ingenierías. En ciencias sociales se suele aceptar un α del 10%.

4. Elegir un *estadístico de contraste*: Este estadístico de contraste es un estadístico cuya distribución es conocida en H_0 , que esté relacionado con θ y permite establecer, en base a dicha distribución, la *región crítica*: región en la que el estadístico calculado tiene una probabilidad menor que α .

5. Calcular el estadístico para una muestra aleatoria y compararlo con la región crítica. Se calcula el estadístico correspondiente a la hipótesis planteada. Si el estadístico tiene en valor absoluto, un valor menor al valor tabular de la distribución conocida correspondiente al α definido, se acepta la H_0 .

Obsérvese que de manera general se está más seguro cuando se rechaza una hipótesis que cuando no. Por eso se fija como H_0 lo que se quiere rechazar. Cuando no se rechaza la H_0 , no necesariamente significa que la hipótesis nula se está cumpliendo, puede suceder que por mucho error experimental o pocas repeticiones del experimento, simplemente el modelo no ha podido rechazar.

Los programas estadísticos de computadora calculan un valor “p”, p-value, del estadístico, que significa la probabilidad de obtener el valor del estadístico calculado u otro más alejado, si H_0 fuera cierta. Este valor “p” es el valor de una integral en una función de probabilidad continua en el intervalo que va desde el estadístico calculado hasta el infinito. Si el valor de α es el 5 %, la regla de decisión para aceptar o rechazar una hipótesis en pruebas unilaterales es la siguiente:

- Si el valor “p” calculado es > 0.05 ocurre H_0
- Si el valor “p” calculado es ≤ 0.05 H_0 es falsa

El valor “p” es la probabilidad de obtener un resultado al menos tan extremo como el estadístico que se ha obtenido

4.3 Prueba de hipótesis con la distribución “t”

4.3.1 La media de una muestra pertenece a una población con media conocida

Esta es una prueba que permite contrastar si una muestra de una variable, difiere significativamente de una media poblacional dada. Generalmente esta media es histórica.

La hipótesis nula es $H_0: \bar{X} \in \mu$, La hipótesis alternativa es $H_A: \bar{X} \notin \mu$

El estadístico de contraste es el valor “t” calculado:

$$t = \frac{\bar{x} - \mu}{S/\sqrt{n}}$$

El valor “t” crítico se encuentra con n-1 grados de libertad.

Ejemplo:

Históricamente se cosecha los árboles a los 18 años. Se quiere saber si este año la edad de corte será la misma a la histórica. Para verificar la pregunta se tomó una muestra de 36 árboles y se calculó la edad estudiando los anillos del tronco. Luego de los datos observados surge la duda que la edad de los árboles de este año es mayor que 18 años. La muestra de 36 árboles dio los siguientes datos: $\bar{x} = 18.5$ $S = 3.6$

Se trata de un contraste sobre medias. La hipótesis nula (lo que queremos rechazar) es: $H_0: \mu = 18$. La hipótesis alternativa es: $H_A: \mu > 18$. Este un contraste lateral derecho.

Fijamos "a priori" el nivel de significación en $\alpha = 0,05$ y la región crítica en este ejemplo $t_{(35)0,05} = 1,70$.

Calculamos el valor de t_c en la muestra

$$t_c = \frac{18.5 - 18}{3.6 / \sqrt{36}} = 0.83$$

El valor " t_c " de 0.83 no está en la región crítica de rechazo de la hipótesis nula (no es mayor que el valor " t_{975} " con 30 gl de 1,70), por tanto no rechazamos H_0 , concluimos que la edad histórica de corte se mantiene.

4.3.2 Comparaciones por parejas de muestras no independientes o apareadas

Esta es una prueba "t" para muestras relacionadas, donde se pretende contrastar las medias de una misma población que se ha medido dos veces en los mismos sujetos, por ejemplo: A- En un grupo de estudiantes se quiere comparar el resultado del primer examen parcial con el del segundo parcial para saber si el comportamiento ha cambiado. B- Se quiere saber si diez fábricas artesanales que producen bloques están manteniendo la calidad de sus productos en el tiempo, para eso se comparan 10 muestras del mes uno con 10 muestras del mes dos.

El estadístico de contraste es

$$t_c = \frac{\bar{d}}{S_d / \sqrt{n}}$$

Donde $\bar{d}$ es la media de las diferencias de los datos repetidos, S_d es la desviación estándar de las diferencias, "n" es el número de pares (diferencias). El valor "t" crítico se encuentra con n-1 grados de libertad.

Ejemplo. Se evaluó el % de germinación de nueve lotes de semillas de maíz, a los 6 y a los 12 meses de estar almacenada. Se tomó una muestra por lote en los dos

momentos. Se quiere saber si ha disminuido de forma general el poder de germinación durante el almacenamiento.

Datos Poder germinativo por lote.

Lote	% Mes 6	% Mes 12
1	86	79
2	82	69
3	80	74
4	78	70
5	75	67
6	82	64
7	85	76
8	86	63
9	86	76

La hipótesis nula es $H_0: \mu_6 = \mu_{12}$, hipótesis alternativa $H_A: \mu_6 > \mu_{12}$. Fijamos "a priori" el nivel de significación en $\alpha = 0,05$ y la región crítica en este ejemplo $t_{(8)0,05} = 1,86$.

Calculamos el valor de t_c en con los dos conjuntos de muestra

$$t_c = \frac{11.33}{5.70 / \sqrt{9}} = 5.96$$

El valor " t_c " de 5.96 está en la región crítica (el valor P es de 0.002), por lo tanto rechazamos H_0 , concluimos que el poder germinativo de la semilla de maíz disminuyó al estar 12 meses almacenados.

4.3.3 Las medias de dos muestras o grupos pertenecen a una misma población

Esta es una prueba de hipótesis muy usada cuando se tienen dos grupos independientes y se quiere saber si estos tienen una misma media poblacional.

La hipótesis nula es $H_0: \mu_1 = \mu_2$, la hipótesis alternativa es $H_A: \mu_1 \neq \mu_2$

Hay diferentes tipos de prueba “t”, pero suponiendo varianzas iguales, el estadístico a calcular se hace:

$$t_c = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{S_1^2}{n_1 - 1} + \frac{S_2^2}{n_2 - 1}}}$$

Ejemplo. En un ensayo para evaluar la vida útil de dos productos. La variable medida es el tiempo de vida útil en años: producto “T”, $n = 35$; $\bar{x} = 3,7$ años de vida y $s^2 = 13,9$; producto “K” $n = 40$; $\bar{x} = 15,1$ años y $s^2 = 12,8$. ¿El producto “K” tiene igual vida útil que el producto “T”? Se trata de un contraste sobre diferencias de medias

Como no conocemos como son las varianzas entre sí, el modelo nos obliga a verificar si la varianzas son iguales, si fueran distintas es otra la prueba “t” a realizar. Para ello se debe plantear primero un contraste de prueba de hipótesis de variancias. Si las variancias son iguales se sigue con la prueba “t” que se presenta, sino se debe hacer otra variante de prueba “t” de más difícil cálculo.

Hipótesis de Variancias

$$H_0: \sigma_T^2 = \sigma_K^2, \quad H_A: \sigma_T^2 \neq \sigma_K^2$$

El estadístico es de contraste es una prueba “F” = $S_K^2 / S_T^2 = 13.9 / 12.8 = 1.09$, como el valor “F” de tabla es 1.74, en consecuencia aceptamos la H_0 y concluimos que las varianzas son iguales. Luego se hace la prueba de hipótesis de medias con el estadístico antes detallado.

$$t_c = \frac{15.1 - 3.7}{\sqrt{\frac{13.9}{35-1} + \frac{12.8}{40-1}}} = 13.28$$

Se concluye que se rechaza la H_0 , ya que el valor “t” calculado es mayor que el valor de tabla con $n_1 + n_2 - 2$, $35 + 40 - 2 = 73$ grados de libertad. Con estos grados de libertad y con un alfa del 5% bilateral (2.5 % de rechazo en cada extremo) el valor “t” es de 2.0, valor menor que 13.28. Concluimos que las medias de años de vida útil de los dos productos son distintas.

Ejercicio 4.2 Se evaluó 2 tipos de abono, uno con base de pulpa de café, otro con base de abono de lombriz, La variable de producción fue grs. promedio del peso seco de las plántulas de café a los 6 meses de siembra por unidad experimental, el ensayo tuvo cuatro repeticiones.

Tabla de Datos. Peso en onzas. Parte aérea plántula de café.

Tratamiento/ Repetición	I	II	III	IV
Pulpa café	1.00	0.90	1.16	0.98
Lombrihumus	1.65	1.59	2.00	1.65

Realizar e Interpretar su prueba de hipótesis. Resolver con una prueba “t” para dos grupos que pertenecen a una misma población

Capítulo 5. Análisis de Correlación y Regresión.

Objetivos

- Desarrollar conceptos y cálculos de Correlación y Regresión Lineal con variables socioeconómicas y productivas.
- Realizar las pruebas de hipótesis asociadas a la Correlación y Regresión lineal que permitan responder problemas de investigación de las ingenierías.

5.1 Correlación

Se puede definir la correlación como la medida estadística que sirve para evaluar la intensidad de la asociación entre dos o más variables cuantitativas. Es común que se quiera saber, si sobre una misma población los valores de dos o más variables cuantitativas distintas tienen alguna relación medible entre ellas, o si los cambios en una o varias de ellas influyen en los valores de otra variable. Si ocurre esto decimos que las variables están correlacionadas o bien que hay correlación entre ellas. Este tipo de análisis funciona bien cuando las variables estudiadas son continuas, no es adecuado usar esta prueba con variables del tipo nominal.

El principal objetivo del análisis de correlación consiste en determinar qué tan fuerte es la relación entre las variables. Las variables que se vinculan se llaman:

- Variable Dependiente.- es la variable que se predice o calcula. Cuya representación es " $\hat{Y}$ "
- Variable/s Independiente/s.- es la o las variables que proporcionan las bases para el cálculo. Cuya letra de representación es: " X ". Esta o estas variables suelen ocurrir antes en el tiempo que la variable dependiente.

Coeficiente de Correlación. El coeficiente de correlación más utilizado es el de Pearson, este es un índice estadístico que mide la relación lineal entre dos variables cuantitativas, es una forma de medir la intensidad de la relación lineal entre dos variables. El valor del coeficiente de correlación puede tomar valores desde menos uno

hasta uno, $-1 < r < 1$, indicando que mientras más cercano a uno sea el valor del coeficiente de correlación, en cualquier dirección, más fuerte será la asociación lineal entre las dos variables. El coeficiente de correlación de cálculo “r” es un estimador muestral del coeficiente poblacional Rho, ρ . Mientras más cercano a cero sea el coeficiente de correlación, este indicará que más débil es la asociación entre ambas variables. Si es igual a cero se concluirá que no existe relación lineal alguna entre ambas variables. Hay varias maneras de equivalentes de calcular “r”, a continuación se muestran tres formas.

Coeficiente de Correlación, estimación por Covarianzas y Desviaciones Estándares

$$r = \frac{S_{XY}}{S_X S_Y}$$

Siendo: “ S_{XY} ” la covarianza de (X,Y) y “ S_X, S_Y ” las desviaciones típicas de las distribuciones de las variables independiente y dependiente respectivamente.

Coeficiente Correlación Estimación Clásica. Poco usada para cálculo.

$$r = \sqrt{\frac{(\sum (X - \bar{X})(Y - \bar{Y}))^2}{\sum (X - \bar{X})^2 \sum (Y - \bar{Y})^2}}$$

Coeficiente Correlación, Estimación por Suma de Cuadrados. Más utilizado cuando se dispone de calculadoras de mano que hacen sumas de cuadrados.

$$r = \frac{\sum XY - \frac{\sum X \sum Y}{n}}{\sqrt{\left(\sum X^2 - \frac{\sum X^2}{n}\right) \left(\sum Y^2 - \frac{\sum Y^2}{n}\right)}}$$

Gráfico de Dispersión de puntos. Es un diagrama de dispersión de puntos “X Y”, el cual es una representación gráfica de la relación entre dos variables, es muy utilizado antes de realizar un estudio de regresión para conocer la tendencia de los datos. Tres conceptos especialmente son destacables: que el descubrimiento de las verdaderas relaciones de causa-efecto es la clave de la resolución eficaz de un problema, que las relaciones de causa-efecto casi siempre muestran variaciones, y que es más fácil ver la relación en un diagrama de dispersión que en una simple tabla de números.

Según sea la dispersión de los datos (nube de puntos) en el plano cartesiano, pueden darse, alguna de las siguientes relaciones: lineales o curvilíneas como la cuadrática, cúbica, etc. Dentro de estas nubes de puntos se pueden generar líneas poligonales a partir de ecuaciones de regresión, que permitan predecir el comportamiento de la variable dependiente.

5.2 Regresión

La regresión es una técnica que permite predecir un valor numérico de una variable, dependiente, basándonos en el conocimiento de un valor diferente de otra variable, independiente. El término regresión fue introducido por Francis Galton en su libro *Natural inheritance* (1889), partiendo de los análisis estadísticos de Karl Pearson. Su trabajo se centró en la descripción de los rasgos físicos de los descendientes a partir de los de sus padres. Estudiando la altura de padres e hijos llegó a la conclusión de que los padres muy altos tenían una tendencia a tener hijos que heredaban parte de esta altura, pero los datos también revelaban una tendencia a *regresar* a la media.

Los tipos de regresión más comunes entre dos variables son las del tipo polinómico como la regresión: lineal, cuadrática y cúbica. La primera regresión genera una recta, las otras diferentes tipos de parábolas. Otros tipos de regresión que se pueden usar con dos variables son la logarítmica y la exponencial, la regresión logarítmica permite

transformar una curva en una línea recta. Cuando hay más de una variable independiente “x”, la regresión más utilizada en la regresión múltiple. A continuación se expresan matemáticamente los diferentes modelos comentados:

REGRESIÓN	ECUACIÓN
Lineal	$\hat{y} = \beta_0 + \beta_1 X$
Logarítmica	$\hat{y} = \beta_0 + \beta_1 \ln(X)$
Exponencial	$\hat{y} = \beta_0 e^{\beta_1 x}$
Cuadrática	$\hat{y} = \beta_0 + \beta_1 X + \beta_2 x^2$
Cúbica	$\hat{y} = \beta_0 + \beta_1 X + \beta_2 x^2 + \beta_3 x^3$
Lineal Múltiple	$\hat{y}_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik}$

Los parámetros poblacionales “ β ” se estiman a partir de los estimadores “b” calculados a partir de los datos generados por muestras.

5.2.1 Ecuación de Regresión Lineal

Es el tipo de regresión más utilizada y fácil de estimar, esta es una ecuación que define la relación lineal entre dos variables. Ecuación de regresión lineal $\hat{y} = b_0 + b_1 X$

Esta ecuación se calcula según el principio de Mínimos Cuadrados. La cual es la técnica empleada para obtener la ecuación de regresión, minimizando la suma de los cuadrados de las distancias verticales entre los valores verdaderos de “y”, los observados y los valores estimados $\hat{y}$. Se debe notar que cada valor observado menos el valor estimado correspondiente genera un intervalo que llamaremos error o residuo, este valor es la distancia que hay del valor observado a la recta de regresión. El error de cada dato se encuentra de la siguiente manera:

$$y_i - \hat{y}_i = \varepsilon_i$$

El valor de ε_i también llamado error aleatorio puede ser negativo o positivo. El error calculado a partir de muestras se simboliza con la letra “e”. Una propiedad de los

errores es que la esperanza de los errores vale 0, $E(e_i) = 0$. El promedio de los errores es igual a cero, al igual que la sumatoria de los mismos.

Para poder hacer pruebas de hipótesis de la población a partir de muestras, estos errores calculados deben cumplir la siguiente propiedad: Los desvíos o errores, e_i se distribuyen de manera Normal. La ecuación que minimiza las desviaciones de los valores de “Y” respecto a la ecuación de la recta, cuando “ $b_0 = 0$ ”, es:

$$\hat{y}_i = \left(\frac{\sum XY - \frac{\sum X \sum Y}{n}}{\sum X^2 - \frac{\sum X^2}{n}} \right) x_0$$

$$\hat{y}_i = b_1 x_0$$

Por lo tanto la expresión del coeficiente de regresión, “ b_1 ”, queda así:

$$b_1 = \frac{\sum XY - \frac{\sum X \sum Y}{n}}{\sum X^2 - \frac{\sum X^2}{n}}$$

Como podemos escribir:

$$\hat{y}_i - \bar{y} = b_1(x_i - \bar{x})$$

Que puede replantearse como:

$$\hat{y}_i = \bar{y} - b_1\bar{x} + b_1x_i$$

De tal manera que la ordenada al origen, cuando “X” vale 0, “ b_0 ”, queda definida de la siguiente manera:

$$\hat{y}_i = b_0 = \bar{y} - b_1\bar{x}$$

Ejemplo de regresión correlación lineal:

Se tienen las notas de un examen parcial de diez alumnos de las asignaturas de matemáticas y español.

Matemáticas	40	56	64	65	66	68	75	76	85	95
Español	45	59	67	59	69	70	61	82	75	100

Se supone que los alumnos con mejores notas en matemáticas, variable independiente “X”, tienen las mejores notas en español, variable dependiente “Y”. Esta pregunta se puede responder con un análisis de regresión correlación.

Para observar la forma de la regresión lo primero que se hace es construir un gráfico de dispersión de puntos que nos permite mirar la tendencia de la nube de puntos, como el que se muestra a continuación. Al observar una tendencia aparentemente lineal se puede calcular los coeficientes r , b_0 y b_1 .




Gráfico de dispersión de puntos de las notas de las asignaturas de matemáticas y español.

Cálculo de la recta de regresión con datos generados con una calculadora de mano que hace sumatorias:

$$\bar{x} = 69, \bar{y} = 68.7; \sum x = 690; \sum x^2 = 49,688 \quad \sum y = 687; \sum y^2 = 49,207; \sum xy = 49,223$$

Coeficiente de correlación “r”:

$$r = \frac{49,223 - \frac{690(687)}{10}}{\sqrt{\left(49,688 - \frac{690^2}{10}\right)\left(49,207 - \frac{687^2}{10}\right)}} = 0.891$$

Este valor de “r” de 0.891 refleja que hay una alta correlación, asociación, entre las notas de matemáticas y español, los mejores estudiantes en una asignatura son los mejores estudiantes en la otra.

Para hacer la recta de regresión debemos calcular b_1 y b_0 :

$$b_1 = \frac{49,223 - \frac{690(687)}{10}}{49,688 - \frac{690^2}{10}} = 0.88$$

$$b_0 = 68.7 - 0.876 (69) = 8.27$$

La recta de regresión queda determinada de la siguiente manera:

$$“\hat{Y}” = 8.27 + 0.88 X “.$$

A continuación se observan los valores estimados por la recta de regresión de la asignatura de español, “ $\hat{y}$ ”, para cada valor observado “ y ”, con el desvío o error asociado a cada dato, “ $y - \hat{y}$ ”, estos son:

“ $\hat{y}$ ”	43.30	57.31	64.32	65.20	66.07	67.82	73.96	74.83	82.71	91.47
Error	1.70	1.69	2.68	-6.20	2.93	2.18	-12.96	7.17	-7.72	8.53

Se puede comprobar que la suma de los errores o desvíos es igual 0.

El gráfico de regresión es el siguiente:





Gráfico de Regresión de la asignatura Matemática y Español. Se observa la recta de regresión y los datos observados en forma de puntos.

Verificación del modelo de regresión.

Para verificar si el modelo de regresión lineal calculado a partir de datos de una muestra, es correcto para ser utilizado en pruebas de hipótesis sobre la población, se puede hacer un gráfico Q-Q plot de residuos o errores con el programa INFOSTAT para observar si estos tienen un comportamiento normal, como es esperado. Este gráfico se utiliza para evaluar el grado de ajuste de un conjunto de observaciones a una distribución teórica, en este caso con la distribución normal.



5.2.2 Análisis de Regresión Múltiple

A menudo en una investigación el objetivo es explicar el comportamiento de una variable en términos de más de una variable, por ejemplo sea la variable “Y” “producción de maíz”, cuyo comportamiento explicaremos en términos de las variables $X_1, X_2, \dots, X_k$ “temperatura, fertilización, incidencia de plagas, etc.”. Se estudiará la situación donde el comportamiento de la variable “Y” (llamada dependiente o respuesta) se explicará mediante una relación lineal en función de las variables $X_1, X_2, \dots, X_k$ (llamadas independientes o también explicativas). La variable respuesta y las variables explicativas deben ser cuantitativas.

Modelo

Sea “Y” una variable respuesta y las variables $X_1, X_2, \dots, X_k$ independientes; deseamos describir la relación que hay entre la variable respuesta y las variables explicativas, si entre ellas hay una relación lineal se espera que:

$$\hat{Y}_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik}$$

Donde $\hat{Y}$ es la variable respuesta cuantitativa para el i-ésimo objeto, este es un valor estimado.

Los β_k son los parámetros poblacionales (valores constantes fijos) llamados coeficientes. Siendo “n” el número de objetos u observaciones donde $i = 0, 1, 2, \dots, n$.

Se espera que la variable dependiente varíe linealmente con las variables independientes. Además cada valor observado de la variable dependiente “ y_i ” se puede descomponer de la siguiente manera

$$y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \varepsilon_{ik} \quad \text{Para } i=1, 2, \dots, n$$

Donde ε_{ik} es el desvío o error de cada observación, este valor hace único a cada dato observado.

5.3 Coeficientes de Correlación Parcial y Múltiple

Coeficientes de correlación parcial

La correlación entre dos variables cuando una o más variables permanecen fijas a un nivel constante, se denomina correlación parcial, este coeficiente suele mejorar su valor respecto al coeficiente de correlación simple. También se utiliza para encontrar el coeficiente de correlación múltiple de manera general.

En el caso particular de tres viables, la correlación parcial entre “Y” y “ X_1 ” con un “ X_2 ” fijo se denota “ $r_{yx_1.x_2}$ ”, y se calcula a partir de las correlaciones simples de la siguiente manera:

$$r_{yx_1.x_2} = \sqrt{\frac{(r_{yx_1} - r_{yx_2} r_{x_1x_2})^2}{(1 - r_{yx_2}^2)(1 - r_{x_1x_2}^2)}}$$

Análogamente “ $r_{yx_2.x_1}$ ” se calcula de igual forma

$$r_{yx_2.x_1} = \sqrt{\frac{(r_{yx_2} - r_{yx_1} r_{x_1x_2})^2}{(1 - r_{yx_1}^2)(1 - r_{x_1x_2}^2)}}$$

Generalizando, siempre existe una ecuación general que permite calcular un coeficiente parcial de cualquier orden “k” si conocemos tres coeficientes parciales de un orden inferior.

Coeficiente de correlación parcial de manera general

$$r_{yx_1x_2x_3\dots x_k} = \frac{(r_{yx_1x_3\dots x_k} - r_{yx_2x_3\dots x_k}r_{x_1x_2x_3\dots x_k})^2}{\sqrt{(1 - r_{yx_2x_3\dots x_k}^2)(1 - r_{x_1x_2x_3\dots x_k}^2)}}$$

Coeficiente de correlación múltiple

El coeficiente de correlación múltiple mide la asociación entre varias variables independientes y una dependiente. El coeficiente de correlación múltiple $r_{y.x_1x_2\dots x_k}$ se puede definir de manera general como la raíz cuadrada de la suma de los cuadrados explicados por la regresión sobre la suma de los cuadrados totales, este coeficiente solo toma valores entre 0 y 1.

$$r_{y.x_1x_2\dots x_k} = \sqrt{\frac{\sum_{i=1}^n (\hat{y} - \bar{y})^2}{\sum_{i=1}^n (y - \bar{y})^2}}$$

El coeficiente de correlación múltiple tiene una desventaja, su valor se incrementa cuando se introducen nuevas variables independientes en el modelo, por tanto resulta puede resultar engañoso para el análisis cuando se tienen muchas variables en el modelo.

De manera general es posible encontrar una ecuación general de coeficiente de correlación múltiple que incluye “k” variables independientes, esta se puede construir a partir de los coeficientes de correlación parciales:

$$1 - r_{y.x_1x_2\dots x_k}^2 = (1 - r_{yx_1}^2)(1 - r_{yx_2.x_1}^2)(1 - r_{yx_3.x_1x_2}^2) \dots (1 - r_{yx_k.x_1\dots x_{k-1}}^2)$$

Coeficiente de correlación múltiple con tres variables “y”, “x₁” y “x₂” a partir de correlaciones lineales simples.

El modelo más sencillo de regresión múltiple es cuando se tiene dos variables independientes “x”. De manera operacional un ejemplo de tres variables se puede resolver a partir de las correlaciones simples entre las 3 variables. “r” se calcula de la siguiente manera:

$$r_{y.x_1x_2} = \sqrt{\frac{r_{yx_1}^2 + r_{yx_2}^2 - 2r_{yx_1}r_{yx_2}r_{x_1x_2}}{1 - r_{x_1x_2}^2}}$$

Se debe notar que en este ejemplo para hacer $r_{y.x_1x_2}$ es necesario calcular previamente tres correlaciones simples de dos variables.

5.4 Estimadores “b” de la ecuación de Regresión Lineal Múltiple

Cálculo de estimadores b_1 y b_2 de una regresión múltiple con dos variables independientes x_1 y x_2 .

Construcción del modelo:

Se parte de la ecuación de regresión múltiple

$$b_0 + b_1x_1 + b_2x_2 = \hat{y}$$

Y se construye un sistema de ecuaciones normales

$$b_0n + b_1 \sum x_1 + b_2 \sum x_2 = \sum \hat{y}$$

$$b_0 \sum x_1 + b_1 \sum x_1^2 + b_2 \sum x_2x_1 = \sum \hat{y}x_1$$

$$b_0 \sum x_2 + b_1 \sum x_2x_1 + b_2 \sum x_2^2 = \sum \hat{y}x_2$$

Si se plantea la ecuación en términos de desviaciones respecto a la media,

$\sum(x_1 - \bar{x}) = 0$, como la suma de las desviaciones es 0, entonces

$\sum x_1 = \sum x_2 = \sum y = 0$. Esto implica que se anula el primer término de las tres ecuaciones y además la primera ecuación, quedando el modelo de forma operativa de la siguiente manera:

Modelo de resolución

$$b_1 \sum (x_1 - \bar{x}_1)^2 + b_2 \sum (x_1 - \bar{x}_1)(x_2 - \bar{x}_2) = \sum (x_1 - \bar{x}_1)(y - \bar{y})$$

$$b_1 \sum (x_1 - \bar{x}_1)(x_2 - \bar{x}_2) + b_2 \sum (x_2 - \bar{x}_2)^2 = \sum (x_2 - \bar{x}_2)(y - \bar{y})$$

Luego se debe despejar b_1 y b_2 , se puede usar el método de Gauss Jordán o de reducción, usado en álgebra lineal para resolver sistemas de ecuaciones lineares.

Para poder resolver una regresión múltiple se puede usar una calculadora de mano que tenga incorporada la función de regresión y permita calcular directamente sumas de cuadrados y suma de productos de los valores de “x y”. Para esto se deben utilizar las dos siguientes igualdades conocidas:

$$\sum (x - \bar{x})^2 = \sum x^2 - \frac{(\sum x)^2}{n} \quad \sum (x - \bar{x})(y - \bar{y}) = \sum xy - \frac{\sum x \sum y}{n}$$

Como todas las sumatorias se pueden calcular, este sistema de ecuaciones se resuelve haciendo cero a b_1 o b_2 y luego despejando b_0

La gráfica de la regresión lineal cuando hay dos variables independientes, es una recta en tres dimensiones, sin embargo no se aconseja hacer gráficas con más de dos dimensiones, ya estas que son difíciles de interpretar.

Ejemplo: Hay una hipótesis que sugiere que el consumo de un producto dado, expresado en unidades compradas por persona en un año está influido por: el ingreso por persona que trabaja y el tamaño de habitantes de la ciudad. Hacer estudio de correlación y regresión para responder a la suposición.

Datos

Millones de habitantes por ciudad “ x_1 ”	Ingreso per cápita, en cientos C\$ por habitante “ x_2 ”	Consumo del producto, unidades año “ y ”
0.6	30	11
1.4	34	16
1.3	17	9
0.3	26	9
6.9	29	8
0.3	18	7
4.2	32	11
0.6	32	8

El coeficiente de regresión múltiple $r_{y.x_1x_2}$ es igual a

$$r_{y.x_1 x_2} = \sqrt{\frac{0.00246 + 0.33 - 2(-0.049)(0.574)(0.274)}{1 - 0.075}} = 0.613$$

La regresión se plantea como un sistema de ecuaciones normales, con los siguientes valores obtenidos a partir de las sumatorias antes definidas.

$$b_1 39.38 + b_2 29.5 = -2.35$$

$$b_1 29.5 + b_2 293.5 = 74.25$$

Luego se despeja b_1 y b_2 , en este ejemplo los valores son respectivamente -0.26 y 0.28. Luego se calcula b_0 sabiendo que

$$b_0 = \bar{y} - b_1 \bar{x}_1 - b_2 \bar{x}_2$$

$$b_0 = 9.875 - (-0.27) 1.95 - (0.28) 27.25 = 2.78$$

Calculo de los coeficientes “b” de manera general

Se debe hacer uso de la teoría de algebra matricial, resolviendo la siguiente ecuación:

$$\hat{b} = (X^T X)^{-1} (X^T Y)$$

Siendo:

- $\hat{b}$ Columna vector de coeficientes “b”, la incógnita.
- “Y” el vector de valores observados de la variable dependiente.

- “X” La matriz de los valores de las variables independientes, cuya primera columna está compuesta de valores “1”.
- “X^T” matriz transpuesta de los variables independientes cuya primera fila está compuesta de valores “1”.

Con programas computacionales matemáticos como Derive, se puede fácilmente obtener las matrices inversas y hacer el producto de éstas, haciendo el cálculo paso a paso. Por supuesto los programas estadísticos como INFOSTAT, hacen directamente el cálculo de los estimadores “b”.

5.5 Pruebas de Hipótesis de Correlación y Regresión

Prueba de Hipótesis del Coeficiente de correlación simple

La prueba de hipótesis del coeficiente de correlación poblacional Rho, (letra griega) se construye de la siguiente manera:

$$H_0: \rho = 0$$

$$H_A: \rho \neq 0$$

El estadístico de Contraste es una prueba “t” donde:

$$t_c = r \sqrt{\frac{n-2}{1-r^2}}$$

Esta prueba se hace con n-2 grados de libertad.

Ejemplo con los datos del problema donde “r” correlaciona las notas obtenidas en “Matemáticas” con las notas de “Español”:

$$t_c = 0.891 \sqrt{\frac{10-2}{1-0.891^2}} = 5.55$$

El valor 5.55 es mayor que el valor “t” de tabla con 8 gl, de 2.3, por lo tanto se acepta la hipótesis alternativa, Rho es diferente de 0, existe correlación, por lo tanto se justifica realizar un estudio posterior de regresión.

Análisis de Variancia, ANDEVA, para la Regresión Simple o Múltiple

El ANDEVA, análisis de variancia, permite responder pruebas de hipótesis sobre los parámetros β , la teoría sobre cuándo usar éste tipo de prueba y sus restricciones se desarrollan con detalle en el Capítulo 6. En este caso de manera particular, El ANDEVA responde a la pregunta siguiente:

$$H_0: \beta_1 = \beta_2 = \beta_3 \dots = \beta_k = 0$$

$$H_A: \text{no todos los } \beta_i = 0$$

Esta prueba se puede usar en casos de regresión simple o de regresión múltiple.

Tabla de Análisis de Variancia, ANDEVA

Fuente Variación	Suma de Cuadrados SC	Grados de Libertad GL	Cuadrado Medio CM	“F” Calculada
Total	$\sum_{i=1}^n (y - \bar{y})^2$	n-1		
Regresión	$r_{y.x_1x_2\dots x_k}^2 \sum_{i=1}^n (y - \bar{y})^2$	K	$\frac{SC_R}{GL_R}$	$\frac{CM_R}{CM_E}$
Desviación, Error	$(1 - r_{y.x_1x_2\dots x_k}^2) \sum_{i=1}^n (y - \bar{y})^2$	n-k-1	$\frac{SC_E}{GL_E}$	

Donde “k” es el número de variables independientes y el “n” número de individuos a los cuales se les toma los datos.

Se debe considerar que:

$$\sum_{i=1}^n (y - \bar{y})^2 = \sum_{i=1}^n y_i^2 - \frac{(\sum_{i=1}^n y)^2}{n}$$

$$r_{y.x_1x_2..x_k}^2 = \frac{\sum_{i=1}^n (\hat{y} - \bar{y})^2}{\sum_{i=1}^n (y - \bar{y})^2}$$

Se hizo con INFOSTAT el análisis de variancia del ejemplo de regresión múltiple entre consumo, habitantes e ingreso. Se obtuvo el siguiente cuadro.

Cuadro de Análisis de la Varianza

<i>F.V.</i>	<i>SC</i>	<i>GL</i>	<i>CM</i>	<i>F</i>	<i>p-valor</i>
Total	56.88	7			
Regresión	21.43	2	10.71	1.51	0.3066
Error	35.45	5	7.09		

Como el p-valor es mayor a 0.05 aceptamos la H_0 , los coeficientes β tienen un valor de 0, por lo tanto la regresión estimada no sirve para predecir el consumo.

Prueba de hipótesis para los coeficientes Betas

De manera particular es posible hacer una prueba de hipótesis “t” para cada coeficiente beta, donde:

$$H_0: \beta_i = 0$$

$$H_A: \beta_i \neq 0$$

Dónde $t_{calculado} = \frac{b_i}{s_{b_i}}$, Con n-k-1 grados de libertad y $S_{b_i}^2 = \frac{\sigma_E^2}{\sum (x_i - \bar{x})^2}$

Intervalos de Confianza de los coeficientes Betas

También se pueden construir intervalos de confianza para los diferentes coeficientes de regresión Betas, estos se harían de la siguiente manera:

$$b_i \pm t_{(\alpha), (n-k-1)} s_{b_i}$$

Ejercicio 5.1 Tomar en clase el peso y la altura de 10 personas, hacer el gráfico de dispersión, calcular el coeficiente de correlación y la recta de regresión de estos datos.

Ejercicio 5.2 Hay una hipótesis de investigación que sugiere que el gasto en comida por familia, expresado en C\$ por mes, está influido directamente por el ingreso familiar mensual en C\$. Haga estudio de regresión y correlación de las dos variables. Trabaje con calculadora.

Tabla de datos

Ingreso observado por familia, en cientos C\$	Gasto observados en alimentación, en cientos C\$
30	21
34	26
17	5
26	19
29	18
18	7
32	23
32	25

- Calcular el coeficiente de regresión Lineal, “ r ”.
- Construya la recta de regresión, determinar los parámetros b_0 y b_1 y Realizar “diagnóstico de los datos”, intervalos de predicción y confianza.
- Determine los gastos estimados (“ y ” estimada) por la recta de regresión, para los ingresos observados.
- Se quiere saber si la correlación obtenida con la muestra, es diferente de 0 en la población. Realice una prueba de hipótesis para el coeficiente de correlación “ r ”. El valor “ t ” de tabla es 2.3
- Comente brevemente sobre los coeficientes obtenidos. Responda la hipótesis de la investigación.

Ejercicio 5.3 En una industria de alimentos, quieren saber si se puede predecir la materia seca de raíces de yuca “ y ” a partir de la cantidad de nitrógeno, “ x_1 ”, y fósforo, “ x_2 ”, que poseen las mismas. Esta información permitirá al gerente de una empresa industrial de alimentos, plantear un plan de fertilización para hacer mejores chips. Para este análisis se tienen 20 datos de 20 raíces tomados al azar.

Datos

“Y” Materia seca	X ₁ p.p.m Nitrógeno	X ₂ p.p.m Fósforo
22	76	20
34	82	36
35	121	32
35	88	32
36	90	38
37	94	36
38	81	39
34	79	36
35	79	35
35	86	35

“Y” Materia seca	X ₁ p.p.m Nitrógeno	X ₂ p.p.m Fósforo
22	66	25
33	73	35
21	58	26
17	31	15
38	38	39
18	56	15
22	64	23
35	87	31
19	56	14
29	55	25

Realizar en una calculadora científica con función de regresión simple:

- Construir el coeficiente de correlación múltiple, r_{y,x_1x_2}
- Construir la ecuación de regresión $\hat{y} = b_0 + b_1x_1 + b_2x_2$
- Construir la tabla de análisis de variancia de la regresión
- Concluir los resultados de manera narrativa

Realizar en computadora con el programa INFOSTAT

- Estudios de residuos y de correlaciones bivariadas.
- Interpretación del análisis de variancia de la regresión múltiple.
- El proceso para elegir el mejor modelo, el que tenga el menor cuadrado medio del error, con la rutina “selección del modelo” opciones “backward” y “forward”.

Ejercicio 5.4 Se hizo un estudio correlación múltiple con 4 variables independientes, que se cree sirven para caracterizar el valor de venta de un producto industrial. Las variables independientes son “vida útil del producto”, “Resistencia del producto”, “apreciación visual de la calidad” y “precio de costo del producto”. La variable dependiente era “valor de venta”, fijado por los compradores. Se hizo la regresión y el análisis de variancia de la regresión

Análisis de Variancia de la regresión

Modelo	Suma de Cuadrados	Grados de Libertad	Cuadrado Medio	“F”
Regresión	18.5	4		
Residual	12.0	20		
Total	30.5	24		

Nota: el valor F de tabla es 2.87

- Plantee las 2 hipótesis correspondientes del ANDEVA para una regresión múltiple, con 4 variables independientes.
- Complete la Tabla de ANDEVA, el valor “F” de tabla es 2.71
- Interprete el valor “F” del ANDEVA y responda a la prueba de hipótesis.

Capítulo 6. Diseño y Análisis de Experimentos

Objetivos

- Diferenciar grupos de una población de datos usando diseños experimentales y pruebas de varianzas ANDEVA.
- Hacer inferencias y valorar los modelos de ANDEVA en la solución de problemas experimentales de la vida real y profesional.
- Desarrollar capacidades del trabajo en equipo al momento de realizar investigaciones experimentales.

6.1 Experimentación, conceptos básicos

Experimentar es Investigar en condiciones controladas y con un diseño predefinido.

Un experimento, es una investigación en condiciones controladas. Es la forma más común de investigar en las ingenierías para evaluar nuevas técnicas. Al controlar las condiciones de investigación el número de repeticiones es menor que en una investigación de tipo descriptivo. Para entrar al mundo de la experimentación es necesario manejar algunos conceptos básicos como:

Unidad Experimental es la mínima unidad donde se aplican los tratamientos, puede ser una persona o una comunidad, una planta o una parcela. Es la unidad donde se toma el dato. El tamaño y *número de elementos varía según los objetivos de la investigación.*

Factor de un experimento es una variable independiente nominal o categórica; es una variable cuyos niveles son configurados por el experimentador, “es el tema del experimento”. Un experimento puede tener más de un factor en estudio. Cada valor o tipo del factor se llama Tratamiento o Grupo, estos suelen ser las nuevas técnicas a evaluar, lo que propone como novedoso el investigador.

Tratamientos Testigos son tratamientos de referencia, sirven para comparar los tratamientos propios del experimento. Pueden ser de dos tipos: Absoluto y Relativo. A veces un experimento lleva ambos testigos. El tratamiento absoluto, puede ser “no aplicar tratamiento”, permite medir la variable dependiente, ante la ausencia de las técnicas que se están probando. El tratamiento relativo puede ser la técnica tradicional, lo que se hace de manera corriente, que permite valorar la mejora que producen las nuevas técnicas, tomando como referencia lo que se hace de forma tradicional.

Repetición Es el número de veces que ocurre cada tratamiento. ¡Para poder hacer estadística debe haber repeticiones; Para tener confiabilidad en los resultados de un experimento, el número mínimo de repeticiones no debería ser menor a cuatro.

Tamaño de un experimento: es el número de unidades experimentales del experimento, “n”. Cuando el número de repeticiones por tratamiento es el mismo valor, “n” es igual al número de tratamientos por el número de repeticiones, “ $n = r \cdot t$ ”.

Diseño del experimento. Es el arreglo espacial y en el tiempo de los tratamientos. Cuando más complicado es el diseño, más grados de libertad pierde modelo, pero se controla mejor el error experimental si se conocen las direcciones de los gradiente de las causas de perturbación. En este sentido hay un equilibrio dinámico, un diseño más complejo y que no tiene un mejor el control del error puede ser más ineficiente que un diseño simple. No hay un diseño mejor que otro, el investigador debe descubrir cuál es el mejor diseño para su experimento y este dependerá de la irregularidad del área experimental, del número de tratamientos y de la orientación espacial de las causas que perturban el experimento. El diseño más simple de todos es el Diseño Completamente al Azar, DCA, sin embargo el diseño más utilizado en la agricultura en el de Bloques completos al azar, BCA.

Un diseño experimental más complicado no garantiza un mejor control del error experimental.

Ejercicio 6.1 Se hizo un experimento de evaluación de la durabilidad en horas, de 4 tipos de máquinas: “A”, “B” “C” y “D”. La máquina “D” es la que usa comercialmente la gente y las máquinas “A”, “B” y “C” son nuevos prototipos que se acaban de diseñar. El experimento tiene 5 repeticiones, hay 5 máquinas iguales de cada tipo. Cada unidad experimental era una máquina. Diga:

¿Cuál es el factor en estudio?

¿Cuántas unidades experimentales tiene el experimento?

¿Cuál es la variable dependiente, de investigación?

¿Cuáles son los tratamientos experimentales, nuevas técnicas?

¿Cuál es el tratamiento testigo?

6.2 Modelos ANDEVA

El Análisis de la Varianza (ANDEVA) es una de las técnicas más utilizadas en los análisis de los datos de los diseños experimentales. Se utiliza cuando queremos contrastar más de dos medias, por lo que puede verse como una extensión de la prueba t para diferencias de dos medias.

El ANDEVA usado para analizar experimentos, es un método muy flexible que permite construir modelos estadísticos para el análisis de los datos experimentales. Básicamente es un procedimiento que permite dividir la varianza de la variable dependiente, generalmente variable continua, en dos o más componentes, cada uno de los cuales puede ser atribuido a una fuente (variable o factor) identificable y la otra al error experimental. Las variables independientes son generalmente nominales, son los Factores en estudio y hacen grupos o tratamientos.

Los modelos que permite construir el ANDEVA pueden ser reducidos al cociente entre dos varianzas, el numerador es la varianza del modelo como los tratamientos, bloques, etc. y el denominador es la varianza de los errores. Por ejemplo en un caso de Andeva

unifactorial ó anova one way el valor “F” calculado es $\frac{S_{trat}^2}{S_{error}^2}$.

El ANDEVA está basado en ciertos supuestos, unos más posibles que otros. Es evidente que cuantos más factores introduzcamos se espera que quede menos cantidad de variación residual (error) por explicar. Pero siempre quedará alguna variación residual.

Suposiciones del Análisis de Varianza

En cada ocasión que se realice un análisis de varianza (ANDEVA), rutinariamente deben examinarse los datos para determinar si estos indican alguna desviación de los supuestos que rigen dicho análisis. Por lo tanto, es recomendable realizar un análisis de las suposiciones en las que se basa el ANDEVA junto con el análisis mismo. Sólo después de hacer este análisis de suposiciones y que éstas se cumplan razonablemente, se puede expresar con cierta confianza la validez de los resultados estadísticos.

Las suposiciones en las que se basa el ANDEVA son las siguientes:

- Los errores de los datos son normales.
- Las Varianzas de los distintos tratamientos son homogéneas.
- Hay Independencia de medias y varianzas.
- Los datos siguen un modelo Aditivo.

Normalidad de los errores: Es relativamente fácil hacer pruebas de normalidad de los errores con programas estadísticos computacionales, ya sea con un gráfico QQ plot o la prueba de normalidad de Shapiro Wilks. En la primera prueba el valor “r” de correlación debe ser mayor a 0.95 y en la segunda prueba el valor “p” de la prueba de hipótesis debe ser mayor a 0.05, estar en H_0 . El programa INFOSTAT puede calcular los errores de cada dato y hace ambas pruebas. Sin embargo este requisito no es tan importante como la Independencia de las Observaciones, pues en general el ANDEVA es una prueba robusta. Esto quiere decir que, aunque los errores de las observaciones no sean normales, las medias de los tratamientos son aproximadamente normales

debido al Teorema Central del Límite. Sin embargo, si los errores de los datos son extremadamente no-normales, es posible transformar los datos para cubrir este requisito, o bien emplear métodos no paramétricos.

Homogeneidad de varianzas de los diferentes tratamientos: Es muy importante para el modelo verificar si hay homogeneidad de las varianzas de los diferentes tratamientos, pues si esto no se cumple se pueden invalidar los resultados de una H_A . Una población heterogénea en varianzas no permite detectar si las diferencias observadas se deben a diferencias de promedios o de las varianzas.

Para corroborar o refutar las afirmaciones hechas respecto de la hipótesis de la homogeneidad de las varianzas de los grupos o tratamientos respecto a la variable dependiente, se dispone de la prueba de Levene de homogeneidad de varianzas. Esta prueba funciona como un estadístico F de la distribución “F” de Fisher, donde la H_0 consiste en suponer que las varianzas de los errores absolutos de los distintos grupos son iguales. Se rechazará esta H_0 en el caso de que la significación del estadístico sea menor que 0,05. El estadístico de Levene se hace realizando una ANDEVA con los errores en valor absoluto, INFOSTAT calcula este tipo de error.

Independencia de promedios y varianzas: Que un promedio mayor no tenga independencia entre medias y varianzas es un caso especial de falta de homogeneidad de varianzas. En algunos datos existe una relación definida entre las medias y sus varianzas, por ejemplo el número de hojas de plantas de tomate de un mes y de tres meses, en ambos casos no solo hay diferencias de promedios sino también de varianzas, a más edad mayor promedio y varianza. Este problema se puede manejar con un buen diseño del experimento. Sin embargo esta relación suele ser la causa más común de heterogeneidad de varianza. Una correlación positiva entre medias y varianzas es una forma de detectar el problema. El estadístico de Levene también detecta este problema.

Aditividad del modelo

Una prueba ANDEVA supone que los datos siguen un modelo lineal aditivo. Para cada diseño experimental se construye un modelo matemático lineal aditivo, para el caso de un diseño completamente aleatorio, DCA, es $x_{ij} = \bar{x} \pm \alpha_i \pm \varepsilon_{ij}$. La ecuación expresa que el valor de cualquier unidad experimental está compuesta por la media general, más o menos el efecto de tratamiento α_i y más o menos un termino de error característico de cada dato ε_{ij} . En este modelo los términos se suman, si esto no ocurre así, el ANDEVA nos puede llevar a conclusiones incorrectas. La falta de aditividad puede ocurrir por un mal diseño del experimento, por ejemplo si se prueban diferentes dosis de fertilizante, pero cada dosis se prueba en una especie de planta diferente, puede resultar una interacción entre dosis de fertilizante y especie de planta, lo que rompa el modelo aditivo.

¿Qué hacer cuando el modelo no funciona?

La violación o falta de apego a cualquiera de estas suposiciones indica que los resultados del ANDEVA podrían no tener validez. Dependiendo del tipo de problema, puede haber solución o no al objetivo buscado en el experimento. El dilema más fuerte con el que ha de luchar el investigador es el de la falta de homogeneidad de varianzas, ya que si esto ocurre, no podemos saber si las diferencias entre los tratamientos se deben a promedios diferentes o varianzas diferentes.

La falta de normalidad no es tan importante, pues la prueba ANDEVA es robusta a este problema y, en casos extremos, se puede optar por el uso de transformaciones de datos. En general para los casos en que los supuestos de normalidad, homogeneidad, independencia de medias-varianzas o aditividad no se cumplen, se puede usar transformaciones de datos, las más usadas son:

- Logaritmo Log (x), útil cuando los datos crecen en sentido exponencial o cuando las desviaciones estándares de las muestra sean aproximadamente

proporcionales a los promedios o hay evidencia de efectos principales multiplicativos de los tratamientos en vez de aditividad.

- La transformación $\sqrt{x + 0.5}$ útil cuando los números observados son pequeños 0-10, por ejemplo son acontecimientos pocos comunes, tienen una posibilidad muy baja de ocurrir en cualquier individuo. Estos datos tienden a seguir una distribución de Poisson.
- La transformación $\text{Arcoseno } \sqrt{x/100}$ cuando los datos son expresados en por ciento o son proporciones de la muestra total. Por lo general estos datos tienen una distribución binomial y no de una distribución normal como se espera.

Como último recurso, ante datos dudosos de análisis se puede hacer uso de métodos de estadística no paramétrica. Es importante mencionar que el empleo de estadística no paramétrica o el uso de transformaciones no eliminan el problema de la falta de aleatoriedad de las unidades experimentales, errores por un mal diseño del experimento o por una mala toma de datos, es decir, la ejecución incorrecta de un experimento, no se tiene más remedio que repetir el experimento, corrigiendo los errores por falta de diseño o mal manejo.

6.3 Andeva uni factorial, anova one way, diseño DCA.

Anova one way es como se le llama en lengua inglesa al Andeva Unifactorial y como comúnmente aparece citado en la bibliografía. Este es el modelo más simple y más usado de ANDEVA, este tiene un único Factor, variable, que genera grupos o tratamientos y una variable dependiente continua. Este es un modelo que funciona aun cuando el número de repeticiones por tratamiento no es constante. El modelo supone que las repeticiones de los distintos tratamientos están distribuidas al azar dentro del experimento y que no necesariamente cada grupo o tratamiento tiene igual número de repeticiones. El diseño de este modelo estadístico se llama Diseño Completamente aleatorio y generalmente funciona bien controlando el error experimental cuando no hay perturbaciones externas con algún sentido definido, como viento, tipos de suelo diferentes, variaciones térmicas, etc.

El Diseño Completamente Aleatorio, DCA, supone que las diferentes unidades experimentales del experimento se encuentran al azar dentro del área experimental y al mismo tiempo. El DCA se utiliza mucho en investigaciones sociales, cuando se posee información de variables dependientes continuas como “peso”, “altura”, “edad” o “ingresos” y variables nominales que hacen grupos como “nivel social” “procedencia” “sexo” etc. También se usa mucho en experimentación en laboratorios, donde se tiene un buen control de aquellos factores que puedan perturbar la investigación. El modelo supone que se debe disponer de los resultados de k muestras aleatorias independientes, cada una de tamaño n_k , de k diferentes poblaciones; y lo que interesa probar es la hipótesis que las medias de esas k poblaciones son todas iguales, o no.

ANOVA ONE WAY : Modelo Estadístico supuesto, es Lineal:

$$x_{ij} = \bar{x} \pm \alpha_i \pm \varepsilon_{ij}$$

x_{ij} = Valor de la n -ésima observación ubicada en el tratamiento “ i ”.

$\bar{x}$ = Promedio General

α_i = Efecto del tratamiento “ i ” que es igual a $\bar{x}_{Ti} - \bar{x}$, la media del tratamiento “ i ” menos la media general. Estos efectos puede tener valor positivo o negativo y el modelo supone que hay variación entre los tratamientos, por lo tanto se puede calcular su variancia, $S_{\alpha \text{ tratamientos}}^2$

ε_{ij} = Error o Variación de las observaciones ubicada en la repetición “ j ” y tratamiento “ i ”. El valor del error puede ser negativo o positivo. Se cumple que la suma y promedios de los errores son iguales a 0. Sin embargo es posible calcular la variancia, S_{ε}^2

Tipo de Hipótesis en un ANOVA ONE WAY

H_0 : $\mu_1 = \mu_2 = \mu_3 = \mu_k$, como se supone que la variancia de los tratamientos es semejante a la variancia del error, por lo tanto la relación $S_\alpha^2/S_\varepsilon^2$ debe ser un valor pequeño, cercano a uno.

H_A : no todos los μ son iguales, al menos el menor y mayor promedios son diferentes.

Esto supone que la relación $S_\alpha^2/S_\varepsilon^2$ es un valor relativamente grande, ya que la variancia de los tratamientos es varias veces mayor a la variancia del error.

Estadístico de Prueba:

$$F_{\text{calculado}} = S_\alpha^2/S_\varepsilon^2$$

Regla de Decisión:

Si el valor $F_{\text{calculado}}$ es mayor que el valor frontera tomado de una tabla de distribución F_{tabla} , se rechaza H_0 , ya que el $F_{\text{calculado}}$ está en la zona de rechazo de la hipótesis nula, H_0 de la distribución “F”. El valor de “F” de frontera se busca en una tabla de valores “F”, donde el valor de las columnas son los grados de libertad de los tratamientos y los de las filas son los grados de libertad del error, para un α del 0.05.

Si se usa un programa estadístico el análisis de hipótesis se hace con el “P” valor.

- Si “P” $\geq$ 0.05 se está en H_0 .
- Si “P” $<$ 0.05 se está en H_A .

Modelo de ANDEVA

Causa de Variación	Grados de Libertad GL	Suma de Cuadrados SC	Cuadrado Medio, CM “S²”	“F_{Calculado}”
Tratamientos	“t - 1”	$\frac{\sum_1^t (\sum_1^r x_i)^2}{r} - \frac{(\sum_1^n x_{ij})^2}{n}$	$\frac{SC_{\text{Tratamientos}}}{GL_{\text{Tratamientos}}}$	$\frac{S_{\text{tratamientos}}^2}{S_{\text{error}}^2}$
Error	“(n - 1) - (t - 1)”	SC _{total} - SC _{tratamientos}	$\frac{SC_{\text{Error}}}{GL_{\text{error}}}$	

Total	"n - 1 "	$\sum_1^n (x_{ij})^2 - \frac{(\sum_1^n x_{ij})^2}{n}$		
-------	----------	---	--	--

Estadísticos que verifican calidad de los datos, R^2 y CV

Al interpretar un ANDEVA es importante medir que tan bueno fue el modelo estadístico aplicado y si el error experimental fue controlados por el diseño experimental. Para este tipo de análisis disponemos de dos coeficientes fáciles de calcular el "coeficiente de determinación", R^2 , y "el coeficiente de variación aplicado al error" CV .

El coeficiente de Determinación, R^2

Este coeficiente muestra que proporción de la variación total de los datos está siendo explicada por el modelo adoptado, R^2 es un valor entre 0 y 1; a más cerca de 1 mejor funciona el modelo. El R^2 se construye con la suma de cuadrados de la tabla ANDEVA de la siguiente manera: $R^2 = SC_{Modelo} / SC_{Total}$. En el caso de un DCA la suma de

cuadrados del modelo, SC_{Modelo} , es la suma de cuadrados de los tratamientos. En el caso de un BCA (bloques completos al azar), la SC_{Modelo} es igual a la $SC_{Tratamientos} + SC_{Bloques}$. En una caso de un cuadro latino, CL, la SC_{Modelo} es igual a la $SC_{Tratamientos} + SC_{Filas} + SC_{columnas}$.

El Coeficiente de Variación, CV, aplicado a un experimento

El Coeficiente de Variación, CV, sirve para medir la variación interna de los tratamientos, variación que se refleja en la variancia del error o cuadrado medio del error. Un experimento mal manejado puede presentar mucha variación entre las repeticiones de un mismo tratamiento, esto es error experimental. El CV también está en dependencia de la variable que se mide o pesa. Si la variable está bien controlada, en un experimento biológico a campo el CV deberá ser menor a 20 %, incluso en laboratorio se pueden exigir CV menores al 10 %. Sin embargo en investigación social descriptiva o en variables biológicas no controladas como es una plaga, es común que los CV sean grandes. Sin embargo en experimentos en la industria con condiciones

muy controladas se espera CV muy bajos. El investigador debe explicar la causa de

esta variación. La forma de cálculo es: $CV = \sqrt{CM_{Error}} / \bar{X}$ (100)

Un Ejemplo de ANDEVA uni factorial

Una tesis de estudiantes evaluó 4 tipos de abono, uno con base de pulpa de café, otro con base de abono de lombriz, lombrihumus, y se utilizaron 2 testigos, uno con la dosis de fertilización química tradicional, testigo relativo y otra con tierra sin abono extra, testigo absoluto. La variable de producción fue grs. promedio del peso seco de las plántulas de café a los 6 meses de siembra por unidad experimental, el ensayo tuvo cuatro repeticiones. A continuación se muestran los datos obtenidos.

Tabla de Datos. Peso en onzas. Parte aérea plántula de café.

Tratamiento/ Repeticiones	I	II	III	IV	$\sum_{tratam}$	$\bar{X}$
Pulpa café	1.00	0.90	1.16	0.98	4.04	1.01
Abono de lombriz	1.65	1.59	2.00	1.65	6.89	1.72
Químico	1.69	1.52	1.40	1.46	6.07	1.52
Tierra	0.58	0.60	0.60	0.46	2.24	0.56
$\Sigma_{repeticiones}$	4.92	4.61	5.16	4.55	19.24	

Tabla de ANDEVA

Causa de Variación	Grados de Libertad	Suma de Cuadrados	Cuadrado Medio, CM “S ² ”	“F _{Calculada} ”
Tratamientos	4 – 1 = 3	3.28	3.28/ 3 =1.09	1.09/0.02= 65.18
Error	15- 3 = 12	0.20	0.2/12 =0.017	P valor 0.00

Total	16 – 1 = 15	3.48		
-------	-------------	------	--	--

$$\text{Suma de Cuadrados Total} = \sum_1^n (x_{ij})^2 - \frac{(\sum_1^n x_{ij})^2}{n}$$

$$= (1.00^2 + 0.90^2 + 1.16^2 + 0.98^2 \dots + 0.46^2) - ((1.00 + 0.90 + 1.16 + 0.98 \dots + 0.46)^2 / 16) = 26.61 - 19.24^2 / 16 = 26.61 - 23.13 = \mathbf{3.48}$$

$$\text{Suma de cuadrados de los Tratamientos} = \frac{\sum_1^t (\sum_1^n x_j)^2}{r} - \frac{(\sum_1^n x_{ij})^2}{n}$$

$$= ((4.04)^2 + (6.89)^2 + (6.07)^2 + (2.34)^2) / 4 - (19.24^2 / 16) = (106.11 / 4) - 23.13 = \mathbf{3.28}$$

Interpretación

La prueba resulta en H_A : no todos los μ son iguales

Ya que la “F” calculada 65.18 > “F” Tabla 3.49 (con 3 y 12 grados de libertad)


El Diseño Completamente al Azar, DCA se resuelve estadísticamente con un ANDEVA unifactorial, ANOVA ONE WAY

Verificación del modelo.

Para realizar un estudio de normalidad y homogeneidad de las variancias es necesario calcular los errores y hacer pruebas de normalidad y homocedasticidad. Con los programas Excel o INFOSTAT se pueden calcular los errores de cada valor observado de la manera: $\varepsilon_{ij} = x_{ij} - \bar{x} - (\bar{x}_{ti} - \bar{x})$

Tratamiento	Peso	Media Total	Media Tratamiento	Efecto Tratamiento	Error	Error Absoluto
Pulpa café	1.00	1.2	1.01	-0.19	-0.01	0.01
Pulpa café	0.90	1.2	1.01	-0.19	-0.11	0.11

Tratamiento	Peso	Media Total	Media Tratamiento	Efecto Tratamiento	Error	Error Absoluto
Pulpa café	1.16	1.2	1.01	-0.19	0.15	0.15
Pulpa café	0.98	1.2	1.01	-0.19	-0.03	0.03
Lombrihumus	1.65	1.2	1.72	0.52	-0.07	0.07
Lombrihumus	1.59	1.2	1.72	0.52	-0.13	0.13
Lombrihumus	2.00	1.2	1.72	0.52	0.28	0.28
Lombrihumus	1.65	1.2	1.72	0.52	-0.07	0.07
Químico	1.69	1.2	1.52	0.32	0.17	0.17
Químico	1.52	1.2	1.52	0.32	0.00	0.00
Químico	1.40	1.2	1.52	0.32	-0.12	0.12
Químico	1.46	1.2	1.52	0.32	-0.06	0.06
Tierra	0.58	1.2	0.56	-0.64	0.02	0.02
Tierra	0.6	1.2	0.56	-0.64	0.04	0.04
Tierra	0.6	1.2	0.56	-0.64	0.04	0.04
Tierra	0.46	1.2	0.56	-0.64	-0.1	0.1



En el Gráfico QQ plot de los residuos se observa que éstos se distribuyen cercanos a la recta de regresión de la normal, lo que hace suponer que los residuos se distribuyen de manera normal. También el programa hace regresión de los residuos y la recta normal y esta fue de $r = 0.95$, valor suficiente para aceptar la normalidad.

Valores de la prueba Shapiro-Wilks para verificar normalidad por prueba de hipótesis.

Variable	n	Media	D.E.	W*	p (una cola)
Rduo gr planta	16	0.00	0.12	0.89	0.10

La prueba de normalidad de Shapiro Wilks para los errores del modelo, realizado con el programa INFOSTAT, confirma que éstos se distribuyen de manera normal. Se acepta la H_0 de normalidad de los errores ya que el valor calculado “p” de 0.10 es mayor al valor de 0.05.


Para verificar la homogeneidad de las variancias, se hizo la prueba de Levene, que consistió en hacer un ANDEVA de los valores promedios de los errores de los tratamientos en valor absoluto.

Cuadro de Análisis de la Varianza de los errores en valor absoluto

F.V.	SC	gl	CM	F	p-valor
Abono	0.02	3	0.01	1.10	0.39
Error	0.06	12	0.01		
Total	0.08	15			

Como el “p” valor de 0.39 es mayor al valor de 0.05 se concluye que ocurre H_0 , las variancias de los errores absolutos de los diferentes tratamientos son iguales, por lo tanto en este experimento se cumple la homogeneidad de variancias.

Para observar gráficamente la homogeneidad de varianzas se puede construir un gráfico de densidad de puntos con los valores por tratamiento de los residuos absolutos, estos puntos deben tener una dispersión semejante en los diferentes tratamientos. A continuación se observa el ejemplo.



Calidad de los datos

El coeficiente de determinación fue bastante alto, lo que explica que el modelo funcionó bastante bien explicar la variación total de los datos, el $R^2 = 3.28/3.48 = 0.94$ es un valor muy alto. El coeficiente de variación tuvo un valor bastante aceptable para un experimento de fertilización a campo, este fue: $CV = \sqrt{0.017}/1.2 (100) = 11 \%$

Ejercicio 6.2 En un estudio socioeconómico se tuvo 75 datos, correspondientes a muestras de diferentes ciudades de cada país. Donde la variable dependiente estudiada fue “calorías ingeridas por día” y la variable dependiente es “País”, en total 8 países. En este caso la Hipótesis nula a responder es: ¿La cantidad promedio de calorías diarias ingeridas por persona es igual en todas las regiones económicas del mundo? A continuación se muestra la tabla incompleta de **ANDEVA**.

Tabla de Análisis de Variancia, ANDEVA.

Causa De variación	Suma de Cuadrados	Grados de Libertad	Cuadrado Medio	“F”
Entre Grupos	1,445	7		
Error, dentro del grupo	5,382	67		
Total		74		

¿Completar la tabla de ANDEVA?

¿Construya las 2 hipótesis correspondientes?

¿Interprete y comente los resultados?

Ejercicio 6.3 Se quería saber si los estudiantes utilizan la teoría explicada en el aula al resolver problemas prácticos. Se hizo un experimento con 12 estudiantes, se formaron 3 grupos, A-B-C, de cuatro estudiantes cada uno. A cada grupo se les dio un ejercicio matemático semejante para resolver de manera individual. A los cinco minutos al grupo B se le dio un papel con una información teórica adicional y al grupo C se les dio un papel con dos informaciones. Cada estudiante resolvía el problema de manera individual. La variable dependiente fue el tiempo medido en segundos.

Los datos obtenidos fueron los siguientes:

Grupo/ Segundos para resolver	E.1	E.2	E.3	E.4
A. Testigo	242	206	300	282
B. Un información adicional	176	129	128	190
C. Dos informaciones adicionales	155	106	122	115

¿Construya las 2 hipótesis correspondientes?

¿Resolver la tabla de ANDEVA?

¿Interprete y comente los resultados?

Verifique el modelo. ¿Son los errores normales, y las variancias de los grupos homogéneas?

6.4 ANDEVA para un Diseño BCA

El diseño de bloques completamente al azar, BCA, es un diseño ampliamente utilizado a campo en centros experimentales agronómicos. Es ideal para evaluar variedades, distancias de siembra, control de plagas, etc. Este diseño permite controlar al menos el principal gradiente de error que posee el área experimental.

El diseño. Un bloque es (en Estadística) un grupo de observaciones que pueden y deben ser analizadas e interpretadas sólo de modo conjunto. Se dice que un bloque es

un bloque completo cuando todos sus elementos componentes tienen valores válidos y están representados todos los tratamientos.

Un bloque puede estar fijado o establecido por el investigador de modo arbitrario. En este caso, se dice que ese bloque es un bloque no aleatorio. Pero puede que este bloque esté fijado, configurado o seleccionado según la ley estadística del azar, en cuyo caso se dice que el bloque es un bloque aleatorio.

El BCA exige que en cada bloque se encuentren todos los tratamientos, de ahí el nombre de “bloques completos” y que los bloques se ubiquen de manera transversal al gradiente que perturba de mayor grado el área experimental, por ejemplo: pendiente de suelos, vientos, riego, luz, etc. De esta manera se trata de reducir la suma de cuadrados del error, de reducir la varianza del error y así poder explicar la variación ocurrida en el área experimental. El punto débil del modelo es que se pierden grados de libertad del error, por lo tanto, sino se reduce la suma de cuadrados del error el BCA pierde precisión frente a un DCA.

En nuestras condiciones se recomienda usar cuando hay menos de 15 tratamientos, ya que con un número mayor de tratamientos es muy difícil de manejar a campo, aún experimentos de 10 tratamientos son difíciles de implementar sin aumentar el error experimental a niveles que hacen dudar de los resultados.

El BCA es el diseño más utilizado en la experimentación agrícola

El Modelo Estadístico, lineal.

$$x_{ij} = \bar{x} \pm \alpha_i \pm \beta_j \pm \varepsilon_{ij}$$

x_{ij} = Valor de la “j” observación ubicada en el “i” tratamiento.

$\bar{x}$ = Promedio General

α_i = Efecto del tratamiento “i”

β_j = Efecto del Bloque “j”

ε_{ij} = Variación o error de las observaciones ubicada en el bloque “j”, utilizando el tratamiento “i”.

Desde el punto estadístico el modelo es semejante al utilizado para resolver un diseño completamente aleatorio, DCA, solo que se le agrega una nueva causa de variación, que en este caso son los bloques. El modelo supone que no existe interacción entre los bloques y que los efectos son fijos sin importar los tratamientos, esto quiere decir que un tratamiento dado no puede ser de los mejores promedio en un bloque y ser de los peores en otro.

Al realizar el experimento lo que se espera es que haya diferencias significativas entre los bloques, que estos absorban error experimental. Sin embargo esta prueba solo es referencial ya que desde un punto de vista estricto de diseño, los bloques no tienen repeticiones.

ANDEVA bifactorial sin interacción es el modelo estadístico para análisis de un diseño B.C.A

Análisis de Varianza

Hipótesis:

Sobre los tratamientos

H₀: $\mu_1 = \mu_2 = \dots = \mu_k$, **H_A:** no todas los μ_k son iguales

Sobre los bloques

H₀: $\mu_1 = \mu_2 = \dots = \mu_j$, **H_A:** no todas μ_j son iguales

Estadísticos de Prueba:

F_{tratamientos} = $S^2_{tratam} / S^2_{error}$; **F_{bloques}** = $S^2_{bloque} / S^2_{error}$

Regla de Decisión:

Si $F_{calculado}$ es mayor que la F_{tabla} se rechaza H_0

Tabla de ANDEVA de un BCA

Causa de Variación	Grados de Libertad	Suma de Cuadrados	Cuadrado Medio, CM "S ² "	"F _{Calculado} "
Tratamientos	"t - 1"	$\frac{\sum_1^t (\sum_1^b x_j)^2}{b} - \frac{(\sum_1^n x_{ij})^2}{n}$	$\frac{SC_{Tratamientos}}{GL_{Tratamientos}}$	$\frac{S_{tratamientos}^2}{S_{error}^2}$
Bloques	"b - 1"	$\frac{\sum_1^b (\sum_1^t x_j)^2}{t} - \frac{(\sum_1^n x_{ij})^2}{n}$	$\frac{SC_{bloques}}{GL_{bloques}}$	$\frac{S_{bloques}^2}{S_{error}^2}$
Error	"(n - 1) - (t - 1) - (b - 1)"	SC _{total} - SC _{tratam} - SC _{bloq}	$\frac{SC_{Error}}{GL_{error}}$	
Total	"n - 1"	$\sum_1^n (x_{ij})^2 - \frac{(\sum_1^n x_{ij})^2}{n}$		

Donde:

"i" es cualquier tratamiento

"j" es cualquier bloque

"t" es el número de tratamientos

"b" es el número de bloques

"n" es el número de unidades experimentales, es igual a "b x t".

Un Ejemplo

Para comparar diseños se analiza el mismo ejemplo anterior, de los fertilizantes, pero considerando que las repeticiones tuvieron un diseño de bloques

Tabla de ANDEVA

Causa de Variación	Grados de Libertad	Suma de Cuadrados	Cuadrado Medio, CM “S ² ”	“F _{Calculada} ”
Tratamientos	4 – 1 = 3	3.28	1.09	Tratamiento 70.07
Bloques	4 – 1 = 3	0.06	0.02	
Error	15- 3 - 3= 9	0.14	0.016	Bloques 1.29
Total	16 – 1 = 15	3.48		

$$\begin{aligned} \text{Suma de cuadrado Total} &= \sum_1^n (x_{ij})^2 - \frac{(\sum_1^n x_{ij})^2}{n} \\ &= (1.00^2 + 0.90^2 + 1.16^2 + 0.98^2 \dots + 0.46^2) - ((1.00 + 0.90 + 1.16 + 0.98 \dots + 0.46)^2 / 16) \\ &= 26.61 - 19.24^2 / 16 = 26.61 - 23.13 = \mathbf{3.48} \end{aligned}$$

$$\begin{aligned} \text{Suma de cuadrados de los Tratamientos} &= \frac{\sum_1^t (\sum_1^b x_j)^2}{b} - \frac{(\sum_1^n x_{ij})^2}{n} \\ &= ((4.04)^2 + (6.89)^2 + (6.07)^2 + (2.34)^2) / 4 - (19.24^2 / 16) \\ &= (106.11 / 4) - 23.13 = \mathbf{3.28} \end{aligned}$$

$$\begin{aligned} \text{Suma de cuadrados de Bloques} &= \frac{\sum_1^b (\sum_1^t x_j)^2}{t} - \frac{(\sum_1^n x_{ij})^2}{n} \\ &= (4.92^2 + 4.61^2 + 5.16^2 + 4.55^2 / 4) - (19.24^2 / 16) \\ &= (96.12 / 4) - 23.13 = \mathbf{0.06} \end{aligned}$$

$$\begin{aligned} \text{Suma de cuadrados del Error} &= \text{S.C total} - \text{S.C tratamientos} - \text{S.C bloques} \\ 3.48 - 3.28 - 0.06 &= \mathbf{0.14} \end{aligned}$$

$$\begin{aligned} \text{Cuadrado Medio de los tratamientos} &= \text{S.C}_{\text{tratamientos}} / \text{G.L}_{\text{tratamientos}} \\ 3.28 / 3 &= \mathbf{1.09} \end{aligned}$$

$$\begin{aligned} \text{Cuadrado Medio de los bloques} &= \text{S.C}_{\text{bloques}} / \text{G.L}_{\text{bloques}} \\ 0.06 / 3 &= \mathbf{0.02} \end{aligned}$$

$$\begin{aligned} \text{Cuadrado Medio del error} &= \text{S.C}_{\text{error}} / \text{G.L}_{\text{error}} \\ 0.14 / 9 &= \mathbf{0.016} \end{aligned}$$

$$“F_{\text{tratamientos}}” = C.M_{\text{tratamientos}} / C.M_{\text{error}}$$

1.09 / 0.016 = **68.12** (la variancia de los tratamientos es 68.12 veces mayor que la variancia del error)

$$“F_{\text{bloques}}” = C.M_{\text{bloques}} / C.M_{\text{error}}$$

$$0.02 / 0.016 = \mathbf{1.25}$$

Interpretación de la prueba de hipótesis.

Siendo “F”_{calculada} = **68.12** > “F”_{tabla, 3-9 GL} = $\alpha_{0.05}$ **3.86**.

El resultado se encuentra en Hipótesis alternativa, es decir “al menos uno de los tratamientos es diferente al resto”, ahora se debe hacer una prueba de separación de promedios para conocer el detalle de las diferencias entre los tratamientos. Sin embargo los bloques no son significativos, lo que significa que estos no disminuyeron el error.

Separación de Promedios

Estas pruebas se realizan solamente cuando el resultado del ANDEVA refleja que estamos en H_A , es decir al menos los promedios extremos son diferentes. Las pruebas que veremos son: Diferencias significativas mínimas, Prueba de rangos múltiples de Duncan y la Prueba de rangos múltiples de Tukey.

Diferencia Significativa Mínima, DSM, LSD

La prueba de diferencia significativa mínima, DSM o LSD en inglés, solo se debe usar para comparar promedios adyacentes, o contra un testigo estándar, donde no se involucren en la comparación más de 2 promedios. Esta prueba suele ser poco usada, pero sirve como insumo para realizar la prueba de Duncan que es más popular.

$$DSM_{0.05} = “t_{0.05}” \sqrt{\frac{2(CM_{error})}{r}}$$

$$DSM_{0.05} = 2.262 \sqrt{\frac{2(0.016)}{4}} = 0.20 \text{ gr}$$

El valor “t” de tabla se busca con los grados de libertad del error, en este caso es de 9 y para un alfa del 5 %. El valor DSM de 0.20 gr se contrasta con las diferentes diferencias de promedios respecto al testigo. Si la diferencia de promedios es mayor que el valor DSM, se concluye que estos promedios son diferentes.

Tratamientos	X en gr	Diferencia con el testigo Tierra de 0.56 gr	Diferencias mayores de 0.20 gr
Lombrihumus	1.72	1.16	Si
Químico	1.52	0.96	Si
Pulpa café	1.01	0.45	Si

Conclusiones: el lombrihumus, el fertilizante químico y la pulpa de café son mejores estadísticamente que el testigo tierra sin fertilizante.

Prueba de Rangos múltiples de Duncan.

Es una prueba muy usada cuando tienen 6 o menos tratamientos, con un número mayor generan muchos subgrupos de comparación, lo que hace difícil la interpretación de resultados

$$DSM_{0.05 \text{ Duncan}} = DSM_{0.05} R$$

Donde R es un valor extraído de una tabla de factores studentizados significativos que se elige de acuerdo con el nivel de significación deseado, con los grados de libertad para el error y con la disposición relativa de las medias en el arreglo, ver la tabla en el libro de Little, T y Hills F, 1989.

Prueba de Rangos múltiples de Tukey

Es una prueba muy estricta, robusta, se sugiere usar cuando hay mas de 6 tratamientos o se quieren resultados de separaciones muy confiables.

$$DSM_{Tukey} = q_{\alpha, gl\ error, "t"} * \sqrt{\frac{CM_{error}}{r}}$$

Donde “q” es un valor tabulado, ver tabla en Daniel (2006), donde se considera: el valor alfa de 0.05, los grados de libertad del error, 9, y el número de tratamientos, 4. En este ejemplo el valor “q” es 4.415

$$DSM_{Tukey} = 4.415 = \sqrt{\frac{0.016}{4}} = 0.28\ gr$$

Tabla de Diferencias

Tratamientos	Lombri humus	Químico	Pulpa café	Tierra
Lombrihumus	-	0.20 NS	0.71**	1.16**
Químico		-	0.52**	0.96**
Pulpa café			-	0.45**
Tierra				-

Según este cuadro, los fertilizantes “lombrihumus y “químico” son iguales y diferentes y mejores a los otros dos tratamientos, pero “pulpa de café” es mejor que “tierra”. En este ejemplo, coinciden en resultados la prueba de Tukey y la prueba DSM, debemos considerar que no siempre sucede así.

6.5 Diseño de Cuadro Latino

El diseño de cuadro latino, CL, es un diseño trifactorial sin interacciones, que es adecuado implementar cuando se pueden encontrar fuentes extrañas de perturbación al experimento en dos sentidos con relativamente pocas repeticiones, lo que significa

un menor gasto al momento de hacer experimentos. Un ejemplo de CL en un experimento de agronomía puede considerar como factores de perturbación el “viento” de norte a sur y un gradiente de fertilidad de este a oeste. Este modelo considera la existencia de bloques dobles, bloques por filas y bloques por columnas. Una Característica importante de este tipo de diseño es su balance, que se logra asignando el mismo número de observaciones a cada tratamiento de cada bloque, por esto son diseños en cuadro.

El cuadro latino, es un diseño trifactorial sin interacciones que resuelve preguntas de tres factores con pocas repeticiones

Un ejemplo de cuadro latino en nutrición animal, consiste en comparar tres diferentes alimentos A-B-C, donde un bloque son diferentes grupos de animales que comen los alimentos y el otro bloque es el tiempo en que a cada grupo de animales se le aplica los diferentes alimentos. En resumen hay: tres tipos de alimentos y tres tiempos, T, de alimentación para tres grupos de animales, el experimento podría disponerse según el patrón siguiente:

Grupo Animales	T1	T2	T3
/Tiempo			
Grupo 1	A	B	C
Grupo 2	C	A	B
Grupo 3	B	C	A

Donde A-B-C son los diferentes tipos de alimentos.

En este caso, cada alimento se aplica una sola vez por cada grupo de animales junto con cada tiempo, y si existiesen efectos sistemáticos debido a diferencias entre los animales o entre los tiempos, dichos efectos estarían presentes de igual manera en cada tratamiento, esto es, en cada tipo de alimento.

En este modelo se pueden observar que las diagonales repiten el mismo grupo, ver el caso de la diagonal A-A-A, B-B y C-C. Estas diagonales no son problema en esta caso ya que las columnas son el Factor “tiempo”, y el tiempo no se perturba diagonalmente, sin embargo si el diseño fuera con filas y columnas en el espacio, por ejemplo filas E-O y columnas N—S, las diagonales no son deseables ya que pueden ser una fuente de error. En este caso se recomienda sortear filas y columnas de forma independiente.

Un arreglo experimental como el que se describió se denomina *cuadrado latino* 3X3. Un cuadrado latino n x n es un arreglo cuadrado, los tratamientos aparecen solo una vez en cada fila y en cada columna.

Ej. de Modelo 4x4, es el más usado

A	B	C	D
B	C	D	E
C	D	A	B
D	A	B	C

Ej. Modelo 5x5

A	B	C	D	E
B	A	E	C	D
C	D	A	E	B
D	E	B	A	C
E	C	D	B	A

Modelo Estadístico Lineal Del Cuadro Latino

$$x_{ij} = \bar{x} \pm \alpha_i \pm c_j \pm f_k \pm \varepsilon_{ij}$$

x_{ij} = valor de la observación “i” ubicada en la columna “k” con la fila “j” usando el tratamiento “i”.

$\bar{x}$ = Promedio General

α_i = Efecto del tratamiento “i”

c_j = Efecto de la columna “j”

f_j = efecto de la fila “k”

ε_{ij} = Variación de las observaciones ubicada en la columna “K”, con la fila “j”, usando el tratamiento “i”.

Análisis de Varianza

Hipótesis:

Sobre los tratamientos

Ho: $\mu_1 = \mu_2 = \dots = \mu_i$ **H_A:** no todas las μ_i , tratamientos, son iguales

Sobre el Factor en columna

Ho: $\mu_1 = \mu_2 = \dots = \mu_j$ **H_A:** no todas las μ_j , columnas, son iguales

Sobre el Factor en Fila

Ho: $\mu_1 = \mu_2 = \dots = \mu_k$, filas, son iguales. **H_A:** no todas las μ_k son iguales

Estadísticos de Prueba:

F1= S_t^2/S_{error}^2 ; **F2=** S_f^2/S_{error}^2 ; **F3=** S_c^2/S_{error}^2

Tabla de ANDEVA de un Cuadro Latino

Causa de Variación	Suma de Cuadrados	Grados de Libertad	Cuadrado Medio, CM “S ² ”	“F _{Calculado} ”
Tratamiento	SC _T	t-1	S _t ²	S _t ² / S _{error} ²
Filas	SC _F	c-1	S _f ²	S _f ² /S _{error} ²
Columnas	SC _C	f-1	S _c ²	S _c ² /S _{error} ²
Error	SC _{Tot} – (SC _T +SC _F +SC _C)	Difer.	S _{error} ²	
Total	SC _{Tot}	n-1		

Las sumas de cuadrados de las filas, columnas y tratamientos se resuelven con procedimientos similares, como si fueran tres anova one way.

El ejemplo: Se quiere estudiar el rendimiento académicos de alumnos de la misma carrera Ingeniería en Sistemas en 4 grupos de estudiantes: A, B, C, D, en cuatro asignaturas: Estadística, Base de Datos, Economía y Física. Para neutralizar el efecto en cadena que una asignatura tiene sobre la otra, el estudio se hace en cuatro

momentos, respetando el hecho que en un mismo momento se evalúen las cuatro asignaturas. En este modelo pueden considerarse los Momentos como columnas y las asignaturas como filas.

Diseño del Experimento

Momento/Grupo	A	B	C	D
Uno	Estadística	B de D	Economía	Física
Dos	Física	Estadística	B de D	Economía
Tres	Economía	Física	Estadística	B de D
Cuatro	B de D	Economía	Física	Estadística

Datos obtenidos

Asignatura	Grupo	Momento	Nota
Economía	C	1	82
Economía	D	2	81
Economía	A	3	83
Economía	B	4	77
Física	D	1	70
Física	A	2	65
Física	B	3	67
Física	C	4	61

Asignatura	Grupo	Momento	Nota
Estadística	A	1	75
Estadística	B	2	70
Estadística	C	3	73
Estadística	D	4	67
B de D	B	1	78
B de D	C	2	76
B de D	D	3	78
B de D	A	4	71

Suma de Cuadrados

$$SC_{total} = 82^2 + 81^2 + \dots + 71^2 - \frac{1174^2}{16} = 623.75$$

$$SC_{Asignaturas} = \frac{323^2 + 285^2 + 263^2 + 303^2}{4} - \frac{1174^2}{16} = 490.75$$

$$SC_{Grupo} = \frac{294^2 + 292^2 + 292^2 + 296^2}{4} - \frac{1174^2}{16} = 2.75$$

$$SC_{Momento} = \frac{305^2 + 292^2 + 301^2 + 276^2}{4} - \frac{1174^2}{16} = 124.25$$

$$SC_{Error} = SC_{Total} - SC_{Asignaturas} - SC_{Grupo} - SC_{Momento} = 6.00$$

El análisis de de variancia realizado con INFOSTAT como un ANDEVA trifactorial sin interacciones dio los siguientes “p” valores.

Cuadro de Análisis de la Varianza de un Cuadro Latino

C.V.	SC	gl	CM	F	p-valor
Asignatura	490.75	3	163.58	163.58	<0.0001
Grupo	2.75	3	0.92	0.92	0.4872
Momento	124.25	3	41.42	41.42	0.0002
Error	6.00	6	1.00		
Total	623.75	15			

Se concluye que hay diferencias significativas para las diferentes asignaturas y diferentes momentos de aplicación de exámenes ya que el “p” valor de 0.0001 y 0.0002 son menores al valor “ α ” de 0.05. Sin embargo los cuatros Grupos de estudiantes tienen un comportamiento semejante.

Ejercicio 6.4 Se evaluó 3 niveles de inclusión (10 %, 20 % y 30 %) de un nuevo alimento para rumiantes desarrollado a base de pulpa de café. El testigo fue 0 % de inclusión. La variable medida fue “consumo de materia seca, CMS” en un periodo determinado. Cómo no se tenían suficientes ovejas para realizar el experimento, se usaron 4 animales en un diseño de cuadro latino en el tiempo, cada una de estos pasó por los cuatro tratamientos de alimentación.

- Realizar el ANDEVA como BCA y como Cuadro Latino e Interpretar ambas pruebas de hipótesis. Comentar la diferencias
- Realizar prueba de separación de medias por Tukey, DUNCAN y DSM e interpretar. Observar diferencias.
- Hacer estudios de residuos con pruebas de normalidad por qq plot
- Hacer estudio de igualdad de varianzas con los residuos absolutos, prueba de Levene.
- Hacer gráficos de barras
- Concluir los resultados de manera narrativa

Datos

Tratamiento	Ovejas	Tiempo	CMS
0	A	1	424.6
10	B	1	427.2
20	C	1	567
30	D	1	774.7
0	B	2	523.3
10	A	2	519.43
20	D	2	444.27
30	C	2	772.56
0	D	3	559
10	C	3	699.1
20	B	3	702.61
30	A	3	734.6
0	C	4	586.2
10	D	4	432
20	A	4	656.78
30	B	4	574

Usando el programa estadístico INFOSTAT se debe realizar:

- El ANDEVA como Cuadro Latino e Interpretar las pruebas de hipótesis.
- Pruebas de separación de medias por Tukey, DUNCAN y DSM e interpretar. Observar diferencias.
- Estudios de residuos con pruebas de normalidad por qq plot
- Estudio de igualdad de varianzas con los residuos absolutos, prueba de Levene.
- Gráficos de barras con intervalos de confianza.
- Concluir los resultados de manera narrativa

6.6 Diseño en Cuadro Greco Latino

El diseño en cuadros Greco Latino, en una extensión del diseño de cuadro latino. Al modelo de tres factores del cuadro latino, tratamiento, filas y columnas, se agrega un nuevo factor que se simboliza con letras griegas. Además de tener control del error por filas y columnas, tenemos un nuevo factor que son las letras griegas. Este tercer permite controlar la heterogeneidad que no pueden neutralizar las diagonales del cuadro latino. Este diseño es poco usado y se justifica cuando el área experimental o

los elementos de perturbación son extremadamente heterogéneos. Ejemplo de un diseño Greco Latino con letras latinas diferenciando los factores columnas y filas y letras griegas como tercer factor que neutraliza las diagonales.

$A\alpha$	$B\beta$	$C\chi$	$D\delta$
$B\chi$	$C\delta$	$D\alpha$	$E\delta$
$C\delta$	$D\alpha$	$A\beta$	$B\chi$
$D\beta$	$A\chi$	$B\delta$	$C\alpha$

6.7 Análisis de la varianza de dos factores con interacción

El diseño bifactorial, es un diseño del tipo factorial, pero con dos factores o temas de estudio, Factor 1 y Factor 2, los cuales pueden tener interacción entre ellos. Este modelo supone tres pruebas de hipótesis una para el Factor 1, otra para el Factor 2 y la tercera para la interacción $F1 \times F2$, en esta prueba la hipótesis nula es la falta de interacción. La interacción responde a la pregunta de si el Factor 1 tiene diferentes comportamientos ante los diferentes valores del Factor 2, por ejemplo ante una prueba de evaluación de variedades de un cultivo en diferentes ambientes, la interacción sería que la mejor variedad en un ambiente de alta fertilidad, ya no se comporta como la mejor variedad al cambiar a un ambiente de baja fertilidad.

El ANDEVA permite estudiar simultáneamente los efectos de dos fuentes de variación. En un ANDEVA de dos factores se clasifica a los tratamientos o grupos de acuerdo a dos factores para estudiar simultáneamente sus efectos. Este modelo difiere del BCA, en que interesa la interacción de los dos factores.

El Modelo Estadístico, lineal.

$$x_{ij} = \bar{x} \pm \alpha_i \pm \beta_j \pm \alpha\beta_{ij} \pm \varepsilon_{ij}$$

x_{ij} = Valor del “j” Factor B ubicada en el “i” Factor A.

$\bar{x}$ = Promedio General

α_i = Efecto del Factor A “i”

β_j = Efecto del Factor B “j”

$\alpha \beta_{ij}$ = Efecto de la interacción del Factor A por el Factor B

ε_{ij} = Variación de las observaciones ubicada en el Facto B “j” y el Factor A “i”.

Análisis de Varianza

Hipótesis de los Factores A y B:

H₀: $\mu_{1A} = \mu_{2A} = \dots = \mu_{iA}$; **H_A:** no todas los μ_{iA} son iguales para el Factor A

H₀: $\mu_{1B} = \mu_{2B} = \dots = \mu_{jB}$; **H_A:** no todas μ_{jB} son iguales para el Factor B

Hipótesis de Interacción

H₀: El Factor A no interactúa con el Factor B

H_A: El Factor A interactúa con el Factor B

Estadístico de Prueba:

F1= S^2_A / S^2_{error} ; **F2**= S^2_B / S^2_{error} ; **F3**= S^2_{AB} / S^2_{error}

ANDEVA de un Diseño Bifactorial con interacción

Causa de Variación	Suma de Cuadrados	Grados de Libertad	Cuadrado Medio, CM “S ² ”	“F _{Calculado} ”
Total	SC _{total}	n-1		
Tratamientos Totales	SC _{tratamientos}	t-1		
Factor A	SC _A	a-1	S ² _A	S ² _A / S ² _{error}
Factor B	SC _B	b-1	S ² _B	S ² _B S ² _{error}
Factor Ax B	SC _{AxB}	(a-1)(b-1)	S ² _{AxB}	S ² _{AxB} S ² _{error}
Error	SC _{Error}	n-t		

Dónde:

- t = número tratamientos totales,
- a = número tratamientos del Factor A,
- b = número de tratamientos del Factor B
- $SC_{A \times B} = SC_{\text{tratamientos}} - SC_A - SC_B$
- $SC_{\text{Error}} = SC_{\text{total}} - SC_{\text{tratamientos}}$

En este modelo la suma cuadrados de los tratamientos totales, $SC_{\text{tratamientos}}$, se descompone en tres sumas de cuadrados, SC_A , SC_B y $SC_{A \times B}$. Esta forma de resolución de la suma de cuadrados de la interacción es válido para calcular los grados de libertad de la interacción.

Ejemplo de un Análisis Bifactorial

Hay un grupo de 26 Estudiantes, 12 varones y 12 mujeres. A ellos se les preguntó su nota promedio y las horas de estudio semanales, esta última variable se codificó: 0 a 3 horas, 4 a 6 horas y más de 6 horas.

Responder a las preguntas:

¿Hay diferencias de notas según sean varón o mujer?

¿Hay diferencias de notas según sean horas de estudio realizadas?

¿Hay interacción entre sexo y horas de estudio realizadas?

Con una calculadora manual con función estadística realice:

1. Análisis de variancia bifactorial con interacción.
2. Un gráfico de interacciones
3. Comentar los resultados

Tabla de datos

Para analizar los datos manualmente se debe hacer las sumatorias por tratamiento.

Sexo	Horas	Repeticiones				$\sum x$	$\bar{x}$
Varón	0-3	70	74	73	69	286	71.50
Varón	4-6	78	75	80	76	309	77.25
Varón	+6	86	82	88	85	341	85.25
Mujer	0-3	64	70	69	76	279	69.75

Mujer	4-6	80	81	73	79	313	78.25
Mujer	+6	80	90	84	82	336	84.00
						1,864	77.67

Suma de Cuadrados

$$SC_{total} = 70^2 + 74^2 + \dots + 82^2 - 1864^2/24$$

$$SC_{tratamientos} = \frac{286^2 + 309^2 + 341^2 + \dots + 336^2}{4} - 1864^2/24$$

$$SC_{Sexo} = \frac{936^2 + 928^2}{12} - 1864^2/24$$

$$SC_{Horas estudio} = \frac{565^2 + 622^2 + 677^2}{8} - 1864^2/24$$

$$SC_{Sexo*Horas estudio} = SC_{Tratamientos} - SC_{Sexo} - SC_{Horas estudio}$$

Resultados. Con el programa estadístico INFOSTAT se obtuvieron los siguientes valores del ANDEVA.

ANDEVA de Interacciones. Variable Dependiente: Nota Promedio

Cuadro de Análisis de la Varianza

C.V.	SC	gl	CM	F	p-valor
Modelo	795.33	5	159.07	13.13	<0.0001
Sexo	2.67	1	2.67	0.22	0.6445
Horas Estudio	784.08	2	392.04	32.37	<0.0001
Sexo*Horas Estudio	8.58	2	4.29	0.35	0.7064
Error	218.00	18	12.11		
Total	1013.33	23			


Estos resultados dicen que no hay diferencias de notas según sean los estudiantes varones o mujeres (significación de 0.64 mayor al 0.05), pero por otro lado si se observa diferencias estadísticas entre las horas de estudio (significación de 0.0001

menor al 0.05), con esta última variable y este resultado se debe hacer una separación de promedios entre las tres categorías de horas de estudio.

Gráfico de Interacciones

Este gráfico nos permite observar si hay interacción con los dos factores, “sexo” y “horas de estudio”. Esta interacción ocurre si las rayas generadas por las variables se cruzan, lo que sería una confirmación de la existencia de interacción entre sexo y horas de estudio. Como esto no se observa en el gráfico que se muestra a continuación, se puede concluir que coinciden los resultados del ANDEVA y del gráfico.

Gráfico de Interacciones entre las Variables “Sexo” y “Horas de estudio”



Capítulo 7. Estadística no paramétrica

Objetivos

- Formar de habilidades para utilizar pruebas no paramétricas de análisis estadístico como la prueba del signo, la prueba Chi.
- Desarrollar capacidades de Identificación de cuando se deben utilizar pruebas paramétricas y no paramétricas.

7.1 Introducción a la Estadística No paramétrica

La estadística **no** paramétrica en general, nos permite resolver pruebas de hipótesis como las estudiadas en los capítulos anteriores pero utilizando procedimientos alternativos. La teoría recomienda utilizar los métodos no paramétricos cuando no se puede asumir que los datos se ajusten a una distribución conocida, por ejemplo la distribución Normal. En la práctica, en un gran número de variables no se pueden determinar a priori la distribución de la población de los datos, entonces se requiere otra metodología de trabajo, una estadística de distribuciones libres.

En el empleo de la estadística **no** paramétrica, hay ciertas ventajas tales como:

- Se puede trabajar con magnitudes cualitativas, además de las cuantitativas.
- Permite estudiar casos donde no es posible precisar la naturaleza de la distribución, casos donde los supuestos de la forma poblacional son débiles.
- Aplicar el mismo modelo a casi todas las distribuciones en lugar a una sola.
- Para quienes no poseen una formación básica estadística, son más fácil de entender y calcular.

Comparando ambos enfoques, en general los modelos paramétricos tienen una mayor sensibilidad para detectar diferencias significativas entre grupos cuando la variable dependiente es continua y normal, pero por otro lado los modelos no paramétricos se pueden aplicar a casi todos los casos de pruebas de hipótesis, son más fáciles de

entender, no tienen tanta complicación de cálculo matemático y funcionan bien con variables cualitativas.

7.2 Prueba del signo

La prueba del signo permite verificar hipótesis sobre las diferencias de dos conjuntos de mediciones tomados sobre los mismos objetos, muestras relacionadas. Se llama prueba del signo, porque si las diferencias entre los valores son positivas, se simboliza esto con un signo “+” y si las diferencias son negativas se usa un signo “-“. Donde en H_0 : la probabilidades $P (+) = P (-)$. Esta prueba es equivalente a la prueba “t” de promedios, con dos muestras apareadas, pero se usa con datos que poseen una distribución desconocida.

La prueba del signo es semejante en su uso a una prueba “t” con muestras apareadas.

Un uso de esta prueba es en actividades de capacitación cuando se quiere conocer si hubo mejora de los participantes luego del evento, para esto se compara las notas obtenidas al evaluar antes de iniciar la capacitación y las notas obtenidas luego de finalizar la misma. En un caso como éste se espera que los capacitados mejoren su nota de evaluación al finalizar la actividad, estar en H_A .

La hipótesis nula de esta prueba, H_0 : plantea que no hay diferencias de notas entre la evaluación final menos la evaluación de inicio o sea que existe el mismo número de positivos (+) que de negativos (-), donde la probabilidad de (+) es un $\frac{1}{2}$ y la mediana de las diferencias es 0. Se rechaza H_0 en favor de H_A sólo si el número observado de signos (+), es grande, la fracción observada de signos positivos es significativamente mayor que $\frac{1}{2}$. Se rechaza la H_0 si el valor p (+) calculado es mayor que un alfa de 0.05

Procedimiento

- 1) Se eligen al azar los objetos de medición por ejemplo estudiantes de un mismo curso y se hace una evaluación de conocimiento antes y después. Luego se calcula la diferencia para cada par de datos.
- 2) Con diferencias >0 se asigna un signo (+).
- 3) Con diferencias <0 se asigna un signo (-).
- 4) Diferencia = 0, no se considera el par.

Se cuenta el número de positivos, (+) y se estudia la diferencia para cada par de observaciones pero no se estudian los dos grupos de personas individualmente como se hacía en las pruebas paramétricas.

Si “n” es pequeño se considera que son “n” pruebas Bernoulli independientes con $p = 1/2$ (+) y $(1-p) = q = 1/2$ (-). Por lo que el número total de (+) es una variable aleatoria con distribución BINOMIAL con parámetros n y p.

Entonces

- El promedio esperado de (+) es “ $n p = n/2$ ”
- La varianza de (+) es “ $n p(1-p) = n/4$ ”
- Las desviación estándar de (+) “ $(n p(1-p))^{1/2} = \sqrt{n/4}$ ”

La hipótesis H_0 se rechaza si el número de positivos, (+) es mucho más grande o más chico que $n/2$, o si la $P(+)> 0.05$

Cuando n es grande, al menos de 12, o “n p” es mayor a 5, se puede hacer una prueba con la distribución normal tipificada Z, donde el valor “Z+” es:

$Z+ = ((\text{Estimador} \pm 0.5) - \text{Promedio esperado}) / \text{Desvío estándar del Estimador}$

$$Z+ = (((+) \pm 0.5) - n p) / \sqrt{npq}$$

Donde “n” es la suma del número de signos, (+) y (-), no se cuentan los ceros.

Dado que el procedimiento implica la aproximación de una distribución continua mediante una distribución discreta, en general se utiliza una corrección de continuidad de 0.5

En la ecuación de “Z+” se hace la siguiente corrección de continuidad: “(+) +0.5” cuando el número de (+) < n/2 y “(+) - 0.5” cuando (+) > n/2

Como el estadístico Z+ se aproxima a una distribución normal estándar con media 0 y varianza 1. El Z de rechazo o crítico es 1.96 para un alfa de 0.5

Regla de decisión:

Si $|Z+| < 1.96$ se acepta la H_0

Si $|Z+| > 1.96$ se rechaza H_0

Ejercicio 7.1

A un grupo de 12 personas se les impartió una capacitación. Antes de iniciar la actividad se les hizo una evaluación de conocimientos previos con cuatro preguntas. Al finalizar la capacitación se volvió a realizar otra evaluación también con cuatro preguntas semejantes a las iniciales, o de igual grado de complejidad. Cada pregunta se evaluó con un punto, si la respuesta era correcta. Los resultados obtenidos fueron:

Persona	Notas Antes	Nota al finalizar	Signo
01	1.5	2.0	+
02	2.0	2.0	0
03	3.5	4.0	+
04	3.0	2.5	-
05	3.5	4.0	+
06	2.5	3.0	+
07	2.0	3.5	+
08	1.5	3.0	+
09	1.5	2.5	+
10	2.0	2.5	+
11	3.0	2.5	-
12	2.0	2.5	+

Se debe responder si la capacitación mejoró la capacidad de respuesta de los participantes o no.

Dónde:

- H_0 : $P (+) = P (-)$.
- H_A : $P (+) \neq P (-)$.
- El número de datos, “n” es 11, solo se cuentan los signos + ó -.
- El promedio esperado es “n x p”, $11 \times 0.5 = 5.5$
- El Estimador es la cantidad de signos (+), es igual 9.
- El desvió estándar del estimador es: $\sqrt{npq} = \sqrt{11(0.5)(0.5)} = \sqrt{11/4}$

Con la información anterior se calcula el valor de:

$$Z+ = ((9-0.5) - (11/2)) / (11/4)^{1/2} = 3/1.658 = 1.81 < 1.96 Z_{\text{Crítico}}$$

Como el valor Z+ calculado es menos al valor de $Z_{\text{Crítico}}$ se acepta la H_0 no hay diferencias entre el número de signos (+) y (-), la mediana es (0), lo que nos dice que la notas no han cambiado entre antes de hacer la capacitación y después de recibirla. Se concluye que la capacitación no ha mejorado la capacidad de responder el examen por los estudiantes.

Ejercicio

- a) En el siguiente grupo de estudiantes determinar por la prueba del signo, si hubo mejora entre las notas promedios de la primera evaluación de exámenes trimestrales y la segunda evaluación trimestral.

Estudiante	Primer Trimestre	Segundo Trimestre	Estudiante	Primer Trimestre	Segundo Trimestre
Sindy	80	87	Indira	75	80
Tatiana	80	85	Rosa	69	73
Eyleen	67	70	Lilliam	70	65
Arlen	70	85	Heydi	75	73
Wilmer	70	75	Clark	75	79
Wendel	72	72	Heydi L.	70	75
Juniel	64	85	Axel	70	70

Juan J	82	73	Itzan	65	70
Nesly	90	88	Milton	71	76
Jeydels	82	89	Meyling	80	82
Erick	78	85	Jasser	70	69
Miriam	79	84	Darol	60	60
Nely	81	90	Karla	63	74

- b) Se informa acerca de un estudio en el que se evalúa un prototipo de motor, determinando el consumo de combustible. Se tienen datos de consumo de 20 motores al azar y se desea probar la hipótesis de que la mediana de consumo es 2000 CC por hora. Resolver usando prueba del signo si el número de signos “+” obtenidos es de trece, (datos de mayor consumo que 2000 CC).

7.3 Prueba ji-cuadrado, χ^2

Prueba de independencia de dos variables cualitativas nominales

Esta prueba se usa para verificar independencia entre variables cualitativas nominales. Esta prueba suele asociarse a la realización de tablas de contingencia.

La prueba χ^2 se usa en pruebas de independencia de dos variables nominales

Por ejemplo si se quiere vincular la variable tener o no beca, con el éxito de un examen académico, dos variables cualitativas nominales. Los resultados de un estudio de este tipo se pueden comprimir en una tabla de contingencia 2x2 del tipo como la siguiente

	Becado	No Becado	
Éxito	a	b	m = a+b
No E	c	d	n = c+d
	e = a+c	f = b+d	T

Donde se estudian “ T ” total de alumnos, “ a ” son becados (**B**) y tienen éxito en un examen (**Éxito**), “ b ” alumnos que no tienen beca (**N B**) y no tiene éxito en un examen (**No E**).

H_0 es que el factor **Beca** y el factor **Éxito** son independientes, y H_A que están asociados (sí es así los becado tiene más rendimiento en notas). Si ambas variables son independientes debe ocurrir que “ $p(E \cap B) = p(E) p(B)$ ”.

Para resolver esta prueba se debe construir una tabla de valores esperados, como a continuación se observa:

	Becado	No Becado	
Éxito	em/T	fm/T	m
No E	en/T	fn/T	n
	e	f	T

El estadístico de contraste es un valor χ^2

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

Que se distribuye según una distribución conocida denominada ji-cuadrado, que depende de un parámetro llamado "grados de libertad" (g.l.) Los g.l. en esta tabla son 1. Esto se puede generalizar a tablas $C \times F$ y los grados de libertad son (Columnas-1) $\times$ (Filas-1). El valor tabular se busca en una tabla de ji-cuadrado, χ^2 a continuación se muestra un resumen de la misma, para un alfa del 5%.

Tipo de tabla de contingencia (filas X columnas)	Grados de Libertad	Valor χ^2 de Tabla
2X2	1	3.84
3X2, 2X3	2	5.99
4X2, 2X4,	3	7.81

3X3, 5X2, 2X5	4	9.48
---------------	---	------

Ejemplo

En una muestra de 300 estudiantes que cursaron matemáticas se observa que 231 aprobaron (éxito). Se quiere estudiar su posible asociación con el hecho de ser Becado o No Becado (factor). La tabla de valores Observados, O , es

	Éxito	No E	Totales
Becado	88	12	100
No Becado	143	57	200
Totales	231	69	300

Calculamos los valores Esperados, E , en H_0

	Éxito	No E
Becado	$231 \times 100 / 300 = 77$	$69 \times 100 / 300 = 23$
No Becado	$231 \times 200 / 300 = 154$	$69 \times 200 / 300 = 46$

Obsérvese que una vez calculado uno de los valores esperados, los demás vienen dados para conservar los totales marginales (eso es lo que significa que hay 1 g.l.).

A partir de aquí calculamos el valor χ^2 con una corrección, sustraer 0.5 del valor absoluto, corrección de Yates, que se usa solamente en las tablas 2x2 (de dos filas y dos columnas), esto es para lograr continuidad en los datos. Como no existe un consenso generalizado sobre su aplicación, este queda a criterio del investigador, sin embargo algunos autores sugieren usar la solamente la corrección cuando los totales de ambas variables son fijos. En este ejemplo aplicaremos la corrección de Yates a modo de ejemplo.

Valor χ^2 aplicando la corrección de Yates:

$$\chi^2 = \sum_{i=1}^k \frac{(|O_i - E_i| - 0.5)^2}{E_i} = \frac{10.5^2}{77} + \frac{10.5^2}{23} + \frac{10.5^2}{154} + \frac{10.5^2}{46} = 9.34$$

El valor de χ^2 calculado sin corrección, es un valor semejante al anterior:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} = \frac{11^2}{77} + \frac{11^2}{23} + \frac{11^2}{154} + \frac{11^2}{46} = 10.25$$

El valor de tabla con un grado de libertad, $(2-1) \times (2-1)$, es de $\chi^2_{1(0.05)} = 3.84$

Rechazamos la H_0 ya que 9.34 (10.25) > 3.84 . Concluimos que no hay independencia entre el aprobar y tener beca. Aparentemente los becados tuvieron más éxito en el examen, esto era de esperarse.

Ejercicio 7.2 En un grupo de 30 estudiantes, se quiere saber si hay independencia entre varón y mujer y el hecho de tener beca de estudio o no. A continuación se detallan los datos. Resolver este ejercicio con una prueba χ^2 de independencia. Con INFOSTAT se debe construir una tabla de contingencia y buscar en estadísticos la prueba χ^2

Beca	Sexo	Beca	Sexo
Si	Mujer	No	Mujer
Si	Mujer	No	Mujer
Si	Mujer	No	Mujer
No	Mujer	Si	Varón
Si	Mujer	Si	Varón
Si	Mujer	No	Varón
No	Mujer	Si	Varón
Si	Varón	No	Varón
Si	Varón	No	Varón
Si	Varón	No	Mujer
No	Varón	No	Varón
No	Mujer	No	Mujer

No	Varón	No	Mujer
Si	Varón	Si	Mujer
No	Mujer	Si	Mujer

Ejercicio 7.3 En el estudio de una fábrica, se hizo un estudio para determinar si la proporción de artículos defectuosos producidos por los trabajadores era la misma durante el día, la tarde o la noche. Se encontraron los siguientes datos:

Frecuencias observadas

	Turno		
	Día	Tarde	Noche
Defectuosos	450	550	700
No defectuosos	9000	8900	8600

Sea que p_1 , p_2 y p_3 representen las proporciones reales de artículos defectuosos para los turnos del día, la tarde y la noche, respectivamente. Resolver la siguiente prueba de hipótesis $H_0: p_1 = p_2 = p_3$; $H_A: p_1, p_2$ y p_3 no son todas iguales.

7.4 Análisis de Variancia no paramétrico

7.4.1 Prueba de Kruskal Wallis.

La prueba de Kruskal Wallis es similar a un análisis de varianza unifactorial, por tanto su objetivo es comparar valores centrales de varios grupos, que es lo misma pregunta de si “un grupo de datos proviene de la misma población”. Para utilizar la prueba de Kruskal – Wallis solo se necesita que la variable dependiente esté en una escala ordinal, luego se calcula la diferencia entre grupos a partir del ranking que toman sus valores en una lista ordenada de todos los datos. Este método no exige normalidad de la variable dependiente, por tanto la prueba puede ser utilizada con pocos datos e incluso con variables de naturaleza no continua, sin embargo el modelo pide que haya varianzas poblaciones iguales.

La prueba de Kruskal Wallis es similar a un análisis de varianza unifactorial pero no exige normalidad de residuos de la variable

El estadístico de Kruskal – Wallis: H se calcula de la siguiente manera:

$$H = \frac{12}{n(n+1)} \sum_{j=1}^k \frac{R_j^2}{n_j} - 3(n+1)$$

Donde:

- K: número de grupos.
- n: número total de elementos o datos.
- R_j : Suma de los ranking del grupo j.
- n_j : número de elementos del grupo j.

La hipótesis nula de la prueba de Kruskal Wallis es:

- H_0 : Los k promedios son todas iguales
- H_1 : Al menos una de los promedios es diferente

Una vez calculado el estadístico H, se busca en una tabla diseñada para esta prueba el valor crítico, $H_{\text{crítico}}$, si $H_{\text{calculado}} > H_{\text{crítico}}$ se rechaza la hipótesis nula y por tanto existe diferencia entre los grupos. En caso de tener suficientes repeticiones, más de 5 observaciones por grupo, se puede usar los valores de la tabla “ χ^2 ” con K-1 grados de libertad para determinar el valor crítico y no es necesario usar la Tabla de valores H.

Ejemplo A tres grupos de jóvenes se les impartió una capacitación de tres maneras diferentes: por video, por internet y a través de un profesor. Luego por medio de una prueba escrita, valorada sobre 100, se midió la capacidad de retención de lo explicado. La nota obtenida de cada una de las personas de los tres grupos fue:

- Video: 50, 55, 60, 61, 65, 70
- Internet: 57, 65, 78, 80, 89, 90.
- Profesor: 78, 83, 90, 91, 94, 95, 96.

Se debe responder a la pregunta ¿hay diferencias de retención según la forma de impartir la capacitación? La información que se dispone es:

- $K = 3$
- $N = 19, N_V = 6, N_I = 6, N_P = 7$.
- Ranking Video: 1, 2, 4, 5, 6.5, 8 = 26.5
- Ranking Internet: 3, 6.5, 9.5, 11, 13, 14.5 = 57.5
- Ranking Profesor: 9.5, 12, 14.5, 16, 17, 18, 19 = 106

Se hace el cálculo del valor H:

$$H = \frac{12}{19(19+1)} \left(\frac{26.5^2}{6} + \frac{57.5^2}{6} + \frac{106^2}{7} \right) - 3(19+1) = 11.78$$

Se concluye que hay diferencias de retención según la forma de impartir la capacitación ya que el valor $H_{calculado} = 11.78 \geq 5.99$ con $\alpha=0.05$ y 2 grados de libertad.

7.4.2 Análisis bilateral por jerarquías de Friedman

La prueba de Friedman es la versión no paramétrica del Análisis de la varianza tradicional para un diseño en bloques completos al azar. Se puede aplicar sin necesidad de que se cumpla el supuesto de normalidad requerido por el ANDEVA. Esta prueba es conveniente usar siempre que los datos de la variable dependiente se midan al menos con una escala ordinal.

La hipótesis nula de esta prueba establece igualdad de las medias de los tratamientos, la alternativa es que al menos un tratamiento sea diferente. Esta prueba no necesita de los supuestos de que los datos son independientes y la varianzas homogéneas.

En esta prueba los datos se organizan en una matriz, donde las filas son los bloques y las columnas los tratamientos o grupos.

La prueba de FRIEDMAN es similar a un análisis de varianza bifactorial sin interacciones de un diseño de BCA, se recomienda con variables ordinales

El estadístico de Friedman se calcula de la siguiente manera:

$$X^2 = \frac{12}{nk(k+1)} \sum_{j=1}^k R_j^2 - 3n(k+1)$$

Donde:

- K: número de grupos o tratamientos.
- n: número bloques.
- R_j : es la suma de las jerarquías dentro de la columna o tratamiento j.

Se puede usar los valores críticos de la tabla “ X^2 ” con K-1 grados de libertad para determinar que hipótesis se cumple.

Ejemplo, se les pidió a nueve estudiantes de Ingeniería Industrial las notas de las cuatro asignaturas que habían cursado el semestre anterior. Se quiere saber si hay diferencias en la evaluación de las asignaturas, pero como se considera que cada estudiante es diferente en su comportamiento, se trata de neutralizar este efecto con un diseño de bloques aplicado a los estudiantes.

Datos

Estudiantes/ bloque	Asignaturas, Notas			
	Programación II	Probabilidades	Física III	Metalurgia
A	74	86	79	93
B	75	82	99	95
C	72	80	84	86
D	79	78	80	88
E	74	75	67	93
F	76	82	84	96
G	71	85	86	94
H	82	86	93	97
I	75	86	96	94

Se hace un ranking por fila, estudiante, de 1 a 4 y se suma el valor por columna, asignatura.

Estudiantes/ bloque	Asignaturas, Ranking por bloque			
	Programación	Probabilidades	Física III	Metalurgia

	II			
A	1	3	2	4
B	1	2	4	3
C	1	2	3	4
D	2	1	3	4
E	2	3	1	4
F	1	2	3	4
G	1	2	3	4
H	1	2	3	4
I	1	2	4	3
Suma	11	19	26	34

Cálculo del coeficiente de Friedman:

$$X^2 = \frac{12}{9(4)(4+1)} (11^2 + 19^2 + 26^2 + 34^2) - 3(9)(4 + 1) = 19.27$$

Este valor calculado de 19.27 es mayor al valor X^2 con 3 grados de libertad de 7.81, lo que se puede concluir que, en cuanto a su forma de ser evaluada, al menos una asignatura es diferente del resto.

7.5 Coeficiente de correlación de Ranking de Spearman

El coeficiente de correlación de Ranking de Spearman “r” construido con las diferencias de los ranking ordinales y no con los valores observados, determina la correlación o asociación de datos de manera fácil y rápida entre dos variables discretas ordinales.

El coeficiente de correlación de Spearman es una medida de asociación lineal recomendado para usar con variables ordinales.

La interpretación del coeficiente de Spearman es igual que la del coeficiente de correlación de Pearson, este valor oscila entre -1 y +1, indicándonos asociaciones negativas o positivas respectivamente, 0 cero significa falta de correlación. El estadístico “r” Spearman se calcula de la siguiente manera:

$$r = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

Donde “d” es la diferencia entre los correspondientes ranking de valores de la variable independiente y dependiente. Siendo el ranking la medida ordinal asignada a cada observación previamente ordenada según cierto criterio relativo a una característica. El número de pares de observaciones es “n”.

El procedimiento de cálculo lleva los siguientes pasos:

- Clasificar por ranking, adjudicando el valor 1 al menor valor y el valor de “n” al mayor valor. Los valores de las variables independiente y dependiente, de 1 a “n” pares de datos. Se generan así dos nuevas variables ordinales construidas con el ranking de las dos variables originales.
- Crear dos nuevas variables, una con las diferencias “d” de cada pareja de observaciones y otra con las diferencias al cuadrado “d²”. Sumar esta última variable. Se debe verificar que la suma de las diferencias “d” sea igual a 0.
- Calcular el coeficiente “r” de Spearman con los valores de “d²” y “n”.

Ejemplo, se toman los datos del ejemplo desarrollado en el capítulo “Análisis de regresión múltiple”, donde se correlacionaron las notas del examen final de diez alumnos de las asignaturas de matemáticas y español

<u>Matemáticas</u>	2	3	5	5	6	6	7	7	8	9
Ranking	1	2	3.5	3.5	5.5	5.5	7.5	7.5	9	10
<u>Español</u>	2	2	5	5	6	7	5	8	7	10
Ranking	1.5	1.5	4	4	6	7.5	4	9	7.5	10
Diferencia de ranking	-0.5	0.5	-0.5	-0.5	-0.5	-2.0	3.5	-1.5	1.5	0
Diferencia al cuadrado d ²	0.25	0.25	0.25	0.25	0.25	4.00	12.25	2.25	2.25	0.0

Donde $n = 10$ pares de datos, siendo:

$$r_{Spearman} = 1 - \frac{6(22)}{10(100 - 1)} = \frac{133.5}{990} = 0.87$$

En este ejemplo el valor “r” de Spearman de 0.87 se asemeja al valor del “r” de Pearson de 0.919.

Capítulo 8. Control estadístico de la calidad

Objetivos

- Reconocer los principios estadísticos del control de calidad de un proceso productivo.
- Resolver la forma de construir los diagramas de control por mediciones y por atributos para mejorar la calidad de los productos finales de una empresa.

8.1 Calidad, conceptos

Calidad es satisfacción del cliente. William Deming.

Una definición de calidad de un producto o servicio es su aptitud para el uso demandado por el mercado. En los procesos de producción las demandas del mercado pueden ser controlados a partir de mediciones de una o más características de calidad. Los parámetros o características de calidad son aquellos atributos (variables discretas) o variables medibles (continuas) del producto que describen su aptitud demandada. Un concepto clave a controlar en cualquier proceso industrial es el de la variabilidad o dispersión de dichas variables de calidad.

8.2 Diagramas de Control

Los diagramas control son un método para controlar estadísticamente procesos productivos detectando cuando éste está fuera de control, varía demasiado. Las ventajas de su uso son: ser una herramienta simple y efectiva para lograr un control del proceso productivo, el operario puede manejar los diagramas en su propia área de trabajo, por lo cual puede dar información confiable a la gente cercana a la operación en el momento en que se deben de tomar acciones correctivas, tanto el empresario como el cliente pueden contar con niveles consistentes de calidad y ambos pueden contar con costos estables para lograr ese nivel de calidad además se visualiza fácilmente el comportamiento del proceso productivo y entonces éste puede ser mejorado.

Los diagramas de control más usados son los propuestos por Walter Shewhart, padre del control estadístico de la calidad. Estos diagramas tienen un límite central, uno inferior y otro superior, estos dos últimos límites señalan cuando el proceso está fuera de control

Los diagramas de control enfocan la atención hacia las causas no aleatorias de variación cuando estas aparecen y también reflejan la magnitud de la variación debida a las causas aleatorias. Las causas aleatorias se deben a la variación natural del proceso. Las causas no aleatorias son aquellas controlables como: un mal ajuste de máquina, errores del operador, defectos en materias primas.

Se dice que un proceso está bajo “Control Estadístico” cuando éste varía únicamente por causas aleatorias. Cuando ocurre esto tenemos un proceso estable y predecible. Cuando existen causas no aleatorias el proceso está fuera de Control Estadístico; los diagramas de control detectan la existencia de estas causas en el momento en que se dan, lo cual permite que podamos tomar acciones al momento.

Generalmente en los procesos que se quieren controlar se deben tomar muestras a intervalos aproximadamente regulares. De cada muestra se mide una o varias variables (diagramas de control por mediciones) ó se determina el número o porcentaje de unidades defectuosas en la muestra (diagramas de control por atributos). Las muestras correspondientes a un mismo intervalo constituyen un grupo. Los intervalos pueden ser definidos en términos de tiempo (8 muestras cada hora o turno) o de cantidad (25 muestras cada 500 unidades fabricadas).

Los valores medidos se comparan con unos límites (líneas paralelas al eje central). Los límites más comunes son los siguientes: el Límite superior de control (LSC) y el inferior (LIC), paralelos a una línea central (LC) representativa del valor medio.

8.3 Diagramas de control por Mediciones

En este caso, en cada grupo son medidas o pesadas una o más características. Para cada grupo se calculan diversos estadísticos, tales como media del grupo, $\bar{X}$, rango, R , o la desviación estándar, S .

Límites. Un diagrama de control consiste en un gráfico formado por una línea central (LC) y dos líneas paralelas una por encima, Límite Superior del Control (LSC), y otra por debajo. Límite inferior del Control (LIC). Para cada grupo se van representando los valores de $\bar{X}$, R , o S , etc., si los valores están comprendidos en el intervalo LSC- LIC) se dice que el proceso está bajo control, en caso contrario el proceso puede estar descontrolado


En el supuesto en el que la característica a controlar sea una variable continua, las medias de las muestras que se vayan tomando seguirán aproximadamente una distribución $N(\mu, \sigma)$. Los Límites de control se consideran habitualmente aquellos que contienen el 99.7 % de la producción. Por tanto vendrán dados por: $LC = \mu \pm 3\sigma$.

Estos límites pueden ser conocidos por experiencias previas y de no ser así es necesario estimarlos a partir de las observaciones de varios grupos de muestreo. Es así que se deben calcular estimadores de los parámetros μ y σ .

Los tipos más frecuentes de diagramas de control para una sola variable son:

- Diagrama de Medias $\bar{X}$ con límites definidos por los rangos.
- Diagrama de Rangos (R).
- Diagrama de Medias con límites definidos por los Desvíos estándares (S).
- Diagrama de Medias de Desvíos estándares (S).
- Diagrama de Valores individuales (X -ind).

Criterios para seleccionar un diagrama de control



8.3.1 Diagrama de Medias $\bar{X}$ con límites definidos por los Rangos

Este diagrama permite observar cómo varían los promedios de los diferentes grupos o muestras. Permite identificar si una un grupo de muestras está alterando su promedio.

Para realizar este gráfico debo calcular:

$LC = \bar{\bar{X}}$, siendo $\bar{\bar{X}}$ el promedio de los promedios por grupo

LSC y $LIC = \bar{\bar{X}} \pm \bar{R} A_2$, siendo A_2 un valor de tabla que considera el tamaño de cada grupo (ver tabla al final del capítulo).

Ejemplo: En un beneficio de café, por cinco días, a medida que llegaba el café se tomaron 5 muestras/día de café pergamino. A estas muestras se les midió el porcentaje humedad. Se quiere saber si el porcentaje de humedad está variando de día en día.

Día	Repeticiones					$\bar{X}$	R
1	17.90	24.10	18.70	19.20	19.30	19.84	6.2

2	21.30	19.60	18.70	19.80	19.20	19.72	2.6
3	18.50	20.30	21.20	19.80	19.00	19.76	2.7
4	21.90	23.10	22.10	20.10	21.90	21.82	3
5	23.10	22.10	20.10	19.20	21.40	21.18	3.9
					$\bar{\bar{X}}$	20.46	3.68

Siendo:

A_2 para grupos de 5 muestras = 0.577, y "n" = 5 el tamaño de cada grupo

Donde: LC = 20.46, LSC= 20.46 + 3.68 (0.577) = 22.59, LSC= 20.46 - 3.68 (0.577) = 18.34.

X-barra	Rango
19.84	6.20
19.72	2.60
19.76	2.70
21.82	3.00
21.18	3.90


Límites de Control :X-barra

Línea Superior: 22.59

Línea Central: 20.46

Línea Inferior: 18.34

Diagrama X Barra R de humedad del café



8.3.2 Diagrama de Rangos (R)

Este diagrama permite observar como varía la variabilidad, construida por los rangos, de los diferentes grupos, permite identificar cuando la variabilidad se hace demasiado grande, lo que nunca es deseable. Siendo:


$$LC = \bar{R}, LSC = \bar{R} D_4, LIC = \bar{R} D_3.$$

Siendo D_4 y D_3 valores tabulares variables en función del “n” de los grupos. (Ver tabla al final del capítulo). Para el ejemplo anterior: $LC = 3.68$, $LCS = 3.68 (2.144) = 7.78$, $LIC = 3.68 (0) = 0$.

Límites de Control: Rango

Línea Superior:	7.78
Línea Central:	3.68
Línea Inferior:	0.00

Diagrama de Rangos de humedad del café



8.3.3 Diagrama de Medias con límites definidos por los Desvíos estándares, S.

El diagrama de medias construido con límites definidos por los S, es parecido al diagrama de medias construido a partir de R, rangos, la diferencia consiste en que el tamaño de la muestra puede ser variable y además es mucho más sensible para detectar cambios en la media o en la variabilidad del proceso. Los límites se calculan de la siguiente forma:

$$LC = \bar{\bar{X}}$$


LSC y LIC = $\bar{\bar{X}} \pm 3 \frac{\bar{S}}{C_4 \sqrt{n}}$, siendo C_4 un valor de tabla que considera el tamaño de

cada grupo (ver tabla al final del capítulo) y $\bar{S}$ el promedio de los desvíos estándares por grupo.

Ejemplo con los datos del ejercicio de muestras de café:

<u>X-barra</u>	<u>Desvío estándar</u>	<u>Límites de Control: X-barra</u>
19.84	2.44	<u>Límites de Control</u>
19.72	0.98	Línea Superior: 22.50
19.76	1.06	Línea Central: 20.46
21.82	1.08	Línea Inferior: 18.43
<u>21.18</u>	<u>1.55</u>	

Diagrama X Barra S del ejercicio de humedad de los granos de café



8.3.4 Diagrama de Medias de Desvíos estándares, S.


El diagrama de S es muy parecido al diagrama de rangos, pero los límites se hacen con los valores de los desvíos estándares. Las formas de cálculo de los límites son:

$$LC = \bar{S}, LSC \text{ y } LIC = \bar{S} \pm 3 \frac{\bar{S}}{C_4} \sqrt{1 - C_4^2}$$

Ejemplo con los datos del ejercicio de muestras de café:

Límites de Control: Desvío estándar

Línea Superior: 2.98
 Línea Central: 1.42
 Línea Inferior: 0.00



8.3.4 Valores individuales (X-ind)

Este diagrama se construye cuando hay un solo grupo con muchas repeticiones. Los límites superiores e inferiores se hacen con rangos móviles, por ejemplo se calculan los rangos de dos medidas sucesivas, obteniéndose así “n-1” rangos. Las formas de cálculo de los límites son:

$LC = \bar{X}$, LSC y $LIC = \bar{X} \pm 3 \frac{\bar{R}}{D_2}$ siendo $\bar{X}$ la media de las mediciones, $\bar{R}$ la media de

los rangos móviles y D_2 un valor de tabla que considera el tamaño de datos de cada rango móvil (ver tabla al final del capítulo). Cada valor observado es un punto del diagrama.

Ejemplo con los datos del ejercicio de humedad de los granos de café, considerando que todas las muestras fueron tomadas al mismo tiempo:

Humedad	Rango Amplitud móvil	Humedad	Rango Amplitud móvil
17.90	sd	22.10	0.90
21.30	3.40	20.10	2.00
18.50	2.80	19.20	0.90
21.90	3.40	19.80	0.60
23.10	1.20		

24.10	1.00	19.80	0.00
19.60	4.50	20.10	0.30
20.30	0.70	19.20	0.90
23.10	2.80	19.30	0.10
22.10	1.00	19.20	0.10
18.70	3.40	19.00	0.20
18.70	0.00	21.90	2.90
21.20	2.50	21.40	0.50
		$\bar{R}$	1.50


Límites de Control: Humedad

$$\text{LSC y LIC} = 20.46 \pm 3\left(1.5/1.128\right)$$

Línea Superior: 24.45

Línea Central: 20.46

Línea Inferior: 16.47



8.4 Diagramas de control por atributos

Los diagramas de control por atributos se construye a partir de la observación de la presencia o ausencia de una determinada característica (atributo o defecto) en cada una de las unidades, entonces se acepta o se rechaza contando cuantas unidades tienen o no el defecto, o comprobando el número de tales eventos que ocurren en la unidad, grupo o área, y comparando con el criterio de aceptación establecido. Se

acepta o rechaza la pieza o el lote sin asociar un valor concreto. El atributo a controlar se suele elegir de forma que sea fácilmente observable y por tanto económico de controlar.

En general los diagramas de Control por Atributos se utilizan con muestras grandes (cientos ó miles). Por otro lado el costo unitario de inspeccionar un atributo es menor y más fácil que el de inspeccionar una variable que se mide o se pesa.

Estas gráficas son útiles como medida del desempeño de un taller, departamento, empresa, etc. Generalmente el desempeño de la industria mejora después de introducir una gráfica para atributos como control de la calidad productiva, pues la gráfica es una representación visual continua de su funcionamiento.

Ejemplos de control por atributos:

- a) La pieza se rechaza si visualmente se observan una o más ralladuras de 0.5 cm.
- b) Un tornillo se acepta si su diámetro está comprendido entre 2.1 y 2.2 mm y se rechaza en otro caso (no es necesario medir el diámetro, basta utilizar un calibre que permita comprobar si se cumple la característica).
- c) Un lote se rechaza si posee más de 15 piezas defectuosas.

Los tipos más frecuentes de diagramas de control por atributos son:

- Diagrama “p”, ejemplo: fracción de piezas defectuosas (p)
- Diagrama “n p”, ejemplo: número de piezas defectuosas por muestra.
- Diagrama “c”, N° de defectos por muestra.
- Diagrama “u”, N° de defectos por unidad.

Límites de control, Para controlar el parámetro al igual que en las diagramas de control por variables, se establece la Línea Central y los Límites naturales del proceso, o Límites de Control Superior e Inferior.

Si el tamaño de cada grupo (numero de objetos inspeccionados) es constante estos límites son idénticos para cada grupo, y se emplean diagramas del tipo “ $n p$ ” y “ c ”. Sin embargo si el tamaño varia, los límites son diferentes para cada grupo, entonces son más útiles las diagramas del tipo p y u .

8.4.1 Diagrama “p”

Este diagrama presenta las variaciones expresadas en proporción de artículos defectuosos, que son los que no cumplen cierto atributo que no le permite pasar a la siguiente etapa del proceso productivo. Para obtener los datos, en cada lote i se toma una muestra de n_i artículos, éstos son revisados y se determina el número de defectuosos d_i . Con esta información se construyen los valores $p_i = \frac{d_i}{n_i}$. Considerando que la variable defectuoso y no defectuoso es una variable binomial, se determina $\mu = \bar{p}$ y $\sigma = \sqrt{\frac{\bar{p}(1-\bar{p})}{n}}$, donde n es el tamaño de cada muestra y $\bar{p}$ es la proporción promedio de artículos defectuosos. Los límites de control superior e inferior queden determinados por: $LSC - LIC = \bar{p} \pm 3\sqrt{\frac{\bar{p}(1-\bar{p})}{n}}$. Si el tamaño de n es variable se puede trabajar con un valor promedio de n ó un diagrama con límites variables.

Un problema de ésta técnica es que las gráficas de control pueden no tener Límite Inferior de Control y por otro lado, a medida que se mejora el proceso, p disminuye y por lo tanto se requiere incrementar el tamaño de los subgrupos.

El ejemplo: En una fábrica de tabaco que produce puros de exportación, al final del proceso de manufactura se hace inspección de la calidad e los mismos. Se evalúan lotes de 500 puros cada uno, en la tabla siguiente se tienen el número de puros rechazados.

Lote	# de Puros defectuosos	Lote	# de Puros defectuosos
01	9	11	6
02	5	12	15

03	4	13	14
04	7	14	11
05	8	15	12
06	9	16	13
07	9	17	10
08	11	18	11
09	13	19	7
10	14	20	8

Diagrama de Control p , proporción de defectos, a partir de los datos del problema de puros.

Para resolver éste problema con el programa INFOSTAT se debe crear una matriz de dos columnas una con el número de defectos y la otra con el tamaño de la muestras (subgrupo) de 500. El número de filas serán 20.


Resolución

<u>Proporción defectos</u>	<u>Proporción defectos</u>
0.02	
0.01	0.03
0.01	0.03
0.01	0.02
0.02	0.02
0.02	0.03
0.02	0.02
0.02	0.02
0.03	0.01
0.03	0.02
0.01	

Siendo, $n = 500$, $\bar{p} = 0.02$ y $(1 - \bar{p}) = 0.98$

Límites de Control: Proporción defectos

Línea Superior: 0.04
 Línea Central: 0.02
Línea Inferior: 1.0E-03



8.4.2 Diagrama “n p”

Cuando el tamaño de las muestras en los diagramas p es constante se puede usar el diagrama np , o diagrama del número de defectuosos. Las gráficas p y np muestran el mismo comportamiento pero a diferente escala. Las gráficas np se grafican directamente con los datos de piezas defectuosas y no es necesario calcular proporciones.

En éste diagrama se grafica el número de defectuosos por muestra d_i , en lugar de la proporción p_i . Es así que $\mu = n\bar{p}$ y $\sigma = \sqrt{n\bar{p}(1 - \bar{p})}$.

Los límites de control, LC, quedan determinados por:

$$LC = n\bar{p} \pm 3\sqrt{n\bar{p}(1 - \bar{p})}.$$

Ejercicio. Diagrama de Control np , a partir de los datos del problema de puros.


Sí $np = 9.80$, $n = 500$, $\bar{p} = 0.02$ y $(1 - \bar{p}) = 0.98$

Límites de Control

Línea Superior: 19.10

Línea Central: 9.80

Línea Inferior: 0.50



8.4.3 Diagrama “c”, número de defectos

Es frecuente que en los procesos industriales existan más de un tipo de defecto por objeto de estudio y sin embargo no hacen que se clasifica al producto como descartable, son características indeseables pero que no necesariamente impidan que el producto pase o no a la siguiente fase del proceso como sucede con los diagramas “p” y “np”. En esto caso se utilizan los diagramas “c” y “u”. También se pueden usar éstos diagramas en casos como “número de fallas por operario”, números de quejas por un mal servicio” “número de fallas de una máquina”, etc.

El objetivo de diagrama “c” es analizar la variabilidad del número de defectos por muestra de tamaño uniforme, siendo “ c_i ” el número de defectos en la muestra i . Se parte de que “c” sigue una distribución de Poisson, en la cual el promedio y la variancia tienen igual valor, quedando: μ y $\sigma^2 = \bar{c} = LC = \frac{\text{Total defectos}}{\text{Total muestras}}$, y los límites $LSC, LIC = \bar{c} \pm 3\sqrt{\bar{c}}$.

Ejemplo: Se posee los datos de 30 meses del número de quejas de clientes por mes de una central telefónica atendida por tres operarios los meses 1-15 y por dos operarios los meses 16-30. Se quiere saber si las quejas por servicio se han mantenido estables en el tiempo.

Mes	Quejas	Mes	Quejas
1	9	16	8
2	8	17	6
3	6	18	8
4	7	19	9
5	5	20	6
6	8	21	7
7	9	22	5
8	10	23	4
9	12	24	5
10	14	25	4
11	13	26	3
12	11	27	4
13	9	28	6
14	8	29	5
15	7	30	4

Diagrama de Control c, a partir de los datos del problema de quejas por central telefónica


$$LSC, LIC = 7.33 \pm 3\sqrt{7.33}.$$

Límites de Control: quejas x central

Línea Superior: 15.46

Línea Central: 7.33

Línea Inferior: 0.00



8.4.4 Diagrama “u”, número de defectos por unidad

El diagrama u, se utiliza cuando el número de elementos por muestras no es constante ó cuando se quiere estudiar el número promedio de defectos por unidad o artículo estudiado, en lugar del número de defectos por muestra.


Se define la media “i” de defectos por muestra de “n” elementos $\mu_i = c_i/n_i$. Quedando el Límite de Control Central:

$$\bar{\mu} = LC = \frac{\text{Total defectos}}{\text{Total artículos inspeccionados}}. \text{ Si } \sigma_i = \sqrt{\bar{\mu}/n_i}$$

Se pueden construir límites de control variables de la siguiente manera LSC-LIC= $\bar{\mu} \pm 3 \sqrt{\bar{\mu}/n_i}$. De ésta manera para cada tamaño de muestra habrá límites diferentes.

Diagrama de Control u, a partir de los datos del problema de quejas por operario

$$\text{LSC-LIC} = 2.83 \pm 3 \sqrt{2.83/3 \text{ o } 2}$$



Este gráfico muestral límites inferiores y superiores variables

Ejercicio 8.1 En una línea de fabricación de cajas de madera se han inspeccionado 30 lotes de 500 unidades cada uno. El número de unidades defectuosas por lote resultó en: 8, 10, 10, 4, 13, 9, 7, 11, 13, 13, 5, 14, 12, 8, 15, 11, 9, 17, 6, 12, 6, 12, 8, 12, 14, 6, 5, 9, 5 y 11. Construir una carta de control " p " y " $n p$ ".

Ejercicio 8.2 En un proceso de fabricación de computadoras el número de defectos totales por cada 5 computadoras fue de 5, 6, 4, 5, 3, 4, 2, 3, 4, 4, 5, 3, 3, 3, 3, 2, 3, 1, 2, 3, 1. Construir una carta de control c y otra u , comente lo observado.

Tabla parcial para construir tablas de control

Tamaño de muestra	A_2	D_3	D_4	C_4	D_2
2	1.880	0.0000	3.2686	0.7979	1.128
3	1.023	0.0000	2.5735	0.8862	1.693
4	0.729	0.0000	2.2822	0.9213	2.059
5	0.577	0.0000	2.1144	0.9400	2.326
6	0.483	0.0000	2.0039	0.9515	2.534
7	0.419	0.0758	1.9242	0.9594	2.704
8	0.373	0.1359	1.8641	0.9650	2.847
9	0.337	0.1838	1.8162	0.9693	2.970
10	0.308	0.2232	1.7768	0.9727	3.078

Bibliografía Consultada

- Cajal, H. U. (sf). *Material docente de la Unidad de Bioestadística Clínica*. Recuperado el 15 de Enero de 2009, de http://www.hrc.es/bioest/M_docente.html#tema2
- Cebrián, M. (2001). *Distribuciones continuas*. Recuperado el 14 de Julio de 2009, de Ministerio de Educación y ciencia:
http://descartes.cnice.mecd.es/Bach_HCS_2/distribuciones_probabilidad/dis_continuas.htm
- CYTA. (s.f.). *Guía de Estadísticas. Distribución de Poisson* . Recuperado el 14 de Julio de 2009, de
http://www.cyta.com.ar/biblioteca/bddoc/bdlibros/guia_estadistica/index.htm
- Daniel, W. (2006). *Bioestadística. Base para el análisis de las ciencias de la salud* . México: Limusa.
- DATA MINING INSTITUTE . (2001). *UNIANOVA - Diseño Completamente Aleatorio*. Recuperado el 17 de Julio de 2009, de
<http://www.estadistico.com/arts.html?20011015>
- Gonzalez, L. (2004). *INFOSTAT, Manual del usuario*. Córdoba: Universidad Nacional de Córdoba.
- Gutiérrez, H., & De la Vara, R. (2004). *Control estadístico de la calidad y seis sigmas*. México: McGraw Hill.
- Hernández, L., Castillo, A., Bofill, A., & Pons, R. (87). *Probabilidades*. Habana: Pueblo y Educación.
- Kessler, M. (2005). *Apuntes de Métodos estadísticos de la Ingeniería*. Recuperado el 14 de Julio de 2009, de
<http://filemon.upct.es/~mathieu/metodos/teoria/pdftema3.pdf>
- Lacayo, I. (2002). *Análisis de Variancia con SPSS 8.0*. Recuperado el 5 de Diciembre de 2008, de Universidad Rafael Bellosó:
<http://www.aibarra.org/Apuntes/Estadistica/00032969.doc>
- Little T y Hills, J. (1990.). *Métodos estadísticos para la investigación en la agricultura*. México: Trillas.
- Martínez Garza, A. (1988). *Diseños experimentales, métodos y elementos de teoría*. México: Trillas.

- Mendenhall, W. (2008). Estadística para administradores. México: Iberoamericana.
- Peña, D. (s.f.). Estadística I, modelos y métodos, Fundamentos.
- Pérez de Vargas, A., & Abaira, V. (1996). *Bioestadística*. Recuperado el 14 de Julio de 2009, de Salud Madrid: http://www.hrc.es/bioest/Probabilidad_1.html
- Ross, S. (2002). *Probabilidad y estadística para ingenieros*. México: Mc Graw Hill.
- Sampieri, R., & Fénández, C. y. (2003). Metodología de la Investigación. México: Mc Graw Hill.
- Sánchez, G. (s.f.). *CARTAS DE CONTROL CON SPSS*. Recuperado el 24 de Junio de 2008, de Universidad de Salamanca: <http://web.usal.es/~guillerm/>
- Sifuentes, V. (2002). *Curso Análisis Multivariante aplicado a la industria pesquera*. Perú: IMARPE.
- Spiegel, M. y. (2002). *Estadística*. México: Mc Graw Hill.
- Vermeer, I. (1996). *Estadística. Curso Básico*. Estelí: EAGE.
- Young, R. y. (1975). *Introducción a la Estadística Aplicada a las Ciencias de la Conducta*. México: Trillas.
- Zadú, I. (s.f.). *Metodología. Variable Aleatoria*. . Recuperado el julio de 15 de 2009, de <http://www.southlink.com.ar/vap/VARIABLE%20ALEATORIA.htm>